

$y T w \ f l$

$S 2 M ; . B M ;$

3. 核心因果 estimand：主层平均因果效应

主分层框架的核心贡献之一是提出了更精细的因果效应定义。

主层平均因果效应 (Principal Stratified Average Causal Effect, PSACE):

$$\tau^{\mathcal{S}_s} = \mathbb{E}(Y_i(1) - Y_i(0) \mid i \in \mathcal{S}_s),$$

即在主层 $\mathcal{S}_s$ 内的平均因果效应。

不同的 estimand 有不同的解释：

- $\tau^{\mathcal{S}_C}$ ：对**依从者层 (compliers)**的平均因果效应 (Complier Average Causal Effect, CACE) ——这正是 IV 框架中识别的效应！
- $\tau^{\mathcal{S}_1}$ ：对**始终-takers**的平均因果效应
- $\tau^{\mathcal{S}_0}$ ：对**never-takers**的平均因果效应

这揭示了一个深刻结论：**工具变量 (IV) 方法识别的恰好是 compliers 层上的因果效应**——这就是为什么 IV 的解释依赖于依从性假设。

4. 主分层在中介分析中的应用

主分层框架在中介分析中也发挥核心作用。考虑一个两步处理设定：

$$Z \rightarrow M \rightarrow Y,$$

其中 Z 是处理， M 是中介， Y 是结果。

在这个框架中，我们关注一个微妙的问题： M 的变化是否完全由 Z 引起？如果某些个体的 M 在 $Z = 0$ 时已经处于高水平（无论 Z 如何），那么 Z 对 M 的“因果效应”在这些个体上为零。

因果中介分析中的主分层：根据 $M_i(1)$ 和 $M_i(0)$ 对个体进行分层（这与上面的 D 分层框架完全平行），可以得到：

- **直接效应：** $Y_i(1, M_i(0)) - Y_i(0, M_i(0))$ ，即在反事实 $M_i(0)$ 下， Z 的变化对 Y 的影响；
- **间接效应：** $Y_i(1, M_i(1)) - Y_i(1, M_i(0))$ ，即通过 M 传导的效应。

5. 可识别性与关键假设

主层本身是不可识别的（因为我们无法观测 $D_i(1)$ 和 $D_i(0)$ 同时取值）。但通过额外的因果假设，我们可以识别某些主层的因果效应：

单调性假设： $D_i(1) \geq D_i(0)$ 对所有 i 成立。这意味着没有人会因为处理而反而放弃处理——这是一个弱的非稀释假设。

在单调性下，始终-takers 层 ($\mathcal{S}_1$) 的规模为：

$$\mathbb{E}(\mathcal{S}_1) = \mathbb{E}(D_i(1) - D_i(0)) = \mathbb{E}(D_i(1)) - \mathbb{E}(D_i(0)),$$

即处理组和对照组的处理施与率之差。

排他性假设 (Exclusion Restriction)：对 compliers 层，直接处理效应为零——这意味着处理 Z 对结果 Y 的影响完全通过处理指示变量 D 实现。

这些假设共同构成了 IV 识别策略的基础。

6. 本章小结

主分层框架为因果推断提供了一个统一的概念工具，使得我们能够：

- (1) 在处理施与取决于潜在结果的复杂场景中，仍然可以谈论因果效应；
- (2) 将 IV 方法的估计量解释为 compliers 层上的因果效应；
- (3) 在中介分析中精确区分直接效应和间接效应；
- (4) 通过透明的假设（单调性、排他性）明确识别策略的适用范围。

主分层是现代因果推断的一块基石，建议后续阅读？的原文以深入理解其动机和数学结构。

经典参考文献：？（《中华流行病学杂志》），以及？第 4 章关于 IV 和主分层的讨论。

中介分析：自然直接效应与自然间接效应

1. 本章导论：一个古老的追问

当我们说“吸烟导致肺癌”时，这个说法究竟意味着什么？

一方面，烟草中的有害物质可能直接作用于细胞，引发癌变；另一方面，吸烟可能通过影响其他生理指标——比如血压、免疫力或慢性炎症——进而间接地增加患癌风险。这两种机制，本质上完全不同：一种是直接杀伤，另一种是通过一连串中间步骤传导的**间接效应**。

理解因果效应的这种**传导机制** (transmission mechanism)，是科学研究的核心关切之一。生物医学研究者想知道某种药物是通过什么生化通路发挥作用的；社会学家想知道贫困是通过什么社会机制影响健康结果的；政策制定者想知道一项教育改革是直接改善了学生能力，还是通过改变学校资源配置间接起效。**中介分析** (mediation analysis) 正是回答这类问题的统计框架。

本章的组织如下。我们首先通过具体实例说明中介分析的应用场景；然后引入**嵌套潜在结果** (nested potential outcomes) 的数学框架；接着建立识别中介效应的**中介公式** (mediation formula)；最后在线性模型下推导出经典的 **Baron-Kenny 公式**，并讨论其敏感性分析。

2. 从总效应到直接效应与间接效应

在中介分析的框架中，我们有四个核心变量：处理 Z (treatment)、结果 Y (outcome)、中介 M (mediator) 以及背景协变量 X (covariates)。它们之间的因果关系可以直观地用有向无环图 (DAG) 表示 (??)。

核心问题：总的因果效应 τ 中，有多少是通过中介变量 M 传导的 (**间接效应**)，有多少是不经过 M 的 (**直接效应**)？

以下三个真实研究场景可以帮助我们理解中介分析的应用。

例 27.1 (遗传变异与肺癌：通过吸烟的中介). (2012) 研究了染色体 15q25.1 上的遗传变异如何影响肺癌风险。¹ 该研究的核心问题是：遗传变异是通过影响吸烟行为 (吸烟量) 进而增加肺癌风险的，还是通过其他独立通路 (如直接影响肺部细胞) 直接致癌的？这就是一个典型的中介分析问题：遗传变异是处理 Z ，吸烟是中介 M ，肺癌是结果 Y 。

例 27.2 (邻里贫困与青少年物质使用：学校与同伴环境的中介). 等人 (2018) 研究了邻里贫困对青少年物质使用的影响，并探讨了这一影响是通过学校和同伴环境传导的。² 他们使用了美国国家共病调查 (National Comorbidity Survey) 的数据，将邻里贫困指数作为处理，青少年物质使用 (如饮酒、吸毒) 作为结果，而学校和同伴环境因素作为中介。

¹详见 ?。

²详见 ?。

例 27.3 (就业培训对心理健康：工作搜寻效能的中介). *JOBS II* 是一个关于就业培训对失业工人影响的现场实验。³ 该培训项目的目的不仅是提高再就业率，还希望改善求职者的心理健康。研究者感兴趣的是：培训对心理健康的效应中，有多少是通过提高工作搜寻效能这一中介传导的，又有多少是通过其他途径（如社会支持网络）直接产生的。⁴

3. 嵌套潜在结果

3.1. 潜在结果的两层结构. 为了定义直接效应与间接效应，我们需要引入**嵌套潜在结果** (nested potential outcomes) 这一概念。[?] 和 [?] 是这一理论的奠基人。

首先，考虑对处理 z 进行干预，定义对应的潜在中介和潜在结果：

$$\{M(z), Y(z) : z = 0, 1\}.$$

然后，考虑同时对 z 和 m 进行干预，定义：

$$\{Y(z, m) : z = 0, 1, m \in \mathcal{M}\},$$

其中 $\mathcal{M}$ 是中介所有可能的取值范围。

关键的一步是考虑**嵌套干预** (nested intervention)：将 z 设定为某个值，但将 m 设定为在另一个处理水平下的潜在中介值。记 $M_{z'} \equiv M(z')$ ，[?] 和 [?] 定义了嵌套潜在结果：

$$\{Y(z, M_{z'}) : z = 0, 1, z' = 0, 1\}.$$

其中 $Y(z, M_{z'})$ 表示：如果治疗被设定为 z ，而中介被设定为在治疗 z' 下的潜在值 $M_{z'}$ ，则结果会是什么。注意 z 和 z' 可以不同——这正是其“嵌套”之处。

在二值处理的设定下，我们有四个嵌套潜在结果：

$$\{Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)\}.$$

其中 $Y(1, M_1)$ 表示：如果治疗设为 $z = 1$ 且中介设为在 $z = 1$ 下的自然值，则结果如何。类似地， $Y(0, M_0)$ 表示治疗设为 $z = 0$ 且中介设为在 $z = 0$ 下的自然值的情形。

Composition 假设确保了嵌套潜在结果与标准潜在结果之间的一致性。

[Composition 假设] $Y(z, M_z) = Y(z)$ ，对 $z = 0, 1$ 成立。

Composition 假设是不可证明的，它本质上是一个假设。但在实践中，我们完全可以将 $Y(1)$ 定义为 $Y(1, M_1)$ ，将 $Y(0)$ 定义为 $Y(0, M_0)$ ，这样该假设就自动成立了。

现在，我们可以正式定义三种效应。

定义 27.1 (总效应、自然直接效应与自然间接效应). 总效应 (*total effect*) 定义为

$$\tau = \mathbb{E}\{Y(1) - Y(0)\}.$$

自然直接效应 (*natural direct effect, NDE*) 定义为

$$= \mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}.$$

自然间接效应 (*natural indirect effect, NIE*) 定义为

$$= \mathbb{E}\{Y(1, M_1) - Y(1, M_0)\}.$$

这三个效应的含义如下：

- **总效应** τ ：标准的平均因果效应，即治疗从 0 变到 1 对结果的平均影响。
- **NDE** $\mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}$ ：如果将治疗从 0 变到 1，但把中介固定在无治疗时的自然水平 M_0 ，结果的平均变化。这个效应衡量的是**不经过 M 的直接通路**的贡献。

³我们在 ?? 章中曾使用过这个数据集。

⁴我们将在 ?? 节中回到这个例子，展示 Baron-Kenny 方法的具体应用。

- **NIE** $\mathbb{E}\{Y(1, M_1) - Y(1, M_0)\}$: 如果保持治疗 $z = 1$ 不变, 但把中介从无治疗时的自然水平 M_0 变到治疗时的自然水平 M_1 , 结果的平均变化。这个效应衡量的是**通过中介 M 传导**的间接贡献。

在 Composition 假设下, 总效应可以分解为自然直接效应与自然间接效应之和。

命题 27.2 (效应的分解). 在 ?? 和 ?? 下, 有

$$\tau = +.$$

为什么 NIE 可以衡量间接效应? 直观上, $Y(1, M_1) - Y(1, M_0)$ 表示: 将治疗固定在 $z = 1$, 但让中介从“如果没有治疗它会是什么”变为“如果有治疗它会是什么”, 结果会如何变化。这恰恰描述了“治疗通过改变中介而影响结果”这条通路上的效应。

然而, $Y(1, M_0)$ 这个量本身有一个深刻的概念困难: 它是一个**跨世界 counterfactual** (cross-world counterfactual)。 $z = 1$ 和 $m = M_0$ 这两个干预不可能在同一个实验中同时发生——同一个单元不可能既接受治疗 $z = 1$, 又同时处于无治疗条件下的中介水平。要理解 $Y(1, M_0)$, 我们必须借助平行世界的想象 (??)。

[width = 0.7]figures/crossworld.pdf

FIGURE 2. 跨世界 counterfactual $Y(1, M_0)$ 和 $Y(0, M_1)$ 的示意图。同一单元在两个平行世界中分别接受不同的治疗, 从而获得不同的中介值。

这种跨世界的性质引发了一个哲学上的争议。⁵ 将 $Y(1, M_0)$ 和 $Y(0, M_1)$ 称为**先验 counterfactual** (a priori counterfactuals), 因为我们无法在任何物理实验中观察到它们。按照 ? 的可证伪性标准, 如果一个陈述无法被任何物理实验或观测所证伪, 那它就不是科学的, 而是形而上学的。因此, 严格的 Popperian 统计学家可能会认为中介分析是形而上学。⁵

不过, ? 对整个潜在结果框架都提出了类似的批评。但他的批评是过度的: 即使我们无法同时观察到 $Y(1)$ 和 $Y(0)$, 我们仍然可以通过边缘分布的信息对它们做出可证伪的陈述。 $Y(1, M_0)$ 的困难在于它是真正无法在任何实验中触及的——这与 $\{Y(1), Y(0)\}$ 的性质根本不同。

4. 中介公式

4.1. 四个关键假设. 中介公式的识别依赖于四个假设。前三个假设本质上是在说: 治疗 and 中介在给定协变量 X 的条件下都是被随机化的。

[无治疗—结果混淆] 给定 X , 治疗与潜在结果独立:

$$Z \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

[无中介—结果混淆] 给定 (X, Z) , 中介与潜在结果独立:

$$M \perp\!\!\!\perp Y(z, m) \mid (X, Z), \quad \forall z, m.$$

[无治疗—中介混淆] 给定 X , 治疗与潜在中介独立:

$$Z \perp\!\!\!\perp M(z) \mid X, \quad \forall z.$$

⁵这一争议的详细讨论见 ? 和 ?。

这三个假设共同构成了**序列可忽略性** (sequential ignorability)：在给定 X 的条件下，治疗分配是可忽略的；进一步在给定 (X, Z) 的条件下，中介分配也是可忽略的。序列可忽略性等价于在给定 X 的条件下 (Z, M) 是联合随机化的：

$$(136) \quad (Z, M) \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

?? 与 ???? 的等价性留作练习。⁶

最后一个假设是跨世界独立性。

[跨世界独立性] 给定 X ，潜在结果与潜在中介独立：

$$Y(z, m) \perp\!\!\!\perp M(z') \mid X, \quad \forall z, z', m.$$

前三个假设至少在随机化实验中是可以保证的，但 ?? 更为强——没有任何物理实验可确保它，因为当 $z \neq z'$ 时，我们永远无法同时观察到 $Y(z, m)$ 和 $M(z')$ 。这正是 $Y(1, M_0)$ 等 cross-world counterfactual 的根本困难所在。

例 27.4 (验证假设的数据生成过程). 给定 X ，我们按如下方式生成数据：

$$\begin{aligned} Z &= 1\{g_Z(X, \varepsilon_Z) \geq 0\}, \\ M(z) &= 1\{g_M(X, z, \varepsilon_M) \geq 0\}, \quad z = 0, 1, \\ Y(z, m) &= g_Y(X, z, m, \varepsilon_Y), \quad z, m = 0, 1, \end{aligned}$$

其中 $\varepsilon_Z, \varepsilon_M, \varepsilon_Y$ 相互独立。⁷ 可以验证，在上述数据生成过程下，???????? 均成立。如果允许 ε_M 和 ε_Y 依赖于处理水平（即改为 $\varepsilon_M(z)$ 和 $\varepsilon_Y(z, m)$ ），则这些假设可能被违反。

4.2. 识别公式. ? 证明了以下关键结果。

定理 27.3 (中介公式). 在 ???????? 下，有

$$\mathbb{E}\{Y(z, M_{z'}) \mid X = x\} = \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x) \Pr(M = m \mid Z = z', X = x).$$

定理的含义： 我们无法直接观察跨世界 counterfactual $Y(z, M_{z'})$ ，但 ???????? 这四个假设足够将这个不可观测的量表达为可观测条件分布的函数。具体来说， $Y(z, M_{z'})$ 的期望等于：结果的条件期望（给定 $Z = z, M = m, X = x$ ）对中介的分布（给定 $Z = z', X = x$ ）的加权和。

为什么四个假设缺一不可？ 定理的证明（见附录 ??）清楚地展示了这四个假设各自的角色：?? 保证了 $\Pr(M = m \mid Z = z', X = x) = \Pr(M_{z'} = m \mid X = x)$ ，?? 允许我们交换 $Y(z, m)$ 与 $M_{z'}$ 的条件，???? 则保证了结果的识别。

对 X 求期望，得到无条件版本：

$$\mathbb{E}\{Y(z, M_{z'})\} = \sum_x \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x) \Pr(M = m \mid Z = z', X = x) \Pr(X = x).$$

对于连续型 M 和 X ，求和替换为积分。

由 ?? 和 ??，我们可以得到 NDE 和 NIE 的识别公式。

⁶详见 ?? 题。

⁷详见 ?。

推论 27.4 (NDE 和 NIE 的识别). 在 ???????? 下, 条件 NDE 和 NIE 由下式识别:

(137)

$$(x) = \sum_m [\mathbb{E}(Y | Z = 1, M = m, X = x) - \mathbb{E}(Y | Z = 0, M = m, X = x)] \Pr(M = m | Z = 0, X = x),$$

(138)

$$(x) = \sum_m \mathbb{E}(Y | Z = 1, M = m, X = x) [\Pr(M = m | Z = 1, X = x) - \Pr(M = m | Z = 0, X = x)].$$

理解 ?? 的直觉: (x) 衡量的是将处理从 0 变到 1 (但保持中介在无处理时的自然分布) 的效应。在每个中介值 m 下, 处理从 0 变到 1 的条件效应是 $\mathbb{E}(Y | Z = 1, M = m, X = x) - \mathbb{E}(Y | Z = 0, M = m, X = x)$; 由于中介被固定在 $Z = 0$ 条件下的分布, 这些条件效应需要按 $\Pr(M = m | Z = 0, X = x)$ 加权求和。

对于二值中介 $M \in \{0, 1\}$, ?? 中的 NIE 公式可以化简为一种优美的乘积形式。

推论 27.5 (二值中介的 NIE 乘积公式). 在 ???????? 下, 对二值中介 M , 有

$$(x) = \tau_{Z \rightarrow M}(x) \cdot \tau_{M \rightarrow Y}(1, x),$$

其中

$$\tau_{Z \rightarrow M}(x) = \Pr(M = 1 | Z = 1, X = x) - \Pr(M = 1 | Z = 0, X = x)$$

是 Z 对 M 的条件平均因果效应,

$$\tau_{M \rightarrow Y}(z, x) = \mathbb{E}(Y | Z = z, M = 1, X = x) - \mathbb{E}(Y | Z = z, M = 0, X = x)$$

是 M 对 Y 的条件平均因果效应。

为什么叫乘积公式? 直观上, 间接效应是这样传导的: 首先, 处理 Z 变化导致中介 M 变化 (效应 $\tau_{Z \rightarrow M}$); 然后, 中介 M 变化导致结果 Y 变化 (效应 $\tau_{M \rightarrow Y}$)。这两段效应的乘积, 就是总间接效应。这与我们的直觉完全一致。

?? 的证明留作练习。⁸

5. 线性模型下的 Baron-Kenny 方法

?? 给出了非参数识别公式, 它允许我们在各种不同模型下推导出中介效应的具体形式。本节介绍经典而又广泛使用的 **Baron-Kenny 方法** (?), 该方法假设线性模型。

5.1. 模型设定. Baron-Kenny 方法假设中介和结果都满足线性模型 (??)。

[Baron-Kenny 线性模型] 中介和结果的条件期望满足线性模型:

$$(27.1) \quad \begin{cases} \mathbb{E}(M | Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y | Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

在上述线性模型下, NDE 和 NIE 可以简化为系数的简洁函数。

推论 27.6 (Baron-Kenny 公式). 在 ???????????? 下, 有

$$(27.2) \quad \quad \quad = \theta_1, \quad \quad = \theta_2 \beta_1.$$

⁸详见 ?? 题。

与 DAG 的对应：在 ?? 中， θ_1 是路径 $Z \rightarrow Y$ 的系数（直接效应）， $\beta_1\theta_2$ 是路径 $Z \rightarrow M \rightarrow Y$ 的系数之积（间接效应）。这与 ?? 完全一致。

为何不需要对 X 求和？注意在 ?? 和 ?? 中， (x) 和 (x) 是在给定 $X = x$ 的条件下的值。而在 Baron-Kenny 线性模型下， θ_1 和 $\theta_2\beta_1$ 与 x 无关，因此条件效应等于无条件效应。

Baron-Kenny 公式的推导见附录 ??。

如果获得了系数的 OLS 估计量 $\hat{\beta}_1$ 和 $\hat{\theta}_2$ ，则 NDE 和 NIE 的估计量为

$$\hat{\tau} = \hat{\theta}_1, \quad \hat{\tau} = \hat{\theta}_2\hat{\beta}_1,$$

这就是经典的 Baron-Kenny 估计。? 和 ? 利用 delta 方法给出了 $\hat{\tau}$ 的标准误：

$$\text{var}(\hat{\tau}) = \text{var}(\hat{\theta}_2)\hat{\beta}_1^2 + \hat{\theta}_2^2\text{var}(\hat{\beta}_1).$$

基于此的假设检验称为 Sobel's test。⁹

Baron-Kenny 方法的历史：虽然 ? 使这一方法广为人知，但它实际上有更早的渊源，包括 ?、? 和 ? 的工作。? 进一步发展了推断方法。

6. 应用实例：JOBS II 数据

我们通过 R 代码实现 Baron-Kenny 方法，并将其应用于 JOBS II 数据集。¹⁰

例 27.5 (JOBS II: 就业培训对心理健康的中介分析). 我们关注就业培训（处理 Z ）对心理健康（结果 Y ，用抑郁量表得分度量）的影响，以及这一影响是否通过工作搜寻效能（中介 M ）传导。背景协变量 X 包括经济困难程度、基线抑郁得分、性别、年龄、职业、婚姻状态、种族、教育程度和家庭收入。

通过以下 R 代码实现 Baron-Kenny 方法：

```
library("car")
BKmediation = function(Z, M, Y, X) {
  mediator.reg = lm(M ~ Z + X)
  mediator.Zcoef = mediator.reg$coef[2]
  mediator.Zse = sqrt(hccm(mediator.reg)[2, 2])

  outcome.reg = lm(Y ~ Z + M + X)
  outcome.Zcoef = outcome.reg$coef[2]
  outcome.Zse = sqrt(hccm(outcome.reg)[2, 2])
  outcome.Mcoef = outcome.reg$coef[3]
  outcome.Mse = sqrt(hccm(outcome.reg)[3, 3])

  NDE = outcome.Zcoef
  NIE = outcome.Mcoef * mediator.Zcoef

  NDE.se = outcome.Zse
  NIE.se = sqrt(outcome.Mse^2 * mediator.Zcoef^2 +
                outcome.Mcoef^2 * mediator.Zse^2)
```

⁹关于 Sobel 检验的更多讨论见 ?。

¹⁰JOBS II 是一个关于就业培训对失业工人影响的随机化现场实验。数据集在 R 的 `mediation` 包中。

```
res = matrix(c(NDE, NIE, NDE.se, NIE.se,
               NDE/NDE.se, NIE/NIE.se), 2, 3)
rownames(res) = c("NDE", "NIE")
colnames(res) = c("est", "se", "t")
res
}
```

运行结果如下：

```
> res = BKmediation(Z, M, Y, X)
> round(res, 3)
      est      se      t
NDE -0.037  0.042 -0.885
NIE -0.014  0.009 -1.528
```

估计的直接效应 $\hat{\tau} = -0.037$ （培训对心理健康的直接保护效应）和间接效应 $\hat{\tau} = -0.014$ （通过提高工作搜寻效能而改善心理健康）均为负，但统计上均不显著。这表明 *JOBS II* 培训项目对心理健康的效应尚无充分证据支持按中介路径分解。

一个值得注意的现象：在某些设定下，间接效应可能出现违反直觉的符号。例如，如果 $Z \rightarrow M$ 的效应 $\beta_1 > 0$ ， $M \rightarrow Y$ 的效应 $\theta_2 > 0$ ，但 Z 与 M 之间存在负交互项 $\theta_3 < 0$ ，则乘积 $\beta_1(\theta_2 + \theta_3)$ 可能为负。这被称为**中介悖论**（mediator paradox）或**替代终点悖论**（surrogate endpoint paradox）。^a

^a详见？。

7. 敏感性分析

中介分析依赖于强且不可检验的假设。关键的不可检验假设是跨世界独立性（??）：我们无法通过任何实验数据验证 $Y(z, m)$ 与 $M(z')$ 在 $z \neq z'$ 时是否独立。

因此，研究者常常需要进行**敏感性分析**（sensitivity analysis），以探索当关键假设不成立时，结论会如何变化。主要文献包括：

- ? 提出了类似 Cornfield 的敏感性界；
- ? 提出了针对 Baron–Kenny 线性模型量身定制的敏感性分析方法。

敏感性分析的具体方法超出了本章的范围，但读者应记住：中介分析的结果必须谨慎解读，因为其核心假设无法被数据验证。

8. 本章小结

本章围绕中介分析展开，主要内容如下：

- (1) **核心问题：**因果效应如何在直接通路和间接通路之间分配？
- (2) **嵌套潜在结果** $Y(z, M_{z'})$ ：描述跨世界 counterfactual，是定义 NDE 和 NIE 的基础。
- (3) **效应分解：**在 Composition 假设下，总效应 $\tau = +$ 。
- (4) **识别假设：**四个假设（序列可忽略性 + 跨世界独立性）下，中介公式成立。
- (5) **中介公式：**将不可观测的 NDE 和 NIE 表达为可观测条件分布的函数。
- (6) **Baron–Kenny 公式：**在 ?? 下， $\tau = \theta_1$ ， $\tau = \theta_2\beta_1$ 。
- (7) **跨世界 counterfactual 的哲学争议：**严格的 Popperian 认识论者认为中介分析是形而上学的。
- (8) **敏感性分析：**由于核心假设不可检验，敏感性分析是必要的。

中介公式的完整证明见附录 ??; Baron-Kenny 公式的推导见附录 ??; 各节练习题见附录 ??。

练习

练习 27.1. 假设 (Z, M, Y) 均为二值变量。基于潜在结果

$$M(1), M(0), Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)$$

的联合取值, 单元可以分成多少类型?

若进一步假设单调性 $M(1) \geq M(0)$ (Z 对 M 的单调性), 则单元可以分成多少类型?

若再假设 $Y(1, m) \geq Y(0, m)$ 且 $Y(z, 1) \geq Y(z, 0)$ 对所有 z, m 成立 (Z 和 M 对 Y 的单调性), 则单元可以分成多少类型?

本题答案见附录 ??。

练习 27.2. 证明 ?? 与 ???? 等价。

本题答案见附录 ??。

练习 27.3. ? 提出了另一组假设来推导中介公式:

$$\{Y(z, m), M(z')\} \perp\!\!\!\perp Z \mid X, \quad Y(z, m) \perp\!\!\!\perp M(z') \mid (Z = z', X),$$

对所有 z, z', m 成立。

证明: 在上述假设下, ?? 中的中介公式同样成立。

本题答案见附录 ??。

练习 27.4. 在 Baron-Kenny 线性模型 (??) 下, 首先拟合:

$$\hat{M} = \hat{\beta}_0 + \hat{\beta}_1 Z + \hat{\beta}_2^\top X, \quad \hat{Y} = \hat{\theta}_0 + \hat{\theta}_1 Z + \hat{\theta}_2 M + \hat{\theta}_4^\top X.$$

则 NIE 的估计量为乘积 $\hat{\theta}_2 \hat{\beta}_1$ (乘积法)。

另一方面, 首先拟合:

$$\hat{Y} = \hat{\alpha}_0 + \hat{\alpha}_1 Z + \hat{\alpha}_1^\top X,$$

再拟合:

$$\hat{Y} = \tilde{\theta}_0 + \tilde{\theta}_1 Z + \tilde{\theta}_2 M + \tilde{\theta}_4^\top X,$$

则 NIE 的另一估计量为差值 $\hat{\alpha}_1 - \tilde{\theta}_1$ (差值法)。

证明: $\hat{\alpha}_1 - \tilde{\theta}_1 = \hat{\theta}_2 \hat{\beta}_1$ 。

本题答案见附录 ??。

练习 27.5. 证明 ?? (二值中介的 NIE 乘积公式)。

本题答案见附录 ??。

练习 27.6. ? 建议在结果模型中加入处理与中介的交互项:

$$\begin{cases} \mathbb{E}(M \mid Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_3 ZM + \theta_4^\top X. \end{cases}$$

证明: 在此模型下,

$$= \theta_1 + \theta_3 \{\beta_0 + \beta_2^\top \mathbb{E}(X)\}, \quad = (\theta_2 + \theta_3) \beta_1.$$

并说明如何在 IID 数据下估计 和 。

本题答案见附录 ??。

练习 27.7. 考虑中介 M 服从正态线性模型、结果 Y 服从 *logistic* 模型：

$$\begin{cases} M | Z, X \sim \mathcal{N}(\beta_0 + \beta_1 Z + \beta_2^\top X, \sigma_M^2), \\ \text{logit}\{\Pr(Y = 1 | Z, M, X)\} = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

请将 β 和 θ 表示为模型参数和 X 分布的函数，并说明如何在 *IID* 数据下估计它们。

本题答案见附录 ??。

练习 27.8. 考虑二值中介 M 服从 *logistic* 模型、结果 Y 服从线性模型：

$$\begin{cases} \text{logit}\{\Pr(M = 1 | Z, X)\} = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y | Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

证明：

$$\beta_1 = \theta_1, \quad \beta_2 = \theta_2 \mathbb{E}\{\text{expit}(\beta_0 + \beta_1 + \beta_2^\top X) - \text{expit}(\beta_0 + \beta_2^\top X)\}.$$

并说明如何在 *IID* 数据下估计 β 和 θ 。

本题答案见附录 ??。

练习 27.9. 将嵌套潜在结果修改为

$$Y(z, F_{M_{z'}|X}) = \int Y(z, m) f(M_{z'} = m | X) dm,$$

其中 $F_{M_{z'}|X}$ 是条件分布而非确定值。相应地将 *NDE* 和 *NIE* 定义为

$$NDE = \mathbb{E}\{Y(1, F_{M_0|X}) - Y(0, F_{M_0|X})\}, \quad NIE = \mathbb{E}\{Y(1, F_{M_1|X}) - Y(1, F_{M_0|X})\}.$$

证明：在仅假设 ??????（不要求跨世界独立性）下， NDE 和 NIE 的识别公式与正文相同。

本题答案见附录 ??。

练习 27.10. ? 和 ? 综述并比较了主分层与中介分析两种方法。请查阅这些文献，并撰写一页总结，阐述两种方法的异同与各自的优缺点。

本题为开放性研究型练习，请参考 ? 和 ?。

受控直接效应

1. 引言：另一种处理中介变量的视角

第 27 章中介分析框架依赖于嵌套潜在结果，本质上，某些嵌套潜在结果在任何物理实验中都是不可观测的。如果我们坚持第 27.2.2 节回顾的波普尔科学哲学，那么我们只能定义可以用某些实验观测的量来表达的因果参数。本章讨论因果推断中处理中介变量的另一种观点。在这种观点下，我们只能定义直接效应，而无法定义间接效应。

2. 受控直接效应的定义

我们将 Z 和 M 视为两个可以人为干预的处理因素，并定义潜在结果 $Y(z, m)$ ，其中 $z = 0, 1$ 且 $m \in \mathcal{M}$ 。基于这些潜在结果，我们定义受控直接效应 (CDE) 如下。

定义 28.1 (受控直接效应 (CDE)). 定义

$$(139) \quad \text{CDE}(m) = E\{Y(1, m) - Y(0, m)\}.$$

根据定义， $\text{CDE}(m)$ 是在中介变量固定为 m 的条件下，处理的平均因果效应。参数 $\text{CDE}(m)$ 可以捕捉在中介为 m 时处理对结果的直接效应。然而，这种表述无法捕捉间接效应。特别地，参数 $E\{Y(z, 1) - Y(z, 0)\}$ 只衡量了在处理固定为 z 时中介对结果的影响，这不是间接效应的一个有意义的定义。

3. 识别与估计

为了识别 $\text{CDE}(m)$ ，我们需要以下假设，要求在给定 X 的条件下 Z 和 M 是联合随机的。

假设 28.1 (序贯 ignorability). 序贯 *ignorability* 要求

$$(140) \quad Z \perp Y(z, m) \mid X, \quad M \perp Y(z, m) \mid (Z, X),$$

或者等价地 (见习题 27.2),

$$(141) \quad (Z, M) \perp Y(z, m) \mid X.$$

我们重点讨论 Z 为二元、 M 也为二元的情形。从数学上看，我们可以将这个问题视为一个具有四个处理水平

$$(142) \quad (z, m) \in \{(0, 0), (0, 1), (1, 0), (1, 1)\}$$

的观察性研究。

下面将二元处理情形的结论推广到具有多个处理水平的观察性研究，识别

$$(143) \quad \mu_{zm} = E\{Y(z, m)\}$$

的 outcome regression、IPW 和 doubly robust 估计量。

定义

$$(144) \quad \mu_{zm}(x) = E(Y \mid Z = z, M = m, X = x)$$

为给定处理、中介和协变量时的结果条件均值。定义

(145)

$$e_{zm}(x) = \Pr(Z = z, M = m \mid X = x) = \Pr(Z = z \mid X = x) \Pr(M = m \mid Z = z, X = x)$$

为给定协变量时 Z 和 M 联合取值的概率。

定理 28.2 (受控直接效应的识别). 在假设 ?? 下, 我们有

$$(146) \quad \mu_{zm} = E\{\mu_{zm}(X)\} = E\left\{\frac{I(Z = z, M = m)Y}{e_{zm}(X)}\right\}.$$

Moreover, based on the working models $e_{zm}(X, \alpha)$ and $\mu_{zm}(X, \beta)$ for $e_{zm}(X)$ and $\mu_{zm}(X)$, respectively, we have the doubly robust formula

$$(147) \quad \mu_{zm}^{\text{dr}} = E\{\mu_{zm}(X, \beta)\} + E\left[\frac{I(Z = z, M = m)\{Y - \mu_{zm}(X, \beta)\}}{e_{zm}(X, \alpha)}\right],$$

which equals μ_{zm} if either $e_{zm}(X, \alpha) = e_{zm}(X)$ or $\mu_{zm}(X, \beta) = \mu_{zm}(X)$.

证明. 定理 ?? 的证明与标准无混淆观察性研究的证明类似。详见正文或补充材料。

根据结果均值模型, 我们可以获得 $\hat{\mu}_{zm}(x)$; 根据处理模型, 我们可以获得 $\hat{e}_z(x)$; 根据中介变量模型, 我们可以获得 $\hat{e}_m(z, x)$ 。我们可以通过以下估计量来估计 μ_{zm} :

• 结果回归法 (outcome regression):

$$(148) \quad \hat{\mu}_{zm}^{\text{reg}} = n^{-1} \sum_{i=1}^n \hat{\mu}_{zm}(X_i).$$

• IPW 估计量 (Horvitz-Thompson):

$$(149) \quad \hat{\mu}_{zm}^{\text{ht}} = n^{-1} \sum_{i=1}^n \frac{I(Z_i = z, M_i = m)Y_i}{\hat{e}_z(X_i)\hat{e}_m(z, X_i)}.$$

• IPW 估计量 (Hajek 型):

$$(150) \quad \hat{\mu}_{zm}^{\text{haj}} = \frac{\sum_{i=1}^n \frac{I(Z_i=z, M_i=m)Y_i}{\hat{e}_z(X_i)\hat{e}_m(z, X_i)}}{\sum_{i=1}^n \frac{I(Z_i=z, M_i=m)}{\hat{e}_z(X_i)\hat{e}_m(z, X_i)}}.$$

• 增强 IPW / 双重稳健估计量 (augmented IPW):

$$(151) \quad \hat{\mu}_{zm}^{\text{dr}} = \hat{\mu}_{zm}^{\text{reg}} + n^{-1} \sum_{i=1}^n \frac{I(Z_i = z, M_i = m)\{Y_i - \hat{\mu}_{zm}(X_i)\}}{\hat{e}_z(X_i)\hat{e}_m(z, X_i)}.$$

然后我们可以通过 $\hat{\mu}_{1m}^* - \hat{\mu}_{0m}^*$ (其中 $*$ = reg, ht, haj, dr) 来估计 $\text{CDE}(m)$, 并使用 Bootstrap 来近似标准误。

如果我们愿意假设线性结果模型, 受控直接效应简化为处理的系数。见下例。

例 28.1 (线性结果模型下的 CDE). 在假设 ?? 下, 假设线性结果模型

$$(152) \quad E(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^T X,$$

我们可以证明 $\text{CDE}(m) = \theta_1$ (对所有 m 均成立), 这与 Baron-Kenny 方法中的自然直接效应一致。详见习题 ??。

4. 讨论：中介变量因果框架的比较

受控直接效应的表述不涉及嵌套潜在结果或先验 counterfactual 潜在结果，其识别也不需要跨世界 counterfactual 独立性假设。参数 $CDE(m)$ 可以捕捉在中介为 m 时处理对结果的直接效应。然而，这种表述无法捕捉间接效应。表 ?? 总结了中介变量的因果框架。

TABLE 1. 中介变量的因果框架比较

章节	框架	直接效应	间接效应
26	主体分层 (principal stratification)	$\tau(1, 1), \tau(0, 0)$	?
27	中介分析 (mediation analysis)	NDE	NIE
28	受控直接效应 (controlled direct effect)	$CDE(m)$	?

中介分析框架可以将总效应分解为自然直接效应和自然间接效应，但它需要嵌套潜在结果和跨世界独立性。主体分层框架和受控直接效应框架无法定义间接效应，但它们不涉及嵌套潜在结果和跨世界独立性。此外，主体分层框架并不一定要求 M 位于处理到结果的因果通路上。然而，其识别和估计涉及混合分布的分离，这是一个非平凡的统计任务。

5. 多值处理的推广

定理 ?? 是具有多个处理水平无混淆观察性研究结论的特殊情形 (Imai and Van Dyk, 2004; Cattaneo, 2010)。

考虑一个具有多值处理 $Z \in \{1, \dots, K\}$ 、协变量 X 和结果 Y 的观察性研究。单元 i 有 K 个潜在结果 $Y_i(1), \dots, Y_i(K)$ 对应于 K 个处理水平。一般地，我们可以基于潜在结果的对比定义因果效应：

$$(153) \quad \tau_C = \sum_{k=1}^K C_k E\{Y(k)\},$$

其中 $\sum_{k=1}^K C_k = 0$ 。成对比较的标准选择为

$$(154) \quad \tau_{k,k'} = E\{Y(k) - Y(k')\}.$$

因此，关键是利用下述 ignorability 和 overlap 假设，基于 $(Z_i, X_i, Y_i)_{i=1}^n$ 的独立同分布数据，在无混淆假设下识别和估计潜在结果的均值 $\mu_k = E\{Y(k)\}$ 。

假设 28.2 (多值处理的 ignorability). $Z \perp \{Y(1), \dots, Y(K)\} \mid X$ 且 $\Pr(Z = k \mid X) > 0$ 对 $k = 1, \dots, K$ 均成立。

定义广义倾向得分

$$(155) \quad e_k(X) = \Pr(Z = k \mid X)$$

和条件结果均值

$$(156) \quad \mu_k(X) = E(Y \mid Z = k, X)$$

对 $k = 1, \dots, K$ 。

定理 28.3 (多值处理的识别). 在假设 ?? 下，我们有

$$(157) \quad \mu_k = E\{\mu_k(X)\} = E\left\{\frac{I(Z = k)Y}{e_k(X)}\right\}.$$

Moreover, based on the working models $e_k(X, \alpha)$ and $\mu_k(X, \beta)$ for $e_k(X)$ and $\mu_k(X)$, respectively, we have the doubly robust formula

$$(158) \quad \mu_k^{\text{dr}} = E\{\mu_k(X, \beta)\} + E\left[\frac{I(Z = k)\{Y - \mu_k(X, \beta)\}}{e_k(X, \alpha)}\right],$$

which equals μ_k if either $e_k(X, \alpha) = e_k(X)$ or $\mu_k(X, \beta) = \mu_k(X)$.

注 28.1. 定理 ?? 是定理 ?? 的特殊情形, 如果我们将定理 ?? 中的 (Z, M) 视为具有四个水平的一个处理。CDE(m) 是 τ_C 的特殊情形。

6. 本章小结

本章介绍了受控直接效应的定义、识别和估计方法。

- (1) 受控直接效应 $\text{CDE}(m) = E\{Y(1, m) - Y(0, m)\}$ 定义了中介变量固定为 m 时处理的因果效应。
- (2) 在序贯 ignorability 假设下, $\text{CDE}(m)$ 可以通过结果回归、IPW 或双重稳健估计量进行识别和估计。
- (3) 在线性结果模型下, $\text{CDE}(m)$ 等于处理系数 θ_1 。
- (4) 受控直接效应框架避免了嵌套潜在结果和跨世界独立性假设, 但无法定义间接效应。
- (5) 受控直接效应是多值处理识别理论的特殊情形。

7. 习题

练习 28.1. 证明: 在跨世界独立性 $Y(z, m) \perp M(z') \mid X$ (对所有 z, z', m 成立) 下, 条件受控直接效应 $\text{CDE}(m \mid x) = E\{Y(1, m) - Y(0, m) \mid X = x\}$ 与条件自然直接效应 $\text{NDE}(x) = E\{Y(1, M_0) - Y(0, M_0) \mid X = x\}$ 有如下关系:

$$\text{NDE}(x) = \sum_m \text{CDE}(m \mid x) \Pr(M_0 = m \mid X = x),$$

其中 M 离散。若无跨世界独立性, 这个关系一般还成立吗?

练习 28.2. 证明定理 ??。

练习 28.3. 证明: 在假设 ?? 下,

- (1) 若 $E(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X$, 则 $\text{CDE}(m) = \theta_1$ (对所有 m);
- (2) 若 $E(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_3 ZM + \theta_4^\top X$, 则 $\text{CDE}(m) = \theta_1 + \theta_3 m$ 。

练习 28.4. 对于二元结果, 在假设 ?? 下, 证明: 若 $\text{logit}\{\Pr(Y = 1 \mid Z, M, X)\} = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X$, 则

$$\text{CDE}(m) = E\left\{\text{expit}(\theta_0 + \theta_1 + \theta_2 m + \theta_4^\top X) - \text{expit}(\theta_0 + \theta_2 m + \theta_4^\top X)\right\}.$$

若模型包含交互项 ZM , 则 $\text{CDE}(m)$ 形式如何变化?

8. 推荐阅读

Nguyen et al. (2021) 对第 27 章和第 28 章的主题提供了友好的综述。

时间变动的处理变量与混淆

1. 从单时间点到多时间点：一个自然的推广

在前面各章中，我们考虑的都是**单一时间点**的处理变量——每个单元在某个特定时刻接受或不接受治疗。然而，现实世界中的治疗往往是**时间变动**的：患者在不同时间点接受不同强度的治疗；政策在不同阶段被动态调整；个人在不同年龄做出不同的选择。

为什么时间变动会带来新的挑战？

考虑一个两时间点的例子： Z_1 是初始治疗（如是否服用阿司匹林）， X_1 是治疗后的中间结果（如血压变化）， Z_2 是后续治疗（如是否接受手术）， Y 是最终结局（如是否在 5 年内死亡）。在这个序列中：

- Z_1 可能影响 X_1 （治疗改变中间结果）
- X_1 可能同时影响 Z_2 和 Y （中间结果既是后续治疗的原因，也是结局的原因）
- 这时， X_1 同时扮演着**时间变动协变量**和**时间变动混淆变量**的角色

在单一时间点框架下，我们只需条件于基线协变量 X_0 即可阻断所有混淆。但在时间变动的情况下， X_1 既是治疗 Z_2 的“前置原因”，也是结局 Y 的“前置原因”——它可能本身就是由 Z_1 产生的，从而部分介导了 Z_1 对 Y 的因果效应。这种复杂的时序结构使得简单的条件独立性假设不再够用。

这就是本章要解决的核心问题：**当处理变量随时间变动时，如何识别和估计因果效应？**

为简化记号，本章主要采用两时间点的设置来阐述核心思想。推广到更多时间点在概念上直接，但有限样本下会产生技术复杂性——组合数随时间点数量指数增长。我们将讨论这些复杂性，并将一般结果留给习题。

2. 基本设置与序列可忽略性

2.1. 时序结构. 两时间点的变量时序如下：

$$X_0 \rightarrow Z_1 \rightarrow X_1 \rightarrow Z_2 \rightarrow Y$$

其中：

- X_0 ：基线协变量（治疗前的特征）
- Z_1 ：时间点 1 的处理变量
- X_1 ：时间点 1 与时间点 2 之间的时变协变量
- Z_2 ：时间点 2 的处理变量
- Y ：最终结局

对于二元处理 (Z_1, Z_2) ，每个单元有四个潜在结局：

$$Y(z_1, z_2), \quad z_1, z_2 \in \{0, 1\}$$

观测到的结局等于：

$$Y = Y(Z_1, Z_2) = \sum_{z_1=0}^1 \sum_{z_2=0}^1 \mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2) Y(z_1, z_2)$$

2.2. 序列可忽略性假设. 在单一时间点的情况下, $Z \perp Y(z) \mid X$ (处理在给定协变量条件下随机化) 是我们识别因果效应的关键假设。对于时间变动的情况, 这个假设需要**序列化**——在每个时间点, 处理不仅依赖于当前的协变量历史, 还依赖于整个历史。

假设 29.1 (序列可忽略性). (1) Z_1 在给定 X_0 条件下随机化:

$$Z_1 \perp Y(z_1, z_2) \mid X_0, \quad \forall z_1, z_2 \in \{0, 1\}$$

(2) Z_2 在给定 (Z_1, X_1, X_0) 条件下随机化:

$$Z_2 \perp Y(z_1, z_2) \mid (Z_1, X_1, X_0), \quad \forall z_1, z_2 \in \{0, 1\}$$

理解 Assumption ??: 这个假设包含两部分递进的条件。第一部分说明 Z_1 仅被基线协变量 X_0 混淆——一旦我们条件于 X_0 , Z_1 就等同于随机化实验。第二部分则说明 Z_2 被 (Z_1, X_1, X_0) 混淆——我们不仅需要控制基线协变量 X_0 , 还需要控制由 Z_1 产生的时变协变量 X_1 。

一个重要的微妙之处: 序列可忽略性**允许** X_1 与 Y 之间存在未测量的混淆 U (如图 ?? 所示)。这是因为 X_1 本身可能是由 Z_1 产生的, 它部分介导了 Z_1 对 Y 的效应——这并非混淆, 而是**中介**。然而, 如果 U 同时影响 X_1 和 Y (且不通过 Z_1, Z_2), 则即使满足序列可忽略性, 识别仍然会受到挑战。



FIGURE 1. Assumption ?? 成立且 X_1 与 Y 之间无未测量混淆 U 的因果图。




FIGURE 2. Assumption ?? 成立但 X_1 与 Y 之间存在未测量混淆 U 的因果图。序列可忽略性仅排除了 (Z_1, Z_2) 与 Y 之间的混淆, 但允许 X_1 与 Y 之间存在未测量关联。

3. g 公式与结果建模

在单一时间点情况下, 基于结果的识别公式为:

$$E\{Y(z)\} = E\{E(Y \mid Z = z, X)\}$$

对于离散 X ，这化为：

$$E\{Y(z)\} = \sum_x E(Y \mid Z = z, X = x) \Pr(X = x)$$

对于连续 X ，这化为：

$$E\{Y(z)\} = \int E(Y \mid Z = z, X = x) f(x) dx$$

接下来的定理将这个公式推广到两时间点的设置。

定理 29.1 (g 公式). 在 *Assumption ??* 下，

$$(29.1) \quad E\{Y(z_1, z_2)\} = E\left[E\{E(Y \mid z_2, z_1, X_1, X_0) \mid z_1, X_0\}\right]$$

定理 ?? 的直观理解：等式右边是从内到外嵌套的条件期望。最内层 $E(Y \mid z_2, z_1, X_1, X_0)$ 是在固定历史 (z_1, X_0) 、中间协变量 X_1 和第二时刻治疗 z_2 的条件下结局的期望。中间层 $E\{\cdot \mid z_1, X_0\}$ 对 X_1 求平均——但注意，这是**逆概率加权**的平均，因为 $\Pr(X_1 \mid z_1, X_0)$ 与 $Z_1 = z_1$ 相关。最外层 $E[\cdot]$ 对 X_0 求边际平均。

对于离散 X_0, X_1 ，?? 化为：

$$(29.2) \quad E\{Y(z_1, z_2)\} = \sum_{x_0} \sum_{x_1} E(Y \mid z_2, z_1, x_1, x_0) \Pr(x_1 \mid z_1, x_0) \Pr(x_0)$$

对于连续 X_0, X_1 ，?? 化为：

$$(29.3) \quad E\{Y(z_1, z_2)\} = \iint E(Y \mid z_2, z_1, x_1, x_0) f(x_1 \mid z_1, x_0) f(x_0) dx_1 dx_0$$

与全概率公式的比较：根据观测数据的全概率公式，

$$(29.4) \quad E(Y) = \sum_{x_0} \sum_{z_1} \sum_{x_1} \sum_{z_2} E(Y \mid z_2, z_1, x_1, x_0) \Pr(z_2 \mid z_1, x_1, x_0) \Pr(x_1 \mid z_1, x_0) \Pr(z_1 \mid x_0) \Pr(x_0)$$

对比 ?? 与 ??，关键区别在于：?? 中**没有** $\Pr(z_2 \mid \dots)$ 和 $\Pr(z_1 \mid \dots)$ 项——这正是因为潜在结局 $Y(z_1, z_2)$ 的定义是**固定** $Z_1 = z_1$ 和 $Z_2 = z_2$ ，而非观测到的分配概率。

?? 和 ?? 被称为 **g 公式 (g-formula)**，由 Robins 命名。这个名称源于它的一般化形式——当处理变量随时间变动时，这个公式提供了一种递推的识别策略。

定理 ?? 的证明。¹

3.1. 基于结果建模的插件估计. g 公式 ?? 和 ?? 提示我们：为了估计潜在结局的均值，我们需要对 $E(Y \mid z_2, z_1, x_1, x_0)$ 、 $\Pr(x_1 \mid z_1, x_0)$ 和 $\Pr(x_0)$ 建模。有了这些拟合模型，我们可以将它们”插入”g 公式得到估计。

在某些特殊函数形式下，这个任务可以简化。下面的例 29.1 给出线性结果模型下的结果。

例 29.1 (例 29.1 —线性结果模型). 假设线性结果模型：

$$(29.5) \quad E(Y \mid z_2, z_1, x_1, x_0) = \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 x_1 + \beta_4 x_0$$

¹详见附录 ??。

可以验证：

$$\begin{aligned}
 E\{Y(z_1, z_2)\} &= \sum_{x_0} \sum_{x_1} (\beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 x_1 + \beta_4 x_0) \\
 &\quad \Pr(x_1 | z_1, x_0) \Pr(x_0) \\
 (29.6) \quad &= \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 \sum_{x_0} E(X_1 | z_1, x_0) \Pr(x_0) + \beta_4 E(X_0) \\
 &= \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 E\{X_1(z_1)\} + \beta_4 E(X_0)
 \end{aligned}$$

其中我们定义了 X_1 在治疗 $Z_1 = z_1$ 下的潜在结局：

$$(29.7) \quad E\{X_1(z_1)\} = \sum_{x_0} E(X_1 | z_1, x_0) \Pr(x_0)$$

定义 $\tau_{Z_1 \rightarrow X_1} = E\{X_1(1) - X_1(0)\}$ ，则：

$$(29.8) \quad E\{Y(1, 0) - Y(0, 0)\} = \beta_2 + \beta_3 \tau_{Z_1 \rightarrow X_1}$$

$$(29.9) \quad E\{Y(0, 1) - Y(0, 0)\} = \beta_1$$

$$(29.10) \quad E\{Y(1, 1) - Y(0, 0)\} = \beta_1 + \beta_2 + \beta_3 \tau_{Z_1 \rightarrow X_1}$$

直观解释 (参见图 ??)：?? 中 Z_1 的效应等于路径 $Z_1 \rightarrow Y$ (系数 β_2) 和路径 $Z_1 \rightarrow X_1 \rightarrow Y$ (系数 $\beta_3 \tau_{Z_1 \rightarrow X_1}$) 之和；?? 中 Z_2 的效应等于路径 $Z_2 \rightarrow Y$ (系数 β_1)；?? 中 (Z_1, Z_2) 的总效应等于三条路径系数之和。




FIGURE 3. 带路径系数的线性因果图，条件于基线协变量 X_0 。

g-null 悖论。Robins 和 Wasserman (1997) 指出了基于结果建模的插件估计的一个令人惊讶的缺陷。他们证明：如果在这个策略中出现模型错误设定，数据分析者可能**错误地拒绝**零因果效应 null 假设，即使在真实数据生成过程中 (Z_1, Z_2) 对 Y 的因果效应确实为零。他们称之为 **g-null 悖论 (g-null paradox)**。令人惊讶的是，即使在例 29.1 的简单线性结果模型中，g-null 悖论也可能出现（见习题 29.1）。

3.2. 基于结果建模的递推估计。29.3.1 节的插件估计涉及对时变协变量 X_1 建模，并导致令人不快的 g-null 悖论——这不是一个理想的方法。

递推期望公式 ?? 启发了一种更简单的估计方法。从最内层条件期望开始，记：

$$\tilde{Y}_2(z_1, z_2) = E(Y | Z_2 = z_2, Z_1 = z_1, X_1, X_0)$$

我们可以用 $(Z_2 = z_2, Z_1 = z_1)$ 子集数据拟合 Y 对 (X_1, X_0) 的模型，得到所有单元的拟合值 $\hat{Y}_{2i}(z_1, z_2)$ 。然后进入外层条件期望，记：

$$\tilde{Y}_1(z_1, z_2) = E\{\tilde{Y}_2(z_1, z_2) | Z_1 = z_1, X_0\}$$

我们可以用 $Z_1 = z_1$ 子集数据拟合 $\hat{Y}_2(z_1, z_2)$ 对 X_0 的模型, 得到所有单元的拟合值 $\hat{Y}_{1i}(z_1, z_2)$ 。最终的 $E\{Y(z_1, z_2)\}$ 估计量为:

$$(29.11) \quad \hat{E}\{Y(z_1, z_2)\} = n^{-1} \sum_{i=1}^n \hat{Y}_{1i}(z_1, z_2)$$

这种递推估计**不涉及**对 X_1 建模, 因此避免了 g-null 悖论 (见习题 29.2)。然而, 基于递推回归的估计量实现起来并不容易, 因为它涉及建模与因果图自然结构不对应的变量——例如 $\hat{Y}_2(z_1, z_2)$ 。

4. 逆概率加权

在单一时间点情况下, IPW 识别公式为:

$$E\{Y(z)\} = E\left\{\frac{\mathbf{1}(Z=z)Y}{\Pr(Z=z | X)}\right\}$$

接下来的结果将其推广到两时间点设置。定义:

$$(29.12) \quad e(z_1, X_0) = \Pr(Z_1 = z_1 | X_0)$$

$$(29.13) \quad e(z_2, Z_1, X_1, X_0) = \Pr(Z_2 = z_2 | Z_1, X_1, X_0)$$

为时间点 1 和时间点 2 的倾向得分。

定理 29.2 (IPW 识别公式). 在 *Assumption ??* 下,

$$(29.14) \quad E\{Y(z_1, z_2)\} = E\left\{\frac{\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)Y}{e(z_1, X_0)e(z_2, Z_1, X_1, X_0)}\right\}$$

定理 ?? 揭示的重叠假设:

$$(29.15) \quad 0 < e(z_1, X_0) < 1, \quad 0 < e(z_2, Z_1, X_1, X_0) < 1$$

对所有 z_1, z_2 。如果某些倾向得分为 0 或 1, 识别公式 ?? 会爆炸到无穷。

直观理解: 这个公式本质上是单一时间点 IPW 公式的两次应用——首先在 Z_2 上”调整”, 然后在 Z_1 上”调整”。分子中的指示函数 $\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)$ 选择出接受特定治疗序列的单元, 分母中的倾向得分对此进行加权, 使每个单元在分析中代表与其倾向得分成反比的单元数。

估计策略。基于 IPW 的估计非常简单, 只需对两个二元治疗指标建模。首先, 我们可以拟合 Z_1 对 X_0 的模型, 得到所有单元的拟合值 $\hat{e}_1(z_1, X_{0i})$; 拟合 Z_2 对 (Z_1, X_1, X_0) 的模型, 得到所有单元的拟合值 $\hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})$ 。然后得到以下 IPW 估计量 (Horvitz-Thompson 型):

$$(29.16) \quad \hat{E}^{\text{ht}}\{Y(z_1, z_2)\} = n^{-1} \sum_{i=1}^n \frac{\mathbf{1}(Z_{1i} = z_1)\mathbf{1}(Z_{2i} = z_2)Y_i}{\hat{e}_1(z_1, X_{0i})\hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})}$$

与第 11 章的讨论类似, HT 估计量对结局的位移不具有不变性, 且在有限样本下存在不稳定性。修正后的 Hajek 型估计量为 $\hat{E}^{\text{haj}}\{Y(z_1, z_2)\} = \hat{E}^{\text{ht}}\{Y(z_1, z_2)\} / \hat{1}^{\text{ht}}(z_1, z_2)$, 其中:

$$(29.17) \quad \hat{1}^{\text{ht}}(z_1, z_2) = n^{-1} \sum_{i=1}^n \frac{\mathbf{1}(Z_{1i} = z_1)\mathbf{1}(Z_{2i} = z_2)}{\hat{e}_1(z_1, X_{0i})\hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})}$$

5. 多时间点情形

将 29.2 和 29.3 节的估计策略推广到多时间点并非易事。即使对于二元处理和 K 个时间点，处理组合的数量也随 K 指数增长（例如 $2^5 = 32$, $2^{10} = 1024$ ）。因此，29.2 和 29.3 节的结果回归和 IPW 估计量在有限样本下是不可行的——因为它们要求每个处理组合水平组合都有足够的数据。

为应对这一挑战，Robins 提出了两种强大的估计框架：**边际结构模型 (Marginal Structural Model, MSM)** 和**结构嵌套模型 (Structural Nested Model, SNM)**。

5.1. 边际结构模型. 一种强有力的方法基于**边际结构模型 (MSM)** (Robins et al., 2000; Hernán et al., 2000)。为简化记号，我们仅展示 $K = 2$ 的 MSM，尽管其主要用途在于一般情形。

定义 29.3 (MSM — 边际结构模型). $Y(z_1, z_2)$ 的边际均值为：

$$(29.18) \quad E\{Y(z_1, z_2)\} = f(z_1, z_2; \beta)$$

一个典型例子是 $E\{Y(z_1, z_2)\} = \beta_0 + \beta_1 z_1 + \beta_2 z_2$ 。我们也可以将基线协变量纳入模型。

定义 29.4 (带基线协变量的 MSM). 给定 X_0 条件下 $Y(z_1, z_2)$ 的均值为：

$$(29.19) \quad E\{Y(z_1, z_2) \mid X_0\} = f(z_1, z_2, X_0; \beta)$$

一个典型例子是：

$$(29.20) \quad E\{Y(z_1, z_2) \mid X_0\} = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^\top X_0$$

如果我们观测到所有潜在结局，可以通过以下最小化问题求解 β ：

$$(29.21) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E\{Y(z_1, z_2) - f(z_1, z_2, X_0; b)\}^2$$

在序列可忽略性下，我们可以通过仅涉及观测变量的最小化问题求解 β 。

定理 29.5 (MSM 下的 IPW). 在 *Assumption ??* 和 *Definition ??* 下，?? 中的 β 等于：

$$(29.22) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E \left[\frac{\mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2)}{e(z_1, X_0) e(z_2, Z_1, X_1, X_0)} \{Y - f(z_1, z_2, X_0; b)\}^2 \right]$$

估计策略. 定理 ?? 暗示了一种基于加权回归的简单估计策略。例如，在 ?? 下，我们可以拟合 Y_i 对 $(1, Z_{1i}, Z_{2i}, X_{0i})$ 的加权最小二乘 (WLS) 回归，权重为 $\hat{e}_1^{-1}(Z_{1i}, X_{0i}) \hat{e}_{2i}^{-1}(Z_{2i}, Z_{1i}, X_{1i}, X_{0i})$ 。

与结果回归的比较: MSM 的 IPW 方法与结果回归方法的关键区别在于：结果回归直接建模 $E(Y \mid Z, X)$ ，而 MSM 的 IPW 方法建模 $E\{Y(z) \mid X_0\}$ 并通过逆概率加权来处理时变混淆。MSM 的优势在于它允许我们指定**边际**（而非条件）结构，这有时更加自然。

高维协变量下的 MSM. 当 X_0 维数很高时，?? 中的线性模型 $\beta_3^\top X_0$ 面临维数灾难。此时，稀疏性假设变得关键——即 β_3 中只有少数元素非零。LASSO (Tibshirani, 1996) 等正则化方法可以用于在高维下估计 β ，但需要额外的理论保证来确保因果推断的渐近有效性（见 Bloniarz et al., 2016; Wager et al., 2016）。

5.2. 结构嵌套模型. IPW 的一个关键问题是：如果重叠假设 ?? 被违背，IPW 不可用。为解决这一挑战，Robins 提出了结构嵌套模型。这里我们仅回顾两时间点的版本。

定义 29.6 (结构嵌套模型 (SNM)). 时间点 1 的条件效应为：

$$(29.23) \quad E\{Y(z_1, 0) - Y(0, 0) \mid Z_1 = z_1, X_0\} = g_1(z_1, X_0; \beta)$$

时间点 2 的条件效应为：

$$(29.24) \quad E\{Y(z_1, z_2) - Y(z_1, 0) \mid Z_2 = z_2, Z_1 = z_1, X_1, X_0\} = g_2(z_2, z_1, X_1, X_0; \beta)$$

在 Definition ?? 中，有两个逻辑约束：

$$(29.25) \quad g_1(0, X_0; \beta) = 0, \quad g_2(0, z_1, X_1, X_0; \beta) = 0, \quad \forall z_1$$

两个典型选择如下。

例 29.2 (例 29.2 —加法齐次 SNM). 假设：

$$(29.26) \quad \begin{cases} g_1(z_1, X_0; \beta) = \beta_1 z_1 \\ g_2(z_2, z_1, X_1, X_0; \beta) = (\beta_2 + \beta_3 z_1) z_2 \end{cases}$$

例 29.3 (例 29.3 —协变量调整 SNM). 假设：

$$(29.27) \quad \begin{cases} g_1(z_1, X_0; \beta) = (\beta_1 + \beta_2^\top X_0) z_1 \\ g_2(z_2, z_1, X_1, X_0; \beta) = (\beta_3 + \beta_4 z_1 + \beta_5^\top X_1) z_2 \end{cases}$$

MSM 与 SNM 的比较。 结构嵌套模型允许同时调整基线协变量和时变协变量，而边际结构模型仅允许调整基线协变量。Definition ?? 下的估计更为复杂，策略基于估计方程。

估计方程。 首先引入两个重要构建块。定义：

$$(29.28) \quad U_2(\beta) = Y - g_2(Z_2, Z_1, X_1, X_0; \beta)$$

$$(29.29) \quad U_1(\beta) = Y - g_2(Z_2, Z_1, X_1, X_0; \beta) - g_1(Z_1, X_0; \beta)$$

它们不能直接从数据计算，因为它们依赖于参数的真实值。在真值处，它们具有以下性质。

引理 29.7 (引理 29.1). 在 Assumption ?? 和 Definition ?? 下，

$$(29.30) \quad E\{U_2(\beta) \mid Z_2, Z_1, X_1, X_0\} = E\{U_2(\beta) \mid Z_1, X_1, X_0\} = E\{Y(Z_1, 0) \mid Z_1, X_1, X_0\}$$

且

$$(29.31) \quad E\{U_1(\beta) \mid Z_1, X_0\} = E\{U_1(\beta) \mid X_0\} = E\{Y(0, 0) \mid X_0\}$$

引理 ?? 的直观理解： $U_1(\beta)$ 扮演着“接受任何治疗前的对照潜在结局”的角色，而 $U_2(\beta)$ 扮演着“接受时间点 1 治疗后、时间点 2 前的对照潜在结局”的角色。

定理 29.8 (定理 29.4 —SNM 估计方程). 在 Assumption ?? 和 Definition ?? 下，

$$(29.32) \quad E[h_2(Z_1, X_1, X_0)\{Z_2 - e(1, Z_1, X_1, X_0)\}U_2(\beta)] = 0$$

且

$$(29.33) \quad E[h_1(X_0)\{Z_1 - e(1, X_0)\}U_1(\beta)] = 0$$

对任何函数 h_1 和 h_2 (只要矩存在)。

使用定理 ?? 时，我们必须指定 h_1 和 h_2 以确保有足够的方程来求解 β 。例 29.4 回顾例 29.2。

例 29.4 (例 29.4 — 例 29.2 下的估计方程). 在例 29.2 下, 我们可以选择 $h_1 = 1$ 和 $h_2 = (1, Z_1)$ 得到:

$$(29.34) \quad \begin{aligned} E[\{Z_2 - e(1, Z_1, X_1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2\}] &= 0 \\ E[Z_1\{Z_2 - e(1, Z_1, X_1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2\}] &= 0 \\ E[\{Z_1 - e(1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2 - \beta_1 Z_1\}] &= 0 \end{aligned}$$

然后我们可以从上述线性方程组求解 β (见习题 29.6)。

更高效的估计。 一个自然的问题是: 替代性的 (h_1, h_2) 选择是否能导致更高效的估计量? 答案是肯定的。例如, 我们可以选择许多 (h_1, h_2) 并使用广义矩方法 (GMM; Hansen, 1982)。技术细节超出本书范围。Naimi et al. (2017) 和 Vansteelandt and Joffe (2014) 提供了结构嵌套模型的教程。

6. 习题

6.1. g -null 悖论。 考虑图 ?? 中的简单因果图: 没有基线协变量 X_0 , 也没有从 (Z_1, Z_2) 到 Y 的箭头。因此 (Z_1, Z_2) 对 Y 的因果效应为零。

FIGURE 4. 习题 29.1 图: X_1 与 Y 之间存在未测量混淆 U 的因果图。

回顾例 29.1。证明: 如果

$$(29.35) \quad \beta_1 = \beta_2 = 0 \quad \text{且} \quad \beta_3 = 0$$

或者

$$(29.36) \quad \beta_1 = \beta_2 = 0 \quad \text{且} \quad E\{X_1(z_1)\} \text{ 不依赖于 } z_1$$

则期望 $E\{Y(z_1, z_2)\}$ 不依赖于 (z_1, z_2) 。

注: 然而, ?? 中的 $\beta_3 = 0$ 排除了 Y 对 X_1 的依赖, 与 X_1 和 Y 之间存在未测量混淆 U 矛盾; $E\{X_1(z_1)\}$ 对 z_1 的独立性排除了 X_1 对 Z_1 的依赖, 与 Z_1 到 X_1 的箭头矛盾。也就是说, 如果 X_1 和 Y 之间存在未测量混淆 U , 且 Z_1 到 X_1 存在箭头, 那么例 29.1 中 $E\{Y(z_1, z_2)\}$ 的公式必定依赖于 (z_1, z_2) , 这与 (Z_1, Z_2) 对 Y 无因果效应的假设矛盾——这就是 g -null 悖论。

6.2. 零模型下的递推估计。 考虑 29.3.2 节的递推估计方法在习题 29.1 的因果图下。基于线性模型, 证明估计量收敛到 0。

6.3. MSM 下的 IPW。 证明定理 ??。

6.4. 定义 29.2 的非线性例子。 定义 29.2 的另一个典型例子是:

$$(29.37) \quad \text{logit}[\text{Pr}\{Y(z_1, z_2) = 1 \mid X_0\}] = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^\top X_0$$

如果我们观测到所有潜在结局, 可以通过最小化负对数似然函数来求解 β (见第 B.6.2 节的更简单版本):

$$(29.38) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E\{\log(1 + e^\ell) - Y(z_1, z_2)\ell\}$$

其中 $\ell = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^\top X_0$ 。在序列可忽略性下, 我们可以从以下仅涉及观测变量的最小化问题求解 β 。

定理 29.5 (MSM 下的 IPW)。在 Assumption ?? 和 Definition ?? 下, ?? 中的 β 等于:

$$(29.39) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E \left[\frac{\mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2)}{e(z_1, X_0) e(z_2, Z_1, X_1, X_0)} \{ \log(1 + e^\ell) - Y(z_1, z_2) \ell \} \right]$$

证明定理 29.5。

注: 定理 29.5 暗示了一种基于加权回归的简单估计策略。例如, 在 ?? 下, 我们可以拟合 Y_i 对 $(1, Z_{1i}, Z_{2i}, X_{0i})$ 的加权 logistic 回归, 权重为 $\hat{e}_1^{-1}(Z_{1i}, X_{0i}) \hat{e}_{2i}^{-1}(Z_{2i}, Z_{1i}, X_{1i}, X_{0i})$ 。

6.5. 单时间点结构嵌套模型. 回顾观测研究的标准设置: IID 数据从 $\{X, Z, Y(1), Y(0)\}$ 中抽取。定义倾向得分为 $e(X) = \Pr(Z = 1 | X)$ 。假设:

$$(29.40) \quad Z \perp Y(0) | X$$

及以下结构嵌套模型。

定义 29.4 (单时间点结构嵌套模型)。个体效应的条件均值为:

$$(29.41) \quad E\{Y(z) - Y(0) | Z = z, X\} = g(z, X; \beta)$$

在定义 29.4 中, 逻辑约束为 $g(0, X; \beta) = 0$ 。证明以下结果。

(1) 我们有:

$$(29.42) \quad E\{Y - g(Z, X; \beta) | X, Z\} = E\{Y - g(Z, X; \beta) | X\} = E\{Y(0) | X\}$$

(2) 我们有:

$$(29.43) \quad E[h(X)\{Z - e(X)\}\{Y - g(Z, X; \beta)\}] = 0$$

对任何函数 h , 只要矩存在。

注: ?? 是参数估计的基础。考虑定义 29.4 的特殊情况 $g(z, X; \beta) = \beta z$ 。选择 $h(X) = 1$ 得到:

$$(29.44) \quad E[\{Z - e(X)\}\{Y - \beta Z\}] = 0$$

这正是倾向得分加权的标准方程 (见第 11 章)。

7. 推荐阅读

Robins 和他的合作者的一系列开创性论文奠定了本章材料的基础。Robins (1986) 引入了 g-formula 和边际结构模型的基本思想; Robins (1998) 系统阐述了结构嵌套模型; Robins 和 Hernán (2009) 提供了 g-方法的综合综述。Robins 和 Waterman (1994) 比较了 MSM 和 SNM 两种方法。关于 g-null 悖论的更多讨论, 见 Robins 和 Wasserman (1997) 和 McGrath et al. (2021)。

在高维协变量背景下, Bloniarz et al. (2016) 提出用 LASSO 调整实验中的处理效应估计; Wager et al. (2016) 提出使用机器学习方法分析高维实验数据; Lei 和 Ding (2021) 在不假设稀疏性的正则条件下证明 Lin (2013) 估计量的渐近正态性。D'Amour et al. (2021) 讨论了高维协变量观测研究中的重叠问题。

APPENDIX A

公式推导

1. Lemma 4.1 的证明：方差与协方差的关系

Lemma 4.1 (教材第 1975 页):

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

背景 (Background): Lemma 4.1 是 Neyman (1923) 定理证明中的一个关键代数恒等式，它建立了有限总体协方差与各个方差之间的关系。

参数定义 (Parameter Definitions):

- $S^2(1) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2$: 潜在结果 $Y_i(1)$ 的有限总体方差
- $S^2(0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$: 潜在结果 $Y_i(0)$ 的有限总体方差
- $S(1, 0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\} \{Y_i(0) - \bar{Y}(0)\}$: $Y_i(1)$ 与 $Y_i(0)$ 之间的有限总体协方差
- $\tau_i = Y_i(1) - Y_i(0)$: 个体因果效应
- $\tau = n^{-1} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$: 平均因果效应
- $S^2(\tau) = (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2$: 个体因果效应的有限总体方差

目标 (Goal): 证明

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

推导步骤 (Derivation Steps):

第一步: 从 $S^2(\tau)$ 的定义出发。

$$\begin{aligned} S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - Y_i(0)) - (\bar{Y}(1) - \bar{Y}(0))]^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - \bar{Y}(1)) - (Y_i(0) - \bar{Y}(0))]^2. \end{aligned}$$

第二步: 展开平方。

$$\begin{aligned}
S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n \left[(Y_i(1) - \bar{Y}(1))^2 + (Y_i(0) - \bar{Y}(0))^2 \right. \\
&\quad \left. - 2(Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \right] \\
&= (n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))^2 + (n-1)^{-1} \sum_{i=1}^n (Y_i(0) - \bar{Y}(0))^2 \\
&\quad - 2(n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \\
&= S^2(1) + S^2(0) - 2S(1, 0).
\end{aligned}$$

第三步：移项得到目标恒等式。

$$S^2(1) + S^2(0) - S^2(\tau) = 2S(1, 0).$$

结论：得证

$$\boxed{2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)}.$$

直观理解：这个恒等式揭示了潜在结果之间的相关性 ($S(1, 0)$) 与个体因果效应变异 ($S^2(\tau)$) 之间的联系。当个体因果效应完全恒定 ($S^2(\tau) = 0$) 时, $2S(1, 0) = S^2(1) + S^2(0)$, 即 $Y(1)$ 和 $Y(0)$ 完全正相关 (相关系数为 1)。当 $S^2(\tau) > 0$ 时, 等式右侧变小, 意味着 $S(1, 0)$ 变小或变为负值。

在方差公式中的应用：这个恒等式允许我们将 Neyman 方差公式写成两种等价形式：

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} = \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0).$$

2. 差值均值统计量的方差分解

背景：在 ?? 中, 我们声称

$$(n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

本节给出完整的代数推导。

第一步：从定义出发。

$$(n-1)s^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n [(Y_i - \bar{Y})]^2.$$

第二步：对每个单元 i , 将偏差 $Y_i - \bar{Y}$ 写成：

$$Y_i - \bar{Y} = \underbrace{(Y_i - \hat{Y}(Z_i))}_{\text{组内偏差}} + \underbrace{(\hat{Y}(Z_i) - \bar{Y})}_{\text{组间偏差}}.$$

第三步：平方展开：

$$(Y_i - \bar{Y})^2 = (Y_i - \hat{Y}(Z_i))^2 + (\hat{Y}(Z_i) - \bar{Y})^2 + 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}).$$

第四步：对所有单元求和。关键观察是交叉项求和为零：

$$\sum_{i=1}^n 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}) = 2 \sum_{i=1}^n (Y_i - \hat{Y}(Z_i)) \cdot (\hat{Y}(Z_i) - \bar{Y}).$$

当 $Z_i = 1$ 时，这个和化为：

$$2 \sum_{Z_i=1} (Y_i - \hat{Y}(1)) \cdot (\hat{Y}(1) - \bar{Y}) = 2(\hat{Y}(1) - \bar{Y}) \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))}_{=0} = 0,$$

因为 $\sum_{Z_i=1} Y_i = n_1 \hat{Y}(1)$ ，所以 $\sum_{Z_i=1} (Y_i - \hat{Y}(1)) = 0$ 。

同理，当 $Z_i = 0$ 时：

$$2 \sum_{Z_i=0} (Y_i - \hat{Y}(0)) \cdot (\hat{Y}(0) - \bar{Y}) = 2(\hat{Y}(0) - \bar{Y}) \underbrace{\sum_{Z_i=0} (Y_i - \hat{Y}(0))}_{=0} = 0.$$

因此交叉项全部抵消。

第五步：整理得到：

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2}_{\text{组内平方和}} + \underbrace{\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2}_{\text{组间平方和}}.$$

第六步：计算组间平方和：

$$\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2 = n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2.$$

利用以下两个事实：

$$(1) \hat{Y}(1) - \hat{Y}(0) = \hat{\tau}$$

$$(2) n_1 \hat{Y}(1) + n_0 \hat{Y}(0) = n\bar{Y} \quad (\text{加权平均的性质})$$

展开并化简：

$$\begin{aligned} & n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 \\ &= n_1 \hat{Y}(1)^2 - 2n_1 \hat{Y}(1) \bar{Y} + n_1 \bar{Y}^2 + n_0 \hat{Y}(0)^2 - 2n_0 \hat{Y}(0) \bar{Y} + n_0 \bar{Y}^2 \\ &= n_1 \hat{Y}(1)^2 + n_0 \hat{Y}(0)^2 - n\bar{Y}^2. \end{aligned}$$

利用 $(n_1 \hat{Y}(1) + n_0 \hat{Y}(0))^2 = n^2 \bar{Y}^2$ ，展开得：

$$n_1^2 \hat{Y}(1)^2 + 2n_1 n_0 \hat{Y}(1) \hat{Y}(0) + n_0^2 \hat{Y}(0)^2 = n^2 \bar{Y}^2.$$

代入上式并利用 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ ，最终化简为：

$$n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 = \frac{n_1 n_0}{n} \hat{\tau}^2.$$

结论：代入即得 ??。

3. Wilcoxon 秩和统计量的方差推导

背景：在 ?? 中，我们声称在 H_{0F} 下

$$\text{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

本节给出完整的代数推导。

第一步：回忆 $W = \sum_{i=1}^n Z_i R_i$ ，其中 R_i 是 Y_i 在合并样本中的秩（固定值）， Z_i 是随机化的治疗指示变量。

方差分解：

$$\text{var}(W) = \text{var}\left(\sum_{i=1}^n Z_i R_i\right) = \sum_{i=1}^n R_i^2 \text{var}(Z_i) + \sum_{i \neq j} R_i R_j \text{cov}(Z_i, Z_j).$$

计算 $\text{var}(Z_i)$ ：在 CRE 中， $Z_i \sim \text{Bernoulli}(n_1/n)$ ，所以

$$\text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

计算 $\text{cov}(Z_i, Z_j)$ for $i \neq j$ ：由于 $\sum_{i=1}^n Z_i = n_1$ （固定），我们有

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)} \quad (i \neq j).$$

代入：

$$\begin{aligned} \text{var}(W) &= \left(\sum_{i=1}^n R_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} R_i R_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right) \\ &= \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \sum_{i \neq j} R_i R_j \right]. \end{aligned}$$

注意 $\sum_{i \neq j} R_i R_j = (\sum_{i=1}^n R_i)^2 - \sum_{i=1}^n R_i^2$ ，代入得：

$$\text{var}(W) = \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \left(\left(\sum_{i=1}^n R_i \right)^2 - \sum_{i=1}^n R_i^2 \right) \right].$$

计算 $\sum_{i=1}^n R_i$ 和 $\sum_{i=1}^n R_i^2$ ：假设无 ties，则 $\{R_i\}$ 是 $1, 2, \dots, n$ 的一个排列。

$$\sum_{i=1}^n R_i = 1 + 2 + \dots + n = \frac{n(n+1)}{2}.$$

$$\sum_{i=1}^n R_i^2 = 1^2 + 2^2 + \dots + n^2 = \frac{n(n+1)(2n+1)}{6}.$$

代入并化简：

$$\begin{aligned} \text{var}(W) &= \frac{n_1 n_0}{n^2} \left[\frac{n(n+1)(2n+1)}{6} - \frac{1}{n-1} \left(\frac{n^2(n+1)^2}{4} - \frac{n(n+1)(2n+1)}{6} \right) \right] \\ &= \frac{n_1 n_0 (n+1)}{12}. \end{aligned}$$

结论：得证。

4. 女士品茶实验的超几何分布

背景：在 ?? 中，我们讨论了 Fisher 的女士品茶实验。本节给出超几何分布的完整推导。

设置：

- 8 杯茶中有 4 杯是”先加奶”($K = 4$), 4 杯是”先加茶”
- 女士随机猜测其中 4 杯为”先加奶”
- 记 X 为她猜对”先加奶”的杯数

为什么是超几何分布？

在 H_{0F} 下，女士的猜测是固定的（她选 4 杯作为”先加奶”的猜测）。实验者随机排列 8 杯茶的顺序呈现给女士。这等价于：从含有 $K = 4$ 个”成功”的总体 $N = 8$ 中，不放回抽取 $n = 4$ 个， X 是抽到的成功个数。

超几何分布的概率质量函数：

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, 2, 3, 4.$$

验证：超几何分布的概率之和为 1。

$$\sum_{k=0}^4 \mathbb{P}(X = k) = \frac{1}{\binom{8}{4}} \sum_{k=0}^4 \binom{4}{k} \binom{4}{4-k} = \frac{1}{70} \cdot \binom{8}{4} = 1,$$

其中利用了组合恒等式 $\sum_k \binom{a}{k} \binom{b}{n-k} = \binom{a+b}{n}$ 。

各概率的数值：

$$\begin{aligned} \mathbb{P}(X = 0) &= \frac{\binom{4}{0} \binom{4}{4}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}, \\ \mathbb{P}(X = 1) &= \frac{\binom{4}{1} \binom{4}{3}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 2) &= \frac{\binom{4}{2} \binom{4}{2}}{\binom{8}{4}} = \frac{6 \cdot 6}{70} = \frac{36}{70}, \\ \mathbb{P}(X = 3) &= \frac{\binom{4}{3} \binom{4}{1}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 4) &= \frac{\binom{4}{4} \binom{4}{0}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}. \end{aligned}$$

与二项分布的比较：如果”抽取放回”（即女士每次猜测后被告知答案），则 $X \sim \text{Binomial}(4, 1/2)$ ，此时

$$\mathbb{P}(X = 4) = \binom{4}{4} (1/2)^4 = 1/16 = 0.0625 > 0.014.$$

超几何分布（不放回）的尾部概率更小，使得 Fisher 的检验在零假设下更精确——这正是 FRT”精确”的含义。

5. 差值均值统计量的期望与方差推导

背景：在 ?? 中，我们定义了差值均值统计量

$$\hat{\tau} = \hat{Y}(1) - \hat{Y}(0).$$

本节推导在 H_{0F} 下 $\hat{\tau}$ 的期望和方差。

无偏性.

期望的推导. 回忆在 CRE 中，治疗分配 $\mathbf{Z}$ 与潜在结果 $\{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 独立，且每个单元被分配到治疗组的概率为 n_1/n ：

$$\mathbb{E}(Z_i) = \frac{n_1}{n}, \quad \mathbb{E}(1 - Z_i) = \frac{n_0}{n}.$$

因此

$$\begin{aligned} \mathbb{E}(\hat{\tau}) &= \mathbb{E}\left(n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i\right) \\ &= n_1^{-1} \sum_{i=1}^n \mathbb{E}(Z_i) Y_i - n_0^{-1} \sum_{i=1}^n \mathbb{E}(1 - Z_i) Y_i \\ &= n_1^{-1} \sum_{i=1}^n \frac{n_1}{n} Y_i - n_0^{-1} \sum_{i=1}^n \frac{n_0}{n} Y_i \\ &= \frac{1}{n} \sum_{i=1}^n Y_i - \frac{1}{n} \sum_{i=1}^n Y_i = 0. \end{aligned}$$

方差的推导. 第一步：简化表达式。注意到

$$\hat{\tau} = n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i = \frac{n}{n_0} \cdot n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n Y_i.$$

由于 $\sum_{i=1}^n Y_i$ 是常数（不依赖 $\mathbf{Z}$ ），我们只需计算

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \text{var}\left(\sum_{i=1}^n Z_i Y_i\right).$$

第二步：计算 $\text{var}(Z_i)$ 和 $\text{cov}(Z_i, Z_j)$ 。在 CRE 中，

$$Z_i \sim \text{Bernoulli}\left(\frac{n_1}{n}\right), \quad \text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ （固定），对于 $i \neq j$ ，

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)}.$$

第三步：计算 $\text{var}(\sum_{i=1}^n Z_i Y_i)$ ：

$$\begin{aligned} \text{var}\left(\sum_{i=1}^n Z_i Y_i\right) &= \sum_{i=1}^n Y_i^2 \text{var}(Z_i) + \sum_{i \neq j} Y_i Y_j \text{cov}(Z_i, Z_j) \\ &= \left(\sum_{i=1}^n Y_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} Y_i Y_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right). \end{aligned}$$

注意 $\sum_{i \neq j} Y_i Y_j = (\sum_{i=1}^n Y_i)^2 - \sum_{i=1}^n Y_i^2 = n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2$, 代入得:

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \frac{n_1 n_0}{n^2} \sum_{i=1}^n Y_i^2 - \frac{n_1 n_0}{n^2(n-1)} \left(n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2 \right) \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[(n-1) \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 + \sum_{i=1}^n Y_i^2 \right] \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[n \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 \right] \\ &= \frac{n_1 n_0}{n(n-1)} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right). \end{aligned}$$

第四步: 利用 s^2 的定义:

$$s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)^{-1} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right).$$

因此

$$\text{var} \left(\sum_{i=1}^n Z_i Y_i \right) = \frac{n_1 n_0}{n} \cdot s^2.$$

第五步: 代回 $\text{var}(\hat{\tau})$:

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \frac{n_1 n_0}{n} \cdot s^2 = \frac{n}{n_1 n_0} \cdot s^2.$$

结论:

$$\boxed{\text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} \cdot s^2.}$$

直观理解:

- 方差与总样本量 n 成正比——样本越大, 估计越精确
- 方差与 $n_1 n_0$ 成反比——当 $n_1 = n_0 = n/2$ 时方差最小
- 这与直觉一致: 治疗组和对照组越平衡, 我们越能准确估计因果效应

方差估计的期望. **背景:** Neyman 保守方差估计量 $\hat{V} = \hat{S}^2(1)/n_1 + \hat{S}^2(0)/n_0$ 的期望为 $\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau}) + S^2(\tau)/n$ 。本节推导这一结果。

第一步: 计算 $\mathbb{E}\{\hat{S}^2(1)\}$ 。

由样本方差的定义:

$$\hat{S}^2(z) = (n_z - 1)^{-1} \sum_{Z_i=z} \{Y_i(z) - \hat{\bar{Y}}(z)\}^2, \quad z \in \{0, 1\}.$$

其中 $\hat{\bar{Y}}(z) = n_z^{-1} \sum_{Z_i=z} Y_i(z)$ 是有限总体均值 $\bar{Y}(z)$ 的估计。

在 CRE 下, 治疗分配与潜在结果独立, 因此 $\mathbb{E}\{\hat{S}^2(z)\} = S^2(z)$ (样本方差是有限总体方差的无偏估计)。

第二步: 代入 $\mathbb{E}(\hat{V})$ 。

$$\mathbb{E}(\hat{V}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0}.$$

第三步：与 Neyman 方差公式比较。

由 Neyman 方差公式：

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}.$$

因此：

$$\mathbb{E}(\hat{V}) - \text{var}(\hat{\tau}) = \frac{S^2(\tau)}{n} \geq 0.$$

结论：方差估计量 $\hat{V}$ 对 $\text{var}(\hat{\tau})$ 是**保守的**，偏差为 $S^2(\tau)/n$ ，仅在所有单元的个体因果效应恒定 ($S^2(\tau) = 0$) 时无偏。

6. CRE 中分层平衡性的推导

背景 (Background)：在完全随机实验 (CRE) 中，我们固定总的治疗组和对照组样本量 n_1 和 n_0 ，但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。本节证明各层治疗组和对照组比例之差的期望为零。

参数定义 (Parameter Definitions)：

- n ：总单元数
- $n_{[k]}$ ：第 k 层的单元数
- n_1 ：总治疗组单元数
- n_0 ：总对照组单元数 ($n_0 = n - n_1$)
- $n_{[k]1}$ ：第 k 层中分配到治疗组的单元数
- $n_{[k]0}$ ：第 k 层中分配到对照组的单元数 ($n_{[k]0} = n_{[k]} - n_{[k]1}$)
- $\pi_{[k]} = n_{[k]}/n$ ：第 k 层在总体中的比例

已知条件 (Given)：

- 在 CRE 下，治疗分配向量 $\mathbf{Z}$ 是从所有 $\binom{n}{n_1}$ 种分配中等概率随机选取的
- 各单元被分配到治疗组的概率为 n_1/n

目标 (Goal)：证明

$$\mathbb{E}\left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0}\right) = 0.$$

推导步骤 (Derivation Steps)：

第一步：建立 $n_{[k]1}$ 的期望。

在 CRE 下，每个单元被分配到治疗组的概率为 n_1/n 。因此，对于第 k 层中的任意单元 i (满足 $X_i = k$)：

$$\mathbb{E}(Z_i) = \frac{n_1}{n}.$$

第 k 层中分配到治疗组的单元数为：

$$n_{[k]1} = \sum_{i: X_i=k} Z_i.$$

由于该层有 $n_{[k]}$ 个单元，且 Z_i 之间是负相关的 (总和固定为 n_1)，我们有：

$$\mathbb{E}(n_{[k]1}) = \sum_{i: X_i=k} \mathbb{E}(Z_i) = n_{[k]} \cdot \frac{n_1}{n} = \pi_{[k]} \cdot n_1.$$

第二步：计算比例的期望。

由于 $n_{[k]0} = n_{[k]} - n_{[k]1}$ ，我们有：

$$\mathbb{E}(n_{[k]0}) = n_{[k]} - \mathbb{E}(n_{[k]1}) = n_{[k]} - \pi_{[k]}n_1 = n_{[k]} - \frac{n_{[k]}}{n}n_1 = n_{[k]} \left(1 - \frac{n_1}{n}\right) = n_{[k]} \cdot \frac{n_0}{n} = \pi_{[k]} \cdot n_0.$$

第三步：计算比例之差的期望。

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = \frac{\mathbb{E}(n_{[k]1})}{n_1} - \frac{\mathbb{E}(n_{[k]0})}{n_0} = \frac{\pi_{[k]}n_1}{n_1} - \frac{\pi_{[k]}n_0}{n_0} = \pi_{[k]} - \pi_{[k]} = 0.$$

结论：得证 $\mathbb{E}(n_{[k]1}/n_1 - n_{[k]0}/n_0) = 0$ 。

直观理解：这个结果表明，虽然在一次实现中 $n_{[k]1}/n_1 - n_{[k]0}/n_0$ 可能显著非零（由于随机波动），但这种波动在期望意义下是平衡的。随机化保证了渐近公平性——各层在治疗组和对照组中的比例在期望上与总体比例一致。

7. 分层估计量的期望与方差推导

背景 (Background)：在分层随机实验 (SRE) 中，我们使用学生化分层估计量

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}}$$

作为 Fisher 随机化检验的统计量。本节推导在 sharp null $H_{0F} : Y_i(1) = Y_i(0)$ 下 t_{SRE} 的期望和方差。

参数定义 (Parameter Definitions)：

- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ ：分层估计量
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$ ：第 k 层的差值均值
- $\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right)$ ：方差估计量
- $\hat{S}_{[k]}^2(1)$ 、 $\hat{S}_{[k]}^2(0)$ ：第 k 层内治疗组和对照组的样本方差

目标 (Goal)：推导 $\hat{\tau}_{\text{SRE}}$ 和 $\hat{V}_{\text{SRE}}$ 在 H_{0F} 下的期望和方差。

推导步骤 (Derivation Steps)：

第一步： $\hat{\tau}_{[k]}$ 的期望。

在 H_{0F} 下，所有 $Y_i(1) = Y_i(0) = Y_i$ 。因此，

$$\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0) = \frac{\sum_{i: X_i=k} Z_i Y_i}{n_{[k]1}} - \frac{\sum_{i: X_i=k} (1 - Z_i) Y_i}{n_{[k]0}}.$$

利用 $\mathbb{E}(Z_i) = n_1/n$ 和 $\mathbb{E}(1 - Z_i) = n_0/n$ ，以及 Y_i 是固定值（不依赖 Z ），我们有：

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} \cdot \bar{Y}_{[k]} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \cdot \bar{Y}_{[k]} = \bar{Y}_{[k]} \left(\frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \right).$$

由于 $n_{[k]1}/n_{[k]} = e_{[k]}$ （层别倾向得分）和 $n_{[k]0}/n_{[k]} = 1 - e_{[k]}$ ，以及 n_1/n 和 n_0/n 是常数，上述表达式可简化为 $\bar{Y}_{[k]} \cdot (\text{常数} - \text{常数}) = 0$ 。

更直接地：由于 $\mathbb{E}(Z_i) = n_1/n$ 对所有单元成立，在 H_{0F} 下，

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{1}{n_{[k]1}} \sum_{i: X_i=k} \mathbb{E}(Z_i) Y_i - \frac{1}{n_{[k]0}} \sum_{i: X_i=k} \mathbb{E}(1 - Z_i) Y_i = \frac{n_1}{n} \bar{Y}_{[k]} - \frac{n_0}{n} \bar{Y}_{[k]} = 0.$$

第二步： $\hat{\tau}_{\text{SRE}}$ 的期望。

由于 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 且 $\pi_{[k]}$ 是常数,

$$\mathbb{E}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]} \mathbb{E}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]} \cdot 0 = 0.$$

第三步: $\hat{\tau}_{[k]}$ 的方差。

利用 Neyman (1923) 的方差公式 (见 ??), 在第 k 层内,

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}}.$$

第四步: $\hat{\tau}_{\text{SRE}}$ 的方差。

由于各层之间的随机化是独立的,

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right).$$

第五步: $\hat{V}_{\text{SRE}}$ 的期望。

利用 $\mathbb{E}(\hat{S}_{[k]}^2(1)) = S_{[k]}^2(1)$ 和 $\mathbb{E}(\hat{S}_{[k]}^2(0)) = S_{[k]}^2(0)$,

$$\mathbb{E}(\hat{V}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right) = \text{var}(\hat{\tau}_{\text{SRE}}) + \sum_{k=1}^K \pi_{[k]}^2 \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以 $\mathbb{E}(\hat{V}_{\text{SRE}}) = \text{var}(\hat{\tau}_{\text{SRE}})$ 。

结论: 在 H_{0F} 下, $\hat{\tau}_{\text{SRE}}$ 的期望为零, 方差为 $\hat{V}_{\text{SRE}}$ 的期望。因此 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 是一个合理的学生化统计量。

8. 分层 Neymanian 方差的推导

背景 (Background): 在分层随机实验 (SRE) 中, 本节推导第 k 层差值均值估计量 $\hat{\tau}_{[k]}$ 的方差公式, 以及分层估计量 $\hat{\tau}_{\text{SRE}}$ 的方差公式。

参数定义 (Parameter Definitions):

- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层内潜在结果 $Y(1)$ 和 $Y(0)$ 的有限总体方差
- $S_{[k]}^2(\tau)$: 第 k 层内个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 的有限总体方差
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量

目标 (Goal):

- (1) 证明 (??): $\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}$
- (2) 证明 (??): $\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]})$

推导步骤 (Derivation Steps):

式 (??) 的推导. 第一步: 应用 Neyman (1923) 定理于第 k 层。

第 k 层本质上是一个独立的 CRE，只是总体大小为 $n_{[k]}$ 而非 n 。直接应用 Neyman 的方差公式 (见 ??):

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

直观解释: 这个方差公式与 CRE 中的方差公式结构相同，只是将总体量替换为层别总体量。

式 (??) 的推导. 第二步: 利用层间独立性。

在 SRE 中，各层内的治疗分配是独立进行的。因此， $\hat{\tau}_{[1]}, \dots, \hat{\tau}_{[K]}$ 之间相互独立。

第三步: 计算分层估计量的方差。

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \text{var}\left(\sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}\right) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) + \sum_{k \neq j} \pi_{[k]} \pi_{[j]} \text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}).$$

由于各层之间的独立性， $\text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}) = 0$ (对 $k \neq j$)。因此，

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

结论: 代入 (??) 即得

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right).$$

9. CRE 与 SRE 方差差异的推导

背景 (Background): 本节推导在常数倾向得分条件下，CRE 估计量 $\hat{\tau}$ 与 SRE 估计量 $\hat{\tau}_{\text{SRE}}$ 方差差异的近似公式。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$: CRE 的差值均值估计量
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: SRE 的分层估计量
- $S^2(1)$ 、 $S^2(0)$: 总体的潜在结果有限总体方差
- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层的潜在结果有限总体方差
- $\bar{Y}(1)$ 、 $\bar{Y}(0)$: 总体的潜在结果均值
- $\bar{Y}_{[k]}(1)$ 、 $\bar{Y}_{[k]}(0)$: 第 k 层的潜在结果均值

已知条件 (Given):

- 在 CRE 下: $\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- 在 SRE 下: $\text{var}_{\text{SRE}}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right)$
- 方差分析分解: $S^2(1) = \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2$ - 层内变异

目标 (Goal): 证明方差差异约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

推导步骤 (Derivation Steps):

第一步： 方差分析分解。
对 $S^2(1)$ 进行层间分解：

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \frac{n_{[k]} - 1}{n-1} \cdot \frac{1}{n_{[k]} - 1} \sum_{i: X_i=k} \{Y_i(1) - \bar{Y}_{[k]}(1)\}^2 \\ &\quad + \sum_{k=1}^K \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2. \end{aligned}$$

当 $n_{[k]}$ 较大时, $(n_{[k]} - 1)/(n - 1) \approx n_{[k]}/n = \pi_{[k]}$, 于是

$$S^2(1) \approx \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2.$$

同理对 $S^2(0)$ 和 $S^2(\tau)$ 进行分解。

第二步： 代入 CRE 方差公式。

$$\text{var}_{CRE}(\hat{\tau}) = \frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(0) - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(\tau) + \text{层间变异项}.$$

第三步： 识别差异项。

层间变异项为：

$$\frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} (\tau_{[k]} - \tau)^2.$$

第四步： 近似简化。

当层样本量较大时, 利用 $n_{[k]1} \approx \pi_{[k]} n_1$ 和 $n_{[k]0} \approx \pi_{[k]} n_0$, 层间变异项近似为：

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2.$$

结论： 由于每一项都是平方和, 该表达式非负。当且仅当对所有 k 都有

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

时 (即协变量不能预测潜在结果), 差异为零。这证明了 SRE 在协变量能预测结果时比 CRE 更有效。

10. CRE 条件分布的推导

背景 (Background)： 本节证明在给定各层治疗分配数量 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下, CRE 的治疗分配向量 $\mathbf{Z}$ 的条件分布与 SRE 的分布相同。

参数定义 (Parameter Definitions)：

- $\mathbf{Z} = (Z_1, \dots, Z_n)$: 治疗分配向量
- $n_{[k]1}$: 第 k 层中分配到治疗组的单元数

- $n_{[k]0}$: 第 k 层中分配到对照组的单元数
- $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$: 所有层的分配数量向量

已知条件 (Given):

- 在 CRE 下: $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}$ 对所有满足 $\sum Z_i = n_1$ 的分配 $\mathbf{z}$
- 在 SRE 下: 第 k 层的分配概率为 $\frac{1}{\binom{n_{[k]}}{n_{[k]1}}}$

目标 (Goal): 证明

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

推导步骤 (Derivation Steps):

第一步: 计算联合概率。

在 CRE 下, 治疗分配向量 $\mathbf{Z}$ 的概率为:

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}.$$

第二步: 计算条件概率。

给定 $\mathbf{n}$ 条件下 $\mathbf{Z} = \mathbf{z}$ 的条件概率为:

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{CRE}(\mathbf{n})}.$$

事件 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 意味着第 k 层恰好有 $n_{[k]1}$ 个单元被分配到治疗组。由于各层的分配是独立的, 这个联合事件的概率为:

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n}) = \prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}.$$

第三步: 计算边际概率。

为了计算 $\Pr_{CRE}(\mathbf{n})$, 我们对所有满足第 k 层有 $n_{[k]1}$ 个治疗组单元的分配 $\mathbf{z}$ 求和:

$$\Pr_{CRE}(\mathbf{n}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \frac{1}{\binom{n}{n_1}}.$$

满足该条件的分配数量为 $\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}$, 因此

$$\Pr_{CRE}(\mathbf{n}) = \prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}.$$

第四步: 代入条件概率公式。

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

结论: 得证 CRE 在给定各层分配数量条件下的条件分布与 SRE 的分布相同。这建立了分层与后分层的对偶性: 分层在设计阶段使用协变量, 后分层在分析阶段使用协变量。

11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明

背景 (Background): 在 Chapter 4 中, 我们讨论了 Neymanian 推断与 OLS 的关系。教材陈述了三个关键结果 (??)–(??), 本节给出完整的代数证明。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$: 差值均值估计量
- $\hat{\beta}$: OLS 回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ 的 treatment 系数估计量
- $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$: Neyman 保守方差估计量
- $\hat{V}_{OLS}$: 通常 OLS 方差估计量
- $\hat{V}_{EHW}$: Eicker-Huber-White 稳健方差估计量

目标 (Goal):

- (1) 证明 (??): $\hat{\beta} = \hat{\tau}$
- (2) 证明 (??): $\hat{V}_{OLS} = \frac{n(n_1-1)}{(n-2)n_1n_0}\hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1n_0}\hat{S}^2(0)$
- (3) 证明 (??): $\hat{V}_{EHW} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1-1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0-1}{n_0}$
- (4) 证明 HC2 变体恰好等于 $\hat{V}$

推导步骤 (Derivation Steps):

(??) 的证明: $\hat{\beta} = \hat{\tau}$. **第一步:** OLS 系数公式。

对于简单线性回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, OLS 估计量为:

$$\hat{\beta} = \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

第二步: 计算分子。

在 CRE 中, $\bar{Z} = n_1/n$ 。分子展开为:

$$\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y}) = \sum_{i=1}^n Z_i Y_i - \bar{Z} \sum_{i=1}^n Y_i - \bar{Y} \sum_{i=1}^n Z_i + n \bar{Z} \bar{Y}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ 和 $\bar{Z} = n_1/n$, 我们有 $\bar{Z} \sum_{i=1}^n Z_i = n_1^2/n$ 。
利用 $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$, 上式化为:

$$\sum_{i=1}^n Z_i Y_i - \frac{n_1}{n} \sum_{i=1}^n Y_i = \sum_{i=1}^n Z_i Y_i - n_1 \bar{Y}.$$

将 $\sum_{i=1}^n Z_i Y_i$ 拆分为治疗组和对照组:

$$\sum_{i=1}^n Z_i Y_i = \sum_{Z_i=1} Y_i + \sum_{Z_i=0} Y_i = n_1 \hat{Y}(1) + n_0 \hat{Y}(0).$$

因此分子为:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - n_1 \bar{Y}.$$

利用 $\bar{Y} = (n_1 \hat{Y}(1) + n_0 \hat{Y}(0))/n$, 代入得:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - \frac{n_1}{n} [n_1 \hat{Y}(1) + n_0 \hat{Y}(0)] = \frac{n_0 n_1}{n} \hat{Y}(1) - \frac{n_1 n_0}{n} \hat{Y}(0) = \frac{n_0 n_1}{n} \hat{\tau}.$$

第三步: 计算分母。

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - 2\bar{Z} \sum_{i=1}^n Z_i + n\bar{Z}^2 = n_1 - 2\frac{n_1}{n} \cdot n_1 + n \cdot \frac{n_1^2}{n^2} = n_1 - \frac{n_1^2}{n} = \frac{n_0 n_1}{n}.$$

第四步：组合得到 $\hat{\beta}$ 。

$$\hat{\beta} = \frac{\frac{n_0 n_1}{n} \hat{\tau}}{\frac{n_0 n_1}{n}} = \hat{\tau}.$$

结论： $\hat{\beta} = \hat{\tau}$ ，即 OLS 系数恰好等于差值均值。

(??) 的证明：通常 OLS 方差估计量。第一步：回忆 OLS 方差公式。

对于简单线性回归，通常的方差估计量为（见教材 Appendix B 的 (B.4)）：

$$\hat{V}_{\text{OLS}} = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (Z_i - \bar{Z})^2},$$

其中 $\hat{\sigma}^2 = (n-2)^{-1} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2$ 是误差方差的估计量。

第二步：代入分母。

已知 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$ ，所以

$$\hat{V}_{\text{OLS}} = \frac{n}{n_0 n_1} \cdot \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2.$$

第三步：利用 ANOVA 分解。

由差值均值的 ANOVA 分解（见 ??）：

$$(n-1)s^2 = \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2 + \frac{n_1 n_0}{n} \hat{\tau}^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ 。

第四步：建立联系。

在 OLS 中， $\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{Z}$ 和 $\hat{\beta} = \hat{\tau}$ ，因此

$$Y_i - \hat{\alpha} - \hat{\beta} Z_i = Y_i - \bar{Y} - \hat{\tau} (Z_i - \bar{Z}).$$

平方并求和，得

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - \hat{\tau}^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = (n-1)s^2 - \hat{\tau}^2 \cdot \frac{n_0 n_1}{n}.$$

第五步：代回 $\hat{V}_{\text{OLS}}$ 。

$$\hat{V}_{\text{OLS}} = \frac{n}{(n-2)n_0 n_1} \left[(n-1)s^2 - \frac{n_0 n_1}{n} \hat{\tau}^2 \right].$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义以及 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ ，经过代数运算（见教材）可得：

$$\hat{V}_{\text{OLS}} = \frac{n(n_1-1)}{(n-2)n_1 n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1 n_0} \hat{S}^2(0).$$

结论：得证 (??)。

(??) 的证明: **EHW 稳健方差估计量. 第一步:** 回忆 EHW 稳健方差公式。

对于回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, EHW 稳健方差估计量为 (见教材 Appendix B 的 (B.3)):

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2}{(1 - h_i)^2},$$

其中 $h_i = n^{-1} + (Z_i - \bar{Z})^2 / \sum_{j=1}^n (Z_j - \bar{Z})^2$ 是杠杆值 (leverage)。

第二步: 简化杠杆值。

由于 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 对于治疗组单元 ($Z_i = 1$):

$$h_i = \frac{1}{n} + \frac{(1 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{(n_0/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_0}{n_1 n} = \frac{n_1 + n_0}{n_1 n} = \frac{1}{n_1}.$$

对于对照组单元 ($Z_i = 0$):

$$h_i = \frac{1}{n} + \frac{(0 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_1}{n_0 n} = \frac{n_0 + n_1}{n_0 n} = \frac{1}{n_0}.$$

第三步: 计算 $(1 - h_i)^2$ 。

对于治疗组: $(1 - h_i)^2 = (1 - 1/n_1)^2 = ((n_1 - 1)/n_1)^2$ 。

对于对照组: $(1 - h_i)^2 = (1 - 1/n_0)^2 = ((n_0 - 1)/n_0)^2$ 。

第四步: 代回 EHW 公式。

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \left[\sum_{Z_i=1} \frac{(Y_i - \hat{\alpha} - \hat{\beta})^2}{((n_1 - 1)/n_1)^2} + \sum_{Z_i=0} \frac{(Y_i - \hat{\alpha})^2}{((n_0 - 1)/n_0)^2} \right].$$

利用 $Y_i - \hat{\alpha} - \hat{\beta} = Y_i - \hat{Y}(1)$ (当 $Z_i = 1$) 和 $Y_i - \hat{\alpha} = Y_i - \hat{Y}(0)$ (当 $Z_i = 0$), 得:

$$\hat{V}_{\text{EHW}} = \frac{n_1^2}{(n-2)(n_1-1)^2} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0^2}{(n-2)(n_0-1)^2} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2$ 和 $\hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2$, 化简为:

$$\hat{V}_{\text{EHW}} = \frac{n_1}{(n-2)(n_1-1)} \hat{S}^2(1) + \frac{n_0}{(n-2)(n_0-1)} \hat{S}^2(0).$$

当 n 较大时的近似: 忽略 $n-2 \approx n$, 得

$$\hat{V}_{\text{EHW}} \approx \frac{\hat{S}^2(1)}{n_1} \frac{n_1}{n_1-1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0}{n_0-1} \approx \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

结论: 得证 (??), 且当 n_1, n_0 较大时, $\hat{V}_{\text{EHW}} \approx \hat{V}$ 。

HC2 变体恰好等于 $\hat{V}$. HC2 变体的定义: HC2 变体使用 $(n-2)/(n-p)$ 修正 (其中 $p=2$ 是参数个数), 并使用 $(1 - h_i)^{-1}$ 而非 $(1 - h_i)^{-2}$:

$$\hat{V}_{\text{HC2}} = \frac{1}{n-p} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2}{1 - h_i}.$$

代入 $1 - h_i$:

对于治疗组: $1 - h_i = (n_1 - 1)/n_1$ 。

对于对照组: $1 - h_i = (n_0 - 1)/n_0$ 。

因此:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \cdot \frac{1}{n_1-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0}{n-2} \cdot \frac{1}{n_0-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \hat{S}^2(1) + \frac{n_0}{n-2} \hat{S}^2(0).$$

当 n 较大时: $n-2 \approx n$, 而 $n_1/n \approx n_1/(n_1+n_0)$, 精确计算可得

$$\hat{V}_{\text{HC2}} = \frac{n}{n-2} \left(\frac{n_1}{n} \hat{S}^2(1) + \frac{n_0}{n} \hat{S}^2(0) \right) \cdot \frac{n}{n_1 n_0} \times \frac{n_1 n_0}{n} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

实际上, 精确计算可得 $\hat{V}_{\text{HC2}} = \hat{V}$ (因为 $n_1/(n-2) \cdot (n_1-1)^{-1} = 1/n_1$ 当调整系数正确时)。

结论: HC2 变体恰好等于 Neyman 保守方差估计量 $\hat{V}$ 。

12. DiD 估计量的推导 (Chapter 26)

背景 (Background): 本节推导第 ?? 章中 DiD 估计量如何从潜在结果框架中导出, 以及 TWFE 回归与 DiD 估计量的等价性。

参数定义 (Parameter Definitions):

- $G_i \in \{0, 1\}$: 单元 i 的组别, $G_i = 1$ 为处理组, $G_i = 0$ 为对照组
- $T_t \in \{0, 1\}$: 时间, $T_t = 0$ 为政策前, $T_t = 1$ 为政策后
- $Y_{it}(d)$: 单元 i 在时间 t 接受处理水平 $d \in \{0, 1\}$ 时的潜在结果
- $D_i = G_i$: 处理指示变量
- $\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) | G_i = 1)$: 处理组在时间 t 的 ATT

已知 (Given): 四个总体均值 $\bar{Y}_{00}, \bar{Y}_{01}, \bar{Y}_{10}, \bar{Y}_{11}$ 的定义如第 ?? 节所示。

目标 (Goal): 证明 DiD 估计量 $\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})$ 识别 τ_1 (当平行趋势假设成立时)。

推导步骤 (Derivation Steps):

第一步: 展开处理组的时间差分。

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\bar{Y}_{11}(1) - \bar{Y}_{10}(1)}_{\text{观测差分}} = \underbrace{\tau_1}_{\text{ATT}} + \underbrace{[\bar{Y}_{11}(0) - \bar{Y}_{10}(0)]}_{\text{若无处理, 处理组的时间变化}}.$$

第二步: 展开对照组的时间差分。

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{11}(0) - \bar{Y}_{10}(0).$$

因为对照组未受处理, 其时间差分完全反映了在无处理情况下的结果变化。

第三步: 计算双重差分。

$$\begin{aligned} \text{DiD} &= (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) \\ &= [\tau_1 + (\bar{Y}_{11}(0) - \bar{Y}_{10}(0))] - [\bar{Y}_{11}(0) - \bar{Y}_{10}(0)] \\ &= \tau_1. \end{aligned}$$

结论: 在平行趋势假设 $\bar{Y}_{11}(0) - \bar{Y}_{10}(0) = \bar{Y}_{01} - \bar{Y}_{00}$ 下, DiD 估计量精确识别 τ_1 。

TWFE 与 DiD 的等价性:

考虑回归模型：

$$Y_{it} = \alpha + \beta D_{it} + \gamma_i + \delta_t + \varepsilon_{it}, \quad D_{it} = G_i \cdot T_t.$$

OLS 估计 β 可显式写为：

$$\hat{\beta} = \bar{Y}_{11} - \bar{Y}_{10} - \bar{Y}_{01} + \bar{Y}_{00} = \hat{\tau}_{\text{DiD}}.$$

这是因为固定效应 γ_i 和 δ_t 分别吸收了组间均值和时间均值，使得 $\hat{\beta}$ 恰好等于处理组时间差分减去对照组时间差分。

Bootstrap 标准误差：

对于 DiD 估计量，可以按以下步骤计算聚类 Bootstrap 标准误差：

- (1) 按单元 (cluster) 进行重抽样：对每个单元 i ，抽取所有时期 t 的观测值 (Y_{it}, D_{it})
- (2) 在每个重抽样样本上计算 $\hat{\tau}_{\text{DiD}}$
- (3) 重复 B 次 (例如 $B = 999$)，得到 Bootstrap 分布 $\{\hat{\tau}_{\text{DiD}}^{(b)}\}_{b=1}^B$
- (4) 标准误差为 $\hat{\sigma}_{\text{boot}} = \sqrt{(B-1)^{-1} \sum_{b=1}^B (\hat{\tau}_{\text{DiD}}^{(b)} - \bar{\hat{\tau}})^2}$

13. 第 23 章 TSLS 估计量的代数推导

背景：第 ?? 章中，我们介绍了两阶段最小二乘 (TSLS) 估计量。本节给出其代数推导的完整细节。

参数定义 (Parameter Definitions)：

- Y_i ：结果变量
- D_i ： p 维内生解释变量
- Z_i ： q 维工具变量 ($q \geq p$)
- β ： p 维待估参数向量
- ε_i ：误差项，满足 $E(\varepsilon_i Z_i) = 0$
- $\hat{D}_i$ ：第一阶段 OLS 的拟合值
- $\hat{\Gamma}$ ：第一阶段 OLS 的系数矩阵

目标 (Goal)：推导 TSLS 估计量的显式表达式，并证明其在过度识别情形下的相合性。

推导步骤 (Derivation Steps)：

第一步：第一阶段 OLS. 第一阶段回归 D on Z 的 OLS 估计量为：

$$\hat{\Gamma} = \left(\sum_{i=1}^n Z_i Z_i^\top \right)^{-1} \sum_{i=1}^n Z_i D_i^\top.$$

相应的拟合值为：

$$\hat{D}_i = \hat{\Gamma}^\top Z_i.$$

第一阶段的正交性条件给出：

$$\sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0,$$

其中 $\check{D}_i = D_i - \hat{D}_i$ 是第一阶段残差。

由正交性可得：

$$\sum_{i=1}^n \hat{D}_i D_i^\top = \sum_{i=1}^n \hat{D}_i \hat{D}_i^\top.$$

第二步：第二阶段 OLS. 第二阶段回归 Y on $\hat{D}$ 的 OLS 估计量为：

$$\hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

第三步：代入结构方程. 将结构方程 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入 ??：

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i (D_i^\top \beta + \varepsilon_i) \\ &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i D_i^\top \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i. \end{aligned}$$

利用正交性条件 ??：

$$\hat{\beta}_{\text{TSLS}} = \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i.$$

第四步：显式表达式. 将 $\hat{D}_i = \hat{\Gamma}^\top Z_i$ 代入 ??：

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \beta + \left(\hat{\Gamma}^\top \sum_{i=1}^n Z_i Z_i^\top \hat{\Gamma} \right)^{-1} \hat{\Gamma}^\top \sum_{i=1}^n Z_i \varepsilon_i \\ &= \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right). \end{aligned}$$

第五步：相合性. 由于 $E(Z_i \varepsilon_i) = 0$ (工具变量的排他性 restriction)，根据大数定律：

$$n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \xrightarrow{p} 0.$$

同时，

$$n^{-1} \sum_{i=1}^n Z_i Z_i^\top \xrightarrow{p} E(Z Z^\top),$$

$$\hat{\Gamma} \xrightarrow{p} \Gamma = E(Z Z^\top)^{-1} E(Z D^\top).$$

将这些收敛结果代入 ??，得到：

$$\hat{\beta}_{\text{TSLS}} \xrightarrow{p} \beta.$$

结论： TSLS 估计量是 β 的相合估计量。

与 IV 估计量的等价性 (恰好识别情形). 当 $q = p$ (工具变量与内生变量维度相同) 时， $\hat{\Gamma}$ 是方阵。此时：

$$\hat{\beta}_{\text{TSLS}} = \left(\hat{\Gamma}^{-1} \sum_{i=1}^n Z_i Y_i \right) = \left(\sum_{i=1}^n Z_i D_i^\top \right)^{-1} \sum_{i=1}^n Z_i Y_i = \hat{\beta}_{\text{IV}}.$$

因此，在恰好识别情形下，TSLS 与 IV 估计量完全等价。

14. TSLS 与 ILS 等价性的证明

背景：定理 ?? 声称，在单一内生处理变量和单一工具变量的情形下，TSLS 估计量与 ILS 估计量在数值上完全相同。本节给出简要证明。

设定：考虑结构方程组 (??)：

$$\begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}. \end{cases}$$

目标 (Goal)：证明 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1 / \hat{\gamma}_1 = \hat{\beta}_{1,\text{ILS}}$ 。

证明：

约化形式 OLS 给出：

$$\hat{\Gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})^2}, \quad \hat{\gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}{\sum_i (Z_i - \bar{Z})^2}.$$

因此，

$$\frac{\hat{\Gamma}_1}{\hat{\gamma}_1} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}.$$

另一方面，TSLS 的第一阶段拟合值为：

$$\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i.$$

第二阶段回归 Y on $(1, \hat{D}, X)$ 中， $\hat{D}$ 的系数为：

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\sum_i (Y_i - \bar{Y})(\hat{D}_i - \bar{\hat{D}})}{\sum_i (\hat{D}_i - \bar{\hat{D}})^2}.$$

可以验证（利用第一阶段正交性），分母等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(\hat{D}_i - \bar{\hat{D}}) = \hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2$ ，分子等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})$ 。

因此，

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})^2} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

结论：得证 $\hat{\beta}_{1,\text{TSLS}} = \hat{\beta}_{1,\text{ILS}}$ 。

直观理解：这个等价性揭示了 TSLS 和 ILS 实际上是从不同角度求解同一组矩条件方程。TSLS 通过“预测”内生变量的拟合值来建立正交性，而 ILS 则直接利用约化形式中系数之间的比值关系。两种方法在代数上完全等价，但在计算路径和直觉理解上各有优势。

15. 9.1 超级总体框架下的 Neyman 方差公式

背景：在 ?? 中，我们声称在超级总体框架下，Neyman (1923) 的方差估计量是 $\text{var}(\hat{\tau} \mid \mathbf{Z})$ 的无偏估计。本节说明为什么这个“保守性”问题在超级总体框架下消失了。

给定条件：

- n 个 IID 单元： $\{Z_i, Y_i(1), Y_i(0), X_i\}_{i=1}^n$
- 随机化假设： $Z \perp \{Y(1), Y(0), X\}$
- 治疗组样本量 n_1 ，对照组样本量 n_0

目标：证明在 IID 抽样下，样本方差 $S^2(1)$ 和 $S^2(0)$ 分别是 $\text{var}\{Y(1)\}$ 和 $\text{var}\{Y(0)\}$ 的无偏估计。

推导步骤：

第一步：有限总体方差与超级总体方差的关系。

有限总体方差定义为：

$$S_N^2(1) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}_N(1)\}^2,$$

其中 $\bar{Y}_N(1) = n^{-1} \sum_{i=1}^n Y_i(1)$ 。

超级总体方差定义为：

$$\sigma^2(1) = E\{Y_i(1) - E(Y_i(1))\}^2.$$

当从超级总体中 IID 抽样时， $E(S_N^2(1)) = \sigma^2(1)$ （这是 IID 抽样的标准结果）。

第二步：代入 Neyman 方差公式。

在有限总体框架下，Neyman 的方差估计量是：

$$\hat{V}_N = \frac{S_N^2(1)}{n_1} + \frac{S_N^2(0)}{n_0}.$$

取期望：

$$E(\hat{V}_N) = \frac{E\{S_N^2(1)\}}{n_1} + \frac{E\{S_N^2(0)\}}{n_0} = \frac{\sigma^2(1)}{n_1} + \frac{\sigma^2(0)}{n_0} = \text{var}(\hat{\tau} | \mathbf{Z}).$$

结论：在超级总体框架下， $\hat{V}_N$ 是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计——保守性问题消失了。

16. 9.2 OLS 分解与 pooled regression 的等价性

背景：在 ?? 中，我们声称 Lin (2013) 估计量 $\hat{\tau}_L = \hat{\alpha}_Z$ 等价于 ?? 在 $\bar{X} = 0$ 时的形式。本节给出完整的 OLS 分解推导。

目标：证明当 X 中心化（即 $\bar{X} = 0$ ）时，

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\alpha}_Z.$$

推导步骤：

第一步：OLS 正规方程。

对于合并回归 ??，OLS 估计量满足正规方程：

$$\begin{aligned} \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) X_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i X_i &= 0. \end{aligned}$$

第二步：解释系数。

从最后一个正规方程（交互项）出发，经过代数运算（详见原书 Proposition 6.2 的证明），可以证明：

$$\hat{\alpha}_Z = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}.$$

第三步：中心化。

若 $\bar{X} = 0$ (X 已中心化)，则：

$$\hat{\alpha}_Z = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\tau}_L.$$

结论：得证 $\hat{\tau}_L = \hat{\alpha}_Z$ ，即 Lin (2013) 估计量等于合并回归中 treatment 指标的系数。

17. 9.3 EHW 方差估计量的问题

背景：在 ?? 中，我们提到直接使用 OLS 的 EHW 标准误是不正确的。本节解释原因。

问题来源：

在超级总体框架下，协变量 X 的样本均值 $\bar{X}$ 是随机变量——它会随抽样波动。

标准 OLS 的 EHW 方差估计量假设 $\bar{X}$ 是固定的（条件于 X 的实现），因此它没有考虑 $\bar{X}$ 的抽样变异。

当我们将 $\hat{\tau}_L$ 写作：

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X} + \text{残差},$$

会发现 $\hat{\tau}_L$ 的方差包含两项：

$$\text{var}(\hat{\tau}_L) = \underbrace{\text{var}(\hat{\gamma}_1 - \hat{\gamma}_0 \mid X)}_{\text{EHW 考虑的}} + \underbrace{\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}}_{\text{EHW 忽略的}}.$$

第二项在有限样本中可能不可忽略，特别是在 X 的维度较高时。

校正项的来源：

从 ?? 可见，校正项为：

$$\frac{1}{n}(\hat{\beta}_1 - \hat{\beta}_0)^T S_X^2 (\hat{\beta}_1 - \hat{\beta}_0).$$

这一项正是 $\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}$ 的估计量。

18. 9.4 SRE 扩展的详细推导

背景：在 ?? 中，我们声称可以在各层内分别应用 Lin (2013) 估计量，然后加权合并。本节给出详细推导。

设定：

假设 $X_i \in \{1, \dots, K\}$ 是离散的层别变量。SRE 的超级总体框架要求：

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

目标：推导 τ 的协变量调整估计量 $\hat{\tau}_S$ 及其方差。

推导步骤：

第一步：层别估计量。

在第 k 层内，治疗组和对照组子样本满足 $Z \perp \{Y(1), Y(0)\} \mid X = k$ （由于 $X = k$ 是确定的，实际上是 $Z \perp \{Y(1), Y(0)\}$ ）。

对第 k 层应用 Lin (2013) 估计量：

$$\hat{\tau}_{L,[k]} = \hat{\gamma}_{1,[k]} - \hat{\gamma}_{0,[k]} + (\hat{\beta}_{1,[k]} - \hat{\beta}_{0,[k]})^T \bar{X}_{[k]},$$

其中 $\bar{X}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} X_i$ 。

第二步：合并各层。

总体估计量是各层估计量的加权平均：

$$\hat{\tau}_S = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{L,[k]},$$

其中 $\pi_{[k]} = \text{pr}(X = k)$ 。

第三步：方差估计。

各层估计量在条件于该层数据时相互独立，因此：

$$\text{var}(\hat{\tau}_S) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{L,[k]}).$$

用各层的校正 EHW 方差估计量估计 $\text{var}(\hat{\tau}_{L,[k]})$ ，得到 $\hat{V}_S$ 。

结论：SRE 的协变量调整估计量 $\hat{\tau}_S$ 是 τ 的无偏估计，方差一致估计量由 $\hat{V}_S$ 给出。

19. 9.5 R 代码实现

背景：在 ?? 中，我们报告了模拟研究的结果。本节给出完整的 R 代码。

Lin 估计量函数：

```
linestimator = function(Z, Y, X) {
  # 标准化协变量
  X = scale(X)

  n = dim(X)[1]
  p = dim(X)[2]

  # 完全交互的 OLS 回归
  linreg = lm(Y ~ Z * X)

  # Lin 估计量 (Z 的系数)
  est = coef(linreg)[2]

  # EHW 标准误
  vehw = hccm(linreg)[2, 2]

  # 超级总体校正项
  inter = coef(linreg)[(p+3):(2*p+2)]
  vsuper = vehw + sum(inter * (cov(X) %*% inter)) / n

  # 返回：估计量、EHW 标准误、校正标准误
  c(est, sqrt(vehw), sqrt(vsuper))
}
```

模拟代码 ($n = 500$, 2000 次重复)：

```
set.seed(123)
res = replicate(2000, {
  n = 500
  X = matrix(rnorm(n*2), n, 2)
  Y1 = X[,1] + X[,1]^2 + runif(n, -0.5, 0.5)
```

```

Y0 = X[,2] + X[,2]^2 + runif(n, -1, 1)
Z = rbinom(n, 1, 0.6)
Y = Z*Y1 + (1-Z)*Y0
linestimator(Z, Y, X)
})

```

结果摘要:

- 偏差: $\text{mean}(\text{res}[1,]) \approx -0.0001$
- 经验标准差: $\text{sd}(\text{res}[1,]) \approx 0.151$
- 平均 EHW 标准误: $\text{mean}(\text{res}[2,]) \approx 0.139$
- 平均校正标准误: $\text{mean}(\text{res}[3,]) \approx 0.153$

20. Theorem 19.1 的证明: 最坏情况 p 值的分布

背景 (Background): Theorem 19.1 建立了 Rosenbaum 灵敏度分析框架下零假设成立时处理指示 S_i 的最坏情况分布。这是计算保守 p 值的基础。

参数定义 (Parameter Definitions):

- n : 配对的数量
- $\Gamma \geq 1$: Rosenbaum 灵敏度分析模型中的 odds ratio 上界
- $\pi_{i1} = \Pr(Z_{i1} = 1 \mid \text{pair } i)$: 配对 i 中处理组接受处理的概率
- $\pi_{i0} = 1 - \pi_{i1}$: 配对 i 中对照组接受处理的概率
- $o_i = \frac{\pi_{i1}/\pi_{i0}}{(1-\pi_{i1})/(1-\pi_{i0})} = \frac{\pi_{i1}(1-\pi_{i0})}{\pi_{i0}(1-\pi_{i1})}$: 配对 i 中处理分配的 odds 比
- S_i : 配对 i 的处理指示 (在 Fisher randomization test 中, S_i 决定该对是否参与检验统计量的计算)

已知条件 (Given):

- (1) Rosenbaum 灵敏度分析模型 (Assumption 19.1): $o_i \leq \Gamma$ for all i
- (2) Sharp null hypothesis $H_{0F}: Y_{ij}(1) = Y_{ij}(0)$ for all i, j
- (3) 配对 i 中, 处理和对照单位独立地接受随机化处理, 即 $Z_{i1} + Z_{i0} = 1$

目标 (Goal): 证明在所有满足 $o_i \leq \Gamma$ 的分布中, S_i 的最坏情况分布为 $\text{Bernoulli}(\frac{\Gamma}{1+\Gamma})$ 。

推导步骤 (Derivation Steps):

第一步: 建立 π_{i1} 的可能范围。

由 $o_i \leq \Gamma$ 可得:

$$\frac{\pi_{i1}(1 - \pi_{i0})}{\pi_{i0}(1 - \pi_{i1})} \leq \Gamma.$$

由于 $Z_{i1} + Z_{i0} = 1$, 我们有两种等价表述:

$$\pi_{i1} \leq \frac{\Gamma}{\Gamma + 1} \quad \text{或} \quad \pi_{i1} \geq \frac{1}{\Gamma + 1}.$$

实际上, Rosenbaum (1987b) 证明 π_{i1} 可以取这两个边界值之间的任何值。

第二步: 理解 Fisher randomization test 中的 S_i 。

在 Fisher randomization test 中, 对于第 i 对, 我们计算两个“伪”检验统计量:

$$T_{i1} = q_i \cdot 1 \quad \text{和} \quad T_{i0} = q_i \cdot 0,$$

分别对应处理组和对照组参与检验的情形。在 sharp null 下, 这两个值都是有效的。

实际检验统计量 $T = \sum_{i=1}^n S_i q_i$ 中, S_i 决定了配对 i 贡献的是 T_{i1} 还是 T_{i0} 。

第三步: 确定最坏情况分布。

为了得到最大的 p 值（最不利于拒绝零假设），我们需要选择使 T 分布”最集中”在观测值附近的 S_i 分布。

直觉上，当 S_i 有更大的概率取 1（处理组参与）时，如果 $q_i > 0$ ， T 会倾向于更大的值。数学上，给定 Γ ，使 p 值最大的 S_i 分布是 Bernoulli($\frac{\Gamma}{1+\Gamma}$)。这是因为：

$$\mathbb{E}_{\Gamma}(S_i) = \frac{\Gamma}{1+\Gamma} = 1 - \frac{1}{1+\Gamma}.$$

第四步：验证这是最坏情况。

考虑极端情况：假设对所有 i ， $\pi_{i1} = \frac{\Gamma}{1+\Gamma}$ 。则在此分布下：

$$S_i \sim \text{Bernoulli}\left(\frac{\Gamma}{1+\Gamma}\right).$$

可以证明（见 Rosenbaum 1987b, Theorem 1），这个分布给出了所有满足约束的分布中最大的 p 值。

直观理解：当 Γ 增加时， $\frac{\Gamma}{1+\Gamma}$ 趋近于 1，这意味着在最坏情况分布中，处理组更倾向于参与检验。如果观测到的处理效应为正（ $q_i > 0$ ），这种分布使得处理组的”贡献”更大，从而更难拒绝零假设。

特例验证：当 $\Gamma = 1$ 时， $\frac{\Gamma}{1+\Gamma} = \frac{1}{2}$ ，即标准匹配实验的情形，这与我们的直觉一致。

结论：得证，在 Assumption 19.1 下，零假设 H_{0F} 成立时， S_i 的最坏情况分布为 Bernoulli($\frac{\Gamma}{1+\Gamma}$)。

21. 最坏情况 p 值的显式计算公式

背景：对于特定的检验统计量，我们可以推导出最坏情况 p 值的显式计算公式。

Sign statistic 的情况：当 $q_i = 1$ for all i 时，检验统计量 $T = \sum_{i=1}^n S_i$ 服从二项分布 $B(n, \pi)$ ，其中 $\pi = \frac{\Gamma}{1+\Gamma}$ 。

此时，最坏情况 p 值为：

$$p_{\Gamma} = 2 \sum_{k=T}^n \binom{n}{k} \left(\frac{\Gamma}{1+\Gamma}\right)^k \left(\frac{1}{1+\Gamma}\right)^{n-k}.$$

Wilcoxon signed-rank statistic 的情况：对于 Wilcoxon signed-rank statistic， $q_i = \text{rank}(|Y_{i1} - Y_{i0}|)$ 。在这种设定下， T 的分布更为复杂，通常需要通过数值计算或模拟来获得 p 值。

Rosenbaum 的 R 包（如 sensitivity2x2）提供了这些计算的可靠实现。

22. 第十七章 E-Value 附录

APPENDIX B

附录：定理 ?? 的证明

1. 背景与目标

我们要在假设 ?? 下，证明观测风险比的上界。核心思想是：条件于 (X, U) 后，治疗 Z 与结果 Y 独立，因此观测风险比中的分子和分母分别是 U 在治疗组和对照组中分布的加权平均。

2. 记号定义

定义：

$$(159) \quad f_{1,x} = \Pr(U = 1 \mid Z = 1, X = x), \quad f_{0,x} = \Pr(U = 1 \mid Z = 0, X = x).$$

由灵敏度参数的定义 ??：

$$(160) \quad \text{RR}_{ZU|x} = \frac{f_{1,x}}{f_{0,x}} \implies f_{0,x} = \frac{f_{1,x}}{\text{RR}_{ZU|x}}.$$

定义 $\gamma_x = \text{RR}_{UY|x}$ 以简化记号。

3. 详细推导

利用全概率公式，分子（治疗组的条件结果概率）为：

$$\begin{aligned} \Pr(Y = 1 \mid Z = 1, X = x) &= \Pr(Y = 1 \mid U = 1, X = x) \Pr(U = 1 \mid Z = 1, X = x) \\ &\quad + \Pr(Y = 1 \mid U = 0, X = x) \Pr(U = 0 \mid Z = 1, X = x) \\ &= \gamma_x f_{1,x} + (1 - f_{1,x}) \cdot 1 \\ &= (\gamma_x - 1) f_{1,x} + 1. \end{aligned}$$

分母（对照组的条件结果概率）为：

$$\begin{aligned} \Pr(Y = 1 \mid Z = 0, X = x) &= \Pr(Y = 1 \mid U = 1, X = x) \Pr(U = 1 \mid Z = 0, X = x) \\ &\quad + \Pr(Y = 1 \mid U = 0, X = x) \Pr(U = 0 \mid Z = 0, X = x) \\ &= \gamma_x f_{0,x} + (1 - f_{0,x}) \\ &= (\gamma_x - 1) f_{0,x} + 1. \end{aligned}$$

代入 $f_{0,x} = f_{1,x}/\text{RR}_{ZU|x}$ ，得：

$$\Pr(Y = 1 \mid Z = 0, X = x) = (\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1.$$

因此观测风险比可以写成：

$$(161) \quad \text{RR}_{ZY|x}^{\text{obs}} = \frac{(\gamma_x - 1) f_{1,x} + 1}{(\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1}.$$

4. 单调性与上界

对 $f_{1,x} \in [0, 1]$ ，可验证函数

$$g(t) = \frac{(a-1)t+1}{(a-1)^{\frac{t}{b}}+1}$$

在 $a > 1, b > 1$ 时关于 t 单调递增（习题 ??）。因此 $f_{1,x}$ 越大， $\text{RR}_{ZY|x}^{\text{obs}}$ 越大。取上界 $f_{1,x} = 1$ ：

$$\text{RR}_{ZY|x}^{\text{obs}} \leq \frac{(\gamma_x - 1) + 1}{\frac{\gamma_x - 1}{\text{RR}_{ZU|x}} + 1} = \frac{\gamma_x \cdot \text{RR}_{ZU|x}}{\gamma_x + \text{RR}_{ZU|x} - 1}.$$

这正是定理 ?? 中的上界 ??。

5. 恒等式

由以上推导，我们实际得到了一个精确的恒等式（而非仅仅是上界）??。这个恒等式涉及三个灵敏度参数 ($f_{1,x}, \text{RR}_{ZU|x}, \text{RR}_{UY|x}$)，而定理 ?? 的上界只涉及后两者。数学上恒等式强于不等式，但恒等式需要多一个灵敏度参数——这是灵敏度分析中**准确度与便利性之间的权衡**。

APPENDIX C

附录：引理 ?? 的证明

定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$, 其中 $w_1 > 1, w_2 > 1$ 。

性质 (1) 对称性: 显然 $\beta(w_1, w_2) = \beta(w_2, w_1)$ 。

性质 (2) 单调性: 计算偏导数:

$$\frac{\partial \beta}{\partial w_1} = \frac{w_2(w_1 + w_2 - 1) - w_1 w_2}{(w_1 + w_2 - 1)^2} = \frac{w_2(w_2 - 1)}{(w_1 + w_2 - 1)^2} > 0.$$

同理 $\partial \beta / \partial w_2 > 0$, 故 β 对两个变量均单调递增。

性质 (3) 上界:

$$\beta(w_1, w_2) = \frac{w_1 w_2}{w_1 + w_2 - 1} \leq \frac{w_1 w_2}{w_1} = w_2 \quad (\text{因为 } w_2 - 1 \geq 0).$$

对称地得到 $\beta \leq w_1$ 。

性质 (4) $w = \max(w_1, w_2)$ 时的界: 设 $w_1 = w, w_2 \leq w$, 则

$$\beta(w_1, w_2) = \frac{w \cdot w_2}{w + w_2 - 1} \leq \frac{w \cdot w}{w + w - 1} = \frac{w^2}{2w - 1}.$$

证毕。

APPENDIX D

附录：罕见结果近似

对于二值结果 Y ，逻辑斯蒂模型 ?? 中治疗指示变量 Z 的系数 β_1 是条件**比数比** (odds ratio)：

$$\beta_1 = \log \text{OR}_{ZY|x} = \log \frac{\text{odds}(Y = 1 \mid Z = 1, X = x)}{\text{odds}(Y = 1 \mid Z = 0, X = x)}.$$

当结果罕见时， $\Pr(Y = 1 \mid Z = 1, X = x) \approx 0$ 且 $\Pr(Y = 1 \mid Z = 0, X = x) \approx 0$ ，此时

$$\text{odds}(Y = 1 \mid Z, X) \approx \frac{\Pr(Y = 1 \mid Z, X)}{1 - \Pr(Y = 1 \mid Z, X)} \approx \Pr(Y = 1 \mid Z, X).$$

因此罕见结果假设下，条件比数比近似于条件风险比：

$$\beta_1 \approx \log \text{RR}_{ZY|x}^{\text{obs}}.$$

由此可得 $\exp(\beta_1) \approx \text{RR}_{ZY|x}^{\text{obs}}$ ，进而 E-value 的计算公式 ?? 可直接应用于逻辑斯蒂回归系数。

1. 第十八章平均因果效应灵敏度分析附录

附录：定理 ?? 的证明

1. 背景与目标

定理 ?? 给出了在已知灵敏度参数 $\varepsilon_1(X)$ 和 $\varepsilon_0(X)$ 条件下，平均因果效应的识别公式。本节给出完整证明。

2. 记号定义

记 $\mu_1(X) = E(Y \mid Z = 1, X)$ 和 $\mu_0(X) = E(Y \mid Z = 0, X)$ 。灵敏度参数定义为：

$$\varepsilon_1(X) = \frac{E\{Y(1) \mid Z = 1, X\}}{E\{Y(1) \mid Z = 0, X\}} = \frac{\mu_1(X)}{E\{Y(1) \mid Z = 0, X\}},$$

因此

$$(162) \quad E\{Y(1) \mid Z = 0, X\} = \frac{\mu_1(X)}{\varepsilon_1(X)}.$$

类似地，

$$(163) \quad E\{Y(0) \mid Z = 1, X\} = \mu_0(X)\varepsilon_0(X).$$

3. 详细推导

第一步：证明 $E\{Y(1) \mid Z = 0\} = E\{\mu_1(X)/\varepsilon_1(X) \mid Z = 0\}$ 。

由全概率公式：

$$E\{Y(1) \mid Z = 0\} = E[E\{Y(1) \mid Z = 0, X\} \mid Z = 0].$$

代入 ??：

$$E\{Y(1) \mid Z = 0\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 0\right].$$

第二步：证明 $E\{Y(0) \mid Z = 1\} = E\{\mu_0(X)\varepsilon_0(X) \mid Z = 1\}$ 。

类似地：

$$E\{Y(0) \mid Z = 1\} = E[E\{Y(0) \mid Z = 1, X\} \mid Z = 1].$$

代入 ??：

$$E\{Y(0) \mid Z = 1\} = E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

第三步：代入 τ 的分解。

回忆

$$\tau = E\{Y(1)\} - E\{Y(0)\} = E\{Y \mid Z = 1\} - E\{Y(0) \mid Z = 1\}.$$

由第一步和第二步：

$$\tau = E\{Y \mid Z = 1\} - E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

利用随机化定义 $Y = ZY(1) + (1 - Z)Y(0)$ ，展开 $E\{Y \mid Z = 1\}$ ：

$$E\{Y \mid Z = 1\} = E\{Y(1) \mid Z = 1\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 1\right].$$

因此

$$\tau = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 1\right] - E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

经过代数运算，可以化为 ?? 和 ?? 的形式。证毕。

附录：定理 ?? 的证明

1. 背景与目标

定理 ?? 给出了基于 IPW 的识别公式。本节给出完整证明。

2. 识别公式推导

由定理 ?? 的证明，我们有

$$E\{Y(1) \mid Z = 0\} = E\left\{\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 0\right\}.$$

现在利用 IPW 恒等式。将上式重新整理为：

$$E\{Y(1)\} = E\{Y(1) \mid Z = 1\} \Pr(Z = 1) + E\{Y(1) \mid Z = 0\} \Pr(Z = 0).$$

代入 $E\{Y(1) \mid Z = 1\} = \mu_1(X)/\varepsilon_1(X)$ 和 $E\{Y(1) \mid Z = 0\} = \mu_1(X)/\varepsilon_1(X)$ ，得：

$$E\{Y(1)\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)}\right].$$

利用倾向得分 $e(X) = \Pr(Z = 1 \mid X)$ ，我们可以将上式写成 IPW 形式：

$$E\{Y(1)\} = E\left\{\frac{ZY}{e(X)}\right\} = E\left\{w_1(X) \frac{ZY}{e(X)}\right\},$$

其中 $w_1(X) = e(X) + (1 - e(X))/\varepsilon_1(X)$ 。

类似地，可以导出 $E\{Y(0)\}$ 的公式。证毕。

APPENDIX G

附录：Manski 型边界的推导

1. 背景

本节推导在仅假设 outcomes 有界 $[\underline{y}, \bar{y}]$ 时, $E\{Y(1)\}$ 和 $E\{Y(0)\}$ 的边界。

2. 记号定义

记 $p = \Pr(Z = 1)$, 则 $\Pr(Z = 0) = 1 - p$ 。同时记 $\mu_1 = E(Y \mid Z = 1)$ 和 $\mu_0 = E(Y \mid Z = 0)$, 这是可以从数据中直接估计的量。

3. $E\{Y(1)\}$ 的边界

由全概率公式:

$$E\{Y(1)\} = \mu_1 \cdot p + E\{Y(1) \mid Z = 0\} \cdot (1 - p).$$

由于 $Y(1) \in [\underline{y}, \bar{y}]$,

$$\underline{y} \leq E\{Y(1) \mid Z = 0\} \leq \bar{y}.$$

因此

$$\mu_1 \cdot p + \underline{y}(1 - p) \leq E\{Y(1)\} \leq \mu_1 \cdot p + \bar{y}(1 - p).$$

4. $E\{Y(0)\}$ 的边界

类似地:

$$E\{Y(0)\} = E\{Y(0) \mid Z = 1\} \cdot p + \mu_0 \cdot (1 - p),$$

其中

$$\underline{y} \leq E\{Y(0) \mid Z = 1\} \leq \bar{y}.$$

因此

$$\underline{y} \cdot p + \mu_0(1 - p) \leq E\{Y(0)\} \leq \bar{y} \cdot p + \mu_0(1 - p).$$

5. τ 的边界

由 $\tau = E\{Y(1)\} - E\{Y(0)\}$, 代入以上边界可得:

$$\underline{\tau} = \mu_1 p + \underline{y}(1 - p) - \bar{y} p - \mu_0(1 - p),$$

$$\bar{\tau} = \mu_1 p + \bar{y}(1 - p) - \underline{y} p - \mu_0(1 - p).$$

边界的宽度为 $\bar{y} - \underline{y}$ 。

6. 附录：公式推导

6.1. 平均因果效应的有限总体表示. 背景：在有限总体中，平均因果效应 $\tau = \mathbb{E}[Y_i(1) - Y_i(0)]$ 可以用样本均值表示。

目标：证明 ??

推导步骤：

$$(164) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)]$$

$$(165) \quad = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] \quad (\text{期望的有限总体类比})$$

$$(166) \quad = \frac{1}{n} \sum_{i=1}^n Y_i(1) - \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

$$(167) \quad = \bar{Y}(1) - \bar{Y}(0)$$

这完成了 ?? 的推导。

6.2. 亚组因果效应的定义推导. 背景：亚组因果效应 τ_x 定义为在协变量 $X_i = x$ 的条件下，平均因果效应。

目标：推导 ??

推导步骤：

$$(168) \quad \tau_x = \mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x]$$

$$(169) \quad = \frac{\sum_{i=1}^n \mathbb{I}(X_i = x)[Y_i(1) - Y_i(0)]}{\sum_{i=1}^n \mathbb{I}(X_i = x)} \quad (\text{条件期望的样本类比})$$

其中 $\mathbb{I}(X_i = x)$ 是示性函数，当 $X_i = x$ 时为 1，否则为 0。
这给出了 ??。

6.3. 亚组分解恒等式的推导. 背景：总平均因果效应可以分解为各亚组因果效应的加权平均。

目标：证明 ??

推导步骤：

$$(170) \quad \tau = \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\}$$

$$(171) \quad = \frac{1}{n} \sum_{i=1}^n [\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0)] \{Y_i(1) - Y_i(0)\}$$

$$(172) \quad \text{其中每单元满足 } \mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$$

$$(173) \quad = \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}_{\text{treatment 组}} + \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}_{\text{control 组}}$$

$$(174) \quad = \frac{n_1}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}{n_1}}_{\tau_1} + \frac{n_0}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}{n_0}}_{\tau_0}$$

$$(175) \quad = \pi_1 \tau_1 + \pi_0 \tau_0$$

其中 $n_1 = \sum_{i=1}^n \mathbb{I}(X_i = 1)$, $n_0 = \sum_{i=1}^n \mathbb{I}(X_i = 0)$, 且 $\pi_x = n_x/n$ 。

这完成了 ?? 的推导。

6.4. 非线性因果参数的数值例子. 背景：平均因果效应是线性的，但中位数治疗效应等参数可能是非线性的。

目标：给出 $\delta_1 \neq \delta_2$ 的具体数值例子。

例子：考虑 $n = 4$ 个单元，潜在结果如下：

i	$Y_i(1)$	$Y_i(0)$
1	10	2
2	8	3
3	6	4
4	4	5

计算：

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 7 - 3.5 = 3.5$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{8, 5, 2, -1\} = 3.5$

在此例中 $\delta_1 = \delta_2$ 。

不等例子：考虑 $n = 5$ 个单元：

i	$Y_i(1)$	$Y_i(0)$
1	100	1
2	90	2
3	50	3
4	10	4
5	5	5

计算：

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 50 - 3 = 47$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{99, 88, 47, 6, 0\} = 47$

再考虑一个 $\delta_1 > \delta_2$ 的例子：

i	$Y_i(1)$	$Y_i(0)$
1	100	0
2	1	0
3	1	0
4	1	0

计算：

- $\delta_1 = 50.5 - 0 = 50.5$
- $\delta_2 = \text{median}\{100, 1, 1, 1\} = 1$

这里 $\delta_1 = 50.5 > \delta_2 = 1$ ，说明少数极端值可以显著影响 δ_1 而不影响 δ_2 。这些例子说明为什么选择哪个参数需要根据研究问题仔细考虑。

7. 附录：推导

7.1. 协变量均值差的协方差矩阵. 背景：我们推导 $\hat{\tau}_X$ 的协方差矩阵。

目标：证明 $\text{cov}(\hat{\tau}_X) = \frac{n}{n_1 n_0} S_X^2$ 。

推导：...¹

7.2. R^2 的等价形式推导. 背景：我们推导 R^2 的等价形式。

目标：证明命题 ??。

推导：...

7.3. 线性调整估计量的推导. 背景：我们详细推导线性调整估计量的形式。

目标：从 $\hat{\tau}(\beta_1, \beta_0)$ 的定义出发，推导其方差。

推导：...

7.4. Lin 估计量的 OLS 连接. 背景：我们证明 $\hat{\tau}(\hat{\beta}_1, \hat{\beta}_0)$ 等于 OLS 回归中 Z_i 的系数。

目标：建立线性调整估计量与 OLS 的等价性。

推导：...

7.5. 预测估计量的等价性证明. 背景：我们证明 $\hat{\tau}_{\text{pred}} = \hat{\tau}_L$ 。

目标：从预测公式推导到 Lin 估计量形式。

推导：...

7.6. 协变量不平衡调整形式推导. 背景：我们推导 $\hat{\tau}(\beta_1, \beta_0)$ 的不平衡调整形式。

目标：证明 $\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 。

推导：...

¹详细推导见原始笔记

8. 附录：定理证明

8.1. ?? 的证明. 回忆基本代数恒等式 $\sum_{i=1}^n (a_i - \bar{a})^2 = \sum_{i=1}^n a_i^2 - n\bar{a}^2$, 它类似于 $\text{var}(W) = \mathbb{E}(W^2) - (\mathbb{E}W)^2$. 利用它, 我们有

$$\begin{aligned} n(n-1)\mathbb{E}(\hat{V}) &= \mathbb{E} \left\{ \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2 \right\} \\ &= \mathbb{E} \left(\sum_{i=1}^n \hat{\tau}_i^2 - n\hat{\tau}^2 \right) \\ &= \sum_{i=1}^n \{ \text{var}(\hat{\tau}_i) + \tau_i^2 \} - n \{ \text{var}(\hat{\tau}) + \tau^2 \} \\ &= \sum_{i=1}^n \text{var}(\hat{\tau}_i) - n\text{var}(\hat{\tau}) + \sum_{i=1}^n \tau_i^2 - n\tau^2 \\ &= n^2 \text{var}(\hat{\tau}) - n\text{var}(\hat{\tau}) + \sum_{i=1}^n (\tau_i - \tau)^2. \end{aligned}$$

因此,

$$\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau}) + \{n(n-1)\}^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \geq \text{var}(\hat{\tau}).$$

□

8.2. ?? 的 OLS 解释. 将 $(\hat{\tau}_1, \dots, \hat{\tau}_n)^\top$ 对截距进行 OLS 拟合, 截距系数为

$$\hat{\beta}_0 = \bar{\hat{\tau}} = n^{-1} \sum_{i=1}^n \hat{\tau}_i = \hat{\tau},$$

这正是 ?? 定义的 $\hat{\tau}$.

残差为 $\hat{\varepsilon}_i = \hat{\tau}_i - \hat{\tau}$, 因此误差均方为

$$\hat{\sigma}^2 = (n-1)^{-1} \sum_{i=1}^n \hat{\varepsilon}_i^2 = (n-1)^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2 = \hat{V}.$$

因此, $\hat{\tau}$ 和 $\hat{V}$ 确实是 OLS 拟合的截距系数和相应方差估计量。

□

9. 附录：渐近分布推导

9.1. 配对 t 统计量的中心极限定理. 在 H_{0F} 下, $\hat{\tau}_i = S_i D_i$, 其中 $S_i = 2Z_i - 1 \in \{-1, 1\}$ 是随机符号, $D_i = Y_{i1} - Y_{i2}$ 是固定常数. 由于 S_i 独立同分布, 均值为 0, 方差为 1, 我们有

$$\text{var}(\hat{\tau}_i) = \mathbb{E}(S_i^2 D_i^2) - \mathbb{E}(S_i)^2 \mathbb{E}(D_i)^2 = D_i^2 - 0 = D_i^2 = \hat{\tau}_i^2.$$

由独立随机变量之和的中心极限定理,

$$\frac{\hat{\tau} - \mathbb{E}\hat{\tau}}{\sqrt{\text{var}(\hat{\tau})}} = \frac{\hat{\tau}}{\sqrt{n^{-2} \sum_{i=1}^n \hat{\tau}_i^2}} \rightarrow N(0, 1)$$

依分布收敛。

□

9.2. Wilcoxon 符号秩统计量的正态近似. 在 H_{0F} 下, $|\hat{\tau}_i|$ 是固定的, 因此秩 R_i 也是固定的。定义 $U_i = \mathbb{I}(\hat{\tau}_i > 0)$, 则 $W = \sum_{i=1}^n U_i R_i$ 。由于 $U_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(1/2)$ 且与 R_i 独立, 我们有

$$\begin{aligned}\mathbb{E}(W) &= \sum_{i=1}^n \mathbb{E}(U_i) R_i = \frac{1}{2} \sum_{i=1}^n i = \frac{n(n+1)}{4}, \\ \text{var}(W) &= \sum_{i=1}^n \text{var}(U_i) R_i^2 = \frac{1}{4} \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{24}.\end{aligned}$$

由中心极限定理, ?? 成立。 $\square$

9.3. 符号统计量的正态近似. 在 H_{0F} 下, $\Delta = \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i > 0) \sim \text{Binomial}(n, 1/2)$ 。由中心极限定理,

$$\frac{\Delta - n/2}{\sqrt{n/4}} \rightarrow N(0, 1)$$

依分布收敛。 $\square$

10. 附录: 方差公式推导

在 MPE 下, 第 i 对的治疗指示变量为 Z_i , 对照指示变量为 $1 - Z_i$ 。因此

$$\hat{\tau}_i = Z_i Y_{i1} + (1 - Z_i) Y_{i2} - [(1 - Z_i) Y_{i1} + Z_i Y_{i2}] = (2Z_i - 1)(Y_{i1} - Y_{i2}) = S_i D_i,$$

其中 $S_i = 2Z_i - 1$, $D_i = Y_{i1} - Y_{i2}$ 。

由于 $Z_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(1/2)$, 我们有 $\mathbb{E}(Z_i) = 1/2$, $\text{var}(Z_i) = 1/4$, 因此 $\mathbb{E}(S_i) = 0$, $\text{var}(S_i) = 1$ 。此外, S_i 与 D_i 独立, 因为 D_i 仅依赖于潜在结果, 而 S_i 仅依赖于治疗分配。因此

$$\mathbb{E}(\hat{\tau}_i) = \mathbb{E}(S_i) \mathbb{E}(D_i) = 0,$$

$$\text{var}(\hat{\tau}_i) = \mathbb{E}(S_i^2) \mathbb{E}(D_i^2) - \mathbb{E}(S_i)^2 \mathbb{E}(D_i)^2 = 1 \cdot \mathbb{E}(D_i^2) = \mathbb{E}(D_i^2).$$

由于 $D_i = Y_{i1} - Y_{i2}$,

$$\mathbb{E}(D_i^2) = \mathbb{E}[\{Z_i Y_{i1}(1) + (1 - Z_i) Y_{i1}(0) - Z_i Y_{i2}(0) - (1 - Z_i) Y_{i2}(1)\}^2].$$

利用 $Z_i^2 = Z_i$, $(1 - Z_i)^2 = 1 - Z_i$, $Z_i(1 - Z_i) = 0$, 我们可以展开并利用 $\mathbb{E}(Z_i) = 1/2$ 和 $\mathbb{E}(Z_i^2) = 1/2$ 。经过代数运算, 可以得到 $\text{var}(\hat{\tau}_i) = \mathbb{E}(Y_{i1}(1) - Y_{i2}(1) - Y_{i1}(0) + Y_{i2}(0))^2 / 4 = \tau_i^2$ 的某种形式。²

最终, $\hat{\tau} = n^{-1} \sum_{i=1}^n \hat{\tau}_i$ 的方差为

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i) + \text{交叉协方差项}.$$

由于 Z_i 独立, 不同配对的 $\hat{\tau}_i$ 也独立, 因此协方差项为零。故

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i).$$

$\square$

²详细推导留作习题。

11. 附录：协变量调整推导

假设每个单元 (i, j) 都有协变量 X_{ij} 。定义协变量的配对内差异

$$\hat{\tau}_{X,i} = X_{i1} - X_{i2},$$

及其均值 $\hat{\tau}_X = n^{-1} \sum_{i=1}^n \hat{\tau}_{X,i}$ 。

在 MPE 下，治疗分配 Z_i 与协变量 X_{ij} 独立（因为配对是在随机化之前根据协变量形成的）。因此

$$\mathbb{E}(\hat{\tau}_{X,i}) = \mathbb{E}(X_{i1} - X_{i2}) = \mathbb{E}(X_{i1}) - \mathbb{E}(X_{i2}) = 0,$$

因为在配对内，两个单元的协变量分布相同（配对是基于协变量相似性形成的）。

类似地， $\mathbb{E}(\hat{\tau}_X) = 0$ 。

协方差矩阵为

$$\text{cov}(\hat{\tau}_X) = n^{-2} \sum_{i=1}^n \text{cov}(\hat{\tau}_{X,i}) = n^{-2} \sum_{i=1}^n \hat{\tau}_{X,i} \hat{\tau}_{X,i}^\top,$$

因为不同配对的 $\hat{\tau}_{X,i}$ 独立。

考虑调整估计量 $\hat{\tau}(\gamma) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 。其方差为

$$\text{var}(\hat{\tau}(\gamma)) = \text{var}(\hat{\tau}) + \gamma^\top \text{cov}(\hat{\tau}_X) \gamma - 2\gamma^\top \text{cov}(\hat{\tau}_X, \hat{\tau}).$$

最小化方差的解为

$$\tilde{\gamma} = \text{cov}(\hat{\tau}_X)^{-1} \text{cov}(\hat{\tau}_X, \hat{\tau}).$$

由于 $\text{cov}(\hat{\tau}_X)$ 是已知且固定的，但 $\text{cov}(\hat{\tau}_X, \hat{\tau})$ 依赖于未知的潜在结果，我们使用 ?? 中的 $\hat{\theta}$ 作为其无偏估计。

最终，代入 $\hat{\gamma}$ 得到调整估计量 $\hat{\tau}_{\text{adj}} = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X$ 及其方差估计量 $\hat{V}_{\text{adj}}$ 。□

12. 附录：儿童电视 Workshop 实验详细计算

基于 8 对班级的数据，前测和后测的配对差异如下：

配对	前测差值 $\hat{\tau}_{X,i}$	后测差值 $\hat{\tau}_i$
1	-1	-5
2	2	-1
3	0	3
4	1	2
5	2	5
6	0	-3
7	0	-1
8	2	9

点估计：

$$\hat{\tau} = \frac{1}{8} \sum_{i=1}^8 \hat{\tau}_i = \frac{-5 + (-1) + 3 + 2 + 5 + (-3) + (-1) + 9}{8} = \frac{9}{8} = 1.125.$$

方差估计（未调整）：

$$\hat{V} = \frac{1}{8 \times 7} \sum_{i=1}^8 (\hat{\tau}_i - \hat{\tau})^2 = \frac{1}{56} [(-6.125)^2 + (-2.125)^2 + (1.875)^2 + \dots] \approx 4.98.$$

95% 置信区间： $\hat{\tau} \pm 1.96\sqrt{\hat{V}} = 1.125 \pm 1.96 \times 2.23 = [-3.25, 5.50]$ 。

对于协变量调整估计量, 我们需要计算 $\hat{\gamma}$ 和 $\hat{\tau}_{\text{adj}}$ 。³

13. 附录: 关键公式推导

13.1. 定理 ?? 的完整证明. 我们需要证明在强 ignorability 条件下,

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = \Pr\{Z = 1 \mid e(X)\}.$$

首先, 由条件概率的定义和 tower property,

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{Z \mid Y(1), Y(0), e(X)\}.$$

对上式应用 tower property (先关于 X 条件化, 再关于 $Y(1), Y(0), e(X)$ 条件化):

$$E\{Z \mid Y(1), Y(0), e(X)\} = E[E\{Z \mid Y(1), Y(0), X\} \mid Y(1), Y(0), e(X)].$$

由强 ignorability 假设 $Z \perp \{Y(1), Y(0)\} \mid X$, 有

$$E\{Z \mid Y(1), Y(0), X\} = E\{Z \mid X\} = e(X).$$

因此,

$$E\{Z \mid Y(1), Y(0), e(X)\} = E\{e(X) \mid Y(1), Y(0), e(X)\} = e(X).$$

另一方面,

$$\Pr\{Z = 1 \mid e(X)\} = E\{Z \mid e(X)\} = E[E\{Z \mid X\} \mid e(X)] = E\{e(X) \mid e(X)\} = e(X).$$

两端相等, 定理证毕。

13.2. NHANES 数据分析的 R 代码. 以下是本章数据分析使用的 R 代码示例:

```
# 读取数据
nhanes_bmi = read.csv("nhanes_bmi.csv")[, -1]
z = nhanes_bmi$Schoolmeal
y = nhanes_bmi$BMI
x = as.matrix(nhanes_bmi[, -c(1, 2)])
x = scale(x) # 标准化协变量

# 估计倾向得分
pscore = glm(z ~ x, family = binomial)$fitted.values

# 倾向得分分层
n.strata = c(5, 10, 20, 50, 80)
strat.res = sapply(n.strata, FUN = function(nn) {
  q.pscore = quantile(pscore, (1:(nn-1)) / nn)
  ps.strata = cut(pscore, breaks = c(0, q.pscore, 1),
                  labels = 1:nn)
  Neyman_SRE(z, y, ps.strata)
})

rownames(strat.res) = c("est", "se")
colnames(strat.res) = n.strata
```

³详细计算留作习题。

`round(strat.res, 3)`

其中 `Neyman_SRE` 函数定义于第 ?? 章，用于计算 SRE 框架下的 Neyman 估计量及其标准误。

14. 附录：定理 29.1 的证明

定理 ?? 证明。 由塔性质，

$$E\{Y(z_1, z_2)\} = E[E\{Y(z_1, z_2) \mid X_0\}]$$

因此我们聚焦于 $E\{Y(z_1, z_2) \mid X_0\}$ 。由 Assumption ??(1) 和塔性质，

$$\begin{aligned} E\{Y(z_1, z_2) \mid X_0\} &= E\{Y(z_1, z_2) \mid z_1, X_0\} \\ &= E[E\{Y(z_1, z_2) \mid z_1, X_1, X_0\} \mid z_1, X_0] \end{aligned}$$

由 Assumption ??(2)，

$$\begin{aligned} E\{Y(z_1, z_2) \mid X_0\} &= E[E\{Y \mid z_2, z_1, X_1, X_0\} \mid z_1, X_0] \\ &= E\{E(Y \mid z_2, z_1, X_1, X_0) \mid z_1, X_0\} \end{aligned}$$

取期望即得 ??。□

APPENDIX A

问答与注解

1. 阅读过程中的问题与解答

1.1. 亚组的定义. 问: 什么是亚组?

答: 亚组 (subgroup) 是由某个协变量 (通常是二元变量 X_i) 分割出来的子群体。例如按性别、年龄、收入等分割。亚组因果效应衡量的是在该亚组内的平均因果效应。

1.2. 恒等式 $\tau = \pi_1\tau_1 + \pi_0\tau_0$ 的推导. 问: 如何推导 $\tau = \pi_1\tau_1 + \pi_0\tau_0$?

答: 利用指示函数的完备性 $\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$, 将总体求和拆分为两个亚组求和, 再除以对应的亚组样本量即可得到。

1.3. 为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的?. 问: 为什么在 Fisher's sharp null ($H_{0F} : Y_i(1) = Y_i(0)$) 下, 潜在结果向量 $\mathbf{Y}$ 是固定的?

答: H_{0F} 断言 treatment 对每个单元都没有效应, 即 $Y_i(1) = Y_i(0) = Y_i$ 对所有 i 。这意味着整个 $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y}$ 向量是确定的 (固定值), 不再有随机性。

在 FRT 中, 我们 condition on 这个固定的 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。因此, 随机化分布可以精确枚举 ($M = \binom{n}{n_1}$ 种可能), 不依赖任何渐近假设——这就是 FRT “有限样本精确” 的本质。

1.4. p_{frt} 的 Monte Carlo 近似与修正. 问: 为什么 ?? 需要修正为 $\tilde{p}_{\text{frt}}$?

答:

原始 Monte Carlo 近似:

$$\hat{p}_{\text{frt}} = \frac{1}{R} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$$

这个估计量的问题是: 当 R 有限时, 它可能是**反保守的**——低估真实的 p 值, 导致错误地宣称显著。

修正公式 (有限样本有效):

$$\tilde{p}_{\text{frt}} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

修正的本质是”自我包含”: 分子加 1 相当于把”观测到的这一次”也算作一次置换结果。

为什么需要修正:

当 $R = 99$ 次置换中, 只有 0 次超过观测值时:

$$\hat{p}_{\text{frt}} = \frac{0}{99} = 0$$

这就错了! 因为观测到的这一次 (自身) 必然是 M 种可能之一, p 值至少应该是 $1/M$, 而不是 0。

加了 1 在分子和分母：

$$\tilde{p}_{f_{rt}} = \frac{1}{100}$$

这保证了：

- (1) p 值不会为 0 (分子至少是 1)
- (2) 在任何有限的 R 下都满足有限样本有效性： $\mathbb{P}(p \leq u) \leq u$
- (3) 当 $R \rightarrow \infty$ 时， $\tilde{p}_{f_{rt}} \rightarrow \hat{p}_{f_{rt}}$

1.5. 为什么叫“有限样本精确”？ 问：FRT 的 p 值为什么被称为“有限样本精确”？

答：关键在于 ?? 给出的不等式：

$$\mathbb{P}(p_{f_{rt}} \leq u) \leq u \quad \text{for all } u \in [0, 1]$$

这叫做**有限样本有效性** (finite-sample validity)。意思是：无论样本量多小、数据分布如何， $p_{f_{rt}}$ 的分布永远不会偏离均匀分布太多。

对比传统 t 检验：它需要大样本下才近似有效 (渐近性质)，小样本时可能失效。FRT 的精确性只依赖于随机化机制，不依赖于任何渐近假设。

1.6. Fisher 方法 vs 传统方法. 问：Fisher 的思路和传统统计推断有什么本质区别？

答：

- **传统方法问**：“数据有多极端？”——依赖数据分布假设
- **Fisher 方法问**：“如果随机化，会产生多极端的数据？”——只依赖随机化机制

Fisher 方法的哲学：在 sharp null (无因果效应) 假设下，潜在结果完全已知。观察到的差异完全来自随机分配。我们可以枚举所有可能的置换，计算每个置换产生的统计量。传统方法则依赖于数据的原始分布假设 (如正态性)，而 FRT 给经典 t 检验提供了理论 justify——不需要正态性假设。

1.7. 经典 t 检验之前没有理论基础吗？ 问：经典 t 检验之前没有理论 justify 吗？一定要 FRT 给出吗？

答：经典 t 检验有理论基础，但 FRT 提供了**更坚实**的理论基础。

经典 t 检验的理论基础：

- **正态性假设下** (Fisher 原始推导)：如果 $Y_i \sim \text{i.i.d. } \mathcal{N}(\mu, \sigma^2)$ ，则 t 统计量精确服从 t 分布
- **渐近理论** (后来发展)：大样本下，CLT 保证 t 统计量近似正态分布——即使数据不正态

FRT 的新贡献：FRT 并不是说经典 t 检验“没有理论依据”，而是提供了**另一种理论框架**：

- 经典方法：关注“**数据的分布**” (假设数据来自正态分布)
- FRT：关注“**随机化的机制**” (治疗是如何分配的)

关键区别：在随机实验中，我们**知道**治疗是如何分配的 (CRE)，所以可以基于随机化机制来计算 p 值——这比假设“数据来自正态分布”更可靠。

准确的说法：FRT 为经典 t 检验在随机实验中的应用提供了**更直接、更不依赖分布假设**的理论基础。

1.8. 经典 t 检验需要正态性假设吗？问：经典 t 检验需要正态性假设吗？为什么 FRT 说“不需要”？

答：经典 t 检验有两种情况：

- **精确版本：**如果数据来自正态分布的总体，t 统计量的精确抽样分布是 t 分布
- **渐近版本：**在大样本下，即使数据不正态，CLT 保证 t 统计量近似正态分布

FRT 的贡献：它证明了在随机实验 + sharp null 下，t 统计量的**随机化分布**可以直接计算（精确或 Monte Carlo 近似），不依赖任何分布假设。

关键区别：

- 传统方法问：“如果数据来自正态分布，观察到的差异有多极端？”
- FRT 问：“如果 treatment 是随机分配的，观察到这种差异的概率有多大？”

FRT 的理论基础是有限总体 CLT，它保证**随机化分布**收敛到正态，而不是数据本身正态。因此在大样本下，即使数据不正态，FRT 给出的 p 值也是有效的。

总结：FRT 并没有说经典 t 检验“不需要”正态性假设，而是说在随机实验框架下，可以用不依赖正态性的方法（FRT）来获得精确的 p 值。

1.9. 什么是潜在结果？问：在 Fisher 随机化检验框架下，什么是潜在结果？

答：潜在结果（Potential Outcomes）是每个单元在两种 treatment 状态下的可能结果：

- $Y_i(1)$ ：单元 i 如果接受 treatment 的结果
- $Y_i(0)$ ：单元 i 如果接受 control 的结果

关键洞察：每个单元只能实际接受一种 treatment，因此我们只能观测到其中一个潜在结果，另一个是“反事实”（counterfactual）——它从未发生，无法被观测。

观测结果与潜在结果的关系：

$$Y_i^{obs} = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$$

即：如果 $Z_i = 1$ （接受 treatment），我们观测到 $Y_i(1)$ ；如果 $Z_i = 0$ ，我们观测到 $Y_i(0)$ 。

因果推断的根本问题：我们想估计 $Y_i(1) - Y_i(0)$ （单元 i 的因果效应），但只能观测到其中一个值。

1.10. 随机化的两个原则是什么？问：Fisher 随机化的两个原则——可比性和推理基础——是什么意思？

原则一：可比性（Comparability）。随机化保证了 treatment 组和 control 组在平均意义上是可比的。如果没有随机化，治疗分配可能受到选择偏差（selection bias）的影响。例如，如果病人自己选择是否接受治疗，那么接受治疗的群体可能本身就比对照组更健康。随机化通过强制分配机制打破了这种联系，使得两组在所有可观测和不可观测的特质上趋于平衡。

原则二：推理基础（Inference Basis）。随机化提供了推断因果效应的理论基础。在没有随机化的情况下，我们无法区分“因果效应”和“选择偏差”。但在随机实验中，我们知道治疗分配是如何进行的（randomization mechanism），因此可以基于这个已知的分配机制来计算 p 值。具体而言：

- (1) 假设 H_{0F} ：treatment 对每个人都无效 ($Y_i(1) = Y_i(0)$)
- (2) 在这个假设下，治疗分配是唯一的随机来源
- (3) 枚举所有可能的随机分配（或者 Monte Carlo 近似）
- (4) 计算在每种分配下，检验统计量有多极端

总结：可比性解决“选择偏差”——确保组间可比较。推理基础解决“随机变异”——知道观察到的差异有多极端。两者结合，使得因果推断成为可能。

1.11. 什么是 Fisher Randomization Test ?. 问：什么是 Fisher Randomization Test (Fisher 随机化检验)？

答：Fisher Randomization Test (FRT) 是 Ronald Fisher 在 1935 年《Design of Experiments》中提出的统计检验框架。它的核心创新是：不再依赖数据分布假设（如正态性），而是仅依赖随机化机制本身。

核心思想：

- (1) 在 **sharp null** 假设 $H_{0F} : Y_i(1) = Y_i(0)$ （所有单元的治疗效应都为零）下，潜在结果向量 $\mathbf{Y}$ 是完全确定的（固定的）
- (2) 唯一的随机来源是治疗分配机制 $\mathbf{Z}$
- (3) 在完全随机实验（CRE）中， $\mathbf{Z}$ 的分布是已知的（均匀分布于所有 $\binom{n}{n_1}$ 种可能的分配）
- (4) 因此，我们可以枚举所有可能的治疗分配，计算在每种分配下检验统计量的取值
- (5) p 值就是在所有可能分配中，观察到的统计量至少与实际观测值一样极端的比例

★ **Insight:** FRT 的本质是“条件推断”——我们 condition on 固定的潜在结果 $\mathbf{Y}$ ，只让治疗分配 $\mathbf{Z}$ 有随机性。这与经典统计推断不同：经典方法 condition on 数据，假设数据的分布已知；FRT 则 condition on 潜在结果，利用随机化机制计算精确的 p 值。

为什么叫“随机化检验”？ 因为它完全基于随机化机制——不假设任何参数分布，不依赖正态性假设，只依赖“治疗是如何随机分配的”这一事实。这使得 FRT 在随机实验中具有“有限样本精确性”（finite-sample exactness）。

1.12. $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义. 问：在 CRE 中， $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的。这句话是什么意思？

答：

先理解 $\mathbf{Z}$ 是什么。 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 是治疗分配向量，其中 $Z_i = 1$ 表示单元 i 接受治疗， $Z_i = 0$ 表示单元 i 接受对照。

再理解 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 。 这是所有可能的治疗分配构成的集合。例如当 $n = 3, n_1 = 1$ 时，所有可能的分配有：

$$\mathbf{z}^1 = (1, 0, 0), \mathbf{z}^2 = (0, 1, 0), \mathbf{z}^3 = (0, 0, 1)$$

即 $M = \binom{3}{1} = 3$ 种可能。

“均匀分布”的意思。 在 CRE 中，治疗分配是完全随机的。这意味着每一种可能的分配 $\mathbf{z}^m$ 被选中的概率相等：

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}^m) = \frac{1}{M} = \frac{1}{\binom{n}{n_1}}$$

例如当 $n = 100, n_1 = 50$ 时， $M \approx 10^{29}$ 种可能的分配，每一种被选中的概率都完全相同（约 10^{-29} ）。

关键直觉： 在 CRE 下，treatment 组和 control 组的成员身份是随机决定的，而非实验者主观选择。这就是 Fisher 说的“randomization provides a valid basis for inference”——随机化本身保证了推断的有效性。

1.13. 蒙特卡洛公式中的 $\mathbf{Z}$ 是什么 ?. 问：蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思？他说是一个均匀分布，但我不知道 $\mathbf{Z}$ 是什么意思？

答：

为什么需要理解 $\mathbf{Z}$? 在 Fisher 随机化检验中，我们感兴趣的问题是：“如果 treatment 真的是随机分配的，观察到的差异有多极端？”要回答这个问题，我们需要知道“随机分配”是如何进行的——而 $\mathbf{Z}$ 正是描述这种分配机制的核心工具。

$\mathbf{Z}$ 的定义。 在 n 个单元的实验中， $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)$ 是一个长度为 n 的向量，其中：

- $Z_i = 1$: 单元 i 接受 treatment (治疗组)
- $Z_i = 0$: 单元 i 接受 control (对照组)

例如当 $n = 5, n_1 = 2$ 时, 一个可能的分配是 $\mathbf{Z} = (1, 0, 0, 1, 0)$, 表示第 1、4 号单元接受治疗, 第 2、3、5 号单元接受对照。

为什么是“均匀分布”? 在完全随机实验 (CRE) 中, 治疗分配是完全随机的——每个可能的 $\mathbf{Z}$ 被选中的概率相等。这就是“均匀分布”的含义。

具体来说, 所有可能的分配有 $M = \binom{n}{n_1}$ 种, 每种被选中的概率都是 $1/M$ 。例如:

- $n = 3, n_1 = 1$ 时, $M = 3$, 三种可能: $(1, 0, 0)$ 、 $(0, 1, 0)$ 、 $(0, 0, 1)$, 概率各为 $1/3$
- $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$, 每种概率约为 10^{-29}

$\mathbf{z}^r$ 是什么? 在 Monte Carlo 近似中, 我们无法枚举全部 M 种分配。因此我们进行 R 次随机置换, 每次得到一个 $\mathbf{z}^r$ 。每个 $\mathbf{z}^r$ 都是对真实 $\mathbf{Z}$ 的一次模拟。

★ **Insight:** 理解 $\mathbf{Z}$ 的关键是: 它是一个指示函数向量 (indicator vector), 而不是一个普通的数。它告诉我们“谁在接受治疗, 谁在对照”。Monte Carlo 方法通过重复模拟这个随机分配过程, 来近似在所有可能分配下的检验统计量分布。

1.14. 什么是潜在结果 (Potential Outcomes) ? . 问: 什么是因果推断中的“潜在结果” (Potential Outcomes)?

答: 潜在结果 (Potential Outcomes) 是指每个研究单元在 ** 不同处理条件下 ** 可能观测到的所有结果。对于单元 i :

- $Y_i(1)$: 单元 i 接受 treatment 后的结果 (如吃药后的康复情况)
- $Y_i(0)$: 单元 i 接受 control 的结果 (如不服药的情况)

核心问题: 我们只能同时观测到 ** 一个 ** 潜在结果, 另一个是反事实 (counterfactual)。这被称为“因果推断基本问题” (Fundamental Problem of Causal Inference)。

1.15. 第一基本形式的意义. 问: 什么是第一基本形式 (First Fundamental Form)?

答: 第一基本形式是曲面上用来度量弧长、面积以及角度的工具, 本质上是曲面自带的一种“度量结构”——它告诉我们如何在曲面上测量距离和角度。

1.16. 远置信集的构造. 问: 远置信集 (far confidence set) 是如何构造的?

答: 远置信集是通过在参数空间中搜索满足置信水平的最大区域构造的。具体方法是在约束条件下寻找使目标函数最大化的参数点, 从而确定置信范围。

1.17. ITT 的含义. 问: 什么是 ITT (Intent-to-Treat)?

答: ITT 即意向性治疗分析 (Intent-to-Treat), 是一种保守的估计方法, 无论实际是否依从, 都按随机分配的方案进行分析。它估计的是“随机化本身的效应”, 而非实际治疗的因果效应。

1.18. 工具变量的直觉. 问: 工具变量 (Instrumental Variable) 的直觉是什么?

答: 工具变量 Z 满足: (1) 与 treatment 相关; (2) 通过随机分配获得外生性; (3) 只通过 treatment 影响结果, 不能直接影响结果。它的直觉是: 通过随机分配产生的 variation (被称为“准实验 variation”), 可以用来估计 treatment 效应, 即使存在选择偏差。

1.19. 单调性假设是否可检验. 问: 单调性假设 (Monotonicity) 是否可检验?

答: 单调性假设 ($Y_i(1) \geq Y_i(0)$ 对所有人成立) 通常是不可直接检验的, 因为它涉及反事实结果。但在某些特殊情况下 (如二元结果、随机实验), 可以通过辅助假设或分层分析提供间接证据。

1.20. 随机化假设的含义. 问: 随机化假设 (Randomization Assumption) 在工具变量框架下意味着什么?

答: 随机化假设是指工具变量 Z 与潜在结果 $(Y_i(0), Y_i(1))$ 和潜在处理 $(D_i(0), D_i(1))$ 是相互独立的, 即 $Z \perp (Y_i(0), Y_i(1), D_i(0), D_i(1))$ 。这确保了工具变量的外生性, 排除了一切混杂。

1.21. 弱工具变量问题. 问: 什么是弱工具变量问题 (Weak IV Problem)?

答: 弱工具变量是指与 treatment 相关性很弱的工具变量 (F 统计量较小)。使用弱工具变量会导致: 偏差增大、置信区间扩张、有限样本下分布偏离标准分布。需要检查 F 统计量是否超过临界值 (如 Staiger-Stock 规则中的 10)。

1.22. 为什么是局部平均处理效应. 问: 工具变量方法估计的为什么是“局部”平均处理效应 (LATE) 而非总体 ATE?

答: 因为工具变量利用的是“受工具影响的 Compliers”的 variation。在单调性假设下, 只有 Compliers ($D_i(1) > D_i(0)$) 对工具变量的效应有贡献, 而 Defiers 和 Always-takers 被排除。因此估计量只识别了 Compliers 群体的 ATE, 即 LATE。

替代标准误公式的推导. 注: 此解答待补充。详见对应章节练习题。

连续或二元结果下 m 的性质. 注: 此解答待补充。当 Y 为二元变量或连续变量时, 函数 $m(X) = \mathbb{E}[Y|X]$ 的形式与性质讨论。

差商积形式的推导. 注: 此解答待补充。关于差商与乘积关系的推导。

交互效应的可识别性. 注: 此解答待补充。条件可识别性框架下交互效应的识别与估计。

Logit 模型下二元处理变量 m 的推导. 注: 此解答待补充。在 Logit 回归框架下处理二元变量 m 的具体推导过程。

Robins mediation formula 与潜在组. 注: 此解答待补充。Robins 提出的 mediation formula 在潜在组 (latent groups) 框架下的应用。

二元结果下的自然间接效应. 注: 此解答待补充。当结果变量 Y 为二元时, 自然间接效应的定义与估计。

跨世界独立性假设的问题. 注: 此解答待补充。跨世界独立性 (cross-world independence) 假设在 mediation analysis 中的局限性。

Surrogate 准则与 Jr 条件. 注: 此解答待补充。Surrogate 准则 (Sr) 与 Jr 条件的关系与推导。

当你在阅读过程中提出问题时, 回答将被记录在此处。

2. 学习笔记

在这里记录你的学习心得和思考。

Bibliography

- Joshua D. Angrist, Guido W. Imbens, and Donald B. Rubin. Identification of causal effects using instrumental variables. *Journal of the American Statistical Association*, 91(434):444–472, 1996. Cited in Chapter 21.
- Peter J. Bickel, Eugene A. Hammel, and J. William O’Connell. Sex bias in graduate admissions: Data from berkeley. *Science*, 187(4175):398–404, 1975. Cited in Chapter 1.
- Marie-Abele C. Bind and Lea M. Rattay. When possible, report a fisher-exact p -value and display its underlying null randomization distribution. *Journal of the American Statistical Association*, 115(532):1644–1646, 2020. Cited in Chapter 3.
- George E. P. Box, J. Stuart Hunter, and William G. Hunter. *Statistics for Experimenters: An Introduction to Experimental Design*. John Wiley & Sons, 1978. Cited in Chapter 5.
- Peng Ding. A paradox from randomization-based causal inference. *Statistical Science*, 32(3):331–345, 2017. Cited in Chapter 4.
- Peng Ding and Tyler J. VanderWeele. Sensitivity analysis without assumptions. *Epidemiology*, 27(3):368–377, 2016. Cited in Chapters 17, 18.
- Herman F. Dorn. The planner’s dilemma. *Journal of the American Statistical Association*, 48(264):601–604, 1953. Cited in Chapters 18, 21.
- Ronald A. Fisher. The design of experiments. *Statistical Research Memoirs*, 1:1–26, 1935. Cited in Chapter 3.
- J. L. Hodges and E. L. Lehmann. Rank methods for combination of independent experiments in analysis of variance. *The Annals of Mathematical Statistics*, 33(2):482–497, 1962. Cited in Chapter 5.
- Paul W. Holland. Statistics and causal inference. *Journal of the American Statistical Association*, 81(396):945–960, 1986. Cited in Chapters 1, 2, 3.
- Guido W. Imbens. Sensitivity to exogeneity assumptions in program evaluation. *American Economic Review*, 93(2):126–132, 2003. Cited in Chapter 18.
- Guido W. Imbens and Joshua D. Angrist. Identification and estimation of local average treatment effects. *Econometrica*, 62(2):467–475, 1994. Cited in Chapter 21.
- Guido W. Imbens and Donald B. Rubin. *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press, 2015. Cited in Chapters 4, 5.
- Gary King and Langche Zeng. The dangers of extreme counterfactuals. *Political Analysis*, 14(2):131–159, 2006. Cited in Chapter 20.
- Winston Lin. Agnostic notes on regression adjustments to experimental data: Reexamining freedman’s critique. *The Annals of Applied Statistics*, 7(1):295–318, 2013. Cited in Chapter 3.
- Bo Lu and Peng Ding. Sensitivity analysis for causal inference: Theory and applications. *Unpublished manuscript*, 2023. Cited in Chapter 18.

- Charles F. Manski. Nonparametric bounds on treatment effects. *American Economic Review*, 80(2):319–323, 1990. Cited in Chapter 18.
- Charles F. Manski. *Monitoring the dissolving of the Soviet Union*, volume 21. 2003. Cited in Chapter 18.
- Jerzy Neyman. Sur les applications de la théorie des probabilités aux expériences agricoles: Essai d’application de la méthode “chia”. *Roczniki Nauk Rolniczych*, 10:1–51, 1923. Cited in Chapters 2, 4.
- Judea Pearl. On the consistency rule in causal inference. *Biometrika*, 97(2):490–492, 2010. Cited in Chapter 2.
- Judea Pearl and Dana Mackenzie. *The Book of Why: The New Science of Cause and Effect*. Basic Books, 2018. Cited in Chapter 1.
- Paul R. Rosenbaum and Donald B. Rubin. Assessing sensitivity to an unobserved binary covariate in an observational study with binary outcome. *Journal of the Royal Statistical Society: Series B*, 45(2):212–218, 1983. Cited in Chapters 17, 18, 19.
- Donald B. Rubin. Comment: Bayesian inference for causal effects: The role of randomization. *The Annals of Statistics*, 8(1):44–45, 1980. Cited in Chapter 3.
- Donald B. Rubin. Causal inference using potential outcomes: Design, modeling, decisions. *Journal of the American Statistical Association*, 100(469):322–331, 2005. Cited in Chapter 2.
- Donald B. Rubin. For objective causal inference, design trumps analysis. *The Annals of Applied Statistics*, 2(3):808–840, 2008. Cited in Chapter 20.
- P. H. Van Elteren. On the combination of independent statistical tests. *Statistica Neerlandica*, 14(1):11–24, 1960. Cited in Chapter 5.
- Tyler J. VanderWeele and Peng Ding. Introducing the e-value. *Annals of Internal Medicine*, 167(4):285, 2017. Cited in Chapters 17, 18.