

$y T w \ f l$

$S 2 M ; . B M ;$

3.1. ACE 的匹配估计量. 采用 $1-M$ 匹配 (带放回)。对治疗单元 i , 将潜在结果 $Y_i(1)$ 估计为观测值 Y_i ,

$$\hat{Y}_i(1) = Y_i.$$

将潜在结果 $Y_i(0)$ 估计为匹配对照单元结果的均值:

$$\hat{Y}_i(0) = M^{-1} \sum_{j=1}^M Y_{m_j(i)},$$

其中 $m_j(i)$ 是第 j 个匹配单元。

匹配估计量为:

$$\hat{\tau}^m = n^{-1} \sum_{i=1}^n Z_i \{\hat{Y}_i(1) - \hat{Y}_i(0)\} + n^{-1} \sum_{i=1}^n (1 - Z_i) \{\hat{Y}_i(0) - \hat{Y}_i(1)\}.$$

为简化记号, 定义 $J(i)$ 为匹配给单元 i 的单元集合, $K_i = |J(i) \cap \{j : Z_j = 1\}|$ 为匹配中治疗单元的个数。

命题 C.1 (匹配估计量的偏差). 在 M 固定的情况下, 当 $n \rightarrow \infty$ 时,

$$\sqrt{n}(\hat{\tau}^m - \tau) \Rightarrow \mathcal{N}\{0, V^m(\tau)\},$$

其中偏差来自不精确匹配。²

3.2. 偏差校正. ? 指出, 简单 bootstrap 不能用于匹配估计量的方差估计。他们提出的方差估计程序不易实现。? 提出了基于线性展开的 bootstrap, 本质上等价于以下简单方差估计量 $\hat{V}^{\text{mbc}}$ 。

偏差校正后的匹配估计量:

$$\hat{\tau}^{\text{mbc}} = \hat{\tau}^m + n^{-1} \sum_{i=1}^n \hat{\psi}_i,$$

其中 $\hat{\psi}_i$ 是偏差校正项。³

通过将 $\hat{\tau}^{\text{mbc}}$ 视为 $\hat{\psi}_i$ 的样本均值, ? 首先证明简单 bootstrap 对匹配估计量不适用。? 的 bootstrap 本质上等价于简单的 $\hat{V}^{\text{mbc}}$, 计算简便。

4. 匹配的双稳健形式

偏差校正匹配估计量与双稳健估计量有着密切联系。两者都等于结果回归估计量加上基于残差的修正。

命题 C.2 (ACE 偏差校正匹配估计量的双稳健形式). 偏差校正匹配估计量满足

$$\hat{\tau}^{\text{mbc}} = \hat{\tau}^{\text{DR}},$$

其中 $\hat{\tau}^{\text{DR}}$ 是第 E 章定义的双稳健估计量。⁴

²完整方差推导见附录 ??

³推导见附录 ??

⁴证明见附录 ??

定义 C.2 揭示了一个深刻联系：匹配本质上是估计倾向得分的非参数方法，而 $1 + K_i/M$ 可以视为 $1/\hat{e}(X_i)$ 的估计。

当治疗单元的 $e(X_i)$ 很小时， $1/\hat{e}(X_i)$ 很大，同时该单元会匹配到很多对照单元，导致 K_i 很大，因此 $1 + K_i/M$ 也很大。这个联系也引发了一个关于匹配的问题：**固定 M 下， $1 + K_i/M$ 对 $1/e(X_i)$ 的估计可能非常嘈杂。**让 M 随样本量增长可能会改善基于匹配倾向得分估计的渐近性质。⁵ 提供了严格理论：当 M 以适当速率增长时，偏差校正匹配估计量可以达到与双稳健估计量相似的性质。

5. ATT 的匹配估计量

实践中，我们经常关心的是**处理组平均因果效应 (ATT)**：

$$\tau_T = \mathbb{E}\{Y_i(1) - Y_i(0) \mid Z_i = 1\}.$$

ATT 的匹配估计量为：

$$\hat{\tau}_T^m = n_1^{-1} \sum_{i:Z_i=1} \{\hat{Y}_i(1) - \hat{Y}_i(0)\},$$

其中 $\hat{Y}_i(1) = Y_i$ 而 $\hat{Y}_i(0) = M^{-1} \sum_{j=1}^M Y_{m_j(i)}$ 。

类似地，偏差校正版本为：

$$\hat{\tau}_T^{\text{mbc}} = \hat{\tau}_T^m + n_1^{-1} \sum_{i:Z_i=1} \hat{\psi}_i^T.$$

命题 C.3 (ATT 偏差校正匹配估计量的双稳健形式). *ATT 的偏差校正匹配估计量满足*

$$\hat{\tau}_T^{\text{mbc}} = \hat{\tau}_T^{\text{DR}},$$

其中 $\hat{\tau}_T^{\text{DR}}$ 是 *ATT* 的双稳健估计量。⁵

定义 C.3 表明：匹配本质上使用 K_i/M 来估计给定协变量条件下治疗的优势比。

6. 实践中的问题

6.1. 一对一还是一对多？ 我们既可以采用一对一匹配，也可以采用一对 M 匹配。当 M 增加时，偏差减小但方差增大。实践中需要权衡。

6.2. 放回还是不放回？ 放回匹配计算更方便，但会引入依赖（同一单元被多次使用）。不放回匹配的计算更复杂，但保证了匹配单元的独立性。当对照组池较大时，两种方法结果差异不大。

6.3. 协变量平衡检验。 匹配后应检验协变量平衡。使用简单 OLS 检查匹配前后协变量的系数显著性。**匹配前**，协变量通常高度不平衡（系数显著）；**匹配后**，协变量应该达到良好平衡（系数不显著）。

⁵证明见附录 ??

7. 实例：LaLonde 数据

？研究工作培训项目对收入的影响。他比较了随机实验结果与观测性研究结果。

实验部分给出 ATT 估计为 \$1794 (标准误 \$623)。⁶

使用？的 Matching 包进行 1-1 匹配分析。匹配后，ATT 估计为 \$1658，与实验结果的 \$1794 非常接近。这说明当匹配质量好时，匹配估计量能够很好地近似实验金标准。

8. 本章小结

本章介绍了观测性研究中的匹配估计量，主要内容如下：

- (a) **匹配的动机**：通过人为配对，使观测性研究模拟随机实验的性质——这比直接假设条件独立性更直观。
- (b) **基本思想 (section 2)**：对每个治疗单元，在对照组中找到协变量相似的单元进行匹配。精确匹配使治疗分配机制与匹配对实验相同。
- (c) **AI 理论 (section 3)**：??? 建立了匹配估计量的渐近理论，包括偏差校正和方差估计。
- (d) **双稳健连接 (section 4)**：偏差校正匹配估计量本质上是另一种形式的双稳健估计量。
- (e) **ATT 估计 (section 5)**：匹配同样适用于 ATT 的估计，且具有类似的双稳健性质。
- (f) **实践要点 (section 6)**：协变量平衡检验是确保匹配质量的关键步骤。

9. 习题

练习 C.1. 匹配与倾向得分 证明：在精确匹配下，倾向得分对所有配对单元相同，即 $e(X_i) = e(X_{m(i)})$ 。这如何支持“精确匹配模拟随机实验”的论断？

练习 C.2. 一对一与一对多匹配的偏差比较 考虑 1-1 匹配和 1-M 匹配。当 M 增大时，匹配估计量的偏差如何变化？为什么？

练习 C.3. 匹配估计量的偏差校正项 从 section 3.2 出发，推导偏差校正项 $\hat{\psi}_i$ 的具体形式。提示：参考？的推导。

练习 C.4. ATT 匹配估计量的性质 证明 定义 C.3: ATT 的偏差校正匹配估计量等于 ATT 的双稳健估计量。

练习 C.5. 协变量平衡 对 LaLonde 数据进行匹配分析，检验匹配前后协变量的平衡性。使用不同的 M 值（一对一、一对二、一对四）比较结果。

练习 C.6. 匹配与回归的比较 使用第 C 章 ?? 节的数据，分别用匹配估计量和结果回归估计量估计 ATT。比较两种方法的结果和效率。

练习 C.7. 倾向得分匹配的理论性质？提供了基于倾向得分匹配的理论。阅读该论文，总结其主要结论及其与？建议的关联。

练习 C.8. 高维协变量的挑战 当协变量维度很高时，直接匹配面临维数灾难。讨论三种可能的解决策略：降维、惩罚回归、机器学习方法。

⁶详见第 C 章 2.1 节

观测性研究中不可混淆性假设的困难

1. 引言：当我们无法控制所有混杂因素时

“*Although we cannot see the wind, we can see its effects on the leaves.*” — 统计学家对隐性混杂的隐喻

在第 C 至 C 章中，我们详细讨论了观测性研究中因果效应的识别与估计方法。这些方法的核心假设是**不可混淆性 (unconfoundedness)**：

$$(16.1) \quad Z \perp \{Y(1), Y(0)\} \mid X.$$

也就是说，在给定协变量 X 的条件下，治疗分配 Z 与潜在结果相互独立。

然而，这个假设在实践中有多可靠？

正如 George Box 所言：“所有模型都是错的，但有些有用。”不可混淆性假设本质上是一个关于数据生成过程的陈述——它声称我们已经控制了所有影响治疗分配和结果的混杂变量。但在真实的观测性研究中，我们真的能确保这一点吗？

问题的根源：协变量 X 永远只是我们观测到的协变量的一个子集。是否存在我们未能观测到的混杂因素 U ？如果存在，那么不可混淆性假设就不成立，我们基于此假设得到的因果效应估计量可能是有偏的。

本章将系统性地探讨这一困难：

- 首先，引入**因果图 (causal diagram)**作为可视化因果关系的工具；
- 其次，讨论**评估不可混淆性假设的策略**——我们无法直接检验它，但可以进行辅助分析；
- 最后，分析**过度调整 (over-adjustment)**的风险——调整错误的协变量反而可能引入新的偏倚。

2. 因果图的基本概念

2.1. 从因果图到数据生成过程。 Pearl (1995) 引入了因果图作为经验研究中因果推理的有力工具。因果图的美妙之处在于：它能够将变量之间的因果关系以图示形式直观地表达出来，而我们可以直接从图中读出统计学含义。

考虑一个最简单的因果图结构：

$$X \rightarrow Z \rightarrow Y$$

其中 X 是协变量， Z 是治疗， Y 是结果。这个图的含义是： X 影响 Z ，而 Z 影响 Y 。从数学上讲，这对应于以下数据生成过程：

$$(16.2) \quad \begin{cases} X \sim F_X(x), \\ Z = f_Z(X, \varepsilon_Z), \\ Y(z) = f_Y(X, z, \varepsilon_Y(z)), \end{cases} \quad ??$$

其中 $\varepsilon_Z \perp \varepsilon_Y(z)$ (两组误差独立)。从这个方程组中，我们可以直接读出 $Z \perp Y(z) \mid X$ ，即不可混淆性假设成立。

现在考虑一个更复杂的情形——存在一个未观测的混杂因素 U ：

$$U \rightarrow Z, U \rightarrow Y, X \rightarrow Z, X \rightarrow Y$$

这个图对应的数据生成过程是：

$$(16.3) \quad \begin{cases} X \sim F_X(x), \\ U \sim F_U(u), \\ Z = f_Z(X, U, \varepsilon_Z), \\ Y(z) = f_Y(X, U, z, \varepsilon_Y(z)), \end{cases} \quad ??$$

其中 $\varepsilon_Z \perp \varepsilon_Y(z)$ 。从方程组中我们可以读出： $Z \perp Y(z) \mid (X, U)$ 成立，但 $Z \not\perp Y(z) \mid X$ ——不可混淆性在给定 (X, U) 时成立，但仅给定 X 时不成立。在这个情形中， U 被称为**未测混杂因素 (unmeasured confounder)**。

因果图的美学价值在于：它将不可测试的假设转化为直观的图形结构。当图中存在从 Z 到 Y 的后门路径 (backdoor path) 时，就意味着存在未被阻断的混杂。

3. 评估不可混淆性假设

3.1. 基本困难：假设本身不可检验。 回到不可混淆性假设：

$$(16.4) \quad Z \perp Y(1) \mid X, \quad Z \perp Y(0) \mid X.??$$

这个假设意味着：

$$(16.5) \quad \begin{aligned} \{Y(1) \mid Z = 1, X\} &= \{Y(1) \mid Z = 0, X\}, \\ \{Y(0) \mid Z = 1, X\} &= \{Y(0) \mid Z = 0, X\}. \end{aligned}$$

也就是说，在给定 X 的条件下，治疗组和对照组的潜在结果分布相同。但问题在于：潜在结果分布 $\{Y(1) \mid Z = 0, X\}$ 和 $\{Y(0) \mid Z = 1, X\}$ 是反事实的，我们永远无法直接从数据中观测到它们。

因此，**不可混淆性假设从根本上是不可直接检验的**——我们无法用统计检验来验证它是否成立。这并不意味着我们应该放弃因果推断，而是需要采用其他策略来评估这个假设的合理性。

统计学家区分了两个概念：**评估 (assess)** 和**检验 (test)**。前者是指补充性分析，用于支持或削弱初始分析的可信度；后者是正式的统计检验。我们无法检验不可混淆性，但可以评估它。

下面介绍两种主要的评估策略。

3.2. 策略一：利用阴性结果。核心思想：如果我们相信 $Z \perp Y(z) \mid X$ ，那么我们也倾向于相信 $Z \perp Y^n(z) \mid X$ ，其中 Y^n 是一个与 Y 具有相似混杂结构的**阴性结果 (negative outcome)**。关键在于，我们事先知道 Z 对 Y^n 的因果效应。

形式化地，假设 Y^n 满足：

$$(16.6) \quad \tau(Z \rightarrow Y^n) = \mathbb{E}\{Y^n(1) - Y^n(0)\} \text{ 是已知的.??}$$

一个特别重要的情形是 $\tau(Z \rightarrow Y^n) = 0$ ——即我们事先知道治疗对阴性结果没有因果效应。

如果不可混淆性假设成立，那么数据应该显示 Z 对 Y^n 没有处理效应（或者有已知大小的效应）。如果数据显示出显著的效应，这可能暗示不可混淆性假设被违反。

例 D.1 (Cornfield 等 (1959): 吸烟与肺癌). *Cornfield 等 (1959)* 研究了吸烟对肺癌的因果效应。他们在分析中控制了众多重要的背景变量, 但仍可能存在某些未测混杂因素使观察到的效应产生偏倚。

为了加强因果关系的证据, 他们同时报告了吸烟对车祸的影响——基于生物学知识, 吸烟对车祸应该没有因果效应。结果显示关联接近于零。因此, 即使无法完全排除未测混杂, 这个基于阴性结果的补充分析使吸烟对肺癌因果效应的证据更加有力。

例 D.2 (Jackson 等 (2006): 流感疫苗接种). *Jackson 等 (2006)* 对观测性研究的结果持怀疑态度。这些研究显示, 在调整了测量的协变量后, 流感疫苗接种显著降低了流感季节的肺炎/流感住院率和全因死亡率。

他们的补充分析考察了流感季节开始之前的结局指标。疫苗接种通常在秋季开始, 但流感传播在冬季之前是极少的。基于生物学, 疫苗效应在流感季节应该最为显著。但 *Jackson 等* 发现, 疫苗效应在流感季节之前反而更大——这暗示观察到的效应可能源于未测混杂。

阴性结果分析的力量来自于: 如果治疗 Z 通过未测混杂 U 影响结果 Y , 那么 Z 通常也会通过同样的 U 影响与 Y 有相似混杂结构的变量。因此, 如果我们在阴性结果上观察到了预期的零效应 (或已知大小的效应), 这支持了不可混淆性假设的合理性。

等 (2010) 是阴性结果方法的系统性研究。Rosenbaum (1989) 讨论了已知因果效应在因果推断中的作用。

3.3. 策略二: 利用阴性暴露. 阴性暴露是阴性结果的对偶概念。假设 Z^n 是一个与 Z 有相似混杂结构的治疗变量, 且我们事先知道 Z^n 对 Y 的因果效应:

$$(16.7) \quad \tau(Z^n \rightarrow Y) = \mathbb{E}\{Y(1^n) - Y(0^n)\} \text{ 是已知的.??}$$

例 D.3 (Sanderson 等 (2017): 母体暴露与后代结局). *Sanderson 等 (2017)* 给出了利用阴性暴露的多个例子。他们建议比较母体暴露与后代结局的关联, 以及父亲暴露与同样结局的关联。

在母体吸烟与后代结局的研究中: 母体吸烟可能受到未测混杂 (如社会经济地位) 的影响, 而父亲吸烟不太可能受到同样的混杂影响 (因为父亲不经历怀孕)。因此, 如果观察到的母体吸烟效应远大于父亲吸烟效应, 这支持了因果解释; 如果两者效应相似, 则暗示可能存在混杂。

阴性暴露分析的逻辑: 如果不可混淆性成立, 那么 Z 和 Z^n 应该表现出与 Y 相似 (但已知) 的关联模式。如果它们的行为不一致, 则暗示存在未被控制的混杂。

3.4. 小结. 不可混淆性假设在本质上是不可直接检验的。虽然阴性结果和阴性暴露分析无法证明或推翻不可混淆性, 但将它们作为补充性分析可以加强或削弱因果推断的证据基础。

然而, 进行这类补充性分析通常并非易事: 它需要更多的数据, 更重要的是需要对因果问题的深入理解, 以找到令人信服的阴性结果和阴性暴露。在实践中, 找到一个与主结果有相同混杂结构但有已知效应的阴性结果/暴露, 往往需要领域知识的支持。

4. 过度调整的问题

在第 C 章的协变量平衡检验中，我们已经看到：调整正确的协变量可以消除混杂偏倚。但**调整错误的协变量会如何？**

Rosenbaum (2002b) 写道：“没有理由避免调整描述研究对象治疗前特征的变量。”类似地，Rubin (2007) 写道：“通常，条件性越强的假设，越容易接受。”两者都主张应该控制所有观测到的治疗前协变量。

Pearl 不同意这个建议，并给出了两个著名的反例。下面我们详细介绍这两个反例。

4.1. M-偏倚. M-偏倚 (M-bias) 出现在具有 M 结构的因果图中。考虑以下图形：

$$U_1 \rightarrow X \leftarrow U_2, U_1 \rightarrow Z, U_2 \rightarrow Y$$

这个图之所以被称为 M 结构，是因为在因果图中它形似字母 M。从图中我们可以读出数据生成过程：

$$(16.8) \quad \begin{cases} U_1 \perp U_2, \\ X = f_X(U_1, U_2, \varepsilon_X), \\ Z = f_Z(U_1, \varepsilon_Z), \\ Y = Y(z) = f_Y(U_2, \varepsilon_Y), \end{cases} \quad ??$$

其中 $(\varepsilon_X, \varepsilon_Z, \varepsilon_Y)$ 是独立的随机误差。在这个因果图中， X 是观测到的，但 U_1 和 U_2 是未观测到的。如果改变 Z 的值， Y 的值完全不会改变——因为 Z 到 Y 之间没有因果路径。因此， Z 对 Y 的真实因果效应必然为零。

从数学上看：在这个数据生成过程中， $Z \perp Y$ 成立，因此 Z 和 Y 之间的简单关联为零。不调整 X 的简单估计量是无偏的：

$$(16.9) \quad \tau_{\text{PF}} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0) = 0.??$$

但是，如果我们调整 X （即条件于 X ），情况就不同了。调整后， U_1 和 U_2 不再条件独立： $U_1 \not\perp U_2 \mid X$ ，进而 $Z \not\perp Y \mid X$ ，导致调整后的估计量有偏：

$$(16.10) \quad \int \{\mathbb{E}(Y \mid Z = 1, X = x) - \mathbb{E}(Y \mid Z = 0, X = x)\} f(x) dx \neq 0.??$$

直觉解释： X 同时受到 U_1 和 U_2 的影响，而 U_1 影响 Z ， U_2 影响 Y 。当我们条件于 X 时，我们实际上是在 X 的各个取值上比较 Z 和 Y 。但 X 的条件化会人为地在 U_1 和 U_2 之间建立关联——这创造了一条从 Z 到 Y 的虚假后门路径。

为了更直观地理解，我们考虑一个正态线性模型的具体例子（详细推导见习题 D.2）：

$$(16.11) \quad \begin{cases} X = aU_1 + bU_2 + \varepsilon_X, \\ Z = cU_1 + \varepsilon_Z, \\ Y = dU_2 + \varepsilon_Y, \end{cases} \quad ??$$

其中 $(U_1, U_2, \varepsilon_X, \varepsilon_Z, \varepsilon_Y) \stackrel{\text{iid}}{\sim} N(0, 1)$ 。我们可以计算：

$$(16.12) \quad \text{cov}(Z, Y) = \text{cov}(cU_1 + \varepsilon_Z, dU_2 + \varepsilon_Y) = 0, ??$$

这证实了未调整估计量是无偏的。但在给定 X 的条件下, Z 和 Y 的偏相关系数为 (推导见习题 D.2):

$$(16.13) \quad \rho_{ZY|X} \propto -abcd, ??$$

即偏倚与路径系数的乘积 $abcd$ 成正比。

例 D.4 (M-偏倚的数值演示). 考虑样本量 $n = 10^6$ 的大规模蒙特卡洛模拟:

```
U1 = rnorm(n)
U2 = rnorm(n)
X = U1 + U2 + rnorm(n)
Y = U2 + rnorm(n)
Z = U1 + rnorm(n)

# 连续治疗
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.001
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] -0.20
```

```
# 二值治疗
Z = (Z >= 0)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.002
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] -0.42
```

未调整的简单估计量接近真实值 (θ), 但调整 X 后的估计量产生了显著偏倚 (约 -0.2 到 -0.4)。这就是 M -偏倚。

M -偏倚的教训是: 并非所有治疗前协变量都应该调整。调整一个与未测混杂 U_1 和 U_2 都相关的变量 X , 可能反而在 U_1 和 U_2 之间建立虚假的关联, 从而引入偏倚。

4.2. Z-偏倚. Z-偏倚 (Z-bias) 是另一个过度调整的例子, 但机制与 M -偏倚不同。考虑以下因果图:

$$Z \leftarrow X \rightarrow U \rightarrow Y$$

其中 X 影响 Z 和 U , 而 U 同时影响 Z 和 Y 。对应的数据生成过程是:

$$(16.14) \quad \begin{cases} Z = aX + bU + \varepsilon_Z, \\ Y(z) = \tau z + cU + \varepsilon_Y, \end{cases} ??$$

其中 $(U, X, \varepsilon_Z, \varepsilon_Y) \stackrel{\text{iid}}{\sim} N(0, 1)$ 。在这个设定中, $X \perp U$, 但 X 与 Z 和 Y 都有关联—— X 通过 Z 影响 Y , 而 U 是一个未测混杂。

直觉: 治疗 Z 是 X 、未测混杂 U 和其他随机误差的函数。条件于 X 会使 Z 变得更依赖于 U , 从而放大了由 U 引起的混杂偏倚。

数学上, 未调整的 OLS 估计量是:¹

$$(16.15) \quad \tau_{\text{unadj}} = \tau + \frac{c \operatorname{cov}(Z, U)}{\operatorname{var}(Z)} = \tau + \frac{cb}{a^2 + b^2 + 1}, ??$$

其偏倚为 $bc/(a^2 + b^2 + 1)$ 。

¹推导见附录 ??

调整后的 OLS 估计量（从 Y 对 (Z, X) 的回归）满足：²

$$(16.16) \quad \tau_{\text{adj}} = \tau + \frac{bc}{b^2 + 1} ??$$

比较两者：当 $a \neq 0$ 时， $a^2 + b^2 + 1 > b^2 + 1$ ，因此

$$(16.17) \quad \left| \frac{bc}{a^2 + b^2 + 1} \right| < \left| \frac{bc}{b^2 + 1} \right| ??$$

也就是说，**调整后的估计量比未调整的估计量偏倚更大！**而且， X 与 Z 的关联越强（ a 越大），调整引入的偏倚就越大。

例 D.5 (Z-偏倚的数值演示). 考虑蒙特卡洛模拟：

```
n = 10^6
X = rnorm(n)
U = rnorm(n)
Z = X + U + rnorm(n)
Y = U + rnorm(n)

# Z ~ X + U
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.333
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.501

# X-Z 关联更强时
Z = 2*X + U + rnorm(n)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.167
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.501

# X-Z 关联更强时
Z = 10*X + U + rnorm(n)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.01
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.50
```

可以看到：随着 X 与 Z 的关联增强，未调整估计量越来越接近真实值 $\tau = 0$ ，而调整后的估计量始终为 0.5——因为调整反而引入了更大的偏倚。

Z-偏倚的技术细节见 Problem D.1。Pearl (2010a, 2011) 用因果图解释了这种现象。Ding 等 (2017b) 提供了更一般的理论。

为什么叫 Z-偏倚？在 Pearl 的原始论文中，他用符号 Z 表示我们这里的变量 X （而用 X 表示治疗变量）。为了避免混淆，本书在第五部分讨论工具变量时会正式使用 Z 这个符号——这也是为什么在工具变量情境下，Z-偏倚也被称为**工具变量偏倚 (instrumental variable bias)**。

4.3. 哪些协变量应该调整？真实的因果图可能非常复杂，但我们可以用一个简化的图形来澄清许多概念。考虑以下结构：

$$X_Y \rightarrow Y, X_Y \rightarrow Z, X \rightarrow Z, X \rightarrow Y, X_I \rightarrow Z, X_I \rightarrow Y$$

各类协变量的特征如下：

- (a) **X (混杂变量)**：同时影响治疗和结果。条件于 X 确保不可混淆性假设成立，我们应该控制 X 。

²推导见附录 ??

- (b) X_R (无关变量): 既不影响治疗也不影响结果, 是纯随机噪声。在分析中包含它不会引入偏倚, 但会在有限样本中引入不必要的变异性。
- (c) X_Z (工具变量): 仅通过治疗影响结果。在图中包含它不会引入偏倚, 但会增加估计量的变异性。然而, 在存在未测混杂的情况下 (如 Z -偏倚所示), 调整 X_Z 会放大偏倚。
- (d) X_Y (预测变量): 仅影响结果但不影响治疗。即使不条件于它, 不可混淆性假设仍然成立。由于它们对结果有预测力, 在分析中包含它们通常能提高精度。
- (e) X_I (干预后变量): 受治疗和结果共同影响, 是治疗后变量。如果目标是推断治疗对结果的因果效应, 我们不应该调整它。

如果我们相信上述因果图的结构, 那么我们应该至少调整 X 以消除偏倚, 理想情况下还应进一步调整 X_Y 以减少方差。

实践中的困难: 我们永远无法确切知道真实的底层数据生成过程。这是因果推断的根本挑战——我们需要领域知识和假设来指导协变量的选择。

Table 1 总结了各类协变量的特征。

TABLE 1. 协变量类型与调整策略

类型	Z 前置吗?	Y 前置吗?	调整建议
X (混杂)	是	是	应该调整
X_R (无关)	否	否	可调整 (增加方差)
X_Z (工具)	是	否	谨慎: 可能放大偏倚
X_Y (预测)	否	是	可调整 (减少方差)
X_I (干预后)	是	是	不应调整

5. 习题

练习 D.1. 验证正文中的公式 ?? 和 ??。

练习 D.2. 考虑正文中的 M -偏倚正态线性模型。证明给定 X 时 Z 和 Y 的偏相关系数公式 ??。

练习 D.3. 找出一个你自己的研究领域中的阴性结果或阴性暴露的例子。讨论为什么它符合阴性控制的条件, 以及它如何帮助评估不可混淆性假设。

练习 D.4. ? 和 *econometricians* 提出了以下 **Cochran 公式** (也称为遗漏变量偏倚公式)。设 $(y_i, x_{1i}, x_{2i})_{i=1}^n$ 为 IID 样本, 其中 y_i 是标量, x_{1i} 维数为 K , x_{2i} 维数为 L 。考虑 OLS 分解:

$$y_i = \beta_1^T x_{1i} + \beta_2^T x_{2i} + \varepsilon_i \quad (\text{长回归}),$$

$$y_i = \gamma^T x_{1i} + e_i \quad (\text{短回归}),$$

$$x_{2i} = \delta^T x_{1i} + v_i.$$

证明: $\gamma = \beta_1 + \delta\beta_2$ 。解释为什么 $\delta\beta_2$ 被称为遗漏变量偏倚。

练习 D.5. 设计一个模拟研究, 演示以下情形:

- (a) 调整混杂变量 X 可以减少偏倚;
- (b) 调整与未测混杂相关的变量会引入 M -偏倚;
- (c) 调整工具变量 X_Z 在存在未测混杂时会放大偏倚。

对于每种情形, 使用大样本量 ($n = 10^5$) 计算未调整和调整后的估计量。

6. 推荐阅读

关于因果图和因果推断的深入讨论，见 Pearl (2000) 的经典教科书。

和 Shpitser (2011) 讨论了协变量选择的正式准则。

(2002b) 是关于观测性研究中敏感性分析的重要参考文献，也是本章许多思想的源头。

等 (2017b) 提供了 Z-偏倚（工具变量偏倚）的一般性理论。

E-Value: 未测混杂观测性研究中的因果证据

1. 引言: 当可忽略性假设失效时

“It is possible that the entire relationship between cigarette smoking and lung cancer is due to some common cause.” — (?)

在 Part III 中, 我们详细讨论了观测性研究的四大支柱: outcome regression (第 C 章)、逆倾向得分加权 (第 D 章)、双重稳健 (第 E 章) 以及匹配 (第 C 章)。这四种方法的核心假设是**可忽略性 (ignorability)**:

$$(17.1) \quad Z \perp \{Y(1), Y(0)\} \mid X.$$

即在协变量 X 条件下, 治疗分配 Z 与潜在结果相互独立。这个假设保证了我们可以从观测数据中识别因果效应。然而, **可忽略性假设无法从数据本身验证**——它是一种根本性的假设, 依赖于研究者的领域知识和对因果结构的判断。

这正是观测性研究长期被批评的原因: 如果无法控制所有混淆因素, 观察到的治疗与结果之间的关联可能是虚假的。统计学能告诉我们观测数据中的关联有多强, 但无法保证这种关联背后存在真实的因果关系。

然而, **并非所有观测性研究都生来平等**。一些研究即便存在未测混杂, 其提供的因果证据也比其他研究更强。关键在于: 要完全解释掉观察到的关联, 未测混杂需要有多强? 如果这种强度在领域知识上是不合理的, 我们就有理由相信因果关系确实存在。

本章引入的 **E-value** (VanderWeele and Ding, 2017) 正是对这一思想的数学量化。它基于 Ding and VanderWeele (2016) 的理论, 为评估观测性研究中的因果证据提供了一个统一且可解释的度量。第 ?? 章讨论平均因果效应的灵敏度分析; 第 ?? 章讨论 Rosenbaum 框架下的匹配研究灵敏度分析。

2. Cornfield 型灵敏度分析

2.1. 从可忽略性到潜在可忽略性. 放弃假设 (??) 并不意味着放弃一切分析工具。我们仍然可以假设**潜在可忽略性 (latent ignorability)**:

$$(17.2) \quad Z \perp \{Y(1), Y(0)\} \mid (X, U),$$

其中 U 是未测混杂变量, 条件于 (X, U) 时治疗与潜在结果独立。注意 (??) 比 (??) 更弱——它允许 Z 与 Y 之间存在通过 U 传递的关联, 只要这种关联可以被 U 完全解释。

本章的方法在二值结果 Y 上表现最佳 (Ding and VanderWeele, 2016), 但可推广到其他非负结果。为简化叙述, 除非特别说明, 我们均假设 Y 为二值。

2.2. 真实风险比与观测风险比. 在 $X = x$ 条件下, 真实的条件风险比为:

$$(17.4) \quad \text{RR}_{ZY|x}^{\text{true}} = \frac{\{Y(1) = 1 \mid X = x\}}{\{Y(0) = 1 \mid X = x\}}.$$

但从数据中能直接计算的是观测风险比:

$$(17.6) \quad \text{RR}_{ZY|x}^{\text{obs}} = \frac{(Y = 1 \mid Z = 1, X = x)}{(Y = 1 \mid Z = 0, X = x)}.$$

在存在未测混杂 U 时, 二者一般不相等。直观上, 这是因为 U 在治疗组和对照组中的分布不同 (U 同时影响治疗分配和结果), 而真实的因果效应需要控制 U 后才能得到。

考虑如下因果图 (条件于 X):

$$Z \rightarrow U \rightarrow Y,$$

其中 U 是 Z 和 Y 的共同原因 (common cause)。在此结构下, $Z \perp Y \mid (X, U)$ 但 $Z \not\perp Y \mid X$ 。为简化, 我们假设 U 为二值, 尽管 Ding and VanderWeele (2016) 的理论对 U 的一般形式也成立。

定义两个灵敏度参数:

$$(17.8) \quad \text{RR}_{ZU|x} = \frac{(U = 1 \mid Z = 1, X = x)}{(U = 1 \mid Z = 0, X = x)},$$

衡量**治疗-混杂关联**; 以及

$$(17.10) \quad \text{RR}_{UY|x} = \frac{(Y = 1 \mid U = 1, X = x)}{(Y = 1 \mid U = 0, X = x)},$$

衡量**混杂-结果关联**。这两个量都无法从数据中识别——它们是未知的灵敏度参数, 反映了未测混杂的强度。

2.3. Cornfield 不等式. 下面的定理是整个 E-value 理论的基石。

定理 E.1 (Cornfield-type 上界). 在假设 (??) 下, 假设

$$(17.12) \quad \text{RR}_{ZY|x}^{\text{obs}} > 1, \quad \text{RR}_{ZU|x} > 1, \quad \text{RR}_{UY|x} > 1.$$

则有

$$(17.14) \quad \text{RR}_{ZY|x}^{\text{obs}} \leq \frac{\text{RR}_{ZU|x} \cdot \text{RR}_{UY|x}}{\text{RR}_{ZU|x} + \text{RR}_{UY|x} - 1}.$$

定理 E.1 的含义: 在潜在可忽略性下, 治疗与结果之间的观测关联完全来自两条路径—— $Z \leftarrow U \rightarrow Y$ ——的组合效应。上界 $\text{RR}_{ZU|x} \cdot \text{RR}_{UY|x} / (\text{RR}_{ZU|x} + \text{RR}_{UY|x} - 1)$ 体现了这两条路径的“乘法阻塞”: 要产生一个较大的 $\text{RR}_{ZY|x}^{\text{obs}}$, 两条路径都必须足够强。

特别地, 从 (??) 可推出 **Cornfield 不等式** (Gastwirth et al., 1998):

$$(17.16) \quad \min(\text{RR}_{ZU|x}, \text{RR}_{UY|x}) \geq \text{RR}_{ZY|x}^{\text{obs}}.$$

即：要完全解释掉观测到的风险比，未测混杂与治疗的关联以及与结果的关联，都必须至少与观测到的风险比一样强。这个简单而强大的结论，首次由 Cornfield et al. (1959) 在讨论吸烟与肺癌时得到。

证明思路：定义 $f_{1,x} = (U = 1 \mid Z = 1, X = x)$ 和 $f_{0,x} = (U = 1 \mid Z = 0, X = x)$ 。通过全概率公式分解 $RR_{ZY|x}^{\text{obs}}$ 并利用 $Z \perp Y \mid (X, U)$ ，可得恒等式 (??)。¹

3. E-value

3.1. 从 Cornfield 不等式到 E-value. 从定理 E.1 和引理 E.3(4)，定义 $w = \max(RR_{ZU|x}, RR_{UY|x})$ ，则

$$(17.18) \quad RR_{ZY|x}^{\text{obs}} \leq \frac{w^2}{2w - 1}.$$

解这个二次不等式，较小根始终 ≤ 1 ，故

$$(17.20) \quad w \geq RR_{ZY|x}^{\text{obs}} + \sqrt{RR_{ZY|x}^{\text{obs}}(RR_{ZY|x}^{\text{obs}} - 1)}.$$

这给出了 E-value 的定义。

定义 E.2 (E-value). 给定观测条件风险比 $RR_{ZY|x}^{\text{obs}}$ ，定义 **E-value** 为

$$(17.22) \quad RR_{ZY|x}^{\text{obs}} + \sqrt{RR_{ZY|x}^{\text{obs}}(RR_{ZY|x}^{\text{obs}} - 1)}.$$

E-value 的解释：E-value 表示要完全解释掉观测到的风险比， $\max(RR_{ZU|x}, RR_{UY|x})$ 必须达到的最小值。换言之，如果领域知识认为任何合理的未测混杂，其与治疗和结果的关联程度都不可能超过某个阈值 R ，那么当 $R < \text{E-value}$ 时，我们有理由相信因果关系确实存在。

E-value 与 Fisher p 值的对比：在随机化实验中，Fisher p 值衡量的是因果证据。但在大样本观测性研究中， p 值可能是因果证据的误导性度量——即使真实因果效应为零，微弱的未测混杂也可以产生极小的 p 值。采样误差随样本量增大而减小，但未测混杂带来的不确定性不会随样本量增大而消失。E-value 正是为了填补这一空白而设计的。

引理 E.3 (β 函数性质). 定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$ ($w_1 > 1, w_2 > 1$)。则：

- (a) $\beta(w_1, w_2)$ 对称于 w_1 和 w_2 ；
- (b) $\beta(w_1, w_2)$ 对 w_1 和 w_2 均单调递增；
- (c) $\beta(w_1, w_2) \leq w_1$ 且 $\beta(w_1, w_2) \leq w_2$ ；
- (d) $\beta(w_1, w_2) \leq w^2 / (2w - 1)$ ，其中 $w = \max(w_1, w_2)$ 。

引理 E.3 的意义：(3) 意味着 Cornfield 不等式可以直接从定理 E.1 推出；(4) 是连接 Cornfield 界与 E-value 的关键步骤。²

4. 经典例子：吸烟与肺癌

例 E.1 (Hammond and Horn, 1958). 研究美国人群中吸烟与肺癌的关系。不调整协变量的数据可列为下表：

¹完整证明推导见附录 chapter A

²证明见附录 chapter B

	肺癌	无肺癌
吸烟者	397	78,557
非吸烟者	51	108,778

基于该数据, 风险比估计为 $\widehat{RR} = 10.73$, 95% 置信区间为 $[8.02, 14.36]$ 。

- 解释点估计的 *E-value*:

$$E - \text{value} = 10.73 + \sqrt{10.73 \times 9.73} \approx 20.95.$$

- 解释下限的 *E-value*:

$$E - \text{value}_{CI} = 8.02 + \sqrt{8.02 \times 7.02} \approx 15.52.$$

解读: 要完全解释掉观察到的风险比 (甚至其置信下限), 未测混杂与治疗的关联以及与结果的关联, 都必须达到至少 15.52。这意味着未测混杂必须是一个**极强**的风险因子——它与吸烟的关联程度要接近吸烟本身与肺癌的关联程度 (10 倍以上)。在领域知识上, 这种强度的未知混杂似乎不太合理, 因此该研究提供了较强的因果证据。

图 ?? (Hammond and Horn 数据的混淆强度轮廓) 展示了要解释掉点估计和置信下限, 两类混淆强度 ($RR_{ZU|x}$, $RR_{UY|x}$) 需要满足的条件。

5. 扩展

5.1. E-value 与 Bradford Hill 因果判定准则. E-value 提供了因果证据的定量度量, 但它与流行病学中经典的 **Bradford Hill 准则** (Bradford Hill, 1965) 有深刻的联系。Bradford Hill 提出了九条判断因果关系的准则, 其中第一条是:

强度 (Strength) : 关联越强, 因果解释的可能性越大。

定理 E.1 从数学上精确化了这一直觉: **更强的关联需要更强的未测混杂来解释**。E-value 正是这种“强度”的量化。

当然, 关联强度只是因果判定的一个方面。Bradford Hill 的其他准则——时间顺序 (temporality)、生物学合理性 (biological plausibility)、一致性 (consistency)、剂量-反应关系 (dose-response) ——都从不同角度提供证据。E-value 只量化了“强度”这一维度。

定义 E.4 (Bradford Hill 九条因果准则). (?) 提出的九条因果判定准则:

- 强度 (*strength*);
- 一致性 (*consistency*);
- 特异性 (*specificity*);
- 时间顺序 (*temporality*);
- 生物学梯度 (*biological gradient*);
- 生物学合理性 (*plausibility*);
- 一致性 (*coherence*);
- 实验证据 (*experiment*);
- 类比 (*analogy*)。

E-value 量化了第 (1) 条准则, 但没有涉及其他八条。这是 E-value 的适用范围——它是一个有意义的补充, 但不是因果判定的全部。

5.2. 逻辑斯蒂回归后的 E-value. 流行病学研究中, 二值结果常用逻辑斯蒂回归建模:

$$(17.24) \quad (Y_i = 1 \mid Z_i, X_i) = \frac{e^{\beta_0 + \beta_1 Z_i + \beta_2^\top X_i}}{1 + e^{\beta_0 + \beta_1 Z_i + \beta_2^\top X_i}}.$$

其中系数 β_1 是给定 X 下治疗与结果的**条件比数比 (conditional odds ratio)** 的对数。逻辑斯蒂模型的一个重要假设是: 比数比在所有 X 取值上是共同的 (common odds ratio)。

当结果罕见时 ($(Y = 1 \mid Z, X)$ 接近 0), 条件比数比近似于条件风险比 (见命题 ??)。³

因此, 在罕见结果假设下, 我们可以直接基于逻辑斯蒂回归估计的 $\hat{\beta}_1$ 计算 E-value:

$$(17.26) \quad \widehat{\text{E-value}} = \exp(\hat{\beta}_1) + \sqrt{\exp(\hat{\beta}_1)(\exp(\hat{\beta}_1) - 1)}.$$

这使得 E-value 可以方便地应用于常规的流行病学分析流程。

例 E.2 (NCHS 2003 出生数据). 使用美国国家卫生统计中心 2003 年出生证明数据, 研究高龄母亲 (≥ 35 岁) 对早产的影响。调整社会人口学协变量后, 逻辑斯蒂回归得到的条件风险比为 1.31, 其 95% 置信区间为 [1.29, 1.33]。

对应的 *E-value* 约为 1.94 (点估计) 和 1.91 (置信下限)。这意味着要解释掉观察到的关联, 未测混杂必须同时与治疗 (高龄) 和结果 (早产) 有至少 1.9 倍的关联——这个强度在流行病学上看起来是较大的, 但远不如吸烟-肺癌例子中的 20.95。

5.3. 允许非零真实因果效应. 定理 E.1 假设真实因果效应为零。Ding and VanderWeele (2016) 将结果推广到允许非零真实因果效应的情形。

定理 E.5 (含真实因果效应的下界). 修改 $RR_{UY|x}$ 的定义为:

$$(17.28) \quad RR_{UY|x} = \max_{z=0,1} \frac{(Y = 1 \mid Z = z, U = 1, X = x)}{(Y = 1 \mid Z = z, U = 0, X = x)}.$$

则在假设 (??) 下,

$$(17.30) \quad RR_{ZY|x}^{\text{true}} \geq \frac{RR_{ZY|x}^{\text{obs}}}{\frac{RR_{ZU|x} \cdot RR_{UY|x}}{RR_{ZU|x} + RR_{UY|x} - 1}}.$$

定理 E.5 的解读: 即使存在未测混杂, 定理也给出了真实因果效应 $RR_{ZY|x}^{\text{true}}$ 的一个下界。这个下界等于观测风险比除以 Cornfield 上界。当灵敏度参数取不同值时, 我们可以评估因果效应下界对未测混杂强度的敏感性。

6. 批评与回应

自 E-value 论文发表以来, 它已成为流行病学研究中报告的标准数字。但它也受到了批评 (Ioannidis et al., 2019)。下面讨论几个主要局限性。

³详见附录 chapter C

6.1. E-value 不过是风险比的单调变换. 从图 ?? 可以看出, 当风险比较大时, E-value 近似等于 $2 \cdot RR_{ZY|x}^{obs}$ ——几乎是线性的。因此批评者认为 E-value 不过是风险比的一个单调变换, 没有提供额外信息。

这部分正确——E-value 确实完全基于风险比的点估计和置信限。但关键在于: E-value 有**有意义的解释** (定义 E.2), 而风险比本身没有这种“需要多强的未测混杂”的解释。从风险比 10.73 到 E-value 20.95, 数字变了, 但解释的含义完全不同。

6.2. E-value 的校准问题. E-value 等于 $\max(RR_{ZU|x}, RR_{UY|x})$ ——即要解释掉观察到的关联, 未测混杂与治疗 and 结果关联所必须达到的最小值。问题在于: 这个未测混杂本身是无法观测的, 因此很难判断某个 E-value 究竟算“大”还是“小”。

此外, E-value 的大小取决于我们调整了多少协变量 X ——它量化的是**给定已调整协变量后的**残余混杂强度。不同研究之间的 E-value 不能直接比较, 因为它们的 X 不同。

一个直观的校准思路是“逐一剔除协变量”法: 如果我们把某个已调整的协变量 X_j 当作“未测混杂”来对待, 计算 $Z - X_j$ 和 $X_j - Y$ 的风险比, 这些比值可以提供参考尺度。但这一方法尚无严格的理论支撑。

6.3. E-value 最适用于二值结果和风险比. 定理 E.1 在二值结果和风险比尺度上表现最佳。Ding and VanderWeele (2016) 也提出了风险差、均值比 (针对非负结果) 以及生存分析中的风险比 (HR) 的灵敏度分析方法, 但它们不如二值结果下的 E-value 那样优雅和简洁。第 ?? 章将给出平均因果效应的更一般灵敏度分析方法, 适用于 outcome regression、IPW 和双重稳健估计。

7. 本章小结

本章围绕 E-value 展开, 核心思想是:

- 未测混杂无法从数据中验证**, 但我们可以量化: 要解释掉观察到的关联, 未测混杂必须有多强?
- Cornfield 不等式**: 要完全解释掉风险比 RR^{obs} , 未测混杂与治疗的关联和与结果的关联都必须至少达到 RR^{obs} ;
- E-value** 是这一思想的精确数学化: $E - value = RR^{obs} + \sqrt{RR^{obs}(RR^{obs} - 1)}$;
- E-value 越大, 意味着需要越强的未测混杂才能解释掉观察到的关联, 因果证据越强;
- E-value 有明确的局限性——它只量化了 Bradford Hill 准则中的“强度”维度, 且最适用于二值结果和风险比。

本章将所有推导放在附录, 正文专注于概念的动机、历史的脉络和结果的理解。

8. 习题

[17.1] 证明函数 $f(x) = (ax + 1)/(bx + 1)$ 在 $a > b$ 时关于 x 单调递增, 在 $a < b$ 时单调递减。

[17.2] 证明在假设 $Z \perp Y \mid (X, U)$ 下, 如果 $RR_{ZU|x} > 1$ 但 $RR_{UY|x} < 1$, 则 $RR_{ZY|x}^{obs} < 1$ 。这说明 (??) 中的第三个条件在某种意义上是冗余的。

[17.3] 证明引理 E.3。

[17.4] (Schlesselman 1978 公式) 在二值治疗 Z 、结果 Y 和未测混杂 U 下, 假设层内 ($U = 0$ 和 $U = 1$) 治疗对结果的风险比相同, $RR_{ZY|U=0} = RR_{ZY|U=1}$, 且

混杂对结果的风险比在两组治疗下也相同（记为 γ ）。证明：

$$(17.32) \quad \frac{RR_{ZY}^{\text{obs}}}{RR_{ZY}^{\text{true}}} = \frac{1 + (\gamma - 1)(U = 1 \mid Z = 1)}{1 + (\gamma - 1)(U = 1 \mid Z = 0)}.$$

并讨论此公式与定理 E.1 的关系。

[17.5] 使用与例 E.2 相同的数据集，计算结果为子痫前期（preeclampsia）时的 E-value。

[17.6] （风险差的 Cornfield 不等式）考虑二值 Z, Y, U 。在潜在可忽略性 $Z \perp Y \mid U$ 下，证明风险差的 Cornfield 不等式：

$$(17.34) \quad RD_{ZY}^{\text{obs}} = RD_{ZU} \times RD_{UY},$$

并由此推出：

$$(17.36) \quad \min(RD_{ZU}, RD_{UY}) \geq RD_{ZY}^{\text{obs}}, \quad \max(RD_{ZU}, RD_{UY}) \geq \sqrt{RD_{ZY}^{\text{obs}}}.$$

9. 推荐阅读

- ?：扩展并统一了 Cornfield 型灵敏度分析，是 E-value 的理论基础。
- ?：首次正式提出 E-value 并给出其流行病学解释。
- ?：Bradford Hill 原文，九条因果准则的经典来源。
- ?：对 E-value 的批评性讨论。

附录：定理 E.1 的证明

1. 背景与目标

我们要在假设 (??) 下，证明观测风险比的上界。核心思想是：条件于 (X, U) 后，治疗 Z 与结果 Y 独立，因此观测风险比中的分子和分母分别是 U 在治疗组和对照组中分布的加权平均。

2. 记号定义

定义：

$$(17.A.1) \quad f_{1,x} = (U = 1 \mid Z = 1, X = x), \quad f_{0,x} = (U = 1 \mid Z = 0, X = x).$$

由灵敏度参数的定义 (??)：

$$(17.A.3) \quad \text{RR}_{ZU|x} = \frac{f_{1,x}}{f_{0,x}} \implies f_{0,x} = \frac{f_{1,x}}{\text{RR}_{ZU|x}}.$$

定义 $\gamma_x = \text{RR}_{UY|x}$ 以简化记号。

3. 详细推导

利用全概率公式，分子（治疗组的条件结果概率）为：

$$(17.A.5) \quad \begin{aligned} (Y = 1 \mid Z = 1, X = x) &= (Y = 1 \mid U = 1, X = x)(U = 1 \mid Z = 1, X = x) \\ &\quad + (Y = 1 \mid U = 0, X = x)(U = 0 \mid Z = 1, X = x) \\ &= \gamma_x f_{1,x} + (1 - f_{1,x}) \cdot 1 \\ &= (\gamma_x - 1)f_{1,x} + 1. \end{aligned}$$

分母（对照组的条件结果概率）为：

$$(17.A.7) \quad \begin{aligned} (Y = 1 \mid Z = 0, X = x) &= (Y = 1 \mid U = 1, X = x)(U = 1 \mid Z = 0, X = x) \\ &\quad + (Y = 1 \mid U = 0, X = x)(U = 0 \mid Z = 0, X = x) \\ &= \gamma_x f_{0,x} + (1 - f_{0,x}) \\ &= (\gamma_x - 1)f_{0,x} + 1. \end{aligned}$$

代入 $f_{0,x} = f_{1,x}/\text{RR}_{ZU|x}$ ，得：

$$(17.A.9) \quad (Y = 1 \mid Z = 0, X = x) = (\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1.$$

因此观测风险比可以写成：

$$(17.A.11) \quad \text{RR}_{ZY|x}^{\text{obs}} = \frac{(\gamma_x - 1)f_{1,x} + 1}{(\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1}.$$

4. 单调性与上界

对 $f_{1,x} \in [0, 1]$ ，可验证函数

$$g(t) = \frac{(a-1)t+1}{(a-1)\frac{t}{b}+1}$$

在 $a > 1, b > 1$ 时关于 t 单调递增（习题 8）。因此 $f_{1,x}$ 越大， $\text{RR}_{ZY|x}^{\text{obs}}$ 越大。取上界 $f_{1,x} = 1$ ：

$$(17.A.13) \quad \text{RR}_{ZY|x}^{\text{obs}} \leq \frac{(\gamma_x - 1) + 1}{\frac{\gamma_x - 1}{\text{RR}_{ZU|x}} + 1} = \frac{\gamma_x \cdot \text{RR}_{ZU|x}}{\gamma_x + \text{RR}_{ZU|x} - 1}.$$

这正是定理 E.1 中的上界 (??)。

5. 恒等式 (??)

由以上推导，我们实际得到了一个精确的恒等式（而非仅仅是上界）：

$$(17.A.15) \quad \text{RR}_{ZY|x}^{\text{obs}} = \frac{(\text{RR}_{UY|x} - 1)f_{1,x} + 1}{\frac{\text{RR}_{UY|x} - 1}{\text{RR}_{ZU|x}} f_{1,x} + 1}.$$

这个恒等式涉及三个灵敏度参数 ($f_{1,x}, \text{RR}_{ZU|x}, \text{RR}_{UY|x}$)，而定理 E.1 的上界只涉及后两者。数学上恒等式强于不等式，但恒等式需要多一个灵敏度参数——这是灵敏度分析中**准确度与便利性之间的权衡**。

附录：引理 E.3 的证明

定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$, 其中 $w_1 > 1, w_2 > 1$ 。

性质 (1) 对称性: 显然 $\beta(w_1, w_2) = \beta(w_2, w_1)$ 。

性质 (2) 单调性: 计算偏导数:

$$(17.B.1) \quad \frac{\partial \beta}{\partial w_1} = \frac{w_2(w_1 + w_2 - 1) - w_1 w_2}{(w_1 + w_2 - 1)^2} = \frac{w_2(w_2 - 1)}{(w_1 + w_2 - 1)^2} > 0.$$

同理 $\partial \beta / \partial w_2 > 0$, 故 β 对两个变量均单调递增。

性质 (3) 上界:

$$(17.B.3) \quad \beta(w_1, w_2) = \frac{w_1 w_2}{w_1 + w_2 - 1} \leq \frac{w_1 w_2}{w_1} = w_2 \quad (\text{因为 } w_2 - 1 \geq 0).$$

对称地得到 $\beta \leq w_1$ 。

性质 (4) $w = \max(w_1, w_2)$ 时的界: 设 $w_1 = w, w_2 \leq w$, 则

$$(17.B.5) \quad \beta(w_1, w_2) = \frac{w \cdot w_2}{w + w_2 - 1} \leq \frac{w \cdot w}{w + w - 1} = \frac{w^2}{2w - 1}.$$

证毕。

附录：罕见结果近似

对于二值结果 Y ，逻辑斯蒂模型 (??) 中治疗指示变量 Z 的系数 β_1 是条件比数比 (odds ratio)：

$$(17.C.1) \quad \beta_1 = \log \text{OR}_{ZY|x} = \log \frac{\text{odds}(Y = 1 \mid Z = 1, X = x)}{\text{odds}(Y = 1 \mid Z = 0, X = x)}.$$

当结果罕见时， $(Y = 1 \mid Z = 1, X = x) \approx 0$ 且 $(Y = 1 \mid Z = 0, X = x) \approx 0$ ，此时

$$(17.C.3) \quad \text{odds}(Y = 1 \mid Z, X) \approx \frac{(Y = 1 \mid Z, X)}{1 - (Y = 1 \mid Z, X)} \approx (Y = 1 \mid Z, X).$$

因此罕见结果假设下，条件比数比近似于条件风险比：

$$(17.C.5) \quad \beta_1 \approx \log \text{RR}_{ZY|x}^{\text{obs}}.$$

由此可得 $\exp(\beta_1) \approx \text{RR}_{ZY|x}^{\text{obs}}$ ，进而 E-value 的计算公式 (??) 可直接应用于逻辑斯蒂回归系数。