

$y T w \ f l$

$S 2 M ; . B M ;$

理解 ?? 的直觉： (x) 衡量的是将处理从 0 变到 1（但保持中介在无处理时的自然分布）的效应。在每个中介值 m 下，处理从 0 变到 1 的条件效应是 $\mathbb{E}(Y | Z = 1, M = m, X = x) - \mathbb{E}(Y | Z = 0, M = m, X = x)$ ；由于中介被固定在 $Z = 0$ 条件下的分布，这些条件效应需要按 $\Pr(M = m | Z = 0, X = x)$ 加权求和。

对于二值中介 $M \in \{0, 1\}$ ，?? 中的 NIE 公式可以化简为一种优美的乘积形式。

推论 G.5 (二值中介的 NIE 乘积公式). 在 ???????? 下，对二值中介 M ，有

$$(x) = \tau_{Z \rightarrow M}(x) \cdot \tau_{M \rightarrow Y}(1, x),$$

其中

$$\tau_{Z \rightarrow M}(x) = \Pr(M = 1 | Z = 1, X = x) - \Pr(M = 1 | Z = 0, X = x)$$

是 Z 对 M 的条件平均因果效应，

$$\tau_{M \rightarrow Y}(z, x) = \mathbb{E}(Y | Z = z, M = 1, X = x) - \mathbb{E}(Y | Z = z, M = 0, X = x)$$

是 M 对 Y 的条件平均因果效应。

为什么叫乘积公式？ 直观上，间接效应是这样传导的：首先，处理 Z 变化导致中介 M 变化（效应 $\tau_{Z \rightarrow M}$ ）；然后，中介 M 变化导致结果 Y 变化（效应 $\tau_{M \rightarrow Y}$ ）。这两段效应的乘积，就是总间接效应。这与我们的直觉完全一致。

?? 的证明留作练习。⁸

5. 线性模型下的 Baron-Kenny 方法

mediation 给出了非参数识别公式，它允许我们在各种不同模型下推导出中介效应的具体形式。本节介绍经典而又广泛使用的 **Baron-Kenny 方法** (?)，该方法假设线性模型。

5.1. 模型设定. Baron-Kenny 方法假设中介和结果都满足线性模型 (??)。

[Baron-Kenny 线性模型] 中介和结果的条件期望满足线性模型：

$$(27.1) \quad \begin{cases} \mathbb{E}(M | Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y | Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

在上述线性模型下，NDE 和 NIE 可以简化为系数的简洁函数。

推论 G.6 (Baron-Kenny 公式). 在 ?????????? 下，有

$$(27.2) \quad \quad \quad = \theta_1, \quad \quad = \theta_2 \beta_1.$$

与 DAG 的对应： 在 ?? 中， θ_1 是路径 $Z \rightarrow Y$ 的系数（直接效应）， $\beta_1 \theta_2$ 是路径 $Z \rightarrow M \rightarrow Y$ 的系数之积（间接效应）。这与 ?? 完全一致。

为何不需要对 X 求和？ 注意在 ?? 和 ?? 中， (x) 和 (x) 是在给定 $X = x$ 的条件下的值。而在 Baron-Kenny 线性模型下， θ_1 和 $\theta_2 \beta_1$ 与 x 无关，因此条件效应等于无条件效应。

Baron-Kenny 公式的推导见附录 ??。

如果获得了系数的 OLS 估计量 $\hat{\beta}_1$ 和 $\hat{\theta}_2$ ，则 NDE 和 NIE 的估计量为

$$\hat{\quad} = \hat{\theta}_1, \quad \hat{\quad} = \hat{\theta}_2 \hat{\beta}_1,$$

⁸详见 ?? 题。

这就是经典的 Baron-Kenny 估计。⁹ 和 ⁹ 利用 delta 方法给出了 $\hat{\gamma}$ 的标准误：

$$\text{var}(\hat{\gamma}) = \text{var}(\hat{\theta}_2)\hat{\beta}_1^2 + \hat{\theta}_2^2\text{var}(\hat{\beta}_1).$$

基于此的假设检验称为 Sobel's test。⁹

Baron-Kenny 方法的历史：虽然 ⁹ 使这一方法广为人知，但它实际上有更早的渊源，包括 ⁹、⁹ 和 ⁹ 的工作。⁹ 进一步发展了推断方法。

6. 应用实例：JOBS II 数据

我们通过 R 代码实现 Baron-Kenny 方法，并将其应用于 JOBS II 数据集。¹⁰

例 G.5 (JOBS II：就业培训对心理健康的中介分析). 我们关注就业培训（处理 Z ）对心理健康（结果 Y ，用抑郁量表得分度量）的影响，以及这一影响是否通过工作搜寻效能（中介 M ）传导。背景协变量 X 包括经济困难程度、基线抑郁得分、性别、年龄、职业、婚姻状态、种族、教育程度和家庭收入。

通过以下 R 代码实现 Baron-Kenny 方法：

```
library("car")
BKmediation = function(Z, M, Y, X) {
  mediator.reg = lm(M ~ Z + X)
  mediator.Zcoef = mediator.reg$coef[2]
  mediator.Zse = sqrt(hccm(mediator.reg)[2, 2])

  outcome.reg = lm(Y ~ Z + M + X)
  outcome.Zcoef = outcome.reg$coef[2]
  outcome.Zse = sqrt(hccm(outcome.reg)[2, 2])
  outcome.Mcoef = outcome.reg$coef[3]
  outcome.Mse = sqrt(hccm(outcome.reg)[3, 3])

  NDE = outcome.Zcoef
  NIE = outcome.Mcoef * mediator.Zcoef

  NDE.se = outcome.Zse
  NIE.se = sqrt(outcome.Mse^2 * mediator.Zcoef^2 +
                outcome.Mcoef^2 * mediator.Zse^2)

  res = matrix(c(NDE, NIE, NDE.se, NIE.se,
                 NDE/NDE.se, NIE/NIE.se), 2, 3)
  rownames(res) = c("NDE", "NIE")
  colnames(res) = c("est", "se", "t")
  res
}
```

运行结果如下：

```
> res = BKmediation(Z, M, Y, X)
> round(res, 3)
```

⁹关于 Sobel 检验的更多讨论见 ⁹。

¹⁰JOBS II 是一个关于就业培训对失业工人影响的随机化现场实验。数据集在 R 的 `mediation` 包中。

	est	se	t
NDE	-0.037	0.042	-0.885
NIE	-0.014	0.009	-1.528

估计的直接效应 $\hat{\gamma} = -0.037$ (培训对心理健康的直接保护效应) 和间接效应 $\hat{\gamma} = -0.014$ (通过提高工作搜寻效能而改善心理健康) 均为负, 但统计上均不显著。这表明 *JOBS II* 培训项目对心理健康的效应尚无充分证据支持按中介路径分解。

一个值得注意的现象：在某些设定下, 间接效应可能出现违反直觉的符号。例如, 如果 $Z \rightarrow M$ 的效应 $\beta_1 > 0$, $M \rightarrow Y$ 的效应 $\theta_2 > 0$, 但 Z 与 M 之间存在负交互项 $\theta_3 < 0$, 则乘积 $\beta_1(\theta_2 + \theta_3)$ 可能为负。这被称为**中介悖论** (mediator paradox) 或**替代终点悖论** (surrogate endpoint paradox)。^a

^a详见 ?。

7. 敏感性分析

中介分析依赖于强且不可检验的假设。关键的不可检验假设是跨世界独立性 (??): 我们无法通过任何实验数据验证 $Y(z, m)$ 与 $M(z')$ 在 $z \neq z'$ 时是否独立。

因此, 研究者常常需要进行**敏感性分析** (sensitivity analysis), 以探索当关键假设不成立时, 结论会如何变化。主要文献包括:

- ? 提出了类似 Cornfield 的敏感性界;
- ? 提出了针对 Baron-Kenny 线性模型量身定制的敏感性分析方法。

敏感性分析的具体方法超出了本章的范围, 但读者应记住: 中介分析的结果必须谨慎解读, 因为其核心假设无法被数据验证。

8. 本章小结

本章围绕中介分析展开, 主要内容如下:

- (1) **核心问题:** 因果效应如何在直接通路和间接通路之间分配?
- (2) **嵌套潜在结果** $Y(z, M_{z'})$: 描述跨世界 counterfactual, 是定义 NDE 和 NIE 的基础。
- (3) **效应分解:** 在 Composition 假设下, 总效应 $\tau = +$ 。
- (4) **识别假设:** 四个假设 (序列可忽略性 + 跨世界独立性) 下, 中介公式成立。
- (5) **中介公式:** 将不可观测的 NDE 和 NIE 表达为可观测条件分布的函数。
- (6) **Baron-Kenny 公式:** 在 ?? 下, $\gamma = \theta_1$, $\gamma = \theta_2\beta_1$ 。
- (7) **跨世界 counterfactual 的哲学争议:** 严格的 Popperian 认识论者认为中介分析是形而上学的。
- (8) **敏感性分析:** 由于核心假设不可检验, 敏感性分析是必要的。

中介公式的完整证明见附录 ??; Baron-Kenny 公式的推导见附录 ??; 各节练习题见附录 ??。

练习

练习 G.1. 假设 (Z, M, Y) 均为二值变量。基于潜在结果

$$M(1), M(0), Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)$$

的联合取值, 单元可以分成多少类型?

若进一步假设单调性 $M(1) \geq M(0)$ (Z 对 M 的单调性), 则单元可以分成多少类型?

若再假设 $Y(1, m) \geq Y(0, m)$ 且 $Y(z, 1) \geq Y(z, 0)$ 对所有 z, m 成立 (Z 和 M 对 Y 的单调性), 则单元可以分成多少类型?

本题答案见附录 ??。

练习 G.2. 证明 ?? 与 ???? 等价。

本题答案见附录 ??。

练习 G.3. ? 提出了另一组假设来推导中介公式：

$$\{Y(z, m), M(z')\} \perp\!\!\!\perp Z \mid X, \quad Y(z, m) \perp\!\!\!\perp M(z') \mid (Z = z', X),$$

对所有 z, z', m 成立。

证明：在上述假设下，*mediation* 中的中介公式同样成立。

本题答案见附录 ??。

练习 G.4. 在 *Baron-Kenny* 线性模型 (??) 下，首先拟合：

$$\hat{M} = \hat{\beta}_0 + \hat{\beta}_1 Z + \hat{\beta}_2^\top X, \quad \hat{Y} = \hat{\theta}_0 + \hat{\theta}_1 Z + \hat{\theta}_2 M + \hat{\theta}_4^\top X.$$

则 *NIE* 的估计量为乘积 $\hat{\theta}_2 \hat{\beta}_1$ (乘积法)。

另一方面，首先拟合：

$$\hat{Y} = \hat{\alpha}_0 + \hat{\alpha}_1 Z + \hat{\alpha}_1^\top X,$$

再拟合：

$$\hat{Y} = \tilde{\theta}_0 + \tilde{\theta}_1 Z + \tilde{\theta}_2 M + \tilde{\theta}_4^\top X,$$

则 *NIE* 的另一估计量为差值 $\hat{\alpha}_1 - \tilde{\theta}_1$ (差值法)。

证明： $\hat{\alpha}_1 - \tilde{\theta}_1 = \hat{\theta}_2 \hat{\beta}_1$ 。

本题答案见附录 ??。

练习 G.5. 证明 ?? (二值中介的 *NIE* 乘积公式)。

本题答案见附录 ??。

练习 G.6. ? 建议在结果模型中加入处理与中介的交互项：

$$\begin{cases} \mathbb{E}(M \mid Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_3 ZM + \theta_4^\top X. \end{cases}$$

证明：在此模型下，

$$= \theta_1 + \theta_3 \{\beta_0 + \beta_2^\top \mathbb{E}(X)\}, \quad = (\theta_2 + \theta_3) \beta_1.$$

并说明如何在 *IID* 数据下估计 和 。

本题答案见附录 ??。

练习 G.7. 考虑中介 M 服从正态线性模型、结果 Y 服从 *logistic* 模型：

$$\begin{cases} M \mid Z, X \sim \mathcal{N}(\beta_0 + \beta_1 Z + \beta_2^\top X, \sigma_M^2), \\ \text{logit}\{\Pr(Y = 1 \mid Z, M, X)\} = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

请将 和 表示为模型参数和 X 分布的函数，并说明如何在 *IID* 数据下估计它们。

本题答案见附录 ??。

练习 G.8. 考虑二值中介 M 服从 *logistic* 模型、结果 Y 服从线性模型：

$$\begin{cases} \text{logit}\{\Pr(M = 1 \mid Z, X)\} = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

证明：

$$= \theta_1, \quad = \theta_2 \mathbb{E}\{\text{expit}(\beta_0 + \beta_1 + \beta_2^\top X) - \text{expit}(\beta_0 + \beta_2^\top X)\}.$$

并说明如何在 *IID* 数据下估计 和 。

本题答案见附录 ??。

练习 G.9. 将嵌套潜在结果修改为

$$Y(z, F_{M_{z'}|X}) = \int Y(z, m) f(M_{z'} = m \mid X) dm,$$

其中 $F_{M_{z'}|X}$ 是条件分布而非确定值。相应地将 *NDE* 和 *NIE* 定义为

$$= \mathbb{E}\{Y(1, F_{M_0|X}) - Y(0, F_{M_0|X})\}, \quad = \mathbb{E}\{Y(1, F_{M_1|X}) - Y(1, F_{M_0|X})\}.$$

证明：在仅假设 ??????（不要求跨世界独立性）下， 和 的识别公式与正文相同。

本题答案见附录 ??。

练习 G.10. ? 和 ? 综述并比较了主分层与中介分析两种方法。请查阅这些文献，并撰写一页总结，阐述两种方法的异同与各自的优缺点。

本题为开放性研究型练习，请参考 ? 和 ?。

APPENDIX A

公式推导

1. Lemma 4.1 的证明：方差与协方差的关系

Lemma 4.1 (教材第 1975 页):

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

背景 (Background): Lemma 4.1 是 Neyman (1923) 定理证明中的一个关键代数恒等式，它建立了有限总体协方差与各个方差之间的关系。

参数定义 (Parameter Definitions):

- $S^2(1) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2$: 潜在结果 $Y_i(1)$ 的有限总体方差
- $S^2(0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$: 潜在结果 $Y_i(0)$ 的有限总体方差
- $S(1, 0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\} \{Y_i(0) - \bar{Y}(0)\}$: $Y_i(1)$ 与 $Y_i(0)$ 之间的有限总体协方差
- $\tau_i = Y_i(1) - Y_i(0)$: 个体因果效应
- $\tau = n^{-1} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$: 平均因果效应
- $S^2(\tau) = (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2$: 个体因果效应的有限总体方差

目标 (Goal): 证明

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

推导步骤 (Derivation Steps):

第一步: 从 $S^2(\tau)$ 的定义出发。

$$\begin{aligned} S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - Y_i(0)) - (\bar{Y}(1) - \bar{Y}(0))]^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - \bar{Y}(1)) - (Y_i(0) - \bar{Y}(0))]^2. \end{aligned}$$

第二步: 展开平方。

$$\begin{aligned}
S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n \left[(Y_i(1) - \bar{Y}(1))^2 + (Y_i(0) - \bar{Y}(0))^2 \right. \\
&\quad \left. - 2(Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \right] \\
&= (n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))^2 + (n-1)^{-1} \sum_{i=1}^n (Y_i(0) - \bar{Y}(0))^2 \\
&\quad - 2(n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \\
&= S^2(1) + S^2(0) - 2S(1, 0).
\end{aligned}$$

第三步：移项得到目标恒等式。

$$S^2(1) + S^2(0) - S^2(\tau) = 2S(1, 0).$$

结论：得证

$$\boxed{2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)}.$$

直观理解：这个恒等式揭示了潜在结果之间的相关性 ($S(1, 0)$) 与个体因果效应变异 ($S^2(\tau)$) 之间的联系。当个体因果效应完全恒定 ($S^2(\tau) = 0$) 时, $2S(1, 0) = S^2(1) + S^2(0)$, 即 $Y(1)$ 和 $Y(0)$ 完全正相关 (相关系数为 1)。当 $S^2(\tau) > 0$ 时, 等式右侧变小, 意味着 $S(1, 0)$ 变小或变为负值。

在方差公式中的应用：这个恒等式允许我们将 Neyman 方差公式写成两种等价形式：

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} = \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0).$$

2. 差值均值统计量的方差分解

背景：在 ?? 中, 我们声称

$$(n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

本节给出完整的代数推导。

第一步：从定义出发。

$$(n-1)s^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n [(Y_i - \bar{Y})]^2.$$

第二步：对每个单元 i , 将偏差 $Y_i - \bar{Y}$ 写成：

$$Y_i - \bar{Y} = \underbrace{(Y_i - \hat{Y}(Z_i))}_{\text{组内偏差}} + \underbrace{(\hat{Y}(Z_i) - \bar{Y})}_{\text{组间偏差}}.$$

第三步：平方展开：

$$(Y_i - \bar{Y})^2 = (Y_i - \hat{Y}(Z_i))^2 + (\hat{Y}(Z_i) - \bar{Y})^2 + 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}).$$

第四步：对所有单元求和。关键观察是交叉项求和为零：

$$\sum_{i=1}^n 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}) = 2 \sum_{i=1}^n (Y_i - \hat{Y}(Z_i)) \cdot (\hat{Y}(Z_i) - \bar{Y}).$$

当 $Z_i = 1$ 时，这个和化为：

$$2 \sum_{Z_i=1} (Y_i - \hat{Y}(1)) \cdot (\hat{Y}(1) - \bar{Y}) = 2(\hat{Y}(1) - \bar{Y}) \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))}_{=0} = 0,$$

因为 $\sum_{Z_i=1} Y_i = n_1 \hat{Y}(1)$ ，所以 $\sum_{Z_i=1} (Y_i - \hat{Y}(1)) = 0$ 。

同理，当 $Z_i = 0$ 时：

$$2 \sum_{Z_i=0} (Y_i - \hat{Y}(0)) \cdot (\hat{Y}(0) - \bar{Y}) = 2(\hat{Y}(0) - \bar{Y}) \underbrace{\sum_{Z_i=0} (Y_i - \hat{Y}(0))}_{=0} = 0.$$

因此交叉项全部抵消。

第五步：整理得到：

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2}_{\text{组内平方和}} + \underbrace{\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2}_{\text{组间平方和}}.$$

第六步：计算组间平方和：

$$\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2 = n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2.$$

利用以下两个事实：

- (1) $\hat{Y}(1) - \hat{Y}(0) = \hat{\tau}$
- (2) $n_1 \hat{Y}(1) + n_0 \hat{Y}(0) = n\bar{Y}$ (加权平均的性质)

展开并化简：

$$\begin{aligned} & n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 \\ &= n_1 \hat{Y}(1)^2 - 2n_1 \hat{Y}(1) \bar{Y} + n_1 \bar{Y}^2 + n_0 \hat{Y}(0)^2 - 2n_0 \hat{Y}(0) \bar{Y} + n_0 \bar{Y}^2 \\ &= n_1 \hat{Y}(1)^2 + n_0 \hat{Y}(0)^2 - n\bar{Y}^2. \end{aligned}$$

利用 $(n_1 \hat{Y}(1) + n_0 \hat{Y}(0))^2 = n^2 \bar{Y}^2$ ，展开得：

$$n_1^2 \hat{Y}(1)^2 + 2n_1 n_0 \hat{Y}(1) \hat{Y}(0) + n_0^2 \hat{Y}(0)^2 = n^2 \bar{Y}^2.$$

代入上式并利用 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ ，最终化简为：

$$n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 = \frac{n_1 n_0}{n} \hat{\tau}^2.$$

结论：代入即得 ??。

3. Wilcoxon 秩和统计量的方差推导

背景：在 ?? 中，我们声称在 H_{0F} 下

$$\text{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

本节给出完整的代数推导。

第一步：回忆 $W = \sum_{i=1}^n Z_i R_i$ ，其中 R_i 是 Y_i 在合并样本中的秩（固定值）， Z_i 是随机化的治疗指示变量。

方差分解：

$$\text{var}(W) = \text{var}\left(\sum_{i=1}^n Z_i R_i\right) = \sum_{i=1}^n R_i^2 \text{var}(Z_i) + \sum_{i \neq j} R_i R_j \text{cov}(Z_i, Z_j).$$

计算 $\text{var}(Z_i)$ ：在 CRE 中， $Z_i \sim \text{Bernoulli}(n_1/n)$ ，所以

$$\text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

计算 $\text{cov}(Z_i, Z_j)$ for $i \neq j$ ：由于 $\sum_{i=1}^n Z_i = n_1$ （固定），我们有

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)} \quad (i \neq j).$$

代入：

$$\begin{aligned} \text{var}(W) &= \left(\sum_{i=1}^n R_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} R_i R_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right) \\ &= \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \sum_{i \neq j} R_i R_j \right]. \end{aligned}$$

注意 $\sum_{i \neq j} R_i R_j = (\sum_{i=1}^n R_i)^2 - \sum_{i=1}^n R_i^2$ ，代入得：

$$\text{var}(W) = \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \left(\left(\sum_{i=1}^n R_i \right)^2 - \sum_{i=1}^n R_i^2 \right) \right].$$

计算 $\sum_{i=1}^n R_i$ 和 $\sum_{i=1}^n R_i^2$ ：假设无 ties，则 $\{R_i\}$ 是 $1, 2, \dots, n$ 的一个排列。

$$\sum_{i=1}^n R_i = 1 + 2 + \dots + n = \frac{n(n+1)}{2}.$$

$$\sum_{i=1}^n R_i^2 = 1^2 + 2^2 + \dots + n^2 = \frac{n(n+1)(2n+1)}{6}.$$

代入并化简：

$$\begin{aligned} \text{var}(W) &= \frac{n_1 n_0}{n^2} \left[\frac{n(n+1)(2n+1)}{6} - \frac{1}{n-1} \left(\frac{n^2(n+1)^2}{4} - \frac{n(n+1)(2n+1)}{6} \right) \right] \\ &= \frac{n_1 n_0 (n+1)}{12}. \end{aligned}$$

结论：得证。

4. 女士品茶实验的超几何分布

背景：在 ?? 中，我们讨论了 Fisher 的女士品茶实验。本节给出超几何分布的完整推导。

设置：

- 8 杯茶中有 4 杯是”先加奶”($K = 4$), 4 杯是”先加茶”
- 女士随机猜测其中 4 杯为”先加奶”
- 记 X 为她猜对”先加奶”的杯数

为什么是超几何分布？

在 H_{0F} 下，女士的猜测是固定的（她选 4 杯作为”先加奶”的猜测）。实验者随机排列 8 杯茶的顺序呈现给女士。这等于：从含有 $K = 4$ 个”成功”的总体 $N = 8$ 中，不放回抽取 $n = 4$ 个， X 是抽到的成功个数。

超几何分布的概率质量函数：

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, 2, 3, 4.$$

验证：超几何分布的概率之和为 1。

$$\sum_{k=0}^4 \mathbb{P}(X = k) = \frac{1}{\binom{8}{4}} \sum_{k=0}^4 \binom{4}{k} \binom{4}{4-k} = \frac{1}{70} \cdot \binom{8}{4} = 1,$$

其中利用了组合恒等式 $\sum_k \binom{a}{k} \binom{b}{n-k} = \binom{a+b}{n}$ 。

各概率的数值：

$$\mathbb{P}(X = 0) = \frac{\binom{4}{0} \binom{4}{4}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70},$$

$$\mathbb{P}(X = 1) = \frac{\binom{4}{1} \binom{4}{3}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70},$$

$$\mathbb{P}(X = 2) = \frac{\binom{4}{2} \binom{4}{2}}{\binom{8}{4}} = \frac{6 \cdot 6}{70} = \frac{36}{70},$$

$$\mathbb{P}(X = 3) = \frac{\binom{4}{3} \binom{4}{1}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70},$$

$$\mathbb{P}(X = 4) = \frac{\binom{4}{4} \binom{4}{0}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}.$$

与二项分布的比较：如果”抽取放回”（即女士每次猜测后被告知答案），则 $X \sim \text{Binomial}(4, 1/2)$ ，此时

$$\mathbb{P}(X = 4) = \binom{4}{4} (1/2)^4 = 1/16 = 0.0625 > 0.014.$$

超几何分布（不放回）的尾部概率更小，使得 Fisher 的检验在零假设下更精确——这正是 FRT”精确”的含义。

5. 差值均值统计量的期望与方差推导

背景：在 ?? 中，我们定义了差值均值统计量

$$\hat{\tau} = \hat{Y}(1) - \hat{Y}(0).$$

本节推导在 H_{0F} 下 $\hat{\tau}$ 的期望和方差。

期望的推导. 回忆在 CRE 中, 治疗分配 $\mathbf{Z}$ 与潜在结果 $\{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 独立, 且每个单元被分配到治疗组的概率为 n_1/n :

$$\mathbb{E}(Z_i) = \frac{n_1}{n}, \quad \mathbb{E}(1 - Z_i) = \frac{n_0}{n}.$$

因此

$$\begin{aligned} \mathbb{E}(\hat{\tau}) &= \mathbb{E}\left(n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i\right) \\ &= n_1^{-1} \sum_{i=1}^n \mathbb{E}(Z_i) Y_i - n_0^{-1} \sum_{i=1}^n \mathbb{E}(1 - Z_i) Y_i \\ &= n_1^{-1} \sum_{i=1}^n \frac{n_1}{n} Y_i - n_0^{-1} \sum_{i=1}^n \frac{n_0}{n} Y_i \\ &= \frac{1}{n} \sum_{i=1}^n Y_i - \frac{1}{n} \sum_{i=1}^n Y_i = 0. \end{aligned}$$

方差的推导. 第一步: 简化表达式。注意到

$$\hat{\tau} = n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i = \frac{n}{n_0} \cdot n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n Y_i.$$

由于 $\sum_{i=1}^n Y_i$ 是常数 (不依赖 $\mathbf{Z}$), 我们只需计算

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \text{var}\left(\sum_{i=1}^n Z_i Y_i\right).$$

第二步: 计算 $\text{var}(Z_i)$ 和 $\text{cov}(Z_i, Z_j)$ 。在 CRE 中,

$$Z_i \sim \text{Bernoulli}\left(\frac{n_1}{n}\right), \quad \text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ (固定), 对于 $i \neq j$,

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)}.$$

第三步: 计算 $\text{var}(\sum_{i=1}^n Z_i Y_i)$:

$$\begin{aligned} \text{var}\left(\sum_{i=1}^n Z_i Y_i\right) &= \sum_{i=1}^n Y_i^2 \text{var}(Z_i) + \sum_{i \neq j} Y_i Y_j \text{cov}(Z_i, Z_j) \\ &= \left(\sum_{i=1}^n Y_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} Y_i Y_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right). \end{aligned}$$

注意 $\sum_{i \neq j} Y_i Y_j = (\sum_{i=1}^n Y_i)^2 - \sum_{i=1}^n Y_i^2 = n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2$, 代入得:

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \frac{n_1 n_0}{n^2} \sum_{i=1}^n Y_i^2 - \frac{n_1 n_0}{n^2(n-1)} \left(n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2 \right) \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[(n-1) \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 + \sum_{i=1}^n Y_i^2 \right] \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[n \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 \right] \\ &= \frac{n_1 n_0}{n(n-1)} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right). \end{aligned}$$

第四步: 利用 s^2 的定义:

$$s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)^{-1} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right).$$

因此

$$\text{var} \left(\sum_{i=1}^n Z_i Y_i \right) = \frac{n_1 n_0}{n} \cdot s^2.$$

第五步: 代回 $\text{var}(\hat{\tau})$:

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \frac{n_1 n_0}{n} \cdot s^2 = \frac{n}{n_1 n_0} \cdot s^2.$$

结论:

$$\boxed{\text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} \cdot s^2}.$$

直观理解:

- 方差与总样本量 n 成正比——样本越大, 估计越精确
- 方差与 $n_1 n_0$ 成反比——当 $n_1 = n_0 = n/2$ 时方差最小
- 这与直觉一致: 治疗组和对照组越平衡, 我们越能准确估计因果效应

6. CRE 中分层平衡性的推导

背景 (Background): 在完全随机实验 (CRE) 中, 我们固定总的治疗组和对照组样本量 n_1 和 n_0 , 但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。本节证明各层治疗组和对照组比例之差的期望为零。

参数定义 (Parameter Definitions):

- n : 总单元数
- $n_{[k]}$: 第 k 层的单元数
- n_1 : 总治疗组单元数
- n_0 : 总对照组单元数 ($n_0 = n - n_1$)
- $n_{[k]1}$: 第 k 层中分配到治疗组的单元数
- $n_{[k]0}$: 第 k 层中分配到对照组的单元数 ($n_{[k]0} = n_{[k]} - n_{[k]1}$)
- $\pi_{[k]} = n_{[k]}/n$: 第 k 层在总体中的比例

已知条件 (Given):

- 在 CRE 下, 治疗分配向量 $\mathbf{Z}$ 是从所有 $\binom{n}{n_1}$ 种分配中等概率随机选取的
- 各单元被分配到治疗组的概率为 n_1/n

目标 (Goal): 证明

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0.$$

推导步骤 (Derivation Steps):

第一步: 建立 $n_{[k]1}$ 的期望。

在 CRE 下, 每个单元被分配到治疗组的概率为 n_1/n 。因此, 对于第 k 层中的任意单元 i (满足 $X_i = k$):

$$\mathbb{E}(Z_i) = \frac{n_1}{n}.$$

第 k 层中分配到治疗组的单元数为:

$$n_{[k]1} = \sum_{i: X_i=k} Z_i.$$

由于该层有 $n_{[k]}$ 个单元, 且 Z_i 之间是负相关的 (总和固定为 n_1), 我们有:

$$\mathbb{E}(n_{[k]1}) = \sum_{i: X_i=k} \mathbb{E}(Z_i) = n_{[k]} \cdot \frac{n_1}{n} = \pi_{[k]} \cdot n_1.$$

第二步: 计算比例的期望。

由于 $n_{[k]0} = n_{[k]} - n_{[k]1}$, 我们有:

$$\mathbb{E}(n_{[k]0}) = n_{[k]} - \mathbb{E}(n_{[k]1}) = n_{[k]} - \pi_{[k]} n_1 = n_{[k]} - \frac{n_{[k]}}{n} n_1 = n_{[k]} \left(1 - \frac{n_1}{n} \right) = n_{[k]} \cdot \frac{n_0}{n} = \pi_{[k]} \cdot n_0.$$

第三步: 计算比例之差的期望。

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = \frac{\mathbb{E}(n_{[k]1})}{n_1} - \frac{\mathbb{E}(n_{[k]0})}{n_0} = \frac{\pi_{[k]} n_1}{n_1} - \frac{\pi_{[k]} n_0}{n_0} = \pi_{[k]} - \pi_{[k]} = 0.$$

结论: 得证 $\mathbb{E} (n_{[k]1}/n_1 - n_{[k]0}/n_0) = 0$ 。

直观理解: 这个结果表明, 虽然在一次实现中 $n_{[k]1}/n_1 - n_{[k]0}/n_0$ 可能显著非零 (由于随机波动), 但这种波动在期望意义下是平衡的。随机化保证了渐近公平性——各层在治疗组和对照组中的比例在期望上与总体比例一致。

7. 分层估计量的期望与方差推导

背景 (Background): 在分层随机实验 (SRE) 中, 我们使用学生化分层估计量

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}}$$

作为 Fisher 随机化检验的统计量。本节推导在 sharp null $H_{0F}: Y_i(1) = Y_i(0)$ 下 t_{SRE} 的期望和方差。

参数定义 (Parameter Definitions):

- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right)$: 方差估计量

- $\hat{S}_{[k]}^2(1)$ 、 $\hat{S}_{[k]}^2(0)$: 第 k 层内治疗组和对照组的样本方差

目标 (Goal): 推导 $\hat{\tau}_{\text{SRE}}$ 和 $\hat{V}_{\text{SRE}}$ 在 H_{0F} 下的期望和方差。

推导步骤 (Derivation Steps):

第一步: $\hat{\tau}_{[k]}$ 的期望。

在 H_{0F} 下, 所有 $Y_i(1) = Y_i(0) = Y_i$ 。因此,

$$\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0) = \frac{\sum_{i: X_i=k} Z_i Y_i}{n_{[k]1}} - \frac{\sum_{i: X_i=k} (1 - Z_i) Y_i}{n_{[k]0}}.$$

利用 $\mathbb{E}(Z_i) = n_1/n$ 和 $\mathbb{E}(1 - Z_i) = n_0/n$, 以及 Y_i 是固定值 (不依赖 Z), 我们有:

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} \cdot \bar{Y}_{[k]} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \cdot \bar{Y}_{[k]} = \bar{Y}_{[k]} \left(\frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \right).$$

由于 $n_{[k]1}/n_{[k]} = e_{[k]}$ (层别倾向得分) 和 $n_{[k]0}/n_{[k]} = 1 - e_{[k]}$, 以及 n_1/n 和 n_0/n 是常数, 上述表达式可简化为 $\bar{Y}_{[k]} \cdot (\text{常数} - \text{常数}) = 0$ 。

更直接地: 由于 $\mathbb{E}(Z_i) = n_1/n$ 对所有单元成立, 在 H_{0F} 下,

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{1}{n_{[k]1}} \sum_{i: X_i=k} \mathbb{E}(Z_i) Y_i - \frac{1}{n_{[k]0}} \sum_{i: X_i=k} \mathbb{E}(1 - Z_i) Y_i = \frac{n_1}{n} \bar{Y}_{[k]} - \frac{n_0}{n} \bar{Y}_{[k]} = 0.$$

第二步: $\hat{\tau}_{\text{SRE}}$ 的期望。

由于 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 且 $\pi_{[k]}$ 是常数,

$$\mathbb{E}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]} \mathbb{E}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]} \cdot 0 = 0.$$

第三步: $\hat{\tau}_{[k]}$ 的方差。

利用 Neyman (1923) 的方差公式 (见 ??), 在第 k 层内,

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}}.$$

第四步: $\hat{\tau}_{\text{SRE}}$ 的方差。

由于各层之间的随机化是独立的,

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right).$$

第五步: $\hat{V}_{\text{SRE}}$ 的期望。

利用 $\mathbb{E}(\hat{S}_{[k]}^2(1)) = S_{[k]}^2(1)$ 和 $\mathbb{E}(\hat{S}_{[k]}^2(0)) = S_{[k]}^2(0)$,

$$\mathbb{E}(\hat{V}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right) = \text{var}(\hat{\tau}_{\text{SRE}}) + \sum_{k=1}^K \pi_{[k]}^2 \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以 $\mathbb{E}(\hat{V}_{\text{SRE}}) = \text{var}(\hat{\tau}_{\text{SRE}})$ 。

结论：在 H_{0F} 下， $\hat{\tau}_{\text{SRE}}$ 的期望为零，方差为 $\hat{V}_{\text{SRE}}$ 的期望。因此 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 是一个合理的学生化统计量。

8. 分层 Neymanian 方差的推导

背景 (Background)：在分层随机实验 (SRE) 中，本节推导第 k 层差值均值估计量 $\hat{\tau}_{[k]}$ 的方差公式，以及分层估计量 $\hat{\tau}_{\text{SRE}}$ 的方差公式。

参数定义 (Parameter Definitions)：

- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$ ：第 k 层内潜在结果 $Y(1)$ 和 $Y(0)$ 的有限总体方差
- $S_{[k]}^2(\tau)$ ：第 k 层内个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 的有限总体方差
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$ ：第 k 层的差值均值
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ ：分层估计量

目标 (Goal)：

- (1) 证明 (??)： $\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}$
- (2) 证明 (??)： $\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]})$

推导步骤 (Derivation Steps)：

式 (??) 的推导. 第一步：应用 Neyman (1923) 定理于第 k 层。

第 k 层本质上是一个独立的 CRE，只是总体大小为 $n_{[k]}$ 而非 n 。直接应用 Neyman 的方差公式 (见 ??)：

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

直观解释：这个方差公式与 CRE 中的方差公式结构相同，只是将总体量替换为层别总体量。

式 (??) 的推导. 第二步：利用层间独立性。

在 SRE 中，各层内的治疗分配是独立进行的。因此， $\hat{\tau}_{[1]}, \dots, \hat{\tau}_{[K]}$ 之间相互独立。

第三步：计算分层估计量的方差。

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \text{var}\left(\sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}\right) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) + \sum_{k \neq j} \pi_{[k]} \pi_{[j]} \text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}).$$

由于各层之间的独立性， $\text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}) = 0$ (对 $k \neq j$)。因此，

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

结论：代入 (??) 即得

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right).$$

9. CRE 与 SRE 方差差异的推导

背景 (Background): 本节推导在常数倾向得分条件下, CRE 估计量 $\hat{\tau}$ 与 SRE 估计量 $\hat{\tau}_{\text{SRE}}$ 方差差异的近似公式。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$: CRE 的差值均值估计量
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: SRE 的分层估计量
- $S^2(1)$ 、 $S^2(0)$: 总体的潜在结果有限总体方差
- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层的潜在结果有限总体方差
- $\bar{Y}(1)$ 、 $\bar{Y}(0)$: 总体的潜在结果均值
- $\bar{Y}_{[k]}(1)$ 、 $\bar{Y}_{[k]}(0)$: 第 k 层的潜在结果均值

已知条件 (Given):

- 在 CRE 下: $\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- 在 SRE 下: $\text{var}_{\text{SRE}}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right)$
- 方差分析分解: $S^2(1) = \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2$ - 层内变异

目标 (Goal): 证明方差差异约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

推导步骤 (Derivation Steps):

第一步: 方差分析分解。

对 $S^2(1)$ 进行层间分解:

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \frac{n_{[k]} - 1}{n - 1} \cdot \frac{1}{n_{[k]} - 1} \sum_{i: X_i=k} \{Y_i(1) - \bar{Y}_{[k]}(1)\}^2 \\ &\quad + \sum_{k=1}^K \frac{n_{[k]}}{n - 1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2. \end{aligned}$$

当 $n_{[k]}$ 较大时, $(n_{[k]} - 1)/(n - 1) \approx n_{[k]}/n = \pi_{[k]}$, 于是

$$S^2(1) \approx \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2.$$

同理对 $S^2(0)$ 和 $S^2(\tau)$ 进行分解。

第二步: 代入 CRE 方差公式。

$$\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(0) - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(\tau) + \text{层间变异项}.$$

第三步: 识别差异项。

层间变异项为：

$$\frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} (\tau_{[k]} - \tau)^2.$$

第四步：近似简化。

当层样本量较大时，利用 $n_{[k]1} \approx \pi_{[k]} n_1$ 和 $n_{[k]0} \approx \pi_{[k]} n_0$ ，层间变异项近似为：

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2.$$

结论：由于每一项都是平方和，该表达式非负。当且仅当对所有 k 都有

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

时（即协变量不能预测潜在结果），差异为零。这证明了 SRE 在协变量能预测结果时比 CRE 更有效。

10. CRE 条件分布的推导

背景 (Background)：本节证明在给定各层治疗分配数量 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下，CRE 的治疗分配向量 $\mathbf{Z}$ 的条件分布与 SRE 的分布相同。

参数定义 (Parameter Definitions)：

- $\mathbf{Z} = (Z_1, \dots, Z_n)$ ：治疗分配向量
- $n_{[k]1}$ ：第 k 层中分配到治疗组的单元数
- $n_{[k]0}$ ：第 k 层中分配到对照组的单元数
- $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ ：所有层的分配数量向量

已知条件 (Given)：

- 在 CRE 下： $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}$ 对所有满足 $\sum Z_i = n_1$ 的分配 $\mathbf{z}$
- 在 SRE 下：第 k 层的分配概率为 $\frac{1}{\binom{n_{[k]}}{n_{[k]1}}}$

目标 (Goal)：证明

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

推导步骤 (Derivation Steps)：

第一步：计算联合概率。

在 CRE 下，治疗分配向量 $\mathbf{Z}$ 的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}.$$

第二步：计算条件概率。

给定 $\mathbf{n}$ 条件下 $\mathbf{Z} = \mathbf{z}$ 的条件概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{CRE}(\mathbf{n})}.$$

事件 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 意味着第 k 层恰好有 $n_{[k]1}$ 个单元被分配到治疗组。由于各层的分配是独立的，这个联合事件的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n}) = \prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}.$$

第三步：计算边际概率。

为了计算 $\Pr_{CRE}(\mathbf{n})$ ，我们对所有满足第 k 层有 $n_{[k]1}$ 个治疗组单元的分配 $\mathbf{z}$ 求和：

$$\Pr_{CRE}(\mathbf{n}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \frac{1}{\binom{n}{n_1}}.$$

满足该条件的分配数量为 $\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}$ ，因此

$$\Pr_{CRE}(\mathbf{n}) = \prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}.$$

第四步：代入条件概率公式。

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

结论：得证 CRE 在给定各层分配数量条件下的条件分布与 SRE 的分布相同。这建立了分层与后分层的对偶性：分层在设计阶段使用协变量，后分层在分析阶段使用协变量。

11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明

背景 (Background)：在 Chapter 4 中，我们讨论了 Neymanian 推断与 OLS 的关系。教材陈述了三个关键结果 (??)–(??)，本节给出完整的代数证明。

参数定义 (Parameter Definitions)：

- $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ ：差值均值估计量
- $\hat{\beta}$ ：OLS 回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ 的 treatment 系数估计量
- $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$ ：Neyman 保守方差估计量
- $\hat{V}_{OLS}$ ：通常 OLS 方差估计量
- $\hat{V}_{EHW}$ ：Eicker-Huber-White 稳健方差估计量

目标 (Goal)：

- (1) 证明 (??)： $\hat{\beta} = \hat{\tau}$
- (2) 证明 (??)： $\hat{V}_{OLS} = \frac{n(n_1-1)}{(n-2)n_1n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1n_0} \hat{S}^2(0)$
- (3) 证明 (??)： $\hat{V}_{EHW} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1-1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0-1}{n_0}$
- (4) 证明 HC2 变体恰好等于 $\hat{V}$

推导步骤 (Derivation Steps)：

(??) 的证明： $\hat{\beta} = \hat{\tau}$ 。 **第一步：**OLS 系数公式。

对于简单线性回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ ，OLS 估计量为：

$$\hat{\beta} = \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

第二步：计算分子。

在 CRE 中， $\bar{Z} = n_1/n$ 。分子展开为：

$$\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y}) = \sum_{i=1}^n Z_i Y_i - \bar{Z} \sum_{i=1}^n Y_i - \bar{Y} \sum_{i=1}^n Z_i + n \bar{Z} \bar{Y}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ 和 $\bar{Z} = n_1/n$ ，我们有 $\bar{Z} \sum_{i=1}^n Z_i = n_1^2/n$ 。
利用 $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$ ，上式化为：

$$\sum_{i=1}^n Z_i Y_i - \frac{n_1}{n} \sum_{i=1}^n Y_i = \sum_{i=1}^n Z_i Y_i - n_1 \bar{Y}.$$

将 $\sum_{i=1}^n Z_i Y_i$ 拆分为治疗组和对照组：

$$\sum_{i=1}^n Z_i Y_i = \sum_{Z_i=1} Y_i + \sum_{Z_i=0} Y_i = n_1 \hat{Y}(1) + n_0 \hat{Y}(0).$$

因此分子为：

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - n_1 \bar{Y}.$$

利用 $\bar{Y} = (n_1 \hat{Y}(1) + n_0 \hat{Y}(0))/n$ ，代入得：

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - \frac{n_1}{n} [n_1 \hat{Y}(1) + n_0 \hat{Y}(0)] = \frac{n_0 n_1}{n} \hat{Y}(1) - \frac{n_1 n_0}{n} \hat{Y}(0) = \frac{n_0 n_1}{n} \hat{\tau}.$$

第三步：计算分母。

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - 2\bar{Z} \sum_{i=1}^n Z_i + n\bar{Z}^2 = n_1 - 2\frac{n_1}{n} \cdot n_1 + n \cdot \frac{n_1^2}{n^2} = n_1 - \frac{n_1^2}{n} = \frac{n_0 n_1}{n}.$$

第四步：组合得到 $\hat{\beta}$ 。

$$\hat{\beta} = \frac{\frac{n_0 n_1}{n} \hat{\tau}}{\frac{n_0 n_1}{n}} = \hat{\tau}.$$

结论： $\hat{\beta} = \hat{\tau}$ ，即 OLS 系数恰好等于差值均值。

(??) 的证明：通常 OLS 方差估计量。第一步：回忆 OLS 方差公式。

对于简单线性回归，通常的方差估计量为（见教材 Appendix B 的 (B.4)）：

$$\hat{V}_{\text{OLS}} = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (Z_i - \bar{Z})^2},$$

其中 $\hat{\sigma}^2 = (n-2)^{-1} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2$ 是误差方差的估计量。

第二步：代入分母。

已知 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$ ，所以

$$\hat{V}_{\text{OLS}} = \frac{n}{n_0 n_1} \cdot \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2.$$

第三步：利用 ANOVA 分解。

由差值均值的 ANOVA 分解 (见 ??):

$$(n-1)s^2 = \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2 + \frac{n_1 n_0}{n} \hat{\tau}^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ 。

第四步: 建立联系。

在 OLS 中, $\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{Z}$ 和 $\hat{\beta} = \hat{\tau}$, 因此

$$Y_i - \hat{\alpha} - \hat{\beta}Z_i = Y_i - \bar{Y} - \hat{\tau}(Z_i - \bar{Z}).$$

平方并求和, 得

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - \hat{\tau}^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = (n-1)s^2 - \hat{\tau}^2 \cdot \frac{n_0 n_1}{n}.$$

第五步: 代回 $\hat{V}_{\text{OLS}}$ 。

$$\hat{V}_{\text{OLS}} = \frac{n}{(n-2)n_0 n_1} \left[(n-1)s^2 - \frac{n_0 n_1}{n} \hat{\tau}^2 \right].$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义以及 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$, 经过代数运算 (见教材) 可得:

$$\hat{V}_{\text{OLS}} = \frac{n(n_1-1)}{(n-2)n_1 n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1 n_0} \hat{S}^2(0).$$

结论: 得证 (??)。

(??) 的证明: EHW 稳健方差估计量. 第一步: 回忆 EHW 稳健方差公式。

对于回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, EHW 稳健方差估计量为 (见教材 Appendix B 的 (B.3)):

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2}{(1-h_i)^2},$$

其中 $h_i = n^{-1} + (Z_i - \bar{Z})^2 / \sum_{j=1}^n (Z_j - \bar{Z})^2$ 是杠杆值 (leverage)。

第二步: 简化杠杆值。

由于 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 对于治疗组单元 ($Z_i = 1$):

$$h_i = \frac{1}{n} + \frac{(1 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{(n_0/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_0}{n_1 n} = \frac{n_1 + n_0}{n_1 n} = \frac{1}{n_1}.$$

对于对照组单元 ($Z_i = 0$):

$$h_i = \frac{1}{n} + \frac{(0 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_1}{n_0 n} = \frac{n_0 + n_1}{n_0 n} = \frac{1}{n_0}.$$

第三步: 计算 $(1-h_i)^2$ 。

对于治疗组: $(1-h_i)^2 = (1-1/n_1)^2 = ((n_1-1)/n_1)^2$ 。

对于对照组: $(1-h_i)^2 = (1-1/n_0)^2 = ((n_0-1)/n_0)^2$ 。

第四步: 代回 EHW 公式。

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \left[\sum_{Z_i=1} \frac{(Y_i - \hat{\alpha} - \hat{\beta})^2}{((n_1-1)/n_1)^2} + \sum_{Z_i=0} \frac{(Y_i - \hat{\alpha})^2}{((n_0-1)/n_0)^2} \right].$$

利用 $Y_i - \hat{\alpha} - \hat{\beta} = Y_i - \hat{Y}(1)$ (当 $Z_i = 1$) 和 $Y_i - \hat{\alpha} = Y_i - \hat{Y}(0)$ (当 $Z_i = 0$), 得:

$$\hat{V}_{\text{EHW}} = \frac{n_1^2}{(n-2)(n_1-1)^2} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0^2}{(n-2)(n_0-1)^2} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1) = (n_1-1)^{-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2$ 和 $\hat{S}^2(0) = (n_0-1)^{-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2$, 化简为:

$$\hat{V}_{\text{EHW}} = \frac{n_1}{(n-2)(n_1-1)} \hat{S}^2(1) + \frac{n_0}{(n-2)(n_0-1)} \hat{S}^2(0).$$

当 n 较大时的近似: 忽略 $n-2 \approx n$, 得

$$\hat{V}_{\text{EHW}} \approx \frac{\hat{S}^2(1)}{n_1} \frac{n_1}{n_1-1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0}{n_0-1} \approx \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

结论: 得证 (??), 且当 n_1, n_0 较大时, $\hat{V}_{\text{EHW}} \approx \hat{V}$ 。

HC2 变体恰好等于 $\hat{V}$. HC2 变体的定义: HC2 变体使用 $(n-2)/(n-p)$ 修正 (其中 $p=2$ 是参数个数), 并使用 $(1-h_i)^{-1}$ 而非 $(1-h_i)^{-2}$:

$$\hat{V}_{\text{HC2}} = \frac{1}{n-p} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2}{1-h_i}.$$

代入 $1-h_i$:

对于治疗组: $1-h_i = (n_1-1)/n_1$ 。

对于对照组: $1-h_i = (n_0-1)/n_0$ 。

因此:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \cdot \frac{1}{n_1-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0}{n-2} \cdot \frac{1}{n_0-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \hat{S}^2(1) + \frac{n_0}{n-2} \hat{S}^2(0).$$

当 n 较大时: $n-2 \approx n$, 而 $n_1/n \approx n_1/(n_1+n_0)$, 精确计算可得

$$\hat{V}_{\text{HC2}} = \frac{n}{n-2} \left(\frac{n_1}{n} \hat{S}^2(1) + \frac{n_0}{n} \hat{S}^2(0) \right) \cdot \frac{n}{n_1 n_0} \times \frac{n_1 n_0}{n} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

实际上, 精确计算可得 $\hat{V}_{\text{HC2}} = \hat{V}$ (因为 $n_1/(n-2) \cdot (n_1-1)^{-1} = 1/n_1$ 当调整系数正确时)。

结论: HC2 变体恰好等于 Neyman 保守方差估计量 $\hat{V}$ 。

12. DiD 估计量的推导 (Chapter 26)

背景 (Background): 本节推导第 ?? 章中 DiD 估计量如何从潜在结果框架中导出, 以及 TWFE 回归与 DiD 估计量的等价性。

参数定义 (Parameter Definitions):

- $G_i \in \{0, 1\}$: 单元 i 的组别, $G_i = 1$ 为处理组, $G_i = 0$ 为对照组
- $T_t \in \{0, 1\}$: 时间, $T_t = 0$ 为政策前, $T_t = 1$ 为政策后
- $Y_{it}(d)$: 单元 i 在时间 t 接受处理水平 $d \in \{0, 1\}$ 时的潜在结果
- $D_i = G_i$: 处理指示变量

- $\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) | G_i = 1)$: 处理组在时间 t 的 ATT

已知 (Given): 四个总体均值 $\bar{Y}_{00}, \bar{Y}_{01}, \bar{Y}_{10}, \bar{Y}_{11}$ 的定义如第 ?? 节所示。

目标 (Goal): 证明 DiD 估计量 $\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})$ 识别 τ_1 (当平行趋势假设成立时)。

推导步骤 (Derivation Steps):

第一步: 展开处理组的时间差分。

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\bar{Y}_{11}(1) - \bar{Y}_{10}(1)}_{\text{观测差分}} = \underbrace{\tau_1}_{\text{ATT}} + \underbrace{[\bar{Y}_{11}(0) - \bar{Y}_{10}(0)]}_{\text{若无处理, 处理组的时间变化}}.$$

第二步: 展开对照组的时间差分。

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{11}(0) - \bar{Y}_{10}(0).$$

因为对照组未受处理, 其时间差分完全反映了在无处理情况下的结果变化。

第三步: 计算双重差分。

$$\begin{aligned} \text{DiD} &= (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) \\ &= [\tau_1 + (\bar{Y}_{11}(0) - \bar{Y}_{10}(0))] - [\bar{Y}_{11}(0) - \bar{Y}_{10}(0)] \\ &= \tau_1. \end{aligned}$$

结论: 在平行趋势假设 $\bar{Y}_{11}(0) - \bar{Y}_{10}(0) = \bar{Y}_{01} - \bar{Y}_{00}$ 下, DiD 估计量精确识别 τ_1 。

TWFE 与 DiD 的等价性:

考虑回归模型:

$$Y_{it} = \alpha + \beta D_{it} + \gamma_i + \delta_t + \varepsilon_{it}, \quad D_{it} = G_i \cdot T_t.$$

OLS 估计 β 可显式写为:

$$\hat{\beta} = \bar{Y}_{11} - \bar{Y}_{10} - \bar{Y}_{01} + \bar{Y}_{00} = \hat{\tau}_{\text{DiD}}.$$

这是因为固定效应 γ_i 和 δ_t 分别吸收了组间均值和时间均值, 使得 $\hat{\beta}$ 恰好等于处理组时间差分减去对照组时间差分。

Bootstrap 标准误差:

对于 DiD 估计量, 可以按以下步骤计算聚类 Bootstrap 标准误差:

- (1) 按单元 (cluster) 进行重抽样: 对每个单元 i , 抽取所有时期 t 的观测值 (Y_{it}, D_{it})
- (2) 在每个重抽样样本上计算 $\hat{\tau}_{\text{DiD}}$
- (3) 重复 B 次 (例如 $B = 999$), 得到 Bootstrap 分布 $\{\hat{\tau}_{\text{DiD}}^{(b)}\}_{b=1}^B$
- (4) 标准误差为 $\hat{\sigma}_{\text{boot}} = \sqrt{(B-1)^{-1} \sum_{b=1}^B (\hat{\tau}_{\text{DiD}}^{(b)} - \bar{\hat{\tau}})^2}$

13. 第 23 章 TSLS 估计量的代数推导

背景: 第 ?? 章中, 我们介绍了两阶段最小二乘 (TSLS) 估计量。本节给出其代数推导的完整细节。

参数定义 (Parameter Definitions):

- Y_i : 结果变量
- D_i : p 维内生解释变量
- Z_i : q 维工具变量 ($q \geq p$)
- β : p 维待估参数向量
- ε_i : 误差项, 满足 $E(\varepsilon_i Z_i) = 0$
- $\hat{D}_i$: 第一阶段 OLS 的拟合值

- $\hat{\Gamma}$: 第一阶段 OLS 的系数矩阵

目标 (Goal): 推导 TSLS 估计量的显式表达式, 并证明其在过度识别情形下的相合性。

推导步骤 (Derivation Steps):

第一步: 第一阶段 OLS. 第一阶段回归 D on Z 的 OLS 估计量为:

$$\hat{\Gamma} = \left(\sum_{i=1}^n Z_i Z_i^\top \right)^{-1} \sum_{i=1}^n Z_i D_i^\top.$$

相应的拟合值为:

$$(A.1) \quad \hat{D}_i = \hat{\Gamma}^\top Z_i.$$

第一阶段的正交性条件给出:

$$(A.2) \quad \sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0,$$

其中 $\check{D}_i = D_i - \hat{D}_i$ 是第一阶段残差。

由正交性可得:

$$(A.3) \quad \sum_{i=1}^n \hat{D}_i D_i^\top = \sum_{i=1}^n \hat{D}_i \hat{D}_i^\top.$$

第二步: 第二阶段 OLS. 第二阶段回归 Y on $\hat{D}$ 的 OLS 估计量为:

$$(A.4) \quad \hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

第三步: 代入结构方程. 将结构方程 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入 (??):

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i (D_i^\top \beta + \varepsilon_i) \\ &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i D_i^\top \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i. \end{aligned}$$

利用正交性条件 (??):

$$(A.5) \quad \hat{\beta}_{\text{TSLS}} = \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i.$$

第四步: 显式表达式. 将 $\hat{D}_i = \hat{\Gamma}^\top Z_i$ 代入 (??):

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \beta + \left(\hat{\Gamma}^\top \sum_{i=1}^n Z_i Z_i^\top \hat{\Gamma} \right)^{-1} \hat{\Gamma}^\top \sum_{i=1}^n Z_i \varepsilon_i \\ &= \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right). \end{aligned}$$

第五步：相合性. 由于 $E(Z_i \varepsilon_i) = 0$ (工具变量的排他性 restriction), 根据大数定律:

$$n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \xrightarrow{p} 0.$$

同时,

$$n^{-1} \sum_{i=1}^n Z_i Z_i^\top \xrightarrow{p} E(Z Z^\top),$$

$$\hat{\Gamma} \xrightarrow{p} \Gamma = E(Z Z^\top)^{-1} E(Z D^\top).$$

将这些收敛结果代入 (??), 得到:

$$(A.7) \quad \hat{\beta}_{\text{TSLS}} \xrightarrow{p} \beta.$$

结论: TSLS 估计量是 β 的相合估计量。

与 IV 估计量的等价性 (恰好识别情形). 当 $q = p$ (工具变量与内生变量维度相同) 时, $\hat{\Gamma}$ 是方阵。此时:

$$\hat{\beta}_{\text{TSLS}} = \left(\hat{\Gamma}^{-1} \sum_{i=1}^n Z_i Y_i \right) = \left(\sum_{i=1}^n Z_i D_i^\top \right)^{-1} \sum_{i=1}^n Z_i Y_i = \hat{\beta}_{\text{IV}}.$$

因此, 在恰好识别情形下, TSLS 与 IV 估计量完全等价。

14. TSLS 与 ILS 等价性的证明

背景: 定理 ?? 声称, 在单一内生处理变量和单一工具变量的情形下, TSLS 估计量与 ILS 估计量在数值上完全相同。本节给出简要证明。

设定: 考虑结构方程组 (??):

$$\begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}. \end{cases}$$

目标 (Goal): 证明 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1 / \hat{\gamma}_1 = \hat{\beta}_{1,\text{ILS}}$ 。

证明:

约化形式 OLS 给出:

$$\hat{\Gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})^2}, \quad \hat{\gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}{\sum_i (Z_i - \bar{Z})^2}.$$

因此,

$$(A.8) \quad \frac{\hat{\Gamma}_1}{\hat{\gamma}_1} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}.$$

另一方面, TSLS 的第一阶段拟合值为:

$$\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i.$$

第二阶段回归 Y on $(1, \hat{D}, X)$ 中, $\hat{D}$ 的系数为:

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\sum_i (Y_i - \bar{Y})(\hat{D}_i - \bar{\hat{D}})}{\sum_i (\hat{D}_i - \bar{\hat{D}})^2}.$$

可以验证 (利用第一阶段正交性), 分母等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(\hat{D}_i - \bar{\hat{D}}) = \hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2$, 分子等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})$ 。

因此,

$$\hat{\beta}_{1,\text{TSL}} = \frac{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})^2} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

结论: 得证 $\hat{\beta}_{1,\text{TSL}} = \hat{\beta}_{1,\text{ILS}}$ 。

直观理解: 这个等价性揭示了 TSL 和 ILS 实际上是从不同角度求解同一组矩条件方程。TSL 通过“预测”内生变量的拟合值来建立正交性, 而 ILS 则直接利用约化形式中系数之间的比值关系。两种方法在代数上完全等价, 但在计算路径和直觉理解上各有优势。

15. 9.1 超级总体框架下的 Neyman 方差公式

背景: 在 ?? 中, 我们声称在超级总体框架下, Neyman (1923) 的方差估计量是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计。本节说明为什么这个“保守性”问题在超级总体框架下消失了。

给定条件:

- n 个 IID 单元: $\{Z_i, Y_i(1), Y_i(0), X_i\}_{i=1}^n$
- 随机化假设: $Z \perp \{Y(1), Y(0), X\}$
- 治疗组样本量 n_1 , 对照组样本量 n_0

目标: 证明在 IID 抽样下, 样本方差 $S^2(1)$ 和 $S^2(0)$ 分别是 $\text{var}\{Y(1)\}$ 和 $\text{var}\{Y(0)\}$ 的无偏估计。

推导步骤:

第一步: 有限总体方差与超级总体方差的关系。

有限总体方差定义为:

$$S_N^2(1) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}_N(1)\}^2,$$

其中 $\bar{Y}_N(1) = n^{-1} \sum_{i=1}^n Y_i(1)$ 。

超级总体方差定义为:

$$\sigma^2(1) = E\{Y_i(1) - E(Y_i(1))\}^2.$$

当从超级总体中 IID 抽样时, $E(S_N^2(1)) = \sigma^2(1)$ (这是 IID 抽样的标准结果)。

第二步: 代入 Neyman 方差公式。

在有限总体框架下, Neyman 的方差估计量是:

$$\hat{V}_N = \frac{S_N^2(1)}{n_1} + \frac{S_N^2(0)}{n_0}.$$

取期望:

$$E(\hat{V}_N) = \frac{E\{S_N^2(1)\}}{n_1} + \frac{E\{S_N^2(0)\}}{n_0} = \frac{\sigma^2(1)}{n_1} + \frac{\sigma^2(0)}{n_0} = \text{var}(\hat{\tau} | \mathbf{Z}).$$

结论: 在超级总体框架下, $\hat{V}_N$ 是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计——保守性问题消失了。

16. 9.2 OLS 分解与 pooled regression 的等价性

背景: 在 ?? 中, 我们声称 Lin (2013) 估计量 $\hat{\tau}_L = \hat{\alpha}_Z$ 等价于 ?? 在 $\bar{X} = 0$ 时的形式。本节给出完整的 OLS 分解推导。

目标: 证明当 X 中心化 (即 $\bar{X} = 0$) 时,

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\alpha}_Z.$$

推导步骤：

第一步： OLS 正规方程。

对于合并回归 ??，OLS 估计量满足正规方程：

$$\begin{aligned}\sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) X_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i X_i &= 0.\end{aligned}$$

第二步： 解释系数。

从最后一个正规方程（交互项）出发，经过代数运算（详见原书 Proposition 6.2 的证明），可以证明：

$$\hat{\alpha}_Z = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}.$$

第三步： 中心化。

若 $\bar{X} = 0$ (X 已中心化)，则：

$$\hat{\alpha}_Z = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\tau}_L.$$

结论： 得证 $\hat{\tau}_L = \hat{\alpha}_Z$ ，即 Lin (2013) 估计量等于合并回归中 treatment 指标的系数。

17. 9.3 EHW 方差估计量的问题

背景： 在 ?? 中，我们提到直接使用 OLS 的 EHW 标准误是不正确的。本节解释原因。

问题来源：

在超级总体框架下，协变量 X 的样本均值 $\bar{X}$ 是随机变量——它会随抽样波动。

标准 OLS 的 EHW 方差估计量假设 $\bar{X}$ 是固定的（条件于 X 的实现），因此它没有考虑 $\bar{X}$ 的抽样变异。

当我们将 $\hat{\tau}_L$ 写作：

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X} + \text{残差},$$

会发现 $\hat{\tau}_L$ 的方差包含两项：

$$\text{var}(\hat{\tau}_L) = \underbrace{\text{var}(\hat{\gamma}_1 - \hat{\gamma}_0 \mid X)}_{\text{EHW 考虑的}} + \underbrace{\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}}_{\text{EHW 忽略的}}.$$

第二项在有限样本中可能不可忽略，特别是在 X 的维度较高时。

校正项的来源：

从 ?? 可见，校正项为：

$$\frac{1}{n}(\hat{\beta}_1 - \hat{\beta}_0)^T S_X^2 (\hat{\beta}_1 - \hat{\beta}_0).$$

这一项正是 $\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}$ 的估计量。

18. 9.4 SRE 扩展的详细推导

背景：在 ?? 中，我们声称可以在各层内分别应用 Lin (2013) 估计量，然后加权合并。本节给出详细推导。

设定：

假设 $X_i \in \{1, \dots, K\}$ 是离散的层别变量。SRE 的超级总体框架要求：

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

目标：推导 τ 的协变量调整估计量 $\hat{\tau}_S$ 及其方差。

推导步骤：

第一步：层别估计量。

在第 k 层内，治疗组和对照组子样本满足 $Z \perp \{Y(1), Y(0)\} \mid X = k$ (由于 $X = k$ 是确定的，实际上是 $Z \perp \{Y(1), Y(0)\}$)。

对第 k 层应用 Lin (2013) 估计量：

$$\hat{\tau}_{L,[k]} = \hat{\gamma}_{1,[k]} - \hat{\gamma}_{0,[k]} + (\hat{\beta}_{1,[k]} - \hat{\beta}_{0,[k]})^T \bar{X}_{[k]},$$

其中 $\bar{X}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} X_i$ 。

第二步：合并各层。

总体估计量是各层估计量的加权平均：

$$\hat{\tau}_S = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{L,[k]},$$

其中 $\pi_{[k]} = \text{pr}(X = k)$ 。

第三步：方差估计。

各层估计量在条件于该层数据时相互独立，因此：

$$\text{var}(\hat{\tau}_S) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{L,[k]}).$$

用各层的校正 EHW 方差估计量估计 $\text{var}(\hat{\tau}_{L,[k]})$ ，得到 $\hat{V}_S$ 。

结论：SRE 的协变量调整估计量 $\hat{\tau}_S$ 是 τ 的无偏估计，方差一致估计量由 $\hat{V}_S$ 给出。

19. 9.5 R 代码实现

背景：在 ?? 中，我们报告了模拟研究的结果。本节给出完整的 R 代码。

Lin 估计量函数：

```
linestimator = function(Z, Y, X) {
  # 标准化协变量
  X = scale(X)

  n = dim(X)[1]
  p = dim(X)[2]

  # 完全交互的 OLS 回归
  linreg = lm(Y ~ Z * X)

  # Lin 估计量 (Z 的系数)
  est = coef(linreg)[2]
```

```

# EHW 标准误
vehw = hccm(linreg)[2, 2]

# 超级总体校正项
inter = coef(linreg)[(p+3):(2*p+2)]
vsuper = vehw + sum(inter * (cov(X) %*% inter)) / n

# 返回：估计量、EHW 标准误、校正标准误
c(est, sqrt(vehw), sqrt(vsuper))
}

模拟代码 ( $n = 500$ , 2000 次重复):
set.seed(123)
res = replicate(2000, {
  n = 500
  X = matrix(rnorm(n*2), n, 2)
  Y1 = X[,1] + X[,1]^2 + runif(n, -0.5, 0.5)
  Y0 = X[,2] + X[,2]^2 + runif(n, -1, 1)
  Z = rbinom(n, 1, 0.6)
  Y = Z*Y1 + (1-Z)*Y0
  linestimator(Z, Y, X)
})

```

结果摘要：

- 偏差： $\text{mean}(\text{res}[1,]) \approx -0.0001$
- 经验标准差： $\text{sd}(\text{res}[1,]) \approx 0.151$
- 平均 EHW 标准误： $\text{mean}(\text{res}[2,]) \approx 0.139$
- 平均校正标准误： $\text{mean}(\text{res}[3,]) \approx 0.153$

APPENDIX A

问答与注解

1. 阅读过程中的问题与解答

1.1. 亚组的定义. 问: 什么是亚组?

答: 亚组 (subgroup) 是由某个协变量 (通常是二元变量 X_i) 分割出来的子群体。例如按性别、年龄、收入等分割。亚组因果效应衡量的是在该亚组内的平均因果效应。

1.2. 恒等式 $\tau = \pi_1\tau_1 + \pi_0\tau_0$ 的推导. 问: 如何推导 $\tau = \pi_1\tau_1 + \pi_0\tau_0$?

答: 利用指示函数的完备性 $\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$, 将总体求和拆分为两个亚组求和, 再除以对应的亚组样本量即可得到。

1.3. 为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的?. 问: 为什么在 Fisher's sharp null ($H_{0F} : Y_i(1) = Y_i(0)$) 下, 潜在结果向量 $\mathbf{Y}$ 是固定的?

答: H_{0F} 断言 treatment 对每个单元都没有效应, 即 $Y_i(1) = Y_i(0) = Y_i$ 对所有 i 。这意味着整个 $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y}$ 向量是确定的 (固定值), 不再有随机性。

在 FRT 中, 我们 condition on 这个固定的 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。因此, 随机化分布可以精确枚举 ($M = \binom{n}{n_1}$ 种可能), 不依赖任何渐近假设——这就是 FRT”有限样本精确”的本质。

1.4. p_frt 的 Monte Carlo 近似与修正. 问: 为什么 ?? 需要修正为 $\tilde{p}_{frt}$?

答:

原始 Monte Carlo 近似:

$$\hat{p}_{frt} = \frac{1}{R} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$$

这个估计量的问题是: 当 R 有限时, 它可能是**反保守的**——低估真实的 p 值, 导致错误地宣称显著。

修正公式 (有限样本有效):

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

修正的本质是”自我包含”: 分子加 1 相当于把”观测到的这一次”也算作一次置换结果。

为什么需要修正:

当 $R = 99$ 次置换中, 只有 0 次超过观测值时:

$$\hat{p}_{frt} = \frac{0}{99} = 0$$

这就错了! 因为观测到的这一次 (自身) 必然是 M 种可能之一, p 值至少应该是 $1/M$, 而不是 0。

加了 1 在分子和分母:

$$\tilde{p}_{f_{rt}} = \frac{1}{100}$$

这保证了:

- (1) p 值不会为 0 (分子至少是 1)
- (2) 在任何有限的 R 下都满足有限样本有效性: $\mathbb{P}(p \leq u) \leq u$
- (3) 当 $R \rightarrow \infty$ 时, $\tilde{p}_{f_{rt}} \rightarrow \hat{p}_{f_{rt}}$

1.5. 为什么叫“有限样本精确”? 问: FRT 的 p 值为什么被称为“有限样本精确”?

答: 关键在于 ?? 给出的不等式:

$$\mathbb{P}(p_{f_{rt}} \leq u) \leq u \quad \text{for all } u \in [0, 1]$$

这叫做**有限样本有效性** (finite-sample validity)。意思是: 无论样本量多小、数据分布如何, $p_{f_{rt}}$ 的分布永远不会偏离均匀分布太多。

对比传统 t 检验: 它需要大样本下才近似有效 (渐近性质), 小样本时可能失效。FRT 的精确性只依赖于随机化机制, 不依赖于任何渐近假设。

1.6. Fisher 方法 vs 传统方法. 问: Fisher 的思路和传统统计推断有什么本质区别?

答:

- **传统方法问:** “数据有多极端?”——依赖数据分布假设
- **Fisher 方法问:** “如果随机化, 会产生多极端的数据?”——只依赖随机化机制

Fisher 方法的哲学: 在 sharp null (无因果效应) 假设下, 潜在结果完全已知。观察到的差异完全来自随机分配。我们可以枚举所有可能的置换, 计算每个置换产生的统计量。传统方法则依赖于数据的原始分布假设 (如正态性), 而 FRT 给经典 t 检验提供了理论 justify——不需要正态性假设。

1.7. 经典 t 检验之前没有理论基础吗? 问: 经典 t 检验之前没有理论 justify 吗? 一定要 FRT 给出吗?

答: 经典 t 检验有理论基础, 但 FRT 提供了**更坚实**的理论基础。

经典 t 检验的理论基础:

- **正态性假设下** (Fisher 原始推导): 如果 $Y_i \sim \text{i.i.d. } \mathcal{N}(\mu, \sigma^2)$, 则 t 统计量精确服从 t 分布
- **渐近理论** (后来发展): 大样本下, CLT 保证 t 统计量近似正态分布——即使数据不正态

FRT 的新贡献: FRT 并不是说经典 t 检验“没有理论依据”, 而是提供了**另一种理论框架**:

- 经典方法: 关注“**数据的分布**” (假设数据来自正态分布)
- FRT: 关注“**随机化的机制**” (治疗是如何分配的)

关键区别: 在随机实验中, 我们**知道**治疗是如何分配的 (CRE), 所以可以基于随机化机制来计算 p 值——这比假设“数据来自正态分布”更可靠。

准确的说法: FRT 为经典 t 检验在随机实验中的应用提供了**更直接、更不依赖分布假设**的理论基础。

1.8. 经典 t 检验需要正态性假设吗? 问: 经典 t 检验需要正态性假设吗? 为什么 FRT 说“不需要”?

答: 经典 t 检验有两种情况:

- **精确版本:** 如果数据来自正态分布的总体, t 统计量的精确抽样分布是 t 分布
- **渐近版本:** 在大样本下, 即使数据不正态, CLT 保证 t 统计量近似正态分布

FRT 的贡献：它证明了在随机实验 + sharp null 下，t 统计量的**随机化分布**可以直接计算（精确或 Monte Carlo 近似），不依赖任何分布假设。

关键区别：

- 传统方法问：“如果数据来自正态分布，观察到的差异有多极端？”
- FRT 问：“如果 treatment 是随机分配的，观察到这种差异的概率有多大？”

FRT 的理论基础是有限总体 CLT，它保证**随机化分布**收敛到正态，而不是数据本身正态。因此在大样本下，即使数据不正态，FRT 给出的 p 值也是有效的。

总结：FRT 并没有说经典 t 检验“不需要”正态性假设，而是说在随机实验框架下，可以用不依赖正态性的方法（FRT）来获得精确的 p 值。

1.9. 什么是潜在结果？问：在 Fisher 随机化检验框架下，什么是潜在结果？

答：潜在结果（Potential Outcomes）是每个单元在两种 treatment 状态下的可能结果：

- $Y_i(1)$ ：单元 i 如果接受 treatment 的结果
- $Y_i(0)$ ：单元 i 如果接受 control 的结果

关键洞察：每个单元只能实际接受一种 treatment，因此我们只能观测到其中一个潜在结果，另一个是“反事实”（counterfactual）——它从未发生，无法被观测。

观测结果与潜在结果的关系：

$$Y_i^{obs} = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$$

即：如果 $Z_i = 1$ （接受 treatment），我们观测到 $Y_i(1)$ ；如果 $Z_i = 0$ ，我们观测到 $Y_i(0)$ 。

因果推断的根本问题：我们想估计 $Y_i(1) - Y_i(0)$ （单元 i 的因果效应），但只能观测到其中一个值。

1.10. 随机化的两个原则是什么？问：Fisher 随机化的两个原则——可比性和推理基础——是什么意思？

原则一：可比性（Comparability）。随机化保证了 treatment 组和 control 组在平均意义下是可比的。如果没有随机化，治疗分配可能受到选择偏差（selection bias）的影响。例如，如果病人自己选择是否接受治疗，那么接受治疗的群体可能本身就比对照组更健康。随机化通过强制分配机制打破了这种联系，使得两组在所有可观测和不可观测的特质上趋于平衡。

原则二：推理基础（Inference Basis）。随机化提供了推断因果效应的理论基础。在没有随机化的情况下，我们无法区分“因果效应”和“选择偏差”。但在随机实验中，我们知道治疗分配是如何进行的（randomization mechanism），因此可以基于这个已知的分配机制来计算 p 值。具体而言：

- (1) 假设 H_{0F} ：treatment 对每个人都无效（ $Y_i(1) = Y_i(0)$ ）
- (2) 在这个假设下，治疗分配是唯一的随机来源
- (3) 枚举所有可能的随机分配（或者 Monte Carlo 近似）
- (4) 计算在每种分配下，检验统计量有多极端

总结：可比性解决“选择偏差”——确保组间可比较。推理基础解决“随机变异”——知道观察到的差异有多极端。两者结合，使得因果推断成为可能。

1.11. 什么是 Fisher Randomization Test？问：什么是 Fisher Randomization Test（Fisher 随机化检验）？

答：Fisher Randomization Test (FRT) 是 Ronald Fisher 在 1935 年《Design of Experiments》中提出的统计检验框架。它的核心创新是：不再依赖数据分布假设（如正态性），而是**仅依赖随机化机制本身**。

核心思想：

- (1) 在 **sharp null** 假设 $H_{0F} : Y_i(1) = Y_i(0)$ (所有单元的治疗效应都为零) 下, 潜在结果向量 $\mathbf{Y}$ 是完全确定的 (固定的)
- (2) 唯一的随机来源是治疗分配机制 $\mathbf{Z}$
- (3) 在完全随机实验 (CRE) 中, $\mathbf{Z}$ 的分布是已知的 (均匀分布于所有 $\binom{n}{n_1}$ 种可能的分配)
- (4) 因此, 我们可以枚举所有可能的治疗分配, 计算在每种分配下检验统计量的取值
- (5) p 值就是在所有可能分配中, 观察到的统计量至少与实际观测值一样极端的比例

★ **Insight:** FRT 的本质是“条件推断”——我们 condition on 固定的潜在结果 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。这与经典统计推断不同: 经典方法 condition on 数据, 假设数据的分布已知; FRT 则 condition on 潜在结果, 利用随机化机制计算精确的 p 值。

为什么叫“随机化检验”? 因为它完全基于随机化机制——不假设任何参数分布, 不依赖正态性假设, 只依赖“治疗是如何随机分配的”这一事实。这使得 FRT 在随机实验中具有“有限样本精确性” (finite-sample exactness)。

1.12. $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义. 问: 在 CRE 中, $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的。这句话是什么意思?

答:

先理解 $\mathbf{Z}$ 是什么。 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 是治疗分配向量, 其中 $Z_i = 1$ 表示单元 i 接受治疗, $Z_i = 0$ 表示单元 i 接受对照。

再理解 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 。 这是所有可能的治疗分配构成的集合。例如当 $n = 3, n_1 = 1$ 时, 所有可能的分配有:

$$\mathbf{z}^1 = (1, 0, 0), \mathbf{z}^2 = (0, 1, 0), \mathbf{z}^3 = (0, 0, 1)$$

即 $M = \binom{3}{1} = 3$ 种可能。

“均匀分布”的意思。 在 CRE 中, 治疗分配是完全随机的。这意味着每一种可能的分配 $\mathbf{z}^m$ 被选中的概率相等:

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}^m) = \frac{1}{M} = \frac{1}{\binom{n}{n_1}}$$

例如当 $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$ 种可能的分配, 每一种被选中的概率都完全相同 (约 10^{-29})。

关键直觉: 在 CRE 下, treatment 组和 control 组的成员身份是随机决定的, 而非实验者主观选择。这就是 Fisher 说的“randomization provides a valid basis for inference”——随机化本身保证了推断的有效性。

1.13. 蒙特卡洛公式中的 $\mathbf{Z}$ 是什么?. 问: 蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思? 他说是一个均匀分布, 但我不知道 $\mathbf{Z}$ 是什么意思?

答:

为什么需要理解 $\mathbf{Z}$? 在 Fisher 随机化检验中, 我们感兴趣的问题是: “如果 treatment 真的是随机分配的, 观察到的差异有多极端?” 要回答这个问题, 我们需要知道“随机分配”是如何进行的——而 $\mathbf{Z}$ 正是描述这种分配机制的核心工具。

$\mathbf{Z}$ 的定义。 在 n 个单元的实验中, $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)$ 是一个长度为 n 的向量, 其中:

- $Z_i = 1$: 单元 i 接受 treatment (治疗组)
- $Z_i = 0$: 单元 i 接受 control (对照组)

例如当 $n = 5, n_1 = 2$ 时, 一个可能的分配是 $\mathbf{Z} = (1, 0, 0, 1, 0)$, 表示第 1、4 号单元接受治疗, 第 2、3、5 号单元接受对照。

为什么是“均匀分布”? 在完全随机实验 (CRE) 中, 治疗分配是完全随机的——每个可能的 $\mathbf{Z}$ 被选中的概率相等。这就是“均匀分布”的含义。

具体来说, 所有可能的分配有 $M = \binom{n}{n_1}$ 种, 每种被选中的概率都是 $1/M$ 。例如:

- $n = 3, n_1 = 1$ 时, $M = 3$, 三种可能: $(1, 0, 0)$ 、 $(0, 1, 0)$ 、 $(0, 0, 1)$, 概率各为 $1/3$
- $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$, 每种概率约为 10^{-29}

$\mathbf{z}^r$ 是什么? 在 Monte Carlo 近似中, 我们无法枚举全部 M 种分配。因此我们进行 R 次随机置换, 每次得到一个 $\mathbf{z}^r$ 。每个 $\mathbf{z}^r$ 都是对真实 $\mathbf{Z}$ 的一次模拟。

★ **Insight**: 理解 $\mathbf{Z}$ 的关键是: 它是一个指示函数向量 (indicator vector), 而不是一个普通的数。它告诉我们”谁在接受治疗, 谁在对照”。Monte Carlo 方法通过重复模拟这个随机分配过程, 来近似在所有可能分配下的检验统计量分布。

1.14. 什么是潜在结果 (Potential Outcomes) ?. 问: 什么是因果推断中的”潜在结果” (Potential Outcomes)?

答: 潜在结果 (Potential Outcomes) 是指每个研究单元在 ** 不同处理条件下 ** 可能观测到的所有结果。对于单元 i :

- $Y_i(1)$: 单元 i 接受 treatment 后的结果 (如吃药后的康复情况)
- $Y_i(0)$: 单元 i 接受 control 的结果 (如不服药的情况)

核心问题: 我们只能同时观测到 ** 一个 ** 潜在结果, 另一个是反事实 (counterfactual)。这被称为”因果推断基本问题” (Fundamental Problem of Causal Inference)。

1.15. 第一基本形式的意义. 问: 什么是第一基本形式 (First Fundamental Form)?

答: 第一基本形式是曲面上用来度量弧长、面积以及角度的工具, 本质上是曲面自带的一种”度量结构”——它告诉我们如何在曲面上测量距离和角度。

当你在阅读过程中提出问题时, 回答将被记录在此处。

2. 学习笔记

在这里记录你的学习心得和思考。

Bibliography