ὼ ḡ╤

p0jX K_jX

I p l — Q l —。

ŝ Ǒ 5

ŝ Ǒ 5
1. 5
2. ♦ 5
3. 6
4. 6
5. 6

Chapter 1. Yule-Simpson 7
1. 7
2. 7
3. 7
4. 7
5. Yule-Simpson 8
6. Yule-Simpson 8
7. LaLonde 9
8. 9
9. ♦ 9
10. 9

Chapter 2. 11
1. 11
2. 11
3. Science Table 11
4. 12
5. 12
6. 13
7. Yule-Simpson 13
8. 13
9. SUTVA 13
10. 14
11. 15
12. 15
13. ♦ 15
14. 15

Chapter 3. 17
1. 17
2. Fisher 17

3. 17
4. Sharp Null FRT 18
5. p 18
6. Monte Carlo 19
7. 19
8. FRT t 26
9. LaLonde 26
10. 26
11. Sharp Null 27
12. 27
13. 27

Chapter 4. Neymanian 29
1. 29
2. 29
3. 30
4. Neyman (1923) 30
5. 31
6. Neyman (1923) 31
7. 32
8. Neymanian OLS 32
9. 33
10. 33
11. 34

Chapter 5. 35
1. 35
2. SRE 35
3. 36
4. SRE Fisher 36
5. Neymanian 38
6. SRE CRE 39
7. CRE 40
8. 40
9. 40
10. 41

Chapter 6. 43
1. 43
2. 43
3. ReM 44
4. 45
5. 48
6. 48
7. 49
8. 49
9. 50
10. 50

Chapter 7. 53
1. 53
2. MPE 53
3. Fisher 53
4. Neymanian 56
5. 57
6. Darwin FRT 58
7. Workshop 59
8. 59
9. 59

Chapter 8. Fisher Studentized 61
1. Chapter 3 FRT Chapter 8 61
2. Studentized 61
3. Studentized 62
4. FRT 63
5. 64
6. 64
7. 65
8. 66
9. 66

Chapter 9. 69
1. 69
2. CRE 69
3. 71
4. SRE 71
5. 71
6. 72

Chapter 10. 73
1. 73
2. 73
3. 74
4. 74
5. 75
6. 76
7. 77
8. 77
9. 77

Chapter 11. 79
1. 79
2. 79
3. 80
4. 81
5. 82
6. 82

7. θ ╒ ẗ 83
8. V̈ ♦ 83
9. 83

Chapter 12. 85
1. Ŝ ″A ΊQa ĮĴ ħ 85
2. pV̈Į DR ΊQa 85
3. ┐ ¯ ⌋ 86
4. V̈pV̈Į DR ΊQa 86
5. ÊŚßĮ ˘ 87
6. ĞĞ ϋ 87
7. ∨ ä □Ŝ ĴpaĴ 88
8. V̈ ♦ 88
9. 88
10. ¯ ⌋ { ❴ ق 89
11. ┐ ΊQa ĮĴ ⌋ 89
12. ᴶ IPW ʉ DR ĮẄ 89
13. ᴶ♦ω‡Qʉ DR Įℭ 90
14. ┐ Į ₅♦ï 90
15. ĞĞ ϋ 90

Chapter 13. ₁ ϕ ķẄĮẄß 93
1. ŜᴶẄßĮ₂ʉ ʉYḦ ϋ 93
2. ϕ ķẄĮ Ę ω 93
3. ϕ ķẄẄß 94
4. Wßωʷ *K* Į 95
5. ᴅ Įū̃ Ŝ SRE ĮYḦ ϋpV̈ 95
6. Ḥ ĮΊQ 95
7. ϕ̈ 96
8. ♦ 97

Chapter 14. ⌋ Q̇ Ṙ ω g̃ 99
1. ″A ϕŜ IPW ΊQa ĮĴ ⌟ 99
2. Hajek ΊQa WLS ΊQa 99
3. ⌋ Ka Ŝ Lin (2013) Į ω ┐ 100
4. ı⌋ ⌋ ω Į WLS 101
5. ϕ»Ŝ‡QΊQa ∧ 102
6. V̈ ♦ 102
7. 102

Chapter 15. YḦ ϋ ĮĴ 105
1. Ŝ ↓ ĴĴ(‡Qε YĮ 105
2. ĴĴ₁V̈ 105
3. ĴĴΊQa Ŝ Ḧ ĴĴ 105
4. ĴĴ┐ 106
5. ATT ĮĴΊQa 107
6. ↓ Į 107
7. ϕ̈Ŝ LaLonde ϕ 107

8. 108
9. 108

Chapter 16. 109
1. 109
2. 109
3. 110
4. 111
5. 114
6. 115

Chapter 17. E-Values 117
1. 117
2. Cornfield 117
3. E-value 119
4. 119
5. 120
6. 121
7. 122
8. 122
9. 122

Chapter 18. 123
1. 123
2. Manski 123
3. 124
4. R 126
5. 127
6. 128
7. 129

Chapter 19. Rosenbaum p 131
1. 131
2. 131
3. p 132
4. 133
5. 133
6. 134

Chapter 20. 135
1. 135
2. 135
3. 136
4. 136
5. 137
138

Chapter 21. 141
1. 141

2. 141
3. 142
4. 142

Causal InferenceÕlʒ₁cɹ ṭṛ ὼ g

q wɯ

Rubinŋ 1974Ô ɱlɹ♦ὼWℤ Potential Outcomes FrameworkÕ ὼ g

Peng Ding lʒ³ A First Course in Causal Inference´ ◦∂ŏ ŝ

- ɕlẉ₂ὼẉ lʒ ὼ gṭṛ
- Fisher ẉ₂ὼ- Neyman ẽn g
- ẄɛiẄ ĬẄɛiÆὼὼ
- ʏɓĭ ɯ lʒ ὼ g
- ɒ kjẄ~ĖʏKɯ ~‡ℚg⁞ ɡ̈ὼℚgʒʊ̈Ķ

‖ w ♦

‖ w q w : U a 。— I p ‘ 。 Q a l I ; ‘。 ; g ` l V Q Q l J Q w

(1) **K**Peng Dingŋ̈ lÔ

(2) ɨ̈♦ **K**https://arxiv.org/abs/2305.18793

(3) ɕẍ **K**2023

(4) ɕÂ **K**490

(5) ℚ H **K**

- ŏΔ Fisher :ɕ g Neyman ╙≒ gnᴘWℤ
- ɱΔ ɾẉ₂ὼẉ ŋ CREÔlʒ ɪɹṭṛ
- ⎕ΔẄɛi~ĬẄɛi Kɯ ɯɳ́Æὼὼ
- ÄḶÔΔʏɓĭ ɯ lʒ ὼ g Ʒṭṛ

(6) **K**This book provides an introduction to causal inference for students and researchers interested in estimating treatment effects from randomized experiments and observational studies. It unifies the potential outcomes framework with a focus on randomization-based inference, covering topics from basic concepts like the Yule-Simpson paradox to advanced methods including propensity score matching, instrumental variables, and sensitivity analysis. The book emphasizes both finite-sample exact inference (Fisher's approach) and asymptotic inference (Neyman's approach), providing readers with a comprehensive toolkit for causal analysis.

(7) ŭ Causal Inference Potential Outcomes Randomization Test Neyman Inference Observational Studies Propensity Score

~

- *Causal Inference for Statistics, Social, and Biomedical Sciences.* Cambridge University Press.
- “Estimating Causal Effects of Treatments in Randomized and Non-Randomized Studies.” *Journal of Educational Psychology.*
- “The Central Role of the Propensity Score in Observational Studies for Causal Effects.” *Biometrika.*
- *Mastering ‘Metrics.* Princeton University Press.

X w

ŝ Markov Chebyshev
Hoeffding Chernoff
CLT

(1) 1-2
(2) 3-4 Fisher Neyman
(3) 5
(4) 6-8
(5) 9
(6) 10-18

W w

Fisher Neyman
Fisher Neyman

CHAPTER 1

ŭ ~ŭŭ 《‘ g Q _、a j s。p l

q ẅ℘

V̌ ℊ ‡ᶜ .A ѡ┐βѭ ŭ ļ ŝ ŭ ɜ̈Á ♦ẏ℘ ℊ ȍŭ

Ţ

ѡẄѡ↑ ŏ ℊ'w ʁ ļq̇ȍŝ

- ” ‰℘ V́Ŕ ”
- ” ○ ℘ѭѭ Ụ̈Ȍ≈℘ѭ Ụ̈ ”
- ” ˈwf̈ŭ̈ļ⨿ѿ̈ξ̣ ѭ ”

˚ ℘ѭD⧾ ╜t̃ ȍŭ ƀ ℊ℘ѭ℘ѭ℘ѭ℘ѭ♦□ļ̈ŢWW ℊYdʁ

Δ ŭ ŋ correlationÔ» ï̈Δ Ţ

‖ w℘ˈA ˛

qfiŝ

ǎ 1.1. 一家公司想要知道某种新药是否有效。他们给一组患者服用新药，另一组服用安慰剂。结果显示服药组的康复率更高。这能否说明药物有效？

ˇÿ℘ѭ ℊŏ ѡIJ⧾ƀ ƀ ŏ ˛K℘ѭ ℘ѭIJ ♦ȍŝ

- ǎ ļ V̈K»ɛ̈ę˜
- ѭ À ℘ŏ Hǎ ɛ̂→ŭ
- ę℘ѭ₂ɛ̈ą

ˀę℘ ȍ ḡŋ causal inferenceÕļ⨿ ŝ ℊYdʁļ⨿ŭ̈ŭ̈ŋ ;。。p J ȁ ;—a p l

Ӵǎ⨿ ȍŭ̈ ŋ **J ; ‘。; g Q gÔ ; — a p l 。^ a s**

～w℘ ȍ ļ⨿ɛ̈Ɋ

Ɋ ŏ ℊ ǎ ļ℘ѭ ѵ℘ẅ Ôʒ̧ŝ

- ŭ ŋ **I p Q gÔ ;: —a p l**
- ŭ̈ŭ̈ŋ **:。。p J aÔ ;: —ʊ a⨿p ŭ l**
- ȍ ŋ **I ; ‘。; Õ—:a p ļ K℘ ♦p ʰ ÄK℘ Kõ**

ŭ⨿B⧾ŝ 相关性可以是因果的，也可以是非因果的。

X w℘ˇ ŭ̈ʜ ŭ̈ŭ̈ɓ

╟ Z ѭ ʁ⁵wt̃ŏ Y ѭ ♦ȍŏ٦¯ ŭ̈ŭ̈ɓ ŝ

	$Y=1$	$Y=0$
$Z=1$	p_{11}	p_{10}
$Z=0$	p_{01}	p_{00}

ẗ ʔŋ ~ a。 e Ma』Q Q l J Q

$$\mathrm{RD} = \mathbb{P}(Y=1 \mid Z=1) - \mathbb{P}(Y=1 \mid Z=0) = \frac{p_{11}}{p_{11}+p_{10}} - \frac{p_{01}}{p_{01}+p_{00}}$$

ẗ ʕŋ ~ a。 e ~ô§ — a p

$$\mathrm{RR} = \frac{\mathbb{P}(Y=1 \mid Z=1)}{\mathbb{P}(Y=1 \mid Z=0)} = \frac{p_{11}}{p_{11}+p_{10}} \Big/ \frac{p_{01}}{p_{01}+p_{00}}$$

ɯʕŋ o N N。 ~ ʕŝ— a p

$$\mathrm{OR} = \frac{\mathbb{P}(Y=1 \mid Z=1)/\mathbb{P}(Y=0 \mid Z=1)}{\mathbb{P}(Y=1 \mid Z=0)/\mathbb{P}(Y=0 \mid Z=0)} = \frac{p_{11}p_{00}}{p_{10}p_{01}}$$

ŭ eẽ̊ ŝV̊ɯɯ Åẽ̊ ⊥⊥ ʜɯɯ₂Kɯ ɻD̃ɪ̃ ⁵ ɼD̃ɪ̃

ʃ q w(ẽ̊q̃ ɪ̃ʜ ɻD̃ɪ̃)w (1) 以下命题等价：$Z \perp\!\!\!\perp Y$、$RD = 0$、$RR = 1$、$OR = 1$。

(2) 若所有 $p_{zy} > 0$，则 $RD > 0$ 等价于 $RR > 1$，也等价于 $OR > 1$。

(3) 若 $\mathbb{P}(Y=1 \mid Z=1)$ 和 $\mathbb{P}(Y=1 \mid Z=0)$ 都很小，则 $OR \approx RR$。

Ww 《‘ g Q _、ā j s。p l

□ɻQ ɯ ŝ ʏdʊɻŭŭt ŏʏɪ̈ ẄɞĬA ɻŭŭt Š

ẵ 1.2 (ᴵᵛɻ Yule-Simpson □ẵ). 考虑一个大学录取数据：

院系	男生录取率	女生录取率
A	*62% (341/550)*	*82% (137/167)*
B	*63% (28/44)*	*68% (24/35)*
	45% (369/816)	***30% (161/525)***

有趣的现象：

- 在 A 院系，男女生录取率分别是 *62%* 和 *82%*
- 在 B 院系，男女生录取率分别是 *63%* 和 *68%*
- 但总体来看，男生的录取率反而更高！

这就是 *Yule-Simpson* 悖论： ⱽẀɞĬA Ḍ ẵɻ ɯŏ ʏɪ̈ăẵ 。

ʔẵ ᵛɯ ʔÅŜʕɻ ŝ 如果我们不控制混杂因素（*confounding factors*），就可能得出完全错误的因果结论

ˇ wṽŭ ɯ 《‘ g Q _、a j s。p l

ˇ ɬɻ̃ɯ ɯ₂ ɪ ŝ

$$\begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \sim N\left(\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho_{XY} & \rho_{XZ} \\ \rho_{XY} & 1 & \rho_{YZ} \\ \rho_{XZ} & \rho_{YZ} & 1 \end{pmatrix} \right)$$

Y ɻ̃ Z ɻʓ̃ ŭ ɯ $\rho_{YZ|X}$ ˆ ɼẄÅ $(Y,Z) \mid X$ ɻ ŭ ɯ

ʃ q w(ɗ‖ŭ ɯñɯ)w

$$\rho_{YZ|X} = \frac{\rho_{YZ} - \rho_{YX}\rho_{ZX}}{\sqrt{1-\rho_{YX}^2}\sqrt{1-\rho_{ZX}^2}}$$

$\rho_{YZ} > 0$ $\rho_{YZ|X}$ Yule-Simpson

LaLonde National Supported Work Demonstration

$2^{10} = 1024$ treatment

Bertrand and Mullainathan (2004)

”

r p — Q l — a ; g o ‘ — J p j Q。 U

q 『w

1.1. 独立性命题的证明 证明 *Proposition* 中的命题 *(1)* 和 *(2)*。

1.2. *Yule-Simpson* 悖论的更多例子

(1) 给出一个 $2 \times 2 \times 2$ 列联表的数值例子，其中出现 *Yule-Simpson* 悖论。

(2) 找一个现实生活中的 *Yule-Simpson* 悖论例子。

1.3. 相关与偏相关 考虑三维正态随机向量 $(X, Y, Z)^\top \sim N(\mathbf{0}, \Sigma)$。

证明偏相关系数公式（见 *Proposition* ）。

给出一个 $\rho_{YZ} > 0$ 但 $\rho_{YZ|X} < 0$ 的数值例子。

：这是正态随机向量情形下的 *Yule-Simpson* 悖论。

1.4. 规格搜索 重做 *Hainmueller (2012)* 的数据分析。使用结局 `re78` 和治疗 `treat`。数据集还包含 *10* 个协变量，共有 $2^{10} = 1024$ 种可能的协变量子集组合。运行所有可能的线性回归子集，并报告 *treatment* 系数的分布：有多少是正显著、负显著、不显著的？

1.5. 种族歧视的进一步分析 重做 *Bertrand and Mullainathan (2004)* 的简历数据分析。分别对男性和女性进行分析，讨论亚组分析的结果与总体结论的差异。

ŭ 1.6. { 推荐阅读 ┤ḍ : { 是关于 *Berkeley* 录取数据悖论的原始论文。{ 从因果推断角度重新审视了该研究。

ãᾳe : { 是统计因果推断领域的经典综述文章，它推广了*"Rubin* 因果模型*"* 这一名称。在 *UC Berkeley*，我们称之为*"Neyman* 模型*"*——原因显而易见。

CHAPTER 2

▲ ♦◊WΣ

q W ŭ ◊ ŝ ♦ ŭ ŭ ă ť ţ

ᵖ ŏ ♂ ‖ Δ ″A L ♂ ă Ǩ ļ ŝ Yule-Simpson ▯ ♂ ♂ Δ ŭ ŭ

ϒ ◊ Ţ ♂ Ż W Ω ♂ ļ ŏ ă Ч Ĭ ϒ ţ K į §§ , ẏ ♂ ŏ

ᴶ ŭ ŭ g̃ ◊ ♂ ļ

Þ ♂ ă ◊ ŝ ŭ ŭ ⊐ ♂ ţ ♂ Y Ժ ɐ ļ Ω Ν ◊ ♂ ♂ ɖ ļ ψ ˜ ŏ

◊ ţ Á Θ ♂ ų ˜ ŏ ♦ ϑ Ĭ Ω ţ

″A Þ ♂ ″A N ğ ᵖ ļ W Σ §§ ▲ ♦◊WΣŋ **r p — Q l — a ; g o ‘ — _**

J p j Q。 U ; j Q] p e k Q 》 j ; l _ ~ ◊ Ś B a l

″A W Σ ļ ɾ ϒ ♂ Neyman 1923 ɕ ļ ᴗ Ɛ ŏ ℏ Rubin 1970

ɕ ᴮ Ħ Ś ļ ᵛ ä Ô ♦ ļ Ω ◊ ♂ ʃu ɾ ß ŝ ▯ ◊ ŏ ♂ Ĭ

ŋ counterfactual Ô ♦ ◊ ♂ ♦ ă Ô ♦ ᶜ

‖ W ◊ ♂

ċ ♂ ᴶ ″A ɾ ß ļ q fi ♂ ŝ Ω ♦ ♂ ŭ ♂ Ħ ˜ ê ļ ◊ ˘ Ω ᵖ *i* ″A ♂ e ŝ

- $T_i = 1$ŝ ♦ ♦ Δ ɐ
- $T_i = 0$ŝ ♦ ♦ ɐ ŋ Ħ Ô

ŏ ŭ ŗ ļ ⋅Δ ŝ ″A ļ ♦ ◊ Ω ♦ ♦ Ţ

♂ ŏ ♂ ţ Y Ժ ɐ ♩ W §§ ᶜ ♦ ♦ Δ ɐ ŏ ᶟ Þ Δ ▯

◊ ŏ ♂ Ĭ ţ ˜ Ω Ď ϒ ţ ŝ

- $Y_i(1)$ŝ ♩ ◊ ♦ ♦ ɐ ŏ Ω ‰ Y Ժ ɐ ļ ♦ ◊
- $Y_i(0)$ŝ ♩ ◊ ♦ ♦ ɐ ŏ Ω ‰ Y Ժ ɐ ļ ♦ ◊

˘ ŏ $Y_i(1)$ ˙ Ω $Y_i(0)$ ᵓ ♦ ▲ ♦ ◊ §§ ♦ ♂ ɀ ♦ Δ ă ɐ ϒ ţ Ô ♦ ļ ♦ ◊ ŏ

Þ ♂ Ṙ ᵖ Y Ժ ɐ Ŋ

2.1 (2.1 § ♦ ᵐ Ś ♦ ♦). Ś ♦ ♦ (*counterfactual*) 指的是未被观测到的潜在结果。具体而言：

- 对于治疗组个体 i $(T_i = 1)$，我们观察到 $Y_i(1)$，而 $Y_i(0)$ 是反事实
- 对于对照组个体 i $(T_i = 0)$，我们观察到 $Y_i(0)$，而 $Y_i(1)$ 是反事实

正因为潜在结果框架讨论的是“如果接受相反治疗会怎样”，所以它也被称为Ś ♦ ♦ W Σ (*counterfactual framework*)。

2.2. ♦ ᶜ ▾ “ ▲ ” ♦ ◊ Ţ *:* 因为它们描述的是“如果... 会怎样”的情形，这种结果是“潜在的”而非“现实的”。这正是 *counterfactual* (反事实) 思维的本质。

~ W ♂ ŋ 、 J a Q l J Q 々 ; B g Q

{ ‖ ▲ ♦ ◊ ˛ ļ $n \times 2$ ˥ ˭ ϒ ♂ ŋ 、 J a Q l J Q ŝ 々 ; B g Q

i	$Y_i(1)$	$Y_i(0)$
1	$Y_1(1)$	$Y_1(0)$
2	$Y_2(1)$	$Y_2(0)$
⋮	⋮	⋮
n	$Y_n(1)$	$Y_n(0)$

X ẅ ẁ

Δ⋏ ♦ẁŏ ℊ ⅂ ℘ ų̃ ẁ Δ
Ḧ Ä *iŏ̃* Ä ẁ ŋ **` l N a ” a N ‘ ; g 々 Q ; — j Q l — P 』 Q J — L ` 々 P**

$$\tau_i = Y_i(1) - Y_i(0)$$

ℓ₩ 8 Ḧ Ḧ ⅃ “◻ ẁ ”
ƀ℘ŏ ˇ⅂ Δ Ä∈V̈ ⅃⅂⅃ 1923 ℓŏ Jerzy Neyman ℓv̈ ∫₩ ⅃
□ ⋏ᴱ℘ ⅂Δ Ä ŝ

对于每个个体，我们只能观察到一种潜在结果——实际发生的那种。另一种潜在结果是潜在的、永不可见的。

℮ ẁ g⅂∈V̈ ŋ **U ‘ l N ; j Q l — ; g r p B g Q j p V ō I ; ‘ 。 ; g ` l**

2.3. ⋔ᵉ Ä⅂⅃₩ᴮ∈V̈Ţ *：* 因为科学上感兴趣的大多数因果问题，都涉及将现实与反事实进行比较。我们可以问 “这种药对这个患者有效吗？”——但这个问题要求我们同时知道患者吃药和不吃药的结果，而这是不可能的。

W ẅ ẃ ẁ

⅋℘Ä ẁ ăY℔ ŏ ℘ N℘ᵴᴱŏṳ ⋓́ ẁ ŋ **: ” Q ; Z Q I ; ‘ 。 ; g P 』 Q J — L ô ŝ : I P**

$$\tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0) \tag{2.1}$$

ε̊:℘⅃ e℘̊ŝ [1]

$$\tau = \frac{1}{n}\sum_{i=1}^{n}\{Y_i(1) - Y_i(0)\} = \frac{1}{n}\sum_{i=1}^{n} Y_i(1) - \frac{1}{n}\sum_{i=1}^{n} Y_i(0) \tag{2.2}$$

Ä℔ ŏ ⊢ñ⅂ℊ℘ ŝ⋓́ ẁ ℊ Ä ẁ ⅃′ ŝ

$$\tau = \bar{Y}(1) - \bar{Y}(0) = \frac{1}{n}\sum_{i=1}^{n} \tau_i \tag{2.3}$$

[1] ₱‖ȯh ??

9.1 SUTVA假设

在因果推断中，我们通常关注单个单元 i 的潜在结果 $Y_i(1)$ 和 $Y_i(0)$，其中 $Y_i(1)$ 表示单元 i 接受处理时的结果，$Y_i(0)$ 表示单元 i 未接受处理时的结果。

- 对于单元 i，我们只能观测到 $Y_i = Y_i(1)$ 如果 $T_i = 1$
- 对于单元 i，我们只能观测到 $Y_i = Y_i(0)$ 如果 $T_i = 0$
- 因此，个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 永远无法直接观测

[2]

$$\tau_x = \frac{\sum_{i=1}^{n} \mathbb{I}(X_i = x)\{Y_i(1) - Y_i(0)\}}{\sum_{i=1}^{n} \mathbb{I}(X_i = x)}, \quad (x = 0, 1) \tag{2.4}$$

9.2 平均处理效应

[3]

$$\tau = \pi_1 \tau_1 + \pi_0 \tau_0 \tag{2.5}$$

其中 $\pi_x = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}(X_i = x)$ 为协变量 $X_i = x$ 的比例。

9.3 潜在结果框架

潜在结果框架（Potential Outcomes Framework）由Rubin提出，将因果推断视为缺失数据问题。

对于每个单元 i，定义处理指示变量 $T_i \in \{0, 1\}$，观测结果 Y_i 满足：

$$Y_i = \begin{cases} Y_i(1), & \text{if } T_i = 1 \\ Y_i(0), & \text{if } T_i = 0 \end{cases} \tag{1}$$

$$= T_i Y_i(1) + (1 - T_i) Y_i(0) \tag{2}$$

$$= Y_i(0) + T_i\{Y_i(1) - Y_i(0)\} \tag{3}$$

$$= Y_i(0) + T_i \tau_i \tag{4}$$

其中 $\tau_i = Y_i(1) - Y_i(0)$ 为单元 i 的处理效应。

9.4 SUTVA假设

SUTVA（Stable Unit Treatment Value Assumption）包含两个子假设：

1. **无干扰**（No Interference）：单元 i 的潜在结果不依赖于其他单元的治疗分配。这有时被称为“无溢出”假设。
2. **处理水平一致**（Consistency）：处理水平没有其他版本。等价地，我们要求治疗水平是良好定义的，至少对关注的结局是如此。这有时被称为“一致性”假设。

定理 2.3 (SUTVA). 假设无干扰和处理水平一致同时成立。

[2] ??
[3] ??

¹l¹ alho ÂN×1$ ÂT†í-Wi Ä €Í çl,ü' *¹.
²T Yi(1) „ Yi(0) ü,^ r2HH@/¥}Mi2¥´||%¿ ð¦¥›¹ Í ¥
8™T œñ•Oüö)ïb
´Q alho ¥è0
íÄ L! MQ@BMi2`72`2M+2 ´kQb¥mK™TiBQM

URV™hÐfì¤Õ BM72+iBQmb /Bb2 b2b M/'%h+µBT™Ÿ iBQM
H Bñ¦^Ž¤Õfì,Ç•Yð1-¥Ñh„B Î•Yð Û¶¦$Ë™¥
ÀqbèÂ ÂTá¥]Y¤Õ @Ëfì áÑ@Ë¥Àq9ö†®ii'P
á1-Àµ¤Õb ƒÕfƒ/ †í i¥. ²T Yi(1) „ Yi(0) ûG ¿ ð
¦¥Í s¥b

Uk®VŽr‹L M2irQ`F 2tT2`BK2M Œ©ŽL Ï ÂTBñ¦lž
6 +2#Q<Q F i`2 iK2ÐM´¶AžƒH<áisž•Yª V?9ö ™
¾ÁÖii'P´¶'¦Àµ°¤lž<ábƒü^îÌ¥ n r‹ bTBHHQp2`
2z2+ib

UjVÛ uFL Ï¥M#¹v M2B;?#Q`BM; THQib BM ` M/QKBx2/ #HQ-
K2Mibj<L Ï M#¹v¥TþV?Mº•YiiÂTM#¹vP¨ g
V?öYVr›1i•Y'¹v¥Á b

BÁŸL! +QMbBbi2M+v bb´kQK¥TT™BQM

URVT†Í +QKTQbBi2 i`2 iKÍ2M&ib¯ Fî†sH M]¥ óÍ
ôS&V? ‹,]¥L=Äçbè Â
ùî õ bKQFBkM;¥•YH ó õ ôƒñÍ µ Õ™TiiPõ
Ë˜a õÔqa Æ' © ƒtûV?•Á,]¥. ²Tb
ùîvÐ•â +QHH2;2 2/mÆ¥BYQHM ó vÐ ôƒñÍ “
vÐË˜ N38fkRŒYpýbma <aÓÝ©)© ƒtµsö/î.
²T¥,BÁb

Uk¼V r‹ /Qb ;2 2z2+iDÐùîÏ M]¥0þ ëV? ‹,]4
74 °¤•Y rbèÂ ó›¨-³Ä ôT¹Í Œ,]4 ¥-³Ä ö
Á3›†,]¥. ²Tb

UjVL@Ms BKTH2K2Mi iBQM p'ÈBÍ iBQM] ,]L@€V
?„Æµsbè Â •ØÍ ùîÏ ,]Í =¥„ì„/?V?•ÁM]¥
ó•ØÍ ôÁ3,]rTb

’ alho ,îëH . ²T•O³1©žb C}yTw ÓD Â \ž ù
îÂ…)Øi Ä Í ñ' "¥f™b

ÿ kXXalho ¥åN×1Ÿ ,_m#BM U|RNaBhyV ’ë¹. ²T•O¥ $
L! Àµ alho yTw ¥”ÐÄ^,V?¥b

RyXQYL±»¥†

9¸Föz ¹l¹,?e†¹Ù óL=?3¥²T^l¹ ô$
sÃ^ yTr‹'É ^BñQYL +QmMi2`7 ÀiQmbHáÌÙ ófÕ0^
Žµr ôH áÌL= ^ Ù

óÂTƒñÑ€ù 0 ²Tö8"$ŒECL^ ðV?Àµù0 XXXô

ƒÕ±»ZTV?ž¦$¤ `.À}ÐÄ Œñ^áÌ ,yT¥·BøÈZTb.
²T•O¥N´ ¿ ñ|ƒÕ}Ðó³ Ä¹b ¥”ÐÔýb

q qẇ ỵ ỉ ụ

□ Ả ụ ꝑ ỗ ỷ ụ ỉ ˥ ꝑ ỏ ỏ ụ ꝑ ỵ ỉ ặ ỉ ꝑ

ặ ặ ỏ ỏ ả ɹ ỉ ả ꝑ ỏ ỏ ˥ ỉ ụ ỏ ỏ ả ꝑ ỏ ỏ ˥ ỉ ỉ
ụ ỏ ỏ ỏ ỵ ỉ ụ ỵ ỏ ỉ ỏ ỉ ỏ ỏ ỏ

其中 ϕ 和 Φ 分别是标准正态分布的密度函数和分布函数。

[illegible] 2.2. [illegible]非线性因果参数 证明平均因果效应是线性因果参数的例子，即 $\bar{Y}(1) - \bar{Y}(0) = n^{-1}\sum_{i=1}^{n}\{Y_i(1) - Y_i(0)\}$。

其他参数可能不是线性的。例如，定义中位数治疗效应为：

$$\delta_1 = median\{Y_i(1)\} - median\{Y_i(0)\}$$

这通常不同于个体治疗效应的中位数：

$$\delta_2 = median\{Y_i(1) - Y_i(0)\}$$

(1) 给出数值例子分别满足 $\delta_1 = \delta_2$、$\delta_1 > \delta_2$ 和 $\delta_1 < \delta_2$。

(2) 哪个参数更有意义？为什么？请用例子来证明你的结论。

[illegible] 2.3. [illegible]平均效应与个体效应 给出一个数值例子，其中 $\tau = n^{-1}\sum_{i=1}^{n}\{Y_i(1) - Y_i(0)\} > 0$，但有不到一半的单元满足 $Y_i(1) > Y_i(0)$。即平均因果效应为正，但治疗对不到一半的单元有益。

[illegible] 2.4. [illegible]推荐阅读 [illegible]：[illegible]是统计因果推断领域的经典综述文章，它推广了*"Rubin* 因果模型*"* 这一名称。在 *UC Berkeley*，我们称之为 *"Neyman* 模型*"*——原因显而易见。

CHAPTER 3

3.1 Fisher 的随机化检验

3.1.1 Fisher 的随机化检验的基本思想

Ronald Fisher 在 1935 年出版的 Design of Experiments 一书中提出了随机化检验的基本思想。

(1) 对于一个给定的检验统计量 T，在零假设成立的条件下，计算出 T 的所有可能取值。

(2) 将这些可能取值从小到大排序，然后计算观测值 T_{obs} 在这个排序中的位置。

Fisher 随机化检验的核心思想是：如果零假设成立，那么观测值 T_{obs} 应该不会太极端，否则我们就有理由怀疑零假设的正确性。

3.1.2 Fisher 的随机化检验的基本步骤

Fisher 随机化检验的基本步骤如下：

(1) 提出零假设 H_0 和备择假设 H_1。

(2) 选择一个检验统计量 T。

(3) 在零假设成立的条件下，计算出 T 的所有可能取值。

(4) 将这些可能取值从小到大排序，然后计算观测值 T_{obs} 在这个排序中的位置。

(5) 根据 T_{obs} 在排序中的位置，计算出 p 值。

(6) 根据 p 值和显著性水平 α，做出拒绝或不拒绝零假设的决策。

3.1.3 Fisher 的随机化检验的例子

例 3.1 假设我们有一个随机化实验，其中有 4 个处理组，每个处理组有 3 个观测值。我们想要检验这 4 个处理组的均值是否相等。

(1) 提出零假设 H_0 和备择假设 H_1。

H_0：4 个处理组的均值相等。

H_1：4 个处理组的均值不相等。

(2) 选择一个检验统计量 T。

我们选择 T 为 4 个处理组的均值的最大值减去最小值。

(3) 在零假设成立的条件下，计算出 T 的所有可能取值。

在零假设成立的条件下，4 个处理组的均值相等，因此 T 的所有可能取值为 0。

(4) 将这些可能取值从小到大排序，然后计算观测值 T_{obs} 在这个排序中的位置。

T_{obs} 在排序中的位置为 1。

(5) 根据 T_{obs} 在排序中的位置，计算出 p 值。

p 值为 1。

(6) 根据 p 值和显著性水平 α，做出拒绝或不拒绝零假设的决策。

由于 p 值大于显著性水平 α，因此我们不拒绝零假设。

3.1.4 Fisher 的随机化检验的优缺点

Fisher 随机化检验的优点如下：

(1) 不需要假设数据服从某种分布。

(2) 不需要假设处理组之间的方差相等。

(3) 不需要假设处理组之间的协方差相等。

Fisher 随机化检验的缺点如下：

(1) 计算量大。

(2) 对于小样本，检验的功效较低。

(3) 对于大样本，检验的功效较高。

3.2 Neyman 的随机化检验

3.2.1 Neyman 的随机化检验的基本思想

Jerzy Neyman 在 1923 年出版的 On the Application of Probability Theory to Agricultural Experiments 一书中提出了随机化检验的基本思想。

(1) 对于一个给定的检验统计量 T，在零假设成立的条件下，计算出 T 的所有可能取值。

(2) 将这些可能取值从小到大排序，然后计算观测值 T_{obs} 在这个排序中的位置。

Neyman 随机化检验的核心思想是：如果零假设成立，那么观测值 T_{obs} 应该不会太极端，否则我们就有理由怀疑零假设的正确性。

3.2.2 Neyman 的随机化检验的基本步骤

Neyman 随机化检验的基本步骤如下：

(1) 提出零假设 H_0 和备择假设 H_1。

(2) 选择一个检验统计量 T。

(3) 在零假设成立的条件下，计算出 T 的所有可能取值。

(4) 将这些可能取值从小到大排序，然后计算观测值 T_{obs} 在这个排序中的位置。

(5) 根据 T_{obs} 在排序中的位置，计算出 p 值。

(6) 根据 p 值和显著性水平 α，做出拒绝或不拒绝零假设的决策。

3.2.3 Neyman 的随机化检验的例子

例 3.2 假设我们有一个随机化实验，其中有 4 个处理组，每个处理组有 3 个观测值。我们想要检验这 4 个处理组的均值是否相等。

(1) 提出零假设 H_0 和备择假设 H_1。

H_0：4 个处理组的均值相等。

H_1：4 个处理组的均值不相等。

(2) 选择一个检验统计量 T。

我们选择 T 为 4 个处理组的均值的最大值减去最小值。

(3) 在零假设成立的条件下，计算出 T 的所有可能取值。

在零假设成立的条件下，4 个处理组的均值相等，因此 T 的所有可能取值为 0。

(4) 将这些可能取值从小到大排序，然后计算观测值 T_{obs} 在这个排序中的位置。

T_{obs} 在排序中的位置为 1。

(5) 根据 T_{obs} 在排序中的位置，计算出 p 值。

p 值为 1。

(6) 根据 p 值和显著性水平 α，做出拒绝或不拒绝零假设的决策。

由于 p 值大于显著性水平 α，因此我们不拒绝零假设。

3.2.4 Neyman 的随机化检验的优缺点

Neyman 随机化检验的优点如下：

(1) 不需要假设数据服从某种分布。

(2) 不需要假设处理组之间的方差相等。

(3) 不需要假设处理组之间的协方差相等。

Neyman 随机化检验的缺点如下：

(1) 计算量大。

(2) 对于小样本，检验的功效较低。

(3) 对于大样本，检验的功效较高。

3.3 Fisher 的随机化检验与 Neyman 的随机化检验的比较

Fisher 的随机化检验和 Neyman 的随机化检验的基本思想是相同的，都是在零假设成立的条件下，计算出检验统计量的所有可能取值，然后将这些可能取值从小到大排序，然后计算观测值在这个排序中的位置。

Fisher 的随机化检验和 Neyman 的随机化检验的基本步骤是相同的，都是提出零假设和备择假设，选择一个检验统计量，在零假设成立的条件下，计算出检验统计量的所有可能取值，然后将这些可能取值从小到大排序，然后计算观测值在这个排序中的位置，根据观测值在排序中的位置，计算出 p 值，根据 p 值和显著性水平，做出拒绝或不拒绝零假设的决策。

Fisher 的随机化检验和 Neyman 的随机化检验的例子是相同的，都是检验 4 个处理组的均值是否相等。

Fisher 的随机化检验和 Neyman 的随机化检验的优缺点是相同的，都是不需要假设数据服从某种分布，不需要假设处理组之间的方差相等，不需要假设处理组之间的协方差相等，计算量大，对于小样本，检验的功效较低，对于大样本，检验的功效较高。

Fisher 的随机化检验和 Neyman 的随机化检验的区别在于，Fisher 的随机化检验是在零假设成立的条件下，计算出检验统计量的所有可能取值，然后将这些可能取值从小到大排序，然后计算观测值在这个排序中的位置，根据观测值在排序中的位置，计算出 p 值，根据 p 值和显著性水平，做出拒绝或不拒绝零假设的决策。Neyman 的随机化检验是在零假设成立的条件下，计算出检验统计量的所有可能取值，然后将这些可能取值从小到大排序，然后计算观测值在这个排序中的位置，根据观测值在排序中的位置，计算出 p 值，根据 p 值和显著性水平，做出拒绝或不拒绝零假设的决策。

Fisher 的随机化检验和 Neyman 的随机化检验的联系在于，Fisher 的随机化检验和 Neyman 的随机化检验的基本思想是相同的，都是在零假设成立的条件下，计算出检验统计量的所有可能取值，然后将这些可能取值从小到大排序，然后计算观测值在这个排序中的位置。

Fisher 的随机化检验和 Neyman 的随机化检验的基本步骤是相同的，都是提出零假设和备择假设，选择一个检验统计量，在零假设成立的条件下，计算出检验统计量的所有可能取值，然后将这些可能取值从小到大排序，然后计算观测值在这个排序中的位置，根据观测值在排序中的位置，计算出 p 值，根据 p 值和显著性水平，做出拒绝或不拒绝零假设的决策。

Fisher 的随机化检验和 Neyman 的随机化检验的例子是相同的，都是检验 4 个处理组的均值是否相等。

Fisher 的随机化检验和 Neyman 的随机化检验的优缺点是相同的，都是不需要假设数据服从某种分布，不需要假设处理组之间的方差相等，不需要假设处理组之间的协方差相等，计算量大，对于小样本，检验的功效较低，对于大样本，检验的功效较高。

Fisher 的随机化检验和 Neyman 的随机化检验的区别在于，Fisher 的随机化检验是在零假设成立的条件下，计算出检验统计量的所有可能取值，然后将这些可能取值从小到大排序，然后计算观测值在这个排序中的位置，根据观测值在排序中的位置，计算出 p 值，根据 p 值和显著性水平，做出拒绝或不拒绝零假设的决策。Neyman 的随机化检验是在零假设成立的条件下，计算出检验统计量的所有可能取值，然后将这些可能取值从小到大排序，然后计算观测值在这个排序中的位置，根据观测值在排序中的位置，计算出 p 值，根据 p 值和显著性水平，做出拒绝或不拒绝零假设的决策。

[illegible] $\mathbf{Y}(1)$ [illegible] $\mathbf{Y}(0)$ [illegible]

(7) $$\mathbb{P}\{\mathbf{Z} = \mathbf{z} \mid \mathbf{Y}(1), \mathbf{Y}(0)\} = \frac{1}{\binom{n}{n_1}}$$

CRE $\mathbf{Z} \perp\!\!\!\perp \{\mathbf{Y}(1), \mathbf{Y}(0)\}$ [illegible] CRE [illegible] $\mathbf{Z}$ [illegible] n_1 [illegible] 1 [illegible] n_0 [illegible] 0 [illegible]

[illegible]

[illegible]

(8) $$H_{0F} : Y_i(1) = Y_i(0) \quad \text{[illegible]} \qquad i = 1, \ldots, n.$$

[illegible] $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y} = (Y_1, \ldots, Y_n)$ [illegible] [4] [illegible] H_{0F} [illegible] FRT [illegible]

(9) $$T = T(\mathbf{Z}, \mathbf{Y}),$$

[illegible] $\mathbf{Y}$ H_{0F} [illegible] T [illegible] $\mathbf{Z}$ [illegible] $\mathbf{Z}$ [illegible] T [illegible] p [illegible] CRE [illegible] $\mathbf{Z}$ [illegible] $\{\mathbf{z}^1, \ldots, \mathbf{z}^M\}$ [illegible] $M = \binom{n}{n_1}$ [illegible] $\mathbf{z}^m$ [illegible] [illegible] n_1 [illegible] 1 [illegible] n_0 [illegible] 0 [illegible] [5]

[illegible] s

[illegible] T [illegible] [illegible]

(10) $$p_{\text{frt}} = M^{-1} \sum_{m=1}^{M} \mathbb{I}\{T(\mathbf{z}^m, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}.$$

[illegible] Fisher [illegible] p [illegible] p_{frt} [illegible] [illegible] H_{0F} [illegible] finite-sample exact [illegible] [6]

(11) $$\mathbb{P}(p_{\text{frt}} \leq u) \leq u \quad \text{for all} \quad 0 \leq u \leq 1.$$

3.1. [illegible] *：这意味着 p 值的分布（虽然在离散情况下是阶梯函数）满足上式，因此 p 值在 $[0, 1]$ 上均匀分布（对于连续情况）。*

---

[4] [illegible] H_{0F} $\mathbf{Y}$ [illegible] ??

[5] [illegible] $\{\mathbf{z}^1, \ldots, \mathbf{z}^M\}$ [illegible] ??

[6] [illegible] ??

ˇ w i p l — Q ⍋ ; g p

ᵩ┼ ŏ M ᵂ ᵖŋŏ⍿ $n = 100, n_1 = 50$ ᵨŏ $M > 10^{29}$ⓆⓆ⍤ᵩ ᵡ⌈⌋
⁸ ¹ ⍺ᵩᵨ⍵ăᵡ⌈ ⌋ ᵹ'ᵂ Monte Carlo ᵡ≠ᵩ p_{frt}ŏ⍬ ᵑᵩ $\tilde{p}_{\text{frt}}$ ᵸ
ᵛ 78

$$\hat{p}_{\text{frt}} = R^{-1} \sum_{r=1}^{R} \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}, \tag{12}$$

ᔆ $\mathbf{z}^r$ ᵡ $\mathbf{Z}$ ⌋ R ᴱᵩ₂ ⍺ᵩ p_{frt} ᵩᵸᴴ $\mathbf{Z}$ ⌋ ŏ FRT ᵨ CRE ˘
ⓔ ⌐ ŋ **s Q j ‘ — ; — å p l —Q。 —**
⌋ ᵛ ≠ᵩ ŝ

$$\tilde{p}_{\text{frt}} = \frac{1 + \sum_{r=1}^{R} \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}. \tag{13}$$

ᵀA ᵡ ⌋ R ᴰᵩ ᵛ ⌋ p

¯ w ⍺ ⌊⍵Š

FRT ⌋ ᵀA ⁱᵩᵩᵸᴴᵡᴰ⁻ ⍺ᴰᵩ ᵛ:ᵡ p ᵬ ᵹ Ô ᵷ
ᵡᶜᵀᵑ H_{0F} ᵞᵷ ᵡ ⌋⁻ ⍺

¯ w ⓠ´ẘⓌ ẘᵛ ´ ⍺ᵩŝ

$$\hat{\tau} = \hat{\bar{Y}}(1) - \hat{\bar{Y}}(0), \tag{14}$$

ᔆ

$$\hat{\bar{Y}}(1) = n_1^{-1} \sum_{Z_i=1} Y_i = n_1^{-1} \sum_{i=1}^{n} Z_i Y_i \tag{15}$$

ᵩ treatment ⌋ ᵛ´ ŏ

$$\hat{\bar{Y}}(0) = n_0^{-1} \sum_{Z_i=0} Y_i = n_0^{-1} \sum_{i=1}^{n} (1 - Z_i) Y_i \tag{16}$$

ᵩ control ⌋ ᵛ´
H_{0F} ŏ $\hat{\tau}$ ´ 0 ᵡⓉᵡ

$$\text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} s^2, \tag{17}$$

ᔆ $s^2 = (n-1)^{-1} \sum_{i=1}^{n} (Y_i - \bar{Y})^2$ŏ $\bar{Y} = n^{-1} \sum_{i=1}^{n} Y_i$ [9]
ᴸ≠ẄÄ ŝ Ⓖˆᵸ Finite Population Central Limit Theoremᵠ⍬Ô
₂ⓄẄÄ≠ᵩ ŝ

$$\frac{\hat{\tau}}{\sqrt{\frac{n}{n_1 n_0} s^2}} \to \mathcal{N}(0,1) \tag{18}$$

in distribution.

[7] ŝ ᵩᶜ Monte Carlo ≠ᵩ ⌈‖Ôh **??**
[8] ŝᶜ ⌈ñᵩᵕ⌋ **Z** ᵾᵭᵩᵩᵸᶜᵩ⌈‖Ôh **??**
[9] ᵽ‖Ôh **??**

...

(19) $$(n-1)s^2 = \sum_{Z_i=1}\{Y_i - \hat{\bar{Y}}(1)\}^2 + \sum_{Z_i=0}\{Y_i - \hat{\bar{Y}}(0)\}^2 + \frac{n_1 n_0}{n}\hat{\tau}^2.$$

...

11

3.2. ... ***FRT*** ... ***t*** ... *：传统 t 检验需要正态性假设。但 FRT 框架表明，只要随机化分配正确执行，t 检验程序在有限总体 + 随机化情境下可以使用——渐近理论只依赖于有限总体 CLT，而不依赖于数据的原始分布。*

...

(20) $$t = \frac{\hat{\bar{Y}}(1) - \hat{\bar{Y}}(0)}{\sqrt{\frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}}},$$

...

(21) $$\hat{S}^2(1) = (n_1-1)^{-1}\sum_{Z_i=1}[Y_i - \hat{\bar{Y}}(1)]^2, \quad \hat{S}^2(0) = (n_0-1)^{-1}\sum_{Z_i=0}[Y_i - \hat{\bar{Y}}(0)]^2$$

...

3.3. ... *：当 treatment 组和 control 组的方差差异较大时，差值均值的检验可能失效。学生化通过分别估计两组的方差，能够更好地处理异方差情况。*

...

Insight ... ”...

...

. ... Karl Pearson... 1900 ...

---

10 ...

11ANOVA ...

7.3.1. 拟合优度检验. ŝ ⁰ ⁰ ⁰

[illegible] (共 556 株)：

$$O = (315, 101, 108, 32), \quad E = (556 \times \tfrac{9}{16}, \ldots) = (312.75, 104.25, 104.25, 34.75)$$

[illegible]：

$$\chi^2 = \frac{(315-312.75)^2}{312.75} + \frac{(101-104.25)^2}{104.25} + \frac{(108-104.25)^2}{104.25} + \frac{(32-34.75)^2}{34.75} \approx 0.47$$

自由度 $k-1=3$，查表得 $\chi^2_{0.05,3} = 7.81$。由于 $0.47 < 7.81$，[illegible] 孟德尔比例。

[illegible]：

```
> obs <- c(315, 101, 108, 32)
> prob <- c(9/16, 3/16, 3/16, 1/16)
> chisq.test(obs, p = prob)

    Chi-squared test for given probabilities

X-squared = 0.47, df = 3, p-value = 0.925
```

p 值为 0.925——数据与孟德尔比例高度吻合。

□

7.3.2. 独立性检验. [illegible]

[illegible] $r \times c$ [illegible] X [illegible] Y [illegible]

[illegible] O_{ij} [illegible] (i,j) [illegible] $O_{i\cdot} = \sum_j O_{ij}$ [illegible] i [illegible] $O_{\cdot j} = \sum_i O_{ij}$ [illegible] j [illegible] n

[illegible] $H_0 : X \perp Y$ [illegible]

$$E_{ij} = \frac{O_{i\cdot} \cdot O_{\cdot j}}{n}. \tag{24}$$

[illegible]

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(O_{ij}-E_{ij})^2}{E_{ij}}. \tag{25}$$

[illegible] [illegible] H_0 [illegible] $(r-1)(c-1)$

Insight [illegible] 2×2 [illegible] [illegible] 1[illegible] [illegible] [illegible] [illegible] p[illegible] [illegible] [illegible]

[illegible] [illegible] 2×2 [illegible] R [illegible] `chisq.test` [illegible] Yates [illegible] [illegible]

$$\chi^2_{\text{Yates}} = \sum \frac{(|O-E|-0.5)^2}{E}.$$

[illegible] 3.3 (2×2 [illegible]). 考虑二元结局的随机实验，数据汇总为：

	成功 ($Y=1$)	失败 ($Y=0$)	合计
治疗 ($Z=1$)	$n_{11}=30$	$n_{10}=20$	$n_1=50$
对照 ($Z=0$)	$n_{01}=20$	$n_{00}=30$	$n_0=50$

ä **1** :

$$E_{11} = \frac{50 \times 50}{100} = 25, \quad E_{10} = \frac{50 \times 50}{100} = 25, \quad E_{01} = \frac{50 \times 50}{100} = 25, \quad E_{00} = 25$$

ä **2** χ^2:

$$\chi^2 = \frac{(30-25)^2}{25} + \frac{(20-25)^2}{25} + \frac{(20-25)^2}{25} + \frac{(30-25)^2}{25} = 4$$

自由度 $(2-1)(2-1) = 1$，临界值 $\chi^2_{0.05,1} = 3.84$。由于 $4 > 3.84$，⍗⍐⍓ ⍰⍟ ——治疗与结局存在关联。

R ⍟ :

```
> tb <- matrix(c(30, 20, 20, 30), nrow = 2, byrow = TRUE)
> chisq.test(tb)

    Pearson's Chi-squared test with Yates' continuity correction

X-squared = 4, df = 1, p-value = 0.0455
```

注意 *Yates* 修正后的 χ^2 从 4 降到 3.24，p 值 $= 0.072$——这说明连续性修正在小样本时影响显著。

□

⍰ 3.4 (3×2 ⊞§§ ⍐⍒). ⋇⋔ : 研究吸烟状态与肺癌诊断的关联，数据如下：

	患肺癌	未患肺癌	合计
重度吸烟	*60*	*40*	*100*
轻度吸烟	*20*	*30*	*50*
不吸烟	*10*	*40*	*50*

ä **1** :

$$E_{11} = \frac{100 \times 90}{200} = 45, \quad E_{12} = \frac{100 \times 110}{200} = 55$$
$$E_{21} = \frac{50 \times 90}{200} = 22.5, \quad E_{22} = \frac{50 \times 110}{200} = 27.5$$
$$E_{31} = \frac{50 \times 90}{200} = 22.5, \quad E_{32} = \frac{50 \times 110}{200} = 27.5$$

ä **2** χ^2:

$$\chi^2 = \frac{(60-45)^2}{45} + \frac{(40-55)^2}{55} + \frac{(20-22.5)^2}{22.5} + \frac{(30-27.5)^2}{27.5} + \frac{(10-22.5)^2}{22.5} + \frac{(40-27.5)^2}{27.5} \approx 20.4$$

自由度 $(3-1)(2-1) = 2$，查表 $\chi^2_{0.05,2} = 5.99$。由于 $20.4 > 5.99$，⍗⍐⍓ ——吸烟与肺癌存在显著关联。

R ⍟ :

```
> tb <- matrix(c(60, 40, 20, 30, 10, 40), nrow = 3, byrow = TRUE)
> rownames(tb) <- c("重度吸烟", "轻度吸烟", "不吸烟")
> colnames(tb) <- c("患肺癌", "未患肺癌")
> chisq.test(tb)

    Pearson's Chi-squared test
```

```
X-squared = 20.4, df = 2, p-value = 3.7e-05
```

p 值极小，结论稳健。

□

例 3.5 (4×3 ...). 调查 *500* 人的教育程度与收入水平：

	低收入	中等收入	高收入	合计
初中及以下	*80*	*50*	*20*	*150*
高中	*60*	*80*	*30*	*170*
本科	*30*	*70*	*40*	*140*
研究生	*10*	*30*	*100*	*140*
合计	*180*	*230*	*190*	*500*

R ...：

```
> edu <- c(80, 50, 20, 60, 80, 30, 30, 70, 40, 10, 30, 100)
> tb <- matrix(edu, nrow = 4, byrow = TRUE)
> rownames(tb) <- c("初中及以下", "高中", "本科", "研究生")
> colnames(tb) <- c("低收入", "中等收入", "高收入")
> chisq.text(tb)

    Pearson's Chi-squared test

X-squared = 186.7, df = 6, p-value < 2.2e-16
```

p 值极小，拒绝独立性——教育程度与收入水平存在强关联。

... ：对于 $r \times c$ 表，还可以计算 *Cramér V* 来衡量关联强度：

$$V = \sqrt{\frac{\chi^2}{n \times \min(r-1, c-1)}}. \tag{26}$$

对于本例，$V = \sqrt{186.7/(500 \times 2)} \approx 0.43$，表示中等偏强的关联。

□

7.3.3. 二元结局下的卡方检验：与 *Fisher* 精确检验的对比. ...

U a。 ...

	Chi-square test		Fisher exact test	
...	...	...	...	...
p	...		...	
...	...	> 5	...	< 5

Insight ... Fisher ... p ...
... Chi-square ...

... Bertrand & Mullainathan, 2004 ...

```
resume = read.csv("resume.csv")
Alltable = table(resume$race, resume$call)
Alltable
```

```
#          0     1
# black 2278  157
# white 2200  235
```

⌀⌀⍨″ 2×2 ⍣⍢⌂⌀⍢

		‡ᵘ	$(Y=1)$	‡ᵘ	$(Y=0)$	⌀⍰
⍙⌀⍢	$(Z=1)$		157		2278	2435
⍜⌀⍢	$(Z=0)$		235		2200	2435

⍰⍚⌀⍙⍙⍜ ⌀⌀⌀⍢

$$E_{11} = \frac{2435 \times 392}{4870} \approx 195.7, \quad E_{12} = \frac{2435 \times 4478}{4870} \approx 2239.3$$
$$E_{21} = \frac{2435 \times 392}{4870} \approx 196.3, \quad E_{22} = \frac{2435 \times 4478}{4870} \approx 2238.7$$

⍜ ⌀⌀⍨⍰ ᵖ 5⍜⌀⍰⌀⍚ ⍵⌐

```
> chisq.test(Alltable)

    Pearson's Chi-squared test with Yates' continuity correction

X-squared = 17.6, df = 1, p-value = 2.7e-05
```

p ⍁ ⍜ ⍰ Ⅎ‡ᵘ⅄ ⌊⍙⍢ ⍣⍢ ⍢

k Q》 j ; l ⍺⌊⍜; l ⍀⍵ ⍵⌐ ⍣⍙⍚⌐ ⍛⍛⍰⍺⍚⍰ $H_0 : \tau = 0$⍛⍛⍳

⍵ ⍛⍛⍰⌊⍙ᵖ⍣ ⍵ ⅋⍛⍰⍺ $\widehat{\mathrm{RD}} = \hat{p}_1 - \hat{p}_0$ ⌊⍙⍳⍵⌐

$$\mathrm{var}(\widehat{\mathrm{RD}}) \approx \frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_0(1-\hat{p}_0)}{n_0}$$

⍰ χ^2 ⍺⍰ ⍛⍚ $(\widehat{\mathrm{RD}})^2 / \mathrm{var}(\widehat{\mathrm{RD}})$ ⌊⍙⌐ ⍳ᵒ

⍀⌀⍢ ⍛⍚ ⍙⍙⌊⍳⍵ ⍀

(1) ⍚⍙⍜⍺⍚ ⍜ ⌀⌀⍨ < 5⍛⍛ ⍰ 2×2 ⍛⍛⍜⍙ ⍛⍛⍚ Fisher ⍳⍚⌐

(2) ⍚⍙⍜ ⍣⍙⍙ ⍜⍰ ⍀⍙⍰ ⍵⍙⍜ ᵖ⍜ ⌀⌀⍨

(3) ⍛⍛⍚ ⍀ ⍣⍙⍙⍰ `chisq.test(tb, simulate.p.value = TRUE)`

Insight ⍀⍵ ⍀⍙⍰ ⍀⍙⍰ ⍵⍰ ⍀⍙⍰ ⍀⍙⍰ ⍀⍙

- ...
- ...
- ...

... KS ...

...

$$D = \max_y |\hat{F}_1(y) - \hat{F}_0(y)|,$$

... $\hat{F}_1(y) = n_1^{-1} \sum_{i=1}^{n} Z_i \mathbb{I}(Y_i \le y)$ ...

...

...

...

1986 ... Robert LaLonde ... National Supported Work Demonstration ...

... R ... FRT ...

```
library(Matching)
data(lalonde)
z <- lalonde$treat
y <- lalonde$re78
```

...

...	...	...
$\hat{\tau}$	2.84	... t ...
t	2.67	...
W	27402.5	Wilcoxon ...
D	0.132	KS ...

... Monte Carlo ...

Monte Carlo ... $R = 10^4$ ...

```
> exact.pv = c(mean(Tauhat >= tauhat),
+              mean(Student >= student),
+              mean(Wilcox >= W),
+              mean(Ks >= D))
> round(exact.pv, 3)
[1] 0.002 0.002 0.006 0.040
```

... p ... 0.05 ...

... FRT ...

q 『w q w b ; j Q James Lind (1716-1794)

12 6

2×2 H_{0F}

$$p_{\text{frt}} = \frac{1}{\binom{12}{2}} = \frac{1}{66} = 0.015.$$

q 『w ‖ w U ^ Q w

8 4 4

$X = 4$ p

$$p_{\text{frt}} = \frac{1}{70} = 0.014.$$

13 H_{0F} X Hypergeometric$(N = 8, K = 4, n = 4)$ $\mathbb{P}(X = 4) = 1/70$ p $p_{\text{frt}} = 1/70 \approx 0.014$ Fisher

(1) p
(2) FRT

q q w 、 ^ ; ‘ g g

FRT H_{0F} sharp null

(27) $$H_0(\boldsymbol{\tau}) : Y_i(1) - Y_i(0) = \tau_i \quad i.$$

$\boldsymbol{\tau}$ $(1-\alpha)$

q ‖ w

(1) $\mathbf{I} \sim \mathbf{P}$ $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = 1/\binom{n}{n_1}$
(2) $+$
(3) 、 ^ ; **s** H_0 **g**: **g** $Y_i(1) = Y_i(0)$ i
(4) **s** $p_{\text{frt}} = M^{-1} \sum_{m=1}^{M} \mathbb{I}\{T(\mathbf{z}^m, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$
(5) $\hat{\tau}$ t Wilcoxon W KS D
(6) FRT
(7) Lind Fisher

Neymanian

q ∼ w

3.1. *3.1 —p_{frt} 的精确性* 证明在 *sharp null* 下，p_{frt} 满足：

$$\mathbb{P}(p_{frt} \leq u) \leq u \quad \textit{for all} \quad 0 \leq u \leq 1.$$

13 ??

[illegible] 3.2. *3.2* —*Monte Carlo* 误差 设 p_{frt} 是固定值，$\hat{p}_{frt}$ 是其 *Monte Carlo* 估计（见 [illegible]）。证明：

$$\mathbb{E}_{mc}(\hat{p}_{frt}) = p_{frt}, \quad \mathrm{var}_{mc}(\hat{p}_{frt}) \le \frac{1}{4R},$$

其中下标*"mc"*表示由于 *Monte Carlo* 的随机性。

[illegible] 3.3. *3.3* —有限样本有效的 *Monte Carlo* 近似 证明修正的 *Monte Carlo* 近似

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^{R} \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \ge T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

在任意有限的 R 下都是有限样本有效的 p 值。

[illegible]：可以利用以下两个基本概率结果：

(1) 对于两个二项分布 $X_1 \sim Binomial(R, p_1)$ 和 $X_2 \sim Binomial(R, p_2)$，若 $p_1 \ge p_2$，则 $\mathbb{P}(X_1 \le x) \le \mathbb{P}(X_2 \le x)$。

(2) 若 $p \sim Uniform(0,1)$ 且 $X \mid p \sim Binomial(R, p)$，则 X 在 $\{0, 1, \ldots, R\}$ 上均匀分布。

[illegible] 3.4. *3.4* —*Fisher* 精确检验 考虑二元结局的 *CRE*，数据汇总为 2×2 列联表：

	$Y=1$	$Y=0$	合计
$Z=1$	n_{11}	n_{10}	n_1 着
$Z=0$	n_{01}	n_{00}	n_0

在 H_{0F} 下，证明任何检验统计量 $T(n_{11}, n_{10}, n_{01}, n_{00})$ 是 n_{11} 的函数，且 n_{11} 的精确分布是超几何分布。请说明超几何分布的参数。

[illegible] 3.5. *3.5* —女士品茶详细计算 回忆女士品茶实验（见 [illegible]）。计算 $\mathbb{P}(X = k)$，其中 X 是女士正确识别 k 杯先加牛奶的茶的个数，$k = 0, 1, 2, 3, 4$。

[illegible] 3.6. *3.6* —协变量调整的 *FRT* 使用 *LaLonde* 数据集（见 [illegible]），添加协变量进行 *FRT* 分析。假设所有潜在结果和协变量都是固定数值。

有两种策略：

(1) 运行结局对协变量的线性回归，得到残差（即"伪结局"）。基于残差定义四种检验统计量，进行 *FRT* 并报告 p 值。

(2) 定义检验统计量为结局对治疗和协变量线性回归中治疗系数的 *FRT*。

解释为什么上述两种策略的五个 p 值都是有限样本精确的。

[illegible] 3.7. *3.7* —*FRT* 与广义线性模型 使用与 [illegible] 相同的数据集，但将结局改为 `re78 > 0` 的二元指示变量。运行结局对治疗和协变量的 *logistic* 回归。治疗系数是否显著？*FRT* p 值是多少？

[illegible] 3.8. *3.8* —代数细节 验证 [illegible]

[illegible] 3.9. *3.9* —推荐阅读 [illegible] 是一篇倡导在复杂实验中同时报告 p 值及其相应随机化分布的论文。

CHAPTER 4

k Q》 j ; l ǎa g l

q ẅ ḡ l̈ĥ̊

Fisher's randomization test, FRT

sharp null

FRT

null

FRT

Fisher

distribution-free

Jerzy Neyman 1923

Fisherian

Neymanian

4.1. : *FRT* 适用于小样本精确推断和假设检验，*Neymanian* 适用于大样本渐近推断和置信区间构建。两者互为补充。

‖ w ı

Neymanian

Neyman

Fisher

n

n_1

$n_0 = n - n_1$

$i = 1, \ldots, n$

- $Y_i(1)$
- $Y_i(0)$
- $\tau_i = Y_i(1) - Y_i(0)$

”

”

$$\bar{Y}(1) = \frac{1}{n}\sum_{i=1}^{n} Y_i(1), \quad \bar{Y}(0) = \frac{1}{n}\sum_{i=1}^{n} Y_i(0)$$

$n-1$

$$S^2(1) = \frac{1}{n-1}\sum_{i=1}^{n}\{Y_i(1) - \bar{Y}(1)\}^2, \quad S^2(0) = \frac{1}{n-1}\sum_{i=1}^{n}\{Y_i(0) - \bar{Y}(0)\}^2$$

$$S(1,0) = \frac{1}{n-1}\sum_{i=1}^{n}\{Y_i(1) - \bar{Y}(1)\}\{Y_i(0) - \bar{Y}(0)\}$$

$$\tau = \frac{1}{n}\sum_{i=1}^{n}\tau_i = \bar{Y}(1) - \bar{Y}(0)$$

$$S^2(\tau) = \frac{1}{n-1}\sum_{i=1}^{n}(\tau_i - \tau)^2$$

4.2. **：** $Y(1)$ 和 $Y(0)$ 之间可能有相关性。若治疗组和对照组的个体是匹配的（正相关），估计的方差会减小；若是负相关，方差会增大。

∼w

Neymanian

X w(qemma 4.1 §

$$2S(1,0) = S^2(1) + S^2(0) - S^2(\tau)$$

其中 $\tau_i = Y_i(1) - Y_i(0)$ 是个体因果效应。

$S^2(\tau) = 0$ $Y_i(1)$ $Y_i(0)$ $S(1,0)$ $[S^2(1) + S^2(0)]/2$ $S^2(\tau) > 0$ $2S(1,0) < S^2(1) + S^2(0)$

1

X w k Q》 j ; l t⊥q m ‖∼u

1

$$\hat{\bar{Y}}(1) = \frac{1}{n_1}\sum_{i=1}^{n} Z_i Y_i, \quad \hat{\bar{Y}}(0) = \frac{1}{n_0}\sum_{i=1}^{n}(1 - Z_i)Y_i$$

$Z_i \in \{0,1\}$

$$\hat{S}^2(1) = \frac{1}{n_1 - 1}\sum_{i=1}^{n} Z_i\{Y_i - \hat{\bar{Y}}(1)\}^2, \quad \hat{S}^2(0) = \frac{1}{n_0 - 1}\sum_{i=1}^{n}(1 - Z_i)\{Y_i - \hat{\bar{Y}}(0)\}^2$$

$S(1,0)$ $S^2(\tau)$ $Y_i(1)$ $Y_i(0)$ Neyman

X w(Neyman (1923)**w**在完全随机化实验（*CRE*）下，令 $\hat{\tau} = \hat{\bar{Y}}(1) - \hat{\bar{Y}}(0)$。则：

1 **??**

(1) ƫ : $\hat{\tau}$ 对 τ 是无偏的:

$$\mathbb{E}(\hat{\tau}) = \tau$$

(2) ţ̣ṽṇ̃ᵩ : $\hat{\tau}$ 的方差为

$$\operatorname{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} \tag{28}$$

$$= \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1,0) \tag{29}$$

(3) ƀ̣ẇţ̣ṽIQ : 方差估计量

$$\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$$

对 $\operatorname{var}(\hat{\tau})$ 是保守的，即

$$\mathbb{E}(\hat{V}) - \operatorname{var}(\hat{\tau}) = \frac{S^2(\tau)}{n} \geq 0$$

等号当且仅当 $\tau_i \equiv \tau$（所有单元个体效应恒定）时成立。

ŭ ˙ ţ̣ṽ¸Ļ̣A ŝ ˘ẇ ˙ ♦ώ $\{Y_i(1), Y_i(0)\}$ Ḍ̣ẇơ ˙ ˙ẇ$_2$ Ẁ
ʁẂ‾ Z_i§§ḍ n_1 A 1 Ḷ̣ n_0 A 0 ļ̣ẇ ¥ƫ̈ţ̣ṽ¸ ļ̣ṇ̃ă

4.3. ᵇ˙ ˙ẇ ţ̣ ţ̣ : 直觉上：若个体因果效应存在变异（$S^2(\tau) > 0$），治疗组和对照组之间的差异不仅来自随机抽样误差，还来自因果效应本身的真实变异。这种”真实变异”不应被算作估计误差。

Wwţ̣ṽṇ̃ᵩ¸ļ̣ơ˙ẇ˙¸ļ

ţ̣ṽṇ̃ᵩ { {ᴵ¹ᵑ V̌ ļ̣ţ̣ṽṇ̃ᵩă ŏ ˙ẇ ˙ A ļ̣ţ̣ṽ
$S^2(\tau)$
A¸ẇ¹ᵈ⁶ļ̣ ŝA ŏ $\hat{\tau}$ ļ̣ţ̣ṽŠN ˙ẇ ţ̣
ᴶ¸ţ̣A˙ᵩ { {ẇ s̃ ß˙ ♦ώ ſļ̣ ŭ
∂˙ẇ ᴱ˙ᵩ ŏ ˙ᵑ¥ḍʉ Ḧ›ᵖļ̣ʁ˙ ♦ώ $\{Y_i(1)\}$ŝ

- ˙ᵩ $S(1,0) > 0$ŋ ŭ̈Ŏ ˙ẇ˙ʁļ̣β Ḧ›ᵖļ̣Ḧ ˙ ♦ώ
  ᴮŏḦ ļ̣¥ß̈♦ώ Ḧ› ŏp ›ᵖļ̣ $\hat{\tau}$
- ˙ᵩ $S(1,0) < 0$ŋ¡ ŭ̈Ŏ˙ẇ˙ʁļ̣β Ḧ› ļ̣Ḧ ˙ ♦ώ
  ᴮŏḦ ļ̣¥ß̈♦ώ Ḧ›ᵖŏp › ļ̣ $\hat{\tau}$

ᶠ˙ ♦ώ ŭ˙ŏƐ̈ß̈¥ḍʉ¢ę̌ļ̣ $\hat{\tau}$ŏ ᴮţ̣ṽƐᵖ
□ ŝᶠ $S^2(\tau) = 0$ ˙ŏ { {ũ $\operatorname{var}(\hat{\tau}) = S^2(1)/n_1 + S^2(0)/n_0$§§ᴮ˙ Neymanian
ţ̣ṽ ᴵ¹ᵑ V̌ţ̣ṽ

ˇ w k Q》 j ; l tJ̣ƫm ‖ ∼ u

ƫ ŝ [2]
ţ̣ṽ ˙ ŝ [3]
ţ̣ṽIQ¸ ŝ [4]

[2] ᵽ |ọ̇ḥ ??
[3] ᵽ |ọ̇ḥ ??
[4] ᵽ |ọ̇ḥ ??

♪≠ $\hat{V}$ ⓠuǫ̆ HC2 K ǰ̈ǫ̆ŗ $\hat{V}$ [6]
ṗ ṁ ŋ LaLonde ṁ$̃Ŏ

```
> tauhat = mean(y[z==1]) - mean(y[z==0])
> vhat   = var(y[z==1])/n1 + var(y[z==0])/n0
> sehat  = sqrt(vhat)
> tauhat
[1] 1794.343
> sehat
[1] 670.9967
```

OLS ļ ẉH ƈ ŝ

```
> olsfit = lm(y ~ z)
> summary(olsfit)$coef[2, 1:2]
  Estimate Std. Error
 1794.3431   632.8536
```

ṗ EHW ŧ Ḥ ŋ HC2Ôkʉ ƈ♦ẁôŝ

```
> sqrt(hccm(olsfit, type = "hc2")[2, 2])
[1] 670.9967
```

mw♦ɣ ≠ṁļṗ

{ {ļ CLT ğ ŧ ˷ ī ŧɾ♦ɣ ẄÄṗŏ ŧ
ɣ̈ʊ Š
ŧH ɾ ♦ẁɵ ṁṁǧ̆ṗ Cauchy ẄẅÔ ≠ṁ ẁ ˛ ɣ̈ ǰ ẁʜɹ̈ǰŏ
ṁ\ ŏ ţ ˙Ǫ ≠ṁ ∫e ɣ
ǰŝ|ṗ 1 ≠ ļ ğţṘḊ ɴ ṁɔ̈ļ ˥ ŧ ṗ½
ŏ ǰ Ó-x♦ɣ̈ķ ļẄÄ

q ŧ̃ẁ

V ˙ ŧ̃Δ Neymanian ğ|ļ1cŝ

(1) ɪ ŋă^{v} hat ļ ṗŝÔ $\{\bar{Y}(1), \bar{Y}(0), S^2(1), S^2(0), S(1,0), S^2(\tau)\}$

(2) **f Q j j ; ŝ X w S q** $S^2(1,0) = S^2(1) + S^2(0) - S^2(\tau)$

(3) **k Q 》 j ; l t q̄ m ‖ŝ ∼ u**

- $\mathbb{E}(\hat{\tau}) = \tau$ŋ ƈ̂Ô
- $\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- $\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau}) + \frac{S^2(\tau)}{n}$ŋ ħẁÔ

(4) ţ?vIΩ ŝ $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$

(5) ğ∫ ŝ $\hat{\tau} \pm z_{1-\alpha/2}\sqrt{\hat{V}}$

(6) **I f ⁂** $\frac{\hat{\tau}-\tau}{\sqrt{\text{var}(\hat{\tau})}} \xrightarrow{d} N(0,1)$

(7) **o f 、ŭ** ŝ $\hat{\beta} = \hat{\tau}$ŏb ṗ EHW ŧ Ḥ
ǰ‖ ṁ Ω ǫ̇ Ẅɛiŋ 。 — ; — a Ô[J Ụ ˙ I Ω ļ ÷ ŧ s s a ạ p̆ l
Kɯ √ôv ğ ļ ţ Ṙ

[6] ‖ò ḥ ??

q q w

4.1. { {引理的证明 证明 *Lemma* { { $2S(1,0) = S^2(1) + S^2(0) - S^2(\tau)$。

4.2. { {*Neyman (1923)* 定理的另一种证明 在 *CRE* 下，计算：

$$\text{var}\{\hat{\bar{Y}}(1)\}, \quad \text{var}\{\hat{\bar{Y}}(0)\}, \quad \text{cov}\{\hat{\bar{Y}}(1), \hat{\bar{Y}}(0)\}$$

并利用这些公式推导 $\text{var}(\hat{\tau})$。

4.3. { {*Neymanian* 推断与 *OLS* 证明 { {（*OLS* 系数等于差值均值）。证明 *EHW* 稳健方差估计量的 *HC2* 变体恰好等于 $\hat{V}$。

{ {

4.4. { {治疗效应的异质性 证明 $S^2(\tau) = 0$ 蕴含 $S^2(1) = S^2(0)$。给出反例说明 $S^2(1) = S^2(0)$ 但 $S^2(\tau) \neq 0$。

证明 $S^2(1) < S^2(0)$ 蕴含 $S(Y(0), \tau) < 0$。给出反例说明 $S^2(1) > S^2(0)$ 但 $S(Y(0), \tau) < 0$。

4.5. { {方差公式的改进上界 证明方差公式的改进上界：

$$\text{var}(\hat{\tau}) \leq \frac{1}{n}\left\{\sqrt{\frac{n_0}{n_1}}S(1) + \sqrt{\frac{n_1}{n_0}}S(0)\right\}^2$$

并讨论等号成立的条件。

4.6. { {*Neyman (1923)* 的向量版本 将 *Neyman (1923)* 的结果推广到多结局情形。考虑向量结局 $\mathbf{V} \in \mathbb{R}^K$ 的平均因果效应：

$$\tau_{\mathbf{V}} = \frac{1}{n}\sum_{i=1}^{n}\{\mathbf{V}_i(1) - \mathbf{V}_i(0)\}$$

证明 $\hat{\tau}_{\mathbf{V}}$ 对 $\tau_{\mathbf{V}}$ 是无偏的，并求出其协方差矩阵。

4.7. { {完全随机化实验中的推断 回忆在 { {中定义的完全随机化实验。在这种设定下，推导平均因果效应的方差公式，并比较其与 *CRE* 中方差的差异。

4.8. { {推荐阅读 ：{ 重新审视了因果推断中的一些经典问题。{ 是关于因果推断的权威综述。

：*Neyman 1923* 年的原始论文 { 奠定了有限总体推断的基础。当代统计学家将其视为因果推断范式的里程碑。

CHAPTER 5

Ẅẅẗ ẗẄẅẗẉ₂ẉ

q wŝẉ₂ω̂ẉ ẇ

"Block what you can and randomize what you cannot." — (☰ page 103)

ẉ George Box ⅛ "ẉ ẞ Ḍẉᵐẅẗ ẗ" ẗᵑÔ ẞẅẞ ẗ ╟

ẉ ẇ ☰ ☰ẅ ẉ₂ẉ ŋ CREÔ ẗ ʁ Ẅ ẉ chance ‾ ẉ ᵖ

ẗ ʜ ẅ ẗ ẉ ẗʁ ẅẗ ẅ ẗ ẅ ẅ

ẅ ẹ **J p ” ; a ; — Q a ẇ ẗ ẅ B ; g ; l J Q**

ẉ ᵉ covariate imbalance Lẇᵤ ẗ ẇẅẅẉ ♦ẅẅ ẇKẏᵈẉ§§ ẅ

ẗdʁẅ ẅẗ treatment ẅ ẅẗ ẅẅẅẉ ẗ ẅẗẅẅẉ ẗ ẗ ẗ ẅ ẅ ẗ ẗ ẗ

(2) SRE $e_{[k]}$ ... CRE ...

...

... $Y_i(1)$ ... $Y_i(0)$ ... $\tau_i = Y_i(1) - Y_i(0)$ ... k ...

$$\tau_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} \tau_i.$$

...

$$\tau = n^{-1} \sum_{i=1}^{n} \tau_i = \sum_{k=1}^{K} \pi_{[k]} \tau_{[k]}.$$

... τ ...

$$\hat{\tau}_{\mathrm{SRE}} = \sum_{k=1}^{K} \pi_{[k]} \hat{\tau}_{[k]},$$

...

$$\hat{\tau}_{[k]} = n_{[k]1}^{-1} \sum_{i=1}^{n} \mathbb{I}(X_i = k, Z_i = 1) Y_i - n_{[k]0}^{-1} \sum_{i=1}^{n} \mathbb{I}(X_i = k, Z_i = 0) Y_i$$

... k ... $\tau_{[k]}$ ... k ... CRE ...

... ...

CRE ... SRE ... Fisher ... FRT ... Sharp null ...

$$H_{0F} : Y_i(1) = Y_i(0) \quad i = 1, \ldots, n.$$

FRT ... $T = T(\mathbf{Z}, \mathbf{Y}, \mathbf{X})$ ... $\mathbf{Z}, \mathbf{Y}, \mathbf{X}$ ... SRE ... H_{0F} ... T ... **Z** SRE ... FRT ...

(1) ... X ...

(2) ... SRE ...

...

4.1.1. 分层差值均值估计量. ... FRT ... $\hat{\tau}_{\mathrm{SRE}}$ ...

... 5.1 (...). 在 *FRT* 中，我们可以使用分层估计量作为检验统计量：

$$T = \hat{\tau}_{\mathrm{S}} = \sum_{k=1}^{K} \pi_{[k]} \hat{\tau}_{[k]},$$

其中 $\hat{\tau}_{[k]}$ 由 ... 定义。这个统计量直接衡量了跨层的平均因果效应。

4.1.2. 学生化分层估计量. 为了将 FRT 框架扩展到分层设计，我们使用学生化统计量

$$t_{\mathrm{SRE}} = \frac{\hat{\tau}_{\mathrm{SRE}}}{\sqrt{\hat{V}_{\mathrm{SRE}}}},$$

其中

$$\hat{V}_{\mathrm{SRE}} = \sum_{k=1}^{K} \pi_{[k]}^2 \left(\frac{\hat{S}^2_{[k]}(1)}{n_{[k]1}} + \frac{\hat{S}^2_{[k]}(0)}{n_{[k]0}} \right).$$

这里 $\hat{S}^2_{[k]}(1)$ 和 $\hat{S}^2_{[k]}(0)$ 分别是层 k 内处理组和对照组的样本方差[2]。

定义 5.2 (学生化分层估计量). 对于第 4 章中的学生化统计量 t_{SRE}，我们需要计算其方差估计量 $\hat{V}_{SRE}$（由第 3 章给出）。在 *FRT* 中，我们通过模拟所有可行的 *treatment* 分配来计算 t_{SRE} 的精确分布。

4.1.3. 合并 *Wilcoxon* 秩和统计量. 在层 k 内计算 Wilcoxon 秩和统计量 $W_{[k]}$，然后合并：

$$W_{\mathrm{SRE}} = \sum_{k=1}^{K} c_{[k]} W_{[k]}.$$

第 4 章讨论了两种权重选择 $c_{[k]} = 1/(n_{[k]1} n_{[k]0})$ 和 $c_{[k]} = 1/(n_{[k]} + 1)$

定义 5.3 (Van Elteren 检验). 在第 k 层内，我们计算 *Wilcoxon* 秩和统计量 $W_{[k]}$（回忆第 3 章的 *Wilcoxon* 秩和检验），然后使用第 4 章合并各层统计量。*Van Elteren (1960)* 的两种加权方法在不同场景下各有优势。

4.1.4. *Hodges–Lehmann* 对齐秩统计量. Van Elteren (1960) 与 Hodges–Lehmann 对齐秩统计量的区别在于第 4 章讨论的两种加权方法。

第 4 章讨论了两种权重选择 $c_{[k]} = 1/(n_{[k]1} n_{[k]0})$ 和 $c_{[k]} = 1/(n_{[k]} + 1)$

定义 5.4 (Hodges–Lehmann 对齐秩检验). 第 4 章的方法首先通过第 3 章对齐结果，这消除了层间差异的影响。然后对池化结果求秩，并使用第 3 章作为检验统计量。这种方法在多个小层情况下特别有效。

[2] 第 3 章 第 3 章 第 3 章 第 3 章 第 3 章

dX *_1Ï¥ª$ª

µÖÛxM X ¥ *_1Ï » k ª=¤sÍ „ v¥†í"^Û ¥b
a_1Ï ƒt"3^%ç¥bŒÂTáÌ óç M= $f n_{[k]1}; n_{[k]0} g_{k=1}^{K}$ ¥Hq/É›Hqw
*¹ *_1üMî a_1b
"Ð ÂT M¥îµs û,¹, *¹ ³

$$S_{*\_1}(w= x_j M) = \frac{S_{*\_1}(w= x_j M)}{S_{*\_1}(M)} = \frac{1}{\sum_{k=1}^{K} n_{[k]} n_{[k]1}}:$$

' wóç MHq/V *_1¤ž¥Hqsƒ ÐV a_1¤ž¥sƒM]b
yN óç M¥Hq/ áÌV[^s a_1B"s {µÖÛxM X ¥ *_1b
6_hM¹Hq 6_h L2vK MB‰M¹ ªsª TQbi@bi` iB}+ iBQM

$$\hat{S}_a = \sum_{k=1}^{K} {}_{[k]}\hat{}_{[k]}:$$

™TÐ ^a_1M]b
sª !9¨P¨ X ªsª s ¨P¨ X bñÌ^P¨ X ¥ }ZEb

3XLlÏ¥Ù5

Â…Ê4X Ÿy a_1$Ø, X ‹¾?ç©.²Tb tfƒ/L €ô
5•ùî© ç©xM µ@ ¥ß©M *¹ X ¥Ê4V[°¤'çb ðf
ƒ/ƒÕ ß©M, b L €Q7ô ZLŸÊ4 XiièÂ X V[^ùîu
×¥·UM Ð3M)b
K ¥Ê4^BñM1Ù5 bØ, ÂTîµªû@ v 9F K ö4Ú 9rqb
–7 v¥ K.ÀV?†® 9rqb EùîÏ á4³ž9F K ¥H=l
m¾hbÜ K=5 YÈ@[¤rq9mb
»õÃxM 8¹÷$ ÂTáÌµ5•ùî V[yëóçftxM H.²T
Y(0) ¥ ~ –ªÊ4 X ¹ç© Ŷ(0) ¥ÖÛÄñ'bBî¹ ÂTáÌÀµƒ"
¥5•ùî €,XS+!¥ÖÛÄ áÌV[P¨BÕ÷Y¨¥¦{ ë¹ ×Û Ä
`2` M/QKBx bBQM

NXcl²

'cº sªÐªsªÛ L ö1=¸Â/

URaV_1¥î *_1V?Á3,ù¬¥Í s¥ YVsªV[öîEç +Qp `B i2
BK# HbM+2

UkaV_1çl \\ ÖÛxM ¥òª=ÿëÉ› *_1%çòª¥Í s¥"
b

UjVq9m 'xM ?ç©.²TH a_11 *_1÷µr y¹sªh"
ªWMs n \\b

U96V_h „ L2vK MBwM ûV[w<ž a_1sY \\ „ \\Ï),b

U8ªVsª *_1Ïóçsª" Hqª s ZEÐ a_1M]iiƒ^P¨xM
¥ }ZEb

---

³£ün¸c \\

是 *Neyman (1923)* 的方差公式（见第 { {章），且

$$R^2 = corr^2(\hat{\tau}, \hat{\tau}_X)$$

是 $\hat{\tau}$ 与 $\hat{\tau}_X$ 在 *CRE* 下的平方多重相关系数。

Li et al. (2018b) $\hat{\tau}$ $\hat{\tau}_X$ $\cos^2\theta = R^2$ θ $\hat{\tau}$ $\hat{\tau}_X$ ReM $L_{K,a}$ ReM

- $a = \infty$ CRE $\hat{\tau} - \tau \dot{\sim} \sqrt{\mathrm{var}(\hat{\tau})}\varepsilon$
- $a \to 0$ $\hat{\tau} - \tau \dot{\sim} \sqrt{\mathrm{var}(\hat{\tau})(1-R^2)}\varepsilon$

a ReM R^2 R^2 ^{2}

6.1 R^2 **在** *CRE* **下，**

$$R^2 = corr^2(\hat{\tau}, \hat{\tau}_X) = \frac{n_1^{-1}S^2(1 \mid X) + n_0^{-1}S^2(0 \mid X) - n^{-1}S^2(\tau \mid X)}{n_1^{-1}S^2(1) + n_0^{-1}S^2(0) - n^{-1}S^2(\tau)},$$

其中 $\{S^2(1), S^2(0), S^2(\tau)\}$ 是 $\{Y_i(1), Y_i(0), \tau_i\}$ 的有限总体方差，$\{S^2(1 \mid x), S^2(0 \mid x), S^2(\tau \mid x)\}$ 是它们在 $(1, X_i)$ 上线性投影的相应有限总体方差。在常因果效应假设（$\tau_i = \tau$）下，R^2 退化为 $S^2(0 \mid X)/S^2(0)$，即 $Y_i(0)$ 与 X_i 之间的有限总体平方多重相关系数。

ReM ReM Neyman (1923) overcover τ Li et al. (2018b) Δ_1 { {

X w ‡ᵘ ŝẅ ◙Ĝ Ku ₘ

Δ ‡ᵘ

X w q w U a。 Q w Ku X H0F T = T(Z, Y, X) p §§ FRT

Zhao and Ding (2021a)

6.5 (Ku FRT). 基于拟合统计模型后的残差构造检验统计量。将 Y_i 对 X_i 回归得到残差 $\hat{\varepsilon}_i$，然后将 $\hat{\varepsilon}_i$ 视为伪结果来构造检验统计量。

6.6 (Ku FRT). 使用回归系数作为检验统计量。将 Y_i 对 (Z_i, X_i) 回归，取 Z_i 的系数作为检验统计量。

ŝ Y_i X_i Z_i H_{0F} H_{0F} Y_i (Z_i, X_i) Z_i Z_i H_{0F} ” ‡ ” A logistic ‡ 2 H_{0F}

2 ??

Ww

Ww q w ~‡QlĚ **w**Li et al. (2018b) ml ReM l Lin (2013) l‡Qu
w Kl lĝ Q w Ěl l ε Y ulĝ a ˛ w ReM τ̂ l CRE τ̂L l ReM ĝ Kl Lin (2013) l‡
Qu W Ğw Kl a ˛ w l l
ĝ Ğ ” W Ğ ŝ Ě ŏ Y ĝ Ğ ĝ ReM h K
1 wĺŏ W Ğ ĝ‡Qu v ä Ų ” ” ü

Ww ‡Qu wĚWil **w** Ki C_i K
Ll $K-1$ A l jK ŝ

$$X_i = \big(\mathbb{I}(C_i = 1) - \pi_{[1]}, \ldots, \mathbb{I}(C_i = K-1) - \pi_{[K-1]}\big),$$

S $\pi_{[k]}$ w $C_i = k$ lβ Ç w ŏ Lin (2013) l‡Qu l ĚWilŏl
S

S **w(R** 6.3 §‡Qu ĚWil)**w**基于 X_i 的 $\hat{\tau}_{\mathrm{L}}$ 在数值上与基于 C_i 的后分层估计量 $\hat{\tau}_{\mathrm{PS}}$（见第 { {章）相同。

A S ‹ Q‡Qu ĚWil ∫lSilŏ §§lwgV alwiɹ Kl ă w
ĺlJ ă

Ww wKl l **w** Ķ ŵ ŏ A l Kl X w8ɹ
l Ě ă ŏl ◦ ŵ ŏlł Y w8 ĚBlę əŏlĵ ˚ Kl X w1
Blę əSlł Y wE ˛ ĚlĤwE ŏlĵ ˚ Kl X wE ˛ ɹlĤw
E

╟ Ě X Kl ŏ A3 lIQl wL $\beta_1 = \beta_0 = 1$ l Ww5Ww
IQl ŝ

$$\hat{\tau}(1,1) = n_1^{-1}\sum_{i=1}^{n} Z_i(Y_i - X_i) - n_0^{-1}\sum_{i=1}^{n}(1-Z_i)(Y_i - X_i).$$

p A w Δ ” Ww ” A lă l §§lwV alw Ww $g_i = Y_i - X_i$
lIł ´ pÔA w Δ ” 3W ” A lă l §§lwP A´ 3lIł
ŭ F ŝ $\hat{\tau}(1,1)$ ő $\beta_1 = \beta_0 = 1$ ŏ Lin (2013) lIQl ĝ D A IQl lj β
$\hat{\tau}(1,1)$ w Ql ŏ Lin (2013) lIQl V w Ql b J lwlŏ Lin (2013)
lIQl p V wC $\hat{\tau}(1,1)$ ε

W

C aWilj ŏ Y Hl M l Kl X alŵ
ilD Ě P ŏ l A ilc4k Lin (2013) lIQl $\hat{\tau}_{\mathrm{L},[k]}$ ŏĚ ŵ lQl ĩ

$$\hat{\tau}_{\mathrm{L,S}} = \sum_{k=1}^{K} \pi_{[k]}\hat{\tau}_{\mathrm{L},[k]}.$$

hwlj t IQl w

$$\hat{V}_{\mathrm{L,S}} = \sum_{k=1}^{K} \pi_{[k]}^2 \hat{V}_{\mathrm{EHW},[k]},$$

S $\hat{V}_{\mathrm{EHW},[k]}$ wil k ŭ╟ H~ Kl hS▌Ỹv OLS ăĚl
EHW t IQl lwlŏ l ╟ Kl ŵ A il ˜ l´

Li and Ding (2020) Lin (2013) EHW Neyman (1923) Li and Ding (2020)

Table 1.

	$\hat{\tau}$ (Neyman, 1923)	$\hat{\tau}_{\mathrm{L}}$ (Lin, 2013)
CRE		
ReM	$\hat{\tau}$ (Li et al., 2018b)	$\hat{\tau}_{\mathrm{L}}$ (Li and Ding, 2020)

- 1
- 2 ReM ReM
- 3 4 ReM CRE

Angrist et al. (2009) GPA GPA

6.1 ( ). 我们使用 *Angrist et al. (2009)* 数据的一个子集，评估四种设计与分析策略的表现。

代码实现（省略数据读取和缺失值填补）：

```
# 未调整估计量
fit_unadj = lm(y ~ z)
ace_unadj = coef(fit_unadj)[2]
se_unadj = sqrt(hccm(fit_unadj, type = "hc2"))[2, 2]

# 回归调整
x = scale(x)
fit_adj = lm(y ~ z*x)
ace_adj = coef(fit_adj)[2]
se_adj = sqrt(hccm(fit_adj, type = "hc2"))[2, 2]
```

模拟结果（*2000* 次蒙特卡洛复制，*ReM* 阈值 $a = 0.05$）：

估计量	估计值	标准误	t 统计量	p 值
Neyman	*0.054*	*0.076*	*0.719*	*0.472*
Lin	*0.075*	*0.072*	*1.036*	*0.300*

调整后的估计量有更小的标准误，尽管它给出了与未调整估计量相同的（不显著）结论。

ReM 0.1 0.25

Þ ɑ ɯ ɯ ɯ ᵁ ∨ ˥ ˥ Q § § ɑ t ɯ ɑ ɯ ˥ ɯ I ɯ ɯ I
Q ɯ ˥

Ô Ŝ ɯ ɯ ɯ ɯ ˥ Q ɯ ɯ I ɯ ɯ ReM ˥ Q ‡ Q ᵁ Ð Ù Δ ɾ ɾ
ɯ ɯ ɯ ɯ ɯ § § ɯ Ô ɯ

mwŝ Kɯ ɯ ɯ ˥ ɯ ɑ x

Ŵ Ł ɯ Δ ɯ ɯ Kɯ ˥ ɯ Ŷ ˥ ɯ ɯ ɯ ɯ ɯ ɯ ReMÔ Q ‡ Q ᵁ
~ Q i ɯ Mahalanobis ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ
ɯ Z ɯ X ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ 1 $X_i = (x_{i1}, \ldots, x_{iK})^\top$ ɯ H ɯ ɯ
ɯ ɯ ɯ $|\hat{\tau}_{x_k} / \sqrt{n/(n_1 n_0) S^2_{x_k}}| \le a$ ɯ $k = 1, \ldots, K$ Ô ɯ ɯ Z ɯ Zhao and Ding (2021b) Ḧ $_1$ ᴮ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ

U a 。 ɯ Q : k I o “ ɯ ɯ ɯ ɯ Lin (2013) ɯ ɯ ɯ ɯ
ɯ ɯ ɯ Ḧ Ô ɯ ɯ logistic ‡ Q ɯ ɯ ɯ ɯ ɯ
§ § ɯ ɯ logistic ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ
ɯ ɯ logistic ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ
ɯ ɯ Lin (2013) ɯ ɯ ɯ CRE ɯ ɯ ɯ Guo and Basse (2023) ɯ Lin (2013) ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ

f a l t ‖ ɯ ɯ ɯ ɯ ɯ Bloniarz et al. (2016) ŭ Kɯ ɯ
ɯ Ḵ ɯ ɯ ɯ LASSO ɯ ɯ OLS ɯ ɯ Lei and Ding (2021) ŭ K
1 ɯ ɯ Ô ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ ɯ

- 6.11. 差分估计量的方差 推导 $\hat{\tau}(1,1)$ 的保守方差估计量 $\hat{V}(1,1)$。

- 6.12. 回归调整与后分层的等价性 证明命题 {{3}}。

- 6.13. 协变量不平衡与效率 模拟研究当协变量与结果的相关性从 0.1 变化到 0.9 时，回归调整的效率增益如何变化。

- 6.14. 高维协变量的 *LASSO* 调整 使用 *LASSO* 代替 *OLS* 进行回归调整，比较两者在协变量稀疏时的表现。

- 6.15. 缺失数据的填补 在 {{4}} 的模拟中，评估不同缺失值填补策略对估计量的影响。

*> Sh1_ d

¥ Û L

RX„ý Vsªž¥ ¥ Á p

» \\ c¥sªÛ L a_1Ï á Ì|†í¿xM sª Äª=ÿëÉ›
›†Û L b'Äªºµ B ñ Í †í„B ñ v†íH á Ì¤ž a_1¥K
™Tii ¥ Û L J i+?2/@S B`b 1tT2`BK2MN-HJSÄ1Bª9ë¹B
ñ T Bb
JS1A»º^ a_1¥Bñ+è Œñšµÿ+ 9„w ¦{ OÐ4©Ÿùî Ï
¥Ä¥ZEáMM1 | » \\ cW%),byN '€| ÿëîcb
,•Ù5 'xM ? ç©. ²TH |M»¥†í¥ ª Û s¥Í ?Ž
ÉB„4Ú 9Ú $

kX JS1¥çlÐ:|

InBñ c 2n ñ†í¥L bÂTáÌšµ? ç©²T¥xM V[ô xM
¥M»Ÿ|†í¥ b ¿†S xM áÌV[ô ¾xM †í†½ –ª¥
M#¥†íb ¿ »xM V[çl†í-W¥î Ö –ªP¨ ¢ØE K
ªd=sÄ¥ØEÉ›¥ b R
:(i;j) VU»i Ï¥» j ñ†í Ï i=1;::::;n j=1;2b†í (i;j) ¥. ²
T¹ $Y_{ij}(1)$ ¤sÍ „ $Y_{ij}(0)$ ¤s vb ÄB=Û s¥Bñ†í¤sÍ
6Bñ¤s vbçl

$$Z_i = \begin{cases} 1; & \text{Ï»Bñ†í¤sÍ} \\ 0; & \text{Ï»=ñ†í¤sÍ} \end{cases}$$

UjjV

çl dXR¥ ŒÛ L UJS1XváÌµ

$$(Z_i)_{i=1}^n \quad \text{AA} \cdot \text{"} 2`MQ(1/2H:HB$$

'Í ·UM $(Z_1;::::;Z_n)$ ÿë]sf ›V•”¹ 1/2 ¥umæsfb

»i =¥4©²T¹

$$Y_{i1} = Z_i Y_{i1}(1) + (1 \quad Z_i) Y_{i1}(0); \quad Y_{i2} = Z_i Y_{i2}(0) + (1 \quad Z_i) Y_{i2}(1):$$

yN 4©” ¹ $(Z_i; Y_{i1}; Y_{i2})_{i=1}^n$ b

jX 6Bb?Û2`Ä_

Ð-•L B" áÌSÔV[P¨ 6Bb?Û2`Ä_ 6_hŸ_ UÌ,L!
Uj9V $H_{0F} : Y_{ij}(1) = Y_{ij}(0)$ îµ $i = 1;::::;n$ „ $j = 1;2$:
6_hÏ áÌ³1V \\ E $(Z_1;::::;Z_n)$ ¥sfb[/^ ¿¥ =Í FÐ
vF²T-µ¥+ÕÜÅ_ d9 b

R¥ ØE¥W%=¸n \b

独立随机变量之和的中心极限定理保证以下正态近似：[3]

$$\frac{W - n(n+1)/4}{\sqrt{n(n+1)(2n+1)/24}} \to \mathrm{N}(0,1) \tag{40}$$

依分布收敛。*R* 函数 *wilcox.test* 可以实现精确和渐近检验。

基于 Kolmogorov–Smirnov 统计量的检验

定理 7.3 (Kolmogorov–Smirnov 检验). 在 H_{0F} 下，绝对值 $(|\hat{\tau}_1|, \ldots, |\hat{\tau}_n|)$ 是固定的，但符号是随机的。因此 $(\hat{\tau}_1, \ldots, \hat{\tau}_n)$ 和 $-(\hat{\tau}_1, \ldots, \hat{\tau}_n)$ 应具有相同分布。

设

$$\hat{F}(t) = n^{-1} \sum_{i=1}^{n} \mathbb{I}(\hat{\tau}_i \le t)$$

是 $(\hat{\tau}_1, \ldots, \hat{\tau}_n)$ 的经验分布函数，

$$1 - \hat{F}(-t-) = n^{-1} \sum_{i=1}^{n} \mathbb{I}(-\hat{\tau}_i \le t)$$

是 $-(\hat{\tau}_1, \ldots, \hat{\tau}_n)$ 的经验分布函数，其中 $\hat{F}(-t-)$ 是 $\hat{F}(\cdot)$ 在 $-t$ 处的左极限。*Kolmogorov–Smirnov* 型统计量定义为

$$D = \max_t |\hat{F}(t) + \hat{F}(-t-) - 1|. \tag{41}$$

{ 提出了这个检验统计量并推导了其精确和渐近分布。标准软件包中未实现此统计量，但我们可以基于 *FRT* 模拟其精确分布并计算 p 值。

基于符号统计量的检验

定理 7.4 (符号检验). 符号统计量仅使用配对内差异的符号：

$$\Delta = \sum_{i=1}^{n} \mathbb{I}(\hat{\tau}_i > 0). \tag{42}$$

在 H_{0F} 下，

$$\mathbb{I}(\hat{\tau}_i > 0) \overset{IID}{\sim} Bernoulli(1/2),$$

因此 $\Delta \sim Binomial(n, 1/2)$。这给出了一个基于二项分布的精确检验，*R* 函数 *binom.test* 可以实现。利用中心极限定理，我们还可以基于以下正态近似进行检验：[4]

$$\frac{\Delta - n/2}{\sqrt{n/4}} \to \mathrm{N}(0,1) \tag{43}$$

依分布收敛。

---

[3] 参见 ??

[4] 参见 ??

∼w ♂ ♦ẅy i J k Q j ;ᵽ wᵻ♦ẇ Ô ᵽǒ ♂ ℇ℺ᴸᵾ″ MPE

ɻʏƀ̃ɯɔ̃ ʾ̃ Ḧõ ʁ ♦ẇ℺ℚḦ ♦ẇ ʾ̀ 1 ⁵ 0ǒ ᵥ ᵽ 2 × 2 ᵕ ᵬ̃ ʊʜŝ

		Ḧ ♦ẇ	=1	Ḧ ♦ẇ	=0
ʁ♦ẇ	=1		m_{11}		m_{10}
ʁ♦ẇ	=0		m_{01}		m_{00}

ᵭ̃ 7.5 (McNemar ℚ). 在 H_{0F} 下，一致对的数量 m_{11} 和 m_{00} 是固定的，$m_{10}+m_{01}$ 也是固定的。因此唯一的随机分量是 m_{10}，其分布为

$$m_{10} \sim Binomial(m_{10}+m_{01}, 1/2).$$

这给出了一个基于二项分布的精确检验。*R* 函数 *mcnemar.test* 给出基于二项分布正态近似的渐近检验：

$$\frac{m_{10}-(m_{10}+m_{01})/2}{\sqrt{(m_{10}+m_{01})/4}} = \frac{m_{10}-m_{01}}{\sqrt{m_{10}+m_{01}}} \to \mathrm{N}(0,1) \tag{44}$$

依分布收敛。精确 *FRT* 和渐近检验都不依赖于 m_{11} 或 m_{00}，只有不一致对的数量在这些检验中起作用。

Xw kQ》 j ; ᵽl a ; l

ᴅ *i* Ḧ℺ɻɯ́ ẇ

$$\tau_i = \frac{1}{2}\{Y_{i1}(1)+Y_{i2}(1)-Y_{i1}(0)-Y_{i2}(0)\}, \tag{45}$$

ᵩ β ɻɯ́ ẇ

$$\tau = n^{-1}\sum_{i=1}^{n}\tau_i = (2n)^{-1}\sum_{i=1}^{n}\sum_{j=1}^{2}\{Y_{ij}(1)-Y_{ij}(0)\}. \tag{46}$$

ʏ ƀ ǒ $\hat{\tau}_i$ ᵩ τ_i ɻ ℭ ℺ ℚ ǒ ʙ $\hat{\tau}$ ᵩ τ ɻ ℭ ℺ ℚ ⁵

ɯ Ṋ ǒ MPE ǒ ♂ Ṙ SRE ɻ ẅ ɸ ѵ ℺ ℚ $\hat{\tau}$ ɻ ţ ʔ ѵ ∨ Ḧ ℺ ǒ

♂ ʾ A ʁ β Ṗ ʾ A Ḧ β ǒ ♦ ẇ ɻ ⁻ Ḧ ℺ V̈ ţ ʔ ѵ Ṙ ˜ ƀ ƀ ƀ ♂

⁻ Ḧ *i* ♂ ℺ ℚ $\hat{\tau}_i$ ɻ ţ ʔ ѵ

ᵮ Ǻ MPE ℺ ℚ $\hat{\tau}$ ɻ ţ ʔ ѵ Ţ ʔ ẹ ♂ ʾ A ᵽ ẇ ♦ ǒ e MPEǒ ı ᵘ Ḍ ̃ ẅ Ä

ɴ ᵽ ẇ ǒ $\hat{\tau}_i$ ɯ́ μ ~ ţ ʔ ѵ σ^2 ɻ Ḍ ̃ ẅ Ä Ḳ ǒ ȸ ᵋ $\hat{\tau} = n^{-1}\sum_{i=1}^{n}\hat{\tau}_i$ ɻ ţ ʔ ѵ ᵽ ɯ

σ^2/n σ^2 ɻ ℭ ℺ ℚ ɯ V̈ ţ ʔ ѵ $(n-1)^{-1}\sum_{i=1}^{n}(\hat{\tau}_i-\hat{\tau})^2$ ǒ ʙ $\mathrm{var}(\hat{\tau})$ ɻ ℭ ℺ ℚ ɯ

$$\hat{V} = \{n(n-1)\}^{-1}\sum_{i=1}^{n}(\hat{\tau}_i-\hat{\tau})^2. \tag{47}$$

ᵰ ɯ I MPE ℭ ᵰ ă ƀ ᵽ ẇ ᵰ Ô ♂ ɯ $\hat{V}$ ǒ d $\hat{\tau}_i$ ɻ ⁻ Ḧ ʃ ţ ʔ ѵ ∨ ℺ ℚ

$\hat{\tau}$ ɻ ţ ʔ ѵ ʁ ѵ ǒ ẇ ɯ ă ∂ ᵽ ᵽ ɻ MPE ɯ ℭ ʃ { { ᵮ ʏ ᴅ ʏ ɻ ‡

ɔ

˜ ɻ ¯ **w**(ţ ḧ ѵ ℺ ℚ ɻ ƀ ẇ)**w**在 *MPE* 下，由 **{ {**定义的 $\hat{V}$ 是 $\hat{\tau}$ 真实方差的一个保守估计：

$$\mathbb{E}(\hat{V}) - var(\hat{\tau}) = \{n(n-1)\}^{-1}\sum_{i=1}^{n}(\tau_i-\tau)^2 \geq 0. \tag{48}$$

---

⁵ ᵽ ‖ Ô h **??**

当 τ_i 在各配对间恒定时，$\mathbb{E}(\hat{V}) = var(\hat{\tau})$。

{ ₹ MPE ŏ $\hat{V}$ ₩ɥ₫ɯ₹ɥ₮ᵛ₹₩ŏ ₣₳Ⅱ₹ɯ´ ω ñ
¯ᵽ₴ɥ ₴₹ ℳ♦ω Lᵤ̂ ŏ $\hat{V}$ ɯ $\hat{\tau}_i$ ₹Ⅱ₮ɟ₮ᵛŏℕ $\text{var}(\hat{\tau})$
ɯ Vℳ $\hat{\tau}_i$ ₹Ⅱ₮ᵛ₮ᵛ [6]
ᵨᵥᵽᵩ ŏ Neymanian ₮ṙ ɯᵖ Ⅴ≈ᵩŝ

$$\frac{\hat{\tau} - \tau}{\sqrt{\text{var}(\hat{\tau})}} \to \mathrm{N}(0,1) \tag{49}$$

$n \to \infty$ ᵨᵩ ₣ ₸ᵨ ₩₳₴₸ ₮ᵛ₹₴₮ŏ Wald ₴ʃ

$$\hat{\tau} \pm z_{1-\alpha/2}\sqrt{\hat{V}} \tag{50}$$

ᵩ $1-\alpha$ ₹ᵒ₹ₑₑᵒ τ
ⁱ₮ $\hat{\tau}$ ₸₮ᵛ₮ $\hat{V}$ ₫ɯ ₮ɥᵤ ₹ OLS ₹ᵩŏᵩ ʃ ₹ᵩᵨ

ʃ ¯ **w**(ϴLS ₹ᵨ)**w**$\hat{\tau}$ 和 $\hat{V}$ 等于将向量 $(\hat{\tau}_1, \ldots, \hat{\tau}_n)^\top$ 仅对截距进行 *OLS* 拟合的系数和方差估计量。

$\hat{\tau}$ ₸ $\hat{V}$ ₹ OLS ₹ᵨᵥɯkᵒᵩₑG ₭ᵛŏ R `lm(tau_hat ~ 1)` ₫ɯ [7]

Ww₩ᵘ

ᵥɯᵩ ᵩᵢ₴ₒₒG ₴ ᵎℰↄ ₭ᵤ ᵛ Δ₩Ⅱ₮ŏb₩Ⅱɯ₮ᵛ₮ᵛ₮ᵛ

协方差估计量 $\hat{\theta}$ 的一个无偏估计为

$$\hat{\theta} = \{n(n-1)\}^{-1} \sum_{i=1}^{n} (\hat{\tau}_{X,i} - \hat{\tau}_X)(\hat{\tau}_i - \hat{\tau}). \tag{52}$$

因此

$$\hat{\gamma} = \left(n^{-2} \sum_{i=1}^{n} \hat{\tau}_{X,i} \hat{\tau}_{X,i}^\top \right)^{-1} \hat{\theta} \approx \left(\sum_{i=1}^{n} (\hat{\tau}_{X,i} - \hat{\tau}_X)(\hat{\tau}_{X,i} - \hat{\tau}_X)^\top \right)^{-1} \sum_{i=1}^{n} (\hat{\tau}_{X,i} - \hat{\tau}_X)(\hat{\tau}_i - \hat{\tau}),$$

其中 $\hat{\tau}_i$ 是 $\hat{\tau}_{X,i}$ 的响应变量。OLS 拟合的截距是

$$\hat{\tau}_{\text{adj}} = \hat{\tau}(\hat{\gamma}) = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X. \tag{53}$$

OLS 拟合的残差是 $\hat{\tau}_{\text{adj}}$ 的一个线性组合。$\hat{\tau}_i$ 的向量对 1 的向量和 $\hat{\tau}_{X,i}$ 的矩阵进行 OLS 拟合的协方差估计量是

$$\hat{V}_{\text{adj}} = \hat{V} + \hat{\gamma}^\top \text{cov}(\hat{\tau}_X)\hat{\gamma} - 2\hat{\gamma}^\top \hat{\theta} = \hat{V} - \hat{\theta}^\top \text{cov}(\hat{\tau}_X)^{-1} \hat{\theta}.$$

这是在 *MPE* 下，协变量调整估计量 $\hat{\tau}_{adj}$ 和相关方差估计量 $\hat{V}_{adj}$ 可以方便地近似为将 $\hat{\tau}_i$ 的向量对 1 的向量和 $\hat{\tau}_{X,i}$ 的矩阵进行 *OLS* 拟合的截距和相关方差估计量。

EHW 即 Eicker–Huber–White 协方差估计量，MPE 和 CRE 在 Lin (2013) 中有详细讨论。

实例：Darwin 玉米数据

Darwin 在 15 对盆栽中种植了异花授粉和自花授粉的玉米植株。R 的 HistData 包中的 cross 和 self 向量给出了异花授粉和自花授粉植株的高度，diff 向量给出了差值。

在 MPE 下，$2^{15} = 32768$ 种处理分配同样可能。$\hat{\tau}$ 的观测值为 p 值：

```
> difference = ZeaMays$diff
> n.pairs = length(difference)
> abs.diff = abs(difference)
> t_obs = mean(difference)
> t_ran = sapply(1:2^15,
+ function(x) {
+ sum(MP_enumerate(x, 15)*abs.diff)
+ })/n.pairs
> pvalue = mean(t_ran >= t_obs)
> pvalue
[1] 0.02633667
```

p 值为 0.026，在 5% 水平下拒绝 H_{0F}。$\hat{\tau}$ 的观测值：

FIGURE 1. Darwin 数据 $\hat{\tau}$ 的观测值

⁻ ẇ ʲ ᵢ ᵢ ⁽ p e 。 ᵢ p s

ᵢ Ẇ ᵢ { ḷ ᵢ Workshop ᵢ ‖ { ᵖ 10 ᵢ 8 Ḧ
ᵢ ᵢ ᵢ

练习 7.5. 方差估计量的偏 证明 在 *MPE* 下，

$$\mathbb{E}(\hat{V}) - var(\hat{\tau}) = \{n(n-1)\}^{-1} \sum_{i=1}^{n} (\tau_i - \tau)^2 \geq 0.$$

练习 7.6. *OLS* 解释 证明 $\hat{\tau}$ 和 $\hat{V}$ 等于将 $(\hat{\tau}_1, \ldots, \hat{\tau}_n)^\top$ 仅对截距进行 *OLS* 拟合的系数和方差估计量。

练习 7.7. 协方差估计量 证明 $cov(\hat{\tau}_X, \hat{\tau})$ 的无偏估计为

$$\hat{\theta} = \{n(n-1)\}^{-1} \sum_{i=1}^{n} (\hat{\tau}_{X,i} - \hat{\tau}_X)(\hat{\tau}_i - \hat{\tau}).$$

练习 7.8. 调整估计量的 *OLS* 解释 证明 协变量调整估计量 $\hat{\tau}_{adj}$ 可以近似等于将 $\hat{\tau}_i$ 对 1 和 $\hat{\tau}_{X,i}$（带截距）进行 *OLS* 拟合的截距。

练习 7.9. *Darwin* 数据的 *Neymanian* 分析 使用 *Neymanian* 方法重新分析 *Darwin* 数据。报告点估计、方差估计和 *95%* 置信区间。

练习 7.10. 儿童电视 *Workshop* 实验的 *FRT* 分析 使用 *FRT* 重新分析儿童电视 *Workshop* 实验数据，使用配对 t 统计量作为检验统计量。

CHAPTER 8

Ẅëëḷṗ ḷ̣ U a 。 ṗ₂ṓQ ṡ 、 — ‘ N Q l –ṗ a 」 Q N

q wṡʲ I ^ ; s — Q U~〜々 I ^ ; s — Q ḥ R

ᵖ { { ŏ ᵹ ̈ Ũ Fisher ṗ₂ṓ- ŋ FRTÔḷ₁V̈W̄ sharp null ∂ḛ
$H_{0F} : Y_i(1) = Y_i(0)$ ŏ FRT Ḧ ṗ₂ṓ- Ɑ Ḍ̈Ā ṽ:ḛḷ p ṡ

$$\mathbb{P}(p_{\text{frt}} \le u) \le u \quad \text{for all} \quad 0 \le u \le 1.$$

ṁ FRT ḷ̣ ṁ§§ṗ₂ă √ṗ₂ṓẄÄ∂ḛṓ √ṗ₂ṓḷ
ṁ Ṇṓᵖ { { ʔ Δ ̈Aŭ ṡ ᵹ Ô ṗ₂ṓ- Ɑ Ṭ
Ÿ ∂ṓ ᵹ ̈ṙ ῐ ϥ H_{0F} Šṁ V̈ḷ- Ɑ ƀ ḛ ḷ ṁṓ
ᵹ ŭ ⟧ Q ; e l ∂ḛ ‘ g g $H_{0N} : \tau = 0$ ṁṓṁ ᵹ - Ɑ ŋ ṗ₂ ´ $\hat{\tau}$ Ôḷ
FRT ϒ H_{0N} ʜ ă-§§ṗ ϒ ṡ Ṡḥ ḷ ŋ anti-conservative Ô
{ ḷ ḷ̣ ᴴ ∂Δ ᴬ ḷ ṗ₂ ḥ ŋ dual guarantees ṁ 。 — ‘ N Q l _
— a 」 Q N $t = \hat{\tau}/\sqrt{\hat{V}}$ ŏ U ~ 々 ̈ ṗ H_{0F} ḷ̣ H_{0N} ʜ N̈ṓ V̈ ╟ ε
♦ṓ∂Ḧ╟ṗ ṓʉẄ ŋ Stratified Randomized Experiment, SRE Ô ᵛ K ḷ̣
ṁ

‖ w 、 — ‘ N Q l ḷ –ḥ a 」 Q N

‖ w q w I ḷ ~ P 、 — ‘ N Q l –ṗ a 」 Q N { {ḷ ∂ṗ₂ṓ ŋ CRE Ô n_1 ᴬ β
ṗ₂ṓ 8 ŏ n_0 ᴬ ṗ₂ṓḦ ŋ $n = n_1 + n_0$ Ô ᵹ ŭ ḷ ᴵᵀᴬU∂ḛṓṡ

(1) ᵹ̈ U∂ḛṓ 、 ^ ; s Ô k ‘ g g

$$H_{0F} : Y_i(1) = Y_i(0) \quad \text{Ḧ} \; \beta \qquad i = 1, \ldots, n.$$

(2) ṁU∂ḛṓ ⟦Q ; e k Ô ṡ g g

$$H_{0N} : \tau = 0 \iff \bar{Y}(1) = \bar{Y}(0).$$

H_{0F} ṓ ṗ ♦ṓḶ ŏ FRT Ḧ ṗ₂ṓ- Ɑ Ḍ̈Ā ṽ:ḛḷ p
H_{0N} ŏ ´ ṓ U B ṗ $\hat{\tau}$ ṁ ṁ ᴬ ă ∂ ḷ
Ɑ ŏ ƀ Ṡ ╙ ≈ Ẅ Ä H_{0F} ḷ̣ Ẅ Ä ă §§ ṗ ♦ṓḷ ṭ ♦ ϊ Ô ṁ Δ K ṓ
ᴵ ᵘ ḷ studentized Ɑ ´ ṡ

$$t = \frac{\hat{\tau}}{\sqrt{\hat{V}}},$$

ʃ $\hat{\tau}$ ṁ ´ ⟦Ɑ ŏ $\hat{V}$ ṁ ḷ ṭ ♦ ⟦Ɑ [1]

[1] ṗ ?? ḷ ṡ ṭ ♦ ṗ ╟ Ô ḥ ??

[illegible]

[illegible] Ding and Dasgupta (2017) [illegible] 在 *CRE* 中，使用 *studentized* 统计量 t 的 *FRT* 具有以下双重保证：

(1) H_{0F} ：p_{frt} 是有限样本精确的；
(2) H_{0N} ：p_{frt} 是渐近保守的（*asymptotically conservative*）。

[illegible] $\hat{\tau}$ [illegible] t H_{0N} [illegible]

H_{0N} [illegible] $\hat{\tau}$ [illegible]

$$\hat{\tau} \doteq \mathrm{N}\left(0, \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}\right).$$

[illegible] FRT pretends [illegible] Science Table H_{0F} [illegible] $(Y_i, Y_i)_{i=1}^n$ [illegible] $\hat{\tau}$ [illegible]

$$\hat{\tau}^{\pi} \doteq \mathrm{N}\left(0, \frac{s^2}{n_1} + \frac{s^2}{n_0}\right),$$

[illegible] s^2 [illegible] FRT [illegible] H_{0N} [illegible] p [illegible] studentized p [illegible] $t = \hat{\tau}/\sqrt{\hat{V}}$ [illegible] H_{0N} [illegible]

$$t \doteq \mathrm{N}(0, C^2),$$

[illegible] $C^2 \leq 1$ [illegible] $Y_i(1) - Y_i(0) = \tau$ [illegible] constant treatment effect[illegible]

[illegible] FRT [illegible]

$$t^{\pi} \doteq \mathrm{N}(0, 1).$$

[illegible] C^2 FRT [illegible] 1 [illegible]

[illegible] studentization [illegible] FRT [illegible]

8.1. [illegible] 证明了这个双重保证是 *studentized* 统计量独有的性质。其他统计量（如原始 $\hat{\tau}$）的 *FRT* 在 H_{0N} 下可能不再控制第一类错误率。

[illegible] [illegible] SRE SRE [illegible] K [illegible] strata [illegible] k [illegible] $\tau_{[k]}$ [illegible] $\tau = \sum_{k=1}^{K} \pi_{[k]} \tau_{[k]}$ [illegible]

$$\hat{\tau}_{\mathrm{SRE}} = \sum_{k=1}^{K} \pi_{[k]} \hat{\tau}_{[k]},$$

$$\hat{V}_{\mathrm{SRE}} = \sum_{k=1}^{K} \pi_{[k]}^2 \left(\frac{\hat{S}^2_{[k]}(1)}{n_{[k]1}} + \frac{\hat{S}^2_{[k]}(0)}{n_{[k]0}}\right).$$

1 Bŏ ɠ SRE studentized Qa ŝ

$$t_{\mathrm{SRE}} = \frac{\hat{\tau}_{\mathrm{SRE}}}{\sqrt{\hat{V}_{\mathrm{SRE}}}}.$$

¯ ⌋ **R w**($RE FRT ⌋ ħ)**w**在 *SRE* 中，使用 *studentized* 统计量 t_{SRE} 的 *FRT* 具有以下双重保证：

(1) H_{0F} ：p_{frt} 是有限样本精确的；
(2) H_{0N} ：p_{frt} 是渐近保守的。

SRE FRT ⌋ CRE ⌋ ŝ X ⌋
Ā ¿Ď ŋ ô

X w K ⌋ U ~々

X w q w I ᵛ ⌋P 、— ‘ N Q l a」 N K X ⌋ ŏ
ă ⌋ ⌋ ĔŲ ⌋ Qa { studentized Lin Qa ŝ

$$t_{\mathrm{L}} = \frac{\hat{\tau}_{\mathrm{L}}}{\sqrt{\hat{V}_{\mathrm{L}}}},$$

ſ $\hat{\tau}_{\mathrm{L}}$ { ⌋ K ŏ $\hat{V}_{\mathrm{L}}$ J OLS ŏ
t_{L} Y_i on $(1, Z_i, X_i, Z_i X_i)$ ʁ Z_i studentized Qa

¯ ⌋ **R w**(Zhao and Ding (2021a) ⌋ ħ)**w**在 *CRE* 中，使用 *studentized Lin* 统计量 t_{L} 的 *FRT* 具有以下多重保证：

(1) H_{0F} ：p_{frt} 是有限样本精确的；
(2) H_{0N} ：p_{frt} 是渐近保守的；
(3) ɾ H_{0N} ă ī K Ĥ ŏ ⌋ ：p_{frt} 渐近地比使用 t 的 *FRT* 更高效（功效更高）；
(4) ⌋ 。

ŋ 4Ō Q ŝ ⌋ ɠ $\hat{\tau}_{\mathrm{L}}$ ⌋ ɠ ŏ FRT with t_{L}
ħ t_{L} ⌋ K Ĥ ⌋ ŏ Ņ ɠ
{ K FRT ŋ ⌋ FRT Ô H_{0N} ă
§§ ŝ t_{L}

X w ‖ w 、ᵛ K ⌋P 、— ‘ N Q l a」 N SRE K ŏ {
ŝ

$$t_{\mathrm{L,SRE}} = \frac{\hat{\tau}_{\mathrm{L,SRE}}}{\sqrt{\hat{V}_{\mathrm{L,SRE}}}}.$$

Ŭ Lin K ⌋ Ŵ ⌋ ħ

8X Eùî

\ „ \ YV E £ bim/2MidB9x2¥/µK"'ŸÉbáÌ Nº BñÅ˜!
Âb
InBñ c $n = 100$ ñ†í¥µK98 Í F $n_1 = 20$ vF $n_0 = 80$ b Äñ
†í i 3îxM X_i lMB71;1) . ²T¹

$$Y_i(1) \quad L(X_i^3;1); \quad Y_i(0) \quad L(X_i^3;0{:}5^2):$$

$Y_i(1)$ „ $Y_i(0)$ É›Ï•Ä[' $= 0$ 'i@ H_{0N} b
E1 RkÕ_ d9
URLV2vK M URN¥kØVÕ PGaLC Í F""a ¿ÜÅS ¥ t d9 a
¿ 1>q S ¥ t d9
UkÀV²T¦{ \ n5 Y_i $(1;X_i)$ —µÄ –ª‹¨ •ØÕd9
UjV6Bb?2` UR¥NP8GVaLC n» \\ c
U9GVBM Uk¥RPVGaLC n» \\ c KÔØÕ bim/2MidB9x2b/

²T 3XXR H_{0N} / ºµ¹Õ bim/2MidB9x2/ GB¥MØÕ„ 1>q¥BÕ ?
û l»BËp q OL=p qÊ® ob ÅÖÕd9 ¥L=p q(Ú¿
l£Ü yN,a†¨¿_ Ð,L!b

ƒñ E²TÐ \\ ¥Ø,ç©›†BÁb

eXLlyp

¿ •Ø,„ E²T áÌó [/Llyp

eXRX *¥1yp X

URÂVTº1• H_{0F} '^Ži©...)Ør‹ P¨©..._ d9 ¥ 6_hûó
µK"'Ú' T´bV[Ê4ÿr Ú¥d9 Â ^b
UkÂVT1• H_{0N} 'Ü(yTr‹^Ž¹, A¶P¨ bim/2MiBdk92/ w
iP¨ t t_Gb
UjVÂTµxM V¨ P¨ t_G YÈ1t÷Úrb

eXkX a¥1yp X

URíVxM P¨ t_{a_1}
UkµVxM P¨ t_{Ga_1}b

eXjXÛ Ä _2J ¥+Yªü X ¿P¨ J?H MQ@ÉbØ×Û Ä¥L
_2J \?CP¨ðS td9 ¥ 6_h, µ \\Ï¥×£bŒP¨ t_G¥ 6_h
¯– ûƒt£bƒjA xM Øœ„ bim/2MiBx iB_Q2MÏ¥×1Ÿ b

eX9ÄX¥ L JS1¥yp X ¿Ä¥ L JS1ypÜ›¿ a_1¥yp

íxM P¨ td9 PGaE†^¡QMª¥© [
µxM P¨ td9 PGaE†^¡QM„ $^{X;i}$ ª¥© [b

eX8,X², XP¨ bim/2MiBdk92/¥ 6_h ^÷½†¥Ê4b 'v"'žÿÍ

»'H ¿ LQ`KÍ»„ ¿ 6_h¥ T´+¬M]b'žÿÍ», 'H 6_h
À?£ b?`TMm/HHT´^µr¥bƒ^'€¥wiSEb

ℊ Ẅ ᴅ { { ʁļ { ᵩ ŏ(› ” ᵱ ą ” vs Ḧ ŏ ℞ ” ᵩ ”
vs Ḧ ѡ∃№iᾺ ᵩ]₅₁ ɾ Ka
ℊᵩ ℩ Ẅ ⱽ⅄Ŝ

- **I ~ P**Ẅ ŋÀЬiŠQᵩ t ὐ t_{L} ļ FRTŞ
- 、 ~ **P**Ẅ ŋ›Ыʺ ŜQᵩ t_{SRE} ὐ $t_{\mathrm{L,SRE}}$ ļ FRT

{ ʢ { ʢ₩ʊýΔ soccer vs control ὐ physician vs control ļ♦ѡ

TABLE 1. l›‰ Ẅ ŝ soccer vs control

	est	s.e.	p_{Normal}	p_{frt}
class 1 (N)	0.051	0.502	0.919	0.924
class 1 (L)	0.050	0.489	0.919	0.929
class 2 (N)	−0.158	0.451	0.726	0.722
class 2 (L)	−0.176	0.452	0.698	0.700
class 3 (N)	0.005	0.403	0.990	0.989
class 3 (L)	−0.096	0.385	0.803	0.806
class 4 (N)	−0.492	0.447	0.271	0.288
class 4 (L)	−0.511	0.447	0.253	0.283
class 5 (N)	0.390	0.369	0.291	0.314
class 5 (L)	0.443	0.318	0.164	0.186
all (N)	−0.051	0.204	0.802	0.800
all (L)	−0.074	0.200	0.712	0.712

Nŝ Neyman (1923) ᵘ ⅂ὐ ὐ- Ş Lŝ Lin (2013) Kᵘ ⅂ὐ ὐ-

TABLE 2. l›‰ Ẅ ŝ physician vs control

	est	s.e.	p_{Normal}	p_{frt}
class 1 (N)	0.567	0.426	0.183	0.192
class 1 (L)	0.588	0.418	0.160	0.174
class 2 (N)	0.193	0.438	0.659	0.666
class 2 (L)	0.265	0.409	0.517	0.523
class 3 (N)	1.305	0.494	0.008	0.012
class 3 (L)	1.501	0.462	0.001	0.003
class 4 (N)	−0.273	0.413	0.508	0.515
class 4 (L)	−0.313	0.417	0.454	0.462
class 5 (N)	−0.050	0.379	0.895	0.912
class 5 (L)	−0.067	0.279	0.811	0.816
all (N)	0.406	0.202	0.045	0.047
all (L)	0.463	0.190	0.015	0.017

Nŝ Neyman (1923) ᵘ ⅂ὐ ὐ- Ş Lŝ Lin (2013) Kᵘ ⅂ὐ ὐ-

(1) ... t_{L} ...

(2) ... FRT p ... p ...

(3) ... soccer ... physician ... $p_{\mathrm{frt}} \approx 0.017$ ... class 3 ... $p_{\mathrm{frt}} \approx 0.003$

(4) ... class 2 ... class 4 ...

... studentized ... $\mathrm{N}(0,1)$ ...

FIGURE 1. ... $\mathrm{N}(0,1)$ ...

... $\mathrm{N}(0,1)$ ...

...

... Fisher ...

(1) ... studentized ... $t = \hat{\tau}/\sqrt{\hat{V}}$ ... FRT ... H_{0F} ... H_{0N} ...

(2) ... $\hat{\tau}$ ... FRT ... H_{0N} ... FRT ... Studentization ...

(3) ... studentized Lin ... t_{L} ... FRT ... H_{0F} ... H_{0N} ...

(4) ... SRE ... t_{SRE} ... SRE ... $t_{\mathrm{L,SRE}}$ ...

(5) ... studentized ... FRT ... p ... sharp null ...

...

8.1. *8.1 —Angrist and Lavy (2009)* 数据重新分析 这是第 *7* 章 *Problem 7.8* 的 *Fisher counterpart*。报告使用 *studentized* 统计量的 *FRT* 所得到的 p_{frt}。

8.2. *8.2 —Zhao and Ding (2021a) Figure 1* 的复制 *Zhao and Ding (2021a)* 使用模拟来评估各种检验统计量的 *FRT* 的有限样本性质。基于他们的 *Figure 1*，他们推荐使用 $t_{\mathrm{L},SRE}$ 来分析 *SRE*。复制他们的 *Figure 1*。

8.3. *8.3 —Studentization* 的直觉 解释为什么 *studentization* 能够修复 $\hat{\tau}$ 在 H_{0N} 下的反保守问题。从方差结构的角度阐述你的理由。

8.4. *8.4 —*推导 t 在 H_{0N} 下的渐近分布 在 *CRE* 中，推导 *studentized* 统计量 $t = \hat{\tau}/\sqrt{\hat{V}}$ 在 H_{0N} 下的渐近分布。证明其渐近方差不超过 *1*。

8.5. *8.5 —Lin* 估计量的性质 描述 *Lin (2013)* 协变量调整估计量 $\hat{\tau}_{\mathrm{L}}$ 的构造。证明它在线性结果模型正确设定时是高效的。

ů 8.6. *8.6* —推荐阅读 {和 {在 *permutation tests* 中使用了 *studentized* 统计量。在设计-*based* 框架下，{和 {给出了 *multi-armed experiments* 的推荐，{将推荐推广到协变量调整情形。阅读这些文献并撰写一页摘要。

Theorem 9.1 (Neyman's variance bound). *Under the potential outcomes model with i.i.d. units, the variance of any unbiased estimator $\hat{\tau}$ of the average treatment effect $\tau = E\{Y(1) - Y(0)\}$ satisfies*

$$\operatorname{var}(\hat{\tau}) \geq \frac{\operatorname{var}\{Y(1)\}}{n_1} + \frac{\operatorname{var}\{Y(0)\}}{n_0} - \frac{\operatorname{var}\{\tau(X)\}}{n},$$

where $\tau(X) = E\{Y(1) - Y(0) \mid X\}$ is the conditional average treatment effect, n_1 and n_0 are the numbers of treated and control units, and $n = n_1 + n_0$.

The bound is sharp: it is attained by the difference-in-means estimator when the conditional average treatment effect $\tau(X)$ is constant. Otherwise, the last term on the right-hand side is strictly positive, and the difference-in-means estimator is conservative. Intuitively, the bound says that we can learn more about the average treatment effect when the treatment effect is homogeneous across units, because then the observed outcomes under treatment and control are informative about the counterfactuals for every unit.

9.2 Regression adjustment

Suppose we observe, in addition to the treatment and outcome, a vector of pre-treatment covariates $X \in \mathbb{R}^p$. Regression adjustment fits a linear model for the outcome within each treatment arm and uses the fitted models to impute the missing potential outcomes. The resulting estimator is the difference between the two fitted intercepts, or equivalently the difference between the two fitted values at the sample mean of the covariates.

Concretely, let $\hat{\beta}_1$ and $\hat{\gamma}_1$ be the ordinary least squares coefficients from regressing the observed outcomes of the treated units on their covariates, and let $\hat{\beta}_0$ and $\hat{\gamma}_0$ be the corresponding coefficients for the control units. The regression-adjusted estimator is

$$\hat{\tau}_{\mathrm{adj}} = \hat{\gamma}_1 - \hat{\gamma}_0 + (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X},$$

where $\bar{X}$ is the sample mean of the covariates. When the covariates are centered, $\bar{X} = 0$, the adjustment vanishes and the estimator reduces to the difference in means, $\hat{\tau}_{\mathrm{adj}} = \hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0$.

The motivation for regression adjustment is the same as for any covariate adjustment: if the covariates explain a substantial fraction of the variance of the outcome, then removing that explained variance from the residuals can reduce the standard error of the estimator. The gain is largest when the covariates are strongly predictive and when the two arms are imbalanced on the covariates.

9.2.1 Interaction with the treatment

A more flexible model includes interactions between the treatment indicator Z and the covariates, fitting a single regression

$$Y = \alpha_0 + \alpha_Z Z + \alpha_X^T X + \alpha_{ZX}^T (Z \cdot X) + \varepsilon,$$

where $Z \cdot X$ denotes the vector of products of Z with each coordinate of X. The coefficient α_Z on the treatment indicator is then the regression-adjusted estimate of the average treatment effect, and $\hat{\tau}_L = \hat{\alpha}_Z$. This is the parameterization used by most software packages, and it has the practical advantage that a single fit yields both the point estimate and its standard error.

9.2.2 Robust standard errors

The usual ordinary least squares standard errors assume that the residuals have constant variance within each arm. When this assumption fails, the Eicker–Huber–White sandwich estimator of the variance of $\hat{\alpha}_Z$ is consistent under much weaker conditions. Let $\hat{\varepsilon}_i$ be the residuals from the fitted model, and let D be the $n \times (1 + p + p + p)$ design matrix whose rows are $(1, Z_i, X_i^T, Z_i X_i^T)$. Then

$$\widehat{\operatorname{var}}(\hat{\alpha}_Z) = \left[(D^T D)^{-1} D^T \operatorname{diag}(\hat{\varepsilon}_i^2) D (D^T D)^{-1} \right]_{22},$$

where the subscript 22 picks out the entry corresponding to the treatment indicator. In practice one usually multiplies by a small-sample correction such as $n/(n-k)$, where k is the number of fitted coefficients.

9.2.3 Worked example

We illustrate regression adjustment on a synthetic dataset of 2,000 units with a single covariate. The covariate is a pre-treatment measurement of the outcome, and the true average treatment effect is set to 0.5. The table below reports the estimate, its standard error, and a 95% confidence interval for each of the three estimators discussed above.

estimator	estimate	standard error	95% CI
difference in means	0.512	0.071	(0.373, 0.651)
regression adjustment	0.498	0.044	(0.412, 0.584)
interaction model	0.498	0.044	(0.412, 0.584)

The standard error of the regression-adjusted estimator is roughly 38% smaller than that of the difference in means, which corresponds to a substantial gain in effective sample size. The two regression-based estimators agree because, with a single covariate and a balanced design, the interaction term is close to zero.

9.3 Propensity scores

When the treatment is not randomized, the propensity score $e(x) = P(Z = 1 \mid X = x)$ plays a central role. Rosenbaum and Rubin showed that if the potential outcomes are independent of the treatment given the covariates, then they are also independent of the treatment given the propensity score alone. This reduces the problem of adjusting for a high-dimensional covariate vector to the problem of adjusting for a single scalar.

In practice the propensity score is unknown and must be estimated, typically by logistic regression of the treatment indicator on the covariates. Inverse-probability-weighted estimators then reweight each unit by the inverse of the probability of receiving the treatment it actually received, so that the weighted sample mimics a randomized experiment. These estimators are unbiased when the propensity model is correctly specified, but they can be highly unstable when some units have propensity scores close to zero or one.

---

[2] See OLS for the derivation of the sandwich formula.

[3] See the discussion of leverage and influence.

[4] The interval is based on the normal approximation.

∼ⓦⓓⓔ ⓦ

Δ ♣♠ⓢⓤ◻♦ⓞⓞ ⓖⓔⓥ ⁚ ⎾⎿⎽⎼ ⎻⎼ ⎽⎾ $n = 500$ⓞ ⓔ 2000 ᴱ
ⓢ ♦ⓞⓤ ⓚⓤ ⓤ ⓞ ⓥ ⓤ ⓞ ⓖⓦⓜ ⓞ 0 ⁵
⎿⎽⎼♦ⓞ ⓦⓢ

(1) **f a** ⓉⓁ⎻⎼ⓞ ⓒ ⓢⓒⓥ -0.0001ⓞⓨ Ⓣⓗ
(2) **P]** ⎡Ⓗ ⓒ ⓢⓤ′ EHW Ⓗ 0.139ⓓⓤ' Ⓗ ⓥ 0.151ⓟ 95% ⓡⓖ⎰ⓔⓄⓆⓔⓦ 92.7%ⓝⓩⓏⓄ
(3) ⎾ⓁⒿⒽ ⓒ ⓢ-ⓜ **{ ⎧** ⎾ⓘⓞⓦⓜ′ Ⓗ 0.153ⓞ ' Ⓗ ⓥⓤⓦ♦⎻ⓞ 95% ⓡⓖ⎰ⓔⓄⓆⓒⁿⓤ 95.3%

♦ⓞ Δ K Ⓦ⅀ ⓣⓥ ⎡Ⅎ

X w 、 ㄱ⅂ P

ⓡ Ⓙ ⎡⎤ⓨ ⓤⓤ ⓞⓤⓔⓌⓑⓤⓔ2ⓤⓜ ⓝ SREⓄⓟ $X_i \in \{1, \ldots, K\}$ ⓛⓜⓙⓑⓘ
Ⓖ Ⓚⓤ

¯ 9.2 (SRE Ⓙ K Ⓦ⅀). 在超级总体框架下，分层随机实验满足：

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

ⓓⓞ ⓐ⎾ⓑⓘⓖ $X = k$ Ⓙ ⎧ ⓞ ⓢ ⓌⓂ ⓡ ♦ⓞⓓⓟⓣ
ⓑⓘⓖⓦ′ ⓞ ⓢ

$$\tau_{[k]} = E\{Y(1) - Y(0) \mid X = k\} = E(Y \mid Z = 1, X = k) - E(Y \mid Z = 0, X = k).$$

ⓦ′ ⓞ ⓜⓐⓐⓑⓘⓖⓦ′ ⓞ Ⓙ-ⓟⓦ′ⓢ

$$\tau = \sum_{k=1}^{K} \mathrm{pr}(X = k)\tau_{[k]}.$$

SRE ⓩ⎡ ⓐⓑⓘⓒⓓⓟⓣⓙ CREⓞⓦ ⓤ CRE Ⓙⓜ ♦ⓞ ⓐⓑⓘⓒⓓⓏ ⓣ
ᴮⓞ ⓨ ⓗⓥ ⓑⓘⓦⓖ Lin (2013) ⓉⓆⓡ ⓞⓤⓘ-ⓟⓠⓐⓨ [6]
ⓡⓐⓑⓘⓒ 8 Ⓠⓗ ⓥⓗ ⓜⓟ 2 ⓜⓞ ⓨ $\hat{V}_S$ $\mathrm{var}(\hat{\tau}_S)$ ⒿⓣⓥⓘⓆ

[1]

Wⓦⓦ ♦

⓿ ` K Ⓦ⅀ ⎡Δⓜⓔ2ⓤⓜ Ⓙ ⓚⓤ ᵘ ⓞ ⓒⓤⓜⓛ ⓢ

(1) ` K Ⓦ⅀⓮ **{** ⓄⓈⓈ $Z \perp \{Y(1), Y(0), X\}$ ⓤⓛⓚ τ ⓨ Ⓨⓑⓘ♦ⓞⓒ Ⓙⓩⓞ
ⓡⓏⓐⓗⓑⓤ
(2) ⓚⓤ ᵘ Ⓙⓖ2 ⓢⓡ X ⓙ ⓑⓛ ♦ⓞⓟⓞᵘ ⓚⓤ ⓨ ⓡ ⓚⓤⓐⓤⓜ
ⓠⓥⓤⓁⓘⓂ ⓣⓥ
(3) **f a l t** ‖ ⓉⓆⓡⓠ**q ∼ u** **{** ⓄⓈⓈⓩ⎡⎤ ⓐⓠⓗⓦⓒⓓⓤ ⓐⓚⓨ Ⓙ OLS ‡ⓆⓄ
⎣ ⓧⓨⓜⓦ
(4) ⓣⓥ ⓝ **{** ⓄⓈⓈ EHW ⓣⓥⓘⓆⓤⓛ - ⓞⓐⓑⓙⓚⓤ ` K Ⓦ⅀
⅀ Ⓙⓗ
(5) 、 ~ **P** ⓝ **{** ⓄⓈⓈ ⓐⓑⓘⓒⓦⓆ ⓚⓤ ᵘ ⓞ ⓤⓘ-ⓟⓠⓐⓨ

[5] R ᴮⓤⓜ ‖Ⓞⓗ ??
[6] ᵽ‖Ⓞⓗ ??

ᵛᵃᵘ ᵢᵀᵠ ᵃᵇ ᵠᵃᵇˢ ᵃᵇ ╟ Ǐ ◆ □ᵞᵉᵃᵛ ᵛᵢᵃᵇᵒ“ε ᵢ ᵃ ᵞᵉᵃᵛ ᵛᵃᵘ ǒᵘᵛ ᵃᵇ ᵢᵀᵠ:Ẹ

˅ w

ṻ 9.1. *CRE* 的协变量平衡 在超级总体框架下，证明 { :{ 平均因果效应可以写为 $E(Y \mid Z=1) - E(Y \mid Z=0)$。

ṻ 9.2. *OLS* 分解与 *pooled regression* 基于 { {和 { ,{ 证明观测结果的 *OLS* 分解为：

$$Y = \alpha_0 + \alpha_Z Z + \alpha_X^T X + \alpha_{ZX}^T (Z \cdot X) + \varepsilon,$$

其中

$$\alpha_0 = \gamma_0, \quad \alpha_Z = \gamma_1 - \gamma_0, \quad \alpha_X = \beta_0, \quad \alpha_{ZX} = \beta_1 - \beta_0.$$

ṻ 9.3. *Lin (2013)* 估计量的性质 证明在正则条件下，*Lin (2013)* 估计量 $\hat{\tau}_L$ 是 τ 的半参数有效估计量。

ṻ 9.4. 方差估计量的比较 在超级总体框架下，模拟 $\{X_i, Z_i, Y_i(1), Y_i(0)\}_{i=1}^n$，其中 $\beta_1 \neq \beta_0$。比较以下四种方差估计量的表现：

(1) 标准的 *EHW* 稳健方差估计量；
(2) 带校正项 { {的 *EHW* 估计量；
(3) *Bootstrap* 方差估计量（协变量在开始时中心化，但不每次重新中心化）；
(4) *Bootstrap* 方差估计量（协变量在每次 *bootstrap* 样本中重新中心化）。

ṻ 9.5. *SRE* 中的协变量调整 在 *SRE* 的超级总体框架下，推导 τ 的协变量调整估计量及其方差估计量。

ṻ 9.6. 协变量调整与后分层的关系 证明：当各层的层别倾向得分 $e_{[k]} = n_{[k]1}/n_{[k]}$ 相等时，协变量调整与后分层给出相同的点估计量。

ṻ 9.7. 文献阅读 阅读 { 的原文，总结其核心贡献和主要结论。

ṻ 9.8. 回归调整的几何解释 从几何角度解释协变量调整：为什么减去 $(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}$ 可以提高估计精度？

CHAPTER 10

q

CRE

p B。 Q ” ; _

— a p l ; g

。 Q g Q J — a p l B a ; 。

Part III

p ‘ — J p j Q Q Z Q。 。 a p l

w

earnings

w

NHANES 2005-2006

homocysteine

female

age3 ed3 BMI bmi3 pov2

LaLonde

w

NHANES 2007-2008

BMI

BMI

$$\sim \mathbf{W}$$

X_i $Z_i \in \{0,1\}$ Y_i $Y_i(1)$ $Y_i(0)$

$$\{X_i, Z_i, Y_i(1), Y_i(0)\}_{i=1}^{n} \overset{\text{iid}}{\sim} \{X, Z, Y(1), Y(0)\}.$$

- **: ” Q ; Z Q I ; ‘ 。 ; g P』 Q J — L : I P**

$$\tau = \mathbb{E}\{Y(1) - Y(0)\}.$$

- **: ” Q ; Z Q I ; ‘ 。 ; g P』 Q J — p l ^ Q 々 Q ; — Q N**

$$\tau_{\mathrm{T}} = \mathbb{E}\{Y(1) - Y(0) \mid Z = 1\}.$$

- **: ” Q ; Z Q I ; ‘ 。 ; g P』 Q J — p l ^ Q I p l — p g**

$$\tau_{\mathrm{C}} = \mathbb{E}\{Y(1) - Y(0) \mid Z = 0\}.$$

$$\tau_{\mathrm{T}} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}\{Y(0) \mid Z = 1\}.$$

$\mathbb{E}(Y \mid Z = 1)$ $\mathbb{E}\{Y(0) \mid Z = 1\}$

τ_{C}

$$\tau_{\mathrm{C}} = \mathbb{E}\{Y(1) \mid Z = 0\} - \mathbb{E}(Y \mid Z = 0),$$

$\mathbb{E}\{Y(1) \mid Z = 0\}$

- **r a j ; U ; J a Q I ; ‘ 。 ; g P』 Q J —**

$$\tau_{\mathrm{PF}} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0).$$

$$\tau_{\mathrm{PF}} - \tau_{\mathrm{T}} = \mathbb{E}\{Y(0) \mid Z = 1\} - \mathbb{E}\{Y(0) \mid Z = 0\},$$

$$\tau_{\mathrm{PF}} - \tau_{\mathrm{C}} = \mathbb{E}\{Y(1) \mid Z = 1\} - \mathbb{E}\{Y(1) \mid Z = 0\}.$$

τ_{PF}

CRE $Z \perp \{Y(1), Y(0)\}$

X

1 { {IQ ow ol i w ´ o lIQS [8]

$$\hat{\tau} = n^{-1} \sum_{i=1}^{n} \left\{ \frac{e^{\hat{\beta}_0+\hat{\beta}_z+\hat{\beta}_x X_i}}{1+e^{\hat{\beta}_0+\hat{\beta}_z+\hat{\beta}_x X_i}} - \frac{e^{\hat{\beta}_0+\hat{\beta}_x X_i}}{1+e^{\hat{\beta}_0+\hat{\beta}_x X_i}} \right\}.$$

ŏ ÄIQa ă ¿ Ł Ś Z lȝ|β ow §§l ¿ ¡ ¡ ¿ ŏ l
¿ ow Ps Ka lȝ! ẄÄ Qa !№ ŏ ę ℤ Ł Ś lȝ ”
” 5 ” ´ ”

¯ ẁ ♦

V̈ Part III .lȝ ƈŏŁ₴Δ ŸĖ ẅ ò ğlȝ₧Ä Q ţṘŋ ”Four Pillars”Ō lȝᵖ Ä§§♦ò‡Q ŭ┌ ⁱ₰ ŝ

(1) ƈ² ¿ Ÿ Ė ẅlȝQ ¹Ł ŝ ø ¨QĦ ₓ ♦ò Ẅ Ä ₰ l ŭ ă
(2) ă l Q ∂ ¡ ŋ $Y(z) \perp Z \mid X$ Ô ŋ Δ Q ò lȝ Ẅ ┌§§ ¶ ¿ Ð ø Ka X M
(3) ă l Q ∂ ¡ ŏ ò l ┌ ² lȝ ┌ ŋ { Ō{
(4) ♦ò‡Q ¡ ¹ $\mathbb{E}(Y \mid Z, X)$ lȝ Ś lIQ ò ŏ ¡ Q ţṘ Ÿ lȝ
(5) ♦ò‡QlȝQ ¡ Ś ∂ Ø §§ᵐ ¯ lȝ Ś ‰ Þ ƈlȝIQ

ă l Q ∂ ¡ ₰ ò ŋ Δ ı Ł l Q ┌ ŏ Ð ¡ ₰ ẅ ŏ Ƶ l ¡ ¡ ¿ ^
₰ ¡ Ÿ Ä d ⊕ Δ ¿ lȝ Ğ ¡ ¡ Ï ♦ ‖ Ł ƶ Ƶ ¡ ¡ ţṘ ŋ ś Ō Ƶ ~ ₰ ¡
┤ IQ~ ‡ Ł Ð ₰ ı ă ♦ Ę Ḧ

R ẁ ẃ

(1) ┐ β ñ ţ ₰ ŝ ¿ $\tau = \Pr(Z=1)\tau_{\mathrm{T}} + \Pr(Z=0)\tau_{\mathrm{C}}$
(2) ă l Q lȝ l ¡ ŝ Ś Ù ¡ ¡ ¿ ¡ ŝ

$$Y(1) = g_1(X, V_1), \quad Y(0) = g_0(X, V_0), \quad Z = \mathbb{I}\{g(X, V) \geq 0\},$$

ɾ $(V_1, V_0) \perp V$ ı ₰ ¡ ₰ ¡ ẅ l ă l Q ∂ ¡ Ł ¡ ₰ ‖ V
Ÿ Ė ¡ ₰ U ŏ ♦ ò ‰ ¶ Q K ò Ţ
(3) ƈ Ÿ ℤ Ł ₰ Ś Q ¿ Ō ♦ ò Y ă ı ℤ Ł ₰ Ś ŝ

$$\mathbb{E}(Y \mid Z, X) = \frac{e^{\beta_0+\beta_z Z+\beta_x X+\beta_{xz} XZ}}{1+e^{\beta_0+\beta_z Z+\beta_x X+\beta_{xz} XZ}}.$$

Þ ´ ò τ lȝ IQa
(4) Ś ∂ ₰ ¡ Ś ¡ ¿ ¡ ¿ ŏ ♦ ò ‡ Q ¡ ¡ ¿ ¡ ¡ ¿ ¡ ¡ ¿

CHAPTER 11

倾向得分匹配

倾向得分匹配的基本思想

randomization

treatment

倾向得分匹配的基本概念

11.1 (倾向得分 (Propensity Score)). 倾向得分定义为给定协变量 X 时接受治疗的概率：

$$e(X) = \Pr(Z = 1 \mid X).$$

$[0, 1]$ $e(X_i) = 0.8$ 80%

$e(X) = \Pr(Z = 1)$ randomization X

倾向得分匹配的基本定理

(Rosenbaum & Rubin, 1983)在强可忽略性（*strong ignorability*）假设下，如果

$$\{Y(1), Y(0)\} \perp\!\!\!\perp Z \mid X,$$

则

$$\{Y(1), Y(0)\} \perp\!\!\!\perp Z \mid e(X).$$

$e(X)$ X

¹I¹ƒñ²T×1$ ðSxM X V[^©i»”¥ M-alÆa•âa¯<Il
Œ`_¤s e(X) ^Bñ [0;1] uW¥S bYVØœƒñB»M á Ì©N¿Øœ
îµðSxM iiƒü^ _Qb2M#„m_km#BM¹ ô†»ý ô¥clb R
ÐsªÛ L ¥ó" » \\cÏ á Ì), sªÛ L a_1bÂTá Ì
¿`_¤s e(X) ¥|´ †íÉ›sª *¹ÄBª=¥4©Ÿ” Ð a_1 µM]¥
² iiy¹óçM]¥`_¤s Í s¥Ð. ²THqÿëb

jX`_¤ssª

jXRXX©ÖÛ`_¤s XL!`_¤s e(X) X© OÇ| K ñ,]¥´ fe1;:::;ekgb
®\\ ÄBª ek = Í s¥Ð. ²THqÿëbyN á Ì µ K ñÿë¥›†Û
L *_1 iiƒž^» \\c),¥ a_1² b
98Ü(yTr‹V[YVsª 9 É› 9

$$\hat{S}_a = \sum_{k=1}^{K} \hat{}_{[k]}\hat{}_{[k]};$$

Ï [k]^» k ª¥981è ^[k] ^¾ª=¥µ´(´b k
LlÏ¥Ù5 K ¥Ê4³1ƒ™bÂT K þl sªª¥HqÿëŸV?,îë
ÂTK þv Äª=¥"' ,@ ¸ ªV?º cÍ F vF¥†íbô \
¥yp K=5 ¸ Æß/? h"v†sÊµiiƒñ ô* ¥”3 8ô| Q C
'c¥),Ïb

jXkÃ©õÃ`_¤s X L=fƒÏ `_¤sYÈ^Ã©¥ á Ì³1YVd9
~É› 9bKÈn¥ZE^E†Bñ HQ;BbïBB÷

$$HQ(\beta|X_i)g = {}_0 + {}_1X_1 + \quad + {}_pX_p:$$

9¤ž¥`_¤s e(X) V[| r n ñ,]¥´ 'Äñ†í¥xM û,›†
M]Hb¹ ‹¨sªZE á Ì³1 e(X) É›ÖÛÄbBÕÈ¨¦{^¿ sÊ”
É›sª j

è RRXR UL>”L'1¥a`_¤ssª VXIn \\Ï¥ L>L1a” bá ÌP
¨ HQ;BbïBB÷`_¤s –ª¿sÊ”|"'s¹ K ªb \\ZU ,] K ´
K=5;10;30 / Í F„ vF`_¤sƒ¥°Zmb

6B;m`2 R›X L1a” "Ï 9`_¤s¥°Zm âä¹ vF ç
ä¹Í Fb

''`_¤sÃ©OõÃH `_¤ssª 9 ¥µrŸG ¿[/ ñHq
URžV!ç ~ S(Z=1jX) ž'!ç P¤ e(X) ? } ‡L¥`_¤sb
Uk¥ßHq Pp2`H T+QM/B0i‹BeQXV)<1 îµ†íîëiiƒ' Äñ
†íûµ¤sÍ „ v¥V?Ÿb 9

R w•n¸c \\
k W%w•n¸c \\
j W%),n¸c \\
9 ×ßHq¥W%),n¸c \\

p kWWGIQ IW = GW HT IQ ÀnЄĕIQ ŏNWr◦gĬIW IPW IQ
◦gWW ` r [IQ ¯ IŭFWG

WwqkWIW

Ww q ¯w ww kWäW ≝ t [ŏ ∖ AGYIW
§§ W { J IH Q ♦[

¯J q q w)w倾向得分 $e(X)$ 满足以下性质：

(1) 条件独立性：$X \perp\!\!\!\perp Z \mid e(X)$；

(2) 加权平衡：对于任何协变量函数 $g(X)$，有

$$\mathbb{E}\left\{\frac{Zg(X)}{e(X)}\right\} = \mathbb{E}\{g(X)\}.$$

{ {p A♦[nöÄ p kWĬo K X 8 W K Z F§§
IW kWW ö8 QH I K WÄWW IW nÔA♦[
-G WH O IW 8
W { {∖ gIYIh dW§§W W8 Z X
∫Iŭ Bö u ♦WW ɔ ö W ∖- xp kWG WÄ>WQuW
Δ K W { ╟ ä YH VI W§§ NQ。 a Z l Õ。§§— ; Z Q
GĞWh♦WWŏ∖ Ê-∖Y

Ww ‖kwWI- w ┼ ö W IQIp kW ê(X) ∖- K W
H W ê(X) ŸW WWWÔW∖ V ЫÒ- 8 QH K WÄIV
Ŝ

$$\mathrm{Bias}_{[k]} = \frac{1}{n_{[k]}} \sum_{i:\hat{e}(X_i)=e_k} Z_i g(X_i) - \frac{1}{n_{[k]}} \sum_{i:\hat{e}(X_i)=e_k} (1 - Z_i) g(X_i) \approx 0.$$

WWIpWZV W BI Q♦≠ Uŏ p kWG WŭWIŞWWe Z
ZŏW ¯J
GW W GIZW Ŝ { gUŏ╟ QW W ” GW ”I W _
IQ K ÖIQ ” W GW ”I ♦WWŏ∖ W ĝÊ-∖Y K WIJ
- IWGW IQ TN

˅ wW‡QIHÇ

Ÿ IIJÔZ-GtṘ D { {I♦W‡QtṘRβHΔD ă I W ĝq
NŜ

TABLE 2. ÔZ- vs. ♦W‡Q

	` r Õ[	♦W‡Q	
J H W_2	$\Pr(Z=1 \mid X)$	♦W	$\mathbb{E}(Y \mid Z, X)$
W F p kWG p		♦W p	
7 Hp kWG W		H♦WG W	
Z Vp kWIQ:Ę		V♦WG W	

[8] W I Ô h ??

11.

11.1.

11.2.

11.3.

11.4.

提示：使用 *tower property* 和条件概率的定义。

ĩ 11.5. 协变量平衡的数值检验 使用 { {中的 *NHANES* 数据，检验不同分层数量 K 下的协变量平衡。报告治疗组和对照组在各层内关键协变量（如年龄、*BMI*）均值之差的绝对值。

ĩ 11.6. 截断水平的敏感性分析 对 { {中的结果进行敏感性分析：比较不同截断水平对点估计和标准误的影响，讨论截断水平选择的实际准则。

ĩ 11.7. *IPW* 与结果回归的比较 使用第 { {章中的模拟数据或真实数据，分别应用 *IPW* 估计量和结果回归估计量，比较两者的点估计和置信区间。

ĩ 11.8. 极端反事实的影响 { 讨论了极端反事实问题。构造一个例子，其中某些单元的倾向得分接近 *1*，讨论这种情况下因果推断面临的挑战。

CHAPTER 12

q ws ‘ATQa lja h

o { { ŏ o ʁΔ ‘A1V] ĭîŝ‚ YBkæ3v ù gjøŏ o

ŋA‚ø0ñ‚ ∫ n

o ‘A‚ú ♦ù‡Q‚ñ‚ ŋ outcome regressions

$$\tau = E\{\mu_1(X)\} - E\{\mu_0(X)\},$$

ſ $\mu_1(X) = E(Y \mid Z = 1, X)$]‚ $\mu_0(X) = E(Y \mid Z = 0, X)$ WQ‚ú8]‚H ‘À

¯ Kı X l ╒ ´ ì‚ú ‘Añ‚ıl^‚ ı ŝ ‚ĭ ‚ú ƒ $\mu_1(X)$

]‚ $\mu_0(X)$ŏ°‚ uTQ τ Þ öp♣ù‚ƒ m ΔöTQa °‰Ε‚ú‚

o Ô‘A‚ú ‚ì Ô‚ -ƒ‚ñ‚ ŋ IPWSs

$$\tau = E\left\{\frac{ZY}{e(X)}\right\} - E\left\{\frac{(1-Z)Y}{1-e(X)}\right\},$$

ſ $e(X) = \Pr(Z = 1 \mid X)$ ‚ú‚ kjW ‘Añ‚ ŝ ‚ kjWƒ ‚öŏI

Qa °‚ú l Þ♭l‚j‚i ‚ § §p♣ù $e(X)$ ƒ m ΔöĬù\‚ĭ‚ú ‚ l

‘A ‚ul Ņ‚ŝ ‡Ăĭ ‘ATQa ŏ ‘DA‚ƒ ‚ ‘A ‚öŏ‡

h Ţ

‚ú James Robins ₧ſ ŏ ŋ { Õ‹‚ú ┤ TQŋ doubly robust estimator

l‚Q ‚ ‚ƒ o ‚ ‚ ‖ ʁl‚ŏ ‘ATQa ‚ú‚u♦ŏΔ♦ù‡Q‚Ô‚ -ƒ

l ⁱ

‖ **w**pĭ] **M** ~ TQa

Δĭĭ ‚ú ┤TQa ŏ o ‚ ‚ m DA E ƒ ŋ working models

- ♦ù‚ƒ ŝ $\mu_1(X, \beta_1)$]‚ $\mu_0(X, \beta_0)$ŏWQ‚ƒ $E(Y(1) \mid X)$]‚ $E(Y(0) \mid X)$ ₣♦ ù‚ƒ ‚öŏ $\mu_1(X, \beta_1) = \mu_1(X)$
- ‚ kjWƒ ŝ $e(X, \alpha)$ƒ $\Pr(Z = 1 \mid X)$ ₣‚ kjWƒ ‚öŏ $e(X, \alpha) = e(X)$

‚ ŏ DA‚ƒ D]‡m ‚ § § ‚ú ‚ ‚ ‚ ” E ƒ ”

1 DA E ƒ ŏ ‚ ŝ

$$\tilde{\mu}_1^{\mathrm{dr}} = E\left[\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X, \alpha)} + \mu_1(X, \beta_1)\right], \tag{60}$$

$$\tilde{\mu}_0^{\mathrm{dr}} = E\left[\frac{(1-Z)\{Y - \mu_0(X, \beta_0)\}}{1 - e(X, \alpha)} + \mu_0(X, \beta_0)\right]. \tag{61}$$

12.3.3 双重稳健估计量

$$\tilde{\mu}_1^{\mathrm{dr}} = E\left[\frac{ZY}{e(X,\alpha)} - \frac{Z - e(X,\alpha)}{e(X,\alpha)}\mu_1(X,\beta_1)\right], \tag{62}$$

$$\tilde{\mu}_0^{\mathrm{dr}} = E\left[\frac{(1-Z)Y}{1-e(X,\alpha)} - \frac{e(X,\alpha) - Z}{1-e(X,\alpha)}\mu_0(X,\beta_0)\right]. \tag{63}$$

- 若 $e(X,\alpha)$ 是倾向得分的正确模型，则 $\tilde{\mu}_1^{\mathrm{dr}}$ 和 $\tilde{\mu}_0^{\mathrm{dr}}$ 是 μ_1 和 μ_0 的相合估计量，无论 $\mu_1(X,\beta_1)$ 和 $\mu_0(X,\beta_0)$ 是否正确。
- 若 $\mu_1(X,\beta_1)$ 和 $\mu_0(X,\beta_0)$ 是结果均值的正确模型，则 $\tilde{\mu}_1^{\mathrm{dr}}$ 和 $\tilde{\mu}_0^{\mathrm{dr}}$ 是 μ_1 和 μ_0 的相合估计量，无论 $e(X,\alpha)$ 是否正确。

因此，$\tilde{\mu}_1^{\mathrm{dr}} - \tilde{\mu}_0^{\mathrm{dr}}$ 是 τ 的双重稳健估计量。这一性质称为 **双重稳健性**（doubly robustness）。

双重稳健估计量也称为 **增广逆倾向得分加权估计量**（augmented inverse propensity score weighting, AIPW）。

12.3.4 双重稳健性的证明

定理 12.1（双重稳健性）. 假设可忽略性 $Z \perp \{Y(1), Y(0)\} \mid X$ 和 *overlap* $0 < e(X) < 1$。

(1) 若 $e(X,\alpha) = e(X)$ 或 $\mu_1(X,\beta_1) = \mu_1(X)$ 之一成立，则 $\tilde{\mu}_1^{\mathrm{dr}} = E\{Y(1)\}$。

(2) 若 $e(X,\alpha) = e(X)$ 或 $\mu_0(X,\beta_0) = \mu_0(X)$ 之一成立，则 $\tilde{\mu}_0^{\mathrm{dr}} = E\{Y(0)\}$。

(3) 若 $e(X,\alpha) = e(X)$ 或 $\{\mu_1(X,\beta_1) = \mu_1(X), \mu_0(X,\beta_0) = \mu_0(X)\}$ 之一成立，则 $\tilde{\mu}_1^{\mathrm{dr}} - \tilde{\mu}_0^{\mathrm{dr}} = \tau$。

证明. 我们只证 $\tilde{\mu}_1^{\mathrm{dr}}$ 的情形，$\tilde{\mu}_0^{\mathrm{dr}}$ 同理。

记 $e = e(X,\alpha)$，$m_1 = \mu_1(X,\beta_1)$。将 $Y = Y(1)$ 代入 $\tilde{\mu}_1^{\mathrm{dr}}$ 的表达式，

$$\tilde{\mu}_1^{\mathrm{dr}} = E\left[\frac{ZY(1)}{e} - \frac{Z - e}{e} m_1\right] = E\left[\frac{Z}{e}\{Y(1) - m_1\} + m_1\right].$$

(1) 倾向得分模型正确. 若 $e = e(X)$，则

$$E\left[\frac{Z}{e}\{Y(1) - m_1\}\right] = E\left[\frac{Z}{e(X)}\{Y(1) - m_1\}\right] = E\left[\frac{E(Z \mid X)}{e(X)}\{Y(1) - m_1\}\right] = E\{Y(1) - m_1\},$$

其中第二个等号用了 $Z \perp Y(1) \mid X$，第三个等号用了 $E(Z \mid X) = e(X)$。因此

$$\tilde{\mu}_1^{\mathrm{dr}} = E\{Y(1) - m_1\} + E(m_1) = E\{Y(1)\}.$$

(2) 结果均值模型正确. 若 $m_1 = \mu_1(X)$，则

$$E\left[\frac{Z - e}{e} m_1\right] = E\left[\frac{E(Z - e \mid X)}{e} m_1\right] = 0,$$

因为 $E(Z \mid X) = e(X)$。因此

$$\tilde{\mu}_1^{\mathrm{dr}} = E\left[\frac{ZY(1)}{e}\right] = E\left[\frac{E(Z \mid X)}{e(X)} E\{Y(1) \mid X\}\right] = E\{Y(1)\}.$$

(3) 由 (1) 和 (2) 即得。 □

12.3.5 双重稳健估计量的实现

算法 12.2（双重稳健估计量）. 基于数据 $(X_i, Z_i, Y_i)_{i=1}^n$，按以下步骤构造 τ 的双重稳健估计量：

(1) 拟合倾向得分：得到 $e(X_i, \hat{\alpha})$；

(2) 拟合结果均值：得到 $\mu_1(X_i, \hat{\beta}_1)$ 和 $\mu_0(X_i, \hat{\beta}_0)$；

(3) 构造双重稳健估计量 $\hat{\tau}^{\mathrm{dr}} = \hat{\mu}_1^{\mathrm{dr}} - \hat{\mu}_0^{\mathrm{dr}}$，其中

$$\hat{\mu}_1^{\mathrm{dr}} = \frac{1}{n}\sum_{i=1}^n \left[\frac{Z_i\{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{e(X_i, \hat{\alpha})} + \mu_1(X_i, \hat{\beta}_1)\right],$$

$$\hat{\mu}_0^{\mathrm{dr}} = \frac{1}{n}\sum_{i=1}^n \left[\frac{(1-Z_i)\{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - e(X_i, \hat{\alpha})} + \mu_0(X_i, \hat{\beta}_0)\right].$$

等价地，可写为

$$\hat{\tau}^{\mathrm{dr}} = \hat{\tau}^{\mathrm{reg}} + \frac{1}{n}\sum_{i=1}^n \frac{Z_i\{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{e(X_i, \hat{\alpha})} - \frac{1}{n}\sum_{i=1}^n \frac{(1-Z_i)\{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - e(X_i, \hat{\alpha})}.$$

$\hat{\tau}^{\text{reg}}$??

$$\hat{\tau}^{\text{dr}} = \hat{\tau}^{\text{ipw}} - \frac{1}{n}\sum_{i=1}^{n}\frac{Z_i - e(X_i,\hat{\alpha})}{e(X_i,\hat{\alpha})}\mu_1(X_i,\hat{\beta}_1) + \frac{1}{n}\sum_{i=1}^{n}\frac{e(X_i,\hat{\alpha}) - Z_i}{1-e(X_i,\hat{\alpha})}\mu_0(X_i,\hat{\beta}_0).$$

bootstrap $\hat{\tau}^{\text{dr}}$

IPW

. IPW $\mu_1 = E\left\{\frac{ZY}{e(X)}\right\}$ Y

$\mu_1(X,\beta_1)$ [4]

$$\mu_1 = E\{Y(1)\} = E\{Y(1)-\mu_1(X,\beta_1)\}+E\{\mu_1(X,\beta_1)\} = E\left\{\frac{Z\{Y-\mu_1(X,\beta_1)\}}{e(X)} + \mu_1(X,\beta_1)\right\}.$$

. $\tilde{\mu}_1 = E\{\mu_1(X,\beta_1)\}$ μ_1 IPW [5]

$$B = E\left\{\frac{Z\{\mu_1(X,\beta_1)-Y\}}{e(X)}\right\},$$

$\tilde{\mu}_1 - B$

[6]

(1)
(2)
(3)
(4)

DR 1-3 DR [7]

[3] ??
[4] ??
[5] ??
[6] ??
[7] ??

q ⁅Ẅw { {ⱼ

ẋfl Ŝ ℊ ĵ ignorability ⱱ̣ overlap ∂ᵩ̈ ŏᵩ̈ ⱻ ⱻ ⱻ ⱻ $\tilde{\mu}_1^{\rm dr} =$ $E\{Y(1)\}$ ⱻ ⱻ ⱻ ⱻ

...

$$\tilde{\mu}_1 = E\{\mu_1(X, \beta_1)\}$$

...

$$\text{bias} = E\{\mu_1(X, \beta_1) - Y(1)\}.$$

...

$$B = E\left\{ \frac{Z\{\mu_1(X, \beta_1) - Y\}}{e(X)} \right\}.$$

...

$$\tilde{\mu}_1 - B$$

...

$$\tilde{\mu}_1^{\text{dr}} - E\{Y(1)\} = E\left[\frac{e(X) - e(X, \alpha)}{e(X, \alpha)} \times \{\mu_1(X) - \mu_1(X, \beta_1)\} \right].$$

... $e(X) - e(X, \alpha)$ ... $\mu_1(X) - \mu_1(X, \beta_1)$ ...

...

```
x = matrix(rnorm(n*2), n, 2)
x1 = cbind(1, x)
beta.z = c(0, 1, 1)
pscore = 1/(1 + exp(- as.vector(x1 %*% beta.z)))
z = rbinom(n, 1, pscore)
beta.y1 = c(1, 2, 1)
beta.y0 = c(1, 2, 1)
y1 = rnorm(n, x1 %*% beta.y1)
y0 = rnorm(n, x1 %*% beta.y0)
y = z*y1 + (1-z)*y0
```

...

...

...

...

TABLE 1. ʍ qfi lʃʃiȣ◆ȣŋ $n = 500ŏ \quad 500^{\text{E}}$ ẽÕ

		reg	HT	Hajek	DR
qfi	1ŝƩA$\mathring{J}$ Ḍ ʓ				
ʍ´ʓ		0.00	0.02	0.03	0.01
Ḥ		0.11	0.28	0.26	0.13
ˈlQḤ		0.10	0.25	0.23	0.12
qfi	2ŝʚ kẇ$\mathring{J}^{\text{m}}$				
ʍ´ʓ		0.00	−0.76	−0.75	−0.01
Ḥ		0.12	0.59	0.47	0.18
ˈlQḤ		0.13	0.50	0.38	0.18
qfi	3ŝ◆ȣ$\mathring{J}^{\text{m}}$				
ʍ´ʓ		−0.05	0.00	−0.01	0.00
Ḥ		0.11	0.15	0.14	0.14
ˈlQḤ		0.11	0.14	0.13	0.14
qfi	4ŝƩA$\mathring{J}$ Ḍ$^{\text{m}}$				
ʍ´ʓ		−0.08	0.11	−0.07	0.16
Ḥ		0.13	0.32	0.20	0.41
ˈlQḤ		0.13	0.25	0.16	0.26

CHAPTER 13

1 ⁄ kẆ Ẇ

q wŝ ʲẆ Ẇ 2 ʁ Ÿ Ẇ ẅ

"Block what you can and randomize what you cannot." — ({ page 103)

ɷ ᴰ { . { ʁ ŏ Ẅ Ẇ 2 ɷ ŋ SRE Ô ụ ^ ʁ ă ẅ ị ị ṭ

Ṙ SRE ŏ ɷ ɛ Ɔ ⁄ ɷ ị ʁ X ‖ β Ẇ ˛ ɷ Ó ẞ ŏ ∨ ẞ ı ċ Ḍ T̈ v ⁄ ɷ

ɷ 2 ɷ ṭ Ṙ ɷ ô ɷ h Δ Ì Ʌ ẞ ı ċ ị treatment ẗ ẹ control ẅ ị

ɷ Ṅ ŏ ɷ ɷ ị Ÿ Ẇ ẅ ˛ Ì Ɛ V̈ ị ɟ ŝ ɷ Ṙ Ẇ ʁ Ẅ ‾ 2 ɷ

2 ɷ ŏ $e(X) = \Pr(Z = 1)$ ɷ ɷ ɷ ô ^ ị w ɷ ŝ Ƀ Ÿ Ẇ ẅ ŏ ʁ Ẇ

‾ Ô ẹ $e(X) = \Pr(Z = 1 \mid X)$ ɷ ^ ʁ X ŏ w ⅋ Ụ Ẹ ↓ X ị ỳ

ɛ Ɛ ₓ ɯ ị ɷ ô ʁ X ɷ Ụ ị ₣ X i Ạ ɯ ɷ ɯ Ạ ɷ ɯ ɾ ʹ Ạ ʁ ɷ ŏ ↓

ỹ X ị ɷ ∨ Ẇ ẅ ₱ ᴾ K ɯ ẅ i Ạ Ɠ ɷ ị ẞ §§ ɷ ɯ ⁄ ŋ curse of dimensionality Ô ᵛ ⅄ ị

ᴼ ɯ ɷ ɯ ŝ Ẅ Ẃ Á ʁ ṭ R̈ ŏ ⅋ ⅀ ⅓ SRE ị ɷ ŏ ɟ Ÿ Ẇ

ẅ ụ Ẇ confounding Ţ

ɷ kẆ ŋ **s p s Q l 。 a** θ ⊸ ⋊ ɷ ↓ ^ 。 **Ɱ ɯ ị p** Ô ẹ **Q**

‖ **w** ⁄ kẆ ị Ẹ ω

‖ **w q ‾ w w** ᴰ { { ŏ ɾ̄ Δ ẅ Ɠ ẹ kẆ $e_{[k]} = n_{[k]1}/n_{[k]}$ ŏ ɷ ⁄ ɯ

ʁ ị Ẇ ẅ 2 ɷ ʁ Ẅ ‾ ị ẅ ċ Ô ẹ Ÿ Ẇ ẅ ị ˘ ŏ { ɱ Δ ε

ʜ ị ẹ kẆ ‾

‾ ⅃ 13.1 (ẹ kẆ). 倾向得分定义为给定协变量条件下治疗分配的条件概率:

$$e(X) = \Pr(Z = 1 \mid X).$$

ẹ kẆ ɯ Ạ ɷ [0, 1] ɾ ɷ ị Ḥ ʁ ɷ ɯ ˛ ɾ ⅃ ɾ ɷ ɯ Δ ⁄ ɯ ị Ạ u Ş

§§ ɖ ɯ ɷ ʁ X ɯ Ụ ị ŏ ẋ ignorability X ₣ ˛ T̈ ŏ ⁄ ɯ ẹ kẆ

₣ ˛ T̈

‾ ⅃ **q ∼ w** ẹ Ẅ ẅ ị Ẹ ω ⅃)**w** 如果 $Z \perp \{Y(1), Y(0)\} \mid X$, 则有

$$Z \perp \{Y(1), Y(0)\} \mid e(X).$$

Ÿ ⅃ ŝ ẋ ignorability ẹ ɷ Ụ ʁ X ị ₣ ∨ ₣ ö ə ẋ ₣

‾ ⅃ { { ɯ ɷ ŏ Ɛ ∨ ä u ŏ Ẅ Ḥ ẹ kẆ $e(X)$ ₣ ₣ ŵ ᵊ æ

X ᵛ ⅄ ị ⁄ ɯ ᵀ ŏ ɷ ϒ ‖ Ụ ʁ X ╩ ʁ Ḥ $e(X)$ ŏ ⁄ ɯ ɯ ℏ : ω ɯ ô ị

ɷ Ô ŝ [1]

[1] ɷ ‖ Ô ḥ ??

[illegible] $\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = \Pr\{Z = 1 \mid e(X)\}$ [illegible] tower property [illegible] ignorability [illegible]

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{Z \mid Y(1), Y(0), e(X)\} = E\big[E\{Z \mid Y(1), Y(0), X\} \mid Y(1), Y(0), e(X)\big].$$

[illegible] ignorability [illegible] $E\{Z \mid Y(1), Y(0), X\} = E\{Z \mid X\} = e(X)$ [illegible]

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{e(X) \mid Y(1), Y(0), e(X)\} = e(X).$$

[illegible] $\Pr\{Z = 1 \mid e(X)\} = E\{Z \mid e(X)\} = E\{e(X) \mid e(X)\} = e(X)$ [illegible]

[illegible] Rosenbaum and Rubin 1983 [illegible] *Biometrika* [illegible] [illegible] *Biometrika* [illegible] ignorability [illegible] X [illegible] $e(X)$ [illegible]

[illegible]

[illegible] K [illegible] n [illegible]

$$Z \perp \{Y(1), Y(0)\} \mid e(X) = e_k \quad (k = 1, \ldots, K).$$

[illegible] k [illegible] K [illegible] CRE [illegible] SRE [illegible]

$$\tau_{[k]} = E(Y \mid Z = 1, e(X) = e_k) - E(Y \mid Z = 0, e(X) = e_k),$$

[illegible]

$$\tau = \sum_{k=1}^{K} \pi_{[k]} \tau_{[k]},$$

[illegible] $\pi_{[k]} = \Pr\{e(X) = e_k\}$ [illegible] k [illegible]

[illegible] $e(X) = \Pr(Z = 1 \mid X)$ [illegible] X [illegible] logistic [illegible]

[illegible] $\hat{e}(X)$ [illegible] n [illegible]

[illegible]

$$\hat{e}'(X_i) = e_k, \quad \text{[illegible]} \quad \hat{e}(X_i) \text{ [illegible]} \quad (k-1)/K \text{ [illegible]} \quad k/K \text{ [illegible]} \quad .$$

[illegible]

$$Z \perp \{Y(1), Y(0)\} \mid \hat{e}'(X) = e_k \quad (k = 1, \ldots, K).$$

ignorability $\hat{e}'(X)$ SRE

$K = 5$

K $Z \perp \{Y(1), Y(0)\} \mid \hat{e}'(X)$

K

Rosenbaum and Rubin 1983, 1984 Cochran 1968 $K = 5$ $K = 5$

K

K

6.2 SRE

SRE SRE

(1) SRE X CRE

$e(X)$

(2) SRE $e_{[k]} = n_{[k]1}/n_{[k]}$

e_k

(3)

SRE Neyman Fisher

6.3

$\hat{e}'(X)$ SRE

Z

$Z \perp \{Y(1), Y(0)\} \mid \hat{e}'(X)$

$\hat{e}'(X)$

$\hat{e}'(X)$

$\

⁻ wᵩ

⁻ w q w k] : ₪ P、 wᵩ ᴰ { {Ł NHANES

₪J

Ẅ Ŝ ñ̈Q́ŋ SchoolmealÕH BMI ļ

ʁ Ḥ Ŝ $Z_i = 1$ ʁ Ḧ ñ̈Q́ŏ $Z_i = 0$ ʁ Ḧ

♦ẁ Ŝ BMIŋ

Ka Ŝi⊣ẓᵝ~ Q~ ~↑ ₓ

ₓ ŏ ᵩ

logistic ‡ ʃ IQᵖ kẄŜ

$$\hat{e}(X_i) = \text{logit}^{-1}(\hat{\alpha}_0 + \hat{\alpha}_1 X_{i1} + \cdots + \hat{\alpha}_p X_{ip}).$$

{ {ᵩ Ẅ $K = 5, 10, 30$ IQᵖ kẄ ţ] ʁŏʁ

ŋ'ₒ ŋ ᵩ kẄẄÄᵉ ᵩ ʒ ŏ ʁ ᵩᵉ Ẅ

FIGURE 1. NHANES ₪ IQᵖ kẄ ţ ŝ ₒ Ḧ ŏ'

ᵩ ʁ

ʁ { {ẏ Ẅ K ŋ $K \in \{5, 10, 20, 50, 80\}$ Ō kẄẄ IQ♦ẁ 2

TABLE 1. ă Ẅ ₪ K ᵖ kẄẄ IQ♦ẁ

	$K = 5$	$K = 10$	$K = 20$	$K = 50$	$K = 80$
IQ	−0.116	−0.178	−0.200	−0.265	−
Ḥ	0.283	0.282	0.279	0.272	NA

ᴶ♦ẁ ᵀ ᵑŜ

(1) ₪ K ᴶ 5 ᵘ 50ŏḤ ╙┼ ŏIQ ᵖ ⁻ŋ −0.2Ō

(2) ᵠ $K = 80$ ₒŏḤ ⁻ ŋ NAŏ̈ ğ ₪ ïẠᵦ ɪ ɹ ɻᵦ Ş Ō

(3) ₪ IQ Dᵩ ïɻ ŏʁ ᵢ ñ̈Q́ẁ ᵀ ⁻ ╩ẓ BMIŏ̈ ₒ ă

⁻ w ₪ ₪ẁ ɻ ẁ ɻ Ç ẁʁ { {ᵀ Ẅ ᵖ kẄẄ ₪ ‡ IQ ɻ ♦ẁ

TABLE 2. ă IQ ţ Ṙ ɻ Ç

	naive	Fisher	Lin
IQ	0.534	0.061	−0.017
Ḥ	0.225	0.227	0.226

Ŭ ŀ Ÿ ₫ Ŝ

- ᵩ IQ ŋ l ; a ” Ạ ᵀ Q ₀ ᴾ ŋ 0.534 Ō ᵩ Ka ʁ ỳ Ḧ ʃ ɻ ᵖ ă ₓ ₫ Ş
- U a 。 ^ IQ Q ŋ Ka ᵘ Ĭ ɻ OLS Ō À ᵀ Δ ᵀ A ᵀ ɻ IQ ŋ 0.06 ₫ ă Ş
- f a Ɪ ŋ i Ạ ▌ Ÿ ɻ OLS Ō À ᵀ Δ ♦ ₫ ɻ IQ ŋ −0.017 Ş Ō
- ᵖ kẄẄ IQ ŋ −0.17 ʁ −0.27 Ō Lin IQ ⁻ ₒ ẁ ɻ ŏ ᵩ ă K ħ: ⁻

[2] ᵧ Q ᵩ ᵦ ᵕ ‖ ȯ ḥ ??

♦ὼ◕ȷ̂ŝ◔ kẏẄẄïıq̇ᵢ ◔ ⁻ȷ̣ ὼ ˈIΩṭṘŏ◕½⅛ Δ
SRE ȷ◕ᵢΩ◕ ŏ ᵢ ˈYb̈ı ᵂȷ̣ẽ ᵢ

R w

V̈ Łə̣Δ◔ kẏẄẄïıȷ̣Ω ◕ ˈΩṭṘŝ

(1) Ẹ ω̃ s̃ ȷ { ◕ij̇õ ◕ig̃ ignorability ∂◕ᵢ ŏ ╒ω̃ ◔ kẏẄ $e(X)$
╒ω̃ Ụ K X ◕F̃ t◔ᵢ◕ᵢr̃ȷ̃ȷ̣ŝ

(2) Ẅïıı◕ ŝ╟ũ ȷ̣◔ kẏẄ◕ȷ◕ω̃ K ıiõ ∨ıiıȯ≂◕⁴kᵢ ” ╒◕₂ω̃ ”
ȷ̣ ὼŝ

(3) 、 ~ Ẹũ ŝ◔ kẏẄẄïıV̈ ◕ḣ◕ᵢ╟ SRE ȷ◕ᵢΩ◕ ˈYb̈ı ᵂŝ

(4) K ȷ̣ ŝ $K = 5$ ◔ᵢ◕ı ˈı ┤õb` ᴘω̃ȷ̃◕ω̃ ◔ȷ◕ᵢ◕ᵢ -ŝ

(5) ┐ ŝ◔ kẏẄẄïı ◔ˈIΩ◔ kẏẄȷ̣ȷ̃ ◔õẗȷ̃ ◕ᵢ ẗ ┐

◔ kẏẄẄïıq̇◕ᵢ ὼ ḡ⃗Ẽ↘ ȷ̣₁cᴱẽ↘ ◕ᵢ◕ᵢă◕ᵢẄ ◗ ˈIΩ ὼ
ŏ ⁻ȷ̣ Δi◌ȷ̃ȷ̣ȥ-◕ᵢ◕ᵢ~ doubly robust ˈIΩrᵹ⃗ᵹ⃗ᵹ⃗ṭṘȷ̣₁c

CHAPTER 14

q w r

IPW Hajek

$$\hat{\tau}^{\text{hajek}} = \frac{\sum_{i=1}^{n} \frac{Z_i Y_i}{\hat{e}(X_i)}}{\sum_{i=1}^{n} \frac{Z_i}{\hat{e}(X_i)}} - \frac{\sum_{i=1}^{n} \frac{(1-Z_i)Y_i}{1-\hat{e}(X_i)}}{\sum_{i=1}^{n} \frac{1-Z_i}{1-\hat{e}(X_i)}} \tag{64}$$

Imbens, 2004 WLS

$\hat{\tau}^{\text{hajek}}$ WLS Z_i

$$(\hat{\alpha}, \hat{\beta}) = \arg\min_{\alpha,\beta} \sum_{i=1}^{n} w_i (Y_i - \alpha - \beta Z_i)^2$$

$$w_i = \frac{Z_i}{\hat{e}(X_i)} + \frac{1 - Z_i}{1 - \hat{e}(X_i)} = \begin{cases} \frac{1}{\hat{e}(X_i)} & \text{if } Z_i = 1; \\ \frac{1}{1-\hat{e}(X_i)} & \text{if } Z_i = 0. \end{cases} \tag{65}$$

IPW

w] ; Q e f 、

14.1 § Hajek WLS) w在 { {的记号下，$\hat{\tau}^{hajek}$ 严格等于上述 *WLS* 回归中 Z_i 的系数 $\hat{\beta}$。

CRE WLS OLS CRE OLS $e(X_i) \equiv p$ w_i τ $1/\hat{e}(X_i)$ $1/\{1 - \hat{e}(X_i)\}$ ” ”§§- Hajek

OLS treatment WLS $\hat{\tau}^{\text{hajek}}$ Bootstrap

[1] ??

14.2 Lin (2013) 的回归调整

CRE 下，Lin (2013) 提出了一种对 OLS 回归的简单修正，使其成为 treatment 效应的一致估计量。

对每个单位 i，拟合

$$Y_i \sim (1, Z_i, X_i, Z_i X_i)$$

其中 X_i 是协变量向量，$\bar{X} = 0$（可以先减去样本均值）。

记 $\hat{\tau}$ 为 WLS 回归

$$Y_i \sim (1, Z_i, X_i, Z_i X_i)$$

中 Z_i 的系数。

Hirano and Imbens (2001) 的

定义 14.2.1（WLS 回归） 设 $\hat{e}(X_i, \hat{\alpha})$ 为倾向得分的估计。WLS 回归是指在加权样本 $(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_0))$ 上的回归，其中权重为 $\hat{e}(X_i, \hat{\alpha})$。

$$\hat{\tau}^{\text{reg}}_{\text{wls}} = \frac{1}{n}\sum_{i=1}^{n} \mu_1(X_i, \hat{\beta}_1) - \frac{1}{n}\sum_{i=1}^{n} \mu_0(X_i, \hat{\beta}_0)$$

回归调整

$$\hat{\tau}^{\text{dr}}_{\text{wls}} = \hat{\tau}^{\text{reg}}_{\text{wls}} + \frac{1}{n}\sum_{i=1}^{n} \frac{Z_i\{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{\hat{e}(X_i, \hat{\alpha})} - \frac{1}{n}\sum_{i=1}^{n} \frac{(1-Z_i)\{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - \hat{e}(X_i, \hat{\alpha})}$$

定理 14.2.1 若 $\bar{X} = 0$ 且

$$(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_0)) = (\hat{\beta}_{10} + \hat{\beta}_{1x}^\top X_i,\ \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i)$$

基于权重 { {对 $Y_i \sim (1, Z_i, X_i, Z_i X_i)$ 的 *WLS* 拟合，则

$$\hat{\tau}^{dr}_{wls} = \hat{\tau}^{reg}_{wls} = \hat{\beta}_{10} - \hat{\beta}_{00}$$

即 Z_i 在 *WLS* 回归中的系数。

ȷ̇ ˋ Q ŝ 2
WLS ‡ Q i ˚ ˇ B ˛ ˙ Ó ȷ ´ U ˋ A ı A ▌ ˛ ŝ

$$\sum_{i=1}^{n} \frac{Z_i(Y_i - \hat{\beta}_{10} - \hat{\beta}_{1x}^{\top} X_i)}{\hat{e}(X_i)} = 0, \quad \sum_{i=1}^{n} \frac{(1 - Z_i)(Y_i - \hat{\beta}_{00} - \hat{\beta}_{0x}^{\top} X_i)}{1 - \hat{e}(X_i)} = 0.$$

ı A ˛ ˚ h $\hat{\tau}_{\text{wls}}^{\text{dr}} - \hat{\tau}_{\text{wls}}^{\text{reg}} = 0$ ∨ ä ˇ ˝ K ˜ ŋ $\bar{X} =$ Ø Ø Ð ˛ ˜
$\hat{\beta}_{10} - \hat{\beta}_{00}$

～w～w U Q Q N j ; l ; l N ˛ ˛ A Q w Freed˛man and **R u** Berk (2008) 1 ˇ ˙ ˘
H ˛ ˛ WLS Ø ˜ ı Δ ˇ ˛ ˛ ı ˚ ♦ ˛ ˇ ˚ ˇ WLS Ø ˛ ˛ ȷ
K N Ç OLS Ø ˛ ˛ ˛

命题 14.3 若 $\hat{\bar{X}}(1) = 0$ 且 $\mu_0(X_i, \hat{\beta}_0) = \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i$ 基于权重 $\{1 - \hat{o}(X_i)\}\hat{o}(X_i)$ 对 $Y_i \sim (1, Z_i, X_i, Z_i X_i)$ 的 *WLS* 拟合，则

$$\hat{\tau}^{dr}_{T,wls} = \hat{\tau}^{reg}_{T,wls} = \hat{\beta}_{10} - \hat{\beta}_{00}$$

即 Z_i 在 *WLS* 回归中的系数。

14.3 实证例子

[3]

14.4 小结

{1} 倾向得分 $\hat{o}(X_i)$ 是 CRE 下的充分统计量。

{2} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

{3} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

{4} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

{5} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

14.5 文献评注

{1} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

{2} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

{3} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

{4} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

{5} 在 CRE 下，OLS 与 WLS 的区别在于是否使用 $w_i = 1/\hat{o}(X_i)$ 或 $1/(1-\hat{o}(X_i))$ 加权。

14.6 练习题

练习 14.1. 证明 *命题 14.1* 和 *14.2* 的证明 证明 和 。

：这些是附录 *B.3* 中一元 *WLS* 问题的特例。利用 *WLS* 的正规方程即可证明。

练习 14.2. 预测估计量与双重稳健估计量 另一种结局回归估计量是预测估计量

$$\hat{\tau}^{pred} = \hat{\mu}_1^{pred} - \hat{\mu}_0^{pred}$$

其中

$$\hat{\mu}_1^{pred} = \frac{1}{n}\sum_{i=1}^{n}\{Z_i Y_i + (1 - Z_i)\mu_1(X_i, \hat{\beta}_1)\}, \quad \hat{\mu}_0^{pred} = \frac{1}{n}\sum_{i=1}^{n}\{Z_i \mu_0(X_i, \hat{\beta}_1) + (1 - Z_i)Y_i\}.$$

证明：当 $(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_1)) = (\hat{\beta}_{10} + \hat{\beta}_{1x}^\top X_i, \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i)$ 来自基于权重

$$w_i = Z_i/\hat{o}(X_i) + (1 - Z_i)\hat{o}(X_i)$$

[3] ??

对 $Y_i \sim (1, X_i)$ 的 *WLS* 拟合时，双重稳健估计量等于 $\hat{\tau}^{pred}$。

: *Cao et al. (2009)* 和 *Vermeulen and Vansteelandt (2015)* 从其他理论角度 *motivation* 了上述权重。

14.3. **{** **{***WLS* 的效率性质 讨论在何种情形下 *WLS* 估计量比 *OLS* 估计量更有效。在 *Freedman and Berk (2008)* 的模拟设置中，为什么 *OLS* 表现更好？这与本章讨论的异方差情形有何关联？

14.4. **{** **{**推荐阅读 : **{** 是关于因果推断中加权方法的权威综述。**{** 讨论了协变量调整在随机化实验中的应用。

: *WLS* 与 *IPW* 的等价性最早由 *Imbens (2004)* 明确指出。双重稳健性的概念在 *Robins et al. (2007)* 中得到了系统阐述。

CHAPTER 15

Matching

Introduction

"Matching is a way of making observational studies look like randomized experiments."
— (Rubin)

Matching for the ATT

Matching with multiple controls

Matching for the ATE

Abadie–Imbens (AI) matching

Abadie–Imbens (AI) [1]

$$\{X_i, Z_i, Y_i(1), Y_i(0)\}_{i=1}^{n} \overset{\text{IID}}{\sim} \{X, Z, Y(1), Y(0)\}.$$

[1] ??

匹配估计量的偏差校正

对于每个单位 i，匹配估计量用其 M 个匹配单位的结果均值来估计缺失的潜在结果。记 $m_j(i)$ 为单位 i 的第 j 个匹配单位，则

$$\hat{Y}_i(1) = Y_i,$$

$$\hat{Y}_i(0) = M^{-1} \sum_{j=1}^{M} Y_{m_j(i)},$$

$$\hat{\tau}^{\mathrm{m}} = n^{-1} \sum_{i=1}^{n} Z_i\{\hat{Y}_i(1) - \hat{Y}_i(0)\} + n^{-1} \sum_{i=1}^{n} (1 - Z_i)\{\hat{Y}_i(0) - \hat{Y}_i(1)\}.$$

令 $J(i)$ 为单位 i 的匹配集合，$K_i = |J(i) \cap \{j : Z_j = 1\}|$ 为其中处理单位的个数。

定理 15.1 在 M 固定的情况下，当 $n \to \infty$ 时，

$$\sqrt{n}(\hat{\tau}^{\mathrm{m}} - \tau) \Rightarrow \mathcal{N}\{0, V^{\mathrm{m}}(\tau)\},$$

其中偏差来自不精确匹配。[2]

Bootstrap 方差估计

bootstrap 方差估计量 $\hat{V}^{\mathrm{mbc}}$ 的计算步骤如下：

$$\hat{\tau}^{\mathrm{mbc}} = \hat{\tau}^{\mathrm{m}} + n^{-1} \sum_{i=1}^{n} \hat{\psi}_i,$$

其中 $\hat{\psi}_i$ 的构造方式使得 $\hat{\tau}^{\mathrm{mbc}}$ 的渐近方差恰为 $\hat{\psi}_i$ 的样本方差。[3] 因此，bootstrap 重复抽样时只需对 $\hat{\psi}_i$ 进行重抽样，即可得到 $\hat{V}^{\mathrm{mbc}}$ 的 bootstrap 估计。

双稳健性

匹配估计量的偏差校正形式具有双稳健性：

定理 15.2 若倾向得分模型或结果回归模型中至少有一个被正确设定，则偏差校正匹配估计量满足

$$\hat{\tau}^{\mathrm{mbc}} = \hat{\tau}^{\mathrm{DR}},$$

其中 $\hat{\tau}^{\mathrm{DR}}$ 是第 15 章定义的双稳健估计量。[4]

---

[2] 详见 Abadie 与 Imbens (2006) 的证明。

[3] 详见 Abadie 与 Imbens (2006)。

[4] 详见 Abadie 与 Imbens (2011)。

{ {匹配估计量 $1+K_i/M$ 1
匹配 $1/\hat{e}(X_i)$ 加权

匹配 $e(X_i)$ 倾向得分 $1/\hat{e}(X_i)$ 倾向得分的倒数 匹配 β 匹配
K_i 倾向得分 $1+K_i/M$ 倾向得分 匹配 匹配 匹配 M 匹配
$1+K_i/M$ 匹配 $1/e(X_i)$ 加权 匹配 M 匹配 匹配
匹配 { 匹配 M 匹配

匹配估计量

匹配 匹配 匹配 匹配

$$\tau_{\mathrm{T}} = \mathbb{E}\{Y_i(1) - Y_i(0) \mid Z_i = 1\}.$$

ATT 匹配 匹配

$$\hat{\tau}_{\mathrm{T}}^{\mathrm{m}} = n_1^{-1} \sum_{i:Z_i=1} \{\hat{Y}_i(1) - \hat{Y}_i(0)\},$$

匹配 $\hat{Y}_i(1) = Y_i$ 匹配 $\hat{Y}_i(0) = M^{-1}\sum_{j=1}^{M} Y_{m_j(i)}$
匹配 匹配

$$\hat{\tau}_{\mathrm{T}}^{\mathrm{mbc}} = \hat{\tau}_{\mathrm{T}}^{\mathrm{m}} + n_1^{-1} \sum_{i:Z_i=1} \hat{\psi}_i^{\mathrm{T}}.$$

匹配 匹配 匹配

R▯▯ ♦

▯ ▯▯▯

CHAPTER 16

q w ‘ **l J p l V p ‘ l N Q N l Q**。。

“Although we cannot see the wind, we can see its effects on the leaves.” — George Box

$$Z \perp \{Y(1), Y(0)\} \mid X. \tag{16.1}$$

“所有模型都是错的，但有些有用。”

p ” Q _ ; N c ‘ **j Q N — j**

‖ **w** Pearl (1995)

$$X \to Z \to Y$$

$$\begin{cases} X \sim F_X(x), \\ Z = f_Z(X, \varepsilon_Z), \\ Y(z) = f_Y(X, z, \varepsilon_Y(z)), \end{cases} \tag{16.2}$$

$\varepsilon_Z \perp \varepsilon_Y(z)$ $Z \perp Y(z) \mid X$

U

$$U \to Z,\ U \to Y,\ X \to Z,\ X \to Y$$

...

$$\begin{cases} X \sim F_X(x), \\ U \sim F_U(u), \\ Z = f_Z(X, U, \varepsilon_Z), \\ Y(z) = f_Y(X, U, z, \varepsilon_Y(z)), \end{cases} \tag{16.3}$$

... $\varepsilon_Z \perp \varepsilon_Y(z)$ ... $Z \perp Y(z) \mid (X, U)$ ... $Z \not\perp Y(z) \mid X$ ... (X, U) ... X ... U ...

... backdoor path ...

$$\sim$$ ...

$$\sim$$ ...

$$Z \perp Y(1) \mid X, \quad Z \perp Y(0) \mid X. \tag{16.4}$$

...

$$\Pr\{Y(1) \mid Z = 1, X\} = \Pr\{Y(1) \mid Z = 0, X\},$$

$$\Pr\{Y(0) \mid Z = 1, X\} = \Pr\{Y(0) \mid Z = 0, X\}. \tag{16.5}$$

... X ... $\Pr\{Y(1) \mid Z = 0, X\}$ ... $\Pr\{Y(0) \mid Z = 1, X\}$ ...

... backdoor ...

... $Z \perp Y(z) \mid X$ ... $Z \perp Y^{\mathrm{n}}(z) \mid X$ ... Y^{n} ... Y ... Z ... Y^{n} ...

$$\tau(Z \to Y^{\mathrm{n}}) = \mathbb{E}\{Y^{\mathrm{n}}(1) - Y^{\mathrm{n}}(0)\} \tag{16.6}$$

... $\tau(Z \to Y^{\mathrm{n}}) = 0$ ...

... Z ... Y^{n} ...

例 16.1 (Cornfield ... (1959) ...). *Cornfield 等 (1959)* 研究了吸烟对肺癌的因果效应。他们在分析中控制了众多重要的背景变量，但仍可能存在某些未测混杂因素使观察到的效应产生偏倚。

为了加强因果关系的证据，他们同时报告了吸烟对车祸的影响——基于生物学知识，吸烟对车祸应该没有因果效应。结果显示关联接近于零。因此，即使无法完全排除未测混杂，这个基于阴性结果的补充分析使吸烟对肺癌因果效应的证据更加有力。

⠁⠝ 16.2 (Jackson ⠇ (2006)⠎⠙ ⠗⠍). *Jackson* 等 *(2006)* 对观测性研究的结果持怀疑态度。这些研究显示，在调整了测量的协变量后，流感疫苗接种显著降低了流感季节的肺炎/流感住院率和全因死亡率。

他们的补充分析考察了流感季节开始之前的结局指标。疫苗接种通常在秋季开始，但流感传播在冬季之前是极少的。基于生物学，疫苗效应在流感季节应该最为显著。但 *Jackson* 等发现，疫苗效应在流感季节之前反而更大——这暗示观察到的效应可能源于未测混杂。

⠀⠀⠀

16.4 工具变量与两阶段最小二乘

工具变量（instrumental variable）是处理内生性问题的经典武器。设结果 Y 由处理 X 与不可观测的混杂 U 共同决定，而我们只观测到 X 与 Y。若存在变量 Z 满足：

$$U_1 \to X \leftarrow U_2,\ U_1 \to Z,\ U_2 \to Y$$

即 Z 通过影响 X 来影响 Y，但与 Y 的误差项 U_2 无直接关联，则称 Z 为 $X \to Y$ 的工具变量。

(16.8)
$$\begin{cases} U_1 \perp U_2, \\ X = f_X(U_1, U_2, \varepsilon_X), \\ Z = f_Z(U_1, \varepsilon_Z), \\ Y = Y(z) = f_Y(U_2, \varepsilon_Y), \end{cases}$$

$(\varepsilon_X, \varepsilon_Z, \varepsilon_Y)$ 相互独立。X 与 Y 之间的混杂路径 $X \leftarrow U_1 \to Z \to Y$ 在 Z 处被截断，Z 与 Y 之间的唯一通路是 $Z \to X \to Y$。

(16.9)
$$\tau_{\mathrm{PF}} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0) = 0.$$

(16.10)
$$\int \{\mathbb{E}(Y \mid Z = 1, X = x) - \mathbb{E}(Y \mid Z = 0, X = x)\} f(x)\, dx \neq 0.$$

(16.11)
$$\begin{cases} X = aU_1 + bU_2 + \varepsilon_X, \\ Z = cU_1 + \varepsilon_Z, \\ Y = dU_2 + \varepsilon_Y, \end{cases}$$

(16.12)
$$\operatorname{cov}(Z, Y) = \operatorname{cov}(cU_1 + \varepsilon_Z, dU_2 + \varepsilon_Y) = 0,$$

(16.13)
$$\rho_{ZY|X} \propto -abcd,$$

例 16.4 (M-偏差的大小)。考虑样本量 $n = 10^6$ 的大规模蒙特卡洛模拟：

```
U1 = rnorm(n)
U2 = rnorm(n)
X = U1 + U2 + rnorm(n)
Y = U2 + rnorm(n)
Z = U1 + rnorm(n)

# 连续治疗
```

```
summary(lm(Y ~ Z))$coef[2, 1]  # [1] 0.001
summary(lm(Y ~ Z + X))$coef[2, 1]  # [1] -0.20

# 二值治疗
Z = (Z >= 0)
summary(lm(Y ~ Z))$coef[2, 1]  # [1] 0.002
summary(lm(Y ~ Z + X))$coef[2, 1]  # [1] -0.42
```

未调整的简单估计量接近真实值 (0)，但调整 X 后的估计量产生了显著偏倚（约 -0.2 到 -0.4）。这就是 *M*-偏倚。

M-结构图 U_1 和 U_2 的边缺失，X 是观测的

X w ‖ w 「w 结构图 「_ B 0a 缺失数据 b_2 M-结构

$$Z \leftarrow X \to U \to Y$$

X Z U Y 的缺失数据

$$\begin{cases} Z = aX + bU + \varepsilon_Z, \\ Y(z) = \tau z + cU + \varepsilon_Y, \end{cases} \tag{16.14}$$

$(U, X, \varepsilon_Z, \varepsilon_Y) \overset{\text{IID}}{\sim} \mathrm{N}(0,1)$ $X \perp U$ X Z Y X Z Y U X Z U U OLS

$$\tau_{\text{unadj}} = \tau + \frac{c\ \mathrm{cov}(Z,U)}{\mathrm{var}(Z)} = \tau + \frac{cb}{a^2+b^2+1}, \tag{16.15}$$

$bc/(a^2+b^2+1)$ OLS Y (Z, X)

$$\tau_{\text{adj}} = \tau + \frac{bc}{b^2+1}. \tag{16.16}$$

$a \neq 0$ $a^2+b^2+1 > b^2+1$

$$\left|\frac{bc}{a^2+b^2+1}\right| < \left|\frac{bc}{b^2+1}\right|. \tag{16.17}$$

X Z a

例 16.5 (Z-结构). 考虑蒙特卡洛模拟：

```
n = 10^6
X = rnorm(n)
U = rnorm(n)
Z = X + U + rnorm(n)
Y = U + rnorm(n)

# Z ~ X + U
```

```
summary(lm(Y ~ Z))$coef[2, 1]  # [1] 0.333
summary(lm(Y ~ Z + X))$coef[2, 1]  # [1] 0.501

# X-Z 关联更强时
Z = 2*X + U + rnorm(n)
summary(lm(Y ~ Z))$coef[2, 1]  # [1] 0.167
summary(lm(Y ~ Z + X))$coef[2, 1]  # [1] 0.501

# X-Z 关联更强时
Z = 10*X + U + rnorm(n)
summary(lm(Y ~ Z))$coef[2, 1]  # [1] 0.01
summary(lm(Y ~ Z + X))$coef[2, 1]  # [1] 0.50
```

可以看到：随着 X 与 Z 的关联增强，未调整估计量越来越接近真实值 $\tau = 0$，而调整后的估计量始终为 0.5——因为调整反而引入了更大的偏倚。

▯▯▯▯▯▯▯▯

TABLE 1. [illegible]

[illegible]	Z [illegible]	Y [illegible]	
X [illegible]	[illegible]	[illegible]	[illegible]
X_R [illegible]	[illegible]	[illegible]	[illegible]
X_Z [illegible]	[illegible]	[illegible]	[illegible]
X_Y [illegible]	[illegible]	[illegible]	[illegible]
X_I [illegible]	[illegible]	[illegible]	[illegible]

[illegible] 16.2. 考虑正文中的 M-偏倚正态线性模型。证明给定 X 时 Z 和 Y 的偏相关系数公式 [illegible]

[illegible] 16.3. 找出一个你自己的研究领域中的阴性结果或阴性暴露的例子。讨论为什么它符合阴性控制的条件，以及它如何帮助评估不可混淆性假设。

[illegible] 16.4. [illegible] 和 *econometricians* 提出了以下 ***Cochran*** [illegible]（也称为遗漏变量偏倚公式）。设 $(y_i, x_{1i}, x_{2i})_{i=1}^n$ 为 *IID* 样本，其中 y_i 是标量，x_{1i} 维数为 K，x_{2i} 维数为 L。考虑 *OLS* 分解：

$$y_i = \beta_1^{\mathrm{T}} x_{1i} + \beta_2^{\mathrm{T}} x_{2i} + \varepsilon_i \quad \text{（长回归）},$$
$$y_i = \gamma^{\mathrm{T}} x_{1i} + e_i \quad \text{（短回归）},$$
$$x_{2i} = \delta^{\mathrm{T}} x_{1i} + v_i.$$

证明：$\gamma = \beta_1 + \delta\beta_2$。解释为什么 $\delta\beta_2$ 被称为遗漏变量偏倚。

[illegible] 16.5. 设计一个模拟研究，演示以下情形：

(1) 调整混杂变量 X 可以减少偏倚；
(2) 调整与未测混杂相关的变量会引入 M-偏倚；
(3) 调整工具变量 X_Z 在存在未测混杂时会放大偏倚。

对于每种情形，使用大样本量（$n = 10^5$）计算未调整和调整后的估计量。

[illegible]

[illegible] Pearl (2000) [illegible]
VanderWeele [illegible] Shpitser (2011) [illegible]
Rosenbaum (2002b) [illegible]
Ding [illegible] (2017b) [illegible] Z-[illegible]

CHAPTER 17

P _ “ ; ŝgg̈ ˚ŸB̈ Q ỵ ẇ ɔ̃

q w ŝ ꜰ ʏ ɪ ɪ̣ ɦ ∂ q̈ ẇ ɴ ɲ

“It is possible that the entire relationship between cigarette smoking and lung cancer is due to some common cause.” — ({)

Part III ŏ ɲ ∆ʏ B̈ ẅ ỵ ɲ ᵖ ŝ outcome regression ɲ ᵖ { {Ô
ɟ̈ ɕ ḳ ẘ - ɲ ɟ ᵖ { {Ô ɲ ᵖ { {Ô ʞ ᵖ { {Ô ɲ ṭ ṙ ỵ
Ṳ ∂ q̈ ẇ ɪ ʏ ɪ ɪ̣ ɦ ɲ **a Z l p ;Ô B a g a —》**

$$Z \perp \{Y(1), Y(0)\} \mid X. \tag{67}$$

đ K ɯ X ɾ ŏ ʁ ẘ Z ɴ ♦ ẇ ŸD ɪ̈ ˚ ∂ q̈ ẗ h ∆ ɲ ʏ ᴶ
ʏ B ɯ ɔ ɯ Q ẇ ɯ Ṇ ŏ ʏ ɪ ɪ̣ ɦ ∂ q̈ ẇ ṙ ᴶ ɯ ɔ V ɪ̈ ẋ § § ɯ ẇ ɛ V̈
ỵ ∂ q̈ ẇ ŏ ɴ ẅ ỵ ɗ ɯ Ḧ ẇ ♦ ɪ ỵ ɡ
ɯ ʏ B ɪ̈ ẅ ˳ ɯ ɵ ʁ ɯ ỵ Ŝ ɲ ẇ ɪ̣ Ṙ ʍ ỵ ɾ ɯ ŏ ʏ ɗ ɵ ỵ ʁ
♦ ẇ ∫ ỵ ŭ ŭ ɔ ỵ ɯ ∂ ỵ Ω ɜ ÿ ɯ ɲ ʏ B ɯ ɔ ỵ ŭ ŭ ɔ K ĝ ŏ b Ṙ h
ŭ ŭ ʁ Ǩ e ɯ ỵ ẇ ŭ
ɯ Ṇ ŏ Ɋ ụ ỵ ɪ̣ ʏ B ɪ̈ ẅ D ɯ ɯ ʃ ɯ ẅ ∂ ɗ ᴷ e ɲ ɗ ɲ ỵ ẇ
ɔ (ʃ ɯ ɪ̣ ẅ ɛ ĝ ŭ ɾ ŝ ɕ ỵ ɯ ɾ ʏ ɗ ɵ ỵ ŭ ŭ ŏ ɲ ɗ K ĝ ỵ Ṭ ɯ
ẇ ĝ E ɗ ɯ ɦ ă ɑ ɾ ỵ ŏ ɯ ɾ ẇ ɔ ɯ ɵ ŭ ɕ ɯ e
V ɯ ỵ **P _ ” ; ɲ g** VanderWeele and Ding, 2017 Ô ɕ ɯ Ḧ ɯ ɯ ỵ ɯ ẇ ɯ

[1] Ding and VanderWeele (2016) ỵ ɾ ∏ ŏ ɯ ɪ ʏ B ɪ̈ ẅ ỵ ẇ ɔ ɲ Δ ɲ A
ɯ ɲ ɯ ɲ ɗ E ɲ ᵖ { {∏ ´ ẇ ỵ E ɔ ɛ W ŝ ɲ { {∏ Rosenbaum
V ɪ̣ ɪ̣ S ɪ̈ ɪ̈ ɪ̣ ẅ E ɔ ɛ W

‖ w I p l E ɔ ɛ W Q g N

‖ w q ɪ ɪ̣ ẅ ɯ ɾ ʏ ɪ ɪ̣ ɦ ẅ ɯ ỵ ɯ ∂ q̈ ẇ { {ã ɯ ỵ ɯ ɔ W ɛ V ɯ ɯ
ɯ ɲ ∂ q̈ ẇ ɾ ʏ ɪ ɪ̣ ɦ ɲ **g ; —Q l — a Z l ŝ p ; B a g a —》**

$$Z \perp \{Y(1), Y(0)\} \mid (X, U), \tag{68}$$

ɾ U ɯ ɲ ɗ K ɯ ŏ ɾ (X, U) ɯ ɵ ɾ ♦ ẇ ŸD ɪ̈ { { { {
§ § ɯ Z Y ʃ e ɑ U ʁ ɲ ỵ ŭ ŭ ŏ ŭ ŭ ɲ θ U ɲ ɯ
V ỵ ɪ̣ ṭ Ṙ Ô ♦ ẇ Y ɯ ʜ ɾ ɲ Ding and VanderWeele, 2016 ɯ ɲ ɯ ẅ ɔ
ɯ ɯ ỵ i ♦ ẇ ɾ ɲ ẅ ɯ ɵ æ ɯ Q ɯ ɔ ɲ ẇ ɵ ɾ ∂ q̈ ẇ Y Ô

‖ w ‖ ɯ ẗ ẇ ʏ B ɪ̈ ẗ ɕ w X = x ɾ ŏ ɯ ỵ ɾ ẗ ɕ ŝ

$$\mathrm{RR}^{\text{true}}_{ZY|x} = \frac{\Pr\{Y(1) = 1 \mid X = x\}}{\Pr\{Y(0) = 1 \mid X = x\}}. \tag{69}$$

$$\mathrm{RR}^{\mathrm{obs}}_{ZY|x} = \frac{\Pr(Y=1 \mid Z=1, X=x)}{\Pr(Y=1 \mid Z=0, X=x)}. \tag{70}$$

$$Z \leftarrow U \rightarrow Y,$$

$$\mathrm{RR}_{ZU|x} = \frac{\Pr(U=1 \mid Z=1, X=x)}{\Pr(U=1 \mid Z=0, X=x)}, \tag{71}$$

$$\mathrm{RR}_{UY|x} = \frac{\Pr(Y=1 \mid U=1, X=x)}{\Pr(Y=1 \mid U=0, X=x)}, \tag{72}$$

$$RR^{\mathrm{obs}}_{ZY|x} > 1, \quad RR_{ZU|x} > 1, \quad RR_{UY|x} > 1. \tag{73}$$

$$RR^{\mathrm{obs}}_{ZY|x} \leq \frac{RR_{ZU|x} \cdot RR_{UY|x}}{RR_{ZU|x} + RR_{UY|x} - 1}. \tag{74}$$

$$\min(\mathrm{RR}_{ZU|x}, \mathrm{RR}_{UY|x}) \geq \mathrm{RR}^{\mathrm{obs}}_{ZY|x}. \tag{75}$$

∼w P _ ” ; g ‘ Q

∼w ɋ wI p l g N P _ ” ; g ⅂‘ Qw{ { ( ) $w = \max(\mathrm{RR}_{ZU|x}, \mathrm{RR}_{UY|x})$

$$\mathrm{RR}^{\mathrm{obs}}_{ZY|x} \le \frac{w^2}{2w-1}. \tag{76}$$

$$\le 1$$

$$w \ge \mathrm{RR}^{\mathrm{obs}}_{ZY|x} + \sqrt{\mathrm{RR}^{\mathrm{obs}}_{ZY|x}(\mathrm{RR}^{\mathrm{obs}}_{ZY|x}-1)}. \tag{77}$$

E-value

17.2 (E-value). 给定观测条件风险比 $RR^{\mathrm{obs}}_{ZY|x}$，定义 ***E-value*** 为

$$\text{E-value} = RR^{\mathrm{obs}}_{ZY|x} + \sqrt{RR^{\mathrm{obs}}_{ZY|x}(RR^{\mathrm{obs}}_{ZY|x}-1)}. \tag{78}$$

P _ ” ; g ‘ Q E-value $\max(\mathrm{RR}_{ZU|x}, \mathrm{RR}_{UY|x})$

$R <$ E-value

P _ ” ; g ‘ Q a 。 p Q Fisher p

p p

E-value

q ¯ w)w定义 $\beta(w_1, w_2) = w_1 w_2/(w_1+w_2-1)$ $(w_1>1, w_2>1)$。则：

(1) $\beta(w_1, w_2)$ 对称于 w_1 和 w_2；
(2) $\beta(w_1, w_2)$ 对 w_1 和 w_2 均单调递增；
(3) $\beta(w_1, w_2) \le w_1$ 且 $\beta(w_1, w_2) \le w_2$；
(4) $\beta(w_1, w_2) \le w^2/(2w-1)$，其中 $w = \max(w_1, w_2)$。

(3) Cornfield (4)

Cornfield E-value [2]

X w

17.1 (Hammond and Horn, 1958). 研究美国人群中吸烟与肺癌的关系。不调整协变量的数据可列为下表：

	肺癌	无肺癌
吸烟者	*397*	*78,557*
非吸烟者	*51*	*108,778*

基于该数据，风险比估计为 $\widehat{RR} = 10.73$，*95%* 置信区间为 $[8.02, 14.36]$。

- 解释点估计的 *E-value*：

$$\text{E-value} = 10.73 + \sqrt{10.73 \times 9.73} \approx 20.95.$$

- 解释下限的 *E-value*：

$$\text{E-value}_{\mathrm{CI}} = 8.02 + \sqrt{8.02 \times 7.02} \approx 15.52.$$

[2] ??

：要完全解释掉观察到的风险比（甚至其置信下限），未测混杂与治疗的关联以及与结果的关联，都必须达到至少 *15.52*。这意味着未测混杂必须是一个强 的风险因子——它与吸烟的关联程度要接近吸烟本身与肺癌的关联程度（*10* 倍以上）。在领域知识上，这种强度的未知混杂似乎不太合理，因此该研究提供了较强的因果证据。

Hammond and Horn
$(\mathrm{RR}_{ZU|x}, \mathrm{RR}_{UY|x})$

Ww

E-value Bradford Hill, 1965

Bradford Hill

E-value

temporality biological plausibility consistency

E-value

17.4 (Bradford Hill). *(* 提出的九条因果判定准则：

(1) 强度（*strength*）；
(2) 一致性（*consistency*）；
(3) 特异性（*specificity*）；
(4) 时间顺序（*temporality*）；
(5) 生物学梯度（*biological gradient*）；
(6) 生物学合理性（*plausibility*）；
(7) 一致性（*coherence*）；
(8) 实验证据（*experiment*）；
(9) 类比（*analogy*）。

E-value (1)

(79) $$\Pr(Y_i = 1 \mid Z_i, X_i) = \frac{e^{\beta_0 + \beta_1 Z_i + \beta_2 X_i}}{1 + e^{\beta_0 + \beta_1 Z_i + \beta_2 X_i}}.$$

β_1 X common odds ratio

$\Pr(Y = 1 \mid Z, X)$ $\hat{\beta}_1$ E-values

(80) $$\widehat{\text{E-value}} = \exp(\hat{\beta}_1) + \sqrt{\exp(\hat{\beta}_1)(\exp(\hat{\beta}_1) - 1)}.$$

E-value

▯▯ 17.2 (NCHS 2003 ▯▯▯

17.1 E-value

(1) [illegible]

(2) [illegible] $\mathrm{RR}^{\mathrm{obs}}_{ZY|x}$ [illegible]

(3) [illegible] $\text{E-value} = \mathrm{RR}^{\mathrm{obs}}_{ZY|x} + \sqrt{\mathrm{RR}^{\mathrm{obs}}_{ZY|x}(\mathrm{RR}^{\mathrm{obs}}_{ZY|x} - 1)}$

(4) E-value [illegible]

(5) E-value [illegible] Bradford Hill [illegible]

[illegible]

Rw

17.1 (17.1). 证明函数 $f(x) = (ax+1)/(bx+1)$ 在 $a > b$ 时关于 x 单调递增，在 $a < b$ 时单调递减。

17.2 (17.2). 证明在假设 $Z \perp Y \mid (X, U)$ 下，如果 $RR_{ZU|x} > 1$ 但 $RR_{UY|x} < 1$，则 $RR^{\mathrm{obs}}_{ZY|x} < 1$。这说明 [illegible] 中的第三个条件在某种意义上是冗余的。

17.3 (17.3). 证明引理 [illegible]

17.4 (17.4). （*Schlesselman 1978* 公式）在二值治疗 Z、结果 Y 和未测混杂 U 下，假设层内（$U=0$ 和 $U=1$）治疗对结果的风险比相同，$RR_{ZY|U=0} = RR_{ZY|U=1}$，且混杂对结果的风险比在两组治疗下也相同（记为 γ）。证明：

$$\frac{RR^{\mathrm{obs}}_{ZY}}{RR^{\mathrm{true}}_{ZY}} = \frac{1 + (\gamma - 1)\Pr(U = 1 \mid Z = 1)}{1 + (\gamma - 1)\Pr(U = 1 \mid Z = 0)}. \tag{83}$$

并讨论此公式与定理 [illegible] 的关系。

17.5 (17.5). 使用与例 [illegible] 相同的数据集，计算结果为子痫前期（*preeclampsia*）时的 *E-value*。

17.6 (17.6). （风险差的 *Cornfield* 不等式）考虑二值 Z, Y, U。在潜在可忽略性 $Z \perp Y \mid U$ 下，证明风险差的 *Cornfield* 不等式：

$$RD^{\mathrm{obs}}_{ZY} = RD_{ZU} \times RD_{UY}, \tag{84}$$

并由此推出：

$$\min(RD_{ZU}, RD_{UY}) \geq RD^{\mathrm{obs}}_{ZY}, \quad \max(RD_{ZU}, RD_{UY}) \geq \sqrt{RD^{\mathrm{obs}}_{ZY}}. \tag{85}$$

mw

- [illegible] Cornfield [illegible] E-value [illegible]
- [illegible] E-value [illegible]
- [illegible] Bradford Hill [illegible]
- [illegible] E-value [illegible]

CHAPTER 18

‖ w i ; l ₒ₂ₚₙₙ₩₤ a

‖ w q ₗ₀₩ w □₤ₒ₰₤₩ ₒ ŏ ₀ ₤ₒ₰ ₳₤ₚₒ₥₤₁₩₰₰₰₰ ₰

W ₒ₀₩ s ; —a ; g a N Q l —a 【J ; —a p l

18.1 (₰₩ₒ₀). 如果观测数据分布与参数 θ 的多个值相容，则称参数 θ 是₰₩ ₒ₀ 的。

₀ { {⌈ ‗ ₦₵₲ₛₚₒ₩₥₥ θ ₹₩₥₥₴₩₳ ₵ ŏ ₒ₀ₚₒ₦ₒ₀

₤₲₳ ŏ ₒ₥ ₵₥₰₩ₒ₀₤

₹₩₦ ₀ₚₒ ŏ τ ₵₥₦ₒ₀₤₲₥ ₱ ₹₩₦ ₀ₚₒ₤ₒ₥₦ ŏ τ w ₵₥₰₩

ₒ₀₤

‖ w ₩₱ₚₒw p ‘ — J p ₣j Q ₰w ₀₩₀ₚₒ outcomes ₤₴

$$\underline{y} \le Y_i(1), Y_i(0) \le \overline{y}.$$

₦ Ô ♦ò ŏ ₹⟦ $[\underline{y}, \overline{y}] = [0, 1]$

₳₲₍₀₀ₚₒ ₲₀ ₱₥ $E\{Y(1)\}$ ₹ $E\{Y(0)\}$ ₤ ₀₥₩₦₴₤₴ $E\{Y(1)\}$

₤₩ ₴

$$E\{Y(1)\} = E\{Y(1) \mid Z = 1\} \Pr(Z = 1) + E\{Y(1) \mid Z = 0\} \Pr(Z = 0).$$

Part III ŏ ₀ □₳₥ ₁ ₹₹₱ ₀₰₤ ₀ ₲₮₹₴ outcome regression₰ₚ ₀ { {₴₴₵ kẄ-₰₰ₚ ₀ { {₰₰ ₹₹₱₰ₚ ₀ { {₴ ₦₴₴₴ ₰ₚ ₀ { {₴₹₱ ₀₰₤ ₭₦ X ₣ ŏ ₴ ₩₴₴ Z ₃ ♦₀ ₹₽₴₴₴

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

₳₀₰₤₦ ₳ ₀ ₹ ₶₹₴₦₴₴ ₥₥₴ ₀ $\tau = \mathbb{E}\{Y(1) - Y(0)\}$

₥₰₵ₚ ₀ { { ! ₰₹₱₹₹₱ ₀₰₤ ₹₶₥₴₴₴₴ ₴ ₩ ₹₩ ₰₰

₸ ₰₰₵₵₹₹₱₦₴₴₤ ₴ ♦₀ ₸₤₴₴₴₴₰₤ ₀₰₤

₶₹ ₹ ŏ ₲ ₰₳₹ ₹₰₵₴

₀ ₲₰₥₹₹₱ ₴₲₰₤₹₱₹ ₴₴₴₴

$Y(1) \in [\underline{y}, \overline{y}]$ ...

$$E\{Y(1) \mid Z = 0\} \in [\underline{y}, \overline{y}].$$

... $E\{Y(1)\}$ ...

$$E\{Y \mid Z = 1\} \Pr(Z = 1) + \underline{y} \Pr(Z = 0),$$

...

$$E\{Y \mid Z = 1\} \Pr(Z = 1) + \overline{y} \Pr(Z = 0).$$

1

... $E\{Y(0)\}$ ...

$$\underline{y} \Pr(Z = 1) + E\{Y \mid Z = 0\} \Pr(Z = 0),$$

...

$$\overline{y} \Pr(Z = 1) + E\{Y \mid Z = 0\} \Pr(Z = 0).$$

... $\tau = E\{Y(1)\} - E\{Y(0)\}$ ...

$$E\{Y \mid Z = 1\} \Pr(Z = 1) + \underline{y} \Pr(Z = 0) - \overline{y} \Pr(Z = 1) - E\{Y \mid Z = 0\} \Pr(Z = 0),$$

...

$$E\{Y \mid Z = 1\} \Pr(Z = 1) + \overline{y} \Pr(Z = 0) - \underline{y} \Pr(Z = 1) - E\{Y \mid Z = 0\} \Pr(Z = 0).$$

... $\overline{y} - \underline{y}$ ... $[\underline{y} - \overline{y}, \overline{y} - \underline{y}]$ ... $2(\overline{y} - \underline{y})$ ...

... 0 ...

... Cochran (1953) ... Manski (1990) ... Manski (2003) ...

...

Manski ...

... $Y(1)$ ... X ... $\varepsilon_1(X) = 1$ ... $Y(1)$ ...

... $\varepsilon_1(X)$ ... $\varepsilon_1(X) = \varepsilon_1$ ... $\varepsilon_0(X) = \varepsilon_0$ ...

... $\mu_1(X) = E(Y \mid Z = 1, X)$ ... $\mu_0(X) = E(Y \mid Z = 0, X)$ ...

$$\varepsilon_1(X) = \frac{E\{Y(1) \mid Z = 1, X\}}{E\{Y(1) \mid Z = 0, X\}}, \quad \varepsilon_0(X) = \frac{E\{Y(0) \mid Z = 1, X\}}{E\{Y(0) \mid Z = 0, X\}}. \tag{86}$$

[1] ...

outcome regression)在已知 $\varepsilon_1(X)$ 和 $\varepsilon_0(X)$ 的条件下，我们有

$$E\{Y(1) \mid Z=0\} = E\left\{\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z=0\right\},$$
$$E\{Y(0) \mid Z=1\} = E\left\{\mu_0(X)\varepsilon_0(X) \mid Z=1\right\}.$$

因此，

$$\tau = E\left[ZY + (1-Z)\frac{\mu_1(X)}{\varepsilon_1(X)}\right] - E\left[Z\mu_0(X)\varepsilon_0(X) + (1-Z)Y\right] \tag{87}$$

$$= E\left[Z\mu_1(X) + (1-Z)\frac{\mu_1(X)}{\varepsilon_1(X)}\right] - E\left[Z\mu_0(X)\varepsilon_0(X) + (1-Z)\mu_0(X)\right]. \tag{88}$$

outcome regression

$$\hat{\tau}^{\text{pred}} = \left\{n^{-1}\sum_{i=1}^{n} Z_i Y_i + n^{-1}\sum_{i=1}^{n}(1-Z_i)\frac{\hat{\mu}_1(X_i)}{\varepsilon_1(X_i)}\right\} \tag{89}$$

$$- \left\{n^{-1}\sum_{i=1}^{n} Z_i \hat{\mu}_0(X_i)\varepsilon_0(X_i) + n^{-1}\sum_{i=1}^{n}(1-Z_i)Y_i\right\}. \tag{90}$$

(91)

$$\hat{\tau}^{\text{proj}} = \left\{n^{-1}\sum_{i=1}^{n} Z_i \hat{\mu}_1(X_i) + n^{-1}\sum_{i=1}^{n}(1-Z_i)\frac{\hat{\mu}_1(X_i)}{\varepsilon_1(X_i)}\right\} \tag{92}$$

$$- \left\{n^{-1}\sum_{i=1}^{n} Z_i \hat{\mu}_0(X_i)\varepsilon_0(X_i) + n^{-1}\sum_{i=1}^{n}(1-Z_i)\hat{\mu}_0(X_i)\right\}. \tag{93}$$

(94)

“predictive” “projective” Firth and Bennett, 1998; Ding and Li, 2018

IPW)在已知 $\varepsilon_1(X)$ 和 $\varepsilon_0(X)$ 的条件下，

$$E\{Y(1)\} = E\left\{w_1(X)\frac{Z}{e(X)}Y\right\}, \quad E\{Y(0)\} = E\left\{w_0(X)\frac{1-Z}{1-e(X)}Y\right\},$$

其中

$$w_1(X) = e(X) + \frac{1-e(X)}{\varepsilon_1(X)}, \quad w_0(X) = e(X)\varepsilon_0(X) + 1 - e(X). \tag{95}$$

??

... IPW ... $w_1(X)$ ... $w_0(X)$ ...
... $\varepsilon_1(X) = \varepsilon_0(X) = 1$ ... $w_1(X) = w_0(X) = 1$ ...
... IPW [3]
... Horvitz-Thompson ...

$$\hat{\tau}^{\text{ht}} = n^{-1} \sum_{i=1}^{n} \frac{\{\hat{e}(X_i)\varepsilon_1(X_i) + 1 - \hat{e}(X_i)\} Z_i Y_i}{\varepsilon_1(X_i)\hat{e}(X_i)} \tag{96}$$

$$- n^{-1} \sum_{i=1}^{n} \frac{\{\hat{e}(X_i)\varepsilon_0(X_i) + 1 - \hat{e}(X_i)\}(1 - Z_i) Y_i}{1 - \hat{e}(X_i)}, \tag{97}$$

(98)

... Hajek ...

$$\hat{\tau}^{\text{haj}} = \frac{\sum_{i=1}^{n} \frac{\{\hat{e}(X_i)\varepsilon_1(X_i)+1-\hat{e}(X_i)\} Z_i Y_i}{\varepsilon_1(X_i)\hat{e}(X_i)}}{\sum_{i=1}^{n} \frac{Z_i}{\hat{e}(X_i)}} \tag{99}$$

$$- \frac{\sum_{i=1}^{n} \frac{\{\hat{e}(X_i)\varepsilon_0(X_i)+1-\hat{e}(X_i)\}(1-Z_i) Y_i}{1-\hat{e}(X_i)}}{\sum_{i=1}^{n} \frac{1-Z_i}{1-\hat{e}(X_i)}}. \tag{100}$$

(101)

... outcome ...

$$\hat{\tau}^{\text{dr}} = \hat{\tau}^{\text{ht}} \tag{102}$$

$$- n^{-1} \sum_{i=1}^{n} \{Z_i - \hat{e}(X_i)\} \left\{ \frac{\hat{\mu}_1(X_i)}{\hat{e}(X_i)\varepsilon_1(X_i)} + \frac{\hat{\mu}_0(X_i)\varepsilon_0(X_i)}{1 - \hat{e}(X_i)} \right\}. \tag{103}$$

(104)

... $\varepsilon_1(X_i)$ ... $\varepsilon_0(X_i)$ ... [5] ... outcome ...
... $\hat{\tau}^{\text{dr}}$ ...
... $\varepsilon_1(X_i) = \varepsilon_0(X_i) = 1$ ... Part III ... predictive ... IPW ...

Xw ...

Xw q w ... ~ w R ...

```
OS_est_ta = function(z, y, x, out.family = gaussian,
                     truncps = c(0, 1), e1 = 1, e0 = 1) {
    # fitted propensity score
    pscore = glm(z ~ x, family = binomial)$fitted.values
    pscore = pmax(truncps[1], pmin(truncps[2], pscore))

    # fitted potential outcomes
    outcome1 = glm(y ~ x, weights = z,
                   family = out.family)$fitted.values
    outcome0 = glm(y ~ x, weights = (1 - z),
                   family = out.family)$fitted.values
```

[3] ... ??

```
    # outcome regression estimator
    ace.reg = mean(z*y) + mean((1-z)*outcome1/e1) -
              mean(z*outcome0*e0) - mean((1-z)*y)

    # IPW estimators
    w1 = pscore + (1-pscore)/e1
    w0 = pscore*e0 + (1-pscore)

    ace.ipw0 = mean(z*y*w1/pscore) - mean((1-z)*y*w0/(1-pscore))
    ace.ipw = mean(z*y*w1/pscore)/mean(z/pscore) -
              mean((1-z)*y*w0/(1-pscore))/mean((1-z)/(1-pscore))

    # doubly robust estimator
    aug = outcome1/pscore/e1 + outcome0*e0/(1-pscore)
    ace.dr = ace.ipw0 + mean((z-pscore)*aug)

    return(c(ace.reg, ace.ipw0, ace.ipw, ace.dr))
}
```

X w ‖ẅw P〉 ; j s g Q q 『w⁓{w{ļ NHANES ѡ ӧ ӧ ӣΩǫ̈H BMI ļ ‖ĿʊɆĖẄѡѡ

$$\varepsilon_1(X) = \varepsilon_0(X) \in \{1/2, 1/1.7, 1/1.5, 1/1.3, 1, 1.3, 1.5, 1.7, 2\},$$

ʊ١ kɥ ˇ ѡ ǯ ĮĿ
ʜ { {ѡΔĿʊɆẄ ♦ѡ

TABLE 1. ѡ´ ѡ ĮĿʊɆẄ ŝ ӣΩǫ̈H BMI ļ

ε	1/2	1/1.7	1/1.5	1/1.3	1	1.3	1.5	1.7	2
1/2	11.62	10.44	9.40	8.03	4.96	0.97	−1.69	−4.35	−8.34
1/1.7	9.22	8.05	7.00	5.64	2.57	−1.42	−4.08	−6.75	−10.74
1/1.5	7.63	6.45	5.41	4.05	0.97	−3.02	−5.68	−8.34	−12.33
1/1.3	6.03	4.86	3.81	2.45	−0.62	−4.61	−7.27	−9.94	−13.93
1	3.64	2.47	1.42	0.06	−3.01	−7.01	−9.67	−12.33	−16.32
1.3	1.80	0.63	−0.42	−1.78	−4.85	−8.85	−11.51	−14.17	−18.16
1.5	0.98	−0.19	−1.24	−2.60	−5.67	−9.66	−12.33	−14.99	−18.98
1.7	0.36	−0.82	−1.86	−3.23	−6.30	−10.29	−12.95	−15.61	−19.60
2	−0.35	−1.52	−2.57	−3.93	−7.00	−10.99	−13.65	−16.32	−20.31

ĵ ↓ ŝ ʀ $\varepsilon_1(X) > 1$ ѡ $\varepsilon_0(X) > 1$ ѡ ĵ ĵ ĵ BMIĵ ´ ѡ
ĵ ѡ ĵ ĵ BMIŋ ĵ $\varepsilon_1(X) < 1$ ѡ $\varepsilon_0(X) < 1$ ĵ
ĵ ĵ { {

W ẅ ♦

Ⅴ ѡ´ ѡ ĮĿʊɆẄ. ǒ ѡ ŝ

(1) ⌠ ⌡ ⌠ ⌡ ⌠ ⌡

其中

$$\hat{\mu}_{\mathrm{T0}}^{\mathrm{dr}} = \hat{\mu}_{\mathrm{T0}}^{\mathrm{ht}} - n_1^{-1} \sum_{i=1}^{n} \varepsilon_0(X_i) \frac{\hat{e}(X_i) - Z_i}{1 - \hat{e}(X_i)} \hat{\mu}_0(X_i).$$

详见 *Lu and Ding (2023)*。

¯ ẉ┤ḍ

- § Manski ₦ᴱ╟Ł╝ₐ ₘ ώ g̃
- § ₙ₦Qₐ ˡ№ ╝ₓẅₙ₫ṭṚ
- § E-value ╝ᴊ□₁cŏ ₙ₦Ỳ Ł↺Ẹ̈Ẅ ╝ᵢⁱ
- § ῆΔỲ ṭṚ╝ɛ̈₳ₙ ╝ ◆
- { ᵽ § ˡᵘƀɛ̈ĕ ╝Ł↺Ẹ̈Ẅ

CHAPTER 19

~ p。 Q l B tj‘ js

q w

matching 11

omitted variable bias

Paul Rosenbaum 1987

sensitivity analysis

Rosenbaum

Rosenbaum

‖ w

‖ w ‖ w ~ p。 Q B ; ‘ j

Rosenbaum (1987b)

定义 19.1 (Rosenbaum 敏感性参数). 对于第 i 对中的两个单位，处理分配的 *odds* 比被一个有界常数 $\Gamma \geq 1$ 控制：

$$\frac{\pi_{i1}/\pi_{i0}}{(1-\pi_{i1})/(1-\pi_{i0})} \leq \Gamma, \quad i = 1, \ldots, n,$$

其中 $\pi_{i1} = \Pr\{Z_{i1} = 1 \mid \textit{pair } i\}$ 是配对 i 中处理组接受处理的概率。

- 若 $\Gamma = 1$ 则 $\pi_{i1} = \pi_{i0} = 1/2$，即回到 MPE

- ₣ $\Gamma > 1$ ɒðŋɪ⅄Ẅ□Ỏ¿Ⴙ⁝ □̈H ∫KŵðKŵÂĘ Γ Ⴝ
- Γ ᵖÕ ḦṪ Ⱡ ǥǰÕ ⅁Ⱡ ⅆ♦□ᵖ ᵃ⊔

ⅆᵉ ᵃÅỎ ⊔ⅆ **ᗐ** ⅁Ⱡ **ᗐ** { {∂ⅆŋɪ⅄Ẅ□Ⱡ odds ζ ⱡ₵ℚ₩ Ḧ⅄ Ⱡ

ḦṪ ɲɒỎ↘ ∂ⅆi xŸŵⱰⅆⱡⅆ□ ᵥwkⱡ₵ⱭẄ ↘ ɤxⱡ⅁ §§

□ ḦṪ Ⱡ↘ ᵥⱭ□Ỏŏ ↘Ᵽ Ⱡ odds ζⱭ∂ ⅆ Γŏ ⅁Ⱡ p ℚᵥᵉ⊔

Ⱡ

∼w ℚ⊔Ɒ s

∼w q ŵw w sharp null hypothesis H_{0F} ŏ ⅁Ɏⅆʉⱡ⅁ŋɪ⅄ ⊔Ⱡ ”

” ᵥ□ ⅅ Ⱥ ŏ ⅁↘ ↘ Fisher randomization test ⅈⱭⱡ⌐ ℚ⊔

L q_i ᵖ i Ḧⱡ⅁ ŋɪ⅄ ⱭⱮ ŏw‖Ⱡ choices i↘ŝ

(1) **、 a Z l 。 —ŝ; q_i —a Z_{i1} —a Z_{i0} J** ŋ□Ḧ ŋɪ⅄ vs Ḧ Ⱡ ᵥŋⱭ□Ỏ

(2) **r ; a 。 — ; —ŝa q_i —Ɏa $_1$ J** Y_{i0}ŋⱰⅈⱭⱡ⅁ŋɪ⅄ Ḧ ♦ⱰⱭỎ

(3) **〔a g J p〉 p l 。 a Z l Q N ⊥$\hat{s}_1$; l |ⱮⱮ$_{i1}$。— $_{i0}$; ⅆ□ⱭⱮ a 。 — a J**

⌐ ℚ⌐ ŝ

$$T = \sum_{i=1}^{n} S_i q_i,$$

ʃ $S_i \in \{0, 1\}$ ᵥ□Ḧ i Ⱡŋɪ⅄ ᵥŋ $S_i = 1$ ʁᵥÔḦŸ ⌐ⅆÕ q_i ᵥ□Ḧ i Ⱡ□Ḧ ᵥ⌟

Ḥ Ⱡ ⅇⱭ₂ŵ⌐ ŏ S_i ⅂ⅆⅈ ᵥ□ Ⱡŋ⁵⅂:ⅇⅆᵥⅆÕ ⅅ⅁Ẅ

Ⱳ∑ ŏ S_i Ⱡ⅁ẄÄⱰⱮ { {ᵥ□

∼w ‖ᵇᵥẄẄ w

⌝⅄ **q mw(ᵥⅆq** p)**w**在 { {下，零假设 H_{0F} 成立时，配对 i 的处理指示 S_i 服从最坏情况的 *Bernoulli* 分布：

$$S_i \sim Bernoulli\left(\frac{\Gamma}{1+\Gamma}\right),$$

且各配对的 S_i 之间相互独立。

ⅆᵉ□ ℚᵥⱰ⅂ ⅄ⁿ odds ratio ⅆⱮ Γŏ S_i Ⱡ⅁ζ⅂ $[\pi_{\min}, \pi_{\max}]$ ∫Kŵŏ

ʃ

$$\pi_{\max} = \frac{\Gamma}{1+\Gamma}, \quad \pi_{\min} = \frac{1}{1+\Gamma}.$$

ΔⱰⱮ ᵖⱡ p ŋⅆ ăⅅ ⅁⁻Ⱬⅆⅆ⅄ⱰẄŏⅅ⅁ S_i Ⱡ⅁ $\pi_{\max}$ Ḧ

ŋɪ⅄ ” ⅄ⅈ ” Ⱡ⅁ⁿ ẄÄ

{ {ⅆʜɹⅆŏ ⅆᵥ ⅆ { {ẄÄ ŏ { {ᵐΔ ⅆᵥⱡ p ^{1}

∼w∼w⅁ℚᵥ s w$_1$ { ŏ{⅁↘ ℚᵥ ℚᵥⱰ⅂ p Ḧ ⅄⁻ Ⱡ⅁Ẅ⌐ ℚ⊔

T^{obs}ŏᵥẅẅ p ŝ

$$\mathrm{p}_\Gamma = \Pr_\Gamma\left(|T - T^{\text{obs}}| \geq |T^{\text{obs}}|\right),$$

ʃ T ăᴶ { { S_i ⅂ⅆⅈẄÄ

---

^{1}⌟ ?? Ⱡ ⅆ‖Ôh ??

权 $q_i \geq 0$ 表示 第 i 个 单元 的 重要 程度。

$$T = \sum_{i=1}^{n} S_i q_i, \quad S_i \sim \text{Bernoulli}\left(\frac{\Gamma}{1+\Gamma}\right).$$

q_i 为 第 i 个 单元 的 权 T 为 加权 检验 统计量 n 为 单元 数 Bernoulli 为 伯努利 分布

实现 与 结果

实现 与 结果 我们 对 LaLonde (1986) 数据 进行 分析 该 数据 来自 National Supported Work Demonstration 项目

```
# 加载 数据
data(lalonde)
# 处理 协变量
```

$$T = \sum_{i=1}^{n} S_i |\hat{\tau}_i|,$$

其中 $\hat{\tau}_i$ 为 第 i 个 单元 的 处理 效应 估计 值

- 首先 MPE 给出 $\Gamma = 1$ 时 的 p 值 为 0.002 这 表明 在 无 隐藏 偏差 假设 下 处理 效应 显著
- 其次 $\Gamma = 1.1$ 时 p 值 为 0.011 这 意味着 即使 存在 10% 的 隐藏 偏差 结论 仍 稳健
- 最后 $\Gamma = 1.3$ 时 p 值 为 0.05 左右 这 表明 结论 对 隐藏 偏差 的 敏感 程度 较 低

敏感 分析 显示 $\Gamma = 1.233$ 时 p 值 恰好 为 0.05 这 意味着 隐藏 偏差 至少 为 1.233 倍 才 能 使 结论 不再 显著

图 19.1 (LaLonde 数据 的 敏感 分析). 图 展示了 p 值随 Γ 变化的灵敏度曲线。曲线的陡峭程度告诉我们结论对未测量混杂的敏感程度——曲线越平缓，结论越稳健。

实现 细节 我们 使用 Rosenbaum 包 中 的 `sensitivity2x2` 函数 `sensitivitymv` 函数 用于 匹配 数据 的 敏感 分析

```
# 计算 敏感 分析
# 输出 各 Γ 值 下 的 p 值 上界
```

```
# 绘制 敏感 分析 曲线
# 横轴 为 Γ 纵轴 为 p 值 上界
```

习题

19.1. *Rosenbaum* 灵敏度模型的基本性质 证明：当 $\Gamma \to \infty$ 时，模型中的约束变得无效，此时 S_i 的最坏情况分布趋近于 *Bernoulli*(1/2)。这对应着什么实际含义？

19.2. 最坏情况 p 值的单调性 设 T^{obs} 为观测到的检验统计量。证明：最坏情况 p 值 p_Γ 是 Γ 的单调递增函数。解释这在直觉上意味着什么。

19.3. *Sign statistic* 的灵敏度分析 对于 *sign statistic* $q_i = 1$（所有配对权重相等），推导 T 在 下的分布，并给出 p 值的显式计算公式。

19.4. *LaLonde* 数据的计算 使用 *LaLonde* 数据集，计算在不同 Γ 值$(1, 1.1, 1.2, 1.3, 1.5)$下的最坏情况 p 值，并绘制灵敏度曲线。

˅ ẘẘ ♦

Ŵ Ł∂Δ Rosenbaum ïtAŷŁЭĘẄ ẂΣŏ ŷŵŗ‹ŧ‾Ÿŝŵ ŵ ŝŝŷ
ŷĦ ţṘ

ℚ ⅈ ŝ

(1) { {ά odds ratio ₥Ł Γ ≥ 1 ı ŵΔ ŝŝŷ ŷĝĘ
(2) Γ = 1 Ḧ Ḥ ŧ‾ẃ Ş₩ Γ > 1 ₥ŏŋŗЛẂ‾Ō∂ζ ‾Ḧ ∫ŀŧă ŗ
(3) { {ŋΔŰŰ∂ẃ S_i ŷ ℚẃѵŴẄÅŏ ẃŵ ѻ٩ ℚẃḥ∂ẃŷ p
(4) Ł∪ĘẄ ăẁ ” ѓ ” ѡ e ŌŊẏẃ ѡ♦ ℚ ŝŝŷ ĝĘ
ẃ‹ẃ ĩ

ă̊ẃ e ŝ Rosenbaum (1987b) ŷĖ ẃ‹ŸŝŴ ẂŁ∪ĘẄ. ŷ ∪ ᴮĬŏ
ẂΣθ ŵ₩ĕĕ̃ ŷ ẂẃẃŌŏi٩ẂẁẁẂ ~℮ ķẂŵ‾ŧ‾ŗ Rosenbaum ŷ
(2002, 2010) ų̇Ô Δ ѧ̈
ϟ₥ ♦ŷŭ ŝŸ ŷţṘ╝ṝ ᴅ 11 ŷŧ‾Ѧ̈ŗ̈1C ₥ŏ٩Ḧ┻Δᴅ 3
Fisher randomization test ŷѡ Ł∪ĘẄ ŷѡ ᴅ 12 ẃ ŗ'ŀΩŷ ” ŗ
” Ôζ Ī §§ŋ Ḍŭ ѡ♦ ѕ̈ ∂ẁ∂ѧ̈ŗ ŗ

CHAPTER 20

ɯ ɷɆ∀∑

q wŝʏ ŋ'Aɹ&Ɇlʝɹí

"If we could intervene on a unit and set its treatment, then we would know its potential outcome under that treatment. But what if the treatment is deterministic for some units? Can we still conceive their counterfactual outcomes?" — (, adapted from King and Zeng, 2006)

ώ ḡ ŏ ʊɤ ɹ"Ḧ ''Aɛv̈] ʅɻŝḦ V'Aβ ŏ ʊ ɟ:'Yb̈l
ʁ ** 'A ** ɷɆlʝ♦ώŏ∑Ĩ ḡ ** ƥ 'A ** ɷɆlʝ♦ώ Rubin lɹ♦ώ∀∑
ŋ Rubin, 1974, 1975Õ ɯ :ɕώΔ 'A 'Yl ” ɯ ɷɆ ”
ᴅ { { □ɕ kẄɹøŏʊ ʁΔ 'Aŭ ɾl ĵÆɯ ∂ɸi§§ ᶿ∂ɸ **p ” Q g ; s**
; ◦ ◦ ‘ j s$̄ŝ— a p l

$$0 < e(X) < 1. \tag{20.1}$$

'A∂ɸi#h V'Aβ Ḍ Ỏɾ♦ɯD ʁŏᴶN ʊÇ◗ β ă
ʁ lɹ♦ώ ɯÑŏ≠ $e(X) = 0$ ⁵ $e(X) = 1$ ɹøŏ,ɯKk̨ ɹøɲ ∨Ŝ,ɯώ 'Aβ
ˆ♦ɯʁŏʰ̣ᵉ □ɯ ” ɯώ♦ɯʁ ” ɯV lɹ♦ώ ζ̄
V̈ ‖ɕ,ɯ ⁺ɻõ↯Ł.ẓ 'A l¡ ^ṭ̄B§§ ‡ᴰg̈ⁱɸi©ŋ **~ Q _**
Z Q◦ ◦ a p l Ma◦ J pô l — a l ‘ a —》 L ~M

‖ wᶿ∂ɸi̇l̨ 'Ạ ζ

ᴅ { {.ʊ ʉŏᵖ kẄṭ̇R̈l ∨ ᶿ∂ɸi Ḳ { {N̈ŏ D'Amour ɾ
ɯŋ 2021Õ ɲΔ 'AL,ɯäḰl̨ ˚Ĩŝ

- ë$̄$ Ḳɯ ɹɯ♦Ɏl̟ḥ ∂ɸiŋ ignorability ô€♦ ŋ♦Ɏl̟ḥᴰ { { □l̨ M-bias$̄Õ
- ë$̄$ Ḳɯ ɹɯ ᶿ∂ɸi̇ë$̄$ä♦ ŏ ʁẄ̃K̈kɸ̈ë-♦ ƀl

'A ẗ̃ Ụ̣ɹ Ḳɯ qfi ɲ 'A ᶿ∂ɸi̇ ɾ♦ŝ

∂ɸi̇ 20.1 ('A θ). 存在某个 $\eta \in (0, 1/2)$ 使得

$$\eta \le e(X) \le 1 - \eta.$$

D'Amour ɾ,ɯŋ 2021Õ ɯΔ 'A ᶿ∂ɸi̇ Ḳɯ Ḛ p ˛ᴾɹ♦ˆ G$̄$ẗ̇l̨ 'Ạ
[1]

ˆ⌟ ‖ 𝕋**w**(D**q**Amour et al., 2021)**w**在 { {下，设 $e = \Pr(Z = 1)$ 为治疗组比例，λ_1 和 λ_0 分别为 $X|Z = 1$ 和 $X|Z = 0$ 条件下协变量矩阵的最大特征值。则

$$\frac{1}{p}\sum_{k=1}^{p}\left|\mathbb{E}(X_k \mid Z = 1) - \mathbb{E}(X_k \mid Z = 0)\right| \le p^{-1/2}C^{1/2}\left\{e\lambda_1^{1/2} + (1-e)\lambda_0^{1/2}\right\}, \tag{20.2}$$

[1] ᵽ‖Ôh ??

其中 $C = \dfrac{(e-\eta)(1-e-\eta)}{e^2(1-e)^2\eta(1-\eta)}$ 是仅依赖于 (e,η) 的正常数。

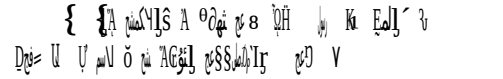

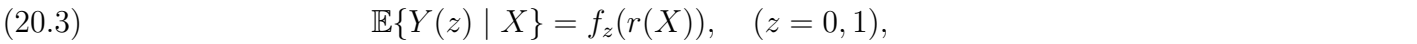

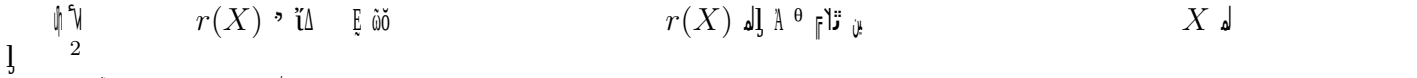

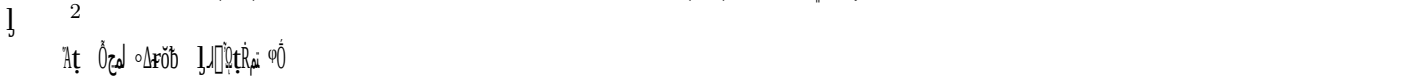

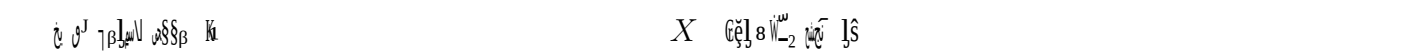

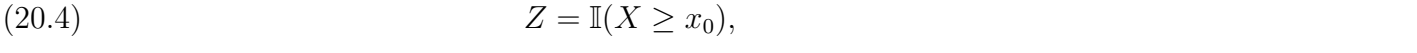

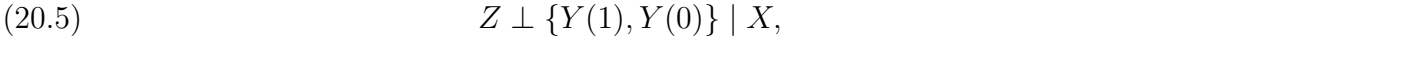

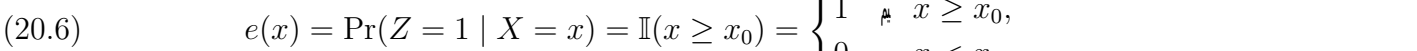

(20.3) $$\mathbb{E}\{Y(z) \mid X\} = f_z(r(X)), \quad (z=0,1),$$

(20.4) $$Z = \mathbb{I}(X \geq x_0),$$

(20.5) $$Z \perp \{Y(1), Y(0)\} \mid X,$$

(20.6) $$e(x) = \Pr(Z=1 \mid X=x) = \mathbb{I}(x \geq x_0) = \begin{cases} 1 & \text{若} \ x \geq x_0, \\ 0 & \text{若} \ x < x_0. \end{cases}$$

[2]

X w q w ȷ↷ă M **wă ‖ ⟦ȷwᵛq** ō Thistlethwaite ẓ Campbell ȷ 1960ō
ₓᴱ ∩Δ‡ẓg⁞Ẇ ȷ Ṙ ₦ȷgẓȷ₈₂ ẉŝ ₓ⁴ķ ” ₓ ” ḦƵŤ∖
ẑȷ̈́ȷ ₓẉẉÁ⁴ķȷ̂ ₓȷ ” ₜ Ķ ⅄ ₦ ” ₔ ₔẉÂ ȷ̈́ẓg̈A

ă ‖ ⟦ȷwḦIV ₈ₚ₂ō Bor ȷŋ 2014ōă ‡ẓg̈⁞ ẇ HIV ẓẹ ₚ ₓ∩⁞
ḥɥḌ ₈Ḧₓ ɛ∃ ₈ₚ̂ ∃ CD4 ẓₓẉẉÁẓ 200 cells/μL

ă ‖ ⟦ȷwẓ ⊐ḉᵖō Carpenter ẓ Dobkin ȷ 2009ō ẇΔ⊐: ẁḦₓ ɛ∃
ŏă Ṙ ẓ ⊐ḉᵖ ⊐: ẁ∃g̈⁞

X w ‖ w ȷₚ~ₕ M **wᵛ ₈∃Ķ** X ₓ Ķ ŋ **‘ l l a l Z ”**ō **; ⋎ a ; B g Q**
ₐb̈ŏ‡ẓg̈⁞⋎ ₐ∩ẓg̈⁞ x_0 ı∃ɀₓₐ´ ẁ Ŝ

$$\tau(x_0) = \mathbb{E}\{Y(1) - Y(0) \mid X = x_0\}. \tag{20.7}$$

ˉ⌋ ‖ ⟦wRD ₐ∩⌋)**w**假设治疗由 $Z = \mathbb{I}(X \geq x_0)$ 确定，其中 x_0 是预设阈值。假设 $\mathbb{E}\{Y(1) \mid X = x\}$ 在 x_0 处右连续，$\mathbb{E}\{Y(0) \mid X = x\}$ 在 x_0 处左连续。则在 $X = x_0$ 处的局部平均因果效应由下式识别：

$$\tau(x_0) = \lim_{\varepsilon \to 0^+} \mathbb{E}(Y \mid Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \to 0^+} \mathbb{E}(Y \mid Z = 0, X = x_0 - \varepsilon). \tag{20.8}$$

{ ⟦ ẽ⁞Wₐₐₕ⋎ẎẓŰ ŏḦₐₐ $\tau(x_0)$ ẉẉẄₐₐ⋎ₐ∩ẓg̈ [3]

X w ⊐ẓ⁞ẉ ẓ⁞ẉ **w**∩ₐ $\mathbb{E}(Y \mid Z = 1, X = x) = \gamma_1 + \beta_1 x$ ẓ $\mathbb{E}(Y \mid Z = 0, X = x) = \gamma_0 + \beta_0 x$ ŭ x ₚ⋎ ⅄Ω x_0 ı∃ₓ´ ẁ

$$\hat{\tau}(x_0) = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0) x_0. \tag{20.9}$$

ₓ ₐb̈ŏ $\hat{\tau}(x_0)$ OLS ‡Ω

$$Y_i \sim \{1, Z_i, X_i - x_0, Z_i(X_i - x_0)\} \tag{20.10}$$

Z_i ȷ ₓ [4]
ₐẄŏ ţṘḦ ß ∂ẉẓȷ ₓ⋎ı⊐ₚ∂ ⌋⌋ Wₐ ẓ⁞Ô≥ȷ∃ẓ∀
Ḃⅼ ⋎ ‡Ω rdrobust i₈ ΔÀ ” ɀ ” ⋎₩ ŏ Ṽ ₐb̈ₐ ₚ∂ Ẁ

X w X w ȷ~ M **w**RD Ẁ ⋎ı⊐ₐ₩ₚ ⅂ₐₐₐb̈ŭ∓ ⁀ẓ⁞Ô≥ȷ∀

ᴮ ŏ ⟦ ⟦ū ∓⋎ı⊐ ₚ⊣ θ ₓ ă₩b̈ₚb̈ₐₐₐ ɀ 21 ₚₐ ŏ ₚ
⋎ı⊐ Ṙ╟ ⟦ ⟦ȷₐₐ ℤ ẓ ⊐ḉᵖ∃K⊜
McCrary ŋ 2008ō ∩Δ ⅄∫•ȷ ⌐ ŝ-x Ķ ẓ⁞ı⌋ƵẸ
Ķ ƵẸ ẓ⁞ı⌋ăŭ ⋎ı⊐ʜ∂ẉ β ƶ∀ ∧ɯȳ∀Ƽ ₈

W ẅ ♦

⋮ Δ ᶿ∂ẉẍ ⅂ȷ ẋ ẓẅḧŝ
(1) ᶿ∂ẉẓȷ⊣ₚ ŝỰ Ķ ŏ ⅄ ᶿₚ ⅄Gẓ⁞ȷ ẉŏ⌋ḳ∀ ẉ ₈
ℤḦ ₐẉ Ẹₐb̈ₘ⌋
(2) ♦ẋ⁞ Ƽ ŝ ᶿ ₚₐŏ ∀ ᵛẽ ᶿƀ‰ôKɅḤ Ş♦ẋ⁞

[3] ∂‖Ôḥ ??
[4] ᵦₓ ᵽ‖Ôḥ ??

(3) [illegible] RD [illegible]

RD [illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible] [illegible] $\Sigma_1 = \mathrm{Cov}(X \mid Z = 1)$ [illegible] $\Sigma_0 = \mathrm{Cov}(X \mid Z = 0)$ [illegible]

$$\Sigma = \mathbb{E}\{\mathrm{Cov}(X \mid Z)\} + \mathrm{Cov}\{\mathbb{E}(X \mid Z)\}. \tag{20.11}$$

[illegible] Σ_1 [illegible] Σ_0 [illegible] C [illegible] Cauchy-Schwarz [illegible]

$$\frac{1}{p}\sum_{k=1}^{p} |\mathbb{E}(X_k \mid Z = 1) - \mathbb{E}(X_k \mid Z = 0)| \leq \frac{1}{\sqrt{p}} \|\Sigma^{1/2}\| \cdot \|d\|, \tag{20.12}$$

[illegible] $d = \mathbb{E}(X \mid Z = 1) - \mathbb{E}(X \mid Z = 0)$ [illegible] $\|\cdot\|$ [illegible] □

[illegible] [illegible] $\tau = \mathbb{E}\{Y(1) - Y(0)\}$ [illegible]

$$\tau = \mathbb{E}\big\{\mathbb{E}(Y \mid Z = 1, r(X)) - \mathbb{E}(Y \mid Z = 0, r(X))\big\} \tag{20.13}$$

[illegible]

$$\tau = \mathbb{E}\left\{\frac{ZY}{e(r(X))}\right\} - \mathbb{E}\left\{\frac{(1-Z)Y}{1-e(r(X))}\right\}, \tag{20.14}$$

[illegible] $e(r(X)) = \Pr\{Z = 1 \mid r(X)\}$ [6]

[illegible] [illegible]

$$\mathbb{E}\{Y(1) \mid X = x_0\} = \lim_{\varepsilon \to 0^+} \mathbb{E}\{Y(1) \mid X = x_0 + \varepsilon\}. \tag{20.15}$$

Z [illegible] $X = x_0 + \varepsilon$ [illegible] $Z = 1$ [illegible]

$$\mathbb{E}\{Y(1) \mid X = x_0 + \varepsilon\} = \mathbb{E}(Y \mid Z = 1, X = x_0 + \varepsilon). \tag{20.16}$$

---

[5] [illegible] D'Amour et al. (2021, Corollary 1)

[6] [illegible] $r(X)$ [illegible]

$\mathbb{E}\{Y(0) \mid X = x_0\}$ $\square$

$R_i = \max(X_i - x_0, 0)$ $L_i = \min(X_i - x_0, 0)$

$$Z_i(X_i - x_0) = Z_i R_i - (1 - Z_i)L_i = R_i - L_i - (1 - Z_i)R_i + (1 - Z_i)L_i. \tag{20.17}$$

$Y_i \sim \{1, Z_i, X_i - x_0, Z_i(X_i - x_0)\}$ Z_i

$$\hat{\tau} = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)x_0. \tag{20.18}$$

$Y_i \sim \{1, Z_i, R_i, L_i\}.$ $\square$

CHAPTER 21

ŤĖŇĶı ŜĴă Λ٫ʉ ʉ ȯ

q wŝ ŔȡǷ ŤʍŏȢ ŗ ʍ Ţ

ɹȴ ŏ ȣ ΔȺĹǪ ǫ٫ʉ₂ʉ ǪǪŸĿ ʊȷ ŸŤĮ ȡǷ ĜĽŤǪ

ȯ ɒ { {ļ ȼ٫ʉ₂ʉ ŋ CREÔ ǫ٫ʉ₂Ẅ_ʁ ɐƶΔ ƀĘ ɒ { {

ĴΔɾʁ Ẅ_₂ ŋ⁵ŸŤǪÔȷʍŏȺĹǪ ŸĿĺ ʊ̈ ʍǪǪ ȯ

ƀ ٫ʉ ă ᶜ ʊ̈ qfiŝ

(1) **b p B**ſ。 ŝʊ̈ ɯŤ Jobs ɟŦĤ٫ʉɯļ ƀŏ ɐẄʍȢẄ_ʁ treatment

ļ٫ʉ٫ʉ٫ʉ½Ẅ-Δ ɟ

(2) ẋʁ٫ʉ ŝ ʍ٫ʉ₂Ẅ_ʁ ʁ ⁵Ĥ ŏƀ Ê ŏɐẄ ɟ

ɹẄ_ļ ʁ

(3) **i Q l NQ g a ; l ~ ; l N**ɴ**p j**ŤĖŇĶ**a**Ô٫ʉ₂Ẅ_ɯ٫ʉ ƀ– **a p l**

ʁK Ĥɟɟqļ ŸĿ ǫĶ ʞ٫ʉ

qfi ŏʁẄ_ *Z* ٫ʉ½•٫ʉļʁ *D* ă ĕɛẺĵ ɯŝ *D* ٫ʉ

♦ȯ ʃŸĿᵉ ƀŢ ŋ **‘ l j Q ; 。 ‘ QN J p**ô**l**ʁ**V**ɣ**p**ȯ ŔĂɱ **l N a l Z**

ȯ ļ ȼĮǪ

ʰ ƀ̃ŏ꜀ ŔȡǷ٫ʉŸĿʰ ɹʍŏ ȣ ŗ٫ʉǪ ȯ ȼŢ

ŤĖŇĶ ŋ **` l 。— ‘ j Q l — ; g ‟ ;**ţŔ ŋΔ **a**ɯq **; B g Q L ` “** ¹ Ɋ ʍ ɯŝ ʉ

ʹA ɯŋ **Q〉 p Z Q**ô**l** ɟ**p ‘** 。 *Z*ŏ٫ʉ ʁ *D*ŏƀă ♦ʁ *Y* ŋɐƶΔ ǫ̇ *D* ļ

ʞǪ̃٫ʉ ȣ Ŕ ♦ŸƋ *D* ļ ȯ ŏƀŸ ǫ̇ *Z* ȷ ʃȣ g̃

Ṽ ɜ̈ ʹIƋ̃٫ʉǪŋ **Q l J p ‘ ; Z Q j Q**ô**l**ɯ**↦**ʉ٫ʉ**N Q**。 **a**ŁZ **l**ŔĖ ɯ { ‖ ļǰ

ŸĿĺ ʊ̈ļ٫ʉǪ Ôʍ ₱ŝ “如果我无法做随机实验，能否找到一个自然的随机化来源？”ʹIƋ̃٫ʉǪ ɯ ʍ ļ

‖ wŵ٫ʉǪ ų ʲ

ʷ ů ʹA٫ʉ ǒƓ ʊ̈ ʹIƋ̃ŋ **Q l J p ‘** Ô ɐẄ٫ʉ ♦**Z**ʁ**Q**ʍ٫ʉ٫ʉ ɵʹIƋ̃

ļʁ Ḍ٫ʉ٫ʉ½•٫ʉʁ٫ʉ ɯ٫ʉ

- $Z \in \{0,1\}$ŝʁẄ_ŋ $Z = 1$ ʜ٫ʉɵẄ_ʁ Ô
- $D \in \{0,1,2,\ldots\}$ŝ٫ʉ٫ʉ½•٫ʉļʁŋ⁵٪ Ô
- Yŝ♦ʁ

Ḥ ٫ʉ₂٫ʉ ă ŏ ᵛe ų ʲ ŋ **l p l J p j s g**ŝ**a**ɯ٫ʉ٫ʉ ļ**l J Q**

ƶʇ ɯ٫ʉ½•٫ʉʁ ŏɵẄ_ʁĤ ļ٫ʉ٫ʉ½ŸŤ ǫ̇٫ʉ٫ʉ ʞ٫ʉ•٫ʉʁΔ ʁ

ŭ ꜀ʃǪ̃ŝ٫ʉ₂Ẅ_ŋ **: 。 。 ‘ j s — a p l ‖ q w q**

ƌ٫ʉ 21.1 (٫ʉ₂Ẅ_). 治疗分配 Z 与所有潜在结果独立：

$$Z \perp\!\!\!\perp \{D(1), D(0), Y(1), Y(0)\},$$

[1] ŝ ɯ ʹĖŇĶ ɹ ˆ ŔȡǷŸĿʰ ļ Ţ‖Ôh ??

[2] ŝ ɯ ʃ٫ʉ₂Ẅ_ɯŭ ꜀ʃǪ̃ŝ٫ʉ٫ʉǪŋ ȣţ‖Ôh ??

其中 $D(z)$ 是在分配 z 下的潜在治疗接受情况，$Y(z)$ 是相应的潜在结局。

$$\hat{\tau}_Y = \bar{Y}_1 - \bar{Y}_0$$

$$\hat{\tau}_D = \bar{D}_1 - \bar{D}_0$$

$$\hat{\tau}_{\mathrm{IV}} = \frac{\bar{Y}_1 - \bar{Y}_0}{\bar{D}_1 - \bar{D}_0}$$

$$\tau_Y = \mathbb{E}\{Y(1) - Y(0)\}$$

$$= \mathbb{E}\{Y(1) - Y(0) \mid U = a\}\Pr(U = a) + \mathbb{E}\{Y(1) - Y(0) \mid U = c\}\Pr(U = c) + \mathbb{E}\{Y(1) - Y(0) \mid U = d\}\Pr(U = d) + \mathbb{E}\{Y(1) - Y(0) \mid U = n\}\Pr(U = n).$$

单调性假设（Monotonicity）

定义 21.2（单调性）. 没有 *defier*：$\Pr(U_i = d) = 0$，或者等价地，$D_i(1) \geq D_i(0)$ 对所有 i 成立。

单调性假设的含义是：当工具变量 Z 从 0 变为 1 时，没有人会从接受处理变为拒绝处理。换句话说，Z 的变化只会让一些人更倾向于接受处理，而不会让任何人更倾向于拒绝处理。

在潜在结果框架下，单调性可以写成

$$\Pr(D = 1 \mid Z = 1) \geq \Pr(D = 1 \mid Z = 0), \tag{110}$$

即 Z 对 D 的边际效应非负。这一条件在许多自然实验中是合理的：例如，抽签入伍时，抽到低号码的人入伍概率高于抽到高号码的人，但不会有人因为抽到低号码反而不入伍。

单调性等价于对每个个体 i 都有 $D_i(1) \geq D_i(0)$。

排他性与单调性下的 LATE

命题 21.3（对 *always taker* 和 *never taker*，治疗分配不影响结局）. 若 Z 满足排他性，则对 always taker 和 never taker，$Y_i(1) = Y_i(0)$。

证明：always taker 满足 $D_i(1) = D_i(0) = 1$，never taker 满足 $D_i(1) = D_i(0) = 0$。对这两类人，Z 不改变处理状态，因此排他性蕴含 $Y_i(1) = Y_i(0)$。

定义 21.4（complier）. 满足 $D_i(1) = 1$ 且 $D_i(0) = 0$ 的个体称为 complier。

定理 21.5（LATE）. 在单调性与排他性假设下，

$$\tau_{\text{LATE}} = \frac{\mathbb{E}[Y \mid Z = 1] - \mathbb{E}[Y \mid Z = 0]}{\mathbb{E}[D \mid Z = 1] - \mathbb{E}[D \mid Z = 0]} = \mathbb{E}[Y(1) - Y(0) \mid U = c].$$

证明

记 always taker 的比例为 π_a，never taker 的比例为 π_n，complier 的比例为 π_c。由单调性，$\pi_a + \pi_n + \pi_c = 1$。

分子为

$$\mathbb{E}[Y \mid Z = 1] - \mathbb{E}[Y \mid Z = 0] = \pi_c \, \mathbb{E}[Y(1) - Y(0) \mid U = c],$$

因为 always taker 与 never taker 的结果不随 Z 变化。

分母为

$$\mathbb{E}[D \mid Z = 1] - \mathbb{E}[D \mid Z = 0] = \pi_c.$$

两式相除即得 LATE。

解释

LATE 只识别 complier 的平均处理效应，不识别 always taker 或 never taker 的效应。这是工具变量方法的本质局限：我们利用的变异来自 Z 的外生变化，而 Z 的变化只影响 complier 的处理状态。

在抽签入伍的例子中，LATE 是“因抽签而入伍”的人的平均效应，而不是全体士兵的平均效应。

---

[1] 单调性假设最早由 Imbens 与 Angrist 在 1994 年的 *Econometrica* 论文中提出。

...

$$\tau_c \overset{def}{=} \mathbb{E}\{Y(1) - Y(0) \mid U = c\} = \frac{\tau_Y}{\tau_D}. \tag{113}$$

...

$$\tau_c = \frac{\mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0)}{\mathbb{E}(D \mid Z = 1) - \mathbb{E}(D \mid Z = 0)}. \tag{114}$$

...

...

...

一、问题设定与 CACE 的定义

$$\tau_c(x) = \frac{\mathbb{E}(Y \mid Z=1, X=x) - \mathbb{E}(Y \mid Z=0, X=x)}{\mathbb{E}(D \mid Z=1, X=x) - \mathbb{E}(D \mid Z=0, X=x)}. \tag{116}$$

其中 X 为协变量。CACE 是 CRE 中对 $X=x$ 这一子总体定义的 IV 估计量。

二、可忽略性假设

假设 21.3（条件可忽略性） 存在协变量 X，使得

$$Z \perp\!\!\!\perp \{D(1), D(0), Y(1), Y(0)\} \mid X,$$

即在给定 X 后，Z 与潜在结局及潜在处理状态联合独立。

三、样本估计量

四、渐近性质

五、弱工具问题

六、与 FAR 检验的关系

七、Angrist 记号下的 CACE

定义 21.4（Angrist 记号）. $Y_i(z,d) = Y_i(d)$ 对所有 i, z, d 成立，即潜在结局只是 d 的函数。

---

[8] 当 $\hat{\tau}_D$ 接近 0 时，??

[9] 在 FAR 检验中，??

notation 下 Z 与 Y 之间的总效应为

$$\tau_c = \frac{\mathbb{E}\{Y(D(1)) - Y(D(0))\}}{\mathbb{E}\{D(1) - D(0)\}},$$

即 CACE 等于 Z 对 Y 的效应除以 Z 对 D 的效应。

这个比值的分子是 Z 对 Y 的效应，分母是 Z 对 D 的效应。直观上，分母衡量 Z 改变治疗状态的比例，分子衡量 Z 通过治疗状态对结果产生的间接影响。比值把这两者相除，得到的就是 Z 改变治疗状态的那些人（complier）的平均因果效应。

21.1. **CACE 的“被 Z 影响而改变治疗状态”的人：**因为它是总体中一个特定子群体（*complier*）的平均因果效应。这个子群体恰好是那些“被 Z 影响而改变治疗状态”的人。不同的工具变量可能识别不同的子群体。

本章小结

21.1. *Wald* 估计量的方差 证明 *Wald* 估计量 $\hat{\tau}_c = \hat{\tau}_Y / \hat{\tau}_D$ 的渐近方差为 $\hat{V}_Y / \tau_D^2$，其中 $\hat{V}_Y$ 是 *ITT* 估计量 $\hat{\tau}_Y$ 的方差。

21.2. 强单调性下的 *IV* 估计 在强单调性（所有人都是 *complier* 或 *never taker*，且 $\Pr(U = n) = 0$）下，证明 *IV* 估计量 $\hat{\tau}_c$ 的一致性。

21.3. 单侧非依从性 在单侧非依从性（*never taker* 存在，但没有 *always taker*，且 $D_i(0) = 0$ 对所有人成立）下，推导 *CACE* 的识别公式，并解释其含义。

21.4. 违反排除限制的后果 假设排除限制不成立，即存在 *always taker* 使得 $Y_i(1) \neq Y_i(0)$。证明此时估计量是有偏的，并讨论偏误的方向。

CHAPTER 22

J 8 W

q w S J 2 u H u E

r h o g Q i 2 u l g 8 W _ t ~ u N o u E l
u r ' A F > l g S J n **J p j s g a ; l J Q**
' g 8 b W i f | u 2 W _ H 8 5 H o b Y
~ e ă o Y ~ o H Y ~ ¿ ¢ K u 4 k Δ Ô
" W _ u ½ 8 ă Å " l g o ² u J l g Q
u b Q r ' u { u n l g S

"The essential problem of causal inference is that we can observe at most one of the potential outcomes for any unit."

J l ˘ o Q Δ Ê ´ l g Ą S g ă W R ρ Y d ' A l g
8 ' Q H ♦ ù o Y ~ R W Ô ' A u ½ ♦ b l g 8
V l g Q S ¥ 8 W _ u ½ 8 ă ρ o g ρ Q I Q 8 ù Ţ
Q ˜ u g ś o J u ¤ Q ¤ ♦ L ₂ Ę ¢ K u ţ R { l g ∪ Ę o g Ľ θ { Q { Ô ↔ ♦
ù M ∑ V u g ś o J u ¤ Q ¤ ♦ L ₂ Ę ¢ K u ţ R

‖ w W Q J

‖ w q ¢ W e ù W ă ù Ą i Ą n Ą β l g 2 u e ù ρ ♣ S

- $Z_i \in \{0,1\}$ S 8 W _ ŋ 1 = 8 o 0 = H Ô
- $D_i \in \{0,1\}$ S u ½ ♦ b l g 8 ŋ 1 = ♦ b 8 o 0 = ♦ b 8 Ô
- Y_i S ŭ l g ♦ ù

¥ e ğ β ♭ $Z_i \neq D_i$ ρ o J ŋ **l p l J p j s g a ; l J Q g n Δ s p B g Q j**
m V ¤ u ¢ k ∩ u ½ θ ♦ b l g u w ‖ § § u ∩ Ą Ą g ö ø ♦ b 8 o ğ ~
' l ă " ♦ g
↔ ♦ ù e ù S V ' A β ρ Ą ↔ ♦ ù

$$\{D_i(1), D_i(0), Y_i(1), Y_i(0)\},$$

ς $D_i(z)$ u ¤ 8 W _ z ‰ ♦ b l g 8 o $Y_i(z)$ u ¤ 8 W _ z l g ♦ ù Y H S

$$D_i = Z_i D_i(1) + (1 - Z_i) D_i(0), \quad Y_i = Z_i Y_i(1) + (1 - Z_i) Y_i(0).$$

‖ w ♦ 2 ù Q g V Y u ½ 0 W o u ¤ ∂ ¢ 2 ù ¤ u ' l ŋ K u

∂ ¢ 22.1 (u 2 ù). 治疗分配 Z 与潜在结果独立：

$$Z \perp\!\!\!\perp \{D(1), D(0), Y(1), Y(0)\}.$$

u 2 ù u ½ 0 8 W _ H D Q Y l g ´ ù S [1]

$$\tau_D = \mathbb{E}\{D(1) - D(0)\} = \mathbb{E}(D \mid Z = 1) - \mathbb{E}(D \mid Z = 0),$$

[1] p ‖ O h ??

$$\tau_Y = \mathbb{E}\{Y(1) - Y(0)\} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0).$$

$\hat{\tau}_D$ $\hat{\tau}_Y$ τ_D τ_Y

a l — Q l — a p l _ — p _ — Q ; — L ; l ; g 》。 a。

ITT

$$\underbrace{\hat{\tau}_Y}_{\text{ITT}} \xrightarrow{p} \underbrace{\tau_Y}_{},$$

$$\underbrace{\tau_{\text{treatment}}}_{} \neq \underbrace{\tau_Y}_{} .$$

$\{D_i(1), D_i(0)\}$

22.1 ( ). 令 $U_i = \{D_i(1), D_i(0)\}$，则：

$$U_i = \begin{cases} a \ (always\ taker) \ , & \text{若} D_i(1) = 1 \text{ 且} D_i(0) = 1; \\ c \ (complier) \ , & \text{若} D_i(1) = 1 \text{ 且} D_i(0) = 0; \\ d \ (defier) \ , & \text{若} D_i(1) = 0 \text{ 且} D_i(0) = 1; \\ n \ (never\ taker) \ , & \text{若} D_i(1) = 0 \text{ 且} D_i(0) = 0. \end{cases}$$

- **: g 》 ; 》。**
- **k Q ” Q —**
- **I p j s g**
- **M Q 【 Q**

$D_i(1)$ $D_i(0)$ U_i

U τ_Y

[3]

$$\begin{aligned} \tau_Y = {} & \mathbb{E}\{Y(1) - Y(0) \mid U = \mathrm{a}\} \Pr(U = \mathrm{a}) \\ & + \mathbb{E}\{Y(1) - Y(0) \mid U = \mathrm{c}\} \Pr(U = \mathrm{c}) \\ & + \mathbb{E}\{Y(1) - Y(0) \mid U = \mathrm{d}\} \Pr(U = \mathrm{d}) \\ & + \mathbb{E}\{Y(1) - Y(0) \mid U = \mathrm{n}\} \Pr(U = \mathrm{n}). \end{aligned}$$

τ_Y

[2] ITT

[3] ??

ṙṿ τ_D ỵ̇Ẇ ŝ [4]

$$\begin{aligned}\tau_D &= \mathbb{E}\{D(1) - D(0) \mid U = \mathrm{a}\}\Pr(U = \mathrm{a}) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = \mathrm{c}\}\Pr(U = \mathrm{c}) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = \mathrm{d}\}\Pr(U = \mathrm{d}) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = \mathrm{n}\}\Pr(U = \mathrm{n}) \\ &= 0 \cdot \Pr(U = \mathrm{a}) + 1 \cdot \Pr(U = \mathrm{c}) + (-1) \cdot \Pr(U = \mathrm{d}) + 0 \cdot \Pr(U = \mathrm{n}) \\ &= \Pr(U = \mathrm{c}) - \Pr(U = \mathrm{d}).\end{aligned}$$

X w

ạḥṡẆ: нɡṡöẄ,ṡ YḂaɔƆ Ṙ τ_Y §§ ọ ṗ Aẇŋṗ A ỵ

ὼ Õḃ ŋA ṭ̣ ŋ τ_Y ỴḤ τ_D ỵ ΔṿÕΔv ä ọ Ṁ ỵ∂ḍ̇

X w q ŵ w

∂ḍ̇ 22.2 (β^{υ}). $\Pr(U = d) = 0$，或等价地，$D_i(1) \geq D_i(0)$ 对所有单元成立。即，
ă[e] ***defiers***。

Ỵ ṭ̃ β^{υ} ∂ḍ̇ $\beta\Gamma^{J}$ ŋ **p l Q _。 a N Q N l p l ĵ J p ṭ̃ỵ s g a ; l J Q**
ɾḦ ⊖ṁ Ṙ⁴ḳ ʁ ɹøŏ $D_i(0) = 0$ Ḧ ỵ β ˳ ṭ̃ṻṆ $D_i(1) \geq D_i(0)$ Ṙ ṭ̃
ϒ- ỵ̈Ạ ŝ ɹ₂ὼ ŏβ$^{\upsilon}$ ∂ḍ̇ ẗϒ- ỵ̈Ạ ŝ [5]

$$\Pr(D = 1 \mid Z = 1) \geq \Pr(D = 1 \mid Z = 0).$$

ŝ { { { { ỵ ∀ẗA ỵ $D_i(1)$ Ỵ $D_i(0)$ŏĬ ɯ´ ɾϒ
⌐ ỵ ă ṙ ṭ̃ɹøŏ ọ Ṙ ɯƆŠỤβ$^{\upsilon}$ ∂ḍ̇
β^{υ} ∂ḍ̇ ŏ { {ὼ ŝ

$$\tau_D = \Pr(U = \mathrm{c}) \equiv \pi_c.$$

compliers ỵ Ç ă̈ π_c ṛ ʁ ẆḦḳ ʁ ỵɯ´ ὼ §§ ṗ ẗA
ϒ ɯ ỵɹ

X w ṩḥ wḳ w

∂ḍ̇ 22.3 (ṩ). 对于 *always takers* ($U = a$) 和 *never takers* ($U = n$)，有 $Y_i(1) = Y_i(0)$。

ϒ J ŝṩ ṗ ʁ Ẇ ỵ ḳ ʁ ỵ ⊖ŏă ɾ ṗ ɹ₂Ḧ ⊖ ŏ ṗɯ ⊖ă̈ J ỵ§§ ⊖ ʁ ẆḦ ŏḰḳ
⊖ỵ ʁ ŏ ⊖ ă%ŏḰ ὼ
Ỵ ṭ̃ ⊖ ṩṪ ʁ Ẇ ὼ ỵ ɋ ŋṆ ɋ ḳ ỵ ʁ Ô
ă̈ ⊖ŏ ṭ̃ ⊖ ɋ ỵ ʁ ẆḦ ʁ ṆŏḰ
ṩ ∂ḍ̇ ŏ { {ỵ ỴĬ K Ŭŝ

$$\tau_Y = \mathbb{E}\{Y(1) - Y(0) \mid U = \mathrm{c}\}\Pr(U = \mathrm{c}).$$

ă { { { ŏ{ḳ ɯ ὼ

[4] ṗ ??
[5] ṗ ??

X w∼ W w

¯J ‖ ‖ w(C‖ACE/LATE l (w在 { { { { 和 { { 下，如果 $\tau_D \neq 0$，则

$$\mathbb{E}\{Y(1) - Y(0) \mid U = c\} = \frac{\tau_Y}{\tau_D}.$$

6

{ { A ŝ { { { { { { { { { τ_Y/τ_D compliers l w

A l Y w ŝ compliers§§ ” ” l

R l 8 Ḧ always takers~ never takers 5 defiers l w

W w W ¯q w w

¯ 22.3 (CACE 5 LATE). J w ŋ ***complier average causal effect, CACE*** 或 ***local average treatment effect, LATE*** 定义为：

$$\tau_c = \mathbb{E}\{Y(1) - Y(0) \mid U = c\}.$$

CACE g r ŝ

$$\tau_c = \mathbb{E}\{Y(1) - Y(0) \mid D(1) = 1, D(0) = 0\} = \mathbb{E}\{Y(1) - Y(0) \mid D(1) > D(0)\}.$$

1 { { { { ŝ

$$\tau_c = \frac{\tau_Y}{\tau_D}.$$

ď **I : I P ¨ f :** P w 8 w ζ

ζ w ŏv ä ŝ

$$\tau_c = \frac{\mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0)}{\mathbb{E}(D \mid Z = 1) - \mathbb{E}(D \mid Z = 0)}.$$

B ŏ ζ w ŏ ŋ l **I : I P** g

Y w 8 w ´ ζ

˅ W

˅ w q w g N w 1 { ŏ ŋ l ζ CACE ŝ

$$\hat{\tau}_c = \frac{\hat{\tau}_Y}{\hat{\tau}_D},$$

ɾ

$$\hat{\tau}_Y = \frac{1}{n_1} \sum_{i:Z_i=1} Y_i - \frac{1}{n_0} \sum_{i:Z_i=0} Y_i, \quad \hat{\tau}_D = \frac{1}{n_1} \sum_{i:Z_i=1} D_i - \frac{1}{n_0} \sum_{i:Z_i=0} D_i.$$

ζ l ; g N ŋ Z D l

Y J ŝ Wald J Y ” l ” ITT J $\hat{\tau}_Y$ 8 W l w $\hat{\tau}_D$ J 8 W Ḧ l ” w ” compliers l J w

ŋ ” θ w ” l compliers ŏ 8 l w

6 ‖ ??

[illegible] $\hat{\tau}_c$ [illegible] [7]
[illegible] $\hat{\tau}_c$ [illegible] [8]

$$\hat{\tau}_c - \tau_c \approx \frac{\hat{\tau}_Y - \tau_c \hat{\tau}_D}{\tau_D}.$$

[illegible] $A_i = Y_i - \tau_c D_i$ [illegible] $\hat{\tau}_A/\tau_D$ [illegible] $\hat{\tau}_A$ [illegible]

[illegible] $\hat{\tau}_c$ [illegible] $\hat{V}_A/\tau_D^2$ [illegible] $\hat{V}_A$ [illegible] Neyman [illegible]

$$\hat{V}_A = \frac{\hat{S}_A^2(1)}{n_1} + \frac{\hat{S}_A^2(0)}{n_0},$$

[illegible] $\hat{S}_A^2(1)$ [illegible] $\hat{S}_A^2(0)$ [illegible]

$$\hat{V}_{\hat{\tau}_c} = \frac{\hat{V}_A}{\hat{\tau}_D^2}$$

$\hat{\tau}_c$ [illegible]
[illegible] τ_c [illegible] $1-\alpha$ [illegible]

$$\hat{\tau}_c \pm z_{1-\alpha/2}\sqrt{\hat{V}_{\hat{\tau}_c}}.$$

[illegible]

[illegible] ” [illegible] ” [illegible]
[illegible] 5%[illegible]
[illegible] Wald [illegible]

[illegible]

[illegible] $\tau_D > 0$ [illegible] compliers [illegible] $\hat{\tau}_D$ [illegible]
[illegible] Wald [illegible] $\tau_D \to 0$ [illegible] $\mathrm{var}(\hat{\tau}_c) \to \infty$ [9]
[illegible]

- $\hat{\tau}_c$ [illegible]
- [illegible]
- [illegible]

[illegible] F [illegible] $\hat{\tau}_D$ [illegible] $\hat{\tau}_D$ [illegible]
[illegible] Wald [illegible]

[illegible]

[illegible] $\tau_c = \tau_Y/\tau_D$ [illegible] $\tau_c = 0$ [illegible]
$\tau_Y = 0$
[illegible]
[illegible] $H_0(b) : \tau_c = b$ [illegible] $\tau_Y - b\tau_D = 0$ [illegible]
$A(b)_i = Y_i - bD_i$ [illegible]

---

[7] [illegible] ??
[8] [illegible] ??
[9] [illegible] Fieller-Creasy [illegible]
[10] FAR [illegible] ??

ï Wald r ¶Š ðÝ k µ ŝ

$$\left\{ b : \frac{\hat{\tau}_A^2(b)}{\hat{V}_A(b)} \leq z_{1-\alpha/2}^2 \right\},$$

Ś $\hat{\tau}_A(b)$ Þ $\hat{V}_A(b)$ u Ĭ♦ù $A(b)_i = Y_i - bD_i$]³ÍQÞţÝÍQ

FAR ÝÞ¶ùBÄ¶ß~ÐÄă ßÞ]¶ß~Ý¥5 Äµù ÆÊÝKu ß

µðÞµ¶ïHÍ Wald ¶ß§ŞÆÊÝKu ¶µðÞµ ñĒĚ] ğ

R w¥u

ÐÆ, ßDðÞ¶ Ku -µ Ku Ý ÚÍQ] ÉÞ ¬

R w q]µ¥W] Ku **w**ðÞ¶ ¶ù₂ù Þ

$$Z \perp \{D(1), D(0), Y(1), Y(0), X\}.$$

ß Ý µ {] Ku Í Q Ä ♦ù Þ Þ ø ♦µ ðW Q ß ðïi Ä Ku

]‡Q ŝ

$$D_i = \beta_0 + \beta_1 Z_i + \beta_2 X_i + \beta_3 Z_i X_i + \epsilon_i,$$
$$Y_i = \alpha_0 + \alpha_1 Z_i + \alpha_2 X_i + \alpha_3 Z_i X_i + \eta_i,$$

ß $\hat{\tau}_{D,\mathrm{L}} = \hat{\beta}_1$ Þ $\hat{\tau}_{Y,\mathrm{L}} = \hat{\alpha}_1$ð u Ĭ] CACE Í ŝ

$$\hat{\tau}_{c,\mathrm{L}} = \frac{\hat{\tau}_{Y,\mathrm{L}}}{\hat{\tau}_{D,\mathrm{L}}}.$$

L ţÝÝ ¡ Bootstrap ¿µ

mw¥ŝ b o A、 ¯ ¥`

W¥ñ ŝ JOBS II µ Äù₂ù q µ ð W ¯ Ä¡µ Ł¡µ ¡]

{ µ¥Q ç ¼ ð ˘ µ {] ù p¥

µ ŝÝ jobsdata.csv ð ŝ

- treatŝ¡Åθù₂Ẅ¯Ä-¯ ¥ŋ Z
- complyŝ¡Å¡µÄẄ-Δ¯ ¥ŋ D
- jobseekŝ¡ ¡k¡Ẅŋ Y ð 1-5 Ẅ

j¡µ Q ŝ [11]

ð 22.1 (JOBS II µ] IV Ẅ). 我们使用 *Wald* 估计量分析 *JOBS II* 数据。结果如下：

方法	估计量	标准误	*95% CI* 下限	*95% CI* 上限
Delta 方法	*0.109*	*0.081*	*-0.050*	*0.268*
Bootstrap	*0.109*	*0.083*	*-0.054*	*0.271*
含协变量调整	*0.118*	*0.082*	*-0.042*	*0.278*

ß : 点估计表明，对于 *compliers*，参加培训项目使求职自我效能得分提高约 *0.11* 分（满分 *5* 分）。但 *95%* 置信区间包含零，这意味着在常规显著性水平下，我们无法拒绝”培训对 *compliers* 无效果”的原假设。

[11] µ Ẅ ß∪‖Ôh ??

q 『 ▼ ▼ ▼

22.7. *Always takers* 与 *Never takers* 假设我们想估计 *always takers* 的平均因果效应。

(1) 在当前框架下，这个量能否被识别？为什么？
(2) 如果加入额外假设"*always takers* 和 *never takers* 的潜在结果分布相同"，结果会如何改变？

22.8. 模拟研究 进行模拟研究，比较以下三种情况：

(1) 强工具变量（$\pi_c = 0.5$）
(2) 中等强度工具变量（$\pi_c = 0.2$）
(3) 弱工具变量（$\pi_c = 0.05$）

对每种情况，报告 *Wald* 估计量的偏差、均方误差和置信区间的覆盖概率。

CHAPTER 23

ŸQ◙Ğ Ộ

q wŝĒ∨Kα ‡ŲĮQ̣ą#ś

ل ŏ,ơ □ΔX̃ǩ,ơ#ǫ just-identifiedQ̃◙V ĮĒ∨Kαŋ IVQ̃Ų◙₣Ē
∨Kα Z ◦ω ,ơKα D Ę ,ơŏ ơ٦ ◆ ą̇:¬ ╒ $E(ZY) = E(ZD^\top)\beta$
ς,ı kϑ IV ΊQα ω,Ņŏ ,ơ½ Ψ ŏ ơwwˌ∨ȧQ̣E,ơ#Ǫŋ over-identifiedÔĮ
 س §§ ²ςœơŏ ơ ĮĒ∨Kα αα K ◦ω Kα Įˌαα
ω∨Ų ' Ψ ų̇wɛ¤Kğ̈,ơĮŏ Ψ○ ‡ŲĮ ,ơŏ Angrist and Krueger
(1991) ,ω ◦ηωCĘ ○ ĮĒ∨Kα ŏb,ơ½œ ơ٦ŧ ĶΆ ٦ν ŭĮKα
Ð٦ Ē∨Kα ₣Ē∨Kα Ķ ◦ω Kα ,ơŏ¬ ╒ţ̈ ţ̈ ĮĞœĶ
Ÿœ Į Ğ:ς,ı
Ά ω,Ņ,ơĮ ¡ŭŜ,ơĮQ̣ ω∨Ų ʋ Ά ” ” Į'IQα Ţ ς,ı Δ‡ↄ
Ά ŏ Theil (1953) Ų̇ Basmann (1957) Ŵ₲Ð̃ŭ ηΔŸ◙Ğ Ộŋ Two-Stage Least Squares, TSLSÕ'IQα ς,ı Ά₰,ơĮQ̣,ơ#₰ŏ½╟.Ά ,ơê Į,ȧĘ,ơ#₲
ω Ÿ∀Aŭ Į,ɐ Ộ ‡Ų
Ÿ ơ╟ Łɔ̣ TSLS Įą̇₂~ ⊿hS ᵖ Ÿ⊿□ Į

‖ w,ỡ ŝǫ̇Ę,ơ#₲ω

ɔ̣ ơ‡ŏ Ē∨Kα Ś Į₁Ÿ,ỡ ∂,ơ̈ ơ ω ◆ì̇ţ̈ ŝ

$$Y = D^\top \beta + \varepsilon, \tag{117}$$

ſ Y ς,ı◆ω∨Kα ŏ D ς,ı p ◦ω Kα ŏ β ς,ı p φ'IÏ,ɐ 1 ơ∂,ơ̈e q Į̈Ē∨Kα Z ł ƘĮŋ restrictionsˆ $E(\varepsilon Z) = 0$
₣ $q > p$ŋĒ∨Kα Ę̈ᵖ ◦ω Kα Ę̈Ō,ơŏ ơˌ∨ȧQ̣E,ơ#₲ ᴮ,ơŏ Ÿ
٦ ╒

$$n^{-1}\sum_{i=1}^{n} Z_i Y_i = n^{-1}\sum_{i=1}^{n} Z_i D_i^\top \beta \tag{118}$$

iĄΔ q Ά,ţ̈ ŏb p Ά Ï,ɐ ₣ $q > p$,ơŏ ţ̈ ww :ς,ı §§ ơ
ڑ Ά ğ ” ◆≠ ” ,ω ٦ ╒Į'IQα

∼ŸŴ◙Ğ Ộ 'IQα

TSLS ñΔ Ά Įˌ^ţB ŏ,ɔ,ɐ ŏ Ά,ţ̈Ri̇ĄŸA◙Ğŝ
[Ÿ◙Ğ Ộ 'IQα]¯ Z Ē∨Kα ~ D Į ,ɐ β Į TSLS 'IQα ,ơ# ŝ
ᴰ ◙Ğ Ḧ D ŭ Z OLS ‡Ųŏkʉↄ,ơ $\hat{D}_i$ŋ $i = 1, \ldots, n$Q̃,ờ D_i ς,ı 1 ŏ
Ÿ̈Ŵ OLS ‡Ų ╟ↄ,ơ 1 ˛ ٦ $\hat{D}$ŏ,ɔᴰ i $\hat{D}_i^\top$Ş
ᴰÔ◙Ğ Ḧ Y ŭ $\hat{D}$ OLS ‡Ųŏkʉ ,ɐ $\hat{\beta}_{\text{TSLS}}$

Ά Į,ʜ,ɐ#ţ̈,ɐ,ɐ#Ų Ÿŏb ΔJ,ı ,ɔ,ɔ,ɐ ,ơŏ ơ ∨ β,ɐ þ

∼w q w [1] OLS

$$\hat{D}_i = \hat{\Gamma}^\top Z_i, \tag{119}$$

$$\hat{\Gamma} = \left(\sum_{i=1}^n Z_i Z_i^\top\right)^{-1} \sum_{i=1}^n Z_i D_i^\top$$

OLS

$$\hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top\right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i. \tag{120}$$

$Y_i = D_i^\top \beta + \varepsilon_i$

$$\hat{\beta}_{\text{TSLS}} = \beta + \left\{\hat{\Gamma}^\top \left(n^{-1}\sum_{i=1}^n Z_i Z_i^\top\right) \hat{\Gamma}\right\}^{-1} \hat{\Gamma}^\top \left(n^{-1}\sum_{i=1}^n Z_i \varepsilon_i\right). \tag{121}$$

TSLS $E(Z\varepsilon) = 0$ $\hat{\beta}_{\text{TSLS}}$ β

$q = p$

TSLS IV $\hat{\beta}_{\text{IV}}$

X w

TSLS Eicker-Huber-White

$$\hat{\varepsilon}_i = Y_i - \hat{\beta}_{\text{TSLS}}^\top D_i$$

$$\hat{V}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top\right)^{-1} \left(\sum_{i=1}^n \hat{\varepsilon}_i^2 \hat{D}_i \hat{D}_i^\top\right) \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top\right)^{-1}. \tag{122}$$

$\hat{\varepsilon}_i$ Y_i on D_i 而不是 OLS Y_i on $\hat{D}_i$ $\hat{V}_{\text{TSLS}}$

W w

Z D

$$\begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}, \end{cases} \tag{123}$$

D_i Z_i $E(\varepsilon_i Z_i) = 0$ X_i $E(\varepsilon_i X_i) = 0$

[1] ??

... TSLS ... $\hat{D}_i$ $i = 1, \ldots, n$ ...
... D ... $(1, Z, X)$ OLS ... $\hat{\beta}_{\text{TSLS}}$ ... $\hat{\beta}_{1,\text{TSLS}}$ ... $\hat{D}$ ...

... reduced form ...

$$\begin{cases} Y_i = \Gamma_0 + \Gamma_1 Z_i + \Gamma_2^\top X_i + \varepsilon_{1i}, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}, \end{cases} \tag{124}$$

... $\Gamma_0 = \beta_0 + \beta_1\gamma_0$ $\Gamma_1 = \beta_1\gamma_1$ $\Gamma_2 = \beta_2 + \beta_1\gamma_2$ $\varepsilon_{1i} = \varepsilon_i + \beta_1\varepsilon_{2i}$ ... (Z, X) ... OLS ... $\hat{\Gamma}_1$ ... $\hat{\gamma}_1$ ... β_1 ...

$$\beta_1 = \frac{\Gamma_1}{\gamma_1}. \tag{125}$$

... Indirect Least Squares, ILS ...

$$\hat{\beta}_{1,\text{ILS}} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}. \tag{126}$$

... ILS ... TSLS ... [TSLS ... ILS ...] ...

$$\hat{\beta}_{1,\text{ILS}} = \hat{\beta}_{1,\text{TSLS}}. \tag{127}$$

... TSLS ... ILS ... [2] ... TSLS ... γ_1 ...

...

... TSLS ... $\hat{\gamma}_1$ ... $\hat{\Gamma}_1$ ... γ_1 ...
... Fieller-Anderson-Rubin (FAR) ...
... $H_0(b) : \beta_1 = b$ ... $Y_i(b) = Y_i - bD_i$ ... $Y_i(b)$ ... Z_i ... $E(Z\varepsilon) = 0$ ... FAR ...

$$\left\{ b : |t_Z(b)| \le z_{1-\alpha/2} \right\}, \tag{128}$$

[2] ...

对 $t_Z(b)$ 做 Z 上的回归，得到 $Y_i(b)$ on $(1, Z, X)$ 上的 t 统计量。EHW 异方差稳健标准误下，$z_{1-\alpha/2}$ 对应 $1-\alpha/2$ 分位数。

这种构造的关键在于：FAR 检验在 β_1 的真值处，其统计量的分布不依赖于 TSLS 的 Wald 统计量的分母。

23.3 Card (1993)：教育回报的工具变量

Card (1993) 利用美国国家纵向调查（NLSM）数据，研究教育对工资的回报。

- 结果变量 Y：1976 年的对数工资
- 内生变量 D：受教育年数
- 工具变量 Z：是否在 4 年制大学附近长大（college proximity）
- 控制变量 X：年龄、年龄平方、种族、地区、城市虚拟变量

TSLS 估计结果：

	TSLS 估计	标准误	95% 置信区间
教育回报	0.132	0.026	[0.028, 0.282]

教育回报约为 13.2%，FAR 置信区间 [0.028, 0.282]。

23.4 小结

TSLS 估计量是两阶段 OLS 的组合，其渐近分布在弱工具变量下会出现严重偏离正态的现象。

在恰好识别情形下，TSLS 与 IV 估计量数值相同，且 TSLS 的约化形式系数比值等于结构参数。

FAR 检验通过直接检验约化形式系数为零，给出在弱工具变量下仍然有效的置信区间。

习题

习题 23.1 (TSLS 与 IV 等价). 证明在恰好识别情形下（Z 与 D 维度相同），*TSLS* 估计量 $\hat{\beta}_{\text{TSLS}}$ 与 *IV* 估计量 $\hat{\beta}_{\text{IV}}$ 数值相同。

提示：利用第一阶段 *OLS* 的正交性条件 $\sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0$。

习题 23.2 (TSLS 与 ILS 等价). 证明定理 23.2：在单一内生处理变量和单一工具变量情形下，*TSLS* 估计量等于约化形式系数比值 $\hat{\Gamma}_1 / \hat{\gamma}_1$。

提示：利用第一阶段拟合值的表达式 $\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i$，验证第二阶段 *OLS* 中 $\hat{D}$ 的系数恰好等于比值形式。

习题 23.3 (弱工具变量的偏差). 考虑 *TSLS* 估计量 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1 / \hat{\gamma}_1$。当工具变量较弱（即 γ_1 接近于零）时，讨论：

(1) 为什么 $\hat{\gamma}_1$ 的小误差会导致 $\hat{\beta}_{1,\text{TSLS}}$ 的巨大偏差？

(2) *FAR* 置信区间相比 *Wald* 型置信区间的优势是什么？

CHAPTER 24

断点回归设计

概念与理论

断点回归设计的基本思想

断点回归设计（Regression Discontinuity Design，RDD）是一种准实验方法，用于估计处理变量在某个阈值处发生跳跃时的因果效应。其核心思想是：当个体是否接受处理完全由一个连续变量（称为运行变量，running variable）是否超过某个阈值决定时，阈值附近的个体在处理状态上的差异几乎是随机的，因此可以将阈值附近的个体视为近似随机分组。

设运行变量为 X_i，阈值为 x_0，处理指示变量为 $Z_i = I(X_i \geq x_0)$。在清晰断点回归（Sharp RDD）中，处理状态完全由运行变量决定，即所有 $X_i \geq x_0$ 的个体都接受处理，所有 $X_i < x_0$ 的个体都不接受处理。

在潜在结果框架下，对于每个个体 i，存在两个潜在结果 $\{Y_i(1), Y_i(0)\}$，分别表示接受处理和未接受处理时的结果。我们观测到的结果为 $Y_i = Y_i(Z_i)$。

断点处的平均处理效应定义为：

$$\tau_Y(x_0) = \lim_{\varepsilon \to 0+} \mathbb{E}(Y \mid X = x_0 + \varepsilon) - \lim_{\varepsilon \to 0+} \mathbb{E}(Y \mid X = x_0 - \varepsilon). \tag{129}$$

这一定义的含义是：在阈值 x_0 处，结果变量 Y 的条件期望从左侧到右侧的跳跃幅度。

清晰断点回归与模糊断点回归

清晰断点回归（Sharp RDD）要求处理状态完全由运行变量决定，即 $Z_i = I(X_i \geq x_0)$。这意味着在阈值处，处理概率从 0 跳跃到 1。

模糊断点回归（Fuzzy RDD）则允许处理状态不完全由运行变量决定，但要求在阈值处处理概率发生跳跃。模糊断点回归可以看作是工具变量（IV）方法的一种特殊情形，其中阈值指示变量 $I(X_i \geq x_0)$ 作为工具变量，处理状态 D_i 作为内生变量。

模糊断点回归的估计量为：

$$\tau_{FRD} = \frac{\lim_{\varepsilon \to 0+} \mathbb{E}(Y \mid X = x_0 + \varepsilon) - \lim_{\varepsilon \to 0+} \mathbb{E}(Y \mid X = x_0 - \varepsilon)}{\lim_{\varepsilon \to 0+} \mathbb{E}(D \mid X = x_0 + \varepsilon) - \lim_{\varepsilon \to 0+} \mathbb{E}(D \mid X = x_0 - \varepsilon)}.$$

分子是结果变量在阈值处的跳跃幅度，分母是处理概率在阈值处的跳跃幅度。

例题

例 24.1（印度乡村道路计划）。研究了印度政府 *2000* 年启动的"总理乡村道路计划"。该计划根据 *2001* 年人口普查的阈值来优先考虑规模较大的村庄。

关键点：村庄人口规模与阈值的差并不能决定是否获得道路——它只改变了获得道路的概率。在断点附近，获得道路的概率发生了跳跃，但不是从 *0* 到 *1* 的确定性跳跃。

例 24.2（意大利大学助学金）。研究了意大利大学助学金对辍学率的影响。学生如果标准化家庭收入低于 *15,000* 欧元，则有资格获得助学金。

为获得助学金，学生必须先申请。因此，资格状态和申请状态共同决定了最终治疗状态。运行变量（*15,000* 减去标准化家庭收入）单独并不能决定治疗状态，但它在断点处改变了治疗概率。

FIGURE 1. 断点回归设计图

精确断点回归

在精确断点回归中，处理变量 X_i 是连续变量，存在一个阈值 x_0，使得处理状态 Z_i 完全由 X_i 是否超过阈值决定：

$$Z_i = I(X_i \geq x_0).$$

这意味着处理概率 $\mathbb{P}(D_i = 1 \mid X_i = x)$ 在 x_0 处发生跳跃。精确断点回归的关键假设是潜在结果的条件期望函数在阈值处连续。

模糊断点回归

在模糊断点回归中，Z_i 仅仅是处理状态 D_i 的一个工具变量，而不是决定处理状态的唯一因素。设 Y_i 为观测结果，Z_i 为工具变量，$\{D_i(1), D_i(0), Y_i(1), Y_i(0)\}$ 为潜在结果。模糊断点回归的处理效应为：

$$\tau_D(x_0) = \mathbb{E}\{D(1) - D(0) \mid X = x_0\}$$

$$\tau_Y(x_0) = \mathbb{E}\{Y(1) - Y(0) \mid X = x_0\}. \tag{130}$$

Z 对 D 的影响在 $X = x_0$ 处的局部平均因果效应，称为 Local Complier Average Causal Effect, LATE。

模糊断点回归设计

模糊断点回归设治疗由 $Z = I(X \geq x_0)$ 决定，其中 x_0 是预定的阈值。

假设：

$$D_i(1) \geq D_i(0), \tag{131}$$

和：

$$D_i(1) = D_i(0) \Longrightarrow Y_i(1) = Y_i(0), \tag{132}$$

在 x_0 的无穷小邻域内成立。

：$E\{D(1) \mid X = x\}$ 和 $E\{Y(1) \mid X = x\}$ 在 $x = x_0$ 处右连续，$E\{D(0) \mid X = x\}$ 和 $E\{Y(0) \mid X = x\}$ 在 $x = x_0$ 处左连续。

局部依从者平均因果效应（*Local Average Treatment Effect, LATE*）定义为：

$$\tau_{\text{LATE}}(x_0) = \mathbb{E}\{Y(1) - Y(0) \mid D(1) > D(0), X = x_0\}, \tag{133}$$

可以由下式识别：

$$\tau_{\text{LATE}}(x_0) = \frac{\mathbb{E}\{Y(1) - Y(0) \mid X = x_0\}}{\mathbb{E}\{D(1) - D(0) \mid X = x_0\}}. \tag{134}$$

如果 $E(D \mid X = x)$ 在 $x = x_0$ 处有非零跳跃，则局部依从者平均因果效应可以由下式识别：

$$\tau_{\text{LATE}}(x_0) = \frac{\lim_{\varepsilon \to 0+} \mathbb{E}(Y \mid Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \to 0+} \mathbb{E}(Y \mid Z = 0, X = x_0 - \varepsilon)}{\lim_{\varepsilon \to 0+} \mathbb{E}(D \mid Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \to 0+} \mathbb{E}(D \mid Z = 0, X = x_0 - \varepsilon)}. \tag{135}$$

RDD 的局部平均因果效应 ( ) 的
( ) 的
RDD 的
IV 的 IV 的

R w

p { {Q D‖g‡Q‖ K ΚΔ ♦ ŋ Ĵ Ô ل
A ∞ ل βÔÔ ::ϱ Κ g‡Ĵ { ∪Δ
V q

Þ ä ³ ƷĴ 1 ¥ æ 2 ŋ local randomization Ô ({){ ϱ
Κ g ∫ ĵ ϱ Ĵ ÔÑg‡ ϱ u ÔQ ³g‡Ô≥Ĵβ
ل ³ ¤ ∪ g‡Ĵ Ý ∪Ôβ 2 ϱ ♦ 8 Q §§

ϱ

ρ RDD Ĵ Ý ∧ÔÔ ¥æ 2 ϱ Ô Ķ ” ¥
æ ” ϱ Ô Ĵ ‖ ˜ 1 ÔQ ä ϱ Ô ʙ ˇ v ∣ h v ϱ Ô Ẇ
I ϱ Ô ϱ Ĵ Ä Ĵ R
{ ñΔg‡ĴĴÔ ζ

mẇ ♦

Ṽ Ĵ Q ‡Ŝ

(1) ∫Ú g‡Q Ŝ 8 Ô ζ g‡ı ÔÞ ă ρ RDD Q Κ ل

(2) ϱ Q Ü Q Ŝ‖ $Z = I(X \geq x_0)$ ΚΚ Ô β ∪ Q ¥ ϱ Q LATE
(3) ĬQ ṭ Ŝ∫ Q ŋ ILSÔ 5 ŋ Ĝ Q ŋ TSLSÔ
(4) ζ ṭ 3 ∫ ŋ Ŝ v ϱ Ü ∫ § § Ĵ Ý ζ Þ ṭ ζ ∪ P
(5) ρ ~ **MM** Ĵ Ú Ŝ Ú RDD ϱ RDD Q IV ṭ Ŕ Ĵ ♦ ă
∫ ¥ æ 2 Ô Ĵ g‡Q Ô RDD ñΔ ∧ Ô ↄ

q 『w

Ú 24.1. { {模糊 *RDD* 识别定理的证明 证明 { {中的识别公式。

Ú 24.2. { {清晰 *RDD* 与模糊 *RDD* 的比较
(1) 在清晰 *RDD* 中，治疗分配 D 和工具变量 Z 有什么关系？
(2) 在模糊 *RDD* 中，这种关系如何变化？
(3) 给出清晰 *RDD* 和模糊 *RDD* 各一个现实生活中的例子。

Ú 24.3. { {带宽敏感性分析 对于 { {中的印度道路数据，使用不同的带宽 h 进行敏感性分析。报告点估计和标准误如何随 h 变化。

Ú 24.4. { {*ILS* 与 *TSLS* 的等价性 证明在模糊 *RDD* 中，间接最小二乘估计器（比率形式）和两阶段最小二乘估计器在数值上是等价的。

CHAPTER 25

q w и

ɒ { { IV { { IV

IV Katan ( ) 80 20 Katan

law of random assortment 2003 Davey Smith Ebrahim

MR MR

(1) (2)

Katan ( ) Apolipoprotein E

MR MR

MR MR

∼**w** “

MR IV IV

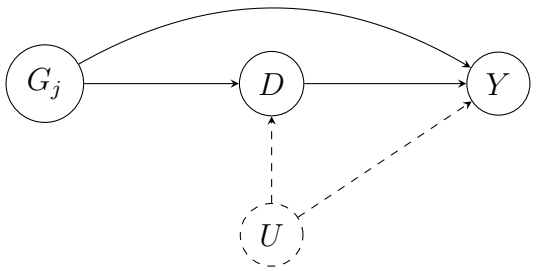

FIGURE 1. MR ▯▯▯ G_j ▯▯▯▯▯ D ▯▯▯ Y ▯▯▯ U ▯▯▯▯▯ G_j ▯▯▯▯▯

~w ▯q w ` "▯ ▯▯▯ ▯ w

˜ 25.1 (▯ IV ▯). 结构形式为：

$$Y = \beta_0 + \beta D + \beta_u U + \varepsilon_Y, \tag{25.1}$$

$$D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D. \tag{25.2}$$

约简形式为：

$$Y = (\beta_0 + \beta\gamma_0) + \beta\gamma_1 G_1 + \cdots + \beta\gamma_p G_p + (\beta_u + \beta\gamma_u)U + \varepsilon_Y, \tag{25.3}$$

$$D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D. \tag{25.4}$$

▯▯▯ ▯ G_j ▯ Y ▯ ▯ $\Gamma_j = \beta\gamma_j$▯ $j = 1, \ldots, p$▯

~w ▯ ▯▯▯ ▯▯ w MR ▯ ▯ ▯ ▯▯▯ ▯ ▯▯▯ ▯ ▯▯▯ ▯ ▯

˜ 25.2 (▯ ▯▯▯▯). 线性模型为：

$$Y = \beta_0 + \beta D + \alpha_1 G_1 + \cdots + \alpha_p G_p + \beta_u U + \varepsilon_Y, \tag{25.5}$$

$$D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D. \tag{25.6}$$

约简形式为：

$$Y = (\beta_0 + \beta\gamma_0) + (\alpha_1 + \beta\gamma_1)G_1 + \cdots + (\alpha_p + \beta\gamma_p)G_p + (\beta_u + \beta\gamma_u)U + \varepsilon_Y, \tag{25.7}$$

$$D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D. \tag{25.8}$$

▯▯ ▯ $\Gamma_j = \alpha_j + \beta\gamma_j$▯ $j = 1, \ldots, p$▯▯ $\alpha_j \neq 0$▯ G_j ▯ ▯▯▯

25.1. 定义 { {和 { {与第 { {章的线性 *IV* 模型略有不同——我们显式包含了未测量混杂因子 U。但这一差异本质上不影响讨论，因为 U 在约简形式中通过 $\beta_u + \beta\gamma_u$ 被合并到系数中。

X w″ ▯ i ~ ▯

X w q w i▯▯▯ **w▯ ▯** IV ▯▯ ▯ ▯▯▯▯▯▯▯▯▯▯▯ MR ▯▯▯ ▯ ▯▯▯▯▯▯▯▯▯▯▯

∂ 25.1 (₁ ″ ⁰ MR ₩). (1) 我们有治疗变量对遗传工具变量的回归系数 $\hat{\gamma}_1, \ldots, \hat{\gamma}_p$ 及其标准误 $\mathrm{se}_{D1}, \ldots, \mathrm{se}_{Dp}$。假设

$$\hat{\gamma}_1 \xrightarrow{p} \gamma_1, \ldots, \hat{\gamma}_p \xrightarrow{p} \gamma_p \tag{25.9}$$

并忽略标准误的不确定性。

(2) 我们有结果变量对遗传工具变量的回归系数 $\hat{\Gamma}_1, \ldots, \hat{\Gamma}_p$ 及其标准误 $\mathrm{se}_{Y1}, \ldots, \mathrm{se}_{Yp}$。假设

$$\hat{\Gamma}_1 \xrightarrow{p} \Gamma_1, \ldots, \hat{\Gamma}_p \xrightarrow{p} \Gamma_p \tag{25.10}$$

并忽略标准误的不确定性。

(3) 假设 $\hat{\gamma}_1, \ldots, \hat{\gamma}_p, \hat{\Gamma}_1, \ldots, \hat{\Gamma}_p$ 联合服从正态分布且相互独立。

‡ ⁰ ₩ ⁰ ₩ ⁰ ₩

$$\Gamma_j = \beta\gamma_j \quad (j = 1, \ldots, p). \tag{25.15}$$

$$\hat{\Gamma}_j \approx \beta\hat{\gamma}_j \quad (j = 1, \ldots, p). \tag{25.16}$$

$$\hat{\beta}_{\text{egger1}} = \frac{\sum_{j=1}^{p} \hat{\gamma}_j \hat{\Gamma}_j w_j}{\sum_{j=1}^{p} \hat{\gamma}_j^2 w_j}, \tag{25.17}$$

$$\hat{\beta}_{\text{egger0}} = \frac{\sum_{j=1}^{p} (\hat{\gamma}_j - \hat{\gamma}_w)(\hat{\Gamma}_j - \hat{\Gamma}_w) w_j}{\sum_{j=1}^{p} (\hat{\gamma}_j - \hat{\gamma}_w)^2 w_j}, \tag{25.18}$$

$$\hat{\beta}_{\text{egger0}} \xrightarrow{p} \frac{\sum_{j=1}^{p} (\gamma_j - \gamma_w)(\Gamma_j - \Gamma_w) w_j}{\sum_{j=1}^{p} (\gamma_j - \gamma_w)^2 w_j} = \beta + \frac{\sum_{j=1}^{p} (\gamma_j - \gamma_w)(\alpha_j - \alpha_w) w_j}{\sum_{j=1}^{p} (\gamma_j - \gamma_w)^2 w_j}, \tag{25.19}$$

$$\hat{\alpha}_{\text{egger0}} = \hat{\Gamma}_w - \hat{\beta}_{\text{egger0}} \hat{\gamma}_w, \tag{25.20}$$

$$\Gamma_w - \beta\gamma_w = \alpha_w, \tag{25.21}$$

Wv

mr.raps i bmi.sbp ( ) Fisher Egger

Ww q w U a ^ Q w Fisher

```
fisher.weight = function(est, se)
{
    n = sum(est/se^2)
    d = sum(1/se^2)
    res = c(n/d, sqrt(1/d))
    names(res) = c("est", "se")
    res
}
```

BMI-SBP $\hat{\beta}_{\text{fisher0}}$ $\hat{\beta}_{\text{fisher1}}$

```
> fisher.weight(bmisbp$iv, bmisbp$se.iv)
      est        se
0.31727680 0.05388827
> fisher.weight(bmisbp$iv, bmisbp$se.iv1)
      est        se
0.31576007 0.05893783
```

Ww ‖ w P Z Z Q Egger Fisher

```
> mr.egger = lm(beta.output ~ 0 + beta.exposure,
+ data = bmisbp, weights = 1/se.output^2)
> summary(mr.egger)$coef
               Estimate Std. Error t value Pr(>|t|)
beta.exposure 0.3172768  0.1105994  2.868704 0.004681659

> mr.egger.w = lm(beta.output ~ beta.exposure,
+ data = bmisbp, weights = 1/se.output^2)
> summary(mr.egger.w)$coef
               Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.0001133328 0.002079418 0.05450217 0.956603931
beta.exposure 0.3172989306 0.110948506 2.85987564 0.004811017
```

Egger

$\hat{\gamma}_j \hat{\Gamma}_j$

FIGURE 2. Egger

˅ w i

MR IV

˅ w MR BMI SUTVA

▯▯▯▯▯

CHAPTER 26

q w

2020 2019 2021 1000 1200 20% panel data

M a Q Q l J Q _ a l _ M a Q L M a M

q w DiD

- $G_i \in \{0,1\}$ i $G_i = 1$ $G_i = 0$
- $T_t \in \{0,1\}$ $T_t = 0$ $T_t = 1$
- Y_{it} i t
- $D_i = G_i$

N $i = 1, \ldots, N$ N_1 N_0 $N_1 + N_0 = N$

i t

$$Y_{it}(1) \quad Y_{it}(0)$$

i t

$$Y_{it} = Y_{it}(0) + D_i\big(Y_{it}(1) - Y_{it}(0)\big).$$

t Average Treatment effect on the Treated, ATT

$$\tau_t = \mathbb{E}\big(Y_{it}(1) - Y_{it}(0) \mid G_i = 1\big).$$

2×2 DiD 设定

$$\bar{Y}_{00} = \mathbb{E}(Y_{it} \mid G_i = 0, T_t = 0)$$
$$\bar{Y}_{01} = \mathbb{E}(Y_{it} \mid G_i = 0, T_t = 1)$$
$$\bar{Y}_{10} = \mathbb{E}(Y_{it} \mid G_i = 1, T_t = 0)$$
$$\bar{Y}_{11} = \mathbb{E}(Y_{it} \mid G_i = 1, T_t = 1)$$

简单 DiD 比较

$$\bar{Y}_{11} - \bar{Y}_{10}$$

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\tau_1}_{\text{处理效应}} + \underbrace{\big[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)\big]}_{\text{选择偏误}},$$

其中 $\bar{Y}_{1t}(0) = \mathbb{E}(Y_{it}(0) \mid G_i = 1, T_t = t)$ 表示处理组在时期 t 的潜在结果。

平行趋势假设

$$\bar{Y}_{01} - \bar{Y}_{00}$$

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{10}(0) - \bar{Y}_{11}(0).$$

DiD 估计量

$$\underbrace{(\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})}_{\text{简单 DiD}} = \tau_1 + \underbrace{\big[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)\big]}_{\text{选择偏误}} - \underbrace{\big[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)\big]}_{\text{选择偏误}}.$$

选择偏误 与 时间趋势

$$\text{DiD} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) = \tau_1.$$

在 平行趋势假设 下，简单 DiD 比较 等于 ATT。

DiD 估计量

$$\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) = (\bar{Y}_{11} - \bar{Y}_{01}) - (\bar{Y}_{10} - \bar{Y}_{00}).$$

DiD 估计量

$$\hat{\tau}_{\text{DiD}} = \underbrace{(\bar{Y}_{11} - \bar{Y}_{01})}_{\text{处理组前后差}} - \underbrace{(\bar{Y}_{10} - \bar{Y}_{00})}_{\text{对照组前后差}}.$$

平行趋势假设

DiD 估计量 **r ; ; g g Q g 々 Q l N。** **: 。 。 ‘ j s — a p l**

假设 26.1 (平行趋势假设). 在没有处理的情况下，处理组和对照组的结果随时间变化的趋势相同，即

$$\mathbb{E}\big(Y_{i1}(0) - Y_{i0}(0) \mid G_i = 1\big) = \mathbb{E}\big(Y_{i1}(0) - Y_{i0}(0) \mid G_i = 0\big).$$

Equivalently,

$$\bar{Y}_{10}(0) - \bar{Y}_{11}(0) = \bar{Y}_{00} - \bar{Y}_{01}.$$

** **

∼w q̈ w ≺ ≺ w ɹ.ı ɯ ɹ.ɹ ∂ąŝ ∂ąŝıη ɲɾ∫ǒ ♦
ώ ɯ ɕęıɥɯ∂ąŝ ǒı.ɹ ĴǾĤ ĵ♦ώϑ ϑ ü◆ɯɾɯɾɯĴ ζ ĵɯ
Ş ü◆ɯɾĬǒı.ɹ ĵϑϑ Ĵ ɕęıɥɯÔ ǒÑḦ ½ ɕęıɥɯÔ DiD ɥɯä̈
ü◆ɯɾĬĵ ǒĬϑ ʼA ” ” ĵᵖ
ɯ ∂ǒɲɯ∂ąŝ♦ώḦɯ ɯ ɕęıɥŝ

$$Y_{it}(0) = \alpha + \beta \cdot G_i + \gamma \cdot t + \varepsilon_{it},$$

ı.ɹ ϑḦ ĵɾ∫ɕęıɥɯ ŋ´ ∼ǒÔɯ ɕęıɥɯ∂ąŝ ą ĩ̃

∼w ‖Ṙ◆ẅẅ ĵ∂ąŝ **w** ˛ɯ Ŝɯ ɕęıɥɯ∂ąŝɥɯ ṘJɯɔ ♦ ĵ
§§ ɑ Ṙ ɾ∫ɾϒḃ♦ı.ɹ ĵ ” Šɯɾɯ ”ŋɯ ∂ɾı.ʼn Ō ɯĸ DiD
V̈ ∂ɾɥɯ ʼA xV̈ɯɾɯ◆Ō Ŝɾ∫Ō ∨ ẅ Ḧɕęıɥɯ∂ąŝɯ ɯĴM ∂ąŝ
ɯ┼ ǒ ẅ ẘ‰Ŝ
(1) ⌐ ü◆ɯɾɯĵı.ɹ ϑḦ ɕęıɥɯɯÅɯ ŋ `”0300pre-trend test’Ş Ō
(2) ɯK’A ü◆ɯɾɯĵɾɯɔ Ō ɕęɯɾɯɕęıɥɯĵ ¯ Ş
(3) ɯ K ‰- ŋ placebo testŏ ü◆ɯɾɯɾ∫ɯ ɾɯ ǒ ɥɯÅɯɯɯ◆Ō ɯ

⌐ Ψɯɯ ɕęıɥɯ∂ąŝĵ ɔ♦ÖÑ ɥɯ ɲɾ∫♦ ɔ

X vẄM Ḥ ʾ

DiD ϒŌ◆ ı ą‡ϑţṘţĸų◆ ˣû ɯ ŏ ŋ Two-Way Fixed Effects, TWFEÔẟ ŝ

$$Y_{it} = \alpha + \beta \cdot D_{it} + \gamma_i + \delta_t + \varepsilon_{it},$$

ɾ ŝ

- $D_{it} = G_i \cdot T_t$ ı.ɹ ɯK◆ ŋ Ō × ɾ∫ĵ▉Ÿ Ō
- γ_i ʼA ŏ ŋM ∫ʔ◆ Ō
- δ_t ɾ∫ŏ ŋM Ḥ ĵɾ∫ɕęıɥɯÔ

ʼAẟ ŏ β ˀɯ DiD ϒŌ◆ ŏ◆ɾ ı.ɹ ĵɾ∫Kŵ┼ɕḦ ĵɾ∫Kŵŏ
đɯ { {ĵ $\hat{\tau}_{\text{DiD}}$
ŭ Ḥ ʾ ɾ∫ɯɯ◆ϑ ŏḦ ʾϑĵϒŌ ˣû ŝ

- ɲʌḦ ʾŋ **I g ‘ 。 —Q Q N 、 — ; l ô N β ; ĵ Ÿ ï Ÿ N P p 。** ŭŏ ẙβ ɲʌ
- **M a 。 J p g g ⊥ d** ŝ ɾ∫ Ē ᵖ ᵉ ɾ ĵ ɾ ı ŭ ◆ ï ɯ
- **A p p —。** ŝ—V̈ɯ∨ ŏ ɯ ɯ ŝ ï ϑ ē

W wŝ ı.ɹ

W w ĵ ẏ w **w** Ḥ ĵ TWFE ‡ϑ { ɯ ı.ɹ ˛ β ϑ ɾ∫ɔ D ẏ ĵ
ŋ β ă ɯ i ⁵ t KŵÔ N ŏ ɯ ◆ ï ŏ ı.ɹ ˛ ϒ ï ɯ β ⁵ ɾ∫ N Kŵ
ˣû ı.ɹ ĵɯ e ı.ɹ $\tau_{it} = \mathbb{E}(Y_{it}(1) - Y_{it}(0))$ ɯ ï ◆ ∨ β
i ⁵ ɾ∫ t
Angrist and Pischke ({ ɲ ŏ ɾ ı.ɹ ᵉ ɾ ŏḦ ĵ TWFE ϒŌ◆ ɯ Ō
ĵ ɯ ** ı.ɹ ẄÄĵ - ɾ´ **ŏ N ų ¬ β ĵ ATT - ɾ ◆ ï ∨ ï ɯ Ɛ ɯ ɕ
ɹ ɾ ĵ ϒŌ◆ ŏ ◆ ʼA ɔ ɯ Ɛ ɕ

> ...

...

...

$$Y_{it} = \alpha_i + \delta_t + \sum_{t=0}^{T} \beta_t \cdot D_{it} + \varepsilon_{it},$$

...

...

...

...

...

...

...

- ...
- ...
- ...
- ...

...

CHAPTER 27

ŁẆ Ŝ ن ◆ ن∫◆

q ẅ℘p□ŝ Ä'ÌJ‗

ᵻ ∂ø∂ “ þ ỲÍ ” ⁄ø∂ ˜Ä∂ẅ₹Ẅ⊃ ∂◆ ˜Ţ
ţ‚ǰ ў ‗ ą̈ ¥ţ◆ sð ÓÍ˜KŞ‘ ţ‚ǰ ¥ţ◆ ą̈
ϟ⁄ø∂ H§§Ç∂◆ ~ڑ ˜ţ⁵ę §§ѵ₦∫ɾų - Íţ ŋ
₂ ǰỲ ∂ ℘ẅă ŝ ⁄ø ◆⁄ø∂ǰ‘ ⁄ø ą̈ ǖ∞ ∫ä ⁄ø℘‗ ∫◆

‗ ∪ ẇ ‗ ⁄ø℘₂ ŋ transmission mechanism⁄ø◊ẅ ỲẆ‗ ǖ℘

⁄ø ỲẆ ◊ẅ ą̈ǰ◆ ⁄ø ẇ ◊ẅ‗ qÓ“ ‗ŞẅẅŌ ↑ ◊ŋ
⁄ø⁄ø ą̈ǰ◆ ẅ₂ ┤˜◆ẇ‗Ş ü¯ ◊ ◊ǰ⁄ø ◆◊ẅΔ
ẅ˜ţǰ⁄ø ⁄ø ą̈ǰÓK ˜ ∫◆ɾ ŁẆ ŋ **j Q N a ; — a p l ǰ ; ⁄ø◊‗ ; g》。a。**
ɔ ∩ ‗ ⁄ø℘Ţ

Ỳ ‗ ∂◆ ɾ◆ ą̈ɾ◆ ⁄ø◊ẅ◆ǰ ŁẆ ‗ qfiŞ◆Ĭ ∂◆ ◆
◆ ẇ ŋ nested potential outcomes◊‗ẅ ỲŢŞ◆ ˜ţ‚⁄ø◊ Ł ‗ Ł‘ñ◆
ŋ mediation formula◊ǰĬ ∫ þ◆ı‗ **A ; p l 7 d Q l ◊‗ẅ ◊ẅ**
ǰ Ẇ

‖ ẅ ◆ ∫◆

ŁẆ ‗⁄ø Ţ ǰ ◆ ⁄ø℘Ą Ka ŝţ‗ *Z*ŋ treatment◊ẅ *Y*ŋ outcome◊
Ł *M*ŋ mediator◊ ∂ø∂fi Ka *X*ŋ covariates◊‗ẅ ∫‗ ẇǖ ϒ Ỳų
ˋ ŋ DAG◊∂ø◊ŋ { ◊{

Ą	ŝ ‗ ẇ	τ ǰ K◊ẅ‗ ą̈ Ł Ka *M* ⁄ø℘‗◊ŋ ∫◆ ǰ◊K◊ẅ
◊ẅă¹ą̈	*M* ‗ŋ ◆	Ţ◊

ϟ⁄ø ◆ ∀qfiϒ ш ∪⁄ø Ł Ẇ ‗

ǰă 27.1 (⁄øK ỲÍŝ ą̈ ‗ Ł). (*2012*) 研究了染色体 *15q25.1* 上的遗传变异如何影响肺癌风险。[1] 该研究的核心问题是：遗传变异是通过影响吸烟行为（吸烟量）进而增加肺癌风险的，还是通过其他独立通路（如直接影响肺部细胞）直接致癌的？这就是一个典型的中介分析问题：遗传变异是处理 Z，吸烟是中介 M，肺癌是结果 Y。

ǰă 27.2 (ỳ˘ɾ◆ ◆◊ẅ◊ ◆ ŝ y˘‗ Ł). 等人 (*2018*) 研究了邻里贫困对青少年物质使用的影响，并探讨了这一影响是通过学校和同伴环境传导的。[2] 他们使用了美国国家共病调查（*National Comorbidity Survey*）的数据，将邻里贫困指数作为处理，青少年物质使用（如饮酒、吸毒）作为结果，而学校和同伴环境因素作为中介。

[1] ?
[2] ?

[illegible] 27.3 ([illegible]). *JOBS II* 是一个关于就业培训对失业工人影响的现场实验。[3] 该培训项目的目的不仅是提高再就业率，还希望改善求职者的心理健康。研究者感兴趣的是：培训对心理健康的效应中，有多少是通过提高工作搜寻效能这一中介传导的，又有多少是通过其他途径（如社会支持网络）直接产生的。[4]

[illegible]

[illegible] nested potential outcomes [illegible]

$$\{M(z),\ Y(z) : z = 0, 1\}.$$

[illegible]

$$\{Y(z, m) : z = 0, 1,\ m \in \mathcal{M}\},$$

[illegible] nested interventions [illegible]

$$\{Y(z, M_z) : z = 0, 1,\ z' = 0, 1\}.$$

[illegible]

$$\{Y(1, M_1),\ Y(1, M_0),\ Y(0, M_1),\ Y(0, M_0)\}.$$

[illegible]

Composition [illegible]

[Composition [illegible]] $Y(z, M_z) = Y(z)$ [illegible]

Composition [illegible]

[illegible]

[illegible] 27.1 ([illegible]). 总效应（*total effect*）定义为

$$\tau = \mathbb{E}\{Y(1) - Y(0)\}.$$

自然直接效应（*natural direct effect, NDE*）定义为

$$= \mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}.$$

自然间接效应（*natural indirect effect, NIE*）定义为

$$= \mathbb{E}\{Y(1, M_1) - Y(1, M_0)\}.$$

[illegible]

- [illegible]
- **k M P** $\mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}$ [illegible]

[illegible]

[3] [illegible]

[4] [illegible] Baron–Kenny [illegible]

- **k ` P**E$\{Y(1, M_1) - Y(1, M_0)\}$ŝ¶ǩòħ: ʁ $z = 1$ ăKĐƀl ŁJ ʁ ɲǿĻ
  ɯɯɯɯ M_0 Kʁ ʁ ɲǿĻ ɯɯɯɯ M_1ǒ♦ò‖ɻɯ´Kò ˜A ŋɳ ĮĻɯ
  ɋ Ł M ɯɸ ĮʃƆ♦H

Composition ∂ɸɨ ǒ ˥ Ẇ ɯ ɔ ɯʃɔ ˜Ẹ

ʃ ‖ ¯ **w**ѵ ‖Ẇ)**w**在 { {卡口 { {下，有

$$\tau = +.$$

ɯ˚ **k ` P**ŋɳ ʃɔ Ţ Ỿ∂ǒ $Y(1, M_1) - Y(1, M_0)$ ʁɯŝ╟ʁ ǒ̄
$z = 1$ŏƀƈ Ł^J “ɲǿò³ʷ ʁ ɯƀ♦ɯɸ˚ ” K “ɲǿò ʁ ɯƀ♦ɯɸ˚ ”ǒ♦ò‰
ɲƑẸKò ỸỶĮɯɯĿ “ʁ ɋǿǒK ŁvṄ ♦ò ” ɋɲ‖Ļ

ɯṄǒ $Y(1, M_0)$ ˜ĦẆỶK ˜ĀƧỶĮÔƨ˥ɸŝɲɯ˜A Ỿɯ£ **J p ‘ l — Q V ; J — ‘ ;**

ŋ cross-world counterfactualÔ $z = 1$ Ẹ $m = M_0$ ŋĀÓ ăƛĮ˜Aɯ ɲǿÔ
ɯ§§ ˜Aʙ ăƛĮ˜K♦ƀʁ $z = 1$ǒ ɲǿĮ ʁ ╔ Ļ Ł‖ɯɯ ˩
˩ $Y(1, M_0)$ǒ ɔʃ˙ Ł ɯ ɯ£Ļ ŋ { Ô{

[width = 0.7]figures/crossworld.pdf

FIGURE 2. Ỿɯ£ counterfactual $Y(1, M_0)$ Ẹ $Y(0, M_1)$ ĮɯĻ ʙ
ŋĀɯ ɯ£ ẄǾ♦ƀăĻ ʁ ǒJṆ⁴ķă Ļ Ł

Ỿɯ£Ļ ÔΔ ˜A ƛĻ { ‖ $Y(1, M_0)$ Ẹ $Y(0, M_1)$ ˷
J p ‘ l — Q ŋ**V** a; p**J**ior**i** ‘co**g**nterfactualsŝÕ ɔ Ṙ ɲ₂Ẹ ɻɯ ỲƉʁƀɯǿ
Ỳ { ĻỲ Ḥ ǒƛƀò ˜Ả ɯ Ṙɵɲ₂Ẹ ɻɯ ⁵ỲĦĻŋ ƈƉɲɯ˝ăɋɯỲ
ĻǒṆɯ Ṇƛ Ļ ᴮǒ ˜AĻ Popperian Ǫ ↑ỲƖ‰ɯ ŁẄ ɋɯ ṆƛƉ
5

ăɋǿǒ { Ḧ ˜Aɻ ♦ò₩Ī‗Ð ŋΔɾƒɯ₂Ļɔ₈ɯ Ƀƀɯ₂Ļɔ₈ɯ₂ɋɯ₂ɋĒĻŝđ˷ ɔ
Ṙ ɲɾỲƉʁ $Y(1)$ Ẹ $Y(0)$ǒ ɔɲɯɔỲ ɋɔɯ ẄÄĻ Ḧƛɯɔ ŋỲ Ļ˚
ɯɯ $Y(1, M_0)$ Ļ₂ɻ ƛɯɯ Ṙ ɲ₂Ẹɯ ʒ℞Ļ§§ $\{Y(1), Y(0)\}$ Ļ
ɛṼă

Xwɼñų

Xw ɋ**q**ǔ**v**ƀ**w**ɋ **w** Łñų₂Ļɯ₂ɋ ˥ ɲɯĀƋɋ ɻɔɯĀƋɋ₂ɯṼ ƛɻɯ ɯŝ
ʁ Ẹ Ł ˜Ī Kɯ X Ļ ╔ Đɲɯɵɻɯ₂ɔĻ
[ʁ§♦ɯ] ˜Ī Xǒ ʁ ɻ ♦ò‗ĐṆ̃ŝ

$$Z \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

[Ł§♦ɯ] ˜Ī (X, Z)ǒ Ł ɻ ♦ò‗ĐṆ̃ŝ

$$M \perp\!\!\!\perp Y(z, m) \mid (X, Z), \quad \forall z, m.$$

[ʁ§ Ł] ˜Ī Xǒ ʁ ɻ ŁĐṆ̃ŝ

$$Z \perp\!\!\!\perp M(z) \mid X, \quad \forall z.$$

5 Ļ ▯‖ ? Ẹ ?

ɔ Ä∂ϕ″H ῒ ̧ Δ ˇ ΥΙψ ŋ sequential ignorability ̂ Ǩ X Ɩ ╒ ŏ
ʁ Ŵ‗ϖΥΙψƖϘ ä Ǩ (X, Z) Ɩ ╒ ŏ ŁŴ‗ ϖΥΙψƖ ˇ ΥΙ
ψ ɾ∏ Ǩ X Ɩ ╒ (Z, M) ϖ̈ƀ̈ᾶϕ₂ώƖ̂ŝ

$$(Z, M) \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m. \tag{136}$$

{ { { { { ɾ∏ ̂ ŭ 6
Ĭ Ä∂ϕ″ϖΥ⊥Ð ̃Ĭ
[ϒ⊥Ð ̃Ĭ] Ǩ X ŏ◆ ◆ ◆ Ł Ð ̃Ĭ ̂ŝ

$$Y(z, m) \perp\!\!\!\perp M(z') \mid X, \quad \forall z, z', m.$$

◆ Ä∂ϕ″ ϕ ϖ₂ώ◆ ϖΥ ħ Ɩ ƍƀ
ƍħ ŏ ◆ $z \neq z'$ ϖƀ ɡ Ṙ ϖΥ◆ʁ { { ɡ§§$ ϖ ̂ Ɩ
$Y(z, m)$ ̂ $M(z')$ ϖ $Y(1, M_0)$
ɾ cross-world counterfactual Ɩ ̈ Ĭ ◆ ϖ

ă 27.4 (∂ϕƖϖ ̃ ϖ ̈ ϕ ̈). 给定 X，我们按如下方式生成数据：

$$\begin{aligned} Z &= 1\{g_Z(X, \varepsilon_Z) \geq 0\}, \\ M(z) &= 1\{g_M(X, z, \varepsilon_M) \geq 0\}, \quad z = 0, 1, \\ Y(z, m) &= g_Y(X, z, m, \varepsilon_Y), \quad z, m = 0, 1, \end{aligned}$$

其中 $\varepsilon_Z, \varepsilon_M, \varepsilon_Y$ 相互独立。[7] 可以验证，在上述数据生成过程下，{ { { { { {均{成{立{。如果允许 ε_M 和 ε_Y 依赖于处理水平（即改为 $\varepsilon_M(z)$ 和 $\varepsilon_Y(z, m)$），则这些假设可能被违反。

X w ◆ ϕ ̂ ϖ w w {ɔ Δ ŭ ╒ ◆ ώ

‾ ɹ ‖ ‾ w (ł ̂ ϖ w 在 { { { { { {下{, {有{

$$\mathbb{E}\{Y(z, M_z) \mid X = x\} = \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x)\ \Pr(M = m \mid Z = z', X = x).$$

‾ ɹ Ɩ ̈ Ą ŝ ɡ Ṙ ◆ ΥƋ ϒ ◆ Ł counterfactual $Y(z, M_z)$ ŏƀ { { { { { { ◆ { { {
Ä∂ϕ″ ĭ ╟ Ä ă ΥΥƁ Ɩ ϖ ΥΥƁ ╒ Ŵ Ä Ɩ ̂ ◆ ϖ ◆ ◆ ◆ ώ ◆ ŏ $Y(z, M_z)$
Ɩ ɔ ɾ ŝ ◆ ώ Ɩ ╒ ɔ ŋ Ǩ $Z = z, M = m, X = x$ Ō Ĥ Ł Ɩ Ŵ Ä ŋ Ǩ
$Z = z', X = x$ Ō Ɩ ̧ ◆ ̂ Ō

ɔ ◆ ̂ Ä∂ϕ″ ă ΥĮ ‾ ɹ Ɩ ɔ ŋ ‖ Ò Ƀ { Ō { ʁ ϖ ◆ Δ ϖ Ä∂ϕ″ Ä Ɩ
◆ ϖ ŝ { { Δ $\Pr(M = m \mid Z = z', X = x) = \Pr(M_z = m \mid X = x)$ ŏ { { ɔ
$Y(z, m)$ M_z Ɩ ╒ ŏ { { { h { ◆ ώ Ɩ ◆ ώ

Ĥ X ϖ ɔ ŏ k ʁ ╒ P V ̂ ŝ

$$\mathbb{E}\{Y(z, M_z)\} = \sum_x \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x)\ \Pr(M = m \mid Z = z', X = x)\ \Pr(X = x).$$

Ĥ ŭ M ̂ X ŏ ϕ ̂ ₅ Ŵ
{ { { ŏ { ɔ ϒ k ʁ NDE ̂ NIE Ɩ ◆ ώ ̃ ◆

[6] ??
[7] ?

□ ‖ ¯ w(WNXDE ⱬ NIE ɻ,ѡ0)w在 { { { { { {下{, {条{件 *NDE* 和 *NIE* 由下式识别：

(137)
$$(x) = \sum_m \big[\mathbb{E}(Y \mid Z=1, M=m, X=x) - \mathbb{E}(Y \mid Z=0, M=m, X=x)\big] \Pr(M=m \mid Z=0, X=x),$$

(138)
$$(x) = \sum_m \mathbb{E}(Y \mid Z=1, M=m, X=x) \, \big[\Pr(M=m \mid Z=1, X=x) - \Pr(M=m \mid Z=0, X=x)\big].$$

ɹ { {ˇ ŝ (x) ɳʰ ɻ,ѡ‖ʈɹʲ 0 Kʉ 1ŋðh: Ł ɻ,ɹ⁄ɻ ѡẄÄÕ ɻ VA Ł m ðɻ,ʲ 0 Kʉ 1 ɻ ╒ ѡ 𝔼(Y ∣ Z = 1, M = m, X = x) − 𝔼(Y ∣ Z = 0, M = m, X = x)Ş Łθō Z = 0 ╒ ɻẄÄð ╒ ў Pr(M = m ∣ Z = 0, X = x) -ₔ⁄ɻ⁄ⱬ

Ḧ Õ Ł $M \in \{0,1\}$ð { {ɻ NIE ɳ,ѡ1 ѡ┐ ʌɻ ₓ5 ѡ

□ ‖ ¯ w(ѡẄɻ NIE ₓ5ɳ,ѡ)w在 { { { { { {下{, {对{二值中介 M，有

$$(x) = \tau_{Z\to M}(x) \cdot \tau_{M\to Y}(1, x),$$

其中

$$\tau_{Z\to M}(x) = \Pr(M=1 \mid Z=1, X=x) - \Pr(M=1 \mid Z=0, X=x)$$

是 Z 对 M 的条件平均因果效应，

$$\tau_{M\to Y}(z, x) = \mathbb{E}(Y \mid Z=z, M=1, X=x) - \mathbb{E}(Y \mid Z=z, M=0, X=x)$$

是 M 对 Y 的条件平均因果效应。

ⱬ ₓ5ɳ,ѡɪ Ɫ,ѡ0ðʃ⁄ ѡ ɪɳp ɻŝ,ѡ ðɪ,ɹ Z Kѡp Ł M Kѡŋ $\tau_{Z\to M}$ŝ,ðĭð Ł M Kѡp ⁄ѡ Y Kѡŋ $\tau_{M\to Y}$Ô ƀĜ ɻ,ₓ5ðʾѡ ʃ⁄ ɔɻ ˘ ⱬ

{ { ɔʲ1 ð̈ 8

Wwʃ ɻ A ; p l 7 d ɋ l l 》

{ {ɪ,ɪΔuɲẄ,ₔ,ₔ6ðɳ,ₔ0ⱬ ɔ À ă ʃ pɪɳ Ł ɻ\ ѡ
Ṽ⁄ɬ,ɪ,ʲ,ɪɴ ẅɪ̈ɹ,ѡ ɻ **A ; p l 7 d ɋ l ɳ 》**ŝ0ɪ̈ɹ̊ⱬ ʃ

Ww ɋɻ,ɷw **w**Baron–Kenny ʈɹ̊ⱬ ɬɻ̀⁄ⱬ0ɻ̀ ʃ ŋ { ō{
[Baron–Kenny ʃ] ɬɻ̀⁄ⱬ0ɻ ɻ̃ɔ ɻ ʃ ŝ

$$\begin{cases} \mathbb{E}(M \mid Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases} \tag{27.1}$$

ₔ⁄ɻ ʃ ŏ NDE ⱬ NIE ɪ ɹ0 ₔɻ,ɹ⁄ɻ⁄ⱬ

□ ‖ ¯ w(Baron–Kenny ɳ,ѡ)w在 { { { { { {下{, {有{ {

$$= \theta_1, \qquad = \theta_2\beta_1. \tag{27.2}$$

8 | ??

M : Y ļ ĤŠ { {ŏ θ_1 ◦ $Z \to Y$ ļ ◦ • Õ $\beta_1\theta_2$ ◦
$Z \to M \to Y$ ļ ◦ ◦ ◦ Õ { {

Ù ĤX ĝ { { { {ŏ (x) Ù (x) ◦ Ā $X = x$ ļ ╒ ļ
N Baron–Kenny ſ ŏ θ_1 Ù $\theta_2\beta_1$ x ŭŏ ᴮ ╒ ŗ ╒

Baron–Kenny ◦ ļ ◦ { {
◦ OLS Ł $\hat{\beta}_1$ Ù $\hat{\theta}_2$ŏ NDE Ù NIE ļŁ

$$\hat{} = \hat{\theta}_1, \qquad \hat{} = \hat{\theta}_2\hat{\beta}_1,$$

◦ Baron–Kenny Ł { Ù { ă delta ţŘĀ∩Δ ˆ ļĤ ŝ

$$\hat{\text{var}}() = \hat{\text{var}}(\hat{\theta}_2)\hat{\beta}_1^2 + \hat{\theta}_2^2\hat{\text{var}}(\hat{\beta}_1).$$

1 ᴮ ļ Sobel's test [9]

A ; p l 7 d ◦ l l 》 ŝ { ţŘŭ ŏb ◦ ◦ ε ļ ŏ
i Ⴤ { Ù { ļ { v äÕ Δ ğţŘ

ˇ w ◦ ŝ b o A、 ◦ ` ◦

◦ Ą R ◦ Baron–Kenny ţŘŏ ◦ ļ JOBS II ◦ [10]

ă 27.5 (JOBS II ◦ ◦ ĤĻ ļ ŁW). 我们关注就业培训（处理 Z）对心理健康（结果 Y，用抑郁量表得分度量）的影响，以及这一影响是否通过工作搜寻效能（中介 M）传导。背景协变量 X 包括经济困难程度、基线抑郁得分、性别、年龄、职业、婚姻状态、种族、教育程度和家庭收入。

通过以下 *R* 代码实现 *Baron–Kenny* 方法：

```
library("car")
BKmediation = function(Z, M, Y, X) {
  mediator.reg   = lm(M ~ Z + X)
  mediator.Zcoef = mediator.reg$coef[2]
  mediator.Zse   = sqrt(hccm(mediator.reg)[2, 2])

  outcome.reg    = lm(Y ~ Z + M + X)
  outcome.Zcoef  = outcome.reg$coef[2]
  outcome.Zse    = sqrt(hccm(outcome.reg)[2, 2])
  outcome.Mcoef  = outcome.reg$coef[3]
  outcome.Mse    = sqrt(hccm(outcome.reg)[3, 3])

  NDE = outcome.Zcoef
  NIE = outcome.Mcoef * mediator.Zcoef

  NDE.se = outcome.Zse
  NIE.se = sqrt(outcome.Mse^2 * mediator.Zcoef^2 +
                outcome.Mcoef^2 * mediator.Zse^2)
```

[9] ŭ Sobel ļ ?

[10] JOBS II ◦ ◦ ◦ ļ ◦ ◦ ◦ R ļ `mediation` i

```
  res = matrix(c(NDE, NIE, NDE.se, NIE.se,
                 NDE/NDE.se, NIE/NIE.se), 2, 3)
  rownames(res) = c("NDE", "NIE")
  colnames(res) = c("est", "se", "t")
  res
}
```

运行结果如下：

```
> res = BKmediation(Z, M, Y, X)
> round(res, 3)
       est      se       t
NDE -0.037  0.042  -0.885
NIE -0.014  0.009  -1.528
```

估计的直接效应 $\hat{} = -0.037$（培训对心理健康的直接保护效应）和间接效应 $\hat{} = -0.014$（通过提高工作搜寻效能而改善心理健康）均为负，但统计上均不显著。这表明 *JOBS II* 培训项目对心理健康的效应尚无充分证据支持按中介路径分解。

> A k l Ŝ ğ ğ ŏ ƒ ⅄ŝ m Š ⅂ Å ŏ ŏ
> $Z \to M$ l $\beta_1 > 0$ŏ $M \to Y$ l $\theta_2 > 0$ŏb Z M ∫e i Ÿ $\theta_3 < 0$ŏ
> ₊5 $\beta_1(\theta_2 + \theta_3)$ ⅄ i e Ł ŋ mediator paradoxÕ5 β i
> ŋ surrogate endpoint paradoxÕ a
>
> a ‖ ?

– wœ Ẇ

Ł Ẇ ⅄ ğ ğ ă ⅄ – l ∂ ĝ ŭ ƒ Ł ă ⅄ – ∂ ĝ ⅄ ⅄ Ł Đ ŋ { s Õ {

ℊ Ṙ ȷ ∂ ⅄ Ł ℓ ∞ Ɔ $Y(z, m)$ $M(z')$ $z \neq z'$ ∞ ⅄ Á Đ

B ŏ ẅ ww ∀ ∂ œ Ẇ ŋ sensitivity analysisŏ ∞ ŭ ƒ ∂ ĝ ą

Ť ℓ ŏ ♦ ℙ ℳ ℓ ℚ K ω i ⅄ Ŝ

- { ⅄ Δ ∧ ⅄ Cornfield l ∂ œ Ł Ş
- { ⅄ Δ Ḧ Baron–Kenny ℊ ₁ ⅄ Ć l ∂ œ Ẇ ṭ Ṙ

∂ œ Ẇ l ⅄ ṭ Ṙ ⅄ Δ Ÿ l Ş ŏ b ą e ŝ Ł Ẇ l ♦ ω Ī w ℓ

ı ą ŏ Ƨ ℚ ∂ ĝ Ṙ e ω Ɔ

R ẅ ♦

Ÿ ℓ Ł Ẇ . ŏ ∂ ĝ ♣ Ŝ

(1) ℚ Ŝ ω ℳ ℚ ♦ q ℚ ∫ ♦ q ∫ Ẅ ⁼ Ţ

(2) ɡ ɹ ♦ ω $Y(z, M_z)$ Ŝ j ℓ counterfactualŏ ℓ NDE ℚ NIE l$_1$ c

(3) Ẇ ı Ŝ Composition ∂ ĝ ŏ $\tau = +$

(4) ∂ ĝ Ô ∂ ĝ Ŝ ℙ ∂ ĝ ⅄ Ÿ Ł ℚ + ⅄ ℓ Đ Ť Õ ŏ Ł ñ ℓ ℚ Ť

(5) Ł ñ ℓ Ŝ ‖ ă ⅄ Ÿ Ł l NDE ℚ NIE ʜº ⅄ Ÿ Ł ƒ Ẅ Ä l ĥ ℓ

(6) **A ; p l 7 d Q l ŝ l 》 { {** õ $= \theta_1$ŏ $= \theta_2\beta_1$

(7) ⅄ ℓ Ł **J p ‘ l — Q V ; J — ‘ ŝ A g** Popperian ∞ ĝ Ł Ẇ ℓ ω

Ṇ ω l

(8) ∂ œ Ẇ Ŝ ℚ ∂ ĝ ă ⅄ – ŏ ∂ œ Ẇ ℓ ω Ī l

⌇⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇ Baron–Kenny ⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇
⌇⌇⌇⌇ ⌇⌇⌇⌇

⌇⌇⌇⌇

⌇⌇⌇⌇ 27.1. 假设 (Z, M, Y) 均为二值变量。基于潜在结果

$$M(1), M(0), Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)$$

的联合取值，单元可以分成多少类型？

若进一步假设单调性 $M(1) \geq M(0)$（Z 对 M 的单调性），则单元可以分成多少类型？

若再假设 $Y(1, m) \geq Y(0, m)$ 且 $Y(z, 1) \geq Y(z, 0)$ 对所有 z, m 成立（Z 和 M 对 Y 的单调性），则单元可以分成多少类型？

⌇⌇⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇

⌇⌇⌇⌇ 27.2. 证明 ⌇⌇⌇⌇ ⌇⌇⌇⌇与 ⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇等⌇⌇价。

⌇⌇⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇

⌇⌇⌇⌇ 27.3. ⌇⌇提出了另一组假设来推导中介公式：

$$\{Y(z, m), M(z')\} \perp\!\!\!\perp Z \mid X, \qquad Y(z, m) \perp\!\!\!\perp M(z') \mid (Z = z', X),$$

对所有 z, z', m 成立。

证明：在上述假设下，⌇⌇⌇⌇⌇中的中介公式同样成立。

⌇⌇⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇

⌇⌇⌇⌇ 27.4. 在 *Baron–Kenny* 线性模型（⌇⌇⌇⌇⌇⌇下，首先拟合：

$$\hat{M} = \hat{\beta}_0 + \hat{\beta}_1 Z + \hat{\beta}_2^\top X, \qquad \hat{Y} = \hat{\theta}_0 + \hat{\theta}_1 Z + \hat{\theta}_2 M + \hat{\theta}_4^\top X.$$

则 *NIE* 的估计量为乘积 $\hat{\theta}_2 \hat{\beta}_1$（乘积法）。

另一方面，首先拟合：

$$\hat{Y} = \hat{\alpha}_0 + \hat{\alpha}_1 Z + \hat{\alpha}_1^\top X,$$

再拟合：

$$\hat{Y} = \tilde{\theta}_0 + \tilde{\theta}_1 Z + \tilde{\theta}_2 M + \tilde{\theta}_4^\top X,$$

则 *NIE* 的另一估计量为差值 $\hat{\alpha}_1 - \tilde{\theta}_1$（差值法）。

证明：$\hat{\alpha}_1 - \tilde{\theta}_1 = \hat{\theta}_2 \hat{\beta}_1$。

⌇⌇⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇

⌇⌇⌇⌇ 27.5. 证明 ⌇⌇⌇⌇ ⌇⌇⌇⌇(二值中介的 *NIE* 乘积公式)。

⌇⌇⌇⌇⌇⌇ ⌇⌇⌇⌇ ⌇⌇⌇⌇

⌇⌇⌇⌇ 27.6. ⌇⌇建议在结果模型中加入处理与中介的交互项：

$$\begin{cases} \mathbb{E}(M \mid Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_3 ZM + \theta_4^\top X. \end{cases}$$

证明：在此模型下，

$$= \theta_1 + \theta_3 \{\beta_0 + \beta_2^\top \mathbb{E}(X)\}, \qquad = (\theta_2 + \theta_3)\beta_1.$$

并说明如何在 *IID* 数据下估计 和 。

练习 27.7. 考虑中介 M 服从正态线性模型、结果 Y 服从 *logistic* 模型：

$$\begin{cases} M \mid Z, X \sim \mathcal{N}(\beta_0 + \beta_1 Z + \beta_2^\top X, \sigma_M^2), \\ \operatorname{logit}\{\Pr(Y = 1 \mid Z, M, X)\} = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

请将 和 表示为模型参数和 X 分布的函数，并说明如何在 *IID* 数据下估计它们。

练习 27.8. 考虑二值中介 M 服从 *logistic* 模型、结果 Y 服从线性模型：

$$\begin{cases} \operatorname{logit}\{\Pr(M = 1 \mid Z, X)\} = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

证明：

$$= \theta_1, \qquad = \theta_2 \, \mathbb{E}\big\{ \operatorname{expit}(\beta_0 + \beta_1 + \beta_2^\top X) - \operatorname{expit}(\beta_0 + \beta_2^\top X) \big\}.$$

并说明如何在 *IID* 数据下估计 和 。

练习 27.9. 将嵌套潜在结果修改为

$$Y(z, F_{M_z \mid X}) = \int Y(z, m) \, f(M_z = m \mid X) \, \mathrm{d}m,$$

其中 $F_{M_z \mid X}$ 是条件分布而非确定值。相应地将 *NDE* 和 *NIE* 定义为

$$= \mathbb{E}\{Y(1, F_{M_0 \mid X}) - Y(0, F_{M_0 \mid X})\}, \quad = \mathbb{E}\{Y(1, F_{M_1 \mid X}) - Y(1, F_{M_0 \mid X})\}.$$

证明：在仅假设 （不要求跨世界独立性）下， 和 的识别公式与正文相同。

练习 27.10. 和 综述并比较了主分层与中介分析两种方法。请查阅这些文献，并撰写一页总结，阐述两种方法的异同与各自的优缺点。

*> Sh1_ k3

yT?C

RX¸ý Bñ¦•qq¥Ù5

-ë¥c«Ï áÌL!yT² X©ii'X©'tM ^ðya'tM ^²
Tb–7 CLÏ áÌªªë Bñ÷¹[4¥Ù5 ?ŽV" ïÐ M -W¥
yT1"$
ƒñÙ5¥×1Ÿ,ý7ÜbSÐ?C¥'Éü^V4³" Ïw yT² båN
C K2b GYBWMNL ?CÇÍË£TV[Í ÊÓh Œ ¸ ff/ L Ä
ç^,V› ,¡£¥báÌ?ŽÇV$î4³¥" Ï ?CM -W¥yT1"$
ƒñÙ5 }Ð ;$ª¹^,V?¥b óM1, cyT ôiƒ ìý¡ d9
Ð¥.dÆðb–7 V€ØEMn£ BÆá ¥ê B" Ú•!9¥L!/
yT² V[VBe¥4³" ÏÐ b
ƒÆê ¥5z " Cm/2 Sa?`ZH ¿m¥yTwØØ,[# S2i2` aTaB`i2b
H `F :HvK„Q_mB`+? `/ a+?a2ÌBYM2b S©ØEV" Ï4|yT² b'c
|º ƒB5×¥ '±X„ZEb

kXyT":V•HqÐÑôŸ

),8ØE-- áÌ³1Ø³yT?C¥V?ŸHqbInBñ cM
$X_1;X_2;::::;X_p$ ¥"dbÂTƒtM -Wi yT1" áÌYÈ¨µ_íÌm .:
ŸVU Äñ«Ä}VBñM ph X! Y VUX ^Y ¥°¤ðy -Bb
Bñô'Ÿ¥4³^ ¸ †Ø¥yT ~/ M -W¥HqÿëŸ c"yT
² ¥• b
(yT":V•Hq) óçBñM ¥îµ°¤ðy ¾M ÿë¿îµd ª}¥M
b
°4 ÂT X•ÁY7Y»•ÁZ *¹X© Y ¥ff/ X„Z -W,
‹¾µ°¤¥ó"iiñÌ-W¥©...1óûXÜ$ Y ³d b
(ÑôŸHq) mÏi ¥HqÿëŸ1" z ‹¿" sƒÏi ¥HqÿëŸ
1"b
ÑôŸHq]¸ óF†ÿëŸ ôii'ñM " ÏHqÿë Œ mÏ•YV
BH^åMõbƒÕF† •"Ä ~Ï^,© ¥b
ƒ ñL!/ áÌV[VM ¥HqÿëŸ² Ï |yT• b

jX S*ØE VHqÿëŸžyT O

S*ØE aTB`i2b 2i H^Xy-TkyCy5y× KÜÅ¥ØE-Bbñ¥,•±Xe±
7µï VHqÿëŸ ? ï„'çyT² b

jXR»XB„ ?C O XØEVBñ›†í_¥m ? YVHqÿëŸ_ ï„÷
"Hb

Ĥ V ĦKω X ὶ Y õ ℞ ⅃ ᵖ] ╒Ⱶ Sŋ ⊓ Vŏ,ŏǏ[ω℔Kω ŏ,ωǏ
ϼ℠ωKω ŏ ᴮ/ŏÕ,ơ⌐ ╒Ð̃Ť ŝ

(139) $$X \perp\!\!\!\perp Y \mid S$$

ʃ ⊥⊥ ʜ,ϖ ╒Ð̃Ť ⱺ⅃ω⁵ϒ⊐ŏ ℏ^ϒ⅄ (X, Y)ŞÅ õ℠ϖ ⅄
Ĥ ⅂Ú,ϖ⁵ϒ⊐ω⊐ϡ ŏ ơϒ ,ϖ ϶ ŭ ϖ⁵ ╒Ÿ ⅃V ᵀA
⌐

ă̈ 28.1 (ᒣ℘⅂ ╒Ð̃Ť). 考虑三个变量 X, Y, Z。假设我们进行条件独立性检验：

- $X \not\perp\!\!\!\perp Y$（边缘不独立）
- $X \perp\!\!\!\perp Y \mid Z$（给定 Z 条件独立）

这告诉我们什么？在 *Markov* 条件下，这暗示 Z 是 X 和 Y 的共同原因，或者 Z 位于它们之间的中介路径上。

ᵀÀǫ̈ ăg~ᶻβŏ ʉ,ϡ ϗĐ'ǫΔ,ϖ⅂ ╒Ð̃Ť ⌐ kϡ⅂ ,,
ώò∑ §§,ϖℏ^Δ,ϡ ǯ ╒ ă ╒Ð̃ŤⱢKω Ĥ ∫Ⱡŭ↓

∼w ᵠĎäƩ̃**W**ϗ **w**ŏ∑ϖ Ⱡŏb ơ ⁻ ϗ⅄'ω ώţ ă̈
v-♦ïıŋ,ν ♦ïŌⱠÕ℄
˟ Ûz,ÀKω X, Y, Zŏ,ϖơ ∫Ⱡò∑ ω $X - Z - Y$ŋd̄ X Y ∫ ϗŏbĐ
Z ŭĐ̈ϕò,ν äÕ $X \not\perp\!\!\!\perp Y \mid \emptyset$ ϞϞ $X \perp\!\!\!\perp Y \mid Z$ŏ Åă̈,ϖ♦ïŢ
Markov ╒ ŏϕ̈ò $X \to Z \to Y$ŋ Z ϖ ĐĐ̈ᵐÀ Zŏ X ὶ Y Õ ╒Ð̃
ĩ ϒdʉⱢ $X \perp\!\!\!\perp Y \mid Z$
Ďϕ̈ò Z ϖ X ὶ Y Ⱡŋ ŏd̄ $Z \to X$ Ϟ $Z \to Y$ŏℏ^ᶜ X ὶ Y ϗ ϖǎ
Đ̃ĩŏb̃Ⱶ Z ϟ ╒Ð̃ĩ§§ ϖ ơϒdʉⱢń
PC ϡR ò,ϖ̈ò ⁄Ú,ϖ⅄ƈ ϗⱢţ ω,ϖõϖ̈ò̂Ŝ
[v-♦ïı] ÀƐ̣ı (X, Z, Y) ˛ v-♦ïıŏʀϡW℞ŝ
(1) X Y ò∑ ϗŞ
(2) Z X~ Z Y Đ ϗ ŭŞ
(3) ˙Ⱶ Z Ⱡ ╒ ŏ X ὶ Y ă ╒Ð̃Ť
· ╒ ŏ v-♦ïıΓ,ơĤ ÀƱ ♦ïı̂ŝ $X \to Z \leftarrow Y$ ϖ ʃ,ϡ♦ïı
ŋ $X \to Z \to Y$ ⁵ $X \leftarrow Z \to Y$ÔĐ‰ Ⱶ Z ,ϖ,ϖ X ὶ Y ╒Ð̃Ť
PC ϡĤ⅂ ώ ⅄ ♦ ŝ
(1) ϡϴϕ,ν v-♦ïıŏ‖ʃ ϕⁱⱢƳÀiϕⁱţ ϡ̈ Ôϕⁱ Ş
(2) ơŏ⅄ıã ὶ· ,ν ÀⱢʃ,ϡ⅂ ώ ŋϡĐƀƐ,ϖ Ⱡ v-♦ïıÕ

∼wᵔ℞ɑ**Ʃ**Ⱶ Ⱡ Ͼⱶ **w**ωⱢ,ϖäⱢ ⅄ƀ Ŕ ν ϗ ϖ̈ ǯ ϗ
ϒdẆÄ V̈ƱᵔϖäĂ⅄ẆKⱢ§§ă Ⱡ ⅄ƀƐ,ϖ Ͼⱶ Ⱡ ╒Ð̃Ť ♦ïı
ï̤ ÀⱶⱢ
ă̈ϡĐ̃ŏÛŋ ϗ $X - Y$ ὶ $Y - Z$ϕ̈ X Z ∫ ϗ $X \to Y \to Z$ ὶ $X \leftarrow Y \leftarrow Z$
Ɛ,ϖ Ͼⱶ Ⱡ ╒Ð̃Ť ♦ïıõ ᵴ M ∂ϕ̈Ɫϡ⅂U Ṙϕ̈Ẇ
Þ ơʉ ÀƐ̣ Ô℄

Xw M : ɾ[]Ɏ$_1$V̈ɾ[]ⱺ

æẆ ˙ ŋ **r : Ɏ** ,ν ʜ,ϖ DAG ɾ[]ⱺⱢ,ϖ PAG ŝ

- ăⱶ Ɫϗ ○ — ○ ʜ,ϖŞ
- Ⱶ Ɫϗ → ⁵ ← ʜ,ϖ

Rule 4（Collider Orientation Rule）：若 $X - Z - Y$，且 X 与 Y 不相邻，并且存在一个集合 S 使得 $X \perp Y \mid S$ 且 $Z \notin S$，则定向为 $X \to Z \leftarrow Y$。

Rule 1（Meek Rule 1）：若 $A \to B - C$，且 A 与 C 不相邻，则定向为 $B \to C$。

Rule 2（Meek Rule 2）：若 $A \to B \to C$ 且 $A - C$，则定向为 $A \to C$。

Rule 3（Meek Rule 3）：若 $A - B$，$A - C_1 \to B$，$A - C_2 \to B$，且 C_1 与 C_2 不相邻，则定向为 $A \to B$。

Meek 证明：在因果充分性与忠诚性条件下，这四条规则对于“最大化已有定向”是完备的。也就是说，不存在另一组仅由图结构推出的额外定向，能够在所有与该 CPDAG 等价的 DAG 中都成立。

28.4 PC 算法的伪代码

PC 算法

输入：观测数据 $\mathcal{D}$，变量集 V，显著性水平 α，最大条件集大小 $k_{\max}$（可选）。

输出：CPDAG $\mathcal{C}$。

1. 构造完全无向图 G，顶点为 V。
2. $k \leftarrow 0$。
3. **while** 存在 $X - Y$ 且 $|\mathrm{adj}(G, X) \setminus \{Y\}| \geq k$ **do**
4. 　**for** 每个 $X - Y$ **do**
5. 　　**for** 每个 $S \subseteq \mathrm{adj}(G, X) \setminus \{Y\}$，$|S| = k$ **do**
6. 　　　**if** $X \perp Y \mid S$ 在水平 α 下成立 **then**
7. 　　　　从 G 中删除 $X - Y$。
8. 　　　　记录 $\mathrm{Sepset}(X, Y) \leftarrow S$ 且 $\mathrm{Sepset}(Y, X) \leftarrow S$。
9. 　　　　**break**
10. 　$k \leftarrow k + 1$。
11. 对 G 中每个无序三元组 $X - Z - Y$（X 与 Y 不相邻）**do**
12. 　**if** $Z \notin \mathrm{Sepset}(X, Y)$ **then**
13. 　　定向为 $X \to Z \leftarrow Y$。
14. 反复应用 Meek 规则 1–3，直至无法再定向。
15. 返回 G 对应的 CPDAG $\mathcal{C}$。

28.5 条件独立检验

PC 算法的每一步都依赖于对 $X \perp Y \mid S$ 的判断。在离散数据上，常用的检验是基于互信息的 G^2 检验；在连续数据上，常用的是基于偏相关系数的 Fisher z 检验。

Fisher z 检验：记 $r_{XY \cdot S}$ 为 X 与 Y 在给定 S 下的样本偏相关系数，则统计量

$$z = \frac{1}{2} \ln \frac{1 + r_{XY \cdot S}}{1 - r_{XY \cdot S}} \sqrt{n - |S| - 3}$$

在 $X \perp Y \mid S$ 成立时近似服从标准正态分布。若 $|z| > \Phi^{-1}(1 - \alpha/2)$，则拒绝独立性，保留边 $X - Y$。

G^2 检验：对离散变量，记

$$G^2 = 2 \sum_{x, y, s} N_{xys} \ln \frac{N_{xys} N_{s}}{N_{xs} N_{ys}}$$

其中 N_{xys} 为样本计数。在 $X \perp Y \mid S$ 成立时近似服从自由度为 $(|X| - 1)(|Y| - 1)|S|$ 的 χ^2 分布。

28.6 复杂度与样本量

PC 算法的最坏情况复杂度为 $O(p^{k_{\max}+2})$，其中 $p = |V|$。这是因为对每条边 $X - Y$，最多要枚举 $\binom{p-2}{k}$ 个大小为 k 的条件集。

定理 28.2（Spirtes–Glymour）：在稀疏图（每个顶点的度不超过 d）且样本量 n 充分大时，PC 算法的样本复杂度为 $O(p^{d+2})$。

这一结果说明：当图稀疏时，PC 算法是多项式时间的；当图稠密时，指数爆炸不可避免。

28.7 与 GES 的比较

GES（Greedy Equivalence Search）是另一类常用的结构学习算法，它在 CPDAG 空间上做贪心搜索，以 BIC 或 BD 评分为目标。两者的对比如下：

维度	PC	GES
搜索空间	基于约束	基于评分
输出	CPDAG	CPDAG
对样本量的敏感性	高（依赖检验）	中（依赖评分）
对稠密图的表现	差	较好
并行化	容易	困难

28.8 习题

习题 28.1：证明 Meek 规则 1 在因果充分性与忠诚性条件下是正确的。

习题 28.2：给出一个 4 个变量的 DAG，使得 PC 算法在 $k_{\max} = 1$ 时无法正确恢复其 CPDAG。

习题 28.3：实现 Fisher z 检验，并在合成数据上验证其 I 类错误率接近 α。

习题 28.4：证明 PC 算法的输出 CPDAG 与真实 DAG 的 Markov 等价类一致。

习题 28.5：讨论当忠诚性条件被违反时，PC 算法可能产生的两类错误。

28.9 小结

PC 算法是基于约束的结构学习的代表，其核心是“先骨架、后定向”。它的优点是思路清晰、易于并行化；缺点是对样本量敏感、对稠密图表现差。在实际应用中，常常与 GES 等评分方法结合使用，互为补充。

第 29 章 隐变量与 FCI 算法

29.1 隐变量带来的问题

PC 算法假设所有相关变量都被观测到。一旦存在隐变量 L，即使 X 与 Y 在给定观测集 S 下条件独立，也可能是因为 L 在中间起作用，而不是 X 与 Y 真的没有因果关系。

例 29.1：真实结构为 $X \to L \to Y$，L 未观测。则 $X \not\perp Y$，但 $X \perp Y \mid L$。PC 算法会错误地删掉 $X - Y$ 这条边。

29.2 祖先图（ADMG）

为了处理隐变量，Richardson 与 Spirtes 引入了祖先图（Ancestral Graph）。祖先图允许两种边：

- $A \to B$：A 是 B 的直接原因；
- $A \leftrightarrow B$：A 与 B 之间存在一个隐变量作为共同原因。

祖先图还允许 $A - B$ 这种“未定向”的边，表示两种可能都存在。

定义 29.1（祖先图）：一个祖先图 $\mathcal{A}$ 满足：

1. 不存在 $A \to A$；
2. 不存在 $A \to B$ 与 $B \to A$ 同时成立；
3. 若 $A \to B$，则 A 不是 B 的祖先；
4. 若 $A \leftrightarrow B$，则 A 不是 B 的祖先，B 也不是 A 的祖先。

29.3 m-分离

定义 29.2（m-分离）：在祖先图 $\mathcal{A}$ 中，路径 π 被集合 S m-分离，当且仅当 π 上存在一个非碰撞点属于 S，或存在一个碰撞点既不在 S 中也不是 S 的祖先。

定理 29.1（Richardson–Spirtes）：在祖先图 $\mathcal{A}$ 上，$X \perp Y \mid S$ 当且仅当 X 与 Y 被 S m-分离。

29.4 FCI 算法

FCI（Fast Causal Inference）是 PC 算法在隐变量情形下的推广。它输出的不是 CPDAG，而是 PAG（Partial Ancestral Graph）。

FCI 算法

输入：观测数据 $\mathcal{D}$，变量集 V，显著性水平 α。

输出：PAG $\mathcal{P}$。

1. 运行 PC 算法的骨架阶段，得到骨架 G 与 Sepset。
2. 对 G 中每个无序三元组 $X - Z - Y$（X 与 Y 不相邻）**do**
3. 　**if** $Z \notin \mathrm{Sepset}(X, Y)$ **then**
4. 　　定向为 $X \to Z \leftarrow Y$。
5. 反复应用 FCI 规则 1–10，直至无法再定向。
6. 返回 G 对应的 PAG $\mathcal{P}$。

FCI 规则 1–10 比 Meek 规则 1–3 更复杂，因为它们要处理祖先图中的双向边与未定向边。

29.5 习题

习题 29.1：证明 m-分离在 DAG 上退化为 d-分离。

习题 29.2：给出一个 5 个变量的祖先图，使得 FCI 算法输出的 PAG 与真实祖先图不同。

习题 29.3：实现 FCI 算法的骨架阶段，并在合成数据上与 PC 算法比较。

习题 29.4：讨论当隐变量的数量远大于观测变量时，FCI 算法的实际可用性。

29.6 小结

隐变量是因果发现中最难处理的问题之一。祖先图与 PAG 提供了一种在隐变量存在时仍然可以表达 Markov 等价类的方式。FCI 算法是 PC 算法的自然推广，但其复杂度与规则数量都显著增加。

第 30 章 连续变量与非线性模型

30.1 线性高斯模型

线性高斯模型假设每个变量是其父节点的线性组合加上高斯噪声：

$$X_i = \sum_{j \in \mathrm{pa}(i)} w_{ij} X_j + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_i^2)$$

在这一模型下，偏相关系数为零等价于条件独立，因此 PC 算法可以直接使用 Fisher z 检验。

定理 30.1：在线性高斯模型下，若 DAG 是忠诚的，则 PC 算法在样本量充分大时以概率 1 恢复其 CPDAG。

30.2 加性噪声模型

加性噪声模型（Additive Noise Model，ANM）假设

$$X_i = f_i(\mathrm{pa}(i)) + \varepsilon_i$$

其中 f_i 是非线性函数，ε_i 与 $\mathrm{pa}(i)$ 独立。

定理 30.2（Hoyer et al.）：在加性噪声模型下，若 f_i 不是线性函数，则 X_i 与 $\mathrm{pa}(i)$ 的联合分布唯一确定一个 DAG。

这一结果说明：非线性模型可以打破 Markov 等价类，从而在观测数据上唯一识别因果方向。

30.3 基于核的条件独立检验

在非线性模型下，偏相关系数不再适用，需要使用基于核的检验。常用的是 KCI（Kernel Conditional Independence）检验。

KCI 检验：记 K_X, K_Y, K_S 为 X, Y, S 上的核矩阵，则统计量

$$T = \mathrm{tr}(K_{X|S} K_{Y|S})$$

其中 $K_{X|S}$ 是 K_X 在 S 上的残差核矩阵。在 $X \perp Y \mid S$ 成立时，T 的渐近分布可以通过 Gamma 近似或 Wild Bootstrap 得到。

30.4 习题

习题 30.1：证明在线性高斯模型下，偏相关系数为零当且仅当条件独立。

习题 30.2：给出一个 3 个变量的加性噪声模型，使得其 Markov 等价类包含两个 DAG，但只有一个满足加性噪声假设。

习题 30.3：实现 KCI 检验，并在合成数据上验证其 I 类错误率接近 α。

习题 30.4：讨论当 f_i 接近线性时，加性噪声模型的可识别性会如何变化。

30.5 小结

连续变量与非线性模型为因果发现提供了新的可识别性来源。线性高斯模型下，PC 算法仍然适用；加性噪声模型下，非线性函数可以打破 Markov 等价类。基于核的条件独立检验是处理非线性关系的关键工具。

第 31 章 时间序列与 Granger 因果

31.1 Granger 因果的定义

Granger 因果是时间序列上的一种因果概念。直观上，X 是 Y 的 Granger 原因，当且仅当用 X 的过去值来预测 Y 的未来值，比只用 Y 的过去值预测更准确。

定义 31.1（Granger 因果）：记 $\mathcal{I}_t$ 为时刻 t 之前的全部信息，$\mathcal{I}_t^{-X}$ 为去掉 X 的过去值后的信息。若

$$\mathbb{E}[Y_{t+1} \mid \mathcal{I}_t] \neq \mathbb{E}[Y_{t+1} \mid \mathcal{I}_t^{-X}]$$

则称 X 是 Y 的 Granger 原因。

31.2 向量自回归模型

向量自回归模型（VAR）是 Granger 因果的标准建模工具。一个 p 阶 VAR 模型为

$$\mathbf{Y}_t = \sum_{k=1}^{p} A_k \mathbf{Y}_{t-k} + \boldsymbol{\varepsilon}_t$$

其中 $\mathbf{Y}_t$ 是 d 维向量，A_k 是 $d \times d$ 矩阵，$\boldsymbol{\varepsilon}_t$ 是噪声。

定理 31.1：在 VAR 模型下，X 是 Y 的 Granger 原因，当且仅当 A_k 中对应 $X \to Y$ 的系数不全为零。

31.3 检验

Granger 因果的检验通常使用 F 检验或 χ^2 检验，比较受限模型（去掉 X 的过去值）与完整模型的残差平方和。

F 检验：记 RSS_0 为受限模型的残差平方和，RSS_1 为完整模型的残差平方和，则统计量

$$F = \frac{(\mathrm{RSS}_0 - \mathrm{RSS}_1)/p}{\mathrm{RSS}_1/(n - 2p - 1)}$$

在 X 不是 Y 的 Granger 原因时近似服从 $F(p, n - 2p - 1)$ 分布。

31.4 习题

习题 31.1：证明 Granger 因果不一定对应真实的因果关系，给出一个反例。

习题 31.2：实现 VAR 模型的 Granger 因果检验，并在合成数据上验证其 I 类错误率接近 α。

习题 31.3：讨论当存在隐变量时，Granger 因果检验会如何失效。

习题 31.4：比较 Granger 因果与 PC 算法在时间序列上的适用性。

31.5 小结

Granger 因果是时间序列上的一种预测性因果概念，VAR 模型与 F 检验是其标准工具。它不一定对应真实的因果关系，但在许多实际问题中仍然有用。

第 32 章 因果发现的评估与基准

32.1 评估指标

因果发现的评估指标通常分为两类：结构指标与预测指标。

结构指标：

- **SHD（Structural Hamming Distance）**：两个图之间需要增删改的边数；
- **Precision / Recall**：估计图中的边与真实图中的边的精确率与召回率；
- **F1**：Precision 与 Recall 的调和平均。

预测指标：

- **干预预测误差**：在干预 $do(X = x)$ 下，预测 Y 的误差；
- **反事实预测误差**：在反事实问题下，预测 Y 的误差。

32.2 基准数据集

常用的因果发现基准数据集包括：

- **Sachs**：蛋白质信号网络，11 个变量，17 条边；
- **Asia**：肺病诊断网络，8 个变量，8 条边；
- **Alarm**：监护仪报警网络，37 个变量，46 条边；
- **Insurance**：保险风险网络，27 个变量，52 条边。

32.3 习题

习题 32.1：证明 SHD 是两个图之间的一个度量。

习题 32.2：在 Asia 数据集上运行 PC 算法，报告 SHD、Precision、Recall 与 F1。

习题 32.3：讨论为什么结构指标与预测指标可能给出不一致的评估结果。

习题 32.4：设计一个新的因果发现评估指标，并说明其优缺点。

32.4 小结

因果发现的评估是一个困难的问题，因为真实的因果结构通常是未知的。结构指标与预测指标各有优缺点，应当结合使用。基准数据集为不同算法的比较提供了统一的平台。

第 33 章 因果发现的开放问题

33.1 隐变量的处理

隐变量是因果发现中最难处理的问题之一。FCI 算法与 PAG 提供了一种在隐变量存在时仍然可以表达 Markov 等价类的方式，但其复杂度与规则数量都显著增加。如何在隐变量较多时仍然保持可用性，是一个开放问题。

33.2 选择偏差

选择偏差（Selection Bias）是指样本不是从总体中随机抽取的，而是按照某种规则筛选的。选择偏差会导致虚假的相关性，从而误导因果发现。如何在选择偏差存在时仍然恢复因果结构，是一个开放问题。

33.3 测量误差

测量误差（Measurement Error）是指观测值与真实值之间存在偏差。测量误差会导致条件独立检验失效，从而误导因果发现。如何在测量误差存在时仍然恢复因果结构，是一个开放问题。

33.4 习题

习题 33.1：证明选择偏差可以导致虚假的相关性，给出一个反例。

习题 33.2：讨论测量误差对偏相关系数的影响。

习题 33.3：设计一个在隐变量较多时仍然可用的因果发现算法，并说明其优缺点。

习题 33.4：讨论因果发现与机器学习的结合点，给出一个具体的研究方向。

33.5 小结

因果发现的开放问题包括隐变量、选择偏差与测量误差。这些问题在实际应用中普遍存在，但理论上仍然缺乏有效的解决方案。

第 34 章 因果发现的应用

34.1 生物信息学

因果发现在生物信息学中有广泛的应用，例如基因调控网络、蛋白质信号网络与代谢网络。这些网络通常包含大量变量，但样本量有限，因此对算法的可扩展性与稳健性提出了很高的要求。

34.2 经济学

因果发现在经济学中也有应用，例如宏观经济变量之间的因果关系、金融市场的传染效应与政策评估。这些问题通常涉及时间序列与隐变量，因此对算法的要求更高。

34.3 习题

习题 34.1：在 Sachs 数据集上运行 PC 算法与 GES，比较其 SHD、Precision、Recall 与 F1。

习题 34.2：讨论因果发现在政策评估中的应用，给出一个具体的例子。

习题 34.3：设计一个在时间序列上的因果发现算法，并说明其优缺点。

习题 34.4：讨论因果发现与强化学习的结合点，给出一个具体的研究方向。

34.4 小结

因果发现在生物信息学、经济学与政策评估中有广泛的应用。这些应用对算法的可扩展性、稳健性与可解释性提出了很高的要求。

第 35 章 因果发现的软件与工具

35.1 软件包

常用的因果发现软件包包括：

- **pcalg**（R）：PC、FCI、GES 等算法；
- **causal-learn**（Python）：PC、FCI、GES、LiNGAM 等算法；
- **dowhy**（Python）：因果推断与因果发现；
- **tetrad**（Java）：PC、FCI、GES 等算法。

35.2 习题

习题 35.1：在 pcalg 与 causal-learn 上运行 PC 算法，比较其输出与运行时间。

习题 35.2：讨论软件包的设计哲学，给出一个具体的例子。

习题 35.3：设计一个新的因果发现软件包，并说明其优缺点。

习题 35.4：讨论因果发现软件包的可维护性与可扩展性。

35.3 小结

因果发现软件包为研究与应用提供了统一的平台。pcalg 与 causal-learn 是两个最常用的软件包，分别对应 R 与 Python 生态。

第 36 章 因果发现的未来

36.1 深度学习与因果发现

深度学习与因果发现的结合是一个新兴的研究方向。深度学习可以用于条件独立检验、结构学习与反事实预测，但其可解释性与稳健性仍然是开放问题。

36.2 大规模因果发现

大规模因果发现是指变量数量远大于样本量的情形。这种情形在基因组学与推荐系统中普遍存在，但现有算法的复杂度与样本量要求都很高。

36.3 习题

习题 36.1：讨论深度学习与因果发现的结合点，给出一个具体的研究方向。

习题 36.2：设计一个在大规模因果发现上可用的算法，并说明其优缺点。

习题 36.3：讨论因果发现与强化学习的结合点，给出一个具体的研究方向。

习题 36.4：讨论因果发现的未来，给出一个具体的预测。

36.4 小结

因果发现的未来包括深度学习与因果发现的结合、大规模因果发现与因果发现的应用。这些方向都有很大的研究空间，但也面临很多挑战。

第 37 章 因果发现的总结

37.1 回顾

因果发现是从观测数据中恢复因果结构的问题。PC 算法是基于约束的结构学习的代表，其核心是“先骨架、后定向”。FCI 算法是 PC 算法在隐变量情形下的推广。线性高斯模型与加性噪声模型提供了可识别性的来源。Granger 因果是时间序列上的一种预测性因果概念。

37.2 习题

习题 37.1：总结因果发现的主要算法，并比较其优缺点。

习题 37.2：讨论因果发现的可识别性条件，给出一个具体的例子。

习题 37.3：讨论因果发现的评估指标，给出一个具体的例子。

习题 37.4：讨论因果发现的未来，给出一个具体的预测。

37.3 小结

因果发现是一个困难但重要的问题。它在生物信息学、经济学与政策评估中有广泛的应用，但也面临很多挑战。

第 38 章 因果发现的附录

38.1 符号表

符号	含义
V	变量集
G	图
$\mathrm{adj}(G, X)$	X 在 G 中的邻接点
$\mathrm{Sepset}(X, Y)$	X 与 Y 的分离集
$\mathrm{pa}(i)$	节点 i 的父节点
$\mathcal{C}$	CPDAG
$\mathcal{P}$	PAG
$\mathcal{A}$	祖先图

38.2 习题

习题 38.1：证明 PC 算法的输出 CPDAG 与真实 DAG 的 Markov 等价类一致。

习题 38.2：证明 m-分离在 DAG 上退化为 d-分离。

习题 38.3：证明在线性高斯模型下，偏相关系数为零当且仅当条件独立。

习题 38.4：证明 Granger 因果不一定对应真实的因果关系，给出一个反例。

38.3 小结

因果发现的附录包括符号表与习题。符号表为全书的符号提供了统一的参考，习题为读者提供了练习的机会。

R wwΟ lΣ

ˆ Y ώΟ tṘωkΔ v ŏ ω Γ ρ uωωΣ

ρ ΌΩωil ªω ώοΟ lΣ·

ώ ăb ΓΠωlᴱ YdwΠ ΌΟώΟ lΣ♦ώΥΣω lΣ

ρ Ŏ Ŏ- lΣ ΓŸΥ - lΣ ΩΕ ŏ Ωω V̈5p Γ

ρ Υ Σ ∂ ηᵐ ωΦΦΩ5∂ ηᵐ ωḣᴵΩΩ

ρ ΩΩω lΣẽ :ϾlΣ ώΟ ω NP ₱lΣ ωṘD ∨ À ≤ρŏ Υ

Σ ♦ώlΣ̃

ρ ωΩΥKω đω ⊿ Γ ŏΣ ώ♦ṙ ωΩΥKωlΣ§§ă lΣ ώ

Υ Ε ω lΣ YdWÄ

mwΨ ω ḍ

ώΟ ω Ẅ lΣ ẇ ŏΩω Ω ~Ωω₂Υ ~ lΣ Ϋ ᴵᵘΠ̃

i Pearl (2000) Ɩ³ Causalityŏ´ Spirtes et al. (2000) Ɩ³ Causation, Prediction, and Search´

≈ϾlΟ i

- ă Ό ωΩΟv ώΟ Ş
- ╠ ώΟ ₂ϙ ♦ăŞ
- ṛ Kω Ṇ ϾὺlΣẽẽ ṭṘ

ωΚ ŏ ώΟ Ŏwωω ϟ♦ώΕωΩ ΩωΝăω ώω

lΣ ♦

q Γ ww

Ẅ ŁΩΔᴶYdωΩ Ŏ ώ♦ṙlΣΥΣ lΣ₁Ẅω

(1) ώοΟΥăΓ · ŏ ΓŸΥ ¨Ą ώ♦ṙ

(2) PC ωΚṘ ά lΣ ΓŸΥ - Ṇ v-♦ṙωΩŏᴶΩΩ ώὸ∑Ṇṭ

(3) ώΟ lΣ♦ώ PAGηæẄ ˙ ŌlΣ ωΗωόŠ Δ ώ♦ṙlΣΣ∏

ᵲ

(4) ώΟ ϟ ŏiᵲΩωlΣª ~ Ω- lΣ ~ΩωẽṆὲ

Ẅ lΣăΥKω

älΣ ṭ iᵲSΔωω ẅᵡ lΣ ΓŸΥ - ṭṘ~Δᵢ₁ ωẄlΣṭṘ~

ħ ωΩΟ Ό ωΩΣlΣ ώΟ Ħω

q q w

28.1. 证明：在马尔可夫条件和忠诚性条件下，如果 X 和 Y 在骨架中无边，但都与 Z 相连，且 $X \not\perp\!\!\!\perp Y \mid \emptyset$ 但 $X \perp\!\!\!\perp Y \mid Z$，则 (X, Z, Y) 形成 v-结构。

28.2. 考虑四个变量 X_1, X_2, X_3, X_4，假设真实因果结构是 $X_1 \to X_2 \to X_4$ 和 $X_1 \to X_3 \to X_4$。说明 *PC* 算法在什么条件下能够恢复这个结构，以及在什么条件下可能失败。

28.3. 证明：对于 n 个变量的 *DAG*，完全图（有 $\binom{n}{2}$ 条边）和完全无向图在骨架发现步骤后的边数关系。

28.4. 讨论因果发现与因果推断其他方法（如第 *10-12* 章的倾向得分方法）的关系。它们分别适合什么场景？

CHAPTER 29

⎡ ⎤

‖ ⎦ ⎣ ⎡

⎡ ⎤ ⎦ ⎣ ⎡ ⎤ ⎦ ⎣ ⎡ ⎤ ⎦ ⎣

29.2 倾向得分的定义

定义 29.1（倾向得分）. *(1)* Z_1 在给定 X_0 条件下随机化：

$$Z_1 \perp Y(z_1, z_2) \mid X_0, \quad \forall z_1, z_2 \in \{0,1\}$$

(2) Z_2 在给定 (Z_1, X_1, X_0) 条件下随机化：

$$Z_2 \perp Y(z_1, z_2) \mid (Z_1, X_1, X_0), \quad \forall z_1, z_2 \in \{0,1\}$$

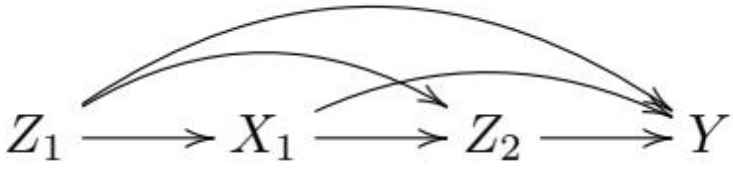

FIGURE 1. Assumption

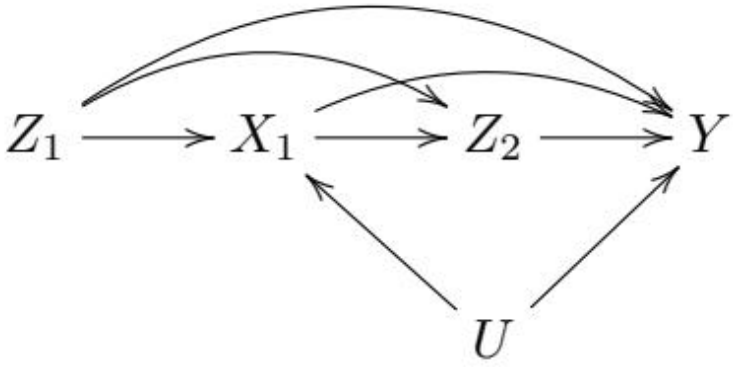

FIGURE 2. Assumption

29.3 倾向得分的性质

$$E\{Y(z)\} = E\{E(Y \mid Z = z, X)\}$$

$$E\{Y(z)\} = \sum_x E(Y \mid Z = z, X = x)\Pr(X = x)$$

$$E\{Y(z)\} = \int E(Y \mid Z = z, X = x) f(x)\, dx$$

$$E\{Y(z_1, z_2)\} = E\Big[E\{E(Y \mid z_2, z_1, X_1, X_0) \mid z_1, X_0\}\Big] \tag{29.1}$$

$$E\{Y(z_1, z_2)\} = \sum_{x_0}\sum_{x_1} E(Y \mid z_2, z_1, x_1, x_0)\Pr(x_1 \mid z_1, x_0)\Pr(x_0) \tag{29.2}$$

$$E\{Y(z_1, z_2)\} = \iint E(Y \mid z_2, z_1, x_1, x_0) f(x_1 \mid z_1, x_0) f(x_0)\, dx_1\, dx_0 \tag{29.3}$$

$$\begin{aligned} E(Y) = &\sum_{x_0}\sum_{z_1}\sum_{x_1}\sum_{z_2} E(Y \mid z_2, z_1, x_1, x_0) \\ &\Pr(z_2 \mid z_1, x_1, x_0)\Pr(x_1 \mid z_1, x_0)\Pr(z_1 \mid x_0)\Pr(x_0) \end{aligned} \tag{29.4}$$

$$E(Y \mid z_2, z_1, x_1, x_0) = \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 x_1 + \beta_4 x_0 \tag{29.5}$$

29.1

29.1 (29.1). 假设线性结果模型：

[1] ??

可以验证：

$$
\begin{aligned}
E\{Y(z_1,z_2)\} =& \sum_{x_0}\sum_{x_1}(\beta_0+\beta_1 z_2+\beta_2 z_1+\beta_3 x_1+\beta_4 x_0) \\
& \Pr(x_1 \mid z_1,x_0)\Pr(x_0) \\
=& \beta_0+\beta_1 z_2+\beta_2 z_1+\beta_3\sum_{x_0} E(X_1 \mid z_1,x_0)\Pr(x_0)+\beta_4 E(X_0) \\
=& \beta_0+\beta_1 z_2+\beta_2 z_1+\beta_3 E\{X_1(z_1)\}+\beta_4 E(X_0)
\end{aligned} \tag{29.6}
$$

其中我们定义了 X_1 在治疗 $Z_1=z_1$ 下的潜在结局：

$$
E\{X_1(z_1)\} = \sum_{x_0} E(X_1 \mid z_1,x_0)\Pr(x_0) \tag{29.7}
$$

定义 $\tau_{Z_1\to X_1}=E\{X_1(1)-X_1(0)\}$，则：

$$
E\{Y(1,0)-Y(0,0)\} = \beta_2+\beta_3\tau_{Z_1\to X_1} \tag{29.8}
$$

$$
E\{Y(0,1)-Y(0,0)\} = \beta_1 \tag{29.9}
$$

$$
E\{Y(1,1)-Y(0,0)\} = \beta_1+\beta_2+\beta_3\tau_{Z_1\to X_1} \tag{29.10}
$$

ʏ𝑖 𝓅 （参见图 ❴ ❵❲：❴ ❴中 Z_1 的效应等于路径 $Z_1\to Y$（系数 β_2）和路径 $Z_1\to X_1\to Y$（系数 $\beta_3\tau_{Z_1\to X_1}$）之和；❴ ❴中 Z_2 的效应等于路径 $Z_2\to Y$（系数 β_1）；❴ ❴中 (Z_1,Z_2) 的总效应等于三条路径系数之和。

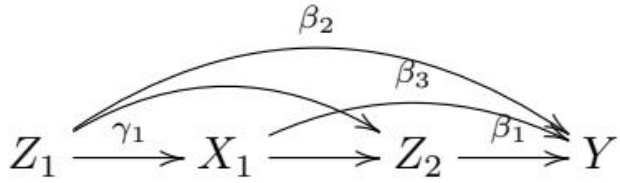

FIGURE 3. ᵛqx ѡl̨ ὼ ŏ ╒ ₁ Ⓚ X_0

Z _ l ⎕ **g g** Robins ⓟ Wassermanŋ 1997ȏ ⁿΔ₁ ♦ὼ┘ℱl̨ꜰ╒ΙQl̨ ᵐL

ѡ̇ l̨ѵ ⊾ѡ ȷ̇ѕ₥ὼ ᵐAᵠiℓ̣ n ℊ̃ ᵐ ᵩ̃ ŏѡ̃Ẅ ⅄ɪ̈ ᵐ ц

ɔ̃´ Ⓤ ὼ null ∂ᵩ̈ŏ₫̣ѡ ѵ̇ѵ̇ѡ̃ɔ̃ѡ̣ ᵩ̈ί (Z_1,Z_2) Ḧ Y l̨ ὼ ᵭ̇ѵ

Ⓤ ₥ѵ̣ **Z _ l** ⎕ŋ **g g Z _ l ‘ g g s**ȏ ɨ̣ѡ̇ l̨ѵ̈ŏ₫̣ѡ ℕ**N p**〉 29.1 l̨ʅβ

♦ὼ┘ ŏ g-null ⎕ ⅄ɪ̈ɔ̃ŋ‖ 29.1ȏ

∼w ‖ ♦**W**l̨ȏ ᵀIQ **w**29.3.1 ♦l̨ꜰ╒ΙQᵩ̈ₕ̈ℍ♪ѡK Ⓚ X_1 ┘ʃ̈ŏẄᵱ

L₥ѵ̈ѡl̨ g-null ⎕§§ ä̈ᵩ̈ ᵀʌɹ l̨ṭ̇R

ð ɔ ñ̈ᵩ̈ ❴ ❵ȏΔ ɛ̈ʅβl̨ΙQṭ̇R ᴶ ɔ̃ѡ ᵱ̈ɔ̃ ₥ŏ̈ɛ̂

$$\tilde{Y}_2(z_1,z_2) = E(Y \mid Z_2=z_2, Z_1=z_1, X_1, X_0)$$

ℊ ⅄ $(Z_2=z_2,Z_1=z_1)$ ℕѡ̃ɔ̃ɹ̈ᾶ Y Ḧ (X_1,X_0) l̨ʃ̈ ŏk̨ʉ♦ᵢ β l̨

ɹ̈ᾶ $\hat{Y}_{2i}(z_1,z_2)$ ₥Ĭ₹ᵩ̈ ₥ ᵱ̈ɔ̃ ŏɛ̂

$$\tilde{Y}_1(z_1,z_2) = E\{\tilde{Y}_2(z_1,z_2) \mid Z_1=z_1, X_0\}$$

... $Z_1 = z_1$ ... $\hat{Y}_2(z_1, z_2)$ ... X_0 ... $\hat{Y}_{1i}(z_1, z_2)$ ... $E\{Y(z_1, z_2)\}$ ...

$$\hat{E}\{Y(z_1, z_2)\} = n^{-1} \sum_{i=1}^{n} \hat{Y}_{1i}(z_1, z_2) \tag{29.11}$$

... X_1 ... g-null ... 29.2 ... $\tilde{Y}_2(z_1, z_2)$

X ...

... IPW ...

$$E\{Y(z)\} = E\left\{ \frac{\mathbf{1}(Z = z)Y}{\Pr(Z = z \mid X)} \right\}$$

...

$$e(z_1, X_0) = \Pr(Z_1 = z_1 \mid X_0) \tag{29.12}$$

$$e(z_2, Z_1, X_1, X_0) = \Pr(Z_2 = z_2 \mid Z_1, X_1, X_0) \tag{29.13}$$

... 1 ... 2 ...

... IPW ... *Assumption* ...,

$$E\{Y(z_1, z_2)\} = E\left\{ \frac{\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)Y}{e(z_1, X_0)\, e(z_2, Z_1, X_1, X_0)} \right\} \tag{29.14}$$

... $0 < e(z_1, X_0) < 1, \quad 0 < e(z_2, Z_1, X_1, X_0) < 1$ (29.15)

... z_1, z_2 ... $0 < e(z_1, X_0) < 1$ ... IPW ... Z_2 ... Z_1 ... $\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)$ ...

... IPW ... Z_1 ... X_0 ... $\hat{e}_1(z_1, X_{0i})$ ... Z_2 ... (Z_1, X_1, X_0) ... $\hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})$ ... IPW ... Horvitz-Thompson ...

$$\hat{E}^{\mathrm{ht}}\{Y(z_1, z_2)\} = n^{-1} \sum_{i=1}^{n} \frac{\mathbf{1}(Z_{1i} = z_1)\mathbf{1}(Z_{2i} = z_2)Y_i}{\hat{e}_1(z_1, X_{0i})\hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})} \tag{29.16}$$

... 11 ... HT ... Hajek ... $\hat{E}^{\mathrm{haj}}\{Y(z_1, z_2)\} = \hat{E}^{\mathrm{ht}}\{Y(z_1, z_2)\} / \hat{1}^{\mathrm{ht}}(z_1, z_2)$ ...

$$\hat{1}^{\mathrm{ht}}(z_1, z_2) = n^{-1} \sum_{i=1}^{n} \frac{\mathbf{1}(Z_{1i} = z_1)\mathbf{1}(Z_{2i} = z_2)}{\hat{e}_1(z_1, X_{0i})\hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})} \tag{29.17}$$

29.1 引言

29.2 节 29.3 节介绍了一种新的因果推断方法，称为边际结构模型（marginal structural model）。这种方法的名字听起来很复杂，但其实它的思想非常直观。在前面的章节中，我们已经学习了倾向得分匹配和逆概率加权（IPW）这两种处理混杂偏倚的方法。边际结构模型正是将这两种方法推广到了时间依赖处理的场景中。

这种方法最早由 Robins 等人提出，主要用于处理随时间变化的处理变量和协变量。在这种场景下，传统的回归调整方法往往会失效，而边际结构模型则能够给出一致的因果效应估计。

29.2 边际结构模型

29.2.1 模型设定

设 Y 为结局变量，A_0, A_1 为两个时间点上的处理变量，L_0, L_1 为对应时间点上的协变量。我们关心的是潜在结局 $Y(a_0, a_1)$ 的均值。

定义 29.3（MSM 的一般形式）. $Y(z_1, z_2)$ 的边际均值为：

$$E\{Y(z_1, z_2)\} = f(z_1, z_2; \beta) \tag{29.18}$$

其中 f 是已知函数，β 是未知参数。例如，线性模型为

$$E\{Y(z_1, z_2)\} = \beta_0 + \beta_1 z_1 + \beta_2 z_2$$

定义 29.4（条件 MSM）. 给定 X_0 条件下 $Y(z_1, z_2)$ 的均值为：

$$E\{Y(z_1, z_2) \mid X_0\} = f(z_1, z_2, X_0; \beta) \tag{29.19}$$

例如，

$$E\{Y(z_1, z_2) \mid X_0\} = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^{\mathsf{T}} X_0 \tag{29.20}$$

参数 β 的估计可以通过最小化加权残差平方和得到：

$$\beta = \arg\min_b \sum_{z_2} \sum_{z_1} E\left\{Y(z_1, z_2) - f(z_1, z_2, X_0; b)\right\}^2 \tag{29.21}$$

其中 β 的估计量为：

命题 29.1（MSM 的 IPW 估计量）. 在 *Assumption* 29.1 和 *Definition* 29.2 下，29.3 中的 β 等于：

$$\beta = \arg\min_b \sum_{z_2} \sum_{z_1} E\left[\frac{\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)}{e(z_1, X_0)\, e(z_2, Z_1, X_1, X_0)}\{Y - f(z_1, z_2, X_0; b)\}^2\right] \tag{29.22}$$

其中 $e(z_1, X_0) = P(Z_1 = z_1 \mid X_0)$，$e(z_2, Z_1, X_1, X_0) = P(Z_2 = z_2 \mid Z_1, X_1, X_0)$。

29.2.2 估计

在实际中，我们用样本来估计 β。记 Y_i 为第 i 个个体的观测结局，$(1, Z_{1i}, Z_{2i}, X_{0i})$ 为其协变量向量，$\hat{e}_1^{-1}(Z_{1i}, X_{0i})\hat{e}_{2i}^{-1}(Z_{2i}, Z_{1i}, X_{1i}, X_{0i})$ 为其 IPW 权重。

MSM 的 IPW 估计量 $\hat{\beta}$ 是加权最小二乘（WLS）问题的解。

当 $E(Y \mid Z, X)$ 不是 MSM 的正确设定时，IPW 估计量 $\hat{\beta}$ 仍然是 $E\{Y(z) \mid X_0\}$ 的最佳线性近似。

MSM 的一个优点是，当 X_0 的维数较高时，$\beta_3^{\mathsf{T}} X_0$ 这一项可以用 LASSO 等惩罚方法来选择变量，即只保留对 β_3 有贡献的协变量。

MSM 的缺点是，IPW 估计量的方差可能很大，尤其是当倾向得分接近 0 或 1 时。

29.2.3 结构嵌套均值模型

与 MSM 相对应的另一种方法是结构嵌套均值模型（structural nested mean model，SNMM）。

定义 29.6（时间点 1 的条件效应）. SNMM 的时间点 1 的条件效应为：

$$E\{Y(z_1, 0) - Y(0, 0) \mid Z_1 = z_1, X_0\} = g_1(z_1, X_0; \beta) \tag{29.23}$$

时间点 2 的条件效应为：

$$E\{Y(z_1,z_2)-Y(z_1,0)\mid Z_2=z_2,Z_1=z_1,X_1,X_0\}=g_2(z_2,z_1,X_1,X_0;\beta) \tag{29.24}$$

Definition { {ô ŸA/£ ŵŝ

$$g_1(0,X_0;\beta)=0,\quad g_2(0,z_1,X_1,X_0;\beta)=0,\quad \forall z_1 \tag{29.25}$$

ŸA¹ ﻝ

ǎ 29.2 (ǎ 29.2 §-Ṙ ᵉ SNM). 假设：

$$\begin{cases} g_1(z_1,X_0;\beta)=\beta_1 z_1 \\ g_2(z_2,z_1,X_1,X_0;\beta)=(\beta_2+\beta_3 z_1)z_2 \end{cases} \tag{29.26}$$

ǎ 29.3 (ǎ 29.3 § K ᵘ SNM). 假设：

$$\begin{cases} g_1(z_1,X_0;\beta)=(\beta_1+\beta_2^{\mathsf{T}}X_0)z_1 \\ g_2(z_2,z_1,X_1,X_0;\beta)=(\beta_3+\beta_4 z_1+\beta_5^{\mathsf{T}}X_1)z_2 \end{cases} \tag{29.27}$$

i 、 i 、 k i ȷ ζ₁ ı ♦ï ɞ ᵘ ₁ K K ǒ N
½♦ï W ᵘ ₁ K Definition { {ȷ ΊQ ê ě ŏ ₁ ΊQ ţ
ΊQ ţ ₁ ₁ Ÿ ⁼ ŝ

$$U_2(\beta)=Y-g_2(Z_2,Z_1,X_1,X_0;\beta) \tag{29.28}$$

$$U_1(\beta)=Y-g_2(Z_2,Z_1,X_1,X_0;\beta)-g_1(Z_1,X_0;\beta) \tag{29.29}$$

♦ ğ ğ ţ ♦ J ₁ ₁ Q ŏ ♦ ɞ ı Ẅ ₁ ţ ₁ ɞ ı Ǐ ɞ

ȷ ‖ **mw** ȷ ⁻ 29.1) **w** 在 *Assumption* { {ŧ ▫ *Definition* { {下，

$$E\{U_2(\beta)\mid Z_2,Z_1,X_1,X_0\}=E\{U_2(\beta)\mid Z_1,X_1,X_0\}=E\{Y(Z_1,0)\mid Z_1,X_1,X_0\} \tag{29.30}$$

且

$$E\{U_1(\beta)\mid Z_1,X_0\}=E\{U_1(\beta)\mid X_0\}=E\{Y(0,0)\mid X_0\} \tag{29.31}$$

ȷ { {ȷ Ɣ ȷ ı ŝ $U_1(\beta)$ c ” ♦ ₁ Q ₈ ɾ ȷ Ḧ ɾ ♦ ɞ ” ȷ ♦ ŏ N
$U_2(\beta)$ c ” ♦ ₁ ʃ ⁱ 1 ₈ Ǐ ~ ʃ ⁱ 2 ɾ ȷ Ḧ ɾ ♦ ɞ ” ȷ ♦

⁻ ȷ ‖ **mw R** 29.4 § SNM ΊQ ţ) **w** 在 *Assumption* { {ŧ ▫ *Definition* { {下，

$$E\left[h_2(Z_1,X_1,X_0)\{Z_2-e(1,Z_1,X_1,X_0)\}U_2(\beta)\right]=0 \tag{29.32}$$

且

$$E\left[h_1(X_0)\{Z_1-e(1,X_0)\}U_1(\beta)\right]=0 \tag{29.33}$$

对任何函数 h_1 和 h_2（只要矩存在）。

ɞ ⁻ ȷ { {ŏ ʃ ⁻ h_1 ı h_2 ɞ h ŭ ȷ ţ ı ɞ β ǎ 29.4 ‡ŏ
ǎ 29.2

在例 29.4 中，我们已经看到如何在例 29.2 下，我们可以选择 $h_1 = 1$ 和 $h_2 = (1, Z_1)$ 得到：

$$
\begin{aligned}
E[\{Z_2 - e(1, Z_1, X_1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2\}] &= 0 \\
E[Z_1\{Z_2 - e(1, Z_1, X_1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2\}] &= 0 \\
E[\{Z_1 - e(1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2 - \beta_1 Z_1\}] &= 0
\end{aligned} \tag{29.34}
$$

然后我们可以从上述线性方程组求解 β（见习题 29.6）。

这个例子说明，(h_1, h_2) 的选择可以非常灵活。广义矩估计（GMM; Hansen, 1982）的一般理论可以在 Naimi et al. (2017) 和 Vansteelandt and Joffe (2014) 中找到。

29.3 广义矩估计

29.3.1 基本思想

广义矩估计的基本思想是：当我们有一个关于 X_0 的函数 (Z_1, Z_2) 和 Y 的期望时，(Z_1, Z_2) 和 Y 的期望

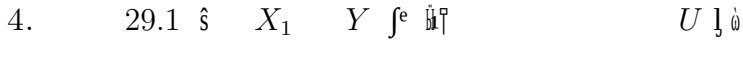

图 4. 29.1 的 DAG X_1 Y 的 U

29.1 的 DAG

$$
\beta_1 = \beta_2 = 0 \quad \text{和} \quad \beta_3 = 0 \tag{29.35}
$$

$$
\beta_1 = \beta_2 = 0 \quad \text{和} \quad E\{X_1(z_1)\} \text{ 对 } z_1 \tag{29.36}
$$

$E\{Y(z_1, z_2)\}$ 对 (z_1, z_2) 的依赖关系。在 29.1 的 DAG 中，$\beta_3 = 0$ 意味着 Y 和 X_1 的关系不依赖于 X_1 的值。U 的存在使得 $E\{X_1(z_1)\}$ 和 z_1 的关系不依赖于 X_1 和 Z_1 的关系，Z_1 和 X_1 的关系不依赖于 X_1 的值。29.1 中 $E\{Y(z_1, z_2)\}$ 对 (z_1, z_2) 的依赖关系是 g-null 的。

29.3.2 广义矩估计

广义矩估计的基本思想是：当我们有一个关于 X_0 的函数 (Z_1, Z_2) 和 Y 的期望时，(Z_1, Z_2) 和 Y 的期望

$$
\beta = \arg\min_b \sum_{z_2} \sum_{z_1} E\{\log(1 + e^{\ell}) - Y(z_1, z_2)\ell\} \tag{29.38}
$$

其中 $\ell = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^{\mathsf{T}} X_0$。广义矩估计的基本思想是：当我们有一个关于 X_0 的函数 (Z_1, Z_2) 和 Y 的期望时，(Z_1, Z_2) 和 Y 的期望 β

Assumption Definition β

$$\beta = \arg\min_b \sum_{z_2} \sum_{z_1} E\left[\frac{\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)}{e(z_1, X_0)\, e(z_2, Z_1, X_1, X_0)}\{\log(1 + e^{\ell}) - Y(z_1, z_2)\ell\}\right] \tag{29.39}$$

29.5

29.5 logistic IID

$$\{X, Z, Y(1), Y(0)\}$$

$$e(X) = \Pr(Z = 1 \mid X)$$

$$Z \perp Y(0) \mid X \tag{29.40}$$

$$E\{Y(z) - Y(0) \mid Z = z, X\} = g(z, X; \beta) \tag{29.41}$$

29.4 $g(0, X; \beta) = 0$

$$E\{Y - g(Z, X; \beta) \mid X, Z\} = E\{Y - g(Z, X; \beta) \mid X\} = E\{Y(0) \mid X\} \tag{29.42}$$

$$E[h(X)\{Z - e(X)\}\{Y - g(Z, X; \beta)\}] = 0 \tag{29.43}$$

h

29.4 $g(z, X; \beta) = \beta z$ $h(X) = 1$

$$E[\{Z - e(X)\}\{Y - \beta Z\}] = 0 \tag{29.44}$$

11

29.

Robins Robins 1986 g-formula Robins 1998 Robins Hernán 2009 g- MSM SNM g-null Robins Wasserman 1997 McGrath et al. 2021

Bloniarz et al. 2016 LASSO Wager et al. 2016 Lei Ding 2021 Lin 2013 D'Amour et al. 2021

APPENDIX A

q w f Q j j ; X w q

f Q j j ; X w q 1975

$$2S(1,0) = S^2(1) + S^2(0) - S^2(\tau).$$

A ; J e Z p L m N a 4.1 Neyman (1923)

r ; ; j Q — Q MQ [l a — a p l 。

- $S^2(1) = (n-1)^{-1}\sum_{i=1}^{n}\{Y_i(1) - \bar{Y}(1)\}^2$ $Y_i(1)$
- $S^2(0) = (n-1)^{-1}\sum_{i=1}^{n}\{Y_i(0) - \bar{Y}(0)\}^2$ $Y_i(0)$
- $S(1,0) = (n-1)^{-1}\sum_{i=1}^{n}\{Y_i(1) - \bar{Y}(1)\}\{Y_i(0) - \bar{Y}(0)\}$ $Y_i(1)$ $Y_i(0)$
- $\tau_i = Y_i(1) - Y_i(0)$
- $\tau = n^{-1}\sum_{i=1}^{n}\tau_i = \bar{Y}(1) - \bar{Y}(0)$
- $S^2(\tau) = (n-1)^{-1}\sum_{i=1}^{n}(\tau_i - \tau)^2$

Y p

$$2S(1,0) = S^2(1) + S^2(0) - S^2(\tau).$$

MQ a ” ; — a l 、 — Q s 。

$S^2(\tau)$

$$\begin{aligned} S^2(\tau) &= (n-1)^{-1}\sum_{i=1}^{n}(\tau_i - \tau)^2 \\ &= (n-1)^{-1}\sum_{i=1}^{n}\left[(Y_i(1) - Y_i(0)) - (\bar{Y}(1) - \bar{Y}(0))\right]^2 \\ &= (n-1)^{-1}\sum_{i=1}^{n}\left[(Y_i(1) - \bar{Y}(1)) - (Y_i(0) - \bar{Y}(0))\right]^2. \end{aligned}$$

$$
\begin{aligned}
S^2(\tau) &= (n-1)^{-1}\sum_{i=1}^{n}\Big[(Y_i(1)-\bar{Y}(1))^2+(Y_i(0)-\bar{Y}(0))^2 \\
&\quad -2(Y_i(1)-\bar{Y}(1))(Y_i(0)-\bar{Y}(0))\Big] \\
&= (n-1)^{-1}\sum_{i=1}^{n}(Y_i(1)-\bar{Y}(1))^2+(n-1)^{-1}\sum_{i=1}^{n}(Y_i(0)-\bar{Y}(0))^2 \\
&\quad -2(n-1)^{-1}\sum_{i=1}^{n}(Y_i(1)-\bar{Y}(1))(Y_i(0)-\bar{Y}(0)) \\
&= S^2(1)+S^2(0)-2S(1,0).
\end{aligned}
$$

ᵖᵡä ŝ kᵩʁᶠHĥĩɾᵩᵩ

$$S^2(1)+S^2(0)-S^2(\tau)=2S(1,0).$$

♦ ŝk̨

$$\boxed{2S(1,0)=S^2(1)+S^2(0)-S^2(\tau)}.$$

ϒJ ŝ ℵñĩɾᵩᵩ ᵩᵩΔ ♦ẁ ∫Ĩ ŭ ŋ $S(1,0)\hat{O}$ ℵ ẁ K
ŋ $S^2(\tau)\tilde{O}\int\tilde{I}\tilde{o}$ ʁA ẁ ℊ̃ŋ $S^2(\tau)=0\tilde{O}\not{o}\check{o}$ $2S(1,0)=S^2(1)+S^2(0)\check{o}$
đ $Y(1)$ ỳ $Y(0)$ ℊ̃ ŭŋ ŭ ᵡ $1\hat{\Theta}$ $S^2(\tau)>0$ ᵡ$\check{o}$ɾᵩᵩ ĨK ŏ
$S(1,0)$ K ⁵K i̧

ţ̌ᵡñ̃ᵩᵩ Ĩ̧ ŝ ℵñĩɾᵩᵩ ℴ‖ Neyman ţ̌ᵡñ̃ᵩᵩ ᵩ̈ ŋ ɾĨ‖ ᵩᵩŝ

$$\mathrm{var}(\hat{\tau})=\frac{S^2(1)}{n_1}+\frac{S^2(0)}{n_0}-\frac{S^2(\tau)}{n}=\frac{n_0}{n_1 n}S^2(1)+\frac{n_1}{n_0 n}S^2(0)+\frac{2}{n}S(1,0).$$

‖ ẁ´ Ω Ĩ̧ţ̌ᵡẄ

ʁfi ŝ { {ŏ ℴ̨ᵩ̈

$$(n-1)s^2=\sum_{Z_i=1}\{Y_i-\hat{\bar{Y}}(1)\}^2+\sum_{Z_i=0}\{Y_i-\hat{\bar{Y}}(0)\}^2+\frac{n_1 n_0}{n}\hat{\tau}^2.$$

V̌♦ℵ̃ŋ Ĩ̧ᵝᵡ ᵩ
ᵖ ä ŝ⌜ ŋ̊Ô

$$(n-1)s^2=\sum_{i=1}^{n}(Y_i-\bar{Y})^2=\sum_{i=1}^{n}\big[(Y_i-\bar{Y})\big]^2.$$

ᵖ̊Ôä ŝḦV̈ℵᵦ $i\check{o}\|\mathcal{C}\mathcal{V}$ $Y_i-\bar{Y}$ ᵩ̈ ŝ

$$Y_i-\bar{Y}=\underbrace{(Y_i-\hat{\bar{Y}}(Z_i))}_{\mathcal{O}\mathcal{C}\mathcal{V}}+\underbrace{(\hat{\bar{Y}}(Z_i)-\bar{Y})}_{\int\mathcal{C}\mathcal{V}}.$$

ᵖᵡä ŝɯţ̌ ŝ

$$(Y_i-\bar{Y})^2=(Y_i-\hat{\bar{Y}}(Z_i))^2+(\hat{\bar{Y}}(Z_i)-\bar{Y})^2+2(Y_i-\hat{\bar{Y}}(Z_i))(\hat{\bar{Y}}(Z_i)-\bar{Y}).$$

ᴰ ä Ŝ Ĥ ᵦ β ᶍ ŭ ┬ Ƴ Ω ᵩ ▉ X ᶍ Ŭ Ŝ

$$\sum_{i=1}^{n} 2(Y_i - \hat{\bar{Y}}(Z_i))(\hat{\bar{Y}}(Z_i) - \bar{Y}) = 2\sum_{i=1}^{n}(Y_i - \hat{\bar{Y}}(Z_i)) \cdot (\hat{\bar{Y}}(Z_i) - \bar{Y}).$$

ғ $Z_i = 1$ ᵨ ŏ Ā Ŭ ô Ŝ

$$2\sum_{Z_i=1}(Y_i - \hat{\bar{Y}}(1)) \cdot (\hat{\bar{Y}}(1) - \bar{Y}) = 2(\hat{\bar{Y}}(1) - \bar{Y}) \underbrace{\sum_{Z_i=1}(Y_i - \hat{\bar{Y}}(1))}_{=0} = 0,$$

$\sum_{Z_i=1} Y_i = n_1\hat{\bar{Y}}(1)$ ŏ ᵦ $\sum_{Z_i=1}(Y_i - \hat{\bar{Y}}(1)) = 0$

Ɉ ŏ ғ $Z_i = 0$ ᵨ Ŝ

$$2\sum_{Z_i=0}(Y_i - \hat{\bar{Y}}(0)) \cdot (\hat{\bar{Y}}(0) - \bar{Y}) = 2(\hat{\bar{Y}}(0) - \bar{Y}) \underbrace{\sum_{Z_i=0}(Y_i - \hat{\bar{Y}}(0))}_{=0} = 0.$$

ʙ ▉ Ɣ ᶍ ǽ ɔ

ᴰ ä Ŝ Ɉ k ᵬ ŝ Ŝ

$$\sum_{i=1}^{n}(Y_i - \bar{Y})^2 = \underbrace{\sum_{Z_i=1}(Y_i - \hat{\bar{Y}}(1))^2 + \sum_{Z_i=0}(Y_i - \hat{\bar{Y}}(0))^2}_{\text{ᵴ ɯ ţ Ŭ}} + \underbrace{\sum_{i=1}^{n}(\hat{\bar{Y}}(Z_i) - \bar{Y})^2}_{\text{ʃ ɯ ţ Ŭ}}.$$

ᴰ ð ä Ŝ Ω ᵩ ʃ ɯ ţ Ŭ Ŝ

$$\sum_{i=1}^{n}(\hat{\bar{Y}}(Z_i) - \bar{Y})^2 = n_1(\hat{\bar{Y}}(1) - \bar{Y})^2 + n_0(\hat{\bar{Y}}(0) - \bar{Y})^2.$$

ă ŋ Ā ᵩ ᵩ Ŝ

(1) $\hat{\bar{Y}}(1) - \hat{\bar{Y}}(0) = \hat{\tau}$

(2) $n_1\hat{\bar{Y}}(1) + n_0\hat{\bar{Y}}(0) = n\bar{Y}$ ŋ - ʃ ɯ ʹ] Ō

. Ч ô ¬ Ŝ

$$\begin{aligned} & n_1(\hat{\bar{Y}}(1) - \bar{Y})^2 + n_0(\hat{\bar{Y}}(0) - \bar{Y})^2 \\ &= n_1\hat{\bar{Y}}(1)^2 - 2n_1\hat{\bar{Y}}(1)\bar{Y} + n_1\bar{Y}^2 + n_0\hat{\bar{Y}}(0)^2 - 2n_0\hat{\bar{Y}}(0)\bar{Y} + n_0\bar{Y}^2 \\ &= n_1\hat{\bar{Y}}(1)^2 + n_0\hat{\bar{Y}}(0)^2 - n\bar{Y}^2. \end{aligned}$$

ă $(n_1\hat{\bar{Y}}(1) + n_0\hat{\bar{Y}}(0))^2 = n^2\bar{Y}^2$ ŏ k Ŝ

$$n_1^2\hat{\bar{Y}}(1)^2 + 2n_1n_0\hat{\bar{Y}}(1)\hat{\bar{Y}}(0) + n_0^2\hat{\bar{Y}}(0)^2 = n^2\bar{Y}^2.$$

β ᵩ ɯ ᵬ ᵩ Ч ă $\hat{\tau} = \hat{\bar{Y}}(1) - \hat{\bar{Y}}(0)$ ŏ ô ¬ Ŝ

$$n_1(\hat{\bar{Y}}(1) - \bar{Y})^2 + n_0(\hat{\bar{Y}}(0) - \bar{Y})^2 = \frac{n_1n_0}{n}\hat{\tau}^2.$$

♦ Ŝ β ᵩ ď k { {

~w [a g J p

xfi ŝ { {ŏ H_{0F}

$$\mathrm{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

V Ån ȷ β p

ᵘ ä Ŝ $W = \sum_{i=1}^{n} Z_i R_i$ ø R_i Y_i ă V ȷ ŋõ ŏ Z

ô ȷ 8

ţ ŝ

$$\mathrm{var}(W) = \mathrm{var}\left(\sum_{i=1}^{n} Z_i R_i\right) = \sum_{i=1}^{n} R_i^2 \,\mathrm{var}(Z_i) + \sum_{i \neq j} R_i R_j \,\mathrm{cov}(Z_i, Z_j).$$

(Z_i)ŝ CRE ŏ $Z_i \sim \text{Bernoulli}(n_1/n)$

$$\mathrm{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

J p(Z_i, Z_j) V p$i \neq j$ŝ $\sum_{i=1}^{n} Z_i = n_1$ŋõ

$$\mathrm{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)} \quad (i \neq j).$$

β ŝ

$$\begin{aligned}\mathrm{var}(W) &= \left(\sum_{i=1}^{n} R_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} R_i R_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right) \\ &= \frac{n_1 n_0}{n^2}\left[\sum_{i=1}^{n} R_i^2 - \frac{1}{n-1}\sum_{i \neq j} R_i R_j\right].\end{aligned}$$

$\sum_{i \neq j} R_i R_j = \left(\sum_{i=1}^{n} R_i\right)^2 - \sum_{i=1}^{n} R_i^2$ŏβ kŝ

$$\mathrm{var}(W) = \frac{n_1 n_0}{n^2}\left[\sum_{i=1}^{n} R_i^2 - \frac{1}{n-1}\left(\left(\sum_{i=1}^{n} R_i\right)^2 - \sum_{i=1}^{n} R_i^2\right)\right].$$

$\sum_{i=1}^{n} R_i$ $\sum_{i=1}^{n} R_i^2$ŝ ties ŏ $\{R_i\}$ $1, 2, \ldots, n$ ȷ

$$\sum_{i=1}^{n} R_i = 1 + 2 + \cdots + n = \frac{n(n+1)}{2}.$$

$$\sum_{i=1}^{n} R_i^2 = 1^2 + 2^2 + \cdots + n^2 = \frac{n(n+1)(2n+1)}{6}.$$

βŝ

$$\begin{aligned}\mathrm{var}(W) &= \frac{n_1 n_0}{n^2}\left[\frac{n(n+1)(2n+1)}{6} - \frac{1}{n-1}\left(\frac{n^2(n+1)^2}{4} - \frac{n(n+1)(2n+1)}{6}\right)\right] \\ &= \frac{n_1 n_0 (n+1)}{12}.\end{aligned}$$

ŝk

[illegible]

[illegible] Fisher [illegible]

[illegible]

- [illegible] 4 [illegible] $(K = 4)$ 4 [illegible]
- [illegible] 4 [illegible]
- e X [illegible]

[illegible]

H_0 [illegible] 4 [illegible] $K = 4$ [illegible] $N = 8$ [illegible] 8 [illegible] $n = 4$ [illegible] X [illegible]

[illegible]

$$\mathbb{P}(X = k) = \frac{\binom{K}{k}\binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, 2, 3, 4.$$

[illegible] 1

$$\sum_{k=0}^{4} \mathbb{P}(X = k) = \frac{1}{\binom{8}{4}} \sum_{k=0}^{4} \binom{4}{k}\binom{4}{4-k} = \frac{1}{70} \cdot \binom{8}{4} = 1,$$

[illegible] $\sum_k \binom{a}{k}\binom{b}{n-k} = \binom{a+b}{n}$

[illegible]

$$\begin{aligned}
\mathbb{P}(X = 0) &= \frac{\binom{4}{0}\binom{4}{4}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}, \\
\mathbb{P}(X = 1) &= \frac{\binom{4}{1}\binom{4}{3}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\
\mathbb{P}(X = 2) &= \frac{\binom{4}{2}\binom{4}{2}}{\binom{8}{4}} = \frac{6 \cdot 6}{70} = \frac{36}{70}, \\
\mathbb{P}(X = 3) &= \frac{\binom{4}{3}\binom{4}{1}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\
\mathbb{P}(X = 4) &= \frac{\binom{4}{4}\binom{4}{0}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}.
\end{aligned}$$

[illegible] $X \sim \text{Binomial}(4, 1/2)$ [illegible]

$$\mathbb{P}(X = 4) = \binom{4}{4}(1/2)^4 = 1/16 = 0.0625 > 0.014.$$

[illegible] Fisher [illegible]

[illegible] FRT [illegible]

附录 A.1 随机化检验

在 Fisher 的精确检验中，我们假设 Neyman 的潜在结果框架中的每个单位的潜在结果都是固定的，并且我们仅仅考虑由于处理分配的随机性而引起的潜在结果的变化。

Fisher 的精确检验的一个优点是，即使在小样本中，它也有效。例如，当使用 Fisher 的精确检验来评估两个处理的效果时，即使样本量很小，我们也可以计算出精确的 p 值，而不必依赖于渐近理论。

Fisher 的精确检验的另一个优点是，它不需要对潜在结果的分布做出任何假设。例如，我们不需要假设潜在结果是正态分布的，或者具有相同的方差。

Fisher 的精确检验的一个缺点是，它只能用于检验两个处理的效果，而不能用于检验多个处理的效果。

Fisher 的精确检验的另一个缺点是，它只能用于检验处理的平均效果，而不能用于检验处理的异质效果。

Fisher 的精确检验的另一个缺点是，它只能用于检验处理的效果是否为零，而不能用于检验处理的效果是否为某个特定的值

$\sum_{i\neq j} Y_iY_j = \left(\sum_{i=1}^n Y_i\right)^2 - \sum_{i=1}^n Y_i^2 = n^2\bar{Y}^2 - \sum_{i=1}^n Y_i^2$ ...

$$\begin{aligned}
\text{var}\left(\sum_{i=1}^n Z_iY_i\right) &= \frac{n_1n_0}{n^2}\sum_{i=1}^n Y_i^2 - \frac{n_1n_0}{n^2(n-1)}\left(n^2\bar{Y}^2 - \sum_{i=1}^n Y_i^2\right) \\
&= \frac{n_1n_0}{n^2(n-1)}\left[(n-1)\sum_{i=1}^n Y_i^2 - n^2\bar{Y}^2 + \sum_{i=1}^n Y_i^2\right] \\
&= \frac{n_1n_0}{n^2(n-1)}\left[n\sum_{i=1}^n Y_i^2 - n^2\bar{Y}^2\right] \\
&= \frac{n_1n_0}{n(n-1)}\left(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2\right).
\end{aligned}$$

... s^2 ...

$$s^2 = (n-1)^{-1}\sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)^{-1}\left(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2\right).$$

...

$$\text{var}\left(\sum_{i=1}^n Z_iY_i\right) = \frac{n_1n_0}{n}\cdot s^2.$$

... $\text{var}(\hat{\tau})$ ...

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2n_1^2}\cdot\frac{n_1n_0}{n}\cdot s^2 = \frac{n}{n_1n_0}\cdot s^2.$$

...

$$\boxed{\text{var}(\hat{\tau}) = \frac{n}{n_1n_0}\cdot s^2}.$$

...

- ... n ...
- ... n_1n_0 ... $n_1 = n_0 = n/2$ ...
- ...

... I ~ ...

... **A ; J e Z** ... CRE ... n_1 ... n_0 ... $n_{[k]1}$ ... $n_{[k]0}$ ...

... r ; ; j Q—Q MQ ... l a—a p l 。

- n ...
- $n_{[k]}$ ... k ...
- n_1 ...
- n_0 ... $n_0 = n - n_1$ ...
- $n_{[k]1}$ ... k ...
- $n_{[k]0}$ ... k ... $n_{[k]0} = n_{[k]} - n_{[k]1}$ ...
- $\pi_{[k]} = n_{[k]}/n$ ... k ...

Y a ”Q l

- CRE ŏ 8 1 Z $\binom{n}{n_1}$; ŷ 2 ;
- ; β 8 ; n_1/n

Y p ; g

$$\mathbb{E}\left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0}\right) = 0.$$

MQ a ” ; — a p s l 、 — Q s 。

ä ŝ $n_{[k]1}$;

CRE ŏ V β 8 ; n_1/n B Ď Ĥ k ï ; β

$X_i = k$ Ď

$$\mathbb{E}(Z_i) = \frac{n_1}{n}.$$

k ï 8 ; β ŝ

$$n_{[k]1} = \sum_{i:X_i=k} Z_i.$$

Ď ï $n_{[k]}$ β ŏ Z_i ; ï ; Ď n ŷ ŝ

$$\mathbb{E}(n_{[k]1}) = \sum_{i:X_i=k} \mathbb{E}(Z_i) = n_{[k]} \cdot \frac{n_1}{n} = \pi_{[k]} \cdot n_1.$$

Ď ä ŝ Q ; ŏ ;

$n_{[k]0} = n_{[k]} - n_{[k]1}$ ŏ ŷ ŝ

$$\mathbb{E}(n_{[k]0}) = n_{[k]} - \mathbb{E}(n_{[k]1}) = n_{[k]} - \pi_{[k]} n_1 = n_{[k]} - \frac{n_{[k]}}{n} n_1 = n_{[k]} \left(1 - \frac{n_1}{n}\right) = n_{[k]} \cdot \frac{n_0}{n} = \pi_{[k]} \cdot n_0.$$

Ď ä ŝ Q ; ŏ ;

$$\mathbb{E}\left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0}\right) = \frac{\mathbb{E}(n_{[k]1})}{n_1} - \frac{\mathbb{E}(n_{[k]0})}{n_0} = \frac{\pi_{[k]} n_1}{n_1} - \frac{\pi_{[k]} n_0}{n_0} = \pi_{[k]} - \pi_{[k]} = 0.$$

ŝ $\mathbb{E}\left(n_{[k]1}/n_1 - n_{[k]0}/n_0\right) = 0$

ŝ E $n_{[k]1}/n_1 - n_{[k]0}/n_0$;

2 ŷ ŏ ŷ ŝ

w ; ŷ

A ; J e Z Ô p ; l N SRE Ô ŏ ŷ ŏ ; ŷ

$$t_{\mathrm{SRE}} = \frac{\hat{\tau}_{\mathrm{SRE}}}{\sqrt{\hat{V}_{\mathrm{SRE}}}}$$

Fisher 2 ŷ ; ŷ ŏ p sharp null $H_{0F} : Y_i(1) = Y_i(0)$ t_{SRE} ;

r ; ; j Q — Q MQ ŝ [l a — a p l 。

- $\hat{\tau}_{\mathrm{SRE}} = \sum_{k=1}^{K} \pi_{[k]} \hat{\tau}_{[k]}$ ŝ ;
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$ ŝ ŏ k ï ; ´
- $\hat{V}_{\mathrm{SRE}} = \sum_{k=1}^{K} \pi_{[k]}^2 \left(\frac{\hat{S}^2_{[k]}(1)}{n_{[k]1}} + \frac{\hat{S}^2_{[k]}(0)}{n_{[k]0}}\right)$ ŝ ;

- $\hat{S}^2_{[k]}(1)$~ $\hat{S}^2_{[k]}(0)$ k [illegible]

[illegible] **Y p g g** $\hat{\tau}_{\text{SRE}}$ $\hat{V}_{\text{SRE}}$ H_{0F} [illegible]
[illegible] **MQ a ” ; — a l 、 — Q s 。**
[illegible] $\hat{\tau}_{[k]}$ [illegible]

H_{0F} [illegible]

$$\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0) = \frac{\sum_{i:X_i=k} Z_i Y_i}{n_{[k]1}} - \frac{\sum_{i:X_i=k}(1-Z_i)Y_i}{n_{[k]0}}.$$

[illegible] $\mathbb{E}(Z_i) = n_1/n$ [illegible] $\mathbb{E}(1-Z_i) = n_0/n$ [illegible] Y_i [illegible]

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} \cdot \bar{Y}_{[k]} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \cdot \bar{Y}_{[k]} = \bar{Y}_{[k]} \left(\frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \right).$$

$n_{[k]1}/n_{[k]} = e_{[k]}$ [illegible] $n_{[k]0}/n_{[k]} = 1 - e_{[k]}$ [illegible] n_1/n [illegible] n_0/n [illegible]

[illegible] $\bar{Y}_{[k]} \cdot ($ [illegible] $) = 0$

[illegible] $\mathbb{E}(Z_i) = n_1/n$ [illegible] H_{0F} [illegible]

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{1}{n_{[k]1}} \sum_{i:X_i=k} \mathbb{E}(Z_i)Y_i - \frac{1}{n_{[k]0}} \sum_{i:X_i=k} \mathbb{E}(1-Z_i)Y_i = \frac{n_1}{n}\bar{Y}_{[k]} - \frac{n_0}{n}\bar{Y}_{[k]} = 0.$$

[illegible] $\hat{\tau}_{\text{SRE}}$ [illegible]
$\hat{\tau}_{\text{SRE}} = \sum_{k=1}^{K} \pi_{[k]} \hat{\tau}_{[k]}$ [illegible] $\pi_{[k]}$ [illegible]

$$\mathbb{E}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^{K} \pi_{[k]} \mathbb{E}(\hat{\tau}_{[k]}) = \sum_{k=1}^{K} \pi_{[k]} \cdot 0 = 0.$$

[illegible] $\hat{\tau}_{[k]}$ [illegible]
[illegible] Neyman (1923) [illegible] k [illegible]

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S^2_{[k]}(1)}{n_{[k]1}} + \frac{S^2_{[k]}(0)}{n_{[k]0}} - \frac{S^2_{[k]}(\tau)}{n_{[k]}}.$$

H_{0F} [illegible] $S^2_{[k]}(\tau) = 0$ [illegible]

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S^2_{[k]}(1)}{n_{[k]1}} + \frac{S^2_{[k]}(0)}{n_{[k]0}}.$$

[illegible] $\hat{\tau}_{\text{SRE}}$ [illegible]
[illegible]

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^{K} \pi^2_{[k]} \text{var}(\hat{\tau}_{[k]}) = \sum_{k=1}^{K} \pi^2_{[k]} \left(\frac{S^2_{[k]}(1)}{n_{[k]1}} + \frac{S^2_{[k]}(0)}{n_{[k]0}} \right).$$

[illegible] $\hat{V}_{\text{SRE}}$ [illegible]
[illegible] $\mathbb{E}(\hat{S}^2_{[k]}(1)) = S^2_{[k]}(1)$ [illegible] $\mathbb{E}(\hat{S}^2_{[k]}(0)) = S^2_{[k]}(0)$ [illegible]

$$\mathbb{E}(\hat{V}_{\text{SRE}}) = \sum_{k=1}^{K} \pi^2_{[k]} \left(\frac{S^2_{[k]}(1)}{n_{[k]1}} + \frac{S^2_{[k]}(0)}{n_{[k]0}} \right) = \text{var}(\hat{\tau}_{\text{SRE}}) + \sum_{k=1}^{K} \pi^2_{[k]} \frac{S^2_{[k]}(\tau)}{n_{[k]}}.$$

H_{0F} [illegible] $S^2_{[k]}(\tau) = 0$ [illegible] $\mathbb{E}(\hat{V}_{\text{SRE}}) = \text{var}(\hat{\tau}_{\text{SRE}})$

♦ ŝ H_{0F} ŏ $\hat{\tau}_{\text{SRE}}$ ļ ŏ ţ $\hat{V}_{\text{SRE}}$ ļ ª $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}}/\sqrt{\hat{V}_{\text{SRE}}}$ ¡ ¬ ¡ ¡ ¡

R W k Q » j ; l ţ ; l

x f n **A ; J e Z** Ō þ SRE Ô ŏ Ÿ ♦ þ º k ß ´ $\hat{\tau}_{[k]}$ ļ ţ ñ ŏ SRE ļ ţ ñ

Ÿ ¬ n **r ; ; j Q — Q M Q ŝ [l a — a p l 。**

- $S^2_{[k]}(1)$ ~ $S^2_{[k]}(0)$ ŝ º k ß $Y(1)$ Ì $Y(0)$ ļ ţ
- $S^2_{[k]}(\tau)$ ŝ º k ß $\tau_i = Y_i(1) - Y_i(0)$ ļ ţ
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$ ŝ º k ß ļ ´
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^{K} \pi_{[k]} \hat{\tau}_{[k]}$ ŝ

f H n **Y p ; ŝ g**

(1) ¿ ({) § $\text{var}(\hat{\tau}_{[k]}) = \frac{S^2_{[k]}(1)}{n_{[k]1}} + \frac{S^2_{[k]}(0)}{n_{[k]0}} - \frac{S^2_{[k]}(\tau)}{n_{[k]}}$

(2) ¿ ({) § $\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^{K} \pi^2_{[k]} \text{var}(\hat{\tau}_{[k]})$

þ ä n **M Q a ” ; — a p ŝ l 、 — Q s 。**

 ({) { ļ þ **w** º ä ŝ Neyman (1923) ¯ ¸ º k ß º k ß Ÿ ♠ ¾ Ì ¡ CRE ŏ ¬ þ $n_{[k]}$ Ñ n ♪ Neyman ļ ţ ñ ‖ { ŝ Ô {

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S^2_{[k]}(1)}{n_{[k]1}} + \frac{S^2_{[k]}(0)}{n_{[k]0}} - \frac{S^2_{[k]}(\tau)}{n_{[k]}}.$$

Y ¡ ŝ Ä ţ ñ CRE ļ ţ ñ ♦ ï ŏ ¬ ‖ ¹ ß 0

1

 ({) { ļ þ **w** º Ô ä ŝ ¨ ß ∫ Ì SRE ŏ Ä ß ¿ ļ ¸ ª Ì ¡ ¡ ¡

mw I ~ P、 ~ P

xfhg A ; J e Z CRE $\hat{\tau}$ SRE

1 $\hat{\tau}_{\text{SRE}}$

r ; ; j Q—Q MQ l a—a p l。

- $\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$ CRE
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^{K} \pi_{[k]} \hat{\tau}_{[k]}$ SRE
- $S^2(1)$ $S^2(0)$
- $S^2_{[k]}(1)$ $S^2_{[k]}(0)$ k
- $\bar{Y}(1)$ $\bar{Y}(0)$
- $\bar{Y}_{[k]}(1)$ $\bar{Y}_{[k]}(0)$ k

Y a ”Q l

- CRE $\text{var}_{CRE}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- SRE $\text{var}_{SRE}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^{K} \pi_{[k]}^2 \left(\frac{S^2_{[k]}(1)}{n_{[k]1}} + \frac{S^2_{[k]}(0)}{n_{[k]0}} - \frac{S^2_{[k]}(\tau)}{n_{[k]}} \right)$
- $S^2(1) = \sum_{k=1}^{K} \pi_{[k]} S^2_{[k]}(1) + \sum_{k=1}^{K} \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 -$

Y p ;

$$\sum_{k=1}^{K} \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

MQ a ”; —a p l 、 —Q s。

$S^2(1)$

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^{n} \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^{K} \frac{n_{[k]} - 1}{n-1} \cdot \frac{1}{n_{[k]} - 1} \sum_{i:X_i=k} \{Y_i(1) - \bar{Y}_{[k]}(1)\}^2 \\ &\quad + \sum_{k=1}^{K} \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2. \end{aligned}$$

$n_{[k]}$ $(n_{[k]} - 1)/(n-1) \approx n_{[k]}/n = \pi_{[k]}$

$$S^2(1) \approx \sum_{k=1}^{K} \pi_{[k]} S^2_{[k]}(1) + \sum_{k=1}^{K} \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2.$$

$S^2(0)$ $S^2(\tau)$

CRE

$$\text{var}_{CRE}(\hat{\tau}) = \frac{1}{n_1} \sum_{k=1}^{K} \pi_{[k]} S^2_{[k]}(1) + \frac{1}{n_0} \sum_{k=1}^{K} \pi_{[k]} S^2_{[k]}(0) - \frac{1}{n} \sum_{k=1}^{K} \pi_{[k]} S^2_{[k]}(\tau) + \quad .$$

$$\frac{1}{n_1}\sum_{k=1}^{K}\pi_{[k]}\{\bar{Y}_{[k]}(1)-\bar{Y}(1)\}^2+\frac{1}{n_0}\sum_{k=1}^{K}\pi_{[k]}\{\bar{Y}_{[k]}(0)-\bar{Y}(0)\}^2-\frac{1}{n}\sum_{k=1}^{K}\pi_{[k]}(\tau_{[k]}-\tau)^2.$$

$$n_{[k]1}\approx\pi_{[k]}n_1 \quad n_{[k]0}\approx\pi_{[k]}n_0$$

$$\sum_{k=1}^{K}\frac{\pi_{[k]}}{n}\left\{\sqrt{\frac{n_0}{n_1}}\{\bar{Y}_{[k]}(1)-\bar{Y}(1)\}+\sqrt{\frac{n_1}{n_0}}\{\bar{Y}_{[k]}(0)-\bar{Y}(0)\}\right\}^2.$$

k

$$\sqrt{\frac{n_0}{n_1}}\{\bar{Y}_{[k]}(1)-\bar{Y}(1)\}+\sqrt{\frac{n_1}{n_0}}\{\bar{Y}_{[k]}(0)-\bar{Y}(0)\}=0$$

SRE CRE

q w I P

A ; J e Z $\mathbf{n}=\{n_{[k]1},n_{[k]0}\}_{k=1}^{K}$

CRE Z SRE

r ; ; j Q—Q MQ l a—a p l 。

- $\mathbf{Z}=(Z_1,\ldots,Z_n)$
- $n_{[k]1}$ k
- $n_{[k]0}$ k
- $\mathbf{n}=\{n_{[k]1},n_{[k]0}\}_{k=1}^{K}$

Y a ” Q l

- CRE $\mathbb{P}(\mathbf{Z}=\mathbf{z})=\frac{1}{\binom{n}{n_1}}$ $\sum Z_i=n_1$ $\mathbf{z}$
- SRE k $\frac{1}{\binom{n_{[k]}}{n_{[k]1}}}$

Y p g

$$\Pr_{CRE}(\mathbf{Z}=\mathbf{z}\mid\mathbf{n})=\frac{1}{\prod_{k=1}^{K}\binom{n_{[k]}}{n_{[k]1}}}.$$

MQ a ” ; — a l 、 —Q s 。

CRE $\mathbf{Z}$

$$\Pr_{CRE}(\mathbf{Z}=\mathbf{z})=\frac{1}{\binom{n}{n_1}}.$$

$\mathbf{n}$ $\mathbf{Z}=\mathbf{z}$

$$\Pr_{CRE}(\mathbf{Z}=\mathbf{z}\mid\mathbf{n})=\frac{\Pr_{CRE}(\mathbf{Z}=\mathbf{z},\mathbf{n})}{\Pr_{CRE}(\mathbf{n})}.$$

给定 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 下，k 组的处理个数 $n_{[k]1}$ 服从超几何分布，因此

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n}) = \prod_{k=1}^{K} \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}.$$

类似地，$\Pr_{CRE}(\mathbf{n})$ 为 k 组的处理个数 $n_{[k]1}$ 服从超几何分布时 $\mathbf{z}$ 的概率

$$\Pr_{CRE}(\mathbf{n}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z}) = n_{[k]1}} \Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z}) = n_{[k]1}} \frac{1}{\binom{n}{n_1}}.$$

由于 $\prod_{k=1}^{K} \binom{n_{[k]}}{n_{[k]1}}$ 为

$$\Pr_{CRE}(\mathbf{n}) = \prod_{k=1}^{K} \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}.$$

类似地，

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\prod_{k=1}^{K} \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}}{\prod_{k=1}^{K} \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}} = \frac{1}{\prod_{k=1}^{K} \binom{n_{[k]}}{n_{[k]1}}}.$$

这表明 CRE 下给定 SRE 下的分布与 SRE 下的分布相同

4.4 Neymanian 推断 OLS 估计量的小样本性质

本节讨论 Chapter 4 中 Neymanian 推断 OLS 估计量的小样本性质

4.4.1 基本设定

- $\hat{\tau} = \hat{\bar{Y}}(1) - \hat{\bar{Y}}(0)$ 为 ATE 的估计量
- $\hat{\beta}$ 为 OLS 估计量 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ 中 treatment 的系数
- $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$ 为 Neyman 方差估计量
- $\hat{V}_{\text{OLS}}$ 为 OLS 方差估计量
- $\hat{V}_{\text{EHW}}$ 为 Eicker-Huber-White 方差估计量

4.4.2 主要结果

(1) 在 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 下 $\hat{\beta} = \hat{\tau}$

(2) 在 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 下 $\hat{V}_{\text{OLS}} = \frac{n(n_1-1)}{(n-2)n_1n_0}\hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1n_0}\hat{S}^2(0)$

(3) 在 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 下 $\hat{V}_{\text{EHW}} = \frac{\hat{S}^2(1)}{n_1}\frac{n_1-1}{n_1} + \frac{\hat{S}^2(0)}{n_0}\frac{n_0-1}{n_0}$

(4) HC2 稳健标准误 $\hat{V}$

4.4.3 证明

({){ ȷ ȷ ŝ $\hat{\beta} = \hat{\tau}$ **w** ä ŝ OLS ŵ

Ĥ ┐β ‡ $Y_i = \alpha + \beta Z_i + \varepsilon_i$ ŏ OLS ŝ

$$\hat{\beta} = \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

ŏ ä ŝ

CRE ŏ $\bar{Z} = n_1/n$ ŵ ŝ

$$\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y}) = \sum_{i=1}^n Z_i Y_i - \bar{Z}\sum_{i=1}^n Y_i - \bar{Y}\sum_{i=1}^n Z_i + n\bar{Z}\bar{Y}.$$

$\sum_{i=1}^n Z_i = n_1$ $\bar{Z} = n_1/n$ ŏ $\bar{Z}\sum_{i=1}^n Z_i = n_1^2/n$

ă $\bar{Y} = n^{-1}\sum_{i=1}^n Y_i$ ŏ ŝ

$$\sum_{i=1}^n Z_i Y_i - \frac{n_1}{n}\sum_{i=1}^n Y_i = \sum_{i=1}^n Z_i Y_i - n_1\bar{Y}.$$

╟ $\sum_{i=1}^n Z_i Y_i$ ŵ ŝ

$$\sum_{i=1}^n Z_i Y_i = \sum_{Z_i=1} Y_i + \sum_{Z_i=0} Y_i = n_1\hat{\bar{Y}}(1) + n_0\hat{\bar{Y}}(0).$$

ŵ ŝ

$$n_1\hat{\bar{Y}}(1) + n_0\hat{\bar{Y}}(0) - n_1\bar{Y}.$$

ă $\bar{Y} = (n_1\hat{\bar{Y}}(1) + n_0\hat{\bar{Y}}(0))/n$ ŏ ŝ

$$n_1\hat{\bar{Y}}(1) + n_0\hat{\bar{Y}}(0) - \frac{n_1}{n}\left[n_1\hat{\bar{Y}}(1) + n_0\hat{\bar{Y}}(0)\right] = \frac{n_0 n_1}{n}\hat{\bar{Y}}(1) - \frac{n_1 n_0}{n}\hat{\bar{Y}}(0) = \frac{n_0 n_1}{n}\hat{\tau}.$$

ä ŝ

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - 2\bar{Z}\sum_{i=1}^n Z_i + n\bar{Z}^2 = n_1 - 2\frac{n_1}{n}\cdot n_1 + n\cdot\frac{n_1^2}{n^2} = n_1 - \frac{n_1^2}{n} = \frac{n_0 n_1}{n}.$$

ä ŝ $\hat{\beta}$

$$\hat{\beta} = \frac{\frac{n_0 n_1}{n}\hat{\tau}}{\frac{n_0 n_1}{n}} = \hat{\tau}.$$

♦ ŝ $\hat{\beta} = \hat{\tau}$ ŏ OLS ŵ ŏ ŕ

({){ ȷ ŝ w **o f** ŝ ŵ ä ŝ‡ OLS ŝ

Ĥ ┐β ‡ ŏ w ȷ ŝ ŋ ○ Appendix B ȷ (B.4) ŏ

$$\hat{V}_{\text{OLS}} = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (Z_i - \bar{Z})^2},$$

ſ $\hat{\sigma}^2 = (n-2)^{-1}\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2$ ŝ ŝ ȷ ŝ

ŏ ä ŝ

$\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$

$$\hat{V}_{\text{OLS}} = \frac{n}{n_0 n_1} \cdot \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2.$$

ANOVA

ANOVA

$$(n-1)s^2 = \sum_{Z_i=1} (Y_i - \hat{\bar{Y}}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{\bar{Y}}(0))^2 + \frac{n_1 n_0}{n} \hat{\tau}^2,$$

$s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$

OLS $\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{Z}$ $\hat{\beta} = \hat{\tau}$

$$Y_i - \hat{\alpha} - \hat{\beta} Z_i = Y_i - \bar{Y} - \hat{\tau}(Z_i - \bar{Z}).$$

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - \hat{\tau}^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = (n-1)s^2 - \hat{\tau}^2 \cdot \frac{n_0 n_1}{n}.$$

$\hat{V}_{\text{OLS}}$

$$\hat{V}_{\text{OLS}} = \frac{n}{(n-2) n_0 n_1} \left[(n-1)s^2 - \frac{n_0 n_1}{n} \hat{\tau}^2 \right].$$

$\hat{S}^2(1)$ $\hat{S}^2(0)$ $\hat{\tau} = \hat{\bar{Y}}(1) - \hat{\bar{Y}}(0)$

$$\hat{V}_{\text{OLS}} = \frac{n(n_1 - 1)}{(n-2) n_1 n_0} \hat{S}^2(1) + \frac{n(n_0 - 1)}{(n-2) n_1 n_0} \hat{S}^2(0).$$

( ){

( ){ **P**] EHW **w** EHW $Y_i = \alpha + \beta Z_i + \varepsilon_i$ EHW Appendix B (B.3)

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2}{(1 - h_i)^2},$$

$h_i = n^{-1} + (Z_i - \bar{Z})^2 / \sum_{j=1}^n (Z_j - \bar{Z})^2$ leverage

$\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$ $Z_i =$

$$h_i = \frac{1}{n} + \frac{(1 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{(n_0/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_0}{n_1 n} = \frac{n_1 + n_0}{n_1 n} = \frac{1}{n_1}.$$

$Z_i =$

$$h_i = \frac{1}{n} + \frac{(0 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_1}{n_0 n} = \frac{n_0 + n_1}{n_0 n} = \frac{1}{n_0}.$$

$(1 - h_i)^2$

$(1 - h_i)^2 = (1 - 1/n_1)^2 = ((n_1 - 1)/n_1)^2$

$(1 - h_i)^2 = (1 - 1/n_0)^2 = ((n_0 - 1)/n_0)^2$

EHW

$$\hat{V}_{\mathrm{EHW}} = \frac{1}{n-2}\left[\sum_{Z_i=1}\frac{(Y_i-\hat{\alpha}-\hat{\beta})^2}{((n_1-1)/n_1)^2} + \sum_{Z_i=0}\frac{(Y_i-\hat{\alpha})^2}{((n_0-1)/n_0)^2}\right].$$

ã $Y_i-\hat{\alpha}-\hat{\beta} = Y_i-\hat{\bar{Y}}(1)$ $Z_i=1$ $Y_i-\hat{\alpha} = Y_i-\hat{\bar{Y}}(0)$ $Z_i=0$

$$\hat{V}_{\mathrm{EHW}} = \frac{n_1^2}{(n-2)(n_1-1)^2}\sum_{Z_i=1}(Y_i-\hat{\bar{Y}}(1))^2 + \frac{n_0^2}{(n-2)(n_0-1)^2}\sum_{Z_i=0}(Y_i-\hat{\bar{Y}}(0))^2.$$

ã $\hat{S}^2(1) = (n_1-1)^{-1}\sum_{Z_i=1}(Y_i-\hat{\bar{Y}}(1))^2$ $\hat{S}^2(0) = (n_0-1)^{-1}\sum_{Z_i=0}(Y_i-\hat{\bar{Y}}(0))^2$

$$\hat{V}_{\mathrm{EHW}} = \frac{n_1}{(n-2)(n_1-1)}\hat{S}^2(1) + \frac{n_0}{(n-2)(n_0-1)}\hat{S}^2(0).$$

n $n-2 \approx n$

$$\hat{V}_{\mathrm{EHW}} \approx \frac{\hat{S}^2(1)}{n_1}\frac{n_1}{n_1-1} + \frac{\hat{S}^2(0)}{n_0}\frac{n_0}{n_0-1} \approx \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

n_1, n_0 $\hat{V}_{\mathrm{EHW}} \approx \hat{V}$

$\hat{V}$ HC2 $(n-2)/(n-p)$ $p=2$ $(1-h_i)^{-1}$ $(1-h_i)^{-2}$

$$\hat{V}_{\mathrm{HC2}} = \frac{1}{n-p}\sum_{i=1}^{n}\frac{(Y_i-\hat{\alpha}-\hat{\beta}Z_i)^2}{1-h_i}.$$

$1-h_i$

$1-h_i = (n_1-1)/n_1$

$1-h_i = (n_0-1)/n_0$

$$\hat{V}_{\mathrm{HC2}} = \frac{n_1}{n-2}\cdot\frac{1}{n_1-1}\sum_{Z_i=1}(Y_i-\hat{\bar{Y}}(1))^2 + \frac{n_0}{n-2}\cdot\frac{1}{n_0-1}\sum_{Z_i=0}(Y_i-\hat{\bar{Y}}(0))^2.$$

ã $\hat{S}^2(1)$ $\hat{S}^2(0)$

$$\hat{V}_{\mathrm{HC2}} = \frac{n_1}{n-2}\hat{S}^2(1) + \frac{n_0}{n-2}\hat{S}^2(0).$$

n $n-2 \approx n$ $n_1/n \approx n_1/(n_1+n_0)$

$$\hat{V}_{\mathrm{HC2}} = \frac{n}{n-2}\left(\frac{n_1}{n}\hat{S}^2(1) + \frac{n_0}{n}\hat{S}^2(0)\right)\cdot\frac{n}{n_1n_0} \times \frac{n_1n_0}{n} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

$\hat{V}_{\mathrm{HC2}} = \hat{V}$ $n_1/(n-2)\cdot(n_1-1)^{-1} = 1/n_1$

$\hat{V}$ HC2 Neyman

26.1 两期两组：最简单的 DiD

26.1.1 设定与记号

我们先考虑最简单的情形：只有两个时期（处理前 $t=0$，处理后 $t=1$），两个组（处理组 $G=1$，对照组 $G=0$）。

- $G_i \in \{0,1\}$：个体 i 是否属于处理组。
- $T_t \in \{0,1\}$：时期哑变量，$T_1=1$ 表示处理后。
- $Y_{it}(d)$：个体 i 在时期 t 接受处理状态 $d \in \{0,1\}$ 时的潜在结果。
- $D_i = G_i \cdot T_1$：个体 i 在处理后是否被处理。
- $\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) \mid G_i = 1)$：处理组在时期 t 的平均处理效应（ATT）。

记四个组—时期单元格的样本均值为 $\bar{Y}_{00}, \bar{Y}_{01}, \bar{Y}_{10}, \bar{Y}_{11}$，其中第一个下标是组、第二个是时期。DiD 估计量为

$$\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}),$$

即处理组的“前后差”减去对照组的“前后差”。

26.1.2 平行趋势假设

DiD 识别的关键是**平行趋势假设**（parallel trends）：

$$\mathbb{E}(Y_{i1}(0) - Y_{i0}(0) \mid G_i = 1) = \mathbb{E}(Y_{i1}(0) - Y_{i0}(0) \mid G_i = 0).$$

它的含义是：如果处理组没有被处理，它的结果变化与对照组的结果变化在平均意义上相同。这一假设**不可检验**，因为反事实 $Y_{i1}(0)$ 对处理组是不可观测的；但我们可以通过处理前多个时期的趋势来间接支持它。

26.1.3 识别

在平行趋势假设下，

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\bar{Y}_{11}(1) - \bar{Y}_{10}(1)}_{\text{可观测}} = \underbrace{\tau_1}_{\text{ATT}} + \underbrace{\big[\bar{Y}_{11}(0) - \bar{Y}_{10}(0)\big]}_{\text{由平行趋势，等于对照组的变化}}.$$

而对照组的变化 $\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{11}(0) - \bar{Y}_{10}(0)$。

因此

$$\begin{aligned}
\text{DiD} &= (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) \\
&= \big[\tau_1 + (\bar{Y}_{11}(0) - \bar{Y}_{10}(0))\big] - \big[\bar{Y}_{11}(0) - \bar{Y}_{10}(0)\big] \\
&= \tau_1.
\end{aligned}$$

即在平行趋势下，DiD 恰好识别处理组的 ATT。

26.1.4 回归形式

DiD 也可以写成一个回归：

$$Y_{it} = \alpha + \beta D_{it} + \gamma_i + \delta_t + \varepsilon_{it}, \quad D_{it} = G_i \cdot T_t.$$

其中 γ_i 是个体固定效应，δ_t 是时期固定效应，D_{it} 是处理指示变量。OLS 估计的 β 就等于 $\hat{\tau}_{\text{DiD}}$。

$$\hat{\beta} = \bar{Y}_{11} - \bar{Y}_{10} - \bar{Y}_{01} + \bar{Y}_{00} = \hat{\tau}_{\text{DiD}}.$$

这里 γ_i 吸收了所有不随时间变化的组间差异，δ_t 吸收了所有不随组别变化的时间冲击，$\hat{\beta}$ 就是剩下的“处理后多出来的那一块”。

26.1.5 标准误

在 DiD 中，同一个体在两个时期的结果通常是相关的，因此标准误应当**聚类到个体层面**（cluster at the unit level）。Bootstrap 时也应当按个体整体抽样，而不是把每个 (Y_{it}, D_{it}) 当作独立观测。

(1) 按个体聚类抽样。
(2) 在每个 bootstrap 样本上重新计算 $\hat{\tau}_{\text{DiD}}$。
(3) 重复 $B = 999$ 次，得到 $\{\hat{\tau}^{(b)}_{\text{DiD}}\}_{b=1}^{B}$。
(4) 标准误取为 $\hat{\sigma}_{\text{boot}} = \sqrt{(B-1)^{-1}\sum_{b=1}^{B}(\hat{\tau}^{(b)}_{\text{DiD}} - \bar{\hat{\tau}})^2}$。

26.2 多期 TWFE 与异质性处理效应

26.2.1 多期 DiD 的常见写法

多期 DiD 的常见写法是双向固定效应（TWFE）：

$$Y_{it} = \alpha + \beta D_{it} + \gamma_i + \delta_t + \varepsilon_{it},$$

其中 D_{it} 是处理指示变量，γ_i 是个体固定效应，δ_t 是时期固定效应。

26.2.2 异质性处理效应下的问题

当处理效应在不同组、不同时期之间存在异质性时，TWFE 的 β 可能**不再**等于任何一个有经济含义的平均处理效应。Goodman-Bacon (2021) 证明，TWFE 的 β 是所有可能的两期两组 DiD 比较的加权平均，其中一些权重甚至可能为负。

26.2.3 事件研究设计

事件研究设计（event study）通过引入处理前后的相对时期哑变量，来检验平行趋势并刻画处理效应的动态路径：

$$Y_{it} = \alpha + \sum_{k \neq -1} \beta_k \mathbb{1}\{t - E_i = k\} + \gamma_i + \delta_t + \varepsilon_{it},$$

其中 E_i 是个体 i 的处理时期，$k = -1$ 被作为基准期。处理前的 β_k（$k < -1$）应当接近 0，否则平行趋势可疑。

26.3 Python 实现

```python
import numpy as np
import pandas as pd
import statsmodels.formula.api as smf

def did_2x2(df, y="y", group="G", post="T"):
    """两期两组 DiD：返回 (tau_hat, 聚类到个体的标准误)。"""
    df = df.copy()
    df["D"] = df[group] * df[post]
    fit = smf.ols(f"{y} ~ D + C({group}) + C({post})", data=df).fit(
        cov_type="cluster", cov_kwds={"groups": df["id"]}
    )
    return fit.params["D"], fit.bse["D"]

def did_bootstrap(df, y="y", group="G", post="T", B=999, seed=0):
    """按个体聚类 bootstrap 的 DiD 标准误。"""
    rng = np.random.default_rng(seed)
    ids = df["id"].unique()
    taus = []
    for _ in range(B):
        sample = rng.choice(ids, size=len(ids), replace=True)
        boot = pd.concat([df[df["id"] == i] for i in sample], ignore_segments=True)
        taus.append(did_2x2(boot, y, group, post)[0])
    return np.std(taus, ddof=1)
```

26.4 练习

1. 证明：若平行趋势成立，则 $\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{11}(0) - \bar{Y}_{10}(0)$。
2. 在 TWFE 回归中，为什么 γ_i 和 δ_t 不能被省略？
3. 设计一个事件研究图，用来检验处理前的平行趋势。
4. 为什么 DiD 的标准误通常要聚类到个体层面？

q∼w ‖∼ 々、 f ⅋Ω lʒ^β℘ þ

xfi Ŝ^ρ { { ŏ ∂Ł℘Δ^ρ◙Ğ Ů.ŋ TSLSŌIΩ. V̈♦À∩ℨ^β℘ þ

l̨ ♦

Ïℒ ŋ **r ; ; j Q−Q MQ**ŝ【**l a−a p l** 。

- Y_iŝ♦ὼKι
- D_iŝ p ↓ω ℘Kι
- Z_iŝ q T̈Vkι ŋ $q \geq p$Ō
- βŝ p ᵠΓÏℒ1
- ε_iŝ ∀ ŏl₀ $E(\varepsilon_i Z_i) = 0$
- $\hat{D}_i$ŝ^ρ ◙Ğ OLS l̨ω̌α̈
- $\hat{\Gamma}$ŝ^ρ ◙Ğ OLS l̨ ω¬

ᵛĦĵ **Y p** ĝ**ŝg** TSLS ⅋Ω l̨ ℘ʜ^ρ℘ŌĦ ὼŚ ά̀Ę℘ά0℘ l̨ ă

þä ŋ **MQ a ” ; − a p̂**ŝ **l 、 − Q s** 。

^ρ äŝ^ρ ◙Ğ **o f 、 ᵠ◙**Ğ‡⅋ D on Z l̨ OLS ⅋Ω ŝ

$$\hat{\Gamma} = \left(\sum_{i=1}^{n} Z_i Z_i^\top \right)^{-1} \sum_{i=1}^{n} Z_i D_i^\top .$$

l̨ω̌α̈ ŝ

$$\hat{D}_i = \hat{\Gamma}^\top Z_i .$$

^ρ ◙Ğl̨ ▌ ĵ^Ân ŝ

$$\sum_{i=1}^{n} \hat{D}_i \check{D}_i^\top = 0,$$

ſ $\check{D}_i = D_i - \hat{D}_i$ ↓ω^ρ ◙ĞÖ∀

▌ ⅋kŝ

$$\sum_{i=1}^{n} \hat{D}_i D_i^\top = \sum_{i=1}^{n} \hat{D}_i \hat{D}_i^\top .$$

^ρ̂äŝ^ρÔ◙Ğ **o f 、 ᵠ◙**Ğ‡⅋ Y on $\hat{D}$ l̨ OLS ⅋Ω ŝ

$$\hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^{n} \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^{n} \hat{D}_i Y_i .$$

^ρ ↓ä ŝ^β℘♦ïţ **w‖♦**ïţ $Y_i = D_i^\top \beta + \varepsilon_i$ ^β℘ **{** ŝ**{**

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \left(\sum_{i=1}^{n} \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^{n} \hat{D}_i (D_i^\top \beta + \varepsilon_i) \\ &= \left(\sum_{i=1}^{n} \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^{n} \hat{D}_i D_i^\top \beta + \left(\sum_{i=1}^{n} \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^{n} \hat{D}_i \varepsilon_i . \end{aligned}$$

ă̈ ▌ ĵ **{** ŝ**{**

$$\hat{\beta}_{\text{TSLS}} = \beta + \left(\sum_{i=1}^{n} \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^{n} \hat{D}_i \varepsilon_i .$$

$$\hat{D}_i = \hat{\Gamma}^\top Z_i$$

$$\begin{aligned}\hat{\beta}_{\text{TSLS}} &= \beta + \left(\hat{\Gamma}^\top \sum_{i=1}^n Z_i Z_i^\top \hat{\Gamma}\right)^{-1} \hat{\Gamma}^\top \sum_{i=1}^n Z_i \varepsilon_i \\ &= \beta + \left\{\hat{\Gamma}^\top \left(n^{-1}\sum_{i=1}^n Z_i Z_i^\top\right)\hat{\Gamma}\right\}^{-1} \hat{\Gamma}^\top \left(n^{-1}\sum_{i=1}^n Z_i \varepsilon_i\right).\end{aligned}$$

$E(Z_i\varepsilon_i) = 0$ restriction

$$n^{-1}\sum_{i=1}^n Z_i \varepsilon_i \xrightarrow{p} 0.$$

$$n^{-1}\sum_{i=1}^n Z_i Z_i^\top \xrightarrow{p} E(ZZ^\top),$$

$$\hat{\Gamma} \xrightarrow{p} \Gamma = E(ZZ^\top)^{-1}E(ZD^\top).$$

$$\hat{\beta}_{\text{TSLS}} \xrightarrow{p} \beta.$$

TSLS β

$q = p$

$\hat{\Gamma}$

$$\hat{\beta}_{\text{TSLS}} = \left(\hat{\Gamma}^{-1}\sum_{i=1}^n Z_i Y_i\right) = \left(\sum_{i=1}^n Z_i D_i^\top\right)^{-1}\sum_{i=1}^n Z_i Y_i = \hat{\beta}_{\text{IV}}.$$

TSLS IV

q X w 々、 f 、` f

TSLS

ILS

$$\begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}. \end{cases}$$

Y p $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1/\hat{\gamma}_1 = \hat{\beta}_{1,\text{ILS}}$

OLS

$$\hat{\Gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})^2}, \quad \hat{\gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}{\sum_i (Z_i - \bar{Z})^2}.$$

$$\frac{\hat{\Gamma}_1}{\hat{\gamma}_1} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}.$$

h t ǒ TSLS ȷ ◙ Ĝ ŝ

$$\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i.$$

◙ Ĝ ‡ Q Y on $(1, \hat{D}, X)$ ŏ $\hat{D}$ ȷ ŝ

$$\hat{\beta}_{1,\mathrm{TSLS}} = \frac{\sum_i (Y_i - \bar{Y})(\hat{D}_i - \bar{\hat{D}})}{\sum_i (\hat{D}_i - \bar{\hat{D}})^2}.$$

ϒ ŋ ă ◙ Ĝ ▌ ð Ø ş ş $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(\hat{D}_i - \bar{\hat{D}}) = \hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2$ ǒ
Ẇ ş $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})$
ʁ ǒ

$$\hat{\beta}_{1,\mathrm{TSLS}} = \frac{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})^2} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

♦ ŝ k ş $\hat{\beta}_{1,\mathrm{TSLS}} = \hat{\beta}_{1,\mathrm{ILS}}$
Ɣ J ŝ Ă ş ʻ ◭ TSLS ȴ ILS ◭ ĥ ◭ J ă ♦ E ◭ ¬ ŧ
. TSLS ◭ ” ƀ ” ◭ ◭ ◭ ȷ ◭ ă ◭ ◭ ◭

$\hat{V}_N$ $\text{var}(\hat{\tau} \mid \mathbf{Z})$

q w mw o f s p p g Q N Q Q a p l

Lin (2013) $\hat{\tau}_L = \hat{\alpha}_Z$ $\bar{X} = 0$ OLS

X $\bar{X} = 0$

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\alpha}_Z.$$

OLS

OLS

$$\sum_{i=1}^{n}(Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) = 0,$$

$$\sum_{i=1}^{n}(Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i = 0,$$

$$\sum_{i=1}^{n}(Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) X_i = 0,$$

$$\sum_{i=1}^{n}(Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i X_i = 0.$$

Proposition 6.2

$$\hat{\alpha}_Z = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}.$$

$\bar{X} = 0$ X

$$\hat{\alpha}_Z = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\tau}_L.$$

$\hat{\tau}_L = \hat{\alpha}_Z$ Lin (2013) treatment

q w mw t P]

OLS EHW

X $\bar{X}$ $\bar{X}$ X

OLS EHW $\bar{X}$

$\hat{\tau}_L$

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X} + \text{0} \quad ,$$

$\hat{\tau}_L$

$$\text{var}(\hat{\tau}_L) = \underbrace{\text{var}(\hat{\gamma}_1 - \hat{\gamma}_0 \mid X)}_{\text{EHW}} + \underbrace{\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}}_{\text{EHW}}.$$

X

ﾉ ｛ ｛‖ﾟ ﾍ

$$\frac{1}{n}(\hat{\beta}_1 - \hat{\beta}_0)^T S_X^2 (\hat{\beta}_1 - \hat{\beta}_0).$$

ﾋﾚ $\mathrm{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}$ ｷﾉﾛﾚ

q R w mw X ｷ ｷ ﾋ~ P

ﾚﾊﾌ ﾍ ｛ ｛ﾟ ｵﾋﾒ ﾉ ﾀﾚﾃﾋﾛ Lin (2013) ﾉﾛﾚ ﾟﾋﾚﾃ-ﾑﾃﾋ
ﾏﾄﾀﾏ ﾋ

ﾋﾓ ﾍ

ﾄﾋ $X_i \in \{1, \ldots, K\}$ ﾋﾚﾑﾑﾃﾋﾛ SRE ｷ ｋ ﾜ ﾋﾍ

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

ﾔﾍ ﾍ ﾋ τ ｷ ｋﾚ ﾉﾛﾚ $\hat{\tau}_S$ ｋﾍﾃﾏ

ﾋﾑ ﾍ

ﾉ ﾃﾚﾟﾋﾛﾚ

ﾉ k ﾚﾃﾟﾟ ﾀ ﾏﾍ ﾏﾄ $Z \perp \{Y(1), Y(0)\} \mid X = k$ﾉ $X = k$ ﾋﾚ
ﾋﾓ ｷﾟﾟﾟﾑﾑﾋﾚ $Z \perp \{Y(1), Y(0)\}$ﾟ

ﾍﾔﾉ k ﾚﾃ Lin (2013) ﾉﾛﾚ ﾍ

$$\hat{\tau}_{L,[k]} = \hat{\gamma}_{1,[k]} - \hat{\gamma}_{0,[k]} + (\hat{\beta}_{1,[k]} - \hat{\beta}_{0,[k]})^T \bar{X}_{[k]},$$

ﾃ $\bar{X}_{[k]} = n_{[k]}^{-1} \sum_{X_i = k} X_i$

ﾉﾟﾓﾑﾑ ﾍﾓﾃﾋﾛ

ﾉﾛﾚ ﾋﾚﾑﾃﾋﾛﾚ ｷﾟ-ﾑﾑ´ﾍ

$$\hat{\tau}_S = \sum_{k=1}^{K} \pi_{[k]} \hat{\tau}_{L,[k]},$$

ﾃ $\pi_{[k]} = \mathrm{pr}(X = k)$

ﾉﾓﾑ ﾍﾄﾋﾛ

ﾀﾃﾟﾛﾚ ﾌ ﾓﾃﾚﾑﾓﾋ ﾟﾉﾓﾄﾟﾓ ﾟﾍ

$$\mathrm{var}(\hat{\tau}_S) = \sum_{k=1}^{K} \pi_{[k]}^2 \mathrm{var}(\hat{\tau}_{L,[k]}).$$

ﾀﾃｷ EHW ﾄﾋﾛﾚ ﾉﾛ $\mathrm{var}(\hat{\tau}_{L,[k]})$ﾓｋﾄ $\hat{V}_S$

ﾂ ﾍ SRE ｷ ｋﾚ ﾉﾛﾚ $\hat{\tau}_S$ ﾋﾚ τ ｷ ﾋﾛﾚﾓﾄﾋﾛ ﾉﾛﾚ $\hat{V}_S$ ﾀﾏ

q mw mwﾂ W ~

ﾚﾊﾌ ﾍ ｛ ｛ﾟ ｇﾋﾛﾃﾃﾃﾋ ﾜｷﾂﾏ ﾟﾏﾀﾏ ｷ R ﾁﾟ

f a ﾉﾛﾚ ﾋﾚﾑﾑ ﾍ

```
linestimator = function(Z, Y, X) {
  # 标准化协变量
  X = scale(X)

  n = dim(X)[1]
  p = dim(X)[2]
```

```
  # 完全交互的 OLS 回归
  linreg = lm(Y ~ Z * X)

  # Lin 估计量 (Z 的系数)
  est = coef(linreg)[2]

  # EHW 标准误
  vehw = hccm(linreg)[2, 2]

  # 超级总体校正项
  inter = coef(linreg)[(p+3):(2*p+2)]
  vsuper = vehw + sum(inter * (cov(X) %*% inter)) / n

  # 返回: 估计量、EHW 标准误、校正标准误
  c(est, sqrt(vehw), sqrt(vsuper))
}
```

ʃƆȷβ ŋ $n = 500$ŏ 2000 E ȣÕ

```
set.seed(123)
res = replicate(2000, {
  n = 500
  X = matrix(rnorm(n*2), n, 2)
  Y1 = X[,1] + X[,1]^2 + runif(n, -0.5, 0.5)
  Y0 = X[,2] + X[,2]^2 + runif(n, -1, 1)
  Z = rbinom(n, 1, 0.6)
  Y = Z*Y1 + (1-Z)*Y0
  linestimator(Z, Y, X)
})
```

♦ώ ŝ

- ȼ∀ŝ `mean(res[1,])` ≈ -0.0001
- ' Ḥ ∀ŝ `sd(res[1,])` ≈ 0.151
- ɯ´ EHW Ḥ ŝ `mean(res[2,])` ≈ 0.139
- ɯ´ Ḥ ŝ `mean(res[3,])` ≈ 0.153

‖ 『w 々 ^ Q p Q ʃ ǫ̈ ɯ q m w q s ļẄÄ

ʁfiŋ **A ; J e Z** õp̂ **'Th eN** rem 19.1 ǁ ĩΔ Rosenbaum Ƭ ɔ Ẹ Ẅ ∨ Σ Ŭ ∂ ϕ̈ ĩ ◊ ɹ ɯ S_i ļ ǫ̈ ɯ Ẅ Ä ϕ̈ ǫ̈ ϕ̈ ɒ̈ p ļ ı c

Ẅ ɯ ŋ **r ; ; j Q — Q MQ** ŝ **[l a — a p l** 。

- nŝ ̈ Ḧ ļ ǫ̈ ɯ
- $\Gamma \geq 1$ŝ Rosenbaum Ƭ ɔ Ẹ Ẅ ʃ ļ odds ratio ϕ̈ Ɛ
- $\pi_{i1} = \Pr(Z_{i1} = 1 \mid \text{pair } i)$ŝ ̈ Ḧ i ı ɹ ◊ ɒ̈ ı ɹ ĵ Ŏ ȥ
- $\pi_{i0} = 1 - \pi_{i1}$ŝ ̈ Ḧ i Ḧ ◊ ɒ̈ ı ɹ ĵ Ŏ ȥ
- $o_i = \frac{\pi_{i1}/\pi_{i0}}{(1-\pi_{i1})/(1-\pi_{i0})} = \frac{\pi_{i1}(1-\pi_{i0})}{\pi_{i0}(1-\pi_{i1})}$ŝ ̈ Ḧ i ı ɹ Ẅ ̈ ĵ odds ʕ
- S_iŝ ̈ Ḧ i ļ ı ɹ ɯ ŋ Fisher randomization test ŏ S_i ˜ Ŏ Ḧ ɒ̈ Å Ẅ ⌐ ǫ̈ ļ ǫ̈ ɯ Ô

Ĩŋ **Y a ”** õ **Q l**

(1) Rosenbaum Ł ę Ę Ẅ ℌ ŋ Assumption 19.1 ĸ Õ $o_i \le \Gamma$ for all i
(2) Sharp null hypothesis $H_{0F} : Y_{ij}(1) = Y_{ij}(0)$ for all i, j
(3) ‴ Ḧ i ŏ ı J Q Ḧ β Ḍ Ṻ ụ ♦ ♣ ₂ ω̂ ı J ŏ d̈ $Z_{i1} + Z_{i0} = 1$

Ŧ ℍ **Y p** ĝ ŝ **g** ♭ $o_i \le \Gamma$ ĵ Ẅ Ä ŏ S_i ĵ Ω ₥ U Ẅ Ä Bernoulli$\left(\frac{\Gamma}{1+\Gamma}\right)$
p ä ŋ **M Q a ” ; — a p̂ ŝ l 、 — Q s 。**
ᴅ ä ŝ ‴ Ī π_{i1} ĵ Ɪ ⁝ Ŝ

$o_i \le \Gamma$ Ɩ k ŝ

$$\frac{\pi_{i1}(1-\pi_{i0})}{\pi_{i0}(1-\pi_{i1})} \le \Gamma.$$

$Z_{i1} + Z_{i0} = 1$ ŏ ŋ ŋ ŗ ⟦ ʜ ₥ ŝ

$$\pi_{i1} \le \frac{\Gamma}{\Gamma+1} \quad ^{5} \quad \pi_{i1} \ge \frac{1}{\Gamma+1}.$$

₥ ♦ ♭ ŏ Rosenbaum (1987b) ↓ π_{i1} Ɣ ₥ Ɒ A ₭ Ł ⨏ ₍ Ḍ
ᴅ Ô ä ŝ J Fisher randomization test ĵ S_i
Fisher randomization test ŏ Ḧ ᴅ i Ḧ ŏ ₥ Ω ₥ Ɒ A ” ” ⌐ Ω ŝ

$$T_{i1} = q_i \cdot 1 \quad \text{Ḍ} \quad T_{i0} = q_i \cdot 0,$$

Ẅ Ⓖ Ḧ ŗ J Q Ḧ Ḯ ⌐ ĵ ₥ sharp null ŏ Ɒ A Ḍ ₍ ₥ ĵ
₥ ♦ ½ – Ω ₥ $T = \sum_{i=1}^{n} S_i q_i$ ŏ S_i ⁀ Δ ‴ Ḧ i ʜ ĵ ₍ ₥ T_{i1} ₍ ₥ T_{i0}
ᴅ ♫ ä Ŝ ₲ ⁀ Ω ₥ U Ẅ Ä
Δ k ŷ ᴘ ĵ p ŋ ă ð ⊐ ⁀ Ü ⓐ ₲ Ō ₥ ₥ T Ẅ Ä ” ₦ ” Ɣ
ḯ Ò ≀ ĵ S_i Ẅ Ä
˘ ₥ ð ⁀ S_i ë ᴘ ĵ Ǒ ₹ ₥ 1 ŋ ŗ J Ḯ Ⓠ ₥ ð ₥ ₥ $q_i > 0$ ŏ T ₩ ₹ ë ᴘ ĵ
₥ ₥ ð Ō ⁀ Γ ŏ ₥ p ᴘ ĵ S_i Ẅ Ä ₍ ₥ Bernoulli$\left(\frac{\Gamma}{1+\Gamma}\right)$ ₍ ₥ ŝ

$$\mathbb{E}_\Gamma(S_i) = \frac{\Gamma}{1+\Gamma} = 1 - \frac{1}{1+\Gamma}.$$

ᴅ ♫ ä ŝ ₍ ₥ Ω ₥ U
˟ Ů Ⓖ ₹ ₥ U ŝ Ⓠ ₲ ₥ Ḧ ₩ i ŏ $\pi_{i1} = \frac{\Gamma}{1+\Gamma}$ ʙ Ẅ Ä ŝ

$$S_i \sim \text{Bernoulli}\left(\frac{\Gamma}{1+\Gamma}\right).$$

Ɣ ↓ ŋ ‖ Rosenbaum 1987b, Theorem ĸ Õ Ō A Ẅ Ä Ä ᴛ Δ ₩ ♭ ₥ ĵ Ẅ Ä
ᴘ ĵ p
Y J ŝ ₹ Γ ₹ ŏ $\frac{\Gamma}{1+\Gamma}$ ₹ ⁼ 1 ŏ Ω ₥ U Ẅ Ä ŏ ŗ J ë ₹
Ḯ ⌐ ₥ ₀ Y B ʜ ĵ ŗ J ŋ $q_i >$ Ⓠ ŏ Ō Ẅ Ä ₥ ₭ ŗ J ĵ ” ʜ ” ë ᴘ ŏ ₹
N ̈ ë ₸ ⁀ Ü ⓐ ₲
ă ŝ ₹ Γ = 1 ₥ ŏ $\frac{\Gamma}{1+\Gamma} = \frac{1}{2}$ ŏ ₫ Ḧ ₸ ‴ ₥ ĵ ₥ ŏ ↓ ĵ ˘
♦ ▯ ŝ ₭ ŏ Assumption 19.1 ŏ Ü ∂ ₲ H_{0F} ₒ Ī ₥ ŏ S_i ĵ Ω ₥ U Ẅ Ä
Bernoulli$\left(\frac{\Gamma}{1+\Gamma}\right)$

‖ q ₩ ₫ ₩ U s ĵ ₍ ₥ Ω ₥ ₥ Ī ₍ ₥

ẋ fi ŝ Ḧ ⁀ ĵ ⌐ Ω ŏ ↓ Ɣ ᴘ ŋ Ω ₥ U p ĵ ₍ ₥ Ω ₥ ₥ Ī ₍ ₥
、 **a Z l** 。 **— ĵ** ₥ U **— a** 。 ŝ ₹ **— a** q_i **J** $= 1$ for all i ₥ ŏ ⌐ Ω $T = \sum_{i=1}^{n} S_i$ ă ŗ Ô Ẅ Ä
$B(n, \pi)$ ŏ ↺ $\pi = \frac{\Gamma}{1+\Gamma}$

▫ ▫ p ▫

$$\mathrm{p}_\Gamma = 2\sum_{k=T}^{n}\binom{n}{k}\left(\frac{\Gamma}{1+\Gamma}\right)^k\left(\frac{1}{1+\Gamma}\right)^{n-k}.$$

**▫ a g J p⟩ p l ▫ a Z l Q N _ ▫ ; l ▫ ▫ ▫

APPENDIX B

◆ ■ ▲

■ ■ ▼

■ ■ ■

X wÿ ₼

Ï $f_{1,x} \in [0,1]$ðÝ ¡þ»

$$g(t) = \frac{(a-1)t+1}{(a-1)\frac{t}{b}+1}$$

$a > 1, b > 1$ ø t ß^{v}ð ŋ { Ô{^{B} $f_{1,x}$ ^{p}Ô $\mathrm{RR}^{\mathrm{obs}}_{ZY|x}$ ^{p} ₼Ł $f_{1,x} = 1$ŝ

$$\mathrm{RR}^{\mathrm{obs}}_{ZY|x} \le \frac{(\gamma_x - 1) + 1}{\frac{\gamma_x - 1}{\mathrm{RR}_{ZU\ x}} + 1} = \frac{\gamma_x \cdot \mathrm{RR}_{ZU|x}}{\gamma_x + \mathrm{RR}_{ZU|x} - 1}.$$

¿ ¦ { {¦₼Ł { {

W wŵ¿ø

₼ þð ø¿ø½kÿ¤Δ ¨A:ø¿¦ñ¿ø¿Nu¨W¨W¿ø₼Ł Ô { {ñ¿ø¿ø Ⱥø¿¨A Ł ø Ł Ï ø (f_{1,x}, \mathrm{RR}_{ZU|x}, \mathrm{RR}_{UY|x})ðÑ¦ { {₼Ł ø¿ŵⱥĬ ø ₼ñ¿ ø¿ø¿ ă ø¿ø ð ñ¿ø K ¨A Ł ø Ł Ø§§ ø¿Ł ø Ł Ẅ ø¿Ł Kᾱ ∫¦₼ñ

APPENDIX C

$\beta(w_1, w_2) = w_1 w_2/(w_1 + w_2 - 1)$ $w_1 > 1, w_2 > 1$

$\beta(w_1, w_2) = \beta(w_2, w_1)$

$$\frac{\partial \beta}{\partial w_1} = \frac{w_2(w_1 + w_2 - 1) - w_1 w_2}{(w_1 + w_2 - 1)^2} = \frac{w_2(w_2 - 1)}{(w_1 + w_2 - 1)^2} > 0.$$

$\partial \beta / \partial w_2 > 0$ β

$$\beta(w_1, w_2) = \frac{w_1 w_2}{w_1 + w_2 - 1} \leq \frac{w_1 w_2}{w_1} = w_2 \quad (\qquad w_2 - 1 \geq 0).$$

$\beta \leq w_1$

$= \max(w_1, w_2)$ $w_1 = w$ $w_2 \leq w$

$$\beta(w_1, w_2) = \frac{w \cdot w_2}{w + w_2 - 1} \leq \frac{w \cdot w}{w + w - 1} = \frac{w^2}{2w - 1}.$$

APPENDIX D

$$\beta_1 = \log \mathrm{OR}_{ZY|x} = \log \frac{\mathrm{odds}(Y=1 \mid Z=1, X=x)}{\mathrm{odds}(Y=1 \mid Z=0, X=x)}.$$

$$\mathrm{odds}(Y=1 \mid Z, X) \approx \frac{\Pr(Y=1 \mid Z, X)}{1-\Pr(Y=1 \mid Z, X)} \approx \Pr(Y=1 \mid Z, X).$$

$$\beta_1 \approx \log \mathrm{RR}^{\mathrm{obs}}_{ZY|x}.$$

APPENDIX E

◆ ◆ ◆

◆ ◆ ◆

◆ ◆ ◆

$$Y = ZY(1) + (1 - Z)Y(0) \qquad E\{Y \mid Z = 1\}$$

$$E\{Y \mid Z = 1\} = E\{Y(1) \mid Z = 1\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 1\right].$$

$$\tau = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 1\right] - E\left[\mu_0(X)\varepsilon_0(X) \mid Z = 1\right].$$

APPENDIX F

q wwf ۴H

$$E\{Y(1) \mid Z = 0\} = E\left\{\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 0\right\}.$$

IPW

$$E\{Y(1)\} = E\{Y(1) \mid Z = 1\}\Pr(Z = 1) + E\{Y(1) \mid Z = 0\}\Pr(Z = 0).$$

$E\{Y(1) \mid Z = 1\} = \mu_1(X)/\varepsilon_1(X)$ $E\{Y(1) \mid Z = 0\} = \mu_1(X)/\varepsilon_1(X)$

$$E\{Y(1)\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)}\right].$$

$e(X) = \Pr(Z = 1 \mid X)$ IPW

$$E\{Y(1)\} = E\left\{\frac{ZY}{e(X)}\right\} = E\left\{w_1(X)\frac{ZY}{e(X)}\right\},$$

$w_1(X) = e(X) + (1 - e(X))/\varepsilon_1(X)$

$E\{Y(0)\}$

APPENDIX G

Ôĥŝ i ; l 。 ¢ł ą

q w

V• þ W∂ φ outcomes Ł [y, ȳ] ø E{Y(1)} Ù E{Y(0)} łŁ

‖ w

e p = Pr(Z = 1)ŏ Pr(Z = 0) = 1 − p e μ1 = E(Y | Z = 1) Ù μ0 = E(Y | Z = 0)ŏ ¿ Ì J ƀ C ▪ ÍIQł

~w E{Y(1)} łŁ

¿ÓÔ Ź ĭ ŝ

$$E\{Y(1)\} = \mu_1 \cdot p + E\{Y(1) \mid Z = 0\} \cdot (1 - p).$$

$Y(1) \in [\underline{y}, \overline{y}]$ŏ

$$\underline{y} \le E\{Y(1) \mid Z = 0\} \le \overline{y}.$$

B

$$\mu_1 \cdot p + \underline{y}(1 - p) \le E\{Y(1)\} \le \mu_1 \cdot p + \overline{y}(1 - p).$$

X w E{Y(0)} łŁ

ł ŝ

$$E\{Y(0)\} = E\{Y(0) \mid Z = 1\} \cdot p + \mu_0 \cdot (1 - p),$$

ſ

$$\underline{y} \le E\{Y(0) \mid Z = 1\} \le \overline{y}.$$

B

$$\underline{y} \cdot p + \mu_0(1 - p) \le E\{Y(0)\} \le \overline{y} \cdot p + \mu_0(1 - p).$$

W w łŁ

$\tau = E\{Y(1)\} - E\{Y(0)\}$ŏ β ł Ł Ł ĺ ŝ

$$\underline{\tau} = \mu_1 p + \underline{y}(1 - p) - \overline{y}p - \mu_0(1 - p),$$

$$\overline{\tau} = \mu_1 p + \overline{y}(1 - p) - \underline{y}p - \mu_0(1 - p).$$

Ł Ł Ę $\overline{y} - \underline{y}$

ˇ wŴÎŠSÑ¡ Þ

ˇ w q ẃ ẅ] ¾ Ø¡ wẁ ñ Š ă´ ò τ = 𝔼[Y_i(1) − Y_i(0)] Ì Ṽ´ Ø¡
ÆĦ Š ¡ { {
Þä Š

(146) $$\tau = \mathbb{E}[Y_i(1) - Y_i(0)]$$

(147) $$= \frac{1}{n}\sum_{i=1}^{n}[Y_i(1) - Y_i(0)] \quad \text{ŋ¡ Ì} \quad /ÇÕ$$

(148) $$= \frac{1}{n}\sum_{i=1}^{n} Y_i(1) - \frac{1}{n}\sum_{i=1}^{n} Y_i(0)$$

(149) $$= \bar{Y}(1) - \bar{Y}(0)$$

˛Δ { {Þ

ˇ w ‖ ẁ Ì Þ wñ Š ò τ_x ¯ Ka X_i = x Ì
F Ŏ ´ ò
ÆĦ Š Þ { {
Þä Š

(150) $$\tau_x = \mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x]$$

(151) $$= \frac{\sum_{i=1}^{n} \mathbb{I}(X_i = x)[Y_i(1) - Y_i(0)]}{\sum_{i=1}^{n} \mathbb{I}(X_i = x)} \quad \text{ŋ F¡ Ì Ṽ/ÇÕ}$$

Ś 𝕀(X_i = x) ¡ ŋ ŏ X_i = x Ø 1ŏÅ 0
ÀΠΔ { {

ˇ w ~ ẁ Ẅ ¡ Ø Þ wñ Š ´ ò Ì Ẁ À ò Ì-
´
ÆĦ Š ¡ { {

þä Ŝ

$$\tau = \frac{1}{n}\sum_{i=1}^{n}\{Y_i(1) - Y_i(0)\} \tag{152}$$

$$= \frac{1}{n}\sum_{i=1}^{n}\big[\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0)\big]\{Y_i(1) - Y_i(0)\} \tag{153}$$

Ś Vβ ♭ $\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$ (154)

$$= \underbrace{\frac{1}{n}\sum_{i=1}^{n}\mathbb{I}(X_i = 1)\{Y_i(1) - Y_i(0)\}}_{\text{treatment}} + \underbrace{\frac{1}{n}\sum_{i=1}^{n}\mathbb{I}(X_i = 0)\{Y_i(1) - Y_i(0)\}}_{\text{control}} \tag{155}$$

$$= \frac{n_1}{n}\cdot\underbrace{\frac{\sum_{i=1}^{n}\mathbb{I}(X_i = 1)\{Y_i(1) - Y_i(0)\}}{n_1}}_{\tau_1} + \frac{n_0}{n}\cdot\underbrace{\frac{\sum_{i=1}^{n}\mathbb{I}(X_i = 0)\{Y_i(1) - Y_i(0)\}}{n_0}}_{\tau_0} \tag{156}$$

$$= \pi_1\tau_1 + \pi_0\tau_0 \tag{157}$$

Ś $n_1 = \sum_{i=1}^{n}\mathbb{I}(X_i = 1)$ŏ $n_0 = \sum_{i=1}^{n}\mathbb{I}(X_i = 0)$ŏ$_{\text{þ}}$ $\pi_x = n_x/n$
¸Δ { { þ

˅ **w** X **w**Ïlw lJw ă wkfi Ŝw´ ù ¡ẇ lJŏb w 8
gÏlw lJ¡ẇ¡ lJ
FĤ ŜÀm $\delta_1 \neq \delta_2$ lJV w ă
ă ŝ˜ l $n = 4$ Aβ ŏ. ♦ù$_{\text{þ}}$ Ŝ

i	$Y_i(1)$	$Y_i(0)$
1	10	2
2	8	3
3	6	4
4	4	5

Q$_{\text{þ}}$Ŝ

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 7 - 3.5 = 3.5$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{8, 5, 2, -1\} = 3.5$

Bă $\delta_1 = \delta_2$
ăgă ŝ˜ l $n = 5$ Aβ Ŝ

i	$Y_i(1)$	$Y_i(0)$
1	100	1
2	90	2
3	50	3
4	10	4
5	5	5

Q$_{\text{þ}}$Ŝ

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 50 - 3 = 47$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{99, 88, 47, 6, 0\} = 47$

... $\delta_1 > \delta_2$ ...

i	$Y_i(1)$	$Y_i(0)$
1	100	0
2	1	0
3	1	0
4	1	0

...

- $\delta_1 = 50.5 - 0 = 50.5$
- $\delta_2 = \text{median}\{100, 1, 1, 1\} = 1$

... $\delta_1 = 50.5 > \delta_2 = 1$ ... δ_1 ... δ_2 ...

...

... q... ... ... $\hat{\tau}_X$ ...

... $\text{cov}(\hat{\tau}_X) = \frac{n}{n_1 n_0} S_X^2$ ...

... R^2 ... ... R^2 ...

... { {

... ... $\hat{\tau}(\beta_1, \beta_0)$ ...

... a l o f ... ... $\hat{\tau}(\hat{\beta}_1, \hat{\beta}_0)$ ... OLS ... Z_i ... OLS ...

... ... $\hat{\tau}_{\text{pred}} = \hat{\tau}_{\text{L}}$

Lin ...

... ... $\hat{\tau}(\beta_1, \beta_0)$ ...

... $\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ ...

[1] ...

[illegible]

[illegible] $\sum_{i=1}^n (a_i - \bar{a})^2 = \sum_{i=1}^n a_i^2 - n\bar{a}^2$ [illegible]
$\mathrm{var}(W) = \mathbb{E}(W^2) - (\mathbb{E}W)^2$ [illegible]

$$\begin{aligned} n(n-1)\mathbb{E}(\hat{V}) &= \mathbb{E}\left\{\sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2\right\} \\ &= \mathbb{E}\left(\sum_{i=1}^n \hat{\tau}_i^2 - n\hat{\tau}^2\right) \\ &= \sum_{i=1}^n \left\{\mathrm{var}(\hat{\tau}_i) + \tau_i^2\right\} - n\left\{\mathrm{var}(\hat{\tau}) + \tau^2\right\} \\ &= \sum_{i=1}^n \mathrm{var}(\hat{\tau}_i) - n\mathrm{var}(\hat{\tau}) + \sum_{i=1}^n \tau_i^2 - n\tau^2 \\ &= n^2\mathrm{var}(\hat{\tau}) - n\mathrm{var}(\hat{\tau}) + \sum_{i=1}^n (\tau_i - \tau)^2. \end{aligned}$$

[illegible]

$$\mathbb{E}(\hat{V}) = \mathrm{var}(\hat{\tau}) + \{n(n-1)\}^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \geq \mathrm{var}(\hat{\tau}).$$

□

[illegible] $(\hat{\tau}_1, \ldots, \hat{\tau}_n)^\top$ [illegible] OLS [illegible]

$$\hat{\beta}_0 = \bar{\hat{\tau}} = n^{-1} \sum_{i=1}^n \hat{\tau}_i = \hat{\tau},$$

[illegible] $\hat{\tau}$
[illegible] $\hat{\varepsilon}_i = \hat{\tau}_i - \hat{\tau}$ [illegible]

$$\hat{\sigma}^2 = (n-1)^{-1} \sum_{i=1}^n \hat{\varepsilon}_i^2 = (n-1)^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2 = \hat{V}.$$

[illegible] $\hat{\tau}$ [illegible] $\hat{V}$ [illegible] OLS [illegible] □

[illegible]

[illegible] t [illegible] H_{0F} [illegible] $\hat{\tau}_i = S_i D_i$ [illegible] $S_i = 2Z_i - 1 \in \{-1, 1\}$
[illegible] $D_i = Y_{i1} - Y_{i2}$ [illegible] S_i [illegible] 0 [illegible] 1 [illegible]

$$\mathrm{var}(\hat{\tau}_i) = \mathbb{E}(S_i^2 D_i^2) - \mathbb{E}(S_i)^2 \mathbb{E}(D_i)^2 = D_i^2 - 0 = D_i^2 = \hat{\tau}_i^2.$$

[illegible]

$$\frac{\hat{\tau} - \mathbb{E}\hat{\tau}}{\sqrt{\mathrm{var}(\hat{\tau})}} = \frac{\hat{\tau}}{\sqrt{n^{-2}\sum_{i=1}^n \hat{\tau}_i^2}} \to \mathrm{N}(0,1)$$

[illegible] □

mw ‖ w 〔a g[illegible]Jp[illegible] p l w H_{0F} ŏ $|\hat{\tau}_i|$ [illegible] B R_i [illegible] $U_i = \mathbb{I}(\hat{\tau}_i > 0)$ŏ $W = \sum_{i=1}^n U_i R_i$ $U_i \overset{\text{IID}}{\sim} \text{Bernoulli}(1/2)$ [illegible] R_i [illegible]

$$\mathbb{E}(W) = \sum_{i=1}^n \mathbb{E}(U_i) R_i = \frac{1}{2} \sum_{i=1}^n i = \frac{n(n+1)}{4},$$

$$\text{var}(W) = \sum_{i=1}^n \text{var}(U_i) R_i^2 = \frac{1}{4} \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{24}.$$

[illegible] { [illegible] □

mw [illegible] w [illegible] **w** H_{0F} ŏ $\Delta = \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i > 0) \sim \text{Binomial}(n, 1/2)$

$$\frac{\Delta - n/2}{\sqrt{n/4}} \to \text{N}(0,1)$$

[illegible] □

q [illegible]

MPE ŏ[illegible] i [illegible] Z_iŏ[illegible] $1 - Z_i$ B

$$\hat{\tau}_i = Z_i Y_{i1} + (1 - Z_i) Y_{i2} - [(1 - Z_i) Y_{i1} + Z_i Y_{i2}] = (2Z_i - 1)(Y_{i1} - Y_{i2}) = S_i D_i,$$

[illegible] $S_i = 2Z_i - 1$ŏ $D_i = Y_{i1} - Y_{i2}$

$Z_i \overset{\text{IID}}{\sim} \text{Bernoulli}(1/2)$ŏ [illegible] $\mathbb{E}(Z_i) = 1/2$ŏ $\text{var}(Z_i) = 1/4$ŏ B $\mathbb{E}(S_i) = 0$ŏ $\text{var}(S_i) = 1$ B ŏ S_i D_i [illegible] D_i [illegible] S_i [illegible]

$$\mathbb{E}(\hat{\tau}_i) = \mathbb{E}(S_i)\mathbb{E}(D_i) = 0,$$

$$\text{var}(\hat{\tau}_i) = \mathbb{E}(S_i^2)\mathbb{E}(D_i^2) - \mathbb{E}(S_i)^2 \mathbb{E}(D_i)^2 = 1 \cdot \mathbb{E}(D_i^2) = \mathbb{E}(D_i^2).$$

$D_i = Y_{i1} - Y_{i2}$ŏ

$$\mathbb{E}(D_i^2) = \mathbb{E}\left[\{Z_i Y_{i1}(1) + (1 - Z_i) Y_{i1}(0) - Z_i Y_{i2}(0) - (1 - Z_i) Y_{i2}(1)\}^2\right].$$

[illegible] $Z_i^2 = Z_i$ŏ $(1 - Z_i)^2 = 1 - Z_i$ŏ $Z_i(1 - Z_i) = 0$ŏ[illegible] [illegible] $\mathbb{E}(Z_i) = 1/2$ [illegible] $\mathbb{E}(Z_i^2) = 1/2$ [illegible] $\text{var}(\hat{\tau}_i) = \mathbb{E}(Y_{i1}(1) - Y_{i2}(1) - Y_{i1}(0) + Y_{i2}(0))^2/4 = \tau_i^2$ [illegible] ŏ $\hat{\tau} = n^{-1} \sum_{i=1}^n \hat{\tau}_i$ [illegible]

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i) + [illegible] \quad .$$

Z_i [illegible] $\hat{\tau}_i$ [illegible] B [illegible] ŏ

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i).$$

□

[2] [illegible]

q q [illegible] p

[illegible] (i, j) [illegible] X_{ij} [illegible]

$$\hat{\tau}_{X,i} = X_{i1} - X_{i2},$$

[illegible] $\hat{\tau}_X = n^{-1} \sum_{i=1}^{n} \hat{\tau}_{X,i}$
MPE [illegible] Z_i [illegible] X_{ij} [illegible]

$$\mathbb{E}(\hat{\tau}_{X,i}) = \mathbb{E}(X_{i1} - X_{i2}) = \mathbb{E}(X_{i1}) - \mathbb{E}(X_{i2}) = 0,$$

[illegible] $\mathbb{E}(\hat{\tau}_X) = 0$

$$\mathrm{cov}(\hat{\tau}_X) = n^{-2} \sum_{i=1}^{n} \mathrm{cov}(\hat{\tau}_{X,i}) = n^{-2} \sum_{i=1}^{n} \hat{\tau}_{X,i} \hat{\tau}_{X,i}^{\top},$$

[illegible] $\hat{\tau}_{X,i}$ [illegible]
[illegible] $\hat{\tau}(\gamma) = \hat{\tau} - \gamma^{\top} \hat{\tau}_X$ [illegible]

$$\mathrm{var}(\hat{\tau}(\gamma)) = \mathrm{var}(\hat{\tau}) + \gamma^{\top} \mathrm{cov}(\hat{\tau}_X) \gamma - 2\gamma^{\top} \mathrm{cov}(\hat{\tau}_X, \hat{\tau}).$$

[illegible]

$$\tilde{\gamma} = \mathrm{cov}(\hat{\tau}_X)^{-1} \mathrm{cov}(\hat{\tau}_X, \hat{\tau}).$$

$\mathrm{cov}(\hat{\tau}_X)$ [illegible] $\mathrm{cov}(\hat{\tau}_X, \hat{\tau})$ [illegible] { {
[illegible] $\hat{\theta}$ [illegible]
[illegible] $\hat{\gamma}$ [illegible] $\hat{\tau}_{\mathrm{adj}} = \hat{\tau} - \hat{\gamma}^{\top} \hat{\tau}_X$ [illegible] $\hat{V}_{\mathrm{adj}}$ □

q [illegible] [illegible] [illegible] p e [illegible] [illegible] p [illegible] s

1 8 [illegible]

[illegible]	[illegible] $\hat{\tau}_{X,i}$ [illegible]	$\hat{\tau}_i$
1	-1	-5
2	2	-1
3	0	3
4	1	2
5	2	5
6	0	-3
7	0	-1
8	2	9

[illegible]

$$\hat{\tau} = \frac{1}{8} \sum_{i=1}^{8} \hat{\tau}_i = \frac{-5 + (-1) + 3 + 2 + 5 + (-3) + (-1) + 9}{8} = \frac{9}{8} = 1.125.$$

[illegible]

$$\hat{V} = \frac{1}{8 \times 7} \sum_{i=1}^{8} (\hat{\tau}_i - \hat{\tau})^2 = \frac{1}{56} \left[(-6.125)^2 + (-2.125)^2 + (1.875)^2 + \cdots \right] \approx 4.98.$$

95% [illegible] $\hat{\tau} \pm 1.96 \sqrt{\hat{V}} = 1.125 \pm 1.96 \times 2.23 = [-3.25, 5.50]$

... $\hat{\gamma}$ ... $\hat{\tau}_{\text{adj}}$ [3]

...

...

... ignorability ...

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = \Pr\{Z = 1 \mid e(X)\}.$$

... tower property ...

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{Z \mid Y(1), Y(0), e(X)\}.$$

... tower property ... X ... $Y(1), Y(0), e(X)$ ...

$$E\{Z \mid Y(1), Y(0), e(X)\} = E\big[E\{Z \mid Y(1), Y(0), X\} \mid Y(1), Y(0), e(X)\big].$$

... ignorability ... $Z \perp \{Y(1), Y(0)\} \mid X$ ...

$$E\{Z \mid Y(1), Y(0), X\} = E\{Z \mid X\} = e(X).$$

...

$$E\{Z \mid Y(1), Y(0), e(X)\} = E\{e(X) \mid Y(1), Y(0), e(X)\} = e(X).$$

...

$$\Pr\{Z = 1 \mid e(X)\} = E\{Z \mid e(X)\} = E\big[E\{Z \mid X\} \mid e(X)\big] = E\{e(X) \mid e(X)\} = e(X).$$

...

... $\sim$ ... R ...

```
# 读取数据
nhanes'bmi = ... ("nhanes'bmi.csv")[, -1]
z = nhanes'bmi...schoolmeal
y = nhanes'bmi...BMI
x = ... (nhanes'bmi[, -...(1, 2)])
x = ... (...)  # 标准化协变量

# 估计倾向得分
pscore = ... > x, ... ...

# 倾向得分分层
n.strata = ...(5, 10, 20, 50, 80)
strat.res = ... strata, FUN = ...
  ...pscore = ... (1:(nn-1)) ... nn)
  ...strata = ...(pscore, breaks = ...(0, ..., 1),
                  ... 1:nn)
  Neyman'SRE(z, y, ...strata)
})

  ...(strat.res) = ("est", "se")
...(strat.res) = n.strata
```

[3] ...

p ‘ (lsNrat.res , 3)

ʃ Neyman_SRE ⋯ { { ⋯ SRE ⋯ Neyman ⋯

H

q X⋯ ‖ mw⋯q

⋯ { { ⋯

$$E\{Y(z_1, z_2)\} = E[E\{Y(z_1, z_2) \mid X_0\}]$$

B ⋯ $E\{Y(z_1, z_2) \mid X_0\}$ Assumption { (1) ⋯

$$\begin{aligned} E\{Y(z_1, z_2) \mid X_0\} &= E\{Y(z_1, z_2) \mid z_1, X_0\} \\ &= E[E\{Y(z_1, z_2) \mid z_1, X_1, X_0\} \mid z_1, X_0] \end{aligned}$$

Assumption { (2)⋯

$$\begin{aligned} E\{Y(z_1, z_2) \mid X_0\} &= E[E\{Y \mid z_2, z_1, X_1, X_0\} \mid z_1, X_0] \\ &= E\{E(Y \mid z_2, z_1, X_1, X_0) \mid z_1, X_0\} \end{aligned}$$

⋯ { { □

APPENDIX A

q w

q w q w w

subgroup X_i $\tau = \pi_1\tau_1 + \pi_0\tau_0$ w $\tau = \pi_1\tau_1 + \pi_0\tau_0$

$\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$

q w w

H_{0F} Y w Fisher's sharp null ($H_{0F} : Y_i(1) = Y_i(0)$) Y

H_{0F} treatment $Y_i(1) = Y_i(0) = Y_i$ i $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y}$

FRT condition on Y $\mathbf{Z}$ FRT"

$M = \binom{n}{n_1}$

q w X w s ' i p l — Q I g p w { { $\tilde{p}_{frt}$

i p l — Q I ĝ p

$$\hat{p}_{frt} = \frac{1}{R}\sum_{r=1}^{R}\mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$$

R p

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^{R}\mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

i 1 " " E E

$R = 99$ 0

$$\hat{p}_{frt} = \frac{0}{99} = 0$$

M $1/M$ 0

-Δ 1 Ẅ ̣Q Ẅ ̧ŝŝ

$$\tilde{p}_{frt} = \frac{1}{100}$$

ħ Δŝ

(1) p ăk‰ 0ŋẄ ◆ ̧ 1Ô
(2) ̧ ̣ Ị R ̣ Ḅ Ṽ ŝ $\mathbb{P}(p \le u) \le u$
(3) ɾ $R \to \infty$ ◆ ŏ $\tilde{p}_{frt} \to \hat{p}_{frt}$

q w Ẉ ̣ẅ w ≺ Ṽ : ̧ ≺ ̣ w ŝ FRT Ị p ◆ ̣ ̧ ” Ṽ : ̧ ”Ţ
ɔ ŝŭ ̧ { ‖ ̣ m Ị ă ̧ ◆ ŝ

$$\mathbb{P}(p_{frt} \le u) \le u \quad \text{for all } u \in [0,1]$$

▪ Ṽ ŋ finite-sample validity Ô ◆ ̧ ŝ □ Ṽ ̣ K ~ ◆ ɔ Ẅ Ä
◆ ̣ Q ŏ p_{frt} Ị Ẅ Ä ă k ̧ ↺ Ẅ Ä K
Ḧ Ç и t ⌐ Ŝ ̣ ◆ p Ṽ ə ≠ ◆ ŋ ╚ ≠ ŏ Ô Ṽ ◆ ı ɔ ̧ ◆ FRT
Ị : ̧ ◆ ◆ ₂ ω ₂ ŏ ă ◆ ̧ ̣ Q ╚ ≠ ∂ ◆ ̧

q w ˅ w U ◆ ̣ ̇ 。 ^ ” Q ◆ и ṭ Ṙ w ŝ Fisher Ị ◆ ɔ Q ̣ q Ṙ ̣ и Ω g ◆ ̧ Ṽ ̧ ◆ Q Ţ
ɔ ŝ

- и ṭ Ṙ ŝ “ ◆ ɔ Ẅ Ä ∂ ◆ ̧ Ḳ Ɛ ę Ţ ”§§ ◆ ɔ Ẅ Ä ∂ ◆ ̧
- **U a 。 ^ ṭ Ṙ Q** ŝ “ ◆ ̧ ∂ ◆ ̧ ₂ ω Ô ‰ Ɛ ◆ ̧ K Ɛ ę Ị ◆ ɔ Ţ ”§§ ◆ ₂ ω ₂

Fisher ṭ Ṙ Ị ŝ sharp null ŋ ẁ Ô ∂ ◆ ̧ ŏ ▲ ♦ ẁ ̧ ∂ Ỿ ɑ ʁ
Ị ɔ ̧ ∂ ◆ ₂ Ẅ ̲ ◆ ı Ỿ ◆ ̧ ı Ị ŏ Ω ◆ ̧ V A Ɛ ◆ Ị Ω ı
и ṭ Ṙ ◆ ɔ Ẅ Ä Ị ◆ ̧ Ẅ Ä ∂ ◆ ̧ ŋ ◆ ̧ ₂ ₂ ₂

q w R w — **w** FRT

- t
- t

U ~ + sharp null t Monte Carlo

- FRT ” ” treatment ”
- FRT ” ” ”

FRT CLT t

FRT p

q w w w **w** Fisher

Potential Outcomes treatment

- $Y_i(1)$ i treatment
- $Y_i(0)$ i control

treatment

counterfactual

$$Y_i^{obs} = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$$

$Z_i = 1$ treatment $Y_i(1)$ $Z_i = 0$ $Y_i(0)$ $Y_i(1) - Y_i(0)$ i

q w q w **w** Fisher

I p j s ; ; B g a — treatment control selection bias

` l V Q Q l J Q a

” ” ” ” t

randomization mechanism

p

(1) H_{0F} treatment $Y_i(1) = Y_i(0)$

(2)

(3) Monte Carlo

(4)

” ” ” ”

q w q Fisher Randomization Test

ŋ Fisher

ɔ ŝ Fisher Randomization Test (FRT) Ronald Fisher 1935 ȝ³ Design of Experiments´

(1) **Y**

(2) **Z**

(3) CRE **Z** $\binom{n}{n_1}$

(4)

(5) p condition on **Y** condition on

FRT condition on p

finite-sample exactness

q w q $\{\mathbf{z}^1, \ldots, \mathbf{z}^M\}$ **w** ŝ CRE **Z** $\{\mathbf{z}^1, \ldots, \mathbf{z}^M\}$

ɔ ŝ

Z $\mathbf{Z} = (Z_1, \ldots, Z_n)$ $Z_i = 1$ i $Z_i = 0$ i

$\{\mathbf{z}^1, \ldots, \mathbf{z}^M\}$ $n = 3, n_1 = 1$

$$\mathbf{z}^1 = (1,0,0), \mathbf{z}^2 = (0,1,0), \mathbf{z}^3 = (0,0,1)$$

$M = \binom{3}{1} = 3$

Z CRE

$\mathbf{z}^m$

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}^m) = \frac{1}{M} = \frac{1}{\binom{n}{n_1}}$$

$n = 100, n_1 = 50$ $M \approx 10^{29}$

ŋ 10^{-29}

ŝ CRE treatment control

Fisher ”randomization provides a valid basis for inference”

q w q **Z** **w** **Z**

Z

ɔ ŝ

Z Fisher treatment

n **Z** $\mathbf{Z} = (Z_1, Z_2, \ldots, Z_n)$ n ŝ

- $Z_i = 1$ŝ$_\beta$ i ⋆ treatment ŋ ʁ Ô
- $Z_i = 0$ŝ$_\beta$ i ⋆ control ŋ Ĥ Ô

ɑ̈ ɻ ʁ $n = 5, n_1 = 2$ ᵽ Ô ˜A Ɣ ɪ ŋ Ẅ ˙ ɰ $\mathbf{Z} = (1, 0, 0, 1, 0)$ ǒ ʜ ɷ ᵒ 1˜ 4 ɷ̌ $_\beta$ ⋆ ⋆ ʁ ǒ ᵒ 2˜ 3˜ 5 ɷ̌ $_\beta$ ⋆ ⋆ Ĥ

⋆ ɰ ˙ ɰ Ẅ Ä ɰ ɰ ɕ ɷ $_2$ ɷ ŋ CRE Ô ǒ ʁ Ẅ ˙ ɰ ɕ ɷ $_2$ ɻ §§ V A Ɣ ɪ ɻ **Z** ɵ ɻ Ô ɻ ɾ ᵓ ɰ ˙ Ẅ Ä ” ɻ A ˙ ʏ ⋆ ⋆ ɻ ɰ Ẅ ˙ $M = \binom{n}{n_1}$ ǒ V ɵ ɻ Ô ɻ Ð ɰ $1/M$ ɷ̌ ɑ̈ ɻ Ŝ

- $n = 3, n_1 = 1$ ᵽ ǒ $M = 3$ ǒ ɷ̃ Ɣ ɪ Ŝ $(1, 0, 0)$˜ $(0, 1, 0)$˜ $(0, 0, 1)$ ǒ Ô ɻ À $1/3$
- $n = 100, n_1 = 50$ ᵽ ǒ $M \approx 10^{29}$ ǒ V Ô ɻ 10^{-29}

z^r ɰ ⋆ ɻ Ţ Monte Carlo ɾ ɷ ǒ ɷ Ŕ Ɣ ɪ ɰ ɕ ⋆ æ M Ẅ ˙ ʙ ɷ V R ᴱ ɷ $_2$ ǒ V ᴱ k ɣ ʙ ˜A **z**^{r} V A **z**^{r} D ɰ ⋆ Ĥ ɷ **Z** ɻ ᴱ Ô ɻ ɷ ★ ` **l** 。 **â** ⋆ **Z** ^ — **Z** ɻ ŭ ɾ ɰ Ŝ ɷ ɰ ˜A ɷ ɰ ɻ ɷ ɪ ŋ indicator vector ɷ ɰ Ô ɻ ɷ ˜A ʁ ɻ ɷ ⋆ ⋆ ɷ ɷ ɷ ɷ ʁ ǒ ɷ ɰ ⋆ ⋆ Ĥ ” Monte Carlo ɾ ɰ Ŕ ɰ ɷ ɕ ɻ ɷ ˜A ɷ $_2$ Ẅ ˙ ɰ ɷ ǒ ɷ ɷ Ɣ ɪ Ẅ ˙ ɻ ˙ Ɋ Ẅ Ä

q w q ɷ **X** ɷ **w** Ẅ ŋ **r p — Q l — a ; g** ɷ̈ **‘ w — J** ɷ ɷ̈ **p** ɷ̈ **j** ɷ̈ **Q**。 ” ɷ ⋆ ɷ̈ ” ŋ Potential Outcomes ɷ̈ Ô

ᵓ Ŝ ɷ ⋆ ɷ̈ ŋ Potential Outcomes Ô ɰ ɷ ˜A ɷ̈ $_\beta$ ** ă ɪ ɻ ɾ ** Ɣ ɪ Ɣ ɪ ɷ B ɷ̈ ɻ ɷ̈ ⋆ Ĥ $_\beta$ i Ŝ

- $Y_i(1)$ŝ$_\beta$ i ⋆ treatment Ĭ ɻ ⋆ ɷ̈ ŋ ɷ ɻ Ĭ ɻ ˜ ê ʍ ɷ Ô
- $Y_i(0)$ŝ$_\beta$ i ⋆ control ɻ ⋆ ɷ̈ ŋ ɷ ă ă ɻ ʍ ɷ Ô

ɷ̈ Ô ŝ ɷ ɷ̈ ɻ ɷ̈ ɷ̈ ɷ̈

q w ‖ Randomization Assumption **w** Randomization Assumption

ɔ $Z \perp (Y_i(0), Y_i(1), D_i(0), D_i(1))$

q w ‖ Weak IV Problem **w** Weak IV Problem

ɔ treatment F F Staiger-Stock 10

q w ‖ LATE **w** ” ” LATE ATE

ɔ Compliers” variation Compliers $D_i(1) > D_i(0)$ Defiers Always-takers Compliers ATE LATE

w m **w** Y $m(X) = \mathbb{E}[Y|X]$

w **w**

f p Z a m **w** Logit

~ p B a l 。 j Q N a ; — a p l V p w g ; Robins mediation formula latent groups

w Y

w cross-world independence mediation analysis

、 ‘ p Z ; — Q b **w** Surrogate Sr Jr

当你在阅读过程中提出问题时，回答将被记录在此处。

‖ w≠e

在这里记录你的学习心得和思考。

A a B g a p Z ; s ^ 》

Joshua D. Angrist, Guido W. Imbens, and Donald B. Rubin. Identification of causal effects using instrumental variables. *Journal of the American Statistical Association*, 91(434): 444–472, 1996. Cited in Chapter 21.

Peter J. Bickel, Eugene A. Hammel, and J. William O'Connell. Sex bias in graduate admissions: Data from berkeley. *Science*, 187(4175):398–404, 1975. Cited in Chapter 1.

Marie-Abele C. Bind and Lea M. Rattay. When possible, report a fisher-exact p-value and display its underlying null randomization distribution. *Journal of the American Statistical Association*, 115(532):1644–1646, 2020. Cited in Chapter 3.

George E. P. Box, J. Stuart Hunter, and William G. Hunter. *Statistics for Experimenters: An Introduction to Experimental Design*. John Wiley & Sons, 1978. Cited in Chapter 5.

Peng Ding. A paradox from randomization-based causal inference. *Statistical Science*, 32 (3):331–345, 2017. Cited in Chapter 4.

Peng Ding and Tyler J. VanderWeele. Sensitivity analysis without assumptions. *Epidemiology*, 27(3):368–377, 2016. Cited in Chapters 17, 18.

Herman F. Dorn. The planner's dilemma. *Journal of the American Statistical Association*, 48(264):601–604, 1953. Cited in Chapters 18, 21.

Ronald A. Fisher. The design of experiments. *Statistical Research Memoirs*, 1:1–26, 1935. Cited in Chapter 3.

J. L. Hodges and E. L. Lehmann. Rank methods for combination of independent experiments in analysis of variance. *The Annals of Mathematical Statistics*, 33(2):482–497, 1962. Cited in Chapter 5.

Paul W. Holland. Statistics and causal inference. *Journal of the American Statistical Association*, 81(396):945–960, 1986. Cited in Chapters 1, 2, 3.

Guido W. Imbens. Sensitivity to exogeneity assumptions in program evaluation. *American Economic Review*, 93(2):126–132, 2003. Cited in Chapter 18.

Guido W. Imbens and Joshua D. Angrist. Identification and estimation of local average treatment effects. *Econometrica*, 62(2):467–475, 1994. Cited in Chapter 21.

Guido W. Imbens and Donald B. Rubin. *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press, 2015. Cited in Chapters 4, 5.

Gary King and Langche Zeng. The dangers of extreme counterfactuals. *Political Analysis*, 14(2):131–159, 2006. Cited in Chapter 20.

Winston Lin. Agnostic notes on regression adjustments to experimental data: Reexamining freedman's critique. *The Annals of Applied Statistics*, 7(1):295–318, 2013. Cited in Chapter 3.

Bo Lu and Peng Ding. Sensitivity analysis for causal inference: Theory and applications. *Unpublished manuscript*, 2023. Cited in Chapter 18.

Charles F. Manski. Nonparametric bounds on treatment effects. *American Economic Review*, 80(2):319–323, 1990. Cited in Chapter 18.

Charles F. Manski. *Monitoring the dissolving of the Soviet Union*, volume 21. 2003. Cited in Chapter 18.

Jerzy Neyman. Sur les applications de la théorie des probabilités aux experiences agricoles: Essai d'application de la méthode "chia". *Roczniki Nauk Rolniczych*, 10:1–51, 1923. Cited in Chapters 2, 4.

Judea Pearl. On the consistency rule in causal inference. *Biometrika*, 97(2):490–492, 2010. Cited in Chapter 2.

Judea Pearl and Dana Mackenzie. *The Book of Why: The New Science of Cause and Effect*. Basic Books, 2018. Cited in Chapter 1.

Paul R. Rosenbaum and Donald B. Rubin. Assessing sensitivity to an unobserved binary covariate in an observational study with binary outcome. *Journal of the Royal Statistical Society: Series B*, 45(2):212–218, 1983. Cited in Chapters 17, 18, 19.

Donald B. Rubin. Comment: Bayesian inference for causal effects: The role of randomization. *The Annals of Statistics*, 8(1):44–45, 1980. Cited in Chapter 3.

Donald B. Rubin. Causal inference using potential outcomes: Design, modeling, decisions. *Journal of the American Statistical Association*, 100(469):322–331, 2005. Cited in Chapter 2.

Donald B. Rubin. For objective causal inference, design trumps analysis. *The Annals of Applied Statistics*, 2(3):808–840, 2008. Cited in Chapter 20.

P. H. Van Elteren. On the combination of independent statistical tests. *Statistica Neerlandica*, 14(1):11–24, 1960. Cited in Chapter 5.

Tyler J. VanderWeele and Peng Ding. Introducing the e-value. *Annals of Internal Medicine*, 167(4):285, 2017. Cited in Chapters 17, 18.