

$y T w \ f l$

$S 2 M ; . B M ;$

由差值均值的 ANOVA 分解 (见 section 2):

$$(n-1)s^2 = \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2 + \frac{n_1 n_0}{n} \hat{\tau}^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ 。

第四步: 建立联系。

在 OLS 中, $\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{Z}$ 和 $\hat{\beta} = \hat{\tau}$, 因此

$$Y_i - \hat{\alpha} - \hat{\beta}Z_i = Y_i - \bar{Y} - \hat{\tau}(Z_i - \bar{Z}).$$

平方并求和, 得

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - \hat{\tau}^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = (n-1)s^2 - \hat{\tau}^2 \cdot \frac{n_0 n_1}{n}.$$

第五步: 代回 $\hat{V}_{OLS}$ 。

$$\hat{V}_{OLS} = \frac{n}{(n-2)n_0 n_1} \left[(n-1)s^2 - \frac{n_0 n_1}{n} \hat{\tau}^2 \right].$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义以及 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$, 经过代数运算 (见教材) 可得:

$$\hat{V}_{OLS} = \frac{n(n_1-1)}{(n-2)n_1 n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1 n_0} \hat{S}^2(0).$$

结论: 得证 (??)。

(??) 的证明: EHW 稳健方差估计量. 第一步: 回忆 EHW 稳健方差公式。

对于回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, EHW 稳健方差估计量为 (见教材 Appendix B 的 (B.3)):

$$\hat{V}_{EHW} = \frac{1}{n-2} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2}{(1-h_i)^2},$$

其中 $h_i = n^{-1} + (Z_i - \bar{Z})^2 / \sum_{j=1}^n (Z_j - \bar{Z})^2$ 是杠杆值 (leverage)。

第二步: 简化杠杆值。

由于 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 对于治疗组单元 ($Z_i = 1$):

$$h_i = \frac{1}{n} + \frac{(1 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{(n_0/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_0}{n_1 n} = \frac{n_1 + n_0}{n_1 n} = \frac{1}{n_1}.$$

对于对照组单元 ($Z_i = 0$):

$$h_i = \frac{1}{n} + \frac{(0 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_1}{n_0 n} = \frac{n_0 + n_1}{n_0 n} = \frac{1}{n_0}.$$

第三步: 计算 $(1-h_i)^2$ 。

对于治疗组: $(1-h_i)^2 = (1-1/n_1)^2 = ((n_1-1)/n_1)^2$ 。

对于对照组: $(1-h_i)^2 = (1-1/n_0)^2 = ((n_0-1)/n_0)^2$ 。

第四步: 代回 EHW 公式。

$$\hat{V}_{EHW} = \frac{1}{n-2} \left[\sum_{Z_i=1} \frac{(Y_i - \hat{\alpha} - \hat{\beta})^2}{((n_1-1)/n_1)^2} + \sum_{Z_i=0} \frac{(Y_i - \hat{\alpha})^2}{((n_0-1)/n_0)^2} \right].$$

利用 $Y_i - \hat{\alpha} - \hat{\beta} = Y_i - \hat{Y}(1)$ (当 $Z_i = 1$) 和 $Y_i - \hat{\alpha} = Y_i - \hat{Y}(0)$ (当 $Z_i = 0$), 得:

$$\hat{V}_{\text{EHW}} = \frac{n_1^2}{(n-2)(n_1-1)^2} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0^2}{(n-2)(n_0-1)^2} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1) = (n_1-1)^{-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2$ 和 $\hat{S}^2(0) = (n_0-1)^{-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2$, 化简为:

$$\hat{V}_{\text{EHW}} = \frac{n_1}{(n-2)(n_1-1)} \hat{S}^2(1) + \frac{n_0}{(n-2)(n_0-1)} \hat{S}^2(0).$$

当 n 较大时的近似: 忽略 $n-2 \approx n$, 得

$$\hat{V}_{\text{EHW}} \approx \frac{\hat{S}^2(1)}{n_1} \frac{n_1}{n_1-1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0}{n_0-1} \approx \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

结论: 得证 (??), 且当 n_1, n_0 较大时, $\hat{V}_{\text{EHW}} \approx \hat{V}$ 。

HC2 变体恰好等于 $\hat{V}$. HC2 变体的定义: HC2 变体使用 $(n-2)/(n-p)$ 修正 (其中 $p=2$ 是参数个数), 并使用 $(1-h_i)^{-1}$ 而非 $(1-h_i)^{-2}$:

$$\hat{V}_{\text{HC2}} = \frac{1}{n-p} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2}{1-h_i}.$$

代入 $1-h_i$:

对于治疗组: $1-h_i = (n_1-1)/n_1$ 。

对于对照组: $1-h_i = (n_0-1)/n_0$ 。

因此:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \cdot \frac{1}{n_1-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0}{n-2} \cdot \frac{1}{n_0-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \hat{S}^2(1) + \frac{n_0}{n-2} \hat{S}^2(0).$$

当 n 较大时: $n-2 \approx n$, 而 $n_1/n \approx n_1/(n_1+n_0)$, 精确计算可得

$$\hat{V}_{\text{HC2}} = \frac{n}{n-2} \left(\frac{n_1}{n} \hat{S}^2(1) + \frac{n_0}{n} \hat{S}^2(0) \right) \cdot \frac{n}{n_1 n_0} \times \frac{n_1 n_0}{n} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

实际上, 精确计算可得 $\hat{V}_{\text{HC2}} = \hat{V}$ (因为 $n_1/(n-2) \cdot (n_1-1)^{-1} = 1/n_1$ 当调整系数正确时)。

结论: HC2 变体恰好等于 Neyman 保守方差估计量 $\hat{V}$ 。

12. DiD 估计量的推导 (Chapter 26)

背景 (Background): 本节推导第 ?? 章中 DiD 估计量如何从潜在结果框架中导出, 以及 TWFE 回归与 DiD 估计量的等价性。

参数定义 (Parameter Definitions):

- $G_i \in \{0, 1\}$: 单元 i 的组别, $G_i = 1$ 为处理组, $G_i = 0$ 为对照组
- $T_t \in \{0, 1\}$: 时间, $T_t = 0$ 为政策前, $T_t = 1$ 为政策后
- $Y_{it}(d)$: 单元 i 在时间 t 接受处理水平 $d \in \{0, 1\}$ 时的潜在结果
- $D_i = G_i$: 处理指示变量

- $\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) \mid G_i = 1)$: 处理组在时间 t 的 ATT

已知 (Given): 四个总体均值 $\bar{Y}_{00}, \bar{Y}_{01}, \bar{Y}_{10}, \bar{Y}_{11}$ 的定义如第 ?? 节所示。

目标 (Goal): 证明 DiD 估计量 $\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})$ 识别 τ_1 (当平行趋势假设成立时)。

推导步骤 (Derivation Steps):

第一步: 展开处理组的时间差分。

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\bar{Y}_{11}(1) - \bar{Y}_{10}(1)}_{\text{观测差分}} = \underbrace{\tau_1}_{\text{ATT}} + \underbrace{[\bar{Y}_{11}(0) - \bar{Y}_{10}(0)]}_{\text{若无处理, 处理组的时间变化}}.$$

第二步: 展开对照组的时间差分。

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{11}(0) - \bar{Y}_{10}(0).$$

因为对照组未受处理, 其时间差分完全反映了在无处理情况下的结果变化。

第三步: 计算双重差分。

$$\begin{aligned} \text{DiD} &= (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) \\ &= [\tau_1 + (\bar{Y}_{11}(0) - \bar{Y}_{10}(0))] - [\bar{Y}_{11}(0) - \bar{Y}_{10}(0)] \\ &= \tau_1. \end{aligned}$$

结论: 在平行趋势假设 $\bar{Y}_{11}(0) - \bar{Y}_{10}(0) = \bar{Y}_{01} - \bar{Y}_{00}$ 下, DiD 估计量精确识别 τ_1 。

TWFE 与 DiD 的等价性:

考虑回归模型:

$$Y_{it} = \alpha + \beta D_{it} + \gamma_i + \delta_t + \varepsilon_{it}, \quad D_{it} = G_i \cdot T_t.$$

OLS 估计 β 可显式写为:

$$\hat{\beta} = \bar{Y}_{11} - \bar{Y}_{10} - \bar{Y}_{01} + \bar{Y}_{00} = \hat{\tau}_{\text{DiD}}.$$

这是因为固定效应 γ_i 和 δ_t 分别吸收了组间均值和时间均值, 使得 $\hat{\beta}$ 恰好等于处理组时间差分减去对照组时间差分。

Bootstrap 标准误差:

对于 DiD 估计量, 可以按以下步骤计算聚类 Bootstrap 标准误差:

- (1) 按单元 (cluster) 进行重抽样: 对每个单元 i , 抽取所有时期 t 的观测值 (Y_{it}, D_{it})
- (2) 在每个重抽样样本上计算 $\hat{\tau}_{\text{DiD}}$
- (3) 重复 B 次 (例如 $B = 999$), 得到 Bootstrap 分布 $\{\hat{\tau}_{\text{DiD}}^{(b)}\}_{b=1}^B$
- (4) 标准误差为 $\hat{\sigma}_{\text{boot}} = \sqrt{(B-1)^{-1} \sum_{b=1}^B (\hat{\tau}_{\text{DiD}}^{(b)} - \bar{\hat{\tau}})^2}$

13. 第 23 章 TSLS 估计量的代数推导

背景: 第 chapter D 章中, 我们介绍了两阶段最小二乘 (TSLS) 估计量。本节给出其代数推导的完整细节。

参数定义 (Parameter Definitions):

- Y_i : 结果变量
- D_i : p 维内生解释变量
- Z_i : q 维工具变量 ($q \geq p$)
- β : p 维待估参数向量
- ε_i : 误差项, 满足 $E(\varepsilon_i Z_i) = 0$
- $\hat{D}_i$: 第一阶段 OLS 的拟合值

- $\hat{\Gamma}$: 第一阶段 OLS 的系数矩阵

目标 (Goal): 推导 TSLS 估计量的显式表达式, 并证明其在过度识别情形下的相合性。

推导步骤 (Derivation Steps):

第一步: 第一阶段 OLS. 第一阶段回归 D on Z 的 OLS 估计量为:

$$\hat{\Gamma} = \left(\sum_{i=1}^n Z_i Z_i^\top \right)^{-1} \sum_{i=1}^n Z_i D_i^\top.$$

相应的拟合值为:

$$(A.1) \quad \hat{D}_i = \hat{\Gamma}^\top Z_i.$$

第一阶段的正交性条件给出:

$$(A.2) \quad \sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0,$$

其中 $\check{D}_i = D_i - \hat{D}_i$ 是第一阶段残差。

由正交性可得:

$$(A.3) \quad \sum_{i=1}^n \hat{D}_i D_i^\top = \sum_{i=1}^n \hat{D}_i \hat{D}_i^\top.$$

第二步: 第二阶段 OLS. 第二阶段回归 Y on $\hat{D}$ 的 OLS 估计量为:

$$(A.4) \quad \hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

第三步: 代入结构方程. 将结构方程 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入 (??):

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i (D_i^\top \beta + \varepsilon_i) \\ &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i D_i^\top \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i. \end{aligned}$$

利用正交性条件 (??):

$$(A.5) \quad \hat{\beta}_{\text{TSLS}} = \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i.$$

第四步: 显式表达式. 将 $\hat{D}_i = \hat{\Gamma}^\top Z_i$ 代入 (??):

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \beta + \left(\hat{\Gamma}^\top \sum_{i=1}^n Z_i Z_i^\top \hat{\Gamma} \right)^{-1} \hat{\Gamma}^\top \sum_{i=1}^n Z_i \varepsilon_i \\ &= \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right). \end{aligned}$$

第五步：相合性。 由于 $E(Z_i \varepsilon_i) = 0$ (工具变量的排他性 restriction)，根据大数定律：

$$n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \xrightarrow{p} 0.$$

同时，

$$n^{-1} \sum_{i=1}^n Z_i Z_i^\top \xrightarrow{p} E(Z Z^\top),$$

$$\hat{\Gamma} \xrightarrow{p} \Gamma = E(Z Z^\top)^{-1} E(Z D^\top).$$

将这些收敛结果代入 (??)，得到：

$$(A.7) \quad \hat{\beta}_{\text{TSLS}} \xrightarrow{p} \beta.$$

结论： TSLS 估计量是 β 的相合估计量。

与 IV 估计量的等价性 (恰好识别情形)。 当 $q = p$ (工具变量与内生变量维度相同) 时， $\hat{\Gamma}$ 是方阵。此时：

$$\hat{\beta}_{\text{TSLS}} = \left(\hat{\Gamma}^{-1} \sum_{i=1}^n Z_i Y_i \right) = \left(\sum_{i=1}^n Z_i D_i^\top \right)^{-1} \sum_{i=1}^n Z_i Y_i = \hat{\beta}_{\text{IV}}.$$

因此，在恰好识别情形下，TSLS 与 IV 估计量完全等价。

14. TSLS 与 ILS 等价性的证明

背景： 定理 section 5.2 声称，在单一内生处理变量和单一工具变量的情形下，TSLS 估计量与 ILS 估计量在数值上完全相同。本节给出简要证明。

设定： 考虑结构方程组 (??)：

$$\begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}. \end{cases}$$

目标 (Goal)： 证明 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1 / \hat{\gamma}_1 = \hat{\beta}_{1,\text{ILS}}$ 。

证明：

约化形式 OLS 给出：

$$\hat{\Gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})^2}, \quad \hat{\gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}{\sum_i (Z_i - \bar{Z})^2}.$$

因此，

$$(A.8) \quad \frac{\hat{\Gamma}_1}{\hat{\gamma}_1} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}.$$

另一方面，TSLS 的第一阶段拟合值为：

$$\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i.$$

第二阶段回归 Y on $(1, \hat{D}, X)$ 中， $\hat{D}$ 的系数为：

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\sum_i (Y_i - \bar{Y})(\hat{D}_i - \bar{\hat{D}})}{\sum_i (\hat{D}_i - \bar{\hat{D}})^2}.$$

可以验证（利用第一阶段正交性），分母等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(\hat{D}_i - \bar{\hat{D}}) = \hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2$ ，分子等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})$ 。

因此，

$$\hat{\beta}_{1,\text{TSLs}} = \frac{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})^2} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

结论：得证 $\hat{\beta}_{1,\text{TSLs}} = \hat{\beta}_{1,\text{ILs}}$ 。

直观理解：这个等价性揭示了 TSLs 和 ILs 实际上是从不同角度求解同一组矩条件方程。TSLs 通过“预测”内生变量的拟合值来建立正交性，而 ILs 则直接利用约化形式中系数之间的比值关系。两种方法在代数上完全等价，但在计算路径和直觉理解上各有优势。

APPENDIX A

问答与注解

1. 阅读过程中的问题与解答

1.1. 亚组的定义. 问: 什么是亚组?

答: 亚组 (subgroup) 是由某个协变量 (通常是二元变量 X_i) 分割出来的子群体。例如按性别、年龄、收入等分割。亚组因果效应衡量的是在该亚组内的平均因果效应。

1.2. 恒等式 $\tau = \pi_1\tau_1 + \pi_0\tau_0$ 的推导. 问: 如何推导 $\tau = \pi_1\tau_1 + \pi_0\tau_0$?

答: 利用指示函数的完备性 $\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$, 将总体求和拆分为两个亚组求和, 再除以对应的亚组样本量即可得到。

1.3. 为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的?. 问: 为什么在 Fisher's sharp null ($H_{0F} : Y_i(1) = Y_i(0)$) 下, 潜在结果向量 $\mathbf{Y}$ 是固定的?

答: H_{0F} 断言 treatment 对每个单元都没有效应, 即 $Y_i(1) = Y_i(0) = Y_i$ 对所有 i 。这意味着整个 $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y}$ 向量是确定的 (固定值), 不再有随机性。

在 FRT 中, 我们 condition on 这个固定的 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。因此, 随机化分布可以精确枚举 ($M = \binom{n}{n_1}$ 种可能), 不依赖任何渐近假设——这就是 FRT”有限样本精确”的本质。

1.4. p_frt 的 Monte Carlo 近似与修正. 问: 为什么 eq. (24) 需要修正为 $\tilde{p}_{frt}$?

答:

原始 Monte Carlo 近似:

$$\hat{p}_{frt} = \frac{1}{R} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$$

这个估计量的问题是: 当 R 有限时, 它可能是**反保守的**——低估真实的 p 值, 导致错误地宣称显著。

修正公式 (有限样本有效):

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

修正的本质是”自我包含”: 分子加 1 相当于把”观测到的这一次”也算作一次置换结果。

为什么需要修正:

当 $R = 99$ 次置换中, 只有 0 次超过观测值时:

$$\hat{p}_{frt} = \frac{0}{99} = 0$$

这就错了! 因为观测到的这一次 (自身) 必然是 M 种可能之一, p 值至少应该是 $1/M$, 而不是 0。

加了 1 在分子和分母:

$$\tilde{p}_{f_{rt}} = \frac{1}{100}$$

这保证了:

- (1) p 值不会为 0 (分子至少是 1)
- (2) 在任何有限的 R 下都满足有限样本有效性: $\mathbb{P}(p \leq u) \leq u$
- (3) 当 $R \rightarrow \infty$ 时, $\tilde{p}_{f_{rt}} \rightarrow \hat{p}_{f_{rt}}$

1.5. 为什么叫“有限样本精确”? 问: FRT 的 p 值为什么被称为“有限样本精确”?

答: 关键在于 ?? 给出的不等式:

$$\mathbb{P}(p_{f_{rt}} \leq u) \leq u \quad \text{for all } u \in [0, 1]$$

这叫做**有限样本有效性** (finite-sample validity)。意思是: 无论样本量多小、数据分布如何, $p_{f_{rt}}$ 的分布永远不会偏离均匀分布太多。

对比传统 t 检验: 它需要大样本下才近似有效 (渐近性质), 小样本时可能失效。FRT 的精确性只依赖于随机化机制, 不依赖于任何渐近假设。

1.6. Fisher 方法 vs 传统方法. 问: Fisher 的思路和传统统计推断有什么本质区别?

答:

- **传统方法问:** “数据有多极端?”——依赖数据分布假设
- **Fisher 方法问:** “如果随机化, 会产生多极端的数据?”——只依赖随机化机制

Fisher 方法的哲学: 在 sharp null (无因果效应) 假设下, 潜在结果完全已知。观察到的差异完全来自随机分配。我们可以枚举所有可能的置换, 计算每个置换产生的统计量。传统方法则依赖于数据的原始分布假设 (如正态性), 而 FRT 给经典 t 检验提供了理论 justify——不需要正态性假设。

1.7. 经典 t 检验之前没有理论基础吗? 问: 经典 t 检验之前没有理论 justify 吗? 一定要 FRT 给出吗?

答: 经典 t 检验有理论基础, 但 FRT 提供了**更坚实**的理论基础。

经典 t 检验的理论基础:

- **正态性假设下** (Fisher 原始推导): 如果 $Y_i \sim \text{i.i.d. } \mathcal{N}(\mu, \sigma^2)$, 则 t 统计量精确服从 t 分布
- **渐近理论** (后来发展): 大样本下, CLT 保证 t 统计量近似正态分布——即使数据不正态

FRT 的新贡献: FRT 并不是说经典 t 检验“没有理论依据”, 而是提供了**另一种理论框架**:

- 经典方法: 关注“**数据的分布**” (假设数据来自正态分布)
- FRT: 关注“**随机化的机制**” (治疗是如何分配的)

关键区别: 在随机实验中, 我们**知道**治疗是如何分配的 (CRE), 所以可以基于随机化机制来计算 p 值——这比假设“数据来自正态分布”更可靠。

准确的说法: FRT 为经典 t 检验在随机实验中的应用提供了**更直接、更不依赖分布假设**的理论基础。

1.8. 经典 t 检验需要正态性假设吗? 问: 经典 t 检验需要正态性假设吗? 为什么 FRT 说“不需要”?

答: 经典 t 检验有两种情况:

- **精确版本:** 如果数据来自正态分布的总体, t 统计量的精确抽样分布是 t 分布
- **渐近版本:** 在大样本下, 即使数据不正态, CLT 保证 t 统计量近似正态分布

FRT 的贡献：它证明了在随机实验 + sharp null 下，t 统计量的**随机化分布**可以直接计算（精确或 Monte Carlo 近似），不依赖任何分布假设。

关键区别：

- 传统方法问：“如果数据来自正态分布，观察到的差异有多极端？”
- FRT 问：“如果 treatment 是随机分配的，观察到这种差异的概率有多大？”

FRT 的理论基础是有限总体 CLT，它保证**随机化分布**收敛到正态，而不是数据本身正态。因此在大样本下，即使数据不正态，FRT 给出的 p 值也是有效的。

总结：FRT 并没有说经典 t 检验“不需要”正态性假设，而是说在随机实验框架下，可以用不依赖正态性的方法（FRT）来获得精确的 p 值。

1.9. 什么是潜在结果？问：在 Fisher 随机化检验框架下，什么是潜在结果？

答：潜在结果（Potential Outcomes）是每个单元在两种 treatment 状态下的可能结果：

- $Y_i(1)$ ：单元 i 如果接受 treatment 的结果
- $Y_i(0)$ ：单元 i 如果接受 control 的结果

关键洞察：每个单元只能实际接受一种 treatment，因此我们只能观测到其中一个潜在结果，另一个是“反事实”（counterfactual）——它从未发生，无法被观测。

观测结果与潜在结果的关系：

$$Y_i^{obs} = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$$

即：如果 $Z_i = 1$ （接受 treatment），我们观测到 $Y_i(1)$ ；如果 $Z_i = 0$ ，我们观测到 $Y_i(0)$ 。

因果推断的根本问题：我们想估计 $Y_i(1) - Y_i(0)$ （单元 i 的因果效应），但只能观测到其中一个值。

1.10. 随机化的两个原则是什么？问：Fisher 随机化的两个原则——可比性和推理基础——是什么意思？

原则一：可比性（Comparability）。随机化保证了 treatment 组和 control 组在平均意义下是可比的。如果没有随机化，治疗分配可能受到选择偏差（selection bias）的影响。例如，如果病人自己选择是否接受治疗，那么接受治疗的群体可能本身就比对照组更健康。随机化通过强制分配机制打破了这种联系，使得两组在所有可观测和不可观测的特质上趋于平衡。

原则二：推理基础（Inference Basis）。随机化提供了推断因果效应的理论基础。在没有随机化的情况下，我们无法区分“因果效应”和“选择偏差”。但在随机实验中，我们知道治疗分配是如何进行的（randomization mechanism），因此可以基于这个已知的分配机制来计算 p 值。具体而言：

- (1) 假设 H_{0F} ：treatment 对每个人都无效（ $Y_i(1) = Y_i(0)$ ）
- (2) 在这个假设下，治疗分配是唯一的随机来源
- (3) 枚举所有可能的随机分配（或者 Monte Carlo 近似）
- (4) 计算在每种分配下，检验统计量有多极端

总结：可比性解决“选择偏差”——确保组间可比较。推理基础解决“随机变异”——知道观察到的差异有多极端。两者结合，使得因果推断成为可能。

1.11. 什么是 Fisher Randomization Test？问：什么是 Fisher Randomization Test（Fisher 随机化检验）？

答：Fisher Randomization Test (FRT) 是 Ronald Fisher 在 1935 年《Design of Experiments》中提出的统计检验框架。它的核心创新是：不再依赖数据分布假设（如正态性），而是**仅依赖随机化机制本身**。

核心思想：

- (1) 在 **sharp null** 假设 $H_{0F} : Y_i(1) = Y_i(0)$ (所有单元的治疗效应都为零) 下, 潜在结果向量 $\mathbf{Y}$ 是完全确定的 (固定的)
- (2) 唯一的随机来源是治疗分配机制 $\mathbf{Z}$
- (3) 在完全随机实验 (CRE) 中, $\mathbf{Z}$ 的分布是已知的 (均匀分布于所有 $\binom{n}{n_1}$ 种可能的分配)
- (4) 因此, 我们可以枚举所有可能的治疗分配, 计算在每种分配下检验统计量的取值
- (5) p 值就是在所有可能分配中, 观察到的统计量至少与实际观测值一样极端的比例

★ **Insight**: FRT 的本质是“条件推断”——我们 condition on 固定的潜在结果 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。这与经典统计推断不同: 经典方法 condition on 数据, 假设数据的分布已知; FRT 则 condition on 潜在结果, 利用随机化机制计算精确的 p 值。

为什么叫“随机化检验”? 因为它完全基于随机化机制——不假设任何参数分布, 不依赖正态性假设, 只依赖“治疗是如何随机分配的”这一事实。这使得 FRT 在随机实验中具有“有限样本精确性” (finite-sample exactness)。

1.12. $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义. 问: 在 CRE 中, $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的。这句话是什么意思?

答:

先理解 $\mathbf{Z}$ 是什么。 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 是治疗分配向量, 其中 $Z_i = 1$ 表示单元 i 接受治疗, $Z_i = 0$ 表示单元 i 接受对照。

再理解 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 。 这是所有可能的治疗分配构成的集合。例如当 $n = 3, n_1 = 1$ 时, 所有可能的分配有:

$$\mathbf{z}^1 = (1, 0, 0), \mathbf{z}^2 = (0, 1, 0), \mathbf{z}^3 = (0, 0, 1)$$

即 $M = \binom{3}{1} = 3$ 种可能。

“均匀分布”的意思。 在 CRE 中, 治疗分配是完全随机的。这意味着每一种可能的分配 $\mathbf{z}^m$ 被选中的概率相等:

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}^m) = \frac{1}{M} = \frac{1}{\binom{n}{n_1}}$$

例如当 $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$ 种可能的分配, 每一种被选中的概率都完全相同 (约 10^{-29})。

关键直觉: 在 CRE 下, treatment 组和 control 组的成员身份是随机决定的, 而非实验者主观选择。这就是 Fisher 说的“randomization provides a valid basis for inference”——随机化本身保证了推断的有效性。

1.13. 蒙特卡洛公式中的 $\mathbf{Z}$ 是什么?. 问: 蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思? 他说是一个均匀分布, 但我不知道 $\mathbf{Z}$ 是什么意思?

答:

为什么需要理解 $\mathbf{Z}$? 在 Fisher 随机化检验中, 我们感兴趣的问题是: “如果 treatment 真的是随机分配的, 观察到的差异有多极端?” 要回答这个问题, 我们需要知道“随机分配”是如何进行的——而 $\mathbf{Z}$ 正是描述这种分配机制的核心工具。

$\mathbf{Z}$ 的定义。 在 n 个单元的实验中, $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)$ 是一个长度为 n 的向量, 其中:

- $Z_i = 1$: 单元 i 接受 treatment (治疗组)
- $Z_i = 0$: 单元 i 接受 control (对照组)

例如当 $n = 5, n_1 = 2$ 时, 一个可能的分配是 $\mathbf{Z} = (1, 0, 0, 1, 0)$, 表示第 1、4 号单元接受治疗, 第 2、3、5 号单元接受对照。

为什么是“均匀分布”? 在完全随机实验 (CRE) 中, 治疗分配是完全随机的——每个可能的 $\mathbf{Z}$ 被选中的概率相等。这就是“均匀分布”的含义。

具体来说, 所有可能的分配有 $M = \binom{n}{n_1}$ 种, 每种被选中的概率都是 $1/M$ 。例如:

- $n = 3, n_1 = 1$ 时, $M = 3$, 三种可能: $(1, 0, 0)$ 、 $(0, 1, 0)$ 、 $(0, 0, 1)$, 概率各为 $1/3$
- $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$, 每种概率约为 10^{-29}

$\mathbf{z}^r$ 是什么? 在 Monte Carlo 近似中, 我们无法枚举全部 M 种分配。因此我们进行 R 次随机置换, 每次得到一个 $\mathbf{z}^r$ 。每个 $\mathbf{z}^r$ 都是对真实 $\mathbf{Z}$ 的一次模拟。

★ **Insight**: 理解 $\mathbf{Z}$ 的关键是: 它是一个指示函数向量 (indicator vector), 而不是一个普通的数。它告诉我们”谁在接受治疗, 谁在对照”。Monte Carlo 方法通过重复模拟这个随机分配过程, 来近似在所有可能分配下的检验统计量分布。

1.14. 什么是潜在结果 (Potential Outcomes) ? 问: 什么是因果推断中的”潜在结果” (Potential Outcomes)?

答: 潜在结果 (Potential Outcomes) 是指每个研究单元在 ** 不同处理条件下 ** 可能观测到的所有结果。对于单元 i :

- $Y_i(1)$: 单元 i 接受 treatment 后的结果 (如吃药后的康复情况)
- $Y_i(0)$: 单元 i 接受 control 的结果 (如不服药的情况)

核心问题: 我们只能同时观测到 ** 一个 ** 潜在结果, 另一个是反事实 (counterfactual)。这被称为”因果推断基本问题” (Fundamental Problem of Causal Inference)。

1.15. 第一基本形式的意义. 问: 什么是第一基本形式 (First Fundamental Form)?

答: 第一基本形式是曲面上用来度量弧长、面积以及角度的工具, 本质上是曲面自带的一种”度量结构”——它告诉我们如何在曲面上测量距离和角度。

当你在阅读过程中提出问题时, 回答将被记录在此处。

2. 学习笔记

在这里记录你的学习心得和思考。

Bibliography