

$y T w \ f l$

$S 2 M ; . B M ;$

类似地, τ_D 的分解为:⁴

$$\begin{aligned}\tau_D &= \mathbb{E}\{D(1) - D(0) \mid U = a\} \Pr(U = a) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = c\} \Pr(U = c) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = d\} \Pr(U = d) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = n\} \Pr(U = n) \\ &= 0 \cdot \Pr(U = a) + 1 \cdot \Pr(U = c) + (-1) \cdot \Pr(U = d) + 0 \cdot \Pr(U = n) \\ &= \Pr(U = c) - \Pr(U = d).\end{aligned}$$

4. 非参数识别

上述分解表明, 仅凭观测数据无法唯一识别 τ_Y ——我们有四个未知数 (四个亚组的因果效应) 但只有两个方程 (τ_Y 和 τ_D 的识别)。为了进一步识别, 我们需要额外的假设。

4.1. 单调性假设.

假设 22.2 (单调性). $\Pr(U = d) = 0$, 或等价地, $D_i(1) \geq D_i(0)$ 对所有单元成立。即, 不存在 *defiers*。

何时成立? 单调性假设在**单侧依从性问题 (one-sided noncompliance)** 中自动成立: 当对照组被试无法获得治疗时, $D_i(0) = 0$ 对所有单元成立, 从而 $D_i(1) \geq D_i(0)$ 必然成立。

可检验的含义: 在随机化下, 单调性假设有一个可检验的含义:⁵

$$\Pr(D = 1 \mid Z = 1) \geq \Pr(D = 1 \mid Z = 0).$$

注意: 假设 22.2 比 section 4.1 更强。前者限制每个个体的 $D_i(1)$ 和 $D_i(0)$, 后者只限制平均值。当可检验的不等式成立时, 我们无法用数据反驳单调性假设。

在单调性假设下, section 3.2 简化为:

$$\tau_D = \Pr(U = c) \equiv \pi_c.$$

这意味着 compliers 的比例 π_c 等于治疗分配对实际治疗的平均因果效应——这是一个可以识别的数量。

4.2. 排斥限制假设.

假设 22.3 (排斥限制). 对于 *always takers* ($U = a$) 和 *never takers* ($U = n$), 有 $Y_i(1) = Y_i(0)$ 。

直观理解: 排斥限制要求治疗分配**只能通过实际接受的治疗**影响结果, 不能有其他直接通路。在双盲随机对照试验中, 这是生物学上合理的——如果治疗分配没有改变实际接受的治疗, 它也不会改变结果。

何时可能被违反? 当治疗分配有直接影响结果的通路时 (而非通过实际接受的治疗)。例如, 在非双盲试验中, 被试可能因为知道自己被分配到治疗组而改变行为。

在排斥限制假设下, section 3.2 中的第一项和最后一项变为零:

$$\tau_Y = \mathbb{E}\{Y(1) - Y(0) \mid U = c\} \Pr(U = c).$$

结合 section 4.1 和 section 4.2, 我们得到识别结果。

⁴推导见附录 ??

⁵推导见附录 ??

4.3. 主要识别定理.

定理 22.2 (CACE/LATE 的识别). 在假设 22.1、假设 22.2 和假设 22.3 下, 如果 $\tau_D \neq 0$, 则

$$\mathbb{E}\{Y(1) - Y(0) \mid U = c\} = \frac{\tau_Y}{\tau_D}.$$

证明思路: 由 section 4.2 和 section 4.1 可直接得到。⁶

定义 22.2 的含义是: 在上述三个假设下, τ_Y/τ_D 识别了 compliers 的平均因果效应。

一个哲学性的观察: 识别结果只涉及 compliers——那些“遵医嘱”的人。这意味着我们无法直接得知治疗对 always takers、never takers 或 defiers 的效果。这既是局限, 也是优势——它允许我们专注于一个明确定义的亚组。

5. 依从性平均因果效应 (CACE/LATE)

5.1. 定义.

定义 22.3 (CACE 或 LATE). **依从性平均因果效应 (complier average causal effect, CACE)** 或 **局部平均治疗效应 (local average treatment effect, LATE)** 定义为:

$$\tau_c = \mathbb{E}\{Y(1) - Y(0) \mid U = c\}.$$

CACE 有两种等价形式:

$$\tau_c = \mathbb{E}\{Y(1) - Y(0) \mid D(1) = 1, D(0) = 0\} = \mathbb{E}\{Y(1) - Y(0) \mid D(1) > D(0)\}.$$

基于定义 22.3, 定义 22.2 可以写成:

$$\tau_c = \frac{\tau_Y}{\tau_D}.$$

即, CACE/LATE 等于结果平均因果效应与治疗接受平均因果效应之比。

在完全随机化下, 进一步有:

$$\tau_c = \frac{\mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0)}{\mathbb{E}(D \mid Z = 1) - \mathbb{E}(D \mid Z = 0)}.$$

因此, 在完全随机化、单调性和排斥限制下, 我们可以**非参数地识别 CACE**——它等于观测数据中结果差值均值与治疗接受差值均值之比。

6. 估计

6.1. Wald 估计量. 基于 section 5.1, 我们可以用简单的比值估计 CACE:

$$\hat{\tau}_c = \frac{\hat{\tau}_Y}{\hat{\tau}_D},$$

其中

$$\hat{\tau}_Y = \frac{1}{n_1} \sum_{i:Z_i=1} Y_i - \frac{1}{n_0} \sum_{i:Z_i=0} Y_i, \quad \hat{\tau}_D = \frac{1}{n_1} \sum_{i:Z_i=1} D_i - \frac{1}{n_0} \sum_{i:Z_i=0} D_i.$$

这就是著名的 **Wald 估计量 (?)**, 也称为 **工具变量估计量**。在这个语境下, Z 作为 D 的工具变量。

直观理解: Wald 估计量可以理解为“缩放的” ITT 估计量。 $\hat{\tau}_Y$ 估计治疗分配的效果, $\hat{\tau}_D$ 估计治疗分配对实际治疗的“转化率” (即 compliers 的比例)。二者的比值估计了对于那些“被转化”的 compliers, 治疗的实际效果。

⁶完整证明见附录 ??

6.2. 方差估计. 为了进行统计推断, 我们需要估计 $\hat{\tau}_c$ 的方差。⁷
基本思想是将 $\hat{\tau}_c$ 在真实值附近线性化:⁸

$$\hat{\tau}_c - \tau_c \approx \frac{\hat{\tau}_Y - \tau_c \hat{\tau}_D}{\tau_D}.$$

定义调整后的结果 $A_i = Y_i - \tau_c D_i$, 则上式近似为 $\hat{\tau}_A/\tau_D$, 其中 $\hat{\tau}_A$ 是调整后结果的差值均值。

因此, $\hat{\tau}_c$ 的渐近方差约为 $\hat{V}_A/\tau_D^2$, 其中 $\hat{V}_A$ 是调整后结果的 Neyman 型方差估计量:

$$\hat{V}_A = \frac{\hat{S}_A^2(1)}{n_1} + \frac{\hat{S}_A^2(0)}{n_0},$$

其中 $\hat{S}_A^2(1)$ 和 $\hat{S}_A^2(0)$ 分别是治疗组和对照组中调整后结果的样本方差。
最终, 我们使用

$$\hat{V}_{\hat{\tau}_c} = \frac{\hat{V}_A}{\hat{\tau}_D^2}$$

作为 $\hat{\tau}_c$ 的方差估计量。

基于此, 我们可以构建 τ_c 的 $1 - \alpha$ 置信区间:

$$\hat{\tau}_c \pm z_{1-\alpha/2} \sqrt{\hat{V}_{\hat{\tau}_c}}.$$

7. 弱工具变量

在实际研究中, 我们常常面临一个尴尬的局面: 工具变量的”强度”并不总能得到保证。想象一下, 即使在真实的随机实验中, 由于各种现实因素, 只有极少数被试 (比如说 5%) 改变了他们的行为。在这种情况下, 我们能否信赖 Wald 估计量?

7.1. 问题诊断. 即使 $\tau_D > 0$ (即 compliers 确实存在), $\hat{\tau}_D$ 仍有可能接近甚至等于零。这会导致 Wald 估计量的方差急剧增大——实际上, 当 $\tau_D \rightarrow 0$ 时, $\text{var}(\hat{\tau}_c) \rightarrow \infty$ 。⁹

这就是**弱工具变量 (weak instrumental variable)**问题。[?]的经典研究表明, 当工具变量弱时, 传统的统计推断方法会失效。在这种情况下:

- $\hat{\tau}_c$ 存在有限样本偏
- 渐近分布不再是正态
- 基于正态近似的置信区间覆盖性质很差

诊断指标: 一个常用的诊断是 F 统计量或 $\hat{\tau}_D$ 的绝对值。经验法则: 当 $\hat{\tau}_D$ 很小时, 应谨慎对待 Wald 估计量。

7.2. FAR 置信区间. 从估计角度, 当工具变量弱时, 我们建议关注**置信区间**而非点估计。从检验角度, 有一个简单的解决方案——由于 $\tau_c = \tau_Y/\tau_D$, 原假设 $\tau_c = 0$ 等价于 $\tau_Y = 0$ 。

更精细的方法是构建 **Fieller-Anderson-Rubin (FAR) 置信区间**。其思想是通过反转一系列假设检验来构建 τ_c 的置信域。¹⁰

对于给定的 b , 考虑原假设 $H_0(b): \tau_c = b$ 。这等价于 $\tau_Y - b\tau_D = 0$, 即调整后的结果 $A(b)_i = Y_i - bD_i$ 的平均因果效应为零。

⁷渐近方差公式的推导见附录 ??

⁸详细推导见附录 ??

⁹这与经典统计学中的 Fieller-Creasy 问题类似。

¹⁰FAR 置信区间的详细讨论见附录 ??。

构造 Wald 型检验并反转，可以得到置信域：

$$\left\{ b : \frac{\hat{\tau}_A^2(b)}{\hat{V}_A(b)} \leq z_{1-\alpha/2}^2 \right\},$$

其中 $\hat{\tau}_A(b)$ 和 $\hat{V}_A(b)$ 是调整后结果 $A(b)_i = Y_i - bD_i$ 的点估计和方差估计。

FAR 置信域可能是单个区间、两个不相连的区间、空集或整个实数线。当工具变量强时，它收敛到标准 Wald 置信区间；当工具变量弱时，它提供更可靠的推断。

8. 协变量调整

到目前为止我们都假设没有协变量。加入协变量可以提高估计的效率和稳健性。

8.1. 完全随机化下的协变量调整. 假设条件随机化成立：

$$Z \perp \{D(1), D(0), Y(1), Y(0), X\}.$$

我们可以使用 ? 的协变量调整估计量。对于结果和和治疗接受，分别拟合包含协变量的回归模型：

$$D_i = \beta_0 + \beta_1 Z_i + \beta_2 X_i + \beta_3 Z_i X_i + \epsilon_i,$$

$$Y_i = \alpha_0 + \alpha_1 Z_i + \alpha_2 X_i + \alpha_3 Z_i X_i + \eta_i,$$

取 $\hat{\tau}_{D,L} = \hat{\beta}_1$ 和 $\hat{\tau}_{Y,L} = \hat{\alpha}_1$ ，则调整后的 CACE 估计量为：

$$\hat{\tau}_{c,L} = \frac{\hat{\tau}_{Y,L}}{\hat{\tau}_{D,L}}.$$

渐近方差可以通过 Bootstrap 近似。

9. 实例：JOBS II 培训项目

研究背景：JOBS II 是一个随机化现场实验，研究职业培训对失业工人求职自我效能的影响。? 原始设计比较复杂，这里使用 ? 的简化版本。

数据：来自 jobsdata.csv。关键变量：

- treat: 是否被随机分配参加培训项目 (Z)
- comply: 是否实际参加了培训项目 (D)
- jobseek: 求职自我效能得分 (Y , 1-5 分制)

描述性统计：¹¹

例 22.1 (JOBS II 数据的 IV 分析). 我们使用 Wald 估计量分析 JOBS II 数据。结果如下：

方法	估计量	标准误	95% CI 下限	95% CI 上限
Delta 方法	0.109	0.081	-0.050	0.268
Bootstrap	0.109	0.083	-0.054	0.271
含协变量调整	0.118	0.082	-0.042	0.278

解读：点估计表明，对于 compliers，参加培训项目使求职自我效能得分提高约 0.11 分 (满分 5 分)。但 95% 置信区间包含零，这意味着在常规显著性水平下，我们无法拒绝“培训对 compliers 无效果”的原假设。

¹¹详细数据分析代码见附录 ??

10. 从识别到解释：CACE 的深层含义

到目前为止，我们建立了 CACE 的识别和估计框架。但还有一个关键问题：CACE 到底代表什么？

定义 22.3 中定义的 τ_c 有两种等价解释：

- (1) **治疗分配的因果效应 (among compliers)**: $\tau_c = \mathbb{E}\{Y(1) - Y(0) \mid U = c\}$ 是治疗分配对 compliers 结果的平均因果效应。
- (2) **实际治疗的因果效应 (among compliers)**: 对于 compliers, 有 $D(1) = 1$ 和 $D(0) = 0$, 因此 $D = Z$ 。所以 τ_c 也是实际接受的治疗对 compliers 结果的因果效应。

第二种解释更具科学吸引力——它回答了“对于那些会遵医嘱的人，治疗真的有效果吗？”这个问题。

局限性: CACE 只告诉我们关于 compliers 的信息，我们无法直接得知治疗对 always takers、never takers 或 defiers 的效果。如果这些亚组与 compliers 有本质不同的治疗效果，CACE 可能无法代表治疗对整个人群的效果。

11. 本章小结

本章介绍了依从性问题的框架，主要内容如下：

- (1) **依从性问题的普遍性**: 在涉及人类被试的实验中，治疗分配与实际治疗往往不一致。
- (2) **四类依从性状态**: always takers、compliers、defiers、never takers。
- (3) **关键假设**: 随机化、单调性（无 defiers）、排斥限制（治疗分配只能通过实际治疗影响结果）。
- (4) **识别**（定义 22.2）: 在上述假设下， $CACE = \tau_Y / \tau_D$ 。
- (5) **估计**: Wald 估计量 $\hat{\tau}_c = \hat{\tau}_Y / \hat{\tau}_D$ 。
- (6) **弱工具变量问题**: 当 compliers 比例很小时，Wald 估计量表现不佳，需要使用 FAR 置信区间。
- (7) **协变量调整**: 可以提高效率和稳健性。

12. 习题

练习 22.1. *ITT 与 CACE 的关系* 证明在假设 22.2 下， $\tau_Y = \tau_c \cdot \pi_c$ ，其中 $\pi_c = \Pr(U = c)$ 。

练习 22.2. *单调性的可检验含义* 证明在完全随机化下，假设 22.2 蕴含 section 4.1。

练习 22.3. *Wald 估计量的方差* 证明当 $\tau_D = 0$ 时， $\text{var}(\hat{\tau}_c) = \infty$ 。

练习 22.4. *单侧依从性* 考虑单侧依从性情形：对照组被试无法获得治疗，即 $D_i(0) = 0$ 对所有 i 成立。

- (1) 证明此时 假设 22.2 自动成立。
- (2) 在这种情况下，CACE 如何简化为 ITT 的函数？

练习 22.5. *FAR 置信区间的形状* 在 section 7.2 中，FAR 置信集可能是单个闭区间、两个不相连的区间、空集或整个实数线。找出每种情况对应的精确条件。

练习 22.6. *协变量调整的 CACE* 使用 JOBS II 数据进行以下分析：

- (1) 计算原始 Wald 估计量及其标准误。
- (2) 加入协变量 (*sex, age, marital, nonwhite, educ, income*) 后重新估计。
- (3) 比较两种方法的估计量和标准误。

练习 22.7. *Always takers* 与 *Never takers* 假设我们想估计 *always takers* 的平均因果效应。

- (1) 在当前框架下，这个量能否被识别？为什么？
- (2) 如果加入额外假设“*always takers* 和 *never takers* 的潜在结果分布相同”，结果会如何改变？

练习 22.8. 模拟研究 进行模拟研究，比较以下三种情况：

- (1) 强工具变量 ($\pi_c = 0.5$)
- (2) 中等强度工具变量 ($\pi_c = 0.2$)
- (3) 弱工具变量 ($\pi_c = 0.05$)

对每种情况，报告 *Wald* 估计量的偏差、均方误差和置信区间的覆盖概率。

两阶段最小二乘

1. 引言：工具变量回归的计算技巧

在上一章中，我们讨论了恰好识别 (just-identified) 情况下的工具变量 (IV) 估计：当工具变量 Z 与内生解释变量 D 维度相同时，我们可以直接通过矩条件 $E(ZY) = E(ZD^\top)\beta$ 求解得到 IV 估计量。然而，在实际研究中，我们常常面临过度识别 (over-identified) 的情形——也就是说，我们拥有的工具变量数量多于内生变量的数量。

这种情况在经验研究中非常普遍。例如，在研究教育回报的问题时，Angrist and Krueger (1991) 使用出生季度作为教育的工具变量，但实际上我们可能有多个与误差项无关的变量都可以作为工具变量。当工具变量多于内生变量时，矩条件方程组中方程的个数多于未知参数的个数，系统没有唯一的精确解。

一个自然而然的问题是：如何在这种情况下找到一个“最优”的估计量？正是为了回答这个问题，Theil (1953) 和 Basmann (1957) 分别独立地提出了两阶段最小二乘 (Two-Stage Least Squares, TSLS) 估计量。这是一个巧妙的计算技巧，它将一个看似复杂的过度识别问题转化为两个连续的普通最小二乘回归。

本章我们将详细介绍 TSLS 的动机、原理及其在大样本理论下的性质。

2. 问题设定：过度识别情形

让我们回顾线性工具变量模型的基本设定。假设我们有如下结构方程：

$$(117) \quad Y = D^\top \beta + \varepsilon,$$

其中 Y 是结果变量， D 是 p 维内生解释变量， β 是 p 维待估参数向量。我们假设存在 q 维的工具变量 Z 满足排他性 restriction: $E(\varepsilon Z) = 0$ 。

当 $q > p$ (工具变量维度大于内生变量维度) 时，我们面临过度识别问题。此时，样本矩条件

$$(118) \quad n^{-1} \sum_{i=1}^n Z_i Y_i = n^{-1} \sum_{i=1}^n Z_i D_i^\top \beta$$

包含了 q 个方程，但只有 p 个未知参数。当 $q > p$ 时，这些方程通常没有精确解——我们只能寻找一个在某种意义上“最接近”所有矩条件的估计量。

3. 两阶段最小二乘估计量

TSLS 提供了一个优雅的解决方案。顾名思义，这个方法包含两个阶段：

[两阶段最小二乘估计量] 定义以 Z 为工具变量、 D 的系数 β 的 TSLS 估计量如下：

第一阶段 对 D 关于 Z 做 OLS 回归，得到拟合值 $\hat{D}_i$ ($i = 1, \dots, n$)。如果 D_i 是向量，则按分量做 OLS 回归。将拟合值向量组成矩阵 $\hat{D}$ ，其第 i 行为 $\hat{D}_i^\top$ ；

第二阶段 对 Y 关于 $\hat{D}$ 做 OLS 回归，得到系数 $\hat{\beta}_{\text{TSLS}}$ 。

这个定义的表述方式非常直观，但为了理解其深层原理，我们需要进行一些代数推导。

3.1. TSLS 的代数推导. 为了看清 TSLS 估计量的本质, 我们将其显式地写出来。¹ 第一阶段 OLS 回归可以写成:

$$(119) \quad \hat{D}_i = \hat{\Gamma}^\top Z_i,$$

其中 $\hat{\Gamma} = (\sum_{i=1}^n Z_i Z_i^\top)^{-1} \sum_{i=1}^n Z_i D_i^\top$ 。

第二阶段的 OLS 估计量为:

$$(120) \quad \hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

将 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入, 经过整理可得:

$$(121) \quad \hat{\beta}_{\text{TSLS}} = \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right).$$

这个表达式揭示了 TSLS 估计量的本质。由于 $E(Z\varepsilon) = 0$, 根据大数定律, 式 eq. (121) 中最后一项的概率极限为 0, 因此 $\hat{\beta}_{\text{TSLS}}$ 是 β 的相合估计量。

一个值得注意的代数事实是, 当工具变量与内生变量维度相同时 (即 $q = p$ 的恰好识别情形), TSLS 估计量与上一章定义的 IV 估计量 $\hat{\beta}_{\text{IV}}$ 在数值上完全相同。

4. 标准误的估计

在获得点估计之后, 我们需要考虑抽样变异性的度量。基于式 eq. (121), 我们可以推导出 TSLS 估计量的渐近方差, 并据此构造标准误。

具体而言, 首先计算残差 $\hat{\varepsilon}_i = Y_i - \hat{\beta}_{\text{TSLS}}^\top D_i$, 然后采用 Eicker-Huber-White 稳健方差估计量:

$$(122) \quad \hat{V}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \left(\sum_{i=1}^n \hat{\varepsilon}_i^2 \hat{D}_i \hat{D}_i^\top \right) \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1}.$$

这里需要特别强调一点: 残差 $\hat{\varepsilon}_i$ 来自对原方程 Y_i on D_i 的回归, 而不是来自第二阶段 OLS 回归 Y_i on $\hat{D}_i$ 的残差。这一细节非常重要, 因为它意味着 $\hat{V}_{\text{TSLS}}$ 与直接对第二阶段回归应用稳健标准误所得的结果不同。

5. 特殊情形: 单一工具变量与单一内生处理

本节我们考虑一个在应用中最常见的情形: 一个工具变量 Z 作用于一个内生处理变量 D 。考虑如下结构方程组:

$$(123) \quad \begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}, \end{cases}$$

其中 D_i 是标量内生处理变量, Z_i 是标量工具变量 (满足 $E(\varepsilon_i Z_i) = 0$), X_i 是外生协变量向量 (满足 $E(\varepsilon_i X_i) = 0$)。

¹推导过程详见附录 section 13

5.1. TSLS 的简化形式. 在此特殊情形下, section 3 中的 TSLS 估计量简化为:
[单一内生回归子的 TSLS] 基于方程组 eq. (123), TSLS 估计量包含以下两步:

第一阶段 对 D 关于 $(1, Z, X)$ 做 OLS 回归, 得到拟合值 $\hat{D}_i$ ($i = 1, \dots, n$);

第二阶段 对 Y 关于 $(1, \hat{D}, X)$ 做 OLS 回归, 得到系数 $\hat{\beta}_{\text{TSLS}}$, 特别是 $\hat{\beta}_{1, \text{TSLS}}$, 即 $\hat{D}$ 的系数。

这个两步程序在经验研究中极为常用, 因为它在计算上简洁直观, 同时保持了良好的统计性质。

5.2. 间接最小二乘. 结构方程组 eq. (123) 还可以通过另一种思路来估计。注意到约化形式 (reduced form) 为:

$$(124) \quad \begin{cases} Y_i = \Gamma_0 + \Gamma_1 Z_i + \Gamma_2^\top X_i + \varepsilon_{1i}, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}, \end{cases}$$

其中 $\Gamma_0 = \beta_0 + \beta_1 \gamma_0$, $\Gamma_1 = \beta_1 \gamma_1$, $\Gamma_2 = \beta_2 + \beta_1 \gamma_2$, 且 $\varepsilon_{1i} = \varepsilon_i + \beta_1 \varepsilon_{2i}$ 。

关键观察是: 由于约化形式方程中的解释变量 (Z, X) 都是外生的, 我们可以对这两个方程分别做 OLS 回归, 得到一致估计量 $\hat{\Gamma}_1$ 和 $\hat{\gamma}_1$ 。而待估参数 β_1 恰好等于这两个系数的比值:

$$(125) \quad \beta_1 = \frac{\Gamma_1}{\gamma_1}.$$

因此, 我们可以构造间接最小二乘 (Indirect Least Squares, ILS) 估计量:

$$(126) \quad \hat{\beta}_{1, \text{ILS}} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

有趣的是, ILS 估计量与 TSLS 估计量在数值上完全相同。

[TSLS 与 ILS 的等价性] 在单一内生处理变量和单一工具变量的情形下 (方程组 eq. (123)), 我们有

$$(127) \quad \hat{\beta}_{1, \text{ILS}} = \hat{\beta}_{1, \text{TSLS}}.$$

这个定理的本质是一个代数恒等式, 它说明尽管 TSLS 和 ILS 看起来是不同的估计方法, 但它们实际上是同一估计量的不同计算路径。²

比值形式的表达式 eq. (126) 揭示了 TSLS 估计量的一个重要弱点: 当工具变量较弱 (即 γ_1 接近于零) 时, 分子和分母都可能面临严重的有限样本偏误问题。

6. 弱工具变量问题

当工具变量与内生处理变量的相关性较弱时, TSLS 估计量的有限样本性质会严重恶化。这是因为在式 eq. (126) 中, 我们需要用分母 $\hat{\gamma}_1$ 去除分子 $\hat{\Gamma}_1$, 而当 γ_1 接近于零时, 估计量的分布会变得极度非正态, 标准的大样本理论不再适用。

一个更加稳健的推断方法是基于约化形式的 Fieller-Anderson-Rubin (FAR) 方法。该方法的核心思想是: 对于任意假设值 b , 考虑原假设 $H_0(b): \beta_1 = b$ 。在该假设下, 构造调整后的结果变量 $Y_i(b) = Y_i - bD_i$, 并检验 $Y_i(b)$ 与工具变量 Z_i 之间是否存在显著关系。如果 b 是真实值, 那么根据矩条件 $E(Z\varepsilon) = 0$, 这一关系应当不显著。

具体地, FAR 置信区间的构造如下:

$$(128) \quad \{b : |t_Z(b)| \leq z_{1-\alpha/2}\},$$

²定理 section 5.2 的证明详见附录 section 14。

其中 $t_Z(b)$ 是 Z 在回归 $Y_i(b)$ on $(1, Z, X)$ 中的 t 统计量 (使用 EHW 稳健标准误), $z_{1-\alpha/2}$ 是标准正态分布的 $1 - \alpha/2$ 分位数。

值得注意的是, 这种 FAR 方法在弱工具变量情形下比传统的基于 TSLS 的 Wald 型置信区间更加稳健, 而且在某些情况下可以完全避免使用 TSLS 估计量。

7. 应用: Card (1993) 教育回报研究

让我们将 TSLS 方法应用于一个经典的经验研究问题: 教育对工资的因果效应。Card (1993) 利用美国年轻男性队列数据, 使用居住地附近是否有四年制大学作为教育的工具变量, 估计了教育的回报率。

在该研究中, 工具变量 Z 是“成长地附近是否有四年制大学”的指示变量, 处理变量 D 是受教育年限, 结果变量 Y 是 1976 年的对数工资。协变量 X 包括种族、年龄及其平方、是否与双亲同住等。

应用 TSLS 方法, 我们得到点估计和 95% 置信区间:

	TSLS 估计		
	下界	上界	
教育回报率	0.132	0.026	0.237

这意味着, 多受一年教育会使工资提高约 13.2%。使用 FAR 方法, 我们得到置信区间为 $[0.028, 0.282]$, 与 TSLS 的结果非常接近, 这是因为在该数据中工具变量并非特别弱。

8. 小结

本章我们介绍了两阶段最小二乘 (TSLS) 估计量, 这是工具变量方法在过度识别情形下的核心计算技术。TSLS 的关键思想是将一个复杂的矩估计问题转化为两个连续的 OLS 回归, 从而大大简化了计算。

从理论角度, 我们证明了 TSLS 估计量在大样本下是相合的, 并且当工具变量与内生变量维度相同时, 它与传统的 IV 估计量完全等价。此外, 我们还介绍了 TSLS 与间接最小二乘 (ILS) 的等价性, 以及弱工具变量情形下的 FAR 稳健推断方法。

在应用层面, TSLS 已成为计量经济学中处理内生性问题的标准工具。下一章我们将讨论如何检验工具变量的有效性, 以及如何处理可能的工具变量失效情形。

9. 习题

练习 23.1 (TSLS 与 IV 的等价性). 证明在恰好识别情形下 (Z 与 D 维度相同), TSLS 估计量 $\hat{\beta}_{\text{TSLS}}$ 与 IV 估计量 $\hat{\beta}_{\text{IV}}$ 数值相同。

提示: 利用第一阶段 OLS 的正交性条件 $\sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0$ 。

练习 23.2 (TSLS 与 ILS 的等价性). 证明定理 section 5.2: 在单一内生处理变量和单一工具变量情形下, TSLS 估计量等于约化形式系数比值 $\hat{\Gamma}_1/\hat{\gamma}_1$ 。

提示: 利用第一阶段拟合值的表达式 $\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i$, 验证第二阶段 OLS 中 $\hat{D}$ 的系数恰好等于比值形式。

练习 23.3 (弱工具变量的影响). 考虑 TSLS 估计量 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1/\hat{\gamma}_1$ 。当工具变量较弱 (即 γ_1 接近于零) 时, 讨论:

- (1) 为什么 $\hat{\gamma}_1$ 的小误差会导致 $\hat{\beta}_{1,\text{TSLS}}$ 的巨大偏差?
- (2) FAR 置信区间相比 Wald 型置信区间的优势是什么?

模糊断点回归

1. 本章导论

在前两章中，我们分别学习了断点回归设计 (Regression Discontinuity Design, RDD) 和工具变量法 (Instrumental Variables, IV)。本章我们要问一个自然的问题：**如果把这两种方法结合起来，会发生什么？**

答案就是本章的主题——**模糊断点回归** (Fuzzy Regression Discontinuity, FRDD)。这是一种“自然实验”，它既保留了断点回归的直观设定，又借助工具变量的识别策略来处理内生性问题。

2. 从清晰断点到模糊断点

2.1. 清晰断点回归的回顾。 在第 20 章中，我们学习了**清晰断点回归** (Sharp RDD)。其核心设定是：治疗分配 $Z_i = I(X_i \geq x_0)$ 由运行变量 (running variable) X_i 在断点 x_0 处**确定性地**决定。

在清晰 RDD 下，潜在结果 $\{Y_i(1), Y_i(0)\}$ 在断点处的期望差可以识别：

$$(129) \quad \tau_Y(x_0) = \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y \mid X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y \mid X = x_0 - \varepsilon).$$

2.2. 模糊断点回归的引入。 然而，在现实中有许多情况，治疗分配并不是由运行变量**完全**决定的。运行变量改变了治疗的**概率**，但不决定治疗的最终结果。

关键观察：在模糊 RDD 中， $Z_i = I(X_i \geq x_0)$ 仍然是一个有效的工具变量——它满足：

- (1) **相关性：** Z_i 与治疗状态 D_i 相关 (因为 $X_i \geq x_0$ 增加了接受治疗的概率)
- (2) **排除限制：** Z_i 通过改变 D_i 来影响 Y_i ，而没有直接影响 (需要额外假设)

这就将我们引向了工具变量法的框架。

3. 动机实例

例 24.1 (印度农村道路项目)。 研究了印度政府 2000 年启动的“总理乡村道路计划”。该计划根据 2001 年人口普查的阈值来优先考虑规模较大的村庄。

关键点：村庄人口规模与阈值的差并不能**直接决定**是否获得道路——它只改变了获得道路的**概率**。在断点附近，获得道路的概率发生了跳跃，但不是从 0 到 1 的确定性跳跃。

例 24.2 (意大利大学助学金项目)。 研究了意大利大学助学金对辍学率的影响。学生如果标准化家庭收入低于 15,000 欧元，则有资格获得助学金。

为获得助学金，学生必须先申请。因此，资格状态和申请状态共同决定了最终治疗状态。运行变量 (15,000 减去标准化家庭收入) 单独并不能决定治疗状态，但它在断点处改变了治疗概率。

FIGURE 1. 清晰断点回归（左）与模糊断点回归（右）的治疗分配概率比较

4. 数学设定

设 X_i 为运行变量，断点为 x_0 。定义工具变量：

$$Z_i = I(X_i \geq x_0).$$

治疗分配 D_i 可能不等于 Z_i ，但条件概率 $\mathbb{P}(D_i = 1 | X_i = x)$ 在 x_0 处有跳跃。
fig. 1 比较了清晰 RDD 和模糊 RDD 中治疗分配概率的差异。

5. 识别定理

设 Y_i 为关注的结果变量。视 Z_i 为已分配的治疗，我们可以定义潜在结果 $\{D_i(1), D_i(0), Y_i(1), Y_i(0)\}$ 。
清晰 RDD 可以识别：

$$\tau_D(x_0) = \mathbb{E}\{D(1) - D(0) | X = x_0\}$$

和

$$(130) \quad \tau_Y(x_0) = \mathbb{E}\{Y(1) - Y(0) | X = x_0\}.$$

使用 Z 作为 D 的工具变量，并施加工具变量假设（在 $X = x_0$ 邻域内），我们可以通过应用定理来识别局部依从者平均因果效应（Local Complier Average Causal Effect, LATE）。

定理 24.1 (模糊 RDD 识别). 设治疗由 $Z = I(X \geq x_0)$ 决定，其中 x_0 是预定的阈值。

假设**单调性**：

$$(131) \quad D_i(1) \geq D_i(0),$$

和**排除限制**：

$$(132) \quad D_i(1) = D_i(0) \implies Y_i(1) = Y_i(0),$$

在 x_0 的无穷小邻域内成立。

连续性假设： $E\{D(1) | X = x\}$ 和 $E\{Y(1) | X = x\}$ 在 $x = x_0$ 处右连续， $E\{D(0) | X = x\}$ 和 $E\{Y(0) | X = x\}$ 在 $x = x_0$ 处左连续。

局部依从者平均因果效应（Local Average Treatment Effect, LATE）定义为：

$$(133) \quad \tau_{\text{LATE}}(x_0) = \mathbb{E}\{Y(1) - Y(0) | D(1) > D(0), X = x_0\},$$

可以由下式识别：

$$(134) \quad \tau_{\text{LATE}}(x_0) = \frac{\mathbb{E}\{Y(1) - Y(0) | X = x_0\}}{\mathbb{E}\{D(1) - D(0) | X = x_0\}}.$$

如果 $E(D | X = x)$ 在 $x = x_0$ 处有非零跳跃，则局部依从者平均因果效应可以由下式识别：

$$(135) \quad \tau_{\text{LATE}}(x_0) = \frac{\lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y | Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y | Z = 0, X = x_0 - \varepsilon)}{\lim_{\varepsilon \rightarrow 0+} \mathbb{E}(D | Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(D | Z = 0, X = x_0 - \varepsilon)}.$$

定理 定义 24.1 的直觉：这是清晰 RDD 识别和工具变量识别定理的叠加。分子是 (130)，分母是 (5)。两者相除，得到依从者亚组的平均因果效应。

识别策略的核心思想：在模糊 RDD 中，我们不再假设治疗由运行变量完全决定，而是假设工具变量 Z 通过影响治疗概率来间接影响结果。这与标准 IV 框架的区别在于：IV 假设在断点的邻域内成立，而不是对全体样本成立。

FIGURE 2. 重分析 ? 的数据, TSLS 的点估计和标准误

FIGURE 3. 重分析 ? 的数据, TSLS 的点估计和标准误

6. 估计方法

6.1. 偏误-方差权衡. 在清晰和模糊 RDD 中, 核心问题都是指定断点周围的邻域。实际中:

- 较小的邻域导致较小的偏误, 但较大的方差
- 较大的邻域导致较大的偏误, 但较小的方差

这就是经典的**偏误-方差权衡** (bias-variance trade-off)。一些自动选择带宽的程序存在, 但它们依赖较强的条件。对一系列邻域选择进行敏感性分析似乎更为明智。

6.2. 间接最小二乘估计. 假设我们已指定由带宽 h 确定的 x_0 邻域。对于 $X_i \in [x_0 - h, x_0 + h]$ 的数据, 我们可以通过以下两步估计 $\tau_{\text{LATE}}(x_0)$:

第一步: 估计第一阶段关系

$$\hat{\tau}_D(x_0) = \text{the coefficient of } Z_i \text{ in the OLS fit of } D_i \text{ on } \{1, Z_i, R_i, L_i\},$$

其中 $R_i = \max(X_i - x_0, 0)$, $L_i = \min(X_i - x_0, 0)$ 。

第二步: 估计约简型关系

$$\hat{\tau}_Y(x_0) = \text{the coefficient of } Z_i \text{ in the OLS fit of } Y_i \text{ on } \{1, Z_i, R_i, L_i\}.$$

第三步: 计算比率

$$\hat{\tau}_{\text{LATE}}(x_0) = \hat{\tau}_Y(x_0) / \hat{\tau}_D(x_0).$$

这被称为**间接最小二乘估计器** (Indirect Least Squares Estimator, ILS)。根据定理, ILS 估计器数值上等同于:

$$\text{the coefficient of } D_i \text{ in the TSLS fit of } Y_i \text{ on } \{1, D_i, R_i, L_i\}$$

with D_i instrumented by Z_i 。

总之, 在指定 h 后, $\tau_{\text{LATE}}(x_0)$ 的估计归结为断点邻域内的两阶段最小二乘 (TSLS) 程序。

7. 数据应用

7.1. 印度农村道路数据. 重温 例 24.1。我们可以基于结果 `occupation_index_andrsn` 计算一系列 h 的点估计和标准误。

fig. 2 展示了结果。除非 h 很大, 否则治疗效应不显著。

7.2. 意大利大学助学金数据. 重温 例 24.2。运行变量定义为 15,000 减去标准化家庭收入。分析中将数据限制在 $[-5000, 5000]$ 的子集, 然后除以 5000 使运行变量有界于 $[-1, 1]$ 。

fig. 3 展示了结果, 表明大学助学金对辍学率没有显著影响。

8. 讨论

第 20 章和本章都将断点回归建立在给定运行变量时潜在结果条件期望的连续性之上。这个视角在数学上更简单，但它只能精确识别运行变量断点处的局部效应。？开创了这一研究路线。

另一种不那么主流的视角基于**局部随机化** (local randomization)。[??]。如果我们视运行变量为某种底层真实值的噪声测量，而断点有些任意地选择，那么断点附近的单元在系统上并没有差异。这表明在断点的较小邻域内，单元以随机方式接受治疗和控制——就像在随机实验中一样。

与清晰 RDD 的选择邻域问题类似，在局部随机化视角下，决定随机实验应该有多“局部”也是至关重要的。将这种直觉数学量化并不容易，因此对一系列带宽 h 进行敏感性分析似乎也是第二种视角下的合理方法。

？提供了断点回归的概念性讨论。

9. 本章小结

本章的核心要点：

- (1) **模糊断点回归**：治疗概率在断点处跳跃，但不像清晰 RDD 那样由运行变量完全决定
- (2) **识别策略**：将 $Z = I(X \geq x_0)$ 作为工具变量，在单调性和排除限制下识别 LATE
- (3) **估计方法**：间接最小二乘 (ILS) 或两阶段最小二乘 (TSLS)
- (4) **偏误-方差权衡**：带宽选择是关键——较小的邻域偏误小但方差大
- (5) **与清晰 RDD 的关系**：模糊 RDD 是清晰 RDD 和 IV 方法的结合

下一章我们将学习**局部随机化视角下的断点回归**，这为 RDD 提供了另一种理论依据。

10. 习题

练习 24.1. 24.1 模糊 RDD 识别定理的证明 证明 定义 24.1 中的识别公式。

练习 24.2. 24.2 清晰 RDD 与模糊 RDD 的比较

- (1) 在清晰 RDD 中，治疗分配 D 和工具变量 Z 有什么关系？
- (2) 在模糊 RDD 中，这种关系如何变化？
- (3) 给出清晰 RDD 和模糊 RDD 各一个现实生活中的例子。

练习 24.3. 24.3 带宽敏感性分析 对于 section 7.1 中的印度道路数据，使用不同的带宽 h 进行敏感性分析。报告点估计和标准误如何随 h 变化。

练习 24.4. 24.4 ILS 与 TSLS 的等价性 证明在模糊 RDD 中，间接最小二乘估计器（比率形式）和两阶段最小二乘估计器在数值上是等价的。

孟德尔随机化

1. 引言：遗传学与因果推断的交汇

在第 21 章和第 ?? 章中，我们看到了工具变量 (IV) 方法如何帮助解决观测性研究中的未测量混杂问题。然而，传统 IV 方法面临一个根本困难：找到一个有效的工具变量谈何容易。研究者需要确信这个变量满足三个关键条件——与治疗变量相关、不与未测量混杂相关、以及仅通过治疗变量影响结果。

20 世纪 80 年代，一位名叫 Katan 的研究者 [?] 提出了一个颇具洞察力的观点：也许遗传变异能够充当天然的工具变量。他的论证基于孟德尔的第二定律——独立分配定律 (law of random assortment)，该定律表明一种性状的遗传独立于其他性状的遗传。这意味着，如果我们能找到与某个暴露因素（如胆固醇水平）相关的基因变异，同时这些变异与混杂暴露因素与结果之间关系的未测量混杂因子相互独立，那么这些基因变异就可能成为一个有效的工具变量。

这一思想在流行病学研究中引发了革命性的变革。2003 年，Davey Smith 和 Ebrahim [?] 将这种方法正式命名为**孟德尔随机化 (Mendelian Randomization, MR)**。如今，MR 已成为流行病学中估计暴露因素对结果因果效应的核心方法 [?]

本章的核心问题：如何利用遗传变异作为工具变量来估计因果效应？这种方法的假设是什么？又有哪些局限性？

2. 背景与动机

2.1. 从胆固醇到癌症：一个经典难题。在深入技术细节之前，让我们先理解 MR 最初被提出时的动机。20 世纪 80 年代的观测性研究暗示，低血清胆固醇水平可能与癌症风险相关。然而，这样的观察性研究面临两个根本性问题：

- (1) **未测量的混杂：**胆固醇水平和癌症之间可能存在共同的未测量混杂因素，例如饮食模式或社会经济地位。
- (2) **反向因果：**更棘手的是，癌症的早期阶段可能反过来导致低血清胆固醇水平，即因果方向可能与假设的相反。

Katan [?] 指出，Apolipoprotein E 基因与血清胆固醇水平相关，但（理论上）不直接影响癌症状态。因此，如果我们能比较携带不同基因型的人群在癌症风险上的差异，就能区分因果效应和混杂/反向因果。这一论证与我们在第 21 章讨论的 IV 框架完美契合。

2.2. MR 的因果图。图 1 展示了一个典型 MR 研究的因果结构。

在许多 MR 研究中，遗传工具变量是**单核苷酸多态性 (single nucleotide polymorphisms, SNPs)**。由于**多效性 (pleiotropy)** 的存在，遗传工具变量有可能直接影响结果，因此图 1 中允许违反排他性限制假设的情况。

3. 线性 IV 模型回顾

在介绍 MR 的统计方法之前，我们需要回顾第 ?? 章中的线性 IV 模型。这里我们显式地引入未测量混杂因子 U ，这在 MR 背景下尤为重要。




FIGURE 1. MR 因果图: G_j 为遗传变异 (工具变量), D 为暴露因素, Y 为结果, U 为未测量的混杂因子, 虚线箭头表示 G_j 可能违反排他性限制的直接效应。

3.1. 标准线性 IV 模型 (满足排他性限制).

定义 25.1 (标准线性 IV 模型). 结构形式为:

$$(25.1) \quad Y = \beta_0 + \beta D + \beta_u U + \varepsilon_Y,$$

$$(25.2) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

约简形式为:

$$(25.3) \quad Y = (\beta_0 + \beta\gamma_0) + \beta\gamma_1 G_1 + \cdots + \beta\gamma_p G_p + (\beta_u + \beta\gamma_u)U + \varepsilon_Y,$$

$$(25.4) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

在排他性限制下, G_j 对 Y 没有直接效应, 因此 $\Gamma_j = \beta\gamma_j$ ($j = 1, \dots, p$).

3.2. 允许违反排他性限制的模型. 在 MR 研究中, 由于多效性的存在, 排他性限制可能不成立。因此我们需要允许遗传工具变量直接作用于结果。

定义 25.2 (可能无效的工具变量模型). 线性模型为:

$$(25.5) \quad Y = \beta_0 + \beta D + \alpha_1 G_1 + \cdots + \alpha_p G_p + \beta_u U + \varepsilon_Y,$$

$$(25.6) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

约简形式为:

$$(25.7) \quad Y = (\beta_0 + \beta\gamma_0) + (\alpha_1 + \beta\gamma_1)G_1 + \cdots + (\alpha_p + \beta\gamma_p)G_p + (\beta_u + \beta\gamma_u)U + \varepsilon_Y,$$

$$(25.8) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

在这种情况下, $\Gamma_j = \alpha_j + \beta\gamma_j$ ($j = 1, \dots, p$)。如果 $\alpha_j \neq 0$, 则 G_j 是无效的工具变量。

注 25.1. 定义 25.1 和 25.2 与第 ?? 章的线性 IV 模型略有不同——我们显式包含了未测量混杂因子 U 。但这一差异本质上不影响讨论, 因为 U 在约简形式中通过 $\beta_u + \beta\gamma_u$ 被合并到系数中。

4. 基于汇总统计的 MR 分析

4.1. MR 研究的数据结构. 传统的 IV 估计需要个体水平的数据。然而, 大多数 MR 研究并没有个体数据, 而是从多个全基因组关联研究 (genome-wide association studies, GWAS) 中获取**汇总统计 (summary statistics)**。一个典型的 MR 研究具有以下数据结构。

假设 25.1 (基于汇总统计的 MR 研究). (1) 我们有治疗变量对遗传工具变量的回归系数 $\hat{\gamma}_1, \dots, \hat{\gamma}_p$ 及其标准误 $\text{se}_{D1}, \dots, \text{se}_{Dp}$ 。假设

$$(25.9) \quad \hat{\gamma}_1 \xrightarrow{p} \gamma_1, \dots, \hat{\gamma}_p \xrightarrow{p} \gamma_p$$

并忽略标准误的不确定性。

(2) 我们有结果变量对遗传工具变量的回归系数 $\hat{\Gamma}_1, \dots, \hat{\Gamma}_p$ 及其标准误 $\text{se}_{Y1}, \dots, \text{se}_{Yp}$ 。假设

$$(25.10) \quad \hat{\Gamma}_1 \xrightarrow{p} \Gamma_1, \dots, \hat{\Gamma}_p \xrightarrow{p} \Gamma_p$$

并忽略标准误的不确定性。

(3) 假设 $\hat{\gamma}_1, \dots, \hat{\gamma}_p, \hat{\Gamma}_1, \dots, \hat{\Gamma}_p$ 联合服从正态分布且相互独立。

回归系数的渐近正态性可由中心极限定理保证。标准误在大样本中是真实标准误的准确估计。因此, 唯一微妙的假设是回归系数之间的联合独立性。 $\hat{\gamma}_j$ 与 $\hat{\Gamma}_j$ 之间的独立性是合理的, 因为它们通常基于不同的样本计算。

4.2. 固定效应估计量. 在定义 25.1 (满足排他性限制) 的假设下, $\alpha_j = 0$, 这意味着 $\beta = \Gamma_j/\gamma_j$ 对所有 j 成立。一个简单的方法基于所谓的**元分析 (meta-analysis)**——即结合多个估计量 $\hat{\beta}_j = \hat{\Gamma}_j/\hat{\gamma}_j$ 来估计共同参数 β , 这种方法也被称为**固定效应 (fixed effect)** 估计。

使用 delta 方法 (见假设 25.1), 比值估计量 $\hat{\beta}_j$ 的近似标准误为:

$$(25.11) \quad \text{se}_j^2 = (\text{se}_{Yj}^2 + \hat{\beta}_j^2 \text{se}_{Dj}^2) / \hat{\gamma}_j^2.$$

因此, 估计 β 的最佳线性组合是基于方差倒数加权的 Fisher 估计 (见练习题):

$$(25.12) \quad \hat{\beta}_{\text{fisher0}} = \frac{\sum_{j=1}^p \hat{\beta}_j / \text{se}_j^2}{\sum_{j=1}^p 1 / \text{se}_j^2},$$

其方差为 $\left(\sum_{j=1}^p 1 / \text{se}_j^2\right)^{-1}$ 。

忽略 $\hat{\gamma}_j$ 由 se_{Dj} 量化的不确定性, 估计量简化为:

$$(25.13) \quad \hat{\beta}_{\text{fisher1}} = \frac{\sum_{j=1}^p \hat{\beta}_j \hat{\gamma}_j^2 / \text{se}_{Yj}^2}{\sum_{j=1}^p \hat{\gamma}_j^2 / \text{se}_{Yj}^2} = \frac{\sum_{j=1}^p \hat{\Gamma}_j \hat{\gamma}_j / \text{se}_{Yj}^2}{\sum_{j=1}^p \hat{\gamma}_j^2 / \text{se}_{Yj}^2},$$

其方差为 $\left(\sum_{j=1}^p \hat{\gamma}_j^2 / \text{se}_{Yj}^2\right)^{-1}$ 。虽然次优, 但 $\hat{\beta}_{\text{fisher1}}$ 在实践中应用更广泛 [?].

在定义 25.2 (允许无效工具变量) 的假设下, 我们可以证明:

$$(25.14) \quad \hat{\beta}_{\text{fisher1}} \xrightarrow{p} \frac{\sum_{j=1}^p \Gamma_j \gamma_j / \text{se}_{Yj}^2}{\sum_{j=1}^p \gamma_j^2 / \text{se}_{Yj}^2} = \beta + \frac{\sum_{j=1}^p \alpha_j \gamma_j / \text{se}_{Yj}^2}{\sum_{j=1}^p \gamma_j^2 / \text{se}_{Yj}^2}.$$

如果对所有 j 都有 $\alpha_j = 0$, 则 $\hat{\beta}_{\text{fisher1}}$ 是一致的。即使这不成立, 只要 α_j 与 γ_j 的内积按 $1/\text{se}_{Yj}^2$ 加权为零, $\hat{\beta}_{\text{fisher1}}$ 仍可能是一致的。

注 25.2. 当有许多遗传工具变量, 且违反排他性限制 (由 α_j 捕获) 是来自均值为零的分布的独立随机抽样时, 上述条件近似成立。

4.3. Egger 回归. 现在从定义 25.1 (满足排他性限制) 出发。在真实参数下, 我们有:

$$(25.15) \quad \Gamma_j = \beta\gamma_j \quad (j = 1, \dots, p).$$

用估计量替代时, 上述等式仅近似成立:

$$(25.16) \quad \hat{\Gamma}_j \approx \beta\hat{\gamma}_j \quad (j = 1, \dots, p).$$

这看似一个经典的最小二乘问题——将 $\{\hat{\Gamma}_j\}_{j=1}^p$ 对 $\{\hat{\gamma}_j\}_{j=1}^p$ 进行回归。我们可以拟合 $\hat{\Gamma}_j$ 对 $\hat{\gamma}_j$ 的加权最小二乘 (WLS), 有或无截距项, 可能按 w_j 加权, 以估计 β 。以下结果得益于第 ?? 章回顾的 WLS 代数性质。

无截距时, $\hat{\gamma}_j$ 的系数为:

$$(25.17) \quad \hat{\beta}_{\text{egger1}} = \frac{\sum_{j=1}^p \hat{\gamma}_j \hat{\Gamma}_j w_j}{\sum_{j=1}^p \hat{\gamma}_j^2 w_j},$$

当 $w_j = 1/\text{se}_{Y_j}^2$ 时, 这退化为 $\hat{\beta}_{\text{fisher1}}$ 。这种 WLS 被称为 **Egger 回归**, 它比第 4.2 节的固定效应估计量更一般。

有截距时, $\hat{\gamma}_j$ 的系数为:

$$(25.18) \quad \hat{\beta}_{\text{egger0}} = \frac{\sum_{j=1}^p (\hat{\gamma}_j - \hat{\gamma}_w)(\hat{\Gamma}_j - \hat{\Gamma}_w)w_j}{\sum_{j=1}^p (\hat{\gamma}_j - \hat{\gamma}_w)^2 w_j},$$

其中 $\hat{\gamma}_w = \sum_{j=1}^p \hat{\gamma}_j w_j / \sum_{j=1}^p w_j$ 和 $\hat{\Gamma}_w = \sum_{j=1}^p \hat{\Gamma}_j w_j / \sum_{j=1}^p w_j$ 分别是 $\hat{\gamma}_j$ 和 $\hat{\Gamma}_j$ 的加权平均值。

即使不假设所有 γ_j 为零 (定义 25.2), 我们也有:

$$(25.19) \quad \hat{\beta}_{\text{egger0}} \xrightarrow{p} \frac{\sum_{j=1}^p (\gamma_j - \gamma_w)(\Gamma_j - \Gamma_w)w_j}{\sum_{j=1}^p (\gamma_j - \gamma_w)^2 w_j} = \beta + \frac{\sum_{j=1}^p (\gamma_j - \gamma_w)(\alpha_j - \alpha_w)w_j}{\sum_{j=1}^p (\gamma_j - \gamma_w)^2 w_j},$$

其中 γ_w, Γ_w 和 α_w 是相应真实参数的加权平均值。

因此, $\hat{\beta}_{\text{egger0}}$ 一致地估计 β , 只要 α_j 对 γ_j 的 WLS 系数为零。这比 $\alpha_j = 0$ (对所有 j) 的假设更弱。当 γ_j 和 α_j 是独立随机变量的实现值时, 这个较弱的假设成立, 这被称为**工具强度独立于直接效应 (Instrument Strength Independent of Direct Effect, InSIDE) 假设** [?].

更有趣的是, Egger 回归的截距:

$$(25.20) \quad \hat{\alpha}_{\text{egger0}} = \hat{\Gamma}_w - \hat{\beta}_{\text{egger0}}\hat{\gamma}_w,$$

在 InSIDE 假设下收敛到:

$$(25.21) \quad \Gamma_w - \beta\gamma_w = \alpha_w,$$

即直接效应的加权平均值。因此, 截距估计了直接效应的加权平均。

5. 实例分析

本节使用 `mr.raps` 包中的 `bmi.sbp` 数据 [?] 来说明 Fisher 加权估计和 Egger 回归的实际应用。

5.1. Fisher 加权估计. 首先, 以下函数实现了 Fisher 加权:

```
fisher.weight = function(est, se)
{
  n = sum(est/se^2)
  d = sum(1/se^2)
  res = c(n/d, sqrt(1/d))
  names(res) = c("est", "se")
  res
}
```

使用该函数对 BMI-SBP 数据进行分析, 基于 $\hat{\beta}_{\text{fisher0}}$ 和 $\hat{\beta}_{\text{fisher1}}$ 的结果非常接近:

```
> fisher.weight(bmisbp$iv, bmisbp$se.iv)
      est      se
0.31727680 0.05388827
> fisher.weight(bmisbp$iv, bmisbp$se.iv1)
      est      se
0.31576007 0.05893783
```

5.2. Egger 回归. 带截距或不带截距的 Egger 回归也给出了非常相似的结果, 但标准误与 Fisher 加权估计的结果差异很大:

```
> mr.egger = lm(beta.output ~ 0 + beta.exposure,
+ data = bmisbp, weights = 1/se.output^2)
> summary(mr.egger)$coef
              Estimate Std. Error t value Pr(>|t|)
beta.exposure 0.3172768  0.1105994  2.868704 0.004681659

> mr.egger.w = lm(beta.output ~ beta.exposure,
+ data = bmisbp, weights = 1/se.output^2)
> summary(mr.egger.w)$coef
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.0001133328 0.002079418 0.05450217 0.956603931
beta.exposure 0.3172989306 0.110948506 2.85987564 0.004811017
```

图 2 展示了原始数据以及带截距的 Egger 回归拟合线。

$\hat{\gamma}_j \hat{\Gamma}_j$ 数据点回归线

FIGURE 2. 按方差倒数加权的散点图及 Egger 回归线。

6. MR 分析的批评与局限

MR 是 IV 方法思想的应用。它依赖于强有力的假设。我从概念、生物学和技术三个层面提供三组批评。

6.1. 概念层面的批评. 从潜在结果的角度看, 大多数 MR 研究中的治疗变量定义并不明确。例如, 治疗通常被定义为胆固醇水平或 BMI。这些是复合变量, 可能对应复杂且非唯一的假设实验定义。SUTVA (稳定单元治疗值假设) 在这些治疗变量上往往不成立。回想第 ?? 章的讨论。

6.2. 生物学层面的批评. IV 分析的基本假设可能不成立。孟德尔的第二定律确保了不同性状的遗传是独立的。然而，它并不能确保候选工具变量与治疗 and 结果之间的未测量混杂因子相互独立。这些工具变量可能直接影响混杂因子。同样，某些未测量基因可能同时影响工具变量和混杂因子。孟德尔的第二定律也不能确保排他性限制假设——工具变量有可能通过治疗感兴趣变量之外的途径影响结果。

6.3. 技术层面的批评. MR 的统计假设相当强。线性 IV 模型是一个强假设。 $\hat{\gamma}_j$ 与 $\hat{\Gamma}_j$ 的独立性也相当强。数据收集过程中的其他问题可能进一步复杂化对 IV 假设的解释。例如，治疗 and 结果通常存在测量误差，而且全基因组关联研究通常基于条件于结果的病例对照设计（见第 ?? 章）。

VanderWeele 等 (2014) 是讨论 MR 方法论挑战的优秀综述论文。

7. 习题

练习 25.1. 25.1 Fisher 加权估计的推导 证明第 4.2 节中 $\hat{\beta}_{\text{fisher0}}$ 的方差为 $\left(\sum_{j=1}^p 1/\text{se}_j^2\right)^{-1}$ 。
提示：利用 $\hat{\beta}_j$ 的独立性。

练习 25.2. 25.2 InSIDE 假设的含义 解释 InSIDE（工具强度独立于直接效应）假设在什么意义上弱于 $\alpha_j = 0$ （对所有 j ）的排他性限制假设。给出一个满足 InSIDE 但不满足 $\alpha_j = 0$ 的数值例子。

练习 25.3. 25.3 Egger 截距的解释 在第 4.3 节中，我们看到 Egger 回归的截距 $\hat{\alpha}_{\text{egger0}}$ 收敛到直接效应的加权平均 α_w 。讨论为什么这个性质在实践中有用——即为什么我们可能关心估计 α_w 而不仅仅是 β 。

练习 25.4. 25.4 数据分析 分析 `mr.raps` 包中的 `bmi.bmi` 数据。参见 ?, 第 7.2 节 了解更多细节。

推荐阅读

- ? 综述了 MR 的潜力和局限性，是该领域的经典文献。
- ? 提出了 Egger 回归方法来检测和调整无效工具变量。
- ? 开发了基于鲁棒调整轮廓得分（robust adjusted profile score, RAPS）的两样本汇总数据 MR 推断方法。

双重差分：利用面板数据的结构识别因果效应

1. 引言：一个看似简单的问题

考虑一个政策评估的常见场景：某市政府在 2020 年对某区企业实施了一项税收优惠政策。我们想知道这项政策是否促进了就业增长。

一个朴素的思路是：比较政策实施前后该区的就业变化。例如，若 2019 年就业人数为 1000，2021 年为 1200，则增长 20%，似乎说明政策有效。

然而，这个推理存在一个根本性的缺陷：**时间趋势本身可能导致就业变化**。即使没有税收优惠，经济周期、技术进步、产业迁移等因素也可能导致就业的自然波动。换言之，我们观察到的变化可能是政策效果，也可能是时间趋势的结果——两者无法分离。

这个困境促使我们思考：能否利用**面板数据**（panel data，即同一组单元在多个时间点的观测数据）的结构，在一定程度上消除时间趋势的干扰，从而更准确地识别政策效果？

双重差分（Difference-in-Differences, DiD）正是为解决这一问题而诞生的方法。其核心思想朴素而深刻——同时利用**组间比较**和**时间比较**，通过两次差分消除时间趋势的影响。

2. 基本设定：2×2 情形

2.1. 研究设计与记号。考虑一个最简单的 DiD 设定：有两组单元（处理组和对照组）和两个时间点（政策实施前和政策实施后）。记

- $G_i \in \{0, 1\}$ ：单元 i 的组别， $G_i = 1$ 表示处理组， $G_i = 0$ 表示对照组
- $T_t \in \{0, 1\}$ ：时间， $T_t = 0$ 表示政策实施前（基期）， $T_t = 1$ 表示政策实施后
- Y_{it} ：单元 i 在时间 t 的观测结果
- $D_i = G_i$ ：处理指示变量（假设政策实施后处理组收到处理，对照组未处理）

我们有 N 个单元的下标 $i = 1, \dots, N$ ，其中处理组有 N_1 个单元，对照组有 N_0 个单元（ $N_1 + N_0 = N$ ）。

关键假设：潜在结果框架。对每个单元 i 和每个时间 t ，定义潜在结果：

$$Y_{it}(1) \quad \text{和} \quad Y_{it}(0)$$

分别表示如果收到处理和未收到处理时单元 i 在时间 t 的结果。观测结果由下式给出：

$$Y_{it} = Y_{it}(0) + D_i(Y_{it}(1) - Y_{it}(0)).$$

att 的定义。处理组在时间 t 的平均处理效应（Average Treatment effect on the Treated, ATT）为：

$$\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) \mid G_i = 1).$$

2.2. 基本 DiD 估计量. 考虑以下四个总体均值：

$$\bar{Y}_{00} = \mathbb{E}(Y_{it} \mid G_i = 0, T_t = 0) \text{ (对照组, 政策前)}$$

$$\bar{Y}_{01} = \mathbb{E}(Y_{it} \mid G_i = 0, T_t = 1) \text{ (对照组, 政策后)}$$

$$\bar{Y}_{10} = \mathbb{E}(Y_{it} \mid G_i = 1, T_t = 0) \text{ (处理组, 政策前)}$$

$$\bar{Y}_{11} = \mathbb{E}(Y_{it} \mid G_i = 1, T_t = 1) \text{ (处理组, 政策后)}$$

第一次差分：组内时间差分。

处理组的时间差分为 $\bar{Y}_{11} - \bar{Y}_{10}$ ，包含两部分：

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\tau_1}_{\text{政策效果}} + \underbrace{[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)]}_{\text{时间趋势造成的变化}},$$

其中 $\bar{Y}_{1t}(0) = \mathbb{E}(Y_{it}(0) \mid G_i = 1, T_t = t)$ 表示处理组若未受处理在时间 t 的潜在结果均值。

类似地，对照组的时间差分为 $\bar{Y}_{01} - \bar{Y}_{00}$ ，这一差分完全由时间趋势驱动（因为对照组未受处理）：

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{10}(0) - \bar{Y}_{11}(0).$$

第二次差分：组间差分消除时间趋势。

将处理组的时间差分减去对照组的时间差分：

$$\underbrace{(\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})}_{\text{双重差分}} = \tau_1 + \underbrace{[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)]}_{\text{时间趋势}} - \underbrace{[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)]}_{\text{时间趋势}}.$$

时间趋势项被消去了！我们得到：

$$\text{DiD} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) = \tau_1.$$

这意味着，在**平行趋势假设**（见下节）下，双重差分恰好识别出了处理组的平均处理效应 ATT。

DiD 估计量可以写成更直观的形式：

$$\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) = (\bar{Y}_{11} - \bar{Y}_{01}) - (\bar{Y}_{10} - \bar{Y}_{00}).$$

核心公式（式 section 2.2）：

$$\hat{\tau}_{\text{DiD}} = \underbrace{(\bar{Y}_{11} - \bar{Y}_{01})}_{\text{处理组的时间变化}} - \underbrace{(\bar{Y}_{10} - \bar{Y}_{00})}_{\text{对照组的时间变化}}.$$

第一项是处理组政策前后的结果均值之差；第二项是对照组政策前后的结果均值之差。两项相减，即消除了时间趋势。

3. 平行趋势假设

DiD 方法的核心假设是**平行趋势假设**（Parallel Trends Assumption）：

假设 26.1（平行趋势假设）. 在没有处理的情况下，处理组和对照组的结果随时间变化的趋势相同，即

$$\mathbb{E}(Y_{i1}(0) - Y_{i0}(0) \mid G_i = 1) = \mathbb{E}(Y_{i1}(0) - Y_{i0}(0) \mid G_i = 0).$$

Equivalently,

$$\bar{Y}_{10}(0) - \bar{Y}_{11}(0) = \bar{Y}_{00} - \bar{Y}_{01}.$$

这个假设的含义是：**若两组都未受处理，它们结果的时间变化模式应完全相同**^{**}。换言之，处理组和对照组之间的差异仅仅是组间固定效应，而不存在特异性的时间趋势。

3.1. 为何称为“平行”趋势. 图示可以帮助理解这一假设。假设横轴为时间，纵轴为结果。在平行趋势假设下，处理组和对照组的结果轨迹在政策实施前是两条斜率相同的平行直线；政策实施后，处理组的轨迹发生跳跃，而对照组继续沿原趋势发展。DiD 正是利用政策实施前后的信息，估计这个“跳跃”的大小。

在数学上，若假设结果对数形式为线性趋势：

$$Y_{it}(0) = \alpha + \beta \cdot G_i + \gamma \cdot t + \varepsilon_{it},$$

则处理组和对照组的时间趋势相同（均为 γ ），平行趋势假设自动成立。

3.2. 无法被数据验证的假设. 重要警示：平行趋势假设是无法从数据中直接验证的——因为我们永远无法同时观测到处理组的“反事实”（若未受处理会怎样）。这使得 DiD 本质上是一个**半参数识别**问题：识别依赖于研究者对趋势函数形式的额外假设。

实践中，研究者通常会：

- (1) 检验政策实施前的处理组和对照组趋势是否平行（“0300pre-trend test”）；
- (2) 展示多个政策实施前的时期，确认趋势的稳定性；
- (3) 使用安慰剂检验（placebo test），将政策实施时间人为提前，看是否仍能识别出效应。

这些检验并非平行趋势假设的证明，而只是提供间接证据。

4. 回归框架与标准误差

DiD 估计量可以通过回归方法方便地实现。考虑以下双向固定效应（Two-Way Fixed Effects, TWFE）模型：

$$Y_{it} = \alpha + \beta \cdot D_{it} + \gamma_i + \delta_t + \varepsilon_{it},$$

其中：

- $D_{it} = G_i \cdot T_t$ 为处理指示变量（组别 $\times$ 时间的交互项）
- γ_i 为个体固定效应（控制组间差异）
- δ_t 为时间固定效应（控制共同的时间趋势）

在这个模型中， β 就是 DiD 估计量，它等于处理组的时间变化减去对照组的时间变化，即式 section 2.2 中的 $\hat{\tau}_{\text{DiD}}$ 。

关于标准误差。在面板数据回归中，标准误差的估计需要考虑以下问题：

- **聚类标准误差 (Clustered Standard Errors)**：同一单元的观测值可能存在自相关，建议按单元聚类
- **Driscoll-Kraay 标准误差**：当时间维度较大且存在潜在的面板相关结构时
- **Bootstrap**：在小样本情况下，参数自举法可能更可靠

5. 拓展：异质性处理效应

5.1. 交互形式.标准的 TWFE 回归 section 4 假设处理效应在所有单元和时间上都是恒定的（ β 不随 i 或 t 变化）。然而，在实际研究中，处理效应很可能随单元特征或时间而变化。

考虑**异质性处理效应**的情形。记处理效应为 $\tau_{it} = \mathbb{E}(Y_{it}(1) - Y_{it}(0))$ ，它可能依赖于单元 i 或时间 t 。

Angrist and Pischke [?] 指出，当处理效应存在异质性时，标准的 TWFE 估计量识别的是一种 ** 处理效应分布的加权均值 **，而非简单的 ATT。这一加权结构可能产生难以解释的估计量，甚至在外推含义上产生偏误。

警告（异质性处理效应下 TWFE 的陷阱）：当不同单元的处理效应不同时，TWFE 回归中的 β 不再简单等于 ATT。它可能混合了处理组和未处理组中不同处理效应分布的特征，导致估计量难以解释。详见 ? 的讨论。

5.2. 多期 DiD. 当有多个时间点时，DiD 可以推广到 ** 多期情形 **。设 $T_t \in \{0, 1, \dots, T\}$ ，则处理指示变量 $D_{it} = G_i \cdot \mathbb{I}(t \geq t^*)$ ，其中 t^* 为政策实施时间。

多期 DiD 的 TWFE 回归为：

$$Y_{it} = \alpha_i + \delta_t + \sum_{t=0}^T \beta_t \cdot D_{it} + \varepsilon_{it},$$

其中 β_t 捕捉了政策实施后各时期的处理效应（通常以政策实施前一期为基准期，令其效应为零）。

事件研究图（Event Study Plot） 是展示多期 DiD 结果的标准方法——将 β_t 对时间作图，政策实施前的系数应接近零（提供平行趋势的间接证据），政策实施后的系数应反映处理效应的大小和动态变化。

6. 本章小结

双重差分（DiD）是政策评估领域最常用的因果推断方法之一。其核心思想利用面板数据的结构，通过两次差分消除时间趋势的影响，从而识别处理组的平均因果效应。

DiD 的成功依赖于**平行趋势假设**——在没有处理的情况下，处理组和对照组的结果趋势应相同。这一假设本质上无法从数据中直接验证，只能通过间接检验（如 pre-trend 检验、安慰剂检验）提供支持证据。

DiD 方法已从最初的 2×2 情形发展到成熟的多期、双向固定效应框架。然而，当处理效应存在异质性时，标准的 TWFE 估计可能产生难以解释的加权平均效应，这是近年来方法论研究的重要关注点。

7. 延伸阅读

关于 DiD 的经典参考文献包括：

- ?：《Mostly Harmless Econometrics》，第 5 章系统介绍了 DiD 的理念和实践
- ?：DiD 方法的早期经典应用，研究最低工资对就业的影响
- ?：关于异质性处理效应下 TWFE 估计量的最新讨论
- ?：提出诊断和处理 TWFE 中异质性处理效应的方法

附录 section 12 包含 DiD 估计量的详细推导和 Bootstrap 标准误差的计算步骤。

中介分析：自然直接效应与自然间接效应

1. 本章导论：一个古老的追问

当我们说“吸烟导致肺癌”时，这个说法究竟意味着什么？

一方面，烟草中的有害物质可能直接作用于细胞，引发癌变；另一方面，吸烟可能通过影响其他生理指标——比如血压、免疫力或慢性炎症——进而间接地增加患癌风险。这两种机制，本质上完全不同：一种是直接杀伤，另一种是通过一连串中间步骤传导的**间接效应**。

理解因果效应的这种**传导机制** (transmission mechanism)，是科学研究的核心关切之一。生物医学研究者想知道某种药物是通过什么生化通路发挥作用的；社会学家想知道贫困是通过什么社会机制影响健康结果的；政策制定者想知道一项教育改革是直接改善了学生能力，还是通过改变学校资源配置间接起效。**中介分析** (mediation analysis) 正是回答这类问题的统计框架。

本章的组织如下。我们首先通过具体实例说明中介分析的应用场景；然后引入**嵌套潜在结果** (nested potential outcomes) 的数学框架；接着建立识别中介效应的**中介公式** (mediation formula)；最后在线性模型下推导出经典的 **Baron-Kenny 公式**，并讨论其敏感性分析。

2. 从总效应到直接效应与间接效应

在中介分析的框架中，我们有四个核心变量：处理 Z (treatment)、结果 Y (outcome)、中介 M (mediator) 以及背景协变量 X (covariates)。它们之间的因果关系可以直观地用有向无环图 (DAG) 表示 (??)。

核心问题：总的因果效应 τ 中，有多少是通过中介变量 M 传导的 (**间接效应**)，有多少是不经过 M 的 (**直接效应**)？

以下三个真实研究场景可以帮助我们理解中介分析的应用。

例 27.1 (遗传变异与肺癌：通过吸烟的中介). (2012) 研究了染色体 15q25.1 上的遗传变异如何影响肺癌风险。¹ 该研究的核心问题是：遗传变异是通过影响吸烟行为 (吸烟量) 进而增加肺癌风险的，还是通过其他独立通路 (如直接影响肺部细胞) 直接致癌的？这就是一个典型的中介分析问题：遗传变异是处理 Z ，吸烟是中介 M ，肺癌是结果 Y 。

例 27.2 (邻里贫困与青少年物质使用：学校与同伴环境的中介). 等人 (2018) 研究了邻里贫困对青少年物质使用的影响，并探讨了这一影响是通过学校和同伴环境传导的。² 他们使用了美国国家共病调查 (National Comorbidity Survey) 的数据，将邻里贫困指数作为处理，青少年物质使用 (如饮酒、吸毒) 作为结果，而学校和同伴环境因素作为中介。

¹详见 ?。

²详见 ?。

例 27.3 (就业培训对心理健康：工作搜寻效能的中介). *JOBS II* 是一个关于就业培训对失业工人影响的现场实验。³ 该培训项目的目的不仅是提高再就业率，还希望改善求职者的心理健康。研究者感兴趣的是：培训对心理健康的效应中，有多少是通过提高工作搜寻效能这一中介传导的，又有多少是通过其他途径（如社会支持网络）直接产生的。⁴

3. 嵌套潜在结果

3.1. 潜在结果的两层结构. 为了定义直接效应与间接效应，我们需要引入**嵌套潜在结果** (nested potential outcomes) 这一概念。[?] 和 [?] 是这一理论的奠基人。

首先，考虑对处理 z 进行干预，定义对应的潜在中介和潜在结果：

$$\{M(z), Y(z) : z = 0, 1\}.$$

然后，考虑同时对 z 和 m 进行干预，定义：

$$\{Y(z, m) : z = 0, 1, m \in \mathcal{M}\},$$

其中 $\mathcal{M}$ 是中介所有可能的取值范围。

关键的一步是考虑**嵌套干预** (nested intervention)：将 z 设定为某个值，但将 m 设定为在另一个处理水平下的潜在中介值。记 $M_{z'} \equiv M(z')$ ，[?] 和 [?] 定义了嵌套潜在结果：

$$\{Y(z, M_{z'}) : z = 0, 1, z' = 0, 1\}.$$

其中 $Y(z, M_{z'})$ 表示：如果治疗被设定为 z ，而中介被设定为在治疗 z' 下的潜在值 $M_{z'}$ ，则结果会是什么。注意 z 和 z' 可以不同——这正是其“嵌套”之处。

在二值处理的设定下，我们有四个嵌套潜在结果：

$$\{Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)\}.$$

其中 $Y(1, M_1)$ 表示：如果治疗设为 $z = 1$ 且中介设为在 $z = 1$ 下的自然值，则结果如何。类似地， $Y(0, M_0)$ 表示治疗设为 $z = 0$ 且中介设为在 $z = 0$ 下的自然值的情形。

Composition 假设确保了嵌套潜在结果与标准潜在结果之间的一致性。

[Composition 假设] $Y(z, M_z) = Y(z)$ ，对 $z = 0, 1$ 成立。

Composition 假设是不可证明的，它本质上是一个假设。但在实践中，我们完全可以将 $Y(1)$ 定义为 $Y(1, M_1)$ ，将 $Y(0)$ 定义为 $Y(0, M_0)$ ，这样该假设就自动成立了。

现在，我们可以正式定义三种效应。

定义 27.1 (总效应、自然直接效应与自然间接效应). 总效应 (*total effect*) 定义为

$$\tau = \mathbb{E}\{Y(1) - Y(0)\}.$$

自然直接效应 (*natural direct effect, NDE*) 定义为

$$= \mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}.$$

自然间接效应 (*natural indirect effect, NIE*) 定义为

$$= \mathbb{E}\{Y(1, M_1) - Y(1, M_0)\}.$$

这三个效应的含义如下：

- **总效应** τ ：标准的平均因果效应，即治疗从 0 变到 1 对结果的平均影响。
- **NDE** $\mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}$ ：如果将治疗从 0 变到 1，但把中介固定在无治疗时的自然水平 M_0 ，结果的平均变化。这个效应衡量的是**不经过 M 的直接通路**的贡献。

³我们在 ?? 章中曾使用过这个数据集。

⁴我们将在 section 6 节中回到这个例子，展示 Baron-Kenny 方法的具体应用。

- **NIE** $\mathbb{E}\{Y(1, M_1) - Y(1, M_0)\}$: 如果保持治疗 $z = 1$ 不变, 但把中介从无治疗时的自然水平 M_0 变到治疗时的自然水平 M_1 , 结果的平均变化。这个效应衡量的是**通过中介 M 传导**的间接贡献。

在 Composition 假设下, 总效应可以分解为自然直接效应与自然间接效应之和。

命题 27.2 (效应的分解). 在定义 27.1 和 section 3.1 下, 有

$$\tau = +.$$

为什么 NIE 可以衡量间接效应? 直观上, $Y(1, M_1) - Y(1, M_0)$ 表示: 将治疗固定在 $z = 1$, 但让中介从“如果没有治疗它会是什么”变为“如果有治疗它会是什么”, 结果会如何变化。这恰恰描述了“治疗通过改变中介进而影响结果”这条通路上的效应。

然而, $Y(1, M_0)$ 这个量本身有一个深刻的概念困难: 它是一个**跨世界 counterfactual** (cross-world counterfactual)。 $z = 1$ 和 $m = M_0$ 这两个干预不可能在同一个实验中同时发生——同一个单元不可能既接受治疗 $z = 1$, 又同时处于无治疗条件下的中介水平。要理解 $Y(1, M_0)$, 我们必须借助平行世界的想象 (fig. 2)。

[width = 0.7]figures/crossworld.pdf

FIGURE 2. 跨世界 counterfactual $Y(1, M_0)$ 和 $Y(0, M_1)$ 的示意图。同一单元在两个平行世界中分别接受不同的治疗, 从而获得不同的中介值。

这种跨世界的性质引发了一个哲学上的争议。⁵ 将 $Y(1, M_0)$ 和 $Y(0, M_1)$ 称为**先验 counterfactual** (a priori counterfactuals), 因为我们无法在任何物理实验中观察到它们。按照 ⁵ 的可证伪性标准, 如果一个陈述无法被任何物理实验或观测所证伪, 那它就不是科学的, 而是形而上学的。因此, 严格的 Popperian 统计学家可能会认为中介分析是形而上学。⁵

不过, ⁵ 对整个潜在结果框架都提出了类似的批评。但他的批评是过度的: 即使我们无法同时观察到 $Y(1)$ 和 $Y(0)$, 我们仍然可以通过边缘分布的信息对它们做出可证伪的陈述。 $Y(1, M_0)$ 的困难在于它是真正无法在任何实验中触及的——这与 $\{Y(1), Y(0)\}$ 的性质根本不同。

4. 中介公式

4.1. 四个关键假设. 中介公式的识别依赖于四个假设。前三个假设本质上是在说: 治疗 and 中介在给定协变量 X 的条件下都是被随机化的。

[无治疗—结果混淆] 给定 X , 治疗与潜在结果独立:

$$Z \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

[无中介—结果混淆] 给定 (X, Z) , 中介与潜在结果独立:

$$M \perp\!\!\!\perp Y(z, m) \mid (X, Z), \quad \forall z, m.$$

[无治疗—中介混淆] 给定 X , 治疗与潜在中介独立:

$$Z \perp\!\!\!\perp M(z) \mid X, \quad \forall z.$$

⁵这一争议的详细讨论见 ⁵ 和 ⁶。

这三个假设共同构成了**序列可忽略性** (sequential ignorability)：在给定 X 的条件下，治疗分配是可忽略的；进一步在给定 (X, Z) 的条件下，中介分配也是可忽略的。序列可忽略性等价于在给定 X 的条件下 (Z, M) 是联合随机化的：

$$(136) \quad (Z, M) \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

eq. (136) 与 section 4.1 的等价性留作练习。⁶

最后一个假设是跨世界独立性。

[跨世界独立性] 给定 X ，潜在结果与潜在中介独立：

$$Y(z, m) \perp\!\!\!\perp M(z') \mid X, \quad \forall z, z', m.$$

前三个假设至少在随机化实验中是可以保证的，但 section 4.1 更为强——没有任何物理实验可以确保它，因为当 $z \neq z'$ 时，我们永远无法同时观察到 $Y(z, m)$ 和 $M(z')$ 。这正是 $Y(1, M_0)$ 等 cross-world counterfactual 的根本困难所在。

例 27.4 (验证假设的数据生成过程). 给定 X ，我们按如下方式生成数据：

$$\begin{aligned} Z &= 1\{g_Z(X, \varepsilon_Z) \geq 0\}, \\ M(z) &= 1\{g_M(X, z, \varepsilon_M) \geq 0\}, \quad z = 0, 1, \\ Y(z, m) &= g_Y(X, z, m, \varepsilon_Y), \quad z, m = 0, 1, \end{aligned}$$

其中 $\varepsilon_Z, \varepsilon_M, \varepsilon_Y$ 相互独立。⁷ 可以验证，在上述数据生成过程下，section 4.1 均成立。如果允许 ε_M 和 ε_Y 依赖于处理水平（即改为 $\varepsilon_M(z)$ 和 $\varepsilon_Y(z, m)$ ），则这些假设可能被违反。

4.2. 识别公式. ? 证明了以下关键结果。

定理 27.3 (中介公式). 在 section 4.1 下，有

$$\mathbb{E}\{Y(z, M_{z'}) \mid X = x\} = \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x) \Pr(M = m \mid Z = z', X = x).$$

定理的含义： 我们无法直接观察跨世界 counterfactual $Y(z, M_{z'})$ ，但 section 4.1 这四个假设足够将这个不可观测的量表达为可观测条件分布的函数。具体来说， $Y(z, M_{z'})$ 的期望等于：结果的条件期望（给定 $Z = z, M = m, X = x$ ）对中介的分布（给定 $Z = z', X = x$ ）的加权和。

为什么四个假设缺一不可？ 定理的证明（见附录 ??）清楚地展示了这四个假设各自的角色：section 4.1 保证了 $\Pr(M = m \mid Z = z', X = x) = \Pr(M_{z'} = m \mid X = x)$ ，section 4.1 允许我们交换 $Y(z, m)$ 与 $M_{z'}$ 的条件，section 4.1 则保证了结果的识别。

对 X 求期望，得到无条件版本：

$$\mathbb{E}\{Y(z, M_{z'})\} = \sum_x \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x) \Pr(M = m \mid Z = z', X = x) \Pr(X = x).$$

对于连续型 M 和 X ，求和替换为积分。

由 定义 27.2 和 定义 27.3，我们可以得到 NDE 和 NIE 的识别公式。

⁶详见 练习 27.2 题。

⁷详见 ?。

推论 27.4 (NDE 和 NIE 的识别). 在 *section 4.1* 下, 条件 NDE 和 NIE 由下式识别:

(137)

$$(x) = \sum_m [\mathbb{E}(Y | Z = 1, M = m, X = x) - \mathbb{E}(Y | Z = 0, M = m, X = x)] \Pr(M = m | Z = 0, X = x),$$

(138)

$$(x) = \sum_m \mathbb{E}(Y | Z = 1, M = m, X = x) [\Pr(M = m | Z = 1, X = x) - \Pr(M = m | Z = 0, X = x)].$$

理解 eq. (137) 的直觉: (x) 衡量的是将处理从 0 变到 1 (但保持中介在无处理时的自然分布) 的效应。在每个中介值 m 下, 处理从 0 变到 1 的条件效应是 $\mathbb{E}(Y | Z = 1, M = m, X = x) - \mathbb{E}(Y | Z = 0, M = m, X = x)$; 由于中介被固定在 $Z = 0$ 条件下的分布, 这些条件效应需要按 $\Pr(M = m | Z = 0, X = x)$ 加权求和。

对于二值中介 $M \in \{0, 1\}$, 定义 27.4 中的 NIE 公式可以化简为一种优美的乘积形式。

推论 27.5 (二值中介的 NIE 乘积公式). 在 *section 4.1* 下, 对二值中介 M , 有

$$(x) = \tau_{Z \rightarrow M}(x) \cdot \tau_{M \rightarrow Y}(1, x),$$

其中

$$\tau_{Z \rightarrow M}(x) = \Pr(M = 1 | Z = 1, X = x) - \Pr(M = 1 | Z = 0, X = x)$$

是 Z 对 M 的条件平均因果效应,

$$\tau_{M \rightarrow Y}(z, x) = \mathbb{E}(Y | Z = z, M = 1, X = x) - \mathbb{E}(Y | Z = z, M = 0, X = x)$$

是 M 对 Y 的条件平均因果效应。

为什么叫乘积公式? 直观上, 间接效应是这样传导的: 首先, 处理 Z 变化导致中介 M 变化 (效应 $\tau_{Z \rightarrow M}$); 然后, 中介 M 变化导致结果 Y 变化 (效应 $\tau_{M \rightarrow Y}$)。这两段效应的乘积, 就是总间接效应。这与我们的直觉完全一致。

定义 27.5 的证明留作练习。⁸

5. 线性模型下的 Baron-Kenny 方法

定义 27.3 给出了非参数识别公式, 它允许我们在各种不同模型下推导出中介效应的具体形式。本节介绍经典而又广泛使用的 **Baron-Kenny 方法** (?), 该方法假设线性模型。

5.1. 模型设定. Baron-Kenny 方法假设中介和结果都满足线性模型 (??)。

[Baron-Kenny 线性模型] 中介和结果的条件期望满足线性模型:

$$(27.1) \quad \begin{cases} \mathbb{E}(M | Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y | Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

在上述线性模型下, NDE 和 NIE 可以简化为系数的简洁函数。

推论 27.6 (Baron-Kenny 公式). 在 *sections 4.1 and 5.1* 下, 有

$$(27.2) \quad \quad \quad = \theta_1, \quad \quad = \theta_2 \beta_1.$$

⁸详见 练习 27.5 题。

与 DAG 的对应：在 ?? 中， θ_1 是路径 $Z \rightarrow Y$ 的系数（直接效应）， $\beta_1\theta_2$ 是路径 $Z \rightarrow M \rightarrow Y$ 的系数之积（间接效应）。这与 定义 27.6 完全一致。

为何不需要对 X 求和？注意在 eq. (137) 和 eq. (138) 中， (x) 和 (x) 是在给定 $X = x$ 的条件下的值。而在 Baron–Kenny 线性模型下， θ_1 和 $\theta_2\beta_1$ 与 x 无关，因此条件效应等于无条件效应。

Baron–Kenny 公式的推导见附录 ??。

如果获得了系数的 OLS 估计量 $\hat{\beta}_1$ 和 $\hat{\theta}_2$ ，则 NDE 和 NIE 的估计量为

$$\hat{\tau} = \hat{\theta}_1, \quad \hat{\tau} = \hat{\theta}_2\hat{\beta}_1,$$

这就是经典的 Baron–Kenny 估计。? 和 ? 利用 delta 方法给出了 $\hat{\tau}$ 的标准误：

$$\text{var}(\hat{\tau}) = \text{var}(\hat{\theta}_2)\hat{\beta}_1^2 + \hat{\theta}_2^2\text{var}(\hat{\beta}_1).$$

基于此的假设检验称为 Sobel’s test。⁹

Baron–Kenny 方法的历史：虽然 ? 使这一方法广为人知，但它实际上有更早的渊源，包括 ?、? 和 ? 的工作。? 进一步发展了推断方法。

6. 应用实例：JOBS II 数据

我们通过 R 代码实现 Baron–Kenny 方法，并将其应用于 JOBS II 数据集。¹⁰

例 27.5 (JOBS II: 就业培训对心理健康的中介分析). 我们关注就业培训（处理 Z ）对心理健康（结果 Y ，用抑郁量表得分度量）的影响，以及这一影响是否通过工作搜寻效能（中介 M ）传导。背景协变量 X 包括经济困难程度、基线抑郁得分、性别、年龄、职业、婚姻状态、种族、教育程度和家庭收入。

通过以下 R 代码实现 Baron–Kenny 方法：

```
library("car")
BKmediation = function(Z, M, Y, X) {
  mediator.reg = lm(M ~ Z + X)
  mediator.Zcoef = mediator.reg$coef[2]
  mediator.Zse = sqrt(hccm(mediator.reg)[2, 2])

  outcome.reg = lm(Y ~ Z + M + X)
  outcome.Zcoef = outcome.reg$coef[2]
  outcome.Zse = sqrt(hccm(outcome.reg)[2, 2])
  outcome.Mcoef = outcome.reg$coef[3]
  outcome.Mse = sqrt(hccm(outcome.reg)[3, 3])

  NDE = outcome.Zcoef
  NIE = outcome.Mcoef * mediator.Zcoef

  NDE.se = outcome.Zse
  NIE.se = sqrt(outcome.Mse^2 * mediator.Zcoef^2 +
                outcome.Mcoef^2 * mediator.Zse^2)
```

⁹关于 Sobel 检验的更多讨论见 ?。

¹⁰JOBS II 是一个关于就业培训对失业工人影响的随机化现场实验。数据集在 R 的 `mediation` 包中。

```

res = matrix(c(NDE, NIE, NDE.se, NIE.se,
               NDE/NDE.se, NIE/NIE.se), 2, 3)
rownames(res) = c("NDE", "NIE")
colnames(res) = c("est", "se", "t")
res
}

```

运行结果如下：

```

> res = BKmediation(Z, M, Y, X)
> round(res, 3)
      est      se      t
NDE -0.037  0.042 -0.885
NIE -0.014  0.009 -1.528

```

估计的直接效应 $\hat{c} = -0.037$ （培训对心理健康的直接保护效应）和间接效应 $\hat{c}' = -0.014$ （通过提高工作搜寻效能而改善心理健康）均为负，但统计上均不显著。这表明 *JOBS II* 培训项目对心理健康的效应尚无充分证据支持按中介路径分解。

一个值得注意的现象：在某些设定下，间接效应可能出现违反直觉的符号。例如，如果 $Z \rightarrow M$ 的效应 $\beta_1 > 0$ ， $M \rightarrow Y$ 的效应 $\theta_2 > 0$ ，但 Z 与 M 之间存在负交互项 $\theta_3 < 0$ ，则乘积 $\beta_1(\theta_2 + \theta_3)$ 可能为负。这被称为**中介悖论**（mediator paradox）或**替代终点悖论**（surrogate endpoint paradox）。^a

^a详见？。

7. 敏感性分析

中介分析依赖于强且不可检验的假设。关键的不可检验假设是跨世界独立性（section 4.1）：我们无法通过任何实验数据验证 $Y(z, m)$ 与 $M(z')$ 在 $z \neq z'$ 时是否独立。

因此，研究者常常需要进行**敏感性分析**（sensitivity analysis），以探索当关键假设不成立时，结论会如何变化。主要文献包括：

- ? 提出了类似 Cornfield 的敏感性界；
- ? 提出了针对 Baron–Kenny 线性模型量身定制的敏感性分析方法。

敏感性分析的具体方法超出了本章的范围，但读者应记住：中介分析的结果必须谨慎解读，因为其核心假设无法被数据验证。

8. 本章小结

本章围绕中介分析展开，主要内容如下：

- (1) **核心问题：**因果效应如何在直接通路和间接通路之间分配？
- (2) **嵌套潜在结果 $Y(z, M_{z'})$ ：**描述跨世界 counterfactual，是定义 NDE 和 NIE 的基础。
- (3) **效应分解：**在 Composition 假设下，总效应 $\tau = +$ 。
- (4) **识别假设：**四个假设（序列可忽略性 + 跨世界独立性）下，中介公式成立。
- (5) **中介公式：**将不可观测的 NDE 和 NIE 表达为可观测条件分布的函数。
- (6) **Baron–Kenny 公式：**在 section 5.1 下， $c' = \theta_1$ ， $c = \theta_2\beta_1$ 。
- (7) **跨世界 counterfactual 的哲学争议：**严格的 Popperian 认识论者认为中介分析是形而上学的。

(8) **敏感性分析**：由于核心假设不可检验，敏感性分析是必要的。

中介公式的完整证明见附录 ??；Baron-Kenny 公式的推导见附录 ??；各节练习题见附录 section 8。

练习

练习 27.1. 假设 (Z, M, Y) 均为二值变量。基于潜在结果

$$M(1), M(0), Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)$$

的联合取值，单元可以分成多少类型？

若进一步假设单调性 $M(1) \geq M(0)$ (Z 对 M 的单调性)，则单元可以分成多少类型？

若再假设 $Y(1, m) \geq Y(0, m)$ 且 $Y(z, 1) \geq Y(z, 0)$ 对所有 z, m 成立 (Z 和 M 对 Y 的单调性)，则单元可以分成多少类型？

本题答案见附录 section 1.22。

练习 27.2. 证明 eq. (136) 与 section 4.1 等价。

本题答案见附录 section 1.22。

练习 27.3. ? 提出了另一组假设来推导中介公式：

$$\{Y(z, m), M(z')\} \perp\!\!\!\perp Z \mid X, \quad Y(z, m) \perp\!\!\!\perp M(z') \mid (Z = z', X),$$

对所有 z, z', m 成立。

证明：在上述假设下，定义 27.3 中的中介公式同样成立。

本题答案见附录 section 1.22。

练习 27.4. 在 Baron-Kenny 线性模型 (section 5.1) 下，首先拟合：

$$\hat{M} = \hat{\beta}_0 + \hat{\beta}_1 Z + \hat{\beta}_2^\top X, \quad \hat{Y} = \hat{\theta}_0 + \hat{\theta}_1 Z + \hat{\theta}_2 M + \hat{\theta}_4^\top X.$$

则 NIE 的估计量为乘积 $\hat{\theta}_2 \hat{\beta}_1$ (乘积法)。

另一方面，首先拟合：

$$\hat{Y} = \hat{\alpha}_0 + \hat{\alpha}_1 Z + \hat{\alpha}_1^\top X,$$

再拟合：

$$\hat{Y} = \tilde{\theta}_0 + \tilde{\theta}_1 Z + \tilde{\theta}_2 M + \tilde{\theta}_4^\top X,$$

则 NIE 的另一估计量为差值 $\hat{\alpha}_1 - \tilde{\theta}_1$ (差值法)。

证明： $\hat{\alpha}_1 - \tilde{\theta}_1 = \hat{\theta}_2 \hat{\beta}_1$ 。

本题答案见附录 section 1.22。

练习 27.5. 证明 定义 27.5 (二值中介的 NIE 乘积公式)。

本题答案见附录 section 1.22。

练习 27.6. ? 建议在结果模型中加入处理与中介的交互项：

$$\begin{cases} \mathbb{E}(M \mid Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_3 ZM + \theta_4^\top X. \end{cases}$$

证明：在此模型下，

$$= \theta_1 + \theta_3 \{\beta_0 + \beta_2^\top \mathbb{E}(X)\}, \quad = (\theta_2 + \theta_3) \beta_1.$$

并说明如何在 IID 数据下估计 和 。

本题答案见附录 section 1.22。

练习 27.7. 考虑中介 M 服从正态线性模型、结果 Y 服从 *logistic* 模型：

$$\begin{cases} M | Z, X \sim \mathcal{N}(\beta_0 + \beta_1 Z + \beta_2^\top X, \sigma_M^2), \\ \text{logit}\{\Pr(Y = 1 | Z, M, X)\} = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

请将 β 和 θ 表示为模型参数和 X 分布的函数，并说明如何在 *IID* 数据下估计它们。

本题答案见附录 section 1.22。

练习 27.8. 考虑二值中介 M 服从 *logistic* 模型、结果 Y 服从线性模型：

$$\begin{cases} \text{logit}\{\Pr(M = 1 | Z, X)\} = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y | Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

证明：

$$\theta_1 = \beta_1, \quad \theta_2 = \mathbb{E}\{\text{expit}(\beta_0 + \beta_1 + \beta_2^\top X) - \text{expit}(\beta_0 + \beta_2^\top X)\}.$$

并说明如何在 *IID* 数据下估计 β 和 θ 。

本题答案见附录 section 1.22。

练习 27.9. 将嵌套潜在结果修改为

$$Y(z, F_{M_{z'}|X}) = \int Y(z, m) f(M_{z'} = m | X) dm,$$

其中 $F_{M_{z'}|X}$ 是条件分布而非确定值。相应地将 *NDE* 和 *NIE* 定义为

$$= \mathbb{E}\{Y(1, F_{M_0|X}) - Y(0, F_{M_0|X})\}, \quad = \mathbb{E}\{Y(1, F_{M_1|X}) - Y(1, F_{M_0|X})\}.$$

证明：在仅假设 section 4.1（不要求跨世界独立性）下， θ 和 β 的识别公式与正文相同。

本题答案见附录 section 1.22。

练习 27.10. ? 和 ? 综述并比较了主分层与中介分析两种方法。请查阅这些文献，并撰写一页总结，阐述两种方法的异同与各自的优缺点。

本题为开放性研究型练习，请参考 ? 和 ?。

因果发现

1. 引言：一个雄心勃勃的问题

在前面的章节中，我们假设因果结构已知——即已知哪些变量是原因、哪些变量是结果。然而在现实中，我们往往面对一个更为艰难的问题：**能否从数据中学习出变量之间的因果关系？**

这个问题的重要性不言而喻。科学发现的本质就是从观察数据中推断因果结构。历史上，James Lind 通过对照实验发现柑橘类水果可以治疗坏血病；但在许多情况下，实验干预是不可行或不道德的。我们能否仅从被动观察的数据中，发现变量之间的因果关系？

这个问题在哲学上曾被认为是不可可能的。“相关不蕴含因果”——这句格言道出了统计学的传统智慧。然而，过去三十年见证了一场静默的革命：在一系列精心设计的假设下，因果结构可以从纯粹的观察数据中学习。

这场革命的先驱包括 Judea Pearl，他发展了基于图的因果推理理论；以及 Peter Spirtes、Clark Glymour 和 Richard Scheines，他们构建了 PC 等算法从数据中提取因果结构。本章将介绍这一领域的基本思想和方法。

2. 因果马尔可夫条件与忠诚性

在讨论具体算法之前，我们需要理解因果发现的可能性条件。考虑一个包含变量 $X_1, X_2, \dots, X_p$ 的系统。如果这些变量之间存在因果关系，我们通常用有向无环图 (DAG) 来表示：每个节点代表一个变量，箭头 $X \rightarrow Y$ 表示 X 是 Y 的直接原因（或之一）。

一个根本性的观察是：在许多合理的因果模型下，变量之间的条件独立性蕴含着因果结构的信息。

[因果马尔可夫条件] 给定一个变量的所有直接原因，该变量独立于所有非其后代的变量。

直观上，如果 X 导致 Y ，而 Y 又导致 Z ，那么在已知 Y 的情况下， X 和 Z 之间不应该有直接的联系——它们之间的任何关联都已经被 Y 解释了。

[忠诚性条件] 图中存在的条件独立性关系，恰好对应于数据分布中存在的条件独立性关系。

忠诚性条件防止了“巧合独立性”——即两个变量在数据中条件独立，但在图中却通过一条路径相连。这种巧合在参数化模型中是零测度的。

在这两个假设下，我们可以从变量的条件独立性结构中读取因果信息。

3. PC 算法：从条件独立性到因果骨架

PC 算法 (Spirtes et al., 2000) 是因果发现领域最经典的算法之一。它的核心思想简洁而有力：**从条件独立性出发，逐步确定因果结构。**

3.1. 第一步：发现骨架。 算法从一个完全无向的图出发，通过条件独立性检验逐步删除边。

对于每一对变量 X 和 Y ，以及越来越大的条件集 S （最初为空，然后是单变量，然后是双变量，以此类推），我们检验条件独立性：

$$(139) \quad X \perp\!\!\!\perp Y \mid S$$

其中 $\perp\!\!\!\perp$ 表示条件独立性。如果拒绝独立性，则保留边 (X, Y) ；否则，删除这条边。

在标准的高斯或离散数据设置下，我们可以使用偏相关系数或条件互信息来进行这个检验。

例 28.1 (简单的条件独立性). 考虑三个变量 X, Y, Z 。假设我们进行条件独立性检验：

- $X \not\perp\!\!\!\perp Y$ (边缘不独立)
- $X \perp\!\!\!\perp Y \mid Z$ (给定 Z 条件独立)

这告诉我们什么？在 *Markov* 条件下，这暗示 Z 是 X 和 Y 的共同原因，或者 Z 位于它们之间的中介路径上。

这个过程不断迭代，直到所有边都经过了适当的条件独立性检验。最终得到的图称为**因果骨架**——它保留了所有在某种条件下不条件独立的变量对之间的连接。

3.2. 第二步：定向边. 骨架是无向的，但我们需要定向边来揭示因果方向。这需要利用 v -结构（碰撞结构）的概念。

考虑三个变量 X, Y, Z ，它们之间的骨架显示 $X - Z - Y$ （即 X 与 Y 之间无边，但都与 Z 相连）。如果进一步发现 $X \perp\!\!\!\perp Y \mid \emptyset$ 且 $X \perp\!\!\!\perp Y \mid Z$ ，这符合什么结构？

在 *Markov* 条件下，如果 $X \rightarrow Z \rightarrow Y$ (Z 是中介)，那么给定 Z ， X 和 Y 应该条件独立。这与观察到的 $X \perp\!\!\!\perp Y \mid Z$ 一致。

但如果有 Z 是 X 和 Y 的共同原因，即 $Z \rightarrow X$ 且 $Z \rightarrow Y$ ，那么 X 和 Y 在边缘上不独立，但给定 Z 时条件独立——这正是我们观察到的！

PC 算法通过识别这类模式来确定边的方向。形式化地说：

[v -结构] 一个三元组 (X, Z, Y) 形成 v -结构，当且仅当：

- (1) X 与 Y 在骨架中无边；
- (2) Z 与 X 、 Z 与 Y 都有边相连；
- (3) 在给定 Z 的条件下， X 和 Y 不条件独立。

在忠诚性条件下， v -结构必然对应一个碰撞结构： $X \rightarrow Z \leftarrow Y$ 。这是因为其他结构 ($X \rightarrow Z \rightarrow Y$ 或 $X \leftarrow Z \rightarrow Y$) 都会在给定 Z 时使 X 和 Y 条件独立。

PC 算法的定向规则可以总结为：

- (1) 识别所有 v -结构，将其中心节点的两个父节点方向设为指向该节点；
- (2) 应用马尔可夫性和忠诚性所隐含的其他定向规则（如避免产生新的 v -结构）。

3.3. 第三步：边定向的最终确定. 上述步骤可能无法定向所有边。这是因为某些边在观察分布下本来就是不可分辨的——不同的有向图可能产生完全相同的条件独立性结构。这些图构成一个**等价类**。

例如，考虑两条边 $X - Y$ 和 $Y - Z$ ，且 X 与 Z 之间无边。 $X \rightarrow Y \rightarrow Z$ 和 $X \leftarrow Y \leftarrow Z$ 产生完全相同的条件独立性结构，在没有额外假设的情况下无法区分。

这引导我们到下一个重要概念。

4. DAG 等价类与基本等价类图

部分有向无环图 (PAG) 是一种表示 DAG 等价类的标准形式。在 PAG 中：

- 不可定向的边用 $\circ - \circ$ 表示；
- 可定向的边用 $\rightarrow$ 或 $\leftarrow$ 表示。

定理 28.1 (忠实性定理的推论). 在因果马尔可夫条件和忠诚性条件下, 观察分布唯一确定一个 PAG。

这个定理保证了 PC 算法输出的 PAG 是唯一的——如果我们相信这些假设的话。

5. 条件独立性检验

PC 算法的核心依赖于可靠的条件独立性检验。这在实践中是一个 nontrivial 的问题。

5.1. 高斯情形：偏相关系数. 对于连续型高斯数据, 条件独立性可以通过偏相关系数来检验。给定条件集 S , X 和 Y 的偏相关系数记为 $\rho_{XY.S}$ 。

我们可以检验零假设 $H_0: \rho_{XY.S} = 0$ 。在正态性假设下, 这个统计量服从一个已知分布, 可以计算 p 值。

注 28.1. 偏相关系数的计算需要 S 中变量的条件协方差矩阵。当 $|S|$ 较大时, 估计精度会下降, 这是 PC 算法的一个 *practical limitation*。

5.2. 离散情形：条件互信息. 对于离散数据, 我们可以使用条件互信息:

$$(140) \quad I(X; Y | S) = \sum_{x,y,s} p(x, y, s) \log \frac{p(x, y | s)}{p(x | s)p(y | s)}.$$

在独立性下, 这个量应该为零。我们可以使用卡方检验或似然比检验来验证。

6. PC 算法的完整流程

综合以上讨论, PC 算法的完整流程如下:

- (1) **初始化:** 从一个完全无向的完全图开始。
- (2) **骨架发现:** 对每一对变量 (X, Y) , 以及越来越大的条件集 S , 进行条件独立性检验。如果 $X \perp\!\!\!\perp Y | S$, 则删除边 (X, Y) 。
- (3) **v-结构识别:** 对于每个三元组 (X, Z, Y) , 检查是否形成 v-结构。如果是, 定向 $X \rightarrow Z \leftarrow Y$ 。
- (4) **边定向传播:** 应用定向规则, 尽可能多地定向剩余的边。
- (5) **输出:** 返回最终的 PAG。

算法的计算复杂度主要取决于条件独立性检验的数量。对于 p 个变量, 最坏情况下需要检验的条件集数量是 $\sum_{k=0}^{p-2} \binom{p-2}{k}$, 这使得 PC 算法在变量数很大时可能不切实际。

7. 其他因果发现方法概述

PC 算法只是因果发现领域的众多种方法之一。这里简要介绍另外两类重要方法。

7.1. 基于评分的方法. GIES (Greedy Equivalence 类 Search) 等方法将因果发现问题框架为模型选择问题。我们为每个候选 DAG 赋予一个评分 (如 BIC 或 BD 评分), 然后搜索评分最高的结构。

这类方法的优点是可以捕获全局最优结构; 缺点是计算复杂度高, 需要使用贪婪搜索等启发式方法。

7.2. 利用因果充分性假设. 许多方法假设不存在未观察到的共同原因 (因果充分性)。在这个假设下, 观测分布的每个因子对应于一个局部 DAG。

在这种假设下, 因果方向可以通过检验的条件独立性完全确定。

8. 因果发现的局限性

尽管因果发现方法取得了显著进展，我们必须清醒地认识其局限性。

第一，假设的脆弱性。因果马尔可夫条件和忠诚性条件是强有力的假设。如果数据生成过程不满足这些条件（如存在未观察到的混杂），因果发现的结果可能是错误的。

第二，检验的局限性。条件独立性检验的统计功效有限，特别是在小样本或大条件集时。可能出现假阳性（错误地删除边）或假阴性（错误地保留边）。

第三，计算的复杂性。精确的因果发现是 NP 难的。现有算法都依赖于各种近似，这可能影响结果的可靠性。

第四，不可辨识性。即使在理想条件下，某些因果结构也是不可辨识的——不同的因果图可能产生完全相同的观察分布。

9. 讨论与延伸阅读

因果发现是一个活跃的研究领域，涉及统计学、计算机科学、哲学的交叉。经典参考文献包括 Pearl (2000) 的《Causality》，以及 Spirtes et al. (2000) 的《Causation, Prediction, and Search》。

近年的发展包括：

- 利用干预数据改进因果发现；
- 将因果发现与机器学习结合；
- 处理隐变量和选择偏差的更复杂方法。

在实际应用中，因果发现应该谨慎使用。其结果更适合作为假设生成，而不是因果声明的最终结论。

10. 本章小结

本章介绍了从观察数据中发现因果结构的可能性的基本思想。

- (1) 在因果马尔可夫条件和忠诚性条件下，条件独立性蕴含因果结构信息。
- (2) PC 算法通过系统的条件独立性检验和 v -结构识别，从数据中学习因果骨架和方向。
- (3) 因果发现的结果以 PAG（部分有向无环图）的形式表示，反映了因果结构的等价类。
- (4) 因果发现有重要局限性，包括假设的脆弱性、统计检验的局限、计算复杂性和根本性的不可辨识性。

下一步的学习方向包括：深入研究具体的条件独立性检验方法、了解基于评分的方法、以及探索利用干预数据的因果发现技术。

11. 习题

练习 28.1. 证明：在马尔可夫条件和忠诚性条件下，如果 X 和 Y 在骨架中无边，但都与 Z 相连，且 $X \perp\!\!\!\perp Y \mid \emptyset$ 但 $X \perp\!\!\!\perp Y \mid Z$ ，则 (X, Z, Y) 形成 v -结构。

练习 28.2. 考虑四个变量 X_1, X_2, X_3, X_4 ，假设真实因果结构是 $X_1 \rightarrow X_2 \rightarrow X_4$ 和 $X_1 \rightarrow X_3 \rightarrow X_4$ 。说明 PC 算法在什么条件下能够恢复这个结构，以及在什么条件下可能失败。

练习 28.3. 证明：对于 n 个变量的 DAG，完全图（有 $\binom{n}{2}$ 条边）和完全无向图在骨架发现步骤后的边数关系。

练习 28.4. 讨论因果发现与因果推断其他方法（如第 10-12 章的倾向得分方法）的关系。它们分别适合什么场景？

时间变动的处理变量与混淆

1. 从单时间点到多时间点：一个自然的推广

在前面各章中，我们考虑的都是**单一时间点**的处理变量——每个单元在某个特定时刻接受或不接受治疗。然而，现实世界中的治疗往往是**时间变动**的：患者在不同时间点接受不同强度的治疗；政策在不同阶段被动态调整；个人在不同年龄做出不同的选择。

为什么时间变动会带来新的挑战？

考虑一个两时间点的例子： Z_1 是初始治疗（如是否服用阿司匹林）， X_1 是治疗后的中间结果（如血压变化）， Z_2 是后续治疗（如是否接受手术）， Y 是最终结局（如是否在 5 年内死亡）。在这个序列中：

- Z_1 可能影响 X_1 （治疗改变中间结果）
- X_1 可能同时影响 Z_2 和 Y （中间结果既是后续治疗的原因，也是结局的原因）
- 这时， X_1 同时扮演着**时间变动协变量**和**时间变动混淆变量**的角色

在单一时间点框架下，我们只需条件于基线协变量 X_0 即可阻断所有混淆。但在时间变动的情况下， X_1 既是治疗 Z_2 的“前置原因”，也是结局 Y 的“前置原因”——它可能本身就是由 Z_1 产生的，从而部分介导了 Z_1 对 Y 的因果效应。这种复杂的时序结构使得简单的条件独立性假设不再够用。

这就是本章要解决的核心问题：**当处理变量随时间变动时，如何识别和估计因果效应？**

为简化记号，本章主要采用两时间点的设置来阐述核心思想。推广到更多时间点在概念上直接，但有限样本下会产生技术复杂性——组合数随时间点数量指数增长。我们将讨论这些复杂性，并将一般结果留给习题。

2. 基本设置与序列可忽略性

2.1. 时序结构. 两时间点的变量时序如下：

$$X_0 \rightarrow Z_1 \rightarrow X_1 \rightarrow Z_2 \rightarrow Y$$

其中：

- X_0 ：基线协变量（治疗前的特征）
- Z_1 ：时间点 1 的处理变量
- X_1 ：时间点 1 与时间点 2 之间的时变协变量
- Z_2 ：时间点 2 的处理变量
- Y ：最终结局

对于二元处理 (Z_1, Z_2) ，每个单元有四个潜在结局：

$$Y(z_1, z_2), \quad z_1, z_2 \in \{0, 1\}$$

观测到的结局等于：

$$Y = Y(Z_1, Z_2) = \sum_{z_1=0}^1 \sum_{z_2=0}^1 \mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2) Y(z_1, z_2)$$

2.2. 序列可忽略性假设. 在单一时间点的情况下, $Z \perp Y(z) \mid X$ (处理在给定协变量条件下随机化) 是我们识别因果效应的关键假设。对于时间变动的情况, 这个假设需要**序列化**——在每个时间点, 处理不仅依赖于当前的协变量历史, 还依赖于整个历史。

假设 29.1 (序列可忽略性). (1) Z_1 在给定 X_0 条件下随机化:

$$Z_1 \perp Y(z_1, z_2) \mid X_0, \quad \forall z_1, z_2 \in \{0, 1\}$$

(2) Z_2 在给定 (Z_1, X_1, X_0) 条件下随机化:

$$Z_2 \perp Y(z_1, z_2) \mid (Z_1, X_1, X_0), \quad \forall z_1, z_2 \in \{0, 1\}$$

理解 Assumption 29.1: 这个假设包含两部分递进的条件。第一部分说明 Z_1 仅被基线协变量 X_0 混淆——一旦我们条件于 X_0 , Z_1 就等同于随机化实验。第二部分则说明 Z_2 被 (Z_1, X_1, X_0) 混淆——我们不仅需要控制基线协变量 X_0 , 还需要控制由 Z_1 产生的时变协变量 X_1 。

一个重要的微妙之处: 序列可忽略性**允许** X_1 与 Y 之间存在未测量的混淆 U (如图 2 所示)。这是因为 X_1 本身可能是由 Z_1 产生的, 它部分介导了 Z_1 对 Y 的效应——这并非混淆, 而是**中介**。然而, 如果 U 同时影响 X_1 和 Y (且不通过 Z_1, Z_2), 则即使满足序列可忽略性, 识别仍然会受到挑战。



FIGURE 1. Assumption 29.1 成立且 X_1 与 Y 之间无未测量混淆 U 的因果图。




FIGURE 2. Assumption 29.1 成立但 X_1 与 Y 之间存在未测量混淆 U 的因果图。序列可忽略性仅排除了 (Z_1, Z_2) 与 Y 之间的混淆, 但允许 X_1 与 Y 之间存在未测量关联。

3. g 公式与结果建模

在单一时间点情况下，基于结果的识别公式为：

$$E\{Y(z)\} = E\{E(Y \mid Z = z, X)\}$$

对于离散 X ，这化为：

$$E\{Y(z)\} = \sum_x E(Y \mid Z = z, X = x) \Pr(X = x)$$

对于连续 X ，这化为：

$$E\{Y(z)\} = \int E(Y \mid Z = z, X = x) f(x) dx$$

接下来的定理将这个公式推广到两时间点的设置。

定理 29.1 (g 公式). 在 *Assumption 29.1* 下,

$$(29.1) \quad E\{Y(z_1, z_2)\} = E\left[E\{E(Y \mid z_2, z_1, X_1, X_0) \mid z_1, X_0\}\right]$$

定理 29.1 的直观理解：等式右边是从内到外嵌套的条件期望。最内层 $E(Y \mid z_2, z_1, X_1, X_0)$ 是在固定历史 (z_1, X_0) 、中间协变量 X_1 和第二时刻治疗 z_2 的条件下结局的期望。中间层 $E\{\cdot \mid z_1, X_0\}$ 对 X_1 求平均——但注意，这是**逆概率加权**的平均，因为 $\Pr(X_1 \mid z_1, X_0)$ 与 $Z_1 = z_1$ 相关。最外层 $E[\cdot]$ 对 X_0 求边际平均。

对于离散 X_0, X_1 ，29.1 化为：

$$(29.2) \quad E\{Y(z_1, z_2)\} = \sum_{x_0} \sum_{x_1} E(Y \mid z_2, z_1, x_1, x_0) \Pr(x_1 \mid z_1, x_0) \Pr(x_0)$$

对于连续 X_0, X_1 ，29.1 化为：

$$(29.3) \quad E\{Y(z_1, z_2)\} = \iint E(Y \mid z_2, z_1, x_1, x_0) f(x_1 \mid z_1, x_0) f(x_0) dx_1 dx_0$$

与全概率公式的比较：根据观测数据的全概率公式，

$$(29.4) \quad E(Y) = \sum_{x_0} \sum_{z_1} \sum_{x_1} \sum_{z_2} E(Y \mid z_2, z_1, x_1, x_0) \Pr(z_2 \mid z_1, x_1, x_0) \Pr(x_1 \mid z_1, x_0) \Pr(z_1 \mid x_0) \Pr(x_0)$$

对比 29.3 与 29.4，关键区别在于：29.3 中**没有** $\Pr(z_2 \mid \dots)$ 和 $\Pr(z_1 \mid \dots)$ 项——这是因为潜在结局 $Y(z_1, z_2)$ 的定义是**固定** $Z_1 = z_1$ 和 $Z_2 = z_2$ ，而非观测到的分配概率。

29.2 和 29.3 被称为 **g 公式 (g-formula)**，由 Robins 命名。这个名称源于它的一般化形式——当处理变量随时间变动时，这个公式提供了一种递推的识别策略。

定理 29.1 的证明。¹

¹详见附录 section 14。

3.1. 基于结果建模的插件估计. g 公式 29.2 和 29.3 提示我们：为了估计潜在结局的均值，我们需要对 $E(Y \mid z_2, z_1, x_1, x_0)$ 、 $\Pr(x_1 \mid z_1, x_0)$ 和 $\Pr(x_0)$ 建模。有了这些拟合模型，我们可以将它们”插入”g 公式得到估计。

在某些特殊函数形式下，这个任务可以简化。下面的例 29.1 给出线性结果模型下的结果。

例 29.1 (例 29.1 — 线性结果模型). 假设线性结果模型：

$$(29.5) \quad E(Y \mid z_2, z_1, x_1, x_0) = \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 x_1 + \beta_4 x_0$$

可以验证：

$$(29.6) \quad \begin{aligned} E\{Y(z_1, z_2)\} &= \sum_{x_0} \sum_{x_1} (\beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 x_1 + \beta_4 x_0) \\ &\quad \Pr(x_1 \mid z_1, x_0) \Pr(x_0) \\ &= \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 \sum_{x_0} E(X_1 \mid z_1, x_0) \Pr(x_0) + \beta_4 E(X_0) \\ &= \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 E\{X_1(z_1)\} + \beta_4 E(X_0) \end{aligned}$$

其中我们定义了 X_1 在治疗 $Z_1 = z_1$ 下的潜在结局：

$$(29.7) \quad E\{X_1(z_1)\} = \sum_{x_0} E(X_1 \mid z_1, x_0) \Pr(x_0)$$

定义 $\tau_{Z_1 \rightarrow X_1} = E\{X_1(1) - X_1(0)\}$ ，则：

$$(29.8) \quad E\{Y(1, 0) - Y(0, 0)\} = \beta_2 + \beta_3 \tau_{Z_1 \rightarrow X_1}$$

$$(29.9) \quad E\{Y(0, 1) - Y(0, 0)\} = \beta_1$$

$$(29.10) \quad E\{Y(1, 1) - Y(0, 0)\} = \beta_1 + \beta_2 + \beta_3 \tau_{Z_1 \rightarrow X_1}$$

直观解释 (参见图 3)：29.8 中 Z_1 的效应等于路径 $Z_1 \rightarrow Y$ (系数 β_2) 和路径 $Z_1 \rightarrow X_1 \rightarrow Y$ (系数 $\beta_3 \tau_{Z_1 \rightarrow X_1}$) 之和；29.9 中 Z_2 的效应等于路径 $Z_2 \rightarrow Y$ (系数 β_1)；29.10 中 (Z_1, Z_2) 的总效应等于三条路径系数之和。




FIGURE 3. 带路径系数的线性因果图，条件于基线协变量 X_0 。

g-null 悖论. Robins 和 Wasserman (1997) 指出了基于结果建模的插件估计的一个令人惊讶的缺陷。他们证明：如果在这个策略中出现模型错误设定，数据分析者可能**错误地拒绝**零因果效应 null 假设，即使在真实数据生成过程中 (Z_1, Z_2) 对 Y 的因果效应确实为零。他们称之为 **g-null 悖论 (g-null paradox)**。令人惊讶的是，即使在例 29.1 的简单线性结果模型中，g-null 悖论也可能出现（见习题 29.1）。

3.2. 基于结果建模的递推估计. 29.3.1 节的插件估计涉及对时变协变量 X_1 建模, 并导致令人不快的 g-null 悖论——这不是一个理想的方法。

递推期望公式 29.1 启发了一种更简单的估计方法。从最内层条件期望开始, 记:

$$\hat{Y}_2(z_1, z_2) = E(Y \mid Z_2 = z_2, Z_1 = z_1, X_1, X_0)$$

我们可以用 $(Z_2 = z_2, Z_1 = z_1)$ 子集数据拟合 Y 对 (X_1, X_0) 的模型, 得到所有单元的拟合值 $\hat{Y}_{2i}(z_1, z_2)$ 。然后进入外层条件期望, 记:

$$\hat{Y}_1(z_1, z_2) = E\{\hat{Y}_2(z_1, z_2) \mid Z_1 = z_1, X_0\}$$

我们可以用 $Z_1 = z_1$ 子集数据拟合 $\hat{Y}_2(z_1, z_2)$ 对 X_0 的模型, 得到所有单元的拟合值 $\hat{Y}_{1i}(z_1, z_2)$ 。最终的 $E\{Y(z_1, z_2)\}$ 估计量为:

$$(29.11) \quad \hat{E}\{Y(z_1, z_2)\} = n^{-1} \sum_{i=1}^n \hat{Y}_{1i}(z_1, z_2)$$

这种递推估计**不涉及**对 X_1 建模, 因此避免了 g-null 悖论 (见习题 29.2)。然而, 基于递推回归的估计量实现起来并不容易, 因为它涉及建模与因果图自然结构不对应的变量——例如 $\hat{Y}_2(z_1, z_2)$ 。

4. 逆概率加权

在单一时间点情况下, IPW 识别公式为:

$$E\{Y(z)\} = E\left\{\frac{\mathbf{1}(Z = z)Y}{\Pr(Z = z \mid X)}\right\}$$

接下来的结果将其推广到两时间点设置。定义:

$$(29.12) \quad e(z_1, X_0) = \Pr(Z_1 = z_1 \mid X_0)$$

$$(29.13) \quad e(z_2, Z_1, X_1, X_0) = \Pr(Z_2 = z_2 \mid Z_1, X_1, X_0)$$

为时间点 1 和时间点 2 的倾向得分。

定理 29.2 (IPW 识别公式). 在 *Assumption 29.1* 下,

$$(29.14) \quad E\{Y(z_1, z_2)\} = E\left\{\frac{\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)Y}{e(z_1, X_0)e(z_2, Z_1, X_1, X_0)}\right\}$$

定理 29.2 揭示的重叠假设:

$$(29.15) \quad 0 < e(z_1, X_0) < 1, \quad 0 < e(z_2, Z_1, X_1, X_0) < 1$$

对所有 z_1, z_2 。如果某些倾向得分为 0 或 1, 识别公式 29.14 会爆炸到无穷。

直观理解: 这个公式本质上是单一时间点 IPW 公式的两次应用——首先在 Z_2 上”调整”, 然后在 Z_1 上”调整”。分子中的指示函数 $\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)$ 选择出接受特定治疗序列的单元, 分母中的倾向得分对此进行加权, 使每个单元在分析中代表与其倾向得分成反比的单元数。

估计策略. 基于 IPW 的估计非常简单, 只需对两个二元治疗指标建模。首先, 我们可以拟合 Z_1 对 X_0 的模型, 得到所有单元的拟合值 $\hat{e}_1(z_1, X_{0i})$; 拟合 Z_2 对 (Z_1, X_1, X_0) 的模型,

得到所有单元的拟合值 $\hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})$ 。然后得到以下 IPW 估计量 (Horvitz-Thompson 型):

$$(29.16) \quad \hat{E}^{\text{ht}}\{Y(z_1, z_2)\} = n^{-1} \sum_{i=1}^n \frac{\mathbf{1}(Z_{1i} = z_1) \mathbf{1}(Z_{2i} = z_2) Y_i}{\hat{e}_1(z_1, X_{0i}) \hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})}$$

与第 11 章的讨论类似, HT 估计量对结局的位移不具有不变性, 且在有限样本下存在不稳定性。修正后的 Hajek 型估计量为 $\hat{E}^{\text{haj}}\{Y(z_1, z_2)\} = \hat{E}^{\text{ht}}\{Y(z_1, z_2)\} / \hat{1}^{\text{ht}}(z_1, z_2)$, 其中:

$$(29.17) \quad \hat{1}^{\text{ht}}(z_1, z_2) = n^{-1} \sum_{i=1}^n \frac{\mathbf{1}(Z_{1i} = z_1) \mathbf{1}(Z_{2i} = z_2)}{\hat{e}_1(z_1, X_{0i}) \hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})}$$

5. 多时间点情形

将 29.2 和 29.3 节的估计策略推广到多时间点并非易事。即使对于二元处理和 K 个时间点, 处理组合的数量也随 K 指数增长 (例如 $2^5 = 32$, $2^{10} = 1024$)。因此, 29.2 和 29.3 节的结果回归和 IPW 估计量在有限样本下是不可行的——因为它们要求每个处理组合水平组合都有足够的数据。

为应对这一挑战, Robins 提出了两种强大的估计框架: **边际结构模型 (Marginal Structural Model, MSM)** 和 **结构嵌套模型 (Structural Nested Model, SNM)**。

5.1. 边际结构模型. 一种强有力的方法基于 **边际结构模型 (MSM)** (Robins et al., 2000; Hernán et al., 2000)。为简化记号, 我们仅展示 $K = 2$ 的 MSM, 尽管其主要用途在于一般情形。

定义 29.3 (MSM — 边际结构模型). $Y(z_1, z_2)$ 的边际均值为:

$$(29.18) \quad E\{Y(z_1, z_2)\} = f(z_1, z_2; \beta)$$

一个典型例子是 $E\{Y(z_1, z_2)\} = \beta_0 + \beta_1 z_1 + \beta_2 z_2$ 。我们也可以将基线协变量纳入模型。

定义 29.4 (带基线协变量的 MSM). 给定 X_0 条件下 $Y(z_1, z_2)$ 的均值为:

$$(29.19) \quad E\{Y(z_1, z_2) \mid X_0\} = f(z_1, z_2, X_0; \beta)$$

一个典型例子是:

$$(29.20) \quad E\{Y(z_1, z_2) \mid X_0\} = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^T X_0$$

如果我们观测到所有潜在结局, 可以通过以下最小化问题求解 β :

$$(29.21) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E\{Y(z_1, z_2) - f(z_1, z_2, X_0; b)\}^2$$

在序列可忽略性下, 我们可以通过仅涉及观测变量的最小化问题求解 β 。

定理 29.5 (MSM 下的 IPW). 在 *Assumption 29.1* 和 *Definition 29.4* 下, ?? 中的 β 等于:

$$(29.22) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E \left[\frac{\mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2)}{e(z_1, X_0) e(z_2, Z_1, X_1, X_0)} \{Y - f(z_1, z_2, X_0; b)\}^2 \right]$$

估计策略. 定理 29.5 暗示了一种基于加权回归的简单估计策略。例如, 在 29.20 下, 我们可以拟合 Y_i 对 $(1, Z_{1i}, Z_{2i}, X_{0i})$ 的加权最小二乘 (WLS) 回归, 权重为 $\hat{e}_1^{-1}(Z_{1i}, X_{0i}) \hat{e}_{2i}^{-1}(Z_{2i}, Z_{1i}, X_{1i}, X_{0i})$ 。

与结果回归的比较: MSM 的 IPW 方法与结果回归方法的关键区别在于: 结果回归直接建模 $E(Y \mid Z, X)$, 而 MSM 的 IPW 方法建模 $E\{Y(z) \mid X_0\}$ 并通过逆概率加权来处理时变混淆。MSM 的优势在于它允许我们指定 **边际** (而非条件) 结构, 这有时更加自然。

高维协变量下的 MSM。当 X_0 维数很高时, 29.20 中的线性模型 $\beta_3^\top X_0$ 面临维数灾难。此时, 稀疏性假设变得关键——即 β_3 中只有少数元素非零。LASSO (Tibshirani, 1996) 等正则化方法可以用于在高维下估计 β , 但需要额外的理论保证来确保因果推断的渐近有效性 (见 Bloniarz et al., 2016; Wager et al., 2016)。

5.2. 结构嵌套模型。IPW 的一个关键问题是: 如果重叠假设 29.15 被违背, IPW 不可用。为解决这一挑战, Robins 提出了结构嵌套模型。这里我们仅回顾两时间点的版本。

定义 29.6 (结构嵌套模型 (SNM))。时间点 1 的条件效应为:

$$(29.23) \quad E\{Y(z_1, 0) - Y(0, 0) \mid Z_1 = z_1, X_0\} = g_1(z_1, X_0; \beta)$$

时间点 2 的条件效应为:

$$(29.24) \quad E\{Y(z_1, z_2) - Y(z_1, 0) \mid Z_2 = z_2, Z_1 = z_1, X_1, X_0\} = g_2(z_2, z_1, X_1, X_0; \beta)$$

在 Definition 29.6 中, 有两个逻辑约束:

$$(29.25) \quad g_1(0, X_0; \beta) = 0, \quad g_2(0, z_1, X_1, X_0; \beta) = 0, \quad \forall z_1$$

两个典型选择如下。

例 29.2 (例 29.2 —加法齐次 SNM)。假设:

$$(29.26) \quad \begin{cases} g_1(z_1, X_0; \beta) = \beta_1 z_1 \\ g_2(z_2, z_1, X_1, X_0; \beta) = (\beta_2 + \beta_3 z_1) z_2 \end{cases}$$

例 29.3 (例 29.3 —协变量调整 SNM)。假设:

$$(29.27) \quad \begin{cases} g_1(z_1, X_0; \beta) = (\beta_1 + \beta_2^\top X_0) z_1 \\ g_2(z_2, z_1, X_1, X_0; \beta) = (\beta_3 + \beta_4 z_1 + \beta_5^\top X_1) z_2 \end{cases}$$

MSM 与 SNM 的比较。结构嵌套模型允许同时调整基线协变量和时变协变量, 而边际结构模型仅允许调整基线协变量。Definition 29.6 下的估计更为复杂, 策略基于估计方程。

估计方程。首先引入两个重要构建块。定义:

$$(29.28) \quad U_2(\beta) = Y - g_2(Z_2, Z_1, X_1, X_0; \beta)$$

$$(29.29) \quad U_1(\beta) = Y - g_2(Z_2, Z_1, X_1, X_0; \beta) - g_1(Z_1, X_0; \beta)$$

它们不能直接从数据计算, 因为它们依赖于参数的真实值。在真值处, 它们具有以下性质。

引理 29.7 (引理 29.1)。在 Assumption 29.1 和 Definition 29.6 下,

$$(29.30) \quad E\{U_2(\beta) \mid Z_2, Z_1, X_1, X_0\} = E\{U_2(\beta) \mid Z_1, X_1, X_0\} = E\{Y(Z_1, 0) \mid Z_1, X_1, X_0\}$$

且

$$(29.31) \quad E\{U_1(\beta) \mid Z_1, X_0\} = E\{U_1(\beta) \mid X_0\} = E\{Y(0, 0) \mid X_0\}$$

引理 29.7 的直观理解: $U_1(\beta)$ 扮演着“接受任何治疗前的对照潜在结局”的角色, 而 $U_2(\beta)$ 扮演着“接受时间点 1 治疗后、时间点 2 前的对照潜在结局”的角色。

定理 29.8 (定理 29.4 —SNM 估计方程). 在 *Assumption 29.1* 和 *Definition 29.6* 下,

$$(29.32) \quad E[h_2(Z_1, X_1, X_0)\{Z_2 - e(1, Z_1, X_1, X_0)\}U_2(\beta)] = 0$$

且

$$(29.33) \quad E[h_1(X_0)\{Z_1 - e(1, X_0)\}U_1(\beta)] = 0$$

对任何函数 h_1 和 h_2 (只要矩存在)。

使用定理 29.8 时, 我们必须指定 h_1 和 h_2 以确保有足够的方程来求解 β 。例 29.4 回顾例 29.2。

例 29.4 (例 29.4 —例 29.2 下的估计方程). 在例 29.2 下, 我们可以选择 $h_1 = 1$ 和 $h_2 = (1, Z_1)$ 得到:

$$(29.34) \quad \begin{aligned} E[\{Z_2 - e(1, Z_1, X_1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2\}] &= 0 \\ E[Z_1\{Z_2 - e(1, Z_1, X_1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2\}] &= 0 \\ E[\{Z_1 - e(1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2 - \beta_1 Z_1\}] &= 0 \end{aligned}$$

然后我们可以从上述线性方程组求解 β (见习题 29.6)。

更高效的估计。 一个自然的问题是: 替代性的 (h_1, h_2) 选择是否能导致更高效的估计量? 答案是肯定的。例如, 我们可以选择许多 (h_1, h_2) 并使用广义矩方法 (GMM; Hansen, 1982)。技术细节超出本书范围。Naimi et al. (2017) 和 Vansteelandt and Joffe (2014) 提供了结构嵌套模型的教程。

6. 习题

6.1. g -null 悖论。 考虑图 4 中的简单因果图: 没有基线协变量 X_0 , 也没有从 (Z_1, Z_2) 到 Y 的箭头。因此 (Z_1, Z_2) 对 Y 的因果效应为零。

FIGURE 4. 习题 29.1 图: X_1 与 Y 之间存在未测量混淆 U 的因果图。

回顾例 29.1。证明: 如果

$$(29.35) \quad \beta_1 = \beta_2 = 0 \quad \text{且} \quad \beta_3 = 0$$

或者

$$(29.36) \quad \beta_1 = \beta_2 = 0 \quad \text{且} \quad E\{X_1(z_1)\} \text{ 不依赖于 } z_1$$

则期望 $E\{Y(z_1, z_2)\}$ 不依赖于 (z_1, z_2) 。

注: 然而, ?? 中的 $\beta_3 = 0$ 排除了 Y 对 X_1 的依赖, 与 X_1 和 Y 之间存在未测量混淆 U 矛盾; $E\{X_1(z_1)\}$ 对 z_1 的独立性排除了 X_1 对 Z_1 的依赖, 与 Z_1 到 X_1 的箭头矛盾。也就是说, 如果 X_1 和 Y 之间存在未测量混淆 U , 且 Z_1 到 X_1 存在箭头, 那么例 29.1 中 $E\{Y(z_1, z_2)\}$ 的公式必定依赖于 (z_1, z_2) , 这与 (Z_1, Z_2) 对 Y 无因果效应的假设矛盾——这就是 g -null 悖论。

6.2. 零模型下的递推估计。 考虑 29.3.2 节的递推估计方法在习题 29.1 的因果图下。基于线性模型, 证明估计量收敛到 0。

6.3. MSM 下的 IPW。 证明定理 29.5。

6.4. 定义 29.2 的非线性例子. 定义 29.2 的另一个典型例子是:

$$(29.37) \quad \text{logit}[\Pr\{Y(z_1, z_2) = 1 \mid X_0\}] = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^\top X_0$$

如果我们观测到所有潜在结局, 可以通过最小化负对数似然函数来求解 β (见第 B.6.2 节的更简单版本):

$$(29.38) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E\{\log(1 + e^\ell) - Y(z_1, z_2)\ell\}$$

其中 $\ell = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^\top X_0$. 在序列可忽略性下, 我们可以从以下仅涉及观测变量的最小化问题求解 β .

定理 29.5 (MSM 下的 IPW). 在 Assumption 29.1 和 Definition 29.4 下, ?? 中的 β 等于:

$$(29.39) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E \left[\frac{\mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2)}{e(z_1, X_0) e(z_2, Z_1, X_1, X_0)} \{\log(1 + e^\ell) - Y(z_1, z_2)\ell\} \right]$$

证明定理 29.5.

注: 定理 29.5 暗示了一种基于加权回归的简单估计策略。例如, 在 ?? 下, 我们可以拟合 Y_i 对 $(1, Z_{1i}, Z_{2i}, X_{0i})$ 的加权 logistic 回归, 权重为 $\hat{e}_1^{-1}(Z_{1i}, X_{0i}) \hat{e}_{2i}^{-1}(Z_{2i}, Z_{1i}, X_{1i}, X_{0i})$ 。

6.5. 单时间点结构嵌套模型. 回顾观测研究的标准设置: IID 数据从 $\{X, Z, Y(1), Y(0)\}$ 中抽取。定义倾向得分为 $e(X) = \Pr(Z = 1 \mid X)$ 。假设:

$$(29.40) \quad Z \perp Y(0) \mid X$$

及以下结构嵌套模型。

定义 29.4 (单时间点结构嵌套模型). 个体效应的条件均值为:

$$(29.41) \quad E\{Y(z) - Y(0) \mid Z = z, X\} = g(z, X; \beta)$$

在定义 29.4 中, 逻辑约束为 $g(0, X; \beta) = 0$ 。证明以下结果。

(1) 我们有:

$$(29.42) \quad E\{Y - g(Z, X; \beta) \mid X, Z\} = E\{Y - g(Z, X; \beta) \mid X\} = E\{Y(0) \mid X\}$$

(2) 我们有:

$$(29.43) \quad E[h(X)\{Z - e(X)\}\{Y - g(Z, X; \beta)\}] = 0$$

对任何函数 h , 只要矩存在。

注: ?? 是参数估计的基础。考虑定义 29.4 的特殊情况 $g(z, X; \beta) = \beta z$ 。选择 $h(X) = 1$ 得到:

$$(29.44) \quad E[\{Z - e(X)\}\{Y - \beta Z\}] = 0$$

这正是倾向得分加权的标准方程 (见第 11 章)。

7. 推荐阅读

Robins 和他的合作者的一系列开创性论文奠定了本章材料的基础。Robins (1986) 引入了 g-formula 和边际结构模型的基本思想; Robins (1998) 系统阐述了结构嵌套模型; Robins 和 Hernán (2009) 提供了 g-方法的综合综述。Robins 和 Waterman (1994) 比较了 MSM 和 SNM 两种方法。关于 g-null 悖论的更多讨论, 见 Robins 和 Wasserman (1997) 和 McGrath et al. (2021)。

在高维协变量背景下, Bloniarz et al. (2016) 提出用 LASSO 调整实验中的处理效应估计; Wager et al. (2016) 提出使用机器学习方法分析高维实验数据; Lei 和 Ding (2021) 在

不假设稀疏性的正则条件下证明 Lin (2013) 估计量的渐近正态性。D'Amour et al. (2021) 讨论了高维协变量观测研究中的重叠问题。

APPENDIX A

公式推导

1. Lemma 4.1 的证明：方差与协方差的关系

Lemma 4.1 (教材第 1975 页):

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

背景 (Background): Lemma 4.1 是 Neyman (1923) 定理证明中的一个关键代数恒等式，它建立了有限总体协方差与各个方差之间的关系。

参数定义 (Parameter Definitions):

- $S^2(1) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2$: 潜在结果 $Y_i(1)$ 的有限总体方差
- $S^2(0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$: 潜在结果 $Y_i(0)$ 的有限总体方差
- $S(1, 0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\} \{Y_i(0) - \bar{Y}(0)\}$: $Y_i(1)$ 与 $Y_i(0)$ 之间的有限总体协方差
- $\tau_i = Y_i(1) - Y_i(0)$: 个体因果效应
- $\tau = n^{-1} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$: 平均因果效应
- $S^2(\tau) = (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2$: 个体因果效应的有限总体方差

目标 (Goal): 证明

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

推导步骤 (Derivation Steps):

第一步: 从 $S^2(\tau)$ 的定义出发。

$$\begin{aligned} S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - Y_i(0)) - (\bar{Y}(1) - \bar{Y}(0))]^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - \bar{Y}(1)) - (Y_i(0) - \bar{Y}(0))]^2. \end{aligned}$$

第二步: 展开平方。

$$\begin{aligned}
S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n \left[(Y_i(1) - \bar{Y}(1))^2 + (Y_i(0) - \bar{Y}(0))^2 \right. \\
&\quad \left. - 2(Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \right] \\
&= (n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))^2 + (n-1)^{-1} \sum_{i=1}^n (Y_i(0) - \bar{Y}(0))^2 \\
&\quad - 2(n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \\
&= S^2(1) + S^2(0) - 2S(1, 0).
\end{aligned}$$

第三步：移项得到目标恒等式。

$$S^2(1) + S^2(0) - S^2(\tau) = 2S(1, 0).$$

结论：得证

$$\boxed{2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)}.$$

直观理解：这个恒等式揭示了潜在结果之间的相关性 ($S(1, 0)$) 与个体因果效应变异 ($S^2(\tau)$) 之间的联系。当个体因果效应完全恒定 ($S^2(\tau) = 0$) 时, $2S(1, 0) = S^2(1) + S^2(0)$, 即 $Y(1)$ 和 $Y(0)$ 完全正相关 (相关系数为 1)。当 $S^2(\tau) > 0$ 时, 等式右侧变小, 意味着 $S(1, 0)$ 变小或变为负值。

在方差公式中的应用：这个恒等式允许我们将 Neyman 方差公式写成两种等价形式：

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} = \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0).$$

2. 差值均值统计量的方差分解

背景：在 eq. (19) 中, 我们声称

$$(n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

本节给出完整的代数推导。

第一步：从定义出发。

$$(n-1)s^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n [(Y_i - \bar{Y})]^2.$$

第二步：对每个单元 i , 将偏差 $Y_i - \bar{Y}$ 写成：

$$Y_i - \bar{Y} = \underbrace{(Y_i - \hat{Y}(Z_i))}_{\text{组内偏差}} + \underbrace{(\hat{Y}(Z_i) - \bar{Y})}_{\text{组间偏差}}.$$

第三步：平方展开：

$$(Y_i - \bar{Y})^2 = (Y_i - \hat{Y}(Z_i))^2 + (\hat{Y}(Z_i) - \bar{Y})^2 + 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}).$$

第四步：对所有单元求和。关键观察是交叉项求和为零：

$$\sum_{i=1}^n 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}) = 2 \sum_{i=1}^n (Y_i - \hat{Y}(Z_i)) \cdot (\hat{Y}(Z_i) - \bar{Y}).$$

当 $Z_i = 1$ 时，这个和化为：

$$2 \sum_{Z_i=1} (Y_i - \hat{Y}(1)) \cdot (\hat{Y}(1) - \bar{Y}) = 2(\hat{Y}(1) - \bar{Y}) \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))}_{=0} = 0,$$

因为 $\sum_{Z_i=1} Y_i = n_1 \hat{Y}(1)$ ，所以 $\sum_{Z_i=1} (Y_i - \hat{Y}(1)) = 0$ 。

同理，当 $Z_i = 0$ 时：

$$2 \sum_{Z_i=0} (Y_i - \hat{Y}(0)) \cdot (\hat{Y}(0) - \bar{Y}) = 2(\hat{Y}(0) - \bar{Y}) \underbrace{\sum_{Z_i=0} (Y_i - \hat{Y}(0))}_{=0} = 0.$$

因此交叉项全部抵消。

第五步：整理得到：

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2}_{\text{组内平方和}} + \underbrace{\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2}_{\text{组间平方和}}.$$

第六步：计算组间平方和：

$$\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2 = n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2.$$

利用以下两个事实：

$$(1) \hat{Y}(1) - \hat{Y}(0) = \hat{\tau}$$

$$(2) n_1 \hat{Y}(1) + n_0 \hat{Y}(0) = n\bar{Y} \quad (\text{加权平均的性质})$$

展开并化简：

$$\begin{aligned} & n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 \\ &= n_1 \hat{Y}(1)^2 - 2n_1 \hat{Y}(1)\bar{Y} + n_1 \bar{Y}^2 + n_0 \hat{Y}(0)^2 - 2n_0 \hat{Y}(0)\bar{Y} + n_0 \bar{Y}^2 \\ &= n_1 \hat{Y}(1)^2 + n_0 \hat{Y}(0)^2 - n\bar{Y}^2. \end{aligned}$$

利用 $(n_1 \hat{Y}(1) + n_0 \hat{Y}(0))^2 = n^2 \bar{Y}^2$ ，展开得：

$$n_1^2 \hat{Y}(1)^2 + 2n_1 n_0 \hat{Y}(1)\hat{Y}(0) + n_0^2 \hat{Y}(0)^2 = n^2 \bar{Y}^2.$$

代入上式并利用 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ ，最终化简为：

$$n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 = \frac{n_1 n_0}{n} \hat{\tau}^2.$$

结论：代入即得 eq. (19)。

3. Wilcoxon 秩和统计量的方差推导

背景：在 ?? 中，我们声称在 H_{0F} 下

$$\text{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

本节给出完整的代数推导。

第一步：回忆 $W = \sum_{i=1}^n Z_i R_i$ ，其中 R_i 是 Y_i 在合并样本中的秩（固定值）， Z_i 是随机化的治疗指示变量。

方差分解：

$$\text{var}(W) = \text{var}\left(\sum_{i=1}^n Z_i R_i\right) = \sum_{i=1}^n R_i^2 \text{var}(Z_i) + \sum_{i \neq j} R_i R_j \text{cov}(Z_i, Z_j).$$

计算 $\text{var}(Z_i)$ ：在 CRE 中， $Z_i \sim \text{Bernoulli}(n_1/n)$ ，所以

$$\text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

计算 $\text{cov}(Z_i, Z_j)$ for $i \neq j$ ：由于 $\sum_{i=1}^n Z_i = n_1$ （固定），我们有

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)} \quad (i \neq j).$$

代入：

$$\begin{aligned} \text{var}(W) &= \left(\sum_{i=1}^n R_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} R_i R_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right) \\ &= \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \sum_{i \neq j} R_i R_j \right]. \end{aligned}$$

注意 $\sum_{i \neq j} R_i R_j = (\sum_{i=1}^n R_i)^2 - \sum_{i=1}^n R_i^2$ ，代入得：

$$\text{var}(W) = \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \left(\left(\sum_{i=1}^n R_i \right)^2 - \sum_{i=1}^n R_i^2 \right) \right].$$

计算 $\sum_{i=1}^n R_i$ 和 $\sum_{i=1}^n R_i^2$ ：假设无 ties，则 $\{R_i\}$ 是 $1, 2, \dots, n$ 的一个排列。

$$\sum_{i=1}^n R_i = 1 + 2 + \dots + n = \frac{n(n+1)}{2}.$$

$$\sum_{i=1}^n R_i^2 = 1^2 + 2^2 + \dots + n^2 = \frac{n(n+1)(2n+1)}{6}.$$

代入并化简：

$$\begin{aligned} \text{var}(W) &= \frac{n_1 n_0}{n^2} \left[\frac{n(n+1)(2n+1)}{6} - \frac{1}{n-1} \left(\frac{n^2(n+1)^2}{4} - \frac{n(n+1)(2n+1)}{6} \right) \right] \\ &= \frac{n_1 n_0 (n+1)}{12}. \end{aligned}$$

结论：得证。

4. 女士品茶实验的超几何分布

背景：在 ?? 中，我们讨论了 Fisher 的女士品茶实验。本节给出超几何分布的完整推导。

设置：

- 8 杯茶中有 4 杯是”先加奶”($K = 4$), 4 杯是”先加茶”
- 女士随机猜测其中 4 杯为”先加奶”
- 记 X 为她猜对”先加奶”的杯数

为什么是超几何分布？

在 H_{0F} 下，女士的猜测是固定的（她选 4 杯作为”先加奶”的猜测）。实验者随机排列 8 杯茶的顺序呈现给女士。这等价于：从含有 $K = 4$ 个”成功”的总体 $N = 8$ 中，不放回抽取 $n = 4$ 个， X 是抽到的成功个数。

超几何分布的概率质量函数：

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, 2, 3, 4.$$

验证：超几何分布的概率之和为 1。

$$\sum_{k=0}^4 \mathbb{P}(X = k) = \frac{1}{\binom{8}{4}} \sum_{k=0}^4 \binom{4}{k} \binom{4}{4-k} = \frac{1}{70} \cdot \binom{8}{4} = 1,$$

其中利用了组合恒等式 $\sum_k \binom{a}{k} \binom{b}{n-k} = \binom{a+b}{n}$ 。

各概率的数值：

$$\begin{aligned} \mathbb{P}(X = 0) &= \frac{\binom{4}{0} \binom{4}{4}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}, \\ \mathbb{P}(X = 1) &= \frac{\binom{4}{1} \binom{4}{3}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 2) &= \frac{\binom{4}{2} \binom{4}{2}}{\binom{8}{4}} = \frac{6 \cdot 6}{70} = \frac{36}{70}, \\ \mathbb{P}(X = 3) &= \frac{\binom{4}{3} \binom{4}{1}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 4) &= \frac{\binom{4}{4} \binom{4}{0}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}. \end{aligned}$$

与二项分布的比较：如果”抽取放回”（即女士每次猜测后被告知答案），则 $X \sim \text{Binomial}(4, 1/2)$ ，此时

$$\mathbb{P}(X = 4) = \binom{4}{4} (1/2)^4 = 1/16 = 0.0625 > 0.014.$$

超几何分布（不放回）的尾部概率更小，使得 Fisher 的检验在零假设下更精确——这正是 FRT”精确”的含义。

5. 差值均值统计量的期望与方差推导

背景：在 eq. (14) 中，我们定义了差值均值统计量

$$\hat{\tau} = \hat{Y}(1) - \hat{Y}(0).$$

本节推导在 H_{0F} 下 $\hat{\tau}$ 的期望和方差。

期望的推导。回忆在 CRE 中，治疗分配 $\mathbf{Z}$ 与潜在结果 $\{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 独立，且每个单元被分配到治疗组的概率为 n_1/n ：

$$\mathbb{E}(Z_i) = \frac{n_1}{n}, \quad \mathbb{E}(1 - Z_i) = \frac{n_0}{n}.$$

因此

$$\begin{aligned} \mathbb{E}(\hat{\tau}) &= \mathbb{E} \left(n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i \right) \\ &= n_1^{-1} \sum_{i=1}^n \mathbb{E}(Z_i) Y_i - n_0^{-1} \sum_{i=1}^n \mathbb{E}(1 - Z_i) Y_i \\ &= n_1^{-1} \sum_{i=1}^n \frac{n_1}{n} Y_i - n_0^{-1} \sum_{i=1}^n \frac{n_0}{n} Y_i \\ &= \frac{1}{n} \sum_{i=1}^n Y_i - \frac{1}{n} \sum_{i=1}^n Y_i = 0. \end{aligned}$$

方差的推导. 第一步：简化表达式。注意到

$$\hat{\tau} = n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i = \frac{n}{n_0} \cdot n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n Y_i.$$

由于 $\sum_{i=1}^n Y_i$ 是常数（不依赖 $\mathbf{Z}$ ），我们只需计算

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \text{var} \left(\sum_{i=1}^n Z_i Y_i \right).$$

第二步：计算 $\text{var}(Z_i)$ 和 $\text{cov}(Z_i, Z_j)$ 。在 CRE 中，

$$Z_i \sim \text{Bernoulli} \left(\frac{n_1}{n} \right), \quad \text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ （固定），对于 $i \neq j$ ，

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)}.$$

第三步：计算 $\text{var}(\sum_{i=1}^n Z_i Y_i)$ ：

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \sum_{i=1}^n Y_i^2 \text{var}(Z_i) + \sum_{i \neq j} Y_i Y_j \text{cov}(Z_i, Z_j) \\ &= \left(\sum_{i=1}^n Y_i^2 \right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} Y_i Y_j \left(-\frac{n_1 n_0}{n^2(n-1)} \right). \end{aligned}$$

注意 $\sum_{i \neq j} Y_i Y_j = (\sum_{i=1}^n Y_i)^2 - \sum_{i=1}^n Y_i^2 = n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2$, 代入得:

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \frac{n_1 n_0}{n^2} \sum_{i=1}^n Y_i^2 - \frac{n_1 n_0}{n^2(n-1)} \left(n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2 \right) \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[(n-1) \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 + \sum_{i=1}^n Y_i^2 \right] \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[n \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 \right] \\ &= \frac{n_1 n_0}{n(n-1)} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right). \end{aligned}$$

第四步: 利用 s^2 的定义:

$$s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)^{-1} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right).$$

因此

$$\text{var} \left(\sum_{i=1}^n Z_i Y_i \right) = \frac{n_1 n_0}{n} \cdot s^2.$$

第五步: 代回 $\text{var}(\hat{\tau})$:

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \frac{n_1 n_0}{n} \cdot s^2 = \frac{n}{n_1 n_0} \cdot s^2.$$

结论:

$$\boxed{\text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} \cdot s^2}.$$

直观理解:

- 方差与总样本量 n 成正比——样本越大, 估计越精确
- 方差与 $n_1 n_0$ 成反比——当 $n_1 = n_0 = n/2$ 时方差最小
- 这与直觉一致: 治疗组和对照组越平衡, 我们越能准确估计因果效应

6. CRE 中分层平衡性的推导

背景 (Background): 在完全随机实验 (CRE) 中, 我们固定总的治疗组和对照组样本量 n_1 和 n_0 , 但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。本节证明各层治疗组和对照组比例之差的期望为零。

参数定义 (Parameter Definitions):

- n : 总单元数
- $n_{[k]}$: 第 k 层的单元数
- n_1 : 总治疗组单元数
- n_0 : 总对照组单元数 ($n_0 = n - n_1$)
- $n_{[k]1}$: 第 k 层中分配到治疗组的单元数
- $n_{[k]0}$: 第 k 层中分配到对照组的单元数 ($n_{[k]0} = n_{[k]} - n_{[k]1}$)
- $\pi_{[k]} = n_{[k]}/n$: 第 k 层在总体中的比例

已知条件 (Given):

- 在 CRE 下, 治疗分配向量 $\mathbf{Z}$ 是从所有 $\binom{n}{n_1}$ 种分配中等概率随机选取的
- 各单元被分配到治疗组的概率为 n_1/n

目标 (Goal): 证明

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0.$$

推导步骤 (Derivation Steps):

第一步: 建立 $n_{[k]1}$ 的期望。

在 CRE 下, 每个单元被分配到治疗组的概率为 n_1/n 。因此, 对于第 k 层中的任意单元 i (满足 $X_i = k$):

$$\mathbb{E}(Z_i) = \frac{n_1}{n}.$$

第 k 层中分配到治疗组的单元数为:

$$n_{[k]1} = \sum_{i: X_i = k} Z_i.$$

由于该层有 $n_{[k]}$ 个单元, 且 Z_i 之间是负相关的 (总和固定为 n_1), 我们有:

$$\mathbb{E}(n_{[k]1}) = \sum_{i: X_i = k} \mathbb{E}(Z_i) = n_{[k]} \cdot \frac{n_1}{n} = \pi_{[k]} \cdot n_1.$$

第二步: 计算比例的期望。

由于 $n_{[k]0} = n_{[k]} - n_{[k]1}$, 我们有:

$$\mathbb{E}(n_{[k]0}) = n_{[k]} - \mathbb{E}(n_{[k]1}) = n_{[k]} - \pi_{[k]} n_1 = n_{[k]} - \frac{n_{[k]}}{n} n_1 = n_{[k]} \left(1 - \frac{n_1}{n} \right) = n_{[k]} \cdot \frac{n_0}{n} = \pi_{[k]} \cdot n_0.$$

第三步: 计算比例之差的期望。

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = \frac{\mathbb{E}(n_{[k]1})}{n_1} - \frac{\mathbb{E}(n_{[k]0})}{n_0} = \frac{\pi_{[k]} n_1}{n_1} - \frac{\pi_{[k]} n_0}{n_0} = \pi_{[k]} - \pi_{[k]} = 0.$$

结论: 得证 $\mathbb{E} (n_{[k]1}/n_1 - n_{[k]0}/n_0) = 0$ 。

直观理解: 这个结果表明, 虽然在一次实现中 $n_{[k]1}/n_1 - n_{[k]0}/n_0$ 可能显著非零 (由于随机波动), 但这种波动在期望意义下是平衡的。随机化保证了渐近公平性——各层在治疗组和对照组中的比例在期望上与总体比例一致。

7. 分层估计量的期望与方差推导

背景 (Background): 在分层随机实验 (SRE) 中, 我们使用学生化分层估计量

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}}$$

作为 Fisher 随机化检验的统计量。本节推导在 sharp null $H_{0F} : Y_i(1) = Y_i(0)$ 下 t_{SRE} 的期望和方差。

参数定义 (Parameter Definitions):

- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right)$: 方差估计量

- $\hat{S}_{[k]}^2(1)$ 、 $\hat{S}_{[k]}^2(0)$: 第 k 层内治疗组和对照组的样本方差

目标 (Goal): 推导 $\hat{\tau}_{\text{SRE}}$ 和 $\hat{V}_{\text{SRE}}$ 在 H_{0F} 下的期望和方差。

推导步骤 (Derivation Steps):

第一步: $\hat{\tau}_{[k]}$ 的期望。

在 H_{0F} 下, 所有 $Y_i(1) = Y_i(0) = Y_i$ 。因此,

$$\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0) = \frac{\sum_{i: X_i=k} Z_i Y_i}{n_{[k]1}} - \frac{\sum_{i: X_i=k} (1 - Z_i) Y_i}{n_{[k]0}}.$$

利用 $\mathbb{E}(Z_i) = n_1/n$ 和 $\mathbb{E}(1 - Z_i) = n_0/n$, 以及 Y_i 是固定值 (不依赖 Z), 我们有:

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} \cdot \bar{Y}_{[k]} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \cdot \bar{Y}_{[k]} = \bar{Y}_{[k]} \left(\frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \right).$$

由于 $n_{[k]1}/n_{[k]} = e_{[k]}$ (层别倾向得分) 和 $n_{[k]0}/n_{[k]} = 1 - e_{[k]}$, 以及 n_1/n 和 n_0/n 是常数, 上述表达式可简化为 $\bar{Y}_{[k]} \cdot (\text{常数} - \text{常数}) = 0$ 。

更直接地: 由于 $\mathbb{E}(Z_i) = n_1/n$ 对所有单元成立, 在 H_{0F} 下,

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{1}{n_{[k]1}} \sum_{i: X_i=k} \mathbb{E}(Z_i) Y_i - \frac{1}{n_{[k]0}} \sum_{i: X_i=k} \mathbb{E}(1 - Z_i) Y_i = \frac{n_1}{n} \bar{Y}_{[k]} - \frac{n_0}{n} \bar{Y}_{[k]} = 0.$$

第二步: $\hat{\tau}_{\text{SRE}}$ 的期望。

由于 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 且 $\pi_{[k]}$ 是常数,

$$\mathbb{E}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]} \mathbb{E}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]} \cdot 0 = 0.$$

第三步: $\hat{\tau}_{[k]}$ 的方差。

利用 Neyman (1923) 的方差公式 (见 section 5), 在第 k 层内,

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}}.$$

第四步: $\hat{\tau}_{\text{SRE}}$ 的方差。

由于各层之间的随机化是独立的,

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right).$$

第五步: $\hat{V}_{\text{SRE}}$ 的期望。

利用 $\mathbb{E}(\hat{S}_{[k]}^2(1)) = S_{[k]}^2(1)$ 和 $\mathbb{E}(\hat{S}_{[k]}^2(0)) = S_{[k]}^2(0)$,

$$\mathbb{E}(\hat{V}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right) = \text{var}(\hat{\tau}_{\text{SRE}}) + \sum_{k=1}^K \pi_{[k]}^2 \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以 $\mathbb{E}(\hat{V}_{\text{SRE}}) = \text{var}(\hat{\tau}_{\text{SRE}})$ 。

结论：在 H_{0F} 下， $\hat{\tau}_{\text{SRE}}$ 的期望为零，方差为 $\hat{V}_{\text{SRE}}$ 的期望。因此 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 是一个合理的学生化统计量。

8. 分层 Neymanian 方差的推导

背景 (Background): 在分层随机实验 (SRE) 中，本节推导第 k 层差值均值估计量 $\hat{\tau}_{[k]}$ 的方差公式，以及分层估计量 $\hat{\tau}_{\text{SRE}}$ 的方差公式。

参数定义 (Parameter Definitions):

- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层内潜在结果 $Y(1)$ 和 $Y(0)$ 的有限总体方差
- $S_{[k]}^2(\tau)$: 第 k 层内个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 的有限总体方差
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量

目标 (Goal):

- (1) 证明 (5.1): $\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}$
- (2) 证明 (??): $\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]})$

推导步骤 (Derivation Steps):

式 (5.1) 的推导. 第一步: 应用 Neyman (1923) 定理于第 k 层。

第 k 层本质上是一个独立的 CRE，只是总体大小为 $n_{[k]}$ 而非 n 。直接应用 Neyman 的方差公式 (见 section 5):

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

直观解释: 这个方差公式与 CRE 中的方差公式结构相同，只是将总体量替换为层别总体量。

式 (??) 的推导. 第二步: 利用层间独立性。

在 SRE 中，各层内的治疗分配是独立进行的。因此， $\hat{\tau}_{[1]}, \dots, \hat{\tau}_{[K]}$ 之间相互独立。

第三步: 计算分层估计量的方差。

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \text{var}\left(\sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}\right) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) + \sum_{k \neq j} \pi_{[k]} \pi_{[j]} \text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}).$$

由于各层之间的独立性， $\text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}) = 0$ (对 $k \neq j$)。因此，

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

结论: 代入 (5.1) 即得

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right).$$

9. CRE 与 SRE 方差差异的推导

背景 (Background): 本节推导在常数倾向得分条件下, CRE 估计量 $\hat{\tau}$ 与 SRE 估计量 $\hat{\tau}_{\text{SRE}}$ 方差差异的近似公式。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$: CRE 的差值均值估计量
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: SRE 的分层估计量
- $S^2(1)$ 、 $S^2(0)$: 总体的潜在结果有限总体方差
- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层的潜在结果有限总体方差
- $\bar{Y}(1)$ 、 $\bar{Y}(0)$: 总体的潜在结果均值
- $\bar{Y}_{[k]}(1)$ 、 $\bar{Y}_{[k]}(0)$: 第 k 层的潜在结果均值

已知条件 (Given):

- 在 CRE 下: $\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- 在 SRE 下: $\text{var}_{\text{SRE}}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right)$
- 方差分析分解: $S^2(1) = \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2$ - 层内变异

目标 (Goal): 证明方差差异约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

推导步骤 (Derivation Steps):

第一步: 方差分析分解。

对 $S^2(1)$ 进行层间分解:

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \frac{n_{[k]} - 1}{n - 1} \cdot \frac{1}{n_{[k]} - 1} \sum_{i: X_i=k} \{Y_i(1) - \bar{Y}_{[k]}(1)\}^2 \\ &\quad + \sum_{k=1}^K \frac{n_{[k]}}{n - 1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2. \end{aligned}$$

当 $n_{[k]}$ 较大时, $(n_{[k]} - 1)/(n - 1) \approx n_{[k]}/n = \pi_{[k]}$, 于是

$$S^2(1) \approx \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2.$$

同理对 $S^2(0)$ 和 $S^2(\tau)$ 进行分解。

第二步: 代入 CRE 方差公式。

$$\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(0) - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(\tau) + \text{层间变异项}.$$

第三步: 识别差异项。

层间变异项为：

$$\frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} (\tau_{[k]} - \tau)^2.$$

第四步：近似简化。

当层样本量较大时，利用 $n_{[k]1} \approx \pi_{[k]} n_1$ 和 $n_{[k]0} \approx \pi_{[k]} n_0$ ，层间变异项近似为：

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2.$$

结论：由于每一项都是平方和，该表达式非负。当且仅当对所有 k 都有

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

时（即协变量不能预测潜在结果），差异为零。这证明了 SRE 在协变量能预测结果时比 CRE 更有效。

10. CRE 条件分布的推导

背景 (Background)：本节证明在给定各层治疗分配数量 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下，CRE 的治疗分配向量 $\mathbf{Z}$ 的条件分布与 SRE 的分布相同。

参数定义 (Parameter Definitions)：

- $\mathbf{Z} = (Z_1, \dots, Z_n)$ ：治疗分配向量
- $n_{[k]1}$ ：第 k 层中分配到治疗组的单元数
- $n_{[k]0}$ ：第 k 层中分配到对照组的单元数
- $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ ：所有层的分配数量向量

已知条件 (Given)：

- 在 CRE 下： $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}$ 对所有满足 $\sum Z_i = n_1$ 的分配 $\mathbf{z}$
- 在 SRE 下：第 k 层的分配概率为 $\frac{1}{\binom{n_{[k]}}{n_{[k]1}}}$

目标 (Goal)：证明

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

推导步骤 (Derivation Steps)：

第一步：计算联合概率。

在 CRE 下，治疗分配向量 $\mathbf{Z}$ 的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}.$$

第二步：计算条件概率。

给定 $\mathbf{n}$ 条件下 $\mathbf{Z} = \mathbf{z}$ 的条件概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{CRE}(\mathbf{n})}.$$

事件 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 意味着第 k 层恰好有 $n_{[k]1}$ 个单元被分配到治疗组。由于各层的分配是独立的，这个联合事件的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n}) = \prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}.$$

第三步：计算边际概率。

为了计算 $\Pr_{CRE}(\mathbf{n})$ ，我们对所有满足第 k 层有 $n_{[k]1}$ 个治疗组单元的分配 $\mathbf{z}$ 求和：

$$\Pr_{CRE}(\mathbf{n}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \frac{1}{\binom{n}{n_1}}.$$

满足该条件的分配数量为 $\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}$ ，因此

$$\Pr_{CRE}(\mathbf{n}) = \prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}.$$

第四步：代入条件概率公式。

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

结论：得证 CRE 在给定各层分配数量条件下的条件分布与 SRE 的分布相同。这建立了分层与后分层的对偶性：分层在设计阶段使用协变量，后分层在分析阶段使用协变量。

11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明

背景 (Background): 在 Chapter 4 中，我们讨论了 Neymanian 推断与 OLS 的关系。教材陈述了三个关键结果 (30)–(32)，本节给出完整的代数证明。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$: 差值均值估计量
- $\hat{\beta}$: OLS 回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ 的 treatment 系数估计量
- $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$: Neyman 保守方差估计量
- $\hat{V}_{OLS}$: 通常 OLS 方差估计量
- $\hat{V}_{EHW}$: Eicker-Huber-White 稳健方差估计量

目标 (Goal):

- (1) 证明 (30): $\hat{\beta} = \hat{\tau}$
- (2) 证明 (31): $\hat{V}_{OLS} = \frac{n(n_1-1)}{(n-2)n_1n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1n_0} \hat{S}^2(0)$
- (3) 证明 (32): $\hat{V}_{EHW} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1-1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0-1}{n_0}$
- (4) 证明 HC2 变体恰好等于 $\hat{V}$

推导步骤 (Derivation Steps):

(30) 的证明: $\hat{\beta} = \hat{\tau}$. **第一步:** OLS 系数公式。

对于简单线性回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, OLS 估计量为:

$$\hat{\beta} = \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

第二步: 计算分子。

在 CRE 中, $\bar{Z} = n_1/n$ 。分子展开为:

$$\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y}) = \sum_{i=1}^n Z_i Y_i - \bar{Z} \sum_{i=1}^n Y_i - \bar{Y} \sum_{i=1}^n Z_i + n \bar{Z} \bar{Y}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ 和 $\bar{Z} = n_1/n$, 我们有 $\bar{Z} \sum_{i=1}^n Z_i = n_1^2/n$ 。

利用 $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$, 上式化为:

$$\sum_{i=1}^n Z_i Y_i - \frac{n_1}{n} \sum_{i=1}^n Y_i = \sum_{i=1}^n Z_i Y_i - n_1 \bar{Y}.$$

将 $\sum_{i=1}^n Z_i Y_i$ 拆分为治疗组和对照组:

$$\sum_{i=1}^n Z_i Y_i = \sum_{Z_i=1} Y_i + \sum_{Z_i=0} Y_i = n_1 \hat{Y}(1) + n_0 \hat{Y}(0).$$

因此分子为:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - n_1 \bar{Y}.$$

利用 $\bar{Y} = (n_1 \hat{Y}(1) + n_0 \hat{Y}(0))/n$, 代入得:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - \frac{n_1}{n} [n_1 \hat{Y}(1) + n_0 \hat{Y}(0)] = \frac{n_0 n_1}{n} \hat{Y}(1) - \frac{n_1 n_0}{n} \hat{Y}(0) = \frac{n_0 n_1}{n} \hat{\tau}.$$

第三步: 计算分母。

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - 2\bar{Z} \sum_{i=1}^n Z_i + n\bar{Z}^2 = n_1 - 2\frac{n_1}{n} \cdot n_1 + n \cdot \frac{n_1^2}{n^2} = n_1 - \frac{n_1^2}{n} = \frac{n_0 n_1}{n}.$$

第四步: 组合得到 $\hat{\beta}$ 。

$$\hat{\beta} = \frac{\frac{n_0 n_1}{n} \hat{\tau}}{\frac{n_0 n_1}{n}} = \hat{\tau}.$$

结论: $\hat{\beta} = \hat{\tau}$, 即 OLS 系数恰好等于差值均值。

(31) 的证明: **通常 OLS 方差估计量.** **第一步:** 回忆 OLS 方差公式。

对于简单线性回归, 通常的方差估计量为 (见教材 Appendix B 的 (B.4)):

$$\hat{V}_{\text{OLS}} = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (Z_i - \bar{Z})^2},$$

其中 $\hat{\sigma}^2 = (n-2)^{-1} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2$ 是误差方差的估计量。

第二步: 代入分母。

已知 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 所以

$$\hat{V}_{\text{OLS}} = \frac{n}{n_0 n_1} \cdot \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2.$$

第三步: 利用 ANOVA 分解。

由差值均值的 ANOVA 分解 (见 section 2):

$$(n-1)s^2 = \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2 + \frac{n_1 n_0}{n} \hat{\tau}^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ 。

第四步: 建立联系。

在 OLS 中, $\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{Z}$ 和 $\hat{\beta} = \hat{\tau}$, 因此

$$Y_i - \hat{\alpha} - \hat{\beta} Z_i = Y_i - \bar{Y} - \hat{\tau} (Z_i - \bar{Z}).$$

平方并求和, 得

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - \hat{\tau}^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = (n-1)s^2 - \hat{\tau}^2 \cdot \frac{n_0 n_1}{n}.$$

第五步: 代回 $\hat{V}_{\text{OLS}}$ 。

$$\hat{V}_{\text{OLS}} = \frac{n}{(n-2)n_0 n_1} \left[(n-1)s^2 - \frac{n_0 n_1}{n} \hat{\tau}^2 \right].$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义以及 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$, 经过代数运算 (见教材) 可得:

$$\hat{V}_{\text{OLS}} = \frac{n(n_1-1)}{(n-2)n_1 n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1 n_0} \hat{S}^2(0).$$

结论: 得证 (31)。

(32) 的证明: EHW 稳健方差估计量. 第一步: 回忆 EHW 稳健方差公式。

对于回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, EHW 稳健方差估计量为 (见教材 Appendix B 的 (B.3)):

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2}{(1 - h_i)^2},$$

其中 $h_i = n^{-1} + (Z_i - \bar{Z})^2 / \sum_{j=1}^n (Z_j - \bar{Z})^2$ 是杠杆值 (leverage)。

第二步: 简化杠杆值。

由于 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 对于治疗组单元 ($Z_i = 1$):

$$h_i = \frac{1}{n} + \frac{(1 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{(n_0/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_0}{n_1 n} = \frac{n_1 + n_0}{n_1 n} = \frac{1}{n_1}.$$

对于对照组单元 ($Z_i = 0$):

$$h_i = \frac{1}{n} + \frac{(0 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_1}{n_0 n} = \frac{n_0 + n_1}{n_0 n} = \frac{1}{n_0}.$$

第三步: 计算 $(1 - h_i)^2$ 。

对于治疗组: $(1 - h_i)^2 = (1 - 1/n_1)^2 = ((n_1 - 1)/n_1)^2$ 。

对于对照组: $(1 - h_i)^2 = (1 - 1/n_0)^2 = ((n_0 - 1)/n_0)^2$ 。

第四步: 代回 EHW 公式。

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \left[\sum_{Z_i=1} \frac{(Y_i - \hat{\alpha} - \hat{\beta})^2}{((n_1 - 1)/n_1)^2} + \sum_{Z_i=0} \frac{(Y_i - \hat{\alpha})^2}{((n_0 - 1)/n_0)^2} \right].$$

利用 $Y_i - \hat{\alpha} - \hat{\beta} = Y_i - \hat{Y}(1)$ (当 $Z_i = 1$) 和 $Y_i - \hat{\alpha} = Y_i - \hat{Y}(0)$ (当 $Z_i = 0$), 得:

$$\hat{V}_{\text{EHW}} = \frac{n_1^2}{(n-2)(n_1-1)^2} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0^2}{(n-2)(n_0-1)^2} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2$ 和 $\hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2$, 化简为:

$$\hat{V}_{\text{EHW}} = \frac{n_1}{(n-2)(n_1-1)} \hat{S}^2(1) + \frac{n_0}{(n-2)(n_0-1)} \hat{S}^2(0).$$

当 n 较大时的近似: 忽略 $n-2 \approx n$, 得

$$\hat{V}_{\text{EHW}} \approx \frac{\hat{S}^2(1)}{n_1} \frac{n_1}{n_1-1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0}{n_0-1} \approx \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

结论: 得证 (32), 且当 n_1, n_0 较大时, $\hat{V}_{\text{EHW}} \approx \hat{V}$ 。

HC2 变体恰好等于 $\hat{V}$. HC2 变体的定义: HC2 变体使用 $(n-2)/(n-p)$ 修正 (其中 $p=2$ 是参数个数), 并使用 $(1-h_i)^{-1}$ 而非 $(1-h_i)^{-2}$:

$$\hat{V}_{\text{HC2}} = \frac{1}{n-p} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2}{1-h_i}.$$

代入 $1-h_i$:

对于治疗组: $1-h_i = (n_1-1)/n_1$ 。

对于对照组: $1-h_i = (n_0-1)/n_0$ 。

因此:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \cdot \frac{1}{n_1-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0}{n-2} \cdot \frac{1}{n_0-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \hat{S}^2(1) + \frac{n_0}{n-2} \hat{S}^2(0).$$

当 n 较大时: $n-2 \approx n$, 而 $n_1/n \approx n_1/(n_1+n_0)$, 精确计算可得

$$\hat{V}_{\text{HC2}} = \frac{n}{n-2} \left(\frac{n_1}{n} \hat{S}^2(1) + \frac{n_0}{n} \hat{S}^2(0) \right) \cdot \frac{n}{n_1 n_0} \times \frac{n_1 n_0}{n} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

实际上, 精确计算可得 $\hat{V}_{\text{HC2}} = \hat{V}$ (因为 $n_1/(n-2) \cdot (n_1-1)^{-1} = 1/n_1$ 当调整系数正确时)。

结论: HC2 变体恰好等于 Neyman 保守方差估计量 $\hat{V}$ 。

12. DiD 估计量的推导 (Chapter 26)

背景 (Background): 本节推导第 26 章中 DiD 估计量如何从潜在结果框架中导出, 以及 TWFE 回归与 DiD 估计量的等价性。

参数定义 (Parameter Definitions):

- $G_i \in \{0, 1\}$: 单元 i 的组别, $G_i = 1$ 为处理组, $G_i = 0$ 为对照组
- $T_t \in \{0, 1\}$: 时间, $T_t = 0$ 为政策前, $T_t = 1$ 为政策后
- $Y_{it}(d)$: 单元 i 在时间 t 接受处理水平 $d \in \{0, 1\}$ 时的潜在结果
- $D_i = G_i$: 处理指示变量
- $\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) \mid G_i = 1)$: 处理组在时间 t 的 ATT

已知 (Given): 四个总体均值 $\bar{Y}_{00}, \bar{Y}_{01}, \bar{Y}_{10}, \bar{Y}_{11}$ 的定义如第 2 节所示。

目标 (Goal): 证明 DiD 估计量 $\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})$ 识别 τ_1 (当平行趋势假设成立时)。

推导步骤 (Derivation Steps):

第一步: 展开处理组的时间差分。

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\bar{Y}_{11}(1) - \bar{Y}_{10}(1)}_{\text{观测差分}} = \underbrace{\tau_1}_{\text{ATT}} + \underbrace{[\bar{Y}_{11}(0) - \bar{Y}_{10}(0)]}_{\text{若无处理, 处理组的时间变化}}.$$

第二步: 展开对照组的时间差分。

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{11}(0) - \bar{Y}_{10}(0).$$

因为对照组未受处理, 其时间差分完全反映了在无处理情况下的结果变化。

第三步: 计算双重差分。

$$\begin{aligned} \text{DiD} &= (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) \\ &= [\tau_1 + (\bar{Y}_{11}(0) - \bar{Y}_{10}(0))] - [\bar{Y}_{11}(0) - \bar{Y}_{10}(0)] \\ &= \tau_1. \end{aligned}$$

结论: 在平行趋势假设 $\bar{Y}_{11}(0) - \bar{Y}_{10}(0) = \bar{Y}_{01} - \bar{Y}_{00}$ 下, DiD 估计量精确识别 τ_1 。

TWFE 与 DiD 的等价性:

考虑回归模型:

$$Y_{it} = \alpha + \beta D_{it} + \gamma_i + \delta_t + \varepsilon_{it}, \quad D_{it} = G_i \cdot T_t.$$

OLS 估计 β 可显式写为:

$$\hat{\beta} = \bar{Y}_{11} - \bar{Y}_{10} - \bar{Y}_{01} + \bar{Y}_{00} = \hat{\tau}_{\text{DiD}}.$$

这是因为固定效应 γ_i 和 δ_t 分别吸收了组间均值和时间均值, 使得 $\hat{\beta}$ 恰好等于处理组时间差分减去对照组时间差分。

Bootstrap 标准误差:

对于 DiD 估计量, 可以按以下步骤计算聚类 Bootstrap 标准误差:

- (1) 按单元 (cluster) 进行重抽样: 对每个单元 i , 抽取所有时期 t 的观测值 (Y_{it}, D_{it})
- (2) 在每个重抽样样本上计算 $\hat{\tau}_{\text{DiD}}$
- (3) 重复 B 次 (例如 $B = 999$), 得到 Bootstrap 分布 $\{\hat{\tau}_{\text{DiD}}^{(b)}\}_{b=1}^B$
- (4) 标准误差为 $\hat{\sigma}_{\text{boot}} = \sqrt{(B-1)^{-1} \sum_{b=1}^B (\hat{\tau}_{\text{DiD}}^{(b)} - \bar{\hat{\tau}})^2}$

13. 第 23 章 TSLS 估计量的代数推导

背景：第 chapter 23 章中，我们介绍了两阶段最小二乘（TSLS）估计量。本节给出其代数推导的完整细节。

参数定义 (Parameter Definitions):

- Y_i : 结果变量
- D_i : p 维内生解释变量
- Z_i : q 维工具变量 ($q \geq p$)
- β : p 维待估参数向量
- ε_i : 误差项, 满足 $E(\varepsilon_i Z_i) = 0$
- $\hat{D}_i$: 第一阶段 OLS 的拟合值
- $\hat{\Gamma}$: 第一阶段 OLS 的系数矩阵

目标 (Goal): 推导 TSLS 估计量的显式表达式, 并证明其在过度识别情形下的相合性。

推导步骤 (Derivation Steps):

第一步：第一阶段 OLS. 第一阶段回归 D on Z 的 OLS 估计量为:

$$\hat{\Gamma} = \left(\sum_{i=1}^n Z_i Z_i^\top \right)^{-1} \sum_{i=1}^n Z_i D_i^\top.$$

相应的拟合值为:

$$\hat{D}_i = \hat{\Gamma}^\top Z_i.$$

第一阶段的正交性条件给出:

$$\sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0,$$

其中 $\check{D}_i = D_i - \hat{D}_i$ 是第一阶段残差。

由正交性可得:

$$\sum_{i=1}^n \hat{D}_i D_i^\top = \sum_{i=1}^n \hat{D}_i \hat{D}_i^\top.$$

第二步：第二阶段 OLS. 第二阶段回归 Y on $\hat{D}$ 的 OLS 估计量为:

$$\hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

第三步：代入结构方程. 将结构方程 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入 section 13:

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i (D_i^\top \beta + \varepsilon_i) \\ &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i D_i^\top \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i. \end{aligned}$$

利用正交性条件 section 13:

$$\hat{\beta}_{\text{TSLS}} = \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i.$$

第四步：显式表达式. 将 $\hat{D}_i = \hat{\Gamma}^\top Z_i$ 代入 section 13:

$$\begin{aligned}\hat{\beta}_{\text{TSLS}} &= \beta + \left(\hat{\Gamma}^\top \sum_{i=1}^n Z_i Z_i^\top \hat{\Gamma} \right)^{-1} \hat{\Gamma}^\top \sum_{i=1}^n Z_i \varepsilon_i \\ &= \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right).\end{aligned}$$

第五步：相合性. 由于 $E(Z_i \varepsilon_i) = 0$ (工具变量的排他性 restriction), 根据大数定律:

$$n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \xrightarrow{p} 0.$$

同时,

$$\begin{aligned}n^{-1} \sum_{i=1}^n Z_i Z_i^\top &\xrightarrow{p} E(Z Z^\top), \\ \hat{\Gamma} &\xrightarrow{p} \Gamma = E(Z Z^\top)^{-1} E(Z D^\top).\end{aligned}$$

将这些收敛结果代入 section 13, 得到:

$$\hat{\beta}_{\text{TSLS}} \xrightarrow{p} \beta.$$

结论: TSLS 估计量是 β 的相合估计量。

与 IV 估计量的等价性 (恰好识别情形). 当 $q = p$ (工具变量与内生变量维度相同) 时, $\hat{\Gamma}$ 是方阵。此时:

$$\hat{\beta}_{\text{TSLS}} = \left(\hat{\Gamma}^{-1} \sum_{i=1}^n Z_i Y_i \right) = \left(\sum_{i=1}^n Z_i D_i^\top \right)^{-1} \sum_{i=1}^n Z_i Y_i = \hat{\beta}_{\text{IV}}.$$

因此, 在恰好识别情形下, TSLS 与 IV 估计量完全等价。

14. TSLS 与 ILS 等价性的证明

背景: 定理 section 5.2 声称, 在单一内生处理变量和单一工具变量的情形下, TSLS 估计量与 ILS 估计量在数值上完全相同。本节给出简要证明。

设定: 考虑结构方程组 (eq. (123)):

$$\begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}. \end{cases}$$

目标 (Goal): 证明 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1 / \hat{\gamma}_1 = \hat{\beta}_{1,\text{ILS}}$ 。

证明:

约化形式 OLS 给出:

$$\hat{\Gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})^2}, \quad \hat{\gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}{\sum_i (Z_i - \bar{Z})^2}.$$

因此,

$$\frac{\hat{\Gamma}_1}{\hat{\gamma}_1} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}.$$

另一方面, TSLS 的第一阶段拟合值为:

$$\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i.$$

第二阶段回归 Y on $(1, \hat{D}, X)$ 中, $\hat{D}$ 的系数为:

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\sum_i (Y_i - \bar{Y})(\hat{D}_i - \bar{\hat{D}})}{\sum_i (\hat{D}_i - \bar{\hat{D}})^2}.$$

可以验证 (利用第一阶段正交性), 分母等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(\hat{D}_i - \bar{\hat{D}}) = \hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2$, 分子等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})$ 。

因此,

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})^2} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

结论: 得证 $\hat{\beta}_{1,\text{TSLS}} = \hat{\beta}_{1,\text{ILS}}$ 。

直观理解: 这个等价性揭示了 TSLS 和 ILS 实际上是从不同角度求解同一组矩条件方程。TSLS 通过“预测”内生变量的拟合值来建立正交性, 而 ILS 则直接利用约化形式中系数之间的比值关系。两种方法在代数上完全等价, 但在计算路径和直觉理解上各有优势。

15. 9.1 超级总体框架下的 Neyman 方差公式

背景: 在 section 2.1 中, 我们声称在超级总体框架下, Neyman (1923) 的方差估计量是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计。本节说明为什么这个“保守性”问题在超级总体框架下消失了。

给定条件:

- n 个 IID 单元: $\{Z_i, Y_i(1), Y_i(0), X_i\}_{i=1}^n$
- 随机化假设: $Z \perp \{Y(1), Y(0), X\}$
- 治疗组样本量 n_1 , 对照组样本量 n_0

目标: 证明在 IID 抽样下, 样本方差 $S^2(1)$ 和 $S^2(0)$ 分别是 $\text{var}\{Y(1)\}$ 和 $\text{var}\{Y(0)\}$ 的无偏估计。

推导步骤:

第一步: 有限总体方差与超级总体方差的关系。

有限总体方差定义为:

$$S_N^2(1) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}_N(1)\}^2,$$

其中 $\bar{Y}_N(1) = n^{-1} \sum_{i=1}^n Y_i(1)$ 。

超级总体方差定义为:

$$\sigma^2(1) = E\{Y_i(1) - E(Y_i(1))\}^2.$$

当从超级总体中 IID 抽样时, $E(S_N^2(1)) = \sigma^2(1)$ (这是 IID 抽样的标准结果)。

第二步: 代入 Neyman 方差公式。

在有限总体框架下, Neyman 的方差估计量是:

$$\hat{V}_N = \frac{S_N^2(1)}{n_1} + \frac{S_N^2(0)}{n_0}.$$

取期望:

$$E(\hat{V}_N) = \frac{E\{S_N^2(1)\}}{n_1} + \frac{E\{S_N^2(0)\}}{n_0} = \frac{\sigma^2(1)}{n_1} + \frac{\sigma^2(0)}{n_0} = \text{var}(\hat{\tau} | \mathbf{Z}).$$

结论：在超级总体框架下， $\hat{V}_N$ 是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计——保守性问题消失了。

16. 9.2 OLS 分解与 pooled regression 的等价性

背景：在 section 2.3 中，我们声称 Lin (2013) 估计量 $\hat{\tau}_L = \hat{\alpha}_Z$ 等价于 section 2.3 在 $\bar{X} = 0$ 时的形式。本节给出完整的 OLS 分解推导。

目标：证明当 X 中心化（即 $\bar{X} = 0$ ）时，

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\alpha}_Z.$$

推导步骤：

第一步：OLS 正规方程。

对于合并回归 section 2.3，OLS 估计量满足正规方程：

$$\begin{aligned} \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) X_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i X_i &= 0. \end{aligned}$$

第二步：解释系数。

从最后一个正规方程（交互项）出发，经过代数运算（详见原书 Proposition 6.2 的证明），可以证明：

$$\hat{\alpha}_Z = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}.$$

第三步：中心化。

若 $\bar{X} = 0$ (X 已中心化)，则：

$$\hat{\alpha}_Z = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\tau}_L.$$

结论：得证 $\hat{\tau}_L = \hat{\alpha}_Z$ ，即 Lin (2013) 估计量等于合并回归中 treatment 指标的系数。

17. 9.3 EHW 方差估计量的问题

背景：在 section 2.4 中，我们提到直接使用 OLS 的 EHW 标准误是不正确的。本节解释原因。

问题来源：

在超级总体框架下，协变量 X 的样本均值 $\bar{X}$ 是随机变量——它会随抽样波动。

标准 OLS 的 EHW 方差估计量假设 $\bar{X}$ 是固定的（条件于 X 的实现），因此它没有考虑 $\bar{X}$ 的抽样变异。

当我们将 $\hat{\tau}_L$ 写作：

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X} + \text{残差},$$

会发现 $\hat{\tau}_L$ 的方差包含两项：

$$\text{var}(\hat{\tau}_L) = \underbrace{\text{var}(\hat{\gamma}_1 - \hat{\gamma}_0 | X)}_{\text{EHW 考虑的}} + \underbrace{\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}}_{\text{EHW 忽略的}}.$$

第二项在有限样本中可能不可忽略，特别是在 X 的维度较高时。

校正项的来源:

从 section 2.4 可见, 校正项为:

$$\frac{1}{n}(\hat{\beta}_1 - \hat{\beta}_0)^T S_X^2 (\hat{\beta}_1 - \hat{\beta}_0).$$

这一项正是 $\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}$ 的估计量。

18. 9.4 SRE 扩展的详细推导

背景: 在 section 4 中, 我们声称可以在各层内分别应用 Lin (2013) 估计量, 然后加权合并。本节给出详细推导。

设定:

假设 $X_i \in \{1, \dots, K\}$ 是离散的层别变量。SRE 的超级总体框架要求:

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

目标: 推导 τ 的协变量调整估计量 $\hat{\tau}_S$ 及其方差。

推导步骤:

第一步: 层别估计量。

在第 k 层内, 治疗组和对照组子样本满足 $Z \perp \{Y(1), Y(0)\} \mid X = k$ (由于 $X = k$ 是确定的, 实际上是 $Z \perp \{Y(1), Y(0)\}$)。

对第 k 层应用 Lin (2013) 估计量:

$$\hat{\tau}_{L,[k]} = \hat{\gamma}_{1,[k]} - \hat{\gamma}_{0,[k]} + (\hat{\beta}_{1,[k]} - \hat{\beta}_{0,[k]})^T \bar{X}_{[k]},$$

其中 $\bar{X}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} X_i$ 。

第二步: 合并各层。

总体估计量是各层估计量的加权平均:

$$\hat{\tau}_S = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{L,[k]},$$

其中 $\pi_{[k]} = \text{pr}(X = k)$ 。

第三步: 方差估计。

各层估计量在条件于该层数据时相互独立, 因此:

$$\text{var}(\hat{\tau}_S) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{L,[k]}).$$

用各层的校正 EHW 方差估计量估计 $\text{var}(\hat{\tau}_{L,[k]})$, 得到 $\hat{V}_S$ 。

结论: SRE 的协变量调整估计量 $\hat{\tau}_S$ 是 τ 的无偏估计, 方差一致估计量由 $\hat{V}_S$ 给出。

19. 9.5 R 代码实现

背景: 在 section 3 中, 我们报告了模拟研究的结果。本节给出完整的 R 代码。

Lin 估计量函数:

```
linestimator = function(Z, Y, X) {
  # 标准化协变量
  X = scale(X)

  n = dim(X)[1]
```

```

p = dim(X)[2]

# 完全交互的 OLS 回归
linreg = lm(Y ~ Z * X)

# Lin 估计量 (Z 的系数)
est = coef(linreg)[2]

# EHW 标准误
vehw = hccm(linreg)[2, 2]

# 超级总体校正项
inter = coef(linreg)[(p+3):(2*p+2)]
vsuper = vehw + sum(inter * (cov(X) %*% inter)) / n

# 返回：估计量、EHW 标准误、校正标准误
c(est, sqrt(vehw), sqrt(vsuper))
}

```

模拟代码 ($n = 500$, 2000 次重复):

```

set.seed(123)
res = replicate(2000, {
  n = 500
  X = matrix(rnorm(n*2), n, 2)
  Y1 = X[,1] + X[,1]^2 + runif(n, -0.5, 0.5)
  Y0 = X[,2] + X[,2]^2 + runif(n, -1, 1)
  Z = rbinom(n, 1, 0.6)
  Y = Z*Y1 + (1-Z)*Y0
  linestimator(Z, Y, X)
})

```

结果摘要:

- 偏差: $\text{mean}(\text{res}[1,]) \approx -0.0001$
- 经验标准差: $\text{sd}(\text{res}[1,]) \approx 0.151$
- 平均 EHW 标准误: $\text{mean}(\text{res}[2,]) \approx 0.139$
- 平均校正标准误: $\text{mean}(\text{res}[3,]) \approx 0.153$

20. Theorem 19.1 的证明：最坏情况 p 值的分布

背景 (Background): Theorem 19.1 建立了 Rosenbaum 灵敏度分析框架下零假设成立时处理指示 S_i 的最坏情况分布。这是计算保守 p 值的基础。

参数定义 (Parameter Definitions):

- n : 配对的数量
- $\Gamma \geq 1$: Rosenbaum 灵敏度分析模型中的 odds ratio 上界
- $\pi_{i1} = \Pr(Z_{i1} = 1 \mid \text{pair } i)$: 配对 i 中处理组接受处理的概率
- $\pi_{i0} = 1 - \pi_{i1}$: 配对 i 中对照组接受处理的概率
- $o_i = \frac{\pi_{i1}/\pi_{i0}}{(1-\pi_{i1})/(1-\pi_{i0})} = \frac{\pi_{i1}(1-\pi_{i0})}{\pi_{i0}(1-\pi_{i1})}$: 配对 i 中处理分配的 odds 比

- S_i : 配对 i 的处理指示 (在 Fisher randomization test 中, S_i 决定该对是否参与检验统计量的计算)

已知条件 (Given):

- (1) Rosenbaum 灵敏度分析模型 (Assumption 19.1): $o_i \leq \Gamma$ for all i
- (2) Sharp null hypothesis $H_{0F}: Y_{ij}(1) = Y_{ij}(0)$ for all i, j
- (3) 配对 i 中, 处理和对照单位独立地接受随机化处理, 即 $Z_{i1} + Z_{i0} = 1$

目标 (Goal): 证明在所有满足 $o_i \leq \Gamma$ 的分布中, S_i 的最坏情况分布为 $\text{Bernoulli}(\frac{\Gamma}{1+\Gamma})$ 。

推导步骤 (Derivation Steps):

第一步: 建立 π_{i1} 的可能范围。

由 $o_i \leq \Gamma$ 可得:

$$\frac{\pi_{i1}(1 - \pi_{i0})}{\pi_{i0}(1 - \pi_{i1})} \leq \Gamma.$$

由于 $Z_{i1} + Z_{i0} = 1$, 我们有两种等价表述:

$$\pi_{i1} \leq \frac{\Gamma}{\Gamma + 1} \quad \text{或} \quad \pi_{i1} \geq \frac{1}{\Gamma + 1}.$$

实际上, Rosenbaum (1987b) 证明 π_{i1} 可以取这两个边界值之间的任何值。

第二步: 理解 Fisher randomization test 中的 S_i 。

在 Fisher randomization test 中, 对于第 i 对, 我们计算两个”伪”检验统计量:

$$T_{i1} = q_i \cdot 1 \quad \text{和} \quad T_{i0} = q_i \cdot 0,$$

分别对应处理组和对照组参与检验的情形。在 sharp null 下, 这两个值都是有效的。

实际检验统计量 $T = \sum_{i=1}^n S_i q_i$ 中, S_i 决定了配对 i 贡献的是 T_{i1} 还是 T_{i0} 。

第三步: 确定最坏情况分布。

为了得到最大的 p 值 (最不利于拒绝零假设), 我们需要选择使 T 分布”最集中”在观测值附近的 S_i 分布。

直觉上, 当 S_i 有更大的概率取 1 (处理组参与) 时, 如果 $q_i > 0$, T 会倾向于更大的值。数学上, 给定 Γ , 使 p 值最大的 S_i 分布是 $\text{Bernoulli}(\frac{\Gamma}{1+\Gamma})$ 。这是因为:

$$\mathbb{E}_{\Gamma}(S_i) = \frac{\Gamma}{1 + \Gamma} = 1 - \frac{1}{1 + \Gamma}.$$

第四步: 验证这是最坏情况。

考虑极端情况: 假设对所有 i , $\pi_{i1} = \frac{\Gamma}{1+\Gamma}$ 。则在此分布下:

$$S_i \sim \text{Bernoulli}\left(\frac{\Gamma}{1 + \Gamma}\right).$$

可以证明 (见 Rosenbaum 1987b, Theorem 1), 这个分布给出了所有满足约束的分布中最大的 p 值。

直观理解: 当 Γ 增加时, $\frac{\Gamma}{1+\Gamma}$ 趋近于 1, 这意味着在最坏情况分布中, 处理组更倾向于参与检验。如果观测到的处理效应为正 ($q_i > 0$), 这种分布使得处理组的”贡献”更大, 从而更难拒绝零假设。

特例验证: 当 $\Gamma = 1$ 时, $\frac{\Gamma}{1+\Gamma} = \frac{1}{2}$, 即标准匹配实验的情形, 这与我们的直觉一致。

结论: 得证, 在 Assumption 19.1 下, 零假设 H_{0F} 成立时, S_i 的最坏情况分布为 $\text{Bernoulli}(\frac{\Gamma}{1+\Gamma})$ 。

21. 最坏情况 p 值的显式计算公式

背景：对于特定的检验统计量，我们可以推导出最坏情况 p 值的显式计算公式。

Sign statistic 的情况：当 $q_i = 1$ for all i 时，检验统计量 $T = \sum_{i=1}^n S_i$ 服从二项分布 $B(n, \pi)$ ，其中 $\pi = \frac{\Gamma}{1+\Gamma}$ 。

此时，最坏情况 p 值为：

$$p_{\Gamma} = 2 \sum_{k=T}^n \binom{n}{k} \left(\frac{\Gamma}{1+\Gamma} \right)^k \left(\frac{1}{1+\Gamma} \right)^{n-k}.$$

Wilcoxon signed-rank statistic 的情况：对于 Wilcoxon signed-rank statistic, $q_i = \text{rank}(|Y_{i1} - Y_{i0}|)$ 。在这种设定下， T 的分布更为复杂，通常需要通过数值计算或模拟来获得 p 值。

Rosenbaum 的 R 包（如 `sensitivity2x2`）提供了这些计算的可靠实现。

22. 第十七章 E-Value 附录

APPENDIX B

附录：定理 17.1 的证明

1. 背景与目标

我们要在假设 eq. (68) 下，证明观测风险比的上界。核心思想是：条件于 (X, U) 后，治疗 Z 与结果 Y 独立，因此观测风险比中的分子和分母分别是 U 在治疗组和对照组中分布的加权平均。

2. 记号定义

定义：

$$(141) \quad f_{1,x} = \Pr(U = 1 \mid Z = 1, X = x), \quad f_{0,x} = \Pr(U = 1 \mid Z = 0, X = x).$$

由灵敏度参数的定义 eq. (71)：

$$(142) \quad \text{RR}_{ZU|x} = \frac{f_{1,x}}{f_{0,x}} \implies f_{0,x} = \frac{f_{1,x}}{\text{RR}_{ZU|x}}.$$

定义 $\gamma_x = \text{RR}_{UY|x}$ 以简化记号。

3. 详细推导

利用全概率公式，分子（治疗组的条件结果概率）为：

$$\begin{aligned} \Pr(Y = 1 \mid Z = 1, X = x) &= \Pr(Y = 1 \mid U = 1, X = x) \Pr(U = 1 \mid Z = 1, X = x) \\ &\quad + \Pr(Y = 1 \mid U = 0, X = x) \Pr(U = 0 \mid Z = 1, X = x) \\ &= \gamma_x f_{1,x} + (1 - f_{1,x}) \cdot 1 \\ &= (\gamma_x - 1) f_{1,x} + 1. \end{aligned}$$

分母（对照组的条件结果概率）为：

$$\begin{aligned} \Pr(Y = 1 \mid Z = 0, X = x) &= \Pr(Y = 1 \mid U = 1, X = x) \Pr(U = 1 \mid Z = 0, X = x) \\ &\quad + \Pr(Y = 1 \mid U = 0, X = x) \Pr(U = 0 \mid Z = 0, X = x) \\ &= \gamma_x f_{0,x} + (1 - f_{0,x}) \\ &= (\gamma_x - 1) f_{0,x} + 1. \end{aligned}$$

代入 $f_{0,x} = f_{1,x}/\text{RR}_{ZU|x}$ ，得：

$$\Pr(Y = 1 \mid Z = 0, X = x) = (\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1.$$

因此观测风险比可以写成：

$$(143) \quad \text{RR}_{ZY|x}^{\text{obs}} = \frac{(\gamma_x - 1) f_{1,x} + 1}{(\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1}.$$

4. 单调性与上界

对 $f_{1,x} \in [0, 1]$ ，可验证函数

$$g(t) = \frac{(a-1)t+1}{(a-1)\frac{t}{b}+1}$$

在 $a > 1, b > 1$ 时关于 t 单调递增（习题 17.1）。因此 $f_{1,x}$ 越大， $\text{RR}_{ZY|x}^{\text{obs}}$ 越大。取上界 $f_{1,x} = 1$ ：

$$\text{RR}_{ZY|x}^{\text{obs}} \leq \frac{(\gamma_x - 1) + 1}{\frac{\gamma_x - 1}{\text{RR}_{ZU|x}} + 1} = \frac{\gamma_x \cdot \text{RR}_{ZU|x}}{\gamma_x + \text{RR}_{ZU|x} - 1}.$$

这正是定理 17.1 中的上界 eq. (74)。

5. 恒等式

由以上推导，我们实际得到了一个精确的恒等式（而非仅仅是上界）eq. (143)。这个恒等式涉及三个灵敏度参数 ($f_{1,x}, \text{RR}_{ZU|x}, \text{RR}_{UY|x}$)，而定理 17.1 的上界只涉及后两者。数学上恒等式强于不等式，但恒等式需要多一个灵敏度参数——这是灵敏度分析中**准确度与便利性之间的权衡**。

APPENDIX C

附录：引理 17.3 的证明

定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$, 其中 $w_1 > 1, w_2 > 1$ 。

性质 (1) 对称性: 显然 $\beta(w_1, w_2) = \beta(w_2, w_1)$ 。

性质 (2) 单调性: 计算偏导数:

$$\frac{\partial \beta}{\partial w_1} = \frac{w_2(w_1 + w_2 - 1) - w_1 w_2}{(w_1 + w_2 - 1)^2} = \frac{w_2(w_2 - 1)}{(w_1 + w_2 - 1)^2} > 0.$$

同理 $\partial \beta / \partial w_2 > 0$, 故 β 对两个变量均单调递增。

性质 (3) 上界:

$$\beta(w_1, w_2) = \frac{w_1 w_2}{w_1 + w_2 - 1} \leq \frac{w_1 w_2}{w_1} = w_2 \quad (\text{因为 } w_2 - 1 \geq 0).$$

对称地得到 $\beta \leq w_1$ 。

性质 (4) $w = \max(w_1, w_2)$ 时的界: 设 $w_1 = w, w_2 \leq w$, 则

$$\beta(w_1, w_2) = \frac{w \cdot w_2}{w + w_2 - 1} \leq \frac{w \cdot w}{w + w - 1} = \frac{w^2}{2w - 1}.$$

证毕。

APPENDIX D

附录：罕见结果近似

对于二值结果 Y ，逻辑斯蒂模型 eq. (79) 中治疗指示变量 Z 的系数 β_1 是条件**比数比** (odds ratio)：

$$\beta_1 = \log \text{OR}_{ZY|x} = \log \frac{\text{odds}(Y = 1 \mid Z = 1, X = x)}{\text{odds}(Y = 1 \mid Z = 0, X = x)}.$$

当结果罕见时， $\Pr(Y = 1 \mid Z = 1, X = x) \approx 0$ 且 $\Pr(Y = 1 \mid Z = 0, X = x) \approx 0$ ，此时

$$\text{odds}(Y = 1 \mid Z, X) \approx \frac{\Pr(Y = 1 \mid Z, X)}{1 - \Pr(Y = 1 \mid Z, X)} \approx \Pr(Y = 1 \mid Z, X).$$

因此罕见结果假设下，条件比数比近似于条件风险比：

$$\beta_1 \approx \log \text{RR}_{ZY|x}^{\text{obs}}.$$

由此可得 $\exp(\beta_1) \approx \text{RR}_{ZY|x}^{\text{obs}}$ ，进而 E-value 的计算公式 eq. (78) 可直接应用于逻辑斯蒂回归系数。

1. 第十八章平均因果效应灵敏度分析附录

附录：定理 18.2 的证明

1. 背景与目标

定理 18.2 给出了在已知灵敏度参数 $\varepsilon_1(X)$ 和 $\varepsilon_0(X)$ 条件下，平均因果效应的识别公式。本节给出完整证明。

2. 记号定义

记 $\mu_1(X) = E(Y \mid Z = 1, X)$ 和 $\mu_0(X) = E(Y \mid Z = 0, X)$ 。灵敏度参数定义为：

$$\varepsilon_1(X) = \frac{E\{Y(1) \mid Z = 1, X\}}{E\{Y(1) \mid Z = 0, X\}} = \frac{\mu_1(X)}{E\{Y(1) \mid Z = 0, X\}},$$

因此

$$(144) \quad E\{Y(1) \mid Z = 0, X\} = \frac{\mu_1(X)}{\varepsilon_1(X)}.$$

类似地，

$$(145) \quad E\{Y(0) \mid Z = 1, X\} = \mu_0(X)\varepsilon_0(X).$$

3. 详细推导

第一步：证明 $E\{Y(1) \mid Z = 0\} = E\{\mu_1(X)/\varepsilon_1(X) \mid Z = 0\}$ 。

由全概率公式：

$$E\{Y(1) \mid Z = 0\} = E[E\{Y(1) \mid Z = 0, X\} \mid Z = 0].$$

代入 eq. (144)：

$$E\{Y(1) \mid Z = 0\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 0\right].$$

第二步：证明 $E\{Y(0) \mid Z = 1\} = E\{\mu_0(X)\varepsilon_0(X) \mid Z = 1\}$ 。

类似地：

$$E\{Y(0) \mid Z = 1\} = E[E\{Y(0) \mid Z = 1, X\} \mid Z = 1].$$

代入 eq. (145)：

$$E\{Y(0) \mid Z = 1\} = E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

第三步：代入 τ 的分解。

回忆

$$\tau = E\{Y(1)\} - E\{Y(0)\} = E\{Y \mid Z = 1\} - E\{Y(0) \mid Z = 1\}.$$

由第一步和第二步：

$$\tau = E\{Y \mid Z = 1\} - E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

利用随机化定义 $Y = ZY(1) + (1 - Z)Y(0)$ ，展开 $E\{Y \mid Z = 1\}$ ：

$$E\{Y \mid Z = 1\} = E\{Y(1) \mid Z = 1\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 1\right].$$

因此

$$\tau = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 1\right] - E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

经过代数运算，可以化为 eq. (87) 和 eq. (88) 的形式。证毕。

附录：定理 18.3 的证明

1. 背景与目标

定理 18.3 给出了基于 IPW 的识别公式。本节给出完整证明。

2. 识别公式推导

由定理 18.2 的证明，我们有

$$E\{Y(1) \mid Z = 0\} = E\left\{\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 0\right\}.$$

现在利用 IPW 恒等式。将上式重新整理为：

$$E\{Y(1)\} = E\{Y(1) \mid Z = 1\} \Pr(Z = 1) + E\{Y(1) \mid Z = 0\} \Pr(Z = 0).$$

代入 $E\{Y(1) \mid Z = 1\} = \mu_1(X)/\varepsilon_1(X)$ 和 $E\{Y(1) \mid Z = 0\} = \mu_1(X)/\varepsilon_1(X)$ ，得：

$$E\{Y(1)\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)}\right].$$

利用倾向得分 $e(X) = \Pr(Z = 1 \mid X)$ ，我们可以将上式写成 IPW 形式：

$$E\{Y(1)\} = E\left\{\frac{ZY}{e(X)}\right\} = E\left\{w_1(X) \frac{ZY}{e(X)}\right\},$$

其中 $w_1(X) = e(X) + (1 - e(X))/\varepsilon_1(X)$ 。

类似地，可以导出 $E\{Y(0)\}$ 的公式。证毕。

APPENDIX G

附录：Manski 型边界的推导

1. 背景

本节推导在仅假设 outcomes 有界 $[\underline{y}, \bar{y}]$ 时, $E\{Y(1)\}$ 和 $E\{Y(0)\}$ 的边界。

2. 记号定义

记 $p = \Pr(Z = 1)$, 则 $\Pr(Z = 0) = 1 - p$ 。同时记 $\mu_1 = E(Y \mid Z = 1)$ 和 $\mu_0 = E(Y \mid Z = 0)$, 这是可以从数据中直接估计的量。

3. $E\{Y(1)\}$ 的边界

由全概率公式:

$$E\{Y(1)\} = \mu_1 \cdot p + E\{Y(1) \mid Z = 0\} \cdot (1 - p).$$

由于 $Y(1) \in [\underline{y}, \bar{y}]$,

$$\underline{y} \leq E\{Y(1) \mid Z = 0\} \leq \bar{y}.$$

因此

$$\mu_1 \cdot p + \underline{y}(1 - p) \leq E\{Y(1)\} \leq \mu_1 \cdot p + \bar{y}(1 - p).$$

4. $E\{Y(0)\}$ 的边界

类似地:

$$E\{Y(0)\} = E\{Y(0) \mid Z = 1\} \cdot p + \mu_0 \cdot (1 - p),$$

其中

$$\underline{y} \leq E\{Y(0) \mid Z = 1\} \leq \bar{y}.$$

因此

$$\underline{y} \cdot p + \mu_0(1 - p) \leq E\{Y(0)\} \leq \bar{y} \cdot p + \mu_0(1 - p).$$

5. τ 的边界

由 $\tau = E\{Y(1)\} - E\{Y(0)\}$, 代入以上边界可得:

$$\underline{\tau} = \mu_1 p + \underline{y}(1 - p) - \bar{y} p - \mu_0(1 - p),$$

$$\bar{\tau} = \mu_1 p + \bar{y}(1 - p) - \underline{y} p - \mu_0(1 - p).$$

边界的宽度为 $\bar{y} - \underline{y}$ 。

6. 附录：公式推导

6.1. 平均因果效应的有限总体表示. 背景：在有限总体中，平均因果效应 $\tau = \mathbb{E}[Y_i(1) - Y_i(0)]$ 可以用样本均值表示。

目标：证明 eq. (2.2)

推导步骤：

$$(146) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)]$$

$$(147) \quad = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] \quad (\text{期望的有限总体类比})$$

$$(148) \quad = \frac{1}{n} \sum_{i=1}^n Y_i(1) - \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

$$(149) \quad = \bar{Y}(1) - \bar{Y}(0)$$

这完成了 eq. (2.2) 的推导。

6.2. 亚组因果效应的定义推导. 背景：亚组因果效应 τ_x 定义为在协变量 $X_i = x$ 的条件下，平均因果效应。

目标：推导 eq. (2.4)

推导步骤：

$$(150) \quad \tau_x = \mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x]$$

$$(151) \quad = \frac{\sum_{i=1}^n \mathbb{I}(X_i = x)[Y_i(1) - Y_i(0)]}{\sum_{i=1}^n \mathbb{I}(X_i = x)} \quad (\text{条件期望的样本类比})$$

其中 $\mathbb{I}(X_i = x)$ 是示性函数，当 $X_i = x$ 时为 1，否则为 0。
这给出了 eq. (2.4)。

6.3. 亚组分解恒等式的推导. 背景：总平均因果效应可以分解为各亚组因果效应的加权平均。

目标：证明 eq. (2.5)

推导步骤：

$$(152) \quad \tau = \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\}$$

$$(153) \quad = \frac{1}{n} \sum_{i=1}^n [\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0)] \{Y_i(1) - Y_i(0)\}$$

$$(154) \quad \text{其中每单元满足 } \mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$$

$$(155) \quad = \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}_{\text{treatment 组}} + \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}_{\text{control 组}}$$

$$(156) \quad = \frac{n_1}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}{n_1}}_{\tau_1} + \frac{n_0}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}{n_0}}_{\tau_0}$$

$$(157) \quad = \pi_1 \tau_1 + \pi_0 \tau_0$$

其中 $n_1 = \sum_{i=1}^n \mathbb{I}(X_i = 1)$, $n_0 = \sum_{i=1}^n \mathbb{I}(X_i = 0)$, 且 $\pi_x = n_x/n$ 。

这完成了 eq. (2.5) 的推导。

6.4. 非线性因果参数的数值例子. 背景：平均因果效应是线性的，但中位数治疗效应等参数可能是非线性的。

目标：给出 $\delta_1 \neq \delta_2$ 的具体数值例子。

例子：考虑 $n = 4$ 个单元，潜在结果如下：

i	$Y_i(1)$	$Y_i(0)$
1	10	2
2	8	3
3	6	4
4	4	5

计算：

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 7 - 3.5 = 3.5$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{8, 5, 2, -1\} = 3.5$

在此例中 $\delta_1 = \delta_2$ 。

不等例子：考虑 $n = 5$ 个单元：

i	$Y_i(1)$	$Y_i(0)$
1	100	1
2	90	2
3	50	3
4	10	4
5	5	5

计算：

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 50 - 3 = 47$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{99, 88, 47, 6, 0\} = 47$

再考虑一个 $\delta_1 > \delta_2$ 的例子：

i	$Y_i(1)$	$Y_i(0)$
1	100	0
2	1	0
3	1	0
4	1	0

计算：

- $\delta_1 = 50.5 - 0 = 50.5$
- $\delta_2 = \text{median}\{100, 1, 1, 1\} = 1$

这里 $\delta_1 = 50.5 > \delta_2 = 1$ ，说明少数极端值可以显著影响 δ_1 而不影响 δ_2 。这些例子说明为什么选择哪个参数需要根据研究问题仔细考虑。

7. 附录：推导

7.1. 协变量均值差的协方差矩阵. 背景：我们推导 $\hat{\tau}_X$ 的协方差矩阵。

目标：证明 $\text{cov}(\hat{\tau}_X) = \frac{n}{n_1 n_0} S_X^2$ 。

推导：...¹

7.2. R^2 的等价形式推导. 背景：我们推导 R^2 的等价形式。

目标：证明命题 定义 6.4。

推导：...

7.3. 线性调整估计量的推导. 背景：我们详细推导线性调整估计量的形式。

目标：从 $\hat{\tau}(\beta_1, \beta_0)$ 的定义出发，推导其方差。

推导：...

7.4. Lin 估计量的 OLS 连接. 背景：我们证明 $\hat{\tau}(\hat{\beta}_1, \hat{\beta}_0)$ 等于 OLS 回归中 Z_i 的系数。

目标：建立线性调整估计量与 OLS 的等价性。

推导：...

7.5. 预测估计量的等价性证明. 背景：我们证明 $\hat{\tau}_{\text{pred}} = \hat{\tau}_L$ 。

目标：从预测公式推导到 Lin 估计量形式。

推导：...

7.6. 协变量不平衡调整形式推导. 背景：我们推导 $\hat{\tau}(\beta_1, \beta_0)$ 的不平衡调整形式。

目标：证明 $\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 。

推导：...

¹详细推导见原始笔记

8. 附录：定理证明

8.1. 定义 7.2 的证明. 回忆基本代数恒等式 $\sum_{i=1}^n (a_i - \bar{a})^2 = \sum_{i=1}^n a_i^2 - n\bar{a}^2$, 它类似于 $\text{var}(W) = \mathbb{E}(W^2) - (\mathbb{E}W)^2$ 。利用它, 我们有

$$\begin{aligned} n(n-1)\mathbb{E}(\hat{V}) &= \mathbb{E} \left\{ \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2 \right\} \\ &= \mathbb{E} \left(\sum_{i=1}^n \hat{\tau}_i^2 - n\hat{\tau}^2 \right) \\ &= \sum_{i=1}^n \{ \text{var}(\hat{\tau}_i) + \tau_i^2 \} - n \{ \text{var}(\hat{\tau}) + \tau^2 \} \\ &= \sum_{i=1}^n \text{var}(\hat{\tau}_i) - n\text{var}(\hat{\tau}) + \sum_{i=1}^n \tau_i^2 - n\tau^2 \\ &= n^2 \text{var}(\hat{\tau}) - n\text{var}(\hat{\tau}) + \sum_{i=1}^n (\tau_i - \tau)^2. \end{aligned}$$

因此,

$$\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau}) + \{n(n-1)\}^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \geq \text{var}(\hat{\tau}).$$

□

8.2. 定义 7.3 的 OLS 解释. 将 $(\hat{\tau}_1, \dots, \hat{\tau}_n)^\top$ 对截距进行 OLS 拟合, 截距系数为

$$\hat{\beta}_0 = \bar{\hat{\tau}} = n^{-1} \sum_{i=1}^n \hat{\tau}_i = \hat{\tau},$$

这正是 eq. (36) 定义的 $\hat{\tau}$ 。

残差为 $\hat{\varepsilon}_i = \hat{\tau}_i - \hat{\tau}$, 因此误差均方为

$$\hat{\sigma}^2 = (n-1)^{-1} \sum_{i=1}^n \hat{\varepsilon}_i^2 = (n-1)^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2 = \hat{V}.$$

因此, $\hat{\tau}$ 和 $\hat{V}$ 确实是 OLS 拟合的截距系数和相应方差估计量。

□

9. 附录：渐近分布推导

9.1. 配对 t 统计量的中心极限定理. 在 H_{0F} 下, $\hat{\tau}_i = S_i D_i$, 其中 $S_i = 2Z_i - 1 \in \{-1, 1\}$ 是随机符号, $D_i = Y_{i1} - Y_{i2}$ 是固定常数。由于 S_i 独立同分布, 均值为 0, 方差为 1, 我们有

$$\text{var}(\hat{\tau}_i) = \mathbb{E}(S_i^2 D_i^2) - \mathbb{E}(S_i)^2 \mathbb{E}(D_i)^2 = D_i^2 - 0 = D_i^2 = \hat{\tau}_i^2.$$

由独立随机变量之和的中心极限定理,

$$\frac{\hat{\tau} - \mathbb{E}\hat{\tau}}{\sqrt{\text{var}(\hat{\tau})}} = \frac{\hat{\tau}}{\sqrt{n^{-2} \sum_{i=1}^n \hat{\tau}_i^2}} \rightarrow N(0, 1)$$

依分布收敛。

□

9.2. Wilcoxon 符号秩统计量的正态近似. 在 H_{0F} 下, $|\hat{\tau}_i|$ 是固定的, 因此秩 R_i 也是固定的。定义 $U_i = \mathbb{I}(\hat{\tau}_i > 0)$, 则 $W = \sum_{i=1}^n U_i R_i$ 。由于 $U_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(1/2)$ 且与 R_i 独立, 我们有

$$\begin{aligned}\mathbb{E}(W) &= \sum_{i=1}^n \mathbb{E}(U_i) R_i = \frac{1}{2} \sum_{i=1}^n i = \frac{n(n+1)}{4}, \\ \text{var}(W) &= \sum_{i=1}^n \text{var}(U_i) R_i^2 = \frac{1}{4} \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{24}.\end{aligned}$$

由中心极限定理, eq. (40) 成立。 $\square$

9.3. 符号统计量的正态近似. 在 H_{0F} 下, $\Delta = \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i > 0) \sim \text{Binomial}(n, 1/2)$ 。由中心极限定理,

$$\frac{\Delta - n/2}{\sqrt{n/4}} \rightarrow N(0, 1)$$

依分布收敛。 $\square$

10. 附录: 方差公式推导

在 MPE 下, 第 i 对的治疗指示变量为 Z_i , 对照指示变量为 $1 - Z_i$ 。因此

$$\hat{\tau}_i = Z_i Y_{i1} + (1 - Z_i) Y_{i2} - [(1 - Z_i) Y_{i1} + Z_i Y_{i2}] = (2Z_i - 1)(Y_{i1} - Y_{i2}) = S_i D_i,$$

其中 $S_i = 2Z_i - 1$, $D_i = Y_{i1} - Y_{i2}$ 。

由于 $Z_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(1/2)$, 我们有 $\mathbb{E}(Z_i) = 1/2$, $\text{var}(Z_i) = 1/4$, 因此 $\mathbb{E}(S_i) = 0$, $\text{var}(S_i) = 1$ 。此外, S_i 与 D_i 独立, 因为 D_i 仅依赖于潜在结果, 而 S_i 仅依赖于治疗分配。因此

$$\mathbb{E}(\hat{\tau}_i) = \mathbb{E}(S_i) \mathbb{E}(D_i) = 0,$$

$$\text{var}(\hat{\tau}_i) = \mathbb{E}(S_i^2) \mathbb{E}(D_i^2) - \mathbb{E}(S_i)^2 \mathbb{E}(D_i)^2 = 1 \cdot \mathbb{E}(D_i^2) = \mathbb{E}(D_i^2).$$

由于 $D_i = Y_{i1} - Y_{i2}$,

$$\mathbb{E}(D_i^2) = \mathbb{E}[\{Z_i Y_{i1}(1) + (1 - Z_i) Y_{i1}(0) - Z_i Y_{i2}(0) - (1 - Z_i) Y_{i2}(1)\}^2].$$

利用 $Z_i^2 = Z_i$, $(1 - Z_i)^2 = 1 - Z_i$, $Z_i(1 - Z_i) = 0$, 我们可以展开并利用 $\mathbb{E}(Z_i) = 1/2$ 和 $\mathbb{E}(Z_i^2) = 1/2$ 。经过代数运算, 可以得到 $\text{var}(\hat{\tau}_i) = \mathbb{E}(Y_{i1}(1) - Y_{i2}(1) - Y_{i1}(0) + Y_{i2}(0))^2 / 4 = \tau_i^2$ 的某种形式。²

最终, $\hat{\tau} = n^{-1} \sum_{i=1}^n \hat{\tau}_i$ 的方差为

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i) + \text{交叉协方差项}.$$

由于 Z_i 独立, 不同配对的 $\hat{\tau}_i$ 也独立, 因此协方差项为零。故

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i).$$

$\square$

²详细推导留作习题。

11. 附录：协变量调整推导

假设每个单元 (i, j) 都有协变量 X_{ij} 。定义协变量的配对内差异

$$\hat{\tau}_{X,i} = X_{i1} - X_{i2},$$

及其均值 $\hat{\tau}_X = n^{-1} \sum_{i=1}^n \hat{\tau}_{X,i}$ 。

在 MPE 下，治疗分配 Z_i 与协变量 X_{ij} 独立（因为配对是在随机化之前根据协变量形成的）。因此

$$\mathbb{E}(\hat{\tau}_{X,i}) = \mathbb{E}(X_{i1} - X_{i2}) = \mathbb{E}(X_{i1}) - \mathbb{E}(X_{i2}) = 0,$$

因为在配对内，两个单元的协变量分布相同（配对是基于协变量相似性形成的）。

类似地， $\mathbb{E}(\hat{\tau}_X) = 0$ 。

协方差矩阵为

$$\text{cov}(\hat{\tau}_X) = n^{-2} \sum_{i=1}^n \text{cov}(\hat{\tau}_{X,i}) = n^{-2} \sum_{i=1}^n \hat{\tau}_{X,i} \hat{\tau}_{X,i}^\top,$$

因为不同配对的 $\hat{\tau}_{X,i}$ 独立。

考虑调整估计量 $\hat{\tau}(\gamma) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 。其方差为

$$\text{var}(\hat{\tau}(\gamma)) = \text{var}(\hat{\tau}) + \gamma^\top \text{cov}(\hat{\tau}_X) \gamma - 2\gamma^\top \text{cov}(\hat{\tau}_X, \hat{\tau}).$$

最小化方差的解为

$$\tilde{\gamma} = \text{cov}(\hat{\tau}_X)^{-1} \text{cov}(\hat{\tau}_X, \hat{\tau}).$$

由于 $\text{cov}(\hat{\tau}_X)$ 是已知且固定的，但 $\text{cov}(\hat{\tau}_X, \hat{\tau})$ 依赖于未知的潜在结果，我们使用 eq. (52) 中的 $\hat{\theta}$ 作为其无偏估计。

最终，代入 $\hat{\gamma}$ 得到调整估计量 $\hat{\tau}_{\text{adj}} = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X$ 及其方差估计量 $\hat{V}_{\text{adj}}$ 。□

12. 附录：儿童电视 Workshop 实验详细计算

基于 8 对班级的数据，前测和后测的配对差异如下：

配对	前测差值 $\hat{\tau}_{X,i}$	后测差值 $\hat{\tau}_i$
1	-1	-5
2	2	-1
3	0	3
4	1	2
5	2	5
6	0	-3
7	0	-1
8	2	9

点估计：

$$\hat{\tau} = \frac{1}{8} \sum_{i=1}^8 \hat{\tau}_i = \frac{-5 + (-1) + 3 + 2 + 5 + (-3) + (-1) + 9}{8} = \frac{9}{8} = 1.125.$$

方差估计（未调整）：

$$\hat{V} = \frac{1}{8 \times 7} \sum_{i=1}^8 (\hat{\tau}_i - \hat{\tau})^2 = \frac{1}{56} [(-6.125)^2 + (-2.125)^2 + (1.875)^2 + \dots] \approx 4.98.$$

95% 置信区间： $\hat{\tau} \pm 1.96\sqrt{\hat{V}} = 1.125 \pm 1.96 \times 2.23 = [-3.25, 5.50]$ 。

对于协变量调整估计量, 我们需要计算 $\hat{\gamma}$ 和 $\hat{\tau}_{\text{adj}}$ 。³

13. 附录: 关键公式推导

13.1. 定理 13.2 的完整证明. 我们需要证明在强 ignorability 条件下,

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = \Pr\{Z = 1 \mid e(X)\}.$$

首先, 由条件概率的定义和 tower property,

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{Z \mid Y(1), Y(0), e(X)\}.$$

对上式应用 tower property (先关于 X 条件化, 再关于 $Y(1), Y(0), e(X)$ 条件化):

$$E\{Z \mid Y(1), Y(0), e(X)\} = E[E\{Z \mid Y(1), Y(0), X\} \mid Y(1), Y(0), e(X)].$$

由强 ignorability 假设 $Z \perp \{Y(1), Y(0)\} \mid X$, 有

$$E\{Z \mid Y(1), Y(0), X\} = E\{Z \mid X\} = e(X).$$

因此,

$$E\{Z \mid Y(1), Y(0), e(X)\} = E\{e(X) \mid Y(1), Y(0), e(X)\} = e(X).$$

另一方面,

$$\Pr\{Z = 1 \mid e(X)\} = E\{Z \mid e(X)\} = E[E\{Z \mid X\} \mid e(X)] = E\{e(X) \mid e(X)\} = e(X).$$

两端相等, 定理证毕。

13.2. NHANES 数据分析的 R 代码. 以下是本章数据分析使用的 R 代码示例:

```
# 读取数据
nhanes_bmi = read.csv("nhanes_bmi.csv")[, -1]
z = nhanes_bmi$Schoolmeal
y = nhanes_bmi$BMI
x = as.matrix(nhanes_bmi[, -c(1, 2)])
x = scale(x) # 标准化协变量

# 估计倾向得分
pscore = glm(z ~ x, family = binomial)$fitted.values

# 倾向得分分层
n.strata = c(5, 10, 20, 50, 80)
strat.res = sapply(n.strata, FUN = function(nn) {
  q.pscore = quantile(pscore, (1:(nn-1)) / nn)
  ps.strata = cut(pscore, breaks = c(0, q.pscore, 1),
                  labels = 1:nn)
  Neyman_SRE(z, y, ps.strata)
})

rownames(strat.res) = c("est", "se")
colnames(strat.res) = n.strata
```

³详细计算留作习题。

`round(strat.res, 3)`

其中 `Neyman_SRE` 函数定义于第 5 章，用于计算 SRE 框架下的 Neyman 估计量及其标准误。

14. 附录：定理 29.1 的证明

定理 29.1 证明。 由塔性质，

$$E\{Y(z_1, z_2)\} = E[E\{Y(z_1, z_2) \mid X_0\}]$$

因此我们聚焦于 $E\{Y(z_1, z_2) \mid X_0\}$ 。由 Assumption 29.1(1) 和塔性质，

$$\begin{aligned} E\{Y(z_1, z_2) \mid X_0\} &= E\{Y(z_1, z_2) \mid z_1, X_0\} \\ &= E[E\{Y(z_1, z_2) \mid z_1, X_1, X_0\} \mid z_1, X_0] \end{aligned}$$

由 Assumption 29.1(2)，

$$\begin{aligned} E\{Y(z_1, z_2) \mid X_0\} &= E[E\{Y \mid z_2, z_1, X_1, X_0\} \mid z_1, X_0] \\ &= E\{E(Y \mid z_2, z_1, X_1, X_0) \mid z_1, X_0\} \end{aligned}$$

取期望即得 29.1。□

APPENDIX A

问答与注解

1. 阅读过程中的问题与解答

1.1. 亚组的定义. 问: 什么是亚组?

答: 亚组 (subgroup) 是由某个协变量 (通常是二元变量 X_i) 分割出来的子群体。例如按性别、年龄、收入等分割。亚组因果效应衡量的是在该亚组内的平均因果效应。

1.2. 恒等式 $\tau = \pi_1\tau_1 + \pi_0\tau_0$ 的推导. 问: 如何推导 $\tau = \pi_1\tau_1 + \pi_0\tau_0$?

答: 利用指示函数的完备性 $\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$, 将总体求和拆分为两个亚组求和, 再除以对应的亚组样本量即可得到。

1.3. 为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的?. 问: 为什么在 Fisher's sharp null ($H_{0F} : Y_i(1) = Y_i(0)$) 下, 潜在结果向量 $\mathbf{Y}$ 是固定的?

答: H_{0F} 断言 treatment 对每个单元都没有效应, 即 $Y_i(1) = Y_i(0) = Y_i$ 对所有 i 。这意味着整个 $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y}$ 向量是确定的 (固定值), 不再有随机性。

在 FRT 中, 我们 condition on 这个固定的 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。因此, 随机化分布可以精确枚举 ($M = \binom{n}{n_1}$ 种可能), 不依赖任何渐近假设——这就是 FRT”有限样本精确”的本质。

1.4. p_frt 的 Monte Carlo 近似与修正. 问: 为什么 eq. (12) 需要修正为 $\tilde{p}_{frt}$?

答:

原始 Monte Carlo 近似:

$$\hat{p}_{frt} = \frac{1}{R} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$$

这个估计量的问题是: 当 R 有限时, 它可能是**反保守的**——低估真实的 p 值, 导致错误地宣称显著。

修正公式 (有限样本有效):

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

修正的本质是”自我包含”: 分子加 1 相当于把”观测到的这一次”也算作一次置换结果。

为什么需要修正:

当 $R = 99$ 次置换中, 只有 0 次超过观测值时:

$$\hat{p}_{frt} = \frac{0}{99} = 0$$

这就错了! 因为观测到的这一次 (自身) 必然是 M 种可能之一, p 值至少应该是 $1/M$, 而不是 0。

加了 1 在分子和分母：

$$\tilde{p}_{f_{rt}} = \frac{1}{100}$$

这保证了：

- (1) p 值不会为 0 (分子至少是 1)
- (2) 在任何有限的 R 下都满足有限样本有效性： $\mathbb{P}(p \leq u) \leq u$
- (3) 当 $R \rightarrow \infty$ 时， $\tilde{p}_{f_{rt}} \rightarrow \hat{p}_{f_{rt}}$

1.5. 为什么叫“有限样本精确”？ 问：FRT 的 p 值为什么被称为“有限样本精确”？

答：关键在于 ?? 给出的不等式：

$$\mathbb{P}(p_{f_{rt}} \leq u) \leq u \quad \text{for all } u \in [0, 1]$$

这叫做**有限样本有效性** (finite-sample validity)。意思是：无论样本量多小、数据分布如何， $p_{f_{rt}}$ 的分布永远不会偏离均匀分布太多。

对比传统 t 检验：它需要大样本下才近似有效 (渐近性质)，小样本时可能失效。FRT 的精确性只依赖于随机化机制，不依赖于任何渐近假设。

1.6. Fisher 方法 vs 传统方法. 问：Fisher 的思路和传统统计推断有什么本质区别？

答：

- **传统方法问**：“数据有多极端？”——依赖数据分布假设
- **Fisher 方法问**：“如果随机化，会产生多极端的数据？”——只依赖随机化机制

Fisher 方法的哲学：在 sharp null (无因果效应) 假设下，潜在结果完全已知。观察到的差异完全来自随机分配。我们可以枚举所有可能的置换，计算每个置换产生的统计量。传统方法则依赖于数据的原始分布假设 (如正态性)，而 FRT 给经典 t 检验提供了理论 justify——不需要正态性假设。

1.7. 经典 t 检验之前没有理论基础吗？ 问：经典 t 检验之前没有理论 justify 吗？一定要 FRT 给出吗？

答：经典 t 检验有理论基础，但 FRT 提供了**更坚实**的理论基础。

经典 t 检验的理论基础：

- **正态性假设下** (Fisher 原始推导)：如果 $Y_i \sim \text{i.i.d. } \mathcal{N}(\mu, \sigma^2)$ ，则 t 统计量精确服从 t 分布
- **渐近理论** (后来发展)：大样本下，CLT 保证 t 统计量近似正态分布——即使数据不正态

FRT 的新贡献：FRT 并不是说经典 t 检验“没有理论依据”，而是提供了**另一种理论框架**：

- 经典方法：关注“**数据的分布**” (假设数据来自正态分布)
- FRT：关注“**随机化的机制**” (治疗是如何分配的)

关键区别：在随机实验中，我们**知道**治疗是如何分配的 (CRE)，所以可以基于随机化机制来计算 p 值——这比假设“数据来自正态分布”更可靠。

准确的说法：FRT 为经典 t 检验在随机实验中的应用提供了**更直接、更不依赖分布假设**的理论基础。

1.8. 经典 t 检验需要正态性假设吗？问：经典 t 检验需要正态性假设吗？为什么 FRT 说“不需要”？

答：经典 t 检验有两种情况：

- **精确版本：**如果数据来自正态分布的总体，t 统计量的精确抽样分布是 t 分布
- **渐近版本：**在大样本下，即使数据不正态，CLT 保证 t 统计量近似正态分布

FRT 的贡献：它证明了在随机实验 + sharp null 下，t 统计量的**随机化分布**可以直接计算（精确或 Monte Carlo 近似），不依赖任何分布假设。

关键区别：

- 传统方法问：“如果数据来自正态分布，观察到的差异有多极端？”
- FRT 问：“如果 treatment 是随机分配的，观察到这种差异的概率有多大？”

FRT 的理论基础是有限总体 CLT，它保证**随机化分布**收敛到正态，而不是数据本身正态。因此在大样本下，即使数据不正态，FRT 给出的 p 值也是有效的。

总结：FRT 并没有说经典 t 检验“不需要”正态性假设，而是说在随机实验框架下，可以用不依赖正态性的方法（FRT）来获得精确的 p 值。

1.9. 什么是潜在结果？问：在 Fisher 随机化检验框架下，什么是潜在结果？

答：潜在结果（Potential Outcomes）是每个单元在两种 treatment 状态下的可能结果：

- $Y_i(1)$ ：单元 i 如果接受 treatment 的结果
- $Y_i(0)$ ：单元 i 如果接受 control 的结果

关键洞察：每个单元只能实际接受一种 treatment，因此我们只能观测到其中一个潜在结果，另一个是“反事实”（counterfactual）——它从未发生，无法被观测。

观测结果与潜在结果的关系：

$$Y_i^{obs} = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$$

即：如果 $Z_i = 1$ （接受 treatment），我们观测到 $Y_i(1)$ ；如果 $Z_i = 0$ ，我们观测到 $Y_i(0)$ 。

因果推断的根本问题：我们想估计 $Y_i(1) - Y_i(0)$ （单元 i 的因果效应），但只能观测到其中一个值。

1.10. 随机化的两个原则是什么？问：Fisher 随机化的两个原则——可比性和推理基础——是什么意思？

原则一：可比性（Comparability）。随机化保证了 treatment 组和 control 组在平均意义上是可比的。如果没有随机化，治疗分配可能受到选择偏差（selection bias）的影响。例如，如果病人自己选择是否接受治疗，那么接受治疗的群体可能本身就比对照组更健康。随机化通过强制分配机制打破了这种联系，使得两组在所有可观测和不可观测的特质上趋于平衡。

原则二：推理基础（Inference Basis）。随机化提供了推断因果效应的理论基础。在没有随机化的情况下，我们无法区分“因果效应”和“选择偏差”。但在随机实验中，我们知道治疗分配是如何进行的（randomization mechanism），因此可以基于这个已知的分配机制来计算 p 值。具体而言：

- (1) 假设 H_{0F} ：treatment 对每个人都无效 ($Y_i(1) = Y_i(0)$)
- (2) 在这个假设下，治疗分配是唯一的随机来源
- (3) 枚举所有可能的随机分配（或者 Monte Carlo 近似）
- (4) 计算在每种分配下，检验统计量有多极端

总结：可比性解决“选择偏差”——确保组间可比较。推理基础解决“随机变异”——知道观察到的差异有多极端。两者结合，使得因果推断成为可能。

1.11. 什么是 Fisher Randomization Test ?. 问：什么是 Fisher Randomization Test (Fisher 随机化检验)？

答：Fisher Randomization Test (FRT) 是 Ronald Fisher 在 1935 年《Design of Experiments》中提出的统计检验框架。它的核心创新是：不再依赖数据分布假设（如正态性），而是仅依赖随机化机制本身。

核心思想：

- (1) 在 **sharp null** 假设 $H_{0F} : Y_i(1) = Y_i(0)$ （所有单元的治疗效应都为零）下，潜在结果向量 $\mathbf{Y}$ 是完全确定的（固定的）
- (2) 唯一的随机来源是治疗分配机制 $\mathbf{Z}$
- (3) 在完全随机实验（CRE）中， $\mathbf{Z}$ 的分布是已知的（均匀分布于所有 $\binom{n}{n_1}$ 种可能的分配）
- (4) 因此，我们可以枚举所有可能的治疗分配，计算在每种分配下检验统计量的取值
- (5) p 值就是在所有可能分配中，观察到的统计量至少与实际观测值一样极端的比例

★ **Insight:** FRT 的本质是“条件推断”——我们 condition on 固定的潜在结果 $\mathbf{Y}$ ，只让治疗分配 $\mathbf{Z}$ 有随机性。这与经典统计推断不同：经典方法 condition on 数据，假设数据的分布已知；FRT 则 condition on 潜在结果，利用随机化机制计算精确的 p 值。

为什么叫“随机化检验”？ 因为它完全基于随机化机制——不假设任何参数分布，不依赖正态性假设，只依赖“治疗是如何随机分配的”这一事实。这使得 FRT 在随机实验中具有“有限样本精确性”（finite-sample exactness）。

1.12. $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义. 问：在 CRE 中， $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的。这句话是什么意思？

答：

先理解 $\mathbf{Z}$ 是什么。 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 是治疗分配向量，其中 $Z_i = 1$ 表示单元 i 接受治疗， $Z_i = 0$ 表示单元 i 接受对照。

再理解 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 。 这是所有可能的治疗分配构成的集合。例如当 $n = 3, n_1 = 1$ 时，所有可能的分配有：

$$\mathbf{z}^1 = (1, 0, 0), \mathbf{z}^2 = (0, 1, 0), \mathbf{z}^3 = (0, 0, 1)$$

即 $M = \binom{3}{1} = 3$ 种可能。

“均匀分布”的意思。 在 CRE 中，治疗分配是完全随机的。这意味着每一种可能的分配 $\mathbf{z}^m$ 被选中的概率相等：

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}^m) = \frac{1}{M} = \frac{1}{\binom{n}{n_1}}$$

例如当 $n = 100, n_1 = 50$ 时， $M \approx 10^{29}$ 种可能的分配，每一种被选中的概率都完全相同（约 10^{-29} ）。

关键直觉： 在 CRE 下，treatment 组和 control 组的成员身份是随机决定的，而非实验者主观选择。这就是 Fisher 说的“randomization provides a valid basis for inference”——随机化本身保证了推断的有效性。

1.13. 蒙特卡洛公式中的 $\mathbf{Z}$ 是什么 ?. 问：蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思？他说是一个均匀分布，但我不知道 $\mathbf{Z}$ 是什么意思？

答：

为什么需要理解 $\mathbf{Z}$? 在 Fisher 随机化检验中，我们感兴趣的问题是：“如果 treatment 真的是随机分配的，观察到的差异有多极端？”要回答这个问题，我们需要知道“随机分配”是如何进行的——而 $\mathbf{Z}$ 正是描述这种分配机制的核心工具。

$\mathbf{Z}$ 的定义。 在 n 个单元的实验中， $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)$ 是一个长度为 n 的向量，其中：

- $Z_i = 1$: 单元 i 接受 treatment (治疗组)
- $Z_i = 0$: 单元 i 接受 control (对照组)

例如当 $n = 5, n_1 = 2$ 时, 一个可能的分配是 $\mathbf{Z} = (1, 0, 0, 1, 0)$, 表示第 1、4 号单元接受治疗, 第 2、3、5 号单元接受对照。

为什么是“均匀分布”? 在完全随机实验 (CRE) 中, 治疗分配是完全随机的——每个可能的 $\mathbf{Z}$ 被选中的概率相等。这就是“均匀分布”的含义。

具体来说, 所有可能的分配有 $M = \binom{n}{n_1}$ 种, 每种被选中的概率都是 $1/M$ 。例如:

- $n = 3, n_1 = 1$ 时, $M = 3$, 三种可能: $(1, 0, 0)$ 、 $(0, 1, 0)$ 、 $(0, 0, 1)$, 概率各为 $1/3$
- $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$, 每种概率约为 10^{-29}

$\mathbf{z}^r$ 是什么? 在 Monte Carlo 近似中, 我们无法枚举全部 M 种分配。因此我们进行 R 次随机置换, 每次得到一个 $\mathbf{z}^r$ 。每个 $\mathbf{z}^r$ 都是对真实 $\mathbf{Z}$ 的一次模拟。

★ **Insight:** 理解 $\mathbf{Z}$ 的关键是: 它是一个指示函数向量 (indicator vector), 而不是一个普通的数。它告诉我们“谁在接受治疗, 谁在对照”。Monte Carlo 方法通过重复模拟这个随机分配过程, 来近似在所有可能分配下的检验统计量分布。

1.14. 什么是潜在结果 (Potential Outcomes) ? . 问: 什么是因果推断中的“潜在结果” (Potential Outcomes)?

答: 潜在结果 (Potential Outcomes) 是指每个研究单元在 ** 不同处理条件下 ** 可能观测到的所有结果。对于单元 i :

- $Y_i(1)$: 单元 i 接受 treatment 后的结果 (如吃药后的康复情况)
- $Y_i(0)$: 单元 i 接受 control 的结果 (如不服药的情况)

核心问题: 我们只能同时观测到 ** 一个 ** 潜在结果, 另一个是反事实 (counterfactual)。这被称为“因果推断基本问题” (Fundamental Problem of Causal Inference)。

1.15. 第一基本形式的意义. 问: 什么是第一基本形式 (First Fundamental Form)?

答: 第一基本形式是曲面上用来度量弧长、面积以及角度的工具, 本质上是曲面自带的一种“度量结构”——它告诉我们如何在曲面上测量距离和角度。

1.16. 远置信集的构造. 问: 远置信集 (far confidence set) 是如何构造的?

答: 远置信集是通过在参数空间中搜索满足置信水平的最大区域构造的。具体方法是在约束条件下寻找使目标函数最大化的参数点, 从而确定置信范围。

1.17. ITT 的含义. 问: 什么是 ITT (Intent-to-Treat)?

答: ITT 即意向性治疗分析 (Intent-to-Treat), 是一种保守的估计方法, 无论实际是否依从, 都按随机分配的方案进行分析。它估计的是“随机化本身的效应”, 而非实际治疗的因果效应。

1.18. 工具变量的直觉. 问: 工具变量 (Instrumental Variable) 的直觉是什么?

答: 工具变量 Z 满足: (1) 与 treatment 相关; (2) 通过随机分配获得外生性; (3) 只通过 treatment 影响结果, 不能直接影响结果。它的直觉是: 通过随机分配产生的 variation (被称为“准实验 variation”), 可以用来估计 treatment 效应, 即使存在选择偏差。

1.19. 单调性假设是否可检验. 问: 单调性假设 (Monotonicity) 是否可检验?

答: 单调性假设 ($Y_i(1) \geq Y_i(0)$ 对所有人成立) 通常是不可直接检验的, 因为它涉及反事实结果。但在某些特殊情况下 (如二元结果、随机实验), 可以通过辅助假设或分层分析提供间接证据。

1.20. 随机化假设的含义. 问: 随机化假设 (Randomization Assumption) 在工具变量框架下意味着什么?

答: 随机化假设是指工具变量 Z 与潜在结果 $(Y_i(0), Y_i(1))$ 和潜在处理 $(D_i(0), D_i(1))$ 是相互独立的, 即 $Z \perp (Y_i(0), Y_i(1), D_i(0), D_i(1))$ 。这确保了工具变量的外生性, 排除了一切混杂。

1.21. 弱工具变量问题. 问: 什么是弱工具变量问题 (Weak IV Problem)?

答: 弱工具变量是指与 treatment 相关性很弱的工具变量 (F 统计量较小)。使用弱工具变量会导致: 偏差增大、置信区间扩张、有限样本下分布偏离标准分布。需要检查 F 统计量是否超过临界值 (如 Staiger-Stock 规则中的 10)。

1.22. 为什么是局部平均处理效应. 问: 工具变量方法估计的为什么是“局部”平均处理效应 (LATE) 而非总体 ATE?

答: 因为工具变量利用的是“受工具影响的 Compliers”的 variation。在单调性假设下, 只有 Compliers ($D_i(1) > D_i(0)$) 对工具变量的效应有贡献, 而 Defiers 和 Always-takers 被排除。因此估计量只识别了 Compliers 群体的 ATE, 即 LATE。

替代标准误公式的推导. 注: 此解答待补充。详见对应章节练习题。

连续或二元结果下 m 的性质. 注: 此解答待补充。当 Y 为二元变量或连续变量时, 函数 $m(X) = \mathbb{E}[Y|X]$ 的形式与性质讨论。

差商积形式的推导. 注: 此解答待补充。关于差商与乘积关系的推导。

交互效应的可识别性. 注: 此解答待补充。条件可识别性框架下交互效应的识别与估计。

Logit 模型下二元处理变量 m 的推导. 注: 此解答待补充。在 Logit 回归框架下处理二元变量 m 的具体推导过程。

Robins mediation formula 与潜在组. 注: 此解答待补充。Robins 提出的 mediation formula 在潜在组 (latent groups) 框架下的应用。

二元结果下的自然间接效应. 注: 此解答待补充。当结果变量 Y 为二元时, 自然间接效应的定义与估计。

跨世界独立性假设的问题. 注: 此解答待补充。跨世界独立性 (cross-world independence) 假设在 mediation analysis 中的局限性。

Surrogate 准则与 Jr 条件. 注: 此解答待补充。Surrogate 准则 (Sr) 与 Jr 条件的关系与推导。

当你在阅读过程中提出问题时, 回答将被记录在此处。

2. 学习笔记

在这里记录你的学习心得和思考。

Bibliography

- Joshua D. Angrist, Guido W. Imbens, and Donald B. Rubin. Identification of causal effects using instrumental variables. *Journal of the American Statistical Association*, 91(434):444–472, 1996. Cited in Chapter 21.
- Peter J. Bickel, Eugene A. Hammel, and J. William O’Connell. Sex bias in graduate admissions: Data from berkeley. *Science*, 187(4175):398–404, 1975. Cited in Chapter 1.
- Marie-Abele C. Bind and Lea M. Rattay. When possible, report a fisher-exact p -value and display its underlying null randomization distribution. *Journal of the American Statistical Association*, 115(532):1644–1646, 2020. Cited in Chapter 3.
- George E. P. Box, J. Stuart Hunter, and William G. Hunter. *Statistics for Experimenters: An Introduction to Experimental Design*. John Wiley & Sons, 1978. Cited in Chapter 5.
- Peng Ding. A paradox from randomization-based causal inference. *Statistical Science*, 32(3):331–345, 2017. Cited in Chapter 4.
- Peng Ding and Tyler J. VanderWeele. Sensitivity analysis without assumptions. *Epidemiology*, 27(3):368–377, 2016. Cited in Chapters 17, 18.
- Herman F. Dorn. The planner’s dilemma. *Journal of the American Statistical Association*, 48(264):601–604, 1953. Cited in Chapters 18, 21.
- Ronald A. Fisher. The design of experiments. *Statistical Research Memoirs*, 1:1–26, 1935. Cited in Chapter 3.
- J. L. Hodges and E. L. Lehmann. Rank methods for combination of independent experiments in analysis of variance. *The Annals of Mathematical Statistics*, 33(2):482–497, 1962. Cited in Chapter 5.
- Paul W. Holland. Statistics and causal inference. *Journal of the American Statistical Association*, 81(396):945–960, 1986. Cited in Chapters 1, 2, 3.
- Guido W. Imbens. Sensitivity to exogeneity assumptions in program evaluation. *American Economic Review*, 93(2):126–132, 2003. Cited in Chapter 18.
- Guido W. Imbens and Joshua D. Angrist. Identification and estimation of local average treatment effects. *Econometrica*, 62(2):467–475, 1994. Cited in Chapter 21.
- Guido W. Imbens and Donald B. Rubin. *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press, 2015. Cited in Chapters 4, 5.
- Gary King and Langche Zeng. The dangers of extreme counterfactuals. *Political Analysis*, 14(2):131–159, 2006. Cited in Chapter 20.
- Winston Lin. Agnostic notes on regression adjustments to experimental data: Reexamining freedman’s critique. *The Annals of Applied Statistics*, 7(1):295–318, 2013. Cited in Chapter 3.
- Bo Lu and Peng Ding. Sensitivity analysis for causal inference: Theory and applications. *Unpublished manuscript*, 2023. Cited in Chapter 18.

- Charles F. Manski. Nonparametric bounds on treatment effects. *American Economic Review*, 80(2):319–323, 1990. Cited in Chapter 18.
- Charles F. Manski. *Monitoring the dissolving of the Soviet Union*, volume 21. 2003. Cited in Chapter 18.
- Jerzy Neyman. Sur les applications de la théorie des probabilités aux expériences agricoles: Essai d’application de la méthode “chia”. *Roczniki Nauk Rolniczych*, 10:1–51, 1923. Cited in Chapters 2, 4.
- Judea Pearl. On the consistency rule in causal inference. *Biometrika*, 97(2):490–492, 2010. Cited in Chapter 2.
- Judea Pearl and Dana Mackenzie. *The Book of Why: The New Science of Cause and Effect*. Basic Books, 2018. Cited in Chapter 1.
- Paul R. Rosenbaum and Donald B. Rubin. Assessing sensitivity to an unobserved binary covariate in an observational study with binary outcome. *Journal of the Royal Statistical Society: Series B*, 45(2):212–218, 1983. Cited in Chapters 17, 18, 19.
- Donald B. Rubin. Comment: Bayesian inference for causal effects: The role of randomization. *The Annals of Statistics*, 8(1):44–45, 1980. Cited in Chapter 3.
- Donald B. Rubin. Causal inference using potential outcomes: Design, modeling, decisions. *Journal of the American Statistical Association*, 100(469):322–331, 2005. Cited in Chapter 2.
- Donald B. Rubin. For objective causal inference, design trumps analysis. *The Annals of Applied Statistics*, 2(3):808–840, 2008. Cited in Chapter 20.
- P. H. Van Elteren. On the combination of independent statistical tests. *Statistica Neerlandica*, 14(1):11–24, 1960. Cited in Chapter 5.
- Tyler J. VanderWeele and Peng Ding. Introducing the e-value. *Annals of Internal Medicine*, 167(4):285, 2017. Cited in Chapters 17, 18.