

因果推断讲义

Peng Ding

Contents

引言：文献概述	7
引言：文献概述	7
1. 总述	7
2. 文献摘要总结	7
3. 补充参考资料	8
4. 学习路径与前置基础知识	8
5. 最终目标	8
Chapter 1. 相关性、关联与 Yule-Simpson 悖论	9
1. 本章导论	9
2. 为什么这个问题很重要	9
3. 相关性与因果性的区别	9
4. 二维列联表与关联度量	9
5. Yule-Simpson 悖论	10
6. 偏相关系数与 Yule-Simpson 悖论	10
7. LaLonde 数据与规格搜索问题	11
8. 种族歧视的简历实验	11
9. 本章小结与下节预告	11
10. 习题	11
Chapter 2. 潜在结果框架	13
1. 从相关到因果：为什么关联不够？	13
2. 一个思想实验	13
3. 科学表 (Science Table)	14
4. 个体因果效应	14
5. 平均因果效应	14
6. 亚组与亚组因果效应	14
7. 亚组因果效应与 Yule-Simpson 悖论的不存在	15
8. 治疗分配机制与基本恒等式	15
9. SUTVA：使框架有效的必要假设	16
10. 反事实思维的逻辑	16
11. 实验单元定义的微妙性	17
12. 非线性因果参数	17
13. 本章小结	17
14. 习题	18
Chapter 3. 完全随机实验与费舍尔随机化检验	19
1. 从潜在结果框架到随机实验：问题的起源	19
2. Fisher 的洞见：随机化的两个原则	19

3. 完全随机实验的定义	19
4. Sharp Null 假设与 FRT 逻辑	20
5. 随机化分布与精确 p 值	20
6. Monte Carlo 近似	21
7. 检验统计量的规范选择	21
8. FRT 与传统 t 检验的关系	28
9. LaLonde 实验数据案例	29
10. 历史侧边栏: 随机实验的起源	29
11. Sharp Null 假设的置信区间	30
12. 本章小结	30
13. 习题	30
Chapter 4. Neymanian 重复抽样推断	33
1. 两种推断哲学的对话	33
2. 有限总体量	33
3. 一个关键引理	34
4. Neyman (1923) 定理	34
5. 方差公式的理解	35
6. Neyman (1923) 定理的证明	35
7. 渐近正态性与置信区间	36
8. Neymanian 推断与 OLS 的关系	37
9. 重尾结局与正态近似的失效	38
10. 本章小结	38
11. 习题	38
Chapter 5. 分层与后分层随机实验	41
1. 引言: 随机化的艺术	41
2. SRE 的定义与记号	41
3. 层别平均因果效应	42
4. SRE 中的 Fisher 随机化检验	42
5. Neymanian 推断	45
6. SRE 与 CRE 的效率比较	46
7. CRE 中的后分层	47
8. 实践中的问题	47
9. 本章小结	47
10. 习题	48
Appendix A. 公式推导	51
1. Lemma 4.1 的证明: 方差与协方差的关系	51
2. 差值均值统计量的方差分解	52
3. Wilcoxon 秩和统计量的方差推导	54
4. 女士品茶实验的超几何分布	55
5. 差值均值统计量的期望与方差推导	56
6. CRE 中分层平衡性的推导	57
7. 分层估计量的期望与方差推导	58
8. 分层 Neymanian 方差的推导	60
9. CRE 与 SRE 方差差异的推导	61
10. CRE 条件分布的推导	62

11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明	63
Appendix A. 问答与注解	67
1. 阅读过程中的问题与解答	67
2. 学习笔记	71
Appendix. Bibliography	73

引言：文献概述

本学习资料旨在系统研究因果推断（Causal Inference）的基础理论与方法。因果推断是现代统计学和计量经济学最重要的研究领域之一，它关注如何从观测数据或实验数据中推断出因果关系，而不仅仅是相关关系。

1. 总述

在科学研究中，“相关并不意味着因果”是一个基本常识。然而，在实际研究中，我们常常需要回答因果性问题：某种治疗是否有效？某个政策是否达到了预期效果？某个变量之间的关联是否具有因果性质？

Rubin (1974) 提出的潜在结果框架（Potential Outcomes Framework）为因果推断奠定了理论基础。在该框架下，每个单元在不同处理条件下都有对应的潜在结果，而我们只能观测到其中一个。这种“因果推断基本问题”推动了各种推断方法的发展。

本课程以 Peng Ding 的《A First Course in Causal Inference》为主教材，系统学习：

- 完全随机化实验中的因果推断方法
- Fisher 随机化检验与 Neyman 重复抽样推断
- 分层分析与后分层技术
- 观测性研究中的因果推断
- 倾向得分、工具变量、回归断点设计等高级主题

2. 文献摘要总结

2.1. A First Course in Causal Inference.

- (1) **作者:** Peng Ding (丁鹏)
- (2) **链接:** <https://arxiv.org/abs/2305.18793>
- (3) **年份:** 2023
- (4) **篇幅:** 490 页
- (5) **核心贡献:**
 - 系统整合了 Fisher 精确推断与 Neyman 渐近推断两大框架
 - 提出了条件随机化实验 (CRE) 的统一处理方法
 - 详细讨论了分层、后分层与协变量平衡技术
 - 涵盖了观测性研究中的因果推断主流方法
- (6) **摘要:** This book provides an introduction to causal inference for students and researchers interested in estimating treatment effects from randomized experiments and observational studies. It unifies the potential outcomes framework with a focus on randomization-based inference, covering topics from basic concepts like the Yule-Simpson paradox to advanced methods including propensity score matching, instrumental variables, and sensitivity analysis. The book emphasizes both finite-sample exact inference (Fisher's approach) and asymptotic inference (Neyman's approach), providing readers with a comprehensive toolkit for causal analysis.

- (7) **关键词:** Causal Inference; Potential Outcomes; Randomization Test; Neyman Inference; Observational Studies; Propensity Score

3. 补充参考资料

- **Imbens and Rubin (2015):** *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press. —因果推断的权威教材。
- **Rubin (1974):** “Estimating Causal Effects of Treatments in Randomized and Non-Randomized Studies.” *Journal of Educational Psychology*. —潜在结果框架的奠基性论文。
- **Rosenbaum and Rubin (1983):** “The Central Role of the Propensity Score in Observational Studies for Causal Effects.” *Biometrika*. —倾向得分理论的开创性工作。
- **Angrist and Pischke (2009):** *Mastering ‘Metrics.’* Princeton University Press. —计量经济学因果推断的入门读物。

4. 学习路径与前置基础知识

数学基础:

- 概率论：条件概率、条件期望、方差与协方差
- 统计学：点估计、置信区间、假设检验
- 线性代数：矩阵运算、特征值

概率不等式:

- Markov 不等式、Chebyshev 不等式
- Hoeffding 不等式、Chernoff 界
- CLT (中心极限定理)

推荐学习顺序:

- (1) 第 1-2 章：基础概念（相关与因果、潜在结果）
- (2) 第 3-4 章：完全随机化实验（Fisher 检验与 Neyman 推断）
- (3) 第 5 章：分层与后分层
- (4) 第 6-8 章：随机化实验的高级话题
- (5) 第 9 章：有限总体与超总体的统一框架
- (6) 第 10-18 章：观测性研究方法

5. 最终目标

完成本课程学习后，期望达到以下目标：

- **理论理解：**深入理解潜在结果框架，掌握 Fisher 精确推断与 Neyman 渐近推断的理论基础与联系。
- **方法掌握：**熟练运用各种因果推断方法，包括分层、协变量调整、倾向得分匹配、工具变量等。
- **应用能力：**能够针对实际研究问题设计合适的因果推断策略，正确解读分析结果。
- **批判思维：**能够识别因果推断中的常见陷阱（如辛普森悖论、选择偏差、混杂因素），并进行敏感性分析。

CHAPTER 1

相关性、关联与 Yule-Simpson 悖论

1. 本章导论

本章我们要回答一个看似简单却至关重要的问题：**相关性能否直接告诉我们因果关系？**

在日常生活中，我们经常听到这样的话：

- ”吸烟会导致肺癌”
- ”教育水平越高，收入越高”
- ”经常锻炼的人更长寿”

这些陈述都试图建立因果关系。但我们是如何得出这些结论的？仅仅因为我们观察到了相关性（correlation）就足够了么？

2. 为什么这个问题很重要

想象一下以下场景：

例 1.1. 一家公司想要知道某种新药是否有效。他们给一组患者服用新药，另一组服用安慰剂。结果显示服药组的康复率更高。这能否说明药物有效？

直觉告诉我们，这似乎能说明问题。但仔细想想，还有很多其他因素可能影响结果：

- 也许服药组的患者本身就更健康
- 也许医生在给药时，无意中对服药组患者更加关照
- 也许这只是随机波动

这就是因果推断（causal inference）的核心挑战：**我们观察到的关联（association），并不等于因果关系（causal relationship）。**

3. 相关性与因果性的区别

统计学中，我们用不同的术语来区分这些概念：

- **相关性（Correlation）**：两个变量共同变化的趋势
- **关联（Association）**：统计学意义上的依赖关系
- **因果性（Causation）**：一个变量的变化直接导致另一个变量变化

关键洞察：相关性可以是因果的，也可以是非因果的。

4. 二维列联表与关联度量

将 Z 视为治疗或暴露， Y 视为结果，可以定义以下关联度量：

	$Y = 1$	$Y = 0$
$Z = 1$	p_{11}	p_{10}
$Z = 0$	p_{01}	p_{00}

风险差 (Risk Difference):

$$RD = \mathbb{P}(Y = 1 \mid Z = 1) - \mathbb{P}(Y = 1 \mid Z = 0) = \frac{p_{11}}{p_{11} + p_{10}} - \frac{p_{01}}{p_{01} + p_{00}}$$

风险比 (Risk Ratio):

$$RR = \frac{\mathbb{P}(Y = 1 \mid Z = 1)}{\mathbb{P}(Y = 1 \mid Z = 0)} = \frac{p_{11}}{p_{11} + p_{10}} \bigg/ \frac{p_{01}}{p_{01} + p_{00}}$$

优势比 (Odds Ratio):

$$OR = \frac{\mathbb{P}(Y = 1 \mid Z = 1)/\mathbb{P}(Y = 0 \mid Z = 1)}{\mathbb{P}(Y = 1 \mid Z = 0)/\mathbb{P}(Y = 0 \mid Z = 0)} = \frac{p_{11}p_{00}}{p_{10}p_{01}}$$

关于记号: 本书使用符号 $\perp$ 表示随机变量的独立性或条件独立性。

命题 1.1 (二维列联表中的独立性). (1) 以下命题等价: $Z \perp Y$ 、 $RD = 0$ 、 $RR = 1$ 、 $OR = 1$ 。

(2) 若所有 $p_{zy} > 0$, 则 $RD > 0$ 等价于 $RR > 1$, 也等价于 $OR > 1$ 。

(3) 若 $\mathbb{P}(Y = 1 \mid Z = 1)$ 和 $\mathbb{P}(Y = 1 \mid Z = 0)$ 都很小, 则 $OR \approx RR$ 。

5. Yule-Simpson 悖论

悖论的核心思想: 在总体中观察到的关联方向, 可能与分层后各组中的关联方向相反。

例 1.2 (经典的 Yule-Simpson 悖论例子). 考虑一个大学录取数据:

院系	男生录取率	女生录取率
A	62% (341/550)	82% (137/167)
B	63% (28/44)	68% (24/35)
总体	45% (369/816)	30% (161/525)

有趣的现象:

- 在 A 院系, 男女生录取率分别是 62% 和 82%
- 在 B 院系, 男女生录取率分别是 63% 和 68%
- 但总体来看, 男生的录取率反而更高!

这就是 *Yule-Simpson 悖论*: 在每个分层中都有利的因素, 在总体中可能不利。

这个例子揭示了一个深刻的问题: 如果我们不控制混杂因素 (*confounding factors*), 就可能得出完全错误的因果结论。

6. 偏相关系数与 Yule-Simpson 悖论

考虑三维正态随机向量:

$$\begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho_{XY} & \rho_{XZ} \\ \rho_{XY} & 1 & \rho_{YZ} \\ \rho_{XZ} & \rho_{YZ} & 1 \end{pmatrix} \right)$$

Y 和 Z 的偏相关系数 $\rho_{YZ|X}$ 定义为在条件分布 $(Y, Z) \mid X$ 中的相关系数。

命题 1.2 (偏相关系数公式).

$$\rho_{YZ|X} = \frac{\rho_{YZ} - \rho_{YX}\rho_{ZX}}{\sqrt{1 - \rho_{YX}^2}\sqrt{1 - \rho_{ZX}^2}}$$

重要含义：即使 $\rho_{YZ} > 0$ ，偏相关系数 $\rho_{YZ|X}$ 仍可能为负！这正是正态随机向量情形下的 Yule-Simpson 悖论。

7. LaLonde 数据与规格搜索问题

LaLonde 数据集包含参与职业培训项目 (National Supported Work Demonstration) 的参与者的结果。在观察性研究中，协变量选择的敏感性是一个重要问题。

当我们运行 $2^{10} = 1024$ 种可能的协变量子集回归时，treatment 系数的显著性可能对模型规格高度敏感。这提醒我们：在观察性研究中，规格搜索可能导致误导性结论。

8. 种族歧视的简历实验

Bertrand and Mullainathan (2004) 通过随机改变简历上的名字来研究种族歧视。这些名字被设计成听起来像非裔美国人或白人的名字。实验显示，有黑人名字的简历回调率显著较低。

当我们分别对男性和女性进行分析时，可能会发现有趣的亚组差异——这进一步说明“平均效应”可能掩盖了重要的异质性。

9. 本章小结与下节预告

本章的核心要点：

- (1) **相关性 $\neq$ 因果性：**观察到的关联可能是由于混杂因素造成的
- (2) **关联度量：**RD、RR、OR 及它们与独立性的关系
- (3) **Yule-Simpson 悖论：**总体关联可能与分层关联方向相反
- (4) **偏相关：**即使边际相关为正，偏相关仍可能为负
- (5) **因果推断的必要性：**我们需要系统性的方法来区分真实的因果效应

下一章我们将学习因果推断的基石——**潜在结果框架 (Potential Outcomes Framework)**，这将为我们的因果分析提供坚实的数学基础。

10. 习题

练习 1.1. 1.1 独立性命题的证明 证明 Proposition 1.1 中的命题 (1) 和 (2)。

练习 1.2. 1.2 Yule-Simpson 悖论的更多例子

- (1) 给出一个 $2 \times 2 \times 2$ 列联表的数值例子，其中出现 Yule-Simpson 悖论。
- (2) 找一个现实生活中的 Yule-Simpson 悖论例子。

练习 1.3. 1.3 相关与偏相关 考虑三维正态随机向量 $(X, Y, Z)^T \sim N(\mathbf{0}, \Sigma)$ 。

证明偏相关系数公式 (见 Proposition 1.2)。

给出一个 $\rho_{YZ} > 0$ 但 $\rho_{YZ|X} < 0$ 的数值例子。

注：这是正态随机向量情形下的 Yule-Simpson 悖论。

练习 1.4. 1.4 规格搜索 重做 Hainmueller (2012) 的数据分析。使用结局 `re78` 和治疗 `treat`。数据集还包含 10 个协变量，共有 $2^{10} = 1024$ 种可能的协变量子集组合。运行所有可能的线性回归子集，并报告 treatment 系数的分布：有多少是正显著、负显著、不显著的？

练习 1.5. 1.5 种族歧视的进一步分析 重做 Bertrand and Mullainathan (2004) 的简历数据分析。分别对男性和女性进行分析，讨论亚组分析的结果与总体结论的差异。

练习 1.6. 1.6 推荐阅读 **推荐阅读**: *Bickel et al. [1975]* 是关于 *Berkeley* 录取数据悖论的原始论文。*Pearl and Mackenzie [2018]* 从因果推断角度重新审视了该研究。

历史注记: *Holland [1986]* 是统计因果推断领域的经典综述文章，它推广了“*Rubin* 因果模型”这一名称。在 *UC Berkeley*，我们称之为“*Neyman* 模型”——原因显而易见。

CHAPTER 2

潜在结果框架

1. 从相关到因果：为什么关联不够？

在第一章中，我们见证了一个令人不安的现象：Yule-Simpson 悖论向我们展示了关联可以与因果相悖。两组数据分别显示的正向效应，在合并后可能变为负向——这警告我们，从关联推断因果是危险的。

但我们不禁要问：关联毕竟是我们能观察到的，而因果是我们真正想知道的。那么，因果效应能否被清晰地定义，甚至被估计？

这个问题引导我们走向一个优雅而强大的框架——潜在结果框架（Potential Outcomes Framework），也被称为 Neyman-Rubin 因果模型。

这个框架的起源可以追溯到 Neyman 在 1923 年的开创性工作，以及 Rubin 在 1970 年代对其的进一步发展。它的核心思想其实出奇地简单：要谈论因果，我们必须想象 (counterfactual) 如果事情有所不同会发生什么。

2. 一个思想实验

让我们从一个最简单的场景开始：假设我们想研究某种新药对患者康复的因果效应。考虑第 i 个患者。我们记：

- $T_i = 1$ ：患者接受了治疗
- $T_i = 0$ ：患者未接受治疗（对照组）

现在，关键的问题来了：这个患者的结果会是什么？

在现实中，我们只能观察到一种情况——要么患者接受了治疗，要么没有。但为了谈论因果，我们必须同时考虑两种可能性：

- $Y_i(1)$ ：如果患者接受治疗，会观察到的结果
- $Y_i(0)$ ：如果患者未接受治疗，会观察到的结果

这里， $Y_i(1)$ 和 $Y_i(0)$ 就是**潜在结果**——它们描述了在不同治疗状态下可能发生的结果，但我们永远无法同时观察到两者。

注 2.1 (注 2.1 —什么是反事实). **反事实** (counterfactual) 指的是未被观测到的潜在结果。具体而言：

- 对于治疗组个体 i ($Z_i = 1$)，我们观察到 $Y_i(1)$ ，而 $Y_i(0)$ 是反事实
- 对于对照组个体 i ($Z_i = 0$)，我们观察到 $Y_i(0)$ ，而 $Y_i(1)$ 是反事实

正因为潜在结果框架讨论的是“如果接受相反治疗会怎样”，所以它也被称为**反事实框架** (counterfactual framework)。这个名字可能造成混淆——在实验前，两种潜在结果都客观存在；只有在实验后，其中一个变为现实，另一个才成为反事实。

注 2.2. 什么叫“潜在”结果？：因为它们描述的是“如果... 会怎样”的情形，这种结果是“潜在的”而非“现实的”。这正是 counterfactual (反事实) 思维的本质。

3. 科学表 (Science Table)

Rubin [2005] 将潜在结果组成的 $n \times 2$ 矩阵称为**科学表 (Science Table)**:

i	$Y_i(1)$	$Y_i(0)$
1	$Y_1(1)$	$Y_1(0)$
2	$Y_2(1)$	$Y_2(0)$
$\vdots$	$\vdots$	$\vdots$
n	$Y_n(1)$	$Y_n(0)$

这个表包含了所有我们需要知道的关于因果效应的信息——但问题是，我们永远只能观察到每一行的其中一个值。

4. 个体因果效应

有了潜在结果，我们终于可以清晰地定义因果效应了。

对于个体 i ，定义**个体因果效应 (Individual Treatment Effect, ITE)** 为：

$$\tau_i = Y_i(1) - Y_i(0)$$

这是治疗相对于对照的“净效果”。

但是，这里出现了一个根本性的困难。1923 年，Jerzy Neyman 在一篇关于田间试验的论文中首次明确指出了这个问题：

对于每个个体，我们只能观察到一种潜在结果——实际发生的那种。另一种潜在结果是潜在的、永不可见的。

这被称为**因果推断的根本问题 (Fundamental Problem of Causal Inference)**。

注 2.3. **为什么这个困难如此根本？**：因为科学上感兴趣的大多数因果问题，都涉及将现实与反事实进行比较。我们可以问“这种药对这个患者有效吗？”——但这个问题要求我们同时知道患者吃药和不吃药的结果，而这是不可能的。

5. 平均因果效应

既然个体因果效应不可测量，我们退而求其次，关注**平均因果效应 (Average Causal Effect, ACE)**：

$$\tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0)$$

用更精确的有限总体记号：

$$\tau = \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} = \frac{1}{n} \sum_{i=1}^n Y_i(1) - \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

一个**关键恒等式**：平均因果效应等于个体因果效应的均值：

$$\tau = \bar{Y}(1) - \bar{Y}(0) = \frac{1}{n} \sum_{i=1}^n \tau_i$$

6. 亚组与亚组因果效应

亚组 (subgroup) 是由某个协变量（通常是二元变量 X_i ）分割出来的子群体。例如：

- 按性别分割：男性亚组 ($X_i = 1$) 和女性亚组 ($X_i = 0$)
- 按年龄分割：老年人/年轻人
- 按收入分割：高收入/低收入

亚组因果效应 (Subgroup Causal Effect) 衡量的是在该亚组内的平均因果效应:

$$\tau_x = \frac{\sum_{i=1}^n \mathbb{I}(X_i = x) \{Y_i(1) - Y_i(0)\}}{\sum_{i=1}^n \mathbb{I}(X_i = x)}, \quad (x = 0, 1)$$

7. 亚组因果效应与 Yule-Simpson 悖论的不存在

一个简单的恒等式是:

$$\tau = \pi_1 \tau_1 + \pi_0 \tau_0$$

其中 $\pi_x = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = x)$ 是 $X_i = x$ 的单元比例。

证明 (推导). 根据定义:

$$\begin{aligned} \tau &= \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} \\ &= \frac{1}{n} \sum_{i=1}^n [\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0)] \{Y_i(1) - Y_i(0)\} \\ &\quad \text{其中每单元满足 } \mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1 \\ &= \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}_{\text{treatment 组}} + \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}_{\text{control 组}} \\ &= \frac{n_1}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}{n_1}}_{\tau_1} + \frac{n_0}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}{n_0}}_{\tau_0} \\ &= \pi_1 \tau_1 + \pi_0 \tau_0. \end{aligned}$$

其中 $n_1 = \sum_{i=1}^n \mathbb{I}(X_i = 1)$, $n_0 = \sum_{i=1}^n \mathbb{I}(X_i = 0)$ 。

关键推论: 如果 $\tau_1 > 0$ 且 $\tau_0 > 0$, 则必有 $\tau > 0$ 。因此, **Yule-Simpson 悖论在因果效应层面不可能发生!** 这澄清了第一章的困惑。

8. 治疗分配机制与基本恒等式

设 Z_i 是单元 i 的二元治疗指示变量, 观测结果 Y_i 是潜在结果和治疗分配的函数:

$$\begin{aligned} (1) \quad Y_i &= \begin{cases} Y_i(1), & \text{if } Z_i = 1 \\ Y_i(0), & \text{if } Z_i = 0 \end{cases} \\ (2) \quad &= Z_i Y_i(1) + (1 - Z_i) Y_i(0) \\ (3) \quad &= Y_i(0) + Z_i \{Y_i(1) - Y_i(0)\} \\ (4) \quad &= Y_i(0) + Z_i \tau_i \end{aligned}$$

Pearl [2010] 将 eq. (2) 视为潜在结果与观测结果之间的**基本桥梁**。这些方程强调了个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 可能在不同单元间存在异质性。

9. SUTVA：使框架有效的必要假设

使用潜在结果框架需要一些技术性假设。其中最重要的是**稳定单位治疗值假设** (Stable Unit Treatment Value Assumption, SUTVA)。

假设 2.1 (无干扰). 单元 i 的潜在结果不依赖于其他单元的治疗分配。这有时被称为**无干扰假设**。

假设 2.2 (一致性). 治疗水平没有其他版本。等价地，我们要求治疗水平是良好定义的，至少对关注的结局是如此。这有时被称为**一致性假设**。

假设 2.3 (SUTVA). 假设 2.1 和 2.2 同时成立。

违反 SUTVA 的例子：

无干扰假设 (no-interference assumption) 违反的情形：

- (1) **传染病与疫苗接种 (infectious diseases and vaccination)**：当疾病具有传染性时，一个人是否接种疫苗不仅影响他自己的患病风险，还影响他周围人被感染的概率。例如，如果我的同事接种了流感疫苗，我患流感的概率也会降低——即使我自己没有接种。在这种情况下，单元 i 的潜在结果 $Y_i(1)$ 和 $Y_i(0)$ 都依赖于其他人的治疗分配。
- (2) **网络效应实验 (network experiments)**：在社交网络实验中，如果一个人收到 Facebook 广告 (treatment)，他的朋友看到这条广告并受到影响后，可能也会购买该产品——即使朋友本人没有直接收到广告。这就是所谓的**溢出效应 (spillover effect)**。
- (3) **随机区组实验中的相邻地块 (neighboring plots in randomized block experiments)**：农业实验中，相邻地块的作物可能相互影响——如果相邻地块使用了肥料，可能会通过土壤渗透影响本地块的产量。

一致性假设 (consistency assumption) 违反的情形：

- (1) **复合治疗 (composite treatments)**：当治疗本身有复杂组成部分时，相同的“治疗”标签可能对应不同的实际干预。例如：
 - 研究吸烟 (smoking) 对肺癌的影响时，“吸烟”这个治疗有多种形式——香烟类型、吸烟频率、吸入深度等，这些都可能产生不同的潜在结果。
 - 研究大学教育 (college education) 对收入的影响时，“上大学”这个治疗包括大学类型 (985/211 vs 普通院校)、专业、文凭等级等，这些差异会造成潜在结果的不一致。
- (2) **剂量效应 (dosage effects)**：在医学研究中，相同的药物名称可能对应不同剂量，而剂量直接影响疗效。例如“服用阿司匹林”作为治疗，但不同剂量的阿司匹林会产生完全不同的潜在结果。
- (3) **实施变异 (implementation variation)**：即使治疗名义上相同，不同实施者可能引入差异。例如，心理治疗研究中，不同治疗师的风格和技能可能导致相同的“心理治疗”产生不同效果。

当 SUTVA 不成立时，潜在结果框架需要修正。**现代因果推断文献**（如 Hudgens and Halloran, 2008）正在积极研究如何处理存在干扰或治疗版本多样的情形。

注 2.4. **SUTVA 的历史重要性**：Rubin (1980) 将 SUTVA 确立为潜在结果框架的基础假设，没有 SUTVA，因果推断的数学化是不可能的。

10. 反事实思维的逻辑

也许你会好奇：为什么不能简单地问“实际发生的结果是什么”？

答案是：**因果效应本质上是一个反事实 (counterfactual) 概念**。当我们问“这种药是否有效”时，我们实际上是在问：

“如果这个患者吃了药，结果会怎样？但现实是，他可能没有吃药...”

这种思维方式可能让人觉得抽象甚至哲学化，但它是我们谈论因果的唯一严谨方式。潜在结果框架的价值在于，它将这种哲学洞察转化为清晰的数学语言。

11. 实验单元定义的微妙性

我讨论一个与实验单元定义相关的微妙之处。简单来说，**实验单元可能不同于物理单元**。

例如，如果我在服药前没有服用阿司匹林且头痛没有消失，但我现在服用阿司匹林后头痛消失了，你可能认为我们可以同时观察到我的两种潜在结果。但这是对实验单元定义的误解！在不同时刻，我是同一个物理人，但成为了两个不同的实验单元。

因此，我们有四个潜在结果，其中两个被观察到，两个缺失。这说明，即使观察到的数据显示治疗“有效”，我们也无法确定地说阿司匹林就是原因——因为在“治疗后”的状态下，可能存在其他因素（如时间效应）导致头痛消失。

12. 非线性因果参数

平均因果效应是一个**线性**因果参数，因为潜在结果的平均差等于个体差别的平均。其他参数可能不是线性的。

例如，中位数治疗效应：

$$\delta_1 = \text{median}\{Y_i(1)\}_{i=1}^n - \text{median}\{Y_i(0)\}_{i=1}^n$$

通常不同于个体治疗效应的中位数：

$$\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\}_{i=1}^n$$

这两个量在某些情况下可能相差很大。

13. 本章小结

本章建立因果推断的数学语言：

- (1) **潜在结果**：为每个个体定义 $Y_i(1)$ 和 $Y_i(0)$
- (2) **科学表**： $n \times 2$ 矩阵 $\{Y_i(1), Y_i(0)\}_{i=1}^n$
- (3) **个体因果效应**： $\tau_i = Y_i(1) - Y_i(0)$
- (4) **平均因果效应**： $\tau = \bar{Y}(1) - \bar{Y}(0) = n^{-1} \sum_{i=1}^n \tau_i$
- (5) **根本问题**：我们只能观察到一种潜在结果
- (6) **基本桥梁方程**： $Y_i = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$
- (7) **SUTVA**：一致性 + 无干扰
- (8) **Yule-Simpson 悖论**在因果框架下不可能发生

下一章我们将看到，**随机实验**提供了一种绕过根本问题的优雅方式——通过随机分配治疗，我们可以建立组间可比性，从而识别因果效应。

14. 习题

练习 2.1. 2.1 完美的医生 假设潜在结果由以下模型生成：

$$Y(0) \sim N(0, 1), \quad \tau = -0.5 + Y(0), \quad Y(1) = Y(0) + \tau$$

治疗分配为 $Z = \mathbb{I}(\tau \geq 0)$ ，观测结果为 $Y = ZY(1) + (1 - Z)Y(0)$ 。

计算条件均值差 $\mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0)$ 。

提示：需要使用截断正态分布的均值公式。当 $X \sim N(\mu, \sigma^2)$ 时，

$$\mathbb{E}(X \mid a < X < b) = \mu - \sigma \frac{\phi\left(\frac{b-\mu}{\sigma}\right) - \phi\left(\frac{a-\mu}{\sigma}\right)}{\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)}$$

其中 ϕ 和 Φ 分别是标准正态分布的密度函数和分布函数。

练习 2.2. 2.2 非线性因果参数 证明平均因果效应是线性因果参数的例子，即 $\bar{Y}(1) - \bar{Y}(0) = n^{-1} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\}$ 。

其他参数可能不是线性的。例如，定义中位数治疗效应为：

$$\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\}$$

这通常不同于个体治疗效应的中位数：

$$\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\}$$

(1) 给出数值例子分别满足 $\delta_1 = \delta_2$ 、 $\delta_1 > \delta_2$ 和 $\delta_1 < \delta_2$ 。

(2) 哪个参数更有意义？为什么？请用例子来证明你的结论。

练习 2.3. 2.3 平均效应与个体效应 给出一个数值例子，其中 $\tau = n^{-1} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} > 0$ ，但有不到一半的单元满足 $Y_i(1) > Y_i(0)$ 。即平均因果效应为正，但治疗对不到一半的单元有益。

练习 2.4. 2.4 推荐阅读 **推荐阅读：** *Holland [1986]* 是统计因果推断领域的经典综述文章，它推广了“Rubin 因果模型”这一名称。在 *UC Berkeley*，我们称之为“Neyman 模型”——原因显而易见。

完全随机实验与费舍尔随机化检验

1. 从潜在结果框架到随机实验：问题的起源

在第 ?? 章中，我们建立了**潜在结果框架 (Potential Outcomes Framework)**，学会了如何清晰地定义因果效应。平均因果效应定义为：

$$(3.1) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0)$$

但我们也清楚地看到了因果推断的**根本问题 (Fundamental Problem of Causal Inference)**：对于每个个体，我们只能观察到一种潜在结果， $Y_i(1)$ 和 $Y_i(0)$ 无法同时被观测。¹ 这意味着，即使我们定义了因果效应，我们也不知道如何用数据来估计它——因为每个单元的“反事实结果”永远无法被观测到。

第 ?? 章的类比：在第 ?? 章中，我们讨论了**相关性不等于因果性**——即使 X 和 Y 相关，我们也无法断定 X 导致 Y 。第 ?? 章通过潜在结果框架给因果效应一个精确的定义，但它留下的核心问题是：我们如何用实际观测到的数据来**识别 (identify)** 和**估计 (estimate)** 这些潜在结果？

那么，一个自然的问题是：我们能否设计某种**数据收集过程**，使得即使无法观察反事实，我们仍然可以估计因果效应？

这个问题的答案是肯定的，而解决方案就是**随机实验 (Randomized Experiment)**——统计学的黄金标准，也是 Fisher 称之为“the design of experiments”的精髓所在。

2. Fisher 的洞见：随机化的两个原则

Ronald Fisher 在 1935 年的开创性著作《Design of Experiments》中指出了随机化的两个优势：

- (1) **可比性**：它创造了在平均意义上可比的 treatment 和 control 组。
- (2) **推理基础**：它作为统计推断的“合理基础”。

第一点直观易懂——随机治疗分配不会偏向 treatment 或 control。第二点更微妙：Fisher 的意思是，随机化为统计检验提供了正当理由，这就是现在所谓的**费舍尔随机化检验 (Fisher Randomization Test, FRT)**^{2, 3}。

3. 完全随机实验的定义

考虑一个包含 n 个单元的实验，其中 n_1 个接受治疗， n_0 个接受对照 ($n = n_1 + n_0$)。

定义 3.1 (CRE). 固定 n_1 和 n_0 (其中 $n = n_1 + n_0$)。完全随机实验的治疗 *assignment* 机制为：

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}) = 1 / \binom{n}{n_1},$$

¹问：什么是潜在结果？见附录 section 1.9。

²问：什么是 Fisher Randomization Test？见附录 section 1.11。

³问：Fisher 随机化检验与经典假设检验有何不同？见附录 section 1.6。

其中 $\mathbf{z} = (z_1, \dots, z_n)$ 满足 $\sum_{i=1}^n z_i = n_1$ 和 $\sum_{i=1}^n (1 - z_i) = n_0$ 。

在这个定义中，我们假设潜在结果向量 $\mathbf{Y}(1)$ 和 $\mathbf{Y}(0)$ 都是固定的。即使将它们视为随机的，我们可以在其上条件化，治疗分配机制变为：

$$\mathbb{P}\{\mathbf{Z} = \mathbf{z} \mid \mathbf{Y}(1), \mathbf{Y}(0)\} = 1 / \binom{n}{n_1}$$

因为在 CRE 中 $\mathbf{Z} \perp\!\!\!\perp \{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 。

关键含义：在 CRE 中， $\mathbf{Z}$ 是从 n_1 个 1 和 n_0 个 0 的随机排列中产生的。

4. Sharp Null 假设与 FRT 逻辑

Fisher [1935] 感兴趣检验的零假设是：

$$H_{0F} : Y_i(1) = Y_i(0) \text{ 对所有单元 } i = 1, \dots, n.$$

Rubin [1980] 称其为 **sharp null 假设**，因为它可以基于观测数据确定所有潜在结果： $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y} = (Y_1, \dots, Y_n)$ ，即观测结果向量。它也被称为**强零假设**。⁴

概念上，在 H_{0F} 下，FRT 适用于任何检验统计量：

$$(5) \quad T = T(\mathbf{Z}, \mathbf{Y}),$$

它是观测数据的函数。观测结果向量 $\mathbf{Y}$ 在 H_{0F} 下是固定的，所以 T 中唯一的随机成分是治疗向量 $\mathbf{Z}$ 。实验者决定 $\mathbf{Z}$ 的分布，进而决定 T 的分布——这就是计算 p 值的基础。

在 CRE 中， $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的，其中 $M = \binom{n}{n_1}$ ， $\mathbf{z}^m$ 是所有可能的包含 n_1 个 1 和 n_0 个 0 的向量。⁵

5. 随机化分布与精确 p 值

如果较大的 T 值更极端，我们可以使用以下尾概率来衡量检验统计量相对于其随机化分布的极端性：

$$(6) \quad p_{\text{firt}} = M^{-1} \sum_{m=1}^M \mathbb{I}\{T(\mathbf{z}^m, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}.$$

这就是 Fisher 的 p 值。重要的是， p_{firt} 在 eq. (6) 中对任何检验统计量和任何结果生成过程都有效。它在 H_{0F} 下是有限样本精确的 (finite-sample exact)。⁶

$$(7) \quad \mathbb{P}(p_{\text{firt}} \leq u) \leq u \quad \text{for all } 0 \leq u \leq 1.$$

注 3.1. 为什么叫“有限样本精确”？：这意味着 p 值的分布（虽然在离散情况下是阶梯函数）满足上式，因此 p 值在 $[0, 1]$ 上均匀分布（对于连续情况）。

⁴问：为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的？见附录 section 1.3。

⁵问： $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义是什么？见附录 section 1.12。

⁶问：什么是有限样本精确？见附录 section 1.5。

6. Monte Carlo 近似

在实践中, M 通常太大 (例如当 $n = 100, n_1 = 50$ 时, $M > 10^{29}$), 枚举所有可能的治疗向量在计算上是不可行的。我们经常用 Monte Carlo 来近似 p_{firt} , 并用修正公式 $\tilde{p}_{\text{firt}}$ 保证有限样本有效性。⁷⁸

$$(8) \quad \hat{p}_{\text{firt}} = R^{-1} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\},$$

其中 $\mathbf{z}^r$ 是 $\mathbf{Z}$ 的 R 次随机置换。由于计算 p_{firt} 涉及对 $\mathbf{Z}$ 的置换, FRT 有时在 CRE 语境下被称为**置换检验 (permutation test)**。

修正的有限样本有效近似:

$$\tilde{p}_{\text{firt}} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

这个修正在任意有限的 R 下都是有限样本有效的 p 值。

7. 检验统计量的规范选择

FRT 的一个特点是它对任何检验统计量都生成有限样本精确 p 值。但我们应该选择能够给出 H_{0F} 可能违背信息的检验统计量。

7.1. 差值均值统计量. 差值均值统计量是:

$$\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$$

其中

$$\hat{Y}(1) = n_1^{-1} \sum_{Z_i=1} Y_i = n_1^{-1} \sum_{i=1}^n Z_i Y_i$$

是 treatment 组的样本均值,

$$\hat{Y}(0) = n_0^{-1} \sum_{Z_i=0} Y_i = n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i$$

是 control 组的样本均值。

在 H_{0F} 下, $\hat{\tau}$ 有均值 0 和方差

$$(9) \quad \text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} s^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$, $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$ 。⁹

渐近分布: 由于有限总体中心极限定理 (Finite Population Central Limit Theorem), 随机化分布近似正态:

$$(10) \quad \frac{\hat{\tau}}{\sqrt{\frac{n}{n_1 n_0} s^2}} \rightarrow \mathcal{N}(0, 1)$$

in distribution.

⁷问: 为什么 Monte Carlo 近似需要修正? 见附录 section 1.4。

⁸问: 蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思? 见附录 section 1.13。

⁹ $\hat{\tau}$ 方差的完整推导见附录 section 5。

与经典 t 检验的联系：在 H_{0F} 下，近似 p 值接近经典两样本 t 检验（假设等方差）的 p 值。

基于代数运算（见习题 3.8），我们有如下展开式：

$$(11) \quad (n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

这个展开式的意义：这本质上是一个方差分解（ANOVA 分解）。将每个单元的偏差 $Y_i - \bar{Y}$ 分解为组内偏差 $(Y_i - \hat{Y}(Z_i))$ 和组间偏差 $(\hat{Y}(Z_i) - \bar{Y})$ ，平方求和后交叉项消失，留下三项：treatment 组内部变异、control 组内部变异，以及由治疗效应解释的变异 $\frac{n_1 n_0}{n} \hat{\tau}^2$ 。

例 3.1 (ANOVA 分解的代数推导). **核心思想：**将偏差 $Y_i - \bar{Y}$ 分解为组内偏差与组间偏差之和，平方后交叉项因正交性而消失。

关键步骤：

- (1) $(Y_i - \bar{Y}) = (Y_i - \hat{Y}(Z_i)) + (\hat{Y}(Z_i) - \bar{Y})$
- (2) 平方展开后，交叉项 $\sum 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}) = 0$ (因为 $\sum_{Z_i=1} (Y_i - \hat{Y}(1)) = 0$)
- (3) 组间平方和化简为 $\frac{n_1 n_0}{n} \hat{\tau}^2$

□

10

ANOVA 分解的几何直觉：将 n 维向量 $\mathbf{Y}$ 投影到 treatment 组和 control 组形成的两个正交子空间。组内平方和是残差平方和，组间平方和 $\frac{n_1 n_0}{n} \hat{\tau}^2$ 是由治疗分配解释的变异。关键发现： s^2 中混入了治疗效应信息，这解释了为什么 FRT 的 t 统计量在 H_{0F} 下能精确分布。

注 3.2. **为什么 FRT 能证明 t 检验的合理性？：**传统 t 检验需要正态性假设。但 FRT 框架表明，只要随机化分配正确执行， t 检验程序在有限总体 + 随机化情境下可以使用——渐近理论只依赖于有限总体 CLT，而不依赖于数据的原始分布。

7.2. 学生化统计量。差值均值隐含地假设两组方差相等。如果治疗可能影响结果的变异性（异方差），我们需要使用学生化统计量：

$$t = \frac{\hat{Y}(1) - \hat{Y}(0)}{\sqrt{\frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}}},$$

其中

$$\hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2, \quad \hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2$$

分别是 treatment 组和 control 组的样本方差。

在 H_{0F} 下，有限总体 CLT 再次意味着 t 渐近正态： $t \rightarrow \mathcal{N}(0, 1)$ 。

这个统计量与 `t.test(var.equal = FALSE)` 的 p 值接近。

注 3.3. **学生化为什么更稳健？：**当 treatment 组和 control 组的方差差异较大时，差值均值的检验可能失效。学生化通过分别估计两组的方差，能够更好地处理异方差情况。

¹⁰ANOVA 分解的完整代数推导见附录 section 2。

7.3. 卡方检验：分类数据的拟合优度与独立性. 迄今为止我们关注的都是连续型结局。但统计学同样关注**分类数据 (categorical data)**——即计数数据。例如：选举中支持不同候选人的选民人数、不同药物治疗后的治愈/未治愈人数。卡方检验 (Chi-Square Test) 正是处理这类数据的核心工具。

Insight 连续数据关注“均值差异”，分类数据关注“频数差异”。这两类数据的分析方法有本质区别——连续数据用 t 检验或 z 检验，分类数据用卡方检验。理解这一点，才能在实战中选对武器。

卡方检验由卡尔·皮尔逊 (Karl Pearson) 于 1900 年提出，核心思想是：**比较观测频数与期望频数。如果两者差异很大，说明数据可能不服从假设的分布或独立性结构。*

7.3.1. 拟合优度检验. **问题：**数据是否来自某个特定分布？

设有 k 个类别的观测频数 $O_1, O_2, \dots, O_k$ ，总样本量为 n 。在零假设 H_0 下，第 i 类的期望频数为 $E_i = np_{i0}$ ，其中 p_{i0} 是 H_0 规定的理论概率。

皮尔逊卡方统计量：

$$(4.5.1) \quad \chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

直观理解： $(O_i - E_i)^2/E_i$ 衡量每个类别的偏差——平方消去正负号，除以 E_i 进行标准化（一个大类的 100 偏差比一个小类的 100 偏差更重要），求和得到总体偏离程度。

渐近分布：在 H_0 下，当样本量 n 足够大时，

$$\chi^2 \xrightarrow{d} \chi_{k-1}^2$$

自由度为 $k-1$ ，因为只有一个约束—— $\sum O_i = \sum E_i = n$ 。

决策规则：计算 χ^2 值，若 $\chi^2 > \chi_{\alpha, k-1}^2$ (临界值)，则拒绝 H_0 。

Insight 为什么自由度是 $k-1$ ？因为 k 个类别的观测频数之和必须等于 n ，这产生了一个线性约束。所以 k 个类别中只有 $k-1$ 个可以自由变化——最后一个由总和决定。

例 3.2 (骰子检验——硬币是否均匀?) . **背景：**投掷一枚骰子 120 次，想检验它是否均匀 (各面概率均为 $1/6$)。

观测数据：

面	1	2	3	4	5	6
观测频数 O_i	15	22	18	25	17	23
期望频数 E_i	20	20	20	20	20	20

计算：

$$\chi^2 = \frac{(15-20)^2}{20} + \frac{(22-20)^2}{20} + \frac{(18-20)^2}{20} + \frac{(25-20)^2}{20} + \frac{(17-20)^2}{20} + \frac{(23-20)^2}{20} = 4.3$$

自由度 $k-1=5$ ，查表得 $\chi_{0.05,5}^2 = 11.07$ 。

由于 $4.3 < 11.07$ ，在 $\alpha = 0.05$ 水平下**不能拒绝**均匀性假设。

R 实现：

```
> obs <- c(15, 22, 18, 25, 17, 23)
> chisq.test(obs, p = rep(1/6, 6))
```

```
Chi-squared test for given probabilities
```

```
X-squared = 4.3, df = 5, p-value = 0.507
```

p 值为 0.507, 远大于 0.05, 与手工计算一致。

□

Insight 骰子例子中, $E_i = 20$ 都相同。如果某个类别期望频数太小 (< 5), 渐近近似的精度会下降, 此时应该用精确检验 (exact test) 或合并相邻类别。

例 3.3 (遗传学——孟德尔豌豆实验). **背景**: 孟德尔杂交黄色圆粒豌豆与绿色皱粒豌豆, 预期后代比例为:

$$\text{黄圆} : \text{黄皱} : \text{绿圆} : \text{绿皱} = 9 : 3 : 3 : 1$$

观测数据 (共 556 株):

$$O = (315, 101, 108, 32), \quad E = (556 \times \frac{9}{16}, \dots) = (312.75, 104.25, 104.25, 34.75)$$

计算:

$$\chi^2 = \frac{(315 - 312.75)^2}{312.75} + \frac{(101 - 104.25)^2}{104.25} + \frac{(108 - 104.25)^2}{104.25} + \frac{(32 - 34.75)^2}{34.75} \approx 0.47$$

自由度 $k - 1 = 3$, 查表得 $\chi_{0.05,3}^2 = 7.81$ 。由于 $0.47 < 7.81$, **不能拒绝**孟德尔比例。

R 实现:

```
> obs <- c(315, 101, 108, 32)
> prob <- c(9/16, 3/16, 3/16, 1/16)
> chisq.test(obs, p = prob)
```

Chi-squared test for given probabilities

X-squared = 0.47, df = 3, p-value = 0.925

p 值为 0.925——数据与孟德尔比例高度吻合 (这也引发了一些历史争议, 因为拟合得太好了)。

□

7.3.2. 独立性检验. 第二个应用场景是**列联表独立性检验**——判断两个分类变量是否独立。

问题: 对于 $r \times c$ 列联表, 检验行变量 X 与列变量 Y 是否独立。

设 O_{ij} 为单元格 (i, j) 的观测频数, $O_{i\cdot} = \sum_j O_{ij}$ 为第 i 行合计, $O_{\cdot j} = \sum_i O_{ij}$ 为第 j 列合计, 总计为 n 。

期望频数 (在独立性假设 $H_0 : X \perp Y$ 下):

$$(4.5.2) \quad E_{ij} = \frac{O_{i\cdot} \cdot O_{\cdot j}}{n}$$

直观理解: 如果 X 和 Y 独立, 第 (i, j) 格的概率应为 $P(X = i)P(Y = j)$ 。用边际频数估计这些概率, 就得到上式。

检验统计量:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

自由度: 在 H_0 下, $(r-1)(c-1)$ 。直观上, r 行中有 $r-1$ 行可以自由取值 (最后一行由行合计决定), c 列中有 $c-1$ 列可以自由取值, 故自由度为 $(r-1)(c-1)$ 。

Insight 2×2 表的自由度为 1，这与二项分布的参数个数一致——只估计了一个参数 p （成功率）。更大的表可以检验更复杂的独立性结构。

连续性修正（仅用于 2×2 表）：R 中的 `chisq.test` 默认使用 Yates 连续性修正，对小样本的渐近近似进行校正：

$$\chi_{\text{Yates}}^2 = \sum \frac{(|O - E| - 0.5)^2}{E}$$

例 3.4 (2×2 表——治疗与结局独立性). 考虑二元结局的随机实验，数据汇总为：

	成功 ($Y = 1$)	失败 ($Y = 0$)	合计
治疗 ($Z = 1$)	$n_{11} = 30$	$n_{10} = 20$	$n_1 = 50$
对照 ($Z = 0$)	$n_{01} = 20$	$n_{00} = 30$	$n_0 = 50$

步骤 1：计算期望频数：

$$E_{11} = \frac{50 \times 50}{100} = 25, \quad E_{10} = \frac{50 \times 50}{100} = 25, \quad E_{01} = \frac{50 \times 50}{100} = 25, \quad E_{00} = 25$$

步骤 2：计算 χ^2 ：

$$\chi^2 = \frac{(30 - 25)^2}{25} + \frac{(20 - 25)^2}{25} + \frac{(20 - 25)^2}{25} + \frac{(30 - 25)^2}{25} = \frac{25}{25} + \frac{25}{25} + \frac{25}{25} + \frac{25}{25} = 4$$

自由度 $(2 - 1)(2 - 1) = 1$ ，临界值 $\chi_{0.05,1}^2 = 3.84$ 。由于 $4 > 3.84$ ，**拒绝独立性假设——治疗与结局存在关联。**

R 实现：

```
> tb <- matrix(c(30, 20, 20, 30), nrow = 2, byrow = TRUE)
> chisq.test(tb)
```

Pearson's Chi-squared test with Yates' continuity correction

X-squared = 4, df = 1, p-value = 0.0455

注意 Yates 修正后的 χ^2 从 4 降到 $4 \times (|30 - 25| - 0.5)^2 / 25 + \dots = 3.24$ （临界值不变）， p 值 = 0.072——这说明连续性修正在小样本时影响显著。

□

例 3.5 (3×2 表——吸烟与肺癌). **背景：**研究吸烟状态与肺癌诊断的关联，数据如下：

	患肺癌	未患肺癌	合计
重度吸烟	60	40	100
轻度吸烟	20	30	50
不吸烟	10	40	50

步骤 1：计算期望频数：

$$E_{11} = \frac{100 \times 90}{200} = 45, \quad E_{12} = \frac{100 \times 110}{200} = 55$$

$$E_{21} = \frac{50 \times 90}{200} = 22.5, \quad E_{22} = \frac{50 \times 110}{200} = 27.5$$

$$E_{31} = \frac{50 \times 90}{200} = 22.5, \quad E_{32} = \frac{50 \times 110}{200} = 27.5$$

步骤 2: 计算 χ^2 :

$$\chi^2 = \frac{(60-45)^2}{45} + \frac{(40-55)^2}{55} + \frac{(20-22.5)^2}{22.5} + \frac{(30-27.5)^2}{27.5} + \frac{(10-22.5)^2}{22.5} + \frac{(40-27.5)^2}{27.5} \approx 20.4$$

自由度 $(3-1)(2-1) = 2$, 查表 $\chi_{0.05,2}^2 = 5.99$ 。由于 $20.4 > 5.99$, **拒绝独立性**——吸烟与肺癌存在显著关联。

R 实现:

```
> tb <- matrix(c(60, 40, 20, 30, 10, 40), nrow = 3, byrow = TRUE)
> rownames(tb) <- c("重度吸烟", "轻度吸烟", "不吸烟")
> colnames(tb) <- c("患肺癌", "未患肺癌")
> chisq.test(tb)
```

Pearson's Chi-squared test

X-squared = 20.4, df = 2, p-value = 3.7e-05

p 值极小, 结论稳健。

□

例 3.6 (4×3 表——教育程度与收入水平). **背景:** 调查 500 人的教育程度与收入水平:

	低收入	中等收入	高收入	合计
初中及以下	80	50	20	150
高中	60	80	30	170
本科	30	70	40	140
研究生	10	30	100	140
合计	180	230	190	500

R 实现:

```
> edu <- c(80, 50, 20, 60, 80, 30, 30, 70, 40, 10, 30, 100)
> tb <- matrix(edu, nrow = 4, byrow = TRUE)
> rownames(tb) <- c("初中及以下", "高中", "本科", "研究生")
> colnames(tb) <- c("低收入", "中等收入", "高收入")
> chisq.test(tb)
```

Pearson's Chi-squared test

X-squared = 186.7, df = 6, p-value < 2.2e-16

p 值极小, 拒绝独立性——教育程度与收入水平存在强关联。

进一步分析: 对于 $r \times c$ 表, 还可以计算列联表相关系数 (*contingency coefficient*) 和 *Cramér V* (*Cramér's V*) 来衡量关联强度:

$$V = \sqrt{\frac{\chi^2}{n \times \min(r-1, c-1)}}$$

对于本例, $V = \sqrt{186.7/(500 \times 2)} \approx 0.43$, 表示中等偏强的关联。

□

7.3.3. 二元结局下的卡方检验：与 Fisher 精确检验的对比。回到随机实验的二元结局语境，我们使用卡方检验来检验 $Z \perp Y$ （治疗与结局独立）。

与 Fisher 精确检验的比较：

特征	Chi-square test	Fisher exact test
原理	渐近方法（大样本）	精确方法（小样本）
p 值	近似	精确
适用场景	期望频数均 > 5	小样本或期望频数 < 5

Insight Fisher 精确检验使用超几何分布计算 p 值，在零假设下有精确的有限样本分布。Chi-square 则是大样本近似——当样本量增大时，两者结果趋于一致。实践中，如果样本不太小且所有期望频数都 > 5 ，两种方法都可以使用。

完整例子——简历种族歧视实验 (Bertrand & Mullainathan, 2004):

该实验将简历上的名字随机分配为黑人听起来或白人听起来的名字，研究感知种族对面试回调率的影响。

```
resume = read.csv("resume.csv")
Alltable = table(resume$race, resume$call)
Alltable
#           0      1
# black 2278  157
# white 2200  235
```

数据汇总为 2×2 列联表：

	回调 ($Y = 1$)	无回调 ($Y = 0$)	合计
黑人名字 ($Z = 1$)	157	2278	2435
白人名字 ($Z = 0$)	235	2200	2435

计算各格期望频数：

$$E_{11} = \frac{2435 \times 392}{4870} \approx 195.7, \quad E_{12} = \frac{2435 \times 4478}{4870} \approx 2239.3$$

$$E_{21} = \frac{2435 \times 392}{4870} \approx 196.3, \quad E_{22} = \frac{2435 \times 4478}{4870} \approx 2238.7$$

由于期望频数都远大于 5，适合使用卡方检验。

```
> chisq.test(Alltable)
```

```
Pearson's Chi-squared test with Yates' continuity correction
```

```
X-squared = 17.6, df = 1, p-value = 2.7e-05
```

p 值极小，提供种族对回调率有显著影响的强有力证据。

与 Neymanian 推断的联系：卡方检验本质上是在检验弱零假设 $H_0: \tau = 0$ （平均因果效应为零）的渐近版本。风险差估计量 $\widehat{RD} = \hat{p}_1 - \hat{p}_0$ 的渐近方差为

$$\text{var}(\widehat{RD}) \approx \frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_0(1 - \hat{p}_0)}{n_0}$$

而 χ^2 统计量正是 $(\widehat{RD})^2 / \text{var}(\widehat{RD})$ 的另一种表达。

不满足适用条件时的处理：

(1) 如果某些期望频数 < 5 （尤其 2×2 表），优先使用 Fisher 精确检验

- (2) 如果样本量太小, 可以合并相邻类别以增大期望频数
 (3) 使用蒙特卡洛近似: `chisq.test(tb, simulate.p.value = TRUE)`

Insight 卡方检验的”大样本近似”条件可以通过经验规则判断: 期望频数都 > 5 时近似精度较好; 如果有多个格子 < 5 , 渐近近似的 p 值可能严重偏离真实值, 此时 Fisher 精确检验更可靠。

7.4. Wilcoxon 秩和统计量. 差值均值和学生化统计量都关注均值差异, 且对异常值敏感。Wilcoxon 秩和统计量基于合并观测结果的秩:

$$W = \sum_{i=1}^n Z_i R_i,$$

其中 R_i 是 Y_i 在合并样本中的秩。

例 3.7 (Wilcoxon 秩和统计量的均值与方差). **核心思想:** 在 H_{0F} 下, 随机性只来自治疗分配 $\mathbf{Z}$, 秩 R_i 是固定值。

均值: 利用 $\mathbb{E}(Z_i) = n_1/n$ 和 $\sum_{i=1}^n R_i = n(n+1)/2$, 得 $\mathbb{E}(W) = n_1(n+1)/2$ 。

方差: 利用 $\text{var}(Z_i) = n_1 n_0 / n^2$ 和 $\text{cov}(Z_i, Z_j) = -n_1 n_0 / [n^2(n-1)]$, 以及 $\sum_{i=1}^n R_i^2 = n(n+1)(2n+1)/6$, 化简得 $\text{var}(W) = n_1 n_0 (n+1)/12$ 。

□

11

这个统计量的优点是:

- 对异常值稳健 (只使用秩次信息, 不依赖具体数值)
- 只依赖于数据的秩次信息
- 在许多备择假设下都有较好的功效

7.5. Kolmogorov-Smirnov 统计量. 上述统计量主要关注均值差异。KS 统计量衡量两个分布之间的最大距离:

$$D = \max_y |\hat{F}_1(y) - \hat{F}_0(y)|,$$

其中 $\hat{F}_1(y) = n_1^{-1} \sum_{i=1}^n Z_i I(Y_i \leq y)$ 。

这个统计量能够检测分布形状的差异, 而不仅仅是均值差异。

8. FRT 与传统 t 检验的关系

一个重要的理论发现是:

FRT 为传统 t 检验提供了更坚实的基础。

传统 t 检验假设”数据来自正态分布的无限总体”。但 FRT 框架表明, 只要随机化分配正确执行, t 检验程序可以在”有限总体 + 随机化”的情境下使用。

这意味着, 在随机实验中, 我们可以不那么担心正态性假设——CLT 会为我们处理这个问题。

¹¹Wilcoxon 秩和统计量的均值与方差完整推导见附录 section 3。

9. LaLonde 实验数据案例

1986 年，Robert LaLonde 发表了一项影响深远的研究，探讨职业培训项目（National Supported Work Demonstration）对参与者收入的影响。

使用 R 进行 FRT 分析：

```
library(Matching)
data(lalonde)
z <- lalonde$treat
y <- lalonde$re78
```

观测到的检验统计量值：

统计量	观测值	描述
$\hat{\tau}$	2.84	差值均值 (t 统计量)
t	2.67	学生化统计量
W	27402.5	Wilcoxon 秩和
D	0.132	KS 统计量

通过随机置换治疗向量，我们可以得到检验统计量的随机化分布的 Monte Carlo 近似。Monte Carlo 置换检验的结果 ($R = 10^4$)：

```
> exact.pv = c(mean(Tauhat >= tauhat),
+               mean(Student >= student),
+               mean(Wilcox >= W),
+               mean(Ks >= D))
> round(exact.pv, 3)
[1] 0.002 0.002 0.006 0.040
```

所有单侧 p 值都小于 0.05——这提供了治疗效应显著的强有力证据。

10. 历史侧边栏：随机实验的起源

FRT 的逻辑可以追溯到早期的历史实例。

10.1. James Lind 的坏血病实验. James Lind (1716-1794) 是苏格兰医生和皇家海军卫生学的先驱。他进行了最早有清晰文献记录的随机实验之一，研究柑橘类水果对坏血病的影响。在 12 名坏血病患者被分配到 6 组后，接受柑橘类水果的组在六天后康复，而其他组没有。

如果将治疗简化为二元指示变量，观测到的极端 2×2 表格在 H_{0F} 下出现的概率为：

$$p_{\text{ftr}} = \frac{1}{\binom{12}{2}} = \frac{1}{66} = 0.015.$$

10.2. Fisher 的女士品茶实验. Fisher [1935] 描述了一个著名实验，一位女士声称能区分先加茶还是先加牛奶制成的奶茶。他制作了 8 杯茶（4 杯先加茶，4 杯先加牛奶），随机顺序呈现给女士。在她的全部猜对 ($X = 4$) 的情况下，p 值为：

$$p_{\text{ftr}} = \frac{1}{70} = 0.014.$$

例 3.8 (女士品茶的超几何分布). **核心思想：** X 服从超几何分布 $\text{Hypergeometric}(N = 8, K = 4, n = 4)$ ——这是“不放回抽样”的结果。

概率质量函数：

$$\mathbb{P}(X = k) = \frac{\binom{4}{k} \binom{4}{4-k}}{\binom{8}{4}}, \quad k = 0, 1, 2, 3, 4.$$

关键概率： $\mathbb{P}(X = 4) = 1/70$ ，故单侧 p 值 $p_{frt} = 1/70 \approx 0.014$ 。

直觉： 在 70 种可能排列中只有 1 种能让 *Lady* 全部猜对。

□

12

这些例子强调了 Fisher 的两个原则：

- (1) **随机化：** 实验的随机分配保证了 p 值的有效性
- (2) **重复：** 必须有足够的单元以确保 FRT 有功效

11. Sharp Null 假设的置信区间

FRT 的逻辑不仅限于 H_{0F} 。我们还可以检验更一般的 sharp null 假设：

$$H_0(\tau) : Y_i(1) - Y_i(0) = \tau_i \quad \text{对所有 } i.$$

通过检验与置信集的对偶性，我们可以构建 τ 的 $(1 - \alpha)$ 置信集。

12. 本章小结

本章建立了随机实验的理论与实践：

- (1) **CRE 定义：** $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = 1/\binom{n}{n_1}$
- (2) **随机化的两个原则：** 可比性 + 推理基础
- (3) **Sharp null：** $H_{0F} : Y_i(1) = Y_i(0)$ 对所有 i
- (4) **精确 p 值：** $p_{frt} = M^{-1} \sum_{m=1}^M \mathbb{I}\{T(\mathbf{z}^m, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$
- (5) **多种统计量：** 差值均值 $\hat{\tau}$ 、学生化 t 、Wilcoxon W 、KS D
- (6) **理论联系：** FRT 为传统 t 检验提供基础
- (7) **历史起源：** Lind 的坏血病实验、Fisher 的女士品茶

下一章我们将学习 Neymanian 推断——另一种基于渐近理论的方法，它可以更方便地构建置信区间。

13. 习题

练习 3.1. 3.1 — p_{frt} 的精确性 证明在 sharp null 下， p_{frt} 满足：

$$\mathbb{P}(p_{frt} \leq u) \leq u \quad \text{for all } 0 \leq u \leq 1.$$

练习 3.2. 3.2 — Monte Carlo 误差 设 p_{frt} 是固定值， $\hat{p}_{frt}$ 是其 Monte Carlo 估计 (见 eq. (8))。证明：

$$\mathbb{E}_{mc}(\hat{p}_{frt}) = p_{frt}, \quad \text{var}_{mc}(\hat{p}_{frt}) \leq \frac{1}{4R},$$

其中下标 “mc” 表示由于 Monte Carlo 的随机性。

¹²女士品茶实验的超几何分布推导及与二项分布的比较见附录 section 4。

练习 3.3. 3.3 —有限样本有效的 *Monte Carlo* 近似 证明修正的 *Monte Carlo* 近似

$$\tilde{p}_{frit} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

在任意有限的 R 下都是有限样本有效的 p 值。

提示：可以利用以下两个基本概率结果：

- (1) 对于两个二项分布 $X_1 \sim \text{Binomial}(R, p_1)$ 和 $X_2 \sim \text{Binomial}(R, p_2)$ ，若 $p_1 \geq p_2$ ，则 $\mathbb{P}(X_1 \leq x) \leq \mathbb{P}(X_2 \leq x)$ 。
- (2) 若 $p \sim \text{Uniform}(0, 1)$ 且 $X | p \sim \text{Binomial}(R, p)$ ，则 X 在 $\{0, 1, \dots, R\}$ 上均匀分布。

练习 3.4. 3.4 —Fisher 精确检验 考虑二元结局的 *CRE*，数据汇总为 2×2 列联表：

	$Y = 1$	$Y = 0$	合计
$Z = 1$	n_{11}	n_{10}	n_1
$Z = 0$	n_{01}	n_{00}	n_0

在 H_{0F} 下，证明任何检验统计量 $T(n_{11}, n_{10}, n_{01}, n_{00})$ 是 n_{11} 的函数，且 n_{11} 的精确分布是超几何分布。请说明超几何分布的参数。

练习 3.5. 3.5 —女士品茶详细计算 回忆女士品茶实验（见 section 10）。计算 $\mathbb{P}(X = k)$ ，其中 X 是女士正确识别 k 杯先加牛奶的茶个数， $k = 0, 1, 2, 3, 4$ 。

练习 3.6. 3.6 —协变量调整的 *FRT* 使用 *LaLonde* 数据集（见 section 9），添加协变量进行 *FRT* 分析。假设所有潜在结果和协变量都是固定数值。

有两种策略：

- (1) 运行结局对协变量的线性回归，得到残差（即“伪结局”）。基于残差定义四种检验统计量，进行 *FRT* 并报告 p 值。
- (2) 定义检验统计量为结局对治疗 and 协变量线性回归中治疗系数的 *FRT*。

解释为什么上述两种策略的五个 p 值都是有限样本精确的。

练习 3.7. 3.7 —*FRT* 与广义线性模型 使用与练习 3.6 相同的数据集，但将结局改为 $re78 > 0$ 的二元指示变量。运行结局对治疗和协变量的 *logistic* 回归。治疗系数是否显著？*FRT* p 值是多少？

练习 3.8. 3.8 —代数细节 验证 eq. (11)。

练习 3.9. 3.9 —推荐阅读 *Bind and Rattay [2020]* 是一篇倡导在复杂实验中同时报告 p 值及其相应随机化分布的论文。

Neymanian 重复抽样推断

1. 两种推断哲学的对话

在上一章中，我们学习了费舍尔随机化检验 (FRT)。Fisher 的方法优雅而精确——它基于随机化的精确性质，在 sharp null 假设下给出精确的 p 值。

但 FRT 也有其局限：它只能检验 sharp null 假设，对于构建置信区间需要额外的推理。而且当样本量很大时，枚举所有可能的置换变得计算上不可行。

Jerzy Neyman 在 1923 年的工作中提出了一种互补的方法。这种方法基于**渐近正态分布**，可以更方便地构建置信区间和进行假设检验。Neyman 的方法不依赖于任何特定的 null 假设，而是直接对因果效应进行统计推断。

这两种方法——Fisherian 和 Neymanian——代表了统计推断的两种哲学。理解它们的联系与区别，对于真正掌握因果推断至关重要。

注 4.1. **为什么需要两种方法？**：FRT 适用于小样本精确推断和假设检验，Neymanian 适用于大样本渐近推断和置信区间构建。两者互为补充，而非相互排斥。

2. 有限总体量

在 Neymanian 框架中，我们需要一套精确的记号来描述**有限总体量**——这些是不带“hat”的真实值。

考虑一个包含 n 个个体的有限总体，其中 n_1 个被分配到治疗组， $n_0 = n - n_1$ 个被分配到对照组。对于单元 $i = 1, \dots, n$ ，我们有潜在结果 $Y_i(1)$ 和 $Y_i(0)$ ，以及个体效应 $\tau_i = Y_i(1) - Y_i(0)$ 。

有限总体均值：

$$\bar{Y}(1) = n^{-1} \sum_{i=1}^n Y_i(1), \quad \bar{Y}(0) = n^{-1} \sum_{i=1}^n Y_i(0)$$

有限总体方差（使用 $n - 1$ 作为除数使定理更优雅）：

$$S^2(1) = (n - 1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2, \quad S^2(0) = (n - 1)^{-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$$

有限总体协方差：

$$S(1, 0) = (n - 1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\} \{Y_i(0) - \bar{Y}(0)\}$$

个体效应：

$$\tau = n^{-1} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$$

是平均因果效应的真值。

个体效应的方差：

$$S^2(\tau) = (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2$$

注 4.2. **为什么需要协方差？** 因为 $Y(1)$ 和 $Y(0)$ 之间可能有相关性。如果治疗组和对照组的个体是匹配的（正相关），估计的方差会减小；如果是负相关，方差会增大。

3. 一个关键引理

在有限总体量的世界中，有一个优雅的关系连接了协方差与各个方差：

引理 4.1 (Lemma 4.1 — 方差与协方差的关系).

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$$

其中 $\tau_i = Y_i(1) - Y_i(0)$ 是个体因果效应。

这个引理的证明是直接的代数运算。这个恒等式将在后续推导中发挥关键作用。¹

推论： 如果所有个体因果效应都相等 ($S^2(\tau) = 0$)，那么 $S(1, 0) = [S^2(1) + S^2(0)]/2$ ，即潜在结果完全正相关。

4. Neyman (1923) 定理

基于观测结果，我们可以计算样本均值：

$$\hat{Y}(1) = n_1^{-1} \sum_{i=1}^n Z_i Y_i, \quad \hat{Y}(0) = n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i$$

样本方差：

$$\hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{i=1}^n Z_i \{Y_i - \hat{Y}(1)\}^2, \quad \hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{i=1}^n (1 - Z_i) \{Y_i - \hat{Y}(0)\}^2$$

关键观察： 不存在 $S(1, 0)$ 和 $S^2(\tau)$ 的样本版本，因为潜在结果 $Y_i(1)$ 和 $Y_i(0)$ 从未对任何单元同时被观测到。

现在陈述 Neyman 的核心定理：

定理 4.2 (Neyman (1923) 定理). 在 *CRE* 下：

(1) **无偏性：** 差值均值估计量 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ 对 τ 是无偏的：

$$\mathbb{E}(\hat{\tau}) = \tau$$

(2) **方差公式：** $\hat{\tau}$ 有方差

$$\begin{aligned} (12) \quad \text{var}(\hat{\tau}) &= \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} \\ (13) \quad &= \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0) \end{aligned}$$

¹详见附录 section 1。

(3) 保守方差估计：方差估计量

$$\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$$

对估计 $\text{var}(\hat{\tau})$ 是保守的，即

$$\mathbb{E}(\hat{V}) - \text{var}(\hat{\tau}) = \frac{S^2(\tau)}{n} \geq 0$$

等号当且仅当 $\tau_i = \tau$ （所有单元的个体效应恒定）时成立。

关于期望和方差的含义：潜在结果都是固定数值，只有治疗指示变量 Z_i 是随机的。因此，期望和方差都相对于 Z_i 的随机性——即 n_1 个 1 和 n_0 个 0 的所有可能排列。

注 4.3. **第三项为什么是减项？**：直觉上：如果个体因果效应存在变异 ($S^2(\tau) > 0$)，治疗组和对照组之间的差异不仅来自随机抽样，还来自因果效应本身的真实变异。这种“真实变异”不应该被算作估计误差，所以被减去。

5. 方差公式的理解

方差公式 eq. (12) 与经典两样本问题中的方差公式不同，因为它不仅依赖于潜在结果的有限总体方差，还依赖于个体效应的有限总体方差。

一个令人困惑的现象：个体效应越异质， $\hat{\tau}$ 的变异性越小。为什么？

从等价格式 eq. (13) 理解：比较正相关和负相关的潜在结果情况。

假设在一次实现的实验中，我们观察到相对较大的治疗潜在结果：

- 如果 $S(1, 0) > 0$ ，则那些接受治疗的单元也有相对较大的对照潜在结果。因此，对照下的观测结果相对较小，导致较大的 $\hat{\tau}$
- 如果 $S(1, 0) < 0$ ，则那些接受治疗的单元有相对较小的对照潜在结果。因此，对照下的观测结果相对较大，导致较小的 $\hat{\tau}$

总体而言，尽管 $\hat{\tau}$ 的无偏性不依赖于潜在结果之间的相关性，但在正相关情况下更可能观察到更极端的 $\hat{\tau}$ 。因此，当潜在结果正相关时， $\hat{\tau}$ 的方差更大。

6. Neyman (1923) 定理的证明

无偏性证明：

从表示开始：

$$\begin{aligned} \hat{\tau} &= n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i \\ &= n_1^{-1} \sum_{i=1}^n Z_i Y_i(1) - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i(0) \end{aligned}$$

利用期望的线性性：

$$\begin{aligned}
\mathbb{E}(\hat{\tau}) &= \mathbb{E} \left\{ n_1^{-1} \sum_{i=1}^n Z_i Y_i(1) - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i(0) \right\} \\
&= n_1^{-1} \sum_{i=1}^n \mathbb{E}(Z_i) Y_i(1) - n_0^{-1} \sum_{i=1}^n \mathbb{E}(1 - Z_i) Y_i(0) \\
&= n_1^{-1} \sum_{i=1}^n \frac{n_1}{n} Y_i(1) - n_0^{-1} \sum_{i=1}^n \frac{n_0}{n} Y_i(0) \\
&= n^{-1} \sum_{i=1}^n Y_i(1) - n^{-1} \sum_{i=1}^n Y_i(0) = \tau
\end{aligned}$$

方差证明：

我们可以进一步将 $\hat{\tau}$ 写为：

$$\hat{\tau} = \sum_{i=1}^n Z_i \left\{ \frac{Y_i(1)}{n_1} + \frac{Y_i(0)}{n_0} \right\} - n_0^{-1} \sum_{i=1}^n Y_i(0)$$

利用简单随机抽样的引理，得到：

$$\begin{aligned}
\text{var}(\hat{\tau}) &= \frac{n_1 n_0}{n(n-1)} \sum_{i=1}^n \left\{ \frac{Y_i(1)}{n_1} + \frac{Y_i(0)}{n_0} - \frac{\bar{Y}(1)}{n_1} - \frac{\bar{Y}(0)}{n_0} \right\}^2 \\
&= \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0)
\end{aligned}$$

利用 定义 4.1，我们也可以将方差写为：

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$$

方差估计的期望：

因为治疗组是从 n 个单元中简单随机抽取的 n_1 个样本，简单随机抽样引理确保：

$$\mathbb{E}\{\hat{S}^2(1)\} = S^2(1), \quad \mathbb{E}\{\hat{S}^2(0)\} = S^2(0)$$

因此， $\hat{V}$ 对 eq. (12) 中前两项是无偏的。

7. 渐近正态性与置信区间

Li et al. [2017] 进一步证明了基于有限总体 CLT 的 $\hat{\tau}$ 的渐近正态性：

定理 4.3 (CLT for 差值均值). 令 $n \rightarrow \infty$ 和 $n_1 \rightarrow \infty$ 。如果 n_1/n 有 $(0, 1)$ 中的极限值， $\{S^2(1), S^2(0), S(1, 0)\}$ 有极限值，且

$$\max_{1 \leq i \leq n} \{Y_i(1) - \bar{Y}(1)\}^2/n \rightarrow 0, \quad \max_{1 \leq i \leq n} \{Y_i(0) - \bar{Y}(0)\}^2/n \rightarrow 0$$

则

$$\frac{\hat{\tau} - \tau}{\sqrt{\text{var}(\hat{\tau})}} \xrightarrow{d} N(0, 1)$$

且

$$\hat{S}^2(1) \rightarrow S^2(1), \quad \hat{S}^2(0) \rightarrow S^2(0) \quad (\text{依概率})$$

这个定理确保当样本量足够大时, $\hat{\tau}$ 的抽样分布可以用正态分布近似。它还确保样本方差是总体方差的一致估计。

置信区间: 这为 τ 的保守大样本置信区间提供了正当理由:

$$\hat{\tau} \pm z_{1-\alpha/2} \sqrt{\hat{V}}$$

其中 $z_{1-\alpha/2}$ 是标准正态分布的 $1 - \alpha/2$ 分位数。

与弱零假设的对偶性: 通过置信区间与假设检验的对偶性, 这也提供了检验

$$H_0 : \tau = 0$$

(称为弱零假设) 的基础。

注 4.4. **为什么 Neymanian 方法只给出“弱零假设”的检验?** 因为在 Neymanian 框架中, 我们无法观测到 $S^2(\tau)$, 所以无法精确计算方差。置信区间和检验都是渐近有效的, 只在样本量大时可靠。

8. Neymanian 推断与 OLS 的关系

实践中, 研究者经常使用基于回归的推断来估计平均因果效应。标准方法是运行 OLS 回归:

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{(a,b)} \sum_{i=1}^n (Y_i - a - bZ_i)^2$$

并使用 treatment 系数的估计量 $\hat{\beta}$ 作为平均因果效应的估计量。

关键发现: 系数 $\hat{\beta}$ 恰好等于差值均值:

$$(14) \quad \hat{\beta} = \hat{\tau}$$

但是, OLS 的通常方差估计量与 $\hat{V}$ 不同。标准 OLS 方差估计量为:

$$(15) \quad \hat{V}_{OLS} = \frac{n(n_1 - 1)}{(n - 2)n_1n_0} \hat{S}^2(1) + \frac{n(n_0 - 1)}{(n - 2)n_1n_0} \hat{S}^2(0).$$

幸运的是, Eicker-Huber-White (EHW) 稳健方差估计量接近 $\hat{V}$:

$$(16) \quad \hat{V}_{EHW} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1 - 1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0 - 1}{n_0},$$

且 HC2 变体恰好等于 $\hat{V}$ 。

在 LaLonde 数据上的应用:

```
> tauhat = mean(y[z==1]) - mean(y[z==0])
> vhat   = var(y[z==1])/n1 + var(y[z==0])/n0
> sehat  = sqrt(vhat)
> tauhat
[1] 1794.343
> sehat
[1] 670.9967
```

OLS 的标准误 (通常) 太小:

```
> olsfit = lm(y ~ z)
> summary(olsfit)$coef[2, 1:2]
      Estimate Std. Error
1794.3431    632.8536
```

使用 EHW 稳健标准误得到正确结果：

```
> sqrt(hccm(olsfit, type = "hc2")[2, 2])
[1] 670.9967
```

9. 重尾结局与正态近似的失效

定义 4.3 中的 CLT 在某些正则条件下成立。当潜在结局为重尾分布时，这些条件可能被违反。

当对照潜在结果被污染时（例如 Cauchy 分布），正态近似效果很差。模拟研究表明，在重尾情况下，直方图和正态近似之间存在显著差异。

10. 本章小结

本章建立了 Neymanian 推断的基础：

(1) **有限总体量**：不带 hat 的真实值

$$\bar{Y}(1), \bar{Y}(0), S^2(1), S^2(0), S(1, 0), S^2(\tau)$$

(2) **Lemma 4.1**: $2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$

(3) **Neyman (1923) 定理**：

- $\mathbb{E}(\hat{\tau}) = \tau$ (无偏)
- $\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- $\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau}) + \frac{S^2(\tau)}{n}$ (保守)

(4) **方差估计**: $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$

(5) **置信区间**: $\hat{\tau} \pm z_{1-\alpha/2} \sqrt{\hat{V}}$

(6) **CLT**: $\frac{\hat{\tau} - \tau}{\sqrt{\text{var}(\hat{\tau})}} \xrightarrow{d} N(0, 1)$

(7) **OLS 关系**: $\hat{\beta} = \hat{\tau}$ ，但需使用 EHW 稳健标准误

下一章我们将学习如何通过分层 (stratification) 来提高估计的精度——这是一种利用协变量信息来改进推断的方法。

11. 习题

练习 4.1. 4.1 引理的证明 证明 Lemma 4.1: $2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$ 。

练习 4.2. 4.2 Neyman (1923) 定理的另一种证明 在 CRE 下，计算：

$$\text{var}\{\hat{Y}(1)\}, \quad \text{var}\{\hat{Y}(0)\}, \quad \text{cov}\{\hat{Y}(1), \hat{Y}(0)\}$$

并利用这些公式计算 $\text{var}(\hat{\tau})$ 。

练习 4.3. 4.3 Neymanian 推断与 OLS 证明 (14) (即 OLS 系数等于差值均值)。证明 EHW 稳健方差估计量的 HC2 变体恰好等于 $\hat{V}$ 。

推导见附录 section 11。

练习 4.4. 4.4 治疗效应的异质性 证明 $S^2(\tau) = 0$ 蕴含 $S^2(1) = S^2(0)$ 。给出反例说明 $S^2(1) = S^2(0)$ 但 $S^2(\tau) \neq 0$ 。

证明 $S^2(1) < S^2(0)$ 蕴含 $S(Y(0), \tau) < 0$ 。给出反例说明 $S^2(1) > S^2(0)$ 但 $S(Y(0), \tau) < 0$ 。

练习 4.5. 4.5 方差公式的改进上界 证明方差公式的改进上界:

$$\text{var}(\hat{\tau}) \leq \frac{1}{n} \left\{ \sqrt{\frac{n_0}{n_1}} S(1) + \sqrt{\frac{n_1}{n_0}} S(0) \right\}^2$$

并讨论等号成立的条件。

练习 4.6. 4.6 Neyman (1923) 的向量版本 将 Neyman (1923) 的结果推广到多结局情形。考虑向量结局 $\mathbf{V} \in \mathbb{R}^K$ 的平均因果效应:

$$\tau_{\mathbf{V}} = \frac{1}{n} \sum_{i=1}^n \{\mathbf{V}_i(1) - \mathbf{V}_i(0)\}$$

证明 $\hat{\tau}_{\mathbf{V}}$ 对 $\tau_{\mathbf{V}}$ 是无偏的, 并求出其协方差矩阵。

练习 4.7. 4.7 BRE 中的推断 回忆在定义 3.1 中定义的完全随机实验。在这种设定下, 推导平均因果效应的方差公式, 并比较其与 CRE 中方差的差异。

练习 4.8. 4.8 推荐阅读 **推荐阅读:** Ding [2017] 重新审视了因果推断中的一些经典问题。Imbens and Rubin [2015] 是关于因果推断的权威综述。

历史注记: Neyman 1923 年的原始论文 Neyman [1923] 奠定了有限总体推断的基础。当代统计学家将其视为因果推断范式的里程碑。

分层与后分层随机实验

1. 引言：随机化的艺术

“Block what you can and randomize what you cannot.” — [Box et al., 1978, page 103]

这是 George Box 继“所有模型都是错的，但有些有用”之后第二著名的名言。本章将解释它的含义。

在完全随机实验 (CRE) 中，治疗分配完全由 chance 决定。这种设计在样本量趋于无穷时表现优异，但在有限样本中，治疗组和对照组可能在某些协变量上出现不平衡。这种 covariate imbalance (协变量不平衡) 会使实验结果的解释变得困难——观察到的结果差异可能归因于治疗，也可能归因于协变量的不平衡。

分层随机实验 (Stratified Randomized Experiment, SRE) 正是为了主动避免这种 covariate imbalance 而设计的。

2. SRE 的定义与记号

考虑一个包含 n 个单元的有限总体，协变量 $X_i \in \{1, \dots, K\}$ 是离散的。定义：

$$n_{[k]} = \#\{i : X_i = k\}, \quad \pi_{[k]} = n_{[k]}/n$$

分别为第 k 层 (stratum) 的单元数和比例 ($k = 1, \dots, K$)。

在 CRE 中，我们固定总的 n_1 和 n_0 ，但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。有趣的是，即使在 CRE 中，各层治疗组和对照组比例之差的期望为零：

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0, \quad \text{但} \quad \frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \neq 0 \text{ 以高概率成立.}$$

直观理解：期望为零说明随机化保证了渐近公平性，但有限样本中的随机波动可能导致显著的不平衡。这个观察促使我们思考：**能否在设计阶段就主动控制这种不平衡？**

定义 5.1 (5.1 — 分层随机实验 (SRE)). 固定 $n_{[k]1}$ 或 $n_{[k]0}$ ($k = 1, \dots, K$)。我们在离散的协变量 X 的每一层内独立进行 CRE。

在农业实验中，SRE 被称为**随机区组设计 (randomized block design)**，各层称为区组 (blocks)。类似地，分层随机化也称为 block randomization。

层别倾向得分 (stratum propensity score)：

$$e_{[k]} = \frac{n_{[k]1}}{n_{[k]}}$$

这个概念将在后续章节讨论观测性研究 (observational studies) 时扮演核心角色。

SRE 与 CRE 的关键区别：

- (1) SRE 的所有可行随机化集合是 CRE 的可行随机化集合的子集；
- (2) 在 SRE 中 $e_{[k]}$ 是固定的，但在 CRE 中是随机的。

1

¹式 (2) 的完整推导见附录 section 6。

3. 层别平均因果效应

对于单元 i ，我们有潜在结果 $Y_i(1)$ 和 $Y_i(0)$ ，个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 。第 k 层的层别平均因果效应为：

$$\tau_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} \tau_i.$$

总体平均因果效应是各层别平均因果效应的加权平均：

$$\tau = n^{-1} \sum_{i=1}^n \tau_i = \sum_{k=1}^K \pi_{[k]} \tau_{[k]}.$$

SRE 估计量：基于各层的差值均值估计量，我们可以构造 τ 的分层估计量：

$$\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}.$$

其中

$$\hat{\tau}_{[k]} = n_{[k]1}^{-1} \sum_{i=1}^n \mathbb{I}(X_i = k, Z_i = 1) Y_i - n_{[k]0}^{-1} \sum_{i=1}^n \mathbb{I}(X_i = k, Z_i = 0) Y_i$$

是第 k 层内治疗组和对照组结果均值之差。

如果我们关心 $\tau_{[k]}$ ，可以在第 k 层内使用 CRE 的方法进行推断。下面讨论对 τ 的统计推断。

4. SRE 中的 Fisher 随机化检验

与 CRE 类似，我们首先讨论 SRE 中的 Fisher 随机化检验 (FRT)。Sharp null 假设仍然是：

$$H_{0F} : Y_i(1) = Y_i(0) \text{ 对所有单元 } i = 1, \dots, n.$$

FRT 的基本思想适用于任何随机实验：我们可以用任何检验统计量 $T = T(\mathbf{Z}, \mathbf{Y}, \mathbf{X})$ ，其中 $\mathbf{Z}, \mathbf{Y}, \mathbf{X}$ 分别是治疗向量、观测结果向量和协变量矩阵。在 SRE 和 H_{0F} 下， T 具有已知分布，因为 $\mathbf{Z}$ 在 SRE 下有已知分布。

两个关键细节：

- (1) 当模拟治疗向量时，必须根据定义 5.1 在 X 的各层内对治疗指标进行置换（这有时被称为**条件随机化检验**或**条件置换检验**）；
- (2) 应选择能够反映 SRE 本质的检验统计量。

4.1. 检验统计量的规范选择.

SRE 中的差值均值估计量受估计 τ 的启发（见 section 5），我们可以在 FRT 中使用分层估计量 $\hat{\tau}_{\text{SRE}}$ 作为检验统计量。

例 5.1 (Example 5.1 — 分层估计量). *Motivated by estimating τ (see Chapter 5.3 below), we can use the following stratified estimator in the FRT:*

$$\hat{\tau}_S = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]},$$

where

$$\hat{\tau}_{[k]} = n_{[k]1}^{-1} \sum_{i=1}^n I(X_i = k, Z_i = 1) Y_i - n_{[k]0}^{-1} \sum_{i=1}^n I(X_i = k, Z_i = 0) Y_i$$

is the stratum-specific difference-in-means within stratum k .

学生化分层估计量. 受简单两样本问题中学生化统计量的启发, 我们可以在 FRT 中使用以下学生化统计量:

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}},$$

其中

$$\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right).$$

这里 $\hat{S}_{[k]}^2(1)$ 和 $\hat{S}_{[k]}^2(0)$ 分别是治疗组和对照组结果在第 k 层内的样本方差。这个统计量的精确形式来自下面 section 5 讨论的 Neymanian 视角。

例 5.2 (Example 5.2 — 学生化分层估计量). *Motivated by the studentized statistic in the simple two-sample problem, we can use the following studentized statistic for the stratified estimator in the FRT:*

$$t_{\text{S}} = \frac{\hat{\tau}_{\text{S}}}{\sqrt{\hat{V}_{\text{S}}}},$$

with

$$\hat{V}_{\text{S}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right),$$

where $\hat{S}_{[k]}^2(1)$ and $\hat{S}_{[k]}^2(0)$ are the stratum-specific sample variances of the outcomes under the treatment and control, respectively. The exact form of this statistic is motivated by the Neymanian perspective discussed in Section 5.3 below.

合并 Wilcoxon 秩和统计量. 我们首先在第 k 层内计算 Wilcoxon 秩和统计量 $W_{[k]}$, 然后合并为:

$$W_{\text{SRE}} = \sum_{k=1}^K c_{[k]} W_{[k]}.$$

基于不同的渐近方案和最优化准则, Van Elteren [1960] 提出了两种加权方法。一种使用 $c_{[k]} = 1/(n_{[k]1}n_{[k]0})$, 另一种使用 $c_{[k]} = 1/(n_{[k]} + 1)$ 。

例 5.3 (Example 5.3 — 合并 Wilcoxon 秩和统计量). *We first compute the Wilcoxon rank sum statistic $W_{[k]}$ within stratum k (recall Example 3.3) and then combine them as*

$$W_{\text{S}} = \sum_{k=1}^K c_{[k]} W_{[k]}.$$

Based on different asymptotic schemes and optimality criteria, Van Elteren (1960) proposed two weighting methods, one with

$$c_{[k]} = \frac{1}{n_{[k]1}n_{[k]0}},$$

and the other with

$$c_{[k]} = \frac{1}{n_{[k]} + 1}.$$

The motivations for these weights are quite technical, and other choices of weights may also be reasonable.

Hodges–Lehmann 对齐秩统计量. Van Elteren (1960) 的统计量在层数较少且各层样本量较大时表现良好。但当层数很多且各层样本量较小时，它不能进行足够多的比较，可能丢失数据中的信息。Hodges and Lehmann [1962] 提出了一种在对齐后进行更多跨层比较的检验统计量。他们首先将结果中心化：

$$\tilde{Y}_i = Y_i - \bar{Y}_{[k]}, \quad \text{若 } X_i = k,$$

其中 $\bar{Y}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} Y_i$ 是第 k 层内的层别均值。然后获得池化结果 $(\tilde{Y}_1, \dots, \tilde{Y}_n)$ 的秩 $(\tilde{R}_1, \dots, \tilde{R}_n)$ ，最后构建检验统计量：

$$\tilde{W} = \sum_{i=1}^n Z_i \tilde{R}_i.$$

例 5.4 (Example 5.4 —Hodges and Lehmann (1962) 的对齐秩统计量). *Van Elteren (1960)'s statistic works well with a few large strata. However, it does not work well with many small strata since it does not make enough comparisons, potentially losing information in the data. Hodges and Lehmann (1962) proposed a test statistic that makes more comparisons across strata after standardizing the outcomes. They suggested first centering the outcomes as*

$$\tilde{Y}_i = Y_i - \bar{Y}_{[k]}$$

with the stratum-specific mean $\bar{Y}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} Y_i$ if $X_i = k$, then obtaining the ranks $(\tilde{R}_1, \dots, \tilde{R}_n)$ of the pooled outcomes $(\tilde{Y}_1, \dots, \tilde{Y}_n)$, and finally constructing the test statistic

$$\tilde{W} = \sum_{i=1}^n Z_i \tilde{R}_i.$$

We can simulate the exact distributions of the above test statistics under the SRE. We can also calculate their means and variances and obtain the p-values based on Normal approximations.

Kolmogorov–Smirnov 统计量. 我们计算 $D_{[k]}$ ，即第 k 层内治疗组和对照组结果的经验分布函数之间的最大差距。最终的检验统计量可以是：

$$D_{\text{SRE}} = \sum_{k=1}^K c_{[k]} D_{[k]}, \quad \text{或} \quad D_{\text{max}} = \max_{1 \leq k \leq K} c_{[k]} D_{[k]},$$

其中 $c_{[k]} = \sqrt{n_{[k]1}n_{[k]0}/n_{[k]}}$ 。

例 5.5 (Example 5.5 —Kolmogorov–Smirnov 统计量). *After searching for a while, I failed to find a detailed discussion of the Kolmogorov–Smirnov statistic for the SRE. Below is my proposal.*

We compute $D_{[k]}$, the maximum difference between the empirical distributions of the outcomes under treatment and control within stratum k . The final test statistic can be

$$D_{\text{S}} = \sum_{k=1}^K c_{[k]} D_{[k]}$$

or

$$D_{\max} = \max_{1 \leq k \leq K} c_{[k]} D_{[k]},$$

where $c_{[k]} = \sqrt{n_{[k]1}n_{[k]0}/n_{[k]}}$ is motivated by the limiting distribution of $D_{[k]}$ with $n_{[k]1}$ and $n_{[k]0}$ approaching infinity (see Example 3.4). The statistics D_S and $D_{\max}$ are more appropriate when all strata have large sample sizes. Another reasonable choice is

$$D = \max_y \left| \sum_{k=1}^K \pi_{[k]} \{ \hat{F}_{[k]1}(y) - \hat{F}_{[k]0}(y) \} \right|,$$

where $\hat{F}_{[k]1}(y)$ and $\hat{F}_{[k]0}(y)$ are the stratum-specific empirical distribution functions of the outcomes under the treatment and control, respectively. The statistic D is appropriate in both the cases with large strata and the cases with many small strata.

2

5. Neymanian 推断

5.1. 点估计与区间估计. SRE 的统计推断建立在一个事实之上：它本质上由 K 个独立的 CRE 组成。基于此，我们可以将 Neyman (1923) 的结果推广到 SRE。

在第 k 层内，差值均值 $\hat{\tau}_{[k]}$ 是 $\tau_{[k]}$ 的无偏估计，其方差为：

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}},$$

其中 $S_{[k]}^2(1), S_{[k]}^2(0), S_{[k]}^2(\tau)$ 分别是潜在结果和个体因果效应在第 k 层内的方差。

因此，分层估计量 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 是 τ 的无偏估计，方差为：

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

如果 $n_{[k]1} \geq 2$ 且 $n_{[k]0} \geq 2$ ，我们可以获得第 k 层内治疗组和对照组结果的样本方差 $\hat{S}_{[k]}^2(1)$ 和 $\hat{S}_{[k]}^2(0)$ ，并构建一个**保守方差估计量**：

$$\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right).$$

基于 $\hat{\tau}_{\text{SRE}}$ 的正态近似，我们可以构建 τ 的 Wald 型 $1 - \alpha$ 置信区间：

$$(5.13) \quad \hat{\tau}_{\text{SRE}} \pm z_{1-\alpha/2} \sqrt{\hat{V}_{\text{SRE}}}.$$

从假设检验的角度，在 $H_{0N} : \tau = 0$ 下，我们可以将 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 与标准正态分位数进行比较，得到渐近 p 值。

3

²式 (4.1) 和 (4.1) 的期望和方差推导见附录 section 7。

³式 (5.1) 和 (5.1) 的推导，以及渐近正态性的证明见附录 section 8。

6. SRE 与 CRE 的效率比较

与 CRE 相比, SRE 有什么好处? 我们从 covariate balance 的角度引入了 SRE。此外, 更好的 covariate balance 会带来更好的平均因果效应估计精度。

为了进行公平比较, 我们假设 $e_{[k]} = e$ (对所有 k), 这保证了:

$$(5.3) \quad \hat{\tau} = \hat{\tau}_{\text{SRE}}.$$

我们比较抽样方差。方差分析技术启发了将总方差分解为层内方差和层间方差之和:

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \left[\frac{n_{[k]} - 1}{n-1} S_{[k]}^2(1) + \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 \right], \end{aligned}$$

类似地,

$$\begin{aligned} S^2(0) &= \sum_{k=1}^K \left[\frac{n_{[k]} - 1}{n-1} S_{[k]}^2(0) + \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 \right], \\ S^2(\tau) &= \sum_{k=1}^K \left[\frac{n_{[k]} - 1}{n-1} S_{[k]}^2(\tau) + \frac{n_{[k]}}{n-1} \{\tau_{[k]} - \tau\}^2 \right]. \end{aligned}$$

CRE 下差值均值估计量的方差分解为:

$$\begin{aligned} \text{var}_{\text{CRE}}(\hat{\tau}) &= \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} \\ &= \underbrace{\sum_{k=1}^K \left[\frac{\pi_{[k]}}{n_1} S_{[k]}^2(1) + \frac{\pi_{[k]}}{n_0} S_{[k]}^2(0) - \frac{\pi_{[k]}}{n} S_{[k]}^2(\tau) \right]}_{\text{与 SRE 相同}} \\ &\quad + \underbrace{\sum_{k=1}^K \left[\frac{\pi_{[k]}}{n_1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{\pi_{[k]}}{n_0} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{\pi_{[k]}}{n} (\tau_{[k]} - \tau)^2 \right]}_{\text{SRE 消除的项}}. \end{aligned} \quad (5.14)$$

当层样本量较大时, $\text{var}_{\text{CRE}}(\hat{\tau})$ 与 $\text{var}_{\text{SRE}}(\hat{\tau}_{\text{SRE}})$ 之差约为:

$$(5.4) \quad \sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

这个差值是非负的, 当且仅当

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

对 $k = 1, \dots, K$ 都成立时才为零。当协变量能预测潜在结果时, 上述量通常不全为零, 这保证了 SRE 相对于 CRE 的效率增益。

⁴

⁴式 (5.14) 和 (5.4) 的完整推导见附录 section 9。

7. CRE 中的后分层

在具有离散协变量 X 的 CRE 中，第 k 层内接受治疗和对照的单元数是随机的。在 SRE 中，这些数字是固定的。但如果我们在给定 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下进行条件推断，那么 CRE 就变成了 SRE。

数学上，如果 $\mathbf{n}$ 的所有分量都不为零，那么：

$$(5.5) \quad \Pr_{\text{CRE}}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{\text{CRE}}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{\text{CRE}}(\mathbf{n})} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

即， $\mathbf{Z}$ 在给定 $\mathbf{n}$ 条件下从 CRE 得到的条件分布与从 SRE 得到的分布相同。

因此，在给定 $\mathbf{n}$ 的条件下，我们可以像分析 SRE 一样分析带有离散协变量 X 的 CRE。FRT 变为**条件 FRT**，Neymanian 分析变为**后分层 (post-stratification)**：

$$(5.15) \quad \hat{\tau}_{\text{PS}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}.$$

其形式与 $\hat{\tau}_{\text{SRE}}$ 相同。

分层在设计阶段使用 X ，后分层在分析阶段使用 X 。它们是使用 X 的对偶方法。

5

8. 实践中的问题

如何选择 X 来构建 SRE？理论上， X 应该能预测潜在结果。在某些情况下，实验者根据先导研究等对预测协变量有足够的背景知识，那么 X 的选择是 straightforward 的。在其他情况下，这种背景知识不够清晰，实验者反而根据方便性选择 X ——例如， X 可以是研究区域的指示变量或学生年级。

K 的选择是一个相关问题。理论上，如果所有层都足够大，增加 K 会提高估计效率。然而，极端大的 K 甚至可能降低估计效率。在模拟研究中，我们观察到增加 K 的边际收益递减。经验上， $K = 5$ 通常足以获得效率增益。

多维连续协变量怎么办？如果我们有先导研究，可以建立给定这些协变量时潜在结果 $Y(0)$ 的模型，然后选择 X 为预测量 $\hat{Y}(0)$ 的离散化版本。一般地，如果我们没有这样的先导研究或者不想做 ad hoc 的离散化，我们可以使用一种更通用的策略，称为**重随机化 (rerandomization)**。

9. 本章小结

- (1) **SRE 的动机**：CRE 可能产生不期望的治疗分配，通过分层可以主动避免 covariate imbalance。
- (2) **SRE 定义**：在离散协变量的各层内独立进行 CRE，固定各层的治疗分配数量。
- (3) **效率增益**：当协变量能预测潜在结果时，SRE 比 CRE 更有效，因为分层消除了层间变异。
- (4) **FRT 和 Neymanian 推断**：都可以推广到 SRE，分别在 section 4 和 section 5 中讨论。
- (5) **后分层**：CRE 中给定分层数量条件后，分析方法与 SRE 相同——这是使用协变量的对偶方法。

6

⁵式 (5.5) 的证明见附录 section 10。

⁶主要定理的完整证明见附录 sections 6 to 10。

10. 习题

练习 5.1. *Covariate balance in the CRE* 证明 (2): 在 CRE 下,

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0.$$

练习 5.2. *5.2 Consequence of the constant propensity score* 证明 (5.3): 当所有层的层别倾向得分相等 $e_{[k]} = e$ (对所有 k) 时,

$$\hat{\tau} = \hat{\tau}_{SRE}.$$

练习 5.3. *5.3 Consequence of constant individual causal effects* 假设个体因果效应是常数 $\tau_i = \tau$ (对所有 $i = 1, \dots, n$)。考虑以下 τ 的加权估计量类:

$$\hat{\tau}_w = \sum_{k=1}^K w_{[k]} \hat{\tau}_{[k]},$$

其中权重 $w_{[k]}$ 对所有 k 非负。

(1) 找出使 $\hat{\tau}_w$ 对 τ 无偏的 $w_{[k]}$ 条件。

(2) 在所有无偏估计量中, 找出使 $\hat{\tau}_w$ 方差最小的权重。

练习 5.4. *5.4 Compare the CRE and SRE* 证明 (5.4): 当层样本量较大时, $var_{CRE}(\hat{\tau})$ 与 $var_{SRE}(\hat{\tau}_{SRE})$ 之差约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{ \bar{Y}_{[k]}(1) - \bar{Y}(1) \} + \sqrt{\frac{n_1}{n_0}} \{ \bar{Y}_{[k]}(0) - \bar{Y}(0) \} \right\}^2 \geq 0.$$

练习 5.5. *5.5 From the CRE to the SRE* 证明 (5.5): 数学上, 如果 $\mathbf{n}$ 的所有分量都不为零, 那么

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

即, $\mathbf{Z}$ 在给定 $\mathbf{n}$ 条件下从 CRE 得到的条件分布与从 SRE 得到的分布相同。

练习 5.6. *5.6 More FRTs for Section 5.2.2* 推广 section 4 中的 FRT 分析, 使用其他检验统计量进行假设检验。

练习 5.7. *5.7 FRT for an SRE in Imbens and Rubin (2015)* Imbens and Rubin (2015) 讨论了 1985-1986 年在田纳西州进行的 SRE (Student/Teacher Achievement Ratio 实验)。kindergarten 数据如下:

`treatment = list(c(1,1,0,0), c(1,1,0,0), ...)` `outcome = list(c(0.165,0.321,-0.197,0.236), ...)`

层对应于学校, 分析单元是教师或班级。treatment 等于 1 表示小班 (每教师 13-17 名学生), 等于 0 表示普通班 (22-25 名学生)。outcome 是标准化的平均数学成绩。

使用 FRT 重新分析 Project STAR 数据。使用 $\hat{\tau}_{SRE}$ 、 W_{SRE} 和 $\tilde{W}$ 作为 FRT 的检验统计量。比较 p 值。

注: 本书使用 Z 表示治疗指示变量, 但 Imbens and Rubin (2015) 使用 W 。

练习 5.8. *5.8 A multi-center trial Gould (1998, Table 1)* 报告了以下来自多中心试验的数据:

这是一个以中心为层的 *SRE*。该试验旨在研究非那雄胺（用于治疗良性前列腺增生的药物）的疗效和耐受性。在每个中心的 29 个中心内，患者被随机分配到三个组：对照组、非那雄胺 1mg 和非那雄胺 5mg。

上述数据集提供了结局的汇总统计，结局是从基线到总症状评分的变化。总症状评分是九个问题（评分 0 到 4）关于各种尿路能力受损症状的评分之和。

由于没有报告个体水平的数据，我们无法实施 *FRT*。然而，*Neymanian* 推断只需要汇总统计。分别报告非那雄胺 1mg 和非那雄胺 5mg 与对照组比较的点估计量和方差估计。

练习 5.9. 5.9 *Data re-analyses* 重新分析第 chapter 4 章 4.5.3 节中使用的 *LaLonde* 数据。同时进行 *Fisherian* 和 *Neymanian* 推断。

APPENDIX A

公式推导

1. Lemma 4.1 的证明：方差与协方差的关系

Lemma 4.1 (教材第 1975 页):

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

背景 (Background): Lemma 4.1 是 Neyman (1923) 定理证明中的一个关键代数恒等式，它建立了有限总体协方差与各个方差之间的关系。

参数定义 (Parameter Definitions):

- $S^2(1) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2$: 潜在结果 $Y_i(1)$ 的有限总体方差
- $S^2(0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$: 潜在结果 $Y_i(0)$ 的有限总体方差
- $S(1, 0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\} \{Y_i(0) - \bar{Y}(0)\}$: $Y_i(1)$ 与 $Y_i(0)$ 之间的有限总体协方差
- $\tau_i = Y_i(1) - Y_i(0)$: 个体因果效应
- $\tau = n^{-1} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$: 平均因果效应
- $S^2(\tau) = (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2$: 个体因果效应的有限总体方差

目标 (Goal): 证明

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

推导步骤 (Derivation Steps):

第一步: 从 $S^2(\tau)$ 的定义出发。

$$\begin{aligned} S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - Y_i(0)) - (\bar{Y}(1) - \bar{Y}(0))]^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - \bar{Y}(1)) - (Y_i(0) - \bar{Y}(0))]^2. \end{aligned}$$

第二步: 展开平方。

$$\begin{aligned}
S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n \left[(Y_i(1) - \bar{Y}(1))^2 + (Y_i(0) - \bar{Y}(0))^2 \right. \\
&\quad \left. - 2(Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \right] \\
&= (n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))^2 + (n-1)^{-1} \sum_{i=1}^n (Y_i(0) - \bar{Y}(0))^2 \\
&\quad - 2(n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \\
&= S^2(1) + S^2(0) - 2S(1, 0).
\end{aligned}$$

第三步：移项得到目标恒等式。

$$S^2(1) + S^2(0) - S^2(\tau) = 2S(1, 0).$$

结论：得证

$$\boxed{2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)}.$$

直观理解：这个恒等式揭示了潜在结果之间的相关性 ($S(1, 0)$) 与个体因果效应变异 ($S^2(\tau)$) 之间的联系。当个体因果效应完全恒定 ($S^2(\tau) = 0$) 时, $2S(1, 0) = S^2(1) + S^2(0)$, 即 $Y(1)$ 和 $Y(0)$ 完全正相关 (相关系数为 1)。当 $S^2(\tau) > 0$ 时, 等式右侧变小, 意味着 $S(1, 0)$ 变小或变为负值。

在方差公式中的应用：这个恒等式允许我们将 Neyman 方差公式写成两种等价形式：

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} = \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0).$$

2. 差值均值统计量的方差分解

背景：在 eq. (11) 中, 我们声称

$$(3.7) \quad (n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

本节给出完整的代数推导。

第一步：从定义出发。

$$(n-1)s^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n [(Y_i - \bar{Y})]^2.$$

第二步：对每个单元 i , 将偏差 $Y_i - \bar{Y}$ 写成：

$$Y_i - \bar{Y} = \underbrace{(Y_i - \hat{Y}(Z_i))}_{\text{组内偏差}} + \underbrace{(\hat{Y}(Z_i) - \bar{Y})}_{\text{组间偏差}}.$$

第三步：平方展开：

$$(Y_i - \bar{Y})^2 = (Y_i - \hat{Y}(Z_i))^2 + (\hat{Y}(Z_i) - \bar{Y})^2 + 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}).$$

第四步：对所有单元求和。关键观察是交叉项求和为零：

$$\sum_{i=1}^n 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}) = 2 \sum_{i=1}^n (Y_i - \hat{Y}(Z_i)) \cdot (\hat{Y}(Z_i) - \bar{Y}).$$

当 $Z_i = 1$ 时，这个和化为：

$$2 \sum_{Z_i=1} (Y_i - \hat{Y}(1)) \cdot (\hat{Y}(1) - \bar{Y}) = 2(\hat{Y}(1) - \bar{Y}) \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))}_{=0} = 0,$$

因为 $\sum_{Z_i=1} Y_i = n_1 \hat{Y}(1)$ ，所以 $\sum_{Z_i=1} (Y_i - \hat{Y}(1)) = 0$ 。

同理，当 $Z_i = 0$ 时：

$$2 \sum_{Z_i=0} (Y_i - \hat{Y}(0)) \cdot (\hat{Y}(0) - \bar{Y}) = 2(\hat{Y}(0) - \bar{Y}) \underbrace{\sum_{Z_i=0} (Y_i - \hat{Y}(0))}_{=0} = 0.$$

因此交叉项全部抵消。

第五步：整理得到：

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2}_{\text{组内平方和}} + \underbrace{\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2}_{\text{组间平方和}}.$$

第六步：计算组间平方和：

$$\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2 = n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2.$$

利用以下两个事实：

$$(1) \hat{Y}(1) - \hat{Y}(0) = \hat{\tau}$$

$$(2) n_1 \hat{Y}(1) + n_0 \hat{Y}(0) = n\bar{Y} \quad (\text{加权平均的性质})$$

展开并化简：

$$\begin{aligned} & n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 \\ &= n_1 \hat{Y}(1)^2 - 2n_1 \hat{Y}(1) \bar{Y} + n_1 \bar{Y}^2 + n_0 \hat{Y}(0)^2 - 2n_0 \hat{Y}(0) \bar{Y} + n_0 \bar{Y}^2 \\ &= n_1 \hat{Y}(1)^2 + n_0 \hat{Y}(0)^2 - n\bar{Y}^2. \end{aligned}$$

利用 $(n_1 \hat{Y}(1) + n_0 \hat{Y}(0))^2 = n^2 \bar{Y}^2$ ，展开得：

$$n_1^2 \hat{Y}(1)^2 + 2n_1 n_0 \hat{Y}(1) \hat{Y}(0) + n_0^2 \hat{Y}(0)^2 = n^2 \bar{Y}^2.$$

代入上式并利用 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ ，最终化简为：

$$n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 = \frac{n_1 n_0}{n} \hat{\tau}^2.$$

结论：代入即得 eq. (11)。

3. Wilcoxon 秩和统计量的方差推导

背景：在 3.7 中，我们声称在 H_{0F} 下

$$\text{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

本节给出完整的代数推导。

第一步：回忆 $W = \sum_{i=1}^n Z_i R_i$ ，其中 R_i 是 Y_i 在合并样本中的秩（固定值）， Z_i 是随机化的治疗指示变量。

方差分解：

$$\text{var}(W) = \text{var}\left(\sum_{i=1}^n Z_i R_i\right) = \sum_{i=1}^n R_i^2 \text{var}(Z_i) + \sum_{i \neq j} R_i R_j \text{cov}(Z_i, Z_j).$$

计算 $\text{var}(Z_i)$ ：在 CRE 中， $Z_i \sim \text{Bernoulli}(n_1/n)$ ，所以

$$\text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

计算 $\text{cov}(Z_i, Z_j)$ for $i \neq j$ ：由于 $\sum_{i=1}^n Z_i = n_1$ （固定），我们有

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)} \quad (i \neq j).$$

代入：

$$\begin{aligned} \text{var}(W) &= \left(\sum_{i=1}^n R_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} R_i R_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right) \\ &= \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \sum_{i \neq j} R_i R_j \right]. \end{aligned}$$

注意 $\sum_{i \neq j} R_i R_j = (\sum_{i=1}^n R_i)^2 - \sum_{i=1}^n R_i^2$ ，代入得：

$$\text{var}(W) = \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \left(\left(\sum_{i=1}^n R_i \right)^2 - \sum_{i=1}^n R_i^2 \right) \right].$$

计算 $\sum_{i=1}^n R_i$ 和 $\sum_{i=1}^n R_i^2$ ：假设无 ties，则 $\{R_i\}$ 是 $1, 2, \dots, n$ 的一个排列。

$$\sum_{i=1}^n R_i = 1 + 2 + \dots + n = \frac{n(n+1)}{2}.$$

$$\sum_{i=1}^n R_i^2 = 1^2 + 2^2 + \dots + n^2 = \frac{n(n+1)(2n+1)}{6}.$$

代入并化简：

$$\begin{aligned} \text{var}(W) &= \frac{n_1 n_0}{n^2} \left[\frac{n(n+1)(2n+1)}{6} - \frac{1}{n-1} \left(\frac{n^2(n+1)^2}{4} - \frac{n(n+1)(2n+1)}{6} \right) \right] \\ &= \frac{n_1 n_0 (n+1)}{12}. \end{aligned}$$

结论：得证。

4. 女士品茶实验的超几何分布

背景：在 3.8 中，我们讨论了 Fisher 的女士品茶实验。本节给出超几何分布的完整推导。

设置：

- 8 杯茶中有 4 杯是”先加奶”($K = 4$), 4 杯是”先加茶”
- 女士随机猜测其中 4 杯为”先加奶”
- 记 X 为她猜对”先加奶”的杯数

为什么是超几何分布？

在 H_{0F} 下，女士的猜测是固定的（她选 4 杯作为”先加奶”的猜测）。实验者随机排列 8 杯茶的顺序呈现给女士。这等价于：从含有 $K = 4$ 个”成功”的总体 $N = 8$ 中，不放回抽取 $n = 4$ 个， X 是抽到的成功个数。

超几何分布的概率质量函数：

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, 2, 3, 4.$$

验证：超几何分布的概率之和为 1。

$$\sum_{k=0}^4 \mathbb{P}(X = k) = \frac{1}{\binom{8}{4}} \sum_{k=0}^4 \binom{4}{k} \binom{4}{4-k} = \frac{1}{70} \cdot \binom{8}{4} = 1,$$

其中利用了组合恒等式 $\sum_k \binom{a}{k} \binom{b}{n-k} = \binom{a+b}{n}$ 。

各概率的数值：

$$\begin{aligned} \mathbb{P}(X = 0) &= \frac{\binom{4}{0} \binom{4}{4}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}, \\ \mathbb{P}(X = 1) &= \frac{\binom{4}{1} \binom{4}{3}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 2) &= \frac{\binom{4}{2} \binom{4}{2}}{\binom{8}{4}} = \frac{6 \cdot 6}{70} = \frac{36}{70}, \\ \mathbb{P}(X = 3) &= \frac{\binom{4}{3} \binom{4}{1}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 4) &= \frac{\binom{4}{4} \binom{4}{0}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}. \end{aligned}$$

与二项分布的比较：如果”抽取放回”（即女士每次猜测后被告知答案），则 $X \sim \text{Binomial}(4, 1/2)$ ，此时

$$\mathbb{P}(X = 4) = \binom{4}{4} (1/2)^4 = 1/16 = 0.0625 > 0.014.$$

超几何分布（不放回）的尾部概率更小，使得 Fisher 的检验在零假设下更精确——这正是 FRT”精确”的含义。

5. 差值均值统计量的期望与方差推导

背景：在 eq. (5) 中，我们定义了差值均值统计量

$$\hat{\tau} = \hat{Y}(1) - \hat{Y}(0).$$

本节推导在 H_{0F} 下 $\hat{\tau}$ 的期望和方差。

期望的推导. 回忆在 CRE 中，治疗分配 $\mathbf{Z}$ 与潜在结果 $\{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 独立，且每个单元被分配到治疗组的概率为 n_1/n ：

$$\mathbb{E}(Z_i) = \frac{n_1}{n}, \quad \mathbb{E}(1 - Z_i) = \frac{n_0}{n}.$$

因此

$$\begin{aligned} \mathbb{E}(\hat{\tau}) &= \mathbb{E} \left(n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i \right) \\ &= n_1^{-1} \sum_{i=1}^n \mathbb{E}(Z_i) Y_i - n_0^{-1} \sum_{i=1}^n \mathbb{E}(1 - Z_i) Y_i \\ &= n_1^{-1} \sum_{i=1}^n \frac{n_1}{n} Y_i - n_0^{-1} \sum_{i=1}^n \frac{n_0}{n} Y_i \\ &= \frac{1}{n} \sum_{i=1}^n Y_i - \frac{1}{n} \sum_{i=1}^n Y_i = 0. \end{aligned}$$

方差的推导. 第一步：简化表达式。注意到

$$\hat{\tau} = n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i = \frac{n}{n_0} \cdot n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n Y_i.$$

由于 $\sum_{i=1}^n Y_i$ 是常数（不依赖 $\mathbf{Z}$ ），我们只需计算

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \text{var} \left(\sum_{i=1}^n Z_i Y_i \right).$$

第二步：计算 $\text{var}(Z_i)$ 和 $\text{cov}(Z_i, Z_j)$ 。在 CRE 中，

$$Z_i \sim \text{Bernoulli} \left(\frac{n_1}{n} \right), \quad \text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ （固定），对于 $i \neq j$ ，

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)}.$$

第三步：计算 $\text{var}(\sum_{i=1}^n Z_i Y_i)$ ：

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \sum_{i=1}^n Y_i^2 \text{var}(Z_i) + \sum_{i \neq j} Y_i Y_j \text{cov}(Z_i, Z_j) \\ &= \left(\sum_{i=1}^n Y_i^2 \right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} Y_i Y_j \left(-\frac{n_1 n_0}{n^2(n-1)} \right). \end{aligned}$$

注意 $\sum_{i \neq j} Y_i Y_j = (\sum_{i=1}^n Y_i)^2 - \sum_{i=1}^n Y_i^2 = n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2$, 代入得:

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \frac{n_1 n_0}{n^2} \sum_{i=1}^n Y_i^2 - \frac{n_1 n_0}{n^2 (n-1)} \left(n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2 \right) \\ &= \frac{n_1 n_0}{n^2 (n-1)} \left[(n-1) \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 + \sum_{i=1}^n Y_i^2 \right] \\ &= \frac{n_1 n_0}{n^2 (n-1)} \left[n \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 \right] \\ &= \frac{n_1 n_0}{n(n-1)} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right). \end{aligned}$$

第四步: 利用 s^2 的定义:

$$s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)^{-1} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right).$$

因此

$$\text{var} \left(\sum_{i=1}^n Z_i Y_i \right) = \frac{n_1 n_0}{n} \cdot s^2.$$

第五步: 代回 $\text{var}(\hat{\tau})$:

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \frac{n_1 n_0}{n} \cdot s^2 = \frac{n}{n_1 n_0} \cdot s^2.$$

结论:

$$\boxed{\text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} \cdot s^2}.$$

直观理解:

- 方差与总样本量 n 成正比——样本越大, 估计越精确
- 方差与 $n_1 n_0$ 成反比——当 $n_1 = n_0 = n/2$ 时方差最小
- 这与直觉一致: 治疗组和对照组越平衡, 我们越能准确估计因果效应

6. CRE 中分层平衡性的推导

背景 (Background): 在完全随机实验 (CRE) 中, 我们固定总的治疗组和对照组样本量 n_1 和 n_0 , 但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。本节证明各层治疗组和对照组比例之差的期望为零。

参数定义 (Parameter Definitions):

- n : 总单元数
- $n_{[k]}$: 第 k 层的单元数
- n_1 : 总治疗组单元数
- n_0 : 总对照组单元数 ($n_0 = n - n_1$)
- $n_{[k]1}$: 第 k 层中分配到治疗组的单元数
- $n_{[k]0}$: 第 k 层中分配到对照组的单元数 ($n_{[k]0} = n_{[k]} - n_{[k]1}$)
- $\pi_{[k]} = n_{[k]}/n$: 第 k 层在总体中的比例

已知条件 (Given):

- 在 CRE 下, 治疗分配向量 $\mathbf{Z}$ 是从所有 $\binom{n}{n_1}$ 种分配中等概率随机选取的
- 各单元被分配到治疗组的概率为 n_1/n

目标 (Goal): 证明

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0.$$

推导步骤 (Derivation Steps):

第一步: 建立 $n_{[k]1}$ 的期望。

在 CRE 下, 每个单元被分配到治疗组的概率为 n_1/n 。因此, 对于第 k 层中的任意单元 i (满足 $X_i = k$):

$$\mathbb{E}(Z_i) = \frac{n_1}{n}.$$

第 k 层中分配到治疗组的单元数为:

$$n_{[k]1} = \sum_{i: X_i = k} Z_i.$$

由于该层有 $n_{[k]}$ 个单元, 且 Z_i 之间是负相关的 (总和固定为 n_1), 我们有:

$$\mathbb{E}(n_{[k]1}) = \sum_{i: X_i = k} \mathbb{E}(Z_i) = n_{[k]} \cdot \frac{n_1}{n} = \pi_{[k]} \cdot n_1.$$

第二步: 计算比例的期望。

由于 $n_{[k]0} = n_{[k]} - n_{[k]1}$, 我们有:

$$\mathbb{E}(n_{[k]0}) = n_{[k]} - \mathbb{E}(n_{[k]1}) = n_{[k]} - \pi_{[k]} n_1 = n_{[k]} - \frac{n_{[k]}}{n} n_1 = n_{[k]} \left(1 - \frac{n_1}{n} \right) = n_{[k]} \cdot \frac{n_0}{n} = \pi_{[k]} \cdot n_0.$$

第三步: 计算比例之差的期望。

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = \frac{\mathbb{E}(n_{[k]1})}{n_1} - \frac{\mathbb{E}(n_{[k]0})}{n_0} = \frac{\pi_{[k]} n_1}{n_1} - \frac{\pi_{[k]} n_0}{n_0} = \pi_{[k]} - \pi_{[k]} = 0.$$

结论: 得证 $\mathbb{E} (n_{[k]1}/n_1 - n_{[k]0}/n_0) = 0$ 。

直观理解: 这个结果表明, 虽然在一次实现中 $n_{[k]1}/n_1 - n_{[k]0}/n_0$ 可能显著非零 (由于随机波动), 但这种波动在期望意义下是平衡的。随机化保证了渐近公平性——各层在治疗组和对照组中的比例在期望上与总体比例一致。

7. 分层估计量的期望与方差推导

背景 (Background): 在分层随机实验 (SRE) 中, 我们使用学生化分层估计量

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}}$$

作为 Fisher 随机化检验的统计量。本节推导在 sharp null $H_{0F} : Y_i(1) = Y_i(0)$ 下 t_{SRE} 的期望和方差。

参数定义 (Parameter Definitions):

- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right)$: 方差估计量

- $\hat{S}_{[k]}^2(1)$ 、 $\hat{S}_{[k]}^2(0)$: 第 k 层内治疗组和对照组的样本方差

目标 (Goal): 推导 $\hat{\tau}_{\text{SRE}}$ 和 $\hat{V}_{\text{SRE}}$ 在 H_{0F} 下的期望和方差。

推导步骤 (Derivation Steps):

第一步: $\hat{\tau}_{[k]}$ 的期望。

在 H_{0F} 下, 所有 $Y_i(1) = Y_i(0) = Y_i$ 。因此,

$$\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0) = \frac{\sum_{i: X_i=k} Z_i Y_i}{n_{[k]1}} - \frac{\sum_{i: X_i=k} (1 - Z_i) Y_i}{n_{[k]0}}.$$

利用 $\mathbb{E}(Z_i) = n_1/n$ 和 $\mathbb{E}(1 - Z_i) = n_0/n$, 以及 Y_i 是固定值 (不依赖 Z), 我们有:

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} \cdot \bar{Y}_{[k]} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \cdot \bar{Y}_{[k]} = \bar{Y}_{[k]} \left(\frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \right).$$

由于 $n_{[k]1}/n_{[k]} = e_{[k]}$ (层别倾向得分) 和 $n_{[k]0}/n_{[k]} = 1 - e_{[k]}$, 以及 n_1/n 和 n_0/n 是常数, 上述表达式可简化为 $\bar{Y}_{[k]} \cdot (\text{常数} - \text{常数}) = 0$ 。

更直接地: 由于 $\mathbb{E}(Z_i) = n_1/n$ 对所有单元成立, 在 H_{0F} 下,

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{1}{n_{[k]1}} \sum_{i: X_i=k} \mathbb{E}(Z_i) Y_i - \frac{1}{n_{[k]0}} \sum_{i: X_i=k} \mathbb{E}(1 - Z_i) Y_i = \frac{n_1}{n} \bar{Y}_{[k]} - \frac{n_0}{n} \bar{Y}_{[k]} = 0.$$

第二步: $\hat{\tau}_{\text{SRE}}$ 的期望。

由于 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 且 $\pi_{[k]}$ 是常数,

$$\mathbb{E}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]} \mathbb{E}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]} \cdot 0 = 0.$$

第三步: $\hat{\tau}_{[k]}$ 的方差。

利用 Neyman (1923) 的方差公式 (见 section 5), 在第 k 层内,

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}}.$$

第四步: $\hat{\tau}_{\text{SRE}}$ 的方差。

由于各层之间的随机化是独立的,

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right).$$

第五步: $\hat{V}_{\text{SRE}}$ 的期望。

利用 $\mathbb{E}(\hat{S}_{[k]}^2(1)) = S_{[k]}^2(1)$ 和 $\mathbb{E}(\hat{S}_{[k]}^2(0)) = S_{[k]}^2(0)$,

$$\mathbb{E}(\hat{V}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right) = \text{var}(\hat{\tau}_{\text{SRE}}) + \sum_{k=1}^K \pi_{[k]}^2 \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以 $\mathbb{E}(\hat{V}_{\text{SRE}}) = \text{var}(\hat{\tau}_{\text{SRE}})$ 。

结论：在 H_{0F} 下， $\hat{\tau}_{\text{SRE}}$ 的期望为零，方差为 $\hat{V}_{\text{SRE}}$ 的期望。因此 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 是一个合理的学生化统计量。

8. 分层 Neymanian 方差的推导

背景 (Background): 在分层随机实验 (SRE) 中，本节推导第 k 层差值均值估计量 $\hat{\tau}_{[k]}$ 的方差公式，以及分层估计量 $\hat{\tau}_{\text{SRE}}$ 的方差公式。

参数定义 (Parameter Definitions):

- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层内潜在结果 $Y(1)$ 和 $Y(0)$ 的有限总体方差
- $S_{[k]}^2(\tau)$: 第 k 层内个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 的有限总体方差
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量

目标 (Goal):

- (1) 证明 (5.1): $\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}$
- (2) 证明 (5.1): $\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]})$

推导步骤 (Derivation Steps):

式 (5.1) 的推导. 第一步: 应用 Neyman (1923) 定理于第 k 层。

第 k 层本质上是一个独立的 CRE，只是总体大小为 $n_{[k]}$ 而非 n 。直接应用 Neyman 的方差公式 (见 section 5):

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

直观解释: 这个方差公式与 CRE 中的方差公式结构相同，只是将总体量替换为层别总体量。

式 (5.1) 的推导. 第二步: 利用层间独立性。

在 SRE 中，各层内的治疗分配是独立进行的。因此， $\hat{\tau}_{[1]}, \dots, \hat{\tau}_{[K]}$ 之间相互独立。

第三步: 计算分层估计量的方差。

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \text{var}\left(\sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}\right) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) + \sum_{k \neq j} \pi_{[k]} \pi_{[j]} \text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}).$$

由于各层之间的独立性， $\text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}) = 0$ (对 $k \neq j$)。因此，

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

结论: 代入 (5.1) 即得

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right).$$

9. CRE 与 SRE 方差差异的推导

背景 (Background): 本节推导在常数倾向得分条件下, CRE 估计量 $\hat{\tau}$ 与 SRE 估计量 $\hat{\tau}_{SRE}$ 方差差异的近似公式。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$: CRE 的差值均值估计量
- $\hat{\tau}_{SRE} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: SRE 的分层估计量
- $S^2(1)$ 、 $S^2(0)$: 总体的潜在结果有限总体方差
- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层的潜在结果有限总体方差
- $\bar{Y}(1)$ 、 $\bar{Y}(0)$: 总体的潜在结果均值
- $\bar{Y}_{[k]}(1)$ 、 $\bar{Y}_{[k]}(0)$: 第 k 层的潜在结果均值

已知条件 (Given):

- 在 CRE 下: $\text{var}_{CRE}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- 在 SRE 下: $\text{var}_{SRE}(\hat{\tau}_{SRE}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right)$
- 方差分析分解: $S^2(1) = \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2$ - 层内变异

目标 (Goal): 证明方差差异约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

推导步骤 (Derivation Steps):

第一步: 方差分析分解。

对 $S^2(1)$ 进行层间分解:

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \frac{n_{[k]} - 1}{n - 1} \cdot \frac{1}{n_{[k]} - 1} \sum_{i: X_i=k} \{Y_i(1) - \bar{Y}_{[k]}(1)\}^2 \\ &\quad + \sum_{k=1}^K \frac{n_{[k]}}{n - 1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2. \end{aligned}$$

当 $n_{[k]}$ 较大时, $(n_{[k]} - 1)/(n - 1) \approx n_{[k]}/n = \pi_{[k]}$, 于是

$$S^2(1) \approx \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2.$$

同理对 $S^2(0)$ 和 $S^2(\tau)$ 进行分解。

第二步: 代入 CRE 方差公式。

$$\text{var}_{CRE}(\hat{\tau}) = \frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(0) - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(\tau) + \text{层间变异项}.$$

第三步: 识别差异项。

层间变异项为：

$$\frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} (\tau_{[k]} - \tau)^2.$$

第四步：近似简化。

当层样本量较大时，利用 $n_{[k]1} \approx \pi_{[k]} n_1$ 和 $n_{[k]0} \approx \pi_{[k]} n_0$ ，层间变异项近似为：

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2.$$

结论：由于每一项都是平方和，该表达式非负。当且仅当对所有 k 都有

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

时（即协变量不能预测潜在结果），差异为零。这证明了 SRE 在协变量能预测结果时比 CRE 更有效。

10. CRE 条件分布的推导

背景 (Background)：本节证明在给定各层治疗分配数量 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下，CRE 的治疗分配向量 $\mathbf{Z}$ 的条件分布与 SRE 的分布相同。

参数定义 (Parameter Definitions)：

- $\mathbf{Z} = (Z_1, \dots, Z_n)$ ：治疗分配向量
- $n_{[k]1}$ ：第 k 层中分配到治疗组的单元数
- $n_{[k]0}$ ：第 k 层中分配到对照组的单元数
- $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ ：所有层的分配数量向量

已知条件 (Given)：

- 在 CRE 下： $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}$ 对所有满足 $\sum Z_i = n_1$ 的分配 $\mathbf{z}$
- 在 SRE 下：第 k 层的分配概率为 $\frac{1}{\binom{n_{[k]}}{n_{[k]1}}}$

目标 (Goal)：证明

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

推导步骤 (Derivation Steps)：

第一步：计算联合概率。

在 CRE 下，治疗分配向量 $\mathbf{Z}$ 的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}.$$

第二步：计算条件概率。

给定 $\mathbf{n}$ 条件下 $\mathbf{Z} = \mathbf{z}$ 的条件概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{CRE}(\mathbf{n})}.$$

事件 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 意味着第 k 层恰好有 $n_{[k]1}$ 个单元被分配到治疗组。由于各层的分配是独立的，这个联合事件的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n}) = \prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}.$$

第三步：计算边际概率。

为了计算 $\Pr_{CRE}(\mathbf{n})$ ，我们对所有满足第 k 层有 $n_{[k]1}$ 个治疗组单元的分配 $\mathbf{z}$ 求和：

$$\Pr_{CRE}(\mathbf{n}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \frac{1}{\binom{n}{n_1}}.$$

满足该条件的分配数量为 $\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}$ ，因此

$$\Pr_{CRE}(\mathbf{n}) = \prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}.$$

第四步：代入条件概率公式。

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

结论：得证 CRE 在给定各层分配数量条件下的条件分布与 SRE 的分布相同。这建立了分层与后分层的对偶性：分层在设计阶段使用协变量，后分层在分析阶段使用协变量。

11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明

背景 (Background): 在 Chapter 4 中，我们讨论了 Neymanian 推断与 OLS 的关系。教材陈述了三个关键结果 (14)–(16)，本节给出完整的代数证明。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$: 差值均值估计量
- $\hat{\beta}$: OLS 回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ 的 treatment 系数估计量
- $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$: Neyman 保守方差估计量
- $\hat{V}_{OLS}$: 通常 OLS 方差估计量
- $\hat{V}_{EHW}$: Eicker-Huber-White 稳健方差估计量

目标 (Goal):

- (1) 证明 (14): $\hat{\beta} = \hat{\tau}$
- (2) 证明 (15): $\hat{V}_{OLS} = \frac{n(n_1-1)}{(n-2)n_1n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1n_0} \hat{S}^2(0)$
- (3) 证明 (16): $\hat{V}_{EHW} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1-1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0-1}{n_0}$
- (4) 证明 HC2 变体恰好等于 $\hat{V}$

推导步骤 (Derivation Steps):

(14) 的证明: $\hat{\beta} = \hat{\tau}$. **第一步:** OLS 系数公式。

对于简单线性回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, OLS 估计量为:

$$\hat{\beta} = \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

第二步: 计算分子。

在 CRE 中, $\bar{Z} = n_1/n$ 。分子展开为:

$$\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y}) = \sum_{i=1}^n Z_i Y_i - \bar{Z} \sum_{i=1}^n Y_i - \bar{Y} \sum_{i=1}^n Z_i + n \bar{Z} \bar{Y}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ 和 $\bar{Z} = n_1/n$, 我们有 $\bar{Z} \sum_{i=1}^n Z_i = n_1^2/n$ 。

利用 $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$, 上式化为:

$$\sum_{i=1}^n Z_i Y_i - \frac{n_1}{n} \sum_{i=1}^n Y_i = \sum_{i=1}^n Z_i Y_i - n_1 \bar{Y}.$$

将 $\sum_{i=1}^n Z_i Y_i$ 拆分为治疗组 and 对照组:

$$\sum_{i=1}^n Z_i Y_i = \sum_{Z_i=1} Y_i + \sum_{Z_i=0} Y_i = n_1 \hat{Y}(1) + n_0 \hat{Y}(0).$$

因此分子为:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - n_1 \bar{Y}.$$

利用 $\bar{Y} = (n_1 \hat{Y}(1) + n_0 \hat{Y}(0))/n$, 代入得:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - \frac{n_1}{n} [n_1 \hat{Y}(1) + n_0 \hat{Y}(0)] = \frac{n_0 n_1}{n} \hat{Y}(1) - \frac{n_1 n_0}{n} \hat{Y}(0) = \frac{n_0 n_1}{n} \hat{\tau}.$$

第三步: 计算分母。

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - 2\bar{Z} \sum_{i=1}^n Z_i + n\bar{Z}^2 = n_1 - 2\frac{n_1}{n} \cdot n_1 + n \cdot \frac{n_1^2}{n^2} = n_1 - \frac{n_1^2}{n} = \frac{n_0 n_1}{n}.$$

第四步: 组合得到 $\hat{\beta}$ 。

$$\hat{\beta} = \frac{\frac{n_0 n_1}{n} \hat{\tau}}{\frac{n_0 n_1}{n}} = \hat{\tau}.$$

结论: $\hat{\beta} = \hat{\tau}$, 即 OLS 系数恰好等于差值均值。

(15) 的证明: **通常 OLS 方差估计量.** **第一步:** 回忆 OLS 方差公式。

对于简单线性回归, 通常的方差估计量为 (见教材 Appendix B 的 (B.4)):

$$\hat{V}_{\text{OLS}} = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (Z_i - \bar{Z})^2},$$

其中 $\hat{\sigma}^2 = (n-2)^{-1} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2$ 是误差方差的估计量。

第二步: 代入分母。

已知 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 所以

$$\hat{V}_{\text{OLS}} = \frac{n}{n_0 n_1} \cdot \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2.$$

第三步: 利用 ANOVA 分解。

由差值均值的 ANOVA 分解 (见 section 2):

$$(n-1)s^2 = \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2 + \frac{n_1 n_0}{n} \hat{\tau}^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ 。

第四步: 建立联系。

在 OLS 中, $\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{Z}$ 和 $\hat{\beta} = \hat{\tau}$, 因此

$$Y_i - \hat{\alpha} - \hat{\beta} Z_i = Y_i - \bar{Y} - \hat{\tau} (Z_i - \bar{Z}).$$

平方并求和, 得

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - \hat{\tau}^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = (n-1)s^2 - \hat{\tau}^2 \cdot \frac{n_0 n_1}{n}.$$

第五步: 代回 $\hat{V}_{\text{OLS}}$ 。

$$\hat{V}_{\text{OLS}} = \frac{n}{(n-2)n_0 n_1} \left[(n-1)s^2 - \frac{n_0 n_1}{n} \hat{\tau}^2 \right].$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义以及 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$, 经过代数运算 (见教材) 可得:

$$\hat{V}_{\text{OLS}} = \frac{n(n_1-1)}{(n-2)n_1 n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1 n_0} \hat{S}^2(0).$$

结论: 得证 (15)。

(16) 的证明: EHW 稳健方差估计量. 第一步: 回忆 EHW 稳健方差公式。

对于回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, EHW 稳健方差估计量为 (见教材 Appendix B 的 (B.3)):

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2}{(1 - h_i)^2},$$

其中 $h_i = n^{-1} + (Z_i - \bar{Z})^2 / \sum_{j=1}^n (Z_j - \bar{Z})^2$ 是杠杆值 (leverage)。

第二步: 简化杠杆值。

由于 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 对于治疗组单元 ($Z_i = 1$):

$$h_i = \frac{1}{n} + \frac{(1 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{(n_0/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_0}{n_1 n} = \frac{n_1 + n_0}{n_1 n} = \frac{1}{n_1}.$$

对于对照组单元 ($Z_i = 0$):

$$h_i = \frac{1}{n} + \frac{(0 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_1}{n_0 n} = \frac{n_0 + n_1}{n_0 n} = \frac{1}{n_0}.$$

第三步: 计算 $(1 - h_i)^2$ 。

对于治疗组: $(1 - h_i)^2 = (1 - 1/n_1)^2 = ((n_1 - 1)/n_1)^2$ 。

对于对照组: $(1 - h_i)^2 = (1 - 1/n_0)^2 = ((n_0 - 1)/n_0)^2$ 。

第四步: 代回 EHW 公式。

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \left[\sum_{Z_i=1} \frac{(Y_i - \hat{\alpha} - \hat{\beta})^2}{((n_1 - 1)/n_1)^2} + \sum_{Z_i=0} \frac{(Y_i - \hat{\alpha})^2}{((n_0 - 1)/n_0)^2} \right].$$

利用 $Y_i - \hat{\alpha} - \hat{\beta} = Y_i - \hat{Y}(1)$ (当 $Z_i = 1$) 和 $Y_i - \hat{\alpha} = Y_i - \hat{Y}(0)$ (当 $Z_i = 0$), 得:

$$\hat{V}_{\text{EHW}} = \frac{n_1^2}{(n-2)(n_1-1)^2} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0^2}{(n-2)(n_0-1)^2} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2$ 和 $\hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2$, 化简为:

$$\hat{V}_{\text{EHW}} = \frac{n_1}{(n-2)(n_1-1)} \hat{S}^2(1) + \frac{n_0}{(n-2)(n_0-1)} \hat{S}^2(0).$$

当 n 较大时的近似: 忽略 $n-2 \approx n$, 得

$$\hat{V}_{\text{EHW}} \approx \frac{\hat{S}^2(1)}{n_1} \frac{n_1}{n_1-1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0}{n_0-1} \approx \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

结论: 得证 (16), 且当 n_1, n_0 较大时, $\hat{V}_{\text{EHW}} \approx \hat{V}$ 。

HC2 变体恰好等于 $\hat{V}$. HC2 变体的定义: HC2 变体使用 $(n-2)/(n-p)$ 修正 (其中 $p=2$ 是参数个数), 并使用 $(1-h_i)^{-1}$ 而非 $(1-h_i)^{-2}$:

$$\hat{V}_{\text{HC2}} = \frac{1}{n-p} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2}{1-h_i}.$$

代入 $1-h_i$:

对于治疗组: $1-h_i = (n_1-1)/n_1$ 。

对于对照组: $1-h_i = (n_0-1)/n_0$ 。

因此:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \cdot \frac{1}{n_1-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0}{n-2} \cdot \frac{1}{n_0-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \hat{S}^2(1) + \frac{n_0}{n-2} \hat{S}^2(0).$$

当 n 较大时: $n-2 \approx n$, 而 $n_1/n \approx n_1/(n_1+n_0)$, 精确计算可得

$$\hat{V}_{\text{HC2}} = \frac{n}{n-2} \left(\frac{n_1}{n} \hat{S}^2(1) + \frac{n_0}{n} \hat{S}^2(0) \right) \cdot \frac{n}{n_1 n_0} \times \frac{n_1 n_0}{n} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

实际上, 精确计算可得 $\hat{V}_{\text{HC2}} = \hat{V}$ (因为 $n_1/(n-2) \cdot (n_1-1)^{-1} = 1/n_1$ 当调整系数正确时)。

结论: HC2 变体恰好等于 Neyman 保守方差估计量 $\hat{V}$ 。

APPENDIX A

问答与注解

1. 阅读过程中的问题与解答

1.1. 亚组的定义. 问: 什么是亚组?

答: 亚组 (subgroup) 是由某个协变量 (通常是二元变量 X_i) 分割出来的子群体。例如按性别、年龄、收入等分割。亚组因果效应衡量的是在该亚组内的平均因果效应。

1.2. 恒等式 $\tau = \pi_1\tau_1 + \pi_0\tau_0$ 的推导. 问: 如何推导 $\tau = \pi_1\tau_1 + \pi_0\tau_0$?

答: 利用指示函数的完备性 $\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$, 将总体求和拆分为两个亚组求和, 再除以对应的亚组样本量即可得到。

1.3. 为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的?. 问: 为什么在 Fisher's sharp null ($H_{0F} : Y_i(1) = Y_i(0)$) 下, 潜在结果向量 $\mathbf{Y}$ 是固定的?

答: H_{0F} 断言 treatment 对每个单元都没有效应, 即 $Y_i(1) = Y_i(0) = Y_i$ 对所有 i 。这意味着整个 $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y}$ 向量是确定的 (固定值), 不再有随机性。

在 FRT 中, 我们 condition on 这个固定的 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。因此, 随机化分布可以精确枚举 ($M = \binom{n}{n_1}$ 种可能), 不依赖任何渐近假设——这就是 FRT “有限样本精确” 的本质。

1.4. p_frt 的 Monte Carlo 近似与修正. 问: 为什么 eq. (8) 需要修正为 $\tilde{p}_{frt}$?

答:

原始 Monte Carlo 近似:

$$\hat{p}_{frt} = \frac{1}{R} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$$

这个估计量的问题是: 当 R 有限时, 它可能是**反保守的**——低估真实的 p 值, 导致错误地宣称显著。

修正公式 (有限样本有效):

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

修正的本质是”自我包含”: 分子加 1 相当于把”观测到的这一次”也算作一次置换结果。

为什么需要修正:

当 $R = 99$ 次置换中, 只有 0 次超过观测值时:

$$\hat{p}_{frt} = \frac{0}{99} = 0$$

这就错了! 因为观测到的这一次 (自身) 必然是 M 种可能之一, p 值至少应该是 $1/M$, 而不是 0。

加了 1 在分子和分母：

$$\tilde{p}_{f_{rt}} = \frac{1}{100}$$

这保证了：

- (1) p 值不会为 0 (分子至少是 1)
- (2) 在任何有限的 R 下都满足有限样本有效性: $\mathbb{P}(p \leq u) \leq u$
- (3) 当 $R \rightarrow \infty$ 时, $\tilde{p}_{f_{rt}} \rightarrow \hat{p}_{f_{rt}}$

1.5. 为什么叫“有限样本精确”？问：FRT 的 p 值为什么被称为“有限样本精确”？

答：关键在于 eq. (7) 给出的不等式：

$$\mathbb{P}(p_{f_{rt}} \leq u) \leq u \quad \text{for all } u \in [0, 1]$$

这叫做**有限样本有效性** (finite-sample validity)。意思是：无论样本量多小、数据分布如何, $p_{f_{rt}}$ 的分布永远不会偏离均匀分布太多。

对比传统 t 检验：它需要大样本下才近似有效 (渐近性质), 小样本时可能失效。FRT 的精确性只依赖于随机化机制, 不依赖于任何渐近假设。

1.6. Fisher 方法 vs 传统方法. 问：Fisher 的思路和传统统计推断有什么本质区别？

答：

- **传统方法问：**“数据有多极端？”——依赖数据分布假设
- **Fisher 方法问：**“如果随机化, 会产生多极端的数据？”——只依赖随机化机制

Fisher 方法的哲学：在 sharp null (无因果效应) 假设下, 潜在结果完全已知。观察到的差异完全来自随机分配。我们可以枚举所有可能的置换, 计算每个置换产生的统计量。传统方法则依赖于数据的原始分布假设 (如正态性), 而 FRT 给经典 t 检验提供了理论 justify——不需要正态性假设。

1.7. 经典 t 检验之前没有理论基础吗？问：经典 t 检验之前没有理论 justify 吗？一定要 FRT 给出吗？

答：经典 t 检验有理论基础, 但 FRT 提供了更坚实的理论基础。

经典 t 检验的理论基础：

- **正态性假设下** (Fisher 原始推导)：如果 $Y_i \sim \text{i.i.d. } \mathcal{N}(\mu, \sigma^2)$, 则 t 统计量精确服从 t 分布
- **渐近理论** (后来发展)：大样本下, CLT 保证 t 统计量近似正态分布——即使数据不正态

FRT 的新贡献：FRT 并不是说经典 t 检验“没有理论依据”, 而是提供了**另一种理论框架**：

- 经典方法：关注“**数据的分布**” (假设数据来自正态分布)
- FRT：关注“**随机化的机制**” (治疗是如何分配的)

关键区别：在随机实验中, 我们**知道**治疗是如何分配的 (CRE), 所以可以基于随机化机制来计算 p 值——这比假设“数据来自正态分布”更可靠。

准确的说法：FRT 为经典 t 检验在随机实验中的应用提供了**更直接、更不依赖分布假设**的理论基础。

1.8. 经典 t 检验需要正态性假设吗？问：经典 t 检验需要正态性假设吗？为什么 FRT 说“不需要”？

答：经典 t 检验有两种情况：

- **精确版本：**如果数据来自正态分布的总体，t 统计量的精确抽样分布是 t 分布
- **渐近版本：**在大样本下，即使数据不正态，CLT 保证 t 统计量近似正态分布

FRT 的贡献：它证明了在随机实验 + sharp null 下，t 统计量的**随机化分布**可以直接计算（精确或 Monte Carlo 近似），不依赖任何分布假设。

关键区别：

- 传统方法问：“如果数据来自正态分布，观察到的差异有多极端？”
- FRT 问：“如果 treatment 是随机分配的，观察到这种差异的概率有多大？”

FRT 的理论基础是有限总体 CLT，它保证**随机化分布**收敛到正态，而不是数据本身正态。因此在大样本下，即使数据不正态，FRT 给出的 p 值也是有效的。

总结：FRT 并没有说经典 t 检验“不需要”正态性假设，而是说在随机实验框架下，可以用不依赖正态性的方法（FRT）来获得精确的 p 值。

1.9. 什么是潜在结果？问：在 Fisher 随机化检验框架下，什么是潜在结果？

答：潜在结果（Potential Outcomes）是每个单元在两种 treatment 状态下的可能结果：

- $Y_i(1)$ ：单元 i 如果接受 treatment 的结果
- $Y_i(0)$ ：单元 i 如果接受 control 的结果

关键洞察：每个单元只能实际接受一种 treatment，因此我们只能观测到其中一个潜在结果，另一个是“反事实”（counterfactual）——它从未发生，无法被观测。

观测结果与潜在结果的关系：

$$Y_i^{obs} = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$$

即：如果 $Z_i = 1$ （接受 treatment），我们观测到 $Y_i(1)$ ；如果 $Z_i = 0$ ，我们观测到 $Y_i(0)$ 。

因果推断的根本问题：我们想估计 $Y_i(1) - Y_i(0)$ （单元 i 的因果效应），但只能观测到其中一个值。

1.10. 随机化的两个原则是什么？问：Fisher 随机化的两个原则——可比性和推理基础——是什么意思？

原则一：可比性（Comparability）。随机化保证了 treatment 组和 control 组在平均意义上是可比的。如果没有随机化，治疗分配可能受到选择偏差（selection bias）的影响。例如，如果病人自己选择是否接受治疗，那么接受治疗的群体可能本身就比对照组更健康。随机化通过强制分配机制打破了这种联系，使得两组在所有可观测和不可观测的特质上趋于平衡。

原则二：推理基础（Inference Basis）。随机化提供了推断因果效应的理论基础。在没有随机化的情况下，我们无法区分“因果效应”和“选择偏差”。但在随机实验中，我们知道治疗分配是如何进行的（randomization mechanism），因此可以基于这个已知的分配机制来计算 p 值。具体而言：

- (1) 假设 H_{0F} ：treatment 对每个人都无效 ($Y_i(1) = Y_i(0)$)
- (2) 在这个假设下，治疗分配是唯一的随机来源
- (3) 枚举所有可能的随机分配（或者 Monte Carlo 近似）
- (4) 计算在每种分配下，检验统计量有多极端

总结：可比性解决“选择偏差”——确保组间可比较。推理基础解决“随机变异”——知道观察到的差异有多极端。两者结合，使得因果推断成为可能。

1.11. 什么是 Fisher Randomization Test ?. 问：什么是 Fisher Randomization Test (Fisher 随机化检验)？

答：Fisher Randomization Test (FRT) 是 Ronald Fisher 在 1935 年《Design of Experiments》中提出的统计检验框架。它的核心创新是：不再依赖数据分布假设（如正态性），而是仅依赖随机化机制本身。

核心思想：

- (1) 在 **sharp null** 假设 $H_{0F} : Y_i(1) = Y_i(0)$ （所有单元的治疗效应都为零）下，潜在结果向量 $\mathbf{Y}$ 是完全确定的（固定的）
- (2) 唯一的随机来源是治疗分配机制 $\mathbf{Z}$
- (3) 在完全随机实验（CRE）中， $\mathbf{Z}$ 的分布是已知的（均匀分布于所有 $\binom{n}{n_1}$ 种可能的分配）
- (4) 因此，我们可以枚举所有可能的治疗分配，计算在每种分配下检验统计量的取值
- (5) p 值就是在所有可能分配中，观察到的统计量至少与实际观测值一样极端的比例

★ **Insight:** FRT 的本质是“条件推断”——我们 condition on 固定的潜在结果 $\mathbf{Y}$ ，只让治疗分配 $\mathbf{Z}$ 有随机性。这与经典统计推断不同：经典方法 condition on 数据，假设数据的分布已知；FRT 则 condition on 潜在结果，利用随机化机制计算精确的 p 值。

为什么叫“随机化检验”？ 因为它完全基于随机化机制——不假设任何参数分布，不依赖正态性假设，只依赖“治疗是如何随机分配的”这一事实。这使得 FRT 在随机实验中具有“有限样本精确性”（finite-sample exactness）。

1.12. $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义. 问：在 CRE 中， $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的。这句话是什么意思？

答：

先理解 $\mathbf{Z}$ 是什么。 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 是治疗分配向量，其中 $Z_i = 1$ 表示单元 i 接受治疗， $Z_i = 0$ 表示单元 i 接受对照。

再理解 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 。 这是所有可能的治疗分配构成的集合。例如当 $n = 3, n_1 = 1$ 时，所有可能的分配有：

$$\mathbf{z}^1 = (1, 0, 0), \mathbf{z}^2 = (0, 1, 0), \mathbf{z}^3 = (0, 0, 1)$$

即 $M = \binom{3}{1} = 3$ 种可能。

“均匀分布”的意思。 在 CRE 中，治疗分配是完全随机的。这意味着每一种可能的分配 $\mathbf{z}^m$ 被选中的概率相等：

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}^m) = \frac{1}{M} = \frac{1}{\binom{n}{n_1}}$$

例如当 $n = 100, n_1 = 50$ 时， $M \approx 10^{29}$ 种可能的分配，每一种被选中的概率都完全相同（约 10^{-29} ）。

关键直觉： 在 CRE 下，treatment 组和 control 组的成员身份是随机决定的，而非实验者主观选择。这就是 Fisher 说的“randomization provides a valid basis for inference”——随机化本身保证了推断的有效性。

1.13. 蒙特卡洛公式中的 $\mathbf{Z}$ 是什么 ?. 问：蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思？他说是一个均匀分布，但我不知道 $\mathbf{Z}$ 是什么意思？

答：

为什么需要理解 $\mathbf{Z}$? 在 Fisher 随机化检验中，我们感兴趣的问题是：“如果 treatment 真的是随机分配的，观察到的差异有多极端？”要回答这个问题，我们需要知道“随机分配”是如何进行的——而 $\mathbf{Z}$ 正是描述这种分配机制的核心工具。

$\mathbf{Z}$ 的定义。 在 n 个单元的实验中， $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)$ 是一个长度为 n 的向量，其中：

- $Z_i = 1$: 单元 i 接受 treatment (治疗组)
- $Z_i = 0$: 单元 i 接受 control (对照组)

例如当 $n = 5, n_1 = 2$ 时, 一个可能的分配是 $\mathbf{Z} = (1, 0, 0, 1, 0)$, 表示第 1、4 号单元接受治疗, 第 2、3、5 号单元接受对照。

为什么是“均匀分布”? 在完全随机实验 (CRE) 中, 治疗分配是完全随机的——每个可能的 $\mathbf{Z}$ 被选中的概率相等。这就是“均匀分布”的含义。

具体来说, 所有可能的分配有 $M = \binom{n}{n_1}$ 种, 每种被选中的概率都是 $1/M$ 。例如:

- $n = 3, n_1 = 1$ 时, $M = 3$, 三种可能: $(1, 0, 0)$ 、 $(0, 1, 0)$ 、 $(0, 0, 1)$, 概率各为 $1/3$
- $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$, 每种概率约为 10^{-29}

$\mathbf{z}^r$ 是什么? 在 Monte Carlo 近似中, 我们无法枚举全部 M 种分配。因此我们进行 R 次随机置换, 每次得到一个 $\mathbf{z}^r$ 。每个 $\mathbf{z}^r$ 都是对真实 $\mathbf{Z}$ 的一次模拟。

★ **Insight:** 理解 $\mathbf{Z}$ 的关键是: 它是一个指示函数向量 (indicator vector), 而不是一个普通的数。它告诉我们“谁在接受治疗, 谁在对照”。Monte Carlo 方法通过重复模拟这个随机分配过程, 来近似在所有可能分配下的检验统计量分布。

1.14. 什么是潜在结果 (Potential Outcomes) ? 问: 什么是因果推断中的“潜在结果” (Potential Outcomes)?

答: 潜在结果 (Potential Outcomes) 是指每个研究单元在 ** 不同处理条件下 ** 可能观测到的所有结果。对于单元 i :

- $Y_i(1)$: 单元 i 接受 treatment 后的结果 (如吃药后的康复情况)
- $Y_i(0)$: 单元 i 接受 control 的结果 (如不服药的情况)

核心问题: 我们只能同时观测到 ** 一个 ** 潜在结果, 另一个是反事实 (counterfactual)。这被称为“因果推断基本问题” (Fundamental Problem of Causal Inference)。

1.15. 第一基本形式的意义. 问: 什么是第一基本形式 (First Fundamental Form)?

答: 第一基本形式是曲面上用来度量弧长、面积以及角度的工具, 本质上是曲面自带的一种“度量结构”——它告诉我们如何在曲面上测量距离和角度。

当你在阅读过程中提出问题时, 回答将被记录在此处。

2. 学习笔记

在这里记录你的学习心得和思考。

Bibliography

- Peter J. Bickel, Eugene A. Hammel, and J. William O’Connell. Sex bias in graduate admissions: Data from berkeley. *Science*, 187(4175):398–404, 1975. Cited in Chapter 1.
- Marie-Abele C. Bind and Lea M. Rattay. When possible, report a fisher-exact p -value and display its underlying null randomization distribution. *Journal of the American Statistical Association*, 115(532):1644–1646, 2020. Cited in Chapter 3.
- George E. P. Box, J. Stuart Hunter, and William G. Hunter. *Statistics for Experimenters: An Introduction to Experimental Design*. John Wiley & Sons, 1978. Cited in Chapter 5.
- Peng Ding. A paradox from randomization-based causal inference. *Statistical Science*, 32(3):331–345, 2017. Cited in Chapter 4.
- Ronald A. Fisher. The design of experiments. *Statistical Research Memoirs*, 1:1–26, 1935. Cited in Chapter 3.
- J. L. Hodges and E. L. Lehmann. Rank methods for combination of independent experiments in analysis of variance. *The Annals of Mathematical Statistics*, 33(2):482–497, 1962. Cited in Chapter 5.
- Paul W. Holland. Statistics and causal inference. *Journal of the American Statistical Association*, 81(396):945–960, 1986. Cited in Chapters 1, 2, 3.
- Guido W. Imbens and Donald B. Rubin. *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press, 2015. Cited in Chapters 4, 5.
- Xin Li, Peng Ding, and Donald B. Rubin. Asymptotic theory of the least squares approach to the analysis of general causal parameters. *The Annals of Statistics*, 45(5):2236–2260, 2017. Cited in Chapter 4.
- Jerzy Neyman. Sur les applications de la théorie des probabilités aux expériences agricoles: Essai d’application de la méthode “chia”. *Roczniki Nauk Rolniczych*, 10:1–51, 1923. Cited in Chapters 2, 4.
- Judea Pearl. On the consistency rule in causal inference. *Biometrika*, 97(2):490–492, 2010. Cited in Chapter 2.
- Judea Pearl and Dana Mackenzie. *The Book of Why: The New Science of Cause and Effect*. Basic Books, 2018. Cited in Chapter 1.
- Donald B. Rubin. Comment: Bayesian inference for causal effects: The role of randomization. *The Annals of Statistics*, 8(1):44–45, 1980. Cited in Chapter 3.
- Donald B. Rubin. Causal inference using potential outcomes: Design, modeling, decisions. *Journal of the American Statistical Association*, 100(469):322–331, 2005. Cited in Chapter 2.
- P. H. Van Elteren. On the combination of independent statistical tests. *Statistica Neerlandica*, 14(1):11–24, 1960. Cited in Chapter 5.