

$y T w \ f l$

$S 2 M ; . B M ;$

*QM i2Mib

„ý ÓDÀ•	N
„ý ÓDÀ•	N
RX9•	N
kXÓDK19 ²	N
jX € •I'	Ry
9XĐ ^åĐ-Â \$©M	Ry
8XKÔ"S	Ry
*? Ti2` RM1Ÿa1óĐ umH2@aBKTbQM	RR
RX'c•,	RR
kX ¹ I ¹ f ñ Û5“×1	RR
jX M1ŸĐyTŸ¥uY	RR
9X=» óVĐ1ó	RR
8X umH2@aBKTbQM	Rk
eXÊM1""Đ umH2@aBKTbQM	Rk
dX G GQM/2ìÆì Û5	Rj
3XÕB j¥eåL	Rj
NX'cl ² Đ/«ç á	Rj
RyX5	Rj
*? Ti2` kX ² T•O	R8
RXVM1žyT ¹ I ¹ 1ó, \$	R8
kXBñ±XL	R8
jX SĐV a+B2M+2 h #H2	R8
9Xñ8yTr<	Re
8XÜ(yTr<	Re
eXđFĐđFyTr<	Rd
dXđFyTr<Đ umH2@aBKTbQM	Rd
3XÍ s¥ ÅĐ 'š©T	Rd
NX alhoP•Oµr¥A1L!	Rd
RyXQYL±»¥†	R3
RRX †íçl¥±óŸ	RN
RkXdLŸyT•"	RN
RjX'cl ²	RN
R9X5	RN
R8Xc Tw•	ky
*? Ti2` jX†Ū L Đn :Ū Ä_	kj
RXV. ² T•OžŪ L Û5¥ ÷	kj

其中 $d = \mathbb{E}(X \mid Z = 1) - \mathbb{E}(X \mid Z = 0)$ 是均值差异向量, $\|\cdot\|$ 是欧几里得范数。结合 ?? 和严格重叠给出的特征值界, 我们得到 ??。 $\square$

5.2. 结果建模的定理. 在 ?? 下, 均衡因果效应 $\tau = \mathbb{E}\{Y(1) - Y(0)\}$ 可由下式识别:

$$\tau = \mathbb{E}\{\mathbb{E}(Y \mid Z = 1, r(X)) - \mathbb{E}(Y \mid Z = 0, r(X))\} \quad (20.13)$$

或等价地,

$$\tau = \mathbb{E}\left\{\frac{ZY}{e(r(X))}\right\} - \mathbb{E}\left\{\frac{(1-Z)Y}{1 - e(r(X))}\right\}, \quad (20.14)$$

其中 $e(r(X)) = \{Z = 1 \mid r(X)\}$ 。⁶

5.3. 定理 ?? 的证明. 由右连续性,

$$\mathbb{E}\{Y(1) \mid X = x_0\} = \lim_{\varepsilon \rightarrow 0^+} \mathbb{E}\{Y(1) \mid X = x_0 + \varepsilon\}. \quad (20.15)$$

由 Z 的定义, 当 $X = x_0 + \varepsilon$ 时, $Z = 1$, 因此

$$\mathbb{E}\{Y(1) \mid X = x_0 + \varepsilon\} = \mathbb{E}(Y \mid Z = 1, X = x_0 + \varepsilon). \quad (20.16)$$

左连续性给出 $\mathbb{E}\{Y(0) \mid X = x_0\}$ 的类似表达式。取差即得 ??。 $\square$

⁶证明思路: 利用 $r(X)$ 上的条件期望和潜在结果的定义, 直接展开即可。

5.4. OLS 等价性的推导. 设 $R_i = \max(X_i - x_0, 0)$ 和 $L_i = \min(X_i - x_0, 0)$ 。则

$$Z_i(X_i - x_0) = Z_i R_i - (1 - Z_i)L_i = R_i - L_i - (1 - Z_i)R_i + (1 - Z_i)L_i. \quad (20.17)$$

在模型 $Y_i \sim \{1, Z_i, X_i - x_0, Z_i(X_i - x_0)\}$ 中, Z_i 的系数为

$$\hat{\tau} = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)x_0. \quad (20.18)$$

这与 ?? 相同。类似地, 对模型 $Y_i \sim \{1, Z_i, R_i, L_i\}$ 展开并比较系数可得相同结果。 $\square$

两阶段最小二乘

1. 引言：工具变量回归的计算技巧

在上一章中，我们讨论了恰好识别（just-identified）情况下的工具变量（IV）估计：当工具变量 Z 与内生解释变量 D 维度相同时，我们可以直接通过矩条件 $E(ZY) = E(ZD^\top)\beta$ 求解得到 IV 估计量。然而，在实际研究中，我们常常面临过度识别（over-identified）的情形——也就是说，我们拥有的工具变量数量多于内生变量的数量。

这种情况在经验研究中非常普遍。例如，在研究教育回报的问题时，Angrist and Krueger (1991) 使用出生季度作为教育的工具变量，但实际上我们可能有多个与误差项无关的变量都可以作为工具变量。当工具变量多于内生变量时，矩条件方程组中方程的个数多于未知参数的个数，系统没有唯一的精确解。

一个自然而然的问题是：如何在这种情况下找到一个“最优”的估计量？正是为了回答这个问题，Theil (1953) 和 Basmann (1957) 分别独立地提出了两阶段最小二乘（Two-Stage Least Squares, TSLS）估计量。这是一个巧妙的计算技巧，它将一个看似复杂的过度识别问题转化为两个连续的普通最小二乘回归。

本章我们将详细介绍 TSLS 的动机、原理及其在大样本理论下的性质。

2. 问题设定：过度识别情形

让我们回顾线性工具变量模型的基本设定。假设我们有如下结构方程：

$$(76) \quad Y = D^\top \beta + \varepsilon,$$

其中 Y 是结果变量， D 是 p 维内生解释变量， β 是 p 维待估参数向量。我们假设存在 q 维的工具变量 Z 满足排他性 restriction: $E(\varepsilon Z) = 0$ 。

当 $q > p$ （工具变量维度大于内生变量维度）时，我们面临过度识别问题。此时，样本矩条件

$$(77) \quad n^{-1} \sum_{i=1}^n Z_i Y_i = n^{-1} \sum_{i=1}^n Z_i D_i^\top \beta$$

包含了 q 个方程，但只有 p 个未知参数。当 $q > p$ 时，这些方程通常没有精确解——我们只能寻找一个在某种意义上“最接近”所有矩条件的估计量。

3. 两阶段最小二乘估计量

TSLS 提供了一个优雅的解决方案。顾名思义，这个方法包含两个阶段：

[两阶段最小二乘估计量] 定义以 Z 为工具变量、 D 的系数 β 的 TSLS 估计量如下：

第一阶段 对 D 关于 Z 做 OLS 回归，得到拟合值 $\hat{D}_i$ ($i = 1, \dots, n$)。如果 D_i 是向量，则按分量做 OLS 回归。将拟合值向量组成矩阵 $\hat{D}$ ，其第 i 行为 $\hat{D}_i^\top$ ；

第二阶段 对 Y 关于 $\hat{D}$ 做 OLS 回归，得到系数 $\hat{\beta}_{\text{TSLS}}$ 。

这个定义的表述方式非常直观，但为了理解其深层原理，我们需要进行一些代数推导。

3.1. TSLS 的代数推导. 为了看清 TSLS 估计量的本质，我们将其显式地写出来。¹

第一阶段 OLS 回归可以写成：

$$(78) \quad \hat{D}_i = \hat{\Gamma}^\top Z_i,$$

其中 $\hat{\Gamma} = (\sum_{i=1}^n Z_i Z_i^\top)^{-1} \sum_{i=1}^n Z_i D_i^\top$ 。

第二阶段的 OLS 估计量为：

$$(79) \quad \hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

将 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入，经过整理可得：

$$(80) \quad \hat{\beta}_{\text{TSLS}} = \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right).$$

这个表达式揭示了 TSLS 估计量的本质。由于 $E(Z\varepsilon) = 0$ ，根据大数定律，式 ?? 中最后一项的概率极限为 0，因此 $\hat{\beta}_{\text{TSLS}}$ 是 β 的相合估计量。

一个值得注意的代数事实是，当工具变量与内生变量维度相同时（即 $q = p$ 的恰好识别情形），TSLS 估计量与上一章定义的 IV 估计量 $\hat{\beta}_{\text{IV}}$ 在数值上完全相同。

4. 标准误的估计

在获得点估计之后，我们需要考虑抽样变异性的度量。基于式 ??，我们可以推导出 TSLS 估计量的渐近方差，并据此构造标准误。

具体而言，首先计算残差 $\hat{\varepsilon}_i = Y_i - \hat{\beta}_{\text{TSLS}}^\top \hat{D}_i$ ，然后采用 Eicker-Huber-White 稳健方差估计量：

$$(81) \quad \hat{V}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \left(\sum_{i=1}^n \hat{\varepsilon}_i^2 \hat{D}_i \hat{D}_i^\top \right) \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1}.$$

这里需要特别强调一点：残差 $\hat{\varepsilon}_i$ 来自对原方程 Y_i on D_i 的回归，而不是来自第二阶段 OLS 回归 Y_i on $\hat{D}_i$ 的残差。这一细节非常重要，因为它意味着 $\hat{V}_{\text{TSLS}}$ 与直接对第二阶段回归应用稳健标准误所得的结果不同。

5. 特殊情形：单一工具变量与单一内生处理

本节我们考虑一个在应用中最常见的情形：一个工具变量 Z 作用于一个内生处理变量 D 。考虑如下结构方程组：

$$(82) \quad \begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}, \end{cases}$$

其中 D_i 是标量内生处理变量， Z_i 是标量工具变量（满足 $E(\varepsilon_i Z_i) = 0$ ）， X_i 是外生协变量向量（满足 $E(\varepsilon_i X_i) = 0$ ）。

¹推导过程详见附录 ??

5.1. TSLS 的简化形式. 在此特殊情形下, ?? 中的 TSLS 估计量简化为:

[单一内生回归子的 TSLS] 基于方程组 ??, TSLS 估计量包含以下两步:

第一阶段 对 D 关于 $(1, Z, X)$ 做 OLS 回归, 得到拟合值 $\hat{D}_i$ ($i = 1, \dots, n$);

第二阶段 对 Y 关于 $(1, \hat{D}, X)$ 做 OLS 回归, 得到系数 $\hat{\beta}_{\text{TSLS}}$, 特别是 $\hat{\beta}_{1, \text{TSLS}}$, 即 $\hat{D}$ 的系数。

这个两步程序在经验研究中极为常用, 因为它在计算上简洁直观, 同时保持了良好的统计性质。

5.2. 间接最小二乘. 结构方程组 ?? 还可以通过另一种思路来估计。注意到约化形式 (reduced form) 为:

$$(83) \quad \begin{cases} Y_i = \Gamma_0 + \Gamma_1 Z_i + \Gamma_2^\top X_i + \varepsilon_{1i}, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}, \end{cases}$$

其中 $\Gamma_0 = \beta_0 + \beta_1 \gamma_0$, $\Gamma_1 = \beta_1 \gamma_1$, $\Gamma_2 = \beta_2 + \beta_1 \gamma_2$, 且 $\varepsilon_{1i} = \varepsilon_i + \beta_1 \varepsilon_{2i}$ 。

关键观察是: 由于约化形式方程中的解释变量 (Z, X) 都是外生的, 我们可以对这两个方程分别做 OLS 回归, 得到一致估计量 $\hat{\Gamma}_1$ 和 $\hat{\gamma}_1$ 。而待估参数 β_1 恰好等于这两个系数的比值:

$$(84) \quad \beta_1 = \frac{\Gamma_1}{\gamma_1}.$$

因此, 我们可以构造间接最小二乘 (Indirect Least Squares, ILS) 估计量:

$$(85) \quad \hat{\beta}_{1, \text{ILS}} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

有趣的是, ILS 估计量与 TSLS 估计量在数值上完全相同。

[TSLS 与 ILS 的等价性] 在单一内生处理变量和单一工具变量的情形下 (方程组 ??), 我们有

$$(86) \quad \hat{\beta}_{1, \text{ILS}} = \hat{\beta}_{1, \text{TSLS}}.$$

这个定理的本质是一个代数恒等式, 它说明尽管 TSLS 和 ILS 看起来是不同的估计方法, 但它们实际上是同一估计量的不同计算路径。²

比值形式的表达式 ?? 揭示了 TSLS 估计量的一个重要弱点: 当工具变量较弱 (即 γ_1 接近于零) 时, 分子和分母都可能面临严重的有限样本偏误问题。

6. 弱工具变量问题

当工具变量与内生处理变量的相关性较弱时, TSLS 估计量的有限样本性质会严重恶化。这是因为在式 ?? 中, 我们需要用分母 $\hat{\gamma}_1$ 去除分子 $\hat{\Gamma}_1$, 而当 γ_1 接近于零时, 估计量的分布会变得极度非正态, 标准的大样本理论不再适用。

一个更加稳健的推断方法是基于约化形式的 Fieller-Anderson-Rubin (FAR) 方法。该方法的核心思想是: 对于任意假设值 b , 考虑原假设 $H_0(b) : \beta_1 = b$ 。在该假设下, 构造调整后的结果变量 $Y_i(b) = Y_i - bD_i$, 并检验 $Y_i(b)$ 与工具变量 Z_i 之间是否存在显著关系。如果 b 是真实值, 那么根据矩条件 $E(Z\varepsilon) = 0$, 这一关系应当不显著。

具体地, FAR 置信区间的构造如下:

$$(23.12) \quad \{b : |t_Z(b)| \leq z_{1-\alpha/2}\},$$

²定理 ?? 的证明见习题 ??。

其中 $t_Z(b)$ 是 Z 在回归 $Y_i(b)$ on $(1, Z, X)$ 中的 t 统计量 (使用 EHW 稳健标准误), $z_{1-\alpha/2}$ 是标准正态分布的 $1 - \alpha/2$ 分位数。

值得注意的是, 这种 FAR 方法在弱工具变量情形下比传统的基于 TSLS 的 Wald 型置信区间更加稳健, 而且在某些情况下可以完全避免使用 TSLS 估计量。

7. 应用: Card (1993) 教育回报研究

让我们将 TSLS 方法应用于一个经典的经验研究问题: 教育对工资的因果效应。Card (1993) 利用美国年轻男性队列数据, 使用居住地附近是否有四年制大学作为教育的工具变量, 估计了教育的回报率。

在该研究中, 工具变量 Z 是” 成长地附近是否有四年制大学” 的指示变量, 处理变量 D 是受教育年限, 结果变量 Y 是 1976 年的对数工资。协变量 X 包括种族、年龄及其平方、是否与双亲同住等。

应用 TSLS 方法, 我们得到点估计和 95% 置信区间:

	TSLS 估计	下界	上界
教育回报率	0.132	0.026	0.237

这意味着, 多受一年教育会使工资提高约 13.2%。使用 FAR 方法, 我们得到置信区间为 $[0.028, 0.282]$, 与 TSLS 的结果非常接近, 这是因为在该数据中工具变量并非特别弱。

8. 小结

本章我们介绍了两阶段最小二乘 (TSLS) 估计量, 这是工具变量方法在过度识别情形下的核心计算技术。TSLS 的关键思想是将一个复杂的矩估计问题转化为两个连续的 OLS 回归, 从而大大简化了计算。

从理论角度, 我们证明了 TSLS 估计量在大样本下是相合的, 并且当工具变量与内生变量维度相同时, 它与传统的 IV 估计量完全等价。此外, 我们还介绍了 TSLS 与间接最小二乘 (ILS) 的等价性, 以及弱工具变量情形下的 FAR 稳健推断方法。

在应用层面, TSLS 已成为计量经济学中处理内生性问题的标准工具。下一章我们将讨论如何检验工具变量的有效性, 以及如何处理可能的工具变量失效情形。

模糊断点回归

1. 本章导论

在前两章中，我们分别学习了断点回归设计（Regression Discontinuity Design, RDD）和工具变量法（Instrumental Variables, IV）。本章我们要问一个自然的问题：**如果把这两种方法结合起来，会发生什么？**

答案就是本章的主题——**模糊断点回归**（Fuzzy Regression Discontinuity, FRDD）。这是一种“自然实验”，它既保留了断点回归的直观设定，又借助工具变量的识别策略来处理内生性问题。

2. 从清晰断点到模糊断点

2.1. 清晰断点回归的回顾。在第 ?? 章中，我们学习了**清晰断点回归**（Sharp RDD）。其核心设定是：治疗分配 $Z_i = I(X_i \geq x_0)$ 由运行变量（running variable） X_i 在断点 x_0 处**确定性地**决定。

在清晰 RDD 下，潜在结果 $\{Y_i(1), Y_i(0)\}$ 在断点处的期望差可以识别：

$$(24.1) \quad \tau_Y(x_0) = \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y \mid X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y \mid X = x_0 - \varepsilon).$$

2.2. 模糊断点回归的引入。然而，在现实中有许多情况，治疗分配并不是由运行变量**完全决定**的。运行变量改变了治疗的**概率**，但不决定治疗的最终结果。

关键观察：在模糊 RDD 中， $Z_i = I(X_i \geq x_0)$ 仍然是一个有效的工具变量——它满足：

- (a) **相关性：** Z_i 与治疗状态 D_i 相关（因为 $X_i \geq x_0$ 增加了接受治疗的概率）
- (b) **排除限制：** Z_i 通过改变 D_i 来影响 Y_i ，而没有直接影响（需要额外假设）

这就将我们引向了工具变量法的框架。

3. 动机实例

例 E.1（印度农村道路项目）。？研究了印度政府 2000 年启动的“总理乡村道路计划”。该计划根据 2001 年人口普查的阈值来优先考虑规模较大的村庄。

关键点：村庄人口规模与阈值的差并不能**直接决定**是否获得道路——它只改变了获得道路的**概率**。在断点附近，获得道路的概率发生了跳跃，但不是从 0 到 1 的确定性跳跃。

例 E.2（意大利大学助学金项目）。？研究了意大利大学助学金对辍学率的影响。学生如果标准化家庭收入低于 15,000 欧元，则有资格获得助学金。

为获得助学金，学生必须先申请。因此，资格状态和申请状态共同决定了最终治疗状态。运行变量（15,000 减去标准化家庭收入）单独并不能决定治疗状态，但它在断点处改变了治疗概率。

FIGURE 1. 清晰断点回归（左）与模糊断点回归（右）的治疗分配概率比较

4. 数学设定

设 X_i 为运行变量，断点为 x_0 。定义工具变量：

$$Z_i = I(X_i \geq x_0).$$

治疗分配 D_i 可能不等于 Z_i ，但条件概率 $\mathbb{P}(D_i = 1 \mid X_i = x)$ 在 x_0 处有跳跃。
?? 比较了清晰 RDD 和模糊 RDD 中治疗分配概率的差异。

5. 识别定理

设 Y_i 为关注的结果变量。视 Z_i 为已分配的治疗，我们可以定义潜在结果 $\{D_i(1), D_i(0), Y_i(1), Y_i(0)\}$ 。

清晰 RDD 可以识别：

$$\tau_D(x_0) = \mathbb{E}\{D(1) - D(0) \mid X = x_0\}$$

和

$$\tau_Y(x_0) = \mathbb{E}\{Y(1) - Y(0) \mid X = x_0\}.$$

使用 Z 作为 D 的工具变量，并施加工具变量假设（在 $X = x_0$ 邻域内），我们可以通过应用定理来识别局部依从者平均因果效应（Local Complier Average Causal Effect, LATE）。

定理 E.1 (模糊 RDD 识别). 设治疗由 $Z = I(X \geq x_0)$ 决定，其中 x_0 是预定的阈值。

假设单调性：

$$D_i(1) \geq D_i(0),$$

和排除限制：

$$D_i(1) = D_i(0) \implies Y_i(1) = Y_i(0),$$

在 x_0 的无穷小邻域内成立。

局部依从者平均因果效应定义为：

$$\tau_{\text{LATE}}(x_0) = \mathbb{E}\{Y(1) - Y(0) \mid D(1) > D(0), X = x_0\},$$

可以由下式识别：

$$\tau_{\text{LATE}}(x_0) = \frac{\mathbb{E}\{Y(1) - Y(0) \mid X = x_0\}}{\mathbb{E}\{D(1) - D(0) \mid X = x_0\}}.$$

进一步假设 $E\{D(1) \mid X = x\}$ 和 $E\{Y(1) \mid X = x\}$ 在 $x = x_0$ 处右连续， $E\{D(0) \mid X = x\}$ 和 $E\{Y(0) \mid X = x\}$ 在 $x = x_0$ 处左连续。如果 $E(D \mid X = x)$ 在 $x = x_0$ 处有非零跳跃，则局部依从者平均因果效应可以由下式识别：

$$\tau_{\text{LATE}}(x_0) = \frac{\lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y \mid Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y \mid Z = 0, X = x_0 - \varepsilon)}{\lim_{\varepsilon \rightarrow 0+} \mathbb{E}(D \mid Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(D \mid Z = 0, X = x_0 - \varepsilon)}.$$

定理 ?? 的直觉： 这是清晰 RDD 识别和工具变量识别定理的叠加。分子是 (??)，分母是 (??)。两者相除，得到依从者亚组的平均因果效应。

识别策略的核心思想： 在模糊 RDD 中，我们不再假设治疗由运行变量完全决定，而是假设工具变量 Z 通过影响治疗概率来间接影响结果。这与标准 IV 框架的区别在于：IV 假设在断点的邻域内成立，而不是对全体样本成立。

FIGURE 2. 重分析 ? 的数据, TSLS 的点估计和标准误

FIGURE 3. 重分析 ? 的数据, TSLS 的点估计和标准误

6. 估计方法

6.1. 偏误-方差权衡. 在清晰和模糊 RDD 中, 核心问题都是指定断点周围的邻域。实际中:

- 较小的邻域导致较小的偏误, 但较大的方差
- 较大的邻域导致较大的偏误, 但较小的方差

这就是经典的**偏误-方差权衡** (bias-variance trade-off)。一些自动选择带宽的程序存在, 但它们依赖较强的条件。对一系列邻域选择进行敏感性分析似乎更为明智。

6.2. 间接最小二乘估计. 假设我们已指定由带宽 h 确定的 x_0 邻域。对于 $X_i \in [x_0 - h, x_0 + h]$ 的数据, 我们可以通过以下两步估计 $\tau_{\text{LATE}}(x_0)$:

第一步: 估计第一阶段关系

$$\hat{\tau}_D(x_0) = \text{the coefficient of } Z_i \text{ in the OLS fit of } D_i \text{ on } \{1, Z_i, R_i, L_i\},$$

其中 $R_i = \max(X_i - x_0, 0)$, $L_i = \min(X_i - x_0, 0)$ 。

第二步: 估计约简型关系

$$\hat{\tau}_Y(x_0) = \text{the coefficient of } Z_i \text{ in the OLS fit of } Y_i \text{ on } \{1, Z_i, R_i, L_i\}.$$

第三步: 计算比率

$$\hat{\tau}_{\text{LATE}}(x_0) = \hat{\tau}_Y(x_0) / \hat{\tau}_D(x_0).$$

这被称为**间接最小二乘估计器** (Indirect Least Squares Estimator, ILS)。根据定理, ILS 估计器数值上等同于:

$$\text{the coefficient of } D_i \text{ in the TSLS fit of } Y_i \text{ on } \{1, D_i, R_i, L_i\}$$

with D_i instrumented by Z_i 。

总之, 在指定 h 后, $\tau_{\text{LATE}}(x_0)$ 的估计归结为断点邻域内的两阶段最小二乘 (TSLS) 程序。

7. 数据应用

7.1. 印度农村道路数据. 重温 ??。我们可以基于结果 `occupation_index_andrsn` 计算一系列 h 的点估计和标准误。

?? 展示了结果。除非 h 很大, 否则治疗效应不显著。

7.2. 意大利大学助学金数据. 重温 ??。运行变量定义为 15,000 减去标准化家庭收入。分析中将数据限制在 $[-5000, 5000]$ 的子集, 然后除以 5000 使运行变量有界于 $[-1, 1]$ 。

?? 展示了结果, 表明大学助学金对辍学率没有显著影响。

8. 讨论

第 ?? 章和本章都将断点回归建立在给定运行变量时潜在结果条件期望的连续性之上。这个视角在数学上更简单，但它只能精确识别运行变量断点处的局部效应。¹ 开创了这一研究路线。

另一种不那么主流的视角基于**局部随机化** (local randomization)。(??)。如果我们视运行变量为某种底层真实值的噪声测量，而断点有些任意地选择，那么断点附近的单元在系统上并没有差异。这表明在断点的较小邻域内，单元以随机方式接受治疗和控制——就像在随机实验中一样。

与清晰 RDD 的选择邻域问题类似，在局部随机化视角下，决定随机实验应该有多“局部”也是至关重要的。将这种直觉数学量化并不容易，因此对一系列带宽 h 进行敏感性分析似乎也是第二种视角下的合理方法。

? 提供了断点回归的概念性讨论。

9. 本章小结

本章的核心要点：

- (a) **模糊断点回归**：治疗概率在断点处跳跃，但不像清晰 RDD 那样由运行变量完全决定
- (b) **识别策略**：将 $Z = I(X \geq x_0)$ 作为工具变量，在单调性和排除限制下识别 LATE
- (c) **估计方法**：间接最小二乘 (ILS) 或两阶段最小二乘 (TSLS)
- (d) **偏误-方差权衡**：带宽选择是关键——较小的邻域偏误小但方差大
- (e) **与清晰 RDD 的关系**：模糊 RDD 是清晰 RDD 和 IV 方法的结合

下一章我们将学习**局部随机化视角下的断点回归**，这为 RDD 提供了另一种理论依据。

10. 习题

练习 E.1. ?? 模糊 RDD 识别定理的证明 证明 ?? 中的识别公式。

练习 E.2. ?? 清晰 RDD 与模糊 RDD 的比较

- (a) 在清晰 RDD 中，治疗分配 D 和工具变量 Z 有什么关系？
- (b) 在模糊 RDD 中，这种关系如何变化？
- (c) 给出清晰 RDD 和模糊 RDD 各一个现实生活中的例子。

练习 E.3. ?? 带宽敏感性分析 对于 ?? 中的印度道路数据，使用不同的带宽 h 进行敏感性分析。报告点估计和标准误如何随 h 变化。

练习 E.4. ?? ILS 与 TSLS 的等价性 证明在模糊 RDD 中，间接最小二乘估计器（比率形式）和两阶段最小二乘估计器在数值上是等价的。¹

¹推导见附录 ??。

孟德尔随机化

1. 引言：遗传学与因果推断的交汇

在第 ?? 章和第 ?? 章中，我们看到了工具变量 (IV) 方法如何帮助解决观测性研究中的未测量混杂问题。然而，传统 IV 方法面临一个根本困难：找到一个有效的工具变量谈何容易。研究者需要确信这个变量满足三个关键条件——与治疗变量相关、不与未测量混杂相关、以及仅通过治疗变量影响结果。

20 世纪 80 年代，一位名叫 Katan 的研究者 (?) 提出了一个颇具洞察力的观点：也许遗传变异能够充当天然的工具变量。他的论证基于孟德尔的第二定律——独立分配定律 (law of random assortment)，该定律表明一种性状的遗传独立于其他性状的遗传。这意味着，如果我们能找到与某个暴露因素（如胆固醇水平）相关的基因变异，同时这些变异与混杂暴露因素与结果之间关系的未测量混杂因子相互独立，那么这些基因变异就可能成为一个有效的工具变量。

这一思想在流行病学研究中引发了革命性的变革。2003 年，Davey Smith 和 Ebrahim (?) 将这种方法正式命名为**孟德尔随机化 (Mendelian Randomization, MR)**。如今，MR 已成为流行病学中估计暴露因素对结果因果效应的核心方法 (?)。

本章的核心问题：如何利用遗传变异作为工具变量来估计因果效应？这种方法的假设是什么？又有哪些局限性？

2. 背景与动机

2.1. 从胆固醇到癌症：一个经典难题。在深入技术细节之前，让我们先理解 MR 最初被提出时的动机。20 世纪 80 年代的观测性研究暗示，低血清胆固醇水平可能与癌症风险相关。然而，这样的观察性研究面临两个根本性问题：

- (a) **未测量的混杂：**胆固醇水平和癌症之间可能存在共同的未测量混杂因素，例如饮食模式或社会经济地位。
- (b) **反向因果：**更棘手的是，癌症的早期阶段可能反过来导致低血清胆固醇水平，即因果方向可能与假设的相反。

Katan (?) 指出，Apolipoprotein E 基因与血清胆固醇水平相关，但（理论上）不直接影响癌症状态。因此，如果我们能比较携带不同基因型的人群在癌症风险上的差异，就能区分因果效应和混杂/反向因果。这一论证与我们在第 ?? 章讨论的 IV 框架完美契合。

2.2. MR 的因果图。图 ?? 展示了一个典型 MR 研究的因果结构。

在许多 MR 研究中，遗传工具变量是**单核苷酸多态性 (single nucleotide polymorphisms, SNPs)**。由于**多效性 (pleiotropy)** 的存在，遗传工具变量有可能直接影响结果，因此图 ?? 中允许违反排他性限制假设的情况。




FIGURE 1. MR 因果图: G_j 为遗传变异 (工具变量), D 为暴露因素, Y 为结果, U 为未测量的混杂因子, 虚线箭头表示 G_j 可能违反排他性限制的直接效应。

3. 线性 IV 模型回顾

在介绍 MR 的统计方法之前, 我们需要回顾第 ?? 章中的线性 IV 模型。这里我们显式地引入未测量混杂因子 U , 这在 MR 背景下尤为重要。

3.1. 标准线性 IV 模型 (满足排他性限制).

定义 F.1 (标准线性 IV 模型). 结构形式为:

$$(25.1) \quad Y = \beta_0 + \beta D + \beta_u U + \varepsilon_Y,$$

$$(25.2) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

约简形式为:

$$(25.3) \quad Y = (\beta_0 + \beta\gamma_0) + \beta\gamma_1 G_1 + \cdots + \beta\gamma_p G_p + (\beta_u + \beta\gamma_u)U + \varepsilon_Y,$$

$$(25.4) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

在排他性限制下, G_j 对 Y 没有直接效应, 因此 $\Gamma_j = \beta\gamma_j$ ($j = 1, \dots, p$)。

3.2. 允许违反排他性限制的模型. 在 MR 研究中, 由于多效性的存在, 排他性限制可能不成立。因此我们需要允许遗传工具变量直接作用于结果。

定义 F.2 (可能无效的工具变量模型). 线性模型为:

$$(25.5) \quad Y = \beta_0 + \beta D + \alpha_1 G_1 + \cdots + \alpha_p G_p + \beta_u U + \varepsilon_Y,$$

$$(25.6) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

约简形式为:

$$(25.7) \quad Y = (\beta_0 + \beta\gamma_0) + (\alpha_1 + \beta\gamma_1)G_1 + \cdots + (\alpha_p + \beta\gamma_p)G_p + (\beta_u + \beta\gamma_u)U + \varepsilon_Y,$$

$$(25.8) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

在这种情况下, $\Gamma_j = \alpha_j + \beta\gamma_j$ ($j = 1, \dots, p$)。如果 $\alpha_j \neq 0$, 则 G_j 是无效的工具变量。

注 F.1. 定义 ?? 和 ?? 与第 ?? 章的线性 IV 模型略有不同——我们显式包含了未测量混杂因子 U 。但这一差异本质上不影响讨论, 因为 U 在约简形式中通过 $\beta_u + \beta\gamma_u$ 被合并到系数中。

4. 基于汇总统计的 MR 分析

4.1. MR 研究的数据结构. 传统的 IV 估计需要个体水平的数据。然而，大多数 MR 研究并没有个体数据，而是从多个全基因组关联研究 (genome-wide association studies, GWAS) 中获取**汇总统计 (summary statistics)**。一个典型的 MR 研究具有以下数据结构。

假设 F.1 (基于汇总统计的 MR 研究). (a) 我们有治疗变量对遗传工具变量的回归系数 $\hat{\gamma}_1, \dots, \hat{\gamma}_p$ 及其标准误 $se_{D1}, \dots, se_{Dp}$ 。假设

$$(25.9) \quad \hat{\gamma}_1 \xrightarrow{p} \gamma_1, \dots, \hat{\gamma}_p \xrightarrow{p} \gamma_p$$

并忽略标准误的不确定性。

(b) 我们有结果变量对遗传工具变量的回归系数 $\hat{\Gamma}_1, \dots, \hat{\Gamma}_p$ 及其标准误 $se_{Y1}, \dots, se_{Yp}$ 。假设

$$(25.10) \quad \hat{\Gamma}_1 \xrightarrow{p} \Gamma_1, \dots, \hat{\Gamma}_p \xrightarrow{p} \Gamma_p$$

并忽略标准误的不确定性。

(c) 假设 $\hat{\gamma}_1, \dots, \hat{\gamma}_p, \hat{\Gamma}_1, \dots, \hat{\Gamma}_p$ 联合服从正态分布且相互独立。

回归系数的渐近正态性可由中心极限定理保证。标准误在大样本中是真实标准误的准确估计。因此，唯一微妙的假设是回归系数之间的联合独立性。 $\hat{\gamma}_j$ 与 $\hat{\Gamma}_j$ 之间的独立性是合理的，因为它们通常基于不同的样本计算。

4.2. 固定效应估计量. 在定义 ?? (满足排他性限制) 的假设下, $\alpha_j = 0$, 这意味着 $\beta = \Gamma_j/\gamma_j$ 对所有 j 成立。一个简单的方法基于所谓的**元分析 (meta-analysis)**——即结合多个估计量 $\hat{\beta}_j = \hat{\Gamma}_j/\hat{\gamma}_j$ 来估计共同参数 β , 这种方法也被称为**固定效应 (fixed effect)** 估计。

使用 delta 方法 (见假设 ??), 比值估计量 $\hat{\beta}_j$ 的近似标准误为:

$$(25.11) \quad se_j^2 = (se_{Yj}^2 + \hat{\beta}_j^2 se_{Dj}^2) / \hat{\gamma}_j^2.$$

因此, 估计 β 的最佳线性组合是基于方差倒数加权的 Fisher 估计 (见练习题):

$$(25.12) \quad \hat{\beta}_{\text{fisher0}} = \frac{\sum_{j=1}^p \hat{\beta}_j / se_j^2}{\sum_{j=1}^p 1 / se_j^2},$$

其方差为 $(\sum_{j=1}^p 1 / se_j^2)^{-1}$ 。

忽略 $\hat{\gamma}_j$ 由 se_{Dj} 量化的不确定性, 估计量简化为:

$$(25.13) \quad \hat{\beta}_{\text{fisher1}} = \frac{\sum_{j=1}^p \hat{\beta}_j \hat{\gamma}_j^2 / se_{Yj}^2}{\sum_{j=1}^p \hat{\gamma}_j^2 / se_{Yj}^2} = \frac{\sum_{j=1}^p \hat{\Gamma}_j \hat{\gamma}_j / se_{Yj}^2}{\sum_{j=1}^p \hat{\gamma}_j^2 / se_{Yj}^2},$$

其方差为 $(\sum_{j=1}^p \hat{\gamma}_j^2 / se_{Yj}^2)^{-1}$ 。虽然次优, 但 $\hat{\beta}_{\text{fisher1}}$ 在实践中应用更广泛 (?)。

在定义 ?? (允许无效工具变量) 的假设下, 我们可以证明:

$$(25.14) \quad \hat{\beta}_{\text{fisher1}} \xrightarrow{p} \frac{\sum_{j=1}^p \Gamma_j \gamma_j / se_{Yj}^2}{\sum_{j=1}^p \gamma_j^2 / se_{Yj}^2} = \beta + \frac{\sum_{j=1}^p \alpha_j \gamma_j / se_{Yj}^2}{\sum_{j=1}^p \gamma_j^2 / se_{Yj}^2}.$$

如果对所有 j 都有 $\alpha_j = 0$, 则 $\hat{\beta}_{\text{fisher1}}$ 是一致的。即使这不成立, 只要 α_j 与 γ_j 的内积按 $1/se_{Yj}^2$ 加权为零, $\hat{\beta}_{\text{fisher1}}$ 仍可能是一致的。

注 F.2. 当有许多遗传工具变量，且违反排他性限制（由 α_j 捕获）是来自均值为零的分布的独立随机抽样时，上述条件近似成立。

4.3. Egger 回归. 现在从定义 ?? (满足排他性限制) 出发。在真实参数下，我们有：

$$(25.15) \quad \Gamma_j = \beta \gamma_j \quad (j = 1, \dots, p).$$

用估计量替代时，上述等式仅近似成立：

$$(25.16) \quad \hat{\Gamma}_j \approx \beta \hat{\gamma}_j \quad (j = 1, \dots, p).$$

这看似一个经典的最小二乘问题——将 $\{\hat{\Gamma}_j\}_{j=1}^p$ 对 $\{\hat{\gamma}_j\}_{j=1}^p$ 进行回归。我们可以拟合 $\hat{\Gamma}_j$ 对 $\hat{\gamma}_j$ 的加权最小二乘 (WLS)，有或无截距项，可能按 w_j 加权，以估计 β 。以下结果得益于第 ?? 章回顾的 WLS 代数性质。

无截距时， $\hat{\gamma}_j$ 的系数为：

$$(25.17) \quad \hat{\beta}_{\text{egger1}} = \frac{\sum_{j=1}^p \hat{\gamma}_j \hat{\Gamma}_j w_j}{\sum_{j=1}^p \hat{\gamma}_j^2 w_j},$$

当 $w_j = 1/\text{se}_{Y_j}^2$ 时，这退化为 $\hat{\beta}_{\text{fisher1}}$ 。这种 WLS 被称为 **Egger 回归**，它比第 ?? 节的固定效应估计量更一般。

有截距时， $\hat{\gamma}_j$ 的系数为：

$$(25.18) \quad \hat{\beta}_{\text{egger0}} = \frac{\sum_{j=1}^p (\hat{\gamma}_j - \hat{\gamma}_w)(\hat{\Gamma}_j - \hat{\Gamma}_w)w_j}{\sum_{j=1}^p (\hat{\gamma}_j - \hat{\gamma}_w)^2 w_j},$$

其中 $\hat{\gamma}_w = \sum_{j=1}^p \hat{\gamma}_j w_j / \sum_{j=1}^p w_j$ 和 $\hat{\Gamma}_w = \sum_{j=1}^p \hat{\Gamma}_j w_j / \sum_{j=1}^p w_j$ 分别是 $\hat{\gamma}_j$ 和 $\hat{\Gamma}_j$ 的加权平均值。

即使不假设所有 γ_j 为零（定义 ??），我们也有：

$$(25.19) \quad \hat{\beta}_{\text{egger0}} \xrightarrow{p} \frac{\sum_{j=1}^p (\gamma_j - \gamma_w)(\Gamma_j - \Gamma_w)w_j}{\sum_{j=1}^p (\gamma_j - \gamma_w)^2 w_j} = \beta + \frac{\sum_{j=1}^p (\gamma_j - \gamma_w)(\alpha_j - \alpha_w)w_j}{\sum_{j=1}^p (\gamma_j - \gamma_w)^2 w_j},$$

其中 γ_w, Γ_w 和 α_w 是相应真实参数的加权平均值。

因此， $\hat{\beta}_{\text{egger0}}$ 一致地估计 β ，只要 α_j 对 γ_j 的 WLS 系数为零。这比 $\alpha_j = 0$ (对所有 j) 的假设更弱。当 γ_j 和 α_j 是独立随机变量的实现值时，这个较弱的假设成立，这被称为**工具强度独立于直接效应 (Instrument Strength Independent of Direct Effect, InSIDE) 假设**(?)。

更有趣的是，Egger 回归的截距：

$$(25.20) \quad \hat{\alpha}_{\text{egger0}} = \hat{\Gamma}_w - \hat{\beta}_{\text{egger0}} \hat{\gamma}_w,$$

在 InSIDE 假设下收敛到：

$$(25.21) \quad \Gamma_w - \beta \gamma_w = \alpha_w,$$

即直接效应的加权平均值。因此，截距估计了直接效应的加权平均。

5. 实例分析

本节使用 `mr.raps` 包中的 `bmi.sbp` 数据 (?) 来说明 Fisher 加权估计和 Egger 回归的实际应用。

5.1. Fisher 加权估计. 首先, 以下函数实现了 Fisher 加权:

```
fisher.weight = function(est, se)
{
  n = sum(est/se^2)
  d = sum(1/se^2)
  res = c(n/d, sqrt(1/d))
  names(res) = c("est", "se")
  res
}
```

使用该函数对 BMI-SBP 数据进行分析, 基于 $\hat{\beta}_{\text{fisher0}}$ 和 $\hat{\beta}_{\text{fisher1}}$ 的结果非常接近:

```
> fisher.weight(bmisbp$iv, bmisbp$se.iv)
      est      se
0.31727680 0.05388827
> fisher.weight(bmisbp$iv, bmisbp$se.iv1)
      est      se
0.31576007 0.05893783
```

5.2. Egger 回归. 带截距或不带截距的 Egger 回归也给出了非常相似的结果, 但标准误与 Fisher 加权估计的结果差异很大:

```
> mr.egger = lm(beta.output ~ 0 + beta.exposure,
+ data = bmisbp, weights = 1/se.output^2)
> summary(mr.egger)$coef
              Estimate Std. Error t value Pr(>|t|)
beta.exposure 0.3172768  0.1105994  2.868704 0.004681659

> mr.egger.w = lm(beta.output ~ beta.exposure,
+ data = bmisbp, weights = 1/se.output^2)
> summary(mr.egger.w)$coef
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.000113328 0.002079418 0.05450217 0.956603931
beta.exposure 0.3172989306 0.110948506 2.85987564 0.004811017
```

图 ?? 展示了原始数据以及带截距的 Egger 回归拟合线。

$\hat{\gamma}_j \hat{\Gamma}_j$ 数据点回归线

FIGURE 2. 按方差倒数加权的散点图及 Egger 回归线。

6. MR 分析的批评与局限

MR 是 IV 方法思想的应用。它依赖于强有力的假设。我从概念、生物学和技术三个层面提供三组批评。

6.1. 概念层面的批评. 从潜在结果的角度看, 大多数 MR 研究中的治疗变量定义并不明确。例如, 治疗通常被定义为胆固醇水平或 BMI。这些是复合变量, 可能对应复杂且非唯一的假设实验定义。SUTVA (稳定单元治疗值假设) 在这些治疗变量上往往不成立。回想第 ?? 章的讨论。

6.2. 生物学层面的批评. IV 分析的基本假设可能不成立。孟德尔的第二定律确保了不同性状的遗传是独立的。然而，它并不能确保候选工具变量与治疗 and 结果之间的未测量混杂因子相互独立。这些工具变量可能直接影响混杂因子。同样，某些未测量基因可能同时影响工具变量和混杂因子。孟德尔的第二定律也不能确保排他性限制假设——工具变量有可能通过治疗感兴趣变量之外的途径影响结果。

6.3. 技术层面的批评. MR 的统计假设相当强。线性 IV 模型是一个强假设。 $\hat{\gamma}_j$ 与 $\hat{\Gamma}_j$ 的独立性也相当强。数据收集过程中的其他问题可能进一步复杂化对 IV 假设的解释。例如，治疗 and 结果通常存在测量误差，而且全基因组关联研究通常基于条件于结果的病例对照设计（见第 ?? 章）。

2014 是讨论 MR 方法论挑战的优秀综述论文。

7. 习题

练习 F.1. ?? Fisher 加权估计的推导 证明第 ?? 节中 $\hat{\beta}_{\text{fisher0}}$ 的方差为 $\left(\sum_{j=1}^p 1/\text{se}_j^2\right)^{-1}$ 。
提示：利用 $\hat{\beta}_j$ 的独立性。

练习 F.2. ?? InSIDE 假设的含义 解释 InSIDE（工具强度独立于直接效应）假设在什么意义上弱于 $\alpha_j = 0$ （对所有 j ）的排他性限制假设。给出一个满足 InSIDE 但不满足 $\alpha_j = 0$ 的数值例子。

练习 F.3. ?? Egger 截距的解释 在第 ?? 节中，我们看到 Egger 回归的截距 $\hat{\alpha}_{\text{egger0}}$ 收敛到直接效应的加权平均 α_w 。讨论为什么这个性质在实践中有用——即为什么我们可能关心估计 α_w 而不仅仅是 β 。

练习 F.4. ?? 数据分析 分析 `mr.raps` 包中的 `bmi.bmi` 数据。参见 ?, 第 7.2 节 了解更多细节。

推荐阅读

- ? 综述了 MR 的潜力和局限性，是该领域的经典文献。
- ? 提出了 Egger 回归方法来检测和调整无效工具变量。
- ? 开发了基于鲁棒调整轮廓得分（robust adjusted profile score, RAPS）的两样本汇总数据 MR 推断方法。

中介分析：自然直接效应与自然间接效应

1. 本章导论：一个古老的追问

当我们说“吸烟导致肺癌”时，这个说法究竟意味着什么？

一方面，烟草中的有害物质可能直接作用于细胞，引发癌变；另一方面，吸烟可能通过影响其他生理指标——比如血压、免疫力或慢性炎症——进而间接地增加患癌风险。这两种机制，本质上完全不同：一种是直接杀伤，另一种是通过一连串中间步骤传导的**间接效应**。

理解因果效应的这种**传导机制** (transmission mechanism)，是科学研究的核心关切之一。生物医学研究者想知道某种药物是通过什么生化通路发挥作用的；社会学家想知道贫困是通过什么社会机制影响健康结果的；政策制定者想知道一项教育改革是直接改善了学生能力，还是通过改变学校资源配置间接起效。**中介分析** (mediation analysis) 正是回答这类问题的统计框架。

本章的组织如下。我们首先通过具体实例说明中介分析的应用场景；然后引入**嵌套潜在结果** (nested potential outcomes) 的数学框架；接着建立识别中介效应的**中介公式** (mediation formula)；最后在线性模型下推导出经典的 **Baron-Kenny 公式**，并讨论其敏感性分析。

2. 从总效应到直接效应与间接效应

在中介分析的框架中，我们有四个核心变量：处理 Z (treatment)、结果 Y (outcome)、中介 M (mediator) 以及背景协变量 X (covariates)。它们之间的因果关系可以直观地用有向无环图 (DAG) 表示 (??)。

FIGURE 1. 中介分析的因果有向无环图： Z 通过 M 影响 Y 的路径，以及 Z 直接影响 Y 的路径。

核心问题：总的因果效应 τ 中，有多少是通过中介变量 M 传导的 (**间接效应**)，有多少是不经过 M 的 (**直接效应**)？

以下三个真实研究场景可以帮助我们理解中介分析的应用。

例 G.1 (遗传变异与肺癌：通过吸烟的中介). (2012) 研究了染色体 15q25.1 上的遗传变异如何影响肺癌风险。¹ 该研究的核心问题是：遗传变异是通过影响吸烟行为 (吸烟量) 进而增加肺癌风险的，还是通过其他独立通路 (如直接影响肺部细胞) 直接致癌的？这就是一个典型的中介分析问题：遗传变异是处理 Z ，吸烟是中介 M ，肺癌是结果 Y 。

例 G.2 (邻里贫困与青少年物质使用：学校与同伴环境的中介). 等人 (2018) 研究了邻里贫困对青少年物质使用的影响，并探讨了这一影响是通过学校和同伴环境传导的。² 他们使用了美国国家共病调查 (National Comorbidity Survey) 的数据，将邻里贫困指数作为处理，青少年物质使用 (如饮酒、吸毒) 作为结果，而学校和同伴环境因素作为中介。

¹详见 ?。

²详见 ?。

例 G.3 (就业培训对心理健康：工作搜寻效能的中介). *JOBS II* 是一个关于就业培训对失业工人影响的现场实验。³ 该培训项目的目的不仅是提高再就业率，还希望改善求职者的心理健康。研究者感兴趣的是：培训对心理健康的效应中，有多少是通过提高工作搜寻效能这一中介传导的，又有多少是通过其他途径（如社会支持网络）直接产生的。⁴

3. 嵌套潜在结果

3.1. 潜在结果的两层结构. 为了定义直接效应与间接效应，我们需要引入**嵌套潜在结果** (nested potential outcomes) 这一概念。⁵ 和 ⁶ 是这一理论的奠基人。

首先，考虑对处理 z 进行干预，定义对应的潜在中介和潜在结果：

$$\{M(z), Y(z) : z = 0, 1\}.$$

然后，考虑同时对 z 和 m 进行干预，定义：

$$\{Y(z, m) : z = 0, 1, m \in \mathcal{M}\},$$

其中 $\mathcal{M}$ 是中介所有可能的取值范围。

关键的一步是考虑**嵌套干预** (nested intervention)：将 z 设定为某个值，但将 m 设定为在另一个处理水平下的潜在中介值。记 $M_{z'} \equiv M(z')$ ，⁷ 和 ⁸ 定义了嵌套潜在结果：

$$\{Y(z, M_{z'}) : z = 0, 1, z' = 0, 1\}.$$

其中 $Y(z, M_{z'})$ 表示：如果治疗被设定为 z ，而中介被设定为在治疗 z' 下的潜在值 $M_{z'}$ ，则结果会是什么。注意 z 和 z' 可以不同——这正是其“嵌套”之处。

在二值处理的设定下，我们有四个嵌套潜在结果：

$$\{Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)\}.$$

其中 $Y(1, M_1)$ 表示：如果治疗设为 $z = 1$ 且中介设为在 $z = 1$ 下的自然值，则结果如何。类似地， $Y(0, M_0)$ 表示治疗设为 $z = 0$ 且中介设为在 $z = 0$ 下的自然值的情形。

Composition 假设确保了嵌套潜在结果与标准潜在结果之间的一致性。

[Composition 假设] $Y(z, M_z) = Y(z)$ ，对 $z = 0, 1$ 成立。

Composition 假设是不可证明的，它本质上是一个假设。但在实践中，我们完全可以将 $Y(1)$ 定义为 $Y(1, M_1)$ ，将 $Y(0)$ 定义为 $Y(0, M_0)$ ，这样该假设就自动成立了。

现在，我们可以正式定义三种效应。

定义 G.1 (总效应、自然直接效应与自然间接效应). 总效应 (*total effect*) 定义为

$$\tau = \mathbb{E}\{Y(1) - Y(0)\}.$$

自然直接效应 (*natural direct effect, NDE*) 定义为

$$= \mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}.$$

自然间接效应 (*natural indirect effect, NIE*) 定义为

$$= \mathbb{E}\{Y(1, M_1) - Y(1, M_0)\}.$$

这三个效应的含义如下：

- **总效应** τ ：标准的平均因果效应，即治疗从 0 变到 1 对结果的平均影响。
- **NDE** $\mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}$ ：如果将治疗从 0 变到 1，但把中介固定在无治疗时的自然水平 M_0 ，结果的平均变化。这个效应衡量的是**不经过 M 的直接通路**的贡献。

³我们在 ?? 章中曾使用过这个数据集。

⁴我们将在 ?? 节中回到这个例子，展示 Baron-Kenny 方法的具体应用。

- **NIE** $E\{Y(1, M_1) - Y(1, M_0)\}$: 如果保持治疗 $z = 1$ 不变, 但把中介从无治疗时的自然水平 M_0 变到治疗时的自然水平 M_1 , 结果的平均变化。这个效应衡量的是**通过中介 M 传导**的间接贡献。

在 Composition 假设下, 总效应可以分解为自然直接效应与自然间接效应之和。

命题 G.2 (效应的分解). 在 ?? 和 ?? 下, 有

$$\tau = +.$$

为什么 NIE 可以衡量间接效应? 直观上, $Y(1, M_1) - Y(1, M_0)$ 表示: 将治疗固定在 $z = 1$, 但让中介从“如果没有治疗它会是什么”变为“如果有治疗它会是什么”, 结果会如何变化。这恰恰描述了“治疗通过改变中介进而影响结果”这条通路上的效应。

然而, $Y(1, M_0)$ 这个量本身有一个深刻的概念困难: 它是一个**跨世界 counterfactual** (cross-world counterfactual)。 $z = 1$ 和 $m = M_0$ 这两个干预不可能在同一个实验中同时发生——同一个单元不可能既接受治疗 $z = 1$, 又同时处于无治疗条件下的中介水平。要理解 $Y(1, M_0)$, 我们必须借助平行世界的想象 (??)。

[width = 0.7]figures/crossworld.pdf

FIGURE 2. 跨世界 counterfactual $Y(1, M_0)$ 和 $Y(0, M_1)$ 的示意图。同一单元在两个平行世界中分别接受不同的治疗, 从而获得不同的中介值。

这种跨世界的性质引发了一个哲学上的争议。⁵ 将 $Y(1, M_0)$ 和 $Y(0, M_1)$ 称为**先验 counterfactual** (a priori counterfactuals), 因为我们无法在任何物理实验中观察到它们。按照 ? 的可证伪性标准, 如果一个陈述无法被任何物理实验或观测所证伪, 那它就不是科学的, 而是形而上学的。因此, 严格的 Popperian 统计学家可能会认为中介分析是形而上学。⁵

不过, ? 对整个潜在结果框架都提出了类似的批评。但他的批评是过度的: 即使我们无法同时观察到 $Y(1)$ 和 $Y(0)$, 我们仍然可以通过边缘分布的信息对它们做出可证伪的陈述。 $Y(1, M_0)$ 的困难在于它是真正无法在任何实验中触及的——这与 $\{Y(1), Y(0)\}$ 的性质根本不同。

4. 中介公式

4.1. 四个关键假设. 中介公式的识别依赖于四个假设。前三个假设本质上是在说: 治疗 and 中介在给定协变量 X 的条件下都是被随机化的。

[无治疗—结果混淆] 给定 X , 治疗与潜在结果独立:

$$Z \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

[无中介—结果混淆] 给定 (X, Z) , 中介与潜在结果独立:

$$M \perp\!\!\!\perp Y(z, m) \mid (X, Z), \quad \forall z, m.$$

[无治疗—中介混淆] 给定 X , 治疗与潜在中介独立:

$$Z \perp\!\!\!\perp M(z) \mid X, \quad \forall z.$$

这三个假设共同构成了**序列可忽略性** (sequential ignorability): 在给定 X 的条件下, 治疗分配是可忽略的; 进一步在给定 (X, Z) 的条件下, 中介分配也是可忽略的。序列可忽略性等价于在给定 X 的条件下 (Z, M) 是联合随机化的:

$$(87) \quad (Z, M) \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

⁵这一争议的详细讨论见 ? 和 ?。

?? 与 ???? 的等价性留作练习。⁶

最后一个假设是跨世界独立性。

[跨世界独立性] 给定 X ，潜在结果与潜在中介独立：

$$Y(z, m) \perp\!\!\!\perp M(z') \mid X, \quad \forall z, z', m.$$

前三个假设至少在随机化实验中是可以保证的，但 ?? 更为强——没有任何物理实验可以确保它，因为当 $z \neq z'$ 时，我们永远无法同时观察到 $Y(z, m)$ 和 $M(z')$ 。这正是 $Y(1, M_0)$ 等 cross-world counterfactual 的根本困难所在。

例 G.4 (验证假设的数据生成过程). 给定 X ，我们按如下方式生成数据：

$$\begin{aligned} Z &= 1\{g_Z(X, \varepsilon_Z) \geq 0\}, \\ M(z) &= 1\{g_M(X, z, \varepsilon_M) \geq 0\}, \quad z = 0, 1, \\ Y(z, m) &= g_Y(X, z, m, \varepsilon_Y), \quad z, m = 0, 1, \end{aligned}$$

其中 $\varepsilon_Z, \varepsilon_M, \varepsilon_Y$ 相互独立。⁷ 可以验证，在上述数据生成过程下，???????? 均成立。如果允许 ε_M 和 ε_Y 依赖于处理水平（即改为 $\varepsilon_M(z)$ 和 $\varepsilon_Y(z, m)$ ），则这些假设可能被违反。

4.2. 识别公式. ? 证明了以下关键结果。

定理 G.3 (中介公式). 在 ????????? 下，有

$$\mathbb{E}\{Y(z, M_{z'}) \mid X = x\} = \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x) \Pr(M = m \mid Z = z', X = x).$$

定理的含义： 我们无法直接观察跨世界 counterfactual $Y(z, M_{z'})$ ，但 ????????? 这四个假设足够将这个不可观测的量表达为可观测条件分布的函数。具体来说， $Y(z, M_{z'})$ 的期望等于：结果的条件期望（给定 $Z = z, M = m, X = x$ ）对中介的分布（给定 $Z = z', X = x$ ）的加权和。

为什么四个假设缺一不可？ 定理的证明（见附录 ??）清楚地展示了这四个假设各自的角色：?? 保证了 $\Pr(M = m \mid Z = z', X = x) = \Pr(M_{z'} = m \mid X = x)$ ，?? 允许我们交换 $Y(z, m)$ 与 $M_{z'}$ 的条件，???? 则保证了结果的识别。

对 X 求期望，得到无条件版本：

$$\mathbb{E}\{Y(z, M_{z'})\} = \sum_x \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x) \Pr(M = m \mid Z = z', X = x) \Pr(X = x).$$

对于连续型 M 和 X ，求和替换为积分。

由 ?? 和 ??，我们可以得到 NDE 和 NIE 的识别公式。

推论 G.4 (NDE 和 NIE 的识别). 在 ????????? 下，条件 NDE 和 NIE 由下式识别：

(88)

$$(x) = \sum_m [\mathbb{E}(Y \mid Z = 1, M = m, X = x) - \mathbb{E}(Y \mid Z = 0, M = m, X = x)] \Pr(M = m \mid Z = 0, X = x),$$

(89)

$$(x) = \sum_m \mathbb{E}(Y \mid Z = 1, M = m, X = x) [\Pr(M = m \mid Z = 1, X = x) - \Pr(M = m \mid Z = 0, X = x)].$$

⁶详见 ?? 题。

⁷详见 ?。

理解 ?? 的直觉: (x) 衡量的是将处理从 0 变到 1 (但保持中介在无处理时的自然分布) 的效应。在每个中介值 m 下, 处理从 0 变到 1 的条件效应是 $\mathbb{E}(Y | Z = 1, M = m, X = x) - \mathbb{E}(Y | Z = 0, M = m, X = x)$; 由于中介被固定在 $Z = 0$ 条件下的分布, 这些条件效应需要按 $\Pr(M = m | Z = 0, X = x)$ 加权求和。

对于二值中介 $M \in \{0, 1\}$, ?? 中的 NIE 公式可以化简为一种优美的乘积形式。

推论 G.5 (二值中介的 NIE 乘积公式). 在 ???????? 下, 对二值中介 M , 有

$$(x) = \tau_{Z \rightarrow M}(x) \cdot \tau_{M \rightarrow Y}(1, x),$$

其中

$$\tau_{Z \rightarrow M}(x) = \Pr(M = 1 | Z = 1, X = x) - \Pr(M = 1 | Z = 0, X = x)$$

是 Z 对 M 的条件平均因果效应,

$$\tau_{M \rightarrow Y}(z, x) = \mathbb{E}(Y | Z = z, M = 1, X = x) - \mathbb{E}(Y | Z = z, M = 0, X = x)$$

是 M 对 Y 的条件平均因果效应。

为什么叫乘积公式? 直观上, 间接效应是这样传导的: 首先, 处理 Z 变化导致中介 M 变化 (效应 $\tau_{Z \rightarrow M}$); 然后, 中介 M 变化导致结果 Y 变化 (效应 $\tau_{M \rightarrow Y}$)。这两段效应的乘积, 就是总间接效应。这与我们的直觉完全一致。

?? 的证明留作练习。⁸

5. 线性模型下的 Baron-Kenny 方法

mediation 给出了非参数识别公式, 它允许我们在各种不同模型下推导出中介效应的具体形式。本节介绍经典而又广泛使用的 **Baron-Kenny 方法** (?), 该方法假设线性模型。

5.1. 模型设定. Baron-Kenny 方法假设中介和结果都满足线性模型 (??)。

[Baron-Kenny 线性模型] 中介和结果的条件期望满足线性模型:

$$(27.1) \quad \begin{cases} \mathbb{E}(M | Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y | Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

在上述线性模型下, NDE 和 NIE 可以简化为系数的简洁函数。

推论 G.6 (Baron-Kenny 公式). 在 ?????????? 下, 有

$$(27.2) \quad \quad \quad = \theta_1, \quad \quad = \theta_2 \beta_1.$$

与 DAG 的对应: 在 ?? 中, θ_1 是路径 $Z \rightarrow Y$ 的系数 (直接效应), $\beta_1 \theta_2$ 是路径 $Z \rightarrow M \rightarrow Y$ 的系数之积 (间接效应)。这与 ?? 完全一致。

为何不需要对 X 求和? 注意在 ?? 和 ?? 中, (x) 和 (x) 是在给定 $X = x$ 的条件下的值。而在 Baron-Kenny 线性模型下, θ_1 和 $\theta_2 \beta_1$ 与 x 无关, 因此条件效应等于无条件效应。

Baron-Kenny 公式的推导见附录 ??。

如果获得了系数的 OLS 估计量 $\hat{\beta}_1$ 和 $\hat{\theta}_2$, 则 NDE 和 NIE 的估计量为

$$\hat{\quad} = \hat{\theta}_1, \quad \hat{\quad} = \hat{\theta}_2 \hat{\beta}_1,$$

⁸详见 ?? 题。

这就是经典的 Baron-Kenny 估计。⁹ 和 ⁹ 利用 delta 方法给出了 $\hat{\gamma}$ 的标准误：

$$\text{var}(\hat{\gamma}) = \text{var}(\hat{\theta}_2)\hat{\beta}_1^2 + \hat{\theta}_2^2\text{var}(\hat{\beta}_1).$$

基于此的假设检验称为 Sobel's test。⁹

Baron-Kenny 方法的历史：虽然 ⁹ 使这一方法广为人知，但它实际上有更早的渊源，包括 ⁹、⁹ 和 ⁹ 的工作。⁹ 进一步发展了推断方法。

6. 应用实例：JOBS II 数据

我们通过 R 代码实现 Baron-Kenny 方法，并将其应用于 JOBS II 数据集。¹⁰

例 G.5 (JOBS II：就业培训对心理健康的中介分析). 我们关注就业培训（处理 Z ）对心理健康（结果 Y ，用抑郁量表得分度量）的影响，以及这一影响是否通过工作搜寻效能（中介 M ）传导。背景协变量 X 包括经济困难程度、基线抑郁得分、性别、年龄、职业、婚姻状态、种族、教育程度和家庭收入。

通过以下 R 代码实现 Baron-Kenny 方法：

```
library("car")
BKmediation = function(Z, M, Y, X) {
  mediator.reg = lm(M ~ Z + X)
  mediator.Zcoef = mediator.reg$coef[2]
  mediator.Zse = sqrt(hccm(mediator.reg)[2, 2])

  outcome.reg = lm(Y ~ Z + M + X)
  outcome.Zcoef = outcome.reg$coef[2]
  outcome.Zse = sqrt(hccm(outcome.reg)[2, 2])
  outcome.Mcoef = outcome.reg$coef[3]
  outcome.Mse = sqrt(hccm(outcome.reg)[3, 3])

  NDE = outcome.Zcoef
  NIE = outcome.Mcoef * mediator.Zcoef

  NDE.se = outcome.Zse
  NIE.se = sqrt(outcome.Mse^2 * mediator.Zcoef^2 +
                outcome.Mcoef^2 * mediator.Zse^2)

  res = matrix(c(NDE, NIE, NDE.se, NIE.se,
                 NDE/NDE.se, NIE/NIE.se), 2, 3)
  rownames(res) = c("NDE", "NIE")
  colnames(res) = c("est", "se", "t")
  res
}
```

运行结果如下：

```
> res = BKmediation(Z, M, Y, X)
> round(res, 3)
```

⁹关于 Sobel 检验的更多讨论见 ⁹。

¹⁰JOBS II 是一个关于就业培训对失业工人影响的随机化现场实验。数据集在 R 的 mediation 包中。

	est	se	t
NDE	-0.037	0.042	-0.885
NIE	-0.014	0.009	-1.528

估计的直接效应 $\hat{\gamma} = -0.037$ (培训对心理健康的直接保护效应) 和间接效应 $\hat{\gamma} = -0.014$ (通过提高工作搜寻效能而改善心理健康) 均为负, 但统计上均不显著。这表明 *JOBS II* 培训项目对心理健康的效应尚无充分证据支持按中介路径分解。

一个值得注意的现象：在某些设定下, 间接效应可能出现违反直觉的符号。例如, 如果 $Z \rightarrow M$ 的效应 $\beta_1 > 0$, $M \rightarrow Y$ 的效应 $\theta_2 > 0$, 但 Z 与 M 之间存在负交互项 $\theta_3 < 0$, 则乘积 $\beta_1(\theta_2 + \theta_3)$ 可能为负。这被称为**中介悖论** (mediator paradox) 或**替代终点悖论** (surrogate endpoint paradox)。^a

^a详见 ?。

7. 敏感性分析

中介分析依赖于强且不可检验的假设。关键的不可检验假设是跨世界独立性 (??): 我们无法通过任何实验数据验证 $Y(z, m)$ 与 $M(z')$ 在 $z \neq z'$ 时是否独立。

因此, 研究者常常需要进行**敏感性分析** (sensitivity analysis), 以探索当关键假设不成立时, 结论会如何变化。主要文献包括:

- ? 提出了类似 Cornfield 的敏感性界;
- ? 提出了针对 Baron-Kenny 线性模型量身定制的敏感性分析方法。

敏感性分析的具体方法超出了本章的范围, 但读者应记住: 中介分析的结果必须谨慎解读, 因为其核心假设无法被数据验证。

8. 本章小结

本章围绕中介分析展开, 主要内容如下:

- (1) **核心问题:** 因果效应如何在直接通路和间接通路之间分配?
- (2) **嵌套潜在结果** $Y(z, M_{z'})$: 描述跨世界 counterfactual, 是定义 NDE 和 NIE 的基础。
- (3) **效应分解:** 在 Composition 假设下, 总效应 $\tau = +$ 。
- (4) **识别假设:** 四个假设 (序列可忽略性 + 跨世界独立性) 下, 中介公式成立。
- (5) **中介公式:** 将不可观测的 NDE 和 NIE 表达为可观测条件分布的函数。
- (6) **Baron-Kenny 公式:** 在 ?? 下, $\gamma = \theta_1$, $\gamma = \theta_2\beta_1$ 。
- (7) **跨世界 counterfactual 的哲学争议:** 严格的 Popperian 认识论者认为中介分析是形而上学的。
- (8) **敏感性分析:** 由于核心假设不可检验, 敏感性分析是必要的。

中介公式的完整证明见附录 ??; Baron-Kenny 公式的推导见附录 ??; 各节练习题见附录 ??。

练习

练习 G.1. 假设 (Z, M, Y) 均为二值变量。基于潜在结果

$$M(1), M(0), Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)$$

的联合取值, 单元可以分成多少类型?

若进一步假设单调性 $M(1) \geq M(0)$ (Z 对 M 的单调性), 则单元可以分成多少类型?

若再假设 $Y(1, m) \geq Y(0, m)$ 且 $Y(z, 1) \geq Y(z, 0)$ 对所有 z, m 成立 (Z 和 M 对 Y 的单调性), 则单元可以分成多少类型?

本题答案见附录 ??。

练习 G.2. 证明 ?? 与 ???? 等价。

本题答案见附录 ??。

练习 G.3. ? 提出了另一组假设来推导中介公式：

$$\{Y(z, m), M(z')\} \perp\!\!\!\perp Z \mid X, \quad Y(z, m) \perp\!\!\!\perp M(z') \mid (Z = z', X),$$

对所有 z, z', m 成立。

证明：在上述假设下，*mediation* 中的中介公式同样成立。

本题答案见附录 ??。

练习 G.4. 在 *Baron-Kenny* 线性模型 (??) 下，首先拟合：

$$\hat{M} = \hat{\beta}_0 + \hat{\beta}_1 Z + \hat{\beta}_2^\top X, \quad \hat{Y} = \hat{\theta}_0 + \hat{\theta}_1 Z + \hat{\theta}_2 M + \hat{\theta}_4^\top X.$$

则 *NIE* 的估计量为乘积 $\hat{\theta}_2 \hat{\beta}_1$ (乘积法)。

另一方面，首先拟合：

$$\hat{Y} = \hat{\alpha}_0 + \hat{\alpha}_1 Z + \hat{\alpha}_1^\top X,$$

再拟合：

$$\hat{Y} = \tilde{\theta}_0 + \tilde{\theta}_1 Z + \tilde{\theta}_2 M + \tilde{\theta}_4^\top X,$$

则 *NIE* 的另一估计量为差值 $\hat{\alpha}_1 - \tilde{\theta}_1$ (差值法)。

证明： $\hat{\alpha}_1 - \tilde{\theta}_1 = \hat{\theta}_2 \hat{\beta}_1$ 。

本题答案见附录 ??。

练习 G.5. 证明 ?? (二值中介的 *NIE* 乘积公式)。

本题答案见附录 ??。

练习 G.6. ? 建议在结果模型中加入处理与中介的交互项：

$$\begin{cases} \mathbb{E}(M \mid Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_3 ZM + \theta_4^\top X. \end{cases}$$

证明：在此模型下，

$$= \theta_1 + \theta_3 \{\beta_0 + \beta_2^\top \mathbb{E}(X)\}, \quad = (\theta_2 + \theta_3) \beta_1.$$

并说明如何在 *iid* 数据下估计 和 。

本题答案见附录 ??。

练习 G.7. 考虑中介 M 服从正态线性模型、结果 Y 服从 *logistic* 模型：

$$\begin{cases} M \mid Z, X \sim \mathcal{N}(\beta_0 + \beta_1 Z + \beta_2^\top X, \sigma_M^2), \\ \text{logit}\{\Pr(Y = 1 \mid Z, M, X)\} = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

请将 和 表示为模型参数和 X 分布的函数，并说明如何在 *iid* 数据下估计它们。

本题答案见附录 ??。

练习 G.8. 考虑二值中介 M 服从 *logistic* 模型、结果 Y 服从线性模型：

$$\begin{cases} \text{logit}\{\Pr(M = 1 \mid Z, X)\} = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

证明：

$$= \theta_1, \quad = \theta_2 \mathbb{E}\{\text{expit}(\beta_0 + \beta_1 + \beta_2^\top X) - \text{expit}(\beta_0 + \beta_2^\top X)\}.$$

并说明如何在 *IID* 数据下估计 和 。

本题答案见附录 ??。

练习 G.9. 将嵌套潜在结果修改为

$$Y(z, F_{M_{z'}|X}) = \int Y(z, m) f(M_{z'} = m \mid X) dm,$$

其中 $F_{M_{z'}|X}$ 是条件分布而非确定值。相应地将 *NDE* 和 *NIE* 定义为

$$= \mathbb{E}\{Y(1, F_{M_0|X}) - Y(0, F_{M_0|X})\}, \quad = \mathbb{E}\{Y(1, F_{M_1|X}) - Y(1, F_{M_0|X})\}.$$

证明：在仅假设 ??????（不要求跨世界独立性）下， 和 的识别公式与正文相同。

本题答案见附录 ??。

练习 G.10. ? 和 ? 综述并比较了主分层与中介分析两种方法。请查阅这些文献，并撰写一页总结，阐述两种方法的异同与各自的优缺点。

本题为开放性研究型练习，请参考 ? 和 ?。

APPENDIX A

公式推导

1. Lemma 4.1 的证明：方差与协方差的关系

Lemma 4.1 (教材第 1975 页):

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

背景 (Background): Lemma 4.1 是 Neyman (1923) 定理证明中的一个关键代数恒等式，它建立了有限总体协方差与各个方差之间的关系。

参数定义 (Parameter Definitions):

- $S^2(1) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2$: 潜在结果 $Y_i(1)$ 的有限总体方差
- $S^2(0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$: 潜在结果 $Y_i(0)$ 的有限总体方差
- $S(1, 0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}\{Y_i(0) - \bar{Y}(0)\}$: $Y_i(1)$ 与 $Y_i(0)$ 之间的有限总体协方差
- $\tau_i = Y_i(1) - Y_i(0)$: 个体因果效应
- $\tau = n^{-1} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$: 平均因果效应
- $S^2(\tau) = (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2$: 个体因果效应的有限总体方差

目标 (Goal): 证明

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

推导步骤 (Derivation Steps):

第一步: 从 $S^2(\tau)$ 的定义出发。

$$\begin{aligned} S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - Y_i(0)) - (\bar{Y}(1) - \bar{Y}(0))]^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - \bar{Y}(1)) - (Y_i(0) - \bar{Y}(0))]^2. \end{aligned}$$

第二步: 展开平方。

$$\begin{aligned}
S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n \left[(Y_i(1) - \bar{Y}(1))^2 + (Y_i(0) - \bar{Y}(0))^2 \right. \\
&\quad \left. - 2(Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \right] \\
&= (n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))^2 + (n-1)^{-1} \sum_{i=1}^n (Y_i(0) - \bar{Y}(0))^2 \\
&\quad - 2(n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \\
&= S^2(1) + S^2(0) - 2S(1, 0).
\end{aligned}$$

第三步：移项得到目标恒等式。

$$S^2(1) + S^2(0) - S^2(\tau) = 2S(1, 0).$$

结论：得证

$$\boxed{2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)}.$$

直观理解：这个恒等式揭示了潜在结果之间的相关性 ($S(1, 0)$) 与个体因果效应变异 ($S^2(\tau)$) 之间的联系。当个体因果效应完全恒定 ($S^2(\tau) = 0$) 时, $2S(1, 0) = S^2(1) + S^2(0)$, 即 $Y(1)$ 和 $Y(0)$ 完全正相关 (相关系数为 1)。当 $S^2(\tau) > 0$ 时, 等式右侧变小, 意味着 $S(1, 0)$ 变小或变为负值。

在方差公式中的应用：这个恒等式允许我们将 Neyman 方差公式写成两种等价形式：

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} = \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0).$$

2. 差值均值统计量的方差分解

背景：在 ?? 中, 我们声称

$$(n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

本节给出完整的代数推导。

第一步：从定义出发。

$$(n-1)s^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n [(Y_i - \bar{Y})]^2.$$

第二步：对每个单元 i , 将偏差 $Y_i - \bar{Y}$ 写成：

$$Y_i - \bar{Y} = \underbrace{(Y_i - \hat{Y}(Z_i))}_{\text{组内偏差}} + \underbrace{(\hat{Y}(Z_i) - \bar{Y})}_{\text{组间偏差}}.$$

第三步：平方展开：

$$(Y_i - \bar{Y})^2 = (Y_i - \hat{Y}(Z_i))^2 + (\hat{Y}(Z_i) - \bar{Y})^2 + 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}).$$

第四步：对所有单元求和。关键观察是交叉项求和为零：

$$\sum_{i=1}^n 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}) = 2 \sum_{i=1}^n (Y_i - \hat{Y}(Z_i)) \cdot (\hat{Y}(Z_i) - \bar{Y}).$$

当 $Z_i = 1$ 时，这个和化为：

$$2 \sum_{Z_i=1} (Y_i - \hat{Y}(1)) \cdot (\hat{Y}(1) - \bar{Y}) = 2(\hat{Y}(1) - \bar{Y}) \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))}_{=0} = 0,$$

因为 $\sum_{Z_i=1} Y_i = n_1 \hat{Y}(1)$ ，所以 $\sum_{Z_i=1} (Y_i - \hat{Y}(1)) = 0$ 。

同理，当 $Z_i = 0$ 时：

$$2 \sum_{Z_i=0} (Y_i - \hat{Y}(0)) \cdot (\hat{Y}(0) - \bar{Y}) = 2(\hat{Y}(0) - \bar{Y}) \underbrace{\sum_{Z_i=0} (Y_i - \hat{Y}(0))}_{=0} = 0.$$

因此交叉项全部抵消。

第五步：整理得到：

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2}_{\text{组内平方和}} + \underbrace{\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2}_{\text{组间平方和}}.$$

第六步：计算组间平方和：

$$\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2 = n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2.$$

利用以下两个事实：

- (1) $\hat{Y}(1) - \hat{Y}(0) = \hat{\tau}$
- (2) $n_1 \hat{Y}(1) + n_0 \hat{Y}(0) = n \bar{Y}$ (加权平均的性质)

展开并化简：

$$\begin{aligned} & n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 \\ &= n_1 \hat{Y}(1)^2 - 2n_1 \hat{Y}(1) \bar{Y} + n_1 \bar{Y}^2 + n_0 \hat{Y}(0)^2 - 2n_0 \hat{Y}(0) \bar{Y} + n_0 \bar{Y}^2 \\ &= n_1 \hat{Y}(1)^2 + n_0 \hat{Y}(0)^2 - n \bar{Y}^2. \end{aligned}$$

利用 $(n_1 \hat{Y}(1) + n_0 \hat{Y}(0))^2 = n^2 \bar{Y}^2$ ，展开得：

$$n_1^2 \hat{Y}(1)^2 + 2n_1 n_0 \hat{Y}(1) \hat{Y}(0) + n_0^2 \hat{Y}(0)^2 = n^2 \bar{Y}^2.$$

代入上式并利用 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ ，最终化简为：

$$n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 = \frac{n_1 n_0}{n} \hat{\tau}^2.$$

结论：代入即得 ??。

3. Wilcoxon 秩和统计量的方差推导

背景：在 ?? 中，我们声称在 H_{0F} 下

$$\text{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

本节给出完整的代数推导。

第一步：回忆 $W = \sum_{i=1}^n Z_i R_i$ ，其中 R_i 是 Y_i 在合并样本中的秩（固定值）， Z_i 是随机化的治疗指示变量。

方差分解：

$$\text{var}(W) = \text{var}\left(\sum_{i=1}^n Z_i R_i\right) = \sum_{i=1}^n R_i^2 \text{var}(Z_i) + \sum_{i \neq j} R_i R_j \text{cov}(Z_i, Z_j).$$

计算 $\text{var}(Z_i)$ ：在 CRE 中， $Z_i \sim \text{Bernoulli}(n_1/n)$ ，所以

$$\text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

计算 $\text{cov}(Z_i, Z_j)$ for $i \neq j$ ：由于 $\sum_{i=1}^n Z_i = n_1$ （固定），我们有

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)} \quad (i \neq j).$$

代入：

$$\begin{aligned} \text{var}(W) &= \left(\sum_{i=1}^n R_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} R_i R_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right) \\ &= \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \sum_{i \neq j} R_i R_j \right]. \end{aligned}$$

注意 $\sum_{i \neq j} R_i R_j = (\sum_{i=1}^n R_i)^2 - \sum_{i=1}^n R_i^2$ ，代入得：

$$\text{var}(W) = \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \left(\left(\sum_{i=1}^n R_i \right)^2 - \sum_{i=1}^n R_i^2 \right) \right].$$

计算 $\sum_{i=1}^n R_i$ 和 $\sum_{i=1}^n R_i^2$ ：假设无 ties，则 $\{R_i\}$ 是 $1, 2, \dots, n$ 的一个排列。

$$\sum_{i=1}^n R_i = 1 + 2 + \dots + n = \frac{n(n+1)}{2}.$$

$$\sum_{i=1}^n R_i^2 = 1^2 + 2^2 + \dots + n^2 = \frac{n(n+1)(2n+1)}{6}.$$

代入并化简：

$$\begin{aligned} \text{var}(W) &= \frac{n_1 n_0}{n^2} \left[\frac{n(n+1)(2n+1)}{6} - \frac{1}{n-1} \left(\frac{n^2(n+1)^2}{4} - \frac{n(n+1)(2n+1)}{6} \right) \right] \\ &= \frac{n_1 n_0 (n+1)}{12}. \end{aligned}$$

结论：得证。

4. 女士品茶实验的超几何分布

背景：在 ?? 中，我们讨论了 Fisher 的女士品茶实验。本节给出超几何分布的完整推导。

设置：

- 8 杯茶中有 4 杯是”先加奶”($K = 4$), 4 杯是”先加茶”
- 女士随机猜测其中 4 杯为”先加奶”
- 记 X 为她猜对”先加奶”的杯数

为什么是超几何分布？

在 H_{0F} 下，女士的猜测是固定的（她选 4 杯作为”先加奶”的猜测）。实验者随机排列 8 杯茶的顺序呈现给女士。这等于：从含有 $K = 4$ 个”成功”的总体 $N = 8$ 中，不放回抽取 $n = 4$ 个， X 是抽到的成功个数。

超几何分布的概率质量函数：

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, 2, 3, 4.$$

验证：超几何分布的概率之和为 1。

$$\sum_{k=0}^4 \mathbb{P}(X = k) = \frac{1}{\binom{8}{4}} \sum_{k=0}^4 \binom{4}{k} \binom{4}{4-k} = \frac{1}{70} \cdot \binom{8}{4} = 1,$$

其中利用了组合恒等式 $\sum_k \binom{a}{k} \binom{b}{n-k} = \binom{a+b}{n}$ 。

各概率的数值：

$$\begin{aligned} \mathbb{P}(X = 0) &= \frac{\binom{4}{0} \binom{4}{4}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}, \\ \mathbb{P}(X = 1) &= \frac{\binom{4}{1} \binom{4}{3}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 2) &= \frac{\binom{4}{2} \binom{4}{2}}{\binom{8}{4}} = \frac{6 \cdot 6}{70} = \frac{36}{70}, \\ \mathbb{P}(X = 3) &= \frac{\binom{4}{3} \binom{4}{1}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 4) &= \frac{\binom{4}{4} \binom{4}{0}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}. \end{aligned}$$

与二项分布的比较：如果”抽取放回”（即女士每次猜测后被告知答案），则 $X \sim \text{Binomial}(4, 1/2)$ ，此时

$$\mathbb{P}(X = 4) = \binom{4}{4} (1/2)^4 = 1/16 = 0.0625 > 0.014.$$

超几何分布（不放回）的尾部概率更小，使得 Fisher 的检验在零假设下更精确——这正是 FRT”精确”的含义。

5. 差值均值统计量的期望与方差推导

背景：在 ?? 中，我们定义了差值均值统计量

$$\hat{\tau} = \hat{Y}(1) - \hat{Y}(0).$$

本节推导在 H_{0F} 下 $\hat{\tau}$ 的期望和方差。

期望的推导. 回忆在 CRE 中, 治疗分配 $\mathbf{Z}$ 与潜在结果 $\{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 独立, 且每个单元被分配到治疗组的概率为 n_1/n :

$$\mathbb{E}(Z_i) = \frac{n_1}{n}, \quad \mathbb{E}(1 - Z_i) = \frac{n_0}{n}.$$

因此

$$\begin{aligned} \mathbb{E}(\hat{\tau}) &= \mathbb{E} \left(n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i \right) \\ &= n_1^{-1} \sum_{i=1}^n \mathbb{E}(Z_i) Y_i - n_0^{-1} \sum_{i=1}^n \mathbb{E}(1 - Z_i) Y_i \\ &= n_1^{-1} \sum_{i=1}^n \frac{n_1}{n} Y_i - n_0^{-1} \sum_{i=1}^n \frac{n_0}{n} Y_i \\ &= \frac{1}{n} \sum_{i=1}^n Y_i - \frac{1}{n} \sum_{i=1}^n Y_i = 0. \end{aligned}$$

方差的推导. 第一步: 简化表达式。注意到

$$\hat{\tau} = n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i = \frac{n}{n_0} \cdot n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n Y_i.$$

由于 $\sum_{i=1}^n Y_i$ 是常数 (不依赖 $\mathbf{Z}$), 我们只需计算

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \text{var} \left(\sum_{i=1}^n Z_i Y_i \right).$$

第二步: 计算 $\text{var}(Z_i)$ 和 $\text{cov}(Z_i, Z_j)$ 。在 CRE 中,

$$Z_i \sim \text{Bernoulli} \left(\frac{n_1}{n} \right), \quad \text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ (固定), 对于 $i \neq j$,

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)}.$$

第三步: 计算 $\text{var}(\sum_{i=1}^n Z_i Y_i)$:

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \sum_{i=1}^n Y_i^2 \text{var}(Z_i) + \sum_{i \neq j} Y_i Y_j \text{cov}(Z_i, Z_j) \\ &= \left(\sum_{i=1}^n Y_i^2 \right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} Y_i Y_j \left(-\frac{n_1 n_0}{n^2(n-1)} \right). \end{aligned}$$

注意 $\sum_{i \neq j} Y_i Y_j = (\sum_{i=1}^n Y_i)^2 - \sum_{i=1}^n Y_i^2 = n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2$, 代入得:

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \frac{n_1 n_0}{n^2} \sum_{i=1}^n Y_i^2 - \frac{n_1 n_0}{n^2(n-1)} \left(n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2 \right) \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[(n-1) \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 + \sum_{i=1}^n Y_i^2 \right] \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[n \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 \right] \\ &= \frac{n_1 n_0}{n(n-1)} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right). \end{aligned}$$

第四步: 利用 s^2 的定义:

$$s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)^{-1} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right).$$

因此

$$\text{var} \left(\sum_{i=1}^n Z_i Y_i \right) = \frac{n_1 n_0}{n} \cdot s^2.$$

第五步: 代回 $\text{var}(\hat{\tau})$:

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \frac{n_1 n_0}{n} \cdot s^2 = \frac{n}{n_1 n_0} \cdot s^2.$$

结论:

$$\boxed{\text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} \cdot s^2}.$$

直观理解:

- 方差与总样本量 n 成正比——样本越大, 估计越精确
- 方差与 $n_1 n_0$ 成反比——当 $n_1 = n_0 = n/2$ 时方差最小
- 这与直觉一致: 治疗组 and 对照组越平衡, 我们越能准确估计因果效应

6. CRE 中分层平衡性的推导

背景 (Background): 在完全随机实验 (CRE) 中, 我们固定总的治疗组和对照组样本量 n_1 和 n_0 , 但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。本节证明各层治疗组和对照组比例之差的期望为零。

参数定义 (Parameter Definitions):

- n : 总单元数
- $n_{[k]}$: 第 k 层的单元数
- n_1 : 总治疗组单元数
- n_0 : 总对照组单元数 ($n_0 = n - n_1$)
- $n_{[k]1}$: 第 k 层中分配到治疗组的单元数
- $n_{[k]0}$: 第 k 层中分配到对照组的单元数 ($n_{[k]0} = n_{[k]} - n_{[k]1}$)
- $\pi_{[k]} = n_{[k]}/n$: 第 k 层在总体中的比例

已知条件 (Given):

- 在 CRE 下, 治疗分配向量 $\mathbf{Z}$ 是从所有 $\binom{n}{n_1}$ 种分配中等概率随机选取的
- 各单元被分配到治疗组的概率为 n_1/n

目标 (Goal): 证明

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0.$$

推导步骤 (Derivation Steps):

第一步: 建立 $n_{[k]1}$ 的期望。

在 CRE 下, 每个单元被分配到治疗组的概率为 n_1/n 。因此, 对于第 k 层中的任意单元 i (满足 $X_i = k$):

$$\mathbb{E}(Z_i) = \frac{n_1}{n}.$$

第 k 层中分配到治疗组的单元数为:

$$n_{[k]1} = \sum_{i: X_i=k} Z_i.$$

由于该层有 $n_{[k]}$ 个单元, 且 Z_i 之间是负相关的 (总和固定为 n_1), 我们有:

$$\mathbb{E}(n_{[k]1}) = \sum_{i: X_i=k} \mathbb{E}(Z_i) = n_{[k]} \cdot \frac{n_1}{n} = \pi_{[k]} \cdot n_1.$$

第二步: 计算比例的期望。

由于 $n_{[k]0} = n_{[k]} - n_{[k]1}$, 我们有:

$$\mathbb{E}(n_{[k]0}) = n_{[k]} - \mathbb{E}(n_{[k]1}) = n_{[k]} - \pi_{[k]} n_1 = n_{[k]} - \frac{n_{[k]}}{n} n_1 = n_{[k]} \left(1 - \frac{n_1}{n} \right) = n_{[k]} \cdot \frac{n_0}{n} = \pi_{[k]} \cdot n_0.$$

第三步: 计算比例之差的期望。

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = \frac{\mathbb{E}(n_{[k]1})}{n_1} - \frac{\mathbb{E}(n_{[k]0})}{n_0} = \frac{\pi_{[k]} n_1}{n_1} - \frac{\pi_{[k]} n_0}{n_0} = \pi_{[k]} - \pi_{[k]} = 0.$$

结论: 得证 $\mathbb{E} (n_{[k]1}/n_1 - n_{[k]0}/n_0) = 0$ 。

直观理解: 这个结果表明, 虽然在一次实现中 $n_{[k]1}/n_1 - n_{[k]0}/n_0$ 可能显著非零 (由于随机波动), 但这种波动在期望意义下是平衡的。随机化保证了渐近公平性——各层在治疗组和对照组中的比例在期望上与总体比例一致。

7. 分层估计量的期望与方差推导

背景 (Background): 在分层随机实验 (SRE) 中, 我们使用学生化分层估计量

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}}$$

作为 Fisher 随机化检验的统计量。本节推导在 sharp null $H_{0F}: Y_i(1) = Y_i(0)$ 下 t_{SRE} 的期望和方差。

参数定义 (Parameter Definitions):

- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right)$: 方差估计量

- $\hat{S}_{[k]}^2(1)$ 、 $\hat{S}_{[k]}^2(0)$: 第 k 层内治疗组和对照组的样本方差

目标 (Goal): 推导 $\hat{\tau}_{\text{SRE}}$ 和 $\hat{V}_{\text{SRE}}$ 在 H_{0F} 下的期望和方差。

推导步骤 (Derivation Steps):

第一步: $\hat{\tau}_{[k]}$ 的期望。

在 H_{0F} 下, 所有 $Y_i(1) = Y_i(0) = Y_i$ 。因此,

$$\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0) = \frac{\sum_{i: X_i=k} Z_i Y_i}{n_{[k]1}} - \frac{\sum_{i: X_i=k} (1 - Z_i) Y_i}{n_{[k]0}}.$$

利用 $\mathbb{E}(Z_i) = n_1/n$ 和 $\mathbb{E}(1 - Z_i) = n_0/n$, 以及 Y_i 是固定值 (不依赖 Z), 我们有:

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} \cdot \bar{Y}_{[k]} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \cdot \bar{Y}_{[k]} = \bar{Y}_{[k]} \left(\frac{n_{[k]}}{n_{[k]1}} \cdot \frac{n_1}{n} - \frac{n_{[k]}}{n_{[k]0}} \cdot \frac{n_0}{n} \right).$$

由于 $n_{[k]1}/n_{[k]} = e_{[k]}$ (层别倾向得分) 和 $n_{[k]0}/n_{[k]} = 1 - e_{[k]}$, 以及 n_1/n 和 n_0/n 是常数, 上述表达式可简化为 $\bar{Y}_{[k]} \cdot (\text{常数} - \text{常数}) = 0$ 。

更直接地: 由于 $\mathbb{E}(Z_i) = n_1/n$ 对所有单元成立, 在 H_{0F} 下,

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{1}{n_{[k]1}} \sum_{i: X_i=k} \mathbb{E}(Z_i) Y_i - \frac{1}{n_{[k]0}} \sum_{i: X_i=k} \mathbb{E}(1 - Z_i) Y_i = \frac{n_1}{n} \bar{Y}_{[k]} - \frac{n_0}{n} \bar{Y}_{[k]} = 0.$$

第二步: $\hat{\tau}_{\text{SRE}}$ 的期望。

由于 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 且 $\pi_{[k]}$ 是常数,

$$\mathbb{E}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]} \mathbb{E}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]} \cdot 0 = 0.$$

第三步: $\hat{\tau}_{[k]}$ 的方差。

利用 Neyman (1923) 的方差公式 (见 ??), 在第 k 层内,

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}}.$$

第四步: $\hat{\tau}_{\text{SRE}}$ 的方差。

由于各层之间的随机化是独立的,

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right).$$

第五步: $\hat{V}_{\text{SRE}}$ 的期望。

利用 $\mathbb{E}(\hat{S}_{[k]}^2(1)) = S_{[k]}^2(1)$ 和 $\mathbb{E}(\hat{S}_{[k]}^2(0)) = S_{[k]}^2(0)$,

$$\mathbb{E}(\hat{V}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right) = \text{var}(\hat{\tau}_{\text{SRE}}) + \sum_{k=1}^K \pi_{[k]}^2 \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以 $\mathbb{E}(\hat{V}_{\text{SRE}}) = \text{var}(\hat{\tau}_{\text{SRE}})$ 。

结论：在 H_{0F} 下， $\hat{\tau}_{\text{SRE}}$ 的期望为零，方差为 $\hat{V}_{\text{SRE}}$ 的期望。因此 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 是一个合理的学生化统计量。

8. 分层 Neymanian 方差的推导

背景 (Background)：在分层随机实验 (SRE) 中，本节推导第 k 层差值均值估计量 $\hat{\tau}_{[k]}$ 的方差公式，以及分层估计量 $\hat{\tau}_{\text{SRE}}$ 的方差公式。

参数定义 (Parameter Definitions)：

- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$ ：第 k 层内潜在结果 $Y(1)$ 和 $Y(0)$ 的有限总体方差
- $S_{[k]}^2(\tau)$ ：第 k 层内个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 的有限总体方差
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$ ：第 k 层的差值均值
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ ：分层估计量

目标 (Goal)：

- (1) 证明 (??)： $\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}$
- (2) 证明 (??)： $\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]})$

推导步骤 (Derivation Steps)：

式 (??) 的推导. 第一步：应用 Neyman (1923) 定理于第 k 层。

第 k 层本质上是一个独立的 CRE，只是总体大小为 $n_{[k]}$ 而非 n 。直接应用 Neyman 的方差公式 (见 ??)：

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

直观解释：这个方差公式与 CRE 中的方差公式结构相同，只是将总体量替换为层别总体量。

式 (??) 的推导. 第二步：利用层间独立性。

在 SRE 中，各层内的治疗分配是独立进行的。因此， $\hat{\tau}_{[1]}, \dots, \hat{\tau}_{[K]}$ 之间相互独立。

第三步：计算分层估计量的方差。

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \text{var}\left(\sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}\right) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) + \sum_{k \neq j} \pi_{[k]} \pi_{[j]} \text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}).$$

由于各层之间的独立性， $\text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}) = 0$ (对 $k \neq j$)。因此，

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

结论：代入 (??) 即得

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right).$$

9. CRE 与 SRE 方差差异的推导

背景 (Background): 本节推导在常数倾向得分条件下, CRE 估计量 $\hat{\tau}$ 与 SRE 估计量 $\hat{\tau}_{\text{SRE}}$ 方差差异的近似公式。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$: CRE 的差值均值估计量
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: SRE 的分层估计量
- $S^2(1)$ 、 $S^2(0)$: 总体的潜在结果有限总体方差
- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层的潜在结果有限总体方差
- $\bar{Y}(1)$ 、 $\bar{Y}(0)$: 总体的潜在结果均值
- $\bar{Y}_{[k]}(1)$ 、 $\bar{Y}_{[k]}(0)$: 第 k 层的潜在结果均值

已知条件 (Given):

- 在 CRE 下: $\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- 在 SRE 下: $\text{var}_{\text{SRE}}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right)$
- 方差分析分解: $S^2(1) = \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2$ - 层内变异

目标 (Goal): 证明方差差异约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

推导步骤 (Derivation Steps):

第一步: 方差分析分解。

对 $S^2(1)$ 进行层间分解:

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \frac{n_{[k]} - 1}{n-1} \cdot \frac{1}{n_{[k]} - 1} \sum_{i: X_i=k} \{Y_i(1) - \bar{Y}_{[k]}(1)\}^2 \\ &\quad + \sum_{k=1}^K \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2. \end{aligned}$$

当 $n_{[k]}$ 较大时, $(n_{[k]} - 1)/(n - 1) \approx n_{[k]}/n = \pi_{[k]}$, 于是

$$S^2(1) \approx \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2.$$

同理对 $S^2(0)$ 和 $S^2(\tau)$ 进行分解。

第二步: 代入 CRE 方差公式。

$$\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(0) - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(\tau) + \text{层间变异项}.$$

第三步: 识别差异项。

层间变异项为：

$$\frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} (\tau_{[k]} - \tau)^2.$$

第四步：近似简化。

当层样本量较大时，利用 $n_{[k]1} \approx \pi_{[k]} n_1$ 和 $n_{[k]0} \approx \pi_{[k]} n_0$ ，层间变异项近似为：

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2.$$

结论：由于每一项都是平方和，该表达式非负。当且仅当对所有 k 都有

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

时（即协变量不能预测潜在结果），差异为零。这证明了 SRE 在协变量能预测结果时比 CRE 更有效。

10. CRE 条件分布的推导

背景 (Background)：本节证明在给定各层治疗分配数量 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下，CRE 的治疗分配向量 $\mathbf{Z}$ 的条件分布与 SRE 的分布相同。

参数定义 (Parameter Definitions)：

- $\mathbf{Z} = (Z_1, \dots, Z_n)$ ：治疗分配向量
- $n_{[k]1}$ ：第 k 层中分配到治疗组的单元数
- $n_{[k]0}$ ：第 k 层中分配到对照组的单元数
- $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ ：所有层的分配数量向量

已知条件 (Given)：

- 在 CRE 下： $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}$ 对所有满足 $\sum Z_i = n_1$ 的分配 $\mathbf{z}$
- 在 SRE 下：第 k 层的分配概率为 $\frac{1}{\binom{n_{[k]}}{n_{[k]1}}}$

目标 (Goal)：证明

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

推导步骤 (Derivation Steps)：

第一步：计算联合概率。

在 CRE 下，治疗分配向量 $\mathbf{Z}$ 的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}.$$

第二步：计算条件概率。

给定 $\mathbf{n}$ 条件下 $\mathbf{Z} = \mathbf{z}$ 的条件概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{CRE}(\mathbf{n})}.$$

事件 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 意味着第 k 层恰好有 $n_{[k]1}$ 个单元被分配到治疗组。由于各层的分配是独立的，这个联合事件的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n}) = \prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}.$$

第三步：计算边际概率。

为了计算 $\Pr_{CRE}(\mathbf{n})$ ，我们对所有满足第 k 层有 $n_{[k]1}$ 个治疗组单元的分配 $\mathbf{z}$ 求和：

$$\Pr_{CRE}(\mathbf{n}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \frac{1}{\binom{n}{n_1}}.$$

满足该条件的分配数量为 $\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}$ ，因此

$$\Pr_{CRE}(\mathbf{n}) = \prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}.$$

第四步：代入条件概率公式。

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

结论：得证 CRE 在给定各层分配数量条件下的条件分布与 SRE 的分布相同。这建立了分层与后分层的对偶性：分层在设计阶段使用协变量，后分层在分析阶段使用协变量。

11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明

背景 (Background): 在 Chapter 4 中，我们讨论了 Neymanian 推断与 OLS 的关系。教材陈述了三个关键结果 (??)–(??)，本节给出完整的代数证明。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$: 差值均值估计量
- $\hat{\beta}$: OLS 回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ 的 treatment 系数估计量
- $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$: Neyman 保守方差估计量
- $\hat{V}_{OLS}$: 通常 OLS 方差估计量
- $\hat{V}_{EHW}$: Eicker-Huber-White 稳健方差估计量

目标 (Goal):

- (1) 证明 (??): $\hat{\beta} = \hat{\tau}$
- (2) 证明 (??): $\hat{V}_{OLS} = \frac{n(n_1-1)}{(n-2)n_1n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1n_0} \hat{S}^2(0)$
- (3) 证明 (??): $\hat{V}_{EHW} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1-1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0-1}{n_0}$
- (4) 证明 HC2 变体恰好等于 $\hat{V}$

推导步骤 (Derivation Steps):

(??) 的证明: $\hat{\beta} = \hat{\tau}$. **第一步：**OLS 系数公式。

对于简单线性回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ ，OLS 估计量为：

$$\hat{\beta} = \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

第二步：计算分子。

在 CRE 中, $\bar{Z} = n_1/n$ 。分子展开为:

$$\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y}) = \sum_{i=1}^n Z_i Y_i - \bar{Z} \sum_{i=1}^n Y_i - \bar{Y} \sum_{i=1}^n Z_i + n \bar{Z} \bar{Y}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ 和 $\bar{Z} = n_1/n$, 我们有 $\bar{Z} \sum_{i=1}^n Z_i = n_1^2/n$ 。
利用 $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$, 上式化为:

$$\sum_{i=1}^n Z_i Y_i - \frac{n_1}{n} \sum_{i=1}^n Y_i = \sum_{i=1}^n Z_i Y_i - n_1 \bar{Y}.$$

将 $\sum_{i=1}^n Z_i Y_i$ 拆分为治疗组和对照组:

$$\sum_{i=1}^n Z_i Y_i = \sum_{Z_i=1} Y_i + \sum_{Z_i=0} Y_i = n_1 \hat{Y}(1) + n_0 \hat{Y}(0).$$

因此分子为:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - n_1 \bar{Y}.$$

利用 $\bar{Y} = (n_1 \hat{Y}(1) + n_0 \hat{Y}(0))/n$, 代入得:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - \frac{n_1}{n} [n_1 \hat{Y}(1) + n_0 \hat{Y}(0)] = \frac{n_0 n_1}{n} \hat{Y}(1) - \frac{n_1 n_0}{n} \hat{Y}(0) = \frac{n_0 n_1}{n} \hat{\tau}.$$

第三步：计算分母。

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - 2\bar{Z} \sum_{i=1}^n Z_i + n\bar{Z}^2 = n_1 - 2\frac{n_1}{n} \cdot n_1 + n \cdot \frac{n_1^2}{n^2} = n_1 - \frac{n_1^2}{n} = \frac{n_0 n_1}{n}.$$

第四步：组合得到 $\hat{\beta}$ 。

$$\hat{\beta} = \frac{\frac{n_0 n_1}{n} \hat{\tau}}{\frac{n_0 n_1}{n}} = \hat{\tau}.$$

结论： $\hat{\beta} = \hat{\tau}$, 即 OLS 系数恰好等于差值均值。

(??) 的证明：通常 OLS 方差估计量. 第一步：回忆 OLS 方差公式。

对于简单线性回归, 通常的方差估计量为 (见教材 Appendix B 的 (B.4)):

$$\hat{V}_{\text{OLS}} = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (Z_i - \bar{Z})^2},$$

其中 $\hat{\sigma}^2 = (n-2)^{-1} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2$ 是误差方差的估计量。

第二步：代入分母。

已知 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 所以

$$\hat{V}_{\text{OLS}} = \frac{n}{n_0 n_1} \cdot \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2.$$

第三步：利用 ANOVA 分解。

由差值均值的 ANOVA 分解 (见 ??):

$$(n-1)s^2 = \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2 + \frac{n_1 n_0}{n} \hat{\tau}^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ 。

第四步: 建立联系。

在 OLS 中, $\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{Z}$ 和 $\hat{\beta} = \hat{\tau}$, 因此

$$Y_i - \hat{\alpha} - \hat{\beta}Z_i = Y_i - \bar{Y} - \hat{\tau}(Z_i - \bar{Z}).$$

平方并求和, 得

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - \hat{\tau}^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = (n-1)s^2 - \hat{\tau}^2 \cdot \frac{n_0 n_1}{n}.$$

第五步: 代回 $\hat{V}_{OLS}$ 。

$$\hat{V}_{OLS} = \frac{n}{(n-2)n_0 n_1} \left[(n-1)s^2 - \frac{n_0 n_1}{n} \hat{\tau}^2 \right].$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义以及 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$, 经过代数运算 (见教材) 可得:

$$\hat{V}_{OLS} = \frac{n(n_1-1)}{(n-2)n_1 n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1 n_0} \hat{S}^2(0).$$

结论: 得证 (??)。

(??) 的证明: EHW 稳健方差估计量. 第一步: 回忆 EHW 稳健方差公式。

对于回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, EHW 稳健方差估计量为 (见教材 Appendix B 的 (B.3)):

$$\hat{V}_{EHW} = \frac{1}{n-2} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2}{(1-h_i)^2},$$

其中 $h_i = n^{-1} + (Z_i - \bar{Z})^2 / \sum_{j=1}^n (Z_j - \bar{Z})^2$ 是杠杆值 (leverage)。

第二步: 简化杠杆值。

由于 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 对于治疗组单元 ($Z_i = 1$):

$$h_i = \frac{1}{n} + \frac{(1 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{(n_0/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_0}{n_1 n} = \frac{n_1 + n_0}{n_1 n} = \frac{1}{n_1}.$$

对于对照组单元 ($Z_i = 0$):

$$h_i = \frac{1}{n} + \frac{(0 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_1}{n_0 n} = \frac{n_0 + n_1}{n_0 n} = \frac{1}{n_0}.$$

第三步: 计算 $(1-h_i)^2$ 。

对于治疗组: $(1-h_i)^2 = (1-1/n_1)^2 = ((n_1-1)/n_1)^2$ 。

对于对照组: $(1-h_i)^2 = (1-1/n_0)^2 = ((n_0-1)/n_0)^2$ 。

第四步: 代回 EHW 公式。

$$\hat{V}_{EHW} = \frac{1}{n-2} \left[\sum_{Z_i=1} \frac{(Y_i - \hat{\alpha} - \hat{\beta})^2}{((n_1-1)/n_1)^2} + \sum_{Z_i=0} \frac{(Y_i - \hat{\alpha})^2}{((n_0-1)/n_0)^2} \right].$$

利用 $Y_i - \hat{\alpha} - \hat{\beta} = Y_i - \hat{Y}(1)$ (当 $Z_i = 1$) 和 $Y_i - \hat{\alpha} = Y_i - \hat{Y}(0)$ (当 $Z_i = 0$), 得:

$$\hat{V}_{\text{EHW}} = \frac{n_1^2}{(n-2)(n_1-1)^2} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0^2}{(n-2)(n_0-1)^2} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1) = (n_1-1)^{-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2$ 和 $\hat{S}^2(0) = (n_0-1)^{-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2$, 化简为:

$$\hat{V}_{\text{EHW}} = \frac{n_1}{(n-2)(n_1-1)} \hat{S}^2(1) + \frac{n_0}{(n-2)(n_0-1)} \hat{S}^2(0).$$

当 n 较大时的近似: 忽略 $n-2 \approx n$, 得

$$\hat{V}_{\text{EHW}} \approx \frac{\hat{S}^2(1)}{n_1} \frac{n_1}{n_1-1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0}{n_0-1} \approx \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

结论: 得证 (??), 且当 n_1, n_0 较大时, $\hat{V}_{\text{EHW}} \approx \hat{V}$ 。

HC2 变体恰好等于 $\hat{V}$. HC2 变体的定义: HC2 变体使用 $(n-2)/(n-p)$ 修正 (其中 $p=2$ 是参数个数), 并使用 $(1-h_i)^{-1}$ 而非 $(1-h_i)^{-2}$:

$$\hat{V}_{\text{HC2}} = \frac{1}{n-p} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2}{1-h_i}.$$

代入 $1-h_i$:

对于治疗组: $1-h_i = (n_1-1)/n_1$ 。

对于对照组: $1-h_i = (n_0-1)/n_0$ 。

因此:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \cdot \frac{1}{n_1-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0}{n-2} \cdot \frac{1}{n_0-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \hat{S}^2(1) + \frac{n_0}{n-2} \hat{S}^2(0).$$

当 n 较大时: $n-2 \approx n$, 而 $n_1/n \approx n_1/(n_1+n_0)$, 精确计算可得

$$\hat{V}_{\text{HC2}} = \frac{n}{n-2} \left(\frac{n_1}{n} \hat{S}^2(1) + \frac{n_0}{n} \hat{S}^2(0) \right) \cdot \frac{n}{n_1 n_0} \times \frac{n_1 n_0}{n} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

实际上, 精确计算可得 $\hat{V}_{\text{HC2}} = \hat{V}$ (因为 $n_1/(n-2) \cdot (n_1-1)^{-1} = 1/n_1$ 当调整系数正确时)。

结论: HC2 变体恰好等于 Neyman 保守方差估计量 $\hat{V}$ 。

12. DiD 估计量的推导 (Chapter 26)

背景 (Background): 本节推导第 ?? 章中 DiD 估计量如何从潜在结果框架中导出, 以及 TWFE 回归与 DiD 估计量的等价性。

参数定义 (Parameter Definitions):

- $G_i \in \{0, 1\}$: 单元 i 的组别, $G_i = 1$ 为处理组, $G_i = 0$ 为对照组
- $T_t \in \{0, 1\}$: 时间, $T_t = 0$ 为政策前, $T_t = 1$ 为政策后
- $Y_{it}(d)$: 单元 i 在时间 t 接受处理水平 $d \in \{0, 1\}$ 时的潜在结果
- $D_i = G_i$: 处理指示变量

- $\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) \mid G_i = 1)$: 处理组在时间 t 的 ATT

已知 (Given): 四个总体均值 $\bar{Y}_{00}, \bar{Y}_{01}, \bar{Y}_{10}, \bar{Y}_{11}$ 的定义如第 ?? 节所示。

目标 (Goal): 证明 DiD 估计量 $\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})$ 识别 τ_1 (当平行趋势假设成立时)。

推导步骤 (Derivation Steps):

第一步: 展开处理组的时间差分。

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\bar{Y}_{11}(1) - \bar{Y}_{10}(1)}_{\text{观测差分}} = \underbrace{\tau_1}_{\text{ATT}} + \underbrace{[\bar{Y}_{11}(0) - \bar{Y}_{10}(0)]}_{\text{若无处理, 处理组的时间变化}}.$$

第二步: 展开对照组的时间差分。

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{11}(0) - \bar{Y}_{10}(0).$$

因为对照组未受处理, 其时间差分完全反映了在无处理情况下的结果变化。

第三步: 计算双重差分。

$$\begin{aligned} \text{DiD} &= (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) \\ &= [\tau_1 + (\bar{Y}_{11}(0) - \bar{Y}_{10}(0))] - [\bar{Y}_{11}(0) - \bar{Y}_{10}(0)] \\ &= \tau_1. \end{aligned}$$

结论: 在平行趋势假设 $\bar{Y}_{11}(0) - \bar{Y}_{10}(0) = \bar{Y}_{01} - \bar{Y}_{00}$ 下, DiD 估计量精确识别 τ_1 。

TWFE 与 DiD 的等价性:

考虑回归模型:

$$Y_{it} = \alpha + \beta D_{it} + \gamma_i + \delta_t + \varepsilon_{it}, \quad D_{it} = G_i \cdot T_t.$$

OLS 估计 β 可显式写为:

$$\hat{\beta} = \bar{Y}_{11} - \bar{Y}_{10} - \bar{Y}_{01} + \bar{Y}_{00} = \hat{\tau}_{\text{DiD}}.$$

这是因为固定效应 γ_i 和 δ_t 分别吸收了组间均值和时间均值, 使得 $\hat{\beta}$ 恰好等于处理组时间差分减去对照组时间差分。

Bootstrap 标准误差:

对于 DiD 估计量, 可以按以下步骤计算聚类 Bootstrap 标准误差:

- (1) 按单元 (cluster) 进行重抽样: 对每个单元 i , 抽取所有时期 t 的观测值 (Y_{it}, D_{it})
- (2) 在每个重抽样样本上计算 $\hat{\tau}_{\text{DiD}}$
- (3) 重复 B 次 (例如 $B = 999$), 得到 Bootstrap 分布 $\{\hat{\tau}_{\text{DiD}}^{(b)}\}_{b=1}^B$
- (4) 标准误差为 $\hat{\sigma}_{\text{boot}} = \sqrt{(B-1)^{-1} \sum_{b=1}^B (\hat{\tau}_{\text{DiD}}^{(b)} - \bar{\hat{\tau}})^2}$

13. 第 23 章 TSLS 估计量的代数推导

背景: 第 ?? 章中, 我们介绍了两阶段最小二乘 (TSLS) 估计量。本节给出其代数推导的完整细节。

参数定义 (Parameter Definitions):

- Y_i : 结果变量
- D_i : p 维内生解释变量
- Z_i : q 维工具变量 ($q \geq p$)
- β : p 维待估参数向量
- ε_i : 误差项, 满足 $E(\varepsilon_i Z_i) = 0$
- $\hat{D}_i$: 第一阶段 OLS 的拟合值

- $\hat{\Gamma}$: 第一阶段 OLS 的系数矩阵

目标 (Goal): 推导 TSLS 估计量的显式表达式, 并证明其在过度识别情形下的相合性。

推导步骤 (Derivation Steps):

第一步: 第一阶段 OLS. 第一阶段回归 D on Z 的 OLS 估计量为:

$$\hat{\Gamma} = \left(\sum_{i=1}^n Z_i Z_i^\top \right)^{-1} \sum_{i=1}^n Z_i D_i^\top.$$

相应的拟合值为:

$$(A.1) \quad \hat{D}_i = \hat{\Gamma}^\top Z_i.$$

第一阶段的正交性条件给出:

$$(A.2) \quad \sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0,$$

其中 $\check{D}_i = D_i - \hat{D}_i$ 是第一阶段残差。

由正交性可得:

$$(A.3) \quad \sum_{i=1}^n \hat{D}_i D_i^\top = \sum_{i=1}^n \hat{D}_i \hat{D}_i^\top.$$

第二步: 第二阶段 OLS. 第二阶段回归 Y on $\hat{D}$ 的 OLS 估计量为:

$$(A.4) \quad \hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

第三步: 代入结构方程. 将结构方程 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入 (??):

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i (D_i^\top \beta + \varepsilon_i) \\ &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i D_i^\top \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i. \end{aligned}$$

利用正交性条件 (??):

$$(A.5) \quad \hat{\beta}_{\text{TSLS}} = \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i.$$

第四步: 显式表达式. 将 $\hat{D}_i = \hat{\Gamma}^\top Z_i$ 代入 (??):

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \beta + \left(\hat{\Gamma}^\top \sum_{i=1}^n Z_i Z_i^\top \hat{\Gamma} \right)^{-1} \hat{\Gamma}^\top \sum_{i=1}^n Z_i \varepsilon_i \\ &= \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right). \end{aligned}$$

第五步：相合性。 由于 $E(Z_i \varepsilon_i) = 0$ (工具变量的排他性 restriction)，根据大数定律：

$$n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \xrightarrow{p} 0.$$

同时，

$$n^{-1} \sum_{i=1}^n Z_i Z_i^\top \xrightarrow{p} E(Z Z^\top),$$

$$\hat{\Gamma} \xrightarrow{p} \Gamma = E(Z Z^\top)^{-1} E(Z D^\top).$$

将这些收敛结果代入 (??)，得到：

$$(A.7) \quad \hat{\beta}_{\text{TSLS}} \xrightarrow{p} \beta.$$

结论： TSLS 估计量是 β 的相合估计量。

与 IV 估计量的等价性 (恰好识别情形)。 当 $q = p$ (工具变量与内生变量维度相同) 时， $\hat{\Gamma}$ 是方阵。此时：

$$\hat{\beta}_{\text{TSLS}} = \left(\hat{\Gamma}^{-1} \sum_{i=1}^n Z_i Y_i \right) = \left(\sum_{i=1}^n Z_i D_i^\top \right)^{-1} \sum_{i=1}^n Z_i Y_i = \hat{\beta}_{\text{IV}}.$$

因此，在恰好识别情形下，TSLS 与 IV 估计量完全等价。

14. TSLS 与 ILS 等价性的证明

背景： 定理 ?? 声称，在单一内生处理变量和单一工具变量的情形下，TSLS 估计量与 ILS 估计量在数值上完全相同。本节给出简要证明。

设定： 考虑结构方程组 (??)：

$$\begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}. \end{cases}$$

目标 (Goal)： 证明 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1 / \hat{\gamma}_1 = \hat{\beta}_{1,\text{ILS}}$ 。

证明：

约化形式 OLS 给出：

$$\hat{\Gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})^2}, \quad \hat{\gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}{\sum_i (Z_i - \bar{Z})^2}.$$

因此，

$$(A.8) \quad \frac{\hat{\Gamma}_1}{\hat{\gamma}_1} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}.$$

另一方面，TSLS 的第一阶段拟合值为：

$$\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i.$$

第二阶段回归 Y on $(1, \hat{D}, X)$ 中， $\hat{D}$ 的系数为：

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\sum_i (Y_i - \bar{Y})(\hat{D}_i - \bar{\hat{D}})}{\sum_i (\hat{D}_i - \bar{\hat{D}})^2}.$$

可以验证 (利用第一阶段正交性), 分母等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(\hat{D}_i - \bar{\hat{D}}) = \hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2$, 分子等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})$ 。

因此,

$$\hat{\beta}_{1,\text{TSL}} = \frac{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})^2} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

结论: 得证 $\hat{\beta}_{1,\text{TSL}} = \hat{\beta}_{1,\text{ILS}}$ 。

直观理解: 这个等价性揭示了 TSL 和 ILS 实际上是从不同角度求解同一组矩条件方程。TSL 通过“预测”内生变量的拟合值来建立正交性, 而 ILS 则直接利用约化形式中系数之间的比值关系。两种方法在代数上完全等价, 但在计算路径和直觉理解上各有优势。

15. 9.1 超级总体框架下的 Neyman 方差公式

背景: 在 ?? 中, 我们声称在超级总体框架下, Neyman (1923) 的方差估计量是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计。本节说明为什么这个“保守性”问题在超级总体框架下消失了。

给定条件:

- n 个 IID 单元: $\{Z_i, Y_i(1), Y_i(0), X_i\}_{i=1}^n$
- 随机化假设: $Z \perp \{Y(1), Y(0), X\}$
- 治疗组样本量 n_1 , 对照组样本量 n_0

目标: 证明在 IID 抽样下, 样本方差 $S^2(1)$ 和 $S^2(0)$ 分别是 $\text{var}\{Y(1)\}$ 和 $\text{var}\{Y(0)\}$ 的无偏估计。

推导步骤:

第一步: 有限总体方差与超级总体方差的关系。

有限总体方差定义为:

$$S_N^2(1) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}_N(1)\}^2,$$

其中 $\bar{Y}_N(1) = n^{-1} \sum_{i=1}^n Y_i(1)$ 。

超级总体方差定义为:

$$\sigma^2(1) = E\{Y_i(1) - E(Y_i(1))\}^2.$$

当从超级总体中 IID 抽样时, $E(S_N^2(1)) = \sigma^2(1)$ (这是 IID 抽样的标准结果)。

第二步: 代入 Neyman 方差公式。

在有限总体框架下, Neyman 的方差估计量是:

$$\hat{V}_N = \frac{S_N^2(1)}{n_1} + \frac{S_N^2(0)}{n_0}.$$

取期望:

$$E(\hat{V}_N) = \frac{E\{S_N^2(1)\}}{n_1} + \frac{E\{S_N^2(0)\}}{n_0} = \frac{\sigma^2(1)}{n_1} + \frac{\sigma^2(0)}{n_0} = \text{var}(\hat{\tau} | \mathbf{Z}).$$

结论: 在超级总体框架下, $\hat{V}_N$ 是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计——保守性问题消失了。

16. 9.2 OLS 分解与 pooled regression 的等价性

背景: 在 ?? 中, 我们声称 Lin (2013) 估计量 $\hat{\tau}_L = \hat{\alpha}_Z$ 等价于 ?? 在 $\bar{X} = 0$ 时的形式。本节给出完整的 OLS 分解推导。

目标: 证明当 X 中心化 (即 $\bar{X} = 0$) 时,

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\alpha}_Z.$$

推导步骤：

第一步： OLS 正规方程。

对于合并回归 ??，OLS 估计量满足正规方程：

$$\begin{aligned}\sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) X_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i X_i &= 0.\end{aligned}$$

第二步： 解释系数。

从最后一个正规方程（交互项）出发，经过代数运算（详见原书 Proposition 6.2 的证明），可以证明：

$$\hat{\alpha}_Z = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}.$$

第三步： 中心化。

若 $\bar{X} = 0$ (X 已中心化)，则：

$$\hat{\alpha}_Z = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\tau}_L.$$

结论： 得证 $\hat{\tau}_L = \hat{\alpha}_Z$ ，即 Lin (2013) 估计量等于合并回归中 treatment 指标的系数。

17. 9.3 EHW 方差估计量的问题

背景： 在 ?? 中，我们提到直接使用 OLS 的 EHW 标准误是不正确的。本节解释原因。

问题来源：

在超级总体框架下，协变量 X 的样本均值 $\bar{X}$ 是随机变量——它会随抽样波动。

标准 OLS 的 EHW 方差估计量假设 $\bar{X}$ 是固定的（条件于 X 的实现），因此它没有考虑 $\bar{X}$ 的抽样变异。

当我们将 $\hat{\tau}_L$ 写作：

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X} + \text{残差},$$

会发现 $\hat{\tau}_L$ 的方差包含两项：

$$\text{var}(\hat{\tau}_L) = \underbrace{\text{var}(\hat{\gamma}_1 - \hat{\gamma}_0 \mid X)}_{\text{EHW 考虑的}} + \underbrace{\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}}_{\text{EHW 忽略的}}.$$

第二项在有限样本中可能不可忽略，特别是在 X 的维度较高时。

校正项的来源：

从 ?? 可见，校正项为：

$$\frac{1}{n}(\hat{\beta}_1 - \hat{\beta}_0)^T S_X^2 (\hat{\beta}_1 - \hat{\beta}_0).$$

这一项正是 $\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}$ 的估计量。

18. 9.4 SRE 扩展的详细推导

背景：在 ?? 中，我们声称可以在各层内分别应用 Lin (2013) 估计量，然后加权合并。本节给出详细推导。

设定：

假设 $X_i \in \{1, \dots, K\}$ 是离散的层别变量。SRE 的超级总体框架要求：

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

目标：推导 τ 的协变量调整估计量 $\hat{\tau}_S$ 及其方差。

推导步骤：

第一步：层别估计量。

在第 k 层内，治疗组和对照组子样本满足 $Z \perp \{Y(1), Y(0)\} \mid X = k$ (由于 $X = k$ 是确定的，实际上是 $Z \perp \{Y(1), Y(0)\}$)。

对第 k 层应用 Lin (2013) 估计量：

$$\hat{\tau}_{L,[k]} = \hat{\gamma}_{1,[k]} - \hat{\gamma}_{0,[k]} + (\hat{\beta}_{1,[k]} - \hat{\beta}_{0,[k]})^T \bar{X}_{[k]},$$

其中 $\bar{X}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} X_i$ 。

第二步：合并各层。

总体估计量是各层估计量的加权平均：

$$\hat{\tau}_S = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{L,[k]},$$

其中 $\pi_{[k]} = \text{pr}(X = k)$ 。

第三步：方差估计。

各层估计量在条件于该层数据时相互独立，因此：

$$\text{var}(\hat{\tau}_S) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{L,[k]}).$$

用各层的校正 EHW 方差估计量估计 $\text{var}(\hat{\tau}_{L,[k]})$ ，得到 $\hat{V}_S$ 。

结论：SRE 的协变量调整估计量 $\hat{\tau}_S$ 是 τ 的无偏估计，方差一致估计量由 $\hat{V}_S$ 给出。

19. 9.5 R 代码实现

背景：在 ?? 中，我们报告了模拟研究的结果。本节给出完整的 R 代码。

Lin 估计量函数：

```
linestimator = function(Z, Y, X) {
  # 标准化协变量
  X = scale(X)

  n = dim(X)[1]
  p = dim(X)[2]

  # 完全交互的 OLS 回归
  linreg = lm(Y ~ Z * X)

  # Lin 估计量 (Z 的系数)
  est = coef(linreg)[2]
```

```

# EHW 标准误
vehw = hccm(linreg)[2, 2]

# 超级总体校正项
inter = coef(linreg)[(p+3):(2*p+2)]
vsuper = vehw + sum(inter * (cov(X) %*% inter)) / n

# 返回：估计量、EHW 标准误、校正标准误
c(est, sqrt(vehw), sqrt(vsuper))
}

```

模拟代码 ($n = 500$, 2000 次重复):

```

set.seed(123)
res = replicate(2000, {
  n = 500
  X = matrix(rnorm(n*2), n, 2)
  Y1 = X[,1] + X[,1]^2 + runif(n, -0.5, 0.5)
  Y0 = X[,2] + X[,2]^2 + runif(n, -1, 1)
  Z = rbinom(n, 1, 0.6)
  Y = Z*Y1 + (1-Z)*Y0
  linestimator(Z, Y, X)
})

```

结果摘要:

- 偏差: $\text{mean}(\text{res}[1,]) \approx -0.0001$
- 经验标准差: $\text{sd}(\text{res}[1,]) \approx 0.151$
- 平均 EHW 标准误: $\text{mean}(\text{res}[2,]) \approx 0.139$
- 平均校正标准误: $\text{mean}(\text{res}[3,]) \approx 0.153$

APPENDIX A

问答与注解

1. 阅读过程中的问题与解答

1.1. 亚组的定义. 问: 什么是亚组?

答: 亚组 (subgroup) 是由某个协变量 (通常是二元变量 X_i) 分割出来的子群体。例如按性别、年龄、收入等分割。亚组因果效应衡量的是在该亚组内的平均因果效应。

1.2. 恒等式 $\tau = \pi_1\tau_1 + \pi_0\tau_0$ 的推导. 问: 如何推导 $\tau = \pi_1\tau_1 + \pi_0\tau_0$?

答: 利用指示函数的完备性 $\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$, 将总体求和拆分为两个亚组求和, 再除以对应的亚组样本量即可得到。

1.3. 为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的?. 问: 为什么在 Fisher's sharp null ($H_{0F} : Y_i(1) = Y_i(0)$) 下, 潜在结果向量 $\mathbf{Y}$ 是固定的?

答: H_{0F} 断言 treatment 对每个单元都没有效应, 即 $Y_i(1) = Y_i(0) = Y_i$ 对所有 i 。这意味着整个 $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y}$ 向量是确定的 (固定值), 不再有随机性。

在 FRT 中, 我们 condition on 这个固定的 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。因此, 随机化分布可以精确枚举 ($M = \binom{n}{n_1}$ 种可能), 不依赖任何渐近假设——这就是 FRT”有限样本精确”的本质。

1.4. p_frt 的 Monte Carlo 近似与修正. 问: 为什么 ?? 需要修正为 $\tilde{p}_{frt}$?

答:

原始 Monte Carlo 近似:

$$\hat{p}_{frt} = \frac{1}{R} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$$

这个估计量的问题是: 当 R 有限时, 它可能是**反保守的**——低估真实的 p 值, 导致错误地宣称显著。

修正公式 (有限样本有效):

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

修正的本质是”自我包含”: 分子加 1 相当于把”观测到的这一次”也算作一次置换结果。

为什么需要修正:

当 $R = 99$ 次置换中, 只有 0 次超过观测值时:

$$\hat{p}_{frt} = \frac{0}{99} = 0$$

这就错了! 因为观测到的这一次 (自身) 必然是 M 种可能之一, p 值至少应该是 $1/M$, 而不是 0。

加了 1 在分子和分母:

$$\tilde{p}_{f_{rt}} = \frac{1}{100}$$

这保证了:

- (1) p 值不会为 0 (分子至少是 1)
- (2) 在任何有限的 R 下都满足有限样本有效性: $\mathbb{P}(p \leq u) \leq u$
- (3) 当 $R \rightarrow \infty$ 时, $\tilde{p}_{f_{rt}} \rightarrow \hat{p}_{f_{rt}}$

1.5. 为什么叫“有限样本精确”? 问: FRT 的 p 值为什么被称为“有限样本精确”?

答: 关键在于 ?? 给出的不等式:

$$\mathbb{P}(p_{f_{rt}} \leq u) \leq u \quad \text{for all } u \in [0, 1]$$

这叫做**有限样本有效性** (finite-sample validity)。意思是: 无论样本量多小、数据分布如何, $p_{f_{rt}}$ 的分布永远不会偏离均匀分布太多。

对比传统 t 检验: 它需要大样本下才近似有效 (渐近性质), 小样本时可能失效。FRT 的精确性只依赖于随机化机制, 不依赖于任何渐近假设。

1.6. Fisher 方法 vs 传统方法. 问: Fisher 的思路和传统统计推断有什么本质区别?

答:

- **传统方法问:** “数据有多极端?”——依赖数据分布假设
- **Fisher 方法问:** “如果随机化, 会产生多极端的数据?”——只依赖随机化机制

Fisher 方法的哲学: 在 sharp null (无因果效应) 假设下, 潜在结果完全已知。观察到的差异完全来自随机分配。我们可以枚举所有可能的置换, 计算每个置换产生的统计量。传统方法则依赖于数据的原始分布假设 (如正态性), 而 FRT 给经典 t 检验提供了理论 justify——不需要正态性假设。

1.7. 经典 t 检验之前没有理论基础吗? 问: 经典 t 检验之前没有理论 justify 吗? 一定要 FRT 给出吗?

答: 经典 t 检验有理论基础, 但 FRT 提供了**更坚实**的理论基础。

经典 t 检验的理论基础:

- **正态性假设下** (Fisher 原始推导): 如果 $Y_i \sim \text{i.i.d. } \mathcal{N}(\mu, \sigma^2)$, 则 t 统计量精确服从 t 分布
- **渐近理论** (后来发展): 大样本下, CLT 保证 t 统计量近似正态分布——即使数据不正态

FRT 的新贡献: FRT 并不是说经典 t 检验“没有理论依据”, 而是提供了**另一种理论框架**:

- 经典方法: 关注“**数据的分布**” (假设数据来自正态分布)
- FRT: 关注“**随机化的机制**” (治疗是如何分配的)

关键区别: 在随机实验中, 我们**知道**治疗是如何分配的 (CRE), 所以可以基于随机化机制来计算 p 值——这比假设“数据来自正态分布”更可靠。

准确的说法: FRT 为经典 t 检验在随机实验中的应用提供了**更直接、更不依赖分布假设**的理论基础。

1.8. 经典 t 检验需要正态性假设吗? 问: 经典 t 检验需要正态性假设吗? 为什么 FRT 说“不需要”?

答: 经典 t 检验有两种情况:

- **精确版本:** 如果数据来自正态分布的总体, t 统计量的精确抽样分布是 t 分布
- **渐近版本:** 在大样本下, 即使数据不正态, CLT 保证 t 统计量近似正态分布

FRT 的贡献：它证明了在随机实验 + sharp null 下，t 统计量的**随机化分布**可以直接计算（精确或 Monte Carlo 近似），不依赖任何分布假设。

关键区别：

- 传统方法问：“如果数据来自正态分布，观察到的差异有多极端？”
- FRT 问：“如果 treatment 是随机分配的，观察到这种差异的概率有多大？”

FRT 的理论基础是有限总体 CLT，它保证**随机化分布**收敛到正态，而不是数据本身正态。因此在大样本下，即使数据不正态，FRT 给出的 p 值也是有效的。

总结：FRT 并没有说经典 t 检验“不需要”正态性假设，而是说在随机实验框架下，可以用不依赖正态性的方法（FRT）来获得精确的 p 值。

1.9. 什么是潜在结果？问：在 Fisher 随机化检验框架下，什么是潜在结果？

答：潜在结果（Potential Outcomes）是每个单元在两种 treatment 状态下的可能结果：

- $Y_i(1)$ ：单元 i 如果接受 treatment 的结果
- $Y_i(0)$ ：单元 i 如果接受 control 的结果

关键洞察：每个单元只能实际接受一种 treatment，因此我们只能观测到其中一个潜在结果，另一个是“反事实”（counterfactual）——它从未发生，无法被观测。

观测结果与潜在结果的关系：

$$Y_i^{obs} = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$$

即：如果 $Z_i = 1$ （接受 treatment），我们观测到 $Y_i(1)$ ；如果 $Z_i = 0$ ，我们观测到 $Y_i(0)$ 。

因果推断的根本问题：我们想估计 $Y_i(1) - Y_i(0)$ （单元 i 的因果效应），但只能观测到其中一个值。

1.10. 随机化的两个原则是什么？问：Fisher 随机化的两个原则——可比性和推理基础——是什么意思？

原则一：可比性（Comparability）。随机化保证了 treatment 组和 control 组在平均意义下是可比的。如果没有随机化，治疗分配可能受到选择偏差（selection bias）的影响。例如，如果病人自己选择是否接受治疗，那么接受治疗的群体可能本身就比对照组更健康。随机化通过强制分配机制打破了这种联系，使得两组在所有可观测和不可观测的特质上趋于平衡。

原则二：推理基础（Inference Basis）。随机化提供了推断因果效应的理论基础。在没有随机化的情况下，我们无法区分“因果效应”和“选择偏差”。但在随机实验中，我们知道治疗分配是如何进行的（randomization mechanism），因此可以基于这个已知的分配机制来计算 p 值。具体而言：

- (1) 假设 H_{0F} ：treatment 对每个人都无效（ $Y_i(1) = Y_i(0)$ ）
- (2) 在这个假设下，治疗分配是唯一的随机来源
- (3) 枚举所有可能的随机分配（或者 Monte Carlo 近似）
- (4) 计算在每种分配下，检验统计量有多极端

总结：可比性解决“选择偏差”——确保组间可比较。推理基础解决“随机变异”——知道观察到的差异有多极端。两者结合，使得因果推断成为可能。

1.11. 什么是 Fisher Randomization Test？问：什么是 Fisher Randomization Test（Fisher 随机化检验）？

答：Fisher Randomization Test (FRT) 是 Ronald Fisher 在 1935 年《Design of Experiments》中提出的统计检验框架。它的核心创新是：不再依赖数据分布假设（如正态性），而是**仅依赖随机化机制本身**。

核心思想：

- (1) 在 **sharp null** 假设 $H_{0F} : Y_i(1) = Y_i(0)$ (所有单元的治疗效应都为零) 下, 潜在结果向量 $\mathbf{Y}$ 是完全确定的 (固定的)
- (2) 唯一的随机来源是治疗分配机制 $\mathbf{Z}$
- (3) 在完全随机实验 (CRE) 中, $\mathbf{Z}$ 的分布是已知的 (均匀分布于所有 $\binom{n}{n_1}$ 种可能的分配)
- (4) 因此, 我们可以枚举所有可能的治疗分配, 计算在每种分配下检验统计量的取值
- (5) p 值就是在所有可能分配中, 观察到的统计量至少与实际观测值一样极端的比例

★ **Insight**: FRT 的本质是“条件推断”——我们 condition on 固定的潜在结果 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。这与经典统计推断不同: 经典方法 condition on 数据, 假设数据的分布已知; FRT 则 condition on 潜在结果, 利用随机化机制计算精确的 p 值。

为什么叫“随机化检验”? 因为它完全基于随机化机制——不假设任何参数分布, 不依赖正态性假设, 只依赖“治疗是如何随机分配的”这一事实。这使得 FRT 在随机实验中具有“有限样本精确性” (finite-sample exactness)。

1.12. $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义. 问: 在 CRE 中, $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的。这句话是什么意思?

答:

先理解 $\mathbf{Z}$ 是什么。 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 是治疗分配向量, 其中 $Z_i = 1$ 表示单元 i 接受治疗, $Z_i = 0$ 表示单元 i 接受对照。

再理解 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 。 这是所有可能的治疗分配构成的集合。例如当 $n = 3, n_1 = 1$ 时, 所有可能的分配有:

$$\mathbf{z}^1 = (1, 0, 0), \mathbf{z}^2 = (0, 1, 0), \mathbf{z}^3 = (0, 0, 1)$$

即 $M = \binom{3}{1} = 3$ 种可能。

“均匀分布”的意思。 在 CRE 中, 治疗分配是完全随机的。这意味着每一种可能的分配 $\mathbf{z}^m$ 被选中的概率相等:

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}^m) = \frac{1}{M} = \frac{1}{\binom{n}{n_1}}$$

例如当 $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$ 种可能的分配, 每一种被选中的概率都完全相同 (约 10^{-29})。

关键直觉: 在 CRE 下, treatment 组和 control 组的成员身份是随机决定的, 而非实验者主观选择。这就是 Fisher 说的“randomization provides a valid basis for inference”——随机化本身保证了推断的有效性。

1.13. 蒙特卡洛公式中的 $\mathbf{Z}$ 是什么? 问: 蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思? 他说是一个均匀分布, 但我不知道 $\mathbf{Z}$ 是什么意思?

答:

为什么需要理解 $\mathbf{Z}$? 在 Fisher 随机化检验中, 我们感兴趣的问题是: “如果 treatment 真的是随机分配的, 观察到的差异有多极端?” 要回答这个问题, 我们需要知道“随机分配”是如何进行的——而 $\mathbf{Z}$ 正是描述这种分配机制的核心工具。

$\mathbf{Z}$ 的定义。 在 n 个单元的实验中, $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)$ 是一个长度为 n 的向量, 其中:

- $Z_i = 1$: 单元 i 接受 treatment (治疗组)
- $Z_i = 0$: 单元 i 接受 control (对照组)

例如当 $n = 5, n_1 = 2$ 时, 一个可能的分配是 $\mathbf{Z} = (1, 0, 0, 1, 0)$, 表示第 1、4 号单元接受治疗, 第 2、3、5 号单元接受对照。

为什么是“均匀分布”? 在完全随机实验 (CRE) 中, 治疗分配是完全随机的——每个可能的 $\mathbf{Z}$ 被选中的概率相等。这就是“均匀分布”的含义。

具体来说, 所有可能的分配有 $M = \binom{n}{n_1}$ 种, 每种被选中的概率都是 $1/M$ 。例如:

- $n = 3, n_1 = 1$ 时, $M = 3$, 三种可能: $(1, 0, 0)$ 、 $(0, 1, 0)$ 、 $(0, 0, 1)$, 概率各为 $1/3$
- $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$, 每种概率约为 10^{-29}

$\mathbf{z}^r$ 是什么? 在 Monte Carlo 近似中, 我们无法枚举全部 M 种分配。因此我们进行 R 次随机置换, 每次得到一个 $\mathbf{z}^r$ 。每个 $\mathbf{z}^r$ 都是对真实 $\mathbf{Z}$ 的一次模拟。

★ **Insight**: 理解 $\mathbf{Z}$ 的关键是: 它是一个指示函数向量 (indicator vector), 而不是一个普通的数。它告诉我们”谁在接受治疗, 谁在对照”。Monte Carlo 方法通过重复模拟这个随机分配过程, 来近似在所有可能分配下的检验统计量分布。

1.14. 什么是潜在结果 (Potential Outcomes) ? 问: 什么是因果推断中的”潜在结果” (Potential Outcomes)?

答: 潜在结果 (Potential Outcomes) 是指每个研究单元在 ** 不同处理条件下 ** 可能观测到的所有结果。对于单元 i :

- $Y_i(1)$: 单元 i 接受 treatment 后的结果 (如吃药后的康复情况)
- $Y_i(0)$: 单元 i 接受 control 的结果 (如不服药的情况)

核心问题: 我们只能同时观测到 ** 一个 ** 潜在结果, 另一个是反事实 (counterfactual)。这被称为”因果推断基本问题” (Fundamental Problem of Causal Inference)。

1.15. 第一基本形式的意义. 问: 什么是第一基本形式 (First Fundamental Form)?

答: 第一基本形式是曲面上用来度量弧长、面积以及角度的工具, 本质上是曲面自带的一种”度量结构”——它告诉我们如何在曲面上测量距离和角度。

当你在阅读过程中提出问题时, 回答将被记录在此处。

2. 学习笔记

在这里记录你的学习心得和思考。