

$y T w \ f l$

$S 2 M ; . B M ;$

*QM i2Mib

„ý ÓDÀ•	N
„ý ÓDÀ•	N
RX9•	N
kXÓDK19 ²	N
jX € •I'	Ry
9XĐ ^åĐ-Â \$©M	Ry
8XKÔ"S	Ry
*? Ti2` RM1Ÿa1óĐ umH2@aBKTbQM	RR
RX'c•,	RR
kX ¹ I ¹ f ñ Û5“×1	RR
jX M1ŸĐyTŸ¥uY	RR
9X=» óVĐ1ó	RR
8X umH2@aBKTbQM	Rk
eXÊM1""Đ umH2@aBKTbQM	Rk
dX G GQM/2ìÆì Û5	Rj
3XÕB j¥eåL	Rj
NX'cl ² Đ/«ç á	Rj
RyX5	Rj
*? Ti2` j>† Û L Đn : Û Ä _	kj
RXV. ² T•Ož Û L Û5¥ ÷	kj
kX 6B¥72n` Û Ä¥ ñđ5	kj
jX >† Û L ¥çl	kj
9X a? `T LhDH6_h†	k9
8X Û ÄsfĐÚ' T	k9
eX JQM i2 í»`HQ	k8
dX_ d9 ¥?SÊ4	k8
3X 6_d.d i_ ¥1"	jk
NX G GQM/Äè	jk
RyXÂN\$H£ Û L ¥ ÷	jk
RRX a? `TL LmÂH W	jj
RkXcl ²	jj
RjX5	jj
*? Ti2` 9X L2vK M'BwM	j8
RX Õw }Đ¥ Ä	j8
kXµK98	j8
jX Bñ1o„Ø	je

重要含义：即使 $\rho_{YZ} > 0$ ，偏相关系数 $\rho_{YZ|X}$ 仍可能为负！这正是正态随机向量情形下的 Yule-Simpson 悖论。

7. LaLonde 数据与规格搜索问题

LaLonde 数据集包含参与职业培训项目 (National Supported Work Demonstration) 的参与者的结果。在观察性研究中，协变量选择的敏感性是一个重要问题。

当我们运行 $2^{10} = 1024$ 种可能的协变量子集回归时，treatment 系数的显著性可能对模型规格高度敏感。这提醒我们：在观察性研究中，规格搜索可能导致误导性结论。

8. 种族歧视的简历实验

Bertrand and Mullainathan (2004) 通过随机改变简历上的名字来研究种族歧视。这些名字被设计成听起来像非裔美国人或白人的名字。实验显示，有黑人名字的简历回调率显著较低。

当我们分别对男性和女性进行分析时，可能会发现有趣的亚组差异——这进一步说明“平均效应”可能掩盖了重要的异质性。

9. 本章小结与下节预告

本章的核心要点：

- (1) **相关性 $\neq$ 因果性：**观察到的关联可能是由于混杂因素造成的
- (2) **关联度量：**RD、RR、OR 及它们与独立性的关系
- (3) **Yule-Simpson 悖论：**总体关联可能与分层关联方向相反
- (4) **偏相关：**即使边际相关为正，偏相关仍可能为负
- (5) **因果推断的必要性：**我们需要系统性的方法来区分真实的因果效应

下一章我们将学习因果推断的基石——**潜在结果框架 (Potential Outcomes Framework)**，这将为我们的因果分析提供坚实的数学基础。

10. 习题

练习 1.1. 1.1 独立性命题的证明 证明 Proposition 1.1 中的命题 (1) 和 (2)。

练习 1.2. 1.2 Yule-Simpson 悖论的更多例子

- (1) 给出一个 $2 \times 2 \times 2$ 列联表的数值例子，其中出现 Yule-Simpson 悖论。
- (2) 找一个现实生活中的 Yule-Simpson 悖论例子。

练习 1.3. 1.3 相关与偏相关 考虑三维正态随机向量 $(X, Y, Z)^T \sim N(\mathbf{0}, \Sigma)$ 。

证明偏相关系数公式 (见 Proposition 1.2)。

给出一个 $\rho_{YZ} > 0$ 但 $\rho_{YZ|X} < 0$ 的数值例子。

注：这是正态随机向量情形下的 Yule-Simpson 悖论。

练习 1.4. 1.4 规格搜索 重做 Hainmueller (2012) 的数据分析。使用结局 `re78` 和治疗 `treat`。数据集还包含 10 个协变量，共有 $2^{10} = 1024$ 种可能的协变量子集组合。运行所有可能的线性回归子集，并报告 treatment 系数的分布：有多少是正显著、负显著、不显著的？

练习 1.5. 1.5 种族歧视的进一步分析 重做 Bertrand and Mullainathan (2004) 的简历数据分析。分别对男性和女性进行分析，讨论亚组分析的结果与总体结论的差异。

练习 1.6. 1.6 推荐阅读 **推荐阅读**：？是关于 *Berkeley* 录取数据悖论的原始论文。？从因果推断角度重新审视了该研究。

历史注记：？是统计因果推断领域的经典综述文章，它推广了“*Rubin* 因果模型”这一名称。在 *UC Berkeley*，我们称之为“*Neyman* 模型”——原因显而易见。

CHAPTER 2

潜在结果框架

1. 从相关到因果：为什么关联不够？

在第一章中，我们见证了一个令人不安的现象：Yule-Simpson 悖论向我们展示了关联可以与因果相悖。两组数据分别显示的正向效应，在合并后可能变为负向——这警告我们，从关联推断因果是危险的。

但我们不禁要问：关联毕竟是我们能观察到的，而因果是我们真正想知道的。那么，因果效应能否被清晰地定义，甚至被估计？

这个问题引导我们走向一个优雅而强大的框架——潜在结果框架 (Potential Outcomes Framework)，也被称为 Neyman-Rubin 因果模型。

这个框架的起源可以追溯到 Neyman 在 1923 年的开创性工作，以及 Rubin 在 1970 年代对其的进一步发展。它的核心思想其实出奇地简单：要谈论因果，我们必须想象 (counterfactual) 如果事情有所不同会发生什么。

2. 一个思想实验

让我们从一个最简单的场景开始：假设我们想研究某种新药对患者康复的因果效应。

考虑第 i 个患者。我们记：

- $T_i = 1$ ：患者接受了治疗
- $T_i = 0$ ：患者未接受治疗（对照组）

现在，关键的问题来了：这个患者的结果会是什么？

在现实中，我们只能观察到一种情况——要么患者接受了治疗，要么没有。但为了谈论因果，我们必须同时考虑两种可能性：

- $Y_i(1)$ ：如果患者接受治疗，会观察到的结果
- $Y_i(0)$ ：如果患者未接受治疗，会观察到的结果

这里， $Y_i(1)$ 和 $Y_i(0)$ 就是**潜在结果**——它们描述了在不同治疗状态下可能发生的结果，但我们永远无法同时观察到两者。

注 2.1 (注 2.1 —什么是反事实). **反事实** (counterfactual) 指的是未被观测到的潜在结果。具体而言：

- 对于治疗组个体 i ($T_i = 1$)，我们观察到 $Y_i(1)$ ，而 $Y_i(0)$ 是反事实
- 对于对照组个体 i ($T_i = 0$)，我们观察到 $Y_i(0)$ ，而 $Y_i(1)$ 是反事实

正因为潜在结果框架讨论的是“如果接受相反治疗会怎样”，所以它也被称为**反事实框架** (counterfactual framework)。

注 2.2. **为什么叫“潜在”结果？**：因为它们描述的是“如果... 会怎样”的情形，这种结果是“潜在的”而非“现实的”。这正是 counterfactual (反事实) 思维的本质。

3. 科学表 (Science Table)

？将潜在结果组成的 $n \times 2$ 矩阵称为**科学表** (Science Table)：

i	$Y_i(1)$	$Y_i(0)$
1	$Y_1(1)$	$Y_1(0)$
2	$Y_2(1)$	$Y_2(0)$
$\vdots$	$\vdots$	$\vdots$
n	$Y_n(1)$	$Y_n(0)$

这个表包含了所有我们需要知道的关于因果效应的信息——但问题是，我们永远只能观察到每一行的其中一个值。

4. 个体因果效应

有了潜在结果，我们终于可以清晰地定义因果效应了。

对于个体 i ，定义**个体因果效应** (Individual Treatment Effect, ITE) 为：

$$\tau_i = Y_i(1) - Y_i(0)$$

这是治疗相对于对照的“净效果”。

但是，这里出现了一个根本性的困难。1923 年，Jerzy Neyman 在一篇关于田间试验的论文中首次明确指出了这个问题：

对于每个个体，我们只能观察到一种潜在结果——实际发生的那种。另一种潜在结果是潜在的、永不可见的。

这被称为**因果推断的根本问题** (Fundamental Problem of Causal Inference)。

注 2.3. **为什么这个困难如此根本？**：因为科学上感兴趣的大多数因果问题，都涉及将现实与反事实进行比较。我们可以问“这种药对这个患者有效吗？”——但这个问题要求我们同时知道患者吃药和不吃药的结果，而这是不可能的。

5. 平均因果效应

既然个体因果效应不可测量，我们退而求其次，关注**平均因果效应** (Average Causal Effect, ACE)：

$$(2.1) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0)$$

用更精确的有限总体记号：¹

$$(2.2) \quad \tau = \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} = \frac{1}{n} \sum_{i=1}^n Y_i(1) - \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

一个关键恒等式：平均因果效应等于个体因果效应的均值：

$$(2.3) \quad \tau = \bar{Y}(1) - \bar{Y}(0) = \frac{1}{n} \sum_{i=1}^n \tau_i$$

¹推导见附录 section 15.1

6. 亚组与亚组因果效应

亚组 (subgroup) 是由某个协变量（通常是二元变量 X_i ）分割出来的子群体。例如：

- 按性别分割：男性亚组 ($X_i = 1$) 和女性亚组 ($X_i = 0$)
- 按年龄分割：老年人/年轻人
- 按收入分割：高收入/低收入

亚组因果效应 (Subgroup Causal Effect) 衡量的是在该亚组内的平均因果效应：²

$$(2.4) \quad \tau_x = \frac{\sum_{i=1}^n \mathbb{I}(X_i = x) \{Y_i(1) - Y_i(0)\}}{\sum_{i=1}^n \mathbb{I}(X_i = x)}, \quad (x = 0, 1)$$

7. 亚组因果效应与 Yule-Simpson 悖论的不存在

一个重要的恒等式揭示了亚组因果效应与总体因果效应的关系：³

$$(2.5) \quad \tau = \pi_1 \tau_1 + \pi_0 \tau_0$$

其中 $\pi_x = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = x)$ 是 $X_i = x$ 的单元比例。

关键推论：如果 $\tau_1 > 0$ 且 $\tau_0 > 0$ ，则必有 $\tau > 0$ 。因此，Yule-Simpson 悖论在因果效应层面不可能发生！

这澄清了第一章的困惑：在关联层面出现的悖论，在因果层面并不存在——因为因果效应是可分解的，而关联并非如此。

8. 治疗分配机制与基本恒等式

设 T_i 是单元 i 的二元治疗指示变量，观测结果 Y_i 是潜在结果和治疗分配的函数：

$$\begin{aligned} (1) \quad Y_i &= \begin{cases} Y_i(1), & \text{if } T_i = 1 \\ Y_i(0), & \text{if } T_i = 0 \end{cases} \\ (2) \quad &= T_i Y_i(1) + (1 - T_i) Y_i(0) \\ (3) \quad &= Y_i(0) + T_i \{Y_i(1) - Y_i(0)\} \\ (4) \quad &= Y_i(0) + T_i \tau_i \end{aligned}$$

？将 eq. (2) 视为潜在结果与观测结果之间的**基本桥梁**。这些方程强调了个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 可能在不同单元间存在异质性。

9. SUTVA：使框架有效的必要假设

使用潜在结果框架需要一些技术性假设。其中最重要的是**稳定单位治疗值假设 (Stable Unit Treatment Value Assumption, SUTVA)**。

假设 2.1 (无干扰). 单元 i 的潜在结果不依赖于其他单元的治疗分配。这有时被称为**无干扰假设**。

假设 2.2 (一致性). 治疗水平没有其他版本。等价地，我们要求治疗水平是良好定义的，至少对关注的结局是如此。这有时被称为**一致性假设**。

假设 2.3 (SUTVA). 假设 2.1 和 2.2 同时成立。

²推导见附录 section 15.2

³推导见附录 section 15.3

为什么 SUTVA 如此重要？如果单元之间存在干扰，或者治疗定义不明确，那么潜在结果 $Y_i(1)$ 和 $Y_i(0)$ 就不是 well-defined 的——它们的值将取决于其他人的行为或治疗的具体形式，整个框架就会崩塌。

违反 SUTVA 的例子：

无干扰假设 (no-interference assumption) 违反的情形：

- (1) **传染病与疫苗接种 (infectious diseases and vaccination)**：当疾病具有传染性时，一个人是否接种疫苗不仅影响他自己的患病风险，还影响他周围人被感染的概率。例如，如果我的同事接种了流感疫苗，我患流感的概率也会降低——即使我自己没有接种。在这种情况下，单元 i 的潜在结果 $Y_i(1)$ 和 $Y_i(0)$ 都依赖于其他人的治疗分配。
- (2) **网络效应实验 (network experiments)**：在社交网络实验中，如果一个人收到 Facebook 广告 (treatment)，他的朋友看到这条广告并受到影响后，可能也会购买该产品——即使朋友本人没有直接收到广告。这就是所谓的**溢出效应 (spillover effect)**。
- (3) **随机区组实验中的相邻地块 (neighboring plots in randomized block experiments)**：农业实验中，相邻地块的作物可能相互影响——如果相邻地块使用了肥料，可能会通过土壤渗透影响本地块的产量。

一致性假设 (consistency assumption) 违反的情形：

- (1) **复合治疗 (composite treatments)**：当治疗本身有复杂组成部分时，相同的“治疗”标签可能对应不同的实际干预。例如：
 - 研究吸烟 (smoking) 对肺癌的影响时，“吸烟”这个治疗有多种形式——香烟类型、吸烟频率、吸入深度等，这些都可能产生不同的潜在结果。
 - 研究大学教育 (college education) 对收入的影响时，“上大学”这个治疗包括大学类型 (985/211 vs 普通院校)、专业、文凭等级等，这些差异会造成潜在结果的不一致。
- (2) **剂量效应 (dosage effects)**：在医学研究中，相同的药物名称可能对应不同剂量，而剂量直接影响疗效。例如“服用阿司匹林”作为治疗，但不同剂量的阿司匹林会产生完全不同的潜在结果。
- (3) **实施变异 (implementation variation)**：即使治疗名义上相同，不同实施者可能引入差异。例如，心理治疗研究中，不同治疗师的风格和技能可能导致相同的“心理治疗”产生不同效果。

当 SUTVA 不成立时，潜在结果框架需要修正。**现代因果推断文献**（如？）正在积极研究如何处理存在干扰或治疗版本多样的情形。

注 2.4. **SUTVA 的历史重要性**：Rubin (1980) 将 SUTVA 确立为潜在结果框架的基础假设，没有 SUTVA，因果推断的数学化是不可能的。

10. 反事实思维的逻辑

也许你会好奇：为什么不能简单地问“实际发生的结果是什么”？

答案是：**因果效应本质上是一个反事实 (counterfactual) 概念**。当我们问“这种药是否有效”时，我们实际上是在问：

“如果这个患者吃了药，结果会怎样？但现实是，他可能没有吃药...”

这种思维方式可能让人觉得抽象甚至哲学化，但它是我们谈论因果的唯一严谨方式。潜在结果框架的价值在于，它将这种哲学洞察转化为清晰的数学语言。

11. 实验单元定义的微妙性

我讨论一个与实验单元定义相关的微妙之处。简单来说，**实验单元可能不同于物理单元**。

例如，如果我在服药前没有服用阿司匹林且头痛没有消失，但我现在服用阿司匹林后头痛消失了，你可能认为我们可以同时观察到我的两种潜在结果。但这是对实验单元定义的误解！在不同时刻，我是同一个物理人，但成为了两个不同的实验单元。

因此，我们有四个潜在结果，其中两个被观察到，两个缺失。这说明，即使观察到的数据显示治疗“有效”，我们也无法确定地说阿司匹林就是原因——因为在“治疗后”的状态下，可能存在其他因素（如时间效应）导致头痛消失。

12. 非线性因果参数

平均因果效应是一个**线性**因果参数，因为潜在结果的平均差等于个体差别的平均。其他参数可能不是线性的。

例如，中位数治疗效应：

$$(2.6) \quad \delta_1 = \text{median}\{Y_i(1)\}_{i=1}^n - \text{median}\{Y_i(0)\}_{i=1}^n$$

通常不同于个体治疗效应的中位数：

$$(2.7) \quad \delta_2 = \text{median}\{Y_i(1) - Y_i(0)\}_{i=1}^n$$

这两个量在某些情况下可能相差很大。⁴

13. 本章小结

本章建立因果推断的数学语言：

- (1) **潜在结果**：为每个个体定义 $Y_i(1)$ 和 $Y_i(0)$
- (2) **科学表**： $n \times 2$ 矩阵 $\{Y_i(1), Y_i(0)\}_{i=1}^n$
- (3) **个体因果效应**： $\tau_i = Y_i(1) - Y_i(0)$
- (4) **平均因果效应**： $\tau = \bar{Y}(1) - \bar{Y}(0) = n^{-1} \sum_{i=1}^n \tau_i$
- (5) **根本问题**：我们只能观察到一种潜在结果
- (6) **基本桥梁方程**： $Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$
- (7) **SUTVA**：一致性 + 无干扰
- (8) **Yule-Simpson 悖论**在因果框架下不可能发生

下一章我们将看到，**随机实验**提供了一种绕过根本问题的优雅方式——通过随机分配治疗，我们可以建立组间可比性，从而识别因果效应。

14. 习题

练习 2.1. 2.1 完美的医生 假设潜在结果由以下模型生成：

$$Y_i(0) \sim N(0, 1), \quad \tau_i = -0.5 + Y_i(0), \quad Y_i(1) = Y_i(0) + \tau_i$$

治疗分配为 $T_i = \mathbb{I}(\tau_i \geq 0)$ ，观测结果为 $Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$ 。

计算条件均值差 $\mathbb{E}(Y_i | T_i = 1) - \mathbb{E}(Y_i | T_i = 0)$ 。

提示：需要使用截断正态分布的均值公式。当 $X \sim N(\mu, \sigma^2)$ 时，

$$\mathbb{E}(X | a < X < b) = \mu - \sigma \frac{\phi\left(\frac{b-\mu}{\sigma}\right) - \phi\left(\frac{a-\mu}{\sigma}\right)}{\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)}$$

⁴数值例子见附录 section 15.4

其中 ϕ 和 Φ 分别是标准正态分布的密度函数和分布函数。

练习 2.2. 2.2 非线性因果参数 证明平均因果效应是线性因果参数的例子，即 $\bar{Y}(1) - \bar{Y}(0) = n^{-1} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\}$ 。

其他参数可能不是线性的。例如，定义中位数治疗效应为：

$$\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\}$$

这通常不同于个体治疗效应的中位数：

$$\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\}$$

(1) 给出数值例子分别满足 $\delta_1 = \delta_2$ 、 $\delta_1 > \delta_2$ 和 $\delta_1 < \delta_2$ 。

(2) 哪个参数更有意义？为什么？请用例子来证明你的结论。

练习 2.3. 2.3 平均效应与个体效应 给出一个数值例子，其中 $\tau = n^{-1} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} > 0$ ，但有不到一半的单元满足 $Y_i(1) > Y_i(0)$ 。即平均因果效应为正，但治疗对不到一半的单元有益。

练习 2.4. 2.4 推荐阅读 **推荐阅读：**？是统计因果推断领域的经典综述文章，它推广了“Rubin 因果模型”这一名称。在 UC Berkeley，我们称之为“Neyman 模型”——原因显而易见。

15. 附录：公式推导

15.1. 平均因果效应的有限总体表示. 背景：在有限总体中，平均因果效应 $\tau = \mathbb{E}[Y_i(1) - Y_i(0)]$ 可以用样本均值表示。

目标：证明 eq. (2.2)

推导步骤：

$$(5) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)]$$

$$(6) \quad = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] \quad (\text{期望的有限总体类比})$$

$$(7) \quad = \frac{1}{n} \sum_{i=1}^n Y_i(1) - \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

$$(8) \quad = \bar{Y}(1) - \bar{Y}(0)$$

这完成了 eq. (2.2) 的推导。

15.2. 亚组因果效应的定义推导. 背景：亚组因果效应 τ_x 定义为在协变量 $X_i = x$ 的条件下，平均因果效应。

目标：推导 eq. (2.4)

推导步骤：

$$(9) \quad \tau_x = \mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x]$$

$$(10) \quad = \frac{\sum_{i=1}^n \mathbb{I}(X_i = x) [Y_i(1) - Y_i(0)]}{\sum_{i=1}^n \mathbb{I}(X_i = x)} \quad (\text{条件期望的样本类比})$$

其中 $\mathbb{I}(X_i = x)$ 是示性函数，当 $X_i = x$ 时为 1，否则为 0。

这给出了 eq. (2.4)。

15.3. 亚组分解恒等式的推导. 背景：总平均因果效应可以分解为各亚组因果效应的加权平均。

目标：证明 eq. (2.5)

推导步骤：

$$(11) \quad \tau = \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\}$$

$$(12) \quad = \frac{1}{n} \sum_{i=1}^n [\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0)] \{Y_i(1) - Y_i(0)\}$$

$$(13) \quad \text{其中每单元满足 } \mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$$

$$(14) \quad = \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}_{\text{treatment 组}} + \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}_{\text{control 组}}$$

$$(15) \quad = \frac{n_1}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}{n_1}}_{\tau_1} + \frac{n_0}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}{n_0}}_{\tau_0}$$

$$(16) \quad = \pi_1 \tau_1 + \pi_0 \tau_0$$

其中 $n_1 = \sum_{i=1}^n \mathbb{I}(X_i = 1)$, $n_0 = \sum_{i=1}^n \mathbb{I}(X_i = 0)$, 且 $\pi_x = n_x/n$ 。

这完成了 eq. (2.5) 的推导。

15.4. 非线性因果参数的数值例子. 背景：平均因果效应是线性的，但中位数治疗效应等参数可能是非线性的。

目标：给出 $\delta_1 \neq \delta_2$ 的具体数值例子。

例子：考虑 $n = 4$ 个单元，潜在结果如下：

i	$Y_i(1)$	$Y_i(0)$
1	10	2
2	8	3
3	6	4
4	4	5

计算：

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 7 - 3.5 = 3.5$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{8, 5, 2, -1\} = 3.5$

在此例中 $\delta_1 = \delta_2$ 。

不等例子：考虑 $n = 5$ 个单元：

i	$Y_i(1)$	$Y_i(0)$
1	100	1
2	90	2
3	50	3
4	10	4
5	5	5

计算：

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 50 - 3 = 47$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{99, 88, 47, 6, 0\} = 47$

再考虑一个 $\delta_1 > \delta_2$ 的例子：

i	$Y_i(1)$	$Y_i(0)$
1	100	0
2	1	0
3	1	0
4	1	0

计算：

- $\delta_1 = 50.5 - 0 = 50.5$
- $\delta_2 = \text{median}\{100, 1, 1, 1\} = 1$

这里 $\delta_1 = 50.5 > \delta_2 = 1$ ，说明少数极端值可以显著影响 δ_1 而不影响 δ_2 。这些例子说明为什么选择哪个参数需要根据研究问题仔细考虑。

完全随机实验与费舍尔随机化检验

1. 从潜在结果框架到随机实验：问题的起源

在第 ?? 章中，我们建立了**潜在结果框架 (Potential Outcomes Framework)**，学会了如何清晰地定义因果效应。平均因果效应定义为：

$$(17) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0)$$

但我们也清楚地看到了因果推断的**根本问题 (Fundamental Problem of Causal Inference)**：对于每个个体，我们只能观察到一种潜在结果， $Y_i(1)$ 和 $Y_i(0)$ 无法同时被观测。¹ 这意味着，即使我们定义了因果效应，我们也不知道如何用数据来估计它——因为每个单元的“反事实结果”永远无法被观测到。

那么，一个自然的问题是：我们能否设计某种**数据收集过程**，使得即使无法观察反事实，我们仍然可以估计因果效应？

第 ?? 章曾指出，相关性不等于因果性——即使 X 和 Y 相关，我们也无法断定 X 导致 Y 。第 ?? 章通过潜在结果框架给因果效应一个精确的定义，但它留下的核心问题是：我们如何用实际观测到的数据来**识别 (identify)** 和**估计 (estimate)** 这些潜在结果？

这个问题的答案是肯定的，而解决方案就是**随机实验 (Randomized Experiment)**——统计学的黄金标准。

2. Fisher 的洞见：随机化的两个原则

Ronald Fisher 在 1935 年的开创性著作《Design of Experiments》中指出了随机化的两个优势：

- (1) **可比性**：它创造了在平均意义上可比的 treatment 和 control 组。
- (2) **推理基础**：它作为统计推断的“合理基础”。

第一点直观易懂——随机治疗分配不会偏向 treatment 或 control。第二点更微妙：Fisher 的意思是，随机化为统计检验提供了正当理由，这就是现在所谓的**费舍尔随机化检验 (Fisher Randomization Test, FRT)**²³。

3. 完全随机实验的定义

考虑一个包含 n 个单元的实验，其中 n_1 个接受治疗， n_0 个接受对照 ($n = n_1 + n_0$)。

定义 3.1 (完全随机实验 (Complete Randomized Experiment, CRE))。固定 n_1 和 n_0 (其中 $n = n_1 + n_0$)。完全随机实验的治疗 *assignment* 机制为：

$$(18) \quad \mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}},$$

其中 $\mathbf{z} = (z_1, \dots, z_n)$ 满足 $\sum_{i=1}^n z_i = n_1$ 和 $\sum_{i=1}^n (1 - z_i) = n_0$ 。

¹问：什么是潜在结果？见附录 ??。

²问：什么是 Fisher Randomization Test？见附录 ??。

³问：Fisher 随机化检验与经典假设检验有何不同？见附录 ??。

在这个定义中，我们假设潜在结果向量 $\mathbf{Y}(1)$ 和 $\mathbf{Y}(0)$ 都是固定的。即使将它们视为随机的，我们可以在其上条件化，治疗分配机制变为：

$$(19) \quad \mathbb{P}\{\mathbf{Z} = \mathbf{z} \mid \mathbf{Y}(1), \mathbf{Y}(0)\} = \frac{1}{\binom{n}{n_1}}$$

因为在 CRE 中 $\mathbf{Z} \perp\!\!\!\perp \{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 。

关键含义：在 CRE 中， $\mathbf{Z}$ 是从 n_1 个 1 和 n_0 个 0 的随机排列中产生的。

4. Sharp Null 假设与 FRT 逻辑

？感兴趣检验的零假设是：

$$(20) \quad H_{0F} : Y_i(1) = Y_i(0) \quad \text{对所有单元 } i = 1, \dots, n.$$

？称其为 **sharp null 假设**，因为它可以基于观测数据确定所有潜在结果： $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y} = (Y_1, \dots, Y_n)$ ，即观测结果向量。它也被称为**强零假设**。⁴

概念上，在 H_{0F} 下，FRT 适用于任何检验统计量：

$$(21) \quad T = T(\mathbf{Z}, \mathbf{Y}),$$

它是观测数据的函数。观测结果向量 $\mathbf{Y}$ 在 H_{0F} 下是固定的，所以 T 中唯一的随机成分 is 治疗向量 $\mathbf{Z}$ 。实验者决定 $\mathbf{Z}$ 的分布，进而决定 T 的分布——这就是计算 p 值的基础。

在 CRE 中， $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的，其中 $M = \binom{n}{n_1}$ ， $\mathbf{z}^m$ 是所有可能的包含 n_1 个 1 和 n_0 个 0 的向量。⁵

5. 随机化分布与精确 p 值

如果较大的 T 值更极端，我们可以使用以下尾概率来衡量检验统计量相对于其随机化分布的极端性：

$$(22) \quad p_{\text{ftr}} = M^{-1} \sum_{m=1}^M \mathbb{I}\{T(\mathbf{z}^m, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}.$$

这就是 Fisher 的 p 值。重要的是， p_{ftr} 在 eq. (22) 中对任何检验统计量和任何结果生成过程都有效。它在 H_{0F} 下是有限样本精确的 (finite-sample exact)。⁶

$$(23) \quad \mathbb{P}(p_{\text{ftr}} \leq u) \leq u \quad \text{for all } 0 \leq u \leq 1.$$

注 3.1. 为什么叫“有限样本精确”？：这意味着 p 值的分布（虽然在离散情况下是阶梯函数）满足上式，因此 p 值在 $[0, 1]$ 上均匀分布（对于连续情况）。

⁴问：为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的？见附录 ??。

⁵问： $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义是什么？见附录 ??。

⁶问：什么是有限样本精确？见附录 ??。

6. Monte Carlo 近似

在实践中, M 通常太大 (例如当 $n = 100, n_1 = 50$ 时, $M > 10^{29}$), 枚举所有可能的治疗向量在计算上是不可行的。我们经常用 Monte Carlo 来近似 p_{frit} , 并用修正公式 $\tilde{p}_{\text{frit}}$ 保证有限样本有效性。⁷⁸

$$(24) \quad \hat{p}_{\text{frit}} = R^{-1} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\},$$

其中 $\mathbf{z}^r$ 是 $\mathbf{Z}$ 的 R 次随机置换。由于计算 p_{frit} 涉及对 $\mathbf{Z}$ 的置换, FRT 有时在 CRE 语境下被称为**置换检验 (permutation test)**。

修正的有限样本有效近似:

$$(25) \quad \tilde{p}_{\text{frit}} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}.$$

这个修正在任意有限的 R 下都是有限样本有效的 p 值。

7. 检验统计量的规范选择

FRT 的一个特点是它对任何检验统计量都生成有限样本精确 p 值。但我们应该选择能够给出 H_{0F} 可能违背信息的检验统计量。

7.1. 差值均值统计量. 差值均值统计量是:

$$(26) \quad \hat{\tau} = \hat{Y}(1) - \hat{Y}(0),$$

其中

$$(27) \quad \hat{Y}(1) = n_1^{-1} \sum_{Z_i=1} Y_i = n_1^{-1} \sum_{i=1}^n Z_i Y_i$$

是 treatment 组的样本均值,

$$(28) \quad \hat{Y}(0) = n_0^{-1} \sum_{Z_i=0} Y_i = n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i$$

是 control 组的样本均值。

在 H_{0F} 下, $\hat{\tau}$ 有均值 0 和方差

$$(29) \quad \text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} s^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$, $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$ 。⁹

渐近分布: 由于有限总体中心极限定理 (Finite Population Central Limit Theorem), 随机化分布近似正态:

$$(30) \quad \frac{\hat{\tau}}{\sqrt{\frac{n}{n_1 n_0} s^2}} \rightarrow \mathcal{N}(0, 1)$$

in distribution.

⁷⁸问: 为什么 Monte Carlo 近似需要修正? 见附录 ??。

⁸问: 蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思? 见附录 ??。

⁹推导见附录 ??。

与经典 t 检验的联系：在 H_{0F} 下，近似 p 值接近经典两样本 t 检验（假设等方差）的 p 值。

方差分解（ANOVA 分解）¹⁰：基于代数运算（见习题 3.8），我们有如下展开式：

$$(31) \quad (n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

这个展开式的意义：这本质上是一个方差分解（ANOVA 分解）。将每个单元的偏差 $Y_i - \bar{Y}$ 分解为组内偏差 $(Y_i - \hat{Y}(Z_i))$ 和组间偏差 $(\hat{Y}(Z_i) - \bar{Y})$ ，平方求和后交叉项消失，留下三项：treatment 组内部变异、control 组内部变异，以及由治疗效应解释的变异 $\frac{n_1 n_0}{n} \hat{\tau}^2$ 。¹¹

注 3.2. 为什么 FRT 能证明 t 检验的合理性？：传统 t 检验需要正态性假设。但 FRT 框架表明，只要随机化分配正确执行，t 检验程序在有限总体 + 随机化情境下可以使用——渐近理论只依赖于有限总体 CLT，而不依赖于数据的原始分布。

7.2. 学生化统计量。差值均值隐含地假设两组方差相等。如果治疗可能影响结果的变异性（异方差），我们需要使用学生化统计量：

$$(32) \quad t = \frac{\hat{Y}(1) - \hat{Y}(0)}{\sqrt{\frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}}},$$

其中

$$(33) \quad \hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{Z_i=1} [Y_i - \hat{Y}(1)]^2, \quad \hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{Z_i=0} [Y_i - \hat{Y}(0)]^2$$

分别是 treatment 组和 control 组的样本方差。

在 H_{0F} 下，有限总体 CLT 再次意味着 t 渐近正态： $t \rightarrow \mathcal{N}(0, 1)$ 。

这个统计量与 `t.test(var.equal = FALSE)` 的 p 值接近。

注 3.3. 学生化为什么更稳健？：当 treatment 组和 control 组的方差差异较大时，差值均值的检验可能失效。学生化通过分别估计两组的方差，能够更好地处理异方差情况。

7.3. 卡方检验：分类数据的拟合优度与独立性。迄今为止我们关注的都是连续型结局。但统计学同样关注**分类数据（categorical data）**——即计数数据。例如：选举中支持不同候选人的选民人数、不同药物治疗后的治愈/未治愈人数。卡方检验（Chi-Square Test）正是处理这类数据的核心工具。

核心思想：比较观测频数与期望频数。如果两者差异很大，说明数据可能不服从假设的分布或独立性结构。

Insight 连续数据关注“均值差异”，分类数据关注“频数差异”。这两类数据的分析方法有本质区别——连续数据用 t 检验，分类数据用卡方检验。

卡方检验由卡尔·皮尔逊（Karl Pearson）于 1900 年提出。

¹⁰详细推导见附录 ??

¹¹ANOVA 分解的完整代数推导见附录 ??。

7.3.1. 拟合优度检验. **问题**: 数据是否来自某个特定分布?

设有 k 个类别的观测频数 $O_1, O_2, \dots, O_k$, 总样本量为 n 。在零假设 H_0 下, 第 i 类的期望频数为 $E_i = np_{i0}$, 其中 p_{i0} 是 H_0 规定的理论概率。

皮尔逊卡方统计量:

$$(34) \quad \chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}.$$

直观理解: $(O_i - E_i)^2/E_i$ 衡量每个类别的偏差——平方消去正负号, 除以 E_i 进行标准化 (一个大类的 100 偏差比一个小类的 100 偏差更重要), 求和得到总体偏离程度。

渐近分布: 在 H_0 下, 当样本量 n 足够大时,

$$(35) \quad \chi^2 \xrightarrow{d} \chi_{k-1}^2,$$

自由度为 $k-1$, 因为只有一个约束—— $\sum O_i = \sum E_i = n$ 。

Insight 为什么自由度是 $k-1$? 因为 k 个类别的观测频数之和必须等于 n , 这产生了一个线性约束。所以 k 个类别中只有 $k-1$ 个可以自由变化——最后一个由总和决定。

例 3.1 (骰子检验——硬币是否均匀?). **背景**: 投掷一枚骰子 120 次, 想检验它是否均匀 (各面概率均为 $1/6$)。

观测数据:

面	1	2	3	4	5	6
观测频数 O_i	15	22	18	25	17	23
期望频数 E_i	20	20	20	20	20	20

计算:

$$\chi^2 = \frac{(15-20)^2}{20} + \frac{(22-20)^2}{20} + \frac{(18-20)^2}{20} + \frac{(25-20)^2}{20} + \frac{(17-20)^2}{20} + \frac{(23-20)^2}{20} = 4.3$$

自由度 $k-1=5$, 查表得 $\chi_{0.05,5}^2 = 11.07$ 。

由于 $4.3 < 11.07$, 在 $\alpha = 0.05$ 水平下 **不能拒绝** 均匀性假设。

R 实现:

```
> obs <- c(15, 22, 18, 25, 17, 23)
> chisq.test(obs, p = rep(1/6, 6))
```

Chi-squared test for given probabilities

X-squared = 4.3, df = 5, p-value = 0.507

p 值为 0.507, 远大于 0.05, 与手工计算一致。

□

Insight 骰子例子中, $E_i = 20$ 都相同。如果某个类别期望频数太小 (< 5), 渐近近似的精度会下降, 此时应该用精确检验 (exact test) 或合并相邻类别。

例 3.2 (遗传学——孟德尔豌豆实验). **背景**: 孟德尔杂交黄色圆粒豌豆与绿色皱粒豌豆, 预期后代比例为:

黄圆 : 黄皱 : 绿圆 : 绿皱 = 9 : 3 : 3 : 1

观测数据 (共 556 株):

$$O = (315, 101, 108, 32), \quad E = (556 \times \frac{9}{16}, \dots) = (312.75, 104.25, 104.25, 34.75)$$

计算:

$$\chi^2 = \frac{(315 - 312.75)^2}{312.75} + \frac{(101 - 104.25)^2}{104.25} + \frac{(108 - 104.25)^2}{104.25} + \frac{(32 - 34.75)^2}{34.75} \approx 0.47$$

自由度 $k - 1 = 3$, 查表得 $\chi_{0.05,3}^2 = 7.81$ 。由于 $0.47 < 7.81$, **不能拒绝**孟德尔比例。

R 实现:

```
> obs <- c(315, 101, 108, 32)
> prob <- c(9/16, 3/16, 3/16, 1/16)
> chisq.test(obs, p = prob)
```

Chi-squared test for given probabilities

X-squared = 0.47, df = 3, p-value = 0.925

p 值为 0.925——数据与孟德尔比例高度吻合。

□

7.3.2. 独立性检验: 第二个应用场景是**列联表独立性检验**——判断两个分类变量是否独立。

问题: 对于 $r \times c$ 列联表, 检验行变量 X 与列变量 Y 是否独立。

设 O_{ij} 为单元格 (i, j) 的观测频数, $O_{i\cdot} = \sum_j O_{ij}$ 为第 i 行合计, $O_{\cdot j} = \sum_i O_{ij}$ 为第 j 列合计, 总计为 n 。

期望频数 (在独立性假设 $H_0: X \perp Y$ 下):

$$(36) \quad E_{ij} = \frac{O_{i\cdot} \cdot O_{\cdot j}}{n}.$$

检验统计量:

$$(37) \quad \chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

自由度: 在 H_0 下, $(r - 1)(c - 1)$ 。

Insight 2×2 表的自由度为 1, 这与二项分布的参数个数一致——只估计了一个参数 p (成功率)。更大的表可以检验更复杂的独立性结构。

连续性修正 (仅用于 2×2 表): R 中的 `chisq.test` 默认使用 Yates 连续性修正, 对小样本的渐近近似进行校正:

$$\chi_{\text{Yates}}^2 = \sum \frac{(|O - E| - 0.5)^2}{E}.$$

例 3.3 (2×2 表——治疗与结局独立性). 考虑二元结局的随机实验, 数据汇总为:

	成功 ($Y = 1$)	失败 ($Y = 0$)	合计
治疗 ($Z = 1$)	$n_{11} = 30$	$n_{10} = 20$	$n_1 = 50$
对照 ($Z = 0$)	$n_{01} = 20$	$n_{00} = 30$	$n_0 = 50$

步骤 1: 计算期望频数:

$$E_{11} = \frac{50 \times 50}{100} = 25, \quad E_{10} = \frac{50 \times 50}{100} = 25, \quad E_{01} = \frac{50 \times 50}{100} = 25, \quad E_{00} = 25$$

步骤 2: 计算 χ^2 :

$$\chi^2 = \frac{(30 - 25)^2}{25} + \frac{(20 - 25)^2}{25} + \frac{(20 - 25)^2}{25} + \frac{(30 - 25)^2}{25} = 4$$

自由度 $(2-1)(2-1) = 1$, 临界值 $\chi_{0.05,1}^2 = 3.84$ 。由于 $4 > 3.84$, **拒绝独立性假设**——治疗与结局存在关联。

R 实现:

```
> tb <- matrix(c(30, 20, 20, 30), nrow = 2, byrow = TRUE)
> chisq.test(tb)
```

Pearson's Chi-squared test with Yates' continuity correction

X-squared = 4, df = 1, p-value = 0.0455

注意 *Yates* 修正后的 χ^2 从 4 降到 3.24, p 值 = 0.072——这说明连续性修正在小样本时影响显著。

□

例 3.4 (3×2 表——吸烟与肺癌). **背景:** 研究吸烟状态与肺癌诊断的关联, 数据如下:

	患肺癌	未患肺癌	合计
重度吸烟	60	40	100
轻度吸烟	20	30	50
不吸烟	10	40	50

步骤 1: 计算期望频数:

$$E_{11} = \frac{100 \times 90}{200} = 45, \quad E_{12} = \frac{100 \times 110}{200} = 55$$

$$E_{21} = \frac{50 \times 90}{200} = 22.5, \quad E_{22} = \frac{50 \times 110}{200} = 27.5$$

$$E_{31} = \frac{50 \times 90}{200} = 22.5, \quad E_{32} = \frac{50 \times 110}{200} = 27.5$$

步骤 2: 计算 χ^2 :

$$\chi^2 = \frac{(60 - 45)^2}{45} + \frac{(40 - 55)^2}{55} + \frac{(20 - 22.5)^2}{22.5} + \frac{(30 - 27.5)^2}{27.5} + \frac{(10 - 22.5)^2}{22.5} + \frac{(40 - 27.5)^2}{27.5} \approx 20.4$$

自由度 $(3-1)(2-1) = 2$, 查表 $\chi_{0.05,2}^2 = 5.99$ 。由于 $20.4 > 5.99$, **拒绝独立性**——吸烟与肺癌存在显著关联。

R 实现:

```
> tb <- matrix(c(60, 40, 20, 30, 10, 40), nrow = 3, byrow = TRUE)
> rownames(tb) <- c("重度吸烟", "轻度吸烟", "不吸烟")
> colnames(tb) <- c("患肺癌", "未患肺癌")
> chisq.test(tb)
```

Pearson's Chi-squared test

X-squared = 20.4, df = 2, p-value = 3.7e-05

p 值极小, 结论稳健。

□

例 3.5 (4×3 表——教育程度与收入水平). 背景: 调查 500 人的教育程度与收入水平:

	低收入	中等收入	高收入	合计
初中及以下	80	50	20	150
高中	60	80	30	170
本科	30	70	40	140
研究生	10	30	100	140
合计	180	230	190	500

R 实现:

```
> edu <- c(80, 50, 20, 60, 80, 30, 30, 70, 40, 10, 30, 100)
> tb <- matrix(edu, nrow = 4, byrow = TRUE)
> rownames(tb) <- c("初中及以下", "高中", "本科", "研究生")
> colnames(tb) <- c("低收入", "中等收入", "高收入")
> chisq.test(tb)
```

Pearson's Chi-squared test

X-squared = 186.7, df = 6, p-value < 2.2e-16

p 值极小, 拒绝独立性——教育程度与收入水平存在强关联。

进一步分析: 对于 $r \times c$ 表, 还可以计算 Cramér V 来衡量关联强度:

$$(38) \quad V = \sqrt{\frac{\chi^2}{n \times \min(r-1, c-1)}}.$$

对于本例, $V = \sqrt{186.7/(500 \times 2)} \approx 0.43$, 表示中等偏强的关联。

□

7.3.3. 二元结局下的卡方检验: 与 Fisher 精确检验的对比. 回到随机实验的二元结局语境, 我们使用卡方检验来检验 $Z \perp Y$ (治疗与结局独立)。

与 Fisher 精确检验的比较:

特征	Chi-square test	Fisher exact test
原理	渐近方法 (大样本)	精确方法 (小样本)
p 值	近似	精确
适用场景	期望频数均 > 5	小样本或期望频数 < 5

Insight Fisher 精确检验使用超几何分布计算 p 值, 在零假设下有精确的有限样本分布。Chi-square 则是大样本近似——当样本量增大时, 两者结果趋于一致。

完整例子——简历种族歧视实验 (Bertrand & Mullainathan, 2004):

该实验将简历上的名字随机分配为黑人听起来或白人听起来的名字, 研究感知种族对面试回调率的影响。

```
resume = read.csv("resume.csv")
Alltable = table(resume$race, resume$call)
Alltable
```

```
#      0      1
# black 2278  157
# white 2200  235
```

数据汇总为 2×2 列联表:

	回调 ($Y = 1$)	无回调 ($Y = 0$)	合计
黑人名字 ($Z = 1$)	157	2278	2435
白人名字 ($Z = 0$)	235	2200	2435

计算各格期望频数:

$$E_{11} = \frac{2435 \times 392}{4870} \approx 195.7, \quad E_{12} = \frac{2435 \times 4478}{4870} \approx 2239.3$$

$$E_{21} = \frac{2435 \times 392}{4870} \approx 196.3, \quad E_{22} = \frac{2435 \times 4478}{4870} \approx 2238.7$$

由于期望频数都远大于 5, 适合使用卡方检验。

```
> chisq.test(Alltable)
```

```
Pearson's Chi-squared test with Yates' continuity correction
```

```
X-squared = 17.6, df = 1, p-value = 2.7e-05
```

p 值极小, 提供种族对回调率有显著影响的强有力证据。

与 Neymanian 推断的联系: 卡方检验本质上是在检验弱零假设 $H_0: \tau = 0$ (平均因果效应为零) 的渐近版本。风险差估计量 $\widehat{RD} = \hat{p}_1 - \hat{p}_0$ 的渐近方差为

$$\text{var}(\widehat{RD}) \approx \frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_0(1 - \hat{p}_0)}{n_0}$$

而 χ^2 统计量正是 $(\widehat{RD})^2 / \text{var}(\widehat{RD})$ 的另一种表达。

不满足适用条件时的处理:

- (1) 如果某些期望频数 < 5 (尤其 2×2 表), 优先使用 Fisher 精确检验
- (2) 如果样本量太小, 可以合并相邻类别以增大期望频数
- (3) 使用蒙特卡洛近似: `chisq.test(tb, simulate.p.value = TRUE)`

Insight 卡方检验的“大样本近似”条件可以通过经验规则判断: 期望频数都 > 5 时近似精度较好; 如果有多个格子 < 5 , 渐近近似的 p 值可能严重偏离真实值, 此时 Fisher 精确检验更可靠。

7.4. Wilcoxon 秩和统计量. 差值均值和学生化统计量都关注均值差异, 且对异常值敏感。Wilcoxon 秩和统计量基于合并观测结果的秩:

$$W = \sum_{i=1}^n Z_i R_i,$$

其中 R_i 是 Y_i 在合并样本中的秩。

均值与方差¹²: 在 H_{0F} 下, 随机性只来自治疗分配 $\mathbf{Z}$, 秩 R_i 是固定值。均值和方差分别为:

$$\mathbb{E}(W) = \frac{n_1(n+1)}{2}, \quad \text{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

这个统计量的优点是:

¹²详细推导见附录 ??

- 对异常值稳健（只使用秩次信息，不依赖具体数值）
- 只依赖于数据的秩次信息
- 在许多备择假设下都有较好的功效

7.5. Kolmogorov-Smirnov 统计量. 上述统计量主要关注均值差异。KS 统计量衡量两个分布之间的最大距离：

$$D = \max_y |\hat{F}_1(y) - \hat{F}_0(y)|,$$

其中 $\hat{F}_1(y) = n_1^{-1} \sum_{i=1}^n Z_i \mathbb{I}(Y_i \leq y)$ 。

这个统计量能够检测分布形状的差异，而不仅仅是均值差异。

8. FRT 与传统 t 检验的关系

一个重要的理论发现是：

FRT 为传统 t 检验提供了更坚实的基础。

传统 t 检验假设“数据来自正态分布的无限总体”。但 FRT 框架表明，只要随机化分配正确执行，t 检验程序可以在“有限总体 + 随机化”的情境下使用。

这意味着，在随机实验中，我们可以不那么担心正态性假设——CLT 会为我们处理这个问题。

9. LaLonde 实验数据案例

1986 年，Robert LaLonde 发表了一项影响深远的研究，探讨职业培训项目（National Supported Work Demonstration）对参与者收入的影响。

使用 R 进行 FRT 分析：

```
library(Matching)
data(lalonde)
z <- lalonde$treat
y <- lalonde$re78
```

观测到的检验统计量值：

统计量	观测值	描述
$\hat{\tau}$	2.84	差值均值 (t 统计量)
t	2.67	学生化统计量
W	27402.5	Wilcoxon 秩和
D	0.132	KS 统计量

通过随机置换治疗向量，我们可以得到检验统计量的随机化分布的 Monte Carlo 近似。Monte Carlo 置换检验的结果 ($R = 10^4$):

```
> exact.pv = c(mean(Tauhat >= tauhat),
+               mean(Student >= student),
+               mean(Wilcox >= W),
+               mean(Ks >= D))
> round(exact.pv, 3)
[1] 0.002 0.002 0.006 0.040
```

所有单侧 p 值都小于 0.05——这提供了治疗效应显著的强有力证据。

10. 历史侧边栏：随机实验的起源

FRT 的逻辑可以追溯到早期的历史实例。

10.1. James Lind 的坏血病实验. James Lind (1716-1794) 是苏格兰医生和皇家海军卫生学的先驱。他进行了最早有清晰文献记录的随机实验之一，研究柑橘类水果对坏血病的影响。在 12 名坏血病患者被分配到 6 组后，接受柑橘类水果的组在六天后康复，而其他组没有。

如果将治疗简化为二元指示变量，观测到的极端 2×2 表格在 H_{0F} 下出现的概率为：

$$p_{\text{frit}} = \frac{1}{\binom{12}{2}} = \frac{1}{66} = 0.015.$$

10.2. Fisher 的女士品茶实验. 描述了一个著名实验，一位女士声称能区分先加茶还是先加牛奶制成的奶茶。他制作了 8 杯茶（4 杯先加茶，4 杯先加牛奶），随机顺序呈现给女士。在她的全部猜对 ($X = 4$) 的情况下，p 值为：

$$p_{\text{frit}} = \frac{1}{70} = 0.014.$$

超几何分布¹³: 在 H_{0F} 下， X 服从超几何分布 $\text{Hypergeometric}(N = 8, K = 4, n = 4)$ ，这对应“不放回抽样”的结果。关键概率 $\mathbb{P}(X = 4) = 1/70$ ，故单侧 p 值 $p_{\text{frit}} = 1/70 \approx 0.014$ 。这些例子强调了 Fisher 的两个原则：

- (1) **随机化**：实验的随机分配保证了 p 值的有效性
- (2) **重复**：必须有足够的单元以确保 FRT 有功效

11. Sharp Null 假设的置信区间

FRT 的逻辑不仅限于 H_{0F} 。我们还可以检验更一般的 sharp null 假设：

$$(39) \quad H_0(\boldsymbol{\tau}) : Y_i(1) - Y_i(0) = \tau_i \quad \text{对所有 } i.$$

通过检验与置信集的对偶性，我们可以构建 $\boldsymbol{\tau}$ 的 $(1 - \alpha)$ 置信集。

12. 本章小结

本章建立了随机实验的理论与实践：

- (1) **CRE 定义**： $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = 1/\binom{n}{n_1}$
- (2) **随机化的两个原则**：可比性 + 推理基础
- (3) **Sharp null**： $H_{0F} : Y_i(1) = Y_i(0)$ 对所有 i
- (4) **精确 p 值**： $p_{\text{frit}} = M^{-1} \sum_{m=1}^M \mathbb{I}\{T(\mathbf{z}^m, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$
- (5) **多种统计量**：差值均值 $\hat{\tau}$ 、学生化 t 、Wilcoxon W 、KS D
- (6) **理论联系**：FRT 为传统 t 检验提供基础
- (7) **历史起源**：Lind 的坏血病实验、Fisher 的女士品茶

下一章我们将学习 Neymanian 推断——另一种基于渐近理论的方法，它可以更方便地构建置信区间。

13. 习题

练习 3.1. 3.1 — p_{frit} 的精确性 证明在 sharp null 下， p_{frit} 满足：

$$\mathbb{P}(p_{\text{frit}} \leq u) \leq u \quad \text{for all } 0 \leq u \leq 1.$$

¹³详细推导见附录 ??

练习 3.2. 3.2 — Monte Carlo 误差 设 p_{frt} 是固定值, $\hat{p}_{frt}$ 是其 Monte Carlo 估计 (见 eq. (24))。证明:

$$\mathbb{E}_{mc}(\hat{p}_{frt}) = p_{frt}, \quad \text{var}_{mc}(\hat{p}_{frt}) \leq \frac{1}{4R},$$

其中下标 "mc" 表示由于 Monte Carlo 的随机性。

练习 3.3. 3.3 — 有限样本有效的 Monte Carlo 近似 证明修正的 Monte Carlo 近似

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

在任意有限的 R 下都是有限样本有效的 p 值。

提示: 可以利用以下两个基本概率结果:

- (1) 对于两个二项分布 $X_1 \sim \text{Binomial}(R, p_1)$ 和 $X_2 \sim \text{Binomial}(R, p_2)$, 若 $p_1 \geq p_2$, 则 $\mathbb{P}(X_1 \leq x) \leq \mathbb{P}(X_2 \leq x)$ 。
- (2) 若 $p \sim \text{Uniform}(0, 1)$ 且 $X | p \sim \text{Binomial}(R, p)$, 则 X 在 $\{0, 1, \dots, R\}$ 上均匀分布。

练习 3.4. 3.4 — Fisher 精确检验 考虑二元结局的 CRE, 数据汇总为 2×2 列联表:

	$Y = 1$	$Y = 0$	合计
$Z = 1$	n_{11}	n_{10}	n_1
$Z = 0$	n_{01}	n_{00}	n_0

在 H_{0F} 下, 证明任何检验统计量 $T(n_{11}, n_{10}, n_{01}, n_{00})$ 是 n_{11} 的函数, 且 n_{11} 的精确分布是超几何分布。请说明超几何分布的参数。

练习 3.5. 3.5 — 女士品茶详细计算 回忆女士品茶实验 (见 section 10)。计算 $\mathbb{P}(X = k)$, 其中 X 是女士正确识别 k 杯先加牛奶的茶个数, $k = 0, 1, 2, 3, 4$ 。

练习 3.6. 3.6 — 协变量调整的 FRT 使用 LaLonde 数据集 (见 section 9), 添加协变量进行 FRT 分析。假设所有潜在结果和协变量都是固定数值。

有两种策略:

- (1) 运行结局对协变量的线性回归, 得到残差 (即 "伪结局")。基于残差定义四种检验统计量, 进行 FRT 并报告 p 值。
- (2) 定义检验统计量为结局对治疗 and 协变量线性回归中治疗系数的 FRT。

解释为什么上述两种策略的五个 p 值都是有限样本精确的。

练习 3.7. 3.7 — FRT 与广义线性模型 使用与练习 3.6 相同的数据集, 但将结局改为 $re78 > 0$ 的二元指示变量。运行结局对治疗 and 协变量的 logistic 回归。治疗系数是否显著? FRT p 值是多少?

练习 3.8. 3.8 — 代数细节 验证 eq. (31)。

练习 3.9. 3.9 — 推荐阅读 ? 是一篇倡导在复杂实验中同时报告 p 值及其相应随机化分布的论文。

CHAPTER 4

Neymanian 重复抽样推断

1. 两种推断哲学的对话

在上一章中，我们遇到了费舍尔随机化检验 (Fisher's randomization test, FRT)。这种方法优雅而精确——它基于随机化的精确性质，在 sharp null 假设下给出精确的 p 值，无需任何分布假设。

然而，FRT 也有其内在局限。首先，它只能检验 **sharp null 假设** (即所有单元的个体因果效应为零)；对于更一般的 null 假设，FRT 无法处理。其次，当样本量增大时，枚举所有可能的置换变得计算上不可行——我们需要渐近近似。

更重要的是：从 Fisher 的视角来看，我们只能得到一个 p 值，却无法直接得到置信区间。而实际研究中，研究者往往更关心“因果效应有多大”而非“因果效应是否为零”。

一个自然的问题产生：能否有一种方法，既保持 Fisher 方法的无分布 (distribution-free) 精神，又能方便地构建置信区间？

Jerzy Neyman 在 1923 年的开创性工作中给出了一种互补的答案。他的方法基于**渐近正态分布**，直接对因果效应进行统计推断，既能得到 p 值，也能构建置信区间。这两种方法——Fisherian 的精确小样本推断与 Neymanian 的大样本渐近推断——代表了统计推断的两种哲学，深刻影响了现代因果推断的发展。

注 4.1. 为什么需要两种方法？：FRT 适用于小样本精确推断和假设检验，Neymanian 适用于大样本渐近推断和置信区间构建。两者互为补充。

2. 有限总体量

在 Neymanian 框架中，我们首先需要一套精确的记号来描述**有限总体**——这是 Neyman 与 Fisher 共同面对的研究对象。

考虑一个包含 n 个单元的有限总体。记 n_1 个单元被分配到治疗组， $n_0 = n - n_1$ 个单元被分配到对照组。对于每个单元 $i = 1, \dots, n$ ，我们定义：

- $Y_i(1)$ ：单元 i 接受治疗后的潜在结果
- $Y_i(0)$ ：单元 i 接受对照后的潜在结果
- $\tau_i = Y_i(1) - Y_i(0)$ ：单元 i 的个体因果效应

这些潜在结果都是**固定的数值**——它们不依赖于我们实际做什么选择，只是“潜在”地存在。

有限总体均值：

$$\bar{Y}(1) = \frac{1}{n} \sum_{i=1}^n Y_i(1), \quad \bar{Y}(0) = \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

有限总体方差 (使用 $n - 1$ 作为除数)：

$$S^2(1) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2, \quad S^2(0) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$$

有限总体协方差：

$$S(1, 0) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\} \{Y_i(0) - \bar{Y}(0)\}$$

平均因果效应：

$$\tau = \frac{1}{n} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$$

这是我们要估计的核心参数。

个体效应的方差：

$$S^2(\tau) = \frac{1}{n-1} \sum_{i=1}^n (\tau_i - \tau)^2$$

衡量治疗效应在单元间的异质性程度。

注 4.2. **为什么需要协方差？** $Y(1)$ 和 $Y(0)$ 之间可能有相关性。若治疗组和对照组的个体是匹配的（正相关），估计的方差会减小；若是负相关，方差会增大。

3. 一个关键引理

在有限总体量的世界中，有一个优雅的关系连接了协方差与各个方差。这个恒等式虽然简单，却贯穿整个 Neymanian 推断框架。

引理 4.1 (Lemma 4.1 — 方差与协方差的关系)。

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$$

其中 $\tau_i = Y_i(1) - Y_i(0)$ 是个体因果效应。

直觉理解： 如果所有单元的治疗效应都相同 ($S^2(\tau) = 0$)，则 $Y_i(1)$ 和 $Y_i(0)$ 完全线性相关（相差一个常数），此时 $S(1, 0)$ 达到最大值 $[S^2(1) + S^2(0)]/2$ 。

推论： 当 $S^2(\tau) > 0$ 时， $2S(1, 0) < S^2(1) + S^2(0)$ ，即协方差小于两个方差之和的一半。这个引理的证明是直接的代数运算。¹

4. Neyman (1923) 定理

基于观测结果，我们可以计算样本均值：

$$\hat{Y}(1) = \frac{1}{n_1} \sum_{i=1}^n Z_i Y_i, \quad \hat{Y}(0) = \frac{1}{n_0} \sum_{i=1}^n (1 - Z_i) Y_i$$

其中 $Z_i \in \{0, 1\}$ 是治疗分配指示变量。

样本方差：

$$\hat{S}^2(1) = \frac{1}{n_1 - 1} \sum_{i=1}^n Z_i \{Y_i - \hat{Y}(1)\}^2, \quad \hat{S}^2(0) = \frac{1}{n_0 - 1} \sum_{i=1}^n (1 - Z_i) \{Y_i - \hat{Y}(0)\}^2$$

一个基本事实： 不存在 $S(1, 0)$ 和 $S^2(\tau)$ 的“样本版本”。这是因为对于每个单元，我们最多只能观测到 $Y_i(1)$ 或 $Y_i(0)$ 中的一个——两者从未同时被观测到。

现在陈述 Neyman 的核心定理：

定理 4.2 (Neyman (1923) 定理). 在完全随机化实验 (CRE) 下，令 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ 。则：

¹详见附录 ??。

(1) **无偏性**: $\hat{\tau}$ 对 τ 是无偏的:

$$\mathbb{E}(\hat{\tau}) = \tau$$

(2) **方差公式**: $\hat{\tau}$ 的方差为

$$(40) \quad \text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$$

$$(41) \quad = \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0)$$

(3) **保守方差估计**: 方差估计量

$$\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$$

对 $\text{var}(\hat{\tau})$ 是保守的, 即

$$\mathbb{E}(\hat{V}) - \text{var}(\hat{\tau}) = \frac{S^2(\tau)}{n} \geq 0$$

等号当且仅当 $\tau_i \equiv \tau$ (所有单元个体效应恒定) 时成立。

关于期望和方差的含义: 这里所有潜在结果 $\{Y_i(1), Y_i(0)\}$ 都是固定数值。随机性仅来自治疗分配 Z_i ——即 n_1 个 1 和 n_0 个 0 的所有可能排列构成的集合。

注 4.3. 第三项为什么是减项?: 直觉上: 若个体因果效应存在变异 ($S^2(\tau) > 0$), 治疗组和对照组之间的差异不仅来自随机抽样误差, 还来自因果效应本身的真实变异。这种“真实变异”不应被算作估计误差。

5. 方差公式的深入理解

方差公式 eq. (40) 与经典两样本问题中的方差公式不同, 因为它还依赖于个体效应的方差 $S^2(\tau)$ 。

一个令人困惑的现象: 个体效应越异质, $\hat{\tau}$ 的方差反而越小。为什么?

从等价格式 eq. (41) 理解: 考虑潜在结果之间的相关性。

假设在一次实现中, 我们观察到相对较大的治疗潜在结果 $\{Y_i(1)\}$:

- 若 $S(1, 0) > 0$ (正相关), 则那些接受治疗的单元也有相对较大的对照潜在结果。因此, 对照下的观测结果相对较小, 导致较大的 $\hat{\tau}$
- 若 $S(1, 0) < 0$ (负相关), 则那些接受治疗的单元有相对较小的对照潜在结果。因此, 对照下的观测结果相对较大, 导致较小的 $\hat{\tau}$

当潜在结果正相关时, 更可能观察到极端的 $\hat{\tau}$, 因此方差更大。

推论: 当 $S^2(\tau) = 0$ 时, eq. (40) 简化为 $\text{var}(\hat{\tau}) = S^2(1)/n_1 + S^2(0)/n_0$ ——此时 Neymanian 方差与经典两样本方差一致。

6. Neyman (1923) 定理的证明

无偏性: ²

方差证明: ³

方差估计的期望: ⁴

²推导详见附录 ??。

³推导详见附录 ??。

⁴推导详见附录 ??。

7. 渐近正态性与置信区间

Neyman (1923) 定理给出了方差的精确表达式，但它是相对于随机分配的分布而言的。在实际应用中，我们还需要知道 $\hat{\tau}$ 的抽样分布形状。

定理 4.3 (有限总体 CLT). 令 $n \rightarrow \infty$ 和 $n_1 \rightarrow \infty$ 。假设：

- (1) n_1/n 趋向于 $(0, 1)$ 中的常数 p
- (2) $\{S^2(1), S^2(0), S(1, 0)\}$ 有有限极限
- (3) $\max_i |Y_i(1) - \bar{Y}(1)|^2/n \rightarrow 0$ 且 $\max_i |Y_i(0) - \bar{Y}(0)|^2/n \rightarrow 0$ (Lindeberg 条件)

则

$$\frac{\hat{\tau} - \tau}{\sqrt{\text{var}(\hat{\tau})}} \xrightarrow{d} N(0, 1)$$

且 $\hat{S}^2(1) \rightarrow S^2(1)$, $\hat{S}^2(0) \rightarrow S^2(0)$ (依概率)。

这个定理意味着：当样本量足够大时， $\hat{\tau}$ 的抽样分布可以用正态分布近似。这为构建置信区间提供了理论基础。

置信区间：由定义 4.3 和 Neyman 定理的第三部分，我们得到 τ 的保守大样本置信区间：

$$\hat{\tau} \pm z_{1-\alpha/2} \sqrt{\hat{V}}$$

其中 $z_{1-\alpha/2}$ 是标准正态分布的 $1 - \alpha/2$ 分位数。

与弱零假设的对偶性：通过置信区间与假设检验的对偶性，这也为检验

$$H_0 : \tau = 0$$

(称为**弱零假设**，区别于 Fisher 的 sharp null) 提供了渐近基础。

注 4.4. **为什么 Neymanian 方法只给“弱零假设”的检验？**：因为在 Neymanian 框架中，我们无法观测到 $S^2(\tau)$ ，无法精确计算方差。置信区间和检验都是渐近有效的。

8. Neymanian 推断与 OLS 的关系

实践中，许多研究者使用回归方法来估计平均因果效应。标准做法是运行 OLS 回归：

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{(a,b)} \sum_{i=1}^n (Y_i - a - bZ_i)^2$$

并使用 treatment 系数估计量 $\hat{\beta}$ 作为 τ 的估计。

关键发现：OLS 系数 $\hat{\beta}$ 恰好等于差值均值：

$$(42) \quad \hat{\beta} = \hat{\tau}$$

5

但是，OLS 的通常方差估计量与 $\hat{V}$ 不同。标准 OLS 方差估计量为：

$$(43) \quad \hat{V}_{\text{OLS}} = \frac{n(n_1 - 1)}{(n - 2)n_1 n_0} \hat{S}^2(1) + \frac{n(n_0 - 1)}{(n - 2)n_1 n_0} \hat{S}^2(0)$$

稳健标准误：幸运的是，Eicker-Huber-White (EHW) 稳健方差估计量：

$$(44) \quad \hat{V}_{\text{EHW}} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1 - 1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0 - 1}{n_0}$$

⁵证明详见附录 ??。

接近 $\hat{V}$ 。特别地，HC2 变体恰好等于 $\hat{V}$ 。⁶

实证演示 (LaLonde 数据):

```
> tauhat = mean(y[z==1]) - mean(y[z==0])
> vhat    = var(y[z==1])/n1 + var(y[z==0])/n0
> sehat   = sqrt(vhat)
> tauhat
[1] 1794.343
> sehat
[1] 670.9967
```

OLS 的通常标准误偏小:

```
> olsfit = lm(y ~ z)
> summary(olsfit)$coef[2, 1:2]
Estimate Std. Error
1794.3431    632.8536
```

使用 EHW 稳健标准误 (HC2) 得到正确结果:

```
> sqrt(hccm(olsfit, type = "hc2")[2, 2])
[1] 670.9967
```

9. 重尾结局与正态近似的失效

定义 4.3 中的有限总体 CLT 在某些正则条件下成立。当潜在结局为重尾分布时，这些条件可能被违反。

当对照潜在结果被污染时 (例如 Cauchy 分布)，正态近似效果很差。模拟研究表明，在重尾情况下，直方图和正态近似之间存在显著差异。

这提醒我们：所有基于渐近正态性的推断方法都依赖于数据的有限矩条件。在实际应用中，我们应该检查结局变量的分布特征。

10. 本章小结

本章建立了 Neymanian 推断的基础:

(1) **有限总体量** (不带 hat 的真实值): $\{\bar{Y}(1), \bar{Y}(0), S^2(1), S^2(0), S(1, 0), S^2(\tau)\}$

(2) **Lemma 4.1**: $2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$

(3) **Neyman (1923) 定理**:

- $\mathbb{E}(\hat{\tau}) = \tau$ (无偏)
- $\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- $\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau}) + \frac{S^2(\tau)}{n}$ (保守)

(4) **方差估计**: $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$

(5) **置信区间**: $\hat{\tau} \pm z_{1-\alpha/2} \sqrt{\hat{V}}$

(6) **CLT**: $\frac{\hat{\tau} - \tau}{\sqrt{\text{var}(\hat{\tau})}} \xrightarrow{d} N(0, 1)$

(7) **OLS 关系**: $\hat{\beta} = \hat{\tau}$, 但需使用 EHW 稳健标准误

下一章我们将学习如何通过**分层 (stratification)** 来提高估计的精度——这是一种利用协变量信息来改进推断的方法。

⁶详见附录 ??。

11. 习题

练习 4.1. 4.1 引理的证明 证明 Lemma 4.1: $2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$ 。

练习 4.2. 4.2 Neyman (1923) 定理的另一种证明 在 CRE 下, 计算:

$$\text{var}\{\hat{Y}(1)\}, \quad \text{var}\{\hat{Y}(0)\}, \quad \text{cov}\{\hat{Y}(1), \hat{Y}(0)\}$$

并利用这些公式推导 $\text{var}(\hat{\tau})$ 。

练习 4.3. 4.3 Neymanian 推断与 OLS 证明 eq. (42) (OLS 系数等于差值均值)。证明 EHW 稳健方差估计量的 HC2 变体恰好等于 $\hat{V}$ 。

推导见附录 ??。

练习 4.4. 4.4 治疗效应的异质性 证明 $S^2(\tau) = 0$ 蕴含 $S^2(1) = S^2(0)$ 。给出反例说明 $S^2(1) = S^2(0)$ 但 $S^2(\tau) \neq 0$ 。

证明 $S^2(1) < S^2(0)$ 蕴含 $S(Y(0), \tau) < 0$ 。给出反例说明 $S^2(1) > S^2(0)$ 但 $S(Y(0), \tau) < 0$ 。

练习 4.5. 4.5 方差公式的改进上界 证明方差公式的改进上界:

$$\text{var}(\hat{\tau}) \leq \frac{1}{n} \left\{ \sqrt{\frac{n_0}{n_1}} S(1) + \sqrt{\frac{n_1}{n_0}} S(0) \right\}^2$$

并讨论等号成立的条件。

练习 4.6. 4.6 Neyman (1923) 的向量版本 将 Neyman (1923) 的结果推广到多结局情形。考虑向量结局 $\mathbf{V} \in \mathbb{R}^K$ 的平均因果效应:

$$\tau_{\mathbf{V}} = \frac{1}{n} \sum_{i=1}^n \{\mathbf{V}_i(1) - \mathbf{V}_i(0)\}$$

证明 $\hat{\tau}_{\mathbf{V}}$ 对 $\tau_{\mathbf{V}}$ 是无偏的, 并求出其协方差矩阵。

练习 4.7. 4.7 完全随机化实验中的推断 回忆在定义 3.1 中定义的完全随机化实验。在这种设定下, 推导平均因果效应的方差公式, 并比较其与 CRE 中方差的差异。

练习 4.8. 4.8 推荐阅读 **推荐阅读:** ? 重新审视了因果推断中的一些经典问题。? 是关于因果推断的权威综述。

历史注记: Neyman 1923 年的原始论文 ? 奠定了有限总体推断的基础。当代统计学家将其视为因果推断范式的里程碑。

分层与后分层随机实验

1. 引言：随机化的艺术

“Block what you can and randomize what you cannot.” — (?, page 103)

这是 George Box 继“所有模型都是错的，但有些有用”之后第二著名的名言。本章将解释它的含义。

在第 4 章的完全随机实验 (CRE) 中，治疗分配完全由 chance 决定。这种设计在大样本下表现优异，但在一个有限实验中，治疗组和对照组可能在某些协变量上出现不平衡。这种现象在统计文献中被称为 **covariate imbalance** (协变量不平衡)。

为什么 covariate imbalance 令人担忧？因为它会使实验结果的解释变得困难——我们观察到的结果差异可能归因于 treatment 的效果，也可能仅仅是由于协变量分布不均造成的。这个问题促使我们思考：能否在设计阶段就主动控制这种不平衡？

分层随机实验 (Stratified Randomized Experiment, SRE) 正是为了解决这个问题而设计的。

2. SRE 的定义与记号

考虑一个包含 n 个单元的有限总体，协变量 $X_i \in \{1, \dots, K\}$ 是离散的。记

$$n_{[k]} = \#\{i : X_i = k\}, \quad \pi_{[k]} = n_{[k]}/n$$

分别为第 k 层的单元数和比例 ($k = 1, \dots, K$)。

在 CRE 中，我们固定总的 n_1 和 n_0 ，但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。即使在 CRE 中，各层治疗组和对照组比例之差的期望为零：¹

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0, \quad \text{但} \quad \frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \neq 0 \text{ 以高概率成立.}$$

直观理解：期望为零说明随机化保证了渐近公平性，但有限样本中的随机波动可能导致显著的不平衡。这个观察促使我们思考：能否在设计阶段就主动控制这种不平衡？

定义 5.1 (分层随机实验 (SRE)). 固定 $n_{[k]1}$ 或 $n_{[k]0}$ ($k = 1, \dots, K$)，在离散的协变量 X 的每一层内独立进行 CRE。

在农业实验中，这种设计被称为**随机区组设计 (randomized block design)**，各层称为区组 (blocks)。类似地，分层随机化也称为 block randomization。

层别倾向得分 (stratum propensity score)：

$$e_{[k]} = \frac{n_{[k]1}}{n_{[k]}}.$$

这个概念将在第 ?? 章讨论观测性研究时扮演核心角色。

SRE 与 CRE 的关键区别在于：

- (1) SRE 的所有可行随机化集合是 CRE 的可行随机化集合的子集；

¹推导见附录 ??

(2) 在 SRE 中 $e_{[k]}$ 是固定的，但在 CRE 中是随机的。

3. 层别平均因果效应

对于单元 i ，我们有潜在结果 $Y_i(1)$ 和 $Y_i(0)$ ，个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 。第 k 层的层别平均因果效应为：

$$\tau_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} \tau_i.$$

总体平均因果效应是各层别平均因果效应的加权平均：

$$\tau = n^{-1} \sum_{i=1}^n \tau_i = \sum_{k=1}^K \pi_{[k]} \tau_{[k]}.$$

基于各层的差值均值，我们可以构造 τ 的分层估计量：

$$\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]},$$

其中

$$\hat{\tau}_{[k]} = n_{[k]1}^{-1} \sum_{i=1}^n \mathbb{I}(X_i = k, Z_i = 1) Y_i - n_{[k]0}^{-1} \sum_{i=1}^n \mathbb{I}(X_i = k, Z_i = 0) Y_i$$

是第 k 层内治疗组和对照组结果均值之差。

如果我们关心 $\tau_{[k]}$ ，可以在第 k 层内使用 CRE 的方法进行推断。下面讨论对 τ 的统计推断。

4. SRE 中的 Fisher 随机化检验

与 CRE 类似，我们首先讨论 SRE 中的 Fisher 随机化检验 (FRT)。Sharp null 假设仍然是：

$$H_{0F} : Y_i(1) = Y_i(0) \text{ 对所有单元 } i = 1, \dots, n.$$

FRT 的基本思想适用于任何随机实验：我们可以用任何检验统计量 $T = T(\mathbf{Z}, \mathbf{Y}, \mathbf{X})$ ，其中 $\mathbf{Z}, \mathbf{Y}, \mathbf{X}$ 分别是治疗向量、观测结果向量和协变量矩阵。在 SRE 和 H_{0F} 下， T 具有已知分布，因为 $\mathbf{Z}$ 在 SRE 下有已知分布。

使用 FRT 时有两个关键细节需要注意：

- (1) 当模拟治疗向量时，必须根据定义 5.1 在 X 的各层内对治疗指标进行置换（这被称为**条件随机化检验**或**条件置换检验**）；
- (2) 应选择能够反映 SRE 本质的检验统计量。

4.1. 检验统计量的选择.

4.1.1. 分层差值均值估计量. 受 section 3 的启发，我们可以在 FRT 中使用分层估计量 $\hat{\tau}_{\text{SRE}}$ 作为检验统计量。

例 5.1 (section 3 的具体应用). 在 FRT 中，我们可以使用分层估计量作为检验统计量：

$$T = \hat{\tau}_S = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]},$$

其中 $\hat{\tau}_{[k]}$ 由 section 3 定义。这个统计量直接衡量了跨层的平均因果效应。

4.1.2. 学生化分层估计量. 受简单两样本问题中学生化统计量的启发, 我们可以在 FRT 中使用以下学生化统计量:

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}},$$

其中

$$\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right).$$

这里 $\hat{S}_{[k]}^2(1)$ 和 $\hat{S}_{[k]}^2(0)$ 分别是治疗组和对照组结果在第 k 层内的样本方差。²

例 5.2 (学生化分层统计量的应用). 对于 section 4.1.2 中的学生化统计量 t_{SRE} , 我们需要计算其方差估计量 $\hat{V}_{\text{SRE}}$ (由 section 4.1.2 给出)。在 FRT 中, 我们通过模拟所有可行的 *treatment* 分配来计算 t_{SRE} 的精确分布。

4.1.3. 合并 Wilcoxon 秩和统计量. 我们首先在第 k 层内计算 Wilcoxon 秩和统计量 $W_{[k]}$, 然后合并为:

$$W_{\text{SRE}} = \sum_{k=1}^K c_{[k]} W_{[k]}.$$

? 提出了两种加权方法: 一种使用 $c_{[k]} = 1/(n_{[k]1}n_{[k]0})$, 另一种使用 $c_{[k]} = 1/(n_{[k]} + 1)$ 。

例 5.3 (Van Elteren 统计量的应用). 在第 k 层内, 我们计算 Wilcoxon 秩和统计量 $W_{[k]}$ (回忆第 4 章的 Wilcoxon 秩和检验), 然后使用 section 4.1.3 合并各层统计量。Van Elteren (1960) 的两种加权方法在不同场景下各有优势。

4.1.4. Hodges–Lehmann 对齐秩统计量. Van Elteren (1960) 的统计量在层数较少且各层样本量较大时表现良好。但当层数很多且各层样本量较小时, 它不能进行足够多的比较, 可能丢失数据中的信息。? 提出了一种在对齐后进行更多跨层比较的检验统计量。

他们首先将结果中心化:

$$\tilde{Y}_i = Y_i - \bar{Y}_{[k]}, \quad \text{若 } X_i = k,$$

其中 $\bar{Y}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} Y_i$ 是第 k 层内的层别均值。然后获得池化结果 $(\tilde{Y}_1, \dots, \tilde{Y}_n)$ 的秩 $(\tilde{R}_1, \dots, \tilde{R}_n)$, 最后构建检验统计量:

$$\tilde{W} = \sum_{i=1}^n Z_i \tilde{R}_i.$$

例 5.4 (Hodges–Lehmann 对齐秩统计量). ? 的方法首先通过 section 4.1.4 对齐结果, 这消除了层间差异的影响。然后对池化结果求秩, 并使用 section 4.1.4 作为检验统计量。这种方法在多个小层情况下特别有效。

²式 section 4.1.2 和 section 4.1.2 的期望和方差推导见附录 ??。

4.1.5. *Kolmogorov-Smirnov* 统计量. 我们计算 $D_{[k]}$, 即第 k 层内治疗组和对照组结果的经验分布函数之间的最大差距. 最终的检验统计量可以是:

$$D_{\text{SRE}} = \sum_{k=1}^K c_{[k]} D_{[k]}, \quad \text{或} \quad D_{\max} = \max_{1 \leq k \leq K} c_{[k]} D_{[k]},$$

其中 $c_{[k]} = \sqrt{n_{[k]1}n_{[k]0}/n_{[k]}}$.

另一个合理的选择是:

$$D = \max_y \left| \sum_{k=1}^K \pi_{[k]} \{ \hat{F}_{[k]1}(y) - \hat{F}_{[k]0}(y) \} \right|,$$

其中 $\hat{F}_{[k]1}(y)$ 和 $\hat{F}_{[k]0}(y)$ 分别是治疗组和对照组结果在第 k 层内的经验分布函数. 统计量 D 在大层和小层情况下都适用.

例 5.5 (*Kolmogorov-Smirnov* 统计量的应用). *section 4.1.5* 中的 D_{SRE} 和 $D_{\max}$ 更适合所有层样本量都较大的情况, 而 *section 4.1.5* 中的 D 则在同时存在大小层的情况下更为稳健.

5. Neymanian 推断

5.1. 点估计与区间估计. SRE 的统计推断建立在一个事实之上: 它本质上由 K 个独立的 CRE 组成. 基于此, 我们可以将 Neyman (1923) 的结果推广到 SRE.

在第 k 层内, 差值均值 $\hat{\tau}_{[k]}$ 是 $\tau_{[k]}$ 的无偏估计, 其方差为:³

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}},$$

其中 $S_{[k]}^2(1), S_{[k]}^2(0), S_{[k]}^2(\tau)$ 分别是潜在结果和个体因果效应在第 k 层内的方差.

因此, 分层估计量 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 是 τ 的无偏估计, 方差为:⁴

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

如果 $n_{[k]1} \geq 2$ 且 $n_{[k]0} \geq 2$, 我们可以获得第 k 层内治疗组和对照组结果的样本方差 $\hat{S}_{[k]}^2(1)$ 和 $\hat{S}_{[k]}^2(0)$, 并构建一个保守方差估计量:

$$\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right).$$

基于 $\hat{\tau}_{\text{SRE}}$ 的正态近似, 我们可以构建 τ 的 Wald 型 $1 - \alpha$ 置信区间:

$$\hat{\tau}_{\text{SRE}} \pm z_{1-\alpha/2} \sqrt{\hat{V}_{\text{SRE}}}.$$

从假设检验的角度, 在 $H_{0N}: \tau = 0$ 下, 我们可以将 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 与标准正态分位数进行比较, 得到渐近 p 值.

³推导见附录 ??

⁴推导见附录 ??

6. SRE 与 CRE 的效率比较

与 CRE 相比, SRE 有什么好处? 我们从 covariate balance 的角度引入了 SRE。此外, 更好的 covariate balance 会带来更好的平均因果效应估计精度。

为了进行公平比较, 我们假设 $e_{[k]} = e$ (对所有 k), 这保证了:⁵

$$\hat{\tau} = \hat{\tau}_{\text{SRE}}.$$

我们比较抽样方差。方差分析技术启发了将总方差分解为层内方差和层间方差之和:

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \left[\frac{n_{[k]}-1}{n-1} S_{[k]}^2(1) + \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 \right], \end{aligned}$$

类似地,

$$\begin{aligned} S^2(0) &= \sum_{k=1}^K \left[\frac{n_{[k]}-1}{n-1} S_{[k]}^2(0) + \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 \right], \\ S^2(\tau) &= \sum_{k=1}^K \left[\frac{n_{[k]}-1}{n-1} S_{[k]}^2(\tau) + \frac{n_{[k]}}{n-1} \{\tau_{[k]} - \tau\}^2 \right]. \end{aligned}$$

CRE 下差值均值估计量的方差分解为:⁶

$$\begin{aligned} \text{var}_{\text{CRE}}(\hat{\tau}) &= \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} \\ &= \underbrace{\sum_{k=1}^K \left[\frac{\pi_{[k]}}{n_1} S_{[k]}^2(1) + \frac{\pi_{[k]}}{n_0} S_{[k]}^2(0) - \frac{\pi_{[k]}}{n} S_{[k]}^2(\tau) \right]}_{\text{与 SRE 相同}} \\ &\quad + \underbrace{\sum_{k=1}^K \left[\frac{\pi_{[k]}}{n_1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{\pi_{[k]}}{n_0} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{\pi_{[k]}}{n} (\tau_{[k]} - \tau)^2 \right]}_{\text{SRE 消除的项}}. \end{aligned}$$

当层样本量较大时, $\text{var}_{\text{CRE}}(\hat{\tau})$ 与 $\text{var}_{\text{SRE}}(\hat{\tau}_{\text{SRE}})$ 之差约为:⁷

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

这个差值是非负的, 当且仅当

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

对 $k = 1, \dots, K$ 都成立时才为零。当协变量能预测潜在结果时, 上述量通常不全为零, 这保证了 SRE 相对于 CRE 的效率增益。

⁵推导见附录 ??

⁶完整推导见附录 ??

⁷推导见附录 ??

7. CRE 中的后分层

在具有离散协变量 X 的 CRE 中，第 k 层内接受治疗和对照的单元数是随机的。在 SRE 中，这些数字是固定的。但如果我们在给定 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下进行条件推断，那么 CRE 就变成了 SRE。

数学上，如果 $\mathbf{n}$ 的所有分量都不为零，那么：⁸

$$\Pr_{\text{CRE}}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{\text{CRE}}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{\text{CRE}}(\mathbf{n})} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

即， $\mathbf{Z}$ 在给定 $\mathbf{n}$ 条件下从 CRE 得到的条件分布与从 SRE 得到的分布相同。

因此，在给定 $\mathbf{n}$ 的条件下，我们可以像分析 SRE 一样分析带有离散协变量 X 的 CRE。FRT 变为**条件 FRT**，Neymanian 分析变为**后分层 (post-stratification)**：

$$\hat{\tau}_{\text{PS}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}.$$

其形式与 $\hat{\tau}_{\text{SRE}}$ 相同。

分层在设计阶段使用 X ，后分层在分析阶段使用 X 。它们是使用 X 的对偶方法。

8. 实践中的问题

如何选择 X 来构建 SRE？理论上， X 应该能预测潜在结果。在某些情况下，实验者根据先导研究等对预测协变量有足够的背景知识，那么 X 的选择可以直接确定。在其他情况下，这种背景知识不够清晰，实验者反而根据方便性选择 X ——例如， X 可以是研究区域的指示变量或学生年级。

K 的选择是一个相关问题。理论上，如果所有层都足够大，增加 K 会提高估计效率。然而，极端大的 K 甚至可能降低估计效率。在模拟研究中，我们观察到增加 K 的边际收益递减。经验上， $K = 5$ 通常足以获得效率增益。

多维连续协变量怎么办？如果我们有先导研究，可以建立给定这些协变量时潜在结果 $Y(0)$ 的模型，然后选择 X 为预测量 $\hat{Y}(0)$ 的离散化版本。一般地，如果我们没有这样的先导研究或者不想做特设的离散化，我们可以使用一种更通用的策略，称为**重随机化 (rerandomization)**。

9. 本章小结

本章介绍了分层与后分层随机实验，主要内容如下：

- (1) **SRE 的动机**：CRE 可能产生不期望的治疗分配，通过分层可以主动避免 covariate imbalance。
- (2) **SRE 定义 (定义 5.1)**：在离散协变量的各层内独立进行 CRE，固定各层的治疗分配数量。
- (3) **效率增益**：当协变量能预测潜在结果时，SRE 比 CRE 更有效，因为分层消除了层间变异（见 section 6）。
- (4) **FRT 和 Neymanian 推断**：都可以推广到 SRE，分别在 section 4 和 section 5 中讨论。
- (5) **后分层**：CRE 中给定分层数量条件后，分析方法与 SRE 相同——这是使用协变量的对偶方法。

⁸证明见附录 ??

10. 习题

练习 5.1. CRE 中的协变量平衡 证明 section 2: 在 CRE 下,

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0.$$

练习 5.2. 常数层别倾向得分的结果 证明 section 6: 当所有层的层别倾向得分相等 $e_{[k]} = e$ (对所有 k) 时,

$$\hat{\tau} = \hat{\tau}_{SRE}.$$

练习 5.3. 常数个体因果效应的后果 假设个体因果效应是常数 $\tau_i = \tau$ (对所有 $i = 1, \dots, n$)。考虑以下 τ 的加权估计量类:

$$\hat{\tau}_w = \sum_{k=1}^K w_{[k]} \hat{\tau}_{[k]},$$

其中权重 $w_{[k]}$ 对所有 k 非负。

(1) 找出使 $\hat{\tau}_w$ 对 τ 无偏的 $w_{[k]}$ 条件。

(2) 在所有无偏估计量中, 找出使 $\hat{\tau}_w$ 方差最小的权重。

练习 5.4. 比较 CRE 和 SRE 证明 section 6: 当层样本量较大时, $\text{var}_{CRE}(\hat{\tau})$ 与 $\text{var}_{SRE}(\hat{\tau}_{SRE})$ 之差约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{ \bar{Y}_{[k]}(1) - \bar{Y}(1) \} + \sqrt{\frac{n_1}{n_0}} \{ \bar{Y}_{[k]}(0) - \bar{Y}(0) \} \right\}^2 \geq 0.$$

练习 5.5. 从 CRE 到 SRE 证明 section 7: 数学上, 如果 $\mathbf{n}$ 的所有分量都不为零, 那么

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

即, $\mathbf{Z}$ 在给定 $\mathbf{n}$ 条件下从 CRE 得到的条件分布与从 SRE 得到的分布相同。

练习 5.6. 更多 FRT 统计量 在 section 4.1 中, 我们介绍了多种检验统计量。选择另一种统计量 (如 Wilcoxon 秩和统计量或 Hodges-Lehmann 对齐秩统计量), 重新进行 FRT 分析。

练习 5.7. Imbens and Rubin (2015) 中的 SRE 的 FRT Imbens and Rubin (2015) 讨论了 1985-1986 年在田纳西州进行的 SRE (Student/Teacher Achievement Ratio 实验)。kindergarten 数据如下:

层对应于学校, 分析单元是教师或班级。treatment 等于 1 表示小班 (每教师 13-17 名学生), 等于 0 表示普通班 (22-25 名学生)。outcome 是标准化的平均数学成绩。

使用 FRT 重新分析 Project STAR 数据。使用 $\hat{\tau}_{SRE}$ 、 W_{SRE} 和 $\tilde{W}$ 作为 FRT 的检验统计量。比较 p 值。

注: 本书使用 Z 表示治疗指示变量, 但 Imbens and Rubin (2015) 使用 W 。

练习 5.8. 多中心试验 Gould (1998, Table 1) 报告了以下来自多中心试验的数据:

这是一个以中心为层的 SRE。该试验旨在研究非那雄胺 (用于治疗良性前列腺增生的药物) 的疗效和耐受性。在每个中心的 29 个中心内, 患者被随机分配到三个组: 对照组、非那雄胺 1mg 和非那雄胺 5mg。

由于没有报告个体水平的数据, 我们无法实施 FRT。然而, Neymanian 推断只需要汇总统计。分别报告非那雄胺 1mg 和非那雄胺 5mg 与对照组比较的点估计量和方差估计。

练习 5.9. 数据分析重新分析 重新分析第 4 章 ?? 节中使用的 *LaLonde* 数据。同时进行 *Fisherian* 和 *Neymanian* 推断。

回归调整与协变量平衡

1. 引言：从分层到连续协变量

在第 5 章中，我们遇到了分层随机实验 (SRE)。这种设计通过在离散的协变量（如性别、年龄段）上分层，在**设计阶段**主动控制协变量不平衡。

然而，现实中的协变量往往是连续的——think of 身高、体重、血压、基线考试成绩。这些连续型协变量无法简单地离散化为有限个层，否则会遇到“维数灾难”：层数指数增长，每层样本量急剧减少。

一个自然的问题产生：当协变量是连续的多维向量时，我们如何在保持随机化优点的同时，利用这些协变量来提高估计效率？

本章将介绍两种互补的策略：

- (1) **重随机化 (Rerandomization, ReM)**：在设计阶段使用 Mahalanobis 距离控制协变量不平衡
- (2) **回归调整 (Regression Adjustment)**：在分析阶段利用线性模型调整协变量不平衡

这两种策略可以在设计阶段与分析阶段分别使用，也可以在同一实验中联合使用 (section 7)。

2. 重随机化：设计阶段的协变量平衡

2.1. 问题起源：Cox (1982) 的洞见。考虑一个包含 n 个单元的有限总体，协变量矩阵 $\mathbf{X} \in \mathbb{R}^{n \times K}$ 是固定的。每个单元 i 的协变量向量为 $X_i \in \mathbb{R}^K$ ，可以包含连续或二元分量。为简化记号，将协变量中心化至均值零： $\bar{X} = n^{-1} \sum_{i=1}^n X_i = 0$ 。

在完全随机实验 (CRE) 中，治疗向量 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 从所有满足 $\sum Z_i = n_1$ 的向量中均匀抽取。随机化保证了协变量在治疗组和对照组之间的**期望平衡**，但无法保证有限样本中的**实现平衡**。

我们用治疗组和对照组协变量均值之差来衡量不平衡程度：

$$\hat{\tau}_X = n_1^{-1} \sum_{i=1}^n Z_i X_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) X_i.$$

在 CRE 下， $\mathbb{E}(\hat{\tau}_X) = 0$ ，但 $\hat{\tau}_X$ 的实现值往往不为零。使用 Neyman (1923) 的向量形式记号，可以证明：¹

$$\text{cov}(\hat{\tau}_X) = \frac{n}{n_1 n_0} S_X^2,$$

其中 $S_X^2 = (n-1)^{-1} \sum_{i=1}^n X_i X_i^\top$ 是协变量的有限总体协方差矩阵。

¹详细推导见附录 section 11.1

2.2. Mahalanobis 距离. 为了综合衡量 K 维协变量的不平衡程度, ReM 使用 Mahalanobis 距离:

$$M = \hat{\tau}_X^\top \text{cov}(\hat{\tau}_X)^{-1} \hat{\tau}_X = \hat{\tau}_X^\top \left(\frac{n}{n_1 n_0} S_X^2 \right)^{-1} \hat{\tau}_X.$$

Mahalanobis 距离的一个优美性质是它对协变量的非奇异线性变换保持不变。

引理 6.1 (引理 6.1 — Mahalanobis 距离的不变性). 式 section 2.2 中的 M 在变换 $X_i \mapsto b_0 + BX_i$ (其中 $b_0 \in \mathbb{R}^K$, $B \in \mathbb{R}^{K \times K}$ 可逆) 下保持不变。

为什么这个性质重要? 因为它意味着在使用 Mahalanobis 距离时, 我们不必担心协变量的量纲问题——无论是用米还是厘米, 用摄氏度还是华氏度, M 的数值都不会改变。

有限总体中心极限定理 (Li and Ding, 2017) 保证: 当 n 足够大时, 在 CRE 下 M 近似服从 χ_K^2 分布, 渐近期望为 K , 方差为 $2K$ 。因此, 在 CRE 下 M 的实现值很可能很大。

重随机化的核心思想是: **拒绝那些协变量不平衡的治疗分配。**

2.3. ReM 的正式定义.

定义 6.2 (重随机化 (ReM)). 从 CRE 中抽取治疗向量 $\mathbf{Z}$, 当且仅当 $M \leq a$ 时接受, 其中 $a > 0$ 是预定阈值。

阈值 a 的选择类似于 SRE 中层数的选择——这是一个在实践中非平凡的问题。当 $a = \infty$ 时, ReM 退化为普通 CRE; 当 $a = 0$ 时, 只有极少数可行的治疗分配, 实验几乎没有随机性。折中方案是选择一个小但不极小的 a , 例如取 χ_K^2 分布的上分位数 (如 0.001 分位数)。

几何直观: ReM 通过约束协变量均值之差 $\hat{\tau}_X$ 的大小, 在设计阶段“塑造”了实验的几何结构。Morgan 和 Rubin (2012) 的研究表明, 这种设计具有优雅的数学理论和良好的几何性质。

3. ReM 下的统计推断

3.1. Fisher 随机化检验在 ReM 下的推广. 一个关键问题是: 如何在 ReM 下分析数据? Bruhn and McKenzie (2009) 和 Morgan and Rubin (2012) 论证, 只要我们在约束 $M \leq a$ 下模拟治疗向量 $\mathbf{Z}$, 就仍然可以使用 FRT。这在 sharp null 假设下总是给出有限样本精确 p 值。

在非 null 假设下, 推导 ReM 的有限样本性质是一个具有挑战性的问题。Li et al. (2018b) 在正则条件 (Condition 6.1) 下推导了 $\hat{\tau}$ 的渐近分布。

[条件 6.1] 当 $n \rightarrow \infty$ 时:

- (1) n_1/n 和 n_0/n 具有正极限;
- (2) $\{X_i, Y_i(1), Y_i(0), \tau_i\}$ 的有限总体协方差具有有限极限;
- (3) $\max_{1 \leq i \leq n} \{Y_i(1) - \bar{Y}(1)\}^2/n \rightarrow 0, \max_{1 \leq i \leq n} \{Y_i(0) - \bar{Y}(0)\}^2/n \rightarrow 0$, 且 $\max_{1 \leq i \leq n} X_i^\top X_i/n \rightarrow 0$ 。

3.2. ReM 的渐近分布: 几何解释. 下面给出 ReM 的主要渐近结果。为符号简洁, 记

$$L_{K,a} \sim D_1 \mid \mathbf{D}^\top \mathbf{D} \leq a,$$

其中 $\mathbf{D} = (D_1, \dots, D_K)$ 服从 K 维标准正态分布; ε 服从一元标准正态分布; $L_{K,a} \perp \varepsilon$ 。

定理 6.3 (定理 6.1 — ReM 下的渐近分布). 在 ReM ($M \leq a$) 和条件 section 3.1 下,

$$\hat{\tau} - \tau \sim \sqrt{\text{var}(\hat{\tau})} \left\{ \sqrt{R^2} L_{K,a} + \sqrt{1 - R^2} \varepsilon \right\},$$

其中

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$$

是 Neyman (1923) 的方差公式 (见第 4 章), 且

$$R^2 = \text{corr}^2(\hat{\tau}, \hat{\tau}_X)$$

是 $\hat{\tau}$ 与 $\hat{\tau}_X$ 在 CRE 下的平方多重相关系数。

虽然 Li et al. (2018b) 的证明是技术性的, 但定义 6.3 中的渐近分布有清晰的几何解释: $\hat{\tau}$ 分解为一个与 $\hat{\tau}_X$ 线性组合的分量和一个与 $\hat{\tau}_X$ 正交的分量。几何上, $\cos^2 \theta = R^2$, 其中 θ 是 $\hat{\tau}$ 与 $\hat{\tau}_X$ 之间的夹角。ReM 影响第一个分量, 但不影响第二个分量。截断正态分布 $L_{K,a}$ 源于 ReM 对第一个分量的约束。

极限情形:

- 当 $a = \infty$ (普通 CRE) 时, 渐近分布简化为 $\hat{\tau} - \tau \sim \sqrt{\text{var}(\hat{\tau})}\varepsilon$;
- 当 $a \rightarrow 0$ (完全平衡) 时, 渐近分布简化为 $\hat{\tau} - \tau \sim \sqrt{\text{var}(\hat{\tau})(1 - R^2)}\varepsilon$ 。

因此, 当阈值 a 很小时, ReM 的效率增益取决于 R^2 。 R^2 有如下等价形式:²

命题 6.4 (命题 6.1 — R^2 的等价形式). 在 CRE 下,

$$R^2 = \text{corr}^2(\hat{\tau}, \hat{\tau}_X) = \frac{n_1^{-1}S^2(1 | X) + n_0^{-1}S^2(0 | X) - n^{-1}S^2(\tau | X)}{n_1^{-1}S^2(1) + n_0^{-1}S^2(0) - n^{-1}S^2(\tau)},$$

其中 $\{S^2(1), S^2(0), S^2(\tau)\}$ 是 $\{Y_i(1), Y_i(0), \tau_i\}$ 的有限总体方差, $\{S^2(1 | x), S^2(0 | x), S^2(\tau | x)\}$ 是它们在 $(1, X_i)$ 上线性投影的相应有限总体方差。在常因果效应假设 ($\tau_i = \tau$) 下, R^2 退化为 $S^2(0 | X)/S^2(0)$, 即 $Y_i(0)$ 与 X_i 之间的有限总体平方多重相关系数。

实践含义: R^2 衡量了协变量解释结果变异的能力。当协变量是结果的强预测因子时, ReM 能显著提高效率。

置信区间: 如果我们忽视 ReM 的设计, 仍然使用 Neyman (1923) 的方差公式和正态近似来构造置信区间, 即使个体因果效应是常数的, 置信区间也会过于保守 (overcover τ)。Li et al. (2018b) 提出了基于定义 6.3 的置信区间构造方法, 我们将在 section 7 中回到推断问题。

4. 回归调整：分析阶段的协变量平衡

如果在设计阶段没有进行重随机化, 我们还能在分析阶段利用协变量吗? 本节将讨论几种回归调整策略。

4.1. 协变量调整的 Fisher 随机化检验. 协变量 $\mathbf{X}$ 是固定的, 在 H_{0F} 下观测结果也是固定的。因此, 我们可以模拟任何检验统计量 $T = T(\mathbf{Z}, \mathbf{Y}, \mathbf{X})$ 的分布并计算 p 值——FRT 的基本思想在存在额外协变量时依然适用。

Zhao and Ding (2021a) 总结了构造检验统计量的两种一般策略。

定义 6.5 (协变量调整 FRT 的伪结果策略). 基于拟合统计模型后的残差构造检验统计量。将 Y_i 对 X_i 回归得到残差 $\hat{\varepsilon}_i$, 然后将 $\hat{\varepsilon}_i$ 视为伪结果来构造检验统计量。

定义 6.6 (协变量调整 FRT 的模型输出策略). 使用回归系数作为检验统计量。将 Y_i 对 (Z_i, X_i) 回归, 取 Z_i 的系数作为检验统计量。

²推导见附录 section 11.2

关键区别：在伪结果策略中， Y_i 对 X_i 的回归不应包含治疗 Z_i ，因为我们希望伪结果在原结果满足 H_{0F} 时也满足 H_{0F} ；在模型输出策略中， Y_i 对 (Z_i, X_i) 的回归包含 Z_i ，因为我们希望用 Z_i 的系数来衡量对 H_{0F} 的偏离。

在以上两种策略中，“回归”是一个通用术语，可以是线性回归、logistic 回归，甚至机器学习算法。任何来自这两种策略的检验统计量在 H_{0F} 下都是有限样本精确的，虽然它们在备择假设下有所不同。

4.2. 从 ANCOVA 到 Lin (2013) 的估计量. 现在我们转向直接估计平均因果效应 τ 并调整观测到的协变量。

历史注记：Fisher (1925) 首先提出使用协方差分析 (ANCOVA) 来提高估计效率。这个方法在许多领域至今仍是标准做法。Fisher 建议将 Y_i 对 $(1, Z_i, X_i)$ 进行 OLS 回归，取 Z_i 的系数作为 τ 的估计量。记 Fisher 的 ANCOVA 估计量为 $\hat{\tau}_F$ 。

Berkeley 统计学教授 David A. Freedman 在 Neyman (1923) 潜在结果框架下重新分析了 Fisher 的 ANCOVA。Freedman (2008a,b) 发现了以下**负面结果**：

- (1) $\hat{\tau}_F$ 是有偏的，而简单差值均值 $\hat{\tau}$ 是无偏的。
- (2) 当 $n_1 \neq n_0$ 时， $\hat{\tau}_F$ 的渐近方差可能甚至大于 $\hat{\tau}$ 的方差。
- (3) OLS 输出的标准误在 CRE 下对 $\hat{\tau}_F$ 的真实标准误是不一致的。

Freedman 的批评促使 Berkeley 博士生 Winston Lin 在其论文中回应。Lin (2013) 发现了以下**正面结果**：

- (1) $\hat{\tau}_F$ 的偏发生在样本量趋近无穷时趋于零。
- (2) 我们可以通过使用 Y_i 对 $(1, Z_i, X_i, Z_i \times X_i)$ 的 OLS 回归中 Z_i 的系数来同时改进 $\hat{\tau}$ 和 $\hat{\tau}_F$ 的渐近效率。记 Lin (2013) 的估计量为 $\hat{\tau}_L$ 。此外，Eicker-Huber-White (EHW) 标准误在 CRE 下是 $\hat{\tau}_L$ 真实标准误的保守估计。
- (3) 在 Y_i 对 $(1, Z_i, X_i)$ 的 OLS 拟合中， $\hat{\tau}_F$ 的 EHW 标准误平方是 CRE 下其真实标准误的保守估计。

这个从 Fisher 到 Freedman 再到 Lin 的学术对话，完美展示了统计学中批评与改进的辩证过程。**Lin (2013) 的贡献在于：他不仅指出了 ANCOVA 的问题，还提出了一个简单而优雅的解决方案——在回归中加入交互项 $Z_i \times X_i$ 。**

4.3. 线性调整估计量的推导. Neyman (1923) 的结果表明，差值均值估计量 $\hat{\tau}$ 的方差取决于潜在结果的方差。直觉上，我们可以通过减小潜在结果的方差来降低估计量的方差。一族线性调整估计量是：³

$$\hat{\tau}(\beta_1, \beta_0) = n_1^{-1} \sum_{i=1}^n Z_i(Y_i - \beta_1^\top X_i) - n_0^{-1} \sum_{i=1}^n (1 - Z_i)(Y_i - \beta_0^\top X_i).$$

这个协变量调整估计量通过残差化潜在结果来尝试降低 $\hat{\tau}$ 的方差。当 $\beta_1 = \beta_0 = 0$ 时，它退化为 $\hat{\tau}$ 。对于任何固定的 β_1 和 β_0 ，它都具有均值 τ (因为 $\bar{X} = 0$)。

我们感兴趣的是找到使 $\hat{\tau}(\beta_1, \beta_0)$ 方差最小的 (β_1, β_0) 。从 OLS 拟合的性质可知，⁴

命题 6.7 (命题 6.2 — Lin 估计量的 OLS 表示). *section 4.3* 中的估计量 $\hat{\tau}(\hat{\beta}_1, \hat{\beta}_0)$ 等于 Y_i 对 $(1, Z_i, X_i, Z_i \times X_i)$ 的 OLS 回归中 Z_i 的系数，即 Lin (2013) 的估计量 $\hat{\tau}_L$ 。

Lin (2013) 进一步表明，来自定义 6.7 中 OLS 的 EHW 标准误与保守估计量 $\hat{V}(\hat{\beta}_1, \hat{\beta}_0)$ 几乎相同。直观上，这是因为我们不假设线性模型是正确的，而 EHW 标准误对模型误设是稳健的。

³详细推导见附录 section 11.3

⁴推导见附录 section 11.4

警告：渐近理论要求较大的样本量以及对潜在结果和协变量的一些正则条件。在有限样本中，由于估计系数 $\hat{\beta}_1$ 和 $\hat{\beta}_0$ 的额外不确定性，回归调整可能甚至有害。

4.4. 从预测视角理解 Lin 估计量. 我们可以用预测潜在结果的视角来看待 Lin (2013) 的估计量。使用治疗组数据，基于 X 建立 $Y(1)$ 的预测模型：

$$\hat{\mu}_1(X) = \hat{\gamma}_1 + \hat{\beta}_1^\top X.$$

类似地，使用对照组数据建立 $Y(0)$ 的预测模型：

$$\hat{\mu}_0(X) = \hat{\gamma}_0 + \hat{\beta}_0^\top X.$$

如果我们用预测模型填补缺失的潜在结果，则有如下**预测估计量**：

$$\hat{\tau}_{\text{pred}} = n^{-1} \left\{ \sum_{Z_i=1} Y_i + \sum_{Z_i=0} \hat{\mu}_1(X_i) - \sum_{Z_i=1} \hat{\mu}_0(X_i) - \sum_{Z_i=0} Y_i \right\}.$$

可以验证，⁵

$$\hat{\tau}_{\text{pred}} = \hat{\tau}_L.$$

如果我们预测所有潜在结果（即使它们已被观测），则得到**投影估计量**：

$$\hat{\tau}_{\text{proj}} = n^{-1} \sum_{i=1}^n \{ \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) \}.$$

同样地， $\hat{\tau}_{\text{proj}} = \hat{\tau}_L$ 。这些等价的表示揭示了 Lin 估计量的不同侧面。

术语注记：“predictive”和“projective”的术语来自调查抽样文献（Firth and Bennett, 1998; Ding and Li, 2018）。预测量 $\hat{\mu}_1(X)$ 和 $\hat{\mu}_0(X)$ 可以相当一般，包括更复杂的机器学习算法。然而，构造点估计只是分析 CRE 的第一步，更重要的第二步是量化与估计量相关的不确定性。

4.5. 从协变量不平衡调整视角理解 Lin 估计量. 线性调整估计量还有另一种等价形式：⁶

$$\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X,$$

其中 $\gamma = \frac{n_0}{n} \beta_1 + \frac{n_1}{n} \beta_0$ 。

类似地，Lin (2013) 的估计量有形式

$$\hat{\tau}_L = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X,$$

其中 $\hat{\gamma} = \frac{n_0}{n} \hat{\beta}_1 + \frac{n_1}{n} \hat{\beta}_0$ 。

这些形式是“调整协变量不平衡”的数学陈述——它们本质上是减去协变量均值差的某个线性组合。由于 $\hat{\tau}$ 和 $\hat{\tau}_X$ 在 CRE 下相关，适当选择的 γ 进行协变量调整可以降低 $\hat{\tau}$ 的方差。

另一个有趣的特点是，最终估计量只依赖于 γ 或 $\hat{\gamma}$ ，因此 β 系数的选择不是唯一的。Li and Ding (2020) 指出了这个简单事实。因此，Lin (2013) 的估计量只是最优估计量之一。然而，它可以通过标准 OLS 和 EHW 标准误轻松实现——这就是为什么本书专注于它。

⁵推导见附录 section 11.5

⁶推导见附录 section 11.6

5. 回归调整的补充讨论

5.1. ReM 与回归调整的对偶性. Li et al. (2018b) 指出, ReM 和 Lin (2013) 的回归调整在使用协变量的设计中是**对偶的**。更具体地说, 当 a 很小时, ReM 下 $\hat{\tau}$ 的渐近分布与 CRE 下 $\hat{\tau}_L$ 的渐近分布几乎相同。因此, ReM 在设计阶段使用协变量, 而 Lin (2013) 的回归调整在分析阶段使用协变量, 当 a 很小时能达到几乎相同的渐近效率增益。

设计阶段 vs 分析阶段: 这种对偶性意味着, 我们可以在设计阶段通过 ReM 确保协变量平衡, 然后在分析阶段通过回归调整进一步提高效率。这是一种“双保险”策略。

5.2. 回归调整与后分层的等价性. 如果我们有离散的协变量 C_i (K 个类别), 可以创建 $K - 1$ 个居中的虚拟变量:

$$X_i = (\mathbb{I}(C_i = 1) - \pi_{[1]}, \dots, \mathbb{I}(C_i = K - 1) - \pi_{[K-1]}),$$

其中 $\pi_{[k]}$ 是 $C_i = k$ 的单元比例。在这种情况下, Lin (2013) 的回归调整等价于后分层, 如下命题所述。

命题 6.8 (命题 6.3 — 回归调整与后分层的等价性). 基于 X_i 的 $\hat{\tau}_L$ 在数值上与基于 C_i 的后分层估计量 $\hat{\tau}_{PS}$ (见第 5 章) 相同。

这个命题揭示了回归调整与后分层之间的深层联系——它们本质上是处理协变量不平衡的两种不同语言。

5.3. 差分作为协变量调整的特殊情形. 在许多研究中, 一个重要的协变量 X 是治疗前的滞后结果。例如, 在教育研究中, 如果结果 Y 是治疗后测试成绩, 那么协变量 X 是基线测试成绩; 如果结果 Y 是工作培训后的对数工资, 那么协变量 X 是工作培训前的对数工资。

将滞后结果 X 作为协变量, 一个流行的估计量是令 $\beta_1 = \beta_0 = 1$ 时的增益分数或差分估计量:

$$\hat{\tau}(1, 1) = n_1^{-1} \sum_{i=1}^n Z_i(Y_i - X_i) - n_0^{-1} \sum_{i=1}^n (1 - Z_i)(Y_i - X_i).$$

第一个形式证明了“增益分数”这个名称的合理性——它本质上是增益分数 $g_i = Y_i - X_i$ 的差值均值。第二个形式证明了“差分”这个名称的合理性——它是两个均值之差的差。

关键区别: $\hat{\tau}(1, 1)$ 预先固定 $\beta_1 = \beta_0 = 1$, 而 Lin (2013) 的估计量涉及两个估计的 β 。 $\hat{\tau}(1, 1)$ 是无偏的, 而 Lin (2013) 的估计量在有限样本中是有偏的。但在理论上, Lin (2013) 的估计量在大样本下总是比 $\hat{\tau}(1, 1)$ 更有效。

6. 分层随机实验的推广

我们可能有在一个离散变量 C 上分层的实验, 同时也观测到额外的协变量 X 。如果所有层都足够大, 我们可以在各层内获得 Lin (2013) 的估计量 $\hat{\tau}_{L,[k]}$, 然后将最终估计量构造为

$$\hat{\tau}_{L,S} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{L,[k]}.$$

保守的方差估计量是

$$\hat{V}_{L,S} = \sum_{k=1}^K \pi_{[k]}^2 \hat{V}_{\text{EHW},[k]},$$

其中 $\hat{V}_{\text{EHW},[k]}$ 是层 k 内将结果对截距、治疗指标、协变量及其交互进行 OLS 拟合后的 EHW 方差估计量。重要的是, 我们需要将协变量中心化到各层特定的均值。

7. 设计策略的统一与比较

Li and Ding (2020) 统一了文献，表明我们可以结合重随机化和回归调整。即，如果我们在设计阶段进行重随机化，我们可以在分析阶段使用 Lin (2013) 的估计量和 EHW 标准误。重随机化和回归调整的结合在设计阶段改善协变量平衡，在分析阶段提高估计效率。

table 1 总结了从 Neyman (1923) 到 Li and Ding (2020) 的文献。

TABLE 1. 实验的设计与分析策略

	分析	
设计	$\hat{\tau}$ (Neyman, 1923)	$\hat{\tau}_L$ (Lin, 2013)
CRE	原始差值均值	回归调整
ReM	$\hat{\tau}$ (Li et al., 2018b)	$\hat{\tau}_L$ (Li and Ding, 2020)

table 1 中的箭头说明了：

- 箭头 1：协变量调整在 CRE 下的效率增益——渐近地， $\hat{\tau}_L$ 比 $\hat{\tau}$ 有更小的方差。
- 箭头 2：ReM 的效率增益——渐近地，ReM 下的 $\hat{\tau}$ 比 CRE 下的 $\hat{\tau}$ 有更窄的分位数范围。
- 箭头 3 和 4：ReM 与 CRE 结合的好处。

8. 模拟研究

Angrist et al. (2009) 进行了一个评估不同策略对大学新生学业成绩影响的实验。这里我使用原始数据的一个子集，聚焦于对照组和接受学业支持服务和良好成绩经济激励的治疗组。结果是第一年结束时的 GPA。两个协变量是性别和基线 GPA。

例 6.1 (模拟研究). 我们使用 Angrist et al. (2009) 数据的一个子集，评估四种设计与分析策略的表现。

代码实现 (省略数据读取和缺失值填补)：

```
# 未调整估计量
fit_unadj = lm(y ~ z)
ace_unadj = coef(fit_unadj)[2]
se_unadj = sqrt(hccm(fit_unadj, type = "hc2"))[2, 2]

# 回归调整
x = scale(x)
fit_adj = lm(y ~ z*x)
ace_adj = coef(fit_adj)[2]
se_adj = sqrt(hccm(fit_adj, type = "hc2"))[2, 2]
```

模拟结果 (2000 次蒙特卡洛复制, ReM 阈值 $\alpha = 0.05$):

	估计量	估计值	标准误	t 统计量	p 值
Neyman		0.054	0.076	0.719	0.472
Lin		0.075	0.072	1.036	0.300

调整后的估计量有更小的标准误，尽管它给出了与未调整估计量相同的 (不显著) 结论。

模拟还评估了四种设计与分析策略组合的表现。为显示 ReM 和回归调整的改进，我将误差项重新缩放了 0.1 和 0.25 倍以提高信噪比。模拟中的“真实”结果模型是非线性的，

但我们仍然使用线性调整进行估计——通过这种方式，我们可以评估在线性模型误设时估计量的性质。

主要发现：如图所示，所有估计量几乎无偏，且 ReM 和回归调整都提高了效率。当噪声水平较小时，它们更有效——这与理论预测一致。

9. 结语：协变量平衡的两种路径

本章介绍了处理连续协变量的两种互补策略：重随机化 (ReM) 和回归调整。

ReM 使用 Mahalanobis 距离作为平衡准则。我们可以考虑更一般的重随机化，将平衡准则定义为 $\mathbf{Z}$ 和 $\mathbf{X}$ 的函数。例如，我们可以使用基于 $X_i = (x_{i1}, \dots, x_{iK})^\top$ 所有坐标边际检验的准则，只在 $|\hat{\tau}_{x_k} / \sqrt{n/(n_1 n_0) S_{x_k}^2}| \leq a$ ($k = 1, \dots, K$) 时接受 $\mathbf{Z}$ 。见 Zhao and Ding (2021b) 对基于此准则及其他准则的重随机化理论的讨论。

Fisher 的 ANCOVA 多年来一直是标准方法。Lin (2013) 的改进即使在线性模型误设时也具有更好的理论性质。对于二元结果，logistic 回归在潜在结果框架下没有好的性质——即使 logistic 模型是正确的，系数估计的也是条件比值比，可能不是感兴趣的参数；如果 logistic 模型不正确，系数更难解释。如果感兴趣的参数是平均因果效应，我们仍然可以使用 Lin (2013) 的估计量分析 CRE 中的二元结果数据。Guo and Basse (2023) 将 Lin (2013) 的理论扩展到允许使用广义线性模型构造平均因果效应的估计量。

Lin (2013) 理论的其他扩展集中于高维协变量。Bloniarz et al. (2016) 关注协变量数目多于样本量的情形，建议用 LASSO 拟合代替 OLS 拟合。Lei and Ding (2021) 关注协变量数目发散而不假设稀疏性的情形，在某些正则条件下证明 Lin (2013) 的估计量仍然一致且渐近正态。Wager et al. (2016) 提出使用机器学习方法分析高维实验数据。

核心信息：ReM 和回归调整代表了协变量平衡的两种哲学——前者通过设计主动控制，后者通过分析被动调整。它们可以单独使用，也可以联合使用——联合使用能在设计阶段和分析阶段同时获益。

10. 习题

练习 6.1. *FRT under ReM* 描述在 *ReM* 下的 *FRT*。

练习 6.2. Mahalanobis 距离的不变性 证明引理 定义 6.1。

练习 6.3. 重随机化下差值均值估计量的无偏性 假设从 CRE 中抽取 $\mathbf{Z} = (Z_1, \dots, Z_n)$ ，当且仅当 $\phi(\mathbf{Z}, \mathbf{X}) = 1$ 时接受，其中 ϕ 是预定的平衡准则。证明：如果 $n_1 = n_0$ 且 $\phi(\mathbf{Z}, \mathbf{X}) = \phi(\mathbf{1}_n - \mathbf{Z}, \mathbf{X})$ ，则 $\hat{\tau}$ 对 τ 无偏。验证当 $n_1 = n_0$ 时，使用 Mahalanobis 距离的重随机化满足此条件。给出当这两个条件不满足时 $\hat{\tau}$ 对 τ 有偏的反例。

练习 6.4. R^2 的等价形式 证明命题 定义 6.4。

练习 6.5. 协变量调整 *FRT* 在协变量调整 *FRT* 中，分别在伪结果策略和模型输出策略下推导 p 值的计算方法。

练习 6.6. Lin 估计量的偏 使用蒙特卡洛模拟研究 Lin 估计量在小样本下的有限样本偏。将样本量从 $n = 20$ 变化到 $n = 500$ ，重复 1000 次，报告平均偏和均方误差。

练习 6.7. Lin 估计量的 OLS 表示 证明命题 定义 6.7 (这是纯线性代数事实)。

练习 6.8. 预测估计量的等价性 证明 $\hat{\tau}_{pred} = \hat{\tau}_L$ 。

练习 6.9. 投影估计量的等价性 证明 $\hat{\tau}_{proj} = \hat{\tau}_L$ 。

练习 6.10. 协变量不平衡调整形式 证明 $\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 和 $\hat{\tau}_L = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X$ 。

练习 6.11. 差分估计量的方差 推导 $\hat{\tau}(1,1)$ 的保守方差估计量 $\hat{V}(1,1)$ 。

练习 6.12. 回归调整与后分层的等价性 证明命题 定义 6.8。

练习 6.13. 协变量不平衡与效率 模拟研究当协变量与结果的相关性从 0.1 变化到 0.9 时，回归调整的效率增益如何变化。

练习 6.14. 高维协变量的 LASSO 调整 使用 LASSO 代替 OLS 进行回归调整，比较两者在协变量稀疏时的表现。

练习 6.15. 缺失数据的填补 在例 6.1 的模拟中，评估不同缺失值填补策略对估计量的影响。

11. 附录：推导

11.1. 协变量均值差的协方差矩阵. 背景：我们推导 $\hat{\tau}_X$ 的协方差矩阵。

目标：证明 $\text{cov}(\hat{\tau}_X) = \frac{n}{n_1 n_0} S_X^2$ 。

推导：...⁷

11.2. R^2 的等价形式推导. 背景：我们推导 R^2 的等价形式。

目标：证明命题 定义 6.4。

推导：...

11.3. 线性调整估计量的推导. 背景：我们详细推导线性调整估计量的形式。

目标：从 $\hat{\tau}(\beta_1, \beta_0)$ 的定义出发，推导其方差。

推导：...

11.4. Lin 估计量的 OLS 连接. 背景：我们证明 $\hat{\tau}(\hat{\beta}_1, \hat{\beta}_0)$ 等于 OLS 回归中 Z_i 的系数。

目标：建立线性调整估计量与 OLS 的等价性。

推导：...

11.5. 预测估计量的等价性证明. 背景：我们证明 $\hat{\tau}_{\text{pred}} = \hat{\tau}_L$ 。

目标：从预测公式推导到 Lin 估计量形式。

推导：...

11.6. 协变量不平衡调整形式推导. 背景：我们推导 $\hat{\tau}(\beta_1, \beta_0)$ 的不平衡调整形式。

目标：证明 $\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 。

推导：...

⁷详细推导见原始笔记

配对随机实验

1. 引言：从分层到配对的极致追求

在第 5 章的分层随机实验 (SRE) 中，我们将单元按协变量分层，在每层内独立进行完全随机实验。当每层只有一个治疗单元和一个对照单元时，我们得到了 SRE 的最极端形式——**配对随机实验 (Matched-Pairs Experiment, MPE)**。此时，每一层也称为一个**对 (pair)**。

MPE 看似只是 SRE 的一个特例，但它拥有独特估计和推断策略，且与观测性研究中的匹配方法密切相关（将在第 ?? 章详细讨论）。因此，本书将其独立成章。

核心问题：当协变量能够预测潜在结果时，将相似的单元配对后再随机分配治疗，能否进一步提高估计精度？

2. MPE 的定义与记号

考虑一个包含 $2n$ 个单元的实验。如果我们拥有能够预测结果的协变量，可以根据协变量的相似性将单元配对。对于单标量协变量，我们可以根据该协变量对单元排序，然后配对相邻的单元。对于多维协变量，可以定义单元之间的成对距离，然后使用贪婪算法或最优非二分匹配算法进行配对。¹

记 (i, j) 表示第 i 对中的第 j 个单元，其中 $i = 1, \dots, n$, $j = 1, 2$ 。单元 (i, j) 的潜在结果为 $Y_{ij}(1)$ （接受治疗）和 $Y_{ij}(0)$ （接受对照）。在每一对内，随机分配一个单元接受治疗，另一个接受对照。定义

$$(45) \quad Z_i = \begin{cases} 1, & \text{若第一个单元接受治疗,} \\ 0, & \text{若第二个单元接受治疗.} \end{cases}$$

定义 7.1 (配对随机实验 (MPE)). 我们有

$$(Z_i)_{i=1}^n \stackrel{IID}{\sim} \text{Bernoulli}(1/2).$$

即，治疗指示变量 $(Z_1, \dots, Z_n)$ 独立同分布，服从参数为 $1/2$ 的伯努利分布。

第 i 对内的观测结果为

$$Y_{i1} = Z_i Y_{i1}(1) + (1 - Z_i) Y_{i1}(0), \quad Y_{i2} = Z_i Y_{i2}(0) + (1 - Z_i) Y_{i2}(1).$$

因此，观测数据为 $(Z_i, Y_{i1}, Y_{i2})_{i=1}^n$ 。

3. Fisher 随机化检验

与前述实验一样，我们始终可以使用 Fisher 随机化检验 (FRT) 来检验**尖锐零假设**：

$$(46) \quad H_{0F} : Y_{ij}(1) = Y_{ij}(0) \quad \text{对所有 } i = 1, \dots, n \text{ 和 } j = 1, 2.$$

在 FRT 中，我们需要从 eq. (45) 模拟 $(Z_1, \dots, Z_n)$ 的分布。以下是基于配对内治疗组与对照组结果之差的几种经典检验统计量。

¹配对算法的详细内容见 ?。

3.1. 配对内差异. 定义配对 i 内的配对差异:

$$(47) \quad \hat{\tau}_i = \text{治疗组结果} - \text{对照组结果} = (2Z_i - 1)(Y_{i1} - Y_{i2}) = S_i(Y_{i1} - Y_{i2}),$$

其中 $S_i = 2Z_i - 1$ 是独立同分布的随机符号, 均值为 0, 方差为 1. 由于 $\hat{\tau}_i = 0$ 的配对对随机化分布没有贡献, 我们在 FRT 讨论中剔除这些配对.

配对差异的均值为

$$(48) \quad \hat{\tau} = n^{-1} \sum_{i=1}^n \hat{\tau}_i.$$

3.2. 配对 t 统计量.

例 7.1 (配对 t 统计量). 在 H_{0F} 下, $\hat{\tau}_i$ 是固定的, 而 S_i 是随机的. 因此

$$\mathbb{E}(\hat{\tau}) = 0, \quad \text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(S_i)(Y_{i1} - Y_{i2})^2 = n^{-2} \sum_{i=1}^n \hat{\tau}_i^2.$$

基于独立随机变量之和的中心极限定理, 我们有正态近似:²

$$(49) \quad \frac{\hat{\tau}}{\sqrt{n^{-2} \sum_{i=1}^n \hat{\tau}_i^2}} \rightarrow N(0, 1)$$

依分布收敛. 许多标准教科书建议在 MPE 中使用以下配对 t 统计量:

$$(50) \quad t_{pair} = \frac{\hat{\tau}}{\sqrt{\{n(n-1)\}^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2}}.$$

在 H_{0F} 下, 当 n 较大且 $\hat{\tau}$ 较小时, t_{pair} 与 eq. (49) 几乎相同.

在经典统计学中, 使用 t_{pair} 的动机基于不同框架. 当 $\hat{\tau}_i \stackrel{IID}{\sim} N(0, \sigma^2)$ 时, 可以证明 $t_{pair} \sim t(n-1)$, 即 t_{pair} 的精确分布是自由度为 $n-1$ 的 t 分布, 在大 n 下接近 $N(0, 1)$. R 函数 `t.test` 可以实现此检验. 例 7.1 的讨论给出了经典配对 t 检验的另一种证明, 无需假设数据的正态性.

3.3. Wilcoxon 符号秩统计量.

例 7.2 (Wilcoxon 符号秩统计量). 基于 $(|\hat{\tau}_1|, \dots, |\hat{\tau}_n|)$ 的秩 $(R_1, \dots, R_n)$, 我们可以定义检验统计量

$$(51) \quad W = \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i > 0) R_i.$$

在 H_{0F} 下, $|\hat{\tau}_i|$ 是固定的, 因此 R_i 也是固定的. 由此可得

$$\begin{aligned} \mathbb{E}(W) &= \frac{1}{2} \sum_{i=1}^n R_i = \frac{1}{2} \sum_{i=1}^n i = \frac{n(n+1)}{4}, \\ \text{var}(W) &= \frac{1}{4} \sum_{i=1}^n R_i^2 = \frac{1}{4} \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{24}. \end{aligned}$$

²推导见附录 section 2.1

独立随机变量之和的中心极限定理保证以下正态近似：³

$$(52) \quad \frac{W - n(n+1)/4}{\sqrt{n(n+1)(2n+1)/24}} \rightarrow N(0, 1)$$

依分布收敛。 R 函数 `wilcox.test` 可以实现精确和渐近检验。

3.4. Kolmogorov-Smirnov 型统计量.

例 7.3 (Kolmogorov-Smirnov 型统计量). 在 H_{0F} 下, 绝对值 $(|\hat{\tau}_1|, \dots, |\hat{\tau}_n|)$ 是固定的, 但符号是随机的。因此 $(\hat{\tau}_1, \dots, \hat{\tau}_n)$ 和 $-(\hat{\tau}_1, \dots, \hat{\tau}_n)$ 应具有相同分布。

设

$$\hat{F}(t) = n^{-1} \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i \leq t)$$

是 $(\hat{\tau}_1, \dots, \hat{\tau}_n)$ 的经验分布函数,

$$1 - \hat{F}(-t-) = n^{-1} \sum_{i=1}^n \mathbb{I}(-\hat{\tau}_i \leq t)$$

是 $-(\hat{\tau}_1, \dots, \hat{\tau}_n)$ 的经验分布函数, 其中 $\hat{F}(-t-)$ 是 $\hat{F}(\cdot)$ 在 $-t$ 处的左极限。Kolmogorov-Smirnov 型统计量定义为

$$(53) \quad D = \max_t |\hat{F}(t) - \hat{F}(-t-) - 1/2|.$$

? 提出了这个检验统计量并推导了其精确和渐近分布。标准软件包中未实现此统计量, 但我们可以基于 FRT 模拟其精确分布并计算 p 值。

3.5. 符号统计量.

例 7.4 (符号统计量). 符号统计量仅使用配对内差异的符号:

$$(54) \quad \Delta = \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i > 0).$$

在 H_{0F} 下,

$$\mathbb{I}(\hat{\tau}_i > 0) \stackrel{IID}{\sim} \text{Bernoulli}(1/2),$$

因此 $\Delta \sim \text{Binomial}(n, 1/2)$ 。这给出了一个基于二项分布的精确检验, R 函数 `binom.test` 可以实现。利用中心极限定理, 我们还可以基于以下正态近似进行检验:⁴

$$(55) \quad \frac{\Delta - n/2}{\sqrt{n/4}} \rightarrow N(0, 1)$$

依分布收敛。

³推导见附录 section 2.2

⁴推导见附录 section 2.3

3.6. 二值结果的 McNemar 统计量. 当结果为二值时, 我们可以更紧凑地汇总 MPE 的观测数据。给定一对, 治疗结果和对照结果可以各为 1 或 0, 形成如下 2×2 列联表:

	对照结果=1	对照结果=0
治疗结果=1	m_{11}	m_{10}
治疗结果=0	m_{01}	m_{00}

例 7.5 (McNemar 统计量). 在 H_{0F} 下, 一致对的数量 m_{11} 和 m_{00} 是固定的, $m_{10} + m_{01}$ 也是固定的。因此唯一的随机分量是 m_{10} , 其分布为

$$m_{10} \sim \text{Binomial}(m_{10} + m_{01}, 1/2).$$

这给出了一个基于二项分布的精确检验。 R 函数 `mcnemar.test` 给出基于二项分布正态近似的渐近检验:

$$(56) \quad \frac{m_{10} - (m_{10} + m_{01})/2}{\sqrt{(m_{10} + m_{01})/4}} = \frac{m_{10} - m_{01}}{\sqrt{m_{10} + m_{01}}} \rightarrow N(0, 1)$$

依分布收敛。精确 FRT 和渐近检验都不依赖于 m_{11} 或 m_{00} , 只有不一致对的数量在这些检验中起作用。

4. Neymanian 推断

第 i 对内的平均因果效应为

$$(57) \quad \tau_i = \frac{1}{2} \{Y_{i1}(1) + Y_{i2}(1) - Y_{i1}(0) - Y_{i2}(0)\},$$

所有单元的平均因果效应为

$$(58) \quad \tau = n^{-1} \sum_{i=1}^n \tau_i = (2n)^{-1} \sum_{i=1}^n \sum_{j=1}^2 \{Y_{ij}(1) - Y_{ij}(0)\}.$$

直观上, $\hat{\tau}_i$ 是 τ_i 的无偏估计, 因此 $\hat{\tau}$ 是 τ 的无偏估计。⁵

然而, 在 MPE 下, 我们无法遵循 SRE 的策略来估计 $\hat{\tau}$ 的方差。因为在每一对内, 我们只有一个治疗单元和一个对照单元, 结果的配对内样本方差无法定义。数据不允许我们在配对 i 内估计 $\hat{\tau}_i$ 的方差。

能否在 MPE 中估计 $\hat{\tau}$ 的方差? 让我们换一个视角, 忘记 MPE, 转向经典独立同分布抽样。如果 $\hat{\tau}_i$ 是均值为 μ 、方差为 σ^2 的独立同分布变量, 那么 $\hat{\tau} = n^{-1} \sum_{i=1}^n \hat{\tau}_i$ 的方差是 σ^2/n 。 σ^2 的无偏估计是样本方差 $(n-1)^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2$, 因此 $\text{var}(\hat{\tau})$ 的无偏估计是

$$(59) \quad \hat{V} = \{n(n-1)\}^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2.$$

上述讨论似乎与 MPE 完全不同。但至少它启发我们使用 $\hat{V}$, 即用 $\hat{\tau}_i$ 的配对内方差来估计 $\hat{\tau}$ 的方差。当然, 它是在不同假设下推导的。这在 MPE 中也适用吗? 定义 7.2 给出了肯定的回答。

定理 7.2 (方差估计的保守性). 在 MPE 下, 由 eq. (59) 定义的 $\hat{V}$ 是 $\hat{\tau}$ 真实方差的一个保守估计:

$$(60) \quad \mathbb{E}(\hat{V}) - \text{var}(\hat{\tau}) = \{n(n-1)\}^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \geq 0.$$

⁵完整推导见附录 section 3

' i ò¥ WšçH E(Ŷ)= p (ʎ) b
 çl dXWü JS1/ Ŷ YÈ^ o¥Zµ 9 °µ'ò¥ ¥Ü(yTr
 <šçHÆ^íÊ¥bfñ²Tµt7! Ûñ y¹ Ŷ G ç ʎ ¥¥ WZµ 7 p (ʎ)
 G ç Äñ ʎ ¥¥ =Zµb^e
 Ð-•L B" L2vK MÆEMG v"'í»

UeRV
$$p \frac{\wedge}{p(\wedge)}! L(0;1)$$

n!1 O tž5HqîëHGsfîûb® ç Zµ¥V 9 q H/Â•uW
 UekV
$$\wedge z_1 /2 \overline{\hat{V}}$$

[À 1 ¥Àq-Â b
 Ä 9 ^ „Zµ 9 Ŷ ûV[ZL¹YV PGæž Â/ 5îUb
 5 dXµPG³ad W^ „ Ŷ © ç | _ (ʎ₁;:::;ʎₙ)> Ç © É> PGæ†¥"„
 Zµ 9 b
 ^ „ Ŷ ¥ PGædP□9Ø ¹L® °³ _ Ĩ > HKUi mn? i'VÆV^d

8 Xx M Ø œ

Ù- !9" áìXÜô xM É> ¥ Æ¥ V?,>Â X_{i1} 6 X_{i2} µ
 Háîîµ¥ " P"¥xM -"¥-"xM b ftf f/ áìV[ØœxM
 [ÉB„4Ú 9rqb³
 L!Äñ†í (i;j) ûµxM X_{ij} bÐ-•),É» JS1ĭxM Øœµ ŒBî
 !{b

8XRX 6ĭ¥xM Øœ XV 6_h~ áìV[xM E†²T¥ PGæž
 —µʎ_{ij} b® ç ft—µ Uì,L!/^%ç" áìV[| ʎ_{ij} j¹4©²Tÿ /_
 d9 b \ +YÐ•f Œ JS1!{b
 áìîV[°□P" ~E†¥"T¹ _ d9 b

8XkíBØœXC áì1ÿ ¥ 9báìV[9ØxM ¥¥ =µs ʎ_{x,i} #
 (´ ʎ ZED²TM]bV[£ü

$$E(\wedge_{x,i})=0; \quad E(\wedge_x)=0;$$

"

$$+Q_p)=n^{-2}\sum_{i=1}^X\wedge_{x,i}\wedge_{x,i}^>:$$

LC¥ JS1ĭ "dîµ ʎ_{x,i} û¹, Ž5 +Q_p),¹,b® ç (Z₁;:::;Zₙ) ¥
 ,• | ʎ V?A÷ÊÖ,bË» ç » ec¥), ØœxM (´ ¥,Ü™ V?ö
 4Ú 9rqb
 Ë» ç » ec¥), áìV[ln® ì„¥BË 9

UejV
$$\wedge(\)=\wedge^{>\wedge_x}:$$

ç © i%ç ¾ 9 ¥ (´¹,báì ¬Ê4 P ^(\) ¥ZµKIÄb

^e£ün,c b2+iBRQM

^d£ün,c b2+iBRQM

³W%w•n,c b2+iBQM

ç Ø d X 9 k Z μ ¥ í Ê 9 W + Q p ; ^) ¥ B ñ í Ê 9 1

$$U \leq 9V \quad \Lambda = f n(n-1) g^{-1} \prod_{i=1}^n (\Lambda_{X,i} - \Lambda_X)(\Lambda_i - \Lambda):$$

yN áìV[9K^a''''

[illegible]
$$f v \ddot{y}^{\wedge} \quad \wedge_1 \quad \wedge_{x,i} \{ \textcircled{C} \quad \acute{E} \rangle \quad P G \mathfrak{A} \dagger H \quad \wedge_{x,i} \quad \mathbb{Y} \text{''''} b K \hat{O} \quad 9 \quad ^1$$
$$U \in V^{\otimes n} \quad \wedge_{D=1}^n (\wedge) = \wedge \quad \wedge^x \wedge_X:$$

® P G a ¢ Ÿ É ^ / D v ¨ © ¿ | ^ 1 „ ^ x, i { © É > P G a ¢ † ¥ © b
^ / D ¥ o Z μ 9 ¹

$$\hat{\nabla}_{\perp D} = \hat{\nabla} + \hat{\Lambda}^> + (Q\hat{p})\hat{\Lambda}^{2^>}\hat{\Lambda} = \hat{\nabla} + \hat{\Lambda}^> + (Q\hat{p})\hat{\Lambda}^1.$$

5 dX80æ 9 ¥ P G â d V X JS1/ xM Øæ 9 ^ /D„ M1Zµ 9
 ∇ /D V[ZL¹í»¹| ^ ¥_ 1 ¥_ „ ^X;i ¥ "É> P G æ†¥© „
 M1Zµ 9 b

μ•¥^ çl dX,j çl dX8,31 1>q 1B+F2` >m#2`nř0y42
 ì| JS1¥" eÄ¹¥ =μs î[,³1^ *_1/ GBM Uk0RjV x
 M É>Ï•Äb

e X . `r B'M¥ 6_h s

f ^Y1 \ ¥ÜÅè0bñ c R8ÖÜ ÌB ¢ss½qx 6B ¢s1½
qx ²T^Ú b - >Bbi. i4 đS" Ĩ +`Q,b,b 2HšY^s ½q
x,,1½qx/¥Ú /B77ñl¥μ´b

œ ñ J S 1 μ 2¹⁵ = 32768 Õ V ? ¥ Í s ¥ f ^ B ñ V) Ø ¥ " " b á ì » î μ
V ? ¥ Í s ¥ i 9 Ø M < ¥ ^ „ † H Ú ' T '

$$= \frac{1}{B^7} 7^2 \cdot 2^{M+2} 4^w 2^J v b^0 \frac{1}{B^7}$$
$$= MXT \quad B \cdot b \quad 4 \quad H2M; i?U/B772 \cdot 2M+2V$$
$$= \#bX/B77\ 4\ \#bU/B772`2M+2V$$
$$= \ln Q \# b \quad 4 \quad K^2 \quad M U / B 772 \quad 2 M + 2 V$$

= in M 4 b TTHvUR,k R8-

Y 7 m M + i B Q M U t V &

Y b m K U J S n 2 M m K 2 ` i 2 U t - R 8 V # b X / B 7 7 V

Y ' V f M X T B ` b

$$= T_p \quad H_{m2} \quad 4 \quad K2 \quad M U_{in} \quad M = 4 \quad in Q \# b V$$
$$= T_p H_m^2$$

(R) yXykejjeed

Ú' T' 1 0:026 V ü 8 WA ÷ Ÿ £ Ü / ' , L ! b } ; XRZ U H_{0F} / ^ ¥
Ú' Ů Ä s f b

6 B ; m ` 2 R Xr B M / ^ ¥ Ú ' Û Ä s f

dX8`Èj qQ`Fb?QT

áì×•s Ÿ1 \ ¥8`Èj qQ`Fb?QT 9n \ » Rycbñ c 3
 ë) ĩB ĩ¥ ñë)\$Ů s¥ S [ùW4AuÊî•iv«" ,4
 Ab" c-©s" xM „a©s" 2Tb
 /V9² =xM „2T# μs

¥	- ©			a ©		
	ë) R ë)	k μ´		ë) R ë)	k μ´	
R	k9	k8	@ R8 R	8e	@ 8	
k	9k	9y	k e9	e8	@ R	
j	8k	8k	y d8	dk	j	
9	dR	dy	R dN	dd	k	
8	kN	kd	k 89	9N	8	
e	8y	8y	y d8	d3	@ j	
d	eN	eN	y NR	Nk	@ R	
3	je	j9	k e9	88	N	

¿ L2vK MBw Máì9ØÄ 9„Zμ 9b N

3Xcl²

'c° ¥ Ů L JS1 ö1=, Â/
 URJS1 ¥î JS1^ a_1¥K ™T 'Ä° μBñí †í„Bñ
 v†íH ¥ !9V[Kvñ h"ªWMSb
 UkVS1 çl çl dXRí ·UM Zi AA"2`MQ12HbB
 UjV_h V[P" Ō_d9 "¥ t d9 2[X8Va qBH+Q̃t|QM
 Çd9 2[X8Va EQHKQ;Q`Qp äK9`MQ2[X8V „~|d9
 2[X8Vb
 U9V2vK MBwM Zμ 9 ∇ 2[X8V^ o¥ çl dXÄ 9„Z
 μ 9ûV[YV PGæL¹æž çl dXj
 U8VM Øœ Øœ 9 ^ /D 2[XeV „Zμ 9 ∇ /DV[YV PGæL¹
 9Ø çl dXb8

NX5

dXRS1¥Zμ £ü JS1/ ^ ¥Zμ¹

$$p(\wedge) = n^2 \sum_{i=1}^{\wedge} p(\wedge_i):$$

dXV t d9 ¥vís f £ü 2[X9N H_{OF} /

$$p \frac{\wedge}{n^2} \frac{P_n}{\wedge_i^2} ! L(0;1)$$

GsfIûb

dXxqBH+Q̃t|QM9 ¥ £ü è dXkE(W) „ p(W) ¥ Tb

dX9+L2K d9 ¥Ú's f £ü H_{OF} / m₁₀ "BMQ(m₁₀+m₀₁;1/2) b

Nœ9Øn,c b2+iBQM

e e

dXŨ L

dXZμ 9 ¥Ê £ü çl dXk JS1/

$$E(\hat{V}) - p(\hat{\gamma}) = \text{fn}(n-1)g^{-1} \sum_{i=1}^n (\hat{\epsilon}_i)^2 = 0:$$

dXPGãd £ü çl dXj^ „ Ŷ © ¿ | (̂₁;::;̂_n)> Ç © É> PGÆ
†¥" „Zμ 9 b

dXkZμ 9 £ü çl dX9+Qp;^) ¥íÊ 9¹

$$\hat{\gamma} = \text{fn}(n-1)g^{-1} \sum_{i=1}^n (\hat{\gamma}_{X;i} - \hat{\gamma}_X)(\hat{\epsilon}_i - \hat{\gamma}):$$

dXØœ 9 ¥ PGãd £ü çl dX&M Øœ 9 ^ /DV[Í»©
¿ | ^ 1 „ ^_{X;i} {© É> PGÆ†¥© b

dXN`rBM¥ L2vK MB MP` L2vK MÆEMk•s . `rBM
b áÄ 9aZμ 9 „ N8W•uWb

dX8y`Èj qQ`Fb¿Q¥ 6_hs P` 6\_h×•s 8`Èj qQ`F@
b?QLT` P`¥ t d9 T¹_ d9 b

RXc çØ£ü
RXR_K dX£ü Xík '}'š©T P_{i=1}ⁿ (a_i - a)² = P_{i=1}ⁿ a_i² - na² ñË»¿
p(W) = E(W²) - (EW)² bæ`ñ áìμ

$$\begin{aligned} n(n-1)E(\hat{V}) &= E \left(\sum_{i=1}^n \hat{\epsilon}_i^2 \right) \\ &= E \left(\sum_{i=1}^n \hat{\epsilon}_i^2 - n\hat{\gamma}^2 \right) \\ &= \sum_{i=1}^n E \left(\hat{\epsilon}_i^2 \right) - n E \left(\hat{\gamma}^2 \right) \\ &= \sum_{i=1}^n \left(p(\hat{\gamma}_i) + \hat{\epsilon}_i^2 \right) - n \left(p(\hat{\gamma}) + \hat{\gamma}^2 \right) \\ &= \sum_{i=1}^n p(\hat{\gamma}_i) - n p(\hat{\gamma}) + \sum_{i=1}^n \hat{\epsilon}_i^2 - n \hat{\gamma}^2 \\ &= n^2 p(\hat{\gamma}) - n p(\hat{\gamma}) + \sum_{i=1}^n (\hat{\epsilon}_i)^2: \end{aligned}$$

y N

$$E(\hat{V}) = p(\hat{\gamma}) + \text{fn}(n-1)g^{-1} \sum_{i=1}^n (\hat{\epsilon}_i)^2 - p(\hat{\gamma}):$$

kX c v í s f w •

e d

$$R(X) \otimes_k X \cong d(X) \oplus P(Ga^3 d(X) | (\wedge_1; \dots; \wedge_n)^{\otimes} \mathbb{C}) \oplus P(Ga^{\dagger} \mathbb{C}) \otimes \mathbb{C}^{\otimes 1}$$

$$\lambda_0 = \lambda = n^{-1} \sum_{i=1}^n \lambda_i = \lambda;$$

$$f \check{z}^2 [X_9] \check{y}^b$$

$$\Lambda^2 = (\wedge_{i=1}^{n-1} X_i)^2 = (\wedge_{i=1}^{n-1} \langle X_i \rangle)^2 = \hat{V}:$$

y N ^ „ ∇ ' L ^ P G a E † ¥ © " „ M < Z μ 9 b

k X, c v í s f w •

$kX \neq t d 9 \neq \bullet K \zeta \emptyset$ $X H_{0F} / \wedge = S_i D_i \ddot{I}$ $S_i = 2Z_i \quad 12 f \quad 1; 1g$
 $\wedge \hat{U} \sim | \quad D_i = Y_{i1} \quad Y_{i2} \quad \wedge \% \zeta \ddot{E} " b \textcircled{R} \zeta$ $S_i \ddot{y} \ddot{e}] s f (' ^1$ $0 Z \mu ^1 \quad 1 \acute{a} \grave{I}$
 μ

$$p(\lambda_i) = E(S_i^2 D_i^2) - E(S_i)^2 E(D_i)^2 = D_i^2 - 0 = D_i^2 = \lambda_i^2.$$

® ÿ ë Û M - „ ¥ İ • K ç Ø

$$p^{\frac{E^{\wedge}}{p^{(\wedge)}}} = p^{\frac{\hat{P}}{n^2 \prod_{i=1}^n \hat{\lambda}_i^2}} ! \quad L(0; 1)$$

G s f l û b

kXkX qBH+~QcQm ¥žŸÍ» P X H_{OF} / j^j ^%ç¥ yNÇ R_i 9^
 %ç¥bçl U_i = I(^ > 0) 5 W = $\prod_{i=1}^n U_i R_i b^{\textcircled{R}} \zeta U_i^{AA} \dots 2^M Q(12) H \textcircled{D} R_i \ddot{y}$
 ë áìμ

$$E(W) = \sum_{i=1}^N E(U_i) R_i = \frac{1}{2} \sum_{i=1}^N i = \frac{n(n+1)}{4};$$

$$p(W) = \prod_{i=1}^n p(U_i) R_i^2 = \frac{1}{4} \prod_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{24}.$$

® ĩ • K ç Ø 2 [X8 W î ë b

kXjX|d9 ¥žýÍ» X H_{0F} / = $\prod_{i=1}^n I(\wedge_i > 0)$ "B M Q(k,1/2)b®
 İ• KçØ

$$-p \frac{n/2}{n/4} ! \quad L(0; 1)$$

G s f l û b

KlÄZµ¥³¹

$$\sim = + \mathcal{Q}(\mathfrak{p})^1 + \mathcal{Q}(\mathfrak{p}; \wedge):$$

®¿ + Q(p) ^X©O%ç¥ Œ + Q(p; ^) G ¿ Ã©¥. ²T áîP¨ 2[XeW
 Ĩ¥ ^T¹ íÊ 9b

KÔ }Æ ^ ¢žØœ 9 ^,D=^ ^>^χ # Zµ 9 ∇,D

8Xc 8`Èj qQ`Fb?QTW%9Ø

¿ 3 ë)¥” -©„ª©¥¥ µsÂ/

¥	-©µ´ ^χ;i	ª©µ´ ^
R	@ R	@ 8
k	k	@ R
j	y	j
9	R	k
8	k	8
e	y	@ j
d	y	@ R
3	k	N

Ä 9

$$\wedge = \frac{1}{8} \sum_{i=1}^8 \wedge_i = \frac{5 + (1) + 3 + 2 + 5 + (3) + (1) + 9}{8} = \frac{9}{8} = 1:125$$

Zµ 9 ÃØœ

$$\hat{V} = \frac{1}{8} \sum_{i=1}^8 (\wedge_i - \wedge)^2 = \frac{1}{56} (6:125)^2 + (2:125)^2 + (1:875)^2 + 4:98$$

N8W•uW ^ 1:96 ∇̄ = 1:125 1:96 2:23 = [3:25; 5:50]b
 ¿ xM Øœ 9 áî³19Ø ^ „ ^,D R R

SS1L.As

s^aL ĩ¥ 6Bb?Ô`Ä_ aim/2MiBα2/

RX_γ V *? Ti2`¥ 6\_h ž \*? Ti2`¥ × £

» j c ĩ á ĩ y ě 6Bb?Ô`Ä\_ 6\_h ¥ '•Ob b? `T LmHH
H_{0F} : Y_i(1) = Y_i(0) / 6_h © ... _ d9 ũ ó μK'''Ú'¥ T'

P(p<sub>7`i</sub> u) u 7Q` ΘHu 1:

f ^ 6_h ¥ ,•a]iiñ,G ©...sfL! °G Ũ Ä¥ŸÉb
-7 » j c 9 = / Bñ1oŨ5 á ĩ < ¾ Ê 4 I¹ _ d9 \$
°4 á ĩ³ 1 Ê 4 ? } H_{0F} ' Qff¥ _ d9 b Æ ÷ ± ó ¥ Ũ 5 ^ ,
á ĩ 1 • r2 F MmLHH_{0N} : = 0 H P" t _ d9 Â ð S μ ' (' ^ ¥
6_h V ? H_{0N} / VC , Dii . Ä V ? ^ Q o ¥ MiB @ + Q M 2 ` p i B p 2
¥ , • D ĩ £ Ÿ B ñ ^ ĩ ¥ × £ / m H ; m ` Mi 2 1 2 P b " bim / 2 M @
i B x 2 d 9 t = ^ / ∇ 6_h ü ?] H H_{0F} „ H_{0N} / VC z b ' c | W % Â • f
B² T i | ñ w < ž s^a L ai` i B } 2 / _ M / Q K B x 2 / 1 t T 2 „ B x M 2 M i - a _ 1
fTM b

kX aim/2MiBα2/ × £

kXRX * ĩ¥ aim/2MiBα2/ XIn» j c ¥ > † Ũ L *_1 n₁ ñ †
í α s í n₀ ñ α s v n = n₁ + n₀ b á ĩ 1 • ¥ ñ , L ! ^

UR<,L! a? `T LmHH

H_{0F} : Y_i(1) = Y_i(0) ĩ μ † í i = 1 ; : : : ; n :

Uk<,L! q2 F LmHH

H_{0N} : = 0 () Y(1) = Y(0):

H_{0F} / ĩ μ . ²T Ũ X © 6_h © ... _ d9 ũ ó μK'''Ú'¥ T' b
H_{0N} / Ũ (yTr<¹, Æ ñ 8 yTr<V?d, bNH ^ _ - ^ B ñ † Ø ¥ _
d9 Æ v í s f Ð H_{0F} / ¥ s f ,] i i y ¹ . ²T ¥ Z μ ² ? 3 M Ä b
Ũ Å ¥ bim / 2 Mi B α 2 / l¹

$$t = \frac{\wedge}{\nabla} p$$

ĩ ^ ^ μ ' (' 9 ∇ ^ M < ¥ Z μ 9 b R

^RT b 2 + i B α 2 Ũ - „ Z μ w • n , c \ \ b

dR

dk Xs^aL Ĩ¥ 6Aa>1Ũ Ä_ ahl.1LhAw1d9

kXkX£¥Ø, X

çØ XRU.BM; M/ . b;mTi¥UxYERdW *_1Ĩ P" bim/2MiBx2/
t ¥ 6_h μ[/ × £

URVH_{OF} / p₇·i^μK""Ú'¥

UkVH_{ON} / p₇·i^vÍ o¥ bvK TiQiB+ HHv bQM b2`p iBp2

¹|¹³¹ bim/2MiBx ~~EBQ~~ =ñ £\$ žál1 ^ „ t H_{ON} /¥>
¹b

H_{ON} / ^ ¥vís f¹

$$\wedge \doteq L\ 0; \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} \frac{S^2(\)}{n} :$$

Æ 6_h T`2i2W/ba+B2M+2@hH#H2¥ (Y_i;Y_i)_{i=1}ⁿ 'îμñ8yTr<¹
,b fñL!/ ^ ¥Ũ Äsf¹

$$\wedge \doteq L\ 0; \frac{s^2}{n_1} + \frac{s^2}{n_0} ;$$

Ĩ s² ^4©²T¥""Zμbÿi \\ „ \\i,Ä¥ii'P v""/ 6_h" \\
T¹Í»9ö H_{ON} /Á3Q o¥ T_pb

Æ'álP" bim/2MiBx2#^/ ∇ H f f?3 MÄb H_{ON} /

$$t \doteq L(0;C^2);$$

Ĩ C² 1 ©|îë¥ 1Hq^ Y_i(1) Y_i(0) = îμ†îë ' +QMbi Mi
i`2 iK2Mi 2z2+i

7 6_hÁ3¥Ũ Äsf¹

$$t \doteq L(0;1):$$

®¿‡Lsf¥Zμ C² l¿ 6_hL!¥Zμ R T' vÍil/^ o¥iif
ž^álX1¥b

1oó³ bim/2MiBx2BQCMZ μ² ¥•Y Pα 6_h¥Ũ Äsf¹
‡Lsf¥ ,b

ÿ XR\ £ü fñ × £^ bim/2MiBx2μ¥ŸÉb ðd9 ÂðS
^ ¥ 6_h H_{ON} /V?, eÄ»BËp qb

jXs^aL Ĩ¥ aim/2MiBx2/

C ál| × £w<ž» 8c),¥ a_1b
a_1Ĩ álμ K pñÖŨ¥xM^a bī` b» k a¥aYÜ(yTr<¹ [K]
98Ü(yTr<¹ = $\prod_{k=1}^K$ [k] [k] b
s^aμ'(' 9 # Zμ 9 X » 8c ó

$$\wedge_{a_1} = \bigwedge_{k=1}^{\times} [k] \wedge [k];$$

$$\hat{V}_{a_1} = \bigwedge_{k=1}^{\times} \frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} ! :$$

9XxM ¥ 6_h

dj

¿ N áîçl a_1ĩ¥ bim/2MidB9x2/

$$t_{a_1} = \frac{q^{\wedge_{a_1}}}{\hat{V}_{a_1}}:$$

çØ XkUa_ĩ 6_h¥ × £ Vx a_1ĩ P¨ bim/2MidB9x2/t_{a_1} ¥ 6_h
μ[/ × £

URVH_{0F} / p_{7`i}^μK'''Ú'¥
UkVH_{0N} / p_{7`i}^vÍ o¥b

a_ĩ 6_h¥LCĐ *_1Ë» ·B¥uY ¿ EÍ s¥H A¶

$$U \rightarrow Z, U \rightarrow Y, X \rightarrow Z, X \rightarrow Y$$

这个图对应的数据生成过程是：

$$(16.3) \quad \begin{cases} X \sim F_X(x), \\ U \sim F_U(u), \\ Z = f_Z(X, U, \varepsilon_Z), \\ Y(z) = f_Y(X, U, z, \varepsilon_Y(z)), \end{cases} \quad ??$$

其中 $\varepsilon_Z \perp \varepsilon_Y(z)$ 。从方程组中我们可以读出： $Z \perp Y(z) \mid (X, U)$ 成立，但 $Z \not\perp Y(z) \mid X$ ——不可混淆性在给定 (X, U) 时成立，但仅给定 X 时不成立。在这个情形中， U 被称为**未测混杂因素 (unmeasured confounder)**。

因果图的美学价值在于：它将不可测试的假设转化为直观的图形结构。当图中存在从 Z 到 Y 的后门路径 (backdoor path) 时，就意味着存在未被阻断的混杂。

3. 评估不可混淆性假设

3.1. 基本困难：假设本身不可检验。 回到不可混淆性假设：

$$(16.4) \quad Z \perp Y(1) \mid X, \quad Z \perp Y(0) \mid X.??$$

这个假设意味着：

$$(16.5) \quad \begin{aligned} \{Y(1) \mid Z = 1, X\} &= \{Y(1) \mid Z = 0, X\}, \\ \{Y(0) \mid Z = 1, X\} &= \{Y(0) \mid Z = 0, X\}. \end{aligned}$$

也就是说，在给定 X 的条件下，治疗组和对照组的潜在结果分布相同。但问题在于：潜在结果分布 $\{Y(1) \mid Z = 0, X\}$ 和 $\{Y(0) \mid Z = 1, X\}$ 是反事实的，我们永远无法直接从数据中观测到它们。

因此，**不可混淆性假设从根本上是不可直接检验的**——我们无法用统计检验来验证它是否成立。这并不意味着我们应该放弃因果推断，而是需要采用其他策略来评估这个假设的合理性。

统计学家区分了两个概念：**评估 (assess)** 和**检验 (test)**。前者是指补充性分析，用于支持或削弱初始分析的可信度；后者是正式的统计检验。我们无法检验不可混淆性，但可以评估它。

下面介绍两种主要的评估策略。

3.2. 策略一：利用阴性结果。核心思想：如果我们相信 $Z \perp Y(z) \mid X$ ，那么我们也倾向于相信 $Z \perp Y^n(z) \mid X$ ，其中 Y^n 是一个与 Y 具有相似混杂结构的**阴性结果 (negative outcome)**。关键在于，我们事先知道 Z 对 Y^n 的因果效应。

形式化地，假设 Y^n 满足：

$$(16.6) \quad \tau(Z \rightarrow Y^n) = \mathbb{E}\{Y^n(1) - Y^n(0)\} \text{ 是已知的.??}$$

一个特别重要的情形是 $\tau(Z \rightarrow Y^n) = 0$ ——即我们事先知道治疗对阴性结果没有因果效应。

如果不可混淆性假设成立，那么数据应该显示 Z 对 Y^n 没有处理效应（或者有已知大小的效应）。如果数据显示出显著的效应，这可能暗示不可混淆性假设被违反。

例 D.1 (Cornfield 等 (1959): 吸烟与肺癌). *Cornfield 等 (1959)* 研究了吸烟对肺癌的因果效应。他们在分析中控制了众多重要的背景变量, 但仍可能存在某些未测混杂因素使观察到的效应产生偏倚。

为了加强因果关系的证据, 他们同时报告了吸烟对车祸的影响——基于生物学知识, 吸烟对车祸应该没有因果效应。结果显示关联接近于零。因此, 即使无法完全排除未测混杂, 这个基于阴性结果的补充分析使吸烟对肺癌因果效应的证据更加有力。

例 D.2 (Jackson 等 (2006): 流感疫苗接种). *Jackson 等 (2006)* 对观测性研究的结果持怀疑态度。这些研究显示, 在调整了测量的协变量后, 流感疫苗接种显著降低了流感季节的肺炎/流感住院率和全因死亡率。

他们的补充分析考察了流感季节开始之前的结局指标。疫苗接种通常在秋季开始, 但流感传播在冬季之前是极少的。基于生物学, 疫苗效应在流感季节应该最为显著。但 *Jackson 等* 发现, 疫苗效应在流感季节之前反而更大——这暗示观察到的效应可能源于未测混杂。

阴性结果分析的力量来自于: 如果治疗 Z 通过未测混杂 U 影响结果 Y , 那么 Z 通常也会通过同样的 U 影响与 Y 有相似混杂结构的变量。因此, 如果我们在阴性结果上观察到了预期的零效应 (或已知大小的效应), 这支持了不可混淆性假设的合理性。

等 (2010) 是阴性结果方法的系统性研究。Rosenbaum (1989) 讨论了已知因果效应在因果推断中的作用。

3.3. 策略二: 利用阴性暴露. 阴性暴露是阴性结果的对偶概念。假设 Z^n 是一个与 Z 有相似混杂结构的治疗变量, 且我们事先知道 Z^n 对 Y 的因果效应:

$$(16.7) \quad \tau(Z^n \rightarrow Y) = \mathbb{E}\{Y(1^n) - Y(0^n)\} \text{ 是已知的.??}$$

例 D.3 (Sanderson 等 (2017): 母体暴露与后代结局). *Sanderson 等 (2017)* 给出了利用阴性暴露的多个例子。他们建议比较母体暴露与后代结局的关联, 以及父亲暴露与同样结局的关联。

在母体吸烟与后代结局的研究中: 母体吸烟可能受到未测混杂 (如社会经济地位) 的影响, 而父亲吸烟不太可能受到同样的混杂影响 (因为父亲不经历怀孕)。因此, 如果观察到的母体吸烟效应远大于父亲吸烟效应, 这支持了因果解释; 如果两者效应相似, 则暗示可能存在混杂。

阴性暴露分析的逻辑: 如果不可混淆性成立, 那么 Z 和 Z^n 应该表现出与 Y 相似 (但已知) 的关联模式。如果它们的行为不一致, 则暗示存在未被控制的混杂。

3.4. 小结. 不可混淆性假设在本质上是不可直接检验的。虽然阴性结果和阴性暴露分析无法证明或推翻不可混淆性, 但将它们作为补充性分析可以加强或削弱因果推断的证据基础。

然而, 进行这类补充性分析通常并非易事: 它需要更多的数据, 更重要的是需要对因果问题的深入理解, 以找到令人信服的阴性结果和阴性暴露。在实践中, 找到一个与主结果有相同混杂结构但有已知效应的阴性结果/暴露, 往往需要领域知识的支持。

4. 过度调整的问题

在第 C 章的协变量平衡检验中，我们已经看到：调整正确的协变量可以消除混杂偏倚。但**调整错误的协变量会如何？**

Rosenbaum (2002b) 写道：“没有理由避免调整描述研究对象治疗前特征的变量。”类似地，Rubin (2007) 写道：“通常，条件性越强的假设，越容易接受。”两者都主张应该控制所有观测到的治疗前协变量。

Pearl 不同意这个建议，并给出了两个著名的反例。下面我们详细介绍这两个反例。

4.1. M-偏倚. M-偏倚 (M-bias) 出现在具有 M 结构的因果图中。考虑以下图形：

$$U_1 \rightarrow X \leftarrow U_2, U_1 \rightarrow Z, U_2 \rightarrow Y$$

这个图之所以被称为 M 结构，是因为在因果图中它形似字母 M。从图中我们可以读出数据生成过程：

$$(16.8) \quad \begin{cases} U_1 \perp U_2, \\ X = f_X(U_1, U_2, \varepsilon_X), \\ Z = f_Z(U_1, \varepsilon_Z), \\ Y = Y(z) = f_Y(U_2, \varepsilon_Y), \end{cases} \quad ??$$

其中 $(\varepsilon_X, \varepsilon_Z, \varepsilon_Y)$ 是独立的随机误差。在这个因果图中， X 是观测到的，但 U_1 和 U_2 是未观测到的。如果改变 Z 的值， Y 的值完全不会改变——因为 Z 到 Y 之间没有因果路径。因此， Z 对 Y 的真实因果效应必然为零。

从数学上看：在这个数据生成过程中， $Z \perp Y$ 成立，因此 Z 和 Y 之间的简单关联为零。不调整 X 的简单估计量是无偏的：

$$(16.9) \quad \tau_{\text{PF}} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0) = 0.??$$

但是，如果我们调整 X （即条件于 X ），情况就不同了。调整后， U_1 和 U_2 不再条件独立： $U_1 \not\perp U_2 \mid X$ ，进而 $Z \not\perp Y \mid X$ ，导致调整后的估计量有偏：

$$(16.10) \quad \int \{\mathbb{E}(Y \mid Z = 1, X = x) - \mathbb{E}(Y \mid Z = 0, X = x)\} f(x) dx \neq 0.??$$

直觉解释： X 同时受到 U_1 和 U_2 的影响，而 U_1 影响 Z ， U_2 影响 Y 。当我们条件于 X 时，我们实际上是在 X 的各个取值上比较 Z 和 Y 。但 X 的条件化会人为地在 U_1 和 U_2 之间建立关联——这创造了一条从 Z 到 Y 的虚假后门路径。

为了更直观地理解，我们考虑一个正态线性模型的具体例子（详细推导见习题 D.2）：

$$(16.11) \quad \begin{cases} X = aU_1 + bU_2 + \varepsilon_X, \\ Z = cU_1 + \varepsilon_Z, \\ Y = dU_2 + \varepsilon_Y, \end{cases} \quad ??$$

其中 $(U_1, U_2, \varepsilon_X, \varepsilon_Z, \varepsilon_Y) \stackrel{\text{iid}}{\sim} N(0, 1)$ 。我们可以计算：

$$(16.12) \quad \text{cov}(Z, Y) = \text{cov}(cU_1 + \varepsilon_Z, dU_2 + \varepsilon_Y) = 0, ??$$

这证实了未调整估计量是无偏的。但在给定 X 的条件下, Z 和 Y 的偏相关系数为 (推导见习题 D.2):

$$(16.13) \quad \rho_{ZY|X} \propto -abcd, ??$$

即偏倚与路径系数的乘积 $abcd$ 成正比。

例 D.4 (M-偏倚的数值演示). 考虑样本量 $n = 10^6$ 的大规模蒙特卡洛模拟:

```
U1 = rnorm(n)
U2 = rnorm(n)
X = U1 + U2 + rnorm(n)
Y = U2 + rnorm(n)
Z = U1 + rnorm(n)

# 连续治疗
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.001
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] -0.20

# 二值治疗
Z = (Z >= 0)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.002
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] -0.42
```

未调整的简单估计量接近真实值 (0), 但调整 X 后的估计量产生了显著偏倚 (约 -0.2 到 -0.4)。这就是 M -偏倚。

M -偏倚的教训是: 并非所有治疗前协变量都应该调整。调整一个与未测混杂 U_1 和 U_2 都相关的变量 X , 可能反而在 U_1 和 U_2 之间建立虚假的关联, 从而引入偏倚。

4.2. Z-偏倚. Z-偏倚 (Z-bias) 是另一个过度调整的例子, 但机制与 M -偏倚不同。考虑以下因果图:

$$Z \leftarrow X \rightarrow U \rightarrow Y$$

其中 X 影响 Z 和 U , 而 U 同时影响 Z 和 Y 。对应的数据生成过程是:

$$(16.14) \quad \begin{cases} Z = aX + bU + \varepsilon_Z, \\ Y(z) = \tau z + cU + \varepsilon_Y, \end{cases} ??$$

其中 $(U, X, \varepsilon_Z, \varepsilon_Y) \stackrel{\text{iid}}{\sim} N(0, 1)$ 。在这个设定中, $X \perp U$, 但 X 与 Z 和 Y 都有关联—— X 通过 Z 影响 Y , 而 U 是一个未测混杂。

直觉: 治疗 Z 是 X 、未测混杂 U 和其他随机误差的函数。条件于 X 会使 Z 变得更依赖于 U , 从而放大了由 U 引起的混杂偏倚。

数学上, 未调整的 OLS 估计量是 (详细推导见习题 D.1):

$$(16.15) \quad \tau_{\text{unadj}} = \tau + \frac{c \operatorname{cov}(Z, U)}{\operatorname{var}(Z)} = \tau + \frac{cb}{a^2 + b^2 + 1}, ??$$

其偏倚为 $bc/(a^2 + b^2 + 1)$ 。

调整后的 OLS 估计量 (从 Y 对 (Z, X) 的回归) 满足 (详细推导见习题 D.1):

$$(16.16) \quad \tau_{\text{adj}} = \tau + \frac{bc}{b^2 + 1}. ??$$

比较两者：当 $a \neq 0$ 时， $a^2 + b^2 + 1 > b^2 + 1$ ，因此

$$(16.17) \quad \left| \frac{bc}{a^2 + b^2 + 1} \right| < \left| \frac{bc}{b^2 + 1} \right| .??$$

也就是说，**调整后的估计量比未调整的估计量偏倚更大！**而且， X 与 Z 的关联越强（ a 越大），调整引入的偏倚就越大。

例 D.5 (Z-偏倚的数值演示). 考虑蒙特卡洛模拟：

```
n = 10^6
X = rnorm(n)
U = rnorm(n)
Z = X + U + rnorm(n)
Y = U + rnorm(n)

# Z ~ X + U
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.333
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.501

# X-Z 关联更强时
Z = 2*X + U + rnorm(n)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.167
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.501

# X-Z 关联更强时
Z = 10*X + U + rnorm(n)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.01
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.50
```

可以看到：随着 X 与 Z 的关联增强，未调整估计量越来越接近真实值 $\tau = 0$ ，而调整后的估计量始终为 0.5——因为调整反而引入了更大的偏倚。

Z-偏倚的技术细节见 Problem D.1。Pearl (2010a, 2011) 用因果图解释了这种现象。Ding 等 (2017b) 提供了更一般的理论。

为什么叫 Z-偏倚？在 Pearl 的原始论文中，他用符号 Z 表示我们这里的变量 X （而用 X 表示治疗变量）。为了避免混淆，本书在第五部分讨论工具变量时会正式使用 Z 这个符号——这也是为什么在工具变量情境下，Z-偏倚也被称为**工具变量偏倚 (instrumental variable bias)**。

4.3. 哪些协变量应该调整？真实的因果图可能非常复杂，但我们可以用一个简化的图形来澄清许多概念。考虑以下结构：

$$X_Y \rightarrow Y, X_Y \rightarrow Z, X \rightarrow Z, X \rightarrow Y, X_I \rightarrow Z, X_I \rightarrow Y$$

各类协变量的特征如下：

- (a) X (**混杂变量**)：同时影响治疗和结果。条件于 X 确保不可混淆性假设成立，我们应该控制 X 。
- (b) X_R (**无关变量**)：既不影响治疗也不影响结果，是纯随机噪声。在分析中包含它不会引入偏倚，但会在有限样本中引入不必要的变异性。
- (c) X_Z (**工具变量**)：仅通过治疗影响结果。在图中包含它不会引入偏倚，但会增加估计量的变异性。然而，在存在未测混杂的情况下（如 Z-偏倚所示），调整 X_Z 会**放大偏倚**。

- (d) X_Y (预测变量): 仅影响结果但不影响治疗。即使不条件于它, 不可混淆性假设仍然成立。由于它们对结果有预测力, 在分析中包含它们通常能提高精度。
- (e) X_I (干预后变量): 受治疗和结果共同影响, 是治疗后变量。如果目标是推断治疗对结果的因果效应, 我们不应该调整它。

如果我们相信上述因果图的结构, 那么我们应该至少调整 X 以消除偏倚, 理想情况下还应进一步调整 X_Y 以减少方差。

实践中的困难: 我们永远无法确切知道真实的底层数据生成过程。这是因果推断的根本挑战——我们需要领域知识和假设来指导协变量的选择。

Table 1 总结了各类协变量的特征。

TABLE 1. 协变量类型与调整策略

类型	Z 前置吗?	Y 前置吗?	调整建议
X (混杂)	是	是	应该调整
X_R (无关)	否	否	可调整 (增加方差)
X_Z (工具)	是	否	谨慎: 可能放大偏倚
X_Y (预测)	否	是	可调整 (减少方差)
X_I (干预后)	是	是	不应调整

5. 习题

练习 D.1. 验证正文中的公式 ?? 和 ??。

练习 D.2. 考虑正文中的 M -偏倚正态线性模型。证明给定 X 时 Z 和 Y 的偏相关系数公式 ??。

练习 D.3. 找出一个你自己的研究领域中的阴性结果或阴性暴露的例子。讨论为什么它符合阴性控制的条件, 以及它如何帮助评估不可混淆性假设。

练习 D.4. ? 和 *econometricians* 提出了以下 **Cochran 公式** (也称为遗漏变量偏倚公式)。设 $(y_i, x_{1i}, x_{2i})_{i=1}^n$ 为 IID 样本, 其中 y_i 是标量, x_{1i} 维数为 K , x_{2i} 维数为 L 。考虑 OLS 分解:

$$y_i = \beta_1^T x_{1i} + \beta_2^T x_{2i} + \epsilon_i \quad (\text{长回归}),$$

$$y_i = \gamma^T x_{1i} + e_i \quad (\text{短回归}),$$

$$x_{2i} = \delta^T x_{1i} + v_i.$$

证明: $\gamma = \beta_1 + \delta\beta_2$ 。解释为什么 $\delta\beta_2$ 被称为遗漏变量偏倚。

练习 D.5. 设计一个模拟研究, 演示以下情形:

- 调整混杂变量 X 可以减少偏倚;
 - 调整与未测混杂相关的变量会引入 M -偏倚;
 - 调整工具变量 X_Z 在存在未测混杂时会放大偏倚。
- 对于每种情形, 使用大样本量 ($n = 10^5$) 计算未调整和调整后的估计量。

6. 推荐阅读

关于因果图和因果推断的深入讨论，见 Pearl (2000) 的经典教科书。

和 Shpitser (2011) 讨论了协变量选择的正式准则。

(2002b) 是关于观测性研究中敏感性分析的重要参考文献，也是本章许多思想的源头。

等 (2017b) 提供了 Z-偏倚（工具变量偏倚）的一般性理论。

E-Value: 未测混杂观测性研究中的因果证据

1. 引言: 当可忽略性假设失效时

“It is possible that the entire relationship between cigarette smoking and lung cancer is due to some common cause.” — (?)

在 Part III 中, 我们详细讨论了观测性研究的四大支柱: outcome regression (第 C 章)、逆倾向得分加权 (第 D 章)、双重稳健 (第 ?? 章) 以及匹配 (第 C 章)。这四种方法的核心假设是**可忽略性 (ignorability)**:

$$(79) \quad Z \perp \{Y(1), Y(0)\} \mid X.$$

即在协变量 X 条件下, 治疗分配 Z 与潜在结果相互独立。这个假设保证了我们可以从观测数据中识别因果效应。然而, **可忽略性假设无法从数据本身验证**——它是一种根本性的假设, 依赖于研究者的领域知识和对因果结构的判断。

这正是观测性研究长期被批评的原因: 如果无法控制所有混淆因素, 观察到的治疗与结果之间的关联可能是虚假的。统计学能告诉我们观测数据中的关联有多强, 但无法保证这种关联背后存在真实的因果关系。

然而, **并非所有观测性研究都生来平等**。一些研究即便存在未测混杂, 其提供的因果证据也比其他研究更强。关键在于: 要完全解释掉观察到的关联, 未测混杂需要有多强? 如果这种强度在领域知识上是不合理的, 我们就有理由相信因果关系确实存在。

本章引入的 **E-value** (VanderWeele and Ding, 2017) 正是对这一思想的数学量化。它基于 Ding and VanderWeele (2016) 的理论, 为评估观测性研究中的因果证据提供了一个统一且可解释的度量。第 ?? 章讨论平均因果效应的灵敏度分析; 第 ?? 章讨论 Rosenbaum 框架下的匹配研究灵敏度分析。

2. Cornfield 型灵敏度分析

2.1. 从可忽略性到潜在可忽略性. 放弃假设 eq. (79) 并不意味着放弃一切分析工具。我们仍然可以假设**潜在可忽略性 (latent ignorability)**:

$$(80) \quad Z \perp \{Y(1), Y(0)\} \mid (X, U),$$

其中 U 是未测混杂变量, 条件于 (X, U) 时治疗与潜在结果独立。注意 eq. (80) 比 eq. (79) 更弱——它允许 Z 与 Y 之间存在通过 U 传递的关联, 只要这种关联可以被 U 完全解释。

本章的方法在二值结果 Y 上表现最佳 (Ding and VanderWeele, 2016), 但可推广到其他非负结果。为简化叙述, 除非特别说明, 我们均假设 Y 为二值。

2.2. 真实风险比与观测风险比. 在 $X = x$ 条件下, 真实的条件风险比为:

$$(81) \quad \text{RR}_{ZY|x}^{\text{true}} = \frac{\{Y(1) = 1 \mid X = x\}}{\{Y(0) = 1 \mid X = x\}}.$$

但从数据中能直接计算的是观测风险比：

$$(82) \quad RR_{ZY|x}^{\text{obs}} = \frac{(Y = 1 \mid Z = 1, X = x)}{(Y = 1 \mid Z = 0, X = x)}.$$

在存在未测混杂 U 时，二者一般不相等。直观上，这是因为 U 在治疗组和对照组中的分布不同 (U 同时影响治疗分配和结果)，而真实的因果效应需要控制 U 后才能得到。

考虑如下因果图 (条件于 X):

$$Z \leftarrow U \rightarrow Y,$$

其中 U 是 Z 和 Y 的共同原因 (common cause)。在此结构下, $Z \perp Y \mid (X, U)$ 但 $Z \not\perp Y \mid X$ 。为简化, 我们假设 U 为二值, 尽管 Ding and VanderWeele (2016) 的理论对 U 的一般形式也成立。

定义两个灵敏度参数:

$$(83) \quad RR_{ZU|x} = \frac{(U = 1 \mid Z = 1, X = x)}{(U = 1 \mid Z = 0, X = x)},$$

衡量**治疗-混杂关联**; 以及

$$(84) \quad RR_{UY|x} = \frac{(Y = 1 \mid U = 1, X = x)}{(Y = 1 \mid U = 0, X = x)},$$

衡量**混杂-结果关联**。这两个量都无法从数据中识别——它们是未知的灵敏度参数, 反映了未测混杂的强度。

2.3. Cornfield 不等式. 下面的定理是整个 E-value 理论的基石。

定理 E.1 (Cornfield-type 上界). 在假设 eq. (80) 下, 假设

$$(85) \quad RR_{ZY|x}^{\text{obs}} > 1, \quad RR_{ZU|x} > 1, \quad RR_{UY|x} > 1.$$

则有

$$(86) \quad RR_{ZY|x}^{\text{obs}} \leq \frac{RR_{ZU|x} \cdot RR_{UY|x}}{RR_{ZU|x} + RR_{UY|x} - 1}.$$

定理 E.1 的含义: 在潜在可忽略性下, 治疗与结果之间的观测关联完全来自两条路径—— $Z \leftarrow U \rightarrow Y$ ——的组合效应。上界 $RR_{ZU|x} \cdot RR_{UY|x} / (RR_{ZU|x} + RR_{UY|x} - 1)$ 体现了这两条路径的“乘法阻塞”: 要产生一个较大的 $RR_{ZY|x}^{\text{obs}}$, 两条路径都必须足够强。

特别地, 从 eq. (86) 可推出 **Cornfield 不等式** (Gastwirth et al., 1998):

$$(87) \quad \min(RR_{ZU|x}, RR_{UY|x}) \geq RR_{ZY|x}^{\text{obs}}.$$

即: 要完全解释掉观测到的风险比, 未测混杂与治疗的关联以及与结果的关联, 都必须**至少与观测到的风险比一样强**。这个简单而强大的结论, 首次由 Cornfield et al. (1959) 在讨论吸烟与肺癌时得到。

证明思路: 定义 $f_{1,x} = (U = 1 \mid Z = 1, X = x)$ 和 $f_{0,x} = (U = 1 \mid Z = 0, X = x)$ 。通过全概率公式分解 $RR_{ZY|x}^{\text{obs}}$ 并利用 $Z \perp Y \mid (X, U)$, 可得恒等式 (100)。¹

¹完整证明推导见附录 chapter A

3. E-value

3.1. 从 Cornfield 不等式到 E-value. 从定理 E.1 和引理 E.3(4), 定义 $w = \max(\text{RR}_{ZU|x}, \text{RR}_{UY|x})$, 则

$$(88) \quad \text{RR}_{ZY|x}^{\text{obs}} \leq \frac{w^2}{2w-1}.$$

解这个二次不等式, 较小根始终 ≤ 1 , 故

$$(89) \quad w \geq \text{RR}_{ZY|x}^{\text{obs}} + \sqrt{\text{RR}_{ZY|x}^{\text{obs}}(\text{RR}_{ZY|x}^{\text{obs}} - 1)}.$$

这给出了 E-value 的定义。

定义 E.2 (E-value). 给定观测条件风险比 $\text{RR}_{ZY|x}^{\text{obs}}$, 定义 **E-value** 为

$$(90) \quad \text{E-value} = \text{RR}_{ZY|x}^{\text{obs}} + \sqrt{\text{RR}_{ZY|x}^{\text{obs}}(\text{RR}_{ZY|x}^{\text{obs}} - 1)}.$$

E-value 的解释: E-value 表示要完全解释掉观测到的风险比, $\max(\text{RR}_{ZU|x}, \text{RR}_{UY|x})$ 必须达到的最小值。换言之, 如果领域知识认为任何合理的未测混杂, 其与治疗结果的关联程度都不可能超过某个阈值 R , 那么当 $R < \text{E-value}$ 时, 我们有理由相信因果关系确实存在。

E-value 与 Fisher p 值的对比: 在随机化实验中, Fisher p 值衡量的是因果证据。但在大样本观测性研究中, p 值可能是因果证据的误导性度量——即使真实因果效应为零, 微弱的未测混杂也可以产生极小的 p 值。采样误差随样本量增大而减小, 但未测混杂带来的不确定性不会随样本量增大而消失。E-value 正是为了填补这一空白而设计的。

引理 E.3 (β 函数性质). 定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$ ($w_1 > 1, w_2 > 1$)。则:

- (a) $\beta(w_1, w_2)$ 对称于 w_1 和 w_2 ;
- (b) $\beta(w_1, w_2)$ 对 w_1 和 w_2 均单调递增;
- (c) $\beta(w_1, w_2) \leq w_1$ 且 $\beta(w_1, w_2) \leq w_2$;
- (d) $\beta(w_1, w_2) \leq w^2 / (2w - 1)$, 其中 $w = \max(w_1, w_2)$ 。

引理 E.3 的意义: (3) 意味着 Cornfield 不等式可以直接从定理 E.1 推出; (4) 是连接 Cornfield 界与 E-value 的关键步骤。²

4. 经典例子：吸烟与肺癌

例 E.1 (Hammond and Horn, 1958). 研究美国人群中吸烟与肺癌的关系。不调整协变量的数据可列为下表:

	肺癌	无肺癌
吸烟者	397	78,557
非吸烟者	51	108,778

基于该数据, 风险比估计为 $\widehat{RR} = 10.73$, 95% 置信区间为 $[8.02, 14.36]$ 。

- 解释点估计的 E-value:

$$\text{E-value} = 10.73 + \sqrt{10.73 \times 9.73} \approx 20.95.$$

²证明见附录 chapter B

- 解释下限的 *E-value*:

$$E\text{-value}_{CI} = 8.02 + \sqrt{8.02 \times 7.02} \approx 15.52.$$

解读: 要完全解释掉观察到的风险比 (甚至其置信下限), 未测混杂与治疗的关联以及与结果的关联, 都必须达到至少 15.52。这意味着未测混杂必须是一个**极强的**风险因子——它与吸烟的关联程度要接近吸烟本身与肺癌的关联程度 (10 倍以上)。在领域知识上, 这种强度的未知混杂似乎不太合理, 因此该研究提供了较强的因果证据。

图 ?? (Hammond and Horn 数据的混淆强度轮廓) 展示了要解释掉点估计和置信下限, 两类混淆强度 ($RR_{ZU|x}, RR_{UY|x}$) 需要满足的条件。

5. 扩展

5.1. E-value 与 Bradford Hill 因果判定准则. E-value 提供了因果证据的定量度量, 但它与流行病学中经典的 **Bradford Hill 准则** (Bradford Hill, 1965) 有深刻的联系。Bradford Hill 提出了九条判断因果关系的准则, 其中第一条是:

强度 (Strength) : 关联越强, 因果解释的可能性越大。

定理 E.1 从数学上精确化了这一直觉: **更强的关联需要更强的未测混杂来解释**。E-value 正是这种“强度”的量化。

当然, 关联强度只是因果判定的一个方面。Bradford Hill 的其他准则——时间顺序 (temporality)、生物学合理性 (biological plausibility)、一致性 (consistency)、剂量-反应关系 (dose-response) ——都从不同角度提供证据。E-value 只量化了“强度”这一维度。

定义 E.4 (Bradford Hill 九条因果准则). (?) 提出的九条因果判定准则:

- 强度 (*strength*);
- 一致性 (*consistency*);
- 特异性 (*specificity*);
- 时间顺序 (*temporality*);
- 生物学梯度 (*biological gradient*);
- 生物学合理性 (*plausibility*);
- 一致性 (*coherence*);
- 实验证据 (*experiment*);
- 类比 (*analogy*)。

E-value 量化了第 (1) 条准则, 但没有涉及其他八条。这是 E-value 的适用范围——它是一个有意义的补充, 但不是因果判定的全部。

5.2. 逻辑斯蒂回归后的 E-value. 流行病学研究中, 二值结果常用逻辑斯蒂回归建模:

$$(91) \quad (Y_i = 1 | Z_i, X_i) = \frac{e^{\beta_0 + \beta_1 Z_i + \beta_2^\top X_i}}{1 + e^{\beta_0 + \beta_1 Z_i + \beta_2^\top X_i}}.$$

其中系数 β_1 是给定 X 下治疗与结果的**条件比数比 (conditional odds ratio)** 的对数。逻辑斯蒂模型的一个重要假设是: 比数比在所有 X 取值上是共同的 (common odds ratio)。

当结果罕见时 ($(Y = 1 | Z, X)$ 接近 0), 条件比数比近似于条件风险比 (见附录 chapter C)。

因此，在罕见结果假设下，我们可以直接基于逻辑斯蒂回归估计的 $\hat{\beta}_1$ 计算 E-value：

$$(92) \quad \widehat{\text{E-value}} = \exp(\hat{\beta}_1) + \sqrt{\exp(\hat{\beta}_1)(\exp(\hat{\beta}_1) - 1)}.$$

这使得 E-value 可以方便地应用于常规的流行病学分析流程。

例 E.2 (NCHS 2003 出生数据). 使用美国国家卫生统计中心 2003 年出生证明数据，研究高龄母亲 (≥ 35 岁) 对早产的影响。调整社会人口学协变量后，逻辑斯蒂回归得到的条件风险比为 1.31，其 95% 置信区间为 [1.29, 1.33]。

对应的 E-value 约为 1.94 (点估计) 和 1.91 (置信下限)。这意味着要解释掉观察到的关联，未测混杂必须同时与治疗 (高龄) 和结果 (早产) 有至少 1.9 倍的关联——这个强度在流行病学上看起来是较大的，但远不如吸烟-肺癌例子中的 20.95。

5.3. 允许非零真实因果效应. 定理 E.1 假设真实因果效应为零。Ding and VanderWeele (2016) 将结果推广到允许非零真实因果效应的情形。

定理 E.5 (含真实因果效应的下界). 修改 $RR_{UY|x}$ 的定义为：

$$(93) \quad RR_{UY|x} = \max_{z=0,1} \frac{(Y=1 | Z=z, U=1, X=x)}{(Y=1 | Z=z, U=0, X=x)}.$$

则在假设 eq. (80) 下，

$$(94) \quad RR_{ZY|x}^{\text{true}} \geq \frac{RR_{ZY|x}^{\text{obs}}}{\frac{RR_{ZU|x} \cdot RR_{UY|x}}{RR_{ZU|x} + RR_{UY|x} - 1}}.$$

定理 E.5 的解读：即使存在未测混杂，定理也给出了真实因果效应 $RR_{ZY|x}^{\text{true}}$ 的一个下界。这个下界等于观测风险比除以 Cornfield 上界。当灵敏度参数取不同值时，我们可以评估因果效应下界对未测混杂强度的敏感性。

6. 批评与回应

自 E-value 论文发表以来，它已成为流行病学研究中报告的标准数字。但它也受到了批评 (Ioannidis et al., 2019)。下面讨论几个主要局限性。

6.1. E-value 不过是风险比的单调变换. 当风险比较大时，E-value 近似等于 $2 \cdot RR_{ZY|x}^{\text{obs}}$ ——几乎是线性的。因此批评者认为 E-value 不过是风险比的一个单调变换，没有提供额外信息。

这部分正确——E-value 确实完全基于风险比的点估计和置信限。但关键在于：E-value 有**有意义的解释** (定义 E.2)，而风险比本身没有这种“需要多强的未测混杂”的解释。从风险比 10.73 到 E-value 20.95，数字变了，但解释的含义完全不同。

6.2. E-value 的校准问题. E-value 等于 $\max(RR_{ZU|x}, RR_{UY|x})$ ——即要解释掉观察到的关联，未测混杂与治疗 and 结果关联所必须达到的最小值。问题在于：这个未测混杂本身是无法观测的，因此很难判断某个 E-value 究竟算“大”还是“小”。

此外，E-value 的大小取决于我们调整了多少协变量 X ——它量化的是**给定已调整协变量后的**残余混杂强度。不同研究之间的 E-value 不能直接比较，因为它们的 X 不同。

一个直观的校准思路是”逐一剔除协变量”法：如果我们把某个已调整的协变量 X_j 当作”未测混杂”来对待，计算 $Z-X_j$ 和 X_j-Y 的风险比，这些比值可以提供参考尺度。但这一方法尚无严格的理论支撑。

6.3. E-value 最适用于二值结果和风险比. 定理 E.1 在二值结果和风险比尺度上表现最佳。Ding and VanderWeele (2016) 也提出了风险差、均值比（针对非负结果）以及生存分析中的风险比（HR）的灵敏度分析方法，但它们不如二值结果下的 E-value 那样优雅和简洁。第 ?? 章将给出平均因果效应的更一般灵敏度分析方法，适用于 outcome regression、IPW 和双重稳健估计。

7. 本章小结

本章围绕 E-value 展开，核心思想是：

- (a) **未测混杂无法从数据中验证**，但我们可以量化：要解释掉观察到的关联，未测混杂必须有多强？
- (b) **Cornfield 不等式**：要完全解释掉风险比 $RR_{ZY|x}^{obs}$ ，未测混杂与治疗的关联和与结果的关联都必须至少达到 $RR_{ZY|x}^{obs}$ ；
- (c) **E-value** 是这一思想的精确数学化： $E\text{-value} = RR_{ZY|x}^{obs} + \sqrt{RR_{ZY|x}^{obs}(RR_{ZY|x}^{obs} - 1)}$ ；
- (d) E-value 越大，意味着需要越强的未测混杂才能解释掉观察到的关联，因果证据越强；
- (e) E-value 有明确的局限性——它只量化了 Bradford Hill 准则中的”强度”维度，且最适用于二值结果和风险比。

本章将所有推导放在附录，正文专注于概念的动机、历史的脉络和结果的理解。

8. 习题

[17.1] 证明函数 $f(x) = (ax+1)/(bx+1)$ 在 $a > b$ 时关于 x 单调递增，在 $a < b$ 时单调递减。

[17.2] 证明在假设 $Z \perp Y | (X, U)$ 下，如果 $RR_{ZU|x} > 1$ 但 $RR_{UY|x} < 1$ ，则 $RR_{ZY|x}^{obs} < 1$ 。这说明 eq. (85) 中的第三个条件在某种意义上是冗余的。

[17.3] 证明引理 E.3。

[17.4] (Schlesselman 1978 公式) 在二值治疗 Z 、结果 Y 和未测混杂 U 下，假设层内 ($U = 0$ 和 $U = 1$) 治疗对结果的风险比相同， $RR_{ZY|U=0} = RR_{ZY|U=1}$ ，且混杂对结果的风险比在两组治疗下也相同（记为 γ ）。证明：

$$(95) \quad \frac{RR_{ZY}^{obs}}{RR_{ZY}^{true}} = \frac{1 + (\gamma - 1)(U = 1 | Z = 1)}{1 + (\gamma - 1)(U = 1 | Z = 0)}.$$

并讨论此公式与定理 E.1 的关系。

[17.5] 使用与例 E.2 相同的数据集，计算结果为子痫前期 (preeclampsia) 时的 E-value。

[17.6] (风险差的 Cornfield 不等式) 考虑二值 Z, Y, U 。在潜在可忽略性 $Z \perp Y | U$ 下，证明风险差的 Cornfield 不等式：

$$(96) \quad RD_{ZY}^{obs} = RD_{ZU} \times RD_{UY},$$

并由此推出：

$$(97) \quad \min(RD_{ZU}, RD_{UY}) \geq RD_{ZY}^{obs}, \quad \max(RD_{ZU}, RD_{UY}) \geq \sqrt{RD_{ZY}^{obs}}.$$

9. 推荐阅读

- ?：扩展并统一了 Cornfield 型灵敏度分析，是 E-value 的理论基础。
- ?：首次正式提出 E-value 并给出其流行病学解释。
- ?：Bradford Hill 原文，九条因果准则的经典来源。
- ?：对 E-value 的批评性讨论。

APPENDIX A

附录：定理 E.1 的证明

1. 背景与目标

我们要在假设 eq. (80) 下，证明观测风险比的上界。核心思想是：条件于 (X, U) 后，治疗 Z 与结果 Y 独立，因此观测风险比中的分子和分母分别是 U 在治疗组和对照组中分布的加权平均。

2. 记号定义

定义：

$$(98) \quad f_{1,x} = (U = 1 \mid Z = 1, X = x), \quad f_{0,x} = (U = 1 \mid Z = 0, X = x).$$

由灵敏度参数的定义 eq. (83)：

$$(99) \quad \text{RR}_{ZU|x} = \frac{f_{1,x}}{f_{0,x}} \implies f_{0,x} = \frac{f_{1,x}}{\text{RR}_{ZU|x}}.$$

定义 $\gamma_x = \text{RR}_{UY|x}$ 以简化记号。

3. 详细推导

利用全概率公式，分子（治疗组的条件结果概率）为：

$$\begin{aligned} (Y = 1 \mid Z = 1, X = x) &= (Y = 1 \mid U = 1, X = x)(U = 1 \mid Z = 1, X = x) \\ &\quad + (Y = 1 \mid U = 0, X = x)(U = 0 \mid Z = 1, X = x) \\ &= \gamma_x f_{1,x} + (1 - f_{1,x}) \cdot 1 \\ &= (\gamma_x - 1)f_{1,x} + 1. \end{aligned}$$

分母（对照组的条件结果概率）为：

$$\begin{aligned} (Y = 1 \mid Z = 0, X = x) &= (Y = 1 \mid U = 1, X = x)(U = 1 \mid Z = 0, X = x) \\ &\quad + (Y = 1 \mid U = 0, X = x)(U = 0 \mid Z = 0, X = x) \\ &= \gamma_x f_{0,x} + (1 - f_{0,x}) \\ &= (\gamma_x - 1)f_{0,x} + 1. \end{aligned}$$

代入 $f_{0,x} = f_{1,x}/\text{RR}_{ZU|x}$ ，得：

$$(Y = 1 \mid Z = 0, X = x) = (\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1.$$

因此观测风险比可以写成：

$$(100) \quad \text{RR}_{ZY|x}^{\text{obs}} = \frac{(\gamma_x - 1)f_{1,x} + 1}{(\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1}.$$

4. 单调性与上界

对 $f_{1,x} \in [0, 1]$ ，可验证函数

$$g(t) = \frac{(a-1)t + 1}{(a-1)^{\frac{t}{b}} + 1}$$

在 $a > 1, b > 1$ 时关于 t 单调递增（习题 8）。因此 $f_{1,x}$ 越大， $\text{RR}_{ZY|x}^{\text{obs}}$ 越大。取上界 $f_{1,x} = 1$ ：

$$\text{RR}_{ZY|x}^{\text{obs}} \leq \frac{(\gamma_x - 1) + 1}{\frac{\gamma_x - 1}{\text{RR}_{ZU|x}} + 1} = \frac{\gamma_x \cdot \text{RR}_{ZU|x}}{\gamma_x + \text{RR}_{ZU|x} - 1}.$$

这正是定理 E.1 中的上界 eq. (86)。

5. 恒等式

由以上推导，我们实际得到了一个精确的恒等式（而非仅仅是上界）eq. (100)。这个恒等式涉及三个灵敏度参数 ($f_{1,x}, \text{RR}_{ZU|x}, \text{RR}_{UY|x}$)，而定理 E.1 的上界只涉及后两者。数学上恒等式强于不等式，但恒等式需要多一个灵敏度参数——这是灵敏度分析中**准确度与便利性之间的权衡**。

附录：引理 E.3 的证明

定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$, 其中 $w_1 > 1, w_2 > 1$ 。

性质 (1) 对称性：显然 $\beta(w_1, w_2) = \beta(w_2, w_1)$ 。

性质 (2) 单调性：计算偏导数：

$$\frac{\partial \beta}{\partial w_1} = \frac{w_2(w_1 + w_2 - 1) - w_1 w_2}{(w_1 + w_2 - 1)^2} = \frac{w_2(w_2 - 1)}{(w_1 + w_2 - 1)^2} > 0.$$

同理 $\partial \beta / \partial w_2 > 0$, 故 β 对两个变量均单调递增。

性质 (3) 上界：

$$\beta(w_1, w_2) = \frac{w_1 w_2}{w_1 + w_2 - 1} \leq \frac{w_1 w_2}{w_1} = w_2 \quad (\text{因为 } w_2 - 1 \geq 0).$$

对称地得到 $\beta \leq w_1$ 。

性质 (4) $w = \max(w_1, w_2)$ 时的界：设 $w_1 = w, w_2 \leq w$, 则

$$\beta(w_1, w_2) = \frac{w \cdot w_2}{w + w_2 - 1} \leq \frac{w \cdot w}{w + w - 1} = \frac{w^2}{2w - 1}.$$

证毕。

附录：罕见结果近似

对于二值结果 Y ，逻辑斯蒂模型 eq. (91) 中治疗指示变量 Z 的系数 β_1 是条件比数比 (odds ratio)：

$$\beta_1 = \log \text{OR}_{ZY|x} = \log \frac{\text{odds}(Y = 1 \mid Z = 1, X = x)}{\text{odds}(Y = 1 \mid Z = 0, X = x)}.$$

当结果罕见时， $(Y = 1 \mid Z = 1, X = x) \approx 0$ 且 $(Y = 1 \mid Z = 0, X = x) \approx 0$ ，此时

$$\text{odds}(Y = 1 \mid Z, X) \approx \frac{(Y = 1 \mid Z, X)}{1 - (Y = 1 \mid Z, X)} \approx (Y = 1 \mid Z, X).$$

因此罕见结果假设下，条件比数比近似于条件风险比：

$$\beta_1 \approx \log \text{RR}_{ZY|x}^{\text{obs}}.$$

由此可得 $\exp(\beta_1) \approx \text{RR}_{ZY|x}^{\text{obs}}$ ，进而 E-value 的计算公式 eq. (90) 可直接应用于逻辑斯蒂回归系数。