

$y T w \ f l$

$S 2 M ; . B M ;$

双重稳健估计

1. 引言：一个估计量的双重保险

在第 D 章中，我们遇到了一个基本的张力：使用观测数据进行因果推断时，我们需要在两个识别公式之间做出选择。

第一个是**结果回归公式** (outcome regression)：

$$\tau = E\{\mu_1(X)\} - E\{\mu_0(X)\},$$

其中 $\mu_1(X) = E(Y | Z = 1, X)$ 和 $\mu_0(X) = E(Y | Z = 0, X)$ 分别是治疗组和对照组在给定协变量 X 下的条件均值函数。这个公式的美妙之处在于：只要我们能正确建模 $\mu_1(X)$ 和 $\mu_0(X)$ ，就能一致地估计 τ 。但问题在于，如果模型错了，估计量就会产生偏倚。

第二个是**逆概率加权公式** (IPW)：

$$\tau = E\left\{\frac{ZY}{e(X)}\right\} - E\left\{\frac{(1-Z)Y}{1-e(X)}\right\},$$

其中 $e(X) = \Pr(Z = 1 | X)$ 是倾向得分。这个公式同样优雅：只要倾向得分模型正确，估计量就是一致的。但它的弱点同样明显——如果 $e(X)$ 模型错了，后果可能是灾难性的。

一个自然的问题应运而生：**能否构造一个估计量，只要两个模型中任意一个正确，就能保证一致性？**

这正是 James Robins 及其合作者 (??) 提出的双重稳健估计量 (doubly robust estimator) 的核心思想。正如我们在下面将看到的，这个估计量巧妙地结合了结果回归和逆概率加权的优点。

2. 总体版本的 DR 估计量

为了构造双重稳健估计量，我们同时引入两个工作模型 (working models)：

- **结果模型**： $\mu_1(X, \beta_1)$ 和 $\mu_0(X, \beta_0)$ ，分别建模 $E(Y(1) | X)$ 和 $E(Y(0) | X)$ 。当结果模型正确时， $\mu_1(X, \beta_1) = \mu_1(X)$ 。
- **倾向得分模型**： $e(X, \alpha)$ ，建模 $\Pr(Z = 1 | X)$ 。当倾向得分模型正确时， $e(X, \alpha) = e(X)$ 。

在实践中，这两个模型都可能错误设定——这也是为什么我们称之为“工作模型”。

基于这两个工作模型，我们定义：

$$(72) \quad \tilde{\mu}_1^{\text{dr}} = E\left[\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X, \alpha)} + \mu_1(X, \beta_1)\right],$$

$$(73) \quad \tilde{\mu}_0^{\text{dr}} = E\left[\frac{(1-Z)\{Y - \mu_0(X, \beta_0)\}}{1 - e(X, \alpha)} + \mu_0(X, \beta_0)\right].$$

这两个公式有另一种等价的书写方式，将它们重新整理为：

$$(74) \quad \tilde{\mu}_1^{\text{dr}} = E \left[\frac{ZY}{e(X, \alpha)} - \frac{Z - e(X, \alpha)}{e(X, \alpha)} \mu_1(X, \beta_1) \right],$$

$$(75) \quad \tilde{\mu}_0^{\text{dr}} = E \left[\frac{(1 - Z)Y}{1 - e(X, \alpha)} - \frac{e(X, \alpha) - Z}{1 - e(X, \alpha)} \mu_0(X, \beta_0) \right].$$

观察这两种形式，我们发现：

- eq. (72) 和 eq. (73) 是对结果回归估计量的”增强”——在结果回归的基础上添加了逆概率加权项来修正残差。
- eq. (74) 和 eq. (75) 是对 IPW 估计量的”增强”——在逆概率加权的基础上添加了插补结果的修正项。

正因为这种双向增强的结构，双重稳健估计量也被称为**增强逆概率加权估计量** (augmented inverse propensity score weighting, AIPW)。

3. 双重稳健性定理

下面这个定理是双重稳健估计量的理论核心。

定理 E.1 (双重稳健性). 假设可忽略性 $Z \perp \{Y(1), Y(0)\} \mid X$ 和 *overlap* $0 < e(X) < 1$ 。

- 若 $e(X, \alpha) = e(X)$ 或 $\mu_1(X, \beta_1) = \mu_1(X)$ 之一成立，则 $\tilde{\mu}_1^{\text{dr}} = E\{Y(1)\}$ 。
- 若 $e(X, \alpha) = e(X)$ 或 $\mu_0(X, \beta_0) = \mu_0(X)$ 之一成立，则 $\tilde{\mu}_0^{\text{dr}} = E\{Y(0)\}$ 。
- 若 $e(X, \alpha) = e(X)$ 或 $\{\mu_1(X, \beta_1) = \mu_1(X), \mu_0(X, \beta_0) = \mu_0(X)\}$ 之一成立，则 $\tilde{\mu}_1^{\text{dr}} - \tilde{\mu}_0^{\text{dr}} = \tau$ 。

为什么称为”双重”稳健？ 因为只要倾向得分模型和结果模型中任意一个正确， $\tilde{\mu}_1^{\text{dr}} - \tilde{\mu}_0^{\text{dr}}$ 就等于 τ 。这给了估计量两次”保险”的机会。¹

4. 样本版本的 DR 估计量

从总体版本 eq. (72) 和 eq. (73) 出发，我们可以用样本 analog 直接构造估计量。

定义 E.2 (平均因果效应的双重稳健估计量). 基于数据 $(X_i, Z_i, Y_i)_{i=1}^n$ ，按以下步骤构造 τ 的双重稳健估计量：

- 拟合倾向得分：得到 $e(X_i, \hat{\alpha})$ ；
- 拟合结果均值：得到 $\mu_1(X_i, \hat{\beta}_1)$ 和 $\mu_0(X_i, \hat{\beta}_0)$ ；
- 构造双重稳健估计量 $\hat{\tau}^{\text{dr}} = \hat{\mu}_1^{\text{dr}} - \hat{\mu}_0^{\text{dr}}$ ，其中

$$\hat{\mu}_1^{\text{dr}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{Z_i \{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{e(X_i, \hat{\alpha})} + \mu_1(X_i, \hat{\beta}_1) \right],$$

$$\hat{\mu}_0^{\text{dr}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{(1 - Z_i) \{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - e(X_i, \hat{\alpha})} + \mu_0(X_i, \hat{\beta}_0) \right].$$

根据定义 E.2，我们还可以将双重稳健估计量写成更直观的形式：²

$$\hat{\tau}^{\text{dr}} = \hat{\tau}^{\text{reg}} + \frac{1}{n} \sum_{i=1}^n \frac{Z_i \{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{e(X_i, \hat{\alpha})} - \frac{1}{n} \sum_{i=1}^n \frac{(1 - Z_i) \{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - e(X_i, \hat{\alpha})}.$$

¹定理 定义 E.1 的完整证明见附录 section 1。

²推导见附录 section 2

这个形式揭示了双重稳健估计量的本质：它从结果回归估计量 $\hat{\tau}^{\text{reg}}$ 出发，通过添加修正项来获得鲁棒性。类似地，利用 eq. (74) 和 eq. (75)，我们也可以写成：³

$$\hat{\tau}^{\text{dr}} = \hat{\tau}^{\text{ipw}} - \frac{1}{n} \sum_{i=1}^n \frac{Z_i - e(X_i, \hat{\alpha})}{e(X_i, \hat{\alpha})} \mu_1(X_i, \hat{\beta}_1) + \frac{1}{n} \sum_{i=1}^n \frac{e(X_i, \hat{\alpha}) - Z_i}{1 - e(X_i, \hat{\alpha})} \mu_0(X_i, \hat{\beta}_0).$$

关于方差估计，？建议使用非参数 bootstrap 来近似 $\hat{\tau}^{\text{dr}}$ 的方差。

5. 更深层的直觉

虽然 eq. (72) 和 eq. (73) 的形式看起来并不显然，但它们可以从两个不同的直观角度推导出来。这两个角度恰好对应了结果回归和 IPW 的各自弱点。

5.1. 从 IPW 出发：降低方差. IPW 估计量 $\mu_1 = E\left\{\frac{ZY}{e(X)}\right\}$ 完全忽略了 Y 的结果模型。它的优势在于不需要任何结果模型假设就能保持一致性。然而，如果协变量能够预测结果，那么即使工作结果模型错误，基于残差的伪潜在结果通常比原始结果具有更小的方差。

给定一个可能错误设定的工作模型 $\mu_1(X, \beta_1)$ ，我们可以做一个简单的分解：⁴

$$\mu_1 = E\{Y(1)\} = E\{Y(1) - \mu_1(X, \beta_1)\} + E\{\mu_1(X, \beta_1)\} = E\left\{\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X)} + \mu_1(X, \beta_1)\right\}.$$

使用工作模型来提高效率是调查采样中的传统思想。？和？都指出了它与双重稳健估计量的联系。

5.2. 从结果回归出发：降低偏倚. 另一种思路是从结果回归出发，改善其偏倚。结果回归估计量 $\tilde{\mu}_1 = E\{\mu_1(X, \beta_1)\}$ 可能不等于 μ_1 ，因为结果模型可能是错误的。这个估计量的偏倚是 $E\{\mu_1(X, \beta_1) - Y(1)\}$ ，它可以用 IPW 估计量来估计：⁵

$$B = E\left\{\frac{Z\{\mu_1(X, \beta_1) - Y\}}{e(X)}\right\},$$

只要倾向得分模型正确。因此，去偏估计量 $\tilde{\mu}_1 - B$ 恰好等于 eq. (72)。这给出了构造双重稳健估计量的第二个直观视角。

6. 模拟研究

为了评估双重稳健估计量在有限样本下的表现，我们考虑四种场景：⁶

- (a) 倾向得分模型和结果模型都正确；
- (b) 倾向得分模型错误，但结果模型正确；
- (c) 倾向得分模型正确，但结果模型错误；
- (d) 倾向得分模型和结果模型都错误。

关键发现：场景 1-3 验证了双重稳健性——只要其中一个模型正确，DR 估计量就几乎无偏。但在场景 4（两个模型都错误）中，DR 估计量可能表现出“双重脆弱性”——两个误差的乘积导致比单独使用任一模型更大的偏差。⁷

³推导见附录 section 2

⁴推导见附录 section 3

⁵推导见附录 section 4

⁶模拟细节和完整结果见附录 section 6。

⁷模拟结果表格见附录 section 6。

7. 进一步讨论：为何脆弱？

回顾 定义 E.1 的证明，双重稳健性的关键在于以下乘积结构：⁸

$$\tilde{\mu}_1^{\text{dr}} - E\{Y(1)\} = E \left[\frac{e(X) - e(X, \alpha)}{e(X, \alpha)} \times \{\mu_1(X) - \mu_1(X, \beta_1)\} \right].$$

只要 $e(X) = e(X, \alpha)$ 或 $\mu_1(X) = \mu_1(X, \beta_1)$ 之一成立，上式就为零。然而，当两个模型都错误时，两个误差的乘积可能放大偏差——这就是“双重脆弱性”的数学本质。模拟研究证实了这一点。

尽管？基于模拟研究批评了双重稳健估计量，但自？的开创性工作以来，双重稳健估计量一直是因果推断的标准策略。近年来，它在理论统计和计量经济学文献中以更响亮的名字“双机器学习”（double machine learning）重新兴起。？的基本思想是用更灵活的机器学习工具替代传统的参数工作模型。

8. 本章小结

本章介绍了双重稳健估计量，主要内容如下：

- (a) **核心思想**：结合结果回归和 IPW，只要其中一个模型正确就能保证一致性。
- (b) **公式结构 (eq. (72)–eq. (73))**：增强逆概率加权估计量 (AIPW)。
- (c) **双重稳健性(定义 E.1)**：只要倾向得分模型或结果模型之一正确， $\tilde{\mu}_1^{\text{dr}} - \tilde{\mu}_0^{\text{dr}} = \tau$ 。
- (d) **两种直觉视角**：从 IPW 降方差 (section 5.1) 和从结果回归降偏倚 (section 5.2)。
- (e) **双重脆弱性**：当两个模型都错误时，两个误差的乘积可能放大偏差。

9. 习题

练习 E.1. 验证双重稳健性 考虑协变量离散的情况 $X \in \{1, \dots, K\}$ 。证明在这种情况下，分层估计量、结果回归估计量、Horvitz-Thompson 估计量、Hajek 估计量和双重稳健估计量在数值上是完全相同的。(参见？, Theorem 12.1)

练习 E.2. DR 估计量的另一种形式 基于 eq. (72)，给出 $\mu_1 = E\{Y(1)\}$ 的双重稳健估计量的另一种形式：

$$\tilde{\mu}_1^{\text{dr2}} = \frac{E \left[\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X, \alpha)} \right]}{E \left[\frac{Z}{e(X, \alpha)} \right]} + E\{\mu_1(X, \beta_1)\}.$$

证明若 $e(X, \alpha) = e(X)$ 或 $\mu_1(X, \beta_1) = \mu_1(X)$ 之一成立，则 $\tilde{\mu}_1^{\text{dr2}} = \mu_1$ 。给出估计 μ_0 的类似公式，并给出基于这些公式的 τ 的双重稳健估计量的样本 analog。(参见？, 式 (12.7))

练习 E.3. DR 估计量的方差 证明 section 4 和 section 4 的等价性。(参见？, 式 (12.9))

⁸详细推导见附录 section 5

1. 定理 定义 E.1 的证明

背景： 我们需要证明在 ignorability 和 overlap 假设下，双重稳健估计量满足 $\tilde{\mu}_1^{\text{dr}} = E\{Y(1)\}$ 当且仅当倾向得分模型或结果模型之一正确。

证明： 这里给出第一部分的证明，第二部分类似。考虑分解：⁹

$$\begin{aligned}
 \tilde{\mu}_1^{\text{dr}} - E\{Y(1)\} &= E \left[\frac{Z\{Y(1) - \mu_1(X, \beta_1)\}}{e(X, \alpha)} - \{Y(1) - \mu_1(X, \beta_1)\} \right] \\
 &= E \left[\frac{Z - e(X, \alpha)}{e(X, \alpha)} \{Y(1) - \mu_1(X, \beta_1)\} \right] \\
 &= E \left(E \left[\frac{Z - e(X, \alpha)}{e(X, \alpha)} \{Y(1) - \mu_1(X, \beta_1)\} \mid X \right] \right) \quad (\text{tower property}) \\
 &= E \left[E \left\{ \frac{Z - e(X, \alpha)}{e(X, \alpha)} \mid X \right\} \times E \{Y(1) - \mu_1(X, \beta_1) \mid X\} \right] \quad (\text{ignorability}) \\
 &= E \left[\frac{e(X) - e(X, \alpha)}{e(X, \alpha)} \times \{\mu_1(X) - \mu_1(X, \beta_1)\} \right].
 \end{aligned}$$

由此可知，上式为零当且仅当 $e(X) = e(X, \alpha)$ 或 $\mu_1(X) = \mu_1(X, \beta_1)$ 之一成立。□

2. 双重稳健估计量的等价形式推导

section 4 的推导. 从 定义 E.2 出发：

$$\hat{\tau}^{\text{dr}} = \hat{\mu}_1^{\text{dr}} - \hat{\mu}_0^{\text{dr}} = \frac{1}{n} \sum_{i=1}^n [\mu_1(X_i, \hat{\beta}_1) - \mu_0(X_i, \hat{\beta}_0)] + \frac{1}{n} \sum_{i=1}^n \left[\frac{Z_i \{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{e(X_i, \hat{\alpha})} - \frac{(1 - Z_i) \{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - e(X_i, \hat{\alpha})} \right]$$

第一项恰好是结果回归估计量 $\hat{\tau}^{\text{reg}}$ ，于是得到 section 4。

section 4 的推导. 利用恒等式

$$\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X, \alpha)} = \frac{ZY}{e(X, \alpha)} - \frac{Z}{e(X, \alpha)} \mu_1(X, \beta_1),$$

以及

$$\frac{(1 - Z)\{Y - \mu_0(X, \beta_0)\}}{1 - e(X, \alpha)} = \frac{(1 - Z)Y}{1 - e(X, \alpha)} - \frac{1 - Z}{1 - e(X, \alpha)} \mu_0(X, \beta_0),$$

代入 section 4 并重新整理项，可得 section 4。

3. 从 IPW 到 DR 的分解

从分解

$$\mu_1 = E\{Y(1)\} = E\{Y(1) - \mu_1(X, \beta_1)\} + E\{\mu_1(X, \beta_1)\}$$

出发，对第一项应用 IPW 公式（将 $Y(1) - \mu_1(X, \beta_1)$ 视为伪潜在结果）：

$$E\{Y(1) - \mu_1(X, \beta_1)\} = E \left\{ \frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X)} \right\},$$

⁹详细步骤见原书 (? , Theorem 12.1)

这在倾向得分模型正确时成立。于是得到

$$\mu_1 = E \left\{ \frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X)} \right\} + E\{\mu_1(X, \beta_1)\}.$$

4. 从结果回归到 DR 的偏倚修正

结果回归估计量 $\tilde{\mu}_1 = E\{\mu_1(X, \beta_1)\}$ 的偏倚为：

$$\text{bias} = E\{\mu_1(X, \beta_1) - Y(1)\}.$$

如果倾向得分模型正确，这个偏倚可以用 IPW 估计量来估计：

$$B = E \left\{ \frac{Z\{\mu_1(X, \beta_1) - Y\}}{e(X)} \right\}.$$

于是去偏估计量为 $\tilde{\mu}_1 - B$ ，展开后恰好等于 eq. (72)。

5. 双重稳健性的乘积结构

从 section 1 的证明中，我们得到：

$$\tilde{\mu}_1^{\text{dr}} - E\{Y(1)\} = E \left[\frac{e(X) - e(X, \alpha)}{e(X, \alpha)} \times \{\mu_1(X) - \mu_1(X, \beta_1)\} \right].$$

这个乘积结构揭示了双重稳健性的本质：当两个模型都错误时， $e(X) - e(X, \alpha)$ 和 $\mu_1(X) - \mu_1(X, \beta_1)$ 这两个误差会相乘，可能放大偏差。

6. 模拟研究详情

数据生成过程. 我们设置样本量 $n = 500$ ，按以下四个场景生成 500 个独立数据集。

场景 1 (两个模型都正确)：

```
x = matrix(rnorm(n*2), n, 2)
x1 = cbind(1, x)
beta.z = c(0, 1, 1)
pscore = 1/(1 + exp(- as.vector(x1 %*% beta.z)))
z = rbinom(n, 1, pscore)
beta.y1 = c(1, 2, 1)
beta.y0 = c(1, 2, 1)
y1 = rnorm(n, x1 %*% beta.y1)
y0 = rnorm(n, x1 %*% beta.y0)
y = z*y1 + (1-z)*y0
```

场景 2 (倾向得分模型错误)： 使用非线性倾向得分模型。

场景 3 (结果模型错误)： 使用非线性结果模型。

场景 4 (两个模型都错误)： 同时使用非线性倾向得分和非线性结果模型。

模拟结果. 结论： 当两个模型都错误时（场景 4），双重稳健估计量的表现反而最差，验证了“双重脆弱性”现象。

TABLE 1. 四种场景下的模拟结果 ($n = 500$, 500 次重复)

	reg	HT	Hajek	DR
场景 1: 两个模型都正确				
平均偏倚	0.00	0.02	0.03	0.01
真标准误	0.11	0.28	0.26	0.13
估计标准误	0.10	0.25	0.23	0.12
场景 2: 倾向得分模型错误				
平均偏倚	0.00	-0.76	-0.75	-0.01
真标准误	0.12	0.59	0.47	0.18
估计标准误	0.13	0.50	0.38	0.18
场景 3: 结果模型错误				
平均偏倚	-0.05	0.00	-0.01	0.00
真标准误	0.11	0.15	0.14	0.14
估计标准误	0.11	0.14	0.13	0.14
场景 4: 两个模型都错误				
平均偏倚	-0.08	0.11	-0.07	0.16
真标准误	0.13	0.32	0.20	0.41
估计标准误	0.13	0.25	0.16	0.26

基于倾向得分的分层

1. 引言：从分层随机实验到观测性研究

“Block what you can and randomize what you cannot.” — (?, page 103)

我们在第 5 章看到，分层随机实验（SRE）是一种优雅地解决协变量不平衡问题的方法。在 SRE 中，我们根据离散的协变量 X 将单元分成若干层，在每一层内独立进行完全随机实验。这种方法在设计上保证了各层内的 treatment 和 control 平衡。

然而，现实中的观测性研究面临一个根本性的困难：我们无法控制治疗分配机制。在随机实验中， $e(X) = (Z = 1)$ 是由实验设计决定的已知常数；但在观测性研究中，治疗分配概率 $e(X) = (Z = 1 | X)$ 取决于协变量 X ，通常既未知又高度依赖于 X 的具体值。

更棘手的是，协变量 X 往往是高维的。当 X 包含数十个甚至数百个变量时，直接按 X 的取值进行分层会导致大多数层只包含极少量的单元——这正是维数灾难（curse of dimensionality）带来的挑战。

这些问题促使我们思考：能否找到一种方法，既能继承 SRE 的思想，又能在观测性研究中有效地控制 confounding？

倾向得分（propensity score）正是为解决这一问题而诞生的核心概念。

2. 倾向得分的维度约化性质

2.1. 核心定理. 在第 5 章中，我们定义了层别倾向得分 $e_{[k]} = n_{[k]1}/n_{[k]}$ ，这是在离散协变量下的分层随机实验中治疗分配的层内概率。在观测性研究的语境下，? 提出了更一般的倾向得分定义。

定义 A.1 (倾向得分). 倾向得分定义为给定协变量条件下治疗分配的条件概率：

$$e(X) = (Z = 1 | X).$$

倾向得分是一个取值在 $[0, 1]$ 区间的标量函数。下面的定理揭示了它的一个非凡性质——即使原始协变量 X 是高维的，只要强 ignorability 在 X 条件下成立，它在倾向得分条件下也成立。

定理 A.2 (倾向得分的维度约化定理). 如果 $Z \perp \{Y(1), Y(0)\} | X$ ，则有

$$Z \perp \{Y(1), Y(0)\} | e(X).$$

直观理解：强 ignorability 要求我们在高维协变量 X 的条件下进行条件化才能消除混杂。定理 A.2 告诉我们，更进一步地，仅在标量倾向得分 $e(X)$ 条件下条件化就足以消除 X 带来的所有混杂。这意味着，我们可以将高维协变量 X 降维到一维标量 $e(X)$ ，同时仍然保持因果识别的有效性。

证明概要:¹

我们需要证明 $\{Z = 1 \mid Y(1), Y(0), e(X)\} = \{Z = 1 \mid e(X)\}$ 。利用 tower property 和强 ignorability 假设, 有

$$\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{Z \mid Y(1), Y(0), e(X)\} = E[E\{Z \mid Y(1), Y(0), X\} \mid Y(1), Y(0), e(X)].$$

由强 ignorability, $E\{Z \mid Y(1), Y(0), X\} = E\{Z \mid X\} = e(X)$, 于是

$$\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{e(X) \mid Y(1), Y(0), e(X)\} = e(X).$$

类似地, $\{Z = 1 \mid e(X)\} = E\{Z \mid e(X)\} = E\{e(X) \mid e(X)\} = e(X)$ 。两端相等, 定理得证。

2.2. 历史注记. 与于 1983 年在 *Biometrika* 上发表了这篇开创性论文, 提出了倾向得分的概念及其在观测性研究中的核心作用。这篇论文是统计学历史上被引用最频繁的工作之一——? 将其列为过去一百年中 *Biometrika* 上引用量第二高的论文。近年来, 其引用量仍在快速增长。

这篇论文的核心贡献在于: 它揭示了因果推断的一个基本对称性——在强 ignorability 假设下, 条件化于高维协变量 X 与条件化于一维标量倾向得分 $e(X)$ 在消除混杂方面是等价的。这一发现从根本上简化了观测性研究中的因果推断问题。

3. 倾向得分分层

3.1. 已知倾向得分的情形. 定理 A.2 立刻启发了一种简单的因果效应估计方法——倾向得分分层 (propensity score stratification), 也称为子分类 (subclassification)。

我们首先考虑最简单的情形: 假设倾向得分 $e(X)$ 已知且仅取 K 个可能的值 $\{e_1, \dots, e_K\}$, 其中 K 远小于样本量 n 。此时定理 A.2 简化为

$$Z \perp \{Y(1), Y(0)\} \mid e(X) = e_k \quad (k = 1, \dots, K).$$

这意味着: 在每一层 k 内, 我们有 K 个独立的完全随机实验 (CRE)。因此, 我们可以像分析 SRE 那样分析观测数据——这就是“倾向得分分层”的基本思想。在各层内, 治疗组的平均因果效应为

$$\tau_{[k]} = E(Y \mid Z = 1, e(X) = e_k) - E(Y \mid Z = 0, e(X) = e_k),$$

总体平均因果效应为各层效应的加权平均:

$$\tau = \sum_{k=1}^K \pi_{[k]} \tau_{[k]},$$

其中 $\pi_{[k]} = \{e(X) = e_k\}$ 是第 k 层的权重。

¹完整证明见附录 section 9.1

3.2. 未知倾向得分的情形. 在实际情况中, 倾向得分 $e(X) = (Z = 1 | X)$ 既未知也不离散。我们通常需要先拟合一个统计模型 (例如对协变量 X 拟合 logistic 回归模型) 来得到**估计倾向得分 (estimated propensity score)** $\hat{e}(X)$ 。

估计倾向得分 $\hat{e}(X)$ 可以取多达 n 个不同的值——它本质上是连续的。为了应用分层方法, 我们需要将其离散化。最常用的离散化策略是按分位数进行划分:

$$\hat{e}'(X_i) = e_k, \quad \text{如果 } \hat{e}(X_i) \text{ 落在第 } (k-1)/K \text{ 和 } k/K \text{ 分位数之间.}$$

于是我们有近似的条件独立性:

$$Z \perp \{Y(1), Y(0)\} \mid \hat{e}'(X) = e_k \quad (k = 1, \dots, K).$$

重要说明: 此时 ignorability 仅在近似意义上成立, 因为 $\hat{e}'(X)$ 是基于样本估计得到的。在每层内, 我们仍然可以使用第 5 章的 SRE 分析方法。进一步地, 我们可以在各层内使用回归调整来消除剩余偏差并提高效率。

稳健性注记: 倾向得分分层估计量的一个吸引人的特性是, 它只需要估计倾向得分的**排序**正确, 而不需要精确的数值。这意味着它相对于其他方法 (如逆概率加权) 是比较稳健的。尽管这种稳健性在许多数值例子中得到了验证, 但严格的理论量化在文献中仍然缺失。

4. 分层数 K 的选择

选择合适的分层数 K 是实践中的一个关键问题。这个问题涉及偏差与方差的权衡:

- 如果 K 太小, 则 $Z \perp \{Y(1), Y(0)\} \mid \hat{e}'(X)$ 即使在近似意义上也难以成立, 导致残余偏倚;
- 如果 K 太大, 则每层内的单元数过少, 许多层可能只包含治疗组或对照组的单元, 导致估计量不稳定甚至未定义。

与 1983, 1984) 基于 1968) 的启发性研究, 建议使用 $K = 5$ ——即五分位数分层。他们证明, 在许多情形下, $K = 5$ 可以消除大部分由协变量不均衡带来的偏倚。

现代视角: 然而, 在超大规模数据集下, 固定 $K = 5$ 可能导致估计量产生偏倚。? 的研究表明, 此时适当增加 K 是合理的, 只要每层仍然包含足够数量的治疗组和对照组单元。? 提出了一种贪婪的 K 选择策略——取使分层估计量良好定义的最大分层数。但这一程序的严格理论尚未完全建立。

5. 与第五章的联系：SRE 的观测性研究版本

倾向得分分层与第 5 章讨论的分层随机实验 (SRE) 有着深刻的联系。在 SRE 中, 我们在设计阶段主动控制了协变量不平衡; 而在观测性研究中, 我们通过倾向得分分层来近似实现这种控制。

- 思想上的对应:** SRE 中我们按协变量 X 的取值分层, 在每层内做 CRE; 倾向得分分层则按倾向得分 $e(X)$ 的取值分层, 在每层内近似地获得“条件随机化”的效果。
- 记号的对应:** SRE 中的层别倾向得分 $e_{[k]} = n_{[k]1}/n_{[k]}$ 对应于倾向得分分层中每层的 e_k ; 只不过前者是设计决定的, 后者需要从数据中估计。
- 估计量的对应:** 两种情形下我们都使用各层差值均值的加权平均作为总体因果效应的估计。唯一的区别在于权重的估计方式。

这种对应关系揭示了为什么 SRE 的分析工具（如 Neyman 估计量、Fisher 随机化检验）可以直接迁移到倾向得分分层的情境中。

6. 标准误的估计

实践中的另一个重要问题是：如何计算基于倾向得分分层的估计量的标准误？

一种常见做法是**条件化于离散化的倾向得分** $\hat{e}(X)$ ，然后基于 SRE 的框架报告标准误。这种做法本质上忽略了估计倾向得分带来的不确定性。由于文献中一个令人惊讶的结果——使用估计倾向得分实际上会**降低**平均因果效应估计的渐近方差(?)，这种做法往往导致方差的高估。

另一种做法是对整个过程进行**自助法 (bootstrap)** 以纳入完整的不确定性。但由于该估计量的离散性质，自助法的理论性质尚不清晰。

7. 应用实例

7.1. NHANES 数据集. 我们使用第 C 章介绍的 NHANES 数据集来说明倾向得分分层的应用。

研究问题：学校供餐计划 (Schoolmeal) 对学生 BMI 的影响。

治疗指标： $Z_i = 1$ 表示参与学校供餐计划， $Z_i = 0$ 表示未参与。

结果变量：BMI (体质指数)。

协变量：包括年龄、性别、种族、家庭收入等基线特征。

首先，我们拟合 logistic 回归模型来估计倾向得分：

$$\hat{e}(X_i) = \text{logit}^{-1}(\hat{\alpha}_0 + \hat{\alpha}_1 X_{i1} + \cdots + \hat{\alpha}_p X_{ip}).$$

图 1 展示了不同分层数 ($K = 5, 10, 30$) 下估计倾向得分的直方图。可以看到，治疗组 (灰色) 和对照组 (白色) 的倾向得分分布存在明显差异，这表明确实存在需要控制的混杂。

FIGURE 1. NHANES 数据集中估计倾向得分的直方图：白色为对照组，灰色为治疗组

表 1 报告了不同 K 值下 ($K \in \{5, 10, 20, 50, 80\}$) 的倾向得分分层估计结果。²

TABLE 1. 不同分层数 K 下的倾向得分分层估计结果

	$K = 5$	$K = 10$	$K = 20$	$K = 50$	$K = 80$
估计值	-0.116	-0.178	-0.200	-0.265	—
标准误	0.283	0.282	0.279	0.272	NA

从结果可以看出：

- (a) 随着 K 从 5 增加到 50，标准误逐渐减小，估计值趋于稳定 (约 -0.2)；
- (b) 当 $K = 80$ 时，标准误未定义 (NA)，因为某些层只包含单一处理组的单元)；
- (c) 所有估计值都是负的，表明学校供餐计划可能有助于降低 BMI，但统计上不显著。

TABLE 2. 不同估计方法的比较

	naive	Fisher	Lin
估计值	0.534	0.061	-0.017
标准误	0.225	0.227	0.226

7.2. 与其他方法的比较. 表 2 比较了倾向得分分层与几种回归估计量的结果。

关键观察：

- **朴素估计量 (naive)** 给出的估计值最大 (0.534)，这是由于协变量在治疗组和对照组之间的巨大不平衡；
- **Fisher 估计量** (协变量调整后的 OLS) 给出了一个较小的正估计 (0.061)，但不显著；
- **Lin 估计量** (包含交互项的 OLS) 给出了接近零的估计 (-0.017)；
- 倾向得分分层估计量 (-0.17 到 -0.27) 与 Lin 估计量在定性上是一致的，且在不同 K 值下保持稳定。

这些结果说明：倾向得分分层是一种有效且稳健的因果效应估计方法，它既继承了 SRE 的设计思想，又适用于观测性研究的复杂情境。

8. 小结

本章介绍了倾向得分分层的核心思想和方法：

- 维度约化：**定理 A.2 表明，在强 ignorability 假设下，条件化于倾向得分 $e(X)$ 与条件化于高维协变量 X 在消除混杂方面是等价的；
- 分层思想：**将连续的倾向得分离散化为 K 层，在每层内近似获得“条件随机化”的效果；
- 与 SRE 的联系：**倾向得分分层本质上是将 SRE 的设计思想应用于观测性研究；
- K 的选择：** $K = 5$ 是经典推荐，但在超大规模数据下可适当增加；
- 稳健性：**倾向得分分层只要求估计倾向得分的排序正确，对模型设定相对稳健。

倾向得分分层是因果推断工具箱中的基础工具之一。它不仅可以直接用于估计因果效应，还构成了逆概率加权、doubly robust 估计等更高级方法的基础。

9. 附录：关键公式推导

9.1. 定理 A.2 的完整证明. 我们需要证明在强 ignorability 条件下，

$$\{Z = 1 \mid Y(1), Y(0), e(X)\} = \{Z = 1 \mid e(X)\}.$$

首先，由条件概率的定义和 tower property，

$$\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{Z \mid Y(1), Y(0), e(X)\}.$$

对上式应用 tower property (先关于 X 条件化，再关于 $Y(1), Y(0), e(X)$ 条件化)：

$$E\{Z \mid Y(1), Y(0), e(X)\} = E[E\{Z \mid Y(1), Y(0), X\} \mid Y(1), Y(0), e(X)].$$

由强 ignorability 假设 $Z \perp \{Y(1), Y(0)\} \mid X$ ，有

$$E\{Z \mid Y(1), Y(0), X\} = E\{Z \mid X\} = e(X).$$

²具体计算代码见附录 section 9.2

因此,

$$E\{Z \mid Y(1), Y(0), e(X)\} = E\{e(X) \mid Y(1), Y(0), e(X)\} = e(X).$$

另一方面,

$$\{Z = 1 \mid e(X)\} = E\{Z \mid e(X)\} = E[E\{Z \mid X\} \mid e(X)] = E\{e(X) \mid e(X)\} = e(X).$$

两端相等, 定理证毕。

9.2. NHANES 数据分析的 R 代码. 以下是本章数据分析使用的 R 代码示例:

```
[language=R] 读取数据 nhanesbmi = read.csv("nhanesbmi.csv")[, -1] z =
nhanesbmiSchoolmeal y = nhanesbmiBMI x = as.matrix(nhanesbmi[, -c(1, 2)]) x =
scale(x)
估计倾向得分 pscore = glm(z ~ x, family = binomial)$fitted.values
倾向得分分层 n.strata = c(5, 10, 20, 50, 80) strat.res = sapply(n.strata, FUN = func-
tion(nn) q.pscore = quantile(pscore, (1:(nn-1)) / nn) ps.strata = cut(pscore, breaks = c(0,
q.pscore, 1), labels = 1:nn) NeymanSRE(z, y, ps.strata))
rownames(strat.res) = c("est", "se") colnames(strat.res) = n.strata round(strat.res,
3)
```

其中 `NeymanSRE` 函数定义于第 5 章, 用于计算 SRE 框架下的 Neyman 估计量及其标准误。

加权最小二乘法用于因果推断

1. 一个问题意识：IPW 估计量的另一种面孔

在第十二章中，我们学习了基于逆概率加权（IPW）的 Hajek 估计量：

$$(76) \quad \hat{\tau}^{\text{hajek}} = \frac{\sum_{i=1}^n \frac{Z_i Y_i}{\hat{e}(X_i)}}{\sum_{i=1}^n \frac{Z_i}{\hat{e}(X_i)}} - \frac{\sum_{i=1}^n \frac{(1-Z_i) Y_i}{1-\hat{e}(X_i)}}{\sum_{i=1}^n \frac{1-Z_i}{1-\hat{e}(X_i)}}$$

这个估计量优美而简洁——它本质上是治疗组和对照组加权均值的差。

然而，一个深邃的观察（Imbens, 2004）是：eq. (76) 实际上与一个加权最小二乘（WLS）回归的系数完全等价。更精确地说， $\hat{\tau}^{\text{hajek}}$ 恰好等于在如下 WLS 回归中 Z_i 的系数：

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \sum_{i=1}^n w_i (Y_i - \alpha - \beta Z_i)^2$$

其中权重为

$$(77) \quad w_i = \frac{Z_i}{\hat{e}(X_i)} + \frac{1-Z_i}{1-\hat{e}(X_i)} = \begin{cases} \frac{1}{\hat{e}(X_i)} & \text{if } Z_i = 1; \\ \frac{1}{1-\hat{e}(X_i)} & \text{if } Z_i = 0. \end{cases}$$

这个等价性绝非偶然的代数巧合——它揭示了 IPW 与加权回归之间深刻的联系，也为更高效的估计开辟了道路。

2. Hajek 估计量作为 WLS 估计量

让我们更仔细地审视这个等价性。

命题 B.1 (命题 14.1 —Hajek 估计量与 WLS). 在 *section 1* 的记号下， $\hat{\tau}^{\text{hajek}}$ 严格等于上述 WLS 回归中 Z_i 的系数 $\hat{\beta}$ 。

为什么这个结果有意义？ 让我们回顾一下完全随机化实验（CRE）的情形。当倾向得分恒为常数 $e(X_i) \equiv p$ 时，权重 w_i 也恒为常数，此时 WLS 退化为普通的 OLS。因此，CRE 中用 OLS 系数估计 τ 的经典结果（参见第四章）可以视为本命题的特例。

直觉理解： 在观测研究中，不同单元接受治疗或对照的概率不同。如果我们用 $1/\hat{e}(X_i)$ 加权治疗组，用 $1/\{1-\hat{e}(X_i)\}$ 加权对照组，就相当于构造了一个“伪随机化实验”——加权后的样本可以代表总体。于是，加权均值之差（Hajek 估计量）等价于在这个伪实验中进行 OLS 回归得到的 treatment 系数。

由定义 B.1，我们可以通过 WLS 回归方便地计算 $\hat{\tau}^{\text{hajek}}$ 。但需要注意：由于倾向得分是估计的，WLS 报告的标准误并非 $\hat{\tau}^{\text{hajek}}$ 的真实标准误。Bootstrap 提供了一种简便的近似方法。¹

¹详见附录 ??。

这个等价性不仅在代数上优雅，更重要的是它为**加入协变量调整**提供了自然的框架。

3. 加入协变量：Lin (2013) 的推广与双重稳健性

在 CRE 中，我们可以通过在回归中加入协变量来提高估计效率。Lin (2013) 的做法是在 OLS 回归中加入 treatment 与协变量的交互项：

$$Y_i \sim (1, Z_i, X_i, Z_i X_i)$$

其中协变量需要中心化 ($\bar{X} = 0$)。

自然的问题是：在观测研究中，我们能否做类似的推广？

答案是肯定的——我们只需要将普通 OLS 替换为 WLS (权重取 eq. (77))。具体而言，估计量 $\hat{\tau}$ 取为 WLS 回归

$$Y_i \sim (1, Z_i, X_i, Z_i X_i)$$

中 Z_i 的系数。

这个推广最早由 Hirano and Imbens (2001) 在一项应用中采用。

3.1. 完全交互线性模型。假设潜在结果的条件期望是线性的：

$$\mathbb{E}(Y | Z = 1, X) = \beta_{10} + \beta_{1x}^\top X, \quad \mathbb{E}(Y | Z = 0, X) = \beta_{00} + \beta_{0x}^\top X$$

两种情形：

- (a) **结局模型正确：**若上述线性模型正确指定，则 WLS 和 OLS 都给出 τ 的相合估计，且 Z 系数的估计量相合于 τ 。
- (b) **倾向得分模型正确，结局模型错误：**更引人注目的是，即使结局模型错误，只要倾向得分模型正确，WLS 中 Z 的系数仍然相合于 τ 。这就是所谓的**双重稳健性 (double robustness)**。

这个双重稳健性结果最早见于 Robins et al. (2007)，他们将功劳归于 M. Joffe 的未发表论文。

3.2. 结局回归估计量与双重稳健估计量。设 $\hat{e}(X_i, \hat{\alpha})$ 为估计的倾向得分， $(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_0))$ 为基于 WLS 的结局条件均值拟合值。

结局回归估计量为

$$\hat{\tau}_{\text{wls}}^{\text{reg}} = \frac{1}{n} \sum_{i=1}^n \mu_1(X_i, \hat{\beta}_1) - \frac{1}{n} \sum_{i=1}^n \mu_0(X_i, \hat{\beta}_0)$$

双重稳健估计量为

$$\hat{\tau}_{\text{wls}}^{\text{dr}} = \hat{\tau}_{\text{wls}}^{\text{reg}} + \frac{1}{n} \sum_{i=1}^n \frac{Z_i \{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{\hat{e}(X_i, \hat{\alpha})} - \frac{1}{n} \sum_{i=1}^n \frac{(1 - Z_i) \{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - \hat{e}(X_i, \hat{\alpha})}$$

一个深刻的结果是：当结局模型为线性模型时，这个双重稳健估计量恰好等于结局回归估计量——二者都简化为 WLS 回归中 Z_i 的系数。

定理 B.2 (定理 14.2 — 双重稳健性)。若 $\bar{X} = 0$ 且

$$(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_0)) = (\hat{\beta}_{10} + \hat{\beta}_{1x}^\top X_i, \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i)$$

基于权重 eq. (77) 对 $Y_i \sim (1, Z_i, X_i, Z_i X_i)$ 的 WLS 拟合，则

$$\hat{\tau}_{\text{wls}}^{\text{dr}} = \hat{\tau}_{\text{wls}}^{\text{reg}} = \hat{\beta}_{10} - \hat{\beta}_{00}$$

即 Z_i 在 WLS 回归中的系数。

证明思路：²

WLS 回归包含截距项，因此加权残差的均值为零。这给出两个正交条件：

$$\sum_{i=1}^n \frac{Z_i(Y_i - \hat{\beta}_{10} - \hat{\beta}_{1x}^\top X_i)}{\hat{e}(X_i)} = 0, \quad \sum_{i=1}^n \frac{(1 - Z_i)(Y_i - \hat{\beta}_{00} - \hat{\beta}_{0x}^\top X_i)}{1 - \hat{e}(X_i)} = 0.$$

这两个条件确保 $\hat{\tau}_{wls}^{dr} - \hat{\tau}_{wls}^{reg} = 0$ 。进一步，利用协变量中心化 ($\bar{X} = 0$)，两者都简化为 $\hat{\beta}_{10} - \hat{\beta}_{00}$ 。

3.3. Freedman and Berk (2008) 的警示。 Freedman and Berk (2008) 基于模拟研究对上述 WLS 估计量提出了批评。他们指出：当结局模型正确时，WLS 估计量由于权重的变异性而比 OLS 估计量表现更差。

然而，这个结论并非普遍成立。关键在于数据的**异方差结构**——若误差方差与倾向得分成反比，则 WLS 估计量将比 OLS 更高效。

此外，Freedman and Berk (2008) 也注意到一个重要事实：当结局模型错误时，只要倾向得分模型正确，WLS 估计量仍然是相合的。这正是双重稳健性的价值所在。

标准误的问题：WLS 回归报告的标准误忽略了倾向得分估计的不确定性，这个缺陷可以通过 Bootstrap 轻易弥补。

注 B.1. **什么时候该用 WLS？**：当 (1) 倾向得分模型可信且 (2) 误差方差可能与倾向得分相关（异方差）时，WLS 是更好的选择。当结局模型可信时，简单的 OLS 可能更稳定。

4. 处理组平均因果效应的 WLS

上述结果可以平行地推广到**处理组平均因果效应** (Average Causal Effect on the Treated, τ_T) 的情形。

处理组 Hajek 估计量为

$$\hat{\tau}_T^{\text{hajek}} = \hat{Y}(1) - \frac{\sum_{i=1}^n \hat{o}(X_i)(1 - Z_i)Y_i}{\sum_{i=1}^n \hat{o}(X_i)(1 - Z_i)}$$

其中 $\hat{o}(X_i) = \hat{e}(X_i)/\{1 - \hat{e}(X_i)\}$ 。

命题 B.3 (命题 14.2 — 处理组 Hajek 估计量与 WLS). $\hat{\tau}_T^{\text{hajek}}$ 严格等于如下 WLS 回归中 Z_i 的系数：

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \sum_{i=1}^n w_{T_i} (Y_i - \alpha - \beta Z_i)^2$$

其中权重为

$$(78) \quad w_{T_i} = Z_i + (1 - Z_i)\hat{o}(X_i) = \begin{cases} 1 & \text{if } Z_i = 1; \\ \hat{o}(X_i) & \text{if } Z_i = 0. \end{cases}$$

若进一步中心化协变量 ($\hat{X}(1) = 0$)，则 τ_T 可以用 WLS 回归

$$Y_i \sim (1, Z_i, X_i, Z_i X_i)$$

(权重取 eq. (78)) 中 Z_i 的系数来估计。

²详细证明见附录 ??。

定理 B.4 (定理 14.3 — 处理组的双重稳健性). 若 $\hat{X}(1) = 0$ 且 $\mu_0(X_i, \hat{\beta}_0) = \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i$ 基于权重 eq. (78) 对 $Y_i \sim (1, Z_i, X_i, Z_i X_i)$ 的 WLS 拟合, 则

$$\hat{\tau}_{T,wls}^{dr} = \hat{\tau}_{T,wls}^{reg} = \hat{\beta}_{10} - \hat{\beta}_{00}$$

即 Z_i 在 WLS 回归中的系数。

证明思路:³

5. 统一视角：回归估计量一览

table 1 总结了完全随机化实验 (CRE) 与非混杂假设下观测研究中回归估计量的对应关系。

TABLE 1. 回归估计量一览：CRE 与观测研究的对比

	CRE	非混杂观测研究
不含协变量	$Y_i \sim (1, Z_i)$	$Y_i \sim (1, Z_i)$ (权重 w_i)
含协变量	$Y_i \sim (1, Z_i, X_i, Z_i X_i)$	$Y_i \sim (1, Z_i, X_i, Z_i X_i)$ (权重 w_i)

其中权重 w_i 如 eq. (77) 所示。

核心洞察：在 CRE 中使用 OLS，在观测研究中只需将 OLS 替换为带逆概率权重的 WLS——两者在代数形式上完全对应。这揭示了随机化实验与观测研究之间深刻的类比。

6. 本章小结

本章建立了加权最小二乘法 (WLS) 与因果推断之间的联系：

- (a) **等价性：**Hajek 估计量严格等于 WLS 回归中 treatment 变量的系数
- (b) **协变量调整：**通过在 WLS 中加入 X_i 和 $Z_i X_i$ 项，可以提高估计效率 (Lin, 2013)
- (c) **双重稳健性：**只要倾向得分模型和结局模型中至少有一个正确，WLS 估计量就相合 (Robins et al., 2007)
- (d) **异方差效率：**当误差方差与倾向得分相关时，WLS 比 OLS 更高效
- (e) **处理组效应：**所有结果平行推广到 τ_T 的估计

WLS 为因果推断提供了一个统一的框架——它既是 IPW 的另一种表述，又自然地融入了协变量调整和双重稳健性的思想。

7. 习题

练习 B.1. B.1 命题 14.1 和 14.2 的证明 证明 定义 B.1 和 定义 B.3。

提示：这些是附录 B.3 中一元 WLS 问题的特例。利用 WLS 的正规方程即可证明。

练习 B.2. B.2 预测估计量与双重稳健估计量 另一种结局回归估计量是预测估计量

$$\hat{\tau}^{pred} = \hat{\mu}_1^{pred} - \hat{\mu}_0^{pred}$$

³详细证明见附录 ??。

其中

$$\hat{\mu}_1^{pred} = \frac{1}{n} \sum_{i=1}^n \{Z_i Y_i + (1 - Z_i) \mu_1(X_i, \hat{\beta}_1)\}, \quad \hat{\mu}_0^{pred} = \frac{1}{n} \sum_{i=1}^n \{Z_i \mu_0(X_i, \hat{\beta}_1) + (1 - Z_i) Y_i\}.$$

证明：当 $(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_1)) = (\hat{\beta}_{10} + \hat{\beta}_{1x}^\top X_i, \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i)$ 来自基于权重

$$w_i = Z_i / \hat{\phi}(X_i) + (1 - Z_i) \hat{\phi}(X_i)$$

对 $Y_i \sim (1, X_i)$ 的 WLS 拟合时，双重稳健估计量等于 $\hat{\tau}^{pred}$ 。

参考文献： *Cao et al. (2009)* 和 *Vermeulen and Vansteelandt (2015)* 从其他理论角度 *motivation* 了上述权重。

练习 B.3. B.3 WLS 的效率性质 讨论在何种情形下 WLS 估计量比 OLS 估计量更有效。在 *Freedman and Berk (2008)* 的模拟设置中，为什么 OLS 表现更好？这与本章讨论的异方差情形有何关联？

练习 B.4. B.4 推荐阅读 **推荐阅读：**？是关于因果推断中加权方法的权威综述。？讨论了协变量调整在随机化实验中的应用。

历史注记： WLS 与 IPW 的等价性最早由 *Imbens (2004)* 明确指出。双重稳健性的概念在 *Robins et al. (2007)* 中得到了系统阐述。

观测性研究中的匹配

1. 引言：为什么匹配比回归更直观？

“*Matching is a way of making observational studies look like randomized experiments.*” — (?)

在第 C 章至第 E 章中，我们介绍了观测性研究的四大支柱：结果回归、逆倾向得分加权、双稳健估计量，以及本章要讨论的**匹配估计量 (matching estimator)**。

为什么匹配如此直观？想象一下：在随机实验中，我们通过随机分配让治疗组和对照组在协变量上达到平衡。但当随机化不可行时，我们能否在设计阶段就主动创造出这种平衡？匹配的核心思想正是如此——**通过人为配对，使匹配后的数据模拟随机实验的性质。**

这个想法有着悠久的历史。? 是早期综述性论文，? 收集了 Rubin 在该领域的贡献。现代渐近理论则由 ??? 的系列论文建立。

2. 匹配的基本思想

考虑一个治疗组单元数 n_1 远小于对照组单元数 n_0 的场景。对每个治疗组单元 $i = 1, \dots, n_1$ ，我们在对照组中寻找一个匹配单元 $m(i)$ 使得 $X_i = X_{m(i)}$ 。

理想情况：精确匹配。如果对于所有单元都能找到协变量完全相同的匹配，那么匹配后的配对与第 7 章讨论的匹配对实验 (matched-pairs experiment, MPE) 具有相同的性质。条件于配对后，一单位接受治疗而另一单位接受对照的概率是

$$\Pr\{i \text{ 接受治疗}, m(i) \text{ 接受对照}\} = \frac{e(X_i)\{1 - e(X_{m(i)})\}}{\sum_j \{e(X_j) + e(X_{m(j)})\}}.$$

由于 $X_i = X_{m(i)}$ ，我们有 $e(X_i) = e(X_{m(i)})$ ，这个概率退化为 $e(X_i)/\{e(X_i) + e(X_i)\} = 1/2$ 。这正是随机化分配的标志。

不精确匹配的问题。然而在实际中， $X_i = X_{m(i)}$ 通常无法对所有单元成立。? 倡导上述分析策略，但 ? 报告了不精确匹配在 FRT 中的负面结果。这是一个重要警示。

倾向得分救兵。当协变量维度较高时，直接匹配面临维数灾难。? 提出使用倾向得分进行匹配。由于倾向得分是一维的，我们只需寻找 $|\hat{e}(X_i) - \hat{e}(X_{m(i)})|$ 很小的配对，或 $|\text{logit}\{\hat{e}(X_i)\} - \text{logit}\{\hat{e}(X_{m(i)})\}|$ 很小的配对。? 为这一策略提供了形式化理论。

3. 匹配估计量：一对一匹配

本节介绍 Abadie–Imbens (AI) 的标准设置：¹

$$\{X_i, Z_i, Y_i(1), Y_i(0)\}_{i=1}^n \stackrel{\text{iid}}{\sim} \{X, Z, Y(1), Y(0)\}.$$

¹详细推导见附录 ??

3.1. ACE 的匹配估计量. 采用 $1-M$ 匹配 (带放回)。对治疗单元 i , 将潜在结果 $Y_i(1)$ 估计为观测值 Y_i ,

$$\hat{Y}_i(1) = Y_i.$$

将潜在结果 $Y_i(0)$ 估计为匹配对照单元结果的均值:

$$\hat{Y}_i(0) = M^{-1} \sum_{j=1}^M Y_{m_j(i)},$$

其中 $m_j(i)$ 是第 j 个匹配单元。

匹配估计量为:

$$\hat{\tau}^m = n^{-1} \sum_{i=1}^n Z_i \{\hat{Y}_i(1) - \hat{Y}_i(0)\} + n^{-1} \sum_{i=1}^n (1 - Z_i) \{\hat{Y}_i(0) - \hat{Y}_i(1)\}.$$

为简化记号, 定义 $J(i)$ 为匹配给单元 i 的单元集合, $K_i = |J(i) \cap \{j : Z_j = 1\}|$ 为匹配中治疗单元的个数。

命题 C.1 (匹配估计量的偏差). 在 M 固定的情况下, 当 $n \rightarrow \infty$ 时,

$$\sqrt{n}(\hat{\tau}^m - \tau) \Rightarrow \mathcal{N}\{0, V^m(\tau)\},$$

其中偏差来自不精确匹配。²

3.2. 偏差校正. ? 指出, 简单 bootstrap 不能用于匹配估计量的方差估计。他们提出的方差估计程序不易实现。? 提出了基于线性展开的 bootstrap, 本质上等价于以下简单方差估计量 $\hat{V}^{\text{mbc}}$ 。

偏差校正后的匹配估计量:

$$\hat{\tau}^{\text{mbc}} = \hat{\tau}^m + n^{-1} \sum_{i=1}^n \hat{\psi}_i,$$

其中 $\hat{\psi}_i$ 是偏差校正项。³

通过将 $\hat{\tau}^{\text{mbc}}$ 视为 $\hat{\psi}_i$ 的样本均值, ? 首先证明简单 bootstrap 对匹配估计量不适用。? 的 bootstrap 本质上等价于简单的 $\hat{V}^{\text{mbc}}$, 计算简便。

4. 匹配的双稳健形式

偏差校正匹配估计量与双稳健估计量有着密切联系。两者都等于结果回归估计量加上基于残差的修正。

命题 C.2 (ACE 偏差校正匹配估计量的双稳健形式). 偏差校正匹配估计量满足

$$\hat{\tau}^{\text{mbc}} = \hat{\tau}^{\text{DR}},$$

其中 $\hat{\tau}^{\text{DR}}$ 是第 E 章定义的双稳健估计量。⁴

²完整方差推导见附录 ??

³推导见附录 ??

⁴证明见附录 ??

定义 C.2 揭示了一个深刻联系：匹配本质上是估计倾向得分的非参数方法，而 $1 + K_i/M$ 可以视为 $1/\hat{e}(X_i)$ 的估计。

当治疗单元的 $e(X_i)$ 很小时， $1/\hat{e}(X_i)$ 很大，同时该单元会匹配到很多对照单元，导致 K_i 很大，因此 $1 + K_i/M$ 也很大。这个联系也引发了一个关于匹配的问题：**固定 M 下， $1 + K_i/M$ 对 $1/e(X_i)$ 的估计可能非常嘈杂。**让 M 随样本量增长可能会改善基于匹配倾向得分估计的渐近性质。⁵ 提供了严格理论：当 M 以适当速率增长时，偏差校正匹配估计量可以达到与双稳健估计量相似的性质。

5. ATT 的匹配估计量

实践中，我们经常关心的是**处理组平均因果效应 (ATT)**：

$$\tau_T = \mathbb{E}\{Y_i(1) - Y_i(0) \mid Z_i = 1\}.$$

ATT 的匹配估计量为：

$$\hat{\tau}_T^m = n_1^{-1} \sum_{i:Z_i=1} \{\hat{Y}_i(1) - \hat{Y}_i(0)\},$$

其中 $\hat{Y}_i(1) = Y_i$ 而 $\hat{Y}_i(0) = M^{-1} \sum_{j=1}^M Y_{m_j(i)}$ 。

类似地，偏差校正版本为：

$$\hat{\tau}_T^{\text{mbc}} = \hat{\tau}_T^m + n_1^{-1} \sum_{i:Z_i=1} \hat{\psi}_i^T.$$

命题 C.3 (ATT 偏差校正匹配估计量的双稳健形式). *ATT 的偏差校正匹配估计量满足*

$$\hat{\tau}_T^{\text{mbc}} = \hat{\tau}_T^{\text{DR}},$$

其中 $\hat{\tau}_T^{\text{DR}}$ 是 ATT 的双稳健估计量。⁵

定义 C.3 表明：匹配本质上使用 K_i/M 来估计给定协变量条件下治疗的优势比。

6. 实践中的问题

6.1. 一对一还是一对多？ 我们既可以采用一对一匹配，也可以采用一对 M 匹配。当 M 增加时，偏差减小但方差增大。实践中需要权衡。

6.2. 放回还是不放回？ 放回匹配计算更方便，但会引入依赖（同一单元被多次使用）。不放回匹配的计算更复杂，但保证了匹配单元的独立性。当对照组池较大时，两种方法结果差异不大。

6.3. 协变量平衡检验。 匹配后应检验协变量平衡。使用简单 OLS 检查匹配前后协变量的系数显著性。**匹配前**，协变量通常高度不平衡（系数显著）；**匹配后**，协变量应该达到良好平衡（系数不显著）。

⁵证明见附录 ??

7. 实例：LaLonde 数据

？研究工作培训项目对收入的影响。他比较了随机实验结果与观测性研究结果。

实验部分给出 ATT 估计为 \$1794 (标准误 \$623)。⁶

使用？的 Matching 包进行 1-1 匹配分析。匹配后，ATT 估计为 \$1658，与实验结果的 \$1794 非常接近。这说明当匹配质量好时，匹配估计量能够很好地近似实验金标准。

8. 本章小结

本章介绍了观测性研究中的匹配估计量，主要内容如下：

- (a) **匹配的动机**：通过人为配对，使观测性研究模拟随机实验的性质——这比直接假设条件独立性更直观。
- (b) **基本思想 (section 2)**：对每个治疗单元，在对照组中找到协变量相似的单元进行匹配。精确匹配使治疗分配机制与匹配对实验相同。
- (c) **AI 理论 (section 3)**：??? 建立了匹配估计量的渐近理论，包括偏差校正和方差估计。
- (d) **双稳健连接 (section 4)**：偏差校正匹配估计量本质上是另一种形式的双稳健估计量。
- (e) **ATT 估计 (section 5)**：匹配同样适用于 ATT 的估计，且具有类似的双稳健性质。
- (f) **实践要点 (section 6)**：协变量平衡检验是确保匹配质量的关键步骤。

9. 习题

练习 C.1. 匹配与倾向得分 证明：在精确匹配下，倾向得分对所有配对单元相同，即 $e(X_i) = e(X_{m(i)})$ 。这如何支持“精确匹配模拟随机实验”的论断？

练习 C.2. 一对一与一对多匹配的偏差比较 考虑 1-1 匹配和 1-M 匹配。当 M 增大时，匹配估计量的偏差如何变化？为什么？

练习 C.3. 匹配估计量的偏差校正项 从 section 3.2 出发，推导偏差校正项 $\hat{\psi}_i$ 的具体形式。提示：参考？的推导。

练习 C.4. ATT 匹配估计量的性质 证明 定义 C.3: ATT 的偏差校正匹配估计量等于 ATT 的双稳健估计量。

练习 C.5. 协变量平衡 对 LaLonde 数据进行匹配分析，检验匹配前后协变量的平衡性。使用不同的 M 值（一对一、一对二、一对四）比较结果。

练习 C.6. 匹配与回归的比较 使用第 C 章 ?? 节的数据，分别用匹配估计量和结果回归估计量估计 ATT。比较两种方法的结果和效率。

练习 C.7. 倾向得分匹配的理论性质？提供了基于倾向得分匹配的理论。阅读该论文，总结其主要结论及其与？建议的关联。

练习 C.8. 高维协变量的挑战 当协变量维度很高时，直接匹配面临维数灾难。讨论三种可能的解决策略：降维、惩罚回归、机器学习方法。

⁶详见第 C 章 2.1 节

观测性研究中不可混淆性假设的困难

1. 引言：当我们无法控制所有混杂因素时

“*Although we cannot see the wind, we can see its effects on the leaves.*” — 统计学家对隐性混杂的隐喻

在第 C 至 C 章中，我们详细讨论了观测性研究中因果效应的识别与估计方法。这些方法的核心假设是**不可混淆性 (unconfoundedness)**：

$$(16.1) \quad Z \perp \{Y(1), Y(0)\} \mid X.$$

也就是说，在给定协变量 X 的条件下，治疗分配 Z 与潜在结果相互独立。

然而，这个假设在实践中有多可靠？

正如 George Box 所言：“所有模型都是错的，但有些有用。”不可混淆性假设本质上是一个关于数据生成过程的陈述——它声称我们已经控制了所有影响治疗分配和结果的混杂变量。但在真实的观测性研究中，我们真的能确保这一点吗？

问题的根源：协变量 X 永远只是我们观测到的协变量的一个子集。是否存在我们未能观测到的混杂因素 U ？如果存在，那么不可混淆性假设就不成立，我们基于此假设得到的因果效应估计量可能是有偏的。

本章将系统性地探讨这一困难：

- 首先，引入**因果图 (causal diagram)** 作为可视化因果关系的工具；
- 其次，讨论**评估不可混淆性假设的策略**——我们无法直接检验它，但可以进行辅助分析；
- 最后，分析**过度调整 (over-adjustment)** 的风险——调整错误的协变量反而可能引入新的偏倚。

2. 因果图的基本概念

2.1. 从因果图到数据生成过程。 Pearl (1995) 引入了因果图作为经验研究中因果推理的有力工具。因果图的美妙之处在于：它能够将变量之间的因果关系以图示形式直观地表达出来，而我们可以直接从图中读出统计学含义。

考虑一个最简单的因果图结构：

$$X \rightarrow Z \rightarrow Y$$

其中 X 是协变量， Z 是治疗， Y 是结果。这个图的含义是： X 影响 Z ，而 Z 影响 Y 。从数学上讲，这对应于以下数据生成过程：

$$(16.2) \quad \begin{cases} X \sim F_X(x), \\ Z = f_Z(X, \varepsilon_Z), \\ Y(z) = f_Y(X, z, \varepsilon_Y(z)), \end{cases} \quad ??$$

其中 $\varepsilon_Z \perp \varepsilon_Y(z)$ (两组误差独立)。从这个方程组中，我们可以直接读出 $Z \perp Y(z) \mid X$ ，即不可混淆性假设成立。

现在考虑一个更复杂的情形——存在一个未观测的混杂因素 U ：

$$U \rightarrow Z, U \rightarrow Y, X \rightarrow Z, X \rightarrow Y$$

这个图对应的数据生成过程是：

$$(16.3) \quad \begin{cases} X \sim F_X(x), \\ U \sim F_U(u), \\ Z = f_Z(X, U, \varepsilon_Z), \\ Y(z) = f_Y(X, U, z, \varepsilon_Y(z)), \end{cases} \quad ??$$

其中 $\varepsilon_Z \perp \varepsilon_Y(z)$ 。从方程组中我们可以读出： $Z \perp Y(z) \mid (X, U)$ 成立，但 $Z \not\perp Y(z) \mid X$ ——不可混淆性在给定 (X, U) 时成立，但仅给定 X 时不成立。在这个情形中， U 被称为**未测混杂因素 (unmeasured confounder)**。

因果图的美学价值在于：它将不可测试的假设转化为直观的图形结构。当图中存在从 Z 到 Y 的后门路径 (backdoor path) 时，就意味着存在未被阻断的混杂。

3. 评估不可混淆性假设

3.1. 基本困难：假设本身不可检验。 回到不可混淆性假设：

$$(16.4) \quad Z \perp Y(1) \mid X, \quad Z \perp Y(0) \mid X.??$$

这个假设意味着：

$$(16.5) \quad \begin{aligned} \{Y(1) \mid Z = 1, X\} &= \{Y(1) \mid Z = 0, X\}, \\ \{Y(0) \mid Z = 1, X\} &= \{Y(0) \mid Z = 0, X\}. \end{aligned}$$

也就是说，在给定 X 的条件下，治疗组和对照组的潜在结果分布相同。但问题在于：潜在结果分布 $\{Y(1) \mid Z = 0, X\}$ 和 $\{Y(0) \mid Z = 1, X\}$ 是反事实的，我们永远无法直接从数据中观测到它们。

因此，**不可混淆性假设从根本上是不可直接检验的**——我们无法用统计检验来验证它是否成立。这并不意味着我们应该放弃因果推断，而是需要采用其他策略来评估这个假设的合理性。

统计学家区分了两个概念：**评估 (assess)** 和**检验 (test)**。前者是指补充性分析，用于支持或削弱初始分析的可信度；后者是正式的统计检验。我们无法检验不可混淆性，但可以评估它。

下面介绍两种主要的评估策略。

3.2. 策略一：利用阴性结果。核心思想：如果我们相信 $Z \perp Y(z) \mid X$ ，那么我们也倾向于相信 $Z \perp Y^n(z) \mid X$ ，其中 Y^n 是一个与 Y 具有相似混杂结构的**阴性结果 (negative outcome)**。关键在于，我们事先知道 Z 对 Y^n 的因果效应。

形式化地，假设 Y^n 满足：

$$(16.6) \quad \tau(Z \rightarrow Y^n) = \mathbb{E}\{Y^n(1) - Y^n(0)\} \text{ 是已知的.??}$$

一个特别重要的情形是 $\tau(Z \rightarrow Y^n) = 0$ ——即我们事先知道治疗对阴性结果没有因果效应。

如果不可混淆性假设成立，那么数据应该显示 Z 对 Y^n 没有处理效应（或者有已知大小的效应）。如果数据显示出显著的效应，这可能暗示不可混淆性假设被违反。

例 D.1 (Cornfield 等 (1959): 吸烟与肺癌). *Cornfield 等 (1959)* 研究了吸烟对肺癌的因果效应。他们在分析中控制了众多重要的背景变量, 但仍可能存在某些未测混杂因素使观察到的效应产生偏倚。

为了加强因果关系的证据, 他们同时报告了吸烟对车祸的影响——基于生物学知识, 吸烟对车祸应该没有因果效应。结果显示关联接近于零。因此, 即使无法完全排除未测混杂, 这个基于阴性结果的补充分析使吸烟对肺癌因果效应的证据更加有力。

例 D.2 (Jackson 等 (2006): 流感疫苗接种). *Jackson 等 (2006)* 对观测性研究的结果持怀疑态度。这些研究显示, 在调整了测量的协变量后, 流感疫苗接种显著降低了流感季节的肺炎/流感住院率和全因死亡率。

他们的补充分析考察了流感季节开始之前的结局指标。疫苗接种通常在秋季开始, 但流感传播在冬季之前是极少的。基于生物学, 疫苗效应在流感季节应该最为显著。但 *Jackson 等* 发现, 疫苗效应在流感季节之前反而更大——这暗示观察到的效应可能源于未测混杂。

阴性结果分析的力量来自于: 如果治疗 Z 通过未测混杂 U 影响结果 Y , 那么 Z 通常也会通过同样的 U 影响与 Y 有相似混杂结构的变量。因此, 如果我们在阴性结果上观察到了预期的零效应 (或已知大小的效应), 这支持了不可混淆性假设的合理性。

等 (2010) 是阴性结果方法的系统性研究。Rosenbaum (1989) 讨论了已知因果效应在因果推断中的作用。

3.3. 策略二: 利用阴性暴露. 阴性暴露是阴性结果的对偶概念。假设 Z^n 是一个与 Z 有相似混杂结构的治疗变量, 且我们事先知道 Z^n 对 Y 的因果效应:

$$(16.7) \quad \tau(Z^n \rightarrow Y) = \mathbb{E}\{Y(1^n) - Y(0^n)\} \text{ 是已知的.??}$$

例 D.3 (Sanderson 等 (2017): 母体暴露与后代结局). *Sanderson 等 (2017)* 给出了利用阴性暴露的多个例子。他们建议比较母体暴露与后代结局的关联, 以及父亲暴露与同样结局的关联。

在母体吸烟与后代结局的研究中: 母体吸烟可能受到未测混杂 (如社会经济地位) 的影响, 而父亲吸烟不太可能受到同样的混杂影响 (因为父亲不经历怀孕)。因此, 如果观察到的母体吸烟效应远大于父亲吸烟效应, 这支持了因果解释; 如果两者效应相似, 则暗示可能存在混杂。

阴性暴露分析的逻辑: 如果不可混淆性成立, 那么 Z 和 Z^n 应该表现出与 Y 相似 (但已知) 的关联模式。如果它们的行为不一致, 则暗示存在未被控制的混杂。

3.4. 小结. 不可混淆性假设在本质上是不可直接检验的。虽然阴性结果和阴性暴露分析无法证明或推翻不可混淆性, 但将它们作为补充性分析可以加强或削弱因果推断的证据基础。

然而, 进行这类补充性分析通常并非易事: 它需要更多的数据, 更重要的是需要对因果问题的深入理解, 以找到令人信服的阴性结果和阴性暴露。在实践中, 找到一个与主结果有相同混杂结构但有已知效应的阴性结果/暴露, 往往需要领域知识的支持。

4. 过度调整的问题

在第 C 章的协变量平衡检验中，我们已经看到：调整正确的协变量可以消除混杂偏倚。但**调整错误的协变量会如何？**

Rosenbaum (2002b) 写道：“没有理由避免调整描述研究对象治疗前特征的变量。”类似地，Rubin (2007) 写道：“通常，条件性越强的假设，越容易接受。”两者都主张应该控制所有观测到的治疗前协变量。

Pearl 不同意这个建议，并给出了两个著名的反例。下面我们详细介绍这两个反例。

4.1. M-偏倚. M-偏倚 (M-bias) 出现在具有 M 结构的因果图中。考虑以下图形：

$$U_1 \rightarrow X \leftarrow U_2, U_1 \rightarrow Z, U_2 \rightarrow Y$$

这个图之所以被称为 M 结构，是因为在因果图中它形似字母 M。从图中我们可以读出数据生成过程：

$$(16.8) \quad \begin{cases} U_1 \perp U_2, \\ X = f_X(U_1, U_2, \varepsilon_X), \\ Z = f_Z(U_1, \varepsilon_Z), \\ Y = Y(z) = f_Y(U_2, \varepsilon_Y), \end{cases} \quad ??$$

其中 $(\varepsilon_X, \varepsilon_Z, \varepsilon_Y)$ 是独立的随机误差。在这个因果图中， X 是观测到的，但 U_1 和 U_2 是未观测到的。如果改变 Z 的值， Y 的值完全不会改变——因为 Z 到 Y 之间没有因果路径。因此， Z 对 Y 的真实因果效应必然为零。

从数学上看：在这个数据生成过程中， $Z \perp Y$ 成立，因此 Z 和 Y 之间的简单关联为零。不调整 X 的简单估计量是无偏的：

$$(16.9) \quad \tau_{\text{PF}} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0) = 0.??$$

但是，如果我们调整 X （即条件于 X ），情况就不同了。调整后， U_1 和 U_2 不再条件独立： $U_1 \not\perp U_2 \mid X$ ，进而 $Z \not\perp Y \mid X$ ，导致调整后的估计量有偏：

$$(16.10) \quad \int \{\mathbb{E}(Y \mid Z = 1, X = x) - \mathbb{E}(Y \mid Z = 0, X = x)\} f(x) dx \neq 0.??$$

直觉解释： X 同时受到 U_1 和 U_2 的影响，而 U_1 影响 Z ， U_2 影响 Y 。当我们条件于 X 时，我们实际上是在 X 的各个取值上比较 Z 和 Y 。但 X 的条件化会人为地在 U_1 和 U_2 之间建立关联——这创造了一条从 Z 到 Y 的虚假后门路径。

为了更直观地理解，我们考虑一个正态线性模型的具体例子（详细推导见习题 D.2）：

$$(16.11) \quad \begin{cases} X = aU_1 + bU_2 + \varepsilon_X, \\ Z = cU_1 + \varepsilon_Z, \\ Y = dU_2 + \varepsilon_Y, \end{cases} \quad ??$$

其中 $(U_1, U_2, \varepsilon_X, \varepsilon_Z, \varepsilon_Y) \stackrel{\text{iid}}{\sim} N(0, 1)$ 。我们可以计算：

$$(16.12) \quad \text{cov}(Z, Y) = \text{cov}(cU_1 + \varepsilon_Z, dU_2 + \varepsilon_Y) = 0, ??$$

这证实了未调整估计量是无偏的。但在给定 X 的条件下, Z 和 Y 的偏相关系数为 (推导见习题 D.2):

$$(16.13) \quad \rho_{ZY|X} \propto -abcd, ??$$

即偏倚与路径系数的乘积 $abcd$ 成正比。

例 D.4 (M-偏倚的数值演示). 考虑样本量 $n = 10^6$ 的大规模蒙特卡洛模拟:

```
U1 = rnorm(n)
U2 = rnorm(n)
X = U1 + U2 + rnorm(n)
Y = U2 + rnorm(n)
Z = U1 + rnorm(n)

# 连续治疗
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.001
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] -0.20

# 二值治疗
Z = (Z >= 0)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.002
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] -0.42
```

未调整的简单估计量接近真实值 (0), 但调整 X 后的估计量产生了显著偏倚 (约 -0.2 到 -0.4)。这就是 M -偏倚。

M -偏倚的教训是: 并非所有治疗前协变量都应该调整。调整一个与未测混杂 U_1 和 U_2 都相关的变量 X , 可能反而在 U_1 和 U_2 之间建立虚假的关联, 从而引入偏倚。

4.2. Z-偏倚. Z-偏倚 (Z-bias) 是另一个过度调整的例子, 但机制与 M -偏倚不同。考虑以下因果图:

$$Z \leftarrow X \rightarrow U \rightarrow Y$$

其中 X 影响 Z 和 U , 而 U 同时影响 Z 和 Y 。对应的数据生成过程是:

$$(16.14) \quad \begin{cases} Z = aX + bU + \varepsilon_Z, \\ Y(z) = \tau z + cU + \varepsilon_Y, \end{cases} ??$$

其中 $(U, X, \varepsilon_Z, \varepsilon_Y) \stackrel{\text{iid}}{\sim} N(0, 1)$ 。在这个设定中, $X \perp U$, 但 X 与 Z 和 Y 都有关联—— X 通过 Z 影响 Y , 而 U 是一个未测混杂。

直觉: 治疗 Z 是 X 、未测混杂 U 和其他随机误差的函数。条件于 X 会使 Z 变得更依赖于 U , 从而**放大了**由 U 引起的混杂偏倚。

数学上, 未调整的 OLS 估计量是 (详细推导见习题 D.1):

$$(16.15) \quad \tau_{\text{unadj}} = \tau + \frac{c \operatorname{cov}(Z, U)}{\operatorname{var}(Z)} = \tau + \frac{cb}{a^2 + b^2 + 1}, ??$$

其偏倚为 $bc/(a^2 + b^2 + 1)$ 。

调整后的 OLS 估计量 (从 Y 对 (Z, X) 的回归) 满足 (详细推导见习题 D.1):

$$(16.16) \quad \tau_{\text{adj}} = \tau + \frac{bc}{b^2 + 1}. ??$$

比较两者：当 $a \neq 0$ 时， $a^2 + b^2 + 1 > b^2 + 1$ ，因此

$$(16.17) \quad \left| \frac{bc}{a^2 + b^2 + 1} \right| < \left| \frac{bc}{b^2 + 1} \right| .??$$

也就是说，**调整后的估计量比未调整的估计量偏倚更大！**而且， X 与 Z 的关联越强（ a 越大），调整引入的偏倚就越大。

例 D.5 (Z-偏倚的数值演示). 考虑蒙特卡洛模拟：

```
n = 10^6
X = rnorm(n)
U = rnorm(n)
Z = X + U + rnorm(n)
Y = U + rnorm(n)

# Z ~ X + U
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.333
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.501

# X-Z 关联更强时
Z = 2*X + U + rnorm(n)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.167
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.501

# X-Z 关联更强时
Z = 10*X + U + rnorm(n)
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.01
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.50
```

可以看到：随着 X 与 Z 的关联增强，未调整估计量越来越接近真实值 $\tau = 0$ ，而调整后的估计量始终为 0.5——因为调整反而引入了更大的偏倚。

Z-偏倚的技术细节见 Problem D.1。Pearl (2010a, 2011) 用因果图解释了这种现象。Ding 等 (2017b) 提供了更一般的理论。

为什么叫 Z-偏倚？在 Pearl 的原始论文中，他用符号 Z 表示我们这里的变量 X （而用 X 表示治疗变量）。为了避免混淆，本书在第五部分讨论工具变量时会正式使用 Z 这个符号——这也是为什么在工具变量情境下，Z-偏倚也被称为**工具变量偏倚 (instrumental variable bias)**。

4.3. 哪些协变量应该调整？真实的因果图可能非常复杂，但我们可以用一个简化的图形来澄清许多概念。考虑以下结构：

$$X_Y \rightarrow Y, X_Y \rightarrow Z, X \rightarrow Z, X \rightarrow Y, X_I \rightarrow Z, X_I \rightarrow Y$$

各类协变量的特征如下：

- (a) X (**混杂变量**)：同时影响治疗和结果。条件于 X 确保不可混淆性假设成立，我们应该控制 X 。
- (b) X_R (**无关变量**)：既不影响治疗也不影响结果，是纯随机噪声。在分析中包含它不会引入偏倚，但会在有限样本中引入不必要的变异性。
- (c) X_Z (**工具变量**)：仅通过治疗影响结果。在图中包含它不会引入偏倚，但会增加估计量的变异性。然而，在存在未测混杂的情况下（如 Z-偏倚所示），调整 X_Z 会**放大偏倚**。

- (d) X_Y (预测变量): 仅影响结果但不影响治疗。即使不条件于它, 不可混淆性假设仍然成立。由于它们对结果有预测力, 在分析中包含它们通常能提高精度。
- (e) X_I (干预后变量): 受治疗和结果共同影响, 是治疗后变量。如果目标是推断治疗对结果的因果效应, 我们不应该调整它。

如果我们相信上述因果图的结构, 那么我们应该至少调整 X 以消除偏倚, 理想情况下还应进一步调整 X_Y 以减少方差。

实践中的困难: 我们永远无法确切知道真实的底层数据生成过程。这是因果推断的根本挑战——我们需要领域知识和假设来指导协变量的选择。

Table 1 总结了各类协变量的特征。

TABLE 1. 协变量类型与调整策略

类型	Z 前置吗?	Y 前置吗?	调整建议
X (混杂)	是	是	应该调整
X_R (无关)	否	否	可调整 (增加方差)
X_Z (工具)	是	否	谨慎: 可能放大偏倚
X_Y (预测)	否	是	可调整 (减少方差)
X_I (干预后)	是	是	不应调整

5. 习题

练习 D.1. 验证正文中的公式 ?? 和 ??。

练习 D.2. 考虑正文中的 M -偏倚正态线性模型。证明给定 X 时 Z 和 Y 的偏相关系数公式 ??。

练习 D.3. 找出一个你自己的研究领域中的阴性结果或阴性暴露的例子。讨论为什么它符合阴性控制的条件, 以及它如何帮助评估不可混淆性假设。

练习 D.4. ? 和 *econometricians* 提出了以下 **Cochran 公式** (也称为遗漏变量偏倚公式)。设 $(y_i, x_{1i}, x_{2i})_{i=1}^n$ 为 IID 样本, 其中 y_i 是标量, x_{1i} 维数为 K , x_{2i} 维数为 L 。考虑 OLS 分解:

$$y_i = \beta_1^T x_{1i} + \beta_2^T x_{2i} + \epsilon_i \quad (\text{长回归}),$$

$$y_i = \gamma^T x_{1i} + e_i \quad (\text{短回归}),$$

$$x_{2i} = \delta^T x_{1i} + v_i.$$

证明: $\gamma = \beta_1 + \delta\beta_2$ 。解释为什么 $\delta\beta_2$ 被称为遗漏变量偏倚。

练习 D.5. 设计一个模拟研究, 演示以下情形:

- 调整混杂变量 X 可以减少偏倚;
 - 调整与未测混杂相关的变量会引入 M -偏倚;
 - 调整工具变量 X_Z 在存在未测混杂时会放大偏倚。
- 对于每种情形, 使用大样本量 ($n = 10^5$) 计算未调整和调整后的估计量。

6. 推荐阅读

关于因果图和因果推断的深入讨论，见 Pearl (2000) 的经典教科书。

和 Shpitser (2011) 讨论了协变量选择的正式准则。

(2002b) 是关于观测性研究中敏感性分析的重要参考文献，也是本章许多思想的源头。

等 (2017b) 提供了 Z-偏倚（工具变量偏倚）的一般性理论。

E-Value: 未测混杂观测性研究中的因果证据

1. 引言：当可忽略性假设失效时

“It is possible that the entire relationship between cigarette smoking and lung cancer is due to some common cause.” — (?)

在 Part III 中，我们详细讨论了观测性研究的四大支柱：outcome regression (第 C 章)、逆倾向得分加权 (第 D 章)、双重稳健 (第 E 章) 以及匹配 (第 C 章)。这四种方法的核心假设是**可忽略性 (ignorability)**：

$$(79) \quad Z \perp \{Y(1), Y(0)\} \mid X.$$

即在协变量 X 条件下，治疗分配 Z 与潜在结果相互独立。这个假设保证了我们可以从观测数据中识别因果效应。然而，**可忽略性假设无法从数据本身验证**——它是一种根本性的假设，依赖于研究者的领域知识和对因果结构的判断。

这正是观测性研究长期被批评的原因：如果无法控制所有混淆因素，观察到的治疗与结果之间的关联可能是虚假的。统计学能告诉我们观测数据中的关联有多强，但无法保证这种关联背后存在真实的因果关系。

然而，**并非所有观测性研究都生来平等**。一些研究即便存在未测混杂，其提供的因果证据也比其他研究更强。关键在于：要完全解释掉观察到的关联，未测混杂需要有多强？如果这种强度在领域知识上是不合理的，我们就有理由相信因果关系确实存在。

本章引入的 **E-value** (VanderWeele and Ding, 2017) 正是对这一思想的数学量化。它基于 Ding and VanderWeele (2016) 的理论，为评估观测性研究中的因果证据提供了一个统一且可解释的度量。第 ?? 章讨论平均因果效应的灵敏度分析；第 ?? 章讨论 Rosenbaum 框架下的匹配研究灵敏度分析。

2. Cornfield 型灵敏度分析

2.1. 从可忽略性到潜在可忽略性。 放弃假设 eq. (79) 并不意味着放弃一切分析工具。我们仍然可以假设**潜在可忽略性 (latent ignorability)**：

$$(80) \quad Z \perp \{Y(1), Y(0)\} \mid (X, U),$$

其中 U 是未测混杂变量，条件于 (X, U) 时治疗与潜在结果独立。注意 eq. (80) 比 eq. (79) 更弱——它允许 Z 与 Y 之间存在通过 U 传递的关联，只要这种关联可以被 U 完全解释。

本章的方法在二值结果 Y 上表现最佳 (Ding and VanderWeele, 2016)，但可推广到其他非负结果。为简化叙述，除非特别说明，我们均假设 Y 为二值。

2.2. 真实风险比与观测风险比。 在 $X = x$ 条件下，真实的条件风险比为：

$$(81) \quad \text{RR}_{ZY|x}^{\text{true}} = \frac{\{Y(1) = 1 \mid X = x\}}{\{Y(0) = 1 \mid X = x\}}.$$

但从数据中能直接计算的是观测风险比：

$$(82) \quad RR_{ZY|x}^{\text{obs}} = \frac{(Y = 1 \mid Z = 1, X = x)}{(Y = 1 \mid Z = 0, X = x)}.$$

在存在未测混杂 U 时，二者一般不相等。直观上，这是因为 U 在治疗组和对照组中的分布不同 (U 同时影响治疗分配和结果)，而真实的因果效应需要控制 U 后才能得到。

考虑如下因果图 (条件于 X):

$$Z \leftarrow U \rightarrow Y,$$

其中 U 是 Z 和 Y 的共同原因 (common cause)。在此结构下, $Z \perp Y \mid (X, U)$ 但 $Z \not\perp Y \mid X$ 。为简化, 我们假设 U 为二值, 尽管 Ding and VanderWeele (2016) 的理论对 U 的一般形式也成立。

定义两个灵敏度参数:

$$(83) \quad RR_{ZU|x} = \frac{(U = 1 \mid Z = 1, X = x)}{(U = 1 \mid Z = 0, X = x)},$$

衡量**治疗-混杂关联**; 以及

$$(84) \quad RR_{UY|x} = \frac{(Y = 1 \mid U = 1, X = x)}{(Y = 1 \mid U = 0, X = x)},$$

衡量**混杂-结果关联**。这两个量都无法从数据中识别——它们是未知的灵敏度参数, 反映了未测混杂的强度。

2.3. Cornfield 不等式. 下面的定理是整个 E-value 理论的基石。

定理 E.1 (Cornfield-type 上界). 在假设 eq. (80) 下, 假设

$$(85) \quad RR_{ZY|x}^{\text{obs}} > 1, \quad RR_{ZU|x} > 1, \quad RR_{UY|x} > 1.$$

则有

$$(86) \quad RR_{ZY|x}^{\text{obs}} \leq \frac{RR_{ZU|x} \cdot RR_{UY|x}}{RR_{ZU|x} + RR_{UY|x} - 1}.$$

定理 E.1 的含义: 在潜在可忽略性下, 治疗与结果之间的观测关联完全来自两条路径—— $Z \leftarrow U \rightarrow Y$ ——的组合效应。上界 $RR_{ZU|x} \cdot RR_{UY|x} / (RR_{ZU|x} + RR_{UY|x} - 1)$ 体现了这两条路径的“乘法阻塞”: 要产生一个较大的 $RR_{ZY|x}^{\text{obs}}$, 两条路径都必须足够强。

特别地, 从 eq. (86) 可推出 **Cornfield 不等式** (Gastwirth et al., 1998):

$$(87) \quad \min(RR_{ZU|x}, RR_{UY|x}) \geq RR_{ZY|x}^{\text{obs}}.$$

即: 要完全解释掉观测到的风险比, 未测混杂与治疗的关联以及与结果的关联, 都必须**至少与观测到的风险比一样强**。这个简单而强大的结论, 首次由 Cornfield et al. (1959) 在讨论吸烟与肺癌时得到。

证明思路: 定义 $f_{1,x} = (U = 1 \mid Z = 1, X = x)$ 和 $f_{0,x} = (U = 1 \mid Z = 0, X = x)$ 。通过全概率公式分解 $RR_{ZY|x}^{\text{obs}}$ 并利用 $Z \perp Y \mid (X, U)$, 可得恒等式 (100)。¹

¹完整证明推导见附录 chapter A

3. E-value

3.1. 从 Cornfield 不等式到 E-value. 从定理 E.1 和引理 E.3(4), 定义 $w = \max(\text{RR}_{ZU|x}, \text{RR}_{UY|x})$, 则

$$(88) \quad \text{RR}_{ZY|x}^{\text{obs}} \leq \frac{w^2}{2w-1}.$$

解这个二次不等式, 较小根始终 ≤ 1 , 故

$$(89) \quad w \geq \text{RR}_{ZY|x}^{\text{obs}} + \sqrt{\text{RR}_{ZY|x}^{\text{obs}}(\text{RR}_{ZY|x}^{\text{obs}} - 1)}.$$

这给出了 E-value 的定义。

定义 E.2 (E-value). 给定观测条件风险比 $\text{RR}_{ZY|x}^{\text{obs}}$, 定义 **E-value** 为

$$(90) \quad \text{E-value} = \text{RR}_{ZY|x}^{\text{obs}} + \sqrt{\text{RR}_{ZY|x}^{\text{obs}}(\text{RR}_{ZY|x}^{\text{obs}} - 1)}.$$

E-value 的解释: E-value 表示要完全解释掉观测到的风险比, $\max(\text{RR}_{ZU|x}, \text{RR}_{UY|x})$ 必须达到的最小值。换言之, 如果领域知识认为任何合理的未测混杂, 其与治疗结果的关联程度都不可能超过某个阈值 R , 那么当 $R < \text{E-value}$ 时, 我们有理由相信因果关系确实存在。

E-value 与 Fisher p 值的对比: 在随机化实验中, Fisher p 值衡量的是因果证据。但在大样本观测性研究中, p 值可能是因果证据的误导性度量——即使真实因果效应为零, 微弱的未测混杂也可以产生极小的 p 值。采样误差随样本量增大而减小, 但未测混杂带来的不确定性不会随样本量增大而消失。E-value 正是为了填补这一空白而设计的。

引理 E.3 (β 函数性质). 定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$ ($w_1 > 1, w_2 > 1$)。则:

- (a) $\beta(w_1, w_2)$ 对称于 w_1 和 w_2 ;
- (b) $\beta(w_1, w_2)$ 对 w_1 和 w_2 均单调递增;
- (c) $\beta(w_1, w_2) \leq w_1$ 且 $\beta(w_1, w_2) \leq w_2$;
- (d) $\beta(w_1, w_2) \leq w^2 / (2w - 1)$, 其中 $w = \max(w_1, w_2)$ 。

引理 E.3 的意义: (3) 意味着 Cornfield 不等式可以直接从定理 E.1 推出; (4) 是连接 Cornfield 界与 E-value 的关键步骤。²

4. 经典例子：吸烟与肺癌

例 E.1 (Hammond and Horn, 1958). 研究美国人群中吸烟与肺癌的关系。不调整协变量的数据可列为下表:

	肺癌	无肺癌
吸烟者	397	78,557
非吸烟者	51	108,778

基于该数据, 风险比估计为 $\widehat{RR} = 10.73$, 95% 置信区间为 $[8.02, 14.36]$ 。

- 解释点估计的 E-value:

$$\text{E-value} = 10.73 + \sqrt{10.73 \times 9.73} \approx 20.95.$$

²证明见附录 chapter B

- 解释下限的 *E-value*:

$$E\text{-value}_{CI} = 8.02 + \sqrt{8.02 \times 7.02} \approx 15.52.$$

解读: 要完全解释掉观察到的风险比 (甚至其置信下限), 未测混杂与治疗的关联以及与结果的关联, 都必须达到至少 15.52。这意味着未测混杂必须是一个**极强的**风险因子——它与吸烟的关联程度要接近吸烟本身与肺癌的关联程度 (10 倍以上)。在领域知识上, 这种强度的未知混杂似乎不太合理, 因此该研究提供了较强的因果证据。

图 ?? (Hammond and Horn 数据的混淆强度轮廓) 展示了要解释掉点估计和置信下限, 两类混淆强度 ($RR_{ZU|x}, RR_{UY|x}$) 需要满足的条件。

5. 扩展

5.1. E-value 与 Bradford Hill 因果判定准则. E-value 提供了因果证据的定量度量, 但它与流行病学中经典的 **Bradford Hill 准则** (Bradford Hill, 1965) 有深刻的联系。Bradford Hill 提出了九条判断因果关系的准则, 其中第一条是:

强度 (Strength) : 关联越强, 因果解释的可能性越大。

定理 E.1 从数学上精确化了这一直觉: **更强的关联需要更强的未测混杂来解释**。E-value 正是这种“强度”的量化。

当然, 关联强度只是因果判定的一个方面。Bradford Hill 的其他准则——时间顺序 (temporality)、生物学合理性 (biological plausibility)、一致性 (consistency)、剂量-反应关系 (dose-response) ——都从不同角度提供证据。E-value 只量化了“强度”这一维度。

定义 E.4 (Bradford Hill 九条因果准则). (?) 提出的九条因果判定准则:

- 强度 (*strength*);
- 一致性 (*consistency*);
- 特异性 (*specificity*);
- 时间顺序 (*temporality*);
- 生物学梯度 (*biological gradient*);
- 生物学合理性 (*plausibility*);
- 一致性 (*coherence*);
- 实验证据 (*experiment*);
- 类比 (*analogy*)。

E-value 量化了第 (1) 条准则, 但没有涉及其他八条。这是 E-value 的适用范围——它是一个有意义的补充, 但不是因果判定的全部。

5.2. 逻辑斯蒂回归后的 E-value. 流行病学研究中, 二值结果常用逻辑斯蒂回归建模:

$$(91) \quad (Y_i = 1 | Z_i, X_i) = \frac{e^{\beta_0 + \beta_1 Z_i + \beta_2^\top X_i}}{1 + e^{\beta_0 + \beta_1 Z_i + \beta_2^\top X_i}}.$$

其中系数 β_1 是给定 X 下治疗与结果的**条件比数比 (conditional odds ratio)** 的对数。逻辑斯蒂模型的一个重要假设是: 比数比在所有 X 取值上是共同的 (common odds ratio)。

当结果罕见时 ($(Y = 1 | Z, X)$ 接近 0), 条件比数比近似于条件风险比 (见附录 chapter C)。

因此，在罕见结果假设下，我们可以直接基于逻辑斯蒂回归估计的 $\hat{\beta}_1$ 计算 E-value：

$$(92) \quad \widehat{\text{E-value}} = \exp(\hat{\beta}_1) + \sqrt{\exp(\hat{\beta}_1)(\exp(\hat{\beta}_1) - 1)}.$$

这使得 E-value 可以方便地应用于常规的流行病学分析流程。

例 E.2 (NCHS 2003 出生数据). 使用美国国家卫生统计中心 2003 年出生证明数据，研究高龄母亲 (≥ 35 岁) 对早产的影响。调整社会人口学协变量后，逻辑斯蒂回归得到的条件风险比为 1.31，其 95% 置信区间为 [1.29, 1.33]。

对应的 E-value 约为 1.94 (点估计) 和 1.91 (置信下限)。这意味着要解释掉观察到的关联，未测混杂必须同时与治疗 (高龄) 和结果 (早产) 有至少 1.9 倍的关联——这个强度在流行病学上看起来是较大的，但远不如吸烟-肺癌例子中的 20.95。

5.3. 允许非零真实因果效应. 定理 E.1 假设真实因果效应为零。Ding and VanderWeele (2016) 将结果推广到允许非零真实因果效应的情形。

定理 E.5 (含真实因果效应的下界). 修改 $RR_{UY|x}$ 的定义为：

$$(93) \quad RR_{UY|x} = \max_{z=0,1} \frac{(Y=1 | Z=z, U=1, X=x)}{(Y=1 | Z=z, U=0, X=x)}.$$

则在假设 eq. (80) 下，

$$(94) \quad RR_{ZY|x}^{\text{true}} \geq \frac{RR_{ZY|x}^{\text{obs}}}{\frac{RR_{ZU|x} \cdot RR_{UY|x}}{RR_{ZU|x} + RR_{UY|x} - 1}}.$$

定理 E.5 的解读：即使存在未测混杂，定理也给出了真实因果效应 $RR_{ZY|x}^{\text{true}}$ 的一个下界。这个下界等于观测风险比除以 Cornfield 上界。当灵敏度参数取不同值时，我们可以评估因果效应下界对未测混杂强度的敏感性。

6. 批评与回应

自 E-value 论文发表以来，它已成为流行病学研究中报告的标准数字。但它也受到了批评 (Ioannidis et al., 2019)。下面讨论几个主要局限性。

6.1. E-value 不过是风险比的单调变换. 当风险比较大时，E-value 近似等于 $2 \cdot RR_{ZY|x}^{\text{obs}}$ ——几乎是线性的。因此批评者认为 E-value 不过是风险比的一个单调变换，没有提供额外信息。

这部分正确——E-value 确实完全基于风险比的点估计和置信限。但关键在于：E-value 有**有意义的解释** (定义 E.2)，而风险比本身没有这种“需要多强的未测混杂”的解释。从风险比 10.73 到 E-value 20.95，数字变了，但解释的含义完全不同。

6.2. E-value 的校准问题. E-value 等于 $\max(RR_{ZU|x}, RR_{UY|x})$ ——即要解释掉观察到的关联，未测混杂与治疗 and 结果关联所必须达到的最小值。问题在于：这个未测混杂本身是无法观测的，因此很难判断某个 E-value 究竟算“大”还是“小”。

此外，E-value 的大小取决于我们调整了多少协变量 X ——它量化的是**给定已调整协变量后的**残余混杂强度。不同研究之间的 E-value 不能直接比较，因为它们的 X 不同。

一个直观的校准思路是”逐一剔除协变量”法：如果我们把某个已调整的协变量 X_j 当作”未测混杂”来对待，计算 $Z-X_j$ 和 X_j-Y 的风险比，这些比值可以提供参考尺度。但这一方法尚无严格的理论支撑。

6.3. E-value 最适用于二值结果和风险比. 定理 E.1 在二值结果和风险比尺度上表现最佳。Ding and VanderWeele (2016) 也提出了风险差、均值比（针对非负结果）以及生存分析中的风险比（HR）的灵敏度分析方法，但它们不如二值结果下的 E-value 那样优雅和简洁。第 ?? 章将给出平均因果效应的更一般灵敏度分析方法，适用于 outcome regression、IPW 和双重稳健估计。

7. 本章小结

本章围绕 E-value 展开，核心思想是：

- (a) **未测混杂无法从数据中验证**，但我们可以量化：要解释掉观察到的关联，未测混杂必须有多强？
- (b) **Cornfield 不等式**：要完全解释掉风险比 $RR_{ZY|x}^{obs}$ ，未测混杂与治疗的关联和与结果的关联都必须至少达到 $RR_{ZY|x}^{obs}$ ；
- (c) **E-value** 是这一思想的精确数学化： $E\text{-value} = RR_{ZY|x}^{obs} + \sqrt{RR_{ZY|x}^{obs}(RR_{ZY|x}^{obs} - 1)}$ ；
- (d) E-value 越大，意味着需要越强的未测混杂才能解释掉观察到的关联，因果证据越强；
- (e) E-value 有明确的局限性——它只量化了 Bradford Hill 准则中的”强度”维度，且最适用于二值结果和风险比。

本章将所有推导放在附录，正文专注于概念的动机、历史的脉络和结果的理解。

8. 习题

[17.1] 证明函数 $f(x) = (ax+1)/(bx+1)$ 在 $a > b$ 时关于 x 单调递增，在 $a < b$ 时单调递减。

[17.2] 证明在假设 $Z \perp Y | (X, U)$ 下，如果 $RR_{ZU|x} > 1$ 但 $RR_{UY|x} < 1$ ，则 $RR_{ZY|x}^{obs} < 1$ 。这说明 eq. (85) 中的第三个条件在某种意义上是冗余的。

[17.3] 证明引理 E.3。

[17.4] (Schlesselman 1978 公式) 在二值治疗 Z 、结果 Y 和未测混杂 U 下，假设层内 ($U = 0$ 和 $U = 1$) 治疗对结果的风险比相同， $RR_{ZY|U=0} = RR_{ZY|U=1}$ ，且混杂对结果的风险比在两组治疗下也相同（记为 γ ）。证明：

$$(95) \quad \frac{RR_{ZY}^{obs}}{RR_{ZY}^{true}} = \frac{1 + (\gamma - 1)(U = 1 | Z = 1)}{1 + (\gamma - 1)(U = 1 | Z = 0)}.$$

并讨论此公式与定理 E.1 的关系。

[17.5] 使用与例 E.2 相同的数据集，计算结果为子痫前期 (preeclampsia) 时的 E-value。

[17.6] (风险差的 Cornfield 不等式) 考虑二值 Z, Y, U 。在潜在可忽略性 $Z \perp Y | U$ 下，证明风险差的 Cornfield 不等式：

$$(96) \quad RD_{ZY}^{obs} = RD_{ZU} \times RD_{UY},$$

并由此推出：

$$(97) \quad \min(RD_{ZU}, RD_{UY}) \geq RD_{ZY}^{obs}, \quad \max(RD_{ZU}, RD_{UY}) \geq \sqrt{RD_{ZY}^{obs}}.$$

9. 推荐阅读

- ?：扩展并统一了 Cornfield 型灵敏度分析，是 E-value 的理论基础。
- ?：首次正式提出 E-value 并给出其流行病学解释。
- ?：Bradford Hill 原文，九条因果准则的经典来源。
- ?：对 E-value 的批评性讨论。

APPENDIX A

附录：定理 E.1 的证明

1. 背景与目标

我们要在假设 eq. (80) 下，证明观测风险比的上界。核心思想是：条件于 (X, U) 后，治疗 Z 与结果 Y 独立，因此观测风险比中的分子和分母分别是 U 在治疗组和对照组中分布的加权平均。

2. 记号定义

定义：

$$(98) \quad f_{1,x} = (U = 1 \mid Z = 1, X = x), \quad f_{0,x} = (U = 1 \mid Z = 0, X = x).$$

由灵敏度参数的定义 eq. (83)：

$$(99) \quad \text{RR}_{ZU|x} = \frac{f_{1,x}}{f_{0,x}} \implies f_{0,x} = \frac{f_{1,x}}{\text{RR}_{ZU|x}}.$$

定义 $\gamma_x = \text{RR}_{UY|x}$ 以简化记号。

3. 详细推导

利用全概率公式，分子（治疗组的条件结果概率）为：

$$\begin{aligned} (Y = 1 \mid Z = 1, X = x) &= (Y = 1 \mid U = 1, X = x)(U = 1 \mid Z = 1, X = x) \\ &\quad + (Y = 1 \mid U = 0, X = x)(U = 0 \mid Z = 1, X = x) \\ &= \gamma_x f_{1,x} + (1 - f_{1,x}) \cdot 1 \\ &= (\gamma_x - 1)f_{1,x} + 1. \end{aligned}$$

分母（对照组的条件结果概率）为：

$$\begin{aligned} (Y = 1 \mid Z = 0, X = x) &= (Y = 1 \mid U = 1, X = x)(U = 1 \mid Z = 0, X = x) \\ &\quad + (Y = 1 \mid U = 0, X = x)(U = 0 \mid Z = 0, X = x) \\ &= \gamma_x f_{0,x} + (1 - f_{0,x}) \\ &= (\gamma_x - 1)f_{0,x} + 1. \end{aligned}$$

代入 $f_{0,x} = f_{1,x}/\text{RR}_{ZU|x}$ ，得：

$$(Y = 1 \mid Z = 0, X = x) = (\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1.$$

因此观测风险比可以写成：

$$(100) \quad \text{RR}_{ZY|x}^{\text{obs}} = \frac{(\gamma_x - 1)f_{1,x} + 1}{(\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1}.$$

4. 单调性与上界

对 $f_{1,x} \in [0, 1]$, 可验证函数

$$g(t) = \frac{(a-1)t + 1}{(a-1)^{\frac{t}{b}} + 1}$$

在 $a > 1, b > 1$ 时关于 t 单调递增 (习题 8)。因此 $f_{1,x}$ 越大, $\text{RR}_{ZY|x}^{\text{obs}}$ 越大。取上界 $f_{1,x} = 1$:

$$\text{RR}_{ZY|x}^{\text{obs}} \leq \frac{(\gamma_x - 1) + 1}{\frac{\gamma_x - 1}{\text{RR}_{ZU|x}} + 1} = \frac{\gamma_x \cdot \text{RR}_{ZU|x}}{\gamma_x + \text{RR}_{ZU|x} - 1}.$$

这正是定理 E.1 中的上界 eq. (86)。

5. 恒等式

由以上推导, 我们实际得到了一个精确的恒等式 (而非仅仅是上界) eq. (100)。这个恒等式涉及三个灵敏度参数 ($f_{1,x}, \text{RR}_{ZU|x}, \text{RR}_{UY|x}$), 而定理 E.1 的上界只涉及后两者。数学上恒等式强于不等式, 但恒等式需要多一个灵敏度参数——这是灵敏度分析中**准确度与便利性之间的权衡**。

附录：引理 E.3 的证明

定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$, 其中 $w_1 > 1, w_2 > 1$ 。

性质 (1) 对称性：显然 $\beta(w_1, w_2) = \beta(w_2, w_1)$ 。

性质 (2) 单调性：计算偏导数：

$$\frac{\partial \beta}{\partial w_1} = \frac{w_2(w_1 + w_2 - 1) - w_1 w_2}{(w_1 + w_2 - 1)^2} = \frac{w_2(w_2 - 1)}{(w_1 + w_2 - 1)^2} > 0.$$

同理 $\partial \beta / \partial w_2 > 0$, 故 β 对两个变量均单调递增。

性质 (3) 上界：

$$\beta(w_1, w_2) = \frac{w_1 w_2}{w_1 + w_2 - 1} \leq \frac{w_1 w_2}{w_1} = w_2 \quad (\text{因为 } w_2 - 1 \geq 0).$$

对称地得到 $\beta \leq w_1$ 。

性质 (4) $w = \max(w_1, w_2)$ 时的界：设 $w_1 = w, w_2 \leq w$, 则

$$\beta(w_1, w_2) = \frac{w \cdot w_2}{w + w_2 - 1} \leq \frac{w \cdot w}{w + w - 1} = \frac{w^2}{2w - 1}.$$

证毕。

附录：罕见结果近似

对于二值结果 Y ，逻辑斯蒂模型 eq. (91) 中治疗指示变量 Z 的系数 β_1 是条件比数比 (odds ratio)：

$$\beta_1 = \log \text{OR}_{ZY|x} = \log \frac{\text{odds}(Y = 1 \mid Z = 1, X = x)}{\text{odds}(Y = 1 \mid Z = 0, X = x)}.$$

当结果罕见时， $(Y = 1 \mid Z = 1, X = x) \approx 0$ 且 $(Y = 1 \mid Z = 0, X = x) \approx 0$ ，此时

$$\text{odds}(Y = 1 \mid Z, X) \approx \frac{(Y = 1 \mid Z, X)}{1 - (Y = 1 \mid Z, X)} \approx (Y = 1 \mid Z, X).$$

因此罕见结果假设下，条件比数比近似于条件风险比：

$$\beta_1 \approx \log \text{RR}_{ZY|x}^{\text{obs}}.$$

由此可得 $\exp(\beta_1) \approx \text{RR}_{ZY|x}^{\text{obs}}$ ，进而 E-value 的计算公式 eq. (90) 可直接应用于逻辑斯蒂回归系数。