

因果推断讲义

Peng Ding

Contents

引言：文献概述	13
引言：文献概述	13
1. 总述	13
2. 文献摘要总结	13
3. 补充参考资料	14
4. 学习路径与前置基础知识	14
5. 最终目标	14
Chapter 1. 相关性、关联与 Yule-Simpson 悖论	15
1. 本章导论	15
2. 为什么这个问题很重要	15
3. 相关性与因果性的区别	15
4. 二维列联表与关联度量	15
5. Yule-Simpson 悖论	16
6. 偏相关系数与 Yule-Simpson 悖论	16
7. LaLonde 数据与规格搜索问题	17
8. 种族歧视的简历实验	17
9. 本章小结与下节预告	17
10. 习题	17
Chapter 2. 潜在结果框架	19
1. 从相关到因果：为什么关联不够？	19
2. 一个思想实验	19
3. 科学表 (Science Table)	19
4. 个体因果效应	20
5. 平均因果效应	20
6. 亚组与亚组因果效应	21
7. 亚组因果效应与 Yule-Simpson 悖论的不存在	21
8. 治疗分配机制与基本恒等式	21
9. SUTVA：使框架有效的必要假设	21
10. 反事实思维的逻辑	22
11. 实验单元定义的微妙性	23
12. 非线性因果参数	23
13. 本章小结	23
14. 习题	23
Chapter 3. 完全随机实验与费舍尔随机化检验	25
1. 从潜在结果框架到随机实验：问题的起源	25
2. Fisher 的洞见：随机化的两个原则	25

3. 完全随机实验的定义	25
4. Sharp Null 假设与 FRT 逻辑	26
5. 随机化分布与精确 p 值	26
6. Monte Carlo 近似	27
7. 检验统计量的规范选择	27
8. FRT 与传统 t 检验的关系	34
9. LaLonde 实验数据案例	34
10. 历史侧边栏：随机实验的起源	34
11. Sharp Null 假设的置信区间	35
12. 本章小结	35
13. 习题	35
Chapter 4. Neymanian 重复抽样推断	37
1. 两种推断哲学的对话	37
2. 有限总体量	37
3. 一个关键引理	38
4. Neyman (1923) 定理	38
5. 方差公式的深入理解	39
6. Neyman (1923) 定理的证明	39
7. 渐近正态性与置信区间	40
8. Neymanian 推断与 OLS 的关系	40
9. 重尾结局与正态近似的失效	41
10. 本章小结	41
11. 习题	42
Chapter 5. 分层与后分层随机实验	43
1. 引言：随机化的艺术	43
2. SRE 的定义与记号	43
3. 层别平均因果效应	44
4. SRE 中的 Fisher 随机化检验	44
5. Neymanian 推断	46
6. SRE 与 CRE 的效率比较	47
7. CRE 中的后分层	48
8. 实践中的问题	48
9. 本章小结	48
10. 习题	49
Chapter 6. 回归调整与协变量平衡	51
1. 引言：从分层到连续协变量	51
2. 重随机化：设计阶段的协变量平衡	51
3. ReM 下的统计推断	52
4. 回归调整：分析阶段的协变量平衡	53
5. 回归调整的补充讨论	56
6. 分层随机实验的推广	56
7. 设计策略的统一与比较	57
8. 模拟研究	57
9. 结语：协变量平衡的两种路径	58
10. 习题	58

Chapter 7. 配对随机实验	61
1. 引言：从分层到配对的极致追求	61
2. MPE 的定义与记号	61
3. Fisher 随机化检验	61
4. Neymanian 推断	64
5. 协变量调整	65
6. Darwin 数据的 FRT 分析	66
7. 儿童电视 Workshop 实验	67
8. MPE 与 CRE 的比较	67
9. 一般配对实验的扩展	68
10. 本章小结	69
11. 习题	69
Chapter 8. 分层实验中的 Fisher 随机化检验：Studentized 统计量	71
1. 引言：从 Chapter 3 的 FRT 到 Chapter 8 的双重保证	71
2. Studentized 统计量的双重保证	71
3. 分层实验中的 Studentized 统计量	72
4. 带协变量的 FRT	73
5. 模拟研究	74
6. 实践建议	74
7. 案例研究：铁补充剂实验的重新分析	75
8. 本章小结	77
9. 习题	78
Chapter 9. 随机实验中的协变量调整	79
1. 引言：为什么需要协变量调整？	79
2. 超级总体框架下的 CRE	79
3. 模拟研究	81
4. SRE 的扩展	81
5. 本章小结	81
6. 习题	82
Chapter 10. 结果回归：连接随机实验与观测性研究	83
1. 从随机实验到观测性研究：一个自然的问题	83
2. 三个典型例子	83
3. 潜在结果框架下的因果效应与选择偏差	84
4. 非参数识别的充分条件	84
5. 两种简单估计策略及其局限	85
6. 二值结果的情形	86
7. 本章小结	87
8. 练习	87
9. 推荐阅读	88
Chapter 11. 倾向得分在观测性研究中的核心地位	89
1. 引言：为什么需要倾向得分？	89
2. 倾向得分的定义与降维性质	89
3. 倾向得分分层	90
4. 逆概率加权估计量	91

5. 倾向得分的平衡性质	92
6. 与结果回归的对比	93
7. 重叠条件与外推风险	93
8. 本章小结	93
9. 习题	94
Chapter 12. 双重稳健估计	95
1. 引言: 一个估计量的双重保险	95
2. 总体版本的 DR 估计量	95
3. 双重稳健性定理	96
4. 样本版本的 DR 估计量	96
5. 更深层的直觉	97
6. 模拟研究	97
7. 进一步讨论: 为何脆弱?	98
8. 本章小结	98
9. 习题	98
10. 定理 定义 12.1 的证明	100
11. 双重稳健估计量的等价形式推导	100
12. 从 IPW 到 DR 的分解	100
13. 从结果回归到 DR 的偏倚修正	101
14. 双重稳健性的乘积结构	101
15. 模拟研究详情	101
Chapter 13. 基于倾向得分的分层	103
1. 引言: 从分层随机实验到观测性研究	103
2. 倾向得分的维度约化性质	103
3. 倾向得分分层	104
4. 分层数 K 的选择	105
5. 与第五章的联系: SRE 的观测性研究版本	105
6. 标准误的估计	105
7. 应用实例	106
8. 小结	107
Chapter 14. 加权最小二乘法用于因果推断	109
1. 一个问题意识: IPW 估计量的另一种面孔	109
2. Hajek 估计量作为 WLS 估计量	109
3. 加入协变量: Lin (2013) 的推广与双重稳健性	110
4. 处理组平均因果效应的 WLS	111
5. 统一视角: 回归估计量一览	112
6. 本章小结	112
7. 习题	112
Chapter 15. 观测性研究中的匹配	115
1. 引言: 为什么匹配比回归更直观?	115
2. 匹配的基本思想	115
3. 匹配估计量: 一对一匹配	115
4. 匹配的双稳健形式	116
5. ATT 的匹配估计量	117

6. 实践中的问题	117
7. 实例：LaLonde 数据	117
8. 本章小结	118
9. 习题	118
Chapter 16. 观测性研究中不可混淆性假设的困难	119
1. 引言：当我们无法控制所有混杂因素时	119
2. 因果图的基本概念	119
3. 评估不可混淆性假设	120
4. 过度调整的问题	121
5. 习题	124
6. 推荐阅读	125
Chapter 17. E-Value：未测混杂观测性研究中的因果证据	127
1. 引言：当可忽略性假设失效时	127
2. Cornfield 型灵敏度分析	127
3. E-value	129
4. 经典例子：吸烟与肺癌	129
5. 扩展	130
6. 批评与回应	131
7. 本章小结	132
8. 习题	132
9. 推荐阅读	132
Chapter 18. 平均因果效应的灵敏度分析	133
1. 引言：可忽略性失效时我们能做什么	133
2. Manski 型最坏情况界	133
3. 平均因果效应的灵敏度分析	134
4. R 函数与实证示例	136
5. 本章小结	137
6. 习题	138
7. 推荐阅读	139
Chapter 19. Rosenbaum 风格 p 值：匹配观测研究中的未测量混杂	141
1. 引言：从理想实验到现实挑战	141
2. 匹配观测研究的灵敏度分析模型	141
3. 最坏情况 p 值	142
4. 实例分析	143
5. 练习	145
6. 本章小结	145
Chapter 20. 平行世界框架	147
1. 引言：跨越两个世界的桥梁	147
2. 重叠假设的隐含要求	147
3. 当重叠失败时：修整与结果建模	148
4. 无重叠情形下的因果推断：回归断点设计	148
5. 本章小结	150
附录：公式推导	150

Chapter 21. 工具变量：从不完美实验到因果效应	153
1. 引言：无法假设无混淆时，我们还能做什么？	153
2. 鼓励设计与非依从性	153
3. 潜在依从性类型与因果效应分解	154
4. 三个核心假设：单调性、排除限制与随机性	154
5. 识别 Complier 平均因果效应 (CACE)	155
6. 估计	156
7. 协变量	157
8. 弱工具变量	158
9. CACE 的解释	159
10. JOBS II 数据集应用	159
11. 习题	161
Chapter 22. 依从性与意向治疗分析	163
1. 引言：从随机实验到现实世界	163
2. 鼓励设计与依从性问题	163
3. 潜在依从性类型与依从性因果效应	164
4. 非参数识别	165
5. 依从性平均因果效应 (CACE/LATE)	166
6. 估计	166
7. 弱工具变量	167
8. 协变量调整	168
9. 实例：JOBS II 培训项目	168
10. 从识别到解释：CACE 的深层含义	169
11. 本章小结	169
12. 习题	169
Chapter 23. 两阶段最小二乘	171
1. 引言：工具变量回归的计算技巧	171
2. 问题设定：过度识别情形	171
3. 两阶段最小二乘估计量	171
4. 标准误的估计	172
5. 特殊情形：单一工具变量与单一内生处理	172
6. 弱工具变量问题	173
7. 应用：Card (1993) 教育回报研究	174
8. 小结	174
9. 习题	174
Chapter 24. 模糊断点回归	175
1. 本章导论	175
2. 从清晰断点到模糊断点	175
3. 动机实例	175
4. 数学设定	176
5. 识别定理	176
6. 估计方法	177
7. 数据应用	177
8. 讨论	178
9. 本章小结	178

10. 习题	178
Chapter 25. 孟德尔随机化	179
1. 引言：遗传学与因果推断的交汇	179
2. 背景与动机	179
3. 线性 IV 模型回顾	179
4. 基于汇总统计的 MR 分析	180
5. 实例分析	182
6. MR 分析的批评与局限	183
7. 习题	184
推荐阅读	184
Chapter 26. 主分层：条件因果效应与中介分析的基础	185
1. 本章导论	185
2. 主分层的定义与记号	185
3. 核心因果 estimand：主层平均因果效应	186
4. 主分层在中介分析中的应用	186
5. 可识别性与关键假设	186
6. 本章小结	187
Chapter 27. 中介分析：自然直接效应与自然间接效应	189
1. 本章导论：一个古老的追问	189
2. 从总效应到直接效应与间接效应	189
3. 嵌套潜在结果	190
4. 中介公式	191
5. 线性模型下的 Baron-Kenny 方法	193
6. 应用实例：JOBS II 数据	194
7. 敏感性分析	195
8. 本章小结	195
练习	196
Chapter 28. 受控直接效应	199
1. 引言：另一种处理中介变量的视角	199
2. 受控直接效应的定义	199
3. 识别与估计	199
4. 讨论：中介变量因果框架的比较	201
5. 多值处理的推广	201
6. 本章小结	202
7. 习题	202
8. 推荐阅读	202
Chapter 29. 时间变动的处理变量与混淆	203
1. 从单时间点到多时间点：一个自然的推广	203
2. 基本设置与序列可忽略性	203
3. g 公式与结果建模	205
4. 逆概率加权	207
5. 多时间点情形	208
6. 习题	210

7. 推荐阅读	211
1. 双重差分：利用面板数据的结构识别因果效应	213
Appendix A. 公式推导	217
1. Lemma 4.1 的证明：方差与协方差的关系	217
2. 差值均值统计量的方差分解	218
3. Wilcoxon 秩和统计量的方差推导	220
4. 女士品茶实验的超几何分布	221
5. 差值均值统计量的期望与方差推导	222
6. CRE 中分层平衡性的推导	224
7. 分层估计量的期望与方差推导	225
8. 分层 Neymanian 方差的推导	226
9. CRE 与 SRE 方差差异的推导	227
10. CRE 条件分布的推导	228
11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明	230
12. DiD 估计量的推导 (附录)	233
13. 第 23 章 TSLS 估计量的代数推导	234
14. TSLS 与 ILS 等价性的证明	236
15. 9.1 超级总体框架下的 Neyman 方差公式	236
16. 9.2 OLS 分解与 pooled regression 的等价性	237
17. 9.3 EHW 方差估计量的问题	238
18. 9.4 SRE 扩展的详细推导	238
19. 9.5 R 代码实现	239
20. Theorem 19.1 的证明：最坏情况 p 值的分布	240
21. 最坏情况 p 值的显式计算公式	241
22. 第十七章 E-Value 附录	241
Appendix B. 附录：定理 17.1 的证明	243
1. 背景与目标	243
2. 记号定义	243
3. 详细推导	243
4. 单调性与上界	244
5. 恒等式	244
Appendix C. 附录：引理 17.3 的证明	245
Appendix D. 附录：罕见结果近似	247
1. 第十八章平均因果效应灵敏度分析附录	247
Appendix E. 附录：定理 18.2 的证明	249
1. 背景与目标	249
2. 记号定义	249
3. 详细推导	249
Appendix F. 附录：定理 18.3 的证明	251
1. 背景与目标	251
2. 识别公式推导	251
Appendix G. 附录：Manski 型边界的推导	253

1. 背景	253
2. 记号定义	253
3. $E\{Y(1)\}$ 的边界	253
4. $E\{Y(0)\}$ 的边界	253
5. τ 的边界	253
6. 附录：公式推导	254
7. 附录：推导	256
8. 附录：定理证明	257
9. 附录：渐近分布推导	257
10. 附录：方差公式推导	258
11. 附录：协变量调整推导	259
12. 附录：儿童电视 Workshop 实验详细计算	259
13. 附录：关键公式推导	260
14. 第十章 logistic 模型的平均因果效应推导	261
15. 定理 19.2 (最坏情况 p 值) 的证明	261
16. CACE 分解的推导	262
17. Wald 估计量方差的推导	262
18. 第十一章 HT 估计量缺乏位置不变性	263
19. 定理 14.2 的证明：WLS 双重稳健估计量	264
20. 定理 14.3 的证明：处理组的双重稳健性	265
21. WLS/Hajek 等价性的详细推导	265
22. 附录：定理 29.1 的证明	266
Appendix A. 问答与注解	267
1. 阅读过程中的问题与解答	267
2. 学习笔记	272
Appendix. Bibliography	273

引言：文献概述

本学习资料旨在系统研究因果推断（Causal Inference）的基础理论与方法。因果推断是现代统计学和计量经济学最重要的研究领域之一，它关注如何从观测数据或实验数据中推断出因果关系，而不仅仅是相关关系。

1. 总述

在科学研究中，“相关并不意味着因果”是一个基本常识。然而，在实际研究中，我们常常需要回答因果性问题：某种治疗是否有效？某个政策是否达到了预期效果？某个变量之间的关联是否具有因果性质？

Rubin (1974) 提出的潜在结果框架（Potential Outcomes Framework）为因果推断奠定了理论基础。在该框架下，每个单元在不同处理条件下都有对应的潜在结果，而我们只能观测到其中一个。这种“因果推断基本问题”推动了各种推断方法的发展。

本课程以 Peng Ding 的《A First Course in Causal Inference》为主教材，系统学习：

- 完全随机化实验中的因果推断方法
- Fisher 随机化检验与 Neyman 重复抽样推断
- 分层分析与后分层技术
- 观测性研究中的因果推断
- 倾向得分、工具变量、回归断点设计等高级主题

2. 文献摘要总结

2.1. A First Course in Causal Inference.

- (1) **作者:** Peng Ding (丁鹏)
- (2) **链接:** <https://arxiv.org/abs/2305.18793>
- (3) **年份:** 2023
- (4) **篇幅:** 490 页
- (5) **核心贡献:**
 - 系统整合了 Fisher 精确推断与 Neyman 渐近推断两大框架
 - 提出了条件随机化实验 (CRE) 的统一处理方法
 - 详细讨论了分层、后分层与协变量平衡技术
 - 涵盖了观测性研究中的因果推断主流方法
- (6) **摘要:** This book provides an introduction to causal inference for students and researchers interested in estimating treatment effects from randomized experiments and observational studies. It unifies the potential outcomes framework with a focus on randomization-based inference, covering topics from basic concepts like the Yule-Simpson paradox to advanced methods including propensity score matching, instrumental variables, and sensitivity analysis. The book emphasizes both finite-sample exact inference (Fisher's approach) and asymptotic inference (Neyman's approach), providing readers with a comprehensive toolkit for causal analysis.

- (7) **关键词:** Causal Inference; Potential Outcomes; Randomization Test; Neyman Inference; Observational Studies; Propensity Score

3. 补充参考资料

- **Imbens and Rubin (2015):** *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press. —因果推断的权威教材。
- **Rubin (1974):** “Estimating Causal Effects of Treatments in Randomized and Non-Randomized Studies.” *Journal of Educational Psychology*. —潜在结果框架的奠基性论文。
- **Rosenbaum and Rubin (1983):** “The Central Role of the Propensity Score in Observational Studies for Causal Effects.” *Biometrika*. —倾向得分理论的开创性工作。
- **Angrist and Pischke (2009):** *Mastering ‘Metrics’*. Princeton University Press. —计量经济学因果推断的入门读物。

4. 学习路径与前置基础知识

数学基础:

- 概率论：条件概率、条件期望、方差与协方差
- 统计学：点估计、置信区间、假设检验
- 线性代数：矩阵运算、特征值

概率不等式:

- Markov 不等式、Chebyshev 不等式
- Hoeffding 不等式、Chernoff 界
- CLT (中心极限定理)

推荐学习顺序:

- (1) 第 1-2 章：基础概念（相关与因果、潜在结果）
- (2) 第 3-4 章：完全随机化实验（Fisher 检验与 Neyman 推断）
- (3) 第 5 章：分层与后分层
- (4) 第 6-8 章：随机化实验的高级话题
- (5) 第 9 章：有限总体与超总体的统一框架
- (6) 第 10-18 章：观测性研究方法

5. 最终目标

完成本课程学习后，期望达到以下目标：

- **理论理解：**深入理解潜在结果框架，掌握 Fisher 精确推断与 Neyman 渐近推断的理论基础与联系。
- **方法掌握：**熟练运用各种因果推断方法，包括分层、协变量调整、倾向得分匹配、工具变量等。
- **应用能力：**能够针对实际研究问题设计合适的因果推断策略，正确解读分析结果。
- **批判思维：**能够识别因果推断中的常见陷阱（如辛普森悖论、选择偏差、混杂因素），并进行敏感性分析。

CHAPTER 1

相关性、关联与 Yule-Simpson 悖论

1. 本章导论

本章我们要回答一个看似简单却至关重要的问题：**相关性能否直接告诉我们因果关系？**

在日常生活中，我们经常听到这样的话：

- ”吸烟会导致肺癌”
- ”教育水平越高，收入越高”
- ”经常锻炼的人更长寿”

这些陈述都试图建立因果关系。但我们是如何得出这些结论的？仅仅因为我们观察到了相关性（correlation）就足够了么？

2. 为什么这个问题很重要

想象一下以下场景：

例 1.1. 一家公司想要知道某种新药是否有效。他们给一组患者服用新药，另一组服用安慰剂。结果显示服药组的康复率更高。这能否说明药物有效？

直觉告诉我们，这似乎能说明问题。但仔细想想，还有很多其他因素可能影响结果：

- 也许服药组的患者本身就更健康
- 也许医生在给药时，无意中对服药组患者更加关照
- 也许这只是随机波动

这就是因果推断（causal inference）的核心挑战：**我们观察到的关联（association），并不等于因果关系（causal relationship）。**

3. 相关性与因果性的区别

统计学中，我们用不同的术语来区分这些概念：

- **相关性（Correlation）**：两个变量共同变化的趋势
- **关联（Association）**：统计学意义上的依赖关系
- **因果性（Causation）**：一个变量的变化直接导致另一个变量变化

关键洞察：相关性可以是因果的，也可以是非因果的。

4. 二维列联表与关联度量

将 Z 视为治疗或暴露， Y 视为结果，可以定义以下关联度量：

	$Y = 1$	$Y = 0$
$Z = 1$	p_{11}	p_{10}
$Z = 0$	p_{01}	p_{00}

风险差 (Risk Difference):

$$RD = \mathbb{P}(Y = 1 \mid Z = 1) - \mathbb{P}(Y = 1 \mid Z = 0) = \frac{p_{11}}{p_{11} + p_{10}} - \frac{p_{01}}{p_{01} + p_{00}}$$

风险比 (Risk Ratio):

$$RR = \frac{\mathbb{P}(Y = 1 \mid Z = 1)}{\mathbb{P}(Y = 1 \mid Z = 0)} = \frac{p_{11}}{p_{11} + p_{10}} \bigg/ \frac{p_{01}}{p_{01} + p_{00}}$$

优势比 (Odds Ratio):

$$OR = \frac{\mathbb{P}(Y = 1 \mid Z = 1)/\mathbb{P}(Y = 0 \mid Z = 1)}{\mathbb{P}(Y = 1 \mid Z = 0)/\mathbb{P}(Y = 0 \mid Z = 0)} = \frac{p_{11}p_{00}}{p_{10}p_{01}}$$

关于记号: 本书使用符号 $\perp\!\!\!\perp$ 表示随机变量的独立性或条件独立性。

命题 1.1 (二维列联表中的独立性). (1) 以下命题等价: $Z \perp\!\!\!\perp Y$ 、 $RD = 0$ 、 $RR = 1$ 、 $OR = 1$ 。

(2) 若所有 $p_{zy} > 0$, 则 $RD > 0$ 等价于 $RR > 1$, 也等价于 $OR > 1$ 。

(3) 若 $\mathbb{P}(Y = 1 \mid Z = 1)$ 和 $\mathbb{P}(Y = 1 \mid Z = 0)$ 都很小, 则 $OR \approx RR$ 。

5. Yule-Simpson 悖论

悖论的核心思想: 在总体中观察到的关联方向, 可能与分层后各组中的关联方向相反。

例 1.2 (经典的 Yule-Simpson 悖论例子). 考虑一个大学录取数据:

院系	男生录取率	女生录取率
A	62% (341/550)	82% (137/167)
B	63% (28/44)	68% (24/35)
总体	45% (369/816)	30% (161/525)

有趣的现象:

- 在 A 院系, 男女生录取率分别是 62% 和 82%
- 在 B 院系, 男女生录取率分别是 63% 和 68%
- 但总体来看, 男生的录取率反而更高!

这就是 *Yule-Simpson 悖论*: 在每个分层中都有利的因素, 在总体中可能不利。

这个例子揭示了一个深刻的问题: 如果我们不控制混杂因素 (*confounding factors*), 就可能得出完全错误的因果结论。

6. 偏相关系数与 Yule-Simpson 悖论

考虑三维正态随机向量:

$$\begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho_{XY} & \rho_{XZ} \\ \rho_{XY} & 1 & \rho_{YZ} \\ \rho_{XZ} & \rho_{YZ} & 1 \end{pmatrix} \right)$$

Y 和 Z 的偏相关系数 $\rho_{YZ|X}$ 定义为在条件分布 $(Y, Z) \mid X$ 中的相关系数。

命题 1.2 (偏相关系数公式).

$$\rho_{YZ|X} = \frac{\rho_{YZ} - \rho_{YX}\rho_{ZX}}{\sqrt{1 - \rho_{YX}^2}\sqrt{1 - \rho_{ZX}^2}}$$

重要含义：即使 $\rho_{YZ} > 0$ ，偏相关系数 $\rho_{YZ|X}$ 仍可能为负！这正是正态随机向量情形下的 Yule-Simpson 悖论。

7. LaLonde 数据与规格搜索问题

LaLonde 数据集包含参与职业培训项目 (National Supported Work Demonstration) 的参与者的结果。在观察性研究中，协变量选择的敏感性是一个重要问题。

当我们运行 $2^{10} = 1024$ 种可能的协变量子集回归时，treatment 系数的显著性可能对模型规格高度敏感。这提醒我们：在观察性研究中，规格搜索可能导致误导性结论。

8. 种族歧视的简历实验

Bertrand and Mullainathan (2004) 通过随机改变简历上的名字来研究种族歧视。这些名字被设计成听起来像非裔美国人或白人的名字。实验显示，有黑人名字的简历回调率显著较低。

当我们分别对男性和女性进行分析时，可能会发现有趣的亚组差异——这进一步说明“平均效应”可能掩盖了重要的异质性。

9. 本章小结与下节预告

本章的核心要点：

- (1) **相关性 $\neq$ 因果性：**观察到的关联可能是由于混杂因素造成的
- (2) **关联度量：**RD、RR、OR 及它们与独立性的关系
- (3) **Yule-Simpson 悖论：**总体关联可能与分层关联方向相反
- (4) **偏相关：**即使边际相关为正，偏相关仍可能为负
- (5) **因果推断的必要性：**我们需要系统性的方法来区分真实的因果效应

下一章我们将学习因果推断的基石——**潜在结果框架 (Potential Outcomes Framework)**，这将为我们的因果分析提供坚实的数学基础。

10. 习题

练习 1.1. 1.1 独立性命题的证明 证明 Proposition 1.1 中的命题 (1) 和 (2)。

练习 1.2. 1.2 Yule-Simpson 悖论的更多例子

- (1) 给出一个 $2 \times 2 \times 2$ 列联表的数值例子，其中出现 Yule-Simpson 悖论。
- (2) 找一个现实生活中的 Yule-Simpson 悖论例子。

练习 1.3. 1.3 相关与偏相关 考虑三维正态随机向量 $(X, Y, Z)^T \sim N(\mathbf{0}, \Sigma)$ 。

证明偏相关系数公式 (见 Proposition 1.2)。

给出一个 $\rho_{YZ} > 0$ 但 $\rho_{YZ|X} < 0$ 的数值例子。

注：这是正态随机向量情形下的 Yule-Simpson 悖论。

练习 1.4. 1.4 规格搜索 重做 Hainmueller (2012) 的数据分析。使用结局 `re78` 和治疗 `treat`。数据集还包含 10 个协变量，共有 $2^{10} = 1024$ 种可能的协变量子集组合。运行所有可能的线性回归子集，并报告 treatment 系数的分布：有多少是正显著、负显著、不显著的？

练习 1.5. 1.5 种族歧视的进一步分析 重做 Bertrand and Mullainathan (2004) 的简历数据分析。分别对男性和女性进行分析，讨论亚组分析的结果与总体结论的差异。

练习 1.6. 1.6 推荐阅读 **推荐阅读**: *Bickel et al. [1975]* 是关于 *Berkeley* 录取数据悖论的原始论文。*Pearl and Mackenzie [2018]* 从因果推断角度重新审视了该研究。

历史注记: *Holland [1986]* 是统计因果推断领域的经典综述文章，它推广了 “*Rubin* 因果模型” 这一名称。在 *UC Berkeley*，我们称之为 “*Neyman* 模型”——原因显而易见。

CHAPTER 2

潜在结果框架

1. 从相关到因果：为什么关联不够？

在第一章中，我们见证了一个令人不安的现象：Yule-Simpson 悖论向我们展示了关联可以与因果相悖。两组数据分别显示的正向效应，在合并后可能变为负向——这警告我们，从关联推断因果是危险的。

但我们不禁要问：关联毕竟是我们能观察到的，而因果是我们真正想知道的。那么，因果效应能否被清晰地定义，甚至被估计？

这个问题引导我们走向一个优雅而强大的框架——潜在结果框架 (Potential Outcomes Framework)，也被称为 Neyman-Rubin 因果模型。

这个框架的起源可以追溯到 Neyman 在 1923 年的开创性工作，以及 Rubin 在 1970 年代对其的进一步发展。它的核心思想其实出奇地简单：要谈论因果，我们必须想象 (counterfactual) 如果事情有所不同会发生什么。

2. 一个思想实验

让我们从一个最简单的场景开始：假设我们想研究某种新药对患者康复的因果效应。考虑第 i 个患者。我们记：

- $T_i = 1$ ：患者接受了治疗
- $T_i = 0$ ：患者未接受治疗（对照组）

现在，关键的问题来了：这个患者的结果会是什么？

在现实中，我们只能观察到一种情况——要么患者接受了治疗，要么没有。但为了谈论因果，我们必须同时考虑两种可能性：

- $Y_i(1)$ ：如果患者接受治疗，会观察到的结果
- $Y_i(0)$ ：如果患者未接受治疗，会观察到的结果

这里， $Y_i(1)$ 和 $Y_i(0)$ 就是**潜在结果**——它们描述了在不同治疗状态下可能发生的结果，但我们永远无法同时观察到两者。

注 2.1 (注 2.1 —什么是反事实). **反事实** (counterfactual) 指的是未被观测到的潜在结果。具体而言：

- 对于治疗组个体 i ($T_i = 1$)，我们观察到 $Y_i(1)$ ，而 $Y_i(0)$ 是反事实
- 对于对照组个体 i ($T_i = 0$)，我们观察到 $Y_i(0)$ ，而 $Y_i(1)$ 是反事实

正因为潜在结果框架讨论的是“如果接受相反治疗会怎样”，所以它也被称为**反事实框架** (counterfactual framework)。

注 2.2. **为什么叫“潜在”结果？**：因为它们描述的是“如果... 会怎样”的情形，这种结果是“潜在的”而非“现实的”。这正是 counterfactual (反事实) 思维的本质。

3. 科学表 (Science Table)

Rubin [2005] 将潜在结果组成的 $n \times 2$ 矩阵称为**科学表** (Science Table)：

i	$Y_i(1)$	$Y_i(0)$
1	$Y_1(1)$	$Y_1(0)$
2	$Y_2(1)$	$Y_2(0)$
$\vdots$	$\vdots$	$\vdots$
n	$Y_n(1)$	$Y_n(0)$

这个表包含了所有我们需要知道的关于因果效应的信息——但问题是，我们永远只能观察到每一行的其中一个值。

4. 个体因果效应

有了潜在结果，我们终于可以清晰地定义因果效应了。

对于个体 i ，定义**个体因果效应** (Individual Treatment Effect, ITE) 为：

$$\tau_i = Y_i(1) - Y_i(0)$$

这是治疗相对于对照的“净效果”。

但是，这里出现了一个根本性的困难。1923 年，Jerzy Neyman 在一篇关于田间试验的论文中首次明确指出了这个问题：

对于每个个体，我们只能观察到一种潜在结果——实际发生的那种。另一种潜在结果是潜在的、永不可见的。

这被称为**因果推断的根本问题** (Fundamental Problem of Causal Inference)。

注 2.3. **为什么这个困难如此根本？**：因为科学上感兴趣的大多数因果问题，都涉及将现实与反事实进行比较。我们可以问“这种药对这个患者有效吗？”——但这个问题要求我们同时知道患者吃药和不吃药的结果，而这是不可能的。

5. 平均因果效应

既然个体因果效应不可测量，我们退而求其次，关注**平均因果效应** (Average Causal Effect, ACE)：

$$(2.1) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0)$$

用更精确的有限总体记号：¹

$$(2.2) \quad \tau = \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} = \frac{1}{n} \sum_{i=1}^n Y_i(1) - \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

一个关键恒等式：平均因果效应等于个体因果效应的均值：

$$(2.3) \quad \tau = \bar{Y}(1) - \bar{Y}(0) = \frac{1}{n} \sum_{i=1}^n \tau_i$$

¹推导见附录 section 6.1

6. 亚组与亚组因果效应

亚组 (subgroup) 是由某个协变量（通常是二元变量 X_i ）分割出来的子群体。例如：

- 按性别分割：男性亚组 ($X_i = 1$) 和女性亚组 ($X_i = 0$)
- 按年龄分割：老年人/年轻人
- 按收入分割：高收入/低收入

亚组因果效应 (Subgroup Causal Effect) 衡量的是在该亚组内的平均因果效应：²

$$(2.4) \quad \tau_x = \frac{\sum_{i=1}^n \mathbb{I}(X_i = x) \{Y_i(1) - Y_i(0)\}}{\sum_{i=1}^n \mathbb{I}(X_i = x)}, \quad (x = 0, 1)$$

7. 亚组因果效应与 Yule-Simpson 悖论的不存在

一个重要的恒等式揭示了亚组因果效应与总体因果效应的关系：³

$$(2.5) \quad \tau = \pi_1 \tau_1 + \pi_0 \tau_0$$

其中 $\pi_x = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = x)$ 是 $X_i = x$ 的单元比例。

关键推论：如果 $\tau_1 > 0$ 且 $\tau_0 > 0$ ，则必有 $\tau > 0$ 。因此，Yule-Simpson 悖论在因果效应层面不可能发生！

这澄清了第一章的困惑：在关联层面出现的悖论，在因果层面并不存在——因为因果效应是可分解的，而关联并非如此。

8. 治疗分配机制与基本恒等式

设 T_i 是单元 i 的二元治疗指示变量，观测结果 Y_i 是潜在结果和治疗分配的函数：

$$\begin{aligned} (1) \quad Y_i &= \begin{cases} Y_i(1), & \text{if } T_i = 1 \\ Y_i(0), & \text{if } T_i = 0 \end{cases} \\ (2) \quad &= T_i Y_i(1) + (1 - T_i) Y_i(0) \\ (3) \quad &= Y_i(0) + T_i \{Y_i(1) - Y_i(0)\} \\ (4) \quad &= Y_i(0) + T_i \tau_i \end{aligned}$$

Pearl [2010] 将 eq. (2) 视为潜在结果与观测结果之间的**基本桥梁**。这些方程强调了个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 可能在不同单元间存在异质性。

9. SUTVA：使框架有效的必要假设

使用潜在结果框架需要一些技术性假设。其中最重要的是**稳定单位治疗值假设 (Stable Unit Treatment Value Assumption, SUTVA)**。

假设 2.1 (无干扰). 单元 i 的潜在结果不依赖于其他单元的治疗分配。这有时被称为**无干扰假设**。

假设 2.2 (一致性). 治疗水平没有其他版本。等价地，我们要求治疗水平是良好定义的，至少对关注的结局是如此。这有时被称为**一致性假设**。

假设 2.3 (SUTVA). 假设 2.1 和 2.2 同时成立。

²推导见附录 section 6.2

³推导见附录 section 6.3

为什么 SUTVA 如此重要？如果单元之间存在干扰，或者治疗定义不明确，那么潜在结果 $Y_i(1)$ 和 $Y_i(0)$ 就不是 well-defined 的——它们的值将取决于其他人的行为或治疗的具体形式，整个框架就会崩塌。

违反 SUTVA 的例子：

无干扰假设 (no-interference assumption) 违反的情形：

- (1) **传染病与疫苗接种 (infectious diseases and vaccination)**：当疾病具有传染性时，一个人是否接种疫苗不仅影响他自己的患病风险，还影响他周围人被感染的概率。例如，如果我的同事接种了流感疫苗，我患流感的概率也会降低——即使我自己没有接种。在这种情况下，单元 i 的潜在结果 $Y_i(1)$ 和 $Y_i(0)$ 都依赖于其他人的治疗分配。
- (2) **网络效应实验 (network experiments)**：在社交网络实验中，如果一个人收到 Facebook 广告 (treatment)，他的朋友看到这条广告并受到影响后，可能也会购买该产品——即使朋友本人没有直接收到广告。这就是所谓的**溢出效应 (spillover effect)**。
- (3) **随机区组实验中的相邻地块 (neighboring plots in randomized block experiments)**：农业实验中，相邻地块的作物可能相互影响——如果相邻地块使用了肥料，可能会通过土壤渗透影响本地块的产量。

一致性假设 (consistency assumption) 违反的情形：

- (1) **复合治疗 (composite treatments)**：当治疗本身有复杂组成部分时，相同的“治疗”标签可能对应不同的实际干预。例如：
 - 研究吸烟 (smoking) 对肺癌的影响时，“吸烟”这个治疗有多种形式——香烟类型、吸烟频率、吸入深度等，这些都可能产生不同的潜在结果。
 - 研究大学教育 (college education) 对收入的影响时，“上大学”这个治疗包括大学类型 (985/211 vs 普通院校)、专业、文凭等级等，这些差异会造成潜在结果的不一致。
- (2) **剂量效应 (dosage effects)**：在医学研究中，相同的药物名称可能对应不同剂量，而剂量直接影响疗效。例如“服用阿司匹林”作为治疗，但不同剂量的阿司匹林会产生完全不同的潜在结果。
- (3) **实施变异 (implementation variation)**：即使治疗名义上相同，不同实施者可能引入差异。例如，心理治疗研究中，不同治疗师的风格和技能可能导致相同的“心理治疗”产生不同效果。

当 SUTVA 不成立时，潜在结果框架需要修正。**现代因果推断文献**（如？）正在积极研究如何处理存在干扰或治疗版本多样的情形。

注 2.4. **SUTVA 的历史重要性**：Rubin (1980) 将 SUTVA 确立为潜在结果框架的基础假设，没有 SUTVA，因果推断的数学化是不可能的。

10. 反事实思维的逻辑

也许你会好奇：为什么不能简单地问“实际发生的结果是什么”？

答案是：**因果效应本质上是一个反事实 (counterfactual) 概念**。当我们问“这种药是否有效”时，我们实际上是在问：

“如果这个患者吃了药，结果会怎样？但现实是，他可能没有吃药...”

这种思维方式可能让人觉得抽象甚至哲学化，但它是我们谈论因果的唯一严谨方式。潜在结果框架的价值在于，它将这种哲学洞察转化为清晰的数学语言。

11. 实验单元定义的微妙性

我讨论一个与实验单元定义相关的微妙之处。简单来说，**实验单元可能不同于物理单元**。

例如，如果我在服药前没有服用阿司匹林且头痛没有消失，但我现在服用阿司匹林后头痛消失了，你可能认为我们可以同时观察到我的两种潜在结果。但这是对实验单元定义的误解！在不同时刻，我是同一个物理人，但成为了两个不同的实验单元。

因此，我们有四个潜在结果，其中两个被观察到，两个缺失。这说明，即使观察到的数据显示治疗“有效”，我们也无法确定地说阿司匹林就是原因——因为在“治疗后”的状态下，可能存在其他因素（如时间效应）导致头痛消失。

12. 非线性因果参数

平均因果效应是一个**线性**因果参数，因为潜在结果的平均差等于个体差别的平均。其他参数可能不是线性的。

例如，中位数治疗效应：

$$(2.6) \quad \delta_1 = \text{median}\{Y_i(1)\}_{i=1}^n - \text{median}\{Y_i(0)\}_{i=1}^n$$

通常不同于个体治疗效应的中位数：

$$(2.7) \quad \delta_2 = \text{median}\{Y_i(1) - Y_i(0)\}_{i=1}^n$$

这两个量在某些情况下可能相差很大。⁴

13. 本章小结

本章建立因果推断的数学语言：

- (1) **潜在结果**：为每个个体定义 $Y_i(1)$ 和 $Y_i(0)$
- (2) **科学表**： $n \times 2$ 矩阵 $\{Y_i(1), Y_i(0)\}_{i=1}^n$
- (3) **个体因果效应**： $\tau_i = Y_i(1) - Y_i(0)$
- (4) **平均因果效应**： $\tau = \bar{Y}(1) - \bar{Y}(0) = n^{-1} \sum_{i=1}^n \tau_i$
- (5) **根本问题**：我们只能观察到一种潜在结果
- (6) **基本桥梁方程**： $Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$
- (7) **SUTVA**：一致性 + 无干扰
- (8) **Yule-Simpson 悖论**在因果框架下不可能发生

下一章我们将看到，**随机实验**提供了一种绕过根本问题的优雅方式——通过随机分配治疗，我们可以建立组间可比性，从而识别因果效应。

14. 习题

练习 2.1. 2.1 完美的医生 假设潜在结果由以下模型生成：

$$Y_i(0) \sim N(0, 1), \quad \tau_i = -0.5 + Y_i(0), \quad Y_i(1) = Y_i(0) + \tau_i$$

治疗分配为 $T_i = \mathbb{I}(\tau_i \geq 0)$ ，观测结果为 $Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$ 。

计算条件均值差 $\mathbb{E}(Y_i | T_i = 1) - \mathbb{E}(Y_i | T_i = 0)$ 。

提示：需要使用截断正态分布的均值公式。当 $X \sim N(\mu, \sigma^2)$ 时，

$$\mathbb{E}(X | a < X < b) = \mu - \sigma \frac{\phi\left(\frac{b-\mu}{\sigma}\right) - \phi\left(\frac{a-\mu}{\sigma}\right)}{\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)}$$

⁴数值例子见附录 section 6.4

其中 ϕ 和 Φ 分别是标准正态分布的密度函数和分布函数。

练习 2.2. 2.2 非线性因果参数 证明平均因果效应是线性因果参数的例子，即 $\bar{Y}(1) - \bar{Y}(0) = n^{-1} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\}$ 。

其他参数可能不是线性的。例如，定义中位数治疗效应为：

$$\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\}$$

这通常不同于个体治疗效应的中位数：

$$\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\}$$

(1) 给出数值例子分别满足 $\delta_1 = \delta_2$ 、 $\delta_1 > \delta_2$ 和 $\delta_1 < \delta_2$ 。

(2) 哪个参数更有意义？为什么？请用例子来证明你的结论。

练习 2.3. 2.3 平均效应与个体效应 给出一个数值例子，其中 $\tau = n^{-1} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} > 0$ ，但有不到一半的单元满足 $Y_i(1) > Y_i(0)$ 。即平均因果效应为正，但治疗对不到一半的单元有益。

练习 2.4. 2.4 推荐阅读 **推荐阅读：** *Holland [1986]* 是统计因果推断领域的经典综述文章，它推广了“Rubin 因果模型”这一名称。在 *UC Berkeley*，我们称之为“Neyman 模型”——原因显而易见。

完全随机实验与费舍尔随机化检验

1. 从潜在结果框架到随机实验：问题的起源

在第 ?? 章中，我们建立了**潜在结果框架 (Potential Outcomes Framework)**，学会了如何清晰地定义因果效应。平均因果效应定义为：

$$(5) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0)$$

但我们也清楚地看到了因果推断的**根本问题 (Fundamental Problem of Causal Inference)**：对于每个个体，我们只能观察到一种潜在结果， $Y_i(1)$ 和 $Y_i(0)$ 无法同时被观测。¹ 这意味着，即使我们定义了因果效应，我们也不知道如何用数据来估计它——因为每个单元的“反事实结果”永远无法被观测到。

那么，一个自然的问题是：我们能否设计某种**数据收集过程**，使得即使无法观察反事实，我们仍然可以估计因果效应？

第 ?? 章曾指出，相关性不等于因果性——即使 X 和 Y 相关，我们也无法断定 X 导致 Y 。第 ?? 章通过潜在结果框架给因果效应一个精确的定义，但它留下的核心问题是：我们如何用实际观测到的数据来**识别 (identify)** 和**估计 (estimate)** 这些潜在结果？

这个问题的答案是肯定的，而解决方案就是**随机实验 (Randomized Experiment)**——统计学的黄金标准。

2. Fisher 的洞见：随机化的两个原则

Ronald Fisher 在 1935 年的开创性著作《Design of Experiments》中指出了随机化的两个优势：

- (1) **可比性**：它创造了在平均意义上可比的 treatment 和 control 组。
- (2) **推理基础**：它作为统计推断的“合理基础”。

第一点直观易懂——随机治疗分配不会偏向 treatment 或 control。第二点更微妙：Fisher 的意思是，随机化为统计检验提供了正当理由，这就是现在所谓的**费舍尔随机化检验 (Fisher Randomization Test, FRT)**²³。

3. 完全随机实验的定义

考虑一个包含 n 个单元的实验，其中 n_1 个接受治疗， n_0 个接受对照 ($n = n_1 + n_0$)。

定义 3.1 (完全随机实验 (Complete Randomized Experiment, CRE))。固定 n_1 和 n_0 (其中 $n = n_1 + n_0$)。完全随机实验的治疗 *assignment* 机制为：

$$(6) \quad \mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}},$$

其中 $\mathbf{z} = (z_1, \dots, z_n)$ 满足 $\sum_{i=1}^n z_i = n_1$ 和 $\sum_{i=1}^n (1 - z_i) = n_0$ 。

¹问：什么是潜在结果？见附录 section 1.9。

²问：什么是 Fisher Randomization Test？见附录 section 1.11。

³问：Fisher 随机化检验与经典假设检验有何不同？见附录 section 1.6。