因果推断讲义

Peng Ding

March 14, 2026

Contents

Chapter 1

相关性、关联与 Yule-Simpson 悖论

1.1 本章导论

本章我们要回答一个看似简单却至关重要的问题：**相关性能否直接告诉我们因果关系？**

在日常生活中，我们经常听到这样的话：

- ”吸烟会导致肺癌”
- ”教育水平越高，收入越高”
- ”经常锻炼的人更长寿”

这些陈述都试图建立因果关系。但我们是如何得出这些结论的？仅仅因为我们观察到了相关性（correlation）就足够了么？

1.2 为什么这个问题很重要

想象一下以下场景：

例 1.1. 一家公司想要知道某种新药是否有效。他们给一组患者服用新药，另一组服用安慰剂。结果显示服药组的康复率更高。这能否说明药物有效？

直觉告诉我们，这似乎能说明问题。但仔细想想，还有很多其他因素可能影响结果：

- 也许服药组的患者本身就更健康
- 也许医生在给药时，无意中对服药组患者更加关照
- 也许这只是随机波动

这就是因果推断（causal inference）的核心挑战：**我们观察到的关联（association），并不等于因果关系（causal relationship）**。

1.3 相关性与因果性的区别

统计学中，我们用不同的术语来区分这些概念：

- **相关性（Correlation）**：两个变量共同变化的趋势
- **关联（Association）**：统计学意义上的依赖关系
- **因果性（Causation）**：一个变量的变化直接导致另一个变量变化

关键洞察：相关性可以是因果的，也可以是非因果的。

1.4 Yule-Simpson 悖论

悖论的核心思想：在总体中观察到的关联方向，可能与分层后各组中的关联方向相反。

例 1.2 (经典的 Yule-Simpson 悖论例子)**.** 考虑一个大学录取数据：

院系	男生录取率	女生录取率
A	*62% (341/550)*	*82% (137/167)*
B	*63% (28/44)*	*68% (24/35)*
总体	***45% (369/816)***	***30% (161/525)***

有趣的现象：

- 在 *A* 院系，男女生录取率分别是 *62%* 和 *82%*
- 在 *B* 院系，男女生录取率分别是 *63%* 和 *68%*
- 但总体来看，男生的录取率反而更高！

这就是 *Yule-Simpson* 悖论：**在每个分层中都有利的因素，在总体中可能不利**。

这个例子揭示了一个深刻的问题：如果我们不控制混杂因素（*confounding factors*），就可能得出完全错误的因果结论。

1.5 本章小结与下节预告

本章的核心要点：

1. **相关性 $\neq$ 因果性**：观察到的关联可能是由于混杂因素造成的
2. **Yule-Simpson 悖论**：总体关联可能与分层关联方向相反
3. **因果推断的必要性**：我们需要系统性的方法来区分真实的因果效应

下一章我们将学习因果推断的基石——**潜在结果框架（Potential Outcomes Framework）**，这将为我们的因果分析提供坚实的数学基础。

Chapter 2

潜在结果框架

2.1 为什么需要潜在结果？

上一章我们看到了相关性与因果性的区别，以及 Yule-Simpson 悖论警告我们不要轻易从关联推断因果。

现在我们要问：**有没有一种方法可以清晰地定义因果效应？**

答案是肯定的，这就是**潜在结果框架（Potential Outcomes Framework）**，也被称为 **Neyman-Rubin 因果模型**。

这个框架的核心思想其实很简单：我们需要比较同一个个体在接受治疗和不接受治疗时的不同结果。

2.2 基本定义

考虑一个最简单的场景：我们想研究某种治疗（treatment）對 outcome 的因果效应。

- 对于每个个体 i，我们有一个二元治疗变量 T_i:
  - $T_i = 1$: 接受治疗（treatment group）
  - $T_i = 0$: 未接受治疗（control group）
- Y_i: 观察到的结果（observed outcome）

关键概念是**潜在结果（Potential Outcomes）**：

- $Y_i(1)$: 如果个体 i 接受治疗，会观察到的结果
- $Y_i(0)$: 如果个体 i 未接受治疗，会观察到的结果

注意：对于每个个体，我们只能观察到一种情况下的结果，另一种是潜在的（potential）而非现实的。

2.3 个体因果效应

对于个体 i，**个体因果效应（Individual Treatment Effect, ITE）**定义为：

$$\tau_i = Y_i(1) - Y_i(0)$$

这衡量了治疗对这一个体的效果。

但是，这里有一个根本性的困难——**因果推断的根本问题（Fundamental Problem of Causal Inference）**：

我们无法同时观察到同一个体的 $Y_i(1)$ 和 $Y_i(0)$。

2.4 平均因果效应

由于我们无法观察到个体因果效应，我们退而求其次，关注**平均因果效应（Average Causal Effect, ACE）**：

$$\tau_{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)]$$

这是所有个体因果效应的期望值。

类似地，我们还可以定义：

- **治疗组的平均因果效应**（Average Treatment Effect on the Treated, ATT）
- **对照组的平均因果效应**（Average Treatment Effect on the Control, ATC）

2.5 为什么要定义”潜在”结果？

也许你会问：为什么不直接定义”实际发生的结果”？

原因是：**因果效应本质上是一个反事实（counterfactual）概念**。

当我们问”这种药是否有效”时，我们实际上是在问：”如果这个患者吃了药，结果会怎样？”但现实是，这个患者可能没有吃药，所以我们只能想象（counterfactual）另一种情况。

这种潜在结果的思维方式，帮助我们澄清了因果效应的本质。

2.6 稳定单位治疗值假设（SUTVA）

使用潜在结果框架需要一些假设，其中最重要的是 SUTVA（Stable Unit Treatment Value Assumption）：

定理 2.1 (SUTVA). *1.* **一致性（*Consistency*）**：对于每个个体，观察到的结果等于其对应治疗下的潜在结果：

$$Y_i = T_i \cdot Y_i(1) + (1 - T_i) \cdot Y_i(0)$$

2. **互不干扰（*No interference*）**：一个个体的潜在结果不受其他个体治疗分配的影响：

$$Y_i(t_1, \ldots, t_n) = Y_i(t_i) \quad \text{对所有} t_1, \ldots, t_n$$

简单来说，SUTVA 假设：

- 治疗效果是稳定的
- 你的结果不受他人治疗的影响

这些假设在很多实际场景中可能不成立（例如，疫苗的群体免疫效应就违反了互不干扰假设），我们需要根据具体情况判断是否适用。

2.7 本章小结

本章我们建立了因果推断的数学基础：

1. **潜在结果框架**：为每个个体定义 $Y_i(1)$ 和 $Y_i(0)$
2. **个体因果效应**：$\tau_i = Y_i(1) - Y_i(0)$
3. **平均因果效应**：$\tau_{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)]$
4. **根本问题**：我们无法同时观察到两种潜在结果
5. **SUTVA 假设**：保证潜在结果框架的有效性

下一章我们将学习**随机实验（Randomized Experiments）**——在某些情况下，我们可以绕过因果推断的根本问题，直接识别因果效应。

Chapter 3

完全随机实验与 FRT

3.1 为什么需要随机实验？

在上一章中，我们学习了潜在结果框架，知道了因果效应的定义：

$$\tau_{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)]$$

但我们也认识到了因果推断的根本问题：对于每个个体，我们只能观察到一种潜在结果，无法同时观察到 $Y_i(1)$ 和 $Y_i(0)$。

那么，如何解决这个问题？如何才能识别（identify）因果效应？

答案就是：随机实验。

3.2 随机实验的基本思想

随机实验的核心思想非常简单但极其强大：

通过随机分配治疗，使得治疗组和对照组在平均意义上是”可比”的。

当我们随机分配治疗时，治疗分配 T_i 与潜在结果 $Y_i(0), Y_i(1)$ 是独立的：

$$T_i \perp Y_i(0), Y_i(1)$$

这意味着，随机分配能够自动平衡两组之间的所有混杂因素（无论是我们已知的还是未知的）。

3.3 完全随机实验的定义

定义 3.1 (完全随机实验). 设有 n 个样本，其中 n_1 个被分配到治疗组，$n_0 = n - n_1$ 个被分配到对照组。完全随机实验（*Completely Randomized Experiment*）满足以下条件：

1. 每个个体被分配到治疗组的概率为 n_1/n；
2. 治疗组总人数固定为 n_1；

3. 个体之间相互独立。

在 ?? 下，我们可以证明：

$$\mathbb{E}[\bar{Y}(1) - \bar{Y}(0)] = \tau_{ATE}$$

也就是说，**观察到的组间差异就是平均因果效应的无偏估计**！这正是随机实验的魔力所在。

3.4 费舍尔随机化检验（FRT）

虽然随机实验可以估计因果效应，但我们还需要统计检验来判断观察到的效应是否是真实的，而不是随机波动造成的。

费舍尔 (Ronald Fisher) 提出了一个优雅的解决方案——费舍尔随机化检验（Fisher's Randomization Test, FRT）。

3.4.1 为什么需要 FRT？

传统统计方法依赖于" 正态分布假设"——假设数据来自正态分布。但在因果推断中，我们的" 总体" 是有限的（finite population），而且我们关心的是特定处理分配的随机性，而不是从某个分布中抽样。

FRT 的核心思想是：**在零假设下，所有可能的治疗分配都是等可能的**。因此，我们可以精确计算检验的 p 值，而不需要任何分布假设。

3.4.2 零假设

FRT 的零假设是：

$$H_0 : Y_i(0) = Y_i(1) \quad \text{对所有} i$$

也就是说，治疗没有任何效果（所有个体的潜在结果都相等）。

在这个零假设下，观察到的结果 Y_i 就等于 $Y_i(0) = Y_i(1)$，与治疗分配无关。

3.5 检验统计量的选择

在 FRT 框架下，我们可以选择不同的检验统计量。不同的统计量对不同的备择假设有不同的功效（power）。

3.5.1 差值均值（Difference-in-means）

最直观的统计量是差值均值：

$$\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$$

在零假设下，$\hat{\tau}$ 的期望为 0，方差为：

$$\mathrm{Var}(\hat{\tau}) = \frac{s^2}{n_1 n_0}$$

其中 s^2 是合并的样本方差。

利用有限总体中心极限定理（Finite Population CLT），我们可以得到：

$$\frac{\hat{\tau}}{\sqrt{s^2/(n_1 n_0)}} \xrightarrow{d} N(0,1)$$

有趣的是，这个统计量与经典的方差相等的 t 检验统计量非常接近！

3.5.2 学生化统计量（Studentized statistic）

差值均值假设两组方差相等。如果两组方差不相等（异方差），我们需要使用学生化统计量：

$$t = \frac{\bar{Y}(1) - \bar{Y}(0)}{\sqrt{\hat{S}^2(1)/n_1 + \hat{S}^2(0)/n_0}}$$

这个统计量与方差不等的 t 检验统计量（`t.test(var.equal = FALSE)`）渐近等价。

注 3.1. 为什么需要学生化统计量？： *当治疗组和对照组的方差差异较大时，差值均值的检验可能失效。学生化统计量通过分别估计两组的方差，能够更好地处理这种异方差情况。*

3.5.3 Wilcoxon 秩和统计量

差值均值和学生化统计量都使用原始观测值，因此对异常值（outliers）敏感。一个更稳健的选择是 Wilcoxon 秩和统计量：

$$W = \sum_{i=1}^{n} Z_i R_i$$

其中 R_i 是 Y_i 在合并样本中的秩。
Wilcoxon 秩和统计量的优点是：

- 对异常值稳健
- 只依赖于数据的秩次信息
- 在许多备择假设下都有较好的功效

3.5.4 Kolmogorov-Smirnov 统计量

上述统计量主要关注均值差异。但治疗效应可能以其他方式体现（例如改变分布的形状）。KS 统计量衡量两个分布之间的最大差距：

$$D = \max_y |\hat{F}_1(y) - \hat{F}_0(y)|$$

这个统计量能够检测分布形状的差异，而不仅仅是均值差异。

3.6 LaLonde 实验数据案例

LaLonde (1986) 的实验数据是因果推断领域的经典案例。

3.6.1 背景

LaLonde 研究了一项职业培训项目（National Supported Work Demonstration）对参与者收入的影响。实验将参与者随机分配到治疗组（接受培训）或对照组（不接受培训），观察他们在 1978 年的真实收入（re78）。

3.6.2 R 语言分析基础

本案例使用 R 语言的 `Matching` 包进行 FRT 分析。数据可以直接从 R 中加载：

```
> library(Matching)
> data(lalonde)
> z <- lalonde\$treat
> y <- lalonde\$re78
```

其中：

- `z`: 二元治疗向量（1 = 治疗组，0 = 对照组）
- `y`: 1978 年真实收入（outcome）

3.6.3 数据分析

使用 R 语言进行 FRT 分析的结果：

统计量	观测值	描述
$\hat{\tau}$	2.84	差值均值
t	2.67	学生化统计量
W	27402.5	Wilcoxon 秩和
D	0.132	KS 统计量

通过随机置换治疗向量 10,000 次，我们可以得到这些统计量的随机化分布，进而计算精确 p 值。

3.7 FRT 与传统 t 检验的关系

一个非常重要的洞察是：

FRT 为传统 t 检验提供了理论依据！

传统 t 检验基于”数据来自正态分布”的假设。但在 FRT 框架下，即使数据不服从正态分布，只要有限总体中心极限定理成立，t 检验程序仍然可以使用！

这是因为 FRT 的渐近性质只依赖于有限总体 CLT，而 CLT 对很多分布都是成立的。

注 3.2. *FRT* 的意义是什么？： *FRT 证明了传统统计方法在因果推断中的合理性。我们不需要担心正态性假设是否满足，只需要关注随机化分配是否正确执行。*

3.7.1 FRT 与 t 检验的对比

在实际应用中，我们需要理解两者在什么情况下相同、什么情况下不同。

相同的时候：

1. **大样本下渐近等价**：当样本量足够大时，差值均值 $\hat{\tau}$ 与方差相等的 t 检验渐近等价；学生化统计量 t 与方差不等的 t 检验渐近等价。
2. **零假设 $H_0 : Y_i(0) = Y_i(1)$ 时**：两者都检验”治疗没有任何效果”。

不同的时候：

1. **理论基础不同**：t 检验假设数据来自正态分布（无限总体），而 FRT 基于治疗分配的随机性（有限总体）。
2. **小样本时**：FRT 可以给出精确的有限样本 p 值，而 t 检验依赖正态性假设，在小样本时可能不准确。
3. **异方差情况下**：当两组方差不相等时，FRT 的功效可能低于方差不等的 t 检验。

实际选择建议：

- 大样本、正态/近似正态：两者皆可，结果相近；
- 小样本、非正态：FRT 更可靠；
- 已知两组方差不等：t 检验（`var.equal=FALSE`）可能更有效；
- 需要精确 p 值：优先使用 FRT。

3.8 3.6 讨论

3.8.1 其他 Sharp Null 假设与置信区间

除了之前讨论的 sharp null 假设 $H_0 : Y_i(0) = Y_i(1)$（所有个体的治疗效应为零），FRT 框架还可以应用于其他假设。

例如，我们可以检验弱 null 假设 $H_0 : \tau_{ATE} = 0$（平均因果效应为零，但个体效应可能不为零）。在这种情况下，我们需要更多假设来构建置信区间。

3.8.2 FRT 的优势与局限

优势：

- 不需要任何分布假设；
- 提供精确的有限样本 p 值；
- 理论基础稳固——完全基于随机化设计。

局限：

- 计算复杂度高（当样本量大时）；
- 只能检验 sharp null 假设；
- 对于连续型结果，精确检验可能功效较低。

3.9 本章小结

本章我们学习了因果推断的" 金标准"——随机实验：

1. **随机实验**：通过随机分配平衡混杂因素，使得观察到的组间差异可以直接解释为因果效应
2. **费舍尔随机化检验（FRT）**：基于治疗分配随机性的精确检验方法
3. **多种检验统计量**：差值均值、学生化统计量、Wilcoxon 秩和、KS 统计量
4. **LaLonde 案例**：经典的实际应用示例
5. **理论意义**：FRT 为传统 t 检验提供了更坚实的基础

下一章我们将学习如何在观察性研究（observational study）中估计因果效应——这需要更多的假设和方法。

Chapter 4

完全随机实验与 Neymanian 推断

4.1 为什么需要 Neymanian 推断？

在上一章中，我们学习了费舍尔随机化检验（FRT）。FRT 的核心思想是基于治疗分配的随机性，在零假设下我们可以精确计算 p 值。

但是，FRT 也有一些局限：

- 只能检验 sharp null 假设（所有个体因果效应为零）
- 对于构建置信区间，需要额外的假设
- 当样本量很大时，计算所有可能置换变得不可行

Neymanian 推断提供了一种互补的方法：它基于**渐近正态分布**，可以更方便地构建置信区间和进行假设检验。

4.2 Neymanian 框架的基本思想

Neymanian 推断的核心是利用有限总体中心极限定理（Finite Population CLT）。

与 FRT 不同，Neymanian 推断不需要检验特定的 null 假设，而是直接对因果效应进行统计推断。

注 4.1. 为什么需要两种方法？： *FRT 适用于小样本精确推断，Neymanian 适用于大样本渐近推断。两者互为补充。*

4.2.1 有限总体量（4.1 节定义）

有限总体量（不带 hat）是固定的真值：

- n：总样本量，n_1：处理组样本量，n_0：对照组样本量
- $\bar{Y}(1) = n^{-1}\sum_{i=1}^{n} Y_i(1)$：处理组的有限总体均值
- $\bar{Y}(0) = n^{-1}\sum_{i=1}^{n} Y_i(0)$：对照组的有限总体均值

- $S^2(1) = (n-1)^{-1}\sum_{i=1}^n (Y_i(1) - \bar{Y}(1))^2$：处理组的有限总体方差
- $S^2(0) = (n-1)^{-1}\sum_{i=1}^n (Y_i(0) - \bar{Y}(0))^2$：对照组的有限总体方差
- $S(1,0) = (n-1)^{-1}\sum_{i=1}^n (Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0))$：有限总体协方差
- $S^2(\tau) = (n-1)^{-1}\sum_{i=1}^n (\tau_i - \bar{\tau})^2$：个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 的方差
- $\tau = \bar{Y}(1) - \bar{Y}(0)$：平均处理效应（ACE）的真值

注 4.2. 为什么需要协方差？： *因为潜在结果 Y(1) 和 Y(0) 之间可能有相关性，这会影响估计量的方差。*

引理 4.1 (Lemma 4.1)**.** *有限总体协方差与方差之间的关系：*

$$2S(1,0) = S^2(1) + S^2(0) - S^2(\tau)$$

其中 $\tau_i = Y_i(1) - Y_i(0)$ 是个体因果效应。

4.3 点估计与方差估计

4.3.1 点估计

与 FRT 相同，Neymanian 推断使用差值均值作为平均因果效应的估计。样本均值定义为：

$$\hat{\bar{Y}}(1) = \frac{1}{n_1}\sum_{i=1}^n Z_i Y_i, \quad \hat{\bar{Y}}(0) = \frac{1}{n_0}\sum_{i=1}^n (1-Z_i) Y_i$$

则点估计为：

$$\hat{\tau} = \hat{\bar{Y}}(1) - \hat{\bar{Y}}(0)$$

这是一个**无偏估计**：$\mathbb{E}[\hat{\tau}] = \tau$。

4.3.2 方差估计

Neymanian 框架下的方差估计是：

$$\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$$

其中样本方差（用 $n_1 - 1$ 或 $n_0 - 1$ 作为除数）是有限总体方差的估计：

- $\hat{S}^2(1) = \frac{1}{n_1 - 1}\sum_{i=1}^n Z_i (Y_i - \hat{\bar{Y}}(1))^2$
- $\hat{S}^2(0) = \frac{1}{n_0 - 1}\sum_{i=1}^n (1 - Z_i)(Y_i - \hat{\bar{Y}}(0))^2$

定理 4.2 (Neyman's Theorem (Theorem 4.1))**.** 在完全随机实验下，估计量 $\hat{\tau} = \hat{\bar{Y}}(1) - \hat{\bar{Y}}(0)$ 的**方差**为：

$$Var(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$$

其中 $S^2(1), S^2(0), S^2(\tau)$ 是 *4.1* 节定义的有限总体方差。

由于我们不知道 $S^2(\tau)$，实际使用的是 *Neymanian* 方差估计（用样本方差代替总体方差）：

$$\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$$

其中样本均值（带 *hat*）和样本方差（带 *hat*）的定义来自 *4.2* 节：

- $\hat{\bar{Y}}(1) = n_1^{-1} \sum_{i=1}^n Z_i Y_i$：处理组的样本均值
- $\hat{\bar{Y}}(0) = n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i$：对照组的样本均值
- $\hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{i=1}^n Z_i \{Y_i - \hat{\bar{Y}}(1)\}^2$：处理组的样本方差
- $\hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{i=1}^n (1 - Z_i) \{Y_i - \hat{\bar{Y}}(0)\}^2$：对照组的样本方差

由于 $S^2(\tau) \geq 0$（方差非负），我们得到：

$$\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} \geq Var(\hat{\tau})$$

即 *Neymanian* 方差估计 $\hat{V}$ 是真实方差的上界，是**保守的**（*conservative*）。

注 4.3. 为什么叫保守估计？： 因为我们用 $\hat{V}$ 代替真实方差时，会高估方差。这会导致更宽的置信区间，虽然不够精确，但不会过度自信，不会错误地拒绝真的零假设。

4.3.3 ?? 的证明（4.3 节）

证明：

(1) 无偏性证明

由定义，

$$\hat{\tau} = \hat{\bar{Y}}(1) - \hat{\bar{Y}}(0) = \frac{1}{n_1} \sum_{i=1}^n Z_i Y_i - \frac{1}{n_0} \sum_{i=1}^n (1 - Z_i) Y_i$$

将 Y_i 替换为潜在结果 $Y_i(1)$ 和 $Y_i(0)$：

$$\hat{\tau} = \frac{1}{n_1} \sum_{i=1}^n Z_i Y_i(1) - \frac{1}{n_0} \sum_{i=1}^n (1 - Z_i) Y_i(0)$$

取期望（注意：潜在结果是固定值，只有 Z_i 是随机的）：

$$\begin{aligned}\mathbb{E}[\hat{\tau}] &= \frac{1}{n_1}\sum_{i=1}^{n}\mathbb{E}[Z_i]Y_i(1) - \frac{1}{n_0}\sum_{i=1}^{n}\mathbb{E}[1-Z_i]Y_i(0)\\ &= \frac{1}{n_1}\sum_{i=1}^{n}\frac{n_1}{n}Y_i(1) - \frac{1}{n_0}\sum_{i=1}^{n}\frac{n_0}{n}Y_i(0)\\ &= \frac{1}{n}\sum_{i=1}^{n}Y_i(1) - \frac{1}{n}\sum_{i=1}^{n}Y_i(0)\\ &= \bar{Y}(1) - \bar{Y}(0) = \tau\end{aligned}$$

其中用到 $\mathbb{E}[Z_i] = n_1/n$（见 **??** 完全随机实验的性质）。

（2）方差公式证明

将 $\hat{\tau}$ 重新整理为：

$$\hat{\tau} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{Y_i(1)}{n_1/n} - \frac{Y_i(0)}{n_0/n}\right)Z_i - \bar{Y}(0)$$

使用简单随机抽样的方差公式（见教材 Lemma C.2），得：

$$\mathrm{Var}(\hat{\tau}) = \frac{n_0^2}{n_1 n}S^2(1) + \frac{n_1^2}{n_0 n}S^2(0) + \frac{2}{n}S(1,0)$$

利用 **??**：$2S(1,0) = S^2(1) + S^2(0) - S^2(\tau)$，化简得：

$$\mathrm{Var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$$

（3）方差估计的无偏性

因为处理组是从 n 个单位中简单随机抽取的 n_1 个单位，样本方差是总体方差的无偏估计：

$$\mathbb{E}[\hat{S}^2(1)] = S^2(1), \quad \mathbb{E}[\hat{S}^2(0)] = S^2(0)$$

因此：

$$\mathbb{E}[\hat{V}] = \mathbb{E}\left[\frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}\right] = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0}$$

即 $\hat{V}$ 对公式 (4.1) 的前两项是无偏的，但无法估计第三项 $S^2(\tau)/n$，因此是保守估计。

注 4.4. 为什么 ?? 有用？： 它建立了协方差与三个方差之间的关系，使得方差公式可以写成两种等价形式，方便理解和应用。

4.4 置信区间

利用有限总体中心极限定理，我们可以构建置信区间：

$$\hat{\tau} \pm z_{\alpha/2}\sqrt{\hat{V}}$$

其中 $z_{\alpha/2}$ 是标准正态分布的分位数。

注 4.5. 保守意味着什么？： 保守的方差估计会导致更宽的置信区间。这意味着我们的推断更”安全”——不会过度自信。

4.5 Neymanian 推断与 OLS 的关系

在实际应用中，很多研究者使用 OLS（普通最小二乘法）来估计因果效应。

4.5.1 OLS 估计

对于二元处理变量，OLS 估计量与差值均值估计量是等价的：

$$\hat{\tau}_{OLS} = \bar{Y}(1) - \bar{Y}(0) = \hat{\tau}$$

4.5.2 标准误的比较

然而，OLS 的默认标准误与 Neymanian 标准误有所不同：

估计方法	点估计	标准误
Neymanian	1794.34	670.99
OLS (默认)	1794.34	632.85
OLS (HC2 稳健)	1794.34	670.99

可以看到，OLS 默认的标准误偏小，而使用 EHW（异方差稳健）标准误后与 Neymanian 估计一致！

这就是为什么在因果推断中使用稳健标准误非常重要。

4.6 模拟验证（4.5.1 节）

为了验证 Neymanian 推断的理论性质，我们进行模拟实验。

4.6.1 实验设置

设定样本量 $n = 100$，其中 $n_1 = 60$ 接受处理，$n_0 = 40$ 为对照组。

我们考虑三种潜在结果的相关结构：

1. **恒定因果效应**：$\tau_i = 1$ 对所有单位
2. **负相关**：处理组潜在结果与对照组负相关
3. **独立**：两组潜在结果独立生成

注意：在这三种情况下，边缘分布相同，但相关性不同。

4.6.2 模拟结果

	恒定效应	负相关	独立
真实方差	0.036	0.007	0.020
估计方差	0.036	0.036	0.036
95% CI 覆盖率	94.7%	100%	98.9%

关键发现：

- 真实方差依赖于潜在结果之间的相关性
- 正相关 ⇒ 更大的抽样方差
- 估计方差在三种情况下几乎相同（只依赖于边缘分布）
- 只有在恒定因果效应下，估计方差 = 真实方差

这验证了 **??** 的公式：$\mathrm{Var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$

注 4.6. 为什么相关性影响方差？： *当潜在结果正相关时，处理组恰好选中较大的潜在结果时，对照组也恰好选中较大的潜在结果（但我们没观察到），导致估计的因果效应偏大。这种"运气"差异增加了估计的不确定性。*

4.7 重尾分布与正态近似的失效（4.5.2 节）

Theorem 4.2 的渐近正态性依赖于一些正则条件。当潜在结果服从重尾分布（如 Cauchy 分布）时，这些条件可能被违反。

4.7.1 模拟实验

将潜在结果中按 10%, 30%, 50% 的概率混入 Cauchy 分布：

```
eps = rbinom(n, 1, 0.1)
y0 = rexp(n)
y0[eps == 1] = rcauchy(sum(eps))
y1 = y0 + 1
```

4.7.2 结果

当污染概率增加时：

- 正态近似变得越来越不准确
- 置信区间的覆盖率显著低于标称的 95%
- CLT 的条件：$\max_i |Y_i - \bar{Y}|^2/n \to 0$ 不再满足

这提醒我们：在实际应用中，需要检查数据的分布特征，确保满足正态近似的条件。

注 4.7. 实际应用启示： *如果数据存在重尾或极端值，考虑：1) 数据变换；2) 使用稳健推断方法；3) 使用 bootstrap。*

4.8 LaLonde 数据案例

使用 LaLonde 数据演示 Neymanian 推断：

```
> library(Matching)
> data(lalonde)
> z <- lalonde\$treat
> y <- lalonde\$re78
> n1 <- sum(z)
> n0 <- length(z) - n1
> tauhat <- mean(y[z==1]) - mean(y[z==0])
> vhat <- var(y[z==1])/n1 + var(y[z==0])/n0
> sehat <- sqrt(vhat)
> tauhat
[1] 1794.343
> sehat
[1] 670.9967
```

95% 置信区间：

$$1794.34 \pm 1.96 \times 670.99 = (478.6, 3110.1)$$

由于置信区间不包含零，我们可以拒绝" 因果效应为零" 的零假设。

4.9 与 FRT 的比较

	Fisherian (FRT)	Neymanian
理论基础	精确（有限样本）	渐近（正态近似）
零假设	Sharp null	-
置信区间	需额外假设	基于 CLT
适用场景	小样本	大样本

两者是互补的关系：- 当 n 小时，用 FRT - 当 n 大时，用 Neymanian - 两者结果应该相近

4.10 本章小结

本章我们学习了 Neymanian 推断：

1. **点估计**：$\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$，无偏估计
2. **方差估计**：$\hat{V} = S^2(1)/n_1 + S^2(0)/n_0$，保守估计
3. **置信区间**：基于渐近正态分布
4. **与 OLS 的关系**：使用稳健标准误后等价
5. **与 FRT 互补**：小样本用 FRT，大样本用 Neymanian

下一章我们将学习**分层随机实验**——通过分层来提高估计精度。

Appendix A

问答与注解

A.1 阅读过程中的问题与解答

暂无记录

当你在阅读过程中提出问题时，回答将被记录在此处。

A.2 学习笔记

在这里记录你的学习心得和思考。