

因果推断讲义

Peng Ding

Contents

引言：文献概述	13
引言：文献概述	13
1. 总述	13
2. 文献摘要总结	13
3. 补充参考资料	14
4. 学习路径与前置基础知识	14
5. 最终目标	14
Chapter 1. 相关性、关联与 Yule-Simpson 悖论	15
1. 本章导论	15
2. 为什么这个问题很重要	15
3. 相关性与因果性的区别	15
4. 二维列联表与关联度量	15
5. Yule-Simpson 悖论	16
6. 偏相关系数与 Yule-Simpson 悖论	16
7. LaLonde 数据与规格搜索问题	17
8. 种族歧视的简历实验	17
9. 本章小结与下节预告	17
10. 习题	17
Chapter 2. 潜在结果框架	19
1. 从相关到因果：为什么关联不够？	19
2. 一个思想实验	19
3. 科学表 (Science Table)	19
4. 个体因果效应	20
5. 平均因果效应	20
6. 亚组与亚组因果效应	21
7. 亚组因果效应与 Yule-Simpson 悖论的不存在	21
8. 治疗分配机制与基本恒等式	21
9. SUTVA：使框架有效的必要假设	21
10. 反事实思维的逻辑	22
11. 实验单元定义的微妙性	23
12. 非线性因果参数	23
13. 本章小结	23
14. 习题	23
15. 附录：公式推导	24
Chapter 3. 完全随机实验与费舍尔随机化检验	27
1. 从潜在结果框架到随机实验：问题的起源	27

2. Fisher 的洞见：随机化的两个原则	27
3. 完全随机实验的定义	27
4. Sharp Null 假设与 FRT 逻辑	28
5. 随机化分布与精确 p 值	28
6. Monte Carlo 近似	29
7. 检验统计量的规范选择	29
8. FRT 与传统 t 检验的关系	36
9. LaLonde 实验数据案例	36
10. 历史侧边栏：随机实验的起源	36
11. Sharp Null 假设的置信区间	37
12. 本章小结	37
13. 习题	37
Chapter 4. Neymanian 重复抽样推断	39
1. 两种推断哲学的对话	39
2. 有限总体量	39
3. 一个关键引理	40
4. Neyman (1923) 定理	40
5. 方差公式的深入理解	41
6. Neyman (1923) 定理的证明	41
7. 渐近正态性与置信区间	42
8. Neymanian 推断与 OLS 的关系	42
9. 重尾结局与正态近似的失效	43
10. 本章小结	43
11. 习题	44
Chapter 5. 分层与后分层随机实验	45
1. 引言：随机化的艺术	45
2. SRE 的定义与记号	45
3. 层别平均因果效应	46
4. SRE 中的 Fisher 随机化检验	46
5. Neymanian 推断	48
6. SRE 与 CRE 的效率比较	49
7. CRE 中的后分层	50
8. 实践中的问题	50
9. 本章小结	50
10. 习题	51
Chapter 6. 回归调整与协变量平衡	53
1. 引言：从分层到连续协变量	53
2. 重随机化：设计阶段的协变量平衡	53
3. ReM 下的统计推断	54
4. 回归调整：分析阶段的协变量平衡	55
5. 回归调整的补充讨论	58
6. 分层随机实验的推广	58
7. 设计策略的统一与比较	59
8. 模拟研究	59
9. 结语：协变量平衡的两种路径	60

10. 习题	60
11. 附录：推导	61
Chapter 7. 配对随机实验	63
1. 引言：从分层到配对的极致追求	63
2. MPE 的定义与记号	63
3. Fisher 随机化检验	63
4. Neymanian 推断	66
5. 协变量调整	67
6. Darwin 数据的 FRT 分析	68
7. 儿童电视 Workshop 实验	69
8. 本章小结	69
9. 习题	69
10. 附录：定理证明	70
11. 附录：渐近分布推导	71
12. 附录：方差公式推导	72
13. 附录：协变量调整推导	72
14. 附录：儿童电视 Workshop 实验详细计算	73
Chapter 8. 分层实验中的 Fisher 随机化检验：Studentized 统计量	75
1. 引言：从 Chapter 3 的 FRT 到 Chapter 8 的双重保证	75
2. Studentized 统计量的双重保证	75
3. 分层实验中的 Studentized 统计量	76
4. 带协变量的 FRT	77
5. 模拟研究	78
6. 实践建议	78
7. 案例研究：铁补充剂实验的重新分析	79
8. 本章小结	80
9. 习题	80
Chapter 9. 随机实验中的协变量调整	83
1. 引言：为什么需要协变量调整？	83
2. 超级总体框架下的 CRE	83
3. 模拟研究	85
4. SRE 的扩展	85
5. 本章小结	85
6. 习题	86
Chapter 10. 结果回归：连接随机实验与观测性研究	87
1. 从随机实验到观测性研究：一个自然的问题	87
2. 三个典型例子	87
3. 潜在结果框架下的因果效应与选择偏差	88
4. 非参数识别的充分条件	88
5. 两种简单估计策略及其局限	89
6. 二值结果的情形	90
7. 本章小结	91
8. 练习	91
9. 推荐阅读	91

Chapter 11. 倾向得分在观测性研究中的核心地位	93
1. 引言：为什么需要倾向得分？	93
2. 倾向得分的定义与降维性质	93
3. 倾向得分分层	94
4. 逆概率加权估计量	95
5. 倾向得分的平衡性质	96
6. 与结果回归的对比	96
7. 重叠条件与外推风险	97
8. 本章小结	97
9. 习题	97
Chapter 12. 双重稳健估计	99
1. 引言：一个估计量的双重保险	99
2. 总体版本的 DR 估计量	99
3. 双重稳健性定理	100
4. 样本版本的 DR 估计量	100
5. 更深层的直觉	101
6. 模拟研究	101
7. 进一步讨论：为何脆弱？	102
8. 本章小结	102
9. 习题	102
10. 定理 定义 12.1 的证明	103
11. 双重稳健估计量的等价形式推导	103
12. 从 IPW 到 DR 的分解	103
13. 从结果回归到 DR 的偏倚修正	104
14. 双重稳健性的乘积结构	104
15. 模拟研究详情	104
Chapter 13. 基于倾向得分的分层	107
1. 引言：从分层随机实验到观测性研究	107
2. 倾向得分的维度约化性质	107
3. 倾向得分分层	108
4. 分层数 K 的选择	109
5. 与第五章的联系：SRE 的观测性研究版本	109
6. 标准误的估计	109
7. 应用实例	110
8. 小结	111
9. 附录：关键公式推导	111
Chapter 14. 加权最小二乘法用于因果推断	113
1. 一个问题意识：IPW 估计量的另一种面孔	113
2. Hajek 估计量作为 WLS 估计量	113
3. 加入协变量：Lin (2013) 的推广与双重稳健性	114
4. 处理组平均因果效应的 WLS	115
5. 统一视角：回归估计量一览	116
6. 本章小结	116
7. 习题	116

Chapter 15. 观测性研究中的匹配	119
1. 引言：为什么匹配比回归更直观？	119
2. 匹配的基本思想	119
3. 匹配估计量：一对一匹配	119
4. 匹配的双稳健形式	120
5. ATT 的匹配估计量	121
6. 实践中的问题	121
7. 实例：LaLonde 数据	121
8. 本章小结	122
9. 习题	122
Chapter 16. 观测性研究中不可混淆性假设的困难	123
1. 引言：当我们无法控制所有混杂因素时	123
2. 因果图的基本概念	123
3. 评估不可混淆性假设	124
4. 过度调整的问题	125
5. 习题	128
6. 推荐阅读	129
Chapter 17. E-Value：未测混杂观测性研究中的因果证据	131
1. 引言：当可忽略性假设失效时	131
2. Cornfield 型灵敏度分析	131
3. E-value	133
4. 经典例子：吸烟与肺癌	133
5. 扩展	134
6. 批评与回应	135
7. 本章小结	136
8. 习题	136
9. 推荐阅读	136
Chapter 18. 附录：定理 17.1 的证明	137
1. 背景与目标	137
2. 记号定义	137
3. 详细推导	137
4. 单调性与上界	138
5. 恒等式	138
Chapter 19. 附录：引理 17.3 的证明	139
Chapter 20. 附录：罕见结果近似	141
Chapter 21. 平均因果效应的灵敏度分析	143
1. 引言：可忽略性失效时我们能做什么	143
2. Manski 型最坏情况界	143
3. 平均因果效应的灵敏度分析	144
4. R 函数与实证示例	146
5. 本章小结	147
6. 习题	148
7. 推荐阅读	149

Chapter 22. 附录：定理 21.2 的证明	151
1. 背景与目标	151
2. 记号定义	151
3. 详细推导	151
Chapter 23. 附录：定理 21.3 的证明	153
1. 背景与目标	153
2. 识别公式推导	153
Chapter 24. 附录：Manski 型边界的推导	155
1. 背景	155
2. 记号定义	155
3. $E\{Y(1)\}$ 的边界	155
4. $E\{Y(0)\}$ 的边界	155
5. τ 的边界	155
Chapter 25. Rosenbaum 风格 p 值：匹配观测研究中的未测量混杂	157
1. 引言：从理想实验到现实挑战	157
2. 匹配观测研究的灵敏度分析模型	157
3. 最坏情况 p 值	158
4. 实例分析	159
5. 练习	159
6. 本章小结	160
Chapter 26. 平行世界框架	161
1. 引言：跨越两个世界的桥梁	161
2. 重叠假设的隐含要求	161
3. 当重叠失败时：修整与结果建模	162
4. 无重叠情形下的因果推断：回归断点设计	162
5. 本章小结	163
附录：公式推导	164
Chapter 27. 工具变量：从不完美实验到因果效应	167
1. 引言：无法假设无混淆时，我们还能做什么？	167
2. 鼓励设计与非依从性	167
3. 潜在依从性类型与因果效应分解	168
4. 三个核心假设：单调性、排除限制与随机性	168
5. 识别 Complier 平均因果效应 (CACE)	169
6. 估计	170
7. 协变量	170
8. 弱工具变量	171
9. CACE 的解释	171
10. 习题	172
Chapter 28. 依从性与意向治疗分析	173
1. 引言：从随机实验到现实世界	173
2. 鼓励设计与依从性问题	173
3. 潜在依从性类型与依从性因果效应	174
4. 非参数识别	175

5. 依从性平均因果效应 (CACE/LATE)	176
6. 估计	176
7. 弱工具变量	177
8. 协变量调整	178
9. 实例: JOBS II 培训项目	178
10. 从识别到解释: CACE 的深层含义	179
11. 本章小结	179
12. 习题	179
Chapter 29. 两阶段最小二乘	181
1. 引言: 工具变量回归的计算技巧	181
2. 问题设定: 过度识别情形	181
3. 两阶段最小二乘估计量	181
4. 标准误的估计	182
5. 特殊情形: 单一工具变量与单一内生处理	182
6. 弱工具变量问题	183
7. 应用: Card (1993) 教育回报研究	184
8. 小结	184
9. 习题	184
Chapter 30. 模糊断点回归	185
1. 本章导论	185
2. 从清晰断点到模糊断点	185
3. 动机实例	185
4. 数学设定	186
5. 识别定理	186
6. 估计方法	187
7. 数据应用	187
8. 讨论	188
9. 本章小结	188
10. 习题	188
Chapter 31. 孟德尔随机化	189
1. 引言: 遗传学与因果推断的交汇	189
2. 背景与动机	189
3. 线性 IV 模型回顾	189
4. 基于汇总统计的 MR 分析	190
5. 实例分析	192
6. MR 分析的批评与局限	193
7. 习题	194
推荐阅读	194
Bibliography	195
Chapter 32. 双重差分: 利用面板数据的结构识别因果效应	197
1. 引言: 一个看似简单的问题	197
2. 基本设定: 2×2 情形	197
3. 平行趋势假设	198

4. 回归框架与标准误差	199
5. 拓展：异质性处理效应	199
6. 本章小结	200
7. 延伸阅读	200
Chapter 33. 中介分析：自然直接效应与自然间接效应	201
1. 本章导论：一个古老的追问	201
2. 从总效应到直接效应与间接效应	201
3. 嵌套潜在结果	202
4. 中介公式	203
5. 线性模型下的 Baron-Kenny 方法	205
6. 应用实例：JOBS II 数据	206
7. 敏感性分析	207
8. 本章小结	207
练习	208
Chapter 34. 因果发现	211
1. 引言：一个雄心勃勃的问题	211
2. 因果马尔可夫条件与忠诚性	211
3. PC 算法：从条件独立性到因果骨架	211
4. DAG 等价类与基本等价类图	212
5. 条件独立性检验	213
6. PC 算法的完整流程	213
7. 其他因果发现方法概述	213
8. 因果发现的局限性	214
9. 讨论与延伸阅读	214
10. 本章小结	214
11. 习题	214
Chapter 35. 时间变动的处理变量与混淆	217
1. 从单时间点到多时间点：一个自然的推广	217
2. 基本设置与序列可忽略性	217
3. g 公式与结果建模	219
4. 逆概率加权	221
5. 多时间点情形	222
6. 习题	224
7. 推荐阅读	225
8. 附录：定理 29.1 的证明	226
Appendix A. 公式推导	227
1. Lemma 4.1 的证明：方差与协方差的关系	227
2. 差值均值统计量的方差分解	228
3. Wilcoxon 秩和统计量的方差推导	230
4. 女士品茶实验的超几何分布	231
5. 差值均值统计量的期望与方差推导	232
6. CRE 中分层平衡性的推导	233
7. 分层估计量的期望与方差推导	234
8. 分层 Neymanian 方差的推导	236

9. CRE 与 SRE 方差差异的推导	237
10. CRE 条件分布的推导	238
11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明	239
12. DiD 估计量的推导 (Chapter 26)	243
13. 第 23 章 TSLS 估计量的代数推导	244
14. TSLS 与 ILS 等价性的证明	245
15. 9.1 超级总体框架下的 Neyman 方差公式	246
16. 9.2 OLS 分解与 pooled regression 的等价性	247
17. 9.3 EHW 方差估计量的问题	247
18. 9.4 SRE 扩展的详细推导	248
19. 9.5 R 代码实现	248
20. Theorem 19.1 的证明: 最坏情况 p 值的分布	249
21. 最坏情况 p 值的显式计算公式	251
Appendix A. 问答与注解	253
1. 阅读过程中的问题与解答	253
2. 学习笔记	257
Appendix. Bibliography	259

引言：文献概述

本学习资料旨在系统研究因果推断（Causal Inference）的基础理论与方法。因果推断是现代统计学和计量经济学最重要的研究领域之一，它关注如何从观测数据或实验数据中推断出因果关系，而不仅仅是相关关系。

1. 总述

在科学研究中，“相关并不意味着因果”是一个基本常识。然而，在实际研究中，我们常常需要回答因果性问题：某种治疗是否有效？某个政策是否达到了预期效果？某个变量之间的关联是否具有因果性质？

Rubin (1974) 提出的潜在结果框架（Potential Outcomes Framework）为因果推断奠定了理论基础。在该框架下，每个单元在不同处理条件下都有对应的潜在结果，而我们只能观测到其中一个。这种“因果推断基本问题”推动了各种推断方法的发展。

本课程以 Peng Ding 的《A First Course in Causal Inference》为主教材，系统学习：

- 完全随机化实验中的因果推断方法
- Fisher 随机化检验与 Neyman 重复抽样推断
- 分层分析与后分层技术
- 观测性研究中的因果推断
- 倾向得分、工具变量、回归断点设计等高级主题

2. 文献摘要总结

2.1. A First Course in Causal Inference.

- (1) **作者:** Peng Ding (丁鹏)
- (2) **链接:** <https://arxiv.org/abs/2305.18793>
- (3) **年份:** 2023
- (4) **篇幅:** 490 页
- (5) **核心贡献:**
 - 系统整合了 Fisher 精确推断与 Neyman 渐近推断两大框架
 - 提出了条件随机化实验（CRE）的统一处理方法
 - 详细讨论了分层、后分层与协变量平衡技术
 - 涵盖了观测性研究中的因果推断主流方法
- (6) **摘要:** This book provides an introduction to causal inference for students and researchers interested in estimating treatment effects from randomized experiments and observational studies. It unifies the potential outcomes framework with a focus on randomization-based inference, covering topics from basic concepts like the Yule-Simpson paradox to advanced methods including propensity score matching, instrumental variables, and sensitivity analysis. The book emphasizes both finite-sample exact inference (Fisher’s approach) and asymptotic inference (Neyman’s approach), providing readers with a comprehensive toolkit for causal analysis.

- (7) **关键词:** Causal Inference; Potential Outcomes; Randomization Test; Neyman Inference; Observational Studies; Propensity Score

3. 补充参考资料

- **Imbens and Rubin (2015):** *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press. —因果推断的权威教材。
- **Rubin (1974):** “Estimating Causal Effects of Treatments in Randomized and Non-Randomized Studies.” *Journal of Educational Psychology*. —潜在结果框架的奠基性论文。
- **Rosenbaum and Rubin (1983):** “The Central Role of the Propensity Score in Observational Studies for Causal Effects.” *Biometrika*. —倾向得分理论的开创性工作。
- **Angrist and Pischke (2009):** *Mastering ‘Metrics’*. Princeton University Press. —计量经济学因果推断的入门读物。

4. 学习路径与前置基础知识

数学基础:

- 概率论：条件概率、条件期望、方差与协方差
- 统计学：点估计、置信区间、假设检验
- 线性代数：矩阵运算、特征值

概率不等式:

- Markov 不等式、Chebyshev 不等式
- Hoeffding 不等式、Chernoff 界
- CLT (中心极限定理)

推荐学习顺序:

- (1) 第 1-2 章：基础概念（相关与因果、潜在结果）
- (2) 第 3-4 章：完全随机化实验（Fisher 检验与 Neyman 推断）
- (3) 第 5 章：分层与后分层
- (4) 第 6-8 章：随机化实验的高级话题
- (5) 第 9 章：有限总体与超总体的统一框架
- (6) 第 10-18 章：观测性研究方法

5. 最终目标

完成本课程学习后，期望达到以下目标：

- **理论理解：**深入理解潜在结果框架，掌握 Fisher 精确推断与 Neyman 渐近推断的理论基础与联系。
- **方法掌握：**熟练运用各种因果推断方法，包括分层、协变量调整、倾向得分匹配、工具变量等。
- **应用能力：**能够针对实际研究问题设计合适的因果推断策略，正确解读分析结果。
- **批判思维：**能够识别因果推断中的常见陷阱（如辛普森悖论、选择偏差、混杂因素），并进行敏感性分析。

CHAPTER 1

相关性、关联与 Yule-Simpson 悖论

1. 本章导论

本章我们要回答一个看似简单却至关重要的问题：**相关性能否直接告诉我们因果关系？**

在日常生活中，我们经常听到这样的话：

- ”吸烟会导致肺癌”
- ”教育水平越高，收入越高”
- ”经常锻炼的人更长寿”

这些陈述都试图建立因果关系。但我们是如何得出这些结论的？仅仅因为我们观察到了相关性（correlation）就足够了么？

2. 为什么这个问题很重要

想象一下以下场景：

例 1.1. 一家公司想要知道某种新药是否有效。他们给一组患者服用新药，另一组服用安慰剂。结果显示服药组的康复率更高。这能否说明药物有效？

直觉告诉我们，这似乎能说明问题。但仔细想想，还有很多其他因素可能影响结果：

- 也许服药组的患者本身就更健康
- 也许医生在给药时，无意中对服药组患者更加关照
- 也许这只是随机波动

这就是因果推断（causal inference）的核心挑战：**我们观察到的关联（association），并不等于因果关系（causal relationship）。**

3. 相关性与因果性的区别

统计学中，我们用不同的术语来区分这些概念：

- **相关性（Correlation）**：两个变量共同变化的趋势
- **关联（Association）**：统计学意义上的依赖关系
- **因果性（Causation）**：一个变量的变化直接导致另一个变量变化

关键洞察：相关性可以是因果的，也可以是非因果的。

4. 二维列联表与关联度量

将 Z 视为治疗或暴露， Y 视为结果，可以定义以下关联度量：

	$Y = 1$	$Y = 0$
$Z = 1$	p_{11}	p_{10}
$Z = 0$	p_{01}	p_{00}

风险差 (Risk Difference):

$$RD = \mathbb{P}(Y = 1 \mid Z = 1) - \mathbb{P}(Y = 1 \mid Z = 0) = \frac{p_{11}}{p_{11} + p_{10}} - \frac{p_{01}}{p_{01} + p_{00}}$$

风险比 (Risk Ratio):

$$RR = \frac{\mathbb{P}(Y = 1 \mid Z = 1)}{\mathbb{P}(Y = 1 \mid Z = 0)} = \frac{p_{11}}{p_{11} + p_{10}} \bigg/ \frac{p_{01}}{p_{01} + p_{00}}$$

优势比 (Odds Ratio):

$$OR = \frac{\mathbb{P}(Y = 1 \mid Z = 1)/\mathbb{P}(Y = 0 \mid Z = 1)}{\mathbb{P}(Y = 1 \mid Z = 0)/\mathbb{P}(Y = 0 \mid Z = 0)} = \frac{p_{11}p_{00}}{p_{10}p_{01}}$$

关于记号: 本书使用符号 $\perp\!\!\!\perp$ 表示随机变量的独立性或条件独立性。

命题 1.1 (二维列联表中的独立性). (1) 以下命题等价: $Z \perp\!\!\!\perp Y$ 、 $RD = 0$ 、 $RR = 1$ 、 $OR = 1$ 。

(2) 若所有 $p_{zy} > 0$, 则 $RD > 0$ 等价于 $RR > 1$, 也等价于 $OR > 1$ 。

(3) 若 $\mathbb{P}(Y = 1 \mid Z = 1)$ 和 $\mathbb{P}(Y = 1 \mid Z = 0)$ 都很小, 则 $OR \approx RR$ 。

5. Yule-Simpson 悖论

悖论的核心思想: 在总体中观察到的关联方向, 可能与分层后各组中的关联方向相反。

例 1.2 (经典的 Yule-Simpson 悖论例子). 考虑一个大学录取数据:

院系	男生录取率	女生录取率
A	62% (341/550)	82% (137/167)
B	63% (28/44)	68% (24/35)
总体	45% (369/816)	30% (161/525)

有趣的现象:

- 在 A 院系, 男女生录取率分别是 62% 和 82%
- 在 B 院系, 男女生录取率分别是 63% 和 68%
- 但总体来看, 男生的录取率反而更高!

这就是 *Yule-Simpson 悖论*: 在每个分层中都有利的因素, 在总体中可能不利。

这个例子揭示了一个深刻的问题: 如果我们不控制混杂因素 (*confounding factors*), 就可能得出完全错误的因果结论。

6. 偏相关系数与 Yule-Simpson 悖论

考虑三维正态随机向量:

$$\begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho_{XY} & \rho_{XZ} \\ \rho_{XY} & 1 & \rho_{YZ} \\ \rho_{XZ} & \rho_{YZ} & 1 \end{pmatrix} \right)$$

Y 和 Z 的偏相关系数 $\rho_{YZ|X}$ 定义为在条件分布 $(Y, Z) \mid X$ 中的相关系数。

命题 1.2 (偏相关系数公式).

$$\rho_{YZ|X} = \frac{\rho_{YZ} - \rho_{YX}\rho_{ZX}}{\sqrt{1 - \rho_{YX}^2}\sqrt{1 - \rho_{ZX}^2}}$$

重要含义：即使 $\rho_{YZ} > 0$ ，偏相关系数 $\rho_{YZ|X}$ 仍可能为负！这正是正态随机向量情形下的 Yule-Simpson 悖论。

7. LaLonde 数据与规格搜索问题

LaLonde 数据集包含参与职业培训项目 (National Supported Work Demonstration) 的参与者的结果。在观察性研究中，协变量选择的敏感性是一个重要问题。

当我们运行 $2^{10} = 1024$ 种可能的协变量子集回归时，treatment 系数的显著性可能对模型规格高度敏感。这提醒我们：在观察性研究中，规格搜索可能导致误导性结论。

8. 种族歧视的简历实验

Bertrand and Mullainathan (2004) 通过随机改变简历上的名字来研究种族歧视。这些名字被设计成听起来像非裔美国人或白人的名字。实验显示，有黑人名字的简历回调率显著较低。

当我们分别对男性和女性进行分析时，可能会发现有趣的亚组差异——这进一步说明“平均效应”可能掩盖了重要的异质性。

9. 本章小结与下节预告

本章的核心要点：

- (1) **相关性 $\neq$ 因果性：**观察到的关联可能是由于混杂因素造成的
- (2) **关联度量：**RD、RR、OR 及它们与独立性的关系
- (3) **Yule-Simpson 悖论：**总体关联可能与分层关联方向相反
- (4) **偏相关：**即使边际相关为正，偏相关仍可能为负
- (5) **因果推断的必要性：**我们需要系统性的方法来区分真实的因果效应

下一章我们将学习因果推断的基石——**潜在结果框架 (Potential Outcomes Framework)**，这将为我们的因果分析提供坚实的数学基础。

10. 习题

练习 1.1. 1.1 独立性命题的证明 证明 Proposition 1.1 中的命题 (1) 和 (2)。

练习 1.2. 1.2 Yule-Simpson 悖论的更多例子

- (1) 给出一个 $2 \times 2 \times 2$ 列联表的数值例子，其中出现 Yule-Simpson 悖论。
- (2) 找一个现实生活中的 Yule-Simpson 悖论例子。

练习 1.3. 1.3 相关与偏相关 考虑三维正态随机向量 $(X, Y, Z)^T \sim N(\mathbf{0}, \Sigma)$ 。

证明偏相关系数公式 (见 Proposition 1.2)。

给出一个 $\rho_{YZ} > 0$ 但 $\rho_{YZ|X} < 0$ 的数值例子。

注：这是正态随机向量情形下的 Yule-Simpson 悖论。

练习 1.4. 1.4 规格搜索 重做 Hainmueller (2012) 的数据分析。使用结局 `re78` 和治疗 `treat`。数据集还包含 10 个协变量，共有 $2^{10} = 1024$ 种可能的协变量子集组合。运行所有可能的线性回归子集，并报告 treatment 系数的分布：有多少是正显著、负显著、不显著的？

练习 1.5. 1.5 种族歧视的进一步分析 重做 Bertrand and Mullainathan (2004) 的简历数据分析。分别对男性和女性进行分析，讨论亚组分析的结果与总体结论的差异。

练习 1.6. 1.6 推荐阅读 **推荐阅读**：？是关于 *Berkeley* 录取数据悖论的原始论文。？从因果推断角度重新审视了该研究。

历史注记：？是统计因果推断领域的经典综述文章，它推广了“*Rubin* 因果模型”这一名称。在 *UC Berkeley*，我们称之为“*Neyman* 模型”——原因显而易见。

CHAPTER 2

潜在结果框架

1. 从相关到因果：为什么关联不够？

在第一章中，我们见证了一个令人不安的现象：Yule-Simpson 悖论向我们展示了关联可以与因果相悖。两组数据分别显示的正向效应，在合并后可能变为负向——这警告我们，从关联推断因果是危险的。

但我们不禁要问：关联毕竟是我们能观察到的，而因果是我们真正想知道的。那么，因果效应能否被清晰地定义，甚至被估计？

这个问题引导我们走向一个优雅而强大的框架——潜在结果框架 (Potential Outcomes Framework)，也被称为 Neyman-Rubin 因果模型。

这个框架的起源可以追溯到 Neyman 在 1923 年的开创性工作，以及 Rubin 在 1970 年代对其的进一步发展。它的核心思想其实出奇地简单：要谈论因果，我们必须想象 (counterfactual) 如果事情有所不同会发生什么。

2. 一个思想实验

让我们从一个最简单的场景开始：假设我们想研究某种新药对患者康复的因果效应。

考虑第 i 个患者。我们记：

- $T_i = 1$ ：患者接受了治疗
- $T_i = 0$ ：患者未接受治疗（对照组）

现在，关键的问题来了：这个患者的结果会是什么？

在现实中，我们只能观察到一种情况——要么患者接受了治疗，要么没有。但为了谈论因果，我们必须同时考虑两种可能性：

- $Y_i(1)$ ：如果患者接受治疗，会观察到的结果
- $Y_i(0)$ ：如果患者未接受治疗，会观察到的结果

这里， $Y_i(1)$ 和 $Y_i(0)$ 就是**潜在结果**——它们描述了在不同治疗状态下可能发生的结果，但我们永远无法同时观察到两者。

注 2.1 (注 2.1 —什么是反事实). **反事实** (counterfactual) 指的是未被观测到的潜在结果。具体而言：

- 对于治疗组个体 i ($T_i = 1$)，我们观察到 $Y_i(1)$ ，而 $Y_i(0)$ 是反事实
- 对于对照组个体 i ($T_i = 0$)，我们观察到 $Y_i(0)$ ，而 $Y_i(1)$ 是反事实

正因为潜在结果框架讨论的是“如果接受相反治疗会怎样”，所以它也被称为**反事实框架** (counterfactual framework)。

注 2.2. **为什么叫“潜在”结果？**：因为它们描述的是“如果... 会怎样”的情形，这种结果是“潜在的”而非“现实的”。这正是 counterfactual (反事实) 思维的本质。

3. 科学表 (Science Table)

？将潜在结果组成的 $n \times 2$ 矩阵称为**科学表** (Science Table)：

i	$Y_i(1)$	$Y_i(0)$
1	$Y_1(1)$	$Y_1(0)$
2	$Y_2(1)$	$Y_2(0)$
$\vdots$	$\vdots$	$\vdots$
n	$Y_n(1)$	$Y_n(0)$

这个表包含了所有我们需要知道的关于因果效应的信息——但问题是，我们永远只能观察到每一行的其中一个值。

4. 个体因果效应

有了潜在结果，我们终于可以清晰地定义因果效应了。

对于个体 i ，定义**个体因果效应** (Individual Treatment Effect, ITE) 为：

$$\tau_i = Y_i(1) - Y_i(0)$$

这是治疗相对于对照的“净效果”。

但是，这里出现了一个根本性的困难。1923 年，Jerzy Neyman 在一篇关于田间试验的论文中首次明确指出了这个问题：

对于每个个体，我们只能观察到一种潜在结果——实际发生的那种。另一种潜在结果是潜在的、永不可见的。

这被称为**因果推断的根本问题** (Fundamental Problem of Causal Inference)。

注 2.3. **为什么这个困难如此根本？**：因为科学上感兴趣的大多数因果问题，都涉及将现实与反事实进行比较。我们可以问“这种药对这个患者有效吗？”——但这个问题要求我们同时知道患者吃药和不吃药的结果，而这是不可能的。

5. 平均因果效应

既然个体因果效应不可测量，我们退而求其次，关注**平均因果效应** (Average Causal Effect, ACE)：

$$(2.1) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0)$$

用更精确的有限总体记号：¹

$$(2.2) \quad \tau = \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} = \frac{1}{n} \sum_{i=1}^n Y_i(1) - \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

一个关键恒等式：平均因果效应等于个体因果效应的均值：

$$(2.3) \quad \tau = \bar{Y}(1) - \bar{Y}(0) = \frac{1}{n} \sum_{i=1}^n \tau_i$$

¹推导见附录 section 15.1

6. 亚组与亚组因果效应

亚组 (subgroup) 是由某个协变量（通常是二元变量 X_i ）分割出来的子群体。例如：

- 按性别分割：男性亚组 ($X_i = 1$) 和女性亚组 ($X_i = 0$)
- 按年龄分割：老年人/年轻人
- 按收入分割：高收入/低收入

亚组因果效应 (Subgroup Causal Effect) 衡量的是在该亚组内的平均因果效应：²

$$(2.4) \quad \tau_x = \frac{\sum_{i=1}^n \mathbb{I}(X_i = x) \{Y_i(1) - Y_i(0)\}}{\sum_{i=1}^n \mathbb{I}(X_i = x)}, \quad (x = 0, 1)$$

7. 亚组因果效应与 Yule-Simpson 悖论的不存在

一个重要的恒等式揭示了亚组因果效应与总体因果效应的关系：³

$$(2.5) \quad \tau = \pi_1 \tau_1 + \pi_0 \tau_0$$

其中 $\pi_x = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = x)$ 是 $X_i = x$ 的单元比例。

关键推论：如果 $\tau_1 > 0$ 且 $\tau_0 > 0$ ，则必有 $\tau > 0$ 。因此，Yule-Simpson 悖论在因果效应层面不可能发生！

这澄清了第一章的困惑：在关联层面出现的悖论，在因果层面并不存在——因为因果效应是可分解的，而关联并非如此。

8. 治疗分配机制与基本恒等式

设 T_i 是单元 i 的二元治疗指示变量，观测结果 Y_i 是潜在结果和治疗分配的函数：

$$\begin{aligned} (1) \quad Y_i &= \begin{cases} Y_i(1), & \text{if } T_i = 1 \\ Y_i(0), & \text{if } T_i = 0 \end{cases} \\ (2) \quad &= T_i Y_i(1) + (1 - T_i) Y_i(0) \\ (3) \quad &= Y_i(0) + T_i \{Y_i(1) - Y_i(0)\} \\ (4) \quad &= Y_i(0) + T_i \tau_i \end{aligned}$$

？将 eq. (2) 视为潜在结果与观测结果之间的**基本桥梁**。这些方程强调了个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 可能在不同单元间存在异质性。

9. SUTVA：使框架有效的必要假设

使用潜在结果框架需要一些技术性假设。其中最重要的是**稳定单位治疗值假设 (Stable Unit Treatment Value Assumption, SUTVA)**。

假设 2.1 (无干扰). 单元 i 的潜在结果不依赖于其他单元的治疗分配。这有时被称为**无干扰假设**。

假设 2.2 (一致性). 治疗水平没有其他版本。等价地，我们要求治疗水平是良好定义的，至少对关注的结局是如此。这有时被称为**一致性假设**。

假设 2.3 (SUTVA). 假设 2.1 和 2.2 同时成立。

²推导见附录 section 15.2

³推导见附录 section 15.3

为什么 SUTVA 如此重要？如果单元之间存在干扰，或者治疗定义不明确，那么潜在结果 $Y_i(1)$ 和 $Y_i(0)$ 就不是 well-defined 的——它们的值将取决于其他人的行为或治疗的具体形式，整个框架就会崩塌。

违反 SUTVA 的例子：

无干扰假设 (no-interference assumption) 违反的情形：

- (1) **传染病与疫苗接种 (infectious diseases and vaccination)**：当疾病具有传染性时，一个人是否接种疫苗不仅影响他自己的患病风险，还影响他周围人被感染的概率。例如，如果我的同事接种了流感疫苗，我患流感的概率也会降低——即使我自己没有接种。在这种情况下，单元 i 的潜在结果 $Y_i(1)$ 和 $Y_i(0)$ 都依赖于其他人的治疗分配。
- (2) **网络效应实验 (network experiments)**：在社交网络实验中，如果一个人收到 Facebook 广告 (treatment)，他的朋友看到这条广告并受到影响后，可能也会购买该产品——即使朋友本人没有直接收到广告。这就是所谓的**溢出效应 (spillover effect)**。
- (3) **随机区组实验中的相邻地块 (neighboring plots in randomized block experiments)**：农业实验中，相邻地块的作物可能相互影响——如果相邻地块使用了肥料，可能会通过土壤渗透影响本地块的产量。

一致性假设 (consistency assumption) 违反的情形：

- (1) **复合治疗 (composite treatments)**：当治疗本身有复杂组成部分时，相同的“治疗”标签可能对应不同的实际干预。例如：
 - 研究吸烟 (smoking) 对肺癌的影响时，“吸烟”这个治疗有多种形式——香烟类型、吸烟频率、吸入深度等，这些都可能产生不同的潜在结果。
 - 研究大学教育 (college education) 对收入的影响时，“上大学”这个治疗包括大学类型 (985/211 vs 普通院校)、专业、文凭等级等，这些差异会造成潜在结果的不一致。
- (2) **剂量效应 (dosage effects)**：在医学研究中，相同的药物名称可能对应不同剂量，而剂量直接影响疗效。例如“服用阿司匹林”作为治疗，但不同剂量的阿司匹林会产生完全不同的潜在结果。
- (3) **实施变异 (implementation variation)**：即使治疗名义上相同，不同实施者可能引入差异。例如，心理治疗研究中，不同治疗师的风格和技能可能导致相同的“心理治疗”产生不同效果。

当 SUTVA 不成立时，潜在结果框架需要修正。**现代因果推断文献**（如？）正在积极研究如何处理存在干扰或治疗版本多样的情形。

注 2.4. **SUTVA 的历史重要性**：*Rubin (1980)* 将 SUTVA 确立为潜在结果框架的基础假设，没有 SUTVA，因果推断的数学化是不可能的。

10. 反事实思维的逻辑

也许你会好奇：为什么不能简单地问“实际发生的结果是什么”？

答案是：**因果效应本质上是一个反事实 (counterfactual) 概念**。当我们问“这种药是否有效”时，我们实际上是在问：

“如果这个患者吃了药，结果会怎样？但现实是，他可能没有吃药...”

这种思维方式可能让人觉得抽象甚至哲学化，但它是我们谈论因果的唯一严谨方式。潜在结果框架的价值在于，它将这种哲学洞察转化为清晰的数学语言。

11. 实验单元定义的微妙性

我讨论一个与实验单元定义相关的微妙之处。简单来说，**实验单元可能不同于物理单元**。

例如，如果我在服药前没有服用阿司匹林且头痛没有消失，但我现在服用阿司匹林后头痛消失了，你可能认为我们可以同时观察到我的两种潜在结果。但这是对实验单元定义的误解！在不同时刻，我是同一个物理人，但成为了两个不同的实验单元。

因此，我们有四个潜在结果，其中两个被观察到，两个缺失。这说明，即使观察到的数据显示治疗“有效”，我们也无法确定地说阿司匹林就是原因——因为在“治疗后”的状态下，可能存在其他因素（如时间效应）导致头痛消失。

12. 非线性因果参数

平均因果效应是一个**线性**因果参数，因为潜在结果的平均差等于个体差别的平均。其他参数可能不是线性的。

例如，中位数治疗效应：

$$(2.6) \quad \delta_1 = \text{median}\{Y_i(1)\}_{i=1}^n - \text{median}\{Y_i(0)\}_{i=1}^n$$

通常不同于个体治疗效应的中位数：

$$(2.7) \quad \delta_2 = \text{median}\{Y_i(1) - Y_i(0)\}_{i=1}^n$$

这两个量在某些情况下可能相差很大。⁴

13. 本章小结

本章建立因果推断的数学语言：

- (1) **潜在结果**：为每个个体定义 $Y_i(1)$ 和 $Y_i(0)$
- (2) **科学表**： $n \times 2$ 矩阵 $\{Y_i(1), Y_i(0)\}_{i=1}^n$
- (3) **个体因果效应**： $\tau_i = Y_i(1) - Y_i(0)$
- (4) **平均因果效应**： $\tau = \bar{Y}(1) - \bar{Y}(0) = n^{-1} \sum_{i=1}^n \tau_i$
- (5) **根本问题**：我们只能观察到一种潜在结果
- (6) **基本桥梁方程**： $Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$
- (7) **SUTVA**：一致性 + 无干扰
- (8) **Yule-Simpson 悖论**在因果框架下不可能发生

下一章我们将看到，**随机实验**提供了一种绕过根本问题的优雅方式——通过随机分配治疗，我们可以建立组间可比性，从而识别因果效应。

14. 习题

练习 2.1. 2.1 完美的医生 假设潜在结果由以下模型生成：

$$Y_i(0) \sim N(0, 1), \quad \tau_i = -0.5 + Y_i(0), \quad Y_i(1) = Y_i(0) + \tau_i$$

治疗分配为 $T_i = \mathbb{I}(\tau_i \geq 0)$ ，观测结果为 $Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$ 。

计算条件均值差 $\mathbb{E}(Y_i | T_i = 1) - \mathbb{E}(Y_i | T_i = 0)$ 。

提示：需要使用截断正态分布的均值公式。当 $X \sim N(\mu, \sigma^2)$ 时，

$$\mathbb{E}(X | a < X < b) = \mu - \sigma \frac{\phi\left(\frac{b-\mu}{\sigma}\right) - \phi\left(\frac{a-\mu}{\sigma}\right)}{\Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)}$$

⁴数值例子见附录 section 15.4

其中 ϕ 和 Φ 分别是标准正态分布的密度函数和分布函数。

练习 2.2. 2.2 非线性因果参数 证明平均因果效应是线性因果参数的例子，即 $\bar{Y}(1) - \bar{Y}(0) = n^{-1} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\}$ 。

其他参数可能不是线性的。例如，定义中位数治疗效应为：

$$\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\}$$

这通常不同于个体治疗效应的中位数：

$$\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\}$$

(1) 给出数值例子分别满足 $\delta_1 = \delta_2$ 、 $\delta_1 > \delta_2$ 和 $\delta_1 < \delta_2$ 。

(2) 哪个参数更有意义？为什么？请用例子来证明你的结论。

练习 2.3. 2.3 平均效应与个体效应 给出一个数值例子，其中 $\tau = n^{-1} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\} > 0$ ，但有不到一半的单元满足 $Y_i(1) > Y_i(0)$ 。即平均因果效应为正，但治疗对不到一半的单元有益。

练习 2.4. 2.4 推荐阅读 **推荐阅读：**？是统计因果推断领域的经典综述文章，它推广了“Rubin 因果模型”这一名称。在 UC Berkeley，我们称之为“Neyman 模型”——原因显而易见。

15. 附录：公式推导

15.1. 平均因果效应的有限总体表示. 背景：在有限总体中，平均因果效应 $\tau = \mathbb{E}[Y_i(1) - Y_i(0)]$ 可以用样本均值表示。

目标：证明 eq. (2.2)

推导步骤：

$$(5) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)]$$

$$(6) \quad = \frac{1}{n} \sum_{i=1}^n [Y_i(1) - Y_i(0)] \quad (\text{期望的有限总体类比})$$

$$(7) \quad = \frac{1}{n} \sum_{i=1}^n Y_i(1) - \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

$$(8) \quad = \bar{Y}(1) - \bar{Y}(0)$$

这完成了 eq. (2.2) 的推导。

15.2. 亚组因果效应的定义推导. 背景：亚组因果效应 τ_x 定义为在协变量 $X_i = x$ 的条件下，平均因果效应。

目标：推导 eq. (2.4)

推导步骤：

$$(9) \quad \tau_x = \mathbb{E}[Y_i(1) - Y_i(0) \mid X_i = x]$$

$$(10) \quad = \frac{\sum_{i=1}^n \mathbb{I}(X_i = x) [Y_i(1) - Y_i(0)]}{\sum_{i=1}^n \mathbb{I}(X_i = x)} \quad (\text{条件期望的样本类比})$$

其中 $\mathbb{I}(X_i = x)$ 是示性函数，当 $X_i = x$ 时为 1，否则为 0。

这给出了 eq. (2.4)。

15.3. 亚组分解恒等式的推导. 背景：总平均因果效应可以分解为各亚组因果效应的加权平均。

目标：证明 eq. (2.5)

推导步骤：

$$(11) \quad \tau = \frac{1}{n} \sum_{i=1}^n \{Y_i(1) - Y_i(0)\}$$

$$(12) \quad = \frac{1}{n} \sum_{i=1}^n [\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0)] \{Y_i(1) - Y_i(0)\}$$

$$(13) \quad \text{其中每单元满足 } \mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$$

$$(14) \quad = \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}_{\text{treatment 组}} + \underbrace{\frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}_{\text{control 组}}$$

$$(15) \quad = \frac{n_1}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 1) \{Y_i(1) - Y_i(0)\}}{n_1}}_{\tau_1} + \frac{n_0}{n} \cdot \underbrace{\frac{\sum_{i=1}^n \mathbb{I}(X_i = 0) \{Y_i(1) - Y_i(0)\}}{n_0}}_{\tau_0}$$

$$(16) \quad = \pi_1 \tau_1 + \pi_0 \tau_0$$

其中 $n_1 = \sum_{i=1}^n \mathbb{I}(X_i = 1)$, $n_0 = \sum_{i=1}^n \mathbb{I}(X_i = 0)$, 且 $\pi_x = n_x/n$ 。

这完成了 eq. (2.5) 的推导。

15.4. 非线性因果参数的数值例子. 背景：平均因果效应是线性的，但中位数治疗效应等参数可能是非线性的。

目标：给出 $\delta_1 \neq \delta_2$ 的具体数值例子。

例子：考虑 $n = 4$ 个单元，潜在结果如下：

i	$Y_i(1)$	$Y_i(0)$
1	10	2
2	8	3
3	6	4
4	4	5

计算：

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 7 - 3.5 = 3.5$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{8, 5, 2, -1\} = 3.5$

在此例中 $\delta_1 = \delta_2$ 。

不等例子：考虑 $n = 5$ 个单元：

i	$Y_i(1)$	$Y_i(0)$
1	100	1
2	90	2
3	50	3
4	10	4
5	5	5

计算：

- $\delta_1 = \text{median}\{Y_i(1)\} - \text{median}\{Y_i(0)\} = 50 - 3 = 47$
- $\delta_2 = \text{median}\{Y_i(1) - Y_i(0)\} = \text{median}\{99, 88, 47, 6, 0\} = 47$

再考虑一个 $\delta_1 > \delta_2$ 的例子：

i	$Y_i(1)$	$Y_i(0)$
1	100	0
2	1	0
3	1	0
4	1	0

计算：

- $\delta_1 = 50.5 - 0 = 50.5$
- $\delta_2 = \text{median}\{100, 1, 1, 1\} = 1$

这里 $\delta_1 = 50.5 > \delta_2 = 1$ ，说明少数极端值可以显著影响 δ_1 而不影响 δ_2 。这些例子说明为什么选择哪个参数需要根据研究问题仔细考虑。

完全随机实验与费舍尔随机化检验

1. 从潜在结果框架到随机实验：问题的起源

在第 ?? 章中，我们建立了**潜在结果框架 (Potential Outcomes Framework)**，学会了如何清晰地定义因果效应。平均因果效应定义为：

$$(17) \quad \tau = \mathbb{E}[Y_i(1) - Y_i(0)] = \bar{Y}(1) - \bar{Y}(0)$$

但我们也清楚地看到了因果推断的**根本问题 (Fundamental Problem of Causal Inference)**：对于每个个体，我们只能观察到一种潜在结果， $Y_i(1)$ 和 $Y_i(0)$ 无法同时被观测。¹ 这意味着，即使我们定义了因果效应，我们也不知道如何用数据来估计它——因为每个单元的“反事实结果”永远无法被观测到。

那么，一个自然的问题是：我们能否设计某种**数据收集过程**，使得即使无法观察反事实，我们仍然可以估计因果效应？

第 ?? 章曾指出，相关性不等于因果性——即使 X 和 Y 相关，我们也无法断定 X 导致 Y 。第 ?? 章通过潜在结果框架给因果效应一个精确的定义，但它留下的核心问题是：我们如何用实际观测到的数据来**识别 (identify)** 和**估计 (estimate)** 这些潜在结果？

这个问题的答案是肯定的，而解决方案就是**随机实验 (Randomized Experiment)**——统计学的黄金标准。

2. Fisher 的洞见：随机化的两个原则

Ronald Fisher 在 1935 年的开创性著作《Design of Experiments》中指出了随机化的两个优势：

- (1) **可比性**：它创造了在平均意义上可比的 treatment 和 control 组。
- (2) **推理基础**：它作为统计推断的“合理基础”。

第一点直观易懂——随机治疗分配不会偏向 treatment 或 control。第二点更微妙：Fisher 的意思是，随机化为统计检验提供了正当理由，这就是现在所谓的**费舍尔随机化检验 (Fisher Randomization Test, FRT)**²³。

3. 完全随机实验的定义

考虑一个包含 n 个单元的实验，其中 n_1 个接受治疗， n_0 个接受对照 ($n = n_1 + n_0$)。

定义 3.1 (完全随机实验 (Complete Randomized Experiment, CRE))。固定 n_1 和 n_0 (其中 $n = n_1 + n_0$)。完全随机实验的治疗 *assignment* 机制为：

$$(18) \quad \mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}},$$

其中 $\mathbf{z} = (z_1, \dots, z_n)$ 满足 $\sum_{i=1}^n z_i = n_1$ 和 $\sum_{i=1}^n (1 - z_i) = n_0$ 。

¹问：什么是潜在结果？见附录 section 1.9。

²问：什么是 Fisher Randomization Test？见附录 section 1.11。

³问：Fisher 随机化检验与经典假设检验有何不同？见附录 section 1.6。

在这个定义中，我们假设潜在结果向量 $\mathbf{Y}(1)$ 和 $\mathbf{Y}(0)$ 都是固定的。即使将它们视为随机的，我们可以在其上条件化，治疗分配机制变为：

$$(19) \quad \mathbb{P}\{\mathbf{Z} = \mathbf{z} \mid \mathbf{Y}(1), \mathbf{Y}(0)\} = \frac{1}{\binom{n}{n_1}}$$

因为在 CRE 中 $\mathbf{Z} \perp\!\!\!\perp \{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 。

关键含义：在 CRE 中， $\mathbf{Z}$ 是从 n_1 个 1 和 n_0 个 0 的随机排列中产生的。

4. Sharp Null 假设与 FRT 逻辑

？感兴趣检验的零假设是：

$$(20) \quad H_{0F} : Y_i(1) = Y_i(0) \quad \text{对所有单元 } i = 1, \dots, n.$$

？称其为 **sharp null 假设**，因为它可以基于观测数据确定所有潜在结果： $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y} = (Y_1, \dots, Y_n)$ ，即观测结果向量。它也被称为**强零假设**。⁴

概念上，在 H_{0F} 下，FRT 适用于任何检验统计量：

$$(21) \quad T = T(\mathbf{Z}, \mathbf{Y}),$$

它是观测数据的函数。观测结果向量 $\mathbf{Y}$ 在 H_{0F} 下是固定的，所以 T 中唯一的随机成分 is 治疗向量 $\mathbf{Z}$ 。实验者决定 $\mathbf{Z}$ 的分布，进而决定 T 的分布——这就是计算 p 值的基础。

在 CRE 中， $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的，其中 $M = \binom{n}{n_1}$ ， $\mathbf{z}^m$ 是所有可能的包含 n_1 个 1 和 n_0 个 0 的向量。⁵

5. 随机化分布与精确 p 值

如果较大的 T 值更极端，我们可以使用以下尾概率来衡量检验统计量相对于其随机化分布的极端性：

$$(22) \quad p_{\text{ftr}} = M^{-1} \sum_{m=1}^M \mathbb{I}\{T(\mathbf{z}^m, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}.$$

这就是 Fisher 的 p 值。重要的是， p_{ftr} 在 eq. (22) 中对任何检验统计量和任何结果生成过程都有效。它在 H_{0F} 下是有限样本精确的 (finite-sample exact)。⁶

$$(23) \quad \mathbb{P}(p_{\text{ftr}} \leq u) \leq u \quad \text{for all } 0 \leq u \leq 1.$$

注 3.1. 为什么叫“有限样本精确”？：这意味着 p 值的分布（虽然在离散情况下是阶梯函数）满足上式，因此 p 值在 $[0, 1]$ 上均匀分布（对于连续情况）。

⁴问：为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的？见附录 section 1.3。

⁵问： $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义是什么？见附录 section 1.12。

⁶问：什么是有限样本精确？见附录 section 1.5。

6. Monte Carlo 近似

在实践中, M 通常太大 (例如当 $n = 100, n_1 = 50$ 时, $M > 10^{29}$), 枚举所有可能的治疗向量在计算上是不可行的。我们经常用 Monte Carlo 来近似 p_{firt} , 并用修正公式 $\tilde{p}_{\text{firt}}$ 保证有限样本有效性。⁷⁸

$$(24) \quad \hat{p}_{\text{firt}} = R^{-1} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\},$$

其中 $\mathbf{z}^r$ 是 $\mathbf{Z}$ 的 R 次随机置换。由于计算 p_{firt} 涉及对 $\mathbf{Z}$ 的置换, FRT 有时在 CRE 语境下被称为**置换检验 (permutation test)**。

修正的有限样本有效近似:

$$(25) \quad \tilde{p}_{\text{firt}} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}.$$

这个修正在任意有限的 R 下都是有限样本有效的 p 值。

7. 检验统计量的规范选择

FRT 的一个特点是它对任何检验统计量都生成有限样本精确 p 值。但我们应该选择能够给出 H_{0F} 可能违背信息的检验统计量。

7.1. 差值均值统计量. 差值均值统计量是:

$$(26) \quad \hat{\tau} = \hat{Y}(1) - \hat{Y}(0),$$

其中

$$(27) \quad \hat{Y}(1) = n_1^{-1} \sum_{Z_i=1} Y_i = n_1^{-1} \sum_{i=1}^n Z_i Y_i$$

是 treatment 组的样本均值,

$$(28) \quad \hat{Y}(0) = n_0^{-1} \sum_{Z_i=0} Y_i = n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i$$

是 control 组的样本均值。

在 H_{0F} 下, $\hat{\tau}$ 有均值 0 和方差

$$(29) \quad \text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} s^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$, $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$ 。⁹

渐近分布: 由于有限总体中心极限定理 (Finite Population Central Limit Theorem), 随机化分布近似正态:

$$(30) \quad \frac{\hat{\tau}}{\sqrt{\frac{n}{n_1 n_0} s^2}} \rightarrow \mathcal{N}(0, 1)$$

in distribution.

⁷⁸问: 为什么 Monte Carlo 近似需要修正? 见附录 section 1.4。

⁸问: 蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思? 见附录 section 1.13。

⁹推导见附录 section 5。

与经典 t 检验的联系：在 H_{0F} 下，近似 p 值接近经典两样本 t 检验（假设等方差）的 p 值。

方差分解（ANOVA 分解）¹⁰：基于代数运算（见习题 3.8），我们有如下展开式：

$$(31) \quad (n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

这个展开式的意义：这本质上是一个方差分解（ANOVA 分解）。将每个单元的偏差 $Y_i - \bar{Y}$ 分解为组内偏差 $(Y_i - \hat{Y}(Z_i))$ 和组间偏差 $(\hat{Y}(Z_i) - \bar{Y})$ ，平方求和后交叉项消失，留下三项：treatment 组内部变异、control 组内部变异，以及由治疗效应解释的变异 $\frac{n_1 n_0}{n} \hat{\tau}^2$ 。¹¹

注 3.2. 为什么 FRT 能证明 t 检验的合理性？：传统 t 检验需要正态性假设。但 FRT 框架表明，只要随机化分配正确执行，t 检验程序在有限总体 + 随机化情境下可以使用——渐近理论只依赖于有限总体 CLT，而不依赖于数据的原始分布。

7.2. 学生化统计量。差值均值隐含地假设两组方差相等。如果治疗可能影响结果的变异性（异方差），我们需要使用学生化统计量：

$$(32) \quad t = \frac{\hat{Y}(1) - \hat{Y}(0)}{\sqrt{\frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}}},$$

其中

$$(33) \quad \hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{Z_i=1} [Y_i - \hat{Y}(1)]^2, \quad \hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{Z_i=0} [Y_i - \hat{Y}(0)]^2$$

分别是 treatment 组和 control 组的样本方差。

在 H_{0F} 下，有限总体 CLT 再次意味着 t 渐近正态： $t \rightarrow \mathcal{N}(0, 1)$ 。

这个统计量与 `t.test(var.equal = FALSE)` 的 p 值接近。

注 3.3. 学生化为什么更稳健？：当 treatment 组和 control 组的方差差异较大时，差值均值的检验可能失效。学生化通过分别估计两组的方差，能够更好地处理异方差情况。

7.3. 卡方检验：分类数据的拟合优度与独立性。迄今为止我们关注的都是连续型结局。但统计学同样关注**分类数据（categorical data）**——即计数数据。例如：选举中支持不同候选人的选民人数、不同药物治疗后的治愈/未治愈人数。卡方检验（Chi-Square Test）正是处理这类数据的核心工具。

核心思想：比较观测频数与期望频数。如果两者差异很大，说明数据可能不服从假设的分布或独立性结构。

Insight 连续数据关注“均值差异”，分类数据关注“频数差异”。这两类数据的分析方法有本质区别——连续数据用 t 检验，分类数据用卡方检验。

卡方检验由卡尔·皮尔逊（Karl Pearson）于 1900 年提出。

¹⁰详细推导见附录 section 2

¹¹ANOVA 分解的完整代数推导见附录 section 2。

7.3.1. 拟合优度检验. **问题**: 数据是否来自某个特定分布?

设有 k 个类别的观测频数 $O_1, O_2, \dots, O_k$, 总样本量为 n 。在零假设 H_0 下, 第 i 类的期望频数为 $E_i = np_{i0}$, 其中 p_{i0} 是 H_0 规定的理论概率。

皮尔逊卡方统计量:

$$(34) \quad \chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}.$$

直观理解: $(O_i - E_i)^2/E_i$ 衡量每个类别的偏差——平方消去正负号, 除以 E_i 进行标准化 (一个大类的 100 偏差比一个小类的 100 偏差更重要), 求和得到总体偏离程度。

渐近分布: 在 H_0 下, 当样本量 n 足够大时,

$$(35) \quad \chi^2 \xrightarrow{d} \chi_{k-1}^2,$$

自由度为 $k-1$, 因为只有一个约束—— $\sum O_i = \sum E_i = n$ 。

Insight 为什么自由度是 $k-1$? 因为 k 个类别的观测频数之和必须等于 n , 这产生了一个线性约束。所以 k 个类别中只有 $k-1$ 个可以自由变化——最后一个由总和决定。

例 3.1 (骰子检验——硬币是否均匀?) . **背景**: 投掷一枚骰子 120 次, 想检验它是否均匀 (各面概率均为 $1/6$)。

观测数据:

面	1	2	3	4	5	6
观测频数 O_i	15	22	18	25	17	23
期望频数 E_i	20	20	20	20	20	20

计算:

$$\chi^2 = \frac{(15-20)^2}{20} + \frac{(22-20)^2}{20} + \frac{(18-20)^2}{20} + \frac{(25-20)^2}{20} + \frac{(17-20)^2}{20} + \frac{(23-20)^2}{20} = 4.3$$

自由度 $k-1=5$, 查表得 $\chi_{0.05,5}^2 = 11.07$ 。

由于 $4.3 < 11.07$, 在 $\alpha = 0.05$ 水平下 **不能拒绝** 均匀性假设。

R 实现:

```
> obs <- c(15, 22, 18, 25, 17, 23)
> chisq.test(obs, p = rep(1/6, 6))
```

Chi-squared test for given probabilities

X-squared = 4.3, df = 5, p-value = 0.507

p 值为 0.507, 远大于 0.05, 与手工计算一致。

□

Insight 骰子例子中, $E_i = 20$ 都相同。如果某个类别期望频数太小 (< 5), 渐近近似的精度会下降, 此时应该用精确检验 (exact test) 或合并相邻类别。

例 3.2 (遗传学——孟德尔豌豆实验). **背景**: 孟德尔杂交黄色圆粒豌豆与绿色皱粒豌豆, 预期后代比例为:

黄圆 : 黄皱 : 绿圆 : 绿皱 = 9 : 3 : 3 : 1

观测数据 (共 556 株):

$$O = (315, 101, 108, 32), \quad E = (556 \times \frac{9}{16}, \dots) = (312.75, 104.25, 104.25, 34.75)$$

计算:

$$\chi^2 = \frac{(315 - 312.75)^2}{312.75} + \frac{(101 - 104.25)^2}{104.25} + \frac{(108 - 104.25)^2}{104.25} + \frac{(32 - 34.75)^2}{34.75} \approx 0.47$$

自由度 $k - 1 = 3$, 查表得 $\chi_{0.05,3}^2 = 7.81$ 。由于 $0.47 < 7.81$, **不能拒绝**孟德尔比例。

R 实现:

```
> obs <- c(315, 101, 108, 32)
> prob <- c(9/16, 3/16, 3/16, 1/16)
> chisq.test(obs, p = prob)
```

Chi-squared test for given probabilities

X-squared = 0.47, df = 3, p-value = 0.925

p 值为 0.925——数据与孟德尔比例高度吻合。

□

7.3.2. 独立性检验: 第二个应用场景是**列联表独立性检验**——判断两个分类变量是否独立。

问题: 对于 $r \times c$ 列联表, 检验行变量 X 与列变量 Y 是否独立。

设 O_{ij} 为单元格 (i, j) 的观测频数, $O_{i\cdot} = \sum_j O_{ij}$ 为第 i 行合计, $O_{\cdot j} = \sum_i O_{ij}$ 为第 j 列合计, 总计为 n 。

期望频数 (在独立性假设 $H_0: X \perp Y$ 下):

$$(36) \quad E_{ij} = \frac{O_{i\cdot} \cdot O_{\cdot j}}{n}.$$

检验统计量:

$$(37) \quad \chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

自由度: 在 H_0 下, $(r - 1)(c - 1)$ 。

Insight 2×2 表的自由度为 1, 这与二项分布的参数个数一致——只估计了一个参数 p (成功率)。更大的表可以检验更复杂的独立性结构。

连续性修正 (仅用于 2×2 表): R 中的 `chisq.test` 默认使用 Yates 连续性修正, 对小样本的渐近近似进行校正:

$$\chi_{\text{Yates}}^2 = \sum \frac{(|O - E| - 0.5)^2}{E}.$$

例 3.3 (2×2 表——治疗与结局独立性). 考虑二元结局的随机实验, 数据汇总为:

	成功 ($Y = 1$)	失败 ($Y = 0$)	合计
治疗 ($Z = 1$)	$n_{11} = 30$	$n_{10} = 20$	$n_1 = 50$
对照 ($Z = 0$)	$n_{01} = 20$	$n_{00} = 30$	$n_0 = 50$

步骤 1: 计算期望频数:

$$E_{11} = \frac{50 \times 50}{100} = 25, \quad E_{10} = \frac{50 \times 50}{100} = 25, \quad E_{01} = \frac{50 \times 50}{100} = 25, \quad E_{00} = 25$$

步骤 2: 计算 χ^2 :

$$\chi^2 = \frac{(30 - 25)^2}{25} + \frac{(20 - 25)^2}{25} + \frac{(20 - 25)^2}{25} + \frac{(30 - 25)^2}{25} = 4$$

自由度 $(2-1)(2-1) = 1$, 临界值 $\chi_{0.05,1}^2 = 3.84$ 。由于 $4 > 3.84$, **拒绝独立性假设**——治疗与结局存在关联。

R 实现:

```
> tb <- matrix(c(30, 20, 20, 30), nrow = 2, byrow = TRUE)
> chisq.test(tb)
```

Pearson's Chi-squared test with Yates' continuity correction

X-squared = 4, df = 1, p-value = 0.0455

注意 *Yates* 修正后的 χ^2 从 4 降到 3.24, p 值 = 0.072——这说明连续性修正在小样本时影响显著。

□

例 3.4 (3×2 表——吸烟与肺癌). **背景:** 研究吸烟状态与肺癌诊断的关联, 数据如下:

	患肺癌	未患肺癌	合计
重度吸烟	60	40	100
轻度吸烟	20	30	50
不吸烟	10	40	50

步骤 1: 计算期望频数:

$$E_{11} = \frac{100 \times 90}{200} = 45, \quad E_{12} = \frac{100 \times 110}{200} = 55$$

$$E_{21} = \frac{50 \times 90}{200} = 22.5, \quad E_{22} = \frac{50 \times 110}{200} = 27.5$$

$$E_{31} = \frac{50 \times 90}{200} = 22.5, \quad E_{32} = \frac{50 \times 110}{200} = 27.5$$

步骤 2: 计算 χ^2 :

$$\chi^2 = \frac{(60 - 45)^2}{45} + \frac{(40 - 55)^2}{55} + \frac{(20 - 22.5)^2}{22.5} + \frac{(30 - 27.5)^2}{27.5} + \frac{(10 - 22.5)^2}{22.5} + \frac{(40 - 27.5)^2}{27.5} \approx 20.4$$

自由度 $(3-1)(2-1) = 2$, 查表 $\chi_{0.05,2}^2 = 5.99$ 。由于 $20.4 > 5.99$, **拒绝独立性**——吸烟与肺癌存在显著关联。

R 实现:

```
> tb <- matrix(c(60, 40, 20, 30, 10, 40), nrow = 3, byrow = TRUE)
> rownames(tb) <- c("重度吸烟", "轻度吸烟", "不吸烟")
> colnames(tb) <- c("患肺癌", "未患肺癌")
> chisq.test(tb)
```

Pearson's Chi-squared test

X-squared = 20.4, df = 2, p-value = 3.7e-05

p 值极小, 结论稳健。

□

例 3.5 (4×3 表——教育程度与收入水平). 背景: 调查 500 人的教育程度与收入水平:

	低收入	中等收入	高收入	合计
初中及以下	80	50	20	150
高中	60	80	30	170
本科	30	70	40	140
研究生	10	30	100	140
合计	180	230	190	500

R 实现:

```
> edu <- c(80, 50, 20, 60, 80, 30, 30, 70, 40, 10, 30, 100)
> tb <- matrix(edu, nrow = 4, byrow = TRUE)
> rownames(tb) <- c("初中及以下", "高中", "本科", "研究生")
> colnames(tb) <- c("低收入", "中等收入", "高收入")
> chisq.test(tb)
```

Pearson's Chi-squared test

X-squared = 186.7, df = 6, p-value < 2.2e-16

p 值极小, 拒绝独立性——教育程度与收入水平存在强关联。

进一步分析: 对于 $r \times c$ 表, 还可以计算 Cramér V 来衡量关联强度:

$$(38) \quad V = \sqrt{\frac{\chi^2}{n \times \min(r-1, c-1)}}.$$

对于本例, $V = \sqrt{186.7/(500 \times 2)} \approx 0.43$, 表示中等偏强的关联。

□

7.3.3. 二元结局下的卡方检验: 与 Fisher 精确检验的对比. 回到随机实验的二元结局语境, 我们使用卡方检验来检验 $Z \perp Y$ (治疗与结局独立)。

与 Fisher 精确检验的比较:

特征	Chi-square test	Fisher exact test
原理	渐近方法 (大样本)	精确方法 (小样本)
p 值	近似	精确
适用场景	期望频数均 > 5	小样本或期望频数 < 5

Insight Fisher 精确检验使用超几何分布计算 p 值, 在零假设下有精确的有限样本分布。Chi-square 则是大样本近似——当样本量增大时, 两者结果趋于一致。

完整例子——简历种族歧视实验 (Bertrand & Mullainathan, 2004):

该实验将简历上的名字随机分配为黑人听起来或白人听起来的名字, 研究感知种族对面试回调率的影响。

```
resume = read.csv("resume.csv")
Alltable = table(resume$race, resume$call)
Alltable
```

```
#      0      1
# black 2278  157
# white 2200  235
```

数据汇总为 2×2 列联表:

	回调 ($Y = 1$)	无回调 ($Y = 0$)	合计
黑人名字 ($Z = 1$)	157	2278	2435
白人名字 ($Z = 0$)	235	2200	2435

计算各格期望频数:

$$E_{11} = \frac{2435 \times 392}{4870} \approx 195.7, \quad E_{12} = \frac{2435 \times 4478}{4870} \approx 2239.3$$

$$E_{21} = \frac{2435 \times 392}{4870} \approx 196.3, \quad E_{22} = \frac{2435 \times 4478}{4870} \approx 2238.7$$

由于期望频数都远大于 5, 适合使用卡方检验。

```
> chisq.test(Alltable)
```

```
Pearson's Chi-squared test with Yates' continuity correction
```

```
X-squared = 17.6, df = 1, p-value = 2.7e-05
```

p 值极小, 提供种族对回调率有显著影响的强有力证据。

与 Neymanian 推断的联系: 卡方检验本质上是在检验弱零假设 $H_0: \tau = 0$ (平均因果效应为零) 的渐近版本。风险差估计量 $\widehat{RD} = \hat{p}_1 - \hat{p}_0$ 的渐近方差为

$$\text{var}(\widehat{RD}) \approx \frac{\hat{p}_1(1 - \hat{p}_1)}{n_1} + \frac{\hat{p}_0(1 - \hat{p}_0)}{n_0}$$

而 χ^2 统计量正是 $(\widehat{RD})^2 / \text{var}(\widehat{RD})$ 的另一种表达。

不满足适用条件时的处理:

- (1) 如果某些期望频数 < 5 (尤其 2×2 表), 优先使用 Fisher 精确检验
- (2) 如果样本量太小, 可以合并相邻类别以增大期望频数
- (3) 使用蒙特卡洛近似: `chisq.test(tb, simulate.p.value = TRUE)`

Insight 卡方检验的“大样本近似”条件可以通过经验规则判断: 期望频数都 > 5 时近似精度较好; 如果有多个格子 < 5 , 渐近近似的 p 值可能严重偏离真实值, 此时 Fisher 精确检验更可靠。

7.4. Wilcoxon 秩和统计量. 差值均值和学生化统计量都关注均值差异, 且对异常值敏感。Wilcoxon 秩和统计量基于合并观测结果的秩:

$$W = \sum_{i=1}^n Z_i R_i,$$

其中 R_i 是 Y_i 在合并样本中的秩。

均值与方差¹²: 在 H_{0F} 下, 随机性只来自治疗分配 $\mathbf{Z}$, 秩 R_i 是固定值。均值和方差分别为:

$$\mathbb{E}(W) = \frac{n_1(n+1)}{2}, \quad \text{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

这个统计量的优点是:

¹²详细推导见附录 section 3

- 对异常值稳健（只使用秩次信息，不依赖具体数值）
- 只依赖于数据的秩次信息
- 在许多备择假设下都有较好的功效

7.5. Kolmogorov-Smirnov 统计量. 上述统计量主要关注均值差异。KS 统计量衡量两个分布之间的最大距离：

$$D = \max_y |\hat{F}_1(y) - \hat{F}_0(y)|,$$

其中 $\hat{F}_1(y) = n_1^{-1} \sum_{i=1}^n Z_i \mathbb{I}(Y_i \leq y)$ 。

这个统计量能够检测分布形状的差异，而不仅仅是均值差异。

8. FRT 与传统 t 检验的关系

一个重要的理论发现是：

FRT 为传统 t 检验提供了更坚实的基础。

传统 t 检验假设“数据来自正态分布的无限总体”。但 FRT 框架表明，只要随机化分配正确执行，t 检验程序可以在“有限总体 + 随机化”的情境下使用。

这意味着，在随机实验中，我们可以不那么担心正态性假设——CLT 会为我们处理这个问题。

9. LaLonde 实验数据案例

1986 年，Robert LaLonde 发表了一项影响深远的研究，探讨职业培训项目（National Supported Work Demonstration）对参与者收入的影响。

使用 R 进行 FRT 分析：

```
library(Matching)
data(lalonde)
z <- lalonde$treat
y <- lalonde$re78
```

观测到的检验统计量值：

统计量	观测值	描述
$\hat{\tau}$	2.84	差值均值 (t 统计量)
t	2.67	学生化统计量
W	27402.5	Wilcoxon 秩和
D	0.132	KS 统计量

通过随机置换治疗向量，我们可以得到检验统计量的随机化分布的 Monte Carlo 近似。Monte Carlo 置换检验的结果 ($R = 10^4$)：

```
> exact.pv = c(mean(Tauhat >= tauhat),
+               mean(Student >= student),
+               mean(Wilcox >= W),
+               mean(Ks >= D))
> round(exact.pv, 3)
[1] 0.002 0.002 0.006 0.040
```

所有单侧 p 值都小于 0.05——这提供了治疗效应显著的强有力证据。

10. 历史侧边栏：随机实验的起源

FRT 的逻辑可以追溯到早期的历史实例。

10.1. James Lind 的坏血病实验. James Lind (1716-1794) 是苏格兰医生和皇家海军卫生学的先驱。他进行了最早有清晰文献记录的随机实验之一，研究柑橘类水果对坏血病的影响。在 12 名坏血病患者被分配到 6 组后，接受柑橘类水果的组在六天后康复，而其他组没有。

如果将治疗简化为二元指示变量，观测到的极端 2×2 表格在 H_{0F} 下出现的概率为：

$$p_{\text{frit}} = \frac{1}{\binom{12}{2}} = \frac{1}{66} = 0.015.$$

10.2. Fisher 的女士品茶实验.[?] 描述了一个著名实验，一位女士声称能区分先加茶还是先加牛奶制成的奶茶。他制作了 8 杯茶（4 杯先加茶，4 杯先加牛奶），随机顺序呈现给女士。在她的全部猜对（ $X = 4$ ）的情况下，p 值为：

$$p_{\text{frit}} = \frac{1}{70} = 0.014.$$

超几何分布¹³：在 H_{0F} 下， X 服从超几何分布 $\text{Hypergeometric}(N = 8, K = 4, n = 4)$ ，这对应“不放回抽样”的结果。关键概率 $\mathbb{P}(X = 4) = 1/70$ ，故单侧 p 值 $p_{\text{frit}} = 1/70 \approx 0.014$ 。这些例子强调了 Fisher 的两个原则：

- (1) **随机化**：实验的随机分配保证了 p 值的有效性
- (2) **重复**：必须有足够的单元以确保 FRT 有功效

11. Sharp Null 假设的置信区间

FRT 的逻辑不仅限于 H_{0F} 。我们还可以检验更一般的 sharp null 假设：

$$(39) \quad H_0(\boldsymbol{\tau}) : Y_i(1) - Y_i(0) = \tau_i \quad \text{对所有 } i.$$

通过检验与置信集的对偶性，我们可以构建 $\boldsymbol{\tau}$ 的 $(1 - \alpha)$ 置信集。

12. 本章小结

本章建立了随机实验的理论与实践：

- (1) **CRE 定义**： $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = 1/\binom{n}{n_1}$
- (2) **随机化的两个原则**：可比性 + 推理基础
- (3) **Sharp null**： $H_{0F} : Y_i(1) = Y_i(0)$ 对所有 i
- (4) **精确 p 值**： $p_{\text{frit}} = M^{-1} \sum_{m=1}^M \mathbb{I}\{T(\mathbf{z}^m, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$
- (5) **多种统计量**：差值均值 $\hat{\tau}$ 、学生化 t 、Wilcoxon W 、KS D
- (6) **理论联系**：FRT 为传统 t 检验提供基础
- (7) **历史起源**：Lind 的坏血病实验、Fisher 的女士品茶

下一章我们将学习 Neymanian 推断——另一种基于渐近理论的方法，它可以更方便地构建置信区间。

13. 习题

练习 3.1. 3.1 — p_{frit} 的精确性 证明在 sharp null 下， p_{frit} 满足：

$$\mathbb{P}(p_{\text{frit}} \leq u) \leq u \quad \text{for all } 0 \leq u \leq 1.$$

¹³详细推导见附录 section 4

练习 3.2. 3.2 — Monte Carlo 误差 设 p_{ftr} 是固定值, $\hat{p}_{ftr}$ 是其 Monte Carlo 估计 (见 eq. (24))。证明:

$$\mathbb{E}_{mc}(\hat{p}_{ftr}) = p_{ftr}, \quad \text{var}_{mc}(\hat{p}_{ftr}) \leq \frac{1}{4R},$$

其中下标 "mc" 表示由于 Monte Carlo 的随机性。

练习 3.3. 3.3 — 有限样本有效的 Monte Carlo 近似 证明修正的 Monte Carlo 近似

$$\tilde{p}_{ftr} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

在任意有限的 R 下都是有限样本有效的 p 值。

提示: 可以利用以下两个基本概率结果:

- (1) 对于两个二项分布 $X_1 \sim \text{Binomial}(R, p_1)$ 和 $X_2 \sim \text{Binomial}(R, p_2)$, 若 $p_1 \geq p_2$, 则 $\mathbb{P}(X_1 \leq x) \leq \mathbb{P}(X_2 \leq x)$ 。
- (2) 若 $p \sim \text{Uniform}(0, 1)$ 且 $X | p \sim \text{Binomial}(R, p)$, 则 X 在 $\{0, 1, \dots, R\}$ 上均匀分布。

练习 3.4. 3.4 — Fisher 精确检验 考虑二元结局的 CRE, 数据汇总为 2×2 列联表:

	$Y = 1$	$Y = 0$	合计
$Z = 1$	n_{11}	n_{10}	n_1
$Z = 0$	n_{01}	n_{00}	n_0

在 H_{0F} 下, 证明任何检验统计量 $T(n_{11}, n_{10}, n_{01}, n_{00})$ 是 n_{11} 的函数, 且 n_{11} 的精确分布是超几何分布。请说明超几何分布的参数。

练习 3.5. 3.5 — 女士品茶详细计算 回忆女士品茶实验 (见 section 10)。计算 $\mathbb{P}(X = k)$, 其中 X 是女士正确识别 k 杯先加牛奶的茶个数, $k = 0, 1, 2, 3, 4$ 。

练习 3.6. 3.6 — 协变量调整的 FRT 使用 LaLonde 数据集 (见 section 9), 添加协变量进行 FRT 分析。假设所有潜在结果和协变量都是固定数值。

有两种策略:

- (1) 运行结局对协变量的线性回归, 得到残差 (即 "伪结局")。基于残差定义四种检验统计量, 进行 FRT 并报告 p 值。
- (2) 定义检验统计量为结局对治疗和协变量线性回归中治疗系数的 FRT。

解释为什么上述两种策略的五个 p 值都是有限样本精确的。

练习 3.7. 3.7 — FRT 与广义线性模型 使用与练习 3.6 相同的数据集, 但将结局改为 $re78 > 0$ 的二元指示变量。运行结局对治疗和协变量的 logistic 回归。治疗系数是否显著? FRT p 值是多少?

练习 3.8. 3.8 — 代数细节 验证 eq. (31)。

练习 3.9. 3.9 — 推荐阅读 ? 是一篇倡导在复杂实验中同时报告 p 值及其相应随机化分布的论文。

CHAPTER 4

Neymanian 重复抽样推断

1. 两种推断哲学的对话

在上一章中，我们遇到了费舍尔随机化检验 (Fisher's randomization test, FRT)。这种方法优雅而精确——它基于随机化的精确性质，在 sharp null 假设下给出精确的 p 值，无需任何分布假设。

然而，FRT 也有其内在局限。首先，它只能检验 **sharp null 假设** (即所有单元的个体因果效应为零)；对于更一般的 null 假设，FRT 无法处理。其次，当样本量增大时，枚举所有可能的置换变得计算上不可行——我们需要渐近近似。

更重要的是：从 Fisher 的视角来看，我们只能得到一个 p 值，却无法直接得到置信区间。而实际研究中，研究者往往更关心“因果效应有多大”而非“因果效应是否为零”。

一个自然的问题产生：能否有一种方法，既保持 Fisher 方法的无分布 (distribution-free) 精神，又能方便地构建置信区间？

Jerzy Neyman 在 1923 年的开创性工作中给出了一种互补的答案。他的方法基于**渐近正态分布**，直接对因果效应进行统计推断，既能得到 p 值，也能构建置信区间。这两种方法——Fisherian 的精确小样本推断与 Neymanian 的大样本渐近推断——代表了统计推断的两种哲学，深刻影响了现代因果推断的发展。

注 4.1. 为什么需要两种方法？：FRT 适用于小样本精确推断和假设检验，Neymanian 适用于大样本渐近推断和置信区间构建。两者互为补充。

2. 有限总体量

在 Neymanian 框架中，我们首先需要一套精确的记号来描述**有限总体**——这是 Neyman 与 Fisher 共同面对的研究对象。

考虑一个包含 n 个单元的有限总体。记 n_1 个单元被分配到治疗组， $n_0 = n - n_1$ 个单元被分配到对照组。对于每个单元 $i = 1, \dots, n$ ，我们定义：

- $Y_i(1)$ ：单元 i 接受治疗后的潜在结果
- $Y_i(0)$ ：单元 i 接受对照后的潜在结果
- $\tau_i = Y_i(1) - Y_i(0)$ ：单元 i 的个体因果效应

这些潜在结果都是**固定的数值**——它们不依赖于我们实际做什么选择，只是“潜在”地存在。

有限总体均值：

$$\bar{Y}(1) = \frac{1}{n} \sum_{i=1}^n Y_i(1), \quad \bar{Y}(0) = \frac{1}{n} \sum_{i=1}^n Y_i(0)$$

有限总体方差 (使用 $n - 1$ 作为除数)：

$$S^2(1) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2, \quad S^2(0) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$$

有限总体协方差：

$$S(1, 0) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\} \{Y_i(0) - \bar{Y}(0)\}$$

平均因果效应：

$$\tau = \frac{1}{n} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$$

这是我们要估计的核心参数。

个体效应的方差：

$$S^2(\tau) = \frac{1}{n-1} \sum_{i=1}^n (\tau_i - \tau)^2$$

衡量治疗效应在单元间的异质性程度。

注 4.2. **为什么需要协方差？** $Y(1)$ 和 $Y(0)$ 之间可能有相关性。若治疗组和对照组的个体是匹配的（正相关），估计的方差会减小；若是负相关，方差会增大。

3. 一个关键引理

在有限总体量的世界中，有一个优雅的关系连接了协方差与各个方差。这个恒等式虽然简单，却贯穿整个 Neymanian 推断框架。

引理 4.1 (Lemma 4.1 — 方差与协方差的关系)。

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$$

其中 $\tau_i = Y_i(1) - Y_i(0)$ 是个体因果效应。

直觉理解： 如果所有单元的治疗效应都相同 ($S^2(\tau) = 0$)，则 $Y_i(1)$ 和 $Y_i(0)$ 完全线性相关（相差一个常数），此时 $S(1, 0)$ 达到最大值 $[S^2(1) + S^2(0)]/2$ 。

推论： 当 $S^2(\tau) > 0$ 时， $2S(1, 0) < S^2(1) + S^2(0)$ ，即协方差小于两个方差之和的一半。这个引理的证明是直接的代数运算。¹

4. Neyman (1923) 定理

基于观测结果，我们可以计算样本均值：

$$\hat{Y}(1) = \frac{1}{n_1} \sum_{i=1}^n Z_i Y_i, \quad \hat{Y}(0) = \frac{1}{n_0} \sum_{i=1}^n (1 - Z_i) Y_i$$

其中 $Z_i \in \{0, 1\}$ 是治疗分配指示变量。

样本方差：

$$\hat{S}^2(1) = \frac{1}{n_1 - 1} \sum_{i=1}^n Z_i \{Y_i - \hat{Y}(1)\}^2, \quad \hat{S}^2(0) = \frac{1}{n_0 - 1} \sum_{i=1}^n (1 - Z_i) \{Y_i - \hat{Y}(0)\}^2$$

一个基本事实： 不存在 $S(1, 0)$ 和 $S^2(\tau)$ 的“样本版本”。这是因为对于每个单元，我们最多只能观测到 $Y_i(1)$ 或 $Y_i(0)$ 中的一个——两者从未同时被观测到。

现在陈述 Neyman 的核心定理：

定理 4.2 (Neyman (1923) 定理). 在完全随机化实验 (CRE) 下，令 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ 。则：

¹详见附录 section 1。

(1) **无偏性**: $\hat{\tau}$ 对 τ 是无偏的:

$$\mathbb{E}(\hat{\tau}) = \tau$$

(2) **方差公式**: $\hat{\tau}$ 的方差为

$$\begin{aligned} (40) \quad \text{var}(\hat{\tau}) &= \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} \\ (41) \quad &= \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0) \end{aligned}$$

(3) **保守方差估计**: 方差估计量

$$\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$$

对 $\text{var}(\hat{\tau})$ 是保守的, 即

$$\mathbb{E}(\hat{V}) - \text{var}(\hat{\tau}) = \frac{S^2(\tau)}{n} \geq 0$$

等号当且仅当 $\tau_i \equiv \tau$ (所有单元个体效应恒定) 时成立。

关于期望和方差的含义: 这里所有潜在结果 $\{Y_i(1), Y_i(0)\}$ 都是固定数值。随机性仅来自治疗分配 Z_i ——即 n_1 个 1 和 n_0 个 0 的所有可能排列构成的集合。

注 4.3. 第三项为什么是减项?: 直觉上: 若个体因果效应存在变异 ($S^2(\tau) > 0$), 治疗组和对照组之间的差异不仅来自随机抽样误差, 还来自因果效应本身的真实变异。这种“真实变异”不应被算作估计误差。

5. 方差公式的深入理解

方差公式 eq. (40) 与经典两样本问题中的方差公式不同, 因为它还依赖于个体效应的方差 $S^2(\tau)$ 。

一个令人困惑的现象: 个体效应越异质, $\hat{\tau}$ 的方差反而越小。为什么?

从等价格式 eq. (41) 理解: 考虑潜在结果之间的相关性。

假设在一次实现中, 我们观察到相对较大的治疗潜在结果 $\{Y_i(1)\}$:

- 若 $S(1, 0) > 0$ (正相关), 则那些接受治疗的单元也有相对较大的对照潜在结果。因此, 对照下的观测结果相对较小, 导致较大的 $\hat{\tau}$
- 若 $S(1, 0) < 0$ (负相关), 则那些接受治疗的单元有相对较小的对照潜在结果。因此, 对照下的观测结果相对较大, 导致较小的 $\hat{\tau}$

当潜在结果正相关时, 更可能观察到极端的 $\hat{\tau}$, 因此方差更大。

推论: 当 $S^2(\tau) = 0$ 时, eq. (40) 简化为 $\text{var}(\hat{\tau}) = S^2(1)/n_1 + S^2(0)/n_0$ ——此时 Neymanian 方差与经典两样本方差一致。

6. Neyman (1923) 定理的证明

无偏性: ²

方差证明: ³

方差估计的期望: ⁴

²推导详见附录 ??。

³推导详见附录 ??。

⁴推导详见附录 ??。

7. 渐近正态性与置信区间

Neyman (1923) 定理给出了方差的精确表达式，但它是相对于随机分配的分布而言的。在实际应用中，我们还需要知道 $\hat{\tau}$ 的抽样分布形状。

定理 4.3 (有限总体 CLT). 令 $n \rightarrow \infty$ 和 $n_1 \rightarrow \infty$ 。假设：

- (1) n_1/n 趋向于 $(0, 1)$ 中的常数 p
- (2) $\{S^2(1), S^2(0), S(1, 0)\}$ 有有限极限
- (3) $\max_i |Y_i(1) - \bar{Y}(1)|^2/n \rightarrow 0$ 且 $\max_i |Y_i(0) - \bar{Y}(0)|^2/n \rightarrow 0$ (Lindeberg 条件)

则

$$\frac{\hat{\tau} - \tau}{\sqrt{\text{var}(\hat{\tau})}} \xrightarrow{d} N(0, 1)$$

且 $\hat{S}^2(1) \rightarrow S^2(1)$, $\hat{S}^2(0) \rightarrow S^2(0)$ (依概率)。

这个定理意味着：当样本量足够大时， $\hat{\tau}$ 的抽样分布可以用正态分布近似。这为构建置信区间提供了理论基础。

置信区间：由定义 4.3 和 Neyman 定理的第三部分，我们得到 τ 的保守大样本置信区间：

$$\hat{\tau} \pm z_{1-\alpha/2} \sqrt{\hat{V}}$$

其中 $z_{1-\alpha/2}$ 是标准正态分布的 $1 - \alpha/2$ 分位数。

与弱零假设的对偶性：通过置信区间与假设检验的对偶性，这也为检验

$$H_0 : \tau = 0$$

(称为**弱零假设**，区别于 Fisher 的 sharp null) 提供了渐近基础。

注 4.4. **为什么 Neymanian 方法只给“弱零假设”的检验？**：因为在 Neymanian 框架中，我们无法观测到 $S^2(\tau)$ ，无法精确计算方差。置信区间和检验都是渐近有效的。

8. Neymanian 推断与 OLS 的关系

实践中，许多研究者使用回归方法来估计平均因果效应。标准做法是运行 OLS 回归：

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{(a,b)} \sum_{i=1}^n (Y_i - a - bZ_i)^2$$

并使用 treatment 系数估计量 $\hat{\beta}$ 作为 τ 的估计。

关键发现：OLS 系数 $\hat{\beta}$ 恰好等于差值均值：

$$(42) \quad \hat{\beta} = \hat{\tau}$$

5

但是，OLS 的通常方差估计量与 $\hat{V}$ 不同。标准 OLS 方差估计量为：

$$(43) \quad \hat{V}_{\text{OLS}} = \frac{n(n_1 - 1)}{(n - 2)n_1n_0} \hat{S}^2(1) + \frac{n(n_0 - 1)}{(n - 2)n_1n_0} \hat{S}^2(0)$$

稳健标准误：幸运的是，Eicker-Huber-White (EHW) 稳健方差估计量：

$$(44) \quad \hat{V}_{\text{EHW}} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1 - 1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0 - 1}{n_0}$$

⁵证明详见附录 ??。

接近 $\hat{V}$ 。特别地，HC2 变体恰好等于 $\hat{V}$ 。⁶

实证演示 (LaLonde 数据):

```
> tauhat = mean(y[z==1]) - mean(y[z==0])
> vhat    = var(y[z==1])/n1 + var(y[z==0])/n0
> sehat   = sqrt(vhat)
> tauhat
[1] 1794.343
> sehat
[1] 670.9967
```

OLS 的通常标准误偏小:

```
> olsfit = lm(y ~ z)
> summary(olsfit)$coef[2, 1:2]
Estimate Std. Error
1794.3431    632.8536
```

使用 EHW 稳健标准误 (HC2) 得到正确结果:

```
> sqrt(hccm(olsfit, type = "hc2")[2, 2])
[1] 670.9967
```

9. 重尾结局与正态近似的失效

定义 4.3 中的有限总体 CLT 在某些正则条件下成立。当潜在结局为重尾分布时，这些条件可能被违反。

当对照潜在结果被污染时 (例如 Cauchy 分布)，正态近似效果很差。模拟研究表明，在重尾情况下，直方图和正态近似之间存在显著差异。

这提醒我们：所有基于渐近正态性的推断方法都依赖于数据的有限矩条件。在实际应用中，我们应该检查结局变量的分布特征。

10. 本章小结

本章建立了 Neymanian 推断的基础:

(1) **有限总体量** (不带 hat 的真实值): $\{\bar{Y}(1), \bar{Y}(0), S^2(1), S^2(0), S(1, 0), S^2(\tau)\}$

(2) **Lemma 4.1**: $2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$

(3) **Neyman (1923) 定理**:

- $\mathbb{E}(\hat{\tau}) = \tau$ (无偏)
- $\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- $\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau}) + \frac{S^2(\tau)}{n}$ (保守)

(4) **方差估计**: $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$

(5) **置信区间**: $\hat{\tau} \pm z_{1-\alpha/2} \sqrt{\hat{V}}$

(6) **CLT**: $\frac{\hat{\tau} - \tau}{\sqrt{\text{var}(\hat{\tau})}} \xrightarrow{d} N(0, 1)$

(7) **OLS 关系**: $\hat{\beta} = \hat{\tau}$, 但需使用 EHW 稳健标准误

下一章我们将学习如何通过**分层 (stratification)** 来提高估计的精度——这是一种利用协变量信息来改进推断的方法。

⁶详见附录 ??。

11. 习题

练习 4.1. 4.1 引理的证明 证明 Lemma 4.1: $2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)$ 。

练习 4.2. 4.2 Neyman (1923) 定理的另一种证明 在 CRE 下, 计算:

$$\text{var}\{\hat{Y}(1)\}, \quad \text{var}\{\hat{Y}(0)\}, \quad \text{cov}\{\hat{Y}(1), \hat{Y}(0)\}$$

并利用这些公式推导 $\text{var}(\hat{\tau})$ 。

练习 4.3. 4.3 Neymanian 推断与 OLS 证明 eq. (42) (OLS 系数等于差值均值)。证明 EHW 稳健方差估计量的 HC2 变体恰好等于 $\hat{V}$ 。

推导见附录 ??。

练习 4.4. 4.4 治疗效应的异质性 证明 $S^2(\tau) = 0$ 蕴含 $S^2(1) = S^2(0)$ 。给出反例说明 $S^2(1) = S^2(0)$ 但 $S^2(\tau) \neq 0$ 。

证明 $S^2(1) < S^2(0)$ 蕴含 $S(Y(0), \tau) < 0$ 。给出反例说明 $S^2(1) > S^2(0)$ 但 $S(Y(0), \tau) < 0$ 。

练习 4.5. 4.5 方差公式的改进上界 证明方差公式的改进上界:

$$\text{var}(\hat{\tau}) \leq \frac{1}{n} \left\{ \sqrt{\frac{n_0}{n_1}} S(1) + \sqrt{\frac{n_1}{n_0}} S(0) \right\}^2$$

并讨论等号成立的条件。

练习 4.6. 4.6 Neyman (1923) 的向量版本 将 Neyman (1923) 的结果推广到多结局情形。考虑向量结局 $\mathbf{V} \in \mathbb{R}^K$ 的平均因果效应:

$$\tau_{\mathbf{V}} = \frac{1}{n} \sum_{i=1}^n \{\mathbf{V}_i(1) - \mathbf{V}_i(0)\}$$

证明 $\hat{\tau}_{\mathbf{V}}$ 对 $\tau_{\mathbf{V}}$ 是无偏的, 并求出其协方差矩阵。

练习 4.7. 4.7 完全随机化实验中的推断 回忆在定义 3.1 中定义的完全随机化实验。在这种设定下, 推导平均因果效应的方差公式, 并比较其与 CRE 中方差的差异。

练习 4.8. 4.8 推荐阅读 **推荐阅读:** ? 重新审视了因果推断中的一些经典问题。? 是关于因果推断的权威综述。

历史注记: Neyman 1923 年的原始论文 ? 奠定了有限总体推断的基础。当代统计学家将其视为因果推断范式的里程碑。

分层与后分层随机实验

1. 引言：随机化的艺术

“Block what you can and randomize what you cannot.” — [?, page 103]

这是 George Box 继“所有模型都是错的，但有些有用”之后第二著名的名言。本章将解释它的含义。

在第 4 章的完全随机实验 (CRE) 中，治疗分配完全由 chance 决定。这种设计在大样本下表现优异，但在一个有限实验中，治疗组和对照组可能在某些协变量上出现不平衡。这种现象在统计文献中被称为 **covariate imbalance** (协变量不平衡)。

为什么 covariate imbalance 令人担忧？因为它会使实验结果的解释变得困难——我们观察到的结果差异可能归因于 treatment 的效果，也可能仅仅是由于协变量分布不均造成的。这个问题促使我们思考：能否在设计阶段就主动控制这种不平衡？

分层随机实验 (Stratified Randomized Experiment, SRE) 正是为了解决这个问题而设计的。

2. SRE 的定义与记号

考虑一个包含 n 个单元的有限总体，协变量 $X_i \in \{1, \dots, K\}$ 是离散的。记

$$n_{[k]} = \#\{i : X_i = k\}, \quad \pi_{[k]} = n_{[k]}/n$$

分别为第 k 层的单元数和比例 ($k = 1, \dots, K$)。

在 CRE 中，我们固定总的 n_1 和 n_0 ，但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。即使在 CRE 中，各层治疗组和对照组比例之差的期望为零：¹

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0, \quad \text{但} \quad \frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \neq 0 \text{ 以高概率成立.}$$

直观理解：期望为零说明随机化保证了渐近公平性，但有限样本中的随机波动可能导致显著的不平衡。这个观察促使我们思考：能否在设计阶段就主动控制这种不平衡？

定义 5.1 (分层随机实验 (SRE)). 固定 $n_{[k]1}$ 或 $n_{[k]0}$ ($k = 1, \dots, K$)，在离散的协变量 X 的每一层内独立进行 CRE。

在农业实验中，这种设计被称为**随机区组设计 (randomized block design)**，各层称为区组 (blocks)。类似地，分层随机化也称为 block randomization。

层别倾向得分 (stratum propensity score)：

$$e_{[k]} = \frac{n_{[k]1}}{n_{[k]}}.$$

这个概念将在第 ?? 章讨论观测性研究时扮演核心角色。

SRE 与 CRE 的关键区别在于：

- (1) SRE 的所有可行随机化集合是 CRE 的可行随机化集合的子集；

¹推导见附录 ??

(2) 在 SRE 中 $e_{[k]}$ 是固定的，但在 CRE 中是随机的。

3. 层别平均因果效应

对于单元 i ，我们有潜在结果 $Y_i(1)$ 和 $Y_i(0)$ ，个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 。第 k 层的层别平均因果效应为：

$$\tau_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} \tau_i.$$

总体平均因果效应是各层别平均因果效应的加权平均：

$$\tau = n^{-1} \sum_{i=1}^n \tau_i = \sum_{k=1}^K \pi_{[k]} \tau_{[k]}.$$

基于各层的差值均值，我们可以构造 τ 的分层估计量：

$$\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]},$$

其中

$$\hat{\tau}_{[k]} = n_{[k]1}^{-1} \sum_{i=1}^n \mathbb{I}(X_i = k, Z_i = 1) Y_i - n_{[k]0}^{-1} \sum_{i=1}^n \mathbb{I}(X_i = k, Z_i = 0) Y_i$$

是第 k 层内治疗组和对照组结果均值之差。

如果我们关心 $\tau_{[k]}$ ，可以在第 k 层内使用 CRE 的方法进行推断。下面讨论对 τ 的统计推断。

4. SRE 中的 Fisher 随机化检验

与 CRE 类似，我们首先讨论 SRE 中的 Fisher 随机化检验 (FRT)。Sharp null 假设仍然是：

$$H_{0F} : Y_i(1) = Y_i(0) \text{ 对所有单元 } i = 1, \dots, n.$$

FRT 的基本思想适用于任何随机实验：我们可以用任何检验统计量 $T = T(\mathbf{Z}, \mathbf{Y}, \mathbf{X})$ ，其中 $\mathbf{Z}, \mathbf{Y}, \mathbf{X}$ 分别是治疗向量、观测结果向量和协变量矩阵。在 SRE 和 H_{0F} 下， T 具有已知分布，因为 $\mathbf{Z}$ 在 SRE 下有已知分布。

使用 FRT 时有两个关键细节需要注意：

- (1) 当模拟治疗向量时，必须根据定义 5.1 在 X 的各层内对治疗指标进行置换（这被称为**条件随机化检验**或**条件置换检验**）；
- (2) 应选择能够反映 SRE 本质的检验统计量。

4.1. 检验统计量的选择.

4.1.1. 分层差值均值估计量. 受 section 3 的启发，我们可以在 FRT 中使用分层估计量 $\hat{\tau}_{\text{SRE}}$ 作为检验统计量。

例 5.1 (section 3 的具体应用). 在 FRT 中，我们可以使用分层估计量作为检验统计量：

$$T = \hat{\tau}_S = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]},$$

其中 $\hat{\tau}_{[k]}$ 由 section 3 定义。这个统计量直接衡量了跨层的平均因果效应。

4.1.2. 学生化分层估计量. 受简单两样本问题中学生化统计量的启发, 我们可以在 FRT 中使用以下学生化统计量:

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}},$$

其中

$$\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right).$$

这里 $\hat{S}_{[k]}^2(1)$ 和 $\hat{S}_{[k]}^2(0)$ 分别是治疗组和对照组结果在第 k 层内的样本方差。²

例 5.2 (学生化分层统计量的应用). 对于 section 4.1.2 中的学生化统计量 t_{SRE} , 我们需要计算其方差估计量 $\hat{V}_{\text{SRE}}$ (由 section 4.1.2 给出)。在 FRT 中, 我们通过模拟所有可行的 *treatment* 分配来计算 t_{SRE} 的精确分布。

4.1.3. 合并 Wilcoxon 秩和统计量. 我们首先在第 k 层内计算 Wilcoxon 秩和统计量 $W_{[k]}$, 然后合并为:

$$W_{\text{SRE}} = \sum_{k=1}^K c_{[k]} W_{[k]}.$$

? 提出了两种加权方法: 一种使用 $c_{[k]} = 1/(n_{[k]1}n_{[k]0})$, 另一种使用 $c_{[k]} = 1/(n_{[k]} + 1)$ 。

例 5.3 (Van Elteren 统计量的应用). 在第 k 层内, 我们计算 Wilcoxon 秩和统计量 $W_{[k]}$ (回忆第 4 章的 Wilcoxon 秩和检验), 然后使用 section 4.1.3 合并各层统计量。Van Elteren (1960) 的两种加权方法在不同场景下各有优势。

4.1.4. Hodges–Lehmann 对齐秩统计量. Van Elteren (1960) 的统计量在层数较少且各层样本量较大时表现良好。但当层数很多且各层样本量较小时, 它不能进行足够多的比较, 可能丢失数据中的信息。? 提出了一种在对齐后进行更多跨层比较的检验统计量。

他们首先将结果中心化:

$$\tilde{Y}_i = Y_i - \bar{Y}_{[k]}, \quad \text{若 } X_i = k,$$

其中 $\bar{Y}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} Y_i$ 是第 k 层内的层别均值。然后获得池化结果 $(\tilde{Y}_1, \dots, \tilde{Y}_n)$ 的秩 $(\tilde{R}_1, \dots, \tilde{R}_n)$, 最后构建检验统计量:

$$\tilde{W} = \sum_{i=1}^n Z_i \tilde{R}_i.$$

例 5.4 (Hodges–Lehmann 对齐秩统计量). ? 的方法首先通过 section 4.1.4 对齐结果, 这消除了层间差异的影响。然后对池化结果求秩, 并使用 section 4.1.4 作为检验统计量。这种方法在多个小层情况下特别有效。

²式 section 4.1.2 和 section 4.1.2 的期望和方差推导见附录 ??。

4.1.5. *Kolmogorov-Smirnov* 统计量. 我们计算 $D_{[k]}$, 即第 k 层内治疗组和对照组结果的经验分布函数之间的最大差距. 最终的检验统计量可以是:

$$D_{\text{SRE}} = \sum_{k=1}^K c_{[k]} D_{[k]}, \quad \text{或} \quad D_{\max} = \max_{1 \leq k \leq K} c_{[k]} D_{[k]},$$

其中 $c_{[k]} = \sqrt{n_{[k]1}n_{[k]0}/n_{[k]}}$.

另一个合理的选择是:

$$D = \max_y \left| \sum_{k=1}^K \pi_{[k]} \{ \hat{F}_{[k]1}(y) - \hat{F}_{[k]0}(y) \} \right|,$$

其中 $\hat{F}_{[k]1}(y)$ 和 $\hat{F}_{[k]0}(y)$ 分别是治疗组和对照组结果在第 k 层内的经验分布函数. 统计量 D 在大层和小层情况下都适用.

例 5.5 (*Kolmogorov-Smirnov* 统计量的应用). *section 4.1.5* 中的 D_{SRE} 和 $D_{\max}$ 更适合所有层样本量都较大的情况, 而 *section 4.1.5* 中的 D 则在同时存在大小层的情况下更为稳健.

5. Neymanian 推断

5.1. 点估计与区间估计. SRE 的统计推断建立在一个事实之上: 它本质上由 K 个独立的 CRE 组成. 基于此, 我们可以将 Neyman (1923) 的结果推广到 SRE.

在第 k 层内, 差值均值 $\hat{\tau}_{[k]}$ 是 $\tau_{[k]}$ 的无偏估计, 其方差为:³

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}},$$

其中 $S_{[k]}^2(1), S_{[k]}^2(0), S_{[k]}^2(\tau)$ 分别是潜在结果和个体因果效应在第 k 层内的方差.

因此, 分层估计量 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 是 τ 的无偏估计, 方差为:⁴

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

如果 $n_{[k]1} \geq 2$ 且 $n_{[k]0} \geq 2$, 我们可以获得第 k 层内治疗组和对照组结果的样本方差 $\hat{S}_{[k]}^2(1)$ 和 $\hat{S}_{[k]}^2(0)$, 并构建一个保守方差估计量:

$$\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right).$$

基于 $\hat{\tau}_{\text{SRE}}$ 的正态近似, 我们可以构建 τ 的 Wald 型 $1 - \alpha$ 置信区间:

$$\hat{\tau}_{\text{SRE}} \pm z_{1-\alpha/2} \sqrt{\hat{V}_{\text{SRE}}}.$$

从假设检验的角度, 在 $H_{0N} : \tau = 0$ 下, 我们可以将 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 与标准正态分位数进行比较, 得到渐近 p 值.

³推导见附录 ??

⁴推导见附录 ??

6. SRE 与 CRE 的效率比较

与 CRE 相比, SRE 有什么好处? 我们从 covariate balance 的角度引入了 SRE。此外, 更好的 covariate balance 会带来更好的平均因果效应估计精度。

为了进行公平比较, 我们假设 $e_{[k]} = e$ (对所有 k), 这保证了:⁵

$$\hat{\tau} = \hat{\tau}_{\text{SRE}}.$$

我们比较抽样方差。方差分析技术启发了将总方差分解为层内方差和层间方差之和:

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \left[\frac{n_{[k]}-1}{n-1} S_{[k]}^2(1) + \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 \right], \end{aligned}$$

类似地,

$$\begin{aligned} S^2(0) &= \sum_{k=1}^K \left[\frac{n_{[k]}-1}{n-1} S_{[k]}^2(0) + \frac{n_{[k]}}{n-1} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 \right], \\ S^2(\tau) &= \sum_{k=1}^K \left[\frac{n_{[k]}-1}{n-1} S_{[k]}^2(\tau) + \frac{n_{[k]}}{n-1} \{\tau_{[k]} - \tau\}^2 \right]. \end{aligned}$$

CRE 下差值均值估计量的方差分解为:⁶

$$\begin{aligned} \text{var}_{\text{CRE}}(\hat{\tau}) &= \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} \\ &= \underbrace{\sum_{k=1}^K \left[\frac{\pi_{[k]}}{n_1} S_{[k]}^2(1) + \frac{\pi_{[k]}}{n_0} S_{[k]}^2(0) - \frac{\pi_{[k]}}{n} S_{[k]}^2(\tau) \right]}_{\text{与 SRE 相同}} \\ &\quad + \underbrace{\sum_{k=1}^K \left[\frac{\pi_{[k]}}{n_1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{\pi_{[k]}}{n_0} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{\pi_{[k]}}{n} (\tau_{[k]} - \tau)^2 \right]}_{\text{SRE 消除的项}}. \end{aligned}$$

当层样本量较大时, $\text{var}_{\text{CRE}}(\hat{\tau})$ 与 $\text{var}_{\text{SRE}}(\hat{\tau}_{\text{SRE}})$ 之差约为:⁷

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

这个差值是非负的, 当且仅当

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

对 $k = 1, \dots, K$ 都成立时才为零。当协变量能预测潜在结果时, 上述量通常不全为零, 这保证了 SRE 相对于 CRE 的效率增益。

⁵推导见附录 ??

⁶完整推导见附录 ??

⁷推导见附录 ??

7. CRE 中的后分层

在具有离散协变量 X 的 CRE 中，第 k 层内接受治疗和对照的单元数是随机的。在 SRE 中，这些数字是固定的。但如果我们在给定 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下进行条件推断，那么 CRE 就变成了 SRE。

数学上，如果 $\mathbf{n}$ 的所有分量都不为零，那么：⁸

$$\Pr_{\text{CRE}}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{\text{CRE}}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{\text{CRE}}(\mathbf{n})} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

即， $\mathbf{Z}$ 在给定 $\mathbf{n}$ 条件下从 CRE 得到的条件分布与从 SRE 得到的分布相同。

因此，在给定 $\mathbf{n}$ 的条件下，我们可以像分析 SRE 一样分析带有离散协变量 X 的 CRE。FRT 变为**条件 FRT**，Neymanian 分析变为**后分层 (post-stratification)**：

$$\hat{\tau}_{\text{PS}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}.$$

其形式与 $\hat{\tau}_{\text{SRE}}$ 相同。

分层在设计阶段使用 X ，后分层在分析阶段使用 X 。它们是使用 X 的对偶方法。

8. 实践中的问题

如何选择 X 来构建 SRE？理论上， X 应该能预测潜在结果。在某些情况下，实验者根据先导研究等对预测协变量有足够的背景知识，那么 X 的选择可以直接确定。在其他情况下，这种背景知识不够清晰，实验者反而根据方便性选择 X ——例如， X 可以是研究区域的指示变量或学生年级。

K 的选择是一个相关问题。理论上，如果所有层都足够大，增加 K 会提高估计效率。然而，极端大的 K 甚至可能降低估计效率。在模拟研究中，我们观察到增加 K 的边际收益递减。经验上， $K = 5$ 通常足以获得效率增益。

多维连续协变量怎么办？如果我们有先导研究，可以建立给定这些协变量时潜在结果 $Y(0)$ 的模型，然后选择 X 为预测量 $\hat{Y}(0)$ 的离散化版本。一般地，如果我们没有这样的先导研究或者不想做特设的离散化，我们可以使用一种更通用的策略，称为**重随机化 (rerandomization)**。

9. 本章小结

本章介绍了分层与后分层随机实验，主要内容如下：

- (1) **SRE 的动机**：CRE 可能产生不期望的治疗分配，通过分层可以主动避免 covariate imbalance。
- (2) **SRE 定义 (定义 5.1)**：在离散协变量的各层内独立进行 CRE，固定各层的治疗分配数量。
- (3) **效率增益**：当协变量能预测潜在结果时，SRE 比 CRE 更有效，因为分层消除了层间变异（见 section 6）。
- (4) **FRT 和 Neymanian 推断**：都可以推广到 SRE，分别在 section 4 和 section 5 中讨论。
- (5) **后分层**：CRE 中给定分层数量条件后，分析方法与 SRE 相同——这是使用协变量的对偶方法。

⁸证明见附录 ??

10. 习题

练习 5.1. CRE 中的协变量平衡 证明 section 2: 在 CRE 下,

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0.$$

练习 5.2. 常数层别倾向得分的结果 证明 section 6: 当所有层的层别倾向得分相等 $e_{[k]} = e$ (对所有 k) 时,

$$\hat{\tau} = \hat{\tau}_{SRE}.$$

练习 5.3. 常数个体因果效应的后果 假设个体因果效应是常数 $\tau_i = \tau$ (对所有 $i = 1, \dots, n$)。考虑以下 τ 的加权估计量类:

$$\hat{\tau}_w = \sum_{k=1}^K w_{[k]} \hat{\tau}_{[k]},$$

其中权重 $w_{[k]}$ 对所有 k 非负。

(1) 找出使 $\hat{\tau}_w$ 对 τ 无偏的 $w_{[k]}$ 条件。

(2) 在所有无偏估计量中, 找出使 $\hat{\tau}_w$ 方差最小的权重。

练习 5.4. 比较 CRE 和 SRE 证明 section 6: 当层样本量较大时, $\text{var}_{CRE}(\hat{\tau})$ 与 $\text{var}_{SRE}(\hat{\tau}_{SRE})$ 之差约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{ \bar{Y}_{[k]}(1) - \bar{Y}(1) \} + \sqrt{\frac{n_1}{n_0}} \{ \bar{Y}_{[k]}(0) - \bar{Y}(0) \} \right\}^2 \geq 0.$$

练习 5.5. 从 CRE 到 SRE 证明 section 7: 数学上, 如果 $\mathbf{n}$ 的所有分量都不为零, 那么

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

即, $\mathbf{Z}$ 在给定 $\mathbf{n}$ 条件下从 CRE 得到的条件分布与从 SRE 得到的分布相同。

练习 5.6. 更多 FRT 统计量 在 section 4.1 中, 我们介绍了多种检验统计量。选择另一种统计量 (如 Wilcoxon 秩和统计量或 Hodges-Lehmann 对齐秩统计量), 重新进行 FRT 分析。

练习 5.7. Imbens and Rubin (2015) 中的 SRE 的 FRT Imbens and Rubin (2015) 讨论了 1985-1986 年在田纳西州进行的 SRE (Student/Teacher Achievement Ratio 实验)。kindergarten 数据如下:

层对应于学校, 分析单元是教师或班级。treatment 等于 1 表示小班 (每教师 13-17 名学生), 等于 0 表示普通班 (22-25 名学生)。outcome 是标准化的平均数学成绩。

使用 FRT 重新分析 Project STAR 数据。使用 $\hat{\tau}_{SRE}$ 、 W_{SRE} 和 $\tilde{W}$ 作为 FRT 的检验统计量。比较 p 值。

注: 本书使用 Z 表示治疗指示变量, 但 Imbens and Rubin (2015) 使用 W 。

练习 5.8. 多中心试验 Gould (1998, Table 1) 报告了以下来自多中心试验的数据:

这是一个以中心为层的 SRE。该试验旨在研究非那雄胺 (用于治疗良性前列腺增生的药物) 的疗效和耐受性。在每个中心的 29 个中心内, 患者被随机分配到三个组: 对照组、非那雄胺 1mg 和非那雄胺 5mg。

由于没有报告个体水平的数据, 我们无法实施 FRT。然而, Neymanian 推断只需要汇总统计。分别报告非那雄胺 1mg 和非那雄胺 5mg 与对照组比较的点估计量和方差估计。

练习 5.9. 数据分析重新分析 重新分析第 4 章 ?? 节中使用的 *LaLonde* 数据。同时进行 *Fisherian* 和 *Neymanian* 推断。

回归调整与协变量平衡

1. 引言：从分层到连续协变量

在第 5 章中，我们遇到了分层随机实验 (SRE)。这种设计通过在离散的协变量（如性别、年龄段）上分层，在**设计阶段**主动控制协变量不平衡。

然而，现实中的协变量往往是连续的——think of 身高、体重、血压、基线考试成绩。这些连续型协变量无法简单地离散化为有限个层，否则会遇到“维数灾难”：层数指数增长，每层样本量急剧减少。

一个自然的问题产生：当协变量是连续的多维向量时，我们如何在保持随机化优点的同时，利用这些协变量来提高估计效率？

本章将介绍两种互补的策略：

- (1) **重随机化 (Rerandomization, ReM)**：在设计阶段使用 Mahalanobis 距离控制协变量不平衡
- (2) **回归调整 (Regression Adjustment)**：在分析阶段利用线性模型调整协变量不平衡

这两种策略可以在设计阶段与分析阶段分别使用，也可以在同一实验中联合使用 (section 7)。

2. 重随机化：设计阶段的协变量平衡

2.1. 问题起源：Cox (1982) 的洞见。考虑一个包含 n 个单元的有限总体，协变量矩阵 $\mathbf{X} \in \mathbb{R}^{n \times K}$ 是固定的。每个单元 i 的协变量向量为 $X_i \in \mathbb{R}^K$ ，可以包含连续或二元分量。为简化记号，将协变量中心化至均值零： $\bar{X} = n^{-1} \sum_{i=1}^n X_i = 0$ 。

在完全随机实验 (CRE) 中，治疗向量 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 从所有满足 $\sum Z_i = n_1$ 的向量中均匀抽取。随机化保证了协变量在治疗组和对照组之间的**期望平衡**，但无法保证有限样本中的**实现平衡**。

我们用治疗组和对照组协变量均值之差来衡量不平衡程度：

$$\hat{\tau}_X = n_1^{-1} \sum_{i=1}^n Z_i X_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) X_i.$$

在 CRE 下， $\mathbb{E}(\hat{\tau}_X) = 0$ ，但 $\hat{\tau}_X$ 的实现值往往不为零。使用 Neyman (1923) 的向量形式记号，可以证明：¹

$$\text{cov}(\hat{\tau}_X) = \frac{n}{n_1 n_0} S_X^2,$$

其中 $S_X^2 = (n-1)^{-1} \sum_{i=1}^n X_i X_i^\top$ 是协变量的有限总体协方差矩阵。

¹详细推导见附录 section 11.1

2.2. Mahalanobis 距离. 为了综合衡量 K 维协变量的不平衡程度, ReM 使用 Mahalanobis 距离:

$$M = \hat{\tau}_X^\top \text{cov}(\hat{\tau}_X)^{-1} \hat{\tau}_X = \hat{\tau}_X^\top \left(\frac{n}{n_1 n_0} S_X^2 \right)^{-1} \hat{\tau}_X.$$

Mahalanobis 距离的一个优美性质是它对协变量的非奇异线性变换保持不变。

引理 6.1 (引理 6.1 — Mahalanobis 距离的不变性). 式 section 2.2 中的 M 在变换 $X_i \mapsto b_0 + BX_i$ (其中 $b_0 \in \mathbb{R}^K$, $B \in \mathbb{R}^{K \times K}$ 可逆) 下保持不变。

为什么这个性质重要? 因为它意味着在使用 Mahalanobis 距离时, 我们不必担心协变量的量纲问题——无论是用米还是厘米, 用摄氏度还是华氏度, M 的数值都不会改变。

有限总体中心极限定理 (Li and Ding, 2017) 保证: 当 n 足够大时, 在 CRE 下 M 近似服从 χ_K^2 分布, 渐近期望为 K , 方差为 $2K$ 。因此, 在 CRE 下 M 的实现值很可能很大。

重随机化的核心思想是: **拒绝那些协变量不平衡的治疗分配。**

2.3. ReM 的正式定义.

定义 6.2 (重随机化 (ReM)). 从 CRE 中抽取治疗向量 $\mathbf{Z}$, 当且仅当 $M \leq a$ 时接受, 其中 $a > 0$ 是预定阈值。

阈值 a 的选择类似于 SRE 中层数的选择——这是一个在实践中非平凡的问题。当 $a = \infty$ 时, ReM 退化为普通 CRE; 当 $a = 0$ 时, 只有极少数可行的治疗分配, 实验几乎没有随机性。折中方案是选择一个小但不极小的 a , 例如取 χ_K^2 分布的上分位数 (如 0.001 分位数)。

几何直观: ReM 通过约束协变量均值之差 $\hat{\tau}_X$ 的大小, 在设计阶段“塑造”了实验的几何结构。Morgan 和 Rubin (2012) 的研究表明, 这种设计具有优雅的数学理论和良好的几何性质。

3. ReM 下的统计推断

3.1. Fisher 随机化检验在 ReM 下的推广. 一个关键问题是: 如何在 ReM 下分析数据? Bruhn and McKenzie (2009) 和 Morgan and Rubin (2012) 论证, 只要我们在约束 $M \leq a$ 下模拟治疗向量 $\mathbf{Z}$, 就仍然可以使用 FRT。这在 sharp null 假设下总是给出有限样本精确 p 值。

在非 null 假设下, 推导 ReM 的有限样本性质是一个具有挑战性的问题。Li et al. (2018b) 在正则条件 (Condition 6.1) 下推导了 $\hat{\tau}$ 的渐近分布。

条件 6.1 (条件 6.1). 当 $n \rightarrow \infty$ 时:

- (1) n_1/n 和 n_0/n 具有正极限;
- (2) $\{X_i, Y_i(1), Y_i(0), \tau_i\}$ 的有限总体协方差具有有限极限;
- (3) $\max_{1 \leq i \leq n} \{Y_i(1) - \bar{Y}(1)\}^2/n \rightarrow 0, \max_{1 \leq i \leq n} \{Y_i(0) - \bar{Y}(0)\}^2/n \rightarrow 0$, 且 $\max_{1 \leq i \leq n} X_i^\top X_i/n \rightarrow 0$ 。

3.2. ReM 的渐近分布: 几何解释. 下面给出 ReM 的主要渐近结果。为符号简洁, 记

$$L_{K,a} \sim D_1 \mid \mathbf{D}^\top \mathbf{D} \leq a,$$

其中 $\mathbf{D} = (D_1, \dots, D_K)$ 服从 K 维标准正态分布; ε 服从一元标准正态分布; $L_{K,a} \perp \varepsilon$ 。

定理 6.3 (定理 6.1 — ReM 下的渐近分布). 在 ReM ($M \leq a$) 和条件 6.1 下,

$$\hat{\tau} - \tau \sim \sqrt{\text{var}(\hat{\tau})} \left\{ \sqrt{R^2} L_{K,a} + \sqrt{1 - R^2} \varepsilon \right\},$$

其中

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$$

是 Neyman (1923) 的方差公式 (见第 4 章), 且

$$R^2 = \text{corr}^2(\hat{\tau}, \hat{\tau}_X)$$

是 $\hat{\tau}$ 与 $\hat{\tau}_X$ 在 CRE 下的平方多重相关系数。

虽然 Li et al. (2018b) 的证明是技术性的, 但定义 6.3 中的渐近分布有清晰的几何解释: $\hat{\tau}$ 分解为一个与 $\hat{\tau}_X$ 线性组合的分量和一个与 $\hat{\tau}_X$ 正交的分量。几何上, $\cos^2 \theta = R^2$, 其中 θ 是 $\hat{\tau}$ 与 $\hat{\tau}_X$ 之间的夹角。ReM 影响第一个分量, 但不影响第二个分量。截断正态分布 $L_{K,a}$ 源于 ReM 对第一个分量的约束。

极限情形:

- 当 $a = \infty$ (普通 CRE) 时, 渐近分布简化为 $\hat{\tau} - \tau \sim \sqrt{\text{var}(\hat{\tau})}\varepsilon$;
- 当 $a \rightarrow 0$ (完全平衡) 时, 渐近分布简化为 $\hat{\tau} - \tau \sim \sqrt{\text{var}(\hat{\tau})(1 - R^2)}\varepsilon$ 。

因此, 当阈值 a 很小时, ReM 的效率增益取决于 R^2 。 R^2 有如下等价形式:²

命题 6.4 (命题 6.1 — R^2 的等价形式). 在 CRE 下,

$$R^2 = \text{corr}^2(\hat{\tau}, \hat{\tau}_X) = \frac{n_1^{-1}S^2(1 | X) + n_0^{-1}S^2(0 | X) - n^{-1}S^2(\tau | X)}{n_1^{-1}S^2(1) + n_0^{-1}S^2(0) - n^{-1}S^2(\tau)},$$

其中 $\{S^2(1), S^2(0), S^2(\tau)\}$ 是 $\{Y_i(1), Y_i(0), \tau_i\}$ 的有限总体方差, $\{S^2(1 | x), S^2(0 | x), S^2(\tau | x)\}$ 是它们在 $(1, X_i)$ 上线性投影的相应有限总体方差。在常因果效应假设 ($\tau_i = \tau$) 下, R^2 退化为 $S^2(0 | X)/S^2(0)$, 即 $Y_i(0)$ 与 X_i 之间的有限总体平方多重相关系数。

实践含义: R^2 衡量了协变量解释结果变异的能力。当协变量是结果的强预测因子时, ReM 能显著提高效率。

置信区间: 如果我们忽视 ReM 的设计, 仍然使用 Neyman (1923) 的方差公式和正态近似来构造置信区间, 即使个体因果效应是常数的, 置信区间也会过于保守 (overcover τ)。Li et al. (2018b) 提出了基于定义 6.3 的置信区间构造方法, 我们将在 section 7 中回到推断问题。

4. 回归调整：分析阶段的协变量平衡

如果在设计阶段没有进行重随机化, 我们还能在分析阶段利用协变量吗? 本节将讨论几种回归调整策略。

4.1. 协变量调整的 Fisher 随机化检验. 协变量 $\mathbf{X}$ 是固定的, 在 H_{0F} 下观测结果也是固定的。因此, 我们可以模拟任何检验统计量 $T = T(\mathbf{Z}, \mathbf{Y}, \mathbf{X})$ 的分布并计算 p 值——FRT 的基本思想在存在额外协变量时依然适用。

Zhao and Ding (2021a) 总结了构造检验统计量的两种一般策略。

定义 6.5 (协变量调整 FRT 的伪结果策略). 基于拟合统计模型后的残差构造检验统计量。将 Y_i 对 X_i 回归得到残差 $\hat{\varepsilon}_i$, 然后将 $\hat{\varepsilon}_i$ 视为伪结果来构造检验统计量。

定义 6.6 (协变量调整 FRT 的模型输出策略). 使用回归系数作为检验统计量。将 Y_i 对 (Z_i, X_i) 回归, 取 Z_i 的系数作为检验统计量。

²推导见附录 section 11.2

关键区别：在伪结果策略中， Y_i 对 X_i 的回归不应包含治疗 Z_i ，因为我们希望伪结果在原结果满足 H_{0F} 时也满足 H_{0F} ；在模型输出策略中， Y_i 对 (Z_i, X_i) 的回归包含 Z_i ，因为我们希望用 Z_i 的系数来衡量对 H_{0F} 的偏离。

在以上两种策略中，“回归”是一个通用术语，可以是线性回归、logistic 回归，甚至机器学习算法。任何来自这两种策略的检验统计量在 H_{0F} 下都是有限样本精确的，虽然它们在备择假设下有所不同。

4.2. 从 ANCOVA 到 Lin (2013) 的估计量. 现在我们转向直接估计平均因果效应 τ 并调整观测到的协变量。

历史注记：Fisher (1925) 首先提出使用协方差分析 (ANCOVA) 来提高估计效率。这个方法在许多领域至今仍是标准做法。Fisher 建议将 Y_i 对 $(1, Z_i, X_i)$ 进行 OLS 回归，取 Z_i 的系数作为 τ 的估计量。记 Fisher 的 ANCOVA 估计量为 $\hat{\tau}_F$ 。

Berkeley 统计学教授 David A. Freedman 在 Neyman (1923) 潜在结果框架下重新分析了 Fisher 的 ANCOVA。Freedman (2008a,b) 发现了以下**负面结果**：

- (1) $\hat{\tau}_F$ 是有偏的，而简单差值均值 $\hat{\tau}$ 是无偏的。
- (2) 当 $n_1 \neq n_0$ 时， $\hat{\tau}_F$ 的渐近方差可能甚至大于 $\hat{\tau}$ 的方差。
- (3) OLS 输出的标准误在 CRE 下对 $\hat{\tau}_F$ 的真实标准误是不一致的。

Freedman 的批评促使 Berkeley 博士生 Winston Lin 在其论文中回应。Lin (2013) 发现了以下**正面结果**：

- (1) $\hat{\tau}_F$ 的偏发生在样本量趋近无穷时趋于零。
- (2) 我们可以通过使用 Y_i 对 $(1, Z_i, X_i, Z_i \times X_i)$ 的 OLS 回归中 Z_i 的系数来同时改进 $\hat{\tau}$ 和 $\hat{\tau}_F$ 的渐近效率。记 Lin (2013) 的估计量为 $\hat{\tau}_L$ 。此外，Eicker-Huber-White (EHW) 标准误在 CRE 下是 $\hat{\tau}_L$ 真实标准误的保守估计。
- (3) 在 Y_i 对 $(1, Z_i, X_i)$ 的 OLS 拟合中， $\hat{\tau}_F$ 的 EHW 标准误平方是 CRE 下其真实标准误的保守估计。

这个从 Fisher 到 Freedman 再到 Lin 的学术对话，完美展示了统计学中批评与改进的辩证过程。**Lin (2013) 的贡献在于：他不仅指出了 ANCOVA 的问题，还提出了一个简单而优雅的解决方案——在回归中加入交互项 $Z_i \times X_i$ 。**

4.3. 线性调整估计量的推导. Neyman (1923) 的结果表明，差值均值估计量 $\hat{\tau}$ 的方差取决于潜在结果的方差。直觉上，我们可以通过减小潜在结果的方差来降低估计量的方差。一族线性调整估计量是：³

$$\hat{\tau}(\beta_1, \beta_0) = n_1^{-1} \sum_{i=1}^n Z_i(Y_i - \beta_1^\top X_i) - n_0^{-1} \sum_{i=1}^n (1 - Z_i)(Y_i - \beta_0^\top X_i).$$

这个协变量调整估计量通过残差化潜在结果来尝试降低 $\hat{\tau}$ 的方差。当 $\beta_1 = \beta_0 = 0$ 时，它退化为 $\hat{\tau}$ 。对于任何固定的 β_1 和 β_0 ，它都具有均值 τ (因为 $\bar{X} = 0$)。

我们感兴趣的是找到使 $\hat{\tau}(\beta_1, \beta_0)$ 方差最小的 (β_1, β_0) 。从 OLS 拟合的性质可知，⁴

命题 6.7 (命题 6.2 — Lin 估计量的 OLS 表示). *section 4.3* 中的估计量 $\hat{\tau}(\hat{\beta}_1, \hat{\beta}_0)$ 等于 Y_i 对 $(1, Z_i, X_i, Z_i \times X_i)$ 的 OLS 回归中 Z_i 的系数，即 Lin (2013) 的估计量 $\hat{\tau}_L$ 。

Lin (2013) 进一步表明，来自定义 6.7 中 OLS 的 EHW 标准误与保守估计量 $\hat{V}(\hat{\beta}_1, \hat{\beta}_0)$ 几乎相同。直观上，这是因为我们不假设线性模型是正确的，而 EHW 标准误对模型误设是稳健的。

³详细推导见附录 section 11.3

⁴推导见附录 section 11.4

警告：渐近理论要求较大的样本量以及对潜在结果和协变量的一些正则条件。在有限样本中，由于估计系数 $\hat{\beta}_1$ 和 $\hat{\beta}_0$ 的额外不确定性，回归调整可能甚至有害。

4.4. 从预测视角理解 Lin 估计量. 我们可以用预测潜在结果的视角来看待 Lin (2013) 的估计量。使用治疗组数据，基于 X 建立 $Y(1)$ 的预测模型：

$$\hat{\mu}_1(X) = \hat{\gamma}_1 + \hat{\beta}_1^\top X.$$

类似地，使用对照组数据建立 $Y(0)$ 的预测模型：

$$\hat{\mu}_0(X) = \hat{\gamma}_0 + \hat{\beta}_0^\top X.$$

如果我们用预测模型填补缺失的潜在结果，则有如下**预测估计量**：

$$\hat{\tau}_{\text{pred}} = n^{-1} \left\{ \sum_{Z_i=1} Y_i + \sum_{Z_i=0} \hat{\mu}_1(X_i) - \sum_{Z_i=1} \hat{\mu}_0(X_i) - \sum_{Z_i=0} Y_i \right\}.$$

可以验证，⁵

$$\hat{\tau}_{\text{pred}} = \hat{\tau}_L.$$

如果我们预测所有潜在结果（即使它们已被观测），则得到**投影估计量**：

$$\hat{\tau}_{\text{proj}} = n^{-1} \sum_{i=1}^n \{ \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) \}.$$

同样地， $\hat{\tau}_{\text{proj}} = \hat{\tau}_L$ 。这些等价的表示揭示了 Lin 估计量的不同侧面。

术语注记：“predictive”和“projective”的术语来自调查抽样文献（Firth and Bennett, 1998; Ding and Li, 2018）。预测量 $\hat{\mu}_1(X)$ 和 $\hat{\mu}_0(X)$ 可以相当一般，包括更复杂的机器学习算法。然而，构造点估计只是分析 CRE 的第一步，更重要的第二步是量化与估计量相关的不确定性。

4.5. 从协变量不平衡调整视角理解 Lin 估计量. 线性调整估计量还有另一种等价形式：⁶

$$\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X,$$

其中 $\gamma = \frac{n_0}{n} \beta_1 + \frac{n_1}{n} \beta_0$ 。

类似地，Lin (2013) 的估计量有形式

$$\hat{\tau}_L = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X,$$

其中 $\hat{\gamma} = \frac{n_0}{n} \hat{\beta}_1 + \frac{n_1}{n} \hat{\beta}_0$ 。

这些形式是“调整协变量不平衡”的数学陈述——它们本质上是减去协变量均值差的某个线性组合。由于 $\hat{\tau}$ 和 $\hat{\tau}_X$ 在 CRE 下相关，适当选择的 γ 进行协变量调整可以降低 $\hat{\tau}$ 的方差。

另一个有趣的特点是，最终估计量只依赖于 γ 或 $\hat{\gamma}$ ，因此 β 系数的选择不是唯一的。Li and Ding (2020) 指出了这个简单事实。因此，Lin (2013) 的估计量只是最优估计量之一。然而，它可以通过标准 OLS 和 EHW 标准误轻松实现——这就是为什么本书专注于它。

⁵推导见附录 section 11.5

⁶推导见附录 section 11.6

5. 回归调整的补充讨论

5.1. ReM 与回归调整的对偶性. Li et al. (2018b) 指出, ReM 和 Lin (2013) 的回归调整在使用协变量的设计中是**对偶的**。更具体地说, 当 a 很小时, ReM 下 $\hat{\tau}$ 的渐近分布与 CRE 下 $\hat{\tau}_L$ 的渐近分布几乎相同。因此, ReM 在设计阶段使用协变量, 而 Lin (2013) 的回归调整在分析阶段使用协变量, 当 a 很小时能达到几乎相同的渐近效率增益。

设计阶段 vs 分析阶段: 这种对偶性意味着, 我们可以在设计阶段通过 ReM 确保协变量平衡, 然后在分析阶段通过回归调整进一步提高效率。这是一种“双保险”策略。

5.2. 回归调整与后分层的等价性. 如果我们有离散的协变量 C_i (K 个类别), 可以创建 $K - 1$ 个居中的虚拟变量:

$$X_i = (\mathbb{I}(C_i = 1) - \pi_{[1]}, \dots, \mathbb{I}(C_i = K - 1) - \pi_{[K-1]}),$$

其中 $\pi_{[k]}$ 是 $C_i = k$ 的单元比例。在这种情况下, Lin (2013) 的回归调整等价于后分层, 如下命题所述。

命题 6.8 (命题 6.3 — 回归调整与后分层的等价性). 基于 X_i 的 $\hat{\tau}_L$ 在数值上与基于 C_i 的后分层估计量 $\hat{\tau}_{PS}$ (见第 5 章) 相同。

这个命题揭示了回归调整与后分层之间的深层联系——它们本质上是处理协变量不平衡的两种不同语言。

5.3. 差分作为协变量调整的特殊情形. 在许多研究中, 一个重要的协变量 X 是治疗前的滞后结果。例如, 在教育研究中, 如果结果 Y 是治疗后测试成绩, 那么协变量 X 是基线测试成绩; 如果结果 Y 是工作培训后的对数工资, 那么协变量 X 是工作培训前的对数工资。

将滞后结果 X 作为协变量, 一个流行的估计量是令 $\beta_1 = \beta_0 = 1$ 时的增益分数或差分估计量:

$$\hat{\tau}(1, 1) = n_1^{-1} \sum_{i=1}^n Z_i(Y_i - X_i) - n_0^{-1} \sum_{i=1}^n (1 - Z_i)(Y_i - X_i).$$

第一个形式证明了“增益分数”这个名称的合理性——它本质上是增益分数 $g_i = Y_i - X_i$ 的差值均值。第二个形式证明了“差分”这个名称的合理性——它是两个均值之差的差。

关键区别: $\hat{\tau}(1, 1)$ 预先固定 $\beta_1 = \beta_0 = 1$, 而 Lin (2013) 的估计量涉及两个估计的 β 。 $\hat{\tau}(1, 1)$ 是无偏的, 而 Lin (2013) 的估计量在有限样本中是有偏的。但在理论上, Lin (2013) 的估计量在大样本下总是比 $\hat{\tau}(1, 1)$ 更有效。

6. 分层随机实验的推广

我们可能有在一个离散变量 C 上分层的实验, 同时也观测到额外的协变量 X 。如果所有层都足够大, 我们可以在各层内获得 Lin (2013) 的估计量 $\hat{\tau}_{L,[k]}$, 然后将最终估计量构造为

$$\hat{\tau}_{L,S} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{L,[k]}.$$

保守的方差估计量是

$$\hat{V}_{L,S} = \sum_{k=1}^K \pi_{[k]}^2 \hat{V}_{\text{EHW},[k]},$$

其中 $\hat{V}_{\text{EHW},[k]}$ 是层 k 内将结果对截距、治疗指标、协变量及其交互进行 OLS 拟合后的 EHW 方差估计量。重要的是, 我们需要将协变量中心化到各层特定的均值。

7. 设计策略的统一与比较

Li and Ding (2020) 统一了文献，表明我们可以结合重随机化和回归调整。即，如果我们在设计阶段进行重随机化，我们可以在分析阶段使用 Lin (2013) 的估计量和 EHW 标准误。重随机化和回归调整的结合在设计阶段改善协变量平衡，在分析阶段提高估计效率。

table 1 总结了从 Neyman (1923) 到 Li and Ding (2020) 的文献。

TABLE 1. 实验的设计与分析策略

	分析	
设计	$\hat{\tau}$ (Neyman, 1923)	$\hat{\tau}_L$ (Lin, 2013)
CRE	原始差值均值	回归调整
ReM	$\hat{\tau}$ (Li et al., 2018b)	$\hat{\tau}_L$ (Li and Ding, 2020)

table 1 中的箭头说明了：

- 箭头 1：协变量调整在 CRE 下的效率增益——渐近地， $\hat{\tau}_L$ 比 $\hat{\tau}$ 有更小的方差。
- 箭头 2：ReM 的效率增益——渐近地，ReM 下的 $\hat{\tau}$ 比 CRE 下的 $\hat{\tau}$ 有更窄的分位数范围。
- 箭头 3 和 4：ReM 与 CRE 结合的好处。

8. 模拟研究

Angrist et al. (2009) 进行了一个评估不同策略对大学新生学业成绩影响的实验。这里我使用原始数据的一个子集，聚焦于对照组和接受学业支持服务和良好成绩经济激励的治疗组。结果是第一年结束时的 GPA。两个协变量是性别和基线 GPA。

例 6.1 (模拟研究). 我们使用 Angrist et al. (2009) 数据的一个子集，评估四种设计与分析策略的表现。

代码实现 (省略数据读取和缺失值填补)：

```
# 未调整估计量
fit_unadj = lm(y ~ z)
ace_unadj = coef(fit_unadj)[2]
se_unadj = sqrt(hccm(fit_unadj, type = "hc2"))[2, 2]

# 回归调整
x = scale(x)
fit_adj = lm(y ~ z*x)
ace_adj = coef(fit_adj)[2]
se_adj = sqrt(hccm(fit_adj, type = "hc2"))[2, 2]
```

模拟结果 (2000 次蒙特卡洛复制, ReM 阈值 $\alpha = 0.05$):

	估计量	估计值	标准误	t 统计量	p 值
	<i>Neyman</i>	0.054	0.076	0.719	0.472
	<i>Lin</i>	0.075	0.072	1.036	0.300

调整后的估计量有更小的标准误，尽管它给出了与未调整估计量相同的 (不显著) 结论。

模拟还评估了四种设计与分析策略组合的表现。为显示 ReM 和回归调整的改进，我将误差项重新缩放了 0.1 和 0.25 倍以提高信噪比。模拟中的“真实”结果模型是非线性的，

但我们仍然使用线性调整进行估计——通过这种方式，我们可以评估在线性模型误设时估计量的性质。

主要发现：如图所示，所有估计量几乎无偏，且 ReM 和回归调整都提高了效率。当噪声水平较小时，它们更有效——这与理论预测一致。

9. 结语：协变量平衡的两种路径

本章介绍了处理连续协变量的两种互补策略：重随机化 (ReM) 和回归调整。

ReM 使用 Mahalanobis 距离作为平衡准则。我们可以考虑更一般的重随机化，将平衡准则定义为 $\mathbf{Z}$ 和 $\mathbf{X}$ 的函数。例如，我们可以使用基于 $X_i = (x_{i1}, \dots, x_{iK})^\top$ 所有坐标边际检验的准则，只在 $|\hat{\tau}_{x_k} / \sqrt{n/(n_1 n_0) S_{x_k}^2}| \leq a$ ($k = 1, \dots, K$) 时接受 $\mathbf{Z}$ 。见 Zhao and Ding (2021b) 对基于此准则及其他准则的重随机化理论的讨论。

Fisher 的 ANCOVA 多年来一直是标准方法。Lin (2013) 的改进即使在线性模型误设时也具有更好的理论性质。对于二元结果，logistic 回归在潜在结果框架下没有好的性质——即使 logistic 模型是正确的，系数估计的也是条件比值比，可能不是感兴趣的参数；如果 logistic 模型不正确，系数更难解释。如果感兴趣的参数是平均因果效应，我们仍然可以使用 Lin (2013) 的估计量分析 CRE 中的二元结果数据。Guo and Basse (2023) 将 Lin (2013) 的理论扩展到允许使用广义线性模型构造平均因果效应的估计量。

Lin (2013) 理论的其他扩展集中于高维协变量。Bloniarz et al. (2016) 关注协变量数目多于样本量的情形，建议用 LASSO 拟合代替 OLS 拟合。Lei and Ding (2021) 关注协变量数目发散而不假设稀疏性的情形，在某些正则条件下证明 Lin (2013) 的估计量仍然一致且渐近正态。Wager et al. (2016) 提出使用机器学习方法分析高维实验数据。

核心信息：ReM 和回归调整代表了协变量平衡的两种哲学——前者通过设计主动控制，后者通过分析被动调整。它们可以单独使用，也可以联合使用——联合使用能在设计阶段和分析阶段同时获益。

10. 习题

练习 6.1. *FRT under ReM* 描述在 *ReM* 下的 *FRT*。

练习 6.2. Mahalanobis 距离的不变性 证明引理 定义 6.1。

练习 6.3. 重随机化下差值均值估计量的无偏性 假设从 CRE 中抽取 $\mathbf{Z} = (Z_1, \dots, Z_n)$ ，当且仅当 $\phi(\mathbf{Z}, \mathbf{X}) = 1$ 时接受，其中 ϕ 是预定的平衡准则。证明：如果 $n_1 = n_0$ 且 $\phi(\mathbf{Z}, \mathbf{X}) = \phi(\mathbf{1}_n - \mathbf{Z}, \mathbf{X})$ ，则 $\hat{\tau}$ 对 τ 无偏。验证当 $n_1 = n_0$ 时，使用 Mahalanobis 距离的重随机化满足此条件。给出当这两个条件不满足时 $\hat{\tau}$ 对 τ 有偏的反例。

练习 6.4. R^2 的等价形式 证明命题 定义 6.4。

练习 6.5. 协变量调整 *FRT* 在协变量调整 *FRT* 中，分别在伪结果策略和模型输出策略下推导 p 值的计算方法。

练习 6.6. Lin 估计量的偏 使用蒙特卡洛模拟研究 Lin 估计量在小样本下的有限样本偏。将样本量从 $n = 20$ 变化到 $n = 500$ ，重复 1000 次，报告平均偏和均方误差。

练习 6.7. Lin 估计量的 OLS 表示 证明命题 定义 6.7 (这是纯线性代数事实)。

练习 6.8. 预测估计量的等价性 证明 $\hat{\tau}_{pred} = \hat{\tau}_L$ 。

练习 6.9. 投影估计量的等价性 证明 $\hat{\tau}_{proj} = \hat{\tau}_L$ 。

练习 6.10. 协变量不平衡调整形式 证明 $\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 和 $\hat{\tau}_L = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X$ 。

练习 6.11. 差分估计量的方差 推导 $\hat{\tau}(1,1)$ 的保守方差估计量 $\hat{V}(1,1)$ 。

练习 6.12. 回归调整与后分层的等价性 证明命题 定义 6.8。

练习 6.13. 协变量不平衡与效率 模拟研究当协变量与结果的相关性从 0.1 变化到 0.9 时，回归调整的效率增益如何变化。

练习 6.14. 高维协变量的 LASSO 调整 使用 LASSO 代替 OLS 进行回归调整，比较两者在协变量稀疏时的表现。

练习 6.15. 缺失数据的填补 在例 6.1 的模拟中，评估不同缺失值填补策略对估计量的影响。

11. 附录：推导

11.1. 协变量均值差的协方差矩阵. 背景：我们推导 $\hat{\tau}_X$ 的协方差矩阵。

目标：证明 $\text{cov}(\hat{\tau}_X) = \frac{n}{n_1 n_0} S_X^2$ 。

推导：...⁷

11.2. R^2 的等价形式推导. 背景：我们推导 R^2 的等价形式。

目标：证明命题 定义 6.4。

推导：...

11.3. 线性调整估计量的推导. 背景：我们详细推导线性调整估计量的形式。

目标：从 $\hat{\tau}(\beta_1, \beta_0)$ 的定义出发，推导其方差。

推导：...

11.4. Lin 估计量的 OLS 连接. 背景：我们证明 $\hat{\tau}(\hat{\beta}_1, \hat{\beta}_0)$ 等于 OLS 回归中 Z_i 的系数。

目标：建立线性调整估计量与 OLS 的等价性。

推导：...

11.5. 预测估计量的等价性证明. 背景：我们证明 $\hat{\tau}_{\text{pred}} = \hat{\tau}_L$ 。

目标：从预测公式推导到 Lin 估计量形式。

推导：...

11.6. 协变量不平衡调整形式推导. 背景：我们推导 $\hat{\tau}(\beta_1, \beta_0)$ 的不平衡调整形式。

目标：证明 $\hat{\tau}(\beta_1, \beta_0) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 。

推导：...

⁷详细推导见原始笔记

配对随机实验

1. 引言：从分层到配对的极致追求

在第 5 章的分层随机实验 (SRE) 中，我们将单元按协变量分层，在每层内独立进行完全随机实验。当每层只有一个治疗单元和一个对照单元时，我们得到了 SRE 的最极端形式——**配对随机实验 (Matched-Pairs Experiment, MPE)**。此时，每一层也称为一个**对 (pair)**。

MPE 看似只是 SRE 的一个特例，但它拥有独特估计和推断策略，且与观测性研究中的匹配方法密切相关（将在第 ?? 章详细讨论）。因此，本书将其独立成章。

核心问题：当协变量能够预测潜在结果时，将相似的单元配对后再随机分配治疗，能否进一步提高估计精度？

2. MPE 的定义与记号

考虑一个包含 $2n$ 个单元的实验。如果我们拥有能够预测结果的协变量，可以根据协变量的相似性将单元配对。对于单标量协变量，我们可以根据该协变量对单元排序，然后配对相邻的单元。对于多维协变量，可以定义单元之间的成对距离，然后使用贪婪算法或最优非二分匹配算法进行配对。¹

记 (i, j) 表示第 i 对中的第 j 个单元，其中 $i = 1, \dots, n$, $j = 1, 2$ 。单元 (i, j) 的潜在结果为 $Y_{ij}(1)$ （接受治疗）和 $Y_{ij}(0)$ （接受对照）。在每一对内，随机分配一个单元接受治疗，另一个接受对照。定义

$$(45) \quad Z_i = \begin{cases} 1, & \text{若第一个单元接受治疗,} \\ 0, & \text{若第二个单元接受治疗.} \end{cases}$$

定义 7.1 (配对随机实验 (MPE)). 我们有

$$(Z_i)_{i=1}^n \stackrel{IID}{\sim} \text{Bernoulli}(1/2).$$

即，治疗指示变量 $(Z_1, \dots, Z_n)$ 独立同分布，服从参数为 $1/2$ 的伯努利分布。

第 i 对内的观测结果为

$$Y_{i1} = Z_i Y_{i1}(1) + (1 - Z_i) Y_{i1}(0), \quad Y_{i2} = Z_i Y_{i2}(0) + (1 - Z_i) Y_{i2}(1).$$

因此，观测数据为 $(Z_i, Y_{i1}, Y_{i2})_{i=1}^n$ 。

3. Fisher 随机化检验

与前述实验一样，我们始终可以使用 Fisher 随机化检验 (FRT) 来检验**尖锐零假设**：

$$(46) \quad H_{0F} : Y_{ij}(1) = Y_{ij}(0) \quad \text{对所有 } i = 1, \dots, n \text{ 和 } j = 1, 2.$$

在 FRT 中，我们需要从 eq. (45) 模拟 $(Z_1, \dots, Z_n)$ 的分布。以下是基于配对内治疗组与对照组结果之差的几种经典检验统计量。

¹配对算法的详细内容见？。

3.1. 配对内差异. 定义配对 i 内的配对差异:

$$(47) \quad \hat{\tau}_i = \text{治疗组结果} - \text{对照组结果} = (2Z_i - 1)(Y_{i1} - Y_{i2}) = S_i(Y_{i1} - Y_{i2}),$$

其中 $S_i = 2Z_i - 1$ 是独立同分布的随机符号, 均值为 0, 方差为 1. 由于 $\hat{\tau}_i = 0$ 的配对对随机化分布没有贡献, 我们在 FRT 讨论中剔除这些配对.

配对差异的均值为

$$(48) \quad \hat{\tau} = n^{-1} \sum_{i=1}^n \hat{\tau}_i.$$

3.2. 配对 t 统计量.

例 7.1 (配对 t 统计量). 在 H_{0F} 下, $\hat{\tau}_i$ 是固定的, 而 S_i 是随机的. 因此

$$\mathbb{E}(\hat{\tau}) = 0, \quad \text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(S_i)(Y_{i1} - Y_{i2})^2 = n^{-2} \sum_{i=1}^n \hat{\tau}_i^2.$$

基于独立随机变量之和的中心极限定理, 我们有正态近似:²

$$(49) \quad \frac{\hat{\tau}}{\sqrt{n^{-2} \sum_{i=1}^n \hat{\tau}_i^2}} \rightarrow N(0, 1)$$

依分布收敛. 许多标准教科书建议在 MPE 中使用以下配对 t 统计量:

$$(50) \quad t_{pair} = \frac{\hat{\tau}}{\sqrt{\{n(n-1)\}^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2}}.$$

在 H_{0F} 下, 当 n 较大且 $\hat{\tau}$ 较小时, t_{pair} 与 eq. (49) 几乎相同.

在经典统计学中, 使用 t_{pair} 的动机基于不同框架. 当 $\hat{\tau}_i \stackrel{IID}{\sim} N(0, \sigma^2)$ 时, 可以证明 $t_{pair} \sim t(n-1)$, 即 t_{pair} 的精确分布是自由度为 $n-1$ 的 t 分布, 在大 n 下接近 $N(0, 1)$. R 函数 `t.test` 可以实现此检验. 例 7.1 的讨论给出了经典配对 t 检验的另一种证明, 无需假设数据的正态性.

3.3. Wilcoxon 符号秩统计量.

例 7.2 (Wilcoxon 符号秩统计量). 基于 $(|\hat{\tau}_1|, \dots, |\hat{\tau}_n|)$ 的秩 $(R_1, \dots, R_n)$, 我们可以定义检验统计量

$$(51) \quad W = \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i > 0) R_i.$$

在 H_{0F} 下, $|\hat{\tau}_i|$ 是固定的, 因此 R_i 也是固定的. 由此可得

$$\begin{aligned} \mathbb{E}(W) &= \frac{1}{2} \sum_{i=1}^n R_i = \frac{1}{2} \sum_{i=1}^n i = \frac{n(n+1)}{4}, \\ \text{var}(W) &= \frac{1}{4} \sum_{i=1}^n R_i^2 = \frac{1}{4} \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{24}. \end{aligned}$$

²推导见附录 section 11.1

独立随机变量之和的中心极限定理保证以下正态近似：³

$$(52) \quad \frac{W - n(n+1)/4}{\sqrt{n(n+1)(2n+1)/24}} \rightarrow N(0, 1)$$

依分布收敛。 R 函数 `wilcox.test` 可以实现精确和渐近检验。

3.4. Kolmogorov–Smirnov 型统计量.

例 7.3 (Kolmogorov–Smirnov 型统计量). 在 H_{0F} 下, 绝对值 $(|\hat{\tau}_1|, \dots, |\hat{\tau}_n|)$ 是固定的, 但符号是随机的。因此 $(\hat{\tau}_1, \dots, \hat{\tau}_n)$ 和 $-(\hat{\tau}_1, \dots, \hat{\tau}_n)$ 应具有相同分布。

设

$$\hat{F}(t) = n^{-1} \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i \leq t)$$

是 $(\hat{\tau}_1, \dots, \hat{\tau}_n)$ 的经验分布函数,

$$1 - \hat{F}(-t-) = n^{-1} \sum_{i=1}^n \mathbb{I}(-\hat{\tau}_i \leq t)$$

是 $-(\hat{\tau}_1, \dots, \hat{\tau}_n)$ 的经验分布函数, 其中 $\hat{F}(-t-)$ 是 $\hat{F}(\cdot)$ 在 $-t$ 处的左极限。Kolmogorov–Smirnov 型统计量定义为

$$(53) \quad D = \max_t |\hat{F}(t) + \hat{F}(-t-) - 1|.$$

? 提出了这个检验统计量并推导了其精确和渐近分布。标准软件包中未实现此统计量, 但我们可以基于 FRT 模拟其精确分布并计算 p 值。

3.5. 符号统计量.

例 7.4 (符号统计量). 符号统计量仅使用配对内差异的符号:

$$(54) \quad \Delta = \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i > 0).$$

在 H_{0F} 下,

$$\mathbb{I}(\hat{\tau}_i > 0) \stackrel{IID}{\sim} \text{Bernoulli}(1/2),$$

因此 $\Delta \sim \text{Binomial}(n, 1/2)$ 。这给出了一个基于二项分布的精确检验, R 函数 `binom.test` 可以实现。利用中心极限定理, 我们还可以基于以下正态近似进行检验:⁴

$$(55) \quad \frac{\Delta - n/2}{\sqrt{n/4}} \rightarrow N(0, 1)$$

依分布收敛。

³推导见附录 section 11.2

⁴推导见附录 section 11.3

3.6. 二值结果的 McNemar 统计量. 当结果为二值时, 我们可以更紧凑地汇总 MPE 的观测数据。给定一对, 治疗结果和对照结果可以各为 1 或 0, 形成如下 2×2 列联表:

	对照结果=1	对照结果=0
治疗结果=1	m_{11}	m_{10}
治疗结果=0	m_{01}	m_{00}

例 7.5 (McNemar 统计量). 在 H_{0F} 下, 一致对的数量 m_{11} 和 m_{00} 是固定的, $m_{10} + m_{01}$ 也是固定的。因此唯一的随机分量是 m_{10} , 其分布为

$$m_{10} \sim \text{Binomial}(m_{10} + m_{01}, 1/2).$$

这给出了一个基于二项分布的精确检验。 R 函数 `mcnemar.test` 给出基于二项分布正态近似的渐近检验:

$$(56) \quad \frac{m_{10} - (m_{10} + m_{01})/2}{\sqrt{(m_{10} + m_{01})/4}} = \frac{m_{10} - m_{01}}{\sqrt{m_{10} + m_{01}}} \rightarrow N(0, 1)$$

依分布收敛。精确 FRT 和渐近检验都不依赖于 m_{11} 或 m_{00} , 只有不一致对的数量在这些检验中起作用。

4. Neymanian 推断

第 i 对内的平均因果效应为

$$(57) \quad \tau_i = \frac{1}{2} \{Y_{i1}(1) + Y_{i2}(1) - Y_{i1}(0) - Y_{i2}(0)\},$$

所有单元的平均因果效应为

$$(58) \quad \tau = n^{-1} \sum_{i=1}^n \tau_i = (2n)^{-1} \sum_{i=1}^n \sum_{j=1}^2 \{Y_{ij}(1) - Y_{ij}(0)\}.$$

直观上, $\hat{\tau}_i$ 是 τ_i 的无偏估计, 因此 $\hat{\tau}$ 是 τ 的无偏估计。⁵

然而, 在 MPE 下, 我们无法遵循 SRE 的策略来估计 $\hat{\tau}$ 的方差。因为在每一对内, 我们只有一个治疗单元和一个对照单元, 结果的配对内样本方差无法定义。数据不允许我们在配对 i 内估计 $\hat{\tau}_i$ 的方差。

能否在 MPE 中估计 $\hat{\tau}$ 的方差? 让我们换一个视角, 忘记 MPE, 转向经典独立同分布抽样。如果 $\hat{\tau}_i$ 是均值为 μ 、方差为 σ^2 的独立同分布变量, 那么 $\hat{\tau} = n^{-1} \sum_{i=1}^n \hat{\tau}_i$ 的方差是 σ^2/n 。 σ^2 的无偏估计是样本方差 $(n-1)^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2$, 因此 $\text{var}(\hat{\tau})$ 的无偏估计是

$$(59) \quad \hat{V} = \{n(n-1)\}^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2.$$

上述讨论似乎与 MPE 完全不同。但至少它启发我们使用 $\hat{V}$, 即用 $\hat{\tau}_i$ 的配对间方差来估计 $\hat{\tau}$ 的方差。当然, 它是在不同假设下推导的。这在 MPE 中也适用吗? 定义 7.2 给出了肯定的回答。

定理 7.2 (方差估计的保守性). 在 MPE 下, 由 eq. (59) 定义的 $\hat{V}$ 是 $\hat{\tau}$ 真实方差的一个保守估计:

$$(60) \quad \mathbb{E}(\hat{V}) - \text{var}(\hat{\tau}) = \{n(n-1)\}^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \geq 0.$$

⁵完整推导见附录 section 12

当 τ_i 在各配对间恒定时, $\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau})$ 。

定义 7.2 表明, 在 MPE 下, $\hat{V}$ 通常是保守的方差估计量, 只有当各配对的平均因果效应恒定时才是无偏的。这个结果有些令人惊讶, 因为 $\hat{V}$ 依赖于 $\hat{\tau}_i$ 的配对间方差, 而 $\text{var}(\hat{\tau})$ 依赖于每个 $\hat{\tau}_i$ 的配对内方差。⁶

与前述实验一样, Neymanian 方法依赖大样本近似:

$$(61) \quad \frac{\hat{\tau} - \tau}{\sqrt{\text{var}(\hat{\tau})}} \rightarrow N(0, 1)$$

在 $n \rightarrow \infty$ 且某些正则条件成立时依分布收敛。由于方差的过度估计, Wald 型置信区间

$$(62) \quad \hat{\tau} \pm z_{1-\alpha/2} \sqrt{\hat{V}}$$

以至少 $1 - \alpha$ 的概率覆盖 τ 。

点估计量 $\hat{\tau}$ 和方差估计量 $\hat{V}$ 都可以方便地通过 OLS 得到, 如下命题所示。

命题 7.3 (OLS 解释). $\hat{\tau}$ 和 $\hat{V}$ 等于将向量 $(\hat{\tau}_1, \dots, \hat{\tau}_n)^\top$ 仅对截距进行 OLS 拟合的系数和方差估计量。

$\hat{\tau}$ 和 $\hat{V}$ 的 OLS 解释使得计算极为便捷, 只需在 R 中运行 `lm(tau_hat ~ 1)` 即可。⁷

5. 协变量调整

虽然在设计阶段我们已经根据协变量进行了配对, 但配对可能不完美 ($X_{i1} \neq X_{i2}$), 有时我们还有配对阶段使用的协变量之外的额外协变量。在这些情况下, 我们可以调整协变量以进一步提高估计效率。⁸

假设每个单元 (i, j) 都有协变量 X_{ij} 。与前述讨论类似, MPE 中协变量调整有两种一般策略。

5.1. FRT 中的协变量调整. 从 FRT 角度, 我们可以在协变量上拟合结果的 OLS 得到残差 $\hat{\varepsilon}_{ij}$ 。由于这些残差在尖锐零假设下是固定数, 我们可以将 $\hat{\varepsilon}_{ij}$ 视为观测结果来构造检验统计量。⁹ 特别倡导这种 MPE 策略。

我们还可以直接使用模型拟合的系数作为检验统计量。

5.2. 回归调整. 现在我们关注 τ 的估计。我们可以计算协变量的配对内差异 $\hat{\tau}_{X,i}$ 及其均值 $\hat{\tau}_X$, 方法与结果相同。可以证明

$$\mathbb{E}(\hat{\tau}_{X,i}) = 0, \quad \mathbb{E}(\hat{\tau}_X) = 0,$$

和

$$\text{cov}(\hat{\tau}_X) = n^{-2} \sum_{i=1}^n \hat{\tau}_{X,i} \hat{\tau}_{X,i}^\top.$$

在实现的 MPE 中, 除非所有 $\hat{\tau}_{X,i}$ 都为零, 否则 $\text{cov}(\hat{\tau}_X)$ 不为零。由于 $(Z_1, \dots, Z_n)$ 的不幸运抽取, $\hat{\tau}_X$ 可能显著偏离零。类似于第 6 章的讨论, 调整协变量均值的不平衡可能会提高估计效率。

类似于第 6 章的讨论, 我们可以考虑由 γ 索引的一类估计量:

$$(63) \quad \hat{\tau}(\gamma) = \hat{\tau} - \gamma^\top \hat{\tau}_X.$$

对于任意固定 γ , 该估计量的均值为零。我们希望选择 γ 使 $\hat{\tau}(\gamma)$ 的方差最小化。

⁶证明见附录 section 10.1

⁷证明见附录 section 10.2

⁸详细推导见附录 section 13

定理 7.4 (协方差的无偏估计). $\text{cov}(\hat{\tau}_X, \hat{\tau})$ 的一个无偏估计为

$$(64) \quad \hat{\theta} = \{n(n-1)\}^{-1} \sum_{i=1}^n (\hat{\tau}_{X,i} - \hat{\tau}_X)(\hat{\tau}_i - \hat{\tau}).$$

因此, 我们可以估计最优系数:

$$\hat{\gamma} = \left(n^{-2} \sum_{i=1}^n \hat{\tau}_{X,i} \hat{\tau}_{X,i}^\top \right)^{-1} \hat{\theta} \approx \left(\sum_{i=1}^n (\hat{\tau}_{X,i} - \hat{\tau}_X)(\hat{\tau}_{X,i} - \hat{\tau}_X)^\top \right)^{-1} \sum_{i=1}^n (\hat{\tau}_{X,i} - \hat{\tau}_X)(\hat{\tau}_i - \hat{\tau}),$$

这大约是 $\hat{\tau}_i$ 对 $\hat{\tau}_{X,i}$ (带截距) 进行 OLS 拟合时 $\hat{\tau}_{X,i}$ 的系数。最终估计量为

$$(65) \quad \hat{\tau}_{\text{adj}} = \hat{\tau}(\hat{\gamma}) = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X.$$

由 OLS 的性质, $\hat{\tau}_{\text{adj}}$ 大约等于将 $\hat{\tau}_i$ 对 1 和 $\hat{\tau}_{X,i}$ (带截距) 进行 OLS 拟合的截距。

$\hat{\tau}_{\text{adj}}$ 的保守方差估计量为

$$\hat{V}_{\text{adj}} = \hat{V} + \hat{\gamma}^\top \text{cov}(\hat{\tau}_X) \hat{\gamma} - 2\hat{\gamma}^\top \hat{\theta} = \hat{V} - \hat{\theta}^\top \text{cov}(\hat{\tau}_X)^{-1} \hat{\theta}.$$

命题 7.5 (调整估计量的 OLS 解释). 在 MPE 下, 协变量调整估计量 $\hat{\tau}_{\text{adj}}$ 和相关方差估计量 $\hat{V}_{\text{adj}}$ 可以方便地近似为将 $\hat{\tau}_i$ 的向量对 1 的向量和 $\hat{\tau}_{X,i}$ 的矩阵进行 OLS 拟合的截距和相关方差估计量。

有趣的是, 定义 7.3 和 定义 7.5 都不需要 EHW (Eicker–Huber–White) 校正。因为我们将 MPE 的数据简化为配对内差异, 所以不需要像 CRE 下 Lin (2013) 估计量那样对协变量进行中心化。

6. Darwin 数据的 FRT 分析

这是来自 ? 的经典例子。它包含 15 对玉米, 其中一对接受异花授粉, 另一对接受自花授粉, 结果是高度。R 包 HistData 提供了原始数据, 其中 `cross` 和 `self` 分别是异花授粉和自花授粉下的高度, `diff` 是它们的差值。

整个 MPE 有 $2^{15} = 32768$ 种可能的治疗分配, 这是一个可处理的数目。我们枚举所有可能的治疗分配并计算相应的 $\hat{\tau}$ 和单边精确 p 值:

```
> difference = ZeaMays$diff
> n.pairs = length(difference)
> abs.diff = abs(difference)
> t_obs = mean(difference)
> t_ran = sapply(1:2^15,
+ function(x) {
+ sum(MP_enumerate(x, 15)*abs.diff)
+ })/n.pairs
> pvalue = mean(t_ran >= t_obs)
> pvalue
[1] 0.02633667
```

精确 p 值为 0.026, 表明在 5% 显著性水平下拒绝零假设。fig. 1 展示了在 H_{0F} 下 $\hat{\tau}$ 的精确随机化分布。

FIGURE 1. Darwin 数据下 $\hat{\tau}$ 的精确随机化分布

7. 儿童电视 Workshop 实验

我们重新分析来自 ? 的儿童电视 Workshop 实验数据 (也见 ? 第 10 章)。它包含 8 对班级, 其中一对中的两个班级被随机分配在标准阅读课期间观看《电动教室》节目或不观看。数据包含前测分数 (协变量) 和后测分数 (结果)。

下表总结了对内协变量和结果及其差异:

配对	前测			后测		
	班级 1	班级 2	差值	班级 1	班级 2	差值
1	24	25	-1	51	56	-5
2	42	40	2	64	65	-1
3	52	52	0	75	72	3
4	71	70	1	79	77	2
5	29	27	2	54	49	5
6	50	50	0	75	78	-3
7	69	69	0	91	92	-1
8	36	34	2	64	55	9

基于 Neymanian 推断, 我们计算点估计和方差估计。⁹

8. 本章小结

本章介绍了配对随机实验 (MPE), 主要内容如下:

- (1) **MPE 的动机**: MPE 是 SRE 的最极端形式, 当每层只有一个治疗单元和一个对照单元时, 配对设计可以最大程度消除层间变异。
- (2) **MPE 定义 (定义 7.1)**: 治疗指示变量 $Z_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(1/2)$ 。
- (3) **FRT**: 可以使用多种检验统计量, 包括配对 t 统计量 (eq. (50))、Wilcoxon 符号秩统计量 (eq. (51))、Kolmogorov-Smirnov 型统计量 (eq. (53)) 和符号统计量 (eq. (54))。
- (4) **Neymanian 推断**: 方差估计量 $\hat{V}$ (eq. (59)) 是保守的 (定义 7.2); 点估计和方差估计都可以通过 OLS 方便地得到 (定义 7.3)。
- (5) **协变量调整**: 调整估计量 $\hat{\tau}_{\text{adj}}$ (eq. (65)) 和方差估计量 $\hat{V}_{\text{adj}}$ 可以通过 OLS 方便地计算 (定义 7.5)。

9. 习题

练习 7.1. MPE 的方差 证明在 MPE 下, $\hat{\tau}$ 的方差为

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i).$$

练习 7.2. 配对 t 统计量的渐近分布 证明 eq. (49): 在 H_{0F} 下,

$$\frac{\hat{\tau}}{\sqrt{n^{-2} \sum_{i=1}^n \hat{\tau}_i^2}} \rightarrow N(0, 1)$$

依分布收敛。

练习 7.3. Wilcoxon 符号秩统计量的矩 证明例 7.2 中 $\mathbb{E}(W)$ 和 $\text{var}(W)$ 的公式。

练习 7.4. McNemar 统计量的精确分布 证明在 H_{0F} 下, $m_{10} \sim \text{Binomial}(m_{10} + m_{01}, 1/2)$ 。

⁹完整计算见附录 section 14

练习 7.5. 方差估计量的偏 证明 定义 7.2: 在 MPE 下,

$$\mathbb{E}(\hat{V}) - \text{var}(\hat{\tau}) = \{n(n-1)\}^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \geq 0.$$

练习 7.6. OLS 解释 证明 定义 7.3: $\hat{\tau}$ 和 $\hat{V}$ 等于将 $(\hat{\tau}_1, \dots, \hat{\tau}_n)^\top$ 仅对截距进行 OLS 拟合的系数和方差估计量。

练习 7.7. 协方差估计量 证明 定义 7.4: $\text{cov}(\hat{\tau}_X, \hat{\tau})$ 的无偏估计为

$$\hat{\theta} = \{n(n-1)\}^{-1} \sum_{i=1}^n (\hat{\tau}_{X,i} - \hat{\tau}_X)(\hat{\tau}_i - \hat{\tau}).$$

练习 7.8. 调整估计量的 OLS 解释 证明 定义 7.5: 协变量调整估计量 $\hat{\tau}_{adj}$ 可以近似等于将 $\hat{\tau}_i$ 对 1 和 $\hat{\tau}_{X,i}$ (带截距) 进行 OLS 拟合的截距。

练习 7.9. *Darwin* 数据的 *Neymanian* 分析 使用 *Neymanian* 方法重新分析 *Darwin* 数据。报告点估计、方差估计和 95% 置信区间。

练习 7.10. 儿童电视 *Workshop* 实验的 FRT 分析 使用 FRT 重新分析儿童电视 *Workshop* 实验数据, 使用配对 t 统计量作为检验统计量。

10. 附录: 定理证明

10.1. 定义 7.2 的证明. 回忆基本代数恒等式 $\sum_{i=1}^n (a_i - \bar{a})^2 = \sum_{i=1}^n a_i^2 - n\bar{a}^2$, 它类似于 $\text{var}(W) = \mathbb{E}(W^2) - (\mathbb{E}W)^2$ 。利用它, 我们有

$$\begin{aligned} n(n-1)\mathbb{E}(\hat{V}) &= \mathbb{E} \left\{ \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2 \right\} \\ &= \mathbb{E} \left(\sum_{i=1}^n \hat{\tau}_i^2 - n\hat{\tau}^2 \right) \\ &= \sum_{i=1}^n \{ \text{var}(\hat{\tau}_i) + \tau_i^2 \} - n \{ \text{var}(\hat{\tau}) + \tau^2 \} \\ &= \sum_{i=1}^n \text{var}(\hat{\tau}_i) - n\text{var}(\hat{\tau}) + \sum_{i=1}^n \tau_i^2 - n\tau^2 \\ &= n^2 \text{var}(\hat{\tau}) - n\text{var}(\hat{\tau}) + \sum_{i=1}^n (\tau_i - \tau)^2. \end{aligned}$$

因此,

$$\mathbb{E}(\hat{V}) = \text{var}(\hat{\tau}) + \{n(n-1)\}^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \geq \text{var}(\hat{\tau}).$$

□

10.2. 定义 7.3 的 OLS 解释. 将 $(\hat{\tau}_1, \dots, \hat{\tau}_n)^\top$ 对截距进行 OLS 拟合, 截距系数为

$$\hat{\beta}_0 = \bar{\hat{\tau}} = n^{-1} \sum_{i=1}^n \hat{\tau}_i = \hat{\tau},$$

这正是 eq. (48) 定义的 $\hat{\tau}$ 。

残差为 $\hat{\varepsilon}_i = \hat{\tau}_i - \hat{\tau}$, 因此误差均方为

$$\hat{\sigma}^2 = (n-1)^{-1} \sum_{i=1}^n \hat{\varepsilon}_i^2 = (n-1)^{-1} \sum_{i=1}^n (\hat{\tau}_i - \hat{\tau})^2 = \hat{V}.$$

因此, $\hat{\tau}$ 和 $\hat{V}$ 确实是 OLS 拟合的截距系数和相应方差估计量。 $\square$

11. 附录：渐近分布推导

11.1. 配对 t 统计量的中心极限定理. 在 H_{0F} 下, $\hat{\tau}_i = S_i D_i$, 其中 $S_i = 2Z_i - 1 \in \{-1, 1\}$ 是随机符号, $D_i = Y_{i1} - Y_{i2}$ 是固定常数。由于 S_i 独立同分布, 均值为 0, 方差为 1, 我们有

$$\text{var}(\hat{\tau}_i) = \mathbb{E}(S_i^2 D_i^2) - \mathbb{E}(S_i)^2 \mathbb{E}(D_i)^2 = D_i^2 - 0 = D_i^2 = \hat{\tau}_i^2.$$

由独立随机变量之和的中心极限定理,

$$\frac{\hat{\tau} - \mathbb{E}\hat{\tau}}{\sqrt{\text{var}(\hat{\tau})}} = \frac{\hat{\tau}}{\sqrt{n^{-2} \sum_{i=1}^n \hat{\tau}_i^2}} \rightarrow N(0, 1)$$

依分布收敛。 $\square$

11.2. Wilcoxon 符号秩统计量的正态近似. 在 H_{0F} 下, $|\hat{\tau}_i|$ 是固定的, 因此秩 R_i 也是固定的。定义 $U_i = \mathbb{I}(\hat{\tau}_i > 0)$, 则 $W = \sum_{i=1}^n U_i R_i$ 。由于 $U_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(1/2)$ 且与 R_i 独立, 我们有

$$\mathbb{E}(W) = \sum_{i=1}^n \mathbb{E}(U_i) R_i = \frac{1}{2} \sum_{i=1}^n i = \frac{n(n+1)}{4},$$

$$\text{var}(W) = \sum_{i=1}^n \text{var}(U_i) R_i^2 = \frac{1}{4} \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{24}.$$

由中心极限定理, eq. (52) 成立。 $\square$

11.3. 符号统计量的正态近似. 在 H_{0F} 下, $\Delta = \sum_{i=1}^n \mathbb{I}(\hat{\tau}_i > 0) \sim \text{Binomial}(n, 1/2)$ 。由中心极限定理,

$$\frac{\Delta - n/2}{\sqrt{n/4}} \rightarrow N(0, 1)$$

依分布收敛。 $\square$

12. 附录：方差公式推导

在 MPE 下，第 i 对的治疗指示变量为 Z_i ，对照指示变量为 $1 - Z_i$ 。因此

$$\hat{\tau}_i = Z_i Y_{i1} + (1 - Z_i) Y_{i2} - [(1 - Z_i) Y_{i1} + Z_i Y_{i2}] = (2Z_i - 1)(Y_{i1} - Y_{i2}) = S_i D_i,$$

其中 $S_i = 2Z_i - 1$ ， $D_i = Y_{i1} - Y_{i2}$ 。

由于 $Z_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(1/2)$ ，我们有 $\mathbb{E}(Z_i) = 1/2$ ， $\text{var}(Z_i) = 1/4$ ，因此 $\mathbb{E}(S_i) = 0$ ， $\text{var}(S_i) = 1$ 。此外， S_i 与 D_i 独立，因为 D_i 仅依赖于潜在结果，而 S_i 仅依赖于治疗分配。因此

$$\mathbb{E}(\hat{\tau}_i) = \mathbb{E}(S_i)\mathbb{E}(D_i) = 0,$$

$$\text{var}(\hat{\tau}_i) = \mathbb{E}(S_i^2)\mathbb{E}(D_i^2) - \mathbb{E}(S_i)^2\mathbb{E}(D_i)^2 = 1 \cdot \mathbb{E}(D_i^2) = \mathbb{E}(D_i^2).$$

由于 $D_i = Y_{i1} - Y_{i2}$ ，

$$\mathbb{E}(D_i^2) = \mathbb{E}[\{Z_i Y_{i1}(1) + (1 - Z_i) Y_{i1}(0) - Z_i Y_{i2}(0) - (1 - Z_i) Y_{i2}(1)\}^2].$$

利用 $Z_i^2 = Z_i$ ， $(1 - Z_i)^2 = 1 - Z_i$ ， $Z_i(1 - Z_i) = 0$ ，我们可以展开并利用 $\mathbb{E}(Z_i) = 1/2$ 和 $\mathbb{E}(Z_i^2) = 1/2$ 。经过代数运算，可以得到 $\text{var}(\hat{\tau}_i) = \mathbb{E}(Y_{i1}(1) - Y_{i2}(1) - Y_{i1}(0) + Y_{i2}(0))^2/4 = \tau_i^2$ 的某种形式。¹⁰

最终， $\hat{\tau} = n^{-1} \sum_{i=1}^n \hat{\tau}_i$ 的方差为

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i) + \text{交叉协方差项}.$$

由于 Z_i 独立，不同配对的 $\hat{\tau}_i$ 也独立，因此协方差项为零。故

$$\text{var}(\hat{\tau}) = n^{-2} \sum_{i=1}^n \text{var}(\hat{\tau}_i).$$

□

13. 附录：协变量调整推导

假设每个单元 (i, j) 都有协变量 X_{ij} 。定义协变量的配对内差异

$$\hat{\tau}_{X,i} = X_{i1} - X_{i2},$$

及其均值 $\hat{\tau}_X = n^{-1} \sum_{i=1}^n \hat{\tau}_{X,i}$ 。

在 MPE 下，治疗分配 Z_i 与协变量 X_{ij} 独立（因为配对是在随机化之前根据协变量形成的）。因此

$$\mathbb{E}(\hat{\tau}_{X,i}) = \mathbb{E}(X_{i1} - X_{i2}) = \mathbb{E}(X_{i1}) - \mathbb{E}(X_{i2}) = 0,$$

因为在配对内，两个单元的协变量分布相同（配对是基于协变量相似性形成的）。

类似地， $\mathbb{E}(\hat{\tau}_X) = 0$ 。

协方差矩阵为

$$\text{cov}(\hat{\tau}_X) = n^{-2} \sum_{i=1}^n \text{cov}(\hat{\tau}_{X,i}) = n^{-2} \sum_{i=1}^n \hat{\tau}_{X,i} \hat{\tau}_{X,i}^\top,$$

因为不同配对的 $\hat{\tau}_{X,i}$ 独立。

考虑调整估计量 $\hat{\tau}(\gamma) = \hat{\tau} - \gamma^\top \hat{\tau}_X$ 。其方差为

$$\text{var}(\hat{\tau}(\gamma)) = \text{var}(\hat{\tau}) + \gamma^\top \text{cov}(\hat{\tau}_X) \gamma - 2\gamma^\top \text{cov}(\hat{\tau}_X, \hat{\tau}).$$

¹⁰详细推导留作习题。

最小化方差的解为

$$\tilde{\gamma} = \text{cov}(\hat{\tau}_X)^{-1} \text{cov}(\hat{\tau}_X, \hat{\tau}).$$

由于 $\text{cov}(\hat{\tau}_X)$ 是已知且固定的，但 $\text{cov}(\hat{\tau}_X, \hat{\tau})$ 依赖于未知的潜在结果，我们使用 eq. (64) 中的 $\hat{\theta}$ 作为其无偏估计。

最终，代入 $\hat{\gamma}$ 得到调整估计量 $\hat{\tau}_{\text{adj}} = \hat{\tau} - \hat{\gamma}^\top \hat{\tau}_X$ 及其方差估计量 $\hat{V}_{\text{adj}}$ 。□

14. 附录：儿童电视 Workshop 实验详细计算

基于 8 对班级的数据，前测和后测的配对差异如下：

配对	前测差值 $\hat{\tau}_{X,i}$	后测差值 $\hat{\tau}_i$
1	-1	-5
2	2	-1
3	0	3
4	1	2
5	2	5
6	0	-3
7	0	-1
8	2	9

点估计：

$$\hat{\tau} = \frac{1}{8} \sum_{i=1}^8 \hat{\tau}_i = \frac{-5 + (-1) + 3 + 2 + 5 + (-3) + (-1) + 9}{8} = \frac{9}{8} = 1.125.$$

方差估计（未调整）：

$$\hat{V} = \frac{1}{8 \times 7} \sum_{i=1}^8 (\hat{\tau}_i - \hat{\tau})^2 = \frac{1}{56} [(-6.125)^2 + (-2.125)^2 + (1.875)^2 + \dots] \approx 4.98.$$

95% 置信区间： $\hat{\tau} \pm 1.96\sqrt{\hat{V}} = 1.125 \pm 1.96 \times 2.23 = [-3.25, 5.50]$ 。

对于协变量调整估计量，我们需要计算 $\hat{\gamma}$ 和 $\hat{\tau}_{\text{adj}}$ 。¹¹

¹¹详细计算留作习题。

分层实验中的 Fisher 随机化检验：Studentized 统计量

1. 引言：从 Chapter 3 的 FRT 到 Chapter 8 的双重保证

在第 3 章中，我们建立了 Fisher 随机化检验 (FRT) 的基本框架。在 sharp null 假设 $H_{0F} : Y_i(1) = Y_i(0)$ 下，FRT 对任何检验统计量都给出有限样本精确的 p 值：

$$\mathbb{P}(p_{\text{ftr}} \leq u) \leq u \quad \text{for all } 0 \leq u \leq 1.$$

这是 FRT 的核心优势——它不依赖任何分布假设，只依赖随机化的性质。

然而，第 3 章也留下了一个关键问题：**我们应该选择什么检验统计量？**

直观上，我们需要选择能够捕捉 H_{0F} 违反情况的检验统计量。但更微妙的问题是，当我们关心 **weak null 假设** $H_{0N} : \tau = 0$ 时，使用某些检验统计量（如原始差值均值 $\hat{\tau}$ ）的 FRT 可能在 H_{0N} 下表现不佳——甚至可能是反保守的 (anti-conservative)。

？的核心贡献在于证明了一个优雅的双重保证 (dual guarantees)：**只要使用 studentized 统计量** $t = \hat{\tau} / \sqrt{\hat{V}}$ ，**FRT 就能同时在 H_{0F} 和 H_{0N} 下表现良好**。本章将详细阐述这一结果，并将它推广到分层实验 (Stratified Randomized Experiment, SRE) 和带协变量的情形。

2. Studentized 统计量的双重保证

2.1. CRE 中的 Studentized 统计量. 考虑第 3 章的完全随机实验 (CRE)： n_1 个单元接受治疗， n_0 个接受对照 ($n = n_1 + n_0$)。我们关心的两个零假设是：

(1) **强零假设 (Sharp Null)**：

$$H_{0F} : Y_i(1) = Y_i(0) \quad \text{对所有单元 } i = 1, \dots, n.$$

(2) **弱零假设 (Weak Null)**：

$$H_{0N} : \tau = 0 \iff \bar{Y}(1) = \bar{Y}(0).$$

在 H_{0F} 下，所有潜在结果都已知，FRT 对任何检验统计量都给出有限样本精确的 p 值。

在 H_{0N} 下，平均因果效应为零但个体因果效应可能非零。此时 $\hat{\tau}$ 仍然是一个合理的检验统计量，但其渐近分布与 H_{0F} 下的分布不同——因为潜在结果的方差结构发生了变化。

经典的 studentized 统计量定义为：

$$t = \frac{\hat{\tau}}{\sqrt{\hat{V}}},$$

其中 $\hat{\tau}$ 是差值均值估计量， $\hat{V}$ 是相应的方差估计量。¹

¹式 section 2.1 的期望和方差推导见附录 ??。

2.2. 双保证的理论.

定理 8.1 (Ding and Dasgupta (2017) 的双重保证). 在 CRE 中, 使用 *studentized* 统计量 t 的 FRT 具有以下双重保证:

- (1) 在 H_{0F} 下: p_{frit} 是有限样本精确的;
- (2) 在 H_{0N} 下: p_{frit} 是渐近保守的 (*asymptotically conservative*).

为什么需要 studentization 才能获得第二个保证? 让我们比较 $\hat{\tau}$ 和 t 在 H_{0N} 下的行为。

在 H_{0N} 下, $\hat{\tau}$ 的渐近分布为:

$$\hat{\tau} \doteq N\left(0, \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}\right).$$

但 FRT pretends 的是 Science Table 由 H_{0F} 诱导的 $(Y_i, Y_i)_{i=1}^n$, 即所有个体因果效应为零。在这个假设下, $\hat{\tau}$ 的随机化分布为:

$$\hat{\tau}^\pi \doteq N\left(0, \frac{s^2}{n_1} + \frac{s^2}{n_0}\right),$$

其中 s^2 是观测结果的样本方差。注意 section 2.2 和 section 2.2 并不匹配——即使在大样本下, FRT 用 section 2.2 作为近似也会在 H_{0N} 下产生反保守的 p 值。

但当我们使用 *studentized* 版本 $t = \hat{\tau}/\sqrt{\hat{V}}$ 时, 情况发生了变化。在 H_{0N} 下:

$$t \doteq N(0, C^2),$$

其中 $C^2 \leq 1$, 等号成立的充要条件是 $Y_i(1) - Y_i(0) = \tau$ 对所有单元成立 (即 constant treatment effect)。

而 FRT 产生的随机化分布为:

$$t^\pi \doteq N(0, 1).$$

由于真实分布的方差 C^2 小于 FRT 假设的方差 1, p 值在渐近意义下是保守的——这正是我们想要的。

关键洞察: studentization 消去了未知方差结构的影响, 使得 FRT 的随机化分布成为真实分布的上界。

注 8.1. ? 证明了这个双重保证是 *studentized* 统计量独有的性质。其他统计量 (如原始 $\hat{\tau}$) 的 FRT 在 H_{0N} 下可能不再控制第一类错误率。

3. 分层实验中的 Studentized 统计量

现在我们将双重保证推广到第 5 章讨论的 SRE 。

在 SRE 中, 我们有 K 个离散的协变量层 (strata)。第 k 层的层别平均因果效应为 $\tau_{[k]}$, 总体平均因果效应为 $\tau = \sum_{k=1}^K \pi_{[k]} \tau_{[k]}$ 。

分层差值均值估计量及其方差估计量已在第 5 章给出:

$$\hat{\tau}_{SRE} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]},$$

$$\hat{V}_{SRE} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right).$$

基于此，我们定义 SRE 中的 studentized 统计量：

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}}.$$

定理 8.2 (SRE 中 FRT 的双重保证). 在 SRE 中，使用 studentized 统计量 t_{SRE} 的 FRT 具有以下双重保证：

- (1) 在 H_{0F} 下： p_{frt} 是有限样本精确的；
- (2) 在 H_{0N} 下： p_{frt} 是渐近保守的。

SRE 中 FRT 的实现与 CRE 类似，唯一的区别在于：在模拟治疗分配时，必须在 X 的各层内独立进行置换（条件随机化检验）。

4. 带协变量的 FRT

4.1. CRE 中带协变量的 Studentized 统计量. 当有基线协变量 $\mathbf{X}$ 可用时，我们可以利用它来构造更高效的检验统计量。？推荐使用 studentized Lin 估计量：

$$t_L = \frac{\hat{\tau}_L}{\sqrt{\hat{V}_L}},$$

其中 $\hat{\tau}_L$ 是？提出的协变量调整估计量， $\hat{V}_L$ 是相应的方差估计量。从 OLS 的角度看， t_L 就是回归 Y_i on $(1, Z_i, X_i, Z_i X_i)$ 中治疗指标 Z_i 系数的 studentized 统计量。

定理 8.3 (Zhao and Ding (2021a) 的多重保证). 在 CRE 中，使用 studentized Lin 统计量 t_L 的 FRT 具有以下多重保证：

- (1) 在 H_{0F} 下： p_{frt} 是有限样本精确的；
- (2) 在 H_{0N} 下： p_{frt} 是渐近保守的；
- (3) 当 H_{0N} 不成立且协变量对结果有预测性时： p_{frt} 渐近地比使用 t 的 FRT 更高效（功效更高）；
- (4) 上述性质在线性结果模型错误设定时仍然成立。

性质（4）特别重要：即使我们用来构造 $\hat{\tau}_L$ 的线性模型是错误的，FRT with t_L 仍然具有双重保证。这是因为 t_L 的渐近有效性来自于协变量对结果的可预测性，而非模型设定。

？同时指出，其他协变量调整 FRT（如基于伪结果策略的 FRT）在 H_{0N} 下可能表现不佳——可能是反保守的，或功效低于 t_L 。

4.2. SRE 中带协变量的 Studentized 统计量. 在 SRE 中同时使用协变量调整，？推荐使用：

$$t_{L,\text{SRE}} = \frac{\hat{\tau}_{L,\text{SRE}}}{\sqrt{\hat{V}_{L,\text{SRE}}}}.$$

这本质上是将 Lin 协变量调整的思想应用到分层估计量框架中。类似地，它也具有定义 8.3 中的多重保证。

5. 模拟研究

？和？通过模拟验证了 studentized 统计量的有限样本性质。我们在此介绍一个典型设置。

考虑一个包含 $n = 100$ 个单元的有限总体，治疗组 $n_1 = 20$ ，对照组 $n_0 = 80$ 。对每个单元 i ，生成协变量 $X_i \sim \text{Unif}(-1, 1)$ ，潜在结果为：

$$Y_i(1) \sim N(X_i^3, 1), \quad Y_i(0) \sim N(-X_i^3, 0.5^2).$$

对 $Y_i(1)$ 和 $Y_i(0)$ 进行中心化以确保 $\tau = 0$ （即满足 H_{0N} ）。

模拟比较了 12 种检验统计量：

- (1) **Neyman (1923) 的三种 OLS 实现**：治疗组系数、基于经典标准误的 t 统计量、基于 EHW 标准误的 t 统计量；
- (2) **伪结果策略 (?)**：首先对 Y_i 在 $(1, X_i)$ 上残差化，然后应用上述三种统计量；
- (3) **Fisher (1925) 的 OLS 实现**（见第 6 章）；
- (4) **Lin (2013) 的 OLS 实现**（见第 6 章）：最终三种 studentized 统计量。

结果 8.1. 在 H_{0N} 下，只有四种 studentized 统计量（Lin 的三种和 EHW 的一种）能够保持名义第一类错误率，且实际错误率偏低（保守）。其余八种统计量的实际错误率均高于名义水平，因此不适合用于检验弱零假设。

这个模拟结果与定义 8.1 的理论预测完全一致。

6. 实践建议

基于上述理论和模拟结果，我们给出以下实践建议：

6.1. CRE 的建议.

- (1) **如果只关心 H_{0F}** （即是否存在任何处理效应）：使用任何检验统计量的 FRT 都给出有限样本精确 p 值。可以选择功效较高的统计量，如 $\hat{\tau}$ 。
- (2) **如果关心 H_{0N}** （即平均因果效应是否为零）：**必须使用 studentized 统计量**，推荐使用 t 或 t_L 。
- (3) **如果有协变量可用**：使用 t_L 通常比 t 更高效。

6.2. SRE 的建议.

- (1) **无协变量**：使用 t_{SRE} ；
- (2) **有协变量**：使用 $t_{L, \text{SRE}}$ 。

6.3. 重随机化 (ReM) 的特别说明. 对于使用 Mahalanobis 距离进行重随机化的实验 (ReM)，？发现使用原始 t 统计量的 FRT 不再具有定义 8.1 中的双重保证。但使用 t_L 的 FRT 仍然保持这些保证。这凸显了**协变量调整和 studentization 在 ReM 中的重要性**。

6.4. 匹配对实验 (MPE) 的建议. 对于匹配对实验 (MPE)，建议平行于 SRE 的建议：

- **无协变量**：使用 t 统计量（OLS 拟合 $\hat{\tau}_i$ on 1 后的截距项）；
- **有协变量**：使用 t 统计量（OLS 拟合 $\hat{\tau}_i$ on 1 和 $\hat{\tau}_{X,i}$ 后的截距项）。

6.5. 核心结论. 使用 studentized 统计量的 FRT 是更安全的选择. 当大样本正态近似准确时，基于 Normal 近似和基于 FRT 的 p 值几乎相同。当正态近似不准确时，FRT 至少能保证在 sharp null 假设下 p 值是有效的。这是本书的推荐做法。

7. 案例研究：铁补充剂实验的重新分析

我们重新分析第 5 章提到的“实验，比较”足球运动员”组 vs 对照组，以及“医生”组 vs 对照组。数据集包含学生的基线贫血状态作为协变量。

我们使用两种分析框架：

- **CRE 分析**（各层内）：使用 t 和 t_L 的 FRT；
- **SRE 分析**（跨层汇总）：使用 t_{SRE} 和 $t_{L,SRE}$ 的 FRT。

table 1 和 table 2 分别报告了 soccer vs control 和 physician vs control 的结果。

TABLE 1. 铁补充剂实验重新分析：soccer vs control

	est	s.e.	p_{Normal}	p_{fit}
class 1 (N)	0.051	0.502	0.919	0.924
class 1 (L)	0.050	0.489	0.919	0.929
class 2 (N)	-0.158	0.451	0.726	0.722
class 2 (L)	-0.176	0.452	0.698	0.700
class 3 (N)	0.005	0.403	0.990	0.989
class 3 (L)	-0.096	0.385	0.803	0.806
class 4 (N)	-0.492	0.447	0.271	0.288
class 4 (L)	-0.511	0.447	0.253	0.283
class 5 (N)	0.390	0.369	0.291	0.314
class 5 (L)	0.443	0.318	0.164	0.186
all (N)	-0.051	0.204	0.802	0.800
all (L)	-0.074	0.200	0.712	0.712

N: Neyman (1923) 未调整估计量和检验；L: Lin (2013) 协变量调整估计量和检验。

TABLE 2. 铁补充剂实验重新分析：physician vs control

	est	s.e.	p_{Normal}	p_{fit}
class 1 (N)	0.567	0.426	0.183	0.192
class 1 (L)	0.588	0.418	0.160	0.174
class 2 (N)	0.193	0.438	0.659	0.666
class 2 (L)	0.265	0.409	0.517	0.523
class 3 (N)	1.305	0.494	0.008	0.012
class 3 (L)	1.501	0.462	0.001	0.003
class 4 (N)	-0.273	0.413	0.508	0.515
class 4 (L)	-0.313	0.417	0.454	0.462
class 5 (N)	-0.050	0.379	0.895	0.912
class 5 (L)	-0.067	0.279	0.811	0.816
all (N)	0.406	0.202	0.045	0.047
all (L)	0.463	0.190	0.015	0.017

N: Neyman (1923) 未调整估计量和检验；L: Lin (2013) 协变量调整估计量和检验。

从表中可以看到几个关键观察：

- (1) **协变量调整通常减少标准误**: 由于基线贫血状态对结果有预测力, 使用 t_L 的标准误通常小于使用 t 的标准误 (在大多数层中成立)。
- (2) **两种 p 值接近但 FRT 略大**: 根据理论, FRT p 值应该略大于基于正态近似的 p 值 (保守性), 在大多数情况下确实如此。
- (3) **跨层汇总的 SRE 分析**: soccer 组在所有层中均不显著; physician 组的整体效应显著 ($p_{\text{ftr}} \approx 0.017$), 且在 class 3 中最为显著 ($p_{\text{ftr}} \approx 0.003$)。
- (4) **小层中的标准误增大**: class 2 和 class 4 中协变量调整反而略微增大了标准误, 这是由于层内样本量较小导致渐近近似不准确。

fig. 1 比较了 studentized 统计量的随机化分布与正态近似。在层内子组分析中, 随机化分布与 $N(0, 1)$ 之间存在一定偏差; 在跨层汇总分析中, 偏差变得不明显。总体而言, 两种方法得出的结论一致。

FIGURE 1. 铁补充剂实验重新分析: 随机化分布与 $N(0, 1)$ 近似的比较
跨层汇总分析 (右侧两列) 中, 随机化分布与 $N(0, 1)$ 的偏差在视觉上已不明显。

8. 本章小结

本章探讨了 Fisher 随机化检验在完全随机实验和分层随机实验中的应用, 主要结论如下:

- (1) **双重保证 (?)**: 使用 studentized 统计量 $t = \hat{\tau} / \sqrt{\hat{V}}$ 的 FRT 在 H_{0F} 下是有限样本精确的, 在 H_{0N} 下是渐近保守的。
- (2) **Studentization 的必要性**: 原始 $\hat{\tau}$ 的 FRT 在 H_{0N} 下可能反保守, 因为 FRT 假设的方差结构与真实方差结构不匹配。Studentization 消去了这一不匹配。
- (3) **带协变量的扩展 (?)**: 使用 studentized Lin 统计量 t_L 的 FRT 在 H_{0F} 下精确, 在 H_{0N} 下保守, 且当协变量预测结果时功效更高。
- (4) **SRE 的推广**: 对 SRE 使用 t_{SRE} , 对带协变量的 SRE 使用 $t_{L, \text{SRE}}$, 均具有双重保证。
- (5) **实践建议**: 使用 studentized 统计量的 FRT 是更安全的选择——当正态近似准确时与渐近 p 值接近, 当正态近似不准确时至少保证 sharp null 下的有效性。

9. 习题

练习 8.1. 8.1 — *Angrist and Lavy (2009)* 数据重新分析 这是第 7 章 Problem 7.8 的 Fisher counterpart。报告使用 studentized 统计量的 FRT 所得到的 p_{ftr} 。

练习 8.2. 8.2 — *Zhao and Ding (2021a)* Figure 1 的复制 *Zhao and Ding (2021a)* 使用模拟来评估各种检验统计量的 FRT 的有限样本性质。基于他们的 Figure 1, 他们推荐使用 $t_{L, \text{SRE}}$ 来分析 SRE。复制他们的 Figure 1。

练习 8.3. 8.3 — *Studentization* 的直觉 解释为什么 studentization 能够修复 $\hat{\tau}$ 在 H_{0N} 下的反保守问题。从方差结构的角度阐述你的理由。

练习 8.4. 8.4 — 推导 t 在 H_{0N} 下的渐近分布在 CRE 中, 推导 studentized 统计量 $t = \hat{\tau} / \sqrt{\hat{V}}$ 在 H_{0N} 下的渐近分布。证明其渐近方差不超过 1。

练习 8.5. 8.5 — Lin 估计量的性质 描述 Lin (2013) 协变量调整估计量 $\hat{\tau}_L$ 的构造。证明它在线性结果模型正确设定时是高效的。

练习 8.6. 8.6 — 推荐阅读 ? 和 ? 在 *permutation tests* 中使用了 *studentized* 统计量。在设计-based 框架下, ? 和 ? 给出了 *multi-armed experiments* 的推荐, ? 将推荐推广到协变量调整情形。阅读这些文献并撰写一页摘要。

随机实验中的协变量调整

1. 引言：为什么需要协变量调整？

“The randomized experiment is the gold standard for causal inference.” — ?

在第 4 章的完全随机实验 (CRE) 中，我们证明了差值均值估计量 $\hat{\tau}$ 是平均因果效应 τ 的无偏估计。然而，无偏性只保证了大样本下的准确性——在有限样本中， $\hat{\tau}$ 的方差仍然可能较大。

一个自然的问题是：**能否利用已观测到的协变量 X 来提高估计精度？**

这并非一个新问题。Fisher (1935) 早就指出，在农业实验中，通过对土壤肥力等协变量进行调整可以提高 treatment 效果估计的精确度。Neyman (1923) 在其经典论文中也曾隐含地讨论过类似的思想。然而，将这一思想系统化、理论化的工作，则要等到 20 世纪后期才逐步完成。

本章在超级总体 (superpopulation) 框架下讨论协变量调整。我们将看到，当协变量能够预测潜在结果时，恰当的协变量调整可以显著提高估计效率。

2. 超级总体框架下的 CRE

2.1. 基本设定与定义. 假设从超级总体中独立同分布地抽取 n 个单元：

$$\{Z_i, Y_i(1), Y_i(0), X_i\}_{i=1}^n \stackrel{\text{iid}}{\sim} \{Z, Y(1), Y(0), X\}.$$

定义 9.1 (CRE 的超级总体框架). 在超级总体框架下，完全随机实验满足：

$$Z \perp \{Y(1), Y(0), X\}.$$

在这个框架下，平均因果效应可以写为：

$$\tau = E\{Y(1)\} - E\{Y(0)\} = E(Y \mid Z = 1) - E(Y \mid Z = 0).$$

第一个等号利用了随机化假设 $Z \perp Y(1)$ 和 $Z \perp Y(0)$ ，第二个等号则说明 τ 等于观测结果期望的差。

section 2.1 立刻提示了一个矩估计量——差值均值 $\hat{\tau}$ 。在给定治疗分配向量 $\mathbf{Z}$ 的条件下，这是标准的双臂独立样本均值比较问题：

$$E(\hat{\tau} \mid \mathbf{Z}) = \tau, \quad \text{var}(\hat{\tau} \mid \mathbf{Z}) = \frac{\text{var}\{Y(1)\}}{n_1} + \frac{\text{var}\{Y(0)\}}{n_0}.$$

在 IID 抽样下，样本方差是总体方差的无偏估计，因此 Neyman (1923) 的方差估计量对 $\text{var}(\hat{\tau} \mid \mathbf{Z})$ 是无偏的。**超级总体框架消除了保守性问题。**¹

¹详细讨论见附录 section 15。

2.2. 协变量调整的动机. 尽管 $\hat{\tau}$ 在超级总体框架下是渐近无偏且渐近正态的，但其方差 $\text{var}(\hat{\tau} | \mathbf{Z})$ 可能较大。当协变量 X 能够预测潜在结果时，我们可以通过调整协变量来降低方差。

直观理解：在差值均值估计量中，治疗组和对照组的协变量分布可能存在随机不平衡。即使这种不平衡在高维空间中很小，它仍然可能污染结果均值差。协变量调整的本质，是从结果均值差中减去由协变量不平衡所贡献的部分。

数学上，我们假设潜在结果关于协变量的线性投影（ANCOVA 框架）：

$$Y(1) = \gamma_1 + \beta_1^T X + \varepsilon(1), \quad E\{\varepsilon(1)\} = 0,$$

$$Y(0) = \gamma_0 + \beta_0^T X + \varepsilon(0), \quad E\{\varepsilon(0)\} = 0.$$

利用这些分解，因果效应可以写为：

$$\tau = E\{Y(1) - Y(0)\} = (\gamma_1 - \gamma_0) + (\beta_1 - \beta_0)^T E(X).$$

注意到右边只涉及 $E(X)$ ，而不涉及 $\varepsilon(1)$ 和 $\varepsilon(0)$ ——这意味着我们可以先拟合 section 2.2 和 section 2.2，然后用样本版本构造 τ 的估计量。

2.3. Lin (2013) 估计量. 设 $\hat{\gamma}_1, \hat{\beta}_1, \hat{\gamma}_0, \hat{\beta}_0$ 分别是 section 2.2 和 section 2.2 的 OLS 估计量。则 τ 的协变量调整估计量为：

$$\hat{\tau}_{\text{adj}} = \hat{\gamma}_1 - \hat{\gamma}_0 + (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}.$$

一个关键洞察是：若我们对协变量进行中心化，即 $\bar{X} = 0$ ，则 section 2.3 简化为：

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0.$$

这就是 ? 提出的估计量。section 2.3 等价于在合并数据上运行以下 OLS 回归：

$$Y = \alpha_0 + \alpha_Z Z + \alpha_X^T X + \alpha_{ZX}^T (Z \cdot X) + \varepsilon,$$

其中 $\hat{\tau}_L = \hat{\alpha}_Z$ 。²

? 证明了在正则条件下， $\hat{\tau}_L$ 是 τ 的半参数有效估计量——它达到了均方误差意义上的最优下界。

2.4. 方差估计：EHW 校正. 标准 OLS 输出会给出 $\hat{\tau}_L$ 的方差估计量。然而，直接使用 OLS 的异方差-稳健（EHW）标准误是不正确的——因为在超级总体框架下，协变量样本均值 $\bar{X}$ 也有随机变异，而 OLS 标准误没有考虑这一额外的随机性。³

?, ? 和 ? 分别独立地提出了对 EHW 方差估计量的校正项：

$$\hat{V}_L = \hat{V}_{\text{EHW}} + \frac{1}{n}(\hat{\beta}_1 - \hat{\beta}_0)^T S_X^2 (\hat{\beta}_1 - \hat{\beta}_0),$$

其中：- $\hat{V}_{\text{EHW}}$ 是 OLS 输出的 EHW 方差估计量；- S_X^2 是协变量 X 的有限总体协方差矩阵的样本版本；- $(\hat{\beta}_1 - \hat{\beta}_0)$ 是交互项 $Z \cdot X$ 的系数估计。

加入校正项后，标准误与经验标准差匹配，95% 置信区间的覆盖率接近标称水平。⁴

²完整的 OLS 分解推导见附录 section 16。

³原因分析见附录 section 17。

⁴模拟验证见第 3 节。

3. 模拟研究

为了验证上述理论结果，我们进行蒙特卡洛模拟。设定样本量 $n = 500$ ，重复 2000 次。潜在结果关于协变量非线性，误差项非正态，真实平均因果效应为 0。⁵

模拟结果显示：

- (1) **Lin 估计量近似无偏**：偏差约为 -0.0001 ，可以忽略。
- (2) **EHW 标准误偏小**：平均 EHW 标准误为 0.139，而经验标准差为 0.151，导致 95% 置信区间覆盖率仅为 92.7%（偏低）。
- (3) **校正后的标准误准确**：加入 section 2.4 的校正项后，平均校正标准误为 0.153，与经验标准差非常接近，95% 置信区间覆盖率达到 95.3%。

这些结果验证了超级总体框架下方差校正的必要性。

4. SRE 的扩展

前文的讨论可以自然地推广到分层随机实验（SRE）。设 $X_i \in \{1, \dots, K\}$ 为离散的层别协变量。

定义 9.2 (SRE 的超级总体框架). 在超级总体框架下，分层随机实验满足：

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

即，在给定层别 $X = k$ 的条件下，治疗分配与潜在结果独立。
层别平均因果效应为：

$$\tau_{[k]} = E\{Y(1) - Y(0) \mid X = k\} = E(Y \mid Z = 1, X = k) - E(Y \mid Z = 0, X = k).$$

总体平均因果效应是各层别平均因果效应的加权平均：

$$\tau = \sum_{k=1}^K \text{pr}(X = k) \tau_{[k]}.$$

由于 SRE 等价于各层内独立的 CRE，前文关于 CRE 的所有结果在各层内都成立。因此，我们可以对每一层分别应用 Lin (2013) 估计量，然后加权合并。⁶

当各层内治疗组和对照组样本量至少为 2 时，我们可以用 $\hat{V}_S$ 作为 $\text{var}(\hat{\tau}_S)$ 的方差估计量。

5. 本章小结

本章在超级总体框架下讨论了随机实验中的协变量调整，主要内容如下：

- (1) **超级总体框架 (定义 9.1)**： $Z \perp \{Y(1), Y(0), X\}$ 使得 τ 可以写为观测结果期望的差，消除了保守性问题。
- (2) **协变量调整的动机**：当 X 能预测潜在结果时，调整协变量可以消除由协变量不平衡带来的额外方差。
- (3) **Lin (2013) 估计量 (section 2.3)**：等价于在合并数据上运行含交互项的 OLS 回归，在正则条件下半参数有效。
- (4) **方差校正 (section 2.4)**：需要在 EHW 方差估计量上添加校正项，才能得到在超级总体框架下一致的标准误。
- (5) **SRE 扩展 (定义 9.2)**：在各层内分别应用协变量调整，然后加权合并。

⁵R 代码实现见附录 section 19。

⁶详细推导见附录 section 18。

协变量调整的核心思想是：**利用可观测的协变量信息，提高因果效应的估计精度**。这一思想将在后续章节讨论观测性研究时发挥更重要的作用。

6. 习题

练习 9.1. *CRE* 的协变量平衡 在超级总体框架下，证明 *section 2.1*：平均因果效应可以写为 $E(Y | Z = 1) - E(Y | Z = 0)$ 。

练习 9.2. *OLS* 分解与 *pooled regression* 基于 *section 2.2* 和 *section 2.2*，证明观测结果的 *OLS* 分解为：

$$Y = \alpha_0 + \alpha_Z Z + \alpha_X^T X + \alpha_{ZX}^T (Z \cdot X) + \varepsilon,$$

其中

$$\alpha_0 = \gamma_0, \quad \alpha_Z = \gamma_1 - \gamma_0, \quad \alpha_X = \beta_0, \quad \alpha_{ZX} = \beta_1 - \beta_0.$$

练习 9.3. *Lin (2013)* 估计量的性质 证明在正则条件下，*Lin (2013)* 估计量 $\hat{\tau}_L$ 是 τ 的半参数有效估计量。

练习 9.4. 方差估计量的比较 在超级总体框架下，模拟 $\{X_i, Z_i, Y_i(1), Y_i(0)\}_{i=1}^n$ ，其中 $\beta_1 \neq \beta_0$ 。比较以下四种方差估计量的表现：

- (1) 标准的 *EHW* 稳健方差估计量；
- (2) 带校正项 *section 2.4* 的 *EHW* 估计量；
- (3) *Bootstrap* 方差估计量（协变量在开始时中心化，但不每次重新中心化）；
- (4) *Bootstrap* 方差估计量（协变量在每次 *bootstrap* 样本中重新中心化）。

练习 9.5. *SRE* 中的协变量调整 在 *SRE* 的超级总体框架下，推导 τ 的协变量调整估计量及其方差估计量。

练习 9.6. 协变量调整与后分层的关系 证明：当各层的层别倾向得分 $e_{[k]} = n_{[k]1}/n_{[k]}$ 相等时，协变量调整与后分层给出相同的点估计量。

练习 9.7. 文献阅读 阅读？的原文，总结其核心贡献和主要结论。

练习 9.8. 回归调整的几何解释 从几何角度解释协变量调整：为什么减去 $(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}$ 可以提高估计精度？

结果回归：连接随机实验与观测性研究

1. 从随机实验到观测性研究：一个自然的问题

在前几章中，我们研究了随机化实验中的因果推断方法。完全随机化实验（CRE）的关键优势在于：随机分配确保了治疗组和对照组在潜在结果分布上是可比的，从而消除了选择偏差。这使得我们能够从观测数据中直接识别因果效应。

然而，现实中的研究往往无法进行随机化实验。研究者只能利用**观测性研究（observational studies）**的数据——治疗分配不是由研究者控制的，而是由各种因素决定的。在这些情况下，治疗组和对照组的可比性不再有保证：接受治疗的群体可能本身就与未接受治疗的群体不同。这种差异被称为**选择偏差（selection bias）**。

核心问题产生了：在观测性研究中，我们能否利用已观测到的协变量信息来恢复因果效应的识别？换句话说，如果治疗分配在给定某些协变量的条件下是“近似随机”的，我们是否可以从观测数据中估计因果效应？

这是因果推断领域的根本问题。本书的第三部分（Part III）将系统讨论这一问题的答案。作为开场，本章介绍四种核心方法的第一种——**结果回归（outcome regression）**。

2. 三个典型例子

在形式化理论之前，让我们先通过三个经典例子来理解观测性研究中因果推断的实际场景。

2.1. 职业培训项目的效果。？研究了职业培训项目对个人 earnings 的因果效应。他同时收集了随机实验数据和观测性研究数据。在随机实验中，参与者被随机分配到培训项目或对照组；而在观测性数据中，参与者是否参与培训并非由研究者控制。？发现，许多传统的统计分析方法在两类数据上给出了截然不同的估计结果。这一发现促使？等学者开始探索更适合观测性研究的因果推断方法。LaLonde 数据集后来成为因果推断领域的基准例子。

2.2. 吸烟与同型半胱氨酸水平。？利用 NHANES 2005-2006 数据研究了每日吸烟者与不吸烟者之间同型半胱氨酸（homocysteine）水平的差异。已知的协变量包括性别（female）、年龄类别（age3）、教育水平（ed3）、BMI 类别（bmi3）以及收入水平（pov2）。这里的核心问题是：观察到的吸烟组与非吸烟组之间的差异，究竟是吸烟的因果效应，还是由这些协变量分布不同造成的？

2.3. 学校餐饮项目与 BMI。？研究了学校餐饮项目参与对儿童 BMI 的因果效应。他们使用 NHANES 2007-2008 的子样本数据，包含年龄、性别、种族、家庭收入水平等多个协变量。与前两个例子类似，我们感兴趣的是：在控制这些协变量之后，项目参与对 BMI 是否有因果效应？

这三个例子的共同特征是：我们希望估计某个非随机化治疗对结果的因果效应。它们都是观测性研究的典型场景。

3. 潜在结果框架下的因果效应与选择偏差

现在我们在潜在结果框架下形式化地描述观测性研究的问题。

记第 i 个单元的预处理协变量为 X_i ，二值治疗指示变量为 $Z_i \in \{0, 1\}$ ，观测结果为 Y_i ，对应的潜在结果为 $Y_i(1)$ 和 $Y_i(0)$ 。为简单起见，假设数据是独立同分布的：

$$\{X_i, Z_i, Y_i(1), Y_i(0)\}_{i=1}^n \stackrel{\text{iid}}{\sim} \{X, Z, Y(1), Y(0)\}.$$

关心的因果效应包括：

- **平均因果效应 (Average Causal Effect, ACE)：**

$$\tau = \mathbb{E}\{Y(1) - Y(0)\}.$$

- **治疗组平均因果效应 (Average Causal Effect on the Treated, ATT)：**

$$\tau_T = \mathbb{E}\{Y(1) - Y(0) \mid Z = 1\}.$$

- **对照组平均因果效应 (Average Causal Effect on the Control, ATC)：**

$$\tau_C = \mathbb{E}\{Y(1) - Y(0) \mid Z = 0\}.$$

利用条件期望的线性分解，我们有：

$$\tau_T = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}\{Y(0) \mid Z = 1\}.$$

在这个表达式中， $\mathbb{E}(Y \mid Z = 1)$ 可以直接从观测数据估计，但 $\mathbb{E}\{Y(0) \mid Z = 1\}$ 是反事实——它度量的是“如果治疗组个体接受对照处理，他们的结果会是什么”。这是无法直接从数据中观测到的量。

类似地，对于 τ_C ，我们有：

$$\tau_C = \mathbb{E}\{Y(1) \mid Z = 0\} - \mathbb{E}(Y \mid Z = 0),$$

其中 $\mathbb{E}\{Y(1) \mid Z = 0\}$ 同样是反事实量。

表面因果效应 (Prima Facie Causal Effect) 定义为：

$$\tau_{PF} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0).$$

这个量可以直接从数据计算，但它通常不是任何因果效应的无偏估计。偏差的大小由**选择偏差**刻画：

$$\tau_{PF} - \tau_T = \mathbb{E}\{Y(0) \mid Z = 1\} - \mathbb{E}\{Y(0) \mid Z = 0\},$$

$$\tau_{PF} - \tau_C = \mathbb{E}\{Y(1) \mid Z = 1\} - \mathbb{E}\{Y(1) \mid Z = 0\}.$$

这些选择偏差项度量的是治疗组和对照组在潜在结果均值上的差异——即使治疗没有任何效果，只要两组在潜在结果分布上不同， τ_{PF} 就会偏离零。

为什么随机化如此重要？在 CRE 中，随机分配保证了 $Z \perp \{Y(1), Y(0)\}$ ，这意味着治疗组和对照组的潜在结果分布是相同的，从而选择偏差项为零。但在观测性研究中，这个条件一般不成立，选择偏差可能任意大。

4. 非参数识别的充分条件

上一节的讨论表明，在没有随机化的情况下，观测数据无法直接识别因果效应——我们需要额外的假设。本节介绍**不可识别性 (ignorability)** 假设，这是观测性研究因果推断的理论基础。

4.1. 条件独立假设. 一个关键假设是：在给定协变量 X 的条件下，治疗分配与潜在结果是独立的。¹

假设 10.1 (不可识别性 / Ignorability).

$$Y(z) \perp Z \mid X \quad (z = 0, 1).$$

这个假设有多多个等价名称：

- **Unconfoundedness** (无混杂)：在流行病学文献中常用
- **Selection on observables** (可观测选择)：在经济学文献中常用
- **Conditional independence** (条件独立性)：这是假设的数学描述

直觉上，假设 10.1 表明给定协变量 X 后，治疗组和对照组的潜在结果分布是相同的——“治疗分配”近似随机化”。换句话说，所有同时影响治疗分配和潜在结果的变量（即混杂因素，confounders）都被协变量 X 所控制。

强不可识别性 (Strong Ignorability) 进一步要求：

$$\{Y(1), Y(0)\} \perp Z \mid X.$$

这比 假设 10.1 更强，但对于估计平均因果效应 τ 来说，两者在大多数统计模型下是等价的。

不可识别性假设的**可塑性 (Plausibility)** 取决于研究场景：如果我们观察到足够丰富的协变量 X ，使得所有混杂因素都被包含，那么这个假设可能是合理的；如果存在未观测的混杂因素，这个假设就不成立。²

4.2. 识别公式. 在 假设 10.1 下，平均因果效应 τ 可以从观测数据中非参数地识别。³

定理 10.1 (识别定理). 在 假设 10.1 下，平均因果效应 τ 由下式识别：

$$(66) \quad \tau = \mathbb{E}\{\tau(X)\} = \mathbb{E}[\mathbb{E}(Y \mid Z = 1, X) - \mathbb{E}(Y \mid Z = 0, X)].$$

定义 10.1 的含义是：给定协变量 X 后，治疗组和对照组的结果条件期望之差就是该协变量取值下的因果效应 $\tau(X)$ ，而总体因果效应是这些条件因果效应的无条件期望。

对于离散协变量 $X \in \{1, \dots, K\}$ ，eq. (66) 可以写为：

$$(67) \quad \tau = \sum_{k=1}^K \mathbb{E}(Y \mid Z = 1, X = k) \Pr(X = k) - \sum_{k=1}^K \mathbb{E}(Y \mid Z = 0, X = k) \Pr(X = k).$$

关键观察：不可识别性假设的核心价值在于，它将无法直接观测的因果效应 τ 转化为可以从小样本中估计的量——条件期望之差的加权平均。

5. 两种简单估计策略及其局限

基于 定义 10.1，我们现在讨论两种估计因果效应的策略。本章的剩余部分将详细展开第一种策略——结果回归。

¹这个假设最早由 ? 系统提出，后来被 ? 发展为倾向得分理论。

²关于不可识别性假设的可塑性讨论，见 ?。

³这个识别公式由 ? 正式建立，也被称为 **g-formula** (见 ?)。

5.1. 分层(标准化). 如果协变量 X 是离散的, 且取值范围有限, 则 eq. (67) 提供了一个直接的估计策略: 在每个 $X = k$ 的层内, 估计 $\mathbb{E}(Y | Z = 1, X = k)$ 和 $\mathbb{E}(Y | Z = 0, X = k)$, 然后按 $\Pr(X = k)$ 加权平均。

这个方法与第五章讨论的分层随机实验 (STR) 估计量形式上相同。⁴

但这种方法有两个明显困难:

- (1) 当 K 很大时, 许多层可能只包含治疗组或只包含对照组的单元, 导致层内估计量定义不良;
- (2) 对于多维连续协变量, 如何定义“层”并不显然。

这些困难促使我们寻找更一般的估计策略。

5.2. 结果回归. 结果回归 (Outcome Regression) 的核心思想是: 首先对条件期望 $\mathbb{E}(Y | Z, X)$ 建立模型, 然后利用 eq. (66) 估计因果效应。

最常用的方法是对结果拟合一个线性加性模型:

$$(68) \quad \mathbb{E}(Y | Z, X) = \beta_0 + \beta_z Z + \beta_x^\top X.$$

在 eq. (68) 下, 给定 X 的因果效应是:

$$\tau(X) = \mathbb{E}(Y | Z = 1, X) - \mathbb{E}(Y | Z = 0, X) = \beta_z,$$

它不依赖于 X ——这意味着线性模型假设了因果效应的同质性。

因此, 平均因果效应为 $\tau = \mathbb{E}\{\tau(X)\} = \beta_z$ 。如果我们相信不可识别性假设且线性模型正确, 那么 β_z 就是我们关心的因果效应。

更一般的形式: 如果我们允许治疗与协变量的交互, 可以拟合:

$$(69) \quad \mathbb{E}(Y | Z, X) = \beta_0 + \beta_z Z + \beta_x^\top X + \beta_{zx}^\top X Z.$$

此时 $\tau(X) = \beta_z + \beta_{zx}^\top X$, 而 $\tau = \beta_z + \beta_{zx}^\top \mathbb{E}(X)$ 。⁵

一般结果回归估计量: 如果我们用两个预测模型 $\hat{\mu}_1(X)$ 和 $\hat{\mu}_0(X)$ 分别估计 $\mathbb{E}(Y | Z = 1, X)$ 和 $\mathbb{E}(Y | Z = 0, X)$, 则因果效应的估计为:

$$(70) \quad \hat{\tau}^{\text{reg}} = n^{-1} \sum_{i=1}^n \{\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i)\}.$$

eq. (70) 与第六章讨论的投影估计量 (projective estimator) 形式相同,⁶ 这不是巧合——结果回归本质上是一种基于模型的预测方法。

模型敏感性: 结果回归方法的核心问题在于其对模型设定的敏感性。如果 eq. (68) 或 eq. (69) 不能正确描述数据生成过程, 估计量就可能是有偏的。⁷ 早已批评了这种方法在实证研究中的滥用——研究者可能会在众多候选模型中选择报告“符合预期”的因果效应估计, 这是因果推断中 p-hacking 的主要来源之一。⁷

6. 二值结果的情形

当结果 Y 是二值变量时, 我们可以使用逻辑斯谛模型:

$$(71) \quad \mathbb{E}(Y | Z, X) = \Pr(Y = 1 | Z, X) = \frac{e^{\beta_0 + \beta_z Z + \beta_x^\top X}}{1 + e^{\beta_0 + \beta_z Z + \beta_x^\top X}}.$$

⁴详见 section 3。

⁵这个估计量与 ? 在随机实验背景下提出的估计量形式相同。

⁶详见 ??。

⁷关于模型敏感性问题的更多讨论, 见 ?, Problem 1.4。

基于 eq. (71) 的估计系数，我们可以构造平均因果效应的估计：⁸

$$\hat{\tau} = n^{-1} \sum_{i=1}^n \left\{ \frac{e^{\hat{\beta}_0 + \hat{\beta}_z + \hat{\beta}_x^\top X_i}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_z + \hat{\beta}_x^\top X_i}} - \frac{e^{\hat{\beta}_0 + \hat{\beta}_x^\top X_i}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_x^\top X_i}} \right\}.$$

注意，这个估计量不再是逻辑斯谛模型中 Z 的简单系数——它是非线性函数，依赖于所有系数以及协变量的经验分布。在计量经济学中，这被称为逻辑斯谛模型中的“平均偏效应”或“平均边际效应”。

7. 本章小结

本章作为 Part III 的开篇，介绍了观测性研究中因果推断的四个核心方法（“Four Pillars”）中的第一个——结果回归。关键点如下：

- (1) **选择偏差**是观测性研究的核心困难：治疗组和对照组在潜在结果分布上可能不同。
- (2) **不可识别性假设** ($Y(z) \perp Z \mid X$) 提供了识别因果效应的充分条件——所有混杂因素都被协变量 X 所控制。
- (3) 在不可识别性假设下，因果效应可以写为条件期望之差的无条件期望（定义 10.1）。
- (4) **结果回归**通过建立 $\mathbb{E}(Y \mid Z, X)$ 的模型来估计因果效应，是四种核心方法中最直观的一种。
- (5) 结果回归的核心问题是**模型敏感性**——错误指定的模型会导致有偏的估计。

不可识别性假设虽然提供了理论上的识别条件，但在实际研究中，其可塑性取决于我们是否观察到了所有重要的混杂因素。后续章节将介绍其他三种方法（逆概率加权、双稳健估计、匹配），它们从不同角度应对这一挑战。

8. 练习

- (1) **简单恒等式**：证明 $\tau = \Pr(Z = 1)\tau_T + \Pr(Z = 0)\tau_C$ 。
- (2) **不可识别性的可塑性**：考虑以下数据生成过程：

$$Y(1) = g_1(X, V_1), \quad Y(0) = g_0(X, V_0), \quad Z = \mathbb{I}\{g(X, V) \geq 0\},$$

其中 $(V_1, V_0) \perp V$ 。解释为什么在这种情况下不可识别性假设成立。如果将 V 替换为未观测的混杂因素 U ，结果会如何变化？

- (3) **完全交互逻辑斯谛模型**：假设二值结果 Y 服从以下逻辑斯谛模型：

$$\mathbb{E}(Y \mid Z, X) = \frac{e^{\beta_0 + \beta_z Z + \beta_x^\top X + \beta_{xz}^\top X Z}}{1 + e^{\beta_0 + \beta_z Z + \beta_x^\top X + \beta_{xz}^\top X Z}}.$$

推导平均因果效应 τ 的估计量。

- (4) **模型敏感性实验**：使用模拟数据，比较在线性模型正确和错误设定下，结果回归估计量的表现。讨论模型偏误对估计的影响。

9. 推荐阅读

- ? —不可识别性假设的奠基性论文。
- ? —倾向得分理论的核心工作，阐述了不可识别性与倾向得分的关系。
- ? —对实证研究中模型依赖性的经典批评。
- ? —g-formula 的系统介绍与现代视角。
- ? —随机实验中协变量调整的理论分析。

⁸推导见附录 ??

倾向得分在观测性研究中的核心地位

1. 引言：为什么需要倾向得分？

在第 10 章中，我们讨论了观测性研究的核心困难：治疗分配并非由研究者控制，因此治疗组和对照组之间存在系统性差异——**选择性偏差 (selection bias)**。在随机实验中，我们通过 randomization 将潜在混淆因素“均衡”到两组，使得观察到的结果差异可以归因于 treatment。但在观测性研究中，治疗分配往往与潜在结果相关联，直接比较两组结果会产生误导性结论。

解决这一问题的传统思路是 **outcome regression**——对给定协变量 X 下的潜在结果建模。然而，协变量 X 通常是高维的、包含众多背景特征，我们并不想对这些背景信息建模——因为它们是发生在治疗 and 结果之前的信息，本质上是“历史”的一部分。

一个更自然的思路是：如果我们无法很好地建模结果，那么至少可以尝试建模**治疗分配机制**本身。正是这一思路引出了本章的核心概念——倾向得分。

2. 倾向得分的定义与降维性质

2.1. 倾向得分的定义. 在观测性研究中，治疗分配机制 $\Pr(Z = 1 | X)$ 刻画了给定协变量 X 时单元接受治疗的概率。我们将这一条件概率定义为**倾向得分 (propensity score)**：

定义 11.1 (倾向得分 (Propensity Score)). 倾向得分定义为给定协变量 X 时接受治疗的概率：

$$e(X) = \Pr(Z = 1 | X).$$

倾向得分是一个取值在 $[0, 1]$ 之间的标量。当 $e(X_i) = 0.8$ 时，这意味着给定该单元的协变量 X_i 后，它有 80% 的概率接受治疗。

直观理解：倾向得分可以看作治疗分配的“强度”度量。在随机实验中， $e(X) = \Pr(Z = 1)$ 是常数——因为 randomization 完全控制了治疗分配。在观测性研究中，倾向得分随 X 变化——它反映了哪些协变量特征使得某些单元更倾向于接受治疗。

2.2. 降维定理. 倾向得分的核心价值在于其**降维性质**：虽然原始协变量 X 可能维数很高，但倾向得分 $e(X)$ 是一个一维标量，且保留了 X 中所有关于治疗分配的信息。

定理 11.2 (Rosenbaum & Rubin, 1983). 在强可忽略性 (*strong ignorability*) 假设下，如果

$$\{Y(1), Y(0)\} \perp\!\!\!\perp Z | X,$$

则

$$\{Y(1), Y(0)\} \perp\!\!\!\perp Z | e(X).$$

定义 11.2 表明，给定倾向得分 $e(X)$ 后，潜在结果与治疗指示变量条件独立——这与给定完整协变量 X 的条件独立性相同。这意味着，如果我们能够调整倾向得分，就能够消除所有由协变量引起的混淆。

为什么这个结果重要？ 原始协变量 X 可以是任意维数的（年龄、收入、教育、职业……），但倾向得分 $e(X)$ 是一个 $[0, 1]$ 区间的标量。通过调整这个一维变量，我们等价于调整了所有原始协变量——这就是 Rosenbaum 和 Rubin 称之为“降维工具”的含义。¹

与分层随机实验的联系： 在第 5 章中，我们讨论了分层随机实验（SRE）。如果我们按倾向得分 $e(X)$ 的取值对单元进行分层，那么每一层内的观测性数据与 SRE 具有相同的结构——因为给定相同的倾向得分，治疗分配与潜在结果条件独立。

3. 倾向得分分层

3.1. 已知离散倾向得分。 假设倾向得分 $e(X)$ 已知，且仅取 K 个不同的值 $\{e_1, \dots, e_K\}$ 。由定义 11.2，在每一层 e_k 内，治疗分配与潜在结果条件独立。因此，我们有 K 个独立的完全随机实验（CRE）——这正是第 5 章讨论的 SRE 结构。

总体平均因果效应可以通过分层估计量进行估计：

$$\hat{\tau}_{PS} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]},$$

其中 $\pi_{[k]}$ 是第 k 层的总体比例， $\hat{\tau}_{[k]}$ 是该层内的差值均值。²

实践中的问题： K 的选择需要权衡。如果 K 太小，分层后的条件独立性可能不成立；如果 K 太大，每层内的样本量不足，许多层可能只包含治疗组或对照组的单元。根据？的建议， $K = 5$ 在许多场景下能够消除大部分偏差——这个“神奇的数字 5”将再次出现在本章的讨论中。

3.2. 未知连续倾向得分。 在实际情况中，倾向得分通常是未知的，我们需要通过统计模型进行估计。最常见的方法是拟合一个 **logistic 回归模型**：

$$\text{logit}\{e(X)\} = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p.$$

估计得到的倾向得分 $\hat{e}(X)$ 可以取多达 n 个不同的值（当每个单元的协变量都不完全相同时）。为了应用分层方法，我们需要对 $\hat{e}(X)$ 进行离散化。一种常用策略是按其**分位数**进行分层：³

例 11.1 (NHANES 数据集的倾向得分分层). 考虑 ?? 中的 NHANES 数据。我们使用 *logistic* 模型估计倾向得分，然后按分位数将样本分为 K 层。*fig. 1* 展示了不同 K 值 ($K = 5, 10, 30$) 下，治疗组和对照组倾向得分分布的直方图。

FIGURE 1. NHANES 数据集中估计倾向得分的直方图：白色为对照组，灰色为治疗组。

当倾向得分未知且连续时，倾向得分分层估计量的有效性依赖于以下两个条件：

- (1) **正确设定：** 模型 $\Pr(Z = 1 | X)$ 正确设定，使得 $\hat{e}(X)$ 能够捕捉真实的倾向得分。
- (2) **重叠条件 (Overlap condition)：** $0 < e(X) < 1$ 对所有单元成立——这确保每个单元都有接受治疗和对照的可能性。⁴

¹推导见附录 ??

²详细推导见附录 ??

³详细讨论见附录 ??

⁴重叠条件的详细讨论见附录 ??

稳健性观察：倾向得分分层估计量只需要 $\hat{e}(X)$ 的排序正确，而不需要其精确值——这使得它相对于其他方法更加稳健。这一性质在许多数值例子中得到验证，但其严格量化理论仍在研究中。

4. 逆概率加权估计量

4.1. Horvitz–Thompson 估计量。基于倾向得分，我们可以构造平均因果效应的估计量。一个直接的想法是使用**逆概率加权 (Inverse Probability Weighting, IPW)**：

$$\hat{\tau}_{\text{HT}} = \frac{1}{n} \sum_{i=1}^n \left\{ \frac{Z_i Y_i}{e(X_i)} - \frac{(1 - Z_i) Y_i}{1 - e(X_i)} \right\}.$$

section 4.1 被称为 **Horvitz–Thompson (HT) 估计量**。⁵ 在抽样调查中首次提出这一估计量，⁶ 将其引入因果推断领域。

为什么这个估计量有效？直观上，对于治疗组的单元，我们用 $1/e(X_i)$ 作为权重进行加权——倾向得分越小的单元（即越“不像”会接受治疗的单元），其权重越大。这相当于对这些单元进行“过度代表”，以消除由选择性偏差造成的治疗组和对照组之间的系统性差异。⁵

稳定性问题：当某些单元的倾向得分接近 0 或 1 时，权重 $1/e(X_i)$ 或 $1/(1 - e(X_i))$ 会变得非常大，导致估计量不稳定。HT 估计量在有限样本中可能表现极差——某些估计值可能远离其他所有方法的结果。⁶

4.2. 标准化逆概率加权估计量。为了解决 HT 估计量的不稳定性问题，一个自然的修正是对权重进行**标准化**：

$$\hat{\tau}_{\text{IPW}} = \frac{1}{\hat{\mathbf{1}}_T} \sum_{i=1}^n \frac{Z_i Y_i}{e(X_i)} - \frac{1}{\hat{\mathbf{1}}_C} \sum_{i=1}^n \frac{(1 - Z_i) Y_i}{1 - e(X_i)},$$

其中

$$\hat{\mathbf{1}}_T = \sum_{i=1}^n \frac{Z_i}{e(X_i)}, \quad \hat{\mathbf{1}}_C = \sum_{i=1}^n \frac{1 - Z_i}{1 - e(X_i)}.$$

直观理解：标准化权重的思想是将权重之和调整为 1——即 $\hat{\mathbf{1}}_T$ 和 $\hat{\mathbf{1}}_C$ 分别代表治疗组和对照组的“有效样本量”。标准化后的估计量对常数平移不敏感，而原始 HT 估计量则不具备这一性质。⁷

例 11.2 (NHANES 数据的逆概率加权估计). 延续例 11.1，我们对 NHANES 数据应用不同截断水平的逆概率加权估计量。

TABLE 1. 不同截断水平下的 IPW 估计量

截断水平	点估计	标准误
(0, 1) (无截断)	−52.3	18.2
(0.01, 0.99)	−8.7	4.3
(0.05, 0.95)	−6.2	3.8
(0.10, 0.90)	−5.1	3.5

⁵HT 估计量的期望推导见附录 ??

⁶HT 估计量的方差分析见附录 ??

⁷标准化估计量的性质证明见附录 ??

如 table 1 所示，无截断的 HT 估计量给出极端的估计值，而适当截断后的 IPW 估计量与倾向得分分层估计量的结果相近。这说明**截断是控制 IPW 估计量稳定性的关键手段**。

5. 倾向得分的平衡性质

5.1. 平衡性定理. 倾向得分不仅在降维方面有重要价值，还具有一个深刻的**平衡性质**——这是？理论中的另一核心结论。

定理 11.3 (倾向得分的平衡性质). 倾向得分 $e(X)$ 满足以下性质：

- (1) 条件独立性： $X \perp\!\!\!\perp Z \mid e(X)$;
- (2) 加权平衡：对于任何协变量函数 $g(X)$ ，有

$$\mathbb{E} \left\{ \frac{Zg(X)}{e(X)} \right\} = \mathbb{E}\{g(X)\}.$$

定义 11.3 的第一个结论指出，给定倾向得分后，协变量 X 与治疗指示变量 Z 条件独立——这意味着在相同的倾向得分水平下，治疗组和对照组的协变量分布是平衡的。第二个结论以加权形式表达了相同的平衡性。⁸

为什么平衡性质重要？ 定义 11.3 不依赖于强可忽略性假设——它只涉及治疗 Z 与协变量 X 之间的关系。因此，在访问结果数据之前，我们就可以检查倾向得分模型是否充分好地实现了协变量平衡。？将这一步骤称为观测性研究的**设计阶段 (design stage)**——因为这一阶段不涉及结果数据，可以更加客观。

5.2. 协变量平衡的检验. 在实践中，我们使用估计的倾向得分 $\hat{e}(X)$ 来检验协变量平衡。首先对 $\hat{e}(X)$ 按分位数离散化，然后在每一层内检验治疗组和对照组协变量分布的差异：

$$\text{Bias}_{[k]} = \frac{1}{n_{[k]}} \sum_{i: \hat{e}'(X_i)=e_k} Z_i g(X_i) - \frac{1}{n_{[k]}} \sum_{i: \hat{e}'(X_i)=e_k} (1 - Z_i) g(X_i) \approx 0.$$

如果上述偏差在所有层中都接近于零，则倾向得分模型是合适的；如果存在系统性偏差，则需要重新指定模型。

设计阶段与分析阶段的区分：？强调，将统计分析分为”设计阶段”（只使用治疗分配和协变量）和”分析阶段”（同时使用结果数据）可以使因果推断更加客观。协变量平衡的检验正是设计阶段的核心工具。

6. 与结果回归的对比

本章讨论的逆概率加权方法与第 10 章的结果回归方法代表了两条不同的因果推断路径：

TABLE 2. 逆概率加权 vs. 结果回归

	逆概率加权 (IPW)	结果回归
建模对象	治疗分配机制 $\Pr(Z = 1 \mid X)$	结果模型 $\mathbb{E}(Y \mid Z, X)$
识别条件	倾向得分模型正确	结果模型正确
稳健性	对倾向得分模型敏感	对结果模型敏感
效率	依赖倾向得分估计精度	依赖结果模型拟合

⁸平衡性质的证明见附录 ??

两条路径各有优劣，这促使研究者探索**双重稳健 (doubly robust)** 方法——同时利用两种模型的信息，使得只要其中之一正确就能保证一致性。第 12 章将详细讨论这一方向。

7. 重叠条件与外推风险

在使用倾向得分方法时，一个关键技术假设是**重叠条件 (overlap condition)**：

$$0 < e(X) < 1 \quad \text{对所有单元都成立.}$$

这一条件确保每个单元都有接受治疗和对照的可能性。当 $e(X_i) = 1$ 时，单元 i 必然接受治疗，其潜在结果 $Y_i(0)$ 永远无法被观测——这类结果被称为**极端反事实 (extreme counterfactual)**。讨论了极端反事实对因果推断的危害。

重叠条件的违背会导致两个问题：

- (1) **识别问题**：识别公式中的分母可能为零；
- (2) **外推风险**：对倾向得分接近 0 或 1 的单元进行估计，本质上是外推而非插值。

即使强重叠条件对真实倾向得分成立，估计的倾向得分仍可能接近 0 或 1。截断策略是一种实用的解决方案，但截断水平的选择需要权衡偏差和方差。

8. 本章小结

本章介绍了倾向得分在观测性研究因果推断中的核心地位，主要内容如下：

- (1) **倾向得分的定义 (定义 11.1)**： $e(X) = \Pr(Z = 1 | X)$ ，是治疗分配机制的条件概率。
- (2) **降维性质 (定义 11.2)**：给定倾向得分后，潜在结果与治疗条件独立——这意味着调整一维倾向得分等价于调整所有高维协变量。
- (3) **倾向得分分层**：按倾向得分的取值对单元进行分层，每层内构成独立的完全随机实验。
- (4) **逆概率加权估计量 (section 4.2)**：Horvitz-Thompson 估计量的标准化版本，通过逆概率加权消除选择性偏差。
- (5) **平衡性质 (定义 11.3)**：倾向得分具有协变量平衡性质——给定倾向得分后，治疗组和对照组的协变量分布相同。
- (6) **重叠条件**： $0 < e(X) < 1$ 是确保识别公式有意义的必要条件，截断是处理不稳定性的实用策略。

9. 习题

练习 11.1. 倾向得分的降维性质 证明 定义 11.2: 在强可忽略性假设下, 如果 $\{Y(1), Y(0)\} \perp\!\!\!\perp Z | X$, 则 $\{Y(1), Y(0)\} \perp\!\!\!\perp Z | e(X)$ 。

提示：利用概率论中的推论——如果 $A \perp\!\!\!\perp B | C$, 且 D 是 C 的函数, 则 $A \perp\!\!\!\perp B | D$ 。

练习 11.2. HT 估计量的期望 证明 HT 估计量 section 4.1 是总体平均因果效应 τ 的无偏估计。

提示：分别计算 $\mathbb{E}\left(\frac{ZY(1)}{e(X)}\right)$ 和 $\mathbb{E}\left(\frac{(1-Z)Y(0)}{1-e(X)}\right)$, 利用 $e(X) = \Pr(Z = 1 | X)$ 。

练习 11.3. 标准化权重的性质 验证 section 4.2 中标准化权重的性质： $\hat{\mathbf{1}}_T$ 和 $\hat{\mathbf{1}}_C$ 在使用真实倾向得分时，其期望均为 n 。

注：这也是 τ 中使用特殊记号 $\hat{\mathbf{1}}_T$ 和 $\hat{\mathbf{1}}_C$ 的原因——这两个量的期望都是 1。

练习 11.4. 倾向得分的平衡性质证明 证明 定义 11.3 的第二个结论：对于任意协变量函数 $g(X)$,

$$\mathbb{E} \left\{ \frac{Zg(X)}{e(X)} \right\} = \mathbb{E}\{g(X)\}.$$

提示：使用 *tower property* 和条件概率的定义。

练习 11.5. 协变量平衡的数值检验 使用 例 11.1 中的 *NHANES* 数据，检验不同分层数量 K 下的协变量平衡。报告治疗组和对照组在各层内关键协变量（如年龄、*BMI*）均值之差的绝对值。

练习 11.6. 截断水平的敏感性分析 对 *table 1* 中的结果进行敏感性分析：比较不同截断水平对点估计和标准误的影响，讨论截断水平选择的实际准则。

练习 11.7. *IPW* 与结果回归的比较 使用第 10 章中的模拟数据或真实数据，分别应用 *IPW* 估计量和结果回归估计量，比较两者的点估计和置信区间。

练习 11.8. 极端反事实的影响？ 讨论了极端反事实问题。构造一个例子，其中某些单元的倾向得分接近 1，讨论这种情况下因果推断面临的挑战。

双重稳健估计

1. 引言：一个估计量的双重保险

在第 11 章中，我们遇到了一个基本的张力：使用观测数据进行因果推断时，我们需要在两个识别公式之间做出选择。

第一个是**结果回归公式** (outcome regression)：

$$\tau = E\{\mu_1(X)\} - E\{\mu_0(X)\},$$

其中 $\mu_1(X) = E(Y | Z = 1, X)$ 和 $\mu_0(X) = E(Y | Z = 0, X)$ 分别是治疗组和对照组在给定协变量 X 下的条件均值函数。这个公式的美妙之处在于：只要我们能正确建模 $\mu_1(X)$ 和 $\mu_0(X)$ ，就能一致地估计 τ 。但问题在于，如果模型错了，估计量就会产生偏倚。

第二个是**逆概率加权公式** (IPW)：

$$\tau = E\left\{\frac{ZY}{e(X)}\right\} - E\left\{\frac{(1-Z)Y}{1-e(X)}\right\},$$

其中 $e(X) = \Pr(Z = 1 | X)$ 是倾向得分。这个公式同样优雅：只要倾向得分模型正确，估计量就是一致的。但它的弱点同样明显——如果 $e(X)$ 模型错了，后果可能是灾难性的。

一个自然的问题应运而生：**能否构造一个估计量，只要两个模型中任意一个正确，就能保证一致性？**

这正是 James Robins 及其合作者(??)提出的双重稳健估计量 (doubly robust estimator) 的核心思想。正如我们在下面将看到的，这个估计量巧妙地结合了结果回归和逆概率加权的优点。

2. 总体版本的 DR 估计量

为了构造双重稳健估计量，我们同时引入两个工作模型 (working models)：

- **结果模型**： $\mu_1(X, \beta_1)$ 和 $\mu_0(X, \beta_0)$ ，分别建模 $E(Y(1) | X)$ 和 $E(Y(0) | X)$ 。当结果模型正确时， $\mu_1(X, \beta_1) = \mu_1(X)$ 。
- **倾向得分模型**： $e(X, \alpha)$ ，建模 $\Pr(Z = 1 | X)$ 。当倾向得分模型正确时， $e(X, \alpha) = e(X)$ 。

在实践中，这两个模型都可能错误设定——这也是为什么我们称之为“工作模型”。基于这两个工作模型，我们定义：

$$(72) \quad \tilde{\mu}_1^{\text{dr}} = E\left[\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X, \alpha)} + \mu_1(X, \beta_1)\right],$$

$$(73) \quad \tilde{\mu}_0^{\text{dr}} = E\left[\frac{(1-Z)\{Y - \mu_0(X, \beta_0)\}}{1 - e(X, \alpha)} + \mu_0(X, \beta_0)\right].$$

这两个公式有另一种等价的书写方式，将它们重新整理为：

$$(74) \quad \tilde{\mu}_1^{\text{dr}} = E \left[\frac{ZY}{e(X, \alpha)} - \frac{Z - e(X, \alpha)}{e(X, \alpha)} \mu_1(X, \beta_1) \right],$$

$$(75) \quad \tilde{\mu}_0^{\text{dr}} = E \left[\frac{(1 - Z)Y}{1 - e(X, \alpha)} - \frac{e(X, \alpha) - Z}{1 - e(X, \alpha)} \mu_0(X, \beta_0) \right].$$

观察这两种形式，我们发现：

- eq. (72) 和 eq. (73) 是对结果回归估计量的”增强”——在结果回归的基础上添加了逆概率加权项来修正残差。
- eq. (74) 和 eq. (75) 是对 IPW 估计量的”增强”——在逆概率加权的基础上添加了插补结果的修正项。

正因为这种双向增强的结构，双重稳健估计量也被称为**增强逆概率加权估计量** (augmented inverse propensity score weighting, AIPW)。

3. 双重稳健性定理

下面这个定理是双重稳健估计量的理论核心。

定理 12.1 (双重稳健性). 假设可忽略性 $Z \perp \{Y(1), Y(0)\} \mid X$ 和 *overlap* $0 < e(X) < 1$ 。

- (1) 若 $e(X, \alpha) = e(X)$ 或 $\mu_1(X, \beta_1) = \mu_1(X)$ 之一成立，则 $\tilde{\mu}_1^{\text{dr}} = E\{Y(1)\}$ 。
- (2) 若 $e(X, \alpha) = e(X)$ 或 $\mu_0(X, \beta_0) = \mu_0(X)$ 之一成立，则 $\tilde{\mu}_0^{\text{dr}} = E\{Y(0)\}$ 。
- (3) 若 $e(X, \alpha) = e(X)$ 或 $\{\mu_1(X, \beta_1) = \mu_1(X), \mu_0(X, \beta_0) = \mu_0(X)\}$ 之一成立，则 $\tilde{\mu}_1^{\text{dr}} - \tilde{\mu}_0^{\text{dr}} = \tau$ 。

为什么称为”双重”稳健？ 因为只要倾向得分模型和结果模型中任意一个正确， $\tilde{\mu}_1^{\text{dr}} - \tilde{\mu}_0^{\text{dr}}$ 就等于 τ 。这给了估计量两次”保险”的机会。¹

4. 样本版本的 DR 估计量

从总体版本 eq. (72) 和 eq. (73) 出发，我们可以用样本 analog 直接构造估计量。

定义 12.2 (平均因果效应的双重稳健估计量). 基于数据 $(X_i, Z_i, Y_i)_{i=1}^n$ ，按以下步骤构造 τ 的双重稳健估计量：

- (1) 拟合倾向得分：得到 $e(X_i, \hat{\alpha})$ ；
- (2) 拟合结果均值：得到 $\mu_1(X_i, \hat{\beta}_1)$ 和 $\mu_0(X_i, \hat{\beta}_0)$ ；
- (3) 构造双重稳健估计量 $\hat{\tau}^{\text{dr}} = \hat{\mu}_1^{\text{dr}} - \hat{\mu}_0^{\text{dr}}$ ，其中

$$\hat{\mu}_1^{\text{dr}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{Z_i \{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{e(X_i, \hat{\alpha})} + \mu_1(X_i, \hat{\beta}_1) \right],$$

$$\hat{\mu}_0^{\text{dr}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{(1 - Z_i) \{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - e(X_i, \hat{\alpha})} + \mu_0(X_i, \hat{\beta}_0) \right].$$

根据定义 12.2，我们还可以将双重稳健估计量写成更直观的形式：²

$$\hat{\tau}^{\text{dr}} = \hat{\tau}^{\text{reg}} + \frac{1}{n} \sum_{i=1}^n \frac{Z_i \{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{e(X_i, \hat{\alpha})} - \frac{1}{n} \sum_{i=1}^n \frac{(1 - Z_i) \{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - e(X_i, \hat{\alpha})}.$$

¹定理 定义 12.1 的完整证明见附录 section 10。

²推导见附录 section 11

这个形式揭示了双重稳健估计量的本质：它从结果回归估计量 $\hat{\tau}^{\text{reg}}$ 出发，通过添加修正项来获得鲁棒性。类似地，利用 eq. (74) 和 eq. (75)，我们也可以写成：³

$$\hat{\tau}^{\text{dr}} = \hat{\tau}^{\text{ipw}} - \frac{1}{n} \sum_{i=1}^n \frac{Z_i - e(X_i, \hat{\alpha})}{e(X_i, \hat{\alpha})} \mu_1(X_i, \hat{\beta}_1) + \frac{1}{n} \sum_{i=1}^n \frac{e(X_i, \hat{\alpha}) - Z_i}{1 - e(X_i, \hat{\alpha})} \mu_0(X_i, \hat{\beta}_0).$$

关于方差估计，？建议使用非参数 bootstrap 来近似 $\hat{\tau}^{\text{dr}}$ 的方差。

5. 更深层的直觉

虽然 eq. (72) 和 eq. (73) 的形式看起来并不显然，但它们可以从两个不同的直观角度推导出来。这两个角度恰好对应了结果回归和 IPW 的各自弱点。

5.1. 从 IPW 出发：降低方差. IPW 估计量 $\mu_1 = E\left\{\frac{ZY}{e(X)}\right\}$ 完全忽略了 Y 的结果模型。它的优势在于不需要任何结果模型假设就能保持一致性。然而，如果协变量能够预测结果，那么即使工作结果模型错误，基于残差的伪潜在结果通常比原始结果具有更小的方差。

给定一个可能错误设定的工作模型 $\mu_1(X, \beta_1)$ ，我们可以做一个简单的分解：⁴

$$\mu_1 = E\{Y(1)\} = E\{Y(1) - \mu_1(X, \beta_1)\} + E\{\mu_1(X, \beta_1)\} = E\left\{\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X)} + \mu_1(X, \beta_1)\right\}.$$

使用工作模型来提高效率是调查采样中的传统思想。？和？都指出了它与双重稳健估计量的联系。

5.2. 从结果回归出发：降低偏倚. 另一种思路是从结果回归出发，改善其偏倚。结果回归估计量 $\tilde{\mu}_1 = E\{\mu_1(X, \beta_1)\}$ 可能不等于 μ_1 ，因为结果模型可能是错误的。这个估计量的偏倚是 $E\{\mu_1(X, \beta_1) - Y(1)\}$ ，它可以用 IPW 估计量来估计：⁵

$$B = E\left\{\frac{Z\{\mu_1(X, \beta_1) - Y\}}{e(X)}\right\},$$

只要倾向得分模型正确。因此，去偏估计量 $\tilde{\mu}_1 - B$ 恰好等于 eq. (72)。这给出了构造双重稳健估计量的第二个直观视角。

6. 模拟研究

为了评估双重稳健估计量在有限样本下的表现，我们考虑四种场景：⁶

- (1) 倾向得分模型和结果模型都正确；
- (2) 倾向得分模型错误，但结果模型正确；
- (3) 倾向得分模型正确，但结果模型错误；
- (4) 倾向得分模型和结果模型都错误。

关键发现：场景 1-3 验证了双重稳健性——只要其中一个模型正确，DR 估计量就几乎无偏。但在场景 4（两个模型都错误）中，DR 估计量可能表现出“双重脆弱性”——两个误差的乘积导致比单独使用任一模型更大的偏差。⁷

³推导见附录 section 11

⁴推导见附录 section 12

⁵推导见附录 section 13

⁶模拟细节和完整结果见附录 section 15。

⁷模拟结果表格见附录 section 15。

7. 进一步讨论：为何脆弱？

回顾 定义 12.1 的证明，双重稳健性的关键在于以下乘积结构：⁸

$$\tilde{\mu}_1^{\text{dr}} - E\{Y(1)\} = E \left[\frac{e(X) - e(X, \alpha)}{e(X, \alpha)} \times \{\mu_1(X) - \mu_1(X, \beta_1)\} \right].$$

只要 $e(X) = e(X, \alpha)$ 或 $\mu_1(X) = \mu_1(X, \beta_1)$ 之一成立，上式就为零。然而，当两个模型都错误时，两个误差的乘积可能放大偏差——这就是“双重脆弱性”的数学本质。模拟研究证实了这一点。

尽管？基于模拟研究批评了双重稳健估计量，但自？的开创性工作以来，双重稳健估计量一直是因果推断的标准策略。近年来，它在理论统计和计量经济学文献中以更响亮的名字“双机器学习”（double machine learning）重新兴起。？的基本思想是用更灵活的机器学习工具替代传统的参数工作模型。

8. 本章小结

本章介绍了双重稳健估计量，主要内容如下：

- (1) **核心思想**：结合结果回归和 IPW，只要其中一个模型正确就能保证一致性。
- (2) **公式结构 (eq. (72)–eq. (73))**：增强逆概率加权估计量 (AIPW)。
- (3) **双重稳健性 (定义 12.1)**：只要倾向得分模型或结果模型之一正确， $\tilde{\mu}_1^{\text{dr}} - \tilde{\mu}_0^{\text{dr}} = \tau$ 。
- (4) **两种直觉视角**：从 IPW 降方差 (section 5.1) 和从结果回归降偏倚 (section 5.2)。
- (5) **双重脆弱性**：当两个模型都错误时，两个误差的乘积可能放大偏差。

9. 习题

练习 12.1. 验证双重稳健性 考虑协变量离散的情况 $X \in \{1, \dots, K\}$ 。证明在这种情况下，分层估计量、结果回归估计量、Horvitz-Thompson 估计量、Hajek 估计量和双重稳健估计量在数值上是完全相同的。[参见？, Theorem 12.1]

练习 12.2. DR 估计量的另一种形式 基于 eq. (72)，给出 $\mu_1 = E\{Y(1)\}$ 的双重稳健估计量的另一种形式：

$$\tilde{\mu}_1^{\text{dr2}} = \frac{E \left[\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X, \alpha)} \right]}{E \left[\frac{Z}{e(X, \alpha)} \right]} + E\{\mu_1(X, \beta_1)\}.$$

证明若 $e(X, \alpha) = e(X)$ 或 $\mu_1(X, \beta_1) = \mu_1(X)$ 之一成立，则 $\tilde{\mu}_1^{\text{dr2}} = \mu_1$ 。给出估计 μ_0 的类似公式，并给出基于这些公式的 τ 的双重稳健估计量的样本 analog。[参见？, 式 (12.7)]

练习 12.3. DR 估计量的方差 证明 section 4 和 section 4 的等价性。[参见？, 式 (12.9)]

⁸详细推导见附录 section 14

10. 定理 定义 12.1 的证明

背景：我们需要证明在 ignorability 和 overlap 假设下，双重稳健估计量满足 $\tilde{\mu}_1^{\text{dr}} = E\{Y(1)\}$ 当且仅当倾向得分模型或结果模型之一正确。

证明：这里给出第一部分的证明，第二部分类似。考虑分解：⁹

$$\begin{aligned}\tilde{\mu}_1^{\text{dr}} - E\{Y(1)\} &= E \left[\frac{Z\{Y(1) - \mu_1(X, \beta_1)\}}{e(X, \alpha)} - \{Y(1) - \mu_1(X, \beta_1)\} \right] \\ &= E \left[\frac{Z - e(X, \alpha)}{e(X, \alpha)} \{Y(1) - \mu_1(X, \beta_1)\} \right] \\ &= E \left(E \left[\frac{Z - e(X, \alpha)}{e(X, \alpha)} \{Y(1) - \mu_1(X, \beta_1)\} \mid X \right] \right) \quad (\text{tower property}) \\ &= E \left[E \left\{ \frac{Z - e(X, \alpha)}{e(X, \alpha)} \mid X \right\} \times E \{Y(1) - \mu_1(X, \beta_1) \mid X\} \right] \quad (\text{ignorability}) \\ &= E \left[\frac{e(X) - e(X, \alpha)}{e(X, \alpha)} \times \{\mu_1(X) - \mu_1(X, \beta_1)\} \right].\end{aligned}$$

由此可知，上式为零当且仅当 $e(X) = e(X, \alpha)$ 或 $\mu_1(X) = \mu_1(X, \beta_1)$ 之一成立。 $\square$

11. 双重稳健估计量的等价形式推导

section 4 的推导。从 定义 12.2 出发：

$$\hat{\tau}^{\text{dr}} = \hat{\mu}_1^{\text{dr}} - \hat{\mu}_0^{\text{dr}} = \frac{1}{n} \sum_{i=1}^n [\mu_1(X_i, \hat{\beta}_1) - \mu_0(X_i, \hat{\beta}_0)] + \frac{1}{n} \sum_{i=1}^n \left[\frac{Z_i \{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{e(X_i, \hat{\alpha})} - \frac{(1 - Z_i) \{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - e(X_i, \hat{\alpha})} \right]$$

第一项恰好是结果回归估计量 $\hat{\tau}^{\text{reg}}$ ，于是得到 section 4。

section 4 的推导。利用恒等式

$$\frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X, \alpha)} = \frac{ZY}{e(X, \alpha)} - \frac{Z}{e(X, \alpha)} \mu_1(X, \beta_1),$$

以及

$$\frac{(1 - Z)\{Y - \mu_0(X, \beta_0)\}}{1 - e(X, \alpha)} = \frac{(1 - Z)Y}{1 - e(X, \alpha)} - \frac{1 - Z}{1 - e(X, \alpha)} \mu_0(X, \beta_0),$$

代入 section 4 并重新整理项，可得 section 4。

12. 从 IPW 到 DR 的分解

从分解

$$\mu_1 = E\{Y(1)\} = E\{Y(1) - \mu_1(X, \beta_1)\} + E\{\mu_1(X, \beta_1)\}$$

出发，对第一项应用 IPW 公式（将 $Y(1) - \mu_1(X, \beta_1)$ 视为伪潜在结果）：

$$E\{Y(1) - \mu_1(X, \beta_1)\} = E \left\{ \frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X)} \right\},$$

这在倾向得分模型正确时成立。于是得到

$$\mu_1 = E \left\{ \frac{Z\{Y - \mu_1(X, \beta_1)\}}{e(X)} \right\} + E\{\mu_1(X, \beta_1)\}.$$

⁹详细步骤见原书 [?, Theorem 12.1]

13. 从结果回归到 DR 的偏倚修正

结果回归估计量 $\tilde{\mu}_1 = E\{\mu_1(X, \beta_1)\}$ 的偏倚为：

$$\text{bias} = E\{\mu_1(X, \beta_1) - Y(1)\}.$$

如果倾向得分模型正确，这个偏倚可以用 IPW 估计量来估计：

$$B = E\left\{\frac{Z\{\mu_1(X, \beta_1) - Y\}}{e(X)}\right\}.$$

于是去偏估计量为 $\tilde{\mu}_1 - B$ ，展开后恰好等于 eq. (72)。

14. 双重稳健性的乘积结构

从 section 10 的证明中，我们得到：

$$\tilde{\mu}_1^{\text{dr}} - E\{Y(1)\} = E\left[\frac{e(X) - e(X, \alpha)}{e(X, \alpha)} \times \{\mu_1(X) - \mu_1(X, \beta_1)\}\right].$$

这个乘积结构揭示了双重稳健性的本质：当两个模型都错误时， $e(X) - e(X, \alpha)$ 和 $\mu_1(X) - \mu_1(X, \beta_1)$ 这两个误差会相乘，可能放大偏差。

15. 模拟研究详情

数据生成过程. 我们设置样本量 $n = 500$ ，按以下四个场景生成 500 个独立数据集。

场景 1 (两个模型都正确)：

```
x = matrix(rnorm(n*2), n, 2)
x1 = cbind(1, x)
beta.z = c(0, 1, 1)
pscore = 1/(1 + exp(- as.vector(x1 %*% beta.z)))
z = rbinom(n, 1, pscore)
beta.y1 = c(1, 2, 1)
beta.y0 = c(1, 2, 1)
y1 = rnorm(n, x1 %*% beta.y1)
y0 = rnorm(n, x1 %*% beta.y0)
y = z*y1 + (1-z)*y0
```

场景 2 (倾向得分模型错误)： 使用非线性倾向得分模型。

场景 3 (结果模型错误)： 使用非线性结果模型。

场景 4 (两个模型都错误)： 同时使用非线性倾向得分和非线性结果模型。

模拟结果. 结论： 当两个模型都错误时（场景 4），双重稳健估计量的表现反而最差，验证了“双重脆弱性”现象。

TABLE 1. 四种场景下的模拟结果 ($n = 500$, 500 次重复)

	reg	HT	Hajek	DR
场景 1: 两个模型都正确				
平均偏倚	0.00	0.02	0.03	0.01
真标准误	0.11	0.28	0.26	0.13
估计标准误	0.10	0.25	0.23	0.12
场景 2: 倾向得分模型错误				
平均偏倚	0.00	-0.76	-0.75	-0.01
真标准误	0.12	0.59	0.47	0.18
估计标准误	0.13	0.50	0.38	0.18
场景 3: 结果模型错误				
平均偏倚	-0.05	0.00	-0.01	0.00
真标准误	0.11	0.15	0.14	0.14
估计标准误	0.11	0.14	0.13	0.14
场景 4: 两个模型都错误				
平均偏倚	-0.08	0.11	-0.07	0.16
真标准误	0.13	0.32	0.20	0.41
估计标准误	0.13	0.25	0.16	0.26

基于倾向得分的分层

1. 引言：从分层随机实验到观测性研究

“Block what you can and randomize what you cannot.” — [?, page 103]

我们在第 5 章看到，分层随机实验 (SRE) 是一种优雅地解决协变量不平衡问题的方法。在 SRE 中，我们根据离散的协变量 X 将单元分成若干层，在每一层内独立进行完全随机实验。这种方法在设计上保证了各层内的 treatment 和 control 平衡。

然而，现实中的观测性研究面临一个根本性的困难：我们无法控制治疗分配机制。在随机实验中， $e(X) = \Pr(Z = 1)$ 是由实验设计决定的已知常数；但在观测性研究中，治疗分配概率 $e(X) = \Pr(Z = 1 | X)$ 取决于协变量 X ，通常既未知又高度依赖于 X 的具体值。

更棘手的是，协变量 X 往往是高维的。当 X 包含数十个甚至数百个变量时，直接按 X 的取值进行分层会导致大多数层只包含极少量的单元——这正是维数灾难 (curse of dimensionality) 带来的挑战。

这些问题促使我们思考：能否找到一种方法，既能继承 SRE 的思想，又能在观测性研究中有效地控制 confounding?

倾向得分 (propensity score) 正是为解决这一问题而诞生的核心概念。

2. 倾向得分的维度约化性质

2.1. 核心定理. 在第 5 章中，我们定义了层别倾向得分 $e_{[k]} = n_{[k]1}/n_{[k]}$ ，这是在离散协变量下的分层随机实验中治疗分配的层内概率。在观测性研究的语境下，? 提出了更一般的倾向得分定义。

定义 13.1 (倾向得分). 倾向得分定义为给定协变量条件下治疗分配的条件概率：

$$e(X) = \Pr(Z = 1 | X).$$

倾向得分是一个取值在 $[0, 1]$ 区间的标量函数。下面的定理揭示了它的一个非凡性质——即使原始协变量 X 是高维的，只要强 ignorability 在 X 条件下成立，它在倾向得分条件下也成立。

定理 13.2 (倾向得分的维度约化定理). 如果 $Z \perp \{Y(1), Y(0)\} | X$ ，则有

$$Z \perp \{Y(1), Y(0)\} | e(X).$$

直观理解：强 ignorability 要求我们在高维协变量 X 的条件下进行条件化才能消除混杂。定理 13.2 告诉我们，更进一步地，仅在标量倾向得分 $e(X)$ 条件下条件化就足以消除 X 带来的所有混杂。这意味着，我们可以将高维协变量 X 降维到一维标量 $e(X)$ ，同时仍然保持因果识别的有效性。

证明概要：¹

¹完整证明见附录 section 9.1

我们需要证明 $\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = \Pr\{Z = 1 \mid e(X)\}$ 。利用 tower property 和强 ignorability 假设, 有

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{Z \mid Y(1), Y(0), e(X)\} = E[E\{Z \mid Y(1), Y(0), X\} \mid Y(1), Y(0), e(X)].$$

由强 ignorability, $E\{Z \mid Y(1), Y(0), X\} = E\{Z \mid X\} = e(X)$, 于是

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{e(X) \mid Y(1), Y(0), e(X)\} = e(X).$$

类似地, $\Pr\{Z = 1 \mid e(X)\} = E\{Z \mid e(X)\} = E\{e(X) \mid e(X)\} = e(X)$ 。两端相等, 定理得证。

2.2. 历史注记. Rosenbaum and Rubin 于 1983 年在 *Biometrika* 上发表了这篇开创性论文, 提出了倾向得分的概念及其在观测性研究中的核心作用。这篇论文是统计学历史上被引用最频繁的工作之一——? 将其列为过去一百年中 *Biometrika* 上引用量第二高的论文。近年来, 其引用量仍在快速增长。

这篇论文的核心贡献在于: 它揭示了因果推断的一个基本对称性——在强 ignorability 假设下, 条件化于高维协变量 X 与条件化于一维标量倾向得分 $e(X)$ 在消除混杂方面是等价的。这一发现从根本上简化了观测性研究中的因果推断问题。

3. 倾向得分分层

3.1. 已知倾向得分的情形. 定理 13.2 立刻启发了一种简单的因果效应估计方法——**倾向得分分层 (propensity score stratification)**, 也称为**子分类 (subclassification)**。

我们首先考虑最简单的情形: 假设倾向得分 $e(X)$ 已知且仅取 K 个可能的值 $\{e_1, \dots, e_K\}$, 其中 K 远小于样本量 n 。此时定理 13.2 简化为

$$Z \perp \{Y(1), Y(0)\} \mid e(X) = e_k \quad (k = 1, \dots, K).$$

这意味着: 在每一层 k 内, 我们有 K 个独立的完全随机实验 (CRE)。因此, 我们可以像分析 SRE 那样分析观测数据——这就是“倾向得分分层”的基本思想。

在各层内, 治疗组的平均因果效应为

$$\tau_{[k]} = E(Y \mid Z = 1, e(X) = e_k) - E(Y \mid Z = 0, e(X) = e_k),$$

总体平均因果效应为各层效应的加权平均:

$$\tau = \sum_{k=1}^K \pi_{[k]} \tau_{[k]},$$

其中 $\pi_{[k]} = \Pr\{e(X) = e_k\}$ 是第 k 层的权重。

3.2. 未知倾向得分的情形. 在实际情况中, 倾向得分 $e(X) = \Pr(Z = 1 \mid X)$ 既未知也不离散。我们通常需要先拟合一个统计模型 (例如对协变量 X 拟合 logistic 回归模型) 来得到**估计倾向得分 (estimated propensity score)** $\hat{e}(X)$ 。

估计倾向得分 $\hat{e}(X)$ 可以取多达 n 个不同的值——它本质上是连续的。为了应用分层方法, 我们需要将其离散化。最常用的离散化策略是按分位数进行划分:

$$\hat{e}'(X_i) = e_k, \quad \text{如果 } \hat{e}(X_i) \text{ 落在第 } (k-1)/K \text{ 和 } k/K \text{ 分位数之间.}$$

于是我们有近似的条件独立性:

$$Z \perp \{Y(1), Y(0)\} \mid \hat{e}'(X) = e_k \quad (k = 1, \dots, K).$$

重要说明：此时 ignorability 仅在近似意义上成立，因为 $e'(X)$ 是基于样本估计得到的。在每层内，我们仍然可以使用第 5 章的 SRE 分析方法。进一步地，我们可以在各层内使用回归调整来消除剩余偏差并提高效率。

稳健性注记：倾向得分分层估计量的一个吸引人的特性是，它只需要估计倾向得分的排序正确，而不需要精确的数值。这意味着它相对于其他方法（如逆概率加权）是比较稳健的。尽管这种稳健性在许多数值例子中得到了验证，但严格的理论量化在文献中仍然缺失。

4. 分层数 K 的选择

选择合适的分层数 K 是实践中的一个关键问题。这个问题涉及偏差与方差的权衡：

- 如果 K 太小，则 $Z \perp \{Y(1), Y(0)\} \mid e'(X)$ 即使在近似意义上也难以成立，导致残余偏倚；
- 如果 K 太大，则每层内的单元数过少，许多层可能只包含治疗组或对照组的单元，导致估计量不稳定甚至未定义。

Rosenbaum and Rubin (1983, 1984) 基于 Cochran (1968) 的启发性研究，建议使用 $K = 5$ ——即五分位数分层。他们证明，在许多情形下， $K = 5$ 可以消除大部分由协变量不均衡带来的偏倚。

现代视角：然而，在超大规模数据集下，固定 $K = 5$ 可能导致估计量产生偏倚。？的研究表明，此时适当增加 K 是合理的，只要每层仍然包含足够数量的治疗组和对照组单元。？提出了一种贪婪的 K 选择策略——取使分层估计量良好定义的最大分层数。但这一程序的严格理论尚未完全建立。

5. 与第五章的联系：SRE 的观测性研究版本

倾向得分分层与第 5 章讨论的分层随机实验 (SRE) 有着深刻的联系。在 SRE 中，我们在设计阶段主动控制了协变量不平衡；而在观测性研究中，我们通过倾向得分分层来近似实现这种控制。

- (1) **思想上的对应：**SRE 中我们按协变量 X 的取值分层，在每层内做 CRE；倾向得分分层则按倾向得分 $e(X)$ 的取值分层，在每层内近似地获得“条件随机化”的效果。
- (2) **记号的对应：**SRE 中的层别倾向得分 $e_{[k]} = n_{[k]1}/n_{[k]}$ 对应于倾向得分分层中每层的 e_k ；只不过前者是设计决定的，后者需要从数据中估计。
- (3) **估计量的对应：**两种情形下我们都使用各层差值均值的加权平均作为总体因果效应的估计。唯一的区别在于权重的估计方式。

这种对应关系揭示了为什么 SRE 的分析工具（如 Neyman 估计量、Fisher 随机化检验）可以直接迁移到倾向得分分层的情境中。

6. 标准误的估计

实践中的另一个重要问题是：如何计算基于倾向得分分层的估计量的标准误？

一种常见做法是**条件化于离散化的倾向得分** $e'(X)$ ，然后基于 SRE 的框架报告标准误。这种做法本质上忽略了估计倾向得分带来的不确定性。由于文献中一个令人惊讶的结果——使用估计倾向得分实际上会**降低**平均因果效应估计的渐近方差（？），这种做法往往导致方差的高估。

另一种做法是对整个过程进行**自助法 (bootstrap)** 以纳入完整的不确定性。但由于该估计量的离散性质，自助法的理论性质尚不清晰。

7. 应用实例

7.1. NHANES 数据集. 我们使用第 10 章介绍的 NHANES 数据集来说明倾向得分分层的应用。

研究问题: 学校供餐计划 (Schoolmeal) 对学生 BMI 的影响。

治疗指标: $Z_i = 1$ 表示参与学校供餐计划, $Z_i = 0$ 表示未参与。

结果变量: BMI (体质指数)。

协变量: 包括年龄、性别、种族、家庭收入等基线特征。

首先, 我们拟合 logistic 回归模型来估计倾向得分:

$$\hat{e}(X_i) = \text{logit}^{-1}(\hat{\alpha}_0 + \hat{\alpha}_1 X_{i1} + \cdots + \hat{\alpha}_p X_{ip}).$$

图 1 展示了不同分层数 ($K = 5, 10, 30$) 下估计倾向得分的直方图。可以看到, 治疗组 (灰色) 和对照组 (白色) 的倾向得分分布存在明显差异, 这表明确实存在需要控制的混杂。

FIGURE 1. NHANES 数据集中估计倾向得分的直方图: 白色为对照组, 灰色为治疗组

表 1 报告了不同 K 值下 ($K \in \{5, 10, 20, 50, 80\}$) 的倾向得分分层估计结果。²

TABLE 1. 不同分层数 K 下的倾向得分分层估计结果

	$K = 5$	$K = 10$	$K = 20$	$K = 50$	$K = 80$
估计值	-0.116	-0.178	-0.200	-0.265	—
标准误	0.283	0.282	0.279	0.272	NA

从结果可以看出:

- (1) 随着 K 从 5 增加到 50, 标准误逐渐减小, 估计值趋于稳定 (约 -0.2);
- (2) 当 $K = 80$ 时, 标准误未定义 (NA), 因为某些层只包含单一处理组的单元);
- (3) 所有估计值都是负的, 表明学校供餐计划可能有助于降低 BMI, 但统计上不显著。

7.2. 与其他方法的比较. 表 2 比较了倾向得分分层与几种回归估计量的结果。

TABLE 2. 不同估计方法的比较

	naive	Fisher	Lin
估计值	0.534	0.061	-0.017
标准误	0.225	0.227	0.226

关键观察:

- **朴素估计量 (naive)** 给出的估计值最大 (0.534), 这是由于协变量在治疗组和对照组之间的巨大不平衡;
- **Fisher 估计量** (协变量调整后的 OLS) 给出了一个较小的正估计 (0.061), 但不显著;
- **Lin 估计量** (包含交互项的 OLS) 给出了接近零的估计 (-0.017);
- 倾向得分分层估计量 (-0.17 到 -0.27) 与 Lin 估计量在定性上是一致的, 且在不同 K 值下保持稳定。

²具体计算代码见附录 section 9.2

这些结果说明：倾向得分分层是一种有效且稳健的因果效应估计方法，它既继承了SRE的设计思想，又适用于观测性研究的复杂情境。

8. 小结

本章介绍了倾向得分分层的核心思想和方法：

- (1) **维度约化**：定理 13.2 表明，在强 ignorability 假设下，条件化于倾向得分 $e(X)$ 与条件化于高维协变量 X 在消除混杂方面是等价的；
- (2) **分层思想**：将连续的倾向得分离散化为 K 层，在每层内近似获得“条件随机化”的效果；
- (3) **与 SRE 的联系**：倾向得分分层本质上是将 SRE 的设计思想应用于观测性研究；
- (4) **K 的选择**： $K = 5$ 是经典推荐，但在超大规模数据下可适当增加；
- (5) **稳健性**：倾向得分分层只要求估计倾向得分的排序正确，对模型设定相对稳健。

倾向得分分层是因果推断工具箱中的基础工具之一。它不仅可以直接用于估计因果效应，还构成了逆概率加权、doubly robust 估计等更高级方法的基础。

9. 附录：关键公式推导

9.1. 定理 13.2 的完整证明。 我们需要证明在强 ignorability 条件下，

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = \Pr\{Z = 1 \mid e(X)\}.$$

首先，由条件概率的定义和 tower property，

$$\Pr\{Z = 1 \mid Y(1), Y(0), e(X)\} = E\{Z \mid Y(1), Y(0), e(X)\}.$$

对上式应用 tower property（先关于 X 条件化，再关于 $Y(1), Y(0), e(X)$ 条件化）：

$$E\{Z \mid Y(1), Y(0), e(X)\} = E[E\{Z \mid Y(1), Y(0), X\} \mid Y(1), Y(0), e(X)].$$

由强 ignorability 假设 $Z \perp \{Y(1), Y(0)\} \mid X$ ，有

$$E\{Z \mid Y(1), Y(0), X\} = E\{Z \mid X\} = e(X).$$

因此，

$$E\{Z \mid Y(1), Y(0), e(X)\} = E\{e(X) \mid Y(1), Y(0), e(X)\} = e(X).$$

另一方面，

$$\Pr\{Z = 1 \mid e(X)\} = E\{Z \mid e(X)\} = E[E\{Z \mid X\} \mid e(X)] = E\{e(X) \mid e(X)\} = e(X).$$

两端相等，定理证毕。

9.2. NHANES 数据分析的 R 代码。 以下是本章数据分析使用的 R 代码示例：

```
# 读取数据
nhanes_bmi = read.csv("nhanes_bmi.csv")[, -1]
z = nhanes_bmi$Schoolmeal
y = nhanes_bmi$BMI
x = as.matrix(nhanes_bmi[, -c(1, 2)])
x = scale(x) # 标准化协变量

# 估计倾向得分
pscore = glm(z ~ x, family = binomial)$fitted.values
```

```
# 倾向得分分层
n.strata = c(5, 10, 20, 50, 80)
strat.res = sapply(n.strata, FUN = function(nn) {
  q.pscore = quantile(pscore, (1:(nn-1)) / nn)
  ps.strata = cut(pscore, breaks = c(0, q.pscore, 1),
                  labels = 1:nn)
  Neyman_SRE(z, y, ps.strata)
})

rownames(strat.res) = c("est", "se")
colnames(strat.res) = n.strata
round(strat.res, 3)
```

其中 `Neyman_SRE` 函数定义于第 5 章，用于计算 SRE 框架下的 Neyman 估计量及其标准误。

加权最小二乘法用于因果推断

1. 一个问题意识：IPW 估计量的另一种面孔

在第十二章中，我们学习了基于逆概率加权（IPW）的 Hajek 估计量：

$$(76) \quad \hat{\tau}^{\text{hajek}} = \frac{\sum_{i=1}^n \frac{Z_i Y_i}{\hat{e}(X_i)}}{\sum_{i=1}^n \frac{Z_i}{\hat{e}(X_i)}} - \frac{\sum_{i=1}^n \frac{(1-Z_i) Y_i}{1-\hat{e}(X_i)}}{\sum_{i=1}^n \frac{1-Z_i}{1-\hat{e}(X_i)}}$$

这个估计量优美而简洁——它本质上是治疗组和对照组加权均值的差。

然而，一个深邃的观察 (Imbens, 2004) 是：eq. (76) 实际上与一个加权最小二乘 (WLS) 回归的系数完全等价。更精确地说， $\hat{\tau}^{\text{hajek}}$ 恰好等于在如下 WLS 回归中 Z_i 的系数：

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \sum_{i=1}^n w_i (Y_i - \alpha - \beta Z_i)^2$$

其中权重为

$$(77) \quad w_i = \frac{Z_i}{\hat{e}(X_i)} + \frac{1-Z_i}{1-\hat{e}(X_i)} = \begin{cases} \frac{1}{\hat{e}(X_i)} & \text{if } Z_i = 1; \\ \frac{1}{1-\hat{e}(X_i)} & \text{if } Z_i = 0. \end{cases}$$

这个等价性绝非偶然的代数巧合——它揭示了 IPW 与加权回归之间深刻的联系，也为更高效的估计开辟了道路。

2. Hajek 估计量作为 WLS 估计量

让我们更仔细地审视这个等价性。

命题 14.1 (命题 14.1 —Hajek 估计量与 WLS). 在 *section 1* 的记号下， $\hat{\tau}^{\text{hajek}}$ 严格等于上述 WLS 回归中 Z_i 的系数 $\hat{\beta}$ 。

为什么这个结果有意义？ 让我们回顾一下完全随机化实验 (CRE) 的情形。当倾向得分恒为常数 $e(X_i) \equiv p$ 时，权重 w_i 也恒为常数，此时 WLS 退化为普通的 OLS。因此，CRE 中用 OLS 系数估计 τ 的经典结果（参见第四章）可以视为本命题的特例。

直觉理解： 在观测研究中，不同单元接受治疗或对照的概率不同。如果我们用 $1/\hat{e}(X_i)$ 加权治疗组，用 $1/\{1-\hat{e}(X_i)\}$ 加权对照组，就相当于构造了一个“伪随机化实验”——加权后的样本可以代表总体。于是，加权均值之差（Hajek 估计量）等价于在这个伪实验中进行 OLS 回归得到的 treatment 系数。

由定义 14.1，我们可以通过 WLS 回归方便地计算 $\hat{\tau}^{\text{hajek}}$ 。但需要注意：由于倾向得分是估计的，WLS 报告的标准误并非 $\hat{\tau}^{\text{hajek}}$ 的真实标准误。Bootstrap 提供了一种简便的近似方法。¹

这个等价性不仅在代数上优雅，更重要的是它为**加入协变量调整**提供了自然的框架。

¹详见附录 ??。

3. 加入协变量: Lin (2013) 的推广与双重稳健性

在 CRE 中, 我们可以通过在回归中加入协变量来提高估计效率。Lin (2013) 的做法是在 OLS 回归中加入 treatment 与协变量的交互项:

$$Y_i \sim (1, Z_i, X_i, Z_i X_i)$$

其中协变量需要中心化 ($\bar{X} = 0$)。

自然的问题是: 在观测研究中, 我们能否做类似的推广?

答案是肯定的——我们只需要将普通 OLS 替换为 WLS (权重取 eq. (77))。具体而言, 估计量 $\hat{\tau}$ 取为 WLS 回归

$$Y_i \sim (1, Z_i, X_i, Z_i X_i)$$

中 Z_i 的系数。

这个推广最早由 Hirano and Imbens (2001) 在一项应用中采用。

3.1. 完全交互线性模型. 假设潜在结果的条件期望是线性的:

$$\mathbb{E}(Y | Z = 1, X) = \beta_{10} + \beta_{1x}^\top X, \quad \mathbb{E}(Y | Z = 0, X) = \beta_{00} + \beta_{0x}^\top X$$

两种情形:

- (1) **结局模型正确:** 若上述线性模型正确指定, 则 WLS 和 OLS 都给出 τ 的相合估计, 且 Z 系数的估计量相合于 τ 。
- (2) **倾向得分模型正确, 结局模型错误:** 更引人注目的是, 即使结局模型错误, 只要倾向得分模型正确, WLS 中 Z 的系数仍然相合于 τ 。这就是所谓的**双重稳健性 (double robustness)**。

这个双重稳健性结果最早见于 Robins et al. (2007), 他们将功劳归于 M. Joffe 的未发表论文。

3.2. 结局回归估计量与双重稳健估计量. 设 $\hat{e}(X_i, \hat{\alpha})$ 为估计的倾向得分, $(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_0))$ 为基于 WLS 的结局条件均值拟合值。

结局回归估计量为

$$\hat{\tau}_{\text{wls}}^{\text{reg}} = \frac{1}{n} \sum_{i=1}^n \mu_1(X_i, \hat{\beta}_1) - \frac{1}{n} \sum_{i=1}^n \mu_0(X_i, \hat{\beta}_0)$$

双重稳健估计量为

$$\hat{\tau}_{\text{wls}}^{\text{dr}} = \hat{\tau}_{\text{wls}}^{\text{reg}} + \frac{1}{n} \sum_{i=1}^n \frac{Z_i \{Y_i - \mu_1(X_i, \hat{\beta}_1)\}}{\hat{e}(X_i, \hat{\alpha})} - \frac{1}{n} \sum_{i=1}^n \frac{(1 - Z_i) \{Y_i - \mu_0(X_i, \hat{\beta}_0)\}}{1 - \hat{e}(X_i, \hat{\alpha})}$$

一个深刻的结果是: 当结局模型为线性模型时, 这个双重稳健估计量恰好等于结局回归估计量——二者都简化为 WLS 回归中 Z_i 的系数。

定理 14.2 (定理 14.2 — 双重稳健性). 若 $\bar{X} = 0$ 且

$$(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_0)) = (\hat{\beta}_{10} + \hat{\beta}_{1x}^\top X_i, \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i)$$

基于权重 eq. (77) 对 $Y_i \sim (1, Z_i, X_i, Z_i X_i)$ 的 WLS 拟合, 则

$$\hat{\tau}_{\text{wls}}^{\text{dr}} = \hat{\tau}_{\text{wls}}^{\text{reg}} = \hat{\beta}_{10} - \hat{\beta}_{00}$$

即 Z_i 在 WLS 回归中的系数。

证明思路：²

WLS 回归包含截距项，因此加权残差的均值为零。这给出两个正交条件：

$$\sum_{i=1}^n \frac{Z_i(Y_i - \hat{\beta}_{10} - \hat{\beta}_{1x}^\top X_i)}{\hat{e}(X_i)} = 0, \quad \sum_{i=1}^n \frac{(1 - Z_i)(Y_i - \hat{\beta}_{00} - \hat{\beta}_{0x}^\top X_i)}{1 - \hat{e}(X_i)} = 0.$$

这两个条件确保 $\hat{\tau}_{\text{wls}}^{\text{dr}} - \hat{\tau}_{\text{wls}}^{\text{reg}} = 0$ 。进一步，利用协变量中心化 ($\bar{X} = 0$)，两者都简化为 $\hat{\beta}_{10} - \hat{\beta}_{00}$ 。

3.3. Freedman and Berk (2008) 的警示. Freedman and Berk (2008) 基于模拟研究对上述 WLS 估计量提出了批评。他们指出：当结局模型正确时，WLS 估计量由于权重的变异性而比 OLS 估计量表现更差。

然而，这个结论并非普遍成立。关键在于数据的**异方差结构**——若误差方差与倾向得分成反比，则 WLS 估计量将比 OLS 更高效。

此外，Freedman and Berk (2008) 也注意到一个重要事实：当结局模型错误时，只要倾向得分模型正确，WLS 估计量仍然是相合的。这正是双重稳健性的价值所在。

标准误的问题：WLS 回归报告的标准误忽略了倾向得分估计的不确定性，这个缺陷可以通过 Bootstrap 轻易弥补。

注 14.1. 什么时候该用 WLS？：当 (1) 倾向得分模型可信且 (2) 误差方差可能与倾向得分相关 (异方差) 时，WLS 是更好的选择。当结局模型可信时，简单的 OLS 可能更稳定。

4. 处理组平均因果效应的 WLS

上述结果可以平行地推广到**处理组平均因果效应** (Average Causal Effect on the Treated, τ_T) 的情形。

处理组 Hajek 估计量为

$$\hat{\tau}_T^{\text{hajek}} = \hat{Y}(1) - \frac{\sum_{i=1}^n \hat{o}(X_i)(1 - Z_i)Y_i}{\sum_{i=1}^n \hat{o}(X_i)(1 - Z_i)}$$

其中 $\hat{o}(X_i) = \hat{e}(X_i)/\{1 - \hat{e}(X_i)\}$ 。

命题 14.3 (命题 14.2 — 处理组 Hajek 估计量与 WLS). $\hat{\tau}_T^{\text{hajek}}$ 严格等于如下 WLS 回归中 Z_i 的系数：

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \sum_{i=1}^n w_{T_i} (Y_i - \alpha - \beta Z_i)^2$$

其中权重为

$$(78) \quad w_{T_i} = Z_i + (1 - Z_i)\hat{o}(X_i) = \begin{cases} 1 & \text{if } Z_i = 1; \\ \hat{o}(X_i) & \text{if } Z_i = 0. \end{cases}$$

若进一步中心化协变量 ($\hat{X}(1) = 0$)，则 τ_T 可以用 WLS 回归

$$Y_i \sim (1, Z_i, X_i, Z_i X_i)$$

(权重取 eq. (78)) 中 Z_i 的系数来估计。

²详细证明见附录 ??。

定理 14.4 (定理 14.3 — 处理组的双重稳健性). 若 $\hat{X}(1) = 0$ 且 $\mu_0(X_i, \hat{\beta}_0) = \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i$ 基于权重 eq. (78) 对 $Y_i \sim (1, Z_i, X_i, Z_i X_i)$ 的 WLS 拟合, 则

$$\hat{\tau}_{T, wls}^{dr} = \hat{\tau}_{T, wls}^{reg} = \hat{\beta}_{10} - \hat{\beta}_{00}$$

即 Z_i 在 WLS 回归中的系数。

证明思路:³

5. 统一视角：回归估计量一览

table 1 总结了完全随机化实验 (CRE) 与非混杂假设下观测研究中回归估计量的对应关系。

TABLE 1. 回归估计量一览：CRE 与观测研究的对比

CRE		非混杂观测研究
不含协变量	$Y_i \sim (1, Z_i)$	$Y_i \sim (1, Z_i)$ (权重 w_i)
含协变量	$Y_i \sim (1, Z_i, X_i, Z_i X_i)$	$Y_i \sim (1, Z_i, X_i, Z_i X_i)$ (权重 w_i)

其中权重 w_i 如 eq. (77) 所示。

核心洞察: 在 CRE 中使用 OLS, 在观测研究中只需将 OLS 替换为带逆概率权重的 WLS——两者在代数形式上完全对应。这揭示了随机化实验与观测研究之间深刻的类比。

6. 本章小结

本章建立了加权最小二乘法 (WLS) 与因果推断之间的联系：

- (1) **等价性:** Hajek 估计量严格等于 WLS 回归中 treatment 变量的系数
- (2) **协变量调整:** 通过在 WLS 中加入 X_i 和 $Z_i X_i$ 项, 可以提高估计效率 (Lin, 2013)
- (3) **双重稳健性:** 只要倾向得分模型和结局模型中至少有一个正确, WLS 估计量就相合 (Robins et al., 2007)
- (4) **异方差效率:** 当误差方差与倾向得分相关时, WLS 比 OLS 更高效
- (5) **处理组效应:** 所有结果平行推广到 τ_T 的估计

WLS 为因果推断提供了一个统一的框架——它既是 IPW 的另一种表述, 又自然地融入了协变量调整和双重稳健性的思想。

7. 习题

练习 14.1. 14.1 命题 14.1 和 14.2 的证明 证明 定义 14.1 和 定义 14.3。

提示: 这些是附录 B.3 中一元 WLS 问题的特例。利用 WLS 的正规方程即可证明。

练习 14.2. 14.2 预测估计量与双重稳健估计量 另一种结局回归估计量是预测估计量

$$\hat{\tau}^{pred} = \hat{\mu}_1^{pred} - \hat{\mu}_0^{pred}$$

其中

$$\hat{\mu}_1^{pred} = \frac{1}{n} \sum_{i=1}^n \{Z_i Y_i + (1 - Z_i) \mu_1(X_i, \hat{\beta}_1)\}, \quad \hat{\mu}_0^{pred} = \frac{1}{n} \sum_{i=1}^n \{Z_i \mu_0(X_i, \hat{\beta}_1) + (1 - Z_i) Y_i\}.$$

³详细证明见附录 ??。

证明：当 $(\mu_1(X_i, \hat{\beta}_1), \mu_0(X_i, \hat{\beta}_1)) = (\hat{\beta}_{10} + \hat{\beta}_{1x}^\top X_i, \hat{\beta}_{00} + \hat{\beta}_{0x}^\top X_i)$ 来自基于权重

$$w_i = Z_i / \hat{o}(X_i) + (1 - Z_i) \hat{o}(X_i)$$

对 $Y_i \sim (1, X_i)$ 的 WLS 拟合时，双重稳健估计量等于 $\hat{\tau}^{pred}$ 。

参考文献： *Cao et al. (2009)* 和 *Vermeulen and Vansteelandt (2015)* 从其他理论角度 *motivation* 了上述权重。

练习 14.3. 14.3 WLS 的效率性质 讨论在何种情形下 WLS 估计量比 OLS 估计量更有效。在 *Freedman and Berk (2008)* 的模拟设置中，为什么 OLS 表现更好？这与本章讨论的异方差情形有何关联？

练习 14.4. 14.4 推荐阅读 **推荐阅读：**？是关于因果推断中加权方法的权威综述。？讨论了协变量调整在随机化实验中的应用。

历史注记： WLS 与 IPW 的等价性最早由 *Imbens (2004)* 明确指出。双重稳健性的概念在 *Robins et al. (2007)* 中得到了系统阐述。

观测性研究中的匹配

1. 引言：为什么匹配比回归更直观？

“*Matching is a way of making observational studies look like randomized experiments.*”
— [?]

在第 10 章至第 12 章中，我们介绍了观测性研究的四大支柱：结果回归、逆倾向得分加权、双稳健估计量，以及本章要讨论的**匹配估计量 (matching estimator)**。

为什么匹配如此直观？想象一下：在随机实验中，我们通过随机分配让治疗组和对照组在协变量上达到平衡。但当随机化不可行时，我们能否在设计阶段就主动创造出这种平衡？匹配的核心思想正是如此——**通过人为配对，使匹配后的数据模拟随机实验的性质。**

这个想法有着悠久的历史。? 是早期综述性论文，? 收集了 Rubin 在该领域的贡献。现代渐近理论则由 ??? 的系列论文建立。

2. 匹配的基本思想

考虑一个治疗组单元数 n_1 远小于对照组单元数 n_0 的场景。对每个治疗组单元 $i = 1, \dots, n_1$ ，我们在对照组中寻找一个匹配单元 $m(i)$ 使得 $X_i = X_{m(i)}$ 。

理想情况：精确匹配。如果对于所有单元都能找到协变量完全相同的匹配，那么匹配后的配对与第 7 章讨论的匹配对实验 (matched-pairs experiment, MPE) 具有相同的性质。条件于配对后，一单位接受治疗而另一单位接受对照的概率是

$$\Pr\{i \text{ 接受治疗}, m(i) \text{ 接受对照}\} = \frac{e(X_i)\{1 - e(X_{m(i)})\}}{\sum_j \{e(X_j) + e(X_{m(j)})\}}.$$

由于 $X_i = X_{m(i)}$ ，我们有 $e(X_i) = e(X_{m(i)})$ ，这个概率退化为 $e(X_i)/\{e(X_i) + e(X_i)\} = 1/2$ 。这正是随机化分配的标志。

不精确匹配的问题。然而在实际中， $X_i = X_{m(i)}$ 通常无法对所有单元成立。? 倡导上述分析策略，但 ? 报告了不精确匹配在 FRT 中的负面结果。这是一个重要警示。

倾向得分救兵。当协变量维度较高时，直接匹配面临维数灾难。? 提出使用倾向得分进行匹配。由于倾向得分是一维的，我们只需寻找 $|\hat{e}(X_i) - \hat{e}(X_{m(i)})|$ 很小的配对，或 $|\text{logit}\{\hat{e}(X_i)\} - \text{logit}\{\hat{e}(X_{m(i)})\}|$ 很小的配对。? 为这一策略提供了形式化理论。

3. 匹配估计量：一对一匹配

本节介绍 Abadie–Imbens (AI) 的标准设置：¹

$$\{X_i, Z_i, Y_i(1), Y_i(0)\}_{i=1}^n \stackrel{\text{iid}}{\sim} \{X, Z, Y(1), Y(0)\}.$$

¹详细推导见附录 ??

3.1. ACE 的匹配估计量. 采用 $1-M$ 匹配 (带放回)。对治疗单元 i , 将潜在结果 $Y_i(1)$ 估计为观测值 Y_i ,

$$\hat{Y}_i(1) = Y_i.$$

将潜在结果 $Y_i(0)$ 估计为匹配对照单元结果的均值:

$$\hat{Y}_i(0) = M^{-1} \sum_{j=1}^M Y_{m_j(i)},$$

其中 $m_j(i)$ 是第 j 个匹配单元。

匹配估计量为:

$$\hat{\tau}^m = n^{-1} \sum_{i=1}^n Z_i \{ \hat{Y}_i(1) - \hat{Y}_i(0) \} + n^{-1} \sum_{i=1}^n (1 - Z_i) \{ \hat{Y}_i(0) - \hat{Y}_i(1) \}.$$

为简化记号, 定义 $J(i)$ 为匹配给单元 i 的单元集合, $K_i = |J(i) \cap \{j : Z_j = 1\}|$ 为匹配中治疗单元的个数。

命题 15.1 (匹配估计量的偏差). 在 M 固定的情况下, 当 $n \rightarrow \infty$ 时,

$$\sqrt{n}(\hat{\tau}^m - \tau) \Rightarrow \mathcal{N}\{0, V^m(\tau)\},$$

其中偏差来自不精确匹配。²

3.2. 偏差校正. ? 指出, 简单 bootstrap 不能用于匹配估计量的方差估计。他们提出的方差估计程序不易实现。? 提出了基于线性展开的 bootstrap, 本质上等价于以下简单方差估计量 $\hat{V}^{\text{mbc}}$ 。

偏差校正后的匹配估计量:

$$\hat{\tau}^{\text{mbc}} = \hat{\tau}^m + n^{-1} \sum_{i=1}^n \hat{\psi}_i,$$

其中 $\hat{\psi}_i$ 是偏差校正项。³

通过将 $\hat{\tau}^{\text{mbc}}$ 视为 $\hat{\psi}_i$ 的样本均值, ? 首先证明简单 bootstrap 对匹配估计量不适用。? 的 bootstrap 本质上等价于简单的 $\hat{V}^{\text{mbc}}$, 计算简便。

4. 匹配的双稳健形式

偏差校正匹配估计量与双稳健估计量有着密切联系。两者都等于结果回归估计量加上基于残差的修正。

命题 15.2 (ACE 偏差校正匹配估计量的双稳健形式). 偏差校正匹配估计量满足

$$\hat{\tau}^{\text{mbc}} = \hat{\tau}^{\text{DR}},$$

其中 $\hat{\tau}^{\text{DR}}$ 是第 12 章定义的双稳健估计量。⁴

²完整方差推导见附录 ??

³推导见附录 ??

⁴证明见附录 ??

定义 15.2 揭示了一个深刻联系：匹配本质上是估计倾向得分的非参数方法，而 $1 + K_i/M$ 可以视为 $1/\hat{e}(X_i)$ 的估计。

当治疗单元的 $e(X_i)$ 很小时， $1/\hat{e}(X_i)$ 很大，同时该单元会匹配到很多对照单元，导致 K_i 很大，因此 $1 + K_i/M$ 也很大。这个联系也引发了一个关于匹配的问题：**固定 M 下， $1 + K_i/M$ 对 $1/e(X_i)$ 的估计可能非常嘈杂。**让 M 随样本量增长可能会改善基于匹配倾向得分估计的渐近性质。⁵ 提供了严格理论：当 M 以适当速率增长时，偏差校正匹配估计量可以达到与双稳健估计量相似的性质。

5. ATT 的匹配估计量

实践中，我们经常关心的是**处理组平均因果效应 (ATT)**：

$$\tau_T = \mathbb{E}\{Y_i(1) - Y_i(0) \mid Z_i = 1\}.$$

ATT 的匹配估计量为：

$$\hat{\tau}_T^m = n_1^{-1} \sum_{i:Z_i=1} \{\hat{Y}_i(1) - \hat{Y}_i(0)\},$$

其中 $\hat{Y}_i(1) = Y_i$ 而 $\hat{Y}_i(0) = M^{-1} \sum_{j=1}^M Y_{m_j(i)}$ 。

类似地，偏差校正版本为：

$$\hat{\tau}_T^{\text{mbc}} = \hat{\tau}_T^m + n_1^{-1} \sum_{i:Z_i=1} \hat{\psi}_i^T.$$

命题 15.3 (ATT 偏差校正匹配估计量的双稳健形式). *ATT 的偏差校正匹配估计量满足*

$$\hat{\tau}_T^{\text{mbc}} = \hat{\tau}_T^{\text{DR}},$$

其中 $\hat{\tau}_T^{\text{DR}}$ 是 ATT 的双稳健估计量。⁵

定义 15.3 表明：匹配本质上使用 K_i/M 来估计给定协变量条件下治疗的优势比。

6. 实践中的问题

6.1. 一对一还是一对多？ 我们既可以采用一对一匹配，也可以采用一对 M 匹配。当 M 增加时，偏差减小但方差增大。实践中需要权衡。

6.2. 放回还是不放回？ 放回匹配计算更方便，但会引入依赖（同一单元被多次使用）。不放回匹配的计算更复杂，但保证了匹配单元的独立性。当对照组池较大时，两种方法结果差异不大。

6.3. 协变量平衡检验。 匹配后应检验协变量平衡。使用简单 OLS 检查匹配前后协变量的系数显著性。**匹配前**，协变量通常高度不平衡（系数显著）；**匹配后**，协变量应该达到良好平衡（系数不显著）。

7. 实例：LaLonde 数据

？研究工作培训项目对收入的影响。他比较了随机实验结果与观测性研究结果。

实验部分给出 ATT 估计为 \$1794（标准误 \$623）。⁶

使用？的 Matching 包进行 1-1 匹配分析。匹配后，ATT 估计为 \$1658，与实验结果的 \$1794 非常接近。这说明**当匹配质量好时，匹配估计量能够很好地近似实验金标准。**

⁵证明见附录 ??

⁶详见第 10 章 2.1 节

8. 本章小结

本章介绍了观测性研究中的匹配估计量，主要内容如下：

- (1) **匹配的动机**：通过人为配对，使观测性研究模拟随机实验的性质——这比直接假设条件独立性更直观。
- (2) **基本思想 (section 2)**：对每个治疗单元，在对照组中找到协变量相似的单元进行匹配。精确匹配使治疗分配机制与匹配对实验相同。
- (3) **AI 理论 (section 3)**：??? 建立了匹配估计量的渐近理论，包括偏差校正和方差估计。
- (4) **双稳健连接 (section 4)**：偏差校正匹配估计量本质上是另一种形式的双稳健估计量。
- (5) **ATT 估计 (section 5)**：匹配同样适用于 ATT 的估计，且具有类似的双稳健性质。
- (6) **实践要点 (section 6)**：协变量平衡检验是确保匹配质量的关键步骤。

9. 习题

练习 15.1. 匹配与倾向得分 证明：在精确匹配下，倾向得分对所有配对单元相同，即 $e(X_i) = e(X_{m(i)})$ 。这如何支持“精确匹配模拟随机实验”的论断？

练习 15.2. 一对一与一对多匹配的偏差比较 考虑 1-1 匹配和 1-M 匹配。当 M 增大时，匹配估计量的偏差如何变化？为什么？

练习 15.3. 匹配估计量的偏差校正项 从 section 3.2 出发，推导偏差校正项 $\hat{\psi}_i$ 的具体形式。提示：参考 ? 的推导。

练习 15.4. ATT 匹配估计量的性质 证明 定义 15.3: ATT 的偏差校正匹配估计量等于 ATT 的双稳健估计量。

练习 15.5. 协变量平衡 对 LaLonde 数据进行匹配分析，检验匹配前后协变量的平衡性。使用不同的 M 值（一对一、一对二、一对四）比较结果。

练习 15.6. 匹配与回归的比较 使用第 10 章 ?? 节的数据，分别用匹配估计量和结果回归估计量估计 ATT。比较两种方法的结果和效率。

练习 15.7. 倾向得分匹配的理论性质 ? 提供了基于倾向得分匹配的理论。阅读该论文，总结其主要结论及其与 ? 建议的关联。

练习 15.8. 高维协变量的挑战 当协变量维度很高时，直接匹配面临维数灾难。讨论三种可能的解决策略：降维、惩罚回归、机器学习方法。

观测性研究中不可混淆性假设的困难

1. 引言：当我们无法控制所有混杂因素时

“*Although we cannot see the wind, we can see its effects on the leaves.*” — 统计学家对隐性混杂的隐喻

在第 10 至 15 章中，我们详细讨论了观测性研究中因果效应的识别与估计方法。这些方法的核心假设是**不可混淆性 (unconfoundedness)**：

$$(16.1) \quad Z \perp \{Y(1), Y(0)\} \mid X.$$

也就是说，在给定协变量 X 的条件下，治疗分配 Z 与潜在结果相互独立。

然而，这个假设在实践中有多可靠？

正如 George Box 所言：“所有模型都是错的，但有些有用。”不可混淆性假设本质上是一个关于数据生成过程的陈述——它声称我们已经控制了所有影响治疗分配和结果的混杂变量。但在真实的观测性研究中，我们真的能确保这一点吗？

问题的根源：协变量 X 永远只是我们观测到的协变量的一个子集。是否存在我们未能观测到的混杂因素 U ？如果存在，那么不可混淆性假设就不成立，我们基于此假设得到的因果效应估计量可能是有偏的。

本章将系统性地探讨这一困难：

- 首先，引入**因果图 (causal diagram)**作为可视化因果关系的工具；
- 其次，讨论**评估不可混淆性假设**的策略——我们无法直接检验它，但可以进行辅助分析；
- 最后，分析**过度调整 (over-adjustment)**的风险——调整错误的协变量反而可能引入新的偏倚。

2. 因果图的基本概念

2.1. 从因果图到数据生成过程。Pearl (1995) 引入了因果图作为经验研究中因果推理的有力工具。因果图的美妙之处在于：它能够将变量之间的因果关系以图示形式直观地表达出来，而我们可以直接从图中读出统计学含义。

考虑一个最简单的因果图结构：

$$X \rightarrow Z \rightarrow Y$$

其中 X 是协变量， Z 是治疗， Y 是结果。这个图的含义是： X 影响 Z ，而 Z 影响 Y 。从数学上讲，这对应于以下数据生成过程：

$$(16.2) \quad \begin{cases} X \sim F_X(x), \\ Z = f_Z(X, \varepsilon_Z), \\ Y(z) = f_Y(X, z, \varepsilon_Y(z)), \end{cases} \quad ??$$

其中 $\varepsilon_Z \perp \varepsilon_Y(z)$ (两组误差独立)。从这个方程组中，我们可以直接读出 $Z \perp Y(z) \mid X$ ，即不可混淆性假设成立。

现在考虑一个更复杂的情形——存在一个未观测的混杂因素 U ：

$$U \rightarrow Z, U \rightarrow Y, X \rightarrow Z, X \rightarrow Y$$

这个图对应的数据生成过程是：

$$(16.3) \quad \begin{cases} X \sim F_X(x), \\ U \sim F_U(u), \\ Z = f_Z(X, U, \varepsilon_Z), \\ Y(z) = f_Y(X, U, z, \varepsilon_Y(z)), \end{cases} \quad ??$$

其中 $\varepsilon_Z \perp \varepsilon_Y(z)$ 。从方程组中我们可以读出： $Z \perp Y(z) \mid (X, U)$ 成立，但 $Z \not\perp Y(z) \mid X$ ——不可混淆性在给定 (X, U) 时成立，但仅给定 X 时不成立。在这个情形中， U 被称为**未测混杂因素 (unmeasured confounder)**。

因果图的美学价值在于：它将不可测试的假设转化为直观的图形结构。当图中存在从 Z 到 Y 的后门路径 (backdoor path) 时，就意味着存在未被阻断的混杂。

3. 评估不可混淆性假设

3.1. 基本困难：假设本身不可检验。 回到不可混淆性假设：

$$(16.4) \quad Z \perp Y(1) \mid X, \quad Z \perp Y(0) \mid X.??$$

这个假设意味着：

$$(16.5) \quad \begin{aligned} \Pr\{Y(1) \mid Z = 1, X\} &= \Pr\{Y(1) \mid Z = 0, X\}, \\ \Pr\{Y(0) \mid Z = 1, X\} &= \Pr\{Y(0) \mid Z = 0, X\}. \end{aligned}$$

也就是说，在给定 X 的条件下，治疗组和对照组的潜在结果分布相同。但问题在于：潜在结果分布 $\Pr\{Y(1) \mid Z = 0, X\}$ 和 $\Pr\{Y(0) \mid Z = 1, X\}$ 是反事实的，我们永远无法直接从数据中观测到它们。

因此，**不可混淆性假设从根本上是不可直接检验的**——我们无法用统计检验来验证它是否成立。这并不意味着我们应该放弃因果推断，而是需要采用其他策略来评估这个假设的合理性。

统计学家区分了两个概念：**评估 (assess)** 和**检验 (test)**。前者是指补充性分析，用于支持或削弱初始分析的可信度；后者是正式的统计检验。我们无法检验不可混淆性，但可以评估它。

下面介绍两种主要的评估策略。

3.2. 策略一：利用阴性结果。核心思想：如果我们相信 $Z \perp Y(z) \mid X$ ，那么我们也倾向于相信 $Z \perp Y^n(z) \mid X$ ，其中 Y^n 是一个与 Y 具有相似混杂结构的**阴性结果 (negative outcome)**。关键在于，我们事先知道 Z 对 Y^n 的因果效应。

形式化地，假设 Y^n 满足：

$$(16.6) \quad \tau(Z \rightarrow Y^n) = \mathbb{E}\{Y^n(1) - Y^n(0)\} \text{ 是已知的.}$$

一个特别重要的情形是 $\tau(Z \rightarrow Y^n) = 0$ ——即我们事先知道治疗对阴性结果没有因果效应。

如果不可混淆性假设成立，那么数据应该显示 Z 对 Y^n 没有处理效应（或者有已知大小的效应）。如果数据显示出显著的效应，这可能暗示不可混淆性假设被违反。

例 16.1 (Cornfield 等 (1959): 吸烟与肺癌). *Cornfield 等 (1959)* 研究了吸烟对肺癌的因果效应。他们在分析中控制了众多重要的背景变量，但仍可能存在某些未测混杂因素使观察到的效应产生偏倚。

为了加强因果关系的证据，他们同时报告了吸烟对车祸的影响——基于生物学知识，吸烟对车祸应该没有因果效应。结果显示关联接近于零。因此，即使无法完全排除未测混杂，这个基于阴性结果的补充分析使吸烟对肺癌因果效应的证据更加有力。

例 16.2 (Jackson 等 (2006): 流感疫苗接种). *Jackson 等 (2006)* 对观测性研究的结果持怀疑态度。这些研究显示，在调整了测量的协变量后，流感疫苗接种显著降低了流感季节的肺炎/流感住院率和全因死亡率。

他们的补充分析考察了流感季节开始之前的结局指标。疫苗接种通常在秋季开始，但流感传播在冬季之前是极少的。基于生物学，疫苗效应在流感季节应该最为显著。但 *Jackson* 等发现，疫苗效应在流感季节之前反而更大——这暗示观察到的效应可能源于未测混杂。

阴性结果分析的力量来自于：如果治疗 Z 通过未测混杂 U 影响结果 Y ，那么 Z 通常也会通过同样的 U 影响与 Y 有相似混杂结构的变量。因此，如果我们在阴性结果上观察到了预期的零效应（或已知大小的效应），这支持了不可混淆性假设的合理性。

Lipsitch 等 (2010) 是阴性结果方法的系统性研究。Rosenbaum (1989) 讨论了已知因果效应在因果推断中的作用。

3.3. 策略二：利用阴性暴露。 阴性暴露是阴性结果的对偶概念。假设 Z^n 是一个与 Z 有相似混杂结构的治疗变量，且我们事先知道 Z^n 对 Y 的因果效应：

$$(16.7) \quad \tau(Z^n \rightarrow Y) = \mathbb{E}\{Y(1^n) - Y(0^n)\} \text{ 是已知的.}$$

例 16.3 (Sanderson 等 (2017): 母体暴露与后代结局). *Sanderson 等 (2017)* 给出了利用阴性暴露的多个例子。他们建议比较母体暴露与后代结局的关联，以及父亲暴露与同样结局的关联。

在母体吸烟与后代结局的研究中：母体吸烟可能受到未测混杂（如社会经济地位）的影响，而父亲吸烟不太可能受到同样的混杂影响（因为父亲不经历怀孕）。因此，如果观察到的母体吸烟效应远大于父亲吸烟效应，这支持了因果解释；如果两者效应相似，则暗示可能存在混杂。

阴性暴露分析的逻辑：如果不可混淆性成立，那么 Z 和 Z^n 应该表现出与 Y 相似（但已知）的关联模式。如果它们的行为不一致，则暗示存在未被控制的混杂。

3.4. 小结。 不可混淆性假设在本质上是不可直接检验的。虽然阴性结果和阴性暴露分析无法证明或推翻不可混淆性，但将它们作为补充性分析可以加强或削弱因果推断的证据基础。

然而，进行这类补充性分析通常并非易事：它需要更多的数据，更重要的是需要对因果问题的深入理解，以找到令人信服的阴性结果和阴性暴露。在实践中，找到一个与主结果有相同混杂结构但有已知效应的阴性结果/暴露，往往需要领域知识的支持。

4. 过度调整的问题

在第 10 章的协变量平衡检验中，我们已经看到：调整正确的协变量可以消除混杂偏倚。但**调整错误的协变量会如何？**

Rosenbaum (2002b) 写道：“没有理由避免调整描述研究对象治疗前特征的变量。”类似地，Rubin (2007) 写道：“通常，条件性越强的假设，越容易接受。”两者都主张应该控制所有观测到的治疗前协变量。

Pearl 不同意这个建议，并给出了两个著名的反例。下面我们详细介绍这两个反例。

4.1. M-偏倚. M-偏倚 (M-bias) 出现在具有 M 结构的因果图中。考虑以下图形：

$$U_1 \rightarrow X \leftarrow U_2, U_1 \rightarrow Z, U_2 \rightarrow Y$$

这个图之所以被称为 M 结构，是因为在因果图中它形似字母 M。从图中我们可以读出数据生成过程：

$$(16.8) \quad \begin{cases} U_1 \perp U_2, \\ X = f_X(U_1, U_2, \varepsilon_X), \\ Z = f_Z(U_1, \varepsilon_Z), \\ Y = Y(z) = f_Y(U_2, \varepsilon_Y), \end{cases}$$

其中 $(\varepsilon_X, \varepsilon_Z, \varepsilon_Y)$ 是独立的随机误差。在这个因果图中， X 是观测到的，但 U_1 和 U_2 是未观测的。如果改变 Z 的值， Y 的值完全不会改变——因为 Z 到 Y 之间没有因果路径。因此， Z 对 Y 的真实因果效应必然为零。

从数学上看：在这个数据生成过程中， $Z \perp Y$ 成立，因此 Z 和 Y 之间的简单关联为零。不调整 X 的简单估计量是无偏的：

$$(16.9) \quad \tau_{PF} = \mathbb{E}(Y | Z = 1) - \mathbb{E}(Y | Z = 0) = 0.$$

但是，如果我们调整 X （即条件于 X ），情况就不同了。调整后， U_1 和 U_2 不再条件独立： $U_1 \not\perp U_2 | X$ ，进而 $Z \not\perp Y | X$ ，导致调整后的估计量有偏：

$$(16.10) \quad \int \{\mathbb{E}(Y | Z = 1, X = x) - \mathbb{E}(Y | Z = 0, X = x)\} f(x) dx \neq 0.$$

直觉解释： X 同时受到 U_1 和 U_2 的影响，而 U_1 影响 Z ， U_2 影响 Y 。当我们条件于 X 时，我们实际上是在 X 的各个取值上比较 Z 和 Y 。但 X 的条件化会人为地在 U_1 和 U_2 之间建立关联——这创造了一条从 Z 到 Y 的虚假后门路径。

为了更直观地理解，我们考虑一个正态线性模型的具体例子（详细推导见习题 16.2）：

$$(16.11) \quad \begin{cases} X = aU_1 + bU_2 + \varepsilon_X, \\ Z = cU_1 + \varepsilon_Z, \\ Y = dU_2 + \varepsilon_Y, \end{cases}$$

其中 $(U_1, U_2, \varepsilon_X, \varepsilon_Z, \varepsilon_Y) \stackrel{\text{iid}}{\sim} N(0, 1)$ 。我们可以计算：

$$(16.12) \quad \text{cov}(Z, Y) = \text{cov}(cU_1 + \varepsilon_Z, dU_2 + \varepsilon_Y) = 0,$$

这证实了未调整估计量是无偏的。但在给定 X 的条件下， Z 和 Y 的偏相关系数为（推导见习题 16.2）：

$$(16.13) \quad \rho_{ZY|X} \propto -abcd,$$

即偏倚与路径系数的乘积 $abcd$ 成正比。

例 16.4 (M-偏倚的数值演示). 考虑样本量 $n = 10^6$ 的大规模蒙特卡洛模拟：

```
U1 = rnorm(n)
U2 = rnorm(n)
X = U1 + U2 + rnorm(n)
Y = U2 + rnorm(n)
Z = U1 + rnorm(n)
```

连续治疗

```
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.001
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] -0.20
```

二值治疗

```
Z = (Z >= 0)
```

```
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.002
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] -0.42
```

未调整的简单估计量接近真实值 (0)，但调整 X 后的估计量产生了显著偏倚 (约 -0.2 到 -0.4)。这就是 M -偏倚。

M -偏倚的教训是：并非所有治疗前协变量都应该调整。调整一个与未测混杂 U_1 和 U_2 都相关的变量 X ，可能反而在 U_1 和 U_2 之间建立虚假的关联，从而引入偏倚。

4.2. Z-偏倚. Z-偏倚 (Z-bias) 是另一个过度调整的例子，但机制与 M -偏倚不同。考虑以下因果图：

$$Z \leftarrow X \rightarrow U \rightarrow Y$$

其中 X 影响 Z 和 U ，而 U 同时影响 Z 和 Y 。对应的数据生成过程是：

$$(16.14) \quad \begin{cases} Z = aX + bU + \varepsilon_Z, \\ Y(z) = \tau z + cU + \varepsilon_Y, \end{cases}$$

其中 $(U, X, \varepsilon_Z, \varepsilon_Y) \stackrel{\text{iid}}{\sim} N(0, 1)$ 。在这个设定中， $X \perp U$ ，但 X 与 Z 和 Y 都有关联—— X 通过 Z 影响 Y ，而 U 是一个未测混杂。

直觉：治疗 Z 是 X 、未测混杂 U 和其他随机误差的函数。条件于 X 会使 Z 变得更依赖于 U ，从而**放大了**由 U 引起的混杂偏倚。

数学上，未调整的 OLS 估计量是（详细推导见习题 16.1）：

$$(16.15) \quad \tau_{\text{unadj}} = \tau + \frac{c \operatorname{cov}(Z, U)}{\operatorname{var}(Z)} = \tau + \frac{cb}{a^2 + b^2 + 1},$$

其偏倚为 $bc/(a^2 + b^2 + 1)$ 。

调整后的 OLS 估计量（从 Y 对 (Z, X) 的回归）满足（详细推导见习题 16.1）：

$$(16.16) \quad \tau_{\text{adj}} = \tau + \frac{bc}{b^2 + 1}.$$

比较两者：当 $a \neq 0$ 时， $a^2 + b^2 + 1 > b^2 + 1$ ，因此

$$(16.17) \quad \left| \frac{bc}{a^2 + b^2 + 1} \right| < \left| \frac{bc}{b^2 + 1} \right|.$$

也就是说，**调整后的估计量比未调整的估计量偏倚更大！**而且， X 与 Z 的关联越强 (a 越大)，调整引入的偏倚就越大。

例 16.5 (Z-偏倚的数值演示). 考虑蒙特卡洛模拟：

```
n = 10^6
X = rnorm(n)
U = rnorm(n)
Z = X + U + rnorm(n)
Y = U + rnorm(n)

# Z ~ X + U
```

```
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.333
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.501
```

X-Z 关联更强时

```
Z = 2*X + U + rnorm(n)
```

```
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.167
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.501
```

X-Z 关联更强时

```
Z = 10*X + U + rnorm(n)
```

```
summary(lm(Y ~ Z))$coef[2, 1] # [1] 0.01
summary(lm(Y ~ Z + X))$coef[2, 1] # [1] 0.50
```

可以看到：随着 X 与 Z 的关联增强，未调整估计量越来越接近真实值 $\tau = 0$ ，而调整后的估计量始终为 0.5——因为调整反而引入了更大的偏倚。

Z-偏倚的技术细节见 Problem 16.1。Pearl (2010a, 2011) 用因果图解释了这种现象。Ding 等 (2017b) 提供了更一般的理论。

为什么叫 Z-偏倚？ 在 Pearl 的原始论文中，他用符号 Z 表示我们这里的变量 X （而用 X 表示治疗变量）。为了避免混淆，本书在第五部分讨论工具变量时会正式使用 Z 这个符号——这也是为什么在工具变量情境下，Z-偏倚也被称为**工具变量偏倚 (instrumental variable bias)**。

4.3. 哪些协变量应该调整？ 真实的因果图可能非常复杂，但我们可以用一个简化的图形来澄清许多概念。考虑以下结构：

$$X_Y \rightarrow Y, X_Y \rightarrow Z, X \rightarrow Z, X \rightarrow Y, X_I \rightarrow Z, X_I \rightarrow Y$$

各类协变量的特征如下：

- (1) X (**混杂变量**)：同时影响治疗和结果。条件于 X 确保不可混淆性假设成立，我们应该控制 X 。
- (2) X_R (**无关变量**)：既不影响治疗也不影响结果，是纯随机噪声。在分析中包含它不会引入偏倚，但会在有限样本中引入不必要的变异性。
- (3) X_Z (**工具变量**)：仅通过治疗影响结果。在图中包含它不会引入偏倚，但会增加估计量的变异性。然而，在存在未测混杂的情况下（如 Z-偏倚所示），调整 X_Z 会**放大偏倚**。
- (4) X_Y (**预测变量**)：仅影响结果但不影响治疗。即使不条件于它，不可混淆性假设仍然成立。由于它们对结果有预测力，在分析中包含它们通常能提高精度。
- (5) X_I (**干预后变量**)：受治疗和结果共同影响，是治疗后变量。如果目标是推断治疗对结果的因果效应，我们不应该调整它。

如果我们相信上述因果图的结构，那么我们应该至少调整 X 以消除偏倚，理想情况下还应进一步调整 X_Y 以减少方差。

实践中的困难： 我们永远无法确切知道真实的底层数据生成过程。这是因果推断的根本挑战——我们需要领域知识和假设来指导协变量的选择。

Table 1 总结了各类协变量的特征。

5. 习题

练习 16.1. 验证正文中的公式 eq. (16.15) 和 eq. (16.16)。

TABLE 1. 协变量类型与调整策略

类型	Z 前置吗?	Y 前置吗?	调整建议
X (混杂)	是	是	应该调整
X_R (无关)	否	否	可调整 (增加方差)
X_Z (工具)	是	否	谨慎: 可能放大偏倚
X_Y (预测)	否	是	可调整 (减少方差)
X_I (干预后)	是	是	不应调整

练习 16.2. 考虑正文中的 M -偏倚正态线性模型。证明给定 X 时 Z 和 Y 的偏相关系数公式 eq. (16.13)。

练习 16.3. 找出一个你自己的研究领域中的阴性结果或阴性暴露的例子。讨论为什么它符合阴性控制的条件, 以及它如何帮助评估不可混淆性假设。

练习 16.4. ? 和 *econometricians* 提出了以下 **Cochran 公式** (也称为遗漏变量偏倚公式)。设 $(y_i, x_{1i}, x_{2i})_{i=1}^n$ 为 IID 样本, 其中 y_i 是标量, x_{1i} 维数为 K , x_{2i} 维数为 L 。考虑 OLS 分解:

$$\begin{aligned} y_i &= \beta_1^T x_{1i} + \beta_2^T x_{2i} + \varepsilon_i \quad (\text{长回归}), \\ y_i &= \gamma^T x_{1i} + e_i \quad (\text{短回归}), \\ x_{2i} &= \delta^T x_{1i} + v_i. \end{aligned}$$

证明: $\gamma = \beta_1 + \delta\beta_2$ 。解释为什么 $\delta\beta_2$ 被称为遗漏变量偏倚。

练习 16.5. 设计一个模拟研究, 演示以下情形:

- (1) 调整混杂变量 X 可以减少偏倚;
- (2) 调整与未测混杂相关的变量会引入 M -偏倚;
- (3) 调整工具变量 X_Z 在存在未测混杂时会放大偏倚。

对于每种情形, 使用大样本量 ($n = 10^5$) 计算未调整和调整后的估计量。

6. 推荐阅读

关于因果图和因果推断的深入讨论, 见 Pearl (2000) 的经典教科书。

VanderWeele 和 Shpitser (2011) 讨论了协变量选择的正式准则。

Rosenbaum (2002b) 是关于观测性研究中敏感性分析的重要参考文献, 也是本章许多思想的源头。

Ding 等 (2017b) 提供了 Z -偏倚 (工具变量偏倚) 的一般性理论。

E-Value: 未测混杂观测性研究中的因果证据

1. 引言：当可忽略性假设失效时

“It is possible that the entire relationship between cigarette smoking and lung cancer is due to some common cause.” — [?]

在 Part III 中，我们详细讨论了观测性研究的四大支柱：outcome regression (第 10 章)、逆倾向得分加权 (第 11 章)、双重稳健 (第 12 章) 以及匹配 (第 15 章)。这四种方法的核心假设是**可忽略性 (ignorability)**：

$$(79) \quad Z \perp \{Y(1), Y(0)\} \mid X.$$

即在协变量 X 条件下，治疗分配 Z 与潜在结果相互独立。这个假设保证了我们可以从观测数据中识别因果效应。然而，**可忽略性假设无法从数据本身验证**——它是一种根本性的假设，依赖于研究者的领域知识和对因果结构的判断。

这正是观测性研究长期被批评的原因：如果无法控制所有混淆因素，观察到的治疗与结果之间的关联可能是虚假的。统计学能告诉我们观测数据中的关联有多强，但无法保证这种关联背后存在真实的因果关系。

然而，**并非所有观测性研究都生来平等**。一些研究即便存在未测混杂，其提供的因果证据也比其他研究更强。关键在于：要完全解释掉观察到的关联，未测混杂需要有多强？如果这种强度在领域知识上是不合理的，我们就有理由相信因果关系确实存在。

本章引入的 **E-value** (VanderWeele and Ding, 2017) 正是对这一思想的数学量化。它基于 Ding and VanderWeele (2016) 的理论，为评估观测性研究中的因果证据提供了一个统一且可解释的度量。第 21 章讨论平均因果效应的灵敏度分析；第 25 章讨论 Rosenbaum 框架下的匹配研究灵敏度分析。

2. Cornfield 型灵敏度分析

2.1. 从可忽略性到潜在可忽略性。 放弃假设 eq. (79) 并不意味着放弃一切分析工具。我们仍然可以假设**潜在可忽略性 (latent ignorability)**：

$$(80) \quad Z \perp \{Y(1), Y(0)\} \mid (X, U),$$

其中 U 是未测混杂变量，条件于 (X, U) 时治疗与潜在结果独立。注意 eq. (80) 比 eq. (79) 更弱——它允许 Z 与 Y 之间存在通过 U 传递的关联，只要这种关联可以被 U 完全解释。

本章的方法在二值结果 Y 上表现最佳 (Ding and VanderWeele, 2016)，但可推广到其他非负结果。为简化叙述，除非特别说明，我们均假设 Y 为二值。

2.2. 真实风险比与观测风险比。 在 $X = x$ 条件下，真实的条件风险比为：

$$(81) \quad \text{RR}_{ZY|x}^{\text{true}} = \frac{\Pr\{Y(1) = 1 \mid X = x\}}{\Pr\{Y(0) = 1 \mid X = x\}}.$$

但我们从数据中能直接计算的是观测风险比：

$$(82) \quad RR_{ZY|x}^{\text{obs}} = \frac{\Pr(Y = 1 \mid Z = 1, X = x)}{\Pr(Y = 1 \mid Z = 0, X = x)}.$$

在存在未测混杂 U 时，二者一般不相等。直观上，这是因为 U 在治疗组和对照组中的分布不同（ U 同时影响治疗分配和结果），而真实的因果效应需要控制 U 后才能得到。

考虑如下因果图（条件于 X ）：

$$Z \leftarrow U \rightarrow Y,$$

其中 U 是 Z 和 Y 的共同原因（common cause）。在此结构下， $Z \perp Y \mid (X, U)$ 但 $Z \not\perp Y \mid X$ 。为简化，我们假设 U 为二值，尽管 Ding and VanderWeele (2016) 的理论对 U 的一般形式也成立。

定义两个灵敏度参数：

$$(83) \quad RR_{ZU|x} = \frac{\Pr(U = 1 \mid Z = 1, X = x)}{\Pr(U = 1 \mid Z = 0, X = x)},$$

衡量治疗-混杂关联；以及

$$(84) \quad RR_{UY|x} = \frac{\Pr(Y = 1 \mid U = 1, X = x)}{\Pr(Y = 1 \mid U = 0, X = x)},$$

衡量混杂-结果关联。这两个量都无法从数据中识别——它们是未知的灵敏度参数，反映了未测混杂的强度。

2.3. Cornfield 不等式。 下面的定理是整个 E-value 理论的基石。

定理 17.1 (Cornfield-type 上界). 在假设 eq. (80) 下，假设

$$(85) \quad RR_{ZY|x}^{\text{obs}} > 1, \quad RR_{ZU|x} > 1, \quad RR_{UY|x} > 1.$$

则有

$$(86) \quad RR_{ZY|x}^{\text{obs}} \leq \frac{RR_{ZU|x} \cdot RR_{UY|x}}{RR_{ZU|x} + RR_{UY|x} - 1}.$$

定理 17.1 的含义： 在潜在可忽略性下，治疗与结果之间的观测关联完全来自两条路径—— $Z \leftarrow U \rightarrow Y$ ——的组合效应。上界 $RR_{ZU|x} \cdot RR_{UY|x} / (RR_{ZU|x} + RR_{UY|x} - 1)$ 体现了这两条路径的“乘法阻塞”：要产生一个较大的 $RR_{ZY|x}^{\text{obs}}$ ，两条路径都必须足够强。

特别地，从 eq. (86) 可推出 **Cornfield 不等式** (Gastwirth et al., 1998)：

$$(87) \quad \min(RR_{ZU|x}, RR_{UY|x}) \geq RR_{ZY|x}^{\text{obs}}.$$

即：要完全解释掉观测到的风险比，未测混杂与治疗的关联以及与结果的关联，都必须至少与观测到的风险比一样强。这个简单而强大的结论，首次由 Cornfield et al. (1959) 在讨论吸烟与肺癌时得到。

证明思路： 定义 $f_{1,x} = \Pr(U = 1 \mid Z = 1, X = x)$ 和 $f_{0,x} = \Pr(U = 1 \mid Z = 0, X = x)$ 。通过全概率公式分解 $RR_{ZY|x}^{\text{obs}}$ 并利用 $Z \perp Y \mid (X, U)$ ，可得恒等式 (100)。¹

¹完整证明推导见附录 chapter 18

3. E-value

3.1. 从 Cornfield 不等式到 E-value. 从定理 17.1 和引理 17.3(4), 定义 $w = \max(\text{RR}_{ZU|x}, \text{RR}_{UY|x})$, 则

$$(88) \quad \text{RR}_{ZY|x}^{\text{obs}} \leq \frac{w^2}{2w - 1}.$$

解这个二次不等式, 较小根始终 ≤ 1 , 故

$$(89) \quad w \geq \text{RR}_{ZY|x}^{\text{obs}} + \sqrt{\text{RR}_{ZY|x}^{\text{obs}}(\text{RR}_{ZY|x}^{\text{obs}} - 1)}.$$

这给出了 E-value 的定义。

定义 17.2 (E-value). 给定观测条件风险比 $\text{RR}_{ZY|x}^{\text{obs}}$, 定义 **E-value** 为

$$(90) \quad \text{E-value} = \text{RR}_{ZY|x}^{\text{obs}} + \sqrt{\text{RR}_{ZY|x}^{\text{obs}}(\text{RR}_{ZY|x}^{\text{obs}} - 1)}.$$

E-value 的解释: E-value 表示要完全解释掉观测到的风险比, $\max(\text{RR}_{ZU|x}, \text{RR}_{UY|x})$ 必须达到的最小值。换言之, 如果领域知识认为任何合理的未测混杂, 其与治疗和结果的关联程度都不可能超过某个阈值 R , 那么当 $R < \text{E-value}$ 时, 我们有理由相信因果关系确实存在。

E-value 与 Fisher p 值的对比: 在随机化实验中, Fisher p 值衡量的是因果证据。但在大样本观测性研究中, p 值可能是因果证据的误导性度量——即使真实因果效应为零, 微弱的未测混杂也可以产生极小的 p 值。采样误差随样本量增大而减小, 但未测混杂带来的不确定性不会随样本量增大而消失。E-value 正是为了填补这一空白而设计的。

引理 17.3 (β 函数性质). 定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$ ($w_1 > 1, w_2 > 1$)。则:

- (1) $\beta(w_1, w_2)$ 对称于 w_1 和 w_2 ;
- (2) $\beta(w_1, w_2)$ 对 w_1 和 w_2 均单调递增;
- (3) $\beta(w_1, w_2) \leq w_1$ 且 $\beta(w_1, w_2) \leq w_2$;
- (4) $\beta(w_1, w_2) \leq w^2 / (2w - 1)$, 其中 $w = \max(w_1, w_2)$ 。

引理 17.3 的意义: (3) 意味着 Cornfield 不等式可以直接从定理 17.1 推出; (4) 是连接 Cornfield 界与 E-value 的关键步骤。²

4. 经典例子：吸烟与肺癌

例 17.1 (Hammond and Horn, 1958). 研究美国人群中吸烟与肺癌的关系。不调整协变量的数据可列为下表:

	肺癌	无肺癌
吸烟者	397	78,557
非吸烟者	51	108,778

基于该数据, 风险比估计为 $\widehat{RR} = 10.73$, 95% 置信区间为 $[8.02, 14.36]$ 。

- 解释点估计的 E-value:

$$\text{E-value} = 10.73 + \sqrt{10.73 \times 9.73} \approx 20.95.$$

- 解释下限的 E-value:

$$\text{E-value}_{\text{CI}} = 8.02 + \sqrt{8.02 \times 7.02} \approx 15.52.$$

²证明见附录 chapter 19

解读：要完全解释掉观察到的风险比（甚至其置信下限），未测混杂与治疗的关联以及与结果的关联，都必须达到至少 15.52。这意味着未测混杂必须是一个**极强**的风险因子——它与吸烟的关联程度要接近吸烟本身与肺癌的关联程度（10 倍以上）。在领域知识上，这种强度的未知混杂似乎不太合理，因此该研究提供了较强的因果证据。

图 ?? (Hammond and Horn 数据的混淆强度轮廓) 展示了要解释掉点估计和置信下限，两类混淆强度 ($RR_{ZU|x}, RR_{UY|x}$) 需要满足的条件。

5. 扩展

5.1. E-value 与 Bradford Hill 因果判定准则. E-value 提供了因果证据的定量度量，但它与流行病学中经典的 **Bradford Hill 准则** (Bradford Hill, 1965) 有深刻的联系。Bradford Hill 提出了九条判断因果关系的准则，其中第一条是：

强度 (Strength)： 关联越强，因果解释的可能性越大。

定理 17.1 从数学上精确化了这一直觉：**更强的关联需要更强的未测混杂来解释**。E-value 正是这种“强度”的量化。

当然，关联强度只是因果判定的一个方面。Bradford Hill 的其他准则——时间顺序 (temporality)、生物学合理性 (biological plausibility)、一致性 (consistency)、剂量-反应关系 (dose-response) ——都从不同角度提供证据。E-value 只量化了“强度”这一维度。

定义 17.4 (Bradford Hill 九条因果准则). [?] 提出的九条因果判定准则：

- (1) 强度 (*strength*);
- (2) 一致性 (*consistency*);
- (3) 特异性 (*specificity*);
- (4) 时间顺序 (*temporality*);
- (5) 生物学梯度 (*biological gradient*);
- (6) 生物学合理性 (*plausibility*);
- (7) 一致性 (*coherence*);
- (8) 实验证据 (*experiment*);
- (9) 类比 (*analogy*).

E-value 量化了第 (1) 条准则，但没有涉及其他八条。这是 E-value 的适用范围——它是一个有意义的补充，但不是因果判定的全部。

5.2. 逻辑斯蒂回归后的 E-value. 流行病学研究中，二值结果常用逻辑斯蒂回归建模：

$$(91) \quad \Pr(Y_i = 1 \mid Z_i, X_i) = \frac{e^{\beta_0 + \beta_1 Z_i + \beta_2^\top X_i}}{1 + e^{\beta_0 + \beta_1 Z_i + \beta_2^\top X_i}}.$$

其中系数 β_1 是给定 X 下治疗与结果的**条件比数比 (conditional odds ratio)** 的对数。逻辑斯蒂模型的一个重要假设是：比数比在所有 X 取值上是共同的 (common odds ratio)。

当结果罕见时 ($\Pr(Y = 1 \mid Z, X)$ 接近 0)，条件比数比近似于条件风险比 (见附录 chapter 20)。

因此，在罕见结果假设下，我们可以直接基于逻辑斯蒂回归估计的 $\hat{\beta}_1$ 计算 E-value：

$$(92) \quad \widehat{\text{E-value}} = \exp(\hat{\beta}_1) + \sqrt{\exp(\hat{\beta}_1)(\exp(\hat{\beta}_1) - 1)}.$$

这使得 E-value 可以方便地应用于常规的流行病学分析流程。

例 17.2 (NCHS 2003 出生数据). 使用美国国家卫生统计中心 2003 年出生证明数据, 研究高龄母亲 (≥ 35 岁) 对早产的影响。调整社会人口学协变量后, 逻辑斯蒂回归得到的条件风险比为 1.31, 其 95% 置信区间为 [1.29, 1.33]。

对应的 *E-value* 约为 1.94 (点估计) 和 1.91 (置信下限)。这意味着要解释掉观察到的关联, 未测混杂必须同时与治疗 (高龄) 和结果 (早产) 有至少 1.9 倍的关联——这个强度在流行病学上看起来是较大的, 但远不如吸烟-肺癌例子中的 20.95。

5.3. 允许非零真实因果效应. 定理 17.1 假设真实因果效应为零。Ding and VanderWeele (2016) 将结果推广到允许非零真实因果效应的情形。

定理 17.5 (含真实因果效应的下界). 修改 $RR_{UY|x}$ 的定义为:

$$(93) \quad RR_{UY|x} = \max_{z=0,1} \frac{\Pr(Y=1 \mid Z=z, U=1, X=x)}{\Pr(Y=1 \mid Z=z, U=0, X=x)}.$$

则在假设 eq. (80) 下,

$$(94) \quad RR_{ZY|x}^{\text{true}} \geq \frac{RR_{ZY|x}^{\text{obs}}}{\frac{RR_{ZU|x} \cdot RR_{UY|x}}{RR_{ZU|x} + RR_{UY|x} - 1}}.$$

定理 17.5 的解读: 即使存在未测混杂, 定理也给出了真实因果效应 $RR_{ZY|x}^{\text{true}}$ 的一个下界。这个下界等于观测风险比除以 Cornfield 上界。当灵敏度参数取不同值时, 我们可以评估因果效应下界对未测混杂强度的敏感性。

6. 批评与回应

自 *E-value* 论文发表以来, 它已成为流行病学研究中报告的标准数字。但它也受到了批评 (Ioannidis et al., 2019)。下面讨论几个主要局限性。

6.1. E-value 不过是风险比的单调变换. 当风险比较大时, *E-value* 近似等于 $2 \cdot RR_{ZY|x}^{\text{obs}}$ ——几乎是线性的。因此批评者认为 *E-value* 不过是风险比的一个单调变换, 没有提供额外信息。

这部分正确——*E-value* 确实完全基于风险比的点估计和置信限。但关键在于: *E-value* 有**有意义的解释** (定义 17.2), 而风险比本身没有这种“需要多强的未测混杂”的解释。从风险比 10.73 到 *E-value* 20.95, 数字变了, 但解释的含义完全不同。

6.2. E-value 的校准问题. *E-value* 等于 $\max(RR_{ZU|x}, RR_{UY|x})$ ——即要解释掉观察到的关联, 未测混杂与治疗 and 结果关联所必须达到的最小值。问题在于: 这个未测混杂本身是无法观测的, 因此很难判断某个 *E-value* 究竟算“大”还是“小”。

此外, *E-value* 的大小取决于我们调整了多少协变量 X ——它量化的是**给定已调整协变量后的**残余混杂强度。不同研究之间的 *E-value* 不能直接比较, 因为它们的 X 不同。

一个直观的校准思路是“逐一剔除协变量”法: 如果我们把某个已调整的协变量 X_j 当作“未测混杂”来对待, 计算 $Z-X_j$ 和 X_j-Y 的风险比, 这些比值可以提供参考尺度。但这一方法尚无严格的理论支撑。

6.3. E-value 最适用于二值结果和风险比. 定理 17.1 在二值结果和风险比尺度上表现最佳。Ding and VanderWeele (2016) 也提出了风险差、均值比 (针对非负结果) 以及生存分析中的风险比 (HR) 的灵敏度分析方法, 但它们不如二值结果下的 *E-value* 那样优雅和简洁。第 21 章将给出平均因果效应的更一般灵敏度分析方法, 适用于 outcome regression、IPW 和双重稳健估计。

7. 本章小结

本章围绕 E-value 展开，核心思想是：

- (1) **未测混杂无法从数据中验证**，但我们可以量化：要解释掉观察到的关联，未测混杂必须有多强？
- (2) **Cornfield 不等式**：要完全解释掉风险比 $RR_{ZY|x}^{obs}$ ，未测混杂与治疗的关联和与结果的关联都必须至少达到 $RR_{ZY|x}^{obs}$ ；
- (3) **E-value** 是这一思想的精确数学化： $E\text{-value} = RR_{ZY|x}^{obs} + \sqrt{RR_{ZY|x}^{obs}(RR_{ZY|x}^{obs} - 1)}$ ；
- (4) E-value 越大，意味着需要越强的未测混杂才能解释掉观察到的关联，因果证据越强；
- (5) E-value 有明确的局限性——它只量化了 Bradford Hill 准则中的“强度”维度，且最适用于二值结果和风险比。

本章将所有推导放在附录，正文专注于概念的动机、历史的脉络和结果的理解。

8. 习题

习题 17.1 (17.1). 证明函数 $f(x) = (ax + 1)/(bx + 1)$ 在 $a > b$ 时关于 x 单调递增，在 $a < b$ 时单调递减。

习题 17.2 (17.2). 证明在假设 $Z \perp Y | (X, U)$ 下，如果 $RR_{ZU|x} > 1$ 但 $RR_{UY|x} < 1$ ，则 $RR_{ZY|x}^{obs} < 1$ 。这说明 eq. (85) 中的第三个条件在某种意义上是冗余的。

习题 17.3 (17.3). 证明引理 17.3。

习题 17.4 (17.4). (*Schlesselman 1978* 公式) 在二值治疗 Z 、结果 Y 和未测混杂 U 下，假设层内 ($U = 0$ 和 $U = 1$) 治疗对结果的风险比相同， $RR_{ZY|U=0} = RR_{ZY|U=1}$ ，且混杂对结果的风险比在两组治疗下也相同 (记为 γ)。证明：

$$(95) \quad \frac{RR_{ZY}^{obs}}{RR_{ZY}^{true}} = \frac{1 + (\gamma - 1) \Pr(U = 1 | Z = 1)}{1 + (\gamma - 1) \Pr(U = 1 | Z = 0)}.$$

并讨论此公式与定理 17.1 的关系。

习题 17.5 (17.5). 使用与例 17.2 相同的数据集，计算结果为子痫前期 (*preeclampsia*) 时的 E-value。

习题 17.6 (17.6). (风险差的 *Cornfield* 不等式) 考虑二值 Z, Y, U 。在潜在可忽略性 $Z \perp Y | U$ 下，证明风险差的 *Cornfield* 不等式：

$$(96) \quad RD_{ZY}^{obs} = RD_{ZU} \times RD_{UY},$$

并由此推出：

$$(97) \quad \min(RD_{ZU}, RD_{UY}) \geq RD_{ZY}^{obs}, \quad \max(RD_{ZU}, RD_{UY}) \geq \sqrt{RD_{ZY}^{obs}}.$$

9. 推荐阅读

- ?：扩展并统一了 Cornfield 型灵敏度分析，是 E-value 的理论基础。
- ?：首次正式提出 E-value 并给出其流行病学解释。
- ?：Bradford Hill 原文，九条因果准则的经典来源。
- ?：对 E-value 的批评性讨论。

附录：定理 17.1 的证明

1. 背景与目标

我们要在假设 eq. (80) 下，证明观测风险比的上界。核心思想是：条件于 (X, U) 后，治疗 Z 与结果 Y 独立，因此观测风险比中的分子和分母分别是 U 在治疗组和对照组中分布的加权平均。

2. 记号定义

定义：

$$(98) \quad f_{1,x} = \Pr(U = 1 \mid Z = 1, X = x), \quad f_{0,x} = \Pr(U = 1 \mid Z = 0, X = x).$$

由灵敏度参数的定义 eq. (83)：

$$(99) \quad \text{RR}_{ZU|x} = \frac{f_{1,x}}{f_{0,x}} \implies f_{0,x} = \frac{f_{1,x}}{\text{RR}_{ZU|x}}.$$

定义 $\gamma_x = \text{RR}_{UY|x}$ 以简化记号。

3. 详细推导

利用全概率公式，分子（治疗组的条件结果概率）为：

$$\begin{aligned} \Pr(Y = 1 \mid Z = 1, X = x) &= \Pr(Y = 1 \mid U = 1, X = x) \Pr(U = 1 \mid Z = 1, X = x) \\ &\quad + \Pr(Y = 1 \mid U = 0, X = x) \Pr(U = 0 \mid Z = 1, X = x) \\ &= \gamma_x f_{1,x} + (1 - f_{1,x}) \cdot 1 \\ &= (\gamma_x - 1) f_{1,x} + 1. \end{aligned}$$

分母（对照组的条件结果概率）为：

$$\begin{aligned} \Pr(Y = 1 \mid Z = 0, X = x) &= \Pr(Y = 1 \mid U = 1, X = x) \Pr(U = 1 \mid Z = 0, X = x) \\ &\quad + \Pr(Y = 1 \mid U = 0, X = x) \Pr(U = 0 \mid Z = 0, X = x) \\ &= \gamma_x f_{0,x} + (1 - f_{0,x}) \\ &= (\gamma_x - 1) f_{0,x} + 1. \end{aligned}$$

代入 $f_{0,x} = f_{1,x}/\text{RR}_{ZU|x}$ ，得：

$$\Pr(Y = 1 \mid Z = 0, X = x) = (\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1.$$

因此观测风险比可以写成：

$$(100) \quad \text{RR}_{ZY|x}^{\text{obs}} = \frac{(\gamma_x - 1) f_{1,x} + 1}{(\gamma_x - 1) \frac{f_{1,x}}{\text{RR}_{ZU|x}} + 1}.$$

4. 单调性与上界

对 $f_{1,x} \in [0, 1]$ ，可验证函数

$$g(t) = \frac{(a-1)t + 1}{(a-1)\frac{t}{b} + 1}$$

在 $a > 1, b > 1$ 时关于 t 单调递增（习题 17.1）。因此 $f_{1,x}$ 越大， $\text{RR}_{ZY|x}^{\text{obs}}$ 越大。取上界 $f_{1,x} = 1$ ：

$$\text{RR}_{ZY|x}^{\text{obs}} \leq \frac{(\gamma_x - 1) + 1}{\frac{\gamma_x - 1}{\text{RR}_{ZU|x}} + 1} = \frac{\gamma_x \cdot \text{RR}_{ZU|x}}{\gamma_x + \text{RR}_{ZU|x} - 1}.$$

这正是定理 17.1 中的上界 eq. (86)。

5. 恒等式

由以上推导，我们实际得到了一个精确的恒等式（而非仅仅是上界）eq. (100)。这个恒等式涉及三个灵敏度参数 ($f_{1,x}, \text{RR}_{ZU|x}, \text{RR}_{UY|x}$)，而定理 17.1 的上界只涉及后两者。数学上恒等式强于不等式，但恒等式需要多一个灵敏度参数——这是灵敏度分析中**准确度与便利性之间的权衡**。

附录：引理 17.3 的证明

定义 $\beta(w_1, w_2) = w_1 w_2 / (w_1 + w_2 - 1)$, 其中 $w_1 > 1, w_2 > 1$ 。

性质 (1) 对称性: 显然 $\beta(w_1, w_2) = \beta(w_2, w_1)$ 。

性质 (2) 单调性: 计算偏导数:

$$\frac{\partial \beta}{\partial w_1} = \frac{w_2(w_1 + w_2 - 1) - w_1 w_2}{(w_1 + w_2 - 1)^2} = \frac{w_2(w_2 - 1)}{(w_1 + w_2 - 1)^2} > 0.$$

同理 $\partial \beta / \partial w_2 > 0$, 故 β 对两个变量均单调递增。

性质 (3) 上界:

$$\beta(w_1, w_2) = \frac{w_1 w_2}{w_1 + w_2 - 1} \leq \frac{w_1 w_2}{w_1} = w_2 \quad (\text{因为 } w_2 - 1 \geq 0).$$

对称地得到 $\beta \leq w_1$ 。

性质 (4) $w = \max(w_1, w_2)$ 时的界: 设 $w_1 = w, w_2 \leq w$, 则

$$\beta(w_1, w_2) = \frac{w \cdot w_2}{w + w_2 - 1} \leq \frac{w \cdot w}{w + w - 1} = \frac{w^2}{2w - 1}.$$

证毕。

附录：罕见结果近似

对于二值结果 Y ，逻辑斯蒂模型 eq. (91) 中治疗指示变量 Z 的系数 β_1 是条件**比数比** (**odds ratio**):

$$\beta_1 = \log \text{OR}_{ZY|x} = \log \frac{\text{odds}(Y = 1 \mid Z = 1, X = x)}{\text{odds}(Y = 1 \mid Z = 0, X = x)}.$$

当结果罕见时， $\Pr(Y = 1 \mid Z = 1, X = x) \approx 0$ 且 $\Pr(Y = 1 \mid Z = 0, X = x) \approx 0$ ，此时

$$\text{odds}(Y = 1 \mid Z, X) \approx \frac{\Pr(Y = 1 \mid Z, X)}{1 - \Pr(Y = 1 \mid Z, X)} \approx \Pr(Y = 1 \mid Z, X).$$

因此罕见结果假设下，条件比数比近似于条件风险比：

$$\beta_1 \approx \log \text{RR}_{ZY|x}^{\text{obs}}.$$

由此可得 $\exp(\beta_1) \approx \text{RR}_{ZY|x}^{\text{obs}}$ ，进而 E-value 的计算公式 eq. (90) 可直接应用于逻辑斯蒂回归系数。

平均因果效应的灵敏度分析

1. 引言：可忽略性失效时我们能做什么

在 Part III 中，我们详细讨论了四种基于可忽略性假设的因果推断方法：outcome regression（第 10 章）、逆倾向得分加权（第 11 章）、双重稳健估计（第 12 章）以及匹配（第 15 章）。可忽略性假设意味着在协变量 X 条件下，治疗分配 Z 与潜在结果相互独立：

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

这个假设保证了我们可以从观测数据中识别平均因果效应 $\tau = \mathbb{E}\{Y(1) - Y(0)\}$ 。

然而，第 17 章已经指出，可忽略性假设无法从数据本身验证。当研究者无法控制所有混淆因素时，观测到的治疗与结果之间的关联可能是虚假的。

面对这一困境，统计学提供了两条出路：

第一条路（乐观）：假设可忽略性成立，利用观测数据直接估计因果效应。这是 Part III 的核心思想。

第二条路（悲观）：完全放弃从观测数据中推断反事实，转而报告因果效应在所有可能情况下的最坏情况边界。Manski (1990) 的界是这一思路的典型代表。

第三条路（折中）：既不盲目假设可忽略性，也不完全放弃推断，而是引入有限的灵敏度参数，量化未测混杂的强度对因果效应估计的影响程度。本章正是沿着这一思路展开。

第 17 章的 E-value 量化了“要解释掉观察到的关联，未测混杂需要有多强”。本章则将这一思想系统化，基于 outcome regression、IPW 和双重稳健估计，给出平均因果效应的完整灵敏度分析框架。

2. Manski 型最坏情况界

2.1. 部分识别。在讨论灵敏度分析之前，我们先介绍一个更弱但更基本的概念——**部分识别（partial identification）**。

定义 21.1（部分识别）。如果观测数据分布与参数 θ 的多个值相容，则称参数 θ 是**部分识别**的。

这与第 ?? 章的定义形成对比：如果参数 θ 由观测数据分布唯一确定，则它是可识别的；否则，它只是部分识别的。

在可忽略性假设下， τ 是可识别的；但在没有可忽略性假设的情况下， τ 通常只是部分识别的。

2.2. 仅假设 outcomes 有界。我们仅假设 outcomes 有界：

$$\underline{y} \leq Y_i(1), Y_i(0) \leq \bar{y}.$$

对于二值结果，这等价于 $[\underline{y}, \bar{y}] = [0, 1]$ 。

在这个极弱假设下，我们可以导出 $E\{Y(1)\}$ 和 $E\{Y(0)\}$ 的最坏情况边界。考虑 $E\{Y(1)\}$ 的分解：

$$E\{Y(1)\} = E\{Y(1) \mid Z = 1\} \Pr(Z = 1) + E\{Y(1) \mid Z = 0\} \Pr(Z = 0).$$

由于 $Y(1) \in [\underline{y}, \bar{y}]$, 我们有

$$E\{Y(1) \mid Z = 0\} \in [\underline{y}, \bar{y}].$$

因此, $E\{Y(1)\}$ 的下界为

$$E\{Y \mid Z = 1\} \Pr(Z = 1) + \underline{y} \Pr(Z = 0),$$

上界为

$$E\{Y \mid Z = 1\} \Pr(Z = 1) + \bar{y} \Pr(Z = 0).$$

¹

同理, $E\{Y(0)\}$ 的下界为

$$\underline{y} \Pr(Z = 1) + E\{Y \mid Z = 0\} \Pr(Z = 0),$$

上界为

$$\bar{y} \Pr(Z = 1) + E\{Y \mid Z = 0\} \Pr(Z = 0).$$

综合可得, 平均因果效应 $\tau = E\{Y(1)\} - E\{Y(0)\}$ 的下界为

$$E\{Y \mid Z = 1\} \Pr(Z = 1) + \underline{y} \Pr(Z = 0) - \bar{y} \Pr(Z = 1) - E\{Y \mid Z = 0\} \Pr(Z = 0),$$

上界为

$$E\{Y \mid Z = 1\} \Pr(Z = 1) + \bar{y} \Pr(Z = 0) - \underline{y} \Pr(Z = 1) - E\{Y \mid Z = 0\} \Pr(Z = 0).$$

这些边界的宽度为 $\bar{y} - \underline{y}$, 比先验边界 $[\underline{y} - \bar{y}, \bar{y} - \underline{y}]$ (宽度为 $2(\bar{y} - \underline{y})$) 要窄, 但通常仍然包含 0, 因此缺乏信息量。

历史注记: Cochran (1953) 在缺失数据的调查中使用了最坏情况界思想, 但因其结果往往过于保守而放弃。Manski (1990) 将这一思想引入因果推断, Manski (2003) 进一步在计量经济学模型中系统化了这一方法。

3. 平均因果效应的灵敏度分析

上一节的 Manski 型界虽然理论优美, 但实践中过于保守。本节引入灵敏度参数, 提供一个更实用的折中方案。

3.1. 灵敏度参数. 定义两个灵敏度参数:

$$(101) \quad \varepsilon_1(X) = \frac{E\{Y(1) \mid Z = 1, X\}}{E\{Y(1) \mid Z = 0, X\}}, \quad \varepsilon_0(X) = \frac{E\{Y(0) \mid Z = 1, X\}}{E\{Y(0) \mid Z = 0, X\}}.$$

直观上, $\varepsilon_1(X)$ 衡量的是在协变量 X 条件下, 治疗组对照组的潜在结果均值之比。当 $\varepsilon_1(X) = 1$ 时, 治疗组和对照组的 $Y(1)$ 条件均值相等, 说明没有未测混杂影响 $Y(1)$ 。

为简化, 我们可以进一步假设灵敏度参数是常数 (不依赖 X): $\varepsilon_1(X) = \varepsilon_1$, $\varepsilon_0(X) = \varepsilon_0$ 。实践中, 我们需要固定这些参数或在一个预先指定的范围内变化它们。

记 $\mu_1(X) = E(Y \mid Z = 1, X)$ 和 $\mu_0(X) = E(Y \mid Z = 0, X)$ 为观测结果在治疗组和对照组下的条件均值函数。

¹推导见附录 chapter 24

3.2. 识别公式. 下面的定理给出了在已知灵敏度参数条件下, 平均因果效应的识别公式。

定理 21.2 (识别公式 I: 基于 outcome regression). 在已知 $\varepsilon_1(X)$ 和 $\varepsilon_0(X)$ 的条件下, 我们有

$$\begin{aligned} E\{Y(1) \mid Z = 0\} &= E\left\{\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 0\right\}, \\ E\{Y(0) \mid Z = 1\} &= E\{\mu_0(X)\varepsilon_0(X) \mid Z = 1\}. \end{aligned}$$

因此,

$$(102) \quad \tau = E\left[ZY + (1 - Z)\frac{\mu_1(X)}{\varepsilon_1(X)}\right] - E[Z\mu_0(X)\varepsilon_0(X) + (1 - Z)Y]$$

$$(103) \quad = E\left[Z\mu_1(X) + (1 - Z)\frac{\mu_1(X)}{\varepsilon_1(X)}\right] - E[Z\mu_0(X)\varepsilon_0(X) + (1 - Z)\mu_0(X)].$$

定理 21.2 的含义: 当 $\varepsilon_1(X) = \varepsilon_0(X) = 1$ 时, 公式 eq. (102) 简化为标准的 outcome regression 估计量。这验证了灵敏度参数是可忽略性假设的推广。²

基于 eq. (102), 我们可以构造两类估计量:

Predictive 估计量 (使用观测结果):

$$(104) \quad \hat{\tau}^{\text{pred}} = \left\{ n^{-1} \sum_{i=1}^n Z_i Y_i + n^{-1} \sum_{i=1}^n (1 - Z_i) \frac{\hat{\mu}_1(X_i)}{\varepsilon_1(X_i)} \right\}$$

$$(105) \quad - \left\{ n^{-1} \sum_{i=1}^n Z_i \hat{\mu}_0(X_i) \varepsilon_0(X_i) + n^{-1} \sum_{i=1}^n (1 - Z_i) Y_i \right\}.$$

$$(106)$$

Projective 估计量 (使用拟合值):

$$(107) \quad \hat{\tau}^{\text{proj}} = \left\{ n^{-1} \sum_{i=1}^n Z_i \hat{\mu}_1(X_i) + n^{-1} \sum_{i=1}^n (1 - Z_i) \frac{\hat{\mu}_1(X_i)}{\varepsilon_1(X_i)} \right\}$$

$$(108) \quad - \left\{ n^{-1} \sum_{i=1}^n Z_i \hat{\mu}_0(X_i) \varepsilon_0(X_i) + n^{-1} \sum_{i=1}^n (1 - Z_i) \hat{\mu}_0(X_i) \right\}.$$

$$(109)$$

术语说明: “predictive” 和 “projective” 的术语来自调查抽样文献 (Firth and Bennett, 1998; Ding and Li, 2018)。前者使用观测结果, 后者用拟合值替换。

下面的定理给出了基于逆概率加权的识别公式。

定理 21.3 (识别公式 II: 基于 IPW). 在已知 $\varepsilon_1(X)$ 和 $\varepsilon_0(X)$ 的条件下,

$$E\{Y(1)\} = E\left\{w_1(X) \frac{Z}{e(X)} Y\right\}, \quad E\{Y(0)\} = E\left\{w_0(X) \frac{1 - Z}{1 - e(X)} Y\right\},$$

其中

$$(110) \quad w_1(X) = e(X) + \frac{1 - e(X)}{\varepsilon_1(X)}, \quad w_0(X) = e(X)\varepsilon_0(X) + 1 - e(X).$$

²完整证明推导见附录 chapter 22

定理 21.3 的含义：经典 IPW 公式被两个额外的因子 $w_1(X)$ 和 $w_0(X)$ 修正，它们同时依赖于倾向得分和灵敏度参数。当 $\varepsilon_1(X) = \varepsilon_0(X) = 1$ 时， $w_1(X) = w_0(X) = 1$ ，公式退化为标准 IPW。³

基于 eq. (110)，可以构造 Horvitz-Thompson 型估计量：

$$(111) \quad \hat{\tau}^{\text{ht}} = n^{-1} \sum_{i=1}^n \frac{\{\hat{e}(X_i)\varepsilon_1(X_i) + 1 - \hat{e}(X_i)\}Z_iY_i}{\varepsilon_1(X_i)\hat{e}(X_i)}$$

$$(112) \quad - n^{-1} \sum_{i=1}^n \frac{\{\hat{e}(X_i)\varepsilon_0(X_i) + 1 - \hat{e}(X_i)\}(1 - Z_i)Y_i}{1 - \hat{e}(X_i)},$$

(113)

以及 Hajek 型估计量：

$$(114) \quad \hat{\tau}^{\text{haj}} = \frac{\sum_{i=1}^n \frac{\{\hat{e}(X_i)\varepsilon_1(X_i) + 1 - \hat{e}(X_i)\}Z_iY_i}{\varepsilon_1(X_i)\hat{e}(X_i)}}{\sum_{i=1}^n \frac{Z_i}{\hat{e}(X_i)}}$$

$$(115) \quad - \frac{\sum_{i=1}^n \frac{\{\hat{e}(X_i)\varepsilon_0(X_i) + 1 - \hat{e}(X_i)\}(1 - Z_i)Y_i}{1 - \hat{e}(X_i)}}{\sum_{i=1}^n \frac{1 - Z_i}{1 - \hat{e}(X_i)}}.$$

(116)

更重要的是，结合倾向得分和 outcome 模型，可以构造双重稳健估计量：

$$(117) \quad \hat{\tau}^{\text{dr}} = \hat{\tau}^{\text{ht}}$$

$$(118) \quad - n^{-1} \sum_{i=1}^n \{Z_i - \hat{e}(X_i)\} \left\{ \frac{\hat{\mu}_1(X_i)}{\hat{e}(X_i)\varepsilon_1(X_i)} + \frac{\hat{\mu}_0(X_i)\varepsilon_0(X_i)}{1 - \hat{e}(X_i)} \right\}.$$

(119)

即，在已知 $\varepsilon_1(X_i)$ 和 $\varepsilon_0(X_i)$ 的条件下，如果倾向得分模型或 outcome 模型中的任意一个正确设定， $\hat{\tau}^{\text{dr}}$ 就是 τ 的相合估计量。

当 $\varepsilon_1(X_i) = \varepsilon_0(X_i) = 1$ 时：上述所有估计量都退化为第 Part III 中介绍的 predictive 估计量、IPW 估计量和双重稳健估计量。

4. R 函数与实证示例

4.1. R 函数实现. 以下 R 函数可计算灵敏度分析的点估计：

```
OS_est_ta = function(z, y, x, out.family = gaussian,
                     truncps = c(0, 1), e1 = 1, e0 = 1) {
  # fitted propensity score
  pscore = glm(z ~ x, family = binomial)$fitted.values
  pscore = pmax(truncps[1], pmin(truncps[2], pscore))

  # fitted potential outcomes
  outcome1 = glm(y ~ x, weights = z,
                 family = out.family)$fitted.values
  outcome0 = glm(y ~ x, weights = (1 - z),
                 family = out.family)$fitted.values
```

³完整证明推导见附录 chapter 23

```

# outcome regression estimator
ace.reg = mean(z*y) + mean((1-z)*outcome1/e1) -
          mean(z*outcome0*e0) - mean((1-z)*y)

# IPW estimators
w1 = pscore + (1-pscore)/e1
w0 = pscore*e0 + (1-pscore)

ace.ipw0 = mean(z*y*w1/pscore) - mean((1-z)*y*w0/(1-pscore))
ace.ipw = mean(z*y*w1/pscore)/mean(z/pscore) -
          mean((1-z)*y*w0/(1-pscore))/mean((1-z)/(1-pscore))

# doubly robust estimator
aug = outcome1/pscore/e1 + outcome0*e0/(1-pscore)
ace.dr = ace.ipw0 + mean((z-pscore)*aug)

return(c(ace.reg, ace.ipw0, ace.ipw, ace.dr))
}

```

4.2. 重新分析 Example 10.3. 沿用第 ?? 章的 NHANES 数据, 研究学校午餐计划对 BMI 的影响。将灵敏度参数设为

$$\varepsilon_1(X) = \varepsilon_0(X) \in \{1/2, 1/1.7, 1/1.5, 1/1.3, 1, 1.3, 1.5, 1.7, 2\},$$

我们可以得到一系列双重稳健估计。

表 1 展示了灵敏度分析结果。

TABLE 1. 平均因果效应的灵敏度分析: 学校午餐计划对 BMI 的影响

ε	1/2	1/1.7	1/1.5	1/1.3	1	1.3	1.5	1.7	2
1/2	11.62	10.44	9.40	8.03	4.96	0.97	-1.69	-4.35	-8.34
1/1.7	9.22	8.05	7.00	5.64	2.57	-1.42	-4.08	-6.75	-10.74
1/1.5	7.63	6.45	5.41	4.05	0.97	-3.02	-5.68	-8.34	-12.33
1/1.3	6.03	4.86	3.81	2.45	-0.62	-4.61	-7.27	-9.94	-13.93
1	3.64	2.47	1.42	0.06	-3.01	-7.01	-9.67	-12.33	-16.32
1.3	1.80	0.63	-0.42	-1.78	-4.85	-8.85	-11.51	-14.17	-18.16
1.5	0.98	-0.19	-1.24	-2.60	-5.67	-9.66	-12.33	-14.99	-18.98
1.7	0.36	-0.82	-1.86	-3.23	-6.30	-10.29	-12.95	-15.61	-19.60
2	-0.35	-1.52	-2.57	-3.93	-7.00	-10.99	-13.65	-16.32	-20.31

解读: 当 $\varepsilon_1(X) > 1$ 且 $\varepsilon_0(X) > 1$ 时 (即参与者倾向于有更高的 BMI), 平均因果效应为负。然而, 当参与者倾向于有更低的 BMI (即 $\varepsilon_1(X) < 1$ 且 $\varepsilon_0(X) < 1$) 时, 结论可能对灵敏度参数相当敏感。标准误差的计算留作习题 21.3。

5. 本章小结

本章围绕平均因果效应的灵敏度分析展开, 核心思想是:

- (1) **部分识别**: 在没有可忽略性假设时, 因果参数通常只能部分识别, 即与多个值相容;
- (2) **Manski 型界**: 仅假设 outcomes 有界, 可以导出因果效应的最坏情况界, 但这些界通常过于保守;
- (3) **灵敏度参数**: 引入 $\varepsilon_1(X)$ 和 $\varepsilon_0(X)$ 量化未测混杂的强度;
- (4) **识别公式**: 在已知灵敏度参数条件下, 可以给出平均因果效应的识别公式 (基于 outcome regression、IPW 和双重稳健估计);
- (5) **估计量**: 从识别公式出发, 可以构造 predictive、projective、IPW 和双重稳健估计量;
- (6) **实践应用**: 灵敏度分析通过在一系列合理的 ε 值上计算估计量, 帮助研究者评估结论对未测混杂的稳健性。

6. 习题

习题 21.1 (18.1). 证明定理 21.2。

习题 21.2 (18.2). 证明定理 21.3。

习题 21.3 (18.3). 第 4 节只给出了点估计。报告相应的 *Bootstrap* 标准误差。

习题 21.4 (18.4). (处理组平均因果效应的灵敏度分析) 本习题将第 13 章的结果推广到允许未测混杂的情形, 估计

$$\tau_T = \mathbb{E}\{Y(1) - Y(0) \mid Z = 1\} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}\{Y(0) \mid Z = 1\}.$$

我们容易用样本矩估计 $\mathbb{E}(Y \mid Z = 1)$: $\hat{\mu}_{T1} = \sum_{i=1}^n Z_i Y_i / \sum_{i=1}^n Z_i$ 。唯一的反事实项是 $\mathbb{E}\{Y(0) \mid Z = 1\}$, 因此我们只需要灵敏度参数 $\varepsilon_0(X)$ 。在已知 $\varepsilon_0(X)$ 的条件下, 我们有以下两个识别公式。

定理 21.4 (处理组平均因果效应的识别). 在已知 $\varepsilon_0(X)$ 的条件下,

$$\mathbb{E}\{Y(0) \mid Z = 1\} = \frac{\mathbb{E}\{Z\mu_0(X)\varepsilon_0(X)\}}{e} = \frac{\mathbb{E}\left\{e(X)\varepsilon_0(X)\frac{1-Z}{1-e(X)}Y\right\}}{e},$$

其中 $e = \Pr(Z = 1)$ 。

证明定理 21.4。

注: 定理 21.4 启发我们使用 $\hat{\tau}_T^* = \hat{\mu}_{T1} - \hat{\mu}_{T0}^*$ 估计 τ_T , 其中

$$\begin{aligned}\hat{\mu}_{T0}^{\text{reg}} &= n_1^{-1} \sum_{i=1}^n Z_i \varepsilon_0(X_i) \hat{\mu}_0(X_i), \\ \hat{\mu}_{T0}^{\text{ht}} &= n_1^{-1} \sum_{i=1}^n \varepsilon_0(X_i) \hat{o}(X_i) (1 - Z_i) Y_i, \\ \hat{\mu}_{T0}^{\text{haj}} &= \frac{\sum_{i=1}^n \varepsilon_0(X_i) \hat{o}(X_i) (1 - Z_i) Y_i}{\sum_{i=1}^n \hat{o}(X_i) (1 - Z_i)},\end{aligned}$$

其中 $\hat{o}(X_i) = \hat{e}(X_i) / \{1 - \hat{e}(X_i)\}$ 是给定协变量条件下治疗的条件比数比估计量。此外, 我们可以构造 τ_T 的双重稳健估计量

$$\hat{\tau}_T^{\text{dr}} = \hat{\mu}_{T1} - \hat{\mu}_{T0}^{\text{dr}},$$

其中

$$\hat{\mu}_{T0}^{\text{dr}} = \hat{\mu}_{T0}^{\text{ht}} - n_1^{-1} \sum_{i=1}^n \varepsilon_0(X_i) \frac{\hat{e}(X_i) - Z_i}{1 - \hat{e}(X_i)} \hat{\mu}_0(X_i).$$

详见 *Lu and Ding (2023)*。

7. 推荐阅读

- ?：Manski 首次将界的思想引入因果推断。
- ?：系统综述了计量经济学中的部分识别方法。
- ?：E-value 的理论基础，也是本章灵敏度分析的起点。
- ?：提供了本章方法的更技术性的细节。
- ? 和 ?：经典但更复杂的灵敏度分析文献。

附录：定理 21.2 的证明

1. 背景与目标

定理 21.2 给出了在已知灵敏度参数 $\varepsilon_1(X)$ 和 $\varepsilon_0(X)$ 条件下，平均因果效应的识别公式。本节给出完整证明。

2. 记号定义

记 $\mu_1(X) = E(Y \mid Z = 1, X)$ 和 $\mu_0(X) = E(Y \mid Z = 0, X)$ 。灵敏度参数定义为：

$$\varepsilon_1(X) = \frac{E\{Y(1) \mid Z = 1, X\}}{E\{Y(1) \mid Z = 0, X\}} = \frac{\mu_1(X)}{E\{Y(1) \mid Z = 0, X\}},$$

因此

$$(120) \quad E\{Y(1) \mid Z = 0, X\} = \frac{\mu_1(X)}{\varepsilon_1(X)}.$$

类似地，

$$(121) \quad E\{Y(0) \mid Z = 1, X\} = \mu_0(X)\varepsilon_0(X).$$

3. 详细推导

第一步：证明 $E\{Y(1) \mid Z = 0\} = E\{\mu_1(X)/\varepsilon_1(X) \mid Z = 0\}$ 。

由全概率公式：

$$E\{Y(1) \mid Z = 0\} = E[E\{Y(1) \mid Z = 0, X\} \mid Z = 0].$$

代入 eq. (120)：

$$E\{Y(1) \mid Z = 0\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 0\right].$$

第二步：证明 $E\{Y(0) \mid Z = 1\} = E\{\mu_0(X)\varepsilon_0(X) \mid Z = 1\}$ 。

类似地：

$$E\{Y(0) \mid Z = 1\} = E[E\{Y(0) \mid Z = 1, X\} \mid Z = 1].$$

代入 eq. (121)：

$$E\{Y(0) \mid Z = 1\} = E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

第三步：代入 τ 的分解。

回忆

$$\tau = E\{Y(1)\} - E\{Y(0)\} = E\{Y \mid Z = 1\} - E\{Y(0) \mid Z = 1\}.$$

由第一步和第二步：

$$\tau = E\{Y \mid Z = 1\} - E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

利用随机化定义 $Y = ZY(1) + (1 - Z)Y(0)$ ，展开 $E\{Y \mid Z = 1\}$ ：

$$E\{Y \mid Z = 1\} = E\{Y(1) \mid Z = 1\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 1\right].$$

因此

$$\tau = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 1\right] - E[\mu_0(X)\varepsilon_0(X) \mid Z = 1].$$

经过代数运算，可以化为 eq. (102) 和 eq. (103) 的形式。证毕。

附录：定理 21.3 的证明

1. 背景与目标

定理 21.3 给出了基于 IPW 的识别公式。本节给出完整证明。

2. 识别公式推导

由定理 21.2 的证明，我们有

$$E\{Y(1) \mid Z = 0\} = E\left\{\frac{\mu_1(X)}{\varepsilon_1(X)} \mid Z = 0\right\}.$$

现在利用 IPW 恒等式。将上式重新整理为：

$$E\{Y(1)\} = E\{Y(1) \mid Z = 1\} \Pr(Z = 1) + E\{Y(1) \mid Z = 0\} \Pr(Z = 0).$$

代入 $E\{Y(1) \mid Z = 1\} = \mu_1(X)/\varepsilon_1(X)$ 和 $E\{Y(1) \mid Z = 0\} = \mu_1(X)/\varepsilon_1(X)$ ，得：

$$E\{Y(1)\} = E\left[\frac{\mu_1(X)}{\varepsilon_1(X)}\right].$$

利用倾向得分 $e(X) = \Pr(Z = 1 \mid X)$ ，我们可以将上式写成 IPW 形式：

$$E\{Y(1)\} = E\left\{\frac{ZY}{e(X)}\right\} = E\left\{w_1(X) \frac{ZY}{e(X)}\right\},$$

其中 $w_1(X) = e(X) + (1 - e(X))/\varepsilon_1(X)$ 。

类似地，可以导出 $E\{Y(0)\}$ 的公式。证毕。

附录：Manski 型边界的推导

1. 背景

本节推导在仅假设 outcomes 有界 $[\underline{y}, \bar{y}]$ 时, $E\{Y(1)\}$ 和 $E\{Y(0)\}$ 的边界。

2. 记号定义

记 $p = \Pr(Z = 1)$, 则 $\Pr(Z = 0) = 1 - p$ 。同时记 $\mu_1 = E(Y \mid Z = 1)$ 和 $\mu_0 = E(Y \mid Z = 0)$, 这是可以从数据中直接估计的量。

3. $E\{Y(1)\}$ 的边界

由全概率公式:

$$E\{Y(1)\} = \mu_1 \cdot p + E\{Y(1) \mid Z = 0\} \cdot (1 - p).$$

由于 $Y(1) \in [\underline{y}, \bar{y}]$,

$$\underline{y} \leq E\{Y(1) \mid Z = 0\} \leq \bar{y}.$$

因此

$$\mu_1 \cdot p + \underline{y}(1 - p) \leq E\{Y(1)\} \leq \mu_1 \cdot p + \bar{y}(1 - p).$$

4. $E\{Y(0)\}$ 的边界

类似地:

$$E\{Y(0)\} = E\{Y(0) \mid Z = 1\} \cdot p + \mu_0 \cdot (1 - p),$$

其中

$$\underline{y} \leq E\{Y(0) \mid Z = 1\} \leq \bar{y}.$$

因此

$$\underline{y} \cdot p + \mu_0(1 - p) \leq E\{Y(0)\} \leq \bar{y} \cdot p + \mu_0(1 - p).$$

5. τ 的边界

由 $\tau = E\{Y(1)\} - E\{Y(0)\}$, 代入以上边界可得:

$$\underline{\tau} = \mu_1 p + \underline{y}(1 - p) - \bar{y} p - \mu_0(1 - p),$$

$$\bar{\tau} = \mu_1 p + \bar{y}(1 - p) - \underline{y} p - \mu_0(1 - p).$$

边界的宽度为 $\bar{y} - \underline{y}$ 。

Rosenbaum 风格 p 值：匹配观测研究中的未测量混杂

1. 引言：从理想实验到现实挑战

在前面的章节中，我们讨论了匹配 (matching) 在观测研究中的应用。匹配的核心思想是：通过构造相似的处理组和对照组单位，来近似随机化实验的条件。正如我们在第 11 章看到的，当可忽略性假设成立时，匹配可以有效地消除选择偏差。

然而，现实的观测研究往往面临一个根本性的困难：我们永远无法保证所有混淆变量都被观测到并纳入匹配。遗漏变量偏倚 (omitted variable bias) 是一个永恒的威胁——那些我们没有观测到的协变量，可能同时影响处理分配和结果，从而破坏因果推断的有效性。

Paul Rosenbaum 在 1987 年的开创性工作中提出了一个优雅的解决方案：不是试图证明未测量混杂不存在，而是系统地量化未测量混杂需要多大才能动摇我们的结论。**灵敏度分析** (sensitivity analysis) 的核心思想是：当我们允许未测量混杂存在时，因果结论的稳健性如何？

本章专注于匹配观测研究中的 Rosenbaum 风格 p 值计算方法。我们将看到，即使在未知混杂存在的情况下，Rosenbaum 的灵敏度分析框架也能帮我们回答：这个结论在多大的未测量混杂强度下仍然是可信的？

2. 匹配观测研究的灵敏度分析模型

2.1. 配对结构的记号. 考虑一个匹配对照研究，我们构造了 n 个配对。每个配对 i 包含两个单位： $j = 1$ 表示处理组， $j = 0$ 表示对照组。令 $(i, 1)$ 为第 i 对的处理单位， $(i, 0)$ 为对照单位。

每个单位 (i, j) 都有两个潜在结果： $Y_{ij}(1)$ 和 $Y_{ij}(0)$ 。在 sharp null hypothesis 下：

$$H_{0F} : Y_{ij}(1) = Y_{ij}(0) \quad \text{for all } i, j.$$

在理想情况下（即没有未测量混杂），每个配对中的处理和对照单位是同质的，处理分配与潜在结果独立。此时，如果我们进行随机化实验，每对中处理组接受治疗的概率应为 $\pi_{i1} = 1/2$ 。

2.2. Rosenbaum 灵敏度分析模型. 然而，在观测研究中，由于未测量混杂的存在，处理分配概率可能在配对之间不相等。Rosenbaum (1987b) 提出了一个关键的灵敏度分析模型。

假设 25.1 (Rosenbaum 灵敏度分析模型). 对于第 i 对中的两个单位，处理分配的 odds 比被一个有界常数 $\Gamma \geq 1$ 控制：

$$\frac{\pi_{i1}/\pi_{i0}}{(1 - \pi_{i1})/(1 - \pi_{i0})} \leq \Gamma, \quad i = 1, \dots, n,$$

其中 $\pi_{i1} = \Pr\{Z_{i1} = 1 \mid \text{pair } i\}$ 是配对 i 中处理组接受处理的概率。

如何理解 Γ ？ 这个参数衡量了未测量混杂导致的处理分配不均衡程度：

- 当 $\Gamma = 1$ 时，假设 25.1 意味着 $\pi_{i1} = \pi_{i0} = 1/2$ ，即每对中处理和对照的概率相等。这正是标准匹配实验 (MPE) 的情形。

- 当 $\Gamma > 1$ 时，处理分配概率可能在配对之间变化，变化幅度由 Γ 控制。
- Γ 越大，未测量混杂的影响越强，我们的因果结论就越脆弱。

为什么这个模型是“自然的”？ 假设 25.1 只假设处理分配的 odds 比有界，而没有对潜在的未测量混杂做任何具体假设。这种半参数化的设定使得灵敏度分析具有普遍的适用性——无论未测量混杂的具体形式如何，只要其导致的 odds 比不超过 Γ ，我们的 p 值计算就是有效的。

3. 最坏情况 p 值

3.1. 检验统计量. 在 sharp null hypothesis H_{0F} 下，我们观察到的是处理效应为零的“无效”数据。利用这个性质，我们可以构造 Fisher randomization test 风格的检验统计量。

令 q_i 为第 i 对的某种处理效应度量，常见的 choices 包括：

- (1) **Sign statistic:** $q_i = Z_{i1} - Z_{i0}$ (即配对中处理 vs 对照的指示函数)
- (2) **Pair t statistic:** $q_i = Y_{i1} - Y_{i0}$ (观测到的处理组与对照组结果差)
- (3) **Wilcoxon signed-rank statistic:** 基于 $|Y_{i1} - Y_{i0}|$ 的符号秩统计量

检验统计量定义为：

$$T = \sum_{i=1}^n S_i q_i,$$

其中 $S_i \in \{0, 1\}$ 是配对 i 的处理指示 ($S_i = 1$ 表示该对参与检验)， q_i 是配对 i 的贡献权重。

在标准的完全随机化检验中， S_i 在零假设下是已知的 (或可精确计算)。但在灵敏度分析框架下， S_i 的分布受到 假设 25.1 的约束。

3.2. 最坏情况分布.

定理 25.1 (最坏情况 p 值). 在 假设 25.1 下，零假设 H_{0F} 成立时，配对 i 的处理指示 S_i 服从最坏情况的 *Bernoulli* 分布：

$$S_i \sim \text{Bernoulli}\left(\frac{\Gamma}{1 + \Gamma}\right),$$

且各配对的 S_i 之间相互独立。

为什么是最坏情况？ 给定 odds ratio 上界 Γ ， S_i 的概率可以在 $[\pi_{\min}, \pi_{\max}]$ 之间变化，其中

$$\pi_{\max} = \frac{\Gamma}{1 + \Gamma}, \quad \pi_{\min} = \frac{1}{1 + \Gamma}.$$

为了得到最大的 p 值 (即最不利于拒绝零假设的情况)，我们选择 S_i 的期望为 $\pi_{\max}$ 。这对应于处理效应“看起来最小”的那种分布。

定义 25.1 的证明表明，在所有满足 假设 25.1 的分布中，定义 25.1 给出了最保守的 p 值。¹

¹定理 定义 25.1 的完整证明见附录 section 20。

3.3. p 值的计算. 基于定义 25.1, 我们可以计算最坏情况 p 值。对于给定的观测检验统计量 T^{obs} , 双边 p 值为:

$$p_{\Gamma} = \Pr_{\Gamma} (|T - T^{\text{obs}}| \geq |T^{\text{obs}}|),$$

其中 T 服从定义 25.1 下 S_i 的混合分布。

当 $q_i \geq 0$ 时, 我们可以简化计算。定义

$$T = \sum_{i=1}^n S_i q_i, \quad S_i \sim \text{Bernoulli} \left(\frac{\Gamma}{1 + \Gamma} \right).$$

由于 q_i 是固定的 (由观测数据决定), T 的分布是 n 个独立 Bernoulli 随机变量的加权求和。

4. 实例分析

4.1. LaLonde 数据重访. LaLonde (1986) 的数据集是因果推断领域最著名的实例之一。该数据集包含一个工作培训项目 (National Supported Work Demonstration) 的参与者及其结果。

我们考虑使用检验统计量:

$$T = \sum_{i=1}^n S_i |\hat{\tau}_i|,$$

其中 $\hat{\tau}_i$ 是第 i 对的处理效应估计。

灵敏度分析结果:

- 在理想 MPE ($\Gamma = 1$) 下, 模拟得到的 p 值为 0.002, 强烈拒绝零假设。
- 当 $\Gamma = 1.1$ 时 (仅允许 10% 的处理分配 odds 偏离), 最坏情况 p 值上升到 0.011。
- 当 $\Gamma = 1.3$ 时, 最坏情况 p 值超过 0.05, 在常规显著性水平下无法拒绝零假设。

更精确地说, $\Gamma = 1.233$ 是临界值: 当未测量混杂导致的 odds 比不超过 1.233 时, 我们仍能在 0.05 水平下拒绝零假设; 超过这个值, 结论就不再稳健。

例 25.1 (LaLonde 数据的灵敏度曲线). 图 ?? 展示了 p 值随 Γ 变化的灵敏度曲线。曲线的陡峭程度告诉我们结论对未测量混杂的敏感程度——曲线越平缓, 结论越稳健。

4.2. Rosenbaum 包中的其他实例. Rosenbaum 的 R 包 (如 `sensitivity2x2` 和 `sensitivitymv`) 提供了便捷的灵敏度分析工具。我们简要介绍两个应用场景。

实例 1: 两分类处理的配对研究. 对于 2×2 配对数据, 可以计算在给定 Γ 下拒绝零假设的最小处理组比例。

实例 2: 多分类处理的匹配研究. 对于多水平处理 (如剂量梯度), 灵敏度分析可以量化每个处理水平相对于对照组的效应稳定性。

这些包的共同特点是: 研究者可以系统地探索因果结论在不同未测量混杂强度下的稳健性, 而不是简单地说“结论成立”或“结论不成立”。

5. 练习

练习 25.1. *Rosenbaum* 灵敏度模型的基本性质 证明: 当 $\Gamma \rightarrow \infty$ 时, 假设 25.1 中的约束变得无效, 此时 S_i 的最坏情况分布趋近于 $\text{Bernoulli}(1/2)$ 。这对应着什么实际含义?

练习 25.2. 最坏情况 p 值的单调性 设 T^{obs} 为观测到的检验统计量。证明: 最坏情况 p 值 p_{Γ} 是 Γ 的单调递增函数。解释这在直觉上意味着什么。

练习 25.3. *Sign statistic* 的灵敏度分析 对于 *sign statistic* $q_i = 1$ (所有配对权重相等), 推导 T 在定义 25.1 下的分布, 并给出 p 值的显式计算公式。

练习 25.4. *LaLonde* 数据的计算 使用 *LaLonde* 数据集, 计算在不同 Γ 值(1, 1.1, 1.2, 1.3, 1.5) 下的最坏情况 p 值, 并绘制灵敏度曲线。

6. 本章小结

本章介绍了 Rosenbaum 风格的灵敏度分析框架, 这是处理匹配观测研究中未测量混杂的标准方法。

核心要点:

- (1) 假设 25.1 通过 odds ratio 上界 $\Gamma \geq 1$ 量化了未测量混杂的强度。
- (2) $\Gamma = 1$ 对应于标准匹配实验; 当 $\Gamma > 1$ 时, 处理分配概率在配对之间可能不相等。
- (3) 定义 25.1 给出了零假设下 S_i 的最坏情况分布, 这使得我们可以计算保守的 p 值。
- (4) 灵敏度分析不试图“证明”因果效应存在, 而是量化结论在何种未测量混杂强度下仍然成立。

历史注记: Rosenbaum (1987b) 的工作是观测研究灵敏度分析的开创性文献。此后, 这一框架被推广到更复杂的研究设计, 包括分层分析、倾向得分匹配等。Rosenbaum 的专著 (2002, 2010) 系统地发展了这一理论。

与其他章节的联系: 本章的方法建立在第 11 章的匹配理论基础之上, 并借鉴了第 3 章 Fisher randomization test 的思想。灵敏度分析的思想也与第 12 章双重稳健估计的“稳健性”概念相呼应——两者都关注因果结论在模型假设偏离时的稳健性。

平行世界框架

1. 引言：跨越两个世界的桥梁

“If we could intervene on a unit and set its treatment, then we would know its potential outcome under that treatment. But what if the treatment is deterministic for some units? Can we still conceive their counterfactual outcomes?” — [, adapted from King and Zeng, 2006]

在因果推断中，我们始终面对一个根本性的哲学困难：对于每个单元，我们只能观测到 ** 一个 ** 世界的结果，而必须推断 ** 另一个 ** 世界的结果。Rubin 的潜在结果框架 (Rubin, 1974, 1975) 用数学语言精确化了这个直观的“平行世界”隐喻。

在第 11 章讨论倾向得分时，我们遇到了一个关键的技术性假设——**重叠假设 (overlap assumption)**：

$$(20.1) \quad 0 < e(X) < 1.$$

这个假设保证每个单元都有正概率接受两种治疗，从而允许我们比较同一单元在不同治疗下的潜在结果。然而，当 $e(X) = 0$ 或 $e(X) = 1$ 时，事情变得微妙起来：如果一个单元注定接受治疗，那么谈论它在“如果没接受治疗”情况下的潜在结果还有意义吗？

本章将深入探讨这一哲学困难，并介绍一个优雅的解决方案——**回归断点设计 (Regression Discontinuity, RD)**。

2. 重叠假设的隐含要求

在第 11 章我们看到，倾向得分方法的有效性依赖于重叠假设 eq. (20.1)。然而，D’Amour 等人 (2021) 指出了令人不安的矛盾：

- **更多协变量**使可忽略性假设 (ignorability) 更可信 (忽略第 16 章讨论的 M-bias)；
- **更多协变量**使重叠假设更不可信，因为治疗分配变得更加可预测。

这个张力在高清协变量场景中尤为突出。严格重叠假设要求：

假设 26.1 (严格重叠). 存在某个 $\eta \in (0, 1/2)$ 使得

$$\eta \leq e(X) \leq 1 - \eta.$$

D’Amour 等人 (2021) 证明了严格重叠假设在协变量维度 p 很大时具有极强的隐含条件。¹

定理 26.1 (D’Amour et al., 2021). 在假设 26.1 下，设 $e = \Pr(Z = 1)$ 为治疗组比例， λ_1 和 λ_0 分别为 $X|Z = 1$ 和 $X|Z = 0$ 条件下协变量矩阵的最大特征值。则

$$(20.2) \quad \frac{1}{p} \sum_{k=1}^p |\mathbb{E}(X_k | Z = 1) - \mathbb{E}(X_k | Z = 0)| \leq p^{-1/2} C^{1/2} \{e\lambda_1^{1/2} + (1 - e)\lambda_0^{1/2}\},$$

¹推导见附录 section 5.1

其中 $C = \frac{(e - \eta)(1 - e - \eta)}{e^2(1 - e)^2\eta(1 - \eta)}$ 是仅依赖于 (e, η) 的正常数。

eq. (20.2) 的含义是深刻的：严格重叠假设要求治疗组和对照组在所有协变量维度上的均值差异都趋近于零。在高维情况下，这是一个极强的要求——它几乎等同于要求两组在每一维上都达到近乎完美的平衡。

3. 当重叠失败时：修整与结果建模

当假设 26.1 不成立时，一个常见的策略是基于估计的倾向得分进行**修整 (trimming)** (Crump 等, 2009; Yang and Ding, 2018b)。修整删除了重叠区域外的单元，从而改变了目标总体和估计量。

然而，D'Amour 等人 (2021) 的上述结果暗示了一个令人担忧的事实：在高维场景中，我们需要修整更大比例的单元才能达到满意的重叠。这意味着修整可能显著改变我们的研究问题。

另一个思路是转向**结果建模**。如果在高维协变量下，结果均值仅依赖于 X 的某个低维函数 $r(X)$ ：

$$(20.3) \quad \mathbb{E}\{Y(z) \mid X\} = f_z(r(X)), \quad (z = 0, 1),$$

那么控制 $r(X)$ 就足够了。由于维度约化， $r(X)$ 上的严格重叠条件可能远弱于 X 上的。²

这个方向在概念上直截了当，但相应的理论和方法仍有待发展。

4. 无重叠情形下的因果推断：回归断点设计

让我们从最简单的情况开始——单位协变量 X 。一种极端的治疗分配机制是确定性的：

$$(20.4) \quad Z = \mathbb{I}(X \geq x_0),$$

其中 x_0 是预设的阈值。

这种分配的一个有趣后果是：可忽略性假设自动成立——

$$(20.5) \quad Z \perp \{Y(1), Y(0)\} \mid X,$$

因为 Z 是 X 的确定性函数，而常数与任何随机变量独立。然而，重叠假设必然被违反：

$$(20.6) \quad e(x) = \Pr(Z = 1 \mid X = x) = \mathbb{I}(x \geq x_0) = \begin{cases} 1 & \text{若 } x \geq x_0, \\ 0 & \text{若 } x < x_0. \end{cases}$$

这正是**回归断点设计 (RD)** 的核心思想。

²详细理论见附录 section 5.2

4.1. RD 的经典例子. 例 20.1 (学业成就证书效应) Thistlethwaite 和 Campbell (1960) 首次提出了回归断点分析的想法。他们的动机问题是：学生获得“优异证书”对其后来职业规划的影响。证书是否获得取决于学生的“奖学金资格考试”成绩是否超过某个阈值。

例 20.2 (HIV 治疗时机) Bor 等 (2014) 利用回归断点研究 HIV 患者何时开始抗逆转录病毒治疗对死亡率的影响。治疗取决于患者的 CD4 计数是否低于 200 cells/ μL 。

例 20.3 (最低饮酒年龄) Carpenter 和 Dobkin (2009) 研究了酒精消费对死亡率的影响，利用法定最低饮酒年龄作为酒精消费的断点。

4.2. RD 的数学表述. 决定治疗的变量 X 称为**运行变量 (running variable)**。直观上，回归断点可以识别断点 x_0 处的局部平均因果效应：

$$(20.7) \quad \tau(x_0) = \mathbb{E}\{Y(1) - Y(0) \mid X = x_0\}.$$

定理 26.2 (RD 识别定理). 假设治疗由 $Z = \mathbb{I}(X \geq x_0)$ 确定，其中 x_0 是预设阈值。假设 $\mathbb{E}\{Y(1) \mid X = x\}$ 在 x_0 处右连续， $\mathbb{E}\{Y(0) \mid X = x\}$ 在 x_0 处左连续。则在 $X = x_0$ 处的局部平均因果效应由下式识别：

$$(20.8) \quad \tau(x_0) = \lim_{\varepsilon \rightarrow 0^+} \mathbb{E}(Y \mid Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0^+} \mathbb{E}(Y \mid Z = 0, X = x_0 - \varepsilon).$$

由于 eq. (20.8) 的右端仅涉及可观测量，参数 $\tau(x_0)$ 是非参数可识别的。³

4.3. 边界附近的回归分析. 假设 $\mathbb{E}(Y \mid Z = 1, X = x) = \gamma_1 + \beta_1 x$ 和 $\mathbb{E}(Y \mid Z = 0, X = x) = \gamma_0 + \beta_0 x$ 关于 x 线性。则我们可以估计 x_0 处的平均因果效应为

$$(20.9) \quad \hat{\tau}(x_0) = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)x_0.$$

数值上， $\hat{\tau}(x_0)$ 与 OLS 回归

$$(20.10) \quad Y_i \sim \{1, Z_i, X_i - x_0, Z_i(X_i - x_0)\}$$

中 Z_i 的系数相同。⁴

然而，这种方法对线性模型假设的违背可能敏感。理论建议仅使用断点附近的局部观测值进行回归。rdrobust 包实现了各种“局部”带宽选择，这本质上是一种敏感性分析。

4.4. RD 的问题. RD 分析可能出什么问题？技术上，关键挑战在于指定断点附近的邻域。

此外，定义 26.2 的连续性条件可能在实践中被违背。例如，如果死亡率在 21 岁有跳跃，我们可能无法将 ?? 中的死亡跳跃归因于最低饮酒年龄的变化。

McCrary (2008) 提出了一个间接的有效性检验：检查运行变量在断点处的密度。运行变量密度在断点处的不连续性可能表明某些单元能够完美地操控其治疗状态。

5. 本章小结

本章探讨了当重叠假设不成立时的因果推断策略：

- (1) **重叠假设的困难**：高维协变量下，严格重叠是一个极强的要求，几乎要求治疗组和对照组在所有维度上平衡。
- (2) **修整与结果建模**：当重叠有限时，修整可以恢复重叠但会改变目标总体；结果建模提供了一种在维度约化下可能更温和的重叠条件。

³证明见附录 section 5.3

⁴代数推导见附录 section 5.4

(3) **回归断点设计**: 当治疗分配完全由运行变量决定时, RD 提供了一种不依赖重叠假设的识别策略, 识别断点处的局部平均因果效应。

RD 设计的核心洞察在于: 当确定性治疗分配使得某些单元的潜在结果在物理上无法构想时 (“如果接受治疗”的单元永远不可能被分配到对照组), 我们可以将注意力转向边界处的局部效应——那里的单元恰好在阈值两侧, 其潜在结果是可构想的。

附录: 公式推导

5.1. 定理 定义 26.1 的证明. 为完整性起见, 我们给出 定义 26.1 的简要推导。⁵

设 $\Sigma_1 = \text{Cov}(X | Z = 1)$ 和 $\Sigma_0 = \text{Cov}(X | Z = 0)$ 。根据条件协方差的分解,

$$(20.11) \quad \Sigma = \mathbb{E}\{\text{Cov}(X | Z)\} + \text{Cov}\{\mathbb{E}(X | Z)\}.$$

在严格重叠假设下, Σ_1 和 Σ_0 的特征值以 C 为界。利用 Cauchy-Schwarz 不等式和对偶范数, 我们得到

$$(20.12) \quad \frac{1}{p} \sum_{k=1}^p |\mathbb{E}(X_k | Z = 1) - \mathbb{E}(X_k | Z = 0)| \leq \frac{1}{\sqrt{p}} \|\Sigma^{1/2}\| \cdot \|d\|,$$

其中 $d = \mathbb{E}(X | Z = 1) - \mathbb{E}(X | Z = 0)$ 是均值差异向量, $\|\cdot\|$ 是欧几里得范数。结合 eq. (20.11) 和严格重叠给出的特征值界, 我们得到 eq. (20.2)。□

5.2. 结果建模的定理. 在 eq. (20.3) 下, 均衡因果效应 $\tau = \mathbb{E}\{Y(1) - Y(0)\}$ 可由下式识别:

$$(20.13) \quad \tau = \mathbb{E}\{\mathbb{E}(Y | Z = 1, r(X)) - \mathbb{E}(Y | Z = 0, r(X))\}$$

或等价地,

$$(20.14) \quad \tau = \mathbb{E}\left\{\frac{ZY}{e(r(X))}\right\} - \mathbb{E}\left\{\frac{(1-Z)Y}{1 - e(r(X))}\right\},$$

其中 $e(r(X)) = \Pr\{Z = 1 | r(X)\}$ 。⁶

5.3. 定理 定义 26.2 的证明. 由右连续性,

$$(20.15) \quad \mathbb{E}\{Y(1) | X = x_0\} = \lim_{\varepsilon \rightarrow 0^+} \mathbb{E}\{Y(1) | X = x_0 + \varepsilon\}.$$

由 Z 的定义, 当 $X = x_0 + \varepsilon$ 时, $Z = 1$, 因此

$$(20.16) \quad \mathbb{E}\{Y(1) | X = x_0 + \varepsilon\} = \mathbb{E}(Y | Z = 1, X = x_0 + \varepsilon).$$

⁵详细内容见 D'Amour et al. (2021, Corollary 1)

⁶证明思路: 利用 $r(X)$ 上的条件期望和潜在结果的定义, 直接展开即可。

左连续性给出 $\mathbb{E}\{Y(0) \mid X = x_0\}$ 的类似表达式。取差即得 eq. (20.8)。 $\square$

5.4. OLS 等价性的推导. 设 $R_i = \max(X_i - x_0, 0)$ 和 $L_i = \min(X_i - x_0, 0)$ 。则

$$Z_i(X_i - x_0) = Z_i R_i - (1 - Z_i) L_i = R_i - L_i - (1 - Z_i) R_i + (1 - Z_i) L_i. \quad (20.17)$$

在模型 $Y_i \sim \{1, Z_i, X_i - x_0, Z_i(X_i - x_0)\}$ 中, Z_i 的系数为

$$\hat{\tau} = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)x_0. \quad (20.18)$$

这与 eq. (20.9) 相同。类似地, 对模型 $Y_i \sim \{1, Z_i, R_i, L_i\}$ 展开并比较系数可得相同结果。 $\square$

工具变量：从不完美实验到因果效应

1. 引言：无法假设无混淆时，我们还能做什么？

在前几章中，我们学习了如何通过随机实验和观测性研究（在可忽略性假设下）来估计因果效应。第 3 章的完全随机实验（CRE）通过随机分配治疗消除了未测混淆。第 10 章讨论了当治疗分配机制已知（或可估计）时，如何在观测性研究中识别因果效应。

但现实往往不这么友好。想象以下场景：

- (1) **Jobs 项目**：研究者想评估 Jobs 项目对收入的影响，但只有部分被分配到 treatment 的人实际参加了项目。
- (2) **医学临床试验**：患者被随机分配到治疗组或对照组，但由于副作用，部分患者没有遵从分配的治疗。
- (3) **Mendelian Randomization**：遗传变异（作为工具变量）随机分配在人群中，但遗传变异对疾病的影响可能通过多条途径实现。

在这些场景中，治疗分配 Z 与实际接受的治疗 D 不一致。更根本的问题是： D 与潜在结果之间可能存在**未测混淆**（unmeasured confounding）。传统的回归方法无法给出因果效应的无偏估计。

那么，当无法假设可忽略性时，我们还能识别因果效应吗？

工具变量（Instrumental Variable, IV）方法提供了一个出路。¹ 核心思想是：找到一个**外生**（exogenous）的变量 Z ，它影响治疗 D ，但不影响结局 Y （除了通过 D 的途径）。虽然我们无法直接观察 D 的因果效应，但可以通过 Z 来**间接推断**。

本章采用**鼓励设计**（encouragement design）视角来介绍 IV 方法。正如？建议的，观测性研究的设计者应该始终问自己：“如果我无法做随机实验，能否找到一个自然的随机化来源？”鼓励设计正是这种思想的体现。

2. 鼓励设计与非依从性

考虑一个实验，其中研究者**鼓励**（encourage）部分单元接受治疗，但不是所有被鼓励的单元都会实际接受治疗。设

- $Z \in \{0, 1\}$ ：治疗分配（ $Z = 1$ 表示被分配到治疗组）
- $D \in \{0, 1, 2, \dots\}$ ：实际接受的治疗（或剂量）
- Y ：结局

与标准随机实验不同，这里存在**非依从性**（noncompliance）：被分配到治疗组的人可能没有实际接受治疗，被分配到对照组的人可能通过其他途径接受了治疗。

关键假设：随机分配（Assumption 21.1）²

假设 27.1（随机分配）。治疗分配 Z 与所有潜在结果独立：

$$Z \perp\!\!\!\perp \{D(1), D(0), Y(1), Y(0)\},$$

¹问：为什么工具变量能解决无法假设可忽略性的问题？见附录 ??。

²问：为什么随机分配是关键假设？它如何帮助我们？见附录 ??。

其中 $D(z)$ 是在分配 z 下的潜在治疗接受情况, $Y(z)$ 是相应的潜在结局。

在随机化实验中, 这个假设天然成立。假设 27.1 保证了治疗分配 Z 本身不影响结局 (除了通过实际接受的治疗 D 间接影响之外)。

意向性治疗分析 (Intention-to-Treat, ITT): 报告 $\hat{\tau}_Y$ 及其标准误差的过程称为 ITT 分析。³ 在假设 27.1 下, ITT 估计量

$$\hat{\tau}_Y = \bar{Y}_1 - \bar{Y}_0$$

一致地估计了治疗分配对结局的平均因果效应。但这不是我们真正关心的——我们想知道的是**实际接受的治疗**对结局的因果效应。

这就是 IV 方法要解决的问题。

3. 潜在依从性类型与因果效应分解

3.1. 四类依从者. 由于我们无法同时观察到 $D_i(1)$ 和 $D_i(0)$, 每个个体的依从性类型是**潜在的 (latent)**。记潜在依从性类型为 $U_i = (D_i(1), D_i(0))$, 可以有四种取值:

- (1) **Always taker (总是接受者):** $U_i = a$, $D_i(1) = D_i(0) = 1$ 。无论是否被鼓励, 都接受治疗。
- (2) **Complier (依从者):** $U_i = c$, $D_i(1) = 1, D_i(0) = 0$ 。只有在被鼓励时才会接受治疗。
- (3) **Defier (违背者):** $U_i = d$, $D_i(1) = 0, D_i(0) = 1$ 。被鼓励时反而拒绝治疗 (对鼓励反向反应)。
- (4) **Never taker (从不接受者):** $U_i = n$, $D_i(1) = D_i(0) = 0$ 。无论是否被鼓励, 都不接受治疗。

注意: 由于我们无法同时观察 $D(1)$ 和 $D(0)$, U_i 对每个个体来说是不可观测的潜在类型。我们只能通过群体的统计性质来推断各类人群的比例。

3.2. ACE 的四类分解. 基于上述分类, 总体平均因果效应可以分解为四类的加权平均:⁴

$$\begin{aligned} (122) \quad \tau_Y &= \mathbb{E}\{Y(1) - Y(0)\} \\ (123) \quad &= \mathbb{E}\{Y(1) - Y(0) \mid U = a\} \Pr(U = a) \\ (124) \quad &+ \mathbb{E}\{Y(1) - Y(0) \mid U = c\} \Pr(U = c) \\ (125) \quad &+ \mathbb{E}\{Y(1) - Y(0) \mid U = d\} \Pr(U = d) \\ (126) \quad &+ \mathbb{E}\{Y(1) - Y(0) \mid U = n\} \Pr(U = n). \end{aligned}$$

eq. (122) 清晰地表明了问题所在: 我们观测到的是四类人的混合效应, 而我们通常只想知道**某一类人** (特别是 complier) 的因果效应。

4. 三个核心假设: 单调性、排除限制与随机性

要识别 complier 的因果效应 (CACE), 我们需要三个关键假设。

³问: ITT 分析估计的是什么效应? 见附录 ??。

⁴推导见附录 ??

4.1. 假设一：单调性 (Monotonicity).

假设 27.2 (单调性). 没有 defier: $\Pr(U_i = d) = 0$, 或者等价地, $D_i(1) \geq D_i(0)$ 对所有 i 成立。

动机: Defier 对鼓励反向反应——被鼓励反而拒绝治疗。这类人在现实中极为罕见, 而且即使存在, 我们也无法用数据识别他们的效应。**单调性假设排除了 defier 的存在。**

可检验的含义: 在随机化下, 单调性等价于

$$(127) \quad \Pr(D = 1 \mid Z = 1) \geq \Pr(D = 1 \mid Z = 0),$$

即治疗接受率在被鼓励组不低于对照组。⁵ 这提供了一个检验方向——如果数据不满足这个不等式, 单调性假设就不成立。

但注意, eq. (127) 只是平均层面的约束, 远弱于 $D_i(1) \geq D_i(0)$ 对每个个体的约束。当数据满足 eq. (127) 时, 我们无法用观测数据否定 假设 27.2。

在**单侧非依从 (one-sided noncompliance)** 情况下 (被分配到对照组的人完全没有机会接受治疗, 即 $D_i(0) = 0$ 对所有人成立), 单调性假设自动满足。

4.2. 假设二：排除限制 (Exclusion Restriction).

假设 27.3 (排除限制). 对 *always taker* 和 *never taker*, 治疗分配不影响结局:

$$Y_i(1) = Y_i(0) \quad \text{当} \quad U_i = a \text{ 或 } U_i = n.$$

动机: 对于 *always taker* 和 *never taker*, 无论是否被分配到治疗组, 他们最终都会 (或都不会) 接受治疗。由于他们的治疗状态不受 Z 影响, 他们的结局也不应该受 Z 影响——除非 Z 有**直接效应 (direct effect)** 绕过 D 影响 Y 。排除限制假设排除了这种直接效应。

等价表述: 如果 $D_i(1) = D_i(0)$, 则 $Y_i(1) = Y_i(0)$ 对所有 i 成立。换言之, 治疗分配**只有通过实际接受的治疗才能影响结局**。

在**双盲随机实验**中, 这是生物学上合理的假设——结局只取决于实际接受的治疗。但在非盲实验、或者治疗分配可能通过非治疗途径 (如安慰剂效应、医生关注等) 影响结局时, 这个假设可能不成立。

违反排除限制的例子: 如果实验不是双盲的, 患者知道自己被分配到治疗组可能产生安慰剂效应, 或者医生对治疗组患者给予更多关注, 这些都会导致 Z 有直接效应绕过 D 影响 Y 。

4.3. 假设三：随机性 (我们已经有的). 假设 27.1 保证了 Z 的外生性——它不受潜在结果的混淆。

5. 识别 Complier 平均因果效应 (CACE)

在 假设 27.2 和 假设 27.3 下, eq. (122) 中的第一项 (*always taker*) 和第四项 (*never taker*) 变为零, 因为对这两类人 $Y(1) = Y(0)$ 。同时, 第三项 (*defier*) 在单调性下消失。因此

$$(128) \quad \tau_Y = \mathbb{E}\{Y(1) - Y(0) \mid U = c\} \Pr(U = c).$$

另一方面, 治疗接受率差为

$$(129) \quad \tau_D = \mathbb{E}\{D(1) - D(0)\} = \Pr(U = c),$$

因为只有 *complier* 在 $Z = 1$ 时接受治疗而在 $Z = 0$ 时不接受治疗, 其他三类人的治疗接受状态在两种分配下相同。

⁵问: 为什么 eq. (127) 是单调性的可检验含义? 见附录 ??。

定理 27.1 (CACE 识别). 在假设 27.2 和假设 27.3 下,

$$(130) \quad \tau_c \stackrel{\text{def}}{=} \mathbb{E}\{Y(1) - Y(0) \mid U = c\} = \frac{\tau_Y}{\tau_D}.$$

推论 27.2 (CACE/LATE 非参数识别). 在假设 27.1、假设 27.2 和假设 27.3 下,

$$(131) \quad \tau_c = \frac{\mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0)}{\mathbb{E}(D \mid Z = 1) - \mathbb{E}(D \mid Z = 0)}.$$

直觉: 分子是 ITT 对结局的效应, 分母是 ITT 对治疗的效应。比值 τ_Y/τ_D 衡量的是“被鼓励而实际接受治疗的人”的因果效应——这正是 complier average causal effect (CACE), 也称为**局部平均处理效应 (Local Average Treatment Effect, LATE)**⁶。

定义 27.2 的重要意义在于: 它不需要任何参数假设 (如线性、正态等), 因此被称为**非参数识别**。

CACE 的解释: CACE 是 complier 子群体的平均因果效应。在单调性下, complier 定义为满足 $D(1) > D(0)$ (即 $D(1) = 1, D(0) = 0$) 的单元。由于对 complier 有 $D = Z$, CACE 也可以解释为 complier 群体中**实际接受的治疗**对结局的因果效应。

局限性: CACE 只告诉我们 complier 的因果效应。对于 always taker、never taker、或者不满足单调性的 defier, 我们无法用 IV 方法识别他们的效应。这也是为什么称之为“局部”——它只识别了总体中一个子群体的效应。

6. 估计

基于定义 27.2, 我们可以用简单的比值估计量来估计 τ_c :

$$(132) \quad \hat{\tau}_c = \frac{\hat{\tau}_Y}{\hat{\tau}_D} = \frac{\bar{Y}_1 - \bar{Y}_0}{\bar{D}_1 - \bar{D}_0},$$

其中 $\bar{Y}_z$ 和 $\bar{D}_z$ 分别是 $Z = z$ 组中的样本均值。

eq. (132) 被称为 **Wald 估计量** 或 **IV 估计量**。

方差估计:⁷ 在 $\tau_c \neq 0$ 的常规情况下, 可以使用

$$\hat{V}(\hat{\tau}_c) = \frac{\hat{V}_Y}{\hat{\tau}_D^2},$$

其中 $\hat{V}_Y$ 是 $\hat{\tau}_Y$ 的 Neyman 型方差估计量。

置信区间:

$$\left(\frac{\hat{\tau}_Y}{\hat{\tau}_D} - z_{1-\alpha/2} \sqrt{\frac{\hat{V}_Y}{\hat{\tau}_D^2}}, \frac{\hat{\tau}_Y}{\hat{\tau}_D} + z_{1-\alpha/2} \sqrt{\frac{\hat{V}_Y}{\hat{\tau}_D^2}} \right).$$

注意: 在原假设 $\tau_c = 0$ 下, 方差估计量 $\hat{V}_Y/\hat{\tau}_D^2$ 是不一致的——它只能用于检验, 不能用于估计。但它揭示了一个洞见: Wald 估计量本质上是 ITT 估计量乘以 $1/\hat{\tau}_D > 1$, 其标准误差也以相同因子增大。

7. 协变量

与标准随机实验一样, 我们可以在 IV 分析中加入协变量 X 。

⁶问: 为什么叫“局部”平均处理效应? 见附录 ??。

⁷推导见附录 ??

7.1. CRE 中的协变量调整. 在假设 27.1 的基础上, 加入协变量后, 定义 27.2 变为条件形式:

$$(133) \quad \tau_c(x) = \frac{\mathbb{E}(Y \mid Z = 1, X = x) - \mathbb{E}(Y \mid Z = 0, X = x)}{\mathbb{E}(D \mid Z = 1, X = x) - \mathbb{E}(D \mid Z = 0, X = x)}.$$

然后通过 X 的分布上积分得到边际 CACE。

在 CRE 中, 我们可以在每层 $X = x$ 中独立进行 IV 分析, 然后汇总得到总体估计。

7.2. 条件随机化或不可混淆观测性研究. 如果治疗分配机制是条件随机的 (给定 X):

$$Z \perp\!\!\!\perp \{D(1), D(0), Y(1), Y(0)\} \mid X,$$

那么 eq. (133) 仍然适用。

如果是在不可混淆的观测性研究中 (治疗分配机制满足给定 X 的可忽略性), 我们可以用逆概率加权或分层方法来调整协变量。

8. 弱工具变量

8.1. 问题. 前述理论假设 $\tau_D > 0$ (即 complier 比例为正)。当 τ_D 接近 0 时, 即存在弱工具变量 (weak instrumental variable) 时, Wald 估计量会出现严重问题。

具体来说, 即使 $\tau_D > 0$, 也有正概率出现 $\hat{\tau}_D = 0$, 此时 $\hat{\tau}_c = \hat{\tau}_Y / \hat{\tau}_D$ 的方差是无穷大。⁸ 在弱 IV 情况下:

- (1) $\hat{\tau}_c$ 有有限样本偏差
- (2) $\hat{\tau}_c$ 的渐近分布不是正态的
- (3) Wald 型置信区间的覆盖性质很差

关键洞见: 对于二元结局 Y , 我们知道 $\tau_Y \in [-1, 1]$, 但 $\hat{\tau}_c = \hat{\tau}_Y / \hat{\tau}_D$ 可能远超出这个范围。

8.2. 对弱 IV 稳健的推断方法. 当存在弱 IV 时, 一个稳健的方法是使用 **Fieller-Anderson-Rubin (FAR) 置信集**。⁹

FAR 方法的核心思想是: 不把 τ_c 的估计量和方差分开处理, 而是直接构建 τ_c 的置信集, 使得该集合在弱 IV 情况下仍然有正确的覆盖概率。

在简单情形 (CRE 无协变量) 下, FAR 置信集可以简化为一个二次不等式

$$(\tau - \hat{\tau}_Y)^2 \leq z_{1-\alpha/2}^2 \hat{V}_Y,$$

其解可能是闭区间、两个不相连区间、空集或整个实数线。

9. CACE 的解释

notation $\{D(1), D(0), Y(1), Y(0)\}$ 是关于治疗分配 Z 的潜在干预结果的 notation。在这个 notation 下, τ_c 是治疗分配对 complier 结局的平均因果效应。

好消息: 对 complier, 由于 $D(1) = 1$ 且 $D(0) = 0$, 我们有 $D = Z$ 。因此, τ_c 也可以解释为 complier 群体中实际接受的治疗对结局的平均因果效应。

另一种 notation: ? 使用 $Y_i(z, d)$ 表示单元 i 在治疗分配 z 和治疗接受 d 下的潜在结局。在这种 notation 下, 排除限制假设变为

假设 27.4 (排除限制 (Angrist notation)). $Y_i(z, d) = Y_i(d)$ 对所有 i, z, d 成立, 即潜在结局只是 d 的函数。

⁸问: 为什么 $\hat{\tau}_D$ 可能为 0? 见附录 ??。

⁹问: FAR 置信集的基本思想是什么? 见附录 ??。

在这种 notation 下，假设 27.4 排除了从 Z 到 Y 的直接箭头，此时 Z 是 D 的工具变量。

定理 21.2 在假设 27.2、假设 27.4 和随机性下，

$$\tau_c = \frac{\mathbb{E}\{Y(D(1)) - Y(D(0))\}}{\mathbb{E}\{D(1) - D(0)\}},$$

即 CACE 是潜在结局增量与治疗接受增量的期望比值。

解释的微妙之处：虽然 τ_c 可以解释为 complier 群体中“实际治疗对结局的因果效应”，但这个群体是由工具变量 Z 的分布所定义子群体。不同 Z 分布下识别的 complier 可能是不同的子群体！这是 LATE 的一个根本性局限。

注 27.1. 为什么 CACE 是“局部”的？：因为它是总体中一个特定子群体 (complier) 的平均因果效应。这个子群体恰好是那些“被 Z 影响而改变治疗状态”的人。不同的工具变量可能识别不同的子群体。

10. 习题

练习 27.1. 27.1 Wald 估计量的方差 证明 Wald 估计量 $\hat{\tau}_c = \hat{\tau}_Y / \hat{\tau}_D$ 的渐近方差为 $\hat{V}_Y / \tau_D^2$ ，其中 $\hat{V}_Y$ 是 ITT 估计量 $\hat{\tau}_Y$ 的方差。

练习 27.2. 27.2 强单调性下的 IV 估计 在强单调性（所有人都是 complier 或 never taker，且 $\Pr(U = n) = 0$ ）下，证明 IV 估计量 $\hat{\tau}_c$ 的一致性。

练习 27.3. 27.3 单侧非依从性 在单侧非依从性（never taker 存在，但没有 always taker，且 $D_i(0) = 0$ 对所有人成立）下，推导 CACE 的识别公式，并解释其含义。

练习 27.4. 27.4 违反排除限制的后果 假设排除限制不成立，即存在 always taker 使得 $Y_i(1) \neq Y_i(0)$ 。证明此时 eq. (131) 估计量是有偏的，并讨论偏误的方向。

依从性与意向治疗分析

1. 引言：从随机实验到现实世界

在前面几章中，我们假设随机化实验的治疗分配能够被完美执行。然而，现实世界中的实验往往面临一个棘手的问题：**依从性 (compliance)** 问题。

想象一项药物临床试验。研究人员将患者随机分配到治疗组或对照组，但有些患者可能忘记服药，有些可能自行停药，还有些对照组患者可能通过其他途径获得了该药物。这种“分配与实际治疗不符”的现象，就是依从性问题的核心。

正如计量经济学家 ? 所指出的：

“The essential problem of causal inference is that we can observe at most one of the potential outcomes for any unit.”

在依从性问题的语境下，这句话有了更深的含义：我们不仅无法同时观察同一个体的治疗组和对照组结果，还可能无法控制该个体实际接受的治疗。

本章的核心问题：当治疗分配与实际治疗不一致时，我们如何估计治疗效果？

历史脉络：依从性问题的系统研究始于 ? 的开创性工作，随后被 ? 和 ? 发展到潜在结果框架下。本章遵循这一脉络，从实验设计视角介绍工具变量方法。

2. 鼓励设计与依从性问题

2.1. 基本设定与记号。考虑一个包含 n 个单元的完全随机实验。记号如下：

- $Z_i \in \{0, 1\}$: 治疗分配 ($1 =$ 治疗组, $0 =$ 对照组)
- $D_i \in \{0, 1\}$: 实际接受的治疗 ($1 =$ 接受治疗, $0 =$ 未接受治疗)
- Y_i : 关注的结果

当存在某些单元满足 $Z_i \neq D_i$ 时，**依从性问题 (noncompliance problem)** 就出现了。这种情况在涉及人类被试的实验中尤为常见——实验人员无法强迫被试接受治疗，只能“鼓励”他们。

潜在结果记号：每个单元有四个潜在结果

$$\{D_i(1), D_i(0), Y_i(1), Y_i(0)\},$$

其中 $D_i(z)$ 是在治疗分配 z 下会接受的治疗， $Y_i(z)$ 是在治疗分配 z 下的结果。观测值为：

$$D_i = Z_i D_i(1) + (1 - Z_i) D_i(0), \quad Y_i = Z_i Y_i(1) + (1 - Z_i) Y_i(0).$$

2.2. 随机化假设与可识别性。我们首先假设完全随机化且忽略协变量。

假设 28.1 (随机化). 治疗分配 Z 与潜在结果独立：

$$Z \perp\!\!\!\perp \{D(1), D(0), Y(1), Y(0)\}.$$

随机化允许我们识别治疗分配对 D 和 Y 的平均因果效应：¹

$$\tau_D = \mathbb{E}\{D(1) - D(0)\} = \mathbb{E}(D \mid Z = 1) - \mathbb{E}(D \mid Z = 0),$$

¹推导见附录 ??

$$\tau_Y = \mathbb{E}\{Y(1) - Y(0)\} = \mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0).$$

我们可以用简单的差值均值估计量 $\hat{\tau}_D$ 和 $\hat{\tau}_Y$ 来估计 τ_D 和 τ_Y 。

2.3. 意向治疗分析 (ITT). 报告 $\hat{\tau}_Y$ 及其标准误的分析称为**意向治疗分析 (intention-to-treat, ITT analysis)**。²

ITT 估计的是**治疗分配**对结果的影响, 而非**实际接受的治疗**对结果的影响。这是一个重要的区别:

$$\underbrace{\hat{\tau}_Y}_{\text{ITT 估计量}} \xrightarrow{p} \underbrace{\tau_Y}_{\text{治疗分配的因果效应}},$$

但我们真正关心的科学问题往往是:

$$\underbrace{\tau_{\text{treatment}}}_{\text{实际治疗的因果效应}} \neq \underbrace{\tau_Y}_{\text{治疗分配的因果效应}}.$$

这就是依从性问题带来的核心挑战。

3. 潜在依从性类型与依从性因果效应

3.1. 四类依从性状态. 遵循 ? 的开创性工作, 我们根据潜在治疗接受值 $\{D_i(1), D_i(0)\}$ 对总体进行分层。由于 D 是二值的, 共有四种可能的组合:

定义 28.1 (依从性类型). 令 $U_i = \{D_i(1), D_i(0)\}$, 则:

$$U_i = \begin{cases} a \text{ (always taker)} & , \text{ 若 } D_i(1) = 1 \text{ 且 } D_i(0) = 1; \\ c \text{ (complier)} & , \text{ 若 } D_i(1) = 1 \text{ 且 } D_i(0) = 0; \\ d \text{ (defier)} & , \text{ 若 } D_i(1) = 0 \text{ 且 } D_i(0) = 1; \\ n \text{ (never taker)} & , \text{ 若 } D_i(1) = 0 \text{ 且 } D_i(0) = 0. \end{cases}$$

直观理解:

- **Always takers:** 无论分配如何, 都会接受治疗
- **Never takers:** 无论分配如何, 都不会接受治疗
- **Compliers:** 服从分配——分配到治疗组则接受, 分配到对照组则不接受
- **Defiers:** 反着来——分配到治疗组反而不接受, 分配到对照组反而接受

由于我们无法同时观察 $D_i(1)$ 和 $D_i(0)$, 类型 U_i 是**潜变量**。

3.2. 平均因果效应的分解. 基于潜在类型 U , 利用全概率公式可以将 τ_Y 分解为四项:

3

$$\begin{aligned} \tau_Y &= \mathbb{E}\{Y(1) - Y(0) \mid U = a\} \Pr(U = a) \\ &\quad + \mathbb{E}\{Y(1) - Y(0) \mid U = c\} \Pr(U = c) \\ &\quad + \mathbb{E}\{Y(1) - Y(0) \mid U = d\} \Pr(U = d) \\ &\quad + \mathbb{E}\{Y(1) - Y(0) \mid U = n\} \Pr(U = n). \end{aligned}$$

这说明 τ_Y 是四个潜在亚组因果效应的加权平均。

²ITT 分析的名称来源于临床试验, 其核心思想是按照原始分配而非实际接受的治疗进行分析。

³完整推导见附录 ??

类似地, τ_D 的分解为:⁴

$$\begin{aligned}\tau_D &= \mathbb{E}\{D(1) - D(0) \mid U = a\} \Pr(U = a) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = c\} \Pr(U = c) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = d\} \Pr(U = d) \\ &\quad + \mathbb{E}\{D(1) - D(0) \mid U = n\} \Pr(U = n) \\ &= 0 \cdot \Pr(U = a) + 1 \cdot \Pr(U = c) + (-1) \cdot \Pr(U = d) + 0 \cdot \Pr(U = n) \\ &= \Pr(U = c) - \Pr(U = d).\end{aligned}$$

4. 非参数识别

上述分解表明, 仅凭观测数据无法唯一识别 τ_Y ——我们有四个未知数 (四个亚组的因果效应) 但只有两个方程 (τ_Y 和 τ_D 的识别)。为了进一步识别, 我们需要额外的假设。

4.1. 单调性假设.

假设 28.2 (单调性). $\Pr(U = d) = 0$, 或等价地, $D_i(1) \geq D_i(0)$ 对所有单元成立。即, 不存在 *defiers*。

何时成立? 单调性假设在单侧依从性问题 (**one-sided noncompliance**) 中自动成立: 当对照组被试无法获得治疗时, $D_i(0) = 0$ 对所有单元成立, 从而 $D_i(1) \geq D_i(0)$ 必然成立。

可检验的含义: 在随机化下, 单调性假设有一个可检验的含义:⁵

$$\Pr(D = 1 \mid Z = 1) \geq \Pr(D = 1 \mid Z = 0).$$

注意: 假设 28.2 比 section 4.1 更强。前者限制每个个体的 $D_i(1)$ 和 $D_i(0)$, 后者只限制平均值。当可检验的不等式成立时, 我们无法用数据反驳单调性假设。

在单调性假设下, section 3.2 简化为:

$$\tau_D = \Pr(U = c) \equiv \pi_c.$$

这意味着 compliers 的比例 π_c 等于治疗分配对实际治疗的平均因果效应——这是一个可以识别的数量。

4.2. 排斥限制假设.

假设 28.3 (排斥限制). 对于 *always takers* ($U = a$) 和 *never takers* ($U = n$), 有 $Y_i(1) = Y_i(0)$ 。

直观理解: 排斥限制要求治疗分配只能通过实际接受的治疗影响结果, 不能有其他直接通路。在双盲随机对照试验中, 这是生物学上合理的——如果治疗分配没有改变实际接受的治疗, 它也不会改变结果。

何时可能被违反? 当治疗分配有直接影响结果的通路时 (而非通过实际接受的治疗)。例如, 在非双盲试验中, 被试可能因为知道自己被分配到治疗组而改变行为。

在排斥限制假设下, section 3.2 中的第一项和最后一项变为零:

$$\tau_Y = \mathbb{E}\{Y(1) - Y(0) \mid U = c\} \Pr(U = c).$$

结合 section 4.1 和 section 4.2, 我们得到识别结果。

⁴推导见附录 ??

⁵推导见附录 ??

4.3. 主要识别定理.

定理 28.2 (CACE/LATE 的识别). 在假设 28.1、假设 28.2 和假设 28.3 下, 如果 $\tau_D \neq 0$, 则

$$\mathbb{E}\{Y(1) - Y(0) \mid U = c\} = \frac{\tau_Y}{\tau_D}.$$

证明思路: 由 section 4.2 和 section 4.1 可直接得到。⁶

定义 28.2 的含义是: 在上述三个假设下, τ_Y/τ_D 识别了 compliers 的平均因果效应。

一个哲学性的观察: 识别结果只涉及 compliers——那些“遵医嘱”的人。这意味着我们无法直接得知治疗对 always takers、never takers 或 defiers 的效果。这既是局限, 也是优势——它允许我们专注于一个明确定义的亚组。

5. 依从性平均因果效应 (CACE/LATE)

5.1. 定义.

定义 28.3 (CACE 或 LATE). **依从性平均因果效应 (complier average causal effect, CACE)** 或 **局部平均治疗效应 (local average treatment effect, LATE)** 定义为:

$$\tau_c = \mathbb{E}\{Y(1) - Y(0) \mid U = c\}.$$

CACE 有两种等价形式:

$$\tau_c = \mathbb{E}\{Y(1) - Y(0) \mid D(1) = 1, D(0) = 0\} = \mathbb{E}\{Y(1) - Y(0) \mid D(1) > D(0)\}.$$

基于定义 28.3, 定义 28.2 可以写成:

$$\tau_c = \frac{\tau_Y}{\tau_D}.$$

即, CACE/LATE 等于结果平均因果效应与治疗接受平均因果效应之比。

在完全随机化下, 进一步有:

$$\tau_c = \frac{\mathbb{E}(Y \mid Z = 1) - \mathbb{E}(Y \mid Z = 0)}{\mathbb{E}(D \mid Z = 1) - \mathbb{E}(D \mid Z = 0)}.$$

因此, 在完全随机化、单调性和排斥限制下, 我们可以**非参数地识别 CACE**——它等于观测数据中结果差值均值与治疗接受差值均值之比。

6. 估计

6.1. Wald 估计量. 基于 section 5.1, 我们可以用简单的比值估计 CACE:

$$\hat{\tau}_c = \frac{\hat{\tau}_Y}{\hat{\tau}_D},$$

其中

$$\hat{\tau}_Y = \frac{1}{n_1} \sum_{i:Z_i=1} Y_i - \frac{1}{n_0} \sum_{i:Z_i=0} Y_i, \quad \hat{\tau}_D = \frac{1}{n_1} \sum_{i:Z_i=1} D_i - \frac{1}{n_0} \sum_{i:Z_i=0} D_i.$$

这就是著名的 **Wald 估计量 (?)**, 也称为 **工具变量估计量**。在这个语境下, Z 作为 D 的工具变量。

直观理解: Wald 估计量可以理解为“缩放的”ITT 估计量。 $\hat{\tau}_Y$ 估计治疗分配的效果, $\hat{\tau}_D$ 估计治疗分配对实际治疗的“转化率” (即 compliers 的比例)。二者的比值估计了对于那些“被转化”的 compliers, 治疗的实际效果。

⁶完整证明见附录 ??

6.2. 方差估计. 为了进行统计推断, 我们需要估计 $\hat{\tau}_c$ 的方差。⁷
基本思想是将 $\hat{\tau}_c$ 在真实值附近线性化:⁸

$$\hat{\tau}_c - \tau_c \approx \frac{\hat{\tau}_Y - \tau_c \hat{\tau}_D}{\tau_D}.$$

定义调整后的结果 $A_i = Y_i - \tau_c D_i$, 则上式近似为 $\hat{\tau}_A/\tau_D$, 其中 $\hat{\tau}_A$ 是调整后结果的差值均值。

因此, $\hat{\tau}_c$ 的渐近方差约为 $\hat{V}_A/\tau_D^2$, 其中 $\hat{V}_A$ 是调整后结果的 Neyman 型方差估计量:

$$\hat{V}_A = \frac{\hat{S}_A^2(1)}{n_1} + \frac{\hat{S}_A^2(0)}{n_0},$$

其中 $\hat{S}_A^2(1)$ 和 $\hat{S}_A^2(0)$ 分别是治疗组和对照组中调整后结果的样本方差。
最终, 我们使用

$$\hat{V}_{\hat{\tau}_c} = \frac{\hat{V}_A}{\hat{\tau}_D^2}$$

作为 $\hat{\tau}_c$ 的方差估计量。

基于此, 我们可以构建 τ_c 的 $1 - \alpha$ 置信区间:

$$\hat{\tau}_c \pm z_{1-\alpha/2} \sqrt{\hat{V}_{\hat{\tau}_c}}.$$

7. 弱工具变量

在实际研究中, 我们常常面临一个尴尬的局面: 工具变量的”强度”并不总能得到保证。想象一下, 即使在真实的随机实验中, 由于各种现实因素, 只有极少数被试 (比如说 5%) 改变了他们的行为。在这种情况下, 我们能否信赖 Wald 估计量?

7.1. 问题诊断. 即使 $\tau_D > 0$ (即 compliers 确实存在), $\hat{\tau}_D$ 仍有可能接近甚至等于零。这会导致 Wald 估计量的方差急剧增大——实际上, 当 $\tau_D \rightarrow 0$ 时, $\text{var}(\hat{\tau}_c) \rightarrow \infty$ 。⁹

这就是**弱工具变量 (weak instrumental variable)**问题。[?]的经典研究表明, 当工具变量弱时, 传统的统计推断方法会失效。在这种情况下:

- $\hat{\tau}_c$ 存在有限样本偏
- 渐近分布不再是正态
- 基于正态近似的置信区间覆盖性质很差

诊断指标: 一个常用的诊断是 F 统计量或 $\hat{\tau}_D$ 的绝对值。经验法则: 当 $\hat{\tau}_D$ 很小时, 应谨慎对待 Wald 估计量。

7.2. FAR 置信区间. 从估计角度, 当工具变量弱时, 我们建议关注**置信区间**而非点估计。从检验角度, 有一个简单的解决方案——由于 $\tau_c = \tau_Y/\tau_D$, 原假设 $\tau_c = 0$ 等价于 $\tau_Y = 0$ 。

更精细的方法是构建 **Fieller-Anderson-Rubin (FAR) 置信区间**。其思想是通过反转一系列假设检验来构建 τ_c 的置信域。¹⁰

对于给定的 b , 考虑原假设 $H_0(b): \tau_c = b$ 。这等价于 $\tau_Y - b\tau_D = 0$, 即调整后的结果 $A(b)_i = Y_i - bD_i$ 的平均因果效应为零。

⁷渐近方差公式的推导见附录 ??

⁸详细推导见附录 ??

⁹这与经典统计学中的 Fieller-Creasy 问题类似。

¹⁰FAR 置信区间的详细讨论见附录 ??。

构造 Wald 型检验并反转，可以得到置信域：

$$\left\{ b : \frac{\hat{\tau}_A^2(b)}{\hat{V}_A(b)} \leq z_{1-\alpha/2}^2 \right\},$$

其中 $\hat{\tau}_A(b)$ 和 $\hat{V}_A(b)$ 是调整后结果 $A(b)_i = Y_i - bD_i$ 的点估计和方差估计。

FAR 置信域可能是单个区间、两个不相连的区间、空集或整个实数线。当工具变量强时，它收敛到标准 Wald 置信区间；当工具变量弱时，它提供更可靠的推断。

8. 协变量调整

到目前为止我们都假设没有协变量。加入协变量可以提高估计的效率和稳健性。

8.1. 完全随机化下的协变量调整. 假设条件随机化成立：

$$Z \perp \{D(1), D(0), Y(1), Y(0), X\}.$$

我们可以使用 ? 的协变量调整估计量。对于结果和和治疗接受，分别拟合包含协变量的回归模型：

$$D_i = \beta_0 + \beta_1 Z_i + \beta_2 X_i + \beta_3 Z_i X_i + \epsilon_i,$$

$$Y_i = \alpha_0 + \alpha_1 Z_i + \alpha_2 X_i + \alpha_3 Z_i X_i + \eta_i,$$

取 $\hat{\tau}_{D,L} = \hat{\beta}_1$ 和 $\hat{\tau}_{Y,L} = \hat{\alpha}_1$ ，则调整后的 CACE 估计量为：

$$\hat{\tau}_{c,L} = \frac{\hat{\tau}_{Y,L}}{\hat{\tau}_{D,L}}.$$

渐近方差可以通过 Bootstrap 近似。

9. 实例：JOBS II 培训项目

研究背景：JOBS II 是一个随机化现场实验，研究职业培训对失业工人求职自我效能的影响。? 原始设计比较复杂，这里使用 ? 的简化版本。

数据：来自 jobsdata.csv。关键变量：

- treat: 是否被随机分配参加培训项目 (Z)
- comply: 是否实际参加了培训项目 (D)
- jobseek: 求职自我效能得分 (Y , 1-5 分制)

描述性统计：¹¹

例 28.1 (JOBS II 数据的 IV 分析). 我们使用 Wald 估计量分析 JOBS II 数据。结果如下：

方法	估计量	标准误	95% CI 下限	95% CI 上限
Delta 方法	0.109	0.081	-0.050	0.268
Bootstrap	0.109	0.083	-0.054	0.271
含协变量调整	0.118	0.082	-0.042	0.278

解读：点估计表明，对于 compliers，参加培训项目使求职自我效能得分提高约 0.11 分 (满分 5 分)。但 95% 置信区间包含零，这意味着在常规显著性水平下，我们无法拒绝“培训对 compliers 无效果”的原假设。

¹¹详细数据分析代码见附录 ??

10. 从识别到解释：CACE 的深层含义

到目前为止，我们建立了 CACE 的识别和估计框架。但还有一个关键问题：CACE 到底代表什么？

定义 28.3 中定义的 τ_c 有两种等价解释：

- (1) **治疗分配的因果效应 (among compliers)**: $\tau_c = \mathbb{E}\{Y(1) - Y(0) \mid U = c\}$ 是治疗分配对 compliers 结果的平均因果效应。
- (2) **实际治疗的因果效应 (among compliers)**: 对于 compliers, 有 $D(1) = 1$ 和 $D(0) = 0$, 因此 $D = Z$ 。所以 τ_c 也是实际接受的治疗对 compliers 结果的因果效应。

第二种解释更具科学吸引力——它回答了”对于那些会遵医嘱的人，治疗真的有效果吗？”这个问题。

局限性：CACE 只告诉我们关于 compliers 的信息，我们无法直接得知治疗对 always takers、never takers 或 defiers 的效果。如果这些亚组与 compliers 有本质不同的治疗效果，CACE 可能无法代表治疗对整个人群的效果。

11. 本章小结

本章介绍了依从性问题的框架，主要内容如下：

- (1) **依从性问题的普遍性**：在涉及人类被试的实验中，治疗分配与实际治疗往往不一致。
- (2) **四类依从性状态**：always takers、compliers、defiers、never takers。
- (3) **关键假设**：随机化、单调性（无 defiers）、排斥限制（治疗分配只能通过实际治疗影响结果）。
- (4) **识别**（定义 28.2）：在上述假设下， $CACE = \tau_Y / \tau_D$ 。
- (5) **估计**：Wald 估计量 $\hat{\tau}_c = \hat{\tau}_Y / \hat{\tau}_D$ 。
- (6) **弱工具变量问题**：当 compliers 比例很小时，Wald 估计量表现不佳，需要使用 FAR 置信区间。
- (7) **协变量调整**：可以提高效率和稳健性。

12. 习题

练习 28.1. *ITT 与 CACE 的关系* 证明在假设 28.2 下， $\tau_Y = \tau_c \cdot \pi_c$ ，其中 $\pi_c = \Pr(U = c)$ 。

练习 28.2. *单调性的可检验含义* 证明在完全随机化下，假设 28.2 蕴含 section 4.1。

练习 28.3. *Wald 估计量的方差* 证明当 $\tau_D = 0$ 时， $\text{var}(\hat{\tau}_c) = \infty$ 。

练习 28.4. *单侧依从性* 考虑单侧依从性情形：对照组被试无法获得治疗，即 $D_i(0) = 0$ 对所有 i 成立。

- (1) 证明此时 假设 28.2 自动成立。
- (2) 在这种情况下，CACE 如何简化为 ITT 的函数？

练习 28.5. *FAR 置信区间的形状* 在 section 7.2 中，FAR 置信集可能是单个闭区间、两个不相连的区间、空集或整个实数线。找出每种情况对应的精确条件。

练习 28.6. *协变量调整的 CACE* 使用 JOBS II 数据进行以下分析：

- (1) 计算原始 Wald 估计量及其标准误。
- (2) 加入协变量 (*sex, age, marital, nonwhite, educ, income*) 后重新估计。
- (3) 比较两种方法的估计量和标准误。

练习 28.7. *Always takers* 与 *Never takers* 假设我们想估计 *always takers* 的平均因果效应。

- (1) 在当前框架下, 这个量能否被识别? 为什么?
- (2) 如果加入额外假设“*always takers* 和 *never takers* 的潜在结果分布相同”, 结果会如何改变?

练习 28.8. 模拟研究 进行模拟研究, 比较以下三种情况:

- (1) 强工具变量 ($\pi_c = 0.5$)
- (2) 中等强度工具变量 ($\pi_c = 0.2$)
- (3) 弱工具变量 ($\pi_c = 0.05$)

对每种情况, 报告 *Wald* 估计量的偏差、均方误差和置信区间的覆盖概率。

两阶段最小二乘

1. 引言：工具变量回归的计算技巧

在上一章中，我们讨论了恰好识别 (just-identified) 情况下的工具变量 (IV) 估计：当工具变量 Z 与内生解释变量 D 维度相同时，我们可以直接通过矩条件 $E(ZY) = E(ZD^\top)\beta$ 求解得到 IV 估计量。然而，在实际研究中，我们常常面临过度识别 (over-identified) 的情形——也就是说，我们拥有的工具变量数量多于内生变量的数量。

这种情况在经验研究中非常普遍。例如，在研究教育回报的问题时，Angrist and Krueger (1991) 使用出生季度作为教育的工具变量，但实际上我们可能有多个与误差项无关的变量都可以作为工具变量。当工具变量多于内生变量时，矩条件方程组中方程的个数多于未知参数的个数，系统没有唯一的精确解。

一个自然而然的问题是：如何在这种情况下找到一个“最优”的估计量？正是为了回答这个问题，Theil (1953) 和 Basman (1957) 分别独立地提出了两阶段最小二乘 (Two-Stage Least Squares, TSLS) 估计量。这是一个巧妙的计算技巧，它将一个看似复杂的过度识别问题转化为两个连续的普通最小二乘回归。

本章我们将详细介绍 TSLS 的动机、原理及其在大样本理论下的性质。

2. 问题设定：过度识别情形

让我们回顾线性工具变量模型的基本设定。假设我们有如下结构方程：

$$(134) \quad Y = D^\top \beta + \varepsilon,$$

其中 Y 是结果变量， D 是 p 维内生解释变量， β 是 p 维待估参数向量。我们假设存在 q 维的工具变量 Z 满足排他性 restriction: $E(\varepsilon Z) = 0$ 。

当 $q > p$ (工具变量维度大于内生变量维度) 时，我们面临过度识别问题。此时，样本矩条件

$$(135) \quad n^{-1} \sum_{i=1}^n Z_i Y_i = n^{-1} \sum_{i=1}^n Z_i D_i^\top \beta$$

包含了 q 个方程，但只有 p 个未知参数。当 $q > p$ 时，这些方程通常没有精确解——我们只能寻找一个在某种意义上“最接近”所有矩条件的估计量。

3. 两阶段最小二乘估计量

TSLS 提供了一个优雅的解决方案。顾名思义，这个方法包含两个阶段：

[两阶段最小二乘估计量] 定义以 Z 为工具变量、 D 的系数 β 的 TSLS 估计量如下：

第一阶段 对 D 关于 Z 做 OLS 回归，得到拟合值 $\hat{D}_i$ ($i = 1, \dots, n$)。如果 D_i 是向量，则按分量做 OLS 回归。将拟合值向量组成矩阵 $\hat{D}$ ，其第 i 行为 $\hat{D}_i^\top$ ；

第二阶段 对 Y 关于 $\hat{D}$ 做 OLS 回归，得到系数 $\hat{\beta}_{\text{TSLS}}$ 。

这个定义的表述方式非常直观，但为了理解其深层原理，我们需要进行一些代数推导。

3.1. TSLS 的代数推导. 为了看清 TSLS 估计量的本质, 我们将其显式地写出来。¹ 第一阶段 OLS 回归可以写成:

$$(136) \quad \hat{D}_i = \hat{\Gamma}^\top Z_i,$$

其中 $\hat{\Gamma} = (\sum_{i=1}^n Z_i Z_i^\top)^{-1} \sum_{i=1}^n Z_i D_i^\top$ 。

第二阶段的 OLS 估计量为:

$$(137) \quad \hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

将 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入, 经过整理可得:

$$(138) \quad \hat{\beta}_{\text{TSLS}} = \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right).$$

这个表达式揭示了 TSLS 估计量的本质。由于 $E(Z\varepsilon) = 0$, 根据大数定律, 式 eq. (138) 中最后一项的概率极限为 0, 因此 $\hat{\beta}_{\text{TSLS}}$ 是 β 的相合估计量。

一个值得注意的代数事实是, 当工具变量与内生变量维度相同时 (即 $q = p$ 的恰好识别情形), TSLS 估计量与上一章定义的 IV 估计量 $\hat{\beta}_{\text{IV}}$ 在数值上完全相同。

4. 标准误的估计

在获得点估计之后, 我们需要考虑抽样变异性的度量。基于式 eq. (138), 我们可以推导出 TSLS 估计量的渐近方差, 并据此构造标准误。

具体而言, 首先计算残差 $\hat{\varepsilon}_i = Y_i - \hat{\beta}_{\text{TSLS}}^\top D_i$, 然后采用 Eicker-Huber-White 稳健方差估计量:

$$(139) \quad \hat{V}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \left(\sum_{i=1}^n \hat{\varepsilon}_i^2 \hat{D}_i \hat{D}_i^\top \right) \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1}.$$

这里需要特别强调一点: 残差 $\hat{\varepsilon}_i$ 来自对原方程 Y_i on D_i 的回归, 而不是来自第二阶段 OLS 回归 Y_i on $\hat{D}_i$ 的残差。这一细节非常重要, 因为它意味着 $\hat{V}_{\text{TSLS}}$ 与直接对第二阶段回归应用稳健标准误所得的结果不同。

5. 特殊情形: 单一工具变量与单一内生处理

本节我们考虑一个在应用中最常见的情形: 一个工具变量 Z 作用于一个内生处理变量 D 。考虑如下结构方程组:

$$(140) \quad \begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}, \end{cases}$$

其中 D_i 是标量内生处理变量, Z_i 是标量工具变量 (满足 $E(\varepsilon_i Z_i) = 0$), X_i 是外生协变量向量 (满足 $E(\varepsilon_i X_i) = 0$)。

¹推导过程详见附录 section 13

5.1. TSLS 的简化形式. 在此特殊情形下, section 3 中的 TSLS 估计量简化为:
[单一内生回归子的 TSLS] 基于方程组 eq. (140), TSLS 估计量包含以下两步:

第一阶段 对 D 关于 $(1, Z, X)$ 做 OLS 回归, 得到拟合值 $\hat{D}_i$ ($i = 1, \dots, n$);

第二阶段 对 Y 关于 $(1, \hat{D}, X)$ 做 OLS 回归, 得到系数 $\hat{\beta}_{\text{TSLS}}$, 特别是 $\hat{\beta}_{1, \text{TSLS}}$, 即 $\hat{D}$ 的系数。

这个两步程序在经验研究中极为常用, 因为它在计算上简洁直观, 同时保持了良好的统计性质。

5.2. 间接最小二乘. 结构方程组 eq. (140) 还可以通过另一种思路来估计。注意到约化形式 (reduced form) 为:

$$(141) \quad \begin{cases} Y_i = \Gamma_0 + \Gamma_1 Z_i + \Gamma_2^\top X_i + \varepsilon_{1i}, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}, \end{cases}$$

其中 $\Gamma_0 = \beta_0 + \beta_1 \gamma_0$, $\Gamma_1 = \beta_1 \gamma_1$, $\Gamma_2 = \beta_2 + \beta_1 \gamma_2$, 且 $\varepsilon_{1i} = \varepsilon_i + \beta_1 \varepsilon_{2i}$ 。

关键观察是: 由于约化形式方程中的解释变量 (Z, X) 都是外生的, 我们可以对这两个方程分别做 OLS 回归, 得到一致估计量 $\hat{\Gamma}_1$ 和 $\hat{\gamma}_1$ 。而待估参数 β_1 恰好等于这两个系数的比值:

$$(142) \quad \beta_1 = \frac{\Gamma_1}{\gamma_1}.$$

因此, 我们可以构造间接最小二乘 (Indirect Least Squares, ILS) 估计量:

$$(143) \quad \hat{\beta}_{1, \text{ILS}} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

有趣的是, ILS 估计量与 TSLS 估计量在数值上完全相同。

[TSLS 与 ILS 的等价性] 在单一内生处理变量和单一工具变量的情形下 (方程组 eq. (140)), 我们有

$$(144) \quad \hat{\beta}_{1, \text{ILS}} = \hat{\beta}_{1, \text{TSLS}}.$$

这个定理的本质是一个代数恒等式, 它说明尽管 TSLS 和 ILS 看起来是不同的估计方法, 但它们实际上是同一估计量的不同计算路径。²

比值形式的表达式 eq. (143) 揭示了 TSLS 估计量的一个重要弱点: 当工具变量较弱 (即 γ_1 接近于零) 时, 分子和分母都可能面临严重的有限样本偏误问题。

6. 弱工具变量问题

当工具变量与内生处理变量的相关性较弱时, TSLS 估计量的有限样本性质会严重恶化。这是因为在式 eq. (143) 中, 我们需要用分母 $\hat{\gamma}_1$ 去除分子 $\hat{\Gamma}_1$, 而当 γ_1 接近于零时, 估计量的分布会变得极度非正态, 标准的大样本理论不再适用。

一个更加稳健的推断方法是基于约化形式的 Fieller-Anderson-Rubin (FAR) 方法。该方法的核心思想是: 对于任意假设值 b , 考虑原假设 $H_0(b): \beta_1 = b$ 。在该假设下, 构造调整后的结果变量 $Y_i(b) = Y_i - bD_i$, 并检验 $Y_i(b)$ 与工具变量 Z_i 之间是否存在显著关系。如果 b 是真实值, 那么根据矩条件 $E(Z\varepsilon) = 0$, 这一关系应当不显著。

具体地, FAR 置信区间的构造如下:

$$(145) \quad \{b : |t_Z(b)| \leq z_{1-\alpha/2}\},$$

²定理 section 5.2 的证明详见附录 section 14。

其中 $t_Z(b)$ 是 Z 在回归 $Y_i(b)$ on $(1, Z, X)$ 中的 t 统计量 (使用 EHW 稳健标准误), $z_{1-\alpha/2}$ 是标准正态分布的 $1 - \alpha/2$ 分位数。

值得注意的是, 这种 FAR 方法在弱工具变量情形下比传统的基于 TSLS 的 Wald 型置信区间更加稳健, 而且在某些情况下可以完全避免使用 TSLS 估计量。

7. 应用: Card (1993) 教育回报研究

让我们将 TSLS 方法应用于一个经典的经验研究问题: 教育对工资的因果效应。Card (1993) 利用美国年轻男性队列数据, 使用居住地附近是否有四年制大学作为教育的工具变量, 估计了教育的回报率。

在该研究中, 工具变量 Z 是“成长地附近是否有四年制大学”的指示变量, 处理变量 D 是受教育年限, 结果变量 Y 是 1976 年的对数工资。协变量 X 包括种族、年龄及其平方、是否与双亲同住等。

应用 TSLS 方法, 我们得到点估计和 95% 置信区间:

	TSLS 估计		
	下界	上界	
教育回报率	0.132	0.026	0.237

这意味着, 多受一年教育会使工资提高约 13.2%。使用 FAR 方法, 我们得到置信区间为 $[0.028, 0.282]$, 与 TSLS 的结果非常接近, 这是因为在该数据中工具变量并非特别弱。

8. 小结

本章我们介绍了两阶段最小二乘 (TSLS) 估计量, 这是工具变量方法在过度识别情形下的核心计算技术。TSLS 的关键思想是将一个复杂的矩估计问题转化为两个连续的 OLS 回归, 从而大大简化了计算。

从理论角度, 我们证明了 TSLS 估计量在大样本下是相合的, 并且当工具变量与内生变量维度相同时, 它与传统的 IV 估计量完全等价。此外, 我们还介绍了 TSLS 与间接最小二乘 (ILS) 的等价性, 以及弱工具变量情形下的 FAR 稳健推断方法。

在应用层面, TSLS 已成为计量经济学中处理内生性问题的标准工具。下一章我们将讨论如何检验工具变量的有效性, 以及如何处理可能的工具变量失效情形。

9. 习题

练习 29.1 (TSLS 与 IV 的等价性). 证明在恰好识别情形下 (Z 与 D 维度相同), TSLS 估计量 $\hat{\beta}_{\text{TSLS}}$ 与 IV 估计量 $\hat{\beta}_{\text{IV}}$ 数值相同。

提示: 利用第一阶段 OLS 的正交性条件 $\sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0$ 。

练习 29.2 (TSLS 与 ILS 的等价性). 证明定理 section 5.2: 在单一内生处理变量和单一工具变量情形下, TSLS 估计量等于约化形式系数比值 $\hat{\Gamma}_1/\hat{\gamma}_1$ 。

提示: 利用第一阶段拟合值的表达式 $\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i$, 验证第二阶段 OLS 中 $\hat{D}$ 的系数恰好等于比值形式。

练习 29.3 (弱工具变量的影响). 考虑 TSLS 估计量 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1/\hat{\gamma}_1$ 。当工具变量较弱 (即 γ_1 接近于零) 时, 讨论:

- (1) 为什么 $\hat{\gamma}_1$ 的小误差会导致 $\hat{\beta}_{1,\text{TSLS}}$ 的巨大偏差?
- (2) FAR 置信区间相比 Wald 型置信区间的优势是什么?

模糊断点回归

1. 本章导论

在前两章中，我们分别学习了断点回归设计 (Regression Discontinuity Design, RDD) 和工具变量法 (Instrumental Variables, IV)。本章我们要问一个自然的问题：**如果把这两种方法结合起来，会发生什么？**

答案就是本章的主题——**模糊断点回归** (Fuzzy Regression Discontinuity, FRDD)。这是一种“自然实验”，它既保留了断点回归的直观设定，又借助工具变量的识别策略来处理内生性问题。

2. 从清晰断点到模糊断点

2.1. 清晰断点回归的回顾。 在第 26 章中，我们学习了**清晰断点回归** (Sharp RDD)。其核心设定是：治疗分配 $Z_i = I(X_i \geq x_0)$ 由运行变量 (running variable) X_i 在断点 x_0 处**确定性地**决定。

在清晰 RDD 下，潜在结果 $\{Y_i(1), Y_i(0)\}$ 在断点处的期望差可以识别：

$$(146) \quad \tau_Y(x_0) = \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y \mid X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y \mid X = x_0 - \varepsilon).$$

2.2. 模糊断点回归的引入。 然而，在现实中有许多情况，治疗分配并不是由运行变量**完全**决定的。运行变量改变了治疗的**概率**，但不决定治疗的最终结果。

关键观察：在模糊 RDD 中， $Z_i = I(X_i \geq x_0)$ 仍然是一个有效的工具变量——它满足：

- (1) **相关性：** Z_i 与治疗状态 D_i 相关 (因为 $X_i \geq x_0$ 增加了接受治疗的概率)
- (2) **排除限制：** Z_i 通过改变 D_i 来影响 Y_i ，而没有直接影响 (需要额外假设)

这就将我们引向了工具变量法的框架。

3. 动机实例

例 30.1 (印度农村道路项目)。 研究了印度政府 2000 年启动的“总理乡村道路计划”。该计划根据 2001 年人口普查的阈值来优先考虑规模较大的村庄。

关键点：村庄人口规模与阈值的差并不能**直接决定**是否获得道路——它只改变了获得道路的**概率**。在断点附近，获得道路的概率发生了跳跃，但不是从 0 到 1 的确定性跳跃。

例 30.2 (意大利大学助学金项目)。 研究了意大利大学助学金对辍学率的影响。学生如果标准化家庭收入低于 15,000 欧元，则有资格获得助学金。

为获得助学金，学生必须先申请。因此，资格状态和申请状态共同决定了最终治疗状态。运行变量 (15,000 减去标准化家庭收入) 单独并不能决定治疗状态，但它在断点处改变了治疗概率。

FIGURE 1. 清晰断点回归（左）与模糊断点回归（右）的治疗分配概率比较

4. 数学设定

设 X_i 为运行变量，断点为 x_0 。定义工具变量：

$$Z_i = I(X_i \geq x_0).$$

治疗分配 D_i 可能不等于 Z_i ，但条件概率 $\mathbb{P}(D_i = 1 | X_i = x)$ 在 x_0 处有跳跃。
fig. 1 比较了清晰 RDD 和模糊 RDD 中治疗分配概率的差异。

5. 识别定理

设 Y_i 为关注的结果变量。视 Z_i 为已分配的治疗，我们可以定义潜在结果 $\{D_i(1), D_i(0), Y_i(1), Y_i(0)\}$ 。
清晰 RDD 可以识别：

$$\tau_D(x_0) = \mathbb{E}\{D(1) - D(0) | X = x_0\}$$

和

$$(147) \quad \tau_Y(x_0) = \mathbb{E}\{Y(1) - Y(0) | X = x_0\}.$$

使用 Z 作为 D 的工具变量，并施加工具变量假设（在 $X = x_0$ 邻域内），我们可以通过应用定理来识别局部依从者平均因果效应（Local Complier Average Causal Effect, LATE）。

定理 30.1 (模糊 RDD 识别). 设治疗由 $Z = I(X \geq x_0)$ 决定，其中 x_0 是预定的阈值。

假设**单调性**：

$$(148) \quad D_i(1) \geq D_i(0),$$

和**排除限制**：

$$(149) \quad D_i(1) = D_i(0) \implies Y_i(1) = Y_i(0),$$

在 x_0 的无穷小邻域内成立。

连续性假设： $E\{D(1) | X = x\}$ 和 $E\{Y(1) | X = x\}$ 在 $x = x_0$ 处右连续， $E\{D(0) | X = x\}$ 和 $E\{Y(0) | X = x\}$ 在 $x = x_0$ 处左连续。

局部依从者平均因果效应（Local Average Treatment Effect, LATE）定义为：

$$(150) \quad \tau_{\text{LATE}}(x_0) = \mathbb{E}\{Y(1) - Y(0) | D(1) > D(0), X = x_0\},$$

可以由下式识别：

$$(151) \quad \tau_{\text{LATE}}(x_0) = \frac{\mathbb{E}\{Y(1) - Y(0) | X = x_0\}}{\mathbb{E}\{D(1) - D(0) | X = x_0\}}.$$

如果 $E(D | X = x)$ 在 $x = x_0$ 处有非零跳跃，则局部依从者平均因果效应可以由下式识别：

$$(152) \quad \tau_{\text{LATE}}(x_0) = \frac{\lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y | Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(Y | Z = 0, X = x_0 - \varepsilon)}{\lim_{\varepsilon \rightarrow 0+} \mathbb{E}(D | Z = 1, X = x_0 + \varepsilon) - \lim_{\varepsilon \rightarrow 0+} \mathbb{E}(D | Z = 0, X = x_0 - \varepsilon)}.$$

定理 定义 30.1 的直觉：这是清晰 RDD 识别和工具变量识别定理的叠加。分子是 (147)，分母是 (5)。两者相除，得到依从者亚组的平均因果效应。

识别策略的核心思想：在模糊 RDD 中，我们不再假设治疗由运行变量完全决定，而是假设工具变量 Z 通过影响治疗概率来间接影响结果。这与标准 IV 框架的区别在于：IV 假设在断点的邻域内成立，而不是对全体样本成立。

FIGURE 2. 重分析 ? 的数据, TSLS 的点估计和标准误

FIGURE 3. 重分析 ? 的数据, TSLS 的点估计和标准误

6. 估计方法

6.1. 偏误-方差权衡. 在清晰和模糊 RDD 中, 核心问题都是指定断点周围的邻域。实际中:

- 较小的邻域导致较小的偏误, 但较大的方差
- 较大的邻域导致较大的偏误, 但较小的方差

这就是经典的**偏误-方差权衡** (bias-variance trade-off)。一些自动选择带宽的程序存在, 但它们依赖较强的条件。对一系列邻域选择进行敏感性分析似乎更为明智。

6.2. 间接最小二乘估计. 假设我们已指定由带宽 h 确定的 x_0 邻域。对于 $X_i \in [x_0 - h, x_0 + h]$ 的数据, 我们可以通过以下两步估计 $\tau_{\text{LATE}}(x_0)$:

第一步: 估计第一阶段关系

$$\hat{\tau}_D(x_0) = \text{the coefficient of } Z_i \text{ in the OLS fit of } D_i \text{ on } \{1, Z_i, R_i, L_i\},$$

其中 $R_i = \max(X_i - x_0, 0)$, $L_i = \min(X_i - x_0, 0)$ 。

第二步: 估计约简型关系

$$\hat{\tau}_Y(x_0) = \text{the coefficient of } Z_i \text{ in the OLS fit of } Y_i \text{ on } \{1, Z_i, R_i, L_i\}.$$

第三步: 计算比率

$$\hat{\tau}_{\text{LATE}}(x_0) = \hat{\tau}_Y(x_0) / \hat{\tau}_D(x_0).$$

这被称为**间接最小二乘估计器** (Indirect Least Squares Estimator, ILS)。根据定理, ILS 估计器数值上等同于:

$$\text{the coefficient of } D_i \text{ in the TSLS fit of } Y_i \text{ on } \{1, D_i, R_i, L_i\}$$

with D_i instrumented by Z_i 。

总之, 在指定 h 后, $\tau_{\text{LATE}}(x_0)$ 的估计归结为断点邻域内的两阶段最小二乘 (TSLS) 程序。

7. 数据应用

7.1. 印度农村道路数据. 重温 例 30.1。我们可以基于结果 `occupation_index_andrsn` 计算一系列 h 的点估计和标准误。

fig. 2 展示了结果。除非 h 很大, 否则治疗效应不显著。

7.2. 意大利大学助学金数据. 重温 例 30.2。运行变量定义为 15,000 减去标准化家庭收入。分析中将数据限制在 $[-5000, 5000]$ 的子集, 然后除以 5000 使运行变量有界于 $[-1, 1]$ 。

fig. 3 展示了结果, 表明大学助学金对辍学率没有显著影响。

8. 讨论

第 26 章和本章都将断点回归建立在给定运行变量时潜在结果条件期望的连续性之上。这个视角在数学上更简单，但它只能精确识别运行变量断点处的局部效应。？开创了这一研究路线。

另一种不那么主流的视角基于**局部随机化** (local randomization)。[??]。如果我们视运行变量为某种底层真实值的噪声测量，而断点有些任意地选择，那么断点附近的单元在系统上并没有差异。这表明在断点的较小邻域内，单元以随机方式接受治疗和控制——就像在随机实验中一样。

与清晰 RDD 的选择邻域问题类似，在局部随机化视角下，决定随机实验应该有多“局部”也是至关重要的。将这种直觉数学量化并不容易，因此对一系列带宽 h 进行敏感性分析似乎也是第二种视角下的合理方法。

？提供了断点回归的概念性讨论。

9. 本章小结

本章的核心要点：

- (1) **模糊断点回归**：治疗概率在断点处跳跃，但不像清晰 RDD 那样由运行变量完全决定
- (2) **识别策略**：将 $Z = I(X \geq x_0)$ 作为工具变量，在单调性和排除限制下识别 LATE
- (3) **估计方法**：间接最小二乘 (ILS) 或两阶段最小二乘 (TSLS)
- (4) **偏误-方差权衡**：带宽选择是关键——较小的邻域偏误小但方差大
- (5) **与清晰 RDD 的关系**：模糊 RDD 是清晰 RDD 和 IV 方法的结合

下一章我们将学习**局部随机化视角下的断点回归**，这为 RDD 提供了另一种理论依据。

10. 习题

练习 30.1. 30.1 模糊 RDD 识别定理的证明 证明 定义 30.1 中的识别公式。

练习 30.2. 30.2 清晰 RDD 与模糊 RDD 的比较

- (1) 在清晰 RDD 中，治疗分配 D 和工具变量 Z 有什么关系？
- (2) 在模糊 RDD 中，这种关系如何变化？
- (3) 给出清晰 RDD 和模糊 RDD 各一个现实生活中的例子。

练习 30.3. 30.3 带宽敏感性分析 对于 section 7.1 中的印度道路数据，使用不同的带宽 h 进行敏感性分析。报告点估计和标准误如何随 h 变化。

练习 30.4. 30.4 ILS 与 TSLS 的等价性 证明在模糊 RDD 中，间接最小二乘估计器（比率形式）和两阶段最小二乘估计器在数值上是等价的。

孟德尔随机化

1. 引言：遗传学与因果推断的交汇

在第 27 章和第 ?? 章中，我们看到了工具变量 (IV) 方法如何帮助解决观测性研究中的未测量混杂问题。然而，传统 IV 方法面临一个根本困难：找到一个有效的工具变量谈何容易。研究者需要确信这个变量满足三个关键条件——与治疗变量相关、不与未测量混杂相关、以及仅通过治疗变量影响结果。

20 世纪 80 年代，一位名叫 Katan 的研究者 [?] 提出了一个颇具洞察力的观点：也许遗传变异能够充当天然的工具变量。他的论证基于孟德尔的第二定律——独立分配定律 (law of random assortment)，该定律表明一种性状的遗传独立于其他性状的遗传。这意味着，如果我们能找到与某个暴露因素（如胆固醇水平）相关的基因变异，同时这些变异与混杂暴露因素与结果之间关系的未测量混杂因子相互独立，那么这些基因变异就可能成为一个有效的工具变量。

这一思想在流行病学研究中引发了革命性的变革。2003 年，Davey Smith 和 Ebrahim [?] 将这种方法正式命名为**孟德尔随机化 (Mendelian Randomization, MR)**。如今，MR 已成为流行病学中估计暴露因素对结果因果效应的核心方法 [?]

本章的核心问题：如何利用遗传变异作为工具变量来估计因果效应？这种方法的假设是什么？又有哪些局限性？

2. 背景与动机

2.1. 从胆固醇到癌症：一个经典难题。在深入技术细节之前，让我们先理解 MR 最初被提出时的动机。20 世纪 80 年代的观测性研究暗示，低血清胆固醇水平可能与癌症风险相关。然而，这样的观察性研究面临两个根本性问题：

- (1) **未测量的混杂：**胆固醇水平和癌症之间可能存在共同的未测量混杂因素，例如饮食模式或社会经济地位。
- (2) **反向因果：**更棘手的是，癌症的早期阶段可能反过来导致低血清胆固醇水平，即因果方向可能与假设的相反。

Katan [?] 指出，Apolipoprotein E 基因与血清胆固醇水平相关，但（理论上）不直接影响癌症状态。因此，如果我们能比较携带不同基因型的人群在癌症风险上的差异，就能区分因果效应和混杂/反向因果。这一论证与我们在第 27 章讨论的 IV 框架完美契合。

2.2. MR 的因果图。图 1 展示了一个典型 MR 研究的因果结构。

在许多 MR 研究中，遗传工具变量是**单核苷酸多态性 (single nucleotide polymorphisms, SNPs)**。由于**多效性 (pleiotropy)** 的存在，遗传工具变量有可能直接影响结果，因此图 1 中允许违反排他性限制假设的情况。

3. 线性 IV 模型回顾

在介绍 MR 的统计方法之前，我们需要回顾第 ?? 章中的线性 IV 模型。这里我们显式地引入未测量混杂因子 U ，这在 MR 背景下尤为重要。




FIGURE 1. MR 因果图: G_j 为遗传变异 (工具变量), D 为暴露因素, Y 为结果, U 为未测量的混杂因子, 虚线箭头表示 G_j 可能违反排他性限制的直接效应。

3.1. 标准线性 IV 模型 (满足排他性限制).

定义 31.1 (标准线性 IV 模型). 结构形式为:

$$(25.1) \quad Y = \beta_0 + \beta D + \beta_u U + \varepsilon_Y,$$

$$(25.2) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

约简形式为:

$$(25.3) \quad Y = (\beta_0 + \beta\gamma_0) + \beta\gamma_1 G_1 + \cdots + \beta\gamma_p G_p + (\beta_u + \beta\gamma_u)U + \varepsilon_Y,$$

$$(25.4) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

在排他性限制下, G_j 对 Y 没有直接效应, 因此 $\Gamma_j = \beta\gamma_j$ ($j = 1, \dots, p$).

3.2. 允许违反排他性限制的模型. 在 MR 研究中, 由于多效性的存在, 排他性限制可能不成立。因此我们需要允许遗传工具变量直接作用于结果。

定义 31.2 (可能无效的工具变量模型). 线性模型为:

$$(25.5) \quad Y = \beta_0 + \beta D + \alpha_1 G_1 + \cdots + \alpha_p G_p + \beta_u U + \varepsilon_Y,$$

$$(25.6) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

约简形式为:

$$(25.7) \quad Y = (\beta_0 + \beta\gamma_0) + (\alpha_1 + \beta\gamma_1)G_1 + \cdots + (\alpha_p + \beta\gamma_p)G_p + (\beta_u + \beta\gamma_u)U + \varepsilon_Y,$$

$$(25.8) \quad D = \gamma_0 + \gamma_1 G_1 + \cdots + \gamma_p G_p + \gamma_u U + \varepsilon_D.$$

在这种情况下, $\Gamma_j = \alpha_j + \beta\gamma_j$ ($j = 1, \dots, p$)。如果 $\alpha_j \neq 0$, 则 G_j 是无效的工具变量。

注 31.1. 定义 31.1 和 31.2 与第 ?? 章的线性 IV 模型略有不同——我们显式包含了未测量混杂因子 U 。但这一差异本质上不影响讨论, 因为 U 在约简形式中通过 $\beta_u + \beta\gamma_u$ 被合并到系数中。

4. 基于汇总统计的 MR 分析

4.1. MR 研究的数据结构. 传统的 IV 估计需要个体水平的数据。然而, 大多数 MR 研究并没有个体数据, 而是从多个全基因组关联研究 (genome-wide association studies, GWAS) 中获取**汇总统计 (summary statistics)**。一个典型的 MR 研究具有以下数据结构。

假设 31.1 (基于汇总统计的 MR 研究). (1) 我们有治疗变量对遗传工具变量的回归系数 $\hat{\gamma}_1, \dots, \hat{\gamma}_p$ 及其标准误 $\text{se}_{D1}, \dots, \text{se}_{Dp}$ 。假设

$$(25.9) \quad \hat{\gamma}_1 \xrightarrow{p} \gamma_1, \dots, \hat{\gamma}_p \xrightarrow{p} \gamma_p$$

并忽略标准误的不确定性。

(2) 我们有结果变量对遗传工具变量的回归系数 $\hat{\Gamma}_1, \dots, \hat{\Gamma}_p$ 及其标准误 $\text{se}_{Y1}, \dots, \text{se}_{Yp}$ 。假设

$$(25.10) \quad \hat{\Gamma}_1 \xrightarrow{p} \Gamma_1, \dots, \hat{\Gamma}_p \xrightarrow{p} \Gamma_p$$

并忽略标准误的不确定性。

(3) 假设 $\hat{\gamma}_1, \dots, \hat{\gamma}_p, \hat{\Gamma}_1, \dots, \hat{\Gamma}_p$ 联合服从正态分布且相互独立。

回归系数的渐近正态性可由中心极限定理保证。标准误在大样本中是真实标准误的准确估计。因此, 唯一微妙的假设是回归系数之间的联合独立性。 $\hat{\gamma}_j$ 与 $\hat{\Gamma}_j$ 之间的独立性是合理的, 因为它们通常基于不同的样本计算。

4.2. 固定效应估计量. 在定义 31.1 (满足排他性限制) 的假设下, $\alpha_j = 0$, 这意味着 $\beta = \Gamma_j/\gamma_j$ 对所有 j 成立。一个简单的方法基于所谓的**元分析 (meta-analysis)**——即结合多个估计量 $\hat{\beta}_j = \hat{\Gamma}_j/\hat{\gamma}_j$ 来估计共同参数 β , 这种方法也被称为**固定效应 (fixed effect)** 估计。

使用 delta 方法 (见假设 31.1), 比值估计量 $\hat{\beta}_j$ 的近似标准误为:

$$(25.11) \quad \text{se}_j^2 = (\text{se}_{Yj}^2 + \hat{\beta}_j^2 \text{se}_{Dj}^2) / \hat{\gamma}_j^2.$$

因此, 估计 β 的最佳线性组合是基于方差倒数加权的 Fisher 估计 (见练习题):

$$(25.12) \quad \hat{\beta}_{\text{fisher0}} = \frac{\sum_{j=1}^p \hat{\beta}_j / \text{se}_j^2}{\sum_{j=1}^p 1 / \text{se}_j^2},$$

其方差为 $\left(\sum_{j=1}^p 1 / \text{se}_j^2\right)^{-1}$ 。

忽略 $\hat{\gamma}_j$ 由 se_{Dj} 量化的不确定性, 估计量简化为:

$$(25.13) \quad \hat{\beta}_{\text{fisher1}} = \frac{\sum_{j=1}^p \hat{\beta}_j \hat{\gamma}_j^2 / \text{se}_{Yj}^2}{\sum_{j=1}^p \hat{\gamma}_j^2 / \text{se}_{Yj}^2} = \frac{\sum_{j=1}^p \hat{\Gamma}_j \hat{\gamma}_j / \text{se}_{Yj}^2}{\sum_{j=1}^p \hat{\gamma}_j^2 / \text{se}_{Yj}^2},$$

其方差为 $\left(\sum_{j=1}^p \hat{\gamma}_j^2 / \text{se}_{Yj}^2\right)^{-1}$ 。虽然次优, 但 $\hat{\beta}_{\text{fisher1}}$ 在实践中应用更广泛 [?].

在定义 31.2 (允许无效工具变量) 的假设下, 我们可以证明:

$$(25.14) \quad \hat{\beta}_{\text{fisher1}} \xrightarrow{p} \frac{\sum_{j=1}^p \Gamma_j \gamma_j / \text{se}_{Yj}^2}{\sum_{j=1}^p \gamma_j^2 / \text{se}_{Yj}^2} = \beta + \frac{\sum_{j=1}^p \alpha_j \gamma_j / \text{se}_{Yj}^2}{\sum_{j=1}^p \gamma_j^2 / \text{se}_{Yj}^2}.$$

如果对所有 j 都有 $\alpha_j = 0$, 则 $\hat{\beta}_{\text{fisher1}}$ 是一致的。即使这不成立, 只要 α_j 与 γ_j 的内积按 $1/\text{se}_{Yj}^2$ 加权为零, $\hat{\beta}_{\text{fisher1}}$ 仍可能是一致的。

注 31.2. 当有许多遗传工具变量, 且违反排他性限制 (由 α_j 捕获) 是来自均值为零的分布的独立随机抽样时, 上述条件近似成立。

4.3. Egger 回归. 现在从定义 31.1 (满足排他性限制) 出发。在真实参数下, 我们有:

$$(25.15) \quad \Gamma_j = \beta\gamma_j \quad (j = 1, \dots, p).$$

用估计量替代时, 上述等式仅近似成立:

$$(25.16) \quad \hat{\Gamma}_j \approx \beta\hat{\gamma}_j \quad (j = 1, \dots, p).$$

这看似一个经典的最小二乘问题——将 $\{\hat{\Gamma}_j\}_{j=1}^p$ 对 $\{\hat{\gamma}_j\}_{j=1}^p$ 进行回归。我们可以拟合 $\hat{\Gamma}_j$ 对 $\hat{\gamma}_j$ 的加权最小二乘 (WLS), 有或无截距项, 可能按 w_j 加权, 以估计 β 。以下结果得益于第 ?? 章回顾的 WLS 代数性质。

无截距时, $\hat{\gamma}_j$ 的系数为:

$$(25.17) \quad \hat{\beta}_{\text{egger1}} = \frac{\sum_{j=1}^p \hat{\gamma}_j \hat{\Gamma}_j w_j}{\sum_{j=1}^p \hat{\gamma}_j^2 w_j},$$

当 $w_j = 1/\text{se}_{Y_j}^2$ 时, 这退化为 $\hat{\beta}_{\text{fisher1}}$ 。这种 WLS 被称为 **Egger 回归**, 它比第 4.2 节的固定效应估计量更一般。

有截距时, $\hat{\gamma}_j$ 的系数为:

$$(25.18) \quad \hat{\beta}_{\text{egger0}} = \frac{\sum_{j=1}^p (\hat{\gamma}_j - \hat{\gamma}_w)(\hat{\Gamma}_j - \hat{\Gamma}_w)w_j}{\sum_{j=1}^p (\hat{\gamma}_j - \hat{\gamma}_w)^2 w_j},$$

其中 $\hat{\gamma}_w = \sum_{j=1}^p \hat{\gamma}_j w_j / \sum_{j=1}^p w_j$ 和 $\hat{\Gamma}_w = \sum_{j=1}^p \hat{\Gamma}_j w_j / \sum_{j=1}^p w_j$ 分别是 $\hat{\gamma}_j$ 和 $\hat{\Gamma}_j$ 的加权平均值。

即使不假设所有 γ_j 为零 (定义 31.2), 我们也有:

$$(25.19) \quad \hat{\beta}_{\text{egger0}} \xrightarrow{p} \frac{\sum_{j=1}^p (\gamma_j - \gamma_w)(\Gamma_j - \Gamma_w)w_j}{\sum_{j=1}^p (\gamma_j - \gamma_w)^2 w_j} = \beta + \frac{\sum_{j=1}^p (\gamma_j - \gamma_w)(\alpha_j - \alpha_w)w_j}{\sum_{j=1}^p (\gamma_j - \gamma_w)^2 w_j},$$

其中 γ_w, Γ_w 和 α_w 是相应真实参数的加权平均值。

因此, $\hat{\beta}_{\text{egger0}}$ 一致地估计 β , 只要 α_j 对 γ_j 的 WLS 系数为零。这比 $\alpha_j = 0$ (对所有 j) 的假设更弱。当 γ_j 和 α_j 是独立随机变量的实现值时, 这个较弱的假设成立, 这被称为**工具强度独立于直接效应 (Instrument Strength Independent of Direct Effect, InSIDE) 假设** [?].

更有趣的是, Egger 回归的截距:

$$(25.20) \quad \hat{\alpha}_{\text{egger0}} = \hat{\Gamma}_w - \hat{\beta}_{\text{egger0}}\hat{\gamma}_w,$$

在 InSIDE 假设下收敛到:

$$(25.21) \quad \Gamma_w - \beta\gamma_w = \alpha_w,$$

即直接效应的加权平均值。因此, 截距估计了直接效应的加权平均。

5. 实例分析

本节使用 `mr.raps` 包中的 `bmi.sbp` 数据 [?] 来说明 Fisher 加权估计和 Egger 回归的实际应用。

5.1. Fisher 加权估计. 首先, 以下函数实现了 Fisher 加权:

```
fisher.weight = function(est, se)
{
  n = sum(est/se^2)
  d = sum(1/se^2)
  res = c(n/d, sqrt(1/d))
  names(res) = c("est", "se")
  res
}
```

使用该函数对 BMI-SBP 数据进行分析, 基于 $\hat{\beta}_{\text{fisher0}}$ 和 $\hat{\beta}_{\text{fisher1}}$ 的结果非常接近:

```
> fisher.weight(bmisbp$iv, bmisbp$se.iv)
      est      se
0.31727680 0.05388827
> fisher.weight(bmisbp$iv, bmisbp$se.iv1)
      est      se
0.31576007 0.05893783
```

5.2. Egger 回归. 带截距或不带截距的 Egger 回归也给出了非常相似的结果, 但标准误与 Fisher 加权估计的结果差异很大:

```
> mr.egger = lm(beta.output ~ 0 + beta.exposure,
+ data = bmisbp, weights = 1/se.output^2)
> summary(mr.egger)$coef
              Estimate Std. Error t value Pr(>|t|)
beta.exposure 0.3172768  0.1105994  2.868704 0.004681659

> mr.egger.w = lm(beta.output ~ beta.exposure,
+ data = bmisbp, weights = 1/se.output^2)
> summary(mr.egger.w)$coef
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 0.0001133328 0.002079418 0.05450217 0.956603931
beta.exposure 0.3172989306 0.110948506 2.85987564 0.004811017
```

图 2 展示了原始数据以及带截距的 Egger 回归拟合线。

$\hat{\gamma}_j \hat{\Gamma}_j$ 数据点回归线

FIGURE 2. 按方差倒数加权的散点图及 Egger 回归线。

6. MR 分析的批评与局限

MR 是 IV 方法思想的应用。它依赖于强有力的假设。我从概念、生物学和技术三个层面提供三组批评。

6.1. 概念层面的批评. 从潜在结果的角度看, 大多数 MR 研究中的治疗变量定义并不明确。例如, 治疗通常被定义为胆固醇水平或 BMI。这些是复合变量, 可能对应复杂且非唯一的假设实验定义。SUTVA (稳定单元治疗值假设) 在这些治疗变量上往往不成立。回想第 ?? 章的讨论。

6.2. 生物学层面的批评. IV 分析的基本假设可能不成立。孟德尔的第二定律确保了不同性状的遗传是独立的。然而，它并不能确保候选工具变量与治疗 and 结果之间的未测量混杂因子相互独立。这些工具变量可能直接影响混杂因子。同样，某些未测量基因可能同时影响工具变量和混杂因子。孟德尔的第二定律也不能确保排他性限制假设——工具变量有可能通过治疗感兴趣变量之外的途径影响结果。

6.3. 技术层面的批评. MR 的统计假设相当强。线性 IV 模型是一个强假设。 $\hat{\gamma}_j$ 与 $\hat{\Gamma}_j$ 的独立性也相当强。数据收集过程中的其他问题可能进一步复杂化对 IV 假设的解释。例如，治疗 and 结果通常存在测量误差，而且全基因组关联研究通常基于条件于结果的病例对照设计（见第 ?? 章）。

VanderWeele 等 (2014) 是讨论 MR 方法论挑战的优秀综述论文。

7. 习题

练习 31.1. 31.1 Fisher 加权估计的推导 证明第 4.2 节中 $\hat{\beta}_{\text{fisher0}}$ 的方差为 $\left(\sum_{j=1}^p 1/\text{se}_j^2\right)^{-1}$ 。
提示：利用 $\hat{\beta}_j$ 的独立性。

练习 31.2. 31.2 InSIDE 假设的含义 解释 InSIDE（工具强度独立于直接效应）假设在什么意义上弱于 $\alpha_j = 0$ （对所有 j ）的排他性限制假设。给出一个满足 InSIDE 但不满足 $\alpha_j = 0$ 的数值例子。

练习 31.3. 31.3 Egger 截距的解释 在第 4.3 节中，我们看到 Egger 回归的截距 $\hat{\alpha}_{\text{egger0}}$ 收敛到直接效应的加权平均 α_w 。讨论为什么这个性质在实践中有用——即为什么我们可能关心估计 α_w 而不仅仅是 β 。

练习 31.4. 31.4 数据分析 分析 `mr.raps` 包中的 `bmi.bmi` 数据。参见 ?, 第 7.2 节 了解更多细节。

推荐阅读

- ? 综述了 MR 的潜力和局限性，是该领域的经典文献。
- ? 提出了 Egger 回归方法来检测和调整无效工具变量。
- ? 开发了基于鲁棒调整轮廓得分（robust adjusted profile score, RAPS）的两样本汇总数据 MR 推断方法。

Bibliography

双重差分：利用面板数据的结构识别因果效应

1. 引言：一个看似简单的问题

考虑一个政策评估的常见场景：某市政府在 2020 年对某区企业实施了一项税收优惠政策。我们想知道这项政策是否促进了就业增长。

一个朴素的思路是：比较政策实施前后该区的就业变化。例如，若 2019 年就业人数为 1000，2021 年为 1200，则增长 20%，似乎说明政策有效。

然而，这个推理存在一个根本性的缺陷：**时间趋势本身可能导致就业变化**。即使没有税收优惠，经济周期、技术进步、产业迁移等因素也可能导致就业的自然波动。换言之，我们观察到的变化可能是政策效果，也可能是时间趋势的结果——两者无法分离。

这个困境促使我们思考：能否利用**面板数据**（panel data，即同一组单元在多个时间点的观测数据）的结构，在一定程度上消除时间趋势的干扰，从而更准确地识别政策效果？

双重差分（Difference-in-Differences, DiD）正是为解决这一问题而诞生的方法。其核心思想朴素而深刻——同时利用**组间比较**和**时间比较**，通过两次差分消除时间趋势的影响。

2. 基本设定：2×2 情形

2.1. 研究设计与记号. 考虑一个最简单的 DiD 设定：有两组单元（处理组和对照组）和两个时间点（政策实施前和政策实施后）。记

- $G_i \in \{0, 1\}$: 单元 i 的组别， $G_i = 1$ 表示处理组， $G_i = 0$ 表示对照组
- $T_t \in \{0, 1\}$: 时间， $T_t = 0$ 表示政策实施前（基期）， $T_t = 1$ 表示政策实施后
- Y_{it} : 单元 i 在时间 t 的观测结果
- $D_i = G_i$: 处理指示变量（假设政策实施后处理组收到处理，对照组未处理）

我们有 N 个单元的下标 $i = 1, \dots, N$ ，其中处理组有 N_1 个单元，对照组有 N_0 个单元（ $N_1 + N_0 = N$ ）。

关键假设：潜在结果框架。 对每个单元 i 和每个时间 t ，定义潜在结果：

$$Y_{it}(1) \quad \text{和} \quad Y_{it}(0)$$

分别表示如果收到处理和未收到处理时单元 i 在时间 t 的结果。观测结果由下式给出：

$$Y_{it} = Y_{it}(0) + D_i(Y_{it}(1) - Y_{it}(0)).$$

att 的定义。 处理组在时间 t 的平均处理效应（Average Treatment effect on the Treated, ATT）为：

$$\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) \mid G_i = 1).$$

2.2. 基本 DiD 估计量. 考虑以下四个总体均值：

$$\bar{Y}_{00} = \mathbb{E}(Y_{it} \mid G_i = 0, T_t = 0) \text{ (对照组, 政策前)}$$

$$\bar{Y}_{01} = \mathbb{E}(Y_{it} \mid G_i = 0, T_t = 1) \text{ (对照组, 政策后)}$$

$$\bar{Y}_{10} = \mathbb{E}(Y_{it} \mid G_i = 1, T_t = 0) \text{ (处理组, 政策前)}$$

$$\bar{Y}_{11} = \mathbb{E}(Y_{it} \mid G_i = 1, T_t = 1) \text{ (处理组, 政策后)}$$

第一次差分：组内时间差分。

处理组的时间差分为 $\bar{Y}_{11} - \bar{Y}_{10}$ ，包含两部分：

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\tau_1}_{\text{政策效果}} + \underbrace{[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)]}_{\text{时间趋势造成的变化}},$$

其中 $\bar{Y}_{1t}(0) = \mathbb{E}(Y_{it}(0) \mid G_i = 1, T_t = t)$ 表示处理组若未受处理在时间 t 的潜在结果均值。

类似地，对照组的时间差分为 $\bar{Y}_{01} - \bar{Y}_{00}$ ，这一差分完全由时间趋势驱动（因为对照组未受处理）：

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{10}(0) - \bar{Y}_{11}(0).$$

第二次差分：组间差分消除时间趋势。

将处理组的时间差分减去对照组的时间差分：

$$\underbrace{(\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})}_{\text{双重差分}} = \tau_1 + \underbrace{[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)]}_{\text{时间趋势}} - \underbrace{[\bar{Y}_{10}(0) - \bar{Y}_{11}(0)]}_{\text{时间趋势}}.$$

时间趋势项被消去了！我们得到：

$$\text{DiD} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) = \tau_1.$$

这意味着，在**平行趋势假设**（见下节）下，双重差分恰好识别出了处理组的平均处理效应 ATT。

DiD 估计量可以写成更直观的形式：

$$\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) = (\bar{Y}_{11} - \bar{Y}_{01}) - (\bar{Y}_{10} - \bar{Y}_{00}).$$

核心公式（式 section 2.2）：

$$\hat{\tau}_{\text{DiD}} = \underbrace{(\bar{Y}_{11} - \bar{Y}_{01})}_{\text{处理组的时间变化}} - \underbrace{(\bar{Y}_{10} - \bar{Y}_{00})}_{\text{对照组的时间变化}}.$$

第一项是处理组政策前后的结果均值之差；第二项是对照组政策前后的结果均值之差。两项相减，即消除了时间趋势。

3. 平行趋势假设

DiD 方法的核心假设是**平行趋势假设**（Parallel Trends Assumption）：

假设 32.1（平行趋势假设）. 在没有处理的情况下，处理组和对照组的结果随时间变化的趋势相同，即

$$\mathbb{E}(Y_{i1}(0) - Y_{i0}(0) \mid G_i = 1) = \mathbb{E}(Y_{i1}(0) - Y_{i0}(0) \mid G_i = 0).$$

Equivalently,

$$\bar{Y}_{10}(0) - \bar{Y}_{11}(0) = \bar{Y}_{00} - \bar{Y}_{01}.$$

这个假设的含义是：**若两组都未受处理，它们结果的时间变化模式应完全相同**^{**}。换言之，处理组和对照组之间的差异仅仅是组间固定效应，而不存在特异性的时间趋势。

3.1. 为何称为“平行”趋势. 图示可以帮助理解这一假设。假设横轴为时间，纵轴为结果。在平行趋势假设下，处理组和对照组的结果轨迹在政策实施前是两条斜率相同的平行直线；政策实施后，处理组的轨迹发生跳跃，而对照组继续沿原趋势发展。DiD 正是利用政策实施前后的信息，估计这个“跳跃”的大小。

在数学上，若假设结果对数形式为线性趋势：

$$Y_{it}(0) = \alpha + \beta \cdot G_i + \gamma \cdot t + \varepsilon_{it},$$

则处理组和对照组的时间趋势相同（均为 γ ），平行趋势假设自动成立。

3.2. 无法被数据验证的假设. 重要警示：平行趋势假设是无法从数据中直接验证的——因为我们永远无法同时观测到处理组的“反事实”（若未受处理会怎样）。这使得 DiD 本质上是一个**半参数识别**问题：识别依赖于研究者对趋势函数形式的额外假设。

实践中，研究者通常会：

- (1) 检验政策实施前的处理组和对照组趋势是否平行（“0300pre-trend test”）；
- (2) 展示多个政策实施前的时期，确认趋势的稳定性；
- (3) 使用安慰剂检验（placebo test），将政策实施时间人为提前，看是否仍能识别出效应。

这些检验并非平行趋势假设的证明，而只是提供间接证据。

4. 回归框架与标准误差

DiD 估计量可以通过回归方法方便地实现。考虑以下双向固定效应（Two-Way Fixed Effects, TWFE）模型：

$$Y_{it} = \alpha + \beta \cdot D_{it} + \gamma_i + \delta_t + \varepsilon_{it},$$

其中：

- $D_{it} = G_i \cdot T_t$ 为处理指示变量（组别 $\times$ 时间的交互项）
- γ_i 为个体固定效应（控制组间差异）
- δ_t 为时间固定效应（控制共同的时间趋势）

在这个模型中， β 就是 DiD 估计量，它等于处理组的时间变化减去对照组的时间变化，即式 section 2.2 中的 $\hat{\tau}_{\text{DiD}}$ 。

关于标准误差。在面板数据回归中，标准误差的估计需要考虑以下问题：

- **聚类标准误差 (Clustered Standard Errors)**：同一单元的观测值可能存在自相关，建议按单元聚类
- **Driscoll-Kraay 标准误差**：当时间维度较大且存在潜在的面板相关结构时
- **Bootstrap**：在小样本情况下，参数自举法可能更可靠

5. 拓展：异质性处理效应

5.1. 交互形式.标准的 TWFE 回归 section 4 假设处理效应在所有单元和时间上都是恒定的（ β 不随 i 或 t 变化）。然而，在实际研究中，处理效应很可能随单元特征或时间而变化。

考虑**异质性处理效应**的情形。记处理效应为 $\tau_{it} = \mathbb{E}(Y_{it}(1) - Y_{it}(0))$ ，它可能依赖于单元 i 或时间 t 。

Angrist and Pischke [?] 指出，当处理效应存在异质性时，标准的 TWFE 估计量识别的是一种 ** 处理效应分布的加权均值 **，而非简单的 ATT。这一加权结构可能产生难以解释的估计量，甚至在外推含义上产生偏误。

警告（异质性处理效应下 TWFE 的陷阱）：当不同单元的处理效应不同时，TWFE 回归中的 β 不再简单等于 ATT。它可能混合了处理组和未处理组中不同处理效应分布的特征，导致估计量难以解释。详见 ? 的讨论。

5.2. 多期 DiD. 当有多个时间点时，DiD 可以推广到 ** 多期情形 **。设 $T_t \in \{0, 1, \dots, T\}$ ，则处理指示变量 $D_{it} = G_i \cdot \mathbb{I}(t \geq t^*)$ ，其中 t^* 为政策实施时间。

多期 DiD 的 TWFE 回归为：

$$Y_{it} = \alpha_i + \delta_t + \sum_{t=0}^T \beta_t \cdot D_{it} + \varepsilon_{it},$$

其中 β_t 捕捉了政策实施后各时期的处理效应（通常以政策实施前一期为基准期，令其效应为零）。

事件研究图（Event Study Plot） 是展示多期 DiD 结果的标准方法——将 β_t 对时间作图，政策实施前的系数应接近零（提供平行趋势的间接证据），政策实施后的系数应反映处理效应的大小和动态变化。

6. 本章小结

双重差分（DiD）是政策评估领域最常用的因果推断方法之一。其核心思想利用面板数据的结构，通过两次差分消除时间趋势的影响，从而识别处理组的平均因果效应。

DiD 的成功依赖于**平行趋势假设**——在没有处理的情况下，处理组和对照组的结果趋势应相同。这一假设本质上无法从数据中直接验证，只能通过间接检验（如 pre-trend 检验、安慰剂检验）提供支持证据。

DiD 方法已从最初的 2×2 情形发展到成熟的多期、双向固定效应框架。然而，当处理效应存在异质性时，标准的 TWFE 估计可能产生难以解释的加权平均效应，这是近年来方法论研究的重要关注点。

7. 延伸阅读

关于 DiD 的经典参考文献包括：

- ?：《Mostly Harmless Econometrics》，第 5 章系统介绍了 DiD 的理念和实践
- ?：DiD 方法的早期经典应用，研究最低工资对就业的影响
- ?：关于异质性处理效应下 TWFE 估计量的最新讨论
- ?：提出诊断和处理 TWFE 中异质性处理效应的方法

附录 section 12 包含 DiD 估计量的详细推导和 Bootstrap 标准误差的计算步骤。

中介分析：自然直接效应与自然间接效应

1. 本章导论：一个古老的追问

当我们说“吸烟导致肺癌”时，这个说法究竟意味着什么？

一方面，烟草中的有害物质可能直接作用于细胞，引发癌变；另一方面，吸烟可能通过影响其他生理指标——比如血压、免疫力或慢性炎症——进而间接地增加患癌风险。这两种机制，本质上完全不同：一种是直接杀伤，另一种是通过一连串中间步骤传导的**间接效应**。

理解因果效应的这种**传导机制** (transmission mechanism)，是科学研究的核心关切之一。生物医学研究者想知道某种药物是通过什么生化通路发挥作用的；社会学家想知道贫困是通过什么社会机制影响健康结果的；政策制定者想知道一项教育改革是直接改善了学生能力，还是通过改变学校资源配置间接起效。**中介分析** (mediation analysis) 正是回答这类问题的统计框架。

本章的组织如下。我们首先通过具体实例说明中介分析的应用场景；然后引入**嵌套潜在结果** (nested potential outcomes) 的数学框架；接着建立识别中介效应的**中介公式** (mediation formula)；最后在线性模型下推导出经典的 **Baron-Kenny 公式**，并讨论其敏感性分析。

2. 从总效应到直接效应与间接效应

在中介分析的框架中，我们有四个核心变量：处理 Z (treatment)、结果 Y (outcome)、中介 M (mediator) 以及背景协变量 X (covariates)。它们之间的因果关系可以直观地用有向无环图 (DAG) 表示 (??)。

核心问题：总的因果效应 τ 中，有多少是通过中介变量 M 传导的 (**间接效应**)，有多少是不经过 M 的 (**直接效应**)？

以下三个真实研究场景可以帮助我们理解中介分析的应用。

例 33.1 (遗传变异与肺癌：通过吸烟的中介). (2012) 研究了染色体 15q25.1 上的遗传变异如何影响肺癌风险。¹ 该研究的核心问题是：遗传变异是通过影响吸烟行为 (吸烟量) 进而增加肺癌风险的，还是通过其他独立通路 (如直接影响肺部细胞) 直接致癌的？这就是一个典型的中介分析问题：遗传变异是处理 Z ，吸烟是中介 M ，肺癌是结果 Y 。

例 33.2 (邻里贫困与青少年物质使用：学校与同伴环境的中介). 等人 (2018) 研究了邻里贫困对青少年物质使用的影响，并探讨了这一影响是通过学校和同伴环境传导的。² 他们使用了美国国家共病调查 (National Comorbidity Survey) 的数据，将邻里贫困指数作为处理，青少年物质使用 (如饮酒、吸毒) 作为结果，而学校和同伴环境因素作为中介。

¹详见 ?。

²详见 ?。

例 33.3 (就业培训对心理健康：工作搜寻效能的中介). *JOBS II* 是一个关于就业培训对失业工人影响的现场实验。³ 该培训项目的目的不仅是提高再就业率，还希望改善求职者的心理健康。研究者感兴趣的是：培训对心理健康的效应中，有多少是通过提高工作搜寻效能这一中介传导的，又有多少是通过其他途径（如社会支持网络）直接产生的。⁴

3. 嵌套潜在结果

3.1. 潜在结果的两层结构. 为了定义直接效应与间接效应，我们需要引入**嵌套潜在结果** (nested potential outcomes) 这一概念。[?] 和 [?] 是这一理论的奠基人。

首先，考虑对处理 z 进行干预，定义对应的潜在中介和潜在结果：

$$\{M(z), Y(z) : z = 0, 1\}.$$

然后，考虑同时对 z 和 m 进行干预，定义：

$$\{Y(z, m) : z = 0, 1, m \in \mathcal{M}\},$$

其中 $\mathcal{M}$ 是中介所有可能的取值范围。

关键的一步是考虑**嵌套干预** (nested intervention)：将 z 设定为某个值，但将 m 设定为在另一个处理水平下的潜在中介值。记 $M_{z'} \equiv M(z')$ ，[?] 和 [?] 定义了嵌套潜在结果：

$$\{Y(z, M_{z'}) : z = 0, 1, z' = 0, 1\}.$$

其中 $Y(z, M_{z'})$ 表示：如果治疗被设定为 z ，而中介被设定为在治疗 z' 下的潜在值 $M_{z'}$ ，则结果会是什么。注意 z 和 z' 可以不同——这正是其“嵌套”之处。

在二值处理的设定下，我们有四个嵌套潜在结果：

$$\{Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)\}.$$

其中 $Y(1, M_1)$ 表示：如果治疗设为 $z = 1$ 且中介设为在 $z = 1$ 下的自然值，则结果如何。类似地， $Y(0, M_0)$ 表示治疗设为 $z = 0$ 且中介设为在 $z = 0$ 下的自然值的情形。

Composition 假设确保了嵌套潜在结果与标准潜在结果之间的一致性。

[Composition 假设] $Y(z, M_z) = Y(z)$ ，对 $z = 0, 1$ 成立。

Composition 假设是不可证明的，它本质上是一个假设。但在实践中，我们完全可以将 $Y(1)$ 定义为 $Y(1, M_1)$ ，将 $Y(0)$ 定义为 $Y(0, M_0)$ ，这样该假设就自动成立了。

现在，我们可以正式定义三种效应。

定义 33.1 (总效应、自然直接效应与自然间接效应). 总效应 (*total effect*) 定义为

$$\tau = \mathbb{E}\{Y(1) - Y(0)\}.$$

自然直接效应 (*natural direct effect, NDE*) 定义为

$$= \mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}.$$

自然间接效应 (*natural indirect effect, NIE*) 定义为

$$= \mathbb{E}\{Y(1, M_1) - Y(1, M_0)\}.$$

这三个效应的含义如下：

- **总效应** τ ：标准的平均因果效应，即治疗从 0 变到 1 对结果的平均影响。
- **NDE** $\mathbb{E}\{Y(1, M_0) - Y(0, M_0)\}$ ：如果将治疗从 0 变到 1，但把中介固定在无治疗时的自然水平 M_0 ，结果的平均变化。这个效应衡量的是**不经过 M 的直接通路**的贡献。

³我们在 ?? 章中曾使用过这个数据集。

⁴我们将在 section 6 节中回到这个例子，展示 Baron-Kenny 方法的具体应用。

- **NIE** $\mathbb{E}\{Y(1, M_1) - Y(1, M_0)\}$: 如果保持治疗 $z = 1$ 不变, 但把中介从无治疗时的自然水平 M_0 变到治疗时的自然水平 M_1 , 结果的平均变化。这个效应衡量的是**通过中介 M 传导**的间接贡献。

在 Composition 假设下, 总效应可以分解为自然直接效应与自然间接效应之和。

命题 33.2 (效应的分解). 在定义 33.1 和 section 3.1 下, 有

$$\tau = +.$$

为什么 NIE 可以衡量间接效应? 直观上, $Y(1, M_1) - Y(1, M_0)$ 表示: 将治疗固定在 $z = 1$, 但让中介从“如果没有治疗它会是什么”变为“如果有治疗它会是什么”, 结果会如何变化。这恰恰描述了“治疗通过改变中介进而影响结果”这条通路上的效应。

然而, $Y(1, M_0)$ 这个量本身有一个深刻的概念困难: 它是一个**跨世界 counterfactual** (cross-world counterfactual)。 $z = 1$ 和 $m = M_0$ 这两个干预不可能在同一个实验中同时发生——同一个单元不可能既接受治疗 $z = 1$, 又同时处于无治疗条件下的中介水平。要理解 $Y(1, M_0)$, 我们必须借助平行世界的想象 (fig. 2)。

[width = 0.7]figures/crossworld.pdf

FIGURE 2. 跨世界 counterfactual $Y(1, M_0)$ 和 $Y(0, M_1)$ 的示意图。同一单元在两个平行世界中分别接受不同的治疗, 从而获得不同的中介值。

这种跨世界的性质引发了一个哲学上的争议。⁵ 将 $Y(1, M_0)$ 和 $Y(0, M_1)$ 称为**先验 counterfactual** (a priori counterfactuals), 因为我们无法在任何物理实验中观察到它们。按照 ⁵ 的可证伪性标准, 如果一个陈述无法被任何物理实验或观测所证伪, 那它就不是科学的, 而是形而上学的。因此, 严格的 Popperian 统计学家可能会认为中介分析是形而上学。⁵

不过, ⁵ 对整个潜在结果框架都提出了类似的批评。但他的批评是过度的: 即使我们无法同时观察到 $Y(1)$ 和 $Y(0)$, 我们仍然可以通过边缘分布的信息对它们做出可证伪的陈述。 $Y(1, M_0)$ 的困难在于它是真正无法在任何实验中触及的——这与 $\{Y(1), Y(0)\}$ 的性质根本不同。

4. 中介公式

4.1. 四个关键假设. 中介公式的识别依赖于四个假设。前三个假设本质上是在说: 治疗 and 中介在给定协变量 X 的条件下都是被随机化的。

[无治疗—结果混淆] 给定 X , 治疗与潜在结果独立:

$$Z \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

[无中介—结果混淆] 给定 (X, Z) , 中介与潜在结果独立:

$$M \perp\!\!\!\perp Y(z, m) \mid (X, Z), \quad \forall z, m.$$

[无治疗—中介混淆] 给定 X , 治疗与潜在中介独立:

$$Z \perp\!\!\!\perp M(z) \mid X, \quad \forall z.$$

⁵这一争议的详细讨论见 ⁵ 和 ⁵。

这三个假设共同构成了**序列可忽略性** (sequential ignorability)：在给定 X 的条件下，治疗分配是可忽略的；进一步在给定 (X, Z) 的条件下，中介分配也是可忽略的。序列可忽略性等价于在给定 X 的条件下 (Z, M) 是联合随机化的：

$$(153) \quad (Z, M) \perp\!\!\!\perp Y(z, m) \mid X, \quad \forall z, m.$$

eq. (153) 与 section 4.1 的等价性留作练习。⁶

最后一个假设是跨世界独立性。

[跨世界独立性] 给定 X ，潜在结果与潜在中介独立：

$$Y(z, m) \perp\!\!\!\perp M(z') \mid X, \quad \forall z, z', m.$$

前三个假设至少在随机化实验中是可以保证的，但 section 4.1 更为强——没有任何物理实验可以确保它，因为当 $z \neq z'$ 时，我们永远无法同时观察到 $Y(z, m)$ 和 $M(z')$ 。这正是 $Y(1, M_0)$ 等 cross-world counterfactual 的根本困难所在。

例 33.4 (验证假设的数据生成过程). 给定 X ，我们按如下方式生成数据：

$$\begin{aligned} Z &= 1\{g_Z(X, \varepsilon_Z) \geq 0\}, \\ M(z) &= 1\{g_M(X, z, \varepsilon_M) \geq 0\}, \quad z = 0, 1, \\ Y(z, m) &= g_Y(X, z, m, \varepsilon_Y), \quad z, m = 0, 1, \end{aligned}$$

其中 $\varepsilon_Z, \varepsilon_M, \varepsilon_Y$ 相互独立。⁷ 可以验证，在上述数据生成过程下，section 4.1 均成立。如果允许 ε_M 和 ε_Y 依赖于处理水平（即改为 $\varepsilon_M(z)$ 和 $\varepsilon_Y(z, m)$ ），则这些假设可能被违反。

4.2. 识别公式. ? 证明了以下关键结果。

定理 33.3 (中介公式). 在 section 4.1 下，有

$$\mathbb{E}\{Y(z, M_{z'}) \mid X = x\} = \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x) \Pr(M = m \mid Z = z', X = x).$$

定理的含义： 我们无法直接观察跨世界 counterfactual $Y(z, M_{z'})$ ，但 section 4.1 这四个假设足够将这个不可观测的量表达为可观测条件分布的函数。具体来说， $Y(z, M_{z'})$ 的期望等于：结果的条件期望（给定 $Z = z, M = m, X = x$ ）对中介的分布（给定 $Z = z', X = x$ ）的加权和。

为什么四个假设缺一不可？ 定理的证明（见附录 ??）清楚地展示了这四个假设各自的角色：section 4.1 保证了 $\Pr(M = m \mid Z = z', X = x) = \Pr(M_{z'} = m \mid X = x)$ ，section 4.1 允许我们交换 $Y(z, m)$ 与 $M_{z'}$ 的条件，section 4.1 则保证了结果的识别。

对 X 求期望，得到无条件版本：

$$\mathbb{E}\{Y(z, M_{z'})\} = \sum_x \sum_m \mathbb{E}(Y \mid Z = z, M = m, X = x) \Pr(M = m \mid Z = z', X = x) \Pr(X = x).$$

对于连续型 M 和 X ，求和替换为积分。

由 定义 33.2 和 定义 33.3，我们可以得到 NDE 和 NIE 的识别公式。

⁶详见 练习 33.2 题。

⁷详见 ?。

推论 33.4 (NDE 和 NIE 的识别). 在 *section 4.1* 下, 条件 NDE 和 NIE 由下式识别:

(154)

$$(x) = \sum_m [\mathbb{E}(Y | Z = 1, M = m, X = x) - \mathbb{E}(Y | Z = 0, M = m, X = x)] \Pr(M = m | Z = 0, X = x),$$

(155)

$$(x) = \sum_m \mathbb{E}(Y | Z = 1, M = m, X = x) [\Pr(M = m | Z = 1, X = x) - \Pr(M = m | Z = 0, X = x)].$$

理解 eq. (154) 的直觉: (x) 衡量的是将处理从 0 变到 1 (但保持中介在无处理时的自然分布) 的效应。在每个中介值 m 下, 处理从 0 变到 1 的条件效应是 $\mathbb{E}(Y | Z = 1, M = m, X = x) - \mathbb{E}(Y | Z = 0, M = m, X = x)$; 由于中介被固定在 $Z = 0$ 条件下的分布, 这些条件效应需要按 $\Pr(M = m | Z = 0, X = x)$ 加权求和。

对于二值中介 $M \in \{0, 1\}$, 定义 33.4 中的 NIE 公式可以化简为一种优美的乘积形式。

推论 33.5 (二值中介的 NIE 乘积公式). 在 *section 4.1* 下, 对二值中介 M , 有

$$(x) = \tau_{Z \rightarrow M}(x) \cdot \tau_{M \rightarrow Y}(1, x),$$

其中

$$\tau_{Z \rightarrow M}(x) = \Pr(M = 1 | Z = 1, X = x) - \Pr(M = 1 | Z = 0, X = x)$$

是 Z 对 M 的条件平均因果效应,

$$\tau_{M \rightarrow Y}(z, x) = \mathbb{E}(Y | Z = z, M = 1, X = x) - \mathbb{E}(Y | Z = z, M = 0, X = x)$$

是 M 对 Y 的条件平均因果效应。

为什么叫乘积公式? 直观上, 间接效应是这样传导的: 首先, 处理 Z 变化导致中介 M 变化 (效应 $\tau_{Z \rightarrow M}$); 然后, 中介 M 变化导致结果 Y 变化 (效应 $\tau_{M \rightarrow Y}$)。这两段效应的乘积, 就是总间接效应。这与我们的直觉完全一致。

定义 33.5 的证明留作练习。⁸

5. 线性模型下的 Baron-Kenny 方法

定义 33.3 给出了非参数识别公式, 它允许我们在各种不同模型下推导出中介效应的具体形式。本节介绍经典而又广泛使用的 **Baron-Kenny 方法** (?), 该方法假设线性模型。

5.1. 模型设定. Baron-Kenny 方法假设中介和结果都满足线性模型 (??)。

[Baron-Kenny 线性模型] 中介和结果的条件期望满足线性模型:

$$(27.1) \quad \begin{cases} \mathbb{E}(M | Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y | Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

在上述线性模型下, NDE 和 NIE 可以简化为系数的简洁函数。

推论 33.6 (Baron-Kenny 公式). 在 *sections 4.1 and 5.1* 下, 有

$$(27.2) \quad \quad \quad = \theta_1, \quad \quad = \theta_2 \beta_1.$$

⁸详见 练习 33.5 题。

与 DAG 的对应：在 ?? 中， θ_1 是路径 $Z \rightarrow Y$ 的系数（直接效应）， $\beta_1\theta_2$ 是路径 $Z \rightarrow M \rightarrow Y$ 的系数之积（间接效应）。这与 定义 33.6 完全一致。

为何不需要对 X 求和？注意在 eq. (154) 和 eq. (155) 中， (x) 和 (x) 是在给定 $X = x$ 的条件下的值。而在 Baron–Kenny 线性模型下， θ_1 和 $\theta_2\beta_1$ 与 x 无关，因此条件效应等于无条件效应。

Baron–Kenny 公式的推导见附录 ??。

如果获得了系数的 OLS 估计量 $\hat{\beta}_1$ 和 $\hat{\theta}_2$ ，则 NDE 和 NIE 的估计量为

$$\hat{\tau} = \hat{\theta}_1, \quad \hat{\tau} = \hat{\theta}_2\hat{\beta}_1,$$

这就是经典的 Baron–Kenny 估计。? 和 ? 利用 delta 方法给出了 $\hat{\tau}$ 的标准误：

$$\text{var}(\hat{\tau}) = \text{var}(\hat{\theta}_2)\hat{\beta}_1^2 + \hat{\theta}_2^2\text{var}(\hat{\beta}_1).$$

基于此的假设检验称为 Sobel’s test。⁹

Baron–Kenny 方法的历史：虽然 ? 使这一方法广为人知，但它实际上有更早的渊源，包括 ?、? 和 ? 的工作。? 进一步发展了推断方法。

6. 应用实例：JOBS II 数据

我们通过 R 代码实现 Baron–Kenny 方法，并将其应用于 JOBS II 数据集。¹⁰

例 33.5 (JOBS II：就业培训对心理健康的中介分析). 我们关注就业培训（处理 Z ）对心理健康（结果 Y ，用抑郁量表得分度量）的影响，以及这一影响是否通过工作搜寻效能（中介 M ）传导。背景协变量 X 包括经济困难程度、基线抑郁得分、性别、年龄、职业、婚姻状态、种族、教育程度和家庭收入。

通过以下 R 代码实现 Baron–Kenny 方法：

```
library("car")
BKmediation = function(Z, M, Y, X) {
  mediator.reg = lm(M ~ Z + X)
  mediator.Zcoef = mediator.reg$coef[2]
  mediator.Zse = sqrt(hccm(mediator.reg)[2, 2])

  outcome.reg = lm(Y ~ Z + M + X)
  outcome.Zcoef = outcome.reg$coef[2]
  outcome.Zse = sqrt(hccm(outcome.reg)[2, 2])
  outcome.Mcoef = outcome.reg$coef[3]
  outcome.Mse = sqrt(hccm(outcome.reg)[3, 3])

  NDE = outcome.Zcoef
  NIE = outcome.Mcoef * mediator.Zcoef

  NDE.se = outcome.Zse
  NIE.se = sqrt(outcome.Mse^2 * mediator.Zcoef^2 +
                 outcome.Mcoef^2 * mediator.Zse^2)
```

⁹关于 Sobel 检验的更多讨论见 ?。

¹⁰JOBS II 是一个关于就业培训对失业工人影响的随机化现场实验。数据集在 R 的 `mediation` 包中。

```
res = matrix(c(NDE, NIE, NDE.se, NIE.se,
               NDE/NDE.se, NIE/NIE.se), 2, 3)
rownames(res) = c("NDE", "NIE")
colnames(res) = c("est", "se", "t")
res
}
```

运行结果如下：

```
> res = BKmediation(Z, M, Y, X)
> round(res, 3)
      est      se      t
NDE -0.037  0.042 -0.885
NIE -0.014  0.009 -1.528
```

估计的直接效应 $\hat{c} = -0.037$ （培训对心理健康的直接保护效应）和间接效应 $\hat{a} = -0.014$ （通过提高工作搜寻效能而改善心理健康）均为负，但统计上均不显著。这表明 *JOBS II* 培训项目对心理健康的效应尚无充分证据支持按中介路径分解。

一个值得注意的现象：在某些设定下，间接效应可能出现违反直觉的符号。例如，如果 $Z \rightarrow M$ 的效应 $\beta_1 > 0$ ， $M \rightarrow Y$ 的效应 $\theta_2 > 0$ ，但 Z 与 M 之间存在负交互项 $\theta_3 < 0$ ，则乘积 $\beta_1(\theta_2 + \theta_3)$ 可能为负。这被称为**中介悖论**（mediator paradox）或**替代终点悖论**（surrogate endpoint paradox）。^a

^a详见？。

7. 敏感性分析

中介分析依赖于强且不可检验的假设。关键的不可检验假设是跨世界独立性（section 4.1）：我们无法通过任何实验数据验证 $Y(z, m)$ 与 $M(z')$ 在 $z \neq z'$ 时是否独立。

因此，研究者常常需要进行**敏感性分析**（sensitivity analysis），以探索当关键假设不成立时，结论会如何变化。主要文献包括：

- ? 提出了类似 Cornfield 的敏感性界；
- ? 提出了针对 Baron–Kenny 线性模型量身定制的敏感性分析方法。

敏感性分析的具体方法超出了本章的范围，但读者应记住：中介分析的结果必须谨慎解读，因为其核心假设无法被数据验证。

8. 本章小结

本章围绕中介分析展开，主要内容如下：

- (1) **核心问题：**因果效应如何在直接通路和间接通路之间分配？
- (2) **嵌套潜在结果 $Y(z, M_{z'})$ ：**描述跨世界 counterfactual，是定义 NDE 和 NIE 的基础。
- (3) **效应分解：**在 Composition 假设下，总效应 $\tau = +$ 。
- (4) **识别假设：**四个假设（序列可忽略性 + 跨世界独立性）下，中介公式成立。
- (5) **中介公式：**将不可观测的 NDE 和 NIE 表达为可观测条件分布的函数。
- (6) **Baron–Kenny 公式：**在 section 5.1 下， $c = \theta_1$ ， $a = \theta_2\beta_1$ 。
- (7) **跨世界 counterfactual 的哲学争议：**严格的 Popperian 认识论者认为中介分析是形而上学的。

(8) **敏感性分析**：由于核心假设不可检验，敏感性分析是必要的。

中介公式的完整证明见附录 ??；Baron-Kenny 公式的推导见附录 ??；各节练习题见附录 section 8。

练习

练习 33.1. 假设 (Z, M, Y) 均为二值变量。基于潜在结果

$$M(1), M(0), Y(1, M_1), Y(1, M_0), Y(0, M_1), Y(0, M_0)$$

的联合取值，单元可以分成多少类型？

若进一步假设单调性 $M(1) \geq M(0)$ (Z 对 M 的单调性)，则单元可以分成多少类型？

若再假设 $Y(1, m) \geq Y(0, m)$ 且 $Y(z, 1) \geq Y(z, 0)$ 对所有 z, m 成立 (Z 和 M 对 Y 的单调性)，则单元可以分成多少类型？

本题答案见附录 ??。

练习 33.2. 证明 eq. (153) 与 section 4.1 等价。

本题答案见附录 ??。

练习 33.3. ? 提出了另一组假设来推导中介公式：

$$\{Y(z, m), M(z')\} \perp\!\!\!\perp Z \mid X, \quad Y(z, m) \perp\!\!\!\perp M(z') \mid (Z = z', X),$$

对所有 z, z', m 成立。

证明：在上述假设下，定义 33.3 中的中介公式同样成立。

本题答案见附录 ??。

练习 33.4. 在 Baron-Kenny 线性模型 (section 5.1) 下，首先拟合：

$$\hat{M} = \hat{\beta}_0 + \hat{\beta}_1 Z + \hat{\beta}_2^\top X, \quad \hat{Y} = \hat{\theta}_0 + \hat{\theta}_1 Z + \hat{\theta}_2 M + \hat{\theta}_4^\top X.$$

则 NIE 的估计量为乘积 $\hat{\theta}_2 \hat{\beta}_1$ (乘积法)。

另一方面，首先拟合：

$$\hat{Y} = \hat{\alpha}_0 + \hat{\alpha}_1 Z + \hat{\alpha}_1^\top X,$$

再拟合：

$$\hat{Y} = \tilde{\theta}_0 + \tilde{\theta}_1 Z + \tilde{\theta}_2 M + \tilde{\theta}_4^\top X,$$

则 NIE 的另一估计量为差值 $\hat{\alpha}_1 - \tilde{\theta}_1$ (差值法)。

证明： $\hat{\alpha}_1 - \tilde{\theta}_1 = \hat{\theta}_2 \hat{\beta}_1$ 。

本题答案见附录 ??。

练习 33.5. 证明 定义 33.5 (二值中介的 NIE 乘积公式)。

本题答案见附录 ??。

练习 33.6. ? 建议在结果模型中加入处理与中介的交互项：

$$\begin{cases} \mathbb{E}(M \mid Z, X) = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y \mid Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_3 ZM + \theta_4^\top X. \end{cases}$$

证明：在此模型下，

$$= \theta_1 + \theta_3 \{\beta_0 + \beta_2^\top \mathbb{E}(X)\}, \quad = (\theta_2 + \theta_3) \beta_1.$$

并说明如何在 IID 数据下估计 和 。

本题答案见附录 ??。

练习 33.7. 考虑中介 M 服从正态线性模型、结果 Y 服从 *logistic* 模型：

$$\begin{cases} M | Z, X \sim \mathcal{N}(\beta_0 + \beta_1 Z + \beta_2^\top X, \sigma_M^2), \\ \text{logit}\{\Pr(Y = 1 | Z, M, X)\} = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

请将 β 和 θ 表示为模型参数和 X 分布的函数，并说明如何在 *IID* 数据下估计它们。

本题答案见附录 ??。

练习 33.8. 考虑二值中介 M 服从 *logistic* 模型、结果 Y 服从线性模型：

$$\begin{cases} \text{logit}\{\Pr(M = 1 | Z, X)\} = \beta_0 + \beta_1 Z + \beta_2^\top X, \\ \mathbb{E}(Y | Z, M, X) = \theta_0 + \theta_1 Z + \theta_2 M + \theta_4^\top X. \end{cases}$$

证明：

$$\beta_1 = \theta_1, \quad \beta_2 = \theta_2 \mathbb{E}\{\text{expit}(\beta_0 + \beta_1 + \beta_2^\top X) - \text{expit}(\beta_0 + \beta_2^\top X)\}.$$

并说明如何在 *IID* 数据下估计 β 和 θ 。

本题答案见附录 ??。

练习 33.9. 将嵌套潜在结果修改为

$$Y(z, F_{M_{z'}|X}) = \int Y(z, m) f(M_{z'} = m | X) dm,$$

其中 $F_{M_{z'}|X}$ 是条件分布而非确定值。相应地将 *NDE* 和 *NIE* 定义为

$$NDE = \mathbb{E}\{Y(1, F_{M_0|X}) - Y(0, F_{M_0|X})\}, \quad NIE = \mathbb{E}\{Y(1, F_{M_1|X}) - Y(1, F_{M_0|X})\}.$$

证明：在仅假设 *section 4.1*（不要求跨世界独立性）下， NDE 和 NIE 的识别公式与正文相同。

本题答案见附录 ??。

练习 33.10. ? 和 ? 综述并比较了主分层与中介分析两种方法。请查阅这些文献，并撰写一页总结，阐述两种方法的异同与各自的优缺点。

本题为开放性研究型练习，请参考 ? 和 ?。

因果发现

1. 引言：一个雄心勃勃的问题

在前面的章节中，我们假设因果结构已知——即已知哪些变量是原因、哪些变量是结果。然而在现实中，我们往往面对一个更为艰难的问题：**能否从数据中学习出变量之间的因果关系？**

这个问题的重要性不言而喻。科学发现的本质就是从观察数据中推断因果结构。历史上，James Lind 通过对照实验发现柑橘类水果可以治疗坏血病；但在许多情况下，实验干预是不可行或不道德的。我们能否仅从被动观察的数据中，发现变量之间的因果关系？

这个问题在哲学上曾被认为是不可可能的。“相关不蕴含因果”——这句格言道出了统计学的传统智慧。然而，过去三十年见证了一场静默的革命：在一系列精心设计的假设下，因果结构可以从纯粹的观察数据中学习。

这场革命的先驱包括 Judea Pearl，他发展了基于图的因果推理理论；以及 Peter Spirtes、Clark Glymour 和 Richard Scheines，他们构建了 PC 等算法从数据中提取因果结构。本章将介绍这一领域的基本思想和方法。

2. 因果马尔可夫条件与忠诚性

在讨论具体算法之前，我们需要理解因果发现的可能性条件。考虑一个包含变量 $X_1, X_2, \dots, X_p$ 的系统。如果这些变量之间存在因果关系，我们通常用有向无环图 (DAG) 来表示：每个节点代表一个变量，箭头 $X \rightarrow Y$ 表示 X 是 Y 的直接原因（或之一）。

一个根本性的观察是：在许多合理的因果模型下，变量之间的条件独立性蕴含着因果结构的信息。

[因果马尔可夫条件] 给定一个变量的所有直接原因，该变量独立于所有非其后代的变量。

直观上，如果 X 导致 Y ，而 Y 又导致 Z ，那么在已知 Y 的情况下， X 和 Z 之间不应该有直接的联系——它们之间的任何关联都已经被 Y 解释了。

[忠诚性条件] 图中存在的条件独立性关系，恰好对应于数据分布中存在的条件独立性关系。

忠诚性条件防止了“巧合独立性”——即两个变量在数据中条件独立，但在图中却通过一条路径相连。这种巧合在参数化模型中是零测度的。

在这两个假设下，我们可以从变量的条件独立性结构中读取因果信息。

3. PC 算法：从条件独立性到因果骨架

PC 算法 (Spirtes et al., 2000) 是因果发现领域最经典的算法之一。它的核心思想简洁而有力：**从条件独立性出发，逐步确定因果结构。**

3.1. 第一步：发现骨架。 算法从一个完全无向的图出发，通过条件独立性检验逐步删除边。

对于每一对变量 X 和 Y ，以及越来越大的条件集 S （最初为空，然后是单变量，然后是双变量，以此类推），我们检验条件独立性：

$$(156) \quad X \perp\!\!\!\perp Y \mid S$$

其中 $\perp\!\!\!\perp$ 表示条件独立性。如果拒绝独立性，则保留边 (X, Y) ；否则，删除这条边。

在标准的高斯或离散数据设置下，我们可以使用偏相关系数或条件互信息来进行这个检验。

例 34.1 (简单的条件独立性). 考虑三个变量 X, Y, Z 。假设我们进行条件独立性检验：

- $X \not\perp\!\!\!\perp Y$ (边缘不独立)
- $X \perp\!\!\!\perp Y \mid Z$ (给定 Z 条件独立)

这告诉我们什么？在 *Markov* 条件下，这暗示 Z 是 X 和 Y 的共同原因，或者 Z 位于它们之间的中介路径上。

这个过程不断迭代，直到所有边都经过了适当的条件独立性检验。最终得到的图称为**因果骨架**——它保留了所有在某种条件下不条件独立的变量对之间的连接。

3.2. 第二步：定向边. 骨架是无向的，但我们需要定向边来揭示因果方向。这需要利用 v -结构（碰撞结构）的概念。

考虑三个变量 X, Y, Z ，它们之间的骨架显示 $X - Z - Y$ （即 X 与 Y 之间无边，但都与 Z 相连）。如果进一步发现 $X \not\perp\!\!\!\perp Y \mid \emptyset$ 且 $X \perp\!\!\!\perp Y \mid Z$ ，这符合什么结构？

在 *Markov* 条件下，如果 $X \rightarrow Z \rightarrow Y$ (Z 是中介)，那么给定 Z ， X 和 Y 应该条件独立。这与观察到的 $X \perp\!\!\!\perp Y \mid Z$ 一致。

但如果有 Z 是 X 和 Y 的共同原因，即 $Z \rightarrow X$ 且 $Z \rightarrow Y$ ，那么 X 和 Y 在边缘上不独立，但给定 Z 时条件独立——这正是我们观察到的！

PC 算法通过识别这类模式来确定边的方向。形式化地说：

[v -结构] 一个三元组 (X, Z, Y) 形成 v -结构，当且仅当：

- (1) X 与 Y 在骨架中无边；
- (2) Z 与 X 、 Z 与 Y 都有边相连；
- (3) 在给定 Z 的条件下， X 和 Y 不条件独立。

在忠诚性条件下， v -结构必然对应一个碰撞结构： $X \rightarrow Z \leftarrow Y$ 。这是因为其他结构 ($X \rightarrow Z \rightarrow Y$ 或 $X \leftarrow Z \rightarrow Y$) 都会在给定 Z 时使 X 和 Y 条件独立。

PC 算法的定向规则可以总结为：

- (1) 识别所有 v -结构，将其中心节点的两个父节点方向设为指向该节点；
- (2) 应用马尔可夫性和忠诚性所隐含的其他定向规则（如避免产生新的 v -结构）。

3.3. 第三步：边定向的最终确定. 上述步骤可能无法定向所有边。这是因为某些边在观察分布下本来就是不可分辨的——不同的有向图可能产生完全相同的条件独立性结构。这些图构成一个**等价类**。

例如，考虑两条边 $X - Y$ 和 $Y - Z$ ，且 X 与 Z 之间无边。 $X \rightarrow Y \rightarrow Z$ 和 $X \leftarrow Y \leftarrow Z$ 产生完全相同的条件独立性结构，在没有额外假设的情况下无法区分。

这引导我们到下一个重要概念。

4. DAG 等价类与基本等价类图

部分有向无环图 (PAG) 是一种表示 DAG 等价类的标准形式。在 PAG 中：

- 不可定向的边用 $\circ - \circ$ 表示；
- 可定向的边用 $\rightarrow$ 或 $\leftarrow$ 表示。

定理 34.1 (忠实性定理的推论). 在因果马尔可夫条件和忠诚性条件下, 观察分布唯一确定一个 PAG。

这个定理保证了 PC 算法输出的 PAG 是唯一的——如果我们相信这些假设的话。

5. 条件独立性检验

PC 算法的核心依赖于可靠的条件独立性检验。这在实践中是一个 nontrivial 的问题。

5.1. 高斯情形：偏相关系数. 对于连续型高斯数据, 条件独立性可以通过偏相关系数来检验。给定条件集 S , X 和 Y 的偏相关系数记为 $\rho_{XY.S}$ 。

我们可以检验零假设 $H_0: \rho_{XY.S} = 0$ 。在正态性假设下, 这个统计量服从一个已知分布, 可以计算 p 值。

注 34.1. 偏相关系数的计算需要 S 中变量的条件协方差矩阵。当 $|S|$ 较大时, 估计精度会下降, 这是 PC 算法的一个 *practical limitation*。

5.2. 离散情形：条件互信息. 对于离散数据, 我们可以使用条件互信息:

$$(157) \quad I(X; Y | S) = \sum_{x,y,s} p(x, y, s) \log \frac{p(x, y | s)}{p(x | s)p(y | s)}.$$

在独立性下, 这个量应该为零。我们可以使用卡方检验或似然比检验来验证。

6. PC 算法的完整流程

综合以上讨论, PC 算法的完整流程如下:

- (1) **初始化:** 从一个完全无向的完全图开始。
- (2) **骨架发现:** 对每一对变量 (X, Y) , 以及越来越大的条件集 S , 进行条件独立性检验。如果 $X \perp\!\!\!\perp Y | S$, 则删除边 (X, Y) 。
- (3) **v-结构识别:** 对于每个三元组 (X, Z, Y) , 检查是否形成 v-结构。如果是, 定向 $X \rightarrow Z \leftarrow Y$ 。
- (4) **边定向传播:** 应用定向规则, 尽可能多地定向剩余的边。
- (5) **输出:** 返回最终的 PAG。

算法的计算复杂度主要取决于条件独立性检验的数量。对于 p 个变量, 最坏情况下需要检验的条件集数量是 $\sum_{k=0}^{p-2} \binom{p-2}{k}$, 这使得 PC 算法在变量数很大时可能不切实际。

7. 其他因果发现方法概述

PC 算法只是因果发现领域的众多种方法之一。这里简要介绍另外两类重要方法。

7.1. 基于评分的方法. GIES (Greedy Equivalence 类 Search) 等方法将因果发现问题框架为模型选择问题。我们为每个候选 DAG 赋予一个评分 (如 BIC 或 BD 评分), 然后搜索评分最高的结构。

这类方法的优点是可以捕获全局最优结构; 缺点是计算复杂度高, 需要使用贪婪搜索等启发式方法。

7.2. 利用因果充分性假设. 许多方法假设不存在未观察到的共同原因 (因果充分性)。在这个假设下, 观测分布的每个因子对应于一个局部 DAG。

在这种假设下, 因果方向可以通过检验的条件独立性完全确定。

8. 因果发现的局限性

尽管因果发现方法取得了显著进展，我们必须清醒地认识其局限性。

第一，假设的脆弱性。因果马尔可夫条件和忠诚性条件是强有力的假设。如果数据生成过程不满足这些条件（如存在未观察到的混杂），因果发现的结果可能是错误的。

第二，检验的局限性。条件独立性检验的统计功效有限，特别是在小样本或大条件集时。可能出现假阳性（错误地删除边）或假阴性（错误地保留边）。

第三，计算的复杂性。精确的因果发现是 NP 难的。现有算法都依赖于各种近似，这可能影响结果的可靠性。

第四，不可辨识性。即使在理想条件下，某些因果结构也是不可辨识的——不同的因果图可能产生完全相同的观察分布。

9. 讨论与延伸阅读

因果发现是一个活跃的研究领域，涉及统计学、计算机科学、哲学的交叉。经典参考文献包括 Pearl (2000) 的《Causality》，以及 Spirtes et al. (2000) 的《Causation, Prediction, and Search》。

近年的发展包括：

- 利用干预数据改进因果发现；
- 将因果发现与机器学习结合；
- 处理隐变量和选择偏差的更复杂方法。

在实际应用中，因果发现应该谨慎使用。其结果更适合作为假设生成，而不是因果声明的最终结论。

10. 本章小结

本章介绍了从观察数据中发现因果结构的可能性的基本思想。

- (1) 在因果马尔可夫条件和忠诚性条件下，条件独立性蕴含因果结构信息。
- (2) PC 算法通过系统的条件独立性检验和 v -结构识别，从数据中学习因果骨架和方向。
- (3) 因果发现的结果以 PAG（部分有向无环图）的形式表示，反映了因果结构的等价类。
- (4) 因果发现有重要局限性，包括假设的脆弱性、统计检验的局限、计算复杂性和根本性的不可辨识性。

下一步的学习方向包括：深入研究具体的条件独立性检验方法、了解基于评分的方法、以及探索利用干预数据的因果发现技术。

11. 习题

练习 34.1. 证明：在马尔可夫条件和忠诚性条件下，如果 X 和 Y 在骨架中无边，但都与 Z 相连，且 $X \perp\!\!\!\perp Y \mid \emptyset$ 但 $X \perp\!\!\!\perp Y \mid Z$ ，则 (X, Z, Y) 形成 v -结构。

练习 34.2. 考虑四个变量 X_1, X_2, X_3, X_4 ，假设真实因果结构是 $X_1 \rightarrow X_2 \rightarrow X_4$ 和 $X_1 \rightarrow X_3 \rightarrow X_4$ 。说明 PC 算法在什么条件下能够恢复这个结构，以及在什么条件下可能失败。

练习 34.3. 证明：对于 n 个变量的 DAG，完全图（有 $\binom{n}{2}$ 条边）和完全无向图在骨架发现步骤后的边数关系。

练习 34.4. 讨论因果发现与因果推断其他方法（如第 10-12 章的倾向得分方法）的关系。它们分别适合什么场景？

时间变动的处理变量与混淆

1. 从单时间点到多时间点：一个自然的推广

在前面各章中，我们考虑的都是**单一时间点**的处理变量——每个单元在某个特定时刻接受或不接受治疗。然而，现实世界中的治疗往往是**时间变动**的：患者在不同时间点接受不同强度的治疗；政策在不同阶段被动态调整；个人在不同年龄做出不同的选择。

为什么时间变动会带来新的挑战？

考虑一个两时间点的例子： Z_1 是初始治疗（如是否服用阿司匹林）， X_1 是治疗后的中间结果（如血压变化）， Z_2 是后续治疗（如是否接受手术）， Y 是最终结局（如是否在 5 年内死亡）。在这个序列中：

- Z_1 可能影响 X_1 （治疗改变中间结果）
- X_1 可能同时影响 Z_2 和 Y （中间结果既是后续治疗的原因，也是结局的原因）
- 这时， X_1 同时扮演着**时间变动协变量**和**时间变动混淆变量**的角色

在单一时间点框架下，我们只需条件于基线协变量 X_0 即可阻断所有混淆。但在时间变动的情况下， X_1 既是治疗 Z_2 的“前置原因”，也是结局 Y 的“前置原因”——它可能本身就是由 Z_1 产生的，从而部分介导了 Z_1 对 Y 的因果效应。这种复杂的时序结构使得简单的条件独立性假设不再够用。

这就是本章要解决的核心问题：**当处理变量随时间变动时，如何识别和估计因果效应？**

为简化记号，本章主要采用两时间点的设置来阐述核心思想。推广到更多时间点在概念上直接，但有限样本下会产生技术复杂性——组合数随时间点数量指数增长。我们将讨论这些复杂性，并将一般结果留给习题。

2. 基本设置与序列可忽略性

2.1. 时序结构. 两时间点的变量时序如下：

$$X_0 \rightarrow Z_1 \rightarrow X_1 \rightarrow Z_2 \rightarrow Y$$

其中：

- X_0 ：基线协变量（治疗前的特征）
- Z_1 ：时间点 1 的处理变量
- X_1 ：时间点 1 与时间点 2 之间的时变协变量
- Z_2 ：时间点 2 的处理变量
- Y ：最终结局

对于二元处理 (Z_1, Z_2) ，每个单元有四个潜在结局：

$$Y(z_1, z_2), \quad z_1, z_2 \in \{0, 1\}$$

观测到的结局等于：

$$Y = Y(Z_1, Z_2) = \sum_{z_1=0}^1 \sum_{z_2=0}^1 \mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2) Y(z_1, z_2)$$

2.2. 序列可忽略性假设. 在单一时间点的情况下, $Z \perp Y(z) \mid X$ (处理在给定协变量条件下随机化) 是我们识别因果效应的关键假设。对于时间变动的情况, 这个假设需要**序列化**——在每个时间点, 处理不仅依赖于当前的协变量历史, 还依赖于整个历史。

假设 35.1 (序列可忽略性). (1) Z_1 在给定 X_0 条件下随机化:

$$Z_1 \perp Y(z_1, z_2) \mid X_0, \quad \forall z_1, z_2 \in \{0, 1\}$$

(2) Z_2 在给定 (Z_1, X_1, X_0) 条件下随机化:

$$Z_2 \perp Y(z_1, z_2) \mid (Z_1, X_1, X_0), \quad \forall z_1, z_2 \in \{0, 1\}$$

理解 Assumption 35.1: 这个假设包含两部分递进的条件。第一部分说明 Z_1 仅被基线协变量 X_0 混淆——一旦我们条件于 X_0 , Z_1 就等同于随机化实验。第二部分则说明 Z_2 被 (Z_1, X_1, X_0) 混淆——我们不仅需要控制基线协变量 X_0 , 还需要控制由 Z_1 产生的时变协变量 X_1 。

一个重要的微妙之处: 序列可忽略性**允许** X_1 与 Y 之间存在未测量的混淆 U (如图 2 所示)。这是因为 X_1 本身可能是由 Z_1 产生的, 它部分介导了 Z_1 对 Y 的效应——这并非混淆, 而是**中介**。然而, 如果 U 同时影响 X_1 和 Y (且不通过 Z_1, Z_2), 则即使满足序列可忽略性, 识别仍然会受到挑战。




FIGURE 1. Assumption 35.1 成立且 X_1 与 Y 之间无未测量混淆 U 的因果图。




FIGURE 2. Assumption 35.1 成立但 X_1 与 Y 之间存在未测量混淆 U 的因果图。序列可忽略性仅排除了 (Z_1, Z_2) 与 Y 之间的混淆, 但允许 X_1 与 Y 之间存在未测量关联。

3. g 公式与结果建模

在单一时间点情况下，基于结果的识别公式为：

$$E\{Y(z)\} = E\{E(Y \mid Z = z, X)\}$$

对于离散 X ，这化为：

$$E\{Y(z)\} = \sum_x E(Y \mid Z = z, X = x) \Pr(X = x)$$

对于连续 X ，这化为：

$$E\{Y(z)\} = \int E(Y \mid Z = z, X = x) f(x) dx$$

接下来的定理将这个公式推广到两时间点的设置。

定理 35.1 (g 公式). 在 *Assumption 35.1* 下,

$$(29.1) \quad E\{Y(z_1, z_2)\} = E\left[E\{E(Y \mid z_2, z_1, X_1, X_0) \mid z_1, X_0\}\right]$$

定理 35.1 的直观理解：等式右边是从内到外嵌套的条件期望。最内层 $E(Y \mid z_2, z_1, X_1, X_0)$ 是在固定历史 (z_1, X_0) 、中间协变量 X_1 和第二时刻治疗 z_2 的条件下结局的期望。中间层 $E\{\cdot \mid z_1, X_0\}$ 对 X_1 求平均——但注意，这是**逆概率加权**的平均，因为 $\Pr(X_1 \mid z_1, X_0)$ 与 $Z_1 = z_1$ 相关。最外层 $E[\cdot]$ 对 X_0 求边际平均。

对于离散 X_0, X_1 ，?? 化为：

$$(29.2) \quad E\{Y(z_1, z_2)\} = \sum_{x_0} \sum_{x_1} E(Y \mid z_2, z_1, x_1, x_0) \Pr(x_1 \mid z_1, x_0) \Pr(x_0)$$

对于连续 X_0, X_1 ，?? 化为：

$$(29.3) \quad E\{Y(z_1, z_2)\} = \iint E(Y \mid z_2, z_1, x_1, x_0) f(x_1 \mid z_1, x_0) f(x_0) dx_1 dx_0$$

与全概率公式的比较：根据观测数据的全概率公式，

$$(29.4) \quad E(Y) = \sum_{x_0} \sum_{z_1} \sum_{x_1} \sum_{z_2} E(Y \mid z_2, z_1, x_1, x_0) \Pr(z_2 \mid z_1, x_1, x_0) \Pr(x_1 \mid z_1, x_0) \Pr(z_1 \mid x_0) \Pr(x_0)$$

对比 ?? 与 ??，关键区别在于：?? 中**没有** $\Pr(z_2 \mid \dots)$ 和 $\Pr(z_1 \mid \dots)$ 项——这正是因为在潜在结局 $Y(z_1, z_2)$ 的定义是**固定** $Z_1 = z_1$ 和 $Z_2 = z_2$ ，而非观测到的分配概率。

?? 和 ?? 被称为 **g 公式 (g-formula)**，由 Robins 命名。这个名称源于它的一般化形式——当处理变量随时间变动时，这个公式提供了一种递推的识别策略。

定理 35.1 的证明。¹

¹详见附录 section 8。

3.1. 基于结果建模的插件估计. g 公式 ?? 和 ?? 提示我们: 为了估计潜在结局的均值, 我们需要对 $E(Y | z_2, z_1, x_1, x_0)$ 、 $\Pr(x_1 | z_1, x_0)$ 和 $\Pr(x_0)$ 建模。有了这些拟合模型, 我们可以将它们”插入”g 公式得到估计。

在某些特殊函数形式下, 这个任务可以简化。下面的例 29.1 给出线性结果模型下的结果。

例 35.1 (例 29.1 —线性结果模型). 假设线性结果模型:

$$(29.5) \quad E(Y | z_2, z_1, x_1, x_0) = \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 x_1 + \beta_4 x_0$$

可以验证:

$$(29.6) \quad \begin{aligned} E\{Y(z_1, z_2)\} &= \sum_{x_0} \sum_{x_1} (\beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 x_1 + \beta_4 x_0) \\ &\quad \Pr(x_1 | z_1, x_0) \Pr(x_0) \\ &= \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 \sum_{x_0} E(X_1 | z_1, x_0) \Pr(x_0) + \beta_4 E(X_0) \\ &= \beta_0 + \beta_1 z_2 + \beta_2 z_1 + \beta_3 E\{X_1(z_1)\} + \beta_4 E(X_0) \end{aligned}$$

其中我们定义了 X_1 在治疗 $Z_1 = z_1$ 下的潜在结局:

$$(29.7) \quad E\{X_1(z_1)\} = \sum_{x_0} E(X_1 | z_1, x_0) \Pr(x_0)$$

定义 $\tau_{Z_1 \rightarrow X_1} = E\{X_1(1) - X_1(0)\}$, 则:

$$(29.8) \quad E\{Y(1, 0) - Y(0, 0)\} = \beta_2 + \beta_3 \tau_{Z_1 \rightarrow X_1}$$

$$(29.9) \quad E\{Y(0, 1) - Y(0, 0)\} = \beta_1$$

$$(29.10) \quad E\{Y(1, 1) - Y(0, 0)\} = \beta_1 + \beta_2 + \beta_3 \tau_{Z_1 \rightarrow X_1}$$

直观解释(参见图 3): ?? 中 Z_1 的效应等于路径 $Z_1 \rightarrow Y$ (系数 β_2) 和路径 $Z_1 \rightarrow X_1 \rightarrow Y$ (系数 $\beta_3 \tau_{Z_1 \rightarrow X_1}$) 之和; ?? 中 Z_2 的效应等于路径 $Z_2 \rightarrow Y$ (系数 β_1); ?? 中 (Z_1, Z_2) 的总效应等于三条路径系数之和。




FIGURE 3. 带路径系数的线性因果图, 条件于基线协变量 X_0 。

g-null 悖论. Robins 和 Wasserman (1997) 指出了基于结果建模的插件估计的一个令人惊讶的缺陷。他们证明: 如果在这个策略中出现模型错误设定, 数据分析者可能**错误地拒绝**零因果效应 null 假设, 即使在真实数据生成过程中 (Z_1, Z_2) 对 Y 的因果效应确实为零。他们称之为 **g-null 悖论 (g-null paradox)**。令人惊讶的是, 即使在例 29.1 的简单线性结果模型中, g-null 悖论也可能出现 (见习题 29.1)。

3.2. 基于结果建模的递推估计. 29.3.1 节的插件估计涉及对时变协变量 X_1 建模, 并导致令人不快的 g-null 悖论——这不是一个理想的方法。

递推期望公式 ?? 启发了一种更简单的估计方法。从最内层条件期望开始, 记:

$$\hat{Y}_2(z_1, z_2) = E(Y \mid Z_2 = z_2, Z_1 = z_1, X_1, X_0)$$

我们可以用 $(Z_2 = z_2, Z_1 = z_1)$ 子集数据拟合 Y 对 (X_1, X_0) 的模型, 得到所有单元的拟合值 $\hat{Y}_{2i}(z_1, z_2)$ 。然后进入外层条件期望, 记:

$$\hat{Y}_1(z_1, z_2) = E\{\hat{Y}_2(z_1, z_2) \mid Z_1 = z_1, X_0\}$$

我们可以用 $Z_1 = z_1$ 子集数据拟合 $\hat{Y}_2(z_1, z_2)$ 对 X_0 的模型, 得到所有单元的拟合值 $\hat{Y}_{1i}(z_1, z_2)$ 。最终的 $E\{Y(z_1, z_2)\}$ 估计量为:

$$(29.11) \quad \hat{E}\{Y(z_1, z_2)\} = n^{-1} \sum_{i=1}^n \hat{Y}_{1i}(z_1, z_2)$$

这种递推估计**不涉及**对 X_1 建模, 因此避免了 g-null 悖论 (见习题 29.2)。然而, 基于递推回归的估计量实现起来并不容易, 因为它涉及建模与因果图自然结构不对应的变量——例如 $\hat{Y}_2(z_1, z_2)$ 。

4. 逆概率加权

在单一时间点情况下, IPW 识别公式为:

$$E\{Y(z)\} = E\left\{\frac{\mathbf{1}(Z = z)Y}{\Pr(Z = z \mid X)}\right\}$$

接下来的结果将其推广到两时间点设置。定义:

$$(29.12) \quad e(z_1, X_0) = \Pr(Z_1 = z_1 \mid X_0)$$

$$(29.13) \quad e(z_2, Z_1, X_1, X_0) = \Pr(Z_2 = z_2 \mid Z_1, X_1, X_0)$$

为时间点 1 和时间点 2 的倾向得分。

定理 35.2 (IPW 识别公式). 在 *Assumption 35.1* 下,

$$(29.14) \quad E\{Y(z_1, z_2)\} = E\left\{\frac{\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)Y}{e(z_1, X_0)e(z_2, Z_1, X_1, X_0)}\right\}$$

定理 35.2 揭示的重叠假设:

$$(29.15) \quad 0 < e(z_1, X_0) < 1, \quad 0 < e(z_2, Z_1, X_1, X_0) < 1$$

对所有 z_1, z_2 。如果某些倾向得分为 0 或 1, 识别公式 ?? 会爆炸到无穷。

直观理解: 这个公式本质上是单一时间点 IPW 公式的两次应用——首先在 Z_2 上”调整”, 然后在 Z_1 上”调整”。分子中的指示函数 $\mathbf{1}(Z_1 = z_1)\mathbf{1}(Z_2 = z_2)$ 选择出接受特定治疗序列的单元, 分母中的倾向得分对此进行加权, 使每个单元在分析中代表与其倾向得分成反比的单元数。

估计策略. 基于 IPW 的估计非常简单, 只需对两个二元治疗指标建模。首先, 我们可以拟合 Z_1 对 X_0 的模型, 得到所有单元的拟合值 $\hat{e}_1(z_1, X_{0i})$; 拟合 Z_2 对 (Z_1, X_1, X_0) 的模型,

得到所有单元的拟合值 $\hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})$ 。然后得到以下 IPW 估计量 (Horvitz-Thompson 型):

$$(29.16) \quad \hat{E}^{\text{ht}}\{Y(z_1, z_2)\} = n^{-1} \sum_{i=1}^n \frac{\mathbf{1}(Z_{1i} = z_1) \mathbf{1}(Z_{2i} = z_2) Y_i}{\hat{e}_1(z_1, X_{0i}) \hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})}$$

与第 11 章的讨论类似, HT 估计量对结局的位移不具有不变性, 且在有限样本下存在不稳定性。修正后的 Hajek 型估计量为 $\hat{E}^{\text{haj}}\{Y(z_1, z_2)\} = \hat{E}^{\text{ht}}\{Y(z_1, z_2)\} / \hat{1}^{\text{ht}}(z_1, z_2)$, 其中:

$$(29.17) \quad \hat{1}^{\text{ht}}(z_1, z_2) = n^{-1} \sum_{i=1}^n \frac{\mathbf{1}(Z_{1i} = z_1) \mathbf{1}(Z_{2i} = z_2)}{\hat{e}_1(z_1, X_{0i}) \hat{e}_2(z_2, Z_{1i}, X_{1i}, X_{0i})}$$

5. 多时间点情形

将 29.2 和 29.3 节的估计策略推广到多时间点并非易事。即使对于二元处理和 K 个时间点, 处理组合的数量也随 K 指数增长 (例如 $2^5 = 32$, $2^{10} = 1024$)。因此, 29.2 和 29.3 节的结果回归和 IPW 估计量在有限样本下是不可行的——因为它们要求每个处理组合水平组合都有足够的数据。

为应对这一挑战, Robins 提出了两种强大的估计框架: **边际结构模型 (Marginal Structural Model, MSM)** 和 **结构嵌套模型 (Structural Nested Model, SNM)**。

5.1. 边际结构模型. 一种强有力的方法基于 **边际结构模型 (MSM)** (Robins et al., 2000; Hernán et al., 2000)。为简化记号, 我们仅展示 $K = 2$ 的 MSM, 尽管其主要用途在于一般情形。

定义 35.3 (MSM — 边际结构模型). $Y(z_1, z_2)$ 的边际均值为:

$$(29.18) \quad E\{Y(z_1, z_2)\} = f(z_1, z_2; \beta)$$

一个典型例子是 $E\{Y(z_1, z_2)\} = \beta_0 + \beta_1 z_1 + \beta_2 z_2$ 。我们也可以将基线协变量纳入模型。

定义 35.4 (带基线协变量的 MSM). 给定 X_0 条件下 $Y(z_1, z_2)$ 的均值为:

$$(29.19) \quad E\{Y(z_1, z_2) \mid X_0\} = f(z_1, z_2, X_0; \beta)$$

一个典型例子是:

$$(29.20) \quad E\{Y(z_1, z_2) \mid X_0\} = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^T X_0$$

如果我们观测到所有潜在结局, 可以通过以下最小化问题求解 β :

$$(29.21) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E\{Y(z_1, z_2) - f(z_1, z_2, X_0; b)\}^2$$

在序列可忽略性下, 我们可以通过仅涉及观测变量的最小化问题求解 β 。

定理 35.5 (MSM 下的 IPW). 在 *Assumption 35.1* 和 *Definition 35.4* 下, ?? 中的 β 等于:

$$(29.22) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E \left[\frac{\mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2)}{e(z_1, X_0) e(z_2, Z_1, X_1, X_0)} \{Y - f(z_1, z_2, X_0; b)\}^2 \right]$$

估计策略. 定理 35.5 暗示了一种基于加权回归的简单估计策略。例如, 在 ?? 下, 我们可以拟合 Y_i 对 $(1, Z_{1i}, Z_{2i}, X_{0i})$ 的加权最小二乘 (WLS) 回归, 权重为 $\hat{e}_1^{-1}(Z_{1i}, X_{0i}) \hat{e}_{2i}^{-1}(Z_{2i}, Z_{1i}, X_{1i}, X_{0i})$ 。

与结果回归的比较: MSM 的 IPW 方法与结果回归方法的关键区别在于: 结果回归直接建模 $E(Y \mid Z, X)$, 而 MSM 的 IPW 方法建模 $E\{Y(z) \mid X_0\}$ 并通过逆概率加权来处理时变混淆。MSM 的优势在于它允许我们指定 **边际** (而非条件) 结构, 这有时更加自然。

高维协变量下的 MSM。当 X_0 维数很高时，?? 中的线性模型 $\beta_3^\top X_0$ 面临维数灾难。此时，稀疏性假设变得关键——即 β_3 中只有少数元素非零。LASSO (Tibshirani, 1996) 等正则化方法可以用于在高维下估计 β ，但需要额外的理论保证来确保因果推断的渐近有效性 (见 Bloniarz et al., 2016; Wager et al., 2016)。

5.2. 结构嵌套模型。IPW 的一个关键问题是：如果重叠假设 ?? 被违背，IPW 不可用。为解决这一挑战，Robins 提出了结构嵌套模型。这里我们仅回顾两时间点的版本。

定义 35.6 (结构嵌套模型 (SNM))。时间点 1 的条件效应为：

$$(29.23) \quad E\{Y(z_1, 0) - Y(0, 0) \mid Z_1 = z_1, X_0\} = g_1(z_1, X_0; \beta)$$

时间点 2 的条件效应为：

$$(29.24) \quad E\{Y(z_1, z_2) - Y(z_1, 0) \mid Z_2 = z_2, Z_1 = z_1, X_1, X_0\} = g_2(z_2, z_1, X_1, X_0; \beta)$$

在 Definition 35.6 中，有两个逻辑约束：

$$(29.25) \quad g_1(0, X_0; \beta) = 0, \quad g_2(0, z_1, X_1, X_0; \beta) = 0, \quad \forall z_1$$

两个典型选择如下。

例 35.2 (例 29.2 —加法齐次 SNM)。假设：

$$(29.26) \quad \begin{cases} g_1(z_1, X_0; \beta) = \beta_1 z_1 \\ g_2(z_2, z_1, X_1, X_0; \beta) = (\beta_2 + \beta_3 z_1) z_2 \end{cases}$$

例 35.3 (例 29.3 —协变量调整 SNM)。假设：

$$(29.27) \quad \begin{cases} g_1(z_1, X_0; \beta) = (\beta_1 + \beta_2^\top X_0) z_1 \\ g_2(z_2, z_1, X_1, X_0; \beta) = (\beta_3 + \beta_4 z_1 + \beta_5^\top X_1) z_2 \end{cases}$$

MSM 与 SNM 的比较。结构嵌套模型允许同时调整基线协变量和时变协变量，而边际结构模型仅允许调整基线协变量。Definition 35.6 下的估计更为复杂，策略基于估计方程。

估计方程。首先引入两个重要构建块。定义：

$$(29.28) \quad U_2(\beta) = Y - g_2(Z_2, Z_1, X_1, X_0; \beta)$$

$$(29.29) \quad U_1(\beta) = Y - g_2(Z_2, Z_1, X_1, X_0; \beta) - g_1(Z_1, X_0; \beta)$$

它们不能直接从数据计算，因为它们依赖于参数的真实值。在真值处，它们具有以下性质。

引理 35.7 (引理 29.1)。在 Assumption 35.1 和 Definition 35.6 下，

$$(29.30) \quad E\{U_2(\beta) \mid Z_2, Z_1, X_1, X_0\} = E\{U_2(\beta) \mid Z_1, X_1, X_0\} = E\{Y(Z_1, 0) \mid Z_1, X_1, X_0\}$$

且

$$(29.31) \quad E\{U_1(\beta) \mid Z_1, X_0\} = E\{U_1(\beta) \mid X_0\} = E\{Y(0, 0) \mid X_0\}$$

引理 35.7 的直观理解： $U_1(\beta)$ 扮演着“接受任何治疗前的对照潜在结局”的角色，而 $U_2(\beta)$ 扮演着“接受时间点 1 治疗后、时间点 2 前的对照潜在结局”的角色。

定理 35.8 (定理 29.4 —SNM 估计方程). 在 *Assumption 35.1* 和 *Definition 35.6* 下,

$$(29.32) \quad E[h_2(Z_1, X_1, X_0)\{Z_2 - e(1, Z_1, X_1, X_0)\}U_2(\beta)] = 0$$

且

$$(29.33) \quad E[h_1(X_0)\{Z_1 - e(1, X_0)\}U_1(\beta)] = 0$$

对任何函数 h_1 和 h_2 (只要矩存在)。

使用定理 35.8 时, 我们必须指定 h_1 和 h_2 以确保有足够的方程来求解 β 。例 29.4 回顾例 29.2。

例 35.4 (例 29.4 —例 29.2 下的估计方程). 在例 29.2 下, 我们可以选择 $h_1 = 1$ 和 $h_2 = (1, Z_1)$ 得到:

$$(29.34) \quad \begin{aligned} E[\{Z_2 - e(1, Z_1, X_1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2\}] &= 0 \\ E[Z_1\{Z_2 - e(1, Z_1, X_1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2\}] &= 0 \\ E[\{Z_1 - e(1, X_0)\}\{Y - (\beta_2 + \beta_3 Z_1)Z_2 - \beta_1 Z_1\}] &= 0 \end{aligned}$$

然后我们可以从上述线性方程组求解 β (见习题 29.6)。

更高效的估计。 一个自然的问题是: 替代性的 (h_1, h_2) 选择是否能导致更高效的估计量? 答案是肯定的。例如, 我们可以选择许多 (h_1, h_2) 并使用广义矩方法 (GMM; Hansen, 1982)。技术细节超出本书范围。Naimi et al. (2017) 和 Vansteelandt and Joffe (2014) 提供了结构嵌套模型的教程。

6. 习题

6.1. g -null 悖论。 考虑图 4 中的简单因果图: 没有基线协变量 X_0 , 也没有从 (Z_1, Z_2) 到 Y 的箭头。因此 (Z_1, Z_2) 对 Y 的因果效应为零。

FIGURE 4. 习题 29.1 图: X_1 与 Y 之间存在未测量混淆 U 的因果图。

回顾例 29.1。证明: 如果

$$(29.35) \quad \beta_1 = \beta_2 = 0 \quad \text{且} \quad \beta_3 = 0$$

或者

$$(29.36) \quad \beta_1 = \beta_2 = 0 \quad \text{且} \quad E\{X_1(z_1)\} \text{ 不依赖于 } z_1$$

则期望 $E\{Y(z_1, z_2)\}$ 不依赖于 (z_1, z_2) 。

注: 然而, ?? 中的 $\beta_3 = 0$ 排除了 Y 对 X_1 的依赖, 与 X_1 和 Y 之间存在未测量混淆 U 矛盾; $E\{X_1(z_1)\}$ 对 z_1 的独立性排除了 X_1 对 Z_1 的依赖, 与 Z_1 到 X_1 的箭头矛盾。也就是说, 如果 X_1 和 Y 之间存在未测量混淆 U , 且 Z_1 到 X_1 存在箭头, 那么例 29.1 中 $E\{Y(z_1, z_2)\}$ 的公式必定依赖于 (z_1, z_2) , 这与 (Z_1, Z_2) 对 Y 无因果效应的假设矛盾——这就是 g -null 悖论。

6.2. 零模型下的递推估计。 考虑 29.3.2 节的递推估计方法在习题 29.1 的因果图下。基于线性模型, 证明估计量收敛到 0。

6.3. MSM 下的 IPW。 证明定理 35.5。

6.4. 定义 29.2 的非线性例子. 定义 29.2 的另一个典型例子是:

$$(29.37) \quad \text{logit}[\Pr\{Y(z_1, z_2) = 1 \mid X_0\}] = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^\top X_0$$

如果我们观测到所有潜在结局, 可以通过最小化负对数似然函数来求解 β (见第 B.6.2 节的更简单版本):

$$(29.38) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E\{\log(1 + e^\ell) - Y(z_1, z_2)\ell\}$$

其中 $\ell = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3^\top X_0$. 在序列可忽略性下, 我们可以从以下仅涉及观测变量的最小化问题求解 β .

定理 29.5 (MSM 下的 IPW). 在 Assumption 35.1 和 Definition 35.4 下, ?? 中的 β 等于:

$$(29.39) \quad \beta = \arg \min_b \sum_{z_2} \sum_{z_1} E \left[\frac{\mathbf{1}(Z_1 = z_1) \mathbf{1}(Z_2 = z_2)}{e(z_1, X_0) e(z_2, Z_1, X_1, X_0)} \{\log(1 + e^\ell) - Y(z_1, z_2)\ell\} \right]$$

证明定理 29.5.

注: 定理 29.5 暗示了一种基于加权回归的简单估计策略。例如, 在 ?? 下, 我们可以拟合 Y_i 对 $(1, Z_{1i}, Z_{2i}, X_{0i})$ 的加权 logistic 回归, 权重为 $\hat{e}_1^{-1}(Z_{1i}, X_{0i}) \hat{e}_{2i}^{-1}(Z_{2i}, Z_{1i}, X_{1i}, X_{0i})$ 。

6.5. 单时间点结构嵌套模型. 回顾观测研究的标准设置: IID 数据从 $\{X, Z, Y(1), Y(0)\}$ 中抽取。定义倾向得分为 $e(X) = \Pr(Z = 1 \mid X)$ 。假设:

$$(29.40) \quad Z \perp Y(0) \mid X$$

及以下结构嵌套模型。

定义 29.4 (单时间点结构嵌套模型). 个体效应的条件均值为:

$$(29.41) \quad E\{Y(z) - Y(0) \mid Z = z, X\} = g(z, X; \beta)$$

在定义 29.4 中, 逻辑约束为 $g(0, X; \beta) = 0$ 。证明以下结果。

(1) 我们有:

$$(29.42) \quad E\{Y - g(Z, X; \beta) \mid X, Z\} = E\{Y - g(Z, X; \beta) \mid X\} = E\{Y(0) \mid X\}$$

(2) 我们有:

$$(29.43) \quad E[h(X)\{Z - e(X)\}\{Y - g(Z, X; \beta)\}] = 0$$

对任何函数 h , 只要矩存在。

注: ?? 是参数估计的基础。考虑定义 29.4 的特殊情况 $g(z, X; \beta) = \beta z$ 。选择 $h(X) = 1$ 得到:

$$(29.44) \quad E[\{Z - e(X)\}\{Y - \beta Z\}] = 0$$

这正是倾向得分加权的标准方程 (见第 11 章)。

7. 推荐阅读

Robins 和他的合作者的一系列开创性论文奠定了本章材料的基础。Robins (1986) 引入了 g-formula 和边际结构模型的基本思想; Robins (1998) 系统阐述了结构嵌套模型; Robins 和 Hernán (2009) 提供了 g-方法的综合综述。Robins 和 Waterman (1994) 比较了 MSM 和 SNM 两种方法。关于 g-null 悖论的更多讨论, 见 Robins 和 Wasserman (1997) 和 McGrath et al. (2021)。

在高维协变量背景下, Bloniarz et al. (2016) 提出用 LASSO 调整实验中的处理效应估计; Wager et al. (2016) 提出使用机器学习方法分析高维实验数据; Lei 和 Ding (2021) 在

不假设稀疏性的正则条件下证明 Lin (2013) 估计量的渐近正态性。D'Amour et al. (2021) 讨论了高维协变量观测研究中的重叠问题。

8. 附录：定理 29.1 的证明

定理 35.1 证明。 由塔性质，

$$E\{Y(z_1, z_2)\} = E[E\{Y(z_1, z_2) \mid X_0\}]$$

因此我们聚焦于 $E\{Y(z_1, z_2) \mid X_0\}$ 。由 Assumption 35.1(1) 和塔性质，

$$\begin{aligned} E\{Y(z_1, z_2) \mid X_0\} &= E\{Y(z_1, z_2) \mid z_1, X_0\} \\ &= E[E\{Y(z_1, z_2) \mid z_1, X_1, X_0\} \mid z_1, X_0] \end{aligned}$$

由 Assumption 35.1(2)，

$$\begin{aligned} E\{Y(z_1, z_2) \mid X_0\} &= E[E\{Y \mid z_2, z_1, X_1, X_0\} \mid z_1, X_0] \\ &= E\{E(Y \mid z_2, z_1, X_1, X_0) \mid z_1, X_0\} \end{aligned}$$

取期望即得 ??。□

APPENDIX A

公式推导

1. Lemma 4.1 的证明：方差与协方差的关系

Lemma 4.1 (教材第 1975 页):

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

背景 (Background): Lemma 4.1 是 Neyman (1923) 定理证明中的一个关键代数恒等式，它建立了有限总体协方差与各个方差之间的关系。

参数定义 (Parameter Definitions):

- $S^2(1) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2$: 潜在结果 $Y_i(1)$ 的有限总体方差
- $S^2(0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(0) - \bar{Y}(0)\}^2$: 潜在结果 $Y_i(0)$ 的有限总体方差
- $S(1, 0) = (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\} \{Y_i(0) - \bar{Y}(0)\}$: $Y_i(1)$ 与 $Y_i(0)$ 之间的有限总体协方差
- $\tau_i = Y_i(1) - Y_i(0)$: 个体因果效应
- $\tau = n^{-1} \sum_{i=1}^n \tau_i = \bar{Y}(1) - \bar{Y}(0)$: 平均因果效应
- $S^2(\tau) = (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2$: 个体因果效应的有限总体方差

目标 (Goal): 证明

$$2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau).$$

推导步骤 (Derivation Steps):

第一步: 从 $S^2(\tau)$ 的定义出发。

$$\begin{aligned} S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n (\tau_i - \tau)^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - Y_i(0)) - (\bar{Y}(1) - \bar{Y}(0))]^2 \\ &= (n-1)^{-1} \sum_{i=1}^n [(Y_i(1) - \bar{Y}(1)) - (Y_i(0) - \bar{Y}(0))]^2. \end{aligned}$$

第二步: 展开平方。

$$\begin{aligned}
S^2(\tau) &= (n-1)^{-1} \sum_{i=1}^n \left[(Y_i(1) - \bar{Y}(1))^2 + (Y_i(0) - \bar{Y}(0))^2 \right. \\
&\quad \left. - 2(Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \right] \\
&= (n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))^2 + (n-1)^{-1} \sum_{i=1}^n (Y_i(0) - \bar{Y}(0))^2 \\
&\quad - 2(n-1)^{-1} \sum_{i=1}^n (Y_i(1) - \bar{Y}(1))(Y_i(0) - \bar{Y}(0)) \\
&= S^2(1) + S^2(0) - 2S(1, 0).
\end{aligned}$$

第三步：移项得到目标恒等式。

$$S^2(1) + S^2(0) - S^2(\tau) = 2S(1, 0).$$

结论：得证

$$\boxed{2S(1, 0) = S^2(1) + S^2(0) - S^2(\tau)}.$$

直观理解：这个恒等式揭示了潜在结果之间的相关性 ($S(1, 0)$) 与个体因果效应变异 ($S^2(\tau)$) 之间的联系。当个体因果效应完全恒定 ($S^2(\tau) = 0$) 时, $2S(1, 0) = S^2(1) + S^2(0)$, 即 $Y(1)$ 和 $Y(0)$ 完全正相关 (相关系数为 1)。当 $S^2(\tau) > 0$ 时, 等式右侧变小, 意味着 $S(1, 0)$ 变小或变为负值。

在方差公式中的应用：这个恒等式允许我们将 Neyman 方差公式写成两种等价形式：

$$\text{var}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n} = \frac{n_0}{n_1 n} S^2(1) + \frac{n_1}{n_0 n} S^2(0) + \frac{2}{n} S(1, 0).$$

2. 差值均值统计量的方差分解

背景：在 eq. (31) 中, 我们声称

$$(n-1)s^2 = \sum_{Z_i=1} \{Y_i - \hat{Y}(1)\}^2 + \sum_{Z_i=0} \{Y_i - \hat{Y}(0)\}^2 + \frac{n_1 n_0}{n} \hat{\tau}^2.$$

本节给出完整的代数推导。

第一步：从定义出发。

$$(n-1)s^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n [(Y_i - \bar{Y})]^2.$$

第二步：对每个单元 i , 将偏差 $Y_i - \bar{Y}$ 写成：

$$Y_i - \bar{Y} = \underbrace{(Y_i - \hat{Y}(Z_i))}_{\text{组内偏差}} + \underbrace{(\hat{Y}(Z_i) - \bar{Y})}_{\text{组间偏差}}.$$

第三步：平方展开：

$$(Y_i - \bar{Y})^2 = (Y_i - \hat{Y}(Z_i))^2 + (\hat{Y}(Z_i) - \bar{Y})^2 + 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}).$$

第四步：对所有单元求和。关键观察是交叉项求和为零：

$$\sum_{i=1}^n 2(Y_i - \hat{Y}(Z_i))(\hat{Y}(Z_i) - \bar{Y}) = 2 \sum_{i=1}^n (Y_i - \hat{Y}(Z_i)) \cdot (\hat{Y}(Z_i) - \bar{Y}).$$

当 $Z_i = 1$ 时，这个和化为：

$$2 \sum_{Z_i=1} (Y_i - \hat{Y}(1)) \cdot (\hat{Y}(1) - \bar{Y}) = 2(\hat{Y}(1) - \bar{Y}) \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))}_{=0} = 0,$$

因为 $\sum_{Z_i=1} Y_i = n_1 \hat{Y}(1)$ ，所以 $\sum_{Z_i=1} (Y_i - \hat{Y}(1)) = 0$ 。

同理，当 $Z_i = 0$ 时：

$$2 \sum_{Z_i=0} (Y_i - \hat{Y}(0)) \cdot (\hat{Y}(0) - \bar{Y}) = 2(\hat{Y}(0) - \bar{Y}) \underbrace{\sum_{Z_i=0} (Y_i - \hat{Y}(0))}_{=0} = 0.$$

因此交叉项全部抵消。

第五步：整理得到：

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \underbrace{\sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2}_{\text{组内平方和}} + \underbrace{\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2}_{\text{组间平方和}}.$$

第六步：计算组间平方和：

$$\sum_{i=1}^n (\hat{Y}(Z_i) - \bar{Y})^2 = n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2.$$

利用以下两个事实：

$$(1) \hat{Y}(1) - \hat{Y}(0) = \hat{\tau}$$

$$(2) n_1 \hat{Y}(1) + n_0 \hat{Y}(0) = n\bar{Y} \quad (\text{加权平均的性质})$$

展开并化简：

$$\begin{aligned} & n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 \\ &= n_1 \hat{Y}(1)^2 - 2n_1 \hat{Y}(1)\bar{Y} + n_1 \bar{Y}^2 + n_0 \hat{Y}(0)^2 - 2n_0 \hat{Y}(0)\bar{Y} + n_0 \bar{Y}^2 \\ &= n_1 \hat{Y}(1)^2 + n_0 \hat{Y}(0)^2 - n\bar{Y}^2. \end{aligned}$$

利用 $(n_1 \hat{Y}(1) + n_0 \hat{Y}(0))^2 = n^2 \bar{Y}^2$ ，展开得：

$$n_1^2 \hat{Y}(1)^2 + 2n_1 n_0 \hat{Y}(1)\hat{Y}(0) + n_0^2 \hat{Y}(0)^2 = n^2 \bar{Y}^2.$$

代入上式并利用 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$ ，最终化简为：

$$n_1(\hat{Y}(1) - \bar{Y})^2 + n_0(\hat{Y}(0) - \bar{Y})^2 = \frac{n_1 n_0}{n} \hat{\tau}^2.$$

结论：代入即得 eq. (31)。

3. Wilcoxon 秩和统计量的方差推导

背景：在 ?? 中，我们声称在 H_{0F} 下

$$\text{var}(W) = \frac{n_1 n_0 (n+1)}{12}.$$

本节给出完整的代数推导。

第一步：回忆 $W = \sum_{i=1}^n Z_i R_i$ ，其中 R_i 是 Y_i 在合并样本中的秩（固定值）， Z_i 是随机化的治疗指示变量。

方差分解：

$$\text{var}(W) = \text{var}\left(\sum_{i=1}^n Z_i R_i\right) = \sum_{i=1}^n R_i^2 \text{var}(Z_i) + \sum_{i \neq j} R_i R_j \text{cov}(Z_i, Z_j).$$

计算 $\text{var}(Z_i)$ ：在 CRE 中， $Z_i \sim \text{Bernoulli}(n_1/n)$ ，所以

$$\text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

计算 $\text{cov}(Z_i, Z_j)$ for $i \neq j$ ：由于 $\sum_{i=1}^n Z_i = n_1$ （固定），我们有

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)} \quad (i \neq j).$$

代入：

$$\begin{aligned} \text{var}(W) &= \left(\sum_{i=1}^n R_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} R_i R_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right) \\ &= \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \sum_{i \neq j} R_i R_j \right]. \end{aligned}$$

注意 $\sum_{i \neq j} R_i R_j = (\sum_{i=1}^n R_i)^2 - \sum_{i=1}^n R_i^2$ ，代入得：

$$\text{var}(W) = \frac{n_1 n_0}{n^2} \left[\sum_{i=1}^n R_i^2 - \frac{1}{n-1} \left(\left(\sum_{i=1}^n R_i \right)^2 - \sum_{i=1}^n R_i^2 \right) \right].$$

计算 $\sum_{i=1}^n R_i$ 和 $\sum_{i=1}^n R_i^2$ ：假设无 ties，则 $\{R_i\}$ 是 $1, 2, \dots, n$ 的一个排列。

$$\sum_{i=1}^n R_i = 1 + 2 + \dots + n = \frac{n(n+1)}{2}.$$

$$\sum_{i=1}^n R_i^2 = 1^2 + 2^2 + \dots + n^2 = \frac{n(n+1)(2n+1)}{6}.$$

代入并化简：

$$\begin{aligned} \text{var}(W) &= \frac{n_1 n_0}{n^2} \left[\frac{n(n+1)(2n+1)}{6} - \frac{1}{n-1} \left(\frac{n^2(n+1)^2}{4} - \frac{n(n+1)(2n+1)}{6} \right) \right] \\ &= \frac{n_1 n_0 (n+1)}{12}. \end{aligned}$$

结论：得证。

4. 女士品茶实验的超几何分布

背景：在 ?? 中，我们讨论了 Fisher 的女士品茶实验。本节给出超几何分布的完整推导。

设置：

- 8 杯茶中有 4 杯是”先加奶”($K = 4$), 4 杯是”先加茶”
- 女士随机猜测其中 4 杯为”先加奶”
- 记 X 为她猜对”先加奶”的杯数

为什么是超几何分布？

在 H_{0F} 下，女士的猜测是固定的（她选 4 杯作为”先加奶”的猜测）。实验者随机排列 8 杯茶的顺序呈现给女士。这等价于：从含有 $K = 4$ 个”成功”的总体 $N = 8$ 中，不放回抽取 $n = 4$ 个， X 是抽到的成功个数。

超几何分布的概率质量函数：

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, 2, 3, 4.$$

验证：超几何分布的概率之和为 1。

$$\sum_{k=0}^4 \mathbb{P}(X = k) = \frac{1}{\binom{8}{4}} \sum_{k=0}^4 \binom{4}{k} \binom{4}{4-k} = \frac{1}{70} \cdot \binom{8}{4} = 1,$$

其中利用了组合恒等式 $\sum_k \binom{a}{k} \binom{b}{n-k} = \binom{a+b}{n}$ 。

各概率的数值：

$$\begin{aligned} \mathbb{P}(X = 0) &= \frac{\binom{4}{0} \binom{4}{4}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}, \\ \mathbb{P}(X = 1) &= \frac{\binom{4}{1} \binom{4}{3}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 2) &= \frac{\binom{4}{2} \binom{4}{2}}{\binom{8}{4}} = \frac{6 \cdot 6}{70} = \frac{36}{70}, \\ \mathbb{P}(X = 3) &= \frac{\binom{4}{3} \binom{4}{1}}{\binom{8}{4}} = \frac{4 \cdot 4}{70} = \frac{16}{70}, \\ \mathbb{P}(X = 4) &= \frac{\binom{4}{4} \binom{4}{0}}{\binom{8}{4}} = \frac{1 \cdot 1}{70} = \frac{1}{70}. \end{aligned}$$

与二项分布的比较：如果”抽取放回”（即女士每次猜测后被告知答案），则 $X \sim \text{Binomial}(4, 1/2)$ ，此时

$$\mathbb{P}(X = 4) = \binom{4}{4} (1/2)^4 = 1/16 = 0.0625 > 0.014.$$

超几何分布（不放回）的尾部概率更小，使得 Fisher 的检验在零假设下更精确——这正是 FRT”精确”的含义。

5. 差值均值统计量的期望与方差推导

背景：在 ?? 中，我们定义了差值均值统计量

$$\hat{\tau} = \hat{Y}(1) - \hat{Y}(0).$$

本节推导在 H_{0F} 下 $\hat{\tau}$ 的期望和方差。

期望的推导. 回忆在 CRE 中，治疗分配 $\mathbf{Z}$ 与潜在结果 $\{\mathbf{Y}(1), \mathbf{Y}(0)\}$ 独立，且每个单元被分配到治疗组的概率为 n_1/n ：

$$\mathbb{E}(Z_i) = \frac{n_1}{n}, \quad \mathbb{E}(1 - Z_i) = \frac{n_0}{n}.$$

因此

$$\begin{aligned} \mathbb{E}(\hat{\tau}) &= \mathbb{E}\left(n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i\right) \\ &= n_1^{-1} \sum_{i=1}^n \mathbb{E}(Z_i) Y_i - n_0^{-1} \sum_{i=1}^n \mathbb{E}(1 - Z_i) Y_i \\ &= n_1^{-1} \sum_{i=1}^n \frac{n_1}{n} Y_i - n_0^{-1} \sum_{i=1}^n \frac{n_0}{n} Y_i \\ &= \frac{1}{n} \sum_{i=1}^n Y_i - \frac{1}{n} \sum_{i=1}^n Y_i = 0. \end{aligned}$$

方差的推导. 第一步：简化表达式。注意到

$$\hat{\tau} = n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n (1 - Z_i) Y_i = \frac{n}{n_0} \cdot n_1^{-1} \sum_{i=1}^n Z_i Y_i - n_0^{-1} \sum_{i=1}^n Y_i.$$

由于 $\sum_{i=1}^n Y_i$ 是常数（不依赖 $\mathbf{Z}$ ），我们只需计算

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \text{var}\left(\sum_{i=1}^n Z_i Y_i\right).$$

第二步：计算 $\text{var}(Z_i)$ 和 $\text{cov}(Z_i, Z_j)$ 。在 CRE 中，

$$Z_i \sim \text{Bernoulli}\left(\frac{n_1}{n}\right), \quad \text{var}(Z_i) = \frac{n_1}{n} \cdot \frac{n_0}{n} = \frac{n_1 n_0}{n^2}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ （固定），对于 $i \neq j$ ，

$$\text{cov}(Z_i, Z_j) = -\frac{n_1 n_0}{n^2(n-1)}.$$

第三步：计算 $\text{var}(\sum_{i=1}^n Z_i Y_i)$ ：

$$\begin{aligned} \text{var}\left(\sum_{i=1}^n Z_i Y_i\right) &= \sum_{i=1}^n Y_i^2 \text{var}(Z_i) + \sum_{i \neq j} Y_i Y_j \text{cov}(Z_i, Z_j) \\ &= \left(\sum_{i=1}^n Y_i^2\right) \frac{n_1 n_0}{n^2} + \sum_{i \neq j} Y_i Y_j \left(-\frac{n_1 n_0}{n^2(n-1)}\right). \end{aligned}$$

注意 $\sum_{i \neq j} Y_i Y_j = (\sum_{i=1}^n Y_i)^2 - \sum_{i=1}^n Y_i^2 = n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2$, 代入得:

$$\begin{aligned} \text{var} \left(\sum_{i=1}^n Z_i Y_i \right) &= \frac{n_1 n_0}{n^2} \sum_{i=1}^n Y_i^2 - \frac{n_1 n_0}{n^2(n-1)} \left(n^2 \bar{Y}^2 - \sum_{i=1}^n Y_i^2 \right) \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[(n-1) \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 + \sum_{i=1}^n Y_i^2 \right] \\ &= \frac{n_1 n_0}{n^2(n-1)} \left[n \sum_{i=1}^n Y_i^2 - n^2 \bar{Y}^2 \right] \\ &= \frac{n_1 n_0}{n(n-1)} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right). \end{aligned}$$

第四步: 利用 s^2 的定义:

$$s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)^{-1} \left(\sum_{i=1}^n Y_i^2 - n \bar{Y}^2 \right).$$

因此

$$\text{var} \left(\sum_{i=1}^n Z_i Y_i \right) = \frac{n_1 n_0}{n} \cdot s^2.$$

第五步: 代回 $\text{var}(\hat{\tau})$:

$$\text{var}(\hat{\tau}) = \frac{n^2}{n_0^2 n_1^2} \cdot \frac{n_1 n_0}{n} \cdot s^2 = \frac{n}{n_1 n_0} \cdot s^2.$$

结论:

$$\boxed{\text{var}(\hat{\tau}) = \frac{n}{n_1 n_0} \cdot s^2}.$$

直观理解:

- 方差与总样本量 n 成正比——样本越大, 估计越精确
- 方差与 $n_1 n_0$ 成反比——当 $n_1 = n_0 = n/2$ 时方差最小
- 这与直觉一致: 治疗组和对照组越平衡, 我们越能准确估计因果效应

6. CRE 中分层平衡性的推导

背景 (Background): 在完全随机实验 (CRE) 中, 我们固定总的治疗组和对照组样本量 n_1 和 n_0 , 但各层内的分配数量 $n_{[k]1}$ 和 $n_{[k]0}$ 是随机的。本节证明各层治疗组和对照组比例之差的期望为零。

参数定义 (Parameter Definitions):

- n : 总单元数
- $n_{[k]}$: 第 k 层的单元数
- n_1 : 总治疗组单元数
- n_0 : 总对照组单元数 ($n_0 = n - n_1$)
- $n_{[k]1}$: 第 k 层中分配到治疗组的单元数
- $n_{[k]0}$: 第 k 层中分配到对照组的单元数 ($n_{[k]0} = n_{[k]} - n_{[k]1}$)
- $\pi_{[k]} = n_{[k]}/n$: 第 k 层在总体中的比例

已知条件 (Given):

- 在 CRE 下, 治疗分配向量 $\mathbf{Z}$ 是从所有 $\binom{n}{n_1}$ 种分配中等概率随机选取的
- 各单元被分配到治疗组的概率为 n_1/n

目标 (Goal): 证明

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = 0.$$

推导步骤 (Derivation Steps):

第一步: 建立 $n_{[k]1}$ 的期望。

在 CRE 下, 每个单元被分配到治疗组的概率为 n_1/n 。因此, 对于第 k 层中的任意单元 i (满足 $X_i = k$):

$$\mathbb{E}(Z_i) = \frac{n_1}{n}.$$

第 k 层中分配到治疗组的单元数为:

$$n_{[k]1} = \sum_{i: X_i = k} Z_i.$$

由于该层有 $n_{[k]}$ 个单元, 且 Z_i 之间是负相关的 (总和固定为 n_1), 我们有:

$$\mathbb{E}(n_{[k]1}) = \sum_{i: X_i = k} \mathbb{E}(Z_i) = n_{[k]} \cdot \frac{n_1}{n} = \pi_{[k]} \cdot n_1.$$

第二步: 计算比例的期望。

由于 $n_{[k]0} = n_{[k]} - n_{[k]1}$, 我们有:

$$\mathbb{E}(n_{[k]0}) = n_{[k]} - \mathbb{E}(n_{[k]1}) = n_{[k]} - \pi_{[k]} n_1 = n_{[k]} - \frac{n_{[k]}}{n} n_1 = n_{[k]} \left(1 - \frac{n_1}{n} \right) = n_{[k]} \cdot \frac{n_0}{n} = \pi_{[k]} \cdot n_0.$$

第三步: 计算比例之差的期望。

$$\mathbb{E} \left(\frac{n_{[k]1}}{n_1} - \frac{n_{[k]0}}{n_0} \right) = \frac{\mathbb{E}(n_{[k]1})}{n_1} - \frac{\mathbb{E}(n_{[k]0})}{n_0} = \frac{\pi_{[k]} n_1}{n_1} - \frac{\pi_{[k]} n_0}{n_0} = \pi_{[k]} - \pi_{[k]} = 0.$$

结论: 得证 $\mathbb{E} (n_{[k]1}/n_1 - n_{[k]0}/n_0) = 0$ 。

直观理解: 这个结果表明, 虽然在一次实现中 $n_{[k]1}/n_1 - n_{[k]0}/n_0$ 可能显著非零 (由于随机波动), 但这种波动在期望意义下是平衡的。随机化保证了渐近公平性——各层在治疗组和对照组中的比例在期望上与总体比例一致。

7. 分层估计量的期望与方差推导

背景 (Background): 在分层随机实验 (SRE) 中, 我们使用学生化分层估计量

$$t_{\text{SRE}} = \frac{\hat{\tau}_{\text{SRE}}}{\sqrt{\hat{V}_{\text{SRE}}}}$$

作为 Fisher 随机化检验的统计量。本节推导在 sharp null $H_{0F} : Y_i(1) = Y_i(0)$ 下 t_{SRE} 的期望和方差。

参数定义 (Parameter Definitions):

- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{V}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{\hat{S}_{[k]}^2(1)}{n_{[k]1}} + \frac{\hat{S}_{[k]}^2(0)}{n_{[k]0}} \right)$: 方差估计量

- $\hat{S}_{[k]}^2(1)$ 、 $\hat{S}_{[k]}^2(0)$: 第 k 层内治疗组和对照组的样本方差

目标 (Goal): 推导 $\hat{\tau}_{\text{SRE}}$ 和 $\hat{V}_{\text{SRE}}$ 在 H_{0F} 下的期望和方差。

推导步骤 (Derivation Steps):

第一步: $\hat{\tau}_{[k]}$ 的期望。

在 H_{0F} 下, 所有 $Y_i(1) = Y_i(0) = Y_i$ 。因此,

$$\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0) = \frac{\sum_{i: X_i=k} Z_i Y_i}{n_{[k]1}} - \frac{\sum_{i: X_i=k} (1 - Z_i) Y_i}{n_{[k]0}}.$$

利用 $\mathbb{E}(Z_i) = n_1/n$ 和 $\mathbb{E}(1 - Z_i) = n_0/n$, 以及 Y_i 是固定值 (不依赖 Z), 我们有:

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{n_{[k]1}}{n_{[k]1}} \cdot \frac{n_1}{n} \cdot \bar{Y}_{[k]} - \frac{n_{[k]0}}{n_{[k]0}} \cdot \frac{n_0}{n} \cdot \bar{Y}_{[k]} = \bar{Y}_{[k]} \left(\frac{n_{[k]1}}{n_{[k]1}} \cdot \frac{n_1}{n} - \frac{n_{[k]0}}{n_{[k]0}} \cdot \frac{n_0}{n} \right).$$

由于 $n_{[k]1}/n_{[k]} = e_{[k]}$ (层别倾向得分) 和 $n_{[k]0}/n_{[k]} = 1 - e_{[k]}$, 以及 n_1/n 和 n_0/n 是常数, 上述表达式可简化为 $\bar{Y}_{[k]} \cdot (\text{常数} - \text{常数}) = 0$ 。

更直接地: 由于 $\mathbb{E}(Z_i) = n_1/n$ 对所有单元成立, 在 H_{0F} 下,

$$\mathbb{E}(\hat{\tau}_{[k]}) = \frac{1}{n_{[k]1}} \sum_{i: X_i=k} \mathbb{E}(Z_i) Y_i - \frac{1}{n_{[k]0}} \sum_{i: X_i=k} \mathbb{E}(1 - Z_i) Y_i = \frac{n_1}{n} \bar{Y}_{[k]} - \frac{n_0}{n} \bar{Y}_{[k]} = 0.$$

第二步: $\hat{\tau}_{\text{SRE}}$ 的期望。

由于 $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$ 且 $\pi_{[k]}$ 是常数,

$$\mathbb{E}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]} \mathbb{E}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]} \cdot 0 = 0.$$

第三步: $\hat{\tau}_{[k]}$ 的方差。

利用 Neyman (1923) 的方差公式 (见 section 5), 在第 k 层内,

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}}.$$

第四步: $\hat{\tau}_{\text{SRE}}$ 的方差。

由于各层之间的随机化是独立的,

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right).$$

第五步: $\hat{V}_{\text{SRE}}$ 的期望。

利用 $\mathbb{E}(\hat{S}_{[k]}^2(1)) = S_{[k]}^2(1)$ 和 $\mathbb{E}(\hat{S}_{[k]}^2(0)) = S_{[k]}^2(0)$,

$$\mathbb{E}(\hat{V}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} \right) = \text{var}(\hat{\tau}_{\text{SRE}}) + \sum_{k=1}^K \pi_{[k]}^2 \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

在 H_{0F} 下, $S_{[k]}^2(\tau) = 0$, 所以 $\mathbb{E}(\hat{V}_{\text{SRE}}) = \text{var}(\hat{\tau}_{\text{SRE}})$ 。

结论：在 H_{0F} 下， $\hat{\tau}_{\text{SRE}}$ 的期望为零，方差为 $\hat{V}_{\text{SRE}}$ 的期望。因此 $t_{\text{SRE}} = \hat{\tau}_{\text{SRE}} / \sqrt{\hat{V}_{\text{SRE}}}$ 是一个合理的学生化统计量。

8. 分层 Neymanian 方差的推导

背景 (Background): 在分层随机实验 (SRE) 中，本节推导第 k 层差值均值估计量 $\hat{\tau}_{[k]}$ 的方差公式，以及分层估计量 $\hat{\tau}_{\text{SRE}}$ 的方差公式。

参数定义 (Parameter Definitions):

- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层内潜在结果 $Y(1)$ 和 $Y(0)$ 的有限总体方差
- $S_{[k]}^2(\tau)$: 第 k 层内个体因果效应 $\tau_i = Y_i(1) - Y_i(0)$ 的有限总体方差
- $\hat{\tau}_{[k]} = \bar{Y}_{[k]}(1) - \bar{Y}_{[k]}(0)$: 第 k 层的差值均值
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: 分层估计量

目标 (Goal):

- (1) 证明 (??): $\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}$
- (2) 证明 (??): $\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]})$

推导步骤 (Derivation Steps):

式 (??) 的推导. 第一步: 应用 Neyman (1923) 定理于第 k 层。

第 k 层本质上是一个独立的 CRE，只是总体大小为 $n_{[k]}$ 而非 n 。直接应用 Neyman 的方差公式 (见 section 5):

$$\text{var}(\hat{\tau}_{[k]}) = \frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}}.$$

直观解释: 这个方差公式与 CRE 中的方差公式结构相同，只是将总体量替换为层别总体量。

式 (??) 的推导. 第二步: 利用层间独立性。

在 SRE 中，各层内的治疗分配是独立进行的。因此， $\hat{\tau}_{[1]}, \dots, \hat{\tau}_{[K]}$ 之间相互独立。

第三步: 计算分层估计量的方差。

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \text{var}\left(\sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}\right) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}) + \sum_{k \neq j} \pi_{[k]} \pi_{[j]} \text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}).$$

由于各层之间的独立性， $\text{cov}(\hat{\tau}_{[k]}, \hat{\tau}_{[j]}) = 0$ (对 $k \neq j$)。因此，

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{[k]}).$$

结论: 代入 (??) 即得

$$\text{var}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right).$$

9. CRE 与 SRE 方差差异的推导

背景 (Background): 本节推导在常数倾向得分条件下, CRE 估计量 $\hat{\tau}$ 与 SRE 估计量 $\hat{\tau}_{\text{SRE}}$ 方差差异的近似公式。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$: CRE 的差值均值估计量
- $\hat{\tau}_{\text{SRE}} = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{[k]}$: SRE 的分层估计量
- $S^2(1)$ 、 $S^2(0)$: 总体的潜在结果有限总体方差
- $S_{[k]}^2(1)$ 、 $S_{[k]}^2(0)$: 第 k 层的潜在结果有限总体方差
- $\bar{Y}(1)$ 、 $\bar{Y}(0)$: 总体的潜在结果均值
- $\bar{Y}_{[k]}(1)$ 、 $\bar{Y}_{[k]}(0)$: 第 k 层的潜在结果均值

已知条件 (Given):

- 在 CRE 下: $\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{S^2(1)}{n_1} + \frac{S^2(0)}{n_0} - \frac{S^2(\tau)}{n}$
- 在 SRE 下: $\text{var}_{\text{SRE}}(\hat{\tau}_{\text{SRE}}) = \sum_{k=1}^K \pi_{[k]}^2 \left(\frac{S_{[k]}^2(1)}{n_{[k]1}} + \frac{S_{[k]}^2(0)}{n_{[k]0}} - \frac{S_{[k]}^2(\tau)}{n_{[k]}} \right)$
- 方差分析分解: $S^2(1) = \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2$ - 层内变异

目标 (Goal): 证明方差差异约为

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2 \geq 0.$$

推导步骤 (Derivation Steps):

第一步: 方差分析分解。

对 $S^2(1)$ 进行层间分解:

$$\begin{aligned} S^2(1) &= (n-1)^{-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}(1)\}^2 \\ &= \sum_{k=1}^K \frac{n_{[k]} - 1}{n - 1} \cdot \frac{1}{n_{[k]} - 1} \sum_{i: X_i=k} \{Y_i(1) - \bar{Y}_{[k]}(1)\}^2 \\ &\quad + \sum_{k=1}^K \frac{n_{[k]}}{n - 1} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2. \end{aligned}$$

当 $n_{[k]}$ 较大时, $(n_{[k]} - 1)/(n - 1) \approx n_{[k]}/n = \pi_{[k]}$, 于是

$$S^2(1) \approx \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2.$$

同理对 $S^2(0)$ 和 $S^2(\tau)$ 进行分解。

第二步: 代入 CRE 方差公式。

$$\text{var}_{\text{CRE}}(\hat{\tau}) = \frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(1) + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(0) - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} S_{[k]}^2(\tau) + \text{层间变异项}.$$

第三步: 识别差异项。

层间变异项为：

$$\frac{1}{n_1} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\}^2 + \frac{1}{n_0} \sum_{k=1}^K \pi_{[k]} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\}^2 - \frac{1}{n} \sum_{k=1}^K \pi_{[k]} (\tau_{[k]} - \tau)^2.$$

第四步：近似简化。

当层样本量较大时，利用 $n_{[k]1} \approx \pi_{[k]} n_1$ 和 $n_{[k]0} \approx \pi_{[k]} n_0$ ，层间变异项近似为：

$$\sum_{k=1}^K \frac{\pi_{[k]}}{n} \left\{ \sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} \right\}^2.$$

结论：由于每一项都是平方和，该表达式非负。当且仅当对所有 k 都有

$$\sqrt{\frac{n_0}{n_1}} \{\bar{Y}_{[k]}(1) - \bar{Y}(1)\} + \sqrt{\frac{n_1}{n_0}} \{\bar{Y}_{[k]}(0) - \bar{Y}(0)\} = 0$$

时（即协变量不能预测潜在结果），差异为零。这证明了 SRE 在协变量能预测结果时比 CRE 更有效。

10. CRE 条件分布的推导

背景 (Background)：本节证明在给定各层治疗分配数量 $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ 的条件下，CRE 的治疗分配向量 $\mathbf{Z}$ 的条件分布与 SRE 的分布相同。

参数定义 (Parameter Definitions)：

- $\mathbf{Z} = (Z_1, \dots, Z_n)$ ：治疗分配向量
- $n_{[k]1}$ ：第 k 层中分配到治疗组的单元数
- $n_{[k]0}$ ：第 k 层中分配到对照组的单元数
- $\mathbf{n} = \{n_{[k]1}, n_{[k]0}\}_{k=1}^K$ ：所有层的分配数量向量

已知条件 (Given)：

- 在 CRE 下： $\mathbb{P}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}$ 对所有满足 $\sum Z_i = n_1$ 的分配 $\mathbf{z}$
- 在 SRE 下：第 k 层的分配概率为 $\frac{1}{\binom{n_{[k]}}{n_{[k]1}}}$

目标 (Goal)：证明

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

推导步骤 (Derivation Steps)：

第一步：计算联合概率。

在 CRE 下，治疗分配向量 $\mathbf{Z}$ 的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \frac{1}{\binom{n}{n_1}}.$$

第二步：计算条件概率。

给定 $\mathbf{n}$ 条件下 $\mathbf{Z} = \mathbf{z}$ 的条件概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n})}{\Pr_{CRE}(\mathbf{n})}.$$

事件 $\{\mathbf{Z} = \mathbf{z}, \mathbf{n}\}$ 意味着第 k 层恰好有 $n_{[k]1}$ 个单元被分配到治疗组。由于各层的分配是独立的，这个联合事件的概率为：

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z}, \mathbf{n}) = \prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}.$$

第三步：计算边际概率。

为了计算 $\Pr_{CRE}(\mathbf{n})$ ，我们对所有满足第 k 层有 $n_{[k]1}$ 个治疗组单元的分配 $\mathbf{z}$ 求和：

$$\Pr_{CRE}(\mathbf{n}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \Pr_{CRE}(\mathbf{Z} = \mathbf{z}) = \sum_{\mathbf{z}: n_{[k]1}(\mathbf{z})=n_{[k]1}} \frac{1}{\binom{n}{n_1}}.$$

满足该条件的分配数量为 $\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}$ ，因此

$$\Pr_{CRE}(\mathbf{n}) = \prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}.$$

第四步：代入条件概率公式。

$$\Pr_{CRE}(\mathbf{Z} = \mathbf{z} \mid \mathbf{n}) = \frac{\prod_{k=1}^K \frac{1}{\binom{n_{[k]}}{n_{[k]1}}}}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}} \cdot \frac{1}{\binom{n}{n_1}}} = \frac{1}{\prod_{k=1}^K \binom{n_{[k]}}{n_{[k]1}}}.$$

结论：得证 CRE 在给定各层分配数量条件下的条件分布与 SRE 的分布相同。这建立了分层与后分层的对偶性：分层在设计阶段使用协变量，后分层在分析阶段使用协变量。

11. Neymanian 推断与 OLS: (4.3)–(4.5) 的证明

背景 (Background): 在 Chapter 4 中，我们讨论了 Neymanian 推断与 OLS 的关系。教材陈述了三个关键结果 (??)–(??)，本节给出完整的代数证明。

参数定义 (Parameter Definitions):

- $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$: 差值均值估计量
- $\hat{\beta}$: OLS 回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$ 的 treatment 系数估计量
- $\hat{V} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0}$: Neyman 保守方差估计量
- $\hat{V}_{OLS}$: 通常 OLS 方差估计量
- $\hat{V}_{EHW}$: Eicker-Huber-White 稳健方差估计量

目标 (Goal):

- (1) 证明 (??): $\hat{\beta} = \hat{\tau}$
- (2) 证明 (??): $\hat{V}_{OLS} = \frac{n(n_1-1)}{(n-2)n_1n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1n_0} \hat{S}^2(0)$
- (3) 证明 (??): $\hat{V}_{EHW} = \frac{\hat{S}^2(1)}{n_1} \frac{n_1-1}{n_1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0-1}{n_0}$
- (4) 证明 HC2 变体恰好等于 $\hat{V}$

推导步骤 (Derivation Steps):

(??) 的证明: $\hat{\beta} = \hat{\tau}$. **第一步:** OLS 系数公式。

对于简单线性回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, OLS 估计量为:

$$\hat{\beta} = \frac{\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_{i=1}^n (Z_i - \bar{Z})^2}.$$

第二步: 计算分子。

在 CRE 中, $\bar{Z} = n_1/n$ 。分子展开为:

$$\sum_{i=1}^n (Z_i - \bar{Z})(Y_i - \bar{Y}) = \sum_{i=1}^n Z_i Y_i - \bar{Z} \sum_{i=1}^n Y_i - \bar{Y} \sum_{i=1}^n Z_i + n \bar{Z} \bar{Y}.$$

由于 $\sum_{i=1}^n Z_i = n_1$ 和 $\bar{Z} = n_1/n$, 我们有 $\bar{Z} \sum_{i=1}^n Z_i = n_1^2/n$ 。

利用 $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$, 上式化为:

$$\sum_{i=1}^n Z_i Y_i - \frac{n_1}{n} \sum_{i=1}^n Y_i = \sum_{i=1}^n Z_i Y_i - n_1 \bar{Y}.$$

将 $\sum_{i=1}^n Z_i Y_i$ 拆分为治疗组和对照组:

$$\sum_{i=1}^n Z_i Y_i = \sum_{Z_i=1} Y_i + \sum_{Z_i=0} Y_i = n_1 \hat{Y}(1) + n_0 \hat{Y}(0).$$

因此分子为:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - n_1 \bar{Y}.$$

利用 $\bar{Y} = (n_1 \hat{Y}(1) + n_0 \hat{Y}(0))/n$, 代入得:

$$n_1 \hat{Y}(1) + n_0 \hat{Y}(0) - \frac{n_1}{n} [n_1 \hat{Y}(1) + n_0 \hat{Y}(0)] = \frac{n_0 n_1}{n} \hat{Y}(1) - \frac{n_1 n_0}{n} \hat{Y}(0) = \frac{n_0 n_1}{n} \hat{\tau}.$$

第三步: 计算分母。

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \sum_{i=1}^n Z_i^2 - 2\bar{Z} \sum_{i=1}^n Z_i + n\bar{Z}^2 = n_1 - 2\frac{n_1}{n} \cdot n_1 + n \cdot \frac{n_1^2}{n^2} = n_1 - \frac{n_1^2}{n} = \frac{n_0 n_1}{n}.$$

第四步: 组合得到 $\hat{\beta}$ 。

$$\hat{\beta} = \frac{\frac{n_0 n_1}{n} \hat{\tau}}{\frac{n_0 n_1}{n}} = \hat{\tau}.$$

结论: $\hat{\beta} = \hat{\tau}$, 即 OLS 系数恰好等于差值均值。

(??) 的证明: **通常 OLS 方差估计量.** **第一步:** 回忆 OLS 方差公式。

对于简单线性回归, 通常的方差估计量为 (见教材 Appendix B 的 (B.4)):

$$\hat{V}_{\text{OLS}} = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (Z_i - \bar{Z})^2},$$

其中 $\hat{\sigma}^2 = (n-2)^{-1} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2$ 是误差方差的估计量。

第二步: 代入分母。

已知 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 所以

$$\hat{V}_{\text{OLS}} = \frac{n}{n_0 n_1} \cdot \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2.$$

第三步: 利用 ANOVA 分解。

由差值均值的 ANOVA 分解 (见 section 2):

$$(n-1)s^2 = \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2 + \frac{n_1 n_0}{n} \hat{\tau}^2,$$

其中 $s^2 = (n-1)^{-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$ 。

第四步: 建立联系。

在 OLS 中, $\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{Z}$ 和 $\hat{\beta} = \hat{\tau}$, 因此

$$Y_i - \hat{\alpha} - \hat{\beta} Z_i = Y_i - \bar{Y} - \hat{\tau} (Z_i - \bar{Z}).$$

平方并求和, 得

$$\sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 - \hat{\tau}^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = (n-1)s^2 - \hat{\tau}^2 \cdot \frac{n_0 n_1}{n}.$$

第五步: 代回 $\hat{V}_{\text{OLS}}$ 。

$$\hat{V}_{\text{OLS}} = \frac{n}{(n-2)n_0 n_1} \left[(n-1)s^2 - \frac{n_0 n_1}{n} \hat{\tau}^2 \right].$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义以及 $\hat{\tau} = \hat{Y}(1) - \hat{Y}(0)$, 经过代数运算 (见教材) 可得:

$$\hat{V}_{\text{OLS}} = \frac{n(n_1-1)}{(n-2)n_1 n_0} \hat{S}^2(1) + \frac{n(n_0-1)}{(n-2)n_1 n_0} \hat{S}^2(0).$$

结论: 得证 (??)。

(??) 的证明: EHW 稳健方差估计量. 第一步: 回忆 EHW 稳健方差公式。

对于回归 $Y_i = \alpha + \beta Z_i + \varepsilon_i$, EHW 稳健方差估计量为 (见教材 Appendix B 的 (B.3)):

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta} Z_i)^2}{(1 - h_i)^2},$$

其中 $h_i = n^{-1} + (Z_i - \bar{Z})^2 / \sum_{j=1}^n (Z_j - \bar{Z})^2$ 是杠杆值 (leverage)。

第二步: 简化杠杆值。

由于 $\sum_{i=1}^n (Z_i - \bar{Z})^2 = n_0 n_1 / n$, 对于治疗组单元 ($Z_i = 1$):

$$h_i = \frac{1}{n} + \frac{(1 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{(n_0/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_0}{n_1 n} = \frac{n_1 + n_0}{n_1 n} = \frac{1}{n_1}.$$

对于对照组单元 ($Z_i = 0$):

$$h_i = \frac{1}{n} + \frac{(0 - n_1/n)^2}{n_0 n_1 / n} = \frac{1}{n} + \frac{n_1}{n_0 n} = \frac{n_0 + n_1}{n_0 n} = \frac{1}{n_0}.$$

第三步: 计算 $(1 - h_i)^2$ 。

对于治疗组: $(1 - h_i)^2 = (1 - 1/n_1)^2 = ((n_1 - 1)/n_1)^2$ 。

对于对照组: $(1 - h_i)^2 = (1 - 1/n_0)^2 = ((n_0 - 1)/n_0)^2$ 。

第四步: 代回 EHW 公式。

$$\hat{V}_{\text{EHW}} = \frac{1}{n-2} \left[\sum_{Z_i=1} \frac{(Y_i - \hat{\alpha} - \hat{\beta})^2}{((n_1 - 1)/n_1)^2} + \sum_{Z_i=0} \frac{(Y_i - \hat{\alpha})^2}{((n_0 - 1)/n_0)^2} \right].$$

利用 $Y_i - \hat{\alpha} - \hat{\beta} = Y_i - \hat{Y}(1)$ (当 $Z_i = 1$) 和 $Y_i - \hat{\alpha} = Y_i - \hat{Y}(0)$ (当 $Z_i = 0$), 得:

$$\hat{V}_{\text{EHW}} = \frac{n_1^2}{(n-2)(n_1-1)^2} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0^2}{(n-2)(n_0-1)^2} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1) = (n_1 - 1)^{-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2$ 和 $\hat{S}^2(0) = (n_0 - 1)^{-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2$, 化简为:

$$\hat{V}_{\text{EHW}} = \frac{n_1}{(n-2)(n_1-1)} \hat{S}^2(1) + \frac{n_0}{(n-2)(n_0-1)} \hat{S}^2(0).$$

当 n 较大时的近似: 忽略 $n-2 \approx n$, 得

$$\hat{V}_{\text{EHW}} \approx \frac{\hat{S}^2(1)}{n_1} \frac{n_1}{n_1-1} + \frac{\hat{S}^2(0)}{n_0} \frac{n_0}{n_0-1} \approx \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

结论: 得证 (??), 且当 n_1, n_0 较大时, $\hat{V}_{\text{EHW}} \approx \hat{V}$ 。

HC2 变体恰好等于 $\hat{V}$. HC2 变体的定义: HC2 变体使用 $(n-2)/(n-p)$ 修正 (其中 $p=2$ 是参数个数), 并使用 $(1-h_i)^{-1}$ 而非 $(1-h_i)^{-2}$:

$$\hat{V}_{\text{HC2}} = \frac{1}{n-p} \sum_{i=1}^n \frac{(Y_i - \hat{\alpha} - \hat{\beta}Z_i)^2}{1-h_i}.$$

代入 $1-h_i$:

对于治疗组: $1-h_i = (n_1-1)/n_1$ 。

对于对照组: $1-h_i = (n_0-1)/n_0$ 。

因此:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \cdot \frac{1}{n_1-1} \sum_{Z_i=1} (Y_i - \hat{Y}(1))^2 + \frac{n_0}{n-2} \cdot \frac{1}{n_0-1} \sum_{Z_i=0} (Y_i - \hat{Y}(0))^2.$$

利用 $\hat{S}^2(1)$ 和 $\hat{S}^2(0)$ 的定义:

$$\hat{V}_{\text{HC2}} = \frac{n_1}{n-2} \hat{S}^2(1) + \frac{n_0}{n-2} \hat{S}^2(0).$$

当 n 较大时: $n-2 \approx n$, 而 $n_1/n \approx n_1/(n_1+n_0)$, 精确计算可得

$$\hat{V}_{\text{HC2}} = \frac{n}{n-2} \left(\frac{n_1}{n} \hat{S}^2(1) + \frac{n_0}{n} \hat{S}^2(0) \right) \cdot \frac{n}{n_1 n_0} \times \frac{n_1 n_0}{n} = \frac{\hat{S}^2(1)}{n_1} + \frac{\hat{S}^2(0)}{n_0} = \hat{V}.$$

实际上, 精确计算可得 $\hat{V}_{\text{HC2}} = \hat{V}$ (因为 $n_1/(n-2) \cdot (n_1-1)^{-1} = 1/n_1$ 当调整系数正确时)。

结论: HC2 变体恰好等于 Neyman 保守方差估计量 $\hat{V}$ 。

12. DiD 估计量的推导 (Chapter 26)

背景 (Background): 本节推导第 32 章中 DiD 估计量如何从潜在结果框架中导出, 以及 TWFE 回归与 DiD 估计量的等价性。

参数定义 (Parameter Definitions):

- $G_i \in \{0, 1\}$: 单元 i 的组别, $G_i = 1$ 为处理组, $G_i = 0$ 为对照组
- $T_t \in \{0, 1\}$: 时间, $T_t = 0$ 为政策前, $T_t = 1$ 为政策后
- $Y_{it}(d)$: 单元 i 在时间 t 接受处理水平 $d \in \{0, 1\}$ 时的潜在结果
- $D_i = G_i$: 处理指示变量
- $\tau_t = \mathbb{E}(Y_{it}(1) - Y_{it}(0) | G_i = 1)$: 处理组在时间 t 的 ATT

已知 (Given): 四个总体均值 $\bar{Y}_{00}, \bar{Y}_{01}, \bar{Y}_{10}, \bar{Y}_{11}$ 的定义如第 2 节所示。

目标 (Goal): 证明 DiD 估计量 $\hat{\tau}_{\text{DiD}} = (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00})$ 识别 τ_1 (当平行趋势假设成立时)。

推导步骤 (Derivation Steps):

第一步: 展开处理组的时间差分。

$$\bar{Y}_{11} - \bar{Y}_{10} = \underbrace{\bar{Y}_{11}(1) - \bar{Y}_{10}(1)}_{\text{观测差分}} = \underbrace{\tau_1}_{\text{ATT}} + \underbrace{[\bar{Y}_{11}(0) - \bar{Y}_{10}(0)]}_{\text{若无处理, 处理组的时间变化}}.$$

第二步: 展开对照组的时间差分。

$$\bar{Y}_{01} - \bar{Y}_{00} = \bar{Y}_{11}(0) - \bar{Y}_{10}(0).$$

因为对照组未受处理, 其时间差分完全反映了在无处理情况下的结果变化。

第三步: 计算双重差分。

$$\begin{aligned} \text{DiD} &= (\bar{Y}_{11} - \bar{Y}_{10}) - (\bar{Y}_{01} - \bar{Y}_{00}) \\ &= [\tau_1 + (\bar{Y}_{11}(0) - \bar{Y}_{10}(0))] - [\bar{Y}_{11}(0) - \bar{Y}_{10}(0)] \\ &= \tau_1. \end{aligned}$$

结论: 在平行趋势假设 $\bar{Y}_{11}(0) - \bar{Y}_{10}(0) = \bar{Y}_{01} - \bar{Y}_{00}$ 下, DiD 估计量精确识别 τ_1 。

TWFE 与 DiD 的等价性:

考虑回归模型:

$$Y_{it} = \alpha + \beta D_{it} + \gamma_i + \delta_t + \varepsilon_{it}, \quad D_{it} = G_i \cdot T_t.$$

OLS 估计 β 可显式写为:

$$\hat{\beta} = \bar{Y}_{11} - \bar{Y}_{10} - \bar{Y}_{01} + \bar{Y}_{00} = \hat{\tau}_{\text{DiD}}.$$

这是因为固定效应 γ_i 和 δ_t 分别吸收了组间均值和时间均值, 使得 $\hat{\beta}$ 恰好等于处理组时间差分减去对照组时间差分。

Bootstrap 标准误差:

对于 DiD 估计量, 可以按以下步骤计算聚类 Bootstrap 标准误差:

- (1) 按单元 (cluster) 进行重抽样: 对每个单元 i , 抽取所有时期 t 的观测值 (Y_{it}, D_{it})
- (2) 在每个重抽样样本上计算 $\hat{\tau}_{\text{DiD}}$
- (3) 重复 B 次 (例如 $B = 999$), 得到 Bootstrap 分布 $\{\hat{\tau}_{\text{DiD}}^{(b)}\}_{b=1}^B$
- (4) 标准误差为 $\hat{\sigma}_{\text{boot}} = \sqrt{(B-1)^{-1} \sum_{b=1}^B (\hat{\tau}_{\text{DiD}}^{(b)} - \bar{\hat{\tau}})^2}$

13. 第 23 章 TSLS 估计量的代数推导

背景：第 chapter 29 章中，我们介绍了两阶段最小二乘（TSLS）估计量。本节给出其代数推导的完整细节。

参数定义 (Parameter Definitions):

- Y_i : 结果变量
- D_i : p 维内生解释变量
- Z_i : q 维工具变量 ($q \geq p$)
- β : p 维待估参数向量
- ε_i : 误差项, 满足 $E(\varepsilon_i Z_i) = 0$
- $\hat{D}_i$: 第一阶段 OLS 的拟合值
- $\hat{\Gamma}$: 第一阶段 OLS 的系数矩阵

目标 (Goal): 推导 TSLS 估计量的显式表达式, 并证明其在过度识别情形下的相合性。

推导步骤 (Derivation Steps):

第一步：第一阶段 OLS. 第一阶段回归 D on Z 的 OLS 估计量为:

$$\hat{\Gamma} = \left(\sum_{i=1}^n Z_i Z_i^\top \right)^{-1} \sum_{i=1}^n Z_i D_i^\top.$$

相应的拟合值为:

$$\hat{D}_i = \hat{\Gamma}^\top Z_i.$$

第一阶段的正交性条件给出:

$$\sum_{i=1}^n \hat{D}_i \check{D}_i^\top = 0,$$

其中 $\check{D}_i = D_i - \hat{D}_i$ 是第一阶段残差。

由正交性可得:

$$\sum_{i=1}^n \hat{D}_i D_i^\top = \sum_{i=1}^n \hat{D}_i \hat{D}_i^\top.$$

第二步：第二阶段 OLS. 第二阶段回归 Y on $\hat{D}$ 的 OLS 估计量为:

$$\hat{\beta}_{\text{TSLS}} = \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i Y_i.$$

第三步：代入结构方程. 将结构方程 $Y_i = D_i^\top \beta + \varepsilon_i$ 代入 section 13:

$$\begin{aligned} \hat{\beta}_{\text{TSLS}} &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i (D_i^\top \beta + \varepsilon_i) \\ &= \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i D_i^\top \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i. \end{aligned}$$

利用正交性条件 section 13:

$$\hat{\beta}_{\text{TSLS}} = \beta + \left(\sum_{i=1}^n \hat{D}_i \hat{D}_i^\top \right)^{-1} \sum_{i=1}^n \hat{D}_i \varepsilon_i.$$

第四步：显式表达式. 将 $\hat{D}_i = \hat{\Gamma}^\top Z_i$ 代入 section 13:

$$\begin{aligned}\hat{\beta}_{\text{TSLS}} &= \beta + \left(\hat{\Gamma}^\top \sum_{i=1}^n Z_i Z_i^\top \hat{\Gamma} \right)^{-1} \hat{\Gamma}^\top \sum_{i=1}^n Z_i \varepsilon_i \\ &= \beta + \left\{ \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i Z_i^\top \right) \hat{\Gamma} \right\}^{-1} \hat{\Gamma}^\top \left(n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \right).\end{aligned}$$

第五步：相合性. 由于 $E(Z_i \varepsilon_i) = 0$ (工具变量的排他性 restriction), 根据大数定律:

$$n^{-1} \sum_{i=1}^n Z_i \varepsilon_i \xrightarrow{p} 0.$$

同时,

$$\begin{aligned}n^{-1} \sum_{i=1}^n Z_i Z_i^\top &\xrightarrow{p} E(Z Z^\top), \\ \hat{\Gamma} &\xrightarrow{p} \Gamma = E(Z Z^\top)^{-1} E(Z D^\top).\end{aligned}$$

将这些收敛结果代入 section 13, 得到:

$$\hat{\beta}_{\text{TSLS}} \xrightarrow{p} \beta.$$

结论: TSLS 估计量是 β 的相合估计量。

与 IV 估计量的等价性 (恰好识别情形). 当 $q = p$ (工具变量与内生变量维度相同) 时, $\hat{\Gamma}$ 是方阵。此时:

$$\hat{\beta}_{\text{TSLS}} = \left(\hat{\Gamma}^{-1} \sum_{i=1}^n Z_i Y_i \right) = \left(\sum_{i=1}^n Z_i D_i^\top \right)^{-1} \sum_{i=1}^n Z_i Y_i = \hat{\beta}_{\text{IV}}.$$

因此, 在恰好识别情形下, TSLS 与 IV 估计量完全等价。

14. TSLS 与 ILS 等价性的证明

背景: 定理 section 5.2 声称, 在单一内生处理变量和单一工具变量的情形下, TSLS 估计量与 ILS 估计量在数值上完全相同。本节给出简要证明。

设定: 考虑结构方程组 (eq. (140)):

$$\begin{cases} Y_i = \beta_0 + \beta_1 D_i + \beta_2^\top X_i + \varepsilon_i, \\ D_i = \gamma_0 + \gamma_1 Z_i + \gamma_2^\top X_i + \varepsilon_{2i}. \end{cases}$$

目标 (Goal): 证明 $\hat{\beta}_{1,\text{TSLS}} = \hat{\Gamma}_1 / \hat{\gamma}_1 = \hat{\beta}_{1,\text{ILS}}$ 。

证明:

约化形式 OLS 给出:

$$\hat{\Gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})^2}, \quad \hat{\gamma}_1 = \frac{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}{\sum_i (Z_i - \bar{Z})^2}.$$

因此,

$$\frac{\hat{\Gamma}_1}{\hat{\gamma}_1} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\sum_i (Z_i - \bar{Z})(D_i - \bar{D})}.$$

另一方面, TSLS 的第一阶段拟合值为:

$$\hat{D}_i = \hat{\gamma}_0 + \hat{\gamma}_1 Z_i + \hat{\gamma}_2^\top X_i.$$

第二阶段回归 Y on $(1, \hat{D}, X)$ 中, $\hat{D}$ 的系数为:

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\sum_i (Y_i - \bar{Y})(\hat{D}_i - \bar{\hat{D}})}{\sum_i (\hat{D}_i - \bar{\hat{D}})^2}.$$

可以验证 (利用第一阶段正交性), 分母等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(\hat{D}_i - \bar{\hat{D}}) = \hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2$, 分子等于 $\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})$.

因此,

$$\hat{\beta}_{1,\text{TSLS}} = \frac{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1^2 \sum_i (Z_i - \bar{Z})^2} = \frac{\sum_i (Z_i - \bar{Z})(Y_i - \bar{Y})}{\hat{\gamma}_1 \sum_i (Z_i - \bar{Z})^2} = \frac{\hat{\Gamma}_1}{\hat{\gamma}_1}.$$

结论: 得证 $\hat{\beta}_{1,\text{TSLS}} = \hat{\beta}_{1,\text{ILS}}$.

直观理解: 这个等价性揭示了 TSLS 和 ILS 实际上是从不同角度求解同一组矩条件方程。TSLS 通过“预测”内生变量的拟合值来建立正交性, 而 ILS 则直接利用约化形式中系数之间的比值关系。两种方法在代数上完全等价, 但在计算路径和直觉理解上各有优势。

15. 9.1 超级总体框架下的 Neyman 方差公式

背景: 在 section 2.1 中, 我们声称在超级总体框架下, Neyman (1923) 的方差估计量是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计。本节说明为什么这个“保守性”问题在超级总体框架下消失了。

给定条件:

- n 个 IID 单元: $\{Z_i, Y_i(1), Y_i(0), X_i\}_{i=1}^n$
- 随机化假设: $Z \perp \{Y(1), Y(0), X\}$
- 治疗组样本量 n_1 , 对照组样本量 n_0

目标: 证明在 IID 抽样下, 样本方差 $S^2(1)$ 和 $S^2(0)$ 分别是 $\text{var}\{Y(1)\}$ 和 $\text{var}\{Y(0)\}$ 的无偏估计。

推导步骤:

第一步: 有限总体方差与超级总体方差的关系。

有限总体方差定义为:

$$S_N^2(1) = \frac{1}{n-1} \sum_{i=1}^n \{Y_i(1) - \bar{Y}_N(1)\}^2,$$

其中 $\bar{Y}_N(1) = n^{-1} \sum_{i=1}^n Y_i(1)$ 。

超级总体方差定义为:

$$\sigma^2(1) = E\{Y_i(1) - E(Y_i(1))\}^2.$$

当从超级总体中 IID 抽样时, $E(S_N^2(1)) = \sigma^2(1)$ (这是 IID 抽样的标准结果)。

第二步: 代入 Neyman 方差公式。

在有限总体框架下, Neyman 的方差估计量是:

$$\hat{V}_N = \frac{S_N^2(1)}{n_1} + \frac{S_N^2(0)}{n_0}.$$

取期望:

$$E(\hat{V}_N) = \frac{E\{S_N^2(1)\}}{n_1} + \frac{E\{S_N^2(0)\}}{n_0} = \frac{\sigma^2(1)}{n_1} + \frac{\sigma^2(0)}{n_0} = \text{var}(\hat{\tau} | \mathbf{Z}).$$

结论：在超级总体框架下， $\hat{V}_N$ 是 $\text{var}(\hat{\tau} | \mathbf{Z})$ 的无偏估计——保守性问题消失了。

16. 9.2 OLS 分解与 pooled regression 的等价性

背景：在 section 2.3 中，我们声称 Lin (2013) 估计量 $\hat{\tau}_L = \hat{\alpha}_Z$ 等价于 section 2.3 在 $\bar{X} = 0$ 时的形式。本节给出完整的 OLS 分解推导。

目标：证明当 X 中心化（即 $\bar{X} = 0$ ）时，

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\alpha}_Z.$$

推导步骤：

第一步：OLS 正规方程。

对于合并回归 section 2.3，OLS 估计量满足正规方程：

$$\begin{aligned} \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) X_i &= 0, \\ \sum_{i=1}^n (Y_i - \hat{\alpha}_0 - \hat{\alpha}_Z Z_i - \hat{\alpha}_X^T X_i - \hat{\alpha}_{ZX}^T Z_i X_i) Z_i X_i &= 0. \end{aligned}$$

第二步：解释系数。

从最后一个正规方程（交互项）出发，经过代数运算（详见原书 Proposition 6.2 的证明），可以证明：

$$\hat{\alpha}_Z = (\hat{\gamma}_1 - \hat{\gamma}_0) + (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}.$$

第三步：中心化。

若 $\bar{X} = 0$ (X 已中心化)，则：

$$\hat{\alpha}_Z = \hat{\gamma}_1 - \hat{\gamma}_0 = \hat{\tau}_L.$$

结论：得证 $\hat{\tau}_L = \hat{\alpha}_Z$ ，即 Lin (2013) 估计量等于合并回归中 treatment 指标的系数。

17. 9.3 EHW 方差估计量的问题

背景：在 section 2.4 中，我们提到直接使用 OLS 的 EHW 标准误是不正确的。本节解释原因。

问题来源：

在超级总体框架下，协变量 X 的样本均值 $\bar{X}$ 是随机变量——它会随抽样波动。

标准 OLS 的 EHW 方差估计量假设 $\bar{X}$ 是固定的（条件于 X 的实现），因此它没有考虑 $\bar{X}$ 的抽样变异。

当我们将 $\hat{\tau}_L$ 写作：

$$\hat{\tau}_L = \hat{\gamma}_1 - \hat{\gamma}_0 = (\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X} + \text{残差},$$

会发现 $\hat{\tau}_L$ 的方差包含两项：

$$\text{var}(\hat{\tau}_L) = \underbrace{\text{var}(\hat{\gamma}_1 - \hat{\gamma}_0 | X)}_{\text{EHW 考虑的}} + \underbrace{\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}}_{\text{EHW 忽略的}}.$$

第二项在有限样本中可能不可忽略，特别是在 X 的维度较高时。

校正项的来源:

从 section 2.4 可见, 校正项为:

$$\frac{1}{n}(\hat{\beta}_1 - \hat{\beta}_0)^T S_X^2 (\hat{\beta}_1 - \hat{\beta}_0).$$

这一项正是 $\text{var}\{(\hat{\beta}_1 - \hat{\beta}_0)^T \bar{X}\}$ 的估计量。

18. 9.4 SRE 扩展的详细推导

背景: 在 section 4 中, 我们声称可以在各层内分别应用 Lin (2013) 估计量, 然后加权合并。本节给出详细推导。

设定:

假设 $X_i \in \{1, \dots, K\}$ 是离散的层别变量。SRE 的超级总体框架要求:

$$Z \perp \{Y(1), Y(0)\} \mid X.$$

目标: 推导 τ 的协变量调整估计量 $\hat{\tau}_S$ 及其方差。

推导步骤:

第一步: 层别估计量。

在第 k 层内, 治疗组和对照组子样本满足 $Z \perp \{Y(1), Y(0)\} \mid X = k$ (由于 $X = k$ 是确定的, 实际上是 $Z \perp \{Y(1), Y(0)\}$)。

对第 k 层应用 Lin (2013) 估计量:

$$\hat{\tau}_{L,[k]} = \hat{\gamma}_{1,[k]} - \hat{\gamma}_{0,[k]} + (\hat{\beta}_{1,[k]} - \hat{\beta}_{0,[k]})^T \bar{X}_{[k]},$$

其中 $\bar{X}_{[k]} = n_{[k]}^{-1} \sum_{X_i=k} X_i$ 。

第二步: 合并各层。

总体估计量是各层估计量的加权平均:

$$\hat{\tau}_S = \sum_{k=1}^K \pi_{[k]} \hat{\tau}_{L,[k]},$$

其中 $\pi_{[k]} = \text{pr}(X = k)$ 。

第三步: 方差估计。

各层估计量在条件于该层数据时相互独立, 因此:

$$\text{var}(\hat{\tau}_S) = \sum_{k=1}^K \pi_{[k]}^2 \text{var}(\hat{\tau}_{L,[k]}).$$

用各层的校正 EHW 方差估计量估计 $\text{var}(\hat{\tau}_{L,[k]})$, 得到 $\hat{V}_S$ 。

结论: SRE 的协变量调整估计量 $\hat{\tau}_S$ 是 τ 的无偏估计, 方差一致估计量由 $\hat{V}_S$ 给出。

19. 9.5 R 代码实现

背景: 在 section 3 中, 我们报告了模拟研究的结果。本节给出完整的 R 代码。

Lin 估计量函数:

```
linestimator = function(Z, Y, X) {
  # 标准化协变量
  X = scale(X)

  n = dim(X)[1]
```

```

p = dim(X)[2]

# 完全交互的 OLS 回归
linreg = lm(Y ~ Z * X)

# Lin 估计量 (Z 的系数)
est = coef(linreg)[2]

# EHW 标准误
vehw = hccm(linreg)[2, 2]

# 超级总体校正项
inter = coef(linreg)[(p+3):(2*p+2)]
vsuper = vehw + sum(inter * (cov(X) %*% inter)) / n

# 返回：估计量、EHW 标准误、校正标准误
c(est, sqrt(vehw), sqrt(vsuper))
}

```

模拟代码 ($n = 500$, 2000 次重复):

```

set.seed(123)
res = replicate(2000, {
  n = 500
  X = matrix(rnorm(n*2), n, 2)
  Y1 = X[,1] + X[,1]^2 + runif(n, -0.5, 0.5)
  Y0 = X[,2] + X[,2]^2 + runif(n, -1, 1)
  Z = rbinom(n, 1, 0.6)
  Y = Z*Y1 + (1-Z)*Y0
  linestimator(Z, Y, X)
})

```

结果摘要:

- 偏差: $\text{mean}(\text{res}[1,]) \approx -0.0001$
- 经验标准差: $\text{sd}(\text{res}[1,]) \approx 0.151$
- 平均 EHW 标准误: $\text{mean}(\text{res}[2,]) \approx 0.139$
- 平均校正标准误: $\text{mean}(\text{res}[3,]) \approx 0.153$

20. Theorem 19.1 的证明：最坏情况 p 值的分布

背景 (Background): Theorem 19.1 建立了 Rosenbaum 灵敏度分析框架下零假设成立时处理指示 S_i 的最坏情况分布。这是计算保守 p 值的基础。

参数定义 (Parameter Definitions):

- n : 配对的数量
- $\Gamma \geq 1$: Rosenbaum 灵敏度分析模型中的 odds ratio 上界
- $\pi_{i1} = \Pr(Z_{i1} = 1 \mid \text{pair } i)$: 配对 i 中处理组接受处理的概率
- $\pi_{i0} = 1 - \pi_{i1}$: 配对 i 中对照组接受处理的概率
- $o_i = \frac{\pi_{i1}/\pi_{i0}}{(1-\pi_{i1})/(1-\pi_{i0})} = \frac{\pi_{i1}(1-\pi_{i0})}{\pi_{i0}(1-\pi_{i1})}$: 配对 i 中处理分配的 odds 比

- S_i : 配对 i 的处理指示 (在 Fisher randomization test 中, S_i 决定该对是否参与检验统计量的计算)

已知条件 (Given):

- (1) Rosenbaum 灵敏度分析模型 (Assumption 19.1): $o_i \leq \Gamma$ for all i
- (2) Sharp null hypothesis $H_{0F}: Y_{ij}(1) = Y_{ij}(0)$ for all i, j
- (3) 配对 i 中, 处理和对照单位独立地接受随机化处理, 即 $Z_{i1} + Z_{i0} = 1$

目标 (Goal): 证明在所有满足 $o_i \leq \Gamma$ 的分布中, S_i 的最坏情况分布为 $\text{Bernoulli}(\frac{\Gamma}{1+\Gamma})$ 。

推导步骤 (Derivation Steps):

第一步: 建立 π_{i1} 的可能范围。

由 $o_i \leq \Gamma$ 可得:

$$\frac{\pi_{i1}(1 - \pi_{i0})}{\pi_{i0}(1 - \pi_{i1})} \leq \Gamma.$$

由于 $Z_{i1} + Z_{i0} = 1$, 我们有两种等价表述:

$$\pi_{i1} \leq \frac{\Gamma}{\Gamma + 1} \quad \text{或} \quad \pi_{i1} \geq \frac{1}{\Gamma + 1}.$$

实际上, Rosenbaum (1987b) 证明 π_{i1} 可以取这两个边界值之间的任何值。

第二步: 理解 Fisher randomization test 中的 S_i 。

在 Fisher randomization test 中, 对于第 i 对, 我们计算两个”伪”检验统计量:

$$T_{i1} = q_i \cdot 1 \quad \text{和} \quad T_{i0} = q_i \cdot 0,$$

分别对应处理组和对照组参与检验的情形。在 sharp null 下, 这两个值都是有效的。

实际检验统计量 $T = \sum_{i=1}^n S_i q_i$ 中, S_i 决定了配对 i 贡献的是 T_{i1} 还是 T_{i0} 。

第三步: 确定最坏情况分布。

为了得到最大的 p 值 (最不利于拒绝零假设), 我们需要选择使 T 分布”最集中”在观测值附近的 S_i 分布。

直觉上, 当 S_i 有更大的概率取 1 (处理组参与) 时, 如果 $q_i > 0$, T 会倾向于更大的值。数学上, 给定 Γ , 使 p 值最大的 S_i 分布是 $\text{Bernoulli}(\frac{\Gamma}{1+\Gamma})$ 。这是因为:

$$\mathbb{E}_{\Gamma}(S_i) = \frac{\Gamma}{1 + \Gamma} = 1 - \frac{1}{1 + \Gamma}.$$

第四步: 验证这是最坏情况。

考虑极端情况: 假设对所有 i , $\pi_{i1} = \frac{\Gamma}{1+\Gamma}$ 。则在此分布下:

$$S_i \sim \text{Bernoulli}\left(\frac{\Gamma}{1 + \Gamma}\right).$$

可以证明 (见 Rosenbaum 1987b, Theorem 1), 这个分布给出了所有满足约束的分布中最大的 p 值。

直观理解: 当 Γ 增加时, $\frac{\Gamma}{1+\Gamma}$ 趋近于 1, 这意味着在最坏情况分布中, 处理组更倾向于参与检验。如果观测到的处理效应为正 ($q_i > 0$), 这种分布使得处理组的”贡献”更大, 从而更难拒绝零假设。

特例验证: 当 $\Gamma = 1$ 时, $\frac{\Gamma}{1+\Gamma} = \frac{1}{2}$, 即标准匹配实验的情形, 这与我们的直觉一致。

结论: 得证, 在 Assumption 19.1 下, 零假设 H_{0F} 成立时, S_i 的最坏情况分布为 $\text{Bernoulli}(\frac{\Gamma}{1+\Gamma})$ 。

21. 最坏情况 p 值的显式计算公式

背景：对于特定的检验统计量，我们可以推导出最坏情况 p 值的显式计算公式。

Sign statistic 的情况：当 $q_i = 1$ for all i 时，检验统计量 $T = \sum_{i=1}^n S_i$ 服从二项分布 $B(n, \pi)$ ，其中 $\pi = \frac{\Gamma}{1+\Gamma}$ 。

此时，最坏情况 p 值为：

$$p_{\Gamma} = 2 \sum_{k=T}^n \binom{n}{k} \left(\frac{\Gamma}{1+\Gamma} \right)^k \left(\frac{1}{1+\Gamma} \right)^{n-k}.$$

Wilcoxon signed-rank statistic 的情况：对于 Wilcoxon signed-rank statistic, $q_i = \text{rank}(|Y_{i1} - Y_{i0}|)$ 。在这种设定下， T 的分布更为复杂，通常需要通过数值计算或模拟来获得 p 值。

Rosenbaum 的 R 包（如 `sensitivity2x2`）提供了这些计算的可靠实现。

APPENDIX A

问答与注解

1. 阅读过程中的问题与解答

1.1. 亚组的定义. 问: 什么是亚组?

答: 亚组 (subgroup) 是由某个协变量 (通常是二元变量 X_i) 分割出来的子群体。例如按性别、年龄、收入等分割。亚组因果效应衡量的是在该亚组内的平均因果效应。

1.2. 恒等式 $\tau = \pi_1\tau_1 + \pi_0\tau_0$ 的推导. 问: 如何推导 $\tau = \pi_1\tau_1 + \pi_0\tau_0$?

答: 利用指示函数的完备性 $\mathbb{I}(X_i = 1) + \mathbb{I}(X_i = 0) = 1$, 将总体求和拆分为两个亚组求和, 再除以对应的亚组样本量即可得到。

1.3. 为什么在 H_{0F} 下 $\mathbf{Y}$ 是固定的?. 问: 为什么在 Fisher's sharp null ($H_{0F} : Y_i(1) = Y_i(0)$) 下, 潜在结果向量 $\mathbf{Y}$ 是固定的?

答: H_{0F} 断言 treatment 对每个单元都没有效应, 即 $Y_i(1) = Y_i(0) = Y_i$ 对所有 i 。这意味着整个 $\mathbf{Y}(1) = \mathbf{Y}(0) = \mathbf{Y}$ 向量是确定的 (固定值), 不再有随机性。

在 FRT 中, 我们 condition on 这个固定的 $\mathbf{Y}$, 只让治疗分配 $\mathbf{Z}$ 有随机性。因此, 随机化分布可以精确枚举 ($M = \binom{n}{n_1}$ 种可能), 不依赖任何渐近假设——这就是 FRT”有限样本精确”的本质。

1.4. p_frt 的 Monte Carlo 近似与修正. 问: 为什么 eq. (24) 需要修正为 $\tilde{p}_{frt}$?

答:

原始 Monte Carlo 近似:

$$\hat{p}_{frt} = \frac{1}{R} \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}$$

这个估计量的问题是: 当 R 有限时, 它可能是**反保守的**——低估真实的 p 值, 导致错误地宣称显著。

修正公式 (有限样本有效):

$$\tilde{p}_{frt} = \frac{1 + \sum_{r=1}^R \mathbb{I}\{T(\mathbf{z}^r, \mathbf{Y}) \geq T(\mathbf{Z}, \mathbf{Y})\}}{1 + R}$$

修正的本质是”自我包含”: 分子加 1 相当于把”观测到的这一次”也算作一次置换结果。

为什么需要修正:

当 $R = 99$ 次置换中, 只有 0 次超过观测值时:

$$\hat{p}_{frt} = \frac{0}{99} = 0$$

这就错了! 因为观测到的这一次 (自身) 必然是 M 种可能之一, p 值至少应该是 $1/M$, 而不是 0。

加了 1 在分子和分母：

$$\tilde{p}_{f_{rt}} = \frac{1}{100}$$

这保证了：

- (1) p 值不会为 0 (分子至少是 1)
- (2) 在任何有限的 R 下都满足有限样本有效性： $\mathbb{P}(p \leq u) \leq u$
- (3) 当 $R \rightarrow \infty$ 时， $\tilde{p}_{f_{rt}} \rightarrow \hat{p}_{f_{rt}}$

1.5. 为什么叫“有限样本精确”？ 问：FRT 的 p 值为什么被称为“有限样本精确”？

答：关键在于 ?? 给出的不等式：

$$\mathbb{P}(p_{f_{rt}} \leq u) \leq u \quad \text{for all } u \in [0, 1]$$

这叫做**有限样本有效性** (finite-sample validity)。意思是：无论样本量多小、数据分布如何， $p_{f_{rt}}$ 的分布永远不会偏离均匀分布太多。

对比传统 t 检验：它需要大样本下才近似有效 (渐近性质)，小样本时可能失效。FRT 的精确性只依赖于随机化机制，不依赖于任何渐近假设。

1.6. Fisher 方法 vs 传统方法. 问：Fisher 的思路和传统统计推断有什么本质区别？

答：

- **传统方法问**：“数据有多极端？”——依赖数据分布假设
- **Fisher 方法问**：“如果随机化，会产生多极端的数据？”——只依赖随机化机制

Fisher 方法的哲学：在 sharp null (无因果效应) 假设下，潜在结果完全已知。观察到的差异完全来自随机分配。我们可以枚举所有可能的置换，计算每个置换产生的统计量。传统方法则依赖于数据的原始分布假设 (如正态性)，而 FRT 给经典 t 检验提供了理论 justify——不需要正态性假设。

1.7. 经典 t 检验之前没有理论基础吗？ 问：经典 t 检验之前没有理论 justify 吗？一定要 FRT 给出吗？

答：经典 t 检验有理论基础，但 FRT 提供了**更坚实**的理论基础。

经典 t 检验的理论基础：

- **正态性假设下** (Fisher 原始推导)：如果 $Y_i \sim \text{i.i.d. } \mathcal{N}(\mu, \sigma^2)$ ，则 t 统计量精确服从 t 分布
- **渐近理论** (后来发展)：大样本下，CLT 保证 t 统计量近似正态分布——即使数据不正态

FRT 的新贡献：FRT 并不是说经典 t 检验“没有理论依据”，而是提供了**另一种理论框架**：

- 经典方法：关注“**数据的分布**” (假设数据来自正态分布)
- FRT：关注“**随机化的机制**” (治疗是如何分配的)

关键区别：在随机实验中，我们**知道**治疗是如何分配的 (CRE)，所以可以基于随机化机制来计算 p 值——这比假设“数据来自正态分布”更可靠。

准确的说法：FRT 为经典 t 检验在随机实验中的应用提供了**更直接、更不依赖分布假设**的理论基础。

1.8. 经典 t 检验需要正态性假设吗？问：经典 t 检验需要正态性假设吗？为什么 FRT 说“不需要”？

答：经典 t 检验有两种情况：

- **精确版本：**如果数据来自正态分布的总体，t 统计量的精确抽样分布是 t 分布
- **渐近版本：**在大样本下，即使数据不正态，CLT 保证 t 统计量近似正态分布

FRT 的贡献：它证明了在随机实验 + sharp null 下，t 统计量的**随机化分布**可以直接计算（精确或 Monte Carlo 近似），不依赖任何分布假设。

关键区别：

- 传统方法问：“如果数据来自正态分布，观察到的差异有多极端？”
- FRT 问：“如果 treatment 是随机分配的，观察到这种差异的概率有多大？”

FRT 的理论基础是有限总体 CLT，它保证**随机化分布**收敛到正态，而不是数据本身正态。因此在大样本下，即使数据不正态，FRT 给出的 p 值也是有效的。

总结：FRT 并没有说经典 t 检验“不需要”正态性假设，而是说在随机实验框架下，可以用不依赖正态性的方法（FRT）来获得精确的 p 值。

1.9. 什么是潜在结果？问：在 Fisher 随机化检验框架下，什么是潜在结果？

答：潜在结果（Potential Outcomes）是每个单元在两种 treatment 状态下的可能结果：

- $Y_i(1)$ ：单元 i 如果接受 treatment 的结果
- $Y_i(0)$ ：单元 i 如果接受 control 的结果

关键洞察：每个单元只能实际接受一种 treatment，因此我们只能观测到其中一个潜在结果，另一个是“反事实”（counterfactual）——它从未发生，无法被观测。

观测结果与潜在结果的关系：

$$Y_i^{obs} = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$$

即：如果 $Z_i = 1$ （接受 treatment），我们观测到 $Y_i(1)$ ；如果 $Z_i = 0$ ，我们观测到 $Y_i(0)$ 。

因果推断的根本问题：我们想估计 $Y_i(1) - Y_i(0)$ （单元 i 的因果效应），但只能观测到其中一个值。

1.10. 随机化的两个原则是什么？问：Fisher 随机化的两个原则——可比性和推理基础——是什么意思？

原则一：可比性（Comparability）。随机化保证了 treatment 组和 control 组在平均意义上是可比的。如果没有随机化，治疗分配可能受到选择偏差（selection bias）的影响。例如，如果病人自己选择是否接受治疗，那么接受治疗的群体可能本身就比对照组更健康。随机化通过强制分配机制打破了这种联系，使得两组在所有可观测和不可观测的特质上趋于平衡。

原则二：推理基础（Inference Basis）。随机化提供了推断因果效应的理论基础。在没有随机化的情况下，我们无法区分“因果效应”和“选择偏差”。但在随机实验中，我们知道治疗分配是如何进行的（randomization mechanism），因此可以基于这个已知的分配机制来计算 p 值。具体而言：

- (1) 假设 H_{0F} ：treatment 对每个人都无效 ($Y_i(1) = Y_i(0)$)
- (2) 在这个假设下，治疗分配是唯一的随机来源
- (3) 枚举所有可能的随机分配（或者 Monte Carlo 近似）
- (4) 计算在每种分配下，检验统计量有多极端

总结：可比性解决“选择偏差”——确保组间可比较。推理基础解决“随机变异”——知道观察到的差异有多极端。两者结合，使得因果推断成为可能。

1.11. 什么是 Fisher Randomization Test ?. 问：什么是 Fisher Randomization Test (Fisher 随机化检验)？

答：Fisher Randomization Test (FRT) 是 Ronald Fisher 在 1935 年《Design of Experiments》中提出的统计检验框架。它的核心创新是：不再依赖数据分布假设（如正态性），而是仅依赖随机化机制本身。

核心思想：

- (1) 在 **sharp null** 假设 $H_{0F} : Y_i(1) = Y_i(0)$ （所有单元的治疗效应都为零）下，潜在结果向量 $\mathbf{Y}$ 是完全确定的（固定的）
- (2) 唯一的随机来源是治疗分配机制 $\mathbf{Z}$
- (3) 在完全随机实验（CRE）中， $\mathbf{Z}$ 的分布是已知的（均匀分布于所有 $\binom{n}{n_1}$ 种可能的分配）
- (4) 因此，我们可以枚举所有可能的治疗分配，计算在每种分配下检验统计量的取值
- (5) p 值就是在所有可能分配中，观察到的统计量至少与实际观测值一样极端的比例

★ **Insight:** FRT 的本质是“条件推断”——我们 condition on 固定的潜在结果 $\mathbf{Y}$ ，只让治疗分配 $\mathbf{Z}$ 有随机性。这与经典统计推断不同：经典方法 condition on 数据，假设数据的分布已知；FRT 则 condition on 潜在结果，利用随机化机制计算精确的 p 值。

为什么叫“随机化检验”？ 因为它完全基于随机化机制——不假设任何参数分布，不依赖正态性假设，只依赖“治疗是如何随机分配的”这一事实。这使得 FRT 在随机实验中具有“有限样本精确性”（finite-sample exactness）。

1.12. $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 的含义. 问：在 CRE 中， $\mathbf{Z}$ 在集合 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 上是均匀分布的。这句话是什么意思？

答：

先理解 $\mathbf{Z}$ 是什么。 $\mathbf{Z} = (Z_1, \dots, Z_n)$ 是治疗分配向量，其中 $Z_i = 1$ 表示单元 i 接受治疗， $Z_i = 0$ 表示单元 i 接受对照。

再理解 $\{\mathbf{z}^1, \dots, \mathbf{z}^M\}$ 。 这是所有可能的治疗分配构成的集合。例如当 $n = 3, n_1 = 1$ 时，所有可能的分配有：

$$\mathbf{z}^1 = (1, 0, 0), \mathbf{z}^2 = (0, 1, 0), \mathbf{z}^3 = (0, 0, 1)$$

即 $M = \binom{3}{1} = 3$ 种可能。

“均匀分布”的意思。 在 CRE 中，治疗分配是完全随机的。这意味着每一种可能的分配 $\mathbf{z}^m$ 被选中的概率相等：

$$\mathbb{P}(\mathbf{Z} = \mathbf{z}^m) = \frac{1}{M} = \frac{1}{\binom{n}{n_1}}$$

例如当 $n = 100, n_1 = 50$ 时， $M \approx 10^{29}$ 种可能的分配，每一种被选中的概率都完全相同（约 10^{-29} ）。

关键直觉： 在 CRE 下，treatment 组和 control 组的成员身份是随机决定的，而非实验者主观选择。这就是 Fisher 说的“randomization provides a valid basis for inference”——随机化本身保证了推断的有效性。

1.13. 蒙特卡洛公式中的 $\mathbf{Z}$ 是什么 ?. 问：蒙特卡洛公式里面的 $\mathbf{Z}$ 到底是什么意思？他说是一个均匀分布，但我不知道 $\mathbf{Z}$ 是什么意思？

答：

为什么需要理解 $\mathbf{Z}$? 在 Fisher 随机化检验中，我们感兴趣的问题是：“如果 treatment 真的是随机分配的，观察到的差异有多极端？”要回答这个问题，我们需要知道“随机分配”是如何进行的——而 $\mathbf{Z}$ 正是描述这种分配机制的核心工具。

$\mathbf{Z}$ 的定义。 在 n 个单元的实验中， $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)$ 是一个长度为 n 的向量，其中：

- $Z_i = 1$: 单元 i 接受 treatment (治疗组)
- $Z_i = 0$: 单元 i 接受 control (对照组)

例如当 $n = 5, n_1 = 2$ 时, 一个可能的分配是 $\mathbf{Z} = (1, 0, 0, 1, 0)$, 表示第 1、4 号单元接受治疗, 第 2、3、5 号单元接受对照。

为什么是“均匀分布”? 在完全随机实验 (CRE) 中, 治疗分配是完全随机的——每个可能的 $\mathbf{Z}$ 被选中的概率相等。这就是“均匀分布”的含义。

具体来说, 所有可能的分配有 $M = \binom{n}{n_1}$ 种, 每种被选中的概率都是 $1/M$ 。例如:

- $n = 3, n_1 = 1$ 时, $M = 3$, 三种可能: $(1, 0, 0)$ 、 $(0, 1, 0)$ 、 $(0, 0, 1)$, 概率各为 $1/3$
- $n = 100, n_1 = 50$ 时, $M \approx 10^{29}$, 每种概率约为 10^{-29}

$\mathbf{z}^r$ 是什么? 在 Monte Carlo 近似中, 我们无法枚举全部 M 种分配。因此我们进行 R 次随机置换, 每次得到一个 $\mathbf{z}^r$ 。每个 $\mathbf{z}^r$ 都是对真实 $\mathbf{Z}$ 的一次模拟。

★ **Insight:** 理解 $\mathbf{Z}$ 的关键是: 它是一个指示函数向量 (indicator vector), 而不是一个普通的数。它告诉我们“谁在接受治疗, 谁在对照”。Monte Carlo 方法通过重复模拟这个随机分配过程, 来近似在所有可能分配下的检验统计量分布。

1.14. 什么是潜在结果 (Potential Outcomes) ? 问: 什么是因果推断中的“潜在结果” (Potential Outcomes)?

答: 潜在结果 (Potential Outcomes) 是指每个研究单元在 ** 不同处理条件下 ** 可能观测到的所有结果。对于单元 i :

- $Y_i(1)$: 单元 i 接受 treatment 后的结果 (如吃药后的康复情况)
- $Y_i(0)$: 单元 i 接受 control 的结果 (如不服药的情况)

核心问题: 我们只能同时观测到 ** 一个 ** 潜在结果, 另一个是反事实 (counterfactual)。这被称为“因果推断基本问题” (Fundamental Problem of Causal Inference)。

1.15. 第一基本形式的意义. 问: 什么是第一基本形式 (First Fundamental Form)?

答: 第一基本形式是曲面上用来度量弧长、面积以及角度的工具, 本质上是曲面自带的一种“度量结构”——它告诉我们如何在曲面上测量距离和角度。

当你在阅读过程中提出问题时, 回答将被记录在此处。

2. 学习笔记

在这里记录你的学习心得和思考。

Bibliography