

March 31, 2026

为什么需要 Gauss-Markov ?

核心问题

OLS 估计凭什么“最好”？

- 有没有比 OLS 更好的估计？
- 第 3 章 OLS 是纯代数运算，没有随机假设谈不上“最优”

直觉说明： Without any stochastic assumptions, the OLS in Chapter 3 is purely algebraic. If we want to discuss the statistical properties of OLS, we must invoke some statistical modeling assumptions.

从代数到统计：引入随机假设的必要性

核心观点

没有随机假设谈不上“最优”

- 第 3 章 OLS 是纯代数运算
- Gauss-Markov 模型给出了讨论统计性质的基础
- 需要引入误差项 ε 的前二阶矩假设

直觉说明： Gauss-Markov 模型 Assumption §4.1 给出随机假设，使得讨论估计量的均值、方差、协方差成为可能。

章节路线图

本章知识结构

- ① Gauss-Markov 模型假设
- ② OLS 估计量的性质（均值、方差）
- ③ Gauss-Markov 定理（核心）
- ④ 定理的直观解释与证明思路

直觉说明：本章从模型假设出发，逐步建立 OLS 的统计性质，最终导出 Gauss-Markov 定理。

Gauss-Markov 模型假设

Assumption 4.1

$$Y = X\beta + \varepsilon \quad (\text{线性形式}) \quad (1)$$

$$E(\varepsilon) = 0 \quad (\text{误差均值零}) \quad (2)$$

$$\text{cov}(\varepsilon) = \sigma^2 I_n \quad (\text{同方差、不相关}) \quad (3)$$

$$X \text{ 固定且列线性无关} \quad (4)$$

未知参数为 (β, σ^2) 。

直觉说明： X 固定非本质（可条件于 X ），关键是误差的前二阶矩。

个体水平视角: $y_i = x_i^\top \beta + \varepsilon_i$

逐观测形式

$$E(\varepsilon_i) = 0 \quad (5)$$

$$\text{var}(\varepsilon_i) = \sigma^2 \quad (\text{同方差}) \quad (6)$$

$$\text{cov}(\varepsilon_i, \varepsilon_j) = 0, \quad i \neq j \quad (\text{不相关}) \quad (7)$$

直觉说明: 向量形式展开为 n 个方程, 每个误差独立满足相同的前二阶矩。

同方差假设的含义与重要性

homoskedasticity

homoskedasticity = 相同方差（词源：homo = 相同，skedasis = 散布）

- 误差项 ε_i 具有相同方差 σ^2
- 异方差情形需要加权最小二乘（见第 19 章）
- 同方差假设是 Gauss-Markov 定理成立的关键

直觉说明： The assumption that the error terms have the same variance σ^2 is called homoskedasticity. The critiques on the assumptions aside, I will derive the properties of $\hat{\beta}$ under the Gauss-Markov model.

OLS 估计量：矩阵形式

OLS 估计量

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad (8)$$

- $\hat{\beta}$ 是 Y 的线性函数
- 仅依赖矩阵运算

直觉说明：令 $A = (X^T X)^{-1} X^T$ ，则 $\hat{\beta} = AY$ ， A 不依赖 Y ，所以 OLS 是线性估计量。

OLS 估计量的均值与方差

Theorem 4.1 (无偏性)

在 Gauss-Markov 模型 Assumption 4.1 下:

$$E(\hat{\beta}) = \beta \quad (9)$$

协方差矩阵

$$\text{cov}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1} \quad (10)$$

直觉说明: OLS 估计量 $\hat{\beta}$ 是 β 的无偏估计, 其协方差矩阵完全由 σ^2 和 X 决定。

Gauss-Markov 定理 (核心)

Gauss-Markov Theorem 4.2

在 Gauss-Markov 模型 Assumption 4.1 下, $\hat{\beta}$ 是 BLUE (Best Linear Unbiased Estimator)。

条件 C1 与 C2

对任意线性估计量 $\tilde{\beta} = AY$ (A 不依赖 Y) 满足 $E(\tilde{\beta}) = \beta$ (对所有 β 无偏), 有:

$$\text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta}) \quad (11)$$

直觉说明: We write $M_1 \succeq M_2$ if $M_1 - M_2$ is positive semi-definite.

BLUE 的含义：协方差矩阵序

协方差序的等价定义

$\text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta})$ 等价于：对任意 $c \in \mathbb{R}^p$,

$$\text{var}(c^\top \tilde{\beta}) \geq \text{var}(c^\top \hat{\beta}) \quad (12)$$

- 每个坐标分量 $\hat{\beta}_j$ 方差最小
- 对任意线性组合 $c^\top \tilde{\beta}$ 方差不小于 $c^\top \hat{\beta}$

直觉说明： So the OLS estimator has a smaller variance than other estimators for all coordinates.

为什么只比较线性估计量？

线性约束的合理性

- A 可以是 X 的任意非线性函数，线性约束已包含极广的估计量类
- 无偏性是自然要求
- 在许多现代应用中，有偏估计（如 Ridge、Lasso）方差更小

直觉说明： Why do we restrict the estimator to be linear? The class of linear estimator is actually quite large because A can be any nonlinear function of X .

OLS 投影几何直观

投影矩阵与分解

$$H = X(X^T X)^{-1} X^T \quad (\text{投影矩阵}) \quad (13)$$

$$\hat{Y} = HY \quad \text{是 } Y \text{ 到 } X \text{ 列空间的投影} \quad (14)$$

$$\hat{\varepsilon} = (I_n - H)Y \quad \text{与列空间正交} \quad (15)$$

OLS 将 Y 分解为拟合值 + 残差: $Y = \hat{Y} + \hat{\varepsilon}$

直觉说明: H 和 $I_n - H$ 是投影矩阵, $HX = X$, $(I_n - H)X = 0$, 两者正交: $H(I_n - H) = 0$ 。

拟合值与残差的分布性质

Theorem 4.2

$$E(\hat{Y}) = X\beta, \quad E(\hat{\varepsilon}) = 0 \quad (16)$$

$$\text{cov}(\hat{Y}) = \sigma^2 H \quad (17)$$

$$\text{cov}(\hat{\varepsilon}) = \sigma^2(I_n - H) \quad (18)$$

$\hat{Y}$ 与 $\hat{\varepsilon}$ 不相关。

直觉说明： 注意 $\hat{y}_i$ 和 $\hat{\varepsilon}_i$ 自身不同观测间是相关的（协方差非零）。

正交 vs. 不相关：两个关键陈述的区别

陈述 (S1)

$\hat{Y}$ 与 $\hat{\varepsilon}$ 正交——代数事实，无需随机假设（OLS 投影性质）

陈述 (S2)

$\hat{Y}$ 与 $\hat{\varepsilon}$ 不相关——随机陈述，需要 Gauss-Markov 假设

两者含义不同，不能混淆。

直觉说明： S1 是纯代数结论（Lemma 4.1），S2 需要 $\text{cov}(Y) = \sigma^2 I_n$ 才能推导。

误差椭圆可视化：“最佳”的含义

几何直观

- $\hat{\beta}$ 的置信椭圆
- 其他线性无偏估计的置信椭圆
- OLS 的置信椭圆最小（被其他所有椭圆包裹）
- $\Rightarrow \hat{\beta}$ 在所有方向上方差最小

直觉说明：几何直观：协方差矩阵正定半定序意味着椭圆包含关系，OLS 的置信椭圆被所有其他线性无偏估计的置信椭圆包含。

Gauss-Markov 定理证明思路

四步框架

第一步： OLS 满足无偏性条件 $\Rightarrow AX = I_p$ (由 $E(AY) = AX\beta = \beta$ 对所有 β 成立推得)

第二步： 协方差分解

$$\text{cov}(\tilde{\beta}) = \text{cov}(\hat{\beta}) + \text{cov}(\tilde{\beta} - \hat{\beta}) \quad (19)$$

第三步： 交叉协方差项 $\text{cov}(\hat{\beta}, \tilde{\beta} - \hat{\beta}) = 0$

第四步： $\text{cov}(\tilde{\beta} - \hat{\beta}) \succeq 0 \Rightarrow \text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta})$

直觉说明： 证明核心是利用无偏性条件 $AX = I_p$ 消去交叉协方差项中的待定矩阵 A ，从而分解式只剩 $\text{cov}(\tilde{\beta} - \hat{\beta}) \succeq 0$ 。

例子：简单线性回归的 BLUE

一元情形

$$y_i = \alpha + \beta x_i + \varepsilon_i \quad (20)$$

$$\text{var}(\hat{\beta}) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2} \quad (21)$$

任何线性无偏估计的 β 系数方差都不小于此值。

直觉说明：设计越分散 ($\sum (x_i - \bar{x})^2$ 越大)，OLS 估计越精确。

例子：均值的 BLUE

均值估计问题

$y_i \sim$ 均值 μ , 方差 σ^2 , 互不相关

线性估计 $\hat{\mu} = \sum a_i y_i$, 无偏要求 $\sum a_i = 1$ 。

最优选择

$a_i = 1/n$ (简单平均), 方差 $\text{var}(\hat{\mu}) = \sigma^2/n$ 为最小

直觉说明：在无偏约束 $\sum a_i = 1$ 下，用 Lagrange 乘子法最小化 $\text{var}(\hat{\mu}) = \sigma^2 \sum a_i^2$ ，最优解为均匀权重。

例子：Gauss-Markov 预测定理

Theorem (Gauss-Markov for Prediction)

$\hat{Y} = X\hat{\beta}$ 是 $X\beta$ 的最佳线性无偏预测

适用于任何线性预测 $\tilde{Y} = \tilde{H}Y$ 。

核心不等式

$$\text{cov}(\tilde{Y}) \succeq \text{cov}(\hat{Y}) \quad (22)$$

条件：无偏 $E(\tilde{Y}) = X\beta$ ，线性 $\tilde{Y} = \tilde{H}Y$ 。

直觉说明：定理可推广到预测情形：OLS 预测 $\hat{Y}$ 在协方差矩阵序意义下优于所有线性无偏预测量。

总结

Gauss-Markov 定理核心要点

- ① **Gauss-Markov 模型**: 线性 + 同方差 + 不相关
- ② **OLS $\hat{\beta}$ 是 BLUE**: $\text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta})$
- ③ **核心不等式**: $\text{cov}(\tilde{\beta}) - \text{cov}(\hat{\beta}) = \text{cov}(\tilde{\beta} - \hat{\beta}) \succeq 0$

三个局限性

- 不谈非线性估计 (Ridge、Lasso 等有偏估计在现代高维问题中方差更小)
- 不谈正态假设 (Normal 模型下 OLS 还具有 MLE 性质)
- 不谈稳健性 (违背假设时的表现)

直觉说明: Gauss-Markov 定理是线性估计理论的基础, 核心洞察是: 在唯一指定“线性 + 无偏”后, OLS 自动最优, 无需进一步选择。

参考文献

-  Peng Ding. *A First Course in Causal Inference*. 2024.
-  Sheather, S.J. *A Modern Approach to Regression with R*. Springer, 2009.
-  McCulloch, J.H. *On Heteroscedasticity*. *Econometrica*, 1985.