

March 31, 2026

为什么需要 Gauss-Markov?

核心问题

- OLS 估计凭什么”最好”?
- 有没有比 OLS 更好的估计?
- 第 3 章 OLS 是纯代数运算，没有随机假设谈不上”最优”

直觉说明： Without any stochastic assumptions, the OLS in Chapter 3 is purely algebraic.

从代数到统计：引入随机假设的必要性

Gauss-Markov 模型

Gauss-Markov 模型 Assumption §4.1 给出随机假设，使得讨论估计量的均值、方差、协方差成为可能。

关键洞察

第 3 章 OLS 是纯代数运算 $\Rightarrow$ 没有随机假设谈不上“最优”

章节路线图

本章知识结构

- ① Gauss-Markov 模型假设
- ② OLS 估计量的性质（均值、方差）
- ③ Gauss-Markov 定理（核心）
- ④ 定理的直观解释与证明思路

Gauss-Markov 模型假设

Assumption (C1): 线性形式

$$y_i = x_i^\top \beta + \varepsilon_i, \quad i = 1, \dots, n$$

其中 x_i 是 p 维回归量, ε_i 是误差项。

关键条件:

- X 固定且列线性无关
- $E(\varepsilon_i) = 0$
- $\text{cov}(\varepsilon_i, \varepsilon_j) = \sigma^2 \mathbf{1}\{i = j\}$ (同方差、不相关)

个体水平视角: $y_i = x_i^\top \beta + \varepsilon_i$

Assumption 的直观理解

- 每个观测的误差均值 0: $E(\varepsilon_i) = 0$
- 每个误差方差 σ^2 (同方差): $\text{var}(\varepsilon_i) = \sigma^2$
- 不同观测间误差不相关: $\text{cov}(\varepsilon_i, \varepsilon_j) = 0, i \neq j$

同方差假设的含义与重要性

Homoskedasticity (同方差)

- homoskedasticity = 相同方差
- 词源学: homo 更好地表示 variance 含义
- 异方差情形需要加权最小二乘 (见第 19 章)

OLS 估计量：矩阵形式

OLS 估计量

$$\hat{\beta} = (X^{\top} X)^{-1} X^{\top} Y$$

关键性质：

- $\hat{\beta}$ 是 Y 的线性函数
- 仅依赖矩阵运算
- $A = (X^{\top} X)^{-1} X^{\top}$ 不依赖 Y

OLS 估计量的均值与方差 (Theorem 4.1)

Theorem 4.1

在 Gauss-Markov 假设下：

$$E(\hat{\beta}) = \beta \quad (\text{无偏性})$$

$$\text{cov}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}$$

证明思路：利用 $E(Y) = X\beta$ 和 $\text{cov}(Y) = \sigma^2 I_n$

Gauss-Markov 定理（核心）

Theorem 4.2 (Gauss-Markov)

$\hat{\beta}$ 是 β 的 BLUE (Best Linear Unbiased Estimator):

(C1) $\tilde{\beta} = AY$ 对 Y 线性

(C2) $E(\tilde{\beta}) = \beta$ (对所有 β 无偏)

$\Rightarrow \text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta})$ (正定半定序)

BLUE 的含义：协方差矩阵序

正定半定序 $\text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta})$

- 对任意线性组合 $c^\top \tilde{\beta}$ 方差不小于 $c^\top \hat{\beta}$
- 特别地：每个坐标分量 $\tilde{\beta}_j$ 方差最小
- 等价形式： $\text{var}(c^\top \tilde{\beta}) \geq \text{var}(c^\top \hat{\beta})$

为什么只比较线性估计量?

”线性”约束的合理性

- A 可以是 X 的任意非线性函数
- 线性约束已经包含极广的估计量类
- 无偏性是自然要求
- 在许多现代应用中, 有偏估计 (如 Ridge、Lasso) 方差更小

OLS 投影几何直观

投影矩阵

$$H = X(X^{\top}X)^{-1}X^{\top}$$

几何含义：

- $\hat{Y} = HY$ 是 Y 到 X 列空间的投影
- 残差 $\hat{\varepsilon} = (I - H)Y$ 与列空间正交
- OLS 将 Y 分解为拟合值 + 残差

拟合值与残差的分布性质 (Theorem 4.2)

Theorem 4.2

$$E(\hat{Y}) = X\beta, \quad E(\hat{\varepsilon}) = 0$$

$$\text{cov}(\hat{Y}) = \sigma^2 H, \quad \text{cov}(\hat{\varepsilon}) = \sigma^2 (I - H)$$

$\hat{Y}$ 与 $\hat{\varepsilon}$ 不相关。

正交 vs. 不相关：两个关键陈述的区别

常见误区

- 陈述 (S1): $\hat{Y}$ 与 $\hat{\varepsilon}$ 正交 — 代数事实，无需随机假设
 - 陈述 (S2): $\hat{Y}$ 与 $\hat{\varepsilon}$ 不相关 — 随机陈述，需要 Gauss-Markov 假设
- 两者含义不同，不能混淆。

误差椭圆可视化：“最佳”的含义

二维情形

- $\hat{\beta}$ 的置信椭圆
- 其他线性无偏估计的置信椭圆
- OLS 的置信椭圆最小（被其他所有椭圆包裹）
- $\Rightarrow \hat{\beta}$ 在所有方向上方差最小

Gauss-Markov 定理证明思路

四步框架

- ① 第一步：OLS 满足无偏性条件 $\Rightarrow AX = I_p$
- ② 第二步：协方差分解 $\text{cov}(\tilde{\beta}) = \text{cov}(\hat{\beta}) + \text{cov}(\tilde{\beta} - \hat{\beta})$
- ③ 第三步：交叉协方差项为零
- ④ 第四步： $\text{cov}(\tilde{\beta} - \hat{\beta}) \succeq 0 \Rightarrow \text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta})$

例子：简单线性回归的 BLUE

Example

- $y_i = \alpha + \beta x_i + \varepsilon_i$
- $\text{var}(\hat{\beta}) = \sigma^2 / \sum (x_i - \bar{x})^2$
- 任何线性无偏估计的 β 系数方差都不小于此值

例子：均值的 BLUE

Example

- $y_i \sim$ 均值 μ , 方差 σ^2 , 互不相关
- 线性估计 $\hat{\mu} = \sum a_i y_i$, 无偏要求 $\sum a_i = 1$
- 最优选择: $a_i = 1/n$ (简单平均)
- 方差 $\text{var}(\hat{\mu}) = \sigma^2/n$ 为最小

例子：Gauss-Markov 预测定理

Example

- $\hat{Y} = X\hat{\beta}$ 是 $X\beta$ 的最佳线性无偏预测
- 适用于任何线性预测 $\tilde{Y} = \tilde{H}Y$
- $\text{cov}(\tilde{Y}) \succeq \text{cov}(\hat{Y})$

Gauss-Markov 定理总结

主要结论

- Gauss-Markov 模型：线性 + 同方差 + 不相关
- OLS $\hat{\beta}$ 是 BLUE
- 核心： $\text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta})$

局限

- 不谈非线性估计
- 不谈正态假设
- 不谈稳健性

参考文献



Peng Ding. *Linear Model and Extensions*. 2023.