

3.1. 数据背景. 考虑美国 1981-1988 年间每日出生人数的数据。设 y_t 是在第 t 天的新生儿数量， t 是从 1981 年 1 月 1 日起的天数。这个数据集有若干有趣的特征：

- (1) **年度周期:** 夏季出生人数通常高于冬季
- (2) **周内周期:** 周末出生人数显著低于工作日
- (3) **长期趋势:** 出生人数有轻微的逐年下降趋势
- (4) **异常日期:** 某些日期（如圣诞节、新年）出生人数异常低

传统的参数化方法需要为上述每个特征单独建模。高斯过程提供了一种更灵活的选择：我们可以选择合适的协方差函数来同时捕捉这些结构。

3.2. 周期协方差函数. 为了捕捉年度周期，我们可以构造一个周期协方差函数：

$$(121) \quad k_{\text{periodic}}(d, d') = \sigma_p^2 \exp \left(-\frac{2 \sin^2(\pi |d - d'| / 365)}{\ell_p^2} \right),$$

其中 d 是日期（天数）， ℓ_p 控制周期效应的衰减速度， σ_p^2 是周期成分的方差。³

将周期核与其他协方差函数（如 SE 核捕捉长期趋势、线性核捕捉线性趋势）组合，可以得到一个灵活的多成分协方差函数：

$$(122) \quad k(x, x') = k_{\text{SE}}(x, x') + k_{\text{periodic}}(x, x') + k_{\text{linear}}(x, x') + \sigma_y^2 \delta_{xx'},$$

其中 $k_{\text{linear}}(x, x') = \sigma_b^2(x - \bar{x})(x' - \bar{x})$ 是一个线性核，捕捉线性趋势； $\delta_{xx'}$ 是克罗内克 delta 项，对应于观测噪声。

3.3. 后验推断与结果. 通过最大化边缘似然或使用 MCMC，我们可以同时估计所有超参数和潜在函数值 $f(t)$ 。后验预测给出了每日潜在出生趋势的平滑估计，其后验方差在数据稀疏区域（如年末）显著增大。

例 21.1 (生日数据的验证). 在上述模型下，圣诞节前后的预测出生人数显著低于其他日期——这反映在潜在函数 $f(t)$ 的负偏移上。后验置信区间自动包含了这一不确定性。周期成分的最大后验估计对应的周期长度约为 365 天，与经验观察一致。

4. 潜变量高斯过程模型

高斯过程的一个重要推广是将其作为**潜变量 (latent variable)** 嵌入更复杂的模型结构中。这种思路在分类、计数数据和空间建模中有着广泛应用。

4.1. 分类问题中的应用. 设 $y_i \in \{0, 1\}$ 是二元分类结果， x_i 是 p 维协变量。我们可以构造以下潜变量模型：

$$(123) \quad f_i = f(x_i) \sim \text{GP}(0, k(x_i, x_j)),$$

$$(124) \quad \mathbb{P}(y_i = 1) = \text{logit}^{-1}(f_i),$$

其中 $f(x)$ 是潜在高斯过程，logistic 变换将实数值 f_i 映射到概率。这个模型称为**高斯过程分类 (Gaussian Process Classification, GPC)**。

由于 logistic 变换的非线性性，后验分布 $p(f|y)$ 不再有解析形式。近似方法包括：

- (1) **拉普拉斯近似 (Laplace approximation):** 用高斯分布近似后验

³周期协方差函数的构造及与傅里叶分析的关联见附录 ??。

(2) **期望传播 (Expectation Propagation, EP)**: 迭代地近似每个数据点的似然贡献

(3) **马尔科夫链蒙特卡洛 (MCMC)**: 对潜变量和超参数进行后验抽样

后验预测: 给定新点 x_* , 我们需要计算

$$\mathbb{P}(y_* = 1|y) = \int \text{logit}^{-1}(f_*)p(f_*|f, y)p(f|y) df_* df.$$

这个积分同样没有解析解, 需要使用近似方法。

注 21.2. GPC 的一个关键计算瓶颈是: 每次超参数更新都需要重新计算协方差矩阵 K 和它的逆。对于大规模数据集, $O(n^3)$ 的计算复杂度成为瓶颈。稀疏近似 (sparse approximation) 通过引入 $m \ll n$ 个诱导点 (inducing points) 将计算复杂度降为 $O(nm^2)$ 。⁴

4.2. 计数数据的应用. 对于计数数据 $y_i \in \{0, 1, 2, \dots\}$, 我们可以使用对数线性模型:

$$(125) \quad \lambda_i = \exp(f(x_i)), \quad f \sim \text{GP}(0, k),$$

$$(126) \quad y_i \sim \text{Poisson}(\lambda_i).$$

这个模型等价于将高斯过程置于对数-link 函数之后。在生态学中, 这称为**对数高斯 Cox 过程 (Log-Gaussian Cox Process)**, 用于空间点格局 (spatial point pattern) 的建模。

5. 函数数据分析

高斯过程为函数数据分析 (Functional Data Analysis, FDA) 提供了一种自然的贝叶斯框架。在 FDA 中, 每个观测单位 (如一个患者) 记录的是整个函数曲线 $y_i(t)$, 而非单个标量值。

5.1. 函数数据的层级模型. 设 $y_i(t)$ 是第 i 个个体的函数型观测, t 通常是时间或空间坐标。我们假设

$$(127) \quad y_i(t) = f_i(t) + \epsilon_i(t),$$

$$(128) \quad f_i(t) = \mu(t) + g_i(t),$$

$$(129) \quad g_i(t) \sim \text{GP}(0, k_g), \quad \epsilon_i(t) \sim \text{GP}(0, \sigma_\epsilon^2 \delta),$$

其中 $\mu(t)$ 是总体均值函数, $g_i(t)$ 是个体随机效应 (捕获个体间的变异), $\epsilon_i(t)$ 是测量误差。

这个模型的优势在于: **高斯过程先验同时提供了函数空间的平滑性约束和数据驱动的平滑度估计**。个体效应 $g_i(t)$ 的后验均值给出了每个个体的平滑轨迹估计, 其后验方差自动反映了样本量 (观测时间点数量) 对估计精度的影响。

5.2. 主成分分析与高斯过程的联系. 在经典的 FDA 中, 主成分分析 (PCA) 用于降维——将无限维函数投影到少数主成分方向上。有趣的是, **高斯过程协方差函数的主成分分解与经典 PCA 之间存在深层对应关系**。

具体而言, 协方差算子 $K(s, t) = \text{cov}(f(s), f(t))$ 的特征函数给出了函数空间中最主要的变异模式。这在函数型数据的降维表示中有着直接应用。⁵

⁴稀疏高斯过程近似的详细推导见附录 ??。

⁵高斯过程与函数型 PCA 的数学联系见附录 ??。

6. 密度估计与回归

高斯过程的灵活性还体现在密度估计和回归问题中。通过对潜在函数施加适当的约束，高斯过程可以用于建模非负函数（密度）和单调函数。

6.1. 变换高斯过程. 设我们希望估计一个未知的一维密度函数 $p(x)$ 。一个自然的想法是先对 $\log p(x)$ 建模：

$$\log p(x) = f(x), \quad f \sim \text{GP}(m(x), k(x, x')).$$

为保证 $p(x) \geq 0$ 且 $\int p(x)dx = 1$ ，我们需要对 f 施加约束。一种方法是在有限网格上离散化，然后用 softmax 变换确保归一化：

$$p_j = \frac{\exp(f_j)}{\sum_k \exp(f_k)}.$$

在贝叶斯框架下，我们可以对 f 指定高斯过程先验，然后使用 MCMC 抽样后验分布。⁶

另一种更直接的方法是对累积分布函数（CDF）建模：对 $F(x) = \mathbb{P}(X \leq x)$ 假设高斯过程先验（保证 F 单调和取值于 $[0, 1]$ ），然后通过微分得到密度 $p(x) = F'(x)$ 。

6.2. 高斯过程回归的边界约束. 在某些应用中，我们需要对回归函数施加单调性约束（ $f'(x) \geq 0$ ）或其他边界约束。高斯过程的条件约束可以通过**镜像技术（reflection method）**或**回归方法（regression method）**实现。⁷

7. 高斯过程的计算复杂度

高斯过程的核心计算瓶颈是协方差矩阵的求逆。对于 n 个训练点，精确计算需要 $O(n^3)$ 时间和 $O(n^2)$ 存储。

7.1. 大规模数据的稀疏近似. 当 n 达到数万甚至更多时，精确高斯过程变得不可行。稀疏近似方法的核心思想是用 m 个代表性诱导点（inducing points）来近似完整协方差矩阵，从而将 $O(n^3)$ 降为 $O(nm^2)$ 。具体而言，我们引入诱导输入点 $Z = \{z_j\}_{j=1}^m$ 和对应的函数值 $u_j = f(z_j)$ ，然后通过 $p(f_*|y) \approx \int p(f_*|u)q(u|y)du$ 来近似后验预测。⁸

(1) **策略近似（Subset of Variables）**：仅使用 $m \ll n$ 个随机选取的训练点

(2) **诱导点近似（Inducing Points）**：引入独立的诱导输入点 $Z = \{z_j\}$ 和诱导输出 $u_j = f(z_j)$ ，然后用 $p(f_*|y) \approx \int p(f_*|u)q(u|y)du$ 近似

代表性方法包括 FITC（Fully Independent Training Conditional）、PITC（Partially Independent Training Conditional）和 Nyström 近似。

7.2. 梯度优化与超参数估计. 超参数 θ 的边缘似然（log-marginal likelihood）为

$$(130) \quad \log p(y|\theta) = -\frac{1}{2}y^\top (K_\theta + \sigma_y^2 I)^{-1}y - \frac{1}{2}\log |K_\theta + \sigma_y^2 I| - \frac{n}{2}\log 2\pi.$$

边缘似然对超参数 θ 的梯度可以通过自动微分或有限差分计算。最大化边缘似然等价于经验贝叶斯估计。⁹

⁶变换高斯过程密度估计的完整推断算法见附录 ??。

⁷单调高斯过程的构造与计算见附录 ??。

⁸稀疏高斯过程近似的详细推导见附录 ??。

⁹边缘似然的梯度推导见附录 ??。

8. 高斯过程与神经网络的联系

一个引人注目的理论结果是：**宽度趋于无穷神经网络 (neural network) 收敛于一个高斯过程**。这一发现由 Neal (1997) 首先证明，随后在无限宽极限与神经网络的贝叶斯后验之间建立了精确对应。

具体而言，设一个全连接神经网络的权重和偏置独立同分布，当网络宽度（每层神经元数）趋于无穷时，网络输出的先验分布趋向于高斯过程。这意味着：

- (1) 无限宽神经网络的函数空间先验等价于某个高斯过程先验
- (2) 网络权重的贝叶斯后验预测在无限宽极限下等价于对应 GP 的预测
- (3) GP 的协方差函数由网络的激活函数和权重初始化方差决定

这个联系为理解神经网络的函数空间动力学提供了概率论框架，也为使用 GP 作为神经网络不确定性的替代模型提供了理论基础。

9. 本章小结

本章我们系统介绍了高斯过程模型：

- (1) 高斯过程是对函数空间的正态分布建模，为回归、分类、密度估计等问题提供了灵活的先验分布
- (2) 协方差函数（核函数）编码了关于函数平滑性、周期性和尺度等重要先验假设
- (3) 高斯过程回归的后验预测分布有解析形式，这是其最重要的计算优势
- (4) 周期核、SE 核等可以组合成复合协方差函数，捕捉数据中的多尺度结构
- (5) 潜变量高斯过程模型可以推广到分类、计数等非高斯数据
- (6) 函数数据分析可以从高斯过程的视角统一理解
- (7) 变换高斯过程可以用于密度估计和单调回归
- (8) 计算复杂度 $O(n^3)$ 是精确高斯过程的主要瓶颈，稀疏近似方法在大规模数据中广泛应用
- (9) 高斯过程与神经网络的深层联系揭示了无限宽网络的函数空间结构

10. 下节预告

下一章我们将学习有限混合模型 (Finite Mixture Models)，这是另一类灵活的非参数化方法。混合模型通过将分布表示为若干成分的加权混合来捕捉数据的异质性——这与高斯过程关注函数空间的连续建模形成互补。

11. 习题

练习 21.1. ?? 高斯过程后验 设 $f \sim \text{GP}(0, k)$ ，观测模型为 $y = f + \epsilon$ ，其中 $\epsilon \sim \text{N}(0, \sigma_y^2 I)$ 。证明后验预测分布的均值和方差满足 ?? 和 ??。

练习 21.2. ?? 协方差函数的性质 证明平方指数核 $k_{\text{SE}}(x, x')$ 是正定的，即对任意实数 $a_1, \dots, a_n$ 和点 $x_1, \dots, x_n$ ，有 $\sum_{i,j} a_i a_j k_{\text{SE}}(x_i, x_j) \geq 0$ 。

练习 21.3. ?? 周期核的构造 设 $k_{\text{base}}(x, x')$ 是一个协方差函数。证明 $k_{\text{periodic}}(x, x') = k_{\text{base}}(\sin(\pi(x - x')/T), \cos(\pi(x - x')/T))$ 产生一个以 T 为周期的协方差函数。

练习 21.4. ?? 边缘似然的梯度 推导边缘似然 ?? 对超参数 θ 的梯度公式，并说明如何在实际计算中利用协方差矩阵的 Cholesky 分解提高数值稳定性。

练习 21.5. ?? 稀疏近似 描述诱导点 (inducing points) 方法的直觉，并比较 FITC 和 PITC 两种稀疏近似策略在计算复杂度和近似精度上的差异。

有限混合模型

1. 本章导论

在前面各章中，我们学习的模型大多假设数据来自某个特定的参数分布族——例如正态分布、二项分布或泊松分布。然而，现实世界的的数据往往远比这复杂：一个总体可能包含多个异质性子群体，而每个子群体内部的行为相对简单。这种**异质性** (heterogeneity) 在社会科学、生物统计学、金融和机器学习中无处不在。

如何为这类异质性数据构建统计模型？一个自然的想法是：将总体视为若干个简单分布的混合，每个简单分布代表一个潜在的子群体。这就是**混合模型** (mixture model) 的核心思想。

本章研究有限混合模型 (finite mixture models)，即假设总体由有限个分量 (component) 混合而成的模型。我们将讨论：

- (1) 混合模型的动机与应用场景
- (2) 有限混合分布的数学形式
- (3) 贝叶斯框架下的推断方法
- (4) 标签切换问题及其处理
- (5) 实际应用案例

2. 异质性数据与混合模型的引入

2.1. 为什么需要混合模型？考虑以下实际场景：

一个天文数据库中记录了星系的退行速度 (redshift)。物理学家知道星系形成于不同的演化阶段，因此观测到的速度分布可能不是单峰的正态分布，而是多个峰值——每个峰值对应一类星系。

或者，考虑医学研究中的生存时间数据：患者在接受治疗后，有些人对治疗反应良好 (生存时间较长)，有些人对治疗反应不佳 (生存时间较短)。如果我们忽略这种异质性，用单一分布建模，可能会得到误导性的结论。

在这些场景中，数据的异质性来源于**未观测到的分组结构** (unobserved grouping structure)。混合模型提供了一种原则性的方法来刻画这种结构。

2.2. 从潜在类别到混合模型. 设我们有一组数据 $y = (y_1, \dots, y_n)$ 。假设每个观测 y_i 属于某个潜在的类别 $z_i \in \{1, 2, \dots, K\}$ ，其中 K 是类别总数。类别 z_i 是未被观测到的 (latent)。

给定类别 $z_i = k$ 时， y_i 的分布为某个简单的参数分布：

$$y_i \mid z_i = k \sim f_k(y_i \mid \theta_k)$$

其中 f_k 是第 k 个分量的密度函数， θ_k 是对应的参数。

类别变量 z_i 本身服从多项分布：

$$z_i \sim \text{Categorical}(\pi_1, \dots, \pi_K)$$

其中 $\pi_k = \mathbb{P}(z_i = k)$ 是第 k 个类别的先验概率。

将潜在类别边缘化, 我们得到观测数据的边际分布:

$$p(y_i) = \sum_{k=1}^K \pi_k \cdot f_k(y_i | \theta_k)$$

这就是**有限混合分布** (finite mixture distribution) 的数学形式。

3. 有限混合分布的形式与性质

3.1. 混合分布的基本形式. 有限混合模型的核心是?? 所示的加权求和形式。权重 π_k 满足 $\pi_k \geq 0$ 且 $\sum_{k=1}^K \pi_k = 1$, 因此构成一个概率分布。

定义 22.1 (有限混合分布). 设 $f_1(y), \dots, f_K(y)$ 为 K 个密度函数 (或质量函数), $\theta = (\pi_1, \dots, \pi_K, \theta_1, \dots, \theta_K)$ 为参数向量, 其中 $\pi_k \geq 0$, $\sum_{k=1}^K \pi_k = 1$ 。则由

$$p(y | \theta) = \sum_{k=1}^K \pi_k \cdot f_k(y | \theta_k)$$

定义的分布称为**有限混合分布** (finite mixture distribution), K 称为混合分量数 (number of components)。

混合分布的矩可以通过各分量的矩加权平均得到。例如, 混合分布的均值为

$$\mathbb{E}(y) = \sum_{k=1}^K \pi_k \cdot \mathbb{E}(y | z = k) = \sum_{k=1}^K \pi_k \cdot \mu_k$$

其中 μ_k 是第 k 个分量的均值。

混合分布的方差更为复杂, 需要考虑组内方差和组间方差的叠加。

3.2. 混合正态分布. 最常用的混合分布是**混合正态分布** (Gaussian mixture model):

$$p(y | \theta) = \sum_{k=1}^K \pi_k \cdot N(y | \mu_k, \sigma_k^2)$$

其中 $\theta_k = (\mu_k, \sigma_k^2)$ 。

混合正态分布具有以下性质:

- (1) 任何平滑的密度函数都可以用足够多分量的混合正态分布任意逼近 (根据 Stone-Weierstrass 逼近定理)
- (2) 混合正态分布本身不再是正态分布, 但其对数是凹函数 (当 $K > 1$ 时)
- (3) 混合正态分布可以表示多峰、偏态等复杂形态

例 22.1 (双正态混合). 设 $K = 2$, $\pi_1 = \pi_2 = 0.5$, $\mu_1 = -2$, $\sigma_1^2 = 1$, $\mu_2 = 2$, $\sigma_2^2 = 1$ 。则混合分布为

$$p(y) = 0.5 \cdot N(y | -2, 1) + 0.5 \cdot N(y | 2, 1)$$

这个分布是双峰的, 两个峰分别位于 $y = -2$ 和 $y = 2$ 附近。

混合正态分布在聚类分析 (clustering) 中应用广泛: 每个分量对应一个潜在的类别, 我们可以用贝叶斯推断来同时估计类别参数和每个观测的类别归属概率。

4. EM 算法与混合模型的推断

4.1. 潜在变量的引入. 混合模型的难点在于：潜在类别 z_i 是未被观测到的。如果 z_i 被观测到（即我们已知每个观测属于哪个分量），则问题将大大简化——我们可以分别对每个分量进行推断。

EM 算法 (Expectation-Maximization) 由 Dempster, Laird 和 Rubin [?] 于 1977 年提出，正是利用了这种思想：通过迭代地估计潜在变量 (E 步) 和更新参数 (M 步)，来最大化观测数据的似然。

设 $\theta = (\pi, \theta_1, \dots, \theta_K)$ 为全部参数，其中 $\pi = (\pi_1, \dots, \pi_K)$ 。观测数据的对数似然为

$$\ell(\theta) = \sum_{i=1}^n \log \left(\sum_{k=1}^K \pi_k \cdot f_k(y_i | \theta_k) \right)$$

这个对数似然包含对潜在变量的求和，导致直接最大化困难。EM 算法通过引入潜在变量的后验分布来解决这个问题。

4.2. E 步：计算潜在变量的后验. 在第 t 次迭代，假设当前参数估计为 $\theta^{(t)}$ 。E 步计算给定观测数据和当前参数下，每个观测属于各分量的后验概率：

$$\gamma_{ik}^{(t)} = \mathbb{P}(z_i = k | y_i, \theta^{(t)}) = \frac{\pi_k^{(t)} \cdot f_k(y_i | \theta_k^{(t)})}{\sum_{j=1}^K \pi_j^{(t)} \cdot f_j(y_i | \theta_j^{(t)})}$$

γ_{ik} 被称为“责任” (responsibility)：第 k 个分量对观测 y_i 的责任程度。

从贝叶斯的角度， γ_{ik} 就是给定 y_i 后， $z_i = k$ 的后验概率。

4.3. M 步：更新参数估计. M 步在“完全数据”（观测数据 + 潜在变量）上最大化期望对数似然。完全数据的对数似然为

$$\ell_c(\theta) = \sum_{i=1}^n \sum_{k=1}^K \mathbb{I}(z_i = k) \cdot [\log \pi_k + \log f_k(y_i | \theta_k)]$$

取期望（关于 z_i 的后验分布），得到期望完全数据对数似然：

$$Q(\theta, \theta^{(t)}) = \sum_{i=1}^n \sum_{k=1}^K \gamma_{ik}^{(t)} \cdot [\log \pi_k + \log f_k(y_i | \theta_k)]$$

M 步通过对 Q 关于 θ 最大化来更新参数。对于混合正态模型，更新公式为：

$$\begin{aligned} \pi_k^{(t+1)} &= \frac{1}{n} \sum_{i=1}^n \gamma_{ik}^{(t)} \\ \mu_k^{(t+1)} &= \frac{\sum_{i=1}^n \gamma_{ik}^{(t)} \cdot y_i}{\sum_{i=1}^n \gamma_{ik}^{(t)}} \\ (\sigma_k^2)^{(t+1)} &= \frac{\sum_{i=1}^n \gamma_{ik}^{(t)} \cdot (y_i - \mu_k^{(t+1)})^2}{\sum_{i=1}^n \gamma_{ik}^{(t)}} \end{aligned}$$

1

¹方差更新公式的推导见附录 ??。

4.4. EM 算法的收敛性. EM 算法保证观测数据似然的单调递增: $\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$ 。但收敛到的点可能是局部极大值, 而非全局极大值。因此, EM 算法对初始值敏感, 通常需要多次随机初始化。

对于混合模型的贝叶斯推断, 我们通常关注后验分布 $p(\theta, z | y)$, 而不仅仅是点估计。这需要使用 MCMC 方法 (如 Gibbs 采样), 我们将在下一节讨论。

5. 贝叶斯混合模型推断

5.1. 完全条件分布. 在贝叶斯框架下, 我们为所有参数指定先验分布 $p(\theta)$, 然后推断后验分布 $p(\theta, z | y)$ 。

对于混合正态模型, 一个方便的选择是共轭先验:

$$\pi \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K)$$

$$\mu_k | \sigma_k^2 \sim N(\mu_0, \sigma_k^2/n_0)$$

$$\sigma_k^2 \sim \text{Inverse-Gamma}(\nu_0/2, \nu_0\sigma_0^2/2)$$

给定这些先验, 可以推导出各参数的完全条件分布 (Gibbs 采样所需)。

第 k 个分量的混合比例 π_k 的完全条件分布为:

$$\pi | y, z, \theta_{-\pi} \sim \text{Dirichlet}(\alpha_1 + n_1, \dots, \alpha_K + n_K)$$

其中 $n_k = \sum_{i=1}^n \mathbb{I}(z_i = k)$ 是属于第 k 个分量的观测数。

第 k 个分量的均值和方差的完全条件分布为正态-逆 Gamma 分布。

潜在类别变量 z_i 的完全条件分布为:

$$\mathbb{P}(z_i = k | y_i, \theta) \propto \pi_k \cdot N(y_i | \mu_k, \sigma_k^2)$$

这就是?? 中的后验概率——在贝叶斯版本中, 它是完全条件分布, 而非 EM 算法中的点估计。

5.2. Gibbs 采样算法. 基于完全条件分布, 我们可以设计 Gibbs 采样器来从后验分布中抽样:

- (1) 初始化参数 $\theta^{(0)}$
- (2) 对 $t = 1, 2, \dots$ 迭代:
 - (a) 对每个 $i = 1, \dots, n$, 从 ?? 抽取 $z_i^{(t)}$
 - (b) 从 π 的完全条件分布抽取 $\pi^{(t)}$
 - (c) 对每个 $k = 1, \dots, K$, 从 μ_k, σ_k^2 的完全条件分布抽取

Gibbs 采样器的收敛性可以通过监控多链的 Gelman-Rubin 统计量 [?] 来诊断。

6. 标签切换问题

6.1. 问题的本质. 混合模型的一个核心问题是**标签切换** (label switching): 由于似然函数在分量标签的置换下保持不变, 后验分布是关于分量标签对称的。

具体来说, 如果 (z_i, π_k, θ_k) 是一个合法的后验样本, 那么对任意置换 $\sigma, (\sigma(z_i), \pi_{\sigma(k)}, \theta_{\sigma(k)})$ 同样是合法的后验样本。

这导致两个问题:

- (1) 后验均值失去意义: K 个分量的后验均值相互混合
- (2) 迭代收敛后, 每次迭代的标签可能不一致

6.2. 标签切换的解决. 解决标签切换问题的方法主要有：

- (1) **排序约束**：通过对参数施加排序约束（如 $\mu_1 < \mu_2 < \dots < \mu_K$ ）来打破对称性。这是最简单的方法，但可能不适合所有场景。
- (2) **标签切换检测与对齐**：在 MCMC 采样后，检测标签切换事件，并通过对齐链来恢复因果顺序。
- (3) **后处理**：使用递归分区或聚类方法将后验样本分类到各个分量。

排序约束是最常用的方法，但需要谨慎使用，因为人为的约束可能影响推断结果。

7. 应用实例：星系速度数据

本节我们用混合正态模型分析星系退行速度数据。²

设 y_i 为第 i 个星系的退行速度（单位：km/s）。我们用双正态混合模型：

$$y_i \sim \pi \cdot N(\mu_1, \sigma_1^2) + (1 - \pi) \cdot N(\mu_2, \sigma_2^2)$$

贝叶斯推断的目标是：

- (1) 估计两个星族（population）的速度分布参数
- (2) 计算每个星系属于各星族的后验概率
- (3) 评估混合比例 π

使用 Gibbs 采样，我们可以从后验分布中抽取样本，然后计算各参数的后验均值和置信区间。

注 22.1. 混合模型的一个优势是它提供了**软聚类**（soft clustering）：与硬聚类（每个观测必须属于某一类）不同，混合模型给出每个观测属于各类的概率。这对于边界情况特别有价值。

8. 混合模型的其他应用

混合模型在统计学和机器学习中有广泛的应用：

- (1) **密度估计**：混合模型可以用于非参数密度估计，用有限个参数的混合分布逼近任意复杂的密度函数。
- (2) **聚类分析**：如上所述，混合模型提供了一种基于概率的聚类方法。
- (3) **缺失数据插补**：在存在缺失值的问题中，可以将缺失数据的插补值视为潜在变量，用混合模型进行多重插补。
- (4) **生存分析**：考虑未观测到的异质性来源（如未观测到的风险因素），混合模型可以用于建模生存数据中的非比例风险。
- (5) **时间序列**：隐马尔可夫模型（Hidden Markov Model）是混合模型在时间序列中的推广。

9. 混合模型的扩展

有限混合模型是更广泛模型类别的特例：

- (1) **无限混合模型**（Infinite mixture models）：当分量数 $K \rightarrow \infty$ 时，得到非参数贝叶斯方法，如狄利克雷过程混合（Dirichlet process mixture）。这将在第 23 章讨论。
- (2) **半参数混合模型**：放松对分量分布的假设，允许非参数形式的分量分布。
- (3) **高斯过程混合**：在函数空间中进行混合，用于非参数回归和分类。

²数据来源见 [?].

10. 本章小结

本章我们学习了有限混合模型：

- (1) 混合模型用于建模具有未观测到的异质性的数据
- (2) 有限混合分布是各分量分布的加权平均
- (3) EM 算法提供了一种寻找最大似然估计的迭代方法
- (4) 贝叶斯推断使用 Gibbs 采样从后验分布中抽样
- (5) 标签切换问题需要特殊处理
- (6) 混合模型在聚类、密度估计、生存分析等领域有广泛应用

11. 延伸阅读

关于混合模型的更多信息，推荐以下参考文献：

- [?]: 混合模型的经典教材
- [?]: 有限混合模型的统计推断
- [?]: 贝叶斯混合模型的方法与应用

狄利克雷过程模型

1. 本章导论

在前几章中，我们探讨了有限混合模型——用有限个组件的加权组合来刻画异质数据。在实践中，分析者必须事先指定成分的数量 K ，这往往是一个困难的选择。Dirichlet 过程 (Dirichlet Process, DP) 提供了一种优雅解决方案：允许无限多个潜在成分，让数据自适应地确定有效成分的个数。

Dirichlet 过程是贝叶斯非参数统计的核心工具。它由 Ferguson (1973) 引入，是一种随机过程，其样本路径 almost surely (以概率 1) 是离散概率分布。这一看似特殊的性质——连续底空间上的随机概率分布却以概率 1 取离散值——正是 DP 成为非参数贝叶斯推断强大先验的根源。

本章的结构如下：先从有限混合模型与 DP 的联系入手，介绍 DP 的三种等价构造 (stick-breaking、Pólya urn、Chinese restaurant process)，然后讨论 DP 作为未知分布的先验及其后验推断，最后介绍 DP 混合模型的计算方法。

2. 从有限混合到无限混合

在有限混合模型中，我们假设数据来自 K 个成分的混合：

$$p(y_i|\theta_1, \dots, \theta_K, \pi) = \sum_{k=1}^K \pi_k p(y_i|\theta_k),$$

其中 $\pi = (\pi_1, \dots, \pi_K)$ 是混合权重，满足 $\pi_k \geq 0$, $\sum_{k=1}^K \pi_k = 1$ 。

一个自然的问题是： K 本身能否从数据中学习，而不是预先固定？一个激进的思路是直接令 $K \rightarrow \infty$ ，但这在参数模型框架下并不容易处理。DP 提供了一种优雅的解决方案：先验性地将混合成分的数量设为无限，然后通过后验推断自动确定有效成分个数。

Dirichlet 过程先验的核心思想是：不去直接参数化混合权重 π_k ，而是假设混合权重本身来自一个随机过程，使得“有多少个有效成分”由数据决定。

3. 狄利克雷过程的定义与构造

3.1. Stick-breaking 构造. 设 G_0 为一个基分布 (base measure), $\alpha > 0$ 为浓度参数 (concentration parameter)。Dirichlet 过程 $G \sim (\alpha, G_0)$ 可以通过以下 stick-breaking 构造 (Sethuraman, 1994) 生成：

定义 23.1 (Stick-breaking 构造). 令 $V_1, V_2, \dots$ 为独立同分布的 Beta 随机变量, $V_k \sim \text{Beta}(1, \alpha)$ 。定义

$$w_k = V_k \prod_{j=1}^{k-1} (1 - V_j), \quad k = 1, 2, \dots$$

则

$$G = \sum_{k=1}^{\infty} w_k \delta_{\theta_k},$$

其中 $\theta_1, \theta_2, \dots$ 独立同分布自 G_0 , 且与 $(V_1, V_2, \dots)$ 相互独立。

直观理解: 取一根单位长度的棍子 (stick), 第一步折下长度为 V_1 的第一段, 分配给 atom θ_1 ; 剩余长度为 $1 - V_1$ 的棍子上, 折下长度为 $(1 - V_1)V_2$ 的第二段, 分配给 θ_2 ; 依此类推。由于 $\prod_{j=1}^{\infty} (1 - V_j) = 0$ with probability 1, 这个过程永远不会终止, 因此产生了无限多个 atoms, 但权重之和为 1。

权重 w_k 的期望为 $\mathbb{E}w_k = \frac{1}{1+\alpha} \left(\frac{\alpha}{1+\alpha}\right)^{k-1}$, 随 k 指数衰减。 α 越大, 衰减越慢, 有效成分个数越多。

3.2. Pólya urn 构造. Stick-breaking 构造从“折棍子”的角度直观理解了 DP 权重的来源。另一种等价的概率视角来自 Pólya urn scheme——一种经典的随机 urn 过程。设我们有颜色 (atoms) 集合, urn 中每次加入一个球:

- (1) 以概率 $\alpha/(\alpha + n - 1)$ 加入一个新颜色的球 (颜色为从 G_0 中独立抽取的 θ);
- (2) 以概率 $(n_k)/(\alpha + n - 1)$ 加入一个颜色为 k 的已有球 (n_k 为 urn 中颜色 k 的球数)。

这个 urn 过程产生的颜色分布恰好与 stick-breaking 构造等价。

3.3. Chinese restaurant process (中国餐厅过程). 第三种构造与中国餐厅过程的隐喻密切相关。

想象一个拥有无限多张桌子的餐厅, 第一位顾客随意选择一张桌子就座。第 n 位顾客到来时:

- 以概率 $\alpha/(\alpha + n - 1)$ 选择一张新桌子;
- 以概率 $n_k/(\alpha + n - 1)$ 选择已有桌子 k (n_k 为该桌已坐的顾客数)。

顾客坐在不同桌子上的概率分布恰好描述了 DP 样本中 atoms 的分配结构。同一桌子上的顾客可以理解为来自同一个聚类 (cluster)。这就是著名的 Chinese restaurant process (CRP)。

CRP 的魅力在于它将离散概率分布的随机结构编码为一个 sequential partition 过程——这与统计学中聚类分析的精神高度一致: 数据自然地聚集成簇, 而簇的数量本身由数据决定。

这三种构造实际上是等价的: stick-breaking 给出了权重的显式分布, urn 过程描述了 atoms 的依次分配, 而 CRP 则是 urn 过程在聚类视角下的另一种表述。Ferguson (1973) 最初通过有限 Dirichlet 分布的类比构造了 DP; Sethuraman (1994) 的 stick-breaking 形式和 Blackwell-MacQueen (1973) 的 urn 形式则给出了更便于计算的等价表述。

注 23.1. CRP 中的参数 α 控制聚类个数的“先验期望”。 α 越小, 倾向于更少的聚类; α 越大, 倾向于更多的聚类。这与直觉一致: α 作为浓度参数, 在 stick-breaking 中控制了权重衰减的速度。

4. DP 作为未知分布的先验

DP 的核心应用是作为未知分布 F 的先验。设我们希望从分布 F 中抽取独立样本 $x_1, \dots, x_n$, 但对 F 的形式一无所知。

一个非参数的思路是: 对 F 赋予先验, 然后在后验下进行推断。DP 正是这样一个先验:

$$F \sim (\alpha, G_0).$$

具体而言，我们假设：

$$\theta_i | F \stackrel{\text{iid}}{\sim} F, \quad F \sim (\alpha, G_0),$$

其中 G_0 是一个参数化的分布（如正态分布）， α 控制先验的灵活性。

由于 G 的样本路径是离散分布，我们可以将模型等价地写为：

$$\theta_i \stackrel{\text{iid}}{\sim} G, \quad G \sim (\alpha, G_0).$$

但更常见的是直接积分掉 G ，得到 θ_i 的边缘分布——这正是下一节要讨论的折棍（stick-breaking）表示的核心应用。

5. 后验推断

给定观测数据 $\mathbf{x} = (x_1, \dots, x_n)$ ，DP 先验下的后验推断有一个优雅的形式。

假设基分布 G_0 是某个参数 ϕ 的分布，即 $x_i | \phi \sim p(x | \phi)$ ，且 $\phi \sim G_0$ 。那么后验有如下形式：¹

$$G | \mathbf{x} \sim \left(\alpha + n, \frac{\alpha}{\alpha + n} G_0 + \frac{n}{\alpha + n} \cdot \frac{1}{n} \sum_{i=1}^n \delta_{x_i} \right).$$

这一结果表明：后验等价于在先验 G_0 的基础上”添加”了经验分布的 contribution。具体而言：

- 有效样本量从 α 增加到 $\alpha + n$ ；
- 后验基分布是 G_0 与经验分布 $\frac{1}{n} \sum_i \delta_{x_i}$ 的加权平均，权重分别为 $\frac{\alpha}{\alpha + n}$ 和 $\frac{n}{\alpha + n}$ 。

预测分布也有简洁形式。设新观测为 $\tilde{x}$ ，则其后验预测分布为：²

$$p(\tilde{x} | \mathbf{x}) = \frac{\alpha}{\alpha + n} G_0(\tilde{x}) + \frac{1}{\alpha + n} \sum_{i=1}^n \delta_{x_i}(\tilde{x}).$$

也就是说，新数据点有概率 $\alpha/(\alpha + n)$ 来自基分布 G_0 （产生一个新 atom），有概率 $n/(\alpha + n)$ 与已有数据点 x_i 相同（与同一 cluster 的数据共享）。这正是 CRP 的 predictive probability。

6. DP 混合模型

DP 混合模型（Dirichlet process mixture model, DPM）是 DP 先验在密度估计中的主要应用形式。模型设定为：

$$x_i | \theta_i \sim p(x | \theta_i), \quad \theta_i | G \stackrel{\text{iid}}{\sim} G, \quad G \sim (\alpha, G_0).$$

与有限混合模型相比，DPM 的关键区别在于：成分的数量是无限的（由 stick-breaking 过程产生），而有效成分的个数由数据通过后验推断自动确定。

从聚类角度看，DPM 自然地产生了一个 partition——数据被划分为若干聚类，每个聚类内的数据共享同一参数 θ_k 。这个 partition 是随机且自适应的，与 CRP 的 sequential partition 精神一致。

7. 计算方法

DP 混合模型的计算核心挑战在于：stick-breaking 构造涉及无限多个 atoms，而后验中 atoms 的个数同样是无限的。MCMC 方法是处理这一问题的主要工具。

¹推导见附录 ??

²推导见附录 ??

7.1. Blocked Gibbs 采样器. 一种直接的方法是引入隐含的聚类分配指标 $\mathbf{c} = (c_1, \dots, c_n)$, 其中 $c_i = k$ 表示 x_i 属于第 k 个聚类。

全条件后验分布为:

$$p(c_i = k | \mathbf{c}_{-i}, \mathbf{x}, \alpha) \propto \begin{cases} n_{-i,k} \cdot p(x_i | \theta_k, \mathbf{x}_{-i}) & \text{if } k \text{ is an existing cluster,} \\ \alpha \cdot p(x_i | \theta_{\text{new}}, G_0) & \text{if } k \text{ is a new cluster.} \end{cases}$$

其中 $n_{-i,k}$ 是除 i 外属于第 k 个聚类的数据点数。

然后从各自的后验分布中采样 θ_k 。这个过程在 c_i 和 θ_k 之间交替进行, 即 blocked Gibbs 采样。

7.2. Chinese Restaurant Process 采样. CRP 的视角给出了一种更直观的采样方案。已知完整数据下的 CRP predictive probability, Gibbs 采样可以直接对聚类分配进行更新, 而无需显式处理无限多个 atoms。

具体而言, 对于数据点 i , 计算其属于现有聚类 k 和属于新聚类的概率, 然后按概率重新分配。这个方法在高维数据和中等规模数据集上通常效率较高。

8. 应用举例

例 23.1 (基于 DP 聚类的密度估计). 假设我们有一组来自混合分布的观测数据, 数据中存在两个自然聚类, 但分析者事先并不知道聚类的个数。

应用 DPM 模型, 设成分分布为正态分布 $N(\mu_k, \sigma_k^2)$, 基分布 G_0 取为 Normal-Inverse-Gamma 共轭先验。MCMC 采样将自动:

- 在后验中探索不同的聚类个数;
- 收敛到数据中真实存在的聚类结构;
- 提供每个聚类的参数后验分布。

DP 混合模型在以下场景中尤为有用:

- 密度估计: 当数据具有未知数量的峰 (modes) 时;
- 聚类分析: 当聚类个数事先未知, 且聚类结构可能随协变量变化时;
- 随机过程建模: 如隐马尔可夫模型的状态转移矩阵非参数化推广;
- 函数逼近: 如 DP 基函数回归 (DP mixture of regressions)。

9. 与其他非参数方法的联系

DP 并非唯一的贝叶斯非参数工具。在密度估计中, 高斯过程 (见 Chapter 21) 提供了函数空间上的先验, Dirichlet 过程则提供了分布空间上的先验。

从数学上看, DP 是概率分布空间 $\mathcal{P}$ 上的先验 (其样本是离散分布), 而高斯过程是函数空间上的先验 (其样本是函数曲线)。两者在无限维参数空间中都实现了“让数据自适应确定有效复杂度”的思想, 但在应用层面: DP 更适合聚类、密度估计和混合模型; 高斯过程更适合函数回归、时空建模。

一个有用的视角是: DP 是有限维 Dirichlet 分布 $\text{Dir}(\alpha_1, \dots, \alpha_K)$ 在 $K \rightarrow \infty$ 时的推广。有限维 Dirichlet 分布是定义在 K 维单纯形上的分布, 其样本是 K 维向量 $(w_1, \dots, w_K)$; DP 则是其无限维推广, 样本是无限维的离散分布。

历史上, Ferguson (1973) 正是通过有限 Dirichlet 分布的类比, 构造了无穷维 Dirichlet 过程。这一构造在数学上优雅, 在应用中有效, 是 20 世纪贝叶斯统计最重要的进展之一。

10. 本章小结

本章我们学习了：

- (1) Dirichlet 过程是定义在概率分布空间上的随机过程，其样本路径几乎 surely 是离散分布；
- (2) DP 有三种等价的构造方式：stick-breaking 构造、Pólya urn 构造和中国餐厅过程 (CRP)；
- (3) 作为未知分布的先验，DP 的后验有简洁的闭式形式；
- (4) DP 混合模型 (DPM) 将 DP 先验与参数化成分分布结合，实现了无限混合的自然贝叶斯非参数建模；
- (5) 主要的计算方法包括 blocked Gibbs 采样和 CRP 采样；
- (6) DP 是有限 Dirichlet 分布在无限维的自然推广，由 Ferguson (1973) 开创。

11. 下节预告

下一章我们将转向更深入的贝叶斯计算方法，讨论如何在大规模问题中高效地进行贝叶斯推断。

APPENDIX A

公式推导

1. 概率与推断 (Chapter 1) 推导

1.1. 贝叶斯定理的推导. 背景 (Background): 贝叶斯定理是概率论中最基本的公式之一, 它描述了如何根据新的证据更新概率估计。这个推导基于条件概率的定义和基本运算规则。

参数定义 (Parameter Definitions):

- A : 某个事件
- B : 另一个事件 (通常代表观测数据或证据)
- $p(A)$: 事件 A 的先验概率 (prior probability)
- $p(A|B)$: 在事件 B 发生的条件下, 事件 A 的后验概率 (posterior probability)
- $p(B|A)$: 在事件 A 发生的条件下, 事件 B 的似然 (likelihood)
- $p(B)$: 事件 B 的边际概率 (marginal probability)

已知条件 (Given):

- 条件概率定义: $p(A|B) = \frac{p(A \cap B)}{p(B)}$, 其中 $p(B) > 0$
- 乘法法则: $p(A \cap B) = p(A) \cdot p(B|A) = p(B) \cdot p(A|B)$

目标 (Goal): 从条件概率的基本定义推导出贝叶斯定理:

$$p(A|B) = \frac{p(A) \cdot p(B|A)}{p(B)}$$

推导步骤 (Derivation Steps):

步骤 1: 从条件概率定义出发

$$p(A|B) = \frac{p(A \cap B)}{p(B)}$$

步骤 2: 用乘法法则替换联合概率 $p(A \cap B)$

$$p(A \cap B) = p(A) \cdot p(B|A)$$

步骤 3: 将步骤 2 代入步骤 1

$$p(A|B) = \frac{p(A) \cdot p(B|A)}{p(B)}$$

步骤 4: 对 $p(B)$ 进行边际化 (如果 $A_1, A_2, \dots, A_k$ 是互斥且完备的事件族)

$$p(B) = \sum_{i=1}^k p(A_i) \cdot p(B|A_i)$$

步骤 5: 将步骤 4 代入贝叶斯定理的分母，得到完整形式

$$p(A_j|B) = \frac{p(A_j) \cdot p(B|A_j)}{\sum_{i=1}^k p(A_i) \cdot p(B|A_i)}$$

结论: 贝叶斯定理建立了先验概率与后验概率之间的桥梁——我们通过似然 $p(B|A)$ 将新的观测 B 与先验知识 $p(A)$ 结合起来。

1.2. 先验预测分布与后验预测分布的推导. 背景 (Background): 在贝叶斯统计中, 我们不仅要推断当前参数 θ 的后验分布, 还需要预测未来观测 $\tilde{y}$ 的分布。这涉及对未知参数进行积分 (边际化)。

参数定义 (Parameter Definitions):

- θ : 不可观测的参数
- y : 已观测的数据
- $\tilde{y}$: 未来或未观测的数据
- $p(\theta)$: 参数的先验分布
- $p(y|\theta)$: 数据的似然函数
- $p(\theta|y)$: 参数的后验分布

已知条件 (Given):

- 贝叶斯定理: $p(\theta|y) \propto p(\theta) \cdot p(y|\theta)$
- 边际概率定义: $p(y) = \int p(\theta) \cdot p(y|\theta) d\theta$
- 条件独立性: 给定 θ , 未来观测 $\tilde{y}$ 与当前观测 y 条件独立

目标 (Goal):

- (1) 推导先验预测分布 $p(y)$
- (2) 推导后验预测分布 $p(\tilde{y}|y)$

推导步骤 (Derivation Steps):

先验预测分布的推导. **步骤 1:** 从边际概率的定义出发

$$p(y) = \int p(\theta) \cdot p(y|\theta) d\theta$$

步骤 2: 解释其含义——这是对所有可能的 θ 值加权平均, 其中权重是先验概率

步骤 3: 先验预测分布表示在我们观测数据之前, 所有可能观测结果的分布

后验预测分布的推导. **步骤 1:** 从条件概率定义出发

$$p(\tilde{y}|y) = \int p(\tilde{y}, \theta|y) d\theta$$

步骤 2: 将联合分布分解

$$p(\tilde{y}, \theta|y) = p(\tilde{y}|\theta, y) \cdot p(\theta|y)$$

步骤 3: 利用条件独立性假设 (给定 θ , $\tilde{y}$ 与 y 独立)

$$p(\tilde{y}|\theta, y) = p(\tilde{y}|\theta)$$

步骤 4: 代入得

$$p(\tilde{y}|y) = \int p(\tilde{y}|\theta) \cdot p(\theta|y) d\theta$$

结论: 后验预测分布是在**参数后验分布上对条件预测进行平均**。这体现了贝叶斯推断的核心思想: 不确定性在两个层次上都存在 (参数的不确定性和预测的随机性), 我们需要对两者都进行边际化。

1.3. 后验优势比的推导. 背景 (Background): 优势比 (odds ratio) 是概率的另一种表示方式, 在许多应用场景下比概率更直观。贝叶斯定理在优势比形式下有一个特别简洁的表达。

参数定义 (Parameter Definitions):

- θ_1 : 某个参数值
- θ_2 : 另一个参数值
- $p(\theta_1)$: θ_1 的先验概率
- $p(\theta_1|y)$: θ_1 的后验概率
- $p(y|\theta_1)$: 似然函数在 θ_1 处的值
- $O(\theta_1, \theta_2) = \frac{p(\theta_1)}{p(\theta_2)}$: 先验优势比
- $O(\theta_1, \theta_2|y) = \frac{p(\theta_1|y)}{p(\theta_2|y)}$: 后验优势比

已知条件 (Given): 贝叶斯定理:

$$p(\theta|y) = \frac{p(\theta) \cdot p(y|\theta)}{p(y)}$$

目标 (Goal): 证明后验优势比 = 先验优势比 $\times$ 似然比

推导步骤 (Derivation Steps):

步骤 1: 写出后验优势比的定义

$$O(\theta_1, \theta_2|y) = \frac{p(\theta_1|y)}{p(\theta_2|y)}$$

步骤 2: 对分子和分母分别应用贝叶斯定理

$$\begin{aligned} & \frac{p(\theta_1) \cdot p(y|\theta_1)}{p(y)} \\ &= \frac{\frac{p(\theta_1) \cdot p(y|\theta_1)}{p(y)}}{\frac{p(\theta_2) \cdot p(y|\theta_2)}{p(y)}} \end{aligned}$$

步骤 3: 约去 $p(y)$

$$= \frac{p(\theta_1) \cdot p(y|\theta_1)}{p(\theta_2) \cdot p(y|\theta_2)}$$

步骤 4: 重新组合

$$= \frac{p(\theta_1)}{p(\theta_2)} \times \frac{p(y|\theta_1)}{p(y|\theta_2)}$$

结论: 这个简洁的关系式告诉我们, **后验优势比 = 先验优势比 $\times$ 似然比**。数据通过似然比来更新优势比——如果 $p(y|\theta_1) > p(y|\theta_2)$, 则数据支持 θ_1 , 后验优势比增大。

2. 单参数模型 (Chapter 2) 推导

2.1. Beta-Binomial 共轭后验分布推导. 背景 (Background): 在二项模型中, 如果我们使用 Beta 先验分布来估计成功概率 θ , 则后验分布也是 Beta 分布。这种性质称为共轭性, 是贝叶斯统计中最重要的概念之一。

参数定义 (Parameter Definitions):

- n : 伯努利试验的总次数
- y : n 次试验中成功的次数
- θ : 每次试验的成功概率 (未知参数)
- α : Beta 先验的第一个参数
- β : Beta 先验的第二个参数
- $p(y|\theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y}$: 二项似然函数
- $p(\theta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}$: Beta 先验

已知条件 (Given):

- Beta 函数定义: $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
- 似然函数: $p(y|\theta) \propto \theta^y (1-\theta)^{n-y}$ (忽略不依赖 θ 的常数 $\binom{n}{y}$)
- 先验分布: $p(\theta) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1}$

目标 (Goal): 证明后验分布 $p(\theta|y)$ 也是 Beta 分布, 并确定其后验参数。

推导步骤 (Derivation Steps):

步骤 1: 应用贝叶斯定理写出非归一化后验分布

$$p(\theta|y) \propto p(\theta) \cdot p(y|\theta)$$

步骤 2: 代入先验和似然

$$p(\theta|y) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1} \cdot \theta^y (1-\theta)^{n-y}$$

步骤 3: 合并同底数指数

$$= \theta^{(\alpha-1)+y} \cdot (1-\theta)^{(\beta-1)+(n-y)} = \theta^{\alpha+y-1} \cdot (1-\theta)^{\beta+n-y-1}$$

步骤 4: 识别分布形式这正是 Beta 分布的核 (kernel), 即

$$p(\theta|y) \propto \theta^{\alpha_{\text{post}}-1} (1-\theta)^{\beta_{\text{post}}-1}$$

其中

$$\alpha_{\text{post}} = \alpha + y, \quad \beta_{\text{post}} = \beta + n - y$$

步骤 5: 写出完整的后验分布

$$\theta|y \sim \text{Beta}(\alpha + y, \beta + n - y)$$

结论: 后验分布与先验分布属于同一形式 (Beta 分布), 这就是共轭性。先验参数 α 可以解释为 $\alpha - 1$ 次“先验成功”, β 解释为 $\beta - 1$ 次“先验失败”。

2.2. Beta-Binomial 后验均值与方差推导. 背景 (Background): 在共轭框架下, 我们可以推导出后验分布的均值和方差的闭式表达式。这些表达式展示了先验信息与数据信息如何”折中”。

参数定义 (Parameter Definitions):

- $\alpha_{\text{post}} = \alpha + y$: 后验第一个参数
- $\beta_{\text{post}} = \beta + n - y$: 后验第二个参数
- $\mathbb{E}(\theta|y)$: 后验均值
- $\text{Var}(\theta|y)$: 后验方差

已知条件 (Given):

- 后验分布: $\theta|y \sim \text{Beta}(\alpha_{\text{post}}, \beta_{\text{post}})$
- Beta 分布均值公式: $\mathbb{E}(X) = \frac{\alpha}{\alpha + \beta}$, 其中 $X \sim \text{Beta}(\alpha, \beta)$
- Beta 分布方差公式: $\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$

目标 (Goal):

- (1) 求后验均值 $\mathbb{E}(\theta|y)$
- (2) 求后验方差 $\text{Var}(\theta|y)$

后验均值推导. **步骤 1**: 应用 Beta 分布均值公式

$$\mathbb{E}(\theta|y) = \frac{\alpha_{\text{post}}}{\alpha_{\text{post}} + \beta_{\text{post}}}$$

步骤 2: 代入后验参数

$$= \frac{\alpha + y}{\alpha + y + \beta + n - y} = \frac{\alpha + y}{\alpha + \beta + n}$$

步骤 3: 改写为加权平均形式

$$= \frac{\alpha + y}{\alpha + \beta + n} = \frac{\alpha + \beta}{\alpha + \beta + n} \cdot \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \cdot \frac{y}{n}$$

结论 1: 后验均值是先验均值 $\frac{\alpha}{\alpha + \beta}$ 和样本比例 $\frac{y}{n}$ 的加权平均, 权重与样本量和先验强度相关。

后验方差推导. **步骤 1:** 应用 Beta 分布方差公式

$$\text{Var}(\theta|y) = \frac{\alpha_{\text{post}} \cdot \beta_{\text{post}}}{(\alpha_{\text{post}} + \beta_{\text{post}})^2 (\alpha_{\text{post}} + \beta_{\text{post}} + 1)}$$

步骤 2: 代入后验参数

$$= \frac{(\alpha + y)(\beta + n - y)}{(\alpha + \beta + n)^2 (\alpha + \beta + n + 1)}$$

步骤 3: 大样本近似 (当 y 和 $n - y$ 较大时) 当 n 很大而 α, β 固定时,

$$\text{Var}(\theta|y) \approx \frac{1}{n} \cdot \frac{y}{n} \left(1 - \frac{y}{n}\right)$$

结论 2: 后验方差以 $1/n$ 的速率趋近于零, 表明随着样本量增大, 后验分布越来越集中在真值附近。

2.3. 拉普拉斯继承法则推导. 背景 (Background): 拉普拉斯在 18 世纪研究”明天太阳会升起”这类问题时, 提出了一个著名的法则。在均匀先验下, 这个法则预测未来成功的概率为 $\frac{y+1}{n+2}$ 。

参数定义 (Parameter Definitions):

- n : 已完成的试验次数
- y : 成功的次数
- $\tilde{y}$: 下一次试验的结果 ($\tilde{y} = 1$ 表示成功)
- θ : 成功概率
- $p(\theta|y) = \text{Beta}(y+1, n-y+1)$: 均匀先验下的后验分布

已知条件 (Given):

- 均匀先验: $\theta \sim \text{Uniform}(0, 1) = \text{Beta}(1, 1)$
- 后验分布: $\theta|y \sim \text{Beta}(y+1, n-y+1)$
- 后验预测分布: $p(\tilde{y} = 1|y) = \int_0^1 \theta \cdot p(\theta|y) d\theta$

目标 (Goal): 求下一次试验成功的概率 $p(\tilde{y} = 1|y)$ 。

推导步骤 (Derivation Steps):

步骤 1: 写出后验预测分布的定义

$$p(\tilde{y} = 1|y) = \int_0^1 p(\tilde{y} = 1|\theta) \cdot p(\theta|y) d\theta$$

步骤 2: 代入 $p(\tilde{y} = 1|\theta) = \theta$ (给定 θ , 成功的条件概率就是 θ)

$$= \int_0^1 \theta \cdot p(\theta|y) d\theta = \mathbb{E}(\theta|y)$$

步骤 3: 识别这是后验均值

$$= \mathbb{E}(\theta|y)$$

步骤 4: 应用 Beta 分布均值公式

$$= \frac{y+1}{(y+1) + (n-y+1)} = \frac{y+1}{n+2}$$

结论: 拉普拉斯继承法则表明, 在均匀先验下, 已知 n 次试验中 y 次成功, 下一次成功的概率是 $\frac{y+1}{n+2}$ 。这推广了”瑞士表匠”问题的直觉——即使观测到 n 次成功, 概率也不是 1 (因为 θ 本身可能是变化的)。

2.4. 总期望与总方差公式推导. 背景 (Background): 全期望公式和全方差公式是概率论中的两个基本恒等式, 它们描述了如何通过条件分布来计算无条件矩。

参数定义 (Parameter Definitions):

- θ : 随机变量 (参数)
- y : 随机变量 (数据)
- $\mathbb{E}(\theta)$: θ 的无条件 (先验) 均值
- $\text{Var}(\theta)$: θ 的无条件 (先验) 方差
- $\mathbb{E}(\theta|y)$: 给定 y 后 θ 的条件均值
- $\text{Var}(\theta|y)$: 给定 y 后 θ 的条件方差

已知条件 (Given):

- 条件期望定义: $\mathbb{E}(\theta|y)$ 是 y 的函数
- 迭代期望法则: $\mathbb{E}[\mathbb{E}(\theta|y)] = \mathbb{E}(\theta)$

目标 (Goal):

- (1) 证明全期望公式: $\mathbb{E}(\theta) = \mathbb{E}[\mathbb{E}(\theta|y)]$
- (2) 证明全方差公式: $\text{Var}(\theta) = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$

全期望公式推导. **步骤 1**: 从条件期望的定义出发

$$\mathbb{E}[\mathbb{E}(\theta|y)] = \int \mathbb{E}(\theta|y) \cdot p(y) dy$$

步骤 2: 代入条件期望 $\mathbb{E}(\theta|y) = \int \theta \cdot p(\theta|y) d\theta$

$$= \int \left(\int \theta \cdot p(\theta|y) d\theta \right) p(y) dy$$

步骤 3: 交换积分次序 (由富比尼定理保证)

$$= \int \theta \left(\int p(\theta|y)p(y) dy \right) d\theta$$

步骤 4: 识别内层积分 $p(\theta) = \int p(\theta|y)p(y)dy$ (全概率)

$$= \int \theta \cdot p(\theta) d\theta = \mathbb{E}(\theta)$$

结论 1: 全期望公式表明, θ 的先验均值等于在所有可能数据上后验均值的加权平均。

全方差公式推导. **步骤 1:** 从方差定义出发

$$\text{Var}(\theta) = \mathbb{E}(\theta^2) - [\mathbb{E}(\theta)]^2$$

步骤 2: 对 $\mathbb{E}(\theta^2)$ 应用全期望公式

$$\mathbb{E}(\theta^2) = \mathbb{E}[\mathbb{E}(\theta^2|y)]$$

步骤 3: 在给定 y 的条件下, 方差可以写为

$$\text{Var}(\theta|y) = \mathbb{E}(\theta^2|y) - [\mathbb{E}(\theta|y)]^2$$

步骤 4: 解出 $\mathbb{E}(\theta^2|y)$

$$\mathbb{E}(\theta^2|y) = \text{Var}(\theta|y) + [\mathbb{E}(\theta|y)]^2$$

步骤 5: 代入步骤 2

$$\mathbb{E}(\theta^2) = \mathbb{E}[\text{Var}(\theta|y)] + \mathbb{E}[\mathbb{E}(\theta|y)]^2$$

步骤 6: 对 $[\mathbb{E}(\theta|y)]^2$ 应用方差分解

$$\mathbb{E}[\mathbb{E}(\theta|y)]^2 = \text{Var}[\mathbb{E}(\theta|y)] + \{\mathbb{E}[\mathbb{E}(\theta|y)]\}^2$$

步骤 7: 代入全期望公式的结果 $\mathbb{E}[\mathbb{E}(\theta|y)] = \mathbb{E}(\theta)$

$$= \text{Var}[\mathbb{E}(\theta|y)] + [\mathbb{E}(\theta)]^2$$

步骤 8: 代回方差的定义

$$\text{Var}(\theta) = \mathbb{E}(\theta^2) - [\mathbb{E}(\theta)]^2 = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$$

结论 2: 全方差公式表明, **总方差 = 条件方差的均值 + 条件均值的方差**。这在贝叶斯语境下的解释是: 参数的总不确定性来自两个方面——(1) 给定数据后参数仍有的剩余不确定性 (条件方差的均值), 以及 (2) 后验均值随数据变化的不确定性 (条件均值的方差)。

2.5. 正态均值估计的后验分布推导. 背景 (Background): 当我们用正态似然估计正态均值时, 如果使用正态先验, 则后验分布也是正态分布。这个推导展示了共轭先验在正态模型中的应用。

参数定义 (Parameter Definitions):

- $y \sim \text{Normal}(\theta, \sigma^2)$: 观测数据 (已知方差 σ^2)
- $\theta \sim \text{Normal}(\mu_0, \tau_0^2)$: 正态先验
- μ_0 : 先验均值
- τ_0^2 : 先验方差
- σ^2 : 已知的观测方差
- μ_1, τ_1^2 : 后验均值和方差

已知条件 (Given):

- 似然函数: $p(y|\theta) \propto \exp\left(-\frac{(y-\theta)^2}{2\sigma^2}\right)$
- 先验密度: $p(\theta) \propto \exp\left(-\frac{(\theta-\mu_0)^2}{2\tau_0^2}\right)$
- 配方法 (completing the square) 技巧

目标 (Goal): 证明后验分布 $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$, 并求出 μ_1 和 τ_1^2 。

推导步骤 (Derivation Steps):

步骤 1: 写出非归一化后验分布的对数

$$\log p(\theta|y) \propto \log p(\theta) + \log p(y|\theta)$$

步骤 2: 代入先验和似然的对数

$$= -\frac{(\theta - \mu_0)^2}{2\tau_0^2} - \frac{(y - \theta)^2}{2\sigma^2}$$

步骤 3: 展开平方项

$$= -\frac{1}{2} \left[\frac{(\theta^2 - 2\mu_0\theta + \mu_0^2)}{\tau_0^2} + \frac{(\theta^2 - 2y\theta + y^2)}{\sigma^2} \right]$$

步骤 4: 合并 θ^2 项的系数

$$= -\frac{1}{2} \left[\theta^2 \left(\frac{1}{\tau_0^2} + \frac{1}{\sigma^2} \right) - 2\theta \left(\frac{\mu_0}{\tau_0^2} + \frac{y}{\sigma^2} \right) + \text{常数} \right]$$

步骤 5: 识别后验精度 (方差的倒数)

$$\frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

步骤 6: 由配方法, 后验均值满足

$$\theta \cdot \frac{1}{\tau_1^2} = \frac{\mu_0}{\tau_0^2} + \frac{y}{\sigma^2}$$

步骤 7: 解出后验均值

$$\mu_1 = \frac{\mu_0/\tau_0^2 + y/\sigma^2}{1/\tau_0^2 + 1/\sigma^2}$$

步骤 8: 写出完整的后验分布

$$\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$$

结论:

- (1) **精度加法**: 后验精度 = 先验精度 + 数据精度
- (2) **后验均值**: 是先验均值 μ_0 和观测值 y 的加权平均, 权重与精度成正比

2.6. Jeffreys 先验与 Fisher 信息推导. 背景 (Background): Jeffreys 提出了一种构建非信息先验的系统方法, 基于 Fisher 信息的不变性原则。这个先验在参数的单调变换下保持不变。

参数定义 (Parameter Definitions):

- θ : 参数
- $p(y|\theta)$: 似然函数
- $J(\theta)$: Fisher 信息
- $L(\theta) = \log p(y|\theta)$: 对数似然
- $I(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \right]$: Fisher 信息 (另一种定义)
- $\phi = h(\theta)$: 参数的单调变换

已知条件 (Given):

- Jeffreys 原则: 先验应在参数的单调变换下保持不变
- Fisher 信息定义: $J(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \right]$
- 变换公式: $p(\phi) = p(\theta) \cdot \left| \frac{d\theta}{d\phi} \right|$

目标 (Goal): 推导 Jeffreys 先验公式并验证其在变换下的不变性。

推导步骤 (Derivation Steps):

Jeffreys 先验公式推导. 步骤 1: Jeffreys 提出先验正比于 Fisher 信息的平方根

$$p(\theta) \propto [J(\theta)]^{1/2}$$

步骤 2: 验证在变换 $\phi = h(\theta)$ 下的不变性

在新参数 ϕ 下, Fisher 信息为

$$J(\phi) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\phi)}{\partial \phi^2} \right]$$

步骤 3: 利用链式法则

$$\frac{\partial \log p(y|\theta)}{\partial \phi} = \frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d\theta}{d\phi}$$

步骤 4: 计算二阶导数

$$\frac{\partial^2 \log p(y|\theta)}{\partial \phi^2} = \frac{\partial}{\partial \phi} \left(\frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d\theta}{d\phi} \right) = \frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \left(\frac{d\theta}{d\phi} \right)^2 + \frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d^2 \theta}{d\phi^2}$$

步骤 5: 取期望, 利用 $\mathbb{E} \left[\frac{\partial \log p(y|\theta)}{\partial \theta} \right] = 0$ (得分函数的期望为零)

$$J(\phi) = \left(\frac{d\theta}{d\phi} \right)^2 J(\theta)$$

步骤 6: 因此

$$[J(\phi)]^{1/2} = \left| \frac{d\theta}{d\phi} \right| [J(\theta)]^{1/2}$$

步骤 7: 新先验为

$$p(\phi) \propto [J(\phi)]^{1/2} \propto [J(\theta)]^{1/2} \left| \frac{d\theta}{d\phi} \right|$$

结论: 这正是概率密度在变量变换下的标准变换公式, 因此 Jeffreys 先验在单调变换下是不变的。

二项模型的 *Jeffreys* 先验推导. **步骤 1:** 写出二项模型的对数似然

$$\log p(y|\theta) = \log \binom{n}{y} + y \log \theta + (n - y) \log(1 - \theta)$$

步骤 2: 计算一阶导数 (得分函数)

$$\frac{\partial}{\partial \theta} \log p(y|\theta) = \frac{y}{\theta} - \frac{n - y}{1 - \theta}$$

步骤 3: 计算二阶导数

$$\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) = -\frac{y}{\theta^2} - \frac{n - y}{(1 - \theta)^2}$$

步骤 4: 取负期望 (注意 $\mathbb{E}(Y) = n\theta$)

$$J(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) \right] = \frac{n\theta}{\theta^2} + \frac{n(1 - \theta)}{(1 - \theta)^2} = \frac{n}{\theta(1 - \theta)}$$

步骤 5: 应用 *Jeffreys* 公式

$$p(\theta) \propto \left[\frac{n}{\theta(1 - \theta)} \right]^{1/2} \propto \theta^{-1/2} (1 - \theta)^{-1/2}$$

步骤 6: 识别为 Beta 分布

$$p(\theta) \propto \theta^{(1/2)-1} (1 - \theta)^{(1/2)-1} \Rightarrow \theta \sim \text{Beta} \left(\frac{1}{2}, \frac{1}{2} \right)$$

结论: 二项模型的 *Jeffreys* 先验是 $\text{Beta}(1/2, 1/2)$, 这是一个弱信息先验, 比均匀先验 $\text{Beta}(1, 1)$ 在边界处更轻。

2.7. 后验预测分布的均值与方差推导. 背景 (Background): 后验预测分布 $\tilde{y}|y$ 的均值和方差有两个组成部分——一个来自模型本身的随机性, 另一个来自参数的后验不确定性。

参数定义 (Parameter Definitions):

- $\tilde{y}$: 未来观测
- y : 当前观测
- θ : 参数
- $\mathbb{E}(\tilde{y}|y)$: 后验预测均值
- $\text{Var}(\tilde{y}|y)$: 后验预测方差

已知条件 (Given):

- $\tilde{y}|\theta \sim \text{Normal}(\theta, \sigma^2)$
- $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$
- 全期望公式: $\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$
- 全方差公式: $\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$

目标 (Goal): 求后验预测分布 $\tilde{y}|y$ 的均值和方差。

后验预测均值推导. **步骤 1**: 应用全期望公式

$$\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 给定 θ , $\tilde{y}$ 与 y 条件独立, 且 $\mathbb{E}(\tilde{y}|\theta) = \theta$

$$= \mathbb{E}(\theta|y) = \mu_1$$

结论 1: 后验预测均值等于参数的后验均值。

后验预测方差推导. **步骤 1**: 应用全方差公式

$$\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 第一项——给定 θ 下的方差是 σ^2 (模型方差)

$$\mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] = \mathbb{E}(\sigma^2|y) = \sigma^2$$

步骤 3: 第二项——条件均值的方差

$$\text{Var}[\mathbb{E}(\tilde{y}|\theta, y)] = \text{Var}(\theta|y) = \tau_1^2$$

步骤 4: 合并

$$\text{Var}(\tilde{y}|y) = \sigma^2 + \tau_1^2$$

结论 2: 后验预测方差 = **模型方差** + **参数后验方差**。这体现了贝叶斯推断的核心: 预测的不确定性来自两个方面——(1) 模型本身的随机性 (σ^2), 以及 (2) 参数估计的不确定性 (τ_1^2)。

3. 拒绝抽样的正确性证明

背景 (Background): 拒绝抽样通过随机接受机制从目标分布中抽取样本。我们需要证明被接受的样本确实服从目标分布 $p(\theta)$ 。

参数定义 (Parameter Definitions):

- $p(\theta)$: 目标 (未归一化) 分布
- $g(\theta)$: 提议分布
- M : 覆盖常数, 满足 $p(\theta) \leq M \cdot g(\theta)$
- θ^* : 候选样本
- u^* : 从 $\text{Uniform}(0, 1)$ 抽取的随机数

目标 (Goal): 证明被接受的样本 θ_{accept} 服从目标分布 $p(\theta)$ 。

推导步骤 (Derivation Steps):

步骤 1: 写出接受的联合概率

$$\text{接受联合概率 } \mathbb{P}(\text{接受} \cap \theta^* \in d\theta) = \mathbb{P}(\theta^* \in d\theta) \cdot \mathbb{P}(\text{接受}|\theta^*) = g(\theta^*)d\theta \cdot \frac{p(\theta^*)}{Mg(\theta^*)} = \frac{p(\theta^*)}{M}d\theta$$

步骤 2: 计算总接受概率 (归一化常数)

$$\text{总接受概率 } \mathbb{P}(\text{接受}) = \int \frac{p(\theta^*)}{M}d\theta = \frac{1}{M}$$

步骤 3: 计算接受样本的条件分布

$$\text{条件分布} = \text{目标分布 } \mathbb{P}(\theta_{\text{accept}} \in d\theta | \text{接受}) = \frac{\mathbb{P}(\text{接受} \cap \theta^* \in d\theta)}{\mathbb{P}(\text{接受})} = \frac{p(\theta^*)/M}{1/M}d\theta = p(\theta^*)d\theta$$

结论: 被接受的样本的条件分布正是目标分布 $p(\theta)$ 。证明完毕。

3.1. 拒绝抽样期望接受率推导. 背景 (Background): 拒绝抽样的期望接受率是衡量算法效率的关键指标。

目标 (Goal): 推导期望接受率的公式。

推导步骤 (Derivation Steps):

步骤 1: 期望接受率定义为

期望定义
$$\text{accept rate} = \int \mathbb{P}(\text{接受}|\theta) \cdot g(\theta) d\theta$$

步骤 2: 代入接受概率

接受概率
$$\mathbb{P}(\text{接受}|\theta) = \min\left(1, \frac{p(\theta)}{Mg(\theta)}\right)$$

步骤 3: 于是

积分结果
$$\text{accept rate} = \int \min\left(\frac{p(\theta)}{Mg(\theta)}, 1\right) \cdot g(\theta) d\theta = \frac{1}{M} \int \min(p(\theta), Mg(\theta)) d\theta$$

步骤 4: 当覆盖条件 $Mg(\theta) \geq p(\theta)$ 对所有 θ 成立时

简化为 $1/M$
$$\text{accept rate} = \frac{1}{M} \int p(\theta) d\theta = \frac{1}{M}$$

结论: 期望接受率与 M 成反比, 选择尽可能小的 M 可提高接受率。

3.2. 细致平衡条件推导. 背景 (Background): 细致平衡是构造满足特定平稳分布的马尔可夫链的关键条件。

目标 (Goal): 证明如果转移核 P 满足细致平衡, 则其平稳分布就是 π 。

推导步骤 (Derivation Steps):

步骤 1: 写出细致平衡条件

细致平衡 $P(\theta'|\theta) \cdot \pi(\theta) = P(\theta|\theta') \cdot \pi(\theta')$

步骤 2: 验证 π 是平稳分布

平稳分布验证

$$\int P(\theta'|\theta) \cdot \pi(\theta) d\theta = \int P(\theta|\theta') \cdot \pi(\theta') d\theta = \pi(\theta') \int P(\theta|\theta') d\theta = \pi(\theta') \cdot 1 = \pi(\theta')$$

其中第三步用到 $\int P(\theta|\theta') d\theta = 1$ (转移核的归一化性)。

结论: 细致平衡是平稳分布的充分条件, 但不是必要条件。

3.3. Metropolis 算法细致平衡证明. 背景 (Background): Metropolis 算法的提议分布是对称的, 我们需要证明其满足细致平衡。

目标 (Goal): 证明 Metropolis 算法的转移核以目标分布 $p(\theta)$ 为平稳分布。

推导步骤 (Derivation Steps):

步骤 1: Metropolis 转移核

$$P(\theta'|\theta) = q(\theta'|\theta) \cdot \min\left(1, \frac{p(\theta')}{p(\theta)}\right)$$

其中 $q(\theta'|\theta) = q(\theta|\theta')$ (对称提议分布)。

步骤 2: 验证细致平衡

$$P(\theta'|\theta) \cdot p(\theta) = q(\theta'|\theta) \cdot \min\left(1, \frac{p(\theta')}{p(\theta)}\right) \cdot p(\theta)$$

分两种情况讨论:

情况 1: $p(\theta') \geq p(\theta)$

$$\text{右边} = q(\theta'|\theta) \cdot 1 \cdot p(\theta) = q(\theta'|\theta) \cdot p(\theta')$$

情况 2: $p(\theta') < p(\theta)$

$$\text{右边} = q(\theta'|\theta) \cdot \frac{p(\theta')}{p(\theta)} \cdot p(\theta) = q(\theta'|\theta) \cdot p(\theta')$$

由于 $q(\theta'|\theta) = q(\theta|\theta')$, 两种情况都满足

细致平衡成立

$$P(\theta'|\theta) \cdot p(\theta) = P(\theta|\theta') \cdot p(\theta')$$

结论: Metropolis 算法的平稳分布正是目标分布 $p(\theta)$ 。证明完毕。

3.4. Gibbs 抽样接受率推导. 背景 (Background): Gibbs 抽样是 Metropolis-Hastings 的特例, 其接受率恒为 1。我们来推导这个结论。

参数定义 (Parameter Definitions):

- $\theta = (\theta_1, \dots, \theta_d)$: 完整参数向量
- $\theta_{-j} = (\theta_1, \dots, \theta_{j-1}, \theta_{j+1}, \dots, \theta_d)$: 除 θ_j 外的所有参数
- $p^*(\theta)$: 未归一化的目标分布
- $q(\theta'_j|\theta_{-j}) = p(\theta'_j|\theta_{-j}, y)$: 提议分布 (条件分布)

目标 (Goal): 证明 Gibbs 抽样的接受率为 1。

推导步骤 (Derivation Steps):

步骤 1: 写出 MH 接受比

$$\text{MH 接受比} \quad r = \frac{p^*(\theta'_j, \theta_{-j})}{p^*(\theta_j, \theta_{-j})} \cdot \frac{q(\theta_j|\theta_{-j})}{q(\theta'_j|\theta_{-j})}$$

步骤 2: 代入 Gibbs 的提议分布

$$q(\theta_j|\theta_{-j}) = p(\theta_j|\theta_{-j}, y)$$

提议分布 = 条件分布

$$q(\theta'_j|\theta_{-j}) = p(\theta'_j|\theta_{-j}, y)$$

步骤 3: 利用链式法则分解联合分布

$$p^*(\theta'_j, \theta_{-j}) = p^*(\theta_{-j}) \cdot p^*(\theta'_j|\theta_{-j})$$

链式法则

$$p^*(\theta_j, \theta_{-j}) = p^*(\theta_{-j}) \cdot p^*(\theta_j|\theta_{-j})$$

步骤 4: 代入接受比

$$\text{代入} \quad r = \frac{p^*(\theta_{-j}) \cdot p^*(\theta'_j|\theta_{-j})}{p^*(\theta_{-j}) \cdot p^*(\theta_j|\theta_{-j})} \cdot \frac{p(\theta_j|\theta_{-j}, y)}{p(\theta'_j|\theta_{-j}, y)} = \frac{p^*(\theta'_j|\theta_{-j})}{p^*(\theta_j|\theta_{-j})} \cdot \frac{p(\theta_j|\theta_{-j}, y)}{p(\theta'_j|\theta_{-j}, y)}$$

步骤 5: 注意 $p^*(\theta_j|\theta_{-j}, y) \propto p(\theta_j|\theta_{-j}, y)$, 因为 $p^*(\theta_{-j})$ 不依赖于 θ_j 。于是两个因子互为倒数,

接受率为 1

$$r = 1$$

结论: Gibbs 抽样的提议分布恰好是条件分布, 因此接受率恒为 1, 无需拒绝。

3.5. 分层模型条件分布推导. 背景 (Background): 在分层模型 eq. (27) 中, 我们需要推导各个参数的条件后验分布。

模型回顾:

$$y_j|\theta_j \sim N(\theta_j, \sigma^2), \quad \theta_j|\mu, \tau \sim N(\mu, \tau^2)$$

其中 σ^2 已知。

目标 (Goal): 推导 $p(\theta_j|\mu, \tau, y)$ 、 $p(\mu|\theta, \tau, y)$ 和 $p(\tau|\theta, \mu, y)$ 。

$p(\theta_j|\mu, \tau, y)$ 推导. **步骤 1:** 写出条件分布的核

核
$$p(\theta_j|\mu, \tau, y) \propto p(y_j|\theta_j) \cdot p(\theta_j|\mu, \tau) \propto \exp\left(-\frac{(y_j - \theta_j)^2}{2\sigma^2}\right) \cdot \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 2: 合并指数

合并
$$= \exp\left(-\frac{(y_j - \theta_j)^2}{2\sigma^2} - \frac{(\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 3: 配方得到正态分布形式

配方
$$= \exp\left(-\frac{1}{2} \left[\frac{1}{\sigma^2} + \frac{1}{\tau^2}\right] \left(\theta_j - \frac{y_j/\sigma^2 + \mu/\tau^2}{1/\sigma^2 + 1/\tau^2}\right)^2\right)$$

因此

条件后验
$$\theta_j|\mu, \tau, y \sim N\left(\frac{y_j/\sigma^2 + \mu/\tau^2}{1/\sigma^2 + 1/\tau^2}, \left(\frac{1}{\sigma^2} + \frac{1}{\tau^2}\right)^{-1}\right)$$

$p(\mu|\theta, \tau, y)$ 推导. **步骤 1:** μ 的条件分布 (似然部分只依赖于 θ_j , 与 μ 通过 $\theta_j|\mu, \tau$ 连接)

先验部分
$$p(\mu|\theta, \tau) \propto p(\theta|\mu, \tau) = \prod_{j=1}^J \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right) \propto \exp\left(-\frac{\sum_j (\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 2: 展开平方

平方展开
$$\sum_j (\theta_j - \mu)^2 = \sum_j (\theta_j - \bar{\theta} + \bar{\theta} - \mu)^2 = \sum_j (\theta_j - \bar{\theta})^2 + J(\bar{\theta} - \mu)^2$$

步骤 3: 识别为正态核

正态核
$$p(\mu|\theta, \tau) \propto \exp\left(-\frac{J(\bar{\theta} - \mu)^2}{2\tau^2}\right)$$

因此

条件后验
$$\mu|\theta, \tau \sim N\left(\bar{\theta}, \frac{\tau^2}{J}\right)$$

其中 $\bar{\theta} = \frac{1}{J} \sum_j \theta_j$ 。

$p(\tau|\theta, \mu, y)$ 的非标准形式. **说明:**

非标准形式
$$p(\tau|\theta, \mu, y) \propto p(\theta|\mu, \tau) \cdot p(\tau) = \prod_{j=1}^J \frac{1}{\tau} \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right) \cdot p(\tau)$$

这个分布不是标准形式 (不是常见的正态、Gamma 等分布), 因此需要使用 Metropolis-Hastings 步骤来抽样。

结论: 在 Gibbs 抽样框架下, 对 τ 需要使用 MH 步骤, 这正是”混合 MCMC”的典型例子。

4. 阅读过程中的问题与解答

5. 什么是分布的核

5.1. 问题. 分布的核是什么概念?

5.2. 回答. 分布的**核 (kernel)** 是指概率密度/质量函数中**依赖于参数的核心部分**, 不包括归一化常数。

举例说明:

Beta-Binomial 共轭中, 后验分布:

$$p(\theta|y) \propto \theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$$

其中 $\theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$ 是**核**, 而完整的 Beta 分布还需要归一化常数:

$$p(\theta|y) = \frac{\Gamma(\alpha + \beta + n)}{\Gamma(\alpha + y)\Gamma(\beta + n - y)} \theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$$

为什么核重要:

- (1) **识别分布形式:** 知道核是 $\theta^a(1-\theta)^b$ 形式, 就能识别这是 Beta 分布
- (2) **贝叶斯推断中省略 $p(y)$:** $p(y)$ 是归一化常数, 不包含关于 θ 的信息, 所以可以省略
- (3) **简化推导:** 在推导过程中只关注核, 省去繁琐的归一化常数

Insight 这本质上是**信息局部性**思想: 归一化常数的作用只是”让面积等于 1”, 它本身不携带关于参数的信息。真正”有意义”的概率质量都集中在核上。

6. 学习笔记

在这里记录你的学习心得和思考。