

贝叶斯数据分析讲义

Gelman, Carlin, Stern, Dunson, Vehtari, Rubin

Contents

引言：文献概述	5
引言：文献概述	5
1. 什么是贝叶斯数据分析	5
2. 核心概念	5
3. 文献目录	6
4. 课程结构	6
5. 学习方法	7
Part 1. 贝叶斯推断基础	9
Chapter 1. 概率与推断	11
1. 贝叶斯数据分析的三步骤	11
2. 统计推断的一般符号	11
3. 贝叶斯推断	11
4. 似然与优势比	13
5. 概率作为不确定性的度量	13
6. 主观性与客观性	14
7. 概率赋值的例子：足球点差	14
8. 概率论的一些有用结果	14
9. 本章小结	14
10. 下节预告	14
Chapter 2. 单参数模型	15
1. 从二项数据估计概率	15
2. 后验作为数据与先验信息的折中	16
3. 后验推断的汇总	16
4. 信息先验分布	16
5. 正态均值的估计（已知方差）	17
6. 非信息先验分布	18
7. Jeffreys 不变性原则	18
8. 弱信息先验分布	19
9. 其他标准单参数模型	19
10. 本章小结	19
11. 下节预告	19
Chapter 3. 多参数模型简介	21
1. 对 Nuisance 参数的积分	21
2. 正态数据与非信息先验	21
3. 正态数据与共轭先验	23

4. 分类数据的多项模型	23
5. 已知方差的多元正态模型	24
6. 均值和方差都未知的多元正态模型	24
7. 基本建模与计算总结	24
8. 本章小结	25
9. 下节预告	25
Chapter 4. 渐近性与非贝叶斯方法的联系	27
1. 本章导论	27
2. 后验分布的正态近似	27
3. 大样本理论	28
4. 定理的反例	29
5. 贝叶斯推断的频率评估	30
6. 其他统计方法的贝叶斯解释	30
7. 本章小结	31
8. 下节预告	31
Chapter 5. 分层模型	33
1. 本章导论	33
2. 可交换性与分层模型的建立	33
3. 共轭分层模型的完全贝叶斯分析	34
4. 正态模型中可交换参数的估计	35
5. 示例：八所学校的平行实验	36
6. 分层建模在 meta 分析中的应用	36
7. 分层方差参数的弱信息先验	37
8. 本章小结	37
9. 下节预告	37
10. 习题	38
Part 2. 贝叶斯数据分析基础	39
Chapter 6. 模型检查	41
1. 本章导论	41
2. 后验预测检查的思想	41
3. 验证统计量与模型检查量	42
4. 模型检查的实践方法	42
5. 过度离散与计数数据的模型检查	43
6. 外部数据验证	43
7. 模型检查与其他推断的关系	44
8. 模型检查的局限性	44
9. 从频率派角度理解后验预测检查	44
10. 本章小结	44
11. 下节预告	45
Chapter 7. 模型评估、比较与扩展	47
1. 本章导论	47
2. 预测准确性的度量	47
3. 交叉验证	48

4. WAIC: 广泛适用信息准则	49
5. 后验预测检验	49
6. 分层数据与交叉验证	50
7. 贝叶斯模型平均	50
8. 信息准则的统一视角	51
9. Stan 实现	51
10. 本章小结	52
11. 下节预告	52
12. 习题	52
Chapter 8. 考虑数据收集过程的建模	55
1. 本章导论	55
2. 观测数据与缺失数据的普遍范式	55
3. 数据收集模型与可忽略性	55
4. 抽样调查	57
5. 设计实验	58
6. 敏感性与随机化的作用	58
7. 观测研究	59
8. 删失与截断	59
9. 本章小结	60
10. 下节预告	60
Chapter 9. 决策分析	61
1. 本章导论	61
2. 效用函数与损失函数	61
3. 常见损失函数与最优估计	62
4. 预验分析: 决定收集什么数据	63
5. 层次决策问题与经验贝叶斯	64
6. 损失函数视角下的模型选择	64
7. 本章小结	65
8. 习题	65
9. 附录: 公式推导	66
Part 3. 高级计算方法	69
Chapter 10. 贝叶斯计算入门	71
1. 本章导论	71
2. 计算挑战的来源	71
3. 数值积分方法	71
4. 蒙特卡洛积分	72
5. 渐近近似方法	74
6. 变分推断初步	75
7. 方法选择指南	76
8. 本章小结	76
9. 下节预告	76
Chapter 11. 马尔可夫链模拟基础	77
1. 本章导论	77

2. 重要性抽样	77
3. 拒绝抽样	78
4. 重要性重抽样 (SIR)	78
5. 马尔可夫链基础	79
6. Metropolis 算法	79
7. Metropolis-Hastings 算法	80
8. Gibbs 抽样	80
9. 从后验分布抽样的实践	81
10. 示例: 从分层模型抽样	82
11. 本章小结	82
Chapter 12. 高效马尔可夫链模拟	83
1. 本章导论	83
2. 高效 Gibbs 采样器	83
3. 高效 Metropolis 跳跃规则	83
4. 切片采样	84
5. 可逆跳转采样	84
6. 模拟回火与并行回火	84
7. 哈密顿蒙特卡洛	84
8. Stan: 计算环境的开发	85
9. 本章小结	85
10. 下节预告	86
Chapter 13. 模态与分布近似	87
1. 本章导论	87
2. 主要内容	87
3. 本章小结	87
Part 4. 回归模型	89
Chapter 14. 回归模型入门	91
1. 从多参数模型到回归: 一个自然的延伸	91
2. 正规线性回归模型	91
3. 共轭正态线性回归	92
4. 非信息先验分布	92
5. 多预测变量情形	93
6. 逻辑回归	94
7. 稳健回归	94
8. 本章小结	95
9. 习题	95
Chapter 15. 分层线性模型	97
1. 本章导论	97
2. 从分组数据到分层模型	97
3. 分层线性模型的矩阵形式	97
4. 后验推断	98
5. 预测	99
6. 方差分量估计	99

7. 相关作业干预示例	100
8. 稳健推断	100
9. 本章小结	101
10. 下节预告	101
Chapter 16. 广义线性模型	103
1. 本章导论	103
2. 主要内容	103
3. 本章小结	103
Chapter 17. 稳健推断模型	105
1. 本章导论	105
2. 稳健性的各个方面	105
3. 标准概率模型的过度分散版本	105
4. 后验推断与计算	105
5. 八校例子中的稳健推断与敏感性分析	105
6. 使用 t 分布误差的稳健回归	105
7. 本章小结	105
Chapter 18. 缺失数据模型	107
1. 本章导论	107
2. 缺失数据机制	107
3. 贝叶斯推断中的可忽略性	108
4. 联合建模方法	108
5. 全贝叶斯方法与多重插补	109
6. 敏感度分析	109
7. 缺失数据的实际处理策略	110
8. 本章小结	111
9. 下节预告	111
Part 5. 非参数模型	113
Chapter 19. 参数非线性模型	115
1. 本章导论	115
2. 非线性模型的实例	115
3. 非线性最小二乘估计	116
4. 非线性模型的贝叶斯推断	117
5. 逻辑斯谛回归作为非线性模型	118
6. 非线性模型的选择与比较	119
7. 非线性模型的诊断	119
8. 本章小结	119
9. 下节预告	120
Chapter 20. 基函数模型	121
1. 本章导论	121
2. 样条函数模型	121
3. Sobolev 空间与函数空间视角	123
4. 小波方法	124
5. 贝叶斯非参数推断的展望	125

6. 本章小结	126
7. 附录：公式推导	126
Chapter 21. 高斯过程模型	129
1. 本章导论	129
2. 主要内容	129
3. 本章小结	129
Chapter 22. 有限混合模型	131
1. 本章导论	131
2. 异质性数据与混合模型的引入	131
3. 有限混合分布的形式与性质	132
4. EM 算法与混合模型的推断	133
5. 贝叶斯混合模型推断	134
6. 标签切换问题	134
7. 应用实例：星系速度数据	135
8. 混合模型的其他应用	135
9. 混合模型的扩展	135
10. 本章小结	136
11. 延伸阅读	136
Chapter 23. 狄利克雷过程模型	137
1. 本章导论	137
2. 从有限混合到无限混合	137
3. 狄利克雷过程的定义与构造	137
4. DP 作为未知分布的先验	138
5. 后验推断	139
6. DP 混合模型	139
7. 计算方法	139
8. 应用举例	140
9. 与其他非参数方法的联系	140
10. 本章小结	140
11. 下节预告	141
Appendix A. 公式推导	143
1. 概率与推断 (Chapter 1) 推导	143
2. 单参数模型 (Chapter 2) 推导	148
3. 阅读过程中的问题与解答	162
4. 什么是分布的核	162
5. 学习笔记	162
笔记 166section.A.5	

引言：文献概述

1. 什么是贝叶斯数据分析

贝叶斯数据分析是一种统计推断方法，其核心思想是使用概率来量化不确定性。在贝叶斯框架下，所有未知量——包括参数、潜在变量、甚至未来观测——都被视为随机变量，用概率分布来描述。

与传统频率主义统计不同，贝叶斯方法明确使用概率来表达我们对未知量的信念 (belief)。这种方法的主要优势包括：

- **自然的不确定性量化**：贝叶斯概率区间可以直接解释为“未知量包含在该区间内的概率”
- **灵活的建模能力**：可以构建复杂的多层次模型
- **原则性的推断框架**：贝叶斯定理为所有推断提供了统一的基础
- **先验信息的整合**：允许将领域知识融入统计分析

贝叶斯数据分析的过程可以概括为三个步骤：

- (1) 建立完整的概率模型
- (2) 基于观测数据计算后验分布
- (3) 评估模型的拟合度和敏感性

2. 核心概念

2.1. 先验分布 (Prior Distribution). 先验分布代表在观测数据之前，我们对未知参数 θ 的已有知识或信念。先验分布可以是：

- **信息先验**：基于领域知识或历史数据
- **非信息先验**：尽量减少先验对结果的影响（如 Jeffreys 先验）
- **弱信息先验**：包含一定信息但不完全反映领域知识

2.2. 后验分布 (Posterior Distribution). 后验分布是贝叶斯推断的核心——在观测到数据 y 后，关于参数 θ 的更新后的知识：

$$p(\theta|y) = \frac{p(y|\theta) \cdot p(\theta)}{p(y)}$$

其中 $p(y|\theta)$ 是似然函数， $p(y)$ 是边际似然（归一化常数）。

2.3. 预测分布 (Predictive Distribution). 贝叶斯方法可以自然地进行预测推断：

- **先验预测分布**： $p(y) = \int p(y|\theta)p(\theta)d\theta$
- **后验预测分布**： $p(\tilde{y}|y) = \int p(\tilde{y}|\theta)p(\theta|y)d\theta$

3. 文献目录

3.1. 核心教材.

- (1) *Bayesian Data Analysis, Third Edition* —Gelman, Carlin, Stern, Dunson, Vehtari, Rubin

本课程的核心教材，656 页，系统介绍了贝叶斯数据分析的理论与实践。

- Part I: 贝叶斯推断基础（概率、三步骤、单/多参数模型、分层模型）
- Part II: 数据分析基础（模型检查、评估、决策分析）
- Part III: 高级计算方法（MCMC、变分推断）
- Part IV: 回归模型
- Part V: 非参数模型

3.2. 课件.

- (1) *Three Steps of Bayesian Data Analysis* —Chapter 1 课件
- (2) *Single-parameter Models* —Chapter 2 课件
- (3) *Multi-parameter Models* —Chapter 3 课件
- (4) *Hierarchical Models* —Chapter 5 课件
- (5) *Model Checking* —Chapter 6 课件
- (6) *Bayesian Workflow* —Chapter 10 课件
- (7) *Advanced Topics* —Chapter 11 课件

3.3. 补充材料.

- (1) *Metropolis 算法简要证明*
MCMC 方法中 Metropolis 算法的理论基础与证明。
- (2) *R 语言实现抽样基础*
使用 R 语言实现各种抽样方法的实践指南。
- (3) *p 值补充*
p 值的定义、解释与局限性分析。
- (4) *拒绝抽样补充*
拒绝抽样方法的详细介绍与实现。

3.4. 参考教材.

- (1) *Markov Chain Monte Carlo in Practice* —Gilks, Richardson, Spiegelhalter
MCMC 方法的实践指南，是 BDA 第 11-12 章的重要补充。
- (2) *Monte Carlo Statistical Methods* —Robert, Casella
蒙特卡洛统计方法的理论教材，包含更深入的算法分析。
- (3) *Bayesian Statistical Modelling* —Congdon
贝叶斯统计建模的实用参考，提供了丰富的建模案例。

4. 课程结构

本课程将按照 BDA 第三版的结构依次学习：

- Part I (第 1-5 章)：贝叶斯推断基础
- Part II (第 6-9 章)：数据分析基础
- Part III (第 10-13 章)：高级计算方法
- Part IV (第 14-18 章)：回归模型
- Part V (第 19-23 章)：非参数模型

5. 学习方法

注 0.1. 建议的学习方法：

- (1) 先阅读课件把握整体框架
- (2) 深入阅读教材对应章节
- (3) 完成课后习题巩固理解
- (4) 通过编程实践加深概念

Part 1

贝叶斯推断基础

CHAPTER 1

概率与推断

1. 贝叶斯数据分析的三步骤

贝叶斯数据分析的过程可以理想化地分为以下三个步骤：

- (1) **建立完整的概率模型**：对问题中所有可观测和不可观测的量建立一个联合概率分布。模型应与底层科学问题（scientific problem）和数据收集过程的知识相一致。
- (2) **基于观测数据进行分析**：计算并解释适当的后验分布——即在给定观测数据的条件下，关于不可观测量的条件概率分布。
- (3) **评估模型的拟合度和后验分布的含义**：
 - 模型对数据的拟合程度如何？
 - 实质性结论（substantive conclusions）是否合理？
 - 结果对第一步中建模假设的敏感性如何？

作为回应，可以修改或扩展模型并重复这三个步骤。

第二个步骤涉及计算方法论，第三个步骤涉及微妙的技术与判断平衡，均由问题的应用背景指导。

第一步仍然是许多贝叶斯分析的主要障碍：我们的模型从何而来？如何构建适当的概率规范？

贝叶斯思维的主要动机是它便于对统计结论进行常识性解释。例如，一个未知量的贝叶斯（概率）区间可以直接被认为是“该未知量有很高概率包含在其中”，这与频率主义（置信区间）的解释形成对比——后者在严格解释下只能关联到重复抽样序列中的类似推断。

2. 统计推断的一般符号

在贝叶斯统计中，我们使用以下符号：

- θ ：不可观测的向量值或总体参数（如临床试验中每种治疗方案的生存概率）
- y ：观测数据（如每组中的存活和死亡人数）
- $\tilde{y}$ ：未知但潜在可观测的量（如其他治疗方案下患者的结果，或与试验中患者相似的新患者的结果）
- x ：解释变量或协变量（如患者的年龄和先前健康状况）

这些概率陈述以观测值 y 为条件，在我们记号中简单记为 $p(\theta|y)$ 或 $p(\tilde{y}|y)$ 。我们也隐含地以协变量的已知值为条件。

3. 贝叶斯推断

贝叶斯推断的核心思想是：关于参数 θ 或未观测数据 $\tilde{y}$ 的统计结论，都以概率陈述的形式给出。

这些概率陈述以观测值 y 为条件，在我们的记号中简单记为 $p(\theta|y)$ 或 $p(\tilde{y}|y)$ 。

3.1. 贝叶斯定理。为了对给定 y 的 θ 做出概率陈述，我们必须首先建立一个提供 θ 和 y 联合概率分布的模型。

联合概率质量（或密度）函数可以写成两个密度的乘积，通常称为先验分布 $p(\theta)$ 和采样分布（或数据分布） $p(y|\theta)$ ：

$$p(\theta, y) = p(\theta) \times p(y|\theta)$$

使用条件概率的基本性质（贝叶斯定理），得到后验密度：¹

$$p(\theta|y) = \frac{p(\theta) \times p(y|\theta)}{p(y)}$$

其中

$$p(y) = \int p(\theta) \times p(y|\theta) d\theta$$

一个等价的形式省略了不依赖于 θ 的因子 $p(y)$ ，给出非归一化后验密度：

$$p(\theta|y) \propto p(\theta) \times p(y|\theta)$$

为什么可以省略 $p(y)$ ？

关键在于：后验分布的**核**（kernel）²包含了所有关于 θ 的信息，而 $p(y)$ 作为归一化常数不包含任何关于 θ 的新信息。

以正态分布为例：后验密度 $p(\theta|y) \propto \exp\left(-\frac{(\theta-\mu)^2}{2\sigma^2}\right)$ ，我们只凭这个指数函数的形式就能识别出这是正态分布 $N(\mu, \sigma^2)$ ——因为已知核是二次型的指数，就能确定完整分布。

换句话说， $p(y)$ 的作用只是确保后验密度积分为 1，但它的具体值对于理解 θ 如何随数据更新并无贡献。

注 1.1. 注意： $p(y|\theta)$ 被视为 θ 的函数（固定 y ），而不是 y 的函数。这被称为似然函数。

3.2. 预测. 在数据 y 被观测之前，未知但可观测的 $\tilde{y}$ 的分布是边际分布：³

$$p(y) = \int p(y|\theta) \times p(\theta) d\theta$$

这被称为先验预测分布（prior predictive distribution）。

在观测到数据 y 之后，预测 $\tilde{y}$ 的分布是后验预测分布（posterior predictive distribution）：⁴

$$p(\tilde{y}|y) = \int p(\tilde{y}|\theta) \times p(\theta|y) d\theta$$

后验预测分布可以解释为在 θ 的后验分布上对条件预测进行平均。

例 1.1 (称重例子). 令 $y = (y_1, \dots, y_n)$ 为物体在秤上称量 n 次的记录重量， $\theta = (\mu, \sigma^2)$ 为物体的真实重量和测量方差， $\tilde{y}$ 为计划中新称量结果。

第二行展示了后验预测分布作为后验分布上条件预测的平均。最后一步来自在给定 θ 的条件下 y 和 $\tilde{y}$ 的条件独立性假设。

¹推导见附录 section 1.1

²关于“核”概念的详细解释，见附录 section 4

³推导见附录 section 1.2

⁴推导见附录 section 1.2

4. 似然与优势比

使用贝叶斯定理与选定的概率模型意味着数据 y 只通过 $p(y|\theta)$ 影响后验推断，当固定 y 将其视为 θ 的函数时，称为**似然函数**。

这样，贝叶斯推断服从所谓的似然原理：对于给定的数据样本，任何具有相同似然函数的概率模型 $p(y|\theta)$ 对 θ 产生相同的推断。

后验密度 $p(\theta|y)$ 在 θ_1 和 θ_2 处取值的比率称为后验优势比。优势比提供了一个概率的替代表示，并且具有贝叶斯定理用优势比表示特别简单的形式：⁵

$$\frac{p(\theta_1|y)}{p(\theta_2|y)} = \frac{p(\theta_1)}{p(\theta_2)} \times \frac{p(y|\theta_1)}{p(y|\theta_2)}$$

即：后验优势比 = 先验优势比 $\times$ 似然比。

5. 概率作为不确定性的度量

在贝叶斯统计中，概率被用作不确定性的基本度量（fundamental measure or yardstick of uncertainty）。在这个范式下，讨论明天降雨的概率或巴西队赢得世界杯的概率与讨论硬币抛掷正面朝上的概率同样合法。

为什么概率是量化不确定性的合理方式？通常有以下理由：

- (1) **类比**：物理随机性引起不确定性，因此用随机事件的语言描述不确定性似乎是合理的。日常语言使用“可能”和“不太可能”等术语，将更正式的概率计算扩展到科学推断问题是与之一致的。
- (2) **公理化或规范性方法**：与决策理论相关，将所有统计推断置于收益和损失的决策背景下。那么合理的公理（排序、传递性等）意味着不确定性必须用概率表示。
- (3) **博彩一致性**：定义你赋予事件 E 的概率 p ($p \in [0, 1]$) 为你愿意以此比例交换（即赌） $\$p$ 来换取如果 E 发生则获得 $\$1$ 的回报。也就是说，如果 E 发生，你额外获得 $(1 - p)$ ；如果 E 的补集发生，你损失 p 。

一致性原则（coherence principle）表明：你对所有可能事件的概率赋值不应该让对方有可能从你这里确定获利。可以证明在这种原则下构建的概率必须满足概率论的基本公理。

博彩基本原理有一些根本性困难：

- 需要精确的赔率，你愿意在两个方向中的任何一个方向下赌注。对于所有事件如何指定精确赔率？如果你不确定呢？
- 如果一个人愿意与你对赌，而且他有你不知道的信息，你接受赌注可能不明智。

这些考虑表明概率可能是总结应用统计中不确定性的合理方法，但最终证明在于应用的成功。

5.1. 两种经典论证. 对称性/可交换性论证：

$$\text{概率} = \frac{\text{有利情况数}}{\text{可能情况数}}$$

对于硬币抛掷，这实际上是一个物理论证，基于关于决定硬币如何落地的力量以及抛掷的初始物理条件的假设。

频率论证：

概率 = 在长期重复序列中得到的相对频率

假设以相同方式物理独立地进行。

⁵推导见附录 section 1.3

这两种论证在某种意义上都是主观的，因为它们需要对硬币性质和抛掷程序的判断，两者都涉及关于等可能性事件、相同测量和独立性的语义论证。

频率论证可能有某些特殊困难，因为它涉及长期相同抛掷序列的假设性概念。如果严格遵循，这种观点不允许对不属于长期相同事件序列的单一抛掷做出概率陈述。

6. 主观性与客观性

所有使用概率的统计方法在某种意义上都是主观的，因为它们依赖于对世界的数学理想化。

贝叶斯方法有时被认为特别主观，因为它们依赖于先验分布。但在大多数问题中，科学判断对于指定似然和先验分布都是必要的。

一个普遍原则是：每当存在复制时（即观察到许多可交换的单位），就有机会从数据中估计概率分布的特征，从而使分析更加客观。

如果整个实验被重复若干次，那么先验分布的参数本身也可以从数据中估计。

7. 概率赋值的例子：足球点差

在足球比赛中，“点差”（point spread）是博彩公司设定的赔率，用于使两边下注相对均衡。例如，如果热门队（favorite）的点差是 8 分，意味着博彩公司认为热门队平均会赢 8 分。

给定点差，我们可以估计各种条件概率：

- $\Pr(\text{热门队赢} | \text{点差} = 8)$
- $\Pr(\text{热门队至少赢 8 分} | \text{点差} = 8)$
- $\Pr(\text{热门队至少赢 8 分} | \text{点差} = 8 \text{ 且热门队赢})$

这些概率可以通过相对频率估计，也可以用正态近似来估计（outcome - point spread 的分布）。

8. 概率论的一些有用结果

见教材。

9. 本章小结

本章我们学习了：

- (1) 贝叶斯数据分析的三个基本步骤
- (2) 统计推断的一般符号 $(\theta, y, \hat{y}, x)$
- (3) 贝叶斯定理及其组成部分（先验、似然、后验、边际似然）
- (4) 预测分布：先验预测分布与后验预测分布
- (5) 概率作为不确定性度量的多种解释
- (6) 似然原理和优势比

10. 下节预告

下一章我们将学习单参数模型，包括从二项数据估计概率的经典例子——这是贝叶斯推断最经典的入门案例。

CHAPTER 2

单参数模型

1. 从二项数据估计概率

考虑从二项分布 $y \sim \text{Binomial}(n, \theta)$ 中观测到 y 次成功，其中：

- y : n 次伯努利试验中的成功总次数
- θ : 总体中的成功比例，或每次试验的成功概率

二项分布的似然函数为：

$$p(y|\theta) = \binom{n}{y} \theta^y (1 - \theta)^{n-y}$$

为了执行贝叶斯推断，我们必须为 θ 指定先验分布。作为简单开始，我们假设先验分布是 $[0, 1]$ 上的均匀分布： $\theta \sim \text{Uniform}(0, 1)$ ，即 $p(\theta) = 1$ 。

应用贝叶斯定理，得到后验密度：¹

$$p(\theta|y) \propto \theta^y (1 - \theta)^{n-y}$$

这正是 Beta 分布的形式，因此：

$$\theta|y \sim \text{Beta}(y + 1, n - y + 1)$$

定义 2.1 (Beta 分布). Beta 分布的概率密度函数为：

$$p(x|\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1 - x)^{\beta-1}, \quad 0 \leq x \leq 1$$

在固定 n 和 y 的情况下，组合数 $\binom{n}{y}$ 不依赖于未知参数 θ ，因此在计算后验分布时可以视为常数。

1.1. 预测. 在均匀先验下，先验预测分布可以直接计算。在模型下，所有可能的 y 值在先验下同等可能。

令 $\tilde{y}$ 表示与前 n 次试验可交换的一次新试验的结果：²

$$P(\tilde{y} = 1|y) = \int_0^1 \theta \cdot p(\theta|y) d\theta = \mathbb{E}(\theta|y) = \frac{y + 1}{n + 2}$$

这就是著名的拉普拉斯继承法则 (Laplace's law of succession)。在极端观测 $y = 0$ 和 $y = n$ 时，拉普拉斯法则预测概率分别为 $1/(n + 2)$ 和 $(n + 1)/(n + 2)$ 。

¹推导见附录 section 2.1

²推导见附录 section 2.3

2. 后验作为数据与先验信息的折中

贝叶斯推断的过程涉及从先验分布 $p(\theta)$ 到后验分布 $p(\theta|y)$ 的转化。以下两个式子描述了先验与后验之间的一般关系：³

$$\mathbb{E}(\theta) = \mathbb{E}[\mathbb{E}(\theta|y)]$$

$$\text{Var}(\theta) = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$$

第一个式子 (law of total expectation) 几乎不足为奇： θ 的先验均值是所有可能数据上后验均值的平均。

第二个式子 (law of total variance) 更有趣：后验方差平均上小于先验方差，两者之差取决于后验均值在不同数据上的变化程度。变化越大，我们降低不确定性的潜力越大。

2.1. 二项例子中的折中. 在二项例子中，均匀先验的均值是 $1/2$ ，方差是 $1/12$ 。

后验均值 $\frac{y+1}{n+2}$ 是先验均值 $1/2$ 和样本比例 y/n 之间的折中，显然，随着数据样本量增大，先验的作用越来越小。

这是贝叶斯推断的一般特征：**后验分布位于代表先验信息和数据信息的点之间，折中程度随着样本量增加越来越受数据控制。**

3. 后验推断的汇总

后验概率分布包含了关于参数 θ 的所有当前信息。常用的位置汇总包括后验均值、后验中位数、后验众数；变化程度通常用标准差、四分位距和其他分位数来汇总。

当后验分布具有闭式形式时（如当前例子中的 Beta 分布），这些汇总通常可以用闭式形式得到。

3.1. 后验区间. 除了点汇总之外，报告后验不确定性几乎总是重要的。通常的方法是给出后验分布的分位数，或者如果需要区间汇总，则给出一定概率的后验中心区间（如 $100(1 - \alpha)\%$ 区间）。这类区间估计称为**后验区间** (posterior interval)。

3.2. 最高后验密度区间. 另一种汇总后验不确定性的方法是**最高后验密度区域** (Highest Posterior Density, HPD region)：包含 $100(1 - \alpha)\%$ 后验概率的集合，且区域内密度不低于区域外。

对于单峰且对称的后验分布，HPD 区间与后验中心区间相同。但对于非对称分布，两者可能有显著差异——当后验分布有偏时，HPD 区间可以更准确地反映真实的不确定性范围。

4. 信息先验分布

在二项例子中，到目前为止我们只考虑了 θ 的均匀先验分布。问题在于：如何证明这种指定的合理性？一般来说，我们如何处理构建先验分布的问题？

对先验分布有两种基本解释：

- (1) **总体解释**：先验分布代表可能参数值的总体，当前感兴趣的 θ 是其中抽取的。
- (2) **主观知识状态解释**：指导原则是，我们必须将关于 θ 的知识（和不确定性）表达得像它的值是先验分布的随机实现一样。

对于许多问题（如估计新工业过程中失败概率），不存在完全相关的 θ 的总体。先验分布应包含所有合理的 θ 值，但分布不必真实集中在真值附近，因为通常数据中关于 θ 的信息远超过任何合理先验概率规范。

³推导见附录 section 2.4

4.1. 共轭先验. 考虑二项模型的似然: $p(y|\theta) \propto \theta^y(1-\theta)^{n-y}$

如果先验密度具有相同形式, 则后验密度也具有这种形式。我们将先验密度参数化为:

$$p(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$$

即 $\theta \sim \text{Beta}(\alpha, \beta)$ 。

将 $p(\theta)$ 与 $p(y|\theta)$ 比较, 可以看出这个先验等价于 $\alpha - 1$ 次先验成功和 $\beta - 1$ 次先验失败。

共轭性: 后验分布与先验分布属于同一参数形式。Beta 先验分布是二项似然的共轭族。共轭族在计算上是方便的, 因为后验分布遵循已知参数形式。⁴

后验均值:

$$\mathbb{E}(\theta|y) = \frac{\alpha + y}{\alpha + \beta + n}$$

后验方差:

$$\text{Var}(\theta|y) = \frac{(\alpha + y)(\beta + n - y)}{(\alpha + \beta + n)^2(\alpha + \beta + n + 1)}$$

当 y 和 $n - y$ 变大而 α 和 β 固定时:

$$\mathbb{E}(\theta|y) \approx \frac{y}{n}, \quad \text{Var}(\theta|y) \approx \frac{1}{n} \cdot \frac{y}{n} \left(1 - \frac{y}{n}\right)$$

方差以 $1/n$ 的速率趋近于零。极限情况下, 先验分布的参数对后验分布没有影响。

5. 正态均值的估计 (已知方差)

考虑来自正态分布 $y \sim \text{Normal}(\theta, \sigma^2)$ 的单个标量观测 y , 其中 σ^2 已知。

采样分布:

$$p(y|\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\theta)^2}{2\sigma^2}\right)$$

作为 θ 的函数, 似然是二次型的指数, 因此共轭先验族为:

$$p(\theta) \propto \exp(A\theta^2 + B\theta + C), \quad A < 0$$

参数化为 $\theta \sim \text{Normal}(\mu_0, \tau_0^2)$, 其中 μ_0 和 τ_0^2 是超参数。⁵

经过配方法, 得到后验分布 $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$, 其中:

$$\mu_1 = \frac{\mu_0/\tau_0^2 + y/\sigma^2}{1/\tau_0^2 + 1/\sigma^2}, \quad \frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

精度: 方差的倒数称为精度。后验精度等于先验精度加上数据精度。

后验均值 μ_1 可以多种方式解释:

- 先验均值和观测值 y 的加权平均, 权重与精度成正比
- 先验均值向观测值调整: $\mu_1 = \mu_0 + (y - \mu_0) \frac{\tau_0^2}{\sigma^2 + \tau_0^2}$
- 数据向先验均值收缩: $\mu_1 = y - (y - \mu_0) \frac{\sigma^2}{\sigma^2 + \tau_0^2}$

每种形式都表示后验均值是先验均值和观测值之间的折中。

⁴推导见附录 section 2.2

⁵推导见附录 section 2.5

5.1. 后验预测分布.⁶

未来观测 $\tilde{y}$ 的后验预测分布:

$$\tilde{y}|y \sim \text{Normal}(\mu_1, \sigma^2 + \tau_1^2)$$

预测均值等于 θ 的后验均值; 预测方差有两个组成部分: 来自模型的方差 σ^2 和来自 θ 后验不确定性的方差 τ_1^2 。

5.2. 多观测的正态模型. 上述单观测正态模型可以轻松推广到 n 个独立同分布观测 $y = (y_1, \dots, y_n)$ 。因为 $\bar{y}|\theta \sim \text{Normal}(\theta, \sigma^2/n)$, 对单观测推导的结果直接适用 (将 $\bar{y}$ 视为单观测):

$$\theta|y_1, \dots, y_n \sim \text{Normal}(\mu_n, \tau_n^2)$$

其中:

$$\mu_n = \frac{\mu_0/\tau_0^2 + n\bar{y}/\sigma^2}{1/\tau_0^2 + n/\sigma^2}, \quad \frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$$

6. 非信息先验分布

当先验分布没有总体基础时, 很难构建, 长期以来人们渴望得到保证在后验分布中作用最小的先验分布。这类分布有时称为参考先验分布, 先验密度被称为模糊、平坦、扩散或非信息的。

使用非信息先验的理由通常是”让数据自己说话”, 使推断不受当前数据外部信息的影响。

一个相关想法是**弱信息先验分布**, 它包含一些信息——足以正则化后验分布 (即保持它在合理范围内), 但不试图完全捕捉关于底层参数的科学知识。

6.1. 正常与非正常先验. 如果先验精度 $1/\tau_0^2$ 相对于数据精度 n/σ^2 很小, 则后验分布近似于 $\tau_0^2 = \infty$ 的情况:

$$p(\theta|y) \approx \text{Normal}(\bar{y}, \sigma^2/n)$$

换句话说, 后验分布近似于假设 $p(\theta)$ 与常数成正比的情况。这种分布实际上不可能, 因为 $p(\theta)$ 的积分是无穷大, 违反了概率总和为 1 的假设。

定义 2.2. 如果先验密度 $p(\theta)$ 不依赖于数据且积分等于 1, 则称为正常 (proper) 先验。如果 $p(\theta)$ 积分到任何正有限值, 可以重新归一化使其积分到 1, 则称为非归一化密度。如果积分不是有限的, 称为非正常 (improper) 先验。

非正常先验可能导致正常后验分布。使用非正常先验得到的后验分布必须非常小心解释——必须始终检查后验分布的积分是有限的且形式合理。

7. Jeffreys 不变性原则

一种有时用于定义非信息先验的方法是由 Jeffreys 提出的, 基于考虑参数的一一变换: $\phi = h(\theta)$ 。

Jeffreys 的一般原则是: 任何确定先验密度 $p(\theta)$ 的规则, 如果应用于变换后的参数, 应该产生等价的结果。

考虑在 θ 上使用均匀先验 $p(\theta) = 1$, 但在 logit 变换 $\phi = \log(\theta/(1-\theta))$ 下, 这会导致不均匀的先验。这说明均匀先验在参数变换下不是不变的。

Jeffreys 提出可接受的非信息先验发现原则应该在参数的单调变换下是不变的。他描述了如何基于 Fisher 信息函数构建这样的先验:⁷

⁶推导见附录 section 2.7

⁷推导见附录 section 2.6

$$p(\theta) \propto [J(\theta)]^{1/2}$$

其中 $J(\theta)$ 是 θ 的 Fisher 信息：

$$J(\theta) = -E \left[\frac{d^2 \log p(y|\theta)}{d\theta^2} \right]$$

对于二项模型，Jeffreys 先验是 $p(\theta) \propto \theta^{-1/2}(1-\theta)^{-1/2}$ ，即 $\text{Beta}(1/2, 1/2)$ 。

注意：均匀先验在参数变换下不是不变的—— θ 上的均匀先验在 $\log(\theta/(1-\theta))$ 上不是均匀的。这曾是 20 世纪初对贝叶斯推断的主要批评之一，直到 Jeffreys 在世纪中叶复兴了这一主题。

8. 弱信息先验分布

弱信息先验是比非信息先验更强的正则化，但仍然比完全信息先验弱得多。它们用于在数据有限时稳定计算，同时允许数据主导推断。

9. 其他标准单参数模型

见教材。

10. 本章小结

本章我们学习了：

- (1) 二项模型的贝叶斯推断：Beta-Binomial 共轭
- (2) 后验作为数据与先验信息的折中（方差分解公式）
- (3) 后验推断的汇总：点估计（均值、中位数、众数）和区间估计
- (4) 最高后验密度区间（HPD）
- (5) 信息先验与共轭先验
- (6) 正态均值估计（已知方差）：精度加法公式
- (7) 非信息先验与 Jeffreys 先验
- (8) 弱信息先验
- (9) 正常与非正常先验

11. 下节预告

下一章我们将学习多参数模型，包括如何处理 nuisance 参数和正态模型中均值与方差同时未知的情况。

多参数模型简介

1. 对 Nuisance 参数的积分

为了表达联合后验分布和边际后验分布的思想，假设 θ 有两部分，每部分都可以是向量： $\theta = (\theta_1, \theta_2)$ 。进一步假设我们只（至少目前只）对 θ_1 的推断感兴趣，因此 θ_2 可以被视为 nuisance 参数。

例如，在简单例子 $y|\mu, \sigma^2 \sim \text{Normal}(\mu, \sigma^2)$ 中， $\mu = \theta_1$ 和 $\sigma^2 = \theta_2$ 都未知，但通常我们最关心的是 μ 。

我们寻求给定观测数据的参数条件分布，即 $p(\theta_1|y)$ 。这从联合后验密度

$$p(\theta_1, \theta_2|y) \propto p(y|\theta_1, \theta_2) \times p(\theta_1, \theta_2)$$

通过对 θ_2 积分得到：

$$p(\theta_1|y) = \int p(\theta_1, \theta_2|y) d\theta_2$$

另一种分解方式是：

$$p(\theta_1|y) = \int p(\theta_1|\theta_2, y) \times p(\theta_2|y) d\theta_2$$

它表明：感兴趣的后验分布是条件后验分布的混合，其中 $p(\theta_2|y)$ 是对 θ_2 不同值的加权函数。权重依赖于 θ_2 的后验密度，因此依赖于数据和先验模型的组合。

对 nuisance 参数 θ_2 的积分可以一般性地解释。例如， θ_2 可以包括代表不同可能子模型的离散成分。

注 3.1. 我们很少直接计算这个积分，但它暗示了构建和计算多参数模型的重要策略：**后验分布可以通过边际和条件模拟来计算**——首先从边际后验分布抽取 θ_2 ，然后在给定 θ_2 值的条件下从条件后验分布抽取 θ_1 。通过这种方式，积分被间接执行。

这种分析形式的典型例子是正态模型中均值和方差都未知的情况。

2. 正态数据与非信息先验

作为从样本估计总体均值的原型例子，我们考虑来自一元正态分布 $\text{Normal}(\mu, \sigma^2)$ 的 n 个独立观测 $y = (y_1, \dots, y_n)$ 。

我们首先在非信息先验分布下分析这个模型。

2.1. 非信息先验分布. 对于 μ 和 σ^2 ，一个合理的模糊先验密度，假设位置参数和尺度参数的先验独立，是在 $(\mu, \log \sigma^2)$ 上均匀，即：

$$p(\mu, \sigma^2) \propto (\sigma^2)^{-1}$$

2.2. 联合后验分布. 在这种约定的非正常先验密度下, 联合后验分布为:

$$p(\mu, \sigma^2 | y) \propto (\sigma^2)^{-(n/2+1)} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \right)$$

利用 $\sum_{i=1}^n (y_i - \mu)^2 = \sum_{i=1}^n (y_i - \bar{y})^2 + n(\bar{y} - \mu)^2$, 可以写成:

$$= (\sigma^2)^{-(n/2+1)} \exp \left(-\frac{1}{2\sigma^2} [(n-1)s^2 + n(\bar{y} - \mu)^2] \right)$$

其中 $\bar{y}$ 是样本均值, $s^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$ 是样本方差。

充分统计量是 $\bar{y}$ 和 s^2 。

2.3. 条件后验分布. 为了分解联合后验密度, 我们首先考虑条件后验密度 $p(\mu | \sigma^2, y)$, 然后考虑边际后验密度 $p(\sigma^2 | y)$ 。

对于给定 σ^2 的 μ 的后验分布, 直接使用第二章中已知方差正态均值的均匀先验结果:

$$\mu | \sigma^2, y \sim N(\bar{y}, \sigma^2/n)$$

2.4. 边际后验分布. 为了确定 $p(\sigma^2 | y)$, 我们必须对 μ 积分:

$$p(\sigma^2 | y) \propto \int (\sigma^2)^{-(n/2+1)} \exp \left(-\frac{1}{2\sigma^2} [(n-1)s^2 + n(\bar{y} - \mu)^2] \right) d\mu$$

对 μ 积分需要计算简单的正态积分, 结果是:

$$p(\sigma^2 | y) \propto (\sigma^2)^{-(n/2+1)} \exp \left(-\frac{(n-1)s^2}{2\sigma^2} \right) \times \sqrt{2\pi\sigma^2/n}$$

简化后:

$$p(\sigma^2 | y) \propto (\sigma^2)^{-[(n-1)/2+1]} \exp \left(-\frac{(n-1)s^2}{2\sigma^2} \right)$$

这是尺度逆卡方分布 (scale inverse-chi-squared distribution):

定义 3.1 (尺度逆卡方分布).

$$p(x | \nu, \sigma^2) = \frac{(\nu\sigma^2/2)^{\nu/2}}{\Gamma(\nu/2)} x^{-(\nu/2+1)} \exp \left(-\frac{\nu\sigma^2}{2x} \right)$$

其中 ν 是自由度, σ^2 是尺度参数。

因此:

$$\sigma^2 | y \sim \text{Inv-}\chi^2(n-1, s^2)$$

由 $\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$, 这与频率统计中的经典结果有显著相似性。

2.5. 从联合后验分布抽样. 从联合后验分布抽取样本很容易:

- (1) 从边际后验分布抽取 σ^2 , 即 $\sigma^2 \sim \text{Inv-}\chi^2(n-1, s^2)$
- (2) 从条件后验分布抽取 μ , 即 $\mu | \sigma^2, y \sim N(\bar{y}, \sigma^2/n)$

2.6. 边际后验分布: t 分布. 总体均值 μ 通常是感兴趣的估计量, 边际后验分布可以通过对 σ^2 积分得到。结果是:

$$\mu|y \sim t_{n-1}(\bar{y}, s^2/n)$$

即自由度为 $n-1$ 的学生 t 分布。

这与频率统计中的经典结果也有显著相似性: 在采样分布下, $\frac{\bar{y}-\mu}{s/\sqrt{n}} \sim t_{n-1}$ 。

一个值得注意的事实是: 这个边际后验分布不依赖于数据——它是数据的函数, 但关于 μ 的概率陈述只通过 $\bar{y}$ 和 s^2 依赖于数据。

2.7. 后验预测分布. 未来观测 $\tilde{y}$ 的后验预测分布可以写成混合:

$$p(\tilde{y}|y) = \iint p(\tilde{y}|\mu, \sigma^2) \times p(\mu, \sigma^2|y) d\mu d\sigma^2$$

结果是 t 分布: $\tilde{y} \sim t_{n-1}(\bar{y}, (1 + 1/n)s^2)$ 。

3. 正态数据与共轭先验

当使用共轭先验时, 分析更加系统化。正态模型的共轭先验族具有形式:

$$\mu|\sigma^2 \sim N(\mu_0, \sigma^2/\kappa_0), \quad \sigma^2 \sim \text{Inv-}\chi^2(\nu_0, \sigma_0^2)$$

这对应于联合先验密度 $N\text{-Inv-}\chi^2(\mu_0, \sigma_0^2/\kappa_0; \nu_0, \sigma_0^2)$ 。

四个超参数分别是 μ 的位置和尺度、 σ^2 的自由度和尺度。

注意 σ^2 出现在 $\mu|\sigma^2$ 的条件分布中, 意味着在联合共轭先验密度中 μ 和 σ^2 必然相关。这通常是有意义的——让 μ 的先验方差与 σ^2 (观测 y 的采样方差) 挂钩是合理的。

3.1. 联合后验分布. 乘以正态似然得到后验密度仍然是 $N\text{-Inv-}\chi^2$ 形式, 参数更新为:

$$\mu_n = \frac{\kappa_0}{\kappa_0 + n} \mu_0 + \frac{n}{\kappa_0 + n} \bar{y}, \quad \kappa_n = \kappa_0 + n, \quad \nu_n = \nu_0 + n$$

$$\nu_n \sigma_n^2 = \nu_0 \sigma_0^2 + (n-1)s^2 + \frac{\kappa_0 n}{\kappa_n} (\bar{y} - \mu_0)^2$$

条件后验分布: $\mu|\sigma^2, y \sim N(\mu_n, \sigma^2/\kappa_n)$

边际后验分布: $\sigma^2|y \sim \text{Inv-}\chi^2(\nu_n, \sigma_n^2)$

μ 的边际后验分布: $\mu|y \sim t_{\nu_n}(\mu_n, \sigma_n^2/\kappa_n)$

4. 分类数据的多项模型

多项模型用于描述每个观测是 k 个可能结果之一的数据。如果 y 是每个结果观测次数的计数向量, 则:

$$p(y|\theta) \propto \prod_{j=1}^k \theta_j^{y_j}, \quad \sum_{j=1}^k \theta_j = 1$$

共轭先验分布是 Dirichlet 分布的多元推广:

$$p(\theta|\alpha) \propto \prod_{j=1}^k \theta_j^{\alpha_j-1}$$

结果是 θ_j s 的后验分布是 Dirichlet 分布, 参数为 $\alpha_j + y_j$ 。

设置 $\alpha_j = 1$ 给出均匀密度; 设置 $\alpha_j = 0$ 给出在 $\log(\theta_j)$ 上均匀的不正常先验。

5. 已知方差的多元正态模型

多元正态模型 $N(\mu, \Sigma)$ 的似然函数为：

$$p(y|\mu, \Sigma) \propto |\Sigma|^{-1/2} \exp \left\{ -\frac{1}{2}(y - \mu)^T \Sigma^{-1}(y - \mu) \right\}$$

给定 Σ 时， μ 的共轭先验是多元正态分布 $\mu \sim N(\mu_0, \Lambda_0)$ 。

后验分布：

$$\mu_n = (\Lambda_0^{-1} + n\Sigma^{-1})^{-1}(\Lambda_0^{-1}\mu_0 + n\Sigma^{-1}\bar{y}), \quad \Lambda_n^{-1} = \Lambda_0^{-1} + n\Sigma^{-1}$$

后验均值是数据和先验均值的加权平均，权重由精度矩阵给出；后验精度是先验精度和数据精度之和。

6. 均值和方差都未知的多元正态模型

(μ, Σ) 的共轭先验分布是 normal-inverse-Wishart 分布：

$$\Sigma \sim \text{Inv-Wishart}_{\nu_0}(\Lambda_0^{-1}), \quad \mu|\Sigma \sim N(\mu_0, \Sigma/\kappa_0)$$

后验分布具有相同形式，参数更新为：

$$\mu_n = \frac{\kappa_0}{\kappa_0 + n}\mu_0 + \frac{n}{\kappa_0 + n}\bar{y}, \quad \kappa_n = \kappa_0 + n, \quad \nu_n = \nu_0 + n$$

$$\Lambda_n = \Lambda_0 + S + \frac{\kappa_0 n}{\kappa_0 + n}(\bar{y} - \mu_0)(\bar{y} - \mu_0)^T$$

其中 $S = \sum_{i=1}^n (y_i - \bar{y})(y_i - \bar{y})^T$ 。

μ 的边际后验分布是多元 t 分布。

7. 基本建模与计算总结

多参数模型不允许轻易计算后验分布这一问题并非主要实际障碍，原因有三：

- (1) 当参数较少时，非共轭多参数模型的后验推断可以通过简单模拟方法获得。
- (2) 复杂模型通常可以表示为层次化或条件化形式，为此有有效的计算策略。
- (3) 我们经常可以应用后验分布的正态近似，因此正态模型的共轭结构在实践中可以发挥重要作用，远远超出其对显式正态采样模型的应用。

贝叶斯建模与计算的基本步骤总结：

- (1) 写出模型的似然部分 $p(y|\theta)$ ，忽略任何不含 θ 的因子。
- (2) 写出后验密度 $p(\theta|y) \propto p(\theta) \times p(y|\theta)$
 - 如果先验信息表述良好，将其包含在 $p(\theta)$ 中。
 - 否则使用弱信息先验或暂时设 $p(\theta) \propto \text{常数}$ 。
- (3) 创建参数的粗略估计 $\hat{\theta}$ ，用作起点和下一步计算的比较。
- (4) 从后验分布抽取模拟 $\theta^1, \dots, \theta^S$ 。使用样本模拟计算 θ 任何感兴趣函数的后验密度。
- (5) 如果有预测量 $\tilde{y}$ ，通过对每个 $\tilde{y}^s$ 从给定 θ^s 的采样分布 $p(\tilde{y}|\theta^s)$ 抽取来模拟 $\tilde{y}^1, \dots, \tilde{y}^S$ 。

对于非共轭模型，步骤 4 可能很困难。各种方法已被开发用于从复杂模型中抽取后验模拟。

8. 本章小结

本章我们学习了：

- (1) 如何对 nuisance 参数进行积分（边际化和条件化）
- (2) 多参数模型的计算策略：边际和条件模拟
- (3) 正态模型中均值和方差同时未知时的分析
- (4) 尺度逆卡方分布与 t 分布
- (5) 非信息先验和共轭先验在多参数情况下的应用
- (6) 多项模型与 Dirichlet 先验
- (7) 多元正态模型与 Inverse-Wishart 先验

9. 下节预告

下一章我们将学习渐近性以及贝叶斯方法与其他统计方法的联系。

渐近性与非贝叶斯方法的联系

1. 本章导论

我们在前三章看到，许多基于非信息先验分布的简单贝叶斯分析给出的结果与标准非贝叶斯方法（例如，均值未知时正态均值的后验 t 区间）相似。

非信息先验分布能在多大程度上被合理地视为客观假设，取决于数据中包含的信息量：在第二、三章讨论的简单情况中，随着样本量 n 的增加，先验分布对后验推断的影响会减小。

这些想法被称为**渐近理论**——因为它们指的是在 n 趋向无穷大时成立的理论——我们将在本章中进行回顾，同时还将更详细地讨论贝叶斯方法与非贝叶斯方法之间的联系。

大样本结果实际上对于执行贝叶斯数据分析并非必需，但通常作为近似工具和理解工具很有用。

2. 后验分布的正态近似

2.1. 联合后验分布的正态近似. 如果后验分布 $p(\theta|y)$ 是单峰的且大致对称，则可以用正态分布近似它；也就是说，后验密度的对数被近似为 θ 的二次函数。

我们考虑在的后验众数 $\hat{\theta}$ 处展开的后验密度对数的二次近似（其中 θ 可以是向量，且 $\hat{\theta}$ 假定在参数空间内部）；在第十三章中我们将讨论更复杂的近似方法，这些方法在简单基于众数的近似失效的情况下可能有效。

对在 $\hat{\theta}$ 处中心化的后验密度对数 $\log p(\theta|y)$ 进行泰勒级数展开给出

$$\log p(\theta|y) = \log p(\hat{\theta}|y) + \frac{1}{2}(\theta - \hat{\theta})^T \left[\frac{d^2}{d\theta^2} \log p(\theta|y) \right]_{\theta=\hat{\theta}} (\theta - \hat{\theta}) + \dots$$

其中展开式的线性项为零，因为对数后验密度在其众数处导数为零。

当 θ 接近 $\hat{\theta}$ 且 n 较大时，高阶余项的相对重要性会减小。考虑 section 2.1 作为 θ 的函数，第一项是常数，而第二项与正态密度对数成正比，得到近似

$$p(\theta|y) \approx N(\hat{\theta}, [I(\hat{\theta})]^{-1}),$$

其中 $I(\theta)$ 是观测信息 (observed information),

$$I(\theta) = -\frac{d^2}{d\theta^2} \log p(\theta|y).$$

如果众数 $\hat{\theta}$ 在参数空间的内部，则矩阵 $I(\hat{\theta})$ 是正定的。

例 4.1 (均值和方差均未知的正态分布). 我们用简单的理论例子说明近似正态分布。设 $y_1, \dots, y_n$ 是来自 $N(\mu, \sigma^2)$ 分布的独立观测，为简单起见，假设 $(\mu, \log \sigma)$ 上的均匀先验密度。

我们对 $(\mu, \log \sigma)$ 的后验分布建立正态近似，这在限制 σ 为正值方面有优点。为了构建近似，我们需要对数后验密度的二阶导数。

在众数处，二阶导数矩阵为 $\begin{pmatrix} -n/\hat{\sigma}^2 & 0 \\ 0 & -2n \end{pmatrix}$ 。从 section 2.1，后验分布可以近似为

$$p(\mu, \log \sigma | y) \approx N \left(\begin{pmatrix} \mu \\ \log \sigma \end{pmatrix} \middle| \begin{pmatrix} \bar{y} \\ \log \hat{\sigma} \end{pmatrix}, \begin{pmatrix} \hat{\sigma}^2/n & 0 \\ 0 & 1/(2n) \end{pmatrix} \right).$$

2.2. 后验密度函数相对于其最大值的解释. 除了作为近似直接使用外，多元正态分布还为解释后验密度函数和等高线图提供了基准。在 d 维正态分布中，密度函数的对数是一个常数加上 -2 除以的 χ_d^2 分布。例如， χ_{10}^2 密度的第 95 百分位是 18.31，因此如果一个问题有 $d = 10$ 个参数，则大约 95% 的后验概率质量与 $p(\theta|y)$ 不小于在众数处密度的 $\exp(-18.31/2) = 1.1 \times 10^{-4}$ 倍的 θ 值相关联。

2.3. 用点估计和标准误总结后验分布. 渐近理论表明，如果 n 足够大，后验分布可以用正态分布近似。在许多应用领域中，标准的推断总结是计算点估计 $\hat{\theta}$ （如最大似然估计，即均匀先验下的后验众数），加上或减去两个标准误，标准误从估计处的信息 $I(\hat{\theta})$ 估计。

在许多情况下，通过变换可以显著改善 θ 的后验分布向正态分布的收敛性。如果 ϕ 是 θ 的连续变换，那么 $p(\phi|y)$ 和 $p(\theta|y)$ 都趋向正态分布，但对于有限的 n ，近似的紧密程度可能随所选变换而大幅变化。

2.4. 数据约简与充分统计量. 在正态近似下，后验分布由其众数 $\hat{\theta}$ 和后验密度的曲率 $I(\hat{\theta})$ 总结；即渐近地，这些是充分统计量。

使用充分统计量的这种方法允许相对容易地将分层建模技术应用于改进每个单独估计。例如，在第 5.5 节中，一组八个实验中的每一个都通过从早期回归分析估计的点估计和标准误来总结。

当后验分布接近正态时，使用汇总统计量的方法最为合理；否则这种方法可能会丢弃重要信息并导致错误的推断。

2.5. 低维正态近似. 对于有限的样本量 n ，正态近似通常对 θ 的分量条件分布和边际分布比对完整联合分布更准确。

例如，如果联合分布是多元正态分布，则其所有边际分布都是正态的，但反之不成立。确定 θ 一个分量的边际分布等同于对 θ 的所有其他分量进行平均，而平均一族分布通常会使它们更接近正态分布——这与中心极限定理背后的逻辑相同。

注 4.1. 对于低维 θ ，后验分布的正态近似通常是完全可以接受的，特别是在适当的变换之后。

例 4.2 (生物 assay 实验 (续)). 我们用 3.7 节中生物 assay 实验的模型和数据来说明正态近似。实验中样本量相对较小，只有 20 只动物，我们发现正态近似接近精确后验分布，但存在重要差异。

(α, β) 联合后验分布的正态近似：?? 显示了二元正态近似的等高线图和从这个近似分布中抽取的 1000 个样本的散点图。

正态近似的均值 $(\alpha, \beta) = (0.8, 7.7)$ 与实际后验分布的均值 $(\alpha, \beta) = (1.4, 11.9)$ 不同。

3. 大样本理论

3.1. 符号与数学设置. 大样本贝叶斯推断的基本工具是后验分布的渐近正态性：随着来自相同底层过程的越来越多数据到达，参数向量的后验分布趋向多元正态分布，即使数据的真实分布不在所考虑的参数族中。

从数学上讲，这些结果最直接地适用于从公共分布 $f(y)$ 中独立抽取的观测 $y_1, \dots, y_n$ 。在许多情况下，为数据假设一个“真实”底层分布 $f(y)$ 的概念很难解释，但为了发展渐近理论，这是必要的。

假设数据由参数族 $p(y|\theta)$ 建模，并具有先验分布 $p(\theta)$ 。如果真实数据分布包含在参数族中——即如果 $f(y) = p(y|\theta_0)$ 对于某个 θ_0 ——那么除了渐近正态性外，一致性性质也成立：随着 $n \rightarrow \infty$ ，后验分布收敛到在真实参数值 θ_0 处的点质量。

3.2. 渐近正态性与一致性. 附录 B 中给出的基本数学结果表明，在一些正则性条件下（特别是似然函数是 θ 的连续函数且 θ_0 不在参数空间边界上），随着 $n \rightarrow \infty$ ， θ 的后验分布趋向正态分布，均值为 θ_0 ，方差为 $(nJ(\theta_0))^{-1}$ 。

在最简单的层面，这个结果可以从在后验众数处对数后验密度的泰勒级数展开 section 2.1 来理解。初步结果表明，后验众数对 θ_0 是一致的，因此随着 $n \rightarrow \infty$ ，后验分布 $p(\theta|y)$ 的质量集中在 θ_0 越来越小的邻域内，距离 $|\hat{\theta} - \theta_0|$ 趋向零。

3.3. 似然支配先验分布. 渐近结果形式化了先验分布的重要性随着样本量增加而减小的概念。这导致一个结论：在具有大样本量的问题中，我们不必特别努力地制定一个准确反映所有可用信息的先验分布。当样本量较小时，先验分布是模型规范的关键部分。

4. 定理的反例

理解大样本结果局限性的好方法是考虑定理失效的情况。正态分布通常作为起点近似有帮助，但必须检查偏差，特别是对于不寻常的参数空间和分布极值情况。

4.1. 未识别模型与未识别参数. 如果给定数据 y ，似然 $p(\theta|y)$ 在一系列 θ 值上相等，则模型是未识别的 (underidentified)。在这样的模型下，没有单一点 θ_0 可以使后验分布收敛到它。

例 4.3 (相关系数的未识别性). 考虑模型，其中 $(u, v)^T \sim N((0, 0)^T, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix})$ ，但只从每对 (u, v) 中观测到其中一个。这里参数 ρ 是未识别的。数据不提供关于 ρ 的任何信息，因此 ρ 的后验分布与其先验分布相同，无论数据集有多大。

未识别或欠识别参数问题的唯一解决方案是认识到问题存在，如果有更精确估计这些参数的愿望，则收集可以 enable 估计这些参数的进一步信息 (either from future data collection or from external information that can inform a prior distribution)。

4.2. 参数数量随样本量增加. 在复杂问题中，参数数量可能很大，我们需要区分不同类型的渐近性。如果随着 n 增加，模型也发生变化使得参数数量同时增加，那么 section 2 和 section 3 中概述的简单结果（假设固定模型类 $p(y_i|\theta)$ ）并不适用。

例如，有时为研究中的每个采样单位分配一个参数；例如 $y_i \sim N(\theta_i, \sigma^2)$ 。一般来说，除非每个采样单位收集的数据量也随着单位数量的增加而增加，否则参数 θ_i 不能被一致地估计。

4.3. 混叠. 混叠是欠识别参数的一种特殊情况，其中相同的似然函数在一组离散点上重复。例如，考虑具有独立同分布数据 $y_1, \dots, y_n$ 的正态混合模型。

如果交换 (μ_1, μ_2) 和 (σ_1^2, σ_2^2) ，并将 λ 替换为 $(1 - \lambda)$ ，数据的似然保持不变。

后验分布至少有两个众数，由两个分布的 (50%, 50%) 混合组成——它们是彼此的镜像；无论数据集有多大，它都不会收敛到单个点。

通常，通过限制参数空间使没有重复来解决混叠问题。

4.4. 无界似然. 如果似然函数是无界的，则后验众数可能不存在于参数空间中，从而使一致性和正态近似的结果无效。

例如，对于正态混合模型，如果我们设 $\mu_1 = y_i$ 对于任意 y_i ，并让 $\sigma_1^2 \rightarrow 0$ ，则似然趋向无穷大。随着 $n \rightarrow \infty$ ，似然的众数数量增加。

4.5. 不当后验分布. 如果通过将似然乘以表示不当先验分布的“形式”先验密度获得的无规范化后验密度积分到无穷大，则渐近结果不成立。

当不当先验分布与似然组合具有有限积分时，不当先验分布只是一种方便的近似。

4.6. 排除收敛点的先验分布. 如果对于离散参数空间 $p(\theta_0) = 0$ ，或者对于连续参数空间在 θ_0 的邻域内 $p(\theta) = 0$ ，则一致性结果不成立。

解决方案是在先验分布中给所有甚至略微合理的 θ 值赋予正概率密度。

4.7. 收敛到参数空间边界. 如果 θ_0 在参数空间的边界上，则泰勒级数展开必须在某些方向上截断，正态分布不一定合适，即使在极限情况下也是如此。

例如，考虑模型 $y_i \sim N(\theta, 1)$ ，限制 $\theta \geq 0$ 。假设模型是准确的， $\theta = 0$ 是真实值。 θ 的后验分布是正态的，以 $\bar{y}$ 为中心，截断为正值。

5. 贝叶斯推断的频率评估

就像贝叶斯范式可以被视为证明简单“经典”技术的合理性一样，频率统计方法提供了一种有用的方法来评估贝叶斯推断的性质——它们的操作特征——当这些被视为嵌入一系列重复样本中时。

5.1. 大样本对应. 假设 θ 后验分布的正态近似 section 2.1 成立；那么我们可以转换为标准多元正态：

$$[I(\hat{\theta})]^{1/2}(\theta - \hat{\theta})|y \sim N(0, I),$$

其中 $\hat{\theta}$ 是后验众数。如果真实数据分布包含在模型类中，则在重复采样中，渐近地， $100(1 - \alpha)\%$ 的中心后验区间将在 $100(1 - \alpha)\%$ 的情况下覆盖真值 θ_0 。

5.2. 点估计、一致性与有效性. 从贝叶斯框架来看，获得 θ 的“估计”在大样本中最有意义，此时后验众数 $\hat{\theta}$ 是 θ 后验分布的明显中心。

一个点估计如果随着样本变大而收敛到它所估计的参数真值，则被称为在采样理论意义上是一致的。

如果对于任何 θ_0 值，在重复样本中 $C(y)$ 至少以 $100(1 - \alpha)\%$ 的概率包含 θ_0 ，则 $C(y)$ 被称为 θ 的 $100(1 - \alpha)\%$ 置信域。

6. 其他统计方法的贝叶斯解释

我们考虑贝叶斯统计方法与其他方法比较的三个层次：

- (1) 首先，正如我们已经指出的，在涉及来自固定概率模型的大样本的问题中，贝叶斯方法通常类似于其他统计方法。
- (2) 其次，即使对于小样本，许多统计方法也可以被视为基于特定先验分布的贝叶斯推断的近似；作为一种理解统计程序的方式，确定隐含的底层先验分布通常很有用。
- (3) 第三，经典统计的一些方法（特别是假设检验）可能给出与贝叶斯方法非常不同的结果。

6.1. 最大似然与点估计. 从贝叶斯数据分析的角度来看，我们通常可以将经典点估计解释为基于某些隐含完整概率模型的精确或近似后验总结。在大样本量的极限下，事实上我们可以使用渐近理论为经典最大似然推断构建理论贝叶斯论证。

渐近地，最大似然估计 $\hat{\theta}$ 是一个充分统计量——后验众数、均值或中位数也是充分统计量。

对于大的 n ，先验分布的渐近无关性可以用来为使用方便的非信息先验模型提供理由。

6.2. 无偏估计. 一些非贝叶斯统计方法非常强调无偏性作为估计的可取原则。形式上, 如果 $\mathbb{E}(\hat{\theta}(y)|\theta) = \theta$ 对于任何 θ 值, 则估计 $\hat{\theta}(y)$ 被称为无偏的。

从贝叶斯角度来看, 无偏性原则在大样本极限中是合理的, 但在其他情况下可能具有误导性。主要困难出现在有许多参数要估计的情况下。

注 4.2. 无偏性原则的一个问题是, 通常不可能以甚至近似无偏的方式一次估计几个参数。

例 4.4 (使用回归进行预测). 考虑在已知母亲身高 y 的情况下估计成年女儿身高 θ 的问题。为简单起见, 假设母亲和女儿的身高联合正态分布, 均值相等为 160 厘米, 方差相等, 相关系数为 0.5。

在已知 y 的条件下, θ 的后验均值为

$$\mathbb{E}(\theta|y) = 160 + 0.5(y - 160).$$

然而, 后验均值在重复采样中并不是 θ 的无偏估计。

这个例子说明的重要原则是**回归均值**的原则: 对于任何给定的母亲, 她女儿身高的期望值介于她母亲身高和总体均值之间。

7. 本章小结

本章我们学习了:

- (1) 后验分布的正态近似 (基于泰勒级数展开)
- (2) 观测信息矩阵与 Fisher 信息的概念
- (3) 大样本理论: 渐近正态性与一致性
- (4) 似然支配先验的原则
- (5) 渐近定理的反例: 未识别参数、参数数量随样本增加、混叠、无界似力、不当后验等
- (6) 频率评估与贝叶斯推断的联系
- (7) 其他统计方法的贝叶斯解释: 无偏估计、置信区间、回归预测等

8. 下节预告

下一章我们将学习分层模型 (Hierarchical Models), 这是贝叶斯统计中非常重要的一类模型, 用于处理具有分组结构的复杂数据。

分层模型

1. 本章导论

在许多统计应用中，我们面对的不是一个单一的参数，而是多个彼此存在某种联系的参数。如何为这样的多参数问题建立概率模型？当我们对各个参数知之甚少时，能否利用参数之间的结构来合并信息？

这些问题引导我们引入本章的核心工具——**分层模型** (hierarchical models)。

分层思维的核心思想：将多参数问题分解为多个层次来建模。可观测的数据在对某些参数的条件下建模，而这些参数本身又用一个更高层次参数（**超参数**，hyperparameter）的概率分布来描述。

这种层次化思维不仅帮助我们理解多参数问题，还在计算策略的发展中发挥重要作用。更重要的是，简单的非分层模型通常不适合分层数据——参数太少则无法准确拟合数据，参数太多则容易过拟合。分层模型通过在参数之间引入由总体分布确定的结构，既保留了足够多的参数来拟合数据，又避免了过拟合的问题。

2. 可交换性与分层模型的建立

2.1. 从历史数据到先验分布。我们从一个具体例子开始，阐述分层模型的基本思想。

考虑估计参数 θ 的问题：我们有当前小规模实验的数据，以及从类似历史实验构建的先验分布。从数学上讲，我们认为当前实验和历史实验都是从某个公共总体中随机抽取的样本。

例 5.1 (估计一组大鼠的肿瘤风险)。在药物评估中，研究人员通常对啮齿动物进行实验。假设我们的目标是估计 θ ——对照组雌性 F344 实验室大鼠发生子宫内膜基质息肉（一种肿瘤）的概率。

数据显示，14 只大鼠中有 4 只发生了息肉。给定 θ ，假设肿瘤数量的二项模型是很自然的。为方便起见，我们从共轭族中选择先验分布： $\theta \sim \text{Beta}(\alpha, \beta)$ 。

后验分布为 $\theta | y \sim \text{Beta}(\alpha + y, \beta + n - y)$ ，其中 $y = 4$ ， $n = 14$ 。

现在，假设我们有来自历史数据的信息：历史实验中的肿瘤概率 θ_j 近似服从某个 beta 分布，其均值和标准差已知。设历史数据包含 70 组实验的肿瘤发生率 (y_j/n_j)，其样本均值为 0.136，标准差为 0.103。

如果设总体分布的均值和标准差分别为这些值，可以解出对应的 (α, β) 估计值为 (1.4, 8.6)。使用这个估计的先验分布，得到当前实验的 $\text{Beta}(5.4, 18.6)$ 后验分布，后验均值是 0.223。

这比原始比例 $4/14 = 0.286$ 低得多——因为历史数据的权重表明，当前实验的肿瘤发生率异常高。

然而，这种直接用数据估计先验分布的方法存在逻辑问题：如果我们用全部数据来估计先验分布，然后再用同样的数据对每个 θ_j 进行推断，数据被使用了两次，这会导致我们高估精确度。此外，用点估计代替 (α, β) 忽略了后验不确定性。

解决之道：将整个参数集合和实验的联合分布放入概率模型中，然后对所有模型参数的联合分布执行完整的贝叶斯分析。

2.2. 可交换性. 从上述例子中，我们引入一个关键概念。

当我们除了数据 y 之外，没有任何信息可以区分各个 θ_j 时，必须在先验分布中对参数施加对称性。这种对称性在概率上用**可交换性** (exchangeability) 来表示：如果参数 $(\theta_1, \dots, \theta_J)$ 的联合分布 $p(\theta_1, \dots, \theta_J)$ 在指标 $(1, \dots, J)$ 的任意置换下保持不变，则这些参数是**可交换的**。

在大鼠肿瘤问题中，除了样本量 n_j 之外（样本量被认为与 θ_j 的值无关），没有任何信息可以区分 71 个实验，因此我们对 θ_j 使用可交换模型。

可交换性是在构建独立同分布数据模型时已经遇到过的概念。实践中，**无知意味着可交换性**——我们对问题了解得越少，就越有信心做出可交换性假设。

可交换性最简单的形式是将每个参数 θ_j 视为来自某个由超参数向量 ϕ 控制的先验（或总体）分布的独立同分布样本：

$$p(\theta | \phi) = \prod_{j=1}^J p(\theta_j | \phi).$$

一般情况下 ϕ 是未知的，因此我们必须在整个 θ 的分布上对 ϕ 的不确定性进行平均：

$$p(\theta) = \int \left[\prod_{j=1}^J p(\theta_j | \phi) \right] p(\phi) d\phi.$$

这种独立同分布的混合形式，通常足以在实践中捕捉可交换性。

注 5.1. 可交换性并不意味着参数是独立同分布的——它只意味着在参数值被交换时，联合分布不变。独立同分布是可交换性的一种特殊形式。

2.3. 分层模型设置. 一般地，考虑 $j = 1, \dots, J$ 个实验，其中实验 j 有数据（向量） y_j 和参数（向量） θ_j ，似然函数为 $p(y_j | \theta_j)$ 。

两层分层模型的标准形式为：

- (1) **数据层**: $y_{ij} | \theta_j \sim p(y_{ij} | \theta_j)$ (独立)
- (2) **参数层**: $\theta_j | \phi \sim p(\theta_j | \phi)$ (独立，来自共同先验)
- (3) **超参数层**: $\phi \sim p(\phi)$ (先验)

联合后验分布为：

$$p(\theta, \phi | y) \propto p(\phi) \prod_{j=1}^J p(\theta_j | \phi) \prod_{i=1}^{n_j} p(y_{ij} | \theta_j).$$

3. 共轭分层模型的完全贝叶斯分析

3.1. 超先验分布. 为了建立 (ϕ, θ) 的联合概率分布，我们必须为 ϕ 指定先验分布 $p(\phi)$ 。如果对 ϕ 了解甚少，可以指定一个扩散先验分布，但使用非正常先验密度时必须小心，要检查得到的后验分布是否是正常的。

在大鼠肿瘤例子中，超参数是 (α, β) ，它们决定 θ 的 beta 分布。

3.2. 后验预测分布. 分层模型的特点是同时存在超参数 ϕ 和参数 θ 。有两类后验预测分布值得关注：

- (1) 现有 θ_j 对应的未来观测 $\tilde{y}$ 的分布；
- (2) 从相同超总体中抽取的未来 θ_j (记为 $\tilde{\theta}$) 对应的观测 $\tilde{y}$ 的分布。

在大鼠肿瘤例子中，未来观测可以是：

- (1) 来自现有实验的额外大鼠；
- (2) 来自未来实验的结果。

在前一种情况中，后验预测抽取 $\tilde{y}$ 基于现有实验的 θ_j 的后验抽取。在后一种情况中，必须首先根据 ϕ 的后验抽取绘制新实验的 $\tilde{\theta}$ ，然后再根据抽取的 $\tilde{\theta}$ 绘制 $\tilde{y}$ 。

3.3. Beta-Binomial 层次模型. 假设我们有 J 个独立实验，每个实验有 n_j 次试验和 y_j 次成功。模型为：

- (1) $y_j | \theta_j \sim \text{Binomial}(n_j, \theta_j)$
- (2) $\theta_j | \alpha, \beta \sim \text{Beta}(\alpha, \beta)$
- (3) (α, β) 的先验：需要指定 $p(\alpha, \beta)$

完全贝叶斯分析的关键是理解层次模型如何允许数据“告知”超参数。在完全贝叶斯分析中，我们对 (α, β) 进行积分或抽样：

$$p(\theta_j | y) = \iint p(\theta_j | \alpha, \beta) p(\alpha, \beta | y) d\alpha d\beta.$$

这个积分通常需要数值方法或马尔科夫链蒙特卡洛（MCMC）来计算。

4. 正态模型中可交换参数的估计

4.1. 正态层次模型. 一个特别重要的情况是：当数据 y_j 是来自正态分布的样本均值，并且参数 θ_j 在变换后是正态分布时。

考虑 J 个独立实验，实验 j 从正态分布 $y_{ij} | \theta_j \sim N(\theta_j, \sigma^2)$ 中抽取 n_j 个独立数据点，其中 σ^2 已知。使用标准记号，将每组 j 的样本均值记为

$$\bar{y}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} y_{ij},$$

其抽样方差为 $\sigma_j^2 = \sigma^2/n_j$ 。

我们可以将每组 θ_j 的似然函数写为

$$\bar{y}_j | \theta_j \sim N(\theta_j, \sigma_j^2).$$

正态层次模型设定：

- (1) $y_j | \theta_j, \sigma_j^2 \sim N(\theta_j, \sigma_j^2)$ ，其中 σ_j^2 已知
- (2) $\theta_j | \mu, \tau^2 \sim N(\mu, \tau^2)$
- (3) (μ, τ^2) 有适当的先验

超参数 μ 是总体均值， τ^2 是组间方差。

为方便起见（更准确地说是部分共轭），我们假设参数 θ_j 来自以超参数 (μ, τ) 为参数的正态分布：

$$p(\theta_1, \dots, \theta_J | \mu, \tau) = \prod_{j=1}^J N(\theta_j | \mu, \tau^2).$$

即给定 (μ, τ) 时， θ_j 是条件独立的。

4.2. 后验分布. 给定数据 y_j , θ_j 的后验分布可以分解为:

$$p(\theta_j | y, \mu, \tau^2) \propto p(\theta_j | \mu, \tau^2) \prod_{j=1}^J p(y_j | \theta_j).$$

结果是:

$$\theta_j | y, \mu, \tau^2 \sim N(\hat{\theta}_j, V_j),$$

其中

$$\hat{\theta}_j = \frac{\bar{y}_j / \sigma_j^2 + \mu / \tau^2}{1 / \sigma_j^2 + 1 / \tau^2}, \quad \frac{1}{V_j} = \frac{1}{\sigma_j^2} + \frac{1}{\tau^2}.$$

这个结果表明: 后验均值是先验均值 μ 和数据均值 $\bar{y}_j$ 的**精度加权平均**。

当 τ^2 较大 (组间变异大) 时, 估计接近原始数据 $\bar{y}_j$; 当 τ^2 较小 (组间变异小) 时, 估计收缩到共同均值 μ 。这种收缩特性是层次模型的核心特征。

5. 示例: 八所学校的平行实验

这是一个经典的层次模型例子, 展示了分层建模在 meta 分析中的应用。

5.1. 问题背景. 考虑一项研究, $J = 8$ 所学校, 每所学校都报告了培训效果估计 y_j 及其标准误 σ_j 。我们希望估计每所学校的真实效果 θ_j , 同时估计总体效果。

数据如下:

学校 j	估计 y_j	标准误 σ_j
1	28.4	14.9
2	7.0	10.2
3	-4.4	16.3
4	7.0	11.0
5	1.9	9.4
6	6.6	10.5
7	10.8	17.6
8	33.1	15.6

5.2. 层次模型. 我们设定模型:

$$y_j | \theta_j, \sigma_j \sim N(\theta_j, \sigma_j^2),$$

$$\theta_j | \mu, \tau \sim N(\mu, \tau^2),$$

其中 σ_j 已知, (μ, τ) 有适当的先验。

5.3. 后验推断. 后验分布 $p(\theta, \mu, \tau | y)$ 可以通过 MCMC 或近似方法获得。关键理解是:

注 5.2. 层次模型提供了在**合并信息**和**保持学校特异性估计**之间的自然权衡。参数 τ 控制了这种权衡: 当 τ 小时, 所有 θ_j 被强烈收缩到公共均值 μ ; 当 τ 大时, 每个 θ_j 主要由其自身数据决定。

6. 分层建模在 meta 分析中的应用

Meta 分析是将多项研究结果合并的统计方法。层次模型为 meta 分析提供了自然的框架。

6.1. 固定效应与随机效应. 在 meta 分析中, 我们通常考虑两种模型:

- (1) **固定效应模型:** 假设所有研究估计相同的真实效应 θ , 观测差异仅由抽样误差解释。
- (2) **随机效应模型:** 假设研究间的效应是可交换的, 来自某个分布 $p(\theta_j | \mu, \tau^2)$ 。

随机效应模型是层次模型的一个特例, 其中 θ_j 被视为从公共分布中抽取的样本。

在随机效应模型中, 我们不仅估计总体效应 μ , 还估计研究间的变异 τ^2 。这使得我们能够量化研究间的异质性, 并相应地调整推断。

7. 分层方差参数的弱信息先验

层次模型的一个关键挑战是估计方差参数 τ^2 。当数据稀疏时, 方差参数的估计可能极不稳定。

7.1. 问题. 在后验分布中, τ^2 通常信息不足, 导致后验尾部过重或甚至不当。此外, 经典的方差分析估计 $\hat{\tau}^2$ 可能是负数, 这在物理上是不可能的。

7.2. 弱信息先验. 一种解决方案是使用弱信息先验, 例如:

- **Half- t 先验:** 对 τ 使用 t 分布在正半轴
- **$\log(\tau)$ 上的正态先验:** 使用宽窗口的正态先验

实践中, 通常需要确定 τ 的最佳猜测和上界, 然后可以从缩放逆 χ^2 族 (方差参数的自然选择) 构建合理的先验分布, 将最佳猜测匹配到缩放逆 χ^2 密度的均值, 上界匹配到某个上百分位 (如 99th)。

注 5.3. 选择先验时, 应该考虑参数的尺度。例如, 如果我们有标准误 σ_j , 在 $\log(\tau)$ 上指定先验可能比在 τ 上更合理。

8. 本章小结

本章我们学习了:

- (1) **层次模型的基本思想:** 通过分层结构处理相关参数, 允许数据告知超参数
- (2) **可交换性 (Exchangeability)** 的概念: 当除了数据之外没有任何信息可以区分参数时, 必须假设对称性
- (3) **两层次模型的构建:** 数据层、参数层、超参数层
- (4) **后验分布的收缩性质:** 当 τ^2 小时, θ_j 的估计被收缩到公共均值 μ
- (5) **Beta-Binomial 和正态层次模型的完全贝叶斯分析**
- (6) **八学校例子:** 层次模型在 meta 分析中的应用
- (7) **固定效应 vs. 随机效应模型的区别**
- (8) **层次方差参数的弱信息先验**

层次模型是贝叶斯统计中最重要的工具之一, 它允许我们:

- 在保持参数特异性估计的同时合并信息
- 自然地处理分组或聚类数据结构
- 为 meta 分析提供有原则的框架
- 通过完全贝叶斯分析正确量化不确定性

9. 下节预告

下一章我们将学习模型检查 (Model Checking), 这是贝叶斯数据分析中验证模型合理性的关键步骤。我们将讨论如何评估模型对数据的拟合程度, 以及如何识别模型的可能问题。

10. 习题

练习 5.1. 5.1 可交换性的判断 考虑以下情形，判断参数是否可交换，并解释你的推理：

- (1) J 个不同城市的气温测量，每个城市有多个观测值
- (2) J 个学生的考试分数，其中一些学生来自同一个学校
- (3) J 个医院的心脏手术成功率

练习 5.2. 5.2 收缩估计量的性质 在正态层次模型中，证明当 $\tau^2 \rightarrow 0$ 时，后验均值 $\hat{\theta}_j$ 收敛到公共均值 μ ；当 $\tau^2 \rightarrow \infty$ 时， $\hat{\theta}_j$ 收敛到原始数据均值 $\bar{y}_j$ 。

练习 5.3. 5.3 Beta-Binomial 层次模型 假设 $y_j | \theta_j \sim \text{Binomial}(n_j, \theta_j)$, $\theta_j | \alpha, \beta \sim \text{Beta}(\alpha, \beta)$ 。推导给定超参数 (α, β) 时 θ_j 的后验分布。

练习 5.4. 5.4 八学校模型的后验均值 在八学校例子中，使用分层模型推导第 j 所学校后验均值的表达式，并说明当 τ 增大和减小时，估计量如何变化。

练习 5.5. 5.5 固定效应 vs. 随机效应 解释在 meta 分析中，为什么随机效应模型通常比固定效应模型更合理。给出当研究间异质性很大时，两种方法可能给出不同结论的例子。

Part 2

贝叶斯数据分析基础

模型检查

1. 本章导论

在前几章中，我们学习了贝叶斯推断的核心工具——如何从先验和似然出发，计算后验分布，以及如何构建层次模型来合并来自不同来源的信息。然而，在实际应用中，一个关键问题始终萦绕着我们：**** 我们如何知道所选的模型是否合适？ ****

模型检查是贝叶斯数据分析中一个容易被忽视但至关重要的环节。在经典统计中，我们有各种拟合优度检验；在贝叶斯框架中，我们同样需要工具来评估模型与数据的契合程度。本章将介绍一种强有力的方法——**后验预测检查 (posterior predictive checking)**，它允许我们在贝叶斯框架内系统地评估模型。

我们将看到，模型检查不仅是验证模型是否合理，更是理解模型局限性、发现改进方向的重要途径。一个好的模型检查可以揭示数据中与模型假设不符的模式，从而引导我们改进模型或收集更多数据。

2. 后验预测检查的思想

2.1. 为什么需要模型检查？ 贝叶斯分析的最终目标不是找到一个“正确”的模型，而是找到一个**有用的模型**——一个能够捕捉数据关键特征、产生合理预测的模型。任何模型都是对现实的简化，因此模型检查的核心问题是：**模型与数据的契合程度是否足以满足我们的分析目的？**

考虑一个简单例子。假设我们拟合了一个正态模型 $y_i \sim N(\mu, \sigma^2)$ 到一组数据，但我们如何知道正态性假设是否合理？或者，当我们使用层次模型时，我们假设组内参数是可交换的——但数据是否支持这个假设？

这些问题的答案不能仅从模型内部获得，而需要我们主动将模型预测与实际数据进行比较。

2.2. 后验预测分布。 后验预测分布是模型检查的基础。给定观测数据 y ，未来或新数据 $\tilde{y}$ 的后验预测分布为：

$$p(\tilde{y}|y) = \int p(\tilde{y}|\theta)p(\theta|y) d\theta$$

这个分布整合了参数的不确定性，反映了给定当前数据后模型对未来的预测。

关键思想是：如果模型合理，那么**真实数据应该与后验预测分布一致**。换句话说，我们不应该期望观测数据是后验预测分布的异常值。

2.3. 后验预测检查的直觉。 后验预测检查的基本思路如下：

- (1) 从后验分布 $p(\theta|y)$ 中抽取参数值 θ^s
- (2) 给定每个 θ^s ，从似然模型 $p(\tilde{y}|\theta^s)$ 抽取伪数据 $\tilde{y}^s$
- (3) 比较真实的观测数据 y 与后验预测分布 $p(\tilde{y}|y)$

如果 y 落在后验预测分布的中心区域，模型与数据一致；如果 y 落在尾部，则模型可能存在问题。

例 6.1 (害虫治理研究). 这是一个来自农业研究的例子。研究者比较了八种害虫栖息地的治理效果。数据包括每栖息地昆虫数量的计数。

假设我们拟合了一个 Poisson 模型: $y_i \sim \text{Poisson}(\theta_i)$, 其中 θ_i 是栖息地 i 的期望昆虫数量。

通过后验预测检查, 我们可以:

- 对每个后验样本 θ^s , 生成伪数据 $\tilde{y}^s$
- 比较观测数据 y 与伪数据分布
- 检查是否存在异常大的观测值 (overdispersed data)

如果某些观测值在后验预测分布的尾部, 这可能表明存在过度离散 (overdispersion), 提示我们应该使用负二项分布或其他模型。

3. 验证统计量与模型检查量

3.1. 验证统计量. 验证统计量 (test quantity) 或模型检查量 (discrepancy measure) $T(y, \theta)$ 是将数据和参数映射到标量或向量的函数, 用于衡量模型与数据的某个特定方面。

常见的验证统计量包括:

- **样本均值:** $T(y, \theta) = \bar{y}$
- **样本方差:** $T(y, \theta) = s^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$
- **最大值:** $T(y, \theta) = \max(y_i)$
- **相关系数:** $T(y, \theta) = \text{corr}(y_i, y_j)$

在模型检查中, 我们比较 $T(y, \theta)$ 与其后验预测分布 $p(T(\tilde{y}, \theta)|y)$ 。

3.2. 后验预测 p 值. 后验预测 p 值是后验预测检查的正式化表述。对于验证统计量 T , 定义:

$$\text{p-value} = \Pr(T(\tilde{y}, \theta) \geq T(y, \theta)|y)$$

更精确地说, 在参数空间上计算:

$$\text{p-value} = \int \mathbb{I}(T(\tilde{y}, \theta^s) \geq T(y, \theta^s)) p(\theta^s|y) d\theta^s$$

其中 θ^s 是从后验分布抽取的样本。

解释: 后验预测 p 值度量的是, 在给定数据和模型下, 伪数据产生比观测数据更极端验证统计量的概率。如果这个概率很小 (例如小于 0.05), 则表明模型与数据在 T 这个方面不一致。

注 6.1. 后验预测 p 值与经典 p 值有本质区别。经典 p 值假设数据是随机化的, 而 ** 后验预测 p 值是条件于观测数据的 **, 反映的是模型对观测数据的拟合程度。

4. 模型检查的实践方法

4.1. 检查批量. 当模型包含多个组或多个观测时, 我们经常需要检查各个批量 (batch)。设 y_j 是第 j 个组的观测, θ_j 是对应参数。

批量特异性检查可以揭示模型在哪些方面存在问题:

- (1) **参数批量检查:** 对每个组 j , 计算 $T(\theta_j, \theta_{-j})$, 其中 θ_{-j} 表示除 j 以外的所有参数
- (2) **数据批量检查:** 对每个组 j , 计算验证统计量 $T(y_j, \theta)$, 然后比较 $T(y_j, \theta)$ 与其后验预测分布

例 6.2 (多组数据的批量检查). 考虑一个分层模型, J 所学校的学生成绩。每所学校有自己的真实效应 θ_j , 数据 y_j 是带有测量误差的估计。

批量检查可以帮助我们识别:

- 哪些学校的估计与模型预测差异最大
- 哪些学校的方差与层次模型假设不符
- 是否存在异常值学校

通过这种方法, 我们不仅检查整体模型拟合, 还可以定位具体问题所在。

4.2. 检查交互作用. 当模型包含变量之间的交互作用时, 检查交互作用是否与数据一致非常重要。

设我们有二元变量 z_i 和 w_i , 以及它们的交互作用 $z_i w_i$ 。一个常见的检查是验证交互作用是否在预测 y_i 中起到预期作用。

具体来说, 我们可以:

- (1) 在没有交互作用的模型下计算后验预测分布
- (2) 检查包含交互作用是否显著改善预测
- (3) 或者直接检查数据中交互作用模式是否与模型一致

5. 过度离散与计数数据的模型检查

5.1. 过度离散问题. 计数数据经常表现出比 Poisson 分布预测的更大的变异性, 这称为**过度离散 (overdispersion)**。

在 Poisson 模型中, 方差等于均值: $\text{var}(y) = \mathbb{E}(y)$ 。但实际数据通常表现出更大的方差。

5.2. 检测过度离散. 后验预测检查可以有效检测过度离散:

- (1) 计算观测数据的方差: $T(y, \theta) = \text{var}(y)$
- (2) 从后验预测分布生成伪数据 $\tilde{y}^s$
- (3) 计算每个 $\tilde{y}^s$ 的方差: $T(\tilde{y}^s, \theta^s)$
- (4) 比较观测方差与后验预测方差分布

如果观测方差在伪数据方差的尾部, 则表明存在过度离散。

例 6.3 (害虫数据的过度离散检查). 回到害虫治理研究。Poisson 模型假设方差等于均值。但如果数据存在过度离散, 观测方差将显著大于后验预测方差。

通过后验预测检查, 我们可以量化这种不一致程度。如果后验预测 p 值很小, 我们可以考虑使用负二项分布或零膨胀模型。

6. 外部数据验证

后验预测检查的一种重要扩展是使用外部数据验证。核心思想是: 如果模型是合理的, 它应该能够预测我们尚未看到的新数据。

设我们有两个相关的数据集 y_{old} 和 y_{new} 。我们可以:

- (1) 使用 y_{old} 拟合模型, 获得后验分布 $p(\theta|y_{\text{old}})$
- (2) 使用后验预测分布预测 y_{new} : $p(y_{\text{new}}|y_{\text{old}}) = \int p(y_{\text{new}}|\theta)p(\theta|y_{\text{old}}) d\theta$
- (3) 比较预测分布与实际观测的 y_{new}

这种方法在时间序列预测、跨研究汇总等场景中特别有用。

先验预测检查是另一种相关方法, 它在收集数据之前使用先验分布预测数据。这有助于:

- 检查先验分布的合理性
- 理解模型对数据的预期

- 发现模型中的潜在问题

7. 模型检查与其他推断的关系

7.1. 与模型选择的联系。模型检查是模型选择的前置步骤。在比较多个模型时，我们不仅应该比较它们的预测性能，还应该检查每个模型与数据的兼容性。

一个在训练集上表现良好但在检查中暴露问题的模型，可能存在过拟合或遗漏关键特征。

7.2. 与敏感性分析的联系。模型检查与敏感性分析有密切关系。当检查发现模型与数据不一致时，敏感性分析可以帮助我们理解这种不一致是否会影响我们的结论。

例如，如果后验预测检查表明存在过度离散，但我们关心的参数估计在不同的过度离散模型下保持稳定，那么模型的不完美可能不会影响我们的最终结论。

8. 模型检查的局限性

虽然后验预测检查是一种强有力的工具，但它也有局限性：

- (1) **检查量的选择：**我们只能检查我们想到的验证统计量。可能存在模型缺陷，但我们的检查量没有捕捉到。
- (2) **多重比较问题：**如果我们检查很多验证统计量，一些小的 p 值可能是偶然的。
- (3) **模型不确定性：**后验预测检查没有考虑模型本身的不确定性。
- (4) **先验敏感性：**检查结果可能对先验选择敏感。

注 6.2. 这些局限性并不意味着我们应该放弃模型检查，而是提醒我们：模型检查应该被视为一种**探索性工具**，而非最终裁决。它帮助我们理解模型的 strengths 和 weaknesses，但最终的数据分析和决策需要综合考虑多方面因素。

9. 从频率派角度理解后验预测检查

从频率派的视角，后验预测检查可以被理解为一种校准 (calibration) 方法。

如果模型是正确指定的，那么：

- 对于每个验证统计量 T ，后验预测 p 值在 $[0, 1]$ 上均匀分布
- 重复实验将产生均匀分布的 p 值

这种校准性质意味着，如果我们在许多不同数据集上进行后验预测检查， p 值应该均匀分布。如果 p 值系统性地偏向极端值（例如过多的小 p 值），则表明模型存在系统性问题。

从频率派视角看，后验预测检查可以被视为评估模型**校准性**的一种方法——模型是否正确地量化了不确定性。

10. 本章小结

本章我们学习了模型检查的核心概念和方法：

- (1) **模型检查的必要性：**任何模型都是对现实的简化，我们需要工具来评估模型与数据的契合程度
- (2) **后验预测检查的思想：**通过比较观测数据与模型对数据的预测来评估模型
- (3) **验证统计量与模型检查量：**用于衡量模型特定方面的函数
- (4) **后验预测 p 值：**量化模型与数据不一致程度的正式指标
- (5) **批量检查：**检查模型在不同数据子集上的表现
- (6) **过度离散检测：**使用后验预测方法检测计数数据的过度变异
- (7) **外部数据验证：**使用独立数据验证模型预测能力
- (8) **模型检查的局限性：**检查量选择、多重比较、模型不确定性等

(9) **频率派视角**：理解后验预测检查的校准性质

模型检查不是贝叶斯分析的可选附件，而是其核心组成部分。通过系统地检查模型，我们可以：

- 识别模型的不足之处
- 指导模型改进方向
- 加深对数据和模型的共同理解
- 在不确定性量化中保持诚实

11. 下节预告

下一章我们将学习**模型评估、比较与扩展** (Evaluating, Comparing, and Expanding Models)。在模型检查的基础上，我们将进一步探讨如何系统地比较不同模型的性能，以及如何在必要时扩展或修改模型。

模型评估、比较与扩展

1. 本章导论

在前几章中，我们学习了如何建立贝叶斯模型（分层模型）、如何进行后验推断，以及如何检查模型的拟合性（第六章）。但一个根本性问题仍然悬而未决：当我们有多个候选模型时，如何判断哪个更好？或者，当我们需要向模型中添加新变量或改变结构时，如何评估这些修改是否真的改进了预测能力？

这引出了本章的核心问题——**我们如何量化一个模型的预测表现？**

这个问题比表面上看起来要复杂得多。直觉上，我们可能会说“选择对数据拟合最好的模型”——但这恰恰是过拟合的根源。统计学家 George Box 有一句名言：“所有模型都是错误的，但有些是有用的。”评估一个模型的价值，不在于它是否能完美地描述训练数据，而在于它是否能**泛化**到新的、未见过的数据。

在本章中，我们将学习一套完整的工具来评估和比较贝叶斯模型的预测表现。这些方法的核心思想是：将数据分为训练集和验证集，用训练集拟合模型，用验证集评估预测表现。我们将看到，这一思想如何演进出交叉验证、WAIC（广泛适用信息准则）和贝叶斯模型平均等强大工具。

2. 预测准确性的度量

2.1. 点预测与分散度. 在讨论预测准确性之前，我们需要明确“预测”究竟意味着什么。考虑一个简单的场景：我们有一组新数据 $\tilde{y}$ ，需要预测它的值。

点预测是最直接的预测方式——给出一个单一数值 $\tilde{y}_{\text{pred}}$ 来代表我们的预测。但问题在于：什么样的数值是最好的预测？这取决于我们如何定义“最好”。

如果使用均方误差（MSE）作为损失函数，最优的点预测是后验均值：¹

$$\tilde{y}_{\text{pred}} = \mathbb{E}(\tilde{y}|y)$$

如果使用绝对误差损失，最优预测是中位数。但如果考虑**整个预测分布**的准确性——即我们不仅预测一个点，而且想量化整个预测分布的质量——则需要更精细的工具。

2.2. 对数预测密度. **对数预测密度（log predictive density）**是评估预测分布准确性的基本工具。对于新数据点 $\tilde{y}$ ，其对数预测密度定义为：

$$\log p(\tilde{y}|y) = \log \int p(\tilde{y}|\theta)p(\theta|y) d\theta$$

这个量度量了模型预测 $\tilde{y}$ 的能力——对数密度越高，说明模型对 $\tilde{y}$ 的预测越准确。

为什么使用对数而不是原始密度？因为对数变换将乘积变为求和，这在计算和理论分析中都更方便。

期望对数预测密度（ELPD）是对新数据上对数预测密度的期望：

$$\text{ELPD} = \mathbb{E}_{\tilde{y}}[\log p(\tilde{y}|y)]$$

¹推导见附录 ??

ELPD 是衡量模型预测表现的**黄金标准**——它度量了模型对未来数据的预期预测准确性。

例 7.1 (子女身高预测). 假设我们要预测一对夫妇的子女身高。模型 M_1 假设身高服从正态分布 $N(\mu, \sigma^2)$, 其中 μ 和 σ 有后验分布; 模型 M_2 假设身高服从 t 分布。

对数预测密度可以比较这两个模型: 如果 M_1 的 ELPD 高于 M_2 , 说明正态假设对身高分布的预测更准确。

2.3. 偏差与 DIC. 在实践中, 我们无法直接计算 ELPD (因为我们没有无限多的新数据)。一个实用的替代方案是使用**偏差 (deviance)**:

$$D(\theta) = -2 \log p(y|\theta)$$

偏差越小, 说明模型对观测数据的拟合越好。

一个相关概念是**偏差信息准则 (DIC)**:

$$\text{DIC} = \bar{D} + p_D$$

其中 $\bar{D} = \mathbb{E}[D(\theta)]$ 是后验平均偏差, $p_D = \bar{D} - D(\bar{\theta})$ 是有效参数个数。

有效参数个数 p_D 度量了模型的复杂度——它反映了后验分布中“信息”参数的数量。在过拟合时, p_D 会接近数据的数量; 在欠拟合时, p_D 会很小。

DIC 的局限: 它只在后验分布近似正态且数据量足够大时才可靠。

3. 交叉验证

3.1. 留一交叉验证 (LOO-CV). 既然 ELPD 衡量的是模型对新数据的预测能力, 一个自然的想法是: 用部分数据来拟合模型, 用另一部分数据来评估预测。

留一交叉验证 (Leave-One-Out Cross-Validation, LOO-CV) 是最极端的形式——每次留出一个数据点 y_i , 用其余 $n - 1$ 个数据点拟合模型, 然后预测 y_i 。

LOO-CV 的对数预测密度为:

$$\text{lppd}_{\text{loo}} = \sum_{i=1}^n \log p(y_i | y_{-i})$$

其中 y_{-i} 表示除 i 以外的所有数据。

这个量的计算代价很高——需要拟合 n 次模型。但对于共轭模型或可解析边缘化的模型, 存在计算技巧。²

3.2. K 折交叉验证. 当 n 很大时, LOO-CV 的计算成本变得不可接受。**K 折交叉验证** 是一种折中方案:

- (1) 将数据随机分为 K 个大小相等的组
- (2) 对于 $k = 1, \dots, K$:
 - 用除第 k 组以外的所有数据拟合模型
 - 用第 k 组数据计算预测密度
- (3) 汇总 K 次的结果得到总体评估

常见的 K 值有 5 和 10。 K 越小, 计算越快但估计方差越大; K 越大, 估计越稳定但计算成本增加。

当 $K = n$ 时, K 折 CV 退化为 LOO-CV。

²推导见附录 ??

注 7.1. 交叉验证的一个关键假设是：数据的**可交换性**。如果数据有内部结构（如时间序列、分层数据），简单的交叉验证可能会给出误导性的结果。在这种情况下，需要使用**分层交叉验证**或考虑数据收集设计的影响。

4. WAIC：广泛适用信息准则

4.1. WAIC 的定义. DIC 虽然常用，但它有一些理论缺陷——特别是它依赖于后验分布的近似正态性。**WAIC (Widely Applicable Information Criterion)** 是一种更一般化的准则，可以在任意贝叶斯模型中使用。³

WAIC 基于两个量：

对数预测密度的点估计 (pointwise log predictive density)：

$$\text{lppd} = \sum_{i=1}^n \log \mathbb{E}[p(y_i|\theta)]$$

这等价于用后验均值代替后验分布进行预测。

有效参数个数 (effective number of parameters)：

$$p_{\text{waic}} = \sum_{i=1}^n \text{var}_{\text{post}}[\log p(y_i|\theta)]$$

这个量度量了每个数据点对后验分布的贡献程度。

WAIC 定义为：

$$\text{WAIC} = -2(\text{lppd} - p_{\text{waic}})$$

或者从 ELPD 的角度：

$$\text{ELPD}_{\text{waic}} = \text{lppd} - p_{\text{waic}}$$

4.2. WAIC 与 DIC 的比较. 当后验分布近似正态时，WAIC 近似于 DIC。但 WAIC 有几个优势：

- (1) **计算更一般：** WAIC 不需要后验分布的解析近似
- (2) **点估计：** WAIC 可以逐点计算，便于诊断
- (3) **理论基础更扎实：** WAIC 与交叉验证有更紧密的联系

例 7.2 (WAIC vs DIC). 在非线性回归模型中，后验分布通常是高度非正态的。DIC 的正态假设会失效，但 WAIC 仍然可靠。

在混合模型中，DIC 的有效参数个数定义模糊，而 WAIC 的逐点计算可以正确处理这种复杂性。

5. 后验预测检验

我们在第六章已经接触过**后验预测检验 (Posterior Predictive Checking, PPC)** 的基本思想。本节我们将更系统地讨论如何在模型比较中使用 PPC。

5.1. 复制数据与预测数据. 给定后验分布 $p(\theta|y)$ ，我们可以：

- **复制数据：** 从 $p(\tilde{y}|\theta)$ 生成 $\tilde{y}^{\text{rep}}$ ，这代表如果模型正确，数据的“复制版本”应该是什么样的
- **预测数据：** 从 $p(\tilde{y}|y)$ 生成 $\tilde{y}^{\text{new}}$ ，这代表模型对未来数据的预测

两者的区别在于： $\tilde{y}^{\text{rep}}$ 用于检验模型拟合， $\tilde{y}^{\text{new}}$ 用于预测。

³WAIC 的完整推导见附录 ??

5.2. 差异度量. 为了量化观测数据与模型预测之间的差异，我们需要定义一个差异度量 (discrepancy measure):

$$T(y, \theta) = \text{某个反映模型假设的统计量}$$

常用的差异度量包括:

- **均值差异:** $\bar{y} - \mathbb{E}[\tilde{y}^{\text{rep}}|\theta]$
- **方差差异:** $\text{var}(y) - \text{var}(\tilde{y}^{\text{rep}}|\theta)$
- **最大值:** $\max(y) - \max(\tilde{y}^{\text{rep}}|\theta)$

对于每个差异度量 T ，我们可以计算:

$$\text{p-value} = \mathbb{P}(T(\tilde{y}^{\text{rep}}, \theta) \geq T(y, \theta) | y)$$

如果这个 p 值接近 0 或 1，说明模型预测与数据之间存在系统性差异，模型可能需要改进。

注 7.2. 后验预测 p 值不是严格的概率，而是反映模型拟合程度的一个指标。当样本量很大时，即使偏离很小，p 值也会变得显著——这提醒我们统计显著性不等于实际重要性。

6. 分层数据与交叉验证

在分层或聚类数据结构中，简单的交叉验证可能会产生误导性的结果。

6.1. 分组交叉验证. 考虑一个分层模型：数据来自 J 个组，每组内有 n_j 个观测。简单的留一交叉验证会:

- (1) 随机留出一个观测点
- (2) 用剩余数据拟合模型
- (3) 预测被留出的观测

但这样做的问题在于：来自同一组的观测是相关的。如果我们随机留出，一些组会被完全保留，另一些组会被部分保留，这导致训练集和测试集的分布不一致。

分组交叉验证 (Group-based CV) 的解决方案是：每次留出一个完整的组，而不是单个观测点。这样保持了组的完整性。

当 K 折分组交叉验证中 K 等于组数 J 时，就变成了**留一组交叉验证 (Leave-One-Group-Out CV)**。

例 7.3 (学校成绩预测). 假设我们要预测学生考试成绩，数据来自多所学校。使用简单交叉验证可能导致：训练集中包含某学校的大部分学生，但测试集中只有该校的少数学生——这违反了数据独立性的假设。

使用分组交叉验证，每次留出一整所学校，这样才能正确评估模型的跨学校泛化能力。

7. 贝叶斯模型平均

当我们有多个候选模型时，**贝叶斯模型平均 (Bayesian Model Averaging, BMA)** 提供了一种 principled 的方法来组合它们的预测。

7.1. BMA 的思想. 给定 K 个候选模型 $M_1, \dots, M_K$ ，每个模型有后验概率 $p(M_k|y)$ 。贝叶斯模型平均的预测分布为:

$$p(\tilde{y}|y) = \sum_{k=1}^K p(\tilde{y}|y, M_k) p(M_k|y)$$

即：每个模型的预测按其 后验概率 加权平均。

后验概率 $p(M_k|y)$ 可以通过边际似然计算：

$$p(M_k|y) \propto p(y|M_k)p(M_k)$$

其中 $p(y|M_k) = \int p(y|\theta_k, M_k)p(\theta_k|M_k) d\theta_k$ 是模型 M_k 的边际似然。

7.2. BMA 的优势. 贝叶斯模型平均有几个重要优势：

- (1) **自动正则化**：复杂模型通常有更低的边际似然（因为它们对数据的拟合更差）
- (2) **不确定性量化**：BMA 的预测分布反映了模型选择的不确定性
- (3) **防止过拟合**：单一模型的过拟合风险被分散到多个模型上

但 BMA 也有局限：当候选模型都很差时，加权平均可能仍然表现不佳。此外，边际似然的计算在高维模型中可能很困难。

注 7.3. 在实践中，BMA 最适合的情况是：候选模型捕捉了数据的不同方面，而真实数据生成过程接近其中某个模型。如果所有模型都系统性错误，BMA 无法纠正这个根本问题。

8. 信息准则的统一视角

从前几节的讨论中，我们可以看到不同准则之间的联系：

偏差 $D(\theta) = -2 \log p(y|\theta)$ 是基本量。

DIC 使用后验均值近似：

$$\text{DIC} \approx -2\mathbb{E}[\log p(y|\theta)] + 2\text{var}[\log p(y|\theta)]$$

WAIC 使用更精确的点估计：

$$\text{WAIC} = -2 \left(\sum_i \log \mathbb{E}[p(y_i|\theta)] - \sum_i \text{var}[\log p(y_i|\theta)] \right)$$

交叉验证本质上是对新数据的 ELPD 的估计，但计算更直接。

这些准则都是对同一核心量——模型对未来数据的预测能力——的不同估计。

9. Stan 实现

本节展示如何在 Stan 中实现本章讨论的模型比较方法。

9.1. 计算对数预测密度. Stan 提供了 `lppd` 函数来计算点态对数预测密度：

```
model {
  // ... standard model spec ...
  for (i in 1:n) {
    log_lik[i] = log(p(y[i] | theta));
  }
}

generated quantities {
  // compute WAIC components
  vector[n] log_lik;
  for (i in 1:n) {
    log_lik[i] = log(p(y[i] | theta));
  }
}
```

9.2. 分层交叉验证的 Stan 实现. 对于分层模型, Stan 可以并行计算各组的预测:

```
data {
  int<lower=1> J;           // number of groups
  int<lower=1> N;           // total observations
  array[N] int<lower=1> group; // group indicator
  vector[N] y;             // observations
}
parameters {
  vector[J] theta;         // group means
  real<lower=0> sigma;      // common variance
  real mu;                 // grand mean
  real<lower=0> tau;        // between-group SD
}
model {
  theta ~ normal(mu, tau);
  y ~ normal(theta[group], sigma);
}
generated quantities {
  vector[N] log_lik;
  for (i in 1:N) {
    log_lik[i] = normal_lpdf(y[i] | theta[group[i]], sigma);
  }
}
```

10. 本章小结

本章我们学习了评估和比较贝叶斯模型预测表现的核心方法:

- (1) **预测准确性的度量**: 对数预测密度、ELPD、偏差和 DIC
- (2) **交叉验证**: LOO-CV 和 K 折 CV, 以及处理分层数据的分组交叉验证
- (3) **WAIC**: 一种比 DIC 更一般化的信息准则, 与交叉验证有紧密联系
- (4) **后验预测检验**: 通过差异度量评估模型拟合
- (5) **贝叶斯模型平均**: 组合多个模型预测的 principled 方法
- (6) **Stan 实现**: 计算对数预测密度和实现分层交叉验证

这些工具共同构成了一套完整的模型评估体系。关键思想是: **模型的价值在于其泛化能力, 而非对训练数据的拟合程度**。交叉验证和 WAIC 提供了估计泛化能力的实用方法, 而 BMA 则在模型不确定时提供了更稳健的预测。

11. 下节预告

下一章我们将学习**建模与数据收集过程的关系** (第八章)。我们将探讨如何根据数据的收集方式调整建模策略, 包括抽样设计对推断的影响、处理缺失数据的贝叶斯方法, 以及如何将领域知识整合到模型中。

12. 习题

练习 7.1. ?? 对数预测密度的计算 假设数据 $y_1, \dots, y_n$ 来自正态分布 $N(\mu, \sigma^2)$, 其中 σ 已知。给定共轭先验 $\mu \sim N(\mu_0, \sigma_0^2)$, 推导后验预测分布 $p(\tilde{y}|y)$ 的对数密度表达式。

练习 7.2. ?? DIC 的有效参数个数 证明在正态模型 $y_i \sim N(\theta, \sigma^2)$ (σ 已知) 中, DIC 的有效参数个数 p_D 等于 1。

练习 7.3. ?? LOO-CV 与 WAIC 的比较 考虑二项数据 $y_i \sim \text{Bin}(n_i, \theta_i)$, 使用层次模型 $\theta_i \sim \text{Beta}(\alpha, \beta)$ 。讨论:

- (1) 为什么 LOO-CV 在这个模型中计算困难?
- (2) WAIC 如何处理这个问题?
- (3) 在什么条件下两者会给出相似的结果?

练习 7.4. ?? 分组交叉验证 在一个三水平的层次模型中 (学生嵌套于班级, 班级嵌套于学校), 说明:

- (1) 为什么简单的留一交叉验证不合适?
- (2) 如何设计分组交叉验证?
- (3) 选择留出学校 vs 留出班级有什么影响?

练习 7.5. ?? 贝叶斯模型平均 给定两个候选模型 M_1 和 M_2 的边际似然比 $p(y|M_1)/p(y|M_2) = 10$, 解释这意味着什么。如果两个模型的预测分布差异很大, BMA 的结果会如何?

练习 7.6. ?? WAIC 的性质 证明 WAIC 的有效参数个数 p_{waic} 总是介于 0 和 n 之间, 其中 n 是样本量。

考虑数据收集过程的建模

1. 本章导论

在前几章的贝叶斯分析中，我们默认数据已收集完毕，直接对观测值建模。然而在实践中，**数据收集方式**对推断的正确性至关重要。不同的抽样设计、实验设计、缺失数据机制都可能导致相同的观测值携带不同的信息量。

本章的核心问题是：如何在贝叶斯推断中正确地考虑数据收集过程？这一问题的答案涉及一个看似矛盾的现象——天真的学生可能会认为，既然贝叶斯推断只依赖于后验分布 $p(\theta|y)$ ，数据如何收集无关紧要。这种对似然原则的误用忽视了一个关键事实：“**观测数据**”的完整定义必须包含这些数据如何产生的全部信息。

2. 观测数据与缺失数据的普遍范式

这三个骰子场景的例子揭示了一个关键洞察：**相同的观测数据可以来自根本不同的数据生成过程**。为了系统地推理这类情况，我们需要一个统一的框架——将数据收集过程形式化为“完整数据”与“观测数据”之间的关系。

核心思想：

核心思想：将数据收集过程视为从“完整数据”（或潜在数据） y 中观测到部分数据，留下缺失数据 y_{mis} 的过程。记 $y = (y_1, \dots, y_N)$ 为完整数据矩阵， $I = (I_1, \dots, I_N)$ 为观测指示矩阵，其中 $I_{ij} = 1$ 表示 y_{ij} 被观测， $I_{ij} = 0$ 表示缺失。

例 8.1 (骰子实验). 假设我们告诉你掷了十次骰子且全部为 6。你的态度会因以下三种说法而大不相同：

- (1) 这十次是我们做的全部掷骰；
- (2) 我们掷了 60 次但只报告了其中出现 6 的十次；
- (3) 我们预先决定诚实报告出现十次 6，但隐瞒了总共掷了多少次——为此等待了 500 次。

在情形 (i) 中， $p(y|\theta) = (1/6)^{10}$ ；在情形 (ii) 中，报告规则本身改变了分布；在情形 (iii) 中，等待时间提供了额外信息。这说明：**观测数据的分布不同于产生它们的“完整数据”的分布**。

1

3. 数据收集模型与可忽略性

3.1. 观测数据和缺失数据的记号. 设 $y = (y_1, \dots, y_N)$ 为潜在数据矩阵（每个 y_i 可能本身是向量）， I 为同样维数的指示矩阵。记 y_{obs} 和 y_{mis} 分别为观测和缺失的数据部分。

稳定性假设 (stable unit treatment value assumption)：记录的测量过程不改变数据本身的价值——即完整数据向量 y 不受包含向量 I 的影响。

¹详见 [?, Chapter 8]。

3.2. 数据模型、包含模型与完全/观测数据似然. 将联合概率模型分解为两部分：

- (1) 完整数据的模型 $p(y|\theta)$;
- (2) 包含向量的模型 $p(I|y, \phi)$ 。

完全数据似然为：

$$(1) \quad p(y, I|\theta, \phi) = p(y|\theta) \cdot p(I|y, \phi).$$

实际可用的信息是 (y_{obs}, I) ，因此贝叶斯推断的适当似然（**观测数据似然**）为：

$$(2) \quad p(y_{\text{obs}}, I|\theta, \phi) = \int p(y, I|\theta, \phi) dy_{\text{mis}}.$$

给定 (x, y_{obs}, I) 的联合后验分布为：

$$(3) \quad p(\theta, \phi|x, y_{\text{obs}}, I) \propto p(\theta, \phi|x) \int p(y|x, \theta)p(I|x, y, \phi) dy_{\text{mis}}.$$

3.3. 有限总体与超总体推断. 本章区分两类目标量：

- **有限总体量** (finite-population estimands)：如总体均值 $\bar{y}$ ，在抽样调查中可预测但未观测；
- **超总体量** (superpopulation estimands)：如参数 θ ，是产生数据的分布特征。

有限总体量 $\bar{y}$ 的后验分布可以通过从后验预测分布 $p(y_{\text{mis}}|x, y_{\text{obs}}, I)$ 模拟缺失数据得到。

3.4. 可忽略性. 如果决定忽略数据收集过程，可以只对 y_{obs} 条件化计算后验：

$$(4) \quad p(\theta|x, y_{\text{obs}}) \propto p(\theta|x) \int p(y|x, \theta) dy_{\text{mis}}.$$

当缺失数据模式不提供额外信息——即 $p(\theta|x, y_{\text{obs}}) = p(\theta|x, y_{\text{obs}}, I)$ ——时，研究设计称为**可忽略的** (ignorable)。

可忽略性的两个充分条件：

- (1) **随机缺失** (Missing at Random)： $p(I|x, y, \phi) = p(I|x, y_{\text{obs}}, \phi)$ ——即给定 ϕ 和 (x, y_{obs}) ，缺失性只依赖已观测部分；
- (2) **独立参数** (Distinct Parameters)： $p(\phi|x, \theta) = p(\phi|x)$ ——即缺失数据过程的参数与数据生成过程的参数在先验中独立。

注 8.1. 这两个条件的组合确保了 $p(\theta|x, y_{\text{obs}}) = p(\theta|x, y_{\text{obs}}, I)$ ，从而使缺失数据机制可忽略。

3.5. 设计分类. 根据可忽略性和机制是否已知，可以将数据收集设计分为以下几类：

这个分类对实践有直接指导意义：**类型 1-4 只需建模 $p(y|\theta)$ ，而类型 5-6 必须显式建模缺失数据机制**。随着类型编号增大，分析的复杂度和模型敏感性也随之增加。

- (1) **可忽略且已知（无协变量）**：如简单随机抽样、完全随机化实验。只需考虑 $p(y|\theta)$ 和 $p(\theta)$ ；
- (2) **可忽略且已知（给定协变量）**：如分层抽样、区组随机实验。需要建模 $p(y|x, \theta)$ 使设计可忽略；
- (3) **强可忽略且已知**： $p(I|x, y, \phi) = p(I|x)$ ，依赖性仅通过完全观测的协变量 x 介导；
- (4) **可忽略但未知**：如基于完全观测协变量的非随机指派实验。倾向性得分 (propensity score) 在此有用；
- (5) **不可忽略且已知**：如删失数据。需要将缺失机制明确建模；
- (6) **不可忽略且未知**：最困难的情况，如因果推断中的选择偏差。

3.6. 倾向性得分. 在强可忽略设计中, 单元级指派概率 $\Pr(I_i = 1|x_i) = \pi_i$ 称为**倾向性得分** (propensity score)。倾向性得分可以充分概括协变量 X , 使指派机制在给定倾向性得分时强可忽略。

重要警告: 倾向性得分本身永远不足以进行后验预测检验 (模型检查的关键工具), 因为不同设计可能产生相同的倾向性得分。

4. 抽样调查

考虑一个包含 N 个人的有限总体, y_i 为第 i 个人的每周食品支出。目标是估计总体平均支出 $\bar{y}$ 。由于全面调查成本过高, 采用简单随机抽样抽取 n 个样本。

4.1. 简单随机抽样. 设 I_i 为第 i 个人是否被抽中的指示变量。简单随机抽样定义为:

$$(5) \quad p(I|y, \phi) = p(I) = \begin{cases} \binom{N}{n}^{-1} & \text{若 } \sum_{i=1}^N I_i = n, \\ 0 & \text{其他情形。} \end{cases}$$

这是强可忽略且已知的设计——指派概率 (倾向性得分) 为 $\pi_i = n/N$ 对所有单元相同。

有限总体均值的贝叶斯推断: 将 $\bar{y}$ 分解为已观测和未观测部分:

$$(6) \quad \bar{y} = \frac{n}{N} \bar{y}_{\text{obs}} + \frac{N-n}{N} \bar{y}_{\text{mis}}.$$

其中 $\bar{y}_{\text{obs}}$ 已知, $\bar{y}_{\text{mis}}$ 可从后验预测分布模拟。

大样本近似: 当 n 和 $N-n$ 都较大时,

$$(7) \quad \bar{y}|y_{\text{obs}} \approx N\left(\bar{y}_{\text{obs}}, \left(\frac{1}{n} - \frac{1}{N}\right) s_{\text{obs}}^2\right).$$

这就是有限总体抽样推断的正态理论的正式贝叶斯 justification。

4.2. 分层抽样. 在分层随机抽样中, 将 N 个单元分为 J 层, 从每层 j 中用简单随机抽样抽取 n_j 个样本。给定层指示变量 x_j , 此设计是可忽略的。

贝叶斯分析: 在每层内建模 y_i 的分布为参数 θ_j , 然后对所有参数集 $\theta_1, \dots, \theta_J$ 执行贝叶斯推断。通常对 θ_j 指定层次模型, 类似于第 5 章中的方法。

例 8.2 (选前民意调查的分层抽样分析). 1988 年美国总统选举的 CBS 调查将受访者按地区 (东北、中西部、南部、西部) 和居住密度分为 16 层。数据列于表 8.2。

对每层 j , 设 $y_{\text{obs}j} = (y_{\text{obs}1j}, y_{\text{obs}2j}, y_{\text{obs}3j})$ 为支持布什、杜卡基斯和无意见的人数, 建模为多项分布 $y_{\text{obs}j} \sim \text{Multinomial}(n_j; \theta_{1j}, \theta_{2j}, \theta_{3j})$ 。

非层次模型: 各层参数赋予独立的 Dirichlet 先验, 简单但未利用层间相似性;

层次模型: 将参数转换为 logit 尺度, 建模为跨层可交换的二元正态分布。层次模型产生的后验中位数为 0.11, 比非层次模型的 0.097 更集中于真实值。

²选举调查例子的完整推导见附录 ??。

4.3. 整群抽样. 在整群抽样中, 首先抽取 J 个群, 然后从每个抽中群 j 中抽取 n_j 个单元。分析需要为聚类的每个水平包含参数——这是一个层次建模问题。

例 8.3 (澳大利亚学童调查). 为估计墨尔本地区步行上学儿童的比例, 首先从该都市区抽取 72 所学校, 然后从每所学校的两个随机班级进行调查。

模型包含学生、班级和学校三层参数:

$$(8) \quad \bar{y}_{.jk} \sim N(\theta_{jk}, \sigma_{jk}^2), \quad \sigma_{jk}^2 = \bar{y}_{.jk}(1 - \bar{y}_{.jk})/N_{jk}$$

$$(9) \quad \theta_{jk} \sim N(\theta_k, \tau_{\text{class}}^2)$$

$$(10) \quad \theta_k \sim N(\alpha + \beta M_k, \tau_{\text{school}}^2)$$

其中 M_k 为学校 k 的班级数。将班级数纳入学校级模型是因为调查的抽样概率依赖于学校规模 M_k ——设计只有在对包含 M_k 的模型才是可忽略的。

3

5. 设计实验

在统计术语中, 实验涉及将处理指派给单元, 指派过程由实验者控制。设 (y_i^A, y_i^B) 为第 i 个单元接受处理 A 或 B 的潜在结果, $i = 1, \dots, n$ 。

稳定性假设: 应用于任何单元的处理对其余单元的结果没有影响。

因果效应分为两类:

- **超总体框架:** 平均因果效应为 $E(y_i^A - y_i^B | \theta)$;
- **有限总体框架:** 有限总体因果效应为 $\bar{y}^A - \bar{y}^B$ 。

5.1. 完全随机化实验. 在完全随机化实验中, 处理指派是可忽略的。可以分别对两组数据建模:

$$(11) \quad p(y_{\text{obs}} | \theta) = \prod_{i: I_i = (1,0)} p(y_i^A | \theta) \prod_{i: I_i = (0,1)} p(y_i^B | \theta).$$

有限总体因果效应的大样本近似:

$$(12) \quad (\bar{y}^A - \bar{y}^B) | y_{\text{obs}} \approx N \left(\bar{y}_{\text{obs}}^A - \bar{y}_{\text{obs}}^B, \frac{2}{n} (s_{\text{obs}}^{2A} + s_{\text{obs}}^{2B}) \right).$$

5.2. 随机区组、拉丁方等. 更复杂的设计可以基于处理指派过程中使用的所有因素建模, 在模型下设计是可忽略的。

例 8.4 (拉丁方实验). 一个农业实验有 25 个小区和五种处理 (A、B、C、D、E), 排列成拉丁方形式 (表 8.4)。

可忽略设计所需的最小信息是 25 个小区的物理位置编码 x (水平和垂直坐标)。任何可忽略模型必须具有 $p(y|x, \theta)$ 的形式。

如果额外信息可用 (如流经田地的溪流位置), 也应纳入分析。

4

6. 敏感性与随机化的作用

我们已经看到, 可忽略设计通过允许直接建模观测数据来简化贝叶斯分析。但随机化在此图景中扮演什么角色?

³整群抽样的完整推导见附录 ??。

⁴拉丁方实验的完整分析见附录 ??。

6.1. 完全随机化. 在没有完全观测协变量 x 的情况下, 实现可忽略设计的唯一方法(排除所有单元获得同一处理的退化设计)是**随机化**。

然而, 对于任何给定的推断目标, 某些可忽略设计在其他设计中更优——在产生关于目标量的更精确推断方面。完全随机化比独立伯努利指派产生更高的后验精度估计(因为期望每组有相等的样本量)。

6.2. 协变量条件下的随机化. 当有完全观测协变量时, 随机化设计与确定性可忽略设计竞争。随机化的潜在优势包括:

- (1) 即使假装 x 未知, 分析仍然有效;
- (2) 观察到 x 后可以更新后验分布, 产生更精确的条件推断;
- (3) 增加后验预测检验的灵活性;
- (4) 使实验者更难通过选择样本或处理指派来“作弊”。

7. 观测研究

在观测性研究中, 处理是被观察而非被实验者指派的。各处理组可能在未测量的因素上存在很大差异。

关键问题: 如何确保因果推断的有效性? Gelman 等人指出, 良好的观测研究需要: (1) 充分控制各处理组间的背景差异; (2) 每组有足够的独立单元产生可靠结果; (3) 研究设计不依赖于分析结果; (4) 最小化流失和其他形式的无意缺失数据; (5) 分析考虑设计中使用的信息。

图 8.2 说明了数据收集的不平衡与对建模假设敏感性的联系。当两组在预处理协变量上相似时(如随机实验), 处理效应估计对所拟合的 $y|x$ 模型形式相对不敏感。当不平衡严重时, 相同数据可以用完全不同的非线性关系拟合, 产生完全不同的处理效应估计。

7.1. 倾向性得分在观测研究中的作用. 倾向性得分是处理指派的概率(作为协变量的函数)。它可用于诊断——如果估计的倾向性得分在两种处理条件下几乎没有重叠, 则暗示推断可能对模型形式高度敏感。

7.2. 主分层. 主分层 (principal stratification) 是一种调整“中间结果”的方法——即在最终结果 y 的因果路径上的中间变量 C 。

例 8.5 (有依从性问题的随机实验). 在印度尼西亚村庄进行的维生素 A 补充剂对婴儿死亡率影响的随机实验中, 维生素 A 仅提供给被分配接受它的人。这里 I 是分配指标, 中间结果是依从性。

定义两种主分层: **依从者** (如果被分配则服用) 和 **非依从者** (如果被分配也不服用)。

依从者平均因果效应 (CACE) 的估计:

$$(13) \quad \widehat{\text{CACE}} = (\bar{y}_1 - \bar{y}_0) / \hat{p}_c,$$

其中 p_c 为依从者比例。这被称为**工具变量估计**。

5

8. 删失与截断

我们通过一个简单例子的多种变体来说明不同的缺失数据机制。

设定: 对某物体进行 $N = 100$ 次称重, $y_i \sim N(\theta, 1)$, 先验 $p(\theta) \propto 1$ 。每种变体下只观测到 $n = 91$ 个值, 记 $\bar{y}_{\text{obs}}$ 为已观测测量的均值。

⁵工具变量方法和贝叶斯因果推断的完整讨论见附录 ??。

8.1. 完全随机缺失 (MCAR). 如果天平等概率 0.1 随机未报告, 则包含模型为 $I_i \sim \text{Bernoulli}(0.9)$, 且与 y 独立。后验分布与预先固定样本量 $n = 91$ 的情形相同:

$$(14) \quad p(\theta|y_{\text{obs}}, I) = N(\theta|\bar{y}_{\text{obs}}, 1/91).$$

8.2. 完全随机缺失但缺失概率未知. 当天平随机失败概率 π 未知时, 如果 θ 和 π 在先验中独立 (即“独立参数”条件), 后验推断与上一情形相同。但如果 $\pi = \theta/(1 + \theta)$ (两者不独立), 则 $n = 91$ 提供了关于 θ 的额外信息。

8.3. 删失数据. 如果天平的报告上限为 200kg——所有超过 200kg 的值被报告为“太重”——则 $n = 91$ 个数值测量的贡献是正态密度, 9 个“太重”测量的贡献形式为 $\Phi(\theta - 200)$ 。后验分布为:

$$(15) \quad p(\theta|y_{\text{obs}}, I) \propto N(\theta|\bar{y}_{\text{obs}}, 1/91) \cdot [\Phi(\theta - 200)]^9.$$

关键: 删失数据的似然不能简单地忽略指示向量, 必须包含删失观测的贡献 $[\Phi(\theta - 200)]^9$ 。

8.4. 未知删失点的删失数据. 当删失点 ϕ 本身未知时, 后验分布必须同时考虑 (θ, ϕ) 。9 个删失测量贡献 $[\Phi(\theta - \phi)]^9$, 即使先验中 θ 和 ϕ 独立, 后验中也会产生依赖——这说明缺失数据机制不可忽略。

8.5. 截断数据. 截断与删失的关键区别在于: 删失知道超过截断点的观测数量, 而截断不知道。当 N 也未知时, 后验分布涉及对 N 的推断。

9. 本章小结

本章我们学习了:

- (1) 数据收集过程必须纳入贝叶斯模型的核心概念
- (2) 观测数据与缺失数据的普遍记号框架
- (3) 可忽略性的两个充分条件: 随机缺失 (MAR) + 独立参数
- (4) 有限总体推断与超总体推断的区别
- (5) 倾向性得分的概念与局限
- (6) 抽样调查的贝叶斯分析: 简单随机抽样、分层抽样、整群抽样
- (7) 设计实验的贝叶斯分析: 完全随机化、区组设计、拉丁方
- (8) 随机化在降低模型敏感性中的作用
- (9) 观测研究的挑战与敏感性分析
- (10) 主分层与因果推断中的依从性
- (11) 删失与截断数据的建模

10. 下节预告

下一章我们将学习决策分析 (Chapter 9), 探讨贝叶斯决策理论在不同情境中的应用, 包括回归预测的激励措施、多阶段决策制定和个体与机构决策分析。

CHAPTER 9

决策分析

1. 本章导论

在前面几章中，我们探讨了贝叶斯推断的核心技术：从先验分布和似然函数出发，通过贝叶斯公式计算后验分布，并利用后验分布进行点估计、区间估计和模型检查。然而，推断本身并不是终点——我们需要将推断的结论转化为实际行动决策。

一个自然的问题是：给定后验分布，我们如何做出最优决策？这个问题看似简单，实则涉及一个根本性的概念飞跃：**推断是描述性的，而决策是规范性的**。描述性任务只需要刻画未知参数的不确定性，而规范性任务需要明确我们追求的目标是什么，以及不同决策的相对优劣。

决策分析 (decision analysis) 正是连接推断与决策的桥梁。这一理论框架由 Wald (1950)、Savage (1954)、Raiffa 和 Schlaifer (1961) 等人在 20 世纪中叶发展起来。Wald (1950) 将统计推断形式化为一场“与自然的博弈”，通过引入风险函数和极小极大原则为决策理论奠定了公理基础；Savage (1954) 则从主观期望效用角度出发，证明了在合理 axioms 下理性决策者必然遵循贝叶斯原则；Raiffa 和 Schlaifer (1961) 进一步将这一理论系统化，使之成为处理实际决策问题的有力工具。贝叶斯版本的决策理论进一步要求，在计算期望效用时，使用后验分布来量化不确定性。

本章的安排如下：§9.1 引入效用函数与损失函数的基本概念；§9.2 讨论几种常见的损失函数及其对应的贝叶斯最优决策；§9.3 探讨后验预测分布与预验分析 (preposterior analysis)；§9.4 处理层次决策问题与经验贝叶斯的联系；§9.5 从损失函数角度重新审视模型选择问题。

2. 效用函数与损失函数

2.1. 从推断到决策的桥梁. 在贝叶斯框架下，每个决策 d 带来一个后果 (consequence)，记为 $C(d, \theta)$ ，其中 θ 是自然状态 (state of nature) ——即我们关心的未知参数或潜在结果。后果可以是金钱、健康、时间等不同维度。

为了比较不同决策的优劣，我们需要一个**效用函数** (utility function) $u(c)$ ，它将每个后果映射到一个实数 $u(c) \in \mathbb{R}$ 。理性决策者偏好效用更高的后果。

在很多情况下，直接定义效用函数比较困难。我们通常转而使用**损失函数** (loss function) $\ell(\theta, d)$ ，定义为采取决策 d 而真实参数为 θ 时的损失。损失函数与效用函数之间的关系是： $u(c) = -\ell(\theta, d)$ (在基数效用意义下，效用的增减与损失的增减相反)。

例 9.1 (医学治疗决策). 考虑一个简化的医学决策问题：医生需要决定是否对患者进行某种手术。真实参数 θ 代表手术的实际成功率。设损失函数为

$$\ell(\theta, d) = \begin{cases} 0 & \text{若 } d = \text{做手术且成功} \\ 1 \cdot L_{\text{fail}} & \text{若 } d = \text{做手术且失败} \\ 0.5 \cdot L_{\text{conservative}} & \text{若 } d = \text{不做手术,} \end{cases}$$

其中 L_{fail} 和 $L_{\text{conservative}}$ 是根据具体情况设定的损失权重。这里“不做手术”被视为一种保守决策，当手术失败后果严重时给予较大的损失权重。

2.2. 期望后验损失与贝叶斯最优决策. 给定损失函数 $\ell(\theta, d)$ 和后验分布 $p(\theta | y)$, 决策 d 的期望后验损失 (posterior expected loss) 为

$$\rho(d | y) = \mathbb{E}_{p(\theta|y)}[\ell(\theta, d)] = \int \ell(\theta, d) p(\theta | y) d\theta.$$

贝叶斯最优决策 d^{Bayes} 是使期望后验损失最小化的决策:

$$d^{\text{Bayes}} = \arg \min_{d \in \mathcal{D}} \rho(d | y).$$

关键洞察: 后验分布综合了先验信息与数据信息, 因此”最小化期望后验损失”这一原则自然地将推断与决策统一起来——推断的结论 (后验分布) 直接决定了最优行动。

值得注意的是, $\rho(d | y)$ 是随机变量 θ 的函数, 但由于我们对 θ 求了期望, 最终得到的是一个确定性的数值 (给定 y 和 d), 因此可以直接比较不同 d 的优劣。

在第三章中, 我们通过积分消去了 nuisance 参数, 得到了边际后验分布。现在我们看到, 这一”积分”操作本身也可以被理解作为一种最优决策——当损失函数取某种特定形式时, 边缘化 (marginalization) 正是使期望损失最小化的最优行动。这一联系揭示了贝叶斯推断中”积分”操作背后的决策理论动机。

3. 常见损失函数与最优估计

我们已经建立了期望后验损失的一般框架, 现在来考察几种在统计推断中最常见的损失函数及其对应的贝叶斯最优决策。

损失函数的选择反映了决策者的风险态度和具体问题的结构。以下是几种在统计推断中最常见的损失函数。

3.1. 平方损失与后验均值. 设 θ 为标量参数, d 为点估计量。平方损失函数 (squared error loss) 定义为

$$\ell(\theta, d) = (\theta - d)^2.$$

代入期望后验损失:

$$\rho(d | y) = \mathbb{E}_{p(\theta|y)}[(\theta - d)^2] = \mathbb{E}(\theta^2 | y) - 2d \mathbb{E}(\theta | y) + d^2.$$

对 d 求导并令其为零, 得到最优解

$$d^{\text{Bayes}} = \mathbb{E}(\theta | y).$$

定理 9.1 (平方损失下的贝叶斯最优估计). 在平方损失下, 贝叶斯最优点估计是后验均值 $\mathbb{E}(\theta | y)$ 。

这解释了为什么在很多贝叶斯分析中, 后验均值被视为”自然”的点估计——它不是任意选择的, 而是平方损失这一合理损失函数下的最优决策。

3.2. 绝对损失与后验中位数. 绝对损失函数 (absolute error loss) 定义为

$$\ell(\theta, d) = |\theta - d|.$$

期望后验损失 $\rho(d | y) = \mathbb{E}_{p(\theta|y)}[|\theta - d|]$ 是 d 的凸函数。其最小化问题

$$\min_d \mathbb{E}[|\theta - d|]$$

的解是后验分布的任意中位数 (当后验分布为连续分布时, 唯一解为后验中位数)。

定理 9.2 (绝对损失下的贝叶斯最优估计). 在绝对损失下, 贝叶斯最优估计量是后验分布的中位数。

绝对损失对大误差的惩罚力度小于平方损失，因此对应的最优估计对尾部不敏感，更加稳健。

3.3. 0-1 损失与后验众数. 在分类问题中，我们常使用 0-1 损失 (zero-one loss)：对于离散参数 θ 取值于有限集合 $\mathcal{K}$ ，

$$\ell(\theta, k) = \begin{cases} 0 & \text{若 } \theta = k, \\ 1 & \text{若 } \theta \neq k. \end{cases}$$

期望后验损失为

$$\rho(k | y) = \mathbb{E}_{p(\theta|y)}[\ell(\theta, k)] = 1 - p(\theta = k | y).$$

最小化期望后验损失等价于最大化后验概率 $p(\theta = k | y)$ ，因此

$$k^{\text{Bayes}} = \arg \max_{k \in \mathcal{K}} p(\theta = k | y),$$

即后验众数 (posterior mode) 或 MAP 估计 (maximum a posteriori estimate)。

定理 9.3 (0-1 损失下的贝叶斯最优分类). 在 0-1 损失下，贝叶斯最优分类决策是选择具有最大后验概率的类别。

3.4. 损失函数的比较.

注 9.1. 平方损失、绝对损失和 0-1 损失分别强调了后验分布的不同特征：均值、中位数和众数。这三个量在对称分布（如正态分布）中重合，但在偏态分布中可能差异显著。选择哪种损失函数，取决于具体问题的结构和决策者的偏好。

4. 预验分析：决定收集什么数据

在许多实际问题中，我们不仅需要在给定数据后做出决策，还需要在收集数据之前决定收集哪些数据。这一问题被称为预验分析 (preposterior analysis)。

4.1. 预验预期损失. 设我们考虑一个未来的观测 y' ，其分布依赖于当前未知但通过先验分布 $p(\theta)$ 建模的参数 θ ：

$$p(y') = \int p(y' | \theta) p(\theta) d\theta.$$

值得注意的是，这里 $p(y')$ 正是我们在第三章中学习的**后验预测分布** (posterior predictive distribution)：在先验 $p(\theta)$ 下对未来数据 y' 的预测分布。预验分析与后验预测分布之间的联系是：前者评估的是“收集新数据”这一行动本身的预期价值，而后者描述的是“在现有知识下”对未观测数据的预测。

在收集数据 y' 之前，我们对参数 θ 仍处于先验分布的认知。预验预期损失 (preposterior expected loss) 定义为：对所有可能的未来数据和参数值取期望，

$$\rho(d) = \mathbb{E}_{p(y', \theta)}[\ell(\theta, d(y'))] = \int \left[\int \ell(\theta, d(y')) p(y' | \theta) dy' \right] p(\theta) d\theta.$$

注意这里有两个期望层：内层关于 y' (给定 θ)，外层关于 θ (先验分布)。通过交换积分次序，可以将预验预期损失写成

$$\rho(d) = \mathbb{E}_{p(\theta)}[\rho(d | \theta)],$$

其中 $\rho(d | \theta) = \mathbb{E}_{p(y'|\theta)}[\ell(\theta, d(y'))]$ 是在参数固定为 θ 时，决策 d 的期望损失。

预验分析的核心问题是：如何选择实验设计 y' 的采样方案（样本量、测量变量等），使得预验预期损失最小？

例 9.2 (样本量确定). 设我们在一项临床试验中需要确定样本量 n 。试验结束后, 我们将使用后验均值 $\mathbb{E}(\theta | y')$ 作为治疗效果的点估计, 采用平方损失。预验分析需要计算不同 n 值下的预验预期损失

$$\rho(n) = \mathbb{E}_{p(\theta)}[\text{var}(\theta | y')],$$

并选择使 $\rho(n)$ 最小 (或在成本约束下使 $\rho(n)$ 可接受) 的 n 。¹

5. 层次决策问题与经验贝叶斯

在层次模型中, 决策问题呈现出特殊的结构。考虑一个两层次层次模型:

$$\theta_i \sim p(\theta | \phi), \quad y_i | \theta_i \sim p(y_i | \theta_i),$$

其中 ϕ 是超参数。

5.1. 层次决策的两阶段特性. 给定超参数 ϕ 的后验分布 $p(\phi | y)$, 层次决策问题可以分解为两个层次:

第一层 (条件最优决策): 给定 ϕ 和数据 y , 对每个 i 选择最优 θ_i 的估计 $\hat{\theta}_i(\phi, y)$ 。

第二层 (全贝叶斯决策): 在第一层的基础上, 对超参数 ϕ 的选择或估计进行决策。

经验贝叶斯 (empirical Bayes) 方法采取一种务实的策略: 用数据估计 ϕ (例如使用边缘似然函数 $p(y | \phi)$ 的最大似然估计 $\hat{\phi}$), 然后在估计得到的 $\phi = \hat{\phi}$ 条件下进行第一层决策。

从决策理论的角度看, 经验贝叶斯是一种**可迭代替代** (iterative alternative) 全贝叶斯方法, 在计算上更为可行, 但理论上不如全贝叶斯方法严格。

例 9.3 (正态均值层次模型的 shrinkage 估计). 考虑一个经典的正态均值层次模型: 设有 J 个学校 (或 J 个实验), 第 j 个学校的真实效果为 θ_j , 观测数据为

$$y_j | \theta_j \sim \text{Normal}(\theta_j, \sigma_j^2), \quad \theta_j \sim \text{Normal}(\mu, \tau^2),$$

其中 σ_j^2 已知。在平方损失下, 层次贝叶斯的最优估计具有著名的 **shrinkage** 形式:

$$\hat{\theta}_j^{\text{Bayes}} = \left(1 - \frac{\sigma_j^2}{\sigma_j^2 + \tau^2}\right) y_j + \frac{\sigma_j^2}{\sigma_j^2 + \tau^2} \mu.$$

这里估计被拉向群体均值 μ , 拉动的程度取决于组间方差 τ^2 与组内方差 σ_j^2 的比值。当 τ^2 很大时 (组间差异大), 估计接近原始观测 y_j ; 当 τ^2 很小时 (组间差异小), 估计强烈收缩向 μ 。如果 τ^2 未知而需要用数据估计 (经验贝叶斯), 则用估计值 $\hat{\tau}^2$ 替代。

注 9.2. 层次决策问题的核心张力在于: 第一层决策 (对 θ_i 的估计) 依赖于超参数 ϕ 的认知, 而 ϕ 本身的认知又依赖于所有 θ_i 的整体结构。这种相互依赖关系在层次模型中通过 **shrinkage 估计** 得到解决——个体估计被拉向群体均值, 拉动的程度由数据的置信度决定。

6. 损失函数视角下的模型选择

决策理论还为模型选择提供了统一框架。设我们有两个候选模型 M_1 和 M_2 , 对应的后验概率分别为 $p(M_1 | y)$ 和 $p(M_2 | y)$ 。

在 0-1 损失 (选择正确模型损失为 0, 选择错误模型损失为 1) 下, 最优模型选择规则是选择后验概率最大的模型:

$$\hat{M} = \arg \max_{M \in \{M_1, M_2\}} p(M | y).$$

¹详细推导见附录 section 9.2.

这一规则与贝叶斯因子 (Bayes factor) 密切相关, 因为

$$\frac{p(M_1 | y)}{p(M_2 | y)} = \frac{p(y | M_1)}{p(y | M_2)} \cdot \frac{p(M_1)}{p(M_2)} = B_{12} \cdot \text{先验比}.$$

当先验等可能时, 模型选择等价于比较贝叶斯因子。

损失函数框架的优势在于: 它允许我们根据具体问题的代价结构来调整决策规则。例如, 如果假阳性 (错误选择 M_1) 的代价远大于假阴性 (错误选择 M_2), 我们可能需要在后验概率上设定一个更严格的阈值。

7. 本章小结

本章建立了贝叶斯决策理论的基本框架, 其核心思想可以概括为以下几条:

- (1) **效用与损失的二元性**: 决策问题可以通过效用函数或损失函数来描述, 两者通过取负号相互转换。
- (2) **贝叶斯最优决策原则**: 在给定后验分布 $p(\theta | y)$ 的条件下, 最优决策是使期望后验损失最小化的决策。
- (3) **损失函数决定估计量的性质**: 平方损失对应后验均值, 绝对损失对应后验中位数, 0-1 损失对应后验众数。
- (4) **预验分析将决策前移到实验设计阶段**: 通过预验预期损失, 我们可以在收集数据之前评估不同数据收集方案的优劣。
- (5) **层次决策体现了多层次不确定性的处理**: 层次模型中的 shrinkage 估计可以从决策理论角度得到自然的解释。

决策分析将贝叶斯推断从“描述不确定性”推进到“基于不确定性做最优决策”, 是贝叶斯思想在实际问题中落地的关键步骤。

8. 习题

练习 9.1. 平方损失的性质 证明在平方损失下, 后验均值 $\mathbb{E}(\theta | y)$ 是唯一最优估计量。

练习 9.2. 绝对损失与后验中位数 设后验分布 $p(\theta | y)$ 均匀分布于区间 $[a, b]$ 。证明在绝对损失下, 任何 $d \in [a, b]$ 都是最优决策, 并解释这一结论的直觉。

练习 9.3. 0-1 损失与后验概率 考虑一个三分类问题, 参数 $\theta \in \{A, B, C\}$, 后验概率分别为 0.7, 0.2, 0.1。在 0-1 损失下, 贝叶斯最优分类是什么? 如果 A 类代表“患病”, 且假阴性 (将患者误判为健康) 的代价是假阳性的 5 倍, 应如何修改损失函数?

练习 9.4. 预验分析 设 $\theta \sim \text{Normal}(0, 1)$, 数据 $y | \theta \sim \text{Normal}(\theta, \sigma^2)$, 其中 σ^2 已知。证明在平方损失下, 预验预期损失 $\rho(n) = 1/(1+n)$, 并说明随着样本量 n 增加, 预验预期损失单调递减。

练习 9.5. 经验贝叶斯与全贝叶斯 考虑一个分层模型: $\theta_i \sim \text{Normal}(\mu, \tau^2)$, $y_i | \theta_i \sim \text{Normal}(\theta_i, \sigma^2)$, 其中 σ^2 已知, μ 和 τ^2 为未知超参数。比较以下两种方法的决策:

- (1) 全贝叶斯方法: 在 (μ, τ^2) 的先验分布下, 对 θ_i 进行全贝叶斯推断;
- (2) 经验贝叶斯方法: 用边缘似然函数 $p(y | \mu, \tau^2)$ 估计 (μ, τ^2) , 然后在估计值下对 θ_i 进行条件最优决策。

哪种方法在理论上更严格? 哪种在计算上更可行?

9. 附录：公式推导

9.1. 平方损失最优解的推导. 背景 (Background): 在 §9.2 中, 我们声称平方损失 $(\theta - d)^2$ 下的贝叶斯最优估计是后验均值 $\mathbb{E}(\theta | y)$ 。本节给出这一结论的完整推导。

参数定义 (Parameter Definitions):

- θ : 未知标量参数;
- d : 点估计量 (决策变量);
- $p(\theta | y)$: 给定数据 y 后的后验分布密度;
- $\rho(d | y) = \mathbb{E}_{p(\theta|y)}[(\theta - d)^2]$: 决策 d 的期望后验损失。

目标 (Goal): 证明 $\arg \min_d \rho(d | y) = \mathbb{E}(\theta | y)$ 。

推导步骤 (Derivation Steps):

对 $\rho(d | y)$ 关于 d 求导:

$$\frac{\partial}{\partial d} \rho(d | y) = \frac{\partial}{\partial d} \int (\theta - d)^2 p(\theta | y) d\theta = \int \frac{\partial}{\partial d} (\theta - d)^2 p(\theta | y) d\theta = \int -2(\theta - d) p(\theta | y) d\theta.$$

交换求导与积分次序的合法性由被积函数的光滑性保证 (控制收敛定理)。

令导数为零:

$$\int -2(\theta - d) p(\theta | y) d\theta = 0 \iff \int \theta p(\theta | y) d\theta = d \int p(\theta | y) d\theta.$$

由于 $p(\theta | y)$ 是密度函数, $\int p(\theta | y) d\theta = 1$, 因此

$$d = \int \theta p(\theta | y) d\theta = \mathbb{E}(\theta | y).$$

二阶条件: $\frac{\partial^2}{\partial d^2} \rho(d | y) = 2 > 0$, 确认是最小值点。

结论: 平方损失下的贝叶斯最优估计量是后验均值 $\mathbb{E}(\theta | y)$ 。 □

9.2. 样本量确定的预验分析推导. 背景 (Background): 在 例 9.2 中, 我们声称在平方损失下, 预验预期损失 $\rho(n) = \mathbb{E}_{p(\theta)}[\text{var}(\theta | y')]$ 。本节证明这一结论, 并推导具体形式。

参数定义 (Parameter Definitions):

- θ : 手术成功率 (未知参数);
- y' : 临床试验的 n 个独立观测, $y'_i \sim \text{Binomial}(1, \theta)$;
- 决策 $d(y') = \mathbb{E}(\theta | y')$ (平方损失下的贝叶斯最优决策);
- 损失函数: $\ell(\theta, d) = (\theta - d)^2$ 。

目标 (Goal): 计算 $\rho(n) = \mathbb{E}_{p(y', \theta)}[(\theta - \mathbb{E}(\theta | y'))^2]$ 。

推导步骤 (Derivation Steps):

第一步: 对给定 θ 的条件期望损失 $\rho(n | \theta) = \mathbb{E}_{p(y'|\theta)}[(\theta - \mathbb{E}(\theta | y'))^2]$ 。

由贝叶斯公式, 后验均值 $\mathbb{E}(\theta | y') = \frac{a + \sum y'_i}{a + b + n}$, 其中 a, b 是先验 Beta 参数。

对 $y'_i \sim \text{Binomial}(1, \theta)$ 求期望时, $\sum y'_i \sim \text{Binomial}(n, \theta)$, 故 $\mathbb{E}(\sum y'_i) = n\theta$, $\text{var}(\sum y'_i) = n\theta(1 - \theta)$ 。

因此:

$$\mathbb{E}(\theta | y') = \frac{a + \sum y'_i}{a + b + n} = \frac{a + b}{a + b + n} \cdot \frac{a}{a + b} + \frac{n}{a + b + n} \cdot \frac{\sum y'_i}{n}.$$

第二步: 对 θ 求期望。注意到 $\mathbb{E}(\theta) = \frac{a}{a+b}$, 以及条件方差分解公式:

$$\text{var}(\theta) = \mathbb{E}[\text{var}(\theta | y')] + \text{var}[\mathbb{E}(\theta | y')].$$

经过计算可得：

$$\rho(n) = \mathbb{E}_{p(\theta)}[\text{var}(\theta \mid y')] = \frac{1}{1+n} \cdot \text{var}(\theta) \propto \frac{1}{1+n}.$$

当先验方差 $\text{var}(\theta)$ 固定时， $\rho(n)$ 随 n 单调递减。

□

Part 3

高级计算方法

贝叶斯计算入门

1. 本章导论

在前面几章中，我们已经建立了贝叶斯推理的基本框架：先验分布、数据模型、似然函数，通过贝叶斯定理将它们结合为后验分布。理论上，这个框架是完整且优雅的。然而，当我们试图将这一理论应用于实际问题时，一个根本性的障碍立刻显现出来：

后验分布的计算往往涉及高维积分，而这些积分在解析上通常是不可解的。

例如，在层次模型中，我们需要计算后验均值、预测分布、模型证据等，每一种都需要在数十甚至数百个参数构成的高维空间中进行积分。传统的解析方法对此束手无策。

这正是本章要解决的问题：我们介绍三种主要的贝叶斯计算方法——**数值积分**、**蒙特卡罗 (Monte Carlo) 积分**和**渐近近似**。这些方法各有优劣，在不同场景下发挥各自的作用。我们将在第十一章深入讨论第四种也是最强大的方法——马尔科夫链蒙特卡罗 (MCMC)。

2. 计算挑战的来源

2.1. 从点估计到后验分布. 在经典统计学中，我们通常只关心某些感兴趣的参数的点估计——如均值或众数。贝叶斯方法则更进一步：我们想要完整的后验分布，以便进行区间估计、预测推断和模型比较。

形式上，对于参数 θ 和数据 y ，后验分布为

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{p(y)},$$

其中 $p(y) = \int p(y|\theta)p(\theta) d\theta$ 是边缘似然（或称证据）。

问题出在哪里？ 边缘似然 $p(y)$ 是一个维度等于 θ 维度的积分。当 θ 是单个参数时，这个积分尚可数值求解；但当 θ 包含数十或数百个参数时，**维度灾难 (curse of dimensionality)** 使得传统数值方法彻底失效。

2.2. 后验特征量的计算需求. 贝叶斯分析中常用的特征量包括：

- (1) **后验均值**： $\mathbb{E}(\theta|y) = \int \theta p(\theta|y) d\theta$
- (2) **后验方差**： $\text{var}(\theta|y) = \int (\theta - \mathbb{E}(\theta))^2 p(\theta|y) d\theta$
- (3) **预测分布**： $p(y_{\text{new}}|y) = \int p(y_{\text{new}}|\theta) p(\theta|y) d\theta$
- (4) **边缘后验**：对部分参数积分得到其余参数的后验

每一种都需要在高维空间中进行积分运算。

注 10.1. 值得注意的是，在许多实际问题中，我们并不需要完整的联合后验分布 $p(\theta|y)$ ，而只需要某些边缘分布或特征量。这就引出了两类主要策略：**直接近似后验分布**（如变分推断）和**直接近似感兴趣的特征量**（如蒙特卡罗方法）。

3. 数值积分方法

3.1. 简单求积法. 最基本的思路是用离散求和逼近连续积分。例如，对于一维积分，我们可以使用矩形法则或 Simpson 法则：

$$\int_a^b f(x) dx \approx \sum_{i=1}^n w_i f(x_i),$$

其中 x_i 是求积节点, w_i 是相应权重。

为什么这在贝叶斯计算中很快失效? 在 d 维空间中, 网格方法需要 n^d 个节点。如果 $d = 10$ 且每维取 10 个节点, 就需要 10^{10} 个节点——这在任何实际计算中都是不可行的。这种指数增长就是维度灾难的本质。

3.2. Latin 超立方采样. 一种改进策略是**分层采样 (stratified sampling)**: 将积分区域划分为若干子区域, 在每个子区域中独立采样。

Latin 超立方采样 (Latin Hypercube Sampling, LHS) 是一种优雅的分层采样方法, 它确保样本在每个维度上均匀分布, 同时保持采样的随机性。

对于 d 维空间和 n 个样本, LHS 将每个维度划分为 n 个等概率区间, 然后通过随机置换确保样本点不重复。这种方法的优势在于: 即使样本量较小, 也能获得比纯随机采样更均匀的覆盖。

然而, LHS 本质上仍是一种**低维方法**。当维度增加到数十甚至数百时, 其效果迅速下降。

4. 蒙特卡洛积分

4.1. 基本思想. 蒙特卡洛方法的核心思想出奇地简单: 用随机模拟代替确定性计算。¹

假设我们想要计算 $\theta = \int h(x) dx$ 。如果我们能够从 x 的分布 $p(x)$ 中独立抽取大量样本 $x_1, \dots, x_n$, 则可以用

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n h(x_i)$$

作为 θ 的估计。强大数定律保证 $\hat{\theta}_n \rightarrow \theta$ (当 $n \rightarrow \infty$)。

更一般地, 如果我们想计算 $\int h(x)p(x) dx$, 其中 $p(x)$ 是某个分布的密度, 我们只需从 $p(x)$ 中采样, 然后用样本均值估计积分。

4.2. 重要性采样. 在贝叶斯计算中, 我们经常需要从难以采样的分布中估计积分。**重要性采样 (importance sampling)** 是一种巧妙的解决方案: 不是从目标分布 $p(\theta|y)$ 直接采样, 而是从另一个更容易采样的分布 $g(\theta)$ 中采样。

设我们想估计

$$I = \int h(\theta) p(\theta|y) d\theta = \int h(\theta) \frac{p(y|\theta)p(\theta)}{p(y)} d\theta.$$

如果从 $g(\theta)$ 中采样, 注意到

$$I = \int h(\theta) \frac{p(y|\theta)p(\theta)}{p(y)} \cdot \frac{g(\theta)}{g(\theta)} d\theta = \int \frac{h(\theta)p(y|\theta)p(\theta)}{p(y)g(\theta)} g(\theta) d\theta.$$

令 $w(\theta) = \frac{p(y|\theta)p(\theta)}{g(\theta)}$, 则

$$\hat{I} = \frac{1}{n} \sum_{i=1}^n \frac{h(\theta_i)w(\theta_i)}{\frac{1}{n} \sum_{j=1}^n w(\theta_j)} = \sum_{i=1}^n h(\theta_i) \tilde{w}(\theta_i),$$

¹关于蒙特卡洛方法的历史, 详见附录 ??。

其中 $\tilde{w}(\theta_i) = \frac{w(\theta_i)}{\sum_j w(\theta_j)}$ 是归一化权重。

例 10.1 (10 维积分的重要性采样估计). 考虑估计 d 维单位球体积: $I_d = \int_{[0,1]^d} 1 d\theta$ 。

使用标准正态分布作为重要性分布 $g(\theta)$, 并将积分区域扩展到全空间 $I = \int_{\mathbb{R}^d} \mathbb{I}_{[0,1]^d}(\theta) d\theta$ 。这实际上是用 $g(\theta)$ 的样本估计 $\mathbb{I}_{[0,1]^d}(\theta)$ 在 $\mathbb{R}^d$ 上的积分。

由于正态分布的尾部概率很小, 我们需要足够多的样本才能获得稳定的估计。²

重要性采样的核心挑战是选择合适的重要性分布 $g(\theta)$ 。好的重要性分布应该:

- (1) **支撑集覆盖**: $g(\theta) > 0$ whenever $p(\theta|y) > 0$
- (2) **轻尾部**: 避免在尾部区域浪费太多样本
- (3) **形状相近**: $g(\theta)$ 的形状应尽量接近 $|h(\theta)|p(\theta|y)$

4.3. 有效样本量. 在重要性采样中, 权重 w_i 的分布反映了估计的效率。如果所有权重几乎相等, 说明 $g(\theta)$ 与目标分布匹配良好; 如果权重分布极其不均, 说明大部分样本贡献很小。

我们用**有效样本量 (Effective Sample Size, ESS)** 量化这一点:

$$\text{ESS} = \frac{n}{1 + \text{var}(w)},$$

其中 $\text{var}(w)$ 是 (未归一化) 权重的变异系数。ESS 的直观含义是: 与直接采样相比, 我们需要多少样本来达到当前的估计精度?

在实践中, 我们用

$$\text{ESS} \approx \frac{n}{1 + \frac{\text{var}(w)}{\mathbb{E}(w)^2}}$$

来估计 ESS。如果 $\text{ESS} \ll n$, 说明重要性采样效果不佳, 我们需要调整 $g(\theta)$ 或尝试其他方法。

注 10.2. ESS 是一个有用的诊断工具, 但不是绝对的。当权重高度非均匀时, 即使 ESS 看起来还可以, 估计量 $\hat{I}$ 的方差也可能被低估。这被称为**权重复制问题 (weight degeneracy)**, 是在实际使用重要性采样时需要警惕的。

4.4. 拒绝采样. 拒绝采样 (rejection sampling) 是另一种从困难分布中采样的通用方法。³

其基本思想是: 找到一个容易采样的包络分布 $g(\theta)$, 使得存在常数 c 满足

$$p(\theta|y) \leq c \cdot g(\theta), \quad \forall \theta.$$

然后算法如下:

- (1) 从 $g(\theta)$ 中抽取候选样本 θ^*
- (2) 计算接受概率 $\alpha = \frac{p(\theta^*|y)}{c \cdot g(\theta^*)}$
- (3) 以概率 α 接受 θ^* , 否则拒绝并返回步骤 1

被接受的样本恰好服从目标分布 $p(\theta|y)$ 。

²详细推导和代码实现见附录 ??。

³关于拒绝采样的详细讨论, 包括与 MCMC 的关系, 见附录 ??。

例 10.2 (截断正态分布的拒绝采样). 假设我们想从截断正态分布 $N(\mu, \sigma^2)$ 在区间 $[a, b]$ 上的限制采样。一个自然的选择是使用同样的正态分布作为包络分布, 但需要确保 $c \cdot g(\theta) \geq p(\theta|y)$ 在整个区间上成立。

具体而言, 我们需要 $c \geq \frac{\max_{\theta \in [a, b]} p(\theta|y)}{g(\theta)}$, 这可以通过分析 g 和 p 的密度比来确定。⁴

拒绝采样的关键挑战是找到合适的包络分布 $g(\theta)$ 和常数 c 。如果 c 太大, 接受率会很低, 算法效率严重下降; 如果 $g(\theta)$ 的形状与 $p(\theta|y)$ 差异太大, c 也不得不设得很大。

4.5. 采样重要性重采样. 采样重要性重采样 (Sequential Importance Resampling, SIR), 也称为粒子滤波的基础, 将重要性采样与重采样结合起来。

当直接估计后验分布 $p(\theta|y)$ 困难时, SIR 提供了一种近似采样的方法:

- (1) 从简单建议分布 $g(\theta)$ 中抽取 n 个样本 $\theta_1, \dots, \theta_n$
- (2) 计算非归一化权重 $w_i \propto \frac{p(y|\theta_i)p(\theta_i)}{g(\theta_i)}$
- (3) 归一化权重 $\tilde{w}_i = w_i / \sum_j w_j$
- (4) 通过重采样 (依据权重 $\tilde{w}_i$) 得到新样本集

重采样步骤是 SIR 与普通重要性采样的关键区别: 通过消除低权重样本、复制高权重样本, 我们得到了一个更接近目标分布的样本集。

注 10.3. SIR 的一个重要应用是状态空间模型中的粒子滤波。在这类模型中, 潜在状态 x_t 是隐含的, 我们只能通过观测 y_t 间接推断。SIR 通过序贯地处理每个时间步的观测, 逐步更新状态的后验分布。

5. 渐近近似方法

当样本量较大时, 中心极限定理为后验分布提供了良好的近似。

5.1. Laplace 方法. Laplace 方法的核心思想是用正态分布逼近后验分布。设

$$p(\theta|y) \propto p(y|\theta)p(\theta) = \exp\{-n \cdot h(\theta)\},$$

其中 $h(\theta) = -\frac{1}{n} \log p(y|\theta)p(\theta)$ 。

将 $h(\theta)$ 在其后验众数 $\hat{\theta}$ 处 Taylor 展开:

$$h(\theta) \approx h(\hat{\theta}) + \frac{1}{2}(\theta - \hat{\theta})^T H(\hat{\theta})(\theta - \hat{\theta}),$$

其中 $H(\hat{\theta}) = \nabla^2 h(\hat{\theta})$ 是 Hessian 矩阵。

代入得

$$p(\theta|y) \approx \exp\{-nh(\hat{\theta})\} \cdot \exp\left\{-\frac{n}{2}(\theta - \hat{\theta})^T H(\hat{\theta})(\theta - \hat{\theta})\right\}.$$

这正是均值为 $\hat{\theta}$ 、协方差为 $\frac{1}{n}H(\hat{\theta})^{-1}$ 的正态分布。⁵

例 10.3 (逻辑回归的 Laplace 近似). 在逻辑回归中, 似然函数为

$$p(y|\theta) = \prod_{i=1}^n \text{logit}^{-1}(\theta^T x_i)^{y_i} (1 - \text{logit}^{-1}(\theta^T x_i))^{1-y_i}.$$

⁴详细推导和 R 实现代码见附录 ??。

⁵关于 Laplace 方法的更严格推导和误差分析, 见附录 ??。

对数似然的 Hessian 矩阵为

$$H(\theta) = \sum_{i=1}^n \text{logit}^{-1}(\theta^T x_i)(1 - \text{logit}^{-1}(\theta^T x_i))x_i x_i^T,$$

其中 $\text{logit}^{-1}(z) = \frac{1}{1+e^{-z}}$ 。

Laplace 近似给出 $\theta|y \approx N(\hat{\theta}, H(\hat{\theta})^{-1})$ ，其中 $\hat{\theta}$ 是后验众数。⁶

Laplace 方法的优势在于计算效率高：当 n 足够大时，它提供了对后验分布的快速近似。其局限性在于它假设后验分布是单峰的且接近正态——这在许多实际问题中是合理的，但绝非普遍成立。

5.2. BIC 近似. 贝叶斯信息准则 (BIC) 是大样本下边缘似然的重要近似。设 d 是参数维度， n 是样本量，则

$$\text{BIC} = -2 \log p(y|\hat{\theta}_{\text{MLE}}) + d \log n.$$

更精确地，边缘似然的 BIC 近似为

$$\log p(y) \approx \log p(y|\hat{\theta}_{\text{MLE}}) - \frac{d}{2} \log n + O(1).$$

BIC 在模型选择中广泛应用，因为它提供了一个在似然性和模型复杂度之间权衡的准则。⁷

在贝叶斯计算中，BIC 的意义在于它提供了一种廉价的边缘似然近似，而无需进行昂贵的高维积分。这在需要快速筛选大量候选模型时尤其有用。

6. 变分推断初步

变分推断 (Variational Inference) 是近年来发展迅速的一种贝叶斯计算方法。⁸

其核心思想是：**用一类简单的分布 Q 去近似难以处理的后验分布 $p(\theta|y)$** 。具体而言，我们寻找 $q(\theta) \in Q$ 使得

$$q^*(\theta) = \arg \min_{q \in Q} \text{KL}(q(\theta) \| p(\theta|y)).$$

由于 KL 散度涉及 $p(\theta|y)$ ，直接最小化 KL 不可行。但可以证明（通过简单的代数变形）：

$$\log p(y) = \text{KL}(q \| p) + \mathcal{L}(q),$$

其中 $\mathcal{L}(q) = \int q(\theta) \log \frac{p(y|\theta)p(\theta)}{q(\theta)} d\theta$ 是**变分下界 (ELBO)**。

由于 $\log p(y)$ 是常数，最小化 $\text{KL}(q \| p)$ 等价于最大化 $\mathcal{L}(q)$ 。而 $\mathcal{L}(q)$ 只涉及 $q(\theta)$ 和对数似然/先验，因而是可以计算的。

变分推断的优势在于其**计算效率**：通过优化有限的变分参数，变分推断可以在百万级参数规模的模型中进行后验近似。这使其成为现代大规模贝叶斯模型（如主题模型、深度贝叶斯网络）的首选方法。

其局限性在于近似误差难以控制：我们无法知道 $q^*(\theta)$ 与真实后验 $p(\theta|y)$ 相差多少，除非进行昂贵的后验校验。

⁶关于如何在实践中使用这个近似的详细讨论，见附录 ??。

⁷关于 BIC 与其他模型选择准则（如 AIC、WAIC）的比较，见附录 ??。

⁸变分推断的完整理论，包括平均场近似和信念传播，见附录 ??。

注 10.4. 变分推断与 MCMC 是互补的关系。当我们需要**可扩展性**时（大规模数据、大参数空间），变分推断是首选；当我们需要**无偏估计**和**可证明收敛**时，MCMC 更适合。在实际应用中，两者经常结合使用：先用变分推断快速获得初始近似，再用 MCMC 进行精细采样。

7. 方法选择指南

面对多样的贝叶斯计算方法，如何选择？以下是一些经验法则：

- (1) **低维问题** ($d \leq 5$)：优先尝试数值积分或拒绝采样。网格方法或简单的自适应求积可能已经足够。
- (2) **中等维度** ($5 < d \leq 20$)：重要性采样和 SIR 是合理的选择。关键是选择好的重要性分布——通常可以使用 Laplace 近似的正态分布作为建议分布。
- (3) **高维问题** ($d > 20$)：MCMC（下一章主题）或变分推断是主要工具。简单的重要性采样在极高维度下效果很差。
- (4) **模型结构**：如果模型具有共轭结构，利用条件分布的解析形式可以大大简化计算（如 EM 算法）。
- (5) **计算资源**：当有 GPU 可用时，基于蒙特卡洛的方法可以并行化；当只有 CPU 时，变分推断的确定性优化可能更快。

8. 本章小结

本章我们介绍了贝叶斯计算的基本工具：

- (1) **计算挑战的本质**：高维积分是贝叶斯计算的核心障碍
- (2) **数值积分方法**：低维有效，但受维度灾难限制
- (3) **蒙特卡洛积分**：用随机采样代替确定性积分
- (4) **重要性采样**：从建议分布采样，加权修正
- (5) **拒绝采样**：用包络分布控制接受率
- (6) **采样重要性重采样 (SIR)**：结合重要性采样与重采样
- (7) **Laplace 方法**：用正态分布近似后验分布
- (8) **变分推断**：用优化方法近似后验

这些方法为下一章马尔科夫链蒙特卡洛 (MCMC) 奠定了基础。MCMC 是解决高维贝叶斯计算问题的最强大武器，它将在第十一章和第十二章中得到系统阐述。

9. 下节预告

下一章我们将学习**马尔科夫链蒙特卡洛 (MCMC)**的基本原理，包括 Metropolis-Hastings 算法和 Gibbs 采样。这两种方法是现代贝叶斯统计计算的核心工具。

马尔可夫链模拟基础

1. 本章导论

在前几章中，我们学习了如何通过共轭先验和解析计算来处理贝叶斯推断。然而，现实世界中的大多数贝叶斯模型都无法得到解析解——后验分布涉及高维积分，这些积分通常没有闭式形式。

这就引出了一个根本性的问题：**如何从无法解析表达的分布中抽取样本？**

答案在统计物理和概率论中早有先例。物理学家 Metropolis 和 Ulam 在 20 世纪 40 年代就发现，通过模拟随机过程可以从复杂分布中抽取样本。这一思想后来发展成为马尔可夫链蒙特卡洛 (MCMC) 方法，成为现代贝叶斯统计的计算基石。

本章我们将学习两类核心的模拟技术：

- (1) **重要性抽样 (Importance Sampling)** 和 **拒绝抽样 (Rejection Sampling)**：直接从目标分布抽样的技术
- (2) **马尔可夫链模拟 (Markov Chain Simulation)**：通过构造马尔可夫链来探索目标分布的技术

这些方法共同构成了贝叶斯计算的工具箱，使我们能够处理从前无法解决的复杂模型。

2. 重要性抽样

2.1. 基本思想. 考虑一个简单的问题：我们希望计算某个函数 $h(\theta)$ 在后验分布下的期望

$$\mathbb{E}(h(\theta)|y) = \int h(\theta)p(\theta|y) d\theta$$

但直接计算这个积分通常是不可行的。

重要性抽样的核心思想是：**不直接从 $p(\theta|y)$ 抽样，而是从一个更容易抽样的分布 $g(\theta)$ 中抽取样本，然后用权重调整来估计期望。**

具体地，如果我们从 $g(\theta)$ 中抽取样本 $\theta^{(1)}, \dots, \theta^{(m)}$ ，则

$$\mathbb{E}(h(\theta)|y) \approx \frac{1}{m} \sum_{i=1}^m h(\theta^{(i)}) \cdot \frac{p(\theta^{(i)}|y)}{g(\theta^{(i)})}$$

其中比值 $\frac{p(\theta|y)}{g(\theta)}$ 称为**重要性权重 (importance weight)**。

2.2. 重要性权重的计算. 注意到 $p(\theta|y) \propto p(y|\theta)p(\theta)$ ，因此重要性权重可以写成

$$w(\theta) = \frac{p(y|\theta)p(\theta)}{g(\theta)}$$

这个权重不需要归一化常数——只要 $g(\theta)$ 的支撑包含 $p(\theta|y)$ 的支撑即可。

注 11.1. 重要性抽样的效果高度依赖于 $g(\theta)$ 和 $p(\theta|y)$ 的匹配程度。如果 $g(\theta)$ 在 $p(\theta|y)$ 重要的区域取值很小，重要性权重会变得极不稳定（方差无穷大）。

3. 拒绝抽样

3.1. 动机：为什么需要拒绝？ 重要性抽样虽然简单，但有一个根本缺陷：当 $g(\theta)$ 和 $p(\theta|y)$ 匹配不好时，重要性权重的方差会爆炸。

拒绝抽样 (Rejection Sampling) 提供了一种保证收敛精度的替代方案。其思想是：**找到一个可抽样的覆盖分布，并在接受率上引入随机拒绝机制。**

3.2. 算法。 设 $p(\theta)$ 是目标分布（可以是未归一化的）， $g(\theta)$ 是我们能抽样的提议分布， M 是一个常数使得对所有 θ 都有

$$p(\theta) \leq M \cdot g(\theta)$$

拒绝抽样的步骤如下：

- (1) 从 $g(\theta)$ 中抽取候选样本 θ^*
- (2) 计算接受概率 $u = \frac{p(\theta^*)}{M \cdot g(\theta^*)}$
- (3) 从 $\text{Uniform}(0, 1)$ 抽取 u^*
- (4) 如果 $u^* \leq u$ ，则接受 θ^* ；否则拒绝

被接受的样本 θ^* 确实来自目标分布 $p(\theta)$ 。

例 11.1 (拒绝抽样的几何直观). 想象在 $p(\theta)$ 曲线下方投掷飞镖。如果我们的提议分布 $g(\theta)$ 是均匀的，那么 M 就是 $p(\theta)$ 的最大值的倒数（归一化后）。只有落在 $p(\theta)$ 曲线下方的点才会被接受。

3.3. 接受率的计算。 拒绝抽样的期望接受率为

$$\text{accept rate} = \frac{1}{M} \int \frac{p(\theta)}{g(\theta)} \cdot g(\theta) d\theta = \frac{1}{M}$$

因此，我们需要选择尽可能小的 M 来提高接受率，但 M 必须满足对所有 θ 的覆盖条件。

这个条件是拒绝抽样的主要限制：对于高维分布或支撑集不规则的分布，找到一个有效的覆盖分布 $g(\theta)$ 和常数 M 往往非常困难。

4. 重要性重抽样 (SIR)

4.1. 动机：结合两种方法的优点。 拒绝抽样保证了精度，但接受率可能极低；重要性抽样效率高，但方差可能失控。

重要性重抽样 (SIR, Sampling Importance Resampling) 结合了两者的优点：首先用重要性抽样生成大量加权样本，然后通过重抽样来消除权重的不均匀性。

4.2. 算法。 SIR 的步骤：

- (1) 从提议分布 $g(\theta)$ 抽取 m 个候选样本 $\theta^{(1)}, \dots, \theta^{(m)}$
- (2) 计算每个样本的重要性权重 $w^{(i)} = \frac{p(\theta^{(i)}|y)}{g(\theta^{(i)})}$
- (3) 归一化权重： $\tilde{w}^{(i)} = \frac{w^{(i)}}{\sum_{j=1}^m w^{(j)}}$
- (4) 从 $\{\theta^{(1)}, \dots, \theta^{(m)}\}$ 中按概率 $\tilde{w}^{(i)}$ 有放回抽取 n 个样本

最终得到的 n 个样本近似服从目标分布 $p(\theta|y)$ 。

注 11.2. SIR 的有效性依赖于 m 足够大—— m 越大，重抽样得到的分布越接近真实目标分布。通常取 $m = 5n$ 到 $m = 10n$ 。

SIR 方法在实际应用中非常广泛，特别是在处理层次模型和混合模型时。它的缺点是仍然依赖于选择合适的提议分布 $g(\theta)$ 。

5. 马尔可夫链基础

5.1. 从独立抽样到依赖抽样. 前述方法有一个共同特点：每次抽样都是独立的。但对于复杂的高维分布，找到一个好的提议分布本身就是一个难题。

马尔可夫链模拟提供了一种革命性的替代思路：**不追求独立同分布抽样，而是构造一个马尔可夫链，使其平稳分布恰好是我们想要的目标分布。**

这样，只需要运行马尔可夫链足够长时间，就可以从目标分布中抽样——即使我们永远无法写出这个分布的解析形式。

5.2. 马尔可夫链的定义. 回忆一下，马尔可夫链是一个随机过程 $\theta^{(1)}, \theta^{(2)}, \dots$ ，满足马尔可夫性质：

$$\theta^{(t+1)} | \theta^{(1)}, \dots, \theta^{(t)} \sim P(\theta^{(t+1)} | \theta^{(t)})$$

也就是说，下一个状态只依赖于当前状态，与历史无关。

转移核 $P(\theta' | \theta)$ 完全决定了链的行为。

5.3. 平稳分布. 如果存在分布 $\pi(\theta)$ 使得

$$\pi(\theta') = \int P(\theta' | \theta) \pi(\theta) d\theta$$

则称 $\pi(\theta)$ 为该马尔可夫链的**平稳分布 (stationary distribution)**。

我们的目标是：构造一个马尔可夫链，使其平稳分布 $\pi(\theta) = p(\theta | y)$ (后验分布)。

5.4. 细致平衡条件. 一个充分条件是**细致平衡 (detailed balance)**：

$$P(\theta' | \theta) \pi(\theta) = P(\theta | \theta') \pi(\theta')$$

如果转移核满足细致平衡，则平稳分布存在且就是 $\pi(\theta)$ 。

5.5. 收敛性. 对于大多数我们构造的马尔可夫链，在适当条件下，链会从任何初始值出发，在运行足够多步后，收敛到平稳分布。这意味着：

- (1) 我们可以用链的样本近似目标分布
- (2) 收敛所需的步数称为“**混合时间 (mixing time)**”
- (3) 我们通常需要“**预烧期 (burn-in)**”——丢弃前若干步的样本

理解马尔可夫链的收敛行为是有效使用 MCMC 方法的关键。

6. Metropolis 算法

6.1. 历史背景. 1953 年，Metropolis、Rosenbluth、Rosenbluth、Teller 和 Teller 在一项关于分子物理的工作中提出了著名的 Metropolis 算法。这一算法后来被 Hastings 在 1970 年推广为更一般的形式。

毫不夸张地说，Metropolis 算法彻底改变了贝叶斯统计的计算格局。

6.2. 算法思想. Metropolis 算法的巧妙之处在于：它只需要能计算目标分布的**非归一化形式** $p^*(\theta) = c \cdot p(\theta | y)$ ，而不需要知道归一化常数 c 。

算法的步骤：

- (1) 选择一个对称的提议分布 $q(\theta' | \theta) = q(\theta | \theta')$ (例如，以当前值为均值的高斯分布)
- (2) 从 $q(\cdot | \theta^{(t)})$ 抽取候选样本 θ^*
- (3) 计算接受比 $r = \frac{p^*(\theta^*)}{p^*(\theta^{(t)})}$
- (4) 以概率 $\min(1, r)$ 接受候选值： $\theta^{(t+1)} = \theta^*$ ；否则 $\theta^{(t+1)} = \theta^{(t)}$

6.3. 为什么有效？ 可以验证，Metropolis 算法构造的马尔可夫链满足细致平衡，因此其平稳分布正是目标分布 $p(\theta|y)$ 。

关键的洞察是：即使我们不知道归一化常数，比值 $r = \frac{p^*(\theta^*)}{p^*(\theta^{(t)})}$ 也不依赖于归一化常数，因为它们被抵消了。

例 11.2 (一维高斯目标分布). 假设目标分布是标准正态分布 $p(\theta) = \phi(\theta)$ 。使用对称的随机游走提议分布 $q(\theta'|\theta) = N(\theta', \theta, \sigma^2)$ 。

接受比 $r = \exp\left(-\frac{1}{2}(\theta^*)^2 + \frac{1}{2}(\theta^{(t)})^2\right)$ 。

如果候选值在概率密度更高的区域（更接近 0），则 $r > 1$ ，必然被接受；如果在更低区域，以一定概率被拒绝。

6.4. 提议分布的选择. 提议分布的选择直接影响 Metropolis 算法的效率：

- (1) **步长 (scale)**: 如果步长太大，接受率会很低，链几乎不动；如果步长太小，混合会很慢
- (2) **形状**: 提议分布应该与目标分布的形状大致匹配
- (3) 经验法则: 目标接受率约为 0.25 到 0.5

调参是使用 Metropolis 算法的重要技巧，需要根据具体问题摸索。

7. Metropolis-Hastings 算法

7.1. 推广到非对称提议. Metropolis 算法要求提议分布对称，这在很多情况下限制了灵活性。Hastings 在 1970 年提出了一个更一般的版本，允许使用非对称的提议分布。

7.2. 算法. Metropolis-Hastings 算法的步骤：

- (1) 从提议分布 $q(\theta'|\theta^{(t)})$ 抽取候选样本 θ^*
- (2) 计算接受比

$$r = \frac{p^*(\theta^*)}{p^*(\theta^{(t)})} \cdot \frac{q(\theta^{(t)}|\theta^*)}{q(\theta^*|\theta^{(t)})}$$

- (3) 以概率 $\min(1, r)$ 接受或拒绝

接受比中的额外因子 $\frac{q(\theta^{(t)}|\theta^*)}{q(\theta^*|\theta^{(t)})}$ 纠正了非对称提议带来的偏差。

当 q 是对称的时，这个因子等于 1，Metropolis-Hastings 算法就退化为普通的 Metropolis 算法。

8. Gibbs 抽样

8.1. 条件分布的神奇作用. 在多参数问题中，直接从联合后验分布抽样通常是不可能的。但如果我们可以从各个参数的**条件分布**中抽样，就会大大简化问题。

Gibbs 抽样正是利用了这一思想。它是 Metropolis-Hastings 算法的一种特殊形式，提议分布就是条件分布，因此接受率恒为 1。

8.2. 算法. 对于 d 维参数 $\theta = (\theta_1, \dots, \theta_d)$ ，Gibbs 抽样的步骤：

- (1) 初始化 $\theta^{(0)} = (\theta_1^{(0)}, \dots, \theta_d^{(0)})$
- (2) 对于 $t = 1, 2, \dots$:
 - (a) 从 $p(\theta_1|\theta_2^{(t)}, \dots, \theta_d^{(t)}, y)$ 抽取 $\theta_1^{(t+1)}$
 - (b) 从 $p(\theta_2|\theta_1^{(t+1)}, \theta_3^{(t)}, \dots, \theta_d^{(t)}, y)$ 抽取 $\theta_2^{(t+1)}$
 - (c) ...
 - (d) 从 $p(\theta_d|\theta_1^{(t+1)}, \dots, \theta_{d-1}^{(t+1)}, y)$ 抽取 $\theta_d^{(t+1)}$

一轮更新完成后, $\theta^{(t+1)} = (\theta_1^{(t+1)}, \dots, \theta_d^{(t+1)})$ 。

8.3. 为什么接受率为 1? 考虑更新 θ_j 时, 提议分布就是条件分布 $q(\theta'_j|\theta_{-j}) = p(\theta'_j|\theta_{-j}, y)$ 。

接受比为

$$r = \frac{p^*(\theta'_j, \theta_{-j})}{p^*(\theta_j, \theta_{-j})} \cdot \frac{p(\theta_j|\theta_{-j}, y)}{p(\theta'_j|\theta_{-j}, y)} = 1$$

因为分子分母中的条件分布恰好互为倒数。因此 Gibbs 抽样总是接受提议值。

8.4. Gibbs 抽样的优势与局限.

注 11.3. Gibbs 抽样的优势在于:

- 无需调参 (没有接受率问题)
- 每步只需要从一元条件分布抽样, 通常比较简单
- 自然地利用了问题的条件结构

局限性在于:

- 必须能够从所有条件分布有效抽样
- 当条件分布不是标准形式时, 可能需要其他 MCMC 步骤 (**混合 MCMC**)
- 参数高度相关时, 收敛可能很慢

9. 从后验分布抽样的实践

9.1. 构建 MCMC 策略. 在实际应用中, 构建一个有效的 MCMC 抽样器通常需要结合多种技术:

- (1) **识别条件结构:** 首先分析模型, 找出哪些条件分布是共轭的或容易抽样的
- (2) **Gibbs 为主:** 优先使用 Gibbs 抽样处理条件分布可解析处理的部分
- (3) **Metropolis-Hastings 补充:** 对难以抽样的条件分布, 使用 Metropolis-Hastings 步骤
- (4) **块更新:** 有时需要对多个参数进行联合更新以加速收敛

9.2. 收敛诊断. MCMC 的一个核心问题是判断链是否已经收敛到目标分布。常用的诊断方法包括:

- **图形诊断:** 绘制链的轨迹图 (trace plot), 检查是否“平稳”
- **Gelman-Rubin 统计量:** 比较多条链的方差
- **自相关函数 (ACF):** 检查样本之间的相关性
- **有效样本量 (ESS):** 考虑自相关后的等效独立样本数

需要强调的是, 这些诊断方法只能检测**未收敛**, 而不能保证收敛。良好的建模实践要求使用多种诊断并谨慎解释结果。

9.3. 预烧期和 thinning.

- **预烧期 (burn-in):** 丢弃前 b 次迭代, 因为链在达到平稳分布之前可能处于“预热”状态
- **Thinning (稀疏化):** 每隔 k 步取一个样本, 以减少样本自相关

这些技术虽然会减少有效样本量, 但可以提高估计的独立性, 是实践中常用的策略。

10. 示例：从分层模型抽样

为了说明 MCMC 的实际应用，考虑一个简单的分层模型：

$$y_j | \theta_j \sim N(\theta_j, \sigma^2), \quad \theta_j | \mu, \tau \sim N(\mu, \tau^2)$$

其中 σ^2 已知，我们希望从后验分布 $p(\mu, \tau, \theta | y)$ 中抽样。

使用 Gibbs 抽样，我们可以依次从以下条件分布抽样：

- (1) $p(\theta_j | \mu, \tau, y)$ ：这是正态分布，均值和方差都是解析的
- (2) $p(\mu | \theta, \tau, y)$ ： μ 的条件后验也是正态的
- (3) $p(\tau | \theta, \mu, y)$ ：这个条件分布通常不是标准形式，需要 Metropolis 步骤

这个例子展示了**混合 MCMC**的价值：利用 Gibbs 抽样的简便性，同时用 Metropolis 处理非标准条件分布。

11. 本章小结

本章我们学习了贝叶斯计算的核心技术——马尔可夫链模拟：

- (1) **重要性抽样**：通过提议分布和权重估计期望，但方差可能不稳定
- (2) **拒绝抽样**：保证精度的覆盖抽样方法，但接受率可能很低
- (3) **SIR**：结合重要性抽样和重抽样，实用性强
- (4) **马尔可夫链基础**：平稳分布、细致平衡、收敛性概念
- (5) **Metropolis 算法**：利用对称提议分布从目标分布抽样
- (6) **Metropolis-Hastings 算法**：推广到非对称提议分布
- (7) **Gibbs 抽样**：利用条件分布的特殊结构，接受率恒为 1
- (8) **实践要点**：收敛诊断、预烧期、混合 MCMC 策略

这些技术共同构成了现代贝叶斯统计的计算基础，使我们能够处理从前无法解决的高维复杂模型。

下一章我们将学习如何进一步提高 MCMC 的计算效率，包括切片抽样 (slice sampling)、Hamiltonian Monte Carlo 等高级技术。

高效马尔可夫链模拟

1. 本章导论

在前两章中，我们介绍了马尔可夫链模拟的基本工具——Gibbs 采样器和 Metropolis 算法。这些方法具有广泛的适用性，但在处理复杂模型时可能面临效率问题。

本章将基本 Gibbs 采样器和 Metropolis 算法视为构建更高级马尔可夫链模拟算法的基石。我们依次讨论参数化变换和调优参数设置以提高效率的方法、切片采样 (slice sampling)、可逆跳转采样 (reversible jump sampling) 以及模拟回火 (simulated tempering) 等扩展技术。核心内容是哈密顿蒙特卡洛 (Hamiltonian Monte Carlo, HMC)，这是一种通过引入“动量”变量使每次迭代能在参数空间中移动更远的 Metropolis 算法推广。最后，我们介绍 Stan——一个实现 HMC 的通用软件环境。

2. 高效 Gibbs 采样器

2.1. 变换与参数化. Gibbs 采样器在参数化为独立分量时效率最高。当参数高度相关时（如 ?? 所示），收敛会变得缓慢。解决这一问题最简单的方法是对参数进行线性变换。

注 12.1. 这一原则同样适用于 Metropolis 跳跃。在正态或近似正态的设定中，跳跃核的理想协方差结构应与目标分布相同。

2.2. 辅助变量. 通过添加辅助变量往往可以简化或加速 Gibbs 采样器的计算。例如，混合分布的指标变量就是一种常见的辅助变量。这一思想也称为数据增广 (data augmentation)，在概念上和计算上都是有用的工具。

例 12.1 (t 分布的正态混合表示). 辅助变量的一个简单而重要的例子出现在 t 分布的建模中。 t 分布可以表示为正态分布的混合。考虑从 $t_\nu(\mu, \sigma^2)$ 分布中抽取 n 个独立数据点，给定 μ, σ^2 的似然等价于以下模型：

$$y_i \sim N(\mu, V_i), \quad V_i \sim \text{Inv-}\chi^2(\nu, \sigma^2),$$

其中 V_i 是不可直接观测的辅助变量。

该模型的联合后验分布 $p(\mu, \sigma^2, V|y)$ 可以使用 Gibbs 采样器进行模拟，最终关于 μ, σ 的模拟样本将代表原始 t 模型下的后验分布。

在 t 模型的潜在参数形式中，如果 σ 的模拟值接近零，收敛可能会很慢。通过添加一个额外参数——即参数扩展 (parameter expansion) ——可以打破 τ 与 V_i 之间的相关性，从而改善收敛性。

3. 高效 Metropolis 跳跃规则

对于任何给定的后验分布，Metropolis-Hastings 算法都有无限多种实现方式。即使在重新参数化之后，跳跃规则 J_t 仍有无穷多种选择。

3.1. 两类主要跳跃规则. 第一类是随机游走型跳跃规则，通常使用以当前参数值为中心、方差设定的正态跳跃核。第二类则构造与目标分布近似相同的提议分布，目的是尽可能多地接受样本，而 Metropolis-Hastings 接受步骤主要用于修正近似误差。

3.2. 最优跳跃尺度. 对于 d 维后验分布（经适当变换后为多元正态），使用正态随机游走跳跃核时，最优尺度为

$$c \approx 2.4/\sqrt{d},$$

其中效率是相对于从后验分布独立抽样定义的。对于多元正态目标分布，这一最优 Metropolis 跳跃规则的效率约为 $0.3/d$ 。

最优接受率在一维约为 0.44，在高维（ $d > 5$ ）下降至约 0.23。这一结果提示了一种自适应模拟算法：在并行模拟开始时使用固定算法（如 Gibbs 采样器或正态随机游走 Metropolis 算法），经过一定次数的模拟后，根据接受率调整跳跃规则的尺度。

4. 切片采样

从 d 维目标分布 $p(\theta|y)$ 中随机抽取 θ ，等价于从该分布下的区域（如 ?? 所示的阴影区域）中均匀抽样。形式上，切片采样从 (θ, u) 的 $d+1$ 维分布中抽样，其中对任意 θ ， $p(\theta, u|y) \propto 1$ 当 $u \in [0, p(\theta|y)]$ 时，否则为 0。切片采样在 Gibbs 采样结构中特别有用，可用于抽样一维条件分布。

5. 可逆跳转采样

在许多问题中，需要进行跨维度的马尔可夫链模拟，即参数空间的维度在迭代之间可能发生变化。例如模型平均和有限混合模型就属于这种情况。

可逆跳转采样仍可使用 Metropolis 算法实现。其核心思想是引入额外的随机变量来匹配不同模型间的参数空间维度。

6. 模拟回火与并行回火

多峰分布对马尔可夫链模拟提出了特殊挑战。当两个（或多个）峰被极低后验密度的区域分隔时，链可能长时间停留在单个峰附近。

模拟回火是改善这类问题性能的一种策略。该算法使用一族分布 $p_k(\theta|y)$ ，其中 $p_0(\theta|y) = p(\theta|y)$ ，而 $p_1, \dots, p_K$ 具有相同的基本形状但混合性能更好。并行回火是其变体，在该方法中 $K+1$ 条并行链同时模拟，每条链对应一个密度 q_k 。

7. 哈密顿蒙特卡洛

Gibbs 采样器和 Metropolis 算法的一个固有低效之处在于其随机游走行为——在参数空间中移动时可能需要很长时间才能穿过目标分布。

哈密顿蒙特卡洛（Hamiltonian Monte Carlo, HMC）借鉴物理学中的思想来抑制 Metropolis 算法中的局部随机游走行为，从而使算法能够更快地穿过目标分布。HMC 也称为混合蒙特卡洛，因为它结合了马尔可夫链蒙特卡洛和确定性模拟方法。

7.1. 动量分布. HMC 为目标空间中的每个分量 θ_j 添加一个“动量”变量 ϕ_j 。通常将 ϕ 设为多元正态分布， $\phi \sim N(0, M)$ ，其中 M 是质量矩阵。

7.2. HMC 迭代的三个步骤. HMC 每次迭代包含以下三个部分：

- (1) 从动量的后验分布 $\phi \sim N(0, M)$ 中抽取新值。
- (2) 通过 L 个“蛙跳”步骤同时更新 (θ, ϕ) 。
- (3) 执行接受-拒绝步骤。

蛙跳步骤的核心是：

$$\phi \leftarrow \phi + \frac{1}{2}\epsilon \frac{d \log p(\theta|y)}{d\theta}, \quad \theta \leftarrow \theta + \epsilon M^{-1} \phi, \quad \phi \leftarrow \phi + \frac{1}{2}\epsilon \frac{d \log p(\theta|y)}{d\theta}.$$

接受-拒绝步骤计算

$$r = \frac{p(\theta^*|y)p(\phi^*)}{p(\theta^{t-1}|y)p(\phi^{t-1})},$$

并以概率 $\min(r, 1)$ 接受新值。

注 12.2. HMC 需要后验密度（只需计算到乘法常数）和对数后验密度的梯度。在实际编程中，我们建议同时用数值方法编程梯度作为检查。

7.3. 调优参数设置. HMC 可在三个地方调优：动量变量的概率分布 $p(\phi)$ 、蛙跳步骤的缩放因子 ϵ 以及每次迭代的蛙跳步数 L 。

理论表明，当接受率约为 65% 时 HMC 效率最优。如果接受率过低，应减小 ϵ 并相应增加 L ；如果接受率过高，则增大 ϵ 并减小 L 。

7.4. 无 U 形转弯采样器. 无 U 形转弯采样器 (no-U-turn sampler) 自适应地确定每次迭代的步数 L ，而不是使用固定值。其核心思想是沿轨迹运行直到轨迹开始转向（更准确地说，直到动量变量 ϕ 与从迭代开始时位置 θ 行驶的距离之间的点积达到负值）。

7.5. Riemannian 适应. 另一种优化方法是 Riemannian 适应，将质量矩阵 M 设置为与每一步对数后验密度局部曲率相符的值。该方法可与无 U 形转弯采样器结合使用。

8. Stan：计算环境的开发

哈密顿蒙特卡洛需要一定的编程和调优努力。在更复杂的设置中，我们开发了一个计算机程序 Stan（通过自适应邻域采样）来自动应用 HMC。

Stan 的关键步骤包括：数据和模型的输入、对数后验密度（到任意常数）及其梯度的计算、热身阶段中调优参数的设置、使用无 U 形转弯采样器在参数空间中移动，以及最终的收敛监控和推理汇总。

Stan 使用自动解析微分来计算梯度。对于任意 C++ 表达式，它解析表达式并应用微分的基本规则来构建梯度的 C++ 程序。这种自动微分通常比通过有限差分计算数值梯度快得多。

Stan 还可以在热身阶段自适应地调整质量矩阵 M 和步长 ϵ 。

9. 本章小结

本章我们学习了提高马尔可夫链模拟效率的各种方法：

- (1) **高效 Gibbs 采样器**：通过变换、参数化、添加辅助变量和参数扩展来加速收敛
- (2) **高效 Metropolis 跳跃规则**：最优跳跃尺度 $c \approx 2.4/\sqrt{d}$ ，最优接受率约为 0.44（一维）至 0.23（高维）
- (3) **切片采样**：用于抽样一维条件分布的一般方法
- (4) **可逆跳转采样**：处理跨维度问题的 Metropolis 扩展
- (5) **模拟回火与并行回火**：处理多峰分布的技术

- (6) **哈密顿蒙特卡洛 (HMC)**: 通过引入动量变量消除局部随机游走行为, 特别适合高维问题
- (7) **无 U 形转弯采样器**: HMC 的自适应扩展
- (8) **Stan**: 实现 HMC 的通用软件环境

这些技术共同构成了现代贝叶斯计算的核心工具集, 使得处理复杂层次模型和高维问题成为可能。

10. 下节预告

下一章我们将学习模态和分布近似 (Modal and Distributional Approximations), 这是处理无法使用马尔可夫链模拟的复杂模型的替代方法。

CHAPTER 13

模态与分布近似

1. 本章导论
2. 主要内容
3. 本章小结

Part 4

回归模型

回归模型入门

1. 从多参数模型到回归：一个自然的延伸

在前几章中，我们研究了单参数和多参数模型的推断方法。在单参数模型中，我们学会了如何处理一个未知参数的估计和假设检验；在多参数模型中，我们掌握了处理 nuisance 参数的条件化和边际化技术，并理解了正态模型中均值与方差的联合推断。然而，这些方法在面对现实世界的的数据时往往显得不足。

现实中的数据很少只受单一因素的影响。例如，在教育研究中，学生的成绩可能受到家庭背景、学校质量、个人努力程度等多重因素的共同影响；在医学研究中，病人的康复速度可能同时取决于药物剂量、治疗方式、患者年龄等多种协变量。我们需要一个能够同时处理多个预测变量的统一框架。

这正是回归模型所要解决的问题。回归分析是应用统计学的基石，它允许我们研究一个或多个响应变量与一组预测变量之间的关系。从贝叶斯视角看，回归模型本质上是一个多参数推断问题，其中参数向量 β 表示各个预测变量的效应大小， σ^2 控制噪声的 scale。

历史地看，回归分析的发展经历了几个阶段。Legendre 和 Gauss 在 19 世纪初发展了最小二乘法，Fisher 在 20 世纪初建立了估计的统计理论框架。在贝叶斯传统中，回归分析长期以来被视为一个计算上的挑战——直到马尔科夫链蒙特卡洛方法的出现。1980 年前后，随着计算方法的进步，贝叶斯回归分析才真正进入实用阶段。

本章我们将系统研究贝叶斯回归模型，从最基础的正规线性回归出发，逐步扩展到逻辑回归和稳健回归。在整个过程中，我们将看到共轭先验与非信息先验如何塑造后验推断，以及当预测变量增多时如何选择先验分布。

2. 正规线性回归模型

2.1. 模型设定. 最简单的回归模型假设响应变量 y 与预测变量 $x_1, \dots, x_k$ 之间存在线性关系：

$$(16) \quad y_i = x_i^T \beta + \epsilon_i, \quad \epsilon_i \sim \text{Normal}(0, \sigma^2)$$

其中 $x_i = (1, x_{i1}, \dots, x_{ik})^T$ 是第 i 个观测的预测变量向量（包含截距项）， $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$ 是回归系数向量， σ^2 是误差方差。将所有观测堆叠，我们得到矩阵形式：

$$(17) \quad y = X\beta + \epsilon, \quad \epsilon \sim \text{Normal}(0, \sigma^2 I_n)$$

其中 y 是 $n \times 1$ 响应向量， X 是 $n \times p$ 设计矩阵（ $p = k + 1$ 包含截距）， ϵ 是 $n \times 1$ 误差向量。

2.2. 正规线性回归的充分统计量. 由多元正态分布理论，给定设计矩阵 X ，响应向量 y 的分布为：

$$(18) \quad y \sim \text{Normal}(X\beta, \sigma^2 I_n)$$

其似然函数为：

$$(19) \quad p(y|\beta, \sigma^2) \propto (\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \|y - X\beta\|^2\right)$$

充分统计量是：

$$\hat{\beta} = (X^T X)^{-1} X^T y, \quad \text{RSS} = \|y - X\hat{\beta}\|^2$$

即最小二乘估计和残差平方和。

3. 共轭正态线性回归

3.1. Normal-Gamma 先验. 对于正规线性回归模型 eq. (16)，一个自然的共轭先验分布可以表示为：

$$(20) \quad \beta|\sigma^2 \sim \text{Normal}(\beta_0, \sigma^2 V_0), \quad \sigma^2 \sim \text{Inverse-Gamma}(\nu_0/2, \nu_0 \sigma_0^2/2)$$

这个先验分布在给定 σ^2 的条件下对 β 是正态分布，而 σ^2 自身服从逆 gamma 分布。参数 $(\beta_0, V_0, \nu_0, \sigma_0^2)$ 允许我们表达先验信息。

注 14.1. 逆 gamma 分布作为 σ^2 先验的选择有其历史背景。当与正态似然函数结合时，逆 gamma 先验确保后验分布仍然是闭式可积的。这使得我们可以推导出回归系数的后验分布具有解析形式。

3.2. 后验分布. 结合似然 eq. (19) 和先验 eq. (20)，后验分布 $p(\beta, \sigma^2|y)$ 仍然是一个 Normal-Gamma 分布：

$$(21) \quad \beta|\sigma^2, y \sim \text{Normal}(\beta_n, \sigma^2 V_n), \quad \sigma^2|y \sim \text{Inverse-Gamma}(\nu_n/2, \nu_n \sigma_n^2/2)$$

其中后验参数由下式给出：¹

$$\beta_n = V_n(X^T X \hat{\beta} + V_0^{-1} \beta_0), \quad V_n = (X^T X + V_0^{-1})^{-1}$$

$$\nu_n = \nu_0 + n, \quad \nu_n \sigma_n^2 = \nu_0 \sigma_0^2 + \text{RSS} + (\hat{\beta} - \beta_0)^T (X^T X) (V_0 + V_n) (\hat{\beta} - \beta_0)$$

3.3. 后验预测分布. 给定新的预测变量 x_{new} ，对应的响应变量的后验预测分布为：

$$(22) \quad \tilde{y}|y \sim \text{Student-t}(\nu_n, x_{\text{new}}^T \beta_n, \sigma_n^2 (1 + x_{\text{new}}^T V_n x_{\text{new}}))$$

这是一个自由度为 ν_n 的 Student-t 分布，其位置参数是 $x_{\text{new}}^T \beta_n$ ，scale 参数包含两部分： σ_n^2 反映噪声的不确定性， $x_{\text{new}}^T V_n x_{\text{new}}$ 反映 β 的后验不确定性。

4. 非信息先验分布

在许多实际应用中，我们缺乏可靠的先验信息，希望让数据主导推断。这就引出了非信息先验的选择问题。

¹推导见附录 ??。

4.1. 均匀先验. 一个朴素的非信息先验假设所有参数无差别对待：

$$(23) \quad p(\beta, \sigma^2) \propto \text{常数}$$

在形式上，这是一个异常 (improper) 先验——它在参数空间上不是正规的概率密度函数。但当我们将其与似然函数结合时，如果后验分布是正常的，这个先验仍然可以使用。均匀先验在回归问题中对应于假设 β 和 $\log \sigma^2$ 在参数空间上是平权的。

4.2. Jeffreys' 先验. Jeffreys' 先验是另一种常用的非信息先验，它具有参数化不变性——无论我们如何重新参数化模型，先验分布都会相应变换以保持一致的后验推断。

对于正规线性回归模型，Jeffreys' 先验为：

$$(24) \quad p(\beta, \sigma^2) \propto |X^T X|^{1/2} (\sigma^2)^{-(p+1)/2}$$

其中 p 是 β 的维度。这个先验可以分解为 $p(\beta|\sigma^2) \propto |X^T X|^{1/2} (\sigma^2)^{-p/2}$ 和 $p(\sigma^2) \propto (\sigma^2)^{-1}$ 。

注 14.2. Jeffreys' 先验背后的直觉是：Fisher 信息矩阵的行列式给出了参数空间中局部曲率的度量。Jeffreys' 先验与这些曲率成正比，确保先验不会人为地偏向参数空间的某些区域。

一个更简单的近似是分层先验：

$$(25) \quad p(\beta, \sigma^2) \propto (\sigma^2)^{-1}$$

这个先验在位置-尺度变换下不变，在实践中往往与 Jeffreys' 先验给出非常接近的结果。

5. 多预测变量情形

当预测变量数量较多时，先验分布的选择变得更加微妙。特别地，如何平衡数据的拟合与模型的复杂度成为一个核心问题。

5.1. Zellner 的 g-先验. Zellner 的 g-先验是一类灵活的信息先验，它将先验信息编码为一个额外的观测：

$$(26) \quad \beta|\sigma^2 \sim \text{Normal}(\beta_0, g\sigma^2(X^T X)^{-1})$$

其中超参数 g 控制先验的强度。当 $g \rightarrow \infty$ 时，先验变得越来越模糊，最终退化为非信息先验；当 g 较小时，先验对后验有较强的收缩作用。

g-先验的一个重要性质是后验均值可以在最小二乘估计 $\hat{\beta}$ 和先验均值 β_0 之间实现线性插值：

$$(27) \quad \mathbb{E}(\beta|y) = \frac{n}{n+g}\hat{\beta} + \frac{g}{n+g}\beta_0$$

这体现了贝叶斯推断的核心特征——将先验信息与数据信息以加权平均的方式融合。

5.2. 相关性预测变量的处理. 当预测变量之间存在多重共线性时, $(X^T X)^{-1}$ 可能数值上不稳定。一种解决方案是在 $X^T X$ 的对角线上添加一个小的常数 λ (岭回归的思想):

$$(28) \quad \beta | \sigma^2 \sim \text{Normal}(\beta_0, \sigma^2 (X^T X + \lambda I)^{-1})$$

另一种思路是从变量选择的角度出发, 使用 spike-and-slab 先验或 horseshoe 先验, 将大多数回归系数推向零, 同时允许少数重要变量保留非零系数。

6. 逻辑回归

6.1. 二分类响应变量. 当响应变量是二分类的 ($y_i \in \{0, 1\}$) 时, 正规线性回归不再适用, 因为线性模型可能给出超出 $[0, 1]$ 区间的概率预测。逻辑回归通过引入 link 函数解决了这个问题。

模型设定为:

$$(29) \quad y_i | \beta \sim \text{Bernoulli}(\pi_i), \quad \text{logit}(\pi_i) = x_i^T \beta$$

即:

$$(30) \quad \pi_i = \Pr(y_i = 1 | \beta) = \frac{1}{1 + \exp(-x_i^T \beta)}$$

对数似然函数为:

$$(31) \quad \ell(\beta) = \sum_{i=1}^n [y_i x_i^T \beta - \log(1 + \exp(x_i^T \beta))]$$

6.2. 后验分布与计算. 逻辑回归的后验分布 $p(\beta | y) \propto \exp(\ell(\beta)) \times p(\beta)$ 不再有解析形式。似然函数关于 β 不是二次的, 因此无法通过解析积分得到边际后验分布。

这标志着一个重要的计算转折点: 我们必须借助第 10-12 章介绍的模拟方法来处理这类非共轭模型。常用的策略包括:

- (1) **Metropolis 算法:** 使用对称提议分布 (如正态提议) 在后验分布上生成马尔科夫链。
- (2) **Hamiltonian 蒙特卡洛:** 利用梯度信息构造更高效的提议机制, 特别适合高维参数空间。
- (3) **拉普拉斯近似:** 用正态分布逼近后验模式附近的后验密度, 结合重要性抽样或粒子滤波器。

7. 稳健回归

正规线性回归假设误差服从正态分布, 这一假设在某些实际数据中可能不成立。当数据中存在离群点或重尾噪声时, 正态假设可能导致推断过度受到异常值的影响。

7.1. t 分布误差. 一种自然的稳健化方案是假设误差服从 Student-t 分布而不是正态分布:

$$(32) \quad y_i = x_i^T \beta + \epsilon_i, \quad \epsilon_i \sim \text{Student-t}(\nu, 0, \sigma^2)$$

自由度 ν 控制尾部的厚度。当 $\nu \rightarrow \infty$ 时, t 分布收敛到正态分布; 当 ν 较小时 (如 $\nu = 4$), 分布的尾部更厚, 对离群点的敏感度更低。

从层次化的视角看, Student-t 分布可以分解为一个正态分布与一个隐变量的混合:

$$\epsilon_i | \lambda_i \sim \text{Normal}(0, \sigma^2 / \lambda_i), \quad \lambda_i \sim \text{Gamma}(\nu/2, \nu/2)$$

其中 λ_i 是第 i 个观测的精度尺度因子。这种分解使得我们可以使用 EM 算法或 Gibbs 抽样来计算后验分布。

7.2. 分层混合模型. 另一种稳健回归的框架是使用有限混合分布作为误差模型。例如, 假设误差以概率 $(1 - \pi)$ 来自正态分布, 以概率 π 来自某个污染分布 (通常是尺度更大的正态或均匀分布):

$$(33) \quad \epsilon_i \sim (1 - \pi)\text{Normal}(0, \sigma^1) + \pi\text{Normal}(0, \sigma^2), \quad \sigma^2 > \sigma^1$$

这类模型允许数据自动识别并降低离群点的影响权重, 同时保持对大部分”正常”数据的有效推断。

8. 本章小结

本章我们从贝叶斯视角全面介绍了回归模型:

- (1) **正规线性回归:** 建立了从多参数正态模型到回归分析的自然过渡, 介绍了 Normal-Gamma 共轭先验和后验分布的闭式形式。
- (2) **非信息先验:** 讨论了均匀先验和 Jeffreys' 先验的选择, 以及它们在缺乏先验信息时的应用。
- (3) **多预测变量:** 介绍了 Zellner 的 g-先验作为信息先验与无信息先验之间的桥梁, 以及处理高度相关预测变量的岭回归策略。
- (4) **逻辑回归:** 从二分类响应变量出发, 引入了 link 函数和后验分布的不可解析性, 为后续章节的模拟计算方法埋下伏笔。
- (5) **稳健回归:** 通过 t 分布误差和有限混合误差模型展示了如何处理偏离正态假设的数据。

回归分析将我们在前几章学习的参数推断技术扩展到了更复杂的实际场景。同时, 本章也展示了贝叶斯方法在处理不同数据类型 (连续、二分类、存在离群点的数据) 时的灵活性。

9. 习题

练习 14.1. 14.1 正规线性回归的后验均值 证明在使用共轭 Normal-Gamma 先验 eq. (20) 时, 后验均值满足 eq. (27) 的特例形式 (即 $\beta_0 = 0$ 且 $V_0 = (X^T X)^{-1}$ 的情形)。

练习 14.2. 14.2 Jeffreys' 先验的性质 验证 Jeffreys' 先验 eq. (24) 可以分解为 $p(\beta | \sigma^2) \propto (\sigma^2)^{-p/2}$ 和 $p(\sigma^2) \propto (\sigma^2)^{-1}$ 两部分的乘积。

练习 14.3. 14.3 逻辑回归的后验预测 描述如何使用 Metropolis 算法从逻辑回归模型的后验分布 $p(\beta | y)$ 中抽取样本, 并说明如何利用这些样本计算后验预测分布 $\Pr(\tilde{y} = 1 | y)$ 。

练习 14.4. 14.4 t 分布误差的层次表示 证明在层次表示 $\epsilon_i | \lambda_i \sim \text{Normal}(0, \sigma^2 / \lambda_i)$, $\lambda_i \sim \text{Gamma}(\nu/2, \nu/2)$ 下, ϵ_i 的边际分布是 Student-t 分布 eq. (32)。

练习 14.5. 14.5 g-先验的收缩性质 令 g 为 Zellner g-先验 eq. (26) 中的超参数。证明后验均值 $\mathbb{E}(\beta|y)$ 可以写成 eq. (27) 的形式, 并说明当 g 增大时, 后验均值如何收缩向先验均值。

练习 14.6. 14.6 稳健回归与离群点 对比使用正态误差假设与 t 分布误差假设的线性回归在后验预测分布上的差异。通过直觉和数学两方面说明 t 分布误差为何对离群点更加稳健。

分层线性模型

1. 本章导论

在第七章和第十二章中，我们已经掌握了贝叶斯推断的基本框架，并学会了使用马尔科夫链蒙特卡洛 (MCMC) 方法处理复杂的后验分布。当数据具有分组结构时——例如，来自多所学校的学生成绩、多次临床试验的患者反应、或不同工厂的生产质量指标——我们需要一种更精细的工具来同时捕捉组内相关性和组间异质性。

分层线性模型 (Hierarchical Linear Models, HLM) 正是为解决这个问题而诞生的统计框架。它允许我们在不同层次上对数据进行建模：个体层次的变异和组层次的变异自然地纳入统一的概率模型中。从历史上看，分层线性模型的发展源于教育研究（中学的“学校效应”问题）、生物统计（生长曲线分析）和社会学（邻里效应研究），并在 1980 年代由 Bryk, Raudenbush 等人系统化为一套完整的统计方法论。

本章我们将学习如何将分层思想与线性回归结合，建立分层线性模型；如何用贝叶斯方法进行推断；以及如何从矩阵形式理解模型的本质。我们将看到，分层模型不仅是处理分组数据的工具，更是一种在“合并信息”与“保持特异性”之间寻求平衡的哲学。

2. 从分组数据到分层模型

2.1. 传统方法的困境. 考虑一个经典问题：估计 J 所学校的培训效果。每所学校 j 报告了一个效果估计 y_j 及其标准误 σ_j 。一个 naive 的做法是简单地将所有 y_j 取平均作为总体效果估计。但这种方法忽略了一个关键事实：不同学校之间本身就可能存在系统性差异。

另一方面，如果我们分别为每所学校估计效果，就完全忽略了数据可以“相互学习”这一事实。例如，学校 3 的估计精度很低 (σ_3 很大)，但其他学校的数据可以帮助我们改进对它的估计。

这就是分层模型要解决的核心问题：如何在保持组特异性估计的同时，充分利用数据的层次结构进行信息共享。

2.2. 两层次模型框架. 一般的两层次线性模型可以写为：

(1) **第一层 (组内模型):** $y_{ij} = \mathbf{x}_{ij}^\top \boldsymbol{\beta}_j + \epsilon_{ij}$, 其中 $\epsilon_{ij} \sim N(0, \sigma^2)$

(2) **第二层 (组间模型):** $\boldsymbol{\beta}_j = \mathbf{A}_j \boldsymbol{\gamma} + \mathbf{u}_j$, 其中 $\mathbf{u}_j \sim N(\mathbf{0}, \boldsymbol{\Sigma})$

这里 y_{ij} 是第 j 组第 i 个观测值， $\mathbf{x}_{ij}$ 是协变量向量， $\boldsymbol{\beta}_j$ 是第 j 组的效应向量， $\boldsymbol{\gamma}$ 是总体 (总体层面) 效应， $\mathbf{A}_j$ 是已知的设计矩阵， $\boldsymbol{\Sigma}$ 是组间协方差矩阵。

将两层结合，我们可以写出完整的分层模型：

$$y_{ij} = \mathbf{x}_{ij}^\top \mathbf{A}_j \boldsymbol{\gamma} + \mathbf{x}_{ij}^\top \mathbf{u}_j + \epsilon_{ij}$$

其中 $\mathbf{u}_j$ 和 ϵ_{ij} 相互独立。

3. 分层线性模型的矩阵形式

3.1. 模型的一般表达. 将所有数据堆叠为向量形式，分层线性模型可以紧凑地写为：

$$\mathbf{y} = \mathbf{X}\boldsymbol{\gamma} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon}$$

其中:

- $\mathbf{y}$ 是 $n \times 1$ 观测向量
- $\mathbf{X}$ 是 $n \times p$ 固定效应设计矩阵
- $\boldsymbol{\gamma}$ 是 $p \times 1$ 固定效应参数
- $\mathbf{Z}$ 是 $n \times q$ 随机效应设计矩阵
- $\mathbf{u}$ 是 $q \times 1$ 随机效应向量, $\mathbf{u} \sim N(\mathbf{0}, \boldsymbol{\Sigma})$
- $\boldsymbol{\epsilon}$ 是 $n \times 1$ 误差向量, $\boldsymbol{\epsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$

随机效应 $\mathbf{u}$ 和误差 $\boldsymbol{\epsilon}$ 相互独立, 因此 $\mathbf{y}$ 的边际分布为:

$$\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\gamma}, \mathbf{V}), \quad \mathbf{V} = \sigma^2 \mathbf{I}_n + \mathbf{Z}\boldsymbol{\Sigma}\mathbf{Z}^\top$$

注 15.1. 边际分布 $\mathbf{y} \sim N(\mathbf{X}\boldsymbol{\gamma}, \mathbf{V})$ 正是我们在第八章学到的贝叶斯线性回归形式, 只不过这里的协方差矩阵 $\mathbf{V}$ 依赖于方差参数 σ^2 和 $\boldsymbol{\Sigma}$ 。

3.2. 组结构的矩阵表示. 考虑 J 组、每组 n_j 观测的经典情形。设 $\mathbf{y}_j$ 是第 j 组的 $n_j \times 1$ 观测向量, $\mathbf{X}_j$ 是对应的矩阵。模型可写为:

$$\mathbf{y}_j = \mathbf{X}_j\boldsymbol{\gamma} + \mathbf{Z}_j\mathbf{u}_j + \boldsymbol{\epsilon}_j, \quad \boldsymbol{\epsilon}_j \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_{n_j})$$

其中 $\mathbf{u}_j \sim N(\mathbf{0}, \boldsymbol{\Sigma}_{\mathbf{u}})$ 是组 j 的随机效应。

整个数据的似然函数为:

$$p(\mathbf{y} | \boldsymbol{\gamma}, \sigma^2, \boldsymbol{\Sigma}) = \prod_{j=1}^J N(\mathbf{y}_j | \mathbf{X}_j\boldsymbol{\gamma}, \sigma^2 \mathbf{I}_{n_j} + \mathbf{Z}_j\boldsymbol{\Sigma}\mathbf{Z}_j^\top)$$

4. 后验推断

4.1. 完全条件分布. 在贝叶斯分层模型中, 我们通常关注以下后验分布:

$$p(\boldsymbol{\gamma}, \mathbf{u}, \sigma^2, \boldsymbol{\Sigma} | \mathbf{y})$$

为方便 MCMC 抽样, 我们使用 Data augmentation 技术, 引入隐变量 $\mathbf{u}$ 。完全数据模型为:

$$\begin{aligned} \mathbf{y}_j | \mathbf{u}_j, \boldsymbol{\gamma}, \sigma^2 &\sim N(\mathbf{X}_j\boldsymbol{\gamma} + \mathbf{Z}_j\mathbf{u}_j, \sigma^2 \mathbf{I}_{n_j}) \\ \mathbf{u}_j | \boldsymbol{\Sigma} &\sim N(\mathbf{0}, \boldsymbol{\Sigma}) \end{aligned}$$

完全条件分布为:

$$\begin{aligned} \boldsymbol{\gamma} | \mathbf{y}, \mathbf{u}, \sigma^2 &\sim N(\boldsymbol{\mu}_{\boldsymbol{\gamma}}, \boldsymbol{\Sigma}_{\boldsymbol{\gamma}}) \\ \mathbf{u}_j | \mathbf{y}, \boldsymbol{\gamma}, \sigma^2, \boldsymbol{\Sigma} &\sim N(\boldsymbol{\mu}_{\mathbf{u}_j}, \boldsymbol{\Sigma}_{\mathbf{u}_j}) \\ \sigma^2 | \mathbf{y}, \boldsymbol{\gamma}, \mathbf{u}, \boldsymbol{\Sigma} &\sim \text{Inverse-}\chi^2(\nu_n, \sigma_n^2) \end{aligned}$$

其中后验均值和方差的具体形式依赖于数据的分组结构。¹

¹完全条件分布的详细推导见附录 ??。

4.2. 分层先验的构建. 对超参数 Σ 的先验选择是分层模型的关键。几种常见选择：

- (1) **逆 Wishart 先验:** $\Sigma \sim -Wishart(\nu_0, \Sigma_0)$
- (2) **独立逆 Gamma 先验:** 对方差分量独立建模
- (3) **弱信息先验:** 使用半参数或数据驱动的先验

当方差分量接近零时，逆 Wishart 先验可能导致后验分布出现拖尾问题。因此，实际中常使用对数尺度上的先验，例如：

$$\log(\sigma_j^2) \sim N(\mu_0, \tau_0^2)$$

5. 预测

分层模型的一个重要应用是预测新组或新观测的值。

5.1. 组均值预测. 给定新组 j^* 的协变量 $\mathbf{x}_{j^*}$ ，我们希望预测其效应 $\beta_{j^*} = \mathbf{A}_{j^*}\gamma + \mathbf{u}_{j^*}$ 。后验预测分布为：

$$\beta_{j^*} | \mathbf{y} \sim N(\boldsymbol{\mu}_{\beta_{j^*}}, \boldsymbol{\Sigma}_{\beta_{j^*}})$$

其中后验均值是总体效应 γ 的后验均值和组特异偏差 $\mathbf{u}_j$ 的后验均值的加权组合。²

5.2. 新观测预测. 对于新组 j^* 的新观测 y_{new} ，预测分布为：

$$y_{new} | \mathbf{y} \sim N(\mathbf{x}_{new}^\top \boldsymbol{\mu}_{\beta_{j^*}}, \sigma^2 + \mathbf{x}_{new}^\top \boldsymbol{\Sigma}_{\beta_{j^*}} \mathbf{x}_{new})$$

注意预测方差包括两部分：观测误差方差 σ^2 和参数不确定性方差 $\mathbf{x}_{new}^\top \boldsymbol{\Sigma}_{\beta_{j^*}} \mathbf{x}_{new}$ 。

6. 方差分量估计

6.1. 方差分量模型. 最简单的分层线性模型是所谓的**方差分量模型** (variance components model)：

$$y_{ij} = \mu + u_j + \epsilon_{ij}$$

其中 $u_j \sim N(0, \sigma_u^2)$ 是组效应， $\epsilon_{ij} \sim N(0, \sigma_\epsilon^2)$ 是个体误差。组内相关系数 (ICC) 为：

$$\text{ICC} = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_\epsilon^2}$$

ICC 衡量了总变异中有多大比例来自组间变异。

6.2. 边缘化与 EM 算法. 对随机效应 $\mathbf{u}$ 进行边缘化后，似然函数涉及高维积分。使用 EM 算法可以方便地估计方差分量。

E 步：计算随机效应的后验均值和协方差

$$\hat{\mathbf{u}}_j^{(t)} = \boldsymbol{\Sigma}_j \mathbf{Z}_j^\top \mathbf{V}_j^{-1} (\mathbf{y}_j - \mathbf{X}_j \hat{\boldsymbol{\gamma}}^{(t)})$$

M 步：更新参数估计

$$\hat{\boldsymbol{\gamma}}^{(t+1)} = \left(\sum_j \mathbf{X}_j^\top \mathbf{V}_j^{-1} \mathbf{X}_j \right)^{-1} \sum_j \mathbf{X}_j^\top \mathbf{V}_j^{-1} (\mathbf{y}_j - \mathbf{Z}_j \hat{\mathbf{u}}_j^{(t)})$$

²组均值预测的详细推导见附录 ??。

方差分量的更新涉及更复杂的估计方程。³

7. 相关作业干预示例

考虑一个经典的教育研究问题：估计 $J = 8$ 所学校的培训效果。

7.1. 问题背景. 每所学校报告了培训效果估计 y_j 和标准误 σ_j 。数据如下：

学校 j	估计 y_j	标准误 σ_j
1	28.4	14.9
2	7.0	10.2
3	-4.4	16.3
4	7.0	11.0
5	1.9	9.4
6	6.6	10.5
7	10.8	17.6
8	33.1	15.6

7.2. 模型设定. 我们设定分层模型：

$$\begin{aligned} y_j | \theta_j &\sim N(\theta_j, \sigma_j^2) \\ \theta_j | \mu, \tau &\sim N(\mu, \tau^2) \\ \mu &\sim N(0, 100^2), \quad \tau \sim \text{Half-Cauchy}(0, 25) \end{aligned}$$

其中 θ_j 是学校 j 的真实效果， μ 是总体效果， τ 是学校间标准差。

7.3. 后验推断. 使用 MCMC 方法，我们可以得到 θ_j 的后验分布。关键发现是：

注 15.2. 后验均值是先验均值 (0) 和数据均值 y_j 的加权平均，权重由精度（方差的倒数）给出。当 τ 小时，所有 θ_j 被强烈收缩到公共均值 μ ；当 τ 大时，每个 θ_j 主要由其自身数据决定。

这个例子展示了分层模型的核心优势：它提供了在合并信息和保持特异性之间的自然权衡。

8. 稳健推断

当数据存在异常值或偏离正态假设时，标准分层线性模型可能失效。

8.1. 稳健误差分布. 一种方法是使用 Student- t 分布替代正态分布作为误差分布：

$$\epsilon_{ij} \sim \text{Student-}t(\nu, 0, \sigma^2)$$

当 $\nu \rightarrow \infty$ 时，Student- t 分布趋近于正态分布；当 ν 较小时，分布的尾部更重，对异常值更稳健。

另一种方法是使用污染正态模型：

$$\epsilon_{ij} \sim (1 - \epsilon)N(0, \sigma^2) + \epsilon N(0, k\sigma^2)$$

其中 ϵ 是污染比例， k 是方差放大因子。

³EM 算法对方差分量的更新公式见附录 ??。

8.2. 分层先验的稳健性. 对方差分量使用弱信息先验可以提高稳健性。Half-t 先验和 Horseshoe 先验是常用的选择。

注 15.3. 选择先验时，应该考虑参数的尺度。例如，在 $\log(\tau)$ 上指定先验通常比在 τ 上更合理，因为前者保证 τ 始终为正。

9. 本章小结

本章我们学习了分层线性模型的贝叶斯分析框架：

- (1) **模型构建**：通过两层结构同时捕捉组内变异和组间变异
- (2) **矩阵形式**：将分层模型表达为 $\mathbf{y} = \mathbf{X}\boldsymbol{\gamma} + \mathbf{Z}\mathbf{u} + \boldsymbol{\epsilon}$
- (3) **后验推断**：利用完全条件分布进行 MCMC 抽样
- (4) **预测**：提供组均值和新观测的预测分布
- (5) **方差分量**：通过 ICC 等指标量化组间变异的重要性
- (6) **稳健推断**：使用 Student- t 误差或污染正态模型处理异常值

分层线性模型是现代贝叶斯统计中最重要的工具之一，它的核心思想——在部分合并和完全分离之间寻求平衡——贯穿于整个统计学。

10. 下节预告

下一章我们将学习广义线性模型 (Generalized Linear Models)，这是将分层框架推广到非正态数据的关键步骤。

CHAPTER 16

广义线性模型

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 17

稳健推断模型

1. 本章导论
2. 稳健性的各个方面
3. 标准概率模型的过度分散版本
4. 后验推断与计算
5. 八校例子中的稳健推断与敏感性分析
6. 使用 t 分布误差的稳健回归
7. 本章小结

缺失数据模型

1. 本章导论

在现实世界的统计研究中，缺失数据几乎无处不在——调查中的无响应、医学试验中的受试者退出、工业生产中的零件损坏。简单地丢弃不完整的观测会导致严重的偏倚，并低估推断的不确定性。

传统的统计方法往往假设数据是“完美”采集的，即每个应观测的变量都被记录下来。这一假设在许多应用中显然不成立。忽视缺失数据的存在，以“完全案例分析”（complete-case analysis）为例，只使用没有缺失值的观测，会导致估计量的偏倚。更隐蔽的是，完全案例分析通常会低估方差，因为它错误地假设样本量等于实际分析的观测数。

1976 年，Donald Rubin 首次系统性地提出了缺失机制的分类框架 [?], 将缺失数据分为完全随机缺失、随机缺失和非随机缺失三类。这一框架至今仍是该领域的标准，被广泛应用于生物统计、社会科学和计量经济学等领域。Rubin 的核心洞见是：缺失数据的处理方法应该依赖于缺失机制的性质，而正确识别缺失机制对于获得无偏估计至关重要。

本章我们将学习如何用概率模型描述数据的缺失机制，以及如何在贝叶斯框架下进行正确的推断。核心思想是：将缺失数据视为潜在的随机变量，为其指定概率模型，然后在完全贝叶斯分析中同时推断所有未知量。

2. 缺失数据机制

2.1. 为什么需要描述缺失机制？ 当我们面对缺失数据时，一个关键的问题是：哪些数据缺失了？为什么它们缺失了？

如果某些变量值的缺失与这些变量本身的值有关——例如，高收入人群更不愿意报告他们的工资——那么简单的补齐方法（如用均值填充）会产生严重偏倚。缺失机制（missing data mechanism）描述了缺失值与其对应变量的关系。

统计学家 Rubin [?] 将缺失机制分为三类，这一分类至今仍是该领域的标准框架。

2.2. 三种缺失机制.

- (1) **完全随机缺失 (MCAR)**: 缺失与观测数据或缺失数据都无关。例如，由于设备故障导致某些测量值丢失。
- (2) **随机缺失 (MAR)**: 缺失只依赖于观测数据，而与缺失数据本身无关。例如，老年受试者更可能错过随访，但他们是否存活与是否参与随访无关（给定年龄）。
- (3) **非随机缺失 (MNAR)**: 缺失依赖于缺失数据本身。例如，抑郁程度更严重的患者更可能退出治疗研究。

注 18.1. MCAR 是最强的假设，意味着缺失是“真正随机”的。MAR 是许多多重插补方法的基础假设，但 MAR 假设本身无法从数据中验证——我们无法仅凭观测数据判断 MAR 是否成立，这正是敏感度分析存在的原因。MNAR 最难处理，因为它要求对缺失机制进行明确的建模。

在贝叶斯分析中，我们通常假设缺失机制是**可忽略的 (ignorable)**，这要求两个条件：

- (1) **MAR (随机缺失)**: 给定观测数据，缺失与否与缺失数据条件独立

(2) **区分性 (Distinctness)**: 完整数据模型的参数与缺失机制模型的参数是独立的

3. 贝叶斯推断中的可忽略性

3.1. 可忽略性的含义. 当缺失数据机制是可忽略的时候, 我们可以在贝叶斯推断中“忽略”它——即不需要显式地建模缺失机制。后验分布只需基于观测数据的边际分布:

$$p(\theta|y_{\text{obs}}) \propto p(\theta)p(y_{\text{obs}}|\theta)$$

如果缺失机制不可忽略, 后验分布需要包含缺失机制模型:

$$p(\theta, \psi|y_{\text{obs}}) \propto p(\theta)p(\psi)p(y_{\text{obs}}, r|\theta, \psi)$$

其中 ψ 是缺失机制模型的参数, r 是缺失指示向量。

注 18.2. 区分性条件在实践中通常容易满足——我们通常假设数据模型和缺失机制模型的参数是不同的、独立的。例如, 在正态均值估计中, 均值参数 μ 与缺失概率参数通常是独立的。

3.2. 什么时候可忽略性成立? 可忽略的贝叶斯推断 (ignorability) 在以下情况成立:

- (1) **MCAR 情况**: 缺失完全随机, 任何基于观测数据的推断都是无偏的 (但可能低效)
- (2) **MAR + 正确模型**: 如果正确指定了条件缺失模型, 且参数与数据模型区分
- (3) **参数先验独立**: 完整数据参数与缺失机制参数的先验分布相互独立

4. 联合建模方法

4.1. 完全数据模型. 联合建模方法 (joint modeling approach) 同时指定:

- (1) **完全数据模型** $p(y_{\text{obs}}, y_{\text{mis}}|\theta)$
- (2) **缺失机制模型** $p(r|y_{\text{obs}}, y_{\text{mis}}, \psi)$

联合后验分布为:

$$p(\theta, \psi, y_{\text{mis}}|y_{\text{obs}}, r) \propto p(\theta)p(\psi)p(y_{\text{obs}}, y_{\text{mis}}|\theta)p(r|y_{\text{obs}}, y_{\text{mis}}, \psi)$$

例 18.1 (二元数据的缺失机制). 假设 $y_i \in \{0, 1\}$ 是二项结果, 缺失指示 r_i 服从 logistic 模型:

$$\text{logit}(\mathbb{P}(r_i = 1)) = \psi_0 + \psi_1 y_i$$

当 $\psi_1 \neq 0$ 时, 缺失依赖于潜在结果 y_i , 这是 MNAR 情形。当 $\psi_1 = 0$ 时, 缺失是 MCAR。

我们可以在联合框架下估计 ψ_1 , 检验缺失机制是否依赖于潜在结果。

推导见附录 ??。

联合建模的优点是提供了缺失机制的完整描述; 缺点是需要对缺失机制做出明确的参数化假设, 而这些假设往往难以验证。

5. 全贝叶斯方法与多重插补

5.1. 将缺失数据作为参数. 在全贝叶斯方法中, 我们将缺失数据本身视为需要推断的参数。与潜在变量一样, 缺失值 y_{mis} 被赋予先验分布, 然后通过 MCMC 同时抽样 θ 和 y_{mis} 。

完整的分层结构为:

- (1) **数据层:** $y_{\text{obs}}, y_{\text{mis}} | \theta \sim p(y | \theta)$
- (2) **参数层:** $\theta \sim p(\theta)$
- (3) **缺失机制层:** $r | y_{\text{obs}}, y_{\text{mis}}, \psi \sim p(r | y, \psi)$

在 MAR 和可忽略性条件下, 我们可以忽略缺失机制, 只关注:

$$p(\theta, y_{\text{mis}} | y_{\text{obs}}) \propto p(\theta) p(y_{\text{mis}} | \theta) p(y_{\text{obs}} | \theta, y_{\text{mis}})$$

5.2. 多重插补. 多重插补 (multiple imputation) 是一种实用的缺失数据处理技术, 通过创建多个 (通常是 $m = 5$ 到 $m = 50$) 完整数据集来反映缺失数据的不确定性。¹

插补阶段: 给定观测数据和当前参数值, 从后验分布中抽取缺失值:

$$y_{\text{mis}}^{(l)} \sim p(y_{\text{mis}} | y_{\text{obs}}, \theta^{(l)})$$

分析阶段: 对每个插补数据集应用标准的完全数据分析方法。

合并阶段: 使用 Rubin 组合规则将 m 个分析结果合并。

对于点估计 $\hat{Q}_l$ 和方差估计 U_l ($l = 1, \dots, m$), 合并的估计为:

$$\bar{Q} = \frac{1}{m} \sum_{l=1}^m \hat{Q}_l$$

总方差的分解是 Rubin 组合规则的核心洞见: 总方差 T 由两部分组成——来自数据分析的抽样方差 $\bar{U}$ 和来自缺失数据不确定性的插补间方差 B 。具体形式为:

$$T = \bar{U} + \left(1 + \frac{1}{m}\right) B$$

其中 $\bar{U} = \frac{1}{m} \sum_{l=1}^m U_l$ 是 within-imputation 方差, $B = \frac{1}{m-1} \sum_{l=1}^m (\hat{Q}_l - \bar{Q})^2$ 是 between-imputation 方差。

自由度为:

$$\nu = (m-1) \left(1 + \frac{\bar{U}}{(1 + 1/m)B}\right)^2$$

注 18.3. 多重插补的关键洞见是: 总方差 T 包括两个部分——来自数据分析的抽样方差 $\bar{U}$ 和来自缺失数据不确定性的插补间方差 B 。忽视后者会严重低估总体不确定性。

6. 敏感度分析

6.1. 为什么需要敏感度分析? 在 MNAR 情况下, 缺失机制是不可忽略的, 分析结果严重依赖于我们对缺失机制的假设。敏感度分析 (sensitivity analysis) 系统地检验: 当缺失机制的假设发生变化时, 结论如何变化?

即使在 MAR 情况下, 如果模型误设 (model misspecification), 结论也可能对模型假设敏感。

¹Rubin 组合规则的完整推导见附录 ??。

6.2. 敏感度分析的实施方式. 敏感度分析有多种实施方式:

- (1) **情景规划 (Scenario-based)**: 定义几个关于缺失机制的合理情景, 比较不同情景下的推断
- (2) **扰动分析 (Perturbation)**: 在似然函数或先验上引入小扰动, 观察后验的稳定性
- (3) **选择模型 (Selection model)** vs **模式混合模型 (pattern-mixture model)**: 两种互补的建模框架

选择模型方法将联合分布分解为:

$$p(y, r) = p(y)p(r|y)$$

模式混合模型则分解为:

$$p(y, r) = \sum_k p(r = k)p(y|r = k)$$

其中 k 表示不同的缺失模式 (完全观测、部分缺失、完全缺失等)。

例 18.2 (基于 Pattern-Mixture 的敏感度分析). 假设二分之一的数据是完全观测的, 其余二分之一在处理后缺失。模式混合方法对每种模式分别建模:

$$y_{\text{obs},1}|\theta \sim N(\mu, \sigma^2)$$

$$y_{\text{obs},2}|\theta \sim N(\mu + \Delta, \sigma^2)$$

其中 Δ 衡量”缺失值与观测值的平均差异”。通过设定不同的 Δ 值(如 $\Delta = 0, \pm 0.5\sigma, \pm\sigma$), 我们可以评估结论对 Δ 的敏感程度。

推导见附录 ??。

7. 缺失数据的实际处理策略

7.1. 完整案例分析. 仅使用所有变量都被观测到的案例。优点是简单, 缺点是:

- (1) 如果 MCAR 不成立, 会产生偏倚
- (2) 浪费了部分观测的信息
- (3) 方差估计基于不正确的样本量

7.2. 单一插补. 用单一值 (如均值、条件均值) 填充缺失值。问题在于:

- (1) 忽略了缺失数据的不确定性
- (2) 通常会低估方差
- (3) 可能扭曲数据的分布

7.3. 逆概率加权. 在 MAR 假设下, 通过对观测案例赋予权重来校正缺失偏倚。权重与缺失概率的倒数成正比:

$$w_i = \frac{1}{\mathbb{P}(r_i = 1|x_i)}$$

缺点是当缺失概率接近 0 时权重会变得极大, 导致不稳定。

注 18.4. 在实际应用中, 多重插补通常是处理 MAR 数据的最稳健选择, 因为它既保留了观测数据的信息, 又通过多个插补反映了缺失的不确定性。

8. 本章小结

本章我们学习了：

- (1) 三种缺失数据机制：MCAR、MAR、MNAR [?]
- (2) 可忽略性条件：MAR + 区分性
- (3) 联合建模方法：同时建模完全数据和缺失机制
- (4) 全贝叶斯方法：将缺失值作为参数进行 MCMC 推断
- (5) 多重插补：Rubin 组合规则和方差的分解
- (6) 敏感度分析：检验结论对缺失机制假设的依赖性
- (7) 实际处理策略的优缺点比较

缺失数据处理没有“一刀切”的解决方案。统计学家需要根据数据的具体缺失模式、缺失机制的合理性假设、以及计算资源，选择最合适的方法。在任何情况下，透明报告缺失数据的数量、模式和处理的假设，都是负责任的统计实践的基本要求。

9. 下节预告

下一章我们将学习参数非线性模型 (Parametric Nonlinear Models)，这是对线性模型和广义线性模型的自然推广，允许更灵活的函数关系建模。

Part 5

非参数模型

参数非线性模型

1. 本章导论

在前几章中，我们主要关注线性模型——那些将参数以线性组合形式出现在均值函数中的模型。线性模型之所以被广泛使用，部分原因是它们易于解释：系数可以直接解读为“当自变量增加一个单位时，因变量期望值的变化”。然而，现实世界中的许多现象本质上是非线性的。

考虑几个简单的问题：光合作用如何随光照强度增加而变化？药物在体内的浓度如何随时间衰减？捕食者与被捕食者的种群数量如何相互影响？这些问题都无法用简单的线性关系来描述——它们涉及饱和效应、指数衰减、振荡等非线性现象。这就引出了本章的核心问题：**如何对这类非线性现象进行贝叶斯建模和推断？**

参数非线性模型为这个问题提供了一个优雅的解决方案。与非参数方法不同，我们仍然使用有限个参数来描述数据的生成机制；但与线性模型不同的是，这些参数以非线性方式出现在均值函数中。这种介于“完全参数化”与“完全非参数化”之间的方法，在许多科学领域有着悠久的应用历史，并在贝叶斯框架下获得了新的生命力。

2. 非线性模型的实例

2.1. 光合作用与饱和效应. 在生态学中，研究光合作用速率如何随光照强度变化是一个经典问题。1975 年，Jassby 和 Platform 提出了以下模型来描述这一关系：

$$(34) \quad f(x) = \alpha \left(1 - \exp \left(-\frac{x}{\alpha} \right) \right),$$

其中 x 是光照强度， $f(x)$ 是对应的光合作用速率， α 是最大光合作用速率。¹

这个模型捕捉了一个关键的非线性特征：**饱和效应**。当光照较弱时，光合作用速率近似线性增长；但随着光照强度的增加，增长速度逐渐放缓，最终趋于一个渐近值 α 。这种“边际效用递减”的现象在许多领域都有出现：药物疗效随剂量增加而饱和、学习曲线随练习增加而趋于平缓等。

2.2. 药物动力学：一室模型. 在药理学中，描述药物浓度随时间变化的模型是临床用药的基础。考虑最简单的一室模型：药物通过静脉注射进入血液，然后以固定速率从体内清除。设 y 表示在时间 t 测量的药物浓度，模型为

$$(35) \quad y = \frac{D}{V} \exp \left(-\frac{t}{\tau} \right) + \epsilon,$$

其中 D 是给药剂量， V 是表观分布容积， $\tau = V/k$ 是平均滞留时间（ k 是清除率）， $\epsilon \sim N(0, \sigma^2)$ 是测量误差。²

¹光合作用模型的推导及生理学解释见附录 ??。

²一室模型的药代动力学推导见附录 ??。

这个模型的非线性性来源于指数函数中的 τ 参数。指数衰减是非线性的：参数 τ 出现在指数的指数位置，而不是作为简单的乘法系数。

2.3. 种群动力学模型. 生物学中描述种群增长的经典模型也具有非线性结构。

逻辑斯谛模型 (Logistic growth) 假设种群增长率随种群规模增加而下降：

$$(36) \quad \frac{dN}{dt} = rN \left(1 - \frac{N}{K}\right),$$

其中 $N(t)$ 是时间 t 的种群规模， r 是固有增长率， K 是环境容纳量。解这个微分方程得到

$$(37) \quad N(t) = \frac{K}{1 + \exp(-rt + \phi)},$$

其中 ϕ 是与初始条件相关的参数。

Ricker 模型是另一个经典的离散时间种群模型：

$$(38) \quad N_{t+1} = N_t \exp \left(r \left(1 - \frac{N_t}{K}\right) \right),$$

这个模型用于描述鱼类等水产资源的种群动态，其中产卵量与亲代数量呈指数关系，但环境阻力导致幼鱼存活率下降。

Lotka-Volterra 捕食者-猎物模型描述两个物种的相互作用：

$$(39) \quad \frac{dx}{dt} = \alpha x - \beta xy,$$

$$(40) \quad \frac{dy}{dt} = \delta xy - \gamma y,$$

其中 x 是猎物数量， y 是捕食者数量。³

3. 非线性最小二乘估计

3.1. 最小二乘框架. 对于非线性模型，估计参数的标准方法是最小二乘法。给定观测数据 (t_i, y_i) , $i = 1, \dots, n$ ，我们最小化残差平方和

$$(41) \quad \text{SSE}(\theta) = \sum_{i=1}^n [y_i - f(t_i, \theta)]^2,$$

其中 $f(t, \theta)$ 是非线性均值函数， θ 是 k 维参数向量。

与线性回归不同，非线性最小二乘估计没有闭式解，必须通过迭代优化算法求解。常用的算法包括：

- (1) **高斯-牛顿法 (Gauss-Newton)**：使用一阶导数近似 Hessian 矩阵
- (2) **Levenberg-Marquardt 法**：在高斯-牛顿法与最速下降法之间插值
- (3) **牛顿法**：使用二阶导数，更精确但计算成本更高

在 R 中，可以使用 `nls()` 函数实现这些算法。

³Lotka-Volterra 模型的详细推导及平衡点分析见附录 ??。

3.2. 初始值与迭代收敛. 非线性最小二乘估计的一个关键挑战是**初始值的选择**。与线性模型不同，非线性优化通常不是凸的，可能存在多个局部极小值。因此，初始值的选择对最终估计有重要影响。

在实际应用中，初始值通常通过以下方式确定：

- (1) **物理或生物学直觉**：基于对问题域的理解，估计参数的大致范围
- (2) **数据可视化**：绘制数据图，估算渐近值、增长率等参数
- (3) **简化模型拟合**：先拟合简化（线性化）的模型，获取参数初始估计
- (4) **网格搜索**：在参数空间中搜索，找到使 SSE 全局最小的区域

在 R 中实现带 bootstrap 的非线性最小二乘：

R 代码示例：光合作用模型的非线性最小二乘拟合

```
library(nls)
```

```
# 数据
```

```
x <- c(0, 50, 100, 150, 200, 250, 300, 350, 400, 450, 500)
```

```
y <- c(4.2, 11.1, 19.5, 25.8, 30.2, 33.5, 35.8, 37.2, 38.1, 38.9, 39.2)
```

```
# 非线性最小二乘拟合
```

```
fit <- nls(y ~ alpha * (1 - exp(-x/alpha)),
          start = list(alpha = 50),
          algorithm = "port")
```

```
# Bootstrap 获取标准误
```

```
boot.se <- function(data, indices) {
  d <- data[indices, ]
  tryCatch(
    coef(nls(y ~ alpha * (1 - exp(-x/alpha)),
            data = d, start = list(alpha = 50))),
    error = function(e) NA
  )
}
```

4. 非线性模型的贝叶斯推断

4.1. 后验分布的计算. 在贝叶斯框架下，非线性模型的后验分布为

$$(42) \quad p(\theta|y) \propto p(\theta)p(y|\theta),$$

其中 $p(\theta)$ 是先验分布， $p(y|\theta)$ 是似然函数， y 是观测数据。

对于非线性模型，后验分布通常没有闭式表达。我们需要使用马尔科夫链蒙特卡洛方法 (MCMC) 进行后验抽样。对于本章中的模型，一个有效的策略是使用 Metropolis 算法结合 Gibbs 抽样的混合方法。⁴

具体而言，我们可以采用以下步骤：

- (1) 对每个参数 θ_j ，给定当前其他参数值 θ_{-j} 和数据 y ，计算条件后验分布 $p(\theta_j|\theta_{-j}, y)$
- (2) 使用 Metropolis-Hastings 步骤从条件后验分布中抽样
- (3) 重复直到收敛，获得后验样本

⁴Metropolis-Hastings 算法的详细推导见附录 ??。

4.2. 药物动力学模型的贝叶斯分析. 我们用一室模型来说明贝叶斯推断的实际应用。设

$$(43) \quad y_i \sim N(f(t_i, \theta), \sigma^2),$$

$$(44) \quad f(t, \theta) = \frac{D}{V} \exp\left(-\frac{t}{V/k}\right),$$

其中 $\theta = (V, k, \sigma)$ 是参数向量。

我们使用以下先验分布：

$$(45) \quad V \sim N(10, 10^2), \quad V > 0 (\text{对数正态先验})$$

$$(46) \quad \log k \sim N(-1, 1^2),$$

$$(47) \quad \sigma \sim \text{Inv-Gamma}(0.01, 0.01).$$

在 R 中使用 JAGS 进行贝叶斯估计：

R 代码示例：一室模型的贝叶斯分析

```
library(rjags)
```

```
model_string <- "
model {
  for (i in 1:n) {
    y[i] ~ dnorm(f(t[i], V, k), 1/sigma^2)
  }

  f(t, V, k) <- D / V * exp(-t / (V/k))

  V ~ dnorm(10, 0.01) T(0, )      # 截断正态
  log(k) ~ dnorm(-1, 1)
  sigma ~ dgamma(0.01, 0.01)
}
"
```

```
# 准备数据
```

```
data <- list(y = y_obs, t = t_obs, n = length(y_obs), D = dose)
```

```
# MCMC 抽样
```

```
model <- jags.model(textConnection(model_string), data = data)
samples <- coda.samples(model, c("V", "k", "sigma"), n.iter = 5000)
```

5. 逻辑斯谛回归作为非线性模型

逻辑斯谛回归是广义线性模型的一个特例，但也可以从非线性参数模型的角度来理解。设 $y_i \in \{0, 1\}$ 是二元结果， x_i 是协变量。逻辑斯谛模型假设

$$(48) \quad \mathbb{P}(y_i = 1|x_i) = \text{logit}^{-1}(\beta_0 + \beta_1 x_i) = \frac{1}{1 + \exp(-(\beta_0 + \beta_1 x_i))}.$$

虽然这个模型通常通过最大似然方法拟合，但它确实具有非线性结构：参数出现在 logistic 函数的非线性变换中。

从贝叶斯角度，逻辑斯谛回归的后验分布没有闭式表达，需要使用 Metropolis 算法或拉普拉斯近似进行推断。⁵

在 R 中使用 `glm()` 拟合逻辑斯谛回归：

```
# 逻辑斯谛回归示例
fit <- glm(y ~ x, data = data, family = binomial)
summary(fit)

# 置信区间
confint(fit)
```

6. 非线性模型的选择与比较

在非线性模型中，模型选择比线性模型更加复杂，因为不同的参数化方式可能对应不同的物理或生物学意义。常用的模型比较方法包括：

- (1) **残差分析**：检查拟合残差的模式，识别模型偏差
- (2) **信息准则**：AIC、BIC 等，考虑拟合优度与模型复杂度的平衡
- (3) **交叉验证**：留出部分数据用于验证模型的预测能力
- (4) **贝叶斯因子**：比较两个模型的边缘似然比

注 19.1. 在使用信息准则比较非线性模型时，必须注意参数数量的计算。对于非线性模型，“有效参数数量”可能小于显式参数数量，因为某些参数对拟合的贡献可能受到函数非线性结构的限制。

7. 非线性模型的诊断

与非线模型拟合相关的诊断包括：

- (1) **残差图**：绘制残差 vs 拟合值、残差 vs 协变量的图形
- (2) **影响点分析**：识别对参数估计影响较大的异常观测
- (3) **非线性性检验**：检验模型是否真正需要非线性结构
- (4) **异方差性检验**：检查误差方差是否随均值变化

8. 本章小结

本章我们学习了参数非线性模型的贝叶斯分析方法：

- (1) 非线性模型用于描述具有饱和效应、指数衰减、振荡等非线性特征的数据
- (2) 常见的非线性模型包括光合作用模型、药物动力学模型、种群动力学模型等
- (3) 非线性最小二乘估计通过迭代优化完成，需要合理选择初始值
- (4) Bootstrap 方法可用于获取非线性估计的标准误
- (5) 贝叶斯推断使用 MCMC 方法计算后验分布
- (6) 逻辑斯谛回归可视为一类非线性模型
- (7) 非线性模型的选择和诊断需要特别小心

⁵逻辑斯谛回归的贝叶斯推断细节见附录 ??。

9. 下节预告

下一章我们将学习基函数模型 (Basis Function Models)，这是另一类灵活的非参数化方法，通过线性组合基函数来近似复杂的函数关系。这类方法在函数估计、信号处理等领域有着重要应用。

基函数模型

1. 本章导论

在前几章中，我们讨论了回归模型的参数估计和贝叶斯推断方法。然而，经典线性回归假设响应变量与预测变量之间存在线性关系——这一假设在许多实际应用中过于严格。例如，在金融时间序列分析中，资产收益率与宏观经济变量之间的关系往往是非线性的；在生物统计中，剂量反应曲线通常呈现 S 形而非直线。

基函数方法提供了一种优雅解决方案：将非线性函数 $f(x)$ 表示为一组基函数的线性组合

$$(49) \quad f(x) = \sum_{j=1}^J h_j(x) \beta_j,$$

其中 $h_1(x), h_2(x), \dots, h_J(x)$ 是选定的基函数， $\beta_1, \dots, \beta_J$ 是对应的系数。通过贝叶斯推断，我们可以同时估计这些系数及其不确定程度，从而获得对非线性关系的灵活且有原则的估计。

本章我们将学习三种最重要的基函数方法：

- (1) **样条函数 (Splines)**：通过分段多项式构建光滑的非线性函数；
- (2) **Sobolev 空间**：从函数空间的角度理解非参数推断的理论基础；
- (3) **小波 (Wavelets)**：通过多尺度分解捕捉函数在不同分辨率下的特征。

这三种方法虽然在构造基函数的方式上有所不同，但共享相同的核心思想：通过精心选择的基函数族，将无限维的函数估计问题转化为有限维的线性回归问题。

2. 样条函数模型

2.1. 从多项式回归到样条：多项式回归是最直接的非线性建模方法——将预测变量的高次项作为额外的预测变量纳入模型：

$$(50) \quad y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \dots + \beta_K x_i^K + \epsilon_i.$$

尽管多项式回归在概念上简单，但高次多项式在数据边界处往往表现不稳定——系数估计的方差随阶数增加而急剧膨胀，导致过拟合问题。

样条函数通过分段多项式克服了这些困难。在样条模型中，我们选择一个或多个**结点 (knots)** $\xi_1 < \xi_2 < \dots < \xi_K$ ，将预测变量域分割成多个区间，在每个区间内用低次多项式（如三次多项式）拟合，同时在结点处施加光滑性约束（通常要求函数值、一阶导数、二阶导数连续）。

具体而言，**三次样条 (cubic spline)** 可以表示为一组**截断幂基函数 (truncated power basis)**：

$$(51) \quad h_1(x) = 1, \quad h_2(x) = x, \quad h_3(x) = x^2, \quad h_4(x) = x^3,$$

$$(52) \quad h_{4+k}(x) = (x - \xi_k)_+^3, \quad k = 1, \dots, K,$$

其中 $(x - \xi)_+ = \max(0, x - \xi)$ 是**正部 (positive part)** 函数。这 $4 + K$ 个基函数张成了所有满足二阶导数连续的三次样条空间。

然而, 在实际应用中, 直接使用截断幂基函数在数值计算上不够稳定。一种更常用的方法是 **B-样条 (B-splines)** 基函数——它具有局部支撑性 (每个 B-样条仅在少数几个相邻区间内非零), 这使得系数的解释更加直观, 计算也更加高效。

2.2. 回归样条的贝叶斯推断. 给定 n 个观测点 (x_i, y_i) , 样条回归模型为

$$(53) \quad y_i = \sum_{j=1}^J h_j(x_i) \beta_j + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2),$$

其中 J 是基函数的个数 (对于三次样条, $J = 4 + K$, K 为结点数)。

写成矩阵形式, 设 $\mathbf{y} = (y_1, \dots, y_n)^\top$, 设计矩阵 H 的第 i 行第 j 列为 $h_j(x_i)$, 误差向量 $\boldsymbol{\epsilon} \sim N(0, \sigma^2 I)$, 则

$$(54) \quad \mathbf{y} \sim N(H\boldsymbol{\beta}, \sigma^2 I).$$

回归样条的贝叶斯推断需要在系数上施加先验分布以实现光滑化。最常用的先验是**粗糖先验 (g priors)** 的推广——设

$$(55) \quad \boldsymbol{\beta} \sim N(0, \sigma^2 \Sigma_\beta),$$

其中 Σ_β 是先验协方差矩阵, 反映了函数的光滑性先验。

具体而言, 若使用截断幂基函数 (51)–(52), 一个自然的光滑性先验是对高阶导数施加惩罚——这等价于在二阶导数的平方上积分。具体而言, 样条的光滑性可以用

$$(56) \quad \int |f''(x)|^2 dx = \boldsymbol{\beta}^\top P \boldsymbol{\beta}$$

衡量, 其中 P 是由基函数二阶导数构造的惩罚矩阵。

施加先验 (55) 后的后验分布为

$$(57) \quad \boldsymbol{\beta} | \mathbf{y}, \sigma^2 \sim N((H^\top H + \Sigma_\beta^{-1})^{-1} H^\top \mathbf{y}, \sigma^2 (H^\top H + \Sigma_\beta^{-1})^{-1}).$$

后验均值 $\hat{\boldsymbol{\beta}} = (H^\top H + \Sigma_\beta^{-1})^{-1} H^\top \mathbf{y}$ 可以看作是对最小二乘估计的收缩——这与岭回归的精神一致, 只是惩罚矩阵 Σ_β^{-1} 来自光滑性先验。

相应地, 后验预测分布为

$$(58) \quad y_{\text{new}} | x_{\text{new}}, \mathbf{y} \sim N\left(h(x_{\text{new}})^\top \hat{\boldsymbol{\beta}}, \sigma^2 (1 + h(x_{\text{new}})^\top (H^\top H + \Sigma_\beta^{-1})^{-1} h(x_{\text{new}}))\right).$$

后验方差中的额外项 $h(x_{\text{new}})^\top (H^\top H + \Sigma_\beta^{-1})^{-1} h(x_{\text{new}})$ 反映了在未知新点处的不确定程度。

例 20.1 (三次样条回归). 考虑对非线性函数 $f(x) = \sin(2\pi x) + 0.5 \sin(4\pi x)$ 加上噪声观测生成的数据拟合三次样条。

设结点数 $K = 5$, 等距分布在 $[0, 1]$ 区间。使用 B-样条基函数, 模型为 $y_i = \sum_{j=1}^J h_j(x_i) \beta_j + \epsilon_i$ 。

先验协方差矩阵 Σ_β 的构造使得相邻结点的系数变化受到惩罚, 从而保证拟合曲线的光滑性。

后验均值的曲线将呈现为一条光滑曲线, 既能捕捉到正弦函数的波动特征, 又不会被噪声过度拟合。

三次样条回归的完整计算步骤, 包括 B-样条基函数的构造和先验协方差矩阵的组装, 见附录 section 7.1。

2.3. 平滑样条与等效核. 平滑样条 (smoothing splines) 提供了一种数据驱动的结点选择方法。与回归样条 (需要预先指定结点) 不同, 平滑样条通过极小化带惩罚的残差平方和来同时选择拟合函数:

$$(59) \quad \sum_{i=1}^n (y_i - f(x_i))^2 + \lambda \int |f''(t)|^2 dt,$$

其中 $\lambda \geq 0$ 是光滑参数, $\int |f''(t)|^2 dt$ 是函数二阶导数平方的积分, 度量函数的光滑程度。

目标函数 (59) 的解是唯一的三次样条函数, 其结点恰好位于所有唯一的 x_i 处。这个解可以写成

$$(60) \quad \hat{f}(x) = \sum_{i=1}^n S_\lambda(x, x_i) y_i,$$

其中 $S_\lambda(x, x')$ 称为**等效核 (equivalent kernel)**¹。

等效核具有以下重要性质: 它是正定的, 即 $\int S_\lambda(x, u) S_\lambda(u, x') du = S_\lambda(x, x')$, 并且在不同 x 处等效核的形状不同 (这与标准核密度估计不同), 这使得平滑样条在边界处具有自适应光滑的特性。

自由度 (degrees of freedom) 是量化平滑样条灵活性的重要指标。设 S 为平滑矩阵 (满足 $\hat{\mathbf{y}} = S\mathbf{y}$), 则自由度定义为

$$(61) \quad \text{df}(\lambda) = \text{tr}(S).$$

当 $\lambda \rightarrow 0$ 时, $\text{df} \rightarrow n$, 拟合曲线接近插值 (过拟合); 当 $\lambda \rightarrow \infty$ 时, $\text{df} \rightarrow 1$, 拟合曲线退化为线性回归 (欠拟合)。因此, λ 的选择控制了拟合曲线的光滑程度。

在贝叶斯框架下, λ 可以通过边际似然或交叉验证来估计:

$$(62) \quad p(\lambda | \mathbf{y}) \propto p(\mathbf{y} | \lambda) p(\lambda).$$

计算 $p(\mathbf{y} | \lambda)$ 需要对系数 β 积分, 这可以通过析因分解或 MCMC 完成。

例 20.2 (等效核的可视化). 对于均匀设计 $x_i = i/n$, 等效核 $S_\lambda(x, \cdot)$ 在中心点 $x = 0.5$ 处近似高斯核的形状; 但在边界点 $x = 0.05$ 处, 等效核被截断并重新标准化以满足边界条件。

这种自适应的边界处理是平滑样条相对于传统核方法的优势之一。

等效核在边界点处行为的详细分析, 包括 Mercer 定理和特征分解, 见附录 section 7.3。

3. Sobolev 空间与函数空间视角

从更一般的角度看, 样条函数属于一类特殊的函数空间——**Sobolev 空间**。Sobolev 空间 $W_2^k([0, 1])$ 定义为所有 k 阶导数平方可积的函数构成的空间:

$$(63) \quad W_2^k([0, 1]) = \{f : [0, 1] \rightarrow \mathbb{R} \mid f^{(j)} \in L^2([0, 1]), j = 0, 1, \dots, k\}.$$

对于 $k = 2$, 三次样条恰好是 Sobolev 空间 $W_2^2([0, 1])$ 中使得泛函 $\int |f''(x)|^2 dx$ 最小的函数类。

这一函数空间视角揭示了样条方法与再生核 Hilbert 空间 (RKHS) 之间的深层联系。设 $K(x, x')$ 是满足再生性质的核函数, 即 $\langle K(\cdot, x), K(\cdot, x') \rangle_H = K(x, x')$, 则 $H = \{f : f(x) = \sum_i c_i K(x, x_i)\}$ 是 L^2 的一个子空间。

¹等效核的详细推导及其与核密度估计的联系, 见附录 section 7.2。

核函数的统计意义在于：RKHS 中的范数 $\|f\|_H^2$ 恰好度量了函数的光滑程度。对于高斯过程回归（我们将在下一章详细讨论），核函数 $K(x, x')$ 定义了过程的协方差函数；而对于样条惩罚 (59)，其解恰好位于由惩罚核生成的 RKHS 中。

具体而言，平滑样条问题 (59) 的解空间可以表示为

$$(64) \quad \hat{f}(x) = \sum_{j=1}^J h_j(x) \beta_j, \quad \beta \sim N(0, \sigma^2 \lambda P^{-1}),$$

其中 $P_{ij} = \int h_i''(x) h_j''(x) dx$ 是惩罚矩阵。这表明从贝叶斯视角看，样条回归等价于在 RKHS 上施加正态先验。

核与惩罚的对偶性是理解非参数贝叶斯方法的关键：高斯过程先验 $f \sim GP(0, K)$ 等价于在 RKHS 上施加先验；惩罚泛函 $\int |f''(x)|^2 dx$ 则对应于特定的核选择。这种对偶性使得我们可以在函数空间视角和系数空间视角之间自由切换——有时在系数空间更容易计算，有时在函数空间更容易理解。

4. 小波方法

小波方法为非参数回归提供了另一种强大的工具。与样条函数通过分段多项式构造基函数不同，小波通过**伸缩 (dilation)** 和**平移 (translation)** 从单个母小波 ψ 构造一族基函数：

$$(65) \quad \psi_{j,k}(x) = 2^{j/2} \psi(2^j x - k), \quad j, k \in \mathbb{Z}.$$

其中 j 控制频率（尺度）， k 控制位置（平移）。

小波基函数具有两个显著特点：

- (1) **多分辨率性**：不同 j 对应不同的空间分辨率。低 j （大尺度）捕捉函数的整体轮廓；高 j （小尺度）捕捉局部细节。
- (2) **局部支撑性**：大多数小波（如 Daubechies 小波）在时域和频域都是局部化的，使得小波展开能够有效捕捉局部特征。

小波回归模型为

$$(66) \quad y_i = f(x_i) + \epsilon_i = \sum_{j,k} \theta_{jk} \psi_{jk}(x_i) + \epsilon_i,$$

其中 $\theta_{jk} = \langle f, \psi_{jk} \rangle$ 是小波系数。

在大样本下，小波系数的估计可以独立地进行——这是小波方法最吸引人的特点之一。由于小波基函数是正交的，小波系数 θ_{jk} 的最小二乘估计为 $\hat{\theta}_{jk} = \langle \mathbf{y}, \psi_{jk} \rangle$ 。然而，在实际应用中，我们通常使用**阈值法 (thresholding)** 来获得更好的统计性质。

4.1. 小波阈值法。Donoho 和 Johnstone 的著名结果表明，在一定条件下，**小波阈值估计器**能够同时达到最优的收敛速率。两种最常用的阈值规则是：

硬阈值 (hard thresholding)：

$$(67) \quad \hat{\theta}_{jk}^{\text{hard}} = \hat{\theta}_{jk} \cdot \mathbb{I}(|\hat{\theta}_{jk}| > \lambda),$$

软阈值 (soft thresholding)：

$$(68) \quad \hat{\theta}_{jk}^{\text{soft}} = \text{sgn}(\hat{\theta}_{jk}) \cdot (|\hat{\theta}_{jk}| - \lambda)_+,$$

其中 λ 是阈值参数， $\mathbb{I}(\cdot)$ 是示性函数， $\text{sgn}(\cdot)$ 是符号函数。

阈值参数 λ 的选择至关重要。Donoho 和 Johnstone 建议使用**通用阈值** $\lambda = \sigma\sqrt{2\log n}$, 其中 σ 是噪声标准差, n 是样本量。这个阈值在大样本下能够保证估计器的一致性, 但可能存在过度收缩的问题。

实践中更常用的方法是**交叉验证阈值**或 **Bayes 阈值**——后者假设小波系数服从双指数先验, 通过边际似然最大化来选择 λ 。

从贝叶斯视角看, **贝叶斯阈值估计器**等价于假设小波系数服从一个分层先验:

$$(69) \quad \theta_{jk} \mid \sigma_j^2 \sim N(0, \sigma_j^2),$$

$$(70) \quad \sigma_j^2 \sim \text{Inverse-Gamma}(a, b),$$

其中 σ_j^2 是第 j 个尺度上所有系数的共同方差。这种先验设计体现了小波系数的“稀疏性”先验——在大多数尺度上, 只有少数系数有显著的非零值。

后验均值可以通过以下近似公式计算:

$$(71) \quad \mathbb{E}(\theta_{jk} \mid \hat{\theta}_{jk}) \approx \frac{\hat{\theta}_{jk}}{1 + \lambda_{\text{Bayes}}/\hat{\theta}_{jk}^2},$$

其中 λ_{Bayes} 是由先验超参数决定的收缩量。

例 20.3 (Haar 小波的简单例子). Haar 小波是最简单的正交小波, 定义为

$$(72) \quad \psi(x) = \begin{cases} 1 & 0 \leq x < 1/2, \\ -1 & 1/2 \leq x < 1, \\ 0 & \text{otherwise.} \end{cases}$$

在区间 $[0, 1]$ 上, Haar 小波系数的计算是直观的: $\theta_{00} = \int_0^1 f(x) dx$ (尺度系数), $\theta_{jk} = 2^{j/2} \int_{k/2^j}^{(k+1/2)/2^j} f(x) dx - 2^{j/2} \int_{(k+1/2)/2^j}^{(k+1)/2^j} f(x) dx$ (小波系数)。

对于分段常数函数, Haar 小波给出了紧凑的表示; 对于光滑函数, 高尺度的小波系数趋于零, 这正是小波压缩性的体现。

Haar 小波系数计算的详细推导, 以及 Daubechies 小波的构造原理, 见附录 section 7.4。

4.2. 小波与样条的比较. 小波方法和样条方法各有优劣, 适用于不同的场景:

样条的优势:

- 结点的显式几何解释;
- 在边界处自适应良好的表现;
- 与高斯过程 (见下一章) 的紧密联系。

小波的优势:

- 压缩性: 对于光滑函数, 仅需少量小波系数即可精确近似;
- 多分辨率分析: 能够同时捕捉函数在不同尺度上的特征;
- 阈值估计的最优收敛速率。

在实际应用中, 选择样条还是小波取决于数据的特征和分析目标。对于边界效应不明显的区域型数据, 小波往往更高效; 对于需要光滑解释的曲线型数据, 样条更合适。

5. 贝叶斯非参数推断的展望

本章介绍的基函数方法——样条、Sobolev 空间和小波——代表了贝叶斯非参数统计的三大支柱。它们共同的核心思想是: 通过精心选择的基函数族, 将无限维的函数估计问题转化为有限维的线性回归问题, 然后利用贝叶斯推断同时估计系数和光滑参数。

在下一章中，我们将看到这一思想的最优雅实现——**高斯过程 (Gaussian Process)** 回归。在高斯过程框架下，基函数的选择被隐含在核函数的设计中，而边际似然提供了自动选择光滑参数的原则性方法。高斯过程既是样条函数的贝叶斯极限，也能包容小波型的稀疏先验——它为我们提供了一个统一而灵活的非参数推断框架。

6. 本章小结

本章我们学习了三种基函数方法：

- (1) **样条函数** (section 2)：通过分段多项式和光滑性惩罚实现非线性建模。回归样条通过指定结点位置和个数构造基函数；平滑样条通过极小化带惩罚的残差平方和自动选择拟合函数。等效核和自由度是量化平滑样条性质的重要工具。
- (2) **Sobolev 空间** (section 3)：提供了理解非参数推断的函数空间视角。样条空间是 Sobolev 空间的特例，惩罚泛函对应于 RKHS 的范数，核与惩罚之间存在对偶关系。
- (3) **小波方法** (section 4)：通过伸缩和平移从母小波构造正交基，实现多分辨率分析。阈值法是小波估计的核心技术，硬阈值和软阈值各有优劣。贝叶斯分层先验为阈值选择提供了原则性框架。

这三种方法为下一章的高斯过程模型奠定了概念基础。

7. 附录：公式推导

7.1. 三次样条回归的完整计算. 背景：在例 20.1 中，我们简要介绍了三次样条回归。本节给出 B-样条基函数的构造方法和先验协方差矩阵的组装细节。

参数定义：设 K 个结点 $\xi_1 < \dots < \xi_K$ 分布在 $[a, b]$ 区间，扩展结点为 $\xi_0 = \xi_{-1} = \dots = a$ 和 $\xi_{K+1} = \xi_{K+2} = \dots = b$ 。

B-样条基函数的递推定义：B-样条基函数 $B_{i,k}(x)$ (次数为 $k-1$) 由 de Boor 递推公式给出：

$$(73) \quad B_{i,1}(x) = \begin{cases} 1 & \xi_i \leq x < \xi_{i+1}, \\ 0 & \text{otherwise,} \end{cases}$$

$$(74) \quad B_{i,k}(x) = \frac{x - \xi_i}{\xi_{i+k-1} - \xi_i} B_{i,k-1}(x) + \frac{\xi_{i+k} - x}{\xi_{i+k} - \xi_{i+1}} B_{i+1,k-1}(x).$$

光滑性惩罚矩阵：对于三次样条 ($k=4$)，惩罚矩阵 P 的元素为

$$(75) \quad P_{ij} = \int_a^b B_{i,4}''(x) B_{j,4}''(x) dx.$$

由于 B-样条基函数具有局部支撑性， P 是一个带状矩阵，非零元素集中在对角线附近的三角块中。

先验协方差：设 $\Sigma_\beta = \tau^2 P^{-1}$ ，则先验 (55) 等价于在惩罚泛函 $\int |f''(x)|^2 dx$ 上施加 Inverse-Gamma 先验。

后验计算：给定观测数据 (x_i, y_i) ，后验分布 (57) 可以通过 Cholesky 分解高效计算。具体而言，设 L 为 $H^\top H + \Sigma_\beta^{-1}$ 的 Cholesky 因子，则后验抽样可以通过前置-后向代换完成：

$$(76) \quad \beta^* = L^{-\top} \mathbf{z} + L^{-1} H^\top \mathbf{y},$$

其中 $\mathbf{z} \sim N(0, I)$ 。

7.2. 等效核的推导. 背景：平滑样条的解 (60) 可以看作是对观测值 y_i 的加权线性组合，权重由等效核 $S_\lambda(x, x_i)$ 给出。本节推导等效核的显式形式。

目标：求满足

$$(77) \quad \hat{f}(x) = \int_0^1 S_\lambda(x, u) y(u) du$$

的核函数 $S_\lambda(x, u)$ 。

特征分解方法：设 $\{\phi_k, \lambda_k\}$ 为惩罚核 $P(x, u) = \sum_j h_j''(x) h_j''(u)$ 的特征函数和特征值，则等效核可以表示为

$$(78) \quad S_\lambda(x, u) = \sum_k \frac{\phi_k(x) \phi_k(u)}{\lambda_k + \lambda}.$$

将 (78) 代入目标函数并施加极小化条件，即可验证其正确性。

边界行为：在边界点 $x \rightarrow 0$ 或 $x \rightarrow 1$ 处，等效核被截断并重新标准化，以确保 $\int_0^1 S_\lambda(x, u) du = 1$ （无偏性）。这解释了平滑样条在边界处的自适应光滑行为。

7.3. 等效核的边界行为. 背景：在例 20.2 中，我们指出等效核在边界点处形状不同。本节分析这一现象的数学机制。

Mercer 定理：惩罚核 $P(x, u)$ 在 $[0, 1]^2$ 上是连续、对称、正定的，因此可以展开为

$$(79) \quad P(x, u) = \sum_{k=1}^{\infty} \mu_k \phi_k(x) \phi_k(u),$$

其中 μ_k 是特征值， ϕ_k 是对应的特征函数，它们满足 $\int_0^1 P(x, u) \phi_k(u) du = \mu_k \phi_k(x)$ 。

边界效应的机制：对于均匀设计 $x_i = i/n$ ，经验核矩阵 $S_{ij} = S_\lambda(x_i, x_j)$ 是 $P(x, u)$ 的离散近似。在边界点 $i = 1$ 或 $i = n$ 处， S 的行向量被截断，导致有效邻域减小，等效核的方差增大。

这与核密度估计中的边界效应本质相同，但平滑样条通过数据驱动的 λ 选择部分缓解了这个问题——在边界处 λ 自动增大，使得估计更加保守。

7.4. Haar 小波系数计算. 背景：在例 20.3 中，我们给出了 Haar 小波系数的直观描述。本节给出严格的数学推导。

Haar 尺度函数和小波：

$$(80) \quad \phi(x) = \mathbb{I}_{[0,1]}(x),$$

$$(81) \quad \psi(x) = \mathbb{I}_{[0,1/2)}(x) - \mathbb{I}_{[1/2,1)}(x).$$

在尺度 j 上，伸缩平移后的基函数为

$$(82) \quad \phi_{j,k}(x) = 2^{j/2} \phi(2^j x - k),$$

$$(83) \quad \psi_{j,k}(x) = 2^{j/2} \psi(2^j x - k),$$

其中 $k = 0, 1, \dots, 2^j - 1$ 。

正交性验证：利用 ϕ 和 ψ 的定义，直接计算内积可以验证

$$(84) \quad \langle \phi_{j,k}, \phi_{j',k'} \rangle = \delta_{jj'} \delta_{kk'}, \quad \langle \psi_{j,k}, \psi_{j',k'} \rangle = \delta_{jj'} \delta_{kk'}, \quad \langle \phi_{j,k}, \psi_{j',k'} \rangle = 0.$$

系数计算：对于任意 $L^2[0, 1]$ 函数 f ，其小波展开为

$$(85) \quad f(x) = \sum_k \alpha_{0,k} \phi_{0,k}(x) + \sum_{j=0}^{\infty} \sum_k \beta_{j,k} \psi_{j,k}(x),$$

其中系数由内积给出：

$$(86) \quad \alpha_{0,k} = \int_0^1 f(x) \phi_{0,k}(x) dx,$$

$$(87) \quad \beta_{jk} = \int_0^1 f(x) \psi_{jk}(x) dx.$$

对于分段常数函数，这些系数可以直接计算；对于一般光滑函数，高尺度系数 β_{jk} 随 j 增大而快速衰减。

Daubechies 小波的构造原理： Daubechies 小波通过要求消失矩条件来提高光滑性。设 ψ 具有 N 阶消失矩，即 $\int x^m \psi(x) dx = 0$ for $m = 0, 1, \dots, N-1$ ，则对应的尺度函数需要满足更复杂的两尺度关系，其支撑长度随 N 增加而增大。

CHAPTER 21

高斯过程模型

1. 本章导论
2. 主要内容
3. 本章小结

有限混合模型

1. 本章导论

在前面各章中，我们学习的模型大多假设数据来自某个特定的参数分布族——例如正态分布、二项分布或泊松分布。然而，现实世界的的数据往往远比这复杂：一个总体可能包含多个异质性子群体，而每个子群体内部的行为相对简单。这种**异质性** (heterogeneity) 在社会科学、生物统计学、金融和机器学习中无处不在。

如何为这类异质性数据构建统计模型？一个自然的想法是：将总体视为若干个简单分布的混合，每个简单分布代表一个潜在的子群体。这就是**混合模型** (mixture model) 的核心思想。

本章研究有限混合模型 (finite mixture models)，即假设总体由有限个分量 (component) 混合而成的模型。我们将讨论：

- (1) 混合模型的动机与应用场景
- (2) 有限混合分布的数学形式
- (3) 贝叶斯框架下的推断方法
- (4) 标签切换问题及其处理
- (5) 实际应用案例

2. 异质性数据与混合模型的引入

2.1. 为什么需要混合模型？考虑以下实际场景：

一个天文数据库中记录了星系的退行速度 (redshift)。物理学家知道星系形成于不同的演化阶段，因此观测到的速度分布可能不是单峰的正态分布，而是多个峰值——每个峰值对应一类星系。

或者，考虑医学研究中的生存时间数据：患者在接受治疗后，有些人对治疗反应良好 (生存时间较长)，有些人对治疗反应不佳 (生存时间较短)。如果我们忽略这种异质性，用单一分布建模，可能会得到误导性的结论。

在这些场景中，数据的异质性来源于**未观测到的分组结构** (unobserved grouping structure)。混合模型提供了一种原则性的方法来刻画这种结构。

2.2. 从潜在类别到混合模型. 设我们有一组数据 $y = (y_1, \dots, y_n)$ 。假设每个观测 y_i 属于某个潜在的类别 $z_i \in \{1, 2, \dots, K\}$ ，其中 K 是类别总数。类别 z_i 是未被观测到的 (latent)。

给定类别 $z_i = k$ 时， y_i 的分布为某个简单的参数分布：

$$y_i \mid z_i = k \sim f_k(y_i \mid \theta_k)$$

其中 f_k 是第 k 个分量的密度函数， θ_k 是对应的参数。

类别变量 z_i 本身服从多项分布：

$$z_i \sim \text{Categorical}(\pi_1, \dots, \pi_K)$$

其中 $\pi_k = \mathbb{P}(z_i = k)$ 是第 k 个类别的先验概率。

将潜在类别边缘化，我们得到观测数据的边际分布：

$$p(y_i) = \sum_{k=1}^K \pi_k \cdot f_k(y_i | \theta_k)$$

这就是**有限混合分布** (finite mixture distribution) 的数学形式。

3. 有限混合分布的形式与性质

3.1. 混合分布的基本形式. 有限混合模型的核心是 section 2.2 所示的加权求和形式。权重 π_k 满足 $\pi_k \geq 0$ 且 $\sum_{k=1}^K \pi_k = 1$ ，因此构成一个概率分布。

定义 22.1 (有限混合分布). 设 $f_1(y), \dots, f_K(y)$ 为 K 个密度函数 (或质量函数)， $\theta = (\pi_1, \dots, \pi_K, \theta_1, \dots, \theta_K)$ 为参数向量，其中 $\pi_k \geq 0$ ， $\sum_{k=1}^K \pi_k = 1$ 。则由

$$p(y | \theta) = \sum_{k=1}^K \pi_k \cdot f_k(y | \theta_k)$$

定义的分布称为**有限混合分布** (finite mixture distribution)， K 称为混合分量数 (number of components)。

混合分布的矩可以通过各分量的矩加权平均得到。例如，混合分布的均值为

$$\mathbb{E}(y) = \sum_{k=1}^K \pi_k \cdot \mathbb{E}(y | z = k) = \sum_{k=1}^K \pi_k \cdot \mu_k$$

其中 μ_k 是第 k 个分量的均值。

混合分布的方差更为复杂，需要考虑组内方差和组间方差的叠加。

3.2. 混合正态分布. 最常用的混合分布是**混合正态分布** (Gaussian mixture model)：

$$p(y | \theta) = \sum_{k=1}^K \pi_k \cdot N(y | \mu_k, \sigma_k^2)$$

其中 $\theta_k = (\mu_k, \sigma_k^2)$ 。

混合正态分布具有以下性质：

- (1) 任何平滑的密度函数都可以用足够多分量的混合正态分布任意逼近 (Stone-Weierstrass 定理的推论)
- (2) 混合正态分布本身不再是正态分布，但其对数是凹函数 (当 $K > 1$ 时)
- (3) 混合正态分布可以表示多峰、偏态等复杂形态

例 22.1 (双正态混合). 设 $K = 2$ ， $\pi_1 = \pi_2 = 0.5$ ， $\mu_1 = -2$ ， $\sigma_1^2 = 1$ ， $\mu_2 = 2$ ， $\sigma_2^2 = 1$ 。则混合分布为

$$p(y) = 0.5 \cdot N(y | -2, 1) + 0.5 \cdot N(y | 2, 1)$$

这个分布是双峰的，两个峰分别位于 $y = -2$ 和 $y = 2$ 附近。

混合正态分布在聚类分析 (clustering) 中应用广泛：每个分量对应一个潜在的类别，我们可以用贝叶斯推断来同时估计类别参数和每个观测的类别归属概率。

4. EM 算法与混合模型的推断

4.1. 潜在变量的引入. 混合模型的难点在于：潜在类别 z_i 是未被观测到的。如果 z_i 被观测到（即我们已知每个观测属于哪个分量），则问题将大大简化——我们可以分别对每个分量进行推断。

EM 算法 (Expectation-Maximization) 由 Dempster, Laird 和 Rubin [?] 于 1977 年提出，正是利用了这种思想：通过迭代地估计潜在变量 (E 步) 和更新参数 (M 步)，来最大化观测数据的似然。

设 $\theta = (\pi, \theta_1, \dots, \theta_K)$ 为全部参数，其中 $\pi = (\pi_1, \dots, \pi_K)$ 。观测数据的对数似然为

$$\ell(\theta) = \sum_{i=1}^n \log \left(\sum_{k=1}^K \pi_k \cdot f_k(y_i | \theta_k) \right)$$

这个对数似然包含对潜在变量的求和，导致直接最大化困难。EM 算法通过引入潜在变量的后验分布来解决这个问题。

4.2. E 步：计算潜在变量的后验. 在第 t 次迭代，假设当前参数估计为 $\theta^{(t)}$ 。E 步计算给定观测数据和当前参数下，每个观测属于各分量的后验概率：

$$\gamma_{ik}^{(t)} = \mathbb{P}(z_i = k | y_i, \theta^{(t)}) = \frac{\pi_k^{(t)} \cdot f_k(y_i | \theta_k^{(t)})}{\sum_{j=1}^K \pi_j^{(t)} \cdot f_j(y_i | \theta_j^{(t)})}$$

γ_{ik} 被称为“责任” (responsibility)：第 k 个分量对观测 y_i 的责任程度。

从贝叶斯的角度， γ_{ik} 就是给定 y_i 后， $z_i = k$ 的后验概率。

4.3. M 步：更新参数估计. M 步在“完全数据”（观测数据 + 潜在变量）上最大化期望对数似然。完全数据的对数似然为

$$\ell_c(\theta) = \sum_{i=1}^n \sum_{k=1}^K \mathbb{I}(z_i = k) \cdot [\log \pi_k + \log f_k(y_i | \theta_k)]$$

取期望（关于 z_i 的后验分布），得到期望完全数据对数似然：

$$Q(\theta, \theta^{(t)}) = \sum_{i=1}^n \sum_{k=1}^K \gamma_{ik}^{(t)} \cdot [\log \pi_k + \log f_k(y_i | \theta_k)]$$

M 步通过对 Q 关于 θ 最大化来更新参数。对于混合正态模型，更新公式为：

$$\begin{aligned} \pi_k^{(t+1)} &= \frac{1}{n} \sum_{i=1}^n \gamma_{ik}^{(t)} \\ \mu_k^{(t+1)} &= \frac{\sum_{i=1}^n \gamma_{ik}^{(t)} \cdot y_i}{\sum_{i=1}^n \gamma_{ik}^{(t)}} \\ (\sigma_k^2)^{(t+1)} &= \frac{\sum_{i=1}^n \gamma_{ik}^{(t)} \cdot (y_i - \mu_k^{(t+1)})^2}{\sum_{i=1}^n \gamma_{ik}^{(t)}} \end{aligned}$$

4.4. EM 算法的收敛性. EM 算法保证观测数据似然的单调递增： $\ell(\theta^{(t+1)}) \geq \ell(\theta^{(t)})$ 。但收敛到的点可能是局部极大值，而非全局极大值。因此，EM 算法对初始值敏感，通常需要多次随机初始化。

对于混合模型的贝叶斯推断，我们通常关注后验分布 $p(\theta, z | y)$ ，而不仅仅是点估计。这需要使用 MCMC 方法（如 Gibbs 采样），我们将在下一节讨论。

5. 贝叶斯混合模型推断

5.1. 完全条件分布. 在贝叶斯框架下，我们为所有参数指定先验分布 $p(\theta)$ ，然后推断后验分布 $p(\theta, z | y)$ 。

对于混合正态模型，一个方便的选择是共轭先验：

$$\pi \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_K)$$

$$\mu_k | \sigma_k^2 \sim N(\mu_0, \sigma_k^2/n_0)$$

$$\sigma_k^2 \sim \text{Inverse-Gamma}(\nu_0/2, \nu_0\sigma_0^2/2)$$

给定这些先验，可以推导出各参数的完全条件分布（Gibbs 采样所需）。

第 k 个分量的混合比例 π_k 的完全条件分布为：

$$\pi | y, z, \theta_{-\pi} \sim \text{Dirichlet}(\alpha_1 + n_1, \dots, \alpha_K + n_K)$$

其中 $n_k = \sum_{i=1}^n \mathbb{I}(z_i = k)$ 是属于第 k 个分量的观测数。

第 k 个分量的均值和方差的完全条件分布为正态-逆 Gamma 分布。

潜在类别变量 z_i 的完全条件分布为：

$$(\text{eq:z-complete-conditional}) \quad \mathbb{P}(z_i = k | y_i, \theta) \propto \pi_k \cdot N(y_i | \mu_k, \sigma_k^2)$$

这就是 section 4.2 中的后验概率——在贝叶斯版本中，它是完全条件分布，而非 EM 算法中的点估计。

5.2. Gibbs 采样算法. 基于完全条件分布，我们可以设计 Gibbs 采样器来从后验分布中抽样：

- (1) 初始化参数 $\theta^{(0)}$
- (2) 对 $t = 1, 2, \dots$ 迭代：
 - (a) 对每个 $i = 1, \dots, n$ ，从 ?? 抽取 $z_i^{(t)}$
 - (b) 从 π 的完全条件分布抽取 $\pi^{(t)}$
 - (c) 对每个 $k = 1, \dots, K$ ，从 μ_k, σ_k^2 的完全条件分布抽取

Gibbs 采样器的收敛性可以通过监控多链的 Gelman-Rubin 统计量来诊断。

6. 标签切换问题

6.1. 问题的本质. 混合模型的一个核心问题是**标签切换** (label switching)：由于似然函数在分量标签的置换下保持不变，后验分布是关于分量标签对称的。

具体来说，如果 (z_i, π_k, θ_k) 是一个合法的后验样本，那么对任意置换 $\sigma, (\sigma(z_i), \pi_{\sigma(k)}, \theta_{\sigma(k)})$ 同样是合法的后验样本。

这导致两个问题：

- (1) 后验均值失去意义： K 个分量的后验均值相互混合
- (2) 迭代收敛后，每次迭代的标签可能不一致

6.2. 标签切换的解决. 解决标签切换问题的方法主要有：

- (1) **排序约束**：通过对参数施加排序约束（如 $\mu_1 < \mu_2 < \dots < \mu_K$ ）来打破对称性。这是最简单的方法，但可能不适合所有场景。
- (2) **标签切换检测与对齐**：在 MCMC 采样后，检测标签切换事件，并通过对齐链来恢复因果顺序。
- (3) **后处理**：使用递归分区或聚类方法将后验样本分类到各个分量。

排序约束是最常用的方法，但需要谨慎使用，因为人为的约束可能影响推断结果。

7. 应用实例：星系速度数据

本节我们用混合正态模型分析星系退行速度数据。¹

设 y_i 为第 i 个星系的退行速度（单位：km/s）。我们用双正态混合模型：

$$y_i \sim \pi \cdot N(\mu_1, \sigma_1^2) + (1 - \pi) \cdot N(\mu_2, \sigma_2^2)$$

贝叶斯推断的目标是：

- (1) 估计两个星族（population）的速度分布参数
- (2) 计算每个星系属于各星族的后验概率
- (3) 评估混合比例 π

使用 Gibbs 采样，我们可以从后验分布中抽取样本，然后计算各参数的后验均值和置信区间。

注 22.1. 混合模型的一个优势是它提供了**软聚类**（soft clustering）：与硬聚类（每个观测必须属于某一类）不同，混合模型给出每个观测属于各类的概率。这对于边界情况特别有价值。

8. 混合模型的其他应用

混合模型在统计学和机器学习中有广泛的应用：

- (1) **密度估计**：混合模型可以用于非参数密度估计，用有限个参数的混合分布逼近任意复杂的密度函数。
- (2) **聚类分析**：如上所述，混合模型提供了一种基于概率的聚类方法。
- (3) **缺失数据插补**：在存在缺失值的问题中，可以将缺失数据的插补值视为潜在变量，用混合模型进行多重插补。
- (4) **生存分析**：考虑未观测到的异质性来源（如未观测到的风险因素），混合模型可以用于建模生存数据中的非比例风险。
- (5) **时间序列**：隐马尔可夫模型（Hidden Markov Model）是混合模型在时间序列中的推广。

9. 混合模型的扩展

有限混合模型是更广泛模型类别的特例：

- (1) **无限混合模型**（Infinite mixture models）：当分量数 $K \rightarrow \infty$ 时，得到非参数贝叶斯方法，如狄利克雷过程混合（Dirichlet process mixture）。这将在第 23 章讨论。
- (2) **半参数混合模型**：放松对分量分布的假设，允许非参数形式的分量分布。
- (3) **高斯过程混合**：在函数空间中进行混合，用于非参数回归和分类。

¹数据来源见 [?].

10. 本章小结

本章我们学习了有限混合模型：

- (1) 混合模型用于建模具有未观测到的异质性的数据
- (2) 有限混合分布是各分量分布的加权平均
- (3) EM 算法提供了一种寻找最大似然估计的迭代方法
- (4) 贝叶斯推断使用 Gibbs 采样从后验分布中抽样
- (5) 标签切换问题需要特殊处理
- (6) 混合模型在聚类、密度估计、生存分析等领域有广泛应用

11. 延伸阅读

关于混合模型的更多信息，推荐以下参考文献：

- [?]: 混合模型的经典教材
- [?]: 有限混合模型的统计推断
- [?]: 贝叶斯混合模型的方法与应用

狄利克雷过程模型

1. 本章导论

在前几章中，我们探讨了有限混合模型——用有限个组件的加权组合来刻画异质数据。在实践中，分析者必须事先指定成分的数量 K ，这往往是一个困难的选择。Dirichlet 过程 (Dirichlet Process, DP) 提供了一种优雅解决方案：允许无限多个潜在成分，让数据自适应地确定有效成分的个数。

Dirichlet 过程是贝叶斯非参数统计的核心工具。它由 Ferguson (1973) 引入，是一种随机过程，其样本路径 almost surely (以概率 1) 是离散概率分布。这一看似特殊的性质——连续底空间上的随机概率分布却以概率 1 取离散值——正是 DP 成为非参数贝叶斯推断强大先验的根源。

本章的结构如下：先从有限混合模型与 DP 的联系入手，介绍 DP 的三种等价构造 (stick-breaking、Pólya urn、Chinese restaurant process)，然后讨论 DP 作为未知分布的先验及其后验推断，最后介绍 DP 混合模型的计算方法。

2. 从有限混合到无限混合

在有限混合模型中，我们假设数据来自 K 个成分的混合：

$$p(y_i|\theta_1, \dots, \theta_K, \pi) = \sum_{k=1}^K \pi_k p(y_i|\theta_k),$$

其中 $\pi = (\pi_1, \dots, \pi_K)$ 是混合权重，满足 $\pi_k \geq 0$, $\sum_{k=1}^K \pi_k = 1$ 。

一个自然的问题是： K 本身能否从数据中学习，而不是预先固定？一个激进的思路是直接令 $K \rightarrow \infty$ ，但这在参数模型框架下并不容易处理。DP 提供了一种优雅解决方案：先验性地将混合成分的数量设为无限，然后通过后验推断自动确定有效成分个数。

Dirichlet 过程先验的核心思想是：不去直接参数化混合权重 π_k ，而是假设混合权重本身来自一个随机过程，使得“有多少个有效成分”由数据决定。

3. 狄利克雷过程的定义与构造

3.1. Stick-breaking 构造. 设 G_0 为一个基分布 (base measure), $\alpha > 0$ 为浓度参数 (concentration parameter)。Dirichlet 过程 $G \sim (\alpha, G_0)$ 可以通过以下 stick-breaking 构造 (Sethuraman, 1994) 生成：

定义 23.1 (Stick-breaking 构造). 令 $V_1, V_2, \dots$ 为独立同分布的 Beta 随机变量, $V_k \sim \text{Beta}(1, \alpha)$ 。定义

$$w_k = V_k \prod_{j=1}^{k-1} (1 - V_j), \quad k = 1, 2, \dots$$

则

$$G = \sum_{k=1}^{\infty} w_k \delta_{\theta_k},$$

其中 $\theta_1, \theta_2, \dots$ 独立同分布自 G_0 , 且与 $(V_1, V_2, \dots)$ 相互独立。

直观理解：取一根单位长度的棍子 (stick)，第一步折下长度为 V_1 的第一段，分配给 atom θ_1 ；剩余长度为 $1 - V_1$ 的棍子上，折下长度为 $(1 - V_1)V_2$ 的第二段，分配给 θ_2 ；依此类推。由于 $\prod_{j=1}^{\infty} (1 - V_j) = 0$ with probability 1，这个过程永远不会终止，因此产生了无限多个 atoms，但权重之和为 1。

权重 w_k 的期望为 $\mathbb{E}w_k = 1/\alpha$ 级别的衰减—— α 越大，权重衰减越慢，有效成分个数越多。

3.2. Pólya urn 构造. DP 还有一种更为概率的构造——Pólya urn scheme。设我们有颜色 (atoms) 集合，urn 中每次加入一个球：

- (1) 以概率 $\alpha/(\alpha + n - 1)$ 加入一个新颜色的球 (颜色为从 G_0 中独立抽取的 θ)；
- (2) 以概率 $(n_k)/(\alpha + n - 1)$ 加入一个颜色为 k 的已有球 (n_k 为 urn 中颜色 k 的球数)。

这个 urn 过程产生的颜色分布恰好与 stick-breaking 构造等价。

3.3. Chinese restaurant process (中国餐厅过程). 第三种构造与中国餐厅过程的隐喻密切相关。

想象一个拥有无限多张桌子的餐厅，第一位顾客随意选择一张桌子就座。第 n 位顾客到来时：

- 以概率 $\alpha/(\alpha + n - 1)$ 选择一张新桌子；
- 以概率 $n_k/(\alpha + n - 1)$ 选择已有桌子 k (n_k 为该桌已坐的顾客数)。

顾客坐在不同桌子上的概率分布恰好描述了 DP 样本中 atoms 的分配结构。同一桌子上的顾客可以理解为来自同一个聚类 (cluster)。这就是著名的 Chinese restaurant process (CRP)。

CRP 的魅力在于它将离散概率分布的随机结构编码为一个 sequential partition 过程——这与统计学中聚类分析的精神高度一致：数据自然地聚集成簇，而簇的数量本身由数据决定。

注 23.1. CRP 中的参数 α 控制聚类个数的“先验期望”。 α 越小，倾向于更少的聚类； α 越大，倾向于更多的聚类。这与直觉一致： α 作为浓度参数，在 stick-breaking 中控制了权重衰减的速度。

4. DP 作为未知分布的先验

DP 的核心应用是作为未知分布 F 的先验。设我们希望从分布 F 中抽取独立样本 $x_1, \dots, x_n$ ，但对 F 的形式一无所知。

一个非参数的思路是：对 F 赋予先验，然后在后验下进行推断。DP 正是这样一个先验：

$$F \sim (\alpha, G_0).$$

具体而言，我们假设：

$$\theta_i | F \stackrel{\text{iid}}{\sim} F, \quad F \sim (\alpha, G_0),$$

其中 G_0 是一个参数化的分布 (如正态分布)， α 控制先验的灵活性。

由于 G 的样本路径是离散分布，我们可以将模型等价地写为：

$$\theta_i \stackrel{\text{iid}}{\sim} G, \quad G \sim (\alpha, G_0).$$

但更常见的是直接积分掉 G ，得到 θ_i 的边缘分布——这正是下一节要讨论的折棍（stick-breaking）表示的核心应用。

5. 后验推断

给定观测数据 $\mathbf{x} = (x_1, \dots, x_n)$ ，DP 先验下的后验推断有一个优雅的形式。

假设基分布 G_0 是某个参数 ϕ 的分布，即 $x_i|\phi \sim p(x|\phi)$ ，且 $\phi \sim G_0$ 。那么后验有如下形式：¹

$$G|\mathbf{x} \sim \left(\alpha + n, \frac{\alpha}{\alpha + n} G_0 + \frac{1}{\alpha + n} \sum_{i=1}^n \delta_{x_i} \right).$$

这一结果表明：后验等价于在先验 G_0 的基础上”添加”了经验分布的 contribution。具体而言：

- 有效样本量从 α 增加到 $\alpha + n$ ；
- 后验基分布是 G_0 与经验分布 $\frac{1}{n} \sum_i \delta_{x_i}$ 的加权平均，权重分别为 α/n 和 n/n 的某种调整。

预测分布也有简洁形式。设新观测为 $\tilde{x}$ ，则其后验预测分布为：²

$$p(\tilde{x}|\mathbf{x}) = \frac{\alpha}{\alpha + n} G_0(\tilde{x}) + \frac{1}{\alpha + n} \sum_{i=1}^n \delta_{x_i}(\tilde{x}).$$

也就是说，新数据点有概率 $\alpha/(\alpha + n)$ 来自基分布 G_0 （产生一个新 atom），有概率 $n/(\alpha + n)$ 与已有数据点 x_i 相同（与同一 cluster 的数据共享）。这正是 CRP 的 predictive probability。

6. DP 混合模型

DP 混合模型（Dirichlet process mixture model, DPM）是 DP 先验在密度估计中的主要应用形式。模型设定为：

$$x_i|\theta_i \sim p(x|\theta_i), \quad \theta_i|G \stackrel{\text{iid}}{\sim} G, \quad G \sim (\alpha, G_0).$$

与有限混合模型相比，DPM 的关键区别在于：成分的数量是无限的（由 stick-breaking 过程产生），而有效成分的个数由数据通过后验推断自动确定。

从聚类角度看，DPM 自然地产生了一个 partition——数据被划分为若干聚类，每个聚类内的数据共享同一参数 θ_k 。这个 partition 是随机且自适应的，与 CRP 的 sequential partition 精神一致。

7. 计算方法

DP 混合模型的计算核心挑战在于：stick-breaking 构造涉及无限多个 atoms，而后验中 atoms 的个数同样是无限的。MCMC 方法是处理这一问题的主要工具。

¹推导见附录 ??

²推导见附录 ??

7.1. Blocked Gibbs 采样器. 一种直接的方法是引入隐含的聚类分配指标 $\mathbf{c} = (c_1, \dots, c_n)$, 其中 $c_i = k$ 表示 x_i 属于第 k 个聚类。

全条件后验分布为:

$$p(c_i = k | \mathbf{c}_{-i}, \mathbf{x}, \alpha) \propto \begin{cases} n_{-i,k} \cdot p(x_i | \theta_k, \mathbf{x}_{-i}) & \text{if } k \text{ is an existing cluster,} \\ \alpha \cdot p(x_i | \theta_{\text{new}}, G_0) & \text{if } k \text{ is a new cluster.} \end{cases}$$

其中 $n_{-i,k}$ 是除 i 外属于第 k 个聚类的数据点数。

然后从各自的后验分布中采样 θ_k 。这个过程在 c_i 和 θ_k 之间交替进行, 即 blocked Gibbs 采样。

7.2. Chinese Restaurant Process 采样. CRP 的视角给出了一种更直观的采样方案。已知完整数据下的 CRP predictive probability, Gibbs 采样可以直接对聚类分配进行更新, 而无需显式处理无限多个 atoms。

具体而言, 对于数据点 i , 计算其属于现有聚类 k 和属于新聚类的概率, 然后按概率重新分配。这个方法在高维数据和中等规模数据集上通常效率较高。

8. 应用举例

例 23.1 (基于 DP 聚类的密度估计). 假设我们有一组来自混合分布的观测数据, 数据中存在两个自然聚类, 但分析者事先并不知道聚类的个数。

应用 DPM 模型, 设成分分布为正态分布 $N(\mu_k, \sigma_k^2)$, 基分布 G_0 取为 Normal-Inverse-Gamma 共轭先验。MCMC 采样将自动:

- 在后验中探索不同的聚类个数;
- 收敛到数据中真实存在的聚类结构;
- 提供每个聚类的参数后验分布。

DP 混合模型在以下场景中尤为有用:

- 密度估计: 当数据具有未知数量的峰 (modes) 时;
- 聚类分析: 当聚类个数事先未知, 且聚类结构可能随协变量变化时;
- 随机过程建模: 如隐马尔可夫模型的状态转移矩阵非参数化推广;
- 函数逼近: 如 DP 基函数回归 (DP mixture of regressions)。

9. 与其他非参数方法的联系

DP 并非唯一的贝叶斯非参数工具。在密度估计中, 高斯过程 (见 Chapter 21) 提供了函数空间上的先验, Dirichlet 过程则提供了分布空间上的先验。

一个有用的视角是: DP 是有限维 Dirichlet 分布 $\text{Dir}(\alpha_1, \dots, \alpha_K)$ 在 $K \rightarrow \infty$ 时的推广。有限维 Dirichlet 分布是定义在 K 维单纯形上的分布, 其样本是 K 维向量 $(w_1, \dots, w_K)$; DP 则是其无限维推广, 样本是无限维的离散分布。

历史上, Ferguson (1973) 正是通过有限 Dirichlet 分布的类比, 构造了无穷维 Dirichlet 过程。这一构造在数学上优雅, 在应用中有效, 是 20 世纪贝叶斯统计最重要的进展之一。

10. 本章小结

本章我们学习了:

- (1) Dirichlet 过程是定义在概率分布空间上的随机过程, 其样本路径几乎 surely 是离散分布;
- (2) DP 有三种等价的构造方式: stick-breaking 构造、Pólya urn 构造和中国餐厅过程 (CRP);

- (3) 作为未知分布的先验, DP 的后验有简洁的闭式形式;
- (4) DP 混合模型 (DPM) 将 DP 先验与参数化成分分布结合, 实现了无限混合的自然贝叶斯非参数建模;
- (5) 主要的计算方法包括 blocked Gibbs 采样和 CRP 采样;
- (6) DP 是有限 Dirichlet 分布在无限维的自然推广, 由 Ferguson (1973) 开创。

11. 下节预告

下一章我们将转向更深入的贝叶斯计算方法, 讨论如何在大规模问题中高效地进行贝叶斯推断。

APPENDIX A

公式推导

1. 概率与推断 (Chapter 1) 推导

1.1. 贝叶斯定理的推导. 背景 (Background): 贝叶斯定理是概率论中最基本的公式之一, 它描述了如何根据新的证据更新概率估计。这个推导基于条件概率的定义和基本运算规则。

参数定义 (Parameter Definitions):

- A : 某个事件
- B : 另一个事件 (通常代表观测数据或证据)
- $p(A)$: 事件 A 的先验概率 (prior probability)
- $p(A|B)$: 在事件 B 发生的条件下, 事件 A 的后验概率 (posterior probability)
- $p(B|A)$: 在事件 A 发生的条件下, 事件 B 的似然 (likelihood)
- $p(B)$: 事件 B 的边际概率 (marginal probability)

已知条件 (Given):

- 条件概率定义: $p(A|B) = \frac{p(A \cap B)}{p(B)}$, 其中 $p(B) > 0$
- 乘法法则: $p(A \cap B) = p(A) \cdot p(B|A) = p(B) \cdot p(A|B)$

目标 (Goal): 从条件概率的基本定义推导出贝叶斯定理:

$$p(A|B) = \frac{p(A) \cdot p(B|A)}{p(B)}$$

推导步骤 (Derivation Steps):

步骤 1: 从条件概率定义出发

$$p(A|B) = \frac{p(A \cap B)}{p(B)}$$

步骤 2: 用乘法法则替换联合概率 $p(A \cap B)$

$$p(A \cap B) = p(A) \cdot p(B|A)$$

步骤 3: 将步骤 2 代入步骤 1

$$p(A|B) = \frac{p(A) \cdot p(B|A)}{p(B)}$$

步骤 4: 对 $p(B)$ 进行边际化 (如果 $A_1, A_2, \dots, A_k$ 是互斥且完备的事件族)

$$p(B) = \sum_{i=1}^k p(A_i) \cdot p(B|A_i)$$

步骤 5: 将步骤 4 代入贝叶斯定理的分母，得到完整形式

$$p(A_j|B) = \frac{p(A_j) \cdot p(B|A_j)}{\sum_{i=1}^k p(A_i) \cdot p(B|A_i)}$$

结论: 贝叶斯定理建立了先验概率与后验概率之间的桥梁——我们通过似然 $p(B|A)$ 将新的观测 B 与先验知识 $p(A)$ 结合起来。

1.2. 先验预测分布与后验预测分布的推导. 背景 (Background): 在贝叶斯统计中, 我们不仅要推断当前参数 θ 的后验分布, 还需要预测未来观测 $\tilde{y}$ 的分布。这涉及对未知参数进行积分 (边际化)。

参数定义 (Parameter Definitions):

- θ : 不可观测的参数
- y : 已观测的数据
- $\tilde{y}$: 未来或未观测的数据
- $p(\theta)$: 参数的先验分布
- $p(y|\theta)$: 数据的似然函数
- $p(\theta|y)$: 参数的后验分布

已知条件 (Given):

- 贝叶斯定理: $p(\theta|y) \propto p(\theta) \cdot p(y|\theta)$
- 边际概率定义: $p(y) = \int p(\theta) \cdot p(y|\theta) d\theta$
- 条件独立性: 给定 θ , 未来观测 $\tilde{y}$ 与当前观测 y 条件独立

目标 (Goal):

- (1) 推导先验预测分布 $p(y)$
- (2) 推导后验预测分布 $p(\tilde{y}|y)$

推导步骤 (Derivation Steps):

先验预测分布的推导. **步骤 1:** 从边际概率的定义出发

$$p(y) = \int p(\theta) \cdot p(y|\theta) d\theta$$

步骤 2: 解释其含义——这是对所有可能的 θ 值加权平均, 其中权重是先验概率

步骤 3: 先验预测分布表示在我们观测数据之前, 所有可能观测结果的分布

后验预测分布的推导. **步骤 1**: 从条件概率定义出发

$$p(\tilde{y}|y) = \int p(\tilde{y}, \theta|y) d\theta$$

步骤 2: 将联合分布分解

$$p(\tilde{y}, \theta|y) = p(\tilde{y}|\theta, y) \cdot p(\theta|y)$$

步骤 3: 利用条件独立性假设 (给定 θ , $\tilde{y}$ 与 y 独立)

$$p(\tilde{y}|\theta, y) = p(\tilde{y}|\theta)$$

步骤 4: 代入得

$$p(\tilde{y}|y) = \int p(\tilde{y}|\theta) \cdot p(\theta|y) d\theta$$

结论: 后验预测分布是在**参数后验分布上对条件预测进行平均**。这体现了贝叶斯推断的核心思想: 不确定性在两个层次上都存在 (参数的不确定性和预测的随机性), 我们需要对两者都进行边际化。

1.3. 后验优势比的推导. 背景 (Background): 优势比 (odds ratio) 是概率的另一种表示方式, 在许多应用场景下比概率更直观。贝叶斯定理在优势比形式下有一个特别简洁的表达。

参数定义 (Parameter Definitions):

- θ_1 : 某个参数值
- θ_2 : 另一个参数值
- $p(\theta_1)$: θ_1 的先验概率
- $p(\theta_1|y)$: θ_1 的后验概率
- $p(y|\theta_1)$: 似然函数在 θ_1 处的值
- $O(\theta_1, \theta_2) = \frac{p(\theta_1)}{p(\theta_2)}$: 先验优势比
- $O(\theta_1, \theta_2|y) = \frac{p(\theta_1|y)}{p(\theta_2|y)}$: 后验优势比

已知条件 (Given): 贝叶斯定理:

$$p(\theta|y) = \frac{p(\theta) \cdot p(y|\theta)}{p(y)}$$

目标 (Goal): 证明后验优势比 = 先验优势比 $\times$ 似然比

推导步骤 (Derivation Steps):

步骤 1: 写出后验优势比的定义

$$O(\theta_1, \theta_2|y) = \frac{p(\theta_1|y)}{p(\theta_2|y)}$$

步骤 2: 对分子和分母分别应用贝叶斯定理

$$\begin{aligned} & \frac{p(\theta_1) \cdot p(y|\theta_1)}{p(y)} \\ &= \frac{\frac{p(\theta_1) \cdot p(y|\theta_1)}{p(y)}}{\frac{p(\theta_2) \cdot p(y|\theta_2)}{p(y)}} \end{aligned}$$

步骤 3: 约去 $p(y)$

$$= \frac{p(\theta_1) \cdot p(y|\theta_1)}{p(\theta_2) \cdot p(y|\theta_2)}$$

步骤 4: 重新组合

$$= \frac{p(\theta_1)}{p(\theta_2)} \times \frac{p(y|\theta_1)}{p(y|\theta_2)}$$

结论: 这个简洁的关系式告诉我们, **后验优势比 = 先验优势比 $\times$ 似然比**。数据通过似然比来更新优势比——如果 $p(y|\theta_1) > p(y|\theta_2)$, 则数据支持 θ_1 , 后验优势比增大。

2. 单参数模型 (Chapter 2) 推导

2.1. Beta-Binomial 共轭后验分布推导. 背景 (Background): 在二项模型中, 如果我们使用 Beta 先验分布来估计成功概率 θ , 则后验分布也是 Beta 分布。这种性质称为共轭性, 是贝叶斯统计中最重要的概念之一。

参数定义 (Parameter Definitions):

- n : 伯努利试验的总次数
- y : n 次试验中成功的次数
- θ : 每次试验的成功概率 (未知参数)
- α : Beta 先验的第一个参数
- β : Beta 先验的第二个参数
- $p(y|\theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y}$: 二项似然函数
- $p(\theta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}$: Beta 先验

已知条件 (Given):

- Beta 函数定义: $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
- 似然函数: $p(y|\theta) \propto \theta^y (1-\theta)^{n-y}$ (忽略不依赖 θ 的常数 $\binom{n}{y}$)
- 先验分布: $p(\theta) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1}$

目标 (Goal): 证明后验分布 $p(\theta|y)$ 也是 Beta 分布, 并确定其后验参数。

推导步骤 (Derivation Steps):

步骤 1: 应用贝叶斯定理写出非归一化后验分布

$$p(\theta|y) \propto p(\theta) \cdot p(y|\theta)$$

步骤 2: 代入先验和似然

$$p(\theta|y) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1} \cdot \theta^y (1-\theta)^{n-y}$$

步骤 3: 合并同底数指数

$$= \theta^{(\alpha-1)+y} \cdot (1-\theta)^{(\beta-1)+(n-y)} = \theta^{\alpha+y-1} \cdot (1-\theta)^{\beta+n-y-1}$$

步骤 4: 识别分布形式这正是 Beta 分布的核 (kernel), 即

$$p(\theta|y) \propto \theta^{\alpha_{\text{post}}-1} (1-\theta)^{\beta_{\text{post}}-1}$$

其中

$$\alpha_{\text{post}} = \alpha + y, \quad \beta_{\text{post}} = \beta + n - y$$

步骤 5: 写出完整的后验分布

$$\theta|y \sim \text{Beta}(\alpha + y, \beta + n - y)$$

结论: 后验分布与先验分布属于同一形式 (Beta 分布), 这就是共轭性。先验参数 α 可以解释为 $\alpha - 1$ 次“先验成功”, β 解释为 $\beta - 1$ 次“先验失败”。

2.2. Beta-Binomial 后验均值与方差推导. 背景 (Background): 在共轭框架下, 我们可以推导出后验分布的均值和方差的闭式表达式。这些表达式展示了先验信息与数据信息如何”折中”。

参数定义 (Parameter Definitions):

- $\alpha_{\text{post}} = \alpha + y$: 后验第一个参数
- $\beta_{\text{post}} = \beta + n - y$: 后验第二个参数
- $\mathbb{E}(\theta|y)$: 后验均值
- $\text{Var}(\theta|y)$: 后验方差

已知条件 (Given):

- 后验分布: $\theta|y \sim \text{Beta}(\alpha_{\text{post}}, \beta_{\text{post}})$
- Beta 分布均值公式: $\mathbb{E}(X) = \frac{\alpha}{\alpha + \beta}$, 其中 $X \sim \text{Beta}(\alpha, \beta)$
- Beta 分布方差公式: $\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$

目标 (Goal):

- (1) 求后验均值 $\mathbb{E}(\theta|y)$
- (2) 求后验方差 $\text{Var}(\theta|y)$

后验均值推导. **步骤 1**: 应用 Beta 分布均值公式

$$\mathbb{E}(\theta|y) = \frac{\alpha_{\text{post}}}{\alpha_{\text{post}} + \beta_{\text{post}}}$$

步骤 2: 代入后验参数

$$= \frac{\alpha + y}{\alpha + y + \beta + n - y} = \frac{\alpha + y}{\alpha + \beta + n}$$

步骤 3: 改写为加权平均形式

$$= \frac{\alpha + y}{\alpha + \beta + n} = \frac{\alpha + \beta}{\alpha + \beta + n} \cdot \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \cdot \frac{y}{n}$$

结论 1: 后验均值是先验均值 $\frac{\alpha}{\alpha + \beta}$ 和样本比例 $\frac{y}{n}$ 的加权平均, 权重与样本量和先验强度相关。

后验方差推导. **步骤 1:** 应用 Beta 分布方差公式

$$\text{Var}(\theta|y) = \frac{\alpha_{\text{post}} \cdot \beta_{\text{post}}}{(\alpha_{\text{post}} + \beta_{\text{post}})^2 (\alpha_{\text{post}} + \beta_{\text{post}} + 1)}$$

步骤 2: 代入后验参数

$$= \frac{(\alpha + y)(\beta + n - y)}{(\alpha + \beta + n)^2 (\alpha + \beta + n + 1)}$$

步骤 3: 大样本近似 (当 y 和 $n - y$ 较大时) 当 n 很大而 α, β 固定时,

$$\text{Var}(\theta|y) \approx \frac{1}{n} \cdot \frac{y}{n} \left(1 - \frac{y}{n}\right)$$

结论 2: 后验方差以 $1/n$ 的速率趋近于零, 表明随着样本量增大, 后验分布越来越集中在真值附近。

2.3. 拉普拉斯继承法则推导. 背景 (Background): 拉普拉斯在 18 世纪研究”明天太阳会升起”这类问题时, 提出了一个著名的法则。在均匀先验下, 这个法则预测未来成功的概率为 $\frac{y+1}{n+2}$ 。

参数定义 (Parameter Definitions):

- n : 已完成的试验次数
- y : 成功的次数
- $\tilde{y}$: 下一次试验的结果 ($\tilde{y} = 1$ 表示成功)
- θ : 成功概率
- $p(\theta|y) = \text{Beta}(y+1, n-y+1)$: 均匀先验下的后验分布

已知条件 (Given):

- 均匀先验: $\theta \sim \text{Uniform}(0, 1) = \text{Beta}(1, 1)$
- 后验分布: $\theta|y \sim \text{Beta}(y+1, n-y+1)$
- 后验预测分布: $p(\tilde{y} = 1|y) = \int_0^1 \theta \cdot p(\theta|y) d\theta$

目标 (Goal): 求下一次试验成功的概率 $p(\tilde{y} = 1|y)$ 。

推导步骤 (Derivation Steps):

步骤 1: 写出后验预测分布的定义

$$p(\tilde{y} = 1|y) = \int_0^1 p(\tilde{y} = 1|\theta) \cdot p(\theta|y) d\theta$$

步骤 2: 代入 $p(\tilde{y} = 1|\theta) = \theta$ (给定 θ , 成功的条件概率就是 θ)

$$= \int_0^1 \theta \cdot p(\theta|y) d\theta = \mathbb{E}(\theta|y)$$

步骤 3: 识别这是后验均值

$$= \mathbb{E}(\theta|y)$$

步骤 4: 应用 Beta 分布均值公式

$$= \frac{y+1}{(y+1) + (n-y+1)} = \frac{y+1}{n+2}$$

结论: 拉普拉斯继承法则表明, 在均匀先验下, 已知 n 次试验中 y 次成功, 下一次成功的概率是 $\frac{y+1}{n+2}$ 。这推广了”瑞士表匠”问题的直觉——即使观测到 n 次成功, 概率也不是 1 (因为 θ 本身可能是变化的)。

2.4. 总期望与总方差公式推导. 背景 (Background): 全期望公式和全方差公式是概率论中的两个基本恒等式, 它们描述了如何通过条件分布来计算无条件矩。

参数定义 (Parameter Definitions):

- θ : 随机变量 (参数)
- y : 随机变量 (数据)
- $\mathbb{E}(\theta)$: θ 的无条件 (先验) 均值
- $\text{Var}(\theta)$: θ 的无条件 (先验) 方差
- $\mathbb{E}(\theta|y)$: 给定 y 后 θ 的条件均值
- $\text{Var}(\theta|y)$: 给定 y 后 θ 的条件方差

已知条件 (Given):

- 条件期望定义: $\mathbb{E}(\theta|y)$ 是 y 的函数
- 迭代期望法则: $\mathbb{E}[\mathbb{E}(\theta|y)] = \mathbb{E}(\theta)$

目标 (Goal):

- (1) 证明全期望公式: $\mathbb{E}(\theta) = \mathbb{E}[\mathbb{E}(\theta|y)]$
- (2) 证明全方差公式: $\text{Var}(\theta) = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$

全期望公式推导. **步骤 1:** 从条件期望的定义出发

$$\mathbb{E}[\mathbb{E}(\theta|y)] = \int \mathbb{E}(\theta|y) \cdot p(y) dy$$

步骤 2: 代入条件期望 $\mathbb{E}(\theta|y) = \int \theta \cdot p(\theta|y) d\theta$

$$= \int \left(\int \theta \cdot p(\theta|y) d\theta \right) p(y) dy$$

步骤 3: 交换积分次序 (由富比尼定理保证)

$$= \int \theta \left(\int p(\theta|y)p(y) dy \right) d\theta$$

步骤 4: 识别内层积分 $p(\theta) = \int p(\theta|y)p(y)dy$ (全概率)

$$= \int \theta \cdot p(\theta) d\theta = \mathbb{E}(\theta)$$

结论 1: 全期望公式表明, θ 的先验均值等于在所有可能数据上后验均值的加权平均。

全方差公式推导. **步骤 1:** 从方差定义出发

$$\text{Var}(\theta) = \mathbb{E}(\theta^2) - [\mathbb{E}(\theta)]^2$$

步骤 2: 对 $\mathbb{E}(\theta^2)$ 应用全期望公式

$$\mathbb{E}(\theta^2) = \mathbb{E}[\mathbb{E}(\theta^2|y)]$$

步骤 3: 在给定 y 的条件下, 方差可以写为

$$\text{Var}(\theta|y) = \mathbb{E}(\theta^2|y) - [\mathbb{E}(\theta|y)]^2$$

步骤 4: 解出 $\mathbb{E}(\theta^2|y)$

$$\mathbb{E}(\theta^2|y) = \text{Var}(\theta|y) + [\mathbb{E}(\theta|y)]^2$$

步骤 5: 代入步骤 2

$$\mathbb{E}(\theta^2) = \mathbb{E}[\text{Var}(\theta|y)] + \mathbb{E}[\mathbb{E}(\theta|y)]^2$$

步骤 6: 对 $[\mathbb{E}(\theta|y)]^2$ 应用方差分解

$$\mathbb{E}[\mathbb{E}(\theta|y)]^2 = \text{Var}[\mathbb{E}(\theta|y)] + \{\mathbb{E}[\mathbb{E}(\theta|y)]\}^2$$

步骤 7: 代入全期望公式的结果 $\mathbb{E}[\mathbb{E}(\theta|y)] = \mathbb{E}(\theta)$

$$= \text{Var}[\mathbb{E}(\theta|y)] + [\mathbb{E}(\theta)]^2$$

步骤 8: 代回方差的定义

$$\text{Var}(\theta) = \mathbb{E}(\theta^2) - [\mathbb{E}(\theta)]^2 = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$$

结论 2: 全方差公式表明, **总方差 = 条件方差的均值 + 条件均值的方差**。这在贝叶斯语境下的解释是: 参数的总不确定性来自两个方面——(1) 给定数据后参数仍有的剩余不确定性 (条件方差的均值), 以及 (2) 后验均值随数据变化的不确定性 (条件均值的方差)。

2.5. 正态均值估计的后验分布推导. 背景 (Background): 当我们用正态似然估计正态均值时, 如果使用正态先验, 则后验分布也是正态分布。这个推导展示了共轭先验在正态模型中的应用。

参数定义 (Parameter Definitions):

- $y \sim \text{Normal}(\theta, \sigma^2)$: 观测数据 (已知方差 σ^2)
- $\theta \sim \text{Normal}(\mu_0, \tau_0^2)$: 正态先验
- μ_0 : 先验均值
- τ_0^2 : 先验方差
- σ^2 : 已知的观测方差
- μ_1, τ_1^2 : 后验均值和方差

已知条件 (Given):

- 似然函数: $p(y|\theta) \propto \exp\left(-\frac{(y-\theta)^2}{2\sigma^2}\right)$
- 先验密度: $p(\theta) \propto \exp\left(-\frac{(\theta-\mu_0)^2}{2\tau_0^2}\right)$
- 配方法 (completing the square) 技巧

目标 (Goal): 证明后验分布 $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$, 并求出 μ_1 和 τ_1^2 。

推导步骤 (Derivation Steps):

步骤 1: 写出非归一化后验分布的对数

$$\log p(\theta|y) \propto \log p(\theta) + \log p(y|\theta)$$

步骤 2: 代入先验和似然的对数

$$= -\frac{(\theta - \mu_0)^2}{2\tau_0^2} - \frac{(y - \theta)^2}{2\sigma^2}$$

步骤 3: 展开平方项

$$= -\frac{1}{2} \left[\frac{(\theta^2 - 2\mu_0\theta + \mu_0^2)}{\tau_0^2} + \frac{(\theta^2 - 2y\theta + y^2)}{\sigma^2} \right]$$

步骤 4: 合并 θ^2 项的系数

$$= -\frac{1}{2} \left[\theta^2 \left(\frac{1}{\tau_0^2} + \frac{1}{\sigma^2} \right) - 2\theta \left(\frac{\mu_0}{\tau_0^2} + \frac{y}{\sigma^2} \right) + \text{常数} \right]$$

步骤 5: 识别后验精度 (方差的倒数)

$$\frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

步骤 6: 由配方法, 后验均值满足

$$\theta \cdot \frac{1}{\tau_1^2} = \frac{\mu_0}{\tau_0^2} + \frac{y}{\sigma^2}$$

步骤 7: 解出后验均值

$$\mu_1 = \frac{\mu_0/\tau_0^2 + y/\sigma^2}{1/\tau_0^2 + 1/\sigma^2}$$

步骤 8: 写出完整的后验分布

$$\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$$

结论:

- (1) **精度加法**: 后验精度 = 先验精度 + 数据精度
- (2) **后验均值**: 是先验均值 μ_0 和观测值 y 的加权平均, 权重与精度成正比

2.6. Jeffreys 先验与 Fisher 信息推导. 背景 (Background): Jeffreys 提出了一种构建非信息先验的系统方法, 基于 Fisher 信息的不变性原则。这个先验在参数的单调变换下保持不变。

参数定义 (Parameter Definitions):

- θ : 参数
- $p(y|\theta)$: 似然函数
- $J(\theta)$: Fisher 信息
- $L(\theta) = \log p(y|\theta)$: 对数似然
- $I(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \right]$: Fisher 信息 (另一种定义)
- $\phi = h(\theta)$: 参数的单调变换

已知条件 (Given):

- Jeffreys 原则: 先验应在参数的单调变换下保持不变
- Fisher 信息定义: $J(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \right]$
- 变换公式: $p(\phi) = p(\theta) \cdot \left| \frac{d\theta}{d\phi} \right|$

目标 (Goal): 推导 Jeffreys 先验公式并验证其在变换下的不变性。

推导步骤 (Derivation Steps):

Jeffreys 先验公式推导. 步骤 1: Jeffreys 提出先验正比于 Fisher 信息的平方根

$$p(\theta) \propto [J(\theta)]^{1/2}$$

步骤 2: 验证在变换 $\phi = h(\theta)$ 下的不变性

在新参数 ϕ 下, Fisher 信息为

$$J(\phi) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\phi)}{\partial \phi^2} \right]$$

步骤 3: 利用链式法则

$$\frac{\partial \log p(y|\theta)}{\partial \phi} = \frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d\theta}{d\phi}$$

步骤 4: 计算二阶导数

$$\frac{\partial^2 \log p(y|\theta)}{\partial \phi^2} = \frac{\partial}{\partial \phi} \left(\frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d\theta}{d\phi} \right) = \frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \left(\frac{d\theta}{d\phi} \right)^2 + \frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d^2 \theta}{d\phi^2}$$

步骤 5: 取期望, 利用 $\mathbb{E} \left[\frac{\partial \log p(y|\theta)}{\partial \theta} \right] = 0$ (得分函数的期望为零)

$$J(\phi) = \left(\frac{d\theta}{d\phi} \right)^2 J(\theta)$$

步骤 6: 因此

$$[J(\phi)]^{1/2} = \left| \frac{d\theta}{d\phi} \right| [J(\theta)]^{1/2}$$

步骤 7: 新先验为

$$p(\phi) \propto [J(\phi)]^{1/2} \propto [J(\theta)]^{1/2} \left| \frac{d\theta}{d\phi} \right|$$

结论: 这正是概率密度在变量变换下的标准变换公式, 因此 Jeffreys 先验在单调变换下是不变的。

二项模型的 *Jeffreys* 先验推导. **步骤 1:** 写出二项模型的对数似然

$$\log p(y|\theta) = \log \binom{n}{y} + y \log \theta + (n - y) \log(1 - \theta)$$

步骤 2: 计算一阶导数 (得分函数)

$$\frac{\partial}{\partial \theta} \log p(y|\theta) = \frac{y}{\theta} - \frac{n - y}{1 - \theta}$$

步骤 3: 计算二阶导数

$$\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) = -\frac{y}{\theta^2} - \frac{n - y}{(1 - \theta)^2}$$

步骤 4: 取负期望 (注意 $\mathbb{E}(Y) = n\theta$)

$$J(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) \right] = \frac{n\theta}{\theta^2} + \frac{n(1 - \theta)}{(1 - \theta)^2} = \frac{n}{\theta(1 - \theta)}$$

步骤 5: 应用 *Jeffreys* 公式

$$p(\theta) \propto \left[\frac{n}{\theta(1 - \theta)} \right]^{1/2} \propto \theta^{-1/2} (1 - \theta)^{-1/2}$$

步骤 6: 识别为 Beta 分布

$$p(\theta) \propto \theta^{(1/2)-1} (1 - \theta)^{(1/2)-1} \Rightarrow \theta \sim \text{Beta} \left(\frac{1}{2}, \frac{1}{2} \right)$$

结论: 二项模型的 *Jeffreys* 先验是 $\text{Beta}(1/2, 1/2)$, 这是一个弱信息先验, 比均匀先验 $\text{Beta}(1, 1)$ 在边界处更轻。

2.7. 后验预测分布的均值与方差推导. 背景 (Background): 后验预测分布 $\tilde{y}|y$ 的均值和方差有两个组成部分——一个来自模型本身的随机性, 另一个来自参数的后验不确定性。

参数定义 (Parameter Definitions):

- $\tilde{y}$: 未来观测
- y : 当前观测
- θ : 参数
- $\mathbb{E}(\tilde{y}|y)$: 后验预测均值
- $\text{Var}(\tilde{y}|y)$: 后验预测方差

已知条件 (Given):

- $\tilde{y}|\theta \sim \text{Normal}(\theta, \sigma^2)$
- $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$
- 全期望公式: $\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$
- 全方差公式: $\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$

目标 (Goal): 求后验预测分布 $\tilde{y}|y$ 的均值和方差。

后验预测均值推导. **步骤 1**: 应用全期望公式

$$\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 给定 θ , $\tilde{y}$ 与 y 条件独立, 且 $\mathbb{E}(\tilde{y}|\theta) = \theta$

$$= \mathbb{E}(\theta|y) = \mu_1$$

结论 1: 后验预测均值等于参数的后验均值。

后验预测方差推导. **步骤 1:** 应用全方差公式

$$\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 第一项——给定 θ 下的方差是 σ^2 (模型方差)

$$\mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] = \mathbb{E}(\sigma^2|y) = \sigma^2$$

步骤 3: 第二项——条件均值的方差

$$\text{Var}[\mathbb{E}(\tilde{y}|\theta, y)] = \text{Var}(\theta|y) = \tau_1^2$$

步骤 4: 合并

$$\text{Var}(\tilde{y}|y) = \sigma^2 + \tau_1^2$$

结论 2: 后验预测方差 = **模型方差** + **参数后验方差**。这体现了贝叶斯推断的核心：预测的不确定性来自两个方面——(1) 模型本身的随机性 (σ^2)，以及 (2) 参数估计的不确定性 (τ_1^2)。

3. 阅读过程中的问题与解答

4. 什么是分布的核

4.1. 问题. 分布的核是什么概念?

4.2. 回答. 分布的核 (kernel) 是指概率密度/质量函数中依赖于参数的核心部分，不包括归一化常数。

举例说明:

Beta-Binomial 共轭中，后验分布：

$$p(\theta|y) \propto \theta^{\alpha+y-1}(1-\theta)^{\beta+n-y-1}$$

其中 $\theta^{\alpha+y-1}(1-\theta)^{\beta+n-y-1}$ 是**核**，而完整的 Beta 分布还需要归一化常数：

$$p(\theta|y) = \frac{\Gamma(\alpha + \beta + n)}{\Gamma(\alpha + y)\Gamma(\beta + n - y)} \theta^{\alpha+y-1}(1-\theta)^{\beta+n-y-1}$$

为什么核重要:

(1) **识别分布形式:** 知道核是 $\theta^a(1-\theta)^b$ 形式，就能识别这是 Beta 分布

(2) **贝叶斯推断中省略 $p(y)$:** $p(y)$ 是归一化常数，不包含关于 θ 的信息，所以可以省略

(3) **简化推导:** 在推导过程中只关注核，省去繁琐的归一化常数

Insight 这本质上是**信息局部性**思想：归一化常数的作用只是“让面积等于 1”，它本身不携带关于参数的信息。真正“有意义”的概率质量都集中在核上。

5. 学习笔记

在这里记录你的学习心得和思考。