

贝叶斯数据分析讲义

Gelman, Carlin, Stern, Dunson, Vehtari, Rubin

Contents

引言：文献概述	7
引言：文献概述	7
1. 什么是贝叶斯数据分析	7
2. 核心概念	7
3. 文献目录	8
4. 课程结构	8
5. 学习方法	9
Part 1. 贝叶斯推断基础	11
Chapter 1. 概率与推断	13
1. 贝叶斯数据分析的三步骤	13
2. 统计推断的一般符号	13
3. 贝叶斯推断	13
4. 似然与优势比	15
5. 概率作为不确定性的度量	15
6. 主观性与客观性	16
7. 概率赋值的例子：足球点差	16
8. 概率论的一些有用结果	16
9. 本章小结	16
10. 下节预告	16
Chapter 2. 单参数模型	17
1. 从二项数据估计概率	17
2. 后验作为数据与先验信息的折中	18
3. 后验推断的汇总	18
4. 信息先验分布	18
5. 正态均值的估计（已知方差）	19
6. 非信息先验分布	20
7. Jeffreys 不变性原则	20
8. 弱信息先验分布	21
9. 其他标准单参数模型	21
10. 本章小结	21
11. 下节预告	21
Chapter 3. 多参数模型简介	23
1. 对 Nuisance 参数的积分	23
2. 正态数据与非信息先验	23
3. 正态数据与共轭先验	25

4. 分类数据的多项模型	25
5. 已知方差的多元正态模型	26
6. 均值和方差都未知的多元正态模型	26
7. 基本建模与计算总结	26
8. 本章小结	27
9. 下节预告	27
Chapter 4. 渐近性与非贝叶斯方法的联系	29
1. 本章导论	29
2. 后验分布的正态近似	29
3. 大样本理论	29
4. 定理的反例	29
5. 贝叶斯推断的频率评估	29
6. 其他统计方法的贝叶斯解释	29
7. 本章小结	29
Chapter 5. 分层模型	31
1. 本章导论	31
2. 主要内容	31
3. 本章小结	31
Part 2. 贝叶斯数据分析基础	33
Chapter 6. 模型检查	35
1. 本章导论	35
2. 主要内容	35
3. 本章小结	35
Chapter 7. 模型评估、比较与扩展	37
1. 本章导论	37
2. 主要内容	37
3. 本章小结	37
Chapter 8. 考虑数据收集过程的建模	39
1. 本章导论	39
2. 主要内容	39
3. 本章小结	39
Chapter 9. 决策分析	41
1. 本章导论	41
2. 主要内容	41
3. 本章小结	41
Part 3. 高级计算方法	43
Chapter 10. 贝叶斯计算入门	45
1. 本章导论	45
2. 主要内容	45
3. 本章小结	45

Chapter 11. 马尔可夫链模拟基础	47
1. 本章导论	47
2. 主要内容	47
3. 本章小结	47
Chapter 12. 高效马尔可夫链模拟	49
1. 本章导论	49
2. 主要内容	49
3. 本章小结	49
Chapter 13. 模态与分布近似	51
1. 本章导论	51
2. 主要内容	51
3. 本章小结	51
Part 4. 回归模型	53
Chapter 14. 回归模型入门	55
1. 本章导论	55
2. 主要内容	55
3. 本章小结	55
Chapter 15. 分层线性模型	57
1. 本章导论	57
2. 主要内容	57
3. 本章小结	57
Chapter 16. 广义线性模型	59
1. 本章导论	59
2. 主要内容	59
3. 本章小结	59
Chapter 17. 稳健推断模型	61
1. 本章导论	61
2. 稳健性的各个方面	61
3. 标准概率模型的过度分散版本	61
4. 后验推断与计算	61
5. 八校例子中的稳健推断与敏感性分析	61
6. 使用 t 分布误差的稳健回归	61
7. 本章小结	61
Chapter 18. 缺失数据模型	63
1. 本章导论	63
2. 主要内容	63
3. 本章小结	63
Part 5. 非参数模型	65
Chapter 19. 参数非线性模型	67
1. 本章导论	67

2. 主要内容	67
3. 本章小结	67
Chapter 20. 基函数模型	69
1. 本章导论	69
2. 主要内容	69
3. 本章小结	69
Chapter 21. 高斯过程模型	71
1. 本章导论	71
2. 主要内容	71
3. 本章小结	71
Chapter 22. 有限混合模型	73
1. 本章导论	73
2. 主要内容	73
3. 本章小结	73
Chapter 23. 狄利克雷过程模型	75
1. 本章导论	75
2. 主要内容	75
3. 本章小结	75
Appendix A. 公式推导	77
1. 概率与推断 (Chapter 1) 推导	77
2. 单参数模型 (Chapter 2) 推导	82
3. 阅读过程中的问题与解答	96
4. 什么是分布的核	96
5. 学习笔记	96

引言：文献概述

1. 什么是贝叶斯数据分析

贝叶斯数据分析是一种统计推断方法，其核心思想是使用概率来量化不确定性。在贝叶斯框架下，所有未知量——包括参数、潜在变量、甚至未来观测——都被视为随机变量，用概率分布来描述。

与传统频率主义统计不同，贝叶斯方法明确使用概率来表达我们对未知量的信念 (belief)。这种方法的主要优势包括：

- **自然的不确定性量化**：贝叶斯概率区间可以直接解释为“未知量包含在该区间内的概率”
- **灵活的建模能力**：可以构建复杂的多层次模型
- **原则性的推断框架**：贝叶斯定理为所有推断提供了统一的基础
- **先验信息的整合**：允许将领域知识融入统计分析

贝叶斯数据分析的过程可以概括为三个步骤：

- (1) 建立完整的概率模型
- (2) 基于观测数据计算后验分布
- (3) 评估模型的拟合度和敏感性

2. 核心概念

2.1. 先验分布 (Prior Distribution). 先验分布代表在观测数据之前，我们对未知参数 θ 的已有知识或信念。先验分布可以是：

- **信息先验**：基于领域知识或历史数据
- **非信息先验**：尽量减少先验对结果的影响（如 Jeffreys 先验）
- **弱信息先验**：包含一定信息但不完全反映领域知识

2.2. 后验分布 (Posterior Distribution). 后验分布是贝叶斯推断的核心——在观测到数据 y 后，关于参数 θ 的更新后的知识：

$$p(\theta|y) = \frac{p(y|\theta) \cdot p(\theta)}{p(y)}$$

其中 $p(y|\theta)$ 是似然函数， $p(y)$ 是边际似然（归一化常数）。

2.3. 预测分布 (Predictive Distribution). 贝叶斯方法可以自然地进行预测推断：

- **先验预测分布**： $p(y) = \int p(y|\theta)p(\theta)d\theta$
- **后验预测分布**： $p(\tilde{y}|y) = \int p(\tilde{y}|\theta)p(\theta|y)d\theta$

3. 文献目录

3.1. 核心教材.

- (1) *Bayesian Data Analysis, Third Edition* —Gelman, Carlin, Stern, Dunson, Vehtari, Rubin

本课程的核心教材，656 页，系统介绍了贝叶斯数据分析的理论与实践。

- Part I: 贝叶斯推断基础（概率、三步骤、单/多参数模型、分层模型）
- Part II: 数据分析基础（模型检查、评估、决策分析）
- Part III: 高级计算方法（MCMC、变分推断）
- Part IV: 回归模型
- Part V: 非参数模型

3.2. 课件.

- (1) *Three Steps of Bayesian Data Analysis* —Chapter 1 课件
- (2) *Single-parameter Models* —Chapter 2 课件
- (3) *Multi-parameter Models* —Chapter 3 课件
- (4) *Hierarchical Models* —Chapter 5 课件
- (5) *Model Checking* —Chapter 6 课件
- (6) *Bayesian Workflow* —Chapter 10 课件
- (7) *Advanced Topics* —Chapter 11 课件

3.3. 补充材料.

- (1) *Metropolis 算法简要证明*
MCMC 方法中 Metropolis 算法的理论基础与证明。
- (2) *R 语言实现抽样基础*
使用 R 语言实现各种抽样方法的实践指南。
- (3) *p 值补充*
p 值的定义、解释与局限性分析。
- (4) *拒绝抽样补充*
拒绝抽样方法的详细介绍与实现。

3.4. 参考教材.

- (1) *Markov Chain Monte Carlo in Practice* —Gilks, Richardson, Spiegelhalter
MCMC 方法的实践指南，是 BDA 第 11-12 章的重要补充。
- (2) *Monte Carlo Statistical Methods* —Robert, Casella
蒙特卡洛统计方法的理论教材，包含更深入的算法分析。
- (3) *Bayesian Statistical Modelling* —Congdon
贝叶斯统计建模的实用参考，提供了丰富的建模案例。

4. 课程结构

本课程将按照 BDA 第三版的结构依次学习：

- Part I (第 1-5 章)：贝叶斯推断基础
- Part II (第 6-9 章)：数据分析基础
- Part III (第 10-13 章)：高级计算方法
- Part IV (第 14-18 章)：回归模型
- Part V (第 19-23 章)：非参数模型

5. 学习方法

注 0.1. 建议的学习方法：

- (1) 先阅读课件把握整体框架
- (2) 深入阅读教材对应章节
- (3) 完成课后习题巩固理解
- (4) 通过编程实践加深概念

Part 1

贝叶斯推断基础

CHAPTER 1

概率与推断

1. 贝叶斯数据分析的三步骤

贝叶斯数据分析的过程可以理想化地分为以下三个步骤：

- (1) **建立完整的概率模型**：对问题中所有可观测和不可观测的量建立一个联合概率分布。模型应与底层科学问题（scientific problem）和数据收集过程的知识相一致。
- (2) **基于观测数据进行分析**：计算并解释适当的后验分布——即在给定观测数据的条件下，关于不可观测量的条件概率分布。
- (3) **评估模型的拟合度和后验分布的含义**：
 - 模型对数据的拟合程度如何？
 - 实质性结论（substantive conclusions）是否合理？
 - 结果对第一步中建模假设的敏感性如何？

作为回应，可以修改或扩展模型并重复这三个步骤。

第二个步骤涉及计算方法论，第三个步骤涉及微妙的技术与判断平衡，均由问题的应用背景指导。

第一步仍然是许多贝叶斯分析的主要障碍：我们的模型从何而来？如何构建适当的概率规范？

贝叶斯思维的主要动机是它便于对统计结论进行常识性解释。例如，一个未知量的贝叶斯（概率）区间可以直接被认为是“该未知量有很高概率包含在其中”，这与频率主义（置信区间）的解释形成对比——后者在严格解释下只能关联到重复抽样序列中的类似推断。

2. 统计推断的一般符号

在贝叶斯统计中，我们使用以下符号：

- θ ：不可观测的向量值或总体参数（如临床试验中每种治疗方案的生存概率）
- y ：观测数据（如每组中的存活和死亡人数）
- $\tilde{y}$ ：未知但潜在可观测的量（如其他治疗方案下患者的结果，或与试验中患者相似的新患者的结果）
- x ：解释变量或协变量（如患者的年龄和先前健康状况）

这些概率陈述以观测值 y 为条件，在我们记号中简单记为 $p(\theta|y)$ 或 $p(\tilde{y}|y)$ 。我们也隐含地以协变量的已知值为条件。

3. 贝叶斯推断

贝叶斯推断的核心思想是：关于参数 θ 或未观测数据 $\tilde{y}$ 的统计结论，都以概率陈述的形式给出。

这些概率陈述以观测值 y 为条件，在我们的记号中简单记为 $p(\theta|y)$ 或 $p(\tilde{y}|y)$ 。

3.1. 贝叶斯定理。为了对给定 y 的 θ 做出概率陈述，我们必须首先建立一个提供 θ 和 y 联合概率分布的模型。

联合概率质量（或密度）函数可以写成两个密度的乘积，通常称为先验分布 $p(\theta)$ 和采样分布（或数据分布） $p(y|\theta)$ ：

$$p(\theta, y) = p(\theta) \times p(y|\theta)$$

使用条件概率的基本性质（贝叶斯定理），得到后验密度：¹

$$p(\theta|y) = \frac{p(\theta) \times p(y|\theta)}{p(y)}$$

其中

$$p(y) = \int p(\theta) \times p(y|\theta) d\theta$$

一个等价的形式省略了不依赖于 θ 的因子 $p(y)$ ，给出非归一化后验密度：

$$p(\theta|y) \propto p(\theta) \times p(y|\theta)$$

为什么可以省略 $p(y)$ ？

关键在于：后验分布的**核**（kernel）²包含了所有关于 θ 的信息，而 $p(y)$ 作为归一化常数不包含任何关于 θ 的新信息。

以正态分布为例：后验密度 $p(\theta|y) \propto \exp\left(-\frac{(\theta-\mu)^2}{2\sigma^2}\right)$ ，我们只凭这个指数函数的形式就能识别出这是正态分布 $N(\mu, \sigma^2)$ ——因为已知核是二次型的指数，就能确定完整分布。

换句话说， $p(y)$ 的作用只是确保后验密度积分为 1，但它的具体值对于理解 θ 如何随数据更新并无贡献。

注 1.1. 注意： $p(y|\theta)$ 被视为 θ 的函数（固定 y ），而不是 y 的函数。这被称为似然函数。

3.2. 预测. 在数据 y 被观测之前，未知但可观测的 $\tilde{y}$ 的分布是边际分布：³

$$p(y) = \int p(y|\theta) \times p(\theta) d\theta$$

这被称为先验预测分布（prior predictive distribution）。

在观测到数据 y 之后，预测 $\tilde{y}$ 的分布是后验预测分布（posterior predictive distribution）：⁴

$$p(\tilde{y}|y) = \int p(\tilde{y}|\theta) \times p(\theta|y) d\theta$$

后验预测分布可以解释为在 θ 的后验分布上对条件预测进行平均。

例 1.1 (称重例子). 令 $y = (y_1, \dots, y_n)$ 为物体在秤上称量 n 次的记录重量， $\theta = (\mu, \sigma^2)$ 为物体的真实重量和测量方差， $\tilde{y}$ 为计划中新称量结果。

第二行展示了后验预测分布作为后验分布上条件预测的平均。最后一步来自在给定 θ 的条件下 y 和 $\tilde{y}$ 的条件独立性假设。

¹推导见附录 section 1.1

²关于“核”概念的详细解释，见附录 section 4

³推导见附录 section 1.2

⁴推导见附录 section 1.2

4. 似然与优势比

使用贝叶斯定理与选定的概率模型意味着数据 y 只通过 $p(y|\theta)$ 影响后验推断，当固定 y 将其视为 θ 的函数时，称为**似然函数**。

这样，贝叶斯推断服从所谓的似然原理：对于给定的数据样本，任何具有相同似然函数的概率模型 $p(y|\theta)$ 对 θ 产生相同的推断。

后验密度 $p(\theta|y)$ 在 θ_1 和 θ_2 处取值的比率称为后验优势比。优势比提供了一个概率的替代表示，并且具有贝叶斯定理用优势比表示特别简单的形式：⁵

$$\frac{p(\theta_1|y)}{p(\theta_2|y)} = \frac{p(\theta_1)}{p(\theta_2)} \times \frac{p(y|\theta_1)}{p(y|\theta_2)}$$

即：后验优势比 = 先验优势比 $\times$ 似然比。

5. 概率作为不确定性的度量

在贝叶斯统计中，概率被用作不确定性的基本度量（fundamental measure or yardstick of uncertainty）。在这个范式下，讨论明天降雨的概率或巴西队赢得世界杯的概率与讨论硬币抛掷正面朝上的概率同样合法。

为什么概率是量化不确定性的合理方式？通常有以下理由：

- (1) **类比**：物理随机性引起不确定性，因此用随机事件的语言描述不确定性似乎是合理的。日常语言使用“可能”和“不太可能”等术语，将更正式的概率计算扩展到科学推断问题是与之一致的。
- (2) **公理化或规范性方法**：与决策理论相关，将所有统计推断置于收益和损失的决策背景下。那么合理的公理（排序、传递性等）意味着不确定性必须用概率表示。
- (3) **博彩一致性**：定义你赋予事件 E 的概率 p ($p \in [0, 1]$) 为你愿意以此比例交换（即赌） $\$p$ 来换取如果 E 发生则获得 $\$1$ 的回报。也就是说，如果 E 发生，你额外获得 $(1 - p)$ ；如果 E 的补集发生，你损失 p 。

一致性原则（coherence principle）表明：你对所有可能事件的概率赋值不应该让对方有可能从你这里确定获利。可以证明在这种原则下构建的概率必须满足概率论的基本公理。

博彩基本原理有一些根本性困难：

- 需要精确的赔率，你愿意在两个方向中的任何一个方向下赌注。对于所有事件如何指定精确赔率？如果你不确定呢？
- 如果一个人愿意与你对赌，而且他有你不知道的信息，你接受赌注可能不明智。

这些考虑表明概率可能是总结应用统计中不确定性的合理方法，但最终证明在于应用的成功。

5.1. 两种经典论证. 对称性/可交换性论证：

$$\text{概率} = \frac{\text{有利情况数}}{\text{可能情况数}}$$

对于硬币抛掷，这实际上是一个物理论证，基于关于决定硬币如何落地的力量以及抛掷的初始物理条件的假设。

频率论证：

概率 = 在长期重复序列中得到的相对频率

假设以相同方式物理独立地进行。

⁵推导见附录 section 1.3

这两种论证在某种意义上都是主观的，因为它们需要对硬币性质和抛掷程序的判断，两者都涉及关于等可能性事件、相同测量和独立性的语义论证。

频率论证可能有某些特殊困难，因为它涉及长期相同抛掷序列的假设性概念。如果严格遵循，这种观点不允许对不属于长期相同事件序列的单一抛掷做出概率陈述。

6. 主观性与客观性

所有使用概率的统计方法在某种意义上都是主观的，因为它们依赖于对世界的数学理想化。

贝叶斯方法有时被认为特别主观，因为它们依赖于先验分布。但在大多数问题中，科学判断对于指定似然和先验分布都是必要的。

一个普遍原则是：每当存在复制时（即观察到许多可交换的单位），就有机会从数据中估计概率分布的特征，从而使分析更加客观。

如果整个实验被重复若干次，那么先验分布的参数本身也可以从数据中估计。

7. 概率赋值的例子：足球点差

在足球比赛中，“点差”（point spread）是博彩公司设定的赔率，用于使两边下注相对均衡。例如，如果热门队（favorite）的点差是 8 分，意味着博彩公司认为热门队平均会赢 8 分。

给定点差，我们可以估计各种条件概率：

- $\Pr(\text{热门队赢} | \text{点差} = 8)$
- $\Pr(\text{热门队至少赢 8 分} | \text{点差} = 8)$
- $\Pr(\text{热门队至少赢 8 分} | \text{点差} = 8 \text{ 且热门队赢})$

这些概率可以通过相对频率估计，也可以用正态近似来估计（outcome - point spread 的分布）。

8. 概率论的一些有用结果

见教材。

9. 本章小结

本章我们学习了：

- (1) 贝叶斯数据分析的三个基本步骤
- (2) 统计推断的一般符号 $(\theta, y, \tilde{y}, x)$
- (3) 贝叶斯定理及其组成部分（先验、似然、后验、边际似然）
- (4) 预测分布：先验预测分布与后验预测分布
- (5) 概率作为不确定性度量的多种解释
- (6) 似然原理和优势比

10. 下节预告

下一章我们将学习单参数模型，包括从二项数据估计概率的经典例子——这是贝叶斯推断最经典的入门案例。

CHAPTER 2

单参数模型

1. 从二项数据估计概率

考虑从二项分布 $y \sim \text{Binomial}(n, \theta)$ 中观测到 y 次成功，其中：

- y : n 次伯努利试验中的成功总次数
- θ : 总体中的成功比例，或每次试验的成功概率

二项分布的似然函数为：

$$p(y|\theta) = \binom{n}{y} \theta^y (1 - \theta)^{n-y}$$

为了执行贝叶斯推断，我们必须为 θ 指定先验分布。作为简单开始，我们假设先验分布是 $[0, 1]$ 上的均匀分布： $\theta \sim \text{Uniform}(0, 1)$ ，即 $p(\theta) = 1$ 。

应用贝叶斯定理，得到后验密度：¹

$$p(\theta|y) \propto \theta^y (1 - \theta)^{n-y}$$

这正是 Beta 分布的形式，因此：

$$\theta|y \sim \text{Beta}(y + 1, n - y + 1)$$

定义 2.1 (Beta 分布). Beta 分布的概率密度函数为：

$$p(x|\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1 - x)^{\beta-1}, \quad 0 \leq x \leq 1$$

在固定 n 和 y 的情况下，组合数 $\binom{n}{y}$ 不依赖于未知参数 θ ，因此在计算后验分布时可以视为常数。

1.1. 预测. 在均匀先验下，先验预测分布可以直接计算。在模型下，所有可能的 y 值在先验下同等可能。

令 $\tilde{y}$ 表示与前 n 次试验可交换的一次新试验的结果：²

$$P(\tilde{y} = 1|y) = \int_0^1 \theta \cdot p(\theta|y) d\theta = \mathbb{E}(\theta|y) = \frac{y + 1}{n + 2}$$

这就是著名的拉普拉斯继承法则 (Laplace's law of succession)。在极端观测 $y = 0$ 和 $y = n$ 时，拉普拉斯法则预测概率分别为 $1/(n + 2)$ 和 $(n + 1)/(n + 2)$ 。

¹推导见附录 section 2.1

²推导见附录 section 2.3

2. 后验作为数据与先验信息的折中

贝叶斯推断的过程涉及从先验分布 $p(\theta)$ 到后验分布 $p(\theta|y)$ 的转化。以下两个式子描述了先验与后验之间的一般关系：³

$$\mathbb{E}(\theta) = \mathbb{E}[\mathbb{E}(\theta|y)]$$

$$\text{Var}(\theta) = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$$

第一个式子 (law of total expectation) 几乎不足为奇： θ 的先验均值是所有可能数据上后验均值的平均。

第二个式子 (law of total variance) 更有趣：后验方差平均上小于先验方差，两者之差取决于后验均值在不同数据上的变化程度。变化越大，我们降低不确定性的潜力越大。

2.1. 二项例子中的折中. 在二项例子中，均匀先验的均值是 $1/2$ ，方差是 $1/12$ 。

后验均值 $\frac{y+1}{n+2}$ 是先验均值 $1/2$ 和样本比例 y/n 之间的折中，显然，随着数据样本量增大，先验的作用越来越小。

这是贝叶斯推断的一般特征：**后验分布位于代表先验信息和数据信息的点之间，折中程度随着样本量增加越来越受数据控制。**

3. 后验推断的汇总

后验概率分布包含了关于参数 θ 的所有当前信息。常用的位置汇总包括后验均值、后验中位数、后验众数；变化程度通常用标准差、四分位距和其他分位数来汇总。

当后验分布具有闭式形式时（如当前例子中的 Beta 分布），这些汇总通常可以用闭式形式得到。

3.1. 后验区间. 除了点汇总之外，报告后验不确定性几乎总是重要的。通常的方法是给出后验分布的分位数，或者如果需要区间汇总，则给出一定概率的后验中心区间（如 $100(1 - \alpha)\%$ 区间）。这类区间估计称为**后验区间** (posterior interval)。

3.2. 最高后验密度区间. 另一种汇总后验不确定性的方法是**最高后验密度区域** (Highest Posterior Density, HPD region)：包含 $100(1 - \alpha)\%$ 后验概率的集合，且区域内密度不低于区域外。

对于单峰且对称的后验分布，HPD 区间与后验中心区间相同。但对于非对称分布，两者可能有显著差异——当后验分布有偏时，HPD 区间可以更准确地反映真实的不确定性范围。

4. 信息先验分布

在二项例子中，到目前为止我们只考虑了 θ 的均匀先验分布。问题在于：如何证明这种指定的合理性？一般来说，我们如何处理构建先验分布的问题？

对先验分布有两种基本解释：

- (1) **总体解释**：先验分布代表可能参数值的总体，当前感兴趣的 θ 是其中抽取的。
- (2) **主观知识状态解释**：指导原则是，我们必须将关于 θ 的知识（和不确定性）表达得像它的值是先验分布的随机实现一样。

对于许多问题（如估计新工业过程中失败概率），不存在完全相关的 θ 的总体。先验分布应包含所有合理的 θ 值，但分布不必真实集中在真值附近，因为通常数据中关于 θ 的信息远超过任何合理先验概率规范。

³推导见附录 section 2.4

4.1. 共轭先验. 考虑二项模型的似然: $p(y|\theta) \propto \theta^y(1-\theta)^{n-y}$

如果先验密度具有相同形式, 则后验密度也具有这种形式。我们将先验密度参数化为:

$$p(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$$

即 $\theta \sim \text{Beta}(\alpha, \beta)$ 。

将 $p(\theta)$ 与 $p(y|\theta)$ 比较, 可以看出这个先验等价于 $\alpha - 1$ 次先验成功和 $\beta - 1$ 次先验失败。

共轭性: 后验分布与先验分布属于同一参数形式。Beta 先验分布是二项似然的共轭族。共轭族在计算上是方便的, 因为后验分布遵循已知参数形式。⁴

后验均值:

$$\mathbb{E}(\theta|y) = \frac{\alpha + y}{\alpha + \beta + n}$$

后验方差:

$$\text{Var}(\theta|y) = \frac{(\alpha + y)(\beta + n - y)}{(\alpha + \beta + n)^2(\alpha + \beta + n + 1)}$$

当 y 和 $n - y$ 变大而 α 和 β 固定时:

$$\mathbb{E}(\theta|y) \approx \frac{y}{n}, \quad \text{Var}(\theta|y) \approx \frac{1}{n} \cdot \frac{y}{n} \left(1 - \frac{y}{n}\right)$$

方差以 $1/n$ 的速率趋近于零。极限情况下, 先验分布的参数对后验分布没有影响。

5. 正态均值的估计 (已知方差)

考虑来自正态分布 $y \sim \text{Normal}(\theta, \sigma^2)$ 的单个标量观测 y , 其中 σ^2 已知。

采样分布:

$$p(y|\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\theta)^2}{2\sigma^2}\right)$$

作为 θ 的函数, 似然是二次型的指数, 因此共轭先验族为:

$$p(\theta) \propto \exp(A\theta^2 + B\theta + C), \quad A < 0$$

参数化为 $\theta \sim \text{Normal}(\mu_0, \tau_0^2)$, 其中 μ_0 和 τ_0^2 是超参数。⁵

经过配方法, 得到后验分布 $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$, 其中:

$$\mu_1 = \frac{\mu_0/\tau_0^2 + y/\sigma^2}{1/\tau_0^2 + 1/\sigma^2}, \quad \frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

精度: 方差的倒数称为精度。后验精度等于先验精度加上数据精度。

后验均值 μ_1 可以多种方式解释:

- 先验均值和观测值 y 的加权平均, 权重与精度成正比
- 先验均值向观测值调整: $\mu_1 = \mu_0 + (y - \mu_0) \frac{\tau_0^2}{\sigma^2 + \tau_0^2}$
- 数据向先验均值收缩: $\mu_1 = y - (y - \mu_0) \frac{\sigma^2}{\sigma^2 + \tau_0^2}$

每种形式都表示后验均值是先验均值和观测值之间的折中。

⁴推导见附录 section 2.2

⁵推导见附录 section 2.5

5.1. 后验预测分布.⁶

未来观测 $\tilde{y}$ 的后验预测分布：

$$\tilde{y}|y \sim \text{Normal}(\mu_1, \sigma^2 + \tau_1^2)$$

预测均值等于 θ 的后验均值；预测方差有两个组成部分：来自模型的方差 σ^2 和来自 θ 后验不确定性的方差 τ_1^2 。

5.2. 多观测的正态模型. 上述单观测正态模型可以轻松推广到 n 个独立同分布观测 $y = (y_1, \dots, y_n)$ 。因为 $\bar{y}|\theta \sim \text{Normal}(\theta, \sigma^2/n)$ ，对单观测推导的结果直接适用（将 $\bar{y}$ 视为单观测）：

$$\theta|y_1, \dots, y_n \sim \text{Normal}(\mu_n, \tau_n^2)$$

其中：

$$\mu_n = \frac{\mu_0/\tau_0^2 + n\bar{y}/\sigma^2}{1/\tau_0^2 + n/\sigma^2}, \quad \frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$$

6. 非信息先验分布

当先验分布没有总体基础时，很难构建，长期以来人们渴望得到保证在后验分布中作用最小的先验分布。这类分布有时称为参考先验分布，先验密度被称为模糊、平坦、扩散或非信息的。

使用非信息先验的理由通常是“让数据自己说话”，使推断不受当前数据外部信息的影响。

一个相关想法是**弱信息先验分布**，它包含一些信息——足以正则化后验分布（即保持它在合理范围内），但不试图完全捕捉关于底层参数的科学知识。

6.1. 正常与非正常先验. 如果先验精度 $1/\tau_0^2$ 相对于数据精度 n/σ^2 很小，则后验分布近似于 $\tau_0^2 = \infty$ 的情况：

$$p(\theta|y) \approx \text{Normal}(\bar{y}, \sigma^2/n)$$

换句话说，后验分布近似于假设 $p(\theta)$ 与常数成正比的情况。这种分布实际上不可能，因为 $p(\theta)$ 的积分是无穷大，违反了概率总和为 1 的假设。

定义 2.2. 如果先验密度 $p(\theta)$ 不依赖于数据且积分等于 1，则称为正常 (proper) 先验。如果 $p(\theta)$ 积分到任何正有限值，可以重新归一化使其积分到 1，则称为非归一化密度。如果积分不是有限的，称为非正常 (improper) 先验。

非正常先验可能导致正常后验分布。使用非正常先验得到的后验分布必须非常小心解释——必须始终检查后验分布的积分是有限的且形式合理。

7. Jeffreys 不变性原则

一种有时用于定义非信息先验的方法是由 Jeffreys 提出的，基于考虑参数的一一变换： $\phi = h(\theta)$ 。

Jeffreys 的一般原则是：任何确定先验密度 $p(\theta)$ 的规则，如果应用于变换后的参数，应该产生等价的结果。

考虑在 θ 上使用均匀先验 $p(\theta) = 1$ ，但在 logit 变换 $\phi = \log(\theta/(1-\theta))$ 下，这会导致不均匀的先验。这说明均匀先验在参数变换下不是不变的。

Jeffreys 提出可接受的非信息先验发现原则应该在参数的单调变换下是不变的。他描述了如何基于 Fisher 信息函数构建这样的先验：⁷

⁶推导见附录 section 2.7

⁷推导见附录 section 2.6

$$p(\theta) \propto [J(\theta)]^{1/2}$$

其中 $J(\theta)$ 是 θ 的 Fisher 信息：

$$J(\theta) = -E \left[\frac{d^2 \log p(y|\theta)}{d\theta^2} \right]$$

对于二项模型，Jeffreys 先验是 $p(\theta) \propto \theta^{-1/2}(1-\theta)^{-1/2}$ ，即 $\text{Beta}(1/2, 1/2)$ 。

注意：均匀先验在参数变换下不是不变的—— θ 上的均匀先验在 $\log(\theta/(1-\theta))$ 上不是均匀的。这曾是 20 世纪初对贝叶斯推断的主要批评之一，直到 Jeffreys 在世纪中叶复兴了这一主题。

8. 弱信息先验分布

弱信息先验是比非信息先验更强的正则化，但仍然比完全信息先验弱得多。它们用于在数据有限时稳定计算，同时允许数据主导推断。

9. 其他标准单参数模型

见教材。

10. 本章小结

本章我们学习了：

- (1) 二项模型的贝叶斯推断：Beta-Binomial 共轭
- (2) 后验作为数据与先验信息的折中（方差分解公式）
- (3) 后验推断的汇总：点估计（均值、中位数、众数）和区间估计
- (4) 最高后验密度区间（HPD）
- (5) 信息先验与共轭先验
- (6) 正态均值估计（已知方差）：精度加法公式
- (7) 非信息先验与 Jeffreys 先验
- (8) 弱信息先验
- (9) 正常与非正常先验

11. 下节预告

下一章我们将学习多参数模型，包括如何处理 nuisance 参数和正态模型中均值与方差同时未知的情况。

多参数模型简介

1. 对 Nuisance 参数的积分

为了表达联合后验分布和边际后验分布的思想，假设 θ 有两部分，每部分都可以是向量： $\theta = (\theta_1, \theta_2)$ 。进一步假设我们只（至少目前只）对 θ_1 的推断感兴趣，因此 θ_2 可以被视为 nuisance 参数。

例如，在简单例子 $y|\mu, \sigma^2 \sim \text{Normal}(\mu, \sigma^2)$ 中， $\mu = \theta_1$ 和 $\sigma^2 = \theta_2$ 都未知，但通常我们最关心的是 μ 。

我们寻求给定观测数据的参数条件分布，即 $p(\theta_1|y)$ 。这从联合后验密度

$$p(\theta_1, \theta_2|y) \propto p(y|\theta_1, \theta_2) \times p(\theta_1, \theta_2)$$

通过对 θ_2 积分得到：

$$p(\theta_1|y) = \int p(\theta_1, \theta_2|y) d\theta_2$$

另一种分解方式是：

$$p(\theta_1|y) = \int p(\theta_1|\theta_2, y) \times p(\theta_2|y) d\theta_2$$

它表明：感兴趣的后验分布是条件后验分布的混合，其中 $p(\theta_2|y)$ 是对 θ_2 不同值的加权函数。权重依赖于 θ_2 的后验密度，因此依赖于数据和先验模型的组合。

对 nuisance 参数 θ_2 的积分可以一般性地解释。例如， θ_2 可以包括代表不同可能子模型的离散成分。

注 3.1. 我们很少直接计算这个积分，但它暗示了构建和计算多参数模型的重要策略：**后验分布可以通过边际和条件模拟来计算**——首先从边际后验分布抽取 θ_2 ，然后在给定 θ_2 值的条件下从条件后验分布抽取 θ_1 。通过这种方式，积分被间接执行。

这种分析形式的典型例子是正态模型中均值和方差都未知的情况。

2. 正态数据与非信息先验

作为从样本估计总体均值的原型例子，我们考虑来自一元正态分布 $\text{Normal}(\mu, \sigma^2)$ 的 n 个独立观测 $y = (y_1, \dots, y_n)$ 。

我们首先在非信息先验分布下分析这个模型。

2.1. 非信息先验分布. 对于 μ 和 σ^2 ，一个合理的模糊先验密度，假设位置参数和尺度参数的先验独立，是在 $(\mu, \log \sigma^2)$ 上均匀，即：

$$p(\mu, \sigma^2) \propto (\sigma^2)^{-1}$$

2.2. 联合后验分布. 在这种约定的非正常先验密度下, 联合后验分布为:

$$p(\mu, \sigma^2 | y) \propto (\sigma^2)^{-(n/2+1)} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \right)$$

利用 $\sum_{i=1}^n (y_i - \mu)^2 = \sum_{i=1}^n (y_i - \bar{y})^2 + n(\bar{y} - \mu)^2$, 可以写成:

$$= (\sigma^2)^{-(n/2+1)} \exp \left(-\frac{1}{2\sigma^2} [(n-1)s^2 + n(\bar{y} - \mu)^2] \right)$$

其中 $\bar{y}$ 是样本均值, $s^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$ 是样本方差。

充分统计量是 $\bar{y}$ 和 s^2 。

2.3. 条件后验分布. 为了分解联合后验密度, 我们首先考虑条件后验密度 $p(\mu | \sigma^2, y)$, 然后考虑边际后验密度 $p(\sigma^2 | y)$ 。

对于给定 σ^2 的 μ 的后验分布, 直接使用第二章中已知方差正态均值的均匀先验结果:

$$\mu | \sigma^2, y \sim N(\bar{y}, \sigma^2/n)$$

2.4. 边际后验分布. 为了确定 $p(\sigma^2 | y)$, 我们必须对 μ 积分:

$$p(\sigma^2 | y) \propto \int (\sigma^2)^{-(n/2+1)} \exp \left(-\frac{1}{2\sigma^2} [(n-1)s^2 + n(\bar{y} - \mu)^2] \right) d\mu$$

对 μ 积分需要计算简单的正态积分, 结果是:

$$p(\sigma^2 | y) \propto (\sigma^2)^{-(n/2+1)} \exp \left(-\frac{(n-1)s^2}{2\sigma^2} \right) \times \sqrt{2\pi\sigma^2/n}$$

简化后:

$$p(\sigma^2 | y) \propto (\sigma^2)^{-[(n-1)/2+1]} \exp \left(-\frac{(n-1)s^2}{2\sigma^2} \right)$$

这是尺度逆卡方分布 (scale inverse-chi-squared distribution):

定义 3.1 (尺度逆卡方分布).

$$p(x | \nu, \sigma^2) = \frac{(\nu\sigma^2/2)^{\nu/2}}{\Gamma(\nu/2)} x^{-(\nu/2+1)} \exp \left(-\frac{\nu\sigma^2}{2x} \right)$$

其中 ν 是自由度, σ^2 是尺度参数。

因此:

$$\sigma^2 | y \sim \text{Inv-}\chi^2(n-1, s^2)$$

由 $\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$, 这与频率统计中的经典结果有显著相似性。

2.5. 从联合后验分布抽样. 从联合后验分布抽取样本很容易:

- (1) 从边际后验分布抽取 σ^2 , 即 $\sigma^2 \sim \text{Inv-}\chi^2(n-1, s^2)$
- (2) 从条件后验分布抽取 μ , 即 $\mu | \sigma^2, y \sim N(\bar{y}, \sigma^2/n)$

2.6. 边际后验分布： t 分布. 总体均值 μ 通常是感兴趣的估计量，边际后验分布可以通过对 σ^2 积分得到。结果是：

$$\mu|y \sim t_{n-1}(\bar{y}, s^2/n)$$

即自由度为 $n-1$ 的学生 t 分布。

这与频率统计中的经典结果也有显著相似性：在采样分布下， $\frac{\bar{y}-\mu}{s/\sqrt{n}} \sim t_{n-1}$ 。

一个值得注意的事实是：这个边际后验分布不依赖于数据——它是数据的函数，但关于 μ 的概率陈述只通过 $\bar{y}$ 和 s^2 依赖于数据。

2.7. 后验预测分布. 未来观测 $\tilde{y}$ 的后验预测分布可以写成混合：

$$p(\tilde{y}|y) = \iint p(\tilde{y}|\mu, \sigma^2) \times p(\mu, \sigma^2|y) d\mu d\sigma^2$$

结果是 t 分布： $\tilde{y} \sim t_{n-1}(\bar{y}, (1 + 1/n)s^2)$ 。

3. 正态数据与共轭先验

当使用共轭先验时，分析更加系统化。正态模型的共轭先验族具有形式：

$$\mu|\sigma^2 \sim N(\mu_0, \sigma^2/\kappa_0), \quad \sigma^2 \sim \text{Inv-}\chi^2(\nu_0, \sigma_0^2)$$

这对应于联合先验密度 $N\text{-Inv-}\chi^2(\mu_0, \sigma_0^2/\kappa_0; \nu_0, \sigma_0^2)$ 。

四个超参数分别是 μ 的位置和尺度、 σ^2 的自由度和尺度。

注意 σ^2 出现在 $\mu|\sigma^2$ 的条件分布中，意味着在联合共轭先验密度中 μ 和 σ^2 必然相关。这通常是有意义的——让 μ 的先验方差与 σ^2 （观测 y 的采样方差）挂钩是合理的。

3.1. 联合后验分布. 乘以正态似然得到后验密度仍然是 $N\text{-Inv-}\chi^2$ 形式，参数更新为：

$$\mu_n = \frac{\kappa_0}{\kappa_0 + n} \mu_0 + \frac{n}{\kappa_0 + n} \bar{y}, \quad \kappa_n = \kappa_0 + n, \quad \nu_n = \nu_0 + n$$

$$\nu_n \sigma_n^2 = \nu_0 \sigma_0^2 + (n-1)s^2 + \frac{\kappa_0 n}{\kappa_n} (\bar{y} - \mu_0)^2$$

条件后验分布： $\mu|\sigma^2, y \sim N(\mu_n, \sigma^2/\kappa_n)$

边际后验分布： $\sigma^2|y \sim \text{Inv-}\chi^2(\nu_n, \sigma_n^2)$

μ 的边际后验分布： $\mu|y \sim t_{\nu_n}(\mu_n, \sigma_n^2/\kappa_n)$

4. 分类数据的多项模型

多项模型用于描述每个观测是 k 个可能结果之一的数据。如果 y 是每个结果观测次数的计数向量，则：

$$p(y|\theta) \propto \prod_{j=1}^k \theta_j^{y_j}, \quad \sum_{j=1}^k \theta_j = 1$$

共轭先验分布是 Dirichlet 分布的多元推广：

$$p(\theta|\alpha) \propto \prod_{j=1}^k \theta_j^{\alpha_j-1}$$

结果是 θ_j 's 的后验分布是 Dirichlet 分布，参数为 $\alpha_j + y_j$ 。

设置 $\alpha_j = 1$ 给出均匀密度；设置 $\alpha_j = 0$ 给出在 $\log(\theta_j)$ 上均匀的不正常先验。

5. 已知方差的多元正态模型

多元正态模型 $N(\mu, \Sigma)$ 的似然函数为：

$$p(y|\mu, \Sigma) \propto |\Sigma|^{-1/2} \exp \left\{ -\frac{1}{2}(y - \mu)^T \Sigma^{-1}(y - \mu) \right\}$$

给定 Σ 时， μ 的共轭先验是多元正态分布 $\mu \sim N(\mu_0, \Lambda_0)$ 。

后验分布：

$$\mu_n = (\Lambda_0^{-1} + n\Sigma^{-1})^{-1}(\Lambda_0^{-1}\mu_0 + n\Sigma^{-1}\bar{y}), \quad \Lambda_n^{-1} = \Lambda_0^{-1} + n\Sigma^{-1}$$

后验均值是数据和先验均值的加权平均，权重由精度矩阵给出；后验精度是先验精度和数据精度之和。

6. 均值和方差都未知的多元正态模型

(μ, Σ) 的共轭先验分布是 normal-inverse-Wishart 分布：

$$\Sigma \sim \text{Inv-Wishart}_{\nu_0}(\Lambda_0^{-1}), \quad \mu|\Sigma \sim N(\mu_0, \Sigma/\kappa_0)$$

后验分布具有相同形式，参数更新为：

$$\mu_n = \frac{\kappa_0}{\kappa_0 + n}\mu_0 + \frac{n}{\kappa_0 + n}\bar{y}, \quad \kappa_n = \kappa_0 + n, \quad \nu_n = \nu_0 + n$$

$$\Lambda_n = \Lambda_0 + S + \frac{\kappa_0 n}{\kappa_0 + n}(\bar{y} - \mu_0)(\bar{y} - \mu_0)^T$$

其中 $S = \sum_{i=1}^n (y_i - \bar{y})(y_i - \bar{y})^T$ 。

μ 的边际后验分布是多元 t 分布。

7. 基本建模与计算总结

多参数模型不允许轻易计算后验分布这一问题并非主要实际障碍，原因有三：

- (1) 当参数较少时，非共轭多参数模型的后验推断可以通过简单模拟方法获得。
- (2) 复杂模型通常可以表示为层次化或条件化形式，为此有有效的计算策略。
- (3) 我们经常可以应用后验分布的正态近似，因此正态模型的共轭结构在实践中可以发挥重要作用，远远超出其对显式正态采样模型的应用。

贝叶斯建模与计算的基本步骤总结：

- (1) 写出模型的似然部分 $p(y|\theta)$ ，忽略任何不含 θ 的因子。
- (2) 写出后验密度 $p(\theta|y) \propto p(\theta) \times p(y|\theta)$
 - 如果先验信息表述良好，将其包含在 $p(\theta)$ 中。
 - 否则使用弱信息先验或暂时设 $p(\theta) \propto \text{常数}$ 。
- (3) 创建参数的粗略估计 $\hat{\theta}$ ，用作起点和下一步计算的比较。
- (4) 从后验分布抽取模拟 $\theta^1, \dots, \theta^S$ 。使用样本模拟计算 θ 任何感兴趣函数的后验密度。
- (5) 如果有预测量 $\tilde{y}$ ，通过对每个 $\tilde{y}^s$ 从给定 θ^s 的采样分布 $p(\tilde{y}|\theta^s)$ 抽取来模拟 $\tilde{y}^1, \dots, \tilde{y}^S$ 。

对于非共轭模型，步骤 4 可能很困难。各种方法已被开发用于从复杂模型中抽取后验模拟。

8. 本章小结

本章我们学习了：

- (1) 如何对 nuisance 参数进行积分（边际化和条件化）
- (2) 多参数模型的计算策略：边际和条件模拟
- (3) 正态模型中均值和方差同时未知时的分析
- (4) 尺度逆卡方分布与 t 分布
- (5) 非信息先验和共轭先验在多参数情况下的应用
- (6) 多项模型与 Dirichlet 先验
- (7) 多元正态模型与 Inverse-Wishart 先验

9. 下节预告

下一章我们将学习渐近性以及贝叶斯方法与其他统计方法的联系。

渐近性与非贝叶斯方法的联系

1. 本章导论

我们在前三章看到，许多基于非信息先验分布的简单贝叶斯分析给出的结果与标准非贝叶斯方法（例如，均值未知时正态均值的后验 t 区间）相似。

非信息先验分布能在多大程度上被合理地视为客观假设，取决于数据中包含的信息量：在第二、三章讨论的简单情况中，随着样本量 n 的增加，先验分布对后验推断的影响会减小。

这些想法被称为**渐近理论**——因为它们指的是在 n 趋向无穷大时成立的理论——我们将在本章中进行回顾，同时还将更详细地讨论贝叶斯方法与非贝叶斯方法之间的联系。

大样本结果实际上对于执行贝叶斯数据分析并非必需，但通常作为近似工具和理解工具很有用。

2. 后验分布的正态近似

2.1. 联合后验分布的正态近似. 如果后验分布 $p(\theta|y)$ 是单峰的且大致对称，则可以用正态分布近似它；也就是说，后验密度的对数被近似为 θ 的二次函数。

我们考虑在的后验众数 $\hat{\theta}$ 处展开的后验密度对数的二次近似（其中 θ 可以是向量，且 $\hat{\theta}$ 假定在参数空间内部）；在第十三章中我们将讨论更复杂的近似方法，这些方法在简单基于众数的近似失效的情况下可能有效。

对在 $\hat{\theta}$ 处中心化的后验密度对数 $\log p(\theta|y)$ 进行泰勒级数展开给出

$$(4.1) \quad \log p(\theta|y) = \log p(\hat{\theta}|y) + \frac{1}{2}(\theta - \hat{\theta})^T \left[\frac{d^2}{d\theta^2} \log p(\theta|y) \right]_{\theta=\hat{\theta}} (\theta - \hat{\theta}) + \dots$$

其中展开式的线性项为零，因为对数后验密度在其众数处导数为零。

当 θ 接近 $\hat{\theta}$ 且 n 较大时，高阶余项的相对重要性会减小。考虑 (4.1) 作为 θ 的函数，第一项是常数，而第二项与正态密度对数成正比，得到近似

$$(4.2) \quad p(\theta|y) \approx N(\hat{\theta}, [I(\hat{\theta})]^{-1}),$$

其中 $I(\theta)$ 是观测信息 (observed information),

$$I(\theta) = -\frac{d^2}{d\theta^2} \log p(\theta|y).$$

如果众数 $\hat{\theta}$ 在参数空间的内部，则矩阵 $I(\hat{\theta})$ 是正定的。

例 4.1 (均值和方差均未知的正态分布). 我们用简单的理论例子说明近似正态分布。设 $y_1, \dots, y_n$ 是来自 $N(\mu, \sigma^2)$ 分布的独立观测，为简单起见，假设 $(\mu, \log \sigma)$ 上的均匀先验密度。

我们对 $(\mu, \log \sigma)$ 的后验分布建立正态近似，这在限制 σ 为正值方面有优点。为了构建近似，我们需要对数后验密度的二阶导数。

在众数处，二阶导数矩阵为 $\begin{pmatrix} -n/\hat{\sigma}^2 & 0 \\ 0 & -2n \end{pmatrix}$ 。从 (4.2)，后验分布可以近似为

$$p(\mu, \log \sigma | y) \approx N \left(\begin{pmatrix} \mu \\ \log \sigma \end{pmatrix} \middle| \begin{pmatrix} \bar{y} \\ \log \hat{\sigma} \end{pmatrix}, \begin{pmatrix} \hat{\sigma}^2/n & 0 \\ 0 & 1/(2n) \end{pmatrix} \right).$$

2.2. 后验密度函数相对于其最大值的解释. 除了作为近似直接使用外，多元正态分布还为解释后验密度函数和等高线图提供了基准。在 d 维正态分布中，密度函数的对数是一个常数加上 -2 除以的 χ_d^2 分布。例如， χ_{10}^2 密度的第 95 百分位是 18.31，因此如果一个问题有 $d = 10$ 个参数，则大约 95% 的后验概率质量与 $p(\theta|y)$ 不小于在众数处密度的 $\exp(-18.31/2) = 1.1 \times 10^{-4}$ 倍的 θ 值相关联。

2.3. 用点估计和标准误总结后验分布. 渐近理论表明，如果 n 足够大，后验分布可以用正态分布近似。在许多应用领域中，标准的推断总结是计算点估计 $\hat{\theta}$ （如最大似然估计，即均匀先验下的后验众数），加上或减去两个标准误，标准误从估计处的信息 $I(\hat{\theta})$ 估计。

在许多情况下，通过变换可以显著改善 θ 的后验分布向正态分布的收敛性。如果 ϕ 是 θ 的连续变换，那么 $p(\phi|y)$ 和 $p(\theta|y)$ 都趋向正态分布，但对于有限的 n ，近似的紧密程度可能随所选变换而大幅变化。

2.4. 数据约简与充分统计量. 在正态近似下，后验分布由其众数 $\hat{\theta}$ 和后验密度的曲率 $I(\hat{\theta})$ 总结；即渐近地，这些是充分统计量。

使用充分统计量的这种方法允许相对容易地将分层建模技术应用于改进每个单独估计。例如，在第 5.5 节中，一组八个实验中的每一个都通过从早期回归分析估计的点估计和标准误来总结。

当后验分布接近正态时，使用汇总统计量的方法最为合理；否则这种方法可能会丢弃重要信息并导致错误的推断。

2.5. 低维正态近似. 对于有限的样本量 n ，正态近似通常对 θ 的分量条件分布和边际分布比对完整联合分布更准确。

例如，如果联合分布是多元正态分布，则其所有边际分布都是正态的，但反之不成立。确定 θ 一个分量的边际分布等同于对 θ 的所有其他分量进行平均，而平均一族分布通常会使它们更接近正态分布——这与中心极限定理背后的逻辑相同。

注 4.1. 对于低维 θ ，后验分布的正态近似通常是完全可以接受的，特别是在适当的变换之后。

例 4.2 (生物 assay 实验 (续)). 我们用 3.7 节中生物 assay 实验的模型和数据来说明正态近似。实验中样本量相对较小，只有 20 只动物，我们发现正态近似接近精确后验分布，但存在重要差异。

(α, β) 联合后验分布的正态近似：?? 显示了二元正态近似的等高线图和从这个近似分布中抽取的 1000 个样本的散点图。

正态近似的均值 $(\alpha, \beta) = (0.8, 7.7)$ 与实际后验分布的均值 $(\alpha, \beta) = (1.4, 11.9)$ 不同。

3. 大样本理论

3.1. 符号与数学设置. 大样本贝叶斯推断的基本工具是后验分布的渐近正态性：随着来自相同底层过程的越来越多数据到达，参数向量的后验分布趋向多元正态分布，即使数据的真实分布不在所考虑的参数族中。

从数学上讲，这些结果最直接地适用于从公共分布 $f(y)$ 中独立抽取的观测 $y_1, \dots, y_n$ 。在许多情况下，为数据假设一个“真实”底层分布 $f(y)$ 的概念很难解释，但为了发展渐近理论，这是必要的。

假设数据由参数族 $p(y|\theta)$ 建模，并具有先验分布 $p(\theta)$ 。如果真实数据分布包含在参数族中——即如果 $f(y) = p(y|\theta_0)$ 对于某个 θ_0 ——那么除了渐近正态性外，一致性性质也成立：随着 $n \rightarrow \infty$ ，后验分布收敛到在真实参数值 θ_0 处的点质量。

3.2. 渐近正态性与一致性. 附录 B 中给出的基本数学结果表明，在一些正则性条件下（特别是似然函数是 θ 的连续函数且 θ_0 不在参数空间边界上），随着 $n \rightarrow \infty$ ， θ 的后验分布趋向正态分布，均值为 θ_0 ，方差为 $(nJ(\theta_0))^{-1}$ 。

在最简单的层面，这个结果可以从在后验众数处对数后验密度的泰勒级数展开 (4.1) 来理解。初步结果表明，后验众数对 θ_0 是一致的，因此随着 $n \rightarrow \infty$ ，后验分布 $p(\theta|y)$ 的质量集中在 θ_0 越来越小的邻域内，距离 $|\hat{\theta} - \theta_0|$ 趋向零。

3.3. 似然支配先验分布. 渐近结果形式化了先验分布的重要性随着样本量增加而减小的概念。这导致一个结论：在具有大样本量的问题中，我们不必特别努力地制定一个准确反映所有可用信息的先验分布。当样本量较小时，先验分布是模型规范的关键部分。

4. 定理的反例

理解大样本结果局限性的好方法是考虑定理失效的情况。正态分布通常作为起点近似有帮助，但必须检查偏差，特别是对于不寻常的参数空间和分布极值情况。

4.1. 未识别模型与未识别参数. 如果给定数据 y ，似然 $p(\theta|y)$ 在一系列 θ 值上相等，则模型是未识别的 (underidentified)。在这样的模型下，没有单一点 θ_0 可以使后验分布收敛到它。

例 4.3 (相关系数的未识别性). 考虑模型，其中 $(u, v)^T \sim N((0, 0)^T, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix})$ ，但只从每对 (u, v) 中观测到其中一个。这里参数 ρ 是未识别的。数据不提供关于 ρ 的任何信息，因此 ρ 的后验分布与其先验分布相同，无论数据集有多大。

未识别或欠识别参数问题的唯一解决方案是认识到问题存在，如果有更精确估计这些参数的愿望，则收集可以 enable 估计这些参数的进一步信息 (either from future data collection or from external information that can inform a prior distribution)。

4.2. 参数数量随样本量增加. 在复杂问题中，参数数量可能很大，我们需要区分不同类型的渐近性。如果随着 n 增加，模型也发生变化使得参数数量同时增加，那么第 4.1 和 4.2 节中概述的简单结果（假设固定模型类 $p(y_i|\theta)$ ）并不适用。

例如，有时为研究中的每个采样单位分配一个参数；例如 $y_i \sim N(\theta_i, \sigma^2)$ 。一般来说，除非每个采样单位收集的数据量也随着单位数量的增加而增加，否则参数 θ_i 不能被一致地估计。

4.3. 混叠. 混叠是欠识别参数的一种特殊情况，其中相同的似然函数在一组离散点上重复。例如，考虑具有独立同分布数据 $y_1, \dots, y_n$ 的正态混合模型。

如果交换 (μ_1, μ_2) 和 (σ_1^2, σ_2^2) ，并将 λ 替换为 $(1 - \lambda)$ ，数据的似然保持不变。

后验分布至少有两个众数，由两个分布的 (50%, 50%) 混合组成——它们是彼此的镜像；无论数据集有多大，它都不会收敛到单个点。

通常，通过限制参数空间使没有重复来解决混叠问题。

4.4. 无界似然. 如果似然函数是无界的, 则后验众数可能不存在于参数空间中, 从而使一致性和正态近似的结果无效。

例如, 对于正态混合模型, 如果我们设 $\mu_1 = y_i$ 对于任意 y_i , 并让 $\sigma_1^2 \rightarrow 0$, 则似然趋向无穷大。随着 $n \rightarrow \infty$, 似然的众数数量增加。

4.5. 不当后验分布. 如果通过将似然乘以表示不当先验分布的“形式”先验密度获得的无规范化后验密度积分到无穷大, 则渐近结果不成立。

当不当先验分布与似然组合具有有限积分时, 不当先验分布只是一种方便的近似。

4.6. 排除收敛点的先验分布. 如果对于离散参数空间 $p(\theta_0) = 0$, 或者对于连续参数空间在 θ_0 的邻域内 $p(\theta) = 0$, 则一致性结果不成立。

解决方案是在先验分布中给所有甚至略微合理的 θ 值赋予正概率密度。

4.7. 收敛到参数空间边界. 如果 θ_0 在参数空间的边界上, 则泰勒级数展开必须在某些方向上截断, 正态分布不一定合适, 即使在极限情况下也是如此。

例如, 考虑模型 $y_i \sim N(\theta, 1)$, 限制 $\theta \geq 0$ 。假设模型是准确的, $\theta = 0$ 是真实值。 θ 的后验分布是正态的, 以 $\bar{y}$ 为中心, 截断为正值。

5. 贝叶斯推断的频率评估

就像贝叶斯范式可以被视为证明简单“经典”技术的合理性一样, 频率统计方法提供了一种有用的方法来评估贝叶斯推断的性质——它们的操作特征——当这些被视为嵌入一系列重复样本中时。

5.1. 大样本对应. 假设 θ 后验分布的正态近似 (4.2) 成立; 那么我们可以转换为标准多元正态:

$$(4.3) \quad [I(\hat{\theta})]^{1/2}(\theta - \hat{\theta})|y \sim N(0, I),$$

其中 $\hat{\theta}$ 是后验众数。如果真实数据分布包含在模型类中, 则在重复采样中, 渐近地, $100(1 - \alpha)\%$ 的中心后验区间将在 $100(1 - \alpha)\%$ 的情况下覆盖真值 θ_0 。

5.2. 点估计、一致性与有效性. 从贝叶斯框架来看, 获得 θ 的“估计”在大样本中最有意义, 此时后验众数 $\hat{\theta}$ 是 θ 后验分布的明显中心。

一个点估计如果随着样本变大而收敛到它所估计的参数真值, 则被称为在采样理论意义上是一致的。

如果对于任何 θ_0 值, 在重复样本中 $C(y)$ 至少以 $100(1 - \alpha)\%$ 的概率包含 θ_0 , 则 $C(y)$ 被称为 θ 的 $100(1 - \alpha)\%$ 置信域。

6. 其他统计方法的贝叶斯解释

我们考虑贝叶斯统计方法与其他方法比较的三个层次:

- (1) 首先, 正如我们已经指出的, 在涉及来自固定概率模型的大样本的问题中, 贝叶斯方法通常类似于其他统计方法。
- (2) 其次, 即使对于小样本, 许多统计方法也可以被视为基于特定先验分布的贝叶斯推断的近似; 作为一种理解统计程序的方式, 确定隐含的底层先验分布通常很有用。
- (3) 第三, 经典统计的一些方法 (特别是假设检验) 可能给出与贝叶斯方法非常不同的结果。

6.1. 最大似然与点估计. 从贝叶斯数据分析的角度来看, 我们通常可以将经典点估计解释为基于某些隐含完整概率模型的精确或近似后验总结。在大样本量的极限下, 事实上我们可以使用渐近理论为经典最大似然推断构建理论贝叶斯论证。

渐近地, 最大似然估计 $\hat{\theta}$ 是一个充分统计量——后验众数、均值或中位数也是充分统计量。

对于大的 n , 先验分布的渐近无关性可以用来为使用方便的非信息先验模型提供理由。

6.2. 无偏估计. 一些非贝叶斯统计方法非常强调无偏性作为估计的可取原则。形式上, 如果 $\mathbb{E}(\hat{\theta}(y)|\theta) = \theta$ 对于任何 θ 值, 则估计 $\hat{\theta}(y)$ 被称为无偏的。

从贝叶斯角度来看, 无偏性原则在大样本极限中是合理的, 但在其他情况下可能具有误导性。主要困难出现在有许多参数要估计的情况下。

注 4.2. 无偏性原则的一个问题是, 通常不可能以甚至近似无偏的方式一次估计几个参数。

例 4.4 (使用回归进行预测). 考虑在已知母亲身高 y 的情况下估计成年女儿身高 θ 的问题。为简单起见, 假设母亲和女儿的身高联合正态分布, 均值相等为 160 厘米, 方差相等, 相关系数为 0.5。

在已知 y 的条件下, θ 的后验均值为

$$(4.5) \quad \mathbb{E}(\theta|y) = 160 + 0.5(y - 160).$$

然而, 后验均值在重复采样中并不是 θ 的无偏估计。

这个例子说明的重要原则是**回归均值**的原则: 对于任何给定的母亲, 她女儿身高的期望值介于她母亲身高和总体均值之间。

7. 本章小结

本章我们学习了:

- (1) 后验分布的正态近似 (基于泰勒级数展开)
- (2) 观测信息矩阵与 Fisher 信息的概念
- (3) 大样本理论: 渐近正态性与一致性
- (4) 似然支配先验的原则
- (5) 渐近定理的反例: 未识别参数、参数数量随样本增加、混叠、无界似力、不当后验等
- (6) 频率评估与贝叶斯推断的联系
- (7) 其他统计方法的贝叶斯解释: 无偏估计、置信区间、回归预测等

8. 下节预告

下一章我们将学习分层模型 (Hierarchical Models), 这是贝叶斯统计中非常重要的一类模型, 用于处理具有分组结构的复杂数据。

分层模型

1. 本章导论

许多统计应用涉及可以认为是通过问题结构以某种方式相关或连接的多个参数，这意味着这些参数的联合概率模型应该反映它们的依赖性。

例如，在一项关于心脏治疗有效性的研究中，医院 j 中患者存活的概率为 θ_j ，我们有来自多家医院的样本，估计 θ_j 的值应该是相互关联的。

如果我们在先验分布中将 θ_j 视为从公共总体分布中抽取的样本，那么就能以一种自然的方式实现这一点。

这类应用的一个关键特征是，观测数据 y_{ij} （单位 i 在组 j 内）可以用来估计 θ_j 总体分布的特征，即使 θ_j 的值本身没有被观测到。

用层次化的方式建模这个问题是很自然的：可观测量在对某些参数的条件建模，这些参数本身用进一步参数（称为超参数）的概率规范来指定。

这种层次化思维有助于理解多参数问题，并且在开发计算策略方面也发挥重要作用。

2. 构参数化先验分布

2.1. 在历史数据背景下分析单个实验. 我们从分层模型的描述开始，考虑使用来自小规模实验的数据和从类似的历史实验中构建的先验分布来估计参数 θ 的问题。从数学上讲，我们将认为当前和历史实验是从一个公共总体中随机抽取的样本。

例 5.1 (估计一组大鼠的肿瘤风险). 在药物评估中，例行对啮齿动物进行研究。对于从统计文献中提取的特定研究，假设直接目标是估计 θ ——即接受零剂量药物（对照组）的雌性 F344 实验室大鼠群体中发生子宫内膜基质息肉（一种肿瘤）的概率。

数据显示，14 只大鼠中有 4 只发生了子宫内膜基质息肉。给定 θ ，假设肿瘤数量的二项模型是很自然的。为方便起见，我们从共轭族中选择 θ 的先验分布， $\theta \sim \text{Beta}(\alpha, \beta)$ 。

后验分布为 $\theta|y \sim \text{Beta}(\alpha + y, \beta + n - y)$ ，其中 $y = 4$ ， $n = 14$ 。

3. 可交换性与分层模型设置

3.1. 可交换性. 当我们对参数一无所知时，通常假设它们是**可交换的 (exchangeable)**。形式上，如果参数的联合分布在我们重新标记这些参数时保持不变，则这些参数 $\theta_1, \dots, \theta_J$ 是可交换的。

可交换性意味着我们没有理由认为任何特定参数比其他参数更大或更小。

在层次模型中，我们通常假设参数 θ_j 是从某个分布 $p(\theta|\phi)$ 中独立同分布抽取的，其中 ϕ 是总体参数（超参数）。

3.2. 两层层次模型. 一般的两层层次模型可以写为：

- (1) **数据层:** $y_{ij}|\theta_j \sim p(y_{ij}|\theta_j)$ (独立)
- (2) **参数层:** $\theta_j|\phi \sim p(\theta_j|\phi)$ (独立，来自共同先验)
- (3) **超参数层:** $\phi \sim p(\phi)$ (先验)

联合后验分布为：

$$p(\theta, \phi|y) \propto p(\phi) \prod_{j=1}^J p(\theta_j|\phi) \prod_{i=1}^{n_j} p(y_{ij}|\theta_j)$$

3.3. 先验分布的参数化. 设 θ_j 的先验分布是参数为 ϕ 的某分布族。关键是选择 ϕ 使其具有直观意义，并且我们可以指定一个适当的先验 $p(\phi)$ 。

例 5.2 (比率参数). 如果 θ_j 是比率(如成功率), 一种常见的选择是使用 $\theta_j|\mu, \sigma \sim N(\mu, \sigma^2)$ 在 logit 变换后, 即 $\text{logit}(\theta_j) \sim N(\mu, \sigma^2)$ 。

超参数 μ 代表总体 logit 比率的均值, σ 衡量组间的变异程度。

4. 共轭层次模型的完全贝叶斯分析

当每层的分布都是共轭的时, 层次模型可以进行完全贝叶斯分析。在这些情况下, 我们可以解析地边缘化超参数, 或使用简单的计算方法。

4.1. Beta-Binomial 层次模型. 假设我们有 J 个独立实验, 每个实验有 n_j 次试验和 y_j 次成功。模型为:

- (1) $y_j|\theta_j \sim \text{Bin}(n_j, \theta_j)$
- (2) $\theta_j|\alpha, \beta \sim \text{Beta}(\alpha, \beta)$
- (3) (α, β) 的先验: 需要指定

如果我们对 (α, β) 指定适当的先验, 可以进行完全贝叶斯分析。

4.2. 从先验到后验. 关键是理解层次模型如何允许数据”通知”超参数。在完全贝叶斯分析中, 我们对 (α, β) 进行积分或抽样:

$$p(\theta_j|y) = \iint p(\theta_j|\alpha, \beta)p(\alpha, \beta|y) d\alpha d\beta$$

这个积分通常需要数值方法或马尔科夫链蒙特卡洛 (MCMC) 来计算。

5. 从正态模型估计可交换参数

一个特别重要的特殊情况是, 当数据 y_j 是来自正态分布的样本均值, 并且参数 θ_j 在变换后是正态分布时。

5.1. 正态层次模型. 假设:

- (1) $y_j|\theta_j, \sigma_j^2 \sim N(\theta_j, \sigma_j^2)$, 其中 σ_j^2 已知
- (2) $\theta_j|\mu, \tau^2 \sim N(\mu, \tau^2)$
- (3) (μ, τ^2) 有适当的先验

超参数 μ 是总体均值, τ^2 是组间方差。

5.2. 后验分布. 给定数据 y_j , θ_j 的后验分布可以分解为:

$$p(\theta_j|y, \mu, \tau^2) \propto p(\theta_j|\mu, \tau^2) \prod_{j=1}^J p(y_j|\theta_j)$$

结果是:

$$\theta_j|y, \mu, \tau^2 \sim N\left(\frac{\frac{\mu}{\tau^2} + \frac{y_j}{\sigma_j^2}}{\frac{1}{\tau^2} + \frac{1}{\sigma_j^2}}, \left(\frac{1}{\tau^2} + \frac{1}{\sigma_j^2}\right)^{-1}\right)$$

这个结果说明: 后验均值是先验均值 μ 和数据均值 y_j 的加权平均, 权重由精度 (方差的倒数) 给出。

当 τ^2 较大 (组间变异大) 时, 估计接近原始数据 y_j ; 当 τ^2 较小 (组间变异小) 时, 估计收缩到共同均值 μ 。

6. 示例: 八所学校的平行实验

这是一个经典的层次模型例子, 展示了分层建模在 meta 分析中的应用。

6.1. 问题背景. 考虑一项研究, $J = 8$ 所学校, 每所学校都报告了培训效果估计 y_j 及其标准误 σ_j 。我们希望估计每所学校的真实效果 θ_j , 同时估计总体效果。

数据形式如下:

学校 j	估计 y_j	标准误 σ_j
1	28.4	14.9
2	7.0	10.2
3	-4.4	16.3
4	7.0	11.0
5	1.9	9.4
6	6.6	10.5
7	10.8	17.6
8	33.1	15.6

6.2. 层次模型. 我们设定模型:

$$y_j|\theta_j \sim N(\theta_j, \sigma_j^2)$$

$$\theta_j|\mu, \tau \sim N(\mu, \tau^2)$$

其中 σ_j 已知, (μ, τ) 有适当的先验。

6.3. 后验推断. 后验分布 $p(\theta, \mu, \tau|y)$ 可以通过 MCMC 或近似方法获得。关键是理解:

注 5.1. 层次模型提供了在合并信息和保持学校特异性估计之间的自然权衡。参数 τ 控制了这种权衡: 当 τ 小时, 所有 θ_j 被强烈收缩到公共均值 μ ; 当 τ 大时, 每个 θ_j 主要由其自身数据决定。

7. 分层建模在 meta 分析中的应用

Meta 分析是将多项研究结果合并的统计方法。层次模型为 meta 分析提供了自然的框架。

7.1. 固定效应与随机效应. 在 meta 分析中, 我们通常考虑两种模型:

(1) **固定效应模型:** 假设所有研究估计相同的真实效应 θ , 观测差异仅由抽样误差解释。

(2) **随机效应模型:** 假设研究间的效应是可交换的, 来自某个分布 $p(\theta_j|\mu, \tau^2)$ 。

随机效应模型是层次模型的一个特例, 其中 θ_j 被视为从公共分布中抽取的样本。

8. 分层方差参数的弱信息先验

层次模型的一个关键挑战是估计方差参数 τ^2 。当数据稀疏时, 方差参数的估计可能极不稳定。

8.1. 问题. 在后验分布中, τ^2 通常信息不足, 导致后验尾部过重或甚至不当。

8.2. 弱信息先验. 一种解决方案是使用弱信息先验, 例如:

- **Half-t 先验:** 对 τ 使用 t 分布在正半轴
- **Prior on $\log(\tau)$:** 使用宽窗口的正态先验

注 5.2. 选择先验时, 应该考虑参数的尺度。例如, 如果我们有标准误 σ_j , 在 $\log(\tau)$ 上指定先验可能比在 τ 上更合理。

9. 本章小结

本章我们学习了:

- (1) 层次模型的基本思想: 通过分层结构处理相关参数
- (2) 可交换性 (Exchangeability) 的概念
- (3) 两层层次模型的构建: 数据层、参数层、超参数层
- (4) Beta-Binomial 和正态层次模型
- (5) 后验分布的收缩 (shrinkage) 性质
- (6) 八学校例子: 层次模型在 meta 分析中的应用
- (7) 固定效应 vs. 随机效应模型
- (8) 层次方差参数的弱信息先验

层次模型是贝叶斯统计中最重要的工具之一, 它允许我们:

- 在保持参数特异性估计的同时合并信息
- 自然地处理分组或聚类数据结构
- 为 meta 分析提供 principled 框架

10. 下节预告

下一章我们将学习模型检查 (Model Checking), 这是贝叶斯数据分析中验证模型合理性的关键步骤。

Part 2

贝叶斯数据分析基础

CHAPTER 6

模型检查

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 7

模型评估、比较与扩展

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 8

考虑数据收集过程的建模

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 9

决策分析

1. 本章导论
2. 主要内容
3. 本章小结

Part 3

高级计算方法

CHAPTER 10

贝叶斯计算入门

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 11

马尔可夫链模拟基础

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 12

高效马尔可夫链模拟

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 13

模态与分布近似

1. 本章导论
2. 主要内容
3. 本章小结

Part 4

回归模型

CHAPTER 14

回归模型入门

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 15

分层线性模型

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 16

广义线性模型

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 17

稳健推断模型

1. 本章导论
2. 稳健性的各个方面
3. 标准概率模型的过度分散版本
4. 后验推断与计算
5. 八校例子中的稳健推断与敏感性分析
6. 使用 t 分布误差的稳健回归
7. 本章小结

CHAPTER 18

缺失数据模型

1. 本章导论
2. 主要内容
3. 本章小结

Part 5

非参数模型

CHAPTER 19

参数非线性模型

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 20

基函数模型

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 21

高斯过程模型

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 22

有限混合模型

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 23

狄利克雷过程模型

1. 本章导论
2. 主要内容
3. 本章小结

APPENDIX A

公式推导

1. 概率与推断 (Chapter 1) 推导

1.1. 贝叶斯定理的推导. 背景 (Background): 贝叶斯定理是概率论中最基本的公式之一, 它描述了如何根据新的证据更新概率估计。这个推导基于条件概率的定义和基本运算规则。

参数定义 (Parameter Definitions):

- A : 某个事件
- B : 另一个事件 (通常代表观测数据或证据)
- $p(A)$: 事件 A 的先验概率 (prior probability)
- $p(A|B)$: 在事件 B 发生的条件下, 事件 A 的后验概率 (posterior probability)
- $p(B|A)$: 在事件 A 发生的条件下, 事件 B 的似然 (likelihood)
- $p(B)$: 事件 B 的边际概率 (marginal probability)

已知条件 (Given):

- 条件概率定义: $p(A|B) = \frac{p(A \cap B)}{p(B)}$, 其中 $p(B) > 0$
- 乘法法则: $p(A \cap B) = p(A) \cdot p(B|A) = p(B) \cdot p(A|B)$

目标 (Goal): 从条件概率的基本定义推导出贝叶斯定理:

$$p(A|B) = \frac{p(A) \cdot p(B|A)}{p(B)}$$

推导步骤 (Derivation Steps):

步骤 1: 从条件概率定义出发

$$p(A|B) = \frac{p(A \cap B)}{p(B)}$$

步骤 2: 用乘法法则替换联合概率 $p(A \cap B)$

$$p(A \cap B) = p(A) \cdot p(B|A)$$

步骤 3: 将步骤 2 代入步骤 1

$$p(A|B) = \frac{p(A) \cdot p(B|A)}{p(B)}$$

步骤 4: 对 $p(B)$ 进行边际化 (如果 $A_1, A_2, \dots, A_k$ 是互斥且完备的事件族)

$$p(B) = \sum_{i=1}^k p(A_i) \cdot p(B|A_i)$$

步骤 5: 将步骤 4 代入贝叶斯定理的分母，得到完整形式

$$p(A_j|B) = \frac{p(A_j) \cdot p(B|A_j)}{\sum_{i=1}^k p(A_i) \cdot p(B|A_i)}$$

结论: 贝叶斯定理建立了先验概率与后验概率之间的桥梁——我们通过似然 $p(B|A)$ 将新的观测 B 与先验知识 $p(A)$ 结合起来。

1.2. 先验预测分布与后验预测分布的推导. 背景 (Background): 在贝叶斯统计中, 我们不仅要推断当前参数 θ 的后验分布, 还需要预测未来观测 $\tilde{y}$ 的分布。这涉及对未知参数进行积分 (边际化)。

参数定义 (Parameter Definitions):

- θ : 不可观测的参数
- y : 已观测的数据
- $\tilde{y}$: 未来或未观测的数据
- $p(\theta)$: 参数的先验分布
- $p(y|\theta)$: 数据的似然函数
- $p(\theta|y)$: 参数的后验分布

已知条件 (Given):

- 贝叶斯定理: $p(\theta|y) \propto p(\theta) \cdot p(y|\theta)$
- 边际概率定义: $p(y) = \int p(\theta) \cdot p(y|\theta) d\theta$
- 条件独立性: 给定 θ , 未来观测 $\tilde{y}$ 与当前观测 y 条件独立

目标 (Goal):

- (1) 推导先验预测分布 $p(y)$
- (2) 推导后验预测分布 $p(\tilde{y}|y)$

推导步骤 (Derivation Steps):

先验预测分布的推导. **步骤 1:** 从边际概率的定义出发

$$p(y) = \int p(\theta) \cdot p(y|\theta) d\theta$$

步骤 2: 解释其含义——这是对所有可能的 θ 值加权平均, 其中权重是先验概率

步骤 3: 先验预测分布表示在我们观测数据之前, 所有可能观测结果的分布

后验预测分布的推导. **步骤 1:** 从条件概率定义出发

$$p(\tilde{y}|y) = \int p(\tilde{y}, \theta|y) d\theta$$

步骤 2: 将联合分布分解

$$p(\tilde{y}, \theta|y) = p(\tilde{y}|\theta, y) \cdot p(\theta|y)$$

步骤 3: 利用条件独立性假设 (给定 θ , $\tilde{y}$ 与 y 独立)

$$p(\tilde{y}|\theta, y) = p(\tilde{y}|\theta)$$

步骤 4: 代入得

$$p(\tilde{y}|y) = \int p(\tilde{y}|\theta) \cdot p(\theta|y) d\theta$$

结论: 后验预测分布是在**参数后验分布上对条件预测进行平均**。这体现了贝叶斯推断的核心思想: 不确定性在两个层次上都存在 (参数的不确定性和预测的随机性), 我们需要对两者都进行边际化。

1.3. 后验优势比的推导. 背景 (Background): 优势比 (odds ratio) 是概率的另一种表示方式, 在许多应用场景下比概率更直观。贝叶斯定理在优势比形式下有一个特别简洁的表达。

参数定义 (Parameter Definitions):

- θ_1 : 某个参数值
- θ_2 : 另一个参数值
- $p(\theta_1)$: θ_1 的先验概率
- $p(\theta_1|y)$: θ_1 的后验概率
- $p(y|\theta_1)$: 似然函数在 θ_1 处的值
- $O(\theta_1, \theta_2) = \frac{p(\theta_1)}{p(\theta_2)}$: 先验优势比
- $O(\theta_1, \theta_2|y) = \frac{p(\theta_1|y)}{p(\theta_2|y)}$: 后验优势比

已知条件 (Given): 贝叶斯定理:

$$p(\theta|y) = \frac{p(\theta) \cdot p(y|\theta)}{p(y)}$$

目标 (Goal): 证明后验优势比 = 先验优势比 $\times$ 似然比

推导步骤 (Derivation Steps):

步骤 1: 写出后验优势比的定义

$$O(\theta_1, \theta_2|y) = \frac{p(\theta_1|y)}{p(\theta_2|y)}$$

步骤 2: 对分子和分母分别应用贝叶斯定理

$$\begin{aligned} & \frac{p(\theta_1) \cdot p(y|\theta_1)}{p(y)} \\ &= \frac{\frac{p(\theta_1) \cdot p(y|\theta_1)}{p(y)}}{\frac{p(\theta_2) \cdot p(y|\theta_2)}{p(y)}} \end{aligned}$$

步骤 3: 约去 $p(y)$

$$= \frac{p(\theta_1) \cdot p(y|\theta_1)}{p(\theta_2) \cdot p(y|\theta_2)}$$

步骤 4: 重新组合

$$= \frac{p(\theta_1)}{p(\theta_2)} \times \frac{p(y|\theta_1)}{p(y|\theta_2)}$$

结论: 这个简洁的关系式告诉我们, **后验优势比 = 先验优势比 $\times$ 似然比**。数据通过似然比来更新优势比——如果 $p(y|\theta_1) > p(y|\theta_2)$, 则数据支持 θ_1 , 后验优势比增大。

2. 单参数模型 (Chapter 2) 推导

2.1. Beta-Binomial 共轭后验分布推导. 背景 (Background): 在二项模型中, 如果我们使用 Beta 先验分布来估计成功概率 θ , 则后验分布也是 Beta 分布。这种性质称为共轭性, 是贝叶斯统计中最重要的概念之一。

参数定义 (Parameter Definitions):

- n : 伯努利试验的总次数
- y : n 次试验中成功的次数
- θ : 每次试验的成功概率 (未知参数)
- α : Beta 先验的第一个参数
- β : Beta 先验的第二个参数
- $p(y|\theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y}$: 二项似然函数
- $p(\theta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}$: Beta 先验

已知条件 (Given):

- Beta 函数定义: $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
- 似然函数: $p(y|\theta) \propto \theta^y (1-\theta)^{n-y}$ (忽略不依赖 θ 的常数 $\binom{n}{y}$)
- 先验分布: $p(\theta) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1}$

目标 (Goal): 证明后验分布 $p(\theta|y)$ 也是 Beta 分布, 并确定其后验参数。

推导步骤 (Derivation Steps):

步骤 1: 应用贝叶斯定理写出非归一化后验分布

$$p(\theta|y) \propto p(\theta) \cdot p(y|\theta)$$

步骤 2: 代入先验和似然

$$p(\theta|y) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1} \cdot \theta^y (1-\theta)^{n-y}$$

步骤 3: 合并同底数指数

$$= \theta^{(\alpha-1)+y} \cdot (1-\theta)^{(\beta-1)+(n-y)} = \theta^{\alpha+y-1} \cdot (1-\theta)^{\beta+n-y-1}$$

步骤 4: 识别分布形式这正是 Beta 分布的核 (kernel), 即

$$p(\theta|y) \propto \theta^{\alpha_{\text{post}}-1} (1-\theta)^{\beta_{\text{post}}-1}$$

其中

$$\alpha_{\text{post}} = \alpha + y, \quad \beta_{\text{post}} = \beta + n - y$$

步骤 5: 写出完整的后验分布

$$\theta|y \sim \text{Beta}(\alpha + y, \beta + n - y)$$

结论: 后验分布与先验分布属于同一形式 (Beta 分布), 这就是共轭性。先验参数 α 可以解释为 $\alpha - 1$ 次“先验成功”, β 解释为 $\beta - 1$ 次“先验失败”。

2.2. Beta-Binomial 后验均值与方差推导. 背景 (Background): 在共轭框架下, 我们可以推导出后验分布的均值和方差的闭式表达式。这些表达式展示了先验信息与数据信息如何”折中”。

参数定义 (Parameter Definitions):

- $\alpha_{\text{post}} = \alpha + y$: 后验第一个参数
- $\beta_{\text{post}} = \beta + n - y$: 后验第二个参数
- $\mathbb{E}(\theta|y)$: 后验均值
- $\text{Var}(\theta|y)$: 后验方差

已知条件 (Given):

- 后验分布: $\theta|y \sim \text{Beta}(\alpha_{\text{post}}, \beta_{\text{post}})$
- Beta 分布均值公式: $\mathbb{E}(X) = \frac{\alpha}{\alpha + \beta}$, 其中 $X \sim \text{Beta}(\alpha, \beta)$
- Beta 分布方差公式: $\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$

目标 (Goal):

- (1) 求后验均值 $\mathbb{E}(\theta|y)$
- (2) 求后验方差 $\text{Var}(\theta|y)$

后验均值推导. **步骤 1:** 应用 Beta 分布均值公式

$$\mathbb{E}(\theta|y) = \frac{\alpha_{\text{post}}}{\alpha_{\text{post}} + \beta_{\text{post}}}$$

步骤 2: 代入后验参数

$$= \frac{\alpha + y}{\alpha + y + \beta + n - y} = \frac{\alpha + y}{\alpha + \beta + n}$$

步骤 3: 改写为加权平均形式

$$= \frac{\alpha + y}{\alpha + \beta + n} = \frac{\alpha + \beta}{\alpha + \beta + n} \cdot \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \cdot \frac{y}{n}$$

结论 1: 后验均值是先验均值 $\frac{\alpha}{\alpha + \beta}$ 和样本比例 $\frac{y}{n}$ 的加权平均, 权重与样本量和先验强度相关。

后验方差推导. **步骤 1:** 应用 Beta 分布方差公式

$$\text{Var}(\theta|y) = \frac{\alpha_{\text{post}} \cdot \beta_{\text{post}}}{(\alpha_{\text{post}} + \beta_{\text{post}})^2 (\alpha_{\text{post}} + \beta_{\text{post}} + 1)}$$

步骤 2: 代入后验参数

$$= \frac{(\alpha + y)(\beta + n - y)}{(\alpha + \beta + n)^2 (\alpha + \beta + n + 1)}$$

步骤 3: 大样本近似 (当 y 和 $n - y$ 较大时) 当 n 很大而 α, β 固定时,

$$\text{Var}(\theta|y) \approx \frac{1}{n} \cdot \frac{y}{n} \left(1 - \frac{y}{n}\right)$$

结论 2: 后验方差以 $1/n$ 的速率趋近于零, 表明随着样本量增大, 后验分布越来越集中在真值附近。

2.3. 拉普拉斯继承法则推导. 背景 (Background): 拉普拉斯在 18 世纪研究”明天太阳会升起”这类问题时, 提出了一个著名的法则。在均匀先验下, 这个法则预测未来成功的概率为 $\frac{y+1}{n+2}$ 。

参数定义 (Parameter Definitions):

- n : 已完成的试验次数
- y : 成功的次数
- $\tilde{y}$: 下一次试验的结果 ($\tilde{y} = 1$ 表示成功)
- θ : 成功概率
- $p(\theta|y) = \text{Beta}(y+1, n-y+1)$: 均匀先验下的后验分布

已知条件 (Given):

- 均匀先验: $\theta \sim \text{Uniform}(0, 1) = \text{Beta}(1, 1)$
- 后验分布: $\theta|y \sim \text{Beta}(y+1, n-y+1)$
- 后验预测分布: $p(\tilde{y} = 1|y) = \int_0^1 \theta \cdot p(\theta|y) d\theta$

目标 (Goal): 求下一次试验成功的概率 $p(\tilde{y} = 1|y)$ 。

推导步骤 (Derivation Steps):

步骤 1: 写出后验预测分布的定义

$$p(\tilde{y} = 1|y) = \int_0^1 p(\tilde{y} = 1|\theta) \cdot p(\theta|y) d\theta$$

步骤 2: 代入 $p(\tilde{y} = 1|\theta) = \theta$ (给定 θ , 成功的条件概率就是 θ)

$$= \int_0^1 \theta \cdot p(\theta|y) d\theta = \mathbb{E}(\theta|y)$$

步骤 3: 识别这是后验均值

$$= \mathbb{E}(\theta|y)$$

步骤 4: 应用 Beta 分布均值公式

$$= \frac{y+1}{(y+1) + (n-y+1)} = \frac{y+1}{n+2}$$

结论: 拉普拉斯继承法则表明, 在均匀先验下, 已知 n 次试验中 y 次成功, 下一次成功的概率是 $\frac{y+1}{n+2}$ 。这推广了”瑞士表匠”问题的直觉——即使观测到 n 次成功, 概率也不是 1 (因为 θ 本身可能是变化的)。

2.4. 总期望与总方差公式推导. 背景 (Background): 全期望公式和全方差公式是概率论中的两个基本恒等式, 它们描述了如何通过条件分布来计算无条件矩。

参数定义 (Parameter Definitions):

- θ : 随机变量 (参数)
- y : 随机变量 (数据)
- $\mathbb{E}(\theta)$: θ 的无条件 (先验) 均值
- $\text{Var}(\theta)$: θ 的无条件 (先验) 方差
- $\mathbb{E}(\theta|y)$: 给定 y 后 θ 的条件均值
- $\text{Var}(\theta|y)$: 给定 y 后 θ 的条件方差

已知条件 (Given):

- 条件期望定义: $\mathbb{E}(\theta|y)$ 是 y 的函数
- 迭代期望法则: $\mathbb{E}[\mathbb{E}(\theta|y)] = \mathbb{E}(\theta)$

目标 (Goal):

- (1) 证明全期望公式: $\mathbb{E}(\theta) = \mathbb{E}[\mathbb{E}(\theta|y)]$
- (2) 证明全方差公式: $\text{Var}(\theta) = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$

全期望公式推导. **步骤 1:** 从条件期望的定义出发

$$\mathbb{E}[\mathbb{E}(\theta|y)] = \int \mathbb{E}(\theta|y) \cdot p(y) dy$$

步骤 2: 代入条件期望 $\mathbb{E}(\theta|y) = \int \theta \cdot p(\theta|y) d\theta$

$$= \int \left(\int \theta \cdot p(\theta|y) d\theta \right) p(y) dy$$

步骤 3: 交换积分次序 (由富比尼定理保证)

$$= \int \theta \left(\int p(\theta|y)p(y) dy \right) d\theta$$

步骤 4: 识别内层积分 $p(\theta) = \int p(\theta|y)p(y)dy$ (全概率)

$$= \int \theta \cdot p(\theta) d\theta = \mathbb{E}(\theta)$$

结论 1: 全期望公式表明, θ 的先验均值等于在所有可能数据上后验均值的加权平均。

全方差公式推导. **步骤 1:** 从方差定义出发

$$\text{Var}(\theta) = \mathbb{E}(\theta^2) - [\mathbb{E}(\theta)]^2$$

步骤 2: 对 $\mathbb{E}(\theta^2)$ 应用全期望公式

$$\mathbb{E}(\theta^2) = \mathbb{E}[\mathbb{E}(\theta^2|y)]$$

步骤 3: 在给定 y 的条件下, 方差可以写为

$$\text{Var}(\theta|y) = \mathbb{E}(\theta^2|y) - [\mathbb{E}(\theta|y)]^2$$

步骤 4: 解出 $\mathbb{E}(\theta^2|y)$

$$\mathbb{E}(\theta^2|y) = \text{Var}(\theta|y) + [\mathbb{E}(\theta|y)]^2$$

步骤 5: 代入步骤 2

$$\mathbb{E}(\theta^2) = \mathbb{E}[\text{Var}(\theta|y)] + \mathbb{E}[\mathbb{E}(\theta|y)]^2$$

步骤 6: 对 $[\mathbb{E}(\theta|y)]^2$ 应用方差分解

$$\mathbb{E}[\mathbb{E}(\theta|y)]^2 = \text{Var}[\mathbb{E}(\theta|y)] + \{\mathbb{E}[\mathbb{E}(\theta|y)]\}^2$$

步骤 7: 代入全期望公式的结果 $\mathbb{E}[\mathbb{E}(\theta|y)] = \mathbb{E}(\theta)$

$$= \text{Var}[\mathbb{E}(\theta|y)] + [\mathbb{E}(\theta)]^2$$

步骤 8: 代回方差的定义

$$\text{Var}(\theta) = \mathbb{E}(\theta^2) - [\mathbb{E}(\theta)]^2 = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$$

结论 2: 全方差公式表明, **总方差 = 条件方差的均值 + 条件均值的方差**。这在贝叶斯语境下的解释是: 参数的总不确定性来自两个方面——(1) 给定数据后参数仍有的剩余不确定性 (条件方差的均值), 以及 (2) 后验均值随数据变化的不确定性 (条件均值的方差)。

2.5. 正态均值估计的后验分布推导. 背景 (Background): 当我们用正态似然估计正态均值时, 如果使用正态先验, 则后验分布也是正态分布。这个推导展示了共轭先验在正态模型中的应用。

参数定义 (Parameter Definitions):

- $y \sim \text{Normal}(\theta, \sigma^2)$: 观测数据 (已知方差 σ^2)
- $\theta \sim \text{Normal}(\mu_0, \tau_0^2)$: 正态先验
- μ_0 : 先验均值
- τ_0^2 : 先验方差
- σ^2 : 已知的观测方差
- μ_1, τ_1^2 : 后验均值和方差

已知条件 (Given):

- 似然函数: $p(y|\theta) \propto \exp\left(-\frac{(y-\theta)^2}{2\sigma^2}\right)$
- 先验密度: $p(\theta) \propto \exp\left(-\frac{(\theta-\mu_0)^2}{2\tau_0^2}\right)$
- 配方法 (completing the square) 技巧

目标 (Goal): 证明后验分布 $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$, 并求出 μ_1 和 τ_1^2 。

推导步骤 (Derivation Steps):

步骤 1: 写出非归一化后验分布的对数

$$\log p(\theta|y) \propto \log p(\theta) + \log p(y|\theta)$$

步骤 2: 代入先验和似然的对数

$$= -\frac{(\theta - \mu_0)^2}{2\tau_0^2} - \frac{(y - \theta)^2}{2\sigma^2}$$

步骤 3: 展开平方项

$$= -\frac{1}{2} \left[\frac{(\theta^2 - 2\mu_0\theta + \mu_0^2)}{\tau_0^2} + \frac{(\theta^2 - 2y\theta + y^2)}{\sigma^2} \right]$$

步骤 4: 合并 θ^2 项的系数

$$= -\frac{1}{2} \left[\theta^2 \left(\frac{1}{\tau_0^2} + \frac{1}{\sigma^2} \right) - 2\theta \left(\frac{\mu_0}{\tau_0^2} + \frac{y}{\sigma^2} \right) + \text{常数} \right]$$

步骤 5: 识别后验精度 (方差的倒数)

$$\frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

步骤 6: 由配方法, 后验均值满足

$$\theta \cdot \frac{1}{\tau_1^2} = \frac{\mu_0}{\tau_0^2} + \frac{y}{\sigma^2}$$

步骤 7: 解出后验均值

$$\mu_1 = \frac{\mu_0/\tau_0^2 + y/\sigma^2}{1/\tau_0^2 + 1/\sigma^2}$$

步骤 8: 写出完整的后验分布

$$\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$$

结论:

- (1) **精度加法**: 后验精度 = 先验精度 + 数据精度
- (2) **后验均值**: 是先验均值 μ_0 和观测值 y 的加权平均, 权重与精度成正比

2.6. Jeffreys 先验与 Fisher 信息推导. 背景 (Background): Jeffreys 提出了一种构建非信息先验的系统方法, 基于 Fisher 信息的不变性原则。这个先验在参数的单调变换下保持不变。

参数定义 (Parameter Definitions):

- θ : 参数
- $p(y|\theta)$: 似然函数
- $J(\theta)$: Fisher 信息
- $L(\theta) = \log p(y|\theta)$: 对数似然
- $I(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \right]$: Fisher 信息 (另一种定义)
- $\phi = h(\theta)$: 参数的单调变换

已知条件 (Given):

- Jeffreys 原则: 先验应在参数的单调变换下保持不变
- Fisher 信息定义: $J(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \right]$
- 变换公式: $p(\phi) = p(\theta) \cdot \left| \frac{d\theta}{d\phi} \right|$

目标 (Goal): 推导 Jeffreys 先验公式并验证其在变换下的不变性。

推导步骤 (Derivation Steps):

Jeffreys 先验公式推导. **步骤 1:** Jeffreys 提出先验正比于 Fisher 信息的平方根

$$p(\theta) \propto [J(\theta)]^{1/2}$$

步骤 2: 验证在变换 $\phi = h(\theta)$ 下的不变性

在新参数 ϕ 下, Fisher 信息为

$$J(\phi) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\phi)}{\partial \phi^2} \right]$$

步骤 3: 利用链式法则

$$\frac{\partial \log p(y|\theta)}{\partial \phi} = \frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d\theta}{d\phi}$$

步骤 4: 计算二阶导数

$$\frac{\partial^2 \log p(y|\theta)}{\partial \phi^2} = \frac{\partial}{\partial \phi} \left(\frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d\theta}{d\phi} \right) = \frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \left(\frac{d\theta}{d\phi} \right)^2 + \frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d^2 \theta}{d\phi^2}$$

步骤 5: 取期望, 利用 $\mathbb{E} \left[\frac{\partial \log p(y|\theta)}{\partial \theta} \right] = 0$ (得分函数的期望为零)

$$J(\phi) = \left(\frac{d\theta}{d\phi} \right)^2 J(\theta)$$

步骤 6: 因此

$$[J(\phi)]^{1/2} = \left| \frac{d\theta}{d\phi} \right| [J(\theta)]^{1/2}$$

步骤 7: 新先验为

$$p(\phi) \propto [J(\phi)]^{1/2} \propto [J(\theta)]^{1/2} \left| \frac{d\theta}{d\phi} \right|$$

结论: 这正是概率密度在变量变换下的标准变换公式, 因此 Jeffreys 先验在单调变换下是不变的。

二项模型的 *Jeffreys* 先验推导. **步骤 1:** 写出二项模型的对数似然

$$\log p(y|\theta) = \log \binom{n}{y} + y \log \theta + (n - y) \log(1 - \theta)$$

步骤 2: 计算一阶导数 (得分函数)

$$\frac{\partial}{\partial \theta} \log p(y|\theta) = \frac{y}{\theta} - \frac{n - y}{1 - \theta}$$

步骤 3: 计算二阶导数

$$\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) = -\frac{y}{\theta^2} - \frac{n - y}{(1 - \theta)^2}$$

步骤 4: 取负期望 (注意 $\mathbb{E}(Y) = n\theta$)

$$J(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) \right] = \frac{n\theta}{\theta^2} + \frac{n(1 - \theta)}{(1 - \theta)^2} = \frac{n}{\theta(1 - \theta)}$$

步骤 5: 应用 *Jeffreys* 公式

$$p(\theta) \propto \left[\frac{n}{\theta(1 - \theta)} \right]^{1/2} \propto \theta^{-1/2} (1 - \theta)^{-1/2}$$

步骤 6: 识别为 Beta 分布

$$p(\theta) \propto \theta^{(1/2)-1} (1 - \theta)^{(1/2)-1} \Rightarrow \theta \sim \text{Beta} \left(\frac{1}{2}, \frac{1}{2} \right)$$

结论: 二项模型的 *Jeffreys* 先验是 $\text{Beta}(1/2, 1/2)$, 这是一个弱信息先验, 比均匀先验 $\text{Beta}(1, 1)$ 在边界处更轻。

2.7. 后验预测分布的均值与方差推导. 背景 (Background): 后验预测分布 $\tilde{y}|y$ 的均值和方差有两个组成部分——一个来自模型本身的随机性, 另一个来自参数的后验不确定性。

参数定义 (Parameter Definitions):

- $\tilde{y}$: 未来观测
- y : 当前观测
- θ : 参数
- $\mathbb{E}(\tilde{y}|y)$: 后验预测均值
- $\text{Var}(\tilde{y}|y)$: 后验预测方差

已知条件 (Given):

- $\tilde{y}|\theta \sim \text{Normal}(\theta, \sigma^2)$
- $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$
- 全期望公式: $\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$
- 全方差公式: $\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$

目标 (Goal): 求后验预测分布 $\tilde{y}|y$ 的均值和方差。

后验预测均值推导. **步骤 1**: 应用全期望公式

$$\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 给定 θ , $\tilde{y}$ 与 y 条件独立, 且 $\mathbb{E}(\tilde{y}|\theta) = \theta$

$$= \mathbb{E}(\theta|y) = \mu_1$$

结论 1: 后验预测均值等于参数的后验均值。

后验预测方差推导. **步骤 1**: 应用全方差公式

$$\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 第一项——给定 θ 下的方差是 σ^2 (模型方差)

$$\mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] = \mathbb{E}(\sigma^2|y) = \sigma^2$$

步骤 3: 第二项——条件均值的方差

$$\text{Var}[\mathbb{E}(\tilde{y}|\theta, y)] = \text{Var}(\theta|y) = \tau_1^2$$

步骤 4: 合并

$$\text{Var}(\tilde{y}|y) = \sigma^2 + \tau_1^2$$

结论 2: 后验预测方差 = **模型方差** + **参数后验方差**。这体现了贝叶斯推断的核心: 预测的不确定性来自两个方面——(1) 模型本身的随机性 (σ^2), 以及 (2) 参数估计的不确定性 (τ_1^2)。

3. 阅读过程中的问题与解答

4. 什么是分布的核

4.1. 问题. 分布的核是什么概念?

4.2. 回答. 分布的核 (kernel) 是指概率密度/质量函数中依赖于参数的核心部分, 不包括归一化常数。

举例说明:

Beta-Binomial 共轭中, 后验分布:

$$p(\theta|y) \propto \theta^{\alpha+y-1}(1-\theta)^{\beta+n-y-1}$$

其中 $\theta^{\alpha+y-1}(1-\theta)^{\beta+n-y-1}$ 是**核**, 而完整的 Beta 分布还需要归一化常数:

$$p(\theta|y) = \frac{\Gamma(\alpha + \beta + n)}{\Gamma(\alpha + y)\Gamma(\beta + n - y)} \theta^{\alpha+y-1}(1-\theta)^{\beta+n-y-1}$$

为什么核重要:

(1) **识别分布形式**: 知道核是 $\theta^a(1-\theta)^b$ 形式, 就能识别这是 Beta 分布

(2) **贝叶斯推断中省略 $p(y)$** : $p(y)$ 是归一化常数, 不包含关于 θ 的信息, 所以可以省略

(3) **简化推导**: 在推导过程中只关注核, 省去繁琐的归一化常数

Insight 这本质上是**信息局部性**思想: 归一化常数的作用只是“让面积等于 1”, 它本身不携带关于参数的信息。真正“有意义”的概率质量都集中在核上。

5. 学习笔记

在这里记录你的学习心得和思考。