

$$= \textcircled{R} " s \textit{f} l$$

: 2 H K M - * ` H B M - a i 2 ` M - . m M b Q M - o

* Q Mi2 Mib

„ý Ó D À •	8
„ý Ó D À •	8
R X I ^{1 ^} = ® ” s	8
k X , • À Q	8
j X Ó D ” c	e
9 X [ñ ²	e
8 X Ð Z E	d
S ` i R X = ® w \$	N
* ? T i 2 ` R X Ð w	R R
R X = ® ” s ¥ Ø „ ç	R R
k X d 9 w ¥ B î ~	R R
j X = ® w	R R
9 X » - Ð ^a] 1	R j
8 X À q T ¹ , ' ç ÿ ¥	R j
e X ö 4 ÿ Ð Z 4 ÿ	R 9
d X À q ® ´ ¥ è 0 @ o Ä µ	R 9
3 X À q , ¥ B t µ “ ² T	R 9
N X ' c l ²	R 9
R y X « ç á	R 9
* ? T i 2 ` k t X ” ~	R 8
R X V = [” 9 À q	R 8
k X ^a T ¹ ” Ð 5 • ¥ ï	R e
j X ^a w ¥ ø 9	R e
9 X • 5 s f	R e
8 X ž ŷ (´ ¥ 9 X © Z µ	R d
e X d • 5 s f	R 3
d X C 2 z , M ŷ Ð 5	R 3
3 X Ð • 5 s f	R N
N X ð S † • ” ~	R N
R y X c l ²	R N
R R X « ç á	R N
* ? T i 2 ` j X ” ~ e °	k R
R X L m B b M ¥ 2 s	k R
k X ž ŷ ” Ð d • 5	k R
j X ž ŷ ” Ð â 5	k j

2.7. 后验预测分布的均值与方差推导. 背景 (Background): 后验预测分布 $\tilde{y}|y$ 的均值和方差有两个组成部分——一个来自模型本身的随机性, 另一个来自参数的后验不确定性。

参数定义 (Parameter Definitions):

- $\tilde{y}$: 未来观测
- y : 当前观测
- θ : 参数
- $\mathbb{E}(\tilde{y}|y)$: 后验预测均值
- $\text{Var}(\tilde{y}|y)$: 后验预测方差

已知条件 (Given):

- $\tilde{y}|\theta \sim \text{Normal}(\theta, \sigma^2)$
- $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$
- 全期望公式: $\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$
- 全方差公式: $\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$

目标 (Goal): 求后验预测分布 $\tilde{y}|y$ 的均值和方差。

后验预测均值推导. **步骤 1**: 应用全期望公式

$$\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 给定 θ , $\tilde{y}$ 与 y 条件独立, 且 $\mathbb{E}(\tilde{y}|\theta) = \theta$

$$= \mathbb{E}(\theta|y) = \mu_1$$

结论 1: 后验预测均值等于参数的后验均值。

后验预测方差推导. **步骤 1**: 应用全方差公式

$$\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 第一项——给定 θ 下的方差是 σ^2 (模型方差)

$$\mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] = \mathbb{E}(\sigma^2|y) = \sigma^2$$

步骤 3: 第二项——条件均值的方差

$$\text{Var}[\mathbb{E}(\tilde{y}|\theta, y)] = \text{Var}(\theta|y) = \tau_1^2$$

步骤 4: 合并

$$\text{Var}(\tilde{y}|y) = \sigma^2 + \tau_1^2$$

结论 2: 后验预测方差 = **模型方差** + **参数后验方差**。这体现了贝叶斯推断的核心: 预测的不确定性来自两个方面——(1) 模型本身的随机性 (σ^2), 以及 (2) 参数估计的不确定性 (τ_1^2)。

3. 拒绝抽样的正确性证明

背景 (Background): 拒绝抽样通过随机接受机制从目标分布中抽取样本。我们需要证明被接受的样本确实服从目标分布 $p(\theta)$ 。

参数定义 (Parameter Definitions):

- $p(\theta)$: 目标 (未归一化) 分布
- $g(\theta)$: 提议分布
- M : 覆盖常数, 满足 $p(\theta) \leq M \cdot g(\theta)$
- θ^* : 候选样本
- u^* : 从 $\text{Uniform}(0, 1)$ 抽取的随机数

目标 (Goal): 证明被接受的样本 θ_{accept} 服从目标分布 $p(\theta)$ 。

推导步骤 (Derivation Steps):

步骤 1: 写出接受的联合概率

$$\text{接受联合概率 } \mathbb{P}(\text{接受} \cap \theta^* \in d\theta) = \mathbb{P}(\theta^* \in d\theta) \cdot \mathbb{P}(\text{接受}|\theta^*) = g(\theta^*)d\theta \cdot \frac{p(\theta^*)}{Mg(\theta^*)} = \frac{p(\theta^*)}{M}d\theta$$

步骤 2: 计算总接受概率 (归一化常数)

$$\text{总接受概率 } \mathbb{P}(\text{接受}) = \int \frac{p(\theta^*)}{M}d\theta = \frac{1}{M}$$

步骤 3: 计算接受样本的条件分布

$$\text{条件分布} = \text{目标分布 } \mathbb{P}(\theta_{\text{accept}} \in d\theta | \text{接受}) = \frac{\mathbb{P}(\text{接受} \cap \theta^* \in d\theta)}{\mathbb{P}(\text{接受})} = \frac{p(\theta^*)/M}{1/M}d\theta = p(\theta^*)d\theta$$

结论: 被接受的样本的条件分布正是目标分布 $p(\theta)$ 。证明完毕。

3.1. 拒绝抽样期望接受率推导. 背景 (Background): 拒绝抽样的期望接受率是衡量算法效率的关键指标。

目标 (Goal): 推导期望接受率的公式。

推导步骤 (Derivation Steps):

步骤 1: 期望接受率定义为

期望定义
$$\text{accept rate} = \int \mathbb{P}(\text{接受}|\theta) \cdot g(\theta) d\theta$$

步骤 2: 代入接受概率

接受概率
$$\mathbb{P}(\text{接受}|\theta) = \min\left(1, \frac{p(\theta)}{Mg(\theta)}\right)$$

步骤 3: 于是

积分结果
$$\text{accept rate} = \int \min\left(\frac{p(\theta)}{Mg(\theta)}, 1\right) \cdot g(\theta) d\theta = \frac{1}{M} \int \min(p(\theta), Mg(\theta)) d\theta$$

步骤 4: 当覆盖条件 $Mg(\theta) \geq p(\theta)$ 对所有 θ 成立时

简化为 $1/M$
$$\text{accept rate} = \frac{1}{M} \int p(\theta) d\theta = \frac{1}{M}$$

结论: 期望接受率与 M 成反比, 选择尽可能小的 M 可提高接受率。

3.2. 细致平衡条件推导. 背景 (Background): 细致平衡是构造满足特定平稳分布的马尔可夫链的关键条件。

目标 (Goal): 证明如果转移核 P 满足细致平衡, 则其平稳分布就是 π 。

推导步骤 (Derivation Steps):

步骤 1: 写出细致平衡条件

细致平衡 $P(\theta'|\theta) \cdot \pi(\theta) = P(\theta|\theta') \cdot \pi(\theta')$

步骤 2: 验证 π 是平稳分布

平稳分布验证

$$\int P(\theta'|\theta) \cdot \pi(\theta) d\theta = \int P(\theta|\theta') \cdot \pi(\theta') d\theta = \pi(\theta') \int P(\theta|\theta') d\theta = \pi(\theta') \cdot 1 = \pi(\theta')$$

其中第三步用到 $\int P(\theta|\theta') d\theta = 1$ (转移核的归一化性)。

结论: 细致平衡是平稳分布的充分条件, 但不是必要条件。

3.3. Metropolis 算法细致平衡证明. 背景 (Background): Metropolis 算法的提议分布是对称的, 我们需要证明其满足细致平衡。

目标 (Goal): 证明 Metropolis 算法的转移核以目标分布 $p(\theta)$ 为平稳分布。

推导步骤 (Derivation Steps):

步骤 1: Metropolis 转移核

$$P(\theta'|\theta) = q(\theta'|\theta) \cdot \min\left(1, \frac{p(\theta')}{p(\theta)}\right)$$

其中 $q(\theta'|\theta) = q(\theta|\theta')$ (对称提议分布)。

步骤 2: 验证细致平衡

$$P(\theta'|\theta) \cdot p(\theta) = q(\theta'|\theta) \cdot \min\left(1, \frac{p(\theta')}{p(\theta)}\right) \cdot p(\theta)$$

分两种情况讨论:

情况 1: $p(\theta') \geq p(\theta)$

$$\text{右边} = q(\theta'|\theta) \cdot 1 \cdot p(\theta) = q(\theta'|\theta) \cdot p(\theta')$$

情况 2: $p(\theta') < p(\theta)$

$$\text{右边} = q(\theta'|\theta) \cdot \frac{p(\theta')}{p(\theta)} \cdot p(\theta) = q(\theta'|\theta) \cdot p(\theta')$$

由于 $q(\theta'|\theta) = q(\theta|\theta')$, 两种情况都满足

细致平衡成立 $P(\theta'|\theta) \cdot p(\theta) = P(\theta|\theta') \cdot p(\theta')$

结论: Metropolis 算法的平稳分布正是目标分布 $p(\theta)$ 。证明完毕。

3.4. Gibbs 抽样接受率推导. 背景 (Background): Gibbs 抽样是 Metropolis-Hastings 的特例, 其接受率恒为 1。我们来推导这个结论。

参数定义 (Parameter Definitions):

- $\theta = (\theta_1, \dots, \theta_d)$: 完整参数向量
- $\theta_{-j} = (\theta_1, \dots, \theta_{j-1}, \theta_{j+1}, \dots, \theta_d)$: 除 θ_j 外的所有参数
- $p^*(\theta)$: 未归一化的目标分布
- $q(\theta'_j|\theta_{-j}) = p(\theta'_j|\theta_{-j}, y)$: 提议分布 (条件分布)

目标 (Goal): 证明 Gibbs 抽样的接受率为 1。

推导步骤 (Derivation Steps):

步骤 1: 写出 MH 接受比

$$\text{MH 接受比} \quad r = \frac{p^*(\theta'_j, \theta_{-j})}{p^*(\theta_j, \theta_{-j})} \cdot \frac{q(\theta_j|\theta_{-j})}{q(\theta'_j|\theta_{-j})}$$

步骤 2: 代入 Gibbs 的提议分布

$$q(\theta_j|\theta_{-j}) = p(\theta_j|\theta_{-j}, y)$$

提议分布 = 条件分布

$$q(\theta'_j|\theta_{-j}) = p(\theta'_j|\theta_{-j}, y)$$

步骤 3: 利用链式法则分解联合分布

$$p^*(\theta'_j, \theta_{-j}) = p^*(\theta_{-j}) \cdot p^*(\theta'_j|\theta_{-j})$$

链式法则

$$p^*(\theta_j, \theta_{-j}) = p^*(\theta_{-j}) \cdot p^*(\theta_j|\theta_{-j})$$

步骤 4: 代入接受比

$$\text{代入} \quad r = \frac{p^*(\theta_{-j}) \cdot p^*(\theta'_j|\theta_{-j})}{p^*(\theta_{-j}) \cdot p^*(\theta_j|\theta_{-j})} \cdot \frac{p(\theta_j|\theta_{-j}, y)}{p(\theta'_j|\theta_{-j}, y)} = \frac{p^*(\theta'_j|\theta_{-j})}{p^*(\theta_j|\theta_{-j})} \cdot \frac{p(\theta_j|\theta_{-j}, y)}{p(\theta'_j|\theta_{-j}, y)}$$

步骤 5: 注意 $p^*(\theta_j|\theta_{-j}, y) \propto p(\theta_j|\theta_{-j}, y)$, 因为 $p^*(\theta_{-j})$ 不依赖于 θ_j 。于是两个因子互为倒数,

接受率为 1

$$r = 1$$

结论: Gibbs 抽样的提议分布恰好是条件分布, 因此接受率恒为 1, 无需拒绝。

3.5. 分层模型条件分布推导. 背景 (Background): 在分层模型 eq. (27) 中, 我们需要推导各个参数的条件后验分布。

模型回顾:

$$y_j|\theta_j \sim N(\theta_j, \sigma^2), \quad \theta_j|\mu, \tau \sim N(\mu, \tau^2)$$

其中 σ^2 已知。

目标 (Goal): 推导 $p(\theta_j|\mu, \tau, y)$ 、 $p(\mu|\theta, \tau, y)$ 和 $p(\tau|\theta, \mu, y)$ 。

$p(\theta_j|\mu, \tau, y)$ 推导. **步骤 1:** 写出条件分布的核

核
$$p(\theta_j|\mu, \tau, y) \propto p(y_j|\theta_j) \cdot p(\theta_j|\mu, \tau) \propto \exp\left(-\frac{(y_j - \theta_j)^2}{2\sigma^2}\right) \cdot \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 2: 合并指数

合并
$$= \exp\left(-\frac{(y_j - \theta_j)^2}{2\sigma^2} - \frac{(\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 3: 配方得到正态分布形式

配方
$$= \exp\left(-\frac{1}{2} \left[\frac{1}{\sigma^2} + \frac{1}{\tau^2}\right] \left(\theta_j - \frac{y_j/\sigma^2 + \mu/\tau^2}{1/\sigma^2 + 1/\tau^2}\right)^2\right)$$

因此

条件后验
$$\theta_j|\mu, \tau, y \sim N\left(\frac{y_j/\sigma^2 + \mu/\tau^2}{1/\sigma^2 + 1/\tau^2}, \left(\frac{1}{\sigma^2} + \frac{1}{\tau^2}\right)^{-1}\right)$$

$p(\mu|\theta, \tau, y)$ 推导. **步骤 1:** μ 的条件分布 (似然部分只依赖于 θ_j , 与 μ 通过 $\theta_j|\mu, \tau$ 连接)

先验部分
$$p(\mu|\theta, \tau) \propto p(\theta|\mu, \tau) = \prod_{j=1}^J \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right) \propto \exp\left(-\frac{\sum_j (\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 2: 展开平方

平方展开
$$\sum_j (\theta_j - \mu)^2 = \sum_j (\theta_j - \bar{\theta} + \bar{\theta} - \mu)^2 = \sum_j (\theta_j - \bar{\theta})^2 + J(\bar{\theta} - \mu)^2$$

步骤 3: 识别为正态核

正态核
$$p(\mu|\theta, \tau) \propto \exp\left(-\frac{J(\bar{\theta} - \mu)^2}{2\tau^2}\right)$$

因此

条件后验
$$\mu|\theta, \tau \sim N\left(\bar{\theta}, \frac{\tau^2}{J}\right)$$

其中 $\bar{\theta} = \frac{1}{J} \sum_j \theta_j$ 。

$p(\tau|\theta, \mu, y)$ 的非标准形式. **说明:**

非标准形式
$$p(\tau|\theta, \mu, y) \propto p(\theta|\mu, \tau) \cdot p(\tau) = \prod_{j=1}^J \frac{1}{\tau} \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right) \cdot p(\tau)$$

这个分布不是标准形式 (不是常见的正态、Gamma 等分布), 因此需要使用 Metropolis-Hastings 步骤来抽样。

结论: 在 Gibbs 抽样框架下, 对 τ 需要使用 MH 步骤, 这正是”混合 MCMC”的典型例子。

4. 阅读过程中的问题与解答

5. 什么是分布的核

5.1. 问题. 分布的核是什么概念?

5.2. 回答. 分布的**核 (kernel)** 是指概率密度/质量函数中**依赖于参数的核心部分**, 不包括归一化常数。

举例说明:

Beta-Binomial 共轭中, 后验分布:

$$p(\theta|y) \propto \theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$$

其中 $\theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$ 是**核**, 而完整的 Beta 分布还需要归一化常数:

$$p(\theta|y) = \frac{\Gamma(\alpha + \beta + n)}{\Gamma(\alpha + y)\Gamma(\beta + n - y)} \theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$$

为什么核重要:

- (1) **识别分布形式:** 知道核是 $\theta^a(1-\theta)^b$ 形式, 就能识别这是 Beta 分布
- (2) **贝叶斯推断中省略 $p(y)$:** $p(y)$ 是归一化常数, 不包含关于 θ 的信息, 所以可以省略
- (3) **简化推导:** 在推导过程中只关注核, 省去繁琐的归一化常数

Insight 这本质上是**信息局部性**思想: 归一化常数的作用只是”让面积等于 1”, 它本身不携带关于参数的信息。真正”有意义”的概率质量都集中在核上。

6. 学习笔记

在这里记录你的学习心得和思考。