贝叶斯数据分析讲义

Gelman, Carlin, Stern, Dunson, Vehtari, Rubin

Contents

Part 1

贝叶斯推断基础

CHAPTER 1

概率与推断

1. 本章导论

贝叶斯数据分析的核心是用**概率**来量化不确定性。在本章中，我们将介绍贝叶斯数据分析的三个基本步骤，这是整本书的基础框架。

2. 贝叶斯数据分析的三步骤

贝叶斯数据分析的过程可以理想化地分为以下三个步骤：

(1) **建立完整的概率模型**：对问题中所有可观测和不可观测的量建立一个联合概率分布。模型应与底层科学问题和数据收集过程的知识相一致。

(2) **基于观测数据进行分析**：计算并解释适当的后验分布——即在给定观测数据的条件下，关于不可观测量的条件概率分布。

(3) **评估模型的拟合度和后验分布的含义**：
   - 模型对数据的拟合程度如何?
   - 实质性结论是否合理?
   - 结果对第一步中建模假设的敏感性如何?

   作为回应，可以修改或扩展模型并重复这三个步骤。

注 1.1. 第三个步骤涉及计算方法论和微妙的技术与判断平衡，由问题的应用背景指导。第一步仍然是许多贝叶斯分析的主要障碍：我们的模型从何而来？如何构建适当的概率规范?

贝叶斯思维的主要动机是它便于对统计结论进行常识性解释。例如，一个未知量的贝叶斯（概率）区间可以直接被认为是”该未知量有很高概率包含在其中”，这与频率主义（置信区间）的解释形成对比。

3. 统计推断的一般符号

在贝叶斯统计中，我们使用以下符号：

- θ：不可观测的向量值或总体参数（如临床试验中每种治疗方案的生存概率）
- y：观测数据（如每组中的存活和死亡人数）
- $\tilde{y}$：未知但潜在可观测的量（如其他治疗方案下患者的结果，或与试验中患者相似的新患者的结果）
- x：解释变量或协变量（如患者的年龄和先前健康状况）

4. 贝叶斯推断

贝叶斯推断的核心思想是：关于参数 θ 或未观测数据 $\tilde{y}$ 的统计结论，都以概率陈述的形式给出。

这些概率陈述以观测值 y 为条件，在我们的记号中简单记为 $p(\theta|y)$ 或 $p(\tilde{y}|y)$。

4.1. 贝叶斯定理. 为了对给定 y 的 θ 做出概率陈述，我们必须首先建立一个提供 θ 和 y 联合概率分布的模型。

联合概率质量（或密度）函数可以写成两个密度的乘积，通常称为先验分布 $p(\theta)$ 和采样分布（或数据分布）$p(y|\theta)$：

$$p(\theta, y) = p(\theta) \times p(y|\theta)$$

使用条件概率的基本性质（贝叶斯定理），得到后验密度：

$$p(\theta|y) = \frac{p(\theta) \times p(y|\theta)}{p(y)}$$

其中

$$p(y) = \int p(\theta) \times p(y|\theta)\, d\theta$$

一个等价的形式省略了不依赖于 θ 的因子 $p(y)$，给出非归一化后验密度：

$$p(\theta|y) \propto p(\theta) \times p(y|\theta)$$

注 1.2. 注意：$p(y|\theta)$ 被视为 θ 的函数（固定 y），而不是 y 的函数。这被称为似然函数。

4.2. 预测. 在数据 y 被观测之前，未知但可观测的 $\tilde{y}$ 的分布是边际分布：

$$p(y) = \int p(y|\theta) \times p(\theta)\, d\theta$$

这被称为先验预测分布（prior predictive distribution）。

在观测到数据 y 之后，预测 $\tilde{y}$ 的分布是后验预测分布（posterior predictive distribution）：

$$p(\tilde{y}|y) = \int p(\tilde{y}|\theta) \times p(\theta|y)\, d\theta$$

后验预测分布可以解释为在 θ 的后验分布上对条件预测进行平均。

5. 似然与优势比

使用贝叶斯定理与选定的概率模型意味着数据 y 只通过 $p(y|\theta)$ 影响后验推断，当固定 y 将其视为 θ 的函数时，称为**似然函数**。

这样，贝叶斯推断服从所谓的似然原理：对于给定的数据样本，任何具有相同似然函数的概率模型 $p(y|\theta)$ 对 θ 产生相同的推断。

后验密度 $p(\theta|y)$ 在 θ_1 和 θ_2 处取值的比率称为后验优势比。优势比提供了一个概率的替代表示，并且具有贝叶斯定理用优势比表示特别简单的形式：

$$\frac{p(\theta_1|y)}{p(\theta_2|y)} = \frac{p(\theta_1)}{p(\theta_2)} \times \frac{p(y|\theta_1)}{p(y|\theta_2)}$$

即：**后验优势比 = 先验优势比 × 似然比**。

6. 概率作为不确定性的度量

在贝叶斯统计中，概率被用作不确定性的基本度量。在这个范式下，讨论明天降雨的概率或巴西队赢得世界杯的概率与讨论硬币抛掷正面朝上的概率同样合法。

6.1. 两种经典论证. 对称性/可交换性论证:

$$\text{概率} = \frac{\text{有利情况数}}{\text{可能情况数}}$$

频率论证:

$$\text{概率} = \text{在长期重复序列中得到的相对频率}$$

6.2. 博彩一致性原理. 将你对事件 E 赋予的概率 p（$p \in [0,1]$）定义为：你愿意以此比例下注 \$p 来换取如果 E 发生则获得 \$1 的回报。

一致性原则要求：你对所有可能事件的概率赋值不应该让对方有可能从你这里确定获利。

7. 主观性与客观性

所有使用概率的统计方法在某种意义上都是主观的，因为它们依赖于对世界的数学理想化。

贝叶斯方法有时被认为特别主观，因为它们依赖于先验分布。但在大多数问题中，科学判断对于指定似然和先验分布都是必要的。

一个普遍原则是：每当存在复制时（即观察到许多可交换的单位），就有机会从数据中估计概率分布的特征，从而使分析更加客观。

8. 本章小结

本章我们学习了：

(1) 贝叶斯数据分析的三个基本步骤
(2) 统计推断的一般符号 $(\theta, y, \tilde{y}, x)$
(3) 贝叶斯定理及其组成部分（先验、似然、后验、边际似然）
(4) 预测分布：先验预测分布与后验预测分布
(5) 概率作为不确定性度量的多种解释
(6) 似然原理和优势比

9. 下节预告

下一章我们将学习单参数模型，包括从二项数据估计概率的经典例子——这是贝叶斯推断最经典的入门案例。

CHAPTER 2

单参数模型

1. 本章导论

本章我们将学习单参数模型的贝叶斯推断，包括二项数据的概率估计、正态均值的估计等经典问题。这些例子将帮助我们理解后验分布如何作为数据与先验信息的折中，以及如何汇总后验推断。

2. 从二项数据估计概率

考虑从二项分布 $y \sim \text{Binomial}(n, \theta)$ 中观测到 y 次成功，其中：

- y：n 次伯努利试验中的成功总次数
- θ：总体中的成功比例，或每次试验的成功概率

2.1. 似然函数. 二项分布的似然函数为：

$$p(y|\theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y}$$

其中 $\binom{n}{y} = \frac{n!}{y!(n-y)!}$ 是组合数。

2.2. 先验分布. 为了执行贝叶斯推断，我们必须为 θ 指定先验分布。作为简单开始，我们假设先验分布是 $[0,1]$ 上的均匀分布：$\theta \sim \text{Uniform}(0,1)$，即 $p(\theta) = 1$。

2.3. 后验分布. 应用贝叶斯定理，得到后验密度：

$$p(\theta|y) \propto \theta^y (1-\theta)^{n-y}$$

这正是 Beta 分布的形式，因此：

$$\theta|y \sim \text{Beta}(y+1, n-y+1)$$

定义 2.1 (Beta 分布). Beta 分布的概率密度函数为：

$$p(x|\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1}, \quad 0 \le x \le 1$$

注 2.1. 在固定 n 和 y 的情况下，组合数 $\binom{n}{y}$ 不依赖于未知参数 θ，因此在计算后验分布时可以视为常数。

2.4. 预测. 在均匀先验下，先验预测分布可以直接计算。在模型下，所有可能的 y 值在先验下同等可能。

令 $\tilde{y}$ 表示与前 n 次试验可交换的一次新试验的结果：

$$P(\tilde{y} = 1|y) = \int \theta \cdot p(\theta|y)\, d\theta = E(\theta|y) = \frac{y+1}{n+2}$$

这就是著名的拉普拉斯继承法则（Laplace's law of succession）。在极端观测 $y = 0$ 和 $y = n$ 时，拉普拉斯法则预测概率分别为 $1/(n+2)$ 和 $(n+1)/(n+2)$。

3. 后验作为数据与先验信息的折中

贝叶斯推断的过程涉及从先验分布 $p(\theta)$ 到后验分布 $p(\theta|y)$ 的转化。

3.1. 一般性质. 以下两个式子描述了先验与后验之间的关系：

$$E(\theta) = E[E(\theta|y)]$$

$$\mathrm{Var}(\theta) = E[\mathrm{Var}(\theta|y)] + \mathrm{Var}[E(\theta|y)]$$

第一个式子表明：θ 的先验均值是所有可能数据上后验均值的平均。

第二个式子更有趣：后验方差平均上小于先验方差，两者之差取决于后验均值在不同数据上的变化程度。变化越大，我们降低不确定性的潜力越大。

3.2. 二项例子中的折中. 在二项例子中，均匀先验的均值是 1/2，方差是 1/12。

后验均值 $\frac{y+1}{n+2}$ 是先验均值 1/2 和样本比例 y/n 之间的折中。显然，随着数据样本量增大，先验的作用越来越小。

这是贝叶斯推断的一般特征：后验分布位于代表先验信息和数据信息的点之间，折中程度随着样本量增加越来越受数据控制。

4. 后验推断的汇总

后验概率分布包含了关于参数 θ 的所有当前信息。

4.1. 点估计. 常用的位置汇总包括：后验均值、后验中位数、后验众数。

变化程度通常用标准差、四分位距和其他分位数来汇总。

当后验分布具有闭式形式时（如当前例子中的 Beta 分布），这些汇总通常可以用闭式形式得到。

4.2. 区间估计. 除了点汇总之外，报告后验不确定性几乎总是重要的。

通常的方法是给出后验分布的分位数，或者如果需要区间汇总，则给出一定概率的后验中心区间（如 $100(1-\alpha)\%$ 区间）。

这类区间估计称为后验区间（posterior interval）。

4.3. 最高后验密度区间. 另一种汇总后验不确定性的方法是最高后验密度区域（Highest Posterior Density, HPD）：包含 $100(1-\alpha)\%$ 后验概率的集合，且区域内密度不低于区域外。

对于单峰且对称的后验分布，HPD 区间与后验中心区间相同。但对于非对称分布，两者可能有显著差异。

5. 信息先验分布

在二项例子中，到目前为止我们只考虑了 θ 的均匀先验分布。

问题在于：如何证明这种指定的合理性？一般来说，我们如何处理构建先验分布的问题？

5.1. 两种解释. 对先验分布有两种基本解释：

(1) **总体解释**：先验分布代表可能参数值的总体，当前感兴趣的 θ 是从中抽取的。
(2) **主观知识状态解释**：指导原则是，我们必须将关于 θ 的知识（和不确定性）表达得像它的值是先验分布的随机实现一样。

对于许多问题（如估计新工业过程中失败概率），不存在完全相关的 θ 的总体，除了假设性想象。

通常，先验分布应包含所有合理的 θ 值，但分布不必真实集中在真值附近，因为通常数据中关于 θ 的信息远超过任何合理先验概率规范。

5.2. 共轭先验. 考虑二项模型的似然：$p(y|\theta) \propto \theta^a(1-\theta)^b$

如果先验密度具有相同形式（带有自己的 a 和 b 值），则后验密度也具有这种形式。

我们将先验密度参数化为：

$$p(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$$

即 $\theta \sim \mathrm{Beta}(\alpha, \beta)$。

将 $p(\theta)$ 与 $p(y|\theta)$ 比较，可以看出这个先验等价于 $\alpha-1$ 次先验成功和 $\beta-1$ 次先验失败。

先验分布的参数通常称为超参数（hyperparameters）。

对于给定的 α 和 β，θ 的后验密度为：

$$p(\theta|y) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1} \times \theta^y(1-\theta)^{n-y} = \theta^{y+\alpha-1}(1-\theta)^{n-y+\beta-1}$$

即 $\theta|y \sim \mathrm{Beta}(\alpha+y, \beta+n-y)$。

定义 2.2 (共轭性). 后验分布与先验分布属于同一参数形式，这一性质称为共轭性。Beta 先验分布是二项似然的共轭族。

共轭族在计算上是方便的，因为后验分布遵循已知参数形式。如果可用信息与共轭参数族矛盾，可能需要使用更现实（尽管不方便）的先验分布。

后验均值：

$$E(\theta|y) = \frac{\alpha+y}{\alpha+\beta+n}$$

后验方差：

$$\mathrm{Var}(\theta|y) = \frac{(\alpha+y)(\beta+n-y)}{(\alpha+\beta+n)^2(\alpha+\beta+n+1)}$$

当 y 和 $n-y$ 变大而 α 和 β 固定时：

$$E(\theta|y) \approx \frac{y}{n}, \quad \mathrm{Var}(\theta|y) \approx \frac{1}{n} \cdot \frac{y}{n}\left(1-\frac{y}{n}\right)$$

方差以 $1/n$ 的速率趋近于零。极限情况下，先验分布的参数对后验分布没有影响。

6. 正态均值的估计（已知方差）

考虑来自正态分布 $y \sim \mathrm{Normal}(\theta, \sigma^2)$ 的单个标量观测 y，其中 σ^2 已知。

采样分布：

$$p(y|\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\theta)^2}{2\sigma^2}\right)$$

6.1. 共轭先验与后验. 作为 θ 的函数，似然是二次型的指数，因此共轭先验族看起来像：

$$p(\theta) \propto \exp(A\theta^2 + B\theta + C), \quad A < 0$$

我们参数化为：

$$p(\theta) \propto \exp\left(-\frac{1}{2\tau_0^2}(\theta - \mu_0)^2\right)$$

即 $\theta \sim \text{Normal}(\mu_0, \tau_0^2)$，其中 μ_0 和 τ_0^2 是超参数。

经过一些代数运算（配方法），得到后验分布：

$$\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$$

其中：

$$\mu_1 = \frac{\mu_0/\tau_0^2 + y/\sigma^2}{1/\tau_0^2 + 1/\sigma^2}$$
$$\frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

注 2.2. 精度的概念：方差的倒数称为精度。后验精度等于先验精度加上数据精度。

后验均值 μ_1 可以解释为：

- 先验均值和观测值 y 的加权平均，权重与精度成正比
- 先验均值向观测值调整：$\mu_1 = \mu_0 + (y - \mu_0)\frac{\tau_0^2}{\sigma^2+\tau_0^2}$
- 数据向先验均值收缩：$\mu_1 = y - (y - \mu_0)\frac{\sigma^2}{\sigma^2+\tau_0^2}$

每种形式都表示后验均值是先验均值和观测值之间的折中。

6.2. 后验预测分布. 未来观测 $\tilde{y}$ 的后验预测分布：

$$\tilde{y}|y \sim \text{Normal}(\mu_1, \sigma^2 + \tau_1^2)$$

预测均值等于 θ 的后验均值；预测方差有两个组成部分：来自模型的方差 σ^2 和来自 θ 后验不确定性的方差 τ_1^2。

6.3. 多观测的正态模型. 上述单观测正态模型可以轻松推广到更现实的情况：$y = (y_1, \ldots, y_n)$ 是来自一元正态分布的 n 个独立同分布观测。

因为 $\bar{y}|\theta \sim \text{Normal}(\theta, \sigma^2/n)$，对单观测推导的结果直接适用（将 $\bar{y}$ 视为单观测）：

$$\theta|y_1, \ldots, y_n \sim \text{Normal}(\mu_n, \tau_n^2)$$

其中：

$$\mu_n = \frac{\mu_0/\tau_0^2 + n\bar{y}/\sigma^2}{1/\tau_0^2 + n/\sigma^2}, \quad \frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$$

7. 非信息先验分布

当先验分布没有总体基础时，很难构建，长期以来人们渴望得到保证在后验分布中作用最小的先验分布。

这类分布有时称为参考先验分布，先验密度被称为模糊、平坦、扩散或非信息的。

使用非信息先验的理由通常是”让数据自己说话”，使推断不受当前数据外部信息的影响。

一个相关想法是弱信息先验分布，它包含一些信息——足以正则化后验分布（即保持它在合理范围内），但不试图完全捕捉关于底层参数的科学知识。

7.1. 正常与非正常先验. 如果先验精度 $1/\tau_0^2$ 相对于数据精度 n/σ^2 很小，则后验分布近似于 $\tau_0^2 = \infty$ 的情况：

$$p(\theta|y) \approx \text{Normal}(\bar{y}, \sigma^2/n)$$

换句话说，后验分布近似于假设 $p(\theta)$ 与常数成正比的情况。这种分布实际上不可能，因为 $p(\theta)$ 的积分是无穷大，违反了概率总和为 1 的假设。

定义 2.3. 如果先验密度 $p(\theta)$ 不依赖于数据且积分等于 1，则称为正常（proper）先验。

如果 $p(\theta)$ 积分到任何正有限值，称为非归一化密度，可以重新归一化（乘以常数）使其积分到 1。

如果积分不是有限的，称为非正常（improper）先验。

非正常先验可能导致正常后验分布。使用非正常先验得到的后验分布必须非常小心解释——必须始终检查后验分布的积分是有限的且形式合理。

8. Jeffreys 不变性原则

一种有时用于定义非信息先验的方法是由 Jeffreys 提出的，基于考虑参数的一一变换：$\phi = h(\theta)$。

Jeffreys 的一般原则是：任何确定先验密度 $p(\theta)$ 的规则，如果应用于变换后的参数，应该产生等价的结果。

Jeffreys 先验定义为：

$$p(\theta) \propto [J(\theta)]^{1/2}$$

其中 $J(\theta)$ 是 θ 的 Fisher 信息：

$$J(\theta) = -E\left[\frac{d^2 \log p(y|\theta)}{d\theta^2}\right]$$

对于二项模型，Jeffreys 先验是 $p(\theta) \propto \theta^{-1/2}(1-\theta)^{-1/2}$，即 $\text{Beta}(1/2, 1/2)$。

注 2.3. 注意：均匀先验在参数变换下不是不变的——θ 上的均匀先验在 $\log(\theta/(1-\theta))$ 上不是均匀的。这曾是 20 世纪初对贝叶斯推断的主要批评之一，直到 Jeffreys 在世纪中叶复兴了这一主题。

9. 弱信息先验分布

弱信息先验是比非信息先验更强的正则化，但仍然比完全信息先验弱得多。它们用于在数据有限时稳定计算，同时允许数据主导推断。

10. 本章小结

本章我们学习了：

(1) 二项模型的贝叶斯推断：Beta-Binomial 共轭
(2) 后验作为数据与先验信息的折中
(3) 后验推断的汇总：点估计（均值、中位数、众数）和区间估计
(4) 最高后验密度区间（HPD）
(5) 信息先验与共轭先验
(6) 正态均值估计（已知方差）
(7) 非信息先验与 Jeffreys 先验
(8) 弱信息先验
(9) 正常与非正常先验

11. 下节预告

下一章我们将学习多参数模型，包括如何处理 nuisance 参数和正态模型中均值与方差同时未知的情况。

CHAPTER 3

多参数模型简介

1. 本章导论

在前一章中，我们学习了单参数模型的贝叶斯推断。然而，现实中的统计问题通常涉及多个参数。本章将介绍处理多参数模型的基本思想，包括如何对"nuisance 参数" 进行积分处理，以及正态模型中均值和方差同时未知时的经典分析。

2. 对 Nuisance 参数的积分

为了表达联合后验分布和边际后验分布的思想，假设 θ 有两部分，每部分都可以是向量：$\theta = (\theta_1, \theta_2)$。进一步假设我们只（至少目前只）对 θ_1 的推断感兴趣，因此 θ_2 可以被视为 nuisance 参数。

例如，在简单例子 $y|\mu, \sigma^2 \sim \text{Normal}(\mu, \sigma^2)$ 中，$\mu = \theta_1$ 和 $\sigma^2 = \theta_2$ 都未知，但通常我们最关心的是 μ。

我们寻求给定观测数据的参数条件分布，即 $p(\theta_1|y)$。这从联合后验密度

$$p(\theta_1, \theta_2|y) \propto p(y|\theta_1, \theta_2) \times p(\theta_1, \theta_2)$$

通过对 θ_2 积分得到：

$$p(\theta_1|y) = \int p(\theta_1, \theta_2|y)\, d\theta_2$$

另一种分解方式是：

$$p(\theta_1|y) = \int p(\theta_1|\theta_2, y) \times p(\theta_2|y)\, d\theta_2$$

它表明：感兴趣的后验分布 $p(\theta_1|y)$ 是给定 nuisance 参数 θ_2 的条件后验分布的混合，其中 $p(\theta_2|y)$ 是对 θ_2 不同值的加权函数。

权重依赖于 θ_2 的后验密度，因此依赖于数据和先验模型的组合。

对 nuisance 参数 θ_2 的积分可以一般性地解释。例如，θ_2 可以包括代表不同可能子模型的离散成分。

注 3.1. 我们很少直接计算积分，但它暗示了构建和计算多参数模型的重要策略：后验分布可以通过边际和条件模拟来计算，首先从边际后验分布抽取 θ_2，然后在给定 θ_2 值的条件下从条件后验分布抽取 θ_1。通过这种方式，积分被间接执行。

这种分析形式的典型例子是正态模型中均值和方差都未知的情况。

3. 正态数据与非信息先验

作为从样本估计总体均值的原型例子，我们考虑来自一元正态分布 $\text{Normal}(\mu, \sigma^2)$ 的 n 个独立观测 $y = (y_1, \ldots, y_n$。

我们首先在非信息先验分布下分析这个模型，理解这只是为了阐述的方便假设，很容易推广到信息先验。

3.1. 非信息先验分布. 对于 μ 和 σ^2 一个合理的模糊先验密度，假设位置参数和尺度参数的先验独立，是在 $(\mu, \log\sigma^2)$ 上均匀，即：

$$p(\mu, \sigma^2) \propto (\sigma^2)^{-1}$$

在这种约定的非正常先验密度下，联合后验分布为：

$$p(\mu, \sigma^2|y) \propto (\sigma^2)^{-(n/2+1)} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\mu)^2\right)$$

后续推导需要用到学生 t 分布等，详见教材。

4. 正态数据与共轭先验

当使用共轭先验时，多参数正态模型的计算更加直接。详见教材中的 Normal-Wishart 分布等。

5. 分类数据的多项模型

多项模型用于分类数据，是二项模型在多于两个类别时的推广。

6. 已知方差的多元正态模型

当方差矩阵已知时，多元正态模型的推断相对简单。

7. 均值和方差都未知的多元正态模型

这是更复杂的情况，需要用到逆 Wishart 分布等。

8. 生物测定实验例子

Bioassay 实验是药物效力评估的经典例子。

9. 本章小结

本章我们学习了：

(1) 如何对 nuisance 参数进行积分（边际化和条件化）
(2) 多参数模型的计算策略：边际和条件模拟
(3) 正态模型中均值和方差同时未知时的分析
(4) 非信息先验和共轭先验在多参数情况下的应用

10. 下节预告

下一章我们将学习渐近性以及贝叶斯方法与其他统计方法的联系。

CHAPTER 4

渐近性与非贝叶斯方法的联系

1. 本章导论

2. 后验分布的正态近似

3. 大样本理论

4. 定理的反例

5. 贝叶斯推断的频率评估

6. 其他统计方法的贝叶斯解释

7. 本章小结

CHAPTER 5

分层模型

1. 本章导论

2. 主要内容

3. 本章小结

Part 2

贝叶斯数据分析基础

CHAPTER 6

模型检查

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 7

模型评估、比较与扩展

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 8

考虑数据收集过程的建模

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 9

决策分析

1. 本章导论

2. 主要内容

3. 本章小结

Part 3

高级计算方法

CHAPTER 10

贝叶斯计算入门

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 11

马尔可夫链模拟基础

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 12

高效马尔可夫链模拟

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 13

模态与分布近似

1. 本章导论

2. 主要内容

3. 本章小结

Part 4

回归模型

CHAPTER 14

回归模型入门

1. 本章导论
2. 主要内容
3. 本章小结

CHAPTER 15

分层线性模型

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 16

广义线性模型

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 17

稳健推断模型

1. 本章导论

2. 稳健性的各个方面

3. 标准概率模型的过度分散版本

4. 后验推断与计算

5. 八校例子中的稳健推断与敏感性分析

6. 使用 t 分布误差的稳健回归

7. 本章小结

CHAPTER 18

缺失数据模型

1. 本章导论
2. 主要内容
3. 本章小结

Part 5

非参数模型

CHAPTER 19

参数非线性模型

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 20

基函数模型

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 21

高斯过程模型

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 22

有限混合模型

1. 本章导论

2. 主要内容

3. 本章小结

CHAPTER 23

狄利克雷过程模型

1. 本章导论

2. 主要内容

3. 本章小结

APPENDIX A

问答与注解

1. 阅读过程中的问题与解答

暂无记录. 当你在阅读过程中提出问题时，回答将被记录在此处。

2. 学习笔记

在这里记录你的学习心得和思考。