

APPENDIX A

公式推导

1. 概率与推断 (Chapter 1) 推导

1.1. 贝叶斯定理的推导. 背景 (Background): 贝叶斯定理是概率论中最基本的公式之一, 它描述了如何根据新的证据更新概率估计。这个推导基于条件概率的定义和基本运算规则。

参数定义 (Parameter Definitions):

- A : 某个事件
- B : 另一个事件 (通常代表观测数据或证据)
- $p(A)$: 事件 A 的先验概率 (prior probability)
- $p(A|B)$: 在事件 B 发生的条件下, 事件 A 的后验概率 (posterior probability)
- $p(B|A)$: 在事件 A 发生的条件下, 事件 B 的似然 (likelihood)
- $p(B)$: 事件 B 的边际概率 (marginal probability)

已知条件 (Given):

- 条件概率定义: $p(A|B) = \frac{p(A \cap B)}{p(B)}$, 其中 $p(B) > 0$
- 乘法法则: $p(A \cap B) = p(A) \cdot p(B|A) = p(B) \cdot p(A|B)$

目标 (Goal): 从条件概率的基本定义推导出贝叶斯定理:

$$p(A|B) = \frac{p(A) \cdot p(B|A)}{p(B)}$$

推导步骤 (Derivation Steps):

步骤 1: 从条件概率定义出发

$$p(A|B) = \frac{p(A \cap B)}{p(B)}$$

步骤 2: 用乘法法则替换联合概率 $p(A \cap B)$

$$p(A \cap B) = p(A) \cdot p(B|A)$$

步骤 3: 将步骤 2 代入步骤 1

$$p(A|B) = \frac{p(A) \cdot p(B|A)}{p(B)}$$

步骤 4: 对 $p(B)$ 进行边际化 (如果 $A_1, A_2, \dots, A_k$ 是互斥且完备的事件族)

$$p(B) = \sum_{i=1}^k p(A_i) \cdot p(B|A_i)$$

步骤 5: 将步骤 4 代入贝叶斯定理的分母，得到完整形式

$$p(A_j|B) = \frac{p(A_j) \cdot p(B|A_j)}{\sum_{i=1}^k p(A_i) \cdot p(B|A_i)}$$

结论: 贝叶斯定理建立了先验概率与后验概率之间的桥梁——我们通过似然 $p(B|A)$ 将新的观测 B 与先验知识 $p(A)$ 结合起来。

1.2. 先验预测分布与后验预测分布的推导. 背景 (Background): 在贝叶斯统计中, 我们不仅要推断当前参数 θ 的后验分布, 还需要预测未来观测 $\tilde{y}$ 的分布。这涉及对未知参数进行积分 (边际化)。

参数定义 (Parameter Definitions):

- θ : 不可观测的参数
- y : 已观测的数据
- $\tilde{y}$: 未来或未观测的数据
- $p(\theta)$: 参数的先验分布
- $p(y|\theta)$: 数据的似然函数
- $p(\theta|y)$: 参数的后验分布

已知条件 (Given):

- 贝叶斯定理: $p(\theta|y) \propto p(\theta) \cdot p(y|\theta)$
- 边际概率定义: $p(y) = \int p(\theta) \cdot p(y|\theta) d\theta$
- 条件独立性: 给定 θ , 未来观测 $\tilde{y}$ 与当前观测 y 条件独立

目标 (Goal):

- (1) 推导先验预测分布 $p(y)$
- (2) 推导后验预测分布 $p(\tilde{y}|y)$

推导步骤 (Derivation Steps):

先验预测分布的推导. **步骤 1:** 从边际概率的定义出发

$$p(y) = \int p(\theta) \cdot p(y|\theta) d\theta$$

步骤 2: 解释其含义——这是对所有可能的 θ 值加权平均, 其中权重是先验概率

步骤 3: 先验预测分布表示在我们观测数据之前, 所有可能观测结果的分布

后验预测分布的推导. **步骤 1:** 从条件概率定义出发

$$p(\tilde{y}|y) = \int p(\tilde{y}, \theta|y) d\theta$$

步骤 2: 将联合分布分解

$$p(\tilde{y}, \theta|y) = p(\tilde{y}|\theta, y) \cdot p(\theta|y)$$

步骤 3: 利用条件独立性假设 (给定 θ , $\tilde{y}$ 与 y 独立)

$$p(\tilde{y}|\theta, y) = p(\tilde{y}|\theta)$$

步骤 4: 代入得

$$p(\tilde{y}|y) = \int p(\tilde{y}|\theta) \cdot p(\theta|y) d\theta$$

结论: 后验预测分布是在**参数后验分布上对条件预测进行平均**。这体现了贝叶斯推断的核心思想: 不确定性在两个层次上都存在 (参数的不确定性和预测的随机性), 我们需要对两者都进行边际化。

1.3. 后验优势比的推导. 背景 (Background): 优势比 (odds ratio) 是概率的另一种表示方式, 在许多应用场景下比概率更直观。贝叶斯定理在优势比形式下有一个特别简洁的表达。

参数定义 (Parameter Definitions):

- θ_1 : 某个参数值
- θ_2 : 另一个参数值
- $p(\theta_1)$: θ_1 的先验概率
- $p(\theta_1|y)$: θ_1 的后验概率
- $p(y|\theta_1)$: 似然函数在 θ_1 处的值
- $O(\theta_1, \theta_2) = \frac{p(\theta_1)}{p(\theta_2)}$: 先验优势比
- $O(\theta_1, \theta_2|y) = \frac{p(\theta_1|y)}{p(\theta_2|y)}$: 后验优势比

已知条件 (Given): 贝叶斯定理:

$$p(\theta|y) = \frac{p(\theta) \cdot p(y|\theta)}{p(y)}$$

目标 (Goal): 证明后验优势比 = 先验优势比 $\times$ 似然比

推导步骤 (Derivation Steps):

步骤 1: 写出后验优势比的定义

$$O(\theta_1, \theta_2|y) = \frac{p(\theta_1|y)}{p(\theta_2|y)}$$

步骤 2: 对分子和分母分别应用贝叶斯定理

$$\begin{aligned} & \frac{p(\theta_1) \cdot p(y|\theta_1)}{p(y)} \\ &= \frac{\frac{p(\theta_1) \cdot p(y|\theta_1)}{p(y)}}{\frac{p(\theta_2) \cdot p(y|\theta_2)}{p(y)}} \end{aligned}$$

步骤 3: 约去 $p(y)$

$$= \frac{p(\theta_1) \cdot p(y|\theta_1)}{p(\theta_2) \cdot p(y|\theta_2)}$$

步骤 4: 重新组合

$$= \frac{p(\theta_1)}{p(\theta_2)} \times \frac{p(y|\theta_1)}{p(y|\theta_2)}$$

结论: 这个简洁的关系式告诉我们, **后验优势比 = 先验优势比 $\times$ 似然比**。数据通过似然比来更新优势比——如果 $p(y|\theta_1) > p(y|\theta_2)$, 则数据支持 θ_1 , 后验优势比增大。

2. 单参数模型 (Chapter 2) 推导

2.1. Beta-Binomial 共轭后验分布推导. 背景 (Background): 在二项模型中, 如果我们使用 Beta 先验分布来估计成功概率 θ , 则后验分布也是 Beta 分布。这种性质称为共轭性, 是贝叶斯统计中最重要的概念之一。

参数定义 (Parameter Definitions):

- n : 伯努利试验的总次数
- y : n 次试验中成功的次数
- θ : 每次试验的成功概率 (未知参数)
- α : Beta 先验的第一个参数
- β : Beta 先验的第二个参数
- $p(y|\theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y}$: 二项似然函数
- $p(\theta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}$: Beta 先验

已知条件 (Given):

- Beta 函数定义: $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$
- 似然函数: $p(y|\theta) \propto \theta^y (1-\theta)^{n-y}$ (忽略不依赖 θ 的常数 $\binom{n}{y}$)
- 先验分布: $p(\theta) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1}$

目标 (Goal): 证明后验分布 $p(\theta|y)$ 也是 Beta 分布, 并确定其后验参数。

推导步骤 (Derivation Steps):

步骤 1: 应用贝叶斯定理写出非归一化后验分布

$$p(\theta|y) \propto p(\theta) \cdot p(y|\theta)$$

步骤 2: 代入先验和似然

$$p(\theta|y) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1} \cdot \theta^y (1-\theta)^{n-y}$$

步骤 3: 合并同底数指数

$$= \theta^{(\alpha-1)+y} \cdot (1-\theta)^{(\beta-1)+(n-y)} = \theta^{\alpha+y-1} \cdot (1-\theta)^{\beta+n-y-1}$$

步骤 4: 识别分布形式这正是 Beta 分布的核 (kernel), 即

$$p(\theta|y) \propto \theta^{\alpha_{\text{post}}-1} (1-\theta)^{\beta_{\text{post}}-1}$$

其中

$$\alpha_{\text{post}} = \alpha + y, \quad \beta_{\text{post}} = \beta + n - y$$

步骤 5: 写出完整的后验分布

$$\theta|y \sim \text{Beta}(\alpha + y, \beta + n - y)$$

结论: 后验分布与先验分布属于同一形式 (Beta 分布), 这就是共轭性。先验参数 α 可以解释为 $\alpha - 1$ 次“先验成功”, β 解释为 $\beta - 1$ 次“先验失败”。

2.2. Beta-Binomial 后验均值与方差推导. 背景 (Background): 在共轭框架下, 我们可以推导出后验分布的均值和方差的闭式表达式。这些表达式展示了先验信息与数据信息如何”折中”。

参数定义 (Parameter Definitions):

- $\alpha_{\text{post}} = \alpha + y$: 后验第一个参数
- $\beta_{\text{post}} = \beta + n - y$: 后验第二个参数
- $\mathbb{E}(\theta|y)$: 后验均值
- $\text{Var}(\theta|y)$: 后验方差

已知条件 (Given):

- 后验分布: $\theta|y \sim \text{Beta}(\alpha_{\text{post}}, \beta_{\text{post}})$
- Beta 分布均值公式: $\mathbb{E}(X) = \frac{\alpha}{\alpha + \beta}$, 其中 $X \sim \text{Beta}(\alpha, \beta)$
- Beta 分布方差公式: $\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$

目标 (Goal):

- (1) 求后验均值 $\mathbb{E}(\theta|y)$
- (2) 求后验方差 $\text{Var}(\theta|y)$

后验均值推导. **步骤 1:** 应用 Beta 分布均值公式

$$\mathbb{E}(\theta|y) = \frac{\alpha_{\text{post}}}{\alpha_{\text{post}} + \beta_{\text{post}}}$$

步骤 2: 代入后验参数

$$= \frac{\alpha + y}{\alpha + y + \beta + n - y} = \frac{\alpha + y}{\alpha + \beta + n}$$

步骤 3: 改写为加权平均形式

$$= \frac{\alpha + y}{\alpha + \beta + n} = \frac{\alpha + \beta}{\alpha + \beta + n} \cdot \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \cdot \frac{y}{n}$$

结论 1: 后验均值是先验均值 $\frac{\alpha}{\alpha + \beta}$ 和样本比例 $\frac{y}{n}$ 的加权平均, 权重与样本量和先验强度相关。

后验方差推导. **步骤 1:** 应用 Beta 分布方差公式

$$\text{Var}(\theta|y) = \frac{\alpha_{\text{post}} \cdot \beta_{\text{post}}}{(\alpha_{\text{post}} + \beta_{\text{post}})^2 (\alpha_{\text{post}} + \beta_{\text{post}} + 1)}$$

步骤 2: 代入后验参数

$$= \frac{(\alpha + y)(\beta + n - y)}{(\alpha + \beta + n)^2 (\alpha + \beta + n + 1)}$$

步骤 3: 大样本近似 (当 y 和 $n - y$ 较大时) 当 n 很大而 α, β 固定时,

$$\text{Var}(\theta|y) \approx \frac{1}{n} \cdot \frac{y}{n} \left(1 - \frac{y}{n}\right)$$

结论 2: 后验方差以 $1/n$ 的速率趋近于零, 表明随着样本量增大, 后验分布越来越集中在真值附近。

2.3. 拉普拉斯继承法则推导. 背景 (Background): 拉普拉斯在 18 世纪研究”明天太阳会升起”这类问题时, 提出了一个著名的法则。在均匀先验下, 这个法则预测未来成功的概率为 $\frac{y+1}{n+2}$ 。

参数定义 (Parameter Definitions):

- n : 已完成的试验次数
- y : 成功的次数
- $\tilde{y}$: 下一次试验的结果 ($\tilde{y} = 1$ 表示成功)
- θ : 成功概率
- $p(\theta|y) = \text{Beta}(y+1, n-y+1)$: 均匀先验下的后验分布

已知条件 (Given):

- 均匀先验: $\theta \sim \text{Uniform}(0, 1) = \text{Beta}(1, 1)$
- 后验分布: $\theta|y \sim \text{Beta}(y+1, n-y+1)$
- 后验预测分布: $p(\tilde{y} = 1|y) = \int_0^1 \theta \cdot p(\theta|y) d\theta$

目标 (Goal): 求下一次试验成功的概率 $p(\tilde{y} = 1|y)$ 。

推导步骤 (Derivation Steps):

步骤 1: 写出后验预测分布的定义

$$p(\tilde{y} = 1|y) = \int_0^1 p(\tilde{y} = 1|\theta) \cdot p(\theta|y) d\theta$$

步骤 2: 代入 $p(\tilde{y} = 1|\theta) = \theta$ (给定 θ , 成功的条件概率就是 θ)

$$= \int_0^1 \theta \cdot p(\theta|y) d\theta = \mathbb{E}(\theta|y)$$

步骤 3: 识别这是后验均值

$$= \mathbb{E}(\theta|y)$$

步骤 4: 应用 Beta 分布均值公式

$$= \frac{y+1}{(y+1) + (n-y+1)} = \frac{y+1}{n+2}$$

结论: 拉普拉斯继承法则表明, 在均匀先验下, 已知 n 次试验中 y 次成功, 下一次成功的概率是 $\frac{y+1}{n+2}$ 。这推广了”瑞士表匠”问题的直觉——即使观测到 n 次成功, 概率也不是 1 (因为 θ 本身可能是变化的)。

2.4. 总期望与总方差公式推导. 背景 (Background): 全期望公式和全方差公式是概率论中的两个基本恒等式, 它们描述了如何通过条件分布来计算无条件矩。

参数定义 (Parameter Definitions):

- θ : 随机变量 (参数)
- y : 随机变量 (数据)
- $\mathbb{E}(\theta)$: θ 的无条件 (先验) 均值
- $\text{Var}(\theta)$: θ 的无条件 (先验) 方差
- $\mathbb{E}(\theta|y)$: 给定 y 后 θ 的条件均值
- $\text{Var}(\theta|y)$: 给定 y 后 θ 的条件方差

已知条件 (Given):

- 条件期望定义: $\mathbb{E}(\theta|y)$ 是 y 的函数
- 迭代期望法则: $\mathbb{E}[\mathbb{E}(\theta|y)] = \mathbb{E}(\theta)$

目标 (Goal):

- (1) 证明全期望公式: $\mathbb{E}(\theta) = \mathbb{E}[\mathbb{E}(\theta|y)]$
- (2) 证明全方差公式: $\text{Var}(\theta) = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$

全期望公式推导. **步骤 1**: 从条件期望的定义出发

$$\mathbb{E}[\mathbb{E}(\theta|y)] = \int \mathbb{E}(\theta|y) \cdot p(y) dy$$

步骤 2: 代入条件期望 $\mathbb{E}(\theta|y) = \int \theta \cdot p(\theta|y) d\theta$

$$= \int \left(\int \theta \cdot p(\theta|y) d\theta \right) p(y) dy$$

步骤 3: 交换积分次序 (由富比尼定理保证)

$$= \int \theta \left(\int p(\theta|y)p(y) dy \right) d\theta$$

步骤 4: 识别内层积分 $p(\theta) = \int p(\theta|y)p(y)dy$ (全概率)

$$= \int \theta \cdot p(\theta) d\theta = \mathbb{E}(\theta)$$

结论 1: 全期望公式表明, θ 的先验均值等于在所有可能数据上后验均值的加权平均。

全方差公式推导. **步骤 1:** 从方差定义出发

$$\text{Var}(\theta) = \mathbb{E}(\theta^2) - [\mathbb{E}(\theta)]^2$$

步骤 2: 对 $\mathbb{E}(\theta^2)$ 应用全期望公式

$$\mathbb{E}(\theta^2) = \mathbb{E}[\mathbb{E}(\theta^2|y)]$$

步骤 3: 在给定 y 的条件下, 方差可以写为

$$\text{Var}(\theta|y) = \mathbb{E}(\theta^2|y) - [\mathbb{E}(\theta|y)]^2$$

步骤 4: 解出 $\mathbb{E}(\theta^2|y)$

$$\mathbb{E}(\theta^2|y) = \text{Var}(\theta|y) + [\mathbb{E}(\theta|y)]^2$$

步骤 5: 代入步骤 2

$$\mathbb{E}(\theta^2) = \mathbb{E}[\text{Var}(\theta|y)] + \mathbb{E}[\mathbb{E}(\theta|y)]^2$$

步骤 6: 对 $[\mathbb{E}(\theta|y)]^2$ 应用方差分解

$$\mathbb{E}[\mathbb{E}(\theta|y)]^2 = \text{Var}[\mathbb{E}(\theta|y)] + \{\mathbb{E}[\mathbb{E}(\theta|y)]\}^2$$

步骤 7: 代入全期望公式的结果 $\mathbb{E}[\mathbb{E}(\theta|y)] = \mathbb{E}(\theta)$

$$= \text{Var}[\mathbb{E}(\theta|y)] + [\mathbb{E}(\theta)]^2$$

步骤 8: 代回方差的定义

$$\text{Var}(\theta) = \mathbb{E}(\theta^2) - [\mathbb{E}(\theta)]^2 = \mathbb{E}[\text{Var}(\theta|y)] + \text{Var}[\mathbb{E}(\theta|y)]$$

结论 2: 全方差公式表明, **总方差 = 条件方差的均值 + 条件均值的方差**。这在贝叶斯语境下的解释是: 参数的总不确定性来自两个方面——(1) 给定数据后参数仍有的剩余不确定性 (条件方差的均值), 以及 (2) 后验均值随数据变化的不确定性 (条件均值的方差)。

2.5. 正态均值估计的后验分布推导. 背景 (Background): 当我们用正态似然估计正态均值时, 如果使用正态先验, 则后验分布也是正态分布。这个推导展示了共轭先验在正态模型中的应用。

参数定义 (Parameter Definitions):

- $y \sim \text{Normal}(\theta, \sigma^2)$: 观测数据 (已知方差 σ^2)
- $\theta \sim \text{Normal}(\mu_0, \tau_0^2)$: 正态先验
- μ_0 : 先验均值
- τ_0^2 : 先验方差
- σ^2 : 已知的观测方差
- μ_1, τ_1^2 : 后验均值和方差

已知条件 (Given):

- 似然函数: $p(y|\theta) \propto \exp\left(-\frac{(y-\theta)^2}{2\sigma^2}\right)$
- 先验密度: $p(\theta) \propto \exp\left(-\frac{(\theta-\mu_0)^2}{2\tau_0^2}\right)$
- 配方法 (completing the square) 技巧

目标 (Goal): 证明后验分布 $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$, 并求出 μ_1 和 τ_1^2 。

推导步骤 (Derivation Steps):

步骤 1: 写出非归一化后验分布的对数

$$\log p(\theta|y) \propto \log p(\theta) + \log p(y|\theta)$$

步骤 2: 代入先验和似然的对数

$$= -\frac{(\theta - \mu_0)^2}{2\tau_0^2} - \frac{(y - \theta)^2}{2\sigma^2}$$

步骤 3: 展开平方项

$$= -\frac{1}{2} \left[\frac{(\theta^2 - 2\mu_0\theta + \mu_0^2)}{\tau_0^2} + \frac{(\theta^2 - 2y\theta + y^2)}{\sigma^2} \right]$$

步骤 4: 合并 θ^2 项的系数

$$= -\frac{1}{2} \left[\theta^2 \left(\frac{1}{\tau_0^2} + \frac{1}{\sigma^2} \right) - 2\theta \left(\frac{\mu_0}{\tau_0^2} + \frac{y}{\sigma^2} \right) + \text{常数} \right]$$

步骤 5: 识别后验精度 (方差的倒数)

$$\frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

步骤 6: 由配方法, 后验均值满足

$$\theta \cdot \frac{1}{\tau_1^2} = \frac{\mu_0}{\tau_0^2} + \frac{y}{\sigma^2}$$

步骤 7: 解出后验均值

$$\mu_1 = \frac{\mu_0/\tau_0^2 + y/\sigma^2}{1/\tau_0^2 + 1/\sigma^2}$$

步骤 8: 写出完整的后验分布

$$\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$$

结论:

- (1) **精度加法**: 后验精度 = 先验精度 + 数据精度
- (2) **后验均值**: 是先验均值 μ_0 和观测值 y 的加权平均, 权重与精度成正比

2.6. Jeffreys 先验与 Fisher 信息推导. 背景 (Background): Jeffreys 提出了一种构建非信息先验的系统方法, 基于 Fisher 信息的不变性原则。这个先验在参数的单调变换下保持不变。

参数定义 (Parameter Definitions):

- θ : 参数
- $p(y|\theta)$: 似然函数
- $J(\theta)$: Fisher 信息
- $L(\theta) = \log p(y|\theta)$: 对数似然
- $I(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \right]$: Fisher 信息 (另一种定义)
- $\phi = h(\theta)$: 参数的单调变换

已知条件 (Given):

- Jeffreys 原则: 先验应在参数的单调变换下保持不变
- Fisher 信息定义: $J(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \right]$
- 变换公式: $p(\phi) = p(\theta) \cdot \left| \frac{d\theta}{d\phi} \right|$

目标 (Goal): 推导 Jeffreys 先验公式并验证其在变换下的不变性。

推导步骤 (Derivation Steps):

Jeffreys 先验公式推导. 步骤 1: Jeffreys 提出先验正比于 Fisher 信息的平方根

$$p(\theta) \propto [J(\theta)]^{1/2}$$

步骤 2: 验证在变换 $\phi = h(\theta)$ 下的不变性

在新参数 ϕ 下, Fisher 信息为

$$J(\phi) = -\mathbb{E} \left[\frac{\partial^2 \log p(y|\phi)}{\partial \phi^2} \right]$$

步骤 3: 利用链式法则

$$\frac{\partial \log p(y|\theta)}{\partial \phi} = \frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d\theta}{d\phi}$$

步骤 4: 计算二阶导数

$$\frac{\partial^2 \log p(y|\theta)}{\partial \phi^2} = \frac{\partial}{\partial \phi} \left(\frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d\theta}{d\phi} \right) = \frac{\partial^2 \log p(y|\theta)}{\partial \theta^2} \left(\frac{d\theta}{d\phi} \right)^2 + \frac{\partial \log p(y|\theta)}{\partial \theta} \cdot \frac{d^2 \theta}{d\phi^2}$$

步骤 5: 取期望, 利用 $\mathbb{E} \left[\frac{\partial \log p(y|\theta)}{\partial \theta} \right] = 0$ (得分函数的期望为零)

$$J(\phi) = \left(\frac{d\theta}{d\phi} \right)^2 J(\theta)$$

步骤 6: 因此

$$[J(\phi)]^{1/2} = \left| \frac{d\theta}{d\phi} \right| [J(\theta)]^{1/2}$$

步骤 7: 新先验为

$$p(\phi) \propto [J(\phi)]^{1/2} \propto [J(\theta)]^{1/2} \left| \frac{d\theta}{d\phi} \right|$$

结论: 这正是概率密度在变量变换下的标准变换公式, 因此 Jeffreys 先验在单调变换下是不变的。

二项模型的 *Jeffreys* 先验推导. **步骤 1:** 写出二项模型的对数似然

$$\log p(y|\theta) = \log \binom{n}{y} + y \log \theta + (n - y) \log(1 - \theta)$$

步骤 2: 计算一阶导数 (得分函数)

$$\frac{\partial}{\partial \theta} \log p(y|\theta) = \frac{y}{\theta} - \frac{n - y}{1 - \theta}$$

步骤 3: 计算二阶导数

$$\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) = -\frac{y}{\theta^2} - \frac{n - y}{(1 - \theta)^2}$$

步骤 4: 取负期望 (注意 $\mathbb{E}(Y) = n\theta$)

$$J(\theta) = -\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) \right] = \frac{n\theta}{\theta^2} + \frac{n(1 - \theta)}{(1 - \theta)^2} = \frac{n}{\theta(1 - \theta)}$$

步骤 5: 应用 *Jeffreys* 公式

$$p(\theta) \propto \left[\frac{n}{\theta(1 - \theta)} \right]^{1/2} \propto \theta^{-1/2} (1 - \theta)^{-1/2}$$

步骤 6: 识别为 Beta 分布

$$p(\theta) \propto \theta^{(1/2)-1} (1 - \theta)^{(1/2)-1} \Rightarrow \theta \sim \text{Beta} \left(\frac{1}{2}, \frac{1}{2} \right)$$

结论: 二项模型的 *Jeffreys* 先验是 $\text{Beta}(1/2, 1/2)$, 这是一个弱信息先验, 比均匀先验 $\text{Beta}(1, 1)$ 在边界处更轻。

2.7. 后验预测分布的均值与方差推导. 背景 (Background): 后验预测分布 $\tilde{y}|y$ 的均值和方差有两个组成部分——一个来自模型本身的随机性, 另一个来自参数的后验不确定性。

参数定义 (Parameter Definitions):

- $\tilde{y}$: 未来观测
- y : 当前观测
- θ : 参数
- $\mathbb{E}(\tilde{y}|y)$: 后验预测均值
- $\text{Var}(\tilde{y}|y)$: 后验预测方差

已知条件 (Given):

- $\tilde{y}|\theta \sim \text{Normal}(\theta, \sigma^2)$
- $\theta|y \sim \text{Normal}(\mu_1, \tau_1^2)$
- 全期望公式: $\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$
- 全方差公式: $\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$

目标 (Goal): 求后验预测分布 $\tilde{y}|y$ 的均值和方差。

后验预测均值推导. **步骤 1**: 应用全期望公式

$$\mathbb{E}(\tilde{y}|y) = \mathbb{E}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 给定 θ , $\tilde{y}$ 与 y 条件独立, 且 $\mathbb{E}(\tilde{y}|\theta) = \theta$

$$= \mathbb{E}(\theta|y) = \mu_1$$

结论 1: 后验预测均值等于参数的后验均值。

后验预测方差推导. **步骤 1**: 应用全方差公式

$$\text{Var}(\tilde{y}|y) = \mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] + \text{Var}[\mathbb{E}(\tilde{y}|\theta, y)]$$

步骤 2: 第一项——给定 θ 下的方差是 σ^2 (模型方差)

$$\mathbb{E}[\text{Var}(\tilde{y}|\theta, y)] = \mathbb{E}(\sigma^2|y) = \sigma^2$$

步骤 3: 第二项——条件均值的方差

$$\text{Var}[\mathbb{E}(\tilde{y}|\theta, y)] = \text{Var}(\theta|y) = \tau_1^2$$

步骤 4: 合并

$$\text{Var}(\tilde{y}|y) = \sigma^2 + \tau_1^2$$

结论 2: 后验预测方差 = **模型方差** + **参数后验方差**。这体现了贝叶斯推断的核心: 预测的不确定性来自两个方面——(1) 模型本身的随机性 (σ^2), 以及 (2) 参数估计的不确定性 (τ_1^2)。

3. 拒绝抽样的正确性证明

背景 (Background): 拒绝抽样通过随机接受机制从目标分布中抽取样本。我们需要证明被接受的样本确实服从目标分布 $p(\theta)$ 。

参数定义 (Parameter Definitions):

- $p(\theta)$: 目标 (未归一化) 分布
- $g(\theta)$: 提议分布
- M : 覆盖常数, 满足 $p(\theta) \leq M \cdot g(\theta)$
- θ^* : 候选样本
- u^* : 从 $\text{Uniform}(0, 1)$ 抽取的随机数

目标 (Goal): 证明被接受的样本 θ_{accept} 服从目标分布 $p(\theta)$ 。

推导步骤 (Derivation Steps):

步骤 1: 写出接受的联合概率

$$\text{接受联合概率 } \mathbb{P}(\text{接受} \cap \theta^* \in d\theta) = \mathbb{P}(\theta^* \in d\theta) \cdot \mathbb{P}(\text{接受}|\theta^*) = g(\theta^*)d\theta \cdot \frac{p(\theta^*)}{Mg(\theta^*)} = \frac{p(\theta^*)}{M}d\theta$$

步骤 2: 计算总接受概率 (归一化常数)

$$\text{总接受概率 } \mathbb{P}(\text{接受}) = \int \frac{p(\theta^*)}{M}d\theta = \frac{1}{M}$$

步骤 3: 计算接受样本的条件分布

$$\text{条件分布} = \text{目标分布 } \mathbb{P}(\theta_{\text{accept}} \in d\theta | \text{接受}) = \frac{\mathbb{P}(\text{接受} \cap \theta^* \in d\theta)}{\mathbb{P}(\text{接受})} = \frac{p(\theta^*)/M}{1/M}d\theta = p(\theta^*)d\theta$$

结论: 被接受的样本的条件分布正是目标分布 $p(\theta)$ 。证明完毕。

3.1. 拒绝抽样期望接受率推导. 背景 (Background): 拒绝抽样的期望接受率是衡量算法效率的关键指标。

目标 (Goal): 推导期望接受率的公式。

推导步骤 (Derivation Steps):

步骤 1: 期望接受率定义为

期望定义
$$\text{accept rate} = \int \mathbb{P}(\text{接受}|\theta) \cdot g(\theta) d\theta$$

步骤 2: 代入接受概率

接受概率
$$\mathbb{P}(\text{接受}|\theta) = \min\left(1, \frac{p(\theta)}{Mg(\theta)}\right)$$

步骤 3: 于是

积分结果
$$\text{accept rate} = \int \min\left(\frac{p(\theta)}{Mg(\theta)}, 1\right) \cdot g(\theta) d\theta = \frac{1}{M} \int \min(p(\theta), Mg(\theta)) d\theta$$

步骤 4: 当覆盖条件 $Mg(\theta) \geq p(\theta)$ 对所有 θ 成立时

简化为 $1/M$
$$\text{accept rate} = \frac{1}{M} \int p(\theta) d\theta = \frac{1}{M}$$

结论: 期望接受率与 M 成反比, 选择尽可能小的 M 可提高接受率。

3.2. 细致平衡条件推导. 背景 (Background): 细致平衡是构造满足特定平稳分布的马尔可夫链的关键条件。

目标 (Goal): 证明如果转移核 P 满足细致平衡, 则其平稳分布就是 π 。

推导步骤 (Derivation Steps):

步骤 1: 写出细致平衡条件

细致平衡
$$P(\theta'|\theta) \cdot \pi(\theta) = P(\theta|\theta') \cdot \pi(\theta')$$

步骤 2: 验证 π 是平稳分布

平稳分布验证

$$\int P(\theta'|\theta) \cdot \pi(\theta) d\theta = \int P(\theta|\theta') \cdot \pi(\theta') d\theta = \pi(\theta') \int P(\theta|\theta') d\theta = \pi(\theta') \cdot 1 = \pi(\theta')$$

其中第三步用到 $\int P(\theta|\theta') d\theta = 1$ (转移核的归一化性)。

结论: 细致平衡是平稳分布的充分条件, 但不是必要条件。

3.3. Metropolis 算法细致平衡证明. 背景 (Background): Metropolis 算法的提议分布是对称的, 我们需要证明其满足细致平衡。

目标 (Goal): 证明 Metropolis 算法的转移核以目标分布 $p(\theta)$ 为平稳分布。

推导步骤 (Derivation Steps):

步骤 1: Metropolis 转移核

$$P(\theta'|\theta) = q(\theta'|\theta) \cdot \min\left(1, \frac{p(\theta')}{p(\theta)}\right)$$

其中 $q(\theta'|\theta) = q(\theta|\theta')$ (对称提议分布)。

步骤 2: 验证细致平衡

$$P(\theta'|\theta) \cdot p(\theta) = q(\theta'|\theta) \cdot \min\left(1, \frac{p(\theta')}{p(\theta)}\right) \cdot p(\theta)$$

分两种情况讨论:

情况 1: $p(\theta') \geq p(\theta)$

$$\text{右边} = q(\theta'|\theta) \cdot 1 \cdot p(\theta) = q(\theta'|\theta) \cdot p(\theta')$$

情况 2: $p(\theta') < p(\theta)$

$$\text{右边} = q(\theta'|\theta) \cdot \frac{p(\theta')}{p(\theta)} \cdot p(\theta) = q(\theta'|\theta) \cdot p(\theta')$$

由于 $q(\theta'|\theta) = q(\theta|\theta')$, 两种情况都满足

细致平衡成立 $P(\theta'|\theta) \cdot p(\theta) = P(\theta|\theta') \cdot p(\theta')$

结论: Metropolis 算法的平稳分布正是目标分布 $p(\theta)$ 。证明完毕。

3.4. Gibbs 抽样接受率推导. 背景 (Background): Gibbs 抽样是 Metropolis-Hastings 的特例, 其接受率恒为 1。我们来推导这个结论。

参数定义 (Parameter Definitions):

- $\theta = (\theta_1, \dots, \theta_d)$: 完整参数向量
- $\theta_{-j} = (\theta_1, \dots, \theta_{j-1}, \theta_{j+1}, \dots, \theta_d)$: 除 θ_j 外的所有参数
- $p^*(\theta)$: 未归一化的目标分布
- $q(\theta'_j|\theta_{-j}) = p(\theta'_j|\theta_{-j}, y)$: 提议分布 (条件分布)

目标 (Goal): 证明 Gibbs 抽样的接受率为 1。

推导步骤 (Derivation Steps):

步骤 1: 写出 MH 接受比

$$\text{MH 接受比} \quad r = \frac{p^*(\theta'_j, \theta_{-j})}{p^*(\theta_j, \theta_{-j})} \cdot \frac{q(\theta_j|\theta_{-j})}{q(\theta'_j|\theta_{-j})}$$

步骤 2: 代入 Gibbs 的提议分布

$$q(\theta_j|\theta_{-j}) = p(\theta_j|\theta_{-j}, y)$$

提议分布 = 条件分布

$$q(\theta'_j|\theta_{-j}) = p(\theta'_j|\theta_{-j}, y)$$

步骤 3: 利用链式法则分解联合分布

$$p^*(\theta'_j, \theta_{-j}) = p^*(\theta_{-j}) \cdot p^*(\theta'_j|\theta_{-j})$$

链式法则

$$p^*(\theta_j, \theta_{-j}) = p^*(\theta_{-j}) \cdot p^*(\theta_j|\theta_{-j})$$

步骤 4: 代入接受比

$$\text{代入} \quad r = \frac{p^*(\theta_{-j}) \cdot p^*(\theta'_j|\theta_{-j})}{p^*(\theta_{-j}) \cdot p^*(\theta_j|\theta_{-j})} \cdot \frac{p(\theta_j|\theta_{-j}, y)}{p(\theta'_j|\theta_{-j}, y)} = \frac{p^*(\theta'_j|\theta_{-j})}{p^*(\theta_j|\theta_{-j})} \cdot \frac{p(\theta_j|\theta_{-j}, y)}{p(\theta'_j|\theta_{-j}, y)}$$

步骤 5: 注意 $p^*(\theta_j|\theta_{-j}, y) \propto p(\theta_j|\theta_{-j}, y)$, 因为 $p^*(\theta_{-j})$ 不依赖于 θ_j 。于是两个因子互为倒数,

接受率为 1

$$r = 1$$

结论: Gibbs 抽样的提议分布恰好是条件分布, 因此接受率恒为 1, 无需拒绝。

3.5. 分层模型条件分布推导. 背景 (Background): 在分层模型 eq. (27) 中, 我们需要推导各个参数的条件后验分布。

模型回顾:

$$y_j|\theta_j \sim N(\theta_j, \sigma^2), \quad \theta_j|\mu, \tau \sim N(\mu, \tau^2)$$

其中 σ^2 已知。

目标 (Goal): 推导 $p(\theta_j|\mu, \tau, y)$ 、 $p(\mu|\theta, \tau, y)$ 和 $p(\tau|\theta, \mu, y)$ 。

$p(\theta_j|\mu, \tau, y)$ 推导. **步骤 1:** 写出条件分布的核

核
$$p(\theta_j|\mu, \tau, y) \propto p(y_j|\theta_j) \cdot p(\theta_j|\mu, \tau) \propto \exp\left(-\frac{(y_j - \theta_j)^2}{2\sigma^2}\right) \cdot \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 2: 合并指数

合并
$$= \exp\left(-\frac{(y_j - \theta_j)^2}{2\sigma^2} - \frac{(\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 3: 配方得到正态分布形式

配方
$$= \exp\left(-\frac{1}{2} \left[\frac{1}{\sigma^2} + \frac{1}{\tau^2}\right] \left(\theta_j - \frac{y_j/\sigma^2 + \mu/\tau^2}{1/\sigma^2 + 1/\tau^2}\right)^2\right)$$

因此

条件后验
$$\theta_j|\mu, \tau, y \sim N\left(\frac{y_j/\sigma^2 + \mu/\tau^2}{1/\sigma^2 + 1/\tau^2}, \left(\frac{1}{\sigma^2} + \frac{1}{\tau^2}\right)^{-1}\right)$$

$p(\mu|\theta, \tau, y)$ 推导. **步骤 1:** μ 的条件分布 (似然部分只依赖于 θ_j , 与 μ 通过 $\theta_j|\mu, \tau$ 连接)

先验部分
$$p(\mu|\theta, \tau) \propto p(\theta|\mu, \tau) = \prod_{j=1}^J \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right) \propto \exp\left(-\frac{\sum_j (\theta_j - \mu)^2}{2\tau^2}\right)$$

步骤 2: 展开平方

平方展开
$$\sum_j (\theta_j - \mu)^2 = \sum_j (\theta_j - \bar{\theta} + \bar{\theta} - \mu)^2 = \sum_j (\theta_j - \bar{\theta})^2 + J(\bar{\theta} - \mu)^2$$

步骤 3: 识别为正态核

正态核
$$p(\mu|\theta, \tau) \propto \exp\left(-\frac{J(\bar{\theta} - \mu)^2}{2\tau^2}\right)$$

因此

条件后验
$$\mu|\theta, \tau \sim N\left(\bar{\theta}, \frac{\tau^2}{J}\right)$$

其中 $\bar{\theta} = \frac{1}{J} \sum_j \theta_j$ 。

$p(\tau|\theta, \mu, y)$ 的非标准形式. **说明:**

$$\text{非标准形式} \quad p(\tau|\theta, \mu, y) \propto p(\theta|\mu, \tau) \cdot p(\tau) = \prod_{j=1}^J \frac{1}{\tau} \exp\left(-\frac{(\theta_j - \mu)^2}{2\tau^2}\right) \cdot p(\tau)$$

这个分布不是标准形式 (不是常见的正态、Gamma 等分布), 因此需要使用 Metropolis-Hastings 步骤来抽样。

结论: 在 Gibbs 抽样框架下, 对 τ 需要使用 MH 步骤, 这正是”混合 MCMC”的典型例子。

4. 阅读过程中的问题与解答

5. 什么是分布的核

5.1. 问题. 分布的核是什么概念?

5.2. 回答. 分布的核 (kernel) 是指概率密度/质量函数中依赖于参数的核心部分, 不包括归一化常数。

举例说明:

Beta-Binomial 共轭中, 后验分布:

$$p(\theta|y) \propto \theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$$

其中 $\theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$ 是核, 而完整的 Beta 分布还需要归一化常数:

$$p(\theta|y) = \frac{\Gamma(\alpha + \beta + n)}{\Gamma(\alpha + y)\Gamma(\beta + n - y)} \theta^{\alpha+y-1} (1-\theta)^{\beta+n-y-1}$$

为什么核重要:

- (1) **识别分布形式:** 知道核是 $\theta^a(1-\theta)^b$ 形式, 就能识别这是 Beta 分布
- (2) **贝叶斯推断中省略 $p(y)$:** $p(y)$ 是归一化常数, 不包含关于 θ 的信息, 所以可以省略
- (3) **简化推导:** 在推导过程中只关注核, 省去繁琐的归一化常数

Insight 这本质上是**信息局部性**思想: 归一化常数的作用只是”让面积等于 1”, 它本身不携带关于参数的信息。真正”有意义”的概率质量都集中在核上。

6. 学习笔记

在这里记录你的学习心得和思考。