

信息几何讲义

Shun-ichi Amari et al.

Contents

引言：文献概述	5
引言：文献概述	5
1. 总述	5
2. 文献摘要总结	5
3. 补充参考资料	11
4. 学习路径与前置基础知识	11
5. 最终目标	11
Part 1. 散度函数与对偶平坦黎曼结构	13
Part I: 散度函数与对偶平坦黎曼结构	14
6. Part I 概述	14
7. 核心概念	14
Chapter 1. 信息几何基础：散度与对偶平坦结构	15
1. 背景与动机	15
2. 核心定义	15
3. Fisher 信息与不变性	16
4. 对偶平坦结构	16
5. 与贝叶斯分析的关联	16
6. 关键概念一览	17
Appendix A. 问答与讨论	19
1. Part I 核心概念与贝叶斯关联	19

引言：文献概述

本学习资料旨在系统研究信息几何 (Information Geometry) 领域。信息几何是利用微分几何方法研究概率分布空间的几何结构的学科，为统计学、机器学习、热力学和量子力学等领域提供了统一的数学框架。

1. 总述

信息几何的核心思想是将概率分布族视为一个黎曼流形，利用几何方法来研究统计推断问题。这种观点起源于 Fisher 信息的研究，后来由 Rao、Cox、Amari 等学者发展为系统的几何理论。

本学习资料涵盖 24 篇文献，包括：

- 核心教材：Amari 的经典著作、Ay 等人的数学基础
- 非参数信息几何：Pistone 开创性工作
- Orlicz 空间理论：处理非参数情况的重要工具
- 应用方向：进化博弈、热力学、量子信息等

2. 文献摘要总结

本节按主题分类概述所有文献。

2.1. 一、核心教材.

2.1.1. *Information Geometry and Its Applications* — Shun-ichi Amari.

- (1) 作者: Shun-ichi Amari
- (2) 链接: <https://link.springer.com/book/978-4-431-55978-8>
- (3) 年份: 2016
- (4) 篇幅: 376 页
- (5) 核心贡献:
 - 建立信息几何的完整理论框架
 - 提出 α -联络族理论
 - 发展自然梯度下降在神经网络中的应用
 - 系统阐述指数族与混合族的几何结构
- (6) 摘要: 这是信息几何领域的奠基之作，由该领域创始人编写。内容涵盖概率分布空间的几何结构、Fisher 信息与 Cramér-Rao 下界、对偶平坦结构、统计学习中的几何方法等。
- (7) 关键词: Information Geometry; Fisher Information; α -Connections; Exponential Family; Natural Gradient

2.1.2. *Information Geometry* — Nihat Ay et al.

- (1) 作者: Nihat Ay, Jürgen Jost, Hông Vân Lê, Lorenz Schwachhofer
- (2) 链接: <https://link.springer.com/book/978-3-319-56478-4>
- (3) 年份: 2017
- (4) 篇幅: 300 页

(5) **核心贡献:**

- 提供信息几何的严格数学基础
- 研究非参数统计流形的几何结构
- 探讨函数空间几何在信息几何中的应用

(6) **摘要:** 侧重于信息几何的数学基础，是该领域重要的理论参考文献。

(7) **关键词:** Information Geometry; Statistical Manifold; Differential Geometry; Non-parametric

2.1.3. *Elements of Information Theory* — Cover & Thomas.

(1) **作者:** Thomas M. Cover, Joy A. Thomas

(2) **链接:** <https://onlinelibrary.wiley.com/book/10.1002/047174882X>

(3) **年份:** 2006 (第二版)

(4) **篇幅:** 748 页

(5) **核心贡献:**

- 建立信息论的完整理论体系
- 系统阐述熵、KL 散度、互信息等核心概念
- 为信息几何提供坚实的信息论基础

(6) **摘要:** 信息论经典教材 (GTM 134)，为理解信息几何中的 KL 散度等概念提供背景知识。

(7) **关键词:** Information Theory; Entropy; KL Divergence; Mutual Information

2.2. 二、非参数信息几何.

2.2.1. *Nonparametric Information Geometry* — Giovanni Pistone.

(1) **作者:** Giovanni Pistone

(2) **链接:** <https://arxiv.org/abs/1306.0480>

(3) **年份:** 2013

(4) **篇幅:** 25 页

(5) **核心贡献:**

- 开创非参数统计流形的微分几何结构研究
- 引入统计 bundle 概念
- 建立非参数情况下的几何理论框架

(6) **摘要:** 本文研究了给定测度空间上正密度集合的微分几何结构，奠定了非参数信息几何的基础。

(7) **关键词:** Nonparametric Information Geometry; Statistical Bundle; Exponential Orlicz Space

2.2.2. *A Lecture About the Use of Orlicz Spaces in Information Geometry* — Giovanni Pistone.

(1) **作者:** Giovanni Pistone

(2) **链接:** <https://arxiv.org/abs/2012.03376>

(3) **年份:** 2020

(4) **篇幅:** 18 页

(5) **核心贡献:**

- 介绍 Orlicz 空间在信息几何中的应用
- 涵盖指数 Orlicz 空间和 Gaussian Orlicz-Sobolev 空间
- 是 2020 年 Les Houches 暑期学校讲义

(6) **摘要:** 本教程介绍了 Orlicz 空间在非参数信息几何中的应用，包括统计 bundle、指数 Orlicz 空间等概念。

(7) **关键词:** Orlicz Spaces; Information Geometry; Nonparametric

2.2.3. *Connections on Non-Parametric Statistical Manifolds by Orlicz Space Geometry* —Gibilisco & Pistone.

(1) **作者:** Paolo Gibilisco, Giovanni Pistone

(2) **链接:** <https://doi.org/10.1142/S021902519800017X>

(3) **年份:** 1998

(4) **篇幅:** 23 页

(5) **核心贡献:**

- 利用 Orlicz 空间几何研究非参数统计流形上的联络
- 建立非参数信息几何的早期理论框架

(6) **摘要:** 早期经典工作, 研究非参数统计流形上的联络结构。

(7) **关键词:** Nonparametric Statistical Manifold; Orlicz Space; Connections

2.3. 三、Orlicz 空间理论.

2.3.1. *Quantum Orlicz Spaces in Information Geometry* —R.F. Streater.

(1) **作者:** R.F. Streater

(2) **链接:** <https://arxiv.org/abs/math-ph/0407046>

(3) **年份:** 2004

(4) **篇幅:** 14 页

(5) **核心贡献:**

- 建立量子 Orlicz 空间理论
- 将 Orlicz 空间概念推广到量子情况

(6) **摘要:** 研究自伴算子与量子 Orlicz 空间在量子信息几何中的应用。

(7) **关键词:** Quantum Information Geometry; Orlicz Space; Selfadjoint Operator

2.3.2. *On Musielak-Orlicz Function Spaces and Applications to Information Geometry* —Rui Facundo Vigelis (PhD).

(1) **作者:** Rui Facundo Vigelis

(2) **链接:** https://www.repositorio.ufc.br/bitstream/riufc/67158/1/2011_tese_rfvigelis.pdf

(3) **年份:** 2013

(4) **篇幅:** 150 页

(5) **核心贡献:**

- 系统研究 Musielak-Orlicz 函数空间
- 建立其在信息几何中的理论应用

(6) **摘要:** 博士学位论文, 全面研究 Musielak-Orlicz 函数空间及其在信息几何中的应用。

(7) **关键词:** Musielak-Orlicz Space; Information Geometry; Function Spaces

2.3.3. *New Results on Mixture and Exponential Models by Orlicz Spaces* —Santacroce, Siri, Trivellato.

(1) **作者:** Marina Santacroce, Paola Siri, Barbara Trivellato

(2) **链接:** <https://arxiv.org/abs/1603.05465>

(3) **年份:** 2016

(4) **篇幅:** 17 页

(5) **核心贡献:**

- 利用 Orlicz 空间方法研究混合模型和指数模型
- 给出新的几何结构分析

(6) **摘要:** 研究混合模型和指数模型的 Orlicz 空间方法。

(7) **关键词:** Mixture Models; Exponential Models; Orlicz Spaces

2.3.4. *On Köthe Duals of Orlicz-Lorentz Spaces* —Kamińska & Tag.

(1) **作者:** Anna Kamińska, Hyung-Joon Tag

(2) **链接:** <https://arxiv.org/abs/2404.07368>

(3) **年份:** 2024

(4) **篇幅:** 28 页

(5) **核心贡献:**

- 研究 Orlicz-Lorentz 空间的 Kothe 对偶
- 给出可分性的特征刻画

(6) **摘要:** 最新研究 Orlicz-Lorentz 空间的 Kothe 对偶性质。

(7) **关键词:** Orlicz-Lorentz Space; Kothe Dual; Separability

2.3.5. *When and Where the Orlicz and Luxemburg (quasi-) Norms are Equivalent?* —del Campo et al.

(1) **作者:** Ricardo del Campo, Antonio Fernández, et al.

(2) **链接:** <https://www.sciencedirect.com/science/article/pii/S0022247X20304649>

(3) **年份:** 2020

(4) **篇幅:** 18 页

(5) **核心贡献:**

- 讨论 Orlicz 范数与 Luxemburg 范数的等价性条件
- 给出等价性成立的充分必要条件

(6) **摘要:** 研究 Orlicz 和 Luxemburg 拟范数何时等价。

(7) **关键词:** Orlicz Norm; Luxemburg Norm; Equivalence

2.3.6. *Applications of Orlicz Spaces* —M.M. Rao & Z.D. Ren.

(1) **作者:** M.M. Rao, Z.D. Ren

(2) **链接:** <https://link.springer.com/book/978-0-8247-1329-2>

(3) **年份:** 2002

(4) **篇幅:** 400 页

(5) **核心贡献:**

- 提供 Orlicz 空间的综合参考文献
- 系统阐述 Orlicz 空间理论

(6) **摘要:** Orlicz 空间的标准参考文献。

(7) **关键词:** Orlicz Space; Banach Space; Function Space

2.3.7. *Topological Duals of Locally Convex Function Spaces* —Pennanen & Perkkiö.

(1) **作者:** Teemu Pennanen, Ari-Pekka Perkkiö

(2) **链接:** <https://arxiv.org/abs/2008.08934>

(3) **年份:** 2020

(4) **篇幅:** 22 页

(5) **核心贡献:**

- 研究局部凸函数空间的拓扑对偶
- 为信息几何提供泛函分析基础

(6) **摘要:** 研究局部凸函数空间的拓扑对偶性质。

(7) **关键词:** Topological Dual; Locally Convex Function Space; Orlicz Space

2.4. 四、统计流形与几何结构.

2.4.1. *Statistical Manifold as an Affine Space: A Functional Equation Approach* —Zhang & Hästö.

- (1) 作者: Jun Zhang, Peter Hästö
- (2) 链接: <https://www.sciencedirect.com/science/article/pii/S0022247X05004139>
- (3) 年份: 2006
- (4) 篇幅: 6 页
- (5) 核心贡献:
 - 将统计流形视为仿射空间
 - 利用函数方程方法研究几何性质
- (6) 摘要: 利用函数方程方法研究统计流形作为仿射空间的几何结构。
- (7) 关键词: Statistical Manifold; Affine Space; Functional Equation

2.4.2. *A Brief Introduction to Finsler Geometry* —Matias Dahl.

- (1) 作者: Matias Dahl
- (2) 链接: <https://arxiv.org/abs/math/0607030>
- (3) 年份: 2006
- (4) 篇幅: 20 页
- (5) 核心贡献:
 - 提供 Finsler 几何的简介
 - 重点讨论 Legendre 变换与辛几何的联系
- (6) 摘要: Finsler 几何的入门教程。
- (7) 关键词: Finsler Geometry; Legendre Transform; Symplectic Geometry

2.5. 五、应用方向.

2.5.1. *Information Geometry and Evolutionary Game Theory* —Marc Harper.

- (1) 作者: Marc Harper
- (2) 链接: <https://arxiv.org/abs/0911.1383>
- (3) 年份: 2009
- (4) 篇幅: 12 页
- (5) 核心贡献:
 - 建立进化博弈论中 Shahshahani 几何与信息几何的关系
 - 为进化动力学提供几何框架
- (6) 摘要: 将信息几何方法应用于进化博弈论。
- (7) 关键词: Evolutionary Game Theory; Shahshahani Geometry; Information Geometry

2.5.2. *Measuring Thermodynamic Length* —Gavin E. Crooks.

- (1) 作者: Gavin E. Crooks
- (2) 链接: <https://arxiv.org/abs/0706.0559>
- (3) 年份: 2007
- (4) 篇幅: 15 页
- (5) 核心贡献:
 - 提出热力学长度的信息几何定义
 - 连接信息论与热力学
- (6) 摘要: 利用信息几何方法测量热力学长度。
- (7) 关键词: Thermodynamic Length; Information Geometry; Statistical Mechanics

2.5.3. *Possible Generalization of Boltzmann-Gibbs Statistics* —Constantino Tsallis.

- (1) 作者: Constantino Tsallis
- (2) 链接: <https://journals.aps.org/jstat/abstract/10.1088/1742-5468/2008/06/P06013>
- (3) 年份: 1988
- (4) 篇幅: 19 页
- (5) 核心贡献:
 - 提出 Tsallis 熵 (广义 Boltzmann-Gibbs 统计)
 - 开创非广延统计力学
- (6) 摘要: 广义 Boltzmann-Gibbs 统计的原始论文, 是非广延统计力学的基础。
- (7) 关键词: Tsallis Entropy; Generalized Statistics; Non-extensive

2.5.4. *Logit Standardization in Knowledge Distillation* —Sun et al.

- (1) 作者: Shangquan Sun, Wenqi Ren, et al.
- (2) 链接: <https://arxiv.org/abs/2403.01427>
- (3) 年份: 2024
- (4) 篇幅: 15 页
- (5) 核心贡献:
 - 将信息几何方法应用于知识蒸馏
 - 提出 Logit 标准化方法
- (6) 摘要: 研究信息几何在知识蒸馏中的应用。
- (7) 关键词: Knowledge Distillation; Logit Standardization; Information Geometry

2.5.5. *Maximum Likelihood Estimation for the λ -exponential Family* —Nielsen & Barbaresco.

- (1) 作者: Frank Nielsen, Frédéric Barbaresco (Eds.)
- (2) 链接: <https://link.springer.com/book/978-3-031-47869-4>
- (3) 年份: 2025
- (4) 篇幅: 500+ 页
- (5) 核心贡献:
 - 探讨 λ -指数族的最大似然估计
 - 研究几何结构在统计推断中的应用
- (6) 摘要: GSI 2025 会议论文集的一部分。
- (7) 关键词: λ -exponential Family; MLE; Geometric Science of Information

2.6. 六、高级主题.

2.6.1. *Towards a Category-theoretic Foundation of Classical and Quantum Information Geometry* —Ciaglia et al.

- (1) 作者: F.M. Ciaglia, F. Di Cosmo, L. González-Bravo
- (2) 链接: <https://arxiv.org/abs/2509.10262>
- (3) 年份: 2025
- (4) 篇幅: 42 页
- (5) 核心贡献:
 - 建立经典和量子信息几何的范畴论基础
 - 提供统一的数学框架
- (6) 摘要: 最新基础性工作, 利用范畴论为信息几何提供新的理论基础。
- (7) 关键词: Category Theory; Information Geometry; Quantum Geometry

2.6.2. *On Reproducing Kernel Banach Spaces* —Lin, Zhang, Zhang.

- (1) **作者:** Rongrong Lin, Haizhang Zhang, Jun Zhang
- (2) **链接:** <https://arxiv.org/abs/1901.01002>
- (3) **年份:** 2019
- (4) **篇幅:** 28 页
- (5) **核心贡献:**
 - 提出再生核 Banach 空间的统一构造框架
 - 为信息几何中的函数空间提供新工具
- (6) **摘要:** 研究再生核 Banach 空间的统一构造。
- (7) **关键词:** Reproducing Kernel Banach Space; RKBS; Function Space

3. 补充参考资料

除上述文献外，以下资料可作为补充学习资源：

- *Coding and Information Theory* —Cover & Thomas (GTM 134)
- **信息论基础** —Cover & Thomas (中文翻译版)
- *Applications of Orlicz Spaces* —Rao & Ren

4. 学习路径与前置基础知识

学习信息几何需要以下基础知识：

- (1) **微分几何:** 流形、切空间、协变导数、联络、黎曼几何
- (2) **概率论:** 概率分布、期望、方差、条件概率、极限定理
- (3) **信息论:** 熵、KL 散度、互信息
- (4) **统计学:** 最大似然估计、充分统计量、Cramér-Rao 下界
- (5) **泛函分析** (高级主题): Banach 空间、Orlicz 空间、函数空间几何

5. 最终目标

通过本学习资料，期望达到以下目标：

- (1) 掌握信息几何的核心概念：Fisher 信息度量、对偶联络、 α -联络族
- (2) 理解非参数信息几何的基本理论
- (3) 了解信息几何在统计学、机器学习、热力学等领域的应用
- (4) 能够阅读和理解该领域的前沿论文
- (5) 为进一步研究打下坚实基础

注 0.1. 本章为信息几何的导论章节，旨在建立整体认知框架。在后续章节中，我们将深入探讨各个核心概念。

Part 1

散度函数与对偶平坦黎曼结构

本部分对应 Amari 《Information Geometry and Its Applications》 Part I (Chapter 1-4), 介绍信息几何的基础理论。

6. Part I 概述

Part I 建立了信息几何的核心数学框架，包括：

- (1) **Chapter 1:** 流形、散度与对偶平坦结构
- (2) **Chapter 2:** 指数族与混合族
- (3) **Chapter 3:** 不变几何与 Fisher 信息
- (4) **Chapter 4:** α -几何与 Tsallis q -熵

7. 核心概念

本 Part 的核心概念包括：

- **散度 (Divergence):** 概率分布之间的非对称“距离”
- **Bregman 散度:** 由凸函数诱导的散度
- **指数族:** $p(x|\theta) = \exp(\theta \cdot u(x) - \psi(\theta))$
- **Fisher 信息:** 概率分布空间的不变度量
- **对偶平坦结构:** 由 Legendre 变换联系的两组仿射坐标

注 0.2. *Part I* 的核心洞见是：**散度函数诱导了概率分布流形上的几何结构**，这为后续的统计推断提供了统一的几何框架。

信息几何基础：散度与对偶平坦结构

本章介绍信息几何的核心概念：散度函数、对偶平坦结构，以及它们与贝叶斯分析的内在联系。

1. 背景与动机

信息几何的核心思想是将概率分布族视为一个黎曼流形，利用几何方法来研究统计推断问题。这种观点起源于 Fisher 信息的研究，后来由 Rao、Cox、Amari 等学者发展为系统的几何理论。

一个关键的洞察是：**散度 (Divergence) 取代了传统几何中的距离概念**，因为概率分布之间的“差异”往往不是对称的。这为贝叶斯分析提供了统一的几何框架。

2. 核心定义

2.1. Divergence (散度).

定义 1.1 (散度). 给定流形 M 上的两点 P 和 Q ，其坐标分别为 ξ_P 和 ξ_Q 。散度 $D[P : Q]$ 是满足以下条件的函数：

- (1) $D[P : Q] \geq 0$
- (2) $D[P : Q] = 0$ 当且仅当 $P = Q$
- (3) 当 P 和 Q 充分接近时， $D[P : Q]$ 可微

散度不是距离，因为它不满足对称性： $D[P : Q] \neq D[Q : P]$ 。这种非对称性正是信息几何的核心特征。

2.2. Bregman 散度.

定义 1.2 (Bregman 散度). 给定凸函数 $\psi(\xi)$ ，由其诱导的 Bregman 散度定义为：

$$(1) \quad D[\xi : \xi'] = \psi(\xi') - \psi(\xi) - \nabla \psi(\xi) \cdot (\xi' - \xi)$$

Bregman 散度的重要性质：当 ψ 是严格凸的可微函数时，它自动满足散度的定义。

2.3. 指数族与混合族.

定义 1.3 (指数族). 指数族分布具有以下形式：

$$(2) \quad p(x|\theta) = \exp(\theta \cdot u(x) - \psi(\theta))$$

其中 θ 是自然参数， $\psi(\theta)$ 是累积量函数（确保归一化）。

定义 1.4 (混合族). 混合族分布具有以下形式：

$$(3) \quad p(x|\pi) = \sum_i \pi_i p_i(x), \quad \sum_i \pi_i = 1, \quad \pi_i \geq 0$$

其中 $\pi = (\pi_1, \dots, \pi_k)$ 是混合权重。

指数族和混合族在信息几何中具有特殊地位：它们分别是对偶平坦空间中 e-平坦和 m-平坦的子流形。

3. Fisher 信息与不变性

定义 1.5 (Fisher 信息矩阵). 给定参数化概率分布族 $\{p(x; \theta)\}_{\theta \in \Theta}$, Fisher 信息矩阵定义为:

$$(4) \quad g_{ij}(\theta) = \mathbb{E} \left[\frac{\partial \log p(X; \theta)}{\partial \theta_i} \cdot \frac{\partial \log p(X; \theta)}{\partial \theta_j} \right]$$

Fisher 信息具有重要的**不变性**: 在充分统计量下保持不变。这使其成为概率分布空间上的”自然”黎曼度量。

命题 1.1 (Fisher 信息的唯一性). 在概率分布的变换群下, 唯一不变且满足某些合理条件的度量就是 Fisher 信息度量。

这意味着: **Fisher 信息是概率分布空间的几何不变量。**

4. 对偶平坦结构

当散度由凸函数通过 Bregman 形式诱导时, 流形获得一种**对偶平坦结构**:

- (1) 由 ψ 诱导一组**仿射坐标** θ (自然参数)
- (2) 由 Legendre 变换 ψ^* 诱导**对偶仿射坐标** η :

$$(5) \quad \eta = \nabla \psi(\theta), \quad \theta = \nabla \psi^*(\eta)$$

- (3) 这两组坐标通过 **Legendre 变换**相互联系

这种结构称为 **dually flat** (对偶平坦), 是信息几何的核心结构。

定理 1.1 (广义勾股定理). thm:pythagorean 在对偶平坦空间中, 对于三点 P, Q, R , 若 Q 是 P 在 m -子流形上的投影, 则:

$$(6) \quad D[P : R] = D[P : Q] + D[Q : R]$$

这个定理是欧几里得空间中勾股定理的推广, 在优化算法 (如 EM 算法) 中发挥重要作用。

5. 与贝叶斯分析的关联

信息几何与贝叶斯分析有着深刻的内在联系。下面我们系统阐述这种联系。

5.1. KL 散度与贝叶斯推断. KL 散度 (Kullback-Leibler Divergence) 是信息几何中最重要的散度:

$$(7) \quad D_{KL}[P : Q] = \int p(x) \log \frac{p(x)}{q(x)} dx$$

在贝叶斯分析中, KL 散度出现在多个关键位置:

- (1) **后验与先验的差异**:

$$(8) \quad D_{KL}[p(\theta|x) : p(\theta)]$$

衡量从先验到后验的信息增益。

- (2) **Bayes Factor**:

$$(9) \quad BF_{12} = \frac{p(x|M_1)}{p(x|M_2)} = \exp(-D_{KL}[p(\theta|x, M_1) : p(\theta|x, M_2)])$$

模型 M_1 相对于 M_2 的后验 odds 与先验 odds 的比值。

(3) 后验预测分布:

$$(10) \quad p(x) = \int p(x|\theta)p(\theta|x) d\theta$$

的几何性质由信息几何刻画。

注 1.1. KL 散度的非对称性在此有深刻含义: $D_{KL}[p:q]$ 衡量用 q 近似 p 时丢失的信息。在贝叶斯语境下, 这对应于“用简单分布近似复杂后验”的损失。

5.2. 指数族与共轭先验. 指数族与贝叶斯分析的另一个深层联系是**共轭先验**:

定理 1.2 (指数族的共轭性). thm:conjugate-prior 若似然函数来自指数族:

$$(11) \quad p(x|\theta) = \exp(\theta \cdot u(x) - \psi(\theta))$$

则共轭先验具有形式:

$$(12) \quad p(\theta|\alpha, \beta) \propto \exp(\alpha \cdot \theta - \beta\psi(\theta))$$

其中 α, β 是超参数。

这解释了为什么 Beta 分布是二项分布的共轭先验, Dirichlet 是 Multinomial 的共轭先验——它们都是指数族!

注 1.2. 从几何角度看, 指数族的共轭先验保持在其对应的“平坦子流形”内, 这使得贝叶斯后验计算可以在封闭形式下完成。

6. 关键概念一览

信息几何概念	贝叶斯分析对应
KL 散度	后验-先验差异; Bayes Factor
指数族	共轭先验分布族
Fisher 信息	Jeffreys 先验; Cramér-Rao 下界
Bregman 散度	ELBO (变分推断)
混合族	混合模型 (Mixture Model)
充分统计量	信息几何不变性
EM 算法	散度最小化的迭代优化

TABLE 1. 信息几何与贝叶斯分析的对应关系

注 1.3. 本章建立了信息几何的基本框架, 并阐释明其与贝叶斯分析的内在联系。核心洞见是:**散度最小化统一了贝叶斯推断、变分推断和统计学习**。

注 1.4. 本章内容对应 Amari 《Information Geometry and Its Applications》Part I (Chapter 1-4)。

APPENDIX A

问答与讨论

1. Part I 核心概念与贝叶斯关联

本节记录学习 Amari 《Information Geometry and Its Applications》Part I (Chapter 1-4) 过程中的问答与思考。

1.1. 散度与距离的核心区别. 问：散度 (Divergence) 与距离的核心区别是什么？

答：散度不是距离，因为它不满足对称性： $D[P : Q] \neq D[Q : P]$ 。这反映了概率分布之间的“方向性”差异——从分布 P 到 Q 的信息损失与从 Q 到 P 是不同的。

在贝叶斯分析中，这对应于 $D_{KL}[p(\theta|x) : p(\theta)]$ 衡量的是“给定数据后”相对于“先验”的信息增益，是有方向的。

1.2. 为何使用散度而非距离. 问：为什么要用散度而不是距离？

答：因为概率分布之间的比较往往需要考虑方向性。例如，用简单分布近似复杂分布时，近似的“损失”取决于我们用哪个分布作为参考。

这正是贝叶斯推断的核心：后验分布 $p(\theta|x)$ 是对先验 $p(\theta)$ 的“更新”，这个更新过程天然是非对称的。

1.3. 指数族在贝叶斯分析中的重要性. 问：指数族为什么在贝叶斯分析中如此重要？

答：指数族的重要性源于两点：

1. **共轭性：**指数族的共轭先验保持在其族内，这意味着后验计算有封闭形式。

2. **充分统计量：**指数族的分布可以表示为 $p(x|\theta) = \exp(\theta \cdot u(x) - \psi(\theta))$ ，其中 $u(x)$ 是充分统计量。这使得贝叶斯更新只需要更新 θ 参数。

从几何角度看，指数族是信息几何中“平坦子流形”的典型例子，其上的推断具有简洁的几何结构。

1.4. 混合族与指数族的关系. 问：混合族和指数族有什么联系？

答：混合族和指数族是对偶的：

- 指数族是 **e-平坦** (exponential-flat) 的
- 混合族是 **m-平坦** (mixture-flat) 的

这种对偶性通过 Legendre 变换相联系。在贝叶斯分析中，混合模型（如高斯混合模型）是重要的非参数/半参数模型。

1.5. 指数族的例子. 问：指数族的例子有哪些？

答：常见指数族包括：

- (1) **正态分布** $N(\mu, \sigma^2)$: $\theta = (\mu/\sigma^2, -1/(2\sigma^2))$
- (2) **二项分布** $Bin(n, p)$: $\theta = \log(p/(1-p))$
- (3) **Poisson 分布** $Pois(\lambda)$: $\theta = \log \lambda$
- (4) **Dirichlet 分布：**多参数指数族

它们的共轭先验分别是：Normal-Inverse-Gamma、Beta、Beta、Dirichlet。

1.6. 指数族的几何意义. 问：指数族的几何意义是什么？

答：从几何角度看，指数族在参数空间中是平坦的（欧几里得几何）。这意味着：

- 任意两点之间的最短路径（测地线）是直线
- 充分统计量提供了坐标系统
- 最大似然估计有封闭形式

在贝叶斯分析中，这意味着我们可以几何地理解后验分布在指数族中的演化。

1.7. Jeffreys 先验与 Fisher 信息的关系. 问：贝叶斯推断中，Jeffreys 先验与 Fisher 信息是什么关系？

答：Jeffreys 先验定义为：

$$(13) \quad p(\theta) \propto \sqrt{\det I(\theta)}$$

其中 $I(\theta)$ 是 Fisher 信息矩阵。这个先验具有重要性质：

- (1) **不变性：**参数变换下形式保持不变
- (2) **信息几何意义：**它是 Fisher 信息度量诱导的“无信息”先验

从信息几何视角看，Jeffreys 先验是在 Fisher 几何意义下的“均匀”分布。

1.8. KL 散度在贝叶斯分析中的应用. 问：KL 散度在贝叶斯分析中的具体应用有哪些？

答：KL 散度在贝叶斯分析中有广泛应用：

(1) **Bayes Factor：**

$$(14) \quad BF_{12} = \exp(-D_{KL}[p(\theta|x, M_1) : p(\theta|x, M_2)])$$

- (2) **后验预测检验：**比较观测数据与后验预测分布
- (3) **变分推断：**

$$(15) \quad q^* = \arg \min_q D_{KL}[q(\theta) : p(\theta|x)]$$

(4) **信息增益：** $D_{KL}[p(\theta|x) : p(\theta)]$ 衡量数据的价值

1.9. EM 算法与信息几何的关系. 问：EM 算法与信息几何是什么关系？

答：EM 算法是对偶平坦空间中的**交替最小化**算法的典型例子：

- (1) **E 步：**在当前参数下，计算隐变量的后验分布
- (2) **M 步：**最大化期望完整数据对数似然

这等价于在两个对偶平坦子流形之间交替投影，每次投影使 KL 散度下降。

广义勾股定理保证了这种交替优化的收敛性。

1.10. 变分推断的信息几何理解. 问：变分推断如何从信息几何角度理解？

答：变分推断 (VI) 的核心是散度最小化：

$$(16) \quad q^* = \arg \min_{q \in \mathcal{Q}} D_{KL}[q(\theta) : p(\theta|x)]$$

从几何角度看：

- $\mathcal{Q}$ 是一个参数化的近似分布族（通常是指指数族）
- 目标是在 $\mathcal{Q}$ 中找到 $p(\theta|x)$ 的“最近”近似
- 这就是投影定理在变分推断中的应用

ELBO (Evidence Lower Bound) 最大化与 KL 散度最小化是等价的。

1.11. 信息几何对贝叶斯模型选择的启示. 问：信息几何对贝叶斯模型选择有什么启示？

答：从信息几何角度看，模型选择本质上是在不同的子流形之间进行选择：

- (1) 每个模型对应一个子流形 $\mathcal{M}$
- (2) 数据分布 p_{data} 在流形上的投影是最佳拟合
- (3) 模型复杂度由子流形的”曲率”刻画
- (4) Bayes Factor 实际上是比较不同子流形上的投影差异

这提供了理解偏差-方差权衡、模型复杂度的几何框架。

1.12. Fisher 信息的唯一性. 问：为什么 Fisher 信息是唯一的？

答：Fisher 信息具有独特的不变性：

- (1) **充分统计量下不变**：若 $T(X)$ 是充分统计量，则 $I(\theta) = I(T, \theta)$
- (2) **参数变换下协变**：在参数变换下以正确的方式变换

信息几何的一个核心定理证明：在满足合理条件下（正定、不变、局部性），唯一满足这些条件的度量就是 Fisher 信息。

这使得 Fisher 信息成为概率分布空间的”自然”几何结构。

1.13. 信息几何视角下的贝叶斯核心思想. 问：信息几何视角下的贝叶斯核心思想是什么？

答：综合以上讨论，信息几何为贝叶斯分析提供了统一的几何框架：

- (1) 概率分布 $\rightarrow$ 流形上的点
- (2) 推断 $\rightarrow$ 流形上的投影（散度最小化）
- (3) 先验 $\rightarrow$ 流形上的参考点
- (4) 后验 $\rightarrow$ 数据驱动的点移动
- (5) 模型 $\rightarrow$ 子流形

核心洞见是：贝叶斯推断就是概率分布空间中的几何运动。