

[12pt]amsbook amsmath,amssymb,amsthm xeCJK microtype hyperref cleveref geometry
natbib margin=1in

CHAPTER 1

综合评述

本章节综述 Rong Tang 与 Yun Yang 的系列工作，涵盖 2019–2025 年间发表在 *Annals of Statistics*、*JRSS B*、*AISTATS*、*ICML* 等顶级期刊与会议上的代表性论文，涉及极小极大理论、稳健贝叶斯、扩散模型、两样本检验、MCMC 等多个方向。

1. 研究背景与动机

现代高维数据（图像、文本）尽管环境维度 D 巨大，但其有效信息维度 $d \ll D$ ，数据通常位于某个低维流形上。传统非参数统计受维度灾难困扰——极小极大速率以 D 为指数，而 GAN、VAE、扩散模型等深度生成模型在实践中却表现出色。这一矛盾促使一个根本性问题：

- (1) 当数据位于未知低维流形上时，分布估计的统计极限是什么？
- (2) 深度生成模型能否隐式自适应流形结构，避免维度灾难？
- (3) 如何在流形约束下进行有效的贝叶斯推断和 MCMC 采样？

Tang-Yang 系列围绕这三个问题，在统计学习理论与方法之间建立了有机联系：从极小极大理论出发，理解扩散模型的自适应性质，并在此基础上建立稳健贝叶斯推断和高效采样算法。

注：本章侧重批判性分析：技术创新来源、证明策略选择、与现有工作的对话、以及开放问题。与第 ?? 章的系统综述形成互补。

2. 论文系列详解

2.1. [?] — 未知子流形上的极小极大分布估计. 文献信息：Rong Tang and Yun Yang. “Minimax Rate of Distribution Estimation on Unknown Submanifold under Adversarial Losses.” *Annals of Statistics*, 2022.

2.1.1. *Summary.* 本文研究了高维数据低维流形结构假设下的分布估计问题，建立了对抗损失 (adversarial loss) 下未知子流形上分布估计的极小极大 (minimax) 理论框架。核心贡献在于证明了估计误差率为

$$n^{-1/2} \vee n^{-\frac{\alpha+\gamma}{2\alpha+d}} \vee n^{-\frac{\gamma\beta}{d}},$$

其中 d 为流形内在维度， α 为密度光滑度， β 为流形光滑度， γ 为判别器光滑度。该速率仅依赖内在维度 d 而非环境维度 D ，成功规避了维度灾难。

技术路线方面：下界证明依赖于精细的 Fano 方法和 Le Cam 方法，通过在球面上构造难以区分的分布族完成；上界的证明综合运用了小波展开、经验过程理论 (chaining 技术)、单位分解和最优传输的 Caffarelli 正则性理论。

2.1.2. Overall Assessment. 理论贡献：本文成功填补了生成模型分布估计与流形统计推断之间的理论空白。核心发现是三类不同的收敛机制（参数机制、密度估计机制、流形估计机制）的识别，揭示了判别器光滑度 γ 在其中的关键调控作用。

批评：（1）下界构造中基于对 d 维球面的特定扰动是否真正代表了所考虑分布类中的最难情形，尚有进一步探讨的空间。（2）估计器的理论构造涉及小波展开截断、Lepski 自适应等复杂步骤，未给出具体算法实现——这是一篇“理论导向”而非“方法导向”的工作。（3）主要处理无噪声情形，对带噪声观测的讨论不够系统。

在系列中的位置：本文是整个系列的奠基之作，后续 [?], [?], [?] 的工作都在此极小极大框架下被评价和比较。

2.2. [?] — VAE 的 Excess Risk Bound. 文献信息：Rong Tang and Yun Yang. “Excess Risk Bounds for Distribution Estimation with VAE.” *COLT*, 2021.

核心发现：VAE 的 encoder-decoder 结构本质上是在学习数据流形的一个全局参数化。建立了 VAE 估计器的 excess risk 上界，证明了在温和假设下 VAE 可以达到最优的统计收敛速率。

批评：（1）假设条件依赖于解码器族和编码器族的逼近能力，在实际应用中的可验证性有待进一步讨论。（2）VAE 的 posterior collapse 问题在理论上没有得到解释，限制了理论结果的实践指导意义。（3）作为系列的开创性工作，理论框架相对简单，主要结果是 excess risk bound 而非极小极大速率比较。

2.3. [?] — 黎曼子流形上的稳健贝叶斯推断. 文献信息：Rong Tang, Anirban Bhattacharya, Debdeep Pati, and Yun Yang. “Robust Bayesian Inference on Riemannian Submanifold,” *JRSS B*, 2023.

核心理论贡献：黎曼流形上的 Bernstein-von Mises (BvM) 定理。通过将后验分布投影到流形切空间并利用局部坐标变换，成功将欧氏空间中的分析工具推广到流形 setting，证明了后验分布在切空间上的投影渐近正态。

计算贡献：黎曼随机游走 Metropolis (RRWM) 算法。证明了混合时间仅依赖流形内在维度 d 而非环境维度 D ——分析工具是经典的 conductance profile 方法。

批评：（1）正则性假设较强：假设流形局部为 C^3 光滑，且要求风险函数满足二次增长条件，限制了在更一般流形上的应用。（2）BvM 定理的收敛速度（到渐近正态的速率）在论文中没有给出，使得有限样本下的可靠性难以量化。（3）RRWM 的 proposal 设计较为简单，在多峰分布或强非线性流形上可能表现不佳。

2.4. [?] — Metropolis-Adjusted Langevin 算法的最优混合时间. 文献信息：Rong Tang and Yun Yang. “Metropolis-Adjusted Langevin Algorithm: Optimal Dimension Dependency and Beyond.” *ICML*, 2024.

核心贡献： s -conductance profile。这是介于经典 conductance 与 Chen et al. (2020) 的 conductance profile 之间的精细分析技术。核心创新：在非凸集假设下将 warm-start 参数依赖从 $\log M_0$ 改进到 $\log \log M_0$ ——在高维后验分布（ M_0 极大）的实际场景中意义显著。

在无需对目标分布施加光滑或强对数凹性假设的条件下，证明了 MALA 达到最优 $O(d^{1/3})$ 维度依赖（经 burn-in 后），并将结果推广到光滑与非光滑 Gibbs 后验（包括贝叶斯分位数回归）。

批评：（1）定理要求 $d \leq cn^{\kappa_1}/\log n$ ，对于非光滑情形需要相对更大的样本量才能保证 $d^{1/3}$ 混合时间。（2） s -warm start 假设在实践中难以验证，与 MCMC “无知采样”的哲学存在张力。（3）没有给出实际可用的 burn-in 长度估计。

与 [?] 的联系：[?] 的 BvM 定理保证了流形后验的渐近高斯性；本文则利用这一性质，将 MALA 在高斯目标上的最优混合时间桥接到一大类后验分布。

2.5. [?] — 对抗损失下的两样本检验. 文献信息: Rong Tang and Yun Yang. “Minimax Nonparametric Two-Sample Test under Adversarial Losses,” *AISTATS*, 2023.

核心创新: 建立了负 Besov 范数与对抗损失之间的等价关系 (引理 1), 基于截断小波展开构造检验统计量, 计算复杂度 $O(n \log n + n^{2d/(4\alpha+d)})$ 远优于 MMD 的 $O(n^2)$ 。

批评: (1) 正则性假设过强: 假设密度函数具有紧支撑且一致有界, 在许多实际应用中可能难以满足。(2) 最优截断水平 J 的选择依赖于未知的光滑度参数 α ——如何构造对 α 自适应的检验仍是开放问题。(3) Bootstrap 阈值的理论支撑不足。

2.6. [?] — 扩散模型自适应流形结构. 文献信息: Rong Tang and Yun Yang. “Adaptivity of Diffusion Models to Manifold Structures,” *AISTATS*, 2024.

Langevin 扩散分支: 通过 Gaussian 平滑 $p_\sigma(x) = \int p_{\text{data}}(y)\phi_\sigma(x-y)dy$ 使密度函数在任意时刻 $t > 0$ 关于 Lebesgue 测度绝对连续。收敛速率为 $\tilde{O}(\sigma)$, 仅需分数函数的四阶矩误差——较现有工作的 L_∞ 或矩母函数假设更弱。

正向-反向扩散分支 (主要贡献): 设计了时间分段常数的神经网络架构来逼近时变分数函数。在 1-Wasserstein 距离下达极小极大速率

$$\frac{1}{\sqrt{n}} \vee n^{-\frac{\alpha+1}{2\alpha+d}}.$$

批评: (1) Langevin 扩散分支的收敛速率弱于正向-反向扩散, 存在若干技术原因导致次优。(2) 各向同性高斯噪声可能“稀释”流形结构——论文提及但未给出严格的量化分析。(3) 时间分段架构的分段数 J 依赖于未知的光滑度参数 α , 实践中难以选择。

与 [?] 的关系: 本文证明了扩散模型能够达到 [?] 建立的极小极大速率 (在 $\gamma = 1$ 的 Wasserstein 度量下), 建立了“实践有效的工具 $\Leftrightarrow$ 理论最优的方法”这一对应关系。

2.7. [?] — 低维结构混合生成模型. 文献信息: Rong Tang and Yun Yang. “Estimating Distributions with Low-dimensional Structures Using Mixtures of Generative Models.” *ICML*, 2023.

核心发现: 多编码器/解码器结构在流形分布估计中是必要的。提出了 MLDMAE (Mixture of Latent Distribution Matched Auto-Encoders) 方法: K 个局部编码器-解码器对分别学习流形局部区域的参数化, 权重函数 ρ_k 通过 softmax 实现光滑拼接。在 1-Wasserstein 距离下达极小极大最优 (至多对数因子)。

批评: (1) 聚类数 K 的选择缺乏自适应理论指导, 仅通过实验说明 $K \approx 10$ 对 MNIST 有效。(2) 当 $\alpha > \beta - 1$ 时, 最优速率是否仍然保持极小极大最优, 论文仅提及但未严格证明。(3) 局部块之间的重叠区域如何处理在理论上没有得到充分分析。

2.8. [?] — 分布回归的极小极大最优速率. 文献信息: Rong Tang and Yun Yang. “Minimax Optimal Rates for Regression on Manifolds and Distributions,” arXiv, 2025.

核心贡献: 在三类层次递进的设定下系统建立了极小极大下界, 并提出融合对抗学习 (IPM 度量) 与同步最小二乘的混合估计量。 γ -Hölder IPM d_γ 统一了全变差距离 ($\gamma = 0$) 和 1-Wasserstein 距离 ($\gamma = 1$)。

批评: 三层 Regime 的下界证明较为复杂, 但上界中的 $\frac{\alpha_Y}{\alpha_X} \cdot d_X$ 项的出现略显 ad hoc——缺乏几何直觉。此外, 文中提出的混合估计量在 $\gamma \neq 0, 1$ 时是否仍然可计算 (如何实现 IPM 的判别器优化?) 并未讨论。

2.9. [?] — 条件扩散模型的极小极大最优性. 文献信息: Rong Tang and Yun Yang. “Conditional Diffusion Models are Minimax-Optimal and Manifold-Adaptive,” arXiv, 2025.

核心发现：首次建立了条件扩散模型的流形自适应理论，在经典密度回归和高维回归（协变量与响应均具有低维流形结构）两种场景下均达到极小极大最优收敛速率。估计误差仅依赖内在维度 (d_X, d_Y) 而非环境维度 (D_X, D_Y)。

批评：(1) 与 [?] 相比，本文缺乏对条件生成模型与条件分布回归理论之间关系的讨论。(2) 条件扩散模型中的 classifier-free guidance 等实践技术的理论解释尚未涉及。(3) 证明中的经验过程局部化与剥离技术虽然标准，但技术细节高度复杂，读者友好性有待提高。

3. 批判性总结

3.1. 系列的整体贡献。 Tang-Yang 系列的核心贡献可以概括为三点：

- (1) **几何 $\rightarrow$ 统计的量化桥梁：**首次将”数据位于低维流形”这一几何先验转化为可计算的极小极大速率，其中环境维度 D 完全不出现在速率指数中。
- (2) **理论工具的创造性应用：**单位分解、Girsanov 定理、 s -conductance profile 等工具的选择具有高度针对性，每一种工具都解决了流形统计学中的特定困难。
- (3) **理论与实践的紧密互动：**从极小极大理论 $\rightarrow$ VAE $\rightarrow$ 扩散模型 $\rightarrow$ 条件扩散模型，理论每前进一步，都伴随着具体方法的验证或改进。

注：该系列的整体启示：低维流形几何结构是理解现代高维数据统计推断的关键钥匙。极小极大理论告诉我们”理论上能达到多好的结果”，稳健贝叶斯告诉我们”如何在模型不确定时量化不确定性”，扩散模型则告诉我们”实践中如何高效地实现这一最优性”。

3.2. 有待解决的问题。

- (1) **流形维数自适应：**整个系列假设内在维度 d 已知。如何在 d 未知的情况下构造自适应估计器，同时保持极小极小最优性？
- (2) **噪声鲁棒性：**[?] 的无噪声设定过于理想。在随机噪声 (deconvolution) 设定下，流形结构能否依然帮助克服维度灾难？
- (3) **光滑性自适应：**小波/局部多项式逼近中的截断参数依赖于未知光滑度。是否存在计算可行（而非仅理论存在）的自适应方法？
- (4) **深度模型的端到端理论：**现有理论建立在”估计器 = 理论构造”的框架上，与实际训练（梯度下降、随机优化）的动态过程存在显著差距。
- (5) **非光滑流形：**整个系列假设流形 β -光滑 ($\beta \geq 1$)。现实中大量数据（分片光滑流形、带边流形）尚无理论保障。

4. 发表时间线

- (1) **2021** — [?] (VAE 流形自适应)
- (2) **2022** — [?] (流形分布估计极小极大框架)
- (3) **2023a** — [?] (MLDMAE)
- (4) **2023b** — [?] (流形稳健贝叶斯 + BvM)
- (5) **2023c** — [?] (两样本检验)
- (6) **2024a** — [?] (扩散模型自适应流形)
- (7) **2024b** — [?] (MALA 最优混合时间)
- (8) **2025a** — [?] (分布回归极小极小速率)
- (9) **2025b** — [?] (条件扩散模型最优性)

主线二： [?] $\xrightarrow{\text{扩展到流形}}$ [?] $\xrightarrow{\text{推广到条件设定}}$ [?]

主线三： [?] $\xrightarrow{\text{利用 BvM 性质}}$ [?]

5. 核心技术索引

- (1) **单位分解 (Partition of Unity)**: [?], [?] 利用此技术处理无全局参数化流形——是估计器构造的核心工具。
- (2) **γ -Hölder IPM**: [?], [?], [?] 将不同光滑度的判别器类统一在同一个框架下, 实现多种距离度量的同时最优。
- (3) **Gaussian 平滑 + 四阶矩误差**: [?] 将 Langevin 扩散的分析弱化到四阶矩, 建立了更弱但更实用的误差条件。
- (4) **时间分段神经网络架构**: [?], [?] 构造了随时间演化的神经网络架构, 有效平衡了近时间端与远时间端的逼近精度。
- (5) **s -conductance profile**: [?] 提出的马尔可夫链分析新技术, 提供了介于经典 conductance 与 conductance profile 之间的精细分析工具。
- (6) **黎曼流形 Bernstein-von Mises 定理**: [?] 将经典 BvM 推广到黎曼子流形 setting, 为流形贝叶斯推断提供了严格的理论基础。
- (7) **Girsanov 定理桥梁**: [?], [?] 通过 Girsanov 定理建立分数估计误差与分布估计误差之间的联系, 是连接 SDE 理论与统计学习的核心工具。