因果推断讲义

Peng Ding

March 14, 2026

Contents

1 相关性、关联与 Yule-Simpson 悖论 **5**
1.1 本章导论 5
1.2 为什么这个问题很重要 5
1.3 相关性与因果性的区别 6
1.4 Yule-Simpson 悖论 6
1.5 本章小结与下节预告 6

2 潜在结果框架 **7**
2.1 为什么需要潜在结果? 7
2.2 基本定义 7
2.3 个体因果效应 8
2.4 平均因果效应 8
2.5 为什么要定义" 潜在" 结果? 8
2.6 稳定单位治疗值假设（SUTVA） 8
2.7 本章小结 9

3 完全随机实验与 FRT **11**
3.1 为什么需要随机实验? 11
3.2 随机实验的基本思想 11
3.3 完全随机实验的定义 11
3.4 费舍尔随机化检验（FRT） 12
3.4.1 为什么需要 FRT? 12
3.4.2 零假设 12
3.5 检验统计量的选择 12
3.5.1 差值均值（Difference-in-means） 12
3.5.2 学生化统计量（Studentized statistic） 13
3.5.3 Wilcoxon 秩和统计量 13
3.5.4 Kolmogorov-Smirnov 统计量 13
3.6 LaLonde 实验数据案例 14
3.6.1 背景 14
3.6.2 数据分析 14
3.7 FRT 与传统 t 检验的关系 14
3.7.1 FRT 与 t 检验的对比 14
3.8 本章小结 15

A 问答与注解 **17**
A.1 阅读过程中的问题与解答 17
A.2 学习笔记 17

Chapter 1

相关性、关联与 Yule-Simpson 悖论

1.1 本章导论

本章我们要回答一个看似简单却至关重要的问题：**相关性能否直接告诉我们因果关系？**

在日常生活中，我们经常听到这样的话：

- ”吸烟会导致肺癌”
- ”教育水平越高，收入越高”
- ”经常锻炼的人更长寿”

这些陈述都试图建立因果关系。但我们是如何得出这些结论的？仅仅因为我们观察到了相关性（correlation）就足够了么？

1.2 为什么这个问题很重要

想象一下以下场景：

例 1.1. 一家公司想要知道某种新药是否有效。他们给一组患者服用新药，另一组服用安慰剂。结果显示服药组的康复率更高。这能否说明药物有效？

直觉告诉我们，这似乎能说明问题。但仔细想想，还有很多其他因素可能影响结果：

- 也许服药组的患者本身就更健康
- 也许医生在给药时，无意中对服药组患者更加关照
- 也许这只是随机波动

这就是因果推断（causal inference）的核心挑战：**我们观察到的关联（association），并不等于因果关系（causal relationship）**。

1.3 相关性与因果性的区别

统计学中，我们用不同的术语来区分这些概念：

- **相关性（Correlation）**：两个变量共同变化的趋势
- **关联（Association）**：统计学意义上的依赖关系
- **因果性（Causation）**：一个变量的变化直接导致另一个变量变化

关键洞察：相关性可以是因果的，也可以是非因果的。

1.4 Yule-Simpson 悖论

悖论的核心思想：在总体中观察到的关联方向，可能与分层后各组中的关联方向相反。

例 1.2 (经典的 Yule-Simpson 悖论例子)**.** 考虑一个大学录取数据：

院系	男生录取率	女生录取率
A	*62% (341/550)*	*82% (137/167)*
B	*63% (28/44)*	*68% (24/35)*
总体	***45% (369/816)***	***30% (161/525)***

有趣的现象：

- 在 *A* 院系，男女生录取率分别是 *62%* 和 *82%*
- 在 *B* 院系，男女生录取率分别是 *63%* 和 *68%*
- 但总体来看，男生的录取率反而更高！

这就是 *Yule-Simpson* 悖论：**在每个分层中都有利的因素，在总体中可能不利**。

这个例子揭示了一个深刻的问题：如果我们不控制混杂因素（*confounding factors*），就可能得出完全错误的因果结论。

1.5 本章小结与下节预告

本章的核心要点：

1. **相关性 $\neq$ 因果性**：观察到的关联可能是由于混杂因素造成的
2. **Yule-Simpson 悖论**：总体关联可能与分层关联方向相反
3. **因果推断的必要性**：我们需要系统性的方法来区分真实的因果效应

下一章我们将学习因果推断的基石——**潜在结果框架（Potential Outcomes Framework）**，这将为我们的因果分析提供坚实的数学基础。

Chapter 2

潜在结果框架

2.1 为什么需要潜在结果？

上一章我们看到了相关性与因果性的区别，以及 Yule-Simpson 悖论警告我们不要轻易从关联推断因果。

现在我们要问：**有没有一种方法可以清晰地定义因果效应？**

答案是肯定的，这就是**潜在结果框架（Potential Outcomes Framework）**，也被称为 **Neyman-Rubin 因果模型**。

这个框架的核心思想其实很简单：我们需要比较同一个个体在接受治疗和不接受治疗时的不同结果。

2.2 基本定义

考虑一个最简单的场景：我们想研究某种治疗（treatment）對 outcome 的因果效应。

- 对于每个个体 i，我们有一个二元治疗变量 T_i:
  - $T_i = 1$: 接受治疗（treatment group）
  - $T_i = 0$: 未接受治疗（control group）
- Y_i: 观察到的结果（observed outcome）

关键概念是**潜在结果（Potential Outcomes）**：

- $Y_i(1)$: 如果个体 i 接受治疗，会观察到的结果
- $Y_i(0)$: 如果个体 i 未接受治疗，会观察到的结果

注意：对于每个个体，我们只能观察到一种情况下的结果，另一种是潜在的（potential）而非现实的。

2.3 个体因果效应

对于个体 i，**个体因果效应（Individual Treatment Effect, ITE）**定义为：

$$\tau_i = Y_i(1) - Y_i(0)$$

这衡量了治疗对这一个体的效果。

但是，这里有一个根本性的困难——**因果推断的根本问题（Fundamental Problem of Causal Inference）**：

我们无法同时观察到同一个体的 $Y_i(1)$ 和 $Y_i(0)$。

2.4 平均因果效应

由于我们无法观察到个体因果效应，我们退而求其次，关注**平均因果效应（Average Causal Effect, ACE）**：

$$\tau_{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)]$$

这是所有个体因果效应的期望值。

类似地，我们还可以定义：

- **治疗组的平均因果效应**（Average Treatment Effect on the Treated, ATT）
- **对照组的平均因果效应**（Average Treatment Effect on the Control, ATC）

2.5 为什么要定义”潜在”结果？

也许你会问：为什么不直接定义”实际发生的结果”？

原因是：**因果效应本质上是一个反事实（counterfactual）概念**。

当我们问”这种药是否有效”时，我们实际上是在问：”如果这个患者吃了药，结果会怎样？”但现实是，这个患者可能没有吃药，所以我们只能想象（counterfactual）另一种情况。

这种潜在结果的思维方式，帮助我们澄清了因果效应的本质。

2.6 稳定单位治疗值假设（SUTVA）

使用潜在结果框架需要一些假设，其中最重要的是 SUTVA（Stable Unit Treatment Value Assumption）：

定理 2.1 (SUTVA). *1.* **一致性（*Consistency*）**：对于每个个体，观察到的结果等于其对应治疗下的潜在结果：

$$Y_i = T_i \cdot Y_i(1) + (1 - T_i) \cdot Y_i(0)$$

2. **互不干扰（*No interference*）**：一个个体的潜在结果不受其他个体治疗分配的影响：

$$Y_i(t_1, \ldots, t_n) = Y_i(t_i) \quad \text{对所有} t_1, \ldots, t_n$$

简单来说，SUTVA 假设：

- 治疗效果是稳定的
- 你的结果不受他人治疗的影响

这些假设在很多实际场景中可能不成立（例如，疫苗的群体免疫效应就违反了互不干扰假设），我们需要根据具体情况判断是否适用。

2.7 本章小结

本章我们建立了因果推断的数学基础：

1. **潜在结果框架**：为每个个体定义 $Y_i(1)$ 和 $Y_i(0)$
2. **个体因果效应**：$\tau_i = Y_i(1) - Y_i(0)$
3. **平均因果效应**：$\tau_{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)]$
4. **根本问题**：我们无法同时观察到两种潜在结果
5. **SUTVA 假设**：保证潜在结果框架的有效性

下一章我们将学习**随机实验（Randomized Experiments）**——在某些情况下，我们可以绕过因果推断的根本问题，直接识别因果效应。

Chapter 3

完全随机实验与 FRT

3.1 为什么需要随机实验？

在上一章中，我们学习了潜在结果框架，知道了因果效应的定义：

$$\tau_{ATE} = \mathbb{E}[Y_i(1) - Y_i(0)]$$

但我们也认识到了因果推断的根本问题：对于每个个体，我们只能观察到一种潜在结果，无法同时观察到 $Y_i(1)$ 和 $Y_i(0)$。

那么，如何解决这个问题？如何才能识别（identify）因果效应？

答案就是：随机实验。

3.2 随机实验的基本思想

随机实验的核心思想非常简单但极其强大：

通过随机分配治疗，使得治疗组和对照组在平均意义上是”可比”的。

当我们随机分配治疗时，治疗分配 T_i 与潜在结果 $Y_i(0), Y_i(1)$ 是独立的：

$$T_i \perp Y_i(0), Y_i(1)$$

这意味着，随机分配能够自动平衡两组之间的所有混杂因素（无论是我们已知的还是未知的）。

3.3 完全随机实验的定义

定义 3.1 (完全随机实验). 设有 n 个样本，其中 n_1 个被分配到治疗组，$n_0 = n - n_1$ 个被分配到对照组。完全随机实验（*Completely Randomized Experiment*）满足以下条件：

1. 每个个体被分配到治疗组的概率为 n_1/n；
2. 治疗组总人数固定为 n_1；

3. 个体之间相互独立。

在完全随机实验下，我们可以证明：

$$\mathbb{E}[\bar{Y}(1) - \bar{Y}(0)] = \tau_{ATE}$$

也就是说，**观察到的组间差异就是平均因果效应的无偏估计**！这正是随机实验的魔力所在。

3.4 费舍尔随机化检验（FRT）

虽然随机实验可以估计因果效应，但我们还需要统计检验来判断观察到的效应是否是真实的，而不是随机波动造成的。

费舍尔 (Ronald Fisher) 提出了一个优雅的解决方案——费舍尔随机化检验（Fisher's Randomization Test, FRT）。

3.4.1 为什么需要 FRT？

传统统计方法依赖于" 正态分布假设"——假设数据来自正态分布。但在因果推断中，我们的" 总体" 是有限的（finite population），而且我们关心的是特定处理分配的随机性，而不是从某个分布中抽样。

FRT 的核心思想是：**在零假设下，所有可能的治疗分配都是等可能的**。因此，我们可以精确计算检验的 p 值，而不需要任何分布假设。

3.4.2 零假设

FRT 的零假设是：

$$H_0 : Y_i(0) = Y_i(1) \quad \text{对所有} i$$

也就是说，治疗没有任何效果（所有个体的潜在结果都相等）。

在这个零假设下，观察到的结果 Y_i 就等于 $Y_i(0) = Y_i(1)$，与治疗分配无关。

3.5 检验统计量的选择

在 FRT 框架下，我们可以选择不同的检验统计量。不同的统计量对不同的备择假设有不同的功效（power）。

3.5.1 差值均值（Difference-in-means）

最直观的统计量是差值均值：

$$\hat{\tau} = \bar{Y}(1) - \bar{Y}(0)$$

在零假设下，$\hat{\tau}$ 的期望为 0，方差为：

$$\mathrm{Var}(\hat{\tau}) = \frac{s^2}{n_1 n_0}$$

其中 s^2 是合并的样本方差。

利用有限总体中心极限定理（Finite Population CLT），我们可以得到：

$$\frac{\hat{\tau}}{\sqrt{s^2/(n_1 n_0)}} \xrightarrow{d} N(0,1)$$

有趣的是，这个统计量与经典的方差相等的 t 检验统计量非常接近！

3.5.2 学生化统计量（Studentized statistic）

差值均值假设两组方差相等。如果两组方差不相等（异方差），我们需要使用学生化统计量：

$$t = \frac{\bar{Y}(1) - \bar{Y}(0)}{\sqrt{\hat{S}^2(1)/n_1 + \hat{S}^2(0)/n_0}}$$

这个统计量与方差不等的 t 检验统计量（`t.test(var.equal = FALSE)`）渐近等价。

用户注解: 为什么需要学生化统计量？当治疗组和对照组的方差差异较大时，差值均值的检验可能失效。学生化统计量通过分别估计两组的方差，能够更好地处理这种异方差情况。

3.5.3 Wilcoxon 秩和统计量

差值均值和学生化统计量都使用原始观测值，因此对异常值（outliers）敏感。一个更稳健的选择是 Wilcoxon 秩和统计量：

$$W = \sum_{i=1}^{n} Z_i R_i$$

其中 R_i 是 Y_i 在合并样本中的秩。

Wilcoxon 秩和统计量的优点是：

- 对异常值稳健
- 只依赖于数据的秩次信息
- 在许多备择假设下都有较好的功效

3.5.4 Kolmogorov-Smirnov 统计量

上述统计量主要关注均值差异。但治疗效应可能以其他方式体现（例如改变分布的形状）。KS 统计量衡量两个分布之间的最大差距：

$$D = \max_y |\hat{F}_1(y) - \hat{F}_0(y)|$$

这个统计量能够检测分布形状的差异，而不仅仅是均值差异。

3.6 LaLonde 实验数据案例

LaLonde (1986) 的实验数据是因果推断领域的经典案例。

3.6.1 背景

LaLonde 研究了一项职业培训项目（National Supported Work Demonstration）对参与者收入的影响。实验将参与者随机分配到治疗组（接受培训）或对照组（不接受培训），观察他们在 1978 年的真实收入（re78）。

3.6.2 R 语言分析基础

本案例使用 R 语言的 `Matching` 包进行 FRT 分析。数据可以直接从 R 中加载：

```
> library(Matching)
> data(lalonde)
> z <- lalonde\$treat
> y <- lalonde\$re78
```

其中：

- `z`: 二元治疗向量（1 = 治疗组，0 = 对照组）
- `y`: 1978 年真实收入（outcome）

3.6.3 数据分析

使用 R 语言进行 FRT 分析的结果：

统计量	观测值	描述
$\hat{\tau}$	2.84	差值均值
t	2.67	学生化统计量
W	27402.5	Wilcoxon 秩和
D	0.132	KS 统计量

通过随机置换治疗向量 10,000 次，我们可以得到这些统计量的随机化分布，进而计算精确 p 值。

3.7 FRT 与传统 t 检验的关系

一个非常重要的洞察是：

FRT 为传统 t 检验提供了理论依据！

传统 t 检验基于”数据来自正态分布”的假设。但在 FRT 框架下，即使数据不服从正态分布，只要有限总体中心极限定理成立，t 检验程序仍然可以使用！

这是因为 FRT 的渐近性质只依赖于有限总体 CLT，而 CLT 对很多分布都是成立的。

用户注解: FRT 的意义是什么？*FRT 证明了传统统计方法在因果推断中的合理性。我们不需要担心正态性假设是否满足，只需要关注随机化分配是否正确执行。*

3.7.1 FRT 与 t 检验的对比

在实际应用中，我们需要理解两者在什么情况下相同、什么情况下不同。

相同的时候：

1. **大样本下渐近等价**：当样本量足够大时，差值均值 $\hat{\tau}$ 与方差相等的 t 检验渐近等价；学生化统计量 t 与方差不等的 t 检验渐近等价。
2. **零假设 $H_0 : Y_i(0) = Y_i(1)$ 时**：两者都检验”治疗没有任何效果”。

不同的时候：

1. **理论基础不同**：t 检验假设数据来自正态分布（无限总体），而 FRT 基于治疗分配的随机性（有限总体）。
2. **小样本时**：FRT 可以给出精确的有限样本 p 值，而 t 检验依赖正态性假设，在小样本时可能不准确。
3. **异方差情况下**：当两组方差不相等时，FRT 的功效可能低于方差不等的 t 检验。

实际选择建议：

- 大样本、正态/近似正态：两者皆可，结果相近；
- 小样本、非正态：FRT 更可靠；
- 已知两组方差不等：t 检验（`var.equal=FALSE`）可能更有效；
- 需要精确 p 值：优先使用 FRT。

3.8 3.6 讨论

3.8.1 其他 Sharp Null 假设与置信区间

除了之前讨论的 sharp null 假设 $H_0 : Y_i(0) = Y_i(1)$（所有个体的治疗效应为零），FRT 框架还可以应用于其他假设。

例如，我们可以检验弱 null 假设 $H_0 : \tau_{ATE} = 0$（平均因果效应为零，但个体效应可能不为零）。在这种情况下，我们需要更多假设来构建置信区间。

3.8.2 FRT 的优势与局限

优势：

- 不需要任何分布假设；
- 提供精确的有限样本 p 值；
- 理论基础稳固——完全基于随机化设计。

局限：

- 计算复杂度高（当样本量大时）；
- 只能检验 sharp null 假设；
- 对于连续型结果，精确检验可能功效较低。

3.9 本章小结

本章我们学习了因果推断的" 金标准"——随机实验：

1. **随机实验**：通过随机分配平衡混杂因素，使得观察到的组间差异可以直接解释为因果效应
2. **费舍尔随机化检验（FRT）**：基于治疗分配随机性的精确检验方法
3. **多种检验统计量**：差值均值、学生化统计量、Wilcoxon 秩和、KS 统计量
4. **LaLonde 案例**：经典的实际应用示例
5. **理论意义**：FRT 为传统 t 检验提供了更坚实的基础

下一章我们将学习如何在观察性研究（observational study）中估计因果效应——这需要更多的假设和方法。

Appendix A

问答与注解

A.1 阅读过程中的问题与解答

暂无记录

当你在阅读过程中提出问题时，回答将被记录在此处。

A.2 学习笔记

在这里记录你的学习心得和思考。