

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;

5.7. 均匀分布到指数分布的极限. 背景：证明 $n(\theta - Y_n) \xrightarrow{D} \Gamma(1, \theta)$ 。

推导：

对 $t > 0$,

$$\mathbb{P}[n(\theta - Y_n) \leq t] = \mathbb{P}[Y_n \geq \theta - t/n] = 1 - F_{Y_n}(\theta - t/n).$$

由 $F_{Y_n}(t) = (t/\theta)^n$ (对 $0 < t \leq \theta$),

$$1 - F_{Y_n}(\theta - t/n) = 1 - \left(\frac{\theta - t/n}{\theta}\right)^n = 1 - \left(1 - \frac{t}{n\theta}\right)^n.$$

令 $n \rightarrow \infty$,

$$\lim_{n \rightarrow \infty} \left(1 - \frac{t}{n\theta}\right)^n = e^{-t/\theta}.$$

因此

$$\lim_{n \rightarrow \infty} \mathbb{P}[n(\theta - Y_n) \leq t] = 1 - e^{-t/\theta},$$

这正是 $\Gamma(1, \theta)$ (指数分布) 的 CDF。

5.8. 依概率收敛推出依分布收敛的证明. 背景：证明定理 5.2.1。

目标：若 $X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{D} X$ 。

推导步骤：

1. 设 x 是 F_X 的连续点。对 $\epsilon > 0$,

$$F_{X_n}(x) = \mathbb{P}[X_n \leq x] = \mathbb{P}[X_n \leq x, |X_n - X| < \epsilon] + \mathbb{P}[X_n \leq x, |X_n - X| \geq \epsilon].$$

2. 第一个概率 $\leq \mathbb{P}[X \leq x + \epsilon]$, 第二个概率 $\leq \mathbb{P}[|X_n - X| \geq \epsilon]$ 。因此

$$F_{X_n}(x) \leq F_X(x + \epsilon) + \mathbb{P}[|X_n - X| \geq \epsilon].$$

3. 取上确界并令 $n \rightarrow \infty$ (利用 $X_n \xrightarrow{P} X$), 再令 $\epsilon \rightarrow 0$ (利用 x 是连续点), 可得

$$\overline{\lim}_{n \rightarrow \infty} F_{X_n}(x) \leq F_X(x).$$

4. 类似地可得

$$\underline{\lim}_{n \rightarrow \infty} F_{X_n}(x) \geq F_X(x).$$

5. 因此 $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$ 。

证毕。

5.9. Slutsky 定理的详细证明. 背景：Slutsky 定理是连接依概率收敛和依分布收敛的关键工具。

定理陈述：若 $X_n \xrightarrow{D} X$, $A_n \xrightarrow{P} a$, $B_n \xrightarrow{P} b$, 则 $A_n + B_n X_n \xrightarrow{D} a + bX$ 。

推导步骤：

1. 首先证明 $B_n X_n \xrightarrow{D} bX$ 。

考虑 $B_n X_n = bX_n + (B_n - b)X_n$ 。由 $B_n \xrightarrow{P} b$, 有 $B_n - b \xrightarrow{P} 0$ 。

2. 由定理 5.2.6 (依分布收敛蕴含概率有界), X_n 概率有界。

3. 应用定理 5.2.7 (概率有界序列与依概率收敛到零的乘积趋于零):

$$(B_n - b)X_n \xrightarrow{P} 0.$$

4. 由定理 5.2.3 (和的极限分布), $bX_n + (B_n - b)X_n \xrightarrow{D} bX$ 。

5. 再考虑 $A_n + B_nX_n = a + bX + (A_n - a) + (B_nX_n - bX)$ 。

由于 $(A_n - a) \xrightarrow{P} 0$ 和 $(B_nX_n - bX) \xrightarrow{P} 0$, 再次应用定理 5.2.3 可得

$$A_n + B_nX_n \xrightarrow{D} a + bX.$$

证毕。

核心洞察: Slutsky 定理允许我们将依概率收敛的随机变量”替换”为其极限常数, 而不影响依分布收敛性。

5.10. 概率有界与乘积收敛的证明. 背景: 证明定理 5.2.7。

目标: 若 X_n 概率有界, $Y_n \xrightarrow{P} 0$, 则 $X_nY_n \xrightarrow{P} 0$ 。

推导步骤:

1. 由概率有界性, 对 $\epsilon > 0$, 存在 B_ϵ 和 N_ϵ 使得

$$n \geq N_\epsilon \Rightarrow \mathbb{P}[|X_n| \leq B_\epsilon] \geq 1 - \epsilon.$$

2. 对任意 $\delta > 0$,

$$\mathbb{P}[|X_nY_n| \geq \delta] = \mathbb{P}[|X_nY_n| \geq \delta, |X_n| \leq B_\epsilon] + \mathbb{P}[|X_nY_n| \geq \delta, |X_n| > B_\epsilon].$$

3. 第一个概率 $\leq \mathbb{P}[|Y_n| \geq \delta/B_\epsilon]$, 第二个概率 $\leq \mathbb{P}[|X_n| > B_\epsilon] \leq \epsilon$ 。

4. 由于 $Y_n \xrightarrow{P} 0$, 当 n 足够大时, 第一个概率 $< \epsilon$ 。

5. 因此对足够大的 n , $\mathbb{P}[|X_nY_n| \geq \delta] \leq 2\epsilon$ 。

由 ϵ 和 δ 的任意性, $X_nY_n \xrightarrow{P} 0$ 。

证毕。

5.11. Δ 方法的完整推导. 背景: Δ 方法提供了一种计算统计量函数渐近分布的系统方法。

定理陈述: 设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, g 在 θ 处可微且 $g'(\theta) \neq 0$ 。则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

推导步骤:

1. 由 Taylor 展开 (带余项):

$$g(X_n) = g(\theta) + g'(\theta)(X_n - \theta) + o_p(|X_n - \theta|).$$

2. 两边乘以 $\sqrt{n}$:

$$\sqrt{n}(g(X_n) - g(\theta)) = g'(\theta)\sqrt{n}(X_n - \theta) + o_p(\sqrt{n}|X_n - \theta|).$$

3. 由假设, $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 故 $\sqrt{n}|X_n - \theta|$ 概率有界。

4. 由 o_p 的定义, $o_p(\sqrt{n}|X_n - \theta|) \xrightarrow{P} 0$ 。

5. 应用 Slutsky 定理（或更精确地，定理 5.2.3），可得

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

证毕。

应用举例：卡方分布的平方根。设 $Z_n \sim \chi^2(n)$ ，则

$$\sqrt{n} \left(\frac{Z_n}{n} - 1 \right) \xrightarrow{D} N(0, 2).$$

取 $g(t) = \sqrt{t}$ ，则 $g'(1) = 1/2$ ，故

$$\sqrt{n}(\sqrt{Z_n/n} - 1) \xrightarrow{D} N(0, 2 \cdot (1/2)^2) = N(0, 1/2).$$

5.12. 二项分布的正态近似误差分析. 背景：二项分布 $b(n, p)$ 在大样本下可用正态分布近似。

误差分析：

设 $Y \sim b(n, p)$ ， $\mu = np$ ， $\sigma^2 = np(1-p)$ 。则

$$Z = \frac{Y - \mu}{\sigma} \xrightarrow{D} N(0, 1).$$

Berry-Esseen 不等式给出了收敛速度的估计：

$$\sup_x |\mathbb{P}(Z \leq x) - \Phi(x)| \leq \frac{C \cdot \rho}{\sigma^3 \sqrt{n}},$$

其中 $\rho = E(|X - \mu|^3)$ ， C 是某个绝对常数（约 0.4748）。

实践意义：当 $np(1-p) \geq 10$ 时，正态近似效果较好。

连续性校正的效果：对于离散分布，使用 ± 0.5 的校正通常可以将误差减少一半。

5.13. 中心极限定理的 MGF 证明. 背景：中心极限定理（CLT）的矩母函数证明。

假设： $X_1, \dots, X_n$ 是 iid 随机变量， $E(X_i) = \mu$ ， $\text{Var}(X_i) = \sigma^2$ ，矩母函数 $M(t) = E(e^{tX})$ 在 0 的邻域内存在。

目标：证明

$$Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \xrightarrow{D} N(0, 1).$$

推导步骤：

1. 考虑 $X_i - \mu$ 的矩母函数 $m(t) = E(e^{t(X_i - \mu)})$ 。则 $m(0) = 1$ ， $m'(0) = 0$ ， $m''(0) = \sigma^2$ 。

2. 由 Taylor 公式，存在 ξ （介于 0 和 t 之间）使得

$$m(t) = 1 + \frac{\sigma^2 t^2}{2} + \frac{[m''(\xi) - \sigma^2] t^2}{2}. \quad (5.3.1)$$

3. Y_n 的矩母函数为

$$M_{Y_n}(t) = E \left[\exp \left(t \frac{\sum X_i - n\mu}{\sqrt{n}\sigma} \right) \right] = [m(t/(\sigma\sqrt{n}))]^n. \quad (5.3.2)$$

4. 将 $t/(\sigma\sqrt{n})$ 代入 (5.3.1)：

$$m \left(\frac{t}{\sigma\sqrt{n}} \right) = 1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2] t^2}{2n\sigma^2},$$

其中 ξ 介于 0 和 $t/(\sigma\sqrt{n})$ 之间。

5. 因此

$$M_{Y_n}(t) = \left[1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2]t^2}{2n\sigma^2} \right]^n.$$

6. 由于 $m''(t)$ 在 0 处连续, 且 $\xi \rightarrow 0$ 当 $n \rightarrow \infty$, 故

$$\lim_{n \rightarrow \infty} [m''(\xi) - \sigma^2] = 0.$$

7. 应用极限定理 (5.2.16):

$$\lim_{n \rightarrow \infty} M_{Y_n}(t) = \lim_{n \rightarrow \infty} \left[1 + \frac{t^2}{2n} \right]^n = e^{t^2/2},$$

这正是 $N(0, 1)$ 的矩母函数。

结论: 由矩母函数收敛定理, $Y_n \xrightarrow{D} N(0, 1)$ 。

证毕。

注: 若不使用矩母函数而使用特征函数, 则证明对所有分布成立 (特征函数总是存在的)。

5.14. 均匀分布样本均值的概率计算. 背景: 计算 $P(0.45 < \bar{X} < 0.55)$ 的近似值。

已知条件:

- $X_i \sim \text{Uniform}(0, 1)$
- $n = 75$
- $\mu = 1/2, \sigma^2 = 1/12$

推导步骤:

1. 由 CLT,

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \approx N(0, 1).$$

2. 标准化:

$$P(0.45 < \bar{X} < 0.55) = P\left(\frac{\sqrt{n}(0.45 - \mu)}{\sigma} < \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} < \frac{\sqrt{n}(0.55 - \mu)}{\sigma}\right).$$

3. 代入数值:

$$\frac{\sqrt{75}(0.5 - 0.5)}{1/\sqrt{12}} = 0, \quad \frac{\sqrt{75}(0.55 - 0.5)}{1/\sqrt{12}} = \sqrt{75} \cdot 0.05 \cdot \sqrt{12} \approx 1.5.$$

4. 因此

$$P(0.45 < \bar{X} < 0.55) \approx \Phi(1.5) - \Phi(-1.5) = 2\Phi(1.5) - 1 \approx 2(0.9332) - 1 = 0.8664.$$

精确值比较: 使用 R 计算精确概率约为 0.864, 近似值 0.866 非常接近。

5.15. 比例推断的详细讨论. 背景：大样本比例推断的理论基础。

设 $X_1, \dots, X_n \sim \text{Bernoulli}(p)$, $\hat{p} = \bar{X}$ 。

推导步骤：

1. 由 CLT,

$$\frac{\sqrt{n}(\hat{p} - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1). \quad (5.3.4)$$

2. 但 p 未知! 用 $\hat{p}$ 替代 p 。需证明

$$\frac{\hat{p}(1-\hat{p})}{p(1-p)} \xrightarrow{P} 1. \quad (5.3.6)$$

3. 由弱大数定律, $\hat{p} \xrightarrow{P} p$, 再由连续映射定理,

$$\hat{p}(1-\hat{p}) \xrightarrow{P} p(1-p).$$

4. 由 Slutsky 定理,

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})/n}} = \frac{\sigma}{\sqrt{\hat{p}(1-\hat{p})}} \cdot \frac{\sqrt{n}(\hat{p} - p)}{\sigma} \xrightarrow{D} N(0, 1). \quad (5.3.7)$$

这正是大样本比例置信区间和假设检验的理论基础。

置信区间： p 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]. \quad (5.3.8)$$

假设检验： 检验 $H_0: p = p_0$ 的检验统计量为

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} \xrightarrow{H_0} N(0, 1). \quad (5.3.9)$$

5.16. 方差稳定化变换. 背景：在例 5.3.7 中, 我们寻求一个变换使渐近方差与参数无关。

问题：设 $X \sim \text{Binomial}(1, p)$, $\hat{p} = \bar{X}$ 。求变换 g 使得 $\text{Var}[\sqrt{n}g(\hat{p})]$ 与 p 无关。

推导步骤：

1. 由 Δ 方法,

$$\text{Var}[\sqrt{n}g(\hat{p})] \approx \sigma^2[g'(p)]^2 = p(1-p)[g'(p)]^2. \quad (5.3.10)$$

2. 要求 $p(1-p)[g'(p)]^2 = c$ (常数), 即

$$g'(p) = \frac{c}{\sqrt{p(1-p)}}. \quad (5.3.11)$$

3. 积分得

$$g(p) = c \int \frac{1}{\sqrt{p(1-p)}} dp = 2c \arcsin(\sqrt{p}) + \text{常数}. \quad (5.3.12)$$

4. 取 $c = 1/2$ 可得最简单的形式 $g(p) = \arcsin(\sqrt{p})$ 。

结论：变换 $g(\hat{p}) = \arcsin(\sqrt{\hat{p}})$ 的渐近方差为 $1/(4n)$, 与 p 无关。²¹

²¹方差稳定化变换的更多应用见 DeGroot 和 Schervish 的《概率与统计》。

5.17. 多元中心极限定理的证明. 背景: 多元中心极限定理说明样本均值向量的标准化形式依分布收敛到多元正态分布。

定理陈述: 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 是 iid 随机向量, 均值向量为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ (正定)。则

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.3)$$

推导步骤:

1. 对任意固定向量 $\mathbf{t} \in \mathbb{R}^p$, 考虑随机变量 $W_i = \mathbf{t}'\mathbf{X}_i$ 。

2. 则 $E(W_i) = \mathbf{t}'\boldsymbol{\mu}$, $\text{Var}(W_i) = \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}$ 。

3. 对 $W_1, \dots, W_n$ 应用一元 CLT:

$$\sqrt{n}(\bar{W}_n - \mathbf{t}'\boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}). \quad (5.4.8)$$

4. 但 $\bar{W}_n = \mathbf{t}'\bar{\mathbf{X}}_n$, 故

$$\sqrt{n}(\mathbf{t}'\bar{\mathbf{X}}_n - \mathbf{t}'\boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}). \quad (5.4.9)$$

5. 由 Cramer-Wold 定理 (若对所有 $\mathbf{t}$, $\mathbf{t}'\mathbf{X}_n \xrightarrow{D} \mathbf{t}'\mathbf{X}$, 则 $\mathbf{X}_n \xrightarrow{D} \mathbf{X}$), 可得

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.10)$$

证毕。

注: Cramer-Wold 定理的证明依赖于特征函数的一致有界性和逆转公式。

CHAPTER 6

Maximum Likelihood Methods

Chapter 6 Overview

在前五章中，我们建立了描述概率分布、进行统计推断的理论框架，并探讨了估计量的一致性和渐近分布。现在我们面临一个根本性问题：

面对观测数据，如何找到“最优”的参数估计方法？

这个问题促使我们发展出统计学中最重要、应用最广泛的估计理论——**最大似然估计 (Maximum Likelihood Estimation, MLE)**。

为什么需要最大似然估计？ 回顾 Chapter 4 的矩估计法，我们发现它虽然直观，但在某些情况下效率较低。最大似然估计则不同——在适当的正则条件下，它不仅是一致的，而且是**渐近有效的 (asymptotically efficient)**，即达到了估计方差的下界。

本章建立一套完整的基于似然的统计推断理论：

- **点估计**：MLE 的定义、性质，以及如何通过似然方程求解
- **方差下界**：Rao-Cramér 不等式揭示任何无偏估计的方差都有下界，而 MLE 渐近达到这个下界
- **假设检验**：似然比检验、Wald 检验、Score 检验构成三大类似然检验方法
- **多参数情形**：将理论推广到参数向量的情形
- **EM 算法**：处理缺失数据或隐变量的强大迭代方法

本章路线图：似然函数 $\rightarrow$ MLE 定义 $\rightarrow$ Rao-Cramér 下界 $\rightarrow$ 渐近有效性 $\rightarrow$ 似然比检验 $\rightarrow$ 多参数扩展 $\rightarrow$ EM 算法

1. 6.1 Maximum Likelihood Estimation

1.1. 似然函数的起源。 在 Chapter 4 中，我们遇到了一个问题：给定数据 $x_1, x_2, \dots, x_n$ ，哪个参数值最“合理”？

这个问题的自然答案是：**使得观测到当前数据的概率最大的参数值**。这就是最大似然估计的核心思想。

设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的 iid 样本，其中 $\theta \in \Omega$ 是未知参数。则样本的联合密度为

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta), \quad \theta \in \Omega. \quad (6.1.1)$$

为什么叫“似然” (Likelihood) 而不是“概率” (Probability)？ 这里的关键在于：概率是关于数据的函数（已知参数，求数据的概率），而似然是关于参数的函数（已知数据，求参数的可能性）。虽然数学形式相同，但解释的角度不同。

定义 $l(\theta) = \log L(\theta)$ 为对数似然函数。使用对数是出于计算便利——乘积变成求和，在求导时更方便。

1.2. MLE 的定义与存在性. 最大似然估计量 $\hat{\theta}$ 是使得似然函数最大化的参数值：

$$\hat{\theta} = \arg \max_{\theta \in \Omega} L(\theta; \mathbf{x}). \quad (6.1.2)$$

直观上，这个估计量代表“最有可能产生观测数据的参数值”。

下面的定理从理论上证明了 MLE 的合理性。

heorem[似然函数的渐近支撑] 设 θ_0 是参数真值，在正则条件 (R0)-(R2) 下，

$$\lim_{n \rightarrow \infty} \mathbb{P}_{\theta_0} [L(\theta_0; \mathbf{X}) > L(\theta; \mathbf{X})] = 1, \quad \forall \theta \neq \theta_0. \quad (6.1.3)$$

heorem

证明思路： 由于 θ_0 是内点，存在领域使得似然函数在该领域内取得最大值。随着 n 增大，似然函数在 θ_0 处超过相邻点的概率趋于 1，因此解序列收敛到 θ_0 。¹

在正则条件下，MLE 可以通过求解似然方程 (likelihood equation) 得到：

$$\frac{\partial l(\theta)}{\partial \theta} = 0. \quad (6.1.4)$$

但要注意：MLE 不唯一存在，且可能没有解析解。

1.3. 经典例子.

EXAMPLE 6.1 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$ ，其中 σ^2 已知， θ 未知。对数似然函数为

$$l(\theta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2.$$

求导并令为零：

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \theta) = \frac{n(\bar{x} - \theta)}{\sigma^2} = 0.$$

解得 $\hat{\theta} = \bar{x}$ 。这是样本均值。

意义： 对于正态分布，样本均值不仅是矩估计量，也是最大似然估计量。

定理 6.1.2 的 Invariance 性质： 若 $\hat{\theta}$ 是 θ 的 MLE，则对任意函数 $g(\theta)$ ， $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE。²

EXAMPLE 6.2 (约束参数空间的 MLE). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$ ，但已知 $\theta \in [0, 1/3]$ 。若样本均值 $\bar{x} > 1/3$ ，则 MLE 为 $\hat{\theta} = 1/3$ 。

这是因为对数似然在 $\theta < \bar{x}$ 时单调递增，所以在约束边界处取得最大值。

启示： 当参数空间有约束时，MLE 可能在边界取得。

¹该定理的完整证明见附录 section 7.1。

²Laplace 分布 MLE 的完整推导见附录 ??。

EXAMPLE 6.3 (Cauchy 分布的 MLE). 设 $X_1, \dots, X_5$ 来自标准 *Cauchy* 分布 $f(x; \theta) = \frac{1}{\pi[1+(x-\theta)^2]}$ 。对于数据 $(-1.94, 0.59, -5.98, -0.08, -0.77)$, MLE 需要数值方法求解。

Cauchy 分布的似然函数无解析解, 需通过数值优化 (如 *Newton* 法) 获得 $\hat{\theta}$ 。这在实际应用中很常见。

注: *Cauchy* 分布不满足某些正则条件, 但其 MLE 仍然是一致的。

1.4. MLE 的一致性. 下面证明在正则条件下, MLE 是真值的相合估计量。

heorem[MLE 的相合性] 在正则条件 (R0)-(R2) 下, 设 $\hat{\theta}_n$ 是似然方程的解序列。则

$$\hat{\theta}_n \xrightarrow{P} \theta_0.$$

heorem

证明思路: 由于 θ_0 是内点, 存在领域使得似然函数在该领域内取得最大值。随着 n 增大, 似然函数在 θ_0 处超过相邻点的概率趋于 1, 因此解序列收敛到 θ_0 。³

这一定理保证了: 在大样本下, MLE 任意接近真值的概率趋于 1。

1.5. Summary of Section 6.1.

- 似然函数 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ 衡量参数 θ 产生观测数据的”可能性”
- MLE $\hat{\theta}$ 最大化似然函数, 是”最可能”产生数据的参数值
- 在正则条件下, MLE 是一致的 ($\hat{\theta}_n \xrightarrow{P} \theta_0$)
- MLE 可以通过求解似然方程 $\partial l(\theta)/\partial \theta = 0$ 得到
- MLE 具有不变性: 若 $\hat{\theta}$ 是 θ 的 MLE, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE

2. 6.2 Rao-Cramér Lower Bound and Efficiency

2.1. 为什么估计量的方差有下界? 我们已经知道 MLE 是一致的。但这只告诉我们估计量在大样本下趋于真值, 却没有告诉我们收敛的速度有多快。

一个自然的疑问是: 对于给定的分布, 是否存在方差最小的估计量? 方差能小到什么程度?

Rao-Cramér 下界回答了这个问题。

2.2. Fisher 信息量. 在推导下界之前, 我们需要一个关键概念——Fisher 信息量。

设 $X \sim f(x; \theta)$, 定义得分函数 (score function) 为

$$S(X; \theta) = \frac{\partial \log f(X; \theta)}{\partial \theta}. \quad (6.2.1)$$

得分函数的期望为零 (这是正则条件的直接结果):

$$\mathbb{E}_\theta[S(X; \theta)] = 0. \quad (6.2.2)$$

Fisher 信息量定义为得分函数的方差:

³该定理的完整证明见附录 ??。

$$I(\theta) = \text{Var}(S(X; \theta)) = \mathbb{E}_\theta \left[\left(\frac{\partial \log f(X; \theta)}{\partial \theta} \right)^2 \right]. \quad (6.2.3)$$

直观上理解：若 θ 的微小变化会导致密度函数较大的变化，则我们对 θ 的了解就更多，信息量就越大。

等价的计算公式（通常更方便）是

$$I(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta^2} \right]. \quad (6.2.4)$$

对于样本 $X_1, \dots, X_n$ (iid)，Fisher 信息为单个样本信息的 n 倍：

$$I_n(\theta) = nI(\theta). \quad (6.2.5)$$

EXAMPLE 6.4 (Bernoulli 分布的 Fisher 信息). 设 $X \sim \text{Bernoulli}(\theta)$ ，则

$$\log f(x; \theta) = x \log \theta + (1 - x) \log(1 - \theta),$$

$$\frac{\partial \log f}{\partial \theta} = \frac{x}{\theta} - \frac{1 - x}{1 - \theta},$$

$$\frac{\partial^2 \log f}{\partial \theta^2} = -\frac{x}{\theta^2} - \frac{1 - x}{(1 - \theta)^2}.$$

因此

$$I(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta^2} \right] = \frac{1}{\theta} + \frac{1}{1 - \theta} = \frac{1}{\theta(1 - \theta)}.$$

含义：当 θ 接近 0 或 1 时，信息量很大（分布几乎确定）；当 $\theta = 1/2$ 时，信息量最小（最不确定）。

EXAMPLE 6.5 (位置族的 Fisher 信息). 设 $X = \theta + e$ ，其中 e 的密度为 $f(z)$ ，与 θ 无关。则

$$f_X(x; \theta) = f(x - \theta).$$

可以验证，Fisher 信息 $I(\theta)$ 与 θ 无关，仅由误差分布 f 决定。⁴

对于 Laplace 分布 $f(z) = \frac{1}{2}e^{-|z|}$ ，信息 $I(\theta) = 1$ 。

⁴Bernoulli 分布和位置族 Fisher 信息的详细推导见附录 ??。

2.3. Rao-Cramér 不等式. 现在我们可以陈述主要结果。

theorem[Rao-Cramér 下界] 设 $X_1, \dots, X_n$ iid $\sim f(x; \theta)$, 满足正则条件 (R0)-(R4)。令 $Y = u(X_1, \dots, X_n)$ 是任意统计量, 其期望为 $\mathbb{E}_\theta[Y] = k(\theta)$ 。则

$$\text{Var}(Y) \geq \frac{[k'(\theta)]^2}{nI(\theta)}. \quad (6.2.6)$$

特别地, 若 Y 是 θ 的无偏估计 ($k(\theta) = \theta$), 则

$$\text{Var}(Y) \geq \frac{1}{nI(\theta)}. \quad (6.2.7)$$

theorem

证明思路: 利用 Cauchy-Schwarz 不等式和得分函数的性质。令 $Z = \sum_{i=1}^n \frac{\partial \log f(X_i; \theta)}{\partial \theta}$, 则 $\mathbb{E}(Z) = 0$, $\text{Var}(Z) = nI(\theta)$ 。由 $k'(\theta) = \mathbb{E}(YZ)$ 和 $|\text{corr}(Y, Z)| \leq 1$ 可得结论。⁵

直观理解: Fisher 信息量 $I(\theta)$ 决定了估计精度能达到的极限。信息量越大, 下界越低, 我们能越精确地估计 θ 。

2.4. 有效估计量.

DEFINITION 6.1 (有效估计量). 若无偏估计量 $\hat{\theta}$ 的方差达到 Rao-Cramér 下界, 即

$$\text{Var}(\hat{\theta}) = \frac{1}{nI(\theta)},$$

则称 $\hat{\theta}$ 为 θ 的**有效估计量 (efficient estimator)**。

EXAMPLE 6.6 (Bernoulli 分布的有效估计). 对于 Bernoulli 分布, 我们有 $I(\theta) = 1/[\theta(1-\theta)]$, 因此 Rao-Cramér 下界为 $\theta(1-\theta)/n$ 。

样本均值 $\bar{X}$ 是 θ 的无偏估计, 其方差为 $\text{Var}(\bar{X}) = \theta(1-\theta)/n$ 。

因此 $\bar{X}$ 是有效估计量!

这意味着: 对于 Bernoulli 分布, 不存在任何无偏估计量比样本均值更有效。

EXAMPLE 6.7 (正态分布的样本均值). 对于 $N(\theta, \sigma^2)$ (σ^2 已知), Fisher 信息 $I(\theta) = 1/\sigma^2$, Rao-Cramér 下界为 σ^2/n 。

样本均值 $\bar{X}$ 的方差为 σ^2/n , 因此 $\bar{X}$ 是有效估计量。

但有效估计量并不总是存在。

EXAMPLE 6.8 (Beta($\theta, 1$) 分布). 设 $X_1, \dots, X_n \sim \text{beta}(\theta, 1)$, 密度为 $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$ 。

MLE 为 $\hat{\theta} = -n / \sum_{i=1}^n \log X_i$ 。

该估计量是有偏的, 其方差为 $\text{Var}(\hat{\theta}) = \theta^2 n^2 / [(n-1)^2(n-2)]$, 而 Rao-Cramér 下界为 θ^2/n 。

因此 $\hat{\theta}$ 不是有效的, 但修正偏后的估计量 $[(n-1)/n]\hat{\theta}$ 是渐近有效的。⁶

⁵Rao-Cramér 下界的完整证明见附录 section 7.2。

⁶Beta 分布 MLE 方差的推导见附录 ??。

2.5. 渐近有效性. 由于有效估计量在有限样本下并不总是存在，我们引入渐近有效的概念。

DEFINITION 6.2 (渐近有效性). 设 $\hat{\theta}_n$ 是估计量序列，满足

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, \sigma_\theta^2).$$

则 $\hat{\theta}_n$ 的渐近效率 (*asymptotic efficiency*) 定义为

$$e(\hat{\theta}_n) = \frac{1/I(\theta_0)}{\sigma_\theta^2}. \quad (6.2.8)$$

若 $e(\hat{\theta}_n) = 1$ ，则称 $\hat{\theta}_n$ 是渐近有效的。

下面定理表明，在正则条件下，MLE 是渐近有效的。

heorem[MLE 的渐近正态性和有效性] 在正则条件 (R0)-(R5) 下，设 $\hat{\theta}_n$ 是似然方程的一致解序列。则

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N\left(0, \frac{1}{I(\theta_0)}\right). \quad (6.2.9)$$

heorem

证明思路：对数似然函数在 θ_0 处 Taylor 展开，利用大数定律和中心极限定理。⁷

这一定理意味着：**MLE 渐近地达到 Rao-Cramér 下界**。这是最大似然估计最重要的最优性结果。

2.6. 渐近相对效率. 在比较两个估计量时，渐近相对效率 (ARE) 提供了统一的标准。

DEFINITION 6.3 (渐近相对效率). 设 $\hat{\theta}_{1n}$ 和 $\hat{\theta}_{2n}$ 是两个渐近正态估计量，满足

$$\sqrt{n}(\hat{\theta}_{in} - \theta_0) \xrightarrow{D} N(0, \sigma_i^2), \quad i = 1, 2.$$

则 $\hat{\theta}_{1n}$ 相对于 $\hat{\theta}_{2n}$ 的 ARE 定义为

$$ARE(\hat{\theta}_{1n}, \hat{\theta}_{2n}) = \frac{\sigma_2^2}{\sigma_1^2}. \quad (6.2.10)$$

EXAMPLE 6.9 (中位数与均值的 ARE). 考虑位置模型 $X_i = \theta + e_i$:

- (a) 若 $e_i \sim \text{Laplace}(0, 1)$ ，则 MLE 是样本中位数 Q_2 ，信息 $I(\theta) = 1$ ，因此 $ARE(Q_2, \bar{X}) = 2$ 。这意味着在大样本下，中位数比均值更有效一倍！
- (b) 若 $e_i \sim N(0, 1)$ ，则 $ARE(Q_2, \bar{X}) = 2/\pi \approx 0.636$ 。此时均值更有效。

启示：没有“最优”的估计量——估计量的效率完全由真实分布决定。选择估计量时应该考虑数据的特点。

⁷MLE 渐近正态性的完整证明见附录 section 7.3。

2.7. Summary of Section 6.2.

- Fisher 信息量 $I(\theta) = \text{Var}(\partial \log f / \partial \theta)$ 衡量分布携带的关于 θ 的信息
- Rao-Cramér 下界: 任何无偏估计量 $\hat{\theta}$ 的方差满足 $\text{Var}(\hat{\theta}) \geq 1/[nI(\theta)]$
- 达到下界的估计量称为有效估计量 (如正态均值、二项比例的样本均值)
- 在正则条件下, MLE 是一致且渐近有效的: $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N(0, 1/I(\theta_0))$
- ARE 允许我们比较不同估计量的渐近效率

3. 6.3 Maximum Likelihood Tests

3.1. 从估计到检验. 我们已经建立了基于似然的点估计理论。现在问: 如何基于似然函数进行假设检验?

设 $X_1, \dots, X_n \sim f(x; \theta)$, 考虑双边假设

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta \neq \theta_0. \quad (6.3.1)$$

直觉告诉我们: 若 H_0 为真, 则似然函数在 θ_0 处应该接近最大值; 若 H_1 为真, 似然函数在 θ_0 处应该明显小于在 $\hat{\theta}$ 处。

定义似然比 (likelihood ratio):

$$\Lambda = \frac{L(\theta_0)}{L(\hat{\theta})}. \quad (6.3.2)$$

显然 $\Lambda \leq 1$ 。若 Λ 太小 (即 $L(\theta_0)$ 远小于 $L(\hat{\theta})$), 则拒绝 H_0 。

3.2. 似然比检验. 似然比检验(LRT): 拒绝 H_0 当且仅当 $\Lambda \leq c$, 其中 c 满足 $\alpha = \sup_{\theta \in \omega} \mathbb{P}_\theta(\Lambda \leq c)$

但通常我们关注简单原假设 $H_0: \theta = \theta_0$, 此时临界值由 $\mathbb{P}_{\theta_0}(\Lambda \leq c) = \alpha$ 确定。

EXAMPLE 6.10 (指数分布的 LRT). 设 $X_1, \dots, X_n \sim \text{Exp}(\theta)$, 密度 $f(x; \theta) = \theta^{-1}e^{-x/\theta}$, $x > 0$ 。

似然函数 $L(\theta) = \theta^{-n} \exp\{-n\bar{x}/\theta\}$ 。MLE 为 $\hat{\theta} = \bar{x}$ 。

似然比

$$\Lambda = e^n \left(\frac{\bar{x}}{\theta_0} \right)^n \exp\{-n\bar{x}/\theta_0\}.$$

可以证明, $\Lambda \leq c$ 等价于 $\bar{x}/\theta_0 \leq c_1$ 或 $\bar{x}/\theta_0 \geq c_2$ 。

注意: 当 H_0 为真时, $2n\bar{X}/\theta_0 \sim \chi^2(2n)$ 。因此临界值可从 χ^2 分布获得。⁸

EXAMPLE 6.11 (正态均值的 LRT). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, σ^2 已知。则

$$-2 \log \Lambda = \left(\frac{\bar{X} - \theta_0}{\sigma/\sqrt{n}} \right)^2 \sim \chi^2(1) \quad \text{under } H_0.$$

因此拒绝域为 $-2 \log \Lambda \geq \chi_\alpha^2(1)$ 。

这正是 Chapter 4 中的 z -test! 似然比检验统一了许多经典检验。

⁸指数分布似然比检验的详细推导见附录 ??。

3.3. 三大似然检验. 定理 6.3.1 揭示了似然比统计量在正则条件下的渐近分布。

heorem[似然比检验的渐近分布] 在正则条件下, 若 $H_0: \theta = \theta_0$ 为真, 则

$$-2 \log \Lambda \xrightarrow{D} \chi^2(1). \quad (6.3.3)$$

heorem

这一定理意味着: 对于任意分布, 在大样本下, 似然比检验都有渐近レベル α 。

除了似然比检验, 还有两种常用的似然型检验:

(1) **Wald 检验:** 基于 $\hat{\theta}$ 与 θ_0 的距离

$$\chi_W^2 = nI(\hat{\theta})(\hat{\theta} - \theta_0)^2 \xrightarrow{D} \chi^2(1). \quad (6.3.4)$$

(2) **Score 检验:** 基于得分函数在 θ_0 处的值

$$\chi_R^2 = \frac{[l'(\theta_0)]^2}{nI(\theta_0)} \xrightarrow{D} \chi^2(1). \quad (6.3.5)$$

三个统计量的关系: 当 n 足够大时, $\chi_L^2 \approx \chi_W^2 \approx \chi_R^2$ 。这三种检验在大样本下是等价的。

在实际中:

- 若已有 MLE, 使用 Wald 检验最方便
- 若求 MLE 困难, 但可计算得分, 使用 Score 检验
- 若两种都不方便, 使用似然比检验 (需要分别求限制和未限制的 MLE)

EXAMPLE 6.12 (正态方差的 Score 检验). 设 $X_1, \dots, X_n \sim N(\mu, \theta)$, μ 已知。要检验 $H_0: \theta = \theta_0$ 。

得分函数 $S(\theta) = \frac{1}{2} \sum (X_i - \mu)^2 - \frac{n\theta}{2\theta^2}$, 信息 $I(\theta) = 1/(2\theta^2)$ 。

Score 统计量 $\chi_R^2 = \frac{[\sum (X_i - \mu)^2 - n\theta_0]^2}{n\theta_0^2}$ 。

当 H_0 为真时, $\chi_R^2 \xrightarrow{D} \chi^2(1)$ 。

3.4. Summary of Section 6.3.

- 似然比检验拒绝 H_0 当 $\Lambda = L(\theta_0)/L(\hat{\theta}) \leq c$
- 三大似然检验: LRT、Wald 检验、Score 检验, 在大样本下都渐近服从 $\chi^2(1)$
- 对于正态均值检验, Wald 检验化为我们熟悉的 z -test
- 选择哪种检验取决于计算的便利性

4. 6.4 Multiparameter Case: Estimation

4.1. 为什么要考虑多参数? 实际统计问题中, 多数分布有多个参数。例如:

- 正态分布 $N(\mu, \sigma^2)$ 有两个参数: μ 和 σ^2
- Gamma 分布 $\Gamma(\alpha, \beta)$ 有两个参数
- 多项分布有 $k - 1$ 个参数

将 MLE 理论推广到多参数情形, 是理论完整性和实际应用的必然要求。

4.2. 多参数似然函数. 设 $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)' \in \Omega \subset \mathbb{R}^p$. 似然函数为

$$L(\boldsymbol{\theta}) = \prod_{i=1}^n f(x_i; \boldsymbol{\theta}), \quad l(\boldsymbol{\theta}) = \sum_{i=1}^n \log f(x_i; \boldsymbol{\theta}). \quad (6.4.1)$$

MLE $\hat{\boldsymbol{\theta}}$ 通过求解 Score 向量方程组得到:

$$\frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{0}. \quad (6.4.2)$$

EXAMPLE 6.13 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 参数 $\boldsymbol{\theta} = (\mu, \sigma^2)'$. 对数似然:

$$l(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

求偏导并令为零:

$$\begin{aligned} \frac{\partial l}{\partial \mu} &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{x}, \\ \frac{\partial l}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \end{aligned}$$

结论: 样本均值和样本方差 (除以 n) 是 MLE。

EXAMPLE 6.14 (Laplace 分布的 MLE). 设 $X_1, \dots, X_n \sim \text{Laplace}(a, b)$, 密度 $f(x) = \frac{1}{2b} \exp\{-|x - a|/b\}$, 参数 $\boldsymbol{\theta} = (a, b)'$.

MLE:

- 位置参数 a : $\hat{a} = Q_2$ (样本中位数), 与 b 无关
- 尺度参数 b : $\hat{b} = \frac{1}{n} \sum_{i=1}^n |X_i - Q_2|$

启示: 对于某些分布, 参数的 MLE 可以分别求解。

4.3. 信息矩阵. 在多参数情形, Fisher 信息由一个矩阵——信息矩阵 (information matrix) 给出:

$$\mathbf{I}(\boldsymbol{\theta}) = \text{Cov}(\nabla \log f(X; \boldsymbol{\theta})), \quad (6.4.3)$$

其中 $\nabla \log f = (\partial \log f / \partial \theta_1, \dots, \partial \log f / \partial \theta_p)'$.

信息矩阵的第 (j, k) 个元素为

$$I_{jk}(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial \log f}{\partial \theta_j} \cdot \frac{\partial \log f}{\partial \theta_k} \right] = -\mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial^2 \log f}{\partial \theta_j \partial \theta_k} \right]. \quad (6.4.4)$$

对于样本, 信息矩阵是单个样本信息的 n 倍: $\mathbf{I}_n(\boldsymbol{\theta}) = n\mathbf{I}(\boldsymbol{\theta})$ 。

EXAMPLE 6.15 (正态分布的信息矩阵). 设 $X \sim N(\mu, \sigma^2)$, 记 $\theta_1 = \mu$, $\theta_2 = \sigma^2$.

对数似然偏导数:

$$\frac{\partial \log f}{\partial \mu} = \frac{x - \mu}{\sigma^2}, \quad \frac{\partial \log f}{\partial \sigma^2} = -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2(\sigma^2)^2}.$$

计算二阶偏导数的期望，可得信息矩阵

$$\mathbf{I}(\mu, \sigma^2) = \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2(\sigma^2)^2} \end{pmatrix}. \quad (6.4.5)$$

注意对角线元素，这意味着 μ 和 σ^2 的信息在正态分布下是独立的！⁹

4.4. 多参数 Rao-Cramér 下界. 在多参数情形，单个参数 θ_j 的无偏估计量 $\hat{\theta}_j$ 满足

$$\text{Var}(\hat{\theta}_j) \geq \frac{1}{n} [\mathbf{I}^{-1}(\boldsymbol{\theta})]_{jj}. \quad (6.4.6)$$

特别地，当信息矩阵是对角矩阵时，每个参数的 Rao-Cramér 下界与其单参数情形相同。

EXAMPLE 6.16 (正态方差估计的效率). 对于 $N(\mu, \sigma^2)$ ，由信息矩阵可知 σ^2 的 Rao-Cramér 下界为 $2(\sigma^2)^2/n$ 。

样本方差 S^2 (无偏估计) 的方差为 $2(\sigma^2)^2/(n-1)$ ，因此不是有效的，但渐近有效。

4.5. 多参数 MLE 的渐近性质. theorem[多参数 MLE 的渐近分布] 在正则条件下，设 $\hat{\boldsymbol{\theta}}_n$ 是一致解序列。则

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}^{-1}(\boldsymbol{\theta}_0)). \quad (6.4.7)$$

theorem

含义：每个参数分量 $\hat{\theta}_{nj}$ 满足

$$\sqrt{n}(\hat{\theta}_{nj} - \theta_{0j}) \xrightarrow{D} N(0, [\mathbf{I}^{-1}(\boldsymbol{\theta}_0)]_{jj}),$$

即 $\hat{\theta}_{nj}$ 是渐近有效的。

对于参数函数 $g(\boldsymbol{\theta})$ ，由 Delta 方法可得类似结论。

EXAMPLE 6.17 (正态协方差矩阵估计). 设 $X_1, \dots, X_n \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。MLE 为样本均值 $\bar{X}$ 和样本协方差矩阵 $\mathbf{S} = \frac{1}{n} \sum (X_i - \bar{X})(X_i - \bar{X})'$ 。

可以证明 $\bar{X}$ 和 $\mathbf{S}$ 联合渐近正态，且达到信息矩阵下界。

4.6. Summary of Section 6.4.

- 多参数情形下，MLE 通过同时求解所有参数的 Score 方程得到
- 信息矩阵 $\mathbf{I}(\boldsymbol{\theta})$ 是 Fisher 信息在多参数情形下的推广
- Rao-Cramér 下界由信息矩阵的逆给出： $\text{Var}(\hat{\theta}_j) \geq \frac{1}{n} [\mathbf{I}^{-1}]_{jj}$
- 在正则条件下，多参数 MLE 联合渐近正态： $\sqrt{n}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}^{-1})$
- 信息矩阵的对角元素给出每个参数的独立信息

⁹正态分布信息矩阵的详细计算见附录 section 7.4。

5. 6.5 Multiparameter Case: Testing

5.1. 多参数假设检验的框架. 在多参数情形, 假设通常规定参数属于参数空间的某个子集。

设 $\Omega \subset \mathbb{R}^p$ 是完整的参数空间, $\omega \subset \Omega$ 是由 q 个约束定义的子空间。考虑假设

$$H_0: \boldsymbol{\theta} \in \omega \quad \text{vs} \quad H_1: \boldsymbol{\theta} \in \Omega \cap \omega^c. \quad (6.5.1)$$

例如, 对于 $N(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ 相当于检验约束 $\mu = \mu_0$ 下的子空间。

似然比检验推广为

$$\Lambda = \frac{\max_{\boldsymbol{\theta} \in \omega} L(\boldsymbol{\theta})}{\max_{\boldsymbol{\theta} \in \Omega} L(\boldsymbol{\theta})}. \quad (6.5.2)$$

定理 6.5.1 给出了其渐近分布。

heorem[多参数似然比检验的渐近分布] 在正则条件下, 若 H_0 由 q 个独立约束定义, 则

$$-2 \log \Lambda \xrightarrow{D} \chi^2(q). \quad (6.5.3)$$

heorem

含义: 渐近分布的自由度等于约束的个数, 而不是原始参数的个数。

EXAMPLE 6.18 (正态均值的检验). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ (σ^2 未知)。

全空间 $\Omega = \{(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$, 约束子空间 $\omega = \{(\mu_0, \sigma^2) : \sigma^2 > 0\}$ 。

似然比统计量简化为

$$\Lambda = \left(\frac{\sum (X_i - \bar{X})^2}{\sum (X_i - \mu_0)^2} \right)^{n/2}.$$

经过推导, $-2 \log \Lambda$ 等价于 t 统计量的平方:

$$-2 \log \Lambda = \frac{n(\bar{X} - \mu_0)^2}{\sum (X_i - \bar{X})^2 / (n-1)} \cdot (n-1) \sim \chi^2(1).$$

这与 t -test 完全一致!

启示: 对于正态分布, 似然比检验就是我们熟悉的 t 检验。

EXAMPLE 6.19 (二项比例的检验). 比较两个独立二项分布的比例 p_1 和 p_2 。设 $X \sim \text{Binomial}(n_1, p_1)$, $Y \sim \text{Binomial}(n_2, p_2)$, 检验 $H_0: p_1 = p_2$ 。

Wald 检验统计量:

$$\chi_W^2 = \frac{(\hat{p}_1 - \hat{p}_2)^2}{\hat{p}(1-\hat{p})(1/n_1 + 1/n_2)} \xrightarrow{D} \chi^2(1),$$

其中 $\hat{p} = (n_1 \hat{p}_1 + n_2 \hat{p}_2) / (n_1 + n_2)$ 是合并后的比例估计。

渐近置信区间：

$$\hat{p}_1 - \hat{p}_2 \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}.$$

三大检验的多参数推广：LRT、Wald、Score 检验都可以推广到多参数情形，在大样本下都渐近服从 $\chi^2(q)$ ，其中 q 是约束个数。

5.2. Summary of Section 6.5.

- 多参数假设检验考虑参数空间 Ω 的子空间 ω
- 似然比统计量渐近服从 $\chi^2(q)$ ，自由度 q 等于约束个数
- 正态均值的 t 检验是似然比检验的特例
- Wald 和 Score 检验提供渐近等价的替代方法
- 信息矩阵用于构造 Wald 统计量和置信域

6. 6.6 The EM Algorithm

6.1. 缺失数据问题的起源。在许多实际统计问题中，数据并非完全观测到。例如：

- **截断数据：**只观测到 $X > a$ 的个体
- **区间删失：**只知道 $L < X < R$ ，而不知道具体值
- **隐变量：**观测到 X ，但 X 依赖于某个不可观测的隐变量 Z
- **混合模型：**数据来自多个群体的混合，但我们不知道每个观测来自哪个群体

这些情况下的似然函数往往难以直接最大化。**EM 算法**提供了一种通用的迭代策略。

6.2. EM 算法的思想。EM 算法通过引入“缺失数据”（可以是真正的缺失值，也可以是隐变量）来简化似然函数。

设 $\mathbf{X}$ 是观测数据， $\mathbf{Z}$ 是缺失数据。完整数据 $(\mathbf{X}, \mathbf{Z})$ 的似然函数记为 $L^c(\theta|\mathbf{x}, \mathbf{z})$ 。

设 $\theta^{(m)}$ 是第 m 步的估计值。EM 算法执行两步迭代：

(1) **E 步 (Expectation)：**计算完整数据对数似然在当前估计 $\theta^{(m)}$ 下的条件期望

$$Q(\theta|\theta^{(m)}, \mathbf{x}) = \mathbb{E}_{\theta^{(m)}} [\log L^c(\theta|\mathbf{x}, \mathbf{Z}) | \theta^{(m)}, \mathbf{x}]. \quad (6.6.1)$$

(2) **M 步 (Maximization)：**找到使 Q 最大化的 θ

$$\theta^{(m+1)} = \arg \max_{\theta} Q(\theta|\theta^{(m)}, \mathbf{x}). \quad (6.6.2)$$

EM 算法保证：每一步迭代都使观测似然单调递增，即 $L(\theta^{(m+1)}|\mathbf{x}) \geq L(\theta^{(m)}|\mathbf{x})$ 。

heorem[EM 算法的单调性] 设 $\theta^{(m+1)}$ 由 E 步和 M 步得到。则

$$L(\theta^{(m+1)}|\mathbf{x}) \geq L(\theta^{(m)}|\mathbf{x}). \quad (6.6.3)$$

heorem

证明思路：利用 Q 函数的定义和 Jensen 不等式。¹⁰

¹⁰EM 算法单调性的完整证明见附录 section 7.5。

这一性质保证了算法的稳定性——不会发散到局部最大值以外。

EM 算法的直观理解：E 步”想象”缺失数据可能取的值，M 步在假设这些值已知的情况下更新参数估计。这两个步骤交替进行，直到收敛。

EXAMPLE 6.20 (正态分布的 EM 算法——缺失数据). 设 $X_1, \dots, X_{n_1} \sim N(\theta, 1)$ 观测到，同时 $Z_1, \dots, Z_{n_2} \sim N(\theta, 1)$ 截断于 a (即只知 $Z_j > a$)。

完整数据似然：

$$L^c(\theta) = \prod_{i=1}^{n_1} \phi(x_i - \theta) \prod_{j=1}^{n_2} \phi(z_j - \theta),$$

其中 ϕ 是标准正态密度。

E 步：需要计算 $\mathbb{E}[Z_j - \theta | Z_j > a, \theta^{(m)}]$ 。

设 $Y \sim N(\theta, 1)$ 截尾于 a ，则

$$\mathbb{E}[Y - \theta | Y > a] = \frac{\phi(a - \theta)}{1 - \Phi(a - \theta)}.$$

因此

$$\theta^{(m+1)} = \frac{n_1 \bar{x} + n_2 \theta^{(m)} + n_2 \frac{\phi(a - \theta^{(m)})}{1 - \Phi(a - \theta^{(m)})}}{n_1 + n_2}. \quad (6.6.4)$$

解释：新估计是样本均值、当前估计和截尾部分期望的加权平均。¹¹

EXAMPLE 6.21 (正态混合模型的 EM 算法). 设观测数据来自两个正态分布的混合：

$$X_i \sim (1 - \epsilon)N(\mu_1, \sigma_1^2) + \epsilon N(\mu_2, \sigma_2^2),$$

参数 $\theta = (\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \epsilon)'$ 。

引入隐变量 W_i ：若 X_i 来自第一个分布则 $W_i = 0$ ，否则 $W_i = 1$ 。

完整数据对数似然：

$$\log L^c = \sum_{i=1}^n [(1 - w_i) \log f_1(x_i) + w_i \log f_2(x_i)]. \quad (6.6.5)$$

E 步：计算 w_i 的后验概率

$$\gamma_i^{(m)} = \mathbb{P}(W_i = 1 | \theta^{(m)}, x_i) = \frac{\epsilon^{(m)} f_2(x_i | \theta^{(m)})}{(1 - \epsilon^{(m)}) f_1(x_i | \theta^{(m)}) + \epsilon^{(m)} f_2(x_i | \theta^{(m)})}. \quad (6.6.6)$$

M 步：更新参数

$$\begin{aligned} \hat{\mu}_1 &= \frac{\sum_{i=1}^n (1 - \gamma_i) x_i}{\sum_{i=1}^n (1 - \gamma_i)}, & \hat{\mu}_2 &= \frac{\sum_{i=1}^n \gamma_i x_i}{\sum_{i=1}^n \gamma_i}, \\ \hat{\sigma}_1^2 &= \frac{\sum_{i=1}^n (1 - \gamma_i) (x_i - \hat{\mu}_1)^2}{\sum_{i=1}^n (1 - \gamma_i)}, & \hat{\sigma}_2^2 &= \frac{\sum_{i=1}^n \gamma_i (x_i - \hat{\mu}_2)^2}{\sum_{i=1}^n \gamma_i}, \\ \hat{\epsilon} &= \frac{1}{n} \sum_{i=1}^n \gamma_i. \end{aligned} \quad (6.6.7)$$

直观解释：E 步根据当前参数估计每个观测来自各成分的概率；M 步根据这些概率重新估计各成分的参数。这等价于”软聚类”然后重新估计。

¹¹正态截尾数据的 EM 算法详细推导见附录 ??。

6.3. EM 算法的收敛性. EM 算法的收敛性由以下事实保证：

- 观测似然 $L(\theta|\mathbf{x})$ 在每一步都单调不降
- $L(\theta|\mathbf{x})$ 有上界，因此必收敛到某个极限
- 收敛点满足 Score 方程 $\partial l/\partial \theta = 0$ (即 MLE 的条件)

在正则条件下，EM 算法收敛到 MLE。

EM 算法的优点：

- 简单：每一步只需要计算条件期望
- 稳定：单调收敛，不会发散
- 灵活：适用于各种缺失数据或隐变量问题

EM 算法的缺点：

- 可能收敛到局部最大值 (而非全局最优)
- 收敛速度可能很慢
- 需要显式计算条件期望，可能很困难

EXAMPLE 6.22 (遗传连锁的 EM 算法). 在遗传学中，估计两个基因座之间的重组率 θ 是一个经典问题。

设四类后代观测个数为 (X_1, X_2, X_3, X_4) ，概率分别为 $(\frac{1}{2} + \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{\theta}{4})$ 。通过引入隐变量 (将第一类拆分为两个子类别)，EM 算法给出迭代公式

$$\theta^{(m+1)} = \frac{x_1\theta^{(m)} + 2x_4 + x_4\theta^{(m)}}{n\theta^{(m)} + 2(x_2 + x_3 + x_4)}. \quad (6.6.8)$$

该公式收敛到重组率 θ 的 MLE。

6.4. Summary of Section 6.6.

- EM 算法适用于缺失数据或隐变量问题
- E 步：计算完整数据对数似然在当前估计下的条件期望
- M 步：最大化条件期望得到新估计
- EM 算法保证观测似然单调递增
- 在正则条件下收敛到 MLE
- 典型应用：截尾数据、混合模型、缺失数据填充

7. 附录：公式推导

7.1. 定理 6.1.1 的证明 (似然函数的渐近支撑). 背景：我们需要证明当样本量 $n \rightarrow \infty$ 时，似然函数 $L(\theta_0; \mathbf{X})$ 以概率 1 大于任何 $\theta \neq \theta_0$ 处的似然值。

证明： 记 $Z_i(\theta) = \log \frac{f(X_i; \theta)}{f(X_i; \theta_0)}$ 。则

$$\log \frac{L(\theta_0; \mathbf{X})}{L(\theta; \mathbf{X})} = \sum_{i=1}^n \log \frac{f(X_i; \theta_0)}{f(X_i; \theta)} = - \sum_{i=1}^n Z_i(\theta).$$

由弱大数定律,

$$\frac{1}{n} \sum_{i=1}^n Z_i(\theta) \xrightarrow{P} \mathbb{E}_{\theta_0}[Z_1(\theta)].$$

由 Jensen 不等式和 $\mathbb{E}_{\theta_0}[f(X; \theta)/f(X; \theta_0)] = 1$,

$$\mathbb{E}_{\theta_0}[Z_1(\theta)] = \mathbb{E}_{\theta_0} \left[\log \frac{f(X; \theta)}{f(X; \theta_0)} \right] < \log \mathbb{E}_{\theta_0} \left[\frac{f(X; \theta)}{f(X; \theta_0)} \right] = \log 1 = 0.$$

因此 $\frac{1}{n} \sum Z_i(\theta) \xrightarrow{P}$ 负数, 从而

$$\mathbb{P}_{\theta_0} \left[\frac{1}{n} \sum Z_i(\theta) < 0 \right] \rightarrow 1.$$

即 $\mathbb{P}_{\theta_0}[L(\theta_0; \mathbf{X}) > L(\theta; \mathbf{X})] \rightarrow 1$ 。

证毕。

7.2. Rao-Cramér 下界的推导. 背景: 证明任何无偏估计量 $\hat{\theta}$ 的方差满足 $\text{Var}(\hat{\theta}) \geq 1/[nI(\theta)]$ 。

证明思路: 利用 Cauchy-Schwarz 不等式。

设 $Y = \hat{\theta}$, $Z = \sum_{i=1}^n \frac{\partial \log f(X_i; \theta)}{\partial \theta}$ 。则 $\mathbb{E}(Z) = 0$, $\text{Var}(Z) = nI(\theta)$ 。

对 $k'(\theta) = \frac{d}{d\theta} \mathbb{E}(Y) = \frac{d}{d\theta} \int yL(y)dy$ 利用微分与积分可交换 (正则条件), 得

$$k'(\theta) = \mathbb{E} \left(Y \cdot \frac{\partial \log L}{\partial \theta} \right) = \mathbb{E}(YZ).$$

由 Cauchy-Schwarz 不等式,

$$|\text{corr}(Y, Z)|^2 = \frac{[\text{cov}(Y, Z)]^2}{\text{Var}(Y)\text{Var}(Z)} \leq 1.$$

即 $[k'(\theta)]^2 \leq \text{Var}(Y) \cdot nI(\theta)$, 整理得 Rao-Cramér 不等式。

证毕。

7.3. MLE 渐近正态性的证明. 背景: 证明 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, 1/I(\theta_0))$ 。

证明思路: 对数似然在 θ_0 处 Taylor 展开。

记 $l'(\theta) = \partial l / \partial \theta$, $l''(\theta) = \partial^2 l / \partial \theta^2$ 。

由 $l'(\hat{\theta}_n) = 0$ (MLE 条件) 和 Taylor 展开:

$$0 = l'(\theta_0) + (\hat{\theta}_n - \theta_0)l''(\theta_0) + \frac{1}{2}(\hat{\theta}_n - \theta_0)^2 l'''(\theta_n^*),$$

其中 θ_n^* 在 θ_0 和 $\hat{\theta}_n$ 之间。

整理得

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{n^{-1/2}l'(\theta_0)}{-n^{-1}l''(\theta_0) - \frac{1}{2}(\hat{\theta}_n - \theta_0) \cdot n^{-1}l'''(\theta_n^*)}.$$

由中心极限定理, $n^{-1/2}l'(\theta_0) \xrightarrow{D} N(0, I(\theta_0))$ 。

由大数定律, $-n^{-1}l''(\theta_0) \xrightarrow{P} I(\theta_0)$ 。

由一致性 $\hat{\theta}_n \xrightarrow{P} \theta_0$ 和条件 (R5), 第三项依概率趋于 0。

因此分子分母分别收敛, 极限分布为 $N(0, 1/I(\theta_0))$ 。

证毕。

7.4. 正态分布信息矩阵的推导. 设 $X \sim N(\mu, \sigma^2)$, 记 $\theta_1 = \mu$, $\theta_2 = \sigma^2$ 。

对数密度:

$$\log f = -\frac{1}{2} \log(2\pi) - \frac{1}{2} \log \theta_2 - \frac{(x - \theta_1)^2}{2\theta_2}.$$

一阶偏导数:

$$\frac{\partial \log f}{\partial \theta_1} = \frac{x - \theta_1}{\theta_2}, \quad \frac{\partial \log f}{\partial \theta_2} = -\frac{1}{2\theta_2} + \frac{(x - \theta_1)^2}{2\theta_2^2}.$$

二阶偏导数:

$$\frac{\partial^2 \log f}{\partial \theta_1^2} = -\frac{1}{\theta_2}, \quad \frac{\partial^2 \log f}{\partial \theta_2^2} = \frac{1}{2\theta_2^2} - \frac{(x - \theta_1)^2}{\theta_2^3}, \quad \frac{\partial^2 \log f}{\partial \theta_1 \partial \theta_2} = -\frac{x - \theta_1}{\theta_2^2}.$$

计算 Fisher 信息矩阵元素 (取负期望):

$$\begin{aligned} I_{11} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_1^2} \right] = \frac{1}{\theta_2}, \\ I_{22} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_2^2} \right] = \frac{1}{2\theta_2^2}, \\ I_{12} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_1 \partial \theta_2} \right] = -\mathbb{E} \left[-\frac{X - \theta_1}{\theta_2^2} \right] = 0. \end{aligned}$$

因此

$$\mathbf{I}(\theta) = \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2(\sigma^2)^2} \end{pmatrix}.$$

注意到 $I_{12} = 0$, 这表明 μ 和 σ^2 的信息在正态分布下是独立的。

证毕。

7.5. EM 算法单调性的证明. 背景: 证明 EM 算法的每一步都使观测似然单调递增。

证明: 由条件概率定义,

$$L(\theta|\mathbf{x}) = \frac{h(\mathbf{x}, \mathbf{z}|\theta)}{k(\mathbf{z}|\theta, \mathbf{x})},$$

其中 h 是完整数据联合密度, k 是缺失数据 $\mathbf{Z}$ 给定观测数据 $\mathbf{x}$ 和参数 θ 的条件密度。

取对数并在给定 $\theta^{(m)}$ 和 $\mathbf{x}$ 的条件下对 $\mathbf{Z}$ 求期望:

$$\log L(\theta|\mathbf{x}) = \mathbb{E}_{\theta^{(m)}} [\log h(\mathbf{x}, \mathbf{Z}|\theta)|\theta^{(m)}, \mathbf{x}] - \mathbb{E}_{\theta^{(m)}} [\log k(\mathbf{Z}|\theta, \mathbf{x})|\theta^{(m)}, \mathbf{x}].$$

第一项正是 $Q(\theta|\theta^{(m)}, \mathbf{x})$ 。第二项由 Jensen 不等式可得

$$\mathbb{E}_{\theta^{(m)}} \left[\log \frac{k(\mathbf{Z}|\theta^{(m)}, \mathbf{x})}{k(\mathbf{Z}|\theta, \mathbf{x})} \right] \leq \log \mathbb{E}_{\theta^{(m)}} \left[\frac{k(\mathbf{Z}|\theta^{(m)}, \mathbf{x})}{k(\mathbf{Z}|\theta, \mathbf{x})} \right] = \log 1 = 0.$$

因此

$$\log L(\theta|\mathbf{x}) \geq Q(\theta|\theta^{(m)}, \mathbf{x}) - Q(\theta^{(m)}|\theta^{(m)}, \mathbf{x}).$$

由于 $\theta^{(m+1)}$ 最大化 Q ，即 $Q(\theta^{(m+1)}|\theta^{(m)}, \mathbf{x}) \geq Q(\theta^{(m)}|\theta^{(m)}, \mathbf{x})$ ，代入得

$$\log L(\theta^{(m+1)}|\mathbf{x}) \geq \log L(\theta^{(m)}|\mathbf{x}).$$

证毕。

CHAPTER 7

Sufficiency and Quality of Estimators

Chapter 7 Overview

在前几章中，我们建立了点估计、置信区间和假设检验的理论基础。我们已经看到，最大似然估计（MLE）在正则条件下具有一致性，并且在渐近意义下具有最优性质。然而，我们还没有回答一个更深层次的问题：

给定一个参数 θ ，在所有可能的估计量中，是否存在一个“最好”的？如何找到它？

要回答这个问题，我们首先需要理解什么叫“信息保留”。当我们收集数据 $X_1, X_2, \dots, X_n$ 后，这些数据包含了关于 θ 的信息。但原始数据量太大——我们需要**数据压缩（data reduction）**。一个自然的想法是用样本均值 $\bar{X}$ 或样本方差 S^2 这样的统计量来代替原始数据。

关键问题是：这种压缩是否丢失了关于 θ 的信息？

这正是**充分性（sufficiency）**理论要回答的问题。一个充分统计量 $T(X_1, \dots, X_n)$ 保留了原始数据中关于 θ 的全部信息——给定 T 的值，数据的条件分布不再依赖于 θ 。本章我们将学习：

- 如何定义和判断充分统计量（因子分解定理）
- Rao-Blackwell 定理：如何利用充分性改进估计量
- 完备性（completeness）与唯一最小方差无偏估计（MVUE）的关系
- 指数族分布（exponential class）的优良性质
- Basu 定理：完备充分统计量与辅助统计量的独立性

本章路线图：充分性定义 $\rightarrow$ 因子分解定理 $\rightarrow$ Rao-Blackwell $\rightarrow$ 完备性 $\rightarrow$ 指数族 $\rightarrow$ Basu 定理

1. 7.1 Measures of Quality of Estimators

在寻找“最好”的估计量之前，我们需要先定义什么叫“好”。前几章我们已经遇到过两个重要标准：无偏性（unbiasedness）和一致性（consistency）。

1.1. 最小方差无偏估计量（MVUE）. 一个自然而优雅的标准是：在所有无偏估计量中，选择方差最小的。

DEFINITION 7.1 (最小方差无偏估计量 (MVUE)). 设 $Y = u(X_1, X_2, \dots, X_n)$ 是基于容量为 n 的随机样本的 θ 的点估计量。若 Y 是无偏的，即 $E(Y) = \theta$ ，且对 θ 的任何其他无偏估计量 Y' ，都有 $\text{var}(Y) \leq \text{var}(Y')$ ，则称 Y 是 θ 的**最小方差无偏估计量（minimum variance unbiased estimator, MVUE）**。

这个定义的诱人之处在于它的自然性：如果两个估计量都是 θ 的无偏估计，那么方差较小的那个在平均意义上更接近 θ 。

EXAMPLE 7.1 (正态分布的样本均值 vs 单个观测值). 设 $X_1, X_2, \dots, X_9$ 是来自 $N(\theta, \sigma^2)$ 分布的随机样本，其中 $-\infty < \theta < \infty$ 。

统计量 $\bar{X} = (X_1 + X_2 + \dots + X_9)/9$ 服从 $N(\theta, \sigma^2/9)$ ，因此是无偏的。而 X_1 服从 $N(\theta, \sigma^2)$ ，也是无偏的。

虽然 $\bar{X}$ 的方差 $\sigma^2/9$ 小于 X_1 的方差 σ^2 ，但定义要求比较的对象是**所有**无偏估计量，而不仅仅是这两个。我们不能仅凭两个例子就宣称 $\bar{X}$ 是 *MVUE*。

真正的问题在于：我们无法枚举所有可能的无偏估计量。这促使我们发展更系统的方法来寻找 *MVUE*。

1.2. 风险函数与决策论视角. 另一种比较估计量的框架是决策论 (decision theory)。设 $\mathcal{L}[\theta, \delta(y)]$ 是损失函数 (loss function)，衡量估计值 $\delta(y)$ 与真实参数 θ 之间的差距。常见的损失函数是平方误差损失 $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$ 。

风险函数 (risk function) 定义为损失的期望： $R(\theta, \delta) = E[\mathcal{L}(\theta, \delta(Y))]$ 。一个自然的想法是寻找使风险函数最小化的决策函数。但在一般情况下，使 $R(\theta, \delta)$ 对所有 θ 同时最小的估计量不存在 (见下例)。

EXAMPLE 7.2 (最小化风险函数的困难). 设 $X_1, \dots, X_{25}$ 是来自 $N(\theta, 1)$ 的样本。考虑平方损失函数 $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$ 。

比较两个决策函数：

- $\delta_1(y) = y = \bar{x}$ ，风险 $R(\theta, \delta_1) = 1/25$
- $\delta_2(y) = 0$ ，风险 $R(\theta, \delta_2) = \theta^2$

当 $\theta = 0$ 时， δ_2 表现完美 ($R(0, \delta_2) = 0$)；但当 $\theta = 2$ 时， $R(2, \delta_2) = 4 > R(2, \delta_1) = 1/25$ 。一般地，当 $|\theta| < 1/5$ 时 δ_2 更好，否则 δ_1 更好。

这说明没有一个决策函数能在所有 θ 值下同时最优。**minimax 原则**提供了一种折中：选择使 $\max_{\theta} R(\theta, \delta)$ 最小的决策函数。

如果没有对决策函数的限制 (如要求无偏)，很难找到统一最优的估计量。这促使我们聚焦于 *MVUE*——在无偏估计量的类中寻找方差最小者。

充分性的引入：如果我们有一个充分统计量 T ，那么所有无偏估计量都可以通过 Rao-Blackwell 过程改进为 T 的函数。这大大简化了 *MVUE* 的搜索。

本节小结.

- *MVUE* 在无偏估计量类中方差最小
- 寻找 *MVUE* 的困难在于无法枚举所有无偏估计量
- 充分统计量为这一问题提供了系统性的解决方案

2. 7.2 A Sufficient Statistic for a Parameter

本节我们正式引入充分统计量的概念，并建立判断充分性的核心工具——因子分解定理 (Factorization Theorem)。

2.1. 为什么需要充分统计量? 统计量 $Y = u(X_1, X_2, \dots, X_n)$ 本质上是对样本空间的一种划分 (partition)。例如, $\bar{X} = 8.32$ 意味着所有满足 $\sum x_i = (8.32)n$ 的点 $(x_1, \dots, x_n)$ 被归入同一类。

给定一个统计量 $Y_1 = u_1(X_1, \dots, X_n)$, 如果我们知道 $(X_1, \dots, X_n)$ 落在由 $Y_1 = y_1$ 确定的集合中, 那么 $X_1, \dots, X_n$ 的条件分布可能仍然依赖于 θ 。如果这个条件分布**完全**不含 θ , 则 Y_1 包含了样本中关于 θ 的全部信息——这就是充分性的直觉。

EXAMPLE 7.3 (二项分布的充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 $Bernoulli(\theta)$ 分布的随机样本, 即

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, \quad x = 0, 1.$$

统计量 $Y_1 = \sum_{i=1}^n X_i$ 服从二项分布 $b(n, \theta)$ 。考虑条件概率

$$P(X_1 = x_1, \dots, X_n = x_n \mid Y_1 = y_1).$$

当且仅当 $\sum x_i = y_1$ 时该条件概率非零, 此时

$$\frac{\theta^{x_1} (1 - \theta)^{1-x_1} \cdots \theta^{x_n} (1 - \theta)^{1-x_n}}{\binom{n}{y_1} \theta^{y_1} (1 - \theta)^{n-y_1}} = \frac{1}{\binom{n}{y_1}},$$

该式不含 θ 。因此给定 $Y_1 = y_1$, 数据的条件分布与 θ 无关—— Y_1 是 θ 的充分统计量。

这个例子的含义是: 只要知道“成功次数” Y_1 是多少, 就不再需要知道具体是哪几次试验成功了。 Y_1 已经包含了所有关于 θ 的信息。

2.2. 充分统计量的正式定义.

DEFINITION 7.2 (充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是统计量, 其 pdf 或 pmf 为 $f_{Y_1}(y_1; \theta)$ 。则 Y_1 是 θ 的**充分统计量**, 当且仅当

$$\frac{f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta)}{f_{Y_1}[u_1(x_1, \dots, x_n); \theta]} = H(x_1, \dots, x_n),$$

其中 $H(x_1, \dots, x_n)$ 不依赖于 θ 。

这个定义的要点是: 分子是联合 pdf/pmf, 分母是充分统计量的 pdf, 比值只与原始数据有关而与 θ 无关。

2.3. 因子分解定理 (Factorization Theorem). 直接使用定义需要知道充分统计量的分布, 这往往很困难。Neyman 的因子分解定理提供了一个更实用的判定方法。

THEOREM 7.1 (Neyman 因子分解定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。统计量 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量, 当且仅当存在两个非负函数 k_1 和 k_2 , 使得

$$f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta) = k_1[u_1(x_1, \dots, x_n); \theta] \cdot k_2(x_1, \dots, x_n),$$

其中 $k_2(x_1, \dots, x_n)$ 不依赖于 θ 。

核心理想：联合 pdf/pmf 可以分解为两部分——一部分只通过 $u_1(x_1, \dots, x_n)$ 依赖于 θ ，另一部分与 θ 无关。能完成这种分解的统计量就是充分的。

EXAMPLE 7.4 (正态分布 $\bar{X}$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 $N(\theta, \sigma^2)$ 的样本，其中 σ^2 已知。则

$$f(x_i; \theta) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x_i - \theta)^2}{2\sigma^2} \right].$$

联合 pdf 为

$$\prod_{i=1}^n f(x_i; \theta) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

利用恒等式 $\sum (x_i - \theta)^2 = \sum (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2$ ，可得

$$\prod_{i=1}^n f(x_i; \theta) = \underbrace{\exp \left[-\frac{n(\bar{x} - \theta)^2}{2\sigma^2} \right]}_{k_1[\bar{x}; \theta]} \cdot \underbrace{\frac{\exp \left[-\frac{1}{2\sigma^2} \sum (x_i - \bar{x})^2 \right]}{(\sigma\sqrt{2\pi})^n}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\bar{X}$ 是 θ 的充分统计量。¹

EXAMPLE 7.5 (指数分布的充分统计量). 设 $X_1, \dots, X_n$ 是来自 $\Gamma(2, \theta)$ 分布的样本。已知 $\Gamma(\alpha, \beta)$ 分布的 mgf 为 $M(t) = (1 - \beta t)^{-\alpha}$ ， $t < 1/\beta$ 。

$Y_1 = \sum_{i=1}^n X_i$ 的 mgf 为 $[(1 - \theta t)^{-2}]^n = (1 - \theta t)^{-2n}$ ，因此 $Y_1 \sim \Gamma(2n, \theta)$ 。

联合 pdf 为

$$\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2} = \frac{(\prod x_i) \exp(-\sum x_i/\theta)}{\theta^{2n}}.$$

给定 $Y_1 = y_1$ 时，条件概率的比值为

$$\frac{\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2}}{\frac{y_1^{2n-1} e^{-y_1/\theta}}{\Gamma(2n)\theta^{2n}}} = \frac{\Gamma(2n) \prod x_i}{y_1^{2n-1}},$$

不含 θ 。故 $Y_1 = \sum X_i$ 是 θ 的充分统计量。

EXAMPLE 7.6 (乘积 $\prod X_i$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0$$

的样本。这是参数化形式的 Beta 分布。

联合 pdf 为

$$\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} = \underbrace{\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta}}_{k_1[\prod x_i; \theta]} \cdot \underbrace{\frac{1}{\prod x_i}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\prod_{i=1}^n X_i$ 是 θ 的充分统计量。

注意：使用因子分解定理时，必须正确处理支撑集 (support) 对参数的依赖。

¹正态分布充分性的详细推导见附录 ??。

EXAMPLE 7.7 (支撑集依赖参数的情况). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta) = e^{-(x-\theta)} I_{(\theta, \infty)}(x).$$

一种错误的分解可能是:

$$\prod e^{-(x_i-\theta)} = [e^{3\theta}] [e^{-x_1-x_2-x_3}],$$

从而声称 $\max X_i$ 是充分的。但这是错误的, 因为支撑集的交集必须满足 $\theta < \min x_i$, 即

$$\prod I_{(\theta, \infty)}(x_i) = I_{(\theta, \infty)}(\min x_i).$$

正确的分解导致 $\min X_i$ 是充分统计量, 而非 $\max X_i$ 。

本节小结.

- 充分统计量 T 保留了样本中关于 θ 的全部信息
- 因子分解定理是判断充分性的实用工具
- 注意支撑集对参数的依赖情况

3. 7.3 Properties of a Sufficient Statistic

本节讨论充分性的关键应用: 如何利用充分统计量改进任意无偏估计量。

3.1. Rao-Blackwell 定理. 给定一个充分统计量 T , 我们可以将任意无偏估计量 Y_2 改进为 T 的函数 $\varphi(T)$, 新估计量不仅保持无偏性, 方差还会减小。

THEOREM 7.2 (Rao-Blackwell 定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量。设 $Y_2 = u_2(X_1, \dots, X_n)$ (不是 Y_1 的函数) 是 θ 的无偏估计量。

则 $E(Y_2 | y_1) = \varphi(y_1)$ 定义了一个统计量 $\varphi(Y_1)$ 。该统计量 $\varphi(Y_1)$:

- (1) 是 θ 的无偏估计量
- (2) 是充分统计量的函数
- (3) 方差不超过 Y_2 的方差

证明思路: 利用全概率公式 $E(Y_2) = E[E(Y_2 | Y_1)]$ 和条件方差不增性质 $\text{var}(Y_2) \geq \text{var}[E(Y_2 | Y_1)]$ 。

这个定理的战略意义是: 在寻找 MVUE 时, 只需在充分统计量的函数中搜索。

EXAMPLE 7.8 (指数分布的 MVUE). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta e^{-\theta x}, \quad x > 0, \quad \theta > 0$$

的样本 (这是 $\Gamma(1, 1/\theta)$ 分布)。

联合 pdf 为 $L(\theta) = \theta^n e^{-\theta \sum x_i}$, 故 $Y_1 = \sum_{i=1}^n X_i$ 是充分统计量。

MLE 为 $Y_2 = 1/\bar{X} = n/Y_1$ 。由于 MLE 渐近无偏, 我们计算其期望。 $Y_1 \sim \Gamma(n, 1/\theta)$, 因此

$$E(Y_2) = n \cdot E(1/Y_1) = n \int_0^\infty \frac{\theta^n}{n!} t^{-1} t^{n-1} e^{-\theta t} dt = \frac{n}{n-1} \theta, \quad n > 1.$$

故 $(n-1)/n \cdot Y_2 = (n-1)/Y_1$ 是 θ 的无偏估计量, 且是充分统计量的函数, 因此是 *MVUE*。

3.2. 充分性与 MLE 的关系.

THEOREM 7.3 (充分性与 MLE). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。若 θ 的 MLE $\hat{\theta}$ 存在且唯一, 则 $\hat{\theta}$ 是充分统计量的函数。

直觉: 若 T 是充分的, 则似然函数 $L(\theta) = f_T(t; \theta) \cdot H(\mathbf{x})$ 。 $L(\theta)$ 和 $f_T(t; \theta)$ 作为 θ 的函数同时达到最大值, 故 $\hat{\theta}$ 必为 T 的函数。

这一结果具有重要的实践意义: 对于指数族分布, MLE 通常可以解析地写成充分统计量的函数。

本节小结.

- Rao-Blackwell 定理: 将任意无偏估计量改进为充分统计量的函数
- 充分性搜索范围: 从所有统计量缩小到充分统计量的函数
- 若 MLE 存在且唯一, 则必为充分统计量的函数

4. 7.4 Completeness and Uniqueness

有了 Rao-Blackwell 定理, 我们知道 MVUE (若存在) 必是充分统计量的函数。但充分统计量的函数可能有很多个——我们如何确定哪一个是 MVUE?

这就需要引入**完备性 (completeness)** 的概念。

4.1. 完备性的定义.

DEFINITION 7.3 (完备族). 设随机变量 Z (连续型或离散型) 的 pdf 或 pmf 是族 $\{h(z; \theta) : \theta \in \Omega\}$ 的一页。若条件 $E[u(Z)] = 0$ 对所有 $\theta \in \Omega$ 成立能够推出 $u(z) = 0$ (除了一个对每个 $h(z; \theta)$ 概率为零的点集), 则称该族为**完备族 (complete family)**。

简言之: 只有零函数才能期望为零。

EXAMPLE 7.9 (泊松分布族的完备性). 设 $X_1, \dots, X_n$ 是来自泊松分布 $P(\theta)$ 的样本。已知 $Y_1 = \sum X_i$ 是充分统计量, 其 pmf 为

$$g(y_1; \theta) = \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!}, \quad y_1 = 0, 1, 2, \dots$$

设 $E[u(Y_1)] = 0$ 对所有 $\theta > 0$ 成立, 即

$$\sum_{y_1=0}^{\infty} u(y_1) \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!} = 0.$$

由于 $e^{-n\theta} \neq 0$, 可得

$$u(0) + nu(1)\theta + \frac{n^2 u(2)}{2!} \theta^2 + \dots = 0, \quad \forall \theta > 0.$$

无穷幂级数对所有 $\theta > 0$ 为零, 意味着所有系数必为零:

$$u(0) = u(1) = u(2) = \cdots = 0.$$

故泊松充分统计量族是完备的。

EXAMPLE 7.10 (指数分布族的完备性). 设 $Z \sim \text{Exp}(\theta)$, 即 pdf 为 $h(z; \theta) = \frac{1}{\theta} e^{-z/\theta}$, $z > 0$ 。

设 $E[u(Z)] = 0$ 对所有 $\theta > 0$ 成立:

$$\int_0^\infty u(z) \frac{1}{\theta} e^{-z/\theta} dz = 0, \quad \forall \theta > 0.$$

令 $t = z/\theta$, 则 $\theta dt = dz$:

$$\int_0^\infty u(\theta t) e^{-t} dt = 0, \quad \forall \theta > 0.$$

对 θ 求导并利用积分号内可微 (假设 u 满足适当条件), 可得 $u(\theta t) \equiv 0$ 。由拉普拉斯变换的唯一性, $u \equiv 0$ 。故该族是完备的。

4.2. 完备充分统计量与 MVUE 的唯一性.

THEOREM 7.4 (Lehmann-Scheffé 定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量, 且族 $\{f_{Y_1}(y_1; \theta) : \theta \in \Omega\}$ 是完备的。

若存在 Y_1 的一个函数是 θ 的无偏估计量, 则该函数是唯一的 MVUE。

证明思路: 设 $\varphi(Y_1)$ 和 $\psi(Y_1)$ 都是 Y_1 的无偏估计量函数。则 $E[\varphi(Y_1) - \psi(Y_1)] = 0$ 对所有 θ 成立。由完备性, $\varphi(y_1) - \psi(y_1) = 0$ 几乎处处成立, 即两个估计量函数几乎处处相等——这就是“唯一”含义。

战略意义: 完备充分统计量的无偏函数就是 MVUE。

EXAMPLE 7.11 (均匀分布最大值的 MVUE). 设 $X_1, \dots, X_n$ 是来自 $\text{Uniform}(0, \theta)$ 的样本。 $Y_n = \max\{X_i\}$ 是充分统计量 (习题 7.2.3), 其 pdf 为

$$g(y_n; \theta) = \frac{ny_n^{n-1}}{\theta^n}, \quad 0 < y_n < \theta.$$

验证完备性: 设 $E[u(Y_n)] = 0$ 对所有 $\theta > 0$ 成立,

$$\int_0^\theta u(t) \frac{nt^{n-1}}{\theta^n} dt = 0.$$

等价于 $\int_0^\theta u(t) t^{n-1} dt = 0$ 。对 θ 求导得 $u(\theta) \theta^{n-1} = 0$, 故 $u(\theta) = 0$ 对所有 $\theta > 0$ 成立。故 Y_n 是完备充分的。

计算 $E(Y_n) = \frac{n}{n+1} \theta$, 故 $(n+1)/n \cdot Y_n$ 是 θ 的 MVUE。

EXAMPLE 7.12 (非完备的情况). 设 $X \sim N(0, \theta)$, $\theta > 0$ 。则 $Y = \sum X_i^2$ 是充分统计量, 但族 $\{f_Y(y; \theta)\}$ 不是完备的 (因为 χ^2 分布的自由度参数不依赖于 θ 的形式)。

实际上, 若 $Z \sim \chi_{n-1}^2$ (与 Y 独立), 则 $E(Z) = n-1$, 但这并不能推出关于 Y 的任何约束。

本节小结.

- 完备性: 只有零函数才能期望为零
- Lehmann-Scheffé 定理: 完备充分统计量的无偏函数是唯一的 MVUE
- 寻找 MVUE 的策略: 先找完备充分统计量, 再在其函数中找无偏估计量

5. 7.5 The Exponential Class of Distributions

在前几节中, 我们看到充分性和完备性是找到 MVUE 的关键。但如何系统地找到完备充分统计量? 本节介绍的**指数族分布 (exponential class)** 是一个具有优良性质的大类。

5.1. 正则指数族的定义.

DEFINITION 7.4 (正则指数族). 设 $f(x; \theta)$ 具有如下形式:

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)], \quad x \in \mathcal{S},$$

其中 $\mathcal{S}$ 是 X 的支撑集。若满足:

- (1) $\mathcal{S}$ 不依赖于 θ
- (2) $p(\theta)$ 是 $\theta \in \Omega$ 的非线性连续函数
- (3) 若 X 连续, 则 $K'(x) \neq 0$ 且 $H(x)$ 在 $\mathcal{S}$ 上连续; 若 X 离散, 则 $K(x)$ 在 $\mathcal{S}$ 上非线性

则称 $f(x; \theta)$ 属于**正则指数族 (regular exponential class)**。

直觉: 指数形式 $e^{p(\theta)K(x)}$ 使得对数似然函数是 $K(x)$ 的线性函数, 从而 $\sum K(X_i)$ 自然成为充分统计量。

EXAMPLE 7.13 (正态分布 $N(0, \theta)$ 是指数族). $N(0, \theta)$ 的 pdf 可写为

$$f(x; \theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-x^2/(2\theta)} = \exp \left[-\frac{1}{2\theta} x^2 - \frac{1}{2} \log(2\pi\theta) \right].$$

对应 $p(\theta) = -1/(2\theta)$, $K(x) = x^2$, $H(x) = -\frac{1}{2} \log(2\pi)$, $q(\theta) = -\frac{1}{2} \log(2\pi\theta)$ 。故 $N(0, \theta)$ 属于正则指数族。

若 $X_1, \dots, X_n \sim N(0, \theta)$, 则 $\sum X_i^2$ 是充分统计量。

EXAMPLE 7.14 (泊松分布是指数族). 泊松分布的 pmf 为

$$f(x; \theta) = e^{-\theta} \frac{\theta^x}{x!} = \exp[(\log \theta)x - \theta - \log(x!)].$$

对应 $p(\theta) = \log \theta$, $K(x) = x$, $q(\theta) = -\theta$, $H(x) = -\log(x!)$ 。故泊松分布属于正则指数族, $\sum X_i$ 是充分统计量。

反例: 均匀分布 $f(x; \theta) = 1/\theta$, $0 < x < \theta$ 的支撑集依赖于 θ , 因此不是正则指数族。

5.2. 指数族的核心定理.

THEOREM 7.5 (指数族充分统计量的性质). 设 $X_1, \dots, X_n$ 来自正则指数族, pdf/pmf 如定义所示. 设 $Y_1 = \sum_{i=1}^n K(X_i)$. 则:

(1) Y_1 的 pdf/pmf 具有形式

$$f_{Y_1}(y_1; \theta) = R(y_1) \exp[p(\theta)y_1 + nq(\theta)], \quad y_1 \in \mathcal{S}_{Y_1},$$

其中 $\mathcal{S}_{Y_1}$ 和 $R(y_1)$ 不依赖于 θ

$$(2) E(Y_1) = -n \frac{q'(\theta)}{p'(\theta)}$$

$$(3) \text{var}(Y_1) = n \cdot \frac{p''(\theta)q'(\theta) - q''(\theta)p'(\theta)}{[p'(\theta)]^3}$$

THEOREM 7.6 (指数族统计量的完备性). 在正则指数族条件下, $Y_1 = \sum_{i=1}^n K(X_i)$ 是 θ 的完备充分统计量。

证明思路: 设 $E[u(Y_1)] = 0$ 对所有 θ 成立. 利用 Y_1 的分布形式, 可得

$$\int u(y_1) R(y_1) \exp[p(\theta)y_1] dy_1 = 0, \quad \forall \theta.$$

由于 $p(\theta)$ 是非线性连续函数, 该积分本质上是 $u(y_1)R(y_1)$ 的拉普拉斯变换. 拉普拉斯变换为零意味着 $u(y_1)R(y_1) \equiv 0$. 由于 $R(y_1) > 0$ (它是 pdf 的因子), 故 $u(y_1) \equiv 0$.

EXAMPLE 7.15 (正态均值 θ 的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知. 则

$$f(x; \theta) = \exp \left[\frac{\theta}{\sigma^2} x - \frac{x^2}{2\sigma^2} - \log \sqrt{2\pi\sigma^2} - \frac{\theta^2}{2\sigma^2} \right].$$

故 $p(\theta) = \theta/\sigma^2$, $K(x) = x$, $q(\theta) = -\frac{\theta^2}{2\sigma^2}$. $Y_1 = \sum X_i = n\bar{X}$ 是完备充分统计量. $E(Y_1) = n\theta$, 故 $\varphi(Y_1) = Y_1/n = \bar{X}$ 是 θ 的唯一 MVUE。

指数族的战略价值: 对于指数族, 完备充分统计量可以通过观察直接写出, MVUE 也容易通过期望计算得到。

本节小结.

- 正则指数族具有形式 $e^{p(\theta)K(x)+H(x)+q(\theta)}$
- $\sum K(X_i)$ 是指数族的充分统计量
- 指数族统计量是完备充分的
- 指数族的 MVUE 可通过期望计算直接得到

6. 7.6 Functions of a Parameter

很多时候, 我们关心的不是参数 θ 本身, 而是其某个函数 $\delta = g(\theta)$. 例如, 估计 $\theta(1-\theta)$ 而非 θ 本身。

6.1. 技术一：观察法. 如果能通过观察 $E[\varphi(Y_1)] = g(\theta)$ 解出 φ 就可直接得到 MVUE。

EXAMPLE 7.16 (二项分布方差的 MVUE). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$. $Y = \sum X_i$ 是完备充分统计量。样本比例 Y/n 是 θ 的 MVUE。

现欲估计 $\delta = \theta(1 - \theta)$, 即 $\text{var}(Y/n) = \theta(1 - \theta)/n$ 。

MLE 为 $\tilde{\delta} = (Y/n)(1 - Y/n)$ 。计算期望:

$$E[\tilde{\delta}] = E\left[\frac{Y}{n}\left(1 - \frac{Y}{n}\right)\right] = \frac{n-1}{n}\theta(1 - \theta).$$

故 $\hat{\delta} = \frac{n}{n-1}\tilde{\delta} = \frac{Y(n-Y)}{n(n-1)}$ 是 δ 的 MVUE。

6.2. 技术二：条件期望法. 若 Z 是 θ 的无偏估计量, 则 $\varphi(Y_1) = E(Z | Y_1)$ 是 MVUE。

EXAMPLE 7.17 (正态分布累积概率的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ 。欲估计 $P(X \leq c) = \Phi(c - \theta)$ 。

取 $Z = I(X_1 \leq c)$, 则 $E(Z) = \Phi(c - \theta)$, 是无偏的。

$(X_1, \bar{X})$ 的联合分布是二元正态, 条件分布 $X_1 | \bar{X} = \bar{x}$ 是正态, 均值为 $\bar{x}$, 方差为 $(n-1)/n$ 。

计算条件期望:

$$E[Z | \bar{X} = \bar{x}] = P(X_1 \leq c | \bar{X} = \bar{x}) = \Phi\left[\frac{\sqrt{n}(c - \bar{x})}{\sqrt{n-1}}\right].$$

这是 $\Phi(c - \theta)$ 的 MVUE。

6.3. 7.6.1 Bootstrap 标准误. 对于 MVUE, 我们通常没有像 MLE 那样的渐近理论。但可以使用 Bootstrap 来获得标准误。

设 $\hat{\theta}$ 是基于原始样本的估计量。从经验分布 $\hat{F}_n$ 中有放回地抽取 B 个 Bootstrap 样本, 计算每个样本的估计值 $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ 。则 Bootstrap 标准误为

$$\text{SE}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\hat{\theta}})^2}, \quad \bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b^*.$$

这在 MVUE 的解析标准误难以获得时特别有用。

本节小结.

- 估计 $g(\theta)$ 时, 先找 θ 的完备充分统计量
- MVUE 或者是 T 的函数的期望, 或者通过条件期望改进
- Bootstrap 可用于估计 MVUE 的标准误

7. 7.7 The Case of Several Parameters

前面的讨论聚焦于单个参数。当分布涉及多个参数时, 我们需要联合充分统计量 (joint sufficient statistics) 的概念。

7.1. 联合充分统计量.

DEFINITION 7.5 (联合充分统计量). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本, 其中 $\theta \in \Omega \subset \mathbb{R}^p$. 设 $\mathbf{Y} = (Y_1, \dots, Y_m)$ 是统计量向量. 则 $\mathbf{Y}$ 是 θ 的联合充分统计量, 当且仅当

$$\frac{\prod_{i=1}^n f(x_i; \theta)}{f_{\mathbf{Y}}(\mathbf{y}; \theta)} = H(x_1, \dots, x_n),$$

其中 H 不依赖于 θ .

因子分解定理同样适用: 联合似然函数可分解为仅依赖 $\mathbf{y}$ 的因子和与参数无关的因子.

EXAMPLE 7.18 (双参数正态分布). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$, 其中 θ_1 是均值, θ_2 是方差.

联合 pdf 为

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi\theta_2}} \exp \left[-\frac{(x_i - \theta_1)^2}{2\theta_2} \right].$$

利用恒等式 $\sum (x_i - \theta_1)^2 = \sum x_i^2 - n\bar{x}^2 + n(\bar{x} - \theta_1)^2$, 可得

$$\prod f(x_i; \theta) = \exp \left[-\frac{n(\bar{x} - \theta_1)^2}{2\theta_2} \right] \cdot \frac{\exp \left[-\frac{1}{2\theta_2} \sum (x_i - \bar{x})^2 \right]}{(\sqrt{2\pi\theta_2})^n}.$$

因此 $(\bar{X}, \sum X_i^2)$ 或等价地 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量.

EXAMPLE 7.19 (均匀分布的双参数). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta_1, \theta_2) = \frac{1}{2\theta_2} I_{(\theta_1 - \theta_2, \theta_1 + \theta_2)}(x).$$

这是区间长度为 $2\theta_2$ 、中心为 θ_1 的均匀分布. 充分统计量为 $(Y_1, Y_n) = (\min X_i, \max X_i)$.

7.2. 多参数指数族.

DEFINITION 7.6 (m 参数指数族). 设 $f(x; \theta)$ 具有形式

$$f(x; \theta) = \exp \left[\sum_{j=1}^m p_j(\theta) K_j(x) + H(x) + q(\theta) \right], \quad x \in \mathcal{S}.$$

在正则条件下, 统计量

$$Y_j = \sum_{i=1}^n K_j(X_i), \quad j = 1, \dots, m$$

是 θ 的联合完备充分统计量 (当 $n > m$ 时).

EXAMPLE 7.20 (双参数指数族). $N(\theta_1, \theta_2)$ 可写为指数形式:

$$f(x; \theta_1, \theta_2) = \exp \left[-\frac{1}{2\theta_2} x^2 + \frac{\theta_1}{\theta_2} x - \frac{\theta_1^2}{2\theta_2} - \frac{1}{2} \log(2\pi\theta_2) \right].$$

取 $K_1(x) = x^2$, $K_2(x) = x$, 则联合充分统计量为 $(\sum X_i^2, \sum X_i)$, 与之前的结论一致.

多参数情况下的 MVUE: 设 $\delta = g(\theta)$ 是感兴趣的参数函数。若 $\mathbf{Y}$ 是联合完备充分统计量, 则 $E[\delta | \mathbf{Y}]$ 是 δ 的 MVUE。

本节小结.

- 多参数时需要联合充分统计量
- 双参数正态: $(\bar{X}, S^2)$ 是联合完备充分统计量
- 多参数指数族具有联合完备充分统计量

8. 7.8 Minimal Sufficiency and Ancillary Statistics

充分统计量不唯一——任何一一变换 (one-to-one transformation) 还是充分统计量。但我们总希望找到“最小”的充分统计量, 用最少的统计量包含全部信息。

8.1. 最小充分统计量.

DEFINITION 7.7 (最小充分统计量). 设 T 是充分统计量。若对任何其他充分统计量 T' , T 都是 T' 的函数, 则称 T 是**最小充分统计量** (*minimal sufficient statistic*)。

直观理解: 最小充分统计量是“最压缩”的充分统计量——无法在保持充分性的前提下进一步压缩。

一个关键洞察: 若 MLE $\hat{\theta}$ 是充分的, 则 $\hat{\theta}$ 必是最小充分统计量 (因为任何其他充分统计量都能导出 $\hat{\theta}$)。

EXAMPLE 7.21 (均匀分布 $(\theta - 1, \theta + 1)$ 的最小充分统计量). 设 $X_1, \dots, X_n$ 来自 $Uniform(\theta - 1, \theta + 1)$ 分布。

联合 pdf 中出现的指示函数要求 $\theta - 1 < \min x_i \leq x_j \leq \max x_i < \theta + 1$ 。因此 $(Y_1, Y_n) = (\min X_i, \max X_i)$ 是充分统计量。

由于无法进一步压缩 (两个统计量缺一不可), 它们是最小充分统计量。注意这与单参数情况不同——无法用一个统计量替代两个。

一般位置模型: 若 $X_i = \theta + W_i$, 其中 W_i iid, 则顺序统计量 $(Y_1, \dots, Y_n)$ 是最小充分的。但有时也可以进一步压缩——例如正态分布时 $\bar{X}$ 就足够了。

8.2. 辅助统计量 (Ancillary Statistics). 充分统计量包含关于参数的全部信息。辅助统计量的分布则完全不含参数信息——看似是充分性的“对立面”。

DEFINITION 7.8 (辅助统计量). 设 $Z = u(X_1, \dots, X_n)$ 是统计量。若 Z 的分布不依赖于 θ , 则称 Z 是**辅助统计量** (*ancillary statistic*)。

例子:

- $N(\theta, 1)$ 分布中, S^2 是辅助统计量 (其分布不依赖于 θ)
- 尺度模型 $X_i = \theta W_i$ 中, X_1/X_2 是辅助统计量

辅助统计量揭示了数据中与参数无关的部分。虽然看似无用, 但它们在构建置信区间和检验中很有价值。

EXAMPLE 7.22 (位置不变统计量). 设 $X_i = \theta + W_i, W_i \text{ iid}$. 统计量 $Z = u(X_1, \dots, X_n)$ 若满足

$$u(x_1 + d, \dots, x_n + d) = u(x_1, \dots, x_n), \quad \forall d,$$

则是位置不变的。直观上, 这意味着 Z 只描述 W_i 的性质, 因此与 θ 无关。

常见的例子包括: 样本方差 S^2 、样本极差 $\max X_i - \min X_i$ 、以及 $\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 。

EXAMPLE 7.23 (尺度不变统计量). 设 $X_i = \theta W_i, \theta > 0, W_i \text{ iid}$. 若 Z 满足

$$u(cx_1, \dots, cx_n) = u(x_1, \dots, x_n), \quad \forall c > 0,$$

则是尺度不变的。

例子: $X_1/(X_1 + X_2)$ 、 $X_1^2/\sum X_i^2$ 、 $\min X_i/\max X_i$ 。

辅助统计量与充分统计量的关系将在下节的 Basu 定理中揭示。

本节小结.

- 最小充分统计量是充分统计量的一一变换后仍保持充分性
- 若 MLE 是充分的, 则它必是最小充分的
- 辅助统计量的分布不含参数信息
- 位置/尺度不变统计量是常见的辅助统计量

9. 7.9 Sufficiency, Completeness, and Independence

本节揭示充分性、完备性与独立性之间的深刻联系——Basu 定理。

9.1. Basu 定理的动机. 我们已经知道:

- 若 T 是充分的, 则 Z 的条件分布 $h(z | t)$ 不依赖于 θ
- 若 T 和 Z 独立, 则 Z 的边际分布 $g_2(z) = h(z | t)$ 不依赖于 θ ——即 Z 是辅助的

反过来: 若 Z 是辅助的 (分布不含 θ), T 是充分的, T 和 Z 是否独立?

直觉上似乎应该独立——但这需要证明。

9.2. Basu 定理.

THEOREM 7.7 (Basu 定理). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本, $\theta \in \Omega$ (Ω 是区间)。设 T 是 θ 的**完备充分统计量**。设 $Z = u(X_1, \dots, X_n)$ 是另一个统计量。

若 Z 的分布不依赖于 θ (即 Z 是辅助的), 则 T 与 Z 独立。

证明思路: 考虑 T 和 Z 的联合 pdf $g_1(t; \theta)h(z | t)$ 。 Z 的边际分布为

$$\int g_1(t; \theta)h(z | t)dt = g_2(z),$$

不依赖于 θ 。同时 $g_2(z) = \int g_2(z)g_1(t; \theta)dt$ 。两式相减得

$$\int [g_2(z) - h(z | t)]g_1(t; \theta)dt = 0, \quad \forall \theta.$$

由于 T 是完备的, 上式意味着 $g_2(z) - h(z | t) = 0$ 几乎处处成立, 即 $h(z | t) = g_2(z)$, 故 T 与 Z 独立。

核心洞察: 完备性是独立性的关键——它保证了期望为零的函数必为零函数。

EXAMPLE 7.24 (正态分布中 $\bar{X}$ 与 S^2 的独立性). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知。则 $\bar{X}$ 是 θ 的完备充分统计量。

样本方差 S^2 是位置不变的——其分布不依赖于 θ 。由 Basu 定理, $\bar{X}$ 与 S^2 独立。这与我们在第 3 章用到的结果一致。

EXAMPLE 7.25 (指数分布中 T 与尺度不变量的独立性). 设 $X_1, X_2 \sim \text{Exp}(\theta)$ 。则 $Y_1 = X_1 + X_2$ 是完备充分统计量。

考虑比值 $Z = X_1 / (X_1 + X_2)$ 。这是尺度不变的 ($Z(cX_1, cX_2) = Z(X_1, X_2)$), 因此 Z 的分布不含 θ 。

由 Basu 定理, Y_1 与 Z 独立。实际上, $Z \sim \text{Beta}(1, 1)$ (均匀分布), 与指数分布的参数无关。

EXAMPLE 7.26 (正态双参数中 $\bar{X}, S^2$ 与辅助量的独立性). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$ 。则 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量。

考虑统计量

$$Z = \frac{\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

该统计量满足位置-尺度不变性, 因此其分布不含 (θ_1, θ_2) 。由 Basu 定理, Z 与 $(\bar{X}, S^2)$ 独立。

9.3. Basu 定理的应用. Basu 定理的价值在于:

- (1) 提供独立性证明的简洁方法 (无需计算联合分布)
- (2) 揭示了“信息对立”: 完备充分统计量与辅助统计量正交
- (3) 辅助统计量虽然不含参数信息, 但可用于构建置信区间 (如枢轴量)

重要注记: 若充分统计量不是完备的, Basu 定理不适用——此时辅助统计量可能与充分统计量不独立, 辅助统计量中可能仍包含关于参数的**条件信息**。

EXAMPLE 7.27 (非完备情况下的条件信息). 在均匀分布 $(\theta - 1, \theta + 1)$ 例子中, 充分统计量是 $(Y_1, Y_n) = (\min X_i, \max X_i)$, 但它们不是完备的。

令 $T_1 = (Y_1 + Y_n)/2$ (θ 的无偏估计) 和 $T_2 = Y_n - Y_1$ (辅助的)。虽然 T_2 是辅助的, 但给定 $T_2 = t_2$ 的条件下, T_1 的方差为 $(2 - t_2)^2/12$ ——较小的 t_2 意味着 T_1 有更大的方差。

这说明 T_2 虽然是边缘意义下的辅助统计量, 但在条件意义下仍提供关于估计精度的信息。

这种情况在实际中很重要: 当样本来自非正态分布时, 样本均值 $\bar{X}$ 和样本方差 S^2 可能相关, S^2 的值能提供关于 $\bar{X}$ 精度的信息。

本节小结.

- Basu 定理: 完备充分统计量与任何辅助统计量独立
- 独立性证明的新工具: 无需计算联合分布
- 若充分统计量非完备, 辅助统计量可能携带条件信息
- 这解释了为什么正态分布中 $\bar{X}$ 与 S^2 的独立性如此特别

本章习题

7.2.1 —Sufficient Statistic for Normal Variance Let $X_1, X_2, \dots, X_n$ be iid $N(0, \theta)$, $0 < \theta < \infty$. Show that $\sum_{i=1}^n X_i^2$ is a sufficient statistic for θ .

7.2.4 —Geometric Distribution Sufficiency Let $X_1, X_2, \dots, X_n$ be a random sample of size n from a geometric distribution that has pmf $f(x; \theta) = (1 - \theta)^x \theta$, $x = 0, 1, 2, \dots$, $0 < \theta < 1$, zero elsewhere. Show that $\sum_{i=1}^n X_i$ is a sufficient statistic for θ .

7.3.3 —Rao-Blackwell for Exponential Distribution If X_1, X_2 is a random sample of size 2 from a distribution having pdf $f(x; \theta) = (1/\theta)e^{-x/\theta}$, $0 < x < \infty$, $0 < \theta < \infty$, zero elsewhere, find the joint pdf of the sufficient statistic $Y_1 = X_1 + X_2$ for θ and $Y_2 = X_2$. Show that Y_2 is an unbiased estimator of θ with variance θ^2 . Find $E(Y_2 | y_1) = \varphi(y_1)$ and the variance of $\varphi(Y_1)$.

7.4.1 —Completeness of Binomial Family If $az^2 + bz + c = 0$ for more than two values of z , then $a = b = c = 0$. Use this result to show that the family $\{b(2, \theta) : 0 < \theta < 1\}$ is complete.

7.4.5 —Complete Sufficient Statistic for Shifted Exponential Show that the first order statistic $Y_1 = \min(X_i)$ of a random sample of size n from the distribution having pdf $f(x; \theta) = e^{-(x-\theta)}$, $\theta < x < \infty$, $-\infty < \theta < \infty$, zero elsewhere, is a complete sufficient statistic for θ . Find the unique function of this statistic which is the MVUE of θ .

7.5.2 —MVUE via Exponential Class Let $X_1, X_2, \dots, X_n$ denote a random sample of size $n > 1$ from a distribution with pdf $f(x; \theta) = \theta e^{-\theta x}$, $0 < x < \infty$, zero elsewhere, and $\theta > 0$. Then $Y = \sum_{i=1}^n X_i$ is a sufficient statistic for θ . Prove that $(n-1)/Y$ is the MVUE of θ .

7.6.1 —MVUE of θ^2 for Normal Let $X_1, X_2, \dots, X_n$ denote a random sample from a distribution that is $N(\theta, 1)$, $-\infty < \theta < \infty$. Find the MVUE of θ^2 .

7.9.1 —Basu's Theorem for Uniform Distribution Let $Y_1 < Y_2 < Y_3 < Y_4$ denote the order statistics of a random sample of size $n = 4$ from a distribution having pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, zero elsewhere, where $0 < \theta < \infty$. Argue that the complete sufficient statistic Y_4 for θ is independent of each of the statistics Y_1/Y_4 and $(Y_1 + Y_2)/(Y_3 + Y_4)$.

Optimal Statistical Tests

Chapter 8 Overview

在前几章中，我们建立了估计理论和假设检验的基本框架。我们学会了如何构造点估计、区间估计，以及如何使用似然比检验。但在所有这些讨论中，一个根本性的问题始终潜伏在幕后：

在所有可能的检验中，哪个检验是“最好”的？

这个问题——即**最优检验理论 (optimal test theory)**——是本章的核心。在假设检验中，我们面临一个固有的权衡 (trade-off)：降低第一类错误 (Type I error) 的概率往往意味着提高第二类错误 (Type II error) 的概率，反之亦然。最优检验理论试图在固定的显著性水平下，找到功效 (power) 最高的检验。

为什么需要最优性理论？ 考虑一个医学检测场景：我们希望设计一个检验来筛查某种疾病。给定显著性水平 $\alpha = 0.05$ ，我们当然希望当患者真的患病时，检验能以最高概率检测出来——这就是功效。没有最优性理论，我们只能在黑暗中摸索不同的检验方法，无法保证我们选择的检验是最佳的。

本章建立这套理论的路径如下：

- (1) **Neyman-Pearson 引理** (8.1 节)：对于简单假设对简单假设的情况，给出了最优检验的完整刻画——这是整个理论的基石。
- (2) **一致最大功效检验 (UMP)** (8.2 节)：将最优性概念推广到复合备择假设。介绍 monotone likelihood ratio (MLR) 和 Karlin-Rubin 定理——单参数指数族存在 UMP 检验。
- (3) **似然比检验 (LRT)** (8.3 节)：在一般复合假设下，LRT 提供了一种构造检验的通用方法。虽然 LRT 不一定是最优的，但在很多情况下它是渐近最优的。
- (4) **序贯概率比检验 (SPRT)** (8.4 节)：打破固定样本量的束缚，允许检验在数据积累过程中随时停止——Wald 的革命性贡献。
- (5) **极小化极大分类** (8.5 节)：将决策论框架应用于假设检验和分类问题。

1. 8.1 Most Powerful Tests

1.1. 问题的起源：什么是“最好”的检验。 在 4.5 节中，我们引入了假设检验的基本框架：给定原假设 H_0 和备择假设 H_1 ，我们构造一个临界区域 C ，当样本落入 C 时拒绝 H_0 。但正如我们在 4.5 节所见，对于同一对假设，存在无穷多个可能的检验——临界区域 C 的选择并非唯一。

在所有这些检验中，我们凭什么说一个比另一个更好？

要回答这个问题，我们首先需要有一个评价标准。在假设检验中，这个标准就是**功效 (power)**——当 H_1 为真时拒绝 H_0 的概率。直观上，我们希望：

- (1) 在 H_0 为真时，拒绝 H_0 的概率（即 α ，显著性水平）不超过预设值；
- (2) 在 H_1 为真时，拒绝 H_0 的概率（即功效）尽可能高。

这就引出了“最好检验”的定义。

1.2. 简单假设对简单假设的最优检验. 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本，其中 $\theta \in \Omega = \{\theta', \theta''\}$ （即只有两个可能的参数值）。我们考虑检验：

$$H_0 : \theta = \theta' \quad \text{versus} \quad H_1 : \theta = \theta''.$$

(8.1.1)

DEFINITION 8.1 (最佳临界区域). 设 C 是样本空间的一个子集。如果

- (a) $P_{\theta'}[\mathbf{X} \in C] = \alpha$ （大小为 α ）；
- (b) 对每一个满足 $P_{\theta'}[\mathbf{X} \in A] = \alpha$ 的子集 A ，都有

$$P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A],$$

则称 C 是检验 $H_0 : \theta = \theta'$ 对 $H_1 : \theta = \theta''$ 的大小为 α 的**最佳临界区域 (best critical region of size α)**。

定义的直观含义：在所有满足显著性水平 α 的检验中，最佳临界区域对应的检验在 H_1 为真时具有最高的拒绝概率——这正是我们想要的。

为什么要关心最佳检验？设想你在设计一个药物试验。你设定 $\alpha = 0.05$ （即当药物无效时，只有 5% 的概率错误地拒绝 H_0 ）。在所有满足这个条件的检验中，你当然希望当药物真的有效时，以最高概率检测出来——这就是最佳检验的价值。

那么，这样的最佳检验是否存在？Neyman-Pearson 定理给出了答案。

1.3. Neyman-Pearson 定理.

有没有一种系统性的方法构造最佳检验？

Neyman-Pearson 定理不仅回答了“最佳检验是否存在”的问题，还给出了构造方法——它是以似然比 (likelihood ratio) 为基础的。

[Neyman-Pearson] 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本，记似然函数为

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

设 θ' 和 θ'' 是 θ 的两个不同取值， $\Omega = \{\theta', \theta''\}$ 。设 $k > 0$ 是一个常数， C 是样本空间的一个子集，满足：

- (a) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$ 对所有 $\mathbf{x} \in C$ ；

- (b) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k$ 对所有 $\mathbf{x} \in C^c$;
 (c) $\alpha = P_{H_0}[\mathbf{X} \in C]$.

则 C 是检验简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ 的、大小为 α 的最佳临界区域。

核心思想：似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x})$ 衡量了数据 $\mathbf{x}$ 更支持 H_0 还是更支持 H_1 。当这个比值很小时，数据更支持 H_1 ，因此我们拒绝 H_0 。

物理直觉：想象你在两个假设之间做选择。 $L(\theta'; \mathbf{x})$ 告诉我们“如果 H_0 为真，观察到这组数据的可能性有多大”； $L(\theta''; \mathbf{x})$ 在 H_0 下很小但在 H_1 下很大，这强烈暗示 H_1 才是正确的解释。

充分性：值得注意的是，定理的证明表明，如果存在一个大小为 α 的最佳检验，那么它的形式必然是上述似然比检验。而且，这个最佳检验（如果存在）是唯一的（在连续型情况下，除了一个零概率集；在离散型中可能存在多个）。¹

EXAMPLE 8.1 (二项分布下的最佳检验). 设 $X \sim \text{Binomial}(n = 5, p = \theta)$ ，考虑检验：

$$H_0: \theta = \frac{1}{2} \quad \text{versus} \quad H_1: \theta = \frac{3}{4}.$$

下表给出 $f(x; 1/2)$ 、 $f(x; 3/4)$ 以及它们的比值：

x	0	1	2	3	4	5
$f(x; 1/2)$	1/32	5/32	10/32	10/32	5/32	1/32
$f(x; 3/4)$	1/1024	15/1024	90/1024	270/1024	405/1024	243/1024
$f(x; 1/2)/f(x; 3/4)$	32/1	32/3	32/9	32/27	32/81	32/243

问题：构造大小 $\alpha = 1/32$ 的最佳检验。

比值 $f(x; 1/2)/f(x; 3/4)$ 在 $x = 5$ 处取得最小值 (32/243)。因此，最佳临界区域应包含那些使 H_0 看起来极不可能而 H_1 看起来极可能的数据点——即 $C = \{x = 5\}$ 。

验证： $P_{H_0}(X \in C) = f(5; 1/2) = 1/32 = \alpha$ ，且 $P_{H_1}(X \in C) = f(5; 3/4) = 243/1024 \approx 0.237$ 。

如果取 $\alpha = 6/32$ ，则最佳临界区域为 $\{x = 4, 5\}$ ，因为 $x = 4$ 和 $x = 5$ 的比值最小。此时

$$P_{H_1}(X \in \{4, 5\}) = \frac{405}{1024} + \frac{243}{1024} = \frac{648}{1024} \approx 0.633.$$

关键洞察：最佳检验包含了“最支持 H_1 而最不支持 H_0 ”的数据点——这正是似然比方法告诉我们的。²

EXAMPLE 8.2 (正态均值差假设的最优检验). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ ，考虑检验：

$$H_0: \theta = 0 \quad \text{versus} \quad H_1: \theta = 1.$$

构造最佳检验：似然函数为

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

¹Neyman-Pearson 引理的完整证明见附录 section 5.3。

²二项分布最佳检验的详细分析见附录 ??。

似然比为

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \exp \left(- \sum_{i=1}^n x_i + \frac{n}{2} \right).$$

令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$, 等价于

$$\sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

因此, 最佳临界区域是 $C = \{\mathbf{x} : \sum_{i=1}^n x_i \geq c\}$, 即基于样本均值 $\bar{X}$ 的检验。

确定临界值: 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故

$$c_1 = \frac{c}{n} = \frac{\frac{n}{2} - \log k}{n} = \frac{1}{2} - \frac{\log k}{n}.$$

给定显著性水平 α , 临界值为 $c_1 = q_\alpha(0, 1/\sqrt{n})$ ($N(0, 1/n)$ 的上 α 分位数)。

数值示例: 设 $n = 25$, $\alpha = 0.05$, 则 $c_1 = \text{qnorm}(0.95, 0, 1/5) = 0.329$ 。

功效计算: 当 H_1 为真时, $\bar{X} \sim N(1, 1/25)$, 功效为

$$Power = P_{H_1}(\bar{X} \geq 0.329) = 1 - \Phi \left(\frac{0.329 - 1}{1/5} \right) = 1 - \Phi(-3.355) \approx 0.9996.$$

也就是说, 当 $\theta = 1$ 时, 这个检验有约 99.96% 的概率正确拒绝 H_0 。³

EXAMPLE 8.3 (Poisson 对 Geometric 的检验). 设 $X_1, \dots, X_n \sim f(x)$, 其中

$$H_0 : f(x) = \frac{e^{-1}}{x!}, \quad x = 0, 1, 2, \dots \quad (\text{Poisson}(\lambda = 1)),$$

$$H_1 : f(x) = \left(\frac{1}{2}\right)^{x+1}, \quad x = 0, 1, 2, \dots \quad (\text{Geometric}(p = 1/2)).$$

构造最佳检验: 似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \frac{(2e^{-1})^n \cdot 2^{\sum x_i}}{\prod_{i=1}^n (x_i!)}.$$

令 $k = 1$ (对应某个特定的 α), 不等式化为

$$\frac{2^{\sum x_i}}{\prod_{i=1}^n (x_i!)} \leq \frac{e}{2}.$$

取 $n = 1$, 则临界区域为 $C = \{x_1 : x_1 = 0, 3, 4, 5, \dots\}$ 。

验证:

$$\alpha = P_{H_0}(X \in C) = 1 - \frac{e^{-1}}{1!} - \frac{e^{-1}}{2!} = 1 - \frac{2}{e} \approx 0.4482,$$

$$Power = P_{H_1}(X \in C) = 1 - \frac{1}{4} - \frac{1}{8} = 0.625.$$

这符合无偏性要求 (功效大于显著性水平)。⁴

无偏性 (Unbiasedness): 注意到所有最佳检验都满足一个共同性质——功效大于等于显著性水平。这意味着拒绝 H_0 (当它为假时) 的概率不小于错误拒绝它的概率。这在经济决策中是完全合理的——如果检验的功效低于 α , 那它的行为还不如随机猜测。

³正态均值检验的完整推导见附录 section 5.4。

⁴Poisson vs Geometric 检验的详细分析见附录 ??。

DEFINITION 8.2 (无偏检验). 设 C 是显著性水平为 α 的检验的临界区域。如果对所有 $\theta \in \omega_1$,

$$P_{\theta}(\mathbf{X} \in C) \geq \alpha,$$

则称该检验是**无偏的** (*unbiased*)。

推论 8.1.1 表明 Neyman-Pearson 最佳检验是无偏的——在 H_0 为假时拒绝它的概率不低于在 H_0 为真时错误拒绝它的概率。⁵

2. 8.2 Uniformly Most Powerful Tests

2.1. 从简单假设到复合假设. 上一节的 Neyman-Pearson 定理解决的是“简单假设对简单假设”的问题—— H_0 和 H_1 都各只有一个参数值。但在实际中, 备择假设通常是复合的 (composite), 例如:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

这里 H_1 包含无穷多个参数值。对于这样的问题, 我们自然希望找到一个检验, 它在 H_0 的每一个边界点上都是最佳的。

能否找到一个检验, 它对 $\theta > \theta'$ 中的每一个 θ 都是最佳检验?

这就是“一致最大功效 (Uniformly Most Powerful, UMP)”检验的思想。

DEFINITION 8.3 (UMP 检验). 设 C 是显著性水平为 α 的检验的临界区域。如果 C 是 H_0 对 H_1 中每一个简单假设的最佳临界区域, 则称 C 为**大小为 α 的一致最大功效临界区域** (*UMP critical region*), 相应的检验称为 **UMP 检验** (*Uniformly Most Powerful test*)。

但 UMP 检验并不总是存在。例 8.2.3 展示了: 对于正态均值 $\sigma^2 = 1$ 已知时, 检验 $H_0: \theta = \theta'$ 对 $H_1: \theta \neq \theta'$ (双向备择) 不存在 UMP 检验——因为对 $\theta'' > \theta'$ 的最佳临界区域 (拒绝域在右尾) 与对 $\theta'' < \theta'$ 的最佳临界区域 (拒绝域在左尾) 形式完全不同, 无法统一。

这个例子揭示了一个深刻的事实: UMP 检验只在**单向备择假设** (*one-sided alternatives*) 下才可能存在。

2.2. 单调似然比与 Karlin-Rubin 定理. 那么, 在什么条件下 UMP 检验存在呢? 答案藏在一种叫做“单调似然比 (Monotone Likelihood Ratio, MLR)”的性质中。

DEFINITION 8.4 (单调似然比). 设 $L(\theta, \mathbf{x})$ 是似然函数。如果对 $\theta_1 < \theta_2$, 比值

$$\frac{L(\theta_1; \mathbf{x})}{L(\theta_2; \mathbf{x})}$$

是统计量 $y = u(\mathbf{x})$ 的单调递减函数, 则称似然函数在 $y = u(\mathbf{x})$ 中有**单调似然比** (*monotone likelihood ratio, mlr*)。

⁵推论 8.1.1 的证明及无偏性的讨论见附录 ??。

为什么 MLR 如此重要? MLR 性质确保了对较大的 y (即更支持备择假设的数据), 我们统一拒绝 H_0 ——而不需要针对每一个具体的 θ'' 分别构造最佳检验。

[Karlin-Rubin 定理] 设随机样本来自密度 $f(x; \theta)$, 似然函数 $L(\theta, \mathbf{x})$ 在统计量 $Y = u(\mathbf{X})$ 中有单调似然比。考虑单向假设:

$$H_0 : \theta \leq \theta' \quad \text{versus} \quad H_1 : \theta > \theta'.$$

则对任意显著性水平 α , UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y \geq c_Y,$$

其中临界值 c_Y 满足 $P_{\theta'}[Y \geq c_Y] = \alpha$ 。

核心洞察: 由于 MLR 性质, 对任何 $\theta'' > \theta'$, 最佳临界区域的形式都是 $Y \geq c$ ——它们恰好是同一个区域! 因此这个区域对所有 $\theta'' > \theta'$ 都是最佳的, 从而是一致最大功效的。

证明思路: 对固定的 $\theta'' > \theta'$, 由 Neyman-Pearson 定理, 最佳临界区域由似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x}) \leq k$ 给出。由于 MLR 性质, 这个不等式等价于 $Y \geq g^{-1}(k)$ ——即只依赖于数据的形状, 而不依赖于具体的 θ'' 值。⁶

EXAMPLE 8.4 (正态方差 UMP 检验). 设 $X_1, \dots, X_n \sim N(0, \theta)$, 其中 $\theta > 0$ 是方差。考虑检验:

$$H_0 : \theta = \theta' \quad \text{versus} \quad H_1 : \theta > \theta'.$$

似然函数为

$$L(\theta; \mathbf{x}) = \left(\frac{1}{2\pi\theta}\right)^{n/2} \exp \left\{ -\frac{1}{2\theta} \sum_{i=1}^n x_i^2 \right\}.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left(\frac{\theta''}{\theta'}\right)^{n/2} \exp \left[-\left(\frac{\theta'' - \theta'}{2\theta'\theta''}\right) \sum_{i=1}^n x_i^2 \right].$$

对 $\theta'' > \theta'$, 这是 $\sum x_i^2$ 的递减函数, 因此似然函数在 $Y = \sum X_i^2$ 中有 MLR。

由 Karlin-Rubin 定理, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad \sum_{i=1}^n X_i^2 \geq c,$$

其中 c 满足 $P_{\theta'}[\sum X_i^2 \geq c] = \alpha$ 。

数值示例: 设 $n = 15$, $\alpha = 0.05$, $\theta' = 3$ 。当 H_0 为真时, $\sum X_i^2/\theta' \sim \chi^2(n)$, 故

$$\frac{c}{3} = \chi_{0.95}^2(15) = 24.996 \quad \Rightarrow \quad c = 74.988.$$

即当 $\sum x_i^2 \geq 74.988$ 时拒绝 $H_0 : \theta = 3$ 。⁷

⁶Karlin-Rubin 定理的完整证明见附录 section 5.5。

⁷正态方差 UMP 检验的详细推导见附录 ??。

EXAMPLE 8.5 (Bernoulli 分布的 UMP 检验). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$, 考虑检验:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left[\frac{\theta'(1-\theta'')}{\theta''(1-\theta')} \right]^{\sum x_i} \left(\frac{1-\theta'}{1-\theta''} \right)^n.$$

由于 $\theta' < \theta''$ 时 $\theta'(1-\theta'')/\theta''(1-\theta') < 1$, 该比值是 $Y = \sum X_i$ 的递减函数。因此似然函数在 $Y = \sum X_i$ 中有 MLR, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y = \sum_{i=1}^n X_i \geq c,$$

其中 c 由 $P_{\theta'}[Y \geq c] = \alpha$ 确定。

这正是我们直观上期望的: 观察到更多的成功次数, 就越有理由拒绝“成功率不高”的原假设。⁸

正规指数族 (Regular Exponential Family): 其实 Bernoulli 分布、正态分布 (方差已知)、Poisson 分布都属于一个更广泛的族——正规指数族。在这个族中, 只要自然参数是单调的, 就存在 UMP 检验。具体地, 如果分布有形式

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)],$$

且 $p(\theta)$ 是 θ 的递增函数, 则对假设 $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$, UMP 检验存在, 基于统计量 $Y = \sum_{i=1}^n K(X_i)$ 。⁹

3. 8.3 Likelihood Ratio Tests

3.1. 似然比检验的动机. 在前两节中, 我们学会了如何在简单假设对简单假设时构造最佳检验, 以及在具有 MLR 性质的族中对单向复合假设构造 UMP 检验。但现实中很多重要问题超出了这些范畴:

- 检验正态均值 $H_0: \mu = \mu_0$ (σ^2 未知) 对 $H_1: \mu \neq \mu_0$ ——不存在 UMP 检验 (双向备择);
- 检验两正态均值是否相等 $H_0: \mu_1 = \mu_2$ ——涉及多于一个参数;
- 一般复合假设——没有 MLR 性质可供利用。

在这些情况下, 我们转向一种通用但不一定最优的构造检验的方法——**似然比检验 (Likelihood Ratio Test, LRT)**。

为什么即使 LRT 不是最优的, 我们仍然使用它? 历史上, Neyman 和 Pearson 引入 LRT 的动机正是为了突破最佳检验只存在于简单假设的限制。LRT 继承了 Neyman-Pearson 定理的似然比思想 (用似然比衡量数据对假设的支持程度), 但将比较扩展到

⁸Bernoulli UMP 检验的 MLR 证明见附录 ??。

⁹正规指数族的 UMP 检验存在性讨论见附录 ??。

了复合假设。虽然在一般情况下 LRT 不能保证最优性，但它是渐近最优的——在样本量趋向无穷时，LRT 具有许多优良性质。¹⁰

3.2. LRT 的定义. 设 X 的密度为 $f(\mathbf{x}; \boldsymbol{\theta})$ ，参数 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$ 。考虑复合假设：

$$H_0 : \boldsymbol{\theta} \in \omega \quad \text{versus} \quad H_1 : \boldsymbol{\theta} \in \Omega \cap \omega^c, \quad (8.3.1)$$

其中 $\omega \subset \Omega$ 是参数空间的某个子集。

DEFINITION 8.5 (似然比). 似然比 (*Likelihood Ratio*) 定义为：

$$\Lambda(\mathbf{x}) = \frac{\sup_{\omega} L(\boldsymbol{\theta}; \mathbf{x})}{\sup_{\Omega} L(\boldsymbol{\theta}; \mathbf{x})} = \frac{L(\hat{\omega}; \mathbf{x})}{L(\hat{\Omega}; \mathbf{x})},$$

其中 $\hat{\omega}$ 是在约束 $\boldsymbol{\theta} \in \omega$ 下的 MLE, $\hat{\Omega}$ 是在无约束 $\boldsymbol{\theta} \in \Omega$ 下的 MLE。

直观含义：分子衡量数据在 H_0 约束下能达到的最大似然，分母衡量数据在无约束情况下能达到的最大似然。如果 H_0 为真，这两个值应该差不多，比值接近 1；如果 H_0 为假，无约束的似然会显著大于约束下的似然，比值会变小。因此我们在小比值时拒绝 H_0 ：

$$\text{Reject } H_0 \quad \text{if} \quad \Lambda(\mathbf{x}) \leq \lambda_0 < 1.$$

LRT 的一个关键性质：在 H_0 下， $-2 \log \Lambda$ 渐近服从 χ^2 分布，自由度为 $\dim(\Omega) - \dim(\omega)$ (在一定正则条件下)。这使得我们可以近似地确定临界值。

LRT 与 NP 引理的关系：当 $\Omega = \{\theta', \theta''\}$ (只有两点) 时，LRT 还原为 NP 似然比检验，此时它是最优的。但一般来说，LRT 不一定是最优的。

接下来我们把 LRT 应用到几个具体的重要情形——正态均值差和正态方差检验。

3.3. 8.3.1 正态均值差的 LRT.

EXAMPLE 8.6 (两样本 t 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_3)$ ，两组样本独立，共同方差 θ_3 未知。考虑检验：

$$H_0 : \theta_1 = \theta_2 \quad \text{versus} \quad H_1 : \theta_1 \neq \theta_2.$$

构造 LRT: 在 H_0 下 ($\theta_1 = \theta_2 = \mu$)，参数的 MLE 为

$$\hat{\mu} = \frac{n\bar{x} + m\bar{y}}{n + m}, \quad \hat{\sigma}_0^2 = \frac{1}{n + m} \left[\sum_{i=1}^n (x_i - \hat{\mu})^2 + \sum_{i=1}^m (y_i - \hat{\mu})^2 \right].$$

在无约束下 (H_1)，MLE 分别为 $\bar{x}$ 、 $\bar{y}$ 和

$$\hat{\sigma}^2 = \frac{1}{n + m} \left[\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 \right].$$

¹⁰LRT 与 Neyman-Pearson 引理的关系讨论见附录 ??。

似然比为

$$\Lambda = \frac{L(\hat{\omega})}{L(\hat{\Omega})} = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2} \right)^{(n+m)/2}.$$

与 t 统计量的联系：可以证明

$$\Lambda^{2/(n+m)} = \frac{(n+m-2)}{(n+m-2) + T^2},$$

其中

$$T = \sqrt{\frac{nm}{n+m}} \frac{\bar{x} - \bar{y}}{S_p}, \quad S_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{n+m-2}.$$

T 服从自由度为 $n+m-2$ 的 t 分布（在 H_0 下）。由于 $\Lambda \leq \lambda_0 \Leftrightarrow |T| \geq c$, LRT 就是经典的两样本 t 检验。

数值示例：设 $n = 10$, $m = 6$, $\alpha = 0.05$, 则临界值

$$c = t_{0.975}(14) = 2.1448.$$

如果 $|t| \geq 2.1448$, 拒绝 H_0 （认为两个总体均值不相等）。¹¹

功效函数：对于非中心 t 分布，当 $\theta_1 \neq \theta_2$ 时， T 服从非中心 t 分布，非中心参数为

$$\delta = \sqrt{\frac{nm}{n+m}} \frac{\theta_1 - \theta_2}{\sigma}.$$

给定 $\theta_3 = 100$, $n = 20$, $m = 15$, $\alpha = 0.05$, $\Delta = 5 = \theta_1 - \theta_2$, 临界值 $t_{0.975}(33) = 2.0345$, 非中心参数 $\delta_2 = 1.4639$, 功效约为

$$1 - \text{pt}(2.0345, 33, \text{ncp} = 1.4639) + \text{pt}(-2.0345, 33, \text{ncp} = 1.4639) \approx 0.2954.$$

即约 29.5% 的概率检测出均值为 5 的差异。¹²

稳健性注记： t 检验在正态性假设不满足时表现如何？在大样本下，由 Slutsky 定理，即使底层分布非正态，只要方差有限， t 统计量仍然渐近正态——因此 t 检验是渐近正确的。然而，在有限样本且严重非正态（特别是高度偏态）时， t 检验可能失效——实际显著性水平会偏离名义水平。¹³

3.4. 8.3.2 正态方差的 LRT.

EXAMPLE 8.7 (两方差相等的 F 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_4)$, 独立样本，考虑检验：

$$H_0 : \theta_3 = \theta_4 \quad \text{versus} \quad H_1 : \theta_3 \neq \theta_4.$$

可以证明（练习 8.3.11）， LRT 统计量可以化为

$$F = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)}{\sum_{i=1}^m (Y_i - \bar{Y})^2 / (m-1)}.$$

(8.3.2)

¹¹两样本 t 检验的完整推导见附录 ??。

¹²非中心 t 分布的功效计算见附录 ??。

¹³非正态情况下 t 检验的稳健性讨论见附录 ??。

在 H_0 下, $F \sim F(n-1, m-1)$ 。因此双向 LRT 为:

$$\text{Reject } H_0 \quad \text{if} \quad F \leq c_1 \quad \text{or} \quad F \geq c_2,$$

其中 c_1 和 c_2 满足 $P(F \leq c_1) = P(F \geq c_2) = \alpha_1/2$ 。

重要警告: 与 t 检验不同, F 检验对正态性假设是敏感的。在非正态情况下, F 检验的名义水平和实际水平可能相差甚远 (可高达 0.80), 因此不应在正态性未经检验的情况下使用 F 检验。¹⁴

4. 8.4 *Sequential Probability Ratio Test

4.1. 固定样本量检验的局限性. 到目前为止, 我们讨论的所有检验都有一个共同假设: 样本量 n 是预先固定的。但在实际应用中, 固定样本量检验存在一个根本性的低效:

为什么要等到收集完所有 n 个样本才做决策? 为什么不能边收集边决策?

考虑一个质量控制场景: 你需要判断一条生产线是否正常 ($\theta = \theta_0$)。固定样本量方法要求你先收集 n 个样本, 然后做决策。但如果在第 5 个样本时, 数据就已经极其强烈地支持 H_1 (生产线已严重偏离正常状态), 继续等待其余 $n-5$ 个样本就是在浪费时间和资源。

1930 年代, Abraham Wald 提出了一个革命性的思想: 允许样本量根据数据动态确定——这就是序贯分析 (sequential analysis) 的诞生。

Wald 的序贯概率比检验 (SPRT) 不仅在概念上优雅, 而且在功效和样本量之间实现了最优权衡。

4.2. SPRT 的构造. 设 $X_1, X_2, \dots$ 是 iid 随机变量序列, 考虑检验:

$$H_0: \theta = \theta' \quad \text{versus} \quad H_1: \theta = \theta'',$$

其中 θ' 和 θ'' 是给定的具体值。

核心思想: 在每个步骤 n , 计算似然比

$$\Lambda_n = \frac{L(\theta'; x_1, \dots, x_n)}{L(\theta''; x_1, \dots, x_n)} = \prod_{i=1}^n \frac{f(x_i; \theta')}{f(x_i; \theta'')}.$$

如果 Λ_n 非常小 (即数据强烈支持 H_1), 我们就提前停止并拒绝 H_0 ; 如果 Λ_n 非常大 (即数据强烈支持 H_0), 我们就提前停止并接受 H_0 ; 如果 Λ_n 处于中间位置, 我们就继续观察下一个样本。

具体地, 选取两个常数 $A < B$ (通常 $A = \beta/(1-\alpha)$, $B = (1-\beta)/\alpha$), SPRT 的决策规则为:

¹⁴方差 F 检验的稳健性问题见附录 ??。

$$(8.4.1) \quad \text{在第 } n \text{ 步, 停止采样并: } \begin{cases} \text{拒绝 } H_0 \text{ (接受 } H_1) & \text{if } \Lambda_n \leq A, \\ \text{接受 } H_0 \text{ (拒绝 } H_1) & \text{if } \Lambda_n \geq B, \\ \text{继续采样} & \text{if } A < \Lambda_n < B. \end{cases}$$

Wald 的关键近似: 在实际应用中, Wald 证明了可以通过近似 $A \approx \beta/\alpha$ 和 $B \approx (1-\beta)/(1-\alpha)$ 来设置常数, 其中 α 和 β 分别是目标第一类和第二类错误概率。

EXAMPLE 8.8 (Bernoulli 的 SPRT). 设 $X_i \sim \text{Bernoulli}(\theta)$, 检验 $H_0: \theta = 1/3$ 对 $H_1: \theta = 2/3$ 。

似然比为

$$\Lambda_n = \frac{(1/3)^{\sum x_i} (2/3)^{n-\sum x_i}}{(2/3)^{\sum x_i} (1/3)^{n-\sum x_i}} = 2^{n-2\sum x_i}.$$

取对数并整理, 不等式 $A < \Lambda_n < B$ 等价于

$$c_0(n) = \frac{n}{2} - \frac{\log_2 B}{2} < \sum_{i=1}^n x_i < \frac{n}{2} - \frac{\log_2 A}{2} = c_1(n).$$

决策规则: 当 $\sum x_i \geq c_1(n)$ 时, 拒绝 H_0 ; 当 $\sum x_i \leq c_0(n)$ 时, 接受 H_0 ; 否则继续采样。

序贯抽样的图示: 想象一条随机游走——每观察一次 $X_i = 1$, 我们就向右跳 1 个单位; 每观察一次 $X_i = 0$, 我们就向左跳 1 个单位。只要这条路径处于上下边界之间, 我们就继续。一旦路径碰到上界 (强烈支持 H_1) 或下界 (强烈支持 H_0), 我们就停止并做出相应决策。¹⁵

EXAMPLE 8.9 (正态均值的 SPRT). 设 $X_1, X_2, \dots \sim N(\theta, 100)$, 检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$, 目标是使 $\alpha \approx \beta \approx 0.10$ 。

取 $A = 1/9$ 、 $B = 9$ 。似然比为

$$\Lambda_n = \exp\left(-\frac{6\sum x_i - 459n}{200}\right).$$

不等式 $A < \Lambda_n < B$ 化为

$$c_0(n) = \frac{153}{2}n - \frac{100}{3}\log 9 < \sum_{i=1}^n x_i < \frac{153}{2}n + \frac{100}{3}\log 9 = c_1(n).$$

决策规则: 在第 n 步, 当 $\sum x_i \geq c_1(n)$ 时拒绝 H_0 (认为 $\theta = 78$); 当 $\sum x_i \leq c_0(n)$ 时接受 H_0 (认为 $\theta = 75$); 否则继续采样。¹⁶

¹⁵Bernoulli SPRT 的详细分析见附录 ??。

¹⁶正态 SPRT 的完整推导见附录 ??。

SPRT 的吸引力：为什么 SPRT 如此重要？因为它在固定两类错误概率的同时，通常使用比固定样本量检验更少的样本。Wald 的近似理论表明，当 H_0 或 H_1 为真时，SPRT 的平均样本量（Average Sample Number, ASN）比相应的固定样本量检验小得多——有时能节省 50% 以上的样本。

SPRT 与质量控制：SPRT 的思想在工业质量控制中有广泛应用。CUSUM（累积和）控制图就是 SPRT 的一个变体——它持续累积标准化后的偏离量 $\sum(Z_i - 0.5)$ （其中 Z_i 是标准化后的检验统计量），一旦超出控制限就发出警报。与固定间隔的 Shewhart 控制图相比，CUSUM 能更快检测到过程均值的微小漂移。

5. 8.5 *Minimax and Classification Procedures

5.1. 8.5.1 极小化极大检验。在第 7 章的决策论框架中，我们介绍了极小化极大（minimax）原则：将最大风险最小化。将这个思想应用到假设检验中，会得到一个有趣的结论——Neyman-Pearson 最佳检验在某种意义上也是极小化极大的。

考虑简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ ，损失函数满足 $\mathcal{L}(\theta', \theta') = \mathcal{L}(\theta'', \theta'') = 0$ （正确决策无损失），而 $\mathcal{L}(\theta', \theta'') > 0$ 和 $\mathcal{L}(\theta'', \theta') > 0$ （错误决策有损失）。¹⁷

此时风险函数为：

$$R(\theta', C) = \mathcal{L}(\theta', \theta'') \cdot \alpha, \quad R(\theta'', C) = \mathcal{L}(\theta'', \theta') \cdot \beta,$$

其中 α 是显著性水平， β 是 Type II 错误概率。

极小化极大原则要求选择 C 使得 $\max\{R(\theta', C), R(\theta'', C)\}$ 最小。可以证明，当 k 满足

$$\mathcal{L}(\theta', \theta'') \int_C L(\theta') = \mathcal{L}(\theta'', \theta') \int_{C^c} L(\theta'')$$

时（即两类错误造成的风险相等），临界区域 C 是极小化极大的。这个条件与 NP 似然比条件是一致的——本质上，最佳检验同时也是极小化极大检验（当两类错误的相对代价被适当选择时）。¹⁸

EXAMPLE 8.10（正态均值的极小化极大检验）。设 $X_1, \dots, X_{100} \sim N(\theta, 100)$ ，检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$ ，损失为 $\mathcal{L}(75, 78) = 3$ 、 $\mathcal{L}(78, 75) = 1$ 。

临界区域形如 $\bar{x} \geq c$ ，其中 c 满足：

$$3 \cdot P_{\theta=75}(\bar{X} \geq c) = P_{\theta=78}(\bar{X} < c).$$

¹⁷极小化极大检验的决策论框架见附录 ??。

¹⁸极小化极大检验的完整证明见附录 ??。

由于 $\bar{X} \sim N(\theta, 1)$ ，这化为

$$3[1 - \Phi(c - 75)] = \Phi(c - 78).$$

求解得 $c \approx 76.8$ 。此时显著性水平 $\alpha = 1 - \Phi(1.8) \approx 0.036$ ，功效为 $1 - \Phi(-1.2) \approx 0.885$ 。¹⁹

5.2. 8.5.2 分类问题. 极小化极大检验理论在分类 (classification) 问题中有直接应用。考虑一个二分类问题：我们观察到 (X, Y) ，需要判断它来自分布 $f(x, y; \theta')$ 还是 $f(x, y; \theta'')$ 。

这本质上就是假设检验问题——如果接受 H_0 ，就把 (X, Y) 分类为来自 θ' 类；如果拒绝 H_0 ，就分类为来自 θ'' 类。

由 NP 定理，最佳分类规则是似然比规则：

$$\frac{f(x, y; \theta')}{f(x, y; \theta'')} \leq k \implies \text{分类为 } \theta'' \text{ 类}.$$

若两类的先验概率为 π' 和 π'' ，则最优规则取 $k = \pi''/\pi'$ （当两类等可能时 $k = 1$ ）。

Fisher 线性判别函数：在正态分布的特殊情况下，似然比不等式化为一个线性函数 $ax + by \leq c$ ——这就是著名的 Fisher 线性判别函数。当参数未知时，用训练样本的均值和方差代替，就得到了 Fisher 判别函数。²⁰

[二元正态的线性判别] 设 (X, Y) 来自二元正态分布，参数为 $(\mu'_1, \mu'_2, \sigma_1^2, \sigma_2^2, \rho')$ 或 $(\mu''_1, \mu''_2, \sigma_1^2, \sigma_2^2, \rho'')$ 。则似然比不等式化为

$$ax + by \leq c,$$

其中 a 和 b 是由两个总体的均值向量和协方差矩阵决定的常数。这给出了一个**线性决策边界**——在二维空间中是一条直线，将平面分为两部分，分别对应两类。²¹

附录：公式推导

本附录包含 Chapter 8 中省略的完整推导。

¹⁹极小化极大检验的数值求解 (Newton 法) 见附录 ??。

²⁰Fisher 线性判别函数的完整推导见附录 ??。

²¹二元正态线性判别的详细推导见附录 ??。

5.3. Neyman-Pearson 引理的证明. 背景 (Background): 我们需要证明, 当临界区域 C 满足 NP 条件 (a) -(c) 时, 它是在固定显著性水平 α 下功效最高的检验。

已知条件 (Given):

- $L(\theta'; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta')$ 是 H_0 下的似然函数
- $L(\theta''; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta'')$ 是 H_1 下的似然函数
- 临界区域 C 满足:

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k, \quad \forall \mathbf{x} \in C; \quad \frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k, \quad \forall \mathbf{x} \in C^c.$$

- 任意其他满足 $P_{\theta'}[\mathbf{X} \in A] = \alpha$ 的区域 A 。

目标 (Goal): 证明 $P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A]$ 。

推导步骤 (Derivation Steps):

1. 写出功效差:

$$\int_C L(\theta'') - \int_A L(\theta'') = \int_{C \cap A^c} L(\theta'') - \int_{A \cap C^c} L(\theta'').$$

2. 由条件 (a): 在 C 上 $L(\theta'') \geq \frac{1}{k} L(\theta')$, 故

$$\int_{C \cap A^c} L(\theta'') \geq \frac{1}{k} \int_{C \cap A^c} L(\theta').$$

3. 由条件 (b): 在 C^c 上 $L(\theta'') \leq \frac{1}{k} L(\theta')$, 故

$$\int_{A \cap C^c} L(\theta'') \leq \frac{1}{k} \int_{A \cap C^c} L(\theta').$$

4. 将 (8.A.2) 和 (8.A.3) 代入 (8.A.1):

$$\int_C L(\theta'') - \int_A L(\theta'') \geq \frac{1}{k} \left[\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') \right].$$

5. 计算括号内项:

$$\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') = \int_C L(\theta') - \int_A L(\theta') = \alpha - \alpha = 0.$$

6. 由 (8.A.4) 和 (8.A.5) 得 $\int_C L(\theta'') - \int_A L(\theta'') \geq 0$, 即

$$P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A].$$

证毕。

5.4. 正态均值 NP 检验的完整推导. 背景 (Background): 在例 8.1.2 中, 我们构造了正态均值差假设的 NP 检验。本节补充完整推导。

目标 (Goal): 对 $X_1, \dots, X_n \sim N(\theta, 1)$, 检验 $H_0: \theta = 0$ 对 $H_1: \theta = 1$, 求大小为 α 的最佳检验。

推导步骤 (Derivation Steps):

1. 写出似然函数:

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

2. 似然比:

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \frac{\exp \left[-\frac{1}{2} \sum x_i^2 \right]}{\exp \left[-\frac{1}{2} \sum (x_i - 1)^2 \right]} = \exp \left[-\sum_{i=1}^n x_i + \frac{n}{2} \right].$$

3. 令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$:

$$\exp \left[-\sum x_i + \frac{n}{2} \right] \leq k \iff \sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

4. 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故临界值

$$c_1 = \frac{c}{n} = \frac{1}{2} - \frac{\log k}{n} = q_\alpha(0, 1/\sqrt{n}).$$

5. 功效函数: 当 $\theta = 1$ 时, $\bar{X} \sim N(1, 1/n)$,

$$\text{Power}(\theta = 1) = P_{\theta=1}(\bar{X} \geq q_\alpha(0, 1/\sqrt{n})) = 1 - \Phi \left(\frac{q_\alpha(0, 1/\sqrt{n}) - 1}{1/\sqrt{n}} \right).$$

证毕。

5.5. Karlin-Rubin 定理的证明. 背景 (Background): 证明当似然函数有 MLR 性质时, 单向复合假设存在 UMP 检验。

已知条件 (Given):

- 似然函数 $L(\theta, \mathbf{x})$ 在 $Y = u(\mathbf{x})$ 中有 MLR: 对 $\theta_1 < \theta_2$, $L(\theta_1; \mathbf{x})/L(\theta_2; \mathbf{x}) = g(Y)$, 其中 g 是递减函数。
- 单向假设: $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$ 。

目标 (Goal): 证明检验 $\phi(\mathbf{x}) = 1$ 当 $Y \geq c_Y$, 其中 c_Y 满足 $P_{\theta'}[Y \geq c_Y] = \alpha$, 是 UMP level α 检验。

推导步骤 (Derivation Steps):

1. 对简单假设 $H'_0: \theta = \theta'$ 对 $\theta'' > \theta'$ 的最优性: 由 NP 定理, 最佳临界区域由

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$$

给出。由于 MLR 性质, $g(Y) \leq k \iff Y \geq g^{-1}(k)$ 。取 $c_Y = g^{-1}(k)$, 则对任意 $\theta'' > \theta'$, 临界区域 $C = \{Y \geq c_Y\}$ 是 $H'_0: \theta = \theta'$ 对 θ'' 的最佳检验。

2. 对所有 $\theta'' > \theta'$ 的一致性: 由于 NP 最佳临界区域的形式只依赖于 $Y \geq c_Y$ (而不依赖于具体的 θ''), $C = \{Y \geq c_Y\}$ 对所有 $\theta'' > \theta'$ 都是最佳的。

3. 无偏性 (保证 level 不超过 α): 设 $\gamma_Y(\theta) = P_\theta(Y \geq c_Y)$ 为功效函数。对 $\theta_1 < \theta_2$, 由第 1 步, C 是 θ_1 对 θ_2 的最佳检验, 故 $\gamma_Y(\theta_2) \geq \gamma_Y(\theta_1)$ 。因此 $\gamma_Y(\theta)$ 是 θ 的非降函数, $\max_{\theta \leq \theta'} \gamma_Y(\theta) = \gamma_Y(\theta') = \alpha$ 。故该检验是 level α 的。

综上, $C = \{Y \geq c_Y\}$ 是 UMP level α 检验。证毕。

Exercises

8.1.4 —Best Critical Region for Normal Variance Let $X_1, X_2, \dots, X_{10}$ be a random sample of size 10 from a normal distribution $N(0, \sigma^2)$. Find a best critical region of size $\alpha = 0.05$ for testing $H_0: \sigma^2 = 1$ against $H_1: \sigma^2 = 2$. Is this a best critical region of size 0.05 for testing $H_0: \sigma^2 = 1$ against $H_1: \sigma^2 = 4$? Against $H_1: \sigma^2 = \sigma_1^2 > 1$?

8.2.7 —UMP Test for Normal Mean Let $X_1, X_2, \dots, X_{25}$ denote a random sample of size 25 from a normal distribution $N(\theta, 100)$. Find a uniformly most powerful critical region of size $\alpha = 0.10$ for testing $H_0: \theta = 75$ against $H_1: \theta > 75$.

8.2.11 —MLR and UMP Test for Beta Distribution Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere, where $\theta > 0$. Show the likelihood has MLR in the statistic $\prod_{i=1}^n X_i$. Use this to determine the UMP test for $H_0: \theta = \theta'$ against $H_1: \theta < \theta'$, for fixed $\theta' > 0$.

8.3.8 —LRT for Normal Mean (Two-Sided) Let $X_1, X_2, \dots, X_n$ be a random sample from the normal distribution $N(\theta, 1)$. Show that the likelihood ratio principle for testing $H_0: \theta = \theta'$, where θ' is specified, against $H_1: \theta \neq \theta'$ leads to the inequality $|\bar{x} - \theta'| \geq c$.

8.3.11 —LRT for Two Normal Variances Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ be independent random samples from the distributions $N(\theta_1, \theta_3)$ and $N(\theta_2, \theta_4)$, respectively. Show that the LRT for testing $H_0 : \theta_3 = \theta_4$ against $H_1 : \theta_3 \neq \theta_4$ leads to the F -test statistic

$$F = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 / (n - 1)}{\sum_{i=1}^m (Y_i - \bar{Y})^2 / (m - 1)}.$$

Under H_0 , $F \sim F(n - 1, m - 1)$.

8.4.2 —SPRT for Poisson Distribution Let X have a Poisson distribution with mean θ . Find the sequential probability ratio test for testing $H_0 : \theta = 0.02$ against $H_1 : \theta = 0.07$. Show that this test can be based upon the statistic $\sum_{i=1}^n X_i$. If $\alpha_a = 0.20$ and $\beta_a = 0.10$, find $c_0(n)$ and $c_1(n)$.

CHAPTER 9

ANOVA and Regression

Chapter 9 Overview

在前几章中，我们讨论了来自单个总体的样本推断，以及两个总体的比较。但实际中，我们常常面临更复杂的问题：

如果有三个、四个甚至更多个总体，我们该如何比较它们的均值？

这个问题——即**多组比较问题**——在农业实验、医学试验、工业质量控制等领域无处不在。例如，在一项评估不同肥料对作物产量影响的实验中，我们需要同时比较多个处理组；而在研究药物疗效时，我们可能需要同时评估多种药物的效果。

本章，我们从单样本 t 检验 $\rightarrow$ 两样本 t 检验 $\rightarrow$ 多组比较的自然推广，引入**方差分析 (Analysis of Variance, 简称 ANOVA)**。这一方法由 Ronald Fisher 在 1920 年代创立，起源于他在英国洛桑农业实验站的农业实验研究。Fisher 的核心思想是：将总变异分解为可解释的变异和随机误差，通过比较两者来判断处理效应是否显著。

本章路线图：

- (1) One-Way ANOVA $\rightarrow$ 组间/组内平方和分解 $\rightarrow F$ 检验
- (2) 非中心 χ^2 和 F 分布 $\rightarrow$ 备择假设下的分布
- (3) Multiple Comparisons $\rightarrow$ Tukey 法、Bonferroni 法（控制族误差率）
- (4) Two-Way ANOVA $\rightarrow$ 主效应、交互效应
- (5) 回归问题 $\rightarrow$ 最小二乘估计、几何解释（投影）
- (6) 二次型分布 $\rightarrow$ Cochran 定理——平方和分解的理论基础

1. 9.1 Introduction

在正式进入 ANOVA 之前，我们需要介绍一个重要的数学工具——**二次型 (quadratic form)**。

DEFINITION 9.1 (二次型). 设 $X_1, \dots, X_n$ 是 n 个变量， a_{ij} 是常数。形如

$$q(X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^n X_i a_{ij} X_j$$

的表达式称为 $X_1, \dots, X_n$ 的（二次）二次型。

为什么二次型重要？ 在统计推断中，许多关键的统计量都可以表示为二次型。例如，样本方差

$$(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

就是关于样本 $X_1, \dots, X_n$ 的一个二次型。理解二次型的分布性质, 是理解 ANOVA 和回归分析的理论基础。

2. 9.2 One-Way ANOVA

2.1. 问题的引入. 考虑 b 个独立的正态总体, 第 j 个总体的均值为 μ_j , 共同方差为 σ^2 。从第 j 个总体中抽取容量为 n_j 的随机样本 $X_{1j}, X_{2j}, \dots, X_{n_jj}$ 。记总样本量为 $n = \sum_{j=1}^b n_j$ 。

模型为:

$$X_{ij} = \mu_j + e_{ij}, \quad i = 1, \dots, n_j, \quad j = 1, \dots, b, \quad (9.2.1)$$

其中 e_{ij} 是 iid $N(0, \sigma^2)$ 随机误差。

我们想检验: 所有 b 个总体的均值是否相等——

$$H_0: \mu_1 = \mu_2 = \dots = \mu_b \quad \text{vs} \quad H_1: \mu_j \neq \mu_{j'} \text{ 对某些 } j \neq j'. \quad (9.2.2)$$

实际背景: 例如, b 种药物对某种疾病的疗效比较; 或 b 种肥料对作物产量的影响。这里”一种因素 (factor)” 处于 b 个”水平 (level)”, 因此称为**单因素实验 (one-way layout)**。

2.2. 似然比检验的推导. 完全模型 (full model) 参数空间:

$$\Omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : -\infty < \mu_j < \infty, \quad 0 < \sigma^2 < \infty\}.$$

约束模型 (reduced model) 参数空间 (H_0 下):

$$\omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : \mu_1 = \dots = \mu_b = \mu, \quad 0 < \sigma^2 < \infty\}.$$

完全模型下的 MLE:

$$\hat{\mu}_j = \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\Omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2. \quad (9.2.7)$$

约束模型下的 MLE (此时等价于单样本问题):

$$\hat{\mu}_\omega = \bar{X}_{\cdot\cdot} = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.3)$$

似然比统计量简化后的形式为:

$$\Lambda^{n/2} = \frac{\hat{\sigma}_\Omega^2}{\hat{\sigma}_\omega^2}. \quad (9.2.9)$$

拒绝 H_0 等价于 F 统计量过大, 其中

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)}, \quad (9.2.11)$$

而

$$Q_3 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2, \quad Q_4 = \sum_{j=1}^b n_j (\bar{X}_{\cdot j} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.10)$$

核心分解:

$$\underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2}_Q = \underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}_{Q_3(\text{组内})} + \underbrace{\sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2}_{Q_4(\text{组间})}. \quad (9.2.10)$$

在 H_0 下, $Q_3/\sigma^2 \sim \chi^2(n-b)$, $Q_4/\sigma^2 \sim \chi^2(b-1)$, 且二者独立。因此 $F \sim F(b-1, n-b)$ 。

2.3. ANOVA 表格. 单因素 ANOVA 的结果可以汇总为一张清晰的表格:

表 1. 单因素 ANOVA 表格

来源	平方和 (SS)	df	均方 (MS)	F 统计量	p 值
组间 (Between)	Q_4	$b-1$	$MSB = Q_4/(b-1)$	$\frac{MSB}{MSW}$	$\mathbb{P}(F > F_0)$
组内 (Within)	Q_3	$n-b$	$MSW = Q_3/(n-b)$		
总计 (Total)	Q	$n-1$			

EXAMPLE 9.1 (合金弹性模量). Devore (2012, 第 412 页) 报告了一项数据: 三种铸造工艺 (永久模具、压铸、石膏模具) 生产合金的弹性模量。三种工艺各有多次测量, 我们想知道铸造工艺是否显著影响弹性模量。

数据汇总后, $F = 12.565$, 自由度为 2 和 19, p 值为 0.0003。如此小的 p 值表明: 铸造工艺对弹性模量有显著影响。

footnote 该例子的详细计算与 R 代码实现见附录 ??。

3. 9.3 Noncentral χ^2 and F Distributions

3.1. 为什么需要非中心分布? 在前一节的 ANOVA 中, 我们在原假设 H_0 下推导了 F 统计量的分布。但在实际应用中, 我们更关心: 当 H_0 不成立 (即各组均值不全相等) 时, F 统计量的分布是什么? 这时就需要引入**非中心 χ^2 分布**和**非中心 F 分布**。

DEFINITION 9.2 (非中心 χ^2 分布). 设 $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, \dots, n$, 独立。则

$$Y = \sum_{i=1}^n \frac{X_i^2}{\sigma^2}$$

的 *mgf* 为

$$M(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}, \quad t < \frac{1}{2}. \quad (9.3.1)$$

此时称 $Y \sim \chi^2(r, \theta)$, 其中 $r = n$ 是自由度, $\theta = \sum_{i=1}^n \mu_i^2 / \sigma^2$ 是**非中心参数 (noncentrality parameter)**。

直观理解: 当所有 $\mu_i = 0$ 时, $\theta = 0$, 回到中心 χ^2 分布; 当某些 $\mu_i \neq 0$ 时, Y 的分布在中心 χ^2 的基础上向右偏移, θ 越大, 偏移越明显。

非中心 χ^2 分布的均值: $E(Y) = r + \theta$ (中心部分 r 加上非中心部分 θ)。

DEFINITION 9.3 (非中心 F 分布). 设 $U \sim \chi^2(r_1, \theta)$, $V \sim \chi^2(r_2)$, 独立。则

$$F = \frac{r_2 U}{r_1 V}$$

服从自由度为 r_1, r_2 、非中心参数为 θ 的非中心 F 分布, 记作 $F(r_1, r_2, \theta)$ 。

EXAMPLE 9.2 (One-Way ANOVA 的非中心参数). 对于 *one-way ANOVA* 模型 (9.2.1), 在备择假设 H_1 下, F 统计量的分子 $Q_4/\sigma^2 \sim \chi^2(b-1, \theta)$, 其中

$$\theta = \frac{1}{\sigma^2} \sum_{j=1}^b n_j (\mu_j - \bar{\mu})^2, \quad \bar{\mu} = \frac{1}{n} \sum_{j=1}^b n_j \mu_j. \quad (9.3.5)$$

当 H_0 成立时, $\theta = 0$, 回到中心 F 分布; 当 H_1 成立时, $\theta > 0$, F 分布向右偏移, 偏移程度由 θ 刻画。这解释了为什么 F 检验在 H_0 不成立时倾向于取更大的值。¹

4. 9.4 Multiple Comparisons

当 *one-way ANOVA* 的 F 检验拒绝了 H_0 后, 我们自然想知道: 具体哪些组之间存在显著差异? 这就是多重比较问题 (Multiple Comparison Problem, MCP)。

4.1. 问题的核心矛盾. 对 b 个总体, 若进行所有 $\binom{b}{2}$ 个成对比较, 即使每个置信区间的置信水平为 95%, 整体的置信水平也会急剧下降。举例来说, 若 $b = 5$, 则共有 10 个成对比较, 每个比较犯错的概率为 5%, 至少有一次犯错的概率粗略估计为 $1 - (0.95)^{10} \approx 40\%$ 。

因此, 我们需要专门设计的方法来**控制族误差率 (Family-Wise Error Rate, FWER)**——即在所有比较中至少有一次犯错的概率。

4.2. Bonferroni 方法. Bonferroni 方法基于一个简单的不等式: 对 k 个参数 θ_i , 若每个区间 I_i 的置信水平为 $1 - \alpha$, 则

$$P(\text{所有 } \theta_i \in I_i) \geq 1 - k\alpha. \quad (9.4.2)$$

核心思想: 将每个区间的置信水平从 $1 - \alpha$ 调整为 $1 - \alpha/k$, 则整体的置信水平至少为 $1 - \alpha$ 。

对 *one-way ANOVA*, 成对差值 $\mu_j - \mu_{j'}$ 的 Bonferroni 置信区间为:

$$\bar{X}_{\cdot j} - \bar{X}_{\cdot j'} \pm t_{\alpha/(2k), n-b} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.3)$$

优点: 通用性强, 适用于任何成对比较。**缺点:** 比较数量 k 越大, 区间越宽, 精度损失越大。

¹非中心 F 分布的完整推导见附录 ??。

4.3. Tukey 方法. Tukey 方法利用学生化极差分布 (Studentized range distribution), 专为 balanced 设计的成对比较设计。

当所有组样本容量相等 ($n_j = a, j = 1, \dots, b$) 时, 所有成对比较的同时置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm q_{1-\alpha, b, n-b} \frac{\hat{\sigma}_{\Omega}}{\sqrt{a}}, \quad \forall j \neq j'. \quad (9.4.4)$$

其中 $q_{1-\alpha, b, n-b}$ 是自由度为 b 和 $n-b$ 的学生化极差分布分位数。

对于 unbalanced 情形, 使用 Tukey-Kramer 修正:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm \frac{q_{1-\alpha, b, n-b}}{\sqrt{2}} \hat{\sigma}_{\Omega} \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.5)$$

EXAMPLE 9.3 (赛车速度比较). *Kitchens (1997)* 报告了一项实验: 比较五种汽车 (*Acura, Ferrari, Lotus, Porsche, Viper*) 的最高速度。每种车进行 6 次运行测试。整体 F 检验高度显著 ($F = 25.15, p \approx 0$)。Tukey 多重比较结果表明: *Ferrari* 和 *Porsche* 的平均速度显著快于其他三种车, 但 *Ferrari* 与 *Porsche* 之间速度差异不显著。²

4.4. Fisher 的保护 LSD 方法. Fisher 方法是一个两步程序:

- (1) 首先进行整体 F 检验; 若拒绝 H_0 ,
- (2) 再使用标准的成对 t 置信区间 (置信水平 $1 - \alpha$)。

Fisher 方法不保证整体覆盖率为 $1 - \alpha$, 但 F 检验提供了”保护”。模拟研究表明它在功效和实际误差率方面表现良好。

5. 9.5 Two-Way ANOVA

5.1. 双因素实验的引入. 在实际研究中, 我们常常需要同时考虑两个因素对结果的影响。例如:

- 作物产量: 同时受品种 (因素 A) 和肥料类型 (因素 B) 的影响
- 考试成绩: 同时受教学方法 (因素 A) 和班级规模 (因素 B) 的影响

这就是双因素方差分析 (two-way ANOVA)。

设因素 A 有 a 个水平, 因素 B 有 b 个水平, 每个组合有一个观测值 X_{ij} 。模型为:

$$X_{ij} = \mu + \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b, \quad (9.5.2)$$

其中 $e_{ij} \sim N(0, \sigma^2)$ iid, 且 $\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0$ 。

可加模型 (additive model) 意味着两个因素的影响是相互独立的——因素 A 的效应不随因素 B 的水平变化。

表 2. 双因素可加模型的单元格均值示例 ($a = 2, b = 3$)

	B=1	B=2	B=3
A=1	7	6	5
A=2	5	4	3

²该例子的 R 实现与详细结果分析见附录 ??。

在可加模型中，行均值轮廓线是**平行的**——这是可加模型的重要特征。

5.2. 假设检验. 我们需要检验两个主效应假设：

$$H_{0A} : \alpha_1 = \cdots = \alpha_a = 0 \quad \text{vs} \quad H_{1A} : \text{某些 } \alpha_i \neq 0, \quad (9.5.3)$$

$$H_{0B} : \beta_1 = \cdots = \beta_b = 0 \quad \text{vs} \quad H_{1B} : \text{某些 } \beta_j \neq 0. \quad (9.5.4)$$

检验 H_{0B} 的 F 统计量：

$$F_B = \frac{a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 / (b-1)}{\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2 / [(a-1)(b-1)]}. \quad (9.5.12)$$

在 H_{0B} 下， $F_B \sim F(b-1, (a-1)(b-1))$ 。

类似地，检验 H_{0A} 的 F 统计量 $F_A \sim F(a-1, (a-1)(b-1))$ 。

5.3. 9.5.1 Interaction between Factors. 交互效应发生在：一个因素的影响程度取决于另一个因素的水平时。

在模型中引入交互参数 γ_{ij} ：

$$\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij}, \quad (9.5.15)$$

其中 $\sum_i \gamma_{ij} = \sum_j \gamma_{ij} = 0$ 。

若所有 $\gamma_{ij} = 0$ ，则回到可加模型；若存在非零 γ_{ij} ，则两个因素之间存在**交互作用**。

图形诊断：在双因素实验中，绘制各行（因素 A 各水平）的均值轮廓线。若线条大致平行，则交互作用不明显；若线条明显交叉或分离，则表明存在交互效应。

EXAMPLE 9.4 (沥青混合料热导率). Devore (2012, 第 435 页) 研究了两个因素对沥青混合料热导率的影响：粘结剂等级 (PG58, PG64, PG70) 和粗骨料含量 (38%, 41%, 44%)。每个处理组合有 2 次重复。

R 分析结果：交互效应不显著 ($p = 0.4135$)，但两个主效应都非常显著 ($p = 0.0017$ 和 $p < 10^{-5}$)。因此接受可加模型，两个因素独立地影响热导率。³

6. 9.6 A Regression Problem

6.1. 为什么研究回归? ANOVA 研究的是类别型 (categorical) 自变量对因变量的影响。但在许多实际问题中，自变量是连续型的。例如：

- 学生的学习时间 (连续) → 考试成绩
- 汽车的发动机排量 (连续) → 每加仑行驶里程
- 农作物的施肥量 (连续) → 作物产量

这就引出了**回归分析 (regression analysis)**——研究自变量 (通常记作 x) 与因变量 Y 之间关系的方法。

线性模型：假设 $E(Y) = \mu(x)$ 是 x 的线性函数——

$$Y_i = \alpha + \beta(x_i - \bar{x}) + e_i, \quad i = 1, \dots, n, \quad (9.6.1)$$

³该例子的详细 ANOVA 表和 R 代码见附录 ??。

其中 $e_i \sim N(0, \sigma^2)$ iid。

为什么假设 x 是已知的非随机变量？ 这是为了简化分析——我们把不确定性全部放在 Y 上。在实际中，如果 x 也是随机的，则需要联合分布建模；但在受控实验或观测研究中，将 x 视为固定设计点是合理的近似。

线性模型 vs 非线性模型： 这里“线性”指的是对参数 (α, β) 线性，而非对 x 线性。因此 $\alpha + \beta x + \gamma x^2$ 仍是线性模型，而 $\alpha e^{\beta x}$ 不是。

6.2. 9.6.1 Maximum Likelihood Estimates. 对模型 (9.6.1)，似然函数为

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{[Y_i - \alpha - \beta(x_i - \bar{x})]^2}{2\sigma^2} \right\}. \quad (9.6.12)$$

最大化似然等价于最小化

$$H(\alpha, \beta) = \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2. \quad (9.6.3)$$

这正是**最小二乘法 (least squares)**——选择使残差平方和最小的 α, β 。

几何直观： $|Y_i - \alpha - \beta(x_i - \bar{x})|$ 是点 (x_i, Y_i) 到直线 $y = \alpha + \beta(x - \bar{x})$ 的垂直距离。最小二乘法就是找到使所有这些距离平方和最小的直线。

MLE 的解：

$$\hat{\alpha} = \bar{Y}, \quad (9.6.3)$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (9.6.5)$$

$\hat{\sigma}^2$ 的 MLE：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2. \quad (9.6.8)$$

拟合值与残差：

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}(x_i - \bar{x}), \quad \hat{e}_i = Y_i - \hat{Y}_i. \quad (9.6.6)$$

估计量的分布： 可以证明

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{pmatrix} \right). \quad (9.6.9)$$

EXAMPLE 9.5 (男子 1500 米奥运会成绩). 考虑 27 届奥运会男子 1500 米冠军成绩与年份的关系。年份为自变量 x ，时间为因变量 Y 。

R 拟合结果： $\hat{y} = 12.33 - 0.0044 \times year$ 。斜率的 95% 置信区间为 $(-0.00547, -0.00328)$ ——这意味着每年获胜时间平均减少约 0.004 分钟（约 0.24 秒）。对 2020 年奥运会的预测时间约为 3.486 分钟。⁴

残差图诊断： 在回归分析中，绘制残差 $\hat{e}_i$ vs 拟合值 $\hat{Y}_i$ 的散点图。如果图呈现随机散布，说明模型是合理的；如果出现系统模式（如 U 形、漏斗形），则提示模型设定有问题（如遗漏非线性项、异方差等）。

⁴该例子的详细计算、残差图分析和预测区间见附录 ??。

6.3. 9.6.2 *Geometry of the Least Squares Fit. 最小二乘拟合有一个优美的几何解释。

将数据写成向量形式 $\mathbf{Y} = (Y_1, \dots, Y_n)'$, 设计矩阵 $\mathbf{X}$ 的列为 $\mathbf{1}$ 和 $\mathbf{x}_c = (x_1 - \bar{x}, \dots, x_n - \bar{x})'$ 。模型为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}). \quad (9.6.13)$$

设 V 为 $\mathbf{X}$ 列张成的 $\mathbb{R}^n$ 中的二维子空间 (拟合空间)。最小二乘估计 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 正是 $\mathbf{Y}$ 在子空间 V 上的**正交投影**——即使得 $\|\mathbf{Y} - \boldsymbol{\theta}\|^2$ 最小的 V 中元素。

几何分解:

$$\|\mathbf{Y}\|^2 = \|\hat{\boldsymbol{\theta}}\|^2 + \|\hat{\mathbf{e}}\|^2,$$

其中 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 是残差向量, 且 $\hat{\boldsymbol{\theta}} \perp \hat{\mathbf{e}}$ (残差与拟合空间正交)。这正是 ANOVA 中平方和分解的几何版本。

7. 9.7 A Test of Independence

在许多应用中, 我们需要检验两个连续变量 X 和 Y 是否独立。对于二元正态分布, X 和 Y 独立当且仅当它们的相关系数 $\rho = 0$ 。因此我们检验:

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0. \quad (9.7.1)$$

样本相关系数:

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}. \quad (9.7.1)$$

关键定理: 在 H_0 下 (即 $\rho = 0$ 时), R 的分布不依赖于 X 的具体分布——只要 X 与 Y 独立, R 的分布在正态情况下就有上式 (9.3.1) 给出的精确形式。特别是,

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t(n-2). \quad (9.7.3)$$

因此, H_0 的拒绝域为 $|T| \geq t_{\alpha/2, n-2}$, 或等价地 $|R| \geq c$ 。

Remark 的深层含义: R 的条件分布 (在给定 $X_1, \dots, X_n$ 下) 不依赖于 X_i 的具体值, 这意味着 R 与所有仅依赖于 X 的统计量独立。这是一个非常优雅的性质——样本相关系数在 $\rho = 0$ 时”不受” X 取值的影响。

8. 9.8 Distributions of Certain Quadratic Forms

前几节的分析依赖于一个共同的理论支柱: 某些二次型服从 χ^2 分布, 且它们相互独立。本节和下一节建立这一理论的严格基础。

设 $\mathbf{X}' = (X_1, \dots, X_n)$, 其中 $X_i \sim N(\mu_i, \sigma^2)$ iid. 二次型 $Q = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}$ 的 mgf 为:

$$M_Q(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}. \quad (9.8.10)$$

特别地, 若 $\mathbf{A}$ 是对称幂等矩阵 ($\mathbf{A}^2 = \mathbf{A}$), 则 $Q \sim \chi^2(r, \theta)$, 其中 $r = \text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A})$, $\theta = \boldsymbol{\mu}' \mathbf{A} \boldsymbol{\mu} / \sigma^2$ 。若进一步 $\boldsymbol{\mu} = \mu \mathbf{1}$ 且 $\sum_{i,j} a_{ij} = 0$, 则 $\theta = 0$, Q 为中心 $\chi^2(r)$ 。

Cochran 定理的特例: 若 $Q_1, \dots, Q_k$ 是相互独立的 χ^2 变量之和, 且 $\sum \text{rank}(Q_i) = n$, 则各 Q_i 独立。

9. 9.9 The Independence of Certain Quadratic Forms

最后一个理论工具：Craig 定理，给出了两个二次型独立的充要条件。

THEOREM 9.1 (Craig). 设 $\mathbf{X} \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$ 。对对称矩阵 $\mathbf{A}, \mathbf{B}$ ，令

$$Q_1 = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}, \quad Q_2 = \sigma^{-2} \mathbf{X}' \mathbf{B} \mathbf{X}.$$

则 Q_1 与 Q_2 独立当且仅当 $\mathbf{AB} = \mathbf{0}$ 。

这个定理在 ANOVA 中有重要应用：在 one-way ANOVA 中，组间平方和 Q_4 （对应某个幂等矩阵）与组内平方和 Q_3 （对应另一个幂等矩阵）满足 $\mathbf{AB} = \mathbf{0}$ ，因此独立——这正是 F 检验的理论基础。

推论：在回归模型中，拟合值的二次型与残差的二次型相互独立，反映了“被解释的变异”与“未被解释的变异”之间的正交性。

习题

9.2.3 —One-Way ANOVA 数据计算 考虑来自三个正态分布的独立随机样本，它们具有相等方差及 respective means μ_1, μ_2, μ_3 。数据如下：

I	II	III
0.5	2.1	3.0
1.3	3.3	5.1
-1.0	0.0	1.9
1.8	2.3	2.4
	2.5	4.2
		4.1

使用 R 或其他统计软件，计算用于检验 $H_0: \mu_1 = \mu_2 = \mu_3$ 的 F 统计量。

9.2.7 —One-Way ANOVA 假设检验 设 μ_1, μ_2, μ_3 分别为三个正态分布的均值，它们具有公共未知方差 σ^2 。为在显著性水平 $\alpha = 0.05$ 下检验假设 $H_0: \mu_1 = \mu_2 = \mu_3$ 对所有可能备择假设，从每个分布中抽取容量为 4 的独立随机样本。若观测值分别为：

$$X_1: \quad 5 \quad 9 \quad 6 \quad 8$$

$$X_2: \quad 11 \quad 13 \quad 10 \quad 12$$

$$X_3: \quad 10 \quad 6 \quad 9 \quad 9$$

判断是否拒绝 H_0 。

9.2.8 —柴油燃料品牌 mpg 比较 一位柴油汽车司机根据 mpg 测试三种柴油燃料的质量。使用以下数据检验三个均值相等的原假设。做通常的假设并取 $\alpha = 0.05$ 。

Brand A: 38.7 39.2 40.1 38.9

Brand B: 41.9 42.3 41.3

Brand C: 40.8 41.2 39.5 38.9 40.3

9.3.2 —非中心 χ^2 分布的方差 计算服从非中心 $\chi^2(r, \theta)$ 分布的随机变量的方差。

9.3.4 —非中心 T 与非中心 F 的关系 证明非中心 T 随机变量的平方是非中心 F 随机变量。

9.4.1 —Bonferroni 多重比较程序 对于练习 9.2.8 中讨论的研究, 使用 $\alpha = 0.10$ 获取 Bonferroni 多重比较程序的结果。基于此程序, 哪个品牌的燃料 (如果有的话) 显著最好?

9.4.2 —Tukey-Kramer 程序 对于练习 9.2.6 中讨论的研究, 计算 Tukey-Kramer 程序。是否存在显著差异?

9.5.1 —两因素交互效应 考虑一个双因素实验, 其中因素 A 有 2 个水平, 因素 B 有 3 个水平。设 $\mu = 5$, $\alpha_1 = 1$, $\alpha_2 = -1$, $\beta_1 = 1$, $\beta_2 = 0$, $\beta_3 = -1$ 。回答以下问题:

(a) 写出单元格均值 μ_{ij} 的表格。

(b) 绘制均值轮廓图 (mean profile plot)。

(c) 若交互效应存在, 轮廓图会有什么特征?

9.6.4 —回归估计量的协方差 证明 $\hat{\alpha}$ 与 $\hat{\beta}$ 之间的协方差为零。

提示: 利用 (9.6.5) 中 $\hat{\beta}$ 的表达式, 以及 $\sum_{i=1}^n (x_i - \bar{x}) = 0$ 的性质。

9.6.5 —回归参数的置信区间 在模型 (9.6.1) 下, 求参数 α 和 β 的 $(1 - \alpha)100\%$ 置信区间。

9.6.9 —回归平方和分解 证明以下等式成立:

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

提示: 这本质上是将总平方和分解为拟合平方和与残差平方和。

9.6.14 —简单最小二乘拟合 使用最小二乘法拟合 $y = a + x$ 到以下数据:

x	0	1
y	1	3

附录: 公式推导

One-Way ANOVA 平方和恒等式的证明. 背景: 在 one-way ANOVA 中, 总平方和 Q 可以分解为组内平方和 Q_3 与组间平方和 Q_4 之和。这一恒等式是 F 检验的基石。

目标: 证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2.$$

推导: 记 $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和：

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零，因为对每个固定的 j ，

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。 $\square$

One-Way ANOVA 检验统计量的分布. 背景：推导 one-way ANOVA 中 F 统计量在原假设下的分布。

目标： 证明在 H_0 下， $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导：

步骤 1： Q_3 的分布。 对每个固定的 j ，由样本方差性质， $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立，故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2 \left(\sum_{j=1}^b (n_j - 1) \right) = \chi^2(n-b).$$

步骤 2： Q_4 与 Q_3 的独立性。 注意 $\bar{X}_{.j}$ 与 Q_3 独立（由正态样本的性质），且 $\bar{X}_{..}$ 是 $\bar{X}_{.1}, \dots, \bar{X}_{.b}$ 的线性组合，因此 $\bar{X}_{..}$ 也与 Q_3 独立。故 Q_4 （ $\bar{X}_{.j}$ 的函数）与 Q_3 独立。

步骤 3： Q_4 的分布。 在 H_0 下， $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$ ，故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各 $\bar{X}_{.j}$ 通过 $\bar{X}_{..}$ 而不独立。直接计算知 $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

步骤 4： F 分布。 由步骤 1、2、3 及 F 分布定义，

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b). \quad (\text{A9.3})$$

$\square$

非中心 χ^2 分布的均值和方差. 背景：验证非中心 χ^2 分布的基本性质。

已知： $Y \sim \chi^2(r, \theta)$ ，mgf 为 $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。

目标： 求 $E(Y)$ 和 $\text{var}(Y)$ 。

推导：

由 mgf， $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。对 $M(t)$ 求导：

$$M'(t) = \left[r(1-2t)^{-r/2-1} + \frac{r\theta}{(1-2t)^{r/2+1}} \right] \exp \left\{ \frac{t\theta}{1-2t} \right\}.$$

故 $E(Y) = M'(0) = r + \theta$ 。

对 $M''(t)$ 在 $t=0$ 求值，可得 $\text{var}(Y) = 2(r + 2\theta)$ 。⁵

⁵该推导的详细计算见附录 ??。

最小二乘估计的几何解释. 背景: 回归最小二乘估计的正交投影几何。

目标: 证明 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是 $\mathbf{Y}$ 在 $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$ 上的正交投影。

推导: 由正交投影的定义, $\hat{\boldsymbol{\theta}}$ 满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}_c$ 都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0. \quad (\text{A9.4})$$

由 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 得 $\sum_i \hat{e}_i = 0$ (残差之和为零)。

由 $\mathbf{x}_c'\hat{\mathbf{e}} = 0$ 并利用正规方程, 可解出 $\hat{\alpha}$ 和 $\hat{\beta}$ 的表达式与 (9.6.3)、(9.6.5) 一致。故 $\hat{\boldsymbol{\theta}}$ 确为正交投影。 $\square$

附录：公式推导

0.1. Gamma 分布的矩母函数推导. 背景 (Background)： 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions)：

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given)：

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal)： 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps)：

1. 根据矩母函数定义：

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换：令 $y = \frac{x(1-\beta t)}{\beta}$ ，则 $x = \frac{\beta y}{1-\beta t}$ ， $dx = \frac{\beta}{1-\beta t} dy$ 。

3. 代入积分（要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$ ）：

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1 - \beta t)^{-\alpha}. \end{aligned}$$

结论： 因此， $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ ，定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background)： 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$ ，方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given)：

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

0.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证: 边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$, 确实是合法的 pdf。

结论: 条件 pdf 公式得证。■

0.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发:

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望 (即关于 X_1 求平均):

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论: 全期望公式得证。■

0.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论: 条件均值的方差不超过原变量的方差, 等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

0.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论: 故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.11. 相关系数范围的推导. 背景 (Background): 我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal): 证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps):

1. Cauchy-Schwarz 不等式: 对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差, 令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$:

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方:

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此:

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论: 故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

0.12. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i\{h_i/k_i\} < t < \min_i\{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.14. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.15. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.16. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.17. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。
2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.18. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。
2. 则 $X = \sum_{j=1}^n I_j$ 。
3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.19. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1 - p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1) \cdots (n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} \rightarrow 1,$$

$$\left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.20. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数：

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论： Poisson 分布的均值和方差相等，都等于参数 λ 。■

0.21. 卡方分布与正态分布的关系. 背景 (Background)： 卡方分布定义为标准正态平方和。

目标 (Goal)： 证明若 $Z \sim N(0, 1)$ ，则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps)：

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$ ，先求 cdf：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf：

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式：

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论： 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.22. 卡方分布的可加性证明. 背景 (Background)： 卡方分布满足可加性：独立卡方变量之和仍为卡方分布。

目标 (Goal)： 证明若 $X_1 \sim \chi^2(m)$ ， $X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps)：

1. 由卡方分布与 Gamma 分布的关系： $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性（见定理 3.3.1）：若 $Y_1 \sim \Gamma(\alpha_1, \beta)$ ， $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立，则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此：

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf： $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$ ，故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论： 卡方分布具有可加性，自由度可累加。■

0.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1+X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.24. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.25. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.26. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}\left[e^{(t/\sigma)X}\right] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.27. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是**固定（但未知）的常数**，而区间 $[L, U]$ 是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 Chapter 4 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及（直方图估计）
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

简单区分：

场景	方法	章节
分布形式未知	非参数方法（直方图、核密度估计）	Chapter 10
分布形式已知、参数未知	参数方法（MLE、CI、检验）	Chapter 4

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计（MLE）被提出的**动机**。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

具体例子：

- S^2 （无偏）和 $\hat{\sigma}^2$ （有偏，但 MLE）
- 两者都常用，但各有用途
- “最优”需要更精确的定义（后续章节的 UMVUE）

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

学习笔记.