

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;

SPRT 的吸引力：为什么 SPRT 如此重要？因为它在固定两类错误概率的同时，通常使用比固定样本量检验更少的样本。Wald 的近似理论表明，当 H_0 或 H_1 为真时，SPRT 的平均样本量（Average Sample Number, ASN）比相应的固定样本量检验小得多——有时能节省 50% 以上的样本。

SPRT 与质量控制：SPRT 的思想在工业质量控制中有广泛应用。CUSUM（累积和）控制图就是 SPRT 的一个变体——它持续累积标准化后的偏离量 $\sum(Z_i - 0.5)$ （其中 Z_i 是标准化后的检验统计量），一旦超出控制限就发出警报。与固定间隔的 Shewhart 控制图相比，CUSUM 能更快检测到过程均值的微小漂移。

5. 8.5 *Minimax and Classification Procedures

5.1. 8.5.1 极小化极大检验。在第 7 章的决策论框架中，我们介绍了极小化极大（minimax）原则：将最大风险最小化。将这个思想应用到假设检验中，会得到一个有趣的结论——Neyman-Pearson 最佳检验在某种意义上也是极小化极大的。

考虑简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ ，损失函数满足 $\mathcal{L}(\theta', \theta') = \mathcal{L}(\theta'', \theta'') = 0$ （正确决策无损失），而 $\mathcal{L}(\theta', \theta'') > 0$ 和 $\mathcal{L}(\theta'', \theta') > 0$ （错误决策有损失）。¹⁷

此时风险函数为：

$$R(\theta', C) = \mathcal{L}(\theta', \theta'') \cdot \alpha, \quad R(\theta'', C) = \mathcal{L}(\theta'', \theta') \cdot \beta,$$

其中 α 是显著性水平， β 是 Type II 错误概率。

极小化极大原则要求选择 C 使得 $\max\{R(\theta', C), R(\theta'', C)\}$ 最小。可以证明，当 k 满足

$$\mathcal{L}(\theta', \theta'') \int_C L(\theta') = \mathcal{L}(\theta'', \theta') \int_{C^c} L(\theta'')$$

时（即两类错误造成的风险相等），临界区域 C 是极小化极大的。这个条件与 NP 似然比条件是一致的——本质上，最佳检验同时也是极小化极大检验（当两类错误的相对代价被适当选择时）。¹⁸

EXAMPLE 6.10（正态均值的极小化极大检验）。设 $X_1, \dots, X_{100} \sim N(\theta, 100)$ ，检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$ ，损失为 $\mathcal{L}(75, 78) = 3$ 、 $\mathcal{L}(78, 75) = 1$ 。

临界区域形如 $\bar{x} \geq c$ ，其中 c 满足：

$$3 \cdot P_{\theta=75}(\bar{X} \geq c) = P_{\theta=78}(\bar{X} < c).$$

¹⁷极小化极大检验的决策论框架见附录 ??。

¹⁸极小化极大检验的完整证明见附录 ??。

由于 $\bar{X} \sim N(\theta, 1)$ ，这化为

$$3[1 - \Phi(c - 75)] = \Phi(c - 78).$$

求解得 $c \approx 76.8$ 。此时显著性水平 $\alpha = 1 - \Phi(1.8) \approx 0.036$ ，功效为 $1 - \Phi(-1.2) \approx 0.885$ 。¹⁹

5.2. 8.5.2 分类问题. 极小化极大检验理论在分类 (classification) 问题中有直接应用。考虑一个二分类问题：我们观察到 (X, Y) ，需要判断它来自分布 $f(x, y; \theta')$ 还是 $f(x, y; \theta'')$ 。

这本质上就是假设检验问题——如果接受 H_0 ，就把 (X, Y) 分类为来自 θ' 类；如果拒绝 H_0 ，就分类为来自 θ'' 类。

由 NP 定理，最佳分类规则是似然比规则：

$$\frac{f(x, y; \theta')}{f(x, y; \theta'')} \leq k \implies \text{分类为 } \theta'' \text{ 类}.$$

若两类的先验概率为 π' 和 π'' ，则最优规则取 $k = \pi''/\pi'$ （当两类等可能时 $k = 1$ ）。

Fisher 线性判别函数：在正态分布的特殊情况下，似然比不等式化为一个线性函数 $ax + by \leq c$ ——这就是著名的 Fisher 线性判别函数。当参数未知时，用训练样本的均值和方差代替，就得到了 Fisher 判别函数。²⁰

[二元正态的线性判别] 设 (X, Y) 来自二元正态分布，参数为 $(\mu'_1, \mu'_2, \sigma_1^2, \sigma_2^2, \rho')$ 或 $(\mu''_1, \mu''_2, \sigma_1^2, \sigma_2^2, \rho'')$ 。则似然比不等式化为

$$ax + by \leq c,$$

其中 a 和 b 是由两个总体的均值向量和协方差矩阵决定的常数。这给出了一个**线性决策边界**——在二维空间中是一条直线，将平面分为两部分，分别对应两类。²¹

附录：公式推导

本附录包含 Chapter 8 中省略的完整推导。

¹⁹极小化极大检验的数值求解 (Newton 法) 见附录 ??。

²⁰Fisher 线性判别函数的完整推导见附录 ??。

²¹二元正态线性判别的详细推导见附录 ??。

5.3. Neyman-Pearson 引理的证明. 背景 (Background): 我们需要证明, 当临界区域 C 满足 NP 条件 (a) -(c) 时, 它是在固定显著性水平 α 下功效最高的检验。

已知条件 (Given):

- $L(\theta'; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta')$ 是 H_0 下的似然函数
- $L(\theta''; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta'')$ 是 H_1 下的似然函数
- 临界区域 C 满足:

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k, \quad \forall \mathbf{x} \in C; \quad \frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k, \quad \forall \mathbf{x} \in C^c.$$

- 任意其他满足 $P_{\theta'}[\mathbf{X} \in A] = \alpha$ 的区域 A 。

目标 (Goal): 证明 $P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A]$ 。

推导步骤 (Derivation Steps):

1. 写出功效差:

$$\int_C L(\theta'') - \int_A L(\theta'') = \int_{C \cap A^c} L(\theta'') - \int_{A \cap C^c} L(\theta'').$$

2. 由条件 (a): 在 C 上 $L(\theta'') \geq \frac{1}{k} L(\theta')$, 故

$$\int_{C \cap A^c} L(\theta'') \geq \frac{1}{k} \int_{C \cap A^c} L(\theta').$$

3. 由条件 (b): 在 C^c 上 $L(\theta'') \leq \frac{1}{k} L(\theta')$, 故

$$\int_{A \cap C^c} L(\theta'') \leq \frac{1}{k} \int_{A \cap C^c} L(\theta').$$

4. 将 (8.A.2) 和 (8.A.3) 代入 (8.A.1):

$$\int_C L(\theta'') - \int_A L(\theta'') \geq \frac{1}{k} \left[\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') \right].$$

5. 计算括号内项:

$$\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') = \int_C L(\theta') - \int_A L(\theta') = \alpha - \alpha = 0.$$

6. 由 (8.A.4) 和 (8.A.5) 得 $\int_C L(\theta'') - \int_A L(\theta'') \geq 0$, 即

$$P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A].$$

证毕。

5.4. 正态均值 NP 检验的完整推导. 背景 (Background): 在例 8.1.2 中, 我们构造了正态均值差假设的 NP 检验。本节补充完整推导。

目标 (Goal): 对 $X_1, \dots, X_n \sim N(\theta, 1)$, 检验 $H_0: \theta = 0$ 对 $H_1: \theta = 1$, 求大小为 α 的最佳检验。

推导步骤 (Derivation Steps):

1. 写出似然函数:

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

2. 似然比:

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \frac{\exp \left[-\frac{1}{2} \sum x_i^2 \right]}{\exp \left[-\frac{1}{2} \sum (x_i - 1)^2 \right]} = \exp \left[-\sum_{i=1}^n x_i + \frac{n}{2} \right].$$

3. 令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$:

$$\exp \left[-\sum x_i + \frac{n}{2} \right] \leq k \iff \sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

4. 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故临界值

$$c_1 = \frac{c}{n} = \frac{1}{2} - \frac{\log k}{n} = q_\alpha(0, 1/\sqrt{n}).$$

5. 功效函数: 当 $\theta = 1$ 时, $\bar{X} \sim N(1, 1/n)$,

$$\text{Power}(\theta = 1) = P_{\theta=1}(\bar{X} \geq q_\alpha(0, 1/\sqrt{n})) = 1 - \Phi \left(\frac{q_\alpha(0, 1/\sqrt{n}) - 1}{1/\sqrt{n}} \right).$$

证毕。

5.5. Karlin-Rubin 定理的证明. 背景 (Background): 证明当似然函数有 MLR 性质时, 单向复合假设存在 UMP 检验。

已知条件 (Given):

- 似然函数 $L(\theta, \mathbf{x})$ 在 $Y = u(\mathbf{x})$ 中有 MLR: 对 $\theta_1 < \theta_2$, $L(\theta_1; \mathbf{x})/L(\theta_2; \mathbf{x}) = g(Y)$, 其中 g 是递减函数。
- 单向假设: $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$ 。

目标 (Goal): 证明检验 $\phi(\mathbf{x}) = 1$ 当 $Y \geq c_Y$, 其中 c_Y 满足 $P_{\theta'}[Y \geq c_Y] = \alpha$, 是 UMP level α 检验。

推导步骤 (Derivation Steps):

1. 对简单假设 $H'_0: \theta = \theta'$ 对 $\theta'' > \theta'$ 的最优性: 由 NP 定理, 最佳临界区域由

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$$

给出。由于 MLR 性质, $g(Y) \leq k \iff Y \geq g^{-1}(k)$ 。取 $c_Y = g^{-1}(k)$, 则对任意 $\theta'' > \theta'$, 临界区域 $C = \{Y \geq c_Y\}$ 是 $H'_0: \theta = \theta'$ 对 θ'' 的最佳检验。

2. 对所有 $\theta'' > \theta'$ 的一致性: 由于 NP 最佳临界区域的形式只依赖于 $Y \geq c_Y$ (而不依赖于具体的 θ''), $C = \{Y \geq c_Y\}$ 对所有 $\theta'' > \theta'$ 都是最佳的。

3. 无偏性 (保证 level 不超过 α): 设 $\gamma_Y(\theta) = P_\theta(Y \geq c_Y)$ 为功效函数。对 $\theta_1 < \theta_2$, 由第 1 步, C 是 θ_1 对 θ_2 的最佳检验, 故 $\gamma_Y(\theta_2) \geq \gamma_Y(\theta_1)$ 。因此 $\gamma_Y(\theta)$ 是 θ 的非降函数, $\max_{\theta \leq \theta'} \gamma_Y(\theta) = \gamma_Y(\theta') = \alpha$ 。故该检验是 level α 的。

综上, $C = \{Y \geq c_Y\}$ 是 UMP level α 检验。证毕。

CHAPTER 7

Sufficiency and Quality of Estimators

Chapter 7 Overview

在前几章中，我们建立了点估计、置信区间和假设检验的理论基础。我们已经看到，最大似然估计（MLE）在正则条件下具有一致性，并且在渐近意义下具有最优性质。然而，我们还没有回答一个更深层次的问题：

给定一个参数 θ ，在所有可能的估计量中，是否存在一个“最好”的？如何找到它？

要回答这个问题，我们首先需要理解什么叫“信息保留”。当我们收集数据 $X_1, X_2, \dots, X_n$ 后，这些数据包含了关于 θ 的信息。但原始数据量太大——我们需要**数据压缩（data reduction）**。一个自然的想法是用样本均值 $\bar{X}$ 或样本方差 S^2 这样的统计量来代替原始数据。

关键问题是：这种压缩是否丢失了关于 θ 的信息？

这正是**充分性（sufficiency）**理论要回答的问题。一个充分统计量 $T(X_1, \dots, X_n)$ 保留了原始数据中关于 θ 的全部信息——给定 T 的值，数据的条件分布不再依赖于 θ 。本章我们将学习：

- 如何定义和判断充分统计量（因子分解定理）
- Rao-Blackwell 定理：如何利用充分性改进估计量
- 完备性（completeness）与唯一最小方差无偏估计（MVUE）的关系
- 指数族分布（exponential class）的优良性质
- Basu 定理：完备充分统计量与辅助统计量的独立性

本章路线图：充分性定义 $\rightarrow$ 因子分解定理 $\rightarrow$ Rao-Blackwell $\rightarrow$ 完备性 $\rightarrow$ 指数族 $\rightarrow$ Basu 定理

1. 7.1 Measures of Quality of Estimators

在寻找“最好”的估计量之前，我们需要先定义什么叫“好”。前几章我们已经遇到过两个重要标准：无偏性（unbiasedness）和一致性（consistency）。

1.1. 最小方差无偏估计量（MVUE）. 一个自然而优雅的标准是：在所有无偏估计量中，选择方差最小的。

DEFINITION 7.1 (最小方差无偏估计量 (MVUE)). 设 $Y = u(X_1, X_2, \dots, X_n)$ 是基于容量为 n 的随机样本的 θ 的点估计量。若 Y 是无偏的，即 $E(Y) = \theta$ ，且对 θ 的任何其他无偏估计量 Y' ，都有 $\text{var}(Y) \leq \text{var}(Y')$ ，则称 Y 是 θ 的**最小方差无偏估计量（minimum variance unbiased estimator, MVUE）**。

这个定义的诱人之处在于它的自然性：如果两个估计量都是 θ 的无偏估计，那么方差较小的那个在平均意义上更接近 θ 。

EXAMPLE 7.1 (正态分布的样本均值 vs 单个观测值). 设 $X_1, X_2, \dots, X_9$ 是来自 $N(\theta, \sigma^2)$ 分布的随机样本，其中 $-\infty < \theta < \infty$ 。

统计量 $\bar{X} = (X_1 + X_2 + \dots + X_9)/9$ 服从 $N(\theta, \sigma^2/9)$ ，因此是无偏的。而 X_1 服从 $N(\theta, \sigma^2)$ ，也是无偏的。

虽然 $\bar{X}$ 的方差 $\sigma^2/9$ 小于 X_1 的方差 σ^2 ，但定义要求比较的对象是**所有**无偏估计量，而不仅仅是这两个。我们不能仅凭两个例子就宣称 $\bar{X}$ 是 *MVUE*。

真正的问题在于：我们无法枚举所有可能的无偏估计量。这促使我们发展更系统的方法来寻找 *MVUE*。

1.2. 风险函数与决策论视角. 另一种比较估计量的框架是决策论 (decision theory)。设 $\mathcal{L}[\theta, \delta(y)]$ 是损失函数 (loss function)，衡量估计值 $\delta(y)$ 与真实参数 θ 之间的差距。常见的损失函数是平方误差损失 $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$ 。

风险函数 (risk function) 定义为损失的期望： $R(\theta, \delta) = E[\mathcal{L}(\theta, \delta(Y))]$ 。一个自然的想法是寻找使风险函数最小化的决策函数。但在一般情况下，使 $R(\theta, \delta)$ 对所有 θ 同时最小的估计量不存在 (见下例)。

EXAMPLE 7.2 (最小化风险函数的困难). 设 $X_1, \dots, X_{25}$ 是来自 $N(\theta, 1)$ 的样本。考虑平方损失函数 $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$ 。

比较两个决策函数：

- $\delta_1(y) = y = \bar{x}$ ，风险 $R(\theta, \delta_1) = 1/25$
- $\delta_2(y) = 0$ ，风险 $R(\theta, \delta_2) = \theta^2$

当 $\theta = 0$ 时， δ_2 表现完美 ($R(0, \delta_2) = 0$)；但当 $\theta = 2$ 时， $R(2, \delta_2) = 4 > R(2, \delta_1) = 1/25$ 。一般地，当 $|\theta| < 1/5$ 时 δ_2 更好，否则 δ_1 更好。

这说明没有一个决策函数能在所有 θ 值下同时最优。**minimax 原则**提供了一种折中：选择使 $\max_{\theta} R(\theta, \delta)$ 最小的决策函数。

如果没有对决策函数的限制 (如要求无偏)，很难找到统一最优的估计量。这促使我们聚焦于 *MVUE*——在无偏估计量的类中寻找方差最小者。

充分性的引入：如果我们有一个充分统计量 T ，那么所有无偏估计量都可以通过 Rao-Blackwell 过程改进为 T 的函数。这大大简化了 *MVUE* 的搜索。

本节小结.

- *MVUE* 在无偏估计量类中方差最小
- 寻找 *MVUE* 的困难在于无法枚举所有无偏估计量
- 充分统计量为这一问题提供了系统性的解决方案

2. 7.2 A Sufficient Statistic for a Parameter

本节我们正式引入充分统计量的概念，并建立判断充分性的核心工具——因子分解定理 (Factorization Theorem)。

2.1. 为什么需要充分统计量? 统计量 $Y = u(X_1, X_2, \dots, X_n)$ 本质上是对样本空间的一种划分 (partition)。例如, $\bar{X} = 8.32$ 意味着所有满足 $\sum x_i = (8.32)n$ 的点 $(x_1, \dots, x_n)$ 被归入同一类。

给定一个统计量 $Y_1 = u_1(X_1, \dots, X_n)$, 如果我们知道 $(X_1, \dots, X_n)$ 落在由 $Y_1 = y_1$ 确定的集合中, 那么 $X_1, \dots, X_n$ 的条件分布可能仍然依赖于 θ 。如果这个条件分布**完全**不含 θ , 则 Y_1 包含了样本中关于 θ 的全部信息——这就是充分性的直觉。

EXAMPLE 7.3 (二项分布的充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 $Bernoulli(\theta)$ 分布的随机样本, 即

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, \quad x = 0, 1.$$

统计量 $Y_1 = \sum_{i=1}^n X_i$ 服从二项分布 $b(n, \theta)$ 。考虑条件概率

$$P(X_1 = x_1, \dots, X_n = x_n \mid Y_1 = y_1).$$

当且仅当 $\sum x_i = y_1$ 时该条件概率非零, 此时

$$\frac{\theta^{x_1}(1-\theta)^{1-x_1} \cdots \theta^{x_n}(1-\theta)^{1-x_n}}{\binom{n}{y_1} \theta^{y_1} (1-\theta)^{n-y_1}} = \frac{1}{\binom{n}{y_1}},$$

该式不含 θ 。因此给定 $Y_1 = y_1$, 数据的条件分布与 θ 无关—— Y_1 是 θ 的充分统计量。

这个例子的含义是: 只要知道“成功次数” Y_1 是多少, 就不再需要知道具体是哪几次试验成功了。 Y_1 已经包含了所有关于 θ 的信息。

2.2. 充分统计量的正式定义.

DEFINITION 7.2 (充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是统计量, 其 pdf 或 pmf 为 $f_{Y_1}(y_1; \theta)$ 。则 Y_1 是 θ 的**充分统计量**, 当且仅当

$$\frac{f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta)}{f_{Y_1}[u_1(x_1, \dots, x_n); \theta]} = H(x_1, \dots, x_n),$$

其中 $H(x_1, \dots, x_n)$ 不依赖于 θ 。

这个定义的要点是: 分子是联合 pdf/pmf, 分母是充分统计量的 pdf, 比值只与原始数据有关而与 θ 无关。

2.3. 因子分解定理 (Factorization Theorem). 直接使用定义需要知道充分统计量的分布, 这往往很困难。Neyman 的因子分解定理提供了一个更实用的判定方法。

THEOREM 7.1 (Neyman 因子分解定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。统计量 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量, 当且仅当存在两个非负函数 k_1 和 k_2 , 使得

$$f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta) = k_1[u_1(x_1, \dots, x_n); \theta] \cdot k_2(x_1, \dots, x_n),$$

其中 $k_2(x_1, \dots, x_n)$ 不依赖于 θ 。

核心理想：联合 pdf/pmf 可以分解为两部分——一部分只通过 $u_1(x_1, \dots, x_n)$ 依赖于 θ ，另一部分与 θ 无关。能完成这种分解的统计量就是充分的。

EXAMPLE 7.4 (正态分布 $\bar{X}$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 $N(\theta, \sigma^2)$ 的样本，其中 σ^2 已知。则

$$f(x_i; \theta) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x_i - \theta)^2}{2\sigma^2} \right].$$

联合 pdf 为

$$\prod_{i=1}^n f(x_i; \theta) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

利用恒等式 $\sum (x_i - \theta)^2 = \sum (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2$ ，可得

$$\prod_{i=1}^n f(x_i; \theta) = \underbrace{\exp \left[-\frac{n(\bar{x} - \theta)^2}{2\sigma^2} \right]}_{k_1[\bar{x}; \theta]} \cdot \underbrace{\frac{\exp \left[-\frac{1}{2\sigma^2} \sum (x_i - \bar{x})^2 \right]}{(\sigma\sqrt{2\pi})^n}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\bar{X}$ 是 θ 的充分统计量。¹

EXAMPLE 7.5 (指数分布的充分统计量). 设 $X_1, \dots, X_n$ 是来自 $\Gamma(2, \theta)$ 分布的样本。已知 $\Gamma(\alpha, \beta)$ 分布的 mgf 为 $M(t) = (1 - \beta t)^{-\alpha}$, $t < 1/\beta$ 。

$Y_1 = \sum_{i=1}^n X_i$ 的 mgf 为 $[(1 - \theta t)^{-2}]^n = (1 - \theta t)^{-2n}$ ，因此 $Y_1 \sim \Gamma(2n, \theta)$ 。

联合 pdf 为

$$\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2} = \frac{(\prod x_i) \exp(-\sum x_i/\theta)}{\theta^{2n}}.$$

给定 $Y_1 = y_1$ 时，条件概率的比值为

$$\frac{\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2}}{\frac{y_1^{2n-1} e^{-y_1/\theta}}{\Gamma(2n)\theta^{2n}}} = \frac{\Gamma(2n) \prod x_i}{y_1^{2n-1}},$$

不含 θ 。故 $Y_1 = \sum X_i$ 是 θ 的充分统计量。

EXAMPLE 7.6 (乘积 $\prod X_i$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0$$

的样本。这是参数化形式的 Beta 分布。

联合 pdf 为

$$\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} = \underbrace{\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta}}_{k_1[\prod x_i; \theta]} \cdot \underbrace{\frac{1}{\prod x_i}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\prod_{i=1}^n X_i$ 是 θ 的充分统计量。

注意：使用因子分解定理时，必须正确处理支撑集 (support) 对参数的依赖。

¹正态分布充分性的详细推导见附录 ??。

EXAMPLE 7.7 (支撑集依赖参数的情况). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta) = e^{-(x-\theta)} I_{(\theta, \infty)}(x).$$

一种错误的分解可能是:

$$\prod e^{-(x_i-\theta)} = [e^{3\theta}] [e^{-x_1-x_2-x_3}],$$

从而声称 $\max X_i$ 是充分的。但这是错误的, 因为支撑集的交集必须满足 $\theta < \min x_i$, 即

$$\prod I_{(\theta, \infty)}(x_i) = I_{(\theta, \infty)}(\min x_i).$$

正确的分解导致 $\min X_i$ 是充分统计量, 而非 $\max X_i$ 。

本节小结.

- 充分统计量 T 保留了样本中关于 θ 的全部信息
- 因子分解定理是判断充分性的实用工具
- 注意支撑集对参数的依赖情况

3. 7.3 Properties of a Sufficient Statistic

本节讨论充分性的关键应用: 如何利用充分统计量改进任意无偏估计量。

3.1. Rao-Blackwell 定理. 给定一个充分统计量 T , 我们可以将任意无偏估计量 Y_2 改进为 T 的函数 $\varphi(T)$, 新估计量不仅保持无偏性, 方差还会减小。

THEOREM 7.2 (Rao-Blackwell 定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量。设 $Y_2 = u_2(X_1, \dots, X_n)$ (不是 Y_1 的函数) 是 θ 的无偏估计量。

则 $E(Y_2 | y_1) = \varphi(y_1)$ 定义了一个统计量 $\varphi(Y_1)$ 。该统计量 $\varphi(Y_1)$:

- (1) 是 θ 的无偏估计量
- (2) 是充分统计量的函数
- (3) 方差不超过 Y_2 的方差

证明思路: 利用全概率公式 $E(Y_2) = E[E(Y_2 | Y_1)]$ 和条件方差不增性质 $\text{var}(Y_2) \geq \text{var}[E(Y_2 | Y_1)]$ 。

这个定理的战略意义是: 在寻找 MVUE 时, 只需在充分统计量的函数中搜索。

EXAMPLE 7.8 (指数分布的 MVUE). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta e^{-\theta x}, \quad x > 0, \quad \theta > 0$$

的样本 (这是 $\Gamma(1, 1/\theta)$ 分布)。

联合 pdf 为 $L(\theta) = \theta^n e^{-\theta \sum x_i}$, 故 $Y_1 = \sum_{i=1}^n X_i$ 是充分统计量。

MLE 为 $Y_2 = 1/\bar{X} = n/Y_1$ 。由于 MLE 渐近无偏, 我们计算其期望。 $Y_1 \sim \Gamma(n, 1/\theta)$, 因此

$$E(Y_2) = n \cdot E(1/Y_1) = n \int_0^\infty \frac{\theta^n}{n!} t^{-1} t^{n-1} e^{-\theta t} dt = \frac{n}{n-1} \theta, \quad n > 1.$$

故 $(n-1)/n \cdot Y_2 = (n-1)/Y_1$ 是 θ 的无偏估计量, 且是充分统计量的函数, 因此是 *MVUE*。

3.2. 充分性与 MLE 的关系.

THEOREM 7.3 (充分性与 MLE). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。若 θ 的 MLE $\hat{\theta}$ 存在且唯一, 则 $\hat{\theta}$ 是充分统计量的函数。

直觉: 若 T 是充分的, 则似然函数 $L(\theta) = f_T(t; \theta) \cdot H(\mathbf{x})$ 。 $L(\theta)$ 和 $f_T(t; \theta)$ 作为 θ 的函数同时达到最大值, 故 $\hat{\theta}$ 必为 T 的函数。

这一结果具有重要的实践意义: 对于指数族分布, MLE 通常可以解析地写成充分统计量的函数。

本节小结.

- Rao-Blackwell 定理: 将任意无偏估计量改进为充分统计量的函数
- 充分性搜索范围: 从所有统计量缩小到充分统计量的函数
- 若 MLE 存在且唯一, 则必为充分统计量的函数

4. 7.4 Completeness and Uniqueness

有了 Rao-Blackwell 定理, 我们知道 MVUE (若存在) 必是充分统计量的函数。但充分统计量的函数可能有很多个——我们如何确定哪一个是 MVUE?

这就需要引入 **完备性 (completeness)** 的概念。

4.1. 完备性的定义.

DEFINITION 7.3 (完备族). 设随机变量 Z (连续型或离散型) 的 pdf 或 pmf 是族 $\{h(z; \theta) : \theta \in \Omega\}$ 的一页。若条件 $E[u(Z)] = 0$ 对所有 $\theta \in \Omega$ 成立能够推出 $u(z) = 0$ (除了一个对每个 $h(z; \theta)$ 概率为零的点集), 则称该族为 **完备族 (complete family)**。

简言之: 只有零函数才能期望为零。

EXAMPLE 7.9 (泊松分布族的完备性). 设 $X_1, \dots, X_n$ 是来自泊松分布 $P(\theta)$ 的样本。已知 $Y_1 = \sum X_i$ 是充分统计量, 其 pmf 为

$$g(y_1; \theta) = \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!}, \quad y_1 = 0, 1, 2, \dots$$

设 $E[u(Y_1)] = 0$ 对所有 $\theta > 0$ 成立, 即

$$\sum_{y_1=0}^{\infty} u(y_1) \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!} = 0.$$

由于 $e^{-n\theta} \neq 0$, 可得

$$u(0) + nu(1)\theta + \frac{n^2 u(2)}{2!} \theta^2 + \dots = 0, \quad \forall \theta > 0.$$

无穷幂级数对所有 $\theta > 0$ 为零, 意味着所有系数必为零:

$$u(0) = u(1) = u(2) = \cdots = 0.$$

故泊松充分统计量族是完备的。

EXAMPLE 7.10 (指数分布族的完备性). 设 $Z \sim \text{Exp}(\theta)$, 即 pdf 为 $h(z; \theta) = \frac{1}{\theta} e^{-z/\theta}$, $z > 0$ 。

设 $E[u(Z)] = 0$ 对所有 $\theta > 0$ 成立:

$$\int_0^\infty u(z) \frac{1}{\theta} e^{-z/\theta} dz = 0, \quad \forall \theta > 0.$$

令 $t = z/\theta$, 则 $\theta dt = dz$:

$$\int_0^\infty u(\theta t) e^{-t} dt = 0, \quad \forall \theta > 0.$$

对 θ 求导并利用积分号内可微 (假设 u 满足适当条件), 可得 $u(\theta t) \equiv 0$ 。由拉普拉斯变换的唯一性, $u \equiv 0$ 。故该族是完备的。

4.2. 完备充分统计量与 MVUE 的唯一性.

THEOREM 7.4 (Lehmann-Scheffé 定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量, 且族 $\{f_{Y_1}(y_1; \theta) : \theta \in \Omega\}$ 是完备的。

若存在 Y_1 的一个函数是 θ 的无偏估计量, 则该函数是唯一的 MVUE。

证明思路: 设 $\varphi(Y_1)$ 和 $\psi(Y_1)$ 都是 Y_1 的无偏估计量函数。则 $E[\varphi(Y_1) - \psi(Y_1)] = 0$ 对所有 θ 成立。由完备性, $\varphi(y_1) - \psi(y_1) = 0$ 几乎处处成立, 即两个估计量函数几乎处处相等——这就是“唯一”含义。

战略意义: 完备充分统计量的无偏函数就是 MVUE。

EXAMPLE 7.11 (均匀分布最大值的 MVUE). 设 $X_1, \dots, X_n$ 是来自 $\text{Uniform}(0, \theta)$ 的样本。 $Y_n = \max\{X_i\}$ 是充分统计量 (习题 7.2.3), 其 pdf 为

$$g(y_n; \theta) = \frac{ny_n^{n-1}}{\theta^n}, \quad 0 < y_n < \theta.$$

验证完备性: 设 $E[u(Y_n)] = 0$ 对所有 $\theta > 0$ 成立,

$$\int_0^\theta u(t) \frac{nt^{n-1}}{\theta^n} dt = 0.$$

等价于 $\int_0^\theta u(t) t^{n-1} dt = 0$ 。对 θ 求导得 $u(\theta) \theta^{n-1} = 0$, 故 $u(\theta) = 0$ 对所有 $\theta > 0$ 成立。故 Y_n 是完备充分的。

计算 $E(Y_n) = \frac{n}{n+1} \theta$, 故 $(n+1)/n \cdot Y_n$ 是 θ 的 MVUE。

EXAMPLE 7.12 (非完备的情况). 设 $X \sim N(0, \theta)$, $\theta > 0$ 。则 $Y = \sum X_i^2$ 是充分统计量, 但族 $\{f_Y(y; \theta)\}$ 不是完备的 (因为 χ^2 分布的自由度参数不依赖于 θ 的形式)。

实际上, 若 $Z \sim \chi_{n-1}^2$ (与 Y 独立), 则 $E(Z) = n-1$, 但这并不能推出关于 Y 的任何约束。

本节小结.

- 完备性: 只有零函数才能期望为零
- Lehmann-Scheffé 定理: 完备充分统计量的无偏函数是唯一的 MVUE
- 寻找 MVUE 的策略: 先找完备充分统计量, 再在其函数中找无偏估计量

5. 7.5 The Exponential Class of Distributions

在前几节中, 我们看到充分性和完备性是找到 MVUE 的关键。但如何系统地找到完备充分统计量? 本节介绍的**指数族分布 (exponential class)** 是一个具有优良性质的大类。

5.1. 正则指数族的定义.

DEFINITION 7.4 (正则指数族). 设 $f(x; \theta)$ 具有如下形式:

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)], \quad x \in \mathcal{S},$$

其中 $\mathcal{S}$ 是 X 的支撑集。若满足:

- (1) $\mathcal{S}$ 不依赖于 θ
- (2) $p(\theta)$ 是 $\theta \in \Omega$ 的非线性连续函数
- (3) 若 X 连续, 则 $K'(x) \neq 0$ 且 $H(x)$ 在 $\mathcal{S}$ 上连续; 若 X 离散, 则 $K(x)$ 在 $\mathcal{S}$ 上非线性

则称 $f(x; \theta)$ 属于**正则指数族 (regular exponential class)**。

直觉: 指数形式 $e^{p(\theta)K(x)}$ 使得对数似然函数是 $K(x)$ 的线性函数, 从而 $\sum K(X_i)$ 自然成为充分统计量。

EXAMPLE 7.13 (正态分布 $N(0, \theta)$ 是指数族). $N(0, \theta)$ 的 pdf 可写为

$$f(x; \theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-x^2/(2\theta)} = \exp \left[-\frac{1}{2\theta} x^2 - \frac{1}{2} \log(2\pi\theta) \right].$$

对应 $p(\theta) = -1/(2\theta)$, $K(x) = x^2$, $H(x) = -\frac{1}{2} \log(2\pi)$, $q(\theta) = -\frac{1}{2} \log(2\pi\theta)$ 。故 $N(0, \theta)$ 属于正则指数族。

若 $X_1, \dots, X_n \sim N(0, \theta)$, 则 $\sum X_i^2$ 是充分统计量。

EXAMPLE 7.14 (泊松分布是指数族). 泊松分布的 pmf 为

$$f(x; \theta) = e^{-\theta} \frac{\theta^x}{x!} = \exp[(\log \theta)x - \theta - \log(x!)].$$

对应 $p(\theta) = \log \theta$, $K(x) = x$, $q(\theta) = -\theta$, $H(x) = -\log(x!)$ 。故泊松分布属于正则指数族, $\sum X_i$ 是充分统计量。

反例: 均匀分布 $f(x; \theta) = 1/\theta$, $0 < x < \theta$ 的支撑集依赖于 θ , 因此不是正则指数族。

5.2. 指数族的核心定理.

THEOREM 7.5 (指数族充分统计量的性质). 设 $X_1, \dots, X_n$ 来自正则指数族, pdf/pmf 如定义所示. 设 $Y_1 = \sum_{i=1}^n K(X_i)$. 则:

(1) Y_1 的 pdf/pmf 具有形式

$$f_{Y_1}(y_1; \theta) = R(y_1) \exp[p(\theta)y_1 + nq(\theta)], \quad y_1 \in \mathcal{S}_{Y_1},$$

其中 $\mathcal{S}_{Y_1}$ 和 $R(y_1)$ 不依赖于 θ

$$(2) E(Y_1) = -n \frac{q'(\theta)}{p'(\theta)}$$

$$(3) \text{var}(Y_1) = n \cdot \frac{p''(\theta)q'(\theta) - q''(\theta)p'(\theta)}{[p'(\theta)]^3}$$

THEOREM 7.6 (指数族统计量的完备性). 在正则指数族条件下, $Y_1 = \sum_{i=1}^n K(X_i)$ 是 θ 的完备充分统计量。

证明思路: 设 $E[u(Y_1)] = 0$ 对所有 θ 成立. 利用 Y_1 的分布形式, 可得

$$\int u(y_1) R(y_1) \exp[p(\theta)y_1] dy_1 = 0, \quad \forall \theta.$$

由于 $p(\theta)$ 是非线性连续函数, 该积分本质上是 $u(y_1)R(y_1)$ 的拉普拉斯变换. 拉普拉斯变换为零意味着 $u(y_1)R(y_1) \equiv 0$. 由于 $R(y_1) > 0$ (它是 pdf 的因子), 故 $u(y_1) \equiv 0$.

EXAMPLE 7.15 (正态均值 θ 的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知. 则

$$f(x; \theta) = \exp \left[\frac{\theta}{\sigma^2} x - \frac{x^2}{2\sigma^2} - \log \sqrt{2\pi\sigma^2} - \frac{\theta^2}{2\sigma^2} \right].$$

故 $p(\theta) = \theta/\sigma^2$, $K(x) = x$, $q(\theta) = -\frac{\theta^2}{2\sigma^2}$. $Y_1 = \sum X_i = n\bar{X}$ 是完备充分统计量. $E(Y_1) = n\theta$, 故 $\varphi(Y_1) = Y_1/n = \bar{X}$ 是 θ 的唯一 MVUE。

指数族的战略价值: 对于指数族, 完备充分统计量可以通过观察直接写出, MVUE 也容易通过期望计算得到。

本节小结.

- 正则指数族具有形式 $e^{p(\theta)K(x)+H(x)+q(\theta)}$
- $\sum K(X_i)$ 是指数族的充分统计量
- 指数族统计量是完备充分的
- 指数族的 MVUE 可通过期望计算直接得到

6. 7.6 Functions of a Parameter

很多时候, 我们关心的不是参数 θ 本身, 而是其某个函数 $\delta = g(\theta)$. 例如, 估计 $\theta(1-\theta)$ 而非 θ 本身。

6.1. 技术一：观察法。如果能通过观察 $E[\varphi(Y_1)] = g(\theta)$ 解出 φ 就可直接得到 MVUE。

EXAMPLE 7.16 (二项分布方差的 MVUE). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$. $Y = \sum X_i$ 是完备充分统计量。样本比例 Y/n 是 θ 的 MVUE。

现欲估计 $\delta = \theta(1 - \theta)$, 即 $\text{var}(Y/n) = \theta(1 - \theta)/n$ 。

MLE 为 $\tilde{\delta} = (Y/n)(1 - Y/n)$ 。计算期望:

$$E[\tilde{\delta}] = E\left[\frac{Y}{n}\left(1 - \frac{Y}{n}\right)\right] = \frac{n-1}{n}\theta(1 - \theta).$$

故 $\hat{\delta} = \frac{n}{n-1}\tilde{\delta} = \frac{Y(n-Y)}{n(n-1)}$ 是 δ 的 MVUE。

6.2. 技术二：条件期望法。若 Z 是 θ 的无偏估计量, 则 $\varphi(Y_1) = E(Z | Y_1)$ 是 MVUE。

EXAMPLE 7.17 (正态分布累积概率的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ 。欲估计 $P(X \leq c) = \Phi(c - \theta)$ 。

取 $Z = I(X_1 \leq c)$, 则 $E(Z) = \Phi(c - \theta)$, 是无偏的。

$(X_1, \bar{X})$ 的联合分布是二元正态, 条件分布 $X_1 | \bar{X} = \bar{x}$ 是正态, 均值为 $\bar{x}$, 方差为 $(n-1)/n$ 。

计算条件期望:

$$E[Z | \bar{X} = \bar{x}] = P(X_1 \leq c | \bar{X} = \bar{x}) = \Phi\left[\frac{\sqrt{n}(c - \bar{x})}{\sqrt{n-1}}\right].$$

这是 $\Phi(c - \theta)$ 的 MVUE。

6.3. 7.6.1 Bootstrap 标准误。对于 MVUE, 我们通常没有像 MLE 那样的渐近理论。但可以使用 Bootstrap 来获得标准误。

设 $\hat{\theta}$ 是基于原始样本的估计量。从经验分布 $\hat{F}_n$ 中有放回地抽取 B 个 Bootstrap 样本, 计算每个样本的估计值 $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ 。则 Bootstrap 标准误为

$$\text{SE}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\hat{\theta}})^2}, \quad \bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b^*.$$

这在 MVUE 的解析标准误难以获得时特别有用。

本节小结。

- 估计 $g(\theta)$ 时, 先找 θ 的完备充分统计量
- MVUE 或者是 T 的函数的期望, 或者通过条件期望改进
- Bootstrap 可用于估计 MVUE 的标准误

7. 7.7 The Case of Several Parameters

前面的讨论聚焦于单个参数。当分布涉及多个参数时, 我们需要联合充分统计量 (joint sufficient statistics) 的概念。

7.1. 联合充分统计量.

DEFINITION 7.5 (联合充分统计量). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本, 其中 $\theta \in \Omega \subset \mathbb{R}^p$. 设 $\mathbf{Y} = (Y_1, \dots, Y_m)$ 是统计量向量. 则 $\mathbf{Y}$ 是 θ 的联合充分统计量, 当且仅当

$$\frac{\prod_{i=1}^n f(x_i; \theta)}{f_{\mathbf{Y}}(\mathbf{y}; \theta)} = H(x_1, \dots, x_n),$$

其中 H 不依赖于 θ .

因子分解定理同样适用: 联合似然函数可分解为仅依赖 $\mathbf{y}$ 的因子和与参数无关的因子.

EXAMPLE 7.18 (双参数正态分布). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$, 其中 θ_1 是均值, θ_2 是方差.

联合 pdf 为

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi\theta_2}} \exp \left[-\frac{(x_i - \theta_1)^2}{2\theta_2} \right].$$

利用恒等式 $\sum (x_i - \theta_1)^2 = \sum x_i^2 - n\bar{x}^2 + n(\bar{x} - \theta_1)^2$, 可得

$$\prod f(x_i; \theta) = \exp \left[-\frac{n(\bar{x} - \theta_1)^2}{2\theta_2} \right] \cdot \frac{\exp \left[-\frac{1}{2\theta_2} \sum (x_i - \bar{x})^2 \right]}{(\sqrt{2\pi\theta_2})^n}.$$

因此 $(\bar{X}, \sum X_i^2)$ 或等价地 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量.

EXAMPLE 7.19 (均匀分布的双参数). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta_1, \theta_2) = \frac{1}{2\theta_2} I_{(\theta_1 - \theta_2, \theta_1 + \theta_2)}(x).$$

这是区间长度为 $2\theta_2$ 、中心为 θ_1 的均匀分布. 充分统计量为 $(Y_1, Y_n) = (\min X_i, \max X_i)$.

7.2. 多参数指数族.

DEFINITION 7.6 (m 参数指数族). 设 $f(x; \theta)$ 具有形式

$$f(x; \theta) = \exp \left[\sum_{j=1}^m p_j(\theta) K_j(x) + H(x) + q(\theta) \right], \quad x \in \mathcal{S}.$$

在正则条件下, 统计量

$$Y_j = \sum_{i=1}^n K_j(X_i), \quad j = 1, \dots, m$$

是 θ 的联合完备充分统计量 (当 $n > m$ 时).

EXAMPLE 7.20 (双参数指数族). $N(\theta_1, \theta_2)$ 可写为指数形式:

$$f(x; \theta_1, \theta_2) = \exp \left[-\frac{1}{2\theta_2} x^2 + \frac{\theta_1}{\theta_2} x - \frac{\theta_1^2}{2\theta_2} - \frac{1}{2} \log(2\pi\theta_2) \right].$$

取 $K_1(x) = x^2$, $K_2(x) = x$, 则联合充分统计量为 $(\sum X_i^2, \sum X_i)$, 与之前的结论一致.

多参数情况下的 MVUE: 设 $\delta = g(\boldsymbol{\theta})$ 是感兴趣的参数函数。若 $\mathbf{Y}$ 是联合完备充分统计量, 则 $E[\delta | \mathbf{Y}]$ 是 δ 的 MVUE。

本节小结.

- 多参数时需要联合充分统计量
- 双参数正态: $(\bar{X}, S^2)$ 是联合完备充分统计量
- 多参数指数族具有联合完备充分统计量

8. 7.8 Minimal Sufficiency and Ancillary Statistics

充分统计量不唯一——任何一一变换 (one-to-one transformation) 还是充分统计量。但我们总希望找到”最小”的充分统计量, 用最少的统计量包含全部信息。

8.1. 最小充分统计量.

DEFINITION 7.7 (最小充分统计量). 设 T 是充分统计量。若对任何其他充分统计量 T' , T 都是 T' 的函数, 则称 T 是**最小充分统计量** (*minimal sufficient statistic*)。

直观理解: 最小充分统计量是”最压缩”的充分统计量——无法在保持充分性的前提下进一步压缩。

一个关键洞察: 若 MLE $\hat{\theta}$ 是充分的, 则 $\hat{\theta}$ 必是最小充分统计量 (因为任何其他充分统计量都能导出 $\hat{\theta}$)。

EXAMPLE 7.21 (均匀分布 $(\theta - 1, \theta + 1)$ 的最小充分统计量). 设 $X_1, \dots, X_n$ 来自 $Uniform(\theta - 1, \theta + 1)$ 分布。

联合 pdf 中出现的指示函数要求 $\theta - 1 < \min x_i \leq x_j \leq \max x_i < \theta + 1$ 。因此 $(Y_1, Y_n) = (\min X_i, \max X_i)$ 是充分统计量。

由于无法进一步压缩 (两个统计量缺一不可), 它们是最小充分统计量。注意这与单参数情况不同——无法用一个统计量替代两个。

一般位置模型: 若 $X_i = \theta + W_i$, 其中 W_i iid, 则顺序统计量 $(Y_1, \dots, Y_n)$ 是最小充分的。但有时也可以进一步压缩——例如正态分布时 $\bar{X}$ 就足够了。

8.2. 辅助统计量 (Ancillary Statistics). 充分统计量包含关于参数的全部信息。辅助统计量的分布则完全不含参数信息——看似是充分性的”对立面”。

DEFINITION 7.8 (辅助统计量). 设 $Z = u(X_1, \dots, X_n)$ 是统计量。若 Z 的分布不依赖于 $\boldsymbol{\theta}$, 则称 Z 是**辅助统计量** (*ancillary statistic*)。

例子:

- $N(\theta, 1)$ 分布中, S^2 是辅助统计量 (其分布不依赖于 θ)
- 尺度模型 $X_i = \theta W_i$ 中, X_1/X_2 是辅助统计量

辅助统计量揭示了数据中与参数无关的部分。虽然看似无用, 但它们在构建置信区间和检验中很有价值。

EXAMPLE 7.22 (位置不变统计量). 设 $X_i = \theta + W_i, W_i \text{ iid}$. 统计量 $Z = u(X_1, \dots, X_n)$ 若满足

$$u(x_1 + d, \dots, x_n + d) = u(x_1, \dots, x_n), \quad \forall d,$$

则是位置不变的。直观上, 这意味着 Z 只描述 W_i 的性质, 因此与 θ 无关。

常见的例子包括: 样本方差 S^2 、样本极差 $\max X_i - \min X_i$ 、以及 $\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 。

EXAMPLE 7.23 (尺度不变统计量). 设 $X_i = \theta W_i, \theta > 0, W_i \text{ iid}$. 若 Z 满足

$$u(cx_1, \dots, cx_n) = u(x_1, \dots, x_n), \quad \forall c > 0,$$

则是尺度不变的。

例子: $X_1/(X_1 + X_2)$ 、 $X_1^2/\sum X_i^2$ 、 $\min X_i/\max X_i$ 。

辅助统计量与充分统计量的关系将在下节的 Basu 定理中揭示。

本节小结.

- 最小充分统计量是充分统计量的一一变换后仍保持充分性
- 若 MLE 是充分的, 则它必是最小充分的
- 辅助统计量的分布不含参数信息
- 位置/尺度不变统计量是常见的辅助统计量

9. 7.9 Sufficiency, Completeness, and Independence

本节揭示充分性、完备性与独立性之间的深刻联系——Basu 定理。

9.1. Basu 定理的动机. 我们已经知道:

- 若 T 是充分的, 则 Z 的条件分布 $h(z | t)$ 不依赖于 θ
- 若 T 和 Z 独立, 则 Z 的边际分布 $g_2(z) = h(z | t)$ 不依赖于 θ ——即 Z 是辅助的

反过来: 若 Z 是辅助的 (分布不含 θ), T 是充分的, T 和 Z 是否独立?

直觉上似乎应该独立——但这需要证明。

9.2. Basu 定理.

THEOREM 7.7 (Basu 定理). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本, $\theta \in \Omega$ (Ω 是区间)。设 T 是 θ 的完备充分统计量。设 $Z = u(X_1, \dots, X_n)$ 是另一个统计量。

若 Z 的分布不依赖于 θ (即 Z 是辅助的), 则 T 与 Z 独立。

证明思路: 考虑 T 和 Z 的联合 pdf $g_1(t; \theta)h(z | t)$ 。 Z 的边际分布为

$$\int g_1(t; \theta)h(z | t)dt = g_2(z),$$

不依赖于 θ 。同时 $g_2(z) = \int g_2(z)g_1(t; \theta)dt$ 。两式相减得

$$\int [g_2(z) - h(z | t)]g_1(t; \theta)dt = 0, \quad \forall \theta.$$

由于 T 是完备的, 上式意味着 $g_2(z) - h(z | t) = 0$ 几乎处处成立, 即 $h(z | t) = g_2(z)$, 故 T 与 Z 独立。

核心洞察: 完备性是独立性的关键——它保证了期望为零的函数必为零函数。

EXAMPLE 7.24 (正态分布中 $\bar{X}$ 与 S^2 的独立性). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知。则 $\bar{X}$ 是 θ 的完备充分统计量。

样本方差 S^2 是位置不变的——其分布不依赖于 θ 。由 Basu 定理, $\bar{X}$ 与 S^2 独立。这与我们在第 3 章用到的结果一致。

EXAMPLE 7.25 (指数分布中 T 与尺度不变量的独立性). 设 $X_1, X_2 \sim \text{Exp}(\theta)$ 。则 $Y_1 = X_1 + X_2$ 是完备充分统计量。

考虑比值 $Z = X_1 / (X_1 + X_2)$ 。这是尺度不变的 ($Z(cX_1, cX_2) = Z(X_1, X_2)$), 因此 Z 的分布不含 θ 。

由 Basu 定理, Y_1 与 Z 独立。实际上, $Z \sim \text{Beta}(1, 1)$ (均匀分布), 与指数分布的参数无关。

EXAMPLE 7.26 (正态双参数中 $\bar{X}, S^2$ 与辅助量的独立性). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$ 。则 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量。

考虑统计量

$$Z = \frac{\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

该统计量满足位置-尺度不变性, 因此其分布不含 (θ_1, θ_2) 。由 Basu 定理, Z 与 $(\bar{X}, S^2)$ 独立。

9.3. Basu 定理的应用. Basu 定理的价值在于:

- (1) 提供独立性证明的简洁方法 (无需计算联合分布)
- (2) 揭示了“信息对立”: 完备充分统计量与辅助统计量正交
- (3) 辅助统计量虽然不含参数信息, 但可用于构建置信区间 (如枢轴量)

重要注记: 若充分统计量不是完备的, Basu 定理不适用——此时辅助统计量可能与充分统计量不独立, 辅助统计量中可能仍包含关于参数的条件信息。

EXAMPLE 7.27 (非完备情况下的条件信息). 在均匀分布 $(\theta - 1, \theta + 1)$ 例子中, 充分统计量是 $(Y_1, Y_n) = (\min X_i, \max X_i)$, 但它们不是完备的。

令 $T_1 = (Y_1 + Y_n)/2$ (θ 的无偏估计) 和 $T_2 = Y_n - Y_1$ (辅助的)。虽然 T_2 是辅助的, 但给定 $T_2 = t_2$ 的条件下, T_1 的方差为 $(2 - t_2)^2/12$ ——较小的 t_2 意味着 T_1 有更大的方差。

这说明 T_2 虽然是边缘意义下的辅助统计量, 但在条件意义下仍提供关于估计精度的信息。

这种情况在实际中很重要: 当样本来自非正态分布时, 样本均值 $\bar{X}$ 和样本方差 S^2 可能相关, S^2 的值能提供关于 $\bar{X}$ 精度的信息。

本节小结.

- *Basu* 定理：完备充分统计量与任何辅助统计量独立
- 独立性证明的新工具：无需计算联合分布
- 若充分统计量非完备，辅助统计量可能携带条件信息
- 这解释了为什么正态分布中 $\bar{X}$ 与 S^2 的独立性如此特别

ANOVA and Regression

Chapter 9 Overview

在前几章中，我们讨论了来自单个总体的样本推断，以及两个总体的比较。但实际中，我们常常面临更复杂的问题：

如果有三个、四个甚至更多个总体，我们该如何比较它们的均值？

这个问题——即**多组比较问题**——在农业实验、医学试验、工业质量控制等领域无处不在。例如，在一项评估不同肥料对作物产量影响的实验中，我们需要同时比较多个处理组；而在研究药物疗效时，我们可能需要同时评估多种药物的效果。

本章，我们从单样本 t 检验 $\rightarrow$ 两样本 t 检验 $\rightarrow$ 多组比较的自然推广，引入**方差分析 (Analysis of Variance, 简称 ANOVA)**。这一方法由 *Ronald Fisher* 在 1920 年代创立，起源于他在英国洛桑农业实验站的农业实验研究。*Fisher* 的核心思想是：将总变异分解为可解释的变异和随机误差，通过比较两者来判断处理效应是否显著。

本章路线图：

- (1) *One-Way ANOVA* $\rightarrow$ 组间/组内平方和分解 $\rightarrow F$ 检验
- (2) 非中心 χ^2 和 F 分布 $\rightarrow$ 备择假设下的分布
- (3) *Multiple Comparisons* $\rightarrow$ *Tukey* 法、*Bonferroni* 法 (控制族误差率)
- (4) *Two-Way ANOVA* $\rightarrow$ 主效应、交互效应
- (5) 回归问题 $\rightarrow$ 最小二乘估计、几何解释 (投影)
- (6) 二次型分布 $\rightarrow$ *Cochran* 定理——平方和分解的理论基础

1. 9.1 Introduction

在正式进入 ANOVA 之前，我们需要介绍一个重要的数学工具——**二次型 (quadratic form)**。

DEFINITION 8.1 (二次型). 设 $X_1, \dots, X_n$ 是 n 个变量, a_{ij} 是常数。形如

$$q(X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^n X_i a_{ij} X_j$$

的表达式称为 $X_1, \dots, X_n$ 的 (二次) 二次型。

为什么二次型重要? 在统计推断中，许多关键的统计量都可以表示为二次型。例如，样本方差

$$(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

就是关于样本 $X_1, \dots, X_n$ 的一个二次型。理解二次型的分布性质, 是理解 ANOVA 和回归分析的理论基础。

2. 9.2 One-Way ANOVA

2.1. 问题的引入. 考虑 b 个独立的正态总体, 第 j 个总体的均值为 μ_j , 共同方差为 σ^2 。从第 j 个总体中抽取容量为 n_j 的随机样本 $X_{1j}, X_{2j}, \dots, X_{n_jj}$ 。记总样本量为 $n = \sum_{j=1}^b n_j$ 。

模型为:

$$X_{ij} = \mu_j + e_{ij}, \quad i = 1, \dots, n_j, \quad j = 1, \dots, b, \quad (9.2.1)$$

其中 e_{ij} 是 $iid N(0, \sigma^2)$ 随机误差。

我们想检验: 所有 b 个总体的均值是否相等——

$$H_0: \mu_1 = \mu_2 = \dots = \mu_b \quad vs \quad H_1: \mu_j \neq \mu_{j'} \text{ 对某些 } j \neq j'. \quad (9.2.2)$$

实际背景: 例如, b 种药物对某种疾病的疗效比较; 或 b 种肥料对作物产量的影响。这里“一种因素 (factor)”处于 b 个“水平 (level)”, 因此称为单因素实验 (*one-way layout*)。

2.2. 似然比检验的推导. 完全模型 (*full model*) 参数空间:

$$\Omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : -\infty < \mu_j < \infty, \quad 0 < \sigma^2 < \infty\}.$$

约束模型 (*reduced model*) 参数空间 (H_0 下):

$$\omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : \mu_1 = \dots = \mu_b = \mu, \quad 0 < \sigma^2 < \infty\}.$$

完全模型下的 MLE:

$$\hat{\mu}_j = \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\Omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2. \quad (9.2.7)$$

约束模型下的 MLE (此时等价于单样本问题):

$$\hat{\mu}_\omega = \bar{X}_{\cdot\cdot} = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.3)$$

似然比统计量简化后的形式为:

$$\Lambda^{n/2} = \frac{\hat{\sigma}_\Omega^2}{\hat{\sigma}_\omega^2}. \quad (9.2.9)$$

拒绝 H_0 等价于 F 统计量过大, 其中

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)}, \quad (9.2.11)$$

而

$$Q_3 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2, \quad Q_4 = \sum_{j=1}^b n_j (\bar{X}_{\cdot j} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.10)$$

核心分解:

$$\underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2}_Q = \underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}_{Q_3(\text{组内})} + \underbrace{\sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2}_{Q_4(\text{组间})}. \quad (9.2.10)$$

在 H_0 下, $Q_3/\sigma^2 \sim \chi^2(n-b)$, $Q_4/\sigma^2 \sim \chi^2(b-1)$, 且二者独立。因此 $F \sim F(b-1, n-b)$ 。

2.3. ANOVA 表格. 单因素 ANOVA 的结果可以汇总为一张清晰的表格:

表 1. 单因素 ANOVA 表格

来源	平方和 (SS)	df	均方 (MS)	F 统计量	p 值
组间 (<i>Between</i>)	Q_4	$b-1$	$MSB = Q_4/(b-1)$	$\frac{MSB}{MSW}$	$\mathbb{P}(F > F_0)$
组内 (<i>Within</i>)	Q_3	$n-b$	$MSW = Q_3/(n-b)$		
总计 (<i>Total</i>)	Q	$n-1$			

EXAMPLE 8.1 (合金弹性模量). Devore (2012, 第 412 页) 报告了一项数据: 三种铸造工艺 (永久模具、压铸、石膏模具) 生产合金的弹性模量。三种工艺各有多次测量, 我们想知道铸造工艺是否显著影响弹性模量。

数据汇总后, $F = 12.565$, 自由度为 2 和 19, p 值为 0.0003。如此小的 p 值表明: 铸造工艺对弹性模量有显著影响。¹

3. 9.3 Noncentral χ^2 and F Distributions

3.1. 为什么需要非中心分布? 在前一节的 ANOVA 中, 我们在原假设 H_0 下推导了 F 统计量的分布。但在实际应用中, 我们更关心: 当 H_0 不成立 (即各组均值不全相等) 时, F 统计量的分布是什么? 这时就需要引入非中心 χ^2 分布和非中心 F 分布。

DEFINITION 8.2 (非中心 χ^2 分布). 设 $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, \dots, n$, 独立。则

$$Y = \sum_{i=1}^n \frac{X_i^2}{\sigma^2}$$

的 mgf 为

$$M(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}, \quad t < \frac{1}{2}. \quad (9.3.1)$$

此时称 $Y \sim \chi^2(r, \theta)$, 其中 $r = n$ 是自由度, $\theta = \sum_{i=1}^n \mu_i^2 / \sigma^2$ 是非中心参数 (*noncentrality parameter*)。

直观理解: 当所有 $\mu_i = 0$ 时, $\theta = 0$, 回到中心 χ^2 分布; 当某些 $\mu_i \neq 0$ 时, Y 的分布在中心 χ^2 的基础上向右偏移, θ 越大, 偏移越明显。

非中心 χ^2 分布的均值: $E(Y) = r + \theta$ (中心部分 r 加上非中心部分 θ)。

¹该例子的详细计算与 R 代码实现见附录 ??。

DEFINITION 8.3 (非中心 F 分布). 设 $U \sim \chi^2(r_1, \theta)$, $V \sim \chi^2(r_2)$, 独立。则

$$F = \frac{r_2 U}{r_1 V}$$

服从自由度为 r_1, r_2 、非中心参数为 θ 的非中心 F 分布, 记作 $F(r_1, r_2, \theta)$ 。

EXAMPLE 8.2 (One-Way ANOVA 的非中心参数). 对于 one-way ANOVA 模型 (9.2.1), 在备择假设 H_1 下, F 统计量的分子 $Q_4/\sigma^2 \sim \chi^2(b-1, \theta)$, 其中

$$\theta = \frac{1}{\sigma^2} \sum_{j=1}^b n_j (\mu_j - \bar{\mu})^2, \quad \bar{\mu} = \frac{1}{n} \sum_{j=1}^b n_j \mu_j. \quad (9.3.5)$$

当 H_0 成立时, $\theta = 0$, 回到中心 F 分布; 当 H_1 成立时, $\theta > 0$, F 分布向右偏移, 偏移程度由 θ 刻画。这解释了为什么 F 检验在 H_0 不成立时倾向于取更大的值。²

4. 9.4 Multiple Comparisons

当 one-way ANOVA 的 F 检验拒绝了 H_0 后, 我们自然想知道: 具体哪些组之间存在显著差异? 这就是多重比较问题 (*Multiple Comparison Problem, MCP*)。

4.1. 问题的核心矛盾. 对 b 个总体, 若进行所有 $\binom{b}{2}$ 个成对比较, 即使每个置信区间的置信水平为 95%, 整体的置信水平也会急剧下降。举例来说, 若 $b = 5$, 则共有 10 个成对比较, 每个比较犯错的概率为 5%, 至少有一次犯错的概率粗略估计为 $1 - (0.95)^{10} \approx 40\%$ 。

因此, 我们需要专门设计的方法来**控制族误差率** (*Family-Wise Error Rate, FWER*) ——即在所有比较中至少有一次犯错的概率。

4.2. Bonferroni 方法. Bonferroni 方法基于一个简单的不等式: 对 k 个参数 θ_i , 若每个区间 I_i 的置信水平为 $1 - \alpha$, 则

$$P(\text{所有 } \theta_i \in I_i) \geq 1 - k\alpha. \quad (9.4.2)$$

核心思想: 将每个区间的置信水平从 $1 - \alpha$ 调整为 $1 - \alpha/k$, 则整体的置信水平至少为 $1 - \alpha$ 。

对 one-way ANOVA, 成对差值 $\mu_j - \mu_{j'}$ 的 Bonferroni 置信区间为:

$$\bar{X}_{\cdot j} - \bar{X}_{\cdot j'} \pm t_{\alpha/(2k), n-b} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.3)$$

优点: 通用性强, 适用于任何成对比较。**缺点:** 比较数量 k 越大, 区间越宽, 精度损失越大。

²非中心 F 分布的完整推导见附录 ??。

4.3. Tukey 方法. *Tukey* 方法利用学生化极差分布 (*Studentized range distribution*), 专为 *balanced* 设计的成对比较设计。

当所有组样本容量相等 ($n_j = a, j = 1, \dots, b$) 时, 所有成对比较的同时置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm q_{1-\alpha, b, n-b} \frac{\hat{\sigma}_{\Omega}}{\sqrt{a}}, \quad \forall j \neq j'. \quad (9.4.4)$$

其中 $q_{1-\alpha, b, n-b}$ 是自由度为 b 和 $n-b$ 的学生化极差分布分位数。

对于 *unbalanced* 情形, 使用 *Tukey-Kramer* 修正:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm \frac{q_{1-\alpha, b, n-b}}{\sqrt{2}} \hat{\sigma}_{\Omega} \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.5)$$

EXAMPLE 8.3 (赛车速度比较). *Kitchens (1997)* 报告了一项实验: 比较五种汽车 (*Acura, Ferrari, Lotus, Porsche, Viper*) 的最高速度。每种车进行 6 次运行测试。整体 F 检验高度显著 ($F = 25.15, p \approx 0$)。Tukey 多重比较结果表明: *Ferrari* 和 *Porsche* 的平均速度显著快于其他三种车, 但 *Ferrari* 与 *Porsche* 之间速度差异不显著。³

4.4. Fisher 的保护 LSD 方法. *Fisher* 方法是一个两步程序:

- (1) 首先进行整体 F 检验; 若拒绝 H_0 ,
- (2) 再使用标准的成对 t 置信区间 (置信水平 $1 - \alpha$)。

Fisher 方法不保证整体覆盖率为 $1 - \alpha$, 但 F 检验提供了“保护”。模拟研究表明它在功效和实际误差率方面表现良好。

5. 9.5 Two-Way ANOVA

5.1. 双因素实验的引入. 在实际研究中, 我们常常需要同时考虑两个因素对结果的影响。例如:

- 作物产量: 同时受品种 (因素 A) 和肥料类型 (因素 B) 的影响
- 考试成绩: 同时受教学方法 (因素 A) 和班级规模 (因素 B) 的影响

这就是双因素方差分析 (*two-way ANOVA*)。

设因素 A 有 a 个水平, 因素 B 有 b 个水平, 每个组合有一个观测值 X_{ij} 。模型为:

$$X_{ij} = \mu + \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b, \quad (9.5.2)$$

其中 $e_{ij} \sim N(0, \sigma^2)$ iid, 且 $\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0$ 。

可加模型 (*additive model*) 意味着两个因素的影响是相互独立的——因素 A 的效应不随因素 B 的水平变化。

表 2. 双因素可加模型的单元格均值示例 ($a = 2, b = 3$)

	$B=1$	$B=2$	$B=3$
$A=1$	7	6	5
$A=2$	5	4	3

³该例子的 R 实现与详细结果分析见附录 ??。

在可加模型中，行均值轮廓线是**平行的**——这是可加模型的重要特征。

5.2. 假设检验. 我们需要检验两个主效应假设：

$$H_{0A} : \alpha_1 = \cdots = \alpha_a = 0 \quad vs \quad H_{1A} : \text{某些 } \alpha_i \neq 0, \quad (9.5.3)$$

$$H_{0B} : \beta_1 = \cdots = \beta_b = 0 \quad vs \quad H_{1B} : \text{某些 } \beta_j \neq 0. \quad (9.5.4)$$

检验 H_{0B} 的 F 统计量：

$$F_B = \frac{a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 / (b-1)}{\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2 / [(a-1)(b-1)]}. \quad (9.5.12)$$

在 H_{0B} 下， $F_B \sim F(b-1, (a-1)(b-1))$ 。

类似地，检验 H_{0A} 的 F 统计量 $F_A \sim F(a-1, (a-1)(b-1))$ 。

5.3. 9.5.1 Interaction between Factors. 交互效应发生在：一个因素的影响程度取决于另一个因素的水平时。

在模型中引入交互参数 γ_{ij} ：

$$\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij}, \quad (9.5.15)$$

其中 $\sum_i \gamma_{ij} = \sum_j \gamma_{ij} = 0$ 。

若所有 $\gamma_{ij} = 0$ ，则回到可加模型；若存在非零 γ_{ij} ，则两个因素之间存在**交互作用**。

图形诊断：在双因素实验中，绘制各行（因素 A 各水平）的均值轮廓线。若线条大致平行，则交互作用不明显；若线条明显交叉或分离，则表明存在交互效应。

EXAMPLE 8.4 (沥青混合料热导率). Devore (2012, 第 435 页) 研究了两个因素对沥青混合料热导率的影响：粘结剂等级 (PG58, PG64, PG70) 和粗骨料含量 (38%, 41%, 44%)。每个处理组合有 2 次重复。

R 分析结果：交互效应不显著 ($p = 0.4135$)，但两个主效应都非常显著 ($p = 0.0017$ 和 $p < 10^{-5}$)。因此接受可加模型，两个因素独立地影响热导率。⁴

6. 9.6 A Regression Problem

6.1. 为什么研究回归?. ANOVA 研究的是类别型 (categorical) 自变量对因变量的影响。但在许多实际问题中，自变量是连续型的。例如：

- 学生的学习时间 (连续) $\rightarrow$ 考试成绩
- 汽车的发动机排量 (连续) $\rightarrow$ 每加仑行驶里程
- 农作物的施肥量 (连续) $\rightarrow$ 作物产量

这就引出了**回归分析 (regression analysis)**——研究自变量 (通常记作 x) 与因变量 Y 之间关系的方法。

线性模型：假设 $E(Y) = \mu(x)$ 是 x 的线性函数——

$$Y_i = \alpha + \beta(x_i - \bar{x}) + e_i, \quad i = 1, \dots, n, \quad (9.6.1)$$

⁴该例子的详细 ANOVA 表和 R 代码见附录 ??。

其中 $e_i \sim N(0, \sigma^2)$ iid。

为什么假设 x 是已知的非随机变量？这是为了简化分析——我们把不确定性全部放在 Y 上。在实际中，如果 x 也是随机的，则需要联合分布建模；但在受控实验或观测研究中，将 x 视为固定设计点是合理的近似。

线性模型 vs 非线性模型：这里“线性”指的是对参数 (α, β) 线性，而非对 x 线性。因此 $\alpha + \beta x + \gamma x^2$ 仍是线性模型，而 $\alpha e^{\beta x}$ 不是。

6.2. 9.6.1 Maximum Likelihood Estimates. 对模型 (9.6.1)，似然函数为

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{[Y_i - \alpha - \beta(x_i - \bar{x})]^2}{2\sigma^2} \right\}. \quad (9.6.12)$$

最大化似然等价于最小化

$$H(\alpha, \beta) = \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2. \quad (9.6.3)$$

这正是最小二乘法 (*least squares*) ——选择使残差平方和最小的 α, β 。

几何直观： $|Y_i - \alpha - \beta(x_i - \bar{x})|$ 是点 (x_i, Y_i) 到直线 $y = \alpha + \beta(x - \bar{x})$ 的垂直距离。最小二乘法就是找到使所有这些距离平方和最小的直线。

MLE 的解：

$$\hat{\alpha} = \bar{Y}, \quad (9.6.3)$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (9.6.5)$$

$\hat{\sigma}^2$ 的 MLE:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2. \quad (9.6.8)$$

拟合值与残差：

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}(x_i - \bar{x}), \quad \hat{e}_i = Y_i - \hat{Y}_i. \quad (9.6.6)$$

估计量的分布：可以证明

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{pmatrix} \right). \quad (9.6.9)$$

EXAMPLE 8.5 (男子 1500 米奥运会成绩). 考虑 27 届奥运会男子 1500 米冠军成绩与年份的关系。年份为自变量 x ，时间为因变量 Y 。

R 拟合结果： $\hat{y} = 12.33 - 0.0044 \times \text{year}$ 。斜率的 95% 置信区间为 $(-0.00547, -0.00328)$ ——这意味着每年获胜时间平均减少约 0.004 分钟 (约 0.24 秒)。对 2020 年奥运会的预测时间约为 3.486 分钟。⁵

残差图诊断：在回归分析中，绘制残差 $\hat{e}_i$ vs 拟合值 $\hat{Y}_i$ 的散点图。如果图呈现随机散布，说明模型是合理的；如果出现系统模式 (如 U 形、漏斗形)，则提示模型设定有问题 (如遗漏非线性项、异方差等)。

⁵该例子的详细计算、残差图分析和预测区间见附录 ??。

6.3. 9.6.2 *Geometry of the Least Squares Fit. 最小二乘拟合有一个优美的几何解释。

将数据写成向量形式 $\mathbf{Y} = (Y_1, \dots, Y_n)'$, 设计矩阵 $\mathbf{X}$ 的列为 $\mathbf{1}$ 和 $\mathbf{x}_c = (x_1 - \bar{x}, \dots, x_n - \bar{x})'$ 。模型为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}). \quad (9.6.13)$$

设 V 为 $\mathbf{X}$ 列张成的 $\mathbb{R}^n$ 中的二维子空间 (拟合空间)。最小二乘估计 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 正是 $\mathbf{Y}$ 在子空间 V 上的正交投影——即使得 $\|\mathbf{Y} - \boldsymbol{\theta}\|^2$ 最小的 V 中元素。

几何分解:

$$\|\mathbf{Y}\|^2 = \|\hat{\boldsymbol{\theta}}\|^2 + \|\hat{\mathbf{e}}\|^2,$$

其中 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 是残差向量, 且 $\hat{\boldsymbol{\theta}} \perp \hat{\mathbf{e}}$ (残差与拟合空间正交)。这正是 ANOVA 中平方和分解的几何版本。

7. 9.7 A Test of Independence

在许多应用中, 我们需要检验两个连续变量 X 和 Y 是否独立。对于二元正态分布, X 和 Y 独立当且仅当它们的相关系数 $\rho = 0$ 。因此我们检验:

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0. \quad (9.7.1)$$

样本相关系数:

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}. \quad (9.7.1)$$

关键定理: 在 H_0 下 (即 $\rho = 0$ 时), R 的分布不依赖于 X 的具体分布——只要 X 与 Y 独立, R 的分布在正态情况下就有上式 (9.3.1) 给出的精确形式。特别是,

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t(n-2). \quad (9.7.3)$$

因此, H_0 的拒绝域为 $|T| \geq t_{\alpha/2, n-2}$, 或等价地 $|R| \geq c$ 。

Remark 的深层含义: R 的条件分布 (在给定 $X_1, \dots, X_n$ 下) 不依赖于 X_i 的具体值, 这意味着 R 与所有仅依赖于 X 的统计量独立。这是一个非常优雅的性质——样本相关系数在 $\rho = 0$ 时“不受” X 取值的影响。

8. 9.8 Distributions of Certain Quadratic Forms

前几节的分析依赖于一个共同的理论支柱: 某些二次型服从 χ^2 分布, 且它们相互独立。本节和下一节建立这一理论的严格基础。

设 $\mathbf{X}' = (X_1, \dots, X_n)$, 其中 $X_i \sim N(\mu_i, \sigma^2)$ iid。二次型 $Q = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}$ 的 mgf 为:

$$M_Q(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}. \quad (9.8.10)$$

特别地, 若 $\mathbf{A}$ 是对称幂等矩阵 ($\mathbf{A}^2 = \mathbf{A}$), 则 $Q \sim \chi^2(r, \theta)$, 其中 $r = \text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A})$, $\theta = \boldsymbol{\mu}' \mathbf{A} \boldsymbol{\mu} / \sigma^2$ 。若进一步 $\boldsymbol{\mu} = \mu \mathbf{1}$ 且 $\sum_{i,j} a_{ij} = 0$, 则 $\theta = 0$, Q 为中心 $\chi^2(r)$ 。

Cochran 定理的特例：若 $Q_1, \dots, Q_k$ 是相互独立的 χ^2 变量之和，且 $\sum \text{rank}(Q_i) = n$ ，则各 Q_i 独立。

9. 9.9 The Independence of Certain Quadratic Forms

最后一个理论工具：*Craig* 定理，给出了两个二次型独立的充要条件。

THEOREM 8.1 (Craig). 设 $\mathbf{X} \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$ 。对对称矩阵 $\mathbf{A}, \mathbf{B}$ ，令

$$Q_1 = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}, \quad Q_2 = \sigma^{-2} \mathbf{X}' \mathbf{B} \mathbf{X}.$$

则 Q_1 与 Q_2 独立当且仅当 $\mathbf{AB} = \mathbf{0}$ 。

这个定理在 ANOVA 中有重要应用：在 *one-way ANOVA* 中，组间平方和 Q_4 （对应某个幂等矩阵）与组内平方和 Q_3 （对应另一个幂等矩阵）满足 $\mathbf{AB} = \mathbf{0}$ ，因此独立——这正是 F 检验的理论基础。

推论：在回归模型中，拟合值的二次型与残差的二次型相互独立，反映了“被解释的变异”与“未被解释的变异”之间的正交性。

附录：公式推导

One-Way ANOVA 平方和恒等式的证明。背景：在 *one-way ANOVA* 中，总平方和 Q 可以分解为组内平方和 Q_3 与组间平方和 Q_4 之和。这一恒等式是 F 检验的基石。

目标：证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2.$$

推导：记 $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和：

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零，因为对每个固定的 j ，

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。 □

One-Way ANOVA 检验统计量的分布. 背景: 推导 *one-way ANOVA* 中 F 统计量在原假设下的分布。

目标: 证明在 H_0 下, $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导:

步骤 1: Q_3 的分布。对每个固定的 j , 由样本方差性质, $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立, 故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2 \left(\sum_{j=1}^b (n_j - 1) \right) = \chi^2(n-b).$$

步骤 2: Q_4 与 Q_3 的独立性。注意 $\bar{X}_{.j}$ 与 Q_3 独立 (由正态样本的性质), 且 $\bar{X}_{..}$ 是 $\bar{X}_{.1}, \dots, \bar{X}_{.b}$ 的线性组合, 因此 $\bar{X}_{..}$ 也与 Q_3 独立。故 Q_4 ($\bar{X}_{.j}$ 的函数) 与 Q_3 独立。

步骤 3: Q_4 的分布。在 H_0 下, $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$, 故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各 $\bar{X}_{.j}$ 通过 $\bar{X}_{..}$ 而不独立。直接计算知 $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

步骤 4: F 分布。由步骤 1、2、3 及 F 分布定义,

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b). \quad (\text{A9.3})$$

□

非中心 χ^2 分布的均值和方差. 背景: 验证非中心 χ^2 分布的基本性质。

已知: $Y \sim \chi^2(r, \theta)$, *mgf* 为 $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。

目标: 求 $E(Y)$ 和 $\text{var}(Y)$ 。

推导:

由 *mgf*, $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。对 $M(t)$ 求导:

$$M'(t) = \left[r(1-2t)^{-r/2-1} + \frac{r\theta}{(1-2t)^{r/2+1}} \right] \exp \left\{ \frac{t\theta}{1-2t} \right\}.$$

故 $E(Y) = M'(0) = r + \theta$ 。

对 $M''(t)$ 在 $t=0$ 求值, 可得 $\text{var}(Y) = 2(r + 2\theta)$ 。⁶

最小二乘估计的几何解释. 背景: 回归最小二乘估计的正交投影几何。

目标: 证明 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是 $\mathbf{Y}$ 在 $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$ 上的正交投影。

推导: 由正交投影的定义, $\hat{\boldsymbol{\theta}}$ 满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}_c$ 都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0. \quad (\text{A9.4})$$

由 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 得 $\sum_i \hat{e}_i = 0$ (残差之和为零)。

⁶该推导的详细计算见附录 ??。

由 $\mathbf{x}'_c \hat{\mathbf{e}} = 0$ 并利用正规方程，可解出 $\hat{\alpha}$ 和 $\hat{\beta}$ 的表达式与 (9.6.3)、(9.6.5) 一致。故 $\hat{\boldsymbol{\theta}}$ 确为正交投影。 $\square$

附录：公式推导

0.1. Gamma 分布的矩母函数推导. 背景 (Background) : 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions) :

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given) :

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal) : 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps) :

1. 根据矩母函数定义:

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换: 令 $y = \frac{x(1-\beta t)}{\beta}$, 则 $x = \frac{\beta y}{1-\beta t}$, $dx = \frac{\beta}{1-\beta t} dy$ 。

3. 代入积分 (要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$):

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论: 因此, $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$, 定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background) : 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$, 方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given) :

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (*degrees of freedom*)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 *cdf* 出发, 对 x_2 求导得到联合 *pdf*:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 *cdf* 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 *cdf* 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 *Leibniz* 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 *pdf* 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

0.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证: 边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$, 确实是合法的 pdf。

结论: 条件 pdf 公式得证。■

0.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发:

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望 (即关于 X_1 求平均):

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论: 全期望公式得证。■

0.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论: 条件均值的方差不超过原变量的方差, 等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

0.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论: 故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.11. 相关系数范围的推导. 背景 (Background): 我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 *Cauchy-Schwarz* 不等式证明。

目标 (Goal): 证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps):

1. *Cauchy-Schwarz* 不等式: 对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差, 令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$:

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方:

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此:

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论: 故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

0.12. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.14. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.15. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 *mgf* 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. *pmf* 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. *mgf* 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 *mgf* 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.16. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j | Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 *pmf*:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j | Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.17. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。

2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.18. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。

2. 则 $X = \sum_{j=1}^n I_j$ 。

3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。

4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.19. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1 - p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1) \cdots (n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} \rightarrow 1, \\ \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.20. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数:

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论： *Poisson* 分布的均值和方差相等，都等于参数 λ 。■

0.21. 卡方分布与正态分布的关系. 背景 (Background): 卡方分布定义为标准正态平方和。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, 则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps):

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$, 先求 cdf:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式:

$$f_Y(y) = \frac{1}{\Gamma(1/2) 2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论： 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.22. 卡方分布的可加性证明. 背景 (Background): 卡方分布满足可加性: 独立卡方变量之和仍为卡方分布。

目标 (Goal): 证明若 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立, 则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps):

1. 由卡方分布与 Gamma 分布的关系: $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性 (见定理 3.3.1): 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此:

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf: $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$, 故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论： 卡方分布具有可加性, 自由度可累加。■

0.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1 + X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.24. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.25. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 *mgf* 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 *mgf*:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 *mgf* 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.26. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 *mgf* 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}[e^{(t/\sigma)X}] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 *mgf*, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.27. t 分布的推导. 背景 (*Background*): t 分布由标准正态和卡方分布构造而来。

目标 (*Goal*): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (*Derivation Steps*):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. *Jacobian*: $|J| = \sqrt{u/n}$ 。

3. 联合 *pdf*:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 *pdf* 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是固定（但未知）的常数，而区间 $[L, U]$ 是随机的（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何单次观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是频率派概念，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1: 硬币抛掷 (Bernoulli 分布) —— Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5”的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1”的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在观测数据之前对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) 主观贝叶斯视角: 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) 客观贝叶斯视角: 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (<i>Prior</i>)	后验 (<i>Posterior</i>)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 *Chapter 4* 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于非参数方法 (*Nonparametric Methods*)
- 在 *Chapter 4* 的 §4.1.2 有简要提及 (直方图估计)
- 深入讨论在 *Chapter 10* (*Nonparametric Methods*)

简单区分：

场景	方法	章节
分布形式未知	非参数方法 (直方图、核密度估计)	<i>Chapter 10</i>
分布形式已知、参数未知	参数方法 (<i>MLE</i> 、 <i>CI</i> 、检验)	<i>Chapter 4</i>

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个承上启下的关键过渡。

1. 防止误解：学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
2. 揭示张力：无偏性只是一个基本要求，不是“最优性”的保证。无偏的估计量可以有有很多，且各有优劣。
3. 引出 *MLE*：正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计 (*MLE*) 被提出的动机。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 *MLE* 作为统一原则

具体例子：

- S^2 (无偏) 和 $\hat{\sigma}^2$ (有偏，但 *MLE*)
- 两者都常用，但各有用途
- “最优”需要更精确的定义 (后续章节的 *UMVUE*)

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 *Stein* 风格的典型特征，强调“为什么需要”而非直接罗列。

学习笔记.