

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;

1E/Æ

É ЪJm *!œ z	d
É ЪJm *!œ z	d
RX n ô! ¹Jr	d
kX Æ p μ (¬	d
jX ø g Ð á μ è ª	Ry
9Xz ¢ š ÷	Ry
8X £ ´	RR
*? Ti2`RX S`Q# #BHBiv M/ .Bbi`B#miBQMb	Rj
*? Ti2`R Pp2`pB2r	Rj
RX RXR AMi`Q/m+iBQM, q?v S`Q# #BHBiv h?2Q`v\	Rj
kX RXk a2ib, h?2 G M;m ;2 Q7 IM+2`i BMiv	R9
jX RXj h?2 S`Q# #BHBiv a2i 6mM+iBQM	R8
9X RX9 *QM/BiBQM H S`Q# #BHBiv M/ AM/2T2M/2M+2	R+8
8X RX8 _ M/QK o `B #H2b	Rd
eX RXe .Bb+`2i2 _ M/QK o `B #H2b	Rd
dX RXd *QM iBMmQmb _ M/QK o `B #H2b	RN
3X RX3 1tT2+i iBQM Q7 _ M/QK o `B #H2	kR
NX RXN aQK2 aT2+B H 1tT2+i iBQM b	kk
RyX RXRy AKTQ`i Mi AM2[m HBiB2b	k9
amKK `v	k8
1t2`+Bb2b	k8
RRX9Jm 4 Ô	kd
*? Ti2`kX œ8•õ74¿	j8
*? Ti2`!k	j8
RX kXÄÄ ú ÄJm>Á4¿	j8
kX kX% 4¿Jm i43 D	jd
jX kXijn 4¿Jm ž ¥ á c Ú	jN
9X k Xù9Jm 8•½ á ôj. • ô	98
8X kX 8m ö .> á ••	93
eX kXÄe nJm 73 ô á Ä4¿	8y
dX kXÄd 2	8k

3XÆÐ, ²	89
£	89
NX 9Jm 4 Ô	88
*? Ti2`jX aT2+B H .Bbi`B#miBQMb	ed
*? Ti2`j Pp2`pB2r	ed
RX jX Æ õ7 .4¿	ed
kX jXk SQ Æ bbQM	dk
jX jXj: K Æ ² "2i 4¿	d9
9X jX 9 ¿J[LQ`K H .Bbi` B #miBQM	dd
8X jX 8 n4¿	d3
eX jtX 4 ¿ F 4¿	dN
*? Ti2`9X aQK2 1H2K2Mi `v ai iBbiB+ H AM72`2M+2	Nd
*? Ti2`9 Pp2`pB2r	Nd
RX 9XR a KTHBM; M/ ai iBbiB+b	Nd
kX 9Xk *QM}/2M+2 AMi2`p Hb	Ryy
jX 9Xj P`/2` ai iBbiB+b	Ryk
9X 9X9 >vTQi?2bBb h2biBM;	Ryj
8X 9X8 *?B@a[m `2 h2bib	Ry9
eX 9Xe JQMi2 * `HQ J2i?Q/b	Ryd
dX 9Xd "QQibi` T J2i?Q/b	Ry3
1t2`+Bb2b	Ry3
ÆÐ) ²	Rkj
3X 9Jm 4 Ô	Rkj
*? Ti2`8X bvK TiQiB+ h?2Q`v	RkN
*? Ti2`8 Pp2`pB2r	RkN
RX 8XR *QMp2`;2M+2 BM S`Q# #BHBiv	RkN
kX 8Xk *QMp2`;2M+2 BM .Bbi`B#miBQM	Rjk
jX 8Xj *2Mi` H GBKBi h?2Q`2K	Rje
9X 8X9 1ti2MbBQMbiQ JmHiBp `B i2 .Bbi`B#miBQM	Rjd
1t2`+Bb2b	Rj3
ÆÐ) ²	R9k
8X 9Jm 4 Ô	R9k
*? Ti2`eX J tBKmK GBF2HB?QQ/ J2i?Q/b	R8R
*? Ti2`e Pp2`pB2r	R8R
RX eXR J tBKmK GBF2HB?QQ/ 1biBK iBQM	R8R
kX eXk _ Q@*` Kû` GQr2` "QmM/ M/ 1{+B2M+v	R8j
jX eXj J tBKmK GBF2HB?QQ/ h2bib	R8d

9X	eX9 JmHiBT ` K2i2` * b2, 1biBK iBQM	R83
8X	eX8 JmHiBT ` K2i2` * b2, h2biBM;	ReR
eX	eXe h?2 1J H;Q`Bi?K	Rek
dX	9Jm 4 Ô	Ree
*?	Ti2` dX am{+B2M+v M/ Zm HBiv Q7 1biBK iQ`b	ReN
*?	Ti2` d Pp2`pB2r	ReN
RX	dXR J2 bm`2b Q7 Zm HBiv Q7 1biBK iQ`b	ReN
kX	dXk am{+B2Mi ai iBbiB+ 7Q` S ` K2i2`	Rdy
jX	dXj S`QT2`iB2b Q7 am{+B2Mi ai iBbiB+	Rdj
9X	dX9 *QKTH2i2M2bb M/ lMB[m2M2bb	Rd9
8X	dX8 h?2 1tTQM2MiB H *H bb Q7 .Bbi`B#miBQMb	Rd8
eX	dXe 6mM+iBQMb Q7 S ` K2i2`	Rdd
dX	dXd h?2 * b2 Q7 a2p2` H S ` K2i2`b	Rd3
3X	dX3 JBMBK H am{+B2M+v M/ M+BHH `v ai iBbiB	RdN
NX	dXN am{+B2M+v- *QKTH2i2M2bb- M/ AM/2T2M/2M+2	R3y
ÆÐ £		R3k
*?	Ti2` 3X PTiBK H ai iBbiB+ H h2bib	R38
*?	Ti2` 3 Pp2`pB2r	R38
RX	3XR JQbi SQr2`7mH h2bib	R38
kX	3Xk lMB7Q`KHv JQbi SQr2`7mH h2bib	R3N
jX	3Xj GBF2HB?QQ/ _ iBQ h2bib	RNR
9X	3X9 a2[m2MiB H S`Q# #BHBiv _ iBQ h2bi	RN9
8X	3X8 JBMBK t M/ *H bbB}+ iBQM S`Q+2/m`2b	RNe
	9Jm 4 Ô	RN3
	1t2`+Bb2b	kyj
*?	Ti2` NX LPo M/ _2;`2bbBQM	kyj
*?	Ti2` N Pp2`pB2r	kyj
RX	NXR AMi`Q/m+iBQM	kyj
kX	NXk PM2@q v LPo	ky9
jX	NXj LQM+2MiF HBbi`B#miBQMb	ky8
9X	NX9 JmHiBTH2 *QKT `BbQMb	kye
8X	NX8 hrQ@q v LPo	kyd
eX	NXe _2;`2bbBQM S`Q#H2K	ky3
dX	NXd h2bi Q7 AM/2T2M/2M+2	kRy
3X	NX3 .Bbi`B#miBQMb Q7 *2`i BM Zm /` iB+ 6Q`K	kRy
NX	NXN h?2 AM/2T2M/2M+2 Q7 *2`i BM Zm /` iB+ 6Q`K	kRb
£		kRR

2.5. 渐近有效性. 由于有效估计量在有限样本下并不总是存在，我们引入渐近有效的概念。

DEFINITION 6.2 (渐近有效性). 设 $\hat{\theta}_n$ 是估计量序列，满足

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, \sigma_\theta^2).$$

则 $\hat{\theta}_n$ 的渐近效率 (*asymptotic efficiency*) 定义为

$$e(\hat{\theta}_n) = \frac{1/I(\theta_0)}{\sigma_\theta^2}. \quad (6.2.8)$$

若 $e(\hat{\theta}_n) = 1$ ，则称 $\hat{\theta}_n$ 是渐近有效的。

下面定理表明，在正则条件下，MLE 是渐近有效的。

heorem[MLE 的渐近正态性和有效性] 在正则条件 (R0)-(R5) 下，设 $\hat{\theta}_n$ 是似然方程的一致解序列。则

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N\left(0, \frac{1}{I(\theta_0)}\right). \quad (6.2.9)$$

heorem

证明思路：对数似然函数在 θ_0 处 Taylor 展开，利用大数定律和中心极限定理。⁷

这一定理意味着：**MLE 渐近地达到 Rao-Cramér 下界**。这是最大似然估计最重要的最优性结果。

2.6. 渐近相对效率. 在比较两个估计量时，渐近相对效率 (ARE) 提供了统一的标准。

DEFINITION 6.3 (渐近相对效率). 设 $\hat{\theta}_{1n}$ 和 $\hat{\theta}_{2n}$ 是两个渐近正态估计量，满足

$$\sqrt{n}(\hat{\theta}_{in} - \theta_0) \xrightarrow{D} N(0, \sigma_i^2), \quad i = 1, 2.$$

则 $\hat{\theta}_{1n}$ 相对于 $\hat{\theta}_{2n}$ 的 ARE 定义为

$$ARE(\hat{\theta}_{1n}, \hat{\theta}_{2n}) = \frac{\sigma_2^2}{\sigma_1^2}. \quad (6.2.10)$$

EXAMPLE 6.9 (中位数与均值的 ARE). 考虑位置模型 $X_i = \theta + e_i$:

- (a) 若 $e_i \sim \text{Laplace}(0, 1)$ ，则 MLE 是样本中位数 Q_2 ，信息 $I(\theta) = 1$ ，因此 $ARE(Q_2, \bar{X}) = 2$ 。这意味着在大样本下，中位数比均值更有效一倍！
- (b) 若 $e_i \sim N(0, 1)$ ，则 $ARE(Q_2, \bar{X}) = 2/\pi \approx 0.636$ 。此时均值更有效。

启示：没有“最优”的估计量——估计量的效率完全由真实分布决定。选择估计量时应该考虑数据的特点。

⁷MLE 渐近正态性的完整证明见附录 section 7.3。

2.7. Summary of Section 6.2.

- Fisher 信息量 $I(\theta) = \text{Var}(\partial \log f / \partial \theta)$ 衡量分布携带的关于 θ 的信息
- Rao-Cramér 下界: 任何无偏估计量 $\hat{\theta}$ 的方差满足 $\text{Var}(\hat{\theta}) \geq 1/[nI(\theta)]$
- 达到下界的估计量称为有效估计量 (如正态均值、二项比例的样本均值)
- 在正则条件下, MLE 是一致且渐近有效的: $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N(0, 1/I(\theta_0))$
- ARE 允许我们比较不同估计量的渐近效率

3. 6.3 Maximum Likelihood Tests

3.1. 从估计到检验. 我们已经建立了基于似然的点估计理论。现在问: 如何基于似然函数进行假设检验?

设 $X_1, \dots, X_n \sim f(x; \theta)$, 考虑双边假设

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta \neq \theta_0. \quad (6.3.1)$$

直觉告诉我们: 若 H_0 为真, 则似然函数在 θ_0 处应该接近最大值; 若 H_1 为真, 似然函数在 θ_0 处应该明显小于在 $\hat{\theta}$ 处。

定义似然比 (likelihood ratio):

$$\Lambda = \frac{L(\theta_0)}{L(\hat{\theta})}. \quad (6.3.2)$$

显然 $\Lambda \leq 1$ 。若 Λ 太小 (即 $L(\theta_0)$ 远小于 $L(\hat{\theta})$), 则拒绝 H_0 。

3.2. 似然比检验. 似然比检验(LRT): 拒绝 H_0 当且仅当 $\Lambda \leq c$, 其中 c 满足 $\alpha = \sup_{\theta \in \omega} \mathbb{P}_\theta(\Lambda \leq c)$

但通常我们关注简单原假设 $H_0: \theta = \theta_0$, 此时临界值由 $\mathbb{P}_{\theta_0}(\Lambda \leq c) = \alpha$ 确定。

EXAMPLE 6.10 (指数分布的 LRT). 设 $X_1, \dots, X_n \sim \text{Exp}(\theta)$, 密度 $f(x; \theta) = \theta^{-1}e^{-x/\theta}$, $x > 0$ 。

似然函数 $L(\theta) = \theta^{-n} \exp\{-n\bar{x}/\theta\}$ 。MLE 为 $\hat{\theta} = \bar{x}$ 。

似然比

$$\Lambda = e^n \left(\frac{\bar{x}}{\theta_0} \right)^n \exp\{-n\bar{x}/\theta_0\}.$$

可以证明, $\Lambda \leq c$ 等价于 $\bar{x}/\theta_0 \leq c_1$ 或 $\bar{x}/\theta_0 \geq c_2$ 。

注意: 当 H_0 为真时, $2n\bar{X}/\theta_0 \sim \chi^2(2n)$ 。因此临界值可从 χ^2 分布获得。⁸

EXAMPLE 6.11 (正态均值的 LRT). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, σ^2 已知。则

$$-2 \log \Lambda = \left(\frac{\bar{X} - \theta_0}{\sigma/\sqrt{n}} \right)^2 \sim \chi^2(1) \quad \text{under } H_0.$$

因此拒绝域为 $-2 \log \Lambda \geq \chi_\alpha^2(1)$ 。

这正是 Chapter 4 中的 z -test! 似然比检验统一了许多经典检验。

⁸指数分布似然比检验的详细推导见附录 ??。

3.3. 三大似然检验. 定理 6.3.1 揭示了似然比统计量在正则条件下的渐近分布。

heorem[似然比检验的渐近分布] 在正则条件下, 若 $H_0: \theta = \theta_0$ 为真, 则

$$-2 \log \Lambda \xrightarrow{D} \chi^2(1). \quad (6.3.3)$$

heorem

这一定理意味着: 对于任意分布, 在大样本下, 似然比检验都有渐近レベル α 。

除了似然比检验, 还有两种常用的似然型检验:

(1) **Wald 检验:** 基于 $\hat{\theta}$ 与 θ_0 的距离

$$\chi_W^2 = nI(\hat{\theta})(\hat{\theta} - \theta_0)^2 \xrightarrow{D} \chi^2(1). \quad (6.3.4)$$

(2) **Score 检验:** 基于得分函数在 θ_0 处的值

$$\chi_R^2 = \frac{[l'(\theta_0)]^2}{nI(\theta_0)} \xrightarrow{D} \chi^2(1). \quad (6.3.5)$$

三个统计量的关系: 当 n 足够大时, $\chi_L^2 \approx \chi_W^2 \approx \chi_R^2$ 。这三种检验在大样本下是等价的。

在实际中:

- 若已有 MLE, 使用 Wald 检验最方便
- 若求 MLE 困难, 但可计算得分, 使用 Score 检验
- 若两种都不方便, 使用似然比检验 (需要分别求限制和未限制的 MLE)

EXAMPLE 6.12 (正态方差的 Score 检验). 设 $X_1, \dots, X_n \sim N(\mu, \theta)$, μ 已知。要检验 $H_0: \theta = \theta_0$ 。

得分函数 $S(\theta) = \frac{1}{2} \sum (X_i - \mu)^2 - \frac{n\theta}{2\theta^2}$, 信息 $I(\theta) = 1/(2\theta^2)$ 。

Score 统计量 $\chi_R^2 = \frac{[\sum (X_i - \mu)^2 - n\theta_0]^2}{n\theta_0^2}$ 。

当 H_0 为真时, $\chi_R^2 \xrightarrow{D} \chi^2(1)$ 。

3.4. Summary of Section 6.3.

- 似然比检验拒绝 H_0 当 $\Lambda = L(\theta_0)/L(\hat{\theta}) \leq c$
- 三大似然检验: LRT、Wald 检验、Score 检验, 在大样本下都渐近服从 $\chi^2(1)$
- 对于正态均值检验, Wald 检验化为我们熟悉的 z -test
- 选择哪种检验取决于计算的便利性

4. 6.4 Multiparameter Case: Estimation

4.1. 为什么要考虑多参数? 实际统计问题中, 多数分布有多个参数。例如:

- 正态分布 $N(\mu, \sigma^2)$ 有两个参数: μ 和 σ^2
- Gamma 分布 $\Gamma(\alpha, \beta)$ 有两个参数
- 多项分布有 $k - 1$ 个参数

将 MLE 理论推广到多参数情形, 是理论完整性和实际应用的必然要求。

4.2. 多参数似然函数. 设 $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)' \in \Omega \subset \mathbb{R}^p$. 似然函数为

$$L(\boldsymbol{\theta}) = \prod_{i=1}^n f(x_i; \boldsymbol{\theta}), \quad l(\boldsymbol{\theta}) = \sum_{i=1}^n \log f(x_i; \boldsymbol{\theta}). \quad (6.4.1)$$

MLE $\hat{\boldsymbol{\theta}}$ 通过求解 Score 向量方程组得到:

$$\frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{0}. \quad (6.4.2)$$

EXAMPLE 6.13 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 参数 $\boldsymbol{\theta} = (\mu, \sigma^2)'$. 对数似然:

$$l(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

求偏导并令为零:

$$\begin{aligned} \frac{\partial l}{\partial \mu} &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{x}, \\ \frac{\partial l}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \end{aligned}$$

结论: 样本均值和样本方差 (除以 n) 是 MLE。

EXAMPLE 6.14 (Laplace 分布的 MLE). 设 $X_1, \dots, X_n \sim \text{Laplace}(a, b)$, 密度 $f(x) = \frac{1}{2b} \exp\{-|x - a|/b\}$, 参数 $\boldsymbol{\theta} = (a, b)'$.

MLE:

- 位置参数 a : $\hat{a} = Q_2$ (样本中位数), 与 b 无关
- 尺度参数 b : $\hat{b} = \frac{1}{n} \sum_{i=1}^n |X_i - Q_2|$

启示: 对于某些分布, 参数的 MLE 可以分别求解。

4.3. 信息矩阵. 在多参数情形, Fisher 信息由一个矩阵——信息矩阵 (information matrix) 给出:

$$\mathbf{I}(\boldsymbol{\theta}) = \text{Cov}(\nabla \log f(X; \boldsymbol{\theta})), \quad (6.4.3)$$

其中 $\nabla \log f = (\partial \log f / \partial \theta_1, \dots, \partial \log f / \partial \theta_p)'$.

信息矩阵的第 (j, k) 个元素为

$$I_{jk}(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial \log f}{\partial \theta_j} \cdot \frac{\partial \log f}{\partial \theta_k} \right] = -\mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial^2 \log f}{\partial \theta_j \partial \theta_k} \right]. \quad (6.4.4)$$

对于样本, 信息矩阵是单个样本信息的 n 倍: $\mathbf{I}_n(\boldsymbol{\theta}) = n\mathbf{I}(\boldsymbol{\theta})$ 。

EXAMPLE 6.15 (正态分布的信息矩阵). 设 $X \sim N(\mu, \sigma^2)$, 记 $\theta_1 = \mu$, $\theta_2 = \sigma^2$.

对数似然偏导数:

$$\frac{\partial \log f}{\partial \mu} = \frac{x - \mu}{\sigma^2}, \quad \frac{\partial \log f}{\partial \sigma^2} = -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2(\sigma^2)^2}.$$

计算二阶偏导数的期望，可得信息矩阵

$$\mathbf{I}(\mu, \sigma^2) = \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2(\sigma^2)^2} \end{pmatrix}. \quad (6.4.5)$$

注意对角线元素，这意味着 μ 和 σ^2 的信息在正态分布下是独立的！⁹

4.4. 多参数 Rao-Cramér 下界. 在多参数情形，单个参数 θ_j 的无偏估计量 $\hat{\theta}_j$ 满足

$$\text{Var}(\hat{\theta}_j) \geq \frac{1}{n} [\mathbf{I}^{-1}(\boldsymbol{\theta})]_{jj}. \quad (6.4.6)$$

特别地，当信息矩阵是对角矩阵时，每个参数的 Rao-Cramér 下界与其单参数情形相同。

EXAMPLE 6.16 (正态方差估计的效率). 对于 $N(\mu, \sigma^2)$ ，由信息矩阵可知 σ^2 的 Rao-Cramér 下界为 $2(\sigma^2)^2/n$ 。

样本方差 S^2 (无偏估计) 的方差为 $2(\sigma^2)^2/(n-1)$ ，因此不是有效的，但渐近有效。

4.5. 多参数 MLE 的渐近性质. theorem[多参数 MLE 的渐近分布] 在正则条件下，设 $\hat{\boldsymbol{\theta}}_n$ 是一致解序列。则

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}^{-1}(\boldsymbol{\theta}_0)). \quad (6.4.7)$$

theorem

含义：每个参数分量 $\hat{\theta}_{nj}$ 满足

$$\sqrt{n}(\hat{\theta}_{nj} - \theta_{0j}) \xrightarrow{D} N(0, [\mathbf{I}^{-1}(\boldsymbol{\theta}_0)]_{jj}),$$

即 $\hat{\theta}_{nj}$ 是渐近有效的。

对于参数函数 $g(\boldsymbol{\theta})$ ，由 Delta 方法可得类似结论。

EXAMPLE 6.17 (正态协方差矩阵估计). 设 $X_1, \dots, X_n \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。MLE 为样本均值 $\bar{X}$ 和样本协方差矩阵 $\mathbf{S} = \frac{1}{n} \sum (X_i - \bar{X})(X_i - \bar{X})'$ 。

可以证明 $\bar{X}$ 和 $\mathbf{S}$ 联合渐近正态，且达到信息矩阵下界。

4.6. Summary of Section 6.4.

- 多参数情形下，MLE 通过同时求解所有参数的 Score 方程得到
- 信息矩阵 $\mathbf{I}(\boldsymbol{\theta})$ 是 Fisher 信息在多参数情形下的推广
- Rao-Cramér 下界由信息矩阵的逆给出： $\text{Var}(\hat{\theta}_j) \geq \frac{1}{n} [\mathbf{I}^{-1}]_{jj}$
- 在正则条件下，多参数 MLE 联合渐近正态： $\sqrt{n}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}^{-1})$
- 信息矩阵的对角元素给出每个参数的独立信息

⁹正态分布信息矩阵的详细计算见附录 section 7.4。

5. 6.5 Multiparameter Case: Testing

5.1. 多参数假设检验的框架. 在多参数情形, 假设通常规定参数属于参数空间的某个子集。

设 $\Omega \subset \mathbb{R}^p$ 是完整的参数空间, $\omega \subset \Omega$ 是由 q 个约束定义的子空间。考虑假设

$$H_0: \boldsymbol{\theta} \in \omega \quad \text{vs} \quad H_1: \boldsymbol{\theta} \in \Omega \cap \omega^c. \quad (6.5.1)$$

例如, 对于 $N(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ 相当于检验约束 $\mu = \mu_0$ 下的子空间。

似然比检验推广为

$$\Lambda = \frac{\max_{\boldsymbol{\theta} \in \omega} L(\boldsymbol{\theta})}{\max_{\boldsymbol{\theta} \in \Omega} L(\boldsymbol{\theta})}. \quad (6.5.2)$$

定理 6.5.1 给出了其渐近分布。

heorem[多参数似然比检验的渐近分布] 在正则条件下, 若 H_0 由 q 个独立约束定义, 则

$$-2 \log \Lambda \xrightarrow{D} \chi^2(q). \quad (6.5.3)$$

heorem

含义: 渐近分布的自由度等于约束的个数, 而不是原始参数的个数。

EXAMPLE 6.18 (正态均值的检验). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ (σ^2 未知)。

全空间 $\Omega = \{(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$, 约束子空间 $\omega = \{(\mu_0, \sigma^2) : \sigma^2 > 0\}$ 。

似然比统计量简化为

$$\Lambda = \left(\frac{\sum (X_i - \bar{X})^2}{\sum (X_i - \mu_0)^2} \right)^{n/2}.$$

经过推导, $-2 \log \Lambda$ 等价于 t 统计量的平方:

$$-2 \log \Lambda = \frac{n(\bar{X} - \mu_0)^2}{\sum (X_i - \bar{X})^2 / (n-1)} \cdot (n-1) \sim \chi^2(1).$$

这与 t -test 完全一致!

启示: 对于正态分布, 似然比检验就是我们熟悉的 t 检验。

EXAMPLE 6.19 (二项比例的检验). 比较两个独立二项分布的比例 p_1 和 p_2 。设 $X \sim \text{Binomial}(n_1, p_1)$, $Y \sim \text{Binomial}(n_2, p_2)$, 检验 $H_0: p_1 = p_2$ 。

Wald 检验统计量:

$$\chi_W^2 = \frac{(\hat{p}_1 - \hat{p}_2)^2}{\hat{p}(1-\hat{p})(1/n_1 + 1/n_2)} \xrightarrow{D} \chi^2(1),$$

其中 $\hat{p} = (n_1 \hat{p}_1 + n_2 \hat{p}_2) / (n_1 + n_2)$ 是合并后的比例估计。

渐近置信区间：

$$\hat{p}_1 - \hat{p}_2 \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}.$$

三大检验的多参数推广：LRT、Wald、Score 检验都可以推广到多参数情形，在大样本下都渐近服从 $\chi^2(q)$ ，其中 q 是约束个数。

5.2. Summary of Section 6.5.

- 多参数假设检验考虑参数空间 Ω 的子空间 ω
- 似然比统计量渐近服从 $\chi^2(q)$ ，自由度 q 等于约束个数
- 正态均值的 t 检验是似然比检验的特例
- Wald 和 Score 检验提供渐近等价的替代方法
- 信息矩阵用于构造 Wald 统计量和置信域

6. 6.6 The EM Algorithm

6.1. 缺失数据问题的起源。在许多实际统计问题中，数据并非完全观测到。例如：

- **截断数据：**只观测到 $X > a$ 的个体
- **区间删失：**只知道 $L < X < R$ ，而不知道具体值
- **隐变量：**观测到 X ，但 X 依赖于某个不可观测的隐变量 Z
- **混合模型：**数据来自多个群体的混合，但我们不知道每个观测来自哪个群体

这些情况下的似然函数往往难以直接最大化。**EM 算法**提供了一种通用的迭代策略。

6.2. EM 算法的思想。EM 算法通过引入“缺失数据”（可以是真正的缺失值，也可以是隐变量）来简化似然函数。

设 $\mathbf{X}$ 是观测数据， $\mathbf{Z}$ 是缺失数据。完整数据 $(\mathbf{X}, \mathbf{Z})$ 的似然函数记为 $L^c(\theta|\mathbf{x}, \mathbf{z})$ 。

设 $\theta^{(m)}$ 是第 m 步的估计值。EM 算法执行两步迭代：

(1) **E 步 (Expectation)：**计算完整数据对数似然在当前估计 $\theta^{(m)}$ 下的条件期望

$$Q(\theta|\theta^{(m)}, \mathbf{x}) = \mathbb{E}_{\theta^{(m)}} [\log L^c(\theta|\mathbf{x}, \mathbf{Z}) | \theta^{(m)}, \mathbf{x}]. \quad (6.6.1)$$

(2) **M 步 (Maximization)：**找到使 Q 最大化的 θ

$$\theta^{(m+1)} = \arg \max_{\theta} Q(\theta|\theta^{(m)}, \mathbf{x}). \quad (6.6.2)$$

EM 算法保证：每一步迭代都使观测似然单调递增，即 $L(\theta^{(m+1)}|\mathbf{x}) \geq L(\theta^{(m)}|\mathbf{x})$ 。

heorem[EM 算法的单调性] 设 $\theta^{(m+1)}$ 由 E 步和 M 步得到。则

$$L(\theta^{(m+1)}|\mathbf{x}) \geq L(\theta^{(m)}|\mathbf{x}). \quad (6.6.3)$$

heorem

证明思路：利用 Q 函数的定义和 Jensen 不等式。¹⁰

¹⁰EM 算法单调性的完整证明见附录 section 7.5。

这一性质保证了算法的稳定性——不会发散到局部最大值以外。

EM 算法的直观理解：E 步”想象”缺失数据可能取的值，M 步在假设这些值已知的情况下更新参数估计。这两个步骤交替进行，直到收敛。

EXAMPLE 6.20 (正态分布的 EM 算法——缺失数据). 设 $X_1, \dots, X_{n_1} \sim N(\theta, 1)$ 观测到，同时 $Z_1, \dots, Z_{n_2} \sim N(\theta, 1)$ 截断于 a (即只知 $Z_j > a$)。

完整数据似然：

$$L^c(\theta) = \prod_{i=1}^{n_1} \phi(x_i - \theta) \prod_{j=1}^{n_2} \phi(z_j - \theta),$$

其中 ϕ 是标准正态密度。

E 步：需要计算 $\mathbb{E}[Z_j - \theta | Z_j > a, \theta^{(m)}]$ 。

设 $Y \sim N(\theta, 1)$ 截尾于 a ，则

$$\mathbb{E}[Y - \theta | Y > a] = \frac{\phi(a - \theta)}{1 - \Phi(a - \theta)}.$$

因此

$$\theta^{(m+1)} = \frac{n_1 \bar{x} + n_2 \theta^{(m)} + n_2 \frac{\phi(a - \theta^{(m)})}{1 - \Phi(a - \theta^{(m)})}}{n_1 + n_2}. \quad (6.6.4)$$

解释：新估计是样本均值、当前估计和截尾部分期望的加权平均。¹¹

EXAMPLE 6.21 (正态混合模型的 EM 算法). 设观测数据来自两个正态分布的混合：

$$X_i \sim (1 - \epsilon)N(\mu_1, \sigma_1^2) + \epsilon N(\mu_2, \sigma_2^2),$$

参数 $\theta = (\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \epsilon)'$ 。

引入隐变量 W_i ：若 X_i 来自第一个分布则 $W_i = 0$ ，否则 $W_i = 1$ 。

完整数据对数似然：

$$\log L^c = \sum_{i=1}^n [(1 - w_i) \log f_1(x_i) + w_i \log f_2(x_i)]. \quad (6.6.5)$$

E 步：计算 w_i 的后验概率

$$\gamma_i^{(m)} = \mathbb{P}(W_i = 1 | \theta^{(m)}, x_i) = \frac{\epsilon^{(m)} f_2(x_i | \theta^{(m)})}{(1 - \epsilon^{(m)}) f_1(x_i | \theta^{(m)}) + \epsilon^{(m)} f_2(x_i | \theta^{(m)})}. \quad (6.6.6)$$

M 步：更新参数

$$\begin{aligned} \hat{\mu}_1 &= \frac{\sum_{i=1}^n (1 - \gamma_i) x_i}{\sum_{i=1}^n (1 - \gamma_i)}, & \hat{\mu}_2 &= \frac{\sum_{i=1}^n \gamma_i x_i}{\sum_{i=1}^n \gamma_i}, \\ \hat{\sigma}_1^2 &= \frac{\sum_{i=1}^n (1 - \gamma_i) (x_i - \hat{\mu}_1)^2}{\sum_{i=1}^n (1 - \gamma_i)}, & \hat{\sigma}_2^2 &= \frac{\sum_{i=1}^n \gamma_i (x_i - \hat{\mu}_2)^2}{\sum_{i=1}^n \gamma_i}, \\ \hat{\epsilon} &= \frac{1}{n} \sum_{i=1}^n \gamma_i. \end{aligned} \quad (6.6.7)$$

直观解释：E 步根据当前参数估计每个观测来自各成分的概率；M 步根据这些概率重新估计各成分的参数。这等价于”软聚类”然后重新估计。

¹¹正态截尾数据的 EM 算法详细推导见附录 ??。

6.3. EM 算法的收敛性. EM 算法的收敛性由以下事实保证：

- 观测似然 $L(\theta|\mathbf{x})$ 在每一步都单调不降
- $L(\theta|\mathbf{x})$ 有上界，因此必收敛到某个极限
- 收敛点满足 Score 方程 $\partial l/\partial \theta = 0$ （即 MLE 的条件）

在正则条件下，EM 算法收敛到 MLE。

EM 算法的优点：

- 简单：每一步只需要计算条件期望
- 稳定：单调收敛，不会发散
- 灵活：适用于各种缺失数据或隐变量问题

EM 算法的缺点：

- 可能收敛到局部最大值（而非全局最优）
- 收敛速度可能很慢
- 需要显式计算条件期望，可能很困难

EXAMPLE 6.22 (遗传连锁的 EM 算法). 在遗传学中，估计两个基因座之间的重组率 θ 是一个经典问题。

设四类后代观测个数为 (X_1, X_2, X_3, X_4) ，概率分别为 $(\frac{1}{2} + \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{\theta}{4})$ 。通过引入隐变量（将第一类拆分为两个子类别），EM 算法给出迭代公式

$$\theta^{(m+1)} = \frac{x_1\theta^{(m)} + 2x_4 + x_4\theta^{(m)}}{n\theta^{(m)} + 2(x_2 + x_3 + x_4)}. \quad (6.6.8)$$

该公式收敛到重组率 θ 的 MLE。

6.4. Summary of Section 6.6.

- EM 算法适用于缺失数据或隐变量问题
- E 步：计算完整数据对数似然在当前估计下的条件期望
- M 步：最大化条件期望得到新估计
- EM 算法保证观测似然单调递增
- 在正则条件下收敛到 MLE
- 典型应用：截尾数据、混合模型、缺失数据填充

EXERCISE 6.1. 6.1 MLE 的有效性 (Efficiency) -Hogg 6.2.1 设 $X_1, X_2, \dots, X_n$ 是来自 $N(\theta, \sigma^2)$ 分布的随机样本，其中 σ^2 已知。

证明 $\bar{X}$ 是 θ 的有效估计量 (efficient estimator)，即其方差达到了 Rao-Cramér 下界。

根据 (6.2.6)，Rao-Cramér 下界为 $[nI(\theta)]^{-1}$ 。先计算 Fisher 信息 $I(\theta)$ ，再验证 $\text{var}(\bar{X}) = \sigma^2/n$ 是否等于下界。

EXERCISE 6.2. 6.2 *Cauchy* 分布的 *Rao-Cramér* 下界 - Hogg 6.1.8 设随机样本 $X_1, \dots, X_n$ 来自标准 *Cauchy* 分布, 其 pdf 为

$$f(x; \theta) = \frac{1}{\pi[1 + (x - \theta)^2]}, \quad -\infty < x < \infty, \quad -\infty < \theta < \infty.$$

证明 *Rao-Cramér* 下界为 $2/n$ 。若 $\hat{\theta}$ 是 θ 的 MLE, 求 $\sqrt{n}(\hat{\theta} - \theta)$ 的渐近分布。

利用 (6.2.3) 计算 Fisher 信息。注意 *Cauchy* 分布的位置参数 θ 的信息为 $I(\theta) = 1/2$ 。

EXERCISE 6.3. 6.3 指数分布的似然比检验 - Hogg 6.3.1 设 $X_1, \dots, X_n$ 是来自指数分布 $f(x; \theta) = \theta^{-1} \exp\{-x/\theta\}$, $x, \theta > 0$ 的 iid 样本。

考虑检验问题 $H_0: \theta = \theta_0$ vs $H_1: \theta \neq \theta_0$ 。

证明似然比检验统计量可以简化为

$$\Lambda = e^n \left(\frac{\bar{x}}{\theta_0} \right)^n \exp\{-n\bar{x}/\theta_0\},$$

并说明该检验在原假设下可基于 χ^2 分布进行。

根据 (6.1.1) 和 (6.3.3), 似然比检验统计量 $\Lambda = L(\theta_0)/L(\hat{\theta})$ 。注意 MLE 为 $\hat{\theta} = \bar{X}$ 。

EXERCISE 6.4. 6.4 两正态总体的似然比检验 - Hogg 6.4.2 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_4)$ 为两个独立随机样本。

(1) 写出原假设 $H_0: \theta_1 = \theta_2$ (均值相等) 且 $\theta_3 = \theta_4$ (方差相等) 下的似然比检验统计量 Λ 。

(2) 证明检验可以基于 F 统计量进行。

根据 (6.5.2), 似然比检验统计量涉及在原假设和备择假设下的 MLE 比较。当方差相等时, 合并方差估计与个别方差估计之比服从 F 分布。

EXERCISE 6.5. ?? EM 算法与遗传学连锁估计 - Hogg 6.6.1 Rao (1973) 考虑过一个遗传学中的连锁估计问题, 可归结为以下多项式模型。设观测频数为 $\mathbf{X} = (X_1, X_2, X_3, X_4)'$, 样本量为 $n = \sum_{i=1}^4 X_i$, 概率模型为:

类别	C_1	C_2	C_3	C_4
概率	$\frac{1}{2} + \frac{1}{4}\theta$	$\frac{1}{4} - \frac{1}{4}\theta$	$\frac{1}{4} - \frac{1}{4}\theta$	$\frac{1}{4}\theta$

其中参数 $\theta \in [0, 1]$ 。

(1) 写出似然函数 $L(\theta|\mathbf{x})$, 并推导对数似然。

(2) 设立 EM 算法: 将 C_1 拆分为两个子类别 C_{11} 和 C_{12} (概率分别为 $1/2$ 和 $\theta/4$), 设 Z_{11} 和 Z_{12} 为相应不可观测频数。证明完整数据的似然为 $L^c(\theta|\mathbf{x}, \mathbf{z})$ 。

(3) 推导 E 步和 M 步的更新公式。

根据 (6.6.1) 和 (6.6.2), EM 算法的 E 步计算条件期望, M 步最大化完整数据对数似然。注意不可观测数据 Z_{11} 在给定观测时的条件分布。

EXERCISE 6.6. 6.6 — 多参数正态模型的信息矩阵 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 参数向量为 $\boldsymbol{\theta} = (\mu, \sigma^2)'$ 。

(1) 根据 (6.4.3) 和 (6.4.4), 求 Fisher 信息矩阵 $\mathbf{I}(\theta)$ 。

(2) 验证 $\hat{\mu} = \bar{X}$ 和 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 的方差是否达到了信息矩阵逆对应元素的下界。

(3) 根据 (6.4.7), 写出 $(\hat{\mu}, \hat{\sigma}^2)$ 的渐近联合分布。

对数似然为 $l(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - n \log \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$ 。计算二阶偏导数并取负期望。

7. 附录：公式推导

7.1. 定理 6.1.1 的证明 (似然函数的渐近支撑). 背景：我们需要证明当样本量 $n \rightarrow \infty$ 时, 似然函数 $L(\theta_0; \mathbf{X})$ 以概率 1 大于任何 $\theta \neq \theta_0$ 处的似然值。

证明： 记 $Z_i(\theta) = \log \frac{f(X_i; \theta)}{f(X_i; \theta_0)}$ 。则

$$\log \frac{L(\theta_0; \mathbf{X})}{L(\theta; \mathbf{X})} = \sum_{i=1}^n \log \frac{f(X_i; \theta_0)}{f(X_i; \theta)} = - \sum_{i=1}^n Z_i(\theta).$$

由弱大数定律,

$$\frac{1}{n} \sum_{i=1}^n Z_i(\theta) \xrightarrow{P} \mathbb{E}_{\theta_0}[Z_1(\theta)].$$

由 Jensen 不等式和 $\mathbb{E}_{\theta_0}[f(X; \theta)/f(X; \theta_0)] = 1$,

$$\mathbb{E}_{\theta_0}[Z_1(\theta)] = \mathbb{E}_{\theta_0} \left[\log \frac{f(X; \theta)}{f(X; \theta_0)} \right] < \log \mathbb{E}_{\theta_0} \left[\frac{f(X; \theta)}{f(X; \theta_0)} \right] = \log 1 = 0.$$

因此 $\frac{1}{n} \sum Z_i(\theta) \xrightarrow{P}$ 负数, 从而

$$\mathbb{P}_{\theta_0} \left[\frac{1}{n} \sum Z_i(\theta) < 0 \right] \rightarrow 1.$$

即 $\mathbb{P}_{\theta_0}[L(\theta_0; \mathbf{X}) > L(\theta; \mathbf{X})] \rightarrow 1$ 。

证毕。

7.2. Rao-Cramér 下界的推导. 背景：证明任何无偏估计量 $\hat{\theta}$ 的方差满足 $\text{Var}(\hat{\theta}) \geq 1/[nI(\theta)]$ 。

证明思路： 利用 Cauchy-Schwarz 不等式。

设 $Y = \hat{\theta}$, $Z = \sum_{i=1}^n \frac{\partial \log f(X_i; \theta)}{\partial \theta}$ 。则 $\mathbb{E}(Z) = 0$, $\text{Var}(Z) = nI(\theta)$ 。

对 $k'(\theta) = \frac{d}{d\theta} \mathbb{E}(Y) = \frac{d}{d\theta} \int y L(y) dy$ 利用微分与积分可交换 (正则条件), 得

$$k'(\theta) = \mathbb{E} \left(Y \cdot \frac{\partial \log L}{\partial \theta} \right) = \mathbb{E}(YZ).$$

由 Cauchy-Schwarz 不等式,

$$|\text{corr}(Y, Z)|^2 = \frac{[\text{cov}(Y, Z)]^2}{\text{Var}(Y)\text{Var}(Z)} \leq 1.$$

即 $[k'(\theta)]^2 \leq \text{Var}(Y) \cdot nI(\theta)$, 整理得 Rao-Cramér 不等式。

证毕。

7.3. MLE 渐近正态性的证明. 背景：证明 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, 1/I(\theta_0))$ 。

证明思路：对数似然在 θ_0 处 Taylor 展开。

记 $l'(\theta) = \partial l / \partial \theta$, $l''(\theta) = \partial^2 l / \partial \theta^2$ 。

由 $l'(\hat{\theta}_n) = 0$ (MLE 条件) 和 Taylor 展开：

$$0 = l'(\theta_0) + (\hat{\theta}_n - \theta_0)l''(\theta_0) + \frac{1}{2}(\hat{\theta}_n - \theta_0)^2 l'''(\theta_n^*),$$

其中 θ_n^* 在 θ_0 和 $\hat{\theta}_n$ 之间。

整理得

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{n^{-1/2}l'(\theta_0)}{-n^{-1}l''(\theta_0) - \frac{1}{2}(\hat{\theta}_n - \theta_0) \cdot n^{-1}l'''(\theta_n^*)}.$$

由中心极限定理, $n^{-1/2}l'(\theta_0) \xrightarrow{D} N(0, I(\theta_0))$ 。

由大数定律, $-n^{-1}l''(\theta_0) \xrightarrow{P} I(\theta_0)$ 。

由一致性 $\hat{\theta}_n \xrightarrow{P} \theta_0$ 和条件 (R5), 第三项依概率趋于 0。

因此分子分母分别收敛, 极限分布为 $N(0, 1/I(\theta_0))$ 。

证毕。

7.4. 正态分布信息矩阵的推导. 设 $X \sim N(\mu, \sigma^2)$, 记 $\theta_1 = \mu$, $\theta_2 = \sigma^2$ 。

对数密度：

$$\log f = -\frac{1}{2} \log(2\pi) - \frac{1}{2} \log \theta_2 - \frac{(x - \theta_1)^2}{2\theta_2}.$$

一阶偏导数：

$$\frac{\partial \log f}{\partial \theta_1} = \frac{x - \theta_1}{\theta_2}, \quad \frac{\partial \log f}{\partial \theta_2} = -\frac{1}{2\theta_2} + \frac{(x - \theta_1)^2}{2\theta_2^2}.$$

二阶偏导数：

$$\frac{\partial^2 \log f}{\partial \theta_1^2} = -\frac{1}{\theta_2}, \quad \frac{\partial^2 \log f}{\partial \theta_2^2} = \frac{1}{2\theta_2^2} - \frac{(x - \theta_1)^2}{\theta_2^3}, \quad \frac{\partial^2 \log f}{\partial \theta_1 \partial \theta_2} = -\frac{x - \theta_1}{\theta_2^2}.$$

计算 Fisher 信息矩阵元素 (取负期望)：

$$\begin{aligned} I_{11} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_1^2} \right] = \frac{1}{\theta_2}, \\ I_{22} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_2^2} \right] = \frac{1}{2\theta_2^2}, \\ I_{12} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_1 \partial \theta_2} \right] = -\mathbb{E} \left[-\frac{X - \theta_1}{\theta_2^2} \right] = 0. \end{aligned}$$

因此

$$\mathbf{I}(\theta) = \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2(\sigma^2)^2} \end{pmatrix}.$$

注意到 $I_{12} = 0$, 这表明 μ 和 σ^2 的信息在正态分布下是独立的。

证毕。

7.5. EM 算法单调性的证明. 背景：证明 EM 算法的每一步都使观测似然单调递增。

证明： 由条件概率定义，

$$L(\theta|\mathbf{x}) = \frac{h(\mathbf{x}, \mathbf{z}|\theta)}{k(\mathbf{z}|\theta, \mathbf{x})},$$

其中 h 是完整数据联合密度， k 是缺失数据 $\mathbf{Z}$ 给定观测数据 $\mathbf{x}$ 和参数 θ 的条件密度。

取对数并在给定 $\theta^{(m)}$ 和 $\mathbf{x}$ 的条件下对 $\mathbf{Z}$ 求期望：

$$\log L(\theta|\mathbf{x}) = \mathbb{E}_{\theta^{(m)}} [\log h(\mathbf{x}, \mathbf{Z}|\theta)|\theta^{(m)}, \mathbf{x}] - \mathbb{E}_{\theta^{(m)}} [\log k(\mathbf{Z}|\theta, \mathbf{x})|\theta^{(m)}, \mathbf{x}].$$

第一项正是 $Q(\theta|\theta^{(m)}, \mathbf{x})$ 。第二项由 Jensen 不等式可得

$$\mathbb{E}_{\theta^{(m)}} \left[\log \frac{k(\mathbf{Z}|\theta^{(m)}, \mathbf{x})}{k(\mathbf{Z}|\theta, \mathbf{x})} \right] \leq \log \mathbb{E}_{\theta^{(m)}} \left[\frac{k(\mathbf{Z}|\theta^{(m)}, \mathbf{x})}{k(\mathbf{Z}|\theta, \mathbf{x})} \right] = \log 1 = 0.$$

因此

$$\log L(\theta|\mathbf{x}) \geq Q(\theta|\theta^{(m)}, \mathbf{x}) - Q(\theta^{(m)}|\theta^{(m)}, \mathbf{x}).$$

由于 $\theta^{(m+1)}$ 最大化 Q ，即 $Q(\theta^{(m+1)}|\theta^{(m)}, \mathbf{x}) \geq Q(\theta^{(m)}|\theta^{(m)}, \mathbf{x})$ ，代入得

$$\log L(\theta^{(m+1)}|\mathbf{x}) \geq \log L(\theta^{(m)}|\mathbf{x}).$$

证毕。

CHAPTER 7

Sufficiency and Quality of Estimators

Chapter 7 Overview

在前几章中，我们建立了点估计、置信区间和假设检验的理论基础。我们已经看到，最大似然估计（MLE）在正则条件下具有一致性，并且在渐近意义下具有最优性质。然而，我们还没有回答一个更深层次的问题：

给定一个参数 θ ，在所有可能的估计量中，是否存在一个“最好”的？如何找到它？

要回答这个问题，我们首先需要理解什么叫“信息保留”。当我们收集数据 $X_1, X_2, \dots, X_n$ 后，这些数据包含了关于 θ 的信息。但原始数据量太大——我们需要**数据压缩（data reduction）**。一个自然的想法是用样本均值 $\bar{X}$ 或样本方差 S^2 这样的统计量来代替原始数据。

关键问题是：这种压缩是否丢失了关于 θ 的信息？

这正是**充分性（sufficiency）**理论要回答的问题。一个充分统计量 $T(X_1, \dots, X_n)$ 保留了原始数据中关于 θ 的全部信息——给定 T 的值，数据的条件分布不再依赖于 θ 。本章我们将学习：

- 如何定义和判断充分统计量（因子分解定理）
- Rao-Blackwell 定理：如何利用充分性改进估计量
- 完备性（completeness）与唯一最小方差无偏估计（MVUE）的关系
- 指数族分布（exponential class）的优良性质
- Basu 定理：完备充分统计量与辅助统计量的独立性

本章路线图：充分性定义 $\rightarrow$ 因子分解定理 $\rightarrow$ Rao-Blackwell $\rightarrow$ 完备性 $\rightarrow$ 指数族 $\rightarrow$ Basu 定理

1. 7.1 Measures of Quality of Estimators

在寻找“最好”的估计量之前，我们需要先定义什么叫“好”。前几章我们已经遇到过两个重要标准：无偏性（unbiasedness）和一致性（consistency）。

1.1. 最小方差无偏估计量（MVUE）. 一个自然而优雅的标准是：在所有无偏估计量中，选择方差最小的。

DEFINITION 7.1 (最小方差无偏估计量 (MVUE)). 设 $Y = u(X_1, X_2, \dots, X_n)$ 是基于容量为 n 的随机样本的 θ 的点估计量。若 Y 是无偏的，即 $E(Y) = \theta$ ，且对 θ 的任何其他无偏估计量 Y' ，都有 $\text{var}(Y) \leq \text{var}(Y')$ ，则称 Y 是 θ 的**最小方差无偏估计量（minimum variance unbiased estimator, MVUE）**。

这个定义的诱人之处在于它的自然性：如果两个估计量都是 θ 的无偏估计，那么方差较小的那个在平均意义上更接近 θ 。

EXAMPLE 7.1 (正态分布的样本均值 vs 单个观测值). 设 $X_1, X_2, \dots, X_9$ 是来自 $N(\theta, \sigma^2)$ 分布的随机样本，其中 $-\infty < \theta < \infty$ 。

统计量 $\bar{X} = (X_1 + X_2 + \dots + X_9)/9$ 服从 $N(\theta, \sigma^2/9)$ ，因此是无偏的。而 X_1 服从 $N(\theta, \sigma^2)$ ，也是无偏的。

虽然 $\bar{X}$ 的方差 $\sigma^2/9$ 小于 X_1 的方差 σ^2 ，但定义要求比较的对象是**所有**无偏估计量，而不仅仅是这两个。我们不能仅凭两个例子就宣称 $\bar{X}$ 是 *MVUE*。

真正的问题在于：我们无法枚举所有可能的无偏估计量。这促使我们发展更系统的方法来寻找 *MVUE*。

1.2. 风险函数与决策论视角. 另一种比较估计量的框架是决策论 (decision theory)。设 $\mathcal{L}[\theta, \delta(y)]$ 是损失函数 (loss function)，衡量估计值 $\delta(y)$ 与真实参数 θ 之间的差距。常见的损失函数是平方误差损失 $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$ 。

风险函数 (risk function) 定义为损失的期望： $R(\theta, \delta) = E[\mathcal{L}(\theta, \delta(Y))]$ 。一个自然的想法是寻找使风险函数最小化的决策函数。但在一般情况下，使 $R(\theta, \delta)$ 对所有 θ 同时最小的估计量不存在 (见下例)。

EXAMPLE 7.2 (最小化风险函数的困难). 设 $X_1, \dots, X_{25}$ 是来自 $N(\theta, 1)$ 的样本。考虑平方损失函数 $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$ 。

比较两个决策函数：

- $\delta_1(y) = y = \bar{x}$ ，风险 $R(\theta, \delta_1) = 1/25$
- $\delta_2(y) = 0$ ，风险 $R(\theta, \delta_2) = \theta^2$

当 $\theta = 0$ 时， δ_2 表现完美 ($R(0, \delta_2) = 0$)；但当 $\theta = 2$ 时， $R(2, \delta_2) = 4 > R(2, \delta_1) = 1/25$ 。一般地，当 $|\theta| < 1/5$ 时 δ_2 更好，否则 δ_1 更好。

这说明没有一个决策函数能在所有 θ 值下同时最优。**minimax 原则**提供了一种折中：选择使 $\max_{\theta} R(\theta, \delta)$ 最小的决策函数。

如果没有对决策函数的限制 (如要求无偏)，很难找到统一最优的估计量。这促使我们聚焦于 *MVUE*——在无偏估计量的类中寻找方差最小者。

充分性的引入：如果我们有一个充分统计量 T ，那么所有无偏估计量都可以通过 Rao-Blackwell 过程改进为 T 的函数。这大大简化了 *MVUE* 的搜索。

本节小结.

- *MVUE* 在无偏估计量类中方差最小
- 寻找 *MVUE* 的困难在于无法枚举所有无偏估计量
- 充分统计量为这一问题提供了系统性的解决方案

2. 7.2 A Sufficient Statistic for a Parameter

本节我们正式引入充分统计量的概念，并建立判断充分性的核心工具——因子分解定理 (Factorization Theorem)。

2.1. 为什么需要充分统计量? 统计量 $Y = u(X_1, X_2, \dots, X_n)$ 本质上是对样本空间的一种划分 (partition)。例如, $\bar{X} = 8.32$ 意味着所有满足 $\sum x_i = (8.32)n$ 的点 $(x_1, \dots, x_n)$ 被归入同一类。

给定一个统计量 $Y_1 = u_1(X_1, \dots, X_n)$, 如果我们知道 $(X_1, \dots, X_n)$ 落在由 $Y_1 = y_1$ 确定的集合中, 那么 $X_1, \dots, X_n$ 的条件分布可能仍然依赖于 θ 。如果这个条件分布**完全**不含 θ , 则 Y_1 包含了样本中关于 θ 的全部信息——这就是充分性的直觉。

EXAMPLE 7.3 (二项分布的充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 $Bernoulli(\theta)$ 分布的随机样本, 即

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, \quad x = 0, 1.$$

统计量 $Y_1 = \sum_{i=1}^n X_i$ 服从二项分布 $b(n, \theta)$ 。考虑条件概率

$$P(X_1 = x_1, \dots, X_n = x_n \mid Y_1 = y_1).$$

当且仅当 $\sum x_i = y_1$ 时该条件概率非零, 此时

$$\frac{\theta^{x_1} (1 - \theta)^{1-x_1} \dots \theta^{x_n} (1 - \theta)^{1-x_n}}{\binom{n}{y_1} \theta^{y_1} (1 - \theta)^{n-y_1}} = \frac{1}{\binom{n}{y_1}},$$

该式不含 θ 。因此给定 $Y_1 = y_1$, 数据的条件分布与 θ 无关—— Y_1 是 θ 的充分统计量。

这个例子的含义是: 只要知道“成功次数” Y_1 是多少, 就不再需要知道具体是哪几次试验成功了。 Y_1 已经包含了所有关于 θ 的信息。

2.2. 充分统计量的正式定义.

DEFINITION 7.2 (充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是统计量, 其 pdf 或 pmf 为 $f_{Y_1}(y_1; \theta)$ 。则 Y_1 是 θ 的**充分统计量**, 当且仅当

$$\frac{f(x_1; \theta) f(x_2; \theta) \dots f(x_n; \theta)}{f_{Y_1}[u_1(x_1, \dots, x_n); \theta]} = H(x_1, \dots, x_n),$$

其中 $H(x_1, \dots, x_n)$ 不依赖于 θ 。

这个定义的要点是: 分子是联合 pdf/pmf, 分母是充分统计量的 pdf, 比值只与原始数据有关而与 θ 无关。

2.3. 因子分解定理 (Factorization Theorem). 直接使用定义需要知道充分统计量的分布, 这往往很困难。Neyman 的因子分解定理提供了一个更实用的判定方法。

核心思想: 联合 pdf/pmf 可以分解为两部分——一部分只通过 $u_1(x_1, \dots, x_n)$ 依赖于 θ , 另一部分与 θ 无关。能完成这种分解的统计量就是充分的。

EXAMPLE 7.4 (正态分布 $\bar{X}$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 $N(\theta, \sigma^2)$ 的样本, 其中 σ^2 已知。则

$$f(x_i; \theta) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x_i - \theta)^2}{2\sigma^2} \right].$$

联合 pdf 为

$$\prod_{i=1}^n f(x_i; \theta) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

利用恒等式 $\sum (x_i - \theta)^2 = \sum (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2$, 可得

$$\prod_{i=1}^n f(x_i; \theta) = \underbrace{\exp \left[-\frac{n(\bar{x} - \theta)^2}{2\sigma^2} \right]}_{k_1(\bar{x}; \theta)} \cdot \underbrace{\frac{\exp \left[-\frac{1}{2\sigma^2} \sum (x_i - \bar{x})^2 \right]}{(\sigma\sqrt{2\pi})^n}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\bar{X}$ 是 θ 的充分统计量。¹

EXAMPLE 7.5 (指数分布的充分统计量). 设 $X_1, \dots, X_n$ 是来自 $\Gamma(2, \theta)$ 分布的样本。已知 $\Gamma(\alpha, \beta)$ 分布的 mgf 为 $M(t) = (1 - \beta t)^{-\alpha}$, $t < 1/\beta$ 。

$Y_1 = \sum_{i=1}^n X_i$ 的 mgf 为 $[(1 - \theta t)^{-2}]^n = (1 - \theta t)^{-2n}$, 因此 $Y_1 \sim \Gamma(2n, \theta)$ 。

联合 pdf 为

$$\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2} = \frac{(\prod x_i) \exp(-\sum x_i/\theta)}{\theta^{2n}}.$$

给定 $Y_1 = y_1$ 时, 条件概率的比值为

$$\frac{\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2}}{\frac{y_1^{2n-1} e^{-y_1/\theta}}{\Gamma(2n)\theta^{2n}}} = \frac{\Gamma(2n) \prod x_i}{y_1^{2n-1}},$$

不含 θ 。故 $Y_1 = \sum X_i$ 是 θ 的充分统计量。

EXAMPLE 7.6 (乘积 $\prod X_i$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0$$

的样本。这是参数化形式的 Beta 分布。

联合 pdf 为

$$\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} = \underbrace{\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta}}_{k_1(\prod x_i; \theta)} \cdot \underbrace{\frac{1}{\prod x_i}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\prod_{i=1}^n X_i$ 是 θ 的充分统计量。

注意: 使用因子分解定理时, 必须正确处理支撑集 (support) 对参数的依赖。

EXAMPLE 7.7 (支撑集依赖参数的情况). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta) = e^{-(x-\theta)} I_{(\theta, \infty)}(x).$$

一种错误的分解可能是:

$$\prod e^{-(x_i-\theta)} = [e^{3\theta}] [e^{-x_1-x_2-x_3}],$$

¹正态分布充分性的详细推导见附录 ??。

从而声称 $\max X_i$ 是充分的。但这是错误的，因为支撑集的交集必须满足 $\theta < \min x_i$ ，即

$$\prod I_{(\theta, \infty)}(x_i) = I_{(\theta, \infty)}(\min x_i).$$

正确的分解导致 $\min X_i$ 是充分统计量，而非 $\max X_i$ 。

本节小结.

- 充分统计量 T 保留了样本中关于 θ 的全部信息
- 因子分解定理是判断充分性的实用工具
- 注意支撑集对参数的依赖情况

3. 7.3 Properties of a Sufficient Statistic

本节讨论充分性的关键应用：如何利用充分统计量改进任意无偏估计量。

3.1. Rao-Blackwell 定理. 给定一个充分统计量 T ，我们可以将任意无偏估计量 Y_2 改进为 T 的函数 $\varphi(T)$ ，新估计量不仅保持无偏性，方差还会减小。

则 $E(Y_2 | y_1) = \varphi(y_1)$ 定义了一个统计量 $\varphi(Y_1)$ 。该统计量 $\varphi(Y_1)$ ：

- (1) 是 θ 的无偏估计量
- (2) 是充分统计量的函数
- (3) 方差不超过 Y_2 的方差

证明思路： 利用全概率公式 $E(Y_2) = E[E(Y_2 | Y_1)]$ 和条件方差不增性质 $\text{var}(Y_2) \geq \text{var}[E(Y_2 | Y_1)]$ 。

这个定理的战略意义是：在寻找 MVUE 时，只需在充分统计量的函数中搜索。

EXAMPLE 7.8 (指数分布的 MVUE). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta e^{-\theta x}, \quad x > 0, \quad \theta > 0$$

的样本（这是 $\Gamma(1, 1/\theta)$ 分布）。

联合 pdf 为 $L(\theta) = \theta^n e^{-\theta \sum x_i}$ ，故 $Y_1 = \sum_{i=1}^n X_i$ 是充分统计量。

MLE 为 $Y_2 = 1/\bar{X} = n/Y_1$ 。由于 MLE 渐近无偏，我们计算其期望。 $Y_1 \sim \Gamma(n, 1/\theta)$ ，因此

$$E(Y_2) = n \cdot E(1/Y_1) = n \int_0^\infty \frac{\theta^n}{n!} t^{-1} t^{n-1} e^{-\theta t} dt = \frac{n}{n-1} \theta, \quad n > 1.$$

故 $(n-1)/n \cdot Y_2 = (n-1)/Y_1$ 是 θ 的无偏估计量，且是充分统计量的函数，因此是 MVUE。

3.2. 充分性与 MLE 的关系. 直觉： 若 T 是充分的，则似然函数 $L(\theta) = f_T(t; \theta) \cdot H(\mathbf{x})$ 。 $L(\theta)$ 和 $f_T(t; \theta)$ 作为 θ 的函数同时达到最大值，故 $\hat{\theta}$ 必为 T 的函数。

这一结果具有重要的实践意义：对于指数族分布，MLE 通常可以解析地写成充分统计量的函数。

本节小结.

- Rao-Blackwell 定理: 将任意无偏估计量改进为充分统计量的函数
- 充分性搜索范围: 从所有统计量缩小到充分统计量的函数
- 若 MLE 存在且唯一, 则必为充分统计量的函数

4. 7.4 Completeness and Uniqueness

有了 Rao-Blackwell 定理, 我们知道 MVUE (若存在) 必是充分统计量的函数。但充分统计量的函数可能有很多个——我们如何确定哪一个是 MVUE?

这就需要引入**完备性 (completeness)**的概念。

4.1. 完备性的定义.

DEFINITION 7.3 (完备族). 设随机变量 Z (连续型或离散型) 的 pdf 或 pmf 是族 $\{h(z; \theta) : \theta \in \Omega\}$ 的一员。若条件 $E[u(Z)] = 0$ 对所有 $\theta \in \Omega$ 成立能够推出 $u(z) = 0$ (除了一个对每个 $h(z; \theta)$ 概率为零的点集), 则称该族为**完备族 (complete family)**。

简言之: 只有零函数才能期望为零。

EXAMPLE 7.9 (泊松分布族的完备性). 设 $X_1, \dots, X_n$ 是来自泊松分布 $P(\theta)$ 的样本。已知 $Y_1 = \sum X_i$ 是充分统计量, 其 pmf 为

$$g(y_1; \theta) = \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!}, \quad y_1 = 0, 1, 2, \dots$$

设 $E[u(Y_1)] = 0$ 对所有 $\theta > 0$ 成立, 即

$$\sum_{y_1=0}^{\infty} u(y_1) \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!} = 0.$$

由于 $e^{-n\theta} \neq 0$, 可得

$$u(0) + nu(1)\theta + \frac{n^2 u(2)}{2!} \theta^2 + \dots = 0, \quad \forall \theta > 0.$$

无穷幂级数对所有 $\theta > 0$ 为零, 意味着所有系数必为零:

$$u(0) = u(1) = u(2) = \dots = 0.$$

故泊松充分统计量族是完备的。

EXAMPLE 7.10 (指数分布族的完备性). 设 $Z \sim \text{Exp}(\theta)$, 即 pdf 为 $h(z; \theta) = \frac{1}{\theta} e^{-z/\theta}$, $z > 0$ 。

设 $E[u(Z)] = 0$ 对所有 $\theta > 0$ 成立:

$$\int_0^{\infty} u(z) \frac{1}{\theta} e^{-z/\theta} dz = 0, \quad \forall \theta > 0.$$

令 $t = z/\theta$, 则 $\theta dt = dz$:

$$\int_0^{\infty} u(\theta t) e^{-t} dt = 0, \quad \forall \theta > 0.$$

对 θ 求导并利用积分号内可微 (假设 u 满足适当条件), 可得 $u(\theta t) \equiv 0$ 。由拉普拉斯变换的唯一性, $u \equiv 0$ 。故该族是完备的。

4.2. 完备充分统计量与 MVUE 的唯一性. 若存在 Y_1 的一个函数是 θ 的无偏估计量, 则该函数是唯一的 MVUE。

证明思路: 设 $\varphi(Y_1)$ 和 $\psi(Y_1)$ 都是 Y_1 的无偏估计量函数。则 $E[\varphi(Y_1) - \psi(Y_1)] = 0$ 对所有 θ 成立。由完备性, $\varphi(y_1) - \psi(y_1) = 0$ 几乎处处成立, 即两个估计量函数几乎处处相等——这就是“唯一”含义。

战略意义: 完备充分统计量的无偏函数就是 MVUE。

EXAMPLE 7.11 (均匀分布最大值的 MVUE). 设 $X_1, \dots, X_n$ 是来自 $Uniform(0, \theta)$ 的样本。 $Y_n = \max\{X_i\}$ 是充分统计量 (习题 7.2.3), 其 pdf 为

$$g(y_n; \theta) = \frac{ny_n^{n-1}}{\theta^n}, \quad 0 < y_n < \theta.$$

验证完备性: 设 $E[u(Y_n)] = 0$ 对所有 $\theta > 0$ 成立,

$$\int_0^\theta u(t) \frac{nt^{n-1}}{\theta^n} dt = 0.$$

等价于 $\int_0^\theta u(t)t^{n-1}dt = 0$ 。对 θ 求导得 $u(\theta)\theta^{n-1} = 0$, 故 $u(\theta) = 0$ 对所有 $\theta > 0$ 成立。故 Y_n 是完备充分的。

计算 $E(Y_n) = \frac{n}{n+1}\theta$, 故 $(n+1)/n \cdot Y_n$ 是 θ 的 MVUE。

EXAMPLE 7.12 (非完备的情况). 设 $X \sim N(0, \theta)$, $\theta > 0$ 。则 $Y = \sum X_i^2$ 是充分统计量, 但族 $\{f_Y(y; \theta)\}$ 不是完备的 (因为 χ^2 分布的自由度参数不依赖于 θ 的形式)。

实际上, 若 $Z \sim \chi_{n-1}^2$ (与 Y 独立), 则 $E(Z) = n-1$, 但这并不能推出关于 Y 的任何约束。

本节小结.

- 完备性: 只有零函数才能期望为零
- Lehmann-Scheffé 定理: 完备充分统计量的无偏函数是唯一的 MVUE
- 寻找 MVUE 的策略: 先找完备充分统计量, 再在其函数中找无偏估计量

5. 7.5 The Exponential Class of Distributions

在前几节中, 我们看到充分性和完备性是找到 MVUE 的关键。但如何系统地找到完备充分统计量? 本节介绍的**指数族分布 (exponential class)** 是一个具有优良性质的大类。

5.1. 正则指数族的定义.

DEFINITION 7.4 (正则指数族). 设 $f(x; \theta)$ 具有如下形式:

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)], \quad x \in \mathcal{S},$$

其中 $\mathcal{S}$ 是 X 的支撑集。若满足:

- (1) $\mathcal{S}$ 不依赖于 θ
- (2) $p(\theta)$ 是 $\theta \in \Omega$ 的非线性连续函数
- (3) 若 X 连续, 则 $K'(x) \neq 0$ 且 $H(x)$ 在 $\mathcal{S}$ 上连续; 若 X 离散, 则 $K(x)$ 在 $\mathcal{S}$ 上非线性

则称 $f(x; \theta)$ 属于**正则指数族** (*regular exponential class*)。

直觉: 指数形式 $e^{p(\theta)K(x)}$ 使得对数似然函数是 $K(x)$ 的线性函数, 从而 $\sum K(X_i)$ 自然成为充分统计量。

EXAMPLE 7.13 (正态分布 $N(0, \theta)$ 是指数族). $N(0, \theta)$ 的 pdf 可写为

$$f(x; \theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-x^2/(2\theta)} = \exp \left[-\frac{1}{2\theta} x^2 - \frac{1}{2} \log(2\pi\theta) \right].$$

对应 $p(\theta) = -1/(2\theta)$, $K(x) = x^2$, $H(x) = -\frac{1}{2} \log(2\pi)$, $q(\theta) = -\frac{1}{2} \log(2\pi\theta)$ 。故 $N(0, \theta)$ 属于正则指数族。

若 $X_1, \dots, X_n \sim N(0, \theta)$, 则 $\sum X_i^2$ 是充分统计量。

EXAMPLE 7.14 (泊松分布是指数族). 泊松分布的 pmf 为

$$f(x; \theta) = e^{-\theta} \frac{\theta^x}{x!} = \exp[(\log \theta)x - \theta - \log(x!)].$$

对应 $p(\theta) = \log \theta$, $K(x) = x$, $q(\theta) = -\theta$, $H(x) = -\log(x!)$ 。故泊松分布属于正则指数族, $\sum X_i$ 是充分统计量。

反例: 均匀分布 $f(x; \theta) = 1/\theta$, $0 < x < \theta$ 的支撑集依赖于 θ , 因此不是正则指数族。

5.2. 指数族的核心定理. 证明思路: 设 $E[u(Y_1)] = 0$ 对所有 θ 成立。利用 Y_1 的分布形式, 可得

$$\int u(y_1) R(y_1) \exp[p(\theta)y_1] dy_1 = 0, \quad \forall \theta.$$

由于 $p(\theta)$ 是非线性连续函数, 该积分本质上是 $u(y_1)R(y_1)$ 的拉普拉斯变换。拉普拉斯变换为零意味着 $u(y_1)R(y_1) \equiv 0$ 。由于 $R(y_1) > 0$ (它是 pdf 的因子), 故 $u(y_1) \equiv 0$ 。

EXAMPLE 7.15 (正态均值 θ 的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知。则

$$f(x; \theta) = \exp \left[\frac{\theta}{\sigma^2} x - \frac{x^2}{2\sigma^2} - \log \sqrt{2\pi\sigma^2} - \frac{\theta^2}{2\sigma^2} \right].$$

故 $p(\theta) = \theta/\sigma^2$, $K(x) = x$, $q(\theta) = -\frac{\theta^2}{2\sigma^2}$ 。 $Y_1 = \sum X_i = n\bar{X}$ 是完备充分统计量。
 $E(Y_1) = n\theta$, 故 $\varphi(Y_1) = Y_1/n = \bar{X}$ 是 θ 的唯一 MVUE。

指数族的战略价值: 对于指数族, 完备充分统计量可以通过观察直接写出, MVUE 也容易通过期望计算得到。

本节小结.

- 正则指数族具有形式 $e^{p(\theta)K(x)+H(x)+q(\theta)}$
- $\sum K(X_i)$ 是指数族的充分统计量
- 指数族统计量是完备充分的
- 指数族的 MVUE 可通过期望计算直接得到

6. 7.6 Functions of a Parameter

很多时候, 我们关心的不是参数 θ 本身, 而是其某个函数 $\delta = g(\theta)$ 。例如, 估计 $\theta(1 - \theta)$ 而非 θ 本身。

6.1. 技术一: 观察法. 如果能通过观察 $E[\varphi(Y_1)] = g(\theta)$ 解出 φ 就可直接得到 MVUE。

EXAMPLE 7.16 (二项分布方差的 MVUE). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$ 。 $Y = \sum X_i$ 是完备充分统计量。样本比例 Y/n 是 θ 的 MVUE。

现欲估计 $\delta = \theta(1 - \theta)$, 即 $\text{var}(Y/n) = \theta(1 - \theta)/n$ 。

MLE 为 $\tilde{\delta} = (Y/n)(1 - Y/n)$ 。计算期望:

$$E[\tilde{\delta}] = E\left[\frac{Y}{n}\left(1 - \frac{Y}{n}\right)\right] = \frac{n-1}{n}\theta(1 - \theta).$$

故 $\hat{\delta} = \frac{n}{n-1}\tilde{\delta} = \frac{Y(n-Y)}{n(n-1)}$ 是 δ 的 MVUE。

6.2. 技术二: 条件期望法. 若 Z 是 θ 的无偏估计量, 则 $\varphi(Y_1) = E(Z | Y_1)$ 是 MVUE。

EXAMPLE 7.17 (正态分布累积概率的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ 。欲估计 $P(X \leq c) = \Phi(c - \theta)$ 。

取 $Z = I(X_1 \leq c)$, 则 $E(Z) = \Phi(c - \theta)$, 是无偏的。

$(X_1, \bar{X})$ 的联合分布是二元正态, 条件分布 $X_1 | \bar{X} = \bar{x}$ 是正态, 均值为 $\bar{x}$, 方差为 $(n-1)/n$ 。

计算条件期望:

$$E[Z | \bar{X} = \bar{x}] = P(X_1 \leq c | \bar{X} = \bar{x}) = \Phi\left[\frac{\sqrt{n}(c - \bar{x})}{\sqrt{n-1}}\right].$$

这是 $\Phi(c - \theta)$ 的 MVUE。

6.3. 7.6.1 Bootstrap 标准误. 对于 MVUE, 我们通常没有像 MLE 那样的渐近理论。但可以使用 Bootstrap 来获得标准误。

设 $\hat{\theta}$ 是基于原始样本的估计量。从经验分布 $\hat{F}_n$ 中有放回地抽取 B 个 Bootstrap 样本, 计算每个样本的估计值 $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ 。则 Bootstrap 标准误为

$$\text{SE}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\hat{\theta}})^2}, \quad \bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b^*.$$

这在 MVUE 的解析标准误难以获得时特别有用。

本节小结.

- 估计 $g(\theta)$ 时, 先找 θ 的完备充分统计量
- MVUE 或者是 T 的函数的期望, 或者通过条件期望改进
- Bootstrap 可用于估计 MVUE 的标准误

7. 7.7 The Case of Several Parameters

前面的讨论聚焦于单个参数。当分布涉及多个参数时, 我们需要联合充分统计量 (joint sufficient statistics) 的概念。

7.1. 联合充分统计量.

DEFINITION 7.5 (联合充分统计量). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本, 其中 $\theta \in \Omega \subset \mathbb{R}^p$ 。设 $\mathbf{Y} = (Y_1, \dots, Y_m)$ 是统计量向量。则 $\mathbf{Y}$ 是 θ 的联合充分统计量, 当且仅当

$$\frac{\prod_{i=1}^n f(x_i; \theta)}{f_{\mathbf{Y}}(\mathbf{y}; \theta)} = H(x_1, \dots, x_n),$$

其中 H 不依赖于 θ 。

因子分解定理同样适用: 联合似然函数可分解为仅依赖 $\mathbf{y}$ 的因子和与参数无关的因子。

EXAMPLE 7.18 (双参数正态分布). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$, 其中 θ_1 是均值, θ_2 是方差。

联合 pdf 为

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi\theta_2}} \exp \left[-\frac{(x_i - \theta_1)^2}{2\theta_2} \right].$$

利用恒等式 $\sum (x_i - \theta_1)^2 = \sum x_i^2 - n\bar{x}^2 + n(\bar{x} - \theta_1)^2$, 可得

$$\prod f(x_i; \theta) = \exp \left[-\frac{n(\bar{x} - \theta_1)^2}{2\theta_2} \right] \cdot \frac{\exp \left[-\frac{1}{2\theta_2} \sum (x_i - \bar{x})^2 \right]}{(\sqrt{2\pi\theta_2})^n}.$$

因此 $(\bar{X}, \sum X_i^2)$ 或等价地 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量。

EXAMPLE 7.19 (均匀分布的双参数). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta_1, \theta_2) = \frac{1}{2\theta_2} I_{(\theta_1 - \theta_2, \theta_1 + \theta_2)}(x).$$

这是区间长度为 $2\theta_2$ 、中心为 θ_1 的均匀分布。充分统计量为 $(Y_1, Y_n) = (\min X_i, \max X_i)$ 。

7.2. 多参数指数族.

DEFINITION 7.6 (m 参数指数族). 设 $f(x; \boldsymbol{\theta})$ 具有形式

$$f(x; \boldsymbol{\theta}) = \exp \left[\sum_{j=1}^m p_j(\boldsymbol{\theta}) K_j(x) + H(x) + q(\boldsymbol{\theta}) \right], \quad x \in \mathcal{S}.$$

在正则条件下, 统计量

$$Y_j = \sum_{i=1}^n K_j(X_i), \quad j = 1, \dots, m$$

是 $\boldsymbol{\theta}$ 的联合完备充分统计量 (当 $n > m$ 时)。

EXAMPLE 7.20 (双参数指数族). $N(\theta_1, \theta_2)$ 可写为指数形式:

$$f(x; \theta_1, \theta_2) = \exp \left[-\frac{1}{2\theta_2} x^2 + \frac{\theta_1}{\theta_2} x - \frac{\theta_1^2}{2\theta_2} - \frac{1}{2} \log(2\pi\theta_2) \right].$$

取 $K_1(x) = x^2$, $K_2(x) = x$, 则联合充分统计量为 $(\sum X_i^2, \sum X_i)$, 与之前的结论一致。

多参数情况下的 MVUE: 设 $\delta = g(\boldsymbol{\theta})$ 是感兴趣的参数函数。若 $\mathbf{Y}$ 是联合完备充分统计量, 则 $E[\delta | \mathbf{Y}]$ 是 δ 的 MVUE。

本节小结.

- 多参数时需要联合充分统计量
- 双参数正态: $(\bar{X}, S^2)$ 是联合完备充分统计量
- 多参数指数族具有联合完备充分统计量

8. 7.8 Minimal Sufficiency and Ancillary Statistics

充分统计量不唯一——任何一一变换 (one-to-one transformation) 还是充分统计量。但我们总希望找到”最小”的充分统计量, 用最少的统计量包含全部信息。

8.1. 最小充分统计量.

DEFINITION 7.7 (最小充分统计量). 设 T 是充分统计量。若对任何其他充分统计量 T' , T 都是 T' 的函数, 则称 T 是**最小充分统计量** (*minimal sufficient statistic*)。

直观理解: 最小充分统计量是”最压缩”的充分统计量——无法在保持充分性的前提下进一步压缩。

一个关键洞察: 若 MLE $\hat{\theta}$ 是充分的, 则 $\hat{\theta}$ 必是最小充分统计量 (因为任何其他充分统计量都能导出 $\hat{\theta}$)。

EXAMPLE 7.21 (均匀分布 $(\theta - 1, \theta + 1)$ 的最小充分统计量). 设 $X_1, \dots, X_n$ 来自 $Uniform(\theta - 1, \theta + 1)$ 分布。

联合 pdf 中出现的指示函数要求 $\theta - 1 < \min x_i \leq x_j \leq \max x_i < \theta + 1$ 。因此 $(Y_1, Y_n) = (\min X_i, \max X_i)$ 是充分统计量。

由于无法进一步压缩（两个统计量缺一不可），它们是最小充分统计量。注意这与单参数情况不同——无法用一个统计量替代两个。

一般位置模型：若 $X_i = \theta + W_i$ ，其中 W_i iid，则顺序统计量 $(Y_1, \dots, Y_n)$ 是最小充分的。但有时也可以进一步压缩——例如正态分布时 $\bar{X}$ 就足够了。

8.2. 辅助统计量 (Ancillary Statistics). 充分统计量包含关于参数的全部信息。辅助统计量的分布则完全不含参数信息——看似是充分性的“对立面”。

DEFINITION 7.8 (辅助统计量). 设 $Z = u(X_1, \dots, X_n)$ 是统计量。若 Z 的分布不依赖于 θ ，则称 Z 是**辅助统计量 (ancillary statistic)**。

例子：

- $N(\theta, 1)$ 分布中， S^2 是辅助统计量（其分布不依赖于 θ ）
- 尺度模型 $X_i = \theta W_i$ 中， X_1/X_2 是辅助统计量

辅助统计量揭示了数据中与参数无关的部分。虽然看似无用，但它们在构建置信区间和检验中很有价值。

EXAMPLE 7.22 (位置不变统计量). 设 $X_i = \theta + W_i, W_i$ iid。统计量 $Z = u(X_1, \dots, X_n)$ 若满足

$$u(x_1 + d, \dots, x_n + d) = u(x_1, \dots, x_n), \quad \forall d,$$

则是位置不变的。直观上，这意味着 Z 只描述 W_i 的性质，因此与 θ 无关。

常见的例子包括：样本方差 S^2 、样本极差 $\max X_i - \min X_i$ 、以及 $\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 。

EXAMPLE 7.23 (尺度不变统计量). 设 $X_i = \theta W_i, \theta > 0, W_i$ iid。若 Z 满足

$$u(cx_1, \dots, cx_n) = u(x_1, \dots, x_n), \quad \forall c > 0,$$

则是尺度不变的。

例子： $X_1/(X_1 + X_2)$ 、 $X_1^2/\sum X_i^2$ 、 $\min X_i/\max X_i$ 。

辅助统计量与充分统计量的关系将在下节的 Basu 定理中揭示。

本节小结.

- 最小充分统计量是充分统计量的一一变换后仍保持充分性
- 若 MLE 是充分的，则它必是最小充分的
- 辅助统计量的分布不含参数信息
- 位置/尺度不变统计量是常见的辅助统计量

9. 7.9 Sufficiency, Completeness, and Independence

本节揭示充分性、完备性与独立性之间的深刻联系——Basu 定理。

9.1. Basu 定理的动机. 我们已经知道:

- 若 T 是充分的, 则 Z 的条件分布 $h(z | t)$ 不依赖于 θ
- 若 T 和 Z 独立, 则 Z 的边际分布 $g_2(z) = h(z | t)$ 不依赖于 θ ——即 Z 是辅助的

反过来: 若 Z 是辅助的 (分布不含 θ), T 是充分的, T 和 Z 是否独立? 直觉上似乎应该独立——但这需要证明。

9.2. Basu 定理. 若 Z 的分布不依赖于 θ (即 Z 是辅助的), 则 T 与 Z 独立。

证明思路: 考虑 T 和 Z 的联合 pdf $g_1(t; \theta)h(z | t)$ 。 Z 的边际分布为

$$\int g_1(t; \theta)h(z | t)dt = g_2(z),$$

不依赖于 θ 。同时 $g_2(z) = \int g_2(z)g_1(t; \theta)dt$ 。两式相减得

$$\int [g_2(z) - h(z | t)]g_1(t; \theta)dt = 0, \quad \forall \theta.$$

由于 T 是完备的, 上式意味着 $g_2(z) - h(z | t) = 0$ 几乎处处成立, 即 $h(z | t) = g_2(z)$, 故 T 与 Z 独立。

核心洞察: 完备性是独立性的关键——它保证了期望为零的函数必为零函数。

EXAMPLE 7.24 (正态分布中 $\bar{X}$ 与 S^2 的独立性). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知。则 $\bar{X}$ 是 θ 的完备充分统计量。

样本方差 S^2 是位置不变的——其分布不依赖于 θ 。由 Basu 定理, $\bar{X}$ 与 S^2 独立。这与我们在第 3 章用到的结果一致。

EXAMPLE 7.25 (指数分布中 T 与尺度不变量的独立性). 设 $X_1, X_2 \sim \text{Exp}(\theta)$ 。则 $Y_1 = X_1 + X_2$ 是完备充分统计量。

考虑比值 $Z = X_1/(X_1 + X_2)$ 。这是尺度不变的 ($Z(cX_1, cX_2) = Z(X_1, X_2)$), 因此 Z 的分布不含 θ 。

由 Basu 定理, Y_1 与 Z 独立。实际上, $Z \sim \text{Beta}(1, 1)$ (均匀分布), 与指数分布的参数无关。

EXAMPLE 7.26 (正态双参数中 $\bar{X}, S^2$ 与辅助量的独立性). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$ 。则 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量。

考虑统计量

$$Z = \frac{\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

该统计量满足位置-尺度不变性, 因此其分布不含 (θ_1, θ_2) 。由 Basu 定理, Z 与 $(\bar{X}, S^2)$ 独立。

9.3. Basu 定理的应用. Basu 定理的价值在于:

- (1) 提供独立性证明的简洁方法 (无需计算联合分布)
- (2) 揭示了“信息对立”: 完备充分统计量与辅助统计量正交
- (3) 辅助统计量虽然不含参数信息, 但可用于构建置信区间 (如枢轴量)

重要注记: 若充分统计量不是完备的, Basu 定理不适用——此时辅助统计量可能与充分统计量不独立, 辅助统计量中可能仍包含关于参数的**条件信息**。

EXAMPLE 7.27 (非完备情况下的条件信息). 在均匀分布 $(\theta - 1, \theta + 1)$ 例子中, 充分统计量是 $(Y_1, Y_n) = (\min X_i, \max X_i)$, 但它们不是完备的。

令 $T_1 = (Y_1 + Y_n)/2$ (θ 的无偏估计) 和 $T_2 = Y_n - Y_1$ (辅助的)。虽然 T_2 是辅助的, 但给定 $T_2 = t_2$ 的条件下, T_1 的方差为 $(2 - t_2)^2/12$ ——较小的 t_2 意味着 T_1 有更大的方差。

这说明 T_2 虽然是边缘意义下的辅助统计量, 但在条件意义下仍提供关于估计精度的信息。

这种情况在实际中很重要: 当样本来自非正态分布时, 样本均值 $\bar{X}$ 和样本方差 S^2 可能相关, S^2 的值能提供关于 $\bar{X}$ 精度的信息。

本节小结.

- Basu 定理: 完备充分统计量与任何辅助统计量独立
- 独立性证明的新工具: 无需计算联合分布
- 若充分统计量非完备, 辅助统计量可能携带条件信息
- 这解释了为什么正态分布中 $\bar{X}$ 与 S^2 的独立性如此特别

本章习题

EXERCISE 7.1. 7.1 Sufficient Statistic for Normal Variance—Hogg 7.2.1 Let $X_1, X_2, \dots, X_n$ be iid $N(0, \theta)$, $0 < \theta < \infty$. Show that $\sum_{i=1}^n X_i^2$ is a sufficient statistic for θ .

EXERCISE 7.2. 7.2.4 —Geometric Distribution Sufficiency Let $X_1, X_2, \dots, X_n$ be a random sample of size n from a geometric distribution that has pmf $f(x; \theta) = (1 - \theta)^x \theta$, $x = 0, 1, 2, \dots$, $0 < \theta < 1$, zero elsewhere. Show that $\sum_{i=1}^n X_i$ is a sufficient statistic for θ .

EXERCISE 7.3. 7.3.3 —Rao-Blackwell for Exponential Distribution If X_1, X_2 is a random sample of size 2 from a distribution having pdf $f(x; \theta) = (1/\theta)e^{-x/\theta}$, $0 < x < \infty$, $0 < \theta < \infty$, zero elsewhere, find the joint pdf of the sufficient statistic $Y_1 = X_1 + X_2$ for θ and $Y_2 = X_2$. Show that Y_2 is an unbiased estimator of θ with variance θ^2 . Find $E(Y_2 | y_1) = \varphi(y_1)$ and the variance of $\varphi(Y_1)$.

EXERCISE 7.4. 7.4.1 —Completeness of Binomial Family If $az^2 + bz + c = 0$ for more than two values of z , then $a = b = c = 0$. Use this result to show that the family $\{b(2, \theta) : 0 < \theta < 1\}$ is complete.

EXERCISE 7.5. 7.4.5 — *Complete Sufficient Statistic for Shifted Exponential* Show that the first order statistic $Y_1 = \min(X_i)$ of a random sample of size n from the distribution having pdf $f(x; \theta) = e^{-(x-\theta)}$, $\theta < x < \infty$, $-\infty < \theta < \infty$, zero elsewhere, is a complete sufficient statistic for θ . Find the unique function of this statistic which is the MVUE of θ .

EXERCISE 7.6. 7.5.2 — *MVUE via Exponential Class* Let $X_1, X_2, \dots, X_n$ denote a random sample of size $n > 1$ from a distribution with pdf $f(x; \theta) = \theta e^{-\theta x}$, $0 < x < \infty$, zero elsewhere, and $\theta > 0$. Then $Y = \sum_{i=1}^n X_i$ is a sufficient statistic for θ . Prove that $(n-1)/Y$ is the MVUE of θ .

EXERCISE 7.7. 7.6.1 — *MVUE of θ^2 for Normal* Let $X_1, X_2, \dots, X_n$ denote a random sample from a distribution that is $N(\theta, 1)$, $-\infty < \theta < \infty$. Find the MVUE of θ^2 .

EXERCISE 7.8. 7.9.1 — *Basu's Theorem for Uniform Distribution* Let $Y_1 < Y_2 < Y_3 < Y_4$ denote the order statistics of a random sample of size $n = 4$ from a distribution having pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, zero elsewhere, where $0 < \theta < \infty$. Argue that the complete sufficient statistic Y_4 for θ is independent of each of the statistics Y_1/Y_4 and $(Y_1 + Y_2)/(Y_3 + Y_4)$.

Optimal Statistical Tests

Chapter 8 Overview

在前几章中，我们建立了估计理论和假设检验的基本框架。我们学会了如何构造点估计、区间估计，以及如何使用似然比检验。但在所有这些讨论中，一个根本性的问题始终潜伏在幕后：

在所有可能的检验中，哪个检验是“最好”的？

这个问题——即**最优检验理论 (optimal test theory)**——是本章的核心。在假设检验中，我们面临一个固有的权衡 (trade-off)：降低第一类错误 (Type I error) 的概率往往意味着提高第二类错误 (Type II error) 的概率，反之亦然。最优检验理论试图在固定的显著性水平下，找到功效 (power) 最高的检验。

为什么需要最优性理论？ 考虑一个医学检测场景：我们希望设计一个检验来筛查某种疾病。给定显著性水平 $\alpha = 0.05$ ，我们当然希望当患者真的患病时，检验能以最高概率检测出来——这就是功效。没有最优性理论，我们只能在黑暗中摸索不同的检验方法，无法保证我们选择的检验是最佳的。

本章建立这套理论的路径如下：

- (1) **Neyman-Pearson 引理** (8.1 节)：对于简单假设对简单假设的情况，给出了最优检验的完整刻画——这是整个理论的基石。
- (2) **一致最大功效检验 (UMP)** (8.2 节)：将最优性概念推广到复合备择假设。介绍 monotone likelihood ratio (MLR) 和 Karlin-Rubin 定理——单参数指数族存在 UMP 检验。
- (3) **似然比检验 (LRT)** (8.3 节)：在一般复合假设下，LRT 提供了一种构造检验的通用方法。虽然 LRT 不一定是最优的，但在很多情况下它是渐近最优的。
- (4) **序贯概率比检验 (SPRT)** (8.4 节)：打破固定样本量的束缚，允许检验在数据积累过程中随时停止——Wald 的革命性贡献。
- (5) **极小化极大分类** (8.5 节)：将决策论框架应用于假设检验和分类问题。

1. 8.1 Most Powerful Tests

1.1. 问题的起源：什么是“最好”的检验。 在 4.5 节中，我们引入了假设检验的基本框架：给定原假设 H_0 和备择假设 H_1 ，我们构造一个临界区域 C ，当样本落入 C 时拒绝 H_0 。但正如我们在 4.5 节所见，对于同一对假设，存在无穷多个可能的检验——临界区域 C 的选择并非唯一。

在所有这些检验中，我们凭什么说一个比另一个更好？

要回答这个问题，我们首先需要有一个评价标准。在假设检验中，这个标准就是**功效 (power)**——当 H_1 为真时拒绝 H_0 的概率。直观上，我们希望：

- (1) 在 H_0 为真时，拒绝 H_0 的概率（即 α ，显著性水平）不超过预设值；
- (2) 在 H_1 为真时，拒绝 H_0 的概率（即功效）尽可能高。

这就引出了“最好检验”的定义。

1.2. 简单假设对简单假设的最优检验. 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本，其中 $\theta \in \Omega = \{\theta', \theta''\}$ （即只有两个可能的参数值）。我们考虑检验：

$$H_0 : \theta = \theta' \quad \text{versus} \quad H_1 : \theta = \theta''.$$

(8.1.1)

DEFINITION 8.1 (最佳临界区域). 设 C 是样本空间的一个子集。如果

- (a) $P_{\theta'}[\mathbf{X} \in C] = \alpha$ （大小为 α ）；
- (b) 对每一个满足 $P_{\theta'}[\mathbf{X} \in A] = \alpha$ 的子集 A ，都有

$$P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A],$$

则称 C 是检验 $H_0 : \theta = \theta'$ 对 $H_1 : \theta = \theta''$ 的大小为 α 的**最佳临界区域 (best critical region of size α)**。

定义的直观含义：在所有满足显著性水平 α 的检验中，最佳临界区域对应的检验在 H_1 为真时具有最高的拒绝概率——这正是我们想要的。

为什么要关心最佳检验？设想你在设计一个药物试验。你设定 $\alpha = 0.05$ （即当药物无效时，只有 5% 的概率错误地拒绝 H_0 ）。在所有满足这个条件的检验中，你当然希望当药物真的有效时，以最高概率检测出来——这就是最佳检验的价值。

那么，这样的最佳检验是否存在？Neyman-Pearson 定理给出了答案。

1.3. Neyman-Pearson 定理.

有没有一种系统性的方法构造最佳检验？

Neyman-Pearson 定理不仅回答了“最佳检验是否存在”的问题，还给出了构造方法——它是以似然比 (likelihood ratio) 为基础的。

theorem[Neyman-Pearson] 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本，记似然函数为

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

设 θ' 和 θ'' 是 θ 的两个不同取值， $\Omega = \{\theta', \theta''\}$ 。设 $k > 0$ 是一个常数， C 是样本空间的一个子集，满足：

- (a) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$ 对所有 $\mathbf{x} \in C$ ；

- (b) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k$ 对所有 $\mathbf{x} \in C^c$;
 (c) $\alpha = P_{H_0}[\mathbf{X} \in C]$ 。

则 C 是检验简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ 的、大小为 α 的最佳临界区域。
 theorem

核心思想：似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x})$ 衡量了数据 $\mathbf{x}$ 更支持 H_0 还是更支持 H_1 。当这个比值很小时，数据更支持 H_1 ，因此我们拒绝 H_0 。

物理直觉：想象你在两个假设之间做选择。 $L(\theta'; \mathbf{x})$ 告诉我们“如果 H_0 为真，观察到这组数据的可能性有多大”； $L(\theta''; \mathbf{x})$ 在 H_0 下很小但在 H_1 下很大，这强烈暗示 H_1 才是正确的解释。

充分性：值得注意的是，定理的证明表明，如果存在一个大小为 α 的最佳检验，那么它的形式必然是上述似然比检验。而且，这个最佳检验（如果存在）是唯一的（在连续型情况下，除了一个零概率集；在离散型中可能存在多个）。¹

EXAMPLE 8.1 (二项分布下的最佳检验). 设 $X \sim \text{Binomial}(n = 5, p = \theta)$ ，考虑检验：

$$H_0: \theta = \frac{1}{2} \quad \text{versus} \quad H_1: \theta = \frac{3}{4}.$$

下表给出 $f(x; 1/2)$ 、 $f(x; 3/4)$ 以及它们的比值：

x	0	1	2	3	4	5
$f(x; 1/2)$	1/32	5/32	10/32	10/32	5/32	1/32
$f(x; 3/4)$	1/1024	15/1024	90/1024	270/1024	405/1024	243/1024
$f(x; 1/2)/f(x; 3/4)$	32/1	32/3	32/9	32/27	32/81	32/243

问题：构造大小 $\alpha = 1/32$ 的最佳检验。

比值 $f(x; 1/2)/f(x; 3/4)$ 在 $x = 5$ 处取得最小值 (32/243)。因此，最佳临界区域应包含那些使 H_0 看起来极不可能而 H_1 看起来极可能的数据点——即 $C = \{x = 5\}$ 。

验证： $P_{H_0}(X \in C) = f(5; 1/2) = 1/32 = \alpha$ ，且 $P_{H_1}(X \in C) = f(5; 3/4) = 243/1024 \approx 0.237$ 。

如果取 $\alpha = 6/32$ ，则最佳临界区域为 $\{x = 4, 5\}$ ，因为 $x = 4$ 和 $x = 5$ 的比值最小。此时

$$P_{H_1}(X \in \{4, 5\}) = \frac{405}{1024} + \frac{243}{1024} = \frac{648}{1024} \approx 0.633.$$

关键洞察：最佳检验包含了“最支持 H_1 而最不支持 H_0 ”的数据点——这正是似然比方法告诉我们的。²

EXAMPLE 8.2 (正态均值差假设的最优检验). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ ，考虑检验：

$$H_0: \theta = 0 \quad \text{versus} \quad H_1: \theta = 1.$$

¹Neyman-Pearson 引理的完整证明见附录 section 5.3。

²二项分布最佳检验的详细分析见附录 ??。

构造最佳检验：似然函数为

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

似然比为

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \exp \left(-\sum_{i=1}^n x_i + \frac{n}{2} \right).$$

令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$ ，等价于

$$\sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

因此，最佳临界区域是 $C = \{\mathbf{x} : \sum_{i=1}^n x_i \geq c\}$ ，即基于样本均值 $\bar{X}$ 的检验。

确定临界值：当 H_0 为真时， $\bar{X} \sim N(0, 1/n)$ ，故

$$c_1 = \frac{c}{n} = \frac{\frac{n}{2} - \log k}{n} = \frac{1}{2} - \frac{\log k}{n}.$$

给定显著性水平 α ，临界值为 $c_1 = q_\alpha(0, 1/\sqrt{n})$ ($N(0, 1/n)$ 的上 α 分位数)。

数值示例：设 $n = 25$ ， $\alpha = 0.05$ ，则 $c_1 = \mathbf{qnorm}(0.95, 0, 1/5) = 0.329$ 。

功效计算：当 H_1 为真时， $\bar{X} \sim N(1, 1/25)$ ，功效为

$$Power = P_{H_1}(\bar{X} \geq 0.329) = 1 - \Phi \left(\frac{0.329 - 1}{1/5} \right) = 1 - \Phi(-3.355) \approx 0.9996.$$

也就是说，当 $\theta = 1$ 时，这个检验有约 99.96% 的概率正确拒绝 H_0 。³

EXAMPLE 8.3 (Poisson 对 Geometric 的检验). 设 $X_1, \dots, X_n \sim f(x)$ ，其中

$$H_0 : f(x) = \frac{e^{-1}}{x!}, \quad x = 0, 1, 2, \dots \quad (\text{Poisson}(\lambda = 1)),$$

$$H_1 : f(x) = \left(\frac{1}{2}\right)^{x+1}, \quad x = 0, 1, 2, \dots \quad (\text{Geometric}(p = 1/2)).$$

构造最佳检验：似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \frac{(2e^{-1})^n \cdot 2^{\sum x_i}}{\prod_{i=1}^n (x_i!)}.$$

令 $k = 1$ (对应某个特定的 α)，不等式化为

$$\frac{2^{\sum x_i}}{\prod_{i=1}^n (x_i!)} \leq \frac{e}{2}.$$

取 $n = 1$ ，则临界区域为 $C = \{x_1 : x_1 = 0, 3, 4, 5, \dots\}$ 。

验证：

$$\alpha = P_{H_0}(X \in C) = 1 - \frac{e^{-1}}{1!} - \frac{e^{-1}}{2!} = 1 - \frac{2}{e} \approx 0.4482,$$

$$Power = P_{H_1}(X \in C) = 1 - \frac{1}{4} - \frac{1}{8} = 0.625.$$

这符合无偏性要求 (功效大于显著性水平)。⁴

³正态均值检验的完整推导见附录 section 5.4。

⁴Poisson vs Geometric 检验的详细分析见附录 ??。

无偏性 (Unbiasedness): 注意到所有最佳检验都满足一个共同性质——功效大于等于显著性水平。这意味着拒绝 H_0 (当它为假时) 的概率不小于错误拒绝它的概率。这在经济决策中是完全合理的——如果检验的功效低于 α , 那它的行为还不如随机猜测。

DEFINITION 8.2 (无偏检验). 设 C 是显著性水平为 α 的检验的临界区域。如果对所有 $\theta \in \omega_1$,

$$P_{\theta}(\mathbf{X} \in C) \geq \alpha,$$

则称该检验是**无偏的 (unbiased)**。

推论 8.1.1 表明 Neyman-Pearson 最佳检验是无偏的——在 H_0 为假时拒绝它的概率不低于在 H_0 为真时错误拒绝它的概率。⁵

2. 8.2 Uniformly Most Powerful Tests

2.1. 从简单假设到复合假设. 上一节的 Neyman-Pearson 定理解决的是“简单假设对简单假设”的问题—— H_0 和 H_1 都各只有一个参数值。但在实际中, 备择假设通常是复合的 (composite), 例如:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

这里 H_1 包含无穷多个参数值。对于这样的问题, 我们自然希望找到一个检验, 它在 H_0 的每一个边界点上都是最佳的。

能否找到一个检验, 它对 $\theta > \theta'$ 中的每一个 θ 都是最佳检验?

这就是“一致最大功效 (Uniformly Most Powerful, UMP)”检验的思想。

DEFINITION 8.3 (UMP 检验). 设 C 是显著性水平为 α 的检验的临界区域。如果 C 是 H_0 对 H_1 中每一个简单假设的最佳临界区域, 则称 C 为**大小为 α 的一致最大功效临界区域 (UMP critical region)**, 相应的检验称为 **UMP 检验 (Uniformly Most Powerful test)**。

但 UMP 检验并不总是存在。例 8.2.3 展示了: 对于正态均值 $\sigma^2 = 1$ 已知时, 检验 $H_0: \theta = \theta'$ 对 $H_1: \theta \neq \theta'$ (双向备择) 不存在 UMP 检验——因为对 $\theta'' > \theta'$ 的最佳临界区域 (拒绝域在右尾) 与对 $\theta'' < \theta'$ 的最佳临界区域 (拒绝域在左尾) 形式完全不同, 无法统一。

这个例子揭示了一个深刻的事实: UMP 检验只在单向备择假设 (one-sided alternatives) 下才可能存在。

⁵推论 8.1.1 的证明及无偏性的讨论见附录 ??。

2.2. 单调似然比与 Karlin-Rubin 定理. 那么, 在什么条件下 UMP 检验存在呢? 答案藏在一种叫做“单调似然比 (Monotone Likelihood Ratio, MLR)”的性质中。

DEFINITION 8.4 (单调似然比). 设 $L(\theta, \mathbf{x})$ 是似然函数。如果对 $\theta_1 < \theta_2$, 比值

$$\frac{L(\theta_1; \mathbf{x})}{L(\theta_2; \mathbf{x})}$$

是统计量 $y = u(\mathbf{x})$ 的单调递减函数, 则称似然函数在 $y = u(\mathbf{x})$ 中有单调似然比 (*monotone likelihood ratio, mlr*)。

为什么 MLR 如此重要? MLR 性质确保了对较大的 y (即更支持备择假设的数据), 我们统一拒绝 H_0 ——而不需要针对每一个具体的 θ'' 分别构造最佳检验。

heorem[Karlin-Rubin 定理] 设随机样本来自密度 $f(x; \theta)$, 似然函数 $L(\theta, \mathbf{x})$ 在统计量 $Y = u(\mathbf{X})$ 中有单调似然比。考虑单向假设:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

则对任意显著性水平 α , UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y \geq c_Y,$$

其中临界值 c_Y 满足 $P_{\theta'}[Y \geq c_Y] = \alpha$ 。heorem

核心洞察: 由于 MLR 性质, 对任何 $\theta'' > \theta'$, 最佳临界区域的形式都是 $Y \geq c$ ——它们恰好是同一个区域! 因此这个区域对所有 $\theta'' > \theta'$ 都是最佳的, 从而是一致最大功效的。

证明思路: 对固定的 $\theta'' > \theta'$, 由 Neyman-Pearson 定理, 最佳临界区域由似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x}) \leq k$ 给出。由于 MLR 性质, 这个不等式等价于 $Y \geq g^{-1}(k)$ ——即只依赖于数据的形状, 而不依赖于具体的 θ'' 值。⁶

EXAMPLE 8.4 (正态方差 UMP 检验). 设 $X_1, \dots, X_n \sim N(0, \theta)$, 其中 $\theta > 0$ 是方差。考虑检验:

$$H_0: \theta = \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然函数为

$$L(\theta; \mathbf{x}) = \left(\frac{1}{2\pi\theta}\right)^{n/2} \exp\left\{-\frac{1}{2\theta} \sum_{i=1}^n x_i^2\right\}.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left(\frac{\theta''}{\theta'}\right)^{n/2} \exp\left[-\left(\frac{\theta'' - \theta'}{2\theta'\theta''}\right) \sum_{i=1}^n x_i^2\right].$$

对 $\theta'' > \theta'$, 这是 $\sum x_i^2$ 的递减函数, 因此似然函数在 $Y = \sum X_i^2$ 中有 MLR。

由 Karlin-Rubin 定理, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad \sum_{i=1}^n X_i^2 \geq c,$$

⁶Karlin-Rubin 定理的完整证明见附录 section 5.5。

其中 c 满足 $P_{\theta'}[\sum X_i^2 \geq c] = \alpha$ 。

数值示例： 设 $n = 15$, $\alpha = 0.05$, $\theta' = 3$ 。当 H_0 为真时, $\sum X_i^2/\theta' \sim \chi^2(n)$, 故

$$\frac{c}{3} = \chi_{0.95}^2(15) = 24.996 \Rightarrow c = 74.988.$$

即当 $\sum x_i^2 \geq 74.988$ 时拒绝 $H_0: \theta = 3$ 。⁷

EXAMPLE 8.5 (Bernoulli 分布的 UMP 检验). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$, 考虑检验:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left[\frac{\theta'(1-\theta'')}{\theta''(1-\theta')} \right]^{\sum x_i} \left(\frac{1-\theta'}{1-\theta''} \right)^n.$$

由于 $\theta' < \theta''$ 时 $\theta'(1-\theta'')/\theta''(1-\theta') < 1$, 该比值是 $Y = \sum X_i$ 的递减函数。因此似然函数在 $Y = \sum X_i$ 中有 MLR, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y = \sum_{i=1}^n X_i \geq c,$$

其中 c 由 $P_{\theta'}[Y \geq c] = \alpha$ 确定。

这正是我们直观上期望的: 观察到更多的成功次数, 就越有理由拒绝“成功率不高”的原假设。⁸

正规指数族 (Regular Exponential Family): 其实 Bernoulli 分布、正态分布 (方差已知)、Poisson 分布都属于一个更广泛的族——正规指数族。在这个族中, 只要自然参数是单调的, 就存在 UMP 检验。具体地, 如果分布有形式

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)],$$

且 $p(\theta)$ 是 θ 的递增函数, 则对假设 $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$, UMP 检验存在, 基于统计量 $Y = \sum_{i=1}^n K(X_i)$ 。⁹

3. 8.3 Likelihood Ratio Tests

3.1. 似然比检验的动机. 在前两节中, 我们学会了如何在简单假设对简单假设时构造最佳检验, 以及在具有 MLR 性质的族中对单向复合假设构造 UMP 检验。但现实中很多重要问题超出了这些范畴:

- 检验正态均值 $H_0: \mu = \mu_0$ (σ^2 未知) 对 $H_1: \mu \neq \mu_0$ ——不存在 UMP 检验 (双向备择);
- 检验两正态均值是否相等 $H_0: \mu_1 = \mu_2$ ——涉及多于一个参数;
- 一般复合假设——没有 MLR 性质可供利用。

⁷正态方差 UMP 检验的详细推导见附录 ??。

⁸Bernoulli UMP 检验的 MLR 证明见附录 ??。

⁹正规指数族的 UMP 检验存在性讨论见附录 ??。

在这些情况下，我们转向一种通用但不一定最优的构造检验的方法——**似然比检验 (Likelihood Ratio Test, LRT)**。

为什么即使 LRT 不是最优的，我们仍然使用它？历史上，Neyman 和 Pearson 引入 LRT 的动机正是为了突破最佳检验只存在于简单假设的限制。LRT 继承了 Neyman-Pearson 定理的似然比思想（用似然比衡量数据对假设的支持程度），但将比较扩展到了复合假设。虽然在一般情况下 LRT 不能保证最优性，但它是渐近最优的——在样本量趋向无穷时，LRT 具有许多优良性质。¹⁰

3.2. LRT 的定义. 设 X 的密度为 $f(\mathbf{x}; \boldsymbol{\theta})$ ，参数 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$ 。考虑复合假设：

$$H_0 : \boldsymbol{\theta} \in \omega \quad \text{versus} \quad H_1 : \boldsymbol{\theta} \in \Omega \cap \omega^c,$$

(8.3.1)

其中 $\omega \subset \Omega$ 是参数空间的某个子集。

DEFINITION 8.5 (似然比). **似然比 (Likelihood Ratio)** 定义为：

$$\Lambda(\mathbf{x}) = \frac{\sup_{\omega} L(\boldsymbol{\theta}; \mathbf{x})}{\sup_{\Omega} L(\boldsymbol{\theta}; \mathbf{x})} = \frac{L(\hat{\omega}; \mathbf{x})}{L(\hat{\Omega}; \mathbf{x})},$$

其中 $\hat{\omega}$ 是在约束 $\boldsymbol{\theta} \in \omega$ 下的 MLE, $\hat{\Omega}$ 是在无约束 $\boldsymbol{\theta} \in \Omega$ 下的 MLE。

直观含义：分子衡量数据在 H_0 约束下能达到的最大似然，分母衡量数据在无约束情况下能达到的最大似然。如果 H_0 为真，这两个值应该差不多，比值接近 1；如果 H_0 为假，无约束的似然会显著大于约束下的似然，比值会变小。因此我们在**小比值时拒绝 H_0** ：

$$\text{Reject } H_0 \quad \text{if} \quad \Lambda(\mathbf{x}) \leq \lambda_0 < 1.$$

LRT 的一个关键性质：在 H_0 下， $-2 \log \Lambda$ 渐近服从 χ^2 分布，自由度为 $\dim(\Omega) - \dim(\omega)$ （在一定正则条件下）。这使得我们可以近似地确定临界值。

LRT 与 NP 引理的关系：当 $\Omega = \{\theta', \theta''\}$ （只有两点）时，LRT 还原为 NP 似然比检验，此时它是最优的。但一般来说，LRT 不一定是最优的。

接下来我们把 LRT 应用到几个具体的重要情形——正态均值差和正态方差检验。

3.3. 8.3.1 正态均值差的 LRT.

EXAMPLE 8.6 (两样本 t 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_3)$ ，两组样本独立，共同方差 θ_3 未知。考虑检验：

$$H_0 : \theta_1 = \theta_2 \quad \text{versus} \quad H_1 : \theta_1 \neq \theta_2.$$

¹⁰LRT 与 Neyman-Pearson 引理的关系讨论见附录 ??。

构造 **LRT**: 在 H_0 下 ($\theta_1 = \theta_2 = \mu$), 参数的 MLE 为

$$\hat{\mu} = \frac{n\bar{x} + m\bar{y}}{n + m}, \quad \hat{\sigma}_0^2 = \frac{1}{n + m} \left[\sum_{i=1}^n (x_i - \hat{\mu})^2 + \sum_{i=1}^m (y_i - \hat{\mu})^2 \right].$$

在无约束下 (H_1), MLE 分别为 $\bar{x}$ 、 $\bar{y}$ 和

$$\hat{\sigma}^2 = \frac{1}{n + m} \left[\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 \right].$$

似然比为

$$\Lambda = \frac{L(\hat{\omega})}{L(\hat{\Omega})} = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2} \right)^{(n+m)/2}.$$

与 t 统计量的联系: 可以证明

$$\Lambda^{2/(n+m)} = \frac{(n + m - 2)}{(n + m - 2) + T^2},$$

其中

$$T = \sqrt{\frac{nm}{n + m}} \frac{\bar{x} - \bar{y}}{S_p}, \quad S_p^2 = \frac{(n - 1)S_x^2 + (m - 1)S_y^2}{n + m - 2}.$$

T 服从自由度为 $n + m - 2$ 的 t 分布 (在 H_0 下)。由于 $\Lambda \leq \lambda_0 \Leftrightarrow |T| \geq c$, LRT 就是经典的两样本 t 检验。

数值示例: 设 $n = 10$, $m = 6$, $\alpha = 0.05$, 则临界值

$$c = t_{0.975}(14) = 2.1448.$$

如果 $|t| \geq 2.1448$, 拒绝 H_0 (认为两个总体均值不相等)。¹¹

功效函数: 对于非中心 t 分布, 当 $\theta_1 \neq \theta_2$ 时, T 服从非中心 t 分布, 非中心参数为

$$\delta = \sqrt{\frac{nm}{n + m}} \frac{\theta_1 - \theta_2}{\sigma}.$$

给定 $\theta_3 = 100$ 、 $n = 20$ 、 $m = 15$ 、 $\alpha = 0.05$ 、 $\Delta = 5 = \theta_1 - \theta_2$, 临界值 $t_{0.975}(33) = 2.0345$, 非中心参数 $\delta_2 = 1.4639$, 功效约为

$$1 - \text{pt}(2.0345, 33, \text{ncp} = 1.4639) + \text{pt}(-2.0345, 33, \text{ncp} = 1.4639) \approx 0.2954.$$

即约 29.5% 的概率检测出均值为 5 的差异。¹²

稳健性注记: t 检验在正态性假设不满足时表现如何? 在大样本下, 由 Slutsky 定理, 即使底层分布非正态, 只要方差有限, t 统计量仍然渐近正态——因此 t 检验是**渐近正确的**。然而, 在有限样本且严重非正态 (特别是高度偏态) 时, t 检验可能失效——实际显著性水平会偏离名义水平。¹³

¹¹两样本 t 检验的完整推导见附录 ??。

¹²非中心 t 分布的功效计算见附录 ??。

¹³非正态情况下 t 检验的稳健性讨论见附录 ??。

3.4. 8.3.2 正态方差的 LRT.

EXAMPLE 8.7 (两方差相等的 F 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_4)$, 独立样本, 考虑检验:

$$H_0 : \theta_3 = \theta_4 \quad \text{versus} \quad H_1 : \theta_3 \neq \theta_4.$$

可以证明 (练习 8.3.11), LRT 统计量可以化为

$$F = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)}{\sum_{i=1}^m (Y_i - \bar{Y})^2 / (m-1)}.$$

(8.3.2)

在 H_0 下, $F \sim F(n-1, m-1)$ 。因此双向 LRT 为:

$$\text{Reject } H_0 \quad \text{if} \quad F \leq c_1 \quad \text{or} \quad F \geq c_2,$$

其中 c_1 和 c_2 满足 $P(F \leq c_1) = P(F \geq c_2) = \alpha_1/2$ 。

重要警告: 与 t 检验不同, F 检验对正态性假设是敏感的。在非正态情况下, F 检验的名义水平和实际水平可能相差甚远 (可高达 0.80), 因此不应在正态性未经检验的情况下使用 F 检验。¹⁴

4. 8.4 *Sequential Probability Ratio Test

4.1. 固定样本量检验的局限性. 到目前为止, 我们讨论的所有检验都有一个共同假设: 样本量 n 是预先固定的。但在实际应用中, 固定样本量检验存在一个根本性的低效:

为什么要等到收集完所有 n 个样本才做决策? 为什么不能边收集边决策?

考虑一个质量控制场景: 你需要判断一条生产线是否正常 ($\theta = \theta_0$)。固定样本量方法要求你先收集 n 个样本, 然后做决策。但如果在第 5 个样本时, 数据就已经极其强烈地支持 H_1 (生产线已严重偏离正常状态), 继续等待其余 $n-5$ 个样本就是在浪费时间和资源。

1930 年代, Abraham Wald 提出了一个革命性的思想: 允许样本量根据数据动态确定——这就是序贯分析 (sequential analysis) 的诞生。

Wald 的序贯概率比检验 (SPRT) 不仅在概念上优雅, 而且在功效和样本量之间实现了最优权衡。

¹⁴方差 F 检验的稳健性问题见附录 ??。

4.2. SPRT 的构造. 设 $X_1, X_2, \dots$ 是 iid 随机变量序列, 考虑检验:

$$H_0 : \theta = \theta' \quad \text{versus} \quad H_1 : \theta = \theta'',$$

其中 θ' 和 θ'' 是给定的具体值。

核心思想: 在每个步骤 n , 计算似然比

$$\Lambda_n = \frac{L(\theta'; x_1, \dots, x_n)}{L(\theta''; x_1, \dots, x_n)} = \prod_{i=1}^n \frac{f(x_i; \theta')}{f(x_i; \theta'')}.$$

如果 Λ_n 非常小 (即数据强烈支持 H_1), 我们就提前停止并拒绝 H_0 ; 如果 Λ_n 非常大 (即数据强烈支持 H_0), 我们就提前停止并接受 H_0 ; 如果 Λ_n 处于中间位置, 我们就继续观察下一个样本。

具体地, 选取两个常数 $A < B$ (通常 $A = \beta/(1 - \alpha)$, $B = (1 - \beta)/\alpha$), SPRT 的决策规则为:

$$(8.4.1) \quad \text{在第 } n \text{ 步, 停止采样并: } \begin{cases} \text{拒绝 } H_0 \text{ (接受 } H_1) & \text{if } \Lambda_n \leq A, \\ \text{接受 } H_0 \text{ (拒绝 } H_1) & \text{if } \Lambda_n \geq B, \\ \text{继续采样} & \text{if } A < \Lambda_n < B. \end{cases}$$

Wald 的关键近似: 在实际应用中, Wald 证明了可以通过近似 $A \approx \beta/\alpha$ 和 $B \approx (1 - \beta)/(1 - \alpha)$ 来设置常数, 其中 α 和 β 分别是目标第一类和第二类错误概率。

EXAMPLE 8.8 (Bernoulli 的 SPRT). 设 $X_i \sim \text{Bernoulli}(\theta)$, 检验 $H_0 : \theta = 1/3$ 对 $H_1 : \theta = 2/3$ 。

似然比为

$$\Lambda_n = \frac{(1/3)^{\sum x_i} (2/3)^{n - \sum x_i}}{(2/3)^{\sum x_i} (1/3)^{n - \sum x_i}} = 2^{n - 2 \sum x_i}.$$

取对数并整理, 不等式 $A < \Lambda_n < B$ 等价于

$$c_0(n) = \frac{n}{2} - \frac{\log_2 B}{2} < \sum_{i=1}^n x_i < \frac{n}{2} - \frac{\log_2 A}{2} = c_1(n).$$

决策规则: 当 $\sum x_i \geq c_1(n)$ 时, 拒绝 H_0 ; 当 $\sum x_i \leq c_0(n)$ 时, 接受 H_0 ; 否则继续采样。

序贯抽样的图示: 想象一条随机游走——每观察一次 $X_i = 1$, 我们就向右跳 1 个单位; 每观察一次 $X_i = 0$, 我们就向左跳 1 个单位。只要这条路径处于上下边界之间, 我们就继续。一旦路径碰到上界 (强烈支持 H_1) 或下界 (强烈支持 H_0), 我们就停止并做出相应决策。¹⁵

¹⁵Bernoulli SPRT 的详细分析见附录 ??。

EXAMPLE 8.9 (正态均值的 SPRT). 设 $X_1, X_2, \dots \sim N(\theta, 100)$, 检验 $H_0 : \theta = 75$ 对 $H_1 : \theta = 78$, 目标是使 $\alpha \approx \beta \approx 0.10$ 。

取 $A = 1/9$ 、 $B = 9$ 。似然比为

$$\Lambda_n = \exp \left(-\frac{6 \sum x_i - 459n}{200} \right).$$

不等式 $A < \Lambda_n < B$ 化为

$$c_0(n) = \frac{153}{2}n - \frac{100}{3} \log 9 < \sum_{i=1}^n x_i < \frac{153}{2}n + \frac{100}{3} \log 9 = c_1(n).$$

决策规则：在第 n 步，当 $\sum x_i \geq c_1(n)$ 时拒绝 H_0 (认为 $\theta = 78$)；当 $\sum x_i \leq c_0(n)$ 时接受 H_0 (认为 $\theta = 75$)；否则继续采样。¹⁶

SPRT 的吸引力：为什么 SPRT 如此重要？因为它在固定两类错误概率的同时，通常使用比固定样本量检验更少的样本。Wald 的近似理论表明，当 H_0 或 H_1 为真时，SPRT 的平均样本量 (Average Sample Number, ASN) 比相应的固定样本量检验小得多——有时能节省 50% 以上的样本。

SPRT 与质量控制：SPRT 的思想在工业质量控制中有广泛应用。CUSUM (累积和) 控制图就是 SPRT 的一个变体——它持续累积标准化后的偏离量 $\sum (Z_i - 0.5)$ (其中 Z_i 是标准化后的检验统计量)，一旦超出控制限就发出警报。与固定间隔的 Shewhart 控制图相比，CUSUM 能更快检测到过程均值的微小漂移。

5. 8.5 *Minimax and Classification Procedures

5.1. 8.5.1 极小化极大检验。在第 7 章的决策论框架中，我们介绍了极小化极大 (minimax) 原则：将最大风险最小化。将这个思想应用到假设检验中，会得到一个有趣的结论——Neyman-Pearson 最佳检验在某种意义上也是极小化极大的。

考虑简单假设 $H_0 : \theta = \theta'$ 对 $H_1 : \theta = \theta''$ ，损失函数满足 $\mathcal{L}(\theta', \theta') = \mathcal{L}(\theta'', \theta'') = 0$ (正确决策无损失)，而 $\mathcal{L}(\theta', \theta'') > 0$ 和 $\mathcal{L}(\theta'', \theta') > 0$ (错误决策有损失)。¹⁷

此时风险函数为：

$$R(\theta', C) = \mathcal{L}(\theta', \theta'') \cdot \alpha, \quad R(\theta'', C) = \mathcal{L}(\theta'', \theta') \cdot \beta,$$

其中 α 是显著性水平， β 是 Type II 错误概率。

极小化极大原则要求选择 C 使得 $\max\{R(\theta', C), R(\theta'', C)\}$ 最小。可以证明，当 k 满足

$$\mathcal{L}(\theta', \theta'') \int_C L(\theta') = \mathcal{L}(\theta'', \theta') \int_{C^c} L(\theta'')$$

¹⁶正态 SPRT 的完整推导见附录 ??。

¹⁷极小化极大检验的决策论框架见附录 ??。

时（即两类错误造成的风险相等），临界区域 C 是极小化极大的。这个条件与 NP 似然比条件是一致的——本质上，最佳检验同时也是极小化极大检验（当两类错误的相对代价被适当选择时）。¹⁸

EXAMPLE 8.10 (正态均值的极小化极大检验). 设 $X_1, \dots, X_{100} \sim N(\theta, 100)$, 检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$, 损失为 $\mathcal{L}(75, 78) = 3$ 、 $\mathcal{L}(78, 75) = 1$ 。

临界区域形如 $\bar{x} \geq c$, 其中 c 满足:

$$3 \cdot P_{\theta=75}(\bar{X} \geq c) = P_{\theta=78}(\bar{X} < c).$$

由于 $\bar{X} \sim N(\theta, 1)$, 这化为

$$3[1 - \Phi(c - 75)] = \Phi(c - 78).$$

求解得 $c \approx 76.8$ 。此时显著性水平 $\alpha = 1 - \Phi(1.8) \approx 0.036$, 功效为 $1 - \Phi(-1.2) \approx 0.885$ 。¹⁹

5.2. 8.5.2 分类问题. 极小化极大检验理论在分类 (classification) 问题中有直接应用。考虑一个二分类问题: 我们观察到 (X, Y) , 需要判断它来自分布 $f(x, y; \theta')$ 还是 $f(x, y; \theta'')$ 。

这本质上就是假设检验问题——如果接受 H_0 , 就把 (X, Y) 分类为来自 θ' 类; 如果拒绝 H_0 , 就分类为来自 θ'' 类。

由 NP 定理, 最佳分类规则是似然比规则:

$$\frac{f(x, y; \theta')}{f(x, y; \theta'')} \leq k \implies \text{分类为 } \theta'' \text{ 类}.$$

若两类的先验概率为 π' 和 π'' , 则最优规则取 $k = \pi''/\pi'$ (当两类等可能时 $k = 1$)。

Fisher 线性判别函数: 在正态分布的特殊情况下, 似然比不等式化为一个线性函数 $ax + by \leq c$ ——这就是著名的 Fisher 线性判别函数。当参数未知时, 用训练样本的均值和方差代替, 就得到了 Fisher 判别函数。²⁰

[二元正态的线性判别] 设 (X, Y) 来自二元正态分布, 参数为 $(\mu'_1, \mu'_2, \sigma_1^2, \sigma_2^2, \rho')$ 或 $(\mu''_1, \mu''_2, \sigma_1^2, \sigma_2^2, \rho'')$ 。则似然比不等式化为

$$ax + by \leq c,$$

¹⁸极小化极大检验的完整证明见附录 ??。

¹⁹极小化极大检验的数值求解 (Newton 法) 见附录 ??。

²⁰Fisher 线性判别函数的完整推导见附录 ??。

其中 a 和 b 是由两个总体的均值向量和协方差矩阵决定的常数。这给出了一个**线性决策边界**——在二维空间中是一条直线，将平面分为两部分，分别对应两类。²¹

附录：公式推导

本附录包含 Chapter 8 中省略的完整推导。

5.3. Neyman-Pearson 引理的证明. 背景 (Background): 我们需要证明，当临界区域 C 满足 NP 条件 (a) -(c) 时，它是在固定显著性水平 α 下功效最高的检验。

已知条件 (Given):

- $L(\theta'; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta')$ 是 H_0 下的似然函数
- $L(\theta''; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta'')$ 是 H_1 下的似然函数
- 临界区域 C 满足:

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k, \quad \forall \mathbf{x} \in C; \quad \frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k, \quad \forall \mathbf{x} \in C^c.$$

- 任意其他满足 $P_{\theta'}[\mathbf{X} \in A] = \alpha$ 的区域 A 。

目标 (Goal): 证明 $P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A]$ 。

推导步骤 (Derivation Steps):

1. 写出功效差:

$$\int_C L(\theta'') - \int_A L(\theta'') = \int_{C \cap A^c} L(\theta'') - \int_{A \cap C^c} L(\theta'').$$

2. 由条件 (a): 在 C 上 $L(\theta'') \geq \frac{1}{k} L(\theta')$, 故

$$\int_{C \cap A^c} L(\theta'') \geq \frac{1}{k} \int_{C \cap A^c} L(\theta').$$

3. 由条件 (b): 在 C^c 上 $L(\theta'') \leq \frac{1}{k} L(\theta')$, 故

$$\int_{A \cap C^c} L(\theta'') \leq \frac{1}{k} \int_{A \cap C^c} L(\theta').$$

4. 将 (8.A.2) 和 (8.A.3) 代入 (8.A.1):

$$\int_C L(\theta'') - \int_A L(\theta'') \geq \frac{1}{k} \left[\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') \right].$$

²¹二元正态线性判别的详细推导见附录 ??。

5. 计算括号内项：

$$\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') = \int_C L(\theta') - \int_A L(\theta') = \alpha - \alpha = 0.$$

6. 由 (8.A.4) 和 (8.A.5) 得 $\int_C L(\theta'') - \int_A L(\theta'') \geq 0$, 即

$$P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A].$$

证毕。

5.4. 正态均值 NP 检验的完整推导. 背景 (Background): 在例 8.1.2 中, 我们构造了正态均值差假设的 NP 检验。本节补充完整推导。

目标 (Goal): 对 $X_1, \dots, X_n \sim N(\theta, 1)$, 检验 $H_0: \theta = 0$ 对 $H_1: \theta = 1$, 求大小为 α 的最佳检验。

推导步骤 (Derivation Steps):

1. 写出似然函数：

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

2. 似然比：

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \frac{\exp \left[-\frac{1}{2} \sum x_i^2 \right]}{\exp \left[-\frac{1}{2} \sum (x_i - 1)^2 \right]} = \exp \left[-\sum_{i=1}^n x_i + \frac{n}{2} \right].$$

3. 令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$:

$$\exp \left[-\sum x_i + \frac{n}{2} \right] \leq k \iff \sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

4. 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故临界值

$$c_1 = \frac{c}{n} = \frac{1}{2} - \frac{\log k}{n} = q_\alpha(0, 1/\sqrt{n}).$$

5. 功效函数：当 $\theta = 1$ 时， $\bar{X} \sim N(1, 1/n)$,

$$\text{Power}(\theta = 1) = P_{\theta=1}(\bar{X} \geq q_\alpha(0, 1/\sqrt{n})) = 1 - \Phi\left(\frac{q_\alpha(0, 1/\sqrt{n}) - 1}{1/\sqrt{n}}\right).$$

证毕。

5.5. Karlin-Rubin 定理的证明. 背景 (Background): 证明当似然函数有 MLR 性质时，单向复合假设存在 UMP 检验。

已知条件 (Given):

- 似然函数 $L(\theta, \mathbf{x})$ 在 $Y = u(\mathbf{x})$ 中有 MLR: 对 $\theta_1 < \theta_2$, $L(\theta_1; \mathbf{x})/L(\theta_2; \mathbf{x}) = g(Y)$, 其中 g 是递减函数。
- 单向假设: $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$ 。

目标 (Goal): 证明检验 $\phi(\mathbf{x}) = 1$ 当 $Y \geq c_Y$, 其中 c_Y 满足 $P_{\theta'}[Y \geq c_Y] = \alpha$, 是 UMP level α 检验。

推导步骤 (Derivation Steps):

1. 对简单假设 $H'_0: \theta = \theta'$ 对 $\theta'' > \theta'$ 的最优性: 由 NP 定理, 最佳临界区域由

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$$

给出。由于 MLR 性质, $g(Y) \leq k \iff Y \geq g^{-1}(k)$ 。取 $c_Y = g^{-1}(k)$, 则对任意 $\theta'' > \theta'$, 临界区域 $C = \{Y \geq c_Y\}$ 是 $H'_0: \theta = \theta'$ 对 θ'' 的最佳检验。

2. 对所有 $\theta'' > \theta'$ 的一致性: 由于 NP 最佳临界区域的形式只依赖于 $Y \geq c_Y$ (而不依赖于具体的 θ''), $C = \{Y \geq c_Y\}$ 对所有 $\theta'' > \theta'$ 都是最佳的。

3. 无偏性 (保证 level 不超过 α): 设 $\gamma_Y(\theta) = P_\theta(Y \geq c_Y)$ 为功效函数。对 $\theta_1 < \theta_2$, 由第 1 步, C 是 θ_1 对 θ_2 的最佳检验, 故 $\gamma_Y(\theta_2) \geq \gamma_Y(\theta_1)$ 。因此 $\gamma_Y(\theta)$ 是 θ 的非降函数, $\max_{\theta \leq \theta'} \gamma_Y(\theta) = \gamma_Y(\theta') = \alpha$ 。故该检验是 level α 的。

综上, $C = \{Y \geq c_Y\}$ 是 UMP level α 检验。证毕。

Exercises

EXERCISE 8.1. *8.1 Best Critical Region for Normal Variance – Hogg 8.1.4 Let $X_1, X_2, \dots, X_{10}$ be a random sample of size 10 from a normal distribution $N(0, \sigma^2)$. Find a best critical region of size $\alpha = 0.05$ for testing $H_0: \sigma^2 = 1$ against $H_1: \sigma^2 = 2$. Is this a best critical region of size 0.05 for testing $H_0: \sigma^2 = 1$ against $H_1: \sigma^2 = 4$? Against $H_1: \sigma^2 = \sigma_1^2 > 1$?*

EXERCISE 8.2. **8.2 UMP Test for Normal Mean** – Hogg 8.2.7 Let $X_1, X_2, \dots, X_{25}$ denote a random sample of size 25 from a normal distribution $N(\theta, 100)$. Find a uniformly most powerful critical region of size $\alpha = 0.10$ for testing $H_0 : \theta = 75$ against $H_1 : \theta > 75$.

EXERCISE 8.3. **8.3 MLR and UMP Test for Beta Distribution** – Hogg 8.2.11 Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere, where $\theta > 0$. Show the likelihood has MLR in the statistic $\prod_{i=1}^n X_i$. Use this to determine the UMP test for $H_0 : \theta = \theta'$ against $H_1 : \theta < \theta'$, for fixed $\theta' > 0$.

EXERCISE 8.4. **8.4 LRT for Normal Mean (Two-Sided)** – Hogg 8.3.8 Let $X_1, X_2, \dots, X_n$ be a random sample from the normal distribution $N(\theta, 1)$. Show that the likelihood ratio principle for testing $H_0 : \theta = \theta'$, where θ' is specified, against $H_1 : \theta \neq \theta'$ leads to the inequality $|\bar{x} - \theta'| \geq c$.

EXERCISE 8.5. **8.5 LRT for Two Normal Variances** – Hogg 8.3.11 Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ be independent random samples from the distributions $N(\theta_1, \theta_3)$ and $N(\theta_2, \theta_4)$, respectively. Show that the LRT for testing $H_0 : \theta_3 = \theta_4$ against $H_1 : \theta_3 \neq \theta_4$ leads to the F -test statistic

$$F = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)}{\sum_{i=1}^m (Y_i - \bar{Y})^2 / (m-1)}.$$

Under H_0 , $F \sim F(n-1, m-1)$.

EXERCISE 8.6. **8.6 SPRT for Poisson Distribution** – Hogg 8.4.2 Let X have a Poisson distribution with mean θ . Find the sequential probability ratio test for testing $H_0 : \theta = 0.02$ against $H_1 : \theta = 0.07$. Show that this test can be based upon the statistic $\sum_{i=1}^n X_i$. If $\alpha_a = 0.20$ and $\beta_a = 0.10$, find $c_0(n)$ and $c_1(n)$.

CHAPTER 9

ANOVA and Regression

Chapter 9 Overview

在前几章中，我们讨论了来自单个总体的样本推断，以及两个总体的比较。但实际中，我们常常面临更复杂的问题：

如果有三个、四个甚至更多个总体，我们该如何比较它们的均值？

这个问题——即**多组比较问题**——在农业实验、医学试验、工业质量控制等领域无处不在。例如，在一项评估不同肥料对作物产量影响的实验中，我们需要同时比较多个处理组；而在研究药物疗效时，我们可能需要同时评估多种药物的效果。

本章，我们从单样本 t 检验 $\rightarrow$ 两样本 t 检验 $\rightarrow$ 多组比较的自然推广，引入**方差分析 (Analysis of Variance, 简称 ANOVA)**。这一方法由 Ronald Fisher 在 1920 年代创立，起源于他在英国洛桑农业实验站的农业实验研究。Fisher 的核心思想是：将总变异分解为可解释的变异和随机误差，通过比较两者来判断处理效应是否显著。

本章路线图：

- (1) One-Way ANOVA $\rightarrow$ 组间/组内平方和分解 $\rightarrow F$ 检验
- (2) 非中心 χ^2 和 F 分布 $\rightarrow$ 备择假设下的分布
- (3) Multiple Comparisons $\rightarrow$ Tukey 法、Bonferroni 法（控制族误差率）
- (4) Two-Way ANOVA $\rightarrow$ 主效应、交互效应
- (5) 回归问题 $\rightarrow$ 最小二乘估计、几何解释（投影）
- (6) 二次型分布 $\rightarrow$ Cochran 定理——平方和分解的理论基础

1. 9.1 Introduction

在正式进入 ANOVA 之前，我们需要介绍一个重要的数学工具——**二次型 (quadratic form)**。

DEFINITION 9.1 (二次型). 设 $X_1, \dots, X_n$ 是 n 个变量， a_{ij} 是常数。形如

$$q(X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^n X_i a_{ij} X_j$$

的表达式称为 $X_1, \dots, X_n$ 的（二次）**二次型**。

为什么二次型重要？ 在统计推断中，许多关键的统计量都可以表示为二次型。例如，样本方差

$$(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

就是关于样本 $X_1, \dots, X_n$ 的一个二次型。理解二次型的分布性质, 是理解 ANOVA 和回归分析的理论基础。

2. 9.2 One-Way ANOVA

2.1. 问题的引入. 考虑 b 个独立的正态总体, 第 j 个总体的均值为 μ_j , 共同方差为 σ^2 。从第 j 个总体中抽取容量为 n_j 的随机样本 $X_{1j}, X_{2j}, \dots, X_{n_jj}$ 。记总样本量为 $n = \sum_{j=1}^b n_j$ 。

模型为:

$$X_{ij} = \mu_j + e_{ij}, \quad i = 1, \dots, n_j, \quad j = 1, \dots, b, \quad (9.2.1)$$

其中 e_{ij} 是 iid $N(0, \sigma^2)$ 随机误差。

我们想检验: 所有 b 个总体的均值是否相等——

$$H_0: \mu_1 = \mu_2 = \dots = \mu_b \quad \text{vs} \quad H_1: \mu_j \neq \mu_{j'} \text{ 对某些 } j \neq j'. \quad (9.2.2)$$

实际背景: 例如, b 种药物对某种疾病的疗效比较; 或 b 种肥料对作物产量的影响。这里“一种因素 (factor)”处于 b 个“水平 (level)”, 因此称为**单因素实验 (one-way layout)**。

2.2. 似然比检验的推导. 完全模型 (full model) 参数空间:

$$\Omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : -\infty < \mu_j < \infty, \quad 0 < \sigma^2 < \infty\}.$$

约束模型 (reduced model) 参数空间 (H_0 下):

$$\omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : \mu_1 = \dots = \mu_b = \mu, \quad 0 < \sigma^2 < \infty\}.$$

完全模型下的 MLE:

$$\hat{\mu}_j = \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\Omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2. \quad (9.2.7)$$

约束模型下的 MLE (此时等价于单样本问题):

$$\hat{\mu}_\omega = \bar{X}_{\cdot\cdot} = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.3)$$

似然比统计量简化后的形式为:

$$\Lambda^{n/2} = \frac{\hat{\sigma}_\Omega^2}{\hat{\sigma}_\omega^2}. \quad (9.2.9)$$

拒绝 H_0 等价于 F 统计量过大, 其中

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)}, \quad (9.2.11)$$

而

$$Q_3 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2, \quad Q_4 = \sum_{j=1}^b n_j (\bar{X}_{\cdot j} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.10)$$

核心分解:

$$\underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2}_Q = \underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}_{Q_3(\text{组内})} + \underbrace{\sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2}_{Q_4(\text{组间})}. \quad (9.2.10)$$

在 H_0 下, $Q_3/\sigma^2 \sim \chi^2(n-b)$, $Q_4/\sigma^2 \sim \chi^2(b-1)$, 且二者独立。因此 $F \sim F(b-1, n-b)$ 。

2.3. ANOVA 表格. 单因素 ANOVA 的结果可以汇总为一张清晰的表格:

表 1. 单因素 ANOVA 表格

来源	平方和 (SS)	df	均方 (MS)	F 统计量	p 值
组间 (Between)	Q_4	$b-1$	$MSB = Q_4/(b-1)$	$\frac{MSB}{MSW}$	$\mathbb{P}(F > F_0)$
组内 (Within)	Q_3	$n-b$	$MSW = Q_3/(n-b)$		
总计 (Total)	Q	$n-1$			

EXAMPLE 9.1 (合金弹性模量). Devore (2012, 第 412 页) 报告了一项数据: 三种铸造工艺 (永久模具、压铸、石膏模具) 生产合金的弹性模量。三种工艺各有多次测量, 我们想知道铸造工艺是否显著影响弹性模量。

数据汇总后, $F = 12.565$, 自由度为 2 和 19, p 值为 0.0003。如此小的 p 值表明: 铸造工艺对弹性模量有显著影响。

(该例子的详细计算与 R 代码实现见附录 ??。)

3. 9.3 Noncentral χ^2 and F Distributions

3.1. 为什么需要非中心分布? 在前一节的 ANOVA 中, 我们在原假设 H_0 下推导了 F 统计量的分布。但在实际应用中, 我们更关心: 当 H_0 不成立 (即各组均值不全相等) 时, F 统计量的分布是什么? 这时就需要引入**非中心 χ^2 分布**和**非中心 F 分布**。

DEFINITION 9.2 (非中心 χ^2 分布). 设 $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, \dots, n$, 独立。则

$$Y = \sum_{i=1}^n \frac{X_i^2}{\sigma^2}$$

的 *mgf* 为

$$M(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}, \quad t < \frac{1}{2}. \quad (9.3.1)$$

此时称 $Y \sim \chi^2(r, \theta)$, 其中 $r = n$ 是自由度, $\theta = \sum_{i=1}^n \mu_i^2 / \sigma^2$ 是**非中心参数 (noncentrality parameter)**。

直观理解: 当所有 $\mu_i = 0$ 时, $\theta = 0$, 回到中心 χ^2 分布; 当某些 $\mu_i \neq 0$ 时, Y 的分布在中心 χ^2 的基础上向右偏移, θ 越大, 偏移越明显。

非中心 χ^2 分布的均值: $E(Y) = r + \theta$ (中心部分 r 加上非中心部分 θ)。

DEFINITION 9.3 (非中心 F 分布). 设 $U \sim \chi^2(r_1, \theta)$, $V \sim \chi^2(r_2)$, 独立。则

$$F = \frac{r_2 U}{r_1 V}$$

服从自由度为 r_1, r_2 、非中心参数为 θ 的非中心 F 分布, 记作 $F(r_1, r_2, \theta)$ 。

EXAMPLE 9.2 (One-Way ANOVA 的非中心参数). 对于 *one-way ANOVA* 模型 (9.2.1), 在备择假设 H_1 下, F 统计量的分子 $Q_4/\sigma^2 \sim \chi^2(b-1, \theta)$, 其中

$$\theta = \frac{1}{\sigma^2} \sum_{j=1}^b n_j (\mu_j - \bar{\mu})^2, \quad \bar{\mu} = \frac{1}{n} \sum_{j=1}^b n_j \mu_j. \quad (9.3.5)$$

当 H_0 成立时, $\theta = 0$, 回到中心 F 分布; 当 H_1 成立时, $\theta > 0$, F 分布向右偏移, 偏移程度由 θ 刻画。这解释了为什么 F 检验在 H_0 不成立时倾向于取更大的值。

(非中心 F 分布的完整推导见附录 ??。)

4. 9.4 Multiple Comparisons

当 one-way ANOVA 的 F 检验拒绝了 H_0 后, 我们自然想知道: **具体哪些组之间存在显著差异?** 这就是**多重比较问题 (Multiple Comparison Problem, MCP)**。

4.1. 问题的核心矛盾. 对 b 个总体, 若进行所有 $\binom{b}{2}$ 个成对比较, 即使每个置信区间的置信水平为 95%, 整体的置信水平也会急剧下降。举例来说, 若 $b = 5$, 则共有 10 个成对比较, 每个比较犯错的概率为 5%, 至少有一次犯错的概率粗略估计为 $1 - (0.95)^{10} \approx 40\%$ 。

因此, 我们需要专门设计的方法来**控制族误差率 (Family-Wise Error Rate, FWER)**——即**在所有比较中至少有一次犯错的概率**。

4.2. Bonferroni 方法. Bonferroni 方法基于一个简单的不等式: 对 k 个参数 θ_i , 若每个区间 I_i 的置信水平为 $1 - \alpha$, 则

$$P(\text{所有 } \theta_i \in I_i) \geq 1 - k\alpha. \quad (9.4.2)$$

核心理想: 将每个区间的置信水平从 $1 - \alpha$ 调整为 $1 - \alpha/k$, 则整体的置信水平至少为 $1 - \alpha$ 。

对 one-way ANOVA, 成对差值 $\mu_j - \mu_{j'}$ 的 Bonferroni 置信区间为:

$$\bar{X}_{\cdot j} - \bar{X}_{\cdot j'} \pm t_{\alpha/(2k), n-b} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.3)$$

优点: 通用性强, 适用于任何成对比较。**缺点:** 比较数量 k 越大, 区间越宽, 精度损失越大。

4.3. Tukey 方法. Tukey 方法利用学生化极差分布 (Studentized range distribution), 专为 balanced 设计的成对比较设计。

当所有组样本容量相等 ($n_j = a, j = 1, \dots, b$) 时, 所有成对比较的同时置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm q_{1-\alpha, b, n-b} \frac{\hat{\sigma}_\Omega}{\sqrt{a}}, \quad \forall j \neq j'. \quad (9.4.4)$$

其中 $q_{1-\alpha, b, n-b}$ 是自由度为 b 和 $n-b$ 的学生化极差分布分位数。

对于 unbalanced 情形, 使用 Tukey-Kramer 修正:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm \frac{q_{1-\alpha, b, n-b}}{\sqrt{2}} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.5)$$

EXAMPLE 9.3 (赛车速度比较). *Kitchens (1997)* 报告了一项实验: 比较五种汽车 (*Acura, Ferrari, Lotus, Porsche, Viper*) 的最高速度。每种车进行 6 次运行测试。整体 F 检验高度显著 ($F = 25.15, p \approx 0$)。Tukey 多重比较结果表明: *Ferrari* 和 *Porsche* 的平均速度显著快于其他三种车, 但 *Ferrari* 与 *Porsche* 之间速度差异不显著。

(该例子的 R 实现与详细结果分析见附录 ??。)

4.4. Fisher 的保护 LSD 方法. Fisher 方法是一个两步程序:

- (1) 首先进行整体 F 检验; 若拒绝 H_0 ,
- (2) 再使用标准的成对 t 置信区间 (置信水平 $1 - \alpha$)。

Fisher 方法不保证整体覆盖率为 $1 - \alpha$, 但 F 检验提供了”保护”。模拟研究表明它在功效和实际误差率方面表现良好。

5. 9.5 Two-Way ANOVA

5.1. 双因素实验的引入. 在实际研究中, 我们常常需要同时考虑两个因素对结果的影响。例如:

- 作物产量: 同时受品种 (因素 A) 和肥料类型 (因素 B) 的影响
- 考试成绩: 同时受教学方法 (因素 A) 和班级规模 (因素 B) 的影响

这就是双因素方差分析 (two-way ANOVA)。

设因素 A 有 a 个水平, 因素 B 有 b 个水平, 每个组合有一个观测值 X_{ij} 。模型为:

$$X_{ij} = \mu + \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b, \quad (9.5.2)$$

其中 $e_{ij} \sim N(0, \sigma^2)$ iid, 且 $\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0$ 。

可加模型 (additive model) 意味着两个因素的影响是相互独立的——因素 A 的效应不随因素 B 的水平变化。

表 2. 双因素可加模型的单元格均值示例 ($a = 2, b = 3$)

	B=1	B=2	B=3
A=1	7	6	5
A=2	5	4	3

在可加模型中，行均值轮廓线是**平行的**——这是可加模型的重要特征。

5.2. 假设检验. 我们需要检验两个主效应假设：

$$H_{0A} : \alpha_1 = \cdots = \alpha_a = 0 \quad \text{vs} \quad H_{1A} : \text{某些 } \alpha_i \neq 0, \quad (9.5.3)$$

$$H_{0B} : \beta_1 = \cdots = \beta_b = 0 \quad \text{vs} \quad H_{1B} : \text{某些 } \beta_j \neq 0. \quad (9.5.4)$$

检验 H_{0B} 的 F 统计量：

$$F_B = \frac{a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 / (b-1)}{\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2 / [(a-1)(b-1)]}. \quad (9.5.12)$$

在 H_{0B} 下， $F_B \sim F(b-1, (a-1)(b-1))$ 。

类似地，检验 H_{0A} 的 F 统计量 $F_A \sim F(a-1, (a-1)(b-1))$ 。

5.3. 9.5.1 Interaction between Factors. 交互效应发生在：一个因素的影响程度取决于另一个因素的水平时。

在模型中引入交互参数 γ_{ij} ：

$$\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij}, \quad (9.5.15)$$

其中 $\sum_i \gamma_{ij} = \sum_j \gamma_{ij} = 0$ 。

若所有 $\gamma_{ij} = 0$ ，则回到可加模型；若存在非零 γ_{ij} ，则两个因素之间存在**交互作用**。

图形诊断：在双因素实验中，绘制各行（因素 A 各水平）的均值轮廓线。若线条大致平行，则交互作用不明显；若线条明显交叉或分离，则表明存在交互效应。

EXAMPLE 9.4 (沥青混合料热导率). Devore (2012, 第 435 页) 研究了两个因素对沥青混合料热导率的影响：粘结剂等级 (PG58, PG64, PG70) 和粗骨料含量 (38%, 41%, 44%)。每个处理组合有 2 次重复。

R 分析结果：交互效应不显著 ($p = 0.4135$)，但两个主效应都非常显著 ($p = 0.0017$ 和 $p < 10^{-5}$)。因此接受可加模型，两个因素独立地影响热导率。

(该例子的详细 ANOVA 表和 R 代码见附录 ??。)

6. 9.6 A Regression Problem

6.1. 为什么研究回归? ANOVA 研究的是类别型 (categorical) 自变量对因变量的影响。但在许多实际问题中，自变量是连续型的。例如：

- 学生的学习时间 (连续) $\rightarrow$ 考试成绩
- 汽车的发动机排量 (连续) $\rightarrow$ 每加仑行驶里程
- 农作物的施肥量 (连续) $\rightarrow$ 作物产量

这就引出了**回归分析 (regression analysis)** ——研究自变量 (通常记作 x) 与因变量 Y 之间关系的方法。

线性模型：假设 $E(Y) = \mu(x)$ 是 x 的线性函数——

$$Y_i = \alpha + \beta(x_i - \bar{x}) + e_i, \quad i = 1, \dots, n, \quad (9.6.1)$$

其中 $e_i \sim N(0, \sigma^2)$ iid。

为什么假设 x 是已知的非随机变量？ 这是为了简化分析——我们把不确定性全部放在 Y 上。在实际中，如果 x 也是随机的，则需要联合分布建模；但在受控实验或观测研究中，将 x 视为固定设计点是合理的近似。

线性模型 vs 非线性模型： 这里“线性”指的是对参数 (α, β) 线性，而非对 x 线性。因此 $\alpha + \beta x + \gamma x^2$ 仍是线性模型，而 $\alpha e^{\beta x}$ 不是。

6.2. 9.6.1 Maximum Likelihood Estimates. 对模型 (9.6.1)，似然函数为

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{[Y_i - \alpha - \beta(x_i - \bar{x})]^2}{2\sigma^2} \right\}. \quad (9.6.12)$$

最大化似然等价于最小化

$$H(\alpha, \beta) = \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2. \quad (9.6.3)$$

这正是**最小二乘法 (least squares)**——选择使残差平方和最小的 α, β 。

几何直观： $|Y_i - \alpha - \beta(x_i - \bar{x})|$ 是点 (x_i, Y_i) 到直线 $y = \alpha + \beta(x - \bar{x})$ 的垂直距离。最小二乘法就是找到使所有这些距离平方和最小的直线。

MLE 的解：

$$\hat{\alpha} = \bar{Y}, \quad (9.6.3)$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (9.6.5)$$

$\hat{\sigma}^2$ 的 MLE：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2. \quad (9.6.8)$$

拟合值与残差：

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}(x_i - \bar{x}), \quad \hat{e}_i = Y_i - \hat{Y}_i. \quad (9.6.6)$$

估计量的分布： 可以证明

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{pmatrix} \right). \quad (9.6.9)$$

EXAMPLE 9.5 (男子 1500 米奥运会成绩). 考虑 27 届奥运会男子 1500 米冠军成绩与年份的关系。年份为自变量 x ，时间为因变量 Y 。

R 拟合结果： $\hat{y} = 12.33 - 0.0044 \times \text{year}$ 。斜率的 95% 置信区间为 $(-0.00547, -0.00328)$ ——这意味着每年获胜时间平均减少约 0.004 分钟（约 0.24 秒）。对 2020 年奥运会的预测时间约为 3.486 分钟。

(该例子的详细计算、残差图分析和预测区间见附录 ??。)

残差图诊断： 在回归分析中，绘制残差 $\hat{e}_i$ vs 拟合值 $\hat{Y}_i$ 的散点图。如果图呈现随机散布，说明模型是合理的；如果出现系统模式（如 U 形、漏斗形），则提示模型设定有问题（如遗漏非线性项、异方差等）。

6.3. 9.6.2 *Geometry of the Least Squares Fit. 最小二乘拟合有一个优美的几何解释。

将数据写成向量形式 $\mathbf{Y} = (Y_1, \dots, Y_n)'$, 设计矩阵 $\mathbf{X}$ 的列为 $\mathbf{1}$ 和 $\mathbf{x}_c = (x_1 - \bar{x}, \dots, x_n - \bar{x})'$ 。模型为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}). \quad (9.6.13)$$

设 V 为 $\mathbf{X}$ 列张成的 $\mathbb{R}^n$ 中的二维子空间 (拟合空间)。最小二乘估计 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 正是 $\mathbf{Y}$ 在子空间 V 上的**正交投影**——即使得 $\|\mathbf{Y} - \boldsymbol{\theta}\|^2$ 最小的 V 中元素。

几何分解:

$$\|\mathbf{Y}\|^2 = \|\hat{\boldsymbol{\theta}}\|^2 + \|\hat{\mathbf{e}}\|^2,$$

其中 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 是残差向量, 且 $\hat{\boldsymbol{\theta}} \perp \hat{\mathbf{e}}$ (残差与拟合空间正交)。这正是 ANOVA 中平方和分解的几何版本。

7. 9.7 A Test of Independence

在许多应用中, 我们需要检验两个连续变量 X 和 Y 是否独立。对于二元正态分布, X 和 Y 独立当且仅当它们的相关系数 $\rho = 0$ 。因此我们检验:

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0. \quad (9.7.1)$$

样本相关系数:

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}. \quad (9.7.1)$$

关键定理: 在 H_0 下 (即 $\rho = 0$ 时), R 的分布不依赖于 X 的具体分布——只要 X 与 Y 独立, R 的分布在正态情况下就有上式 (9.3.1) 给出的精确形式。特别是,

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t(n-2). \quad (9.7.3)$$

因此, H_0 的拒绝域为 $|T| \geq t_{\alpha/2, n-2}$, 或等价地 $|R| \geq c$ 。

Remark 的深层含义: R 的条件分布 (在给定 $X_1, \dots, X_n$ 下) 不依赖于 X_i 的具体值, 这意味着 R 与所有仅依赖于 X 的统计量独立。这是一个非常优雅的性质——样本相关系数在 $\rho = 0$ 时”不受” X 取值的影响。

8. 9.8 Distributions of Certain Quadratic Forms

前几节的分析依赖于一个共同的理论支柱: 某些二次型服从 χ^2 分布, 且它们相互独立。本节和下一节建立这一理论的严格基础。

设 $\mathbf{X}' = (X_1, \dots, X_n)$, 其中 $X_i \sim N(\mu_i, \sigma^2)$ iid. 二次型 $Q = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}$ 的 mgf 为:

$$M_Q(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}. \quad (9.8.10)$$

特别地, 若 $\mathbf{A}$ 是对称幂等矩阵 ($\mathbf{A}^2 = \mathbf{A}$), 则 $Q \sim \chi^2(r, \theta)$, 其中 $r = \text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A})$, $\theta = \boldsymbol{\mu}' \mathbf{A} \boldsymbol{\mu} / \sigma^2$ 。若进一步 $\boldsymbol{\mu} = \mu \mathbf{1}$ 且 $\sum_{i,j} a_{ij} = 0$, 则 $\theta = 0$, Q 为中心 $\chi^2(r)$ 。

Cochran 定理的特例: 若 $Q_1, \dots, Q_k$ 是相互独立的 χ^2 变量之和, 且 $\sum \text{rank}(Q_i) = n$, 则各 Q_i 独立。

9. 9.9 The Independence of Certain Quadratic Forms

最后一个理论工具：Craig 定理，给出了两个二次型独立的充要条件。

这个定理在 ANOVA 中有重要应用：在 one-way ANOVA 中，组间平方和 Q_4 （对应某个幂等矩阵）与组内平方和 Q_3 （对应另一个幂等矩阵）满足 $\mathbf{AB} = \mathbf{0}$ ，因此独立——这正是 F 检验的理论基础。

推论：在回归模型中，拟合值的二次型与残差的二次型相互独立，反映了”被解释的变异”与”未被解释的变异”之间的正交性。

习题

EXERCISE 9.1. 9.2.3 — One-Way ANOVA 数据计算 考虑来自三个正态分布的独立随机样本，它们具有相等方差及 *respective means* μ_1, μ_2, μ_3 。数据如下：

<i>I</i>	<i>II</i>	<i>III</i>
0.5	2.1	3.0
1.3	3.3	5.1
-1.0	0.0	1.9
1.8	2.3	2.4
	2.5	4.2
		4.1

使用 R 或其他统计软件，计算用于检验 $H_0: \mu_1 = \mu_2 = \mu_3$ 的 F 统计量。

EXERCISE 9.2. 9.2.7 — One-Way ANOVA 假设检验 设 μ_1, μ_2, μ_3 分别为三个正态分布的均值，它们具有公共未知方差 σ^2 。为在显著性水平 $\alpha = 0.05$ 下检验假设 $H_0: \mu_1 = \mu_2 = \mu_3$ 对所有可能备择假设，从每个分布中抽取容量为 4 的独立随机样本。若观测值分别为：

$$X_1: \quad 5 \quad 9 \quad 6 \quad 8$$

$$X_2: \quad 11 \quad 13 \quad 10 \quad 12$$

$$X_3: \quad 10 \quad 6 \quad 9 \quad 9$$

判断是否拒绝 H_0 。

EXERCISE 9.3. 9.2.8 — 柴油燃料品牌 *mpg* 比较 一位柴油汽车司机根据 *mpg* 测试三种柴油燃料的质量。使用以下数据检验三个均值相等的原假设。做通常的假设并取 $\alpha = 0.05$ 。

Brand A: 38.7 39.2 40.1 38.9

Brand B: 41.9 42.3 41.3

Brand C: 40.8 41.2 39.5 38.9 40.3

EXERCISE 9.4. 9.3.2 —非中心 χ^2 分布的方差 计算服从非中心 $\chi^2(r, \theta)$ 分布的随机变量的方差。

EXERCISE 9.5. 9.3.4 —非中心 T 与非中心 F 的关系 证明非中心 T 随机变量的平方是非中心 F 随机变量。

EXERCISE 9.6. 9.4.1 —Bonferroni 多重比较程序 对于练习 9.2.8 中讨论的研究, 使用 $\alpha = 0.10$ 获取 Bonferroni 多重比较程序的结果。基于此程序, 哪个品牌的燃料 (如果有的话) 显著最好?

EXERCISE 9.7. 9.4.2 —Tukey-Kramer 程序 对于练习 9.2.6 中讨论的研究, 计算 Tukey-Kramer 程序。是否存在显著差异?

EXERCISE 9.8. 9.5.1 —两因素交互效应 考虑一个双因素实验, 其中因素 A 有 2 个水平, 因素 B 有 3 个水平。设 $\mu = 5$, $\alpha_1 = 1$, $\alpha_2 = -1$, $\beta_1 = 1$, $\beta_2 = 0$, $\beta_3 = -1$ 。回答以下问题:

- (a) 写出单元格均值 μ_{ij} 的表格。
- (b) 绘制均值轮廓图 (mean profile plot)。
- (c) 若交互效应存在, 轮廓图会有什么特征?

EXERCISE 9.9. 9.6.4 —回归估计量的协方差 证明 $\hat{\alpha}$ 与 $\hat{\beta}$ 之间的协方差为零。

提示: 利用 (9.6.5) 中 $\hat{\beta}$ 的表达式, 以及 $\sum_{i=1}^n (x_i - \bar{x}) = 0$ 的性质。

EXERCISE 9.10. 9.6.5 —回归参数的置信区间 在模型 (9.6.1) 下, 求参数 α 和 β 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.11. 9.6.9 —回归平方和分解 证明以下等式成立:

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

提示: 这本质上是将总平方和分解为拟合平方和与残差平方和。

EXERCISE 9.12. 9.6.14 —简单最小二乘拟合 使用最小二乘法拟合 $y = a + x$ 到以下数据:

x	0	1
	2	
y	1	3
	4	

附录: 公式推导

One-Way ANOVA 平方和恒等式的证明. 背景: 在 one-way ANOVA 中, 总平方和 Q 可以分解为组内平方和 Q_3 与组间平方和 Q_4 之和。这一恒等式是 F 检验的基石。

目标：证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2.$$

推导：记 $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和：

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零，因为对每个固定的 j ，

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。 □

One-Way ANOVA 检验统计量的分布。背景：推导 one-way ANOVA 中 F 统计量在原假设下的分布。

目标：证明在 H_0 下， $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导：

步骤 1: Q_3 的分布。对每个固定的 j ，由样本方差性质， $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立，故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2 \left(\sum_{j=1}^b (n_j - 1) \right) = \chi^2(n-b).$$

步骤 2: Q_4 与 Q_3 的独立性。注意 $\bar{X}_{.j}$ 与 Q_3 独立（由正态样本的性质），且 $\bar{X}_{..}$ 是 $\bar{X}_{.1}, \dots, \bar{X}_{.b}$ 的线性组合，因此 $\bar{X}_{..}$ 也与 Q_3 独立。故 Q_4 （ $\bar{X}_{.j}$ 的函数）与 Q_3 独立。

步骤 3: Q_4 的分布。在 H_0 下， $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$ ，故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各 $\bar{X}_{.j}$ 通过 $\bar{X}_{..}$ 而不独立。直接计算知 $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

步骤 4: F 分布。由步骤 1、2、3 及 F 分布定义，

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b). \quad (\text{A9.3})$$

□

非中心 χ^2 分布的均值和方差. 背景: 验证非中心 χ^2 分布的基本性质。

已知: $Y \sim \chi^2(r, \theta)$, mgf 为 $M(t) = (1 - 2t)^{-r/2} \exp\{t\theta/(1 - 2t)\}$ 。

目标: 求 $E(Y)$ 和 $\text{var}(Y)$ 。

推导:

由 mgf, $M(t) = (1 - 2t)^{-r/2} \exp\{t\theta/(1 - 2t)\}$ 。对 $M(t)$ 求导:

$$M'(t) = \left[r(1 - 2t)^{-r/2-1} + \frac{r\theta}{(1 - 2t)^{r/2+1}} \right] \exp \left\{ \frac{t\theta}{1 - 2t} \right\}.$$

故 $E(Y) = M'(0) = r + \theta$ 。

对 $M''(t)$ 在 $t = 0$ 求值, 可得 $\text{var}(Y) = 2(r + 2\theta)$ 。¹

最小二乘估计的几何解释. 背景: 回归最小二乘估计的正交投影几何。

目标: 证明 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是 $\mathbf{Y}$ 在 $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$ 上的正交投影。

推导: 由正交投影的定义, $\hat{\boldsymbol{\theta}}$ 满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}_c$ 都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0. \quad (\text{A9.4})$$

由 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 得 $\sum_i \hat{e}_i = 0$ (残差之和为零)。

由 $\mathbf{x}_c'\hat{\mathbf{e}} = 0$ 并利用正规方程, 可解出 $\hat{\alpha}$ 和 $\hat{\beta}$ 的表达式与 (9.6.3)、(9.6.5) 一致。故 $\hat{\boldsymbol{\theta}}$ 确为正交投影。□

¹该推导的详细计算见附录 ??。

附录：公式推导

0.1. Gamma 分布的矩母函数推导. 背景 (Background)： 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions)：

- $\alpha > 0$ ：形状参数 (shape parameter)
- $\beta > 0$ ：尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$ ：服从 Gamma 分布的随机变量

已知条件 (Given)：

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal)： 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps)：

1. 根据矩母函数定义：

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换：令 $y = \frac{x(1-\beta t)}{\beta}$ ，则 $x = \frac{\beta y}{1-\beta t}$ ， $dx = \frac{\beta}{1-\beta t} dy$ 。
3. 代入积分（要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$ ）：

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1 - \beta t)^{-\alpha}. \end{aligned}$$

结论： 因此， $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ ，定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background)： 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$ ，方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given)：

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

0.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证: 边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$, 确实是合法的 pdf。

结论: 条件 pdf 公式得证。■

0.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发:

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望 (即关于 X_1 求平均):

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论: 全期望公式得证。■

0.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论: 条件均值的方差不超过原变量的方差, 等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

0.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论: 故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.11. 相关系数范围的推导. 背景 (Background): 我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal): 证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps):

1. Cauchy-Schwarz 不等式: 对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差, 令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$:

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方:

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此:

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论: 故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

0.12. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i\{h_i/k_i\} < t < \min_i\{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.14. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.15. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.16. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.17. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。
2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.18. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。
2. 则 $X = \sum_{j=1}^n I_j$ 。
3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.19. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} \rightarrow 1, \\ \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.20. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数：

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论： Poisson 分布的均值和方差相等，都等于参数 λ 。■

0.21. 卡方分布与正态分布的关系. 背景 (Background)： 卡方分布定义为标准正态平方和。

目标 (Goal)： 证明若 $Z \sim N(0, 1)$ ，则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps)：

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$ ，先求 cdf：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf：

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式：

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论： 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.22. 卡方分布的可加性证明. 背景 (Background)： 卡方分布满足可加性：独立卡方变量之和仍为卡方分布。

目标 (Goal)： 证明若 $X_1 \sim \chi^2(m)$ ， $X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps)：

1. 由卡方分布与 Gamma 分布的关系： $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性（见定理 3.3.1）：若 $Y_1 \sim \Gamma(\alpha_1, \beta)$ ， $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立，则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此：

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf： $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$ ，故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论： 卡方分布具有可加性，自由度可累加。■

0.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1+X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.24. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.25. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.26. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}[e^{(t/\sigma)X}] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.27. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是**固定（但未知）的常数**，而区间 $[L, U]$ 是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 Chapter 4 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及（直方图估计）
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

简单区分：

场景	方法	章节
分布形式未知	非参数方法（直方图、核密度估计）	Chapter 10
分布形式已知、参数未知	参数方法（MLE、CI、检验）	Chapter 4

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计（MLE）被提出的**动机**。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

具体例子：

- S^2 （无偏）和 $\hat{\sigma}^2$ （有偏，但 MLE）
- 两者都常用，但各有用途
- “最优”需要更精确的定义（后续章节的 UMVUE）

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

学习笔记.