

数理统计导论

Hogg, McKean, Craig

目录

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 notation，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 Overview

本章从概率论的公理化基础出发，逐步建立整套理论框架。这条脉络贯穿本书始终——理解随机现象的本质、建立描述分布的工具、掌握期望与矩的计算。

为什么从概率论开始？ 因为统计学的一切推断都建立在概率论的基础上。如果不理解概率的数学本质，就无法真正理解统计推断的逻辑。

本章路线图： 随机现象 → 概率公理 → 条件概率与独立性 → 随机变量 → 离散/连续分布 → 期望与矩 → 矩母函数 → 重要不等式

1. 1.1 Introduction: Why Probability Theory?

1.1. The Genesis of Probability. 概率论的故事始于一场赌博。1654 年，赌徒 Chevalier de Méré 向数学家 Blaise Pascal 提出一个问题：如果两名玩家在赌局中途中断，如何公平地分配赌金？这个问题引发了 Pascal 与 Pierre de Fermat 的通信，从而奠定了概率论的基础。

从频率到概率： 设想进行 N 次重复实验。事件 A 发生的次数记为 $f_N(A)$ ，则 $f_N(A)/N$ 称为相对频率 (relative frequency)。当 N 增大时， $f_N(A)/N$ 趋于稳定，趋向某个数 p ——这正是事件 A 的概率。Kolmogorov 在 1933 年的开创性著作《概率论基础》中将这种直觉严格化，建立了现代概率论的公理化体系。

两派观点： 概率的相对频率解释依赖于实验可重复的条件。另一种观点——贝叶斯学派——将概率视为主观信念的度量。无论采用哪种解释，概率的数学性质（公理）都是一致的，因此我们可以在坚实的数学基础上统一处理。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. Random Experiments and Sample Spaces. 若一个实验可以在相同条件下重复进行，且所有可能的结果可以在实验前描述，我们就称其为随机实验 (random experiment)。

所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

这三个例子揭示了样本空间的三种类型：离散有限（硬币）、离散无限（骰子）、连续（等待时间）。理解样本空间的类型决定了我们使用离散还是连续的数学工具。

EXAMPLE 1.1 (Coin Toss). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (Two Dice). 投掷一枚红骰子和一枚白骰子。样本空间包含 36 个有序对: $\mathcal{C} = \{(1, 1), (1, 2), \dots, (6, 6)\}$ 。

EXAMPLE 1.3 (Continuous Sample Space). 等待地铁到达的时间。样本空间为 $\mathcal{C} = (0, \infty)$ ——这是一个连续不可数的集合。

事件是样本空间的子集。如果一个实验进行一次, 事件 A 要么发生, 要么不发生, 没有第三种可能。概率论正是描述这种不确定性的数学语言。

2. 1.2 Sets: The Language of Uncertainty

2.1. Why Do We Need Set Theory for Probability? 在概率论中, 事件 (event) 本质上就是样本空间的子集。为什么要用集合的语言? 因为集合运算 (并、交、补) 完美地对应了事件的逻辑运算 (“或”、“且”、“非”)。

德摩根定律 (De Morgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c. \quad (1.2.1)$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C). \quad (1.2.2)$$

这些看似简单的定律, 在概率计算中非常有用。例如, 要计算 “既不是 A 也不是 B ” 的概率, 我们可以直接使用德摩根定律: $\mathbb{P}((A \cup B)^c) = \mathbb{P}(A^c \cap B^c)$ 。

2.2. Key Set Operations. 设 $\mathcal{C}$ 为样本空间, A, B, C 为事件:

- **补集** A^c : 所有不在 A 中的元素
- **并集** $A \cup B$: 至少在 A 或 B 之一中的元素
- **交集** $A \cap B$: 同时在 A 和 B 中的元素
- **不交** $A \cap B = \phi$: A 和 B 互不相容

EXAMPLE 1.4 (Set Operations). 设 $\mathcal{C} = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。

则 $A^c = \{3, 4, \dots, 10\}$, $A \cup B = \{1, 2, 3, 4\}$, $A \cap B = \{2\}$, $A \cap C = \phi$, $B \cap C = \{3, 4\}$ 。

2.3. Countable and Uncountable Sets. 若集合 C 是有限的, 或与正整数集等势, 则称 C 为可数的 (countable)。

可数并: $\cup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}$

可数交: $\cap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \cup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \cap_{n=1}^{\infty} A_n$ 。

3. 1.3 The Probability Set Function

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。

概率必须满足：

- (1) 非负性： $\mathbb{P}(A) \geq 0$
- (2) 规范化： $\mathbb{P}(\mathcal{C}) = 1$
- (3) 可数可加性：若 $A_1, A_2, \dots$ 两两不交，则 $\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$

REMARK. **概率公理的直观含义**：非负性说明概率不能为负；规范化说明必然事件的概率为 1；可数可加性说明互不相容事件的并的概率等于各自概率之和。

从这三条公理可以推导出概率的所有其他性质。¹

REMARK. **定理 1.3.1**：对每个事件 A ， $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ 。

证明：由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$ ，结合公理得

$$1 = \mathbb{P}(\mathcal{C}) = \mathbb{P}(A) + \mathbb{P}(A^c).$$

布尔不等式：对任意事件 $A_1, \dots, A_n$ ，

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i). \quad (1.3.1)$$

这在估计复合事件概率时非常有用——当精确计算困难时，布尔不等式提供了一个上界。

REMARK. **等可能性情形**：若样本空间 $\mathcal{C} = \{x_1, x_2, \dots, x_m\}$ 有限，且每个 *outcome* 等概率，则

$$\mathbb{P}(A) = \frac{\#(A)}{m}. \quad (1.3.2)$$

EXAMPLE 1.5 (扑克牌概率). 从 52 张扑克牌中随机抽取一张。设 $A =$ “抽到 A ”， $B =$ “抽到红桃”。则

$$\mathbb{P}(A) = \frac{4}{52}, \quad \mathbb{P}(B) = \frac{13}{52}, \quad \mathbb{P}(A \cap B) = \frac{1}{52}.$$

由容斥原理，

$$\mathbb{P}(A \cup B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52} = \frac{4}{13}.$$

4. 1.4 Conditional Probability and Independence

条件概率是概率论中最重要的概念之一。它描述了在已知某些信息发生的条件下，如何更新我们对其他事件概率的判断。

REMARK. **定义 1.4.1 (条件概率)**：设 $\mathbb{P}(B) > 0$ ，在事件 B 已发生的条件下，事件 A 的条件概率定义为

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (1.4.1)$$

¹详细推导见附录 section 11.1。

条件概率满足概率的三条公理——它是一种新的概率度量，样本空间缩小为 B 。

乘法法则：

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) = \mathbb{P}(B) \cdot \mathbb{P}(A | B). \quad (1.4.2)$$

推广到 n 个事件：

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right). \quad (1.4.3)$$

REMARK. **全概率公式：** 设 $\{B_i\}$ 为 C 的一个划分，则对任意事件 A ,

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i). \quad (1.4.4)$$

REMARK. **贝叶斯公式：**

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i)}. \quad (1.4.5)$$

术语：

- $\mathbb{P}(B_j)$: 先验概率 (*prior probability*) ——在观测到 A 之前我们对 B_j 的信念
- $\mathbb{P}(B_j | A)$: 后验概率 (*posterior probability*) ——在观测到 A 之后我们对 B_j 的更新信念
- $\mathbb{P}(A | B_j)$: 似然 (*likelihood*) ——在 B_j 成立的条件下观测到 A 的概率

贝叶斯公式不仅是一个计算工具，更提供了一种思考不确定性的思维方式。²

EXAMPLE 1.6 (医学检测). 设某疾病患病率为 1%，检测准确率为 99%。令 $D =$ “患病”， $+$ = “检测阳性”。

即使检测准确率高达 99%，检测阳性者真正患病的概率只有 50%!

这个违反直觉的结果说明：在疾病罕见的情况下，即使非常准确的检测也可能产生大量假阳性。³

4.1. 1.4.1 Independence.

REMARK. **定义 1.4.2 (独立性)：** 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，则称 A 与 B 相互独立，记作 $A \perp\!\!\!\perp B$ 。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时，独立性等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$ ——知道 B 发生并不改变 A 的概率。

EXAMPLE 1.7 (独立硬币). 抛掷两枚独立硬币。设 $A =$ “第一枚正面朝上”， $B =$ “第二枚正面朝上”。则 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$ ，且 $\mathbb{P}(A \cap B) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，故 $A \perp\!\!\!\perp B$ 。

WARNING: 两两独立 (pairwise independent) 不一定意味着相互独立!⁴

²贝叶斯公式的深层意义见附录 section 11.2。

³详细计算见附录 section 11.3。

⁴反例见附录 section 11.4。

5. 1.5 Random Variables

样本空间的元素可能不是数字——随机变量正是将样本空间数值化的工具。

REMARK. 定义 1.5.1 (随机变量): 随机变量是从样本空间 $\mathcal{C}$ 到实数的函数: $X: \mathcal{C} \rightarrow \mathbb{R}$ 。

通常用大写字母 X, Y, Z 表示随机变量, 用小写字母 x, y, z 表示具体取值。

随机变量可分为:

- 离散随机变量: 取值可数 (有限或无限)
- 连续随机变量: 取值充满区间, 不可数

给定随机变量 X , 它的取值空间 $\mathcal{D}$ 成为新的样本空间。 X 不仅诱导了新的样本空间, 还诱导了一个概率分布——这正是”分布”概念的起源。

EXAMPLE 1.8 (硬币投掷). 抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$ 。定义 X 为正面出现的次数: $X(HH) = 2, X(HT) = X(TH) = 1, X(TT) = 0$ 。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。

EXAMPLE 1.9 (均匀选择). 从区间 $(0, 1)$ 中随机选择一个数 X 。 X 是连续随机变量, 取值充满 $(0, 1)$ 。

5.1. Cumulative Distribution Function.

REMARK. 定义 1.5.2 (CDF): $F_X(x) = \mathbb{P}(X \leq x), -\infty < x < \infty$ 。

CDF 满足:

- (1) 非递减: 若 $x_1 < x_2$, 则 $F_X(x_1) \leq F_X(x_2)$
- (2) $\lim_{x \rightarrow -\infty} F_X(x) = 0, \lim_{x \rightarrow \infty} F_X(x) = 1$
- (3) 右连续: $F_X(x) = \lim_{t \rightarrow x^+} F_X(t)$

从 CDF 计算概率:

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a). \quad (1.5.1)$$

关键洞察: 对连续随机变量, $\mathbb{P}(X = x) = 0$, 因此

$$\mathbb{P}(a < X < b) = \mathbb{P}(a \leq X \leq b) = F(b) - F(a). \quad (1.5.2)$$

6. 1.6 Discrete Random Variables

离散随机变量的取值是可数的。

REMARK. 定义 1.6.1 (pmf): $p_X(x) = \mathbb{P}(X = x)$ 。

pmf 满足: $p_X(x) \geq 0$ 对所有 x , 且 $\sum_x p_X(x) = 1$ 。

6.1. 1.6.1 Common Discrete Distributions. 伯努利分布 $X \sim \text{Bernoulli}(p)$:

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p. \quad (1.6.1)$$

二项分布 $X \sim \text{Bin}(n, p)$:

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n. \quad (1.6.2)$$

EXAMPLE 1.10 (二项分布). 抛掷一枚均匀硬币 10 次。设 X 为正面出现的次数。则 $X \sim \text{Bin}(10, 0.5)$,

$$\mathbb{P}(X = 3) = \binom{10}{3} (0.5)^3 (0.5)^7 = \frac{120}{1024} \approx 0.117.$$

几何分布 $X \sim \text{Geom}(p)$:

$$\mathbb{P}(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, 3, \dots \quad (1.6.3)$$

几何分布具有“无记忆性”——等待时间不受过去等待的影响。⁵

EXAMPLE 1.11 (几何分布). 抛掷一枚均匀硬币直到第一次出现正面。设 X 为抛掷次数。则 $X \sim \text{Geom}(0.5)$,

$$\mathbb{P}(X = 3) = (0.5)^2 \cdot 0.5 = \frac{1}{8}.$$

泊松分布 $X \sim \text{Poisson}(\lambda)$:

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots \quad (1.6.4)$$

泊松分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限分布。⁶

这揭示了离散分布之间的深刻联系——泊松分布作为稀有事件的模型具有重要意义。

EXAMPLE 1.12 (泊松分布). 某医院每小时接到的急诊电话数服从泊松分布，均值 $\lambda = 3$ 。则

$$\mathbb{P}(\text{每小时接到 5 个电话}) = \frac{3^5 e^{-3}}{5!} \approx 0.101.$$

超几何分布 $X \sim \text{Hypergeometric}(N, K, n)$:

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}. \quad (1.6.5)$$

这是从有限总体中无放回抽样的模型。

EXAMPLE 1.13 (超几何分布). 一个盒子中有 20 个红球和 80 个白球 (共 100 个)。从中抽取 5 个 (无放回)。令 X 为抽到的红球数。则

$$\mathbb{P}(X = 2) = \frac{\binom{20}{2} \binom{80}{3}}{\binom{100}{5}}.$$

⁵详细证明见附录 section 11.5。

⁶详细推导见附录 section 11.6。

6.2. 1.6.2 Transformations of Discrete Random Variables. 在统计中, 我们经常需要对一个随机变量进行变换: $Y = g(X)$ 。

一对一变换: 若 g 是一一对应的, 则

$$p_Y(y) = p_X(g^{-1}(y)). \quad (1.6.6)$$

非一对一变换: 需要合并所有映射到相同 y 的 x 的概率。

EXAMPLE 1.14 (离散变换). 设 $X \sim \text{Geom}(0.5)$, $Y = X^2$ 。因为 $g(x) = x^2$ 在 $\{1, 2, 3, \dots\}$ 上是一一对应的 (没有负数),

$$p_Y(y) = p_X(\sqrt{y}) = (0.5)^{\sqrt{y}+1}, \quad y = 1, 4, 9, \dots$$

7. 1.7 Continuous Random Variables

连续随机变量的取值充满一个或多个区间, 不可数。

REMARK. **定义 1.7.1 (连续随机变量):** 若随机变量 X 的 *cdf* $F_X(x)$ 对所有 x 都连续, 则称 X 为连续随机变量。

对连续随机变量, $\mathbb{P}(X = x) = 0$ 对所有 x ——这意味着单点概率为零。

REMARK. **定义 1.7.2 (pdf):** 若存在非负函数 $f_X(x)$ 使得

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x) dx$$

对任意 $a < b$ 成立, 则称 $f_X(x)$ 为 *pdf*。

pdf 满足: $f_X(x) \geq 0$ 对所有 x , 且 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。

WARNING: $f_X(x)$ 可以大于 1! 这与 *pmf* 的 $p_X(x) \leq 1$ 形成对比。pdf 的值不是概率, 而是概率密度——只有积分才是概率。

EXAMPLE 1.15 (均匀分布). 从区间 $(0, 1)$ 中随机选择一个数 X 。则 $X \sim \text{Uniform}(0, 1)$,

$$f_X(x) = \begin{cases} 1 & 0 < x < 1 \\ 0 & \text{otherwise} \end{cases}$$

EXAMPLE 1.16 (单位圆内的随机点). 在单位圆内随机选择一个点。设 X 为该点到原点的距离。则 X 的 *cdf* 为 $F_X(x) = x^2$, $0 \leq x \leq 1$ 。因此 *pdf* 为 $f_X(x) = 2x$, $0 < x < 1$ 。

EXAMPLE 1.17 (指数分布). 电话呼叫间隔时间 X 服从指数分布, *pdf* 为

$$f_X(x) = \frac{1}{4}e^{-x/4}, \quad x > 0.$$

则 $\mathbb{P}(X > 4) = \int_4^{\infty} \frac{1}{4}e^{-x/4} dx = e^{-1} \approx 0.368$ 。

指数分布也具有无记忆性。⁷

⁷详细讨论见附录 section 11.7。

正态分布 $X \sim N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \quad (1.7.1)$$

正态分布是统计学中最重要的分布——这将在第三章详细讨论。

7.1. 1.7.1 Quantiles. 分位数是分布的重要特征。

REMARK. **定义 1.7.3 (分位数)**: 设 $0 < p < 1$. 分布的 $100p\%$ 分位数 ξ_p 满足

$$\mathbb{P}(X < \xi_p) \leq p \quad \text{且} \quad \mathbb{P}(X \leq \xi_p) \geq p. \quad (1.7.2)$$

特殊分位数:

- 中位数 (*median*): $\xi_{0.5}$
- 第一四分位数: $\xi_{0.25}$
- 第三四分位数: $\xi_{0.75}$

四分位距 (IQR): $q_3 - q_1$, 是衡量离散程度的稳健指标。

若 X 连续且 F_X 严格递增, 则 $\xi_p = F_X^{-1}(p)$ 。

偏度 (Skewness): 描述分布的不对称程度。

- 右偏 (positively skewed): 右尾较长, 如指数分布
- 左偏 (negatively skewed): 左尾较长
- 对称 (symmetric): 如正态分布

7.2. 1.7.2 Transformations of Continuous Random Variables. 设 X 是连续随机变量, $f_X(x)$ 已知。我们想知道 $Y = g(X)$ 的分布。

CDF 法: 先求 $F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y)$, 然后求导得 $f_Y(y) = \frac{d}{dy}F_Y(y)$ 。

EXAMPLE 1.18 (连续变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = X^2$ 。则对 $0 < y < 1$,

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(X \leq \sqrt{y}) = \sqrt{y}.$$

因此 $f_Y(y) = \frac{1}{2\sqrt{y}}$, $0 < y < 1$ 。

一一变换公式: 若 $y = g(x)$ 是一一对应且可导的, $x = g^{-1}(y)$, 则

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy}g^{-1}(y) \right|, \quad y \in \mathcal{S}_Y. \quad (1.7.3)$$

这里 $\left| \frac{dx}{dy} \right|$ 称为雅可比 (Jacobian)。

EXAMPLE 1.19 (对数变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = -\log X$ 。则 $x = e^{-y}$, $dx/dy = -e^{-y}$ 。因此

$$f_Y(y) = 1 \cdot |-e^{-y}| = e^{-y}, \quad y > 0.$$

即 $Y \sim \text{Exp}(1)$ 。

这提供了从均匀分布生成指数分布的方法——逆变换采样 (*inverse transform sampling*) 的基础。⁸

⁸逆变换采样的详细讨论见第四章。

变换公式的证明：⁹

7.3. 1.7.3 Mixture Distributions. 有些分布既不是纯离散的，也不是纯连续的，而是两者的混合。

EXAMPLE 1.20 (混合分布). 设 X 的 cdf 为

$$F(x) = \begin{cases} 0 & x < 0 \\ \frac{x+1}{2} & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases}$$

则 $\mathbb{P}(X = 0) = 1/2$ ，且对 $0 < x < 1$ ， $\mathbb{P}(0 < X < x) = x/2$ 。这是一个离散-连续混合分布。

这种分布在实际中经常出现，例如：

- 删失数据 (*censored data*)
- 保险中的限额保单

8. 1.8 Expectation of a Random Variable

期望是随机变量最重要的一致性度量。它描述了分布的”中心位置”。

REMARK. 定义 1.8.1 (数学期望):

- 离散型: $\mathbb{E}X = \sum x \cdot p_X(x)$
- 连续型: $\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$

要求级数或积分绝对收敛，即 $\mathbb{E}|X| < \infty$ 。

期望的起源：在赌博游戏中，”期望” (expectation) 一词来源于玩家对游戏收益的长期平均预期。

公平游戏：若 $E(G) = 0$ ，则游戏是公平的 (fair game)。

EXAMPLE 1.21 (骰子期望). 设 X 为掷骰子的点数。则 $\mathbb{E}X = \frac{1}{6}(1+2+3+4+5+6) = 3.5$ 。

REMARK. 函数期望定理: 设 $Y = g(X)$ 。则

- 离散型: $\mathbb{E}Y = \sum g(x) \cdot p_X(x)$
- 连续型: $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx$

重要含义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！¹⁰

期望的线性性是概率论中最重要、最有用的性质之一。¹¹

⁹详细推导见附录 section 11.8。

¹⁰详细证明见附录 section 11.9。

¹¹详细证明见附录 section 11.10。

REMARK. 定理 1.8.1 (期望的线性性): 对任意随机变量 X, Y (期望存在) 和常数 a, b :

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y. \quad (1.8.1)$$

关键点: 无需 X, Y 相互独立!

EXAMPLE 1.22 (样本均值). 设 $X_1, \dots, X_n$ 是独立同分布的随机变量, $\mathbb{E}X_i = \mu$ 。则样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望为

$$\mathbb{E}\bar{X} = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \mu.$$

这说明样本均值是总体均值的无偏估计!¹²

乘积期望: 一般情况下 $\mathbb{E}(XY) \neq \mathbb{E}X \cdot \mathbb{E}Y$ 。只有当 X 和 Y 独立时, 等式才成立。

EXAMPLE 1.23 (乘积期望). 设 X 和 Y 是区间 $(0, 1)$ 上的均匀分布, 但 $Y = X$ (完全相关)。则 $\mathbb{E}(XY) = \mathbb{E}(X^2) = 1/3$, 而 $\mathbb{E}X \cdot \mathbb{E}Y = 1/4$, 两者不相等。

方差度量分布的离散程度。¹³

REMARK. 定理 1.8.2 (方差公式):

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}(X^2) - \mu^2. \quad (1.8.2)$$

方差性质:

$$(1) \text{var}(aX + b) = a^2 \text{var}(X)$$

$$(2) \text{若 } X_1, \dots, X_n \text{ 相互独立, 则 } \text{var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{var}(X_i)$$

9. 1.9 Some Special Expectations

某些期望具有特殊名称和重要意义。

9.1. Moments.

REMARK. 定义 1.9.1 (矩):

- k 阶原点矩: $\mu'_k = \mathbb{E}(X^k)$
- k 阶中心矩: $\mu_k = \mathbb{E}[(X - \mu)^k]$

一阶原点矩 $\mu'_1 = \mathbb{E}X$ 就是均值。

均值 (Mean): $\mu = \mathbb{E}X$ 是分布的中心位置度量。

方差 (Variance): $\sigma^2 = \text{var}(X)$ 度量分布的离散程度。

标准差 (Standard Deviation): $\sigma = \sqrt{\text{var}(X)}$, 与 X 具有相同单位。

变异系数 (CV): $\text{CV} = \sigma/\mu$, 是无量纲的离散程度度量。

偏度系数: $\gamma_1 = \mathbb{E}[(X - \mu)^3]/\sigma^3$, 衡量分布的不对称程度。

峰度系数: $\gamma_2 = \mathbb{E}[(X - \mu)^4]/\sigma^4 - 3$, 衡量分布尾部的厚重程度。

¹²这将在第四章统计推断中发挥核心作用。

¹³详细推导见附录 section 11.11。

EXAMPLE 1.24 (均匀分布的矩). 设 $X \sim \text{Uniform}(-a, a)$ 。则

$$\mu = 0, \quad \text{var}(X) = \frac{a^2}{3}.$$

EXAMPLE 1.25 (指数分布的矩). 设 $X \sim \text{Exp}(\lambda)$ 。则

$$\mathbb{E}X = \frac{1}{\lambda}, \quad \text{var}(X) = \frac{1}{\lambda^2}.$$

9.2. Covariance and Correlation. 两个随机变量之间的”共同变化”程度，用协方差来度量。

REMARK. 定义 1.9.2 (协方差):

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y. \quad (1.9.1)$$

协方差性质:

- (1) $\text{cov}(X, X) = \text{var}(X)$
- (2) $\text{cov}(X, Y) = \text{cov}(Y, X)$
- (3) $\text{cov}(aX + b, Y) = a\text{cov}(X, Y)$
- (4) $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y)$
- (5) 若 $X \perp\!\!\!\perp Y$, 则 $\text{cov}(X, Y) = 0$

REMARK. 定义 1.9.3 (相关系数):

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}. \quad (1.9.2)$$

重要性质: $-1 \leq \text{corr}(X, Y) \leq 1$ 。

相关系数衡量两个变量之间的线性关系强度。

WARNING: 相关不等于因果! 两个变量相关可能是由于第三个隐藏变量导致的。

14

9.3. Moment Generating Function. 矩母函数是计算矩的强大工具。

REMARK. 定义 1.9.4 (矩母函数): 若对某个 $h > 0$,

$$M_X(t) = \mathbb{E}(e^{tX}) \quad \text{对 } -h < t < h \text{ 存在}, \quad (1.9.3)$$

则称 $M_X(t)$ 为 X 的矩母函数 (mgf)。

核心性质: 矩母函数唯一确定分布! 若两个随机变量的 mgf 相同, 则它们同分布。
为什么叫”矩母函数”? 因为

$$M_X^{(k)}(0) = \mathbb{E}(X^k). \quad (1.9.4)$$

这意味着如果我们有 mgf, 可以通过对它求导来获得所有矩!

¹⁴因果推断的讨论见本书因果推断部分。

EXAMPLE 1.26 (正态分布的 mgf). 设 $X \sim N(\mu, \sigma^2)$ 。则

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right).$$

特别地, $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - [M'(0)]^2 = \sigma^2$ 。

EXAMPLE 1.27 (泊松分布的 mgf). 设 $X \sim \text{Poisson}(\lambda)$ 。则

$$M_X(t) = \exp(\lambda(e^t - 1)).$$

mgf 的加法性质尤为重要: 若 $X_1, \dots, X_n$ 独立, 则

$$M_{X_1 + \dots + X_n}(t) = \prod_{i=1}^n M_{X_i}(t). \quad (1.9.5)$$

这提供了一种验证独立随机变量和的分布的方法。

10. 1.10 Important Inequalities

概率论中有几个基本不等式, 它们在理论证明和实际应用中都非常重要。

REMARK. 定理 1.10.1 (*Markov 不等式*): 若 X 为随机变量, $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}. \quad (1.10.1)$$

Markov 不等式的意义在于: 它仅用期望就能给出概率的上界, 而不需要知道分布的完整信息。¹⁵

REMARK. 定理 1.10.2 (*Chebyshev 不等式*): 设 $\mu = \mathbb{E}X$, $\sigma^2 = \text{var}(X)$ 。则对任意 $k > 0$,

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}. \quad (1.10.2)$$

Chebyshev 不等式告诉我们: 无论分布是什么, 至少 $1 - 1/k^2$ 的概率质量落在 $\mu \pm k\sigma$ 区间内。

EXAMPLE 1.28 (*Chebyshev 应用*). 设某考试成绩均值为 70, 标准差为 10。则根据 *Chebyshev* 不等式, 至少 75% 的学生成绩在 50 到 90 分之间。

Chebyshev 不等式虽然保守, 但在无法获知确切分布时是唯一可用的工具。它也是证明大数定律的关键工具。

REMARK. 定理 1.10.3 (*Cauchy-Schwarz 不等式*): 对于任意随机变量 X 和 Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}. \quad (1.10.3)$$

重要应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。¹⁶

Jensen 不等式: 若 g 是凸函数, 则 $\mathbb{E}[g(X)] \geq g(\mathbb{E}X)$ 。¹⁷

¹⁵详细证明见附录 section 11.12。

¹⁶详细证明及更多应用见附录 section 11.13。

¹⁷Jensen 不等式的证明及更多应用见附录 section 11.14。

Summary

本章建立了概率论的基本框架，这些概念相互关联，共同构成了数理统计的基石：

- (1) **概率公理化** (1.3 节)：从相对频率的直观性质出发，建立了概率的严格数学定义
- (2) **条件概率与贝叶斯公式** (1.4 节)：提供了更新信息的数学工具，是统计推断的理论基础
- (3) **独立性** (1.4.1 节)：刻画了两个事件之间的概率关系
- (4) **随机变量** (1.5 节)：从集合论过渡到数值函数，为分布理论奠定基础
- (5) **离散与连续分布** (1.6-1.7 节)：建立了描述随机现象的主要分布类型 (Binomial, Poisson, Geometric, Normal, Exponential 等)
- (6) **变换与分位数** (1.6.2, 1.7.1-1.7.3 节)：提供了操作随机变量的技术工具
- (7) **期望与矩** (1.8-1.9 节)：分别度量分布的中心位置、离散程度和分布形状
- (8) **矩母函数** (1.9.3 节)：统一处理矩的强大工具，具有唯一性定理
- (9) **重要不等式** (1.10 节)：Markov、Chebyshev、Cauchy-Schwarz 是理论证明的基础工具

本章的核心思想：从随机现象出发，通过公理化定义建立概率论，用随机变量将样本空间数值化，然后用分布描述随机变量的行为，最后用期望等数字特征概括分布的关键性质。

与后续章节的联系：

- 第二章将概率论扩展到多个随机变量，研究联合分布、边缘分布、条件分布
- 第三章将详细介绍各种具体分布及其性质
- 第四章将利用这些工具进行统计推断（点估计、区间估计、假设检验）

Exercises

EXERCISE 1.1. 1.2.1 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$ ：

- (1) $C_1 = \{0, 1, 2\}$, $C_2 = \{2, 3, 4\}$
- (2) $C_1 = \{x : 0 < x < 2\}$, $C_2 = \{x : 1 \leq x < 3\}$

EXERCISE 1.2. 1.3.1 设 $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.4$, $\mathbb{P}(A \cap B) = 0.1$ 。求：

- (1) $\mathbb{P}(A \cup B)$
- (2) $\mathbb{P}(A | B)$
- (3) $\mathbb{P}(B | A)$

EXERCISE 1.3. 1.3.2 从 5 男 3 女中随机选 3 人。求恰好选到 2 名女生的概率。

EXERCISE 1.4. 1.4.1 某箱中有 5 个红球和 3 个白球。无放回地抽取 3 个球。求恰好抽到 2 个红球的概率。

EXERCISE 1.5. 1.4.2 设 A 和 B 是互不相容的事件， $\mathbb{P}(A) = 0.2$, $\mathbb{P}(B) = 0.3$ 。求 $\mathbb{P}(A \cup B)$ 、 $\mathbb{P}(A^c)$ 、 $\mathbb{P}((A \cup B)^c)$ 。

EXERCISE 1.6. 1.5.1 设 X 的 *cdf* 为

$$F(x) = \begin{cases} 0 & x < 0 \\ x/2 & 0 \leq x < 1 \\ 1/2 & 1 \leq x < 2 \\ 1 & x \geq 2 \end{cases}$$

求 $\mathbb{P}(0 < X \leq 1)$ 、 $\mathbb{P}(X = 1)$ 、 $\mathbb{P}(X > 1/2)$ 。

EXERCISE 1.7. 1.6.1 设 $X \sim \text{Binomial}(10, 0.3)$ 。求：

- (1) $\mathbb{P}(X = 3)$
- (2) $\mathbb{P}(X \geq 2)$
- (3) $\mathbb{E}X$

EXERCISE 1.8. 1.6.2 设 $X \sim \text{Poisson}(4)$ 。求 $\mathbb{P}(X = 0)$ 、 $\mathbb{P}(X \leq 2)$ 、 $\mathbb{E}X$ 。

EXERCISE 1.9. 1.6.3 设 $X \sim \text{Geometric}(0.4)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.10. 1.6.4 设 $X \sim \text{Binomial}(5, 0.5)$ ， $Y = X^2$ 。求 Y 的 *pmf*。

EXERCISE 1.11. 1.7.1 设 $X \sim N(100, 225)$ 。求：

- (1) $\mathbb{P}(X < 95)$
- (2) $\mathbb{P}(90 < X < 110)$
- (3) $\mathbb{P}(X > 115)$

EXERCISE 1.12. 1.7.2 设 $X \sim \text{Exp}(2)$ 。求：

- (1) $\mathbb{P}(X > 1)$
- (2) $\mathbb{P}(X < 0.5)$
- (3) 50% 分位数 (中位数)

EXERCISE 1.13. 1.7.3 设 $X \sim \text{Uniform}(0, 1)$ ， $Y = -\log X$ 。证明 $Y \sim \text{Exp}(1)$ 。

EXERCISE 1.14. 1.7.4 设 $X \sim N(0, 1)$ ， $Y = e^X$ 。求 Y 的 *pdf* (这是对数正态分布)。

EXERCISE 1.15. 1.8.1 设 X 的 *pdf* 为 $f(x) = 3x^2$ ， $0 < x < 1$ 。求 $\mathbb{E}X$ 、 $\mathbb{E}(X^2)$ 、 $\text{var}(X)$ 。

EXERCISE 1.16. 1.8.2 设 $X \sim \text{Poisson}(\lambda)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.17. 1.8.3 设 X 和 Y 是独立同分布的随机变量， $\mathbb{E}X = \mu$ ， $\text{var}(X) = \sigma^2$ 。求 $\text{var}(X - Y)$ 和 $\text{var}(X + Y)$ 。

EXERCISE 1.18. 1.9.1 设 $X \sim N(\mu, \sigma^2)$ 。求 X 的 *mgf*，并验证它产生正确的均值和方差。

EXERCISE 1.19. 1.9.2 设 X 和 Y 独立, $X \sim \text{Poisson}(2)$, $Y \sim \text{Poisson}(3)$ 。求 $X+Y$ 的分布。

EXERCISE 1.20. 1.10.1 设 $\mathbb{E}X = 100$, $\text{var}(X) = 25$ 。用 Chebyshev 不等式给出 $\mathbb{P}(|X - 100| \geq 10)$ 的上界, 并用 Markov 不等式给出另一个上界。

EXERCISE 1.21. 1.10.2 用 Cauchy-Schwarz 不等式证明: 若 $\mathbb{E}(X^2) = \mathbb{E}(Y^2) = 1$, 则 $|\mathbb{E}(XY)| \leq 1$ 。

11. 附录：公式推导

11.1. 概率公理的推导. 背景: 概率公理 (Kolmogorov, 1933) 为概率论奠定了严格数学基础。

目标: 从三条公理推导出概率的其他基本性质。

推导步骤:

性质 1: $\mathbb{P}(\phi) = 0$ 。

由公理 3, 令 $A_n = \phi$ 对所有 n , 则 $\cup_{n=1}^{\infty} A_n = \phi$, 故

$$\mathbb{P}(\phi) = \sum_{n=1}^{\infty} \mathbb{P}(\phi) = \mathbb{P}(\phi) + \sum_{n=2}^{\infty} \mathbb{P}(\phi).$$

两边减去 $\sum_{n=2}^{\infty} \mathbb{P}(\phi)$ 得 $\mathbb{P}(\phi) = 0$ 。

性质 2: 若 $A \subset B$, 则 $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$ 。

由 $B = A \cup (B \setminus A)$ 且 $A \cap (B \setminus A) = \phi$, 结合公理得

$$\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A).$$

性质 3: $\mathbb{P}(A) \leq 1$ 。

由 $A \subset C$ 和性质 2, $\mathbb{P}(A) \leq \mathbb{P}(C) = 1$ 。

性质 4 (容斥原理):

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

将 $A \cup B$ 写成不交并: $A \cup B = A \cup (B \setminus A)$, 再用公理。

布尔不等式: 对任意 $A_1, \dots, A_n$,

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i).$$

使用数学归纳法, 从容斥原理中去掉负项得到。

11.2. 贝叶斯公式的深层意义. 背景: 贝叶斯公式是更新信念的数学工具。

全概率公式是贝叶斯公式的基础:

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \mathbb{P}(A | B_i),$$

其中 $\{B_i\}$ 是样本空间的一个划分。

贝叶斯公式的直觉:

将条件概率公式 $\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j \cap A)}{\mathbb{P}(A)}$ 中的分子、分母分别展开：

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j)\mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i)\mathbb{P}(A | B_i)}.$$

先验到后验的更新机制：

- (1) 先验概率 $\mathbb{P}(B_j)$ ：观测数据前对假设的信念
- (2) 似然 $\mathbb{P}(A | B_j)$ ：在该假设下观测到数据的“可能性”
- (3) 归一化常数 $\sum_i \mathbb{P}(B_i)\mathbb{P}(A | B_i)$ ：确保后验概率之和为 1
- (4) 后验概率 $\mathbb{P}(B_j | A)$ ：观测数据后对假设的更新信念

贝叶斯公式的核心思想：用数据（通过似然）来更新先验信念，得到后验分布。这构成了贝叶斯统计的理论基础。

11.3. 医学检测假阳性详解. 问题设定：

- 疾病患病率： $\mathbb{P}(D) = 0.01$ （1%）
- 检测准确率： $\mathbb{P}(+ | D) = 0.99$ （患病者 99% 阳性）
- 误报率： $\mathbb{P}(+ | D^c) = 0.01$ （健康者 1% 阳性）

求解： $\mathbb{P}(D | +)$ ——检测阳性者真正患病的概率。

由贝叶斯公式：

$$\mathbb{P}(D | +) = \frac{\mathbb{P}(D)\mathbb{P}(+ | D)}{\mathbb{P}(D)\mathbb{P}(+ | D) + \mathbb{P}(D^c)\mathbb{P}(+ | D^c)}.$$

代入数值：

$$= \frac{0.01 \times 0.99}{0.01 \times 0.99 + 0.99 \times 0.01} = \frac{0.0099}{0.0099 + 0.0099} = \frac{0.0099}{0.0198} = 0.5.$$

直觉解释：即使检测准确率高达 99%，由于疾病非常罕见（1%），在所有阳性结果中，真阳性（ $0.01 \times 0.99 = 0.0099$ ）和假阳性（ $0.99 \times 0.01 = 0.0099$ ）的数量竟然相同！这说明在罕见事件检测中，**先验概率**（患病率）对后验概率有决定性影响。

11.4. 两两独立但不相互独立的反例. 背景：独立性是概率论中的重要概念，但两两独立不等于相互独立。

经典反例：掷两枚公平硬币，考虑以下四个事件：

- A ：第一枚硬币正面朝上
- B ：第二枚硬币正面朝上
- C ：两枚硬币结果相同（ HH 或 TT ）

验证两两独立：

- $\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = 1/2$
- $\mathbb{P}(A \cap B) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(A)\mathbb{P}(B)$
- $\mathbb{P}(A \cap C) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(A)\mathbb{P}(C)$
- $\mathbb{P}(B \cap C) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(B)\mathbb{P}(C)$

但不相互独立：

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(HH) = 1/4 \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = 1/8.$$

这个例子说明：三个事件中，任意两个都独立，但三个放在一起就不独立了。

11.5. 几何分布无记忆性的证明. 背景：几何分布描述”直到第一次成功所需等待次数”的分布。

定义： $X \sim \text{Geom}(p)$, $\mathbb{P}(X = k) = (1-p)^{k-1}p$, $k = 1, 2, 3, \dots$

无记忆性：对任意 $m, n \geq 1$,

$$\mathbb{P}(X > m+n \mid X > m) = \mathbb{P}(X > n).$$

证明：

$$\mathbb{P}(X > m+n \mid X > m) = \frac{\mathbb{P}(X > m+n)}{\mathbb{P}(X > m)} = \frac{(1-p)^{m+n}}{(1-p)^m} = (1-p)^n = \mathbb{P}(X > n).$$

直观含义：如果已经等待了 m 次且没有成功，那么再等待 n 次的概率与”从头开始等待 n 次”的概率完全相同。过去的时间”被遗忘”了。

唯一性：无记忆性是几何分布的特征性质——离散支撑集 $\{1, 2, 3, \dots\}$ 上具有无记忆性的分布只有几何分布。

11.6. Poisson 近似二项分布的证明. 背景：Poisson 分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限。

定理：若 $X_n \sim \text{Bin}(n, p_n)$ ，且 $np_n \rightarrow \lambda$ ，则对任意固定 k ：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

证明：

二项分布式：

$$\mathbb{P}(X_n = k) = \frac{n(n-1)\cdots(n-k+1)}{k!} p_n^k (1-p_n)^{n-k}.$$

写成：

$$= \frac{n^k \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} + o(1).$$

当 $n \rightarrow \infty$ 时：

$$\begin{aligned} \left(1 - \frac{j}{n}\right) &\rightarrow 1 \quad \text{for fixed } j, \\ \left(1 - \frac{\lambda}{n}\right)^n &\rightarrow e^{-\lambda}, \\ \left(1 - \frac{\lambda}{n}\right)^{-k} &\rightarrow 1. \end{aligned}$$

因此：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

实际意义：当 n 很大、 p 很小时，用 $\text{Poisson}(\lambda = np)$ 近似 $\text{Bin}(n, p)$ 可以大大简化计算。

11.7. 指数分布无记忆性的讨论. 背景：指数分布是连续版本的无记忆分布。

定义： $X \sim \text{Exp}(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $x > 0$ 。

无记忆性：对任意 $s, t > 0$,

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t).$$

证明：

$$\mathbb{P}(X > s + t \mid X > s) = \frac{\mathbb{P}(X > s + t)}{\mathbb{P}(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(X > t).$$

与几何分布的类比：离散几何分布和连续指数分布都具有无记忆性。这不是巧合——它们都是“等待直到事件发生”这一过程的模型，只是时间参数不同。

实际应用：指数分布常用于描述：

- 电子元件的寿命（假设失效率恒定）
- 客户服务时间
- 打电话的间隔时间

Poisson 过程的联系：如果事件以固定速率 λ 发生（Poisson 过程），那么相邻事件的时间间隔服从指数分布 $\text{Exp}(\lambda)$ 。

11.8. 一元变换公式的推导. 背景：已知 X 的分布，求 $Y = g(X)$ 的分布。

定理：设 X 是连续随机变量， $f_X(x)$ 已知。 $y = g(x)$ 是一一对应且可导的， $x = g^{-1}(y) = h(y)$ 。则

$$f_Y(y) = f_X(h(y)) |h'(y)|, \quad y \in \mathcal{S}_Y.$$

证明：

由 CDF 定义：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq h(y)) = F_X(h(y)).$$

对 y 求导（链式法则）：

$$f_Y(y) = f_X(h(y)) \cdot h'(y) = f_X(h(y)) |h'(y)|.$$

多对一情况：若 g 不是一一对应，则需将所有映射到同一 y 的 x 的概率相加：

$$f_Y(y) = \sum_i f_X(x_i) |x'_i|,$$

其中 $x_i = h_i(y)$ 是 $y = g(x)$ 的各个解。

11.9. 函数期望定理的证明. 背景：已知 X 的分布，求 $Y = g(X)$ 的期望。

定理：设 $Y = g(X)$ 。

- 若 X 离散： $\mathbb{E}Y = \sum_x g(x)p_X(x)$
- 若 X 连续： $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x)f_X(x)dx$

证明（连续情形）：

由定义：

$$\mathbb{E}Y = \int_{-\infty}^{\infty} y f_Y(y) dy.$$

使用变换公式：

$$= \int_{-\infty}^{\infty} y \cdot f_X(h(y)) |h'(y)| dy.$$

做变量替换 $x = h(y)$ ，则 $dx = h'(y)dy$ ， $y = g(x)$ ：

$$= \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

重要意义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！这就是“函数期望定理”的价值。

11.10. 期望线性性的证明. 定理：对任意随机变量 X, Y （期望存在）和常数 a, b ：

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y.$$

证明：

由函数期望定理和重期望：

$$\mathbb{E}[aX + bY] = \iint (ax + by) f_{XY}(x, y) dx dy.$$

分离积分：

$$= a \iint x f_{XY}(x, y) dx dy + b \iint y f_{XY}(x, y) dx dy = a\mathbb{E}X + b\mathbb{E}Y.$$

关键点：无需 X, Y 独立！线性性对所有随机变量都成立，无论它们是否相关。

推论：对 iid $X_1, \dots, X_n$ ， $\mathbb{E}\bar{X} = \mathbb{E}X_1$ 。

由线性性：

$$\mathbb{E}\bar{X} = \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n X_i \right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \frac{1}{n} \cdot n\mathbb{E}X_1 = \mathbb{E}X_1.$$

11.11. 方差公式的推导. 背景：方差度量随机变量偏离其均值的程度。

定义： $\text{var}(X) = \mathbb{E}[(X - \mu)^2]$ ，其中 $\mu = \mathbb{E}X$ 。

计算公式： $\text{var}(X) = \mathbb{E}(X^2) - \mu^2$ 。

推导：

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2 - 2\mu X + \mu^2] = \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - 2\mu^2 + \mu^2 = \mathbb{E}(X^2) - \mu^2.$$

方差性质：

(1) $\text{var}(aX + b) = a^2\text{var}(X)$ （尺度变换）

(2) 若 $X \perp Y$: $\text{var}(X+Y) = \text{var}(X) + \text{var}(Y)$

第二点的证明: 若 X, Y 独立,

$$\text{var}(X+Y) = \mathbb{E}[(X+Y)^2] - [\mathbb{E}(X+Y)]^2 = \mathbb{E}(X^2) + 2\mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(Y^2) - \mu_X^2 - 2\mu_X\mu_Y - \mu_Y^2 = \text{var}(X) + \text{var}(Y)$$

注意: 独立性条件不可少! 若 $X = Y$, 则 $\text{var}(X+Y) = \text{var}(2X) = 4\text{var}(X) \neq 2\text{var}(X)$ 。

11.12. Markov 不等式的证明. 定理: 若 $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}.$$

证明:

设事件 $A = \{g(X) \geq a\}$, 则 $g(X) \geq a \cdot \mathbb{I}_A$ (因为在 A 上 $g(X) \geq a$, 在 A^c 上 $g(X) \geq 0$)。

取期望:

$$\mathbb{E}[g(X)] \geq \mathbb{E}[a \cdot \mathbb{I}_A] = a \cdot \mathbb{P}(A) = a \cdot \mathbb{P}(g(X) \geq a).$$

两边除以 $a > 0$ 得证。

意义: Markov 不等式仅用一阶矩 (期望) 就能给出概率上界, 不依赖分布的具体形式。当然, 上界可能很松——例如对正态分布, $\mathbb{P}(|X| \geq 2\sigma)$ 的真实值约为 0.05, 而 Markov 上界给出的是 1/4。

特例: 取 $g(X) = (X - \mu)^2$, $a = k^2$, 得 Chebyshev 不等式:

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\text{var}(X)}{k^2}.$$

11.13. Cauchy-Schwarz 不等式的证明. 定理: 对任意随机变量 X, Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}.$$

证明:

考虑 $\mathbb{E}[(tX - Y)^2] \geq 0$ 对任意实数 t 成立。

展开:

$$0 \leq \mathbb{E}[t^2 X^2 - 2tXY + Y^2] = t^2 \mathbb{E}(X^2) - 2t \mathbb{E}(XY) + \mathbb{E}(Y^2).$$

这是关于 t 的二次不等式, 其判别式必须非正:

$$[2\mathbb{E}(XY)]^2 - 4\mathbb{E}(X^2)\mathbb{E}(Y^2) \leq 0.$$

整理得:

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}.$$

应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。

设 $X^* = X - \mu_X$, $Y^* = Y - \mu_Y$, 则

$$|\text{corr}(X, Y)| = \frac{|\mathbb{E}(X^*Y^*)|}{\sqrt{\text{var}(X)\text{var}(Y)}} \leq \frac{\sqrt{\mathbb{E}(X^{*2})\mathbb{E}(Y^{*2})}}{\sqrt{\text{var}(X)\text{var}(Y)}} = 1.$$

11.14. Jensen 不等式的证明. 定理：若 g 是凸函数， X 的期望存在，则

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}X).$$

证明（使用凸函数的支撑超平面）：

由凸函数的性质，对任意 x_0 ，存在支撑线 $L(x) = g(x_0) + c(x - x_0)$ 使得 $g(x) \geq L(x)$ 对所有 x 成立。

取 $x_0 = \mathbb{E}X$ ，则 $g(x) \geq g(\mathbb{E}X) + c(x - \mathbb{E}X)$ 。

取期望：

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}X) + c\mathbb{E}(X - \mathbb{E}X) = g(\mathbb{E}X) + c \cdot 0 = g(\mathbb{E}X).$$

特例：

- $g(x) = x^2$ (凸)： $\mathbb{E}(X^2) \geq (\mathbb{E}X)^2$
- $g(x) = e^x$ (凸)： $\mathbb{E}(e^X) \geq e^{\mathbb{E}X}$

第二个特例说明：指数函数的期望大于等于期望的指数——这在金融中用于证明“彩票溢价”现象。

CHAPTER 2

多元随机变量及其分布

Chapter 2 概述

在一元情形，我们用 cdf $F_X(x) = \mathbb{P}(X \leq x)$ 描述单个随机变量的行为。但在许多场景中，单个变量的分布并不能回答我们的问题——我们需要知道多个变量如何共同变化。

为什么需要联合分布？ 例如，在经济学中，我们关心收入与教育年限的共同分布；在医学中，我们关心血压与胆固醇的联合水平；在金融中，资产收益率之间的相关性是风险管理的核心。这些问题都涉及多个随机变量的联合行为。

统计推断的核心任务——从样本推断总体——本质上也是多元的：样本是多个观测值的向量，而统计量是这些观测值的函数。第 4 章将看到，点估计、置信区间、假设检验全部建立在多元分布理论之上。

本章路线图： 联合分布 $\rightarrow$ 边缘分布 $\rightarrow$ 条件分布 $\rightarrow$ 独立性 $\rightarrow$ 相关性 $\rightarrow$ 多元正态 $\rightarrow$ 多元推广

1. 2.1 从一元到多元：联合分布

1.1. 为什么需要联合分布？ 在一元情形，我们学会了用 cdf、pmf/pdf 描述单个随机变量的行为。但在真实世界中，变量很少孤立存在。

核心问题： 给定两个随机变量 X_1 和 X_2 ，如何描述它们的联合行为？

例如，设 X_1 为身高， X_2 为体重。知道身高分布和体重分布当然有用，但知道两者如何“共同变化”——高个子是否倾向于更重——显然更有价值。这种“共同变化”的数学表达，正是联合分布。

历史注记： 多元分析的思想可以追溯到 Francis Galton (1822-1911) 的工作。他研究遗传问题时发现，单个特征的分布不足以描述遗传规律——必须考虑特征之间的相关性。他发明的“相关系数” (correlation coefficient) 正是本章的核心概念之一。

1.2. 随机向量与联合分布.

DEFINITION 2.1 (随机向量). 设样本空间为 $\mathcal{C}$ ， X_1 和 X_2 为定义在 $\mathcal{C}$ 上的两个随机变量。则 (X_1, X_2) 称为随机向量，其取值空间为 $\mathcal{D} = \{(x_1, x_2) : x_1 = X_1(c), x_2 = X_2(c), c \in \mathcal{C}\}$ 。

联合 cdf 是一元 cdf 的自然推广：

$$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2). \quad (1)$$

注意：这里的“且” ($,$) 表示两个事件同时发生。