

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;

0.24. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.25. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}\left[e^{(t/\sigma)X}\right] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.26. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

0.27. 正态分布有界性的证明. 背景 (Background): 正态分布的尾部概率可以任意小。

目标 (Goal): 证明对任意 $\epsilon > 0$, 存在 η 使得 $\mathbb{P}[|X| > \eta] < \epsilon$ 。

推导步骤 (Derivation Steps):

1. 设 $X \sim N(\mu, \sigma^2)$, 考虑尾部概率 $\mathbb{P}(|X| > \eta)$ 。

2. 利用 Markov 不等式: 对任意 $t > 0$,

$$\mathbb{P}(|X - \mu| > \eta) = \mathbb{P}((X - \mu)^2 > \eta^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{\eta^2} = \frac{\sigma^2}{\eta^2}.$$

3. 由 Chebyshev 不等式可直接得出: 对于任意 $\epsilon > 0$, 取 $\eta > \sigma/\sqrt{\epsilon}$, 则

$$\mathbb{P}(|X - \mu| > \eta) \leq \frac{\sigma^2}{\eta^2} < \epsilon.$$

4. 进一步, 对于标准正态分布 $Z \sim N(0, 1)$, 尾部概率有更精确的界: 由积分不等式

$$\int_\eta^\infty e^{-t^2/2} dt \leq \frac{1}{\eta} e^{-\eta^2/2}, \quad \eta > 0,$$

可得 $\mathbb{P}(|Z| > \eta) \leq \sqrt{\frac{2}{\pi}} \frac{e^{-\eta^2/2}}{\eta}$ 。

5. 因此, 无论使用 Chebyshev 的粗略界还是正态分布的精确界, 均可证明: 对于任意 $\epsilon > 0$, 存在 η 使得 $\mathbb{P}(|X| > \eta) < \epsilon$ 。这说明正态分布的尾部概率可以任意小。

结论: 正态分布的尾部概率可以任意小, 即 $\lim_{\eta \rightarrow \infty} \mathbb{P}(|X| > \eta) = 0$ 。这体现了正态分布的 ** 有界性 ** (tails vanish)。■

0.28. 卡方分布 Δ 方法的详细推导. 背景 (Background): 将 Δ 方法应用于卡方变量的标准差。设 $V_n \sim \chi^2(n)$ (即 n 个标准正态变量的平方和), 则 $V_n/n \xrightarrow{P} 1$, 我们希望求 $\sqrt{n}(\sqrt{V_n} - \sqrt{n})$ 的渐近分布。

参数定义 (Parameter Definitions):

- $V_n \sim \chi^2(n)$: 自由度为 n 的卡方分布
- $v = n$: 卡方分布的均值
- $g(x) = \sqrt{x}$: 平方根变换函数

已知条件 (Given):

- 由大数定律: $V_n/n \xrightarrow{P} 1$
- 由中心极限定理: $\sqrt{n}(V_n/n - 1) \xrightarrow{D} N(0, 2)$
- Δ 方法 (Theorem 5.2.9, Hogg): 若 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 且 $g(x)$ 在 θ 处可导且 $g'(\theta) \neq 0$, 则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

目标 (Goal): 求 $\sqrt{n}(\sqrt{V_n} - \sqrt{n})$ 的渐近分布。

推导步骤 (Derivation Steps):

1. 令 $X_n = V_n/n$, 则 $X_n \xrightarrow{P} 1 = \theta$ 。
2. 计算 $g'(x) = \frac{d}{dx}\sqrt{x} = \frac{1}{2\sqrt{x}}$, 因此 $g'(\theta) = g'(1) = \frac{1}{2}$ 。
3. 验证 Δ 方法条件: - $X_n = V_n/n$ 依概率收敛到 $\theta = 1$ - $g(x) = \sqrt{x}$ 在 $x = 1$ 处可导 - 由 CLT: $\sqrt{n}(X_n - 1) = \frac{1}{\sqrt{n}}(V_n - n) \xrightarrow{D} N(0, 2)$
4. 应用 Δ 方法:

$$\sqrt{n}(g(V_n/n) - g(1)) = \sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) \xrightarrow{D} N\left(0, 2 \cdot \left(\frac{1}{2}\right)^2\right) = N(0, \frac{1}{2}).$$

5. 注意到

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = n \cdot \sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) = n \cdot \sqrt{n}\left(\frac{\sqrt{V_n}}{\sqrt{n}} - 1\right).$$

实际上更直接的方式是: 直接对 $g(V_n) = \sqrt{V_n}$ 在 $v = n$ 处应用 Δ 方法。

6. 设 $Y_n = V_n$, 则 $\sqrt{n}(Y_n - n) \xrightarrow{D} N(0, 2n)$ 。但更好的做法是利用 $V_n/n \xrightarrow{P} 1$: 由步骤 4 的结果, 乘以 $\sqrt{n}$:

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = \sqrt{n} \cdot \sqrt{n} \cdot \left(\sqrt{\frac{V_n}{n}} - 1\right) = n \cdot \sqrt{n} \left(\sqrt{\frac{V_n}{n}} - 1\right).$$

更直接地: 对 $X_n = V_n/n$ 应用 Δ 方法得

$$\sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) \xrightarrow{D} N\left(0, \frac{1}{2}\right).$$

两边乘以 $\sqrt{n}$:

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = \sqrt{n} \cdot \sqrt{n} \left(\sqrt{\frac{V_n}{n}} - 1 \right) \xrightarrow{D} \sqrt{n} \cdot N\left(0, \frac{1}{2}\right).$$

但这不是正确的缩放。正确的做法是直接对 $\sqrt{V_n}$ 应用 Δ 方法到 $\sqrt{n}$:

因为 $\sqrt{n}(\frac{V_n}{n} - 1) \xrightarrow{D} N(0, 2)$, 且 $g'(1) = \frac{1}{2}$, 所以

$$\sqrt{n} \left(\sqrt{\frac{V_n}{n}} - 1 \right) \xrightarrow{D} N\left(0, 2 \cdot \frac{1}{4}\right) = N\left(0, \frac{1}{2}\right).$$

即

$$\sqrt{n} \left(\frac{\sqrt{V_n}}{\sqrt{n}} - 1 \right) \xrightarrow{D} N\left(0, \frac{1}{2}\right).$$

因此

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) \xrightarrow{D} N\left(0, \frac{1}{2} \cdot n\right) = N\left(0, \frac{n}{2}\right).$$

这表明 $\sqrt{V_n}$ 的渐近方差与 $\sqrt{n}$ 成正比。

结论: 应用 Δ 方法于卡方变量的平方根变换, 得到

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) \xrightarrow{D} N\left(0, \frac{1}{2}\right) \cdot \sqrt{n} = N\left(0, \frac{n}{2}\right).$$

更精确地, $\sqrt{n}(\sqrt{V_n} - \sqrt{n})/\sqrt{n/2} = \sqrt{2}(\sqrt{V_n} - \sqrt{n})/\sqrt{V_n/2} \xrightarrow{D} N(0, 1)$ 。■

0.29. 卡方检验的详细推导. 背景 (Background): 拟合优度 χ^2 检验 (Goodness-of-Fit Test) 由 Karl Pearson 于 1900 年提出, 是统计推断的早期方法之一。该检验用于检验观测频数与期望频数之间的偏离程度。

参数定义 (Parameter Definitions):

- $X_i \sim \text{Multinomial}(n, p_1, \dots, p_k)$: 多项分布, X_i 为落入第 i 类的频数
- p_i : 落入第 i 类的真实概率
- p_{i0} : 原假设 H_0 下指定的概率值
- np_{i0} : 原假设下第 i 类的期望频数
- $Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_{i0})^2}{np_{i0}}$: Pearson χ^2 统计量

已知条件 (Given):

- 当 H_0 为真时, $p_i = p_{i0}$, $i = 1, \dots, k$
- 由中心极限定理, 当 $n \rightarrow \infty$ 且 $np_i > 0$ 时,

$$\frac{X_i - np_i}{\sqrt{np_i(1 - p_i)}} \xrightarrow{D} N(0, 1).$$

- 当 H_0 为真时, $X_i \approx N(np_{i0}, np_{i0}(1 - p_{i0}))$

目标 (Goal): 证明在 H_0 下, $Q_{k-1} \xrightarrow{D} \chi^2(k-1)$ 。

推导步骤 (Derivation Steps):

1. 首先考虑二项分布情形。设 $X_1 \sim b(n, p_1)$, $X_2 = n - X_1$, $p_2 = 1 - p_1$ 。定义标准化变量

$$Z = \frac{X_1 - np_1}{\sqrt{np_1(1-p_1)}}.$$

由 CLT, $Z \xrightarrow{D} N(0, 1)$ 。

2. 则 $Z^2 \xrightarrow{D} \chi^2(1)$ (标准正态变量的平方服从自由度为 1 的卡方分布)。

3. 展开 Z^2 :

$$Z^2 = \frac{(X_1 - np_1)^2}{np_1(1-p_1)} = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_1 - np_1)^2}{n(1-p_1)}.$$

4. 利用 $X_2 = n - X_1$, 有 $(X_1 - np_1)^2 = (n - X_2 - n + np_2)^2 = (X_2 - np_2)^2$ 。因此

$$Z^2 = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_2 - np_2)^2}{np_2} = Q_1,$$

即二项情形的 Pearson χ^2 统计量。

5. 推广到多项分布。设 $(X_1, \dots, X_{k-1}) \sim \text{Multinomial}(n, p_1, \dots, p_{k-1})$, $X_k = n - \sum_{i=1}^{k-1} X_i$, $p_k = 1 - \sum_{i=1}^{k-1} p_i$ 。

定义 Pearson 统计量

$$Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i}.$$

6. 关键步骤: 将 Q_{k-1} 表示为平方和形式。令

$$Y_i = \frac{X_i - np_i}{\sqrt{np_i}}, \quad i = 1, \dots, k.$$

则 $Q_{k-1} = \sum_{i=1}^k Y_i^2$ 。

7. 向量形式: 设 $\mathbf{Y} = (Y_1, \dots, Y_k)$ 。可以证明 (见 Hogg, McKean, Craig Theorem 4.7.1 或更高级课程的证明), 当 $n \rightarrow \infty$ 时, $\mathbf{Y}$ 的协方差矩阵为

$$\Sigma = I_k - \mathbf{p}\mathbf{p}',$$

其中 $\mathbf{p} = (p_1, \dots, p_k)'$, I_k 为 $k \times k$ 单位矩阵。

8. 该协方差矩阵 Σ 是 ** 幂等矩阵 ** (idempotent), 且 $\text{rank}(\Sigma) = k - 1$ 。对于幂等矩阵, 其特征值为 0 或 1。

9. 因此, $Q_{k-1} = \mathbf{Y}'\mathbf{Y}$ 服从 (渐近) $\chi^2(k-1)$ 分布。这基于以下事实: 若 $\mathbf{Y} \xrightarrow{D} N(\mathbf{0}, \Sigma)$, 且 Σ 是幂等的, 则 $\mathbf{Y}'\Sigma^-\mathbf{Y} \xrightarrow{D} \chi^2(\text{rank}(\Sigma))$, 其中 Σ^- 为广义逆。

10. 具体推导 (来自 Hogg): 设 $Z_i = (X_i - np_i)/\sqrt{np_i}$, 则 $\sum_{i=1}^k \sqrt{p_i}Z_i = 0$ (因为 $\sum X_i = n$)。定义

$$Q_{k-1} = \sum_{i=1}^k Z_i^2 = \sum_{i=1}^k (Z_i - \bar{Z}_w)^2 + (\text{某个组合})^2,$$

其中 $\bar{Z}_w = \sum_{i=1}^k p_i Z_i / \sum_{i=1}^k p_i = 0$ 。

最终得到 Q_{k-1} 可以分解为一个 $\chi^2(1)$ 变量 (来自组合约束) 和一个 $\chi^2(k-2)$ 变量之和, 即 $\chi^2(k-1)$ 。

结论：在原假设 $H_0 : p_i = p_{i0}, i = 1, \dots, k$ 下，当样本量 $n \rightarrow \infty$ 时，

$$Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_{i0})^2}{np_{i0}} \xrightarrow{D} \chi^2(k-1).$$

因此，对于大样本， Q_{k-1} 具有近似卡方分布，自由度为 $k-1$ （减去一个约束 $\sum p_i = 1$ ）。这就是 Karl Pearson 于 1900 年提出的拟合优度 χ^2 检验的理论基础。■

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是**固定（但未知）的常数**，而区间 $[L, U]$ 是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 Chapter 4 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及（直方图估计）
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

简单区分：

场景	方法	章节
分布形式未知	非参数方法（直方图、核密度估计）	Chapter 10
分布形式已知、参数未知	参数方法（MLE、CI、检验）	Chapter 4

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 1. 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 2. 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 3. 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计（MLE）被提出的**动机**。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

具体例子：

- S^2 （无偏）和 $\hat{\sigma}^2$ （有偏，但 MLE）
- 两者都常用，但各有用途
- “最优”需要更精确的定义（后续章节的 UMVUE）

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

学习笔记.