数理统计导论

Hogg, McKean, Craig

目录

Part 1. 概率论基础 5

引言：从随机性中学习 7

引言：从随机性中学习 7
1. 为什么需要概率论? 7
2. 教材内容预览 7
3. 这三章的内在逻辑 10
4. 学习方法建议 10
5. 习题说明 11

Chapter 1. Probability and Distributions 13
Chapter 1 概述 13
1. 1.1 Introduction 13
2. 1.2 Sets 14
3. 1.3 The Probability Set Function 15
4. 1.4 Conditional Probability and Independence 16
5. 1.5 Random Variables 18
6. 1.6 Discrete Random Variables 18
7. 1.7 Continuous Random Variables 19
8. 1.8 Expectation of a Random Variable 19
9. 1.9 Some Special Expectations 20
10. 1.10 Important Inequalities 20
Summary 21
Exercises 21

Chapter 2. 二元随机变量分布 23
Chapter 2 概述 23
1. 2.1 从一元到二元 23
2. 2.2 变换：寻找新视角 24
3. 2.3 条件分布：信息的价值 25
4. 2.4 独立性：变量间的”无关系” 25
5. 2.5 相关性：线性关联的度量 26
6. 2.6 二元正态：最重要的二元分布 26

Chapter 3. 一些特殊分布 29
Chapter 3 概述 29
1. 3.1 从伯努利到二项：计数的科学 29
2. 3.2 泊松分布：稀有事件的世界 31
3. 3.3 伽马、卡方与贝塔分布 31
4. 3.4 正态分布：统计学的女王 33
5. 3.5 多元正态分布 34
6. 3.6 t 分布与 F 分布 34
本章小结 35

Chapter 4. 一些基本的统计推断 37
Chapter 4 概述 37
1. 4.1 抽样与统计量 37
2. 4.2 点估计 38
3. 4.3 置信区间 38
4. 4.4 顺序统计量 39
5. 4.5 假设检验 39
6. 4.6 卡方检验 40
7. 4.7 蒙特卡洛方法 40
8. 4.8 Bootstrap 方法 41
本章小结 41
1. 问答记录 42

Part 1

概率论基础

引言：从随机性中学习

1. 为什么需要概率论?

当我们掷一枚硬币时，结果是”正面”还是”反面?¨ 在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计（mathematical statistics）的核心问题是：*给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息?*

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论（probability theory）存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化”可能性的¨ 大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

Remark. **这部分类比是否恰当? 微积分 *vs* 概率论**

2. 教材内容预览

本书（Hogg, McKean & Craig, *Introduction to Mathematical Statistics*）的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布（Probability and Distributions). 第一章从最基本的问题出发：*如何用数学语言描述”可能性?¨*

1. 概率公理化. 我们从集合论开始，建立样本空间（sample space）和事件（event）的概念。然后引入概率集函数（probability set function）P，这是一个满足非负性、归一化、可列可加性的集合函数。*为什么需要公理化? 因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。*

2. 分布函数. 随机变量（random variable）是将随机现象数量化的桥梁。对于随机变量 X，其累积分布函数（cumulative distribution function, CDF）定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数（probability mass function, pmf）$p_X(x) = \mathbb{P}(X = x)$；对于连续型随机变量，我们用概率密度函数（probability density function, pdf）$f_X(x)$，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x)\,dx$。

为什么需要同时引入 *CDF*、*pmf*、*pdf*？这三种描述适用于不同场景。*CDF* 是最一般的概念；*pmf* 适用于离散型变量（如二项分布）；*pdf* 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率（conditional probability）$P(A \mid B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式（Bayes' theorem）

$$P(B \mid A) = \frac{P(A \mid B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从"结果反向推断"原因的概率。

4. 条件期望. 条件期望（conditional expectation）$\mathbb{E}(X \mid Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时，X 的最佳预测恰好是条件期望。

5. 变换（Transformations）. 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式（Markov inequality）和切比雪夫不等式（Chebyshev inequality）结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- **马尔可夫不等式:** 若 $X \geq 0$，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- **切比雪夫不等式:** $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \mathrm{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布（Multivariate Distributions）. 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y，其联合分布（joint distribution）$F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以"消去一个变量得到边缘分布（marginal distribution）：

$$F_X(x) = \lim_{y \to \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x \mid y) = \mathbb{P}(X \leq x \mid Y = y).$$

条件期望 $\mathbb{E}(X \mid Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数（correlation coefficient）

$$\mathrm{corr}(X, Y) = \frac{\mathrm{cov}(X, Y)}{\sqrt{\mathrm{var}(X)\mathrm{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注"线性关"系？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \ldots, X_n)'$ 时，协方差矩阵（covariance matrix）

$$\mathbf{\Sigma} = \mathrm{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\mathbf{\Sigma}\mathbf{A}'$。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 *notation*，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布（Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布（binomial distribution）$B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布（Poisson distribution）$P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$，$Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$（可加性）。

3. 伽马分布与卡方分布. 伽马分布（gamma distribution）$\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$，$\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$，$X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布（beta distribution）Beta(α, β) 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布（normal distribution）$N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯（Gauss）发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布（CLT）
- t 分布、F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布（Student's t distribution）。在方差分析和回归分析中，F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

(1) **描述单个随机变量.** 概率函数 → CDF/PDF → 期望与矩 → 特殊分布（第一、三章）

(2) **描述多个随机变量的关系.** 联合分布 → 边缘/条件分布 → 相关系数 → 线性变换（第二、七章）

(3) **连接理论与计算.** 理论结果 ↔ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联?

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 概述

本章建立概率论的基本框架，从集合论和概率公理出发，逐步过渡到随机变量、期望、方差等核心概念。

1. 1.1 Introduction

本节直观介绍概率模型的概念，在 1.3 节中将其形式化。许多研究的特点是，在本质上相同的条件下可以重复进行实验。例如，医学研究关注药物的效果；经济学家关注某些商品的价格变化；农学家研究肥料对粮食产量的影响。实验产生 outcome，但无法在实验前确定预测结果。

若实验可以重复进行，且所有可能 outcome 可以事先描述，则称为随机实验（random experiment），所有可能 outcome 的集合称为样本空间（sample space），记为 $\mathcal{C}$。

Example 1.1 (例 1.1.1). *抛掷硬币，outcome 为 T（反面）或 H（正面）。样本空间为 $\mathcal{C} = \{H, T\}$。*

Example 1.2 (例 1.1.2). *投掷一枚红骰子和一枚白骰子，outcome 为有序对（红骰子点数，白骰子点数）。样本空间包含 36 个有序对：$\mathcal{C} = \{(1,1), \ldots, (1,6), (2,1), \ldots, (6,6)\}$。*

我们用小写 Roman 字母表示 $\mathcal{C}$ 的元素，如 a, b, c。事件（event）是 $\mathcal{C}$ 的子集，用大写 Roman 字母表示，如 A, B, C。

重复实验 N 次，事件 A 发生的次数（频率）记为 f，则 f/N 称为相对频率（relative frequency）。当 N 增大时，相对频率趋于稳定，趋向某个数 p，这称为事件 A 的概率（probability）。

Example 1.3 (例 1.1.3). *在例 1.1.2 中，设 B 为点数之和为 7 的所有有序对：$B = \{(1,6), (2,5), (3,4), (4,3), (5,2), (6,1)\}$。若投掷 $N = 400$ 次，$f = 60$ 次出现点数之和为 7，则相对频率 $f/N = 60/400 = 0.15$，因此 B 的概率约为 0.15。*

Remark (注 1.1.1). *概率的相对频率解释依赖于实验可重复的条件。另一种观点是将概率视为主观信念。无论采用哪种解释，1.3 节的概率数学性质都是一致的。*

统计学的目的是为随机实验提供数学模型，进而进行统计推断。概率论的理论基础之一是基于集合和集合函数的概念，这正是下一节的内容。

2. 1.2 Sets

集合是现代数学的基本概念。设 C 表示区间 $[0,1]$ 上的实数集合，则 $\frac{3}{4} \in C$。

若集合 C 是有限的或与正整数集等势，则称 C 为可数的（countable）。

2.1. 1.2.1 Review of Set Theory. 设 $\mathcal{C}$ 为样本空间，事件是 $\mathcal{C}$ 的子集。

Definition 1.1 (定义 1.2.1). *事件 A 的补（complement）A^c 是 $\mathcal{C}$ 中所有不属于 A 的元素构成的集合：$A^c = \{x \in \mathcal{C} : x \notin A\}$。*

空集（empty set）记为 ϕ。注意 $\mathcal{C}^c = \phi$，$\phi^c = \mathcal{C}$。

Definition 1.2 (定义 1.2.2). *若集合 A 的每个元素都是集合 B 的元素，则称 A 是 B 的子集，记作 $A \subset B$。若 $A \subset B$ 且 $B \subset A$，则 $A = B$。*

Definition 1.3 (定义 1.2.3). *设 A 和 B 为事件。A 和 B 的并（union）$A \cup B$ 是所有属于 A 或属于 B 的元素构成的集合。*

Definition 1.4 (定义 1.2.4). *设 A 和 B 为事件。A 和 B 的交（intersection）$A \cap B$ 是所有同时属于 A 和 B 的元素构成的集合。*

Definition 1.5 (定义 1.2.5). *若 $A \cap B = \phi$，则称 A 和 B 是不交的（disjoint）。*

若 $A_1, A_2, \ldots, A_n$ 为任意集合，定义

$$A_1 \cup A_2 \cup \cdots \cup A_n = \{x : x \in A_i \text{ for some } i = 1, 2, \ldots, n\} \tag{1.2.8}$$

$$A_1 \cap A_2 \cap \cdots \cap A_n = \{x : x \in A_i \text{ for all } i = 1, 2, \ldots, n\}. \tag{1.2.9}$$

简写为 $\cup_{i=1}^n A_i$ 和 $\cap_{i=1}^n A_i$。

可数并和可数交定义为

$$\cup_{n=1}^\infty A_n = \{x : x \in A_n \text{ for some } n\} \tag{1.2.10}$$

$$\cap_{n=1}^\infty A_n = \{x : x \in A_n \text{ for all } n\}. \tag{1.2.11}$$

德摩根定律（DeMorgan's Laws）：对任意集合 A 和 B，

$$(A \cap B)^c = A^c \cup B^c \tag{1.2.6}$$

$$(A \cup B)^c = A^c \cap B^c. \tag{1.2.7}$$

分配律：

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C) \tag{1.2.5}$$

Example 1.4 (例 1.2.3). *设 $\mathcal{C} = \{1, 2, 3, \ldots\}$，$A_n = \{1, 3, \ldots, 2n-1\}$，$B_n = \{n, n+1, \ldots\}$，则*

$$\cup_{n=1}^\infty A_n = \{1, 3, 5, \ldots\}; \quad \cap_{n=1}^\infty A_n = \{1\}$$

$$\cup_{n=1}^\infty B_n = \mathcal{C}; \quad \cap_{n=1}^\infty B_n = \phi. \tag{1.2.13}$$

单调序列：若 $\{A_n\}$ 非递减（$A_n \subset A_{n+1}$），则 $\lim_{n\to\infty} A_n = \cup_{n=1}^\infty A_n$。若 $\{A_n\}$ 非递增（$A_n \supset A_{n+1}$），则 $\lim_{n\to\infty} A_n = \cap_{n=1}^\infty A_n$。

2.2. 1.2.2 Set Functions. 集合函数（set function）是将集合映射到实数的函数。

Example 1.5 (例 1.2.5). 设 $\mathcal{C}=\mathbb{R}$，$Q(A)$ 为 A 中正整数的个数。若 $A=\{x:0<x<5\}$，则 $Q(A)=4$；若 $A=\{-2,-1\}$，则 $Q(A)=0$。

Example 1.6 (例 1.2.6). 设 $\mathcal{C}=\mathbb{R}^2$，$Q(A)$ 为 A 的面积（若面积存在）。若 $A=\{(x,y):x^2+y^2\leq 1\}$（单位圆盘），则 $Q(A)=\pi$。

集合函数常用求和或积分定义。记号:

$$\sum_A f(x) \quad \text{表示在所有} x\in A \text{ 上求和}$$

$$\int_A f(x)\,dx \quad \text{表示在集合} A \text{ 上的积分}$$

Example 1.7 (例 1.2.7). 设 $\mathcal{C}$ 为所有非负整数构成的集合，$Q(A)=\sum_{n\in A}\left(\frac{2}{3}\right)^n$。由几何级数公式 $\sum_{n=0}^{\infty}a^n=\frac{1}{1-a}$（$|a|<1$），可得 $Q(\mathcal{C})=3$。

Example 1.8 (例 1.2.8). 设 $\mathcal{C}=(0,\infty)$，$Q(A)=\int_A e^{-x}\,dx$。则

$$Q[(1,3)]=\int_1^3 e^{-x}\,dx=e^{-1}-e^{-3}\approx 0.318$$

$$Q(\mathcal{C})=\int_0^\infty e^{-x}\,dx=1.$$

3. 1.3 The Probability Set Function

设 $\mathcal{C}$ 为样本空间，$\mathcal{B}$ 为事件域（σ-域），现在定义概率集函数。

Remark 1.3.1: 概率的定义由三条公理组成，这三条公理来源于相对频率的三条直观性质。设重复实验 N 次，事件 A 的相对频率为 $f_A=\#\{A\}/N$。则 $f_A\geq 0$、$f_{\mathcal{C}}=1$，且若 A_1,A_2 不交则 $f_{A_1\cup A_2}=f_{A_1}+f_{A_2}$。

Definition 1.6 (定义 1.3.1 (概率)). 设 $\mathcal{C}$ 为样本空间，$\mathcal{B}$ 为事件域。函数 $\mathbb{P}:\mathcal{B}\to\mathbb{R}$ 满足以下三条条件则称为概率集函数:

(1) $\mathbb{P}(A)\geq 0$，对所有 $A\in\mathcal{B}$

(2) $\mathbb{P}(\mathcal{C})=1$

(3) 若 $\{A_n\}$ 为两两不相交的事件序列，则

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty}A_n\right)=\sum_{n=1}^{\infty}\mathbb{P}(A_n).$$

若事件序列两两不相交，称其为互不相容的（mutually exclusive）。若序列还是穷尽的（exhaustive），即其并为 $\mathcal{C}$，则构成 $\mathcal{C}$ 的一个划分（partition）。

概率集函数告诉我们在事件域上概率如何分布。

Theorem 1.1 (定理 1.3.1). 对每个事件 $A\in\mathcal{B}$，$\mathbb{P}(A)=1-\mathbb{P}(A^c)$。

证明. 由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$，结合公理 (2) 和 (3) 得

$$1 = \mathbb{P}(A) + \mathbb{P}(A^c).$$

□

THEOREM 1.2 (定理 1.3.2). $\mathbb{P}(\phi) = 0$。

THEOREM 1.3 (定理 1.3.3). *若 $A \subset B$，则 $\mathbb{P}(A) \leq \mathbb{P}(B)$。*

证明. $B = A \cup (A^c \cap B)$，且两项不相交。由公理 (3) 得 $\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(A^c \cap B) \geq \mathbb{P}(A)$。 □

COROLLARY 1.1 (推论 1.3.1). *对每个 $A \in \mathcal{B}$，$0 \leq \mathbb{P}(A) \leq 1$。*

THEOREM 1.4 (定理 1.3.5). *对任意事件 A, B，*

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

证明. 将 $A \cup B$ 和 B 分解为不相交集合的并：

$$A \cup B = A \cup (A^c \cap B), \quad B = (A \cap B) \cup (A^c \cap B).$$

由公理 (3) 得 $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(A^c \cap B)$ 和 $\mathbb{P}(B) = \mathbb{P}(A \cap B) + \mathbb{P}(A^c \cap B)$。消去 $\mathbb{P}(A^c \cap B)$ 即得结果。 □

等可能性情形（Equilikely Case）：若样本空间 $\mathcal{C} = \{x_1, x_2, \ldots, x_m\}$ 有限，且每个 outcome 等概率 $p_i = 1/m$，则

$$\mathbb{P}(A) = \sum_{x_i \in A} \frac{1}{m} = \frac{\#(A)}{m}.$$

4. 1.4 Conditional Probability and Independence

4.1. Conditional Probability.

DEFINITION 1.7 (定义 1.4.1 (条件概率)). *设 $\mathbb{P}(B) > 0$，在事件 B 已发生的条件下，事件 A 的条件概率（conditional probability）定义为*

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

条件概率也满足概率公理。

由条件概率定义可直接导出乘法法则（multiplication rule）：

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B \mid A) = \mathbb{P}(B) \cdot \mathbb{P}(A \mid B).$$

推广到 n 个事件：

$$\mathbb{P}\left(\bigcap_{i=1}^{n} A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 \mid A_1) \cdots \mathbb{P}\left(A_n \mid \bigcap_{i=1}^{n-1} A_i\right).$$

全概率公式（Law of Total Probability）：设 $\{B_i\}$ 为 $\mathcal{C}$ 的一个划分，则对任意事件 A，

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A \mid B_i).$$

THEOREM 1.5 (定理 1.4.1 (贝叶斯公式)). 设 $\{B_i\}$ 为 $\mathcal{C}$ 的一个划分，$\mathbb{P}(B_i) > 0$。则对任意事件 A（$\mathbb{P}(A) > 0$），

$$\mathbb{P}(B_j \mid A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A \mid B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A \mid B_i)}.$$

术语：$\mathbb{P}(B_j)$ 为先验概率（prior probability），$\mathbb{P}(B_j \mid A)$ 为后验概率（posterior probability），$\mathbb{P}(A \mid B_j)$ 为似然（likelihood）。

EXAMPLE 1.9 (例 1.4.1 (医学检测)). 设某疾病患病率为 1%，检测准确率为 99%。令 $D = \{\text{患病}\}$，$+ = \{\text{检测阳性}\}$。则

$$\mathbb{P}(D \mid +) = \frac{\mathbb{P}(D) \cdot \mathbb{P}(+ \mid D)}{\mathbb{P}(D) \cdot \mathbb{P}(+ \mid D) + \mathbb{P}(D^c) \cdot \mathbb{P}(+ \mid D^c)} = \frac{0.01 \cdot 0.99}{0.01 \cdot 0.99 + 0.99 \cdot 0.01} = \frac{1}{2}.$$

即使检测准确率高达 99%，检测阳性者真正患病的概率只有 50%!

REMARK (贝叶斯视角的启示). 贝叶斯公式不仅仅是一个计算工具，更提供了一种**思考不确定性的思维方式**。

***1.* 先验与后验的博弈**

先验概率（*prior*）$\mathbb{P}(B_j)$ 反映了我们在获得新证据之前的信念；后验概率（*posterior*）$\mathbb{P}(B_j \mid A)$ 则是融合了新证据之后的更新信念。贝叶斯公式告诉我们：如何根据证据更新信念。

***2.* 似然的核心作用**

似然（*likelihood*）$\mathbb{P}(A \mid B_j)$ 衡量的是，在假设 B_j 成立的条件下，观测到证据 A 的"理所当然"程度。注意这是一个方向性问题——它不是问"B_j 能否解释 A"，而是问"如果 B_j 为真，A 有多常见"。这正是贝叶斯推理与逻辑推理的关键区别。

***3.* 从特殊到一般的延伸**

在医学检测例子中，我们关注的是 $\mathbb{P}(\text{患病} \mid \text{阳性})$——这是最直接有用的信息。但在更一般的统计推断中，我们往往需要从数据（A）反推参数（B_j）的分布。这正是贝叶斯统计的核心任务。

***4.* 与频率学派的对话**

频率学派将概率解释为长期频率，认为参数是固定常数，只能通过反复抽样来估计；贝叶斯学派则将参数也视为随机变量，用概率分布描述我们对参数的信念，并将数据视为更新这种信念的证据。两种视角并非互斥——贝叶斯公式本身是中性的，它只是提供了融合先验信息与观测数据的数学框架。

4.2. 1.4.1 Independence.

DEFINITION 1.8 (定义 1.4.2 (独立性)). 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$，则称事件 A 与 B 相互独立（*independent*），记作 $A \perp\!\!\!\perp B$。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时，独立性等价于 $\mathbb{P}(A \mid B) = \mathbb{P}(A)$ 或 $\mathbb{P}(B \mid A) = \mathbb{P}(B)$。

Proposition 1.1 (命题 1.4.1). *若 $A \perp\!\!\!\perp B$，则：*

(1) $A \perp\!\!\!\perp B^c$

(2) $A^c \perp\!\!\!\perp B$

(3) $A^c \perp\!\!\!\perp B^c$

Definition 1.9 (定义 1.4.3 (相互独立)). *事件序列 $\{A_i : i \in I\}$ 相互独立，若对任意有限子集 $\{i_1, \ldots, i_k\}$，*

$$\mathbb{P}\left(\bigcap_{j=1}^{k} A_{i_j}\right) = \prod_{j=1}^{k} \mathbb{P}(A_{i_j}).$$

Warning: 两两独立（pairwise independent）不一定意味着相互独立!

5. 1.5 Random Variables

随机变量（random variable）是从样本空间 $\mathcal{C}$ 到实数的函数：$X : \mathcal{C} \to \mathbb{R}$。

通常用大写字母 X, Y, Z 表示随机变量，用小写字母 x, y, z 表示具体取值。

随机变量可分为：

- **离散随机变量（discrete）**：取值可数
- **连续随机变量（continuous）**：取值充满区间，不可数

Example 1.10 (例 1.5.1). *抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$。定义 X 为正面出现的次数：$X(HH) = 2$，$X(HT) = X(TH) = 1$，$X(TT) = 0$。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。*

6. 1.6 Discrete Random Variables

Definition 1.10 (定义 1.6.1 (概率质量函数)). *设 X 为离散随机变量。函数 $p_X(x) = \mathbb{P}(X = x)$ 称为概率质量函数（probability mass function, pmf）。*

pmf 满足：$p_X(x) \geq 0$ 对所有 x，且 $\sum_x p_X(x) = 1$。

伯努利分布（Bernoulli）：$X \sim \text{Bernoulli}(p)$，取值 $\{0, 1\}$，

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

二项分布（Binomial）：$X \sim \text{Bin}(n, p)$，

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \ldots, n.$$

这是 n 次独立伯努利试验中成功的次数。

泊松分布（Poisson）：$X \sim \text{Poisson}(\lambda)$，

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \ldots.$$

泊松分布是二项分布当 $n \to \infty$、$p \to 0$、$np = \lambda$ 固定时的极限分布。

6.1. 1.6.1 Transformations. 设 X 为离散随机变量，$Y = g(X)$。则 $p_Y(y) = \sum_{x:g(x)=y} p_X(x)$。

7. 1.7 Continuous Random Variables

Definition 1.11 (定义 1.7.1 (概率密度函数)). *设 X 为连续随机变量。若存在非负函数 $f_X(x)$ 使得*

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x)\,dx$$

对任意 $a < b$ 成立，则称 $f_X(x)$ 为概率密度函数（probability density function, pdf）。

pdf 满足：$f_X(x) \geq 0$ 对所有 x，且 $\int_{-\infty}^{\infty} f_X(x)\,dx = 1$。
Warning: $f_X(x)$ 可以大于 1!
正态分布（Normal/Gaussian）：$X \sim N(\mu, \sigma^2)$，

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad -\infty < x < \infty.$$

标准正态分布：$Z \sim N(0,1)$，$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$。
指数分布（Exponential）：$X \sim \mathrm{Exp}(\lambda)$，$f(x) = \lambda e^{-\lambda x}$，$x > 0$。

7.1. 1.7.1 Quantiles.

Definition 1.12 (定义 1.7.2 (分位数)). *设 X 的 CDF 为 $F_X(x)$。对 $0 < p < 1$，p-分位数 x_p 满足 $F_X(x_p) = p$。中位数是 $p = 0.5$ 的分位数。*

7.2. 1.7.2 Transformations. 设 X 为连续随机变量，$Y = g(X)$。若 $y = g(x)$ 严格单调且可导，则

$$f_Y(y) = f_X(h(y)) \cdot |h'(y)|,$$

其中 $x = h(y)$ 是 $y = g(x)$ 的反函数。

若 $Y = aX + b$，则 $f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right)$。

8. 1.8 Expectation of a Random Variable

Definition 1.13 (定义 1.8.1 (数学期望)). *随机变量 X 的期望（expected value）：*

- *离散型：$\mathbb{E}X = \sum_x x \cdot p_X(x)$*
- *连续型：$\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x)\,dx$*

要求级数或积分绝对收敛。

Theorem 1.6 (定理 1.8.1 (期望的线性性)). *对任意随机变量 X, Y 和常数 a, b:*

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y.$$

关键点：*无需 X, Y 相互独立!*

THEOREM 1.7 (定理 1.8.2 (方差公式)).

$$var(X) = \mathbb{E}[(X-\mu)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2,$$

其中 $\mu = \mathbb{E}X$。

THEOREM 1.8 (定理 1.8.3 (方差的性质)). *(1)* $var(aX+b) = a^2 var(X)$
(2) 若 $X_1, \ldots, X_n$ 相互独立，则 $var(\sum_{i=1}^n X_i) = \sum_{i=1}^n var(X_i)$

9. 1.9 Some Special Expectations

DEFINITION 1.14 (定义 1.9.1 (协方差)).

$$cov(X,Y) = \mathbb{E}[(X-\mathbb{E}X)(Y-\mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y.$$

协方差的性质：

(1) $\mathrm{cov}(X,X) = \mathrm{var}(X)$
(2) $\mathrm{cov}(X,Y) = \mathrm{cov}(Y,X)$
(3) $\mathrm{cov}(aX+b,Y) = a\mathrm{cov}(X,Y)$
(4) $\mathrm{var}(X+Y) = \mathrm{var}(X) + \mathrm{var}(Y) + 2\mathrm{cov}(X,Y)$
(5) 若 $X \perp\!\!\!\perp Y$，则 $\mathrm{cov}(X,Y) = 0$

DEFINITION 1.15 (定义 1.9.2 (相关系数)).

$$corr(X,Y) = \frac{cov(X,Y)}{\sqrt{var(X) \cdot var(Y)}}.$$

$-1 \le \mathrm{corr}(X,Y) \le 1$。

10. 1.10 Important Inequalities

THEOREM 1.9 (Markov 不等式). 若 X 为随机变量，$g(X) \ge 0$，则对任意 $a > 0$，

$$\mathbb{P}(g(X) \ge a) \le \frac{\mathbb{E}[g(X)]}{a}.$$

特别地，取 $g(X) = X^2$，$a = k^2$，得

$$\mathbb{P}(|X| \ge k) \le \frac{\mathbb{E}[X^2]}{k^2}.$$

THEOREM 1.10 (Chebyshev 不等式). 设 $\mu = \mathbb{E}X$，$\sigma^2 = var(X)$。则对任意 $k > 0$，

$$\mathbb{P}(|X-\mu| \ge k) \le \frac{\sigma^2}{k^2}.$$

THEOREM 1.11 (Cauchy-Schwarz 不等式).

$$|\mathbb{E}(XY)| \le \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}.$$

Summary

本章建立了概率论的基本框架：

(1) **概率公理化**：从相对频率的直观性质出发，建立了概率的公理化定义
(2) **条件概率与贝叶斯公式**：提供了更新信息的数学工具
(3) **独立性**：刻画了两个事件之间的概率关系
(4) **随机变量**：从集合论过渡到数值函数，为分布理论奠定基础
(5) **期望与方差**：分别度量分布的中心位置和离散程度
(6) **协方差与相关系数**：度量两个随机变量的联合变化趋势
(7) **重要不等式**：Markov、Chebyshev、Cauchy-Schwarz

Exercises

Exercise 1.1. *1.2.1* 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$：

(1) $C_1 = \{0, 1, 2\}$，$C_2 = \{2, 3, 4\}$
(2) $C_1 = \{x : 0 < x < 2\}$，$C_2 = \{x : 1 \leq x < 3\}$

Exercise 1.2. *1.3.1* 设 $\mathbb{P}(A) = 0.3$，$\mathbb{P}(B) = 0.4$，$\mathbb{P}(A \cap B) = 0.1$。求：

(1) $\mathbb{P}(A \cup B)$
(2) $\mathbb{P}(A \mid B)$
(3) $\mathbb{P}(B \mid A)$

Exercise 1.3. *1.4.1* 某箱中有 *5* 个红球和 *3* 个白球。无放回地抽取 *3* 个球。求恰好抽到 *2* 个红球的概率。

Exercise 1.4. *1.5.1* 设 $X \sim N(100, 225)$。求：

(1) $\mathbb{P}(X < 95)$
(2) $\mathbb{P}(90 < X < 110)$

CHAPTER 2

二元随机变量分布

Chapter 2 概述

在实际问题中，我们往往不只关心单个随机变量，而是关心它们之间的**相互作用**。例如，在金融中我们想研究两种资产收益的联合波动；在医学中想了解剂量与疗效的关系；在物理中想描述两个测量值的相关性。本章将一元推广到二元，建立联合分布理论。

本章路线图：联合分布 → 边缘分布 → 条件分布 → 独立性 → 相关性 → 二元正态

1. 2.1 从一元到二元

1.1. 为什么需要联合分布?. 在一元情形，我们用 cdf $F_X(x) = \mathbb{P}(X \le x)$ 描述单个随机变量的行为。但在许多场景中，*单个变量的分布并不能回答我们的问题*——我们需要知道多个变量如何共同变化。这引导我们提出以下问题：

核心问题：给定两个随机变量 X_1 和 X_2，如何描述它们的联合行为?

这促使我们定义随机向量和联合分布。

1.2. 随机向量.

Definition 2.1 (随机向量). *设样本空间为 $\mathcal{C}$，X_1 和 X_2 为定义在 $\mathcal{C}$ 上的两个随机变量。则 (X_1, X_2) 称为随机向量，其取值空间为 $\mathcal{D} = \{(x_1, x_2) : x_1 = X_1(c), x_2 = X_2(c), c \in \mathcal{C}\}$。*

为什么要用向量? 因为 (X_1, X_2) 的取值是一个有序对，用向量符号 $\mathbf{X} = (X_1, X_2)'$ 能更清晰地表示这种结构。

1.3. 联合分布. 联合 cdf 是一元 cdf 的自然推广：

$$F_{X_1,X_2}(x_1, x_2) = \mathbb{P}(X_1 \le x_1, X_2 \le x_2). \tag{1}$$

离散型：用 pmf 描述，

$$p_{X_1,X_2}(x_1, x_2) = \mathbb{P}(X_1 = x_1, X_2 = x_2), \tag{2}$$

满足 $p \ge 0$ 且 $\sum\sum_{\mathcal{D}} p = 1$。

连续型：用 pdf 描述，

$$F_{X_1,X_2}(x_1, x_2) = \int_{-\infty}^{x_1}\int_{-\infty}^{x_2} f(w_1, w_2)\, dw_1\, dw_2, \tag{3}$$

其中 $f \ge 0$ 且 $\int\int_{\mathcal{D}} f = 1$。

Warning：与一元情形不同，这里的 $f(x_1, x_2)$ 可以大于 1！因为它是”密度”而非概率值。

Remark (几何直观). *若把联合 pdf $z = f(x_1, x_2)$ 视作一张曲面，则 $\mathbb{P}((X_1, X_2) \in A)$ 就是该曲面下区域 A 上的体积。这是一元情形"曲线下面积"在二维的推广。*emark

1.4. 从联合到边缘：积分即求和. 核心问题：已知 (X_1, X_2) 的联合分布，如何得到单个 X_1 的分布?

直觉上，我们需要"忽略" X_2 的信息。具体做法是：

- **离散型**：对 x_2 求和
- **连续型**：对 x_2 积分

这引导我们得到：

边缘 pmf：

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1,X_2}(x_1, x_2). \tag{4}$$

边缘 pdf：

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1,X_2}(x_1, x_2)\, dx_2. \tag{5}$$

在二维离散情形，将联合 pmf 列表，边缘分布恰好是每行（或每列）的"边缘"之和。这解释了名称的由来。

1.5. 期望的推广. 同样的思想：$Y = g(X_1, X_2)$ 是新的随机变量，其期望为

$$\mathbb{E}Y = \int\int g(x_1, x_2) f(x_1, x_2)\, dx_1\, dx_2 \quad \text{（连续型）}.$$

关键发现：期望算子 E 对加法保持线性，无论 X_1, X_2 是否独立：

$$\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2. \tag{6}$$

这为什么重要? 在第 1 章我们学过独立随机变量之和的方差公式 $\mathrm{var}(X_1 + X_2) = \mathrm{var}(X_1) + \mathrm{var}(X_2)$。期望的线性性是其基础——它无需独立性即可成立。

2. 2.2 变换：寻找新视角

给定 (X_1, X_2) 的分布，我们经常想研究其函数 $Y = u(X_1, X_2)$ 的分布。例如：

- 和 $Y = X_1 + X_2$（两个随机变量之和）
- 商 $Y = X_1/X_2$（比值）
- 极坐标变换 $(R, \Theta) = (\sqrt{X_1^2 + X_2^2}, \arctan(X_2/X_1))$

对于连续型，一一对应的变换有简洁的公式：

$$f_{Y_1,Y_2}(y_1, y_2) = f_{X_1,X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|. \tag{7}$$

其中 Jacobian 行列式

$$J = \det \begin{pmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{pmatrix} = \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1}. \tag{8}$$

为什么有 $|J|$?这是面积元素的变换因子。在一元情形我们有 $f_Y(y) = f_X(h(y))|h'(y)|$；二维情形类似，只是用行列式度量了面积缩放比例。

3. 2.3 条件分布：信息的价值

核心问题：已知 X_1 的值，X_2 的分布会如何变化?

这就是条件分布要回答的问题。条件分布本质上是在 $X_1 = x_1$ 的条件下，重新审视 X_2 的行为。

离散型条件 pmf：

$$p_{X_2|X_1}(x_2 \mid x_1) = \frac{p_{X_1,X_2}(x_1, x_2)}{p_{X_1}(x_1)}, \quad p_{X_1}(x_1) > 0. \tag{9}$$

连续型条件 pdf：

$$f_{X_2|X_1}(x_2 \mid x_1) = \frac{f_{X_1,X_2}(x_1, x_2)}{f_{X_1}(x_1)}, \quad f_{X_1}(x_1) > 0. \tag{10}$$

注意：分子是联合密度，分母是边缘密度。这个比值衡量的是，在 $X_1 = x_1$ 的条件下，(x_1, x_2) 这个”点”有多”典型”。

由此可以定义条件期望：

$$\mathbb{E}[u(X_2) \mid x_1] = \int_{-\infty}^{\infty} u(x_2) f_{X_2|X_1}(x_2 \mid x_1)\, dx_2. \tag{11}$$

这里有一个深刻的定理，它连接了条件与边缘：

$$\mathbb{E}[\mathbb{E}(X_2 \mid X_1)] = \mathbb{E}(X_2). \tag{12}$$

这称为**全期望公式**。它的含义是：*对条件均值再取期望，等于无条件期望*。直观上，无论我们按哪个 x_1 分组计算均值，最终的平均仍然是总均值。

更惊人的是方差的不等式：

$$\mathrm{var}[\mathbb{E}(X_2 \mid X_1)] \le \mathrm{var}(X_2).$$

Rao-Blackwell 定理：若用 X_2 估计 $\mu_2 = \mathbb{E}X_2$，则条件均值 $E(X_2 \mid x_1)$ 比 X_2 本身更精确（方差更小）。这在统计推断中极其重要——它告诉我们如何利用辅助信息改进估计。

4. 2.4 独立性：变量间的”无关系”

核心问题：什么时候 X_1 和 X_2 互不影响?

若 X_1 与 X_2 独立，则知道 X_1 的值不会改变我们对 X_2 的认知。用条件分布的语言：

$$f_{X_2|X_1}(x_2 \mid x_1) = f_{X_2}(x_2) \quad （不依赖于x_1）.$$

由此推出联合密度可分离：

$$X_1 \text{ 与} X_2 \text{ 独立} \iff f(x_1, x_2) \equiv f_1(x_1) f_2(x_2). \tag{13}$$

一个实用的判据：

$$X_1 \text{ 与} X_2 \text{ 独立} \iff f(x_1, x_2) \equiv g(x_1)h(x_2) \quad \text{（可分离变量）}. \tag{14}$$

独立性的后果（这些在第 1 章学过，现在有了二元语境）：

- $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$
- $\mathrm{cov}(X_1, X_2) = 0$

逆命题不成立！ *$cov(X_1, X_2) = 0$ 并不意味着独立性（除二元正态分布外）。*

这提醒我们：**不相关**（uncorrelated）和**独立**（independent）是两个不同概念。不相关只说明没有线性关系，但变量间可能存在非线性依赖。

5. 2.5 相关性：线性关联的度量

我们已经知道 $\mathrm{cov}(X_1, X_2) = 0$ 不能完全刻画独立性。那么如何量化 X_1 与 X_2 之间的" 关联程度"?

协方差 $\mathrm{cov}(X_1, X_2)$ 存在一个问题：它依赖于 X_1, X_2 的量纲。例如，身高（cm）和体重（kg）的协方差与换算成英寸和磅时不同。

解决方案：先标准化，再求协方差：

$$\rho_{12} = \mathrm{corr}(X_1, X_2) = \frac{\mathrm{cov}(X_1, X_2)}{\sqrt{\mathrm{var}(X_1)}\sqrt{\mathrm{var}(X_2)}} = \frac{\mathrm{cov}(X_1, X_2)}{\sigma_1 \sigma_2}. \tag{15}$$

这就是相关系数（correlation coefficient）。

核心性质：

- $-1 \le \rho_{12} \le 1$
- $|\rho_{12}| = 1 \iff X_2 = aX_1 + b$（完美线性关系）
- $\rho_{12} = 0$ 称**不相关**

为什么是 $[-1, 1]$? 这来自 Cauchy-Schwarz 不等式：

$$|\mathrm{cov}(X_1, X_2)| = |\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]| \le \sqrt{\mathbb{E}[(X_1 - \mu_1)^2] \cdot \mathbb{E}[(X_2 - \mu_2)^2]} = \sigma_1 \sigma_2.$$

协方差取决于量纲（" 米的协方差"vs" 厘米的协方差" 数值不同）；相关系数是无量纲的，消除了单位影响。因此，相关系数是更通用的" 关联程度" 度量。

6. 2.6 二元正态：最重要的二元分布

在所有二元分布中，二元正态分布占据核心地位。它是一元正态分布在二维的自然推广。

为什么重要?

(1) 边缘分布和条件分布都是正态的

(2) 线性组合仍是正态

(3) 不相关 $\iff$ 独立（这是正态独有的优雅性质）

(4) 多元正态是计量经济学、信号处理等领域的基石

Definition 2.2 (二元正态分布). (X_1, X_2) 服从二元正态分布，若其联合 *pdf* 为

$$f(x_1,x_2)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}\exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2}+\frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\},$$

记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$。

五个参数的含义:

- μ_1, μ_2：边缘分布的均值
- σ_1^2, σ_2^2：边缘分布的方差
- ρ：相关系数

在二元正态中，条件均值

$$\mathbb{E}(X_2 \mid x_1)=\mu_2+\rho\frac{\sigma_2}{\sigma_1}(x_1-\mu_1)$$

是 x_1 的线性函数。这意味着：给定 $X_1 = x_1$，X_2 的最佳预测也是线性的，其斜率由相关系数 ρ 决定。

关键性质:

(1) 边缘分布：$X_1 \sim N(\mu_1, \sigma_1^2)$，$X_2 \sim N(\mu_2, \sigma_2^2)$

(2) 条件分布：

$$X_2 \mid X_1=x_1 \sim N\left(\mu_2+\rho\frac{\sigma_2}{\sigma_1}(x_1-\mu_1),\ \sigma_2^2(1-\rho^2)\right)$$

(3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$（正态独有的" 不相关 $\Rightarrow$ 独立"）

(4) 任意线性组合 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, \mathrm{var}(aX_1 + bX_2))$

概念	公式/描述
联合 cdf	$F_{X_1,X_2}(x_1,x_2)=\mathbb{P}(X_1\le x_1, X_2\le x_2)$
边缘 pmf	$p_{X_1}(x_1)=\sum_{x_2}p_{X_1,X_2}(x_1,x_2)$
边缘 pdf	$f_{X_1}(x_1)=\int_{-\infty}^{\infty}f(x_1,x_2)\,dx_2$
条件 pmf	$p_{X_2\mid X_1}(x_2\mid x_1)=p(x_1,x_2)/p_{X_1}(x_1)$
条件 pdf	$f_{X_2\mid X_1}(x_2\mid x_1)=f(x_1,x_2)/f_{X_1}(x_1)$
全期望	$\mathbb{E}[\mathbb{E}(X_2\mid X_1)]=\mathbb{E}X_2$
独立性	$f(x_1,x_2)=f_1(x_1)f_2(x_2)$
协方差	$\mathrm{cov}=\mathbb{E}(X_1X_2)-\mathbb{E}X_1\mathbb{E}X_2$
相关系数	$\rho=\mathrm{cov}/(\sigma_1\sigma_2)$，$-1\le\rho\le 1$

CHAPTER 3

一些特殊分布

Chapter 3 概述

在前两章中，我们建立了描述单一和多个随机变量的数学框架。现在是时候问：**哪些分布最值得关注?**

统计学之所以有用，是因为某些概率分布反复出现在自然界和实验数据中。掌握这些分布就像掌握一门语言的基本词汇——它们是进一步学习的基石。

本章路线图：二项分布 → 泊松分布 → 伽马/卡方/贝塔分布 → 正态分布 → 多元正态 → t 与 F 分布

1. 3.1 从伯努利到二项：计数的科学

1.1. 为什么需要二项分布?. 当我们重复进行某项独立实验时，最自然的问题是：**成功多少次?** 抛 10 次硬币正面出现几次？1000 个零件中有多少合格？这种”计数问题”在统计学中无处不在。

1.2. 伯努利试验. 伯努利试验（Bernoulli trial）是一种最简单的随机实验：结果只有两种互斥且互补的可能性——成功或失败。

用随机变量 X 表示：

$$X(\text{成功}) = 1, \quad X(\text{失败}) = 0.$$

其 pmf 为

$$p(x) = p^x(1-p)^{1-x}, \quad x = 0, 1. \tag{16}$$

期望和方差：

$$\mathbb{E}X = p, \quad \mathrm{var}(X) = p(1-p).$$

为什么伯努利分布如此基础? 因为它是最简单的非平凡随机变量——既不是确定性常量，也不是均匀分布。它捕捉了”是/否”决策的不确定性本质。

1.3. 二项分布. 现在问：**进行 n 次独立伯努利试验，成功次数的分布是什么?**

设 X_i 为第 i 次试验的伯努利变量，我们关心 $X = \sum_{i=1}^n X_i$。

x 次成功意味着在 n 个位置中选择 x 个放成功，其余放失败。组合数为 $\binom{n}{x}$，每种排列的概率为 $p^x(1-p)^{n-x}$。

$$p(x) = \binom{n}{x} p^x(1-p)^{n-x}, \quad x = 0, 1, \ldots, n. \tag{17}$$

记作 $X \sim \mathrm{Bin}(n, p)$。

Example 3.1 (骰子问题). *掷一枚均匀六面骰子 3 次，得到恰好 2 次 6 点的概率是多少?*

解：设 X 为 6 点出现次数，则 $X \sim Bin(n=3, p=1/6)$，

$$\mathbb{P}(X=2) = \binom{3}{2}\left(\frac{1}{6}\right)^2\left(\frac{5}{6}\right)^1 = 0.06944.$$

矩母函数:

$$M(t) = [(1-p) + pe^t]^n.$$

均值与方差:

$$\mathbb{E}X = np, \quad \mathrm{var}(X) = np(1-p).$$

Theorem 3.1 (二项分布的可加性). *若 $X_1 \sim Bin(n_1, p)$，$X_2 \sim Bin(n_2, p)$ 独立，则 $X_1 + X_2 \sim Bin(n_1 + n_2, p)$。*

这意味着：两次二项实验可以合并成一次更大的二项实验。

[直观理解] 想象两堆独立的硬币抛掷：第一堆 n_1 枚得到 X_1 个正面，第二堆 n_2 枚得到 X_2 个正面。合并后总共 $n_1 + n_2$ 枚，正面总数自然是 $X_1 + X_2$。emark

1.4. 负二项与几何分布. 核心问题：如果我们不数成功次数，而是数**获得第 r 次成功所需的试验次数**，分布会是什么?

设 Y 为第 r 次成功前的失败次数。则试验总数为 $Y + r$。

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \ldots \tag{18}$$

这称为**负二项分布**。

当 $r = 1$ 时，得到**几何分布**:

$$p_Y(y) = p(1-p)^y, \quad y = 0, 1, 2, \ldots \tag{19}$$

几何分布具有独特的**无记忆性**:

$$\mathbb{P}(Y \geq k + j \mid Y \geq k) = \mathbb{P}(Y \geq j).$$

这意味着什么? 如果你已经失败了 k 次，等待第 1 次成功的剩余时间与一开始完全相同。过去的失败不改变未来的期望。

1.5. 多项分布. 二项分布推广到 k 类：每次试验结果属于 k 个互斥类别之一。

设 X_i 为第 i 类出现的次数，则 $(X_1, \ldots, X_k)$ 服从参数为 n 和 $p_1, \ldots, p_k$ 的**多项分布**:

$$P(X_1 = x_1, \ldots, X_k = x_k) = \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k}. \tag{20}$$

1.6. 超几何分布. 核心问题：如果不放回抽样，成功次数的分布是什么?

一批 N 件产品中有 D 件次品，抽取 n 件（不放回），X 为次品数：

$$p(x) = \frac{\binom{N-D}{n-x}\binom{D}{x}}{\binom{N}{n}}, \quad x = 0, 1, \ldots, n. \tag{21}$$

均值与方差：

$$\mathbb{E}X = n\frac{D}{N}, \quad \mathrm{var}(X) = n\frac{D}{N}\frac{N-D}{N}\frac{N-n}{N-1}.$$

最后一个因子 $\frac{N-n}{N-1}$ 是**不放回修正系数**。当 $N \gg n$ 时，它接近 1，此时超几何分布近似二项分布。

2. 3.2 泊松分布：稀有事件的世界

2.1. 为什么泊松分布重要?. 在自然界和社会中,有一类特殊的现象:**在固定时间/空间内，事件发生的次数**——如每小时到达银行的顾客数、每页书的印刷错误数、每年地震次数。

这些现象有一个共同特征：**发生概率很小，但试验次数很多**。二项分布的极限形式正是泊松分布。

2.2. 泊松分布的定义.

$$p(x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \ldots \tag{22}$$

其中 $\lambda > 0$ 是参数。记作 $X \sim \mathrm{Poisson}(\lambda)$。

验证：因为 $e^\lambda = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$，

$$\sum_{x=0}^{\infty} p(x) = e^{-\lambda}\sum_{x=0}^{\infty}\frac{\lambda^x}{x!} = e^{-\lambda}\cdot e^{\lambda} = 1.$$

均值与方差：

$$\mathbb{E}X = \lambda, \quad \mathrm{var}(X) = \lambda.$$

这有一个令人惊讶的性质：均值和方差相等！这是泊松分布的标志特征。

$\widehat{\mathrm{h}}$eorem[泊松近似] 若 $X_n \sim \mathrm{Bin}(n, p_n)$ 且 $np_n \to \lambda$，则 $X_n \xrightarrow{d} \mathrm{Poisson}(\lambda)$。

直观理解：当 n 很大、p 很小时，二项分布的行为与泊松分布几乎没有区别。实践中常用泊松近似简化计算。

[泊松分布的起源] 泊松分布由西莫恩 · 德 · 泊松（Simeon Denis Poisson）在 1837 年提出，最初用于分析法国法院的判决数据——法官在给定时间内做出一定数量判决的概率。emark

3. 3.3 伽马、卡方与贝塔分布

这三个分布是连续统计推断的支柱。理解它们的关系，就理解了半参数推断的数学基础。

3.1. 伽马函数. 为什么从伽马函数开始? 因为它是连接阶乘与积分的桥梁——这本身就是数学中最美的恒等式之一。

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x}\, dx, \quad \alpha > 0.$$

关键性质: $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$，对正整数 n，$\Gamma(n) = (n-1)!$。

3.2. 伽马分布.

Definition 3.1 (伽马分布). *若随机变量 X 的 pdf 为*

$$f(x) = \begin{cases} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} & x > 0 \\ 0 & elsewhere, \end{cases}$$

则称 X 服从伽马分布，记作 $X \sim \Gamma(\alpha, \beta)$。

参数的意义:

- α: 形状参数（shape），控制分布的形态
- β: 尺度参数（scale），控制分布的宽窄

均值与方差:

$$\mathbb{E}X = \alpha\beta, \quad \mathrm{var}(X) = \alpha\beta^2.$$

两个重要特例:

- $\Gamma(1, \beta) = \mathrm{Exp}(1/\beta)$（指数分布）
- $\Gamma(n/2, 2) =$ 卡方分布

[可加性] 若 $X_1 \sim \Gamma(\alpha_1, \beta)$，$X_2 \sim \Gamma(\alpha_2, \beta)$ 独立，则 $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$。emark

3.3. 卡方分布. 核心问题: 如果我们将多个标准正态随机变量平方后求和，这个新变量的分布是什么?

Definition 3.2 (卡方分布). *设 $Z_1, Z_2, \ldots, Z_n \sim N(0,1)$ iid，则*

$$X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n).$$

卡方分布是 $\Gamma(n/2, 2)$ 的特例。

均值与方差:

$$\mathbb{E}X = n, \quad \mathrm{var}(X) = 2n.$$

可加性: 若 $X_1 \sim \chi^2(m)$，$X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$。

为什么重要? 样本方差的抽样分布与卡方分布紧密相连——这使得它成为方差估计和假设检验的核心工具。

3.4. 贝塔分布. 与伽马分布类似，贝塔分布也是定义在 $(0,1)$ 区间上的连续分布，在建模概率时特别有用。

Definition 3.3 (贝塔分布). *若 X 的 pdf 为*

$$f(x) = \begin{cases} \frac{1}{B(\alpha,\beta)} x^{\alpha-1}(1-x)^{\beta-1} & 0 < x < 1 \\ 0 & elsewhere, \end{cases}$$

其中 $B(\alpha,\beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$，则称 $X \sim Beta(\alpha,\beta)$。

均值与方差：

$$\mathbb{E}X = \frac{\alpha}{\alpha+\beta}, \quad \mathrm{var}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}.$$

特别地：$\mathrm{Beta}(1,1) = \mathrm{Uniform}(0,1)$。

贝叶斯视角：在贝叶斯统计中，当我们用贝塔分布作为二项分布参数 p 的先验时，后验分布仍然是贝塔分布——这称为**共轭先验**。

4. 3.4 正态分布：统计学的女王

在所有概率分布中，**正态分布**占据至高无上的地位。它是统计推断、计量经济学、信号处理等领域的基石。

为什么正态分布如此特殊？原因有三：

(1) **中心极限定理**：大量独立小因素的总和近似正态分布
(2) **数学上的优雅性**：正态分布的线性组合仍是正态分布
(3) **可解释的参数**：均值和方差都有直观含义

Definition 3.4 (正态分布). *若 X 的 pdf 为*

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad -\infty < x < \infty,$$

则称 X 服从正态分布，记作 $X \sim N(\mu,\sigma^2)$。

特别地，$N(0,1)$ 称为**标准正态分布**，其 pdf 记作 $\phi(z)$，cdf 记作 $\Phi(z)$。

标准化：若 $X \sim N(\mu,\sigma^2)$，则 $Z = \frac{X-\mu}{\sigma} \sim N(0,1)$。

这使得任何正态概率计算都能转化为标准正态计算：

$$\mathbb{P}(X \le x) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

Example 3.2 (正态概率计算). *设 $X \sim N(100,225)$（即 $\sigma = 15$），求 $\mathbb{P}(X < 85)$。*
解：$Z = \frac{85-100}{15} = -1$，所以 $\mathbb{P}(X < 85) = \Phi(-1) \approx 0.1587$。

h͡eorem[正态分布的线性组合] 若 $X_1 \sim N(\mu_1,\sigma_1^2)$，$X_2 \sim N(\mu_2,\sigma_2^2)$ 独立，则对任意常数 a, b，

$$aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2).$$

为什么这个性质重要? 它意味着正态分布在线性变换下封闭——这使得正态分布成为线性模型的理论基础。

[高斯的贡献] 正态分布由卡尔 · 弗里德里希 · 高斯（Carl Friedrich Gauss）在 1809 年研究测量误差时提出。尽管拉普拉斯更早讨论过误差分布，但高斯的工作使正态分布在统计学中占据了核心地位。这也解释了为什么正态分布常被称为" 高斯分布"。emark

5. 3.5 多元正态分布

正态分布向高维的自然推广。

5.1. 二元正态分布.

Definition 3.5 (二元正态分布). *若 (X_1, X_2) 的联合 pdf 为*

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{Q(x_1, x_2)}{2(1-\rho^2)}\right\},$$

其中 $Q = \frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}$，则称 (X_1, X_2) 服从二元正态分布，记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$。

五个参数的含义:

- μ_1, μ_2：边缘分布的均值
- σ_1^2, σ_2^2：边缘分布的方差
- ρ：相关系数

h̄eorem[二元正态的性质] 若 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$，则:

(1) 边缘分布：$X_1 \sim N(\mu_1, \sigma_1^2)$，$X_2 \sim N(\mu_2, \sigma_2^2)$

(2) 条件分布：$X_2 \mid X_1 = x_1 \sim N(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1),\ \sigma_2^2(1-\rho^2))$

(3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$（正态独有的" 不相关 $\Rightarrow$ 独立"）

(4) 任意线性组合 $aX_1 + bX_2$ 服从正态分布

关键洞察：条件均值是 x_1 的线性函数。这意味着给定一个变量，另一个变量的最佳预测也是线性的。

6. 3.6 t 分布与 F 分布

这两个分布起源于一个现实问题：**当总体方差未知时，如何进行推断?**

6.1. t 分布.

Definition 3.6 (t 分布). *设 $Z \sim N(0,1)$，$X \sim \chi^2(n)$ 独立，则*

$$T = \frac{Z}{\sqrt{X/n}} \sim t(n).$$

均值与方差:

$$\mathbb{E}T = 0\ (n > 1), \quad \mathrm{var}(T) = \frac{n}{n-2}\ (n > 2).$$

与正态的关系：当 $n \to \infty$ 时，$t(n) \xrightarrow{d} N(0,1)$。

直观理解：分子 Z 是标准正态，分母 $\sqrt{X/n}$ 估算了 Z 的标准差。当 n 小时，这个估算很不稳定，所以 t 分布比正态分布有更厚的尾部。$n=1$ 时得到柯西分布——这是一个均值不存在的”危险”分布。

Example 3.3 (t 分布应用). 设 $T \sim t(10)$，求 $\mathbb{P}(|T|>2.228)$。
查表得 $t_{0.025,10}=2.228$，所以 $\mathbb{P}(|T|>2.228)=0.05$。

6.2. F 分布.

Definition 3.7 (F 分布). 设 $X_1 \sim \chi^2(m)$，$X_2 \sim \chi^2(n)$ 独立，则

$$F=\frac{X_1/m}{X_2/n} \sim F(m,n).$$

均值与方差：

$$\mathbb{E}F=\frac{n}{n-2}\ (n>2), \quad \mathrm{var}(F)=\frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}\ (n>4).$$

倒数性质：若 $F \sim F(m,n)$，则 $1/F \sim F(n,m)$。

为什么重要? F 分布是方差分析（ANOVA）和回归分析的核心——我们用它比较两个方差是否相等。

分布	参数	记号
二项	试验次数 n，成功概率 p	$\mathrm{Bin}(n,p)$
泊松	速率 λ	$\mathrm{Poisson}(\lambda)$
伽马	形状 α，尺度 β	$\Gamma(\alpha,\beta)$
卡方	自由度 n	$\chi^2(n)$
贝塔	形状 α,β	$\mathrm{Beta}(\alpha,\beta)$
正态	均值 μ，方差 σ^2	$N(\mu,\sigma^2)$
t	自由度 n	$t(n)$
F	自由度 m,n	$F(m,n)$

本章小结

本章介绍了统计学中最重要的特殊分布家族：

离散型：伯努利 → 二项 → 负二项/几何 → 泊松 → 多项/超几何

连续型：均匀 → 指数 → 伽马 → 卡方 → 贝塔 → 正态 → t/F

关键关系：

- $\mathrm{Bin}(n,p) \xrightarrow{n\to\infty,p\to 0} \mathrm{Poisson}(\lambda)$
- $\Gamma(n/2,2)=\chi^2(n)$
- $t(n) \xrightarrow{n\to\infty} N(0,1)$
- $F(m,n)$ 中 $1/F \sim F(n,m)$

CHAPTER 4

一些基本的统计推断

Chapter 4 概述

在前三章中，我们建立了描述随机变量和概率分布的理论框架。现在我们面临一个根本性问题：**给定观测数据，如何推断产生这些数据的底层分布?**

这就是统计推断的核心问题。本章将介绍两种主要的推断工具：

- **置信区间**（Confidence Intervals）：未知参数的合理取值范围
- **假设检验**（Hypothesis Testing）：评估关于总体的声明是否成立

本章路线图：抽样与统计量 → 点估计 → 置信区间 → 假设检验 → 卡方检验 → 蒙特卡洛 → Bootstrap

1. 4.1 抽样与统计量

1.1. 为什么需要抽样?. 在现实中，我们通常无法观测整个总体。例如，测量所有成年人的身高是不可能的。因此，我们从总体中抽取一个随机样本，用样本信息推断总体特征。

核心假设：$X_1, X_2, \ldots, X_n$ 是 iid（独立同分布）随机变量，来自某个分布 $f(x;\theta)$，其中 θ 是未知参数。

1.2. 样本均值与样本方差. 给定样本，最自然的首选统计量是**样本均值**：

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i. \tag{23}$$

关键性质：

$$\mathbb{E}\bar{X} = \mu, \quad \mathrm{var}(\bar{X}) = \frac{\sigma^2}{n}.$$

这意味着：

- $\bar{X}$ 是 μ 的**无偏估计**（$E\bar{X} = \mu$）
- $\bar{X}$ 的方差随样本量 n 增大而减小（$1/n$ 衰减）

大样本性质：

- **弱大数定律**：$\bar{X} \xrightarrow{P} \mu$（当 $n \to \infty$）
- **中心极限定理**：$\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0,1)$

ěmark 为什么中心极限定理重要?] 即使总体分布未知，只要样本量足够大，$\bar{X}$ 的分布也近似正态。这使得我们可以构造置信区间、进行假设检验——而不需要知道总体的具体分布。emark

样本方差:

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2. \tag{24}$$

注意: 分母是 $n-1$ 而非 n! 这是为了保证 S^2 是 σ^2 的无偏估计（$E(S^2) = \sigma^2$）。

2. 4.2 点估计

核心问题: 给定数据，如何估计未知参数 θ?
点估计提供一个单一数值作为参数的估计值。

2.1. 估计量的评判标准.

Definition 4.1 (偏差). *估计量 $\hat{\theta}$ 的偏差定义为 $Bias(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$。若 $\mathbb{E}(\hat{\theta}) = \theta$，则 $\hat{\theta}$ 是无偏的。*

Definition 4.2 (均方误差). *估计量 $\hat{\theta}$ 的均方误差为 $MSE(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2]$。对无偏估计，$MSE = var(\hat{\theta})$。*

偏差-方差权衡: 一个有偏估计量可能比无偏估计量有更小的 MSE。

Example 4.1 (样本均值的性质). *设 $X_1, \ldots, X_n$ 来自均值为 μ、方差为 σ^2 的分布。则 $\bar{X}$ 是 μ 的无偏估计，$MSE(\bar{X}) = \sigma^2/n$。*

2.2. 矩估计与最大似然估计. $\widehat{\text{h}}$eorem[矩估计] 样本矩 $M_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k$ 依概率收敛到相应的总体矩 $E(X^k)$。矩估计通过解方程组 $\hat{\mu}_k = M_k$ 得到参数估计。heorem

Example 4.2 (正态分布的 MLE). *设 $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$。最大似然估计（$MLE$）为:*

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

注意: $\hat{\mu}$ 无偏，但 $\hat{\sigma}^2$ 有偏（除以 n 而非 $n-1$）。

3. 4.3 置信区间

核心问题: 点估计 $\hat{\theta}$ 有多好? 它离真实参数有多远?
置信区间提供了一个**区间**而非单一数值，告诉你参数可能落在什么范围内。

Definition 4.3 (置信区间). *设 $L = g_1(X_1, \ldots, X_n)$ 和 $U = g_2(X_1, \ldots, X_n)$ 是两个统计量。若对所有 $\theta \in \Omega$,*

$$\mathbb{P}_\theta(L \le \theta \le U) = 1 - \alpha,$$

则称随机区间 $[L, U]$ 为 θ 的 $100(1-\alpha)\%$ 置信区间。

解释: 不是"θ 以 $1-\alpha$ 的概率落在区间内"（θ 是固定常数），而是" 如果重复抽样，100 次中有 $100(1-\alpha)$ 次构造的区间会包含 θ"。

Example 4.3 (正态均值、已知方差). 设 $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$，$\sigma^2$ 已知。μ 的 $100(1-\alpha)\%$ 置信区间为：

$$\left[\bar{X} - z_{\alpha/2}\frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2}\frac{\sigma}{\sqrt{n}}\right],$$

其中 $z_{\alpha/2}$ 满足 $\Phi(z_{\alpha/2}) = 1 - \alpha/2$。

Example 4.4 (正态均值、未知方差). 设 $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$，$\sigma^2$ 未知。μ 的 $100(1-\alpha)\%$ 置信区间为：

$$\left[\bar{X} - t_{\alpha/2,n-1}\frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2,n-1}\frac{S}{\sqrt{n}}\right],$$

其中 $t_{\alpha/2,n-1}$ 是 $t(n-1)$ 分布的上侧 $\alpha/2$ 分位数。

注意：用 S 替代 σ，用 t 替代 z。因为未知方差带来的不确定性，区间变宽了。

$\widehat{\text{h}}$eorem[方差置信区间] 设 $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$。$\sigma^2$ 的 $100(1-\alpha)\%$ 置信区间为：

$$\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2,n-1}}, \quad \frac{(n-1)S^2}{\chi^2_{1-\alpha/2,n-1}}\right].$$

heorem

ěmark 直觉解释] 置信区间的宽度与 $\sqrt{n}$ 成反比——样本量越大，区间越窄，估计越精确。同时，置信水平 $1-\alpha$ 越高，区间越宽。emark

4. 4.4 顺序统计量

核心思想：将样本从小到大排列：

$$X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}.$$

$X_{(k)}$ 是第 k 个顺序统计量。

样本中位数：

$$\tilde{X} = \begin{cases} X_{((n+1)/2)} & n \text{ 奇数} \\ \frac{1}{2}\left(X_{(n/2)} + X_{(n/2+1)}\right) & n \text{ 偶数} \end{cases}$$

样本极差：$R = X_{(n)} - X_{(1)}$

顺序统计量的 cdf 和 pdf：

$$F_{X_{(k)}}(x) = \sum_{j=k}^{n} \binom{n}{j} [F(x)]^j [1 - F(x)]^{n-j},$$

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x).$$

5. 4.5 假设检验

假设检验回答一个问题：**数据是否提供足够证据拒绝关于总体的某个声明?**

核心概念：

- **原假设** H_0：被检验的假设（通常代表" 无效应" 或" 现状"）
- **备择假设** H_1：与 H_0 对立的假设

	未拒绝 H_0	拒绝 H_0
H_0 为真	正确	第一类错误 (α)
H_0 为假	第二类错误 (β)	正确（功效 $1-\beta$）

显著性水平 $\alpha = \mathbb{P}(\text{第一类错误}) = \mathbb{P}(\text{拒绝}H_0 \mid H_0 \text{ 为真})$。

Example 4.5 (正态均值检验、已知方差). 设 $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$，$\sigma^2$ 已知。检验 $H_0 : \mu = \mu_0$ *vs* $H_1 : \mu > \mu_0$。

检验统计量：$Z = \frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}}$。

在 α 水平下拒绝 H_0 当且仅当 $Z > z_\alpha$。

Example 4.6 (正态均值检验、未知方差). 设 $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$，$\sigma^2$ 未知。检验 $H_0 : \mu = \mu_0$ *vs* $H_1 : \mu \neq \mu_0$。

检验统计量：$T = \frac{\bar{X}-\mu_0}{S/\sqrt{n}}$。

在 α 水平下拒绝 H_0 当且仅当 $|T| > t_{\alpha/2,n-1}$。

ěmark$p$ 值的直观理解] p 值是在 H_0 为真的假设下，观察到比当前样本更极端结果的概率。p 值越小，拒绝 H_0 的证据越强。emark

6. 4.6 卡方检验

卡方检验用于分析**分类数据**——即计数数据。

6.1. 拟合优度检验. 问题：数据是否来自某个特定分布?

设 $O_1, \ldots, O_k$ 是 k 个类别的观测频数，$E_i = np_{i,0}$ 是 H_0 下的期望频数。

检验统计量：

$$\chi^2 = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}.$$

在 H_0 下，$\chi^2 \approx \chi^2(k-1)$（大样本近似）。

拒绝 H_0 当 $\chi^2 > \chi^2_{\alpha,k-1}$。

6.2. 独立性检验. 对于 $r \times c$ 列联表，设 O_{ij} 为单元格 (i,j) 的观测频数。

在独立性假设下，$E_{ij} = \frac{O_{i\cdot}O_{\cdot j}}{n}$。

检验统计量：

$$\chi^2 = \sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

在 H_0 下，$\chi^2 \approx \chi^2((r-1)(c-1))$。

7. 4.7 蒙特卡洛方法

核心思想：用随机模拟来近似计算概率和积分。

7.1. 为什么需要蒙特卡洛?. 有些概率/期望无法解析计算，但可以用计算机模拟近似。大数定律保证了模拟的收敛性：

$$\frac{1}{n}\sum_{i=1}^{n} g(X_i) \xrightarrow{P} \mathbb{E}[g(X)].$$

Example 4.7 (蒙特卡洛估计 π). *在单位正方形 $[0,1]\times[0,1]$ 中均匀随机投点，落入单位圆弧内的概率为 $\pi/4$。因此 $\hat{\pi} = 4\times$ (落入圆内比例)。*

7.2. 接受-拒绝算法. 当目标分布 $f(x)$ 难以直接抽样时，接受-拒绝算法提供了一种间接方法。

算法：

(1) 选择一个提议分布 $g(x)$，满足 $f(x) \le Mg(x)$（对某个 $M > 1$）
(2) 生成 $Y \sim g$ 和 $U \sim \text{Uniform}(0,1)$ 独立
(3) 若 $U \le f(Y)/(Mg(Y))$，接受 $X = Y$；否则拒绝，返回步骤 2

接受概率为 $1/M$。

8. 4.8 Bootstrap 方法

核心问题：估计量的抽样分布通常难以解析计算，怎么办?
Bootstrap 的答案是：**用重抽样近似**。
步骤：

(1) 从原始样本中有放回地抽取 n 个观测，形成一个 bootstrap 样本 $X_1^*, \ldots, X_n^*$
(2) 计算 bootstrap 复制 $T^* = g(X_1^*, \ldots, X_n^*)$
(3) 重复步骤 1-2 多次（如 $B = 1000$ 次），得到 $T_1^*, \ldots, T_B^*$
(4) 用 $T_1^*, \ldots, T_B^*$ 的经验分布近似 T 的抽样分布

8.1. 百分位 Bootstrap 置信区间. θ 的 $100(1-\alpha)\%$ percentile bootstrap 置信区间：

$$\left[T^*_{(\alpha B)}, \quad T^*_{((1-\alpha)B)}\right].$$

ěmarkBootstrap 的哲学] Bootstrap 假设" 样本就像总体"——通过从样本中有放回抽样，我们模拟了如果重复实验会得到什么。这是一种非参数的近似方法，不需要对分布做任何假设。emark

本章小结

核心概念：

- **统计量**：样本的函数，不依赖未知参数
- **点估计**：用单一数值估计参数；无偏性、渐近性、效率是主要评判标准
- **置信区间**：参数的合理取值范围；宽度随样本量增大而减小

- **假设检验**：判断数据是否提供足够证据拒绝 H_0；第一类和第二类错误的权衡

重要公式：

场景	置信区间/检验统计量
正态均值、已知 σ	$\bar{X} \pm z_{\alpha/2}\sigma/\sqrt{n}$
正态均值、未知 σ	$\bar{X} \pm t_{\alpha/2,n-1}S/\sqrt{n}$
正态方差	$\frac{(n-1)S^2}{\chi^2_{\alpha/2,n-1}}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2,n-1}}$
单样本 Z 检验	$Z = \frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}}$
单样本 t 检验	$T = \frac{\bar{X}-\mu_0}{S/\sqrt{n}}$
拟合优度 χ^2 检验	$\chi^2 = \sum \frac{(O-E)^2}{E} \approx \chi^2(k-1)$

1. 问答记录

问题记录. 问题: ... **回答:** ...

学习笔记.