

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - \* ` B ;





































































































































































































































































































































































































































































## CHAPTER 9

# ANOVA and Regression

### Chapter 9 Overview

在前几章中，我们讨论了来自单个总体的样本推断，以及两个总体的比较。但实际中，我们常常面临更复杂的问题：

如果有三个、四个甚至更多个总体，我们该如何比较它们的均值？

这个问题——即**多组比较问题**——在农业实验、医学试验、工业质量控制等领域无处不在。例如，在一项评估不同肥料对作物产量影响的实验中，我们需要同时比较多个处理组；而在研究药物疗效时，我们可能需要同时评估多种药物的效果。

本章，我们从单样本  $t$  检验  $\rightarrow$  两样本  $t$  检验  $\rightarrow$  多组比较的自然推广，引入**方差分析 (Analysis of Variance, 简称 ANOVA)**。这一方法由 Ronald Fisher 在 1920 年代创立，起源于他在英国洛桑农业实验站的农业实验研究。Fisher 的核心思想是：将总变异分解为可解释的变异和随机误差，通过比较两者来判断处理效应是否显著。

**本章路线图：**

- (1) One-Way ANOVA  $\rightarrow$  组间/组内平方和分解  $\rightarrow F$  检验
- (2) 非中心  $\chi^2$  和  $F$  分布  $\rightarrow$  备择假设下的分布
- (3) Multiple Comparisons  $\rightarrow$  Tukey 法、Bonferroni 法（控制族误差率）
- (4) Two-Way ANOVA  $\rightarrow$  主效应、交互效应
- (5) 回归问题  $\rightarrow$  最小二乘估计、几何解释（投影）
- (6) 二次型分布  $\rightarrow$  Cochran 定理——平方和分解的理论基础

### 1. 9.1 Introduction

在正式进入 ANOVA 之前，我们需要介绍一个重要的数学工具——**二次型 (quadratic form)**。

DEFINITION 9.1 (二次型). 设  $X_1, \dots, X_n$  是  $n$  个变量， $a_{ij}$  是常数。形如

$$q(X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^n X_i a_{ij} X_j$$

的表达式称为  $X_1, \dots, X_n$  的（二次）**二次型**。

**为什么二次型重要？** 在统计推断中，许多关键的统计量都可以表示为二次型。例如，样本方差

$$(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

就是关于样本  $X_1, \dots, X_n$  的一个二次型。理解二次型的分布性质, 是理解 ANOVA 和回归分析的理论基础。

## 2. 9.2 One-Way ANOVA

**2.1. 问题的引入.** 考虑  $b$  个独立的正态总体, 第  $j$  个总体的均值为  $\mu_j$ , 共同方差为  $\sigma^2$ 。从第  $j$  个总体中抽取容量为  $n_j$  的随机样本  $X_{1j}, X_{2j}, \dots, X_{n_jj}$ 。记总样本量为  $n = \sum_{j=1}^b n_j$ 。

模型为:

$$X_{ij} = \mu_j + e_{ij}, \quad i = 1, \dots, n_j, \quad j = 1, \dots, b, \quad (9.2.1)$$

其中  $e_{ij}$  是 iid  $N(0, \sigma^2)$  随机误差。

我们想检验: 所有  $b$  个总体的均值是否相等——

$$H_0: \mu_1 = \mu_2 = \dots = \mu_b \quad \text{vs} \quad H_1: \mu_j \neq \mu_{j'} \text{ 对某些 } j \neq j'. \quad (9.2.2)$$

**实际背景:** 例如,  $b$  种药物对某种疾病的疗效比较; 或  $b$  种肥料对作物产量的影响。这里”一种因素 (factor)” 处于  $b$  个”水平 (level)”, 因此称为**单因素实验 (one-way layout)**。

**2.2. 似然比检验的推导.** 完全模型 (full model) 参数空间:

$$\Omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : -\infty < \mu_j < \infty, \quad 0 < \sigma^2 < \infty\}.$$

约束模型 (reduced model) 参数空间 ( $H_0$  下):

$$\omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : \mu_1 = \dots = \mu_b = \mu, \quad 0 < \sigma^2 < \infty\}.$$

完全模型下的 MLE:

$$\hat{\mu}_j = \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\Omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2. \quad (9.2.7)$$

约束模型下的 MLE (此时等价于单样本问题):

$$\hat{\mu}_\omega = \bar{X}_{\cdot\cdot} = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.3)$$

似然比统计量简化后的形式为:

$$\Lambda^{n/2} = \frac{\hat{\sigma}_\Omega^2}{\hat{\sigma}_\omega^2}. \quad (9.2.9)$$

拒绝  $H_0$  等价于  $F$  统计量过大, 其中

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)}, \quad (9.2.11)$$

而

$$Q_3 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2, \quad Q_4 = \sum_{j=1}^b n_j (\bar{X}_{\cdot j} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.10)$$

核心分解:

$$\underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2}_Q = \underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}_{Q_3(\text{组内})} + \underbrace{\sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2}_{Q_4(\text{组间})}. \quad (9.2.10)$$

在  $H_0$  下,  $Q_3/\sigma^2 \sim \chi^2(n-b)$ ,  $Q_4/\sigma^2 \sim \chi^2(b-1)$ , 且二者独立。因此  $F \sim F(b-1, n-b)$ 。

**2.3. ANOVA 表格.** 单因素 ANOVA 的结果可以汇总为一张清晰的表格:

表 1. 单因素 ANOVA 表格

| 来源           | 平方和 (SS) | df    | 均方 (MS)           | $F$ 统计量           | p 值                   |
|--------------|----------|-------|-------------------|-------------------|-----------------------|
| 组间 (Between) | $Q_4$    | $b-1$ | $MSB = Q_4/(b-1)$ | $\frac{MSB}{MSW}$ | $\mathbb{P}(F > F_0)$ |
| 组内 (Within)  | $Q_3$    | $n-b$ | $MSW = Q_3/(n-b)$ |                   |                       |
| 总计 (Total)   | $Q$      | $n-1$ |                   |                   |                       |

EXAMPLE 9.1 (合金弹性模量). Devore (2012, 第 412 页) 报告了一项数据: 三种铸造工艺 (永久模具、压铸、石膏模具) 生产合金的弹性模量。三种工艺各有多次测量, 我们想知道铸造工艺是否显著影响弹性模量。

数据汇总后,  $F = 12.565$ , 自由度为 2 和 19,  $p$  值为 0.0003。如此小的  $p$  值表明: 铸造工艺对弹性模量有显著影响。

(该例子的详细计算与  $R$  代码实现见附录 ??。)

### 3. 9.3 Noncentral $\chi^2$ and $F$ Distributions

**3.1. 为什么需要非中心分布?** 在前一节的 ANOVA 中, 我们在原假设  $H_0$  下推导了  $F$  统计量的分布。但在实际应用中, 我们更关心: 当  $H_0$  不成立 (即各组均值不全相等) 时,  $F$  统计量的分布是什么? 这时就需要引入**非中心  $\chi^2$  分布**和**非中心  $F$  分布**。

DEFINITION 9.2 (非中心  $\chi^2$  分布). 设  $X_i \sim N(\mu_i, \sigma^2)$ ,  $i = 1, \dots, n$ , 独立。则

$$Y = \sum_{i=1}^n \frac{X_i^2}{\sigma^2}$$

的 *mgf* 为

$$M(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}, \quad t < \frac{1}{2}. \quad (9.3.1)$$

此时称  $Y \sim \chi^2(r, \theta)$ , 其中  $r = n$  是自由度,  $\theta = \sum_{i=1}^n \mu_i^2 / \sigma^2$  是**非中心参数 (noncentrality parameter)**。

**直观理解:** 当所有  $\mu_i = 0$  时,  $\theta = 0$ , 回到中心  $\chi^2$  分布; 当某些  $\mu_i \neq 0$  时,  $Y$  的分布在中心  $\chi^2$  的基础上向右偏移,  $\theta$  越大, 偏移越明显。

非中心  $\chi^2$  分布的均值:  $E(Y) = r + \theta$  (中心部分  $r$  加上非中心部分  $\theta$ )。

DEFINITION 9.3 (非中心  $F$  分布). 设  $U \sim \chi^2(r_1, \theta)$ ,  $V \sim \chi^2(r_2)$ , 独立。则

$$F = \frac{r_2 U}{r_1 V}$$

服从自由度为  $r_1, r_2$ 、非中心参数为  $\theta$  的非中心  $F$  分布, 记作  $F(r_1, r_2, \theta)$ 。

EXAMPLE 9.2 (One-Way ANOVA 的非中心参数). 对于 *one-way ANOVA* 模型 (9.2.1), 在备择假设  $H_1$  下,  $F$  统计量的分子  $Q_4/\sigma^2 \sim \chi^2(b-1, \theta)$ , 其中

$$\theta = \frac{1}{\sigma^2} \sum_{j=1}^b n_j (\mu_j - \bar{\mu})^2, \quad \bar{\mu} = \frac{1}{n} \sum_{j=1}^b n_j \mu_j. \quad (9.3.5)$$

当  $H_0$  成立时,  $\theta = 0$ , 回到中心  $F$  分布; 当  $H_1$  成立时,  $\theta > 0$ ,  $F$  分布向右偏移, 偏移程度由  $\theta$  刻画。这解释了为什么  $F$  检验在  $H_0$  不成立时倾向于取更大的值。

(非中心  $F$  分布的完整推导见附录 ??。)

#### 4. 9.4 Multiple Comparisons

当 one-way ANOVA 的  $F$  检验拒绝了  $H_0$  后, 我们自然想知道: **具体哪些组之间存在显著差异?** 这就是**多重比较问题 (Multiple Comparison Problem, MCP)**。

**4.1. 问题的核心矛盾.** 对  $b$  个总体, 若进行所有  $\binom{b}{2}$  个成对比较, 即使每个置信区间的置信水平为 95%, 整体的置信水平也会急剧下降。举例来说, 若  $b = 5$ , 则共有 10 个成对比较, 每个比较犯错的概率为 5%, 至少有一次犯错的概率粗略估计为  $1 - (0.95)^{10} \approx 40\%$ 。

因此, 我们需要专门设计的方法来**控制族误差率 (Family-Wise Error Rate, FWER)**——即**在所有比较中至少有一次犯错的概率**。

**4.2. Bonferroni 方法.** Bonferroni 方法基于一个简单的不等式: 对  $k$  个参数  $\theta_i$ , 若每个区间  $I_i$  的置信水平为  $1 - \alpha$ , 则

$$P(\text{所有 } \theta_i \in I_i) \geq 1 - k\alpha. \quad (9.4.2)$$

**核心理想:** 将每个区间的置信水平从  $1 - \alpha$  调整为  $1 - \alpha/k$ , 则整体的置信水平至少为  $1 - \alpha$ 。

对 one-way ANOVA, 成对差值  $\mu_j - \mu_{j'}$  的 Bonferroni 置信区间为:

$$\bar{X}_{\cdot j} - \bar{X}_{\cdot j'} \pm t_{\alpha/(2k), n-b} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.3)$$

**优点:** 通用性强, 适用于任何成对比较。**缺点:** 比较数量  $k$  越大, 区间越宽, 精度损失越大。

**4.3. Tukey 方法.** Tukey 方法利用学生化极差分布 (Studentized range distribution), 专为 balanced 设计的成对比较设计。

当所有组样本容量相等 ( $n_j = a, j = 1, \dots, b$ ) 时, 所有成对比较的同时置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm q_{1-\alpha, b, n-b} \frac{\hat{\sigma}_{\Omega}}{\sqrt{a}}, \quad \forall j \neq j'. \quad (9.4.4)$$

其中  $q_{1-\alpha, b, n-b}$  是自由度为  $b$  和  $n-b$  的学生化极差分布分位数。

对于 unbalanced 情形, 使用 Tukey-Kramer 修正:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm \frac{q_{1-\alpha, b, n-b}}{\sqrt{2}} \hat{\sigma}_{\Omega} \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.5)$$

EXAMPLE 9.3 (赛车速度比较). *Kitchens (1997)* 报告了一项实验: 比较五种汽车 (*Acura, Ferrari, Lotus, Porsche, Viper*) 的最高速度。每种车进行 6 次运行测试。整体  $F$  检验高度显著 ( $F = 25.15, p \approx 0$ )。Tukey 多重比较结果表明: *Ferrari* 和 *Porsche* 的平均速度显著快于其他三种车, 但 *Ferrari* 与 *Porsche* 之间速度差异不显著。

(该例子的  $R$  实现与详细结果分析见附录 ??。)

**4.4. Fisher 的保护 LSD 方法.** Fisher 方法是一个两步程序:

- (1) 首先进行整体  $F$  检验; 若拒绝  $H_0$ ,
- (2) 再使用标准的成对  $t$  置信区间 (置信水平  $1 - \alpha$ )。

Fisher 方法不保证整体覆盖率为  $1 - \alpha$ , 但  $F$  检验提供了”保护”。模拟研究表明它在功效和实际误差率方面表现良好。

## 5. 9.5 Two-Way ANOVA

**5.1. 双因素实验的引入.** 在实际研究中, 我们常常需要同时考虑两个因素对结果的影响。例如:

- 作物产量: 同时受品种 (因素 A) 和肥料类型 (因素 B) 的影响
- 考试成绩: 同时受教学方法 (因素 A) 和班级规模 (因素 B) 的影响

这就是双因素方差分析 (two-way ANOVA)。

设因素 A 有  $a$  个水平, 因素 B 有  $b$  个水平, 每个组合有一个观测值  $X_{ij}$ 。模型为:

$$X_{ij} = \mu + \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b, \quad (9.5.2)$$

其中  $e_{ij} \sim N(0, \sigma^2)$  iid, 且  $\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0$ 。

可加模型 (additive model) 意味着两个因素的影响是相互独立的——因素 A 的效应不随因素 B 的水平变化。

表 2. 双因素可加模型的单元格均值示例 ( $a = 2, b = 3$ )

|     | B=1 | B=2 | B=3 |
|-----|-----|-----|-----|
| A=1 | 7   | 6   | 5   |
| A=2 | 5   | 4   | 3   |

在可加模型中，行均值轮廓线是**平行的**——这是可加模型的重要特征。

**5.2. 假设检验.** 我们需要检验两个主效应假设：

$$H_{0A} : \alpha_1 = \cdots = \alpha_a = 0 \quad \text{vs} \quad H_{1A} : \text{某些 } \alpha_i \neq 0, \quad (9.5.3)$$

$$H_{0B} : \beta_1 = \cdots = \beta_b = 0 \quad \text{vs} \quad H_{1B} : \text{某些 } \beta_j \neq 0. \quad (9.5.4)$$

检验  $H_{0B}$  的  $F$  统计量：

$$F_B = \frac{a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 / (b-1)}{\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2 / [(a-1)(b-1)]}. \quad (9.5.12)$$

在  $H_{0B}$  下， $F_B \sim F(b-1, (a-1)(b-1))$ 。

类似地，检验  $H_{0A}$  的  $F$  统计量  $F_A \sim F(a-1, (a-1)(b-1))$ 。

**5.3. 9.5.1 Interaction between Factors.** 交互效应发生在：一个因素的影响程度取决于另一个因素的水平时。

在模型中引入交互参数  $\gamma_{ij}$ ：

$$\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij}, \quad (9.5.15)$$

其中  $\sum_i \gamma_{ij} = \sum_j \gamma_{ij} = 0$ 。

若所有  $\gamma_{ij} = 0$ ，则回到可加模型；若存在非零  $\gamma_{ij}$ ，则两个因素之间存在**交互作用**。

**图形诊断：**在双因素实验中，绘制各行（因素 A 各水平）的均值轮廓线。若线条大致平行，则交互作用不明显；若线条明显交叉或分离，则表明存在交互效应。

EXAMPLE 9.4 (沥青混合料热导率). Devore (2012, 第 435 页) 研究了两个因素对沥青混合料热导率的影响：粘结剂等级 (PG58, PG64, PG70) 和粗骨料含量 (38%, 41%, 44%)。每个处理组合有 2 次重复。

$R$  分析结果：交互效应不显著 ( $p = 0.4135$ )，但两个主效应都非常显著 ( $p = 0.0017$  和  $p < 10^{-5}$ )。因此接受可加模型，两个因素独立地影响热导率。

(该例子的详细 ANOVA 表和  $R$  代码见附录 ??。)

## 6. 9.6 A Regression Problem

**6.1. 为什么研究回归?** ANOVA 研究的是类别型 (categorical) 自变量对因变量的影响。但在许多实际问题中，自变量是连续型的。例如：

- 学生的学习时间 (连续)  $\rightarrow$  考试成绩
- 汽车的发动机排量 (连续)  $\rightarrow$  每加仑行驶里程
- 农作物的施肥量 (连续)  $\rightarrow$  作物产量

这就引出了**回归分析 (regression analysis)** ——研究自变量 (通常记作  $x$ ) 与因变量  $Y$  之间关系的方法。

**线性模型：**假设  $E(Y) = \mu(x)$  是  $x$  的线性函数——

$$Y_i = \alpha + \beta(x_i - \bar{x}) + e_i, \quad i = 1, \dots, n, \quad (9.6.1)$$



其中  $e_i \sim N(0, \sigma^2)$  iid。

**为什么假设  $x$  是已知的非随机变量？** 这是为了简化分析——我们把不确定性全部放在  $Y$  上。在实际中，如果  $x$  也是随机的，则需要联合分布建模；但在受控实验或观测研究中，将  $x$  视为固定设计点是合理的近似。

**线性模型 vs 非线性模型：** 这里“线性”指的是对参数  $(\alpha, \beta)$  线性，而非对  $x$  线性。因此  $\alpha + \beta x + \gamma x^2$  仍是线性模型，而  $\alpha e^{\beta x}$  不是。

**6.2. 9.6.1 Maximum Likelihood Estimates.** 对模型 (9.6.1)，似然函数为

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{[Y_i - \alpha - \beta(x_i - \bar{x})]^2}{2\sigma^2} \right\}. \quad (9.6.12)$$

最大化似然等价于最小化

$$H(\alpha, \beta) = \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2. \quad (9.6.3)$$

这正是**最小二乘法 (least squares)**——选择使残差平方和最小的  $\alpha, \beta$ 。

**几何直观：**  $|Y_i - \alpha - \beta(x_i - \bar{x})|$  是点  $(x_i, Y_i)$  到直线  $y = \alpha + \beta(x - \bar{x})$  的垂直距离。最小二乘法就是找到使所有这些距离平方和最小的直线。

MLE 的解：

$$\hat{\alpha} = \bar{Y}, \quad (9.6.3)$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (9.6.5)$$

$\hat{\sigma}^2$  的 MLE：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2. \quad (9.6.8)$$

**拟合值与残差：**

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}(x_i - \bar{x}), \quad \hat{e}_i = Y_i - \hat{Y}_i. \quad (9.6.6)$$

**估计量的分布：** 可以证明

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} \sim N_2 \left( \begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{pmatrix} \right). \quad (9.6.9)$$

**EXAMPLE 9.5 (男子 1500 米奥运会成绩).** 考虑 27 届奥运会男子 1500 米冠军成绩与年份的关系。年份为自变量  $x$ ，时间为因变量  $Y$ 。

$R$  拟合结果： $\hat{y} = 12.33 - 0.0044 \times \text{year}$ 。斜率的 95% 置信区间为  $(-0.00547, -0.00328)$ ——这意味着每年获胜时间平均减少约 0.004 分钟（约 0.24 秒）。对 2020 年奥运会的预测时间约为 3.486 分钟。

（该例子的详细计算、残差图分析和预测区间见附录 ??。）

**残差图诊断：** 在回归分析中，绘制残差  $\hat{e}_i$  vs 拟合值  $\hat{Y}_i$  的散点图。如果图呈现随机散布，说明模型是合理的；如果出现系统模式（如 U 形、漏斗形），则提示模型设定有问题（如遗漏非线性项、异方差等）。

**6.3. 9.6.2 \*Geometry of the Least Squares Fit.** 最小二乘拟合有一个优美的几何解释。

将数据写成向量形式  $\mathbf{Y} = (Y_1, \dots, Y_n)'$ , 设计矩阵  $\mathbf{X}$  的列为  $\mathbf{1}$  和  $\mathbf{x}_c = (x_1 - \bar{x}, \dots, x_n - \bar{x})'$ 。模型为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}). \quad (9.6.13)$$

设  $V$  为  $\mathbf{X}$  列张成的  $\mathbb{R}^n$  中的二维子空间 (拟合空间)。最小二乘估计  $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$  正是  $\mathbf{Y}$  在子空间  $V$  上的**正交投影**——即使得  $\|\mathbf{Y} - \boldsymbol{\theta}\|^2$  最小的  $V$  中元素。

几何分解:

$$\|\mathbf{Y}\|^2 = \|\hat{\boldsymbol{\theta}}\|^2 + \|\hat{\mathbf{e}}\|^2,$$

其中  $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$  是残差向量, 且  $\hat{\boldsymbol{\theta}} \perp \hat{\mathbf{e}}$  (残差与拟合空间正交)。这正是 ANOVA 中平方和分解的几何版本。

## 7. 9.7 A Test of Independence

在许多应用中, 我们需要检验两个连续变量  $X$  和  $Y$  是否独立。对于二元正态分布,  $X$  和  $Y$  独立当且仅当它们的相关系数  $\rho = 0$ 。因此我们检验:

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0. \quad (9.7.1)$$

**样本相关系数:**

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}. \quad (9.7.1)$$

**关键定理:** 在  $H_0$  下 (即  $\rho = 0$  时),  $R$  的分布不依赖于  $X$  的具体分布——只要  $X$  与  $Y$  独立,  $R$  的分布在正态情况下就有上式 (9.3.1) 给出的精确形式。特别是,

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t(n-2). \quad (9.7.3)$$

因此,  $H_0$  的拒绝域为  $|T| \geq t_{\alpha/2, n-2}$ , 或等价地  $|R| \geq c$ 。

**Remark 的深层含义:**  $R$  的条件分布 (在给定  $X_1, \dots, X_n$  下) 不依赖于  $X_i$  的具体值, 这意味着  $R$  与所有仅依赖于  $X$  的统计量独立。这是一个非常优雅的性质——样本相关系数在  $\rho = 0$  时”不受”  $X$  取值的影响。

## 8. 9.8 Distributions of Certain Quadratic Forms

前几节的分析依赖于一个共同的理论支柱: 某些二次型服从  $\chi^2$  分布, 且它们相互独立。本节和下一节建立这一理论的严格基础。

设  $\mathbf{X}' = (X_1, \dots, X_n)$ , 其中  $X_i \sim N(\mu_i, \sigma^2)$  iid. 二次型  $Q = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}$  的 mgf 为:

$$M_Q(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}. \quad (9.8.10)$$

特别地, 若  $\mathbf{A}$  是对称幂等矩阵 ( $\mathbf{A}^2 = \mathbf{A}$ ), 则  $Q \sim \chi^2(r, \theta)$ , 其中  $r = \text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A})$ ,  $\theta = \boldsymbol{\mu}' \mathbf{A} \boldsymbol{\mu} / \sigma^2$ 。若进一步  $\boldsymbol{\mu} = \mu \mathbf{1}$  且  $\sum_{i,j} a_{ij} = 0$ , 则  $\theta = 0$ ,  $Q$  为中心  $\chi^2(r)$ 。

**Cochran 定理的特例:** 若  $Q_1, \dots, Q_k$  是相互独立的  $\chi^2$  变量之和, 且  $\sum \text{rank}(Q_i) = n$ , 则各  $Q_i$  独立。

### 9. 9.9 The Independence of Certain Quadratic Forms

最后一个理论工具：Craig 定理，给出了两个二次型独立的充要条件。

这个定理在 ANOVA 中有重要应用：在 one-way ANOVA 中，组间平方和  $Q_4$ （对应某个幂等矩阵）与组内平方和  $Q_3$ （对应另一个幂等矩阵）满足  $\mathbf{AB} = \mathbf{0}$ ，因此独立——这正是  $F$  检验的理论基础。

推论：在回归模型中，拟合值的二次型与残差的二次型相互独立，反映了”被解释的变异”与”未被解释的变异”之间的正交性。

### 习题

EXERCISE 9.1. 9.1 One-Way ANOVA 数据计算—Hogg 9.2.3 考虑来自三个正态分布的独立随机样本，它们具有相等方差及 *respective means*  $\mu_1, \mu_2, \mu_3$ 。数据如下：

| <i>I</i> | <i>II</i> | <i>III</i> |
|----------|-----------|------------|
| 0.5      | 2.1       | 3.0        |
| 1.3      | 3.3       | 5.1        |
| -1.0     | 0.0       | 1.9        |
| 1.8      | 2.3       | 2.4        |
|          | 2.5       | 4.2        |
|          |           | 4.1        |

使用  $R$  或其他统计软件，计算用于检验  $H_0: \mu_1 = \mu_2 = \mu_3$  的  $F$  统计量。

EXERCISE 9.2. 9.2 One-Way ANOVA 假设检验—Hogg 9.2.7 设  $\mu_1, \mu_2, \mu_3$  分别为三个正态分布的均值，它们具有公共未知方差  $\sigma^2$ 。为在显著性水平  $\alpha = 0.05$  下检验假设  $H_0: \mu_1 = \mu_2 = \mu_3$  对所有可能备择假设，从每个分布中抽取容量为 4 的独立随机样本。若观测值分别为：

$$X_1: \quad 5 \quad 9 \quad 6 \quad 8$$

$$X_2: \quad 11 \quad 13 \quad 10 \quad 12$$

$$X_3: \quad 10 \quad 6 \quad 9 \quad 9$$

判断是否拒绝  $H_0$ 。

EXERCISE 9.3. 9.3 柴油燃料品牌 *mpg* 比较—Hogg 9.2.8 一位柴油汽车司机根据 *mpg* 测试三种柴油燃料的质量。使用以下数据检验三个均值相等的原假设。做通常的假设并取  $\alpha = 0.05$ 。

Brand A: 38.7 39.2 40.1 38.9

Brand B: 41.9 42.3 41.3

Brand C: 40.8 41.2 39.5 38.9 40.3

EXERCISE 9.4. 9.4 非中心  $\chi^2$  分布的方差-Hogg 9.3.2 计算服从非中心  $\chi^2(r, \theta)$  分布的随机变量的方差。

EXERCISE 9.5. 9.5 非中心  $T$  与非中心  $F$  的关系-Hogg 9.3.4 证明非中心  $T$  随机变量的平方是非中心  $F$  随机变量。

EXERCISE 9.6. 9.6 Bonferroni 多重比较程序-Hogg 9.4.1 对于练习 9.2.8 中讨论的研究, 使用  $\alpha = 0.10$  获取 Bonferroni 多重比较程序的结果。基于此程序, 哪个品牌的燃料 (如果有的话) 显著最好?

EXERCISE 9.7. 9.7 Tukey-Kramer 程序-Hogg 9.4.2 对于练习 9.2.6 中讨论的研究, 计算 Tukey-Kramer 程序。是否存在显著差异?

EXERCISE 9.8. 9.8 两因素可加模型平方和分解-Hogg 9.5.1 考虑一个双因素实验, 其中因素  $A$  有 2 个水平, 因素  $B$  有 3 个水平。设  $\mu = 5$ ,  $\alpha_1 = 1$ ,  $\alpha_2 = -1$ ,  $\beta_1 = 1$ ,  $\beta_2 = 0$ ,  $\beta_3 = -1$ 。回答以下问题:

- 写出单元格均值  $\mu_{ij}$  的表格。
- 绘制均值轮廓图 (mean profile plot)。
- 若交互效应存在, 轮廓图会有什么特征?

EXERCISE 9.9. 9.6.4 一回归估计量的协方差 证明  $\hat{\alpha}$  与  $\hat{\beta}$  之间的协方差为零。

提示: 利用 (9.6.5) 中  $\hat{\beta}$  的表达式, 以及  $\sum_{i=1}^n (x_i - \bar{x}) = 0$  的性质。

EXERCISE 9.10. 9.6.5 一回归参数的置信区间 在模型 (9.6.1) 下, 求参数  $\alpha$  和  $\beta$  的  $(1 - \alpha)100\%$  置信区间。

EXERCISE 9.11. 9.6.9 一回归平方和分解 证明以下等式成立:

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

提示: 这本质上是将总平方和分解为拟合平方和与残差平方和。

EXERCISE 9.12. 9.6.14 简单最小二乘拟合 使用最小二乘法拟合  $y = a + x$  到以下数据:

$$\begin{array}{r} x \quad 0 \quad 1 \\ 2 \\ \hline y \quad 1 \quad 3 \\ 4 \end{array}$$

## 附录: 公式推导

**One-Way ANOVA 平方和恒等式的证明.** 背景: 在 one-way ANOVA 中, 总平方和  $Q$  可以分解为组内平方和  $Q_3$  与组间平方和  $Q_4$  之和。这一恒等式是  $F$  检验的基石。

目标：证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2.$$

推导：记  $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和：

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零，因为对每个固定的  $j$ ，

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。 □

**One-Way ANOVA 检验统计量的分布。背景：**推导 one-way ANOVA 中  $F$  统计量在原假设下的分布。

目标：证明在  $H_0$  下， $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导：

**步骤 1:  $Q_3$  的分布。**对每个固定的  $j$ ，由样本方差性质， $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立，故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2 \left( \sum_{j=1}^b (n_j - 1) \right) = \chi^2(n-b).$$

**步骤 2:  $Q_4$  与  $Q_3$  的独立性。**注意  $\bar{X}_{.j}$  与  $Q_3$  独立（由正态样本的性质），且  $\bar{X}_{..}$  是  $\bar{X}_{.1}, \dots, \bar{X}_{.b}$  的线性组合，因此  $\bar{X}_{..}$  也与  $Q_3$  独立。故  $Q_4$ （ $\bar{X}_{.j}$  的函数）与  $Q_3$  独立。

**步骤 3:  $Q_4$  的分布。**在  $H_0$  下， $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$ ，故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各  $\bar{X}_{.j}$  通过  $\bar{X}_{..}$  而不独立。直接计算知  $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

**步骤 4:  $F$  分布。**由步骤 1、2、3 及  $F$  分布定义，

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b). \quad (\text{A9.3})$$

□

**非中心  $\chi^2$  分布的均值和方差.** 背景: 验证非中心  $\chi^2$  分布的基本性质。

已知:  $Y \sim \chi^2(r, \theta)$ , mgf 为  $M(t) = (1 - 2t)^{-r/2} \exp\{t\theta/(1 - 2t)\}$ 。

目标: 求  $E(Y)$  和  $\text{var}(Y)$ 。

推导:

由 mgf,  $M(t) = (1 - 2t)^{-r/2} \exp\{t\theta/(1 - 2t)\}$ 。对  $M(t)$  求导:

$$M'(t) = \left[ r(1 - 2t)^{-r/2-1} + \frac{r\theta}{(1 - 2t)^{r/2+1}} \right] \exp \left\{ \frac{t\theta}{1 - 2t} \right\}.$$

故  $E(Y) = M'(0) = r + \theta$ 。

对  $M''(t)$  在  $t = 0$  求值, 可得  $\text{var}(Y) = 2(r + 2\theta)$ 。<sup>1</sup>

**最小二乘估计的几何解释.** 背景: 回归最小二乘估计的正交投影几何。

目标: 证明  $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$  是  $\mathbf{Y}$  在  $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$  上的正交投影。

推导: 由正交投影的定义,  $\hat{\boldsymbol{\theta}}$  满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量  $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$  与  $\mathbf{1}$  和  $\mathbf{x}_c$  都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0. \quad (\text{A9.4})$$

由  $\mathbf{1}'\hat{\mathbf{e}} = 0$  得  $\sum_i \hat{e}_i = 0$  (残差之和为零)。

由  $\mathbf{x}_c'\hat{\mathbf{e}} = 0$  并利用正规方程, 可解出  $\hat{\alpha}$  和  $\hat{\beta}$  的表达式与 (9.6.3)、(9.6.5) 一致。故  $\hat{\boldsymbol{\theta}}$  确为正交投影。□

---

<sup>1</sup>该推导的详细计算见附录 ??。

## 附录：公式推导

**0.1. Gamma 分布的矩母函数推导. 背景 (Background)：** 在正文中我们声明 Gamma 分布的矩母函数为  $M(t) = (1 - \beta t)^{-\alpha}$  for  $t < 1/\beta$ 。这里给出完整推导。

**参数定义 (Parameter Definitions)：**

- $\alpha > 0$ : 形状参数 (shape parameter)
- $\beta > 0$ : 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$ : 服从 Gamma 分布的随机变量

**已知条件 (Given)：**

- Gamma 分布的 pdf:  $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$ ,  $x > 0$
- 矩母函数定义:  $M(t) = \mathbb{E}(e^{tX})$

**目标 (Goal)：** 证明  $M(t) = (1 - \beta t)^{-\alpha}$  for  $t < 1/\beta$ 。

**推导步骤 (Derivation Steps)：**

1. 根据矩母函数定义：

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换：令  $y = \frac{x(1-\beta t)}{\beta}$ ，则  $x = \frac{\beta y}{1-\beta t}$ ， $dx = \frac{\beta}{1-\beta t} dy$ 。

3. 代入积分（要求  $t < 1/\beta$  以保证  $1 - \beta t > 0$ ）：

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left( \frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

**结论：** 因此， $X \sim \Gamma(\alpha, \beta)$  的矩母函数为  $M(t) = (1 - \beta t)^{-\alpha}$ ，定义域为  $t < 1/\beta$ 。■

**0.2. Gamma 分布的均值与方差推导. 背景 (Background)：** 在正文中我们给出 Gamma 分布的均值为  $\mathbb{E}X = \alpha\beta$ ，方差为  $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

**已知条件 (Given)：**

- 矩母函数:  $M(t) = (1 - \beta t)^{-\alpha}$  for  $t < 1/\beta$
- 均值公式:  $\mathbb{E}X = M'(0)$
- 方差公式:  $\text{var}(X) = M''(0) - [M'(0)]^2$

**目标 (Goal):** 计算  $\mathbb{E}X$  和  $\text{var}(X)$ 。

**推导步骤 (Derivation Steps):**

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入  $t = 0$ :

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

**结论:** 因此,  $\mathbb{E}X = \alpha\beta$ ,  $\text{var}(X) = \alpha\beta^2$ 。■

**0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background):** 卡方分布  $\chi^2(n)$  是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

**参数定义 (Parameter Definitions):**

- $n$ : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$  iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

**目标 (Goal):** 证明  $X \sim \Gamma(n/2, 2)$ 。

**推导步骤 (Derivation Steps):**

1. 单个标准正态平方的分布: 若  $Z \sim N(0, 1)$ , 则  $Y = Z^2$  的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是  $\Gamma(1/2, 2)$  的形式。

2. 利用 Gamma 分布的可加性: 若  $Y_1 \sim \Gamma(\alpha_1, \beta)$ ,  $Y_2 \sim \Gamma(\alpha_2, \beta)$  独立, 则  $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于  $Z_1^2, Z_2^2, \dots, Z_n^2$  独立同分布, 且每个  $Z_i^2 \sim \Gamma(1/2, 2)$ , 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

**结论:** 卡方分布  $\chi^2(n)$  等价于  $\Gamma(n/2, 2)$ 。■



**0.4. 边缘分布公式的推导. 背景 (Background):** 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

**目标 (Goal):** 证明  $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

**推导步骤 (Derivation Steps):**

1. 从联合 cdf 出发, 对  $x_2$  求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

**结论:** 因此,  $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

**0.5. 期望线性性的推导. 背景 (Background):** 在正文中我们声称期望算子  $E$  是线性的, 即  $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

**目标 (Goal):** 给出这一性质的形式化推导。

**推导步骤 (Derivation Steps):**

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质  $\int \int f(y_1, y_2) dy_1 dy_2 = 1$ , 我们分别处理两项。

4. 第一项: 先对  $y_2$  积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left( \int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得  $\mathbb{E}Y_2$ 。

**结论:** 因此  $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需  $Y_1, Y_2$  独立。■

**0.6. Jacobian 变换公式的推导. 背景 (Background):** 在正文中我们给出二元变换公式  $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

**目标 (Goal):** 解释  $|J|$  的来源。

**推导步骤 (Derivation Steps):**

1. 设变换为  $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$ , 逆变换为  $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件  $\{Y_1 \leq y_1, Y_2 \leq y_2\}$  等价于  $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

**结论:**  $|J|$  度量了变换下的面积元素缩放比例。■

**0.7. 条件分布公式的推导. 背景 (Background):** 条件分布  $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$  是概率论的核心概念。

**目标 (Goal):** 从条件概率的基本定义出发推导出条件 pdf 公式。

**推导步骤 (Derivation Steps):**

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件  $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$ :

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证: 边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故  $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$ , 确实是合法的 pdf。

**结论:** 条件 pdf 公式得证。■

**0.8. 全期望公式的推导. 背景 (Background):** 全期望公式  $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$  是连接条件期望与边缘期望的桥梁。

**目标 (Goal):** 形式化推导这一公式。

**推导步骤 (Derivation Steps):**

1. 从条件期望定义出发:

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望 (即关于  $X_1$  求平均):

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left( \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义  $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$ :

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

**结论:** 全期望公式得证。■

**0.9. 条件方差不等式的推导. 背景 (Background):** 在正文中我们给出  $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

**目标 (Goal):** 证明条件方差不等式。

**推导步骤 (Derivation Steps):**

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

**结论:** 条件均值的方差不超过原变量的方差, 等号成立当且仅当  $X_2 | X_1$  的条件方差几乎处处为 0 (即  $X_2$  可由  $X_1$  确定性决定)。■

**0.10. 独立性判定的推导. 背景 (Background):** 我们声称  $X_1$  与  $X_2$  独立等价于  $f(x_1, x_2) \equiv g(x_1)h(x_2)$  (可分离变量)。

**目标 (Goal):** 证明这一判定条件。

**推导步骤 (Derivation Steps):**

( $\Rightarrow$ ) 若  $X_1$  与  $X_2$  独立, 则  $f(x_1, x_2) = f_1(x_1)f_2(x_2)$ , 显然可分离。

( $\Leftarrow$ ) 若  $f(x_1, x_2) \equiv g(x_1)h(x_2)$ :

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中  $c_1 = \int h(x_2) dx_2$  为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中  $c_2 = \int g(x_1) dx_1$  为常数。

3. 由归一性  $\int \int f(x_1, x_2) dx_1 dx_2 = 1$ , 得  $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

**结论:** 故  $f(x_1, x_2) \equiv g(x_1)h(x_2)$  是独立性的等价条件。■

**0.11. 相关系数范围的推导. 背景 (Background):** 我们声称相关系数满足  $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

**目标 (Goal):** 证明  $|\rho| \leq 1$ 。

**推导步骤 (Derivation Steps):**

1. Cauchy-Schwarz 不等式: 对任意随机变量  $U, V$ ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差, 令  $U = X_1 - \mu_1$ ,  $V = X_2 - \mu_2$ :

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方:

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此:

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

**结论:** 故  $-1 \leq \rho \leq 1$ 。等号成立当且仅当  $X_2 = aX_1 + b$  (完美线性关系)。■

**0.12. 二元正态条件分布的推导. 背景 (Background):** 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

**参数定义 (Parameter Definitions):**

- $\mu_1, \mu_2$ : 边缘分布均值
- $\sigma_1^2, \sigma_2^2$ : 边缘分布方差
- $\rho$ : 相关系数
- $f(x_1, x_2)$ : 二元正态联合密度

**目标 (Goal):** 求条件分布  $f_{2|1}(x_2|x_1)$ 。

**推导步骤 (Derivation Steps):**

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中  $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于  $x_2$  完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为  $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为  $\sigma_2^2(1 - \rho^2)$  的正态密度。

**结论:** 二元正态的条件分布仍是正态分布。■

**0.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background):** 在正文中给出若  $X_1, \dots, X_n$  相互独立, 则  $T = \sum_{i=1}^n k_i X_i$  的 mgf 为  $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

**目标 (Goal):** 形式化推导这一公式。

**推导步骤 (Derivation Steps):**

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于  $X_1, \dots, X_n$  相互独立,  $e^{tk_i X_i}$  也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[ \prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各  $M_i(t)$  的存在域  $-h_i < t < h_i$ ,  $T$  的 mgf 定义域为  $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$  (假设  $k_i > 0$ ; 若  $k_i < 0$  则需调整)。

**结论:** 故  $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若  $X_i$  iid, 则  $M_T(t) = [M(kt)]^n$ 。■

**0.14. Binomial 分布的矩母函数推导. 背景 (Background):** 在正文中我们声明 Binomial 分布的矩母函数为  $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

**参数定义 (Parameter Definitions):**

- $n$ : 试验次数
- $p$ : 成功概率
- $X \sim \text{Bin}(n, p)$ : 成功次数

**目标 (Goal):** 证明  $M(t) = [(1-p) + pe^t]^n$ 。

**推导步骤 (Derivation Steps):**

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故  $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故  $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

**结论:** 因此,  $X \sim \text{Bin}(n, p)$  的矩母函数为  $M(t) = [(1-p) + pe^t]^n$ , 均值为  $np$ , 方差为  $np(1-p)$ 。■

**0.15. Negative Binomial 分布的矩母函数推导. 背景 (Background):** 负二项分布描述的是在获得  $r$  次成功之前所需的失败次数。

**参数定义 (Parameter Definitions):**

- $r$ : 成功次数
- $p$ : 单次成功概率
- $Y$ : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

**目标 (Goal):** 证明负二项分布的 mgf 为  $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$ ,  $t < -\log(1-p)$ 。

**推导步骤 (Derivation Steps):**

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令  $z = (1-p)e^t$ , 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求  $|(1-p)e^t| < 1$ , 即  $t < -\log(1-p)$ 。

**结论:** 负二项分布的 mgf 为  $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$ ,  $t < -\log(1-p)$ 。■

**0.16. 几何分布的无记忆性推导. 背景 (Background):** 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

**目标 (Goal):** 证明  $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

**推导步骤 (Derivation Steps):**

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

**结论:** 几何分布具有无记忆性: 已知前  $k$  次失败, 未来等待时间与最初等待时间分布相同。■

**0.17. 多项分布的协方差推导. 背景 (Background):** 多项分布是二项分布在多类别上的推广。

**目标 (Goal):** 求  $\text{cov}(X_i, X_j)$  for  $i \neq j$ 。

**推导步骤 (Derivation Steps):**

1. 多项分布的均值:  $X_i \sim \text{Bin}(n, p_i)$ , 故  $\mathbb{E}X_i = np_i$ 。
2. 对于  $i \neq j$ , 考虑  $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$ , 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入  $\text{var}(X_i) = np_i(1 - p_i)$  和  $\text{var}(X_j) = np_j(1 - p_j)$ :

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

**结论:** 对于多项分布,  $\text{cov}(X_i, X_j) = -np_i p_j$  ( $i \neq j$ ), 这反映了类别之间的竞争关系。■

**0.18. 超几何分布的均值与方差推导. 背景 (Background):** 超几何分布描述不放回抽样中的成功次数。

**参数定义 (Parameter Definitions):**

- $N$ : 总体容量
- $D$ : 总体中成功元素个数
- $n$ : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

**目标 (Goal):** 求  $\mathbb{E}X$  和  $\text{var}(X)$ 。

**推导步骤 (Derivation Steps):**

**均值推导:**

1. 使用指示变量法: 设  $I_j = 1$  if 第  $j$  次抽样抽到成功元素, 否则为 0。
2. 则  $X = \sum_{j=1}^n I_j$ 。
3. 由对称性,  $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故  $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

**方差推导:**

1. 首先计算  $\mathbb{E}[X(X-1)]$ :

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为  $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。



3. 共有  $n(n-1)$  对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用  $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$ :

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

**结论:** 超几何分布的均值为  $n \frac{D}{N}$ , 方差为  $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$ , 其中  $\frac{N-n}{N-1}$  是有限总体校正因子。■

**0.19. Poisson 近似二项分布的证明. 背景 (Background):** 当  $n$  很大、 $p$  很小时, 二项分布  $\text{Bin}(n, p)$  近似于  $\text{Poisson}(\lambda = np)$ 。

**目标 (Goal):** 证明若  $X_n \sim \text{Bin}(n, p_n)$  且  $np_n \rightarrow \lambda$ , 则  $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

**推导步骤 (Derivation Steps):**

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当  $n \rightarrow \infty$  时:

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} \rightarrow 1,$$

$$\left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是  $\text{Poisson}(\lambda)$  的 pmf。

**结论:** Poisson 分布是二项分布在“稀有事件”情形下的极限。■

**0.20. Poisson 分布的矩母函数推导. 背景 (Background):** Poisson 分布的矩母函数和均值、方差。

**目标 (Goal):** 求  $M(t)$  并计算  $\mathbb{E}X$  和  $\text{var}(X)$ 。

**推导步骤 (Derivation Steps):**

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故  $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数：

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故  $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

**结论：** Poisson 分布的均值和方差相等，都等于参数  $\lambda$ 。■

**0.21. 卡方分布与正态分布的关系. 背景 (Background)：** 卡方分布定义为标准正态平方和。

**目标 (Goal)：** 证明若  $Z \sim N(0, 1)$ ，则  $Z^2 \sim \chi^2(1)$ 。

**推导步骤 (Derivation Steps)：**

1.  $Z$  的 pdf 为  $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设  $Y = Z^2$ ，先求 cdf：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf：

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式：

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是  $\chi^2(1)$  的 pdf。

**结论：** 标准正态变量的平方服从自由度为 1 的卡方分布。■

**0.22. 卡方分布的可加性证明. 背景 (Background)：** 卡方分布满足可加性：独立卡方变量之和仍为卡方分布。

**目标 (Goal)：** 证明若  $X_1 \sim \chi^2(m)$ ， $X_2 \sim \chi^2(n)$  独立，则  $X_1 + X_2 \sim \chi^2(m+n)$ 。

**推导步骤 (Derivation Steps)：**

1. 由卡方分布与 Gamma 分布的关系： $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性（见定理 3.3.1）：若  $Y_1 \sim \Gamma(\alpha_1, \beta)$ ， $Y_2 \sim \Gamma(\alpha_2, \beta)$  独立，则  $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此：

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf： $\chi^2(r)$  的 mgf 为  $M(t) = (1-2t)^{-r/2}$ ，故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

**结论：** 卡方分布具有可加性，自由度可累加。■

**0.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background):** Beta 分布可由两个独立 Gamma 变量构造而来。

**目标 (Goal):** 证明若  $X_1 \sim \Gamma(\alpha, 1)$ ,  $X_2 \sim \Gamma(\beta, 1)$  独立, 令  $Y = X_1/(X_1 + X_2)$ , 则  $Y \sim \text{Beta}(\alpha, \beta)$ 。

**推导步骤 (Derivation Steps):**

1. 联合 pdf ( $x_1 > 0, x_2 > 0$ ):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换:  $y_1 = x_1 + x_2$ ,  $y_2 = \frac{x_1}{x_1+x_2}$ , 则  $x_1 = y_1 y_2$ ,  $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式:  $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见  $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$ ,  $Y_2 = \frac{X_1}{X_1+X_2} \sim \text{Beta}(\alpha, \beta)$ , 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

**结论:** Beta 分布可如此构造, 且  $Y_1$  和  $Y_2$  独立。■

**0.24. Beta 分布的均值与方差推导. 背景 (Background):** Beta 分布的均值和方差的计算。

**目标 (Goal):** 求  $\mathbb{E}Y$  和  $\text{var}(Y)$ , 其中  $Y \sim \text{Beta}(\alpha, \beta)$ 。

**推导步骤 (Derivation Steps):**

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

**结论:** Beta 分布的均值为  $\frac{\alpha}{\alpha + \beta}$ , 方差为  $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

**0.25. 正态分布的矩母函数推导. 背景 (Background):** 正态分布是最重要的连续分布之一。

**目标 (Goal):** 证明  $X \sim N(\mu, \sigma^2)$  的 mgf 为  $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

**推导步骤 (Derivation Steps):**

1.  $X = \sigma Z + \mu$ , 其中  $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故  $\mathbb{E}X = M'(0) = \mu$ ,  $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

**结论:** 正态分布  $N(\mu, \sigma^2)$  的 mgf 为  $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

**0.26. 标准化变换的推导. 背景 (Background):** 任何正态变量都可以通过标准化变换化为标准正态。

**目标 (Goal):** 证明若  $X \sim N(\mu, \sigma^2)$ , 则  $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

**推导步骤 (Derivation Steps):**

1. 变换  $Z = g(X) = \frac{X-\mu}{\sigma}$ , 其逆为  $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}\left[e^{(t/\sigma)X}\right] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是  $N(0, 1)$  的 mgf, 故  $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

**结论:** 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

**0.27.  $t$  分布的推导. 背景 (Background):**  $t$  分布由标准正态和卡方分布构造而来。

**目标 (Goal):** 证明若  $Z \sim N(0, 1)$ ,  $V \sim \chi^2(n)$  独立,  $T = \frac{Z}{\sqrt{V/n}}$ , 则  $T \sim t(n)$ 。

**推导步骤 (Derivation Steps):**

1. 变换:  $T = \frac{Z}{\sqrt{V/n}}$ ,  $U = V$ , 逆变换为  $Z = T\sqrt{U/n}$ ,  $V = U$ 。

2. Jacobian:  $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对  $u$  积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令  $y = \frac{u}{2}(1 + t^2/n)$ , 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为  $\frac{n}{n-2}$  (当  $n > 2$ )。

**结论:**  $t$  分布的 pdf 如上所示, 当  $n \rightarrow \infty$  时趋于标准正态分布。■

## 1. 问答记录

**1.1. 置信区间的频率派解释.** 问：很多初学者把置信区间的定义  $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$  误解为“ $\theta$  有  $1 - \alpha$  的概率落在区间  $[L, U]$  中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

**关键区别：**在频率派统计中， $\theta$  是**固定（但未知）的常数**，而区间  $[L, U]$  是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数  $\theta$  做概率陈述。

**正确的频率派解释：**如果我们重复抽样很多次，构造置信区间，那么  $100(1 - \alpha)\%$  的区间会包含真实的  $\theta$ 。但对于任何**单次**观察到的区间，真实的  $\theta$  要么在里面，要么不在里面——没有概率可言。

**举例说明：**设硬币抛掷  $n = 100$  次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如  $[0.45, 0.55]$ ，真实的  $\theta$  要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实  $\theta$  做 1000 次实验，约 950 次构造出的区间会包含  $\theta$ 。这就是“95% 置信度”的含义。

**贝叶斯派的理解则不同：**在贝叶斯统计中， $\theta$  被视为随机变量（需要先验分布），可以得到“后验可信区间”  $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于  $\theta$  的，可以合理地说是“ $\theta$  有 95% 的概率在这个区间内”。

**总结对比：**

| 表述                                             | 频率派有效?     | 含义                  |
|------------------------------------------------|------------|---------------------|
| $P(\theta \in [L, U]) = 0.95$                  | 否          | $\theta$ 是固定的       |
| “用此方法构造的区间中 95% 包含 $\theta$ ”                  | 是          | 概率在区间构造上            |
| $P(\theta \in [L, U] \mid \text{data}) = 0.95$ | 仅在贝叶斯框架下成立 | 需要对 $\theta$ 设定先验分布 |

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

**1.2. 贝叶斯先验分布的具体例子.** 问：在之前关于置信区间的回答中提到，贝叶斯学派认为  $\theta$  需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数  $\theta$  视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

### 例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为  $\theta$ ，抛掷  $n$  次得到  $Y$  次正面，则  $Y \sim \text{Binomial}(n, \theta)$ 。

**共轭先验：**我们为  $\theta$  选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

**直观理解:** Beta 分布是  $[0, 1]$  区间上的灵活分布, 参数  $(\alpha, \beta)$  控制先验信念:

- $\alpha = \beta = 1$ : 均匀分布 (无信息先验), 表示”对  $\theta$  一无所知”
- $\alpha = \beta = 2$ : 表示” $\theta$  可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$ : 表示” $\theta$  更可能接近 1” 的信念

**为什么选择 Beta 分布?** 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

## 例 2: 正态均值——正态先验

设  $X_1, \dots, X_n \sim N(\theta, \sigma^2)$ , 其中  $\sigma^2$  已知,  $\theta$  未知。

**共轭先验:** 我们为  $\theta$  选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中  $\mu_0$  是先验均值 (你对  $\theta$  的初始猜测),  $\tau_0^2$  是先验方差 (你对这个猜测的信心)。

**直观理解:**

- $\tau_0^2$  很大: 先验方差大, 表示对  $\theta$  的初始信念很模糊
- $\tau_0^2$  很小: 先验方差小, 表示对  $\theta$  有很强的先验信念
- $\mu_0 = 0$ : 如果你没有任何理由偏好正值或负值

**后验分布:** 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

## 为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数  $\theta$  的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为  $\theta \sim \text{Beta}(2, 2)$  (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如,  $\text{Beta}(1, 1)$  (均匀分布) 或 Jeffreys 先验  $\text{Beta}(1/2, 1/2)$ 。

**贝叶斯推断的本质**是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于  $\theta$  的信息——既包含先验信念, 也包含数据证据。

**先验 vs. 后验的直观理解：**

|    | 先验 (Prior) | 后验 (Posterior) |
|----|------------|----------------|
| 时机 | 看到数据之前     | 看到数据之后         |
| 性质 | 主观信念或无信息设定 | 更新后的知识状态       |

**总结：**先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

**1.3. 参数方法 vs. 非参数方法.** 问：在 Chapter 4 的 §4.1 中提到，当  $f(x)$  或  $p(x)$  的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及（直方图估计）
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

**简单区分：**

| 场景          | 方法               | 章节               |
|-------------|------------------|------------------|
| 分布形式未知      | 非参数方法（直方图、核密度估计） | Chapter 10       |
| 分布形式已知、参数未知 | 参数方法（MLE、CI、检验）  | <b>Chapter 4</b> |

**1.4. 无偏性过渡到 MLE 的动机.** 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差  $S^2$  是无偏的，但  $n^{-1} \sum (X_i - \bar{X})^2$  是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计（MLE）被提出的**动机**。

**逻辑链条：**

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

**具体例子：**

- $S^2$ （无偏）和  $\hat{\sigma}^2$ （有偏，但 MLE）
- 两者都常用，但各有用途
- “最优”需要更精确的定义（后续章节的 UMVUE）

**数学写作手法：**先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

**学习笔记.**