

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;

当 $n \rightarrow \infty$,

$$\lim_{n \rightarrow \infty} F_n(\bar{x}) = \begin{cases} 0, & \bar{x} < 0 \\ \frac{1}{2}, & \bar{x} = 0 \\ 1, & \bar{x} > 0 \end{cases} \quad (5.2.2)$$

这正是集中在 $\bar{x} = 0$ 的退化分布。因此 $\bar{X}_n$ 依分布收敛到该退化分布。⁵

EXAMPLE 5.5 (t 分布趋近正态分布). 设 T_n 服从自由度为 n 的 t 分布。其 cdf 为

$$F_n(t) = \int_{-\infty}^t \frac{\Gamma[(n+1)/2]}{\sqrt{\pi n} \Gamma(n/2)} \frac{1}{(1+y^2/n)^{(n+1)/2}} dy. \quad (5.2.3)$$

由 Lebesgue 控制收敛定理, 可以交换极限和积分次序。计算表明

$$\lim_{n \rightarrow \infty} F_n(t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} e^{-y^2/2} dy,$$

即标准正态分布的 cdf 。因此 $T_n \xrightarrow{D} N(0, 1)$ 。⁶

EXAMPLE 5.6 (均匀分布最大值的渐近指数分布). 回顾例 5.1.2: $Y_n = \max\{X_1, \dots, X_n\}$, 其中 $X_i \sim \text{Uniform}(0, \theta)$ 。考虑 $Z_n = n(\theta - Y_n)$ 。

对 $t \in (0, n\theta)$, 利用 Y_n 的 cdf , 可得

$$\mathbb{P}[Z_n \leq t] = 1 - \left(1 - \frac{t/\theta}{n}\right)^n \rightarrow 1 - e^{-t/\theta}. \quad (5.2.4)$$

因此 $Z_n \xrightarrow{D} \Gamma(1, \theta)$ (指数分布)。这是一个典型的“最大值标准化后收敛到指数分布”的例子。⁷

2.1. 依概率收敛与依分布收敛的关系.

THEOREM 5.5 (依概率收敛推出依分布收敛). 若 $X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{D} X$ 。heorem

证明梗概: 设 x 是 F_X 的连续点。对 $\epsilon > 0$,

$$F_{X_n}(x) = \mathbb{P}[X_n \leq x] \leq \mathbb{P}[X \leq x + \epsilon] + \mathbb{P}[|X_n - X| \geq \epsilon].$$

令 $n \rightarrow \infty$, 再令 $\epsilon \rightarrow 0$, 利用 $X_n \xrightarrow{P} X$ 可得上确界收敛到 $F_X(x)$ 。类似地可得到下界。⁸

注: 反过来一般不成立。但若极限 X 是常数, 则两者等价。

THEOREM 5.6 (常数情形下两种收敛等价). 若 $X_n \xrightarrow{D} b$ (常数), 则 $X_n \xrightarrow{P} b$ 。heorem

THEOREM 5.7 (和的极限分布). 设 $X_n \xrightarrow{D} X$ 且 $Y_n \xrightarrow{P} 0$ 。则 $X_n + Y_n \xrightarrow{D} X$ 。heorem

应用场景: 若难以直接证明 $X_n \xrightarrow{D} X$, 但容易证明 $Y_n \xrightarrow{D} X$ 且 $X_n - Y_n \xrightarrow{P} 0$, 则 $X_n = Y_n + (X_n - Y_n) \xrightarrow{D} X$ 。

⁵该例子的详细分析见附录 section 5.5。

⁶该证明利用了 Stirling 公式, 见附录 section 5.6。

⁷均匀分布最大值的完整推导见附录 section 5.7。

⁸完整证明见附录 section 5.8。

THEOREM 5.8 (连续函数变换保持依分布收敛). 设 $X_n \xrightarrow{D} X$ 且 g 是支撑上的连续函数, 则 $g(X_n) \xrightarrow{D} g(X)$ 。heorem

重要应用: 若 $Z_n \xrightarrow{D} Z \sim N(0, 1)$, 则 $Z_n^2 \xrightarrow{D} \chi^2(1)$ (因为 $Z^2 \sim \chi^2(1)$)。

THEOREM 5.9 (Slutsky 定理). 设 X_n, X, A_n, B_n 是随机变量, a, b 是常数。若 $X_n \xrightarrow{D} X$, $A_n \xrightarrow{P} a$, $B_n \xrightarrow{P} b$, 则

$$A_n + B_n X_n \xrightarrow{D} a + bX. \quad (5.2.5)$$

heorem

核心思想: 依分布收敛允许与依概率收敛的随机变量相乘——这是中心极限定理应用中最重要工具。⁹

2.2. 5.2.1 有界概率. 另一个有用的概念是随机变量序列的**概率有界性**。

DEFINITION 5.4 (有界概率). 称随机变量序列 $\{X_n\}$ 概率有界, 若对所有 $\epsilon > 0$, 存在常数 $B_\epsilon > 0$ 和整数 N_ϵ , 使得

$$n \geq N_\epsilon \Rightarrow \mathbb{P}[|X_n| \leq B_\epsilon] \geq 1 - \epsilon. \quad (5.2.6)$$

直观理解: 概率有界意味着序列的概率质量不会“逃逸”到无穷。

EXAMPLE 5.7 (标准正态分布是有界概率). 设 $X \sim N(0, 1)$ 。对 $\epsilon > 0$, 可以找到 η 使得 $\mathbb{P}[|X| \leq \eta] \geq 1 - \epsilon$ 。这是因为正态分布的尾部概率可以任意小。¹⁰

THEOREM 5.10 (依分布收敛蕴含概率有界). 若 $X_n \xrightarrow{D} X$, 则 $\{X_n\}$ 概率有界。heorem

EXAMPLE 5.8 (有界但不依分布收敛). 令 $n = 2m$ (偶数) 时 $X_{2m} = 2 + 1/(2m)$; $n = 2m - 1$ (奇数) 时 $X_{2m-1} = 1 + 1/(2m)$ 。则偶数子序列依分布收敛到常数 2, 奇数子序列依分布收敛到常数 1。整个序列不依分布收敛 (两个极限不同), 但所有项都在 $[1, 5/2]$ 中, 因此是概率有界的。

THEOREM 5.11 (乘积的收敛性). 设 $\{X_n\}$ 概率有界, $Y_n \xrightarrow{P} 0$ 。则 $X_n Y_n \xrightarrow{P} 0$ 。heorem

证明梗概: 由概率有界性, $|X_n|$ 在大概率下被某个常数控制。再由 $Y_n \rightarrow 0$ 的概率, 可得上确界收敛到 0。¹¹

2.3. 5.2.2 Δ 方法. Δ 方法是处理统计量函数渐近分布的强大工具。

背景: 在渐近理论中, 我们常需确定一个函数的分布。设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 如何求 $g(X_n)$ 的渐近分布?

关键工具——Taylor 展开: 若 $g(x)$ 在 x 处可微, 则

$$g(y) = g(x) + g'(x)(y - x) + o(|y - x|). \quad (5.2.7)$$

⁹Slutsky 定理的详细证明见附录 section 5.9。

¹⁰该性质的证明见附录 ??。

¹¹完整证明见附录 section 5.10。

记号 o_p 和 O_p (小 o 和大 O 的概率版本):

$$Y_n = o_p(X_n) \iff \frac{Y_n}{X_n} \xrightarrow{P} 0, \quad Y_n = O_p(X_n) \iff \frac{Y_n}{X_n} \text{ 概率有界.} \quad (5.2.8)$$

EXAMPLE 5.9 (Δ 方法的应用). 设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, g 在 θ 处可微且 $g'(\theta) \neq 0$ 。则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2). \quad (5.2.9)$$

这称为 Δ 方法。¹²

EXAMPLE 5.10 (卡方分布标准化). 在例 5.2.7 中, 我们证明了 $Z_n \sim \chi^2(n)$, 则

$$Y_n = \frac{Z_n - n}{\sqrt{2n}} \xrightarrow{D} N(0, 1). \quad (5.2.10)$$

利用 Δ 方法, 取 $g(t) = \sqrt{t}$, 则 $W_n = g(Z_n/(\sqrt{2n})) = (Z_n/(\sqrt{2n}))^{1/2}$ 的渐近分布为

$$\sqrt{n}[W_n - 1/2^{1/4}] \xrightarrow{D} N(0, 2^{-3/2}). \quad (5.2.11)$$

这在实践中非常有用, 例如当我们对卡方变量的标准差感兴趣时。¹³

2.4. 5.2.3 矩母函数技巧. 矩母函数 (MGF) 提供了一种确定渐近分布的系统方法。

THEOREM 5.12 (MGF 收敛定理). 设 $\{X_n\}$ 是随机变量序列, 每个 X_n 的 mgf $M_{X_n}(t)$ 在 $-h < t < h$ 上存在。设 X 的 mgf $M(t)$ 在 $|t| \leq h_1 \leq h$ 上存在。若

$$\lim_{n \rightarrow \infty} M_{X_n}(t) = M(t), \quad |t| \leq h_1,$$

则 $X_n \xrightarrow{D} X$ 。heorem

应用: 二项分布趋近泊松分布. 设 $Y_n \sim b(n, p)$, 其中 $p = \mu/n$ (μ 固定)。则

$$M_{Y_n}(t) = [1 + p(e^t - 1)]^n = \left[1 + \frac{\mu(e^t - 1)}{n}\right]^n \rightarrow e^{\mu(e^t - 1)},$$

这正是参数为 μ 的泊松分布的 mgf。因此当 n 大、 p 小时, 二项分布可用泊松分布近似。¹⁴

应用: 卡方分布标准化趋近正态. 设 $Z_n \sim \chi^2(n)$, 可计算其 mgf 并证明

$$\frac{Z_n - n}{\sqrt{2n}} \xrightarrow{D} N(0, 1). \quad (5.2.12)$$

¹² Δ 方法的完整推导见附录 section 5.11。

¹³卡方分布 Δ 方法的详细推导见附录 ??。

¹⁴该近似的误差分析和更精确的估计见附录 section 5.12。

3. 5.3 Central Limit Theorem

本节介绍统计学中最重要、最优雅的定理之一——中心极限定理 (CLT)。

背景：在第 3 章中，我们知道若 $X_1, \dots, X_n$ 来自均值为 μ 、方差为 σ^2 的正态分布，则

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \sim N(0, 1)$$

对每个正整数 n 都成立。

中心极限定理的核心发现：这一定理告诉我们，即使总体分布不是正态，只要满足某些温和条件（有限方差），上述统计量在大样本下仍然近似服从标准正态分布！

[中心极限定理 (CLT)] 设 $X_1, X_2, \dots, X_n$ 是来自均值为 μ 、正方差为 σ^2 的分布的随机样本。则随机变量

$$Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}$$

依分布收敛到标准正态随机变量：

$$Y_n \xrightarrow{D} N(0, 1). \quad (5.3.1)$$

实践意义：当 n 足够大（通常 $n \geq 30$ ），我们可以将 $\bar{X}$ 近似为 $N(\mu, \sigma^2/n)$ ，从而计算概率近似值。¹⁵

等价的表述：

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{D} N(0, \sigma^2). \quad (5.3.2)$$

这一表述在实践中更方便使用。

EXAMPLE 5.11 (均匀分布样本均值的概率). 设 $\bar{X}$ 是来自 $\text{Uniform}(0, 1)$ 分布、样本量为 75 的样本均值。对于该分布， $\mu = 1/2$ ， $\sigma^2 = 1/12$ 。

要计算 $P(0.45 < \bar{X} < 0.55)$ ，直接计算需要知道 $\bar{X}$ 的精确分布（由 75 个不同多项式片段组成的复杂函数）。但由 CLT，

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \approx N(0, 1),$$

因此

$$P(0.45 < \bar{X} < 0.55) \approx \Phi(1.5) - \Phi(-1.5) = 0.8663. \quad (5.3.3)$$

这个近似相当准确，尽管 $\bar{X}$ 的精确分布并不正态！¹⁶

EXAMPLE 5.12 (二项分布的正态近似). 设 $Y_n \sim b(n, p)$ 。则 $Y_n = \sum_{i=1}^n X_i$ ，其中 $X_i \sim \text{Bernoulli}(p)$ 。由 CLT，

$$\frac{Y_n - np}{\sqrt{np(1-p)}} = \frac{\sqrt{n}(\bar{X}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1). \quad (5.3.4)$$

因此， Y_n 近似服从 $N(np, np(1-p))$ 。

¹⁵中心极限定理的完整证明（包括 MGF 方法）见附录 section 5.13。

¹⁶均匀分布样本均值概率的详细计算见附录 section 5.14。

图 5.3.1 展示了 $b(10, 1/2)$ 的二项分布与 $N(5, 5/2)$ 正态近似的对比。即使 $n = 10$, 拟合效果已相当不错。

连续性校正: 对于离散分布, 通常使用 ± 0.5 的校正来提高近似精度。例如,

$$P(Y = 48, 49, 50, 51, 52) = P(47.5 < Y < 52.5). \quad (5.3.5)$$

EXAMPLE 5.13 (大样本比例推断). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(p)$, $\hat{p} = \bar{X}$. 则

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1 - \hat{p})/n}} \xrightarrow{D} N(0, 1). \quad (5.3.6)$$

这是大样本置信区间和假设检验 (第 4 章) 的基础。¹⁷

EXAMPLE 5.14 (卡方检验的渐近分布). 由 CLT 和定理 5.2.4,

$$\left(\frac{Y_n - np}{\sqrt{np(1-p)}} \right)^2 \xrightarrow{D} \chi^2(1). \quad (5.3.7)$$

这正是第 4 章中拟合优度 χ^2 检验的理论基础。¹⁸

EXAMPLE 5.15 (Δ 方法与函数变换). 设 $X_1, \dots, X_n$ 是来自均值为 μ 、方差为 σ^2 的分布的随机样本。由 CLT,

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{D} N(0, \sigma^2). \quad (5.3.8)$$

对连续变换 g , 由 Δ 方法,

$$\sqrt{n}[g(\bar{X}) - g(\mu)] \xrightarrow{D} N(0, \sigma^2[g'(\mu)]^2). \quad (5.3.9)$$

应用: 反正弦变换. 在二项情形 ($X_i \sim \text{Bernoulli}(p)$), 为了获得渐近方差与 p 无关的估计, 取 $g(p) = \arcsin(\sqrt{p})$, 则

$$\sqrt{n}[\arcsin(\sqrt{\bar{X}}) - \arcsin(\sqrt{p})] \xrightarrow{D} N(0, 1/4). \quad (5.3.10)$$

这一变换在方差稳定化中有重要应用。¹⁹

4. 5.4 Extensions to Multivariate Distributions

本节简要讨论随机向量序列的渐近概念。

为什么需要多元扩展? 在多参数统计中, 我们经常同时估计多个参数, 需要知道这些估计量的联合渐近分布。

记 $\mathbf{v} \in \mathbb{R}^p$ 的 Euclidean 范数为

$$\|\mathbf{v}\| = \sqrt{\sum_{i=1}^p v_i^2}. \quad (5.4.1)$$

¹⁷比例推断的详细讨论见附录 section 5.15。

¹⁸卡方检验的详细推导见附录 ??。

¹⁹方差稳定化变换的详细讨论见附录 section 5.16。

DEFINITION 5.5 (随机向量的依概率收敛). 设 $\{\mathbf{X}_n\}$ 是一列 p 维随机向量, $\mathbf{X}$ 是随机向量. 若对所有 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}[\|\mathbf{X}_n - \mathbf{X}\| \geq \epsilon] = 0,$$

则称 $\mathbf{X}_n \xrightarrow{P} \mathbf{X}$.

[向量收敛等价于分量收敛] $\mathbf{X}_n \xrightarrow{P} \mathbf{X}$ 当且仅当对每个 $j = 1, \dots, p$, $X_{nj} \xrightarrow{P} X_j$.

应用: 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 是 iid 随机向量, 均值向量为 $\boldsymbol{\mu}$, 协方差矩阵为 $\boldsymbol{\Sigma}$. 则样本均值向量

$$\bar{\mathbf{X}}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \xrightarrow{P} \boldsymbol{\mu}. \quad (5.4.2)$$

样本协方差矩阵 $\mathbf{S} \xrightarrow{P} \boldsymbol{\Sigma}$.

[多元中心极限定理] 设 $\{\mathbf{X}_n\}$ 是 iid 随机向量序列, 均值向量为 $\boldsymbol{\mu}$, 协方差矩阵为 $\boldsymbol{\Sigma}$ (正定). 则

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.3)$$

证明思路: 将问题转化为一元情形. 设 $\mathbf{t} \in \mathbb{R}^p$, 则 $\mathbf{t}'\mathbf{X}_i$ 是均值为 $\mathbf{t}'\boldsymbol{\mu}$ 、方差为 $\mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}$ 的随机变量. 对一维随机变量应用 CLT, 再利用 mgf 的性质可得多元情形.²⁰

[线性变换的正态性] 设 $\mathbf{X}_n \xrightarrow{D} N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. 则对任意常数矩阵 $\mathbf{A}$ ($m \times p$) 和向量 $\mathbf{b}$ (m 维),

$$\mathbf{A}\mathbf{X}_n + \mathbf{b} \xrightarrow{D} N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}'). \quad (5.4.4)$$

多元 Δ 方法: 设

$$\sqrt{n}(\mathbf{X}_n - \boldsymbol{\mu}_0) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}),$$

$g: \mathbb{R}^p \rightarrow \mathbb{R}^k$ 是可微变换, Jacobian 矩阵 $\mathbf{B} = \partial g / \partial \mathbf{x}$ 在 $\boldsymbol{\mu}_0$ 处非奇异. 则

$$\sqrt{n}(g(\mathbf{X}_n) - g(\boldsymbol{\mu}_0)) \xrightarrow{D} N_k(\mathbf{0}, \mathbf{B}_0 \boldsymbol{\Sigma} \mathbf{B}_0'). \quad (5.4.5)$$

Exercises

EXERCISE 5.1. 5.1 Sequence Convergence Let $\{a_n\}$ be a sequence of real numbers (degenerate random variables). Let a be a real number. Show that $a_n \rightarrow a$ is equivalent to $a_n \xrightarrow{P} a$.

EXERCISE 5.2. 5.2 Binomial Convergence Let $Y_n \sim b(n, p)$.

- (a) Prove that Y_n/n converges in probability to p . This is one form of the weak law of large numbers.
- (b) Prove that $1 - Y_n/n$ converges in probability to $1 - p$.
- (c) Prove that $(Y_n/n)(1 - Y_n/n)$ converges in probability to $p(1 - p)$.

²⁰多元 CLT 的完整证明见附录 section 5.17.

EXERCISE 5.3. **5.3 Variance Convergence** Let W_n denote a random variable with mean μ and variance b/n^p , where $p > 0$, μ , and b are constants (not functions of n). Prove that W_n converges in probability to μ .

Hint: Use Chebyshev's inequality.

EXERCISE 5.4. **5.4 Uniform Maximum CDF** Derive the cdf given in expression (5.1.6).

EXERCISE 5.5. **5.5 Sample Median Convergence** Consider the R function `consistmean` which produces the plot shown in Figure 5.1.1. Obtain a similar plot for the sample median when the distribution sampled is the $N(0, 1)$ distribution. Compare the mean and median plots.

EXERCISE 5.6. **5.6 Uniform Maximum Plot** Write an R function that obtains a plot similar to Figure 5.1.1 for the situation described in Example 5.1.2. For the plot choose $\theta = 10$.

EXERCISE 5.7. **5.7 Shifted Exponential Minimum** Let $X_1, \dots, X_n$ be iid random variables with common pdf

$$f(x) = \begin{cases} e^{-(x-\theta)} & x > \theta, -\infty < \theta < \infty \\ 0 & \text{elsewhere.} \end{cases} \quad (5.1.3)$$

This pdf is called the shifted exponential. Let $Y_n = \min\{X_1, \dots, X_n\}$. Prove that $Y_n \rightarrow \theta$ in probability by first obtaining the cdf of Y_n .

EXERCISE 5.8. **5.8 Ratio Convergence** Using the assumptions behind the confidence interval given in expression (4.3.3), show that

$$\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} / \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \xrightarrow{P} 1.$$

EXERCISE 5.9. **5.9 Shifted Exponential Mean** For Exercise 5.1.7, obtain the mean of Y_n . Is Y_n an unbiased estimator of θ ? Obtain an unbiased estimator of θ based on Y_n .

EXERCISE 5.10. **5.10 Normal Sample Mean Limit** Let $\bar{X}_n$ denote the mean of a random sample of size n from a distribution that is $N(\mu, \sigma^2)$. Find the limiting distribution of $\bar{X}_n$.

EXERCISE 5.11. **5.11 Exponential Minimum Limit** Let Y_1 denote the minimum of a random sample of size n from a distribution that has pdf $f(x) = e^{-(x-\theta)}$, $\theta < x < \infty$, zero elsewhere. Let $Z_n = n(Y_1 - \theta)$. Investigate the limiting distribution of Z_n .

EXERCISE 5.12. **5.12 Maximum Limit Distribution** Let Y_n denote the maximum of a random sample of size n from a distribution of the continuous type that has cdf $F(x)$ and pdf $f(x) = F'(x)$. Find the limiting distribution of $Z_n = n[1 - F(Y_n)]$.

EXERCISE 5.13. **5.13** *Second Minimum Limit* Let Y_2 denote the second smallest item of a random sample of size n from a distribution of the continuous type that has cdf $F(x)$ and pdf $f(x) = F'(x)$. Find the limiting distribution of $W_n = nF(Y_2)$.

EXERCISE 5.14. **5.14** *No Limiting Distribution* Let the pmf of Y_n be $p_n(y) = 1$, $y = n$, zero elsewhere. Show that Y_n does not have a limiting distribution. (In this case, the probability has "escaped" to infinity.)

EXERCISE 5.15. **5.15** *Normal Sum No Limit* Let $X_1, X_2, \dots, X_n$ be a random sample of size n from a distribution that is $N(\mu, \sigma^2)$, where $\sigma^2 > 0$. Show that the sum $Z_n = \sum_{i=1}^n X_i$ does not have a limiting distribution.

EXERCISE 5.16. **5.16** *Gamma Limit* Let X_n have a gamma distribution with parameter $\alpha = n$ and β , where β is not a function of n . Let $Y_n = X_n/n$. Find the limiting distribution of Y_n .

EXERCISE 5.17. **5.17** *Chi-Square Ratio Limit* Let Z_n be $\chi^2(n)$ and let $W_n = Z_n/n^2$. Find the limiting distribution of W_n .

EXERCISE 5.18. **5.18** *Chi-Square Probability* Let X be $\chi^2(50)$. Using the limiting distribution discussed in Example 5.2.7, approximate $P(40 < X < 60)$. Compare your answer with that calculated by R .

EXERCISE 5.19. **5.19** *Poisson Binomial Approximation* Let $p = 0.95$ be the probability that a man, in a certain age group, lives at least 5 years.

- (a) If we are to observe 60 such men and if we assume independence, use R to compute the probability that at least 56 of them live 5 or more years.
 - (b) Find an approximation to the result of part (a) by using the Poisson distribution.
- Hint: Redefine p to be 0.05 and $1 - p = 0.95$.

EXERCISE 5.20. **5.20** *Poisson to Normal* Let the random variable Z_n have a Poisson distribution with parameter $\mu = n$. Show that the limiting distribution of the random variable $Y_n = (Z_n - n)/\sqrt{n}$ is normal with mean zero and variance 1.

EXERCISE 5.21. **5.21** *Normal Sample Chi-Square* Let $\bar{X}_n$ denote the mean of a random sample of size 100 from a distribution that is $\chi^2(50)$. Compute an approximate value of $P(49 < \bar{X} < 51)$.

EXERCISE 5.22. **5.22** *Gamma Sample Mean* Let $\bar{X}_n$ denote the mean of a random sample of size 128 from a gamma distribution with $\alpha = 2$ and $\beta = 4$. Approximate $P(7 < \bar{X} < 9)$.

EXERCISE 5.23. **5.23** *Binomial Probability* Let Y be $b(72, 1/3)$. Approximate $P(22 \leq Y \leq 28)$.

EXERCISE 5.24. **5.24** *Beta Sample Mean* Compute an approximate probability that the mean of a random sample of size 15 from a distribution having pdf $f(x) = 3x^2$, $0 < x < 1$, zero elsewhere, is between $\frac{3}{5}$ and $\frac{4}{5}$.

EXERCISE 5.25. **5.25** *Discrete Sample Sum* Let Y denote the sum of the observations of a random sample of size 12 from a distribution having pmf $p(x) = 1/6$, $x = 1, 2, 3, 4, 5, 6$, zero elsewhere. Compute an approximate value of $P(36 \leq Y \leq 48)$.

Hint: Since the event of interest is $Y = 36, 37, \dots, 48$, rewrite the probability as $P(35.5 < Y < 48.5)$.

EXERCISE 5.26. **5.26** *Binomial Proportion* Let Y be $b(400, 1/5)$. Compute an approximate value of $P(0.25 < Y/400)$.

EXERCISE 5.27. **5.27** *Binomial Point Probability* If Y is $b(100, 1/2)$, approximate the value of $P(Y = 50)$.

EXERCISE 5.28. **5.28** *Sample Size for Proportion* Let Y be $b(n, 0.55)$. Find the smallest value of n such that (approximately) $P(Y/n > 1/2) \geq 0.95$.

EXERCISE 5.29. **5.29** *Tail Probability Approximation* Let $f(x) = 1/x^2$, $1 < x < \infty$, zero elsewhere, be the pdf of a random variable X . Consider a random sample of size 72 from the distribution having this pdf. Compute approximately the probability that more than 50 of the observations of the random sample are less than 3.

EXERCISE 5.30. **5.30** *Rounding Error Approximation* Forty-eight measurements are recorded to several decimal places. Each of these 48 numbers is rounded off to the nearest integer. The sum of the original 48 numbers is approximated by the sum of these integers. If we assume that the errors made by rounding off are iid and have a uniform distribution over the interval $(-1/2, 1/2)$, compute approximately the probability that the sum of the integers is within two units of the true sum.

EXERCISE 5.31. **5.31** *Cube Transformation* We know that $\bar{X}$ is approximately $N(\mu, \sigma^2/n)$ for large n . Find the approximate distribution of $u(\bar{X}) = \bar{X}^3$, provided that $\mu \neq 0$.

EXERCISE 5.32. **5.32** *Variance Stabilization* Let $X_1, X_2, \dots, X_n$ be a random sample from a Poisson distribution with mean μ . Thus, $Y = \sum_{i=1}^n X_i$ has a Poisson distribution with mean $n\mu$. Moreover, $\bar{X} = Y/n$ is approximately $N(\mu, \mu/n)$ for large n . Show that $u(Y/n) = \sqrt{Y/n}$ is a function of Y/n whose variance is essentially free of μ .

EXERCISE 5.33. **5.33** *Proportion CLT* Using the notation of Example 5.3.5, show that equation (5.3.6) is true.

EXERCISE 5.34. **5.34** *Gamma Asymptotics* Assume that $X_1, \dots, X_n$ is a random sample from a $\Gamma(1, \beta)$ distribution. Determine the asymptotic distribution of $\sqrt{n}(\bar{X} - \beta)$. Then find a transformation $g(\bar{X})$ whose asymptotic variance is free of β .

EXERCISE 5.35. **5.35 Multivariate Convergence** Let $\{\mathbf{X}_n\}$ be a sequence of p -dimensional random vectors. Show that

$$\mathbf{X}_n \xrightarrow{D} N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \text{ if and only if } \mathbf{a}'\mathbf{X}_n \xrightarrow{D} N_1(\mathbf{a}'\boldsymbol{\mu}, \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a}),$$

for all vectors $\mathbf{a} \in \mathbb{R}^p$.

EXERCISE 5.36. **5.36 Uniform Vector Convergence** Let $X_1, \dots, X_n$ be a random sample from a $\text{Uniform}(a, b)$ distribution. Let $Y_1 = \min X_i$ and let $Y_2 = \max X_i$. Show that $(Y_1, Y_2)'$ converges in probability to the vector $(a, b)'$.

本章小结

核心概念：

- 依概率收敛： $X_n \xrightarrow{P} X$ ，概率质量越来越集中在目标附近
- 依分布收敛： $X_n \xrightarrow{D} X$ ，分布函数在连续点处收敛
- 弱大数定律：样本均值依概率收敛到总体均值
- 中心极限定理：标准化样本均值趋向标准正态分布
- Slutsky 定理：允许依概率收敛的随机变量参与依分布收敛的线性组合
- Δ 方法：处理统计量函数渐近分布的工具
- 一致性：估计量的基本要求， $T_n \xrightarrow{P} \theta$

重要公式：

场景	渐近分布
$\sqrt{n}(\bar{X} - \mu)/\sigma$	$N(0, 1)$ (CLT)
$\bar{X}_n$	$N(\mu, \sigma^2/n)$ (大样本)
$\sqrt{n}(g(\bar{X}) - g(\mu))$	$N(0, \sigma^2[g'(\mu)]^2)$ (Δ 方法)
$\hat{p}$ 样本比例	$N(p, p(1-p)/n)$ (大样本)
$(Y_n - np)/\sqrt{np(1-p)}$	$N(0, 1)$ (二项正态近似)

收敛关系图：

依概率收敛 + 连续函数 $\Rightarrow$ 依概率收敛

依概率收敛 $\Rightarrow$ 依分布收敛

依分布收敛 (常数) $\Leftrightarrow$ 依概率收敛

5. 附录：公式推导

5.1. 弱大数定律的完整证明. 背景 (Background)：弱大数定律 (WLLN) 是最基本的渐近结果之一，说明样本均值依概率收敛到总体均值。

已知条件 (Given)：

- $X_1, X_2, \dots, X_n$ 是 iid 随机变量
- $E(X_i) = \mu$
- $\text{Var}(X_i) = \sigma^2 < \infty$
- $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$

目标 (Goal): 证明 $\bar{X}_n \xrightarrow{P} \mu$ 。

推导步骤 (Derivation Steps):

1. 计算 $\bar{X}_n$ 的均值和方差:

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu,$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

2. 对任意 $\epsilon > 0$, 应用 Chebyshev 不等式:

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}.$$

3. 当 $n \rightarrow \infty$ 时, 右边趋于 0, 故

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) = 0.$$

结论: 由定义, $\bar{X}_n \xrightarrow{P} \mu$ 。

5.2. 依概率收敛性质证明. 背景: 证明若 $X_n \xrightarrow{P} X$ 和 $Y_n \xrightarrow{P} Y$, 则 $X_n Y_n \xrightarrow{P} XY$ 。

推导步骤:

1. 利用恒等式:

$$X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2.$$

2. 由定理 5.1.3 (标量乘积收敛) 和定理 5.1.2 (和的收敛), $X_n^2 \xrightarrow{P} X^2$, $Y_n^2 \xrightarrow{P} Y^2$, $(X_n - Y_n)^2 \xrightarrow{P} (X - Y)^2$ 。

3. 因此

$$X_n Y_n \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY.$$

证毕。

5.3. 样本方差一致性的详细推导. 背景: 证明样本方差 S_n^2 是 σ^2 的一致估计量。

已知条件:

- $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$
- $E(X_i^4) < \infty$ (有限四阶矩)

推导步骤:

1. 由弱大数定律:

$$\bar{X}_n \xrightarrow{P} \mu, \quad \frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E(X_1^2).$$

2. 利用恒等式:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right).$$

3. 由连续映射定理 (定理 5.1.4), $\bar{X}_n^2 \xrightarrow{P} \mu^2$ 。

4. 因此

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \xrightarrow{P} E(X_1^2) - \mu^2 = \sigma^2.$$

5. 由于 $\frac{n}{n-1} \rightarrow 1$, 故 $S_n^2 \xrightarrow{P} \sigma^2$ 。

结论: S_n^2 是 σ^2 的一致估计。

5.4. 均匀分布最大值分析. 背景: 分析 $\text{Uniform}(0, \theta)$ 分布最大值的渐近行为。

已知条件: $Y_n = \max\{X_1, \dots, X_n\}$, 其中 $X_i \sim \text{Uniform}(0, \theta)$ 。

推导步骤:

1. 求 Y_n 的 CDF:

$$F_{Y_n}(t) = \mathbb{P}(Y_n \leq t) = \mathbb{P}(X_1 \leq t, \dots, X_n \leq t) = [F_X(t)]^n = \left(\frac{t}{\theta}\right)^n,$$

对 $0 < t \leq \theta$ 。

2. 求 Y_n 的 PDF:

$$f_{Y_n}(t) = \frac{d}{dt} F_{Y_n}(t) = \frac{n}{\theta^n} t^{n-1}, \quad 0 < t \leq \theta.$$

3. 计算期望:

$$E(Y_n) = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{n+1} \theta.$$

关键发现: $Y_n \xrightarrow{P} \theta$, 因为对任意 $\epsilon > 0$,

$$\mathbb{P}(|Y_n - \theta| \geq \epsilon) = \mathbb{P}(Y_n \leq \theta - \epsilon) = \left(\frac{\theta - \epsilon}{\theta}\right)^n \rightarrow 0.$$

渐近分布: 标准化后 $n(\theta - Y_n) \xrightarrow{D} \Gamma(1, \theta)$ (见例 5.2.4)。

5.5. 退化分布的例子. 背景: 说明为什么在 CDF 的间断点处不要求收敛。

例子: 设 X_n 所有概率质量集中在 $1/n$, X 所有概率质量集中在 0。

(1) 若 $x < 0$, 则 $F_{X_n}(x) = 0 = F_X(x)$ 。

(2) 若 $x > 0$, 则 $F_{X_n}(x) = 1 = F_X(x)$ 。

(3) 若 $x = 0$ (F_X 的间断点), 则 $F_{X_n}(0) = 0 \neq 1 = F_X(0)$ 。

因此 $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$ 对所有 $x \in C(F_X)$ (即 $x \neq 0$) 成立, 故 $X_n \xrightarrow{D} X$ 。

5.6. Stirling 公式. 背景: Stirling 公式在渐近分析中非常重要。

公式:

$$\Gamma(k+1) \approx \sqrt{2\pi} k^{k+1/2} e^{-k}. \quad (5.2.2)$$

应用: 在例 5.2.3 中, 证明 t 分布趋向标准正态分布时, 需要用到

$$\lim_{n \rightarrow \infty} \frac{\Gamma[(n+1)/2]}{\sqrt{n/2} \Gamma(n/2)} = 1.$$

使用 Stirling 公式:

$$\frac{\Gamma[(n+1)/2]}{\sqrt{n/2} \Gamma(n/2)} \approx \frac{\sqrt{2\pi} (n/2)^{n/2+1/2} e^{-n/2}}{\sqrt{n/2} \sqrt{2\pi} (n/2-1)^{n/2-1/2} e^{-(n/2-1)}} = 1.$$

5.7. 均匀分布到指数分布的极限. 背景：证明 $n(\theta - Y_n) \xrightarrow{D} \Gamma(1, \theta)$ 。

推导：

对 $t > 0$,

$$\mathbb{P}[n(\theta - Y_n) \leq t] = \mathbb{P}[Y_n \geq \theta - t/n] = 1 - F_{Y_n}(\theta - t/n).$$

由 $F_{Y_n}(t) = (t/\theta)^n$ (对 $0 < t \leq \theta$),

$$1 - F_{Y_n}(\theta - t/n) = 1 - \left(\frac{\theta - t/n}{\theta}\right)^n = 1 - \left(1 - \frac{t}{n\theta}\right)^n.$$

令 $n \rightarrow \infty$,

$$\lim_{n \rightarrow \infty} \left(1 - \frac{t}{n\theta}\right)^n = e^{-t/\theta}.$$

因此

$$\lim_{n \rightarrow \infty} \mathbb{P}[n(\theta - Y_n) \leq t] = 1 - e^{-t/\theta},$$

这正是 $\Gamma(1, \theta)$ (指数分布) 的 CDF。

5.8. 依概率收敛推出依分布收敛的证明. 背景：证明定理 5.2.1。

目标：若 $X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{D} X$ 。

推导步骤：

1. 设 x 是 F_X 的连续点。对 $\epsilon > 0$,

$$F_{X_n}(x) = \mathbb{P}[X_n \leq x] = \mathbb{P}[X_n \leq x, |X_n - X| < \epsilon] + \mathbb{P}[X_n \leq x, |X_n - X| \geq \epsilon].$$

2. 第一个概率 $\leq \mathbb{P}[X \leq x + \epsilon]$, 第二个概率 $\leq \mathbb{P}[|X_n - X| \geq \epsilon]$ 。因此

$$F_{X_n}(x) \leq F_X(x + \epsilon) + \mathbb{P}[|X_n - X| \geq \epsilon].$$

3. 取上确界并令 $n \rightarrow \infty$ (利用 $X_n \xrightarrow{P} X$), 再令 $\epsilon \rightarrow 0$ (利用 x 是连续点), 可得

$$\overline{\lim}_{n \rightarrow \infty} F_{X_n}(x) \leq F_X(x).$$

4. 类似地可得

$$\underline{\lim}_{n \rightarrow \infty} F_{X_n}(x) \geq F_X(x).$$

5. 因此 $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$ 。

证毕。

5.9. Slutsky 定理的详细证明. 背景：Slutsky 定理是连接依概率收敛和依分布收敛的关键工具。

定理陈述：若 $X_n \xrightarrow{D} X$, $A_n \xrightarrow{P} a$, $B_n \xrightarrow{P} b$, 则 $A_n + B_n X_n \xrightarrow{D} a + bX$ 。

推导步骤：

1. 首先证明 $B_n X_n \xrightarrow{D} bX$ 。

考虑 $B_n X_n = bX_n + (B_n - b)X_n$ 。由 $B_n \xrightarrow{P} b$, 有 $B_n - b \xrightarrow{P} 0$ 。

2. 由定理 5.2.6 (依分布收敛蕴含概率有界), $\{X_n\}$ 概率有界。

3. 应用定理 5.2.7 (概率有界序列与依概率收敛到零的乘积趋于零):

$$(B_n - b)X_n \xrightarrow{P} 0.$$

4. 由定理 5.2.3 (和的极限分布), $bX_n + (B_n - b)X_n \xrightarrow{D} bX$ 。

5. 再考虑 $A_n + B_nX_n = a + bX + (A_n - a) + (B_nX_n - bX)$ 。

由于 $(A_n - a) \xrightarrow{P} 0$ 和 $(B_nX_n - bX) \xrightarrow{P} 0$, 再次应用定理 5.2.3 可得

$$A_n + B_nX_n \xrightarrow{D} a + bX.$$

证毕。

核心洞察: Slutsky 定理允许我们将依概率收敛的随机变量”替换”为其极限常数, 而不影响依分布收敛性。

5.10. 概率有界与乘积收敛的证明. 背景: 证明定理 5.2.7。

目标: 若 $\{X_n\}$ 概率有界, $Y_n \xrightarrow{P} 0$, 则 $X_nY_n \xrightarrow{P} 0$ 。

推导步骤:

1. 由概率有界性, 对 $\epsilon > 0$, 存在 B_ϵ 和 N_ϵ 使得

$$n \geq N_\epsilon \Rightarrow \mathbb{P}[|X_n| \leq B_\epsilon] \geq 1 - \epsilon.$$

2. 对任意 $\delta > 0$,

$$\mathbb{P}[|X_nY_n| \geq \delta] = \mathbb{P}[|X_nY_n| \geq \delta, |X_n| \leq B_\epsilon] + \mathbb{P}[|X_nY_n| \geq \delta, |X_n| > B_\epsilon].$$

3. 第一个概率 $\leq \mathbb{P}[|Y_n| \geq \delta/B_\epsilon]$, 第二个概率 $\leq \mathbb{P}[|X_n| > B_\epsilon] \leq \epsilon$ 。

4. 由于 $Y_n \xrightarrow{P} 0$, 当 n 足够大时, 第一个概率 $< \epsilon$ 。

5. 因此对足够大的 n , $\mathbb{P}[|X_nY_n| \geq \delta] \leq 2\epsilon$ 。

由 ϵ 和 δ 的任意性, $X_nY_n \xrightarrow{P} 0$ 。

证毕。

5.11. Δ 方法的完整推导. 背景: Δ 方法提供了一种计算统计量函数渐近分布的系统方法。

定理陈述: 设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, g 在 θ 处可微且 $g'(\theta) \neq 0$ 。则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

推导步骤:

1. 由 Taylor 展开 (带余项):

$$g(X_n) = g(\theta) + g'(\theta)(X_n - \theta) + o_p(|X_n - \theta|).$$

2. 两边乘以 $\sqrt{n}$:

$$\sqrt{n}(g(X_n) - g(\theta)) = g'(\theta)\sqrt{n}(X_n - \theta) + o_p(\sqrt{n}|X_n - \theta|).$$

3. 由假设, $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 故 $\{\sqrt{n}|X_n - \theta|\}$ 概率有界。

4. 由 o_p 的定义, $o_p(\sqrt{n}|X_n - \theta|) \xrightarrow{P} 0$ 。

5. 应用 Slutsky 定理（或更精确地，定理 5.2.3），可得

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

证毕。

应用举例：卡方分布的平方根。设 $Z_n \sim \chi^2(n)$ ，则

$$\sqrt{n} \left(\frac{Z_n}{n} - 1 \right) \xrightarrow{D} N(0, 2).$$

取 $g(t) = \sqrt{t}$ ，则 $g'(1) = 1/2$ ，故

$$\sqrt{n}(\sqrt{Z_n/n} - 1) \xrightarrow{D} N(0, 2 \cdot (1/2)^2) = N(0, 1/2).$$

5.12. 二项分布的正态近似误差分析. 背景：二项分布 $b(n, p)$ 在大样本下可用正态分布近似。

误差分析：

设 $Y \sim b(n, p)$ ， $\mu = np$ ， $\sigma^2 = np(1-p)$ 。则

$$Z = \frac{Y - \mu}{\sigma} \xrightarrow{D} N(0, 1).$$

Berry-Esseen 不等式给出了收敛速度的估计：

$$\sup_x |\mathbb{P}(Z \leq x) - \Phi(x)| \leq \frac{C \cdot \rho}{\sigma^3 \sqrt{n}},$$

其中 $\rho = E(|X - \mu|^3)$ ， C 是某个绝对常数（约 0.4748）。

实践意义：当 $np(1-p) \geq 10$ 时，正态近似效果较好。

连续性校正的效果：对于离散分布，使用 ± 0.5 的校正通常可以将误差减少一半。

5.13. 中心极限定理的 MGF 证明. 背景：中心极限定理（CLT）的矩母函数证明。

假设： $X_1, \dots, X_n$ 是 iid 随机变量， $E(X_i) = \mu$ ， $\text{Var}(X_i) = \sigma^2$ ，矩母函数 $M(t) = E(e^{tX})$ 在 0 的邻域内存在。

目标：证明

$$Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \xrightarrow{D} N(0, 1).$$

推导步骤：

1. 考虑 $X_i - \mu$ 的矩母函数 $m(t) = E(e^{t(X_i - \mu)})$ 。则 $m(0) = 1$ ， $m'(0) = 0$ ， $m''(0) = \sigma^2$ 。

2. 由 Taylor 公式，存在 ξ （介于 0 和 t 之间）使得

$$m(t) = 1 + \frac{\sigma^2 t^2}{2} + \frac{[m''(\xi) - \sigma^2] t^2}{2}. \quad (5.3.1)$$

3. Y_n 的矩母函数为

$$M_{Y_n}(t) = E \left[\exp \left(t \frac{\sum X_i - n\mu}{\sqrt{n}\sigma} \right) \right] = [m(t/(\sigma\sqrt{n}))]^n. \quad (5.3.2)$$

4. 将 $t/(\sigma\sqrt{n})$ 代入 (5.3.1)：

$$m \left(\frac{t}{\sigma\sqrt{n}} \right) = 1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2] t^2}{2n\sigma^2},$$

其中 ξ 介于 0 和 $t/(\sigma\sqrt{n})$ 之间。

5. 因此

$$M_{Y_n}(t) = \left[1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2]t^2}{2n\sigma^2} \right]^n.$$

6. 由于 $m''(t)$ 在 0 处连续, 且 $\xi \rightarrow 0$ 当 $n \rightarrow \infty$, 故

$$\lim_{n \rightarrow \infty} [m''(\xi) - \sigma^2] = 0.$$

7. 应用极限定理 (5.2.16):

$$\lim_{n \rightarrow \infty} M_{Y_n}(t) = \lim_{n \rightarrow \infty} \left[1 + \frac{t^2}{2n} \right]^n = e^{t^2/2},$$

这正是 $N(0, 1)$ 的矩母函数。

结论: 由矩母函数收敛定理, $Y_n \xrightarrow{D} N(0, 1)$ 。

证毕。

注: 若不使用矩母函数而使用特征函数, 则证明对所有分布成立 (特征函数总是存在的)。

5.14. 均匀分布样本均值的概率计算. 背景: 计算 $P(0.45 < \bar{X} < 0.55)$ 的近似值。

已知条件:

- $X_i \sim \text{Uniform}(0, 1)$
- $n = 75$
- $\mu = 1/2, \sigma^2 = 1/12$

推导步骤:

1. 由 CLT,

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \approx N(0, 1).$$

2. 标准化:

$$P(0.45 < \bar{X} < 0.55) = P\left(\frac{\sqrt{n}(0.45 - \mu)}{\sigma} < \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} < \frac{\sqrt{n}(0.55 - \mu)}{\sigma}\right).$$

3. 代入数值:

$$\frac{\sqrt{75}(0.5 - 0.5)}{1/\sqrt{12}} = 0, \quad \frac{\sqrt{75}(0.55 - 0.5)}{1/\sqrt{12}} = \sqrt{75} \cdot 0.05 \cdot \sqrt{12} \approx 1.5.$$

4. 因此

$$P(0.45 < \bar{X} < 0.55) \approx \Phi(1.5) - \Phi(-1.5) = 2\Phi(1.5) - 1 \approx 2(0.9332) - 1 = 0.8664.$$

精确值比较: 使用 R 计算精确概率约为 0.864, 近似值 0.866 非常接近。

5.15. 比例推断的详细讨论. 背景：大样本比例推断的理论基础。

设 $X_1, \dots, X_n \sim \text{Bernoulli}(p)$, $\hat{p} = \bar{X}$ 。

推导步骤：

1. 由 CLT,

$$\frac{\sqrt{n}(\hat{p} - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1). \quad (5.3.4)$$

2. 但 p 未知! 用 $\hat{p}$ 替代 p 。需证明

$$\frac{\hat{p}(1-\hat{p})}{p(1-p)} \xrightarrow{P} 1. \quad (5.3.6)$$

3. 由弱大数定律, $\hat{p} \xrightarrow{P} p$, 再由连续映射定理,

$$\hat{p}(1-\hat{p}) \xrightarrow{P} p(1-p).$$

4. 由 Slutsky 定理,

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})/n}} = \frac{\sigma}{\sqrt{\hat{p}(1-\hat{p})}} \cdot \frac{\sqrt{n}(\hat{p} - p)}{\sigma} \xrightarrow{D} N(0, 1). \quad (5.3.7)$$

这正是大样本比例置信区间和假设检验的理论基础。

置信区间： p 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]. \quad (5.3.8)$$

假设检验： 检验 $H_0: p = p_0$ 的检验统计量为

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} \xrightarrow{H_0} N(0, 1). \quad (5.3.9)$$

5.16. 方差稳定化变换. 背景： 在例 5.3.7 中, 我们寻求一个变换使渐近方差与参数无关。

问题： 设 $X \sim \text{Binomial}(1, p)$, $\hat{p} = \bar{X}$ 。求变换 g 使得 $\text{Var}[\sqrt{n}g(\hat{p})]$ 与 p 无关。

推导步骤：

1. 由 Δ 方法,

$$\text{Var}[\sqrt{n}g(\hat{p})] \approx \sigma^2[g'(p)]^2 = p(1-p)[g'(p)]^2. \quad (5.3.10)$$

2. 要求 $p(1-p)[g'(p)]^2 = c$ (常数), 即

$$g'(p) = \frac{c}{\sqrt{p(1-p)}}. \quad (5.3.11)$$

3. 积分得

$$g(p) = c \int \frac{1}{\sqrt{p(1-p)}} dp = 2c \arcsin(\sqrt{p}) + \text{常数}. \quad (5.3.12)$$

4. 取 $c = 1/2$ 可得最简单的形式 $g(p) = \arcsin(\sqrt{p})$ 。

结论： 变换 $g(\hat{p}) = \arcsin(\sqrt{\hat{p}})$ 的渐近方差为 $1/(4n)$, 与 p 无关。²¹

²¹ 方差稳定化变换的更多应用见 DeGroot 和 Schervish 的《概率与统计》。

5.17. 多元中心极限定理的证明. 背景: 多元中心极限定理说明样本均值向量的标准化形式依分布收敛到多元正态分布。

定理陈述: 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 是 iid 随机向量, 均值向量为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ (正定)。则

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.3)$$

推导步骤:

1. 对任意固定向量 $\mathbf{t} \in \mathbb{R}^p$, 考虑随机变量 $W_i = \mathbf{t}'\mathbf{X}_i$ 。

2. 则 $E(W_i) = \mathbf{t}'\boldsymbol{\mu}$, $\text{Var}(W_i) = \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}$ 。

3. 对 $W_1, \dots, W_n$ 应用一元 CLT:

$$\sqrt{n}(\bar{W}_n - \mathbf{t}'\boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}). \quad (5.4.8)$$

4. 但 $\bar{W}_n = \mathbf{t}'\bar{\mathbf{X}}_n$, 故

$$\sqrt{n}(\mathbf{t}'\bar{\mathbf{X}}_n - \mathbf{t}'\boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}). \quad (5.4.9)$$

5. 由 Cramer-Wold 定理 (若对所有 $\mathbf{t}$, $\mathbf{t}'\mathbf{X}_n \xrightarrow{D} \mathbf{t}'\mathbf{X}$, 则 $\mathbf{X}_n \xrightarrow{D} \mathbf{X}$), 可得

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.10)$$

证毕。

注: Cramer-Wold 定理的证明依赖于特征函数的一致有界性和逆转公式。

1. 附录：公式推导

2. 第二章公式推导

2.1. 边缘分布公式推导. 背景：已知联合分布，如何得到单个变量的边缘分布？

目标：从联合 pmf/pdf 推导边缘 pmf/pdf 的计算公式。

推导步骤：

离散型：设 (X_1, X_2) 的联合 pmf 为 $p_{X_1, X_2}(x_1, x_2)$ 。

1. 由边缘 pmf 的定义， X_1 的边缘 pmf 为 $p_{X_1}(x_1) = \mathbb{P}(X_1 = x_1)$ 。

2. 事件 $\{X_1 = x_1\}$ 可以分解为与 X_2 的联合事件：

$$\mathbb{P}(X_1 = x_1) = \sum_{x_2} \mathbb{P}(X_1 = x_1, X_2 = x_2).$$

3. 因此边缘 pmf 公式为

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2).$$

连续型：设 (X_1, X_2) 的联合 pdf 为 $f_{X_1, X_2}(x_1, x_2)$ 。

1. 由边缘 pdf 的定义， X_1 的边缘 pdf 满足

$$\mathbb{P}(a \leq X_1 \leq b) = \int_a^b f_{X_1}(x_1) dx_1.$$

2. 另一方面，

$$\mathbb{P}(a \leq X_1 \leq b) = \int_a^b \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

3. 比较两式，由微积分基本定理，得到边缘 pdf 公式：

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2.$$

几何直观：联合 pdf 是二维“概率密度曲面”，边缘 pdf 是该曲面对 x_2 方向“压扁”后得到的、一维曲线下的面积。

2.2. 条件分布公式推导. 背景：已知联合分布，如何描述“已知 X_1 的值时 X_2 的分布”？

目标：推导条件 pmf/pdf 的计算公式。

推导步骤：

离散型：

1. 条件概率的基本定义：

$$\mathbb{P}(X_2 = x_2 \mid X_1 = x_1) = \frac{\mathbb{P}(X_1 = x_1, X_2 = x_2)}{\mathbb{P}(X_1 = x_1)}.$$

2. 代入联合 pmf 和边缘 pmf：

$$p_{X_2|X_1}(x_2 \mid x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}.$$

3. 验证归一性： $\sum_{x_2} p_{X_2|X_1}(x_2 \mid x_1) = 1$ 。

连续型:

1. 连续情形不能直接用条件概率定义, 因为 $\mathbb{P}(X_1 = x_1) = 0$ 。我们用极限思想:

$$f_{X_2|X_1}(x_2 | x_1) = \lim_{\Delta \rightarrow 0} \frac{\mathbb{P}(x_1 \leq X_1 < x_1 + \Delta, X_2 \in dx_2)}{\mathbb{P}(x_1 \leq X_1 < x_1 + \Delta) \cdot dx_2}.$$

2. 分子分母同除以 Δ 并取极限, 得到

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

3. 验证归一性: $\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$ 。

直觉理解: 条件密度是联合密度在固定 x_1 处的“切片”, 再除以该切片下的总面积 (边缘密度) 进行归一化。

2.3. 条件密度与 Radon-Nikodym 定理. 背景: 连续情形下条件密度 $f_{X_2|X_1}(x_2|x_1) = f(x_1, x_2)/f_{X_1}(x_1)$ 的严格数学基础是什么?

已知条件:

- 联合 pdf $f_{X_1, X_2}(x_1, x_2)$ 存在
- 边缘 pdf $f_{X_1}(x_1) > 0$

目标: 严格论证条件密度的存在性与定义。

推导步骤:

1. 条件分布函数定义为

$$F_{X_2|X_1}(x_2 | x_1) = \mathbb{P}(X_2 \leq x_2 | X_1 = x_1).$$

2. 由 Radon-Nikodym 定理: 若 $\mathbb{P}_c(\cdot | X_1)$ 是给定 X_1 时的条件概率测度, 则存在 Radon-Nikodym 导数 (即条件密度):

$$\mathbb{P}(X_2 \leq x_2 | X_1 = x_1) = \int_{-\infty}^{x_2} f_{X_2|X_1}(x'_2 | x_1) dx'_2.$$

3. 验证条件密度的公式:

$$\int_{-\infty}^{x_2} \frac{f_{X_1, X_2}(x_1, x'_2)}{f_{X_1}(x_1)} dx'_2 = \frac{1}{f_{X_1}(x_1)} \int_{-\infty}^{x_2} f_{X_1, X_2}(x_1, x'_2) dx'_2 = \frac{F_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 对 x_2 求导得到条件密度表达式:

$$\frac{\partial}{\partial x_2} F_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

注: Radon-Nikodym 定理保证了在 σ -有限条件下, 条件密度 (条件期望的 Radon-Nikodym 导数) 的存在性, 这是现代概率论的基础结果之一。

2.4. 全期望公式推导. 背景: 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是概率论中最强大的工具之一。

目标: 严格推导全期望公式。

推导步骤:

离散型:

1. 条件期望的定义:

$$\mathbb{E}(X_2 | X_1 = x_1) = \sum_{x_2} x_2 \cdot p_{X_2|X_1}(x_2 | x_1) = \sum_{x_2} x_2 \cdot \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}.$$

2. 外层期望是对 X_1 求平均:

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \sum_{x_1} \left[\sum_{x_2} x_2 \cdot \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)} \right] p_{X_1}(x_1).$$

3. 约去 $p_{X_1}(x_1)$:

$$= \sum_{x_1} \sum_{x_2} x_2 \cdot p_{X_1, X_2}(x_1, x_2) = \sum_{x_2} x_2 \left[\sum_{x_1} p_{X_1, X_2}(x_1, x_2) \right].$$

4. 内层和是边缘 pmf: $= \sum_{x_2} x_2 \cdot p_{X_2}(x_2) = \mathbb{E}(X_2)$ 。

连续型: 类似地,

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} x_2 \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2 \right] f_{X_1}(x_1) dx_1 = \iint x_2 f_{X_1, X_2}(x_1, x_2) dx_1 dx_2 = \mathbb{E}(X_2).$$

意义: 全期望公式本质上是“加权平均的加权平均”——先在每个 X_1 条件下计算 X_2 的条件均值, 再对条件均值按 X_1 的分布加权平均, 结果等于全体平均。

2.5. 方差分解公式推导. 背景: 条件方差公式 $\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)]$ 是统计学中最重要的恒等式之一。

目标: 证明总方差等于“平均条件方差”加上“条件均值的方差”。

推导步骤:

1. 由方差的定义:

$$\text{var}(X_2) = \mathbb{E}(X_2^2) - [\mathbb{E}(X_2)]^2.$$

2. 对第一项应用全期望公式:

$$\mathbb{E}(X_2^2) = \mathbb{E}[\mathbb{E}(X_2^2 | X_1)].$$

3. 在每个 $X_1 = x_1$ 条件下, $\mathbb{E}(X_2^2 | X_1 = x_1) = \text{var}(X_2 | X_1 = x_1) + [\mathbb{E}(X_2 | X_1 = x_1)]^2$ 。

4. 因此

$$\mathbb{E}(X_2^2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \mathbb{E}[\mathbb{E}(X_2 | X_1)]^2.$$

5. 代入方差公式:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \mathbb{E}[\mathbb{E}(X_2 | X_1)]^2 - [\mathbb{E}(X_2)]^2.$$

6. 注意最后两项恰好是 $\mathbb{E}(X_2 | X_1)$ 的方差：

$$\text{var}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}[\mathbb{E}(X_2 | X_1)^2] - [\mathbb{E}(X_2)]^2.$$

7. 代入即得方差分解公式：

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

直观理解：第一项是“组内方差的平均”（知道 X_1 后 X_2 的残余变异），第二项是“组间方差”（不同 X_1 条件下条件均值的变化）。

2.6. Rao-Blackwell 定理. 背景：Rao-Blackwell 定理是统计决策理论的核心结果，说明了如何利用条件化改进估计量。

已知条件：

- T 是 θ 的无偏估计量： $\mathbb{E}_\theta(T) = \theta$
- $S = \mathbb{E}(T | U)$ 是 T 关于充分统计量 U 的条件期望

目标：证明 $\mathbb{E}[(S - \theta)^2] \leq \mathbb{E}[(T - \theta)^2]$ ，即 S 比 T 更好（均方误差更小）。

推导步骤：

1. 由全方差公式：

$$\text{var}_\theta(T) = \mathbb{E}[\text{var}_\theta(T | U)] + \text{var}_\theta[\mathbb{E}_\theta(T | U)].$$

2. 由于 $S = \mathbb{E}(T | U)$ ，有 $\mathbb{E}_\theta(S) = \mathbb{E}_\theta(T) = \theta$ （ S 仍是无偏的）。

3. 由方差分解式两边减去 θ^2 （注意 S 无偏），得

$$\mathbb{E}[(T - \theta)^2] = \underbrace{\mathbb{E}[\text{var}(T | U)]}_{\geq 0} + \mathbb{E}[(S - \theta)^2] \geq \mathbb{E}[(S - \theta)^2].$$

结论：条件化（于充分统计量）不会增加均方误差，且在 T 不是充分统计量的函数时严格减少。这为用条件期望改进任意估计量提供了理论依据。

2.7. 贝叶斯公式推导. 背景：贝叶斯公式是连接先验、似然和后验的桥梁。

已知条件：

- 先验分布： $\theta \sim \pi(\theta)$
- 似然函数： $X | \theta \sim f(x | \theta)$

目标：求后验分布 $\pi(\theta | x)$ 。

推导步骤：

1. 由条件概率的定义：

$$\pi(\theta | x) = \frac{f(x, \theta)}{f(x)} = \frac{f(x | \theta)\pi(\theta)}{f(x)}.$$

2. 其中归一化常数（边际似然）为

$$f(x) = \int f(x | \theta')\pi(\theta') d\theta'.$$

3. 因此贝叶斯公式为

$$\pi(\theta | x) = \frac{f(x | \theta)\pi(\theta)}{\int f(x | \theta')\pi(\theta') d\theta'}.$$

后验均值：作为点估计，

$$\mathbb{E}(\theta | x) = \int \theta \cdot \pi(\theta | x) d\theta = \frac{\int \theta f(x | \theta)\pi(\theta) d\theta}{\int f(x | \theta)\pi(\theta) d\theta}.$$

共轭先验：若先验 π 与似然 $f(\cdot | \theta)$ 共轭，则后验与先验有相同形式，计算大为简化。

2.8. 贝叶斯方法历史概述. 背景：理解贝叶斯方法的历史脉络有助于认识其哲学内涵。

历史时间线：

1761 年：Thomas Bayes (1702-1761) 发表《An Essay Towards Solving a Problem in the Doctrine of Chances》，首次提出贝叶斯公式。贝叶斯的证明使用了“逆概率”思想——从观测数据反推原因的概率。

1774 年：Pierre-Simon Laplace (1749-1827) 独立发展了贝叶斯方法，并将其系统化。拉普拉斯使用贝叶斯方法估计太阳系行星的质量和轨道参数。

19 世纪：贝叶斯方法在统计界占据主导地位，但 Frequentist 学派 (Fisher、Pearson、Neyman) 对其“主观先验”提出了批评。

1930-1950 年代：Frequentist 方法成为主流，贝叶斯方法被边缘化。Fisher 的显著性检验和 Neyman 的置信区间理论主导了统计实践。

1980 年代至今：由于计算革命 (尤其是 MCMC 方法的发展)，贝叶斯方法复兴。如今它与 Frequentist 方法并列为统计学的两大流派。

哲学争论：贝叶斯方法的核心争议在于先验分布的选择——

- **客观贝叶斯学派：**选择无信息先验 (如 Jeffreys 先验)，使后验主要由数据决定
- **主观贝叶斯学派：**先验分布应反映研究者的真实信念

现代应用：贝叶斯方法在机器学习 (贝叶斯神经网络)、生物统计 (药物试验)、金融 (风险建模) 等领域有广泛应用。

2.9. 独立性因子化判据推导. 背景：独立性 $X_1 \perp\!\!\!\perp X_2$ 的定义是 $F(x_1, x_2) = F_1(x_1)F_2(x_2)$ ，但这在应用中不方便。因子化判据提供了更实用的检验方法。

目标：证明 $X_1 \perp\!\!\!\perp X_2 \iff f(x_1, x_2) \equiv g(x_1)h(x_2)$ (对某些 g, h)。

推导步骤：

($\Rightarrow$) 若 $X_1 \perp\!\!\!\perp X_2$:

1. 由独立性, $f_{X_1, X_2}(x_1, x_2) = f_{X_1}(x_1) \cdot f_{X_2}(x_2)$ 。
2. 取 $g(x_1) = f_{X_1}(x_1)$, $h(x_2) = f_{X_2}(x_2)$, 则 $f(x_1, x_2) = g(x_1)h(x_2)$ 。

($\Leftarrow$) 若 $f(x_1, x_2) = g(x_1)h(x_2)$:

1. 对两边积分求边缘:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \underbrace{\int_{-\infty}^{\infty} h(x_2) dx_2}_{C_2} = C_2 g(x_1).$$

同理 $f_{X_2}(x_2) = C_1 h(x_2)$ 。

2. 由归一性 $\iint f = 1$, 得 $C_1 C_2 \iint g(x_1)h(x_2) dx_1 dx_2 = 1$, 故 $C_1 C_2 \cdot C_2 C_1 = 1$, 即 $C_1 C_2 = 1$ (假设 $C_1, C_2 > 0$)。

3. 因此

$$f_{X_1}(x_1)f_{X_2}(x_2) = (C_2 g(x_1)) \cdot (C_1 h(x_2)) = C_1 C_2 g(x_1)h(x_2) = f(x_1, x_2).$$

4. 故 $X_1 \perp\!\!\!\perp X_2$ 。

注: 这个判据对于离散型同样适用, 只需把积分换成求和。

2.10. 独立 $\Rightarrow$ 不相关的反例. 背景: 已知独立一定推出不相关 ($\text{cov} = 0$), 但逆命题一般不成立。这里给出经典反例。

目标: 构造 $\text{cov}(X, Y) = 0$ 但 X 与 Y 不独立的例子。

推导步骤:

设 $X \sim \text{Uniform}(-1, 1)$, $Y = X^2$ 。

1. 验证 $\text{cov}(X, Y) = 0$:

$$\text{cov}(X, Y) = \mathbb{E}(X \cdot X^2) - \mathbb{E}(X) \cdot \mathbb{E}(X^2) = \mathbb{E}(X^3) - 0 \cdot \mathbb{E}(X^2).$$

由于 X 对称分布 ($\text{Uniform}(-1, 1)$ 对称于 0), $\mathbb{E}(X^3) = \int_{-1}^1 x^3 \cdot \frac{1}{2} dx = 0$ (奇函数在对称区间积分为零)。

故 $\text{cov}(X, Y) = 0$ 。

2. 验证 X 与 Y 不独立:

给定 $X = 0.5$, 则 $Y = 0.25$ 是确定值。给定 $X = -0.5$, 则 $Y = 0.25$ 也是确定值。但 Y 的取值完全由 X 决定——知道 X 就完全知道 Y , 这说明两者不独立。

更精确地, $\mathbb{P}(Y > 0.5) \neq \mathbb{P}(Y > 0.5 | X > 0)$, 因为 $Y = X^2$ 。

结论: 不相关只说明没有线性关系, 但不排除非线性依赖。在这个例子中, Y 是 X 的二次函数, 它们之间存在明确的函数关系 (非线性), 但协方差为零。

2.11. 相关系数范围推导. 背景: 相关系数满足 $-1 \leq \rho \leq 1$, 这一性质源自 Cauchy-Schwarz 不等式。

目标: 严格证明 $|\rho| \leq 1$ 。

已知条件:

$$\rho = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)}\sqrt{\text{var}(X_2)}} = \frac{\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]}{\sigma_1 \sigma_2}.$$

推导步骤:

1. 考虑随机变量 $Y = (X_1 - \mu_1) - t(X_2 - \mu_2)$, 其中 $t \in \mathbb{R}$ 待定。

2. 由方差的非负性:

$$0 \leq \text{var}(Y) = \mathbb{E}(Y^2) = \sigma_1^2 - 2t\text{cov}(X_1, X_2) + t^2\sigma_2^2.$$

3. 将 $\text{cov}(X_1, X_2) = \rho\sigma_1\sigma_2$ 代入:

$$0 \leq \sigma_1^2 - 2t\rho\sigma_1\sigma_2 + t^2\sigma_2^2.$$

4. 这是关于 t 的二次不等式, 要使对所有 t 成立, 判别式必须 ≤ 0 :

$$(2\rho\sigma_1\sigma_2)^2 - 4\sigma_1^2\sigma_2^2 \leq 0.$$

5. 化简得

$$4\rho^2\sigma_1^2\sigma_2^2 \leq 4\sigma_1^2\sigma_2^2 \implies \rho^2 \leq 1.$$

6. 即 $-1 \leq \rho \leq 1$ 。

等号条件: $|\rho| = 1$ 当且仅当存在 t 使 $\text{var}(Y) = 0$, 即 Y 几乎处处为零: $X_1 - \mu_1 = t(X_2 - \mu_2)$, 此时 X_1 与 X_2 有完美线性关系。

2.12. 二元正态条件分布推导. 背景: 二元正态分布的条件分布仍是正态的, 这是其最重要的性质之一。

已知条件: $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 联合 pdf 为

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{Q(x_1, x_2)}{2(1-\rho^2)}\right\},$$

其中 $Q = \frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2}$ 。

目标: 求条件分布 $X_2 | X_1 = x_1$ 。

推导步骤:

1. 条件分布的 pdf 为

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)} = \frac{f(x_1, x_2)}{\frac{1}{\sigma_1}\phi\left(\frac{x_1 - \mu_1}{\sigma_1}\right)}.$$

2. 将 Q 整理成关于 x_2 的二次函数:

$$Q = \frac{1}{1-\rho^2} \left[\left(\frac{x_2 - \mu_2}{\sigma_2} - \rho\frac{x_1 - \mu_1}{\sigma_1} \right)^2 + (1-\rho^2)\frac{(x_1 - \mu_1)^2}{\sigma_1^2} \right].$$

3. 因此

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)} \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho\frac{x_1 - \mu_1}{\sigma_1} \right)^2\right\} \cdot \exp\left\{-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2}\right\}.$$

4. 除以边缘密度 $f_{X_1}(x_1) = \frac{1}{\sigma_1}\phi\left(\frac{x_1 - \mu_1}{\sigma_1}\right)$, 消去与 x_2 无关的因子:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{1}{\sigma_2\sqrt{2\pi(1-\rho^2)}} \exp\left\{-\frac{1}{2(1-\rho^2)} \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho\frac{x_1 - \mu_1}{\sigma_1} \right)^2\right\}.$$

5. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1-\rho^2)$ 的正态分布密度。

6. 故

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

最优线性预测：条件均值 $\mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 是 x_1 的线性函数，它在均方误差意义下是 X_2 的最优预测。

2.13. 回归理论的简要推导. 背景：回归分析的核心是找到使预测误差最小的线性预测器。

目标：在所有线性预测 $\hat{X}_2 = \alpha + \beta X_1$ 中，找到均方误差最小的预测。

推导步骤：

1. 均方预测误差 (MSE) 为

$$\mathbb{E}[(X_2 - \alpha - \beta X_1)^2] = \mathbb{E}(X_2^2) + \alpha^2 + \beta^2 \mathbb{E}(X_1^2) - 2\alpha \mathbb{E}(X_2) - 2\beta \mathbb{E}(X_1 X_2) + 2\alpha \beta \mathbb{E}(X_1).$$

2. 对 α 求偏导并设为零：

$$\frac{\partial \text{MSE}}{\partial \alpha} = 2\alpha + 2\beta \mathbb{E}(X_1) - 2\mathbb{E}(X_2) = 0 \implies \alpha^* = \mathbb{E}(X_2) - \beta \mathbb{E}(X_1).$$

3. 对 β 求偏导并设为零：

$$\frac{\partial \text{MSE}}{\partial \beta} = 2\beta \mathbb{E}(X_1^2) + 2\alpha \mathbb{E}(X_1) - 2\mathbb{E}(X_1 X_2) = 0.$$

4. 代入 α^* ：

$$\beta^* \mathbb{E}(X_1^2) + [\mathbb{E}(X_2) - \beta^* \mathbb{E}(X_1)] \mathbb{E}(X_1) - \mathbb{E}(X_1 X_2) = 0.$$

5. 整理得

$$\beta^* = \frac{\mathbb{E}(X_1 X_2) - \mathbb{E}(X_1) \mathbb{E}(X_2)}{\mathbb{E}(X_1^2) - [\mathbb{E}(X_1)]^2} = \frac{\text{cov}(X_1, X_2)}{\text{var}(X_1)} = \rho \frac{\sigma_2}{\sigma_1}.$$

6. 最优线性预测为

$$\hat{X}_2^* = \mathbb{E}(X_2) + \rho \frac{\sigma_2}{\sigma_1}(X_1 - \mathbb{E}(X_1)).$$

7. 对二元正态分布，这就是条件均值。

最小二乘法：在样本情形，用样本矩代替总体矩，得到 $\hat{\beta} = \hat{\rho}_{s_1}^{s_2}$ ，其中 s_1^2, s_2^2 是样本方差， $\hat{\rho}$ 是样本相关系数。

2.14. 两两独立不推出相互独立反例. 背景：对于多个随机变量，两两独立不一定推出相互独立，这是一个经典反例。

目标：构造三个事件 A, B, C ，使得两两独立但三者不相互独立。

推导步骤：

考虑抛两枚公平硬币的样本空间 $\{HH, HT, TH, TT\}$ ，每个结果等概率 $1/4$ 。

定义事件：

- A ：第一枚硬币正面 (HH 或 HT)
- B ：第二枚硬币正面 (HH 或 TH)
- C ：两面相同 (HH 或 TT)

1. 验证两两独立:

$$\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}.$$

$$\mathbb{P}(A \cap B) = \mathbb{P}(HH) = \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(B) = \frac{1}{2} \cdot \frac{1}{2}.$$

同理 $\mathbb{P}(A \cap C) = \mathbb{P}(B \cap C) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2}$ 。故 A, B, C 两两独立。

2. 验证三者不相互独立:

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(HH) = \frac{1}{4}.$$

但 $\mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8} \neq \frac{1}{4}$ 。

3. 不独立性体现: 给定 A 和 B 都发生 (即两面都是正面), 则 C 必然发生 (两面相同), 即

$$\mathbb{P}(C | A \cap B) = 1 \neq \mathbb{P}(C) = \frac{1}{2}.$$

结论: 两两独立只保证任意两个变量之间的依赖关系被消除, 但不能保证多个变量之间的整体依赖结构。这个反例提醒我们, 在处理多元随机变量时需要小心。

2.15. 独立随机变量线性组合的 mgf 推导. 背景: 若 $X_1, \dots, X_n$ 相互独立, $T = \sum_{i=1}^n k_i X_i$, 则 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标: 推导独立随机变量线性组合的矩母函数。

推导步骤:

1. 由 mgf 的定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[e^{t \sum_{i=1}^n k_i X_i}\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_1 X_1}, \dots, e^{tk_n X_n}$ 也相互独立。

3. 对独立随机变量的乘积取期望, 等于各自期望的乘积:

$$M_T(t) = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_{X_i}(k_i t).$$

特别情形: 若 $X_1, \dots, X_n$ iid, 则 $M_T(t) = [M_X(t)]^n$ 。

例如, 若 $X_i \sim N(\mu, \sigma^2)$, $M_X(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$, 则

$$M_{\bar{X}}(t) = M_X(t/n)^n = \exp\left\{n \left(\mu \frac{t}{n} + \frac{1}{2}\sigma^2 \frac{t^2}{n^2}\right)\right\} = \exp\left\{\mu t + \frac{1}{2}\frac{\sigma^2}{n} t^2\right\},$$

这正是 $N(\mu, \sigma^2/n)$ 的 mgf。

2.16. 中心极限定理概述. 背景: 中心极限定理 (CLT) 是概率论和统计学中最重要的结果之一。

已知条件:

- $X_1, \dots, X_n$ iid (独立同分布)
- $\mathbb{E}X_i = \mu$, $\text{var}(X_i) = \sigma^2 < \infty$
- $\bar{X} = n^{-1} \sum X_i$

目标：描述 $\bar{X}$ （或标准化后的 $\bar{X}$ ）的极限分布。

推导思路：

1. 考虑标准化和 $Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$ 。
2. 由独立随机变量和的 mgf 性质， Z_n 的 mgf 为

$$M_{Z_n}(t) = \left[M_X\left(\frac{t}{\sqrt{n}\sigma}\right) \right]^n e^{-\sqrt{n}\mu t/\sigma}.$$

3. 对 $M_X(t/\sqrt{n}\sigma)$ 在 $t = 0$ 处 Taylor 展开：

$$M_X\left(\frac{t}{\sqrt{n}\sigma}\right) = 1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

4. 代入得

$$M_{Z_n}(t) = \left(1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n e^{-\sqrt{n}\mu t/\sigma} \xrightarrow{n \rightarrow \infty} e^{t^2/2}.$$

5. 标准正态分布 $\mathcal{N}(0, 1)$ 的 mgf 正是 $e^{t^2/2}$ 。

6. 由 mgf 的唯一性（若随机变量的 mgf 收敛到某个分布的 mgf，则该随机变量的分布收敛到该分布），得

$$Z_n \Rightarrow \mathcal{N}(0, 1), \quad \text{即} \quad \sqrt{n}(\bar{X} - \mu)/\sigma \Rightarrow \mathcal{N}(0, 1).$$

核心洞察：无论 X_i 原来是什么分布（只要方差有限），其样本均值经适当标准化后都收敛到标准正态分布。这使得正态分布在统计推断中具有核心地位。

2.17. Gamma 分布的矩母函数推导. 背景 (Background)：在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions)：

- $\alpha > 0$ ：形状参数 (shape parameter)
- $\beta > 0$ ：尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$ ：服从 Gamma 分布的随机变量

已知条件 (Given)：

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal)：证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps)：

1. 根据矩母函数定义：

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换：令 $y = \frac{x(1-\beta t)}{\beta}$ ，则 $x = \frac{\beta y}{1-\beta t}$ ， $dx = \frac{\beta}{1-\beta t} dy$ 。

3. 代入积分（要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$ ）：

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1 - \beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1 - \beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1 - \beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1 - \beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1 - \beta t)^{-\alpha}. \end{aligned}$$

结论：因此， $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ ，定义域为 $t < 1/\beta$ 。■

2.18. Gamma 分布的均值与方差推导. 背景 (Background): 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$ ，方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given):

- 矩母函数： $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式： $\mathbb{E}X = M'(0)$
- 方差公式： $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数：

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数：

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$ ：

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差：

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论：因此， $\mathbb{E}X = \alpha\beta$ ， $\text{var}(X) = \alpha\beta^2$ 。■

2.19. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一，它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

2.20. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

2.21. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性：

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$ ，我们分别处理两项。

4. 第一项：先对 y_2 积分得到边缘密度，再积分：

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论： 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。 ■

2.22. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$ ，逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导：

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则：

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论： $|J|$ 度量了变换下的面积元素缩放比例。 ■

2.23. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义：

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$ ：

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证：边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$ ，确实是合法的 pdf。

结论：条件 pdf 公式得证。■

2.24. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发：

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望（即关于 X_1 求平均）：

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序：

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$ ：

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论：全期望公式得证。■

2.25. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解：

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance)：

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项：

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此：

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论：条件均值的方差不超过原变量的方差，等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0（即 X_2 可由 X_1 确定性决定）。■

2.26. 独立性判定的推导. 背景 (Background)：我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ （可分离变量）。

目标 (Goal)：证明这一判定条件。

推导步骤 (Derivation Steps)：

($\Rightarrow$) 若 X_1 与 X_2 独立，则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$ ，显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ ：

1. 由边缘密度定义：

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理：

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$ ，得 $c_1 c_2 = 1$ 。

4. 因此：

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论：故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

2.27. 相关系数范围的推导. 背景 (Background)：我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal)：证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps)：

1. Cauchy-Schwarz 不等式：对任意随机变量 U, V ，

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差，令 $U = X_1 - \mu_1$ ， $V = X_2 - \mu_2$ ：

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方：

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此：

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论：故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ （完美线性关系）。■

2.28. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

2.29. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

2.30. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

2.31. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

2.32. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j | Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j | Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

2.33. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。

2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

2.34. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。

2. 则 $X = \sum_{j=1}^n I_j$ 。

3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。

4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

2.35. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} \rightarrow 1,$$

$$\left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

2.36. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数:

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论: Poisson 分布的均值和方差相等, 都等于参数 λ 。■

2.37. 卡方分布与正态分布的关系. 背景 (Background): 卡方分布定义为标准正态平方和。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, 则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps):

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$, 先求 cdf:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式:

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论: 标准正态变量的平方服从自由度为 1 的卡方分布。■

2.38. 卡方分布的可加性证明. 背景 (Background): 卡方分布满足可加性: 独立卡方变量之和仍为卡方分布。

目标 (Goal): 证明若 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立, 则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps):

1. 由卡方分布与 Gamma 分布的关系: $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性 (见定理 3.3.1): 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此:

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf: $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$, 故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论: 卡方分布具有可加性, 自由度可累加。■

2.39. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1 + X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

2.40. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

2.41. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

2.42. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}\left[e^{(t/\sigma)X}\right] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

2.43. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

3. 问答记录

3.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是**固定（但未知）的常数**，而区间 $[L, U]$ 是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

3.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的”参数固定但未知”观点形成了根本性对比。

学习笔记.