

引言：从随机性中学习

引言：从随机性中学习

为什么需要概率论？

教材内容预览

这三章的内在逻辑

学习方法建议

习题说明

附录：公式推导

多元随机变量及其分布

概述

从一元到多元：联合分布

边缘分布：积分即求和

条件分布：信息的价值

独立性：变量间的 无关系

相关性：线性关联的度量

二元正态：最重要的二元分布

多元推广

本章习题

附录：公式推导

2 F

习题

附录：公式推导

问答记录

附录 参考文献

1 t K T H 2 X 2 d ä' <# ? N ä' # ? P Ú Ø P â K j e ö ĩ
P Q > C f ; ; ; ; ; ; ; g P Ú

1 t K T H 2 X Ó K P ý ĩ â! æ P Ú Ø P â C
; 1 P Æ P Æ ü Ł ä ò 0 O æ fi â Û P Ú

事件是样本空间的子集。如果一个实验进行一次，事件 A 要么发生，要么不发生，没有第三种可能。概率论正是描述这种不确定性的数学语言。

k X R X k a 2 i b , h ? 2 G M ; m ; 2 Q 7 I M + 2 ` i B M i v

k X R X q ? v . Q q 2 L 2 2 / a 2 i h ? 2 Q ` v 7 Q ` S 在概率论中，事件 A ()
本质上就是样本空间的子集。为什么要用集合的语言？因为集合运算（并、交、补）完美地对应了事件的逻辑运算（或、且、非）。

. 2 J Q ` ; M ö b G : r b

$$A \setminus B^c = A^c \cap B^c; \quad A \cap B^c = A^c \setminus B^c:$$

:

$$A \setminus B \cap C = A \setminus B \cap A \setminus C:$$

这些看似简单的定律，在概率计算中非常有用。例如，要计算 既不是 A 也不是 B 的概率，我们可以直接使用德摩根定律： $P[A \cap B^c] = P[A^c \setminus B^c]$ 。

k X k X E 2 v a 2 i P T 2 ` 设 Ω 为样本空间， A, B, C 为事件：

A^c : 所有不在 A 中的元素

$A \cap B$: 至少在 A 或 B 之一中的元素

$A \setminus B$: 同时在 A 和 B 中的元素

$A \setminus B$: A 和 B 互不相容

1 t K T H 2 X \$ C f ; ; ; ; ; g Q A f ; g Q B f ; ; g Q
C f ; ; ; g P Ú
ç A^c f ; ; ; ; ; g Q A [B f ; ; ; g Q A \ B f g Q A \ C Q B \ C f ; g P Ú

k X j X * Q m M i # H 2 M / I M + Q m 若集合 C 是有限的，或与正整数集等
势，则称 C 为可数的 ()。

$$: [_{n=1}^{\infty} A_n \text{ f x x 2 } A_n \quad n g$$

$$: \setminus_{n=1}^{\infty} A_n \text{ f x x 2 } A_n \quad n g$$

: 若 $f A_n g$ 非递减 ($A_n \subset A_{n+1}$)，则 $\bigcup_n A_n = [_{n=1}^{\infty} A_n$ 。若非递增，则

$$\bigcap_n A_n = \setminus_{n=1}^{\infty} A_n。$$

C

C

jX R Xj h?2 S`Q# #BHBiv a2i 6mM+iBQM

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。

概率必须满足：

非负性： $P A$

规范化： $P C$

可数可加性：若 $A_1; A_2; \dots$ 两两不交，则 $P [\cup_{n=1}^{\infty} A_n] = \sum_{n=1}^{\infty} P A_n$

$_2 K \text{ ' F X } \quad Q \text{ > I â R \& Õ 5 æ } \hat{Q} \text{ fi } \text{ } ^\circ \& \tilde{O} A \} -$
 $\hat{a}' 5 \quad \hat{Q} \text{ fi) fi) } * R \& \tilde{O} \hat{a} Q \} - \hat{a} \hat{a}' 5 \acute{O} \grave{a} ' 5 \text{ fi NPÚ}$

从这三条公理可以推导出概率的所有其他性质。^R

$_2 K \text{ ' F X } \quad R X j \hat{Q} \text{ RP } \% \grave{o} \} - \quad A Q P A \quad P A^c P Ú$
 $Q \text{ > U C } \quad A [A^c N A \setminus A^c \quad Q \quad B G$

$P C \quad P A \quad P A^c :$

：对任意事件 $A_1; \dots; A_n$,

$$P \left[\bigcup_{i=1}^n A_i \right] \leq \sum_{i=1}^n P A_i :$$

这在估计复合事件概率时非常有用——当精确计算困难时，布尔不等式提供了一个上界。

$_2 K \text{ ' F X } \quad Q \text{ > } \text{¥} \emptyset P \hat{a} \quad C \quad f x_1; x_2; \dots; x_m g \hat{\text{ }} Q U \% \grave{o} \quad Q m i + Q K 2$
 $\acute{O} 5 Q \text{ } \text{ç}$

$P A = \frac{A}{m} :$

$1 t \text{ K T H } 2 \quad \text{扑克牌概率 } X c \text{ } 8 k 9 q ' \ddot{o} \text{ } „ u y \grave{a} 9 P Ú \$ \quad A \text{ } 4 \hat{o} u \acute{y} \quad \hat{o} Q$
 $B \text{ } 4 \hat{o} u \acute{y} < \quad \hat{P} Ú \text{ç}$

$P A = \text{—}; \quad P B = \text{—}; \quad P A \setminus B = \text{—}:$

U ÔGQ

$P A [B = \text{—} = \text{—} = \text{—} = \text{—} = \text{—}:$

9X R X9 *QM/BiBQM H S`Q# #BHBiv M/ AM/2T2M/2M+

条件概率是概率论中最重要的概念之一。它描述了在已知某些信息发生的条件下，如何更新我们对其他事件概率的判断。

$_2 K \text{ ' F X } \quad R X 9 X R U \quad \hat{Q} \text{ > } \$ P B > Q \grave{i} \} - \quad B \acute{y} M - \hat{a} - Q \}$
 $- A \hat{a} - ' 5 \text{ } S$

$P A | B = \frac{P A \setminus B}{P B}:$

^R详细推导见附录 [0H\\$nj](#) [00U0](#)。

•

推广到 n 个事件:

$$P \prod_{i=1}^n A_i = P A_1 P A_2 \cdots P A_n \prod_{i=1}^n A_i :$$

$$\begin{array}{c} _2 K \quad ' F X \\ P A \end{array} \quad \begin{array}{c} Q > \$ f B_i g \\ P B_i \end{array} \quad \begin{array}{c} C \hat{a} \hat{o} > Q \quad \zeta P \beta \acute{Y} - \\ P A j B_i : \end{array} \quad \begin{array}{c} A Q \end{array}$$

$$\frac{P_{B_j}^A}{\sum_i P_{B_i}^A} = \frac{P_{B_j}^A}{\sum_i P_{B_i}^A}$$

Q_{γ}

P B_j Q> 1'5Q T`B Q` T`Q Q #A P B i j à y A f i ü^a \$ P B_j â...
P B_j j A Q>m 1'5Q T Q b i 2`B Q` T`Q Q #A P B i j à y A f i m^a \$ P B_j â

$P A_j B_i Q \triangleright p Q$ HBF2 QBPFQEB [â - J àý A â'5

k

1t KTH2 医学检测 X\$°P Ø Ø Q à Ü5 PÚ D 4 ô
(Ø ØQ 4 ô àß R ØPÚ
“ à Ü5 ¶¶ Q àß R Ø_ S (Ø' 5 a î Q
üöÑ D Ââ » & Ø>ì P Ø% A âe e Q “ I K Üâ à) Ø
ÿæ ß RPÚ j

9XR X RX9XR AM/2T 2M/2M+2X

_2K 'FX RX9Xk U Q> P A\ B P A P B Q ç A 2 B Q ô
 Q ü† A? BPÚ
 / P A > ;P B > !Q R Ó î P A j B P A PÆPÆ' B M- æ
 X u A â'5PÚ

1t KTH2 独立硬币 X d . ' O bPÚ\$ A 4 ô Úä' S æ ° p Q B 4
ô ÚC ' S æ ° p PÚç P A P B Q U P A \ B P A P B Q à
A ? BPÚ

q _ LAL: , 两两独立 () 不一定意味着相互独立! ⁹

^k贝叶斯公式的深层意义见附录 0H§_nj 00u©。

^j详细计算见附录“0H§_nj 00u”。

⁹反例见附录 OH§_nj ooUV。

$$8XRX8_M/QK o`B\#H2b$$

样本空间的元素可能不是数字——随机变量正是将样本空间数值化的工具。

$_2K'FXRX8XR U Q> „u æ c ¥ Ø P â C ý fi â fi Q> X$
 $C! RPÚ$
 $ìKcÿ e X;Y;Z], „u æ c 2 e x;y;z], yrPÚ$

随机变量可分为：

：取值可数（有限或无限）

：取值充满区间，不可数

给定随机变量 X ，它的取值空间 D 成为新的样本空间。 X 不仅诱导了新的样本空间，还诱导了一个概率分布——这正是 分布 概念的起源。

$1t KTH2$ 硬币投掷 $X d \cdot ' O b PÚ ¥ Ø P â C fHH;HT;TH;TT gPÚ$
 $SX S æ G â fi Q> X HH QX HT X TH QX TT PÚ ç X Ł$
 $yrì f ; ; g â ð Æ „u æ Ú$

$1t KTH2$ 均匀选择 $Xc^â ; „ < \% ä ð fi XPÚ Ł O O „ u$
 $æ yr Ö ; PÚ$

$$8XRX *mK m H i B p 2 . B b i ` B \# m i B Q M 6 m M + i B Q M X$$

$_2K'FXRX8Xk U * Q F x P X x Q 1 < x < 1 PÚ$
 $*.6 Ö Q>$

$URN^{\circ} Q> x_1 < x_2 Q ç F_X x_1 F_X x_2$
 $Uk V_x F_X x Q_x F_X x$
 $Uj V 0 O Q> F_X x t x^+ F_X t$

*.6 :

$$P a < X b F_X b F_X a :$$

：对连续随机变量， $P X x$ ，因此

$$P a < X < b P a X b F b F a :$$

$$eXRXe.Bb+`2i2\_M/QK o`B\#H2b$$

离散随机变量的取值是可数的。

$_2K'FXRXeXR U Q p x P X x PÚ$
 $TK Ö Q> p_x x P î x Q U_x p_x x PÚ$

2. 期望与方差 $E(X)$ 和 $D(X)$ 的定义及性质

$$E(aX + bY) = aEX + bEY;$$

$$D(X) = E(X^2) - [E(X)]^2$$

1. 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望和方差

$$E\bar{X} = \frac{1}{n} \sum_{i=1}^n EX_i = EX$$

2. 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

：一般情况下 $E(S^2) \neq D(X)$ 。只有当 X 和 Y 独立时，等式才成立。

1. 乘积期望 $E(XY) = EXEY$ 当且仅当 X 与 Y 独立时成立。

方差度量分布的离散程度。

2. 协方差 $Cov(X, Y) = E[(X - EX)(Y - EY)]$

$$D(X \pm Y) = D(X) \pm 2Cov(X, Y) + D(Y)$$

3.

1. 期望 EX 的性质

$$E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n EX_i$$

$$EX^2 = EX(X-EX + EX) = EX(X-EX) + EX^2 = EX(X-EX) + EX^2$$

某些期望具有特殊名称和重要意义。

1. 期望 EX 的性质

2. 期望 EX^k 的性质

$$E(X^k) = \int_{-\infty}^{+\infty} x^k f(x) dx$$

$$E(X^k) = \int_{-\infty}^{+\infty} x^k f(x) dx$$

$$EX = \int_{-\infty}^{+\infty} x f(x) dx$$

2. EX 是分布的中心位置度量。

3. $D(X)$ 度量分布的离散程度。

4. EX^2 与 EX 具有相同单位。

5. $D(X)$ 是无量纲的离散程度度量。

6. EX^3 ，衡量分布的不对称程度。

7. EX^4 ，衡量分布尾部的厚重程度。

^{R1} 这将在 08§_nj 统计推断中发挥核心作用。

^{R2} 详细推导见附录 08§_nj 00000。

—> VQ>

$$P_{X_2} = \frac{p_{X_1;X_2}}{p_{X_1}} \quad -; \quad X_2 \quad ; \quad ; \quad ; \quad ;$$

+ GQ X_1 !Q X_2 u +> V $\hat{f}$; ; ; gPÚ

1t KTH2 连续条件分布 $X\$ X_1;X_2$ 5cC Sđ N ; ; ; ; : PÚ -
> V $f_{X_2|X_1}$ $X_2|X_1$: PÚ
UBfi Q>

$$X_2|X_1 : N : - : ; : ^2 N : ; : :$$

_ {HQ>

O7k+ '¶#æ#5÷

Kmkn;Bp2MntR l@ y Y yX8 UyX8 @ yV O 4 yXk8
bB;K knb[l@ R UR @ yX8 kV O 4 yXd8

O=@ _>†*¾7k+ 0&Æ

+m`p2U/MQ`KUt- Kmkn;Bp2MntR- b[`iUbB;K knb[VV-
7`QK 4 @k- iQ 4 k-
tH # 4 2tT`2bbBQMUt(k)V- vH # 4].2MbBiv]-
K BM 4 2tT`2bbBQMUT bi2U]*QM/BiBQM H /2MbBiv Q7]- s

jX9X

X条件分布在统计建模中有广泛应用：

RX : 条件均值 $E Y | X = x$ 正是回归函数。线性回归假设 $E Y | X = x$ 是 x 的线性函数，但更一般地，任何条件均值函数都可以作为回归目标。

kX : 在抽样设计中，我们经常按子群（ ）分组。子群内的条件分布描述了组内变异，而边缘分布描述了总体变异。方差分解公式正是这种思想的数学表达。

jX : 后验分布 $f_j | x$ 是在观测数据 x 的条件下参数 θ 的条件分布。整个贝叶斯推断都建立在条件分布的理论之上。

jX8X _

X继续展示条件分布在 中的实际计算。

1t KTH2 二元正态条件分布可视化 $X\$ X_1;X_2$ N ; ; ; ; : PÚ {æ
ó x_1 - X_2 â - , ØÚ
HB#` `vUKpiMQ`KV
HB#` `v ; ; THQikV

O5\$>¥#H5÷

KmR l@ Km k l@ y
bB;K R l@ bB;K k l@ R

在观测数据之前的分布，记作 $f(x)$ 。
 $L(\theta | x) \propto f(x | \theta) \prod_{j=1}^n f(x_j | \theta)$ ，描述数据如何更新我们对 θ 的认知。
 贝叶斯定理：

$$f(\theta | x) = \frac{f(x | \theta) f(\theta)}{\int f(x | \theta) f(\theta) d\theta}$$
 其中 $f(\theta)$ 是归一化常数。
 $E[\theta | x]$ 是贝叶斯估计量，它优于普通样本均值——尤其在样本量较小时。
 $\text{Var}[\theta | x]$ 度量了参数估计的不确定性。它在统计决策理论和置信区间构建中都有重要应用。
 拉普拉斯（Pierre-Simon Laplace）在其论文《Mémoire sur la probabilité de la cause》中首次提出了贝叶斯公式。拉普拉斯（Pierre-Simon Laplace）后来独立发展了贝叶斯方法，并将其应用于天文学、人口统计等领域。贝叶斯方法在 20 世纪经历了从被忽视到复兴的过程——部分原因是计算限制（马尔可夫链蒙特卡洛方法解决了这个问题），部分原因是哲学层面的争论。^d

1t KTH2 共轭 X\$ X j "BMQk B Q "2i ; PÚ
çm†>V

$$jX \quad x \quad "2i \quad x; \quad n \quad x:$$

$$m \downarrow ur$$

$$E \quad jX \quad x \quad \frac{x}{n}:$$

$$\ddot{u} _ \text{ } ^{\circ} \text{ } \text{ } \neq \emptyset U, \quad p \quad x \quad n \quad N \quad \downarrow ur \quad \frac{\quad}{+} \quad \hat{a}^* \quad - uP\text{Æ}P\text{Æ} \text{ fi } \text{ } ^{\circ} Q \quad m$$

$$\text{ } ^{\circ} x (\hat{\text{ i fi } } \hat{a}^{\text{ PÚ$$

$$_ \downarrow HQ \rangle$$

O9x; #5÷
HT? I@ k
#2i I@ j

O)7\$ 5÷;ï
M l @ R y
t l @ d

O* ; #15÷
HT? nTQbi l@ HT? Y t
#2i nTObi l@ #2i Y M @ t

$$O^* : - \rightarrow$$
^e详细推导见附录 OH§_nj ku¢。^d详细历史讨论见附录 OH§_ni kuP。

HB#` `vUBM7Qi?2QV

/Bb+`2iBx2U+#BM/Ut- vVV

Kmim HBM7Q`K iBQMU/Bb+`2iBx2U+#BM/Ut- vVVV

9X² Q>Ncî>đuæ>

O%Z+ũ.ǾY

bKQF2 I@ +U`2TU]u2b]- 98V- `2TU]LQ]- Ry8VV

+ M+2` I@ +U`2TU]u2b]- kyV- `2TU]LQ]- k8V- `2TU]u2b]- R8V-

i #H2 I@ K i`BtU+Uky- k8- R8- NyV- M`Qr 4 k- #v`Qr 4 h_l1V

O-x'+;

+?Bb[Xi2biUi #H2V

O 6Bb?%45+; d;%#*/:5«(- - e

7Bb?2`Xi2biUi #H2V

:

RX : 在金融工程中, 资产收益率的独立性假设是

公式的基础。虽然这个假设在实践中经常被违反(存在 波动率聚集 等现象), 但它提供了一个有用的基准模型。

kX : 在噪声模型中, 我们通常假设信号与噪声独立。这使得我们可以从噪声观测中恢复信号。

jX : 许多算法假设训练样本独立同分布()。当这个假设被违反时(如时间序列数据), 需要使用专门的模型(如 、)。

8X kX8

我们已经知道 $X_1; X_2$ 不能完全刻画独立性。那么如何量化 X_1 与 X_2 之间的 关联程度?

协方差 $X_1; X_2$ 存在一个问题: 它依赖于 $X_1; X_2$ 的量纲。例如, 身高()和体重()的协方差与换算成英寸和磅时不同。

: 先标准化, 再求协方差:

$$12 \quad X_1; X_2 \quad \rho = \frac{X_1; X_2}{X_1 X_2} = \frac{X_1; X_2}{1 \ 2}:$$

这就是相关系数()。

: RR

RR 推导见附录 0H\$nj ·uo·。

$$j_{12} = 0 \quad X_2 = aX_1 + b \quad (\text{完美线性关系})$$

称

为什么是 j_{12} ；？这来自 不等式：

$$j(X_1; X_2) = j(E X_1, E X_2) = \frac{\rho(E X_1^2, E X_2^2)}{\sqrt{E X_1^2 E X_2^2}} = \rho_{12}.$$

ρ_{12} ：协方差取决于量纲（厘米的协方差 数值不同）；相关系数是无量纲的，消除了单位影响。因此，相关系数是更通用的 关联程度 度量。

ρ_{12} 相关系数的概念由 () 在研究遗传问题时首次提出，但 () 给出了严格的数学定义和估计方法。

的工作奠定了生物计量学的基础，也使得相关性成为统计学中最广泛使用的概念之一。

： $H_i Q M$ ：研究双胞胎身高时发现，父亲身高与子女身高之间存在回归 () 现象——极端身高（非常高或非常矮）的父母，其子女的身高倾向于向平均值 回归。这种 向均值回归 的现象正是相关性的体现。

$S^2(b Q M)$ ：给出了相关系数的精确数学定义：

$$r_{XY} = \frac{X; Y}{X \quad Y};$$

并推导了其统计性质。他发展的矩估计方法至今仍是估计相关系数的主要方法之一。

R^2 提供了丰富的相关分析功能：

$$1 - R^2 = \frac{S^2(b Q M)}{S^2(Y)}$$

$H_i Q M$ ：

$$b Q M = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \frac{1}{n} \sum_{i=1}^n X_i Y_i - \bar{X} \bar{Y}$$

$$O + \frac{1}{2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{2} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$+ Q^2 U^2 = \frac{1}{2} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$O + \frac{1}{2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{2} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$M = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$+ Q^2 U^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$x = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$b^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

$x_n + B \mid @ + Ux @ R X N e b 2 - x Y R X N e b 2 V$

$\backslash n + B \mid @ U 2 t T U k x n + B V @ R V f U 2 t T U k x n + B V Y R V$

$\backslash n + B$

:

ρ_{jj} : 无线性关系

ρ_{jj}^2 ; : : 弱相关

ρ_{jj}^2 : ; : : 中等相关

ρ_{jj}^2 : ; : : 强相关

ρ_{jj} : 完美线性关系

:

相关系数只度量线性关系，非线性关系可能表现出

相关系数对异常值敏感（可以使用 或 相关系数作为鲁棒替代）

相关不等于因果——两个变量相关可能是因为它们共同受第三个变量影响

1 t K T H 2 相关与因果 X R ¾ æ 2 , Þ < i f i u S Q f Q : Q P Ú
 ü æ ý ð ; R ¾ i , H P Æ P Æ · Ø 2 Z 1 S Q f P Ú S Ü â ° Ł Q > Z
 Q D ó Ô + Q i R ¾ æ Ø N i ¶ ¶ Q c f l , Þ Ø Q P Ú

$eX kXe$

在所有二元分布中，二元正态分布占据核心地位。它是一元正态分布在二维的自然推广，也是计量经济学、信号处理等领域的基石。

边缘分布和条件分布都是正态的

线性组合仍是正态

不相关 $\Leftrightarrow$ 独立（这是正态独有的优雅性质）

多元正态是计量经济学、信号处理等领域的基石

历史注记：二元正态分布由 和 在 世纪末独立发展。

发展的多元相关理论为现代统计学奠定了重要基础。

. 2 7 B M B i B Q M 元正态分布 $XX_1; X_2$ 5 c C S ð > V Q s ä T / 7

$$f_{X_1; X_2} = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{1 - \rho^2}} \exp \left\{ -\frac{1}{2(1 - \rho^2)} \left[\frac{X_1^2}{1} - 2\rho \frac{X_1 X_2}{1 \cdot 2} + \frac{X_2^2}{2} \right] \right\};$$

ü ¶ $X_1; X_2 \sim N \left(\begin{matrix} \mu_1 \\ \mu_2 \end{matrix}; \begin{matrix} \sigma_1^2 & \rho \sigma_1 \sigma_2 \\ \rho \sigma_1 \sigma_2 & \sigma_2^2 \end{matrix} \right)$ P Ú

:

$\mu_1; \mu_2$: 边缘分布的均值

$\sigma_1^2; \sigma_2^2$: 边缘分布的方差

ρ : 相关系数

$N \times k \times X$ X : 已知联合分布, 如何描述 已知 X_1 的值时 X_2 的分布?

: 推导条件 的计算公式。

:

:

条件概率的基本定义:

$$P_{X_2 = x_2 | X_1 = x_1} = \frac{P_{X_1 = x_1; X_2 = x_2}}{P_{X_1 = x_1}};$$

代入联合 和边缘 :

$$p_{X_2 = x_2 | X_1 = x_1} = \frac{p_{X_1; X_2}(x_1; x_2)}{p_{X_1}(x_1)};$$

验证归一性: $\sum_{x_2} p_{X_2 = x_2 | X_1 = x_1} = 1$ 。

:

连续情形不能直接用条件概率定义, 因为 $P_{X_1 = x_1} = 0$ 。我们用极限思想:

$$f_{X_2 = x_2 | X_1 = x_1} = \lim_{l \rightarrow 0} \frac{P_{X_1 \in [x_1 - l, x_1 + l]; X_2 = x_2}}{P_{X_1 \in [x_1 - l, x_1 + l]}};$$

分子分母同除以 l 并取极限, 得到

$$f_{X_2 = x_2 | X_1 = x_1} = \frac{f_{X_1; X_2}(x_1; x_2)}{f_{X_1}(x_1)};$$

验证归一性: $\int_{-\infty}^{\infty} f_{X_2 = x_2 | X_1 = x_1} dx_2 = 1$ 。

: 条件密度是联合密度在固定 x_1 处的 切片, 再除以该切片下的总面积 (边缘密度) 进行归一化。

$N \times j \times X$ $_{-} / Q M @ L B F Q / v X$: 连续情形下条件密度 $f_{X_2 = x_2 | X_1 = x_1}$ 的严格数学基础是什么?

:

联合 $f_{X_1; X_2}(x_1; x_2)$ 存在

边缘 $f_{X_1}(x_1) > 0$

: 严格论证条件密度的存在性与定义。

:

条件分布函数定义为

$$F_{X_2 = x_2 | X_1 = x_1} = P_{X_2 \leq x_2 | X_1 = x_1}:$$

由 定理: 若 $P_{\cdot | X_1 = x_1}$ 是给定 X_1 时的条件概率测度, 则存在 导数 (即条件密度):

$$P_{X_2 \leq x_2 | X_1 = x_1} = \int_{-\infty}^{x_2} f_{X_2 = x_2 | X_1 = x_1} dx_2:$$

在每个 $X_1 = x_1$ 条件下, $E(X_2^2 | X_1 = x_1) = E(X_2 | X_1 = x_1)^2 + E(X_2 - E(X_2 | X_1 = x_1))^2$ 。

因此

$$E(X_2^2) = E(E(X_2^2 | X_1)) = E(E(X_2 | X_1)^2 + E(X_2 - E(X_2 | X_1))^2):$$

代入方差公式:

$$E(X_2^2) = E(E(X_2 | X_1)^2) + E(E(X_2 - E(X_2 | X_1))^2) = E(X_2^2):$$

注意最后两项恰好是 $E(X_2 | X_1)$ 的方差:

$$E(X_2 | X_1) = E(E(X_2 | X_1)^2) + E(X_2 - E(X_2 | X_1))^2 = E(X_2^2):$$

代入即得方差分解公式:

$$E(X_2^2) = E(E(X_2 | X_1)^2) + E(X_2 - E(X_2 | X_1))^2 = E(X_2^2):$$

: 第一项是 组内方差的平均 (知道 X_1 后 X_2 的残余变异), 第二项是组间方差 (不同 X_1 条件下条件均值的变化)。

$E(X_2^2) = E(E(X_2 | X_1)^2) + E(X_2 - E(X_2 | X_1))^2$ 定理是统计决策理论的核心结果, 说明了如何利用条件化改进估计量。

:

T 是 的无偏估计量: $E(T) = \theta$

$S = E(T | U)$ 是 T 关于充分统计量 U 的条件期望

: 证明 $E(S) = \theta$ 且 $E(S^2) \leq E(T^2)$, 即 S 比 T 更好 (均方误差更小)。

:

由全方差公式:

$$E(T^2) = E(E(T | U)^2) + E(T - E(T | U))^2 = E(S^2) + E(T - S)^2:$$

由于 $S = E(T | U)$, 有 $E(S) = E(T) = \theta$ (S 仍是无偏的)。

由方差分解式两边减去 θ^2 (注意 S 无偏), 得

$$E(T - \theta)^2 = E\left(\underbrace{T - E(T | U)}_0\right)^2 = E(S - \theta)^2 + E(T - S)^2 = E(S - \theta)^2 + E(T - S)^2:$$

: 条件化 (于充分统计量) 不会增加均方误差, 且在 T 不是充分统计量的函数时严格减少。这为用条件期望改进任意估计量提供了理论依据。

$P(X = x | Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)}$: 贝叶斯公式是连接先验、似然和后验的桥梁。

:

先验分布:

似然函数: $L(x | \theta) = f(x | \theta)$

C

$$jX \ jXj : KK^2 \ "2i$$

这三种分布构成了连续统计推断的支柱。理解它们之间的关系对于掌握统计学的数学基础至关重要。

$jXRX : KK \ X$ 函数架起了阶乘与积分之间的桥梁——这是数学中最美的恒等式之一。

. 27BMBiBQM 函数 $XP\hat{> Q : KK \{fi \ S \ Q\}$

$$\int_0^{\infty} x^{n-1} e^{-x} dx:$$

(递归公式):

$$\int_0^{\infty} x^n e^{-x} dx = n \int_0^{\infty} x^{n-1} e^{-x} dx:$$

这来自分部积分: [R.R.](#)

$$\int_0^{\infty} x^n e^{-x} dx = \left[x^n e^{-x} \right]_0^{\infty} + \int_0^{\infty} x^{n-1} e^{-x} dx = \int_0^{\infty} x^{n-1} e^{-x} dx:$$

对于正整数 n :

$$\int_0^{\infty} x^n e^{-x} dx = n!:$$

函数还与 Γ 函数有联系:

$$\Gamma(n) = \int_0^{\infty} t^{n-1} e^{-t} dt:$$

1 t KTH2 函数的值 $X \ E$

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

$jXkX : KK \ X$ 分布是 χ^2 上的连续分布,它统一了指数分布和卡方分布。

. 27BMBiBQM 分布 $X \ 0 \ O \ „u \ a \ e \ X \ \hat{a} \ T/7Q\}$

$$f(x) = \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-x/2}$$

$$\chi^2_{n-1} \leq x \leq \chi^2_n \Rightarrow P(\chi^2_{n-1} \leq x \leq \chi^2_n) = F(x) - F(x)$$

[R.R.](#) 函数递归公式的推导见附录 [OHS.nj](#) [Cuoo](#)。

C

χ^2 分布是 $E(n)$ ； 的特殊情形：如果 $X \sim \chi^2(n)$ ，则 $X \sim E(n/2)$ ；
：

$$EX = n; \quad X \sim n:$$

1 t K T H 2 $X = X_1, \dots, X_n \sim N(\mu, \sigma^2)$ $Q = X_1^2 + \dots + X_n^2 \sim \chi^2(n)$ $P(U < Q) = 1 - e^{-Q/2}$
D # ö : $K > V(\hat{\mu}) * R P \hat{U}$

样本方差的抽样分布与 χ^2 分布密切相关，这使它成为方差估计和假设检验的基础。

1 t K T H 2 样本方差分布 $XP \hat{B} X_1, \dots, X_n \sim N(\mu, \sigma^2)$ $Q = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \frac{\sigma^2}{n-1} \chi^2(n-1)$ $\hat{S}^2 = \frac{Q}{n-1}$ $\hat{Q} = \frac{Q}{\sigma^2}$

$$\frac{n-1}{2} \frac{S^2}{\sigma^2} \sim \chi^2(n-1) :$$

üò ø » ° ÷ ^ a \$ Q > ô u r â & - ^ N 5 c B ^ > V P Ū ĩ ĩ ^ — ~ ... ^ â
N ĩ L P o â ĩ P Ū

1 t K T H 2 卡方分位数 $X \sim \chi^2(n)$ $P(U < Q) = 1 - e^{-Q/2}$
u r Q > EX $Q = \chi^2(n)$ $Q = \chi^2(n)$:

6 > ĩ fi Q > [+ ? B b [U + U y X k 8 - y X 8 - y X d 8 X d 9 R y X j 9 - R k X 8 8 V

χ^2 分布是区间 $(0, \infty)$ 上的连续分布，特别适用于建模概率和比例。

. 2 7 B M B ĩ B Q M 分布 $X \sim \chi^2(n)$ $T = \frac{Q}{n}$

$$f(x) = \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-x/2} \quad 0 < x < \infty$$

s B ; $\frac{(\frac{n}{2})!}{(\frac{n}{2})!} Q = X \sim \chi^2(n)$; $P(U < Q) = 1 - e^{-Q/2}$

函数 B ; 使分布归一化，确保 $\int_0^\infty f(x) dx = 1$ 。
：

$$EX = \frac{n}{2}; \quad X \sim \frac{n}{2} :$$

R 9

：
； （均匀分布）
； （； 上的幂分布）

1 t K T H 2 分布的形状 $X \sim \chi^2(n)$ $P(U < Q) = 1 - e^{-Q/2}$

$Q = u + \sqrt{v}$
 $> Q = P(U < Q)$

R 9: 推导见附录 0H\$nj ·u@”。

$$\begin{aligned} &> \mu \\ &< \mu \end{aligned}$$

1. 正态分布的灵活性——通过不同的 μ 和 σ 值在 x 轴上捕捉各种形状——使其成为建模不确定概率的理想选择。

$$X \sim N(\mu, \sigma^2)$$

在所有概率分布中，正态分布占据着核心地位。它构成了统计推断、计量经济学、信号处理及许多其他领域的基石。

正态分布的重要性源于三个关键事实：

1. 中心极限定理：大量独立小因素的和近似正态分布。

2. 线性组合：正态变量的线性组合仍然是正态的。

含义

历史注记：正态分布由 Gauss 于 1796 年在研究测量误差时引入。虽然 Laplace 早些时候讨论过误差分布，但 Gauss 的工作巩固了正态分布在统计学中的核心地位。这就是为什么我们经常称它为 高斯分布 (Gaussian)。

$$X \sim N(\mu, \sigma^2)$$

正态分布的概率密度函数 (PDF) 为：

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}; \quad -\infty < x < \infty$$

$$X \sim N(\mu, \sigma^2) \Rightarrow \frac{X - \mu}{\sigma} \sim N(0, 1)$$

标准正态分布是 $N(0, 1)$ ，其 PDF 为 $\frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ ，其中 $z = \frac{x - \mu}{\sigma}$ 。若 $X \sim N(\mu, \sigma^2)$ ，则 $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$ 。这种标准化使得任何正态概率计算都可以转化为标准正态计算：

$$P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

1. 身高分布：假设身高 X 服从正态分布 $N(\mu, \sigma^2)$ ，求身高小于 170cm 的概率。

$$P(X \leq 170) = \Phi\left(\frac{170 - \mu}{\sigma}\right)$$

$$N(170, 10)$$

$$P(X \leq 170) = \Phi\left(\frac{170 - 175}{10}\right) = \Phi(-0.5)$$

1 t 2 ` + B b 2 XjXjXRd BM i mMBQK BbiBmiBQM Q i QMiBMmQmb ivT QM i
BMiptH(b; q) iπi τb i bτK KτM τM i bτK pτBτM τb iQb Q τ Bδbmτ
BbiBmiBQM rBi ,b Q QKX hτi Bb M b τM cX

1 t 2 ` + B b 2 XjXjXR BM i KτM τM pτBτM Q i BbiBmiBQMX
B Mi QK i T r FMQr iπi y - (1 y) - dy = $\int_1^{\infty} Q \tau HH > 0$
> 0X

1 t 2 ` + B b 2 XjXjXRN iKBM i QMbiτMi c BM τ Q i QHHQrBM, bQ iπi
τ f(x) Bb τ T

URV(x) = cx(1 - x) 0 < x < 1 xQ HbrX

UkV(x) = cx (1 - x) 0 < x < 1 xQ HbrX

UjV(x) = cx (1 - x) 0 < x < 1 xQ HbrX

1 t 2 ` + B b 2 XjXjXk GiX τp τM tTQMMiBτH BbiBmiBQMX

URQ x > 0 τM y > 0 bQr iπi P(X > x + y X > x) = P(X > y)X M i

tTQMMiBτH BbiBmiBQM τb i KKQvHbb TQTivX

UkVGi F(x) i Q τQMiBMmQmb τMQK pτBτH YX σbbmK iπi F(0) = 0 τM

0 < F(y) < 1 Q y > 0X amTTQb TQTivP(X > x + y X > x) = P(X > y)

QHb Q YX aQr iπi F(y) = 1 e- Q y > 0X

B Mi aQr iπi g(y) = 1 F(y) bπiBbb i mπiBQM g(y + z) = g(y)g(z)X

1 t 2 ` + B b 2 XjXXR A(z) = $-\infty \sqrt{} e^{-^2} dw$ bQr iπi (z) = 1 (z)X

1 t 2 ` + B b 2 XjXXk A BN(75;100) M P(X < 60) τM P(70 < X < 100) v
mbBM, Bi hτH AA Q i QKKτM T M QX K

1 t 2 ` + B b 2 XjXXj A BN(;) M bbQ iπi P[b < (X)/ < b] = 0:90
v mbBM, Bi hτH AA Q σTTMBt Q i QKKτM [M QX K

1 t 2 ` + B b 2 XjXX Gi X N(;) bQ iπi P(X < 89) = 0:90 τM P(X <
94) = 0:95X BM τM X

1 t 2 ` + B b 2 XjXXe A BN(;) bQr iπi E(X) = $\overline{2I}$ X

1 t 2 ` + B b 2 XjXXd aQr iπi i ,τT Q τ T N(;) τb TQBMib Q B MiBQM
πi x = τM x = + X

1 t 2 ` + B b 2 XjXXN iKBM i Nyi TMiBH Q i BbiBmiBQM rB Bb
N(65;25)X

1 t 2 ` + B b 2 XjXXRy A ^2 Bb i K, Q i τMQK pτBτH X M P(1 <
X < 9)X

1 t 2 ` + B b 2 XjXXRk GX N(5;10)X BMP[0:04 < (X 5) < 38:4]X

jX aS1*A G .Aah_A"lhAPLa

$$\begin{aligned}
& 1 \text{ t } 2^{-} + B \text{ p } 2 \text{ d } X X N \text{ a } \tau \nu \text{ i } Q H \tau i B Q M \text{ Q B M i } i r M \text{ i } B, i b \text{ Q } m b \tau M b \\
& \tau M \text{ r B p b } B b \text{ y X d y } \tau M \text{ i } K \tau M \text{ K } \tau H \text{ B, i } B b \text{ i } R y \text{ B M b } r B i \text{ b i } \tau M \tau p B \tau i B Q M \text{ k } \\
& B M b \text{ } \tau M \text{ i } K \tau M \text{ K } \tau H \text{ B, i } B b \text{ i } B M b \text{ r B i } b i \tau M \tau p B \tau i B Q M \quad 1.5 \text{ B M b X } \\
& \sigma b b m K B M, \tau \text{ B p } \tau B \tau i \text{ M Q K } \tau H \text{ B b i B m i B Q M } r \tau i \text{ B b i b i, m b b } Q \text{ i } B, i \text{ Q } \tau \text{ r Q K } \tau M \\
& r Q b \text{ m b } \tau M b \text{ B, i } B b \text{ e i } B M \text{ } \tau \text{ N W T B i B Q M } B M i p \tau H \text{ Q } B, i X
\end{aligned}$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_e X_R \text{ } \mathbb{G} i \tau p \tau \text{ } t \partial B b i B m i B Q M \text{ } r B i \text{ } R y \text{ } , b \text{ } Q \text{ } Q K X \text{ } B M \\ P(T > 2:228) Q K \text{ } B i \text{ } h \tau H \text{ } A A A \text{ } Q \text{ } v \text{ } m b B M, X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_e X_k \text{ } \mathbb{G} i \tau p \tau \text{ } t \partial B b i B m i B Q M \text{ } r B i \text{ } R \text{ } , b \text{ } Q \text{ } Q K X \text{ } \partial \\ i K B M \text{ } b b Q \text{ } i \tau i \text{ } P(b < T < b) = 0:90 X \text{ } l b \text{ } B i \text{ } h \tau H \text{ } A A A \text{ } Q \text{ } v \text{ } m b B M, X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_e X_j \text{ } \mathbb{G} i \tau p \tau \text{ } t \partial B b i B m i B Q M \text{ } r B i \text{ } 4 \text{ } , b \text{ } Q \text{ } Q K X \text{ } l b \\ t T b b B Q M \text{ } U j X_e X V \text{ } i Q \text{ } i K B M \text{ } i \text{ } F m i Q b B b \text{ } \mathbb{G} X \text{ } a \text{ } t B b \text{ } R X N X R \text{ } Q \text{ } i \text{ } M B i B Q M \\ Q \text{ } F m i Q b B b X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_e X_d \text{ } \mathbb{G} i \tau p \tau M \text{ } F \partial B b i B m i B Q M \text{ } r B i \text{ } T \tau \tau K i b \text{ } r \text{ } \tau M \text{ } r \text{ } X \\ o b b m K B M, i \pi i > 2 k \text{ } Q M i B M m \text{ } r B i \text{ } t \tau K T H \text{ } j X_e X_k \text{ } \tau M \text{ } B p \text{ } i \text{ } E(F) X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_e X_N \text{ } \mathbb{G} i \tau p \tau M \text{ } F \partial B b i B m i B Q M \text{ } r B i \text{ } T \tau \tau K i b \text{ } r \text{ } \tau M \text{ } r \text{ } X \text{ } \sigma, m \\ i \tau i \text{ } 1 / F \text{ } \tau b \text{ } \tau M \text{ } F \partial B b i B m i B Q M \text{ } r B i \text{ } T \tau \tau K i b \text{ } r \text{ } \tau M \text{ } r \text{ } X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_e X_R R \text{ } \mathbb{G} i \tau p \tau M \text{ } \sqrt{r} \text{ } r \text{ } i \text{ } B M T M M i \text{ } p \tau B \tau H b \text{ } W \text{ } \tau M \\ V \text{ } \tau b T i B p H v \text{ } M Q K \tau H \text{ } r B i \text{ } K \tau M \text{ } x Q \text{ } \tau M \text{ } p \tau B \tau M \text{ } R \text{ } \tau M \text{ } B \partial b m \tau \text{ } r B i \text{ } r \text{ } , b \\ Q \text{ } Q K X \text{ } a Q r \text{ } i \tau i \text{ } T \text{ } \tau b \text{ } \tau M \text{ } F \partial B b i B m i B Q M \text{ } r B i \text{ } T \tau \tau K i b \text{ } r \text{ } = 1 \text{ } \tau M \text{ } r \text{ } = r X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_e X_R k \text{ } a Q r \text{ } i \tau i \text{ } i \text{ } t \partial B b i B m i B Q M \text{ } r B i \text{ } 1 \text{ } , Q \text{ } Q K \text{ } \tau M \\ i \text{ } \tau m v \text{ } B b i B m i B Q M \text{ } \tau i \text{ } b \tau K X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_e X_R \text{ } G X \text{ } ; X \text{ } B B \text{ } r B i \text{ } Q K K Q M \text{ } B b i B m i B Q M \text{ } \tau p B M, i \text{ } T \\ f(x) = e^{-} \text{ } 0 < x < \text{ } x Q \text{ } H b r X \text{ } a Q r \text{ } i \tau i \text{ } Z = X \text{ } / X \text{ } \tau b \text{ } \tau M \text{ } F \partial B b i B m i B Q M X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_d X_R \text{ } a m T \tau Q b \text{ } \tau \text{ } (\text{ } ; \text{ }) \text{ } B b i B m i B Q M X X \text{ } \mathbb{G} e \text{ } X \text{ } a Q r \text{ } i \tau i \\ i \text{ } T Q \text{ } X \text{ } B b \text{ } , B p M \text{ } v \text{ } t T b b B Q M \text{ } U j X_d X V X \text{ } i K B M \text{ } i \text{ } Q \text{ } X \text{ } B M \text{ } i K b \text{ } Q \text{ } i \\ Q \text{ } \tau \text{ } \partial B b i B m i B Q M X \text{ } B p \text{ } i \text{ } K \tau M \text{ } \tau M \text{ } p \tau B \tau M \text{ } Q \text{ } X X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_d X_j \text{ } A M \text{ } t \tau K T H \text{ } j X_d X_R \text{ } B p \text{ } i \text{ } T Q \text{ } i \text{ } K B t i m \text{ } B b i B m i B Q M \\ , B p M \text{ } B M \text{ } t T b b B Q M \text{ } U j X_d X_e V \text{ } i M \text{ } Q i \tau B M \text{ } B i b \text{ } K \tau M \text{ } \tau M \text{ } p \tau B \tau M \text{ } \tau b \text{ } , B p M \text{ } B M \text{ } t T b b B Q M b \\ U j X_d X_d V \text{ } \tau M \text{ } U j X_d X V X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_d X \text{ } Q M b B i \text{ } K B t i m \text{ } B b i B m i B Q M (9/10) N(0; 1) + (1/10) N(0; 9) X \\ a Q r \text{ } i \tau i \text{ } B i b \text{ } F m i Q b B b \text{ } B b \text{ } X_j X$$

$$1 t 2^{-} + B b 2 \text{ } X_j X_d X_R \text{ } \mathbb{X} \text{ } \tau b \text{ } \tau \text{ } S \tau i Q \text{ } B b i B m i B Q M \text{ } r B i \text{ } T \tau \tau K i b \text{ } \tau M \text{ } \tau M \\ B c \text{ } B b \text{ } \tau \text{ } T Q b B i B p \text{ } Q M b i \tau M i \text{ } b Q r \text{ } \mathbb{X} \text{ } \tau b \text{ } \tau \text{ } S \tau i Q \text{ } B b i B m i B Q M \text{ } r B i \text{ } T \tau \tau K i b \\ \tau M \text{ } / c X$$

：二项分布 X $(n; p)$ 的矩母函数定义为

$$M(t) = E[e^{\text{ }}].$$

：求 $M(t)$ ，并由此导出均值和方差。

:

由定义:

$$M(t) = e^{\sum_{n=0}^{\infty} \frac{t^n}{n!} p^n (1-p)^{n+1}} :$$

将 $e^{p \sum_{n=0}^{\infty} \frac{t^n}{n!} p^n (1-p)^{n+1}}$ 提取出来:

$$M(t) = e^{p \sum_{n=0}^{\infty} \frac{t^n}{n!} p^n (1-p)^{n+1}} = e^{p(1-p)} e^{\sum_{n=0}^{\infty} \frac{t^n}{n!} p^n (1-p)^{n+1}} ;$$

其中最后一步使用了二项式定理。

对 $M(t)$ 求导:

$$M'(t) = \sum_{n=0}^{\infty} \frac{t^n}{n!} p^n (1-p)^{n+1} p ;$$

$$M''(t) = \sum_{n=0}^{\infty} \frac{t^n}{n!} p^n (1-p)^{n+1} p^2 = \sum_{n=0}^{\infty} \frac{t^n}{n!} p^n (1-p)^{n+1} p^2 ;$$

在 $t=0$ 处求值:

$$M'(0) = \sum_{n=0}^{\infty} \frac{0^n}{n!} p^n (1-p)^{n+1} p = p ;$$

$$M''(0) = \sum_{n=0}^{\infty} \frac{0^n}{n!} p^n (1-p)^{n+1} p^2 = p^2 ;$$

因此:

$$X = M''(0) - (M'(0))^2 = p^2 - p^2 = 0 ;$$

$d^2 X / d t^2 = X$: 若 $X \sim n ; p$ 和 $X \sim n ; p$ 独立, 证明 $X = X \sim n ; p$ 。

:

使用矩母函数方法。两独立随机变量和的矩母函数是它们的乘积:

 X_1, X_2 的矩母函数为:

$$M_{X_1+X_2}(t) = M_{X_1}(t) M_{X_2}(t) = e^{p(1-p)} e^{p(1-p)} = e^{2p(1-p)} :$$

这正是 $n \sim n ; p$ 的矩母函数。由于矩母函数唯一确定分布, 结论得证。

$d^2 X / d t^2 = X$: 负二项分布描述第 r 次成功前失败次数的分布。

: 推导 $p^r y^r = \sum_{y=0}^{\infty} p^r y^r$ 。

:

恰好有 y 次失败发生在第 r 次成功之前, 当且仅当:前 $y+r-1$ 次试验中恰好有 $r-1$ 次成功和 y 次失败第 $y+r$ 次试验是成功第一步的概率由二项分布给出: $\binom{y+r-1}{r-1} p^{r-1} (1-p)^y$ 。第二步的成功概率为 p 。

由独立性, 总概率为:

$$p^r y^r = \sum_{r=0}^{\infty} \binom{y+r-1}{r-1} p^{r-1} (1-p)^y p = \sum_{r=0}^{\infty} \binom{y+r-1}{r-1} p^r (1-p)^y ; y=0, 1, 2, \dots$$

验证归一性: 利用负二项级数 $\sum_{r=0}^{\infty} \binom{y+r-1}{r-1} p^r (1-p)^y = (1-p)^{-y}$, 可得 $p^r y^r = (1-p)^{-y}$ 。

d X 9 X X : 几何分布具有独特的无记忆性: $\sum_{k=1}^{\infty} P(X \geq k) = \sum_{k=1}^{\infty} \sum_{j=k}^{\infty} p(1-p)^{j-1}$ 。

由条件概率定义:

几何分布下, $\sum_{k=1}^{\infty} P(X \geq k) = \sum_{k=1}^{\infty} \sum_{j=k}^{\infty} p(1-p)^{j-1}$ (对于 $y = 1, 2, \dots$)。

因此:

$$\sum_{k=1}^{\infty} \sum_{j=k}^{\infty} p(1-p)^{j-1} = \sum_{j=1}^{\infty} \sum_{k=1}^j p(1-p)^{j-1} = \sum_{j=1}^{\infty} j p(1-p)^{j-1} = \frac{p}{p} = 1$$

证毕。

d X 8 X X : 求几何分布 $X \sim \text{Geo}(p)$ (支撑集 $\{1, 2, \dots\}$) 的均值和方差。

:

均值: 使用几何级数求和技巧。

$$E[X] = \sum_{k=1}^{\infty} k p (1-p)^{k-1} = p \sum_{k=1}^{\infty} k (1-p)^{k-1}$$

利用 $\sum_{k=1}^{\infty} k x^{k-1} = \frac{1}{(1-x)^2}$ ($|x| < 1$), 得:

$$E[X] = p \cdot \frac{1}{p^2} = \frac{1}{p}$$

方差: 先求 $E[X^2]$:

$$E[X^2] = \sum_{k=1}^{\infty} k^2 p (1-p)^{k-1} = p \sum_{k=1}^{\infty} k^2 (1-p)^{k-1}$$

由 $E[X] = \frac{1}{p}$ 和 $E[X^2] = \frac{1}{p^2}$, 得:

$$E[X^2] = \frac{1}{p^2} = \frac{1}{p} + \frac{1}{p^2}$$

因此:

$$E[X^2] = \frac{1}{p^2} = \frac{1}{p} + \frac{1}{p^2}$$

d X e X X : 推导负二项分布 $X \sim \text{NB}(r, p)$ 的。

:

使用概率生成函数的性质。负二项分布可以分解为 r 个独立几何随机变量之和:

$$X = G_1 + G_2 + \dots + G_r$$

其中每个 $G_i \sim \text{Geo}(p)$ (支撑集 $\{1, 2, \dots\}$)。

几何分布的 MGF 为 $M_G(t) = \frac{pe^{pt}}{1-(1-p)e^{pt}}$ ($t < -\ln(1-p)$)。

由于独立同分布之和：

$$M_t \quad M_t \quad \frac{p}{pe} \quad \frac{p}{pe} :$$

$dX dX \quad X$: 多项分布是二项分布对 k 个类别的推广。

: 推导联合

:

Γ 在 n 次独立试验中, 第 i 个类别出现 x 次的概率为 $\frac{\Gamma_1 \Delta}{1! 2! \cdots k!} p^i$, 其中 $\frac{\Gamma_1 \Delta}{1! 2! \cdots k!}$ 是多项式系数。

这正是 的形式。验证归一性: 由多项式定理, $\frac{\Gamma_1 \Delta}{1! \cdots k!} p^i$

$p \quad p$ 。

边缘分布: X 的边缘分布为 $n; p$, 因为忽略其他类别后, 每次试验中类别 i 出现的概率为 p 。

协方差: 对于 $i \neq j$,

$$X; X \quad X X \quad X \quad X :$$

利用多项分布的性质可得 $X; X \quad np p$ 。

$dX \times X \quad X$: 超几何分布描述不放回抽样。

: 推导 和矩。

:

: 从 N 件产品中不放回抽取 n 件, 恰好得到 x 件次品的概率为:

$$\frac{\Gamma \Delta \Gamma_- \Delta}{\Gamma \Delta} p x \quad \frac{\Gamma \Delta}{\Gamma \Delta} :$$

这来自组合计数: 选择 x 件次品的方式数乘以选择 $n - x$ 件好品的方式数, 除以从 N 件中选择 n 件的总方式数。

均值: $X \quad n \frac{D}{N}$ 。直观理解: 每次抽取次品的 概率 在不放回情况下仍为 $\frac{D}{N}$ (对称性)。

方差: $X \quad n \frac{D}{N} \frac{\Gamma \Delta}{\Gamma \Delta}$ 。

有限总体校正因子 $\frac{\Gamma \Delta}{\Gamma \Delta}$ 反映了不放回抽样与放回抽样的差异。当 $N \rightarrow \infty$ 时, 此因子接近 1。

$dX N X \quad S Q B b b Q M \quad X$: 求 分布的均值和方差。

:

均值:

$$X \quad \sum_{x=0}^{\infty} x \frac{e^{-\lambda} \lambda^x}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{(x-1)!} = e^{-\lambda} \lambda e^{\lambda} = \lambda :$$

方差: 先求 $X X$:

$$X X \quad \sum_{x=0}^{\infty} x^2 \frac{e^{-\lambda} \lambda^x}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{(x-2)!} = e^{-\lambda} \lambda^2 e^{\lambda} = \lambda^2 :$$

因此 X 的方差为：

$$D(X) = \sum_{k=0}^n k^2 \binom{n}{k} p^k (1-p)^{n-k} - [E(X)]^2$$

当 n 很大、 p 很小时，二项分布近似于泊松分布：

设 $X \sim P(\lambda)$ ，其中 $\lambda = np$ 。对固定的 k ：

$$\sum_{k=0}^{\infty} \binom{n}{k} p^k (1-p)^{n-k} = 1$$

写成：

$$\sum_{k=0}^n \frac{n!}{k!} p^k (1-p)^{n-k} = 1$$

当 $n \rightarrow \infty$ 时， $\lambda = np \rightarrow \lambda$ ，所以 $p \rightarrow 0$ 。因此：

$$\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = 1$$

证毕。

泊松分布的矩母函数： $M_X(t) = e^{\lambda(e^t - 1)}$ ：证明。

由定义：

$$M_X(t) = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} e^{kt}$$

使用分部积分 ($u = x$, $dv = e^{-x} dx$):

$$\int_0^{\infty} x e^{-x} dx = \int_0^{\infty} x^{-1} e^{-x} dx$$

边界项在两端均为零，因为 $x e^{-x} \rightarrow 0$ 当 $x \rightarrow \infty$ (指数衰减快于多项增长)，且当 $x \rightarrow 0$ 时 $x \rightarrow 0$ (> 0)。

泊松分布的矩母函数： $M_X(t) = e^{\lambda(e^t - 1)}$ ：推导；分布的，并求均值和方差。

由定义：

$$M_X(t) = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} e^{kt}$$

令 $z = e^t$, $dz = e^t dt$ ：

$$M_X(t) = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} z^k e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda z)^k}{k!}$$

利用 $\int_0^{\infty} z^{-s} e^{-z} dz = \Gamma(s)$ ($s > 0$)，得：

$$M_X(t) = e^{\lambda(z - 1)}; \quad t < \infty$$

Ne

jX aS1*A G .Aah_A"lhAPLa

求导:

$$M'(t) = t^{-1}; \quad M''(t) = -t^{-2};$$

在 $t = 1$ 处求值:

$$X = M'(1) = -1; \quad X = M''(1) = -2;$$

因此 $X = -1$ 。

$dX/dt = -1/t^2$: KK X : 若 X ; 和 X ; 独立, 证明 $X = X$; 。

:

使用 方法。独立随机变量和的 是 的乘积:

$$M_{1+2}(t) = M_1(t) M_2(t) = t^{-1} t^{-2} = t^{-3};$$

这正是 ; 的 。证毕。

$dX/dt = -1/t^2$: 推导 ; 分布的均值和方差。

:

均值:

$$X = \int_0^1 x x^{-1} dx = \int_0^1 x^{-1} dx = \frac{B}{B};$$

利用 B ; $\int_0^1 x^{-1} dx = B$; , 得:

$$X = 1;$$

方差: 先求 X :

$$X = \frac{B}{B};$$

因此:

$$X = X = X = \frac{B}{B};$$

$dX/dt = -1/t^2$ @ X : 在贝叶斯统计中, 分布是二项分布的共轭先验。

:

设 $X \sim \text{Bin}(n; p)$, 先验 p ; 。

似然: $L(p) = p^x (1-p)^{n-x}$ 。

先验: $p \sim \text{Beta}(a, b)$ 。

后验:

$$p(x) \propto p^x (1-p)^{n-x} p^{a-1} (1-p)^{b-1} = p^{a+x-1} (1-p)^{b+n-x-1};$$

这正是 x ; $n+x$ 的核。因此后验仍是 分布。

这就是 共轭先验 的含义: 先验和后验属于同一分布族。

$dXReX$ X : 推导 N ; 的。

标准化方法。设 $Z \sim N$; , 则 $X = Z$ 。

$$M(t) = E[e^{-t^T X}] = E[e^{-t^T Z}] :$$

对 $Z \sim N$; , 完成平方:

$$M(t) = \int_{-\infty}^{\infty} e^{-t^T z} \phi(z) dz = \int_{-\infty}^{\infty} e^{-t^T z} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2} dz = e^{\frac{1}{2}t^T t} :$$

因此:

$$M(t) = e^{\frac{1}{2}t^T t} :$$

$dXRdX$ X : 正态分布在线性变换下闭合。

设 $X_1 \sim N$; , $X_2 \sim N$; 独立。

$Y = aX_1 + bX_2$ 的 :

$$M_Y(t) = E[e^{-tY}] = E[e^{-t(aX_1 + bX_2)}] = M_{X_1}(at) M_{X_2}(bt) :$$

代入正态 :

$$M_Y(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(at)^2} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(bt)^2} = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(a^2 + b^2)t^2} :$$

这正是 $N(a^2 + b^2)$ 的。证毕。

$dXR3X$ X : 推导二元正态分布的联合。

由二元正态的定义, $X_1; X_2$ 的联合可写成矩阵形式。联合为:

$$M(t_1; t_2) = e^{-\frac{1}{2}(t_1^2 + t_2^2)} :$$

利用条件分布或矩阵形式可证:

$$M(t_1; t_2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(t_1^2 + t_2^2)} \phi(z_1, z_2) dz_1 dz_2 :$$

$dXRtNX$ $T/7$ X : t 分布由 $T = \frac{Z^2}{U/n}$ 定义, 其中 $Z \sim N$; , n 独立。

使用变量变换法。设 $U \sim \chi^2_n$, 则 $T = \frac{Z^2}{U/n}$, U 与 Z 独立。

联合分布: $f_{Z,U}(z,u) = \phi(z) f_U(u)$ 。

变换 $T; U \rightarrow Z; U$ 的雅可比为 $|J| = \frac{1}{2} \sqrt{u/n}$ 。

因此 T 的边缘为:

$$f_T(t) = \int_0^{\infty} f_{Z,U}\left(\sqrt{t u/n}, u\right) \frac{1}{2} \sqrt{u/n} du :$$

完成积分（标准推导）可得：

$$f(t) = \frac{((n+1)/2)}{\Gamma(n/2)} \left(1 + \frac{t}{n}\right)^{-n/2} :$$

设 $X_1, \dots, X_n$ 独立， F 分布由 $F = \frac{X_1^2/m}{X_2^2/n}$ 定义，其中 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立。

设 $W = F$, $V = X_2^2$ ，则 $X_1^2 = W \frac{m}{n} V$ 。

变换的雅可比为 $J(x; x) / J(w; v) = \frac{m}{n} v$ 。

积分掉 v 可得 W 的 PDF:

$$f(w) = \frac{((m+n)/2)}{\Gamma(m/2) \Gamma(n/2)} \frac{m^{m/2} n^{n/2}}{n} \frac{w^{m/2}}{(1 + mw/n)^{(m+n)/2}}; \quad w > 0:$$

求 $F(m; n)$ 分布的均值和方差。

由定义 $F = \frac{X_1^2/m}{X_2^2/n} = \frac{n}{m} \frac{X_1^2}{X_2^2}$ ，其中 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立。
 $E(F)$ 的存在性要求 $n > 2$:

$$EF = \frac{n}{m} \frac{E[X_1^2]}{E[X_2^2]} = \frac{n}{m} \frac{m}{n} = \frac{n}{n-2}; \quad n > 2:$$

方差的计算类似，需要 $E[F^2]$ ，要求 $n > 4$:

$$D(F) = \frac{2n(m+n-2)}{m(n-2)(n-4)}; \quad n > 4:$$

$NW \sim \frac{1}{4} \wedge \hat{a}$

: : : — — : : : : : : : ; : :

Q- ã\$ NW Ü¼ 2 ‡ U † Ÿ ‡ - u ¶ R X R y k X N Š P Ú U î ^ â æ < K y Q Ÿ
2 ‡ - u # ¶ ¿ 9 ¶ î † Ÿ ‡ P Ú R 8

: 如果 6 , 可以使用 近似 (不要求合并方差), 自
由度由 公式给出:

$$\frac{S^2_{n1} + S^2_{n2}}{S^2_{n1} + S^2_{n2}} :$$

k X j X 9 X k X k X 比较两个二项总体中成功概率的差异是统计
学中的经典问题。例如, 比较两种药物的治愈率、两个地区的患病率等。

设有两个独立总体:

总体 : X n ; p , 观测值 x
总体 : Y n ; p , 观测值 y
样本比例 $p = x/n$, $p = y/n$ 。我们关心比例差 $p - p$ 。

当样本量较大时 (np 、 $n(1-p)$ 、 n_1p 、 $n_1(1-p)$ 均), 由中心极限定理:

$$p - p \sim N(0, \frac{p(1-p)}{n} + \frac{p(1-p)}{n}) :$$

用样本比例替代总体比例, 得到 的近似 置信区间:

$$p - p \pm z \sqrt{\frac{p(1-p)}{n} + \frac{p(1-p)}{n}} :$$

在医学试验、调查研究中, 我们经常需要回答
两组之间的差异是否显著 , 比例差及其置信区间提供了回答这个问题的框架。

1 t K T H 2 年脊髓灰质炎疫苗试验 X R N ` a τ H F P R q i „ ø è
« ” W p A 9 â ¹ P m „ ø ® ä P Ú
„ ø \$ ë Q - M ¼ a ¹ > î ý i Q ç ^ w ° Q P Ú

Q 8	¥ é æ n	P R q Ø , ®	U , p
i Q	n ;	x	p :
^ w ° Q	n ;	y	p :

¥ é U , Ð p p : Q > i Q ' ¬ Q Ÿ & Õ i î É Q æ P Ú
ë Ô Q -

$$\frac{p_1 - p_2}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} :$$

R 8 两独立正态均值差 $\mu_1 - \mu_2$ 的置信区间基于 $T = (X_1 - X_2 - (\mu_1 - \mu_2)) / \sqrt{S_1^2/n_1 + S_2^2/n_2} \sim t$,
其中 由 q 2 H + ? @ a i i 2 公式近似. 2 详细推导见附录 b 2 + i B Q M j

直到现在，我们讨论的都是连续型数据。但统计学同样关注——即计数数据。例如：选举中支持不同候选人的选民人数、不同药物治疗后的治愈 未治愈人数。

：比较观测频数与期望频数。如果两者差异很大，说明数据可能不服从假设的分布。

：数据是否来自某个特定分布？

设 $O_1, \dots, O_k$ 是 k 个类别的观测频数， $E_i = np_i$ 是 H_0 下的期望频数。

：

$$\frac{(O_i - E_i)^2}{E_i}$$

在 H_0 下， $\chi^2 \sim \chi^2_{k-1}$ （大样本近似）。拒绝 H_0 当 $\chi^2 > \chi^2_{\alpha, k-1}$ 。

： $\frac{(O_i - E_i)^2}{E_i}$ 衡量每个类别的偏差，平方消去正负号，除以 E_i 进行标准化，求和得到总体偏差。²⁰

图 2. 自由度为 $k-1$ 的卡方分布，显著性水平 α ： $\chi^2_{\alpha, k-1}$ 的拒绝域（右侧尾部）。当检验统计量 $\chi^2 > \chi^2_{\alpha, k-1}$ 时，拒绝原假设。

投掷一枚均匀骰子 n 次，观测到各面的次数记录如下：

点数 i		合计
观测频数 O_i		

如果骰子是均匀的（ H_0 ：骰子公平），每个面的期望频数为 $E_i = n/6$ 。

计算 χ^2 统计量：

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

²⁰检验统计量 $\chi^2 = \sum_{i=1}^k (O_i - E_i)^2 / E_i \xrightarrow{d} \chi^2_{k-1}$ ，大样本下近似卡方分布。详细推导见附录。

由于 $t = 8 > 3.84$, 我们 H_0 ——两种药物的疗效存在显著差异。药物 A 的治愈率为 75%, 显著高于药物 B 的 50%。

有些概率和期望无法解析计算——积分可能没有闭式解, 分布可能过于复杂。这时, 蒙特卡罗方法提供了一条出路。

蒙特卡罗方法: 用随机模拟来近似计算。如果我们可以从某个分布抽样, 就可以通过大量重复实验来估计任何期望。

大数定律保证了模拟的收敛性:

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \rightarrow [g(X)]:$$

这意味着: 只要模拟次数足够多, 样本均值可以任意接近真实期望。

重要性抽样: 当目标分布 $f(x)$ 难以直接抽样时, 我们可以利用更容易抽样的提议分布 $g(x)$:

选择提议分布 $g(x)$, 满足 $f(x) \leq M g(x)$ (对某个 $M > 1$)

生成 $Y \sim g$ 和 $U \sim \text{Uniform}(0, 1)$ 独立

若 $U \leq f(Y)/(M g(Y))$, 接受 $X = Y$; 否则拒绝, 返回步骤

接受-拒绝算法的接受概率为

$$P(\text{接受}) = \frac{1}{M}:$$

其中 $M = \max_x f(x)/g(x)$ 。^{kR}

接受率 $1/M$ 是算法的效率指标。若 M 很大, 接受率很低, 算法效率差。寻找紧的 M 值 (即尽可能小的上界) 是算法实现的关键。

例: 用重要性抽样生成标准正态随机变量 $X \sim N(0, 1)$ 。取 $g(x) = \frac{1}{2} e^{-|x|}$, $f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ 。

$$\frac{f(x)}{g(x)} = \frac{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}}{\frac{1}{2} e^{-|x|}} = \frac{2}{\sqrt{2\pi}} e^{-x^2/2 + |x|} = \frac{2}{\sqrt{2\pi}} e^{-\frac{1}{2}(x^2 - 2|x|)} = \frac{2}{\sqrt{2\pi}} e^{-\frac{1}{2}(x-1)^2 + \frac{1}{2}} = \frac{2}{\sqrt{2\pi}} e^{\frac{1}{2}} e^{-\frac{1}{2}(x-1)^2} = \frac{2}{\sqrt{2\pi}} e^{\frac{1}{2}} = 1.52$$

因此 $M = 1.52$ 。

接受-拒绝算法的接受概率为

接受-拒绝算法的接受概率为

接受-拒绝算法的接受概率为

接受-拒绝算法的接受概率为

接受-拒绝算法的接受概率为

接受-拒绝算法的接受概率为

接受-拒绝算法的接受概率为

接受-拒绝算法的接受概率为

^{kR} 接受-拒绝算法的推导及收敛性证明见附录 B.2.1。

++2Ti2/ l@ +U ++2Ti2/- uV
B7 UH2M;i?U ++2Ti2/V =4 LV #`2 F

,5Ö/Ô 4 L f H2M;i?U ++2Ti2 /("eB)X/d dÖV

Q-#®5Ö : : Qÿ•½-[Ö RXkò τmv ¥é ý ä ò S
đ ¥ é PÚ -[â ¥ é ì, EQHKQ,QQpðaKBMMQp p> : QœQÿÜ"Ü ö Sđ
>VPÚ

Cauchy τmv >V2Sđ>V•đQpQ> è
•PÙP QœQÿJb*‘mPÚü^a Ur f x g x ì ô ò ®®pîÖU#HK®Qÿc
¬7 q¶â#®5PÚ ²²

：估计量的抽样分布是统计推断的基础，但这个分布在大多数情况下难以解析计算。例如，样本中位数 m 的分布无法用初等函数表达。

的解决思路既简单又巧妙：

：样本就像总体。如果我们有了一个好 的样本，为什么不从这个样本中有放回地再次抽样，模拟重复实验的过程？

：

从原始样本中有放回地抽取 n 个观测，形成一个 样本 $X^*; \dots; X^*$
计算 复制 $T^* \quad g X^*; \dots; X^*$
重复步骤 多次（如 B 次），得到 $T^*; \dots; T^*$
用 $T^*; \dots; T^*$ 的经验分布近似 T 的抽样分布

： 的 置信区间为

$T^* \quad ; \quad T^* \quad _ \quad :$

：如果样本是总体的良好代表，那么从样本有放回抽样就是在模拟 从总体中抽取样本 的过程。 T^* 的分布反映了 T 的抽样分布的近似。²³

的强大之处在于它的通用性——几乎任何估计量都可以用 近似其分布，不需要繁复的数学推导。这使它成为现代统计实践中的重要工具。

置信区间的构造方法直观且易于实现，特别适合复杂统计量。

：

²²选择 因为 $f(x)/g(x)$ 在整个实轴有界且接近常数，使得 M 较小、接受率高。 提议分布的选取技巧及 M 的优化方法见附录 。

²³核心思想：从样本有放回重抽样， T 的分布近似 T 的抽样分布。理论依据：经验分布函数收敛到总体分布函数。 的理论基础及更多细节见附录 。

RRe 9X aPJ1 1G1J1Lh _u ah hAahA* G AL61_1L*1a

从原始样本 $x_1, \dots, x_n$ 中有放回随机抽取 n 个观测，形成第一个样本

计算感兴趣的统计量 T （如样本均值、中位数、两样本均值差等）

独立重复步骤 共 B 次（如 $B=1000$ ），得到 B 个 复制 $T_1, \dots, T_B$

取 和 分位数： $T_{(1)}$ 和 $T_{(B)}$

构造置信区间

$T_{(1)}; T_{(B)}$:

如果 复制 T 的分布很好地近似了 T 的真实抽样分布，那么 T 的 分位数和 分位数之间的区域就包含了 T 的真实值的概率。

B : B 越大，置信区间的变异性越小。通常选择 B 到 B 。现代计算条件下， B 是常见默认值。

1 t K T H 2 分布的 $X \sim N(\mu, \sigma^2)$; $Q > \epsilon \Rightarrow VQ \check{K} \tau M Ryy Q \check{Q} \check{Y} c uyn \hat{a}^{-1} \neq \acute{e} \acute{P} \acute{U} g \grave{e} \neq [ur \hat{a} NyW \sim \frac{1}{4} \wedge \hat{a} \acute{P} \acute{U} \hat{O} J \neq \acute{e} ur x : \acute{P} \acute{U} \acute{a} c TMiBH QQibitT \tilde{A} \hat{a} Q \check{Y} B \ddot{m} u \neq Q- b2iXb22/U9kV " l@ jyyy M l@ 8y t l@ `; KK UM- b? T24R- ` i256$ f9# yV O hX# QQi l@ `2THB+ i2U"- K2 MUb KTH2Ut- M- `2TH +24h_I1VV HT? l@ yXRy *A l@ [m MiBH2UhX# QQi- +U HT? fk- R@ HT? fkVV O *A(8W 8-5÷="8æ 38Xk O *A(N8W 8-5÷="8æ RyNX3 NyW QQibitT A Ö :; : PÚ 2 ‡ ' ^ â x z : n̄ : : — :; : Q U Q Q Q ibitT ^ â ' PQ > + æ Š ² Î H G & Q Q PÚ k9$

不仅可以构造置信区间，还可以用于假设检验。当原假设下检验统计量的分布难以解析计算时， 提供了有效的近似方法。

:

设有两个独立总体，我们想检验 H_0 H_1 。

传统方法：使用 t 检验，依赖正态性或中心极限定理。

方法：

^{k9, *} 区间通过偏差校正和加速因子改进，形式为 $[\hat{\mu}_1; \hat{\mu}_2]$ 。更多 "QQibi 置信区间的比较见附录 b2+iBQM8

计算观测到的统计量： $T_{\text{obs}} = \bar{x} - \bar{y}$

在 H_0 下，将两样本合并，从合并数据中有放回抽样
具体步骤：

合并两样本得 $x_1, \dots, x_n; y_1, \dots, y_n$

从合并数据中随机抽取 n 个得到样本 x^* ，抽取 n 个得到样本 y^*

计算 $T^* = \bar{x}^* - \bar{y}^*$

重复步骤 共 B 次，得到 B 个 T^* 值

计算 p 值

$$p = \frac{\text{number of } T^* \leq T_{\text{obs}}}{B}$$

其中 $T_{\text{obs}} = \bar{x} - \bar{y}$ 是观测到的统计量。

：在 H_0 下，两总体分布相同，因此从合并数据中有放回抽样相当于 模拟 在原假设成立时重复实验的过程。

：当样本量固定时， 检验枚举所有可能的分组（当 n_1, n_2 较小时可行）；当 n_1, n_2 较大时， 近似提供了计算上可行的替代方案。

Example

两总体均值差

检验 $H_0: \mu_1 = \mu_2$ vs $H_a: \mu_1 \neq \mu_2$

σ_1, σ_2 已知

$n_1 = 10, n_2 = 10$

Q 8	¥ é æ n	¥ é u r x
J σ	n	x :
J	n	x :

$T_{\text{obs}} = \bar{x}_1 - \bar{x}_2 = 2.5 - 1.5 = 1.0$

$B = 1000$ 次模拟

p 值

$p = \frac{\text{number of } T^* \leq T_{\text{obs}}}{B} = \frac{10}{1000} = 0.01$

结论：拒绝 H_0 ，认为两总体均值存在显著差异。

tn nbi ` l@ b KTH2UTQQH2/- jy- `2TH +24h_l1V

tn"nbi ` l@ b KTH2UTQQH2/- j8- `2TH +24h_l1V

K2 MUtn nbi `V @ K2 MUtn"nbi `V

'V

Tnp Hm2 l@ K2 MU #bUhX#QQiV =4 #bU8XeVV

O Tnp Hm2 yXykj

$T_{\text{obs}} = 1.0$: $p = 0.01$ 拒绝 H_0

25

Exercise . $R\ QiQ\ GBiBK\ \pi\tau\ hrMiv\ KQiQb\ r\ Tmi\ QM\ ibi\ mM\ \tau\ B,\partial iKT\tau im\ biiBM,X\ h\ HBiBKb\ BM\ Qmb\ Q\ i\ KQiQb\ mM\ ib\ QMBiBQMb\ \tau\ ,BpM\ HQRX\ amTTQb\ r\ \tau bbmK\ i\tau i\ i\ HBiBK\ Q\ \tau\ KQiQ\ mM\ ib\ QMBiBQMbX\ \tau b\ \tau\ (1 ;)\ BbiBmiBQMX$

$U\tau VPi\tau BM\ \tau\ BbiQ,\tau K\ Q\ i\ \tau i\tau\ \tau M\ QpH\tau v\ Bi\ rBi\ \tau\ MbBiv\ biBK\tau iX\ \tau b\ QM\ iBb\ THQi\ Q\ vQm\ iBMF\ i\tau i\ (1 ;)\ KQH\ Bb\ BH$
 $UV\ \sigma bbmKBM,(\frac{1}{2} ;)\ KQH\ Qi\tau BM\ i\ K\tau tBKmK\ HBFHBQQ\ biBK\tau i\ \tau M\ HQ\tau i\ Bi\ QM\ vQm\ BbiQ,\tau KX$
 $UV\ Pi\tau BM\ i\ b\tau KTH\ KB\tau M\ Q\ i\ \tau i\tau X\ q\tau i\ T\tau Ki\ Bb\ Bi\ biBK\tau iBM,$
 $UV\ \tau b\ QM\ i\ KH\ r\tau i\ Bb\ \tau MQi\ biBK\tau i\ Q\ i\ KB\tau M\ Q\ X$

Exercise . $k\ \tau b\tau HH\ SH\tau v\ qB,ib\ \tau\ i\ rB,ib\ Q\ ke\ TQbbBQM\tau H\ \tau b\tau HH\ TBibX\ amTTQb\ r\ \tau bbmK\ i\tau i\ i\ rB,i\ Q\ \tau\ TQbbBQM\tau H\ \tau b\tau HH\ TBi\ Bb\ MQK\tau HHv\ BbiBmi\ rBi\ K\tau M\ \tau M\ p\tau B\tau M\ X$

$U\tau VPi\tau BM\ \tau\ BbiQ,\tau K\ Q\ i\ \tau i\tau X\ \tau b\ QM\ iBb\ THQi\ Bb\ \tau\ MQK\tau H\ TQ\tau BHBiv\ KQH\ BH$
 $UV\ Pi\tau BM\ i\ K\tau tBKmK\ HBFHBQQ\ biBK\tau ib\ Q\ \tau M\ / \ X$
 $UV\ lbBM,i\ BMQKB\tau H\ KQH\ Qi\tau BM\ i\ K\tau tBKmK\ HBFHBQQ\ biBK\tau i\ Q\ i\ TQTQ\partial\ iBQ\tau MQ\ TQbbBQM\tau H\ \tau b\tau HH\ TBib\ rQ\ rB, Qp\ kR\ TQmMbX$
 $UV\ iKBM\ i\ KH\ Q\ p\ \tau bbmKBM, i\tau i\ i\ rB,i\ QHHQrb\ i\ MQK\tau H\ TQ\tau BHBiv\ KQHN(;)X$

Exercise . $j\ SQBbbQM\ mbiQK\ \sigma Bp\tau Hb\ amTTQb\ i\ MmK\ Q\ mbiQKbX\ i\tau i\ Mi\ \tau\ biQ\ irM\ Nyy\ \tau XKX\ \tau M\ Ryyy\ \tau XKX\ QHHQrb\ \tau\ SQBbbQM\ BbiBmiBQM\ rBi\ T\tau Ki\ X\ amTTQb\ \tau\ \tau MQK\ b\tau KTH\ Q\ i\ MmK\ Q\ mbiQKb\ Q\ Ry\ \tau vb\ bmHib\ BM\ p\tau Hmb\ N\ d\ N\ R\ Ry\ Rj\ RR\ d\ k\ RkX$

$U\tau ViKBM\ i\ K\tau tBKmK\ HBFHBQQ\ biBK\tau i\ Q\ X\ aQr\ i\tau i\ Bi\ Bb\ \tau M\ mMB\tau b\ biBK\tau iQX$
 $UV\ \tau b\ QM\ ib\ \tau i\tau\ Qi\tau BM\ i\ \tau HBx\tau iBQM\ Q\ vQm\ biBK\tau iQX\ tTH\tau BM\ Bib\ K\tau M\partial\ BM,X$

Exercise . $Bv\ GBFHBQQ\ m\tau iBQMb\ Q\ t\tau KTH\ XRXj\ pBv\ m\tau iBQMb\ UXR XV\partial UXR XVX$

Exercise . $Pai\tau iBbiBb\ SQ\tau BHBiv\ Gi\ X ; X ; :: ; X\ \tau\ \tau MQK\ b\tau KTH\ QK\ \tau\ QMiBMmQmb\partial ivT\ BbiBmiBQMX$

$U\tau VBM\ P(X\ X) \ P(X\ X ; X\ X) :: P(X\ X ; i = 2 ; 3 ; :: ; n)X$

$UV amTTQb \text{ } i \text{ } b\tau KTHBM, QMiBMmbXmMBBMQ \text{ } HQM, i \text{ } bK\tau HHbi \text{ } Qbp\tau iBQMX$
 $Gi \text{ } Y \text{ } m\tau H \text{ } i \text{ } MmK \text{ } Q \text{ } iB\tau Hb \text{ } UMQi \text{ } BMHm\text{ } \text{ } BM,mMi\text{ } \text{ } BHBb \text{ } MQ \text{ } HQM, i$
 $bK\tau HHbiX \text{ } aQr \text{ } i\tau \text{ } \mathbb{P}(Y = y) = \text{---} \text{ } y = 1; 2; 3; \dots X$
 $UV QKTmi \text{ } i \text{ } K\tau M \text{ } \tau M \text{ } p\tau B\tau M \text{ } Q \text{ } \text{ } Y \text{ } B \text{ } iv \text{ } tBbiX$

Exercise 9 $\times e \text{ } \tau B\tau M \text{ } Q \text{ } S \text{ } biBK\tau iQ \text{ } QMbB \text{ } i \text{ } biBK\tau iQ \text{ } Q \text{ } i \text{ } TK \text{ } BM$
 $tTbbBQM \text{ } UXRXRyVX \text{ } q \text{ } bQr \text{ } i\tau i \text{ } iBb \text{ } biBK\tau iQ \text{ } Bb \text{ } mMB\tau bX \text{ } BM \text{ } i \text{ } p\tau B\tau M \text{ } Q \text{ } i$
 $biBK\tau iQ \text{ } \tau M \text{ } Bib \text{ } K, X$

Exercise 9 $\times a \text{ } aQiiBb \text{ } aQQHBHM \text{ } v \text{ } QHQb \text{ } h \text{ } \tau i\tau \text{ } bi \text{ } QM \text{ } aQiiBb \text{ } bQQHBH\partial$
 $M \text{ } BMHm \text{ } i \text{ } v \text{ } QHQb \text{ } Q \text{ } i \text{ } BHMx \text{ } h \text{ } mMBb \text{ } Q \text{ } iB \text{ } v \text{ } QHQb \text{ } \tau \text{ } Hm$
 $kNd \text{ } GB, i \text{ } eeNd \text{ } BmK \text{ } dRR \text{ } \tau F \text{ } RdX \text{ } lb \text{ } ib \text{ } mMBb \text{ } iQ \text{ } Qi\tau BM \text{ } \tau \text{ } \tau$
 $\tau i \text{ } \tau M \text{ } \tau M \text{ } biBK\tau i \text{ } Q \text{ } i \text{ } \tau bbQB\tau i \text{ } TKX$

Exercise 9 $\times 3G \text{ } Q \text{ } SQBbbQM \text{ } S \text{ } \sigma bbmKBM, i\tau i \text{ } i \text{ } \tau i\tau \text{ } BM \text{ } t\tau KTH \text{ } XRXe$
 $r \text{ } \tau rM \text{ } QK \text{ } \tau \text{ } SQBbbQM \text{ } BbiBmiBQM \text{ } rBi \text{ } K\tau M \text{ } Qi\tau BM \text{ } i \text{ } KH \text{ } Q \text{ } \text{ } \tau M \text{ } iM \text{ } mb \text{ } Bi$
 $iQ \text{ } Qi\tau BM \text{ } i \text{ } KH \text{ } Q \text{ } i \text{ } TKX \text{ } QKT\tau i \text{ } KH \text{ } Q \text{ } i \text{ } TK \text{ } iQ \text{ } i \text{ } MQMT\tau\tau KiB \text{ } biBK\tau iX$

Exercise 9 $\times N \text{ } LQMT\tau\tau KiB \text{ } MbBiv \text{ } biBK\tau iQ \text{ } QMbB \text{ } i \text{ } MQMT\tau\tau KiB \text{ } b\partial$
 $iBK\tau iQ \text{ } Q \text{ } \tau \text{ } TX$

$U\tau VPi\tau BM \text{ } Bib \text{ } K\tau M \text{ } \tau M \text{ } iKBM \text{ } i \text{ } B\tau b \text{ } Q \text{ } i \text{ } biBK\tau iQX$
 $UV \text{ } Pi\tau BM \text{ } i \text{ } p\tau B\tau M \text{ } Q \text{ } i \text{ } biBK\tau iQX$

Exercise 9 $\times R \text{ } Ry \text{ } \tau BM \text{ } \tau i\tau \text{ } \sigma M\tau HvbBb \text{ } hBb \text{ } \tau i\tau \text{ } bi \text{ } QMbBbib \text{ } Q \text{ } \tau \text{ } b\tau KTH \text{ } Q \text{ } \tau BM$
 $BMQK\tau iBQM \text{ } Q \text{ } QM \text{ } y \text{ } QHH, bimMibX \text{ } h \text{ } p\tau B\tau Hb \text{ } BMHm \text{ } ,M \text{ } B, i \text{ } rB, i$
 $i \text{ } AZ \text{ } K\tau b mKMib \text{ } \tau M \text{ } A \text{ } QmMibX$

$U\tau VGQ\tau \text{ } i \text{ } \tau \text{ } H \text{ } \tau M \text{ } TBMi \text{ } i \text{ } A \text{ } \tau i\tau X$
 $UV \text{ } Pi\tau BM \text{ } \tau \text{ } BbiQ, \tau K \text{ } Q \text{ } i \text{ } \tau i\tau X \text{ } QKKMi \text{ } QM \text{ } i \text{ } b\tau TX$
 $UV \text{ } PpH\tau v \text{ } i \text{ } \tau mHi \text{ } MbBiv \text{ } biBK\tau iQX \text{ } QKKMi \text{ } QM \text{ } i \text{ } b\tau TX$
 $UV \text{ } Pi\tau BM \text{ } i \text{ } b\tau KTH \text{ } K\tau M \text{ } \tau M \text{ } bi\tau M\tau pB\tau iBQM \text{ } \tau M \text{ } QpH\tau v \text{ } i \text{ } MQK\tau H \text{ } T \text{ } rBi$
 $ib \text{ } biBK\tau ibX \text{ } QKKMi \text{ } QM \text{ } i \text{ } iX$
 $UV \text{ } iKBM \text{ } i \text{ } TQTQiBQM \text{ } b \text{ } Q \text{ } i \text{ } \tau i\tau \text{ } rBiBM \text{ } R \text{ } \tau M \text{ } k \text{ } bi\tau M\tau pB\tau iBQM \text{ } b \text{ } Q \text{ } i$
 $b\tau KTH \text{ } K\tau MX$

Exercise 9 $\times R \text{ } RR \text{ } aTQ \text{ } GB, i \text{ } \tau i\tau \text{ } hBb \text{ } Bb \text{ } \tau \text{ } \tau KQmb \text{ } \tau i\tau \text{ } bi \text{ } QM \text{ } i \text{ } bTQ$
 $HB, i \text{ } Q \text{ } v \text{ } i \text{ } bBMiBbi \text{ } aBKQM \text{ } LrQKX$

$U\tau VGQ\tau \text{ } i \text{ } \tau \text{ } HX \text{ } Bbmbb \text{ } i \text{ } \tau i\tau X$
 $UV \text{ } Pi\tau BM \text{ } \tau \text{ } BbiQ, \tau K \text{ } Q \text{ } i \text{ } \tau i\tau X \text{ } QKKMi \text{ } QM \text{ } i \text{ } b\tau TX$
 $UV \text{ } PpH\tau v \text{ } i \text{ } \tau mHi \text{ } MbBiv \text{ } biBK\tau iQX \text{ } QKKMi \text{ } QM \text{ } i \text{ } b\tau TX$
 $UV \text{ } PpH\tau v \text{ } i \text{ } MQK\tau H \text{ } T \text{ } rBi \text{ } b\tau KTH \text{ } K\tau M \text{ } \tau M \text{ } bi\tau M\tau pB\tau iBQMX \text{ } QKKMi \text{ } QM$
 $i \text{ } iX$

Rky

9X aPJ1 1G1J1Lh _u ah hAahA* G AL61_1L*1a

$UV iKBM i TQTQiBQM b Q i \tau i \tau rBiBM R \tau M k bi\tau M \tau pB\tau iBQM b Q i$
 $b\tau KTH K\tau MX$

Exercise 9 X.Rk $LQK\tau H QMM AMip\tau H b Gi i Qbp p\tau H m Q i K\tau M$
 $\bar{X} \tau M Q i b\tau KTH p\tau B\tau M Q \tau \tau MQK b\tau KTH Q bBx ky QK \tau BbiBmiBQM i\tau i Bb$
 $N(;) RXk \tau M keX b\tau iBpHvX BM b\tau iBpHv \quad 90W 95W\tau M 99WQMM$
 $BMip\tau H b Q X$

Exercise 9 X.Rj $QiQ GBiBK S\tau Q,, XkXk QMbB i \tau i \tau QM i HBiBK b$
 $Q KQiQb ,BpM BM tBb XRXRX Pi\tau BM \tau H\tau, b\tau iB\tau WQMM BMip\tau H Q i$
 $K\tau M HBiBK Q \tau KQiQX$

Exercise 9 X.Rk $9\tau KK\tau BbiBmiBQ S\tau Q,, XkXj amTTQb r \tau bbmK i\tau i X ;X ;:::;X$
 $Bb \tau \tau MQK b\tau KTH QK \tau (1 ;) BbiBmiBQMX$

$U\tau VaQr i\tau i i \tau MQK p\tau B\tau H (2I) X \tau b \tau \partial BbiBmiBQM r\tau i,b$
 $Q QKX$

$UV lbBM, i \tau MQK p\tau B\tau H BM T\tau i U\tau V \tau b \tau TBpQi \tau MQK p\tau B\tau H M \tau (1$
 $)100WQMM BMip\tau H Q X$

$UV Pi\tau BM i QMM BMip\tau H Q i \tau i \tau Q tBb XRXRX$

Exercise 9 X.Rj $8b\tau HH qB,i S\tau Q,, XkX AM t\tau KTH XkX Q i \tau b\tau HH$
 $\tau i \tau M i TQQH t 95WQMM BMip\tau H Q i K\tau M BzM BM rB,ib irM$
 $i TBib \tau M BiibX$

Exercise 9 X.R@ $i\partial\tau M SH\tau vb S\tau Q,, XkX AM i \tau b\tau HH \tau i \tau bi Bi r\tau b$
 $QmM i\tau i Qmi Q N \tau b\tau HH TH\tau vb R r Hi\partial\tau MX QMbimi \tau 95W\tau TTQtBK\tau i$
 $QMM BMip\tau H Q p i TQTQiBQM Q Hi\partial\tau M TQbbBQM\tau H \tau b\tau HH TH\tau vbX$

Exercise 9 X.R@ $b\tau KTH aBx UNV S\tau Q,, XkXe Gi \bar{X} i K\tau M Q \tau \tau MQK$
 $b\tau KTH Q bBx QK \tau BbiBmiBQM i\tau i Bb(; 9)X BMn bm i\tau i P(\bar{X} 1 < <$
 $\bar{X} + 1) = 0 :90 \tau TTQtBK\tau iHvX$

Exercise 9 X.R@ $3 QK \tau i \tau S\tau Q,, XkXd Gi \tau \tau MQK b\tau KTH Q bBx Rd QK i$
 $MQK\tau H BbiBmiBQM) vBHx = 4:7 \tau M s = 5:76X iKBM \tau NyW QMM$
 $BMip\tau H Q X$

Exercise 9 X.Ri $N\tau KTH aBx URyVS\tau Q,, XkX Gi \bar{X} MQi i K\tau M Q \tau$
 $\tau MQK b\tau KTH Q bBx QK \tau BbiBmiBQM i\tau i \tau b K\tau M \tau M p\tau B\tau M = 10X BM$
 $n bQ i\tau i i TQ\tau BHBiv Bb \tau TTQtBK\tau iHv yXN i\tau i i \tau MQK BMip\tau H(\bar{X} 1/2; \bar{X} + 1/2)$
 $BMHmb X$

Exercise 9 X.k $1QK\tau H A GM,i S\tau Q,, XkXN Gi X ;X ;:::;X \tau \tau MQK$
 $b\tau KTH Q bBx N QK \tau BbiBmiBQM i\tau i Bb)X$

$U\tau VA \quad Bb \text{ FMQrM } M \text{ i HM},i \text{ Q } \tau 95 \text{ WQMM } BMip\tau H \text{ Q } \quad X$

$UV A \quad Bb \text{ mFMQrM } M \text{ i tTi } p\tau Hm \text{ Q } i \text{ HM},i \text{ Q } \tau \quad 95 \text{ WQMM } BMip\tau H$
 $\text{Q } \quad X$

$UV \text{ QKT}\tau \text{ ib } ir\text{Q } \tau MbrbX$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } SBiBQM \text{ AMip}\tau \text{ S}\tau\text{Q},, XkXRR \text{ GiX } ;X ;:::;X ;X \quad \tau$
 $\tau MQK \text{ b}\tau KTH \text{ Q } bB\text{m} + 1 \quad n > 1 \text{ QK } \tau BbiBmiBQM \text{ i}\tau i \text{ BM}(\text{ ; })X \text{ BM } i$
 $QMbi\tau M\text{bQ } i\tau i \text{ i bi}\tau i BbiB \text{ c}(\overline{X} \quad X \quad)/S \text{ }\tau b \text{ }\tau \text{ t}\partial BbiBmiBQMX$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } QMi \text{ }\tau HQ \text{ A } \text{ S}\tau\text{Q},, XkXRR \text{ GiX } ;:::;X \quad \tau \tau MQK \text{ b}\tau KTH$
 $QK \text{ }\tau \text{ N}(0;1) \text{ BbiBmiBQMX } aBkmQMM \text{ BMip}\tau Hb \text{ }\tau M \text{ }\tau Hm \text{ H}\tau i \text{ i TQTQiBQM}$
 $i\tau i \text{ i}\tau T \text{ yX}$

$U\tau Vai \quad n = 10 \text{ }\tau M \text{ m} = 50X \text{ m}M \text{ i } \text{ Q } \tau M \text{ M } i \text{ TQTQiBQM } \text{ Q } bmbbmH$
 $QMM \text{ BMip}\tau HbX$

$UV \text{ SHQi } i \text{ BMip}\tau Hb \text{ }\tau M \text{ QKKMi } QM \text{ i } p\tau B\tau BHBiv \text{ Q } i \text{ HM},ibX$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } AMp\tau B\tau M \text{ Q } \text{ S}\tau\text{Q},, XkXRR \text{ AM } tBb \text{ XkXRR } bQr \text{ i}\tau i$
 $biiBM, = 0 \text{ }\tau M \quad = 1 \text{ Bb } rBiQmi \text{ HQbb } \text{ Q } ,M\tau HBivX$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } KTBB\tau H \text{ QMM } GpH \quad \text{ S}\tau\text{Q},, XkXRj \text{ }\tau M, i \text{ Q } BM$
 $i \text{ mMiBQM } ,iBb \text{ bQ } i\tau i \text{ Bi } \tau HbQ \text{ imMb } i \text{ piQ } BM \text{ r } BMB \text{ R } B \text{ i } \quad ii$
 $QMM \text{ BMip}\tau H \text{ Bb } bmbbmHX \text{ aQr } i\tau i \text{ i } KTBB\tau H \text{ QMM } HpH \text{ Bb } K\tau MUBMVX$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } j .\tau KK\tau \text{ A } pB\tau \text{ Gh } \text{ S}\tau\text{Q},, XkXR \text{ Gi } \overline{X} \text{ MQi } i \text{ K}\tau M \text{ Q } \tau$
 $\tau MQK \text{ b}\tau KTH \text{ Q } bBx \text{ k } QK \text{ }\tau ,\tau KK\tau \partial ivT \text{ BbiBmiBQM } rBi = 4 \text{ }\tau M \quad > 0X \text{ lb } i$
 $Mi\tau H \text{ GBKBi } hQK \text{ iQ } M \text{ }\tau M \text{ }\tau TTQtBK\tau i \text{ yXN } QMM \text{ BMip}\tau H \text{ Q } \quad X$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } a\tau KTH \text{ aBx } \text{ Q } .BpM \text{ GM},i \text{ S}\tau\text{Q},, XkXR \text{ Gi } \text{ x } i \text{ Qbp}$
 $K\tau M \text{ Q } \tau \tau MQK \text{ b}\tau KTH \text{ Q } bBn \text{ QK } \tau BbiBmiBQM \text{ }\tau pBM, K\tau MM \text{ FMQrM } p\tau B\tau M$
 $X \text{ BMn } bQ \text{ i}\tau i \text{ x } \quad /4 \text{ iQx} + \quad /4 \text{ Bb } \tau M \text{ }\tau TTQtBK95 \text{ WQMM } BMip\tau H \text{ Q } \quad X$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } BMQKB\tau H \text{ a}\tau KTH \text{ S}\tau\text{Q},, XkXRe \text{ obbmK } \tau BMQKB\tau H \text{ KQH}$
 $Q \text{ }\tau i\tau BM \text{ }\tau MQK \text{ p}\tau B\tau HX \text{ A } r \text{ bB } \tau \quad 90 \text{ WQMM } BMip\tau H \text{ Q } \quad p \text{ i}\tau i \text{ Bb } \tau i \text{ KQbi}$
 $yXyk \text{ BM } HM,i \text{ MX}$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } e \text{ SQBbbQM } QMM \text{ AMip}\tau \text{ S}\tau\text{Q},, XkXRd \text{ Ai } Bb \text{ FMQrM } i\tau i$
 $\tau \tau MQK \text{ p}\tau B\tau H \text{ X } \tau b \text{ }\tau \text{ SQBbbQM } BbiBmiBQM \text{ rBi } T\tau\tau KiX \text{ }\sigma \text{ b}\tau KTH \text{ Q } kyy$
 $Qbp\tau iBQMb \text{ QK } iBb \text{ BbiBmiBQM } \tau b \text{ }\tau K\tau M \text{ m}\tau H \text{ iQ } jXX \text{ QMbimi } \tau M \text{ }\tau TTQtBK\tau i$
 $90 \text{ WQMM } BMip\tau H \text{ Q } \quad X$

$1 \text{ t } 2 \text{ ` } + \text{ B } \text{ 92XKR } \tau B\tau M \text{ A } pB\tau \text{ B}\partial bm\tau \quad \text{ S}\tau\text{Q},, XkXRN \text{ GiX } ;X ;:::;X$
 $\tau \tau MQK \text{ b}\tau KTH \text{ QK } N(\text{ ; }) \text{ r Qi } T\tau\tau Kib \text{ }\tau m \text{ FMQrMX}$

$U\tau VaQr \text{ i}\tau i \quad P((n-1)S / \quad < b) = 0:975 \text{ }\tau M \text{ P}(a < (n-1)S / \quad < b) = 0:95X$

9X aPJ1 1G1J1Lh _u ah hAahA* G AL61_1L*1a

UV A Bb FMQrM Qr rQmH vQm KQBv i TQm

1 t 2 ` + B 9 2 K R N h τ F S Q B M i S i 7 ,, X k X k R q M R y y i τ F b r i Q r M Q M τ
i τ H e y Q i K H τ M T Q B M i m T X P i τ B M 9 5 W Q M M B M i p τ H Q i T Q τ B H B i v
i π i τ i τ F Q i B b i v T H τ M b T Q B M i m T X

1 t 2` + B 12X K R BMQKBτH SQTQiBQ S iQ BzXkXkj Gi irQ BMTMMi
τMQK pτBτHb Y τM Y rBi BMQKBτH BbiBmiBQMb τpBM, TτKz n = 100
p τM p Qbp iQ y = 50 τM y = 40X iKBM τM τTTQtBKπi 90W
QMM BMipτH Q p p X

1 t 2 ` + B 9 2 X 8 j l M F M Q r M l M m τ H τ B τ M S Q , , X k X k B b m b b i T Q H K
r M i p τ B τ M b τ m M F M Q r M τ M m M m τ H X A i p τ B τ M b τ m M F M Q r M m i i B
τ i B Q / B b τ F M Q r M Q M i i M i τ b i τ i B b i B i τ i B b τ T τ M Q K p τ B τ H τ M τ , τ B M
m b X q v

1 t 2 ` + B 92X Kd aτKTH aBx Q τM Bz S n Q,, XkXkd Gi X̄ τM Ȳ i
KτMb Q irQ BMTMMi τMQK bτKTHb τQ bBx n QK N(;) τM N(;)
r i QKKQM pτBτM Bb FMQrMX BM n bm iτi P(X̄ Ȳ /5 < <
X̄ Ȳ + /5) = 0 :90X

1 t 2` + B 92 X M tri BMQKBτH A 50, XjXRτHH Q i τbτHH πiτ R
Qmi Q N τHHTHτub τ HiδτMX iKBM τM tri 90 WQMM BMipτH Q pX

1t2`+Bb2 **XXy** tTQMMiBτH G hbsm,, XX Gi X ;X τbτKTH QK
f x e⁻ X Di H Bf x f x f x f x X BM
bB,MBτM HpH τM TQr rM H Bb τHbX

1t2`+Bb2 **XXR** SQr mp aFi sm,, XXe QMbB ibib hbi R τM
hbi kX Q hbi σ Di H BS k c Q hbi Di B S k X A hbi σ τb
B, bB,MBτM HpH bQr hbi σ τb B, TQrX

1t2`+Bb2 **XXk** hB GB hbi sm,, XXd Gi iB HB X N ; X hbi
H pb H > X iKBM n τM c bQ iτi : τM
: X

1t2`+Bb2 **XXj** SQBbbQM SQr mMiBsm,, XXN Gi X τp SQBbbQM
BbiBmiBQMX hbi pb H < X qBi n Di B Y X X
τT i TQr mMiBQM τM iKBM bB,MBτM HpHX

1t2`+Bb2 **XX** BMQKBτH aτKTHsm,, XXRy Gi Y BMQKBτH X
hbi H p pb H p> X BM n τM c bQ iτi : τM : X

1t2`+Bb2 **XX** lMBQK τ hbi sm,, XXRR Gi Y < Y < Y < Y
Q biτiBbiBb QK f x < x < X hbi H pb H > v DiBM,
BY cX

UτVBM c Q : X

UV iKBM i TQr mMiBQMX

1t2`+Bb2 **XXe** SQBbbQM hbi asm,, XXRk Gi X ;:::;X QK SQBbbQM
rBi KτM X hbi H : pb H > : v DiBM, B x X

UτVaQr bB,MBτM HpH Bb TTQBh X

UV iKBM : : X

1t2`+Bb2 **XXd** hMMBb ap vTQibBb sm,, XXRj Gi p TQτBHBiv iτi
bi bp Bb ,QQX hbi H p : pb H p> : rBi n X Di B Y X

UτVaQr TBMQK ; ; : X

UV BM rM p : X

1t2`+Bb2 **XX** MQmHHB SQr QKTτBbsm,, XXR Gi S MmK
Q bmbbb BM n MQmHHB iBτHbXhbi p : pb H p> : X QKTτ ibib
URV Di B S τM UkV Di B S X iKBM HpHbX

1t2`+Bb2 **XXN** SQTQiBQM SQr mp sm,, XXR QMbB i irQdbB
ibi Q TQTQiBQMbX qBi Q iQ QKTmi τ THQi Q i TQr mpX

1t2`+Bb2 **XXNy** SQr mMiBQM BpriBp sm,, XeXR QMbB i TQr
mMiBQM X aQr ' Bb biBiHv M,τiBp Q < τM biBiHv TQbBiBp Q X

1 t 2 ` + B b 2 **XXNN**QB m Mv hbi **SnQ**,, XdXj amTTQb Qbp ∂
mMBb Q A ;::;A τ ky jy Nk RyX τHmHτi i ibi τM TQi pδpτHmX

1 t 2 ` + B b 2 **XXRyy**QMiBMmQmb AMipτ**SnQ**biXdXk σ MmK Bb bHi
QK ; X hbi vTQibBb rBi p x dxX Q Qbp mMBb jy
jy Ry Ry rQmHH τTi

1 t 2 ` + B b 2 **XXRyFL**QKτH σTTQtBKτiBQM**SnQ**i,, XdXj M bib A
x E < x A x i < x i Q i ;::; A x < x < X
hbi rBi mMBb ey Ne Ry kRy Rdk Rey dX

1 t 2 ` + B b 2 **XXRykB** τbiBM, hbi **SnQ**,, XdX σ B rτb τbi n iBKb
rBi mMBb R b kky jky ky ky e bX Q rτi pτHmb Q b rQmH i
vTQibBb Q mMBτb B Di τi : HpH

1 t 2 ` + B b 2 **XXRyj**MHBτM .MiBb **SnQ**,, XdX MHBτM iQv biτib
TQτBHBiBb τNfRe jfRe jfRe RfRe Q Qm HτbbBτiBQMbX qBi Qbp mMBb
e j ke Rj Qmi Q Rey ibi τi : X

1 t 2 ` + B b 2 **XXRy** hτBM, iQ QKTτBbQM **SnQ**,, XdXe hrQ ,QmTb Q
Ryy bimMib τX hbi τi ri i irQ BbiBmiBQMb τ i bτKX

1 t 2 ` + B b 2 **XXRy** BK τM σHQQHbBb**SnQ**,, XdXd τiτ QM BK ivTτM
τHQQHb biτimbX hbi BMTMMX

UτVQKTmi ∂ibi Q BMTMMX

UV lb SτbQM bBmτHb iQ iKBM biQM,bi TMMX

UV QMK rBi QMBiBQMτH ibiX

1 t 2 ` + B b 2 **XXRye**AMTMM hbi **SnQ**,, XdX Ry BMTMMi iBτHb rBi
HτbbBτiBQM BAmiQ ;A τM B ;B ;B ;B X qτi Bb bKτH Hbiτi Hτb iQ DiBQM
τi :

1 t 2 ` + B b 2 **XXRyd**SQBbbQM .QQMbb Q**SnQ**,, XdXN Bi SQBbbQM BbiBmiBQM
iQ τiτ t yRkjτ rBi mMBb kyyReReX

UτVQKTmi Bδbmτ biτiBbiBX

UV ,b Q QK

UV Di τi :

1 t 2 ` + B b 2 **XXRy** h QMpb **SnQ**,, XXR SQp i QMpb Q hQ∂
K h Gi X τp QMiBMmQmb F x biBiHv BMτbBM,X aQz F X τb
mMBQKUyRV BbiBmiBQMX

1 t 2 ` + B b 2 **XXRyNQ**Mi τHQ GQ, k **SnQ**,, XXk σTTQtBKτi
x dx mbBM, mMBQKUyRV ,MτiQX qBi mMiBQM τM QKTτ rBi im
pτHmX

with pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, zero elsewhere. By Example 7.4.2, the statistic Y_n is a complete sufficient statistic for θ and it has pdf

$$g(y_n; \theta) = \frac{ny_n^{n-1}}{\theta^n}, \quad 0 < y_n < \theta,$$

and zero elsewhere.

- (a) Find the distribution function $H_n(z; \theta)$ of $Z = n(\theta - Y_n)$
- (b) Find the $\lim_{n \rightarrow \infty} H_n(z; \theta)$ and thus the limiting distribution of Z .

EXERCISE 7.35. ?? Gamma Distribution in Exponential Form –Hogg 7.5.1 Write the pdf

$$f(x; \theta) = \frac{1}{6\theta^4} x^3 e^{-x/\theta}, \quad 0 < x < \infty, \quad 0 < \theta < \infty,$$

zero elsewhere, in the exponential form. If $X_1, X_2, \dots, X_n$ is a random sample from this distribution, find a complete sufficient statistic Y_1 for θ and the unique function $\varphi(Y_1)$ of this statistic that is the MVUE of θ . Is $\varphi(Y_1)$ itself a complete sufficient statistic?

EXERCISE 7.36. ?? MVUE via Exponential Class –Hogg 7.5.2 Let $X_1, X_2, \dots, X_n$ denote a random sample of size $n > 1$ from a distribution with pdf $f(x; \theta) = \theta e^{-\theta x}$, $0 < x < \infty$, zero elsewhere, and $\theta > 0$. Then $Y = \sum_{i=1}^n X_i$ is a sufficient statistic for θ . Prove that $(n-1)/Y$ is the MVUE of θ .

EXERCISE 7.37. ?? Beta Distribution Complete Sufficient Statistic –Hogg 7.5.3 Let $X_1, X_2, \dots, X_n$ denote a random sample of size n from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere, and $\theta > 0$.

(a) Show that the geometric mean $(X_1 X_2 \dots X_n)^{1/n}$ of the sample is a complete sufficient statistic for θ

(b) Find the maximum likelihood estimator of θ , and observe that it is a function of this geometric mean.

EXERCISE 7.38. ?? Conditional Expectation for Gamma Mean –Hogg 7.5.4 Let $\bar{X}$ denote the mean of the random sample $X_1, X_2, \dots, X_n$ from a gamma-type distribution with parameters $\alpha > 0$ and $\beta = \theta > 0$. Compute $\mathbb{E}[X_1 | \bar{x}]$.

Hint: Can you find directly a function $\psi(\bar{X})$ of $\bar{X}$ such that $\mathbb{E}[\psi(\bar{X})] = \theta$? Is $\mathbb{E}(X_1 | \bar{x}) = \psi(\bar{x})$? Why?

EXERCISE 7.39. ?? Mean and Variance of Exponential Class –Hogg 7.5.5 Let X be a random variable with the pdf of a regular case of the exponential class, given by $f(x; \theta) = \exp[\theta K(x) + H(x) + q(\theta)]$, $a < x < b$, $\gamma < \theta < \delta$. Show that $\mathbb{E}[K(X)] = -q'(\theta)/p'(\theta)$, provided these derivatives exist, by differentiating both members of the equality

$$\int_a^b \exp[p(\theta)K(x) + H(x) + q(\theta)] dx = 1$$

with respect to θ . By a second differentiation, find the variance of $K(X)$.

EXERCISE 7.40. ?? *MGF of Exponential Class – Hogg 7.5.6* Given that $f(x; \theta) = \exp[\theta K(x) + H(x) + q(\theta)]$, $a < x < b$, $\gamma < \theta < \delta$, represents a regular case of the exponential class, show that the moment-generating function $M(t)$ of $Y = K(X)$ is $M(t) = \exp[q(\theta) - q(\theta + t)]$, $\gamma < \theta + t < \delta$.

EXERCISE 7.41. ?? *Normal from Exponential Class – Hogg 7.5.7* In the preceding exercise, given that $\mathbb{E}(Y) = \mathbb{E}[K(X)] = \theta$, prove that Y is $N(\theta, 1)$.

Hint: Consider $M'(0) = \theta$ and solve the resulting differential equation.

EXERCISE 7.42. ?? *Distribution of Sum in Exponential Class – Hogg 7.5.8* If $X_1, X_2, \dots, X_n$ is a random sample from a distribution that has a pdf which is a regular case of the exponential class, show that the pdf of $Y_1 = \sum_{i=1}^n K(X_i)$ is of the form $f_{Y_1}(y_1; \theta) = R(y_1) \exp[p(\theta)y_1 + nq(\theta)]$.

Hint: Let $Y_2 = X_2, \dots, Y_n = X_n$ be $n - 1$ auxiliary random variables. Find the joint pdf of $Y_1, Y_2, \dots, Y_n$ and then the marginal pdf of Y_1 .

EXERCISE 7.43. ?? *Conditional Expectation of Median given Mean – Hogg 7.5.9* Let Y denote the median and let $\bar{X}$ denote the mean of a random sample of size $n = 2k + 1$ from a distribution that is $N(\mu, \sigma^2)$. Compute $\mathbb{E}(Y | \bar{X} = \bar{x})$.

Hint: See Exercise 7.5.4.

EXERCISE 7.44. ?? *Gamma(2, θ) Complete Sufficient Statistic – Hogg 7.5.10* Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta^2 x e^{-\theta x}$, $0 < x < \infty$, where $\theta > 0$.

(a) Argue that $Y = \sum_{i=1}^n X_i$ is a complete sufficient statistic for θ .

(b) Compute $\mathbb{E}(1/Y)$ and find the function of Y that is the unique MVUE of θ .

EXERCISE 7.45. ?? *Binomial MVUE via Rao-Blackwell – Hogg 7.5.11* Let $X_1, X_2, \dots, X_n$, $n > 2$, be a random sample from the binomial distribution $b(1, \theta)$.

(a) Show that $Y_1 = X_1 + X_2 + \dots + X_n$ is a complete sufficient statistic for θ .

(b) Find the function $\varphi(Y_1)$ that is the MVUE of θ .

(c) Let $Y_2 = (X_1 + X_2)/2$ and compute $\mathbb{E}(Y_2)$.

(d) Determine $\mathbb{E}(Y_2 | Y_1 = y_1)$.

EXERCISE 7.46. ?? *Zero-Truncated Geometric MVUE – Hogg 7.5.12* Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pmf $p(x; \theta) = \theta^x (1 - \theta)$, $x = 0, 1, 2, \dots$, zero elsewhere, where $0 \leq \theta \leq 1$.

(a) Find the mle, $\hat{\theta}$, of θ .

(b) Show that $\sum_{i=1}^n X_i$ is a complete sufficient statistic for θ .

(c) Determine the MVUE of θ .

EXERCISE 7.47. ?? MVUE of θ^2 for Normal –Hogg 7.6.1 Let $X_1, X_2, \dots, X_n$ denote a random sample from a distribution that is $N(\theta, 1)$, $-\infty < \theta < \infty$. Find the MVUE of θ^2 .

EXERCISE 7.48. ?? MVUE of θ^2 for Normal $(0, \theta)$ –Hogg 7.6.2 Let $X_1, X_2, \dots, X_n$ denote a random sample from a distribution that is $N(0, \theta)$. Then $Y = \sum X_i^2$ is a complete sufficient statistic for θ . Find the MVUE of θ^2 .

EXERCISE 7.49. ?? Bootstrap SE for Normal CDF MVUE –Hogg 7.6.3 Consider Example 7.6.3 where the parameter of interest is $\mathbb{P}(X < c)$ for X distributed $N(\theta, 1)$. Modify the R function `bootse1.R` so that for a specified value of c it returns the MVUE of $\mathbb{P}(X < c)$ and the bootstrap standard error of the estimate. Run your function on the data in `ex763data.rda` with $c = 11$ and 3,000 bootstraps. These data are generated from a $N(10, 1)$ distribution. Report (a) the true parameter, (b) the MVUE, and (c) the bootstrap standard error.

EXERCISE 7.50. ?? Bootstrap SE for Median MVUE –Hogg 7.6.4 For Example 7.6.4, modify the R function `bootse1.R` so that the estimate is the median not the mean. Using 3,000 bootstraps, run your function on the data set discussed in the example and report (a) the estimate and (b) the bootstrap standard error.

EXERCISE 7.51. ?? Uniform $(0, \theta)$ MVUEs –Hogg 7.6.5 Let $X_1, X_2, \dots, X_n$ be a random sample from a uniform $(0, \theta)$ distribution. Continuing with Example 7.6.2, find the MVUEs for the following functions of θ .

- (a) $g(\theta) = \frac{\theta^2}{12}$, i.e., the variance of the distribution.
- (b) $g(\theta) = \frac{1}{\theta}$, i.e., the pdf of the distribution.
- (c) For t real, $g(\theta) = \frac{e^{t\theta} - 1}{t\theta}$, i.e., the mgf of the distribution.

EXERCISE 7.52. ?? Poisson MVUE for $\mathbb{P}(X \leq 1)$ –Hogg 7.6.6 Let $X_1, X_2, \dots, X_n$ be a random sample from a Poisson distribution with parameter $\theta > 0$.

- (a) Find the MVUE of $\mathbb{P}(X \leq 1) = (1 + \theta)e^{-\theta}$

Hint: Let $u(x_1) = 1$, $x_1 \leq 1$, zero elsewhere, and find $\mathbb{E}[u(X_1)|Y = y]$ where $Y = \sum_{i=1}^n X_i$.

- (b) Express the MVUE as a function of the mle of θ
- (c) Determine the asymptotic distribution of the mle of θ
- (d) Obtain the mle of $\mathbb{P}(X \leq 1)$. Then use Theorem 5.2.9 to determine its asymptotic distribution.

EXERCISE 7.53. ?? Poisson Conditional Expectation with $(-1)^{X_1}$ –Hogg 7.6.7 Let $X_1, X_2, \dots, X_n$ denote a random sample from a Poisson distribution with parameter $\theta > 0$. From Remark 7.6.1, we know that $\mathbb{E}[(-1)^{X_1}] = e^{-2\theta}$.

(a) Show that $\mathbb{E}[(-1)^{X_1} | Y_1 = y_1] = (1 - 2/n)^{y_1}$, where $Y_1 = X_1 + X_2 + \cdots + X_n$. Hint: First show that the conditional pdf of $X_1, X_2, \dots, X_{n-1}$, given $Y_1 = y_1$, is multinomial, and hence that of X_1 , given $Y_1 = y_1$, is $b(y_1, 1/n)$.

(b) Show that the mle of $e^{-2\theta}$ is $e^{-2\bar{X}}$

(c) Since $y_1 = n\bar{x}$, show that $(1 - 2/n)^{y_1}$ is approximately equal to $e^{-2\bar{x}}$ when n is large.

EXERCISE 7.54. ?? Bivariate Normal Distribution of $(X_1, \bar{X})$ –Hogg 7.6.8 As in Example 7.6.3, let $X_1, X_2, \dots, X_n$ be a random sample of size $n > 1$ from a distribution that is $N(\theta, 1)$. Show that the joint distribution of X_1 and $\bar{X}$ is bivariate normal with mean vector (θ, θ) , variances $\sigma_1^2 = 1$ and $\sigma_2^2 = 1/n$, and correlation coefficient $\rho = 1/\sqrt{n}$.

EXERCISE 7.55. ?? Exponential MLE and MVUE of $\mathbb{P}(X \leq 2)$ –Hogg 7.6.9 Let a random sample of size n be taken from a distribution that has the pdf $f(x; \theta) = (1/\theta) \exp(-x/\theta) \mathbb{I}_{(0, \infty)}(x)$. Find the mle and MVUE of $\mathbb{P}(X \leq 2)$.

EXERCISE 7.56. ?? Gamma(1, θ) MLE and MVUE –Hogg 7.6.10 Let $X_1, X_2, \dots, X_n$ be a random sample with the common pdf $f(x) = \theta^{-1} e^{-x/\theta}$, for $x > 0$, zero elsewhere; that is, $f(x)$ is a $\Gamma(1, \theta)$ pdf.

(a) Show that the statistic $\bar{X} = n^{-1} \sum_{i=1}^n X_i$ is a complete and sufficient statistic for θ .

(b) Determine the MVUE of θ

(c) Determine the mle of θ

(d) Often, though, this pdf is written as $f(x) = \tau e^{-\tau x}$, for $x > 0$, zero elsewhere. Thus $\tau = 1/\theta$. Use Theorem 6.1.2 to determine the mle of τ .

(e) Show that the statistic $\bar{X} = n^{-1} \sum_{i=1}^n X_i$ is a complete and sufficient statistic for τ . Show that $(n-1)/(n\bar{X})$ is the MVUE of $\tau = 1/\theta$. Hence, as usual, the reciprocal of the mle of θ is the mle of $1/\theta$, but, in this situation, the reciprocal of the MVUE of θ is not the MVUE of $1/\theta$.

(f) Compute the variances of each of the unbiased estimators in parts (b) and (e).

EXERCISE 7.57. ?? Two-Sample F-Distribution for θ^2 –Hogg 7.6.11 Consider the situation of the last exercise, but suppose we have the following two independent random samples: (1) $X_1, X_2, \dots, X_n$ is a random sample with the common pdf $f_X(x) = \theta^{-1} e^{-x/\theta}$, for $x > 0$, zero elsewhere, and (2) $Y_1, Y_2, \dots, Y_n$ is a random sample with common pdf $f_Y(y) = \theta e^{-\theta y}$, for $y > 0$, zero elsewhere. The last exercise suggests that, for some constant c , $Z = c\bar{X}/\bar{Y}$ might be an unbiased estimator of θ^2 . Find this constant c and the variance of Z .

Hint: Show that $\bar{X}/(\theta^2 \bar{Y})$ has an F-distribution.

EXERCISE 7.58. ?? *Asymptotics of Normal Variance MVUE at $\theta = 1/2$ –Hogg 7.6.12*
Obtain the asymptotic distribution of the MVUE in Example 7.6.1 for the case $\theta = 1/2$.

11. 7.7 The Case of Several Parameters —Exercises

EXERCISE 7.59. ?? *Joint Sufficient Statistics for Gumbel Distribution –Hogg 7.7.1*
Let $Y_1 < Y_2 < Y_3$ be the order statistics of a random sample of size 3 from the distribution with pdf

$$f(x; \theta_1, \theta_2) = \begin{cases} \frac{1}{\theta_2} \exp\left(-\frac{x-\theta_1}{\theta_2}\right) & \theta_1 < x < \infty, -\infty < \theta_1 < \infty, 0 < \theta_2 < \infty \\ 0 & \text{elsewhere.} \end{cases}$$

Find the joint pdf of $Z_1 = Y_1, Z_2 = Y_2$, and $Z_3 = Y_1 + Y_2 + Y_3$. The corresponding transformation maps the space $\{(y_1, y_2, y_3) : \theta_1 < y_1 < y_2 < y_3 < \infty\}$ onto the space

$$\{(z_1, z_2, z_3) : \theta_1 < z_1 < z_2 < (z_3 - z_1)/2 < \infty\}.$$

Show that Z_1 and Z_3 are joint sufficient statistics for θ_1 and θ_2 .

EXERCISE 7.60. ?? *Exponential Class Joint Sufficient Statistics –Hogg 7.7.2* Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution that has a pdf of the form (7.7.2) of this section. Show that $Y_1 = \sum_{i=1}^n K_1(X_i), \dots, Y_m = \sum_{i=1}^n K_m(X_i)$ have a joint pdf of the form (7.7.4) of this section.

EXERCISE 7.61. ?? *Bivariate Normal Joint Complete Sufficient Statistics –Hogg 7.7.3* Let $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ denote a random sample of size n from a bivariate normal distribution with means μ_1 and μ_2 , positive variances σ_1^2 and σ_2^2 , and correlation coefficient ρ . Show that $\sum_1^n X_i, \sum_1^n Y_i, \sum_1^n X_i^2, \sum_1^n Y_i^2$, and $\sum_1^n X_i Y_i$ are joint complete sufficient statistics for the five parameters. Are $\bar{X} = \sum_1^n X_i/n, \bar{Y} = \sum_1^n Y_i/n, S_1^2 = \sum_1^n (X_i - \bar{X})^2/(n-1), S_2^2 = \sum_1^n (Y_i - \bar{Y})^2/(n-1)$, and $\sum_1^n (X_i - \bar{X})(Y_i - \bar{Y})/(n-1)$ also joint complete sufficient statistics for these parameters?

EXERCISE 7.62. ?? *Reparameterization of Exponential Class –Hogg 7.7.4* Let the pdf $f(x; \theta_1, \theta_2)$ be of the form

$$\exp[p_1(\theta_1, \theta_2)K_1(x) + p_2(\theta_1, \theta_2)K_2(x) + H(x) + q_1(\theta_1, \theta_2)], a < x < b,$$

zero elsewhere. Suppose that $K_1'(x) = cK_2'(x)$. Show that $f(x; \theta_1, \theta_2)$ can be written in the form

$$\exp[p(\theta_1, \theta_2)K_2(x) + H(x) + q(\theta_1, \theta_2)], a < x < b,$$

zero elsewhere. This is the reason why it is required that no one $K_j'(x)$ be a linear homogeneous function of the others, that is, so that the number of sufficient statistics equals the number of parameters.

EXERCISE 7.63. ?? *MVUE of Standard Deviation for Normal – Hogg 7.7.5 In Example 7.7.2:*

- (a) Find the MVUE of the standard deviation $\sqrt{\theta_2}$.
- (b) Modify the R function `bootse1.R` so that it returns the estimate in (a) and its bootstrap standard error. Run it on the Bavarian forest data discussed in Example 4.1.3, where the response is the concentration of sulfur dioxide. Using 3,000 bootstraps, report the estimate and its bootstrap standard error.

EXERCISE 7.64. ?? *Uniform($\theta_1 - \theta_2, \theta_1 + \theta_2$) Complete Sufficient – Hogg 7.7.6 Let $X_1, X_2, \dots, X_n$ be a random sample from the uniform distribution with pdf $f(x; \theta_1, \theta_2) = 1/(2\theta_2)$, $\theta_1 - \theta_2 < x < \theta_1 + \theta_2$, where $-\infty < \theta_1 < \infty$ and $\theta_2 > 0$, and the pdf is equal to zero elsewhere.*

- (a) Show that $Y_1 = \min(X_i)$ and $Y_n = \max(X_i)$, the joint sufficient statistics for θ_1 and θ_2 , are complete.
- (b) Find the MVUEs of θ_1 and θ_2 .

EXERCISE 7.65. ?? *MVUE of Normal Quantile – Hogg 7.7.7 Let $X_1, X_2, \dots, X_n$ be a random sample from $N(\theta_1, \theta_2)$*

- (a) If the constant b is defined by the equation $\mathbb{P}(X \leq b) = p$ where p is specified, find the mle and the MVUE of b .
- (b) Modify the R function `bootse1.R` so that it returns the MVUE of Part (a) and its bootstrap standard error.
- (c) Run your function in Part (b) on the data set discussed in Example 7.6.4 for $p = 0.75$ and 3,000 bootstraps.

EXERCISE 7.66. ?? *MLE of Multinomial Cell Probability Product – Hogg 7.7.8 In the notation of Example 7.7.3, show that the mle of $p_j p_l$ is $n^{-2} Y_j Y_l$.*

EXERCISE 7.67. ?? *MVUE of Covariance Parameters for Multivariate Normal – Hogg 7.7.9 Refer to Example 7.7.4 on sufficiency for the multivariate normal model.*

- (a) Determine the MVUE of the covariance parameters σ_{ij} .
- (b) Let $g = \sum_{i=1}^k a_i \mu_i$, where $a_1, \dots, a_k$ are specified constants. Find the MVUE for g .

EXERCISE 7.68. ?? *Inverse Gaussian Complete Sufficient Statistics – Hogg 7.7.10 In a personal communication, LeRoy Folks noted that the inverse Gaussian pdf*

$$f(x; \theta_1, \theta_2) = \left(\frac{\theta_2}{2\pi x^3} \right)^{1/2} \exp \left[\frac{-\theta_2(x - \theta_1)^2}{2\theta_1^2 x} \right], \quad 0 < x < \infty,$$

where $\theta_1 > 0$ and $\theta_2 > 0$, is often used to model lifetimes. Find the complete sufficient statistics for (θ_1, θ_2) if $X_1, X_2, \dots, X_n$ is a random sample from the distribution having this pdf.

EXERCISE 7.69. ?? MVUE of $3\theta_2^2$ for Normal –Hogg 7.7.11 Let $X_1, X_2, \dots, X_n$ be a random sample from a $N(\theta_1, \theta_2)$ distribution.

(a) Show that $\mathbb{E}[(X_1 - \theta_1)^4] = 3\theta_2^2$.

(b) Find the MVUE of $3\theta_2^2$.

EXERCISE 7.70. ?? MVUE of Mean for Continuous Distribution –Hogg 7.7.12 Let $X_1, \dots, X_n$ be a random sample from a distribution of the continuous type with cdf $F(x)$. Suppose the mean, $\mu = \mathbb{E}(X_1)$, exists. Using Example 7.7.5, show that the sample mean, $\bar{X} = n^{-1} \sum_{i=1}^n X_i$, is the MVUE of μ .

EXERCISE 7.71. ?? MVUE of CDF at Known Point –Hogg 7.7.13 Let $X_1, \dots, X_n$ be a random sample from a distribution of the continuous type with cdf $F(x)$. Let $\theta = \mathbb{P}(X_1 \leq a) = F(a)$, where a is known. Show that the proportion $n^{-1} \#\{X_i \leq a\}$ is the MVUE of θ .

12. 7.9 Sufficiency, Completeness, and Independence —Exercises

EXERCISE 7.72. ?? Basu for Normal Order Statistics and Sample Mean –Hogg 7.9.2 Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics of a random sample from a $N(\theta, \sigma^2)$, $-\infty < \theta < \infty$, distribution. Show that the distribution of $Z = Y_n - \bar{X}$ does not depend upon θ . Thus $\bar{Y} = \sum_1^n Y_i/n$, a complete sufficient statistic for θ is independent of Z .

EXERCISE 7.73. ?? Basu's Theorem for Uniform Distribution –Hogg 7.9.1 Let $Y_1 < Y_2 < Y_3 < Y_4$ denote the order statistics of a random sample of size $n = 4$ from a distribution having pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, zero elsewhere, where $0 < \theta < \infty$. Argue that the complete sufficient statistic Y_4 for θ is independent of each of the statistics Y_1/Y_4 and $(Y_1 + Y_2)/(Y_3 + Y_4)$.

EXERCISE 7.74. ?? Independence Condition for Linear Statistics –Hogg 7.9.3 Let $X_1, X_2, \dots, X_n$ be iid with the distribution $N(\theta, \sigma^2)$, $-\infty < \theta < \infty$. Prove that a necessary and sufficient condition that the statistics $Z = \sum_1^n a_i X_i$ and $Y = \sum_1^n X_i$, a complete sufficient statistic for θ , are independent is that $\sum_1^n a_i = 0$.

Optimal Statistical Tests

Chapter 8 Overview

前几章已经给出了假设检验的基本语言：原假设、备择假设、显著性水平、功效函数，以及似然比思想。可是，一旦这些语言建立起来，一个更尖锐的问题就不可避免地出现了：同一个检验问题往往有许多临界区域，它们都能把第一类错误控制在同一个水平；那么我们凭什么选择其中一个，而不是另一个？

在所有可能的检验中，哪个检验是“最好”的？

这个问题就是**最优检验理论 (optimal test theory)**的起点。假设检验的困难不在于写出一个拒绝域，而在于处理两类错误之间的张力：若把拒绝域取得太大，第一类错误会上升；若取得太小，又会牺牲发现备择假设的能力。最优性理论的基本思想是：先把第一类错误控制在给定水平 α ，再在这个约束下尽可能提高功效 (power)。

为什么需要最优性理论？以医学筛查为例，若我们把误报率控制在 5%，接下来真正关心的就是：当患者确实患病时，检验能否以尽可能高的概率发现它。没有最优性理论，检验的选择只是经验判断；有了最优性理论，我们至少能在清楚的数学标准下说明某个检验为什么不可改进。

本章按从理想到现实的顺序展开：

- (1) **Neyman-Pearson 引理** (8.1 节)：对于简单假设对简单假设的情况，给出了最优检验的完整刻画——这是整个理论的基石。
- (2) **一致最大功效检验 (UMP)** (8.2 节)：将最优性概念推广到复合备择假设。介绍 monotone likelihood ratio (MLR) 和 Karlin-Rubin 定理——单参数指数族存在 UMP 检验。
- (3) **似然比检验 (LRT)** (8.3 节)：在一般复合假设下，LRT 提供了一种构造检验的通用方法。虽然 LRT 不一定是最优的，但在很多情况下它是渐近最优的。
- (4) **序贯概率比检验 (SPRT)** (8.4 节)：打破固定样本量的束缚，允许检验在数据积累过程中随时停止——Wald 的革命性贡献。
- (5) **极小化极大分类** (8.5 节)：将决策论框架应用于假设检验和分类问题。

1. 8.1 Most Powerful Tests

1.1. 问题的起源：什么是“最好”的检验。在 4.5 节中，我们引入了假设检验的基本框架：给定原假设 H_0 和备择假设 H_1 ，构造一个临界区域 C ，当样本落入 C 时拒绝 H_0 。这个定义看似完整，却留下了最重要的自由度：临界区域 C 并不唯一。许多不同的 C 都可能具有同样的显著性水平，但它们发现备择假设的能力可能完全不同。

在所有这些检验中，我们凭什么说一个比另一个更好？

要回答这个问题，必须先固定比较的规则。在假设检验中，这个规则就是**功效 (power)**——当 H_1 为真时拒绝 H_0 的概率。直观上，我们希望：

- (1) 在 H_0 为真时，拒绝 H_0 的概率（即 α ，显著性水平）不超过预设值；
- (2) 在 H_1 为真时，拒绝 H_0 的概率（即功效）尽可能高。

这就引出了“最好检验”的定义。

1.2. 简单假设对简单假设的最优检验. 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本，其中 $\theta \in \Omega = \{\theta', \theta''\}$ （即只有两个可能的参数值）。我们考虑检验：

$$H_0 : \theta = \theta' \quad \text{versus} \quad H_1 : \theta = \theta''.$$

DEFINITION 8.1 (最佳临界区域). 设 C 是样本空间的一个子集。如果

- (a) $\mathbb{P}_{\theta'}(\mathbf{X} \in C) = \alpha$ (大小为 α)；
- (b) 对每一个满足 $\mathbb{P}_{\theta'}(\mathbf{X} \in A) = \alpha$ 的子集 A ，都有

$$\mathbb{P}_{\theta''}(\mathbf{X} \in C) \geq \mathbb{P}_{\theta''}(\mathbf{X} \in A),$$

则称 C 是检验 $H_0 : \theta = \theta'$ 对 $H_1 : \theta = \theta''$ 的大小为 α 的**最佳临界区域 (best critical region of size α)**。

定义的直观含义：在所有满足显著性水平 α 的检验中，最佳临界区域对应的检验在 H_1 为真时具有最高的拒绝概率——这正是我们想要的。

为什么要关心最佳检验？设想你在设计一个药物试验。你设定 $\alpha = 0.05$ （即当药物无效时，只有 5% 的概率错误地拒绝 H_0 ）。在所有满足这个条件的检验中，你当然希望当药物真的有效时，以最高概率检测出来——这就是最佳检验的价值。

那么，这样的最佳检验是否存在？Neyman-Pearson 定理给出了答案。

1.3. Neyman-Pearson 定理.

有没有一种系统性的方法构造最佳检验？

Neyman-Pearson 定理不仅回答了“最佳检验是否存在”的问题，还给出了构造方法——它是以似然比 (likelihood ratio) 为基础的。

THEOREM 8.1 (Neyman-Pearson). 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本，记似然函数为

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

设 θ' 和 θ'' 是 θ 的两个不同取值， $\Omega = \{\theta', \theta''\}$ 。设 $k > 0$ 是一个常数， C 是样本空间的一个子集，满足：

- (a) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$ 对所有 $\mathbf{x} \in C$;
 (b) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k$ 对所有 $\mathbf{x} \in C^c$;
 (c) $\alpha = \mathbb{P}_{H_0}[\mathbf{X} \in C]$ 。

则 C 是检验简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ 的、大小为 α 的最佳临界区域。

核心思想：似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x})$ 衡量了数据 $\mathbf{x}$ 更支持 H_0 还是更支持 H_1 。当这个比值很小时，说明同一组数据在 H_0 下相对不容易出现，而在 H_1 下相对容易出现；于是最自然的动作就是拒绝 H_0 。

物理直觉：想象你在两个解释之间做选择。 $L(\theta'; \mathbf{x})$ 告诉我们“如果 H_0 为真，观察到这组数据的可能性有多大”； $L(\theta''; \mathbf{x})$ 告诉我们同一组数据在 H_1 下有多自然。如果观察到的数据在 H_0 下很牵强、在 H_1 下很自然，那么拒绝 H_0 就不是主观偏好，而是似然原则的直接要求。

必要性：值得注意的是，教材中的证明还说明了一个更强的事实：如果存在大小为 α 的最佳检验，那么它必须具有这种似然比形式。连续型情形下，这个最佳区域除了零概率集外是唯一的；离散型情形中，因为边界点可能需要随机化或有并列比值，最佳区域可能不唯一。

EXAMPLE 8.1 (二项分布下的最佳检验). 设 $X \sim \text{Binomial}(n = 5, p = \theta)$ ，考虑检验：

$$H_0: \theta = \frac{1}{2} \quad \text{versus} \quad H_1: \theta = \frac{3}{4}.$$

下表给出 $f(x; 1/2)$ 、 $f(x; 3/4)$ 以及它们的比值：

x	0	1	2	3	4	5
$f(x; 1/2)$	1/32	5/32	10/32	10/32	5/32	1/32
$f(x; 3/4)$	1/1024	15/1024	90/1024	270/1024	405/1024	243/1024
$f(x; 1/2)/f(x; 3/4)$	32/1	32/3	32/9	32/27	32/81	32/243

问题：构造大小 $\alpha = 1/32$ 的最佳检验。

比值 $f(x; 1/2)/f(x; 3/4)$ 在 $x = 5$ 处取得最小值 (32/243)。因此，最佳临界区域应包含那些使 H_0 看起来极不可能而 H_1 看起来极可能的数据点——即 $C = \{x = 5\}$ 。

验证： $\mathbb{P}_{H_0}(X \in C) = f(5; 1/2) = 1/32 = \alpha$ ，且 $\mathbb{P}_{H_1}(X \in C) = f(5; 3/4) = 243/1024 \approx 0.237$ 。

如果取 $\alpha = 6/32$ ，则最佳临界区域为 $\{x = 4, 5\}$ ，因为 $x = 4$ 和 $x = 5$ 的比值最小。此时

$$\mathbb{P}_{H_1}(X \in \{4, 5\}) = \frac{405}{1024} + \frac{243}{1024} = \frac{648}{1024} \approx 0.633.$$

关键洞察：最佳检验包含了“最支持 H_1 而最不支持 H_0 ”的数据点——这正是似然比方法告诉我们的。

EXAMPLE 8.2 (正态均值差假设的最优检验). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ ，考虑检验：

$$H_0: \theta = 0 \quad \text{versus} \quad H_1: \theta = 1.$$

构造最佳检验：似然函数为

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

似然比为

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \exp \left(-\sum_{i=1}^n x_i + \frac{n}{2} \right).$$

令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$, 等价于

$$\sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

因此, 最佳临界区域是 $C = \{\mathbf{x} : \sum_{i=1}^n x_i \geq c\}$, 即基于样本均值 $\bar{X}$ 的检验。

确定临界值: 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故

$$c_1 = \frac{c}{n} = \frac{\frac{n}{2} - \log k}{n} = \frac{1}{2} - \frac{\log k}{n}.$$

给定显著性水平 α , 临界值为 $c_1 = q_\alpha(0, 1/\sqrt{n})$ ($N(0, 1/n)$ 的上 α 分位数)。

数值示例: 设 $n = 25$, $\alpha = 0.05$, 则 $c_1 = \mathbf{qnorm}(0.95, 0, 1/5) = 0.329$ 。

功效计算: 当 H_1 为真时, $\bar{X} \sim N(1, 1/25)$, 功效为

$$Power = \mathbb{P}_{H_1}(\bar{X} \geq 0.329) = 1 - \Phi \left(\frac{0.329 - 1}{1/5} \right) = 1 - \Phi(-3.355) \approx 0.9996.$$

也就是说, 当 $\theta = 1$ 时, 这个检验有约 99.96% 的概率正确拒绝 H_0 。

EXAMPLE 8.3 (Poisson 对 Geometric 的检验). 设 $X_1, \dots, X_n \sim f(x)$, 其中

$$H_0 : f(x) = \frac{e^{-1}}{x!}, \quad x = 0, 1, 2, \dots \quad (Poisson(\lambda = 1)),$$

$$H_1 : f(x) = \left(\frac{1}{2}\right)^{x+1}, \quad x = 0, 1, 2, \dots \quad (Geometric(p = 1/2)).$$

构造最佳检验：似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \frac{(2e^{-1})^n \cdot 2^{\sum x_i}}{\prod_{i=1}^n (x_i!)}.$$

令 $k = 1$ (对应某个特定的 α), 不等式化为

$$\frac{2^{\sum x_i}}{\prod_{i=1}^n (x_i!)} \leq \frac{e}{2}.$$

取 $n = 1$, 则临界区域为 $C = \{x_1 : x_1 = 0, 3, 4, 5, \dots\}$ 。

验证:

$$\alpha = \mathbb{P}_{H_0}(X \in C) = 1 - \frac{e^{-1}}{1!} - \frac{e^{-1}}{2!} = 1 - \frac{2}{e} \approx 0.4482,$$

$$Power = \mathbb{P}_{H_1}(X \in C) = 1 - \frac{1}{4} - \frac{1}{8} = 0.625.$$

这符合无偏性要求 (功效大于显著性水平)。

无偏性 (Unbiasedness): 注意到所有最佳检验都满足一个共同性质——功效大于等于显著性水平。这意味着拒绝 H_0 (当它为假时) 的概率不小于错误拒绝它的概率。这在经济决策中是完全合理的——如果检验的功效低于 α , 那它的行为还不如随机猜测。

DEFINITION 8.2 (无偏检验). 设 C 是显著性水平为 α 的检验的临界区域。如果对所有 $\theta \in \omega_1$,

$$\mathbb{P}_\theta(\mathbf{X} \in C) \geq \alpha,$$

则称该检验是**无偏的 (unbiased)**。

推论 8.1.1 表明 Neyman-Pearson 最佳检验是无偏的——在 H_0 为假时拒绝它的概率不低于在 H_0 为真时错误拒绝它的概率。

2. 8.2 Uniformly Most Powerful Tests

2.1. 从简单假设到复合假设. 上一节的 Neyman-Pearson 定理解决的是“简单假设对简单假设”的问题—— H_0 和 H_1 都各只有一个参数值。这是最干净的理论模型, 但它也太理想化了: 实际问题中, 我们通常不知道备择假设会落在哪一个具体点上, 只知道它属于某个方向或某个范围。例如:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

这里 H_1 包含无穷多个参数值。若我们对每一个固定的 $\theta'' > \theta'$ 分别使用 Neyman-Pearson 定理, 可能会得到一族不同的最佳临界区域。真正有用的检验应当更强: 它不仅要对某一个备择点最佳, 而且要同时对整个备择方向都最佳。

能否找到一个检验, 它对 $\theta > \theta'$ 中的每一个 θ 都是最佳检验?

这就是“一致最大功效 (Uniformly Most Powerful, UMP)”检验的思想。

DEFINITION 8.3 (UMP 检验). 设 C 是显著性水平为 α 的检验的临界区域。如果 C 是 H_0 对 H_1 中每一个简单假设的最佳临界区域, 则称 C 为**大小为 α 的一致最大功效临界区域 (UMP critical region)**, 相应的检验称为 **UMP 检验 (Uniformly Most Powerful test)**。

但 UMP 检验并不总是存在。例 8.2.3 展示了: 对于正态均值 $\sigma^2 = 1$ 已知时, 检验 $H_0: \theta = \theta'$ 对 $H_1: \theta \neq \theta'$ (双向备择) 不存在 UMP 检验——因为对 $\theta'' > \theta'$ 的最佳临界区域 (拒绝域在右尾) 与对 $\theta'' < \theta'$ 的最佳临界区域 (拒绝域在左尾) 形式完全不同, 无法统一。

这个例子揭示了一个深刻的事实: **UMP 检验只在单向备择假设 (one-sided alternatives) 下才可能存在。**

2.2. 单调似然比与 Karlin-Rubin 定理. 那么, 在什么条件下 UMP 检验存在呢? 答案藏在一种叫做“单调似然比 (Monotone Likelihood Ratio, MLR)”的性质中。

DEFINITION 8.4 (单调似然比). 设 $L(\theta, \mathbf{x})$ 是似然函数。如果对 $\theta_1 < \theta_2$, 比值

$$\frac{L(\theta_1; \mathbf{x})}{L(\theta_2; \mathbf{x})}$$

是统计量 $y = u(\mathbf{x})$ 的单调递减函数, 则称似然函数在 $y = u(\mathbf{x})$ 中有**单调似然比 (monotone likelihood ratio, mlr)**。

为什么 MLR 如此重要? MLR 性质说的是: 无论把较大的参数值取成哪一个, 数据对大参数的支持程度都可以由同一个统计量 Y 排序。于是“证据更强”这件事有了统一方向: Y 越大, 越支持 θ 较大的备择假设。正因为这个排序不随具体的 θ'' 改变, 我们才有可能得到同一个拒绝域, 而不是为每个备择点重新设计检验。

THEOREM 8.2 (Karlin-Rubin 定理). 设随机样本来自密度 $f(x; \theta)$, 似然函数 $L(\theta, \mathbf{x})$ 在统计量 $Y = u(\mathbf{X})$ 中有单调似然比。考虑单向假设:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

则对任意显著性水平 α , UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y \geq c_Y,$$

其中临界值 c_Y 满足 $\mathbb{P}_{\theta'}(Y \geq c_Y) = \alpha$ 。

核心洞察: 由于 MLR 性质, 对任何 $\theta'' > \theta'$, 最佳临界区域的形式都是 $Y \geq c$ ——它们恰好是同一个区域! 因此这个区域对所有 $\theta'' > \theta'$ 都是最佳的, 从而是一致最大功效的。

证明思路: 对固定的 $\theta'' > \theta'$, 由 Neyman-Pearson 定理, 最佳临界区域由似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x}) \leq k$ 给出。由于 MLR 性质, 这个不等式等价于 $Y \geq g^{-1}(k)$ ——即只依赖于数据的形状, 而不依赖于具体的 θ'' 值。

EXAMPLE 8.4 (正态方差 UMP 检验). 设 $X_1, \dots, X_n \sim N(0, \theta)$, 其中 $\theta > 0$ 是方差。考虑检验:

$$H_0: \theta = \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然函数为

$$L(\theta; \mathbf{x}) = \left(\frac{1}{2\pi\theta}\right)^{n/2} \exp\left\{-\frac{1}{2\theta} \sum_{i=1}^n x_i^2\right\}.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left(\frac{\theta''}{\theta'}\right)^{n/2} \exp\left[-\left(\frac{\theta'' - \theta'}{2\theta'\theta''}\right) \sum_{i=1}^n x_i^2\right].$$

对 $\theta'' > \theta'$, 这是 $\sum x_i^2$ 的递减函数, 因此似然函数在 $Y = \sum X_i^2$ 中有 MLR。

由 Karlin-Rubin 定理, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad \sum_{i=1}^n X_i^2 \geq c,$$

其中 c 满足 $\mathbb{P}_{\theta'}(\sum X_i^2 \geq c) = \alpha$ 。

数值示例: 设 $n = 15$, $\alpha = 0.05$, $\theta' = 3$ 。当 H_0 为真时, $\sum X_i^2/\theta' \sim \chi^2(n)$, 故

$$\frac{c}{3} = \chi_{0.95}^2(15) = 24.996 \quad \Rightarrow \quad c = 74.988.$$

即当 $\sum x_i^2 \geq 74.988$ 时拒绝 $H_0: \theta = 3$ 。

EXAMPLE 8.5 (Bernoulli 分布的 UMP 检验). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$, 考虑检验:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left[\frac{\theta'(1-\theta'')}{\theta''(1-\theta')} \right]^{\sum x_i} \left(\frac{1-\theta'}{1-\theta''} \right)^n.$$

由于 $\theta' < \theta''$ 时 $\theta'(1-\theta'')/\theta''(1-\theta') < 1$, 该比值是 $Y = \sum X_i$ 的递减函数。因此似然函数在 $Y = \sum X_i$ 中有 MLR, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y = \sum_{i=1}^n X_i \geq c,$$

其中 c 由 $\mathbb{P}_{\theta'}(Y \geq c) = \alpha$ 确定。

这正是我们直观上期望的: 观察到更多的成功次数, 就越有理由拒绝“成功率不高”的原假设。

正规指数族 (Regular Exponential Family): 其实 Bernoulli 分布、正态分布 (方差已知)、Poisson 分布都属于一个更广泛的族——正规指数族。在这个族中, 只要自然参数是单调的, 就存在 UMP 检验。具体地, 如果分布有形式

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)],$$

且 $p(\theta)$ 是 θ 的递增函数, 则对假设 $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$, UMP 检验存在, 基于统计量 $Y = \sum_{i=1}^n K(X_i)$ 。

3. 8.3 Likelihood Ratio Tests

3.1. 似然比检验的动机. 前两节给出了最优检验理论中最漂亮的部分: 简单假设有 Neyman-Pearson 定理, 单向复合假设在 MLR 条件下有 Karlin-Rubin 定理。然而, 漂亮理论往往依赖强条件; 一旦问题变成双向备择、多参数模型或带有 nuisance parameter 的复合假设, UMP 检验通常不再存在。现实中许多重要问题正落在这些范畴之外:

- 检验正态均值 $H_0: \mu = \mu_0$ (σ^2 未知) 对 $H_1: \mu \neq \mu_0$ ——不存在 UMP 检验 (双向备择);
- 检验两正态均值是否相等 $H_0: \mu_1 = \mu_2$ ——涉及多于一个参数;
- 一般复合假设——没有 MLR 性质可供利用。

在这些情况下, 我们转向一种通用但不一定最优的构造检验的方法——**似然比检验 (Likelihood Ratio Test, LRT)**。

为什么即使 LRT 不是最优的, 我们仍然使用它? Neyman-Pearson 定理告诉我们, 在最简单的情形中, 似然比就是最佳检验的核心。LRT 保留了这个思想, 但把“两个点之间的比较”推广为“约束参数空间与完整参数空间之间的比较”: 若 H_0 受到约束后仍能很好解释数据, 就没有理由拒绝; 若放开约束后似然显著增大, 数据就在提醒我们 H_0 可能过于狭窄。虽然一般 LRT 不保证有限样本最优, 但它统一、可计算, 并且在正则条件下有清晰的渐近理论。

3.2. LRT 的定义. 设 X 的密度为 $f(\mathbf{x}; \boldsymbol{\theta})$, 参数 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$. 考虑复合假设:

$$H_0: \boldsymbol{\theta} \in \omega \quad \text{versus} \quad H_1: \boldsymbol{\theta} \in \Omega \cap \omega^c,$$

其中 $\omega \subset \Omega$ 是参数空间的某个子集。

DEFINITION 8.5 (似然比). **似然比 (Likelihood Ratio)** 定义为:

$$\Lambda(\mathbf{x}) = \frac{\sup_{\omega} L(\boldsymbol{\theta}; \mathbf{x})}{\sup_{\Omega} L(\boldsymbol{\theta}; \mathbf{x})} = \frac{L(\hat{\omega}; \mathbf{x})}{L(\hat{\Omega}; \mathbf{x})},$$

其中 $\hat{\omega}$ 是在约束 $\boldsymbol{\theta} \in \omega$ 下的 MLE, $\hat{\Omega}$ 是在无约束 $\boldsymbol{\theta} \in \Omega$ 下的 MLE。

直观含义: 分子衡量数据在 H_0 约束下能达到的最大似然, 分母衡量数据在无约束情况下能达到的最大似然。如果 H_0 为真, 这两个值应该差不多, 比值接近 1; 如果 H_0 为假, 无约束的似然会显著大于约束下的似然, 比值会变小。因此我们在小比值时拒绝 H_0 :

$$\text{Reject } H_0 \quad \text{if} \quad \Lambda(\mathbf{x}) \leq \lambda_0 < 1.$$

LRT 的一个关键性质: 在 H_0 下, $-2 \log \Lambda$ 渐近服从 χ^2 分布, 自由度为 $\dim(\Omega) - \dim(\omega)$ (在一定正则条件下)。这使得我们可以近似地确定临界值。

LRT 与 NP 引理的关系: 当 $\Omega = \{\theta', \theta''\}$ (只有两点) 时, LRT 还原为 NP 似然比检验, 此时它是最优的。但一般来说, LRT 不一定是最优的。

接下来我们把 LRT 应用到几个具体的重要情形——正态均值差和正态方差检验。

3.3. 8.3.1 正态均值差的 LRT.

EXAMPLE 8.6 (两样本 t 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_3)$, 两组样本独立, 共同方差 θ_3 未知。考虑检验:

$$H_0: \theta_1 = \theta_2 \quad \text{versus} \quad H_1: \theta_1 \neq \theta_2.$$

构造 LRT: 在 H_0 下 ($\theta_1 = \theta_2 = \mu$), 参数的 MLE 为

$$\hat{\mu} = \frac{n\bar{x} + m\bar{y}}{n + m}, \quad \hat{\sigma}_0^2 = \frac{1}{n + m} \left[\sum_{i=1}^n (x_i - \hat{\mu})^2 + \sum_{i=1}^m (y_i - \hat{\mu})^2 \right].$$

在无约束下 (H_1), MLE 分别为 $\bar{x}$ 、 $\bar{y}$ 和

$$\hat{\sigma}^2 = \frac{1}{n+m} \left[\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 \right].$$

似然比为

$$\Lambda = \frac{L(\hat{\omega})}{L(\hat{\Omega})} = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2} \right)^{(n+m)/2}.$$

与 t 统计量的联系: 可以证明

$$\Lambda^{2/(n+m)} = \frac{(n+m-2)}{(n+m-2) + T^2},$$

其中

$$T = \sqrt{\frac{nm}{n+m}} \frac{\bar{x} - \bar{y}}{S_p}, \quad S_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{n+m-2}.$$

T 服从自由度为 $n+m-2$ 的 t 分布 (在 H_0 下)。由于 $\Lambda \leq \lambda_0 \Leftrightarrow |T| \geq c$, LRT 就是经典的两样本 t 检验。

数值示例: 设 $n=10$, $m=6$, $\alpha=0.05$, 则临界值

$$c = t_{0.975}(14) = 2.1448.$$

如果 $|t| \geq 2.1448$, 拒绝 H_0 (认为两个总体均值不相等)。

功效函数: 对于非中心 t 分布, 当 $\theta_1 \neq \theta_2$ 时, T 服从非中心 t 分布, 非中心参数为

$$\delta = \sqrt{\frac{nm}{n+m}} \frac{\theta_1 - \theta_2}{\sigma}.$$

给定 $\theta_3 = 100$, $n = 20$, $m = 15$, $\alpha = 0.05$, $\Delta = 5 = \theta_1 - \theta_2$, 临界值 $t_{0.975}(33) = 2.0345$, 非中心参数 $\delta_2 = 1.4639$, 功效约为

$$1 - \text{pt}(2.0345, 33, \text{nfp} = 1.4639) + \text{pt}(-2.0345, 33, \text{nfp} = 1.4639) \approx 0.2954.$$

即约 29.5% 的概率检测出均值为 5 的差异。**稳健性注记:** t 检验在正态性假设不满足时表现如何? 在大样本下, 由 Slutsky 定理, 即使底层分布非正态, 只要方差有限, t 统计量仍然渐近正态——因此 t 检验是**渐近正确的**。然而, 在有限样本且严重非正态 (特别是高度偏态) 时, t 检验可能失效——实际显著性水平会偏离名义水平。

3.4. 8.3.2 正态方差的 LRT.

EXAMPLE 8.7 (两方差相等的 F 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_4)$, 独立样本, 考虑检验:

$$H_0: \theta_3 = \theta_4 \quad \text{versus} \quad H_1: \theta_3 \neq \theta_4.$$

可以证明 (练习 8.3.11), LRT 统计量可以化为

$$F = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)}{\sum_{i=1}^m (Y_i - \bar{Y})^2 / (m-1)}.$$

在 H_0 下, $F \sim F(n-1, m-1)$ 。因此双向 LRT 为:

$$\text{Reject } H_0 \quad \text{if} \quad F \leq c_1 \quad \text{or} \quad F \geq c_2,$$

其中 c_1 和 c_2 满足 $\mathbb{P}(F \leq c_1) = \mathbb{P}(F \geq c_2) = \alpha_1/2$ 。

重要警告: 与 t 检验不同, F 检验对正态性假设是敏感的。在非正态情况下, F 检验的名义水平和实际水平可能相差甚远 (可高达 0.80), 因此不应在正态性未经检验的情况下使用 F 检验。

4. 8.4 *Sequential Probability Ratio Test

4.1. 固定样本量检验的局限性. 到目前为止, 我们讨论的所有检验都有一个共同假设: 样本量 n 是预先固定的。但在实际应用中, 固定样本量检验存在一个根本性的低效:

为什么要等到收集完所有 n 个样本才做决策? 为什么不能边收集边决策?

考虑一个质量控制场景: 你需要判断一条生产线是否正常 ($\theta = \theta_0$)。固定样本量方法要求你先收集 n 个样本, 然后做决策。但如果在第 5 个样本时, 数据就已经极其强烈地支持 H_1 (生产线已严重偏离正常状态), 继续等待其余 $n-5$ 个样本就是在浪费时间和资源。

1930 年代, Abraham Wald 提出了一个革命性的思想: 允许样本量根据数据动态确定——这就是序贯分析 (sequential analysis) 的诞生。

Wald 的序贯概率比检验 (SPRT) 不仅在概念上优雅, 而且在功效和样本量之间实现了最优权衡。

4.2. SPRT 的构造. 设 $X_1, X_2, \dots$ 是 iid 随机变量序列, 考虑检验:

$$H_0: \theta = \theta' \quad \text{versus} \quad H_1: \theta = \theta'',$$

其中 θ' 和 θ'' 是给定的具体值。

核心思想: 在每个步骤 n , 计算似然比

$$\Lambda_n = \frac{L(\theta'; x_1, \dots, x_n)}{L(\theta''; x_1, \dots, x_n)} = \prod_{i=1}^n \frac{f(x_i; \theta')}{f(x_i; \theta'')}.$$

如果 Λ_n 非常小 (即数据强烈支持 H_1), 我们就提前停止并拒绝 H_0 ; 如果 Λ_n 非常大 (即数据强烈支持 H_0), 我们就提前停止并接受 H_0 ; 如果 Λ_n 处于中间位置, 我们就继续观察下一个样本。

具体地, 选取两个常数 $A < B$ 。若预先给定目标错误概率 α_a 与 β_a , Hogg 的记号取

$$A = \frac{\alpha_a}{1 - \beta_a}, \quad B = \frac{1 - \alpha_a}{\beta_a},$$

SPRT 的决策规则为:

$$\text{在第 } n \text{ 步, 停止采样并: } \begin{cases} \text{拒绝 } H_0 \text{ (接受 } H_1) & \text{if } \Lambda_n \leq A, \\ \text{接受 } H_0 \text{ (拒绝 } H_1) & \text{if } \Lambda_n \geq B, \\ \text{继续采样} & \text{if } A < \Lambda_n < B. \end{cases}$$

Wald 的误差控制: 教材证明, 在连续型情形下若真实错误概率记为 α 与 β , 则

$$\frac{\alpha}{1-\beta} \leq A, \quad B \leq \frac{1-\alpha}{\beta}.$$

因此取 $A = \alpha_a/(1-\beta_a)$ 、 $B = (1-\alpha_a)/\beta_a$ 时, $\alpha + \beta \leq \alpha_a + \beta_a$, 并且实际应用中 α, β 通常接近预设值 α_a, β_a 。

EXAMPLE 8.8 (Bernoulli 的 SPRT). 设 $X_i \sim \text{Bernoulli}(\theta)$, 检验 $H_0: \theta = 1/3$ 对 $H_1: \theta = 2/3$ 。

似然比为

$$\Lambda_n = \frac{(1/3)^{\sum x_i} (2/3)^{n-\sum x_i}}{(2/3)^{\sum x_i} (1/3)^{n-\sum x_i}} = 2^{n-2\sum x_i}.$$

取对数并整理, 不等式 $A < \Lambda_n < B$ 等价于

$$c_0(n) = \frac{n}{2} - \frac{\log_2 B}{2} < \sum_{i=1}^n x_i < \frac{n}{2} - \frac{\log_2 A}{2} = c_1(n).$$

决策规则: 当 $\sum x_i \geq c_1(n)$ 时, 拒绝 H_0 ; 当 $\sum x_i \leq c_0(n)$ 时, 接受 H_0 ; 否则继续采样。

序贯抽样的图示: 想象一条随机游走——每观察一次 $X_i = 1$, 我们就向右跳 1 个单位; 每观察一次 $X_i = 0$, 我们就向左跳 1 个单位。只要这条路径处于上下边界之间, 我们就继续。一旦路径碰到上界 (强烈支持 H_1) 或下界 (强烈支持 H_0), 我们就停止并做出相应决策。

EXAMPLE 8.9 (正态均值的 SPRT). 设 $X_1, X_2, \dots \sim N(\theta, 100)$, 检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$, 目标是使 $\alpha \approx \beta \approx 0.10$ 。

取 $A = 1/9$ 、 $B = 9$ 。似然比为

$$\Lambda_n = \exp\left(-\frac{6\sum x_i - 459n}{200}\right).$$

不等式 $A < \Lambda_n < B$ 化为

$$c_0(n) = \frac{153}{2}n - \frac{100}{3}\log 9 < \sum_{i=1}^n x_i < \frac{153}{2}n + \frac{100}{3}\log 9 = c_1(n).$$

决策规则: 在第 n 步, 当 $\sum x_i \geq c_1(n)$ 时拒绝 H_0 (认为 $\theta = 78$); 当 $\sum x_i \leq c_0(n)$ 时接受 H_0 (认为 $\theta = 75$); 否则继续采样。

SPRT 的吸引力：为什么 SPRT 如此重要？因为它在固定两类错误概率的同时，通常使用比固定样本量检验更少的样本。Wald 的近似理论表明，当 H_0 或 H_1 为真时，SPRT 的平均样本量（Average Sample Number, ASN）比相应的固定样本量检验小得多——有时能节省 50% 以上的样本。

SPRT 与质量控制：SPRT 的思想在工业质量控制中有广泛应用。CUSUM（累积和）控制图就是 SPRT 的一个变体——它持续累积标准化后的偏离量 $\sum(Z_i - 0.5)$ （其中 Z_i 是标准化后的检验统计量），一旦超出控制限就发出警报。与固定间隔的 Shewhart 控制图相比，CUSUM 能更快检测到过程均值的微小漂移。

5. 8.5 *Minimax and Classification Procedures

5.1. 8.5.1 极小化极大检验。在第 7 章的决策论框架中，我们介绍了极小化极大（minimax）原则：将最大风险最小化。将这个思想应用到假设检验中，会得到一个有趣的结论——**Neyman-Pearson 最佳检验在某种意义上也是极小化极大的。**

考虑简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ ，损失函数满足 $\mathcal{L}(\theta', \theta') = \mathcal{L}(\theta'', \theta'') = 0$ （正确决策无损失），而 $\mathcal{L}(\theta', \theta'') > 0$ 和 $\mathcal{L}(\theta'', \theta') > 0$ （错误决策有损失）。此时风险函数为：

$$R(\theta', C) = \mathcal{L}(\theta', \theta'') \cdot \alpha, \quad R(\theta'', C) = \mathcal{L}(\theta'', \theta') \cdot \beta,$$

其中 α 是显著性水平， β 是 Type II 错误概率。

极小化极大原则要求选择 C 使得 $\max\{R(\theta', C), R(\theta'', C)\}$ 最小。可以证明，当 k 满足

$$\mathcal{L}(\theta', \theta'') \int_C L(\theta') = \mathcal{L}(\theta'', \theta') \int_{C^c} L(\theta'')$$

时（即两类错误造成的风险相等），临界区域 C 是极小化极大的。这个条件与 NP 似然比条件是一致的——本质上，最佳检验同时也是极小化极大检验（当两类错误的相对代价被适当选择时）。

EXAMPLE 8.10（正态均值的极小化极大检验）。设 $X_1, \dots, X_{100} \sim N(\theta, 100)$ ，检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$ ，损失为 $\mathcal{L}(75, 78) = 3$ 、 $\mathcal{L}(78, 75) = 1$ 。

临界区域形如 $\bar{x} \geq c$ ，其中 c 满足：

$$3 \cdot \mathbb{P}_{\theta=75}(\bar{X} \geq c) = \mathbb{P}_{\theta=78}(\bar{X} < c).$$

由于 $\bar{X} \sim N(\theta, 1)$ ，这化为

$$3[1 - \Phi(c - 75)] = \Phi(c - 78).$$

求解得 $c \approx 76.8$ 。此时显著性水平 $\alpha = 1 - \Phi(1.8) \approx 0.036$ ，功效为 $1 - \Phi(-1.2) \approx 0.885$ 。

5.2. 8.5.2 分类问题. 极小化极大检验理论在分类 (classification) 问题中有直接应用。考虑一个二分类问题：我们观察到 (X, Y) ，需要判断它来自分布 $f(x, y; \theta')$ 还是 $f(x, y; \theta'')$ 。

这本质上就是假设检验问题——如果接受 H_0 ，就把 (X, Y) 分类为来自 θ' 类；如果拒绝 H_0 ，就分类为来自 θ'' 类。

由 NP 定理，最佳分类规则是似然比规则：

$$\frac{f(x, y; \theta')}{f(x, y; \theta'')} \leq k \implies \text{分类为 } \theta'' \text{ 类.}$$

若两类的先验概率为 π' 和 π'' ，则最优规则取 $k = \pi''/\pi'$ （当两类等可能时 $k = 1$ ）。

Fisher 线性判别函数：在正态分布的特殊情况下，似然比不等式化为一个线性函数 $ax + by \leq c$ ——这就是著名的 Fisher 线性判别函数。当参数未知时，用训练样本的均值和方差代替，就得到了 Fisher 判别函数。

EXAMPLE 8.11 (二元正态的线性判别). 设 (X, Y) 来自二元正态分布，参数为 $(\mu'_1, \mu'_2, \sigma_1^2, \sigma_2^2, \rho')$ 或 $(\mu''_1, \mu''_2, \sigma_1^2, \sigma_2^2, \rho'')$ 。则似然比不等式化为

$$ax + by \leq c,$$

其中 a 和 b 是由两个总体的均值向量和协方差矩阵决定的常数。这给出了一个**线性决策边界**——在二维空间中是一条直线，将平面分为两部分，分别对应两类。

附录：公式推导

本附录包含 Chapter 8 中省略的完整推导。

5.3. Neyman-Pearson 引理的证明. 背景 (Background): 我们需要证明，当临界区域 C 满足 NP 条件 (a) -(c) 时，它是在固定显著性水平 α 下功效最高的检验。

已知条件 (Given):

- $L(\theta'; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta')$ 是 H_0 下的似然函数
- $L(\theta''; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta'')$ 是 H_1 下的似然函数
- 临界区域 C 满足：

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k, \quad \forall \mathbf{x} \in C; \quad \frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k, \quad \forall \mathbf{x} \in C^c.$$

- 任意其他满足 $\mathbb{P}_{\theta'}(\mathbf{X} \in A) = \alpha$ 的区域 A 。

目标 (Goal): 证明 $\mathbb{P}_{\theta''}(\mathbf{X} \in C) \geq \mathbb{P}_{\theta''}(\mathbf{X} \in A)$ 。

推导步骤 (Derivation Steps):

1. 写出功效差:

$$\int_C L(\theta'') - \int_A L(\theta'') = \int_{C \cap A^c} L(\theta'') - \int_{A \cap C^c} L(\theta'').$$

2. 由条件 (a): 在 C 上 $L(\theta'') \geq \frac{1}{k}L(\theta')$, 故

$$\int_{C \cap A^c} L(\theta'') \geq \frac{1}{k} \int_{C \cap A^c} L(\theta').$$

3. 由条件 (b): 在 C^c 上 $L(\theta'') \leq \frac{1}{k}L(\theta')$, 故

$$\int_{A \cap C^c} L(\theta'') \leq \frac{1}{k} \int_{A \cap C^c} L(\theta').$$

4. 将 (8.A.2) 和 (8.A.3) 代入 (8.A.1):

$$\int_C L(\theta'') - \int_A L(\theta'') \geq \frac{1}{k} \left[\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') \right].$$

5. 计算括号内项:

$$\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') = \int_C L(\theta') - \int_A L(\theta') = \alpha - \alpha = 0.$$

6. 由 (8.A.4) 和 (8.A.5) 得 $\int_C L(\theta'') - \int_A L(\theta'') \geq 0$, 即

$$\mathbb{P}_{\theta''}(\mathbf{X} \in C) \geq \mathbb{P}_{\theta''}(\mathbf{X} \in A).$$

证毕。

5.4. 正态均值 NP 检验的完整推导. 背景 (Background): 在例 8.1.2 中, 我们构造了正态均值差假设的 NP 检验。本节补充完整推导。

目标 (Goal): 对 $X_1, \dots, X_n \sim N(\theta, 1)$, 检验 $H_0: \theta = 0$ 对 $H_1: \theta = 1$, 求大小为 α 的最佳检验。

推导步骤 (Derivation Steps):

1. 写出似然函数:

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

2. 似然比:

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \frac{\exp \left[-\frac{1}{2} \sum x_i^2 \right]}{\exp \left[-\frac{1}{2} \sum (x_i - 1)^2 \right]} = \exp \left[-\sum_{i=1}^n x_i + \frac{n}{2} \right].$$

3. 令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$:

$$\exp \left[-\sum x_i + \frac{n}{2} \right] \leq k \iff \sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

4. 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故临界值

$$c_1 = \frac{c}{n} = \frac{1}{2} - \frac{\log k}{n} = q_\alpha(0, 1/\sqrt{n}).$$

5. 功效函数: 当 $\theta = 1$ 时, $\bar{X} \sim N(1, 1/n)$,

$$\text{Power}(\theta = 1) = P_{\theta=1}(\bar{X} \geq q_\alpha(0, 1/\sqrt{n})) = 1 - \Phi \left(\frac{q_\alpha(0, 1/\sqrt{n}) - 1}{1/\sqrt{n}} \right).$$

证毕。

5.5. Karlin-Rubin 定理的证明. 背景 (Background): 证明当似然函数有 MLR 性质时, 单向复合假设存在 UMP 检验。

已知条件 (Given):

- 似然函数 $L(\theta, \mathbf{x})$ 在 $Y = u(\mathbf{x})$ 中有 MLR: 对 $\theta_1 < \theta_2$, $L(\theta_1; \mathbf{x})/L(\theta_2; \mathbf{x}) = g(Y)$, 其中 g 是递减函数。
- 单向假设: $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$ 。

目标 (Goal): 证明检验 $\phi(\mathbf{x}) = 1$ 当 $Y \geq c_Y$, 其中 c_Y 满足 $\mathbb{P}_{\theta'}(Y \geq c_Y) = \alpha$, 是 UMP level α 检验。

推导步骤 (Derivation Steps):

1. 对简单假设 $H'_0: \theta = \theta'$ 对 $\theta'' > \theta'$ 的最优性: 由 NP 定理, 最佳临界区域由

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$$

给出。由于 MLR 性质, $g(Y) \leq k \iff Y \geq g^{-1}(k)$ 。取 $c_Y = g^{-1}(k)$, 则对任意 $\theta'' > \theta'$, 临界区域 $C = \{Y \geq c_Y\}$ 是 $H'_0: \theta = \theta'$ 对 θ'' 的最佳检验。

2. 对所有 $\theta'' > \theta'$ 的一致性: 由于 NP 最佳临界区域的形式只依赖于 $Y \geq c_Y$ (而不依赖于具体的 θ''), $C = \{Y \geq c_Y\}$ 对所有 $\theta'' > \theta'$ 都是最佳的。

3. 无偏性 (保证 level 不超过 α): 设 $\gamma_Y(\theta) = \mathbb{P}_\theta(Y \geq c_Y)$ 为功效函数。对 $\theta_1 < \theta_2$, 由第 1 步, C 是 θ_1 对 θ_2 的最佳检验, 故 $\gamma_Y(\theta_2) \geq \gamma_Y(\theta_1)$ 。因此 $\gamma_Y(\theta)$ 是 θ 的非降函数, $\max_{\theta \leq \theta'} \gamma_Y(\theta) = \gamma_Y(\theta') = \alpha$ 。故该检验是 level α 的。

综上, $C = \{Y \geq c_Y\}$ 是 UMP level α 检验。证毕。

Exercises

Section 8.1.

EXERCISE 8.1. ?? Best Test for Normal Mean ($\mu = -1$) – Hogg 8.1.1 In Example 8.1.2 of this section, let the simple hypotheses read $H_0: \theta = \theta' = 0$ and $H_1: \theta = \theta'' = -1$. Show that the best test of H_0 against H_1 may be carried out by use of the statistic $\bar{X}$, and that if $n = 25$ and $\alpha = 0.05$, the power of the test is 0.9996 when H_1 is true.

EXERCISE 8.2. ?? Best Test for Exponential Distribution – Hogg 8.1.2 Let the random variable X have the pdf $f(x; \theta) = (1/\theta)e^{-x/\theta}$, $0 < x < \infty$, zero elsewhere. Consider the simple hypothesis $H_0: \theta = \theta' = 2$ and the alternative hypothesis $H_1: \theta = \theta'' = 4$. Let X_1, X_2 denote a random sample of size 2 from this distribution. Show that the best test of H_0 against H_1 may be carried out by use of the statistic $X_1 + X_2$.

EXERCISE 8.3. ?? Generalization for Exponential Best Test – Hogg 8.1.3 Repeat Exercise 8.1.2 when $H_1: \theta = \theta'' = 6$. Generalize this for every $\theta'' > 2$.

EXERCISE 8.4. ?? *Best Critical Region for Normal Variance – Hogg 8.1.4* Let $X_1, X_2, \dots, X_{10}$ be a random sample of size 10 from a normal distribution $N(0, \sigma^2)$. Find a best critical region of size $\alpha = 0.05$ for testing $H_0 : \sigma^2 = 1$ against $H_1 : \sigma^2 = 2$. Is this a best critical region of size 0.05 for testing $H_0 : \sigma^2 = 1$ against $H_1 : \sigma^2 = 4$? Against $H_1 : \sigma^2 = \sigma_1^2 > 1$?

EXERCISE 8.5. ?? *Best Test for Beta Distribution – Hogg 8.1.5* If $X_1, X_2, \dots, X_n$ is a random sample from a distribution having pdf of the form $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere, show that a best critical region for testing $H_0 : \theta = 1$ against $H_1 : \theta = 2$ is $C = \{(x_1, x_2, \dots, x_n) : c \leq \prod_{i=1}^n x_i\}$.

EXERCISE 8.6. ?? *Best Test for Bivariate Normal – Hogg 8.1.6* Let $X_1, X_2, \dots, X_{10}$ be a random sample from a distribution that is $N(\theta_1, \theta_2)$. Find a best test of the simple hypothesis $H_0 : \theta_1 = \theta'_1 = 0, \theta_2 = \theta'_2 = 1$ against the alternative simple hypothesis $H_1 : \theta_1 = \theta''_1 = 1, \theta_2 = \theta''_2 = 4$.

EXERCISE 8.7. ?? *Best Test for Normal Mean with Power Constraint – Hogg 8.1.7* Let $X_1, X_2, \dots, X_n$ denote a random sample from a normal distribution $N(\theta, 100)$. Show that $C = \{(x_1, x_2, \dots, x_n) : c \leq \bar{x} = \sum_1^n x_i/n\}$ is a best critical region for testing $H_0 : \theta = 75$ against $H_1 : \theta = 78$. Find n and c so that

$$\mathbb{P}_{H_0}[(X_1, X_2, \dots, X_n) \in C] = \mathbb{P}_{H_0}(\bar{X} \geq c) = 0.05$$

and

$$\mathbb{P}_{H_1}[(X_1, X_2, \dots, X_n) \in C] = \mathbb{P}_{H_1}(\bar{X} \geq c) = 0.90,$$

approximately.

EXERCISE 8.8. ?? *Best Test for Beta(,) Distribution – Hogg 8.1.8* If $X_1, X_2, \dots, X_n$ is a random sample from a beta distribution with parameters $\alpha = \beta = \theta > 0$, find a best critical region for testing $H_0 : \theta = 1$ against $H_1 : \theta = 2$.

EXERCISE 8.9. ?? *Best Test for Bernoulli with CLT Approximation – Hogg 8.1.9* Let $X_1, X_2, \dots, X_n$ be iid with pmf $f(x; p) = p^x(1-p)^{1-x}$, $x = 0, 1$, zero elsewhere. Show that $C = \{(x_1, \dots, x_n) : \sum_1^n x_i \leq c\}$ is a best critical region for testing $H_0 : p = 1/2$ against $H_1 : p = 1/3$. Use the Central Limit Theorem to find n and c so that approximately $\mathbb{P}_{H_0}(\sum_1^n X_i \leq c) = 0.10$ and $\mathbb{P}_{H_1}(\sum_1^n X_i \leq c) = 0.80$.

EXERCISE 8.10. ?? *Best Test for Poisson Distribution – Hogg 8.1.10* Let $X_1, X_2, \dots, X_{10}$ denote a random sample of size 10 from a Poisson distribution with mean θ . Show that the critical region C defined by $\sum_1^{10} x_i \geq 3$ is a best critical region for testing $H_0 : \theta = 0.1$ against $H_1 : \theta = 0.5$. Determine, for this test, the significance level α and the power at $\theta = 0.5$. Use the R function `ppois`.

Section 8.2.

EXERCISE 8.11. ?? *Power Function for Bernoulli Test – Hogg 8.2.1* Let X have the pmf $f(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$, zero elsewhere. We test the simple hypothesis $H_0 : \theta = 1/4$ against the alternative composite hypothesis $H_1 : \theta < 1/4$ by taking a random sample of size 10 and rejecting $H_0 : \theta = 1/4$ if and only if the observed values $x_1, x_2, \dots, x_{10}$ of the sample observations are such that $\sum_{i=1}^{10} x_i \leq 1$. Find the power function $\gamma(\theta)$, $0 < \theta \leq 1/4$, of this test.

EXERCISE 8.12. ?? *Power Function for Uniform Distribution Test – Hogg 8.2.2* Let X have a pdf of the form $f(x; \theta) = 1/\theta$, $0 < x < \theta$, zero elsewhere. Let $Y_1 < Y_2 < Y_3 < Y_4$ denote the order statistics of a random sample of size 4 from this distribution. Let the observed value of Y_4 be y_4 . We reject $H_0 : \theta = 1$ and accept $H_1 : \theta \neq 1$ if either $y_4 \leq 1/2$ or $y_4 > 1$. Find the power function $\gamma(\theta)$, $0 < \theta$, of the test.

EXERCISE 8.13. ?? *Power Function for Normal Mean Test – Hogg 8.2.3* Consider a normal distribution of the form $N(\theta, 4)$. The simple hypothesis $H_0 : \theta = 0$ is rejected, and the alternative composite hypothesis $H_1 : \theta > 0$ is accepted if and only if the observed mean $\bar{x}$ of a random sample of size 25 is greater than or equal to $3/5$. Find the power function $\gamma(\theta)$, $0 \leq \theta$, of this test.

EXERCISE 8.14. ?? *Two-Sample Normal Test with Power Constraint – Hogg 8.2.4* Consider the distributions $N(\mu_1, 400)$ and $N(\mu_2, 225)$. Let $\theta = \mu_1 - \mu_2$. Let $\bar{x}$ and $\bar{y}$ denote the observed means of two independent random samples, each of size n , from these two distributions. We reject $H_0 : \theta = 0$ and accept $H_1 : \theta > 0$ if and only if $\bar{x} - \bar{y} \geq c$. If $\gamma(\theta)$ is the power function of this test, find n and c so that $\gamma(0) = 0.05$ and $\gamma(10) = 0.90$, approximately.

EXERCISE 8.15. ?? *MLR and UMP Test for Normal Variance – Hogg 8.2.5* Consider Example 8.2.2. Show that $L(\theta)$ has a monotone likelihood ratio in the statistic $\sum_{i=1}^n X_i^2$. Use this to determine the UMP test for $H_0 : \theta = \theta'$, where θ' is a fixed positive number, versus $H_1 : \theta < \theta'$.

EXERCISE 8.16. ?? *No UMP Test for Two-Sided Normal Mean – Hogg 8.2.6* If, in Example 8.2.2 of this section, $H_0 : \theta = \theta'$, where θ' is a fixed positive number, and $H_1 : \theta \neq \theta'$, show that there is no uniformly most powerful test for testing H_0 against H_1 .

EXERCISE 8.17. ?? *UMP Test for Normal Mean – Hogg 8.2.7* Let $X_1, X_2, \dots, X_{25}$ denote a random sample of size 25 from a normal distribution $N(\theta, 100)$. Find a uniformly most powerful critical region of size $\alpha = 0.10$ for testing $H_0 : \theta = 75$ against $H_1 : \theta > 75$.

EXERCISE 8.18. ?? *UMP Test for Normal Mean (Lower Tail) – Hogg 8.2.8* Let $X_1, X_2, \dots, X_n$ denote a random sample from a normal distribution $N(\theta, 16)$. Find the

sample size n and a uniformly most powerful test of $H_0 : \theta = 25$ against $H_1 : \theta < 25$ with power function $\gamma(\theta)$ so that approximately $\gamma(25) = 0.10$ and $\gamma(23) = 0.90$.

EXERCISE 8.19. ?? *Sample Size for Bernoulli UMP Test – Hogg 8.2.9* Consider a distribution having a pmf of the form $f(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$, zero elsewhere. Let $H_0 : \theta = 1/20$ and $H_1 : \theta > 1/20$. Use the Central Limit Theorem to determine the sample size n of a random sample so that a uniformly most powerful test of H_0 against H_1 has a power function $\gamma(\theta)$, with approximately $\gamma(1/20) = 0.05$ and $\gamma(1/10) = 0.90$.

EXERCISE 8.20. ?? *Gamma Distribution SPRT Generalization – Hogg 8.2.10* Illustrative Example 8.2.1 of this section dealt with a random sample of size $n = 2$ from a gamma distribution with $\alpha = 1$, $\beta = \theta$. Thus the mgf of the distribution is $(1 - \theta t)^{-1}$, $t < 1/\theta$, $\theta \geq 2$. Let $Z = X_1 + X_2$. Show that Z has a gamma distribution with $\alpha = 2$, $\beta = \theta$. Express the power function $\gamma(\theta)$ of Example 8.2.1 in terms of a single integral. Generalize this for a random sample of size n .

EXERCISE 8.21. ?? *MLR and UMP Test for Beta Distribution – Hogg 8.2.11* Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere, where $\theta > 0$. Show the likelihood has MLR in the statistic $\prod_{i=1}^n X_i$. Use this to determine the UMP test for $H_0 : \theta = \theta'$ against $H_1 : \theta < \theta'$, for fixed $\theta' > 0$.

EXERCISE 8.22. ?? *Randomized UMP Test for Bernoulli – Hogg 8.2.12* Let X have the pdf $f(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$, zero elsewhere. We test $H_0 : \theta = 1/2$ against $H_1 : \theta < 1/2$ by taking a random sample $X_1, X_2, \dots, X_5$ of size $n = 5$ and rejecting H_0 if $Y = \sum_{i=1}^n X_i$ is observed to be less than or equal to a constant c .

- Show that this is a uniformly most powerful test.
- Find the significance level when $c = 1$.
- Find the significance level when $c = 0$.
- By using a randomized test, as discussed in Example 4.6.4, modify the tests given in parts (b) and (c) to find a test with significance level $\alpha = 2/32$.

EXERCISE 8.23. ?? *UMP Test for Gamma Distribution – Hogg 8.2.13* Let $X_1, \dots, X_n$ denote a random sample from a gamma-type distribution with $\alpha = 2$ and $\beta = \theta$. Let $H_0 : \theta = 1$ and $H_1 : \theta > 1$.

- Show that there exists a uniformly most powerful test for H_0 against H_1 , determine the statistic Y upon which the test may be based, and indicate the nature of the best critical region.
- Find the pdf of the statistic Y in part (a). If we want a significance level of 0.05, write an equation that can be used to determine the critical region. Let $\gamma(\theta)$, $\theta \geq 1$, be the power function of the test. Express the power function as an integral.

EXERCISE 8.24. ?? *MLR Test is Unbiased – Hogg 8.2.14* Show that the MLR test defined by expression (8.2.3) is an unbiased test for the hypotheses (8.2.1).

Section 8.3.

EXERCISE 8.25. ?? *Temperature Data Analysis – Hogg 8.3.1* Verzani (2014) discusses a data set on healthy individuals, including their temperatures by gender. The data are in the file `tempbygender.rda` and the variables of interest are `maletemp` and `femaletemp`. Download this file from the site listed in the Preface.

- (a) Obtain comparison boxplots. Comment on the plots. Which, if any, gender seems to have lower temperatures? Based on the width of the boxplots, comment on the assumption of equal variances.
- (b) As discussed in Example 8.3.3, compute the two-sample, two-sided t -test that there is no difference in the true mean temperatures between genders. Obtain the p -value of the test and conclude in terms of the problem at the nominal α -level of 0.05.
- (c) Obtain a 95% confidence interval for the difference in means. What does it mean in terms of the problem?

EXERCISE 8.26. ?? *Verify LRT Equations – Hogg 8.3.2* Verify Equations (8.3.2) of Example 8.3.1 of this section.

EXERCISE 8.27. ?? *Verify LRT Equations (Continued) – Hogg 8.3.3* Verify Equations (8.3.3) of Example 8.3.1 of this section.

EXERCISE 8.28. ?? *Location Model Two-Sample Test – Hogg 8.3.4* Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ follow the location model

$$\begin{aligned} X_i &= \theta_1 + Z_i, & i &= 1, \dots, n, \\ Y_i &= \theta_2 + Z_{n+i}, & i &= 1, \dots, m, \end{aligned}$$

where $Z_1, \dots, Z_{n+m}$ are iid random variables with common pdf $f(z)$. Assume that $\mathbb{E}(Z_i) = 0$ and $\text{var}(Z_i) = \theta_3 < \infty$.

- (a) Show that $\mathbb{E}(X_i) = \theta_1$, $\mathbb{E}(Y_i) = \theta_2$, and $\text{var}(X_i) = \text{var}(Y_i) = \theta_3$.
- (b) Consider the hypotheses of Example 8.3.1, i.e.,

$$H_0 : \theta_1 = \theta_2 \text{ versus } H_1 : \theta_1 \neq \theta_2.$$

Show that under H_0 , the test statistic T given in expression (8.3.4) has a limiting $N(0, 1)$ distribution.

- (c) Using part (b), determine the corresponding large sample test (decision rule) of H_0 versus H_1 . (This shows that the test in Example 8.3.1 is asymptotically correct.)

EXERCISE 8.29. ?? *Power Function for One-Sample t-Test –Hogg 8.3.5* In Example 8.3.2, the power function for the one-sample t-test is discussed.

- (a) Plot the power function for the following setup: X has a $N(\mu, \sigma^2)$ distribution; $H_0 : \mu = 50$ versus $H_1 : \mu \neq 50$; $\alpha = 0.05$; $n = 25$; and $\sigma = 10$.
- (b) Overlay the power curve in (a) with that for $\alpha = 0.01$. Comment.
- (c) Overlay the power curve in (a) with that for $n = 35$. Comment.
- (d) Determine the smallest value of n so the power exceeds 0.80 to detect $\mu = 53$.
Hint: Modify the R function `tpowerg.R` so it returns the power for a specified alternative.

EXERCISE 8.30. ?? *Drug Comparison Power Analysis –Hogg 8.3.6* The effect that a certain drug (Drug A) has on increasing blood pressure is a major concern. It is thought that a modification of the drug (Drug B) will lessen the increase in blood pressure. Let μ_A and μ_B be the true mean increases in blood pressure due to Drug A and B, respectively. The hypotheses of interest are $H_0 : \mu_A = \mu_B = 0$ versus $H_1 : \mu_A > \mu_B = 0$. The two-sample t-test statistic discussed in Example 8.3.3 is to be used to conduct the analysis. The nominal level is set at $\alpha = 0.05$. For the experimental design assume that the sample sizes are the same; i.e., $m = n$. Also, based on data from Drug A, $\sigma = 30$ seems to be a reasonable selection for the common standard deviation. Determine the common sample size, so that the difference in means $\mu_A - \mu_B = 12$ has an 80% detection rate. Suppose when the experiment is over, due to patients dropping out, the sample sizes for Drugs A and B are respectively $n = 72$ and $m = 68$. What was the actual power of the experiment to detect the difference of 12?

EXERCISE 8.31. ?? *LRT Equals NP Test for Simple Hypotheses –Hogg 8.3.7* Show that the likelihood ratio principle leads to the same test when testing a simple hypothesis H_0 against an alternative simple hypothesis H_1 , as that given by the Neyman-Pearson theorem. Note that there are only two points in Ω .

EXERCISE 8.32. ?? *LRT for Normal Mean (Two-Sided) –Hogg 8.3.8* Let $X_1, X_2, \dots, X_n$ be a random sample from the normal distribution $N(\theta, 1)$. Show that the likelihood ratio principle for testing $H_0 : \theta = \theta'$, where θ' is specified, against $H_1 : \theta \neq \theta'$ leads to the inequality $|\bar{x} - \theta'| \geq c$.

- (a) Is this a uniformly most powerful test of H_0 against H_1 ?
- (b) Is this a uniformly most powerful unbiased test of H_0 against H_1 ?

EXERCISE 8.33. ?? *LRT for Normal Variance –Hogg 8.3.9* Let $X_1, X_2, \dots, X_n$ be iid $N(\theta_1, \theta_2)$. Show that the likelihood ratio principle for testing $H_0 : \theta_2 = \theta'_2$ specified, and θ_1 unspecified, against $H_1 : \theta_2 \neq \theta'_2$, θ_1 unspecified, leads to a test that rejects when $\sum_1^n (x_i - \bar{x})^2 \leq c_1$ or $\sum_1^n (x_i - \bar{x})^2 \geq c_2$, where $c_1 < c_2$ are selected appropriately.

EXERCISE 8.34. ?? *Power Function for LRT in Example 8.3.5 – Hogg 8.3.10* For the situation discussed in Example 8.3.5, derive the power function for the likelihood ratio test statistic given in expression (8.3.9).

EXERCISE 8.35. ?? *LRT for Two Normal Variances – Hogg 8.3.11* Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ be independent random samples from the distributions $N(\theta_1, \theta_3)$ and $N(\theta_2, \theta_4)$, respectively.

- (a) Show that the likelihood ratio for testing $H_0 : \theta_1 = \theta_2, \theta_3 = \theta_4$ against all alternatives is given by

$$\frac{[\sum_1^n (x_i - \bar{x})^2 / n]^{n/2} [\sum_1^m (y_i - \bar{y})^2 / m]^{m/2}}{\{[\sum_1^n (x_i - u)^2 + \sum_1^m (y_i - u)^2] / (m + n)\}^{(n+m)/2}},$$

where $u = (n\bar{x} + m\bar{y}) / (n + m)$.

- (b) Show that the likelihood ratio for testing $H_0 : \theta_3 = \theta_4$ with θ_1 and θ_2 unspecified can be based on the test statistic F given in expression (8.3.9).

EXERCISE 8.36. ?? *LRT for Laplace Distribution – Hogg 8.3.12* Let $Y_1 < Y_2 < \dots < Y_5$ be the order statistics of a random sample of size $n = 5$ from a distribution with pdf $f(x; \theta) = \frac{1}{2}e^{-|x-\theta|}$, $-\infty < x < \infty$, for all real θ . Find the likelihood ratio test Λ for testing $H_0 : \theta = \theta_0$ against $H_1 : \theta \neq \theta_0$.

EXERCISE 8.37. ?? *LRT for Uniform vs Exponential – Hogg 8.3.13* A random sample $X_1, X_2, \dots, X_n$ arises from a distribution given by

$$H_0 : f(x; \theta) = \frac{1}{\theta}, \quad 0 < x < \theta, \quad \text{zero elsewhere,}$$

or

$$H_1 : f(x; \theta) = \frac{1}{\theta}e^{-x/\theta}, \quad 0 < x < \infty, \quad \text{zero elsewhere.}$$

Determine the likelihood ratio (Λ) test associated with the test of H_0 against H_1 .

EXERCISE 8.38. ?? *UMP and LRT for Beta-like Distribution – Hogg 8.3.14* Consider a random sample $X_1, X_2, \dots, X_n$ from a distribution with pdf $f(x; \theta) = \theta(1 - x)^{\theta-1}$, $0 < x < 1$, zero elsewhere, where $\theta > 0$.

- (a) Find the form of the uniformly most powerful test of $H_0 : \theta = 1$ against $H_1 : \theta > 1$.
- (b) What is the likelihood ratio Λ for testing $H_0 : \theta = 1$ against $H_1 : \theta \neq 1$?

EXERCISE 8.39. ?? *LRT for Testing Means with Common Variance – Hogg 8.3.15* Let $X_1, X_2, \dots, X_n$ and $Y_1, Y_2, \dots, Y_n$ be independent random samples from two normal distributions $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$, respectively, where σ^2 is the common but unknown variance.

- (a) Find the likelihood ratio Λ for testing $H_0 : \mu_1 = \mu_2 = 0$ against all alternatives.

- (b) Rewrite Λ so that it is a function of a statistic Z which has a well-known distribution.
- (c) Give the distribution of Z under both null and alternative hypotheses.

EXERCISE 8.40. ?? *LRT for Bivariate Normal – Hogg 8.3.16* Let $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ be a random sample from a bivariate normal distribution with $\mu_1, \mu_2, \sigma_1^2 = \sigma_2^2 = \sigma^2, \rho = 1/2$, where μ_1, μ_2 , and $\sigma^2 > 0$ are unknown real numbers. Find the likelihood ratio Λ for testing $H_0 : \mu_1 = \mu_2 = 0, \sigma^2$ unknown against all alternatives. The likelihood ratio Λ is a function of what statistic that has a well-known distribution?

EXERCISE 8.41. ?? *LRT for Comparing Variances of Laplace Distributions – Hogg 8.3.17* Let X be a random variable with pdf $f_X(x) = (2b_X)^{-1} \exp\{-|x|/b_X\}$, for $-\infty < x < \infty$ and $b_X > 0$. First, show that the variance of X is $\sigma_X^2 = 2b_X^2$. Next, let Y , independent of X , have pdf $f_Y(y) = (2b_Y)^{-1} \exp\{-|y|/b_Y\}$, for $-\infty < x < \infty$ and $b_Y > 0$. Consider the hypotheses

$$H_0 : \sigma_X^2 = \sigma_Y^2 \text{ versus } H_1 : \sigma_X^2 > \sigma_Y^2.$$

To illustrate Remark 8.3.2 for testing these hypotheses, consider the following data set (data are also in the file `exercise8316.rda`). Sample 1 represents the values of a sample drawn on X with $b_X = 1$, while Sample 2 represents the values of a sample drawn on Y with $b_Y = 1$. Hence, in this case H_0 is true.

Sample 1	−0.389	−0.110	−2.177	−0.709	0.813	0.456	−0.001
	0.135	0.763	0.403	−0.570	0.778	−2.565	−0.115
	−1.733						
Sample 2	−1.067	−0.634	−0.577	−0.996	0.361	−0.181	−0.680
	0.239	−0.775	0.213	−1.421	1.425	−0.818	−0.165
	0.328						

- (a) Obtain comparison boxplots of these two samples. Comparison boxplots consist of boxplots of both samples drawn on the same scale. Based on these plots, in particular the interquartile ranges, what do you conclude about H_0 ?
- (b) Obtain the F -test (for a one-sided hypothesis) as discussed in Remark 8.3.2 at level $\alpha = 0.10$. What is your conclusion?
- (c) The test in part (b) is not exact. Why?

EXERCISE 8.42. ?? *Skewed Contaminated Normal Properties – Hogg 8.3.18* For the skewed contaminated normal random variable X of Example 8.3.4, derive the cdf, pdf, mean, and variance of X .

EXERCISE 8.43. ?? *Binomial CI Half-Width – Hogg 8.3.19* For Table 8.3.1 of Example 8.3.4, show that the half-width of the 95% confidence interval for a binomial proportion as given in Chapter 4 is 0.004 at the nominal value of 0.05.

EXERCISE 8.44. ?? *Monte Carlo Study for t-Test under Contaminated Normal – Hogg 8.3.20* If computational facilities are available, perform a Monte Carlo study of the two-sided t -test for the skewed contaminated normal situation of Example 8.3.4. The R function ‘`rscn.R`’ generates variates from the distribution of X .

EXERCISE 8.45. ?? *Unbiased Test for Normal Mean with Known Variance – Hogg 8.3.21* Suppose $X_1, \dots, X_n$ is a random sample on X which has a $N(\mu, \sigma_0^2)$ distribution, where σ_0^2 is known. Consider the two-sided hypotheses

$$H_0 : \mu = 0 \text{ versus } H_1 : \mu \neq 0.$$

Show that the test based on the critical region $C = \{|\bar{X}| > \sqrt{\sigma_0^2/n} z_{\alpha/2}\}$ is an unbiased level α test.

EXERCISE 8.46. ?? *One-Sided Test is Not Unbiased – Hogg 8.3.22* Assume the same situation as in the last exercise but consider the test with critical region $C^* = \{\bar{X} > \sqrt{\sigma_0^2/n} z_\alpha\}$. Show that the test based on C^* has significance level α but that it is not an unbiased test.

Section 8.4.

EXERCISE 8.47. ?? *SPRT for Normal Variance – Hogg 8.4.1* Let X be $N(0, \theta)$ and, in the notation of this section, let $\theta' = 4$, $\theta'' = 9$, $\alpha_a = 0.05$, and $\beta_a = 0.10$. Show that the sequential probability ratio test can be based upon the statistic $\sum_1^n X_i^2$. Determine $c_0(n)$ and $c_1(n)$.

EXERCISE 8.48. ?? *SPRT for Poisson Distribution – Hogg 8.4.2* Let X have a Poisson distribution with mean θ . Find the sequential probability ratio test for testing $H_0 : \theta = 0.02$ against $H_1 : \theta = 0.07$. Show that this test can be based upon the statistic $\sum_{i=1}^n X_i$. If $\alpha_a = 0.20$ and $\beta_a = 0.10$, find $c_0(n)$ and $c_1(n)$.

EXERCISE 8.49. ?? *SPRT for Difference of Normal Means – Hogg 8.4.3* Let the independent random variables Y and Z be $N(\mu_1, 1)$ and $N(\mu_2, 1)$, respectively. Let $\theta = \mu_1 - \mu_2$. Let us observe independent observations from each distribution, say $Y_1, Y_2, \dots$ and $Z_1, Z_2, \dots$. To test sequentially the hypothesis $H_0 : \theta = 0$ against $H_1 : \theta = 1/2$, use the sequence $X_i = Y_i - Z_i$, $i = 1, 2, \dots$. If $\alpha_a = \beta_a = 0.05$, show that the test can be based upon $\bar{X} = \bar{Y} - \bar{Z}$. Find $c_0(n)$ and $c_1(n)$.

EXERCISE 8.50. ?? *SPRT for Binomial Process – Hogg 8.4.4* Suppose that a manufacturing process makes about 3% defective items, which is considered satisfactory for this particular product. The managers would like to decrease this to about 1% and clearly want to guard against a substantial increase, say to 5%. To monitor the process, periodically $n = 100$ items are taken and the number X of defectives counted. Assume that X is $b(n = 100, p = \theta)$. Based on a sequence $X_1, X_2, \dots, X_m, \dots$, determine a sequential

probability ratio test that tests $H_0 : \theta = 0.01$ against $H_1 : \theta = 0.05$. (Note that $\theta = 0.03$, the present level, is in between these two values.) Write this test in the form

$$h_0 > \sum_{i=1}^m (x_i - nd) > h_1$$

and determine d , h_0 , and h_1 if $\alpha_a = \beta_a = 0.02$.

EXERCISE 8.51. ?? SPRT for Beta Distribution –Hogg 8.4.5 Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere.

- (a) Find a complete sufficient statistic for θ .
- (b) If $\alpha_a = \beta_a = 1/10$, find the sequential probability ratio test of $H_0 : \theta = 2$ against $H_1 : \theta = 3$.

Section 8.5.

EXERCISE 8.52. ?? Minimax Test for Normal Mean –Hogg 8.5.1 Let $X_1, X_2, \dots, X_{20}$ be a random sample of size 20 from a distribution that is $N(\theta, 5)$. Let $L(\theta)$ represent the joint pdf of $X_1, X_2, \dots, X_{20}$. The problem is to test $H_0 : \theta = 1$ against $H_1 : \theta = 0$. Thus $\Omega = \{\theta : \theta = 0, 1\}$.

- (a) Show that $L(1)/L(0) \leq k$ is equivalent to $\bar{x} \leq c$.
- (b) Find c so that the significance level is $\alpha = 0.05$. Compute the power of this test if H_1 is true.
- (c) If the loss function is such that $\mathcal{L}(1, 1) = \mathcal{L}(0, 0) = 0$ and $\mathcal{L}(1, 0) = \mathcal{L}(0, 1) > 0$, find the minimax test. Evaluate the power function of this test at the points $\theta = 1$ and $\theta = 0$.

EXERCISE 8.53. ?? Minimax Test for Poisson Distribution –Hogg 8.5.2 Let $X_1, X_2, \dots, X_{10}$ be a random sample of size 10 from a Poisson distribution with parameter θ . Let $L(\theta)$ be the joint pdf of $X_1, X_2, \dots, X_{10}$. The problem is to test $H_0 : \theta = 1/2$ against $H_1 : \theta = 1$.

- (a) Show that $L(1/2)/L(1) \leq k$ is equivalent to $y = \sum_{i=1}^n x_i \geq c$.
- (b) In order to make $\alpha = 0.05$, show that H_0 is rejected if $y > 9$ and, if $y = 9$, reject H_0 with probability $1/2$ (using some auxiliary random experiment).
- (c) If the loss function is such that $\mathcal{L}(1/2, 1/2) = \mathcal{L}(1, 1) = 0$ and $\mathcal{L}(1/2, 1) = 1$ and $\mathcal{L}(1, 1/2) = 2$, show that the minimax procedure is to reject H_0 if $y > 6$ and, if $y = 6$, reject H_0 with probability 0.08 (using some auxiliary random experiment).

EXERCISE 8.54. ?? Classification for Bivariate Normal –Hogg 8.5.3 In Example 8.5.2 let $\mu'_1 = \mu'_2 = 0$, $\mu''_1 = \mu''_2 = 1$, $\sigma_1^2 = 1$, $\sigma_2^2 = 1$, and $\rho = 1/2$.

- (a) Find the distribution of the linear function $aX + bY$.
- (b) With $k = 1$, compute $P(aX + bY \leq c; \mu'_1 = \mu'_2 = 0)$ and $P(aX + bY > c; \mu''_1 = \mu''_2 = 1)$.

EXERCISE 8.55. ?? *Newton's Algorithm for Minimax – Hogg 8.5.4 Determine Newton's algorithm to find the solution of Equation (8.5.2). If software is available, write a program that performs your algorithm and then show that the solution is $c = 76.8$. If software is not available, solve (8.5.2) by "trial and error".*

EXERCISE 8.56. ?? *Classification Rule for Bivariate Exponential – Hogg 8.5.5 Let X and Y have the joint pdf*

$$f(x, y; \theta_1, \theta_2) = \frac{1}{\theta_1 \theta_2} \exp \left(-\frac{x}{\theta_1} - \frac{y}{\theta_2} \right), \quad 0 < x < \infty, \quad 0 < y < \infty,$$

zero elsewhere, where $0 < \theta_1, 0 < \theta_2$. An observation (x, y) arises from the joint distribution with parameters equal to either $(\theta'_1 = 1, \theta'_2 = 5)$ or $(\theta''_1 = 3, \theta''_2 = 2)$. Determine the form of the classification rule.

EXERCISE 8.57. ?? *Quadratic Classification Rule – Hogg 8.5.6 Let X and Y have a joint bivariate normal distribution. An observation (x, y) arises from the joint distribution with parameters equal to either*

$$\mu'_1 = \mu'_2 = 0, \quad (\sigma_1^2)' = (\sigma_2^2)' = 1, \quad \rho' = 1/2$$

or

$$\mu''_1 = \mu''_2 = 1, \quad (\sigma_1^2)'' = 4, \quad (\sigma_2^2)'' = 9, \quad \rho'' = 1/2.$$

Show that the classification rule involves a second-degree polynomial in x and y .

EXERCISE 8.58. ?? *Classification for Bivariate Normal with Different Variances – Hogg 8.5.7 Let $\mathbf{W}' = (W_1, W_2)$ be an observation from one of two bivariate normal distributions, I and II, each with $\mu_1 = \mu_2 = 0$ but with the respective variance-covariance matrices*

$$\mathbf{V}_1 = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix} \quad \text{and} \quad \mathbf{V}_2 = \begin{pmatrix} 3 & 0 \\ 0 & 12 \end{pmatrix}.$$

How would you classify $\mathbf{W}$ into I or II?

CHAPTER 9

ANOVA and Regression

Chapter 9 Overview

在前几章中，我们讨论了来自单个总体的样本推断，以及两个总体的比较。但实际中，我们常常面临更复杂的问题：

如果有三个、四个甚至更多个总体，我们该如何比较它们的均值？

这个问题——即**多组比较问题**——在农业实验、医学试验、工业质量控制等领域无处不在。例如，在一项评估不同肥料对作物产量影响的实验中，我们需要同时比较多个处理组；而在研究药物疗效时，我们可能需要同时评估多种药物的效果。

本章，我们从单样本 t 检验 $\rightarrow$ 两样本 t 检验 $\rightarrow$ 多组比较的自然推广，引入**方差分析 (Analysis of Variance, 简称 ANOVA)**。这一方法由 Ronald Fisher 在 1920 年代创立，起源于他在英国洛桑农业实验站的农业实验研究。Fisher 的核心思想是：将总变异分解为可解释的变异和随机误差，通过比较两者来判断处理效应是否显著。

本章路线图：

- (1) One-Way ANOVA $\rightarrow$ 组间/组内平方和分解 $\rightarrow F$ 检验
- (2) 非中心 χ^2 和 F 分布 $\rightarrow$ 备择假设下的分布
- (3) Multiple Comparisons $\rightarrow$ Tukey 法、Bonferroni 法（控制族误差率）
- (4) Two-Way ANOVA $\rightarrow$ 主效应、交互效应
- (5) 回归问题 $\rightarrow$ 最小二乘估计、几何解释（投影）
- (6) 二次型分布 $\rightarrow$ Cochran 定理——平方和分解的理论基础

1. 9.1 Introduction

在正式进入 ANOVA 之前，我们需要介绍一个重要的数学工具——**二次型 (quadratic form)**。

DEFINITION 9.1 (二次型). 设 $X_1, \dots, X_n$ 是 n 个变量， a_{ij} 是常数。形如

$$q(X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^n X_i a_{ij} X_j$$

的表达式称为 $X_1, \dots, X_n$ 的（二次）**二次型**。

为什么二次型重要？ 在统计推断中，许多关键的统计量都可以表示为二次型。例如，样本方差

$$(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

就是关于样本 $X_1, \dots, X_n$ 的一个二次型。理解二次型的分布性质, 是理解 ANOVA 和回归分析的理论基础。

2. 9.2 One-Way ANOVA

2.1. 问题的引入. 考虑 b 个独立的正态总体, 第 j 个总体的均值为 μ_j , 共同方差为 σ^2 。从第 j 个总体中抽取容量为 n_j 的随机样本 $X_{1j}, X_{2j}, \dots, X_{n_jj}$ 。记总样本量为 $n = \sum_{j=1}^b n_j$ 。

模型为:

$$X_{ij} = \mu_j + e_{ij}, \quad i = 1, \dots, n_j, \quad j = 1, \dots, b,$$

其中 e_{ij} 是 iid $N(0, \sigma^2)$ 随机误差。

我们想检验: 所有 b 个总体的均值是否相等——

$$H_0: \mu_1 = \mu_2 = \dots = \mu_b \quad \text{vs} \quad H_1: \mu_j \neq \mu_{j'} \text{ 对某些 } j \neq j'.$$

实际背景: 例如, b 种药物对某种疾病的疗效比较; 或 b 种肥料对作物产量的影响。这里“一种因素 (factor)”处于 b 个“水平 (level)”, 因此称为**单因素实验 (one-way layout)**。

2.2. 似然比检验的推导. 完全模型 (full model) 参数空间:

$$\Omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : -\infty < \mu_j < \infty, \quad 0 < \sigma^2 < \infty\}.$$

约束模型 (reduced model) 参数空间 (H_0 下):

$$\omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : \mu_1 = \dots = \mu_b = \mu, \quad 0 < \sigma^2 < \infty\}.$$

完全模型下的 MLE:

$$\hat{\mu}_j = \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\Omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2.$$

约束模型下的 MLE (此时等价于单样本问题):

$$\hat{\mu}_\omega = \bar{X}_{..} = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2.$$

似然比统计量简化后的形式为:

$$\Lambda^{n/2} = \frac{\hat{\sigma}_\Omega^2}{\hat{\sigma}_\omega^2}.$$

拒绝 H_0 等价于 F 统计量过大, 其中

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)},$$

而

$$Q_3 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2, \quad Q_4 = \sum_{j=1}^b n_j (\bar{X}_{\cdot j} - \bar{X}_{..})^2.$$

核心分解:

$$\underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2}_Q = \underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}_{Q_3(\text{组内})} + \underbrace{\sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2}_{Q_4(\text{组间})}.$$

在 H_0 下, $Q_3/\sigma^2 \sim \chi^2(n-b)$, $Q_4/\sigma^2 \sim \chi^2(b-1)$, 且二者独立。因此 $F \sim F(b-1, n-b)$ 。

2.3. ANOVA 表格. 单因素 ANOVA 的结果可以汇总为一张清晰的表格:

表 1. 单因素 ANOVA 表格

来源	平方和 (SS)	df	均方 (MS)	F 统计量	p 值
组间 (Between)	Q_4	$b-1$	$MSB = Q_4/(b-1)$	$\frac{MSB}{MSW}$	$\mathbb{P}(F > F_0)$
组内 (Within)	Q_3	$n-b$	$MSW = Q_3/(n-b)$		
总计 (Total)	Q	$n-1$			

EXAMPLE 9.1 (合金弹性模量). Devore (2012, 第 412 页) 报告了一项数据: 三种铸造工艺 (永久模具、压铸、石膏模具) 生产合金的弹性模量。三种工艺各有多次测量, 我们想知道铸造工艺是否显著影响弹性模量。

数据汇总后, $F = 12.565$, 自由度为 2 和 19, p 值为 0.0003。如此小的 p 值表明: 铸造工艺对弹性模量有显著影响。

3. 9.3 Noncentral χ^2 and F Distributions

3.1. 为什么需要非中心分布? 在前一节的 ANOVA 中, 我们在原假设 H_0 下推导了 F 统计量的分布。但在实际应用中, 我们更关心: 当 H_0 不成立 (即各组均值不全相等) 时, F 统计量的分布是什么? 这时就需要引入**非中心 χ^2 分布**和**非中心 F 分布**。

DEFINITION 9.2 (非中心 χ^2 分布). 设 $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, \dots, n$, 独立。则

$$Y = \sum_{i=1}^n \frac{X_i^2}{\sigma^2}$$

的 mgf 为

$$M(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}, \quad t < \frac{1}{2}.$$

此时称 $Y \sim \chi^2(r, \theta)$, 其中 $r = n$ 是自由度, $\theta = \sum_{i=1}^n \mu_i^2 / \sigma^2$ 是**非中心参数 (noncentrality parameter)**。

直观理解: 当所有 $\mu_i = 0$ 时, $\theta = 0$, 回到中心 χ^2 分布; 当某些 $\mu_i \neq 0$ 时, Y 的分布在中心 χ^2 的基础上向右偏移, θ 越大, 偏移越明显。

非中心 χ^2 分布的均值: $\mathbb{E}(Y) = r + \theta$ (中心部分 r 加上非中心部分 θ)。

DEFINITION 9.3 (非中心 F 分布). 设 $U \sim \chi^2(r_1, \theta)$, $V \sim \chi^2(r_2)$, 独立。则

$$F = \frac{r_2 U}{r_1 V}$$

服从自由度为 r_1, r_2 、非中心参数为 θ 的非中心 F 分布, 记作 $F(r_1, r_2, \theta)$ 。

EXAMPLE 9.2 (One-Way ANOVA 的非中心参数). 对于 one-way ANOVA 模型 (??), 在备择假设 H_1 下, F 统计量的分子 $Q_4/\sigma^2 \sim \chi^2(b-1, \theta)$, 其中

$$\theta = \frac{1}{\sigma^2} \sum_{j=1}^b n_j (\mu_j - \bar{\mu})^2, \quad \bar{\mu} = \frac{1}{n} \sum_{j=1}^b n_j \mu_j.$$

当 H_0 成立时, $\theta = 0$, 回到中心 F 分布; 当 H_1 成立时, $\theta > 0$, F 分布向右偏移, 偏移程度由 θ 刻画。这解释了为什么 F 检验在 H_0 不成立时倾向于取更大的值。

4. 9.4 Multiple Comparisons

当 one-way ANOVA 的 F 检验拒绝了 H_0 后, 我们自然想知道: 具体哪些组之间存在显著差异? 这就是多重比较问题 (Multiple Comparison Problem, MCP)。

4.1. 问题的核心矛盾. 对 b 个总体, 若进行所有 $\binom{b}{2}$ 个成对比较, 即使每个置信区间的置信水平为 95%, 整体的置信水平也会急剧下降。举例来说, 若 $b = 5$, 则共有 10 个成对比较, 每个比较犯错的概率为 5%, 至少有一次犯错的概率粗略估计为 $1 - (0.95)^{10} \approx 40\%$ 。

因此, 我们需要专门设计的方法来**控制族误差率 (Family-Wise Error Rate, FWER)**——即**在所有比较中至少有一次犯错的概率**。

4.2. Bonferroni 方法. Bonferroni 方法基于一个简单的不等式: 对 k 个参数 θ_i , 若每个区间 I_i 的置信水平为 $1 - \alpha$, 则

$$P(\text{所有 } \theta_i \in I_i) \geq 1 - k\alpha.$$

核心理想: 将每个区间的置信水平从 $1 - \alpha$ 调整为 $1 - \alpha/k$, 则整体的置信水平至少为 $1 - \alpha$ 。

对 one-way ANOVA, 成对差值 $\mu_j - \mu_{j'}$ 的 Bonferroni 置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm t_{\alpha/(2k), n-b} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}.$$

优点: 通用性强, 适用于任何成对比较。**缺点:** 比较数量 k 越大, 区间越宽, 精度损失越大。

4.3. Tukey 方法. Tukey 方法利用**学生化极差分布 (Studentized range distribution)**，专为 balanced 设计的成对比较设计。

当所有组样本容量相等 ($n_j = a, j = 1, \dots, b$) 时，所有成对比较的**同时置信区间**为：

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm q_{1-\alpha, b, n-b} \frac{\hat{\sigma}_{\Omega}}{\sqrt{a}}, \quad \forall j \neq j'.$$

其中 $q_{1-\alpha, b, n-b}$ 是自由度为 b 和 $n-b$ 的学生化极差分布分位数。

对于 unbalanced 情形，使用 Tukey-Kramer 修正：

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm \frac{q_{1-\alpha, b, n-b}}{\sqrt{2}} \hat{\sigma}_{\Omega} \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}.$$

EXAMPLE 9.3 (赛车速度比较). *Kitchens (1997)* 报告了一项实验：比较五种汽车 (*Acura, Ferrari, Lotus, Porsche, Viper*) 的最高速度。每种车进行 6 次运行测试。整体 F 检验高度显著 ($F = 25.15, p \approx 0$)。Tukey 多重比较结果表明：*Ferrari* 和 *Porsche* 的平均速度显著快于其他三种车，但 *Ferrari* 与 *Porsche* 之间速度差异不显著。

4.4. Fisher 的保护 LSD 方法. Fisher 方法是一个两步程序：

- (1) 首先进行整体 F 检验；若拒绝 H_0 ,
- (2) 再使用标准的成对 t 置信区间 (置信水平 $1 - \alpha$)。

Fisher 方法不保证整体覆盖率为 $1 - \alpha$ ，但 F 检验提供了”保护”。模拟研究表明它在功效和实际误差率方面表现良好。

5. 9.5 Two-Way ANOVA

5.1. 双因素实验的引入. 在实际研究中，我们常常需要同时考虑两个因素对结果的影响。例如：

- 作物产量：同时受品种 (因素 A) 和肥料类型 (因素 B) 的影响
- 考试成绩：同时受教学方法 (因素 A) 和班级规模 (因素 B) 的影响

这就是**双因素方差分析 (two-way ANOVA)**。

设因素 A 有 a 个水平，因素 B 有 b 个水平，每个组合有一个观测值 X_{ij} 。模型为：

$$X_{ij} = \mu + \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b,$$

其中 $e_{ij} \sim N(0, \sigma^2)$ iid, 且 $\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0$ 。

可加模型 (additive model) 意味着两个因素的影响是相互独立的——因素 A 的效应不随因素 B 的水平变化。

表 2. 双因素可加模型的单元格均值示例 ($a = 2, b = 3$)

	B=1	B=2	B=3
A=1	7	6	5
A=2	5	4	3

在可加模型中，行均值轮廓线是**平行的**——这是可加模型的重要特征。

5.2. 假设检验. 我们需要检验两个主效应假设:

$$H_{0A} : \alpha_1 = \cdots = \alpha_a = 0 \quad \text{vs} \quad H_{1A} : \text{某些} \alpha_i \neq 0,$$

$$H_{0B} : \beta_1 = \cdots = \beta_b = 0 \quad \text{vs} \quad H_{1B} : \text{某些} \beta_j \neq 0.$$

检验 H_{0B} 的 F 统计量:

$$F_B = \frac{a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 / (b-1)}{\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2 / [(a-1)(b-1)]}.$$

在 H_{0B} 下, $F_B \sim F(b-1, (a-1)(b-1))$ 。

类似地, 检验 H_{0A} 的 F 统计量 $F_A \sim F(a-1, (a-1)(b-1))$ 。

5.3. 9.5.1 Interaction between Factors. 交互效应发生在: 一个因素的影响程度取决于另一个因素的水平时。

在模型中引入交互参数 γ_{ij} :

$$\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij},$$

其中 $\sum_i \gamma_{ij} = \sum_j \gamma_{ij} = 0$ 。

若所有 $\gamma_{ij} = 0$, 则回到可加模型; 若存在非零 γ_{ij} , 则两个因素之间存在交互作用。

图形诊断: 在双因素实验中, 绘制各行 (因素 A 各水平) 的均值轮廓线。若线条大致平行, 则交互作用不明显; 若线条明显交叉或分离, 则表明存在交互效应。

EXAMPLE 9.4 (沥青混合料热导率). Devore (2012, 第 435 页) 研究了两个因素对沥青混合料热导率的影响: 粘结剂等级 (PG58, PG64, PG70) 和粗骨料含量 (38%, 41%, 44%)。每个处理组合有 2 次重复。

R 分析结果: 交互效应不显著 ($p = 0.4135$), 但两个主效应都非常显著 ($p = 0.0017$ 和 $p < 10^{-5}$)。因此接受可加模型, 两个因素独立地影响热导率。

6. 9.6 A Regression Problem

6.1. 为什么研究回归? ANOVA 研究的是类别型 (categorical) 自变量对因变量的影响。但在许多实际问题中, 自变量是连续型的。例如:

- 学生的学习时间 (连续) $\rightarrow$ 考试成绩
- 汽车的发动机排量 (连续) $\rightarrow$ 每加仑行驶里程
- 农作物的施肥量 (连续) $\rightarrow$ 作物产量

这就引出了**回归分析 (regression analysis)**——研究自变量 (通常记作 x) 与因变量 Y 之间关系的方法。

线性模型: 假设 $\mathbb{E}(Y) = \mu(x)$ 是 x 的线性函数——

$$Y_i = \alpha + \beta(x_i - \bar{x}) + e_i, \quad i = 1, \dots, n,$$

其中 $e_i \sim N(0, \sigma^2)$ iid。

为什么假设 x 是已知的非随机变量? 这是为了简化分析——我们把不确定性全部放在 Y 上。在实际中, 如果 x 也是随机的, 则需要联合分布建模; 但在受控实验或观测研究中, 将 x 视为固定设计点是合理的近似。

线性模型 vs 非线性模型: 这里“线性”指的是对参数 (α, β) 线性, 而非对 x 线性。因此 $\alpha + \beta x + \gamma x^2$ 仍是线性模型, 而 $\alpha e^{\beta x}$ 不是。

6.2. 9.6.1 Maximum Likelihood Estimates. 对模型 (??), 似然函数为

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{[Y_i - \alpha - \beta(x_i - \bar{x})]^2}{2\sigma^2} \right\}.$$

最大化似然等价于最小化

$$H(\alpha, \beta) = \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2.$$

这正是**最小二乘法 (least squares)**——选择使残差平方和最小的 α, β 。

几何直观: $|Y_i - \alpha - \beta(x_i - \bar{x})|$ 是点 (x_i, Y_i) 到直线 $y = \alpha + \beta(x - \bar{x})$ 的垂直距离。最小二乘法就是找到使所有这些距离平方和最小的直线。

MLE 的解:

$$\begin{aligned} \hat{\alpha} &= \bar{Y}, \\ \hat{\beta} &= \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \end{aligned}$$

$\hat{\sigma}^2$ 的 MLE:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

拟合值与残差:

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}(x_i - \bar{x}), \quad \hat{e}_i = Y_i - \hat{Y}_i.$$

估计量的分布: 可以证明

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{pmatrix} \right).$$

EXAMPLE 9.5 (男子 1500 米奥运会成绩). 考虑 27 届奥运会男子 1500 米冠军成绩与年份的关系。年份为自变量 x , 时间为因变量 Y 。

R 拟合结果: $\hat{y} = 12.33 - 0.0044 \times \text{year}$. 斜率的 95% 置信区间为 $(-0.00547, -0.00328)$ ——这意味着每年获胜时间平均减少约 0.004 分钟 (约 0.24 秒)。对 2020 年奥运会的预测时间约为 3.486 分钟。

残差图诊断: 在回归分析中, 绘制残差 $\hat{e}_i$ vs 拟合值 $\hat{Y}_i$ 的散点图。如果图呈现随机散布, 说明模型是合理的; 如果出现系统模式 (如 U 形、漏斗形), 则提示模型设定有问题 (如遗漏非线性项、异方差等)。

6.3. 9.6.2 *Geometry of the Least Squares Fit. 最小二乘拟合有一个优美的几何解释。

将数据写成向量形式 $\mathbf{Y} = (Y_1, \dots, Y_n)'$, 设计矩阵 $\mathbf{X}$ 的列为 $\mathbf{1}$ 和 $\mathbf{x}_c = (x_1 - \bar{x}, \dots, x_n - \bar{x})'$ 。模型为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}).$$

设 V 为 $\mathbf{X}$ 列张成的 $\mathbb{R}^n$ 中的二维子空间 (拟合空间)。最小二乘估计 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 正是 $\mathbf{Y}$ 在子空间 V 上的**正交投影**——即使得 $\|\mathbf{Y} - \boldsymbol{\theta}\|^2$ 最小的 V 中元素。

几何分解:

$$\|\mathbf{Y}\|^2 = \|\hat{\boldsymbol{\theta}}\|^2 + \|\hat{\mathbf{e}}\|^2,$$

其中 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 是残差向量, 且 $\hat{\boldsymbol{\theta}} \perp \hat{\mathbf{e}}$ (残差与拟合空间正交)。这正是 ANOVA 中平方和分解的几何版本。

7. 9.7 A Test of Independence

在许多应用中, 我们需要检验两个连续变量 X 和 Y 是否独立。对于二元正态分布, X 和 Y 独立当且仅当它们的相关系数 $\rho = 0$ 。因此我们检验:

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0.$$

样本相关系数:

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}.$$

关键定理: 在 H_0 下 (即 $\rho = 0$ 时), R 的分布不依赖于 X 的具体分布——只要 X 与 Y 独立, R 的分布在正态情况下就有上式 (??) 给出的精确形式。特别是,

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t(n-2).$$

因此, H_0 的拒绝域为 $|T| \geq t_{\alpha/2, n-2}$, 或等价地 $|R| \geq c$ 。

Remark 的深层含义: R 的条件分布 (在给定 $X_1, \dots, X_n$ 下) 不依赖于 X_i 的具体值, 这意味着 R 与所有仅依赖于 X 的统计量独立。这是一个非常优雅的性质——样本相关系数在 $\rho = 0$ 时”不受” X 取值的影响。

8. 9.8 Distributions of Certain Quadratic Forms

前几节的分析依赖于一个共同的理论支柱: 某些二次型服从 χ^2 分布, 且它们相互独立。本节和下一节建立这一理论的严格基础。

设 $\mathbf{X}' = (X_1, \dots, X_n)$, 其中 $X_i \sim N(\mu_i, \sigma^2)$ iid. 二次型 $Q = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}$ 的 mgf 为:

$$M_Q(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}.$$

特别地, 若 $\mathbf{A}$ 是对称幂等矩阵 ($\mathbf{A}^2 = \mathbf{A}$), 则 $Q \sim \chi^2(r, \theta)$, 其中 $r = \text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A})$, $\theta = \boldsymbol{\mu}' \mathbf{A} \boldsymbol{\mu} / \sigma^2$ 。若进一步 $\boldsymbol{\mu} = \mu \mathbf{1}$ 且 $\sum_{i,j} a_{ij} = 0$, 则 $\theta = 0$, Q 为中心 $\chi^2(r)$ 。

Cochran 定理的特例: 若 $Q_1, \dots, Q_k$ 是相互独立的 χ^2 变量之和, 且 $\sum \text{rank}(Q_i) = n$, 则各 Q_i 独立。

9. 9.9 The Independence of Certain Quadratic Forms

最后一个理论工具: Craig 定理, 给出了两个二次型独立的充要条件。

这个定理在 ANOVA 中有重要应用: 在 one-way ANOVA 中, 组间平方和 Q_4 (对应某个幂等矩阵) 与组内平方和 Q_3 (对应另一个幂等矩阵) 满足 $\mathbf{AB} = \mathbf{0}$, 因此独立——这正是 F 检验的理论基础。

推论: 在回归模型中, 拟合值的二次型与残差的二次型相互独立, 反映了“被解释的变异”与“未被解释的变异”之间的正交性。

习题

EXERCISE 9.1. ?? T^2 与 F 统计量的关系—Hogg 9.2.1 考虑在例 8.3.1 中通过似然比检验推导出的 T 统计量, 用于检验两个具有公共方差的正态分布均值的相等性。证明 T^2 恰好是表达式 (9.2.11) 中的 F 统计量。

EXERCISE 9.2. ?? 线性函数的不相关性—Hogg 9.2.2 在模型 (9.2.1) 下, 证明线性函数 $X_{ij} - \bar{X}_{.j}$ 与 $\bar{X}_{.j} - \bar{X}_{..}$ 不相关。

提示: 回忆 $\bar{X}_{.j}$ 和 $\bar{X}_{..}$ 的定义, 不失一般性地设 $E(X_{ij}) = 0$ 对所有 i, j 。

EXERCISE 9.3. ?? One-Way ANOVA 数据计算—Hogg 9.2.3 考虑来自三个正态分布的独立随机样本, 它们具有相等方差及 respective means μ_1, μ_2, μ_3 。数据如下:

I	II	III
0.5	2.1	3.0
1.3	3.3	5.1
-1.0	0.0	1.9
1.8	2.3	2.4
	2.5	4.2
		4.1

使用 R 或其他统计软件, 计算用于检验 $H_0: \mu_1 = \mu_2 = \mu_3$ 的 F 统计量。

EXERCISE 9.4. ?? 样本方差的分解—Hogg 9.2.4 设 $X_1, X_2, \dots, X_n$ 是来自正态分布 $N(\mu, \sigma^2)$ 的随机样本。证明

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=2}^n (X_i - \bar{X}')^2 + \frac{n-1}{n} (X_1 - \bar{X}')^2,$$

其中 $\bar{X} = \sum_{i=1}^n X_i/n$ 且 $\bar{X}' = \sum_{i=2}^n X_i/(n-1)$ 。

提示: 将 $X_i - \bar{X}$ 替换为 $(X_i - \bar{X}') - (X_1 - \bar{X}')/n$ 。证明 $\sum_{i=2}^n (X_i - \bar{X}')^2/\sigma^2$ 服从自由度为 $n-2$ 的卡方分布。证明右边两项独立。下列统计量的分布是什么?

$$\frac{[(n-1)/n](X_1 - \bar{X}')^2}{\sigma^2}?$$

EXERCISE 9.5. ?? MLE 与平方和分解—Hogg 9.2.5 使用本节的记号, 假设均值满足条件 $\mu = \mu_1 + (b-1)d = \mu_2 - d = \mu_3 - d = \dots = \mu_b - d$ 。即最后 $b-1$ 个均值相等但与

第一个均值 μ_1 不同 (假设 $d \neq 0$)。从 b 个具有公共未知方差 σ^2 的正态分布中分别抽取容量为 a 的独立随机样本。

(a) 证明 μ 和 d 的最大似然估计量分别是 $\hat{\mu} = \bar{X}_{..}$ 和

$$\hat{d} = \frac{\sum_{j=2}^b \bar{X}_{.j}/(b-1) - \bar{X}_{.1}}{b}.$$

(b) 使用练习 9.2.4, 求 Q_6 和 $Q_7 = c\hat{d}^2$, 使得当 $d = 0$ 时, $Q_7/\sigma^2 \sim \chi^2(1)$, 且

$$\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{..})^2 = Q_3 + Q_6 + Q_7.$$

(c) 论证当 $d = 0$ 时, 右边的三项除以 σ^2 后是相互独立的卡方分布随机变量。

(d) $Q_7/(Q_3 + Q_6)$ 乘以什么常数在 $d = 0$ 时服从 F 分布? 注意, 这个 F 实际上就是用于检验第一个分布的均值与后 $b - 1$ 个分布合并后的公共均值相等的双样本 T 的平方。

EXERCISE 9.6. ?? LDL 胆固醇水平 ANOVA 分析—Hogg 9.2.6 一项研究比较了四种药物对 LDL (低密度脂蛋白) 胆固醇水平的影响。数据记录在文件 `quailldl.rda` 中。

(a) 绘制 LDL 水平的比较箱线图。哪种药物似乎导致更低的 LDL 水平? 识别数据中的异常值 (按观测号)。

(b) 计算所有四种药物的 LDL 均值相等的 F 检验。报告 F 检验统计量和 p 值。使用显著性水平 0.05 就问题给出结论。使用例 9.2.1 中的 R 代码。

(c) (b) 中的结论与 (a) 中的箱线图一致吗?

(d) 注意, F 检验的一个假设是模型 (9.2.1) 中的随机误差 e_{ij} 服从正态分布。 e_{ij} 的估计量是 $x_{ij} - \bar{x}_{.j}$, 这些称为残差, 即全模型拟合后剩余的部分。计算这些残差, 然后获取它们的直方图、箱线图和正态 $Q-Q$ 图。评价正态性假设。

EXERCISE 9.7. ?? One-Way ANOVA 假设检验—Hogg 9.2.7 设 μ_1, μ_2, μ_3 分别为三个正态分布的均值, 它们具有公共未知方差 σ^2 。为在显著性水平 $\alpha = 0.05$ 下检验假设 $H_0: \mu_1 = \mu_2 = \mu_3$ 对所有可能备择假设, 从每个分布中抽取容量为 4 的独立随机样本。若观测值分别为:

$$X_1: \quad 5 \quad 9 \quad 6 \quad 8$$

$$X_2: \quad 11 \quad 13 \quad 10 \quad 12$$

$$X_3: \quad 10 \quad 6 \quad 9 \quad 9$$

判断是否拒绝 H_0 。

EXERCISE 9.8. ?? 柴油燃料品牌 mpg 比较-Hogg 9.2.8 一位柴油汽车司机根据 mpg 测试三种柴油燃料的质量。使用以下数据检验三个均值相等的原假设。做通常的假设并取 $\alpha = 0.05$ 。

Brand A: 38.7 39.2 40.1 38.9

Brand B: 41.9 42.3 41.3

Brand C: 40.8 41.2 39.5 38.9 40.3

EXERCISE 9.9. ?? 非中心 χ^2 分布的可加性-Hogg 9.3.1 设 $Y_i, i = 1, 2, \dots, n$, 是相互独立的随机变量, 分别服从 $\chi^2(r_i, \theta_i), i = 1, 2, \dots, n$ 。证明 $Z = \sum_{i=1}^n Y_i$ 服从 $\chi^2(\sum_{i=1}^n r_i, \sum_{i=1}^n \theta_i)$ 。

EXERCISE 9.10. ?? 非中心 χ^2 分布的方差-Hogg 9.3.2 计算服从非中心 $\chi^2(r, \theta)$ 分布的随机变量的方差。

EXERCISE 9.11. ?? 非中心性参数的计算与检验功效-Hogg 9.3.3 考虑 one-way ANOVA 问题, 其中各组样本容量相等 ($n_j = m, j = 1, \dots, b$), 且各组均值满足模式: $\mu_1 = \mu + 2d, \mu_2 = \mu_3 = \dots = \mu_b = \mu - d$ 。

(a) 确定上述均值模式下的非中心性参数。¹

(b) 使用 R 函数 `pf` 确定 F 检验在 $m = 5$ 和 $m = 10$ 时检测该均值模式的功效。²

(c) 确定检测功效至少为 0.80 的最小 m 值。³

(d) 如果 $\sigma^2 = 40$, 回答 (a)-(c)。

EXERCISE 9.12. ?? 非中心 T 与非中心 F 的关系-Hogg 9.3.4 证明非中心 T 随机变量的平方是非中心 F 随机变量。

EXERCISE 9.13. ?? 非中心 χ^2 分布的差-Hogg 9.3.5 设 X_1 和 X_2 是两个独立的随机变量。设 $X_1 \sim \chi^2(r_1, \theta_1), Y = X_1 + X_2 \sim \chi^2(r, \theta)$, 其中 $r_1 < r$ 且 $\theta_1 \leq \theta$ 。证明 $X_2 \sim \chi^2(r - r_1, \theta - \theta_1)$ 。

EXERCISE 9.14. ?? Bonferroni 多重比较程序-Hogg 9.4.1 对于练习 9.2.8 中讨论的研究, 使用 $\alpha = 0.10$ 获取 Bonferroni 多重比较程序的结果。基于此程序, 哪个品牌的燃料 (如果有的话) 显著最好?

EXERCISE 9.15. ?? Tukey-Kramer 程序-Hogg 9.4.2 对于练习 9.2.6 中讨论的研究, 计算 Tukey-Kramer 程序。是否存在显著差异?

EXERCISE 9.16. ?? Bonferroni 与 Fisher 多重比较方法-Hogg 9.4.3 假设 X 和 Y 是离散随机变量, 它们具有共同的范围 $\{1, 2, \dots, k\}$ 。设 p_{1j} 和 p_{2j} 分别是 $P(X = j)$ 和 $P(Y = j)$ 的相应概率。

(a) 确定执行所有这些比较的 Bonferroni 方法。

(b) 确定执行所有这些比较的 Fisher 方法。

¹答案: $\theta = 5md/3$, 当 $\sigma^2 = 1$ 。

²答案: 对于 $m = 5$: 功效 = 0.6174; 对于 $m = 10$: 功效 = 0.9421。

³答案: $m = 7$ 。

EXERCISE 9.17. ?? 列联表的多重比较-Hogg 9.4.4 假设练习 9.4.3 中的样本产生了以下列联表:

	1	2	3	4	5	6	7	8	9	10
x	20	31	56	18	45	55	47	78	56	81
y	36	41	65	15	38	78	18	72	59	85

为计算 (用 R) 下面的置信区间, 使用命令 `prop.test` (见例 4.2.5)。

(a) 基于所有 10 个比较的 Bonferroni 程序, 计算 $p_{16} - p_{26}$ 的置信区间。

(b) 基于所有 10 个比较的 Fisher 程序, 计算 $p_{16} - p_{26}$ 的置信区间。

EXERCISE 9.18. ?? Fisher 程序的 R 函数-Hogg 9.4.5 编写一个 R 函数, 计算练习 9.4.3 中的 Fisher 程序。用练习 9.4.4 的数据验证它。

EXERCISE 9.19. ?? 同时检验的 Bonferroni 程序推广-Hogg 9.4.6 将 Bonferroni 程序推广到同时检验。即, 假设我们有 m 个感兴趣的假设: H_{0i} 对 H_{1i} , $i = 1, \dots, m$ 。对于检验 H_{0i} 对 H_{1i} , 设 $C_{i,\alpha}$ 是大小为 α 的临界域, 并假设如果样本 $\mathbf{X}_i \in C_{i,\alpha}$, 则拒绝 H_{0i} 。确定一个规则, 使我们能够同时检验这 m 个假设, 且第一类错误率不超过 α 。

EXERCISE 9.20. ?? 两因素可加模型平方和分解-Hogg 9.5.1 考虑一个双因素实验, 其中因素 A 有 2 个水平, 因素 B 有 3 个水平。设 $\mu = 5$, $\alpha_1 = 1$, $\alpha_2 = -1$, $\beta_1 = 1$, $\beta_2 = 0$, $\beta_3 = -1$ 。回答以下问题:

(a) 写出单元格均值 μ_{ij} 的表格。

(b) 绘制均值轮廓图 (mean profile plot)。

(c) 若交互效应存在, 轮廓图会有什么特征?

EXERCISE 9.21. ?? MLE 的分布-Hogg 9.5.2 考虑表达式 (9.5.14) 之前的讨论。证明随机变量 $\sqrt{a}\bar{X}_{.1}, \dots, \sqrt{a}\bar{X}_{.b}$ 是相互独立的, 且服从公共的 $N(\sqrt{a}\bar{\mu}, \sigma^2)$ 分布。

EXERCISE 9.22. ?? 交互效应的非中心性参数-Hogg 9.5.3 对于双因素交互模型 (9.5.15), 证明检验统计量 F_{AB} 的非中心性参数等于 $c \sum_{j=1}^b \sum_{i=1}^a \gamma_{ij}^2 / \sigma^2$ 。

EXERCISE 9.23. ?? 单观测值单元的 MLE 分布-Hogg 9.5.4 使用双因素分类 (每单元一观测值) 的背景, 确定 α_i 、 β_j 和 μ 的最大似然估计量的分布。

EXERCISE 9.24. ?? 线性函数的不相关性-Hogg 9.5.5 证明在线性函数 $X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..}$ 与 $\bar{X}_{.j} - \bar{X}_{..}$ 在本节的假设下是不相关的。

EXERCISE 9.25. ?? 双因素分类的 F 检验计算-Hogg 9.5.6 给定以下与双因素分类相关的观测值, 其中 $a = 3$, $b = 4$, 使用 R 或其他统计软件计算用于检验列均值相等 ($\beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$) 和行均值相等 ($\alpha_1 = \alpha_2 = \alpha_3 = 0$) 的 F 统计量。

行/列	1	2	3	4
1	3.1	4.2	2.7	4.9
2	2.7	2.9	1.8	3.0
3	4.0	4.6	3.0	3.9

EXERCISE 9.26. ?? 多观测值单元的 MLE 分布-Hogg 9.5.7 在每单元有 $c > 1$ 个观测值的双因素分类背景下, 确定 α_i 、 β_j 和 γ_{ij} 的最大似然估计量的分布。

EXERCISE 9.27. ?? 含交互效应的双因素分类 F 检验-Hogg 9.5.8 给定以下在双因素分类中的观测值, 其中 $a = 3$, $b = 4$, $c = 2$, 计算用于检验所有交互效应为零 ($\gamma_{ij} = 0$)、所有列均值相等 ($\beta_j = 0$) 和所有行均值相等 ($\alpha_i = 0$) 的 F 统计量。数据形式为 x_{ijk} , i, j 在数据集 *sec951.rda* 中。

行/列	1	2	3	4
1	3.1	4.2	2.7	4.9
	2.9	4.9	3.2	4.5
2	2.7	2.9	1.8	3.0
	2.9	2.3	2.4	3.7
3	4.0	4.6	3.0	3.9
	4.4	5.0	2.5	4.2

EXERCISE 9.28. ?? 可加模型的均值轮廓图-Hogg 9.5.9 对于可加模型 (9.5.1), 证明均值轮廓图是平行的。样本均值轮廓图通过绘制 $\bar{X}_{ij}$ 对 j (对每个 i) 得到。这些提供了检测交互效应的图形诊断。为上一道练习获取这些图。

EXERCISE 9.29. ?? 随机区组设计的双因素 ANOVA-Hogg 9.5.10 考虑一个随机区组设计, 其中处理 (A) 有 3 个水平, 区组 (B) 有 5 个水平。数据如下:

处理	区组				
	B1	B2	B3	B4	B5
A1	52	47	44	51	42
A2	60	55	49	52	43
A3	56	48	45	44	38

(a) 使用 5% 的显著性水平, 检验 $H_A: \alpha_1 = \alpha_2 = \alpha_3 = 0$ 对所有备择假设。

(b) 使用 5% 的显著性水平, 检验 $H_B: \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$ 对所有备择假设。

EXERCISE 9.30. ?? 双因素模型参数分解-Hogg 9.5.11 设 $a = 3$ 、 $b = 4$, 如果 μ_{ij} ($i = 1, 2, 3$ 和 $j = 1, 2, 3, 4$) 由下表给出, 求 μ 、 α_i 、 β_j 和 γ_{ij} :

6	7	7	12
10	3	11	8
8	5	9	10

EXERCISE 9.31. ?? 回归系数 α^* 的最小二乘估计-Hogg 9.6.1 通过最小化表达式 (9.6.11) 给出的平方和, 得到模型 $y_i = \alpha^* + \beta x_i + e_i$ 的最小二乘估计。确定 $\hat{\alpha}^*$ 的分布。

EXERCISE 9.32. ?? ACT 与微积分成绩的回归分析-Hogg 9.6.2 学生在 ACT 数学考试中的成绩 x 和第一学期微积分期末考试 (满分 200 分) 的成绩 y 如下:

x	25	20	26	26	28	28	29	32	20	25
y	138	84	104	112	88	132	90	183	100	143
x	26	28	25	31	30					
y	141	161	124	118	168					

数据也在 *rda* 文件 *regr1.rda* 中。使用 *R* 或其他统计软件进行计算和绘图。

- 计算这些数据的最小二乘回归线。
- 在同一图上绘制散点和最小二乘回归线。
- 获取残差图并评价模型的适用性。
- 求 β 的 95% 置信区间。就问题给出评论。

EXERCISE 9.33. ?? 电话数据回归分析-Hogg 9.6.3 考虑以下数据。该数据集的响应变量 y 是 1950 年至 1973 年比利时电话通话次数 (单位: 千万次)。时间 (年份) 作为预测变量 x 。数据在文件 *telephone.rda* 中。

- 计算这些数据的最小二乘回归线。
- 在同一图上绘制散点和最小二乘回归线。
- 最小二乘拟合效果差的原因是什么?

EXERCISE 9.34. ?? 回归估计量的协方差-Hogg 9.6.4 证明 $\hat{\alpha}$ 与 $\hat{\beta}$ 之间的协方差为零。

提示: 利用 (??) 中 $\hat{\beta}$ 的表达式, 以及 $\sum_{i=1}^n (x_i - \bar{x}) = 0$ 的性质。

EXERCISE 9.35. ?? 回归参数的置信区间-Hogg 9.6.5 在模型 (??) 下, 求参数 α 和 β 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.36. ?? 均值估计量的分布与置信区间-Hogg 9.6.6 考虑模型 (9.6.1)。设 $\eta_0 = E(Y|x = x_0 - \bar{x})$ 。 η_0 的最小二乘估计量是 $\hat{\eta}_0 = \hat{\alpha} + \hat{\beta}(x_0 - \bar{x})$ 。

- 使用 (9.6.9), 证明 $\hat{\eta}_0$ 是无偏估计量, 并证明其方差为

$$V(\hat{\eta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

- 获取 $\hat{\eta}_0$ 的分布, 并用它来确定 η_0 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.37. ?? 预测区间-Hogg 9.6.7 假设样本 $(x_1, Y_1), \dots, (x_n, Y_n)$ 服从线性模型 (9.6.1)。设 Y_0 是在 $x = x_0 - \bar{x}$ 处的一个未来观测值, 我们想为其确定一个预测区间。假设模型 (9.6.1) 对 Y_0 成立; 即 $Y_0 \sim N(\alpha + \beta(x_0 - \bar{x}), \sigma^2)$ 。我们使用练习 9.6.6 中的 $\hat{\eta}_0$ 作为对 Y_0 的预测。

- 获取 $Y_0 - \hat{\eta}_0$ 的分布, 证明其方差为:

$$V(Y_0 - \hat{\eta}_0) = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

- 获取以 $Y_0 - \hat{\eta}_0$ 为分子的 t 统计量。

(c) 现在从 $1 - \alpha = P[-t_{\alpha/2, n-2} < T < t_{\alpha/2, n-2}]$ 开始, 其中 $0 < \alpha < 1$, 确定 Y_0 的 $(1 - \alpha)100\%$ 预测区间。

(d) 将此预测区间与练习 9.6.6 获得的置信区间进行比较。为什么预测区间更大？从直觉上解释。

EXERCISE 9.38. ?? 奥运会 1500 米成绩的预测区间—Hogg 9.6.8 在例 9.6.1 中，我们得到了 2020 年奥运会男子 1500 米冠军成绩的预测。计算上一道练习中给出的该预测的 95% 预测区间。这些计算由 R 函数 `cipi.R` 执行。调用方式是 `cipi(lm(time~year), matrix(c(1,2020), ncol=2))`。就问题而言，这个预测区间意味着什么？接下来计算 2024 年和 2028 年奥运会的预测。为什么区间长度在增加？

EXERCISE 9.39. ?? 回归平方和分解—Hogg 9.6.9 证明以下等式成立：

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

提示：这本质上是将总平方和分解为拟合平方和与残差平方和。

EXERCISE 9.40. ?? 简单最小二乘拟合—Hogg 9.6.14 使用最小二乘法拟合 $y = a + x$ 到以下数据：

$$\begin{array}{r} x \quad 0 \quad 1 \\ 2 \\ \hline y \quad 1 \quad 3 \\ 4 \end{array}$$

EXERCISE 9.41. ?? 异方差回归模型的 MLE—Hogg 9.6.10 设独立随机变量 $Y_1, Y_2, \dots, Y_n$ 分别具有概率密度函数 $N(\beta x_i, \gamma^2 x_i^2)$, $i = 1, 2, \dots, n$ ，其中给定的数 $x_1, x_2, \dots, x_n$ 不全相等且均不为零。求 β 和 γ^2 的最大似然估计量。

EXERCISE 9.42. ?? 似然比检验与回归—Hogg 9.6.11 设独立随机变量 $Y_1, \dots, Y_n$ 具有联合 pdf

$$L(\alpha, \beta, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - \alpha - \beta(x_i - \bar{x})]^2 \right\},$$

其中给定的数 $x_1, x_2, \dots, x_n$ 不全相等。设原假设 $H_0: \beta = 0$ (α 和 σ^2 未指定)。希望使用似然比检验来检验 H_0 对所有备择假设。求 Λ ，并看看检验是否能基于一个熟悉的统计量。

提示：在本节的记号下，证明

$$\sum_{i=1}^n (Y_i - \hat{\alpha})^2 = Q_3 + \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2.$$

EXERCISE 9.43. ?? 线性趋势 ANOVA—Hogg 9.6.12 使用第 9.2 节的记号，假设均值满足 j 的线性函数： $\mu_j = c + d[j - (b+1)/2]$ 。从 b 个均值分别为 $\mu_1, \mu_2, \dots, \mu_b$ 、公共未知方差为 σ^2 的正态分布中分别抽取容量为 a 的独立随机样本。

(a) 证明 c 和 d 的最大似然估计量分别为 $\hat{c} = \bar{X}_{..}$ 和

$$\hat{d} = \frac{\sum_{j=1}^b [j - (b-1)/2](\bar{X}_{.j} - \bar{X}_{..})}{\sum_{j=1}^b [j - (b+1)/2]^2}.$$

(b) 类似于练习 9.2.5, 求平方和分解。

(c) 论证当 $d = 0$ 时, (b) 中右边的两项除以 σ^2 后是自由度分别为 1 和 $ab - 2$ 的独立卡方分布随机变量。

(d) 什么 F 统计量用于检验均值的相等性, 即 $H_0: d = 0$?

EXERCISE 9.44. ?? 最小二乘估计的几何-Hogg 9.6.13 考虑第 9.6.2 节的讨论。

(a) 证明 $\hat{\boldsymbol{\theta}} = \hat{\alpha}\mathbf{1} + \hat{\beta}\mathbf{x}_c$, 其中 $\hat{\alpha}$ 和 $\hat{\beta}$ 是本节导出的最小二乘估计量。

(b) 证明残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$; 即它的第 i 个元素是 $\hat{e}_i$, (9.6.7)。

(c) 如图 9.6.3 所示, 证明向量 $\hat{\boldsymbol{\theta}}$ 和 $\hat{\mathbf{e}}$ 之间的夹角是直角。

(d) 证明残差之和为零; 即 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 。

EXERCISE 9.45. ?? 平面拟合-Hogg 9.6.15 用最小二乘法拟合平面 $z = a + bx + cy$ 到五个点 $(x, y, z): (-1, -2, 5), (0, -2, 4), (0, 0, 4), (1, 0, 2), (2, 1, 0)$ 。

令 R 向量 $\mathbf{x}$ 、 $\mathbf{y}$ 、 $\mathbf{z}$ 包含 x 、 y 和 z 的值。则 LS 拟合通过 $\text{lm}(\mathbf{z} \sim \mathbf{x} + \mathbf{y})$ 计算。

EXERCISE 9.46. ?? 多元正态回归估计-Hogg 9.6.16 设 4×1 矩阵 $\mathbf{Y}$ 服从多元正态分布 $N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$, 其中 4×3 矩阵 $\mathbf{X}$ 等于

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 2 \\ 1 & -1 & 2 \\ 1 & 0 & -3 \\ 1 & 0 & -1 \end{pmatrix}.$$

(a) 求 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 的均值矩阵和协方差矩阵。

(b) 如果我们观测到 $\mathbf{Y}' = (6, 1, 11, 3)$, 计算 $\hat{\boldsymbol{\beta}}$ 。

EXERCISE 9.47. ?? 多元正态回归的 pdf-Hogg 9.6.17 设 $\mathbf{Y}$ 是 $n \times 1$ 随机向量, $\mathbf{X}$ 是 $n \times p$ 已知常数矩阵 (秩为 p), $\boldsymbol{\beta}$ 是 $p \times 1$ 回归系数向量。设 $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$ 。求 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 的 pdf。

EXERCISE 9.48. ?? 异方差检验-Hogg 9.6.18 设独立正态随机变量 $Y_1, Y_2, \dots, Y_n$ 分别具有概率密度函数 $N(\mu, \gamma^2 x_i^2)$, $i = 1, 2, \dots, n$, 其中给定的 $x_1, x_2, \dots, x_n$ 不全相等且均不为零。讨论在未指定 μ 的情况下, 检验原假设 $H_0: \gamma = 1$ 对所有备择假设 $H_1: \gamma \neq 1$ 。

EXERCISE 9.49. ?? 相关系数表达式的化简-Hogg 9.7.1 证明

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{(\sum_{i=1}^n X_i^2 - n\bar{X}^2)(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2)}}.$$

EXERCISE 9.50. ?? 相关系数的假设检验-Hogg 9.7.2 从二元正态分布中抽取容量为 $n = 6$ 的随机样本, 得到相关系数为 0.89 。在 5% 的显著性水平下, 我们是接受还是拒绝 $\rho = 0$ 的假设?

EXERCISE 9.51. ?? 验证相关系数的 t 分布-Hogg 9.7.3 验证本节的等式 (9.7.3)。

EXERCISE 9.52. ?? 验证相关系数的分布-Hogg 9.7.4 验证本节的 (9.7.4) 中的 pdf。

EXERCISE 9.53. ?? 相关系数的一致性-Hogg 9.7.5 使用第 4.5 节的结果, 证明 R , (9.7.1), 是 ρ 的一致估计量。

EXERCISE 9.54. ?? 相关系数的置信区间-Hogg 9.7.6 通过执行以下步骤, 确定 ρ 的 $(1 - \alpha)100\%$ 近似置信区间。

(a) 对于 $0 < \alpha < 1$, 通常从 $1 - \alpha = P(-z_{\alpha/2} < Z < z_{\alpha/2})$ 开始, 其中 Z 由表达式 (9.7.5) 给出。然后在不等式的中间部分孤立 $h(\rho) = (1/2) \log[(1 + \rho)/(1 - \rho)]$ 。求 $h'(\rho)$ 并证明它在 $-1 < \rho < 1$ 上严格为正; 因此 h 是严格递增的, 其逆函数存在。

(b) 证明这个逆函数是双曲正切函数, $\tanh(y) = (e^y - e^{-y})/(e^y + e^{-y})$ 。

(c) 获取 ρ 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.55. ?? 棒球数据的相关系数分析-Hogg 9.7.7 R 函数 `cor.test(x, y)` 计算 ρ 的估计量和练习 9.7.6 中的置信区间。回忆棒球数据, 它在文件 `bb.rda` 中。

(a) 使用棒球数据, 确定职业棒球运动员身高与体重之间相关系数的估计值和置信区间。

(b) 将投手和击球手分开, 分别获取身高与体重之间相关系数的估计值和置信区间。它们有显著差异吗?

(c) 论证第二部分中相关系数估计值的差异是关于两个独立样本的 $\rho_1 - \rho_2$ 的一个模型。

EXERCISE 9.56. ?? 组合样本的相关系数-Hogg 9.7.8 两个实验给出以下结果:

n	$\bar{x}$	$\bar{y}$	s_x	s_y	r
100	10	20	5	8	0.70
200	12	22	6	10	0.80

计算组合样本的 r 。

EXERCISE 9.57. ?? 二次型与卡方分布-Hogg 9.8.1 设 $Q = X_1X_2 - X_3X_4$, 其中 X_1, X_2, X_3, X_4 是来自 $N(0, \sigma^2)$ 分布的容量为 4 的随机样本。证明 Q/σ^2 不服从卡方分布。求 Q/σ^2 的 mgf。

EXERCISE 9.58. ?? 二次型的非中心卡方分布-Hogg 9.8.2 设 $\mathbf{X}' = [X_1, X_2]$ 服从二元正态分布, 均值矩阵 $\boldsymbol{\mu}' = [\mu_1, \mu_2]$ 和正定协方差矩阵 Σ 。设

$$Q_1 = \frac{X_1^2}{\sigma_1^2(1 - \rho^2)} - 2\rho \frac{X_1X_2}{\sigma_1\sigma_2(1 - \rho^2)} + \frac{X_2^2}{\sigma_2^2(1 - \rho^2)}.$$

证明 $Q_1 \sim \chi^2(r, \theta)$, 并求 r 和 θ 。 Q_1 何时且仅何时服从中心卡方分布?

EXERCISE 9.59. ?? 非中心卡方分布的计算-Hogg 9.8.3 设 $\mathbf{X}' = [X_1, X_2, X_3]$ 是来自 $N(4, 8)$ 分布的容量为 3 的随机样本, 并设

$$\mathbf{A} = \begin{pmatrix} \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 1 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} \end{pmatrix}.$$

设 $Q = \mathbf{X}'\mathbf{A}\mathbf{X}/\sigma^2$ 。

(a) 使用定理 9.8.1 求 $E(Q)$ 。

(b) 说明为什么断言 $Q \sim \chi^2(2, 6)$ 成立。

EXERCISE 9.60. ?? 不等方差的样本均值方差-Hogg 9.8.4 假设 $X_1, \dots, X_n$ 是独立随机变量, 有公共均值 μ 但有不等方差 $\sigma_i^2 = \text{var}(X_i)$ 。

(a) 确定 $\bar{X}$ 的方差。

(b) 确定常数 K , 使得 $Q = K \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\bar{X}$ 方差的无偏估计量。(提示: 按例 9.8.3 中的方法进行。)

EXERCISE 9.61. ?? 相关变量的样本均值方差-Hogg 9.8.5 假设 $X_1, \dots, X_n$ 是相关随机变量, 有公共均值 μ 和方差 σ^2 但相关系数 ρ (所有相关系数相同)。

(a) 确定 $\bar{X}$ 的方差。

(b) 确定常数 K , 使得 $Q = K \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\bar{X}$ 方差的无偏估计量。(提示: 按例 9.8.3 中的方法进行。)

EXERCISE 9.62. ?? 验证表达式 (9.8.13) -Hogg 9.8.6 补充表达式 (9.8.13) 的细节。

EXERCISE 9.63. ?? 迹算子的性质-Hogg 9.8.7 证明表达式 (9.8.1) 中定义的迹算子具有以下性质。

(a) 如果 $\mathbf{A}$ 和 $\mathbf{B}$ 是 $n \times n$ 矩阵, a 和 b 是标量, 则

$$\text{tr}(a\mathbf{A} + b\mathbf{B}) = a \text{tr} \mathbf{A} + b \text{tr} \mathbf{B}.$$

(b) 对于任何 $n \times n$ 矩阵 $\mathbf{A}$ 和 $\mathbf{B}$, $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ 。

(c) 如果 $\mathbf{A}$ 是方阵, Γ 是正交矩阵, 利用 (a) 的结果证明 $\text{tr}(\Gamma'\mathbf{A}\Gamma) = \text{tr} \mathbf{A}$ 。

(d) 如果 $\mathbf{A}$ 是实对称幂等矩阵, 利用 (b) 的结果证明 $\mathbf{A}$ 的秩等于 $\text{tr} \mathbf{A}$ 。

EXERCISE 9.64. ?? 矩阵元素平方和与特征值-Hogg 9.8.8 设 $\mathbf{A} = [a_{ij}]$ 是实对称矩阵。证明 $\sum_i \sum_j a_{ij}^2$ 等于 $\mathbf{A}$ 的特征值的平方和。

提示: 如果 Γ 是正交矩阵, 证明 $\sum_j \sum_i a_{ij}^2 = \text{tr}(\mathbf{A}^2) = \text{tr}(\Gamma'\mathbf{A}^2\Gamma) = \text{tr}[(\Gamma'\mathbf{A}\Gamma)(\Gamma'\mathbf{A}\Gamma)]$ 。

EXERCISE 9.65. ?? 非中心卡方分布的判定-Hogg 9.8.9 假设 $\mathbf{X} \sim N_n(0, \Sigma)$, 其中 Σ 是正定矩阵。对于对称矩阵 $\mathbf{A}$, 设 $Q = \mathbf{X}'\mathbf{A}\mathbf{X}$ 。证明当且仅当 $\mathbf{A}\Sigma\mathbf{A} = \mathbf{A}$ 时, $Q \sim \chi^2(r)$, 其中 $r = \text{rank}(\mathbf{A})$ 。

提示: 将 Q 写成

$$Q = (\Sigma^{-1/2} \mathbf{X})' \Sigma^{1/2} \mathbf{A} \Sigma^{1/2} (\Sigma^{-1/2} \mathbf{X}),$$

其中 $\Sigma^{1/2} = \Gamma' \Lambda^{1/2} \Gamma$, $\Sigma = \Gamma' \Lambda \Gamma$ 是 Σ 的谱分解。然后使用定理 9.8.4。

EXERCISE 9.66. ?? 幂等矩阵的特征值-Hogg 9.8.10 假设 $\mathbf{A}$ 是实对称矩阵。如果 $\mathbf{A}$ 的特征值只有 0 和 1, 证明 $\mathbf{A}$ 是幂等的。

EXERCISE 9.67. ?? 二次型的独立性判定-Hogg 9.9.1 设 X_1, X_2, X_3 是来自正态分布 $N(0, \sigma^2)$ 的随机样本。二次型 $X_1^2 + 3X_1X_2 + X_2^2 + X_1X_3 + X_3^2$ 和 $X_1^2 - 2X_1X_2 + \frac{2}{3}X_2^2 - 2X_1X_3 - X_3^2$ 是独立还是相关?

EXERCISE 9.68. ?? 平方和与二次型的相关性-Hogg 9.9.2 设 $X_1, X_2, \dots, X_n$ 表示来自 $N(0, \sigma^2)$ 分布的容量为 n 的随机样本。证明 $\sum_{i=1}^n X_i^2$ 与每一个在 $X_1, X_2, \dots, X_n$ 中非恒为零的二次型都是相关的。

EXERCISE 9.69. ?? 线性函数与二次型的独立性-Hogg 9.9.3 设 X_1, X_2, X_3, X_4 是来自 $N(0, \sigma^2)$ 分布的容量为 4 的随机样本。设 $Y = \sum_{i=1}^4 a_i X_i$, 其中 a_1, a_2, a_3, a_4 是实常数。如果 Y^2 和 $Q = X_1X_2 - X_3X_4$ 独立, 确定 a_1, a_2, a_3, a_4 。

附录：公式推导

One-Way ANOVA 平方和恒等式的证明. 背景: 在 one-way ANOVA 中, 总平方和 Q 可以分解为组内平方和 Q_3 与组间平方和 Q_4 之和。这一恒等式是 F 检验的基石。

目标: 证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2.$$

推导: 记 $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和:

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零, 因为对每个固定的 j ,

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。

□

One-Way ANOVA 检验统计量的分布. 背景: 推导 one-way ANOVA 中 F 统计量在原假设下的分布。

目标: 证明在 H_0 下, $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导:

步骤 1: Q_3 的分布. 对每个固定的 j , 由样本方差性质, $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立, 故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2\left(\sum_{j=1}^b (n_j - 1)\right) = \chi^2(n-b).$$

步骤 2: Q_4 与 Q_3 的独立性. 注意 $\bar{X}_{.j}$ 与 Q_3 独立 (由正态样本的性质), 且 $\bar{X}_{..}$ 是 $\bar{X}_{.1}, \dots, \bar{X}_{.b}$ 的线性组合, 因此 $\bar{X}_{..}$ 也与 Q_3 独立。故 Q_4 ($\bar{X}_{.j}$ 的函数) 与 Q_3 独立。

步骤 3: Q_4 的分布. 在 H_0 下, $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$, 故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各 $\bar{X}_{.j}$ 通过 $\bar{X}_{..}$ 而不独立。直接计算知 $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

步骤 4: F 分布. 由步骤 1、2、3 及 F 分布定义,

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b).$$

□

非中心 χ^2 分布的均值和方差. 背景: 验证非中心 χ^2 分布的基本性质。

已知: $Y \sim \chi^2(r, \theta)$, mgf 为 $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。

目标: 求 $\mathbb{E}(Y)$ 和 $\text{var}(Y)$ 。

推导:

由 mgf, $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。对 $M(t)$ 求导:

$$M'(t) = \left[r(1-2t)^{-r/2-1} + \frac{r\theta}{(1-2t)^{r/2+1}} \right] \exp\left\{ \frac{t\theta}{1-2t} \right\}.$$

故 $\mathbb{E}(Y) = M'(0) = r + \theta$ 。

对 $M''(t)$ 在 $t=0$ 求值, 可得 $\text{var}(Y) = 2(r + 2\theta)$ 。⁴

最小二乘估计的几何解释. 背景: 回归最小二乘估计的正交投影几何。

目标: 证明 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是 $\mathbf{Y}$ 在 $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$ 上的正交投影。

推导: 由正交投影的定义, $\hat{\boldsymbol{\theta}}$ 满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}_c$ 都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0.$$

由 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 得 $\sum_i \hat{e}_i = 0$ (残差之和为零)。

⁴该推导的详细计算见附录 ??。

由 $\mathbf{x}'_e \hat{\mathbf{e}} = 0$ 并利用正规方程，可解出 $\hat{\alpha}$ 和 $\hat{\beta}$ 的表达式与 (??)、(??) 一致。故 $\hat{\boldsymbol{\theta}}$ 确为正交投影。 $\square$

0.1. Gamma 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given):

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal): 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换: 令 $y = \frac{x(1-\beta t)}{\beta}$, 则 $x = \frac{\beta y}{1-\beta t}$, $dx = \frac{\beta}{1-\beta t} dy$ 。
3. 代入积分 (要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$):

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论: 因此, $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$, 定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background): 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$, 方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given):

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1-0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha+1)\beta^2(1-0)^{-\alpha-2} = \alpha(\alpha+1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha+1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.6. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1], X_2 \in [x_2, x_2 + dx_2]\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证：边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$ ，确实是合法的 pdf。

结论：条件 pdf 公式得证。■

0.7. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发：

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望（即关于 X_1 求平均）：

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序：

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$ ：

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论：全期望公式得证。■

0.8. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解：

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance)：

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项：

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此：

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论：条件均值的方差不超过原变量的方差，等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0（即 X_2 可由 X_1 确定性决定）。■

0.9. 独立性判定的推导. 背景 (Background)：我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ （可分离变量）。

目标 (Goal)：证明这一判定条件。

推导步骤 (Derivation Steps)：

($\Rightarrow$) 若 X_1 与 X_2 独立，则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$ ，显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ ：

1. 由边缘密度定义：

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理：

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$ ，得 $c_1 c_2 = 1$ 。

4. 因此：

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论：故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.10. 相关系数范围的推导. 背景 (Background)：我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal)：证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps)：

1. Cauchy-Schwarz 不等式：对任意随机变量 U, V ，

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差，令 $U = X_1 - \mu_1$ ， $V = X_2 - \mu_2$ ：

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方：

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此：

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论：故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ （完美线性关系）。■

0.11. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.12. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.13. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.14. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.15. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.16. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。
2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.17. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。
2. 则 $X = \sum_{j=1}^n I_j$ 。
3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.18. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1) \cdots (n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} \rightarrow 1, \\ \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.19. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数:

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论: Poisson 分布的均值和方差相等, 都等于参数 λ 。■

0.20. 卡方分布与正态分布的关系. 背景 (Background): 卡方分布定义为标准正态平方和。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, 则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps):

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$, 先求 cdf:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式:

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论: 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.21. 卡方分布的可加性证明. 背景 (Background): 卡方分布满足可加性: 独立卡方变量之和仍为卡方分布。

目标 (Goal): 证明若 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立, 则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps):

1. 由卡方分布与 Gamma 分布的关系: $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性 (见定理 3.3.1): 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此:

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf: $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$, 故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论: 卡方分布具有可加性, 自由度可累加。■

0.22. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1+X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.23. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.24. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.25. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}[e^{(t/\sigma)X}] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.26. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

0.27. 正态分布有界性的证明. 背景 (Background): 正态分布的尾部概率可以任意小。

目标 (Goal): 证明对任意 $\epsilon > 0$, 存在 η 使得 $\mathbb{P}[|X| > \eta] < \epsilon$ 。

推导步骤 (Derivation Steps):

1. 设 $X \sim N(\mu, \sigma^2)$, 考虑尾部概率 $\mathbb{P}(|X| > \eta)$ 。

2. 利用 Markov 不等式: 对任意 $t > 0$,

$$\mathbb{P}(|X - \mu| > \eta) = \mathbb{P}((X - \mu)^2 > \eta^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{\eta^2} = \frac{\sigma^2}{\eta^2}.$$

3. 由 Chebyshev 不等式可直接得出: 对于任意 $\epsilon > 0$, 取 $\eta > \sigma/\sqrt{\epsilon}$, 则

$$\mathbb{P}(|X - \mu| > \eta) \leq \frac{\sigma^2}{\eta^2} < \epsilon.$$

4. 进一步, 对于标准正态分布 $Z \sim N(0, 1)$, 尾部概率有更精确的界: 由积分不等式

$$\int_\eta^\infty e^{-t^2/2} dt \leq \frac{1}{\eta} e^{-\eta^2/2}, \quad \eta > 0,$$

可得 $\mathbb{P}(|Z| > \eta) \leq \sqrt{\frac{2}{\pi}} \frac{e^{-\eta^2/2}}{\eta}$ 。

5. 因此, 无论使用 Chebyshev 的粗略界还是正态分布的精确界, 均可证明: 对于任意 $\epsilon > 0$, 存在 η 使得 $\mathbb{P}(|X| > \eta) < \epsilon$ 。这说明正态分布的尾部概率可以任意小。

结论: 正态分布的尾部概率可以任意小, 即 $\lim_{\eta \rightarrow \infty} \mathbb{P}(|X| > \eta) = 0$ 。这体现了正态分布的 ** 有界性 ** (tails vanish)。■

0.28. 卡方分布 Δ 方法的详细推导. 背景 (Background): 将 Δ 方法应用于卡方变量的标准差。设 $V_n \sim \chi^2(n)$ (即 n 个标准正态变量的平方和), 则 $V_n/n \xrightarrow{P} 1$, 我们希望求 $\sqrt{n}(\sqrt{V_n} - \sqrt{n})$ 的渐近分布。

参数定义 (Parameter Definitions):

- $V_n \sim \chi^2(n)$: 自由度为 n 的卡方分布
- $v = n$: 卡方分布的均值
- $g(x) = \sqrt{x}$: 平方根变换函数

已知条件 (Given):

- 由大数定律: $V_n/n \xrightarrow{P} 1$
- 由中心极限定理: $\sqrt{n}(V_n/n - 1) \xrightarrow{D} N(0, 2)$
- Δ 方法 (Theorem 5.2.9, Hogg): 若 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 且 $g(x)$ 在 θ 处可导且 $g'(\theta) \neq 0$, 则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

目标 (Goal): 求 $\sqrt{n}(\sqrt{V_n} - \sqrt{n})$ 的渐近分布。

推导步骤 (Derivation Steps):

1. 令 $X_n = V_n/n$, 则 $X_n \xrightarrow{P} 1 = \theta$ 。
2. 计算 $g'(x) = \frac{d}{dx}\sqrt{x} = \frac{1}{2\sqrt{x}}$, 因此 $g'(\theta) = g'(1) = \frac{1}{2}$ 。
3. 验证 Δ 方法条件: - $X_n = V_n/n$ 依概率收敛到 $\theta = 1$ - $g(x) = \sqrt{x}$ 在 $x = 1$ 处可导 - 由 CLT: $\sqrt{n}(X_n - 1) = \frac{1}{\sqrt{n}}(V_n - n) \xrightarrow{D} N(0, 2)$
4. 应用 Δ 方法:

$$\sqrt{n}(g(V_n/n) - g(1)) = \sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) \xrightarrow{D} N\left(0, 2 \cdot \left(\frac{1}{2}\right)^2\right) = N(0, \frac{1}{2}).$$

5. 注意到

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = n \cdot \sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) = n \cdot \sqrt{n}\left(\frac{\sqrt{V_n}}{\sqrt{n}} - 1\right).$$

实际上更直接的方式是: 直接对 $g(V_n) = \sqrt{V_n}$ 在 $v = n$ 处应用 Δ 方法。

6. 设 $Y_n = V_n$, 则 $\sqrt{n}(Y_n - n) \xrightarrow{D} N(0, 2n)$ 。但更好的做法是利用 $V_n/n \xrightarrow{P} 1$: 由步骤 4 的结果, 乘以 $\sqrt{n}$:

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = \sqrt{n} \cdot \sqrt{n} \cdot \left(\sqrt{\frac{V_n}{n}} - 1\right) = n \cdot \sqrt{n} \left(\sqrt{\frac{V_n}{n}} - 1\right).$$

更直接地: 对 $X_n = V_n/n$ 应用 Δ 方法得

$$\sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) \xrightarrow{D} N\left(0, \frac{1}{2}\right).$$

两边乘以 $\sqrt{n}$:

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = \sqrt{n} \cdot \sqrt{n} \left(\sqrt{\frac{V_n}{n}} - 1 \right) \xrightarrow{D} \sqrt{n} \cdot N\left(0, \frac{1}{2}\right).$$

但这不是正确的缩放。正确的做法是直接对 $\sqrt{V_n}$ 应用 Δ 方法到 $\sqrt{n}$:

因为 $\sqrt{n}(\frac{V_n}{n} - 1) \xrightarrow{D} N(0, 2)$, 且 $g'(1) = \frac{1}{2}$, 所以

$$\sqrt{n} \left(\sqrt{\frac{V_n}{n}} - 1 \right) \xrightarrow{D} N\left(0, 2 \cdot \frac{1}{4}\right) = N\left(0, \frac{1}{2}\right).$$

即

$$\sqrt{n} \left(\frac{\sqrt{V_n}}{\sqrt{n}} - 1 \right) \xrightarrow{D} N\left(0, \frac{1}{2}\right).$$

因此

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) \xrightarrow{D} N\left(0, \frac{1}{2} \cdot n\right) = N\left(0, \frac{n}{2}\right).$$

这表明 $\sqrt{V_n}$ 的渐近方差与 $\sqrt{n}$ 成正比。

结论: 应用 Δ 方法于卡方变量的平方根变换, 得到

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) \xrightarrow{D} N\left(0, \frac{1}{2}\right) \cdot \sqrt{n} = N\left(0, \frac{n}{2}\right).$$

更精确地, $\sqrt{n}(\sqrt{V_n} - \sqrt{n})/\sqrt{n/2} = \sqrt{2}(\sqrt{V_n} - \sqrt{n})/\sqrt{V_n/2} \xrightarrow{D} N(0, 1)$ 。■

0.29. 卡方检验的详细推导. 背景 (Background): 拟合优度 χ^2 检验 (Goodness-of-Fit Test) 由 Karl Pearson 于 1900 年提出, 是统计推断的早期方法之一。该检验用于检验观测频数与期望频数之间的偏离程度。

参数定义 (Parameter Definitions):

- $X_i \sim \text{Multinomial}(n, p_1, \dots, p_k)$: 多项分布, X_i 为落入第 i 类的频数
- p_i : 落入第 i 类的真实概率
- p_{i0} : 原假设 H_0 下指定的概率值
- np_{i0} : 原假设下第 i 类的期望频数
- $Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_{i0})^2}{np_{i0}}$: Pearson χ^2 统计量

已知条件 (Given):

- 当 H_0 为真时, $p_i = p_{i0}$, $i = 1, \dots, k$
- 由中心极限定理, 当 $n \rightarrow \infty$ 且 $np_i > 0$ 时,

$$\frac{X_i - np_i}{\sqrt{np_i(1 - p_i)}} \xrightarrow{D} N(0, 1).$$

- 当 H_0 为真时, $X_i \approx N(np_{i0}, np_{i0}(1 - p_{i0}))$

目标 (Goal): 证明在 H_0 下, $Q_{k-1} \xrightarrow{D} \chi^2(k-1)$ 。

推导步骤 (Derivation Steps):

1. 首先考虑二项分布情形。设 $X_1 \sim b(n, p_1)$, $X_2 = n - X_1$, $p_2 = 1 - p_1$ 。定义标准化变量

$$Z = \frac{X_1 - np_1}{\sqrt{np_1(1-p_1)}}.$$

由 CLT, $Z \xrightarrow{D} N(0, 1)$ 。

2. 则 $Z^2 \xrightarrow{D} \chi^2(1)$ (标准正态变量的平方服从自由度为 1 的卡方分布)。

3. 展开 Z^2 :

$$Z^2 = \frac{(X_1 - np_1)^2}{np_1(1-p_1)} = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_1 - np_1)^2}{n(1-p_1)}.$$

4. 利用 $X_2 = n - X_1$, 有 $(X_1 - np_1)^2 = (n - X_2 - n + np_2)^2 = (X_2 - np_2)^2$ 。因此

$$Z^2 = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_2 - np_2)^2}{np_2} = Q_1,$$

即二项情形的 Pearson χ^2 统计量。

5. 推广到多项分布。设 $(X_1, \dots, X_{k-1}) \sim \text{Multinomial}(n, p_1, \dots, p_{k-1})$, $X_k = n - \sum_{i=1}^{k-1} X_i$, $p_k = 1 - \sum_{i=1}^{k-1} p_i$ 。

定义 Pearson 统计量

$$Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i}.$$

6. 关键步骤: 将 Q_{k-1} 表示为平方和形式。令

$$Y_i = \frac{X_i - np_i}{\sqrt{np_i}}, \quad i = 1, \dots, k.$$

则 $Q_{k-1} = \sum_{i=1}^k Y_i^2$ 。

7. 向量形式: 设 $\mathbf{Y} = (Y_1, \dots, Y_k)$ 。可以证明 (见 Hogg, McKean, Craig Theorem 4.7.1 或更高级课程的证明), 当 $n \rightarrow \infty$ 时, $\mathbf{Y}$ 的协方差矩阵为

$$\Sigma = I_k - \mathbf{p}\mathbf{p}',$$

其中 $\mathbf{p} = (p_1, \dots, p_k)'$, I_k 为 $k \times k$ 单位矩阵。

8. 该协方差矩阵 Σ 是 ** 幂等矩阵 ** (idempotent), 且 $\text{rank}(\Sigma) = k - 1$ 。对于幂等矩阵, 其特征值为 0 或 1。

9. 因此, $Q_{k-1} = \mathbf{Y}'\mathbf{Y}$ 服从 (渐近) $\chi^2(k-1)$ 分布。这基于以下事实: 若 $\mathbf{Y} \xrightarrow{D} N(\mathbf{0}, \Sigma)$, 且 Σ 是幂等的, 则 $\mathbf{Y}'\Sigma^-\mathbf{Y} \xrightarrow{D} \chi^2(\text{rank}(\Sigma))$, 其中 Σ^- 为广义逆。

10. 具体推导 (来自 Hogg): 设 $Z_i = (X_i - np_i)/\sqrt{np_i}$, 则 $\sum_{i=1}^k \sqrt{p_i}Z_i = 0$ (因为 $\sum X_i = n$)。定义

$$Q_{k-1} = \sum_{i=1}^k Z_i^2 = \sum_{i=1}^k (Z_i - \bar{Z}_w)^2 + (\text{某个组合})^2,$$

其中 $\bar{Z}_w = \sum_{i=1}^k p_i Z_i / \sum_{i=1}^k p_i = 0$ 。

最终得到 Q_{k-1} 可以分解为一个 $\chi^2(1)$ 变量 (来自组合约束) 和一个 $\chi^2(k-2)$ 变量之和, 即 $\chi^2(k-1)$ 。

结论：在原假设 $H_0 : p_i = p_{i0}, i = 1, \dots, k$ 下，当样本量 $n \rightarrow \infty$ 时，

$$Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_{i0})^2}{np_{i0}} \xrightarrow{D} \chi^2(k-1).$$

因此，对于大样本， Q_{k-1} 具有近似卡方分布，自由度为 $k-1$ （减去一个约束 $\sum p_i = 1$ ）。这就是 Karl Pearson 于 1900 年提出的拟合优度 χ^2 检验的理论基础。■

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是**固定（但未知）的常数**，而区间 $[L, U]$ 是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 Chapter 4 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及 (直方图估计)
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

简单区分：

场景	方法	章节
分布形式未知	非参数方法 (直方图、核密度估计)	Chapter 10
分布形式已知、参数未知	参数方法 (MLE、CI、检验)	Chapter 4

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 1. 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 2. 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 3. 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计 (MLE) 被提出的**动机**。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

具体例子：

- S^2 (无偏) 和 $\hat{\sigma}^2$ (有偏，但 MLE)
- 两者都常用，但各有用途
- “最优”需要更精确的定义 (后续章节的 UMVUE)

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

1.5. 正则条件 (R0)-(R2) 的定义. 问: 在 Chapter 6 中多次提到”正则条件 (R0)-(R2)”, 但没有给出正确定义。这些条件具体是什么?

答: 正则条件 (R0)-(R2) 是 MLE 渐近理论中的经典正则条件, 确保 MLE 具有一致性和渐近正态性。

(R0) 可辨识性 (Identifiability): 参数 θ 可辨识, 即若对所有 x 有 $f(x; \theta) = f(x; \theta')$, 则 $\theta = \theta'$ 。这保证了不同参数值对应不同的分布。

(R1) 参数空间正则性: 参数空间 Ω 是 $\mathbb{R}^p$ 的开子集, 且真参数 θ_0 是 Ω 的内点。这保证了在 θ_0 附近可以进行泰勒展开。

(R2) 密度函数光滑性: 密度 $f(x; \theta)$ 对 θ 足够光滑, 满足:

- 积分号下可微分: $\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx$
- 得分函数 $S(X, \theta) = \nabla_{\theta} \log f(X; \theta)$ 有有限二阶矩
- Fisher 信息矩阵 $I(\theta) = \mathbb{E}[S(X, \theta)S(X, \theta)^T]$ 在 θ_0 处存在且正定

这些条件的作用:

- (R0) 保证参数可以被唯一估计
- (R1) 允许在真参数附近进行局部分析
- (R2) 使得大数定律和中心极限定理可以应用于得分函数, 从而建立 MLE 的渐近理论

注: Cauchy 分布的 MLE 不满足某些正则条件, 因此需要特殊处理 (见 §6.1 的例子)。

学习笔记.

参考文献

- [1] Jonas E. Salk, J. S. Youngner, E. N. Ward, A. B. Ángelbeck, H. C. Merritt, M. E. Glabe, I. L. Sherman, J. W. Osborne, A. J. Lindsey, A. M. Bodanza, et al. The use of adjuvants to facilitate studies on the immunologic properties of poliomyelitis vaccines. *American Journal of Public Health*, 45:151–170, 1955.
- [2] Samuel S. Wilks. *Statistical Design and Analysis of Experiments*. John Wiley & Sons, reprint of 1963 edition edition, 2006.
- [3] Edwin B. Wilson. One probable inference, the ligature of arteries, and the first statistical test of the etiology of disease. *Journal of the American Statistical Association*, 22:209–212, 1927.