

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;

the sequence $X_i = Y_i - Z_i$, $i = 1, 2, \dots$. If $\alpha_a = \beta_a = 0.05$, show that the test can be based upon $\bar{X} = \bar{Y} - \bar{Z}$. Find $c_0(n)$ and $c_1(n)$.

EXERCISE 8.50. **8.50 SPRT for Binomial Process –Hogg 8.4.4** Suppose that a manufacturing process makes about 3% defective items, which is considered satisfactory for this particular product. The managers would like to decrease this to about 1% and clearly want to guard against a substantial increase, say to 5%. To monitor the process, periodically $n = 100$ items are taken and the number X of defectives counted. Assume that X is $b(n = 100, p = \theta)$. Based on a sequence $X_1, X_2, \dots, X_m, \dots$, determine a sequential probability ratio test that tests $H_0 : \theta = 0.01$ against $H_1 : \theta = 0.05$. (Note that $\theta = 0.03$, the present level, is in between these two values.) Write this test in the form

$$h_0 > \sum_{i=1}^m (x_i - nd) > h_1$$

and determine d , h_0 , and h_1 if $\alpha_a = \beta_a = 0.02$.

EXERCISE 8.51. **8.51 SPRT for Beta Distribution –Hogg 8.4.5** Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere.

- (a) Find a complete sufficient statistic for θ .
- (b) If $\alpha_a = \beta_a = 1/10$, find the sequential probability ratio test of $H_0 : \theta = 2$ against $H_1 : \theta = 3$.

Section 8.5.

EXERCISE 8.52. **8.52 Minimax Test for Normal Mean –Hogg 8.5.1** Let $X_1, X_2, \dots, X_{20}$ be a random sample of size 20 from a distribution that is $N(\theta, 5)$. Let $L(\theta)$ represent the joint pdf of $X_1, X_2, \dots, X_{20}$. The problem is to test $H_0 : \theta = 1$ against $H_1 : \theta = 0$. Thus $\Omega = \{\theta : \theta = 0, 1\}$.

- (a) Show that $L(1)/L(0) \leq k$ is equivalent to $\bar{x} \leq c$.
- (b) Find c so that the significance level is $\alpha = 0.05$. Compute the power of this test if H_1 is true.
- (c) If the loss function is such that $\mathcal{L}(1, 1) = \mathcal{L}(0, 0) = 0$ and $\mathcal{L}(1, 0) = \mathcal{L}(0, 1) > 0$, find the minimax test. Evaluate the power function of this test at the points $\theta = 1$ and $\theta = 0$.

EXERCISE 8.53. **8.53 Minimax Test for Poisson Distribution –Hogg 8.5.2** Let $X_1, X_2, \dots, X_{10}$ be a random sample of size 10 from a Poisson distribution with parameter θ . Let $L(\theta)$ be the joint pdf of $X_1, X_2, \dots, X_{10}$. The problem is to test $H_0 : \theta = 1/2$ against $H_1 : \theta = 1$.

- (a) Show that $L(1/2)/L(1) \leq k$ is equivalent to $y = \sum_{i=1}^n x_i \geq c$.
- (b) In order to make $\alpha = 0.05$, show that H_0 is rejected if $y > 9$ and, if $y = 9$, reject H_0 with probability $1/2$ (using some auxiliary random experiment).

- (c) If the loss function is such that $\mathcal{L}(1/2, 1/2) = \mathcal{L}(1, 1) = 0$ and $\mathcal{L}(1/2, 1) = 1$ and $\mathcal{L}(1, 1/2) = 2$, show that the minimax procedure is to reject H_0 if $y > 6$ and, if $y = 6$, reject H_0 with probability 0.08 (using some auxiliary random experiment).

EXERCISE 8.54. **8.54** Classification for Bivariate Normal –Hogg 8.5.3 In Example 8.5.2 let $\mu'_1 = \mu'_2 = 0$, $\mu''_1 = \mu''_2 = 1$, $\sigma_1^2 = 1$, $\sigma_2^2 = 1$, and $\rho = 1/2$.

- (a) Find the distribution of the linear function $aX + bY$.
 (b) With $k = 1$, compute $P(aX + bY \leq c; \mu'_1 = \mu'_2 = 0)$ and $P(aX + bY > c; \mu''_1 = \mu''_2 = 1)$.

EXERCISE 8.55. **8.55** Newton's Algorithm for Minimax –Hogg 8.5.4 Determine Newton's algorithm to find the solution of Equation (8.5.2). If software is available, write a program that performs your algorithm and then show that the solution is $c = 76.8$. If software is not available, solve (8.5.2) by "trial and error".

EXERCISE 8.56. **8.56** Classification Rule for Bivariate Exponential –Hogg 8.5.5 Let X and Y have the joint pdf

$$f(x, y; \theta_1, \theta_2) = \frac{1}{\theta_1 \theta_2} \exp\left(-\frac{x}{\theta_1} - \frac{y}{\theta_2}\right), \quad 0 < x < \infty, \quad 0 < y < \infty,$$

zero elsewhere, where $0 < \theta_1$, $0 < \theta_2$. An observation (x, y) arises from the joint distribution with parameters equal to either $(\theta'_1 = 1, \theta'_2 = 5)$ or $(\theta''_1 = 3, \theta''_2 = 2)$. Determine the form of the classification rule.

EXERCISE 8.57. **8.57** Quadratic Classification Rule –Hogg 8.5.6 Let X and Y have a joint bivariate normal distribution. An observation (x, y) arises from the joint distribution with parameters equal to either

$$\mu'_1 = \mu'_2 = 0, \quad (\sigma_1^2)' = (\sigma_2^2)' = 1, \quad \rho' = 1/2$$

or

$$\mu''_1 = \mu''_2 = 1, \quad (\sigma_1^2)'' = 4, \quad (\sigma_2^2)'' = 9, \quad \rho'' = 1/2.$$

Show that the classification rule involves a second-degree polynomial in x and y .

EXERCISE 8.58. **8.58** Classification for Bivariate Normal with Different Variances –Hogg 8.5.7 Let $\mathbf{W}' = (W_1, W_2)$ be an observation from one of two bivariate normal distributions, I and II, each with $\mu_1 = \mu_2 = 0$ but with the respective variance-covariance matrices

$$\mathbf{V}_1 = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix} \quad \text{and} \quad \mathbf{V}_2 = \begin{pmatrix} 3 & 0 \\ 0 & 12 \end{pmatrix}.$$

How would you classify $\mathbf{W}$ into I or II?

CHAPTER 9

ANOVA and Regression

Chapter 9 Overview

在前几章中，我们讨论了来自单个总体的样本推断，以及两个总体的比较。但实际中，我们常常面临更复杂的问题：

如果有三个、四个甚至更多个总体，我们该如何比较它们的均值？

这个问题——即**多组比较问题**——在农业实验、医学试验、工业质量控制等领域无处不在。例如，在一项评估不同肥料对作物产量影响的实验中，我们需要同时比较多个处理组；而在研究药物疗效时，我们可能需要同时评估多种药物的效果。

本章，我们从单样本 t 检验 $\rightarrow$ 两样本 t 检验 $\rightarrow$ 多组比较的自然推广，引入**方差分析 (Analysis of Variance, 简称 ANOVA)**。这一方法由 Ronald Fisher 在 1920 年代创立，起源于他在英国洛桑农业实验站的农业实验研究。Fisher 的核心思想是：将总变异分解为可解释的变异和随机误差，通过比较两者来判断处理效应是否显著。

本章路线图：

- (1) One-Way ANOVA $\rightarrow$ 组间/组内平方和分解 $\rightarrow F$ 检验
- (2) 非中心 χ^2 和 F 分布 $\rightarrow$ 备择假设下的分布
- (3) Multiple Comparisons $\rightarrow$ Tukey 法、Bonferroni 法（控制族误差率）
- (4) Two-Way ANOVA $\rightarrow$ 主效应、交互效应
- (5) 回归问题 $\rightarrow$ 最小二乘估计、几何解释（投影）
- (6) 二次型分布 $\rightarrow$ Cochran 定理——平方和分解的理论基础

1. 9.1 Introduction

在正式进入 ANOVA 之前，我们需要介绍一个重要的数学工具——**二次型 (quadratic form)**。

DEFINITION 9.1 (二次型). 设 $X_1, \dots, X_n$ 是 n 个变量， a_{ij} 是常数。形如

$$q(X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^n X_i a_{ij} X_j$$

的表达式称为 $X_1, \dots, X_n$ 的（二次）**二次型**。

为什么二次型重要？ 在统计推断中，许多关键的统计量都可以表示为二次型。例如，样本方差

$$(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

就是关于样本 $X_1, \dots, X_n$ 的一个二次型。理解二次型的分布性质, 是理解 ANOVA 和回归分析的理论基础。

2. 9.2 One-Way ANOVA

2.1. 问题的引入. 考虑 b 个独立的正态总体, 第 j 个总体的均值为 μ_j , 共同方差为 σ^2 。从第 j 个总体中抽取容量为 n_j 的随机样本 $X_{1j}, X_{2j}, \dots, X_{n_jj}$ 。记总样本量为 $n = \sum_{j=1}^b n_j$ 。

模型为:

$$X_{ij} = \mu_j + e_{ij}, \quad i = 1, \dots, n_j, \quad j = 1, \dots, b, \quad (9.2.1)$$

其中 e_{ij} 是 iid $N(0, \sigma^2)$ 随机误差。

我们想检验: 所有 b 个总体的均值是否相等——

$$H_0: \mu_1 = \mu_2 = \dots = \mu_b \quad \text{vs} \quad H_1: \mu_j \neq \mu_{j'} \text{ 对某些 } j \neq j'. \quad (9.2.2)$$

实际背景: 例如, b 种药物对某种疾病的疗效比较; 或 b 种肥料对作物产量的影响。这里“一种因素 (factor)”处于 b 个“水平 (level)”, 因此称为**单因素实验 (one-way layout)**。

2.2. 似然比检验的推导. 完全模型 (full model) 参数空间:

$$\Omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : -\infty < \mu_j < \infty, \quad 0 < \sigma^2 < \infty\}.$$

约束模型 (reduced model) 参数空间 (H_0 下):

$$\omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : \mu_1 = \dots = \mu_b = \mu, \quad 0 < \sigma^2 < \infty\}.$$

完全模型下的 MLE:

$$\hat{\mu}_j = \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\Omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2. \quad (9.2.7)$$

约束模型下的 MLE (此时等价于单样本问题):

$$\hat{\mu}_\omega = \bar{X}_{\cdot\cdot} = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.3)$$

似然比统计量简化后的形式为:

$$\Lambda^{n/2} = \frac{\hat{\sigma}_\Omega^2}{\hat{\sigma}_\omega^2}. \quad (9.2.9)$$

拒绝 H_0 等价于 F 统计量过大, 其中

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)}, \quad (9.2.11)$$

而

$$Q_3 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2, \quad Q_4 = \sum_{j=1}^b n_j (\bar{X}_{\cdot j} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.10)$$

核心分解:

$$\underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2}_Q = \underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}_{Q_3(\text{组内})} + \underbrace{\sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2}_{Q_4(\text{组间})}. \quad (9.2.10)$$

在 H_0 下, $Q_3/\sigma^2 \sim \chi^2(n-b)$, $Q_4/\sigma^2 \sim \chi^2(b-1)$, 且二者独立。因此 $F \sim F(b-1, n-b)$ 。

2.3. ANOVA 表格. 单因素 ANOVA 的结果可以汇总为一张清晰的表格:

表 1. 单因素 ANOVA 表格

来源	平方和 (SS)	df	均方 (MS)	F 统计量	p 值
组间 (Between)	Q_4	$b-1$	$MSB = Q_4/(b-1)$	$\frac{MSB}{MSW}$	$\mathbb{P}(F > F_0)$
组内 (Within)	Q_3	$n-b$	$MSW = Q_3/(n-b)$		
总计 (Total)	Q	$n-1$			

EXAMPLE 9.1 (合金弹性模量). Devore (2012, 第 412 页) 报告了一项数据: 三种铸造工艺 (永久模具、压铸、石膏模具) 生产合金的弹性模量。三种工艺各有多次测量, 我们想知道铸造工艺是否显著影响弹性模量。

数据汇总后, $F = 12.565$, 自由度为 2 和 19, p 值为 0.0003。如此小的 p 值表明: 铸造工艺对弹性模量有显著影响。

(该例子的详细计算与 R 代码实现见附录 ??。)

3. 9.3 Noncentral χ^2 and F Distributions

3.1. 为什么需要非中心分布? 在前一节的 ANOVA 中, 我们在原假设 H_0 下推导了 F 统计量的分布。但在实际应用中, 我们更关心: 当 H_0 不成立 (即各组均值不全相等) 时, F 统计量的分布是什么? 这时就需要引入**非中心 χ^2 分布**和**非中心 F 分布**。

DEFINITION 9.2 (非中心 χ^2 分布). 设 $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, \dots, n$, 独立。则

$$Y = \sum_{i=1}^n \frac{X_i^2}{\sigma^2}$$

的 *mgf* 为

$$M(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}, \quad t < \frac{1}{2}. \quad (9.3.1)$$

此时称 $Y \sim \chi^2(r, \theta)$, 其中 $r = n$ 是自由度, $\theta = \sum_{i=1}^n \mu_i^2 / \sigma^2$ 是**非中心参数 (noncentrality parameter)**。

直观理解: 当所有 $\mu_i = 0$ 时, $\theta = 0$, 回到中心 χ^2 分布; 当某些 $\mu_i \neq 0$ 时, Y 的分布在中心 χ^2 的基础上向右偏移, θ 越大, 偏移越明显。

非中心 χ^2 分布的均值: $E(Y) = r + \theta$ (中心部分 r 加上非中心部分 θ)。

DEFINITION 9.3 (非中心 F 分布). 设 $U \sim \chi^2(r_1, \theta)$, $V \sim \chi^2(r_2)$, 独立。则

$$F = \frac{r_2 U}{r_1 V}$$

服从自由度为 r_1, r_2 、非中心参数为 θ 的非中心 F 分布, 记作 $F(r_1, r_2, \theta)$ 。

EXAMPLE 9.2 (One-Way ANOVA 的非中心参数). 对于 one-way ANOVA 模型 (9.2.1), 在备择假设 H_1 下, F 统计量的分子 $Q_4/\sigma^2 \sim \chi^2(b-1, \theta)$, 其中

$$\theta = \frac{1}{\sigma^2} \sum_{j=1}^b n_j (\mu_j - \bar{\mu})^2, \quad \bar{\mu} = \frac{1}{n} \sum_{j=1}^b n_j \mu_j. \quad (9.3.5)$$

当 H_0 成立时, $\theta = 0$, 回到中心 F 分布; 当 H_1 成立时, $\theta > 0$, F 分布向右偏移, 偏移程度由 θ 刻画。这解释了为什么 F 检验在 H_0 不成立时倾向于取更大的值。

(非中心 F 分布的完整推导见附录 ??。)

4. 9.4 Multiple Comparisons

当 one-way ANOVA 的 F 检验拒绝了 H_0 后, 我们自然想知道: 具体哪些组之间存在显著差异? 这就是多重比较问题 (Multiple Comparison Problem, MCP)。

4.1. 问题的核心矛盾. 对 b 个总体, 若进行所有 $\binom{b}{2}$ 个成对比较, 即使每个置信区间的置信水平为 95%, 整体的置信水平也会急剧下降。举例来说, 若 $b = 5$, 则共有 10 个成对比较, 每个比较犯错的概率为 5%, 至少有一次犯错的概率粗略估计为 $1 - (0.95)^{10} \approx 40\%$ 。

因此, 我们需要专门设计的方法来**控制族误差率 (Family-Wise Error Rate, FWER)**——即**在所有比较中至少有一次犯错的概率**。

4.2. Bonferroni 方法. Bonferroni 方法基于一个简单的不等式: 对 k 个参数 θ_i , 若每个区间 I_i 的置信水平为 $1 - \alpha$, 则

$$P(\text{所有 } \theta_i \in I_i) \geq 1 - k\alpha. \quad (9.4.2)$$

核心理想: 将每个区间的置信水平从 $1 - \alpha$ 调整为 $1 - \alpha/k$, 则整体的置信水平至少为 $1 - \alpha$ 。

对 one-way ANOVA, 成对差值 $\mu_j - \mu_{j'}$ 的 Bonferroni 置信区间为:

$$\bar{X}_{\cdot j} - \bar{X}_{\cdot j'} \pm t_{\alpha/(2k), n-b} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.3)$$

优点: 通用性强, 适用于任何成对比较。**缺点:** 比较数量 k 越大, 区间越宽, 精度损失越大。

4.3. Tukey 方法. Tukey 方法利用学生化极差分布 (Studentized range distribution), 专为 balanced 设计的成对比较设计。

当所有组样本容量相等 ($n_j = a, j = 1, \dots, b$) 时, 所有成对比较的同时置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm q_{1-\alpha, b, n-b} \frac{\hat{\sigma}_{\Omega}}{\sqrt{a}}, \quad \forall j \neq j'. \quad (9.4.4)$$

其中 $q_{1-\alpha, b, n-b}$ 是自由度为 b 和 $n-b$ 的学生化极差分布分位数。

对于 unbalanced 情形, 使用 Tukey-Kramer 修正:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm \frac{q_{1-\alpha, b, n-b}}{\sqrt{2}} \hat{\sigma}_{\Omega} \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.5)$$

EXAMPLE 9.3 (赛车速度比较). *Kitchens (1997)* 报告了一项实验: 比较五种汽车 (*Acura, Ferrari, Lotus, Porsche, Viper*) 的最高速度。每种车进行 6 次运行测试。整体 F 检验高度显著 ($F = 25.15, p \approx 0$)。Tukey 多重比较结果表明: *Ferrari* 和 *Porsche* 的平均速度显著快于其他三种车, 但 *Ferrari* 与 *Porsche* 之间速度差异不显著。

(该例子的 R 实现与详细结果分析见附录 ??。)

4.4. Fisher 的保护 LSD 方法. Fisher 方法是一个两步程序:

- (1) 首先进行整体 F 检验; 若拒绝 H_0 ,
- (2) 再使用标准的成对 t 置信区间 (置信水平 $1 - \alpha$)。

Fisher 方法不保证整体覆盖率为 $1 - \alpha$, 但 F 检验提供了”保护”。模拟研究表明它在功效和实际误差率方面表现良好。

5. 9.5 Two-Way ANOVA

5.1. 双因素实验的引入. 在实际研究中, 我们常常需要同时考虑两个因素对结果的影响。例如:

- 作物产量: 同时受品种 (因素 A) 和肥料类型 (因素 B) 的影响
- 考试成绩: 同时受教学方法 (因素 A) 和班级规模 (因素 B) 的影响

这就是双因素方差分析 (two-way ANOVA)。

设因素 A 有 a 个水平, 因素 B 有 b 个水平, 每个组合有一个观测值 X_{ij} 。模型为:

$$X_{ij} = \mu + \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b, \quad (9.5.2)$$

其中 $e_{ij} \sim N(0, \sigma^2)$ iid, 且 $\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0$ 。

可加模型 (additive model) 意味着两个因素的影响是相互独立的——因素 A 的效应不随因素 B 的水平变化。

表 2. 双因素可加模型的单元格均值示例 ($a = 2, b = 3$)

	B=1	B=2	B=3
A=1	7	6	5
A=2	5	4	3

在可加模型中，行均值轮廓线是**平行的**——这是可加模型的重要特征。

5.2. 假设检验. 我们需要检验两个主效应假设：

$$H_{0A} : \alpha_1 = \cdots = \alpha_a = 0 \quad \text{vs} \quad H_{1A} : \text{某些 } \alpha_i \neq 0, \quad (9.5.3)$$

$$H_{0B} : \beta_1 = \cdots = \beta_b = 0 \quad \text{vs} \quad H_{1B} : \text{某些 } \beta_j \neq 0. \quad (9.5.4)$$

检验 H_{0B} 的 F 统计量：

$$F_B = \frac{a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 / (b-1)}{\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2 / [(a-1)(b-1)]}. \quad (9.5.12)$$

在 H_{0B} 下， $F_B \sim F(b-1, (a-1)(b-1))$ 。

类似地，检验 H_{0A} 的 F 统计量 $F_A \sim F(a-1, (a-1)(b-1))$ 。

5.3. 9.5.1 Interaction between Factors. 交互效应发生在：一个因素的影响程度取决于另一个因素的水平时。

在模型中引入交互参数 γ_{ij} ：

$$\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij}, \quad (9.5.15)$$

其中 $\sum_i \gamma_{ij} = \sum_j \gamma_{ij} = 0$ 。

若所有 $\gamma_{ij} = 0$ ，则回到可加模型；若存在非零 γ_{ij} ，则两个因素之间存在**交互作用**。

图形诊断：在双因素实验中，绘制各行（因素 A 各水平）的均值轮廓线。若线条大致平行，则交互作用不明显；若线条明显交叉或分离，则表明存在交互效应。

EXAMPLE 9.4 (沥青混合料热导率). Devore (2012, 第 435 页) 研究了两个因素对沥青混合料热导率的影响：粘结剂等级 (PG58, PG64, PG70) 和粗骨料含量 (38%, 41%, 44%)。每个处理组合有 2 次重复。

R 分析结果：交互效应不显著 ($p = 0.4135$)，但两个主效应都非常显著 ($p = 0.0017$ 和 $p < 10^{-5}$)。因此接受可加模型，两个因素独立地影响热导率。

(该例子的详细 ANOVA 表和 R 代码见附录 ??。)

6. 9.6 A Regression Problem

6.1. 为什么研究回归? ANOVA 研究的是类别型 (categorical) 自变量对因变量的影响。但在许多实际问题中，自变量是连续型的。例如：

- 学生的学习时间 (连续) $\rightarrow$ 考试成绩
- 汽车的发动机排量 (连续) $\rightarrow$ 每加仑行驶里程
- 农作物的施肥量 (连续) $\rightarrow$ 作物产量

这就引出了**回归分析 (regression analysis)**——研究自变量 (通常记作 x) 与因变量 Y 之间关系的方法。

线性模型：假设 $E(Y) = \mu(x)$ 是 x 的线性函数——

$$Y_i = \alpha + \beta(x_i - \bar{x}) + e_i, \quad i = 1, \dots, n, \quad (9.6.1)$$

其中 $e_i \sim N(0, \sigma^2)$ iid。

为什么假设 x 是已知的非随机变量？ 这是为了简化分析——我们把不确定性全部放在 Y 上。在实际中，如果 x 也是随机的，则需要联合分布建模；但在受控实验或观测研究中，将 x 视为固定设计点是合理的近似。

线性模型 vs 非线性模型： 这里“线性”指的是对参数 (α, β) 线性，而非对 x 线性。因此 $\alpha + \beta x + \gamma x^2$ 仍是线性模型，而 $\alpha e^{\beta x}$ 不是。

6.2. 9.6.1 Maximum Likelihood Estimates. 对模型 (9.6.1)，似然函数为

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{[Y_i - \alpha - \beta(x_i - \bar{x})]^2}{2\sigma^2} \right\}. \quad (9.6.12)$$

最大化似然等价于最小化

$$H(\alpha, \beta) = \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2. \quad (9.6.3)$$

这正是**最小二乘法 (least squares)**——选择使残差平方和最小的 α, β 。

几何直观： $|Y_i - \alpha - \beta(x_i - \bar{x})|$ 是点 (x_i, Y_i) 到直线 $y = \alpha + \beta(x - \bar{x})$ 的垂直距离。最小二乘法就是找到使所有这些距离平方和最小的直线。

MLE 的解：

$$\hat{\alpha} = \bar{Y}, \quad (9.6.3)$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (9.6.5)$$

$\hat{\sigma}^2$ 的 MLE：

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2. \quad (9.6.8)$$

拟合值与残差：

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}(x_i - \bar{x}), \quad \hat{e}_i = Y_i - \hat{Y}_i. \quad (9.6.6)$$

估计量的分布： 可以证明

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{pmatrix} \right). \quad (9.6.9)$$

EXAMPLE 9.5 (男子 1500 米奥运会成绩). 考虑 27 届奥运会男子 1500 米冠军成绩与年份的关系。年份为自变量 x ，时间为因变量 Y 。

R 拟合结果： $\hat{y} = 12.33 - 0.0044 \times \text{year}$ 。斜率的 95% 置信区间为 $(-0.00547, -0.00328)$ ——这意味着每年获胜时间平均减少约 0.004 分钟（约 0.24 秒）。对 2020 年奥运会的预测时间约为 3.486 分钟。

（该例子的详细计算、残差图分析和预测区间见附录 ??。）

残差图诊断： 在回归分析中，绘制残差 $\hat{e}_i$ vs 拟合值 $\hat{Y}_i$ 的散点图。如果图呈现随机散布，说明模型是合理的；如果出现系统模式（如 U 形、漏斗形），则提示模型设定有问题（如遗漏非线性项、异方差等）。

6.3. 9.6.2 *Geometry of the Least Squares Fit. 最小二乘拟合有一个优美的几何解释。

将数据写成向量形式 $\mathbf{Y} = (Y_1, \dots, Y_n)'$, 设计矩阵 $\mathbf{X}$ 的列为 $\mathbf{1}$ 和 $\mathbf{x}_c = (x_1 - \bar{x}, \dots, x_n - \bar{x})'$ 。模型为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}). \quad (9.6.13)$$

设 V 为 $\mathbf{X}$ 列张成的 $\mathbb{R}^n$ 中的二维子空间 (拟合空间)。最小二乘估计 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 正是 $\mathbf{Y}$ 在子空间 V 上的**正交投影**——即使得 $\|\mathbf{Y} - \boldsymbol{\theta}\|^2$ 最小的 V 中元素。

几何分解:

$$\|\mathbf{Y}\|^2 = \|\hat{\boldsymbol{\theta}}\|^2 + \|\hat{\mathbf{e}}\|^2,$$

其中 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 是残差向量, 且 $\hat{\boldsymbol{\theta}} \perp \hat{\mathbf{e}}$ (残差与拟合空间正交)。这正是 ANOVA 中平方和分解的几何版本。

7. 9.7 A Test of Independence

在许多应用中, 我们需要检验两个连续变量 X 和 Y 是否独立。对于二元正态分布, X 和 Y 独立当且仅当它们的相关系数 $\rho = 0$ 。因此我们检验:

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0. \quad (9.7.1)$$

样本相关系数:

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}. \quad (9.7.1)$$

关键定理: 在 H_0 下 (即 $\rho = 0$ 时), R 的分布不依赖于 X 的具体分布——只要 X 与 Y 独立, R 的分布在正态情况下就有上式 (9.3.1) 给出的精确形式。特别是,

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t(n-2). \quad (9.7.3)$$

因此, H_0 的拒绝域为 $|T| \geq t_{\alpha/2, n-2}$, 或等价地 $|R| \geq c$ 。

Remark 的深层含义: R 的条件分布 (在给定 $X_1, \dots, X_n$ 下) 不依赖于 X_i 的具体值, 这意味着 R 与所有仅依赖于 X 的统计量独立。这是一个非常优雅的性质——样本相关系数在 $\rho = 0$ 时”不受” X 取值的影响。

8. 9.8 Distributions of Certain Quadratic Forms

前几节的分析依赖于一个共同的理论支柱: 某些二次型服从 χ^2 分布, 且它们相互独立。本节和下一节建立这一理论的严格基础。

设 $\mathbf{X}' = (X_1, \dots, X_n)$, 其中 $X_i \sim N(\mu_i, \sigma^2)$ iid. 二次型 $Q = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}$ 的 mgf 为:

$$M_Q(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}. \quad (9.8.10)$$

特别地, 若 $\mathbf{A}$ 是对称幂等矩阵 ($\mathbf{A}^2 = \mathbf{A}$), 则 $Q \sim \chi^2(r, \theta)$, 其中 $r = \text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A})$, $\theta = \boldsymbol{\mu}' \mathbf{A} \boldsymbol{\mu} / \sigma^2$ 。若进一步 $\boldsymbol{\mu} = \mu \mathbf{1}$ 且 $\sum_{i,j} a_{ij} = 0$, 则 $\theta = 0$, Q 为中心 $\chi^2(r)$ 。

Cochran 定理的特例: 若 $Q_1, \dots, Q_k$ 是相互独立的 χ^2 变量之和, 且 $\sum \text{rank}(Q_i) = n$, 则各 Q_i 独立。

9. 9.9 The Independence of Certain Quadratic Forms

最后一个理论工具：Craig 定理，给出了两个二次型独立的充要条件。

这个定理在 ANOVA 中有重要应用：在 one-way ANOVA 中，组间平方和 Q_4 （对应某个幂等矩阵）与组内平方和 Q_3 （对应另一个幂等矩阵）满足 $\mathbf{AB} = \mathbf{0}$ ，因此独立——这正是 F 检验的理论基础。

推论：在回归模型中，拟合值的二次型与残差的二次型相互独立，反映了“被解释的变异”与“未被解释的变异”之间的正交性。

习题

EXERCISE 9.1. 9.1 T^2 与 F 统计量的关系—Hogg 9.2.1 考虑在例 8.3.1 中通过似然比检验推导出的 T 统计量，用于检验两个具有公共方差的正态分布均值的相等性。证明 T^2 恰好是表达式 (9.2.11) 中的 F 统计量。

EXERCISE 9.2. 9.2 线性函数的不相关性—Hogg 9.2.2 在模型 (9.2.1) 下，证明线性函数 $X_{ij} - \bar{X}_{.j}$ 与 $\bar{X}_{.j} - \bar{X}_{..}$ 不相关。

提示：回忆 $\bar{X}_{.j}$ 和 $\bar{X}_{..}$ 的定义，不失一般性地设 $E(X_{ij}) = 0$ 对所有 i, j 。

EXERCISE 9.3. 9.3 One-Way ANOVA 数据计算—Hogg 9.2.3 考虑来自三个正态分布的独立随机样本，它们具有相等方差及 respective means μ_1, μ_2, μ_3 。数据如下：

I	II	III
0.5	2.1	3.0
1.3	3.3	5.1
-1.0	0.0	1.9
1.8	2.3	2.4
	2.5	4.2
		4.1

使用 R 或其他统计软件，计算用于检验 $H_0: \mu_1 = \mu_2 = \mu_3$ 的 F 统计量。

EXERCISE 9.4. 9.4 样本方差的分解—Hogg 9.2.4 设 $X_1, X_2, \dots, X_n$ 是来自正态分布 $N(\mu, \sigma^2)$ 的随机样本。证明

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=2}^n (X_i - \bar{X}')^2 + \frac{n-1}{n} (X_1 - \bar{X}')^2,$$

其中 $\bar{X} = \sum_{i=1}^n X_i/n$ 且 $\bar{X}' = \sum_{i=2}^n X_i/(n-1)$ 。

提示：将 $X_i - \bar{X}$ 替换为 $(X_i - \bar{X}') - (X_1 - \bar{X}')/n$ 。证明 $\sum_{i=2}^n (X_i - \bar{X}')^2/\sigma^2$ 服从自由度为 $n-2$ 的卡方分布。证明右边两项独立。下列统计量的分布是什么？

$$\frac{[(n-1)/n](X_1 - \bar{X}')^2}{\sigma^2}?$$

EXERCISE 9.5. 9.5 MLE 与平方和分解—Hogg 9.2.5 使用本节的记号，假设均值满足条件 $\mu = \mu_1 + (b-1)d = \mu_2 - d = \mu_3 - d = \dots = \mu_b - d$ 。即最后 $b-1$ 个均值相等但

与第一个均值 μ_1 不同 (假设 $d \neq 0$)。从 b 个具有公共未知方差 σ^2 的正态分布中分别抽取容量为 a 的独立随机样本。

(a) 证明 μ 和 d 的最大似然估计量分别是 $\hat{\mu} = \bar{X}_{..}$ 和

$$\hat{d} = \frac{\sum_{j=2}^b \bar{X}_{.j} / (b-1) - \bar{X}_{.1}}{b}.$$

(b) 使用练习 9.2.4, 求 Q_6 和 $Q_7 = c\hat{d}^2$, 使得当 $d = 0$ 时, $Q_7/\sigma^2 \sim \chi^2(1)$, 且

$$\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{..})^2 = Q_3 + Q_6 + Q_7.$$

(c) 论证当 $d = 0$ 时, 右边的三项除以 σ^2 后是相互独立的卡方分布随机变量。

(d) $Q_7/(Q_3 + Q_6)$ 乘以什么常数在 $d = 0$ 时服从 F 分布? 注意, 这个 F 实际上就是用于检验第一个分布的均值与后 $b-1$ 个分布合并后的公共均值相等的双样本 T 的平方。

EXERCISE 9.6. 9.6 LDL 胆固醇水平 ANOVA 分析—Hogg 9.2.6 一项研究比较了四种药物对 LDL (低密度脂蛋白) 胆固醇水平的影响。数据记录在文件 `quailldl.rda` 中。

(a) 绘制 LDL 水平的比较箱线图。哪种药物似乎导致更低的 LDL 水平? 识别数据中的异常值 (按观测号)。

(b) 计算所有四种药物的 LDL 均值相等的 F 检验。报告 F 检验统计量和 p 值。使用显著性水平 0.05 就问题给出结论。使用例 9.2.1 中的 R 代码。

(c) (b) 中的结论与 (a) 中的箱线图一致吗?

(d) 注意, F 检验的一个假设是模型 (9.2.1) 中的随机误差 e_{ij} 服从正态分布。 e_{ij} 的估计量是 $x_{ij} - \bar{x}_{.j}$, 这些称为残差, 即全模型拟合后剩余的部分。计算这些残差, 然后获取它们的直方图、箱线图和正态 $Q-Q$ 图。评价正态性假设。

EXERCISE 9.7. 9.7 One-Way ANOVA 假设检验—Hogg 9.2.7 设 μ_1, μ_2, μ_3 分别为三个正态分布的均值, 它们具有公共未知方差 σ^2 。为在显著性水平 $\alpha = 0.05$ 下检验假设 $H_0: \mu_1 = \mu_2 = \mu_3$ 对所有可能备择假设, 从每个分布中抽取容量为 4 的独立随机样本。若观测值分别为:

$$X_1: \quad 5 \quad 9 \quad 6 \quad 8$$

$$X_2: \quad 11 \quad 13 \quad 10 \quad 12$$

$$X_3: \quad 10 \quad 6 \quad 9 \quad 9$$

判断是否拒绝 H_0 。

EXERCISE 9.8. 9.8 柴油燃料品牌 mpg 比较-Hogg 9.2.8 一位柴油汽车司机根据 mpg 测试三种柴油燃料的质量。使用以下数据检验三个均值相等的原假设。做通常的假设并取 $\alpha = 0.05$ 。

Brand A: 38.7 39.2 40.1 38.9

Brand B: 41.9 42.3 41.3

Brand C: 40.8 41.2 39.5 38.9 40.3

EXERCISE 9.9. 9.9 非中心 χ^2 分布的可加性-Hogg 9.3.1 设 $Y_i, i = 1, 2, \dots, n$, 是相互独立的随机变量, 分别服从 $\chi^2(r_i, \theta_i), i = 1, 2, \dots, n$ 。证明 $Z = \sum_{i=1}^n Y_i$ 服从 $\chi^2(\sum_{i=1}^n r_i, \sum_{i=1}^n \theta_i)$ 。

EXERCISE 9.10. 9.10 非中心 χ^2 分布的方差-Hogg 9.3.2 计算服从非中心 $\chi^2(r, \theta)$ 分布的随机变量的方差。

EXERCISE 9.11. 9.11 非中心性参数的计算与检验功效-Hogg 9.3.3 考虑 one-way ANOVA 问题, 其中各组样本容量相等 ($n_j = m, j = 1, \dots, b$), 且各组均值满足模式: $\mu_1 = \mu + 2d, \mu_2 = \mu_3 = \dots = \mu_b = \mu - d$ 。

(a) 确定上述均值模式下的非中心性参数。¹

(b) 使用 R 函数 `pf` 确定 F 检验在 $m = 5$ 和 $m = 10$ 时检测该均值模式的功效。²

(c) 确定检测功效至少为 0.80 的最小 m 值。³

(d) 如果 $\sigma^2 = 40$, 回答 (a)-(c)。

EXERCISE 9.12. 9.12 非中心 T 与非中心 F 的关系-Hogg 9.3.4 证明非中心 T 随机变量的平方是非中心 F 随机变量。

EXERCISE 9.13. 9.13 非中心 χ^2 分布的差-Hogg 9.3.5 设 X_1 和 X_2 是两个独立的随机变量。设 $X_1 \sim \chi^2(r_1, \theta_1), Y = X_1 + X_2 \sim \chi^2(r, \theta)$, 其中 $r_1 < r$ 且 $\theta_1 \leq \theta$ 。证明 $X_2 \sim \chi^2(r - r_1, \theta - \theta_1)$ 。

EXERCISE 9.14. 9.14 Bonferroni 多重比较程序-Hogg 9.4.1 对于练习 9.2.8 中讨论的研究, 使用 $\alpha = 0.10$ 获取 Bonferroni 多重比较程序的结果。基于此程序, 哪个品牌的燃料 (如果有的话) 显著最好?

EXERCISE 9.15. 9.15 Tukey-Kramer 程序-Hogg 9.4.2 对于练习 9.2.6 中讨论的研究, 计算 Tukey-Kramer 程序。是否存在显著差异?

EXERCISE 9.16. 9.16 Bonferroni 与 Fisher 多重比较方法-Hogg 9.4.3 假设 X 和 Y 是离散随机变量, 它们具有共同的范围 $\{1, 2, \dots, k\}$ 。设 p_{1j} 和 p_{2j} 分别是 $P(X = j)$ 和 $P(Y = j)$ 的相应概率。

(a) 确定执行所有这些比较的 Bonferroni 方法。

(b) 确定执行所有这些比较的 Fisher 方法。

¹答案: $\theta = 5md/3$, 当 $\sigma^2 = 1$ 。

²答案: 对于 $m = 5$: 功效 = 0.6174; 对于 $m = 10$: 功效 = 0.9421。

³答案: $m = 7$ 。

EXERCISE 9.17. 9.17 列联表的多重比较-Hogg 9.4.4 假设练习 9.4.3 中的样本产生了以下列联表:

	1	2	3	4	5	6	7	8	9	10
x	20	31	56	18	45	55	47	78	56	81
y	36	41	65	15	38	78	18	72	59	85

为计算 (用 R) 下面的置信区间, 使用命令 `prop.test` (见例 4.2.5)。

(a) 基于所有 10 个比较的 Bonferroni 程序, 计算 $p_{16} - p_{26}$ 的置信区间。

(b) 基于所有 10 个比较的 Fisher 程序, 计算 $p_{16} - p_{26}$ 的置信区间。

EXERCISE 9.18. 9.18 Fisher 程序的 R 函数-Hogg 9.4.5 编写一个 R 函数, 计算练习 9.4.3 中的 Fisher 程序。用练习 9.4.4 的数据验证它。

EXERCISE 9.19. 9.19 同时检验的 Bonferroni 程序推广-Hogg 9.4.6 将 Bonferroni 程序推广到同时检验。即, 假设我们有 m 个感兴趣的假设: H_{0i} 对 H_{1i} , $i = 1, \dots, m$ 。对于检验 H_{0i} 对 H_{1i} , 设 $C_{i,\alpha}$ 是大小为 α 的临界域, 并假设如果样本 $\mathbf{X}_i \in C_{i,\alpha}$, 则拒绝 H_{0i} 。确定一个规则, 使我们能够同时检验这 m 个假设, 且第一类错误率不超过 α 。

EXERCISE 9.20. 9.20 两因素可加模型平方和分解-Hogg 9.5.1 考虑一个双因素实验, 其中因素 A 有 2 个水平, 因素 B 有 3 个水平。设 $\mu = 5$, $\alpha_1 = 1$, $\alpha_2 = -1$, $\beta_1 = 1$, $\beta_2 = 0$, $\beta_3 = -1$ 。回答以下问题:

(a) 写出单元格均值 μ_{ij} 的表格。

(b) 绘制均值轮廓图 (mean profile plot)。

(c) 若交互效应存在, 轮廓图会有什么特征?

EXERCISE 9.21. 9.21 MLE 的分布-Hogg 9.5.2 考虑表达式 (9.5.14) 之前的讨论。证明随机变量 $\sqrt{a}\bar{X}_{.1}, \dots, \sqrt{a}\bar{X}_{.b}$ 是相互独立的, 且服从公共的 $N(\sqrt{a}\bar{\mu}, \sigma^2)$ 分布。

EXERCISE 9.22. 9.22 交互效应的非中心性参数-Hogg 9.5.3 对于双因素交互模型 (9.5.15), 证明检验统计量 F_{AB} 的非中心性参数等于 $c \sum_{j=1}^b \sum_{i=1}^a \gamma_{ij}^2 / \sigma^2$ 。

EXERCISE 9.23. 9.23 单观测值单元的 MLE 分布-Hogg 9.5.4 使用双因素分类 (每单元一观测值) 的背景, 确定 α_i 、 β_j 和 μ 的最大似然估计量的分布。

EXERCISE 9.24. 9.24 线性函数的不相关性-Hogg 9.5.5 证明在线性函数 $X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..}$ 与 $\bar{X}_{.j} - \bar{X}_{..}$ 在本节的假设下是不相关的。

EXERCISE 9.25. 9.25 双因素分类的 F 检验计算-Hogg 9.5.6 给定以下与双因素分类相关的观测值, 其中 $a = 3$, $b = 4$, 使用 R 或其他统计软件计算用于检验列均值相等 ($\beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$) 和行均值相等 ($\alpha_1 = \alpha_2 = \alpha_3 = 0$) 的 F 统计量。

行/列	1	2	3	4
1	3.1	4.2	2.7	4.9
2	2.7	2.9	1.8	3.0
3	4.0	4.6	3.0	3.9

EXERCISE 9.26. 9.26 多观测值单元的 MLE 分布-Hogg 9.5.7 在每单元有 $c > 1$ 个观测值的双因素分类背景下, 确定 α_i 、 β_j 和 γ_{ij} 的最大似然估计量的分布。

EXERCISE 9.27. 9.27 含交互效应的双因素分类 F 检验-Hogg 9.5.8 给定以下在双因素分类中的观测值, 其中 $a = 3$, $b = 4$, $c = 2$, 计算用于检验所有交互效应为零 ($\gamma_{ij} = 0$)、所有列均值相等 ($\beta_j = 0$) 和所有行均值相等 ($\alpha_i = 0$) 的 F 统计量。数据形式为 x_{ijk} , i, j 在数据集 *sec951.rda* 中。

行/列	1	2	3	4
1	3.1	4.2	2.7	4.9
	2.9	4.9	3.2	4.5
2	2.7	2.9	1.8	3.0
	2.9	2.3	2.4	3.7
3	4.0	4.6	3.0	3.9
	4.4	5.0	2.5	4.2

EXERCISE 9.28. 9.28 可加模型的均值轮廓图-Hogg 9.5.9 对于可加模型 (9.5.1), 证明均值轮廓图是平行的。样本均值轮廓图通过绘制 $\bar{X}_{ij}$ 对 j (对每个 i) 得到。这些提供了检测交互效应的图形诊断。为上一道练习获取这些图。

EXERCISE 9.29. 9.29 随机区组设计的双因素 ANOVA -Hogg 9.5.10 考虑一个随机区组设计, 其中处理 (A) 有 3 个水平, 区组 (B) 有 5 个水平。数据如下:

处理	区组				
	B1	B2	B3	B4	B5
A1	52	47	44	51	42
A2	60	55	49	52	43
A3	56	48	45	44	38

- (a) 使用 5% 的显著性水平, 检验 $H_A: \alpha_1 = \alpha_2 = \alpha_3 = 0$ 对所有备择假设。
 (b) 使用 5% 的显著性水平, 检验 $H_B: \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$ 对所有备择假设。

EXERCISE 9.30. 9.30 双因素模型参数分解-Hogg 9.5.11 设 $a = 3$ 、 $b = 4$, 如果 μ_{ij} ($i = 1, 2, 3$ 和 $j = 1, 2, 3, 4$) 由下表给出, 求 μ 、 α_i 、 β_j 和 γ_{ij} :

6	7	7	12
10	3	11	8
8	5	9	10

EXERCISE 9.31. 9.31 回归系数 α^* 的最小二乘估计-Hogg 9.6.1 通过最小化表达式 (9.6.11) 给出的平方和, 得到模型 $y_i = \alpha^* + \beta x_i + e_i$ 的最小二乘估计。确定 $\hat{\alpha}^*$ 的分布。

EXERCISE 9.32. 9.32 ACT 与微积分成绩的回归分析-Hogg 9.6.2 学生在 ACT 数学考试中的成绩 x 和第一学期微积分期末考试 (满分 200 分) 的成绩 y 如下:

x	25	20	26	26	28	28	29	32	20	25
y	138	84	104	112	88	132	90	183	100	143
x	26	28	25	31	30					
y	141	161	124	118	168					

数据也在 *rda* 文件 *regr1.rda* 中。使用 *R* 或其他统计软件进行计算和绘图。

- 计算这些数据的最小二乘回归线。
- 在同一图上绘制散点和最小二乘回归线。
- 获取残差图并评价模型的适用性。
- 求 β 的 95% 置信区间。就问题给出评论。

EXERCISE 9.33. 9.33 电话数据回归分析-Hogg 9.6.3 考虑以下数据。该数据集的响应变量 y 是 1950 年至 1973 年比利时电话通话次数 (单位: 千万次)。时间 (年份) 作为预测变量 x 。数据在文件 *telephone.rda* 中。

- 计算这些数据的最小二乘回归线。
- 在同一图上绘制散点和最小二乘回归线。
- 最小二乘拟合效果差的原因是什么?

EXERCISE 9.34. 9.34 回归估计量的协方差-Hogg 9.6.4 证明 $\hat{\alpha}$ 与 $\hat{\beta}$ 之间的协方差为零。

提示: 利用 (9.6.5) 中 $\hat{\beta}$ 的表达式, 以及 $\sum_{i=1}^n (x_i - \bar{x}) = 0$ 的性质。

EXERCISE 9.35. 9.35 回归参数的置信区间-Hogg 9.6.5 在模型 (9.6.1) 下, 求参数 α 和 β 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.36. 9.36 均值估计量的分布与置信区间-Hogg 9.6.6 考虑模型 (9.6.1)。设 $\eta_0 = E(Y|x = x_0 - \bar{x})$ 。 η_0 的最小二乘估计量是 $\hat{\eta}_0 = \hat{\alpha} + \hat{\beta}(x_0 - \bar{x})$ 。

- 使用 (9.6.9), 证明 $\hat{\eta}_0$ 是无偏估计量, 并证明其方差为

$$V(\hat{\eta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

- 获取 $\hat{\eta}_0$ 的分布, 并用它来确定 η_0 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.37. 9.37 预测区间-Hogg 9.6.7 假设样本 $(x_1, Y_1), \dots, (x_n, Y_n)$ 服从线性模型 (9.6.1)。设 Y_0 是在 $x = x_0 - \bar{x}$ 处的一个未来观测值, 我们想为其确定一个预测区间。假设模型 (9.6.1) 对 Y_0 成立; 即 $Y_0 \sim N(\alpha + \beta(x_0 - \bar{x}), \sigma^2)$ 。我们使用练习 9.6.6 中的 $\hat{\eta}_0$ 作为对 Y_0 的预测。

- 获取 $Y_0 - \hat{\eta}_0$ 的分布, 证明其方差为:

$$V(Y_0 - \hat{\eta}_0) = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

- 获取以 $Y_0 - \hat{\eta}_0$ 为分子的 t 统计量。

(c) 现在从 $1 - \alpha = P[-t_{\alpha/2, n-2} < T < t_{\alpha/2, n-2}]$ 开始, 其中 $0 < \alpha < 1$, 确定 Y_0 的 $(1 - \alpha)100\%$ 预测区间。

(d) 将此预测区间与练习 9.6.6 获得的置信区间进行比较。为什么预测区间更大? 从直觉上解释。

EXERCISE 9.38. 9.38 奥运会 1500 米成绩的预测区间—Hogg 9.6.8 在例 9.6.1 中, 我们得到了 2020 年奥运会男子 1500 米冠军成绩的预测。计算上一道练习中给出的该预测的 95% 预测区间。这些计算由 R 函数 `cipi.R` 执行。调用方式是 `cipi(lm(time~year), matrix(c(1,2020), ncol=2))`。就问题而言, 这个预测区间意味着什么? 接下来计算 2024 年和 2028 年奥运会的预测。为什么区间长度在增加?

EXERCISE 9.39. 9.39 回归平方和分解—Hogg 9.6.9 证明以下等式成立:

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

提示: 这本质上是将总平方和分解为拟合平方和与残差平方和。

EXERCISE 9.40. 9.40 简单最小二乘拟合—Hogg 9.6.14 使用最小二乘法拟合 $y = a + x$ 到以下数据:

$$\begin{array}{r} x \quad 0 \quad 1 \\ 2 \\ \hline y \quad 1 \quad 3 \\ 4 \end{array}$$

EXERCISE 9.41. 9.41 异方差回归模型的 MLE —Hogg 9.6.10 设独立随机变量 $Y_1, Y_2, \dots, Y_n$ 分别具有概率密度函数 $N(\beta x_i, \gamma^2 x_i^2), i = 1, 2, \dots, n$, 其中给定的数 $x_1, x_2, \dots, x_n$ 不全相等且均不为零。求 β 和 γ^2 的最大似然估计量。

EXERCISE 9.42. 9.42 似然比检验与回归—Hogg 9.6.11 设独立随机变量 $Y_1, \dots, Y_n$ 具有联合 pdf

$$L(\alpha, \beta, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - \alpha - \beta(x_i - \bar{x})]^2 \right\},$$

其中给定的数 $x_1, x_2, \dots, x_n$ 不全相等。设原假设 $H_0: \beta = 0$ (α 和 σ^2 未指定)。希望使用似然比检验来检验 H_0 对所有备择假设。求 Λ , 并看看检验是否能基于一个熟悉的统计量。

提示: 在本节的记号下, 证明

$$\sum_{i=1}^n (Y_i - \hat{\alpha})^2 = Q_3 + \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2.$$

EXERCISE 9.43. 9.43 线性趋势 ANOVA —Hogg 9.6.12 使用第 9.2 节的记号, 假设均值满足 j 的线性函数: $\mu_j = c + d[j - (b+1)/2]$ 。从 b 个均值分别为 $\mu_1, \mu_2, \dots, \mu_b$ 、公共未知方差为 σ^2 的正态分布中分别抽取容量为 a 的独立随机样本。

(a) 证明 c 和 d 的最大似然估计量分别为 $\hat{c} = \bar{X}_{..}$ 和

$$\hat{d} = \frac{\sum_{j=1}^b [j - (b-1)/2](\bar{X}_{.j} - \bar{X}_{..})}{\sum_{j=1}^b [j - (b+1)/2]^2}.$$

(b) 类似于练习 9.2.5, 求平方和分解。

(c) 论证当 $d = 0$ 时, (b) 中右边的两项除以 σ^2 后是自由度分别为 1 和 $ab - 2$ 的独立卡方分布随机变量。

(d) 什么 F 统计量用于检验均值的相等性, 即 $H_0: d = 0$?

EXERCISE 9.44. 9.44 最小二乘估计的几何-Hogg 9.6.13 考虑第 9.6.2 节的讨论。

(a) 证明 $\hat{\boldsymbol{\theta}} = \hat{\alpha}\mathbf{1} + \hat{\beta}\mathbf{x}_c$, 其中 $\hat{\alpha}$ 和 $\hat{\beta}$ 是本节导出的最小二乘估计量。

(b) 证明残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$; 即它的第 i 个元素是 $\hat{e}_i$, (9.6.7)。

(c) 如图 9.6.3 所示, 证明向量 $\hat{\boldsymbol{\theta}}$ 和 $\hat{\mathbf{e}}$ 之间的夹角是直角。

(d) 证明残差之和为零; 即 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 。

EXERCISE 9.45. 9.45 平面拟合-Hogg 9.6.15 用最小二乘法拟合平面 $z = a + bx + cy$ 到五个点 $(x, y, z): (-1, -2, 5), (0, -2, 4), (0, 0, 4), (1, 0, 2), (2, 1, 0)$ 。

令 R 向量 $\mathbf{x}$ 、 $\mathbf{y}$ 、 $\mathbf{z}$ 包含 x 、 y 和 z 的值。则 LS 拟合通过 $\text{lm}(\mathbf{z} \sim \mathbf{x} + \mathbf{y})$ 计算。

EXERCISE 9.46. 9.46 多元正态回归估计-Hogg 9.6.16 设 4×1 矩阵 $\mathbf{Y}$ 服从多元正态分布 $N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$, 其中 4×3 矩阵 $\mathbf{X}$ 等于

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 2 \\ 1 & -1 & 2 \\ 1 & 0 & -3 \\ 1 & 0 & -1 \end{pmatrix}.$$

(a) 求 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 的均值矩阵和协方差矩阵。

(b) 如果我们观测到 $\mathbf{Y}' = (6, 1, 11, 3)$, 计算 $\hat{\boldsymbol{\beta}}$ 。

EXERCISE 9.47. 9.47 多元正态回归的 pdf-Hogg 9.6.17 设 $\mathbf{Y}$ 是 $n \times 1$ 随机向量, $\mathbf{X}$ 是 $n \times p$ 已知常数矩阵 (秩为 p), $\boldsymbol{\beta}$ 是 $p \times 1$ 回归系数向量。设 $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$ 。求 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 的 pdf。

EXERCISE 9.48. 9.48 异方差检验-Hogg 9.6.18 设独立正态随机变量 $Y_1, Y_2, \dots, Y_n$ 分别具有概率密度函数 $N(\mu, \gamma^2 x_i^2)$, $i = 1, 2, \dots, n$, 其中给定的 $x_1, x_2, \dots, x_n$ 不全相等且均不为零。讨论在未指定 μ 的情况下, 检验原假设 $H_0: \gamma = 1$ 对所有备择假设 $H_1: \gamma \neq 1$ 。

EXERCISE 9.49. 9.49 相关系数表达式的化简-Hogg 9.7.1 证明

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{(\sum_{i=1}^n X_i^2 - n\bar{X}^2)(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2)}}.$$

EXERCISE 9.50. 9.50 相关系数的假设检验-Hogg 9.7.2 从二元正态分布中抽取容量为 $n = 6$ 的随机样本, 得到相关系数为 0.89。在 5% 的显著性水平下, 我们是接受还是拒绝 $\rho = 0$ 的假设?

EXERCISE 9.51. 9.51 验证相关系数的 t 分布-Hogg 9.7.3 验证本节的等式 (9.7.3)。

EXERCISE 9.52. 9.52 验证相关系数的分布-Hogg 9.7.4 验证本节的 (9.7.4) 中的 pdf。

EXERCISE 9.53. 9.53 相关系数的一致性-Hogg 9.7.5 使用第 4.5 节的结果, 证明 R , (9.7.1), 是 ρ 的一致估计量。

EXERCISE 9.54. 9.54 相关系数的置信区间-Hogg 9.7.6 通过执行以下步骤, 确定 ρ 的 $(1 - \alpha)100\%$ 近似置信区间。

(a) 对于 $0 < \alpha < 1$, 通常从 $1 - \alpha = P(-z_{\alpha/2} < Z < z_{\alpha/2})$ 开始, 其中 Z 由表达式 (9.7.5) 给出。然后在不等式的中间部分孤立 $h(\rho) = (1/2) \log[(1 + \rho)/(1 - \rho)]$ 。求 $h'(\rho)$ 并证明它在 $-1 < \rho < 1$ 上严格为正; 因此 h 是严格递增的, 其逆函数存在。

(b) 证明这个逆函数是双曲正切函数, $\tanh(y) = (e^y - e^{-y})/(e^y + e^{-y})$ 。

(c) 获取 ρ 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.55. 9.55 棒球数据的相关系数分析-Hogg 9.7.7 R 函数 `cor.test(x, y)` 计算 ρ 的估计量和练习 9.7.6 中的置信区间。回忆棒球数据, 它在文件 `bb.rda` 中。

(a) 使用棒球数据, 确定职业棒球运动员身高与体重之间相关系数的估计值和置信区间。

(b) 将投手和击球手分开, 分别获取身高与体重之间相关系数的估计值和置信区间。它们有显著差异吗?

(c) 论证第二部分中相关系数估计值的差异是关于两个独立样本的 $\rho_1 - \rho_2$ 的一个模型。

EXERCISE 9.56. 9.56 组合样本的相关系数-Hogg 9.7.8 两个实验给出以下结果:

n	$\bar{x}$	$\bar{y}$	s_x	s_y	r
100	10	20	5	8	0.70
200	12	22	6	10	0.80

计算组合样本的 r 。

EXERCISE 9.57. 9.57 二次型与卡方分布-Hogg 9.8.1 设 $Q = X_1X_2 - X_3X_4$, 其中 X_1, X_2, X_3, X_4 是来自 $N(0, \sigma^2)$ 分布的容量为 4 的随机样本。证明 Q/σ^2 不服从卡方分布。求 Q/σ^2 的 mgf。

EXERCISE 9.58. 9.58 二次型的非中心卡方分布-Hogg 9.8.2 设 $\mathbf{X}' = [X_1, X_2]$ 服从二元正态分布, 均值矩阵 $\boldsymbol{\mu}' = [\mu_1, \mu_2]$ 和正定协方差矩阵 Σ 。设

$$Q_1 = \frac{X_1^2}{\sigma_1^2(1 - \rho^2)} - 2\rho \frac{X_1X_2}{\sigma_1\sigma_2(1 - \rho^2)} + \frac{X_2^2}{\sigma_2^2(1 - \rho^2)}.$$

证明 $Q_1 \sim \chi^2(r, \theta)$, 并求 r 和 θ 。 Q_1 何时且仅何时服从中心卡方分布?

EXERCISE 9.59. ?? 非中心卡方分布的计算-Hogg 9.8.3 设 $\mathbf{X}' = [X_1, X_2, X_3]$ 是来自 $N(4, 8)$ 分布的容量为 3 的随机样本, 并设

$$\mathbf{A} = \begin{pmatrix} \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 1 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} \end{pmatrix}.$$

设 $Q = \mathbf{X}'\mathbf{A}\mathbf{X}/\sigma^2$ 。

(a) 使用定理 9.8.1 求 $E(Q)$ 。

(b) 说明为什么断言 $Q \sim \chi^2(2, 6)$ 成立。

EXERCISE 9.60. 9.60 不等方差的样本均值方差-Hogg 9.8.4 假设 $X_1, \dots, X_n$ 是独立随机变量, 有公共均值 μ 但有不等方差 $\sigma_i^2 = \text{Var}(X_i)$ 。

(a) 确定 $\bar{X}$ 的方差。

(b) 确定常数 K , 使得 $Q = K \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\bar{X}$ 方差的无偏估计量。(提示: 按例 9.8.3 中的方法进行。)

EXERCISE 9.61. 9.61 相关变量的样本均值方差-Hogg 9.8.5 假设 $X_1, \dots, X_n$ 是相关随机变量, 有公共均值 μ 和方差 σ^2 但相关系数 ρ (所有相关系数相同)。

(a) 确定 $\bar{X}$ 的方差。

(b) 确定常数 K , 使得 $Q = K \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\bar{X}$ 方差的无偏估计量。(提示: 按例 9.8.3 中的方法进行。)

EXERCISE 9.62. 9.62 验证表达式 (9.8.13) -Hogg 9.8.6 补充表达式 (9.8.13) 的细节。

EXERCISE 9.63. 9.63 迹算子的性质-Hogg 9.8.7 证明表达式 (9.8.1) 中定义的迹算子具有以下性质。

(a) 如果 $\mathbf{A}$ 和 $\mathbf{B}$ 是 $n \times n$ 矩阵, a 和 b 是标量, 则

$$\text{tr}(a\mathbf{A} + b\mathbf{B}) = a \text{tr} \mathbf{A} + b \text{tr} \mathbf{B}.$$

(b) 对于任何 $n \times n$ 矩阵 $\mathbf{A}$ 和 $\mathbf{B}$, $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ 。

(c) 如果 $\mathbf{A}$ 是方阵, Γ 是正交矩阵, 利用 (a) 的结果证明 $\text{tr}(\Gamma'\mathbf{A}\Gamma) = \text{tr} \mathbf{A}$ 。

(d) 如果 $\mathbf{A}$ 是实对称幂等矩阵, 利用 (b) 的结果证明 $\mathbf{A}$ 的秩等于 $\text{tr} \mathbf{A}$ 。

EXERCISE 9.64. 9.64 矩阵元素平方和与特征值-Hogg 9.8.8 设 $\mathbf{A} = [a_{ij}]$ 是实对称矩阵。证明 $\sum_i \sum_j a_{ij}^2$ 等于 $\mathbf{A}$ 的特征值的平方和。

提示: 如果 Γ 是正交矩阵, 证明 $\sum_j \sum_i a_{ij}^2 = \text{tr}(\mathbf{A}^2) = \text{tr}(\Gamma'\mathbf{A}^2\Gamma) = \text{tr}[(\Gamma'\mathbf{A}\Gamma)(\Gamma'\mathbf{A}\Gamma)]$ 。

EXERCISE 9.65. 9.65 非中心卡方分布的判定-Hogg 9.8.9 假设 $\mathbf{X} \sim N_n(0, \Sigma)$, 其中 Σ 是正定矩阵。对于对称矩阵 $\mathbf{A}$, 设 $Q = \mathbf{X}'\mathbf{A}\mathbf{X}$ 。证明当且仅当 $\mathbf{A}\Sigma\mathbf{A} = \mathbf{A}$ 时, $Q \sim \chi^2(r)$, 其中 $r = \text{rank}(\mathbf{A})$ 。

提示: 将 Q 写成

$$Q = (\Sigma^{-1/2} \mathbf{X})' \Sigma^{1/2} \mathbf{A} \Sigma^{1/2} (\Sigma^{-1/2} \mathbf{X}),$$

其中 $\Sigma^{1/2} = \Gamma' \Lambda^{1/2} \Gamma$, $\Sigma = \Gamma' \Lambda \Gamma$ 是 Σ 的谱分解。然后使用定理 9.8.4。

EXERCISE 9.66. 9.66 幂等矩阵的特征值-Hogg 9.8.10 假设 $\mathbf{A}$ 是实对称矩阵。如果 $\mathbf{A}$ 的特征值只有 0 和 1, 证明 $\mathbf{A}$ 是幂等的。

EXERCISE 9.67. 9.67 二次型的独立性判定-Hogg 9.9.1 设 X_1, X_2, X_3 是来自正态分布 $N(0, \sigma^2)$ 的随机样本。二次型 $X_1^2 + 3X_1X_2 + X_2^2 + X_1X_3 + X_3^2$ 和 $X_1^2 - 2X_1X_2 + \frac{2}{3}X_2^2 - 2X_1X_3 - X_3^2$ 是独立还是相关?

EXERCISE 9.68. 9.68 平方和与二次型的相关性-Hogg 9.9.2 设 $X_1, X_2, \dots, X_n$ 表示来自 $N(0, \sigma^2)$ 分布的容量为 n 的随机样本。证明 $\sum_{i=1}^n X_i^2$ 与每一个在 $X_1, X_2, \dots, X_n$ 中非恒为零的二次型都是相关的。

EXERCISE 9.69. 9.69 线性函数与二次型的独立性-Hogg 9.9.3 设 X_1, X_2, X_3, X_4 是来自 $N(0, \sigma^2)$ 分布的容量为 4 的随机样本。设 $Y = \sum_{i=1}^4 a_i X_i$, 其中 a_1, a_2, a_3, a_4 是实常数。如果 Y^2 和 $Q = X_1X_2 - X_3X_4$ 独立, 确定 a_1, a_2, a_3, a_4 。

附录：公式推导

One-Way ANOVA 平方和恒等式的证明. 背景：在 one-way ANOVA 中, 总平方和 Q 可以分解为组内平方和 Q_3 与组间平方和 Q_4 之和。这一恒等式是 F 检验的基石。

目标：证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2.$$

推导：记 $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和：

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零, 因为对每个固定的 j ,

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。

□

One-Way ANOVA 检验统计量的分布. 背景: 推导 one-way ANOVA 中 F 统计量在原假设下的分布。

目标: 证明在 H_0 下, $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导:

步骤 1: Q_3 的分布. 对每个固定的 j , 由样本方差性质, $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立, 故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2 \left(\sum_{j=1}^b (n_j - 1) \right) = \chi^2(n-b).$$

步骤 2: Q_4 与 Q_3 的独立性. 注意 $\bar{X}_{.j}$ 与 Q_3 独立 (由正态样本的性质), 且 $\bar{X}_{..}$ 是 $\bar{X}_{.1}, \dots, \bar{X}_{.b}$ 的线性组合, 因此 $\bar{X}_{..}$ 也与 Q_3 独立。故 Q_4 ($\bar{X}_{.j}$ 的函数) 与 Q_3 独立。

步骤 3: Q_4 的分布. 在 H_0 下, $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$, 故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各 $\bar{X}_{.j}$ 通过 $\bar{X}_{..}$ 而不独立。直接计算知 $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

步骤 4: F 分布. 由步骤 1、2、3 及 F 分布定义,

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b). \quad (\text{A9.3})$$

□

非中心 χ^2 分布的均值和方差. 背景: 验证非中心 χ^2 分布的基本性质。

已知: $Y \sim \chi^2(r, \theta)$, mgf 为 $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。

目标: 求 $E(Y)$ 和 $\text{var}(Y)$ 。

推导:

由 mgf, $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。对 $M(t)$ 求导:

$$M'(t) = \left[r(1-2t)^{-r/2-1} + \frac{r\theta}{(1-2t)^{r/2+1}} \right] \exp \left\{ \frac{t\theta}{1-2t} \right\}.$$

故 $E(Y) = M'(0) = r + \theta$ 。

对 $M''(t)$ 在 $t=0$ 求值, 可得 $\text{var}(Y) = 2(r + 2\theta)$ 。⁴

最小二乘估计的几何解释. 背景: 回归最小二乘估计的正交投影几何。

目标: 证明 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是 $\mathbf{Y}$ 在 $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$ 上的正交投影。

推导: 由正交投影的定义, $\hat{\boldsymbol{\theta}}$ 满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}_c$ 都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0. \quad (\text{A9.4})$$

由 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 得 $\sum_i \hat{e}_i = 0$ (残差之和为零)。

⁴该推导的详细计算见附录 ??。

由 $\mathbf{x}'_c \hat{\mathbf{e}} = 0$ 并利用正规方程，可解出 $\hat{\alpha}$ 和 $\hat{\beta}$ 的表达式与 (9.6.3)、(9.6.5) 一致。故 $\hat{\boldsymbol{\theta}}$ 确为正交投影。 $\square$

附录：公式推导

0.1. Gamma 分布的矩母函数推导. 背景 (Background)： 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions)：

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given)：

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal)： 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps)：

1. 根据矩母函数定义：

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换：令 $y = \frac{x(1-\beta t)}{\beta}$ ，则 $x = \frac{\beta y}{1-\beta t}$ ， $dx = \frac{\beta}{1-\beta t} dy$ 。
3. 代入积分（要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$ ）：

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论： 因此， $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ ，定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background)： 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$ ，方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given)：

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

0.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证: 边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$, 确实是合法的 pdf。

结论: 条件 pdf 公式得证。■

0.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发:

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望 (即关于 X_1 求平均):

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论: 全期望公式得证。■

0.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论: 条件均值的方差不超过原变量的方差, 等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

0.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论: 故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.11. 相关系数范围的推导. 背景 (Background): 我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal): 证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps):

1. Cauchy-Schwarz 不等式: 对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差, 令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$:

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方:

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此:

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论: 故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

0.12. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.14. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.15. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.16. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j | Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j | Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.17. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。
2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.18. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。
2. 则 $X = \sum_{j=1}^n I_j$ 。
3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.19. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} \rightarrow 1, \\ \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.20. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数：

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论： Poisson 分布的均值和方差相等，都等于参数 λ 。■

0.21. 卡方分布与正态分布的关系. 背景 (Background)： 卡方分布定义为标准正态平方和。

目标 (Goal)： 证明若 $Z \sim N(0, 1)$ ，则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps)：

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$ ，先求 cdf：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf：

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式：

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论： 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.22. 卡方分布的可加性证明. 背景 (Background)： 卡方分布满足可加性：独立卡方变量之和仍为卡方分布。

目标 (Goal)： 证明若 $X_1 \sim \chi^2(m)$ ， $X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps)：

1. 由卡方分布与 Gamma 分布的关系： $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性（见定理 3.3.1）：若 $Y_1 \sim \Gamma(\alpha_1, \beta)$ ， $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立，则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此：

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf： $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$ ，故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论： 卡方分布具有可加性，自由度可累加。■

0.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1+X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.24. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.25. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.26. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}[e^{(t/\sigma)X}] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.27. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是**固定（但未知）的常数**，而区间 $[L, U]$ 是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 Chapter 4 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及（直方图估计）
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

简单区分：

场景	方法	章节
分布形式未知	非参数方法（直方图、核密度估计）	Chapter 10
分布形式已知、参数未知	参数方法（MLE、CI、检验）	Chapter 4

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 1. 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 2. 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 3. 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计（MLE）被提出的**动机**。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

具体例子：

- S^2 （无偏）和 $\hat{\sigma}^2$ （有偏，但 MLE）
- 两者都常用，但各有用途
- “最优”需要更精确的定义（后续章节的 UMVUE）

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

学习笔记.