

数理统计导论

Hogg, McKean, Craig

目录

Part 1. 概率论基础	5
引言：从随机性中学习	7
引言：从随机性中学习	7
1. 为什么需要概率论?	7
2. 教材内容预览	7
3. 这三章的内在逻辑	10
4. 学习方法建议	10
5. 习题说明	11
Chapter 1. Probability and Distributions	13
Chapter 1 Overview	13
1. 1.1 Introduction: Why Probability Theory?	13
2. 1.2 Sets: The Language of Uncertainty	14
3. 1.3 The Probability Set Function	15
4. 1.4 Conditional Probability and Independence	15
5. 1.5 Random Variables	17
6. 1.6 Discrete Random Variables	17
7. 1.7 Continuous Random Variables	19
8. 1.8 Expectation of a Random Variable	21
9. 1.9 Some Special Expectations	22
10. 1.10 Important Inequalities	24
Summary	25
Exercises	25
Chapter 2. 多元随机变量及其分布	29
Chapter 2 概述	29
1. 2.1 从一元到多元：联合分布	29
2. 2.2 边缘分布：积分即求和	31
3. 2.3 条件分布：信息的价值	33
4. 2.4 独立性：变量间的”无关系”	39
5. 2.5 相关性：线性关联的度量	42
6. 2.6 二元正态：最重要的二元分布	44

7. 2.7 多元推广	46
8. 本章总结	48
习题	48
Chapter 3. Special Distributions	51
Chapter 3 Overview	51
1. 3.1 The Binomial and Related Distributions	51
2. 3.2 The Poisson Distribution	57
3. 3.3 The Gamma, χ^2 , and Beta Distributions	58
4. 3.4 The Normal Distribution	62
5. 3.5 Multivariate Normal Distribution	64
6. 3.6 The t and F Distributions	65
Chapter Summary	67
Exercises	68
7. 附录：公式推导	69
Chapter 4. Some Elementary Statistical Inferences	77
Chapter 4 Overview	77
1. 4.1 Sampling and Statistics	77
2. 4.2 Point Estimation	78
3. 4.3 Confidence Intervals	80
4. 4.4 Hypothesis Testing	82
5. 4.5 Chi-Square Tests	83
6. 4.6 Monte Carlo Methods	83
7. 4.7 Bootstrap Methods	84
Exercises	84
本章小结	98
8. 附录：公式推导	99
1. 附录：公式推导	105
2. 问答记录	119

Part 1

概率论基础

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分的类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 notation，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 Overview

本章从概率论的公理化基础出发，逐步建立整套理论框架。这条脉络贯穿本书始终——理解随机现象的本质、建立描述分布的工具、掌握期望与矩的计算。

为什么从概率论开始？ 因为统计学的一切推断都建立在概率论的基础上。如果不理解概率的数学本质，就无法真正理解统计推断的逻辑。

本章路线图： 随机现象 → 概率公理 → 条件概率与独立性 → 随机变量 → 离散/连续分布 → 期望与矩 → 矩母函数 → 重要不等式

1. 1.1 Introduction: Why Probability Theory?

1.1. The Genesis of Probability. 概率论的故事始于一场赌博。1654 年，赌徒 Chevalier de Méré 向数学家 Blaise Pascal 提出一个问题：如果两名玩家在赌局中途中断，如何公平地分配赌金？这个问题引发了 Pascal 与 Pierre de Fermat 的通信，从而奠定了概率论的基础。

从频率到概率： 设想进行 N 次重复实验。事件 A 发生的次数记为 $f_N(A)$ ，则 $f_N(A)/N$ 称为相对频率 (relative frequency)。当 N 增大时， $f_N(A)/N$ 趋于稳定，趋向某个数 p ——这正是事件 A 的概率。Kolmogorov 在 1933 年的开创性著作《概率论基础》中将这种直觉严格化，建立了现代概率论的公理化体系。

两派观点： 概率的相对频率解释依赖于实验可重复的条件。另一种观点——贝叶斯学派——将概率视为主观信念的度量。无论采用哪种解释，概率的数学性质（公理）都是一致的，因此我们可以在坚实的数学基础上统一处理。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. Random Experiments and Sample Spaces. 若一个实验可以在相同条件下重复进行，且所有可能的结果可以在实验前描述，我们就称其为随机实验 (random experiment)。

所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

这三个例子揭示了样本空间的三种类型：离散有限（硬币）、离散无限（骰子）、连续（等待时间）。理解样本空间的类型决定了我们使用离散还是连续的数学工具。

EXAMPLE 1.1 (Coin Toss). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (Two Dice). 投掷一枚红骰子和一枚白骰子。样本空间包含 36 个有序对: $\mathcal{C} = \{(1, 1), (1, 2), \dots, (6, 6)\}$ 。

EXAMPLE 1.3 (Continuous Sample Space). 等待地铁到达的时间。样本空间为 $\mathcal{C} = (0, \infty)$ ——这是一个连续不可数的集合。

事件是样本空间的子集。如果一个实验进行一次, 事件 A 要么发生, 要么不发生, 没有第三种可能。概率论正是描述这种不确定性的数学语言。

2. 1.2 Sets: The Language of Uncertainty

2.1. Why Do We Need Set Theory for Probability? 在概率论中, 事件 (event) 本质上就是样本空间的子集。为什么要用集合的语言? 因为集合运算 (并、交、补) 完美地对应了事件的逻辑运算 (“或”、“且”、“非”)。

德摩根定律 (De Morgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c. \quad (1.2.1)$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C). \quad (1.2.2)$$

这些看似简单的定律, 在概率计算中非常有用。例如, 要计算 “既不是 A 也不是 B ” 的概率, 我们可以直接使用德摩根定律: $\mathbb{P}((A \cup B)^c) = \mathbb{P}(A^c \cap B^c)$ 。

2.2. Key Set Operations. 设 $\mathcal{C}$ 为样本空间, A, B, C 为事件:

- **补集** A^c : 所有不在 A 中的元素
- **并集** $A \cup B$: 至少在 A 或 B 之一中的元素
- **交集** $A \cap B$: 同时在 A 和 B 中的元素
- **不交** $A \cap B = \phi$: A 和 B 互不相容

EXAMPLE 1.4 (Set Operations). 设 $\mathcal{C} = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。

则 $A^c = \{3, 4, \dots, 10\}$, $A \cup B = \{1, 2, 3, 4\}$, $A \cap B = \{2\}$, $A \cap C = \phi$, $B \cap C = \{3, 4\}$ 。

2.3. Countable and Uncountable Sets. 若集合 C 是有限的, 或与正整数集等势, 则称 C 为可数的 (countable)。

可数并: $\cup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}$

可数交: $\cap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \cup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \cap_{n=1}^{\infty} A_n$ 。

3. 1.3 The Probability Set Function

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。

概率必须满足：

- (1) 非负性： $\mathbb{P}(A) \geq 0$
- (2) 规范化： $\mathbb{P}(\mathcal{C}) = 1$
- (3) 可数可加性：若 $A_1, A_2, \dots$ 两两不交，则 $\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$

REMARK. **概率公理的直观含义**：非负性说明概率不能为负；规范化说明必然事件的概率为 1；可数可加性说明互不相容事件的并的概率等于各自概率之和。

从这三条公理可以推导出概率的所有其他性质。¹

REMARK. **定理 1.3.1**：对每个事件 A ， $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ 。

证明：由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$ ，结合公理得

$$1 = \mathbb{P}(\mathcal{C}) = \mathbb{P}(A) + \mathbb{P}(A^c).$$

布尔不等式：对任意事件 $A_1, \dots, A_n$ ，

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i). \quad (1.3.1)$$

这在估计复合事件概率时非常有用——当精确计算困难时，布尔不等式提供了一个上界。

REMARK. **等可能性情形**：若样本空间 $\mathcal{C} = \{x_1, x_2, \dots, x_m\}$ 有限，且每个 *outcome* 等概率，则

$$\mathbb{P}(A) = \frac{\#(A)}{m}. \quad (1.3.2)$$

EXAMPLE 1.5 (扑克牌概率). 从 52 张扑克牌中随机抽取一张。设 $A =$ “抽到 A ”， $B =$ “抽到红桃”。则

$$\mathbb{P}(A) = \frac{4}{52}, \quad \mathbb{P}(B) = \frac{13}{52}, \quad \mathbb{P}(A \cap B) = \frac{1}{52}.$$

由容斥原理，

$$\mathbb{P}(A \cup B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52} = \frac{4}{13}.$$

4. 1.4 Conditional Probability and Independence

条件概率是概率论中最重要的概念之一。它描述了在已知某些信息发生的条件下，如何更新我们对其他事件概率的判断。

REMARK. **定义 1.4.1 (条件概率)**：设 $\mathbb{P}(B) > 0$ ，在事件 B 已发生的条件下，事件 A 的条件概率定义为

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (1.4.1)$$

¹详细推导见附录 ??。

条件概率满足概率的三条公理——它是一种新的概率度量，样本空间缩小为 B 。

乘法法则：

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) = \mathbb{P}(B) \cdot \mathbb{P}(A | B). \quad (1.4.2)$$

推广到 n 个事件：

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right). \quad (1.4.3)$$

REMARK. **全概率公式：** 设 $\{B_i\}$ 为 C 的一个划分，则对任意事件 A ,

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i). \quad (1.4.4)$$

REMARK. **贝叶斯公式：**

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i)}. \quad (1.4.5)$$

术语：

- $\mathbb{P}(B_j)$: 先验概率 (*prior probability*) ——在观测到 A 之前我们对 B_j 的信念
- $\mathbb{P}(B_j | A)$: 后验概率 (*posterior probability*) ——在观测到 A 之后我们对 B_j 的更新信念
- $\mathbb{P}(A | B_j)$: 似然 (*likelihood*) ——在 B_j 成立的条件下观测到 A 的概率

贝叶斯公式不仅是一个计算工具，更提供了一种思考不确定性的思维方式。²

EXAMPLE 1.6 (医学检测). 设某疾病患病率为 1%，检测准确率为 99%。令 $D =$ “患病”， $+$ = “检测阳性”。

即使检测准确率高达 99%，检测阳性者真正患病的概率只有 50%!

这个违反直觉的结果说明：在疾病罕见的情况下，即使非常准确的检测也可能产生大量假阳性。³

4.1. 1.4.1 Independence.

REMARK. **定义 1.4.2 (独立性)：** 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，则称 A 与 B 相互独立，记作 $A \perp B$ 。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时，独立性等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$ ——知道 B 发生并不改变 A 的概率。

EXAMPLE 1.7 (独立硬币). 抛掷两枚独立硬币。设 $A =$ “第一枚正面朝上”， $B =$ “第二枚正面朝上”。则 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$ ，且 $\mathbb{P}(A \cap B) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，故 $A \perp B$ 。

WARNING: 两两独立 (pairwise independent) 不一定意味着相互独立!⁴

²贝叶斯公式的深层意义见附录 ??。

³详细计算见附录 ??。

⁴反例见附录 ??。

5. 1.5 Random Variables

样本空间的元素可能不是数字——随机变量正是将样本空间数值化的工具。

REMARK. 定义 1.5.1 (随机变量): 随机变量是从样本空间 $\mathcal{C}$ 到实数的函数: $X: \mathcal{C} \rightarrow \mathbb{R}$ 。

通常用大写字母 X, Y, Z 表示随机变量, 用小写字母 x, y, z 表示具体取值。

随机变量可分为:

- 离散随机变量: 取值可数 (有限或无限)
- 连续随机变量: 取值充满区间, 不可数

给定随机变量 X , 它的取值空间 $\mathcal{D}$ 成为新的样本空间。 X 不仅诱导了新的样本空间, 还诱导了一个概率分布——这正是“分布”概念的起源。

EXAMPLE 1.8 (硬币投掷). 抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$ 。定义 X 为正面出现的次数: $X(HH) = 2, X(HT) = X(TH) = 1, X(TT) = 0$ 。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。

EXAMPLE 1.9 (均匀选择). 从区间 $(0, 1)$ 中随机选择一个数 X 。 X 是连续随机变量, 取值充满 $(0, 1)$ 。

5.1. Cumulative Distribution Function.

REMARK. 定义 1.5.2 (CDF): $F_X(x) = \mathbb{P}(X \leq x), -\infty < x < \infty$ 。

CDF 满足:

- (1) 非递减: 若 $x_1 < x_2$, 则 $F_X(x_1) \leq F_X(x_2)$
- (2) $\lim_{x \rightarrow -\infty} F_X(x) = 0, \lim_{x \rightarrow \infty} F_X(x) = 1$
- (3) 右连续: $F_X(x) = \lim_{t \rightarrow x^+} F_X(t)$

从 CDF 计算概率:

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a). \quad (1.5.1)$$

关键洞察: 对连续随机变量, $\mathbb{P}(X = x) = 0$, 因此

$$\mathbb{P}(a < X < b) = \mathbb{P}(a \leq X \leq b) = F(b) - F(a). \quad (1.5.2)$$

6. 1.6 Discrete Random Variables

离散随机变量的取值是可数的。

REMARK. 定义 1.6.1 (pmf): $p_X(x) = \mathbb{P}(X = x)$ 。

pmf 满足: $p_X(x) \geq 0$ 对所有 x , 且 $\sum_x p_X(x) = 1$ 。

6.1. 1.6.1 Common Discrete Distributions. 伯努利分布 $X \sim \text{Bernoulli}(p)$:

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p. \quad (1.6.1)$$

二项分布 $X \sim \text{Bin}(n, p)$:

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n. \quad (1.6.2)$$

EXAMPLE 1.10 (二项分布). 抛掷一枚均匀硬币 10 次。设 X 为正面出现的次数。则 $X \sim \text{Bin}(10, 0.5)$,

$$\mathbb{P}(X = 3) = \binom{10}{3} (0.5)^3 (0.5)^7 = \frac{120}{1024} \approx 0.117.$$

几何分布 $X \sim \text{Geom}(p)$:

$$\mathbb{P}(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, 3, \dots \quad (1.6.3)$$

几何分布具有“无记忆性”——等待时间不受过去等待的影响。⁵

EXAMPLE 1.11 (几何分布). 抛掷一枚均匀硬币直到第一次出现正面。设 X 为抛掷次数。则 $X \sim \text{Geom}(0.5)$,

$$\mathbb{P}(X = 3) = (0.5)^2 \cdot 0.5 = \frac{1}{8}.$$

泊松分布 $X \sim \text{Poisson}(\lambda)$:

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots \quad (1.6.4)$$

泊松分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限分布。⁶

这揭示了离散分布之间的深刻联系——泊松分布作为稀有事件的模型具有重要意义。

EXAMPLE 1.12 (泊松分布). 某医院每小时接到的急诊电话数服从泊松分布，均值 $\lambda = 3$ 。则

$$\mathbb{P}(\text{每小时接到 5 个电话}) = \frac{3^5 e^{-3}}{5!} \approx 0.101.$$

超几何分布 $X \sim \text{Hypergeometric}(N, K, n)$:

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}. \quad (1.6.5)$$

这是从有限总体中无放回抽样的模型。

EXAMPLE 1.13 (超几何分布). 一个盒子中有 20 个红球和 80 个白球 (共 100 个)。从中抽取 5 个 (无放回)。令 X 为抽到的红球数。则

$$\mathbb{P}(X = 2) = \frac{\binom{20}{2} \binom{80}{3}}{\binom{100}{5}}.$$

⁵详细证明见附录 ??。

⁶详细推导见附录 section 7.10。

6.2. 1.6.2 Transformations of Discrete Random Variables. 在统计中, 我们经常需要对一个随机变量进行变换: $Y = g(X)$ 。

一对一变换: 若 g 是一一对应的, 则

$$p_Y(y) = p_X(g^{-1}(y)). \quad (1.6.6)$$

非一对一变换: 需要合并所有映射到相同 y 的 x 的概率。

EXAMPLE 1.14 (离散变换). 设 $X \sim \text{Geom}(0.5)$, $Y = X^2$ 。因为 $g(x) = x^2$ 在 $\{1, 2, 3, \dots\}$ 上是一一对应的 (没有负数),

$$p_Y(y) = p_X(\sqrt{y}) = (0.5)^{\sqrt{y}+1}, \quad y = 1, 4, 9, \dots$$

7. 1.7 Continuous Random Variables

连续随机变量的取值充满一个或多个区间, 不可数。

REMARK. **定义 1.7.1 (连续随机变量):** 若随机变量 X 的 *cdf* $F_X(x)$ 对所有 x 都连续, 则称 X 为连续随机变量。

对连续随机变量, $\mathbb{P}(X = x) = 0$ 对所有 x ——这意味着单点概率为零。

REMARK. **定义 1.7.2 (pdf):** 若存在非负函数 $f_X(x)$ 使得

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x) dx$$

对任意 $a < b$ 成立, 则称 $f_X(x)$ 为 *pdf*。

pdf 满足: $f_X(x) \geq 0$ 对所有 x , 且 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。

WARNING: $f_X(x)$ 可以大于 1! 这与 *pmf* 的 $p_X(x) \leq 1$ 形成对比。pdf 的值不是概率, 而是概率密度——只有积分才是概率。

EXAMPLE 1.15 (均匀分布). 从区间 $(0, 1)$ 中随机选择一个数 X 。则 $X \sim \text{Uniform}(0, 1)$,

$$f_X(x) = \begin{cases} 1 & 0 < x < 1 \\ 0 & \text{otherwise} \end{cases}$$

EXAMPLE 1.16 (单位圆内的随机点). 在单位圆内随机选择一个点。设 X 为该点到原点的距离。则 X 的 *cdf* 为 $F_X(x) = x^2$, $0 \leq x \leq 1$ 。因此 *pdf* 为 $f_X(x) = 2x$, $0 < x < 1$ 。

EXAMPLE 1.17 (指数分布). 电话呼叫间隔时间 X 服从指数分布, *pdf* 为

$$f_X(x) = \frac{1}{4}e^{-x/4}, \quad x > 0.$$

则 $\mathbb{P}(X > 4) = \int_4^{\infty} \frac{1}{4}e^{-x/4} dx = e^{-1} \approx 0.368$ 。

指数分布也具有无记忆性。⁷

⁷详细讨论见附录 ??。

正态分布 $X \sim N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \quad (1.7.1)$$

正态分布是统计学中最重要的分布——这将在第三章详细讨论。

7.1. 1.7.1 Quantiles. 分位数是分布的重要特征。

REMARK. 定义 1.7.3 (分位数): 设 $0 < p < 1$. 分布的 $100p\%$ 分位数 ξ_p 满足

$$\mathbb{P}(X < \xi_p) \leq p \quad \text{且} \quad \mathbb{P}(X \leq \xi_p) \geq p. \quad (1.7.2)$$

特殊分位数:

- 中位数 (*median*): $\xi_{0.5}$
- 第一四分位数: $\xi_{0.25}$
- 第三四分位数: $\xi_{0.75}$

四分位距 (*IQR*): $q_3 - q_1$, 是衡量离散程度的稳健指标。

若 X 连续且 F_X 严格递增, 则 $\xi_p = F_X^{-1}(p)$ 。

偏度 (*Skewness*): 描述分布的不对称程度。

- 右偏 (*positively skewed*): 右尾较长, 如指数分布
- 左偏 (*negatively skewed*): 左尾较长
- 对称 (*symmetric*): 如正态分布

7.2. 1.7.2 Transformations of Continuous Random Variables. 设 X 是连续随机变量, $f_X(x)$ 已知。我们想知道 $Y = g(X)$ 的分布。

CDF 法: 先求 $F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y)$, 然后求导得 $f_Y(y) = \frac{d}{dy}F_Y(y)$ 。

EXAMPLE 1.18 (连续变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = X^2$ 。则对 $0 < y < 1$,

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(X \leq \sqrt{y}) = \sqrt{y}.$$

因此 $f_Y(y) = \frac{1}{2\sqrt{y}}$, $0 < y < 1$ 。

——变换公式: 若 $y = g(x)$ 是一一对应且可导的, $x = g^{-1}(y)$, 则

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy}g^{-1}(y) \right|, \quad y \in \mathcal{S}_Y. \quad (1.7.3)$$

这里 $\left| \frac{dx}{dy} \right|$ 称为雅可比 (Jacobian)。

EXAMPLE 1.19 (对数变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = -\log X$ 。则 $x = e^{-y}$, $dx/dy = -e^{-y}$ 。因此

$$f_Y(y) = 1 \cdot |-e^{-y}| = e^{-y}, \quad y > 0.$$

即 $Y \sim \text{Exp}(1)$ 。

这提供了从均匀分布生成指数分布的方法——逆变换采样 (*inverse transform sampling*) 的基础。⁸

⁸逆变换采样的详细讨论见第四章。

变换公式的证明：⁹

7.3. 1.7.3 Mixture Distributions. 有些分布既不是纯离散的，也不是纯连续的，而是两者的混合。

EXAMPLE 1.20 (混合分布). 设 X 的 cdf 为

$$F(x) = \begin{cases} 0 & x < 0 \\ \frac{x+1}{2} & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases}$$

则 $\mathbb{P}(X=0) = 1/2$ ，且对 $0 < x < 1$ ， $\mathbb{P}(0 < X < x) = x/2$ 。这是一个离散-连续混合分布。

这种分布在实际中经常出现，例如：

- 删失数据 (*censored data*)
- 保险中的限额保单

8. 1.8 Expectation of a Random Variable

期望是随机变量最重要的一致性度量。它描述了分布的”中心位置”。

REMARK. 定义 1.8.1 (数学期望):

- 离散型: $\mathbb{E}X = \sum x \cdot p_X(x)$
- 连续型: $\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$

要求级数或积分绝对收敛，即 $\mathbb{E}|X| < \infty$ 。

期望的起源：在赌博游戏中，”期望”(expectation)一词来源于玩家对游戏收益的长期平均预期。

公平游戏：若 $E(G) = 0$ ，则游戏是公平的 (fair game)。

EXAMPLE 1.21 (骰子期望). 设 X 为掷骰子的点数。则 $\mathbb{E}X = \frac{1}{6}(1+2+3+4+5+6) = 3.5$ 。

REMARK. 函数期望定理: 设 $Y = g(X)$ 。则

- 离散型: $\mathbb{E}Y = \sum g(x) \cdot p_X(x)$
- 连续型: $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx$

重要含义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！¹⁰

期望的线性性是概率论中最重要、最有用的性质之一。¹¹

⁹详细推导见附录 ??。

¹⁰详细证明见附录 ??。

¹¹详细证明见附录 section 1.5。

REMARK. 定理 1.8.1 (期望的线性性): 对任意随机变量 X, Y (期望存在) 和常数 a, b :

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y. \quad (1.8.1)$$

关键点: 无需 X, Y 相互独立!

EXAMPLE 1.22 (样本均值). 设 $X_1, \dots, X_n$ 是独立同分布的随机变量, $\mathbb{E}X_i = \mu$ 。则样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望为

$$\mathbb{E}\bar{X} = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \mu.$$

这说明样本均值是总体均值的无偏估计!¹²

乘积期望: 一般情况下 $\mathbb{E}(XY) \neq \mathbb{E}X \cdot \mathbb{E}Y$ 。只有当 X 和 Y 独立时, 等式才成立。

EXAMPLE 1.23 (乘积期望). 设 X 和 Y 是区间 $(0, 1)$ 上的均匀分布, 但 $Y = X$ (完全相关)。则 $\mathbb{E}(XY) = \mathbb{E}(X^2) = 1/3$, 而 $\mathbb{E}X \cdot \mathbb{E}Y = 1/4$, 两者不相等。

方差度量分布的离散程度。¹³

REMARK. 定理 1.8.2 (方差公式):

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}(X^2) - \mu^2. \quad (1.8.2)$$

方差性质:

$$(1) \text{var}(aX + b) = a^2 \text{var}(X)$$

$$(2) \text{若 } X_1, \dots, X_n \text{ 相互独立, 则 } \text{var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{var}(X_i)$$

9. 1.9 Some Special Expectations

某些期望具有特殊名称和重要意义。

9.1. Moments.

REMARK. 定义 1.9.1 (矩):

- k 阶原点矩: $\mu'_k = \mathbb{E}(X^k)$
- k 阶中心矩: $\mu_k = \mathbb{E}[(X - \mu)^k]$

一阶原点矩 $\mu'_1 = \mathbb{E}X$ 就是均值。

均值 (Mean): $\mu = \mathbb{E}X$ 是分布的中心位置度量。

方差 (Variance): $\sigma^2 = \text{var}(X)$ 度量分布的离散程度。

标准差 (Standard Deviation): $\sigma = \sqrt{\text{var}(X)}$, 与 X 具有相同单位。

变异系数 (CV): $\text{CV} = \sigma/\mu$, 是无量纲的离散程度度量。

偏度系数: $\gamma_1 = \mathbb{E}[(X - \mu)^3]/\sigma^3$, 衡量分布的不对称程度。

峰度系数: $\gamma_2 = \mathbb{E}[(X - \mu)^4]/\sigma^4 - 3$, 衡量分布尾部的厚重程度。

¹²这将在第四章统计推断中发挥核心作用。

¹³详细推导见附录 ??。

EXAMPLE 1.24 (均匀分布的矩). 设 $X \sim \text{Uniform}(-a, a)$ 。则

$$\mu = 0, \quad \text{var}(X) = \frac{a^2}{3}.$$

EXAMPLE 1.25 (指数分布的矩). 设 $X \sim \text{Exp}(\lambda)$ 。则

$$\mathbb{E}X = \frac{1}{\lambda}, \quad \text{var}(X) = \frac{1}{\lambda^2}.$$

9.2. Covariance and Correlation. 两个随机变量之间的”共同变化”程度，用协方差来度量。

REMARK. 定义 1.9.2 (协方差):

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y. \quad (1.9.1)$$

协方差性质:

- (1) $\text{cov}(X, X) = \text{var}(X)$
- (2) $\text{cov}(X, Y) = \text{cov}(Y, X)$
- (3) $\text{cov}(aX + b, Y) = a\text{cov}(X, Y)$
- (4) $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y)$
- (5) 若 $X \perp\!\!\!\perp Y$, 则 $\text{cov}(X, Y) = 0$

REMARK. 定义 1.9.3 (相关系数):

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}. \quad (1.9.2)$$

重要性质: $-1 \leq \text{corr}(X, Y) \leq 1$ 。

相关系数衡量两个变量之间的线性关系强度。

WARNING: 相关不等于因果! 两个变量相关可能是由于第三个隐藏变量导致的。

14

9.3. Moment Generating Function. 矩母函数是计算矩的强大工具。

REMARK. 定义 1.9.4 (矩母函数): 若对某个 $h > 0$,

$$M_X(t) = \mathbb{E}(e^{tX}) \quad \text{对 } -h < t < h \text{ 存在}, \quad (1.9.3)$$

则称 $M_X(t)$ 为 X 的矩母函数 (mgf)。

核心性质: 矩母函数唯一确定分布! 若两个随机变量的 mgf 相同, 则它们同分布。
为什么叫”矩母函数”? 因为

$$M_X^{(k)}(0) = \mathbb{E}(X^k). \quad (1.9.4)$$

这意味着如果我们有 mgf, 可以通过对它求导来获得所有矩!

¹⁴因果推断的讨论见本书因果推断部分。

EXAMPLE 1.26 (正态分布的 mgf). 设 $X \sim N(\mu, \sigma^2)$ 。则

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right).$$

特别地, $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - [M'(0)]^2 = \sigma^2$ 。

EXAMPLE 1.27 (泊松分布的 mgf). 设 $X \sim \text{Poisson}(\lambda)$ 。则

$$M_X(t) = \exp(\lambda(e^t - 1)).$$

mgf 的加法性质尤为重要: 若 $X_1, \dots, X_n$ 独立, 则

$$M_{X_1 + \dots + X_n}(t) = \prod_{i=1}^n M_{X_i}(t). \quad (1.9.5)$$

这提供了一种验证独立随机变量和的分布的方法。

10. 1.10 Important Inequalities

概率论中有几个基本不等式, 它们在理论证明和实际应用中都非常重要。

REMARK. 定理 1.10.1 (*Markov 不等式*): 若 X 为随机变量, $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}. \quad (1.10.1)$$

Markov 不等式的意义在于: 它仅用期望就能给出概率的上界, 而不需要知道分布的完整信息。¹⁵

REMARK. 定理 1.10.2 (*Chebyshev 不等式*): 设 $\mu = \mathbb{E}X$, $\sigma^2 = \text{var}(X)$ 。则对任意 $k > 0$,

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}. \quad (1.10.2)$$

Chebyshev 不等式告诉我们: 无论分布是什么, 至少 $1 - 1/k^2$ 的概率质量落在 $\mu \pm k\sigma$ 区间内。

EXAMPLE 1.28 (*Chebyshev 应用*). 设某考试成绩均值为 70, 标准差为 10。则根据 *Chebyshev* 不等式, 至少 75% 的学生成绩在 50 到 90 分之间。

Chebyshev 不等式虽然保守, 但在无法获知确切分布时是唯一可用的工具。它也是证明大数定律的关键工具。

REMARK. 定理 1.10.3 (*Cauchy-Schwarz 不等式*): 对于任意随机变量 X 和 Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}. \quad (1.10.3)$$

重要应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。¹⁶

Jensen 不等式: 若 g 是凸函数, 则 $\mathbb{E}[g(X)] \geq g(\mathbb{E}X)$ 。¹⁷

¹⁵详细证明见附录 ??。

¹⁶详细证明及更多应用见附录 ??。

¹⁷Jensen 不等式的证明及更多应用见附录 ??。

Summary

本章建立了概率论的基本框架，这些概念相互关联，共同构成了数理统计的基石：

- (1) **概率公理化** (1.3 节)：从相对频率的直观性质出发，建立了概率的严格数学定义
- (2) **条件概率与贝叶斯公式** (1.4 节)：提供了更新信息的数学工具，是统计推断的理论基础
- (3) **独立性** (1.4.1 节)：刻画了两个事件之间的概率关系
- (4) **随机变量** (1.5 节)：从集合论过渡到数值函数，为分布理论奠定基础
- (5) **离散与连续分布** (1.6-1.7 节)：建立了描述随机现象的主要分布类型 (Binomial, Poisson, Geometric, Normal, Exponential 等)
- (6) **变换与分位数** (1.6.2, 1.7.1-1.7.3 节)：提供了操作随机变量的技术工具
- (7) **期望与矩** (1.8-1.9 节)：分别度量分布的中心位置、离散程度和分布形状
- (8) **矩母函数** (1.9.3 节)：统一处理矩的强大工具，具有唯一性定理
- (9) **重要不等式** (1.10 节)：Markov、Chebyshev、Cauchy-Schwarz 是理论证明的基础工具

本章的核心思想：从随机现象出发，通过公理化定义建立概率论，用随机变量将样本空间数值化，然后用分布描述随机变量的行为，最后用期望等数字特征概括分布的关键性质。

与后续章节的联系：

- 第二章将概率论扩展到多个随机变量，研究联合分布、边缘分布、条件分布
- 第三章将详细介绍各种具体分布及其性质
- 第四章将利用这些工具进行统计推断（点估计、区间估计、假设检验）

Exercises

EXERCISE 1.1. 1.2.1 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$ ：

- (1) $C_1 = \{0, 1, 2\}$, $C_2 = \{2, 3, 4\}$
- (2) $C_1 = \{x : 0 < x < 2\}$, $C_2 = \{x : 1 \leq x < 3\}$

EXERCISE 1.2. 1.3.1 设 $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.4$, $\mathbb{P}(A \cap B) = 0.1$ 。求：

- (1) $\mathbb{P}(A \cup B)$
- (2) $\mathbb{P}(A | B)$
- (3) $\mathbb{P}(B | A)$

EXERCISE 1.3. 1.3.2 从 5 男 3 女中随机选 3 人。求恰好选到 2 名女生的概率。

EXERCISE 1.4. 1.4.1 某箱中有 5 个红球和 3 个白球。无放回地抽取 3 个球。求恰好抽到 2 个红球的概率。

EXERCISE 1.5. 1.4.2 设 A 和 B 是互不相容的事件， $\mathbb{P}(A) = 0.2$, $\mathbb{P}(B) = 0.3$ 。求 $\mathbb{P}(A \cup B)$ 、 $\mathbb{P}(A^c)$ 、 $\mathbb{P}((A \cup B)^c)$ 。

EXERCISE 1.6. 1.5.1 设 X 的 *cdf* 为

$$F(x) = \begin{cases} 0 & x < 0 \\ x/2 & 0 \leq x < 1 \\ 1/2 & 1 \leq x < 2 \\ 1 & x \geq 2 \end{cases}$$

求 $\mathbb{P}(0 < X \leq 1)$ 、 $\mathbb{P}(X = 1)$ 、 $\mathbb{P}(X > 1/2)$ 。

EXERCISE 1.7. 1.6.1 设 $X \sim \text{Binomial}(10, 0.3)$ 。求：

- (1) $\mathbb{P}(X = 3)$
- (2) $\mathbb{P}(X \geq 2)$
- (3) $\mathbb{E}X$

EXERCISE 1.8. 1.6.2 设 $X \sim \text{Poisson}(4)$ 。求 $\mathbb{P}(X = 0)$ 、 $\mathbb{P}(X \leq 2)$ 、 $\mathbb{E}X$ 。

EXERCISE 1.9. 1.6.3 设 $X \sim \text{Geometric}(0.4)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.10. 1.6.4 设 $X \sim \text{Binomial}(5, 0.5)$ ， $Y = X^2$ 。求 Y 的 *pmf*。

EXERCISE 1.11. 1.7.1 设 $X \sim N(100, 225)$ 。求：

- (1) $\mathbb{P}(X < 95)$
- (2) $\mathbb{P}(90 < X < 110)$
- (3) $\mathbb{P}(X > 115)$

EXERCISE 1.12. 1.7.2 设 $X \sim \text{Exp}(2)$ 。求：

- (1) $\mathbb{P}(X > 1)$
- (2) $\mathbb{P}(X < 0.5)$
- (3) 50% 分位数 (中位数)

EXERCISE 1.13. 1.7.3 设 $X \sim \text{Uniform}(0, 1)$ ， $Y = -\log X$ 。证明 $Y \sim \text{Exp}(1)$ 。

EXERCISE 1.14. 1.7.4 设 $X \sim N(0, 1)$ ， $Y = e^X$ 。求 Y 的 *pdf* (这是对数正态分布)。

EXERCISE 1.15. 1.8.1 设 X 的 *pdf* 为 $f(x) = 3x^2$ ， $0 < x < 1$ 。求 $\mathbb{E}X$ 、 $\mathbb{E}(X^2)$ 、 $\text{var}(X)$ 。

EXERCISE 1.16. 1.8.2 设 $X \sim \text{Poisson}(\lambda)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.17. 1.8.3 设 X 和 Y 是独立同分布的随机变量， $\mathbb{E}X = \mu$ ， $\text{var}(X) = \sigma^2$ 。求 $\text{var}(X - Y)$ 和 $\text{var}(X + Y)$ 。

EXERCISE 1.18. 1.9.1 设 $X \sim N(\mu, \sigma^2)$ 。求 X 的 *mgf*，并验证它产生正确的均值和方差。

EXERCISE 1.19. 1.9.2 设 X 和 Y 独立, $X \sim \text{Poisson}(2)$, $Y \sim \text{Poisson}(3)$ 。求 $X+Y$ 的分布。

EXERCISE 1.20. 1.10.1 设 $\mathbb{E}X = 100$, $\text{var}(X) = 25$ 。用 *Chebyshev* 不等式给出 $\mathbb{P}(|X - 100| \geq 10)$ 的上界, 并用 *Markov* 不等式给出另一个上界。

EXERCISE 1.21. 1.10.2 用 *Cauchy-Schwarz* 不等式证明: 若 $\mathbb{E}(X^2) = \mathbb{E}(Y^2) = 1$, 则 $|\mathbb{E}(XY)| \leq 1$ 。

CHAPTER 2

多元随机变量及其分布

Chapter 2 概述

在一元情形，我们用 cdf $F_X(x) = \mathbb{P}(X \leq x)$ 描述单个随机变量的行为。但在许多场景中，单个变量的分布并不能回答我们的问题——我们需要知道多个变量如何共同变化。

为什么需要联合分布？ 例如，在经济学中，我们关心收入与教育年限的共同分布；在医学中，我们关心血压与胆固醇的联合水平；在金融中，资产收益率之间的相关性是风险管理的核心。这些问题都涉及多个随机变量的联合行为。

统计推断的核心任务——从样本推断总体——本质上也是多元的：样本是多个观测值的向量，而统计量是这些观测值的函数。第 4 章将看到，点估计、置信区间、假设检验全部建立在多元分布理论之上。

本章路线图： 联合分布 $\rightarrow$ 边缘分布 $\rightarrow$ 条件分布 $\rightarrow$ 独立性 $\rightarrow$ 相关性 $\rightarrow$ 多元正态 $\rightarrow$ 多元推广

1. 2.1 从一元到多元：联合分布

1.1. 为什么需要联合分布？ 在一元情形，我们学会了用 cdf、pmf/pdf 描述单个随机变量的行为。但在真实世界中，变量很少孤立存在。

核心问题： 给定两个随机变量 X_1 和 X_2 ，如何描述它们的联合行为？

例如，设 X_1 为身高， X_2 为体重。知道身高分布和体重分布当然有用，但知道两者如何“共同变化”——高个子是否倾向于更重——显然更有价值。这种“共同变化”的数学表达，正是联合分布。

历史注记： 多元分析的思想可以追溯到 Francis Galton (1822-1911) 的工作。他研究遗传问题时发现，单个特征的分布不足以描述遗传规律——必须考虑特征之间的相关性。他发明的“相关系数” (correlation coefficient) 正是本章的核心概念之一。

1.2. 随机向量与联合分布.

DEFINITION 2.1 (随机向量). 设样本空间为 $\mathcal{C}$ ， X_1 和 X_2 为定义在 $\mathcal{C}$ 上的两个随机变量。则 (X_1, X_2) 称为随机向量，其取值空间为 $\mathcal{D} = \{(x_1, x_2) : x_1 = X_1(c), x_2 = X_2(c), c \in \mathcal{C}\}$ 。

联合 cdf 是一元 cdf 的自然推广：

$$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2). \quad (1)$$

注意：这里的“且” ($,$) 表示两个事件同时发生。

离散型用 pmf 描述:

$$p_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 = x_1, X_2 = x_2), \quad (2)$$

满足 $p \geq 0$ 且 $\sum \sum_{\mathcal{D}} p = 1$ 。

连续型用 pdf 描述:

$$f_{X_1, X_2}(x_1, x_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f(w_1, w_2) dw_1 dw_2, \quad (3)$$

其中 $f \geq 0$ 且 $\int \int_{\mathcal{D}} f = 1$ 。

emark **警告**: 与一元情形不同, 这里的 $f(x_1, x_2)$ 可以大于 1! 因为它是“密度”而非概率值。emark

几何直观: 若把联合 pdf $z = f(x_1, x_2)$ 视作一张曲面, 则 $\mathbb{P}((X_1, X_2) \in A)$ 就是该曲面下区域 A 上的体积。这是一元情形“曲线下面积”在二维的推广。

1.3. R 计算: 联合分布.

EXAMPLE 2.1 (二元正态概率计算). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.5)$ 。求 $\mathbb{P}(X_1 \leq 0, X_2 \leq 0)$ 。

在 R 中使用 *mvtnorm* 包:

```
install.packages("mvtnorm")
library(mvtnorm)
```

二元正态 CDF

```
pmvnorm(lower = c(-Inf, -Inf), upper = c(0, 0),
         mean = c(0, 0), sigma = matrix(c(1, 0.5, 0.5, 1), nrow = 2))
```

EXAMPLE 2.2 (生成二元正态样本). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.8)$ 。生成 $n = 1000$ 的样本并可视化。

```
library(mvtnorm)
n <- 1000
rho <- 0.8
sigma <- matrix(c(1, rho, rho, 1), nrow = 2)
set.seed(42)
sample <- rmvnorm(n, mean = c(0, 0), sigma = sigma)
```

绘制散点图

```
plot(sample, xlab = expression(X[1]), ylab = expression(X[2]),
     main = bquote(rho == .(rho)), pch = 20, cex = 0.5)
```

计算样本相关系数

```
cor(sample[,1], sample[,2])
```

不同 ρ 值的散点图形态：

- $\rho = 0$ ：分布呈圆形，变量独立
- $\rho > 0$ ：分布沿主对角线 ($x_2 = x_1$) 拉伸
- $\rho < 0$ ：分布沿副对角线 ($x_2 = -x_1$) 拉伸
- $|\rho| \rightarrow 1$ ：分布越来越集中在一条直线附近

2. 2.2 边缘分布：积分即求和

2.1. 核心问题：如何从联合分布得到边缘分布？ 我们已经知道 (X_1, X_2) 的联合分布，自然会问：如何得到单个 X_1 的分布？

直觉上，我们需要“忽略” X_2 的信息。具体做法是：

- **离散型**：对 x_2 求和
- **连续型**：对 x_2 积分

这引导我们得到边缘分布公式。¹

边缘 pmf:

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2). \quad (4)$$

边缘 pdf:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2. \quad (5)$$

emark 为什么叫“边缘”？ 在二维离散情形，将联合 pmf 列表，边缘分布恰好是每行（或每列）的“边缘”之和。这解释了名称的由来。emark

一个重要发现： 已知联合分布可以推出边缘分布，但反过来不成立——边缘分布丢失了变量之间的依赖信息。例如，两个不同的联合分布可能有相同的边缘分布。

EXAMPLE 2.3 (不同联合分布有相同边缘分布). 设 (X_1, X_2) 和 (Y_1, Y_2) 有相同的边缘分布，但不同的联合结构。实际上，如果不知道联合分布，就无法回答“两个变量是否相关”这样的问题。

2.2. R 计算：边缘分布. 边缘分布在 R 中通过逐行或逐列求和（离散）或积分（连续）计算。

EXAMPLE 2.4 (离散边缘分布). 设 (X_1, X_2) 的联合 pmf 如下（列联表形式）：

$X_2 \backslash X_1$	1	2	3	4	边缘
1	0.05	0.10	0.05	0.02	?
2	0.08	0.15	0.12	0.05	?
3	0.02	0.08	0.10	0.08	?
边缘	?	?	?	?	1.00

¹推导见附录 section 1.4。

则 X_1 的边缘 *pmf* 为每列之和:

$$p_{X_1}(1) = 0.05 + 0.08 + 0.02 = 0.15, \quad p_{X_1}(2) = 0.10 + 0.15 + 0.08 = 0.33, \quad \text{等等}$$

R 计算:

```
# 联合 pmf (矩阵形式)
joint <- matrix(c(0.05, 0.08, 0.02, # X1=1
                  0.10, 0.15, 0.08, # X1=2
                  0.05, 0.12, 0.10, # X1=3
                  0.02, 0.05, 0.08), # X1=4
               nrow = 3, byrow = FALSE)
colnames(joint) <- c("X1=1", "X1=2", "X1=3", "X1=4")
rownames(joint) <- c("X2=1", "X2=2", "X2=3")

# 边缘分布 (按行、按列求和)
margin_x1 <- colSums(joint) # X1 的边缘 pmf
margin_x2 <- rowSums(joint) # X2 的边缘 pmf

# 验证: 边缘分布之和为 1
sum(margin_x1) # = 1
sum(margin_x2) # = 1
```

EXAMPLE 2.5 (连续边缘分布). 设 (X_1, X_2) 的联合 *pdf* 为

$$f(x_1, x_2) = \begin{cases} 8x_1x_2 & 0 < x_1 < x_2 < 1, \\ 0 & \text{otherwise.} \end{cases}$$

求 X_1 的边缘 *pdf*。

由于 $0 < x_1 < x_2 < 1$, x_2 的取值范围是 $x_1 < x_2 < 1$, 因此:

$$f_{X_1}(x_1) = \int_{x_1}^1 8x_1x_2 dx_2 = 8x_1 \left[\frac{x_2^2}{2} \right]_{x_2=x_1}^{x_2=1} = 8x_1 \cdot \frac{1-x_1^2}{2} = 4x_1(1-x_1^2),$$

其中 $0 < x_1 < 1$ 。

验证:

$$\int_0^1 4x_1(1-x_1^2) dx_1 = 4 \left[\frac{x_1^2}{2} - \frac{x_1^4}{4} \right]_0^1 = 4 \left(\frac{1}{2} - \frac{1}{4} \right) = 1.$$

R 数值验证:

```
# 验证边缘 pdf 的数值积分
f_marginal_x1 <- function(x1) {
  f <- function(x2) 8 * x1 * x2
  integrate(f, lower = x1, upper = 1)$value
}
```



```
# 在几个点验证
x1_vals <- c(0.2, 0.5, 0.8)
sapply(x1_vals, f_marginal_x1) # 应该接近 4*x1*(1-x1^2)
4 * x1_vals * (1 - x1_vals^2)
```

2.3. 边缘分布的深度理解. 为什么边缘分布重要? 边缘分布在实际应用中有广泛用途：

1. 人口统计学：当我们研究”收入”与”教育年限”的联合分布时，边缘分布给出了各变量的边缘分布——即不考虑另一变量时该变量的分布。这相当于”总体”的分布。

2. 保险精算：在汽车保险中，我们关心”理赔次数”与”理赔金额”的联合分布，但边缘分布分别给出了理赔次数的分布和理赔金额的分布——这两个分布本身就有独立的应用价值。

3. 信号处理：在处理二元信号时，边缘分布给出了各分量信号的分布，这在单独分析各分量时有用。

信息损失：一个关键事实是，从联合分布到边缘分布会丢失信息。如果只知道边缘分布，则无法恢复联合分布——因为这需要知道变量之间的依赖结构。

Clayton 模型：在金融保险中，Clayton copula 正是用来说明：相同的边缘分布可以对应于不同的联合分布。这个事实在风险管理中非常重要——仅知道各变量的边缘分布是不够的。

3. 2.3 条件分布：信息的价值

3.1. 条件分布的核心思想. 核心问题：已知 X_1 的值， X_2 的分布会如何变化？

这就是条件分布要回答的问题。条件分布本质上是在 $X_1 = x_1$ 的条件下，重新审视 X_2 的行为——这是贝叶斯思维在随机变量层面的延伸。

离散型条件 pmf: ²

$$p_{X_2|X_1}(x_2 | x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}, \quad p_{X_1}(x_1) > 0. \quad (6)$$

连续型条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}, \quad f_{X_1}(x_1) > 0. \quad (7)$$

分子是联合密度，分母是边缘密度。这个比值衡量的是，在 $X_1 = x_1$ 的条件下， (x_1, x_2) 这个”点”有多”典型”。

注意：在连续情形， $\mathbb{P}(X_1 = x_1) = 0$ ，所以不能直接用条件概率定义。这里用条件密度代替——条件密度的定义源自 Radon-Nikodym 定理，它是条件期望存在性的数学基础。³

²推导见附录 section 1.7。

³条件密度的严格数学讨论见附录 ??。

由此定义条件期望：

$$\mathbb{E}[u(X_2) | x_1] = \int_{-\infty}^{\infty} u(x_2) f_{X_2|X_1}(x_2 | x_1) dx_2. \quad (8)$$

条件期望 $\mathbb{E}[X_2 | X_1 = x_1]$ 是 x_1 的函数，可以理解为 X_1 取某个值时 X_2 的最佳预测。

3.2. 全期望公式与方差分解. 这里有一个深刻的定理，它连接了条件与边缘。⁴

THEOREM 2.1 (全期望公式).

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2). \quad (2.3.1)$$

含义：对条件均值再取期望，等于无条件期望。这看起来显而易见，但它是概率论中最强大的工具之一。

更惊人的是方差的不等式：⁵

THEOREM 2.2 (条件方差公式).

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)]. \quad (2.3.2)$$

直观理解：总方差等于“平均条件方差”加上“条件均值的方差”。第一项度量 X_2 在给定 X_1 后的残余不确定性；第二项度量 X_1 带来的不确定性。

Rao-Blackwell 定理：若用 X_2 估计 $\mu_2 = \mathbb{E}X_2$ ，则条件均值 $\mathbb{E}(X_2 | x_1)$ 比 X_2 本身更精确（方差更小）。这在统计推断中极其重要——它告诉我们如何利用辅助信息改进估计。⁶

3.3. R 计算：条件分布.

EXAMPLE 2.6 (离散条件分布). 设 (X_1, X_2) 的联合 pmf 如下：

$$p_{X_1, X_2}(x_1, x_2) = \frac{1}{8}, \quad x_1 = 1, 2, \quad x_2 = 1, 2, 3, 4.$$

求条件分布 $\mathbb{P}(X_2 = x_2 | X_1 = 1)$ 。

边缘分布 $p_{X_1}(1) = \sum_{x_2=1}^4 \frac{1}{8} = \frac{4}{8} = \frac{1}{2}$ 。

条件分布：

$$\mathbb{P}(X_2 = x_2 | X_1 = 1) = \frac{p_{X_1, X_2}(1, x_2)}{p_{X_1}(1)} = \frac{1/8}{1/2} = \frac{1}{4}, \quad x_2 = 1, 2, 3, 4.$$

因此，给定 $X_1 = 1$ 时， X_2 均匀分布于 $\{1, 2, 3, 4\}$ 。

⁴推导见附录 section 1.8。

⁵推导见附录 section 1.9。

⁶Rao-Blackwell 定理的详细讨论见附录 ??。

EXAMPLE 2.7 (连续条件分布). 设 (X_1, X_2) 服从二元正态 $N(0, 0, 1, 1, 0.5)$ 。求条件分布 $f_{X_2|X_1}(x_2 | x_1 = 0.5)$ 。

由公式 (2.6.1):

$$X_2 | X_1 = 0.5 \sim N\left(0 + 0.5 \cdot \frac{1}{1}(0.5 - 0), 1 \cdot (1 - 0.5^2)\right) = N(0.25, 0.75).$$

R 验证:

条件分布参数

```
mu2_given_x1 <- 0 + 0.5 * (0.5 - 0) # = 0.25
```

```
sigma2_sq <- 1 * (1 - 0.5^2) # = 0.75
```

在 R 中绘制条件密度

```
curve(dnorm(x, mu2_given_x1, sqrt(sigma2_sq)),
      from = -2, to = 2,
      xlab = expression(x[2]), ylab = "Density",
      main = expression(paste("Conditional density of ", X[2], " | ", X[1], " = 0.5"))
```

3.4. 条件分布的实际应用. 条件分布在统计建模中有广泛应用:

1. 回归分析: 条件均值 $\mathbb{E}(Y | X = x)$ 正是回归函数。线性回归假设 $\mathbb{E}(Y | X = x) = \alpha + \beta x$, 但更一般地, 任何条件均值函数都可以作为回归目标。

2. 分层抽样: 在抽样设计中, 我们经常按子群 (strata) 分组。子群内的条件分布描述了组内变异, 而边缘分布描述了总体变异。方差分解公式 (2.3.2) 正是这种思想的数学表达。

3. 贝叶斯统计: 后验分布 $f(\theta | x)$ 是在观测数据 x 的条件下参数 θ 的条件分布。整个贝叶斯推断都建立在条件分布的理论之上。

3.5. R 计算: 条件分布的应用. 继续展示条件分布在 R 中的实际计算。

[二元正态条件分布可视化] 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.7)$ 。绘制不同 x_1 条件下 X_2 的条件密度。

```
library(mvtnorm)
```

```
library(ggplot2)
```

设置参数

```
mu1 <- mu2 <- 0
```

```
sigma1 <- sigma2 <- 1
```

```
rho <- 0.7
```

条件分布参数

```
cond_mean <- function(x1) mu2 + rho * (sigma2/sigma1) * (x1 - mu1)
```

```
cond_var <- sigma2^2 * (1 - rho^2)
```

```

# 绘制条件密度
x1_vals <- c(-2, -1, 0, 1, 2)
colors <- c("blue", "green", "red", "orange", "purple")

plot(NULL, xlim = c(-4, 4), ylim = c(0, 0.5),
      xlab = expression(x[2]), ylab = "Density",
      main = "Conditional densities of X2 given X1")

for (i in seq_along(x1_vals)) {
  curve(dnorm(x, cond_mean(x1_vals[i]), sqrt(cond_var)),
        add = TRUE, col = colors[i], lwd = 2)
  abline(v = cond_mean(x1_vals[i]), col = colors[i], lty = 2)
}

legend("topright", legend = paste("X1 =", x1_vals),
      col = colors, lwd = 2, cex = 0.8)

```

观察：条件均值随 x_1 线性变化（回归效应），条件方差保持不变（正态分布的特殊性质）。

[分层抽样的方差分解] 设某大学有 10000 名学生，按专业分为 5 个阶层（strata）。我们想估计学生的平均每周学习时间。

假设各阶层的样本均值和方差如下：

专业	n_h	$\bar{X}_h$	s_h^2
理工	3000	20	25
文科	2500	25	20
商科	2000	22	30
法学	1500	18	15
医学	1000	28	35

边缘分布的方差分解：

$$\text{var}(\bar{X}) = \mathbb{E}[\text{var}(X | H)] + \text{var}[\mathbb{E}(X | H)].$$

第一项（层内方差）是各阶层方差的加权平均：

$$\mathbb{E}[\text{var}(X | H)] = \sum_h \frac{n_h}{N} s_h^2.$$

第二项（层间方差）是各阶层均值方差的加权平均：

$$\text{var}[\mathbb{E}(X | H)] = \sum_h \frac{n_h}{N} (\bar{X}_h - \bar{X})^2,$$

其中 $\bar{X}$ 是总体均值。

R 计算：

```
# 阶层数据
n_h <- c(3000, 2500, 2000, 1500, 1000)
Xbar_h <- c(20, 25, 22, 18, 28)
s2_h <- c(25, 20, 30, 15, 35)
N <- sum(n_h)

# 总体均值
Xbar <- sum(n_h * Xbar_h) / N

# 层内方差期望
within_var <- sum(n_h * s2_h) / N

# 层间方差
between_var <- sum(n_h * (Xbar_h - Xbar)^2) / N

# 总方差
total_var <- within_var + between_var

# 分层抽样估计的方差
# 简单随机抽样的方差（比较基准）
srs_var <- total_var / N # 简单随机抽样

# 分层抽样的效率
strat_efficiency <- srs_var / (within_var/N)
cat("层内方差期望:", within_var, "\n")
cat("层间方差:", between_var, "\n")
cat("总方差:", total_var, "\n")
cat("分层抽样相对效率:", round(strat_efficiency, 2), "倍\n")
```

3.6. 条件分布的贝叶斯视角。 贝叶斯统计的核心思想是：参数 θ 也是随机变量，我们应该用条件分布来描述我们对参数的认知。

先验分布： θ 在观测数据之前的分布，记作 $f(\theta)$ 。

似然函数： $L(\theta | x) = f(x | \theta)$ ，描述数据如何更新我们对 θ 的认知。

后验分布：⁷

$$f(\theta | x) = \frac{f(x | \theta)f(\theta)}{f(x)},$$

其中 $f(x) = \int f(x | \theta)f(\theta) d\theta$ 是归一化常数。

⁷推导见附录 ??。

后验均值： $\mathbb{E}(\theta | x)$ 是贝叶斯估计量，它优于普通样本均值——尤其在样本量较小时。

后验方差： $\text{var}(\theta | x)$ 度量了参数估计的不确定性。它在统计决策理论和置信区间构建中都有重要应用。

历史注记：Thomas Bayes (1702-1761) 在其论文《An Essay Towards Solving a Problem in the Doctrine of Chances》中首次提出了贝叶斯公式。拉普拉斯 (Laplace) 后来独立发展了贝叶斯方法，并将其应用于天文学、人口统计等领域。贝叶斯方法在 20 世纪经历了从被忽视到复兴的过程——部分原因是计算限制（马尔可夫链蒙特卡洛方法解决了这个问题），部分原因是哲学层面的争论。⁸

[Beta-Binomial 共轭] 设 $X | \theta \sim \text{Binomial}(n, \theta)$, $\theta \sim \text{Beta}(\alpha, \beta)$ 。

则后验分布为

$$\theta | X = x \sim \text{Beta}(\alpha + x, \beta + n - x).$$

后验均值为

$$\mathbb{E}(\theta | X = x) = \frac{\alpha + x}{\alpha + \beta + n}.$$

这个估计量是样本比例 $\hat{p} = x/n$ 和先验均值 $\frac{\alpha}{\alpha + \beta}$ 的加权平均——数据越多，权重越倾向于数据一方。

R 验证：

```
# 先验参数
```

```
alpha <- 2
```

```
beta <- 3
```

```
# 观测数据
```

```
n <- 10
```

```
x <- 7
```

```
# 后验参数
```

```
alpha_post <- alpha + x
```

```
beta_post <- beta + n - x
```

```
# 后验均值
```

```
post_mean <- alpha_post / (alpha_post + beta_post)
```

```
# 样本比例
```

```
sample_prop <- x / n
```

```
# 先验均值
```

```
prior_mean <- alpha / (alpha + beta)
```

⁸贝叶斯方法的详细历史讨论见附录 ??。

```
# 贝叶斯估计量（后验均值）
cat("先验均值:", prior_mean, "\n")
cat("样本比例:", sample_prop, "\n")
cat("后验均值:", post_mean, "\n")
cat("后验均值 = (n/(n++)) * 样本比例 + ((+)/(n++)) * 先验均值\n")
cat("= (10/15)*0.7 + (5/15)*0.4 =", 10/15*0.7 + 5/15*0.4, "\n")
```

4. 2.4 独立性：变量间的“无关系”

4.1. 什么时候 X_1 和 X_2 互不影响? 若 X_1 与 X_2 独立，则知道 X_1 的值不会改变我们对 X_2 的认知。用条件分布的语言：

$$f_{X_2|X_1}(x_2 | x_1) = f_{X_2}(x_2) \quad (\text{不依赖于 } x_1) .$$

由此推出联合密度可分离。⁹

THEOREM 2.3 (独立性).

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv f_1(x_1)f_2(x_2). \quad (2.4.1)$$

一个实用的判据：

THEOREM 2.4 (独立性因子化判据).

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv g(x_1)h(x_2) \quad (\text{可分离变量}) . \quad (2.4.2)$$

独立性的后果：

- $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$
- $\text{cov}(X_1, X_2) = 0$

emark **逆命题不成立!** $\text{cov}(X_1, X_2) = 0$ 并不意味着独立性（除二元正态分布外）。
emark

这提醒我们：**不相关**（uncorrelated）和**独立**（independent）是两个不同概念。不相关只说明没有线性关系，但变量间可能存在非线性依赖。

一个经典反例：设 $X \sim \text{Uniform}(-1, 1)$, $Y = X^2$ 。则 $\text{cov}(X, Y) = 0$ （因为 X 对称），但 Y 完全由 X 决定——它们显然不独立。¹⁰

⁹推导见附录 section 1.10。

¹⁰更多反例见附录 ??。

4.2. 独立的实际意义. 独立性在统计推断中极其重要, 因为:

1. **简化计算:** 若 $X_1 \perp\!\!\!\perp X_2$, 则

$$\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)],$$

这大大简化了期望的计算。

2. **分解问题:** 在许多统计问题中, 我们假设观测独立。这使得复杂问题可以分解为简单问题的组合。

3. **乘积分布:** 若 $X_1 \perp\!\!\!\perp X_2$, 则联合分布是边缘分布的乘积——这是一个优雅的结构性陈述。

4.3. R 计算: 独立性检验. 在实际数据分析中, 我们经常需要检验两个变量是否独立。

EXAMPLE 2.8 (独立性检验). 使用卡方检验检验两个分类变量的独立性:

创建列联表

```
smoking <- c(rep("Yes", 45), rep("No", 105))
cancer <- c(rep("Yes", 20), rep("No", 25), rep("Yes", 15), rep("No", 90))
table <- matrix(c(20, 25, 15, 90), nrow = 2, byrow = TRUE)
colnames(table) <- c("Cancer Yes", "Cancer No")
rownames(table) <- c("Smoking Yes", "Smoking No")
```

卡方检验

```
chisq.test(table)
```

Fisher 精确检验: 当样本量较小时, 使用 Fisher 精确检验比卡方检验更可靠:

```
fisher.test(table)
```

4.4. 独立性的深入理解. 为什么独立性如此重要? 独立性假设是现代统计推断的基石之一。

1. **计算简化:** 若 $X_1 \perp\!\!\!\perp X_2$, 则

$$\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)].$$

这大大简化了期望的计算。

2. **分解简化:** 在许多统计问题中, 我们假设观测独立。这使得复杂问题可以分解为简单问题的组合。例如, 样本均值 $\bar{X} = n^{-1} \sum X_i$ 的方差, 当 X_i 独立同分布时, 为 $\text{var}(\bar{X}) = \sigma^2/n$ 。没有独立性, 这个公式不成立。

3. **乘积分布:** 若 $X_1 \perp\!\!\!\perp X_2$, 则联合分布是边缘分布的乘积——这是一个优雅的结构性陈述。

独立性的判别: 在实际问题中, 我们如何判断两个变量是否独立?

1. **因子化判据:** 若联合 pdf/pmf 可以写成 $f(x_1, x_2) = g(x_1)h(x_2)$ 的形式, 则 X_1 与 X_2 独立。

2. 条件分布判据：若条件分布等于边缘分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_2}(x_2)$ ，则独立。

3. 协方差判据（反向）：若 $\text{cov}(X_1, X_2) \neq 0$ ，则一定不独立。但 $\text{cov}(X_1, X_2) = 0$ 不能推出独立（除特殊情况外）。

独立 vs 不相关：这是一个极其重要的区别。

不相关 (uncorrelated) 只说明没有线性关系： $\text{cov}(X_1, X_2) = 0$ 。

独立 (independent) 意味着知道一个变量的值对另一个变量的分布没有任何影响。

独立 $\Rightarrow$ 不相关，但反过来一般不成立。

二元正态的特殊性：在二元正态分布中，不相关 $\iff$ 独立。这是因为二元正态的联合分布完全由一阶矩和二阶矩决定。

在其他分布中：对于非正态分布， $\text{cov} = 0$ 但不独立是可能的。

反例： X 与 $Y = X^2$ ：设 $X \sim \text{Uniform}(-1, 1)$ ， $Y = X^2$ 。则 $\text{cov}(X, Y) = 0$ ，但显然 Y 完全由 X 决定，不独立。¹¹

[独立性检验的更多方法] 在实际数据分析中，独立性检验方法的选择取决于数据。

1. 连续变量的 Pearson 相关系数检验：

```
# 检验 X 和 Y 是否独立（假设二元正态）
x <- rnorm(100, mean = 0, sd = 1)
y <- 0.5 * x + rnorm(100, mean = 0, sd = sqrt(1 - 0.5^2))
cor.test(x, y, method = "pearson")
```

2. 秩相关 (Spearman 和 Kendall)：对非正态数据更鲁棒：

```
# Spearman 秩相关
cor.test(x, y, method = "spearman")
```

```
# Kendall tau 相关
cor.test(x, y, method = "kendall")
```

3. 互信息：度量变量的整体依赖关系（包括非线性）：

```
# 计算互信息（需要 infotheo 包）
library(infotheo)
discretize(cbind(x, y))
mutualinformation(discretize(cbind(x, y)))
```

4. χ^2 检验：适用于分类变量：

```
# 创建列联表
smoke <- c(rep("Yes", 45), rep("No", 105))
cancer <- c(rep("Yes", 20), rep("No", 25), rep("Yes", 15), rep("No", 90))
table <- matrix(c(20, 25, 15, 90), nrow = 2, byrow = TRUE)
```

```
# 卡方检验
```

¹¹详细计算见附录 ??。

```
chisq.test(table)
```

```
# Fisher 精确检验 (样本量小时更可靠)
```

```
fisher.test(table)
```

独立性的实际应用：

1. 金融风险管理的核心假设：在金融工程中，资产收益率的独立性假设是 Black-Scholes 公式的基础。虽然这个假设在实践中经常被违反（存在“波动率聚集”等现象），但它提供了一个有用的基准模型。

2. 信号处理：在噪声模型中，我们通常假设信号与噪声独立。这使得我们可以从噪声观测中恢复信号。

3. 机器学习：许多算法假设训练样本独立同分布 (i.i.d.)。当这个假设被违反时（如时间序列数据），需要使用专门的模型（如 RNN、LSTM）。

5. 2.5 相关性：线性关联的度量

我们已经知道 $\text{cov}(X_1, X_2) = 0$ 不能完全刻画独立性。那么如何量化 X_1 与 X_2 之间的“关联程度”？

协方差 $\text{cov}(X_1, X_2)$ 存在一个问题：它依赖于 X_1, X_2 的量纲。例如，身高 (cm) 和体重 (kg) 的协方差与换算成英寸和磅时不同。

解决方案：先标准化，再求协方差：

$$\rho_{12} = \text{corr}(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)}\sqrt{\text{var}(X_2)}} = \frac{\text{cov}(X_1, X_2)}{\sigma_1\sigma_2}. \quad (2.5.1)$$

这就是相关系数 (correlation coefficient)。

核心性质：¹²

- $-1 \leq \rho_{12} \leq 1$
- $|\rho_{12}| = 1 \iff X_2 = aX_1 + b$ (完美线性关系)
- $\rho_{12} = 0$ 称**不相关**

为什么是 $[-1, 1]$ ？这来自 Cauchy-Schwarz 不等式：

$$|\text{cov}(X_1, X_2)| = |\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]| \leq \sqrt{\mathbb{E}[(X_1 - \mu_1)^2] \cdot \mathbb{E}[(X_2 - \mu_2)^2]} = \sigma_1\sigma_2. \quad (2.5.2)$$

emark 相关 vs 协方差：协方差取决于量纲（“米的协方差”vs“厘米的协方差”数值不同）；相关系数是无量纲的，消除了单位影响。因此，相关系数是更通用的“关联程度”度量。emark

¹²推导见附录 section 1.11。

5.1. 历史注记：Pearson 与相关系数. 相关系数的概念由 Francis Galton (1888) 在研究遗传问题时首次提出，但 Karl Pearson (1896) 给出了严格的数学定义和估计方法。Pearson 的工作奠定了生物计量学的基础，也使得相关性成为统计学中最广泛使用的概念之一。

Galton 的发现： Galton 研究双胞胎身高时发现，父亲身高与子女身高之间存在“回归” (regression) 现象——极端身高（非常高或非常矮）的父母，其子女的身高倾向于向平均值“回归”。这种“向均值回归”的现象正是相关性的体现。

Pearson 的贡献： Pearson 给出了相关系数的精确数学定义：

$$\rho_{XY} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y},$$

并推导了其统计性质。他发展的矩估计方法至今仍是估计相关系数的主要方法之一。

5.2. R 计算：相关分析. R 提供了丰富的相关分析功能：

EXAMPLE 2.9 (样本相关系数). 计算两组数据的 *Pearson* 相关系数：

```
# 数据：父亲身高与儿子身高（模拟 Galton 数据）
father <- c(65, 63, 67, 64, 68, 62, 70, 66, 68, 65)
son <- c(68, 66, 68, 65, 69, 63, 71, 67, 69, 66)

# 计算样本相关系数
cor(father, son)

# 计算置信区间（使用 Fisher z 变换）
n <- length(father)
r <- cor(father, son)
z <- 0.5 * log((1+r)/(1-r)) # Fisher z 变换
se <- 1/sqrt(n-3)
z_ci <- c(z - 1.96*se, z + 1.96*se)
r_ci <- (exp(2*z_ci) - 1)/(exp(2*z_ci) + 1)
r_ci
```

相关性的解释：

- $|\rho| = 0$ ：无线性关系
- $|\rho| \in (0, 0.3)$ ：弱相关
- $|\rho| \in [0.3, 0.7)$ ：中等相关
- $|\rho| \in [0.7, 1)$ ：强相关
- $|\rho| = 1$ ：完美线性关系

注意事项：

- (1) 相关系数只度量线性关系，非线性关系可能表现出 $\rho = 0$

- (2) 相关系数对异常值敏感（可以使用 Spearman 或 Kendall 相关系数作为鲁棒替代）
- (3) 相关不等于因果——两个变量相关可能是因为它们共同受第三个变量影响

EXAMPLE 2.10 (相关与因果). 冰淇淋销量与溺水死亡人数呈正相关 ($\rho \approx 0.9$)。但这并不意味着吃冰淇淋导致溺水——两者都与夏季气温正相关。正确的解释是：夏季（共同原因）导致冰淇淋销量增加和更多人游泳（从而溺水增加）。

6. 2.6 二元正态：最重要的二元分布

在所有二元分布中，二元正态分布占据核心地位。它是一元正态分布在二维的自然推广，也是计量经济学、信号处理等领域的基石。

为什么重要？

- (1) 边缘分布和条件分布都是正态的
- (2) 线性组合仍是正态
- (3) 不相关 $\iff$ 独立（这是正态独有的优雅性质）
- (4) 多元正态是计量经济学、信号处理等领域的基石

历史注记：二元正态分布由 Francis Galton 和 Karl Pearson 在 19 世纪末独立发展。Pearson 发展的多元相关理论为现代统计学奠定了重要基础。

DEFINITION 2.2 (二元正态分布). (X_1, X_2) 服从二元正态分布，若其联合 pdf 为

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\},$$

记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

五个参数的含义：

- μ_1, μ_2 : 边缘分布的均值
- σ_1^2, σ_2^2 : 边缘分布的方差
- ρ : 相关系数

关键性质：

- (1) 边缘分布: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) 条件分布: ¹³

$$X_2 | X_1 = x_1 \sim N \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2 (1 - \rho^2) \right) \quad (2.6.1)$$

$X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ （正态独有的”不相关 $\Rightarrow$ 独立”）

任意线性组合 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, \text{var}(aX_1 + bX_2))$

¹³推导见附录 section 1.12。

emark 条件分布的几何直觉：条件均值

$$\mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1)$$

是 x_1 的线性函数。这意味着：给定 $X_1 = x_1$ ， X_2 的最佳预测也是线性的，其斜率由相关系数 ρ 决定。emark

条件分布的方差 $\sigma_2^2(1 - \rho^2)$ 小于无条件方差 σ_2^2 ——知道 X_1 的值减少了我们对 X_2 的不确定性。当 $|\rho| = 1$ 时，方差为零，意味着 X_2 可以完全由 X_1 线性决定。

6.1. R 计算：二元正态. R 中处理二元正态分布的核心函数包括 `mvtnorm` 包中的函数。

EXAMPLE 2.11 (二元正态概率计算). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.7)$ 。求 $\mathbb{P}(X_1 \leq 0.5, X_2 \leq 0.5)$ 。

在 R 中：

```
# 安装和加载 mvtnorm 包
install.packages("mvtnorm")
library(mvtnorm)

# 计算二元正态 CDF
pmvnorm(lower = c(-Inf, -Inf), upper = c(0.5, 0.5),
         mean = c(0, 0), sigma = matrix(c(1, 0.7, 0.7, 1), nrow = 2))
```

EXAMPLE 2.12 (生成二元正态样本). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.8)$ 。生成 $n = 1000$ 的样本并可视化。

```
library(mvtnorm)
n <- 1000
rho <- 0.8
sigma <- matrix(c(1, rho, rho, 1), nrow = 2)
set.seed(123)
sample <- rmvnorm(n, mean = c(0, 0), sigma = sigma)

# 绘制散点图
plot(sample, xlab = expression(X[1]), ylab = expression(X[2]),
     main = paste("Bivariate Normal, rho =", rho), pch = 20, cex = 0.5)

# 添加相关系数
cor(sample[,1], sample[,2])
```

不同 ρ 值的效果：

- $\rho = 0$: X_1 和 X_2 独立，分布呈圆形对称
- $\rho > 0$: 正相关，分布沿主对角线 ($y = x$) 拉伸

- $\rho < 0$: 负相关, 分布沿副对角线 ($y = -x$) 拉伸
- $|\rho| = 1$: 分布退化为一条直线 (完美线性关系)

6.2. 条件均值与预测. 二元正态的一个核心应用是**最优线性预测**。给定 $X_1 = x_1$, X_2 的最佳预测是条件均值:

$$\hat{X}_2 = \mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1).$$

为什么是”最优”? 考虑预测误差 $e = X_2 - \hat{X}_2$ 。可以证明, 在所有线性预测中, 这个条件均值预测的均方误差最小。¹⁴

预测误差的方差: $\text{var}(e) = \sigma_2^2(1 - \rho^2)$ 。当 $|\rho| = 1$ 时, 误差方差为零—— X_2 可以完全由 X_1 预测。

EXAMPLE 2.13 (身高与体重预测). 设 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 其中 X_1 为父亲身高 (英寸), X_2 为儿子身高 (英寸)。根据 Galton 的经典数据:

$$\mu_1 = \mu_2 = 68.2, \quad \sigma_1 = \sigma_2 = 2.7, \quad \rho = 0.5.$$

给定父亲身高 $x_1 = 72$ 英寸, 儿子的预测身高为:

$$\mathbb{E}(X_2 | X_1 = 72) = 68.2 + 0.5 \cdot \frac{2.7}{2.7} (72 - 68.2) = 68.2 + 1.9 = 70.1 \text{ 英寸}.$$

预测误差的标准差为 $\sigma_2 \sqrt{1 - \rho^2} = 2.7 \cdot \sqrt{0.75} \approx 2.34$ 英寸。

6.3. 回归与条件均值. 从条件均值公式, 我们可以写出”回归方程”:

$$X_2 = \alpha + \beta X_1 + \varepsilon,$$

其中 $\beta = \rho \frac{\sigma_2}{\sigma_1}$, $\alpha = \mu_2 - \beta \mu_1$, $\varepsilon \sim N(0, \sigma_2^2(1 - \rho^2))$ 与 X_1 独立。

最小二乘法的联系: 在统计学中, 我们通常从数据估计回归系数。样本回归系数 $\hat{\beta} = \hat{\rho}_{s_2 s_1}$ 依概率收敛到真实的 β 。¹⁵

7. 2.7 多元推广

前述概念可以推广到 n 个随机变量。记随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$, 其联合 cdf 为

$$F_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

7.1. 边缘与条件分布. 边缘 pdf 通过 $n - 1$ 重积分得到:

$$f_1(x_1) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, x_2, \dots, x_n) dx_2 \cdots dx_n.$$

条件分布定义为联合密度与边缘密度之比:

$$f_{2, \dots, n|1}(x_2, \dots, x_n | x_1) = \frac{f(x_1, x_2, \dots, x_n)}{f_1(x_1)}.$$

¹⁴最优线性预测的推导见附录 section 1.12。

¹⁵回归理论的详细讨论见附录 ??。

7.2. 多元独立性. n 个随机变量 $X_1, \dots, X_n$ 相互独立, 当且仅当

$$f(x_1, x_2, \dots, x_n) \equiv f_1(x_1)f_2(x_2) \cdots f_n(x_n). \quad (2.7.1)$$

注意: 两两独立 (pairwise independence) 不一定推出相互独立 (mutual independence)。Bernstein 的例子说明了这一点。¹⁶

7.3. 线性组合的 mgf. 若 $X_1, \dots, X_n$ 相互独立, $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为

$$M_T(t) = \prod_{i=1}^n M_i(k_i t).$$

¹⁷

特别地, 若 $X_1, \dots, X_n$ iid (独立同分布), 则 $T = \sum_{i=1}^n X_i$ 的 mgf 为

$$M_T(t) = [M(t)]^n. \quad (2.7.2)$$

这个性质在研究样本和的分布时极为有用——它是一切大样本理论的起点。¹⁸

7.4. 多元正态分布. 多元正态分布是二元正态的自然推广, 在统计学中占据核心地位。

DEFINITION 2.3 (n 元正态分布). 随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 服从 n 元正态分布, 若其联合 pdf 为

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\},$$

记作 $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$, 其中 $\boldsymbol{\mu}$ 是均值向量, Σ 是协方差矩阵。

关键性质:

- (1) 任意边缘分布都是正态的
- (2) 任意线性组合 $a_1 X_1 + \cdots + a_n X_n \sim N(\mathbf{a}' \boldsymbol{\mu}, \mathbf{a}' \Sigma \mathbf{a})$
- (3) 若 Σ 对角线之外所有元素为零 (即变量独立), 则 $\mathbf{X}$ 的分量独立
- (4) 条件分布仍是正态的

协方差矩阵的性质:

- Σ 是对称的 ($\Sigma' = \Sigma$)
- Σ 是半正定的 (所有特征值 ≥ 0)
- $|\Sigma|^{1/2}$ 是 Σ 的行列式的平方根

¹⁶反例见附录 ??。

¹⁷推导见附录 section 1.13。

¹⁸中心极限定理的讨论见附录 ??。

7.5. 复相关系数与偏相关. 在多元分析中, 我们经常关心一个变量与一组变量整体的相关性。

复相关系数 (Multiple Correlation Coefficient): 度量 X_1 与 $(X_2, \dots, X_n)$ 整体之间的相关性:

$$R_{1.23\dots n} = \sqrt{\frac{\text{var}(\mathbb{E}(X_1 | X_2, \dots, X_n))}{\text{var}(X_1)}}.$$

偏相关系数 (Partial Correlation Coefficient): 在控制其他变量的影响后, X_1 与 X_2 之间的相关性:

$$\rho_{12.3\dots n} = \frac{\text{cov}(X_1, X_2 | X_3, \dots, X_n)}{\sqrt{\text{var}(X_1 | X_3, \dots, X_n) \cdot \text{var}(X_2 | X_3, \dots, X_n)}}.$$

偏相关在因果推断中特别重要——它度量了在控制一组混杂变量后, 两个变量之间的”直接”相关性。

8. 本章总结

概念	公式/描述
联合 cdf	$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2)$
边缘 pmf	$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2)$
边缘 pdf	$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2) dx_2$
条件 pmf	$p_{X_2 X_1}(x_2 x_1) = p(x_1, x_2)/p_{X_1}(x_1)$
条件 pdf	$f_{X_2 X_1}(x_2 x_1) = f(x_1, x_2)/f_{X_1}(x_1)$
全期望	$\mathbb{E}[\mathbb{E}(X_2 X_1)] = \mathbb{E}X_2$
方差分解	$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 X_1)] + \text{var}[\mathbb{E}(X_2 X_1)]$
独立性	$f(x_1, x_2) = f_1(x_1)f_2(x_2)$
协方差	$\text{cov} = \mathbb{E}(X_1X_2) - \mathbb{E}X_1\mathbb{E}X_2$
相关系数	$\rho = \text{cov}/(\sigma_1\sigma_2), -1 \leq \rho \leq 1$

本章内部脉络: 联合分布 (描述共同行为) $\rightarrow$ 边缘分布 (提取单个变量信息) $\rightarrow$ 条件分布 (利用已知变量更新未知变量) $\rightarrow$ 独立性 (无关系时的简化) $\rightarrow$ 相关性 (量化关联程度)。

为下一章铺垫: 第 3 章将系统研究最重要的几类分布, 这些分布在多元情形下自然出现。第 4 章则利用这些分布建立统计推断的基本工具。

习题

EXERCISE 2.1. 2.1.1 设 X_1 和 X_2 的联合 pdf 为 $f(x_1, x_2) = x_1 + x_2, 0 < x_1 < 1, 0 < x_2 < 1$, 其他位置为零。求 X_1 的边缘 pdf。

EXERCISE 2.2. 2.2.1 设 (X_1, X_2) 的联合 pdf 为 $f(x_1, x_2) = 2, 0 < x_1 < x_2 < 1$, 其他位置为零。

(1) 求边缘 pdf $f_{X_1}(x_1)$ 和 $f_{X_2}(x_2)$

(2) 验证 $\int \int f = 1$

EXERCISE 2.3. 2.3.1 设 X_1 和 X_2 具有联合 pdf $f(x_1, x_2) = x_1 + x_2$, $0 < x_1 < 1$, $0 < x_2 < 1$ 。求给定 $X_1 = x_1$ 时 X_2 的条件均值和条件方差。

EXERCISE 2.4. 2.3.2 证明全期望公式: $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}X_2$ 。(提示: 对离散和连续两种情形分别证明)

EXERCISE 2.5. 2.4.1 证明: 若 X_1 和 X_2 独立, 则 $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$ 。

EXERCISE 2.6. 2.4.2 设 (X, Y) 具有联合 pdf $f(x, y) = x + y$, $0 < x < 1$, $0 < y < 1$ 。 X 与 Y 是否独立? 为什么?

EXERCISE 2.7. 2.5.1 设 (X, Y) 具有联合 pdf $f(x, y) = x + y$, $0 < x < 1$, $0 < y < 1$ 。求相关系数 ρ 。

EXERCISE 2.8. 2.5.2 证明: $-1 \leq \text{corr}(X, Y) \leq 1$ 。(提示: 使用 *Cauchy-Schwarz* 不等式)

EXERCISE 2.9. 2.6.1 设 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。证明条件分布 $X_2 | X_1 = x_1 \sim N(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2))$ 。

EXERCISE 2.10. 2.6.2 设 $(X_1, X_2) \sim N(0, 0, 1, 1, \rho)$ (相关系数为 ρ 的二元标准正态)。求 $X_1 + X_2$ 的分布。

EXERCISE 2.11. 2.7.1 设 X_1, X_2, X_3 为三个独立同分布的随机变量, 每个的 pdf 为 $f(x) = 2x$, $0 < x < 1$ 。求 $Y = \max\{X_1, X_2, X_3\}$ 的分布。

EXERCISE 2.12. 2.7.2 设 $X_1, \dots, X_n \text{ iid} \sim N(\mu, \sigma^2)$ 。令 $\bar{X} = n^{-1} \sum X_i$ 。利用 mgf 证明 $\bar{X} \sim N(\mu, \sigma^2/n)$ 。

CHAPTER 3

Special Distributions

Chapter 3 Overview

In Chapters 1 and 2, we established the mathematical foundations for describing single and multiple random variables. Now we face a fundamental question: **Which probability distributions deserve our special attention, and why?**

The answer lies at the heart of statistics itself. Certain distributions appear again and again in nature, in experiments, and in theoretical investigations. These are not arbitrary choices—they emerge naturally from simple, recurring patterns: counting successes in independent trials, measuring waiting times, modeling measurement errors, and describing the behavior of averages.

This chapter introduces the most important families of distributions in statistical theory and practice. We will discover how these distributions arise from fundamental principles, appreciate their interconnected relationships, and understand why each distribution is indispensable in statistical work.

Chapter Roadmap:

- Bernoulli $\rightarrow$ Binomial $\rightarrow$ Negative Binomial/Geometric $\rightarrow$ Multinomial $\rightarrow$ Hypergeometric
- Poisson (as a limiting form of the binomial)
- Gamma $\rightarrow$ Chi-square $\rightarrow$ Beta
- Normal $\rightarrow$ Bivariate Normal $\rightarrow$ Multivariate Normal
- t and F Distributions (arising from normal theory)

The relationships between these distributions are not accidental—they reflect deep mathematical structures that will accompany us throughout statistical inference.

1. 3.1 The Binomial and Related Distributions

1.1. Why Do We Study the Binomial Distribution? Consider the following scenarios: How many heads appear when a coin is tossed 100 times? How many defective items are found in a batch of 1000 products? How many patients recover after receiving an experimental treatment?

These questions share a common mathematical structure: we perform n independent trials, each with two possible outcomes (success or failure), and we count the total number of successes. This “counting problem” pervades statistics, and the binomial distribution is its natural mathematical model.

The binomial distribution originated from the study of games of chance in the 18th century. Jakob Bernoulli (1713) proved the weak law of large numbers for Bernoulli trials, establishing the theoretical foundation. Later, Abraham de Moivre and Pierre-Simon Laplace developed approximations that would lead to the central limit theorem—one of mathematics' most remarkable results.

1.2. Bernoulli Trials. A **Bernoulli trial** is the simplest random experiment: the outcome is one of two mutually exclusive and exhaustive possibilities—success or failure.

Let the random variable X denote the outcome:

$$X(\text{success}) = 1, \quad X(\text{failure}) = 0.$$

The probability mass function (pmf) is:

$$p(x) = p^x(1-p)^{1-x}, \quad x = 0, 1, \quad (9)$$

where p is the probability of success.

The mean and variance of a Bernoulli distribution are:

$$\mathbb{E}X = p, \quad \text{var}(X) = p(1-p). \quad (10)$$

EXAMPLE 3.1 (Coin Toss). *If we toss a fair coin ($p = 1/2$), then $\mathbb{E}X = 1/2$ and $\text{var}(X) = 1/4$. The standard deviation is 0.5, meaning typical deviations from the mean are about half a coin toss.*

Why is the Bernoulli distribution so fundamental? It is the simplest non-trivial random variable—neither a deterministic constant nor a uniform distribution. It captures the essential nature of “yes/no” decision uncertainty. Every experiment with binary outcome can be modeled as a Bernoulli trial.

1.3. The Binomial Distribution. Now we ask: **What is the distribution of the number of successes in n independent Bernoulli trials?**

Let X_i be the Bernoulli variable for trial i , and we are interested in $X = \sum_{i=1}^n X_i$.

To have exactly x successes means: we choose x positions out of n for the successes (there are $\binom{n}{x}$ ways to do this), and the remaining $n - x$ positions are failures. Each arrangement has probability $p^x(1-p)^{n-x}$.

Therefore, the pmf is:

$$p(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n. \quad (11)$$

We write $X \sim \text{Bin}(n, p)$ and call n and p the parameters of the binomial distribution.

Verification that $p(x)$ sums to 1: By the binomial theorem,

$$\sum_{x=0}^n \binom{n}{x} p^x (1-p)^{n-x} = [(1-p) + p]^n = 1^n = 1.$$

EXAMPLE 3.2 (Dice Problem). *Rolling a fair six-sided die 3 times, what is the probability of getting exactly 2 sixes?*

Let X be the number of sixes, so $X \sim \text{Bin}(n = 3, p = 1/6)$:

$$\mathbb{P}(X = 2) = \binom{3}{2} \left(\frac{1}{6}\right)^2 \left(\frac{5}{6}\right)^1 = 3 \times \frac{1}{36} \times \frac{5}{6} = \frac{15}{216} \approx 0.06944.$$

In R, this is computed as `dbinom(2, 3, 1/6)`.

Moment generating function: The mgf of a binomial distribution is:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x} = [(1-p) + pe^t]^n. \quad (12)$$

From the mgf, we derive the mean and variance:

$$\mathbb{E}X = M'(0) = np, \quad \text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p). \quad (13)$$

1

EXAMPLE 3.3 (Battery Lifetime). *Suppose a battery has probability $p = 0.95$ of lasting at least 100 hours. In a package of $n = 10$ batteries, the expected number that last at least 100 hours is $np = 9.5$, with variance $np(1-p) = 0.475$.*

The probability that at least 8 batteries last is:

$$\mathbb{P}(X \geq 8) = \sum_{x=8}^{10} \binom{10}{x} (0.95)^x (0.05)^{10-x}.$$

In R: `1 - pbinom(7, 10, 0.95) = 0.9885`.

Additivity of Binomial Distributions. One of the most important properties of the binomial distribution is its additivity under the same success probability.

THEOREM 3.1 (Additivity of Binomial Distributions). *If $X_1 \sim \text{Bin}(n_1, p)$ and $X_2 \sim \text{Bin}(n_2, p)$ are independent, then*

$$X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p).$$

Intuitive understanding: Imagine two independent piles of coin flips. The first pile of n_1 coins yields X_1 heads, the second pile of n_2 coins yields X_2 heads. Combined, we have $n_1 + n_2$ coins with total heads $X_1 + X_2$. This must still be binomial with the combined sample size.²

This additivity property reflects the fundamental nature of counting: if we count successes in two batches of trials (each batch having the same success probability), the total is simply the sum.

¹Derivation in Appendix section 7.1.

²Proof using mgf in Appendix section 7.2.

emark The mode (most likely value) of a $\text{Bin}(n, p)$ distribution is $\lfloor (n+1)p \rfloor$. This makes intuitive sense: the expected number of successes is np , and the mode should be near this value. emark

1.4. Negative Binomial and Geometric Distributions. A different question: Instead of counting the number of successes in n trials, we ask: **How many trials are needed to achieve the r -th success?**

This question leads to the negative binomial distribution. Let Y be the number of failures before the r -th success. Then the total number of trials is $Y + r$.

To have exactly y failures before the r -th success: the first $y + r - 1$ trials must contain exactly $r - 1$ successes and y failures (in any order), and the last $((y + r)$ -th) trial must be a success. The number of such sequences is $\binom{y+r-1}{r-1}$:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots \quad (14)$$

We write $Y \sim \text{NB}(r, p)$. The distribution derives its name from the fact that $p_Y(y)$ is a general term in the expansion of $p^r [1 - (1-p)]^{-r}$.³

When $r = 1$, we obtain the **geometric distribution**:

$$p_Y(y) = p(1-p)^y, \quad y = 0, 1, 2, \dots \quad (15)$$

In terms of Bernoulli trials, Y is the number of failures until the first success.

EXAMPLE 3.4 (Blood Type Problem). *Suppose the probability that a person has blood type B is $p = 0.12$. Patients are sampled until 10 people with blood type B are obtained. What is the probability that at most 30 patients need to be tested?*

Let $Y \sim \text{NB}(r = 10, p = 0.12)$. We want $\mathbb{P}(Y \leq 20)$ (since the 10th success occurs on trial $y + r = y + 10$, and $y \leq 20$ means at most 30 trials).

In R: `pnbinom(20, 10, 0.12) = 0.0019`. The probability is quite small!

EXAMPLE 3.5 (First Success Waiting Time). *For a geometric distribution with $p = 0.12$, the probability that exactly 11 patients must be tested before finding the first with blood type B is:*

$$\mathbb{P}(Y = 11) = (0.12)(0.88)^{11} \approx 0.0294.$$

In R: `dgeom(11, 0.12)`.

heorem[Memorylessness of Geometric Distribution] The geometric distribution possesses a unique **memorylessness property**:

$$\mathbb{P}(Y \geq k + j \mid Y \geq k) = \mathbb{P}(Y \geq j), \quad k, j \geq 0. \quad (16)$$

heorem

³Derivation in Appendix section 7.3.

What does this mean? If you have already failed k times, the remaining waiting time for the first success is exactly the same as it was at the beginning. Past failures do not change future expectations. This property characterizes the geometric distribution among all discrete distributions on $\{0, 1, 2, \dots\}$.⁴

The mean and variance of the geometric distribution (with support $\{0, 1, 2, \dots\}$) are:

$$\mathbb{E}Y = \frac{1-p}{p}, \quad \text{var}(Y) = \frac{1-p}{p^2}. \quad (17)$$

5

emark The mgf of the negative binomial distribution is:

$$M(t) = \frac{p^r}{[1 - (1-p)e^t]^r}, \quad t < -\log(1-p).$$

This can be derived using the negative binomial series.⁶ emark

1.5. The Multinomial Distribution. The binomial generalizes naturally to k categories. In each trial, exactly one of k mutually exclusive categories occurs.

Let categories be $C_1, C_2, \dots, C_k$ with probabilities $p_1, p_2, \dots, p_k$ (where $\sum_{i=1}^k p_i = 1$). We repeat the experiment n times independently. Let X_i be the count of category i occurrences.

The joint pmf of $(X_1, X_2, \dots, X_k)$ is:

$$\mathbb{P}(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1!x_2! \dots x_k!} p_1^{x_1} \dots p_k^{x_k}, \quad (18)$$

where $\sum_{i=1}^k x_i = n$.

We say $(X_1, \dots, X_k)$ has a **multinomial distribution** with parameters n and $p_1, \dots, p_k$. The binomial is a special case with $k = 2$.⁷

Properties: For each i , the marginal distribution of X_i is $\text{Bin}(n, p_i)$. The covariance between X_i and X_j ($i \neq j$) is:

$$\text{cov}(X_i, X_j) = -np_i p_j. \quad (19)$$

EXAMPLE 3.6 (Die Roll). Roll a fair six-sided die $n = 30$ times. What is the probability of getting exactly 5 ones, 4 twos, 6 threes, 3 fours, 7 fives, and 5 sixes?

Here $k = 6$, $p_i = 1/6$ for all i . The probability is:

$$\frac{30!}{5!4!6!3!7!5!} \left(\frac{1}{6}\right)^{30} \approx 0.0028.$$

⁴Proof in Appendix section 7.4.

⁵Derivation in Appendix section 7.5.

⁶Derivation in Appendix section 7.6.

⁷Derivation in Appendix section 7.7.

emark The correlation between X_i and X_j is:

$$\rho_{ij} = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}}.$$

This negative correlation makes intuitive sense: if we observe more occurrences of category i , there are fewer trials remaining for category j . emark

1.6. The Hypergeometric Distribution. Central question: What is the distribution of successes when sampling **without replacement**?

Consider a batch of N items with D defectives. We draw n items without replacement, and X is the number of defectives in our sample. Unlike the binomial case, successive draws are not independent because the composition changes as we sample.

The pmf is:

$$p(x) = \frac{\binom{N-D}{n-x} \binom{D}{x}}{\binom{N}{n}}, \quad x = 0, 1, \dots, \min(n, D). \quad (20)$$

We write $X \sim \text{Hypergeometric}(N, D, n)$.

Mean and variance:

$$\mathbb{E}X = n \frac{D}{N}, \quad \text{var}(X) = n \frac{D}{N} \left(1 - \frac{D}{N}\right) \frac{N-n}{N-1}. \quad (21)$$

The factor $\frac{N-n}{N-1}$ is the **finite population correction factor**. When $N \gg n$, it approaches 1, and the hypergeometric distribution approximates the binomial with $p = D/N$.⁸

This approximation reflects an important principle: when the sample size is small relative to the population, sampling without replacement is almost the same as sampling with replacement.

EXAMPLE 3.7 (Card Drawing). *Draw 2 cards from a standard deck of 52 cards without replacement. What is the probability of getting exactly 1 ace?*

Here $N = 52$, $D = 4$ (aces), $n = 2$. We want $\mathbb{P}(X = 1)$:

$$\mathbb{P}(X = 1) = \frac{\binom{48}{1} \binom{4}{1}}{\binom{52}{2}} = \frac{48 \times 4}{1326} \approx 0.1448.$$

For comparison, with replacement (binomial), the probability would be:

$$\binom{2}{1} \left(\frac{4}{52}\right) \left(\frac{48}{52}\right) \approx 0.1412.$$

The probabilities are quite close!

⁸Derivation in Appendix section 7.8.

2. 3.2 The Poisson Distribution

In nature and society, there exists a remarkable class of phenomena: **the number of events occurring in a fixed time or space interval**. Examples include:

- Customers arriving at a bank per hour
- Typographical errors per page of a manuscript
- Earthquakes per year in a region
- Decay events of a radioactive substance
- Accidents at an intersection per week

These phenomena share a common feature: **the probability of each individual event is small, but the number of opportunities is large**. This is precisely the regime where the Poisson distribution emerges.

Historical note: The Poisson distribution was introduced by Siméon Denis Poisson in 1837, originally for analyzing data on French court judgments—the probability that a judge makes a certain number of rulings in a given time period. Little did Poisson know that his distribution would become one of the most widely used tools in all of statistics.

2.1. Definition and Properties. A discrete random variable X has a Poisson distribution with parameter $\lambda > 0$ if:

$$p(x) = \mathbb{P}(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots \quad (22)$$

We write $X \sim \text{Poisson}(\lambda)$.

Verification: Because $e^\lambda = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$,

$$\sum_{x=0}^{\infty} p(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} \cdot e^\lambda = 1. \quad (3.2.1)$$

The parameter λ has a beautiful interpretation: it is both the mean and the variance of the distribution:

$$\mathbb{E}X = \lambda, \quad \text{var}(X) = \lambda. \quad (23)$$

9

Here is a surprising and useful property: Mean equals variance! This is a hallmark feature of the Poisson distribution, useful for checking whether data might follow a Poisson model.

EXAMPLE 3.8 (Automobile Accidents). *Let X be the number of automobile accidents at a busy intersection per week. Suppose $X \sim \text{Poisson}(\lambda = 2)$.*

Then $\mathbb{E}X = 2$ and $\text{std}(X) = \sqrt{2} \approx 1.41$.

- $\mathbb{P}(X \geq 1) = 1 - \mathbb{P}(X = 0) = 1 - e^{-2} \approx 0.8647$
- $\mathbb{P}(3 \leq X \leq 8) = \mathbb{P}(X \leq 8) - \mathbb{P}(X \leq 2) \approx 0.3231$

⁹Derivation in Appendix section 7.9.

In R: `1 - ppois(0, 2)` and `ppois(8, 2) - ppois(2, 2)`.

EXAMPLE 3.9 (Chocolate Chips). *The number of chocolate chips in a cookie follows a Poisson distribution. We want the probability that a cookie contains at least 2 chips to be greater than 0.99. Find the smallest mean λ .*

We need:

$$\mathbb{P}(X \geq 2) = 1 - \mathbb{P}(X = 0) - \mathbb{P}(X = 1) = 1 - e^{-\lambda} - \lambda e^{-\lambda} > 0.99.$$

Solving: $e^{-\lambda}(1 + \lambda) < 0.01$. By trial, $\lambda \approx 6$ works, since $e^{-6}(7) \approx 0.007$.

So at least 6 chips on average are needed!

2.2. The Poisson Approximation to the Binomial. One of the most important limit theorems in probability connects the binomial and Poisson distributions.

theorem[Poisson Approximation to Binomial] If $X_n \sim \text{Bin}(n, p_n)$ and $np_n \rightarrow \lambda$ as $n \rightarrow \infty$, then for any fixed k :

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

That is, $X_n \xrightarrow{d} \text{Poisson}(\lambda)$. **theorem**

Intuitive understanding: When n is large and p is small, the binomial distribution behaves almost identically to the Poisson distribution. The key insight is that only $\lambda = np$ (the mean) matters in the limit.¹⁰

EXAMPLE 3.10 (Typographical Errors). *A manuscript has 500 pages, each page containing approximately 300 words. If the probability of a word being misspelled is $p = 1/10,000$, then the number of errors per page follows $\text{Bin}(300, 1/10000) \approx \text{Poisson}(0.03)$.*

Using the Poisson model:

$$\mathbb{P}(\text{at least 1 error}) \approx 1 - e^{-0.03} \approx 0.03.$$

This explains why Poisson is often used for rare event counting!

emark If $X_1 \sim \text{Poisson}(\lambda_1)$ and $X_2 \sim \text{Poisson}(\lambda_2)$ are independent, then $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$. This additivity property reflects the superposition of independent Poisson processes. **emark**

3. 3.3 The Gamma, χ^2 , and Beta Distributions

These three distributions form the backbone of continuous statistical inference. Understanding their relationships is essential for mastering the mathematical foundations of statistics.

¹⁰Proof in Appendix section 7.10.

3.1. The Gamma Function. The gamma function serves as a bridge between factorials and integrals—one of the most beautiful identities in mathematics.

DEFINITION 3.1 (Gamma Function). *For $\alpha > 0$, the gamma function is defined as:*

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx. \quad (3.3.1)$$

Key property (recursion formula):

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha). \quad (3.3.2)$$

This follows from integration by parts:¹¹:

$$\Gamma(\alpha + 1) = \int_0^\infty x^\alpha e^{-x} dx = [-x^\alpha e^{-x}]_0^\infty + \alpha \int_0^\infty x^{\alpha-1} e^{-x} dx = \alpha \Gamma(\alpha).$$

For positive integers n :

$$\Gamma(n) = (n - 1)!.$$

The gamma function also connects to the beta function:

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)} = \int_0^1 t^{\alpha-1} (1 - t)^{\beta-1} dt. \quad (3.3.3)$$

EXAMPLE 3.11 (Gamma Function Values). • $\Gamma(1) = 0! = 1$

- $\Gamma(2) = 1! = 1$
- $\Gamma(3) = 2! = 2$
- $\Gamma(4) = 3! = 6$
- $\Gamma(\frac{1}{2}) = \sqrt{\pi}$ (a remarkable result!)

3.2. The Gamma Distribution. The gamma distribution is a continuous distribution on $(0, \infty)$ that generalizes both the exponential and chi-square distributions.

DEFINITION 3.2 (Gamma Distribution). *A continuous random variable X has a gamma distribution with parameters $\alpha > 0$ (shape) and $\beta > 0$ (scale) if its pdf is:*

$$f(x) = \begin{cases} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} & x > 0 \\ 0 & \text{elsewhere.} \end{cases} \quad (3.3.4)$$

We write $X \sim \Gamma(\alpha, \beta)$.

Verification that $f(x)$ integrates to 1: Use the substitution $z = x/\beta$, $dz = dx/\beta$:

$$\int_0^\infty \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)} \int_0^\infty z^{\alpha-1} e^{-z} dz = 1.$$

Meaning of the parameters:

- α (shape): Controls the shape of the distribution. Larger α means more mass concentrated near the mean.

¹¹Derivation in Appendix section 7.11.

- β (scale): Controls the spread. Larger β means more probability at larger values.

Special cases:

- $\Gamma(1, \beta) = \text{Exp}(1/\beta)$ (exponential distribution)
- $\Gamma(n/2, 2) = \chi^2(n)$ (chi-square distribution with n degrees of freedom)

Moment generating function:

$$M(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}. \quad (3.3.5)$$

From the mgf, the mean and variance are:¹²

$$\mathbb{E}X = \alpha\beta, \quad \text{var}(X) = \alpha\beta^2. \quad (3.3.6)$$

EXAMPLE 3.12 (Battery Lifetime). *Let X be the lifetime in hours of a certain battery under extremely cold conditions. Suppose $X \sim \Gamma(5, 4)$.*

Then:

- *Mean lifetime:* $\mathbb{E}X = 5 \times 4 = 20$ hours
- *Standard deviation:* $\sqrt{5 \times 16} = 8.94$ hours
- *Probability it lasts at least 50 hours:* $1 - F(50) = 0.0053$ (in R: `1 - pgamma(50, shape=5, scale=4)`)
- *Median lifetime:* $F^{-1}(0.5) = 18.68$ hours (in R: `qgamma(0.5, shape=5, scale=4)`)

emark If $X_1 \sim \Gamma(\alpha_1, \beta)$ and $X_2 \sim \Gamma(\alpha_2, \beta)$ are independent, then $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$. This additivity property reflects the natural structure of gamma-distributed waiting times.¹³emark

emark The hazard function of a gamma distribution is $r(x) = \frac{x^{\alpha-1}e^{-x/\beta}}{\beta^\alpha \Gamma(\alpha)(1-F(x))}$. For the exponential ($\alpha = 1$), $r(x) = 1/\beta$ is constant. For $\alpha > 1$, $r(x)$ is increasing; for $\alpha < 1$, it is decreasing. emark

3.3. The χ^2 Distribution. The chi-square distribution is central to statistics, arising naturally in problems involving variances and sums of squared normal variables.

DEFINITION 3.3 (Chi-Square Distribution). *Let $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ be iid. Then*

$$X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n). \quad (3.3.7)$$

The parameter n is called the number of degrees of freedom.

The χ^2 distribution is a special case of $\Gamma(n/2, 2)$: if $X \sim \chi^2(n)$ then $X \sim \Gamma(n/2, 2)$.

Mean and variance:

$$\mathbb{E}X = n, \quad \text{var}(X) = 2n. \quad (3.3.8)$$

¹²Derivation in Appendix section 7.12.

¹³Proof using mgf in Appendix section 7.13.

emark If $X_1 \sim \chi^2(m)$ and $X_2 \sim \chi^2(n)$ are independent, then $X_1 + X_2 \sim \chi^2(m+n)$. This follows directly from the gamma additivity property. emark

Why is it important? The sampling distribution of the sample variance is closely connected to the χ^2 distribution, making it essential for variance estimation and hypothesis testing.

EXAMPLE 3.13 (Sample Variance Distribution). *For iid $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, the sample variance S^2 satisfies:*

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1). \quad (3.3.9)$$

This fundamental result tells us that the scaled sum of squared deviations from the mean follows a chi-square distribution. It is the foundation for confidence intervals for variance and ANOVA.

EXAMPLE 3.14 (Chi-Square Percentiles). *Suppose $X \sim \chi^2(10)$. In R:*

- *Mean:* $\mathbb{E}X = 10$, *std:* $\sqrt{20} = 4.47$
- *Quantiles:* `qchisq(c(0.25, 0.5, 0.75), 10) = (6.74, 9.34, 12.55)`

3.4. The Beta Distribution. The beta distribution is a continuous distribution on the interval $(0, 1)$, particularly useful for modeling probabilities and proportions.

DEFINITION 3.4 (Beta Distribution). *If X has pdf:*

$$f(x) = \begin{cases} \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} & 0 < x < 1 \\ 0 & \text{elsewhere,} \end{cases} \quad (3.3.10)$$

where $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$, then $X \sim \text{Beta}(\alpha, \beta)$.

The beta function $B(\alpha, \beta)$ normalizes the distribution so that $\int_0^1 f(x)dx = 1$.

Mean and variance:

$$\mathbb{E}X = \frac{\alpha}{\alpha + \beta}, \quad \text{var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}. \quad (3.3.11)$$

14

Special cases:

- $\text{Beta}(1, 1) = \text{Uniform}(0, 1)$
- $\text{Beta}(\alpha, 1) = \text{Power}(1/\alpha)$ (power distribution on $(0, 1)$)

EXAMPLE 3.15 (Beta Distribution Shapes). *The beta distribution offers a wide variety of shapes:*

- $\alpha = \beta = 1$: *Uniform*
- $\alpha = \beta > 1$: *Symmetric, mound-shaped*

¹⁴Derivation in Appendix section 7.14.

- $\alpha > \beta$: *Right-skewed*
- $\alpha < \beta$: *Left-skewed*

emark In Bayesian statistics, when we use a beta distribution as the prior for a binomial parameter p , the posterior distribution remains beta. This is called a **conjugate prior** relationship. The beta-binomial model is one of the most important conjugate pairs in Bayesian analysis.¹⁵emark

The beta distribution’s flexibility—capturing a wide variety of shapes on $(0, 1)$ through different α, β values—makes it ideal for modeling uncertain probabilities.

4. 3.4 The Normal Distribution

Among all probability distributions, the **normal distribution** holds a paramount position. It forms the cornerstone of statistical inference, econometrics, signal processing, and many other fields.

The normal distribution’s importance stems from three key facts:

- (1) **Central Limit Theorem:** Sums of many independent small factors approximate a normal distribution
- (2) **Mathematical elegance:** Linear combinations of normal variables remain normal
- (3) **Interpretable parameters:** Both mean and variance have clear, intuitive meanings

Historical note: The normal distribution was introduced by Carl Friedrich Gauss in 1809 when studying measurement errors. Although Laplace had discussed error distributions earlier, Gauss’s work cemented the normal distribution’s central role in statistics. This is why we often call it the “Gaussian distribution”.

4.1. Definition and Basic Properties.

DEFINITION 3.5 (Normal Distribution). *We say a random variable X has a normal distribution if its pdf is:*

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}, \quad -\infty < x < \infty. \quad (3.4.1)$$

We write $X \sim N(\mu, \sigma^2)$, where μ is the mean and σ^2 is the variance.

The standard normal distribution is $N(0, 1)$, with pdf $\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$ and cdf $\Phi(z)$.

Key property: If $X \sim N(\mu, \sigma^2)$, then $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$. This standardization allows any normal probability calculation to be transformed into a standard normal

¹⁵Discussion of conjugate priors in Appendix section 7.21.

calculation:

$$\mathbb{P}(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right). \quad (3.4.2)$$

EXAMPLE 3.16 (Height Distribution). Suppose the height of adult males is $N(\mu = 70, \sigma^2 = 16)$ (in inches). Then:

- Probability a man exceeds 6 feet (72 inches): $Z = (72 - 70)/4 = 0.5$, so $\mathbb{P}(X > 72) = 1 - \Phi(0.5) \approx 0.3085$
- 95th percentile: $x_{0.95} = 70 + 4 \cdot \Phi^{-1}(0.95) \approx 76.6$ inches
- Probability within one standard deviation: $\Phi(1) - \Phi(-1) \approx 0.6827$

The mgf of $N(\mu, \sigma^2)$ is:

$$M(t) = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}, \quad -\infty < t < \infty. \quad (3.4.3)$$

16

From the mgf, $\mathbb{E}X = \mu$ and $\text{var}(X) = \sigma^2$.

theorem[Linear Combinations of Normal Variables] If $X_1 \sim N(\mu_1, \sigma_1^2)$ and $X_2 \sim N(\mu_2, \sigma_2^2)$ are independent, then for any constants a, b :

$$aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2). \quad (3.4.4)$$

theorem

Why is this property important? It means the normal distribution is closed under linear transformations—making it the theoretical foundation of linear models.¹⁷

emark The mean μ is a **location parameter**: changing μ shifts the entire distribution without changing its shape. The standard deviation σ is a **scale parameter**: changing σ stretches or compresses the distribution. emark

emark For any normal distribution:

- $\mathbb{P}(\mu - \sigma < X < \mu + \sigma) \approx 0.6827$
- $\mathbb{P}(\mu - 2\sigma < X < \mu + 2\sigma) \approx 0.9545$
- $\mathbb{P}(\mu - 3\sigma < X < \mu + 3\sigma) \approx 0.9973$

These are sometimes called the **empirical rule** or 68-95-99.7 rule. emark

theorem[Chi-Square from Normal Squares] If $X \sim N(\mu, \sigma^2)$, then $\frac{(X-\mu)^2}{\sigma^2} \sim \chi^2(1)$.
theorem

This connects the normal and chi-square distributions and explains why the chi-square distribution with n degrees of freedom involves the sum of n squared standard normals.

¹⁶Derivation in Appendix section 7.15.

¹⁷Proof in Appendix section 7.16.

5. 3.5 Multivariate Normal Distribution

The natural extension of the normal distribution to higher dimensions provides powerful tools for modeling correlated variables.

5.1. Bivariate Normal Distribution. The bivariate normal distribution is not just a two-dimensional version of the univariate normal—its correlation structure creates a rich geometry of elliptical contours.

DEFINITION 3.6 (Bivariate Normal Distribution). *If (X_1, X_2) has joint pdf:*

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{Q(x_1, x_2)}{2(1-\rho^2)} \right\}, \quad (3.5.1)$$

where

$$Q = \frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2},$$

then (X_1, X_2) follows a bivariate normal distribution, written $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$.

The five parameters have clear interpretations:

- μ_1, μ_2 : means of the marginal distributions
- σ_1^2, σ_2^2 : variances of the marginal distributions
- ρ : correlation coefficient between X_1 and X_2

theorem[Properties of the Bivariate Normal] If $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, then:

- (1) Marginal distributions: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) Conditional distribution: $X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right)$
- (3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ (uncorrelated implies independent for normals)
- (4) Any linear combination $aX_1 + bX_2$ follows a normal distribution

theorem

Key insight: The conditional mean is a linear function of x_1 . This means that given one variable, the best prediction for the other is also linear. The slope $\rho\sigma_2/\sigma_1$ tells us how much X_2 changes (in standard deviations) for each standard deviation change in X_1 .

The conditional variance $\sigma_2^2(1 - \rho^2)$ is always smaller than the marginal variance σ_2^2 —knowing X_1 reduces our uncertainty about X_2 . When $|\rho| = 1$, the conditional variance is zero: X_2 is perfectly determined by X_1 .

EXAMPLE 3.17 (Husband-Wife Heights). *In a certain population, husband height $X_1 \sim N(5.8, 0.04)$ feet and wife height $X_2 \sim N(5.3, 0.04)$ feet, with correlation $\rho = 0.6$.*

Given a husband is 6.3 feet tall, the conditional distribution of wife's height is:

$$X_2 | X_1 = 6.3 \sim N\left(5.3 + 0.6 \cdot \frac{0.2}{0.2}(6.3 - 5.8), 0.04(1 - 0.36)\right) = N(5.6, 0.0256).$$

So the predicted wife height is 5.6 feet, with standard deviation 0.16 feet. A 95% prediction interval is $5.6 \pm 1.96 \times 0.16 = (5.29, 5.91)$ feet.

The joint mgf of the bivariate normal is:¹⁸

$$M(t_1, t_2) = \exp \left\{ t_1\mu_1 + t_2\mu_2 + \frac{1}{2}(t_1^2\sigma_1^2 + 2t_1t_2\rho\sigma_1\sigma_2 + t_2^2\sigma_2^2) \right\}. \quad (3.5.2)$$

6. 3.6 The t and F Distributions

These two distributions originated from a practical question: **How do we make inferences when the population variance is unknown?**

This question lies at the heart of statistical inference: when we estimate a population mean using the sample mean, we typically don't know the true variance. The t and F distributions allow us to account for this additional uncertainty.

Historical note: William Gosset (Student) introduced the t distribution in 1908 while working at Guinness Brewery. He published under the pseudonym "Student" because his employer prohibited employees from publishing research. Fisher later developed the F distribution for ANOVA.

6.1. The t Distribution.

DEFINITION 3.7 (t Distribution). If $Z \sim N(0, 1)$ and $X \sim \chi^2(n)$ are independent, then

$$T = \frac{Z}{\sqrt{X/n}} \sim t(n). \quad (3.6.1)$$

We say T follows a t distribution with n degrees of freedom.

The pdf of the t distribution is:

$$f(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, \quad -\infty < t < \infty. \quad (3.6.2)$$

¹⁹

The t distribution has heavier tails than the normal distribution, reflecting the additional uncertainty introduced by estimating the variance.

Mean and variance:

$$\mathbb{E}T = 0 \ (n > 1), \quad \text{var}(T) = \frac{n}{n-2} \ (n > 2). \quad (3.6.3)$$

When $n = 1$, we obtain the Cauchy distribution—a “dangerous” distribution with no mean (the integral diverges).

Relationship to normal: As $n \rightarrow \infty$, $t(n) \xrightarrow{d} N(0, 1)$. This reflects the intuitive idea: as the sample size grows, our knowledge of the variance improves, and the t distribution converges to the standard normal.

¹⁸Derivation in Appendix section 7.17.

¹⁹Derivation in Appendix section 7.18.

EXAMPLE 3.18 (*t* Distribution Application). Let $T \sim t(10)$. Find $\mathbb{P}(|T| > 2.228)$.

From tables, $t_{0.025,10} = 2.228$, so $\mathbb{P}(|T| > 2.228) = 0.05$.

Compare to the normal: for $Z \sim N(0, 1)$, $\mathbb{P}(|Z| > 1.96) = 0.05$. The *t* critical values are larger because of heavier tails.

In R: `2 * (1 - pt(2.228, 10)) = 0.05`.

The *t* distribution is fundamental to constructing confidence intervals for the mean when the population variance is unknown. When we replace the population standard deviation σ with the sample standard deviation S , the resulting statistic follows a *t* distribution.²⁰

6.2. The *F* Distribution.

DEFINITION 3.8 (*F* Distribution). If $X_1 \sim \chi^2(m)$ and $X_2 \sim \chi^2(n)$ are independent, then

$$F = \frac{X_1/m}{X_2/n} \sim F(m, n). \quad (3.6.4)$$

We say *F* follows an *F* distribution with degrees of freedom (m, n) .

The pdf is.²¹

$$f(w) = \begin{cases} \frac{\Gamma((m+n)/2)}{\Gamma(m/2)\Gamma(n/2)} \left(\frac{m}{n}\right)^{m/2} \frac{w^{m/2-1}}{(1+mw/n)^{(m+n)/2}} & w > 0 \\ 0 & \text{elsewhere.} \end{cases} \quad (3.6.5)$$

The *F* distribution is the ratio of two independent chi-square variables, each divided by its degrees of freedom.

Mean and variance:

$$\mathbb{E}F = \frac{n}{n-2} \quad (n > 2), \quad \text{var}(F) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)} \quad (n > 4). \quad (3.6.6)$$

²²

Reciprocal property: If $F \sim F(m, n)$, then $1/F \sim F(n, m)$. This symmetry is useful for computing tail probabilities.

emark If $T \sim t(n)$, then $T^2 \sim F(1, n)$. This follows from the definitions: $T = Z/\sqrt{\chi^2(n)/n}$, so $T^2 = Z^2/(\chi^2(n)/n) = \chi^2(1)/(\chi^2(n)/n) \sim F(1, n)$. emark

Why is the *F* distribution important? It is central to ANOVA (analysis of variance) and regression analysis—we use it to compare whether two variances are equal, or whether the variance explained by a model is significantly greater than the residual variance.

²⁰This is the foundation of Chapter 4's confidence interval theory.

²¹Derivation in Appendix section 7.19.

²²Derivation in Appendix section 7.20.

The F statistic in ANOVA compares the variance between group means to the variance within groups. If the between-group variance is large relative to within-group variance, we reject the null hypothesis that all groups have the same mean.

Chapter Summary

This chapter introduced the most important families of distributions in statistics:

Discrete distributions:

- Bernoulli $\rightarrow$ Binomial $\rightarrow$ Negative Binomial/Geometric
- Multinomial $\rightarrow$ Hypergeometric
- Poisson (as a limit of binomial for rare events)

Continuous distributions:

- Uniform $\rightarrow$ Exponential $\rightarrow$ Gamma $\rightarrow$ Chi-square
- Beta (on the unit interval)
- Normal $\rightarrow$ Bivariate Normal
- t and F (arising from Normal + Chi-square constructions)

Key relationships between distributions:

Relationship	Formula
Binomial $\rightarrow$ Poisson limit	$\text{Bin}(n, p) \xrightarrow{n \rightarrow \infty, p \rightarrow 0, np = \lambda} \text{Poisson}(\lambda)$
Gamma $\rightarrow$ Chi-square	$\chi^2(n) = \Gamma(n/2, 2)$
Gamma additivity	$\Gamma(\alpha_1, \beta) + \Gamma(\alpha_2, \beta) \sim \Gamma(\alpha_1 + \alpha_2, \beta)$
Chi-square additivity	$\chi^2(m) + \chi^2(n) \sim \chi^2(m + n)$
Normal squares	$(X - \mu)^2 / \sigma^2 \sim \chi^2(1)$
t as Normal/Chi-square ratio	$t(n) = Z / \sqrt{\chi^2(n)/n}$
F as Chi-square ratio	$F(m, n) = \frac{\chi^2(m)/m}{\chi^2(n)/n}$
$t \rightarrow N$ limit	$t(n) \xrightarrow{d} N(0, 1) \text{ as } n \rightarrow \infty$
Beta normalization	$B(\alpha, \beta) = \Gamma(\alpha)\Gamma(\beta)/\Gamma(\alpha + \beta)$

These relationships are not accidental: they reflect deep mathematical structures. The gamma function unifies discrete and continuous through factorials; limit theorems connect binomial and Poisson; the chi-square distribution emerges naturally from squared normals; and t , F distributions arise when we estimate unknown variance.

Why each distribution matters:

- **Binomial:** Counts of successes in independent trials
- **Poisson:** Rare events in large populations
- **Gamma/Chi-square:** Sums of squares, waiting times, variance estimation
- **Beta:** Probabilities and proportions
- **Normal:** CLT limits, measurement errors, linear models
- **t :** Inference about means with unknown variance

- F : Comparing variances, ANOVA

These distributions will return as the foundation for statistical inference in Chapter 4.

Exercises

?? Let X be the number of successes in n independent Bernoulli trials with success probability p . Show that the moment generating function of X is $M(t) = [(1-p) + pe^t]^n$, and use it to verify $\mathbb{E}X = np$ and $\text{var}(X) = np(1-p)$.

?? Show that the geometric distribution has mean $(1-p)/p$ and variance $(1-p)/p^2$. Verify its memorylessness property: $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$.

?? Prove the binomial additivity theorem: if $X_1 \sim \text{Bin}(n_1, p)$ and $X_2 \sim \text{Bin}(n_2, p)$ are independent, then $X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p)$. (Hint: use the moment generating function)

?? Consider n independent Bernoulli trials with success probability $p = 1/4$. Find the smallest n such that $\mathbb{P}(Y \geq 1) \geq 0.70$, where Y is the number of successes.

?? Suppose Y is $b(n, p)$. Show that the ratio Y/n (relative frequency of success) satisfies:

$$\mathbb{E}(Y/n) = p, \quad \text{var}(Y/n) = \frac{p(1-p)}{n}.$$

?? Suppose $X \sim \text{Poisson}(\lambda)$. Show that $\mathbb{E}X = \lambda$ and $\text{var}(X) = \lambda$.

?? Prove the Poisson approximation to the binomial: if $X_n \sim \text{Bin}(n, p_n)$ and $np_n \rightarrow \lambda$, then for any fixed k :

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

?? The number of customers arriving at a bank per hour follows a Poisson distribution with mean $\lambda = 15$. Find:

- $\mathbb{P}(\text{at least 20 customers})$
- $\mathbb{P}(\text{between 10 and 20 inclusive})$

?? Let $X \sim \Gamma(\alpha, \beta)$. Show that $\mathbb{E}X = \alpha\beta$ and $\text{var}(X) = \alpha\beta^2$.²³

?? Show that the gamma function satisfies $\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$ and that for positive integers n , $\Gamma(n) = (n-1)!$.

?? If $Z_1, Z_2, \dots, Z_n$ are iid $N(0, 1)$, show that $Y = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$. (Hint: use the moment generating function)

?? Let $X \sim \chi^2(8)$. Find:

- $\mathbb{E}X$ and $\text{var}(X)$
- The 95th percentile
- $\mathbb{P}(X > 15)$

²³Derivation in Appendix section 7.12.

?? Let $X \sim \text{Beta}(\alpha, \beta)$. Show that:

$$\mathbb{E}X = \frac{\alpha}{\alpha + \beta}, \quad \text{var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

?? Let $X \sim N(\mu, \sigma^2)$. Show that the standardized variable $Z = (X - \mu)/\sigma \sim N(0, 1)$.

?? If $X_1 \sim N(\mu_1, \sigma_1^2)$ and $X_2 \sim N(\mu_2, \sigma_2^2)$ are independent, show that $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

?? Show that the moment generating function of $N(\mu, \sigma^2)$ is $M(t) = \exp\{\mu t + \sigma^2 t^2/2\}$.

?? Let $X \sim N(100, 225)$ (i.e., $\sigma = 15$). Find:

- $\mathbb{P}(X < 85)$
- $\mathbb{P}(90 < X < 110)$
- The 90th percentile

?? Let $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. Derive the conditional distribution $X_2 | X_1 = x_1$ and verify it is normal with mean and variance as stated in Theorem 5.1.

?? Let $T \sim t(n)$. Show that $T^2 \sim F(1, n)$. (Hint: use the definition of t and F distributions)

?? If $X \sim \chi^2(n)$, show that $E(X^k) = \frac{2^k \Gamma(\frac{n}{2} + k)}{\Gamma(\frac{n}{2})}$ for $k > -n/2$.

?? Let $T \sim t(15)$. Find $\mathbb{P}(|T| > 2.131)$.

?? Show that if $F \sim F(m, n)$, then $1/F \sim F(n, m)$.

7. 附录：公式推导

7.1. Binomial Distribution MGF and Moments. 背景 (Background) : We need to verify that for $X \sim \text{Bin}(n, p)$, the mgf is $M(t) = [(1 - p) + pe^t]^n$ and derive the mean and variance.

参数定义 (Parameter Definitions) :

- n : number of independent trials
- p : probability of success on each trial
- $X = \sum_{i=1}^n X_i$: total number of successes
- $X_i \sim \text{Bernoulli}(p)$: indicator of success on trial i

已知条件 (Given) :

- pmf: $p(x) = \binom{n}{x} p^x (1 - p)^{n-x}$, $x = 0, 1, \dots, n$
- Each X_i has mgf $M_{X_i}(t) = (1 - p) + pe^t$

目标 (Goal) : Derive $M(t)$, then compute $\mathbb{E}X$ and $\text{var}(X)$.

推导步骤 (Derivation Steps) :

Step 1: MGF derivation using independence

Since the X_i are iid, the mgf of their sum is the product of their mgfs:

$$M(t) = \prod_{i=1}^n M_{X_i}(t) = [(1-p) + pe^t]^n.$$

Step 2: First derivative for mean

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t.$$

At $t = 0$:

$$\mathbb{E}X = M'(0) = n[(1-p) + p]^{n-1} \cdot p = np.$$

Step 3: Second derivative for variance

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2}(pe^t)^2 + n[(1-p) + pe^t]^{n-1}(pe^t).$$

At $t = 0$:

$$M''(0) = n(n-1)p^2 + np = n(n-1)p^2 + np = np[(n-1)p + 1] = np[(n-1)p + 1].$$

Therefore:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = np[(n-1)p + 1] - n^2p^2 = np(1-p).$$

7.2. Binomial Additivity Theorem. 背景 (Background): We want to show that if $X_1 \sim \text{Bin}(n_1, p)$ and $X_2 \sim \text{Bin}(n_2, p)$ are independent, then $X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p)$.

推导步骤 (Derivation Steps):

Using the mgf approach:

$$M_{X_1+X_2}(t) = M_{X_1}(t) \cdot M_{X_2}(t) = [(1-p) + pe^t]^{n_1} \cdot [(1-p) + pe^t]^{n_2} = [(1-p) + pe^t]^{n_1+n_2}.$$

This is exactly the mgf of $\text{Bin}(n_1 + n_2, p)$. By the uniqueness of mgfs, the result follows.

7.3. Negative Binomial PMF Derivation. 背景 (Background): We want to derive the pmf of Y , the number of failures before the r -th success.

目标 (Goal): Show that $p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y$.

推导步骤 (Derivation Steps):

For $Y = y$ to occur:

- The first $y + r - 1$ trials must contain exactly $r - 1$ successes and y failures
- The last trial (trial $y + r$) must be a success

The probability of any specific sequence with $r - 1$ successes and y failures in the first $y + r - 1$ trials is $p^{r-1}(1-p)^y$. The probability of success on the last trial is p .

The number of ways to arrange $r - 1$ successes and y failures in $y + r - 1$ trials is $\binom{y+r-1}{r-1}$.

Therefore:

$$p_Y(y) = \binom{y+r-1}{r-1} \cdot p^{r-1}(1-p)^y \cdot p = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

7.4. Geometric Distribution Memorylessness Proof. 背景 (Background) :

We need to show that for $Y \sim \text{Geometric}(p)$:

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j).$$

推导步骤 (Derivation Steps):

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

This shows the geometric distribution is memoryless.

7.5. Geometric Distribution Moments. 背景 (Background) : Find $\mathbb{E}Y$ and $\text{var}(Y)$ for $Y \sim \text{Geometric}(p)$ with pmf $p_Y(y) = p(1-p)^y$.

推导步骤 (Derivation Steps):

Using the fact that $\sum_{y=0}^{\infty} (1-p)^y = \frac{1}{p}$:

$$\mathbb{E}Y = \sum_{y=0}^{\infty} y \cdot p(1-p)^y = p(1-p) \sum_{y=1}^{\infty} y(1-p)^{y-1}.$$

Let $q = 1-p$. Using the formula $\sum_{y=1}^{\infty} yq^{y-1} = \frac{1}{(1-q)^2}$ for $|q| < 1$:

$$\mathbb{E}Y = pq \cdot \frac{1}{p^2} = \frac{q}{p} = \frac{1-p}{p}.$$

For variance, we need $\mathbb{E}[Y(Y-1)]$:

$$\mathbb{E}[Y(Y-1)] = \sum_{y=0}^{\infty} y(y-1)pq^y = pq^2 \sum_{y=2}^{\infty} y(y-1)q^{y-2} = pq^2 \cdot \frac{2}{(1-q)^3} = \frac{2q^2}{p^2}.$$

Then:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \mathbb{E}[Y(Y-1)] + \mathbb{E}Y - (\mathbb{E}Y)^2 = \frac{2q^2}{p^2} + \frac{q}{p} - \frac{q^2}{p^2} = \frac{q^2 + qp}{p^2} = \frac{q}{p^2}.$$

$$\text{So } \text{var}(Y) = \frac{1-p}{p^2}.$$

7.6. Negative Binomial MGF. 背景 (Background) : Derive the mgf of $Y \sim \text{NB}(r, p)$.

推导步骤 (Derivation Steps):

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

Let $q = 1-p$. Using the negative binomial series $(1-q)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} q^y$:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} (qe^t)^y = \frac{p^r}{[1-qe^t]^r} = \frac{p^r}{[1-(1-p)e^t]^r},$$

for $t < -\log(1 - p)$.

7.7. Multinomial Distribution Derivation. 背景 (Background): Derive the joint pmf of $(X_1, \dots, X_k)$ where X_i is the count of category i in n iid trials.

目标 (Goal): Show $p(x_1, \dots, x_k) = \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k}$.

推导步骤 (Derivation Steps):

The number of distinguishable arrangements of $x_1 C_1$'s, $x_2 C_2$'s, $\dots$, $x_k C_k$'s is:

$$\binom{n}{x_1} \binom{n-x_1}{x_2} \cdots \binom{n-x_1-\cdots-x_{k-1}}{x_k} = \frac{n!}{x_1! x_2! \cdots x_k!}.$$

Each such arrangement has probability $p_1^{x_1} p_2^{x_2} \cdots p_k^{x_k}$. Therefore:

$$\mathbb{P}(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k}.$$

7.8. Hypergeometric Distribution Mean and Variance. 背景 (Background): Find $\mathbb{E}X$ and $\text{var}(X)$ for $X \sim \text{Hypergeometric}(N, D, n)$.

推导步骤 (Derivation Steps):

The pmf is:

$$p(x) = \frac{\binom{N-D}{n-x} \binom{D}{x}}{\binom{N}{n}}.$$

For the mean, we use an indicator variable approach. Let $X_i = 1$ if the i -th draw is a defective, 0 otherwise. Then $X = \sum_{i=1}^n X_i$.

Each draw is equally likely to be any of the N items, and exactly D of them are defective. Therefore $\mathbb{P}(X_i = 1) = D/N$, so $\mathbb{E}X_i = D/N$.

By linearity of expectation:

$$\mathbb{E}X = \sum_{i=1}^n \mathbb{E}X_i = n \cdot \frac{D}{N}.$$

For the variance, we use:

$$\text{var}(X) = \sum_{i=1}^n \text{var}(X_i) + 2 \sum_{i < j} \text{cov}(X_i, X_j).$$

Each X_i is Bernoulli with $p = D/N$, so $\text{var}(X_i) = \frac{D(N-D)}{N^2}$.

For $i \neq j$, $\text{cov}(X_i, X_j) = -\frac{D(N-D)}{N^2(N-1)}$ (due to without-replacement sampling).

Therefore:

$$\text{var}(X) = n \cdot \frac{D(N-D)}{N^2} + 2 \binom{n}{2} \cdot \left(-\frac{D(N-D)}{N^2(N-1)} \right) = n \frac{D(N-D)}{N^2} \cdot \frac{N-n}{N-1}.$$

7.9. Poisson Distribution Moments. 背景 (Background): Show that for $X \sim \text{Poisson}(\lambda)$, $\mathbb{E}X = \lambda$ and $\text{var}(X) = \lambda$.

推导步骤 (Derivation Steps):

$$\mathbb{E}X = \sum_{x=0}^{\infty} x \cdot \frac{\lambda^x e^{-\lambda}}{x!} = \lambda e^{-\lambda} \sum_{x=1}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda.$$

For variance:

$$\mathbb{E}[X(X-1)] = \sum_{x=0}^{\infty} x(x-1) \cdot \frac{\lambda^x e^{-\lambda}}{x!} = \lambda^2 e^{-\lambda} \sum_{x=2}^{\infty} \frac{\lambda^{x-2}}{(x-2)!} = \lambda^2.$$

Therefore:

$$\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2 = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

7.10. Poisson Limit Theorem. 背景 (Background): Prove that if $X_n \sim \text{Bin}(n, p_n)$ with $np_n \rightarrow \lambda$, then $X_n \xrightarrow{d} \text{Poisson}(\lambda)$.

推导步骤 (Derivation Steps):

For fixed k :

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{n(n-1) \cdots (n-k+1)}{k!} \left(\frac{\lambda_n}{n}\right)^k \left(1 - \frac{\lambda_n}{n}\right)^{n-k},$$

where $\lambda_n = np_n \rightarrow \lambda$.

As $n \rightarrow \infty$:

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} \rightarrow 1, \quad \left(1 - \frac{\lambda_n}{n}\right)^{-k} \rightarrow 1, \quad \left(1 - \frac{\lambda_n}{n}\right)^n \rightarrow e^{-\lambda}.$$

Therefore:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

7.11. Gamma Function Recursion Proof. 背景 (Background): Prove $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$.

推导步骤 (Derivation Steps):

Using integration by parts with $u = x^\alpha$ and $dv = e^{-x} dx$:

$$\Gamma(\alpha + 1) = \int_0^\infty x^\alpha e^{-x} dx = [-x^\alpha e^{-x}]_0^\infty + \alpha \int_0^\infty x^{\alpha-1} e^{-x} dx = 0 + \alpha \Gamma(\alpha) = \alpha \Gamma(\alpha).$$

For positive integers, $\Gamma(n) = (n-1)!$ follows by induction.

7.12. Gamma Distribution MGF and Mean/Variance. 背景 (Background): Derive the mgf and moments of $\Gamma(\alpha, \beta)$.

推导步骤 (Derivation Steps):

The pdf is $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$ for $x > 0$.

MGF:

$$M(t) = \mathbb{E}[e^{tX}] = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1/\beta - t)} dx.$$

With $z = x(1 - \beta t)/\beta$, $dz = (1 - \beta t)/\beta dx$:

$$M(t) = \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1 - \beta t)^\alpha} \Gamma(\alpha) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}.$$

Mean: $M'(t) = \alpha\beta(1 - \beta t)^{-\alpha-1}$, so $M'(0) = \alpha\beta$.

Variance: $M''(t) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}$, so $M''(0) = \alpha(\alpha + 1)\beta^2$.

Thus $\text{var}(X) = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2$.

7.13. Gamma Additivity Proof. 背景 (Background): Show that if $X_1 \sim \Gamma(\alpha_1, \beta)$ and $X_2 \sim \Gamma(\alpha_2, \beta)$ are independent, then $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$.

推导步骤 (Derivation Steps):

Using the mgf:

$$M_{X_1+X_2}(t) = M_{X_1}(t) \cdot M_{X_2}(t) = (1 - \beta t)^{-\alpha_1} \cdot (1 - \beta t)^{-\alpha_2} = (1 - \beta t)^{-(\alpha_1+\alpha_2)}.$$

This is the mgf of $\Gamma(\alpha_1 + \alpha_2, \beta)$.

7.14. Beta Distribution Moments. 背景 (Background): Derive $\mathbb{E}X$ and $\text{var}(X)$ for $X \sim \text{Beta}(\alpha, \beta)$.

推导步骤 (Derivation Steps):

The pdf is $f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}$ for $0 < x < 1$.

$$\mathbb{E}X = \frac{1}{B(\alpha, \beta)} \int_0^1 x^\alpha (1-x)^{\beta-1} dx = \frac{B(\alpha+1, \beta)}{B(\alpha, \beta)} = \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+\beta+1)} \cdot \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} = \frac{\alpha}{\alpha+\beta}.$$

For variance:

$$\mathbb{E}[X^2] = \frac{B(\alpha+2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}.$$

Therefore:

$$\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \frac{\alpha^2}{(\alpha+\beta)^2} = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}.$$

7.15. Normal Distribution MGF. 背景 (Background) : Derive the mgf of $N(\mu, \sigma^2)$.

推导步骤 (Derivation Steps):

Let $Z = (X - \mu)/\sigma \sim N(0, 1)$. Then $X = \sigma Z + \mu$, so:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

For $Z \sim N(0, 1)$, we used:

$$\mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

7.16. Normal Linear Combination Proof. 背景 (Background) : Show that if $X_1 \sim N(\mu_1, \sigma_1^2)$ and $X_2 \sim N(\mu_2, \sigma_2^2)$ are independent, then $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$.

推导步骤 (Derivation Steps) :

Using mgfs:

$$M_{aX_1+bX_2}(t) = M_{X_1}(at) \cdot M_{X_2}(bt) = \exp \left\{ \mu_1(at) + \frac{1}{2}\sigma_1^2(at)^2 \right\} \cdot \exp \left\{ \mu_2(bt) + \frac{1}{2}\sigma_2^2(bt)^2 \right\}.$$

Simplifying:

$$= \exp \left\{ (a\mu_1 + b\mu_2)t + \frac{1}{2}(a^2\sigma_1^2 + b^2\sigma_2^2)t^2 \right\}.$$

This is the mgf of $N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$.

7.17. Bivariate Normal MGF. 背景 (Background) : Derive the joint mgf of a bivariate normal distribution.

推导步骤 (Derivation Steps) :

For $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$:

$$M(t_1, t_2) = \mathbb{E}[\exp\{t_1X_1 + t_2X_2\}] = \exp \left\{ t_1\mu_1 + t_2\mu_2 + \frac{1}{2}(t_1^2\sigma_1^2 + 2t_1t_2\rho\sigma_1\sigma_2 + t_2^2\sigma_2^2) \right\}.$$

This follows from the quadratic form in the exponential of the joint pdf.

7.18. t Distribution Derivation. 背景 (Background) : Derive the pdf of $T = Z/\sqrt{\chi^2(n)/n}$ where $Z \sim N(0, 1)$ and $\chi^2(n)$ are independent.

推导步骤 (Derivation Steps) :

The transformation $(T, U) = (z/\sqrt{v/n}, v)$ where $Z \sim N(0, 1)$ and $V \sim \chi^2(n)$.

The Jacobian is $|J| = \sqrt{u/n}$.

The joint pdf is:

$$g(t, u) = \frac{1}{\sqrt{2\pi}} e^{-t^2u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}}.$$

Integrating out u using the gamma integral with $z = u(1 + t^2/n)/2$:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}.$$

7.19. F Distribution Derivation. 背景 (Background) : Derive the pdf of $F = \frac{U/m}{V/n}$ where $U \sim \chi^2(m)$ and $V \sim \chi^2(n)$ are independent.

推导步骤 (Derivation Steps) :

Let $W = F$ and $Z = V$, so $U = (m/n)WZ$ and $V = Z$.

The Jacobian is $|J| = (m/n)z$.

The joint pdf is:

$$g(w, z) = \frac{1}{\Gamma(m/2)\Gamma(n/2)2^{(m+n)/2}} \left(\frac{m}{n}wz\right)^{m/2-1} z^{n/2-1} e^{-(mw+n)z/(2n)} \cdot \frac{m}{n}z.$$

Integrating out z using the gamma integral with $y = z(mw + n)/(2n)$:

$$f_W(w) = \frac{\Gamma((m+n)/2)}{\Gamma(m/2)\Gamma(n/2)} \left(\frac{m}{n}\right)^{m/2} \frac{w^{m/2-1}}{(1+mw/n)^{(m+n)/2}}, \quad w > 0.$$

7.20. F Distribution Moments. 背景 (Background) : Derive the mean and variance of $F(m, n)$.

推导步骤 (Derivation Steps) :

Using $F = \frac{r_2}{r_1} \cdot \frac{U}{V}$ where $U \sim \chi^2(r_1)$ and $V \sim \chi^2(r_2)$ are independent:

$$\mathbb{E}[F^k] = \left(\frac{r_2}{r_1}\right)^k \mathbb{E}[U^k] \mathbb{E}[V^{-k}].$$

For $k = 1$:

$$\mathbb{E}[F] = \frac{r_2}{r_1} \cdot r_1 \cdot \frac{2^{-1}\Gamma(r_2/2 - 1)}{\Gamma(r_2/2)} = \frac{r_2}{r_2 - 2}, \quad r_2 > 2.$$

The variance formula follows similarly for $k = 2$.

7.21. Beta-Binomial Conjugate Prior. 背景 (Background) : Show that if $X | p \sim \text{Bin}(n, p)$ and $p \sim \text{Beta}(\alpha, \beta)$, then the posterior $p | X = x \sim \text{Beta}(\alpha + x, \beta + n - x)$.

推导步骤 (Derivation Steps) :

By Bayes' theorem:

$$\pi(p | x) \propto f(x | p) \cdot \pi(p) = \binom{n}{x} p^x (1-p)^{n-x} \cdot \frac{1}{B(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1}.$$

Combining exponents:

$$\pi(p | x) \propto p^{\alpha+x-1} (1-p)^{\beta+n-x-1}.$$

This is the kernel of $\text{Beta}(\alpha + x, \beta + n - x)$.

This conjugate relationship is fundamental in Bayesian statistics, allowing sequential updating of beliefs about p as data is observed.

CHAPTER 4

Some Elementary Statistical Inferences

Chapter 4 Overview

在前三章中，我们建立了描述随机变量和概率分布的理论框架。现在我们面临一个根本性问题：

给定观测数据，如何推断产生这些数据的底层分布？

这个问题——从已知数据推断未知规律——正是统计学的核心任务。正如 Fisher 在 1922 年的经典论文中所强调的，统计推断的本质是在不确定性下做出明智决策。

本章介绍三种主要的推断工具：

- **点估计** (Point Estimation)：用单一数值估计未知参数
- **置信区间** (Confidence Intervals)：参数的合理取值范围，而非点估计的单一数值
- **假设检验** (Hypothesis Testing)：评估关于总体的声明是否获得数据支持

这三种工具相互关联：点估计给出参数的最佳猜测，置信区间度量这个猜测的精度，而假设检验则让我们能够验证关于总体的具体声明。

本章路线图：抽样与统计量 → 点估计 (MLE) → 置信区间 → 假设检验 → 卡方检验 → 蒙特卡洛 → Bootstrap

1. 4.1 Sampling and Statistics

1.1. 从总体到样本。在典型的统计问题中，我们关心某个随机变量 X ，但其 pdf $f(x)$ 或 pmf $p(x)$ 未知。这种未知性可以分为两类：

- (1) $f(x)$ 或 $p(x)$ 的形式完全未知
- (2) 分布的形式已知，但包含未知参数 θ (θ 可以是向量)

本章聚焦第二类——这正是统计学中最常见的场景。我们已知数据的分布类型，只是不知道具体的参数值。几个典型例子：

- (a) $X \sim \text{Exp}(\theta)$, θ 未知——指数分布常用于描述等待时间
- (b) $X \sim \text{Binomial}(n, p)$, p 未知——二项分布描述 n 次试验中的成功次数
- (c) $X \sim \Gamma(\alpha, \beta)$, α 和 β 均未知——Gamma 分布广泛出现于保险和排队论
- (d) $X \sim N(\mu, \sigma^2)$, μ 和 σ^2 均未知——正态分布是统计学的核心

我们用 $f(x; \theta)$ 或 $p(x; \theta)$ 表示含参分布，其中 $\theta \in \Omega$, Ω 是参数空间（所有可能的 θ 组成的集合）。

1.2. 随机样本. 为什么要强调“随机”抽取? 因为只有随机抽样才能保证样本具有代表性——每个个体被选中的概率相等, 这样样本才能“代表”总体。

从总体中抽取样本, 样本观测值与 X 同分布。记为随机变量 $X_1, X_2, \dots, X_n$, 其中 n 是样本量。抽到具体数值后记为 $x_1, x_2, \dots, x_n$ 。

若 $X_1, \dots, X_n$ 相互独立且同分布, 则称它们为来自该共同分布的**随机样本 (random sample)**。

DEFINITION 4.1 (随机样本). 如果随机变量 $X_1, X_2, \dots, X_n$ 独立同分布 (*iid*), 则称这些随机变量构成来自该共同分布的容量为 n 的随机样本。

从这个定义出发, 样本的联合 pdf/pmf 为

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

这正是后续推导似然函数的基础。

1.3. 统计量. 我们已经学会了如何描述单个随机变量, 现在面临一个新问题: **如何从样本中提取信息?**

设 $T = T(X_1, X_2, \dots, X_n)$ 是样本的函数。则称 T 为一个**统计量 (statistic)**。

统计量的关键特征在于: **不依赖任何未知参数**。换言之, 统计量只基于观测数据进行计算, 不涉及任何未知数。一旦样本被观测, $t = T(x_1, \dots, x_n)$ 称为 T 的实现值。

2. 4.2 Point Estimation

点估计提供一个单一数值 (记作 $\hat{\theta}$) 作为未知参数 θ 的估计。但这里立刻产生一个问题: 如何找到“好”的估计量?

2.1. 无偏性. 我们希望估计量具有什么性质? 最基本的要求是无偏性——如果反复抽样, 估计量的平均值应该等于真实参数值。

DEFINITION 4.2 (无偏估计量). 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的样本, $\theta \in \Omega$ 。设 $T = T(X_1, \dots, X_n)$ 是统计量。若

$$\mathbb{E}(T) = \theta,$$

则称 T 是 θ 的**无偏估计量 (unbiased estimator)**。

若 $\mathbb{E}(T) \neq \theta$, 则称 $\text{Bias}(T) = \mathbb{E}(T) - \theta$ 为偏差。无偏性保证估计量没有系统性偏差——既不高估也不低估。

注意: 无偏性并不保证估计量“最好”。例如, 样本方差 S^2 是无偏的, 但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题: 能否找到一个统一的、“最优”的估计原则?

2.2. 最大似然估计 (MLE). 为什么需要似然函数? 样本来自参数 θ 的分布 $f(x; \theta)$ 。给定 θ 时, 观察到当前数据 $\mathbf{x} = (x_1, \dots, x_n)$ 的概率 (密度) 为 $f(\mathbf{x}; \theta)$ 。似然函数正是这个想法的数学表达——它衡量在给定 θ 时, 观察到当前数据的”可能性”。

DEFINITION 4.3 (似然函数). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本。则

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

称为该随机样本的**似然函数 (likelihood function)**。

核心思想: 如果 θ 是真实参数, 那么它应该使得观察到的数据具有较高的”可能性”。因此, 我们选择使 $L(\theta)$ 最大化的 $\hat{\theta}$ ——这正是最大似然估计量的定义。

最大似然估计量 (MLE):

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} L(\theta). \quad (4.2.1)$$

在实际计算中, 通常使用对数似然 $l(\theta) = \log L(\theta)$, 因为 $\log$ 是严格递增函数, 最大化 $l(\theta)$ 等价于最大化 $L(\theta)$ 。在正则条件下, $\hat{\theta}$ 满足

$$\frac{\partial l(\theta)}{\partial \theta} = 0. \quad (4.2.2)$$

这个方程称为**似然方程 (score equation)**。¹

EXAMPLE 4.1 (指数分布的 MLE). 设 $X_1, \dots, X_n \sim \operatorname{Exp}(\theta)$, pdf 为 $f(x) = \theta^{-1} \exp\{-x/\theta\}$, $x > 0$ 。

对数似然为

$$l(\theta) = -n \log \theta - \frac{1}{\theta} \sum_{i=1}^n x_i.$$

令导数为零, 解得 $\hat{\theta} = \bar{x}$ 。由于 $\mathbb{E}(X) = \theta$, 故 $\hat{\theta} = \bar{X}$ 也是无偏估计。²

EXAMPLE 4.2 (二项分布的 MLE). 设 $X \sim \operatorname{Bernoulli}(\theta)$, $p(x; \theta) = \theta^x (1 - \theta)^{1-x}$, $x = 0, 1$ 。

对于随机样本, 似然函数为

$$L(\theta) = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}.$$

对数似然求导并令为零, 解得 $\hat{\theta} = \bar{x}$ 。由于 $\mathbb{E}(X) = \theta$, 故 $\hat{\theta} = \bar{X}$ 是无偏的。³

¹通用推导框架见附录 section 8.1。

²详细推导见附录 section 8.2。

³详细推导见附录 section 8.3。

EXAMPLE 4.3 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 参数向量为 $\theta = (\mu, \sigma)$ 。

对数似然为

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2. \quad (4.2.3)$$

对 μ 和 σ 分别求偏导并令为零, 解得

$$\hat{\mu} = \bar{X}, \quad (4.2.4)$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (4.2.5)$$

一个重要发现: $\hat{\mu} = \bar{X}$ 是无偏的 ($\mathbb{E}(\bar{X}) = \mu$), 但 $\hat{\sigma}^2$ 是有偏的——

$$\mathbb{E}(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2,$$

而样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是无偏的 ($\mathbb{E}(S^2) = \sigma^2$)。这说明 MLE 有时并非无偏——无偏性和最大似然是两种不同的估计原则。⁴

MLE 的吸引力来自其渐近理论: 在温和条件下, MLE 是渐近正态的、渐近有效的, 且具有最优性。这些性质使 MLE 成为现代统计推断的基石。

3. 4.3 Confidence Intervals

点估计给出一个数值, 但它没有告诉我们这个估计有多“可靠”。置信区间通过提供参数的取值范围来解决这个问题。

一个直观的类比: 如果点估计是“我认为明天的温度是 22 度”, 那么置信区间就是“我认为温度在 18 到 26 度之间”。后者不仅给出估计, 还表达了不确定性。

DEFINITION 4.4 (置信区间). 设 $L = g_1(X_1, \dots, X_n)$ 和 $U = g_2(X_1, \dots, X_n)$ 是两个统计量。若对所有 $\theta \in \Omega$,

$$\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha,$$

则称随机区间 $[L, U]$ 为 θ 的 $100(1 - \alpha)\%$ 置信区间 (*confidence interval*)。

正确理解: 不是说“ θ 以 $1 - \alpha$ 概率落在区间内” (θ 是固定常数, 没有随机性), 而是说“如果重复抽样 $100(1 - \alpha)\%$ 的区间会包含 θ ”。这称为置信区间的频率学派解释。

构造置信区间的关键是找到枢轴量 (pivot) —— 一个其分布不依赖于未知参数的函数。⁵

⁴详细推导见附录 section 8.4。

⁵枢轴量的构造方法及推导见附录 section 8.5。

3.1. 正态均值的置信区间.

EXAMPLE 4.4 (已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。则 μ 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right], \quad (4.3.1)$$

其中 $z_{\alpha/2}$ 满足 $\Phi(z_{\alpha/2}) = 1 - \alpha/2$ 。

直觉理解： 区间宽度 $\propto \sigma/\sqrt{n}$ ——样本量越大，估计越精确。这与大数定律的直觉一致：更多信息带来更精确的估计。⁶

EXAMPLE 4.5 (未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。用 S^2 替代 σ^2 , 则

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}, \quad (4.3.2)$$

故 μ 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \right]. \quad (4.3.3)$$

用 t 分布替代正态分布： 当方差未知时，我们用样本标准差 S 替代总体标准差 σ 。这引入了额外的随机性，导致分布从正态变为 t 分布。 t 分布比正态分布更“重尾”，反映了未知方差带来的不确定性。⁷

THEOREM 4.1 (方差置信区间). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ 。则 σ^2 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right]. \quad (4.3.4)$$

其中 $\chi_{p,k}^2$ 是 $\chi^2(k)$ 分布的上侧 p 分位数。⁸

⁶详细推导见附录 section 8.6。

⁷详细推导见附录 section 8.7。

⁸详细推导见附录 section 8.8。

4. 4.4 Hypothesis Testing

假设检验回答一个根本性问题：数据是否提供足够证据拒绝关于总体的某个声明？

这本质上是一种“举证”逻辑：我们先假设某个声明为真 (H_0)，然后问：在这个假设下，当前数据出现的概率有多大？如果概率很小，我们就有理由拒绝这个假设。

核心概念：

- **原假设** H_0 ：被检验的假设（通常代表“无效应”或“现状”）
- **备择假设** H_1 ：与 H_0 对立的假设

在设定假设时，我们需要权衡两类错误：

	未拒绝 H_0	拒绝 H_0
H_0 为真	正确（置信度 $1 - \alpha$ ）	第一类错误（概率 α ）
H_0 为假	第二类错误（概率 β ）	正确（功效 $1 - \beta$ ）

显著性水平： $\alpha = \mathbb{P}(\text{第一类错误}) = \mathbb{P}(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$

自然的问题：为什么不能同时最小化两类错误？因为在固定样本量下，两类错误是此消彼长的——降低 α 会提高 β ，反之亦然。这正是统计推断中不确定性本质的体现。

EXAMPLE 4.6 (正态均值检验、已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。检验 $H_0 : \mu = \mu_0$ vs $H_1 : \mu > \mu_0$ (单侧检验)。

检验统计量：

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}. \quad (4.4.1)$$

在 α 水平下，当 $Z > z_\alpha$ 时拒绝 H_0 。⁹

EXAMPLE 4.7 (正态均值检验、未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。检验 $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$ (双侧检验)。

检验统计量：

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}. \quad (4.4.2)$$

在 α 水平下，当 $|T| > t_{\alpha/2, n-1}$ 时拒绝 H_0 。¹⁰

p 值：在 H_0 为真条件下，观察到比当前样本更极端结果的概率。 p 值越小，拒绝 H_0 的证据越强。

与置信区间的联系：假设检验和置信区间在本质上是等价的——如果 μ_0 落在置信区间内，我们就不拒绝 $H_0 : \mu = \mu_0$ ；反之则拒绝。

⁹详细推导见附录 section 8.9。

¹⁰详细推导见附录 section 8.9。

5. 4.5 Chi-Square Tests

直到现在，我们讨论的都是连续型数据。但统计学同样关注**分类数据 (categorical data)**——即计数数据。例如：选举中支持不同候选人的选民人数、不同药物治疗后的治愈/未治愈人数。

卡方检验的核心思想：比较观测频数与期望频数。如果两者差异很大，说明数据可能不服从假设的分布。

5.1. 拟合优度检验. 问题：数据是否来自某个特定分布？

设 $O_1, \dots, O_k$ 是 k 个类别的观测频数， $E_i = np_{i,0}$ 是 H_0 下的期望频数。

检验统计量：

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}. \quad (4.5.1)$$

在 H_0 下， $\chi^2 \approx \chi^2(k-1)$ (大样本近似)。拒绝 H_0 当 $\chi^2 > \chi_{\alpha, k-1}^2$ 。

直观理解： $(O_i - E_i)^2/E_i$ 衡量每个类别的偏差，平方消去正负号，除以 E_i 进行标准化，求和得到总体偏差。¹¹

5.2. 独立性检验. 对于 $r \times c$ 列联表，设 O_{ij} 为单元格 (i, j) 的观测频数。

在独立性假设下，行合计与列合计的乘积除以总数给出期望频数：

$$E_{ij} = \frac{O_{i \cdot} O_{\cdot j}}{n}. \quad (4.5.2)$$

检验统计量：

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}. \quad (4.5.3)$$

在 H_0 下， $\chi^2 \approx \chi^2((r-1)(c-1))$ 。

6. 4.6 Monte Carlo Methods

有些概率和期望无法解析计算——积分可能没有闭式解，分布可能过于复杂。这时，Monte Carlo 方法提供了一条出路。

核心思想：用随机模拟来近似计算。如果我们可以从某个分布抽样，就可以通过大量重复实验来估计任何期望。

大数定律保证了模拟的收敛性：

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \xrightarrow{P} \mathbb{E}[g(X)]. \quad (4.6.1)$$

这意味着：只要模拟次数足够多，样本均值可以任意接近真实期望。

¹¹详细推导见附录 section 8.10。

接受-拒绝算法：当目标分布 $f(x)$ 难以直接抽样时，我们可以利用更容易抽样的提议分布 $g(x)$ ：

- (1) 选择提议分布 $g(x)$ ，满足 $f(x) \leq Mg(x)$ (对某个 $M > 1$)
- (2) 生成 $Y \sim g$ 和 $U \sim \text{Uniform}(0, 1)$ 独立
- (3) 若 $U \leq f(Y)/(Mg(Y))$ ，接受 $X = Y$ ；否则拒绝，返回步骤 2

接受概率为 $1/M$ 。¹²

7. 4.7 Bootstrap Methods

核心困境：估计量的抽样分布是统计推断的基础，但这个分布在大多数情况下难以解析计算。例如，样本中位数 $\hat{m}$ 的分布无法用初等函数表达。

Bootstrap 的解决思路既简单又巧妙：**用重抽样近似抽样分布。**

Bootstrap 的核心假设：样本就像总体。如果我们有了一个“好”的样本，为什么不从这个样本中有放回地再次抽样，模拟重复实验的过程？

步骤：

- (1) 从原始样本中有放回地抽取 n 个观测，形成一个 bootstrap 样本 $X_1^*, \dots, X_n^*$
- (2) 计算 bootstrap 复制 $T^* = g(X_1^*, \dots, X_n^*)$
- (3) 重复步骤 1-2 多次 (如 $B = 1000$ 次)，得到 $T_1^*, \dots, T_B^*$
- (4) 用 $T_1^*, \dots, T_B^*$ 的经验分布近似 T 的抽样分布

percentile bootstrap 置信区间： θ 的 $100(1 - \alpha)\%$ 置信区间为

$$[T_{(\alpha B)}^*, T_{((1-\alpha)B)}^*]. \quad (4.7.1)$$

直觉：如果样本是总体的良好代表，那么从样本有放回抽样就是在模拟“从总体中抽取样本”的过程。 T^* 的分布反映了 T 的抽样分布的近似。¹³

Bootstrap 的强大之处在于它的通用性——几乎任何估计量都可以用 Bootstrap 近似其分布，不需要繁复的数学推导。这使它成为现代统计实践中的重要工具。

Exercises

EXERCISE 4.1. *4.1 Motor Lifetime Data Twenty motors were put on test under a high-temperature setting. The lifetimes in hours of the motors under these conditions are given below. Suppose we assume that the lifetime of a motor under these conditions, X , has a $\Gamma(1, \theta)$ distribution.*

- (a) *Obtain a histogram of the data and overlay it with a density estimate. Based on this plot, do you think that the $\Gamma(1, \theta)$ model is credible?*
- (b) *Assuming a $\Gamma(1, \theta)$ model, obtain the maximum likelihood estimate $\hat{\theta}$ of θ and locate it on your histogram.*

¹²接受-拒绝算法的推导及收敛性证明见附录 section 8.11。

¹³Bootstrap 的理论基础及更多细节见附录 section 8.12。

- (c) Obtain the sample median of the data. What parameter is it estimating?
- (d) Based on the mle, what is another estimate of the median of X ?

EXERCISE 4.2. **4.2 Baseball Player Weights** Here are the weights of 26 professional baseball pitchers. Suppose we assume that the weight of a professional baseball pitcher is normally distributed with mean μ and variance σ^2 .

- (a) Obtain a histogram of the data. Based on this plot, is a normal probability model credible?
- (b) Obtain the maximum likelihood estimates of μ , σ^2 , σ , and μ/σ .
- (c) Using the binomial model, obtain the maximum likelihood estimate of the proportion p of professional baseball pitchers who weigh over 215 pounds.
- (d) Determine the mle of p assuming that the weight follows the normal probability model $N(\mu, \sigma^2)$.

EXERCISE 4.3. **4.3 Poisson Customer Arrivals** Suppose the number of customers X that enter a store between 9:00 a.m. and 10:00 a.m. follows a Poisson distribution with parameter θ . Suppose a random sample of the number of customers for 10 days results in values: 9, 7, 9, 15, 10, 13, 11, 7, 2, 12.

- (a) Determine the maximum likelihood estimate of θ . Show that it is an unbiased estimator.
- (b) Based on these data, obtain the realization of your estimator. Explain its meaning.

EXERCISE 4.4. **4.4 Verify Likelihood Equations** For Example 4.1.3, verify equations (4.1.4)-(4.1.8).

EXERCISE 4.5. **4.5 Order Statistics Probability** Let $X_1, X_2, \dots, X_n$ be a random sample from a continuous-type distribution.

- (a) Find $P(X_1 \leq X_2)$, $P(X_1 \leq X_2, X_1 \leq X_3)$, $\dots$, $P(X_1 \leq X_i, i = 2, 3, \dots, n)$.
- (b) Suppose the sampling continues until X_1 is no longer the smallest observation. Let Y equal the number of trials (not including X_1) until X_1 is no longer the smallest. Show that $P(Y = y) = \frac{1}{y(y+1)}$, $y = 1, 2, 3, \dots$.
- (c) Compute the mean and variance of Y if they exist.

EXERCISE 4.6. **4.6 Variance of PMF Estimator** Consider the estimator of the pmf in expression (4.1.10). We showed that this estimator is unbiased. Find the variance of the estimator and its mgf.

EXERCISE 4.7. **4.7 Scottish Schoolchildren Eye Colors** The data set on Scottish schoolchildren included the eye colors of the children. The frequencies of their eye colors are: Blue: 2978, Light: 6697, Medium: 7511, Dark: 5175. Use these frequencies to obtain a bar chart and an estimate of the associated pmf.

EXERCISE 4.8. [4.8](#) *MLE of Poisson PMF* Assuming that the data in Example 4.1.6 were drawn from a Poisson distribution with mean λ , obtain the mle of λ and then use it to obtain the mle of the pmf. Compare the mle of the pmf to the nonparametric estimate.

EXERCISE 4.9. [4.9](#) *Nonparametric Density Estimator* Consider the nonparametric estimator of a pdf.

- (a) Obtain its mean and determine the bias of the estimator.
- (b) Obtain the variance of the estimator.

EXERCISE 4.10. [4.10](#) *Brain Data Analysis* This data set consists of a sample of brain information recorded on 40 college students. The variables include gender, height, weight, three IQ measurements, and MRI counts.

- (a) Load the rda file and print the MRI data.
- (b) Obtain a histogram of the data. Comment on the shape.
- (c) Overlay the default density estimator. Comment on the shape.
- (d) Obtain the sample mean and standard deviation and overlay the normal pdf with these estimates. Comment on the fit.
- (e) Determine the proportions of the data within 1 and 2 standard deviations of the sample mean.

EXERCISE 4.11. [4.11](#) *Speed of Light Data* This is a famous data set on the speed of light recorded by the scientist Simon Newcomb.

- (a) Load the rda file. Discuss the data.
- (b) Obtain a histogram of the data. Comment on the shape.
- (c) Overlay the default density estimator. Comment on the shape.
- (d) Overlay the normal pdf with sample mean and standard deviation. Comment on the fit.
- (e) Determine the proportions of the data within 1 and 2 standard deviations of the sample mean.

EXERCISE 4.12. [4.12](#) *Normal Confidence Intervals* Let the observed value of the mean $\bar{X}$ and of the sample variance of a random sample of size 20 from a distribution that is $N(\mu, \sigma^2)$ be 81.2 and 26.5, respectively. Find respectively 90%, 95% and 99% confidence intervals for μ .

EXERCISE 4.13. [4.13](#) *Motor Lifetime Confidence Interval* Consider the data on the lifetimes of motors given in Exercise 4.1.1. Obtain a large sample 95% confidence interval for the mean lifetime of a motor.

EXERCISE 4.14. [4.14](#) *Gamma Distribution Inference* Suppose we assume that $X_1, X_2, \dots, X_n$ is a random sample from a $\Gamma(1, \theta)$ distribution.

- (a) Show that the random variable $(2/\theta) \sum_{i=1}^n X_i$ has a χ^2 -distribution with $2n$ degrees of freedom.
- (b) Using the random variable in part (a) as a pivot random variable, find a $(1 - \alpha)100\%$ confidence interval for θ .
- (c) Obtain the confidence interval for the data of Exercise 4.1.1.

EXERCISE 4.15. [4.15](#) *Baseball Weight Difference* In Example 4.2.4, for the baseball data, find the pooled t 95% confidence interval for the mean difference in weights between the pitchers and hitters.

EXERCISE 4.16. [4.16](#) *Left-handed Baseball Players* In the baseball data set, it was found that out of 59 baseball players, 15 were left-handed. Construct a 95% approximate confidence interval for p , the proportion of left-handed professional baseball players.

EXERCISE 4.17. [4.17](#) *Sample Size for CI Length* Let $\bar{X}$ be the mean of a random sample of size n from a distribution that is $N(\mu, 9)$. Find n such that $P(\bar{X} - 1 < \mu < \bar{X} + 1) = 0.90$, approximately.

EXERCISE 4.18. [4.18](#) *CI from Sample Data* Let a random sample of size 17 from the normal distribution $N(\mu, \sigma^2)$ yield $\bar{x} = 4.7$ and $s^2 = 5.76$. Determine a 90% confidence interval for μ .

EXERCISE 4.19. [4.19](#) *Sample Size for Half-length* Let $\bar{X}$ denote the mean of a random sample of size n from a distribution that has mean μ and variance $\sigma^2 = 10$. Find n so that the probability is approximately 0.954 that the random interval $(\bar{X} - 1/2, \bar{X} + 1/2)$ includes μ .

EXERCISE 4.20. [4.20](#) *Normal CI Length Comparison* Let $X_1, X_2, \dots, X_9$ be a random sample of size 9 from a distribution that is $N(\mu, \sigma^2)$.

- (a) If σ is known, find the length of a 95% confidence interval for μ .
- (b) If σ is unknown, find the expected value of the length of a 95% confidence interval for μ .
- (c) Compare these two answers.

EXERCISE 4.21. [4.21](#) *Prediction Interval* Let $X_1, X_2, \dots, X_n, X_{n+1}$ be a random sample of size $n + 1$, $n > 1$, from a distribution that is $N(\mu, \sigma^2)$. Find the constant c so that the statistic $c(\bar{X} - X_{n+1})/S$ has a t -distribution.

EXERCISE 4.22. [4.22](#) *Monte Carlo CI Coverage* Let $X_1, \dots, X_n$ be a random sample from a $N(0, 1)$ distribution. Simulate m confidence intervals and calculate the proportion that trap 0.

- (a) Set $n = 10$ and $m = 50$. Run the R code and find the proportion of successful confidence intervals.

(b) Plot the intervals and comment on the variability of the lengths.

EXERCISE 4.23. [4.23](#) *Invariance of CI Coverage* In Exercise 4.2.11, show that setting $\mu = 0$ and $\sigma = 1$ is without loss of generality.

EXERCISE 4.24. [4.24](#) *Empirical Confidence Level* Change the code in the R function `getcis` so that it also returns the vector `ind` where `ind[i] = 1` if the i th confidence interval is successful. Show that the empirical confidence level is `mean(ind)`.

EXERCISE 4.25. [4.25](#) *Gamma CI via CLT* Let $\bar{X}$ denote the mean of a random sample of size 25 from a gamma-type distribution with $\alpha = 4$ and $\beta > 0$. Use the Central Limit Theorem to find an approximate 0.954 confidence interval for μ .

EXERCISE 4.26. [4.26](#) *Sample Size for Given Length* Let $\bar{x}$ be the observed mean of a random sample of size n from a distribution having mean μ and known variance σ^2 . Find n so that $\bar{x} - \sigma/4$ to $\bar{x} + \sigma/4$ is an approximate 95% confidence interval for μ .

EXERCISE 4.27. [4.27](#) *Binomial Sample Size* Assume a binomial model for a certain random variable. If we desire a 90% confidence interval for p that is at most 0.02 in length, find n .

EXERCISE 4.28. [4.28](#) *Poisson Confidence Interval* It is known that a random variable X has a Poisson distribution with parameter μ . A sample of 200 observations from this distribution has a mean equal to 3.4. Construct an approximate 90% confidence interval for μ .

EXERCISE 4.29. [4.29](#) *Variance CI via Chi-square* Let $X_1, X_2, \dots, X_n$ be a random sample from $N(\mu, \sigma^2)$, where both parameters are unknown.

- (a) Show that $P((n-1)S^2/\sigma^2 < b) = 0.975$ and $P(a < (n-1)S^2/\sigma^2 < b) = 0.95$.
- (b) If $n = 9$ and $s^2 = 7.93$, find a 95% confidence interval for σ^2 .
- (c) If μ is known, how would you modify the procedure?

EXERCISE 4.30. [4.30](#) *Exact Gamma CI* Let $X_1, X_2, \dots, X_n$ be a random sample from a gamma distribution with known parameter $\alpha = 3$ and unknown $\beta > 0$. Obtain an exact confidence interval by first obtaining the distribution of $2\sum_{i=1}^n X_i/\beta$.

EXERCISE 4.31. [4.31](#) *Tack Point-Up Probability* When 100 tacks were thrown on a table, 60 of them landed point up. Obtain a 95% confidence interval for the probability that a tack of this type lands point up.

EXERCISE 4.32. [4.32](#) *Two-Sample Normal CI* Let two independent random samples, each of size 10, from two normal distributions $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$ yield $\bar{x} = 4.8$, $s_1^2 = 8.64$, $\bar{y} = 5.6$, $s_2^2 = 7.88$. Find a 95% confidence interval for $\mu_1 - \mu_2$.

EXERCISE 4.33. [4.33](#) *Binomial Proportion Difference* Let two independent random variables Y_1 and Y_2 with binomial distributions having parameters $n_1 = n_2 = 100$, p_1 and p_2 , be observed to be $y_1 = 50$ and $y_2 = 40$. Determine an approximate 90% confidence interval for $p_1 - p_2$.

EXERCISE 4.34. [4.34](#) *Known Variance Difference* Discuss the problem of finding a confidence interval for the difference $\mu_1 - \mu_2$ between the two means of two normal distributions if the variances σ_1^2 and σ_2^2 are known but not necessarily equal.

EXERCISE 4.35. [4.35](#) *Unknown Unequal Variance* Discuss the problem when the variances are unknown and unequal. If the variances are unknown but their ratio σ_1^2/σ_2^2 is a known constant k , then a statistic that is a T random variable can again be used. Why?

EXERCISE 4.36. [4.36](#) *Ratio Known Variance CI* Let $X_1, \dots, X_9$ and $Y_1, \dots, Y_{12}$ represent two independent random samples from $N(\mu_1, \sigma_1^2)$ and $N(\mu_2, \sigma_2^2)$. It is given that $\sigma_1^2 = 3\sigma_2^2$, but σ_2^2 is unknown. Define a random variable that has a t -distribution for a 95% confidence interval for $\mu_1 - \mu_2$.

EXERCISE 4.37. [4.37](#) *Sample Size for Mean Difference* Let $\bar{X}$ and $\bar{Y}$ be the means of two independent random samples, each of size n , from $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$, where the common variance is known. Find n such that $P(\bar{X} - \bar{Y} - \sigma/5 < \mu_1 - \mu_2 < \bar{X} - \bar{Y} + \sigma/5) = 0.90$.

EXERCISE 4.38. [4.38](#) *Variance Ratio CI* Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ be two independent random samples from $N(\mu_1, \sigma_1^2)$ and $N(\mu_2, \sigma_2^2)$. Construct a confidence interval for the ratio σ_1^2/σ_2^2 .

EXERCISE 4.39. [4.39](#) *Exact Binomial CI Recall* for the baseball data, 15 out of 59 ballplayers are left-handed. Determine an exact 90% confidence interval for p .

EXERCISE 4.40. [4.40](#) *Asymptotic CI Verification* In Example 4.3.2, verify the result for the asymptotic confidence interval for θ .

EXERCISE 4.41. [4.41](#) *Discrete Exact Tack CI* In Exercise 4.2.20, find the discrete exact confidence interval for the proportion.

EXERCISE 4.42. [4.42](#) *Poisson Exact CI* Suppose $X_1, X_2, \dots, X_{10}$ is a random sample from a Poisson distribution with mean θ . Suppose $n\bar{x} = 5$. Compute the exact 90% confidence interval for θ .

EXERCISE 4.43. [4.43](#) *t-Interval Derivation* Consider the same setup as in Example 4.3.1 except now assume that σ^2 is unknown. Set up the equations and derive the t -interval for θ .

EXERCISE 4.44. [4.44](#) *Beta Integral Identity Using Exercise 3.3.22, show that*

$$\int_0^p \frac{n!}{(k-1)!(n-k)!} z^{k-1} (1-z)^{n-k} dz = \sum_{w=k}^n \binom{n}{w} p^w (1-p)^{n-w}.$$

EXERCISE 4.45. [4.45](#) *Poisson CDF Identity This exercise obtains a useful identity for the cdf of a Poisson cdf.*

(a) *Show that*

$$\frac{\lambda^n}{\Gamma(n)} \int_1^\infty x^{n-1} e^{-x\lambda} dx = \sum_{j=0}^{n-1} e^{-\lambda} \frac{\lambda^j}{j!}.$$

(b) *Obtain the identity used in Example 4.3.3.*

EXERCISE 4.46. [4.46](#) *Distribution Quantiles Obtain closed-form expressions for the distribution quantiles based on the exponential and Laplace distributions.*

EXERCISE 4.47. [4.47](#) *Potential Outlier Probability Suppose the pdf $f(x)$ is symmetric about 0. Show that the probability of a potential outlier from this distribution is $2F(4q_1)$, where $F^{-1}(0.25) = q_1$. Use this for:*

(a) *The normal distribution.*

(b) *The logistic distribution.*

(c) *The Laplace distribution.*

EXERCISE 4.48. [4.48](#) *Data Summary and Outliers Consider the sample of data: 13, 5, 202, 15, 99, 4, 67, 83, 36, 11, 301, 23, 213, 40, 66, 106, 78, 69, 166, 84, 64.*

(a) *Obtain the five-number summary.*

(b) *Determine if there are any outliers.*

(c) *Boxplot the data. Comment.*

EXERCISE 4.49. [4.49](#) *Normal Q-Q Plot Consider the data in Exercise 4.4.3. Obtain the normal q-q plot. Does it suggest the underlying distribution is normal? If not, determine a more appropriate distribution.*

EXERCISE 4.50. [4.50](#) *Exponential Order Statistic Let $Y_1 < Y_2 < Y_3 < Y_4$ be the order statistics of a random sample of size 4 from the distribution having pdf $f(x) = e^{-x}$, $0 < x < \infty$. Find $P(Y_4 \geq 3)$.*

EXERCISE 4.51. [4.51](#) *Continuous Distribution Order Stats Let X_1, X_2, X_3 be a random sample from a distribution having pdf $f(x) = 2x$, $0 < x < 1$.*

(a) *Compute the probability that the smallest exceeds the median.*

(b) *Find the correlation between Y_2 and Y_3 .*

EXERCISE 4.52. [4.52](#) *Discrete Order Statistic PMF Let $f(x) = 1/6$, $x = 1, 2, 3, 4, 5, 6$, be the pmf of a discrete distribution. Show that the pmf of the smallest observation of a random sample of size 5 is $g_1(y_1) = (7 - y_1)^5/6^5 - (6 - y_1)^5/6^5$, $y_1 = 1, 2, \dots, 6$.*

EXERCISE 4.53. [4.53](#) *Independent Transformations* Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ denote the order statistics from exponential distribution. Show that $Z_1 = Y_2$ and $Z_2 = Y_4 - Y_2$ are independent.

EXERCISE 4.54. [4.54](#) *Beta Distribution of Order Statistic* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics from $\text{uniform}(0,1)$. Show that Y_k has a beta pdf with parameters $\alpha = k$ and $\beta = n - k + 1$.

EXERCISE 4.55. [4.55](#) *Weibull Minimum* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics from a Weibull distribution. Find the distribution function and pdf of Y_1 .

EXERCISE 4.56. [4.56](#) *Uniform Range* Find the probability that the range of a random sample of size 4 from the uniform distribution is less than $1/2$.

EXERCISE 4.57. [4.57](#) *Ratio of Order Statistics* Let $Y_1 < Y_2 < Y_3$ be order statistics from $f(x) = 2x$, $0 < x < 1$. Show that $Z_1 = Y_1/Y_2$, $Z_2 = Y_2/Y_3$, and $Z_3 = Y_3$ are mutually independent.

EXERCISE 4.58. [4.58](#) *Ratio of Observations* Suppose a random sample of size 2 is obtained from $f(x) = 2(1 - x)$, $0 < x < 1$. Compute the probability that one sample observation is at least twice as large as the other.

EXERCISE 4.59. [4.59](#) *Midrange Distribution* Let $Y_1 < Y_2 < Y_3$ denote order statistics from $\text{uniform}(0,1)$. Let $Z = (Y_1 + Y_3)/2$ be the midrange. Find the pdf of Z .

EXERCISE 4.60. [4.60](#) *Normal Order Stats Expectation* Let $Y_1 < Y_2$ denote the order statistics of a random sample of size 2 from $N(0, \sigma^2)$.

- (a) Show $E(Y_1) = -\sigma/\sqrt{\pi}$.
- (b) Find the covariance of Y_1 and Y_2 .

EXERCISE 4.61. [4.61](#) *Independence Characterizes Exponential* Let $Y_1 < Y_2$ be order statistics from a continuous distribution with pdf $f(x) > 0$ for $x \geq 0$. Show that the independence of $Z_1 = Y_1$ and $Z_2 = Y_2 - Y_1$ characterizes the gamma pdf with $\alpha = 1$.

EXERCISE 4.62. [4.62](#) *Conditional Distribution* Let $Y_1 < Y_2 < Y_3 < Y_4$ be order statistics from $f(x) = 2x$, $0 < x < 1$.

- (a) Find the joint pdf of Y_3 and Y_4 .
- (b) Find the conditional pdf of Y_3 given $Y_4 = y_4$.
- (c) Evaluate $E(Y_3|y_4)$.

EXERCISE 4.63. [4.63](#) *Triangle Probability* Two numbers are selected at random from the interval $(0,1)$. Compute the probability that the three resulting line segments can form a triangle.

EXERCISE 4.64. [4.64](#) *Min and Max Joint PDF* Let X and Y be independent with $f(x) = 2x$ and $g(y) = 3y^2$ on $(0, 1)$. Let $U = \min(X, Y)$ and $V = \max(X, Y)$. Find the joint pdf of U and V .

EXERCISE 4.65. [4.65](#) *Joint PDF of Min and Max* Let the joint pdf of X and Y be $f(x, y) = 12x(x + y)/7$, $0 < x < 1$, $0 < y < 1$. Let $U = \min(X, Y)$ and $V = \max(X, Y)$. Find the joint pdf of U and V .

EXERCISE 4.66. [4.66](#) *Gini's Mean Difference* Let $X_1, X_2, \dots, X_n$ be a random sample. Gini's mean difference is $G = \sum_{j=2}^n \sum_{i=1}^{j-1} |X_i - X_j| / \binom{n}{2}$.

- (a) If $n = 10$, find $a_1, \dots, a_{10}$ so that $G = \sum_{i=1}^{10} a_i Y_i$.
- (b) Show $E(G) = 2\sigma/\sqrt{\pi}$ for normal distribution.

EXERCISE 4.67. [4.67](#) *Exponential Order Stats Properties* Let $Y_1 < Y_2 < \dots < Y_n$ be order statistics from exponential distribution.

- (a) Show $Z_1 = nY_1$, $Z_2 = (n-1)(Y_2 - Y_1)$, $Z_3 = (n-2)(Y_3 - Y_2)$, $\dots$, $Z_n = Y_n - Y_{n-1}$ are independent exponentials.
- (b) Demonstrate that all linear functions of Y_i can be expressed as linear functions of independent random variables.

EXERCISE 4.68. [4.68](#) *PERT Distribution* In PERT, let X_1, X_2, X_3 be three independent uniform random times. For series completion ($Y = X_1 + X_2 + X_3$) and parallel completion ($Z = \max(X_1, X_2, X_3)$), find their pdfs.

EXERCISE 4.69. [4.69](#) *Sample Size for Extreme Quantile* Let Y_n denote the n th order statistic. Find the smallest n for which $P(\xi_{0.9} < Y_n) \geq 0.75$.

EXERCISE 4.70. [4.70](#) *Probability Involving Quantiles* Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ denote order statistics of size 5. Compute:

- (a) $P(Y_1 < \xi_{0.5} < Y_5)$
- (b) $P(Y_1 < \xi_{0.25} < Y_3)$
- (c) $P(Y_4 < \xi_{0.80} < Y_5)$

EXERCISE 4.71. [4.71](#) *Median Between Order Stats* Compute $P(Y_3 < \xi_{0.5} < Y_7)$ if $Y_1 < \dots < Y_9$ are order statistics of size 9.

EXERCISE 4.72. [4.72](#) *Sample Size for Median Coverage* Find the smallest n for which $P(Y_1 < \xi_{0.5} < Y_n) \geq 0.99$.

EXERCISE 4.73. [4.73](#) *Normal Order Stats Interval* Let $Y_1 < Y_2$ be order statistics from $N(\mu, \sigma^2)$ with known σ^2 .

- (a) Show $P(Y_1 < \mu < Y_2) = 1/2$ and compute $E(Y_2 - Y_1)$.
- (b) Find c such that $P(\bar{X} - c\sigma < \mu < \bar{X} + c\sigma) = 1/2$.

EXERCISE 4.74. [4.74](#) *Selection Algorithm* Let $y_1 < y_2 < y_3$ be observed order statistics. A statistician is given these values in random order and wants to select the largest. She looks at the first but refuses it and then takes the second if larger than the first, else takes the third. Show this algorithm has probability $1/2$ of selecting the largest.

EXERCISE 4.75. [4.75](#) *Motor Median CI* Refer to Exercise 4.1.1. Using expression (4.4.10), obtain a confidence interval for the median lifetime of a motor.

EXERCISE 4.76. [4.76](#) *Power Function of Test* Show that the approximate power function given in expression (4.5.12) is strictly increasing. Show the test has approximate size α for testing $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$.

EXERCISE 4.77. [4.77](#) *Darwin Data t-Test* For the Darwin data, verify that the Student t -test statistic is 2.15.

EXERCISE 4.78. [4.78](#) *Neyman-Pearson Test* Let X have pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$. To test $H_0 : \theta = 1$ against $H_1 : \theta = 2$, use critical region $C = \{(x_1, x_2) : x_1 x_2 \geq 3/4\}$. Find the power function.

EXERCISE 4.79. [4.79](#) *Binomial Significance Level* Let X have binomial distribution with $n = 10$ and $p = 1/4$ or $1/2$. Test $H_0 : p = 1/2$ vs $H_1 : p = 1/4$ by rejecting if $X_1 \leq 3$. Find significance level and power.

EXERCISE 4.80. [4.80](#) *Exponential LR Test* Let X_1, X_2 be a sample from $f(x; \theta) = (1/\theta)e^{-x/\theta}$. Reject $H_0 : \theta = 2$ if $f(x_1; 2)f(x_2; 2)/[f(x_1; 1)f(x_2; 1)] \leq 1/2$. Find significance level and power when H_0 is false.

EXERCISE 4.81. [4.81](#) *Power Curve Sketch* Consider tests Test 1 and Test 2. For Test A, reject H_0 if $S \leq k_A$; for Test B, reject if $S \leq k_B$. If Test A has higher significance level, show Test A has higher power.

EXERCISE 4.82. [4.82](#) *Tire Life Test* Let tire life $X \sim N(\theta, 5000^2)$. Test $H_0 : \theta = 30000$ vs $H_1 : \theta > 30000$. Determine n and c so that $\gamma(30000) = 0.01$ and $\gamma(35000) = 0.98$.

EXERCISE 4.83. [4.83](#) *Poisson Power Function* Let X have Poisson distribution. Test $H_0 : \theta = 1/2$ vs $H_1 : \theta < 1/2$. With $n = 12$, reject if $Y = \sum X_i \leq 2$. Graph the power function and determine significance level.

EXERCISE 4.84. [4.84](#) *Binomial Sample Size* Let $Y \sim \text{binomial}(n, p)$. Test $H_0 : p = 1/2$ vs $H_1 : p > 1/2$. Find n and c so that $\gamma(1/2) = 0.10$ and $\gamma(2/3) = 0.95$.

EXERCISE 4.85. [4.85](#) *Uniform Max Test* Let $Y_1 < Y_2 < Y_3 < Y_4$ be order statistics from $f(x; \theta) = 1/\theta$, $0 < x < \theta$. Test $H_0 : \theta = 1$ vs $H_1 : \theta > 1$ by rejecting if $Y_4 \geq c$.

(a) Find c for $\alpha = 0.05$.

(b) Determine the power function.

EXERCISE 4.86. [4.86](#) *Poisson Test Size* Let $X_1, \dots, X_8$ be from Poisson with mean μ . Test $H_0 : \mu = 0.5$ vs $H_1 : \mu > 0.5$ by rejecting if $\sum x_i \geq 8$.

(a) Show significance level is $1 - \text{ppois}(7, 4)$.

(b) Determine $\gamma(0.75)$, $\gamma(1)$, $\gamma(1.25)$.

EXERCISE 4.87. [4.87](#) *Tennis Serve Hypothesis* Let p be probability that first serve is good. Test $H_0 : p = 0.40$ vs $H_1 : p > 0.40$ with $n = 25$. Reject if $Y \geq 13$.

(a) Show $\alpha = 1 - \text{pbinom}(12, 25, 0.4)$.

(b) Find β when $p = 0.60$.

EXERCISE 4.88. [4.88](#) *Bernoulli Power Comparison* Let S be number of successes in $n = 40$ Bernoulli trials. Test $H_0 : p \leq 0.3$ vs $H_1 : p > 0.3$. Compare tests: (1) Reject if $S \geq 16$ and (2) Reject if $S \geq 17$. Determine levels.

EXERCISE 4.89. [4.89](#) *Proportion Power Curve* Consider the two-sided test for proportions. Write R code to compute a plot of the power curve.

EXERCISE 4.90. [4.90](#) *Power Function Derivative* Consider the power function $\gamma(\mu)$. Show $\gamma'(\mu)$ is strictly negative for $\mu < \mu_0$ and strictly positive for $\mu > \mu_0$.

EXERCISE 4.91. [4.91](#) *Exact Size t-Test* Show that the test defined by (4.6.9) has exact size α for testing $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$.

EXERCISE 4.92. [4.92](#) *One vs Two-Sided Power* Consider the one-sided t-test and two-sided t-test, both of size α . Show that for $\mu > \mu_0$, the power function of the one-sided test is larger.

EXERCISE 4.93. [4.93](#) *Paired Design Analysis* A baseball coach paired 20 members by speed. Data on self vs rival times are given.

(a) Obtain comparison boxplots. Comment.

(b) Compute paired t-test and p-value.

(c) Obtain point estimate and 95% CI for μ_d .

(d) Conclude.

EXERCISE 4.94. [4.94](#) *AZT Dosage Study* A data set concerning the effect of AZT dosages on HIV patients. Compare 300mg and 600mg groups.

(a) Obtain comparison boxplots.

(b) Compute two-sample t-test and p-value.

(c) Obtain point estimate and 95% CI for Δ .

(d) Conclude.

EXERCISE 4.95. **4.95** *Air Quality Comparison* Compare suspended particle concentrations between Melbourne and Houston. Test $H_0 : \mu_X = \mu_Y$ against $H_1 : \mu_X < \mu_Y$.

- (a) Define test statistic and critical region.
- (b) Calculate with given statistics.

EXERCISE 4.96. **4.96** *Seat Belt Campaign* Let p be proportion of drivers using seat belts. After campaign, $y = 104$ out of $n = 590$ wore belts. Was campaign successful?

- (a) Define hypotheses.
- (b) Critical region at $\alpha = 0.01$.
- (c) Determine p -value.

EXERCISE 4.97. **4.97** *Variance Test Critical Value* Test $H_0 : \sigma^2 = \sigma_0^2$ against $H_1 : \sigma^2 > \sigma_0^2$ using critical region $(n-1)S^2/\sigma_0^2 \geq c$. If $n = 13$ and $\alpha = 0.025$, determine c .

EXERCISE 4.98. **4.98** *F-Test Critical Value* Test $H_0 : \sigma_1^2 = \sigma_2^2$ against $H_1 : \sigma_1^2 > \sigma_2^2$ using $F \geq c$. If $n = 13$, $m = 11$, and $\alpha = 0.05$, find c .

EXERCISE 4.99. **4.99** *Modified Frequency Test* Suppose observed frequencies of $A_1, \dots, A_4$ are 20, 30, 92, 105. Calculate the test and report p -value.

EXERCISE 4.100. **4.100** *Continuous Interval Test* A number is selected from $(0, 2)$. Test hypothesis with $p_{i0} = \int_{A_i} (1/2)(2-x)dx$. For observed frequencies 30, 30, 10, 10, would H_0 be accepted?

EXERCISE 4.101. **4.101** *Normal Approximation Test* Define sets $A_1 = \{x : -\infty < x \leq 0\}$, $A_i = \{x : i-2 < x \leq i-1\}$ for $i = 2, \dots, 7$, $A_8 = \{x : 6 < x < \infty\}$. Test with frequencies 60, 96, 140, 210, 172, 160, 88, 74.

EXERCISE 4.102. **4.102** *Die Casting Test* A die was cast $n = 120$ times with frequencies: 1: b , 2:20, 3:20, 4:20, 5:20, 6:40 – b . For what values of b would the hypothesis of unbiased die be rejected at 0.025 level?

EXERCISE 4.103. **4.103** *Mendelian Genetics* Mendelian theory states probabilities are 9/16, 3/16, 3/16, 1/16 for four classifications. With observed frequencies 86, 35, 26, 13 out of 160, test at $\alpha = 0.01$.

EXERCISE 4.104. **4.104** *Teaching Method Comparison* Two groups of 100 students each. Test at 5% whether the two distributions are the same.

EXERCISE 4.105. **4.105** *Crime and Alcoholism Data* on crime type and alcoholic status. Test independence.

- (a) Compute χ^2 -test for independence.
- (b) Use Pearson residuals to determine strongest dependence.
- (c) Confirm with conditional test.

EXERCISE 4.106. [4.106](#) *Independence Test* 180 independent trials with classification into A_1, A_2, A_3 and B_1, B_2, B_3, B_4 . What is smallest k that leads to rejection at $\alpha = 0.05$?

EXERCISE 4.107. [4.107](#) *Poisson Goodness of Fit* Fit Poisson distribution to data: $x: 0, 1, 2, 3, 3 < x$ with frequencies 20, 40, 16, 18, 6.

(a) Compute chi-square statistic.

(b) Degrees of freedom?

(c) Reject at $\alpha = 0.05$?

EXERCISE 4.108. [4.108](#) *MCT Converse* Prove the converse of Theorem MCT: Let X have continuous cdf $F(x)$ strictly increasing. Show $Z = F(X)$ has uniform(0,1) distribution.

EXERCISE 4.109. [4.109](#) *Monte Carlo Log 2 Approximate* $\log 2 = \int_0^1 1/(x+1)dx$ using uniform(0,1) generator. Write R function and compare with true value.

EXERCISE 4.110. [4.110](#) *Normal CDF Approximation* Approximate $\int_0^{1.96} (1/\sqrt{2\pi}) \exp\{-t^2/2\}dt$ using Monte Carlo.

EXERCISE 4.111. [4.111](#) *Location-Scale Generation* Suppose X has pdf $f_X(x) = b^{-1}f((x-a)/b)$. If we can generate from $f(z)$, explain how to generate from $f_X(x)$.

EXERCISE 4.112. [4.112](#) *Logistic Distribution Generation* Determine a method to generate random observations for the logistic pdf. Write R function and verify with histogram.

EXERCISE 4.113. [4.113](#) *Beta Generator* Determine a method to generate random observations for $f(x) = 4x^3$, $0 < x < 1$. Write R function.

EXERCISE 4.114. [4.114](#) *Laplace Inverse CDF* Obtain the inverse function of the cdf of the Laplace pdf $f(x) = (1/2)e^{-|x|}$. Write R function.

EXERCISE 4.115. [4.115](#) *Extreme Value Generation* Determine a method to generate random observations for the extreme-valued pdf $f(x) = \exp\{x - e^x\}$. Write R function.

EXERCISE 4.116. [4.116](#) *Cauchy Distribution* Determine a method to generate random observations for the Cauchy distribution $f(x) = 1/[\pi(1+x^2)]$. Write R function.

EXERCISE 4.117. [4.117](#) *Weibull Generation* Determine a method to generate random observations for the Weibull distribution. Write R function.

EXERCISE 4.118. [4.118](#) *Contaminated Normal Power* Write algorithm to simulate power of the test for contaminated normal distribution. Modify R function.

EXERCISE 4.119. [4.119](#) *Logistic Power Simulation* Write algorithm to simulate significance level and power for logistic distribution.

EXERCISE 4.120. [4.120](#) *General Inverse CDF* For cdf $F(x)$ not strictly increasing, define $F^{-1}(u) = \inf\{x : F(x) \geq u\}$. Let $U \sim \text{uniform}(0, 1)$. Prove $F^{-1}(U)$ has cdf $F(x)$.

EXERCISE 4.121. [4.121](#) *Ratio Maximum* Verify the derivative in (4.8.12) and show the function attains maximum at $x = (\alpha - [\alpha])/(1 - b)$.

EXERCISE 4.122. [4.122](#) *Minimum Derivation* Derive expression (4.8.14) and show $b = [\alpha]/\alpha$ gives minimum.

EXERCISE 4.123. [4.123](#) *Gamma via Beta* Assume $Y_1 \sim \Gamma(\alpha+1, 1)$, $Y_2 \sim \text{uniform}(0, 1)$. Let $X_1 = Y_1 Y_2^{1/\alpha}$ and $X_2 = Y_2$. Show $X_1 \sim \Gamma(\alpha, 1)$.

EXERCISE 4.124. [4.124](#) *Ratio Derivative* Show the derivative of the ratio in (4.8.10) is $-x \exp\{-x^2/2\}(x^2 - 1)$ with critical values ± 1 .

EXERCISE 4.125. [4.125](#) *Beta Distribution Generation* Consider accept-reject algorithm for beta distribution. Show X has beta distribution with parameters α and β .

EXERCISE 4.126. [4.126](#) *Marsaglia-Bray Normal* Consider the Marsaglia-Bray algorithm for generating normal random variables. Show X_1 and X_2 are iid $N(0, 1)$.

EXERCISE 4.127. [4.127](#) *Bootstrap CI for Mean* Use the R function `percentboot` to obtain a bootstrap 95% confidence interval for the mean concentration. Compare with t -CI.

EXERCISE 4.128. [4.128](#) *Bootstrap Sample Properties* Let $x_1^*, \dots, x_n^*$ be a bootstrap sample drawn with replacement.

- (a) Show x_i^* are iid with common cdf $\hat{F}_n$.
- (b) Show $E(x_i^*) = \bar{x}$.
- (c) If n odd, show $\text{median}\{x_i^*\} = x_{(n+1)/2}$.
- (d) Show $V(x_i^*) = n^{-1} \sum (x_i - \bar{x})^2$.

EXERCISE 4.129. [4.129](#) *Gamma Bootstrap CI* Let $X_1, \dots, X_n \sim \Gamma(1, \beta)$.

- (a) Show $(2n\bar{X}/(\chi_{2n}^2)^{(1-\alpha/2)}, 2n\bar{X}/(\chi_{2n}^2)^{(\alpha/2)})$ is exact CI for β .
- (b) Show 90% CI for data is (64.99, 136.69).

EXERCISE 4.130. [4.130](#) *Bootstrap Median CI* Suppose we want to estimate the median using sample median. Obtain 90% bootstrap percentile CI. Did it trap the true median?

EXERCISE 4.131. [4.131](#) *Bootstrap t -Interval* Suppose $X_1, \dots, X_n \sim N(\mu, \sigma^2)$. Show the pivot $t = (\bar{X} - \mu)/(S/\sqrt{n})$ leads to CI.

EXERCISE 4.132. [4.132](#) *Standardized Bootstrap CI* Consider bootstrap pivot $t^* = (\bar{x}^* - \bar{x})/(s^*/\sqrt{n})$.

- (a) Rewrite percentile CI algorithm using t^* .

- (b) Find 90% CI for data in Example 4.9.3.
- (c) Compare with nonstandardized CI.

EXERCISE 4.133. [4.133](#) *Bootstrap Median Test* Consider algorithm for two-sample bootstrap test based on difference in medians.

- (a) Rewrite algorithm for median.
- (b) Obtain bootstrap test.
- (c) Compare p -value with 0.063.

EXERCISE 4.134. [4.134](#) *Two-Sample t -Test Value* Consider data of Example 4.9.2. Show $t = 0.93$ with p -value 0.18.

EXERCISE 4.135. [4.135](#) *Bootstrap Two-Sided Test* In Example 4.9.3, test $H_0 : \mu = 90$ vs $H_1 : \mu \neq 90$.

- (a) Determine bootstrap p -value.
- (b) Rewrite R program.
- (c) Compute p -value with 3000 bootstraps.

EXERCISE 4.136. [4.136](#) *Permutation Test* Consider permutation test for two-sample problem.

- (a) For $x' = (10, 15, 21)$ and $y' = (20, 25, 30)$, determine p -value.
- (b) Approximate permutation test with 3000 resamples.
- (c) Probability of distinct samples?

EXERCISE 4.137. [4.137](#) *Bootstrap z Distribution* Let z^* be drawn from discrete distribution with mass n^{-1} at $z_i = x_i - \bar{x} + \mu_0$. Determine $E(z^*)$ and $V(z^*)$.

EXERCISE 4.138. [4.138](#) *Bootstrap t -Test Value* For Example 4.9.3, show $t = 0.84$ and p -value is 0.20.

EXERCISE 4.139. [4.139](#) *Bootstrap Median Test* For Example 4.9.3, obtain bootstrap test based on medians for $H_0 : \mu = 90$ vs $H_1 : \mu > 90$.

EXERCISE 4.140. [4.140](#) *Darwin Experiment Bootstrap* Consider Darwin's experiment on *Zea mays*.

- (a) Obtain bootstrap test keeping pairing intact.
- (b) Write R program and compare p -value.

本章小结

核心概念：

- 统计量：样本的函数，不依赖未知参数
- 点估计：MLE、矩估计；无偏性、偏差

- **置信区间**：参数的合理取值范围；宽度随样本量增大而减小
- **假设检验**：第一类和第二类错误的权衡

重要公式：

场景	置信区间/检验统计量
正态均值、已知 σ	$\bar{X} \pm z_{\alpha/2}\sigma/\sqrt{n}$
正态均值、未知 σ	$\bar{X} \pm t_{\alpha/2, n-1}S/\sqrt{n}$
正态方差	$\frac{(n-1)S^2}{\chi^2_{\alpha/2, n-1}}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2, n-1}}$
单样本 Z 检验	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$
单样本 t 检验	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$
拟合优度 χ^2	$\chi^2 = \sum \frac{(O-E)^2}{E} \approx \chi^2(k-1)$

8. 附录：公式推导

8.1. 通用 MLE 推导. 背景：最大似然估计的通用推导框架。

核心思想：MLE 选择使似然函数最大化的参数值。在正则条件下，MLE 满足似然方程 $\frac{\partial l(\theta)}{\partial \theta} = 0$ 。

渐近性质（不证）：在温和条件下， $\hat{\theta}$ 具有以下渐近性质：

- (1) **一致性**： $\hat{\theta} \xrightarrow{P} \theta$
- (2) **渐近正态性**： $\sqrt{n}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, I(\theta)^{-1})$ ，其中 $I(\theta)$ 是 Fisher 信息量
- (3) **渐近有效性**：方差达到 Cramér-Rao 下界

这些性质使 MLE 成为现代统计推断的基石。

8.2. 指数分布 MLE 的推导. 背景：设 $X_1, \dots, X_n \sim \text{Exp}(\theta)$ ，即 $f(x) = \theta^{-1} \exp\{-x/\theta\}$ ， $x > 0$ 。

目标：求使似然函数最大化的 θ 值。

推导步骤：

1. 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta^{-1} \exp\{-x_i/\theta\} = \theta^{-n} \exp\{-\theta^{-1} \sum_{i=1}^n x_i\}.$$

2. 对数似然函数为

$$l(\theta) = -n \log \theta - \theta^{-1} \sum_{i=1}^n x_i.$$

3. 求导并设为零：

$$\frac{\partial l(\theta)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i = 0.$$

4. 解得

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

5. 验证这是最大值（二阶导数为负）：

$$\frac{\partial^2 l(\theta)}{\partial \theta^2} = \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^n x_i = -\frac{n}{\theta^2} < 0.$$

结论： $\hat{\theta} = \bar{X}$ 是 θ 的 MLE。由于 $\mathbb{E}(X) = \theta$ ，故它也是无偏的。

8.3. 二项分布 MLE 的推导. 背景：设 $X \sim \text{Bernoulli}(\theta)$ ，对于随机样本 $X_1, \dots, X_n$ 。

目标：求 θ 的 MLE。

推导步骤：

1. 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} = \theta^{\sum x_i} (1-\theta)^{n-\sum x_i}.$$

2. 对数似然函数为

$$l(\theta) = \left(\sum_{i=1}^n x_i \right) \log \theta + \left(n - \sum_{i=1}^n x_i \right) \log(1-\theta).$$

3. 求导并设为零：

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{\sum x_i}{\theta} - \frac{n - \sum x_i}{1-\theta} = 0.$$

4. 解得

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

结论：样本均值（样本比例）是 θ 的 MLE，也是无偏估计。

8.4. 正态分布 MLE 的推导. 背景：设 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，对于随机样本。

目标：求 μ 和 σ^2 的 MLE。

推导步骤：

1. 对数似然函数为

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2.$$

2. 对 μ 求偏导并设为零：

$$\frac{\partial l}{\partial \mu} = -\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu} = \bar{x}.$$

3. 对 σ 求偏导并设为零（先代入 $\hat{\mu}$ ）：

$$\frac{\partial l}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \bar{x})^2 = 0 \implies \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

注意： $\hat{\sigma}^2$ 是有偏的，因为

$$\mathbb{E}[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2.$$

无偏估计为 $S^2 = \frac{n}{n-1} \hat{\sigma}^2$ 。

8.5. 置信区间推导汇总. 背景：置信区间构造的核心思想是找枢轴量。

枢轴量的定义：设 $Q = q(X_1, \dots, X_n; \theta)$ 。如果 Q 的分布不依赖于 θ ，则称 Q 为枢轴量。

构造步骤：

- (1) 找一个枢轴量 Q
- (2) 确定 a, b 使得 $\mathbb{P}(a \leq Q \leq b) = 1 - \alpha$
- (3) 解不等式得到 θ 的置信区间

8.6. 正态均值置信区间（已知方差）的推导. 背景：设 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ ，其中 σ^2 已知，推导 μ 的置信区间。

已知条件：

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- 标准化的随机变量 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$

目标：找到 L 和 U 使得 $\mathbb{P}(L \leq \mu \leq U) = 1 - \alpha$

推导步骤：

1. 由标准正态分布的对称性：

$$\mathbb{P}(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha.$$

2. 代入 Z 的表达式：

$$\mathbb{P}\left(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha.$$

3. 利用不等式的代数运算：

$$\mathbb{P}\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

4. 因此置信区间为：

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

关键洞察：区间以 $\bar{X}$ 为中心，宽度为 $2z_{\alpha/2}\sigma/\sqrt{n}$ ，随 $\sqrt{n}$ 减小。

8.7. 正态均值置信区间（未知方差）的推导. 背景：设 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ ，其中 σ^2 未知，用 S^2 估计。

已知条件：

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$
- $\bar{X}$ 与 S^2 独立

目标：推导 μ 的置信区间

推导步骤：

1. 构造枢轴量：

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

2. 可以证明 $T \sim t(n-1)$ 。
3. 给定置信水平 $1 - \alpha$ ：

$$\mathbb{P}(-t_{\alpha/2, n-1} \leq T \leq t_{\alpha/2, n-1}) = 1 - \alpha.$$

4. 代入 T 并解出 μ ：

$$\mathbb{P}\left(\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}\right) = 1 - \alpha.$$

5. 因此置信区间为：

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \right].$$

与已知方差情形的比较：用 S 替代 σ ，用 t 分位数替代 z 分位数。由于 t 分布比正态分布更重尾，区间更宽，反映了用样本方差代替总体方差的不确定性。

8.8. 方差置信区间的推导. 背景：推导正态分布方差 σ^2 的置信区间。

已知条件： $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$

推导步骤：

1. 由卡方分布的性质：

$$\mathbb{P}\left(\chi_{1-\alpha/2, n-1}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{\alpha/2, n-1}^2\right) = 1 - \alpha.$$

2. 解出 σ^2 ：

$$\mathbb{P}\left(\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}\right) = 1 - \alpha.$$

3. 因此置信区间为：

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right].$$

8.9. 假设检验的推导. 背景：正态均值检验的推导。

已知方差情形：

1. 在 $H_0: \mu = \mu_0$ 下， $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ 。
2. 拒绝域为 $Z > z_\alpha$ （单侧）或 $|Z| > z_{\alpha/2}$ （双侧）。
3. p 值定义为观察到比当前样本更极端结果的概率。

未知方差情形：

1. 在 $H_0: \mu = \mu_0$ 下， $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ 。
2. 拒绝域为 $|T| > t_{\alpha/2, n-1}$ 。
3. p 值由 t 分布计算。

8.10. 卡方统计量极限分布的推导. 背景：拟合优度 χ^2 统计量的极限分布推导。**推导步骤：**

1. 在 H_0 下, $O_i \sim \text{Binomial}(n, p_{i0})$, 因此 $\mathbb{E}(O_i) = E_i = np_{i0}$, $\text{var}(O_i) = np_{i0}(1-p_{i0})$ 。
2. 标准化: $Z_i = (O_i - E_i)/\sqrt{E_i}$ 。
3. 可以证明 Z_i 近似服从 $\mathcal{N}(0, 1-p_{i0})$, 且协方差矩阵不是单位矩阵 (因为 $\sum O_i = n$ 是约束)。
4. 因此

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \approx \chi^2(k-1).$$

自由度减 1 是因为约束 $\sum O_i = n$ 。**8.11. 蒙特卡洛方法的推导. 背景：**接受-拒绝算法的推导和收敛性分析。**逆 CDF 方法：**

定理：如果 $U \sim \text{Uniform}(0, 1)$, F 是连续分布函数, 则 $X = F^{-1}(U)$ 的分布函数为 F 。

证明：设 $X = F^{-1}(U)$, 即 $X \leq x$ 当且仅当 $U \leq F(x)$ 。因此

$$\mathbb{P}(X \leq x) = \mathbb{P}(U \leq F(x)) = F(x).$$

证毕。

接受-拒绝算法：

1. 每次迭代的接受概率为

$$\mathbb{P}(\text{接受}) = \int \frac{f(y)}{Mg(y)}g(y)dy = \frac{1}{M} \int f(y)dy = \frac{1}{M}.$$

2. 因此平均接受次数为 M 。

3. 效率与 M 成反比。

收敛性：由大数定律, 接受的样本确实来自 $f(x)$ 。

8.12. Bootstrap 的理论基础. 背景：Bootstrap 的理论基础。

核心假设：样本的经验分布函数 $\hat{F}_n$ 是真实分布 F 的良好估计。

Bootstrap 分布：

$$T^* \mid X_1, \dots, X_n \approx T \mid X_1, \dots, X_n$$

其中 $\approx$ 表示“分布近似”。**误差分析：**

Bootstrap 的误差来源：

- (1) 抽样变异性：由 B 的有限性引入
- (2) 代理误差：由 $\hat{F}_n$ 逼近 F 引入

当样本量 n 足够大时, 这两种误差都可以控制。**偏差校正 Bootstrap：**

如果 $\hat{\theta}$ 有系统性偏差 ($\mathbb{E}[\hat{\theta}] \neq \theta$)，则 percentile bootstrap 区间可能有偏差。偏差校正因子：

$$\hat{a} = \Phi^{-1} \left(\frac{\#\{\hat{\theta}_b^* < \hat{\theta}\}}{B} \right).$$

偏差校正的置信区间为 $[\theta_{\alpha_1}^*, \theta_{\alpha_2}^*]$ ，其中 $\alpha_1 = \Phi(2\hat{a} + z_\alpha)$ ， $\alpha_2 = \Phi(2\hat{a} - z_\alpha)$ 。

1. 附录：公式推导

1.1. Gamma 分布的矩母函数推导. 背景 (Background)： 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions)：

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given)：

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal)： 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps)：

1. 根据矩母函数定义：

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换：令 $y = \frac{x(1-\beta t)}{\beta}$ ，则 $x = \frac{\beta y}{1-\beta t}$ ， $dx = \frac{\beta}{1-\beta t} dy$ 。

3. 代入积分（要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$ ）：

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论： 因此， $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ ，定义域为 $t < 1/\beta$ 。■

1.2. Gamma 分布的均值与方差推导. 背景 (Background)： 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$ ，方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given)：

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal)： 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps)：

1. 计算一阶导数：

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$. ■

1.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

1.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

1.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

1.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。

2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。

3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导：

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则：

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论： $|J|$ 度量了变换下的面积元素缩放比例。■

1.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义：

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$ ：

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf：

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证：边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$ ，确实是合法的 pdf。

结论： 条件 pdf 公式得证。■

1.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发：

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望（即关于 X_1 求平均）：

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序：

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1)f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论：全期望公式得证。■

1.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论：条件均值的方差不超过原变量的方差，等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

1.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论：故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

1.11. 相关系数范围的推导. 背景 (Background)：我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal)：证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps)：

1. Cauchy-Schwarz 不等式：对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差，令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$ ：

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方：

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此：

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论：故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

1.12. 二元正态条件分布的推导. 背景 (Background)：在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions)：

- μ_1, μ_2 ：边缘分布均值
- σ_1^2, σ_2^2 ：边缘分布方差
- ρ ：相关系数
- $f(x_1, x_2)$ ：二元正态联合密度

目标 (Goal)：求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps)：

1. 条件密度公式：

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1 \sqrt{2\pi}} \exp\left\{-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数)：

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1 - \rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1 \sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right]\right\}.$$

3. 关于 x_2 完全平方配方：

$$\frac{(x_2 - \mu_2)^2}{\sigma_2^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1 \sigma_2} = \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho \frac{x_1 - \mu_1}{\sigma_1} \right)^2 - \rho^2 \frac{(x_1 - \mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理：

$$f(x_1, x_2) \propto \exp \left\{ -\frac{(x_1 - \mu_1)^2}{2\sigma_1^2} \right\} \cdot \exp \left\{ -\frac{1}{2(1-\rho^2)} \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho \frac{x_1 - \mu_1}{\sigma_1} \right)^2 \right\}.$$

5. 因此条件密度为：

$$f_{2|1}(x_2|x_1) \propto \exp \left\{ -\frac{1}{2(1-\rho^2)} \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho \frac{x_1 - \mu_1}{\sigma_1} \right)^2 \right\}.$$

6. 这正是均值为 $\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论：二元正态的条件分布仍是正态分布。■

1.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义：

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E} \left[\exp \left(t \sum_{i=1}^n k_i X_i \right) \right] = \mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积：

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域：由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论：故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

1.14. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义：

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开：

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得：

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论： 因此， $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ ，均值为 np ，方差为 $np(1-p)$ 。■

1.15. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为：

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义：

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开：

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$ ，得：

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$ ，即 $t < -\log(1-p)$ 。

结论： 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

1.16. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质，这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k + j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1 - p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1 - p)^i = p \cdot \frac{(1 - p)^y}{1 - (1 - p)} = (1 - p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k + j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k + j)}{\mathbb{P}(Y \geq k)} = \frac{(1 - p)^{k+j}}{(1 - p)^k} = (1 - p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性：已知前 k 次失败，未来等待时间与最初等待时间分布相同。■

1.17. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。

2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

1.18. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。
2. 则 $X = \sum_{j=1}^n I_j$ 。
3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。
3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

1.19. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1 - p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1) \cdots (n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} \rightarrow 1,$$

$$\left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论： Poisson 分布是二项分布在“稀有事件”情形下的极限。■

1.20. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数:

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论： Poisson 分布的均值和方差相等，都等于参数 λ 。■

1.21. 卡方分布与正态分布的关系. 背景 (Background): 卡方分布定义为标准正态平方和。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, 则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps):

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$, 先求 cdf:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式:

$$f_Y(y) = \frac{1}{\Gamma(1/2) 2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论：标准正态变量的平方服从自由度为 1 的卡方分布。■

1.22. 卡方分布的可加性证明. 背景 (Background): 卡方分布满足可加性: 独立卡方变量之和仍为卡方分布。

目标 (Goal): 证明若 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立, 则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps):

1. 由卡方分布与 Gamma 分布的关系: $\chi^2(r) = \Gamma(r/2, 2)$ 。
2. 利用 Gamma 分布的可加性 (见定理 3.3.1): 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。
3. 因此:

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf: $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$, 故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论：卡方分布具有可加性, 自由度可累加。■

1.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1-y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1-y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1-y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1+X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1-y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1-y_2)^{\beta-1}.$$

结论：Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

1.24. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1}(1-y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1}(1-y)^{\beta-1} dy = \frac{B(\alpha+1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha+\beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha+2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \frac{\alpha^2}{(\alpha+\beta)^2} = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha+\beta}$, 方差为 $\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$ 。 ■

1.25. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。 ■

1.26. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}\left[e^{(t/\sigma)X}\right] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu\frac{t}{\sigma} + \frac{1}{2}\sigma^2\left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

1.27. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

2. 问答记录

问题记录. 问题: ... 回答: ...

学习笔记.