

数理统计导论

Hogg, McKean, Craig

目录

引言：从随机性中学习	7
引言：从随机性中学习	7
1. 为什么需要概率论?	7
2. 教材内容预览	7
3. 这三章的内在逻辑	10
4. 学习方法建议	10
5. 习题说明	11
Chapter 1. Probability and Distributions	13
Chapter 1 Overview	13
1. 1.1 Introduction: Why Probability Theory?	13
2. 1.2 Sets: The Language of Uncertainty	14
3. 1.3 The Probability Set Function	15
4. 1.4 Conditional Probability and Independence	15
5. 1.5 Random Variables	17
6. 1.6 Discrete Random Variables	17
7. 1.7 Continuous Random Variables	19
8. 1.8 Expectation of a Random Variable	21
9. 1.9 Some Special Expectations	22
10. 1.10 Important Inequalities	24
Summary	25
Exercises	25
11. 附录：公式推导	27
Chapter 2. 多元随机变量及其分布	35
Chapter 2 概述	35
1. 2.1 从一元到多元：联合分布	35
2. 2.2 边缘分布：积分即求和	37
3. 2.3 条件分布：信息的价值	39
4. 2.4 独立性：变量间的”无关系”	45
5. 2.5 相关性：线性关联的度量	48
6. 2.6 二元正态：最重要的二元分布	50
7. 2.7 多元推广	52

8. 本章总结	54
习题	54
9. 附录：公式推导	55
Chapter 3. Special Distributions	67
Chapter 3 Overview	67
1. 3.1 二项分布及其相关分布	67
2. 3.2 Poisson 分布	72
3. 3.3 Gamma、 χ^2 与 Beta 分布	74
4. 3.4 正态分布 (Normal Distribution)	77
5. 3.5 多元正态分布	78
6. 3.6 t 分布与 F 分布	79
本章小结	81
习题	81
7. 附录：公式推导	90
Chapter 4. Some Elementary Statistical Inferences	97
Chapter 4 Overview	97
1. 4.1 Sampling and Statistics	97
2. 4.2 Confidence Intervals	100
3. 4.4 Hypothesis Testing	102
4. 4.5 Chi-Square Tests	103
5. 4.6 Monte Carlo Methods	106
6. 4.7 Bootstrap Methods	107
Exercises	107
本章小结	122
7. 附录：公式推导	122
Chapter 5. Asymptotic Theory	129
Chapter 5 Overview	129
1. 5.1 Convergence in Probability	129
2. 5.2 Convergence in Distribution	132
3. 5.3 Central Limit Theorem	136
4. 5.4 Extensions to Multivariate Distributions	137
Exercises	138
本章小结	142
5. 附录：公式推导	142
Chapter 6. Maximum Likelihood Methods	151
Chapter 6 Overview	151
1. 6.1 Maximum Likelihood Estimation	151

2.	6.2 Rao-Cramér Lower Bound and Efficiency	153
3.	6.3 Maximum Likelihood Tests	157
4.	6.4 Multiparameter Case: Estimation	158
5.	6.5 Multiparameter Case: Testing	161
6.	6.6 The EM Algorithm	162
7.	附录：公式推导	164
Chapter 7. Sufficiency and Quality of Estimators		169
Chapter 7 Overview		169
1.	7.1 Measures of Quality of Estimators	169
2.	7.2 A Sufficient Statistic for a Parameter	170
3.	7.3 Properties of a Sufficient Statistic	173
4.	7.4 Completeness and Uniqueness	174
5.	7.5 The Exponential Class of Distributions	176
6.	7.6 Functions of a Parameter	177
7.	7.7 The Case of Several Parameters	178
8.	7.8 Minimal Sufficiency and Ancillary Statistics	180
9.	7.9 Sufficiency, Completeness, and Independence	181
Chapter 8. Optimal Statistical Tests		185
Chapter 8 Overview		185
1.	8.1 Most Powerful Tests	185
2.	8.2 Uniformly Most Powerful Tests	189
3.	8.3 Likelihood Ratio Tests	191
4.	8.4 *Sequential Probability Ratio Test	194
5.	8.5 *Minimax and Classification Procedures	196
附录：公式推导		197
Chapter 9. ANOVA and Regression		201
Chapter 9 Overview		201
1.	9.1 Introduction	201
2.	9.2 One-Way ANOVA	202
3.	9.3 Noncentral χ^2 and F Distributions	203
4.	9.4 Multiple Comparisons	204
5.	9.5 Two-Way ANOVA	205
6.	9.6 A Regression Problem	206
7.	9.7 A Test of Independence	208
8.	9.8 Distributions of Certain Quadratic Forms	208
9.	9.9 The Independence of Certain Quadratic Forms	209
附录：公式推导		209

附录 A. 附录：公式推导	213
1. 问答记录	228

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 *notation*，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 Overview

本章从概率论的公理化基础出发，逐步建立整套理论框架。这条脉络贯穿本书始终——理解随机现象的本质、建立描述分布的工具、掌握期望与矩的计算。

为什么从概率论开始？ 因为统计学的一切推断都建立在概率论的基础上。如果不理解概率的数学本质，就无法真正理解统计推断的逻辑。

本章路线图： 随机现象 → 概率公理 → 条件概率与独立性 → 随机变量 → 离散/连续分布 → 期望与矩 → 矩母函数 → 重要不等式

1. 1.1 Introduction: Why Probability Theory?

1.1. The Genesis of Probability. 概率论的故事始于一场赌博。1654 年，赌徒 Chevalier de Méré 向数学家 Blaise Pascal 提出一个问题：如果两名玩家在赌局中途中断，如何公平地分配赌金？这个问题引发了 Pascal 与 Pierre de Fermat 的通信，从而奠定了概率论的基础。

从频率到概率： 设想进行 N 次重复实验。事件 A 发生的次数记为 $f_N(A)$ ，则 $f_N(A)/N$ 称为相对频率 (relative frequency)。当 N 增大时， $f_N(A)/N$ 趋于稳定，趋向某个数 p ——这正是事件 A 的概率。Kolmogorov 在 1933 年的开创性著作《概率论基础》中将这种直觉严格化，建立了现代概率论的公理化体系。

两派观点： 概率的相对频率解释依赖于实验可重复的条件。另一种观点——贝叶斯学派——将概率视为主观信念的度量。无论采用哪种解释，概率的数学性质（公理）都是一致的，因此我们可以在坚实的数学基础上统一处理。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. Random Experiments and Sample Spaces. 若一个实验可以在相同条件下重复进行，且所有可能的结果可以在实验前描述，我们就称其为随机实验 (random experiment)。

所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

这三个例子揭示了样本空间的三种类型：离散有限（硬币）、离散无限（骰子）、连续（等待时间）。理解样本空间的类型决定了我们使用离散还是连续的数学工具。

EXAMPLE 1.1 (Coin Toss). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (Two Dice). 投掷一枚红骰子和一枚白骰子。样本空间包含 36 个有序对: $\mathcal{C} = \{(1, 1), (1, 2), \dots, (6, 6)\}$ 。

EXAMPLE 1.3 (Continuous Sample Space). 等待地铁到达的时间。样本空间为 $\mathcal{C} = (0, \infty)$ ——这是一个连续不可数的集合。

事件是样本空间的子集。如果一个实验进行一次, 事件 A 要么发生, 要么不发生, 没有第三种可能。概率论正是描述这种不确定性的数学语言。

2. 1.2 Sets: The Language of Uncertainty

2.1. Why Do We Need Set Theory for Probability? 在概率论中, 事件 (event) 本质上就是样本空间的子集。为什么要用集合的语言? 因为集合运算 (并、交、补) 完美地对应了事件的逻辑运算 (“或”、“且”、“非”)。

德摩根定律 (De Morgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c. \quad (1.2.1)$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C). \quad (1.2.2)$$

这些看似简单的定律, 在概率计算中非常有用。例如, 要计算 “既不是 A 也不是 B ” 的概率, 我们可以直接使用德摩根定律: $\mathbb{P}((A \cup B)^c) = \mathbb{P}(A^c \cap B^c)$ 。

2.2. Key Set Operations. 设 $\mathcal{C}$ 为样本空间, A, B, C 为事件:

- **补集** A^c : 所有不在 A 中的元素
- **并集** $A \cup B$: 至少在 A 或 B 之一中的元素
- **交集** $A \cap B$: 同时在 A 和 B 中的元素
- **不交** $A \cap B = \phi$: A 和 B 互不相容

EXAMPLE 1.4 (Set Operations). 设 $\mathcal{C} = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。

则 $A^c = \{3, 4, \dots, 10\}$, $A \cup B = \{1, 2, 3, 4\}$, $A \cap B = \{2\}$, $A \cap C = \phi$, $B \cap C = \{3, 4\}$ 。

2.3. Countable and Uncountable Sets. 若集合 C 是有限的, 或与正整数集等势, 则称 C 为可数的 (countable)。

可数并: $\cup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}$

可数交: $\cap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \cup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \cap_{n=1}^{\infty} A_n$ 。

3. 1.3 The Probability Set Function

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。

概率必须满足：

- (1) 非负性： $\mathbb{P}(A) \geq 0$
- (2) 规范化： $\mathbb{P}(\mathcal{C}) = 1$
- (3) 可数可加性：若 $A_1, A_2, \dots$ 两两不交，则 $\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$

REMARK. **概率公理的直观含义**：非负性说明概率不能为负；规范化说明必然事件的概率为 1；可数可加性说明互不相容事件的并的概率等于各自概率之和。

从这三条公理可以推导出概率的所有其他性质。¹

REMARK. **定理 1.3.1**：对每个事件 A ， $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ 。

证明：由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$ ，结合公理得

$$1 = \mathbb{P}(\mathcal{C}) = \mathbb{P}(A) + \mathbb{P}(A^c).$$

布尔不等式：对任意事件 $A_1, \dots, A_n$ ，

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i). \quad (1.3.1)$$

这在估计复合事件概率时非常有用——当精确计算困难时，布尔不等式提供了一个上界。

REMARK. **等可能性情形**：若样本空间 $\mathcal{C} = \{x_1, x_2, \dots, x_m\}$ 有限，且每个 *outcome* 等概率，则

$$\mathbb{P}(A) = \frac{\#(A)}{m}. \quad (1.3.2)$$

EXAMPLE 1.5 (扑克牌概率). 从 52 张扑克牌中随机抽取一张。设 $A =$ “抽到 A ”， $B =$ “抽到红桃”。则

$$\mathbb{P}(A) = \frac{4}{52}, \quad \mathbb{P}(B) = \frac{13}{52}, \quad \mathbb{P}(A \cap B) = \frac{1}{52}.$$

由容斥原理，

$$\mathbb{P}(A \cup B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52} = \frac{4}{13}.$$

4. 1.4 Conditional Probability and Independence

条件概率是概率论中最重要的概念之一。它描述了在已知某些信息发生的条件下，如何更新我们对其他事件概率的判断。

REMARK. **定义 1.4.1 (条件概率)**：设 $\mathbb{P}(B) > 0$ ，在事件 B 已发生的条件下，事件 A 的条件概率定义为

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (1.4.1)$$

¹详细推导见附录 section 11.1。

条件概率满足概率的三条公理——它是一种新的概率度量，样本空间缩小为 B 。

乘法法则：

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) = \mathbb{P}(B) \cdot \mathbb{P}(A | B). \quad (1.4.2)$$

推广到 n 个事件：

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right). \quad (1.4.3)$$

REMARK. **全概率公式：** 设 $\{B_i\}$ 为 C 的一个划分，则对任意事件 A ,

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i). \quad (1.4.4)$$

REMARK. **贝叶斯公式：**

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i)}. \quad (1.4.5)$$

术语：

- $\mathbb{P}(B_j)$: 先验概率 (*prior probability*) ——在观测到 A 之前我们对 B_j 的信念
- $\mathbb{P}(B_j | A)$: 后验概率 (*posterior probability*) ——在观测到 A 之后我们对 B_j 的更新信念
- $\mathbb{P}(A | B_j)$: 似然 (*likelihood*) ——在 B_j 成立的条件下观测到 A 的概率

贝叶斯公式不仅是一个计算工具，更提供了一种思考不确定性的思维方式。²

EXAMPLE 1.6 (医学检测). 设某疾病患病率为 1%，检测准确率为 99%。令 $D =$ “患病”， $+$ = “检测阳性”。

即使检测准确率高达 99%，检测阳性者真正患病的概率只有 50%!

这个违反直觉的结果说明：在疾病罕见的情况下，即使非常准确的检测也可能产生大量假阳性。³

4.1. 1.4.1 Independence.

REMARK. **定义 1.4.2 (独立性)：** 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，则称 A 与 B 相互独立，记作 $A \perp B$ 。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时，独立性等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$ ——知道 B 发生并不改变 A 的概率。

EXAMPLE 1.7 (独立硬币). 抛掷两枚独立硬币。设 $A =$ “第一枚正面朝上”， $B =$ “第二枚正面朝上”。则 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$ ，且 $\mathbb{P}(A \cap B) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，故 $A \perp B$ 。

WARNING: 两两独立 (pairwise independent) 不一定意味着相互独立!⁴

²贝叶斯公式的深层意义见附录 section 11.2。

³详细计算见附录 section 11.3。

⁴反例见附录 section 11.4。

5. 1.5 Random Variables

样本空间的元素可能不是数字——随机变量正是将样本空间数值化的工具。

REMARK. 定义 1.5.1 (随机变量): 随机变量是从样本空间 $\mathcal{C}$ 到实数的函数: $X: \mathcal{C} \rightarrow \mathbb{R}$ 。

通常用大写字母 X, Y, Z 表示随机变量, 用小写字母 x, y, z 表示具体取值。

随机变量可分为:

- 离散随机变量: 取值可数 (有限或无限)
- 连续随机变量: 取值充满区间, 不可数

给定随机变量 X , 它的取值空间 $\mathcal{D}$ 成为新的样本空间。 X 不仅诱导了新的样本空间, 还诱导了一个概率分布——这正是“分布”概念的起源。

EXAMPLE 1.8 (硬币投掷). 抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$ 。定义 X 为正面出现的次数: $X(HH) = 2, X(HT) = X(TH) = 1, X(TT) = 0$ 。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。

EXAMPLE 1.9 (均匀选择). 从区间 $(0, 1)$ 中随机选择一个数 X 。 X 是连续随机变量, 取值充满 $(0, 1)$ 。

5.1. Cumulative Distribution Function.

REMARK. 定义 1.5.2 (CDF): $F_X(x) = \mathbb{P}(X \leq x), -\infty < x < \infty$ 。

CDF 满足:

- (1) 非递减: 若 $x_1 < x_2$, 则 $F_X(x_1) \leq F_X(x_2)$
- (2) $\lim_{x \rightarrow -\infty} F_X(x) = 0, \lim_{x \rightarrow \infty} F_X(x) = 1$
- (3) 右连续: $F_X(x) = \lim_{t \rightarrow x^+} F_X(t)$

从 CDF 计算概率:

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a). \quad (1.5.1)$$

关键洞察: 对连续随机变量, $\mathbb{P}(X = x) = 0$, 因此

$$\mathbb{P}(a < X < b) = \mathbb{P}(a \leq X \leq b) = F(b) - F(a). \quad (1.5.2)$$

6. 1.6 Discrete Random Variables

离散随机变量的取值是可数的。

REMARK. 定义 1.6.1 (pmf): $p_X(x) = \mathbb{P}(X = x)$ 。

pmf 满足: $p_X(x) \geq 0$ 对所有 x , 且 $\sum_x p_X(x) = 1$ 。

6.1. 1.6.1 Common Discrete Distributions. 伯努利分布 $X \sim \text{Bernoulli}(p)$:

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p. \quad (1.6.1)$$

二项分布 $X \sim \text{Bin}(n, p)$:

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n. \quad (1.6.2)$$

EXAMPLE 1.10 (二项分布). 抛掷一枚均匀硬币 10 次。设 X 为正面出现的次数。则 $X \sim \text{Bin}(10, 0.5)$,

$$\mathbb{P}(X = 3) = \binom{10}{3} (0.5)^3 (0.5)^7 = \frac{120}{1024} \approx 0.117.$$

几何分布 $X \sim \text{Geom}(p)$:

$$\mathbb{P}(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, 3, \dots \quad (1.6.3)$$

几何分布具有“无记忆性”——等待时间不受过去等待的影响。⁵

EXAMPLE 1.11 (几何分布). 抛掷一枚均匀硬币直到第一次出现正面。设 X 为抛掷次数。则 $X \sim \text{Geom}(0.5)$,

$$\mathbb{P}(X = 3) = (0.5)^2 \cdot 0.5 = \frac{1}{8}.$$

泊松分布 $X \sim \text{Poisson}(\lambda)$:

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots \quad (1.6.4)$$

泊松分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限分布。⁶

这揭示了离散分布之间的深刻联系——泊松分布作为稀有事件的模型具有重要意义。

EXAMPLE 1.12 (泊松分布). 某医院每小时接到的急诊电话数服从泊松分布，均值 $\lambda = 3$ 。则

$$\mathbb{P}(\text{每小时接到 5 个电话}) = \frac{3^5 e^{-3}}{5!} \approx 0.101.$$

超几何分布 $X \sim \text{Hypergeometric}(N, K, n)$:

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}. \quad (1.6.5)$$

这是从有限总体中无放回抽样的模型。

EXAMPLE 1.13 (超几何分布). 一个盒子中有 20 个红球和 80 个白球 (共 100 个)。从中抽取 5 个 (无放回)。令 X 为抽到的红球数。则

$$\mathbb{P}(X = 2) = \frac{\binom{20}{2} \binom{80}{3}}{\binom{100}{5}}.$$

⁵详细证明见附录 section 11.5。

⁶详细推导见附录 section 7.10。

6.2. 1.6.2 Transformations of Discrete Random Variables. 在统计中, 我们经常需要对一个随机变量进行变换: $Y = g(X)$ 。

一对一变换: 若 g 是一一对应的, 则

$$p_Y(y) = p_X(g^{-1}(y)). \quad (1.6.6)$$

非一对一变换: 需要合并所有映射到相同 y 的 x 的概率。

EXAMPLE 1.14 (离散变换). 设 $X \sim \text{Geom}(0.5)$, $Y = X^2$ 。因为 $g(x) = x^2$ 在 $\{1, 2, 3, \dots\}$ 上是一一对应的 (没有负数),

$$p_Y(y) = p_X(\sqrt{y}) = (0.5)^{\sqrt{y}+1}, \quad y = 1, 4, 9, \dots$$

7. 1.7 Continuous Random Variables

连续随机变量的取值充满一个或多个区间, 不可数。

REMARK. **定义 1.7.1 (连续随机变量):** 若随机变量 X 的 *cdf* $F_X(x)$ 对所有 x 都连续, 则称 X 为连续随机变量。

对连续随机变量, $\mathbb{P}(X = x) = 0$ 对所有 x ——这意味着单点概率为零。

REMARK. **定义 1.7.2 (pdf):** 若存在非负函数 $f_X(x)$ 使得

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x) dx$$

对任意 $a < b$ 成立, 则称 $f_X(x)$ 为 *pdf*。

pdf 满足: $f_X(x) \geq 0$ 对所有 x , 且 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。

WARNING: $f_X(x)$ 可以大于 1! 这与 *pmf* 的 $p_X(x) \leq 1$ 形成对比。pdf 的值不是概率, 而是概率密度——只有积分才是概率。

EXAMPLE 1.15 (均匀分布). 从区间 $(0, 1)$ 中随机选择一个数 X 。则 $X \sim \text{Uniform}(0, 1)$,

$$f_X(x) = \begin{cases} 1 & 0 < x < 1 \\ 0 & \text{otherwise} \end{cases}$$

EXAMPLE 1.16 (单位圆内的随机点). 在单位圆内随机选择一个点。设 X 为该点到原点的距离。则 X 的 *cdf* 为 $F_X(x) = x^2$, $0 \leq x \leq 1$ 。因此 *pdf* 为 $f_X(x) = 2x$, $0 < x < 1$ 。

EXAMPLE 1.17 (指数分布). 电话呼叫间隔时间 X 服从指数分布, *pdf* 为

$$f_X(x) = \frac{1}{4}e^{-x/4}, \quad x > 0.$$

则 $\mathbb{P}(X > 4) = \int_4^{\infty} \frac{1}{4}e^{-x/4} dx = e^{-1} \approx 0.368$ 。

指数分布也具有无记忆性。⁷

⁷详细讨论见附录 section 11.7。

正态分布 $X \sim N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \quad (1.7.1)$$

正态分布是统计学中最重要的分布——这将在第三章详细讨论。

7.1. 1.7.1 Quantiles. 分位数是分布的重要特征。

REMARK. 定义 1.7.3 (分位数): 设 $0 < p < 1$. 分布的 $100p\%$ 分位数 ξ_p 满足

$$\mathbb{P}(X < \xi_p) \leq p \quad \text{且} \quad \mathbb{P}(X \leq \xi_p) \geq p. \quad (1.7.2)$$

特殊分位数:

- 中位数 (*median*): $\xi_{0.5}$
- 第一四分位数: $\xi_{0.25}$
- 第三四分位数: $\xi_{0.75}$

四分位距 (*IQR*): $q_3 - q_1$, 是衡量离散程度的稳健指标。

若 X 连续且 F_X 严格递增, 则 $\xi_p = F_X^{-1}(p)$ 。

偏度 (*Skewness*): 描述分布的不对称程度。

- 右偏 (*positively skewed*): 右尾较长, 如指数分布
- 左偏 (*negatively skewed*): 左尾较长
- 对称 (*symmetric*): 如正态分布

7.2. 1.7.2 Transformations of Continuous Random Variables. 设 X 是连续随机变量, $f_X(x)$ 已知。我们想知道 $Y = g(X)$ 的分布。

CDF 法: 先求 $F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y)$, 然后求导得 $f_Y(y) = \frac{d}{dy}F_Y(y)$ 。

EXAMPLE 1.18 (连续变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = X^2$ 。则对 $0 < y < 1$,

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(X \leq \sqrt{y}) = \sqrt{y}.$$

因此 $f_Y(y) = \frac{1}{2\sqrt{y}}$, $0 < y < 1$ 。

——变换公式: 若 $y = g(x)$ 是一一对应且可导的, $x = g^{-1}(y)$, 则

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy}g^{-1}(y) \right|, \quad y \in \mathcal{S}_Y. \quad (1.7.3)$$

这里 $\left| \frac{dx}{dy} \right|$ 称为雅可比 (Jacobian)。

EXAMPLE 1.19 (对数变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = -\log X$ 。则 $x = e^{-y}$, $dx/dy = -e^{-y}$ 。因此

$$f_Y(y) = 1 \cdot |-e^{-y}| = e^{-y}, \quad y > 0.$$

即 $Y \sim \text{Exp}(1)$ 。

这提供了从均匀分布生成指数分布的方法——逆变换采样 (*inverse transform sampling*) 的基础。⁸

⁸逆变换采样的详细讨论见第四章。

变换公式的证明：⁹

7.3. 1.7.3 Mixture Distributions. 有些分布既不是纯离散的，也不是纯连续的，而是两者的混合。

EXAMPLE 1.20 (混合分布). 设 X 的 cdf 为

$$F(x) = \begin{cases} 0 & x < 0 \\ \frac{x+1}{2} & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases}$$

则 $\mathbb{P}(X = 0) = 1/2$ ，且对 $0 < x < 1$ ， $\mathbb{P}(0 < X < x) = x/2$ 。这是一个离散-连续混合分布。

这种分布在实际中经常出现，例如：

- 删失数据 (*censored data*)
- 保险中的限额保单

8. 1.8 Expectation of a Random Variable

期望是随机变量最重要的一致性度量。它描述了分布的”中心位置”。

REMARK. 定义 1.8.1 (数学期望):

- 离散型: $\mathbb{E}X = \sum x \cdot p_X(x)$
- 连续型: $\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$

要求级数或积分绝对收敛，即 $\mathbb{E}|X| < \infty$ 。

期望的起源：在赌博游戏中，”期望”(expectation)一词来源于玩家对游戏收益的长期平均预期。

公平游戏：若 $E(G) = 0$ ，则游戏是公平的 (fair game)。

EXAMPLE 1.21 (骰子期望). 设 X 为掷骰子的点数。则 $\mathbb{E}X = \frac{1}{6}(1+2+3+4+5+6) = 3.5$ 。

REMARK. 函数期望定理: 设 $Y = g(X)$ 。则

- 离散型: $\mathbb{E}Y = \sum g(x) \cdot p_X(x)$
- 连续型: $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx$

重要含义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！¹⁰

期望的线性性是概率论中最重要、最有用的性质之一。¹¹

⁹详细推导见附录 section 11.8。

¹⁰详细证明见附录 section 11.9。

¹¹详细证明见附录 section 0.5。

REMARK. 定理 1.8.1 (期望的线性性): 对任意随机变量 X, Y (期望存在) 和常数 a, b :

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y. \quad (1.8.1)$$

关键点: 无需 X, Y 相互独立!

EXAMPLE 1.22 (样本均值). 设 $X_1, \dots, X_n$ 是独立同分布的随机变量, $\mathbb{E}X_i = \mu$ 。则样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望为

$$\mathbb{E}\bar{X} = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \mu.$$

这说明样本均值是总体均值的无偏估计!¹²

乘积期望: 一般情况下 $\mathbb{E}(XY) \neq \mathbb{E}X \cdot \mathbb{E}Y$ 。只有当 X 和 Y 独立时, 等式才成立。

EXAMPLE 1.23 (乘积期望). 设 X 和 Y 是区间 $(0, 1)$ 上的均匀分布, 但 $Y = X$ (完全相关)。则 $\mathbb{E}(XY) = \mathbb{E}(X^2) = 1/3$, 而 $\mathbb{E}X \cdot \mathbb{E}Y = 1/4$, 两者不相等。

方差度量分布的离散程度。¹³

REMARK. 定理 1.8.2 (方差公式):

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}(X^2) - \mu^2. \quad (1.8.2)$$

方差性质:

$$(1) \text{var}(aX + b) = a^2 \text{var}(X)$$

$$(2) \text{若 } X_1, \dots, X_n \text{ 相互独立, 则 } \text{var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{var}(X_i)$$

9. 1.9 Some Special Expectations

某些期望具有特殊名称和重要意义。

9.1. Moments.

REMARK. 定义 1.9.1 (矩):

- k 阶原点矩: $\mu'_k = \mathbb{E}(X^k)$
- k 阶中心矩: $\mu_k = \mathbb{E}[(X - \mu)^k]$

一阶原点矩 $\mu'_1 = \mathbb{E}X$ 就是均值。

均值 (Mean): $\mu = \mathbb{E}X$ 是分布的中心位置度量。

方差 (Variance): $\sigma^2 = \text{var}(X)$ 度量分布的离散程度。

标准差 (Standard Deviation): $\sigma = \sqrt{\text{var}(X)}$, 与 X 具有相同单位。

变异系数 (CV): $\text{CV} = \sigma/\mu$, 是无量纲的离散程度度量。

偏度系数: $\gamma_1 = \mathbb{E}[(X - \mu)^3]/\sigma^3$, 衡量分布的不对称程度。

峰度系数: $\gamma_2 = \mathbb{E}[(X - \mu)^4]/\sigma^4 - 3$, 衡量分布尾部的厚重程度。

¹²这将在第四章统计推断中发挥核心作用。

¹³详细推导见附录 section 11.11。

EXAMPLE 1.24 (均匀分布的矩). 设 $X \sim \text{Uniform}(-a, a)$ 。则

$$\mu = 0, \quad \text{var}(X) = \frac{a^2}{3}.$$

EXAMPLE 1.25 (指数分布的矩). 设 $X \sim \text{Exp}(\lambda)$ 。则

$$\mathbb{E}X = \frac{1}{\lambda}, \quad \text{var}(X) = \frac{1}{\lambda^2}.$$

9.2. Covariance and Correlation. 两个随机变量之间的”共同变化”程度，用协方差来度量。

REMARK. 定义 1.9.2 (协方差):

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y. \quad (1.9.1)$$

协方差性质:

- (1) $\text{cov}(X, X) = \text{var}(X)$
- (2) $\text{cov}(X, Y) = \text{cov}(Y, X)$
- (3) $\text{cov}(aX + b, Y) = a\text{cov}(X, Y)$
- (4) $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y)$
- (5) 若 $X \perp\!\!\!\perp Y$, 则 $\text{cov}(X, Y) = 0$

REMARK. 定义 1.9.3 (相关系数):

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}. \quad (1.9.2)$$

重要性质: $-1 \leq \text{corr}(X, Y) \leq 1$ 。

相关系数衡量两个变量之间的线性关系强度。

WARNING: 相关不等于因果! 两个变量相关可能是由于第三个隐藏变量导致的。

14

9.3. Moment Generating Function. 矩母函数是计算矩的强大工具。

REMARK. 定义 1.9.4 (矩母函数): 若对某个 $h > 0$,

$$M_X(t) = \mathbb{E}(e^{tX}) \quad \text{对 } -h < t < h \text{ 存在}, \quad (1.9.3)$$

则称 $M_X(t)$ 为 X 的矩母函数 (mgf)。

核心性质: 矩母函数唯一确定分布! 若两个随机变量的 mgf 相同, 则它们同分布。
为什么叫”矩母函数”? 因为

$$M_X^{(k)}(0) = \mathbb{E}(X^k). \quad (1.9.4)$$

这意味着如果我们有 mgf, 可以通过对它求导来获得所有矩!

¹⁴因果推断的讨论见本书因果推断部分。

EXAMPLE 1.26 (正态分布的 mgf). 设 $X \sim N(\mu, \sigma^2)$ 。则

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right).$$

特别地, $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - [M'(0)]^2 = \sigma^2$ 。

EXAMPLE 1.27 (泊松分布的 mgf). 设 $X \sim \text{Poisson}(\lambda)$ 。则

$$M_X(t) = \exp(\lambda(e^t - 1)).$$

mgf 的加法性质尤为重要: 若 $X_1, \dots, X_n$ 独立, 则

$$M_{X_1 + \dots + X_n}(t) = \prod_{i=1}^n M_{X_i}(t). \quad (1.9.5)$$

这提供了一种验证独立随机变量和的分布的方法。

10. 1.10 Important Inequalities

概率论中有几个基本不等式, 它们在理论证明和实际应用中都非常重要。

REMARK. 定理 1.10.1 (*Markov 不等式*): 若 X 为随机变量, $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}. \quad (1.10.1)$$

Markov 不等式的意义在于: 它仅用期望就能给出概率的上界, 而不需要知道分布的完整信息。¹⁵

REMARK. 定理 1.10.2 (*Chebyshev 不等式*): 设 $\mu = \mathbb{E}X$, $\sigma^2 = \text{var}(X)$ 。则对任意 $k > 0$,

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}. \quad (1.10.2)$$

Chebyshev 不等式告诉我们: 无论分布是什么, 至少 $1 - 1/k^2$ 的概率质量落在 $\mu \pm k\sigma$ 区间内。

EXAMPLE 1.28 (*Chebyshev 应用*). 设某考试成绩均值为 70, 标准差为 10。则根据 *Chebyshev* 不等式, 至少 75% 的学生成绩在 50 到 90 分之间。

Chebyshev 不等式虽然保守, 但在无法获知确切分布时是唯一可用的工具。它也是证明大数定律的关键工具。

REMARK. 定理 1.10.3 (*Cauchy-Schwarz 不等式*): 对于任意随机变量 X 和 Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}. \quad (1.10.3)$$

重要应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。¹⁶

Jensen 不等式: 若 g 是凸函数, 则 $\mathbb{E}[g(X)] \geq g(\mathbb{E}X)$ 。¹⁷

¹⁵详细证明见附录 section 11.12。

¹⁶详细证明及更多应用见附录 section 11.13。

¹⁷Jensen 不等式的证明及更多应用见附录 section 11.14。

Summary

本章建立了概率论的基本框架，这些概念相互关联，共同构成了数理统计的基石：

- (1) **概率公理化** (1.3 节)：从相对频率的直观性质出发，建立了概率的严格数学定义
- (2) **条件概率与贝叶斯公式** (1.4 节)：提供了更新信息的数学工具，是统计推断的理论基础
- (3) **独立性** (1.4.1 节)：刻画了两个事件之间的概率关系
- (4) **随机变量** (1.5 节)：从集合论过渡到数值函数，为分布理论奠定基础
- (5) **离散与连续分布** (1.6-1.7 节)：建立了描述随机现象的主要分布类型 (Binomial, Poisson, Geometric, Normal, Exponential 等)
- (6) **变换与分位数** (1.6.2, 1.7.1-1.7.3 节)：提供了操作随机变量的技术工具
- (7) **期望与矩** (1.8-1.9 节)：分别度量分布的中心位置、离散程度和分布形状
- (8) **矩母函数** (1.9.3 节)：统一处理矩的强大工具，具有唯一性定理
- (9) **重要不等式** (1.10 节)：Markov、Chebyshev、Cauchy-Schwarz 是理论证明的基础工具

本章的核心思想：从随机现象出发，通过公理化定义建立概率论，用随机变量将样本空间数值化，然后用分布描述随机变量的行为，最后用期望等数字特征概括分布的关键性质。

与后续章节的联系：

- 第二章将概率论扩展到多个随机变量，研究联合分布、边缘分布、条件分布
- 第三章将详细介绍各种具体分布及其性质
- 第四章将利用这些工具进行统计推断（点估计、区间估计、假设检验）

Exercises

EXERCISE 1.1. 1.2.1 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$ ：

- (1) $C_1 = \{0, 1, 2\}$, $C_2 = \{2, 3, 4\}$
- (2) $C_1 = \{x : 0 < x < 2\}$, $C_2 = \{x : 1 \leq x < 3\}$

EXERCISE 1.2. 1.3.1 设 $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.4$, $\mathbb{P}(A \cap B) = 0.1$ 。求：

- (1) $\mathbb{P}(A \cup B)$
- (2) $\mathbb{P}(A | B)$
- (3) $\mathbb{P}(B | A)$

EXERCISE 1.3. 1.3.2 从 5 男 3 女中随机选 3 人。求恰好选到 2 名女生的概率。

EXERCISE 1.4. 1.4.1 某箱中有 5 个红球和 3 个白球。无放回地抽取 3 个球。求恰好抽到 2 个红球的概率。

EXERCISE 1.5. 1.4.2 设 A 和 B 是互不相容的事件， $\mathbb{P}(A) = 0.2$, $\mathbb{P}(B) = 0.3$ 。求 $\mathbb{P}(A \cup B)$ 、 $\mathbb{P}(A^c)$ 、 $\mathbb{P}((A \cup B)^c)$ 。

EXERCISE 1.6. 1.5.1 设 X 的 *cdf* 为

$$F(x) = \begin{cases} 0 & x < 0 \\ x/2 & 0 \leq x < 1 \\ 1/2 & 1 \leq x < 2 \\ 1 & x \geq 2 \end{cases}$$

求 $\mathbb{P}(0 < X \leq 1)$ 、 $\mathbb{P}(X = 1)$ 、 $\mathbb{P}(X > 1/2)$ 。

EXERCISE 1.7. 1.6.1 设 $X \sim \text{Binomial}(10, 0.3)$ 。求：

- (1) $\mathbb{P}(X = 3)$
- (2) $\mathbb{P}(X \geq 2)$
- (3) $\mathbb{E}X$

EXERCISE 1.8. 1.6.2 设 $X \sim \text{Poisson}(4)$ 。求 $\mathbb{P}(X = 0)$ 、 $\mathbb{P}(X \leq 2)$ 、 $\mathbb{E}X$ 。

EXERCISE 1.9. 1.6.3 设 $X \sim \text{Geometric}(0.4)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.10. 1.6.4 设 $X \sim \text{Binomial}(5, 0.5)$ ， $Y = X^2$ 。求 Y 的 *pmf*。

EXERCISE 1.11. 1.7.1 设 $X \sim N(100, 225)$ 。求：

- (1) $\mathbb{P}(X < 95)$
- (2) $\mathbb{P}(90 < X < 110)$
- (3) $\mathbb{P}(X > 115)$

EXERCISE 1.12. 1.7.2 设 $X \sim \text{Exp}(2)$ 。求：

- (1) $\mathbb{P}(X > 1)$
- (2) $\mathbb{P}(X < 0.5)$
- (3) 50% 分位数 (中位数)

EXERCISE 1.13. 1.7.3 设 $X \sim \text{Uniform}(0, 1)$ ， $Y = -\log X$ 。证明 $Y \sim \text{Exp}(1)$ 。

EXERCISE 1.14. 1.7.4 设 $X \sim N(0, 1)$ ， $Y = e^X$ 。求 Y 的 *pdf* (这是对数正态分布)。

EXERCISE 1.15. 1.8.1 设 X 的 *pdf* 为 $f(x) = 3x^2$ ， $0 < x < 1$ 。求 $\mathbb{E}X$ 、 $\mathbb{E}(X^2)$ 、 $\text{var}(X)$ 。

EXERCISE 1.16. 1.8.2 设 $X \sim \text{Poisson}(\lambda)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.17. 1.8.3 设 X 和 Y 是独立同分布的随机变量， $\mathbb{E}X = \mu$ ， $\text{var}(X) = \sigma^2$ 。求 $\text{var}(X - Y)$ 和 $\text{var}(X + Y)$ 。

EXERCISE 1.18. 1.9.1 设 $X \sim N(\mu, \sigma^2)$ 。求 X 的 *mgf*，并验证它产生正确的均值和方差。

EXERCISE 1.19. 1.9.2 设 X 和 Y 独立, $X \sim \text{Poisson}(2)$, $Y \sim \text{Poisson}(3)$ 。求 $X+Y$ 的分布。

EXERCISE 1.20. 1.10.1 设 $\mathbb{E}X = 100$, $\text{var}(X) = 25$ 。用 Chebyshev 不等式给出 $\mathbb{P}(|X - 100| \geq 10)$ 的上界, 并用 Markov 不等式给出另一个上界。

EXERCISE 1.21. 1.10.2 用 Cauchy-Schwarz 不等式证明: 若 $\mathbb{E}(X^2) = \mathbb{E}(Y^2) = 1$, 则 $|\mathbb{E}(XY)| \leq 1$ 。

11. 附录：公式推导

11.1. 概率公理的推导. 背景: 概率公理 (Kolmogorov, 1933) 为概率论奠定了严格数学基础。

目标: 从三条公理推导出概率的其他基本性质。

推导步骤:

性质 1: $\mathbb{P}(\phi) = 0$ 。

由公理 3, 令 $A_n = \phi$ 对所有 n , 则 $\cup_{n=1}^{\infty} A_n = \phi$, 故

$$\mathbb{P}(\phi) = \sum_{n=1}^{\infty} \mathbb{P}(\phi) = \mathbb{P}(\phi) + \sum_{n=2}^{\infty} \mathbb{P}(\phi).$$

两边减去 $\sum_{n=2}^{\infty} \mathbb{P}(\phi)$ 得 $\mathbb{P}(\phi) = 0$ 。

性质 2: 若 $A \subset B$, 则 $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$ 。

由 $B = A \cup (B \setminus A)$ 且 $A \cap (B \setminus A) = \phi$, 结合公理得

$$\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A).$$

性质 3: $\mathbb{P}(A) \leq 1$ 。

由 $A \subset C$ 和性质 2, $\mathbb{P}(A) \leq \mathbb{P}(C) = 1$ 。

性质 4 (容斥原理):

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

将 $A \cup B$ 写成不交并: $A \cup B = A \cup (B \setminus A)$, 再用公理。

布尔不等式: 对任意 $A_1, \dots, A_n$,

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i).$$

使用数学归纳法, 从容斥原理中去掉负项得到。

11.2. 贝叶斯公式的深层意义. 背景: 贝叶斯公式是更新信念的数学工具。

全概率公式是贝叶斯公式的基础:

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \mathbb{P}(A | B_i),$$

其中 $\{B_i\}$ 是样本空间的一个划分。

贝叶斯公式的直觉:

将条件概率公式 $\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j \cap A)}{\mathbb{P}(A)}$ 中的分子、分母分别展开：

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j)\mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i)\mathbb{P}(A | B_i)}.$$

先验到后验的更新机制：

- (1) 先验概率 $\mathbb{P}(B_j)$ ：观测数据前对假设的信念
- (2) 似然 $\mathbb{P}(A | B_j)$ ：在该假设下观测到数据的“可能性”
- (3) 归一化常数 $\sum_i \mathbb{P}(B_i)\mathbb{P}(A | B_i)$ ：确保后验概率之和为 1
- (4) 后验概率 $\mathbb{P}(B_j | A)$ ：观测数据后对假设的更新信念

贝叶斯公式的核心思想：用数据（通过似然）来更新先验信念，得到后验分布。这构成了贝叶斯统计的理论基础。

11.3. 医学检测假阳性详解. 问题设定：

- 疾病患病率： $\mathbb{P}(D) = 0.01$ （1%）
- 检测准确率： $\mathbb{P}(+ | D) = 0.99$ （患病者 99% 阳性）
- 误报率： $\mathbb{P}(+ | D^c) = 0.01$ （健康者 1% 阳性）

求解： $\mathbb{P}(D | +)$ ——检测阳性者真正患病的概率。

由贝叶斯公式：

$$\mathbb{P}(D | +) = \frac{\mathbb{P}(D)\mathbb{P}(+ | D)}{\mathbb{P}(D)\mathbb{P}(+ | D) + \mathbb{P}(D^c)\mathbb{P}(+ | D^c)}.$$

代入数值：

$$= \frac{0.01 \times 0.99}{0.01 \times 0.99 + 0.99 \times 0.01} = \frac{0.0099}{0.0099 + 0.0099} = \frac{0.0099}{0.0198} = 0.5.$$

直觉解释：即使检测准确率高达 99%，由于疾病非常罕见（1%），在所有阳性结果中，真阳性（ $0.01 \times 0.99 = 0.0099$ ）和假阳性（ $0.99 \times 0.01 = 0.0099$ ）的数量竟然相同！这说明在罕见事件检测中，**先验概率**（患病率）对后验概率有决定性影响。

11.4. 两两独立但不相互独立的反例. 背景：独立性是概率论中的重要概念，但两两独立不等于相互独立。

经典反例：掷两枚公平硬币，考虑以下四个事件：

- A ：第一枚硬币正面朝上
- B ：第二枚硬币正面朝上
- C ：两枚硬币结果相同（ HH 或 TT ）

验证两两独立：

- $\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = 1/2$
- $\mathbb{P}(A \cap B) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(A)\mathbb{P}(B)$
- $\mathbb{P}(A \cap C) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(A)\mathbb{P}(C)$
- $\mathbb{P}(B \cap C) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(B)\mathbb{P}(C)$

但不相互独立：

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(HH) = 1/4 \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = 1/8.$$

这个例子说明：三个事件中，任意两个都独立，但三个放在一起就不独立了。

11.5. 几何分布无记忆性的证明. 背景：几何分布描述”直到第一次成功所需等待次数”的分布。

定义： $X \sim \text{Geom}(p)$, $\mathbb{P}(X = k) = (1-p)^{k-1}p$, $k = 1, 2, 3, \dots$

无记忆性：对任意 $m, n \geq 1$,

$$\mathbb{P}(X > m+n \mid X > m) = \mathbb{P}(X > n).$$

证明：

$$\mathbb{P}(X > m+n \mid X > m) = \frac{\mathbb{P}(X > m+n)}{\mathbb{P}(X > m)} = \frac{(1-p)^{m+n}}{(1-p)^m} = (1-p)^n = \mathbb{P}(X > n).$$

直观含义：如果已经等待了 m 次且没有成功，那么再等待 n 次的概率与”从头开始等待 n 次”的概率完全相同。过去的时间”被遗忘”了。

唯一性：无记忆性是几何分布的特征性质——离散支撑集 $\{1, 2, 3, \dots\}$ 上具有无记忆性的分布只有几何分布。

11.6. Poisson 近似二项分布的证明. 背景：Poisson 分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限。

定理：若 $X_n \sim \text{Bin}(n, p_n)$ ，且 $np_n \rightarrow \lambda$ ，则对任意固定 k ：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

证明：

二项分布式：

$$\mathbb{P}(X_n = k) = \frac{n(n-1)\cdots(n-k+1)}{k!} p_n^k (1-p_n)^{n-k}.$$

写成：

$$= \frac{n^k \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} + o(1).$$

当 $n \rightarrow \infty$ 时：

$$\begin{aligned} \left(1 - \frac{j}{n}\right) &\rightarrow 1 \quad \text{for fixed } j, \\ \left(1 - \frac{\lambda}{n}\right)^n &\rightarrow e^{-\lambda}, \\ \left(1 - \frac{\lambda}{n}\right)^{-k} &\rightarrow 1. \end{aligned}$$

因此：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

实际意义：当 n 很大、 p 很小时，用 $\text{Poisson}(\lambda = np)$ 近似 $\text{Bin}(n, p)$ 可以大大简化计算。

11.7. 指数分布无记忆性的讨论. 背景：指数分布是连续版本的无记忆分布。

定义： $X \sim \text{Exp}(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $x > 0$ 。

无记忆性：对任意 $s, t > 0$,

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t).$$

证明：

$$\mathbb{P}(X > s + t \mid X > s) = \frac{\mathbb{P}(X > s + t)}{\mathbb{P}(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(X > t).$$

与几何分布的类比：离散几何分布和连续指数分布都具有无记忆性。这不是巧合——它们都是“等待直到事件发生”这一过程的模型，只是时间参数不同。

实际应用：指数分布常用于描述：

- 电子元件的寿命（假设失效率恒定）
- 客户服务时间
- 打电话的间隔时间

Poisson 过程的联系：如果事件以固定速率 λ 发生（Poisson 过程），那么相邻事件的时间间隔服从指数分布 $\text{Exp}(\lambda)$ 。

11.8. 一元变换公式的推导. 背景：已知 X 的分布，求 $Y = g(X)$ 的分布。

定理：设 X 是连续随机变量， $f_X(x)$ 已知。 $y = g(x)$ 是一一对应且可导的， $x = g^{-1}(y) = h(y)$ 。则

$$f_Y(y) = f_X(h(y)) |h'(y)|, \quad y \in \mathcal{S}_Y.$$

证明：

由 CDF 定义：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq h(y)) = F_X(h(y)).$$

对 y 求导（链式法则）：

$$f_Y(y) = f_X(h(y)) \cdot h'(y) = f_X(h(y)) |h'(y)|.$$

多对一情况：若 g 不是一一对应，则需将所有映射到同一 y 的 x 的概率相加：

$$f_Y(y) = \sum_i f_X(x_i) |x'_i|,$$

其中 $x_i = h_i(y)$ 是 $y = g(x)$ 的各个解。

11.9. 函数期望定理的证明. 背景：已知 X 的分布，求 $Y = g(X)$ 的期望。

定理：设 $Y = g(X)$ 。

- 若 X 离散： $\mathbb{E}Y = \sum_x g(x)p_X(x)$
- 若 X 连续： $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x)f_X(x)dx$

证明（连续情形）：

由定义：

$$\mathbb{E}Y = \int_{-\infty}^{\infty} y f_Y(y) dy.$$

使用变换公式：

$$= \int_{-\infty}^{\infty} y \cdot f_X(h(y)) |h'(y)| dy.$$

做变量替换 $x = h(y)$ ，则 $dx = h'(y)dy$ ， $y = g(x)$ ：

$$= \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

重要意义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！这就是“函数期望定理”的价值。

11.10. 期望线性性的证明. 定理：对任意随机变量 X, Y （期望存在）和常数 a, b ：

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y.$$

证明：

由函数期望定理和重期望：

$$\mathbb{E}[aX + bY] = \iint (ax + by) f_{XY}(x, y) dx dy.$$

分离积分：

$$= a \iint x f_{XY}(x, y) dx dy + b \iint y f_{XY}(x, y) dx dy = a\mathbb{E}X + b\mathbb{E}Y.$$

关键点：无需 X, Y 独立！线性性对所有随机变量都成立，无论它们是否相关。

推论：对 iid $X_1, \dots, X_n$ ， $\mathbb{E}\bar{X} = \mathbb{E}X_1$ 。

由线性性：

$$\mathbb{E}\bar{X} = \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n X_i \right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \frac{1}{n} \cdot n\mathbb{E}X_1 = \mathbb{E}X_1.$$

11.11. 方差公式的推导. 背景：方差度量随机变量偏离其均值的程度。

定义： $\text{var}(X) = \mathbb{E}[(X - \mu)^2]$ ，其中 $\mu = \mathbb{E}X$ 。

计算公式： $\text{var}(X) = \mathbb{E}(X^2) - \mu^2$ 。

推导：

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2 - 2\mu X + \mu^2] = \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - 2\mu^2 + \mu^2 = \mathbb{E}(X^2) - \mu^2.$$

方差性质：

(1) $\text{var}(aX + b) = a^2\text{var}(X)$ （尺度变换）

(2) 若 $X \perp Y$: $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y)$

第二点的证明: 若 X, Y 独立,

$$\text{var}(X+Y) = \mathbb{E}[(X+Y)^2] - [\mathbb{E}(X+Y)]^2 = \mathbb{E}(X^2) + 2\mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(Y^2) - \mu_X^2 - 2\mu_X\mu_Y - \mu_Y^2 = \text{var}(X) + \text{var}(Y)$$

注意: 独立性条件不可少! 若 $X = Y$, 则 $\text{var}(X + Y) = \text{var}(2X) = 4\text{var}(X) \neq 2\text{var}(X)$ 。

11.12. Markov 不等式的证明. 定理: 若 $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}.$$

证明:

设事件 $A = \{g(X) \geq a\}$, 则 $g(X) \geq a \cdot \mathbb{I}_A$ (因为在 A 上 $g(X) \geq a$, 在 A^c 上 $g(X) \geq 0$)。

取期望:

$$\mathbb{E}[g(X)] \geq \mathbb{E}[a \cdot \mathbb{I}_A] = a \cdot \mathbb{P}(A) = a \cdot \mathbb{P}(g(X) \geq a).$$

两边除以 $a > 0$ 得证。

意义: Markov 不等式仅用一阶矩 (期望) 就能给出概率上界, 不依赖分布的具体形式。当然, 上界可能很松——例如对正态分布, $\mathbb{P}(|X| \geq 2\sigma)$ 的真实值约为 0.05, 而 Markov 上界给出的是 1/4。

特例: 取 $g(X) = (X - \mu)^2$, $a = k^2$, 得 Chebyshev 不等式:

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\text{var}(X)}{k^2}.$$

11.13. Cauchy-Schwarz 不等式的证明. 定理: 对任意随机变量 X, Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}.$$

证明:

考虑 $\mathbb{E}[(tX - Y)^2] \geq 0$ 对任意实数 t 成立。

展开:

$$0 \leq \mathbb{E}[t^2 X^2 - 2tXY + Y^2] = t^2 \mathbb{E}(X^2) - 2t \mathbb{E}(XY) + \mathbb{E}(Y^2).$$

这是关于 t 的二次不等式, 其判别式必须非正:

$$[2\mathbb{E}(XY)]^2 - 4\mathbb{E}(X^2)\mathbb{E}(Y^2) \leq 0.$$

整理得:

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}.$$

应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。

设 $X^* = X - \mu_X$, $Y^* = Y - \mu_Y$, 则

$$|\text{corr}(X, Y)| = \frac{|\mathbb{E}(X^*Y^*)|}{\sqrt{\text{var}(X)\text{var}(Y)}} \leq \frac{\sqrt{\mathbb{E}(X^{*2})\mathbb{E}(Y^{*2})}}{\sqrt{\text{var}(X)\text{var}(Y)}} = 1.$$

11.14. Jensen 不等式的证明. 定理：若 g 是凸函数， X 的期望存在，则

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}X).$$

证明（使用凸函数的支撑超平面）：

由凸函数的性质，对任意 x_0 ，存在支撑线 $L(x) = g(x_0) + c(x - x_0)$ 使得 $g(x) \geq L(x)$ 对所有 x 成立。

取 $x_0 = \mathbb{E}X$ ，则 $g(x) \geq g(\mathbb{E}X) + c(x - \mathbb{E}X)$ 。

取期望：

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}X) + c\mathbb{E}(X - \mathbb{E}X) = g(\mathbb{E}X) + c \cdot 0 = g(\mathbb{E}X).$$

特例：

- $g(x) = x^2$ (凸)： $\mathbb{E}(X^2) \geq (\mathbb{E}X)^2$
- $g(x) = e^x$ (凸)： $\mathbb{E}(e^X) \geq e^{\mathbb{E}X}$

第二个特例说明：指数函数的期望大于等于期望的指数——这在金融中用于证明“彩票溢价”现象。

CHAPTER 2

多元随机变量及其分布

Chapter 2 概述

在一元情形，我们用 cdf $F_X(x) = \mathbb{P}(X \leq x)$ 描述单个随机变量的行为。但在许多场景中，单个变量的分布并不能回答我们的问题——我们需要知道多个变量如何共同变化。

为什么需要联合分布？ 例如，在经济学中，我们关心收入与教育年限的共同分布；在医学中，我们关心血压与胆固醇的联合水平；在金融中，资产收益率之间的相关性是风险管理的核心。这些问题都涉及多个随机变量的联合行为。

统计推断的核心任务——从样本推断总体——本质上也是多元的：样本是多个观测值的向量，而统计量是这些观测值的函数。第 4 章将看到，点估计、置信区间、假设检验全部建立在多元分布理论之上。

本章路线图： 联合分布 $\rightarrow$ 边缘分布 $\rightarrow$ 条件分布 $\rightarrow$ 独立性 $\rightarrow$ 相关性 $\rightarrow$ 多元正态 $\rightarrow$ 多元推广

1. 2.1 从一元到多元：联合分布

1.1. 为什么需要联合分布？ 在一元情形，我们学会了用 cdf、pmf/pdf 描述单个随机变量的行为。但在真实世界中，变量很少孤立存在。

核心问题： 给定两个随机变量 X_1 和 X_2 ，如何描述它们的联合行为？

例如，设 X_1 为身高， X_2 为体重。知道身高分布和体重分布当然有用，但知道两者如何“共同变化”——高个子是否倾向于更重——显然更有价值。这种“共同变化”的数学表达，正是联合分布。

历史注记： 多元分析的思想可以追溯到 Francis Galton (1822-1911) 的工作。他研究遗传问题时发现，单个特征的分布不足以描述遗传规律——必须考虑特征之间的相关性。他发明的“相关系数” (correlation coefficient) 正是本章的核心概念之一。

1.2. 随机向量与联合分布.

DEFINITION 2.1 (随机向量). 设样本空间为 $\mathcal{C}$ ， X_1 和 X_2 为定义在 $\mathcal{C}$ 上的两个随机变量。则 (X_1, X_2) 称为随机向量，其取值空间为 $\mathcal{D} = \{(x_1, x_2) : x_1 = X_1(c), x_2 = X_2(c), c \in \mathcal{C}\}$ 。

联合 cdf 是一元 cdf 的自然推广：

$$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2). \quad (1)$$

注意：这里的“且” ($,$) 表示两个事件同时发生。

离散型用 pmf 描述:

$$p_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 = x_1, X_2 = x_2), \quad (2)$$

满足 $p \geq 0$ 且 $\sum \sum_{\mathcal{D}} p = 1$ 。

连续型用 pdf 描述:

$$f_{X_1, X_2}(x_1, x_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f(w_1, w_2) dw_1 dw_2, \quad (3)$$

其中 $f \geq 0$ 且 $\int \int_{\mathcal{D}} f = 1$ 。

emark **警告**: 与一元情形不同, 这里的 $f(x_1, x_2)$ 可以大于 1! 因为它是“密度”而非概率值。emark

几何直观: 若把联合 pdf $z = f(x_1, x_2)$ 视作一张曲面, 则 $\mathbb{P}((X_1, X_2) \in A)$ 就是该曲面下区域 A 上的体积。这是一元情形“曲线下面积”在二维的推广。

1.3. R 计算: 联合分布.

EXAMPLE 2.1 (二元正态概率计算). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.5)$ 。求 $\mathbb{P}(X_1 \leq 0, X_2 \leq 0)$ 。

在 R 中使用 *mvtnorm* 包:

```
install.packages("mvtnorm")
library(mvtnorm)
```

二元正态 CDF

```
pmvnorm(lower = c(-Inf, -Inf), upper = c(0, 0),
         mean = c(0, 0), sigma = matrix(c(1, 0.5, 0.5, 1), nrow = 2))
```

EXAMPLE 2.2 (生成二元正态样本). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.8)$ 。生成 $n = 1000$ 的样本并可视化。

```
library(mvtnorm)
n <- 1000
rho <- 0.8
sigma <- matrix(c(1, rho, rho, 1), nrow = 2)
set.seed(42)
sample <- rmvnorm(n, mean = c(0, 0), sigma = sigma)
```

绘制散点图

```
plot(sample, xlab = expression(X[1]), ylab = expression(X[2]),
     main = bquote(rho == .(rho)), pch = 20, cex = 0.5)
```

计算样本相关系数

```
cor(sample[,1], sample[,2])
```

不同 ρ 值的散点图形态：

- $\rho = 0$ ：分布呈圆形，变量独立
- $\rho > 0$ ：分布沿主对角线 ($x_2 = x_1$) 拉伸
- $\rho < 0$ ：分布沿副对角线 ($x_2 = -x_1$) 拉伸
- $|\rho| \rightarrow 1$ ：分布越来越集中在一条直线附近

2. 2.2 边缘分布：积分即求和

2.1. 核心问题：如何从联合分布得到边缘分布？ 我们已经知道 (X_1, X_2) 的联合分布，自然会问：如何得到单个 X_1 的分布？

直觉上，我们需要“忽略” X_2 的信息。具体做法是：

- **离散型**：对 x_2 求和
- **连续型**：对 x_2 积分

这引导我们得到边缘分布公式。¹

边缘 pmf:

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2). \quad (4)$$

边缘 pdf:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2. \quad (5)$$

emark 为什么叫“边缘”？ 在二维离散情形，将联合 pmf 列表，边缘分布恰好是每行（或每列）的“边缘”之和。这解释了名称的由来。emark

一个重要发现： 已知联合分布可以推出边缘分布，但反过来不成立——边缘分布丢失了变量之间的依赖信息。例如，两个不同的联合分布可能有相同的边缘分布。

EXAMPLE 2.3 (不同联合分布有相同边缘分布). 设 (X_1, X_2) 和 (Y_1, Y_2) 有相同的边缘分布，但不同的联合结构。实际上，如果不知道联合分布，就无法回答“两个变量是否相关”这样的问题。

2.2. R 计算：边缘分布. 边缘分布在 R 中通过逐行或逐列求和（离散）或积分（连续）计算。

EXAMPLE 2.4 (离散边缘分布). 设 (X_1, X_2) 的联合 pmf 如下（列联表形式）：

$X_2 \backslash X_1$	1	2	3	4	边缘
1	0.05	0.10	0.05	0.02	?
2	0.08	0.15	0.12	0.05	?
3	0.02	0.08	0.10	0.08	?
边缘	?	?	?	?	1.00

¹推导见附录 section 9.1。

则 X_1 的边缘 *pmf* 为每列之和:

$$p_{X_1}(1) = 0.05 + 0.08 + 0.02 = 0.15, \quad p_{X_1}(2) = 0.10 + 0.15 + 0.08 = 0.33, \quad \text{等等}$$

R 计算:

```
# 联合 pmf (矩阵形式)
joint <- matrix(c(0.05, 0.08, 0.02, # X1=1
                  0.10, 0.15, 0.08, # X1=2
                  0.05, 0.12, 0.10, # X1=3
                  0.02, 0.05, 0.08), # X1=4
               nrow = 3, byrow = FALSE)
colnames(joint) <- c("X1=1", "X1=2", "X1=3", "X1=4")
rownames(joint) <- c("X2=1", "X2=2", "X2=3")

# 边缘分布 (按行、按列求和)
margin_x1 <- colSums(joint) # X1 的边缘 pmf
margin_x2 <- rowSums(joint) # X2 的边缘 pmf

# 验证: 边缘分布之和为 1
sum(margin_x1) # = 1
sum(margin_x2) # = 1
```

EXAMPLE 2.5 (连续边缘分布). 设 (X_1, X_2) 的联合 *pdf* 为

$$f(x_1, x_2) = \begin{cases} 8x_1x_2 & 0 < x_1 < x_2 < 1, \\ 0 & \text{otherwise.} \end{cases}$$

求 X_1 的边缘 *pdf*。

由于 $0 < x_1 < x_2 < 1$, x_2 的取值范围是 $x_1 < x_2 < 1$, 因此:

$$f_{X_1}(x_1) = \int_{x_1}^1 8x_1x_2 dx_2 = 8x_1 \left[\frac{x_2^2}{2} \right]_{x_2=x_1}^{x_2=1} = 8x_1 \cdot \frac{1-x_1^2}{2} = 4x_1(1-x_1^2),$$

其中 $0 < x_1 < 1$ 。

验证:

$$\int_0^1 4x_1(1-x_1^2) dx_1 = 4 \left[\frac{x_1^2}{2} - \frac{x_1^4}{4} \right]_0^1 = 4 \left(\frac{1}{2} - \frac{1}{4} \right) = 1.$$

R 数值验证:

```
# 验证边缘 pdf 的数值积分
f_marginal_x1 <- function(x1) {
  f <- function(x2) 8 * x1 * x2
  integrate(f, lower = x1, upper = 1)$value
}
```

```
# 在几个点验证
x1_vals <- c(0.2, 0.5, 0.8)
sapply(x1_vals, f_marginal_x1) # 应该接近 4*x1*(1-x1^2)
4 * x1_vals * (1 - x1_vals^2)
```

2.3. 边缘分布的深度理解. 为什么边缘分布重要? 边缘分布在实际应用中有广泛用途：

1. 人口统计学：当我们研究”收入”与”教育年限”的联合分布时，边缘分布给出了各变量的边缘分布——即不考虑另一变量时该变量的分布。这相当于”总体”的分布。

2. 保险精算：在汽车保险中，我们关心”理赔次数”与”理赔金额”的联合分布，但边缘分布分别给出了理赔次数的分布和理赔金额的分布——这两个分布本身就有独立的应用价值。

3. 信号处理：在处理二元信号时，边缘分布给出了各分量信号的分布，这在单独分析各分量时有用。

信息损失：一个关键事实是，从联合分布到边缘分布会丢失信息。如果只知道边缘分布，则无法恢复联合分布——因为这需要知道变量之间的依赖结构。

Clayton 模型：在金融保险中，Clayton copula 正是用来说明：相同的边缘分布可以对应于不同的联合分布。这个事实在风险管理中非常重要——仅知道各变量的边缘分布是不够的。

3. 2.3 条件分布：信息的价值

3.1. 条件分布的核心思想. 核心问题：已知 X_1 的值， X_2 的分布会如何变化？

这就是条件分布要回答的问题。条件分布本质上是在 $X_1 = x_1$ 的条件下，重新审视 X_2 的行为——这是贝叶斯思维在随机变量层面的延伸。

离散型条件 pmf: ²

$$p_{X_2|X_1}(x_2 | x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}, \quad p_{X_1}(x_1) > 0. \quad (6)$$

连续型条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}, \quad f_{X_1}(x_1) > 0. \quad (7)$$

分子是联合密度，分母是边缘密度。这个比值衡量的是，在 $X_1 = x_1$ 的条件下， (x_1, x_2) 这个”点”有多”典型”。

注意：在连续情形， $\mathbb{P}(X_1 = x_1) = 0$ ，所以不能直接用条件概率定义。这里用条件密度代替——条件密度的定义源自 Radon-Nikodym 定理，它是条件期望存在性的数学基础。³

²推导见附录 section 9.2。

³条件密度的严格数学讨论见附录 section 9.3。

由此定义条件期望：

$$\mathbb{E}[u(X_2) | x_1] = \int_{-\infty}^{\infty} u(x_2) f_{X_2|X_1}(x_2 | x_1) dx_2. \quad (8)$$

条件期望 $\mathbb{E}[X_2 | X_1 = x_1]$ 是 x_1 的函数，可以理解为 X_1 取某个值时 X_2 的最佳预测。

3.2. 全期望公式与方差分解. 这里有一个深刻的定理，它连接了条件与边缘。⁴

THEOREM 2.1 (全期望公式).

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2). \quad (2.3.1)$$

含义：对条件均值再取期望，等于无条件期望。这看起来显而易见，但它是概率论中最强大的工具之一。

更惊人的是方差的不等式：⁵

THEOREM 2.2 (条件方差公式).

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)]. \quad (2.3.2)$$

直观理解：总方差等于“平均条件方差”加上“条件均值的方差”。第一项度量 X_2 在给定 X_1 后的残余不确定性；第二项度量 X_1 带来的不确定性。

Rao-Blackwell 定理：若用 X_2 估计 $\mu_2 = \mathbb{E}X_2$ ，则条件均值 $\mathbb{E}(X_2 | x_1)$ 比 X_2 本身更精确（方差更小）。这在统计推断中极其重要——它告诉我们如何利用辅助信息改进估计。⁶

3.3. R 计算：条件分布.

EXAMPLE 2.6 (离散条件分布). 设 (X_1, X_2) 的联合 pmf 如下：

$$p_{X_1, X_2}(x_1, x_2) = \frac{1}{8}, \quad x_1 = 1, 2, \quad x_2 = 1, 2, 3, 4.$$

求条件分布 $\mathbb{P}(X_2 = x_2 | X_1 = 1)$ 。

边缘分布 $p_{X_1}(1) = \sum_{x_2=1}^4 \frac{1}{8} = \frac{4}{8} = \frac{1}{2}$ 。

条件分布：

$$\mathbb{P}(X_2 = x_2 | X_1 = 1) = \frac{p_{X_1, X_2}(1, x_2)}{p_{X_1}(1)} = \frac{1/8}{1/2} = \frac{1}{4}, \quad x_2 = 1, 2, 3, 4.$$

因此，给定 $X_1 = 1$ 时， X_2 均匀分布于 $\{1, 2, 3, 4\}$ 。

⁴推导见附录 section 9.4。

⁵推导见附录 section 9.5。

⁶Rao-Blackwell 定理的详细讨论见附录 section 9.6。

EXAMPLE 2.7 (连续条件分布). 设 (X_1, X_2) 服从二元正态 $N(0, 0, 1, 1, 0.5)$ 。求条件分布 $f_{X_2|X_1}(x_2 | x_1 = 0.5)$ 。

由公式 (2.6.1):

$$X_2 | X_1 = 0.5 \sim N\left(0 + 0.5 \cdot \frac{1}{1}(0.5 - 0), 1 \cdot (1 - 0.5^2)\right) = N(0.25, 0.75).$$

R 验证:

条件分布参数

```
mu2_given_x1 <- 0 + 0.5 * (0.5 - 0) # = 0.25
```

```
sigma2_sq <- 1 * (1 - 0.5^2) # = 0.75
```

在 R 中绘制条件密度

```
curve(dnorm(x, mu2_given_x1, sqrt(sigma2_sq)),
      from = -2, to = 2,
      xlab = expression(x[2]), ylab = "Density",
      main = expression(paste("Conditional density of ", X[2], " | ", X[1], " = 0.5"))
```

3.4. 条件分布的实际应用. 条件分布在统计建模中有广泛应用:

1. **回归分析:** 条件均值 $\mathbb{E}(Y | X = x)$ 正是回归函数。线性回归假设 $\mathbb{E}(Y | X = x) = \alpha + \beta x$, 但更一般地, 任何条件均值函数都可以作为回归目标。

2. **分层抽样:** 在抽样设计中, 我们经常按子群 (strata) 分组。子群内的条件分布描述了组内变异, 而边缘分布描述了总体变异。方差分解公式 (2.3.2) 正是这种思想的数学表达。

3. **贝叶斯统计:** 后验分布 $f(\theta | x)$ 是在观测数据 x 的条件下参数 θ 的条件分布。整个贝叶斯推断都建立在条件分布的理论之上。

3.5. R 计算: 条件分布的应用. 继续展示条件分布在 R 中的实际计算。

EXAMPLE 2.8 (二元正态条件分布可视化). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.7)$ 。绘制不同 x_1 条件下 X_2 的条件密度。

```
library(mvtnorm)
```

```
library(ggplot2)
```

设置参数

```
mu1 <- mu2 <- 0
```

```
sigma1 <- sigma2 <- 1
```

```
rho <- 0.7
```

条件分布参数

```
cond_mean <- function(x1) mu2 + rho * (sigma2/sigma1) * (x1 - mu1)
```

```
cond_var <- sigma2^2 * (1 - rho^2)
```

```
# 绘制条件密度
x1_vals <- c(-2, -1, 0, 1, 2)
colors <- c("blue", "green", "red", "orange", "purple")

plot(NULL, xlim = c(-4, 4), ylim = c(0, 0.5),
      xlab = expression(x[2]), ylab = "Density",
      main = "Conditional densities of X2 given X1")

for (i in seq_along(x1_vals)) {
  curve(dnorm(x, cond_mean(x1_vals[i]), sqrt(cond_var)),
        add = TRUE, col = colors[i], lwd = 2)
  abline(v = cond_mean(x1_vals[i]), col = colors[i], lty = 2)
}

legend("topright", legend = paste("X1 =", x1_vals),
      col = colors, lwd = 2, cex = 0.8)
```

观察：条件均值随 x_1 线性变化（回归效应），条件方差保持不变（正态分布的特殊性质）。

EXAMPLE 2.9 (分层抽样的方差分解). 设某大学有 10000 名学生，按专业分为 5 个阶层 (*strata*)。我们想估计学生的平均每周学习时间。

假设各阶层的样本均值和方差如下：

专业	n_h	$\bar{X}_h$	s_h^2
理工	3000	20	25
文科	2500	25	20
商科	2000	22	30
法学	1500	18	15
医学	1000	28	35

边缘分布的方差分解：

$$\text{var}(\bar{X}) = \mathbb{E}[\text{var}(X | H)] + \text{var}[\mathbb{E}(X | H)].$$

第一项（层内方差）是各阶层方差的加权平均：

$$\mathbb{E}[\text{var}(X | H)] = \sum_h \frac{n_h}{N} s_h^2.$$

第二项（层间方差）是各阶层均值方差的加权平均：

$$\text{var}[\mathbb{E}(X | H)] = \sum_h \frac{n_h}{N} (\bar{X}_h - \bar{X})^2,$$

其中 $\bar{X}$ 是总体均值。

R 计算：

```
# 阶层数据
n_h <- c(3000, 2500, 2000, 1500, 1000)
Xbar_h <- c(20, 25, 22, 18, 28)
s2_h <- c(25, 20, 30, 15, 35)
N <- sum(n_h)

# 总体均值
Xbar <- sum(n_h * Xbar_h) / N

# 层内方差期望
within_var <- sum(n_h * s2_h) / N

# 层间方差
between_var <- sum(n_h * (Xbar_h - Xbar)^2) / N

# 总方差
total_var <- within_var + between_var

# 分层抽样估计的方差
# 简单随机抽样的方差（比较基准）
srs_var <- total_var / N # 简单随机抽样

# 分层抽样的效率
strat_efficiency <- srs_var / (within_var/N)
cat("层内方差期望:", within_var, "\n")
cat("层间方差:", between_var, "\n")
cat("总方差:", total_var, "\n")
cat("分层抽样相对效率:", round(strat_efficiency, 2), "倍\n")
```

3.6. 条件分布的贝叶斯视角. 贝叶斯统计的核心思想是：参数 θ 也是随机变量，我们应该用条件分布来描述我们对参数的认知。

先验分布： θ 在观测数据之前的分布，记作 $f(\theta)$ 。

似然函数： $L(\theta | x) = f(x | \theta)$ ，描述数据如何更新我们对 θ 的认知。

后验分布：⁷

$$f(\theta | x) = \frac{f(x | \theta)f(\theta)}{f(x)},$$

⁷推导见附录 section 9.7。

其中 $f(x) = \int f(x | \theta) f(\theta) d\theta$ 是归一化常数。

后验均值： $\mathbb{E}(\theta | x)$ 是贝叶斯估计量，它优于普通样本均值——尤其在样本量较小时。

后验方差： $\text{var}(\theta | x)$ 度量了参数估计的不确定性。它在统计决策理论和置信区间构建中都有重要应用。

历史注记：Thomas Bayes (1702-1761) 在其论文《An Essay Towards Solving a Problem in the Doctrine of Chances》中首次提出了贝叶斯公式。拉普拉斯 (Laplace) 后来独立发展了贝叶斯方法，并将其应用于天文学、人口统计等领域。贝叶斯方法在 20 世纪经历了从被忽视到复兴的过程——部分原因是计算限制（马尔可夫链蒙特卡洛方法解决了这个问题），部分原因是哲学层面的争论。⁸

EXAMPLE 2.10 (Beta-Binomial 共轭). 设 $X | \theta \sim \text{Binomial}(n, \theta)$, $\theta \sim \text{Beta}(\alpha, \beta)$ 。则后验分布为

$$\theta | X = x \sim \text{Beta}(\alpha + x, \beta + n - x).$$

后验均值为

$$\mathbb{E}(\theta | X = x) = \frac{\alpha + x}{\alpha + \beta + n}.$$

这个估计量是样本比例 $\hat{p} = x/n$ 和先验均值 $\frac{\alpha}{\alpha + \beta}$ 的加权平均——数据越多，权重越倾向于数据一方。

R 验证：

```
# 先验参数
alpha <- 2
beta <- 3

# 观测数据
n <- 10
x <- 7

# 后验参数
alpha_post <- alpha + x
beta_post <- beta + n - x

# 后验均值
post_mean <- alpha_post / (alpha_post + beta_post)

# 样本比例
sample_prop <- x / n
```

⁸贝叶斯方法的详细历史讨论见附录 section 9.8。

```
# 先验均值
prior_mean <- alpha / (alpha + beta)

# 贝叶斯估计量（后验均值）
cat("先验均值:", prior_mean, "\n")
cat("样本比例:", sample_prop, "\n")
cat("后验均值:", post_mean, "\n")
cat("后验均值 = (n/(n++)) * 样本比例 + ((+)/(n++)) * 先验均值\n")
cat("= (10/15)*0.7 + (5/15)*0.4 =", 10/15*0.7 + 5/15*0.4, "\n")
```

4. 2.4 独立性：变量间的“无关系”

4.1. 什么时候 X_1 和 X_2 互不影响? 若 X_1 与 X_2 独立，则知道 X_1 的值不会改变我们对 X_2 的认知。用条件分布的语言：

$$f_{X_2|X_1}(x_2 | x_1) = f_{X_2}(x_2) \quad (\text{不依赖于 } x_1) .$$

由此推出联合密度可分离。⁹

THEOREM 2.3 (独立性).

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv f_1(x_1)f_2(x_2). \quad (2.4.1)$$

一个实用的判据：

THEOREM 2.4 (独立性因子化判据).

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv g(x_1)h(x_2) \quad (\text{可分离变量}) . \quad (2.4.2)$$

独立性的后果：

- $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$
- $\text{cov}(X_1, X_2) = 0$

emark **逆命题不成立!** $\text{cov}(X_1, X_2) = 0$ 并不意味着独立性（除二元正态分布外）。
emark

这提醒我们：**不相关**（uncorrelated）和**独立**（independent）是两个不同概念。不相关只说明没有线性关系，但变量间可能存在非线性依赖。

一个经典反例：设 $X \sim \text{Uniform}(-1, 1)$, $Y = X^2$ 。则 $\text{cov}(X, Y) = 0$ （因为 X 对称），但 Y 完全由 X 决定——它们显然不独立。¹⁰

⁹推导见附录 section 9.9。

¹⁰更多反例见附录 section 9.10。

4.2. 独立的实际意义. 独立性在统计推断中极其重要, 因为:

1. **简化计算:** 若 $X_1 \perp\!\!\!\perp X_2$, 则

$$\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)],$$

这大大简化了期望的计算。

2. **分解问题:** 在许多统计问题中, 我们假设观测独立。这使得复杂问题可以分解为简单问题的组合。

3. **乘积分布:** 若 $X_1 \perp\!\!\!\perp X_2$, 则联合分布是边缘分布的乘积——这是一个优雅的结构性陈述。

4.3. R 计算: 独立性检验. 在实际数据分析中, 我们经常需要检验两个变量是否独立。

EXAMPLE 2.11 (独立性检验). 使用卡方检验检验两个分类变量的独立性:

```
# 创建列联表
smoking <- c(rep("Yes", 45), rep("No", 105))
cancer <- c(rep("Yes", 20), rep("No", 25), rep("Yes", 15), rep("No", 90))
table <- matrix(c(20, 25, 15, 90), nrow = 2, byrow = TRUE)
colnames(table) <- c("Cancer Yes", "Cancer No")
rownames(table) <- c("Smoking Yes", "Smoking No")

# 卡方检验
chisq.test(table)
```

Fisher 精确检验: 当样本量较小时, 使用 Fisher 精确检验比卡方检验更可靠:

```
fisher.test(table)
```

4.4. 独立性的深入理解. 为什么独立性如此重要? 独立性假设是现代统计推断的基石之一。

1. **计算简化:** 若 $X_1 \perp\!\!\!\perp X_2$, 则

$$\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)].$$

这大大简化了期望的计算。

2. **分解简化:** 在许多统计问题中, 我们假设观测独立。这使得复杂问题可以分解为简单问题的组合。例如, 样本均值 $\bar{X} = n^{-1} \sum X_i$ 的方差, 当 X_i 独立同分布时, 为 $\text{var}(\bar{X}) = \sigma^2/n$ 。没有独立性, 这个公式不成立。

3. **乘积分布:** 若 $X_1 \perp\!\!\!\perp X_2$, 则联合分布是边缘分布的乘积——这是一个优雅的结构性陈述。

独立性的判别: 在实际问题中, 我们如何判断两个变量是否独立?

1. **因子化判据:** 若联合 pdf/pmf 可以写成 $f(x_1, x_2) = g(x_1)h(x_2)$ 的形式, 则 X_1 与 X_2 独立。

2. 条件分布判据：若条件分布等于边缘分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_2}(x_2)$ ，则独立。

3. 协方差判据（反向）：若 $\text{cov}(X_1, X_2) \neq 0$ ，则一定不独立。但 $\text{cov}(X_1, X_2) = 0$ 不能推出独立（除特殊情况外）。

独立 vs 不相关：这是一个极其重要的区别。

不相关 (uncorrelated) 只说明没有线性关系： $\text{cov}(X_1, X_2) = 0$ 。

独立 (independent) 意味着知道一个变量的值对另一个变量的分布没有任何影响。

独立 $\Rightarrow$ 不相关，但反过来一般不成立。

二元正态的特殊性：在二元正态分布中，不相关 $\iff$ 独立。这是因为二元正态的联合分布完全由一阶矩和二阶矩决定。

在其他分布中：对于非正态分布， $\text{cov} = 0$ 但不独立是可能的。

反例： X 与 $Y = X^2$ ：设 $X \sim \text{Uniform}(-1, 1)$ ， $Y = X^2$ 。则 $\text{cov}(X, Y) = 0$ ，但显然 Y 完全由 X 决定，不独立。¹¹

EXAMPLE 2.12 (独立性检验的更多方法). 在实际数据分析中，独立性检验方法的选择取决于数据。

1. 连续变量的 *Pearson* 相关系数检验：

检验 X 和 Y 是否独立（假设二元正态）

```
x <- rnorm(100, mean = 0, sd = 1)
y <- 0.5 * x + rnorm(100, mean = 0, sd = sqrt(1 - 0.5^2))
cor.test(x, y, method = "pearson")
```

2. 秩相关 (*Spearman* 和 *Kendall*): 对非正态数据更鲁棒：

Spearman 秩相关

```
cor.test(x, y, method = "spearman")
```

Kendall tau 相关

```
cor.test(x, y, method = "kendall")
```

3. 互信息：度量变量的整体依赖关系（包括非线性）：

计算互信息（需要 *infotheo* 包）

```
library(infotheo)
discretize(cbind(x, y))
mutualinformation(discretize(cbind(x, y)))
```

4. χ^2 检验：适用于分类变量：

创建列联表

```
smoke <- c(rep("Yes", 45), rep("No", 105))
cancer <- c(rep("Yes", 20), rep("No", 25), rep("Yes", 15), rep("No", 90))
table <- matrix(c(20, 25, 15, 90), nrow = 2, byrow = TRUE)
```

¹¹详细计算见附录 section 9.10。

卡方检验

```
chisq.test(table)
```

Fisher 精确检验（样本量小时更可靠）

```
fisher.test(table)
```

独立性的实际应用：

1. 金融风险管理的核心假设：在金融工程中，资产收益率的独立性假设是 Black-Scholes 公式的基础。虽然这个假设在实践中经常被违反（存在“波动率聚集”等现象），但它提供了一个有用的基准模型。

2. 信号处理：在噪声模型中，我们通常假设信号与噪声独立。这使得我们可以从噪声观测中恢复信号。

3. 机器学习：许多算法假设训练样本独立同分布（i.i.d.）。当这个假设被违反时（如时间序列数据），需要使用专门的模型（如 RNN、LSTM）。

5. 2.5 相关性：线性关联的度量

我们已经知道 $\text{cov}(X_1, X_2) = 0$ 不能完全刻画独立性。那么如何量化 X_1 与 X_2 之间的“关联程度”？

协方差 $\text{cov}(X_1, X_2)$ 存在一个问题：它依赖于 X_1, X_2 的量纲。例如，身高（cm）和体重（kg）的协方差与换算成英寸和磅时不同。

解决方案：先标准化，再求协方差：

$$\rho_{12} = \text{corr}(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)}\sqrt{\text{var}(X_2)}} = \frac{\text{cov}(X_1, X_2)}{\sigma_1\sigma_2}. \quad (2.5.1)$$

这就是相关系数（correlation coefficient）。

核心性质：¹²

- $-1 \leq \rho_{12} \leq 1$
- $|\rho_{12}| = 1 \iff X_2 = aX_1 + b$ （完美线性关系）
- $\rho_{12} = 0$ 称**不相关**

为什么是 $[-1, 1]$ ？这来自 Cauchy-Schwarz 不等式：

$$|\text{cov}(X_1, X_2)| = |\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]| \leq \sqrt{\mathbb{E}[(X_1 - \mu_1)^2] \cdot \mathbb{E}[(X_2 - \mu_2)^2]} = \sigma_1\sigma_2 \cdot |\text{corr}(X_1, X_2)| = |\text{corr}(X_1, X_2)| \sigma_1\sigma_2 \quad (2.5.2)$$

emark 相关 vs 协方差：协方差取决于量纲（“米的协方差”vs“厘米的协方差”数值不同）；相关系数是无量纲的，消除了单位影响。因此，相关系数是更通用的“关联程度”度量。emark

¹²推导见附录 section 9.11。

5.1. 历史注记：Pearson 与相关系数. 相关系数的概念由 Francis Galton (1888) 在研究遗传问题时首次提出，但 Karl Pearson (1896) 给出了严格的数学定义和估计方法。Pearson 的工作奠定了生物计量学的基础，也使得相关性成为统计学中最广泛使用的概念之一。

Galton 的发现： Galton 研究双胞胎身高时发现，父亲身高与子女身高之间存在“回归” (regression) 现象——极端身高（非常高或非常矮）的父母，其子女的身高倾向于向平均值“回归”。这种“向均值回归”的现象正是相关性的体现。

Pearson 的贡献： Pearson 给出了相关系数的精确数学定义：

$$\rho_{XY} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y},$$

并推导了其统计性质。他发展的矩估计方法至今仍是估计相关系数的主要方法之一。

5.2. R 计算：相关分析. R 提供了丰富的相关分析功能：

EXAMPLE 2.13 (样本相关系数). 计算两组数据的 *Pearson* 相关系数：

```
# 数据：父亲身高与儿子身高（模拟 Galton 数据）
father <- c(65, 63, 67, 64, 68, 62, 70, 66, 68, 65)
son <- c(68, 66, 68, 65, 69, 63, 71, 67, 69, 66)

# 计算样本相关系数
cor(father, son)

# 计算置信区间（使用 Fisher z 变换）
n <- length(father)
r <- cor(father, son)
z <- 0.5 * log((1+r)/(1-r)) # Fisher z 变换
se <- 1/sqrt(n-3)
z_ci <- c(z - 1.96*se, z + 1.96*se)
r_ci <- (exp(2*z_ci) - 1)/(exp(2*z_ci) + 1)
r_ci
```

相关性的解释：

- $|\rho| = 0$ ：无线性关系
- $|\rho| \in (0, 0.3)$ ：弱相关
- $|\rho| \in [0.3, 0.7)$ ：中等相关
- $|\rho| \in [0.7, 1)$ ：强相关
- $|\rho| = 1$ ：完美线性关系

注意事项：

- (1) 相关系数只度量线性关系，非线性关系可能表现出 $\rho = 0$

- (2) 相关系数对异常值敏感（可以使用 Spearman 或 Kendall 相关系数作为鲁棒替代）
- (3) 相关不等于因果——两个变量相关可能是因为它们共同受第三个变量影响

EXAMPLE 2.14 (相关与因果). 冰淇淋销量与溺水死亡人数呈正相关 ($\rho \approx 0.9$)。但这并不意味着吃冰淇淋导致溺水——两者都与夏季气温正相关。正确的解释是：夏季（共同原因）导致冰淇淋销量增加和更多人游泳（从而溺水增加）。

6. 2.6 二元正态：最重要的二元分布

在所有二元分布中，二元正态分布占据核心地位。它是一元正态分布在二维的自然推广，也是计量经济学、信号处理等领域的基石。

为什么重要？

- (1) 边缘分布和条件分布都是正态的
- (2) 线性组合仍是正态
- (3) 不相关 $\iff$ 独立（这是正态独有的优雅性质）
- (4) 多元正态是计量经济学、信号处理等领域的基石

历史注记：二元正态分布由 Francis Galton 和 Karl Pearson 在 19 世纪末独立发展。Pearson 发展的多元相关理论为现代统计学奠定了重要基础。

DEFINITION 2.2 (二元正态分布). (X_1, X_2) 服从二元正态分布，若其联合 pdf 为

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\},$$

记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

五个参数的含义：

- μ_1, μ_2 : 边缘分布的均值
- σ_1^2, σ_2^2 : 边缘分布的方差
- ρ : 相关系数

关键性质：

- (1) 边缘分布: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) 条件分布: ¹³

$$X_2 | X_1 = x_1 \sim N \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2 (1 - \rho^2) \right) \quad X_2 | X_1 = x_1 \sim N \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2 (1 - \rho^2) \right) \quad (2.6.1)$$

- (3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ （正态独有的”不相关 $\Rightarrow$ 独立”）
- (4) 任意线性组合 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, \text{var}(aX_1 + bX_2))$

¹³推导见附录 section 9.12。

emark 条件分布的几何直觉：条件均值

$$\mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1)$$

是 x_1 的线性函数。这意味着：给定 $X_1 = x_1$ ， X_2 的最佳预测也是线性的，其斜率由相关系数 ρ 决定。emark

条件分布的方差 $\sigma_2^2(1 - \rho^2)$ 小于无条件方差 σ_2^2 ——知道 X_1 的值减少了对 X_2 的不确定性。当 $|\rho| = 1$ 时，方差为零，意味着 X_2 可以完全由 X_1 线性决定。

6.1. R 计算：二元正态. R 中处理二元正态分布的核心函数包括 `mvtnorm` 包中的函数。

EXAMPLE 2.15 (二元正态概率计算). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.7)$ 。求 $\mathbb{P}(X_1 \leq 0.5, X_2 \leq 0.5)$ 。

在 R 中：

```
# 安装和加载 mvtnorm 包
install.packages("mvtnorm")
library(mvtnorm)

# 计算二元正态 CDF
pmvnorm(lower = c(-Inf, -Inf), upper = c(0.5, 0.5),
         mean = c(0, 0), sigma = matrix(c(1, 0.7, 0.7, 1), nrow = 2))
```

EXAMPLE 2.16 (生成二元正态样本). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.8)$ 。生成 $n = 1000$ 的样本并可视化。

```
library(mvtnorm)
n <- 1000
rho <- 0.8
sigma <- matrix(c(1, rho, rho, 1), nrow = 2)
set.seed(123)
sample <- rmvnorm(n, mean = c(0, 0), sigma = sigma)

# 绘制散点图
plot(sample, xlab = expression(X[1]), ylab = expression(X[2]),
     main = paste("Bivariate Normal, rho =", rho), pch = 20, cex = 0.5)

# 添加相关系数
cor(sample[,1], sample[,2])
```

不同 ρ 值的效果：

- $\rho = 0$: X_1 和 X_2 独立，分布呈圆形对称
- $\rho > 0$: 正相关，分布沿主对角线 ($y = x$) 拉伸

- $\rho < 0$: 负相关, 分布沿副对角线 ($y = -x$) 拉伸
- $|\rho| = 1$: 分布退化为一条直线 (完美线性关系)

6.2. 条件均值与预测. 二元正态的一个核心应用是**最优线性预测**。给定 $X_1 = x_1$, X_2 的最佳预测是条件均值:

$$\hat{X}_2 = \mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1).$$

为什么是”最优”? 考虑预测误差 $e = X_2 - \hat{X}_2$ 。可以证明, 在所有线性预测中, 这个条件均值预测的均方误差最小。¹⁴

预测误差的方差: $\text{var}(e) = \sigma_2^2(1 - \rho^2)$ 。当 $|\rho| = 1$ 时, 误差方差为零—— X_2 可以完全由 X_1 预测。

EXAMPLE 2.17 (身高与体重预测). 设 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 其中 X_1 为父亲身高 (英寸), X_2 为儿子身高 (英寸)。根据 Galton 的经典数据:

$$\mu_1 = \mu_2 = 68.2, \quad \sigma_1 = \sigma_2 = 2.7, \quad \rho = 0.5.$$

给定父亲身高 $x_1 = 72$ 英寸, 儿子的预测身高为:

$$\mathbb{E}(X_2 | X_1 = 72) = 68.2 + 0.5 \cdot \frac{2.7}{2.7} (72 - 68.2) = 68.2 + 1.9 = 70.1 \text{ 英寸}.$$

预测误差的标准差为 $\sigma_2 \sqrt{1 - \rho^2} = 2.7 \cdot \sqrt{0.75} \approx 2.34$ 英寸。

6.3. 回归与条件均值. 从条件均值公式, 我们可以写出”回归方程”:

$$X_2 = \alpha + \beta X_1 + \varepsilon,$$

其中 $\beta = \rho \frac{\sigma_2}{\sigma_1}$, $\alpha = \mu_2 - \beta \mu_1$, $\varepsilon \sim N(0, \sigma_2^2(1 - \rho^2))$ 与 X_1 独立。

最小二乘法的联系: 在统计学中, 我们通常从数据估计回归系数。样本回归系数 $\hat{\beta} = \hat{\rho}_{s_2 s_1}$ 依概率收敛到真实的 β 。¹⁵

7. 2.7 多元推广

前述概念可以推广到 n 个随机变量。记随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$, 其联合 cdf 为

$$F_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

7.1. 边缘与条件分布. 边缘 pdf 通过 $n - 1$ 重积分得到:

$$f_1(x_1) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, x_2, \dots, x_n) dx_2 \cdots dx_n.$$

条件分布定义为联合密度与边缘密度之比:

$$f_{2, \dots, n|1}(x_2, \dots, x_n | x_1) = \frac{f(x_1, x_2, \dots, x_n)}{f_1(x_1)}.$$

¹⁴最优线性预测的推导见附录 section 9.12。

¹⁵回归理论的详细讨论见附录 section 9.13。

7.2. 多元独立性. n 个随机变量 $X_1, \dots, X_n$ 相互独立, 当且仅当

$$f(x_1, x_2, \dots, x_n) \equiv f_1(x_1)f_2(x_2) \cdots f_n(x_n). \quad (2.7.1)$$

注意: 两两独立 (pairwise independence) 不一定推出相互独立 (mutual independence)。Bernstein 的例子说明了这一点。¹⁶

7.3. 线性组合的 mgf. 若 $X_1, \dots, X_n$ 相互独立, $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为

$$M_T(t) = \prod_{i=1}^n M_i(k_i t).$$

¹⁷

特别地, 若 $X_1, \dots, X_n$ iid (独立同分布), 则 $T = \sum_{i=1}^n X_i$ 的 mgf 为

$$M_T(t) = [M(t)]^n. \quad (2.7.2)$$

这个性质在研究样本和的分布时极为有用——它是一切大样本理论的起点。¹⁸

7.4. 多元正态分布. 多元正态分布是二元正态的自然推广, 在统计学中占据核心地位。

DEFINITION 2.3 (n 元正态分布). 随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 服从 n 元正态分布, 若其联合 pdf 为

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\},$$

记作 $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$, 其中 $\boldsymbol{\mu}$ 是均值向量, Σ 是协方差矩阵。

关键性质:

- (1) 任意边缘分布都是正态的
- (2) 任意线性组合 $a_1 X_1 + \dots + a_n X_n \sim N(\mathbf{a}' \boldsymbol{\mu}, \mathbf{a}' \Sigma \mathbf{a})$
- (3) 若 Σ 对角线之外所有元素为零 (即变量独立), 则 $\mathbf{X}$ 的分量独立
- (4) 条件分布仍是正态的

协方差矩阵的性质:

- Σ 是对称的 ($\Sigma' = \Sigma$)
- Σ 是半正定的 (所有特征值 ≥ 0)
- $|\Sigma|^{1/2}$ 是 Σ 的行列式的平方根

¹⁶反例见附录 section 9.14。

¹⁷推导见附录 section 9.15。

¹⁸中心极限定理的讨论见附录 section 9.16。

7.5. 复相关系数与偏相关. 在多元分析中, 我们经常关心一个变量与一组变量整体的相关性。

复相关系数 (Multiple Correlation Coefficient): 度量 X_1 与 $(X_2, \dots, X_n)$ 整体之间的相关性:

$$R_{1.23\dots n} = \sqrt{\frac{\text{var}(\mathbb{E}(X_1 | X_2, \dots, X_n))}{\text{var}(X_1)}}.$$

偏相关系数 (Partial Correlation Coefficient): 在控制其他变量的影响后, X_1 与 X_2 之间的相关性:

$$\rho_{12.3\dots n} = \frac{\text{cov}(X_1, X_2 | X_3, \dots, X_n)}{\sqrt{\text{var}(X_1 | X_3, \dots, X_n) \cdot \text{var}(X_2 | X_3, \dots, X_n)}}.$$

偏相关在因果推断中特别重要——它度量了在控制一组混杂变量后, 两个变量之间的”直接”相关性。

8. 本章总结

概念	公式/描述
联合 cdf	$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2)$
边缘 pmf	$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2)$
边缘 pdf	$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2) dx_2$
条件 pmf	$p_{X_2 X_1}(x_2 x_1) = p(x_1, x_2)/p_{X_1}(x_1)$
条件 pdf	$f_{X_2 X_1}(x_2 x_1) = f(x_1, x_2)/f_{X_1}(x_1)$
全期望	$\mathbb{E}[\mathbb{E}(X_2 X_1)] = \mathbb{E}X_2$
方差分解	$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 X_1)] + \text{var}[\mathbb{E}(X_2 X_1)]$
独立性	$f(x_1, x_2) = f_1(x_1)f_2(x_2)$
协方差	$\text{cov} = \mathbb{E}(X_1X_2) - \mathbb{E}X_1\mathbb{E}X_2$
相关系数	$\rho = \text{cov}/(\sigma_1\sigma_2), -1 \leq \rho \leq 1$

本章内部脉络: 联合分布 (描述共同行为) $\rightarrow$ 边缘分布 (提取单个变量信息) $\rightarrow$ 条件分布 (利用已知变量更新未知变量) $\rightarrow$ 独立性 (无关系时的简化) $\rightarrow$ 相关性 (量化关联程度)。

为下一章铺垫: 第 3 章将系统研究最重要的几类分布, 这些分布在多元情形下自然出现。第 4 章则利用这些分布建立统计推断的基本工具。

习题

EXERCISE 2.1. 2.1.1 设 X_1 和 X_2 的联合 pdf 为 $f(x_1, x_2) = x_1 + x_2, 0 < x_1 < 1, 0 < x_2 < 1$, 其他位置为零。求 X_1 的边缘 pdf。

EXERCISE 2.2. 2.2.1 设 (X_1, X_2) 的联合 pdf 为 $f(x_1, x_2) = 2, 0 < x_1 < x_2 < 1$, 其他位置为零。

(1) 求边缘 pdf $f_{X_1}(x_1)$ 和 $f_{X_2}(x_2)$

(2) 验证 $\int \int f = 1$

EXERCISE 2.3. 2.3.1 设 X_1 和 X_2 具有联合 pdf $f(x_1, x_2) = x_1 + x_2$, $0 < x_1 < 1$, $0 < x_2 < 1$ 。求给定 $X_1 = x_1$ 时 X_2 的条件均值和条件方差。

EXERCISE 2.4. 2.3.2 证明全期望公式: $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}X_2$ 。(提示: 对离散和连续两种情形分别证明)

EXERCISE 2.5. 2.4.1 证明: 若 X_1 和 X_2 独立, 则 $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$ 。

EXERCISE 2.6. 2.4.2 设 (X, Y) 具有联合 pdf $f(x, y) = x + y$, $0 < x < 1$, $0 < y < 1$ 。 X 与 Y 是否独立? 为什么?

EXERCISE 2.7. 2.5.1 设 (X, Y) 具有联合 pdf $f(x, y) = x + y$, $0 < x < 1$, $0 < y < 1$ 。求相关系数 ρ 。

EXERCISE 2.8. 2.5.2 证明: $-1 \leq \text{corr}(X, Y) \leq 1$ 。(提示: 使用 Cauchy-Schwarz 不等式)

EXERCISE 2.9. 2.6.1 设 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。证明条件分布 $X_2 | X_1 = x_1 \sim N(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2))$ 。

EXERCISE 2.10. 2.6.2 设 $(X_1, X_2) \sim N(0, 0, 1, 1, \rho)$ (相关系数为 ρ 的二元标准正态)。求 $X_1 + X_2$ 的分布。

EXERCISE 2.11. 2.7.1 设 X_1, X_2, X_3 为三个独立同分布的随机变量, 每个的 pdf 为 $f(x) = 2x$, $0 < x < 1$ 。求 $Y = \max\{X_1, X_2, X_3\}$ 的分布。

EXERCISE 2.12. 2.7.2 设 $X_1, \dots, X_n \text{ iid} \sim N(\mu, \sigma^2)$ 。令 $\bar{X} = n^{-1} \sum X_i$ 。利用 mgf 证明 $\bar{X} \sim N(\mu, \sigma^2/n)$ 。

9. 附录：公式推导

9.1. 边缘分布公式推导. 背景: 已知联合分布, 如何得到单个变量的边缘分布?

目标: 从联合 pmf/pdf 推导边缘 pmf/pdf 的计算公式。

推导步骤:

离散型: 设 (X_1, X_2) 的联合 pmf 为 $p_{X_1, X_2}(x_1, x_2)$ 。

1. 由边缘 pmf 的定义, X_1 的边缘 pmf 为 $p_{X_1}(x_1) = \mathbb{P}(X_1 = x_1)$ 。

2. 事件 $\{X_1 = x_1\}$ 可以分解为与 X_2 的联合事件:

$$\mathbb{P}(X_1 = x_1) = \sum_{x_2} \mathbb{P}(X_1 = x_1, X_2 = x_2).$$

3. 因此边缘 pmf 公式为

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2).$$

连续型: 设 (X_1, X_2) 的联合 pdf 为 $f_{X_1, X_2}(x_1, x_2)$ 。

1. 由边缘 pdf 的定义, X_1 的边缘 pdf 满足

$$\mathbb{P}(a \leq X_1 \leq b) = \int_a^b f_{X_1}(x_1) dx_1.$$

2. 另一方面,

$$\mathbb{P}(a \leq X_1 \leq b) = \int_a^b \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

3. 比较两式, 由微积分基本定理, 得到边缘 pdf 公式:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2.$$

几何直观: 联合 pdf 是二维” 概率密度曲面”, 边缘 pdf 是该曲面对 x_2 方向” 压扁” 后得到的、一维曲线下的面积。

9.2. 条件分布公式推导. 背景: 已知联合分布, 如何描述” 已知 X_1 的值时 X_2 的分布”?

目标: 推导条件 pmf/pdf 的计算公式。

推导步骤:

离散型:

1. 条件概率的基本定义:

$$\mathbb{P}(X_2 = x_2 \mid X_1 = x_1) = \frac{\mathbb{P}(X_1 = x_1, X_2 = x_2)}{\mathbb{P}(X_1 = x_1)}.$$

2. 代入联合 pmf 和边缘 pmf:

$$p_{X_2|X_1}(x_2 \mid x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}.$$

3. 验证归一性: $\sum_{x_2} p_{X_2|X_1}(x_2 \mid x_1) = 1$ 。

连续型:

1. 连续情形不能直接用条件概率定义, 因为 $\mathbb{P}(X_1 = x_1) = 0$ 。我们用极限思想:

$$f_{X_2|X_1}(x_2 \mid x_1) = \lim_{\Delta \rightarrow 0} \frac{\mathbb{P}(x_1 \leq X_1 < x_1 + \Delta, X_2 \in dx_2)}{\mathbb{P}(x_1 \leq X_1 < x_1 + \Delta) \cdot dx_2}.$$

2. 分子分母同除以 Δ 并取极限, 得到

$$f_{X_2|X_1}(x_2 \mid x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

3. 验证归一性: $\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 \mid x_1) dx_2 = 1$ 。

直觉理解: 条件密度是联合密度在固定 x_1 处的” 切片”, 再除以该切片下的总面积 (边缘密度) 进行归一化。

9.3. 条件密度与 Radon-Nikodym 定理. 背景：连续情形下条件密度 $f_{X_2|X_1}(x_2|x_1) = f(x_1, x_2)/f_{X_1}(x_1)$ 的严格数学基础是什么？

已知条件：

- 联合 pdf $f_{X_1, X_2}(x_1, x_2)$ 存在
- 边缘 pdf $f_{X_1}(x_1) > 0$

目标：严格论证条件密度的存在性与定义。

推导步骤：

1. 条件分布函数定义为

$$F_{X_2|X_1}(x_2 | x_1) = \mathbb{P}(X_2 \leq x_2 | X_1 = x_1).$$

2. 由 Radon-Nikodym 定理：若 $\mathbb{P}_c(\cdot | X_1)$ 是给定 X_1 时的条件概率测度，则存在 Radon-Nikodym 导数（即条件密度）：

$$\mathbb{P}(X_2 \leq x_2 | X_1 = x_1) = \int_{-\infty}^{x_2} f_{X_2|X_1}(x'_2 | x_1) dx'_2.$$

3. 验证条件密度的公式：

$$\int_{-\infty}^{x_2} \frac{f_{X_1, X_2}(x_1, x'_2)}{f_{X_1}(x_1)} dx'_2 = \frac{1}{f_{X_1}(x_1)} \int_{-\infty}^{x_2} f_{X_1, X_2}(x_1, x'_2) dx'_2 = \frac{F_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 对 x_2 求导得到条件密度表达式：

$$\frac{\partial}{\partial x_2} F_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

注：Radon-Nikodym 定理保证了在 σ -有限条件下，条件密度（条件期望的 Radon-Nikodym 导数）的存在性，这是现代概率论的基础结果之一。

9.4. 全期望公式推导. 背景：全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是概率论中最强大的工具之一。

目标：严格推导全期望公式。

推导步骤：

离散型：

1. 条件期望的定义：

$$\mathbb{E}(X_2 | X_1 = x_1) = \sum_{x_2} x_2 \cdot p_{X_2|X_1}(x_2 | x_1) = \sum_{x_2} x_2 \cdot \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}.$$

2. 外层期望是对 X_1 求平均：

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \sum_{x_1} \left[\sum_{x_2} x_2 \cdot \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)} \right] p_{X_1}(x_1).$$

3. 约去 $p_{X_1}(x_1)$ ：

$$= \sum_{x_1} \sum_{x_2} x_2 \cdot p_{X_1, X_2}(x_1, x_2) = \sum_{x_2} x_2 \left[\sum_{x_1} p_{X_1, X_2}(x_1, x_2) \right].$$

4. 内层和是边缘 pmf： $= \sum_{x_2} x_2 \cdot p_{X_2}(x_2) = \mathbb{E}(X_2)$ 。

连续型：类似地，

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} x_2 \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2 \right] f_{X_1}(x_1) dx_1 = \iint x_2 f_{X_1, X_2}(x_1, x_2) dx_1 dx_2 = \mathbb{E}(X_2).$$

意义：全期望公式本质上是”加权平均的加权平均”——先在每个 X_1 条件下计算 X_2 的条件均值，再对条件均值按 X_1 的分布加权平均，结果等于全体平均。

9.5. 方差分解公式推导. 背景：条件方差公式 $\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)]$ 是统计学中最重要的恒等式之一。

目标：证明总方差等于”平均条件方差”加上”条件均值的方差”。

推导步骤：

1. 由方差的定义：

$$\text{var}(X_2) = \mathbb{E}(X_2^2) - [\mathbb{E}(X_2)]^2.$$

2. 对第一项应用全期望公式：

$$\mathbb{E}(X_2^2) = \mathbb{E}[\mathbb{E}(X_2^2 | X_1)].$$

3. 在每个 $X_1 = x_1$ 条件下， $\mathbb{E}(X_2^2 | X_1 = x_1) = \text{var}(X_2 | X_1 = x_1) + [\mathbb{E}(X_2 | X_1 = x_1)]^2$ 。

4. 因此

$$\mathbb{E}(X_2^2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \mathbb{E}[[\mathbb{E}(X_2 | X_1)]^2].$$

5. 代入方差公式：

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \mathbb{E}[[\mathbb{E}(X_2 | X_1)]^2] - [\mathbb{E}(X_2)]^2.$$

6. 注意最后两项恰好是 $\mathbb{E}(X_2 | X_1)$ 的方差：

$$\text{var}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}[[\mathbb{E}(X_2 | X_1)]^2] - [\mathbb{E}(X_2)]^2.$$

7. 代入即得方差分解公式：

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

直观理解：第一项是”组内方差的平均”（知道 X_1 后 X_2 的残余变异），第二项是”组间方差”（不同 X_1 条件下条件均值的变化）。

9.6. Rao-Blackwell 定理. 背景：Rao-Blackwell 定理是统计决策理论的核心结果，说明了如何利用条件化改进估计量。

已知条件：

- T 是 θ 的无偏估计量： $\mathbb{E}_\theta(T) = \theta$
- $S = \mathbb{E}(T | U)$ 是 T 关于充分统计量 U 的条件期望

目标：证明 $\mathbb{E}[(S - \theta)^2] \leq \mathbb{E}[(T - \theta)^2]$ ，即 S 比 T 更好（均方误差更小）。

推导步骤：

1. 由全方差公式：

$$\text{var}_\theta(T) = \mathbb{E}[\text{var}_\theta(T | U)] + \text{var}_\theta[\mathbb{E}_\theta(T | U)].$$

2. 由于 $S = \mathbb{E}(T | U)$ ，有 $\mathbb{E}_\theta(S) = \mathbb{E}_\theta(T) = \theta$ （ S 仍是无偏的）。

3. 由方差分解式两边减去 θ^2 （注意 S 无偏），得

$$\mathbb{E}[(T - \theta)^2] = \underbrace{\mathbb{E}[\text{var}(T | U)]}_{\geq 0} + \mathbb{E}[(S - \theta)^2] \geq \mathbb{E}[(S - \theta)^2].$$

结论：条件化（于充分统计量）不会增加均方误差，且在 T 不是充分统计量的函数时严格减少。这为用条件期望改进任意估计量提供了理论依据。

9.7. 贝叶斯公式推导. 背景：贝叶斯公式是连接先验、似然和后验的桥梁。

已知条件：

- 先验分布： $\theta \sim \pi(\theta)$
- 似然函数： $X | \theta \sim f(x | \theta)$

目标：求后验分布 $\pi(\theta | x)$ 。

推导步骤：

1. 由条件概率的定义：

$$\pi(\theta | x) = \frac{f(x, \theta)}{f(x)} = \frac{f(x | \theta)\pi(\theta)}{f(x)}.$$

2. 其中归一化常数（边际似然）为

$$f(x) = \int f(x | \theta')\pi(\theta') d\theta'.$$

3. 因此贝叶斯公式为

$$\pi(\theta | x) = \frac{f(x | \theta)\pi(\theta)}{\int f(x | \theta')\pi(\theta') d\theta'}.$$

后验均值：作为点估计，

$$\mathbb{E}(\theta | x) = \int \theta \cdot \pi(\theta | x) d\theta = \frac{\int \theta f(x | \theta)\pi(\theta) d\theta}{\int f(x | \theta)\pi(\theta) d\theta}.$$

共轭先验：若先验 π 与似然 $f(\cdot | \theta)$ 共轭，则后验与先验有相同形式，计算大为简化。

9.8. 贝叶斯方法历史概述. 背景: 理解贝叶斯方法的历史脉络有助于认识其哲学内涵。

历史时间线:

1761 年: Thomas Bayes (1702-1761) 发表《An Essay Towards Solving a Problem in the Doctrine of Chances》, 首次提出贝叶斯公式。贝叶斯的证明使用了“逆概率”思想——从观测数据反推原因的概率。

1774 年: Pierre-Simon Laplace (1749-1827) 独立发展了贝叶斯方法, 并将其系统化。拉普拉斯使用贝叶斯方法估计太阳系行星的质量和轨道参数。

19 世纪: 贝叶斯方法在统计界占据主导地位, 但 Frequentist 学派 (Fisher、Pearson、Neyman) 对其“主观先验”提出了批评。

1930-1950 年代: Frequentist 方法成为主流, 贝叶斯方法被边缘化。Fisher 的显著性检验和 Neyman 的置信区间理论主导了统计实践。

1980 年代至今: 由于计算革命 (尤其是 MCMC 方法的发展), 贝叶斯方法复兴。如今它与 Frequentist 方法并列为统计学的两大流派。

哲学争论: 贝叶斯方法的核心争议在于先验分布的选择——

- **客观贝叶斯学派:** 选择无信息先验 (如 Jeffreys 先验), 使后验主要由数据决定
- **主观贝叶斯学派:** 先验分布应反映研究者的真实信念

现代应用: 贝叶斯方法在机器学习 (贝叶斯神经网络)、生物统计 (药物试验)、金融 (风险建模) 等领域有广泛应用。

9.9. 独立性因子化判据推导. 背景: 独立性 $X_1 \perp\!\!\!\perp X_2$ 的定义是 $F(x_1, x_2) = F_1(x_1)F_2(x_2)$, 但这在应用中不方便。因子化判据提供了更实用的检验方法。

目标: 证明 $X_1 \perp\!\!\!\perp X_2 \iff f(x_1, x_2) \equiv g(x_1)h(x_2)$ (对某些 g, h)。

推导步骤:

($\Rightarrow$) 若 $X_1 \perp\!\!\!\perp X_2$:

1. 由独立性, $f_{X_1, X_2}(x_1, x_2) = f_{X_1}(x_1) \cdot f_{X_2}(x_2)$ 。
2. 取 $g(x_1) = f_{X_1}(x_1)$, $h(x_2) = f_{X_2}(x_2)$, 则 $f(x_1, x_2) = g(x_1)h(x_2)$ 。

($\Leftarrow$) 若 $f(x_1, x_2) = g(x_1)h(x_2)$:

1. 对两边积分求边缘:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \underbrace{\int_{-\infty}^{\infty} h(x_2) dx_2}_{C_2} = C_2 g(x_1).$$

同理 $f_{X_2}(x_2) = C_1 h(x_2)$ 。

2. 由归一性 $\iint f = 1$, 得 $C_1 C_2 \iint g(x_1)h(x_2) dx_1 dx_2 = 1$, 故 $C_1 C_2 \cdot C_2 C_1 = 1$, 即 $C_1 C_2 = 1$ (假设 $C_1, C_2 > 0$)。

3. 因此

$$f_{X_1}(x_1)f_{X_2}(x_2) = (C_2 g(x_1)) \cdot (C_1 h(x_2)) = C_1 C_2 g(x_1)h(x_2) = f(x_1, x_2).$$

4. 故 $X_1 \perp\!\!\!\perp X_2$ 。

注：这个判据对于离散型同样适用，只需把积分换成求和。

9.10. 独立 $\Rightarrow$ 不相关的反例. 背景：已知独立一定推出不相关 ($\text{cov} = 0$)，但逆命题一般不成立。这里给出经典反例。

目标：构造 $\text{cov}(X, Y) = 0$ 但 X 与 Y 不独立的例子。

推导步骤：

设 $X \sim \text{Uniform}(-1, 1)$, $Y = X^2$ 。

1. 验证 $\text{cov}(X, Y) = 0$:

$$\text{cov}(X, Y) = \mathbb{E}(X \cdot X^2) - \mathbb{E}(X) \cdot \mathbb{E}(X^2) = \mathbb{E}(X^3) - 0 \cdot \mathbb{E}(X^2).$$

由于 X 对称分布 ($\text{Uniform}(-1, 1)$ 对称于 0), $\mathbb{E}(X^3) = \int_{-1}^1 x^3 \cdot \frac{1}{2} dx = 0$ (奇函数在对称区间积分为零)。

故 $\text{cov}(X, Y) = 0$ 。

2. 验证 X 与 Y 不独立:

给定 $X = 0.5$, 则 $Y = 0.25$ 是确定值。给定 $X = -0.5$, 则 $Y = 0.25$ 也是确定值。但 Y 的取值完全由 X 决定——知道 X 就完全知道 Y , 这说明两者不独立。

更精确地, $\mathbb{P}(Y > 0.5) \neq \mathbb{P}(Y > 0.5 | X > 0)$, 因为 $Y = X^2$ 。

结论：不相关只说明没有线性关系，但不排除非线性依赖。在这个例子中, Y 是 X 的二次函数，它们之间存在明确的函数关系（非线性），但协方差为零。

9.11. 相关系数范围推导. 背景：相关系数满足 $-1 \leq \rho \leq 1$, 这一性质源自 Cauchy-Schwarz 不等式。

目标：严格证明 $|\rho| \leq 1$ 。

已知条件：

$$\rho = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)}\sqrt{\text{var}(X_2)}} = \frac{\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]}{\sigma_1 \sigma_2}.$$

推导步骤：

1. 考虑随机变量 $Y = (X_1 - \mu_1) - t(X_2 - \mu_2)$, 其中 $t \in \mathbb{R}$ 待定。

2. 由方差的非负性:

$$0 \leq \text{var}(Y) = \mathbb{E}(Y^2) = \sigma_1^2 - 2t\text{cov}(X_1, X_2) + t^2\sigma_2^2.$$

3. 将 $\text{cov}(X_1, X_2) = \rho\sigma_1\sigma_2$ 代入:

$$0 \leq \sigma_1^2 - 2t\rho\sigma_1\sigma_2 + t^2\sigma_2^2.$$

4. 这是关于 t 的二次不等式，要使对所有 t 成立，判别式必须 ≤ 0 :

$$(2\rho\sigma_1\sigma_2)^2 - 4\sigma_1^2\sigma_2^2 \leq 0.$$

5. 化简得

$$4\rho^2\sigma_1^2\sigma_2^2 \leq 4\sigma_1^2\sigma_2^2 \implies \rho^2 \leq 1.$$

6. 即 $-1 \leq \rho \leq 1$ 。

等号条件： $|\rho| = 1$ 当且仅当存在 t 使 $\text{var}(Y) = 0$ ，即 Y 几乎处处为零： $X_1 - \mu_1 = t(X_2 - \mu_2)$ ，此时 X_1 与 X_2 有完美线性关系。

9.12. 二元正态条件分布推导. 背景：二元正态分布的条件分布仍是正态的，这是其最重要的性质之一。

已知条件： $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，联合 pdf 为

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{Q(x_1, x_2)}{2(1-\rho^2)}\right\},$$

其中 $Q = \frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2}$ 。

目标：求条件分布 $X_2 | X_1 = x_1$ 。

推导步骤：

1. 条件分布的 pdf 为

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)} = \frac{f(x_1, x_2)}{\frac{1}{\sigma_1}\phi\left(\frac{x_1 - \mu_1}{\sigma_1}\right)}.$$

2. 将 Q 整理成关于 x_2 的二次函数：

$$Q = \frac{1}{1-\rho^2} \left[\left(\frac{x_2 - \mu_2}{\sigma_2} - \rho\frac{x_1 - \mu_1}{\sigma_1} \right)^2 + (1-\rho^2)\frac{(x_1 - \mu_1)^2}{\sigma_1^2} \right].$$

3. 因此

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)} \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho\frac{x_1 - \mu_1}{\sigma_1} \right)^2\right\} \cdot \exp\left\{-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2}\right\}.$$

4. 除以边缘密度 $f_{X_1}(x_1) = \frac{1}{\sigma_1}\phi\left(\frac{x_1 - \mu_1}{\sigma_1}\right)$ ，消去与 x_2 无关的因子：

$$f_{X_2|X_1}(x_2 | x_1) = \frac{1}{\sigma_2\sqrt{2\pi(1-\rho^2)}} \exp\left\{-\frac{1}{2(1-\rho^2)} \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho\frac{x_1 - \mu_1}{\sigma_1} \right)^2\right\}.$$

5. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1-\rho^2)$ 的正态分布密度。

6. 故

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1-\rho^2)\right).$$

最优线性预测：条件均值 $\mathbb{E}(X_2 | x_1) = \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 是 x_1 的线性函数，它在均方误差意义下是 X_2 的最优预测。

9.13. 回归理论的简要推导. 背景：回归分析的核心是找到使预测误差最小的线性预测器。

目标：在所有线性预测 $\hat{X}_2 = \alpha + \beta X_1$ 中，找到均方误差最小的预测。

推导步骤：

1. 均方预测误差 (MSE) 为

$$\mathbb{E}[(X_2 - \alpha - \beta X_1)^2] = \mathbb{E}(X_2^2) + \alpha^2 + \beta^2\mathbb{E}(X_1^2) - 2\alpha\mathbb{E}(X_2) - 2\beta\mathbb{E}(X_1X_2) + 2\alpha\beta\mathbb{E}(X_1).$$

2. 对 α 求偏导并设为零：

$$\frac{\partial \text{MSE}}{\partial \alpha} = 2\alpha + 2\beta\mathbb{E}(X_1) - 2\mathbb{E}(X_2) = 0 \implies \alpha^* = \mathbb{E}(X_2) - \beta\mathbb{E}(X_1).$$

3. 对 β 求偏导并设为零：

$$\frac{\partial \text{MSE}}{\partial \beta} = 2\beta\mathbb{E}(X_1^2) + 2\alpha\mathbb{E}(X_1) - 2\mathbb{E}(X_1X_2) = 0.$$

4. 代入 α^* ：

$$\beta^*\mathbb{E}(X_1^2) + [\mathbb{E}(X_2) - \beta^*\mathbb{E}(X_1)]\mathbb{E}(X_1) - \mathbb{E}(X_1X_2) = 0.$$

5. 整理得

$$\beta^* = \frac{\mathbb{E}(X_1X_2) - \mathbb{E}(X_1)\mathbb{E}(X_2)}{\mathbb{E}(X_1^2) - [\mathbb{E}(X_1)]^2} = \frac{\text{cov}(X_1, X_2)}{\text{var}(X_1)} = \rho \frac{\sigma_2}{\sigma_1}.$$

6. 最优线性预测为

$$\hat{X}_2^* = \mathbb{E}(X_2) + \rho \frac{\sigma_2}{\sigma_1} (X_1 - \mathbb{E}(X_1)).$$

7. 对二元正态分布，这就是条件均值。

最小二乘法：在样本情形，用样本矩代替总体矩，得到 $\hat{\beta} = \hat{\rho} \frac{s_2}{s_1}$ ，其中 s_1^2, s_2^2 是样本方差， $\hat{\rho}$ 是样本相关系数。

9.14. 两两独立不推出相互独立反例。背景：对于多个随机变量，两两独立不一定推出相互独立，这是一个经典反例。

目标：构造三个事件 A, B, C ，使得两两独立但三者不相互独立。

推导步骤：

考虑抛两枚公平硬币的样本空间 $\{HH, HT, TH, TT\}$ ，每个结果等概率 $1/4$ 。

定义事件：

- A ：第一枚硬币正面 (HH 或 HT)
- B ：第二枚硬币正面 (HH 或 TH)
- C ：两面相同 (HH 或 TT)

1. 验证两两独立：

$$\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}.$$

$$\mathbb{P}(A \cap B) = \mathbb{P}(HH) = \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(B) = \frac{1}{2} \cdot \frac{1}{2}.$$

同理 $\mathbb{P}(A \cap C) = \mathbb{P}(B \cap C) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2}$ 。故 A, B, C 两两独立。

2. 验证三者不相互独立：

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(HH) = \frac{1}{4}.$$

但 $\mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8} \neq \frac{1}{4}$ 。

3. 不独立性体现：给定 A 和 B 都发生（即两面都是正面），则 C 必然发生（两面相同），即

$$\mathbb{P}(C \mid A \cap B) = 1 \neq \mathbb{P}(C) = \frac{1}{2}.$$

结论：两两独立只保证任意两个变量之间的依赖关系被消除，但不能保证多个变量之间的整体依赖结构。这个反例提醒我们，在处理多元随机变量时需要小心。

9.15. 独立随机变量线性组合的 mgf 推导. 背景：若 $X_1, \dots, X_n$ 相互独立， $T = \sum_{i=1}^n k_i X_i$ ，则 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标：推导独立随机变量线性组合的矩母函数。

推导步骤：

1. 由 mgf 的定义：

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[e^{t \sum_{i=1}^n k_i X_i}\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立， $e^{tk_1 X_1}, \dots, e^{tk_n X_n}$ 也相互独立。

3. 对独立随机变量的乘积取期望，等于各自期望的乘积：

$$M_T(t) = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_{X_i}(k_i t).$$

特别情形：若 $X_1, \dots, X_n$ iid，则 $M_T(t) = [M_X(t)]^n$ 。

例如，若 $X_i \sim N(\mu, \sigma^2)$ ， $M_X(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ ，则

$$M_{\bar{X}}(t) = M_X(t/n)^n = \exp\left\{n \left(\mu \frac{t}{n} + \frac{1}{2}\sigma^2 \frac{t^2}{n^2}\right)\right\} = \exp\left\{\mu t + \frac{1}{2} \frac{\sigma^2}{n} t^2\right\},$$

这正是 $N(\mu, \sigma^2/n)$ 的 mgf。

9.16. 中心极限定理概述. 背景：中心极限定理 (CLT) 是概率论和统计学中最重要的结果之一。

已知条件：

- $X_1, \dots, X_n$ iid (独立同分布)
- $\mathbb{E}X_i = \mu$, $\text{var}(X_i) = \sigma^2 < \infty$
- $\bar{X} = n^{-1} \sum X_i$

目标：描述 $\bar{X}$ (或标准化后的 $\bar{X}$) 的极限分布。

推导思路：

1. 考虑标准化和 $Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$ 。
2. 由独立随机变量和的 mgf 性质， Z_n 的 mgf 为

$$M_{Z_n}(t) = \left[M_X\left(\frac{t}{\sqrt{n}\sigma}\right) \right]^n e^{-\sqrt{n}\mu t/\sigma}.$$

3. 对 $M_X(t/\sqrt{n}\sigma)$ 在 $t = 0$ 处 Taylor 展开：

$$M_X\left(\frac{t}{\sqrt{n}\sigma}\right) = 1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

4. 代入得

$$M_{Z_n}(t) = \left(1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n e^{-\sqrt{n}\mu t/\sigma} \xrightarrow{n \rightarrow \infty} e^{t^2/2}.$$

5. 标准正态分布 $\mathcal{N}(0, 1)$ 的 mgf 正是 $e^{t^2/2}$ 。

6. 由 mgf 的唯一性（若随机变量的 mgf 收敛到某个分布的 mgf，则该随机变量的分布收敛到该分布），得

$$Z_n \Rightarrow \mathcal{N}(0, 1), \quad \text{即} \quad \sqrt{n}(\bar{X} - \mu)/\sigma \Rightarrow \mathcal{N}(0, 1).$$

核心洞察：无论 X_i 原来是什么分布（只要方差有限），其样本均值经适当标准化后都收敛到标准正态分布。这使得正态分布在统计推断中具有核心地位。

CHAPTER 3

Special Distributions

Chapter 3 Overview

在前两章中，我们建立了描述单一和多元随机变量的数学框架。现在我们面临一个根本性问题：

哪些概率分布值得我们特别关注？为什么？

答案蕴藏在统计学本身的核心之中。某些分布在自然界、实验中和理论研究里反复出现——这不是任意的选择，而是来自简单、重复模式的自然涌现：独立试验中成功次数的计数、等待时间的测量、测量误差的建模，以及描述平均值的行为。

本章介绍统计学理论及实践中最重要的分布族。我们将发现这些分布如何从基本原理中产生，欣赏它们之间错综复杂的联系，理解每个分布在统计工作中的不可替代性。

本章路线图：

- Bernoulli $\rightarrow$ Binomial (二项分布) $\rightarrow$ Negative Binomial/Geometric (负二项/几何分布) $\rightarrow$ Multinomial (多项分布) $\rightarrow$ Hypergeometric (超几何分布)
- Poisson (作为二项分布的极限形式)
- Gamma (Gamma 分布) $\rightarrow \chi^2$ (卡方分布) $\rightarrow$ Beta (BETA 分布)
- Normal (正态分布) $\rightarrow$ Bivariate Normal (二元正态分布) $\rightarrow$ Multivariate Normal (多元正态分布)
- t 和 F 分布 (由正态理论导出)

这些分布之间的关系并非偶然——它们反映了将贯穿整个统计推断的深层数学结构。

1. 3.1 二项分布及其相关分布

1.1. 为什么研究二项分布？ 考虑以下场景：抛掷一枚硬币 100 次，出现多少次正面？一袋 1000 件产品中有多少件次品？接受实验治疗后有多少患者康复？

这些问题共享一个共同的数学结构：我们进行 n 次独立试验，每次试验只有两个可能结果（成功或失败），然后计算成功出现的总次数。这个“计数问题”遍布统计学，而二项分布正是其天然数学模型。

二项分布起源于 18 世纪对赌博游戏的研究。Jakob Bernoulli (1713 年) 为 Bernoulli 试验 (Bernoulli trial) 建立了大数定律 (弱律)，奠定了理论基础。随后 Abraham de Moivre 和 Pierre-Simon Laplace 发展出了逼近方法，最终导致了中心极限定理——这是数学最卓越的成果之一。

1.2. Bernoulli 试验 (Bernoulli Trial). Bernoulli 试验是最简单的随机实验：结果只有两个互斥且穷举的可能性——成功或失败。

设随机变量 X 表示结果：

$$X(\text{成功}) = 1, \quad X(\text{失败}) = 0.$$

概率质量函数 (pmf) 为：

$$p(x) = p^x(1-p)^{1-x}, \quad x = 0, 1, \quad (9)$$

其中 p 是成功概率。

Bernoulli 分布的均值和方差为：

$$\mathbb{E}X = p, \quad \text{var}(X) = p(1-p). \quad (10)$$

EXAMPLE 3.1 (抛硬币). 如果抛一枚均匀硬币 ($p = 1/2$), 则 $\mathbb{E}X = 1/2$, $\text{var}(X) = 1/4$ 。标准差为 0.5, 意味着典型偏差约为半次硬币翻转。

为什么 Bernoulli 分布如此基础? 它是最简单但非平凡的随机变量——既不是确定性常数, 也不是均匀分布。它捕捉了“是/否”决策不确定性的本质。每个二元结果的实验都可以建模为 Bernoulli 试验。

1.3. 二项分布 (Binomial Distribution). 现在我们问： n 次独立 Bernoulli 试验中成功次数的分布是什么？

设 X_i 是第 i 次试验的 Bernoulli 变量, 我们关心 $X = \sum_{i=1}^n X_i$ 。

恰好有 x 次成功意味着：我们在 n 个位置中选择 x 个作为成功 (共有 $\binom{n}{x}$ 种方式), 其余 $n-x$ 个位置是失败。每种排列的概率为 $p^x(1-p)^{n-x}$ 。

因此, pmf 为：

$$p(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n. \quad (11)$$

记作 $X \sim \text{Bin}(n, p)$, 称 n 和 p 为二项分布的参数。

验证 $p(x)$ 之和为 1: 由二项式定理,

$$\sum_{x=0}^n \binom{n}{x} p^x (1-p)^{n-x} = [(1-p) + p]^n = 1^n = 1.$$

EXAMPLE 3.2 (骰子问题). 掷一枚均匀六面骰子 3 次, 恰好出现 2 次六点的概率是多少？

设 X 为六点出现的次数, 则 $X \sim \text{Bin}(n=3, p=1/6)$:

$$\mathbb{P}(X=2) = \binom{3}{2} \left(\frac{1}{6}\right)^2 \left(\frac{5}{6}\right)^1 = 3 \times \frac{1}{36} \times \frac{5}{6} = \frac{15}{216} \approx 0.06944.$$

在 R 中计算: `dbinom(2, 3, 1/6)`。

矩母函数 (mgf): 二项分布的 mgf 为:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x} = [(1-p) + pe^t]^n. \quad (12)$$

由此可得均值和方差:¹

$$\mathbb{E}X = M'(0) = np, \quad \text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p). \quad (13)$$

EXAMPLE 3.3 (电池寿命). 假设一枚电池有概率 $p = 0.95$ 可以使用至少 100 小时。一包 $n = 10$ 枚电池中, 预期有 $np = 9.5$ 枚可以使用至少 100 小时, 方差为 $np(1-p) = 0.475$ 。

至少 8 枚电池可用的概率为:

$$\mathbb{P}(X \geq 8) = \sum_{x=8}^{10} \binom{10}{x} (0.95)^x (0.05)^{10-x}.$$

在 R 中: $1 - \text{pbinom}(7, 10, 0.95) = 0.9885$ 。

二项分布的可加性. 二项分布最重要的性质之一是在相同成功概率下的可加性。

THEOREM 3.1 (二项分布的可加性). 若 $X_1 \sim \text{Bin}(n_1, p)$ 和 $X_2 \sim \text{Bin}(n_2, p)$ 独立, 则

$$X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p).$$

直观理解: 想象两堆独立的硬币翻转。第一堆 n_1 枚硬币产生 X_1 个正面, 第二堆 n_2 枚硬币产生 X_2 个正面。合并后, 我们有 $n_1 + n_2$ 枚硬币, 总正面数为 $X_1 + X_2$ 。这仍然服从二项分布, 样本量是合并后的总量。²

这种可加性反映了计数的本质: 如果我们在两批试验 (每批具有相同成功概率) 中计数成功次数, 总数就是简单求和。

EXAMPLE 3.4. $\text{Bin}(n, p)$ 分布的众数 (最可能取值) 为 $\lfloor (n+1)p \rfloor$ 。这很直观: 成功次数的期望值是 np , 众数应该接近这个值。

1.4. 负二项分布与几何分布. 一个不同的问题: 不是计数 n 次试验中的成功次数, 而是问: 需要多少次试验才能实现第 r 次成功?

这个问题引出了负二项分布。设 Y 为第 r 次成功前的失败次数, 则试验总次数为 $Y + r$ 。

恰好有 y 次失败发生在第 r 次成功之前意味着: 前 $y+r-1$ 次试验恰好包含 $r-1$ 次成功和 y 次失败 (任意顺序), 而最后一次 (第 $y+r$ 次) 必须是成功。这样的序列数为 $\binom{y+r-1}{r-1}$:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots \quad (14)$$

¹推导见附录 section 7.1。

²使用 mgf 的证明见附录 section 7.2。

记作 $Y \sim \text{NB}(r, p)$ 。该分布的名称来源于 $p_Y(y)$ 是 $p^r[1 - (1 - p)]^{-r}$ 展开式中的通项。³

当 $r = 1$ 时, 得到**几何分布 (geometric distribution)**:

$$p_Y(y) = p(1 - p)^y, \quad y = 0, 1, 2, \dots \quad (15)$$

从 Bernoulli 试验的角度看, Y 是直到第一次成功前的失败次数。

EXAMPLE 3.5 (血型问题). 设一个人拥有 B 型血的概率为 $p = 0.12$ 。抽取患者直到获得 10 个 B 型血的人。最多需要检测 30 个患者的概率是多少?

设 $Y \sim \text{NB}(r = 10, p = 0.12)$ 。我们需要 $\mathbb{P}(Y \leq 20)$ (因为第 10 次成功发生在试验 $y + r = y + 10$, $y \leq 20$ 意味着最多 30 次试验)。

在 R 中: `pnbinom(20, 10, 0.12) = 0.0019`。概率相当小!

EXAMPLE 3.6 (首次成功等待时间). 对于 $p = 0.12$ 的几何分布, 必须恰好检测 11 个患者才能找到第一个 B 型血的人的概率为:

$$\mathbb{P}(Y = 11) = (0.12)(0.88)^{10} \approx 0.0294.$$

在 R 中: `dgeom(11, 0.12)`。

EXAMPLE 3.7 (几何分布的无记忆性). 几何分布具有独特的**无记忆性 (memorylessness property)**:

$$\mathbb{P}(Y \geq k + j \mid Y \geq k) = \mathbb{P}(Y \geq j), \quad k, j \geq 0. \quad (16)$$

这是什么意思? 如果你已经失败了 k 次, 那么距离第一次成功的剩余等待时间与开始时完全相同。过去的失败不会改变未来的期望。这个性质刻画了 $\{0, 1, 2, \dots\}$ 上所有离散分布中几何分布的独特地位。⁴

几何分布 (支撑集为 $\{0, 1, 2, \dots\}$) 的均值和方差为:⁵

$$\mathbb{E}Y = \frac{1 - p}{p}, \quad \text{var}(Y) = \frac{1 - p}{p^2}. \quad (17)$$

EXAMPLE 3.8. 负二项分布的 *mgf* 为:

$$M(t) = \frac{p^r}{[1 - (1 - p)e^t]^r}, \quad t < -\log(1 - p).$$

这可以用负二项级数推导。⁶

³推导见附录 section 7.3。

⁴证明见附录 section 7.4。

⁵推导见附录 section 7.5。

⁶推导见附录 section 7.6。

1.5. 多项分布 (Multinomial Distribution). 二项分布自然推广到 k 个类别。每次试验恰好发生 k 个互斥类别中的一个。

设类别为 $C_1, C_2, \dots, C_k$, 概率分别为 $p_1, p_2, \dots, p_k$ (其中 $\sum_{i=1}^k p_i = 1$)。独立重复实验 n 次。设 X_i 为类别 i 出现的次数。

$(X_1, X_2, \dots, X_k)$ 的联合 pmf 为:

$$\mathbb{P}(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! x_2! \dots x_k!} p_1^{x_1} \dots p_k^{x_k}, \quad (18)$$

其中 $\sum_{i=1}^k x_i = n$ 。

称 $(X_1, \dots, X_k)$ 服从参数为 n 和 $p_1, \dots, p_k$ 的**多项分布**。二项分布是 $k = 2$ 的特殊情形。⁷

性质: 对每个 i , X_i 的边缘分布为 $\text{Bin}(n, p_i)$ 。 X_i 和 X_j ($i \neq j$) 之间的协方差为:

$$\text{cov}(X_i, X_j) = -np_i p_j. \quad (19)$$

EXAMPLE 3.9 (掷骰子). 掷一枚均匀六面骰子 $n = 30$ 次。恰好得到 5 个一点、4 个两点、6 个三点、3 个四点、7 个五点和 5 个六点的概率是多少?

这里 $k = 6$, 对所有 i 有 $p_i = 1/6$ 。概率为:

$$\frac{30!}{5!4!6!3!7!5!} \left(\frac{1}{6}\right)^{30} \approx 0.0028.$$

EXAMPLE 3.10. X_i 和 X_j 的相关系数为:

$$\rho_{ij} = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}}.$$

这种负相关很直观: 如果我们观察到类别 i 出现更多, 那么剩余给类别 j 的试验次数就更少。

1.6. 超几何分布 (Hypergeometric Distribution). **核心问题:** 不放回抽样时成功次数的分布是什么?

考虑一批 N 件产品, 其中 D 件次品。我们不放回地抽取 n 件, X 为样本中次品的个数。与二项情形不同, 连续抽取不独立, 因为抽样过程中组成成分在变化。

pmf 为:

$$p(x) = \frac{\binom{N-D}{n-x} \binom{D}{x}}{\binom{N}{n}}, \quad x = 0, 1, \dots, \min(n, D). \quad (20)$$

记作 $X \sim \text{Hypergeometric}(N, D, n)$ 。

均值和方差:

$$\mathbb{E}X = n \frac{D}{N}, \quad \text{var}(X) = n \frac{D}{N} \left(1 - \frac{D}{N}\right) \frac{N-n}{N-1}. \quad (21)$$

因子 $\frac{N-n}{N-1}$ 是**有限总体校正因子 (finite population correction factor)**。当 $N \gg n$ 时, 它趋近于 1, 超几何分布近似于 $p = D/N$ 的二项分布。⁸

⁷推导见附录 section 7.7。

⁸推导见附录 section 7.8。

这个近似反映了一个重要原理：当样本量相对于总体较小时，不放回抽样几乎等同于放回抽样。

EXAMPLE 3.11 (抽牌). 从一副 52 张牌中不放回地抽取 2 张。恰好得到 1 张 A 的概率是多少？

这里 $N = 52$, $D = 4$ (A 的数量), $n = 2$ 。我们需要 $\mathbb{P}(X = 1)$:

$$\mathbb{P}(X = 1) = \frac{\binom{48}{1}\binom{4}{1}}{\binom{52}{2}} = \frac{48 \times 4}{1326} \approx 0.1448.$$

作为对比，放回抽样（二项分布）的概率为：

$$\binom{2}{1} \left(\frac{4}{52}\right) \left(\frac{48}{52}\right) \approx 0.1412.$$

概率非常接近！

2. 3.2 Poisson 分布

在自然界和社会中存在一类显著的现象：**在固定时间或空间区间内发生的事件次数**。例子包括：

- 每小时到达银行的客户数
- 手稿每页的印刷错误数
- 一个地区每年的地震次数
- 放射性物质的衰变事件数
- 每周一个路口的事故数

这些现象有一个共同特征：**每个单独事件的概率很小，但机会数量很大**。这正是 Poisson 分布出现的领域。

历史注记：Poisson 分布由 Siméon Denis Poisson 于 1837 年引入，最初用于分析法国法院判决数据——法官在给定时间段内做出一定数量判决的概率。Poisson 当时并不知道，他的分布会成为整个统计学中最广泛使用的工具之一。

2.1. 定义与性质. 若离散随机变量 X 的 pmf 为：

$$p(x) = \mathbb{P}(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots \quad (22)$$

则称 X 服从参数为 $\lambda > 0$ 的 Poisson 分布。

记作 $X \sim \text{Poisson}(\lambda)$ 。

验证： 因为 $e^\lambda = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$,

$$\sum_{x=0}^{\infty} p(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} \cdot e^\lambda = 1. \quad (3.2.1)$$

参数 λ 有一个优美的解释：它是分布的均值和方差：

$$\mathbb{E}X = \lambda, \quad \text{var}(X) = \lambda. \quad (23)$$

9

这里有一个令人惊讶且有用的性质：均值等于方差！这是 Poisson 分布的标志特征，可用于检验数据是否可能服从 Poisson 模型。

EXAMPLE 3.12 (汽车事故). 设 X 为一个繁忙路口每周的汽车事故数。假设 $X \sim \text{Poisson}(\lambda = 2)$ 。

则 $\mathbb{E}X = 2$, $\text{std}(X) = \sqrt{2} \approx 1.41$ 。

- $\mathbb{P}(X \geq 1) = 1 - \mathbb{P}(X = 0) = 1 - e^{-2} \approx 0.8647$
- $\mathbb{P}(3 \leq X \leq 8) = \mathbb{P}(X \leq 8) - \mathbb{P}(X \leq 2) \approx 0.3231$

在 R 中: $1 - \text{ppois}(0, 2)$ 和 $\text{ppois}(8, 2) - \text{ppois}(2, 2)$ 。

EXAMPLE 3.13 (巧克力碎片). 一块饼干中巧克力碎片的数量服从 Poisson 分布。我们希望至少含有 2 片碎片的概率大于 0.99。求最小的均值 λ 。

我们需要:

$$\mathbb{P}(X \geq 2) = 1 - \mathbb{P}(X = 0) - \mathbb{P}(X = 1) = 1 - e^{-\lambda} - \lambda e^{-\lambda} > 0.99.$$

求解: $e^{-\lambda}(1 + \lambda) < 0.01$ 。通过试错, $\lambda \approx 6$ 有效, 因为 $e^{-6}(7) \approx 0.007$ 。

所以平均至少需要 6 片!

2.2. Poisson 分布对二项分布的近似. 概率论中最重要的极限定理之一, 连接了二项分布和 Poisson 分布。

THEOREM 3.2 (Poisson 分布对二项分布的近似). 若 $X_n \sim \text{Bin}(n, p_n)$, 且当 $n \rightarrow \infty$ 时 $np_n \rightarrow \lambda$, 则对任意固定的 k :

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

即 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

直观理解: 当 n 很大且 p 很小时, 二项分布的行为几乎与 Poisson 分布完全相同。关键洞见是: 在极限中只有 $\lambda = np$ (均值) 起作用。¹⁰

EXAMPLE 3.14 (印刷错误). 一份手稿有 500 页, 每页约 300 个单词。一个单词拼写错误的概率为 $p = 1/10,000$, 则每页错误数服从 $\text{Bin}(300, 1/10000) \approx \text{Poisson}(0.03)$ 。

使用 Poisson 模型:

$$\mathbb{P}(\text{至少 1 个错误}) \approx 1 - e^{-0.03} \approx 0.03.$$

这就解释了为什么 Poisson 分布常用于稀有事件计数!

EXAMPLE 3.15. 若 $X_1 \sim \text{Poisson}(\lambda_1)$ 和 $X_2 \sim \text{Poisson}(\lambda_2)$ 独立, 则 $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$ 。这种可加性反映了独立 Poisson 过程 (Poisson process) 的叠加性质。

⁹推导见附录 section 7.9。

¹⁰证明见附录 section 7.10。

3. 3.3 Gamma、 χ^2 与 Beta 分布

这三种分布构成了连续统计推断的支柱。理解它们之间的关系对于掌握统计学的数学基础至关重要。

3.1. Gamma 函数. Gamma 函数架起了阶乘与积分之间的桥梁——这是数学中最美的恒等式之一。

DEFINITION 3.1 (Gamma 函数). 对于 $\alpha > 0$, Gamma 函数定义为:

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx. \quad (3.3.1)$$

关键性质 (递归公式):

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha). \quad (3.3.2)$$

这来自分部积分: ¹¹:

$$\Gamma(\alpha + 1) = \int_0^{\infty} x^{\alpha} e^{-x} dx = [-x^{\alpha} e^{-x}]_0^{\infty} + \alpha \int_0^{\infty} x^{\alpha-1} e^{-x} dx = \alpha \Gamma(\alpha).$$

对于正整数 n :

$$\Gamma(n) = (n-1)!.$$

Gamma 函数还与 Beta 函数有联系:

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} = \int_0^1 t^{\alpha-1}(1-t)^{\beta-1} dt. \quad (3.3.3)$$

EXAMPLE 3.16 (Gamma 函数的值). • $\Gamma(1) = 0! = 1$

- $\Gamma(2) = 1! = 1$
- $\Gamma(3) = 2! = 2$
- $\Gamma(4) = 3! = 6$
- $\Gamma(\frac{1}{2}) = \sqrt{\pi}$ (一个惊人的结果!)

3.2. Gamma 分布. Gamma 分布是 $(0, \infty)$ 上的连续分布, 它统一了指数分布和卡方分布。

DEFINITION 3.2 (Gamma 分布). 若连续随机变量 X 的 pdf 为:

$$f(x) = \begin{cases} \frac{1}{\Gamma(\alpha)\beta^{\alpha}} x^{\alpha-1} e^{-x/\beta} & x > 0 \\ 0 & \text{elsewhere.} \end{cases} \quad (3.3.4)$$

则称 X 服从参数为 $\alpha > 0$ (形状参数) 和 $\beta > 0$ (尺度参数) 的 Gamma 分布, 记作 $X \sim \Gamma(\alpha, \beta)$ 。

¹¹推导见附录 section 7.11。

验证 $f(x)$ 积分等于 1: 使用代换 $z = x/\beta$, $dz = dx/\beta$:

$$\int_0^\infty \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)} \int_0^\infty z^{\alpha-1} e^{-z} dz = 1.$$

参数的含义:

- α (形状参数, shape): 控制分布的形状。较大的 α 意味着更多质量集中在均值附近。
- β (尺度参数, scale): 控制分散程度。较大的 β 意味着在较大值处有更多概率。

特殊情形:

- $\Gamma(1, \beta) = \text{Exp}(1/\beta)$ (指数分布, exponential distribution)
- $\Gamma(n/2, 2) = \chi^2(n)$ (自由度为 n 的卡方分布, chi-square distribution)

矩母函数:

$$M(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}. \quad (3.3.5)$$

由此可得均值和方差: ¹²

$$\mathbb{E}X = \alpha\beta, \quad \text{var}(X) = \alpha\beta^2. \quad (3.3.6)$$

EXAMPLE 3.17 (电池寿命). 设 X 为某种电池在极寒条件下的寿命 (小时)。假设 $X \sim \Gamma(5, 4)$ 。

则:

- 平均寿命: $\mathbb{E}X = 5 \times 4 = 20$ 小时
- 标准差: $\sqrt{5 \times 16} = 8.94$ 小时
- 至少使用 50 小时的概率: $1 - F(50) = 0.0053$ (在 R 中: `1 - pgamma(50, shape=5, scale=4)`)
- 中位寿命: $F^{-1}(0.5) = 18.68$ 小时 (在 R 中: `qgamma(0.5, shape=5, scale=4)`)

EXAMPLE 3.18. 若 $X_1 \sim \Gamma(\alpha_1, \beta)$ 和 $X_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。这种可加性反映了 Gamma 分布等待时间的自然结构。 ¹³

EXAMPLE 3.19. Gamma 分布的危险函数 (hazard function) 为 $r(x) = \frac{x^{\alpha-1}e^{-x/\beta}}{\beta^\alpha \Gamma(\alpha)(1-F(x))}$ 。对于指数分布 ($\alpha = 1$), $r(x) = 1/\beta$ 是常数; 对于 $\alpha > 1$, $r(x)$ 递增; 对于 $\alpha < 1$, $r(x)$ 递减。

3.3. χ^2 分布. 卡方分布在统计学中处于核心地位, 它自然出现在涉及方差和平方正态变量和的问题中。

DEFINITION 3.3 (卡方分布). 设 $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid, 则

$$X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n). \quad (3.3.7)$$

参数 n 称为自由度 (degrees of freedom) 数目。

¹²推导见附录 section 7.12。

¹³使用 mgf 的证明见附录 section 7.13。

χ^2 分布是 $\Gamma(n/2, 2)$ 的特殊情形：如果 $X \sim \chi^2(n)$ ，则 $X \sim \Gamma(n/2, 2)$ 。

均值和方差：

$$\mathbb{E}X = n, \quad \text{var}(X) = 2n. \quad (3.3.8)$$

EXAMPLE 3.20. 若 $X_1 \sim \chi^2(m)$ 和 $X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$ 。这直接来自 *Gamma* 分布的可加性。

为什么它很重要？ 样本方差的抽样分布与 χ^2 分布密切相关，这使它成为方差估计和假设检验的基础。

EXAMPLE 3.21 (样本方差分布). 对于 *iid* $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ ，样本方差 S^2 满足：

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1). \quad (3.3.9)$$

这个基本结果告诉我们：偏离均值的缩放平方和服从卡方分布。它是方差置信区间和 ANOVA 的基础。

EXAMPLE 3.22 (卡方分位数). 假设 $X \sim \chi^2(10)$ 。在 *R* 中：

- 均值： $\mathbb{E}X = 10$ ，标准差： $\sqrt{20} = 4.47$
- 四分位数： $qchisq(c(0.25, 0.5, 0.75), 10) = (6.74, 9.34, 12.55)$

3.4. Beta 分布. Beta 分布是区间 $(0, 1)$ 上的连续分布，特别适用于建模概率和比例。

DEFINITION 3.4 (Beta 分布). 若 X 的 *pdf* 为：

$$f(x) = \begin{cases} \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} & 0 < x < 1 \\ 0 & \text{elsewhere,} \end{cases} \quad (3.3.10)$$

其中 $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ ，则 $X \sim \text{Beta}(\alpha, \beta)$ 。

Beta 函数 $B(\alpha, \beta)$ 使分布归一化，确保 $\int_0^1 f(x)dx = 1$ 。

均值和方差：

$$\mathbb{E}X = \frac{\alpha}{\alpha + \beta}, \quad \text{var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}. \quad (3.3.11)$$

14

特殊情形：

- $\text{Beta}(1, 1) = \text{Uniform}(0, 1)$ (均匀分布)
- $\text{Beta}(\alpha, 1) = \text{Power}(1/\alpha)$ ($(0, 1)$ 上的幂分布)

EXAMPLE 3.23 (Beta 分布的形状). *Beta* 分布提供了丰富多样的形状：

- $\alpha = \beta = 1$ ：均匀分布
- $\alpha = \beta > 1$ ：对称、峰形

¹⁴推导见附录 section 7.14。

- $\alpha > \beta$: 右偏
- $\alpha < \beta$: 左偏

EXAMPLE 3.24. 在贝叶斯统计中, 当我们用 *Beta* 分布作为二项分布参数 p 的先验时, 后验分布仍然是 *Beta* 分布。这称为**共轭先验** (*conjugate prior*) 关系。*Beta*-二项模型是贝叶斯分析中最重要的共轭对之一。¹⁵

Beta 分布的灵活性——通过不同的 α, β 值在 $(0, 1)$ 上捕捉各种形状——使其成为建模不确定概率的理想选择。

4. 3.4 正态分布 (Normal Distribution)

在所有概率分布中, **正态分布** (normal distribution) 占据至高无上的地位。它构成了统计推断、计量经济学、信号处理及许多其他领域的基石。

正态分布的重要性源于三个关键事实:

- (1) **中心极限定理** (Central Limit Theorem): 许多独立小因素的和近似正态分布
- (2) **数学优美性** (Mathematical elegance): 正态变量的线性组合仍然是正态的
- (3) **可解释的参数** (Interpretable parameters): 均值和方差都有清晰、直观的含义

历史注记: 正态分布由 Carl Friedrich Gauss 于 1809 年在研究测量误差时引入。虽然 Laplace 早些时候讨论过误差分布, 但 Gauss 的工作巩固了正态分布在统计学中的核心地位。这就是为什么我们经常称它为“高斯分布 (Gaussian distribution)”。

4.1. 定义与基本性质.

DEFINITION 3.5 (正态分布). 若随机变量 X 的 pdf 为:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}, \quad -\infty < x < \infty. \quad (3.4.1)$$

则称 X 服从正态分布, 记作 $X \sim N(\mu, \sigma^2)$, 其中 μ 是均值, σ^2 是方差。

标准正态分布是 $N(0, 1)$, 其 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$, cdf 为 $\Phi(z)$ 。

关键性质: 若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$ 。这种标准化使得任何正态概率计算都可以转化为标准正态计算:

$$\mathbb{P}(X \leq x) = \Phi \left(\frac{x - \mu}{\sigma} \right). \quad (3.4.2)$$

EXAMPLE 3.25 (身高分布). 假设成年男性的身高为 $N(\mu = 70, \sigma^2 = 16)$ (英寸)。则:

- 一个男性超过 6 英尺 (72 英寸) 的概率: $Z = (72 - 70)/4 = 0.5$, 所以 $\mathbb{P}(X > 72) = 1 - \Phi(0.5) \approx 0.3085$

¹⁵共轭先验的讨论见附录 section 7.15。

- 95 分位数: $x_{0.95} = 70 + 4 \cdot \Phi^{-1}(0.95) \approx 76.6$ 英寸
- 在一个标准差内的概率: $\Phi(1) - \Phi(-1) \approx 0.6827$

$N(\mu, \sigma^2)$ 的 mgf 为:

$$M(t) = \exp \left\{ \mu t + \frac{1}{2} \sigma^2 t^2 \right\}, \quad -\infty < t < \infty. \quad (3.4.3)$$

16

由此得 $\mathbb{E}X = \mu$, $\text{var}(X) = \sigma^2$ 。

THEOREM 3.3 (正态变量的线性组合). 若 $X_1 \sim N(\mu_1, \sigma_1^2)$ 和 $X_2 \sim N(\mu_2, \sigma_2^2)$ 独立, 则对任意常数 a, b :

$$aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2). \quad (3.4.4)$$

为什么这个性质重要? 它意味着正态分布在线性变换下闭合——这使它成为线性模型的理论基础。¹⁷

EXAMPLE 3.26. 均值 μ 是**位置参数 (location parameter)**: 改变 μ 只平移整个分布而不改变形状。标准差 σ 是**尺度参数 (scale parameter)**: 改变 σ 拉伸或压缩分布。

EXAMPLE 3.27. 对于任何正态分布:

- $\mathbb{P}(\mu - \sigma < X < \mu + \sigma) \approx 0.6827$
- $\mathbb{P}(\mu - 2\sigma < X < \mu + 2\sigma) \approx 0.9545$
- $\mathbb{P}(\mu - 3\sigma < X < \mu + 3\sigma) \approx 0.9973$

这些有时被称为**经验法则 (empirical rule)** 或 **68-95-99.7 法则**。

EXAMPLE 3.28 (正态平方到卡方). 若 $X \sim N(\mu, \sigma^2)$, 则 $\frac{(X-\mu)^2}{\sigma^2} \sim \chi^2(1)$ 。

这连接了正态分布和卡方分布, 解释了为什么自由度为 n 的卡方分布涉及 n 个平方标准正态的和。

5. 3.5 多元正态分布

正态分布到高维的自然推广, 为建模相关变量提供了强大工具。

5.1. 二元正态分布 (Bivariate Normal Distribution). 二元正态分布不仅仅是一元正态的二维版本——它的相关结构创造了椭圆轮廓的丰富几何学。

DEFINITION 3.6 (二元正态分布). 若 (X_1, X_2) 的联合 pdf 为:

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{Q(x_1, x_2)}{2(1-\rho^2)} \right\}, \quad (3.5.1)$$

¹⁶推导见附录 section 7.16。

¹⁷证明见附录 section 7.17。

其中

$$Q = \frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2},$$

则 (X_1, X_2) 服从二元正态分布, 记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

五个参数有清晰的解释:

- μ_1, μ_2 : 边缘分布的均值
- σ_1^2, σ_2^2 : 边缘分布的方差
- ρ : X_1 和 X_2 之间的相关系数

THEOREM 3.4 (二元正态分布的性质). 若 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则:

- (1) 边缘分布: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) 条件分布: $X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right)$
- (3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ (对正态变量, 不相关等价于独立)
- (4) 任何线性组合 $aX_1 + bX_2$ 服从正态分布

关键洞见: 条件均值是 x_1 的线性函数。这意味着给定一个变量, 对另一个变量的最佳预测也是线性的。斜率 $\rho\sigma_2/\sigma_1$ 告诉我们 X_2 相对于 X_1 每个标准差变化多少 (以标准差计)。

条件方差 $\sigma_2^2(1 - \rho^2)$ 始终小于边缘方差 σ_2^2 ——知道 X_1 降低了对 X_2 的不确定性。当 $|\rho| = 1$ 时, 条件方差为零: X_2 完全由 X_1 决定。

EXAMPLE 3.29 (夫妻身高). 在某人群中, 丈夫身高 $X_1 \sim N(5.8, 0.04)$ 英尺, 妻子身高 $X_2 \sim N(5.3, 0.04)$ 英尺, 相关系数 $\rho = 0.6$ 。

给定丈夫身高为 6.3 英尺, 妻子身高的条件分布为:

$$X_2 | X_1 = 6.3 \sim N\left(5.3 + 0.6 \cdot \frac{0.2}{0.2}(6.3 - 5.8), 0.04(1 - 0.36)\right) = N(5.6, 0.0256).$$

因此预测妻子身高为 5.6 英尺, 标准差为 0.16 英尺。95% 预测区间为 $5.6 \pm 1.96 \times 0.16 = (5.29, 5.91)$ 英尺。

二元正态分布的联合 mgf 为: ¹⁸

$$M(t_1, t_2) = \exp\left\{t_1\mu_1 + t_2\mu_2 + \frac{1}{2}(t_1^2\sigma_1^2 + 2t_1t_2\rho\sigma_1\sigma_2 + t_2^2\sigma_2^2)\right\}. \quad (3.5.2)$$

6. 3.6 t 分布与 F 分布

这两个分布源于一个实际问题: **当总体方差未知时, 我们如何进行推断?**

这个问题处于统计推断的核心: 当我们用样本均值估计总体均值时, 通常不知道真实的方差。 t 和 F 分布使我们能够考虑这种额外的不确定性。

历史注记: William Gosset (笔名“Student”) 于 1908 年在 Guinness 啤酒厂工作时引入了 t 分布。由于雇主禁止员工发表研究, 他以笔名“Student”发表。Fisher 后来为 ANOVA 开发了 F 分布。

¹⁸推导见附录 section 7.18。

6.1. t 分布.

DEFINITION 3.7 (t 分布). 若 $Z \sim N(0, 1)$ 和 $X \sim \chi^2(n)$ 独立, 则

$$T = \frac{Z}{\sqrt{X/n}} \sim t(n). \quad (3.6.1)$$

称 T 服从自由度为 n 的 t 分布。

t 分布的 pdf 为:

$$f(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, \quad -\infty < t < \infty. \quad (3.6.2)$$

19

t 分布的尾部比正态分布更厚, 反映了估计方差时引入的额外不确定性。

均值和方差:

$$\mathbb{E}T = 0 \ (n > 1), \quad \text{var}(T) = \frac{n}{n-2} \ (n > 2). \quad (3.6.3)$$

当 $n = 1$ 时, 得到柯西分布——一种“危险”的分布, 没有均值 (积分发散)。

与正态的关系: 当 $n \rightarrow \infty$ 时, $t(n) \xrightarrow{d} N(0, 1)$ 。这反映了直观思想: 随着样本量增大, 对方差的了解改善, t 分布收敛到标准正态。

EXAMPLE 3.30 (t 分布应用). 设 $T \sim t(10)$ 。求 $\mathbb{P}(|T| > 2.228)$ 。

由表得 $t_{0.025, 10} = 2.228$, 所以 $\mathbb{P}(|T| > 2.228) = 0.05$ 。

与正态对比: 对于 $Z \sim N(0, 1)$, $\mathbb{P}(|Z| > 1.96) = 0.05$ 。 t 分布的临界值更大, 因为尾部更厚。

在 R 中: `2 * (1 - pt(2.228, 10)) = 0.05`。

t 分布在总体方差未知时构造均值的置信区间中起基础作用。当我们用样本标准差 S 替换总体标准差 σ 时, 所得统计量服从 t 分布。²⁰

6.2. F 分布.

DEFINITION 3.8 (F 分布). 若 $X_1 \sim \chi^2(m)$ 和 $X_2 \sim \chi^2(n)$ 独立, 则

$$F = \frac{X_1/m}{X_2/n} \sim F(m, n). \quad (3.6.4)$$

称 F 服从自由度为 (m, n) 的 F 分布。

pdf 为: ²¹

$$f(w) = \begin{cases} \frac{\Gamma((m+n)/2)}{\Gamma(m/2)\Gamma(n/2)} \left(\frac{m}{n}\right)^{m/2} \frac{w^{m/2-1}}{(1+mw/n)^{(m+n)/2}} & w > 0 \\ 0 & \text{elsewhere.} \end{cases} \quad (3.6.5)$$

F 分布是两个独立卡方变量的比值, 每个除以各自的自由度。

¹⁹推导见附录 section 7.19。

²⁰这是第四章置信区间理论的基础。

²¹推导见附录 section 7.20。

均值和方差：

$$\mathbb{E}F = \frac{n}{n-2} \quad (n > 2), \quad \text{var}(F) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)} \quad (n > 4). \quad (3.6.6)$$

22

倒数性质：若 $F \sim F(m, n)$ ，则 $1/F \sim F(n, m)$ 。这个对称性对计算尾部概率很有用。

EXAMPLE 3.31. 若 $T \sim t(n)$ ，则 $T^2 \sim F(1, n)$ 。这从定义可得： $T = Z/\sqrt{\chi^2(n)/n}$ ，所以 $T^2 = Z^2/(\chi^2(n)/n) = \chi^2(1)/(\chi^2(n)/n) \sim F(1, n)$ 。

为什么 F 分布重要？它是 ANOVA（方差分析）和回归分析的核心——我们用它比较两个方差是否相等，或模型解释的方差是否显著大于残差方差。

ANOVA 中的 F 统计量比较组间均值方差与组内方差。如果组间方差相对于组内方差较大，我们拒绝所有组具有相同均值的原假设。

本章小结

本章介绍了统计学中最重要的分布族：

离散分布：

- Bernoulli $\rightarrow$ Binomial $\rightarrow$ Negative Binomial/Geometric
- Multinomial $\rightarrow$ Hypergeometric
- Poisson（二项分布在稀有事件下的极限）

连续分布：

- Uniform $\rightarrow$ Exponential $\rightarrow$ Gamma $\rightarrow$ Chi-square
- Beta（在单位区间上）
- Normal $\rightarrow$ Bivariate Normal
- t 和 F （由正态 + 卡方结构导出）

习题

EXERCISE 3.1. 3.1.1 If the mgf of a random variable X is $(\frac{1}{3} + \frac{2}{3}e^t)^5$, find $P(X = 2 \text{ or } 3)$. Verify using the R function `dbinom`.

EXERCISE 3.2. 3.1.2 The mgf of a random variable X is $(\frac{2}{3} + \frac{1}{3}e^t)^9$.

(1) Show that $P(\mu - 2\sigma < X < \mu + 2\sigma) = \sum_{x=1}^5 \binom{9}{x} \left(\frac{1}{3}\right)^x \left(\frac{2}{3}\right)^{9-x}$.

(2) Use R to compute the probability in Part (a).

EXERCISE 3.3. 3.1.3 If X is $b(n, p)$, show that $E(X/n) = p$ and $E[(X/n - p)^2] = p(1-p)/n$.

²²推导见附录 section 7.21。

EXERCISE 3.4. 3.1.4 Let the independent random variables $X_1, X_2, \dots, X_{40}$ be iid with the common pdf $f(x) = 3x^2$, $0 < x < 1$, zero elsewhere. Find the probability that at least 35 of the X_i 's exceed $\frac{1}{2}$.

EXERCISE 3.5. 3.1.5 Over the years, the percentage of candidates passing an entrance exam to a prestigious law school is 20%. At one of the testing centers, a group of 50 candidates take the exam and 20 pass. Is this odd? Answer on the basis that $X \geq 20$ where X is the number that pass in a group of 50 when the probability of a pass is 0.2.

EXERCISE 3.6. 3.1.6 Let Y be the number of successes throughout n independent repetitions of a random experiment with probability of success $p = \frac{1}{4}$. Determine the smallest value of n so that $P(1 \leq Y) \geq 0.70$.

EXERCISE 3.7. 3.1.7 Let the independent random variables X_1 and X_2 have binomial distribution with parameters $n_1 = 3$, $p = \frac{2}{3}$ and $n_2 = 4$, $p = \frac{1}{2}$, respectively. Compute $P(X_1 = X_2)$.

Hint: List the four mutually exclusive ways that $X_1 = X_2$ and compute the probability of each.

EXERCISE 3.8. 3.1.8 For this exercise, the reader must have access to a statistical package that obtains the binomial distribution. Hints are given for R code, but other packages can be used too.

- (1) Obtain the plot of the pmf for the $b(15, 0.2)$ distribution.
- (2) Repeat part (a) for the binomial distributions with $n = 15$ and with $p = 0.10, 0.20, \dots, 0.90$.
Comment on the shapes of the pmf's as p increases.
- (3) Let $Y = X/n$, where X has a $b(n, 0.05)$ distribution. Obtain the plots of the pmfs of Y for $n = 10, 20, 50, 200$. Comment on the plots.

EXERCISE 3.9. 3.1.9 If $x = r$ is the unique mode of a distribution that is $b(n, p)$, show that $(n+1)p - 1 < r < (n+1)p$.

Hint: Determine the values of x for which $p(x+1)/p(x) > 1$.

EXERCISE 3.10. 3.1.10 Suppose X is $b(n, p)$. Then by definition the pmf is symmetric if and only if $p(x) = p(n-x)$, for $x = 0, \dots, n$. Show that the pmf is symmetric if and only if $p = 1/2$.

EXERCISE 3.11. 3.1.11 Toss two nickels and three dimes at random. Make appropriate assumptions and compute the probability that there are more heads showing on the nickels than on the dimes.

EXERCISE 3.12. 3.1.12 Let $X_1, X_2, \dots, X_{k-1}$ have a multinomial distribution.

- (1) Find the mgf of $X_2, X_3, \dots, X_{k-1}$.
- (2) What is the pmf of $X_2, X_3, \dots, X_{k-1}$?

(3) Determine the conditional pmf of X_1 given that $X_2 = x_2, \dots, X_{k-1} = x_{k-1}$.

(4) What is the conditional expectation $E(X_1 | x_2, \dots, x_{k-1})$?

EXERCISE 3.13. 3.1.13 Let X be $b(2, p)$ and let Y be $b(4, p)$. If $P(X \geq 1) = \frac{5}{9}$, find $P(Y \geq 1)$.

EXERCISE 3.14. 3.1.14 Let X have a binomial distribution with parameters n and $p = \frac{1}{3}$. Determine the smallest integer n can be such that $P(X \geq 1) \geq 0.85$.

EXERCISE 3.15. 3.1.15 Let X have the pmf $p(x) = \left(\frac{1}{3}\right) \left(\frac{2}{3}\right)^x$, $x = 0, 1, 2, 3, \dots$, zero elsewhere. Find the conditional pmf of X given that $X \geq 3$.

EXERCISE 3.16. 3.1.16 One of the numbers $1, 2, \dots, 6$ is to be chosen by casting an unbiased die. Let this random experiment be repeated five independent times. Let the random variable X_1 be the number of terminations in the set $\{x : x = 1, 2, 3\}$ and let the random variable X_2 be the number of terminations in the set $\{x : x = 4, 5\}$. Compute $P(X_1 = 2, X_2 = 1)$.

EXERCISE 3.17. 3.1.17 Show that the moment generating function of the negative binomial distribution is $M(t) = p^r [1 - (1 - p)e^t]^{-r}$. Find the mean and the variance of this distribution.

Hint: In the summation representing $M(t)$, make use of the negative binomial series.

EXERCISE 3.18. 3.1.18 One way of estimating the number of fish in a lake is the following capture-recapture sampling scheme. Suppose there are N fish in the lake where N is unknown. A specified number of fish T are captured, tagged, and released back to the lake. Then at a specified time and for a specified positive integer r , fish are captured until the r th tagged fish is caught. The random variable of interest is Y the number of nontagged fish caught.

(1) What is the distribution of Y ? Identify all parameters.

(2) What is $E(Y)$ and the $\text{Var}(Y)$?

(3) The method of moment estimate of N is to set Y equal to the expression for $E(Y)$ and solve this equation for N . Call the solution $\hat{N}$. Determine $\hat{N}$.

(4) Determine the mean and variance of $\hat{N}$.

EXERCISE 3.19. 3.1.19 Consider a multinomial trial with outcomes $1, 2, \dots, k$ and respective probabilities $p_1, p_2, \dots, p_k$.

(1) Compute 10 random trials if $p_1 = 0.3, p_2 = 0.2, p_3 = 0.2, p_4 = 0.2, p_5 = 0.1$.

(2) Compute 10,000 random trials for the above probabilities. Check to see how close the estimates of p_i are with p_i .

EXERCISE 3.20. 3.1.20 Using the experiment in part (a) of Exercise 3.1.19, consider a game when a person pays \$5 to play. If the trial results in a 1 or 2, she receives nothing;

if a 3, she receives \$1; if a 4, she receives \$2; and if a 5, she receives \$20. Let G be her gain.

- (1) Determine $E(G)$.
- (2) Write R code that simulates the gain. Then simulate it 10,000 times, collecting the gains. Compute the average of these 10,000 gains and compare it with $E(G)$.

EXERCISE 3.21. 3.1.21 Let X_1 and X_2 have a trinomial distribution. Differentiate the moment-generating function to show that their covariance is $-np_1p_2$.

EXERCISE 3.22. 3.1.22 If a fair coin is tossed at random five independent times, find the conditional probability of five heads given that there are at least four heads.

EXERCISE 3.23. 3.1.23 Let an unbiased die be cast at random seven independent times. Compute the conditional probability that each side appears at least once given that side 1 appears exactly twice.

EXERCISE 3.24. 3.1.24 Compute the measures of skewness and kurtosis of the binomial distribution $b(n, p)$.

EXERCISE 3.25. 3.1.27 Let X have a geometric distribution. Show that $P(X \geq k + j \mid X \geq k) = P(X \geq j)$, where k and j are nonnegative integers. Note that we sometimes say in this situation that X is memoryless.

EXERCISE 3.26. 3.1.28 Let X equal the number of independent tosses of a fair coin that are required to observe heads on consecutive tosses. Let u_n equal the n th Fibonacci number, where $u_1 = u_2 = 1$ and $u_n = u_{n-1} + u_{n-2}$, $n = 3, 4, 5, \dots$

- (1) Show that the pmf of X is $p(x) = \frac{u_x - 1}{2^x}$, $x = 2, 3, 4, \dots$
- (2) Use the fact that $u_n = \frac{1}{\sqrt{5}} \left[\left(\frac{1+\sqrt{5}}{2} \right)^n - \left(\frac{1-\sqrt{5}}{2} \right)^n \right]$ to show that $\sum_{x=2}^{\infty} p(x) = 1$.

EXERCISE 3.27. 3.1.30 Consider a shipment of 1000 items into a factory. Suppose the factory can tolerate about 5% defective items. Let X be the number of defective items in a sample without replacement of size $n = 10$. Suppose the factory returns the shipment if $X \geq 2$.

- (1) Obtain the probability that the factory returns a shipment of items that has 5% defective items.
- (2) Suppose the shipment has 10% defective items. Obtain the probability that the factory returns such a shipment.
- (3) Obtain approximations to the probabilities in parts (a) and (b) using appropriate binomial distributions.

EXERCISE 3.28. 3.1.31 Show that the variance of a hypergeometric (N, D, n) distribution is given by expression (3.1.8).

Hint: First obtain $E[X(X-1)]$ by proceeding in the same way as the derivation of the mean given in Section 3.1.3.

EXERCISE 3.29. 3.2.1 If the random variable X has a Poisson distribution such that $P(X=1) = P(X=2)$, find $P(X=4)$.

EXERCISE 3.30. 3.2.2 The mgf of a random variable X is $e^{4(e^t-1)}$. Show that $P(\mu - 2\sigma < X < \mu + 2\sigma) = 0.931$.

EXERCISE 3.31. 3.2.3 In a lengthy manuscript, it is discovered that only 13.5 percent of the pages contain no typing errors. If we assume that the number of errors per page is a random variable with a Poisson distribution, find the percentage of pages that have exactly one error.

EXERCISE 3.32. 3.2.4 Let the pmf $p(x)$ be positive on and only on the nonnegative integers. Given that $p(x) = (4/x)p(x-1)$, $x = 1, 2, 3, \dots$, find the formula for $p(x)$.

Hint: Note that $p(1) = 4p(0)$, $p(2) = (4^2/2!)p(0)$, and so on. That is, find each $p(x)$ in terms of $p(0)$ and then determine $p(0)$ from $1 = p(0) + p(1) + p(2) + \dots$.

EXERCISE 3.33. 3.2.5 Let X have a Poisson distribution with $\mu = 100$. Use Chebyshev's inequality to determine a lower bound for $P(75 < X < 125)$. Next, calculate the probability using R . Is the approximation by Chebyshev's inequality accurate?

EXERCISE 3.34. 3.2.7 By Exercise 3.2.6 it seems that the Poisson pmf peaks at its mean λ . Show that this is the case by solving the inequalities $[p(x+1)/p(x)] > 1$ and $[p(x+1)/p(x)] < 1$, where $p(x)$ is the pmf of a Poisson distribution with parameter λ .

EXERCISE 3.35. 3.2.10 The approximation discussed in Exercise 3.2.8 can be made precise in the following way. Suppose X_n is binomial with the parameters n and $p = \lambda/n$, for a given $\lambda > 0$. Let Y be Poisson with mean λ . Show that $P(X_n = k) \rightarrow P(Y = k)$, as $n \rightarrow \infty$, for an arbitrary but fixed value of k .

Hint: First show that $P(X_n = k) = \frac{\lambda^k}{k!} \left[\frac{n(n-1)\cdots(n-k+1)}{n^k} \left(1 - \frac{\lambda}{n}\right)^{-k} \right] \left(1 - \frac{\lambda}{n}\right)^n$.

EXERCISE 3.36. 3.2.11 Let the number of chocolate chips in a certain type of cookie have a Poisson distribution. We want the probability that a cookie of this type contains at least two chocolate chips to be greater than 0.99. Find the smallest value of the mean that the distribution can take.

EXERCISE 3.37. 3.2.12 Compute the measures of skewness and kurtosis of the Poisson distribution with mean μ .

EXERCISE 3.38. 3.2.13 On the average, a grocer sells three of a certain article per week. How many of these should he have in stock so that the chance of his running out within a week is less than 0.01? Assume a Poisson distribution.

EXERCISE 3.39. 3.2.14 Let X have a Poisson distribution. If $P(X = 1) = P(X = 3)$, find the mode of the distribution.

EXERCISE 3.40. 3.3.2 If X is $\chi^2(5)$, determine the constants c and d so that $P(c < X < d) = 0.95$ and $P(X < c) = 0.025$.

EXERCISE 3.41. 3.3.3 Suppose the lifetime in months of an engine, working under hazardous conditions, has a Γ distribution with a mean of 10 months and a variance of 20 months squared.

- (1) Determine the median lifetime of an engine.
- (2) Suppose such an engine is termed successful if its lifetime exceeds 15 months. In a sample of 10 engines, determine the probability of at least 3 successful engines.

EXERCISE 3.42. 3.3.4 Let X be a random variable such that $E(X^m) = (m+1)!2^m$, $m = 1, 2, 3, \dots$. Determine the mgf and the distribution of X .

Hint: Write out the Taylor series of the mgf.

EXERCISE 3.43. 3.3.6 Let X_1, X_2, X_3 be iid random variables, each with pdf $f(x) = e^{-x}$, $0 < x < \infty$, zero elsewhere.

- (1) Find the distribution of $Y = \text{minimum}(X_1, X_2, X_3)$.

Hint: $P(Y \leq y) = 1 - P(Y > y) = 1 - P(X_i > y, i = 1, 2, 3)$.

- (2) Find the distribution of $Y = \text{maximum}(X_1, X_2, X_3)$.

EXERCISE 3.44. 3.3.7 Let X have a gamma distribution with pdf $f(x) = \frac{1}{\beta^2}xe^{-x/\beta}$, $0 < x < \infty$, zero elsewhere. If $x = 2$ is the unique mode of the distribution, find the parameter β and $P(X < 9.49)$.

EXERCISE 3.45. 3.3.8 Compute the measures of skewness and kurtosis of a gamma distribution that has parameters α and β .

EXERCISE 3.46. 3.3.9 Let X have a gamma distribution with parameters α and β . Show that $P(X \geq 2\alpha\beta) \leq (2/e)^\alpha$.

Hint: Use the result of Exercise 1.10.5.

EXERCISE 3.47. 3.3.11 Using the computer, obtain plots of the pdfs of chi-squared distributions with degrees of freedom $r = 1, 2, 5, 10, 20$. Comment on the plots.

EXERCISE 3.48. 3.3.12 Using the computer, plot the cdf of a $\Gamma(5, 4)$ distribution and use it to guess the median. Confirm it with a computer command that returns the median. In R, use the command `qgamma(.5, shape=5, scale=4)`.

EXERCISE 3.49. 3.3.13 Using the computer, obtain plots of beta pdfs for $\alpha = 1, 5, 10$ and $\beta = 1, 2, 5, 10, 20$.

EXERCISE 3.50. 3.3.16 Let X have the uniform distribution with pdf $f(x) = 1$, $0 < x < 1$, zero elsewhere. Find the cdf of $Y = -2 \log X$. What is the pdf of Y ?

EXERCISE 3.51. 3.3.17 Find the uniform distribution of the continuous type on the interval (b, c) that has the same mean and the same variance as those of a chi-square distribution with 8 degrees of freedom. That is, find b and c .

EXERCISE 3.52. 3.3.18 Find the mean and variance of the β distribution.

Hint: From the pdf, we know that $\int_0^1 y^{\alpha-1}(1-y)^{\beta-1} dy = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ for all $\alpha > 0$, $\beta > 0$.

EXERCISE 3.53. 3.3.19 Determine the constant c in each of the following so that each $f(x)$ is a β pdf:

- (1) $f(x) = cx(1-x)^3$, $0 < x < 1$, zero elsewhere.
- (2) $f(x) = cx^4(1-x)^5$, $0 < x < 1$, zero elsewhere.
- (3) $f(x) = cx^2(1-x)^8$, $0 < x < 1$, zero elsewhere.

EXERCISE 3.54. 3.3.25 Let X have an exponential distribution.

- (1) For $x > 0$ and $y > 0$, show that $P(X > x + y \mid X > x) = P(X > y)$. Hence, the exponential distribution has the memoryless property.
- (2) Let $F(x)$ be the cdf of a continuous random variable Y . Assume that $F(0) = 0$ and $0 < F(y) < 1$ for $y > 0$. Suppose property $P(X > x + y \mid X > x) = P(X > y)$ holds for Y . Show that $F_Y(y) = 1 - e^{-\lambda y}$ for $y > 0$.

Hint: Show that $g(y) = 1 - F_Y(y)$ satisfies the equation $g(y+z) = g(y)g(z)$.

EXERCISE 3.55. 3.4.1 If $\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-w^2/2} dw$, show that $\Phi(-z) = 1 - \Phi(z)$.

EXERCISE 3.56. 3.4.2 If X is $N(75, 100)$, find $P(X < 60)$ and $P(70 < X < 100)$ by using either Table II or the R command `pnorm`.

EXERCISE 3.57. 3.4.3 If X is $N(\mu, \sigma^2)$, find b so that $P[-b < (X - \mu)/\sigma < b] = 0.90$, by using either Table II of Appendix D or the R command `qnorm`.

EXERCISE 3.58. 3.4.4 Let X be $N(\mu, \sigma^2)$ so that $P(X < 89) = 0.90$ and $P(X < 94) = 0.95$. Find μ and σ^2 .

EXERCISE 3.59. 3.4.6 If X is $N(\mu, \sigma^2)$, show that $E(|X - \mu|) = \sigma\sqrt{2/\pi}$.

EXERCISE 3.60. 3.4.7 Show that the graph of a pdf $N(\mu, \sigma^2)$ has points of inflection at $x = \mu - \sigma$ and $x = \mu + \sigma$.

EXERCISE 3.61. 3.4.9 Determine the 90th percentile of the distribution which is $N(65, 25)$.

EXERCISE 3.62. 3.4.10 If e^{3t+8t^2} is the mgf of the random variable X , find $P(-1 < X < 9)$.

EXERCISE 3.63. 3.4.12 Let X be $N(5, 10)$. Find $P[0.04 < (X - 5)^2 < 38.4]$.

EXERCISE 3.64. 3.4.13 If X is $N(1, 4)$, compute the probability $P(1 < X^2 < 9)$.

EXERCISE 3.65. 3.4.17 Compute the measures of skewness and kurtosis of a distribution which is $N(\mu, \sigma^2)$. See Exercises 1.9.14 and 1.9.15 for the definitions of skewness and kurtosis, respectively.

EXERCISE 3.66. 3.4.29 Let X_1 and X_2 be independent with normal distributions $N(6, 1)$ and $N(7, 1)$, respectively. Find $P(X_1 > X_2)$.

Hint: Write $P(X_1 > X_2) = P(X_1 - X_2 > 0)$ and determine the distribution of $X_1 - X_2$.

EXERCISE 3.67. 3.4.30 Compute $P(X_1 + 2X_2 - 2X_3 > 7)$ if X_1, X_2, X_3 are iid with common distribution $N(1, 4)$.

EXERCISE 3.68. 3.4.32 Let X be $N(0, 1)$. Use the moment generating function technique to show that $Y = X^2$ is $\chi^2(1)$.

Hint: Evaluate the integral that represents $E(e^{tX^2})$ by writing $w = x\sqrt{1-2t}$, $t < 1/2$.

EXERCISE 3.69. 3.5.1 Let X and Y have a bivariate normal distribution with respective parameters $\mu_x = 2.8$, $\mu_y = 110$, $\sigma_x^2 = 0.16$, $\sigma_y^2 = 100$, and $\rho = 0.6$. Using R , compute:

- (1) $P(106 < Y < 124)$.
- (2) $P(106 < Y < 124 \mid X = 3.2)$.

EXERCISE 3.70. 3.5.2 Let X and Y have a bivariate normal distribution with parameters $\mu_1 = 3$, $\mu_2 = 1$, $\sigma_1^2 = 16$, $\sigma_2^2 = 25$, and $\rho = \frac{3}{5}$. Using R , determine the following probabilities:

- (1) $P(3 < Y < 8)$
- (2) $P(3 < Y < 8 \mid X = 7)$
- (3) $P(-3 < X < 3)$
- (4) $P(-3 < X < 3 \mid Y = -4)$

EXERCISE 3.71. 3.5.3 Show that $E(XY) = \rho\sigma_1\sigma_2 + \mu_1\mu_2$ for the bivariate normal distribution.

EXERCISE 3.72. 3.5.7 Let X and Y have a bivariate normal distribution with parameters $\mu_1 = 5$, $\mu_2 = 10$, $\sigma_1^2 = 1$, $\sigma_2^2 = 25$, and $\rho > 0$. If $P(4 < Y < 16 \mid X = 5) = 0.954$, determine ρ .

EXERCISE 3.73. 3.5.9 Say the correlation coefficient between the heights of husbands and wives is 0.70 and the mean male height is 5 feet 10 inches with standard deviation 2 inches, and the mean female height is 5 feet 4 inches with standard deviation 1.5 inches. Assuming a bivariate normal distribution, what is the best guess of the height of a woman whose husband's height is 6 feet? Find a 95% prediction interval for her height.

EXERCISE 3.74. 3.6.1 Let T have a t -distribution with 10 degrees of freedom. Find $P(|T| > 2.228)$ from either Table III or by using R .

EXERCISE 3.75. 3.6.2 Let T have a t -distribution with 14 degrees of freedom. Determine b so that $P(-b < T < b) = 0.90$. Use either Table III or by using R .

EXERCISE 3.76. 3.6.3 Let T have a t -distribution with $r > 4$ degrees of freedom. Use expression (3.6.4) to determine the kurtosis of T . See Exercise 1.9.15 for the definition of kurtosis.

EXERCISE 3.77. 3.6.7 Let F have an F -distribution with parameters r_1 and r_2 . Assuming that $r_2 > 2k$, continue with Example 3.6.2 and derive the $E(F^k)$.

EXERCISE 3.78. 3.6.9 Let F have an F -distribution with parameters r_1 and r_2 . Argue that $1/F$ has an F -distribution with parameters r_2 and r_1 .

EXERCISE 3.79. 3.6.11 Let $T = W/\sqrt{V/r}$, where the independent variables W and V are, respectively, normal with mean zero and variance 1 and chi-square with r degrees of freedom. Show that T^2 has an F -distribution with parameters $r_1 = 1$ and $r_2 = r$.

EXERCISE 3.80. 3.6.12 Show that the t -distribution with $r = 1$ degree of freedom and the Cauchy distribution are the same.

EXERCISE 3.81. 3.6.15 Let X_1, X_2 be iid with common distribution having the pdf $f(x) = e^{-x}$, $0 < x < \infty$, zero elsewhere. Show that $Z = X_1/X_2$ has an F -distribution.

EXERCISE 3.82. 3.7.1 Suppose Y has a $\Gamma(\alpha, \beta)$ distribution. Let $X = e^Y$. Show that the pdf of X is given by expression (3.7.5). Determine the cdf of X in terms of the cdf of a Γ -distribution. Derive the mean and variance of X .

EXERCISE 3.83. 3.7.3 In Example 3.7.1, derive the pdf of the mixture distribution given in expression (3.7.6), then obtain its mean and variance as given in expressions (3.7.7) and (3.7.8).

EXERCISE 3.84. 3.7.5 Consider the mixture distribution $(9/10)N(0, 1) + (1/10)N(0, 9)$. Show that its kurtosis is 8.34.

EXERCISE 3.85. 3.7.14 If X has a Pareto distribution with parameters α and β and if c is a positive constant, show that $Y = cX$ has a Pareto distribution with parameters α and β/c .

7. 附录：公式推导

7.1. 二项分布矩母函数的推导. 背景：二项分布 $X \sim \text{Bin}(n, p)$ 的矩母函数定义为 $M(t) = \mathbb{E}[e^{tX}]$ 。

目标：求 $M(t)$ ，并由此导出均值和方差。

推导步骤：

由定义：

$$M(t) = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

将 $e^{tx} p^x = (pe^t)^x$ 提取出来：

$$M(t) = \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n,$$

其中最后一步使用了二项式定理。

对 $M(t)$ 求导：

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t.$$

在 $t = 0$ 处求值：

$$M'(0) = n[(1-p) + p]^{n-1} \cdot p = np,$$

$$M''(0) = n(n-1)[(1-p) + p]^{n-2} \cdot p^2 + n[(1-p) + p]^{n-1} \cdot p = n(n-1)p^2 + np.$$

因此：

$$\text{var}(X) = M''(0) - [M'(0)]^2 = [n(n-1)p^2 + np] - n^2p^2 = np(1-p).$$

7.2. 二项分布可加性的证明. 背景：若 $X_1 \sim \text{Bin}(n_1, p)$ 和 $X_2 \sim \text{Bin}(n_2, p)$ 独立，证明 $X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p)$ 。

推导步骤：

使用矩母函数方法。两独立随机变量和的 mgf 是它们 mgf 的乘积：

$X_1 + X_2$ 的 mgf 为：

$$M_{X_1+X_2}(t) = M_{X_1}(t) \cdot M_{X_2}(t) = [(1-p) + pe^t]^{n_1} \cdot [(1-p) + pe^t]^{n_2} = [(1-p) + pe^t]^{n_1+n_2}.$$

这正是 $\text{Bin}(n_1 + n_2, p)$ 的 mgf。由于 mgf 唯一确定分布，结论得证。

7.3. 负二项分布的推导. 背景：负二项分布描述“第 r 次成功前失败次数”的分布。

目标：推导 pmf $p_Y(y) = \mathbb{P}(Y = y)$ 。

推导步骤：

恰好有 y 次失败发生在第 r 次成功之前，当且仅当：

- (1) 前 $y + r - 1$ 次试验中恰好有 $r - 1$ 次成功和 y 次失败
- (2) 第 $y + r$ 次试验是成功

第一步的概率由二项分布给出： $\binom{y+r-1}{r-1}p^{r-1}(1-p)^y$ 。

第二步的成功概率为 p 。

由独立性，总概率为：

$$p_Y(y) = \binom{y+r-1}{r-1}p^{r-1}(1-p)^y \cdot p = \binom{y+r-1}{r-1}p^r(1-p)^y, \quad y = 0, 1, 2, \dots$$

验证归一性：利用负二项级数 $\sum_{y=0}^{\infty} \binom{y+r-1}{r-1}(1-p)^y = p^{-r}$ ，可得 $\sum_y p_Y(y) = 1$ 。

7.4. 几何分布无记忆性的证明. 背景：几何分布具有独特的无记忆性： $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤：

由条件概率定义：

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)}.$$

几何分布下， $\mathbb{P}(Y \geq y) = (1-p)^y$ （对于 $y = 0, 1, 2, \dots$ ）。

因此：

$$\frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

证毕。

7.5. 几何分布矩的推导. 目标：求几何分布 $Y \sim \text{Geom}(p)$ （支撑集 $\{0, 1, 2, \dots\}$ ）的均值和方差。

推导步骤：

均值：使用几何级数求和技巧。

$$\mathbb{E}Y = \sum_{y=0}^{\infty} y \cdot p(1-p)^y = p(1-p) \sum_{y=1}^{\infty} y(1-p)^{y-1}.$$

利用 $\sum_{y=1}^{\infty} yx^{y-1} = \frac{1}{(1-x)^2}$ ($|x| < 1$)，得：

$$\mathbb{E}Y = p(1-p) \cdot \frac{1}{p^2} = \frac{1-p}{p}.$$

方差：先求 $\mathbb{E}[Y(Y-1)]$ ：

$$\mathbb{E}[Y(Y-1)] = \sum_{y=0}^{\infty} y(y-1)p(1-p)^y = p(1-p)^2 \sum_{y=2}^{\infty} y(y-1)(1-p)^{y-2} = p(1-p)^2 \cdot \frac{2}{p^3} = \frac{2(1-p)^2}{p^2}.$$

由 $\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2$ 和 $\mathbb{E}[Y(Y-1)] = \mathbb{E}[Y^2] - \mathbb{E}[Y]$ ，得：

$$\mathbb{E}[Y^2] = \mathbb{E}[Y(Y-1)] + \mathbb{E}[Y] = \frac{2(1-p)^2}{p^2} + \frac{1-p}{p} = \frac{(1-p)(2-p)}{p^2}.$$

因此：

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{(1-p)(2-p)}{p^2} - \frac{(1-p)^2}{p^2} = \frac{1-p}{p^2}.$$

7.6. 负二项分布矩母函数的推导. 目标: 推导负二项分布 $Y \sim \text{NB}(r, p)$ 的 mgf。

推导步骤:

使用概率生成函数的性质。负二项分布可以分解为 r 个独立几何随机变量之和:

$$Y = G_1 + G_2 + \cdots + G_r,$$

其中每个 $G_i \sim \text{Geom}(p)$ (支撑集 $\{0, 1, 2, \dots\}$)。

几何分布的 mgf 为 $M_G(t) = \frac{p}{1-(1-p)e^t}$ ($t < -\log(1-p)$)。

由于独立同分布之和:

$$M_Y(t) = [M_G(t)]^r = \left[\frac{p}{1-(1-p)e^t} \right]^r = \frac{p^r}{[1-(1-p)e^t]^r}.$$

7.7. 多项分布的推导. 背景: 多项分布是二项分布对 k 个类别的推广。

目标: 推导联合 pmf。

推导步骤:

在 n 次独立试验中, 第 i 个类别出现 x_i 次的概率为 $\binom{n}{x_1, x_2, \dots, x_k} \prod_{i=1}^k p_i^{x_i}$, 其中 $\binom{n}{x_1, x_2, \dots, x_k} = \frac{n!}{x_1! x_2! \cdots x_k!}$ 是多项式系数。

这正是 pmf 的形式。验证归一性: 由多项式定理, $\sum_{x_1 + \cdots + x_k = n} \binom{n}{x_1, \dots, x_k} \prod p_i^{x_i} = (p_1 + \cdots + p_k)^n = 1$ 。

边缘分布: X_i 的边缘分布为 $\text{Bin}(n, p_i)$, 因为忽略其他类别后, 每次试验中类别 i 出现的概率为 p_i 。

协方差: 对于 $i \neq j$,

$$\text{cov}(X_i, X_j) = \mathbb{E}[X_i X_j] - \mathbb{E}[X_i] \mathbb{E}[X_j].$$

利用多项分布的性质可得 $\text{cov}(X_i, X_j) = -np_i p_j$ 。

7.8. 超几何分布的推导. 背景: 超几何分布描述不放回抽样。

目标: 推导 pmf 和矩。

推导步骤:

pmf: 从 N 件产品中不放回抽取 n 件, 恰好得到 x 件次品的概率为:

$$p(x) = \frac{\binom{D}{x} \binom{N-D}{n-x}}{\binom{N}{n}}.$$

这来自组合计数: 选择 x 件次品的方式数乘以选择 $n-x$ 件好品的方式数, 除以从 N 件中选择 n 件的总方式数。

均值: $\mathbb{E}X = n \frac{D}{N}$ 。直观理解: 每次抽取次品的“概率”在不放回情况下仍为 D/N (对称性)。

方差: $\text{var}(X) = n \frac{D}{N} \left(1 - \frac{D}{N}\right) \frac{N-n}{N-1}$ 。

有限总体校正因子 $\frac{N-n}{N-1}$ 反映了不放回抽样与放回抽样的差异。当 $N \gg n$ 时, 此因子接近 1。

7.9. Poisson 分布矩的推导. 目标：求 Poisson 分布的均值和方差。

推导步骤：

均值：

$$\mathbb{E}X = \sum_{x=0}^{\infty} x \cdot \frac{\lambda^x e^{-\lambda}}{x!} = \lambda e^{-\lambda} \sum_{x=1}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda.$$

方差：先求 $\mathbb{E}[X(X-1)]$ ：

$$\mathbb{E}[X(X-1)] = \sum_{x=0}^{\infty} x(x-1) \cdot \frac{\lambda^x e^{-\lambda}}{x!} = \lambda^2 e^{-\lambda} \sum_{x=2}^{\infty} \frac{\lambda^{x-2}}{(x-2)!} = \lambda^2 e^{-\lambda} \cdot e^{\lambda} = \lambda^2.$$

因此 $\mathbb{E}[X^2] = \mathbb{E}[X(X-1)] + \mathbb{E}[X] = \lambda^2 + \lambda$ ，方差为：

$$\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda.$$

7.10. Poisson 近似二项分布的证明. 背景：当 n 很大、 p 很小时，二项分布 $\text{Bin}(n, p)$ 近似 Poisson(λ)。

推导步骤：

设 $X_n \sim \text{Bin}(n, p_n)$ ，其中 $np_n \rightarrow \lambda$ 。对固定的 k ：

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

写成：

$$= \frac{n(n-1)\cdots(n-k+1)}{k!} p_n^k (1-p_n)^{n-k} = \frac{n^k p_n^k}{k!} (1-p_n)^n \cdot \frac{(1-p_n^{-1})(1-2p_n^{-1})\cdots(1-(k-1)p_n^{-1})}{(1-p_n)^k}.$$

当 $n \rightarrow \infty$ 时， $np_n \rightarrow \lambda$ ，所以 $p_n \rightarrow 0$ 。因此：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} \cdot \lim_{n \rightarrow \infty} (1-p_n)^n = \frac{\lambda^k}{k!} e^{-\lambda}.$$

证毕。

7.11. Gamma 函数递归公式的推导. 目标：证明 $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$ 。

推导步骤：

由定义：

$$\Gamma(\alpha+1) = \int_0^{\infty} x^{\alpha} e^{-x} dx.$$

使用分部积分 ($u = x^{\alpha}$, $dv = e^{-x} dx$)：

$$\Gamma(\alpha+1) = [-x^{\alpha} e^{-x}]_0^{\infty} + \alpha \int_0^{\infty} x^{\alpha-1} e^{-x} dx = 0 + \alpha \Gamma(\alpha) = \alpha \Gamma(\alpha).$$

边界项在两端均为零，因为 $x^{\alpha} e^{-x} \rightarrow 0$ 当 $x \rightarrow \infty$ (指数衰减快于多项增长)，且当 $x \rightarrow 0$ 时 $x^{\alpha} \rightarrow 0$ ($\alpha > 0$)。

7.12. Gamma 分布矩母函数的推导. 目标: 推导 $\Gamma(\alpha, \beta)$ 分布的 mgf, 并求均值和方差。

推导步骤:

由定义:

$$M(t) = \mathbb{E}[e^{tX}] = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx.$$

令 $z = x/\beta$, $dx = \beta dz$:

$$M(t) = \frac{1}{\Gamma(\alpha)} \int_0^\infty e^{t\beta z} z^{\alpha-1} e^{-z} dz = \frac{1}{\Gamma(\alpha)} \int_0^\infty z^{\alpha-1} e^{-(1-t\beta)z} dz.$$

利用 $\int_0^\infty z^{\alpha-1} e^{-sz} dz = \Gamma(\alpha)/s^\alpha$ ($\text{Re}(s) > 0$), 得:

$$M(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}.$$

求导:

$$M'(t) = \alpha\beta(1 - \beta t)^{-\alpha-1}, \quad M''(t) = \alpha(\alpha+1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

在 $t = 0$ 处求值:

$$\mathbb{E}X = M'(0) = \alpha\beta, \quad \mathbb{E}[X^2] = M''(0) = \alpha(\alpha+1)\beta^2.$$

因此 $\text{var}(X) = \alpha(\alpha+1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2$ 。

7.13. Gamma 分布可加性的证明. 背景: 若 $X_1 \sim \Gamma(\alpha_1, \beta)$ 和 $X_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 证明 $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

推导步骤:

使用 mgf 方法。独立随机变量和的 mgf 是 mgf 的乘积:

$$M_{X_1+X_2}(t) = M_{X_1}(t) \cdot M_{X_2}(t) = (1 - \beta t)^{-\alpha_1} \cdot (1 - \beta t)^{-\alpha_2} = (1 - \beta t)^{-(\alpha_1+\alpha_2)}.$$

这正是 $\Gamma(\alpha_1 + \alpha_2, \beta)$ 的 mgf。证毕。

7.14. Beta 分布矩的推导. 目标: 推导 $\text{Beta}(\alpha, \beta)$ 分布的均值和方差。

推导步骤:

均值:

$$\mathbb{E}X = \frac{1}{B(\alpha, \beta)} \int_0^1 x \cdot x^{\alpha-1} (1-x)^{\beta-1} dx = \frac{1}{B(\alpha, \beta)} \int_0^1 x^\alpha (1-x)^{\beta-1} dx = \frac{B(\alpha+1, \beta)}{B(\alpha, \beta)}.$$

利用 $B(\alpha+1, \beta) = \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+\beta+1)} = \frac{\alpha}{\alpha+\beta} \cdot \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} = \frac{\alpha}{\alpha+\beta} B(\alpha, \beta)$, 得:

$$\mathbb{E}X = \frac{\alpha}{\alpha+\beta}.$$

方差: 先求 $\mathbb{E}[X^2]$:

$$\mathbb{E}[X^2] = \frac{B(\alpha+2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}.$$

因此：

$$\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \frac{\alpha^2}{(\alpha+\beta)^2} = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}.$$

7.15. Beta-二项共轭关系. 背景：在贝叶斯统计中，Beta 分布是二项分布的共轭先验。

推导步骤：

设 $X \sim \text{Bin}(n, p)$ ，先验 $p \sim \text{Beta}(\alpha, \beta)$ 。

似然： $L(p) \propto p^x(1-p)^{n-x}$ 。

先验： $\pi(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$ 。

后验：

$$\pi(p | x) \propto p^x(1-p)^{n-x} \cdot p^{\alpha-1}(1-p)^{\beta-1} = p^{\alpha+x-1}(1-p)^{\beta+n-x-1}.$$

这正是 $\text{Beta}(\alpha+x, \beta+n-x)$ 的核。因此后验仍是 Beta 分布。

这就是“共轭先验”的含义：先验和后验属于同一分布族。

7.16. 正态分布矩母函数的推导. 目标：推导 $N(\mu, \sigma^2)$ 的 mgf。

推导步骤：

标准化方法。设 $Z \sim N(0, 1)$ ，则 $X = \mu + \sigma Z$ 。

$$M_X(t) = \mathbb{E}[e^{tX}] = \mathbb{E}[e^{t(\mu+\sigma Z)}] = e^{\mu t} \mathbb{E}[e^{\sigma t Z}] = e^{\mu t} M_Z(\sigma t).$$

对 $Z \sim N(0, 1)$ ，完成平方：

$$M_Z(s) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{sz - z^2/2} dz = e^{s^2/2} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-(z-s)^2/2} dz = e^{s^2/2}.$$

因此：

$$M_X(t) = \exp \left\{ \mu t + \frac{1}{2} \sigma^2 t^2 \right\}.$$

7.17. 正态变量线性组合的证明. 背景：正态分布在线性变换下闭合。

推导步骤：

设 $X_1 \sim N(\mu_1, \sigma_1^2)$ ， $X_2 \sim N(\mu_2, \sigma_2^2)$ 独立。

$Y = aX_1 + bX_2$ 的 mgf：

$$M_Y(t) = \mathbb{E}[e^{t(aX_1+bX_2)}] = \mathbb{E}[e^{(at)X_1}] \cdot \mathbb{E}[e^{(bt)X_2}] = M_{X_1}(at) \cdot M_{X_2}(bt).$$

代入正态 mgf：

$$M_Y(t) = \exp \left\{ \mu_1(at) + \frac{1}{2} \sigma_1^2(at)^2 \right\} \cdot \exp \left\{ \mu_2(bt) + \frac{1}{2} \sigma_2^2(bt)^2 \right\} = \exp \left\{ (a\mu_1 + b\mu_2)t + \frac{1}{2} (a^2\sigma_1^2 + b^2\sigma_2^2)t^2 \right\}.$$

这正是 $N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$ 的 mgf。证毕。

7.18. 二元正态分布矩母函数的推导. 目标: 推导二元正态分布的联合 mgf.

推导步骤:

由二元正态的定义, (X_1, X_2) 的联合 pdf 可写成矩阵形式. 联合 mgf 为:

$$M(t_1, t_2) = \mathbb{E}[e^{t_1 X_1 + t_2 X_2}].$$

利用条件分布或矩阵形式可证:

$$M(t_1, t_2) = \exp \left\{ t_1 \mu_1 + t_2 \mu_2 + \frac{1}{2} (t_1^2 \sigma_1^2 + 2t_1 t_2 \rho \sigma_1 \sigma_2 + t_2^2 \sigma_2^2) \right\}.$$

7.19. t 分布 pdf 的推导. 背景: t 分布由 $T = Z/\sqrt{\chi^2(n)/n}$ 定义, 其中 $Z \sim N(0, 1)$, $\chi^2(n)$ 独立。

推导步骤:

使用变量变换法。设 $U = \chi^2(n)$, 则 $T = Z/\sqrt{U/n}$, U 与 Z 独立。

联合分布: $f_{Z,U}(z, u) = \phi(z) \cdot f_{\chi^2(n)}(u)$ 。

变换 $(T, U) \rightarrow (Z, U)$ 的雅可比为 $|\partial z / \partial t| = \sqrt{u/n}$ 。

因此 T 的边缘 pdf 为:

$$f_T(t) = \int_0^\infty f_{Z,U}(t\sqrt{u/n}, u) \sqrt{u/n} du.$$

完成积分 (标准推导) 可得:

$$f(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}.$$

7.20. F 分布 pdf 的推导. 背景: F 分布由 $F = \frac{X_1/m}{X_2/n}$ 定义, 其中 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立。

推导步骤:

设 $W = F$, $V = X_2$, 则 $X_1 = W \cdot \frac{m}{n} V$ 。

变换的雅可比为 $|\partial(x_1, x_2)/\partial(w, v)| = \frac{m}{n} v$ 。

积分掉 v 可得 W 的 pdf:

$$f(w) = \frac{\Gamma((m+n)/2)}{\Gamma(m/2)\Gamma(n/2)} \left(\frac{m}{n}\right)^{m/2} \frac{w^{m/2-1}}{(1+mw/n)^{(m+n)/2}}, \quad w > 0.$$

7.21. F 分布矩的推导. 目标: 求 $F(m, n)$ 分布的均值和方差。

推导步骤:

由定义 $F = \frac{X_1/m}{X_2/n} = \frac{n}{m} \cdot \frac{X_1}{X_2}$, 其中 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立。

$E(F)$ 的存在性要求 $n > 2$:

$$\mathbb{E}F = \frac{n}{m} \cdot \frac{\mathbb{E}[X_1]}{\mathbb{E}[X_2]} = \frac{n}{m} \cdot \frac{m}{n} = \frac{n}{n-2}, \quad n > 2.$$

方差的计算类似, 需要 $\mathbb{E}[F^2]$, 要求 $n > 4$:

$$\text{var}(F) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}, \quad n > 4.$$

CHAPTER 4

Some Elementary Statistical Inferences

Chapter 4 Overview

在前三章中，我们建立了描述随机变量和概率分布的理论框架。现在我们面临一个根本性问题：

给定观测数据，如何推断产生这些数据的底层分布？

这个问题——从已知数据推断未知规律——正是统计学的核心任务。正如 Fisher 在 1922 年的经典论文中所强调的，统计推断的本质是在不确定性下做出明智决策。

本章介绍三种主要的推断工具：

- **点估计** (Point Estimation)：用单一数值估计未知参数
- **置信区间** (Confidence Intervals)：参数的合理取值范围，而非点估计的单一数值
- **假设检验** (Hypothesis Testing)：评估关于总体的声明是否获得数据支持

这三种工具相互关联：点估计给出参数的最佳猜测，置信区间度量这个猜测的精度，而假设检验则让我们能够验证关于总体的具体声明。

本章路线图：抽样与统计量 → 点估计 (MLE) → 置信区间 → 假设检验 → 卡方检验 → 蒙特卡洛 → Bootstrap

1. 4.1 Sampling and Statistics

1.1. 从总体到样本。在典型的统计问题中，我们关心某个随机变量 X ，但其 pdf $f(x)$ 或 pmf $p(x)$ 未知。这种未知性可以分为两类：

- (1) $f(x)$ 或 $p(x)$ 的形式完全未知
- (2) 分布的形式已知，但包含未知参数 θ (θ 可以是向量)

1

本章聚焦第二类——这正是统计学中最常见的场景。我们已知数据的分布类型，只是不知道具体的参数值。几个典型例子：

- (a) $X \sim \text{Exp}(\theta)$, θ 未知——指数分布常用于描述等待时间
- (b) $X \sim \text{Binomial}(n, p)$, p 未知——二项分布描述 n 次试验中的成功次数
- (c) $X \sim \Gamma(\alpha, \beta)$, α 和 β 均未知——Gamma 分布广泛出现于保险和排队论
- (d) $X \sim N(\mu, \sigma^2)$, μ 和 σ^2 均未知——正态分布是统计学的核心

¹第一种情况属于非参数方法 (Chapter 10 深入讨论)，第二种情况是本章的核心内容。见附录 section 1.3。

我们用 $f(x; \theta)$ 或 $p(x; \theta)$ 表示含参分布，其中 $\theta \in \Omega$ ， Ω 是参数空间（所有可能的 θ 组成的集合）。

1.2. 随机样本. 为什么要强调“随机”抽取？ 因为只有随机抽样才能保证样本具有代表性——每个个体被选中的概率相等，这样样本才能“代表”总体。

从总体中抽取样本，样本观测值与 X 同分布。记为随机变量 $X_1, X_2, \dots, X_n$ ，其中 n 是样本量。抽到具体数值后记为 $x_1, x_2, \dots, x_n$ 。

若 $X_1, \dots, X_n$ 相互独立且同分布，则称它们为来自该共同分布的**随机样本** (random sample)。

DEFINITION 4.1 (随机样本). 如果随机变量 $X_1, X_2, \dots, X_n$ 独立同分布 (iid)，则称这些随机变量构成来自该共同分布的容量为 n 的随机样本。

从这个定义出发，样本的联合 pdf/pmf 为

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

这正是后续推导似然函数的基础。

1.3. 统计量. 我们已经学会了如何描述单个随机变量，现在面临一个新问题：**如何从样本中提取信息？**

设 $T = T(X_1, X_2, \dots, X_n)$ 是样本的函数。则称 T 为一个**统计量** (statistic)。

统计量的关键特征在于：**不依赖任何未知参数**。换言之，统计量只基于观测数据进行计算，不涉及任何未知数。一旦样本被观测， $t = T(x_1, \dots, x_n)$ 称为 T 的实现值。

1.4. 4.1.1 Point Estimation. 点估计提供一个单一数值（记作 $\hat{\theta}$ ）作为未知参数 θ 的估计。但这里立刻产生一个问题：如何找到“好”的估计量？

1.5. 无偏性. 我们希望估计量具有什么性质？最基本的要求是无偏性——如果反复抽样，估计量的平均值应该等于真实参数值。

DEFINITION 4.2 (无偏估计量). 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的样本， $\theta \in \Omega$ 。设 $T = T(X_1, \dots, X_n)$ 是统计量。若

$$\mathbb{E}(T) = \theta,$$

则称 T 是 θ 的**无偏估计量** (unbiased estimator)。

若 $\mathbb{E}(T) \neq \theta$ ，则称 $\text{Bias}(T) = \mathbb{E}(T) - \theta$ 为偏差。无偏性保证估计量没有系统性偏差——既不高估也不低估。

注意：无偏性并不保证估计量“最好”。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、“最优”的估计原则？

2

²问：为什么要举这个例子？它在整个章节中起什么作用？见附录 section 1.4。

1.6. 最大似然估计 (MLE). 为什么需要似然函数? 样本来自参数 θ 的分布 $f(x; \theta)$ 。给定 θ 时, 观察到当前数据 $\mathbf{x} = (x_1, \dots, x_n)$ 的概率 (密度) 为 $f(\mathbf{x}; \theta)$ 。似然函数正是这个想法的数学表达——它衡量在给定 θ 时, 观察到当前数据的”可能性”。³

DEFINITION 4.3 (似然函数). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本。则

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

称为该随机样本的**似然函数 (likelihood function)**。

核心思想: 如果 θ 是真实参数, 那么它应该使得观察到的数据具有较高的”可能性”。因此, 我们选择使 $L(\theta)$ 最大化的 $\hat{\theta}$ ——这正是最大似然估计量的定义。

最大似然估计量 (MLE):

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} L(\theta). \quad (4.2.1)$$

在实际计算中, 通常使用对数似然 $l(\theta) = \log L(\theta)$, 因为 $\log$ 是严格递增函数, 最大化 $l(\theta)$ 等价于最大化 $L(\theta)$ 。在正则条件下, $\hat{\theta}$ 满足

$$\frac{\partial l(\theta)}{\partial \theta} = 0. \quad (4.2.2)$$

这个方程称为**似然方程 (score equation)**。⁴

EXAMPLE 4.1 (指数分布的 MLE). 设 $X_1, \dots, X_n \sim \operatorname{Exp}(\theta)$, pdf 为 $f(x) = \theta^{-1} \exp\{-x/\theta\}$, $x > 0$ 。

对数似然为

$$l(\theta) = -n \log \theta - \frac{1}{\theta} \sum_{i=1}^n x_i.$$

令导数为零, 解得 $\hat{\theta} = \bar{x}$ 。由于 $\mathbb{E}(X) = \theta$, 故 $\hat{\theta} = \bar{X}$ 也是无偏估计。⁵

EXAMPLE 4.2 (二项分布的 MLE). 设 $X \sim \operatorname{Bernoulli}(\theta)$, $p(x; \theta) = \theta^x (1 - \theta)^{1-x}$, $x = 0, 1$ 。

对于随机样本, 似然函数为

$$L(\theta) = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}.$$

对数似然求导并令为零, 解得 $\hat{\theta} = \bar{x}$ 。由于 $\mathbb{E}(X) = \theta$, 故 $\hat{\theta} = \bar{X}$ 是无偏的。⁶

³在贝叶斯统计中, 似然函数与先验分布结合通过贝叶斯定理产生后验分布。见附录 section 1.2。

⁴通用推导框架见附录 section 7.1。

⁵详细推导见附录 section 7.2。

⁶详细推导见附录 section 7.3。

EXAMPLE 4.3 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 参数向量为 $\theta = (\mu, \sigma)$ 。

对数似然为

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2. \quad (4.2.3)$$

对 μ 和 σ 分别求偏导并令为零, 解得

$$\hat{\mu} = \bar{X}, \quad (4.2.4)$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (4.2.5)$$

一个重要发现: $\hat{\mu} = \bar{X}$ 是无偏的 ($\mathbb{E}(\bar{X}) = \mu$), 但 $\hat{\sigma}^2$ 是有偏的——

$$\mathbb{E}(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2,$$

而样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是无偏的 ($\mathbb{E}(S^2) = \sigma^2$)。这说明 MLE 有时并非无偏——无偏性和最大似然是两种不同的估计原则。⁷

MLE 的吸引力来自其渐近理论: 在温和条件下, MLE 是渐近正态的、渐近有效的, 且具有最优性。这些性质使 MLE 成为现代统计推断的基石。

2. 4.2 Confidence Intervals

点估计给出一个数值, 但它没有告诉我们这个估计有多“可靠”。置信区间通过提供参数的取值范围来解决这个问题。

一个直观的类比: 如果点估计是“我认为明天的温度是 22 度”, 那么置信区间就是“我认为温度在 18 到 26 度之间”。后者不仅给出估计, 还表达了不确定性。

DEFINITION 4.4 (置信区间). 设 $L = g_1(X_1, \dots, X_n)$ 和 $U = g_2(X_1, \dots, X_n)$ 是两个统计量。若对所有 $\theta \in \Omega$,

$$\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha,$$

则称随机区间 $[L, U]$ 为 θ 的 $100(1 - \alpha)\%$ 置信区间 (*confidence interval*)。

正确理解: 不是说“ θ 以 $1 - \alpha$ 概率落在区间内” (θ 是固定常数, 没有随机性), 而是说“如果重复抽样 $100(1 - \alpha)\%$ 的区间会包含 θ ”。这称为置信区间的频率学派解释。⁸

构造置信区间的关键是找到枢轴量 (pivot) ——一个其分布不依赖于未知参数的函数。⁹

⁷详细推导见附录 section 7.4。

⁸问: 很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别? 见附录 section 1.1。

⁹枢轴量的构造方法及推导见附录 section 7.5。

2.1. 正态均值的置信区间.

EXAMPLE 4.4 (已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。则 μ 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right], \quad (4.3.1)$$

其中 $z_{\alpha/2}$ 满足 $\Phi(z_{\alpha/2}) = 1 - \alpha/2$ 。

直觉理解： 区间宽度 $\propto \sigma/\sqrt{n}$ ——样本量越大，估计越精确。这与大数定律的直觉一致：更多信息带来更精确的估计。¹⁰

EXAMPLE 4.5 (未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。用 S^2 替代 σ^2 , 则

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}, \quad (4.3.2)$$

故 μ 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \right]. \quad (4.3.3)$$

用 t 分布替代正态分布： 当方差未知时，我们用样本标准差 S 替代总体标准差 σ 。这引入了额外的随机性，导致分布从正态变为 t 分布。 t 分布比正态分布更“重尾”，反映了未知方差带来的不确定性。¹¹

THEOREM 4.1 (方差置信区间). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ 。则 σ^2 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right]. \quad (4.3.4)$$

其中 $\chi_{p,k}^2$ 是 $\chi^2(k)$ 分布的上侧 p 分位数。¹²

¹⁰详细推导见附录 section 7.6。

¹¹详细推导见附录 section 7.7。

¹²详细推导见附录 section 7.8。




图 1. χ^2 分布的置信区间示意图。图中阴影区域为置信区间 $[(n-1)S^2/\chi_{\alpha/2, n-1}^2, (n-1)S^2/\chi_{1-\alpha/2, n-1}^2]$ 对应的统计量 $(n-1)S^2/\sigma^2$ 的取值范围，两侧红色区域为显著性水平 $\alpha/2$ 的拒绝域。

3. 4.4 Hypothesis Testing

假设检验回答一个根本性问题：**数据是否提供足够证据拒绝关于总体的某个声明？**

这本质上是一种”举证”逻辑：我们先假设某个声明为真 (H_0)，然后问：在这个假设下，当前数据出现的概率有多大？如果概率很小，我们就有理由拒绝这个假设。

核心概念：

- **原假设 H_0 ：**被检验的假设（通常代表”无效应”或”现状”）
- **备择假设 H_1 ：**与 H_0 对立的假设

在设定假设时，我们需要权衡两类错误：

	未拒绝 H_0	拒绝 H_0
H_0 为真	正确（置信度 $1 - \alpha$ ）	第一类错误（概率 α ）
H_0 为假	第二类错误（概率 β ）	正确（功效 $1 - \beta$ ）

显著性水平： $\alpha = \mathbb{P}(\text{第一类错误}) = \mathbb{P}(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$

自然的问题：为什么不能同时最小化两类错误？因为在固定样本量下，两类错误是此消彼长的——降低 α 会提高 β ，反之亦然。这正是统计推断中不确定性本质的体现。

EXAMPLE 4.6 (正态均值检验、已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。检验 $H_0 : \mu = \mu_0$ vs $H_1 : \mu > \mu_0$ (单侧检验)。

检验统计量：

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}. \quad (4.4.1)$$

在 α 水平下，当 $Z > z_\alpha$ 时拒绝 H_0 。¹³

¹³详细推导见附录 section 7.9。

EXAMPLE 4.7 (正态均值检验、未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。检验 $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$ (双侧检验)。

检验统计量:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}. \quad (4.4.2)$$

在 α 水平下, 当 $|T| > t_{\alpha/2, n-1}$ 时拒绝 H_0 。¹⁴

p 值: 在 H_0 为真条件下, 观察到比当前样本更极端结果的概率。 p 值越小, 拒绝 H_0 的证据越强。

与置信区间的联系: 假设检验和置信区间在本质上是等价的——如果 μ_0 落在置信区间内, 我们就不拒绝 $H_0: \mu = \mu_0$; 反之则拒绝。

4. 4.5 Chi-Square Tests

直到现在, 我们讨论的都是连续型数据。但统计学同样关注**分类数据 (categorical data)**——即计数数据。例如: 选举中支持不同候选人的选民人数、不同药物治疗后的治愈/未治愈人数。

卡方检验的核心思想: 比较观测频数与期望频数。如果两者差异很大, 说明数据可能不服从假设的分布。

4.1. 拟合优度检验. 问题: 数据是否来自某个特定分布?

设 $O_1, \dots, O_k$ 是 k 个类别的观测频数, $E_i = np_{i,0}$ 是 H_0 下的期望频数。

检验统计量:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}. \quad (4.5.1)$$

在 H_0 下, $\chi^2 \approx \chi^2(k-1)$ (大样本近似)。拒绝 H_0 当 $\chi^2 > \chi_{\alpha, k-1}^2$ 。

直观理解: $(O_i - E_i)^2/E_i$ 衡量每个类别的偏差, 平方消去正负号, 除以 E_i 进行标准化, 求和得到总体偏差。¹⁵

includegraphics[width=0.7]R/chi-square-goodness.png

图 2. 自由度为 5 的卡方分布, 显著性水平 $\alpha = 0.05$ 的拒绝域 (右侧尾部)。当检验统计量 $\chi^2 > 11.07$ 时, 拒绝原假设。

例 1: 骰子公平性检验

投掷一枚均匀骰子 $n = 600$ 次, 观测到各面的次数记录如下:

点数 i	1	2	3	4	5	6	合计
观测频数 O_i	100	110	95	105	90	100	600

¹⁴详细推导见附录 section 7.9。

¹⁵详细推导见附录 section 7.10。

如果骰子是均匀的 (H_0 : 骰子公平), 每个面的期望频数为 $E_i = 600/6 = 100$ 。

计算 χ^2 统计量:

$$\begin{aligned}\chi^2 &= \sum_{i=1}^6 \frac{(O_i - E_i)^2}{E_i} = \frac{(100 - 100)^2}{100} + \frac{(110 - 100)^2}{100} + \frac{(95 - 100)^2}{100} + \frac{(105 - 100)^2}{100} + \frac{(90 - 100)^2}{100} + \frac{(100 - 100)^2}{100} \\ &= 0 + 1 + 0.25 + 0.25 + 1 + 0 = 2.5.\end{aligned}$$

自由度为 $k - 1 = 6 - 1 = 5$ 。在 $\alpha = 0.05$ 水平,

$$\chi_{0.05,5}^2 = 11.07.$$

由于 $\chi^2 = 2.5 < 11.07$, 我们**不拒绝** H_0 —— 没有足够证据认为这枚骰子不公平。

例 2: 遗传学中的 Hardy-Weinberg 平衡

Hardy-Weinberg 平衡 (遗传平衡定律) 是群体遗传学的基石: 在一个随机交配、无选择、无突变、无迁移的群体中, 基因型频率将保持世代不变。

设一个二等位基因位点, 等位基因频率为 p (A) 和 q (a), 则 Hardy-Weinberg 平衡下的基因型期望频率为:

$$p^2 \text{ (AA)}, \quad 2pq \text{ (Aa)}, \quad q^2 \text{ (aa)}, \quad p + q = 1.$$

数据: 在某人群中随机调查 300 人, 观测到:

基因型	AA	Aa	aa	合计
观测频数 O_i	100	50	150	300

首先由数据估计等位基因频率:

$$\hat{p} = \frac{2 \times 100 + 50}{2 \times 300} = \frac{250}{600} \approx 0.417, \quad \hat{q} = 1 - \hat{p} \approx 0.583.$$

在 Hardy-Weinberg 平衡假设下, 期望频数为:

$$E_{AA} = 300 \times \hat{p}^2 = 300 \times 0.417^2 \approx 52.1,$$

$$E_{Aa} = 300 \times 2\hat{p}\hat{q} = 300 \times 2 \times 0.417 \times 0.583 \approx 145.8,$$

$$E_{aa} = 300 \times \hat{q}^2 = 300 \times 0.583^2 \approx 102.1.$$

计算 χ^2 统计量:

$$\chi^2 = \frac{(100 - 52.1)^2}{52.1} + \frac{(50 - 145.8)^2}{145.8} + \frac{(150 - 102.1)^2}{102.1} \approx 44.1 + 63.0 + 22.5 = 129.6.$$

自由度为 $k - 1 = 3 - 1 = 2$ 。在 $\alpha = 0.05$ 水平, $\chi_{0.05,2}^2 = 5.99$ 。

由于 $\chi^2 = 129.6 > 5.99$, 我们**拒绝** H_0 —— 该人群的基因型分布显著偏离 Hardy-Weinberg 平衡, 可能受到自然选择、突变、迁移或其他进化因素的影响。

4.2. 独立性检验. 对于 $r \times c$ 列联表, 设 O_{ij} 为单元格 (i, j) 的观测频数。

在独立性假设下, 行合计与列合计的乘积除以总数给出期望频数:

$$E_{ij} = \frac{O_{i.} O_{.j}}{n}. \quad (4.5.2)$$

检验统计量:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}. \quad (4.5.3)$$

在 H_0 下, $\chi^2 \approx \chi^2((r-1)(c-1))$ 。

直观理解: 如果行变量与列变量独立, 则每个单元格的观测频数 O_{ij} 应该接近其期望 E_{ij} 。 χ^2 统计量衡量这种偏离程度——偏离越大, 行列不独立的可能性越高。

例 3: 吸烟与肺癌的关联性检验

下表记录了 400 人的吸烟状态与肺癌诊断结果:

	肺癌	无肺癌	合计
吸烟	60	140	200
不吸烟	20	180	200
合计	80	320	400

研究问题: 吸烟与肺癌是否独立?

在独立性假设下, 每个单元格的期望频数为 $E_{ij} = (\text{行合计} \times \text{列合计})/n$:

$$E_{11} = \frac{200 \times 80}{400} = 40, \quad E_{12} = \frac{200 \times 320}{400} = 160,$$

$$E_{21} = \frac{200 \times 80}{400} = 40, \quad E_{22} = \frac{200 \times 320}{400} = 160.$$

计算 χ^2 统计量:

$$\begin{aligned} \chi^2 &= \frac{(60 - 40)^2}{40} + \frac{(140 - 160)^2}{160} + \frac{(20 - 40)^2}{40} + \frac{(180 - 160)^2}{160} \\ &= \frac{400}{40} + \frac{400}{160} + \frac{400}{40} + \frac{400}{160} = 10 + 2.5 + 10 + 2.5 = 25. \end{aligned}$$

自由度为 $(r-1)(c-1) = (2-1)(2-1) = 1$ 。在 $\alpha = 0.05$ 水平, $\chi_{0.05,1}^2 = 3.84$ 。

由于 $\chi^2 = 25 > 3.84$, 我们**拒绝** H_0 ——吸烟与肺癌之间存在显著关联。进一步计算效应量:

$$\phi = \sqrt{\frac{\chi^2}{n}} = \sqrt{\frac{25}{400}} = 0.25,$$

表明吸烟与肺癌之间存在中等强度的正向关联。

例 4: 两种药物疗效比较

某制药公司希望比较药物 A 和药物 B 的疗效, 将 120 名患者随机分配到两组:

	治愈	未治愈	合计
药物 A	45	15	60
药物 B	30	30	60
合计	75	45	120

研究问题：两种药物的治愈率是否有显著差异？

在独立性假设下计算期望频数：

$$E_{11} = \frac{60 \times 75}{120} = 37.5, \quad E_{12} = \frac{60 \times 45}{120} = 22.5,$$

$$E_{21} = \frac{60 \times 75}{120} = 37.5, \quad E_{22} = \frac{60 \times 45}{120} = 22.5.$$

计算 χ^2 统计量：

$$\begin{aligned} \chi^2 &= \frac{(45 - 37.5)^2}{37.5} + \frac{(15 - 22.5)^2}{22.5} + \frac{(30 - 37.5)^2}{37.5} + \frac{(30 - 22.5)^2}{22.5} \\ &= \frac{56.25}{37.5} + \frac{56.25}{22.5} + \frac{56.25}{37.5} + \frac{56.25}{22.5} = 1.5 + 2.5 + 1.5 + 2.5 = 8. \end{aligned}$$

自由度为 $(2 - 1)(2 - 1) = 1$ 。在 $\alpha = 0.05$ 水平， $\chi_{0.05,1}^2 = 3.84$ 。

由于 $\chi^2 = 8 > 3.84$ ，我们**拒绝** H_0 ——两种药物的疗效存在显著差异。药物 A 的治愈率为 75%，显著高于药物 B 的 50%。

5. 4.6 Monte Carlo Methods

有些概率和期望无法解析计算——积分可能没有闭式解，分布可能过于复杂。这时，Monte Carlo 方法提供了一条出路。

核心思想：用随机模拟来近似计算。如果我们可以从某个分布抽样，就可以通过大量重复实验来估计任何期望。

大数定律保证了模拟的收敛性：

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \xrightarrow{P} \mathbb{E}[g(X)]. \quad (4.6.1)$$

这意味着：只要模拟次数足够多，样本均值可以任意接近真实期望。

接受-拒绝算法：当目标分布 $f(x)$ 难以直接抽样时，我们可以利用更容易抽样的提议分布 $g(x)$ ：

- (1) 选择提议分布 $g(x)$ ，满足 $f(x) \leq Mg(x)$ （对某个 $M > 1$ ）
- (2) 生成 $Y \sim g$ 和 $U \sim \text{Uniform}(0, 1)$ 独立
- (3) 若 $U \leq f(Y)/(Mg(Y))$ ，接受 $X = Y$ ；否则拒绝，返回步骤 2

接受概率为 $1/M$ 。¹⁶

¹⁶接受-拒绝算法的推导及收敛性证明见附录 section 7.11。

6. 4.7 Bootstrap Methods

核心困境：估计量的抽样分布是统计推断的基础，但这个分布在大多数情况下难以解析计算。例如，样本中位数 $\hat{m}$ 的分布无法用初等函数表达。

Bootstrap 的解决思路既简单又巧妙：**用重抽样近似抽样分布。**

Bootstrap 的核心假设：样本就像总体。如果我们有了一个“好”的样本，为什么不从这个样本中有放回地再次抽样，模拟重复实验的过程？

步骤：

- (1) 从原始样本中有放回地抽取 n 个观测，形成一个 bootstrap 样本 $X_1^*, \dots, X_n^*$
- (2) 计算 bootstrap 复制 $T^* = g(X_1^*, \dots, X_n^*)$
- (3) 重复步骤 1-2 多次（如 $B = 1000$ 次），得到 $T_1^*, \dots, T_B^*$
- (4) 用 $T_1^*, \dots, T_B^*$ 的经验分布近似 T 的抽样分布

percentile bootstrap 置信区间： θ 的 $100(1 - \alpha)\%$ 置信区间为

$$\left[T_{(\alpha B)}^*, T_{((1-\alpha)B)}^* \right]. \quad (4.7.1)$$

直觉：如果样本是总体的良好代表，那么从样本有放回抽样就是在模拟“从总体中抽取样本”的过程。 T^* 的分布反映了 T 的抽样分布的近似。¹⁷

Bootstrap 的强大之处在于它的通用性——几乎任何估计量都可以用 Bootstrap 近似其分布，不需要繁复的数学推导。这使它成为现代统计实践中的重要工具。

Exercises

EXERCISE 4.1. *4.1 Motor Lifetime Data Twenty motors were put on test under a high-temperature setting. The lifetimes in hours of the motors under these conditions are given below. Suppose we assume that the lifetime of a motor under these conditions, X , has a $\Gamma(1, \theta)$ distribution.*

- (a) Obtain a histogram of the data and overlay it with a density estimate. Based on this plot, do you think that the $\Gamma(1, \theta)$ model is credible?
- (b) Assuming a $\Gamma(1, \theta)$ model, obtain the maximum likelihood estimate $\hat{\theta}$ of θ and locate it on your histogram.
- (c) Obtain the sample median of the data. What parameter is it estimating?
- (d) Based on the mle, what is another estimate of the median of X ?

EXERCISE 4.2. *4.2 Baseball Player Weights Here are the weights of 26 professional baseball pitchers. Suppose we assume that the weight of a professional baseball pitcher is normally distributed with mean μ and variance σ^2 .*

- (a) Obtain a histogram of the data. Based on this plot, is a normal probability model credible?

¹⁷Bootstrap 的理论基础及更多细节见附录 section 7.12。

- (b) Obtain the maximum likelihood estimates of μ , σ^2 , σ , and μ/σ .
- (c) Using the binomial model, obtain the maximum likelihood estimate of the proportion p of professional baseball pitchers who weigh over 215 pounds.
- (d) Determine the mle of p assuming that the weight follows the normal probability model $N(\mu, \sigma^2)$.

EXERCISE 4.3. **4.3 Poisson Customer Arrivals** Suppose the number of customers X that enter a store between 9:00 a.m. and 10:00 a.m. follows a Poisson distribution with parameter θ . Suppose a random sample of the number of customers for 10 days results in values: 9, 7, 9, 15, 10, 13, 11, 7, 2, 12.

- (a) Determine the maximum likelihood estimate of θ . Show that it is an unbiased estimator.
- (b) Based on these data, obtain the realization of your estimator. Explain its meaning.

EXERCISE 4.4. **4.4 Verify Likelihood Equations** For Example 4.1.3, verify equations (4.1.4)-(4.1.8).

EXERCISE 4.5. **4.5 Order Statistics Probability** Let $X_1, X_2, \dots, X_n$ be a random sample from a continuous-type distribution.

- (a) Find $P(X_1 \leq X_2)$, $P(X_1 \leq X_2, X_1 \leq X_3)$, $\dots$, $P(X_1 \leq X_i, i = 2, 3, \dots, n)$.
- (b) Suppose the sampling continues until X_1 is no longer the smallest observation. Let Y equal the number of trials (not including X_1) until X_1 is no longer the smallest. Show that $P(Y = y) = \frac{1}{y(y+1)}$, $y = 1, 2, 3, \dots$.
- (c) Compute the mean and variance of Y if they exist.

EXERCISE 4.6. **4.6 Variance of PMF Estimator** Consider the estimator of the pmf in expression (4.1.10). We showed that this estimator is unbiased. Find the variance of the estimator and its mgf.

EXERCISE 4.7. **4.7 Scottish Schoolchildren Eye Colors** The data set on Scottish schoolchildren included the eye colors of the children. The frequencies of their eye colors are: Blue: 2978, Light: 6697, Medium: 7511, Dark: 5175. Use these frequencies to obtain a bar chart and an estimate of the associated pmf.

EXERCISE 4.8. **4.8 MLE of Poisson PMF** Assuming that the data in Example 4.1.6 were drawn from a Poisson distribution with mean λ , obtain the mle of λ and then use it to obtain the mle of the pmf. Compare the mle of the pmf to the nonparametric estimate.

EXERCISE 4.9. **4.9 Nonparametric Density Estimator** Consider the nonparametric estimator of a pdf.

- (a) Obtain its mean and determine the bias of the estimator.

- (b) Obtain the variance of the estimator.

EXERCISE 4.10. [4.10 Brain Data Analysis](#) This data set consists of a sample of brain information recorded on 40 college students. The variables include gender, height, weight, three IQ measurements, and MRI counts.

- (a) Load the rda file and print the MRI data.
- (b) Obtain a histogram of the data. Comment on the shape.
- (c) Overlay the default density estimator. Comment on the shape.
- (d) Obtain the sample mean and standard deviation and overlay the normal pdf with these estimates. Comment on the fit.
- (e) Determine the proportions of the data within 1 and 2 standard deviations of the sample mean.

EXERCISE 4.11. [4.11 Speed of Light Data](#) This is a famous data set on the speed of light recorded by the scientist Simon Newcomb.

- (a) Load the rda file. Discuss the data.
- (b) Obtain a histogram of the data. Comment on the shape.
- (c) Overlay the default density estimator. Comment on the shape.
- (d) Overlay the normal pdf with sample mean and standard deviation. Comment on the fit.
- (e) Determine the proportions of the data within 1 and 2 standard deviations of the sample mean.

EXERCISE 4.12. [4.12 Normal Confidence Intervals](#) Let the observed value of the mean $\bar{X}$ and of the sample variance of a random sample of size 20 from a distribution that is $N(\mu, \sigma^2)$ be 81.2 and 26.5, respectively. Find respectively 90%, 95% and 99% confidence intervals for μ .

EXERCISE 4.13. [4.13 Motor Lifetime –Hogg 4.2.2](#) Consider the data on the lifetimes of motors given in Exercise 4.1.1. Obtain a large sample 95% confidence interval for the mean lifetime of a motor.

EXERCISE 4.14. [4.14 Gamma Distribution –Hogg 4.2.3](#) Suppose we assume that $X_1, X_2, \dots, X_n$ is a random sample from a $\Gamma(1, \theta)$ distribution.

- (a) Show that the random variable $(2/\theta) \sum_{i=1}^n X_i$ has a χ^2 -distribution with $2n$ degrees of freedom.
- (b) Using the random variable in part (a) as a pivot random variable, find a $(1 - \alpha)100\%$ confidence interval for θ .
- (c) Obtain the confidence interval for the data of Exercise 4.1.1.

EXERCISE 4.15. [4.15](#) *Baseball Weight – Hogg 4.2.4* In Example 4.2.4, for the baseball data, find the pooled t 95% confidence interval for the mean difference in weights between the pitchers and hitters.

EXERCISE 4.16. [4.16](#) *Left-handed Players – Hogg 4.2.5* In the baseball data set, it was found that out of 59 baseball players, 15 were left-handed. Construct a 95% approximate confidence interval for p , the proportion of left-handed professional baseball players.

EXERCISE 4.17. [4.17](#) *Sample Size ($\alpha=9$) – Hogg 4.2.6* Let $\bar{X}$ be the mean of a random sample of size n from a distribution that is $N(\mu, 9)$. Find n such that $P(\bar{X} - 1 < \mu < \bar{X} + 1) = 0.90$, approximately.

EXERCISE 4.18. [4.18](#) *CI from Data – Hogg 4.2.7* Let a random sample of size 17 from the normal distribution $N(\mu, \sigma^2)$ yield $\bar{x} = 4.7$ and $s^2 = 5.76$. Determine a 90% confidence interval for μ .

EXERCISE 4.19. [4.19](#) *Sample Size ($\alpha=10$) – Hogg 4.2.8* Let $\bar{X}$ denote the mean of a random sample of size n from a distribution that has mean μ and variance $\sigma^2 = 10$. Find n so that the probability is approximately 0.954 that the random interval $(\bar{X} - 1/2, \bar{X} + 1/2)$ includes μ .

EXERCISE 4.20. [4.20](#) *Normal CI Length – Hogg 4.2.9* Let $X_1, X_2, \dots, X_9$ be a random sample of size 9 from a distribution that is $N(\mu, \sigma^2)$.

- (a) If σ is known, find the length of a 95% confidence interval for μ .
- (b) If σ is unknown, find the expected value of the length of a 95% confidence interval for μ .
- (c) Compare these two answers.

EXERCISE 4.21. [4.21](#) *Prediction Interval – Hogg 4.2.11* Let $X_1, X_2, \dots, X_n, X_{n+1}$ be a random sample of size $n + 1$, $n > 1$, from a distribution that is $N(\mu, \sigma^2)$. Find the constant c so that the statistic $c(\bar{X} - X_{n+1})/S$ has a t -distribution.

EXERCISE 4.22. [4.22](#) *Monte Carlo CI – Hogg 4.2.11* Let $X_1, \dots, X_n$ be a random sample from a $N(0, 1)$ distribution. Simulate m confidence intervals and calculate the proportion that trap 0.

- (a) Set $n = 10$ and $m = 50$. Run the R code and find the proportion of successful confidence intervals.
- (b) Plot the intervals and comment on the variability of the lengths.

EXERCISE 4.23. [4.23](#) *Invariance of CI – Hogg 4.2.12* In Exercise 4.2.11, show that setting $\mu = 0$ and $\sigma = 1$ is without loss of generality.

EXERCISE 4.24. [4.24](#) *Empirical Confidence Level – Hogg 4.2.13* Change the code in the R function `getcis` so that it also returns the vector `ind` where $\text{ind}[i] = 1$ if the i th confidence interval is successful. Show that the empirical confidence level is $\text{mean}(\text{ind})$.

EXERCISE 4.25. [4.25](#) *Gamma CI via CLT – Hogg 4.2.14* Let $\bar{X}$ denote the mean of a random sample of size 25 from a gamma-type distribution with $\alpha = 4$ and $\beta > 0$. Use the Central Limit Theorem to find an approximate 0.954 confidence interval for μ .

EXERCISE 4.26. [4.26](#) *Sample Size for Given Length – Hogg 4.2.15* Let $\bar{x}$ be the observed mean of a random sample of size n from a distribution having mean μ and known variance σ^2 . Find n so that $\bar{x} - \sigma/4$ to $\bar{x} + \sigma/4$ is an approximate 95% confidence interval for μ .

EXERCISE 4.27. [4.27](#) *Binomial Sample Size – Hogg 4.2.16* Assume a binomial model for a certain random variable. If we desire a 90% confidence interval for p that is at most 0.02 in length, find n .

EXERCISE 4.28. [4.28](#) *Poisson Confidence Interval – Hogg 4.2.17* It is known that a random variable X has a Poisson distribution with parameter μ . A sample of 200 observations from this distribution has a mean equal to 3.4. Construct an approximate 90% confidence interval for μ .

EXERCISE 4.29. [4.29](#) *Variance CI via Chi-square – Hogg 4.2.19* Let $X_1, X_2, \dots, X_n$ be a random sample from $N(\mu, \sigma^2)$, where both parameters are unknown.

- (a) Show that $P((n-1)S^2/\sigma^2 < b) = 0.975$ and $P(a < (n-1)S^2/\sigma^2 < b) = 0.95$.
- (b) If $n = 9$ and $s^2 = 7.93$, find a 95% confidence interval for σ^2 .
- (c) If μ is known, how would you modify the procedure?

EXERCISE 4.30. [4.30](#) *Exact Gamma CI – Hogg 4.2.20* Let $X_1, X_2, \dots, X_n$ be a random sample from a gamma distribution with known parameter $\alpha = 3$ and unknown $\beta > 0$. Obtain an exact confidence interval by first obtaining the distribution of $2 \sum_{i=1}^n X_i/\beta$.

EXERCISE 4.31. [4.31](#) *Tack Point-Up – Hogg 4.2.21* When 100 tacks were thrown on a table, 60 of them landed point up. Obtain a 95% confidence interval for the probability that a tack of this type lands point up.

EXERCISE 4.32. [4.32](#) *Two-Sample Normal CI – Hogg 4.2.22* Let two independent random samples, each of size 10, from two normal distributions $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$ yield $\bar{x} = 4.8$, $s_1^2 = 8.64$, $\bar{y} = 5.6$, $s_2^2 = 7.88$. Find a 95% confidence interval for $\mu_1 - \mu_2$.

EXERCISE 4.33. [4.33](#) *Binomial Proportion Diff – Hogg 4.2.23* Let two independent random variables Y_1 and Y_2 with binomial distributions having parameters $n_1 = n_2 = 100$, p_1 and p_2 , be observed to be $y_1 = 50$ and $y_2 = 40$. Determine an approximate 90% confidence interval for $p_1 - p_2$.

EXERCISE 4.34. [4.34](#) *Known Variance Diff – Hogg 4.2.24* Discuss the problem of finding a confidence interval for the difference $\mu_1 - \mu_2$ between the two means of two normal distributions if the variances σ_1^2 and σ_2^2 are known but not necessarily equal.

EXERCISE 4.35. [4.35](#) *Unknown Unequal Variance – Hogg 4.2.25* Discuss the problem when the variances are unknown and unequal. If the variances are unknown but their ratio σ_1^2/σ_2^2 is a known constant k , then a statistic that is a T random variable can again be used. Why?

EXERCISE 4.36. [4.36](#) *Ratio Known Variance – Hogg 4.2.26* Let $X_1, \dots, X_9$ and $Y_1, \dots, Y_{12}$ represent two independent random samples from $N(\mu_1, \sigma_1^2)$ and $N(\mu_2, \sigma_2^2)$. It is given that $\sigma_1^2 = 3\sigma_2^2$, but σ_2^2 is unknown. Define a random variable that has a t -distribution for a 95% confidence interval for $\mu_1 - \mu_2$.

EXERCISE 4.37. [4.37](#) *Sample Size for Mean Diff – Hogg 4.2.27* Let $\bar{X}$ and $\bar{Y}$ be the means of two independent random samples, each of size n , from $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$, where the common variance is known. Find n such that $P(\bar{X} - \bar{Y} - \sigma/5 < \mu_1 - \mu_2 < \bar{X} - \bar{Y} + \sigma/5) = 0.90$.

EXERCISE 4.38. [4.38](#) *Variance Ratio CI – Hogg 4.2.27* Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ be two independent random samples from $N(\mu_1, \sigma_1^2)$ and $N(\mu_2, \sigma_2^2)$. Construct a confidence interval for the ratio σ_1^2/σ_2^2 .

EXERCISE 4.39. [4.39](#) *Exact Binomial CI – Hogg 4.3.1* Recall for the baseball data, 15 out of 59 ballplayers are left-handed. Determine an exact 90% confidence interval for p .

EXERCISE 4.40. [4.40](#) *Asymptotic CI Verification – Hogg 4.3.2* In Example 4.3.2, verify the result for the asymptotic confidence interval for θ .

EXERCISE 4.41. [4.41](#) *Discrete Exact Tack CI – Hogg 4.3.3* In Exercise 4.2.20, find the discrete exact confidence interval for the proportion.

EXERCISE 4.42. [4.42](#) *Poisson Exact CI – Hogg 4.3.4* Suppose $X_1, X_2, \dots, X_{10}$ is a random sample from a Poisson distribution with mean θ . Suppose $n\bar{x} = 5$. Compute the exact 90% confidence interval for θ .

EXERCISE 4.43. [4.43](#) *t -Interval Derivation – Hogg 4.3.5* Consider the same setup as in Example 4.3.1 except now assume that σ^2 is unknown. Set up the equations and derive the t -interval for θ .

EXERCISE 4.44. [4.44](#) *Beta Integral Identity – Hogg 4.3.6* Using Exercise 3.3.22, show that

$$\int_0^p \frac{n!}{(k-1)!(n-k)!} z^{k-1} (1-z)^{n-k} dz = \sum_{w=k}^n \binom{n}{w} p^w (1-p)^{n-w}.$$

EXERCISE 4.45. [4.45](#) *Poisson CDF Identity – Hogg 4.3.7* This exercise obtains a useful identity for the cdf of a Poisson cdf.

(a) Show that

$$\frac{\lambda^n}{\Gamma(n)} \int_1^\infty x^{n-1} e^{-x\lambda} dx = \sum_{j=0}^{n-1} e^{-\lambda} \frac{\lambda^j}{j!}.$$

(b) Obtain the identity used in Example 4.3.3.

EXERCISE 4.46. [4.46](#) *Distribution Quantiles – Hogg 4.4.1* Obtain closed-form expressions for the distribution quantiles based on the exponential and Laplace distributions.

EXERCISE 4.47. [4.47](#) *Potential Outlier Probability – Hogg 4.4.2* Suppose the pdf $f(x)$ is symmetric about 0. Show that the probability of a potential outlier from this distribution is $2F(4q_1)$, where $F^{-1}(0.25) = q_1$. Use this for:

(a) The normal distribution.

(b) The logistic distribution.

(c) The Laplace distribution.

EXERCISE 4.48. [4.48](#) *Data Summary and Outliers – Hogg 4.4.3* Consider the sample of data: 13, 5, 202, 15, 99, 4, 67, 83, 36, 11, 301, 23, 213, 40, 66, 106, 78, 69, 166, 84, 64.

(a) Obtain the five-number summary.

(b) Determine if there are any outliers.

(c) Boxplot the data. Comment.

EXERCISE 4.49. [4.49](#) *Normal Q-Q Plot – Hogg 4.4.4* Consider the data in Exercise 4.4.3. Obtain the normal q-q plot. Does it suggest the underlying distribution is normal? If not, determine a more appropriate distribution.

EXERCISE 4.50. [4.50](#) *Exponential Order Statistic – Hogg 4.4.5* Let $Y_1 < Y_2 < Y_3 < Y_4$ be the order statistics of a random sample of size 4 from the distribution having pdf $f(x) = e^{-x}$, $0 < x < \infty$. Find $P(Y_4 \geq 3)$.

EXERCISE 4.51. [4.51](#) *Continuous Distribution Order Stats – Hogg 4.4.6* Let X_1, X_2, X_3 be a random sample from a distribution having pdf $f(x) = 2x$, $0 < x < 1$.

(a) Compute the probability that the smallest exceeds the median.

(b) Find the correlation between Y_2 and Y_3 .

EXERCISE 4.52. [4.52](#) *Discrete Order Statistic PMF – Hogg 4.4.7* Let $f(x) = 1/6$, $x = 1, 2, 3, 4, 5, 6$, be the pmf of a discrete distribution. Show that the pmf of the smallest observation of a random sample of size 5 is $g_1(y_1) = (7 - y_1)^5/6^5 - (6 - y_1)^5/6^5$, $y_1 = 1, 2, \dots, 6$.

EXERCISE 4.53. [4.53](#) *Independent Transformations – Hogg 4.4.8* Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ denote the order statistics from exponential distribution. Show that $Z_1 = Y_2$ and $Z_2 = Y_4 - Y_2$ are independent.

EXERCISE 4.54. [4.54](#) *Beta Distribution of Order Statistic – Hogg 4.4.9* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics from $\text{uniform}(0,1)$. Show that Y_k has a beta pdf with parameters $\alpha = k$ and $\beta = n - k + 1$.

EXERCISE 4.55. [4.55](#) *Weibull Minimum – Hogg 4.4.10* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics from a Weibull distribution. Find the distribution function and pdf of Y_1 .

EXERCISE 4.56. [4.56](#) *Uniform Range – Hogg 4.4.11* Find the probability that the range of a random sample of size 4 from the uniform distribution is less than $1/2$.

EXERCISE 4.57. [4.57](#) *Ratio of Order Statistics – Hogg 4.4.12* Let $Y_1 < Y_2 < Y_3$ be order statistics from $f(x) = 2x$, $0 < x < 1$. Show that $Z_1 = Y_1/Y_2$, $Z_2 = Y_2/Y_3$, and $Z_3 = Y_3$ are mutually independent.

EXERCISE 4.58. [4.58](#) *Ratio of Observations – Hogg 4.4.13* Suppose a random sample of size 2 is obtained from $f(x) = 2(1 - x)$, $0 < x < 1$. Compute the probability that one sample observation is at least twice as large as the other.

EXERCISE 4.59. [4.59](#) *Midrange Distribution – Hogg 4.4.14* Let $Y_1 < Y_2 < Y_3$ denote order statistics from $\text{uniform}(0,1)$. Let $Z = (Y_1 + Y_3)/2$ be the midrange. Find the pdf of Z .

EXERCISE 4.60. [4.60](#) *Normal Order Stats Expectation – Hogg 4.4.15* Let $Y_1 < Y_2$ denote the order statistics of a random sample of size 2 from $N(0, \sigma^2)$.

(a) Show $E(Y_1) = -\sigma/\sqrt{\pi}$.

(b) Find the covariance of Y_1 and Y_2 .

EXERCISE 4.61. [4.61](#) *Independence Characterizes Exponential – Hogg 4.4.16* Let $Y_1 < Y_2$ be order statistics from a continuous distribution with pdf $f(x) > 0$ for $x \geq 0$. Show that the independence of $Z_1 = Y_1$ and $Z_2 = Y_2 - Y_1$ characterizes the gamma pdf with $\alpha = 1$.

EXERCISE 4.62. [4.62](#) *Conditional Distribution – Hogg 4.4.17* Let $Y_1 < Y_2 < Y_3 < Y_4$ be order statistics from $f(x) = 2x$, $0 < x < 1$.

(a) Find the joint pdf of Y_3 and Y_4 .

(b) Find the conditional pdf of Y_3 given $Y_4 = y_4$.

(c) Evaluate $E(Y_3|y_4)$.

EXERCISE 4.63. [4.63](#) *Triangle Probability – Hogg 4.4.18* Two numbers are selected at random from the interval $(0,1)$. Compute the probability that the three resulting line segments can form a triangle.

EXERCISE 4.64. [4.64](#) *Min and Max Joint PDF – Hogg 4.4.19* Let X and Y be independent with $f(x) = 2x$ and $g(y) = 3y^2$ on $(0, 1)$. Let $U = \min(X, Y)$ and $V = \max(X, Y)$. Find the joint pdf of U and V .

EXERCISE 4.65. [4.65](#) *Joint PDF of Min and Max – Hogg 4.4.20* Let the joint pdf of X and Y be $f(x, y) = 12x(x + y)/7$, $0 < x < 1$, $0 < y < 1$. Let $U = \min(X, Y)$ and $V = \max(X, Y)$. Find the joint pdf of U and V .

EXERCISE 4.66. [4.66](#) *Gini's Mean Difference – Hogg 4.4.21* Let $X_1, X_2, \dots, X_n$ be a random sample. Gini's mean difference is $G = \sum_{j=2}^n \sum_{i=1}^{j-1} |X_i - X_j| / \binom{n}{2}$.

- (a) If $n = 10$, find $a_1, \dots, a_{10}$ so that $G = \sum_{i=1}^{10} a_i Y_i$.
- (b) Show $E(G) = 2\sigma/\sqrt{\pi}$ for normal distribution.

EXERCISE 4.67. [4.67](#) *Exponential Order Stats Properties – Hogg 4.4.22* Let $Y_1 < Y_2 < \dots < Y_n$ be order statistics from exponential distribution.

- (a) Show $Z_1 = nY_1$, $Z_2 = (n-1)(Y_2 - Y_1)$, $Z_3 = (n-2)(Y_3 - Y_2)$, $\dots$, $Z_n = Y_n - Y_{n-1}$ are independent exponentials.
- (b) Demonstrate that all linear functions of Y_i can be expressed as linear functions of independent random variables.

EXERCISE 4.68. [4.68](#) *PERT Distribution – Hogg 4.4.24* In PERT, let X_1, X_2, X_3 be three independent uniform random times. For series completion ($Y = X_1 + X_2 + X_3$) and parallel completion ($Z = \max(X_1, X_2, X_3)$), find their pdfs.

EXERCISE 4.69. [4.69](#) *Sample Size for Extreme Quantile – Hogg 4.4.25* Let Y_n denote the n th order statistic. Find the smallest n for which $P(\xi_{0.9} < Y_n) \geq 0.75$.

EXERCISE 4.70. [4.70](#) *Probability Involving Quantiles – Hogg 4.4.26* Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ denote order statistics of size 5. Compute:

- (a) $P(Y_1 < \xi_{0.5} < Y_5)$
- (b) $P(Y_1 < \xi_{0.25} < Y_3)$
- (c) $P(Y_4 < \xi_{0.80} < Y_5)$

EXERCISE 4.71. [4.71](#) *Median Between Order Stats – Hogg 4.4.27* Compute $P(Y_3 < \xi_{0.5} < Y_7)$ if $Y_1 < \dots < Y_9$ are order statistics of size 9.

EXERCISE 4.72. [4.72](#) *Sample Size for Median Coverage – Hogg 4.4.28* Find the smallest n for which $P(Y_1 < \xi_{0.5} < Y_n) \geq 0.99$.

EXERCISE 4.73. [4.73](#) *Normal Order Stats Interval – Hogg 4.4.30* Let $Y_1 < Y_2$ be order statistics from $N(\mu, \sigma^2)$ with known σ^2 .

- (a) Show $P(Y_1 < \mu < Y_2) = 1/2$ and compute $E(Y_2 - Y_1)$.
- (b) Find c such that $P(\bar{X} - c\sigma < \mu < \bar{X} + c\sigma) = 1/2$.

EXERCISE 4.74. [4.74](#) *Selection Algorithm –Hogg 4.4.31* Let $y_1 < y_2 < y_3$ be observed order statistics. A statistician is given these values in random order and wants to select the largest. She looks at the first but refuses it and then takes the second if larger than the first, else takes the third. Show this algorithm has probability $1/2$ of selecting the largest.

EXERCISE 4.75. [4.75](#) *Motor Median CI –Hogg 4.4.32* Refer to Exercise 4.1.1. Using expression (4.4.10), obtain a confidence interval for the median lifetime of a motor.

EXERCISE 4.76. [4.76](#) *Power Function of Test –Hogg 4.5.1* Show that the approximate power function given in expression (4.5.12) is strictly increasing. Show the test has approximate size α for testing $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$.

EXERCISE 4.77. [4.77](#) *Darwin Data t-Test –Hogg 4.5.2* For the Darwin data, verify that the Student t -test statistic is 2.15.

EXERCISE 4.78. [4.78](#) *Neyman-Pearson Test –Hogg 4.5.3* Let X have pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$. To test $H_0 : \theta = 1$ against $H_1 : \theta = 2$, use critical region $C = \{(x_1, x_2) : x_1 x_2 \geq 3/4\}$. Find the power function.

EXERCISE 4.79. [4.79](#) *Binomial Significance Level –Hogg 4.5.4* Let X have binomial distribution with $n = 10$ and $p = 1/4$ or $1/2$. Test $H_0 : p = 1/2$ vs $H_1 : p = 1/4$ by rejecting if $X_1 \leq 3$. Find significance level and power.

EXERCISE 4.80. [4.80](#) *Exponential LR Test –Hogg 4.5.5* Let X_1, X_2 be a sample from $f(x; \theta) = (1/\theta)e^{-x/\theta}$. Reject $H_0 : \theta = 2$ if $f(x_1; 2)f(x_2; 2)/[f(x_1; 1)f(x_2; 1)] \leq 1/2$. Find significance level and power when H_0 is false.

EXERCISE 4.81. [4.81](#) *Power Curve Sketch –Hogg 4.5.6* Consider tests Test 1 and Test 2. For Test A, reject H_0 if $S \leq k_A$; for Test B, reject if $S \leq k_B$. If Test A has higher significance level, show Test A has higher power.

EXERCISE 4.82. [4.82](#) *Tire Life Test –Hogg 4.5.7* Let tire life $X \sim N(\theta, 5000^2)$. Test $H_0 : \theta = 30000$ vs $H_1 : \theta > 30000$. Determine n and c so that $\gamma(30000) = 0.01$ and $\gamma(35000) = 0.98$.

EXERCISE 4.83. [4.83](#) *Poisson Power Function –Hogg 4.5.9* Let X have Poisson distribution. Test $H_0 : \theta = 1/2$ vs $H_1 : \theta < 1/2$. With $n = 12$, reject if $Y = \sum X_i \leq 2$. Graph the power function and determine significance level.

EXERCISE 4.84. [4.84](#) *Binomial Sample Size –Hogg 4.5.10* Let $Y \sim \text{binomial}(n, p)$. Test $H_0 : p = 1/2$ vs $H_1 : p > 1/2$. Find n and c so that $\gamma(1/2) = 0.10$ and $\gamma(2/3) = 0.95$.

EXERCISE 4.85. [4.85](#) *Uniform Max Test –Hogg 4.5.11* Let $Y_1 < Y_2 < Y_3 < Y_4$ be order statistics from $f(x; \theta) = 1/\theta$, $0 < x < \theta$. Test $H_0 : \theta = 1$ vs $H_1 : \theta > 1$ by rejecting if $Y_4 \geq c$.

- (a) Find c for $\alpha = 0.05$.
- (b) Determine the power function.

EXERCISE 4.86. [4.86](#) *Poisson Test Size – Hogg 4.5.12* Let $X_1, \dots, X_8$ be from Poisson with mean μ . Test $H_0 : \mu = 0.5$ vs $H_1 : \mu > 0.5$ by rejecting if $\sum x_i \geq 8$.

- (a) Show significance level is $1 - \text{ppois}(7, 4)$.
- (b) Determine $\gamma(0.75)$, $\gamma(1)$, $\gamma(1.25)$.

EXERCISE 4.87. [4.87](#) *Tennis Serve Hypothesis – Hogg 4.5.13* Let p be probability that first serve is good. Test $H_0 : p = 0.40$ vs $H_1 : p > 0.40$ with $n = 25$. Reject if $Y \geq 13$.

- (a) Show $\alpha = 1 - \text{pbinom}(12, 25, 0.4)$.
- (b) Find β when $p = 0.60$.

EXERCISE 4.88. [4.88](#) *Bernoulli Power Comparison – Hogg 4.5.14* Let S be number of successes in $n = 40$ Bernoulli trials. Test $H_0 : p \leq 0.3$ vs $H_1 : p > 0.3$. Compare tests: (1) Reject if $S \geq 16$ and (2) Reject if $S \geq 17$. Determine levels.

EXERCISE 4.89. [4.89](#) *Proportion Power Curve – Hogg 4.5.14* Consider the two-sided test for proportions. Write R code to compute a plot of the power curve.

EXERCISE 4.90. [4.90](#) *Power Function Derivative – Hogg 4.6.1* Consider the power function $\gamma(\mu)$. Show $\gamma'(\mu)$ is strictly negative for $\mu < \mu_0$ and strictly positive for $\mu > \mu_0$.

EXERCISE 4.91. [4.91](#) *Exact Size t-Test – Hogg 4.6.3* Show that the test defined by (4.6.9) has exact size α for testing $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$.

EXERCISE 4.92. [4.92](#) *One vs Two-Sided Power – Hogg 4.6.4* Consider the one-sided t -test and two-sided t -test, both of size α . Show that for $\mu > \mu_0$, the power function of the one-sided test is larger.

EXERCISE 4.93. [4.93](#) *Paired Design Analysis – Hogg 4.7.3* A baseball coach paired 20 members by speed. Data on self vs rival times are given.

- (a) Obtain comparison boxplots. Comment.
- (b) Compute paired t -test and p -value.
- (c) Obtain point estimate and 95% CI for μ_d .
- (d) Conclude.

EXERCISE 4.94. [4.94](#) *AZT Dosage Study – Hogg 4.7.4* A data set concerning the effect of AZT dosages on HIV patients. Compare 300mg and 600mg groups.

- (a) Obtain comparison boxplots.
- (b) Compute two-sample t -test and p -value.
- (c) Obtain point estimate and 95% CI for Δ .
- (d) Conclude.

EXERCISE 4.95. [4.95](#) *Air Quality Comparison – Hogg 4.6.7* Compare suspended particle concentrations between Melbourne and Houston. Test $H_0 : \mu_X = \mu_Y$ against $H_1 : \mu_X < \mu_Y$.

- (a) Define test statistic and critical region.
- (b) Calculate with given statistics.

EXERCISE 4.96. [4.96](#) *Seat Belt Campaign – Hogg 4.6.8* Let p be proportion of drivers using seat belts. After campaign, $y = 104$ out of $n = 590$ wore belts. Was campaign successful?

- (a) Define hypotheses.
- (b) Critical region at $\alpha = 0.01$.
- (c) Determine p -value.

EXERCISE 4.97. [4.97](#) *Variance Test Critical Value – Hogg 4.6.2* Test $H_0 : \sigma^2 = \sigma_0^2$ against $H_1 : \sigma^2 > \sigma_0^2$ using critical region $(n-1)S^2/\sigma_0^2 \geq c$. If $n = 13$ and $\alpha = 0.025$, determine c .

EXERCISE 4.98. [4.98](#) *F-Test Critical Value – Hogg 4.6.10* Test $H_0 : \sigma_1^2 = \sigma_2^2$ against $H_1 : \sigma_1^2 > \sigma_2^2$ using $F \geq c$. If $n = 13$, $m = 11$, and $\alpha = 0.05$, find c .

EXERCISE 4.99. [4.99](#) *Modified Frequency Test – Hogg 4.7.3* Suppose observed frequencies of $A_1, \dots, A_4$ are 20, 30, 92, 105. Calculate the test and report p -value.

EXERCISE 4.100. [4.100](#) *Continuous Interval Test – Hogg 4.7.2* A number is selected from $(0, 2)$. Test hypothesis with $p_{i0} = \int_{A_i} (1/2)(2-x)dx$. For observed frequencies 30, 30, 10, 10, would H_0 be accepted?

EXERCISE 4.101. [4.101](#) *Normal Approximation Test – Hogg 4.7.3* Define sets $A_1 = \{x : -\infty < x \leq 0\}$, $A_i = \{x : i-2 < x \leq i-1\}$ for $i = 2, \dots, 7$, $A_8 = \{x : 6 < x < \infty\}$. Test with frequencies 60, 96, 140, 210, 172, 160, 88, 74.

EXERCISE 4.102. [4.102](#) *Die Casting Test – Hogg 4.7.4* A die was cast $n = 120$ times with frequencies: 1:b, 2:20, 3:20, 4:20, 5:20, 6:40 – b. For what values of b would the hypothesis of unbiased die be rejected at 0.025 level?

EXERCISE 4.103. [4.103](#) *Mendelian Genetics – Hogg 4.7.4* Mendelian theory states probabilities are 9/16, 3/16, 3/16, 1/16 for four classifications. With observed frequencies 86, 35, 26, 13 out of 160, test at $\alpha = 0.01$.

EXERCISE 4.104. [4.104](#) *Teaching Method Comparison – Hogg 4.7.6* Two groups of 100 students each. Test at 5% whether the two distributions are the same.

EXERCISE 4.105. [4.105](#) *Crime and Alcoholism – Hogg 4.7.7* Data on crime type and alcoholic status. Test independence.

- (a) Compute χ^2 -test for independence.
- (b) Use Pearson residuals to determine strongest dependence.
- (c) Confirm with conditional test.

EXERCISE 4.106. [4.106](#) Independence Test – Hogg 4.7.8 180 independent trials with classification into A_1, A_2, A_3 and B_1, B_2, B_3, B_4 . What is smallest k that leads to rejection at $\alpha = 0.05$?

EXERCISE 4.107. [4.107](#) Poisson Goodness of Fit – Hogg 4.7.9 Fit Poisson distribution to data: $x: 0, 1, 2, 3, 3 < x$ with frequencies 20, 40, 16, 18, 6.

- (a) Compute chi-square statistic.
- (b) Degrees of freedom?
- (c) Reject at $\alpha = 0.05$?

EXERCISE 4.108. [4.108](#) MCT Converse – Hogg 4.8.1 Prove the converse of Theorem MCT: Let X have continuous cdf $F(x)$ strictly increasing. Show $Z = F(X)$ has $\text{uniform}(0, 1)$ distribution.

EXERCISE 4.109. [4.109](#) Monte Carlo Log 2 – Hogg 4.8.2 Approximate $\log 2 = \int_0^1 1/(x+1)dx$ using $\text{uniform}(0, 1)$ generator. Write R function and compare with true value.

EXERCISE 4.110. [4.110](#) Normal CDF Approximation – Hogg 4.8.3 Approximate $\int_0^{1.96} (1/\sqrt{2\pi}) \exp\{-t^2/2\}dt$ using Monte Carlo.

EXERCISE 4.111. [4.111](#) Location-Scale Generation – Hogg 4.8.4 Suppose X has pdf $f_X(x) = b^{-1}f((x-a)/b)$. If we can generate from $f(z)$, explain how to generate from $f_X(x)$.

EXERCISE 4.112. [4.112](#) Logistic Distribution Generation – Hogg 4.8.5 Determine a method to generate random observations for the logistic pdf. Write R function and verify with histogram.

EXERCISE 4.113. [4.113](#) Beta Generator – Hogg 4.8.6 Determine a method to generate random observations for $f(x) = 4x^3, 0 < x < 1$. Write R function.

EXERCISE 4.114. [4.114](#) Laplace Inverse CDF – Hogg 4.8.7 Obtain the inverse function of the cdf of the Laplace pdf $f(x) = (1/2)e^{-|x|}$. Write R function.

EXERCISE 4.115. [4.115](#) Extreme Value Generation – Hogg 4.8.8 Determine a method to generate random observations for the extreme-valued pdf $f(x) = \exp\{x - e^x\}$. Write R function.

EXERCISE 4.116. [4.116](#) Cauchy Distribution – Hogg 4.8.9 Determine a method to generate random observations for the Cauchy distribution $f(x) = 1/[\pi(1+x^2)]$. Write R function.

EXERCISE 4.117. [4.117](#) *Weibull Generation – Hogg 4.8.10* Determine a method to generate random observations for the Weibull distribution. Write R function.

EXERCISE 4.118. [4.118](#) *Contaminated Normal Power – Hogg 4.8.11* Write algorithm to simulate power of the test for contaminated normal distribution. Modify R function.

EXERCISE 4.119. [4.119](#) *Logistic Power Simulation – Hogg 4.8.12* Write algorithm to simulate significance level and power for logistic distribution.

EXERCISE 4.120. [4.120](#) *General Inverse CDF – Hogg 4.8.13* For cdf $F(x)$ not strictly increasing, define $F^{-1}(u) = \inf\{x : F(x) \geq u\}$. Let $U \sim \text{uniform}(0, 1)$. Prove $F^{-1}(U)$ has cdf $F(x)$.

EXERCISE 4.121. [4.121](#) *Ratio Maximum – Hogg 4.8.14* Verify the derivative in (4.8.12) and show the function attains maximum at $x = (\alpha - [\alpha])/(1 - b)$.

EXERCISE 4.122. [4.122](#) *Minimum Derivation – Hogg 4.8.15* Derive expression (4.8.14) and show $b = [\alpha]/\alpha$ gives minimum.

EXERCISE 4.123. [4.123](#) *Gamma via Beta – Hogg 4.8.16* Assume $Y_1 \sim \Gamma(\alpha + 1, 1)$, $Y_2 \sim \text{uniform}(0, 1)$. Let $X_1 = Y_1 Y_2^{1/\alpha}$ and $X_2 = Y_2$. Show $X_1 \sim \Gamma(\alpha, 1)$.

EXERCISE 4.124. [4.124](#) *Ratio Derivative – Hogg 4.8.17* Show the derivative of the ratio in (4.8.10) is $-x \exp\{-x^2/2\}(x^2 - 1)$ with critical values ± 1 .

EXERCISE 4.125. [4.125](#) *Beta Distribution Generation – Hogg 4.8.18* Consider accept-reject algorithm for beta distribution. Show X has beta distribution with parameters α and β .

EXERCISE 4.126. [4.126](#) *Marsaglia-Bray Normal – Hogg 4.8.19* Consider the Marsaglia-Bray algorithm for generating normal random variables. Show X_1 and X_2 are iid $N(0, 1)$.

EXERCISE 4.127. [4.127](#) *Bootstrap CI for Mean – Hogg 4.9.1* Use the R function `percentboot` to obtain a bootstrap 95% confidence interval for the mean concentration. Compare with t -CI.

EXERCISE 4.128. [4.128](#) *Bootstrap Sample Properties – Hogg 4.9.2* Let $x_1^*, \dots, x_n^*$ be a bootstrap sample drawn with replacement.

(a) Show x_i^* are iid with common cdf $\hat{F}_n$.

(b) Show $E(x_i^*) = \bar{x}$.

(c) If n odd, show $\text{median}\{x_i^*\} = x_{(n+1)/2}$.

(d) Show $V(x_i^*) = n^{-1} \sum (x_i - \bar{x})^2$.

EXERCISE 4.129. [4.129](#) *Gamma Bootstrap CI – Hogg 4.9.3* Let $X_1, \dots, X_n \sim \Gamma(1, \beta)$.

(a) Show $(2n\bar{X}/(\chi_{2n}^2)^{(1-\alpha/2)}, 2n\bar{X}/(\chi_{2n}^2)^{(\alpha/2)})$ is exact CI for β .

(b) Show 90% CI for data is (64.99, 136.69).

EXERCISE 4.130. [4.130](#) *Bootstrap Median CI – Hogg 4.9.4* Suppose we want to estimate the median using sample median. Obtain 90% bootstrap percentile CI. Did it trap the true median?

EXERCISE 4.131. [4.131](#) *Bootstrap t-Interval – Hogg 4.9.5* Suppose $X_1, \dots, X_n \sim N(\mu, \sigma^2)$. Show the pivot $t = (\bar{X} - \mu)/(S/\sqrt{n})$ leads to CI.

EXERCISE 4.132. [4.132](#) *Standardized Bootstrap CI – Hogg 4.9.6* Consider bootstrap pivot $t^* = (\bar{x}^* - \bar{x})/(s^*/\sqrt{n})$.

- (a) Rewrite percentile CI algorithm using t^* .
- (b) Find 90% CI for data in Example 4.9.3.
- (c) Compare with nonstandardized CI.

EXERCISE 4.133. [4.133](#) *Bootstrap Median Test – Hogg 4.9.7* Consider algorithm for two-sample bootstrap test based on difference in medians.

- (a) Rewrite algorithm for median.
- (b) Obtain bootstrap test.
- (c) Compare p-value with 0.063.

EXERCISE 4.134. [4.134](#) *Two-Sample t-Test Value – Hogg 4.9.8* Consider data of Example 4.9.2. Show $t = 0.93$ with p-value 0.18.

EXERCISE 4.135. [4.135](#) *Bootstrap Two-Sided Test – Hogg 4.9.9* In Example 4.9.3, test $H_0 : \mu = 90$ vs $H_1 : \mu \neq 90$.

- (a) Determine bootstrap p-value.
- (b) Rewrite R program.
- (c) Compute p-value with 3000 bootstraps.

EXERCISE 4.136. [4.136](#) *Permutation Test – Hogg 4.9.10* Consider permutation test for two-sample problem.

- (a) For $x' = (10, 15, 21)$ and $y' = (20, 25, 30)$, determine p-value.
- (b) Approximate permutation test with 3000 resamples.
- (c) Probability of distinct samples?

EXERCISE 4.137. [4.137](#) *Bootstrap z Distribution – Hogg 4.9.11* Let z^* be drawn from discrete distribution with mass n^{-1} at $z_i = x_i - \bar{x} + \mu_0$. Determine $E(z^*)$ and $V(z^*)$.

EXERCISE 4.138. [4.138](#) *Bootstrap t-Test Value – Hogg 4.9.12* For Example 4.9.3, show $t = 0.84$ and p-value is 0.20.

EXERCISE 4.139. [4.139](#) *Bootstrap Median Test – Hogg 4.9.13* For Example 4.9.3, obtain bootstrap test based on medians for $H_0 : \mu = 90$ vs $H_1 : \mu > 90$.

EXERCISE 4.140. **4.140** *Darwin Experiment Bootstrap – Hogg 4.9.14* Consider Darwin's experiment on *Zea mays*.

- (a) Obtain bootstrap test keeping pairing intact.
 (b) Write R program and compare p -value.

本章小结

核心概念：

- **统计量**：样本的函数，不依赖未知参数
- **点估计**：MLE、矩估计；无偏性、偏差
- **置信区间**：参数的合理取值范围；宽度随样本量增大而减小
- **假设检验**：第一类和第二类错误的权衡

重要公式：

场景	置信区间/检验统计量
正态均值、已知 σ	$\bar{X} \pm z_{\alpha/2}\sigma/\sqrt{n}$
正态均值、未知 σ	$\bar{X} \pm t_{\alpha/2, n-1}S/\sqrt{n}$
正态方差	$\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}$
单样本 Z 检验	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$
单样本 t 检验	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$
拟合优度 χ^2	$\chi^2 = \sum \frac{(O-E)^2}{E} \approx \chi^2(k-1)$

7. 附录：公式推导

7.1. 通用 MLE 推导. 背景：最大似然估计的通用推导框架。

核心思想：MLE 选择使似然函数最大化的参数值。在正则条件下，MLE 满足似然方程 $\frac{\partial l(\theta)}{\partial \theta} = 0$ 。

渐近性质（不证）：在温和条件下， $\hat{\theta}$ 具有以下渐近性质：

- (1) **一致性**： $\hat{\theta} \xrightarrow{P} \theta$
- (2) **渐近正态性**： $\sqrt{n}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, I(\theta)^{-1})$ ，其中 $I(\theta)$ 是 Fisher 信息量
- (3) **渐近有效性**：方差达到 Cramér-Rao 下界

这些性质使 MLE 成为现代统计推断的基石。

7.2. 指数分布 MLE 的推导. 背景：设 $X_1, \dots, X_n \sim \text{Exp}(\theta)$ ，即 $f(x) = \theta^{-1} \exp\{-x/\theta\}$ ， $x > 0$ 。

目标：求使似然函数最大化的 θ 值。

推导步骤：

1. 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta^{-1} \exp\{-x_i/\theta\} = \theta^{-n} \exp\{-\theta^{-1} \sum_{i=1}^n x_i\}.$$

2. 对数似然函数为

$$l(\theta) = -n \log \theta - \theta^{-1} \sum_{i=1}^n x_i.$$

3. 求导并设为零：

$$\frac{\partial l(\theta)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i = 0.$$

4. 解得

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

5. 验证这是最大值（二阶导数为负）：

$$\frac{\partial^2 l(\theta)}{\partial \theta^2} = \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^n x_i = -\frac{n}{\theta^2} < 0.$$

结论： $\hat{\theta} = \bar{X}$ 是 θ 的 MLE。由于 $\mathbb{E}(X) = \theta$ ，故它也是无偏的。

7.3. 二项分布 MLE 的推导. 背景： 设 $X \sim \text{Bernoulli}(\theta)$ ，对于随机样本 $X_1, \dots, X_n$ 。

目标： 求 θ 的 MLE。

推导步骤：

1. 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}.$$

2. 对数似然函数为

$$l(\theta) = \left(\sum_{i=1}^n x_i \right) \log \theta + \left(n - \sum_{i=1}^n x_i \right) \log(1 - \theta).$$

3. 求导并设为零：

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{\sum x_i}{\theta} - \frac{n - \sum x_i}{1 - \theta} = 0.$$

4. 解得

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

结论： 样本均值（样本比例）是 θ 的 MLE，也是无偏估计。

7.4. 正态分布 MLE 的推导. 背景： 设 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，对于随机样本。

目标： 求 μ 和 σ^2 的 MLE。

推导步骤：

1. 对数似然函数为

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2.$$

2. 对 μ 求偏导并设为零:

$$\frac{\partial l}{\partial \mu} = -\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu} = \bar{x}.$$

3. 对 σ 求偏导并设为零 (先代入 $\hat{\mu}$):

$$\frac{\partial l}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \bar{x})^2 = 0 \implies \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

注意: $\hat{\sigma}^2$ 是有偏的, 因为

$$\mathbb{E}[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2.$$

无偏估计为 $S^2 = \frac{n}{n-1} \hat{\sigma}^2$ 。

7.5. 置信区间推导汇总. 背景: 置信区间构造的核心思想是找枢轴量。

枢轴量的定义: 设 $Q = q(X_1, \dots, X_n; \theta)$ 。如果 Q 的分布不依赖于 θ , 则称 Q 为枢轴量。

构造步骤:

- (1) 找一个枢轴量 Q
- (2) 确定 a, b 使得 $\mathbb{P}(a \leq Q \leq b) = 1 - \alpha$
- (3) 解不等式得到 θ 的置信区间

7.6. 正态均值置信区间 (已知方差) 的推导. 背景: 设 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, 其中 σ^2 已知, 推导 μ 的置信区间。

已知条件:

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- 标准化的随机变量 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$

目标: 找到 L 和 U 使得 $\mathbb{P}(L \leq \mu \leq U) = 1 - \alpha$

推导步骤:

1. 由标准正态分布的对称性:

$$\mathbb{P}(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha.$$

2. 代入 Z 的表达式:

$$\mathbb{P}\left(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha.$$

3. 利用不等式的代数运算:

$$\mathbb{P}\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

4. 因此置信区间为:

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

关键洞察: 区间以 $\bar{X}$ 为中心, 宽度为 $2z_{\alpha/2}\sigma/\sqrt{n}$, 随 $\sqrt{n}$ 减小。

7.7. 正态均值置信区间（未知方差）的推导. 背景：设 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ ，其中 σ^2 未知，用 S^2 估计。

已知条件：

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$
- $\bar{X}$ 与 S^2 独立

目标：推导 μ 的置信区间

推导步骤：

1. 构造枢轴量：

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

2. 可以证明 $T \sim t(n-1)$ 。

3. 给定置信水平 $1 - \alpha$ ：

$$\mathbb{P}(-t_{\alpha/2, n-1} \leq T \leq t_{\alpha/2, n-1}) = 1 - \alpha.$$

4. 代入 T 并解出 μ ：

$$\mathbb{P}\left(\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}\right) = 1 - \alpha.$$

5. 因此置信区间为：

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}\right].$$

与已知方差情形的比较：用 S 替代 σ ，用 t 分位数替代 z 分位数。由于 t 分布比正态分布更重尾，区间更宽，反映了用样本方差代替总体方差的不确定性。

7.8. 方差置信区间的推导. 背景：推导正态分布方差 σ^2 的置信区间。

已知条件： $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$

推导步骤：

1. 由卡方分布的性质：

$$\mathbb{P}\left(\chi_{1-\alpha/2, n-1}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{\alpha/2, n-1}^2\right) = 1 - \alpha.$$

2. 解出 σ^2 ：

$$\mathbb{P}\left(\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}\right) = 1 - \alpha.$$

3. 因此置信区间为：

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}\right].$$

7.9. 假设检验的推导. 背景: 正态均值检验的推导。**已知方差情形:**

1. 在 $H_0: \mu = \mu_0$ 下, $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ 。
2. 拒绝域为 $Z > z_\alpha$ (单侧) 或 $|Z| > z_{\alpha/2}$ (双侧)。
3. p 值定义为观察到比当前样本更极端结果的概率。

未知方差情形:

1. 在 $H_0: \mu = \mu_0$ 下, $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ 。
2. 拒绝域为 $|T| > t_{\alpha/2, n-1}$ 。
3. p 值由 t 分布计算。

7.10. 卡方统计量极限分布的推导. 背景: 拟合优度 χ^2 统计量的极限分布推导。**推导步骤:**

1. 在 H_0 下, $O_i \sim \text{Binomial}(n, p_{i0})$, 因此 $\mathbb{E}(O_i) = E_i = np_{i0}$, $\text{var}(O_i) = np_{i0}(1-p_{i0})$ 。
2. 标准化: $Z_i = (O_i - E_i)/\sqrt{E_i}$ 。
3. 可以证明 Z_i 近似服从 $\mathcal{N}(0, 1-p_{i0})$, 且协方差矩阵不是单位矩阵 (因为 $\sum O_i = n$ 是约束)。
4. 因此

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \approx \chi^2(k-1).$$

自由度减 1 是因为约束 $\sum O_i = n$ 。**7.11. 蒙特卡洛方法的推导. 背景: 接受-拒绝算法的推导和收敛性分析。****逆 CDF 方法:**

定理: 如果 $U \sim \text{Uniform}(0, 1)$, F 是连续分布函数, 则 $X = F^{-1}(U)$ 的分布函数为 F 。

证明: 设 $X = F^{-1}(U)$, 即 $X \leq x$ 当且仅当 $U \leq F(x)$ 。因此

$$\mathbb{P}(X \leq x) = \mathbb{P}(U \leq F(x)) = F(x).$$

证毕。

接受-拒绝算法:

1. 每次迭代的接受概率为

$$\mathbb{P}(\text{接受}) = \int \frac{f(y)}{Mg(y)} g(y) dy = \frac{1}{M} \int f(y) dy = \frac{1}{M}.$$

2. 因此平均接受次数为 M 。
3. 效率与 M 成反比。

收敛性: 由大数定律, 接受的样本确实来自 $f(x)$ 。

7.12. Bootstrap 的理论基础. 背景：Bootstrap 的理论基础。

核心假设：样本的经验分布函数 $\hat{F}_n$ 是真实分布 F 的良好估计。

Bootstrap 分布：

$$T^* \mid X_1, \dots, X_n \approx T \mid X_1, \dots, X_n$$

其中 $\approx$ 表示“分布近似”。

误差分析：

Bootstrap 的误差来源：

(1) 抽样变异性：由 B 的有限性引入

(2) 代理误差：由 $\hat{F}_n$ 逼近 F 引入

当样本量 n 足够大时，这两种误差都可以控制。

偏差校正 Bootstrap：

如果 $\hat{\theta}$ 有系统性偏差 ($\mathbb{E}[\hat{\theta}] \neq \theta$)，则 percentile bootstrap 区间可能有偏差。偏差校正因子：

$$\hat{a} = \Phi^{-1} \left(\frac{\#\{\hat{\theta}_b^* < \hat{\theta}\}}{B} \right).$$

偏差校正的置信区间为 $[\theta_{\alpha_1}^*, \theta_{\alpha_2}^*]$ ，其中 $\alpha_1 = \Phi(2\hat{a} + z_\alpha)$ ， $\alpha_2 = \Phi(2\hat{a} - z_\alpha)$ 。

CHAPTER 5

Asymptotic Theory

Chapter 5 Overview

在前四章中，我们建立了描述概率分布和统计推断的理论框架。现在我们面临一个根本性问题：

当样本量趋向无穷大时，统计量的行为如何？

这个问题——即**渐近理论 (asymptotic theory)**——是现代统计学的核心。在实际应用中，我们往往无法获得精确的有限样本分布，但通过渐近分析，我们可以理解统计量在大样本下的行为。

本章介绍三种关键的收敛概念和中心极限定理：

- **依概率收敛** (Convergence in Probability)：统计量越来越接近参数真值
- **依分布收敛** (Convergence in Distribution)：统计量的分布越来越接近某个极限分布
- **中心极限定理** (Central Limit Theorem)：样本均值标准化后趋向正态分布

这三种收敛是渐近统计学的基石。依概率收敛保证估计量的一致性 (**consistency**)；依分布收敛结合中心极限定理，使得我们能够对大样本下的统计推断进行近似计算；而 Slutsky 定理和 Δ 方法则提供了处理统计量函数的通用工具。

本章路线图：依概率收敛 $\rightarrow$ 依分布收敛 $\rightarrow$ 中心极限定理 $\rightarrow$ 多元扩展 $\rightarrow$ Δ 方法

1. 5.1 Convergence in Probability

1.1. 收敛性的定义。本节，我们形式化地描述随机变量序列 X_n “接近”另一个随机变量 X 的方式。

为什么需要收敛性？ 在统计中，我们通常不知道总体的精确分布，但希望知道当样本量增大时，估计量是否越来越准确。收敛性正是描述这种“越来越准确”的数学语言。

DEFINITION 5.1 (依概率收敛)。设 X_n 是一列随机变量， X 是定义在同一样本空间上的随机变量。若对所有 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}[|X_n - X| \geq \epsilon] = 0,$$

或等价地，

$$\lim_{n \rightarrow \infty} \mathbb{P}[|X_n - X| < \epsilon] = 1,$$

则称 X_n 依概率收敛到 X ，记作

$$X_n \xrightarrow{P} X.$$

直观理解：无论你设定多小的误差界 ϵ ，当 n 足够大时， X_n 与 X 的差异超过 ϵ 的概率可以任意小。

统计中的特殊情况：在统计学中，渐近随机变量 X 往往是常数——即所有概率质量集中在某个常数 a 上的退化分布。此时记 $X_n \xrightarrow{P} a$ 。

例：数列收敛是依概率收敛的特殊情况 (习题 5.1.1)：若 a_n 是普通数列（可视为退化的随机变量），则 $a_n \rightarrow a$ 等价于 $a_n \xrightarrow{P} a$ 。

1.2. 弱大数定律。展示依概率收敛的一个经典方法是使用 Chebyshev 不等式。

EXAMPLE 5.1 (弱大数定律 (WLLN)). 设 X_n 是 *iid* 随机变量序列，具有共同均值 μ 和有限方差 σ^2 。令 $\bar{X}_n = n^{-1} \sum_{i=1}^n X_i$ 。则

$$\bar{X}_n \xrightarrow{P} \mu.$$

证明：由例 2.8.1， $\bar{X}_n$ 的均值和方差分别为 μ 和 σ^2/n 。因此，由 Chebyshev 不等式，对 $\epsilon > 0$ ，

$$\mathbb{P}[|\bar{X}_n - \mu| \geq \epsilon] = \mathbb{P}[|\bar{X}_n - \mu| \geq (\epsilon\sqrt{n}/\sigma)(\sigma/\sqrt{n})] \leq \frac{\sigma^2}{n\epsilon^2} \rightarrow 0. \quad (5.1.1)$$

意义：这个定理表明，当 $n \rightarrow \infty$ 时，样本均值 $\bar{X}_n$ 的概率质量越来越集中在 μ 附近。从某种意义上看，当 n 足够大时， $\bar{X}_n$ “接近” μ 。¹

强化的注记：在更高级的课程中，可以证明强大数定律——它只需要每个随机变量有有限均值 μ （不要求方差存在）。这说明强大数定律是“一阶矩定理”，而弱大数定律需要二阶矩存在。

1.3. 依概率收敛的性质。以下定理表明，依概率收敛在线性运算下是封闭的。

THEOREM 5.1 (和的收敛性). 若 $X_n \xrightarrow{P} X$ 且 $Y_n \xrightarrow{P} Y$ ，则 $X_n + Y_n \xrightarrow{P} X + Y$ 。

证明：由三角不等式，

$$|X_n + Y_n - (X + Y)| \leq |X_n - X| + |Y_n - Y|.$$

对 $\epsilon > 0$ ，有

$$\mathbb{P}[|X_n + Y_n - (X + Y)| \geq \epsilon] \leq \mathbb{P}[|X_n - X| \geq \epsilon/2] + \mathbb{P}[|Y_n - Y| \geq \epsilon/2] \rightarrow 0. \quad (5.1.2)$$

THEOREM 5.2 (常数乘积的收敛性). 若 $X_n \xrightarrow{P} X$ 且 a 是常数，则 $aX_n \xrightarrow{P} aX$ 。

证明：若 $a = 0$ ，结论显然。若 $a \neq 0$ ，

$$\mathbb{P}[|aX_n - aX| \geq \epsilon] = \mathbb{P}[|X_n - X| \geq \epsilon/|a|] \rightarrow 0. \quad (5.1.3)$$

THEOREM 5.3 (连续函数变换). 若 $X_n \xrightarrow{P} a$ 且实函数 g 在 a 处连续，则 $g(X_n) \xrightarrow{P} g(a)$ 。

¹弱大数定律的完整推导见附录 section 5.1。

证明：由于 g 在 a 处连续，对 $\epsilon > 0$ ，存在 $\delta > 0$ ，使得若 $|x - a| < \delta$ ，则 $|g(x) - g(a)| < \epsilon$ 。因此

$$\mathbb{P}[|g(X_n) - g(a)| \geq \epsilon] \leq \mathbb{P}[|X_n - a| \geq \delta] \rightarrow 0. \quad (5.1.4)$$

重要推论：由该定理，若 $X_n \xrightarrow{P} a$ ，则：

$$X_n^2 \xrightarrow{P} a^2, \quad \frac{1}{X_n} \xrightarrow{P} \frac{1}{a} \quad (a \neq 0), \quad \sqrt{X_n} \xrightarrow{P} \sqrt{a} \quad (a \geq 0).$$

THEOREM 5.4 (乘积的收敛性). 若 $X_n \xrightarrow{P} X$ 且 $Y_n \xrightarrow{P} Y$ ，则 $X_n Y_n \xrightarrow{P} XY$ 。

证明：利用恒等式 $2X_n Y_n = X_n^2 + Y_n^2 - (X_n - Y_n)^2$ ，结合上述结果可得。²

1.4. 5.1.1 抽样与统计量. 考虑随机变量 X ，其 pdf (或 pmf) 为 $f(x; \theta)$ ，其中 $\theta \in \Omega$ 是未知参数。例如：

- $X \sim N(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$
- $X \sim \Gamma(1, \beta)$, $\beta > 0$ 未知

设 $X_1, X_2, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本 (即 iid)。我们称统计量 $T = T(X_1, \dots, X_n)$ 为**估计量 (estimator)**。

两个关键性质：

- (1) **无偏性 (Unbiasedness):** $E(T) = \theta$
- (2) **一致性 (Consistency):** $T_n \xrightarrow{P} \theta$

DEFINITION 5.2 (一致性估计量). 设 X 是具有 cdf $F(x; \theta)$ 的随机变量， $\theta \in \Omega$ 。设 $X_1, \dots, X_n$ 是来自该分布的样本， T_n 是统计量。若

$$T_n \xrightarrow{P} \theta,$$

则称 T_n 是 θ 的**一致估计量 (consistent estimator)**。

注：一致性是估计量最重要的性质之一——如果估计量随着样本量增大都不能接近真实参数，那它就是一个“糟糕”的估计量。无偏性则不能保证这一点。例如，有偏估计量 $V = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是一致的 (有偏但偏差随 $n \rightarrow \infty$ 消失)，而 S^2 是无偏的。

EXAMPLE 5.2 (样本方差的一致性). 设 $X_1, \dots, X_n$ 是来自均值为 μ 、方差为 σ^2 的分布的随机样本。在例 2.8.7 中，我们证明了样本方差 S_n^2 是 σ^2 的无偏估计。

进一步，假设 $E[X_1^4] < \infty$ (有限四阶矩)，则 $S_n^2 \xrightarrow{P} \sigma^2$ 。

证明思路：由弱大数定律， $\bar{X}_n \xrightarrow{P} \mu$ ， $\frac{1}{n} \sum X_i^2 \xrightarrow{P} E(X_1^2)$ 。利用

$$S_n^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum X_i^2 - \bar{X}_n^2 \right) \xrightarrow{P} E(X_1^2) - \mu^2 = \sigma^2. \quad (5.1.5)$$

因此，样本标准差 $S_n \xrightarrow{P} \sigma$ 也是一致的。³

²乘积收敛性的完整证明见附录 section 5.2。

³样本方差一致性的完整推导见附录 section 5.3。

EXAMPLE 5.3 (均匀分布最大值的收敛). 设 $X_1, \dots, X_n \sim \text{Uniform}(0, \theta)$, θ 未知。令 $Y_n = \max X_1, \dots, X_n$ 。

Y_n 的 cdf 为 (习题 5.1.4)

$$F_{Y_n}(t) = \begin{cases} 0, & t \leq 0 \\ (t/\theta)^n, & 0 < t \leq \theta \\ 1, & t > \theta \end{cases} \quad (5.1.6)$$

由此可得 $Y_n \xrightarrow{P} \theta$, 即样本最大值是 θ 的一致估计。注意, 虽然 $E(Y_n) = \frac{n}{n+1}\theta$ (有偏), 但 $(n+1)/n \cdot Y_n$ 是无偏且一致的。⁴

2. 5.2 Convergence in Distribution

上一节我们介绍了依概率收敛的概念。利用这个概念, 我们可以形式化地说统计量收敛到参数。但“有多接近”? 我们能否量化估计的误差? 本节介绍的依分布收敛与前述结果结合, 给出了这些问题的肯定答案。

DEFINITION 5.3 (依分布收敛). 设 X_n 是一列随机变量, X 是一随机变量。设 F_{X_n} 和 F_X 分别是 X_n 和 X 的 cdf。设 $C(F_X)$ 表示 F_X 的所有连续点集合。若

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x), \quad \forall x \in C(F_X),$$

则称 X_n 依分布收敛到 X , 记作

$$X_n \xrightarrow{D} X.$$

注: 在统计学和概率论中, 依分布收敛常称为**弱收敛 (weak convergence)**。

简化记号: 若 $X_n \xrightarrow{D} X$, 其中 $X \sim N(0, 1)$, 我们可以简短地写作

$$X_n \xrightarrow{D} N(0, 1). \quad (5.2.1)$$

为什么只要求在 F_X 的连续点收敛? 考虑一个简单例子: X_n 所有概率质量集中在 $1/n$, X 所有质量集中在 0。则在 F_X 的间断点 0 处, $\lim F_{X_n}(0) = 0 \neq 1 = F_X(0)$; 但在所有其他点, 两者的 CDF 收敛。因此 $X_n \xrightarrow{D} X$ 。

EXAMPLE 5.4 (样本均值的退化分布). 设 $\bar{X}_n$ 的 cdf 为

$$F_n(\bar{x}) = \int_{-\infty}^{\bar{x}} \frac{1}{\sqrt{1/n}\sqrt{2\pi}} e^{-nw^2/2} dw.$$

令 $v = \sqrt{n}w$, 有

$$F_n(\bar{x}) = \int_{-\infty}^{\sqrt{n}\bar{x}} \frac{1}{\sqrt{2\pi}} e^{-v^2/2} dv.$$

⁴均匀分布最大值的详细分析见附录 section 5.4。

当 $n \rightarrow \infty$,

$$\lim_{n \rightarrow \infty} F_n(\bar{x}) = \begin{cases} 0, & \bar{x} < 0 \\ \frac{1}{2}, & \bar{x} = 0 \\ 1, & \bar{x} > 0 \end{cases} \quad (5.2.2)$$

这正是集中在 $\bar{x} = 0$ 的退化分布。因此 $\bar{X}_n$ 依分布收敛到该退化分布。⁵

EXAMPLE 5.5 (t 分布趋近正态分布). 设 T_n 服从自由度为 n 的 t 分布。其 cdf 为

$$F_n(t) = \int_{-\infty}^t \frac{\Gamma[(n+1)/2]}{\sqrt{\pi n} \Gamma(n/2)} \frac{1}{(1+y^2/n)^{(n+1)/2}} dy. \quad (5.2.3)$$

由 Lebesgue 控制收敛定理, 可以交换极限和积分次序。计算表明

$$\lim_{n \rightarrow \infty} F_n(t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} e^{-y^2/2} dy,$$

即标准正态分布的 cdf 。因此 $T_n \xrightarrow{D} N(0, 1)$ 。⁶

EXAMPLE 5.6 (均匀分布最大值的渐近指数分布). 回顾例 5.1.2: $Y_n = \max X_1, \dots, X_n$, 其中 $X_i \sim \text{Uniform}(0, \theta)$ 。考虑 $Z_n = n(\theta - Y_n)$ 。

对 $t \in (0, n\theta)$, 利用 Y_n 的 cdf , 可得

$$\mathbb{P}[Z_n \leq t] = 1 - \left(1 - \frac{t/\theta}{n}\right)^n \rightarrow 1 - e^{-t/\theta}. \quad (5.2.4)$$

因此 $Z_n \xrightarrow{D} \Gamma(1, \theta)$ (指数分布)。这是一个典型的“最大值标准化后收敛到指数分布”的例子。⁷

2.1. 依概率收敛与依分布收敛的关系.

THEOREM 5.5 (依概率收敛推出依分布收敛). 若 $X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{D} X$ 。

证明梗概: 设 x 是 F_X 的连续点。对 $\epsilon > 0$,

$$F_{X_n}(x) = \mathbb{P}[X_n \leq x] \leq \mathbb{P}[X \leq x + \epsilon] + \mathbb{P}[|X_n - X| \geq \epsilon].$$

令 $n \rightarrow \infty$, 再令 $\epsilon \rightarrow 0$, 利用 $X_n \xrightarrow{P} X$ 可得上确界收敛到 $F_X(x)$ 。类似地可得到下界。⁸

注: 反过来一般不成立。但若极限 X 是常数, 则两者等价。

THEOREM 5.6 (常数情形下两种收敛等价). 若 $X_n \xrightarrow{D} b$ (常数), 则 $X_n \xrightarrow{P} b$ 。

THEOREM 5.7 (和的极限分布). 设 $X_n \xrightarrow{D} X$ 且 $Y_n \xrightarrow{P} 0$ 。则 $X_n + Y_n \xrightarrow{D} X$ 。

⁵该例子的详细分析见附录 section 5.5。

⁶该证明利用了 Stirling 公式, 见附录 section 5.6。

⁷均匀分布最大值的完整推导见附录 section 5.7。

⁸完整证明见附录 section 5.8。

应用场景：若难以直接证明 $X_n \xrightarrow{D} X$ ，但容易证明 $Y_n \xrightarrow{D} X$ 且 $X_n - Y_n \xrightarrow{P} 0$ ，则 $X_n = Y_n + (X_n - Y_n) \xrightarrow{D} X$ 。

THEOREM 5.8 (连续函数变换保持依分布收敛). 设 $X_n \xrightarrow{D} X$ 且 g 是支撑上的连续函数，则 $g(X_n) \xrightarrow{D} g(X)$ 。

重要应用：若 $Z_n \xrightarrow{D} Z \sim N(0, 1)$ ，则 $Z_n^2 \xrightarrow{D} \chi^2(1)$ (因为 $Z^2 \sim \chi^2(1)$)。

THEOREM 5.9 (Slutsky 定理). 设 X_n, X, A_n, B_n 是随机变量, a, b 是常数。若 $X_n \xrightarrow{D} X$, $A_n \xrightarrow{P} a$, $B_n \xrightarrow{P} b$ ，则

$$A_n + B_n X_n \xrightarrow{D} a + bX. \quad (5.2.5)$$

核心思想：依分布收敛允许与依概率收敛的随机变量相乘——这是中心极限定理应用中最重要工具。⁹

2.2. 5.2.1 有界概率。 另一个有用的概念是随机变量序列的**概率有界性**。

DEFINITION 5.4 (有界概率). 称随机变量序列 X_n 概率有界，若对所有 $\epsilon > 0$ ，存在常数 $B_\epsilon > 0$ 和整数 N_ϵ ，使得

$$n \geq N_\epsilon \Rightarrow \mathbb{P}[|X_n| \leq B_\epsilon] \geq 1 - \epsilon. \quad (5.2.6)$$

直观理解：概率有界意味着序列的概率质量不会“逃逸”到无穷。

EXAMPLE 5.7 (标准正态分布是有界概率). 设 $X \sim N(0, 1)$ 。对 $\epsilon > 0$ ，可以找到 η 使得 $\mathbb{P}[|X| \leq \eta] \geq 1 - \epsilon$ 。这是因为正态分布的尾部概率可以任意小。¹⁰

THEOREM 5.10 (依分布收敛蕴含概率有界). 若 $X_n \xrightarrow{D} X$ ，则 X_n 概率有界。

EXAMPLE 5.8 (有界但不依分布收敛). 令 $n = 2m$ (偶数) 时 $X_{2m} = 2 + 1/(2m)$; $n = 2m - 1$ (奇数) 时 $X_{2m-1} = 1 + 1/(2m)$ 。则偶数子序列依分布收敛到常数 2，奇数子序列依分布收敛到常数 1。整个序列不依分布收敛 (两个极限不同)，但所有项都在 $[1, 5/2]$ 中，因此是概率有界的。

THEOREM 5.11 (乘积的收敛性). 设 X_n 概率有界, $Y_n \xrightarrow{P} 0$ 。则 $X_n Y_n \xrightarrow{P} 0$ 。

证明梗概：由概率有界性, $|X_n|$ 在大概率下被某个常数控制。再由 $Y_n \rightarrow 0$ 的概率，可得上确界收敛到 0。¹¹

⁹Slutsky 定理的详细证明见附录 section 5.9。

¹⁰该性质的证明见附录 ??。

¹¹完整证明见附录 section 5.10。

2.3. 5.2.2 Δ 方法. Δ 方法是处理统计量函数渐近分布的强大工具。

背景: 在渐近理论中, 我们常需确定一个函数的分布。设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 如何求 $g(X_n)$ 的渐近分布?

关键工具——Taylor 展开: 若 $g(x)$ 在 x 处可微, 则

$$g(y) = g(x) + g'(x)(y - x) + o(|y - x|). \quad (5.2.7)$$

记号 o_p 和 O_p (小 o 和大 O 的概率版本):

$$Y_n = o_p(X_n) \iff \frac{Y_n}{X_n} \xrightarrow{P} 0, \quad Y_n = O_p(X_n) \iff \frac{Y_n}{X_n} \text{ 概率有界}. \quad (5.2.8)$$

EXAMPLE 5.9 (Δ 方法的应用). 设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, g 在 θ 处可微且 $g'(\theta) \neq 0$ 。则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2). \quad (5.2.9)$$

这称为 Δ 方法。¹²

EXAMPLE 5.10 (卡方分布标准化). 在例 5.2.7 中, 我们证明了 $Z_n \sim \chi^2(n)$, 则

$$Y_n = \frac{Z_n - n}{\sqrt{2n}} \xrightarrow{D} N(0, 1). \quad (5.2.10)$$

利用 Δ 方法, 取 $g(t) = \sqrt{t}$, 则 $W_n = g(Z_n/(\sqrt{2}n)) = (Z_n/(\sqrt{2}n))^{1/2}$ 的渐近分布为

$$\sqrt{n}[W_n - 1/2^{1/4}] \xrightarrow{D} N(0, 2^{-3/2}). \quad (5.2.11)$$

这在实践中非常有用, 例如当我们对卡方变量的标准差感兴趣时。¹³

2.4. 5.2.3 矩母函数技巧. 矩母函数 (MGF) 提供了一种确定渐近分布的系统方法。

THEOREM 5.12 (MGF 收敛定理). 设 X_n 是随机变量序列, 每个 X_n 的 mgf $M_{X_n}(t)$ 在 $-h < t < h$ 上存在。设 X 的 mgf $M(t)$ 在 $|t| \leq h_1 \leq h$ 上存在。若

$$\lim_{n \rightarrow \infty} M_{X_n}(t) = M(t), \quad |t| \leq h_1,$$

则 $X_n \xrightarrow{D} X$ 。

应用: 二项分布趋近泊松分布. 设 $Y_n \sim b(n, p)$, 其中 $p = \mu/n$ (μ 固定)。则

$$M_{Y_n}(t) = [1 + p(e^t - 1)]^n = \left[1 + \frac{\mu(e^t - 1)}{n}\right]^n \rightarrow e^{\mu(e^t - 1)},$$

这正是参数为 μ 的泊松分布的 mgf。因此当 n 大、 p 小时, 二项分布可用泊松分布近似。¹⁴

应用: 卡方分布标准化趋近正态. 设 $Z_n \sim \chi^2(n)$, 可计算其 mgf 并证明

$$\frac{Z_n - n}{\sqrt{2n}} \xrightarrow{D} N(0, 1). \quad (5.2.12)$$

¹² Δ 方法的完整推导见附录 section 5.11。

¹³卡方分布 Δ 方法的详细推导见附录 ??。

¹⁴该近似的误差分析和更精确的估计见附录 section 5.12。

3. 5.3 Central Limit Theorem

本节介绍统计学中最重要、最优雅的定理之一——中心极限定理 (CLT)。

背景：在第 3 章中，我们知道若 $X_1, \dots, X_n$ 来自均值为 μ 、方差为 σ^2 的正态分布，则

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \sim N(0, 1)$$

对每个正整数 n 都成立。

中心极限定理的核心发现：这一定理告诉我们，即使总体分布不是正态，只要满足某些温和条件（有限方差），上述统计量在大样本下仍然近似服从标准正态分布！

[中心极限定理 (CLT)] 设 $X_1, X_2, \dots, X_n$ 是来自均值为 μ 、正方差为 σ^2 的分布的随机样本。则随机变量

$$Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}$$

依分布收敛到标准正态随机变量：

$$Y_n \xrightarrow{D} N(0, 1). \quad (5.3.1)$$

实践意义：当 n 足够大（通常 $n \geq 30$ ），我们可以将 $\bar{X}$ 近似为 $N(\mu, \sigma^2/n)$ ，从而计算概率近似值。¹⁵

等价的表述：

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{D} N(0, \sigma^2). \quad (5.3.2)$$

这一表述在实践中更方便使用。

EXAMPLE 5.11 (均匀分布样本均值的概率). 设 $\bar{X}$ 是来自 $\text{Uniform}(0, 1)$ 分布、样本量为 75 的样本均值。对于该分布， $\mu = 1/2$ ， $\sigma^2 = 1/12$ 。

要计算 $P(0.45 < \bar{X} < 0.55)$ ，直接计算需要知道 $\bar{X}$ 的精确分布（由 75 个不同多项式片段组成的复杂函数）。但由 CLT，

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \approx N(0, 1),$$

因此

$$P(0.45 < \bar{X} < 0.55) \approx \Phi(1.5) - \Phi(-1.5) = 0.8663. \quad (5.3.3)$$

这个近似相当准确，尽管 $\bar{X}$ 的精确分布并不正态！¹⁶

EXAMPLE 5.12 (二项分布的正态近似). 设 $Y_n \sim b(n, p)$ 。则 $Y_n = \sum_{i=1}^n X_i$ ，其中 $X_i \sim \text{Bernoulli}(p)$ 。由 CLT，

$$\frac{Y_n - np}{\sqrt{np(1-p)}} = \frac{\sqrt{n}(\bar{X}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1). \quad (5.3.4)$$

因此， Y_n 近似服从 $N(np, np(1-p))$ 。

¹⁵中心极限定理的完整证明（包括 MGF 方法）见附录 section 5.13。

¹⁶均匀分布样本均值概率的详细计算见附录 section 5.14。

图 5.3.1 展示了 $b(10, 1/2)$ 的二项分布与 $N(5, 5/2)$ 正态近似的对比。即使 $n = 10$, 拟合效果已相当不错。

连续性校正: 对于离散分布, 通常使用 ± 0.5 的校正来提高近似精度。例如,

$$P(Y = 48, 49, 50, 51, 52) = P(47.5 < Y < 52.5). \quad (5.3.5)$$

EXAMPLE 5.13 (大样本比例推断). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(p)$, $\hat{p} = \bar{X}$. 则

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1 - \hat{p})/n}} \xrightarrow{D} N(0, 1). \quad (5.3.6)$$

这是大样本置信区间和假设检验 (第 4 章) 的基础。¹⁷

EXAMPLE 5.14 (卡方检验的渐近分布). 由 CLT 和定理 5.2.4,

$$\left(\frac{Y_n - np}{\sqrt{np(1-p)}} \right)^2 \xrightarrow{D} \chi^2(1). \quad (5.3.7)$$

这正是第 4 章中拟合优度 χ^2 检验的理论基础。¹⁸

EXAMPLE 5.15 (Δ 方法与函数变换). 设 $X_1, \dots, X_n$ 是来自均值为 μ 、方差为 σ^2 的分布的随机样本。由 CLT,

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{D} N(0, \sigma^2). \quad (5.3.8)$$

对连续变换 g , 由 Δ 方法,

$$\sqrt{n}[g(\bar{X}) - g(\mu)] \xrightarrow{D} N(0, \sigma^2[g'(\mu)]^2). \quad (5.3.9)$$

应用: 反正弦变换. 在二项情形 ($X_i \sim \text{Bernoulli}(p)$), 为了获得渐近方差与 p 无关的估计, 取 $g(p) = \arcsin(\sqrt{p})$, 则

$$\sqrt{n}[\arcsin(\sqrt{\bar{X}}) - \arcsin(\sqrt{p})] \xrightarrow{D} N(0, 1/4). \quad (5.3.10)$$

这一变换在方差稳定化中有重要应用。¹⁹

4. 5.4 Extensions to Multivariate Distributions

本节简要讨论随机向量序列的渐近概念。

为什么需要多元扩展? 在多参数统计中, 我们经常同时估计多个参数, 需要知道这些估计量的联合渐近分布。

记 $\mathbf{v} \in \mathbb{R}^p$ 的 Euclidean 范数为

$$\|\mathbf{v}\| = \sqrt{\sum_{i=1}^p v_i^2}. \quad (5.4.1)$$

¹⁷比例推断的详细讨论见附录 section 5.15。

¹⁸卡方检验的详细推导见附录 ??。

¹⁹方差稳定化变换的详细讨论见附录 section 5.16。

DEFINITION 5.5 (随机向量的依概率收敛). 设 $\mathbf{X}_n$ 是一列 p 维随机向量, $\mathbf{X}$ 是随机向量。若对所有 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}[\|\mathbf{X}_n - \mathbf{X}\| \geq \epsilon] = 0,$$

则称 $\mathbf{X}_n \xrightarrow{P} \mathbf{X}$ 。

[向量收敛等价于分量收敛] $\mathbf{X}_n \xrightarrow{P} \mathbf{X}$ 当且仅当对每个 $j = 1, \dots, p$, $X_{nj} \xrightarrow{P} X_j$ 。

应用: 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 是 iid 随机向量, 均值向量为 $\boldsymbol{\mu}$, 协方差矩阵为 $\boldsymbol{\Sigma}$ 。则样本均值向量

$$\bar{\mathbf{X}}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \xrightarrow{P} \boldsymbol{\mu}. \quad (5.4.2)$$

样本协方差矩阵 $\mathbf{S} \xrightarrow{P} \boldsymbol{\Sigma}$ 。

EXAMPLE 5.16 (多元中心极限定理). 设 $\mathbf{X}_n$ 是 iid 随机向量序列, 均值向量为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ (正定)。则

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.3)$$

证明思路: 将问题转化为一元情形。设 $\mathbf{t} \in \mathbb{R}^p$, 则 $\mathbf{t}'\mathbf{X}_i$ 是均值为 $\mathbf{t}'\boldsymbol{\mu}$ 、方差为 $\mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}$ 的随机变量。对一维随机变量应用 CLT, 再利用 mgf 的性质可得多元情形。²⁰

EXAMPLE 5.17 (线性变换的正态性). 设 $\mathbf{X}_n \xrightarrow{D} N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。则对任意常数矩阵 $\mathbf{A}$ ($m \times p$) 和向量 $\mathbf{b}$ (m 维),

$$\mathbf{A}\mathbf{X}_n + \mathbf{b} \xrightarrow{D} N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}'). \quad (5.4.4)$$

多元 Δ 方法: 设

$$\sqrt{n}(\mathbf{X}_n - \boldsymbol{\mu}_0) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}),$$

$g: \mathbb{R}^p \rightarrow \mathbb{R}^k$ 是可微变换, Jacobian 矩阵 $\mathbf{B} = \partial g / \partial \mathbf{x}$ 在 $\boldsymbol{\mu}_0$ 处非奇异。则

$$\sqrt{n}(g(\mathbf{X}_n) - g(\boldsymbol{\mu}_0)) \xrightarrow{D} N_k(\mathbf{0}, \mathbf{B}_0 \boldsymbol{\Sigma} \mathbf{B}_0'). \quad (5.4.5)$$

Exercises

EXERCISE 5.1. 5.1 Sequence Convergence Let a_n be a sequence of real numbers (degenerate random variables). Let a be a real number. Show that $a_n \rightarrow a$ is equivalent to $a_n \xrightarrow{P} a$.

EXERCISE 5.2. 5.2 Binomial Convergence Let $Y_n \sim b(n, p)$.

(a) Prove that Y_n/n converges in probability to p . This is one form of the weak law of large numbers.

(b) Prove that $1 - Y_n/n$ converges in probability to $1 - p$.

(c) Prove that $(Y_n/n)(1 - Y_n/n)$ converges in probability to $p(1 - p)$.

²⁰多元 CLT 的完整证明见附录 section 5.17。

EXERCISE 5.3. **5.3 Variance Convergence** Let W_n denote a random variable with mean μ and variance b/n^p , where $p > 0$, μ , and b are constants (not functions of n). Prove that W_n converges in probability to μ .

Hint: Use Chebyshev's inequality.

EXERCISE 5.4. **5.4 Uniform Maximum CDF** Derive the cdf given in expression (5.1.6).

EXERCISE 5.5. **5.5 Sample Median Convergence** Consider the R function `consistmean` which produces the plot shown in Figure 5.1.1. Obtain a similar plot for the sample median when the distribution sampled is the $N(0, 1)$ distribution. Compare the mean and median plots.

EXERCISE 5.6. **5.6 Uniform Maximum Plot** Write an R function that obtains a plot similar to Figure 5.1.1 for the situation described in Example 5.1.2. For the plot choose $\theta = 10$.

EXERCISE 5.7. **5.7 Shifted Exponential Minimum** Let $X_1, \dots, X_n$ be iid random variables with common pdf

$$f(x) = \begin{cases} e^{-(x-\theta)} & x > \theta, -\infty < \theta < \infty \\ 0 & \text{elsewhere.} \end{cases} \quad (5.1.3)$$

This pdf is called the shifted exponential. Let $Y_n = \min X_1, \dots, X_n$. Prove that $Y_n \rightarrow \theta$ in probability by first obtaining the cdf of Y_n .

EXERCISE 5.8. **5.8 Ratio Convergence** Using the assumptions behind the confidence interval given in expression (4.3.3), show that

$$\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} / \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \xrightarrow{P} 1.$$

EXERCISE 5.9. **5.9 Shifted Exponential Mean** For Exercise 5.1.7, obtain the mean of Y_n . Is Y_n an unbiased estimator of θ ? Obtain an unbiased estimator of θ based on Y_n .

EXERCISE 5.10. **5.10 Normal Sample Mean Limit** Let $\bar{X}_n$ denote the mean of a random sample of size n from a distribution that is $N(\mu, \sigma^2)$. Find the limiting distribution of $\bar{X}_n$.

EXERCISE 5.11. **5.11 Exponential Minimum Limit** Let Y_1 denote the minimum of a random sample of size n from a distribution that has pdf $f(x) = e^{-(x-\theta)}$, $\theta < x < \infty$, zero elsewhere. Let $Z_n = n(Y_1 - \theta)$. Investigate the limiting distribution of Z_n .

EXERCISE 5.12. **5.12 Maximum Limit Distribution** Let Y_n denote the maximum of a random sample of size n from a distribution of the continuous type that has cdf $F(x)$ and pdf $f(x) = F'(x)$. Find the limiting distribution of $Z_n = n[1 - F(Y_n)]$.

EXERCISE 5.13. **5.13** *Second Minimum Limit* Let Y_2 denote the second smallest item of a random sample of size n from a distribution of the continuous type that has cdf $F(x)$ and pdf $f(x) = F'(x)$. Find the limiting distribution of $W_n = nF(Y_2)$.

EXERCISE 5.14. **5.14** *No Limiting Distribution* Let the pmf of Y_n be $p_n(y) = 1$, $y = n$, zero elsewhere. Show that Y_n does not have a limiting distribution. (In this case, the probability has "escaped" to infinity.)

EXERCISE 5.15. **5.15** *Normal Sum No Limit* Let $X_1, X_2, \dots, X_n$ be a random sample of size n from a distribution that is $N(\mu, \sigma^2)$, where $\sigma^2 > 0$. Show that the sum $Z_n = \sum_{i=1}^n X_i$ does not have a limiting distribution.

EXERCISE 5.16. **5.16** *Gamma Limit* Let X_n have a gamma distribution with parameter $\alpha = n$ and β , where β is not a function of n . Let $Y_n = X_n/n$. Find the limiting distribution of Y_n .

EXERCISE 5.17. **5.17** *Chi-Square Ratio Limit* Let Z_n be $\chi^2(n)$ and let $W_n = Z_n/n^2$. Find the limiting distribution of W_n .

EXERCISE 5.18. **5.18** *Chi-Square Probability* Let X be $\chi^2(50)$. Using the limiting distribution discussed in Example 5.2.7, approximate $P(40 < X < 60)$. Compare your answer with that calculated by R .

EXERCISE 5.19. **5.19** *Poisson Binomial Approximation* Let $p = 0.95$ be the probability that a man, in a certain age group, lives at least 5 years.

- (a) If we are to observe 60 such men and if we assume independence, use R to compute the probability that at least 56 of them live 5 or more years.
 - (b) Find an approximation to the result of part (a) by using the Poisson distribution.
- Hint: Redefine p to be 0.05 and $1 - p = 0.95$.

EXERCISE 5.20. **5.20** *Poisson to Normal* Let the random variable Z_n have a Poisson distribution with parameter $\mu = n$. Show that the limiting distribution of the random variable $Y_n = (Z_n - n)/\sqrt{n}$ is normal with mean zero and variance 1.

EXERCISE 5.21. **5.21** *Normal Sample Chi-Square* Let $\bar{X}_n$ denote the mean of a random sample of size 100 from a distribution that is $\chi^2(50)$. Compute an approximate value of $P(49 < \bar{X} < 51)$.

EXERCISE 5.22. **5.22** *Gamma Sample Mean* Let $\bar{X}_n$ denote the mean of a random sample of size 128 from a gamma distribution with $\alpha = 2$ and $\beta = 4$. Approximate $P(7 < \bar{X} < 9)$.

EXERCISE 5.23. **5.23** *Binomial Probability* Let Y be $b(72, 1/3)$. Approximate $P(22 \leq Y \leq 28)$.

EXERCISE 5.24. **5.24** *Beta Sample Mean* Compute an approximate probability that the mean of a random sample of size 15 from a distribution having pdf $f(x) = 3x^2$, $0 < x < 1$, zero elsewhere, is between $\frac{3}{5}$ and $\frac{4}{5}$.

EXERCISE 5.25. **5.25** *Discrete Sample Sum* Let Y denote the sum of the observations of a random sample of size 12 from a distribution having pmf $p(x) = 1/6$, $x = 1, 2, 3, 4, 5, 6$, zero elsewhere. Compute an approximate value of $P(36 \leq Y \leq 48)$.

Hint: Since the event of interest is $Y = 36, 37, \dots, 48$, rewrite the probability as $P(35.5 < Y < 48.5)$.

EXERCISE 5.26. **5.26** *Binomial Proportion* Let Y be $b(400, 1/5)$. Compute an approximate value of $P(0.25 < Y/400)$.

EXERCISE 5.27. **5.27** *Binomial Point Probability* If Y is $b(100, 1/2)$, approximate the value of $P(Y = 50)$.

EXERCISE 5.28. **5.28** *Sample Size for Proportion* Let Y be $b(n, 0.55)$. Find the smallest value of n such that (approximately) $P(Y/n > 1/2) \geq 0.95$.

EXERCISE 5.29. **5.29** *Tail Probability Approximation* Let $f(x) = 1/x^2$, $1 < x < \infty$, zero elsewhere, be the pdf of a random variable X . Consider a random sample of size 72 from the distribution having this pdf. Compute approximately the probability that more than 50 of the observations of the random sample are less than 3.

EXERCISE 5.30. **5.30** *Rounding Error Approximation* Forty-eight measurements are recorded to several decimal places. Each of these 48 numbers is rounded off to the nearest integer. The sum of the original 48 numbers is approximated by the sum of these integers. If we assume that the errors made by rounding off are iid and have a uniform distribution over the interval $(-1/2, 1/2)$, compute approximately the probability that the sum of the integers is within two units of the true sum.

EXERCISE 5.31. **5.31** *Cube Transformation* We know that $\bar{X}$ is approximately $N(\mu, \sigma^2/n)$ for large n . Find the approximate distribution of $u(\bar{X}) = \bar{X}^3$, provided that $\mu \neq 0$.

EXERCISE 5.32. **5.32** *Variance Stabilization* Let $X_1, X_2, \dots, X_n$ be a random sample from a Poisson distribution with mean μ . Thus, $Y = \sum_{i=1}^n X_i$ has a Poisson distribution with mean $n\mu$. Moreover, $\bar{X} = Y/n$ is approximately $N(\mu, \mu/n)$ for large n . Show that $u(Y/n) = \sqrt{Y/n}$ is a function of Y/n whose variance is essentially free of μ .

EXERCISE 5.33. **5.33** *Proportion CLT* Using the notation of Example 5.3.5, show that equation (5.3.6) is true.

EXERCISE 5.34. **5.34** *Gamma Asymptotics* Assume that $X_1, \dots, X_n$ is a random sample from a $\Gamma(1, \beta)$ distribution. Determine the asymptotic distribution of $\sqrt{n}(\bar{X} - \beta)$. Then find a transformation $g(\bar{X})$ whose asymptotic variance is free of β .

EXERCISE 5.35. **5.35 Multivariate Convergence** Let $\mathbf{X}_n$ be a sequence of p -dimensional random vectors. Show that

$$\mathbf{X}_n \xrightarrow{D} N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \text{ if and only if } \mathbf{a}'\mathbf{X}_n \xrightarrow{D} N_1(\mathbf{a}'\boldsymbol{\mu}, \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a}),$$

for all vectors $\mathbf{a} \in \mathbb{R}^p$.

EXERCISE 5.36. **5.36 Uniform Vector Convergence** Let $X_1, \dots, X_n$ be a random sample from a $\text{Uniform}(a, b)$ distribution. Let $Y_1 = \min X_i$ and let $Y_2 = \max X_i$. Show that $(Y_1, Y_2)'$ converges in probability to the vector $(a, b)'$.

本章小结

核心概念：

- 依概率收敛： $X_n \xrightarrow{P} X$ ，概率质量越来越集中在目标附近
- 依分布收敛： $X_n \xrightarrow{D} X$ ，分布函数在连续点处收敛
- 弱大数定律：样本均值依概率收敛到总体均值
- 中心极限定理：标准化样本均值趋向标准正态分布
- Slutsky 定理：允许依概率收敛的随机变量参与依分布收敛的线性组合
- Δ 方法：处理统计量函数渐近分布的工具
- 一致性：估计量的基本要求， $T_n \xrightarrow{P} \theta$

重要公式：

场景	渐近分布
$\sqrt{n}(\bar{X} - \mu)/\sigma$	$N(0, 1)$ (CLT)
$\bar{X}_n$	$N(\mu, \sigma^2/n)$ (大样本)
$\sqrt{n}(g(\bar{X}) - g(\mu))$	$N(0, \sigma^2[g'(\mu)]^2)$ (Δ 方法)
$\hat{p}$ 样本比例	$N(p, p(1-p)/n)$ (大样本)
$(Y_n - np)/\sqrt{np(1-p)}$	$N(0, 1)$ (二项正态近似)

收敛关系图：

依概率收敛 + 连续函数 $\Rightarrow$ 依概率收敛

依概率收敛 $\Rightarrow$ 依分布收敛

依分布收敛 (常数) $\Leftrightarrow$ 依概率收敛

5. 附录：公式推导

5.1. 弱大数定律的完整证明. 背景 (Background): 弱大数定律 (WLLN) 是最基本的渐近结果之一，说明样本均值依概率收敛到总体均值。

已知条件 (Given):

- $X_1, X_2, \dots, X_n$ 是 iid 随机变量
- $E(X_i) = \mu$
- $\text{Var}(X_i) = \sigma^2 < \infty$
- $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$

目标 (Goal): 证明 $\bar{X}_n \xrightarrow{P} \mu$ 。

推导步骤 (Derivation Steps):

1. 计算 $\bar{X}_n$ 的均值和方差:

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu,$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

2. 对任意 $\epsilon > 0$, 应用 Chebyshev 不等式:

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}.$$

3. 当 $n \rightarrow \infty$ 时, 右边趋于 0, 故

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) = 0.$$

结论: 由定义, $\bar{X}_n \xrightarrow{P} \mu$ 。

5.2. 依概率收敛性质证明. 背景: 证明若 $X_n \xrightarrow{P} X$ 和 $Y_n \xrightarrow{P} Y$, 则 $X_n Y_n \xrightarrow{P} XY$ 。

推导步骤:

1. 利用恒等式:

$$X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2.$$

2. 由定理 5.1.3 (标量乘积收敛) 和定理 5.1.2 (和的收敛), $X_n^2 \xrightarrow{P} X^2$, $Y_n^2 \xrightarrow{P} Y^2$, $(X_n - Y_n)^2 \xrightarrow{P} (X - Y)^2$ 。

3. 因此

$$X_n Y_n \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY.$$

证毕。

5.3. 样本方差一致性的详细推导. 背景: 证明样本方差 S_n^2 是 σ^2 的一致估计量。

已知条件:

- $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$
- $E(X_i^4) < \infty$ (有限四阶矩)

推导步骤:

1. 由弱大数定律:

$$\bar{X}_n \xrightarrow{P} \mu, \quad \frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E(X_1^2).$$

2. 利用恒等式:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right).$$

3. 由连续映射定理 (定理 5.1.4), $\bar{X}_n^2 \xrightarrow{P} \mu^2$ 。

4. 因此

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \xrightarrow{P} E(X_1^2) - \mu^2 = \sigma^2.$$

5. 由于 $\frac{n}{n-1} \rightarrow 1$, 故 $S_n^2 \xrightarrow{P} \sigma^2$ 。

结论: S_n^2 是 σ^2 的一致估计。

5.4. 均匀分布最大值分析. 背景: 分析 $\text{Uniform}(0, \theta)$ 分布最大值的渐近行为。

已知条件: $Y_n = \max X_1, \dots, X_n$, 其中 $X_i \sim \text{Uniform}(0, \theta)$ 。

推导步骤:

1. 求 Y_n 的 CDF:

$$F_{Y_n}(t) = \mathbb{P}(Y_n \leq t) = \mathbb{P}(X_1 \leq t, \dots, X_n \leq t) = [F_X(t)]^n = \left(\frac{t}{\theta}\right)^n,$$

对 $0 < t \leq \theta$ 。

2. 求 Y_n 的 PDF:

$$f_{Y_n}(t) = \frac{d}{dt} F_{Y_n}(t) = \frac{n}{\theta^n} t^{n-1}, \quad 0 < t \leq \theta.$$

3. 计算期望:

$$E(Y_n) = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{n+1} \theta.$$

关键发现: $Y_n \xrightarrow{P} \theta$, 因为对任意 $\epsilon > 0$,

$$\mathbb{P}(|Y_n - \theta| \geq \epsilon) = \mathbb{P}(Y_n \leq \theta - \epsilon) = \left(\frac{\theta - \epsilon}{\theta}\right)^n \rightarrow 0.$$

渐近分布: 标准化后 $n(\theta - Y_n) \xrightarrow{D} \Gamma(1, \theta)$ (见例 5.2.4)。

5.5. 退化分布的例子. 背景: 说明为什么在 CDF 的间断点处不要求收敛。

例子: 设 X_n 所有概率质量集中在 $1/n$, X 所有概率质量集中在 0。

(1) 若 $x < 0$, 则 $F_{X_n}(x) = 0 = F_X(x)$ 。

(2) 若 $x > 0$, 则 $F_{X_n}(x) = 1 = F_X(x)$ 。

(3) 若 $x = 0$ (F_X 的间断点), 则 $F_{X_n}(0) = 0 \neq 1 = F_X(0)$ 。

因此 $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$ 对所有 $x \in C(F_X)$ (即 $x \neq 0$) 成立, 故 $X_n \xrightarrow{D} X$ 。

5.6. Stirling 公式. 背景: Stirling 公式在渐近分析中非常重要。

公式:

$$\Gamma(k+1) \approx \sqrt{2\pi} k^{k+1/2} e^{-k}. \quad (5.2.2)$$

应用: 在例 5.2.3 中, 证明 t 分布趋向标准正态分布时, 需要用到

$$\lim_{n \rightarrow \infty} \frac{\Gamma[(n+1)/2]}{\sqrt{n/2} \Gamma(n/2)} = 1.$$

使用 Stirling 公式:

$$\frac{\Gamma[(n+1)/2]}{\sqrt{n/2} \Gamma(n/2)} \approx \frac{\sqrt{2\pi} (n/2)^{n/2+1/2} e^{-n/2}}{\sqrt{n/2} \sqrt{2\pi} (n/2-1)^{n/2-1/2} e^{-(n/2-1)}} = 1.$$

5.7. 均匀分布到指数分布的极限. 背景：证明 $n(\theta - Y_n) \xrightarrow{D} \Gamma(1, \theta)$ 。

推导：

对 $t > 0$,

$$\mathbb{P}[n(\theta - Y_n) \leq t] = \mathbb{P}[Y_n \geq \theta - t/n] = 1 - F_{Y_n}(\theta - t/n).$$

由 $F_{Y_n}(t) = (t/\theta)^n$ (对 $0 < t \leq \theta$),

$$1 - F_{Y_n}(\theta - t/n) = 1 - \left(\frac{\theta - t/n}{\theta}\right)^n = 1 - \left(1 - \frac{t}{n\theta}\right)^n.$$

令 $n \rightarrow \infty$,

$$\lim_{n \rightarrow \infty} \left(1 - \frac{t}{n\theta}\right)^n = e^{-t/\theta}.$$

因此

$$\lim_{n \rightarrow \infty} \mathbb{P}[n(\theta - Y_n) \leq t] = 1 - e^{-t/\theta},$$

这正是 $\Gamma(1, \theta)$ (指数分布) 的 CDF。

5.8. 依概率收敛推出依分布收敛的证明. 背景：证明定理 5.2.1。

目标：若 $X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{D} X$ 。

推导步骤：

1. 设 x 是 F_X 的连续点。对 $\epsilon > 0$,

$$F_{X_n}(x) = \mathbb{P}[X_n \leq x] = \mathbb{P}[X_n \leq x, |X_n - X| < \epsilon] + \mathbb{P}[X_n \leq x, |X_n - X| \geq \epsilon].$$

2. 第一个概率 $\leq \mathbb{P}[X \leq x + \epsilon]$, 第二个概率 $\leq \mathbb{P}[|X_n - X| \geq \epsilon]$ 。因此

$$F_{X_n}(x) \leq F_X(x + \epsilon) + \mathbb{P}[|X_n - X| \geq \epsilon].$$

3. 取上确界并令 $n \rightarrow \infty$ (利用 $X_n \xrightarrow{P} X$), 再令 $\epsilon \rightarrow 0$ (利用 x 是连续点), 可得

$$\overline{\lim}_{n \rightarrow \infty} F_{X_n}(x) \leq F_X(x).$$

4. 类似地可得

$$\underline{\lim}_{n \rightarrow \infty} F_{X_n}(x) \geq F_X(x).$$

5. 因此 $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$ 。

证毕。

5.9. Slutsky 定理的详细证明. 背景：Slutsky 定理是连接依概率收敛和依分布收敛的关键工具。

定理陈述：若 $X_n \xrightarrow{D} X$, $A_n \xrightarrow{P} a$, $B_n \xrightarrow{P} b$, 则 $A_n + B_n X_n \xrightarrow{D} a + bX$ 。

推导步骤：

1. 首先证明 $B_n X_n \xrightarrow{D} bX$ 。

考虑 $B_n X_n = bX_n + (B_n - b)X_n$ 。由 $B_n \xrightarrow{P} b$, 有 $B_n - b \xrightarrow{P} 0$ 。

2. 由定理 5.2.6 (依分布收敛蕴含概率有界), X_n 概率有界。

3. 应用定理 5.2.7 (概率有界序列与依概率收敛到零的乘积趋于零):

$$(B_n - b)X_n \xrightarrow{P} 0.$$

4. 由定理 5.2.3 (和的极限分布), $bX_n + (B_n - b)X_n \xrightarrow{D} bX$ 。

5. 再考虑 $A_n + B_nX_n = a + bX + (A_n - a) + (B_nX_n - bX)$ 。

由于 $(A_n - a) \xrightarrow{P} 0$ 和 $(B_nX_n - bX) \xrightarrow{P} 0$, 再次应用定理 5.2.3 可得

$$A_n + B_nX_n \xrightarrow{D} a + bX.$$

证毕。

核心洞察: Slutsky 定理允许我们将依概率收敛的随机变量”替换”为其极限常数, 而不影响依分布收敛性。

5.10. 概率有界与乘积收敛的证明. 背景: 证明定理 5.2.7。

目标: 若 X_n 概率有界, $Y_n \xrightarrow{P} 0$, 则 $X_nY_n \xrightarrow{P} 0$ 。

推导步骤:

1. 由概率有界性, 对 $\epsilon > 0$, 存在 B_ϵ 和 N_ϵ 使得

$$n \geq N_\epsilon \Rightarrow \mathbb{P}[|X_n| \leq B_\epsilon] \geq 1 - \epsilon.$$

2. 对任意 $\delta > 0$,

$$\mathbb{P}[|X_nY_n| \geq \delta] = \mathbb{P}[|X_nY_n| \geq \delta, |X_n| \leq B_\epsilon] + \mathbb{P}[|X_nY_n| \geq \delta, |X_n| > B_\epsilon].$$

3. 第一个概率 $\leq \mathbb{P}[|Y_n| \geq \delta/B_\epsilon]$, 第二个概率 $\leq \mathbb{P}[|X_n| > B_\epsilon] \leq \epsilon$ 。

4. 由于 $Y_n \xrightarrow{P} 0$, 当 n 足够大时, 第一个概率 $< \epsilon$ 。

5. 因此对足够大的 n , $\mathbb{P}[|X_nY_n| \geq \delta] \leq 2\epsilon$ 。

由 ϵ 和 δ 的任意性, $X_nY_n \xrightarrow{P} 0$ 。

证毕。

5.11. Δ 方法的完整推导. 背景: Δ 方法提供了一种计算统计量函数渐近分布的系统方法。

定理陈述: 设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, g 在 θ 处可微且 $g'(\theta) \neq 0$ 。则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

推导步骤:

1. 由 Taylor 展开 (带余项):

$$g(X_n) = g(\theta) + g'(\theta)(X_n - \theta) + o_p(|X_n - \theta|).$$

2. 两边乘以 $\sqrt{n}$:

$$\sqrt{n}(g(X_n) - g(\theta)) = g'(\theta)\sqrt{n}(X_n - \theta) + o_p(\sqrt{n}|X_n - \theta|).$$

3. 由假设, $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 故 $\sqrt{n}|X_n - \theta|$ 概率有界。

4. 由 o_p 的定义, $o_p(\sqrt{n}|X_n - \theta|) \xrightarrow{P} 0$ 。

5. 应用 Slutsky 定理（或更精确地，定理 5.2.3），可得

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

证毕。

应用举例：卡方分布的平方根。设 $Z_n \sim \chi^2(n)$ ，则

$$\sqrt{n} \left(\frac{Z_n}{n} - 1 \right) \xrightarrow{D} N(0, 2).$$

取 $g(t) = \sqrt{t}$ ，则 $g'(1) = 1/2$ ，故

$$\sqrt{n}(\sqrt{Z_n/n} - 1) \xrightarrow{D} N(0, 2 \cdot (1/2)^2) = N(0, 1/2).$$

5.12. 二项分布的正态近似误差分析. 背景：二项分布 $b(n, p)$ 在大样本下可用正态分布近似。

误差分析：

设 $Y \sim b(n, p)$ ， $\mu = np$ ， $\sigma^2 = np(1-p)$ 。则

$$Z = \frac{Y - \mu}{\sigma} \xrightarrow{D} N(0, 1).$$

Berry-Esseen 不等式给出了收敛速度的估计：

$$\sup_x |\mathbb{P}(Z \leq x) - \Phi(x)| \leq \frac{C \cdot \rho}{\sigma^3 \sqrt{n}},$$

其中 $\rho = E(|X - \mu|^3)$ ， C 是某个绝对常数（约 0.4748）。

实践意义：当 $np(1-p) \geq 10$ 时，正态近似效果较好。

连续性校正的效果：对于离散分布，使用 ± 0.5 的校正通常可以将误差减少一半。

5.13. 中心极限定理的 MGF 证明. 背景：中心极限定理（CLT）的矩母函数证明。

假设： $X_1, \dots, X_n$ 是 iid 随机变量， $E(X_i) = \mu$ ， $\text{Var}(X_i) = \sigma^2$ ，矩母函数 $M(t) = E(e^{tX})$ 在 0 的邻域内存在。

目标：证明

$$Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \xrightarrow{D} N(0, 1).$$

推导步骤：

1. 考虑 $X_i - \mu$ 的矩母函数 $m(t) = E(e^{t(X_i - \mu)})$ 。则 $m(0) = 1$ ， $m'(0) = 0$ ， $m''(0) = \sigma^2$ 。

2. 由 Taylor 公式，存在 ξ （介于 0 和 t 之间）使得

$$m(t) = 1 + \frac{\sigma^2 t^2}{2} + \frac{[m''(\xi) - \sigma^2] t^2}{2}. \quad (5.3.1)$$

3. Y_n 的矩母函数为

$$M_{Y_n}(t) = E \left[\exp \left(t \frac{\sum X_i - n\mu}{\sqrt{n}\sigma} \right) \right] = [m(t/(\sigma\sqrt{n}))]^n. \quad (5.3.2)$$

4. 将 $t/(\sigma\sqrt{n})$ 代入 (5.3.1)：

$$m \left(\frac{t}{\sigma\sqrt{n}} \right) = 1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2] t^2}{2n\sigma^2},$$

其中 ξ 介于 0 和 $t/(\sigma\sqrt{n})$ 之间。

5. 因此

$$M_{Y_n}(t) = \left[1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2]t^2}{2n\sigma^2} \right]^n.$$

6. 由于 $m''(t)$ 在 0 处连续, 且 $\xi \rightarrow 0$ 当 $n \rightarrow \infty$, 故

$$\lim_{n \rightarrow \infty} [m''(\xi) - \sigma^2] = 0.$$

7. 应用极限定理 (5.2.16):

$$\lim_{n \rightarrow \infty} M_{Y_n}(t) = \lim_{n \rightarrow \infty} \left[1 + \frac{t^2}{2n} \right]^n = e^{t^2/2},$$

这正是 $N(0, 1)$ 的矩母函数。

结论: 由矩母函数收敛定理, $Y_n \xrightarrow{D} N(0, 1)$ 。

证毕。

注: 若不使用矩母函数而使用特征函数, 则证明对所有分布成立 (特征函数总是存在的)。

5.14. 均匀分布样本均值的概率计算. 背景: 计算 $P(0.45 < \bar{X} < 0.55)$ 的近似值。

已知条件:

- $X_i \sim \text{Uniform}(0, 1)$
- $n = 75$
- $\mu = 1/2, \sigma^2 = 1/12$

推导步骤:

1. 由 CLT,

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \approx N(0, 1).$$

2. 标准化:

$$P(0.45 < \bar{X} < 0.55) = P\left(\frac{\sqrt{n}(0.45 - \mu)}{\sigma} < \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} < \frac{\sqrt{n}(0.55 - \mu)}{\sigma}\right).$$

3. 代入数值:

$$\frac{\sqrt{75}(0.5 - 0.5)}{1/\sqrt{12}} = 0, \quad \frac{\sqrt{75}(0.55 - 0.5)}{1/\sqrt{12}} = \sqrt{75} \cdot 0.05 \cdot \sqrt{12} \approx 1.5.$$

4. 因此

$$P(0.45 < \bar{X} < 0.55) \approx \Phi(1.5) - \Phi(-1.5) = 2\Phi(1.5) - 1 \approx 2(0.9332) - 1 = 0.8664.$$

精确值比较: 使用 R 计算精确概率约为 0.864, 近似值 0.866 非常接近。

5.15. 比例推断的详细讨论. 背景：大样本比例推断的理论基础。

设 $X_1, \dots, X_n \sim \text{Bernoulli}(p)$, $\hat{p} = \bar{X}$ 。

推导步骤：

1. 由 CLT,

$$\frac{\sqrt{n}(\hat{p} - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1). \quad (5.3.4)$$

2. 但 p 未知! 用 $\hat{p}$ 替代 p 。需证明

$$\frac{\hat{p}(1-\hat{p})}{p(1-p)} \xrightarrow{P} 1. \quad (5.3.6)$$

3. 由弱大数定律, $\hat{p} \xrightarrow{P} p$, 再由连续映射定理,

$$\hat{p}(1-\hat{p}) \xrightarrow{P} p(1-p).$$

4. 由 Slutsky 定理,

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})/n}} = \frac{\sigma}{\sqrt{\hat{p}(1-\hat{p})}} \cdot \frac{\sqrt{n}(\hat{p} - p)}{\sigma} \xrightarrow{D} N(0, 1). \quad (5.3.7)$$

这正是大样本比例置信区间和假设检验的理论基础。

置信区间： p 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]. \quad (5.3.8)$$

假设检验： 检验 $H_0: p = p_0$ 的检验统计量为

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} \xrightarrow{H_0} N(0, 1). \quad (5.3.9)$$

5.16. 方差稳定化变换. 背景：在例 5.3.7 中, 我们寻求一个变换使渐近方差与参数无关。

问题：设 $X \sim \text{Binomial}(1, p)$, $\hat{p} = \bar{X}$ 。求变换 g 使得 $\text{Var}[\sqrt{n}g(\hat{p})]$ 与 p 无关。

推导步骤：

1. 由 Δ 方法,

$$\text{Var}[\sqrt{n}g(\hat{p})] \approx \sigma^2[g'(p)]^2 = p(1-p)[g'(p)]^2. \quad (5.3.10)$$

2. 要求 $p(1-p)[g'(p)]^2 = c$ (常数), 即

$$g'(p) = \frac{c}{\sqrt{p(1-p)}}. \quad (5.3.11)$$

3. 积分得

$$g(p) = c \int \frac{1}{\sqrt{p(1-p)}} dp = 2c \arcsin(\sqrt{p}) + \text{常数}. \quad (5.3.12)$$

4. 取 $c = 1/2$ 可得最简单的形式 $g(p) = \arcsin(\sqrt{p})$ 。

结论：变换 $g(\hat{p}) = \arcsin(\sqrt{\hat{p}})$ 的渐近方差为 $1/(4n)$, 与 p 无关。²¹

²¹方差稳定化变换的更多应用见 DeGroot 和 Schervish 的《概率与统计》。

5.17. 多元中心极限定理的证明. 背景: 多元中心极限定理说明样本均值向量的标准化形式依分布收敛到多元正态分布。

定理陈述: 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 是 iid 随机向量, 均值向量为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ (正定)。则

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.3)$$

推导步骤:

1. 对任意固定向量 $\mathbf{t} \in \mathbb{R}^p$, 考虑随机变量 $W_i = \mathbf{t}'\mathbf{X}_i$ 。

2. 则 $E(W_i) = \mathbf{t}'\boldsymbol{\mu}$, $\text{Var}(W_i) = \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}$ 。

3. 对 $W_1, \dots, W_n$ 应用一元 CLT:

$$\sqrt{n}(\bar{W}_n - \mathbf{t}'\boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}). \quad (5.4.8)$$

4. 但 $\bar{W}_n = \mathbf{t}'\bar{\mathbf{X}}_n$, 故

$$\sqrt{n}(\mathbf{t}'\bar{\mathbf{X}}_n - \mathbf{t}'\boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}). \quad (5.4.9)$$

5. 由 Cramer-Wold 定理 (若对所有 $\mathbf{t}$, $\mathbf{t}'\mathbf{X}_n \xrightarrow{D} \mathbf{t}'\mathbf{X}$, 则 $\mathbf{X}_n \xrightarrow{D} \mathbf{X}$), 可得

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.10)$$

证毕。

注: Cramer-Wold 定理的证明依赖于特征函数的一致有界性和逆转公式。

CHAPTER 6

Maximum Likelihood Methods

Chapter 6 Overview

在前五章中，我们建立了描述概率分布、进行统计推断的理论框架，并探讨了估计量的一致性和渐近分布。现在我们面临一个根本性问题：

面对观测数据，如何找到“最优”的参数估计方法？

这个问题促使我们发展出统计学中最重要、应用最广泛的估计理论——**最大似然估计 (Maximum Likelihood Estimation, MLE)**。

为什么需要最大似然估计？ 回顾 Chapter 4 的矩估计法，我们发现它虽然直观，但在某些情况下效率较低。最大似然估计则不同——在适当的正则条件下，它不仅是一致的，而且是**渐近有效的 (asymptotically efficient)**，即达到了估计方差的下界。

本章建立一套完整的基于似然的统计推断理论：

- **点估计**：MLE 的定义、性质，以及如何通过似然方程求解
- **方差下界**：Rao-Cramér 不等式揭示任何无偏估计的方差都有下界，而 MLE 渐近达到这个下界
- **假设检验**：似然比检验、Wald 检验、Score 检验构成三大类似然检验方法
- **多参数情形**：将理论推广到参数向量的情形
- **EM 算法**：处理缺失数据或隐变量的强大迭代方法

本章路线图：似然函数 $\rightarrow$ MLE 定义 $\rightarrow$ Rao-Cramér 下界 $\rightarrow$ 渐近有效性 $\rightarrow$ 似然比检验 $\rightarrow$ 多参数扩展 $\rightarrow$ EM 算法

1. 6.1 Maximum Likelihood Estimation

1.1. 似然函数的起源。 在 Chapter 4 中，我们遇到了一个问题：给定数据 $x_1, x_2, \dots, x_n$ ，哪个参数值最“合理”？

这个问题的自然答案是：**使得观测到当前数据的概率最大的参数值**。这就是最大似然估计的核心思想。

设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的 iid 样本，其中 $\theta \in \Omega$ 是未知参数。则样本的联合密度为

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta), \quad \theta \in \Omega. \quad (6.1.1)$$

为什么叫“似然” (Likelihood) 而不是“概率” (Probability)？ 这里的关键在于：概率是关于数据的函数（已知参数，求数据的概率），而似然是关于参数的函数（已知数据，求参数的可能性）。虽然数学形式相同，但解释的角度不同。

定义 $l(\theta) = \log L(\theta)$ 为对数似然函数。使用对数是出于计算便利——乘积变成求和，在求导时更方便。

1.2. MLE 的定义与存在性. 最大似然估计量 $\hat{\theta}$ 是使得似然函数最大化的参数值：

$$\hat{\theta} = \arg \max_{\theta \in \Omega} L(\theta; \mathbf{x}). \quad (6.1.2)$$

直观上，这个估计量代表“最有可能产生观测数据的参数值”。

下面的定理从理论上证明了 MLE 的合理性。

heorem[似然函数的渐近支撑] 设 θ_0 是参数真值，在正则条件 (R0)-(R2) 下，

$$\lim_{n \rightarrow \infty} \mathbb{P}_{\theta_0} [L(\theta_0; \mathbf{X}) > L(\theta; \mathbf{X})] = 1, \quad \forall \theta \neq \theta_0. \quad (6.1.3)$$

heorem

证明思路： 由于 θ_0 是内点，存在领域使得似然函数在该领域内取得最大值。随着 n 增大，似然函数在 θ_0 处超过相邻点的概率趋于 1，因此解序列收敛到 θ_0 。¹

在正则条件下，MLE 可以通过求解似然方程 (likelihood equation) 得到：

$$\frac{\partial l(\theta)}{\partial \theta} = 0. \quad (6.1.4)$$

但要注意：MLE 不唯一存在，且可能没有解析解。

1.3. 经典例子.

EXAMPLE 6.1 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$ ，其中 σ^2 已知， θ 未知。对数似然函数为

$$l(\theta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2.$$

求导并令为零：

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \theta) = \frac{n(\bar{x} - \theta)}{\sigma^2} = 0.$$

解得 $\hat{\theta} = \bar{x}$ 。这是样本均值。

意义： 对于正态分布，样本均值不仅是矩估计量，也是最大似然估计量。

定理 6.1.2 的 Invariance 性质： 若 $\hat{\theta}$ 是 θ 的 MLE，则对任意函数 $g(\theta)$ ， $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE。²

EXAMPLE 6.2 (约束参数空间的 MLE). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$ ，但已知 $\theta \in [0, 1/3]$ 。若样本均值 $\bar{x} > 1/3$ ，则 MLE 为 $\hat{\theta} = 1/3$ 。

这是因为对数似然在 $\theta < \bar{x}$ 时单调递增，所以在约束边界处取得最大值。

启示： 当参数空间有约束时，MLE 可能在边界取得。

¹该定理的完整证明见附录 section 7.1。

²Laplace 分布 MLE 的完整推导见附录 ??。

EXAMPLE 6.3 (Cauchy 分布的 MLE). 设 $X_1, \dots, X_5$ 来自标准 *Cauchy* 分布 $f(x; \theta) = \frac{1}{\pi[1+(x-\theta)^2]}$ 。对于数据 $(-1.94, 0.59, -5.98, -0.08, -0.77)$, MLE 需要数值方法求解。

Cauchy 分布的似然函数无解析解, 需通过数值优化 (如 *Newton* 法) 获得 $\hat{\theta}$ 。这在实际应用中很常见。

注: *Cauchy* 分布不满足某些正则条件, 但其 MLE 仍然是一致的。

1.4. MLE 的一致性. 下面证明在正则条件下, MLE 是真值的相合估计量。

heorem[MLE 的相合性] 在正则条件 (R0)-(R2) 下, 设 $\hat{\theta}_n$ 是似然方程的解序列。则

$$\hat{\theta}_n \xrightarrow{P} \theta_0.$$

heorem

证明思路: 由于 θ_0 是内点, 存在领域使得似然函数在该领域内取得最大值。随着 n 增大, 似然函数在 θ_0 处超过相邻点的概率趋于 1, 因此解序列收敛到 θ_0 。³

这一定理保证了: 在大样本下, MLE 任意接近真值的概率趋于 1。

1.5. Summary of Section 6.1.

- 似然函数 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ 衡量参数 θ 产生观测数据的”可能性”
- MLE $\hat{\theta}$ 最大化似然函数, 是”最可能”产生数据的参数值
- 在正则条件下, MLE 是一致的 ($\hat{\theta}_n \xrightarrow{P} \theta_0$)
- MLE 可以通过求解似然方程 $\partial l(\theta)/\partial \theta = 0$ 得到
- MLE 具有不变性: 若 $\hat{\theta}$ 是 θ 的 MLE, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE

2. 6.2 Rao-Cramér Lower Bound and Efficiency

2.1. 为什么估计量的方差有下界?. 我们已经知道 MLE 是一致的。但这只告诉我们估计量在大样本下趋于真值, 却没有告诉我们收敛的速度有多快。

一个自然的疑问是: 对于给定的分布, 是否存在方差最小的估计量? 方差能小到什么程度?

Rao-Cramér 下界回答了这个问题。

2.2. Fisher 信息量. 在推导下界之前, 我们需要一个关键概念——Fisher 信息量。

设 $X \sim f(x; \theta)$, 定义得分函数 (score function) 为

$$S(X; \theta) = \frac{\partial \log f(X; \theta)}{\partial \theta}. \quad (6.2.1)$$

得分函数的期望为零 (这是正则条件的直接结果):

$$\mathbb{E}_\theta[S(X; \theta)] = 0. \quad (6.2.2)$$

Fisher 信息量定义为得分函数的方差:

³该定理的完整证明见附录 ??。

$$I(\theta) = \text{Var}(S(X; \theta)) = \mathbb{E}_\theta \left[\left(\frac{\partial \log f(X; \theta)}{\partial \theta} \right)^2 \right]. \quad (6.2.3)$$

直观上理解：若 θ 的微小变化会导致密度函数较大的变化，则我们对 θ 的了解就更多，信息量就越大。

等价的计算公式（通常更方便）是

$$I(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta^2} \right]. \quad (6.2.4)$$

对于样本 $X_1, \dots, X_n$ (iid)，Fisher 信息为单个样本信息的 n 倍：

$$I_n(\theta) = nI(\theta). \quad (6.2.5)$$

EXAMPLE 6.4 (Bernoulli 分布的 Fisher 信息). 设 $X \sim \text{Bernoulli}(\theta)$ ，则

$$\log f(x; \theta) = x \log \theta + (1 - x) \log(1 - \theta),$$

$$\frac{\partial \log f}{\partial \theta} = \frac{x}{\theta} - \frac{1 - x}{1 - \theta},$$

$$\frac{\partial^2 \log f}{\partial \theta^2} = -\frac{x}{\theta^2} - \frac{1 - x}{(1 - \theta)^2}.$$

因此

$$I(\theta) = -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta^2} \right] = \frac{1}{\theta} + \frac{1}{1 - \theta} = \frac{1}{\theta(1 - \theta)}.$$

含义：当 θ 接近 0 或 1 时，信息量很大（分布几乎确定）；当 $\theta = 1/2$ 时，信息量最小（最不确定）。

EXAMPLE 6.5 (位置族的 Fisher 信息). 设 $X = \theta + e$ ，其中 e 的密度为 $f(z)$ ，与 θ 无关。则

$$f_X(x; \theta) = f(x - \theta).$$

可以验证，Fisher 信息 $I(\theta)$ 与 θ 无关，仅由误差分布 f 决定。⁴

对于 Laplace 分布 $f(z) = \frac{1}{2}e^{-|z|}$ ，信息 $I(\theta) = 1$ 。

⁴Bernoulli 分布和位置族 Fisher 信息的详细推导见附录 ??。

2.3. Rao-Cramér 不等式. 现在我们可以陈述主要结果。

theorem[Rao-Cramér 下界] 设 $X_1, \dots, X_n$ iid $\sim f(x; \theta)$, 满足正则条件 (R0)-(R4)。令 $Y = u(X_1, \dots, X_n)$ 是任意统计量, 其期望为 $\mathbb{E}_\theta[Y] = k(\theta)$ 。则

$$\text{Var}(Y) \geq \frac{[k'(\theta)]^2}{nI(\theta)}. \quad (6.2.6)$$

特别地, 若 Y 是 θ 的无偏估计 ($k(\theta) = \theta$), 则

$$\text{Var}(Y) \geq \frac{1}{nI(\theta)}. \quad (6.2.7)$$

theorem

证明思路: 利用 Cauchy-Schwarz 不等式和得分函数的性质。令 $Z = \sum_{i=1}^n \frac{\partial \log f(X_i; \theta)}{\partial \theta}$, 则 $\mathbb{E}(Z) = 0$, $\text{Var}(Z) = nI(\theta)$ 。由 $k'(\theta) = \mathbb{E}(YZ)$ 和 $|\text{corr}(Y, Z)| \leq 1$ 可得结论。⁵

直观理解: Fisher 信息量 $I(\theta)$ 决定了估计精度能达到的极限。信息量越大, 下界越低, 我们能越精确地估计 θ 。

2.4. 有效估计量.

DEFINITION 6.1 (有效估计量). 若无偏估计量 $\hat{\theta}$ 的方差达到 Rao-Cramér 下界, 即

$$\text{Var}(\hat{\theta}) = \frac{1}{nI(\theta)},$$

则称 $\hat{\theta}$ 为 θ 的**有效估计量** (*efficient estimator*)。

EXAMPLE 6.6 (Bernoulli 分布的有效估计). 对于 Bernoulli 分布, 我们有 $I(\theta) = 1/[\theta(1-\theta)]$, 因此 Rao-Cramér 下界为 $\theta(1-\theta)/n$ 。

样本均值 $\bar{X}$ 是 θ 的无偏估计, 其方差为 $\text{Var}(\bar{X}) = \theta(1-\theta)/n$ 。

因此 $\bar{X}$ 是有效估计量!

这意味着: 对于 Bernoulli 分布, 不存在任何无偏估计量比样本均值更有效。

EXAMPLE 6.7 (正态分布的样本均值). 对于 $N(\theta, \sigma^2)$ (σ^2 已知), Fisher 信息 $I(\theta) = 1/\sigma^2$, Rao-Cramér 下界为 σ^2/n 。

样本均值 $\bar{X}$ 的方差为 σ^2/n , 因此 $\bar{X}$ 是有效估计量。

但有效估计量并不总是存在。

EXAMPLE 6.8 (Beta($\theta, 1$) 分布). 设 $X_1, \dots, X_n \sim \text{beta}(\theta, 1)$, 密度为 $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$ 。

MLE 为 $\hat{\theta} = -n / \sum_{i=1}^n \log X_i$ 。

该估计量是有偏的, 其方差为 $\text{Var}(\hat{\theta}) = \theta^2 n^2 / [(n-1)^2(n-2)]$, 而 Rao-Cramér 下界为 θ^2/n 。

因此 $\hat{\theta}$ 不是有效的, 但修正偏后的估计量 $[(n-1)/n]\hat{\theta}$ 是渐近有效的。⁶

⁵Rao-Cramér 下界的完整证明见附录 section 7.2。

⁶Beta 分布 MLE 方差的推导见附录 ??。

2.5. 渐近有效性. 由于有效估计量在有限样本下并不总是存在，我们引入渐近有效的概念。

DEFINITION 6.2 (渐近有效性). 设 $\hat{\theta}_n$ 是估计量序列，满足

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, \sigma_\theta^2).$$

则 $\hat{\theta}_n$ 的渐近效率 (*asymptotic efficiency*) 定义为

$$e(\hat{\theta}_n) = \frac{1/I(\theta_0)}{\sigma_\theta^2}. \quad (6.2.8)$$

若 $e(\hat{\theta}_n) = 1$ ，则称 $\hat{\theta}_n$ 是渐近有效的。

下面定理表明，在正则条件下，MLE 是渐近有效的。

heorem[MLE 的渐近正态性和有效性] 在正则条件 (R0)-(R5) 下，设 $\hat{\theta}_n$ 是似然方程的一致解序列。则

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N\left(0, \frac{1}{I(\theta_0)}\right). \quad (6.2.9)$$

heorem

证明思路：对数似然函数在 θ_0 处 Taylor 展开，利用大数定律和中心极限定理。⁷

这一定理意味着：**MLE 渐近地达到 Rao-Cramér 下界**。这是最大似然估计最重要的最优性结果。

2.6. 渐近相对效率. 在比较两个估计量时，渐近相对效率 (ARE) 提供了统一的标准。

DEFINITION 6.3 (渐近相对效率). 设 $\hat{\theta}_{1n}$ 和 $\hat{\theta}_{2n}$ 是两个渐近正态估计量，满足

$$\sqrt{n}(\hat{\theta}_{in} - \theta_0) \xrightarrow{D} N(0, \sigma_i^2), \quad i = 1, 2.$$

则 $\hat{\theta}_{1n}$ 相对于 $\hat{\theta}_{2n}$ 的 ARE 定义为

$$ARE(\hat{\theta}_{1n}, \hat{\theta}_{2n}) = \frac{\sigma_2^2}{\sigma_1^2}. \quad (6.2.10)$$

EXAMPLE 6.9 (中位数与均值的 ARE). 考虑位置模型 $X_i = \theta + e_i$:

- (a) 若 $e_i \sim \text{Laplace}(0, 1)$ ，则 MLE 是样本中位数 Q_2 ，信息 $I(\theta) = 1$ ，因此 $ARE(Q_2, \bar{X}) = 2$ 。这意味着在大样本下，中位数比均值更有效一倍！
- (b) 若 $e_i \sim N(0, 1)$ ，则 $ARE(Q_2, \bar{X}) = 2/\pi \approx 0.636$ 。此时均值更有效。

启示：没有“最优”的估计量——估计量的效率完全由真实分布决定。选择估计量时应该考虑数据的特点。

⁷MLE 渐近正态性的完整证明见附录 section 7.3。

2.7. Summary of Section 6.2.

- Fisher 信息量 $I(\theta) = \text{Var}(\partial \log f / \partial \theta)$ 衡量分布携带的关于 θ 的信息
- Rao-Cramér 下界: 任何无偏估计量 $\hat{\theta}$ 的方差满足 $\text{Var}(\hat{\theta}) \geq 1/[nI(\theta)]$
- 达到下界的估计量称为有效估计量 (如正态均值、二项比例的样本均值)
- 在正则条件下, MLE 是一致且渐近有效的: $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{D} N(0, 1/I(\theta_0))$
- ARE 允许我们比较不同估计量的渐近效率

3. 6.3 Maximum Likelihood Tests

3.1. 从估计到检验. 我们已经建立了基于似然的点估计理论。现在问: 如何基于似然函数进行假设检验?

设 $X_1, \dots, X_n \sim f(x; \theta)$, 考虑双边假设

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta \neq \theta_0. \quad (6.3.1)$$

直觉告诉我们: 若 H_0 为真, 则似然函数在 θ_0 处应该接近最大值; 若 H_1 为真, 似然函数在 θ_0 处应该明显小于在 $\hat{\theta}$ 处。

定义似然比 (likelihood ratio):

$$\Lambda = \frac{L(\theta_0)}{L(\hat{\theta})}. \quad (6.3.2)$$

显然 $\Lambda \leq 1$ 。若 Λ 太小 (即 $L(\theta_0)$ 远小于 $L(\hat{\theta})$), 则拒绝 H_0 。

3.2. 似然比检验. 似然比检验(LRT): 拒绝 H_0 当且仅当 $\Lambda \leq c$, 其中 c 满足 $\alpha = \sup_{\theta \in \omega} \mathbb{P}_\theta(\Lambda \leq c)$

但通常我们关注简单原假设 $H_0: \theta = \theta_0$, 此时临界值由 $\mathbb{P}_{\theta_0}(\Lambda \leq c) = \alpha$ 确定。

EXAMPLE 6.10 (指数分布的 LRT). 设 $X_1, \dots, X_n \sim \text{Exp}(\theta)$, 密度 $f(x; \theta) = \theta^{-1}e^{-x/\theta}$, $x > 0$ 。

似然函数 $L(\theta) = \theta^{-n} \exp\{-n\bar{x}/\theta\}$ 。MLE 为 $\hat{\theta} = \bar{x}$ 。

似然比

$$\Lambda = e^n \left(\frac{\bar{x}}{\theta_0} \right)^n \exp\{-n\bar{x}/\theta_0\}.$$

可以证明, $\Lambda \leq c$ 等价于 $\bar{x}/\theta_0 \leq c_1$ 或 $\bar{x}/\theta_0 \geq c_2$ 。

注意: 当 H_0 为真时, $2n\bar{X}/\theta_0 \sim \chi^2(2n)$ 。因此临界值可从 χ^2 分布获得。⁸

EXAMPLE 6.11 (正态均值的 LRT). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, σ^2 已知。则

$$-2 \log \Lambda = \left(\frac{\bar{X} - \theta_0}{\sigma/\sqrt{n}} \right)^2 \sim \chi^2(1) \quad \text{under } H_0.$$

因此拒绝域为 $-2 \log \Lambda \geq \chi_\alpha^2(1)$ 。

这正是 Chapter 4 中的 z -test! 似然比检验统一了许多经典检验。

⁸指数分布似然比检验的详细推导见附录 ??。

3.3. 三大似然检验. 定理 6.3.1 揭示了似然比统计量在正则条件下的渐近分布。

heorem[似然比检验的渐近分布] 在正则条件下, 若 $H_0: \theta = \theta_0$ 为真, 则

$$-2 \log \Lambda \xrightarrow{D} \chi^2(1). \quad (6.3.3)$$

heorem

这一定理意味着: 对于任意分布, 在大样本下, 似然比检验都有渐近レベル α 。

除了似然比检验, 还有两种常用的似然型检验:

(1) **Wald 检验:** 基于 $\hat{\theta}$ 与 θ_0 的距离

$$\chi_W^2 = nI(\hat{\theta})(\hat{\theta} - \theta_0)^2 \xrightarrow{D} \chi^2(1). \quad (6.3.4)$$

(2) **Score 检验:** 基于得分函数在 θ_0 处的值

$$\chi_R^2 = \frac{[l'(\theta_0)]^2}{nI(\theta_0)} \xrightarrow{D} \chi^2(1). \quad (6.3.5)$$

三个统计量的关系: 当 n 足够大时, $\chi_L^2 \approx \chi_W^2 \approx \chi_R^2$ 。这三种检验在大样本下是等价的。

在实际中:

- 若已有 MLE, 使用 Wald 检验最方便
- 若求 MLE 困难, 但可计算得分, 使用 Score 检验
- 若两种都不方便, 使用似然比检验 (需要分别求限制和未限制的 MLE)

EXAMPLE 6.12 (正态方差的 Score 检验). 设 $X_1, \dots, X_n \sim N(\mu, \theta)$, μ 已知。要检验 $H_0: \theta = \theta_0$ 。

得分函数 $S(\theta) = \frac{1}{2} \sum (X_i - \mu)^2 - \frac{n\theta}{2\theta^2}$, 信息 $I(\theta) = 1/(2\theta^2)$ 。

Score 统计量 $\chi_R^2 = \frac{[\sum (X_i - \mu)^2 - n\theta_0]^2}{n\theta_0^2}$ 。

当 H_0 为真时, $\chi_R^2 \xrightarrow{D} \chi^2(1)$ 。

3.4. Summary of Section 6.3.

- 似然比检验拒绝 H_0 当 $\Lambda = L(\theta_0)/L(\hat{\theta}) \leq c$
- 三大似然检验: LRT、Wald 检验、Score 检验, 在大样本下都渐近服从 $\chi^2(1)$
- 对于正态均值检验, Wald 检验化为我们熟悉的 z -test
- 选择哪种检验取决于计算的便利性

4. 6.4 Multiparameter Case: Estimation

4.1. 为什么要考虑多参数? 实际统计问题中, 多数分布有多个参数。例如:

- 正态分布 $N(\mu, \sigma^2)$ 有两个参数: μ 和 σ^2
- Gamma 分布 $\Gamma(\alpha, \beta)$ 有两个参数
- 多项分布有 $k - 1$ 个参数

将 MLE 理论推广到多参数情形, 是理论完整性和实际应用的必然要求。

4.2. 多参数似然函数. 设 $\boldsymbol{\theta} = (\theta_1, \dots, \theta_p)' \in \Omega \subset \mathbb{R}^p$. 似然函数为

$$L(\boldsymbol{\theta}) = \prod_{i=1}^n f(x_i; \boldsymbol{\theta}), \quad l(\boldsymbol{\theta}) = \sum_{i=1}^n \log f(x_i; \boldsymbol{\theta}). \quad (6.4.1)$$

MLE $\hat{\boldsymbol{\theta}}$ 通过求解 Score 向量方程组得到:

$$\frac{\partial l(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \mathbf{0}. \quad (6.4.2)$$

EXAMPLE 6.13 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 参数 $\boldsymbol{\theta} = (\mu, \sigma^2)'$. 对数似然:

$$l(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

求偏导并令为零:

$$\begin{aligned} \frac{\partial l}{\partial \mu} &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{x}, \\ \frac{\partial l}{\partial \sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \end{aligned}$$

结论: 样本均值和样本方差 (除以 n) 是 MLE。

EXAMPLE 6.14 (Laplace 分布的 MLE). 设 $X_1, \dots, X_n \sim \text{Laplace}(a, b)$, 密度 $f(x) = \frac{1}{2b} \exp\{-|x - a|/b\}$, 参数 $\boldsymbol{\theta} = (a, b)'$.

MLE:

- 位置参数 a : $\hat{a} = Q_2$ (样本中位数), 与 b 无关
- 尺度参数 b : $\hat{b} = \frac{1}{n} \sum_{i=1}^n |X_i - Q_2|$

启示: 对于某些分布, 参数的 MLE 可以分别求解。

4.3. 信息矩阵. 在多参数情形, Fisher 信息由一个矩阵——信息矩阵 (information matrix) 给出:

$$\mathbf{I}(\boldsymbol{\theta}) = \text{Cov}(\nabla \log f(X; \boldsymbol{\theta})), \quad (6.4.3)$$

其中 $\nabla \log f = (\partial \log f / \partial \theta_1, \dots, \partial \log f / \partial \theta_p)'$.

信息矩阵的第 (j, k) 个元素为

$$I_{jk}(\boldsymbol{\theta}) = \mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial \log f}{\partial \theta_j} \cdot \frac{\partial \log f}{\partial \theta_k} \right] = -\mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial^2 \log f}{\partial \theta_j \partial \theta_k} \right]. \quad (6.4.4)$$

对于样本, 信息矩阵是单个样本信息的 n 倍: $\mathbf{I}_n(\boldsymbol{\theta}) = n\mathbf{I}(\boldsymbol{\theta})$ 。

EXAMPLE 6.15 (正态分布的信息矩阵). 设 $X \sim N(\mu, \sigma^2)$, 记 $\theta_1 = \mu$, $\theta_2 = \sigma^2$.

对数似然偏导数:

$$\frac{\partial \log f}{\partial \mu} = \frac{x - \mu}{\sigma^2}, \quad \frac{\partial \log f}{\partial \sigma^2} = -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2(\sigma^2)^2}.$$

计算二阶偏导数的期望，可得信息矩阵

$$\mathbf{I}(\mu, \sigma^2) = \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2(\sigma^2)^2} \end{pmatrix}. \quad (6.4.5)$$

注意对角线元素，这意味着 μ 和 σ^2 的信息在正态分布下是独立的！⁹

4.4. 多参数 Rao-Cramér 下界. 在多参数情形，单个参数 θ_j 的无偏估计量 $\hat{\theta}_j$ 满足

$$\text{Var}(\hat{\theta}_j) \geq \frac{1}{n} [\mathbf{I}^{-1}(\boldsymbol{\theta})]_{jj}. \quad (6.4.6)$$

特别地，当信息矩阵是对角矩阵时，每个参数的 Rao-Cramér 下界与其单参数情形相同。

EXAMPLE 6.16 (正态方差估计的效率). 对于 $N(\mu, \sigma^2)$ ，由信息矩阵可知 σ^2 的 Rao-Cramér 下界为 $2(\sigma^2)^2/n$ 。

样本方差 S^2 (无偏估计) 的方差为 $2(\sigma^2)^2/(n-1)$ ，因此不是有效的，但渐近有效。

4.5. 多参数 MLE 的渐近性质. theorem[多参数 MLE 的渐近分布] 在正则条件下，设 $\hat{\boldsymbol{\theta}}_n$ 是一致解序列。则

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}^{-1}(\boldsymbol{\theta}_0)). \quad (6.4.7)$$

theorem

含义：每个参数分量 $\hat{\theta}_{nj}$ 满足

$$\sqrt{n}(\hat{\theta}_{nj} - \theta_{0j}) \xrightarrow{D} N(0, [\mathbf{I}^{-1}(\boldsymbol{\theta}_0)]_{jj}),$$

即 $\hat{\theta}_{nj}$ 是渐近有效的。

对于参数函数 $g(\boldsymbol{\theta})$ ，由 Delta 方法可得类似结论。

EXAMPLE 6.17 (正态协方差矩阵估计). 设 $X_1, \dots, X_n \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。MLE 为样本均值 $\bar{X}$ 和样本协方差矩阵 $\mathbf{S} = \frac{1}{n} \sum (X_i - \bar{X})(X_i - \bar{X})'$ 。

可以证明 $\bar{X}$ 和 $\mathbf{S}$ 联合渐近正态，且达到信息矩阵下界。

4.6. Summary of Section 6.4.

- 多参数情形下，MLE 通过同时求解所有参数的 Score 方程得到
- 信息矩阵 $\mathbf{I}(\boldsymbol{\theta})$ 是 Fisher 信息在多参数情形下的推广
- Rao-Cramér 下界由信息矩阵的逆给出： $\text{Var}(\hat{\theta}_j) \geq \frac{1}{n} [\mathbf{I}^{-1}]_{jj}$
- 在正则条件下，多参数 MLE 联合渐近正态： $\sqrt{n}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}^{-1})$
- 信息矩阵的对角元素给出每个参数的独立信息

⁹正态分布信息矩阵的详细计算见附录 section 7.4。

5. 6.5 Multiparameter Case: Testing

5.1. 多参数假设检验的框架. 在多参数情形, 假设通常规定参数属于参数空间的某个子集。

设 $\Omega \subset \mathbb{R}^p$ 是完整的参数空间, $\omega \subset \Omega$ 是由 q 个约束定义的子空间。考虑假设

$$H_0: \boldsymbol{\theta} \in \omega \quad \text{vs} \quad H_1: \boldsymbol{\theta} \in \Omega \cap \omega^c. \quad (6.5.1)$$

例如, 对于 $N(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ 相当于检验约束 $\mu = \mu_0$ 下的子空间。

似然比检验推广为

$$\Lambda = \frac{\max_{\boldsymbol{\theta} \in \omega} L(\boldsymbol{\theta})}{\max_{\boldsymbol{\theta} \in \Omega} L(\boldsymbol{\theta})}. \quad (6.5.2)$$

定理 6.5.1 给出了其渐近分布。

heorem[多参数似然比检验的渐近分布] 在正则条件下, 若 H_0 由 q 个独立约束定义, 则

$$-2 \log \Lambda \xrightarrow{D} \chi^2(q). \quad (6.5.3)$$

heorem

含义: 渐近分布的自由度等于约束的个数, 而不是原始参数的个数。

EXAMPLE 6.18 (正态均值的检验). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 检验 $H_0: \mu = \mu_0$ (σ^2 未知)。

全空间 $\Omega = \{(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$, 约束子空间 $\omega = \{(\mu_0, \sigma^2) : \sigma^2 > 0\}$ 。

似然比统计量简化为

$$\Lambda = \left(\frac{\sum (X_i - \bar{X})^2}{\sum (X_i - \mu_0)^2} \right)^{n/2}.$$

经过推导, $-2 \log \Lambda$ 等价于 t 统计量的平方:

$$-2 \log \Lambda = \frac{n(\bar{X} - \mu_0)^2}{\sum (X_i - \bar{X})^2 / (n-1)} \cdot (n-1) \sim \chi^2(1).$$

这与 t -test 完全一致!

启示: 对于正态分布, 似然比检验就是我们熟悉的 t 检验。

EXAMPLE 6.19 (二项比例的检验). 比较两个独立二项分布的比例 p_1 和 p_2 。设 $X \sim \text{Binomial}(n_1, p_1)$, $Y \sim \text{Binomial}(n_2, p_2)$, 检验 $H_0: p_1 = p_2$ 。

Wald 检验统计量:

$$\chi_W^2 = \frac{(\hat{p}_1 - \hat{p}_2)^2}{\hat{p}(1-\hat{p})(1/n_1 + 1/n_2)} \xrightarrow{D} \chi^2(1),$$

其中 $\hat{p} = (n_1 \hat{p}_1 + n_2 \hat{p}_2) / (n_1 + n_2)$ 是合并后的比例估计。

渐近置信区间：

$$\hat{p}_1 - \hat{p}_2 \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}.$$

三大检验的多参数推广：LRT、Wald、Score 检验都可以推广到多参数情形，在大样本下都渐近服从 $\chi^2(q)$ ，其中 q 是约束个数。

5.2. Summary of Section 6.5.

- 多参数假设检验考虑参数空间 Ω 的子空间 ω
- 似然比统计量渐近服从 $\chi^2(q)$ ，自由度 q 等于约束个数
- 正态均值的 t 检验是似然比检验的特例
- Wald 和 Score 检验提供渐近等价的替代方法
- 信息矩阵用于构造 Wald 统计量和置信域

6. 6.6 The EM Algorithm

6.1. 缺失数据问题的起源。在许多实际统计问题中，数据并非完全观测到。例如：

- **截断数据：**只观测到 $X > a$ 的个体
- **区间删失：**只知道 $L < X < R$ ，而不知道具体值
- **隐变量：**观测到 X ，但 X 依赖于某个不可观测的隐变量 Z
- **混合模型：**数据来自多个群体的混合，但我们不知道每个观测来自哪个群体

这些情况下的似然函数往往难以直接最大化。**EM 算法**提供了一种通用的迭代策略。

6.2. EM 算法的思想。EM 算法通过引入“缺失数据”（可以是真正的缺失值，也可以是隐变量）来简化似然函数。

设 $\mathbf{X}$ 是观测数据， $\mathbf{Z}$ 是缺失数据。完整数据 $(\mathbf{X}, \mathbf{Z})$ 的似然函数记为 $L^c(\theta|\mathbf{x}, \mathbf{z})$ 。

设 $\theta^{(m)}$ 是第 m 步的估计值。EM 算法执行两步迭代：

(1) **E 步 (Expectation)：**计算完整数据对数似然在当前估计 $\theta^{(m)}$ 下的条件期望

$$Q(\theta|\theta^{(m)}, \mathbf{x}) = \mathbb{E}_{\theta^{(m)}} [\log L^c(\theta|\mathbf{x}, \mathbf{Z}) | \theta^{(m)}, \mathbf{x}]. \quad (6.6.1)$$

(2) **M 步 (Maximization)：**找到使 Q 最大化的 θ

$$\theta^{(m+1)} = \arg \max_{\theta} Q(\theta|\theta^{(m)}, \mathbf{x}). \quad (6.6.2)$$

EM 算法保证：每一步迭代都使观测似然单调递增，即 $L(\theta^{(m+1)}|\mathbf{x}) \geq L(\theta^{(m)}|\mathbf{x})$ 。

heorem[EM 算法的单调性] 设 $\theta^{(m+1)}$ 由 E 步和 M 步得到。则

$$L(\theta^{(m+1)}|\mathbf{x}) \geq L(\theta^{(m)}|\mathbf{x}). \quad (6.6.3)$$

heorem

证明思路：利用 Q 函数的定义和 Jensen 不等式。¹⁰

¹⁰EM 算法单调性的完整证明见附录 section 7.5。

这一性质保证了算法的稳定性——不会发散到局部最大值以外。

EM 算法的直观理解：E 步”想象”缺失数据可能取的值，M 步在假设这些值已知的情况下更新参数估计。这两个步骤交替进行，直到收敛。

EXAMPLE 6.20 (正态分布的 EM 算法——缺失数据). 设 $X_1, \dots, X_{n_1} \sim N(\theta, 1)$ 观测到，同时 $Z_1, \dots, Z_{n_2} \sim N(\theta, 1)$ 截断于 a (即只知 $Z_j > a$)。

完整数据似然：

$$L^c(\theta) = \prod_{i=1}^{n_1} \phi(x_i - \theta) \prod_{j=1}^{n_2} \phi(z_j - \theta),$$

其中 ϕ 是标准正态密度。

E 步：需要计算 $\mathbb{E}[Z_j - \theta | Z_j > a, \theta^{(m)}]$ 。

设 $Y \sim N(\theta, 1)$ 截尾于 a ，则

$$\mathbb{E}[Y - \theta | Y > a] = \frac{\phi(a - \theta)}{1 - \Phi(a - \theta)}.$$

因此

$$\theta^{(m+1)} = \frac{n_1 \bar{x} + n_2 \theta^{(m)} + n_2 \frac{\phi(a - \theta^{(m)})}{1 - \Phi(a - \theta^{(m)})}}{n_1 + n_2}. \quad (6.6.4)$$

解释：新估计是样本均值、当前估计和截尾部分期望的加权平均。¹¹

EXAMPLE 6.21 (正态混合模型的 EM 算法). 设观测数据来自两个正态分布的混合：

$$X_i \sim (1 - \epsilon)N(\mu_1, \sigma_1^2) + \epsilon N(\mu_2, \sigma_2^2),$$

参数 $\theta = (\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \epsilon)'$ 。

引入隐变量 W_i ：若 X_i 来自第一个分布则 $W_i = 0$ ，否则 $W_i = 1$ 。

完整数据对数似然：

$$\log L^c = \sum_{i=1}^n [(1 - w_i) \log f_1(x_i) + w_i \log f_2(x_i)]. \quad (6.6.5)$$

E 步：计算 w_i 的后验概率

$$\gamma_i^{(m)} = \mathbb{P}(W_i = 1 | \theta^{(m)}, x_i) = \frac{\epsilon^{(m)} f_2(x_i | \theta^{(m)})}{(1 - \epsilon^{(m)}) f_1(x_i | \theta^{(m)}) + \epsilon^{(m)} f_2(x_i | \theta^{(m)})}. \quad (6.6.6)$$

M 步：更新参数

$$\begin{aligned} \hat{\mu}_1 &= \frac{\sum_{i=1}^n (1 - \gamma_i) x_i}{\sum_{i=1}^n (1 - \gamma_i)}, & \hat{\mu}_2 &= \frac{\sum_{i=1}^n \gamma_i x_i}{\sum_{i=1}^n \gamma_i}, \\ \hat{\sigma}_1^2 &= \frac{\sum_{i=1}^n (1 - \gamma_i) (x_i - \hat{\mu}_1)^2}{\sum_{i=1}^n (1 - \gamma_i)}, & \hat{\sigma}_2^2 &= \frac{\sum_{i=1}^n \gamma_i (x_i - \hat{\mu}_2)^2}{\sum_{i=1}^n \gamma_i}, \\ \hat{\epsilon} &= \frac{1}{n} \sum_{i=1}^n \gamma_i. \end{aligned} \quad (6.6.7)$$

直观解释：E 步根据当前参数估计每个观测来自各成分的概率；M 步根据这些概率重新估计各成分的参数。这等价于”软聚类”然后重新估计。

¹¹正态截尾数据的 EM 算法详细推导见附录 ??。

6.3. EM 算法的收敛性. EM 算法的收敛性由以下事实保证：

- 观测似然 $L(\theta|\mathbf{x})$ 在每一步都单调不降
- $L(\theta|\mathbf{x})$ 有上界，因此必收敛到某个极限
- 收敛点满足 Score 方程 $\partial l/\partial \theta = 0$ (即 MLE 的条件)

在正则条件下，EM 算法收敛到 MLE。

EM 算法的优点：

- 简单：每一步只需要计算条件期望
- 稳定：单调收敛，不会发散
- 灵活：适用于各种缺失数据或隐变量问题

EM 算法的缺点：

- 可能收敛到局部最大值 (而非全局最优)
- 收敛速度可能很慢
- 需要显式计算条件期望，可能很困难

EXAMPLE 6.22 (遗传连锁的 EM 算法). 在遗传学中，估计两个基因座之间的重组率 θ 是一个经典问题。

设四类后代观测个数为 (X_1, X_2, X_3, X_4) ，概率分别为 $(\frac{1}{2} + \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{1}{4} - \frac{\theta}{4}, \frac{\theta}{4})$ 。

通过引入隐变量 (将第一类拆分为两个子类别)，EM 算法给出迭代公式

$$\theta^{(m+1)} = \frac{x_1\theta^{(m)} + 2x_4 + x_4\theta^{(m)}}{n\theta^{(m)} + 2(x_2 + x_3 + x_4)}. \quad (6.6.8)$$

该公式收敛到重组率 θ 的 MLE。

6.4. Summary of Section 6.6.

- EM 算法适用于缺失数据或隐变量问题
- E 步：计算完整数据对数似然在当前估计下的条件期望
- M 步：最大化条件期望得到新估计
- EM 算法保证观测似然单调递增
- 在正则条件下收敛到 MLE
- 典型应用：截尾数据、混合模型、缺失数据填充

7. 附录：公式推导

7.1. 定理 6.1.1 的证明 (似然函数的渐近支撑). 背景：我们需要证明当样本量 $n \rightarrow \infty$ 时，似然函数 $L(\theta_0; \mathbf{X})$ 以概率 1 大于任何 $\theta \neq \theta_0$ 处的似然值。

证明： 记 $Z_i(\theta) = \log \frac{f(X_i; \theta)}{f(X_i; \theta_0)}$ 。则

$$\log \frac{L(\theta_0; \mathbf{X})}{L(\theta; \mathbf{X})} = \sum_{i=1}^n \log \frac{f(X_i; \theta_0)}{f(X_i; \theta)} = - \sum_{i=1}^n Z_i(\theta).$$

由弱大数定律,

$$\frac{1}{n} \sum_{i=1}^n Z_i(\theta) \xrightarrow{P} \mathbb{E}_{\theta_0}[Z_1(\theta)].$$

由 Jensen 不等式和 $\mathbb{E}_{\theta_0}[f(X; \theta)/f(X; \theta_0)] = 1$,

$$\mathbb{E}_{\theta_0}[Z_1(\theta)] = \mathbb{E}_{\theta_0} \left[\log \frac{f(X; \theta)}{f(X; \theta_0)} \right] < \log \mathbb{E}_{\theta_0} \left[\frac{f(X; \theta)}{f(X; \theta_0)} \right] = \log 1 = 0.$$

因此 $\frac{1}{n} \sum Z_i(\theta) \xrightarrow{P}$ 负数, 从而

$$\mathbb{P}_{\theta_0} \left[\frac{1}{n} \sum Z_i(\theta) < 0 \right] \rightarrow 1.$$

即 $\mathbb{P}_{\theta_0}[L(\theta_0; \mathbf{X}) > L(\theta; \mathbf{X})] \rightarrow 1$ 。

证毕。

7.2. Rao-Cramér 下界的推导. 背景: 证明任何无偏估计量 $\hat{\theta}$ 的方差满足 $\text{Var}(\hat{\theta}) \geq 1/[nI(\theta)]$ 。

证明思路: 利用 Cauchy-Schwarz 不等式。

设 $Y = \hat{\theta}$, $Z = \sum_{i=1}^n \frac{\partial \log f(X_i; \theta)}{\partial \theta}$ 。则 $\mathbb{E}(Z) = 0$, $\text{Var}(Z) = nI(\theta)$ 。

对 $k'(\theta) = \frac{d}{d\theta} \mathbb{E}(Y) = \frac{d}{d\theta} \int yL(y)dy$ 利用微分与积分可交换 (正则条件), 得

$$k'(\theta) = \mathbb{E} \left(Y \cdot \frac{\partial \log L}{\partial \theta} \right) = \mathbb{E}(YZ).$$

由 Cauchy-Schwarz 不等式,

$$|\text{corr}(Y, Z)|^2 = \frac{[\text{cov}(Y, Z)]^2}{\text{Var}(Y)\text{Var}(Z)} \leq 1.$$

即 $[k'(\theta)]^2 \leq \text{Var}(Y) \cdot nI(\theta)$, 整理得 Rao-Cramér 不等式。

证毕。

7.3. MLE 渐近正态性的证明. 背景: 证明 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, 1/I(\theta_0))$ 。

证明思路: 对数似然在 θ_0 处 Taylor 展开。

记 $l'(\theta) = \partial l / \partial \theta$, $l''(\theta) = \partial^2 l / \partial \theta^2$ 。

由 $l'(\hat{\theta}_n) = 0$ (MLE 条件) 和 Taylor 展开:

$$0 = l'(\theta_0) + (\hat{\theta}_n - \theta_0)l''(\theta_0) + \frac{1}{2}(\hat{\theta}_n - \theta_0)^2 l'''(\theta_n^*),$$

其中 θ_n^* 在 θ_0 和 $\hat{\theta}_n$ 之间。

整理得

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \frac{n^{-1/2}l'(\theta_0)}{-n^{-1}l''(\theta_0) - \frac{1}{2}(\hat{\theta}_n - \theta_0) \cdot n^{-1}l'''(\theta_n^*)}.$$

由中心极限定理, $n^{-1/2}l'(\theta_0) \xrightarrow{D} N(0, I(\theta_0))$ 。

由大数定律, $-n^{-1}l''(\theta_0) \xrightarrow{P} I(\theta_0)$ 。

由一致性 $\hat{\theta}_n \xrightarrow{P} \theta_0$ 和条件 (R5), 第三项依概率趋于 0。

因此分子分母分别收敛, 极限分布为 $N(0, 1/I(\theta_0))$ 。

证毕。

7.4. 正态分布信息矩阵的推导. 设 $X \sim N(\mu, \sigma^2)$, 记 $\theta_1 = \mu$, $\theta_2 = \sigma^2$ 。

对数密度:

$$\log f = -\frac{1}{2} \log(2\pi) - \frac{1}{2} \log \theta_2 - \frac{(x - \theta_1)^2}{2\theta_2}.$$

一阶偏导数:

$$\frac{\partial \log f}{\partial \theta_1} = \frac{x - \theta_1}{\theta_2}, \quad \frac{\partial \log f}{\partial \theta_2} = -\frac{1}{2\theta_2} + \frac{(x - \theta_1)^2}{2\theta_2^2}.$$

二阶偏导数:

$$\frac{\partial^2 \log f}{\partial \theta_1^2} = -\frac{1}{\theta_2}, \quad \frac{\partial^2 \log f}{\partial \theta_2^2} = \frac{1}{2\theta_2^2} - \frac{(x - \theta_1)^2}{\theta_2^3}, \quad \frac{\partial^2 \log f}{\partial \theta_1 \partial \theta_2} = -\frac{x - \theta_1}{\theta_2^2}.$$

计算 Fisher 信息矩阵元素 (取负期望):

$$\begin{aligned} I_{11} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_1^2} \right] = \frac{1}{\theta_2}, \\ I_{22} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_2^2} \right] = \frac{1}{2\theta_2^2}, \\ I_{12} &= -\mathbb{E} \left[\frac{\partial^2 \log f}{\partial \theta_1 \partial \theta_2} \right] = -\mathbb{E} \left[-\frac{X - \theta_1}{\theta_2^2} \right] = 0. \end{aligned}$$

因此

$$\mathbf{I}(\theta) = \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2(\sigma^2)^2} \end{pmatrix}.$$

注意到 $I_{12} = 0$, 这表明 μ 和 σ^2 的信息在正态分布下是独立的。

证毕。

7.5. EM 算法单调性的证明. 背景: 证明 EM 算法的每一步都使观测似然单调递增。

证明: 由条件概率定义,

$$L(\theta|\mathbf{x}) = \frac{h(\mathbf{x}, \mathbf{z}|\theta)}{k(\mathbf{z}|\theta, \mathbf{x})},$$

其中 h 是完整数据联合密度, k 是缺失数据 $\mathbf{Z}$ 给定观测数据 $\mathbf{x}$ 和参数 θ 的条件密度。

取对数并在给定 $\theta^{(m)}$ 和 $\mathbf{x}$ 的条件下对 $\mathbf{Z}$ 求期望:

$$\log L(\theta|\mathbf{x}) = \mathbb{E}_{\theta^{(m)}} [\log h(\mathbf{x}, \mathbf{Z}|\theta)|\theta^{(m)}, \mathbf{x}] - \mathbb{E}_{\theta^{(m)}} [\log k(\mathbf{Z}|\theta, \mathbf{x})|\theta^{(m)}, \mathbf{x}].$$

第一项正是 $Q(\theta|\theta^{(m)}, \mathbf{x})$ 。第二项由 Jensen 不等式可得

$$\mathbb{E}_{\theta^{(m)}} \left[\log \frac{k(\mathbf{Z}|\theta^{(m)}, \mathbf{x})}{k(\mathbf{Z}|\theta, \mathbf{x})} \right] \leq \log \mathbb{E}_{\theta^{(m)}} \left[\frac{k(\mathbf{Z}|\theta^{(m)}, \mathbf{x})}{k(\mathbf{Z}|\theta, \mathbf{x})} \right] = \log 1 = 0.$$

因此

$$\log L(\theta|\mathbf{x}) \geq Q(\theta|\theta^{(m)}, \mathbf{x}) - Q(\theta^{(m)}|\theta^{(m)}, \mathbf{x}).$$

由于 $\theta^{(m+1)}$ 最大化 Q ，即 $Q(\theta^{(m+1)}|\theta^{(m)}, \mathbf{x}) \geq Q(\theta^{(m)}|\theta^{(m)}, \mathbf{x})$ ，代入得

$$\log L(\theta^{(m+1)}|\mathbf{x}) \geq \log L(\theta^{(m)}|\mathbf{x}).$$

证毕。

CHAPTER 7

Sufficiency and Quality of Estimators

Chapter 7 Overview

在前几章中，我们建立了点估计、置信区间和假设检验的理论基础。我们已经看到，最大似然估计（MLE）在正则条件下具有一致性，并且在渐近意义下具有最优性质。然而，我们还没有回答一个更深层次的问题：

给定一个参数 θ ，在所有可能的估计量中，是否存在一个“最好”的？如何找到它？

要回答这个问题，我们首先需要理解什么叫“信息保留”。当我们收集数据 $X_1, X_2, \dots, X_n$ 后，这些数据包含了关于 θ 的信息。但原始数据量太大——我们需要**数据压缩（data reduction）**。一个自然的想法是用样本均值 $\bar{X}$ 或样本方差 S^2 这样的统计量来代替原始数据。

关键问题是：这种压缩是否丢失了关于 θ 的信息？

这正是**充分性（sufficiency）**理论要回答的问题。一个充分统计量 $T(X_1, \dots, X_n)$ 保留了原始数据中关于 θ 的全部信息——给定 T 的值，数据的条件分布不再依赖于 θ 。本章我们将学习：

- 如何定义和判断充分统计量（因子分解定理）
- Rao-Blackwell 定理：如何利用充分性改进估计量
- 完备性（completeness）与唯一最小方差无偏估计（MVUE）的关系
- 指数族分布（exponential class）的优良性质
- Basu 定理：完备充分统计量与辅助统计量的独立性

本章路线图：充分性定义 $\rightarrow$ 因子分解定理 $\rightarrow$ Rao-Blackwell $\rightarrow$ 完备性 $\rightarrow$ 指数族 $\rightarrow$ Basu 定理

1. 7.1 Measures of Quality of Estimators

在寻找“最好”的估计量之前，我们需要先定义什么叫“好”。前几章我们已经遇到过两个重要标准：无偏性（unbiasedness）和一致性（consistency）。

1.1. 最小方差无偏估计量（MVUE）. 一个自然而优雅的标准是：在所有无偏估计量中，选择方差最小的。

DEFINITION 7.1 (最小方差无偏估计量 (MVUE)). 设 $Y = u(X_1, X_2, \dots, X_n)$ 是基于容量为 n 的随机样本的 θ 的点估计量。若 Y 是无偏的，即 $E(Y) = \theta$ ，且对 θ 的任何其他无偏估计量 Y' ，都有 $\text{var}(Y) \leq \text{var}(Y')$ ，则称 Y 是 θ 的**最小方差无偏估计量（minimum variance unbiased estimator, MVUE）**。

这个定义的诱人之处在于它的自然性：如果两个估计量都是 θ 的无偏估计，那么方差较小的那个在平均意义上更接近 θ 。

EXAMPLE 7.1 (正态分布的样本均值 vs 单个观测值). 设 $X_1, X_2, \dots, X_9$ 是来自 $N(\theta, \sigma^2)$ 分布的随机样本，其中 $-\infty < \theta < \infty$ 。

统计量 $\bar{X} = (X_1 + X_2 + \dots + X_9)/9$ 服从 $N(\theta, \sigma^2/9)$ ，因此是无偏的。而 X_1 服从 $N(\theta, \sigma^2)$ ，也是无偏的。

虽然 $\bar{X}$ 的方差 $\sigma^2/9$ 小于 X_1 的方差 σ^2 ，但定义要求比较的对象是**所有**无偏估计量，而不仅仅是这两个。我们不能仅凭两个例子就宣称 $\bar{X}$ 是 *MVUE*。

真正的问题在于：我们无法枚举所有可能的无偏估计量。这促使我们发展更系统的方法来寻找 *MVUE*。

1.2. 风险函数与决策论视角. 另一种比较估计量的框架是决策论 (decision theory)。设 $\mathcal{L}[\theta, \delta(y)]$ 是损失函数 (loss function)，衡量估计值 $\delta(y)$ 与真实参数 θ 之间的差距。常见的损失函数是平方误差损失 $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$ 。

风险函数 (risk function) 定义为损失的期望： $R(\theta, \delta) = E[\mathcal{L}(\theta, \delta(Y))]$ 。一个自然的想法是寻找使风险函数最小化的决策函数。但在一般情况下，使 $R(\theta, \delta)$ 对所有 θ 同时最小的估计量不存在 (见下例)。

EXAMPLE 7.2 (最小化风险函数的困难). 设 $X_1, \dots, X_{25}$ 是来自 $N(\theta, 1)$ 的样本。考虑平方损失函数 $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$ 。

比较两个决策函数：

- $\delta_1(y) = y = \bar{x}$ ，风险 $R(\theta, \delta_1) = 1/25$
- $\delta_2(y) = 0$ ，风险 $R(\theta, \delta_2) = \theta^2$

当 $\theta = 0$ 时， δ_2 表现完美 ($R(0, \delta_2) = 0$)；但当 $\theta = 2$ 时， $R(2, \delta_2) = 4 > R(2, \delta_1) = 1/25$ 。一般地，当 $|\theta| < 1/5$ 时 δ_2 更好，否则 δ_1 更好。

这说明没有一个决策函数能在所有 θ 值下同时最优。**minimax 原则**提供了一种折中：选择使 $\max_{\theta} R(\theta, \delta)$ 最小的决策函数。

如果没有对决策函数的限制 (如要求无偏)，很难找到统一最优的估计量。这促使我们聚焦于 *MVUE*——在无偏估计量的类中寻找方差最小者。

充分性的引入：如果我们有一个充分统计量 T ，那么所有无偏估计量都可以通过 Rao-Blackwell 过程改进为 T 的函数。这大大简化了 *MVUE* 的搜索。

本节小结.

- *MVUE* 在无偏估计量类中方差最小
- 寻找 *MVUE* 的困难在于无法枚举所有无偏估计量
- 充分统计量为这一问题提供了系统性的解决方案

2. 7.2 A Sufficient Statistic for a Parameter

本节我们正式引入充分统计量的概念，并建立判断充分性的核心工具——因子分解定理 (Factorization Theorem)。

2.1. 为什么需要充分统计量? 统计量 $Y = u(X_1, X_2, \dots, X_n)$ 本质上是对样本空间的一种划分 (partition)。例如, $\bar{X} = 8.32$ 意味着所有满足 $\sum x_i = (8.32)n$ 的点 $(x_1, \dots, x_n)$ 被归入同一类。

给定一个统计量 $Y_1 = u_1(X_1, \dots, X_n)$, 如果我们知道 $(X_1, \dots, X_n)$ 落在由 $Y_1 = y_1$ 确定的集合中, 那么 $X_1, \dots, X_n$ 的条件分布可能仍然依赖于 θ 。如果这个条件分布**完全**不含 θ , 则 Y_1 包含了样本中关于 θ 的全部信息——这就是充分性的直觉。

EXAMPLE 7.3 (二项分布的充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 $Bernoulli(\theta)$ 分布的随机样本, 即

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, \quad x = 0, 1.$$

统计量 $Y_1 = \sum_{i=1}^n X_i$ 服从二项分布 $b(n, \theta)$ 。考虑条件概率

$$P(X_1 = x_1, \dots, X_n = x_n \mid Y_1 = y_1).$$

当且仅当 $\sum x_i = y_1$ 时该条件概率非零, 此时

$$\frac{\theta^{x_1} (1 - \theta)^{1-x_1} \cdots \theta^{x_n} (1 - \theta)^{1-x_n}}{\binom{n}{y_1} \theta^{y_1} (1 - \theta)^{n-y_1}} = \frac{1}{\binom{n}{y_1}},$$

该式不含 θ 。因此给定 $Y_1 = y_1$, 数据的条件分布与 θ 无关—— Y_1 是 θ 的充分统计量。

这个例子的含义是: 只要知道“成功次数” Y_1 是多少, 就不再需要知道具体是哪几次试验成功了。 Y_1 已经包含了所有关于 θ 的信息。

2.2. 充分统计量的正式定义.

DEFINITION 7.2 (充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是统计量, 其 pdf 或 pmf 为 $f_{Y_1}(y_1; \theta)$ 。则 Y_1 是 θ 的**充分统计量**, 当且仅当

$$\frac{f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta)}{f_{Y_1}[u_1(x_1, \dots, x_n); \theta]} = H(x_1, \dots, x_n),$$

其中 $H(x_1, \dots, x_n)$ 不依赖于 θ 。

这个定义的要点是: 分子是联合 pdf/pmf, 分母是充分统计量的 pdf, 比值只与原始数据有关而与 θ 无关。

2.3. 因子分解定理 (Factorization Theorem). 直接使用定义需要知道充分统计量的分布, 这往往很困难。Neyman 的因子分解定理提供了一个更实用的判定方法。

THEOREM 7.1 (Neyman 因子分解定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。统计量 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量, 当且仅当存在两个非负函数 k_1 和 k_2 , 使得

$$f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta) = k_1[u_1(x_1, \dots, x_n); \theta] \cdot k_2(x_1, \dots, x_n),$$

其中 $k_2(x_1, \dots, x_n)$ 不依赖于 θ 。

核心理念：联合 pdf/pmf 可以分解为两部分——一部分只通过 $u_1(x_1, \dots, x_n)$ 依赖于 θ ，另一部分与 θ 无关。能完成这种分解的统计量就是充分的。

EXAMPLE 7.4 (正态分布 $\bar{X}$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 $N(\theta, \sigma^2)$ 的样本，其中 σ^2 已知。则

$$f(x_i; \theta) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x_i - \theta)^2}{2\sigma^2} \right].$$

联合 pdf 为

$$\prod_{i=1}^n f(x_i; \theta) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

利用恒等式 $\sum (x_i - \theta)^2 = \sum (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2$ ，可得

$$\prod_{i=1}^n f(x_i; \theta) = \underbrace{\exp \left[-\frac{n(\bar{x} - \theta)^2}{2\sigma^2} \right]}_{k_1[\bar{x}; \theta]} \cdot \underbrace{\frac{\exp \left[-\frac{1}{2\sigma^2} \sum (x_i - \bar{x})^2 \right]}{(\sigma\sqrt{2\pi})^n}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\bar{X}$ 是 θ 的充分统计量。¹

EXAMPLE 7.5 (指数分布的充分统计量). 设 $X_1, \dots, X_n$ 是来自 $\Gamma(2, \theta)$ 分布的样本。已知 $\Gamma(\alpha, \beta)$ 分布的 mgf 为 $M(t) = (1 - \beta t)^{-\alpha}$, $t < 1/\beta$ 。

$Y_1 = \sum_{i=1}^n X_i$ 的 mgf 为 $[(1 - \theta t)^{-2}]^n = (1 - \theta t)^{-2n}$ ，因此 $Y_1 \sim \Gamma(2n, \theta)$ 。

联合 pdf 为

$$\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2} = \frac{(\prod x_i) \exp(-\sum x_i/\theta)}{\theta^{2n}}.$$

给定 $Y_1 = y_1$ 时，条件概率的比值为

$$\frac{\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2}}{\frac{y_1^{2n-1} e^{-y_1/\theta}}{\Gamma(2n)\theta^{2n}}} = \frac{\Gamma(2n) \prod x_i}{y_1^{2n-1}},$$

不含 θ 。故 $Y_1 = \sum X_i$ 是 θ 的充分统计量。

EXAMPLE 7.6 (乘积 $\prod X_i$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0$$

的样本。这是参数化形式的 Beta 分布。

联合 pdf 为

$$\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} = \underbrace{\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta}}_{k_1[\prod x_i; \theta]} \cdot \underbrace{\frac{1}{\prod x_i}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\prod_{i=1}^n X_i$ 是 θ 的充分统计量。

注意：使用因子分解定理时，必须正确处理支撑集 (support) 对参数的依赖。

¹正态分布充分性的详细推导见附录 ??。

EXAMPLE 7.7 (支撑集依赖参数的情况). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta) = e^{-(x-\theta)} I_{(\theta, \infty)}(x).$$

一种错误的分解可能是:

$$\prod e^{-(x_i-\theta)} = [e^{3\theta}] [e^{-x_1-x_2-x_3}],$$

从而声称 $\max X_i$ 是充分的。但这是错误的, 因为支撑集的交集必须满足 $\theta < \min x_i$, 即

$$\prod I_{(\theta, \infty)}(x_i) = I_{(\theta, \infty)}(\min x_i).$$

正确的分解导致 $\min X_i$ 是充分统计量, 而非 $\max X_i$ 。

本节小结.

- 充分统计量 T 保留了样本中关于 θ 的全部信息
- 因子分解定理是判断充分性的实用工具
- 注意支撑集对参数的依赖情况

3. 7.3 Properties of a Sufficient Statistic

本节讨论充分性的关键应用: 如何利用充分统计量改进任意无偏估计量。

3.1. Rao-Blackwell 定理. 给定一个充分统计量 T , 我们可以将任意无偏估计量 Y_2 改进为 T 的函数 $\varphi(T)$, 新估计量不仅保持无偏性, 方差还会减小。

THEOREM 7.2 (Rao-Blackwell 定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量。设 $Y_2 = u_2(X_1, \dots, X_n)$ (不是 Y_1 的函数) 是 θ 的无偏估计量。

则 $E(Y_2 | y_1) = \varphi(y_1)$ 定义了一个统计量 $\varphi(Y_1)$ 。该统计量 $\varphi(Y_1)$:

- (1) 是 θ 的无偏估计量
- (2) 是充分统计量的函数
- (3) 方差不超过 Y_2 的方差

证明思路: 利用全概率公式 $E(Y_2) = E[E(Y_2 | Y_1)]$ 和条件方差不增性质 $\text{var}(Y_2) \geq \text{var}[E(Y_2 | Y_1)]$ 。

这个定理的战略意义是: 在寻找 MVUE 时, 只需在充分统计量的函数中搜索。

EXAMPLE 7.8 (指数分布的 MVUE). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta e^{-\theta x}, \quad x > 0, \quad \theta > 0$$

的样本 (这是 $\Gamma(1, 1/\theta)$ 分布)。

联合 pdf 为 $L(\theta) = \theta^n e^{-\theta \sum x_i}$, 故 $Y_1 = \sum_{i=1}^n X_i$ 是充分统计量。

MLE 为 $Y_2 = 1/\bar{X} = n/Y_1$ 。由于 MLE 渐近无偏, 我们计算其期望。 $Y_1 \sim \Gamma(n, 1/\theta)$, 因此

$$E(Y_2) = n \cdot E(1/Y_1) = n \int_0^\infty \frac{\theta^n}{n!} t^{-1} t^{n-1} e^{-\theta t} dt = \frac{n}{n-1} \theta, \quad n > 1.$$

故 $(n-1)/n \cdot Y_2 = (n-1)/Y_1$ 是 θ 的无偏估计量, 且是充分统计量的函数, 因此是 *MVUE*。

3.2. 充分性与 MLE 的关系.

THEOREM 7.3 (充分性与 MLE). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。若 θ 的 MLE $\hat{\theta}$ 存在且唯一, 则 $\hat{\theta}$ 是充分统计量的函数。

直觉: 若 T 是充分的, 则似然函数 $L(\theta) = f_T(t; \theta) \cdot H(\mathbf{x})$ 。 $L(\theta)$ 和 $f_T(t; \theta)$ 作为 θ 的函数同时达到最大值, 故 $\hat{\theta}$ 必为 T 的函数。

这一结果具有重要的实践意义: 对于指数族分布, MLE 通常可以解析地写成充分统计量的函数。

本节小结.

- Rao-Blackwell 定理: 将任意无偏估计量改进为充分统计量的函数
- 充分性搜索范围: 从所有统计量缩小到充分统计量的函数
- 若 MLE 存在且唯一, 则必为充分统计量的函数

4. 7.4 Completeness and Uniqueness

有了 Rao-Blackwell 定理, 我们知道 MVUE (若存在) 必是充分统计量的函数。但充分统计量的函数可能有很多个——我们如何确定哪一个是 MVUE?

这就需要引入**完备性 (completeness)** 的概念。

4.1. 完备性的定义.

DEFINITION 7.3 (完备族). 设随机变量 Z (连续型或离散型) 的 pdf 或 pmf 是族 $\{h(z; \theta) : \theta \in \Omega\}$ 的一页。若条件 $E[u(Z)] = 0$ 对所有 $\theta \in \Omega$ 成立能够推出 $u(z) = 0$ (除了一个对每个 $h(z; \theta)$ 概率为零的点集), 则称该族为**完备族 (complete family)**。

简言之: 只有零函数才能期望为零。

EXAMPLE 7.9 (泊松分布族的完备性). 设 $X_1, \dots, X_n$ 是来自泊松分布 $P(\theta)$ 的样本。已知 $Y_1 = \sum X_i$ 是充分统计量, 其 pmf 为

$$g(y_1; \theta) = \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!}, \quad y_1 = 0, 1, 2, \dots$$

设 $E[u(Y_1)] = 0$ 对所有 $\theta > 0$ 成立, 即

$$\sum_{y_1=0}^{\infty} u(y_1) \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!} = 0.$$

由于 $e^{-n\theta} \neq 0$, 可得

$$u(0) + nu(1)\theta + \frac{n^2 u(2)}{2!} \theta^2 + \dots = 0, \quad \forall \theta > 0.$$

无穷幂级数对所有 $\theta > 0$ 为零, 意味着所有系数必为零:

$$u(0) = u(1) = u(2) = \cdots = 0.$$

故泊松充分统计量族是完备的。

EXAMPLE 7.10 (指数分布族的完备性). 设 $Z \sim \text{Exp}(\theta)$, 即 pdf 为 $h(z; \theta) = \frac{1}{\theta} e^{-z/\theta}$, $z > 0$ 。

设 $E[u(Z)] = 0$ 对所有 $\theta > 0$ 成立:

$$\int_0^\infty u(z) \frac{1}{\theta} e^{-z/\theta} dz = 0, \quad \forall \theta > 0.$$

令 $t = z/\theta$, 则 $\theta dt = dz$:

$$\int_0^\infty u(\theta t) e^{-t} dt = 0, \quad \forall \theta > 0.$$

对 θ 求导并利用积分号内可微 (假设 u 满足适当条件), 可得 $u(\theta t) \equiv 0$ 。由拉普拉斯变换的唯一性, $u \equiv 0$ 。故该族是完备的。

4.2. 完备充分统计量与 MVUE 的唯一性.

THEOREM 7.4 (Lehmann-Scheffé 定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量, 且族 $\{f_{Y_1}(y_1; \theta) : \theta \in \Omega\}$ 是完备的。

若存在 Y_1 的一个函数是 θ 的无偏估计量, 则该函数是唯一的 MVUE。

证明思路: 设 $\varphi(Y_1)$ 和 $\psi(Y_1)$ 都是 Y_1 的无偏估计量函数。则 $E[\varphi(Y_1) - \psi(Y_1)] = 0$ 对所有 θ 成立。由完备性, $\varphi(y_1) - \psi(y_1) = 0$ 几乎处处成立, 即两个估计量函数几乎处处相等——这就是“唯一”含义。

战略意义: 完备充分统计量的无偏函数就是 MVUE。

EXAMPLE 7.11 (均匀分布最大值的 MVUE). 设 $X_1, \dots, X_n$ 是来自 $\text{Uniform}(0, \theta)$ 的样本。 $Y_n = \max\{X_i\}$ 是充分统计量 (习题 7.2.3), 其 pdf 为

$$g(y_n; \theta) = \frac{n y_n^{n-1}}{\theta^n}, \quad 0 < y_n < \theta.$$

验证完备性: 设 $E[u(Y_n)] = 0$ 对所有 $\theta > 0$ 成立,

$$\int_0^\theta u(t) \frac{n t^{n-1}}{\theta^n} dt = 0.$$

等价于 $\int_0^\theta u(t) t^{n-1} dt = 0$ 。对 θ 求导得 $u(\theta) \theta^{n-1} = 0$, 故 $u(\theta) = 0$ 对所有 $\theta > 0$ 成立。故 Y_n 是完备充分的。

计算 $E(Y_n) = \frac{n}{n+1} \theta$, 故 $(n+1)/n \cdot Y_n$ 是 θ 的 MVUE。

EXAMPLE 7.12 (非完备的情况). 设 $X \sim N(0, \theta)$, $\theta > 0$ 。则 $Y = \sum X_i^2$ 是充分统计量, 但族 $\{f_Y(y; \theta)\}$ 不是完备的 (因为 χ^2 分布的自由度参数不依赖于 θ 的形式)。

实际上, 若 $Z \sim \chi_{n-1}^2$ (与 Y 独立), 则 $E(Z) = n-1$, 但这并不能推出关于 Y 的任何约束。

本节小结.

- 完备性: 只有零函数才能期望为零
- Lehmann-Scheffé 定理: 完备充分统计量的无偏函数是唯一的 MVUE
- 寻找 MVUE 的策略: 先找完备充分统计量, 再在其函数中找无偏估计量

5. 7.5 The Exponential Class of Distributions

在前几节中, 我们看到充分性和完备性是找到 MVUE 的关键。但如何系统地找到完备充分统计量? 本节介绍的**指数族分布 (exponential class)** 是一个具有优良性质的大类。

5.1. 正则指数族的定义.

DEFINITION 7.4 (正则指数族). 设 $f(x; \theta)$ 具有如下形式:

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)], \quad x \in \mathcal{S},$$

其中 $\mathcal{S}$ 是 X 的支撑集。若满足:

- (1) $\mathcal{S}$ 不依赖于 θ
- (2) $p(\theta)$ 是 $\theta \in \Omega$ 的非线性连续函数
- (3) 若 X 连续, 则 $K'(x) \neq 0$ 且 $H(x)$ 在 $\mathcal{S}$ 上连续; 若 X 离散, 则 $K(x)$ 在 $\mathcal{S}$ 上非线性

则称 $f(x; \theta)$ 属于**正则指数族 (regular exponential class)**。

直觉: 指数形式 $e^{p(\theta)K(x)}$ 使得对数似然函数是 $K(x)$ 的线性函数, 从而 $\sum K(X_i)$ 自然成为充分统计量。

EXAMPLE 7.13 (正态分布 $N(0, \theta)$ 是指数族). $N(0, \theta)$ 的 pdf 可写为

$$f(x; \theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-x^2/(2\theta)} = \exp \left[-\frac{1}{2\theta} x^2 - \frac{1}{2} \log(2\pi\theta) \right].$$

对应 $p(\theta) = -1/(2\theta)$, $K(x) = x^2$, $H(x) = -\frac{1}{2} \log(2\pi)$, $q(\theta) = -\frac{1}{2} \log(2\pi\theta)$ 。故 $N(0, \theta)$ 属于正则指数族。

若 $X_1, \dots, X_n \sim N(0, \theta)$, 则 $\sum X_i^2$ 是充分统计量。

EXAMPLE 7.14 (泊松分布是指数族). 泊松分布的 pmf 为

$$f(x; \theta) = e^{-\theta} \frac{\theta^x}{x!} = \exp[(\log \theta)x - \theta - \log(x!)].$$

对应 $p(\theta) = \log \theta$, $K(x) = x$, $q(\theta) = -\theta$, $H(x) = -\log(x!)$ 。故泊松分布属于正则指数族, $\sum X_i$ 是充分统计量。

反例: 均匀分布 $f(x; \theta) = 1/\theta$, $0 < x < \theta$ 的支撑集依赖于 θ , 因此不是正则指数族。

5.2. 指数族的核心定理.

THEOREM 7.5 (指数族充分统计量的性质). 设 $X_1, \dots, X_n$ 来自正则指数族, pdf/pmf 如定义所示. 设 $Y_1 = \sum_{i=1}^n K(X_i)$. 则:

(1) Y_1 的 pdf/pmf 具有形式

$$f_{Y_1}(y_1; \theta) = R(y_1) \exp[p(\theta)y_1 + nq(\theta)], \quad y_1 \in \mathcal{S}_{Y_1},$$

其中 $\mathcal{S}_{Y_1}$ 和 $R(y_1)$ 不依赖于 θ

$$(2) E(Y_1) = -n \frac{q'(\theta)}{p'(\theta)}$$

$$(3) \text{var}(Y_1) = n \cdot \frac{p''(\theta)q'(\theta) - q''(\theta)p'(\theta)}{[p'(\theta)]^3}$$

THEOREM 7.6 (指数族统计量的完备性). 在正则指数族条件下, $Y_1 = \sum_{i=1}^n K(X_i)$ 是 θ 的完备充分统计量。

证明思路: 设 $E[u(Y_1)] = 0$ 对所有 θ 成立. 利用 Y_1 的分布形式, 可得

$$\int u(y_1) R(y_1) \exp[p(\theta)y_1] dy_1 = 0, \quad \forall \theta.$$

由于 $p(\theta)$ 是非线性连续函数, 该积分本质上是 $u(y_1)R(y_1)$ 的拉普拉斯变换. 拉普拉斯变换为零意味着 $u(y_1)R(y_1) \equiv 0$. 由于 $R(y_1) > 0$ (它是 pdf 的因子), 故 $u(y_1) \equiv 0$.

EXAMPLE 7.15 (正态均值 θ 的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知. 则

$$f(x; \theta) = \exp \left[\frac{\theta}{\sigma^2} x - \frac{x^2}{2\sigma^2} - \log \sqrt{2\pi\sigma^2} - \frac{\theta^2}{2\sigma^2} \right].$$

故 $p(\theta) = \theta/\sigma^2$, $K(x) = x$, $q(\theta) = -\frac{\theta^2}{2\sigma^2}$. $Y_1 = \sum X_i = n\bar{X}$ 是完备充分统计量. $E(Y_1) = n\theta$, 故 $\varphi(Y_1) = Y_1/n = \bar{X}$ 是 θ 的唯一 MVUE。

指数族的战略价值: 对于指数族, 完备充分统计量可以通过观察直接写出, MVUE 也容易通过期望计算得到。

本节小结.

- 正则指数族具有形式 $e^{p(\theta)K(x)+H(x)+q(\theta)}$
- $\sum K(X_i)$ 是指数族的充分统计量
- 指数族统计量是完备充分的
- 指数族的 MVUE 可通过期望计算直接得到

6. 7.6 Functions of a Parameter

很多时候, 我们关心的不是参数 θ 本身, 而是其某个函数 $\delta = g(\theta)$. 例如, 估计 $\theta(1-\theta)$ 而非 θ 本身。

6.1. 技术一：观察法。如果能通过观察 $E[\varphi(Y_1)] = g(\theta)$ 解出 φ 就可直接得到 MVUE。

EXAMPLE 7.16 (二项分布方差的 MVUE). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$. $Y = \sum X_i$ 是完备充分统计量。样本比例 Y/n 是 θ 的 MVUE。

现欲估计 $\delta = \theta(1 - \theta)$, 即 $\text{var}(Y/n) = \theta(1 - \theta)/n$ 。

MLE 为 $\tilde{\delta} = (Y/n)(1 - Y/n)$ 。计算期望:

$$E[\tilde{\delta}] = E\left[\frac{Y}{n}\left(1 - \frac{Y}{n}\right)\right] = \frac{n-1}{n}\theta(1 - \theta).$$

故 $\hat{\delta} = \frac{n}{n-1}\tilde{\delta} = \frac{Y(n-Y)}{n(n-1)}$ 是 δ 的 MVUE。

6.2. 技术二：条件期望法。若 Z 是 θ 的无偏估计量, 则 $\varphi(Y_1) = E(Z | Y_1)$ 是 MVUE。

EXAMPLE 7.17 (正态分布累积概率的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ 。欲估计 $P(X \leq c) = \Phi(c - \theta)$ 。

取 $Z = I(X_1 \leq c)$, 则 $E(Z) = \Phi(c - \theta)$, 是无偏的。

$(X_1, \bar{X})$ 的联合分布是二元正态, 条件分布 $X_1 | \bar{X} = \bar{x}$ 是正态, 均值为 $\bar{x}$, 方差为 $(n-1)/n$ 。

计算条件期望:

$$E[Z | \bar{X} = \bar{x}] = P(X_1 \leq c | \bar{X} = \bar{x}) = \Phi\left[\frac{\sqrt{n}(c - \bar{x})}{\sqrt{n-1}}\right].$$

这是 $\Phi(c - \theta)$ 的 MVUE。

6.3. 7.6.1 Bootstrap 标准误。对于 MVUE, 我们通常没有像 MLE 那样的渐近理论。但可以使用 Bootstrap 来获得标准误。

设 $\hat{\theta}$ 是基于原始样本的估计量。从经验分布 $\hat{F}_n$ 中有放回地抽取 B 个 Bootstrap 样本, 计算每个样本的估计值 $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ 。则 Bootstrap 标准误为

$$\text{SE}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\hat{\theta}})^2}, \quad \bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b^*.$$

这在 MVUE 的解析标准误难以获得时特别有用。

本节小结。

- 估计 $g(\theta)$ 时, 先找 θ 的完备充分统计量
- MVUE 或者是 T 的函数的期望, 或者通过条件期望改进
- Bootstrap 可用于估计 MVUE 的标准误

7. 7.7 The Case of Several Parameters

前面的讨论聚焦于单个参数。当分布涉及多个参数时, 我们需要联合充分统计量 (joint sufficient statistics) 的概念。

7.1. 联合充分统计量.

DEFINITION 7.5 (联合充分统计量). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本, 其中 $\theta \in \Omega \subset \mathbb{R}^p$. 设 $\mathbf{Y} = (Y_1, \dots, Y_m)$ 是统计量向量. 则 $\mathbf{Y}$ 是 θ 的联合充分统计量, 当且仅当

$$\frac{\prod_{i=1}^n f(x_i; \theta)}{f_{\mathbf{Y}}(\mathbf{y}; \theta)} = H(x_1, \dots, x_n),$$

其中 H 不依赖于 θ .

因子分解定理同样适用: 联合似然函数可分解为仅依赖 $\mathbf{y}$ 的因子和与参数无关的因子.

EXAMPLE 7.18 (双参数正态分布). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$, 其中 θ_1 是均值, θ_2 是方差.

联合 pdf 为

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi\theta_2}} \exp \left[-\frac{(x_i - \theta_1)^2}{2\theta_2} \right].$$

利用恒等式 $\sum (x_i - \theta_1)^2 = \sum x_i^2 - n\bar{x}^2 + n(\bar{x} - \theta_1)^2$, 可得

$$\prod f(x_i; \theta) = \exp \left[-\frac{n(\bar{x} - \theta_1)^2}{2\theta_2} \right] \cdot \frac{\exp \left[-\frac{1}{2\theta_2} \sum (x_i - \bar{x})^2 \right]}{(\sqrt{2\pi\theta_2})^n}.$$

因此 $(\bar{X}, \sum X_i^2)$ 或等价地 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量.

EXAMPLE 7.19 (均匀分布的双参数). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta_1, \theta_2) = \frac{1}{2\theta_2} I_{(\theta_1 - \theta_2, \theta_1 + \theta_2)}(x).$$

这是区间长度为 $2\theta_2$ 、中心为 θ_1 的均匀分布. 充分统计量为 $(Y_1, Y_n) = (\min X_i, \max X_i)$.

7.2. 多参数指数族.

DEFINITION 7.6 (m 参数指数族). 设 $f(x; \theta)$ 具有形式

$$f(x; \theta) = \exp \left[\sum_{j=1}^m p_j(\theta) K_j(x) + H(x) + q(\theta) \right], \quad x \in \mathcal{S}.$$

在正则条件下, 统计量

$$Y_j = \sum_{i=1}^n K_j(X_i), \quad j = 1, \dots, m$$

是 θ 的联合完备充分统计量 (当 $n > m$ 时).

EXAMPLE 7.20 (双参数指数族). $N(\theta_1, \theta_2)$ 可写为指数形式:

$$f(x; \theta_1, \theta_2) = \exp \left[-\frac{1}{2\theta_2} x^2 + \frac{\theta_1}{\theta_2} x - \frac{\theta_1^2}{2\theta_2} - \frac{1}{2} \log(2\pi\theta_2) \right].$$

取 $K_1(x) = x^2$, $K_2(x) = x$, 则联合充分统计量为 $(\sum X_i^2, \sum X_i)$, 与之前的结论一致.

多参数情况下的 MVUE: 设 $\delta = g(\theta)$ 是感兴趣的参数函数。若 $\mathbf{Y}$ 是联合完备充分统计量, 则 $E[\delta | \mathbf{Y}]$ 是 δ 的 MVUE。

本节小结.

- 多参数时需要联合充分统计量
- 双参数正态: $(\bar{X}, S^2)$ 是联合完备充分统计量
- 多参数指数族具有联合完备充分统计量

8. 7.8 Minimal Sufficiency and Ancillary Statistics

充分统计量不唯一——任何一一变换 (one-to-one transformation) 还是充分统计量。但我们总希望找到“最小”的充分统计量, 用最少的统计量包含全部信息。

8.1. 最小充分统计量.

DEFINITION 7.7 (最小充分统计量). 设 T 是充分统计量。若对任何其他充分统计量 T' , T 都是 T' 的函数, 则称 T 是**最小充分统计量** (*minimal sufficient statistic*)。

直观理解: 最小充分统计量是“最压缩”的充分统计量——无法在保持充分性的前提下进一步压缩。

一个关键洞察: 若 MLE $\hat{\theta}$ 是充分的, 则 $\hat{\theta}$ 必是最小充分统计量 (因为任何其他充分统计量都能导出 $\hat{\theta}$)。

EXAMPLE 7.21 (均匀分布 $(\theta - 1, \theta + 1)$ 的最小充分统计量). 设 $X_1, \dots, X_n$ 来自 $Uniform(\theta - 1, \theta + 1)$ 分布。

联合 pdf 中出现的指示函数要求 $\theta - 1 < \min x_i \leq x_j \leq \max x_i < \theta + 1$ 。因此 $(Y_1, Y_n) = (\min X_i, \max X_i)$ 是充分统计量。

由于无法进一步压缩 (两个统计量缺一不可), 它们是最小充分统计量。注意这与单参数情况不同——无法用一个统计量替代两个。

一般位置模型: 若 $X_i = \theta + W_i$, 其中 W_i iid, 则顺序统计量 $(Y_1, \dots, Y_n)$ 是最小充分的。但有时也可以进一步压缩——例如正态分布时 $\bar{X}$ 就足够了。

8.2. 辅助统计量 (Ancillary Statistics). 充分统计量包含关于参数的全部信息。辅助统计量的分布则完全不含参数信息——看似是充分性的“对立面”。

DEFINITION 7.8 (辅助统计量). 设 $Z = u(X_1, \dots, X_n)$ 是统计量。若 Z 的分布不依赖于 θ , 则称 Z 是**辅助统计量** (*ancillary statistic*)。

例子:

- $N(\theta, 1)$ 分布中, S^2 是辅助统计量 (其分布不依赖于 θ)
- 尺度模型 $X_i = \theta W_i$ 中, X_1/X_2 是辅助统计量

辅助统计量揭示了数据中与参数无关的部分。虽然看似无用, 但它们在构建置信区间和检验中很有价值。

EXAMPLE 7.22 (位置不变统计量). 设 $X_i = \theta + W_i, W_i \text{ iid}$. 统计量 $Z = u(X_1, \dots, X_n)$ 若满足

$$u(x_1 + d, \dots, x_n + d) = u(x_1, \dots, x_n), \quad \forall d,$$

则是位置不变的。直观上, 这意味着 Z 只描述 W_i 的性质, 因此与 θ 无关。

常见的例子包括: 样本方差 S^2 、样本极差 $\max X_i - \min X_i$ 、以及 $\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 。

EXAMPLE 7.23 (尺度不变统计量). 设 $X_i = \theta W_i, \theta > 0, W_i \text{ iid}$. 若 Z 满足

$$u(cx_1, \dots, cx_n) = u(x_1, \dots, x_n), \quad \forall c > 0,$$

则是尺度不变的。

例子: $X_1/(X_1 + X_2)$ 、 $X_1^2/\sum X_i^2$ 、 $\min X_i/\max X_i$ 。

辅助统计量与充分统计量的关系将在下节的 Basu 定理中揭示。

本节小结.

- 最小充分统计量是充分统计量的一一变换后仍保持充分性
- 若 MLE 是充分的, 则它必是最小充分的
- 辅助统计量的分布不含参数信息
- 位置/尺度不变统计量是常见的辅助统计量

9. 7.9 Sufficiency, Completeness, and Independence

本节揭示充分性、完备性与独立性之间的深刻联系——Basu 定理。

9.1. Basu 定理的动机. 我们已经知道:

- 若 T 是充分的, 则 Z 的条件分布 $h(z | t)$ 不依赖于 θ
- 若 T 和 Z 独立, 则 Z 的边际分布 $g_2(z) = h(z | t)$ 不依赖于 θ ——即 Z 是辅助的

反过来: 若 Z 是辅助的 (分布不含 θ), T 是充分的, T 和 Z 是否独立?

直觉上似乎应该独立——但这需要证明。

9.2. Basu 定理.

THEOREM 7.7 (Basu 定理). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本, $\theta \in \Omega$ (Ω 是区间)。设 T 是 θ 的完备充分统计量。设 $Z = u(X_1, \dots, X_n)$ 是另一个统计量。

若 Z 的分布不依赖于 θ (即 Z 是辅助的), 则 T 与 Z 独立。

证明思路: 考虑 T 和 Z 的联合 pdf $g_1(t; \theta)h(z | t)$ 。 Z 的边际分布为

$$\int g_1(t; \theta)h(z | t)dt = g_2(z),$$

不依赖于 θ 。同时 $g_2(z) = \int g_2(z)g_1(t; \theta)dt$ 。两式相减得

$$\int [g_2(z) - h(z | t)]g_1(t; \theta)dt = 0, \quad \forall \theta.$$

由于 T 是完备的, 上式意味着 $g_2(z) - h(z | t) = 0$ 几乎处处成立, 即 $h(z | t) = g_2(z)$, 故 T 与 Z 独立。

核心洞察: 完备性是独立性的关键——它保证了期望为零的函数必为零函数。

EXAMPLE 7.24 (正态分布中 $\bar{X}$ 与 S^2 的独立性). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知。则 $\bar{X}$ 是 θ 的完备充分统计量。

样本方差 S^2 是位置不变的——其分布不依赖于 θ 。由 Basu 定理, $\bar{X}$ 与 S^2 独立。这与我们在第 3 章用到的结果一致。

EXAMPLE 7.25 (指数分布中 T 与尺度不变量的独立性). 设 $X_1, X_2 \sim \text{Exp}(\theta)$ 。则 $Y_1 = X_1 + X_2$ 是完备充分统计量。

考虑比值 $Z = X_1 / (X_1 + X_2)$ 。这是尺度不变的 ($Z(cX_1, cX_2) = Z(X_1, X_2)$), 因此 Z 的分布不含 θ 。

由 Basu 定理, Y_1 与 Z 独立。实际上, $Z \sim \text{Beta}(1, 1)$ (均匀分布), 与指数分布的参数无关。

EXAMPLE 7.26 (正态双参数中 $\bar{X}, S^2$ 与辅助量的独立性). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$ 。则 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量。

考虑统计量

$$Z = \frac{\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

该统计量满足位置-尺度不变性, 因此其分布不含 (θ_1, θ_2) 。由 Basu 定理, Z 与 $(\bar{X}, S^2)$ 独立。

9.3. Basu 定理的应用. Basu 定理的价值在于:

- (1) 提供独立性证明的简洁方法 (无需计算联合分布)
- (2) 揭示了“信息对立”: 完备充分统计量与辅助统计量正交
- (3) 辅助统计量虽然不含参数信息, 但可用于构建置信区间 (如枢轴量)

重要注记: 若充分统计量不是完备的, Basu 定理不适用——此时辅助统计量可能与充分统计量不独立, 辅助统计量中可能仍包含关于参数的条件信息。

EXAMPLE 7.27 (非完备情况下的条件信息). 在均匀分布 $(\theta - 1, \theta + 1)$ 例子中, 充分统计量是 $(Y_1, Y_n) = (\min X_i, \max X_i)$, 但它们不是完备的。

令 $T_1 = (Y_1 + Y_n)/2$ (θ 的无偏估计) 和 $T_2 = Y_n - Y_1$ (辅助的)。虽然 T_2 是辅助的, 但给定 $T_2 = t_2$ 的条件下, T_1 的方差为 $(2 - t_2)^2/12$ ——较小的 t_2 意味着 T_1 有更大的方差。

这说明 T_2 虽然是边缘意义下的辅助统计量, 但在条件意义下仍提供关于估计精度的信息。

这种情况在实际中很重要: 当样本来自非正态分布时, 样本均值 $\bar{X}$ 和样本方差 S^2 可能相关, S^2 的值能提供关于 $\bar{X}$ 精度的信息。

本节小结.

- *Basu* 定理：完备充分统计量与任何辅助统计量独立
- 独立性证明的新工具：无需计算联合分布
- 若充分统计量非完备，辅助统计量可能携带条件信息
- 这解释了为什么正态分布中 $\bar{X}$ 与 S^2 的独立性如此特别

Optimal Statistical Tests

Chapter 8 Overview

在前几章中，我们建立了估计理论和假设检验的基本框架。我们学会了如何构造点估计、区间估计，以及如何使用似然比检验。但在所有这些讨论中，一个根本性的问题始终潜伏在幕后：

在所有可能的检验中，哪个检验是“最好”的？

这个问题——即**最优检验理论 (optimal test theory)**——是本章的核心。在假设检验中，我们面临一个固有的权衡 (*trade-off*)：降低第一类错误 (*Type I error*) 的概率往往意味着提高第二类错误 (*Type II error*) 的概率，反之亦然。最优检验理论试图在固定的显著性水平下，找到功效 (*power*) 最高的检验。

为什么需要最优性理论？ 考虑一个医学检测场景：我们希望设计一个检验来筛查某种疾病。给定显著性水平 $\alpha = 0.05$ ，我们当然希望当患者真的患病时，检验能以最高概率检测出来——这就是功效。没有最优性理论，我们只能在黑暗中摸索不同的检验方法，无法保证我们选择的检验是最佳的。

本章建立这套理论的路径如下：

- (1) **Neyman-Pearson 引理** (8.1 节)：对于简单假设对简单假设的情况，给出了最优检验的完整刻画——这是整个理论的基石。
- (2) **一致最大功效检验 (UMP)** (8.2 节)：将最优性概念推广到复合备择假设。介绍 *monotone likelihood ratio (MLR)* 和 *Karlin-Rubin* 定理——单参数指数族存在 UMP 检验。
- (3) **似然比检验 (LRT)** (8.3 节)：在一般复合假设下，LRT 提供了一种构造检验的通用方法。虽然 LRT 不一定是最优的，但在很多情况下它是渐近最优的。
- (4) **序贯概率比检验 (SPRT)** (8.4 节)：打破固定样本量的束缚，允许检验在数据积累过程中随时停止——Wald 的革命性贡献。
- (5) **极小化极大分类** (8.5 节)：将决策论框架应用于假设检验和分类问题。

1. 8.1 Most Powerful Tests

1.1. 问题的起源：什么是“最好”的检验。 在 4.5 节中，我们引入了假设检验的基本框架：给定原假设 H_0 和备择假设 H_1 ，我们构造一个临界区域 C ，当样本落入 C 时拒绝 H_0 。但正如我们在 4.5 节所见，对于同一对假设，存在无穷多个可能的检验——临界区域 C 的选择并非唯一。

在所有这些检验中，我们凭什么说一个比另一个更好？

要回答这个问题, 我们首先需要有一个评价标准。在假设检验中, 这个标准就是**功效 (power)**——当 H_1 为真时拒绝 H_0 的概率。直观上, 我们希望:

- (1) 在 H_0 为真时, 拒绝 H_0 的概率 (即 α , 显著性水平) 不超过预设值;
- (2) 在 H_1 为真时, 拒绝 H_0 的概率 (即功效) 尽可能高。

这就引出了“最好检验”的定义。

1.2. 简单假设对简单假设的最优检验. 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本, 其中 $\theta \in \Omega = \{\theta', \theta''\}$ (即只有两个可能的参数值)。我们考虑检验:

$$H_0: \theta = \theta' \quad \text{versus} \quad H_1: \theta = \theta''.$$

(8.1.1)

DEFINITION 8.1 (最佳临界区域). 设 C 是样本空间的一个子集。如果

- (a) $P_{\theta'}[\mathbf{X} \in C] = \alpha$ (大小为 α);
- (b) 对每一个满足 $P_{\theta'}[\mathbf{X} \in A] = \alpha$ 的子集 A , 都有

$$P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A],$$

则称 C 是检验 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ 的大小为 α 的**最佳临界区域 (best critical region of size α)**。

定义的直观含义: 在所有满足显著性水平 α 的检验中, 最佳临界区域对应的检验在 H_1 为真时具有最高的拒绝概率——这正是我们想要的。

为什么要关心最佳检验? 设想你在设计一个药物试验。你设定 $\alpha = 0.05$ (即当药物无效时, 只有 5% 的概率错误地拒绝 H_0)。在所有满足这个条件的检验中, 你当然希望当药物真的有效时, 以最高概率检测出来——这就是最佳检验的价值。

那么, 这样的最佳检验是否存在? *Neyman-Pearson* 定理给出了答案。

1.3. Neyman-Pearson 定理.

有没有一种系统性的方法构造最佳检验?

Neyman-Pearson 定理不仅回答了“最佳检验是否存在”的问题, 还给出了构造方法——它是以似然比 (*likelihood ratio*) 为基础的。

[*Neyman-Pearson*] 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本, 记似然函数为

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

设 θ' 和 θ'' 是 θ 的两个不同取值, $\Omega = \{\theta', \theta''\}$ 。设 $k > 0$ 是一个常数, C 是样本空间的一个子集, 满足:

- (a) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$ 对所有 $\mathbf{x} \in C$;

- (b) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k$ 对所有 $\mathbf{x} \in C^c$;
 (c) $\alpha = P_{H_0}[\mathbf{X} \in C]$.

则 C 是检验简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ 的、大小为 α 的最佳临界区域。

核心思想：似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x})$ 衡量了数据 $\mathbf{x}$ 更支持 H_0 还是更支持 H_1 。当这个比值很小时，数据更支持 H_1 ，因此我们拒绝 H_0 。

物理直觉：想象你在两个假设之间做选择。 $L(\theta'; \mathbf{x})$ 告诉我们“如果 H_0 为真，观察到这组数据的可能性有多大”； $L(\theta''; \mathbf{x})$ 在 H_0 下很小但在 H_1 下很大，这强烈暗示 H_1 才是正确的解释。

充分性：值得注意的是，定理的证明表明，如果存在一个大小为 α 的最佳检验，那么它的形式必然是上述似然比检验。而且，这个最佳检验（如果存在）是唯一的（在连续型情况下，除了一个零概率集；在离散型中可能存在多个）。¹

EXAMPLE 8.1 (二项分布下的最佳检验). 设 $X \sim \text{Binomial}(n = 5, p = \theta)$ ，考虑检验：

$$H_0: \theta = \frac{1}{2} \quad \text{versus} \quad H_1: \theta = \frac{3}{4}.$$

下表给出 $f(x; 1/2)$ 、 $f(x; 3/4)$ 以及它们的比值：

x	0	1	2	3	4	5
$f(x; 1/2)$	1/32	5/32	10/32	10/32	5/32	1/32
$f(x; 3/4)$	1/1024	15/1024	90/1024	270/1024	405/1024	243/1024
$f(x; 1/2)/f(x; 3/4)$	32/1	32/3	32/9	32/27	32/81	32/243

问题：构造大小 $\alpha = 1/32$ 的最佳检验。

比值 $f(x; 1/2)/f(x; 3/4)$ 在 $x = 5$ 处取得最小值 (32/243)。因此，最佳临界区域应包含那些使 H_0 看起来极不可能而 H_1 看起来极可能的数据点——即 $C = \{x = 5\}$ 。

验证： $P_{H_0}(X \in C) = f(5; 1/2) = 1/32 = \alpha$ ，且 $P_{H_1}(X \in C) = f(5; 3/4) = 243/1024 \approx 0.237$ 。

如果取 $\alpha = 6/32$ ，则最佳临界区域为 $\{x = 4, 5\}$ ，因为 $x = 4$ 和 $x = 5$ 的比值最小。此时

$$P_{H_1}(X \in \{4, 5\}) = \frac{405}{1024} + \frac{243}{1024} = \frac{648}{1024} \approx 0.633.$$

关键洞察：最佳检验包含了“最支持 H_1 而最不支持 H_0 ”的数据点——这正是似然比方法告诉我们的。²

EXAMPLE 8.2 (正态均值差假设的最优检验). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ ，考虑检验：

$$H_0: \theta = 0 \quad \text{versus} \quad H_1: \theta = 1.$$

构造最佳检验：似然函数为

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

¹Neyman-Pearson 引理的完整证明见附录 section 5.3。

²二项分布最佳检验的详细分析见附录 ??。

似然比为

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \exp \left(- \sum_{i=1}^n x_i + \frac{n}{2} \right).$$

令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$, 等价于

$$\sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

因此, 最佳临界区域是 $C = \{\mathbf{x} : \sum_{i=1}^n x_i \geq c\}$, 即基于样本均值 $\bar{X}$ 的检验。

确定临界值: 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故

$$c_1 = \frac{c}{n} = \frac{\frac{n}{2} - \log k}{n} = \frac{1}{2} - \frac{\log k}{n}.$$

给定显著性水平 α , 临界值为 $c_1 = q_\alpha(0, 1/\sqrt{n})$ ($N(0, 1/n)$ 的上 α 分位数)。

数值示例: 设 $n = 25$, $\alpha = 0.05$, 则 $c_1 = \text{qnorm}(0.95, 0, 1/5) = 0.329$ 。

功效计算: 当 H_1 为真时, $\bar{X} \sim N(1, 1/25)$, 功效为

$$Power = P_{H_1}(\bar{X} \geq 0.329) = 1 - \Phi \left(\frac{0.329 - 1}{1/5} \right) = 1 - \Phi(-3.355) \approx 0.9996.$$

也就是说, 当 $\theta = 1$ 时, 这个检验有约 99.96% 的概率正确拒绝 H_0 。³

EXAMPLE 8.3 (Poisson 对 Geometric 的检验). 设 $X_1, \dots, X_n \sim f(x)$, 其中

$$H_0 : f(x) = \frac{e^{-1}}{x!}, \quad x = 0, 1, 2, \dots \quad (\text{Poisson}(\lambda = 1)),$$

$$H_1 : f(x) = \left(\frac{1}{2}\right)^{x+1}, \quad x = 0, 1, 2, \dots \quad (\text{Geometric}(p = 1/2)).$$

构造最佳检验: 似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \frac{(2e^{-1})^n \cdot 2^{\sum x_i}}{\prod_{i=1}^n (x_i!)}.$$

令 $k = 1$ (对应某个特定的 α), 不等式化为

$$\frac{2^{\sum x_i}}{\prod_{i=1}^n (x_i!)} \leq \frac{e}{2}.$$

取 $n = 1$, 则临界区域为 $C = \{x_1 : x_1 = 0, 3, 4, 5, \dots\}$ 。

验证:

$$\alpha = P_{H_0}(X \in C) = 1 - \frac{e^{-1}}{1!} - \frac{e^{-1}}{2!} = 1 - \frac{2}{e} \approx 0.4482,$$

$$Power = P_{H_1}(X \in C) = 1 - \frac{1}{4} - \frac{1}{8} = 0.625.$$

这符合无偏性要求 (功效大于显著性水平)。⁴

无偏性 (Unbiasedness): 注意到所有最佳检验都满足一个共同性质——功效大于等于显著性水平。这意味着拒绝 H_0 (当它为假时) 的概率不小于错误拒绝它的概率。这在经济决策中是完全合理的——如果检验的功效低于 α , 那它的行为还不如随机猜测。

³正态均值检验的完整推导见附录 section 5.4。

⁴Poisson vs Geometric 检验的详细分析见附录 ??。

DEFINITION 8.2 (无偏检验). 设 C 是显著性水平为 α 的检验的临界区域。如果对所有 $\theta \in \omega_1$,

$$P_{\theta}(\mathbf{X} \in C) \geq \alpha,$$

则称该检验是**无偏的** (*unbiased*)。

推论 8.1.1 表明 *Neyman-Pearson* 最佳检验是无偏的——在 H_0 为假时拒绝它的概率不低于在 H_0 为真时错误拒绝它的概率。⁵

2. 8.2 Uniformly Most Powerful Tests

2.1. 从简单假设到复合假设. 上一节的 *Neyman-Pearson* 定理解决的是“简单假设对简单假设”的问题—— H_0 和 H_1 都各只有一个参数值。但在实际中, 备择假设通常是复合的 (*composite*), 例如:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

这里 H_1 包含无穷多个参数值。对于这样的问题, 我们自然希望找到一个检验, 它在 H_0 的每一个边界点上都是最佳的。

能否找到一个检验, 它对 $\theta > \theta'$ 中的每一个 θ 都是最佳检验?

这就是“一致最大功效 (*Uniformly Most Powerful, UMP*)”检验的思想。

DEFINITION 8.3 (UMP 检验). 设 C 是显著性水平为 α 的检验的临界区域。如果 C 是 H_0 对 H_1 中每一个简单假设的最佳临界区域, 则称 C 为大小为 α 的一致最大功效临界区域 (*UMP critical region*), 相应的检验称为 *UMP 检验* (*Uniformly Most Powerful test*)。

但 *UMP* 检验并不总是存在。例 8.2.3 展示了: 对于正态均值 $\sigma^2 = 1$ 已知时, 检验 $H_0: \theta = \theta'$ 对 $H_1: \theta \neq \theta'$ (双向备择) 不存在 *UMP* 检验——因为对 $\theta'' > \theta'$ 的最佳临界区域 (拒绝域在右尾) 与对 $\theta'' < \theta'$ 的最佳临界区域 (拒绝域在左尾) 形式完全不同, 无法统一。

这个例子揭示了一个深刻的事实: *UMP* 检验只在单向备择假设 (*one-sided alternatives*) 下才可能存在。

2.2. 单调似然比与 Karlin-Rubin 定理. 那么, 在什么条件下 *UMP* 检验存在呢? 答案藏在一种叫做“单调似然比 (*Monotone Likelihood Ratio, MLR*)”的性质中。

DEFINITION 8.4 (单调似然比). 设 $L(\theta, \mathbf{x})$ 是似然函数。如果对 $\theta_1 < \theta_2$, 比值

$$\frac{L(\theta_1; \mathbf{x})}{L(\theta_2; \mathbf{x})}$$

是统计量 $y = u(\mathbf{x})$ 的单调递减函数, 则称似然函数在 $y = u(\mathbf{x})$ 中有**单调似然比** (*monotone likelihood ratio, mlr*)。

⁵推论 8.1.1 的证明及无偏性的讨论见附录 ??。

为什么 MLR 如此重要? MLR 性质确保了对较大的 y (即更支持备择假设的数据), 我们统一拒绝 H_0 ——而不需要针对每一个具体的 θ'' 分别构造最佳检验。

[Karlin-Rubin 定理] 设随机样本来自密度 $f(x; \theta)$, 似然函数 $L(\theta, \mathbf{x})$ 在统计量 $Y = u(\mathbf{X})$ 中有单调似然比。考虑单向假设:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

则对任意显著性水平 α , UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y \geq c_Y,$$

其中临界值 c_Y 满足 $P_{\theta'}[Y \geq c_Y] = \alpha$ 。

核心洞察: 由于 MLR 性质, 对任何 $\theta'' > \theta'$, 最佳临界区域的形式都是 $Y \geq c$ ——它们恰好是同一个区域! 因此这个区域对所有 $\theta'' > \theta'$ 都是最佳的, 从而是一致最大功效的。

证明思路: 对固定的 $\theta'' > \theta'$, 由 Neyman-Pearson 定理, 最佳临界区域由似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x}) \leq k$ 给出。由于 MLR 性质, 这个不等式等价于 $Y \geq g^{-1}(k)$ ——即只依赖于数据的形状, 而不依赖于具体的 θ'' 值。⁶

EXAMPLE 8.4 (正态方差 UMP 检验). 设 $X_1, \dots, X_n \sim N(0, \theta)$, 其中 $\theta > 0$ 是方差。考虑检验:

$$H_0: \theta = \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然函数为

$$L(\theta; \mathbf{x}) = \left(\frac{1}{2\pi\theta}\right)^{n/2} \exp\left\{-\frac{1}{2\theta} \sum_{i=1}^n x_i^2\right\}.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left(\frac{\theta''}{\theta'}\right)^{n/2} \exp\left[-\left(\frac{\theta'' - \theta'}{2\theta'\theta''}\right) \sum_{i=1}^n x_i^2\right].$$

对 $\theta'' > \theta'$, 这是 $\sum x_i^2$ 的递减函数, 因此似然函数在 $Y = \sum X_i^2$ 中有 MLR。

由 Karlin-Rubin 定理, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad \sum_{i=1}^n X_i^2 \geq c,$$

其中 c 满足 $P_{\theta'}[\sum X_i^2 \geq c] = \alpha$ 。

数值示例: 设 $n = 15$, $\alpha = 0.05$, $\theta' = 3$ 。当 H_0 为真时, $\sum X_i^2/\theta' \sim \chi^2(n)$, 故

$$\frac{c}{3} = \chi_{0.95}^2(15) = 24.996 \quad \Rightarrow \quad c = 74.988.$$

即当 $\sum x_i^2 \geq 74.988$ 时拒绝 $H_0: \theta = 3$ 。⁷

⁶Karlin-Rubin 定理的完整证明见附录 section 5.5。

⁷正态方差 UMP 检验的详细推导见附录 ??。

EXAMPLE 8.5 (Bernoulli 分布的 UMP 检验). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$, 考虑检验:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left[\frac{\theta'(1-\theta'')}{\theta''(1-\theta')} \right]^{\sum x_i} \left(\frac{1-\theta'}{1-\theta''} \right)^n.$$

由于 $\theta' < \theta''$ 时 $\theta'(1-\theta'')/\theta''(1-\theta') < 1$, 该比值是 $Y = \sum X_i$ 的递减函数。因此似然函数在 $Y = \sum X_i$ 中有 MLR, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y = \sum_{i=1}^n X_i \geq c,$$

其中 c 由 $P_{\theta'}[Y \geq c] = \alpha$ 确定。

这正是我们直观上期望的: 观察到更多的成功次数, 就越有理由拒绝“成功率不高”的原假设。⁸

正规指数族 (Regular Exponential Family): 其实 Bernoulli 分布、正态分布 (方差已知)、Poisson 分布都属于一个更广泛的族——正规指数族。在这个族中, 只要自然参数是单调的, 就存在 UMP 检验。具体地, 如果分布有形式

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)],$$

且 $p(\theta)$ 是 θ 的递增函数, 则对假设 $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$, UMP 检验存在, 基于统计量 $Y = \sum_{i=1}^n K(X_i)$ 。⁹

3. 8.3 Likelihood Ratio Tests

3.1. 似然比检验的动机. 在前两节中, 我们学会了如何在简单假设对简单假设时构造最佳检验, 以及在具有 MLR 性质的族中对单向复合假设构造 UMP 检验。但现实中很多重要问题超出了这些范畴:

- 检验正态均值 $H_0: \mu = \mu_0$ (σ^2 未知) 对 $H_1: \mu \neq \mu_0$ ——不存在 UMP 检验 (双向备择);
- 检验两正态均值是否相等 $H_0: \mu_1 = \mu_2$ ——涉及多于一个参数;
- 一般复合假设——没有 MLR 性质可供利用。

在这些情况下, 我们转向一种通用但不一定最优的构造检验的方法——似然比检验 (**Likelihood Ratio Test, LRT**)。

为什么即使 LRT 不是最优的, 我们仍然使用它? 历史上, Neyman 和 Pearson 引入 LRT 的动机正是为了突破最佳检验只存在于简单假设的限制。LRT 继承了 Neyman-Pearson 定理的似然比思想 (用似然比衡量数据对假设的支持程度), 但将比较扩展到

⁸Bernoulli UMP 检验的 MLR 证明见附录 ??。

⁹正规指数族的 UMP 检验存在性讨论见附录 ??。

了复合假设。虽然在一般情况下 LRT 不能保证最优性，但它是渐近最优的——在样本量趋向无穷时， LRT 具有许多优良性质。¹⁰

3.2. LRT 的定义. 设 X 的密度为 $f(\mathbf{x}; \boldsymbol{\theta})$ ，参数 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$ 。考虑复合假设：

$$H_0 : \boldsymbol{\theta} \in \omega \quad \text{versus} \quad H_1 : \boldsymbol{\theta} \in \Omega \cap \omega^c, \quad (8.3.1)$$

其中 $\omega \subset \Omega$ 是参数空间的某个子集。

DEFINITION 8.5 (似然比). 似然比 (*Likelihood Ratio*) 定义为：

$$\Lambda(\mathbf{x}) = \frac{\sup_{\omega} L(\boldsymbol{\theta}; \mathbf{x})}{\sup_{\Omega} L(\boldsymbol{\theta}; \mathbf{x})} = \frac{L(\hat{\omega}; \mathbf{x})}{L(\hat{\Omega}; \mathbf{x})},$$

其中 $\hat{\omega}$ 是在约束 $\boldsymbol{\theta} \in \omega$ 下的 MLE, $\hat{\Omega}$ 是在无约束 $\boldsymbol{\theta} \in \Omega$ 下的 MLE。

直观含义：分子衡量数据在 H_0 约束下能达到的最大似然，分母衡量数据在无约束情况下能达到的最大似然。如果 H_0 为真，这两个值应该差不多，比值接近 1；如果 H_0 为假，无约束的似然会显著大于约束下的似然，比值会变小。因此我们在小比值时拒绝 H_0 ：

$$\text{Reject } H_0 \quad \text{if} \quad \Lambda(\mathbf{x}) \leq \lambda_0 < 1.$$

LRT 的一个关键性质：在 H_0 下， $-2 \log \Lambda$ 渐近服从 χ^2 分布，自由度为 $\dim(\Omega) - \dim(\omega)$ (在一定正则条件下)。这使得我们可以近似地确定临界值。

LRT 与 NP 引理的关系：当 $\Omega = \{\theta', \theta''\}$ (只有两点) 时， LRT 还原为 NP 似然比检验，此时它是最优的。但一般来说， LRT 不一定是最优的。

接下来我们把 LRT 应用到几个具体的重要情形——正态均值差和正态方差检验。

3.3. 8.3.1 正态均值差的 LRT.

EXAMPLE 8.6 (两样本 t 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_3)$ ，两组样本独立，共同方差 θ_3 未知。考虑检验：

$$H_0 : \theta_1 = \theta_2 \quad \text{versus} \quad H_1 : \theta_1 \neq \theta_2.$$

构造 LRT ：在 H_0 下 ($\theta_1 = \theta_2 = \mu$)，参数的 MLE 为

$$\hat{\mu} = \frac{n\bar{x} + m\bar{y}}{n + m}, \quad \hat{\sigma}_0^2 = \frac{1}{n + m} \left[\sum_{i=1}^n (x_i - \hat{\mu})^2 + \sum_{i=1}^m (y_i - \hat{\mu})^2 \right].$$

在无约束下 (H_1)，MLE 分别为 $\bar{x}$ 、 $\bar{y}$ 和

$$\hat{\sigma}^2 = \frac{1}{n + m} \left[\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 \right].$$

¹⁰ LRT 与 Neyman-Pearson 引理的关系讨论见附录 ??。

似然比为

$$\Lambda = \frac{L(\hat{\omega})}{L(\hat{\Omega})} = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2} \right)^{(n+m)/2}.$$

与 t 统计量的联系：可以证明

$$\Lambda^{2/(n+m)} = \frac{(n+m-2)}{(n+m-2) + T^2},$$

其中

$$T = \sqrt{\frac{nm}{n+m}} \frac{\bar{x} - \bar{y}}{S_p}, \quad S_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{n+m-2}.$$

T 服从自由度为 $n+m-2$ 的 t 分布（在 H_0 下）。由于 $\Lambda \leq \lambda_0 \Leftrightarrow |T| \geq c$, LRT 就是经典的两样本 t 检验。

数值示例：设 $n=10$, $m=6$, $\alpha=0.05$, 则临界值

$$c = t_{0.975}(14) = 2.1448.$$

如果 $|t| \geq 2.1448$, 拒绝 H_0 (认为两个总体均值不相等)。¹¹

功效函数：对于非中心 t 分布，当 $\theta_1 \neq \theta_2$ 时， T 服从非中心 t 分布，非中心参数为

$$\delta = \sqrt{\frac{nm}{n+m}} \frac{\theta_1 - \theta_2}{\sigma}.$$

给定 $\theta_3 = 100$, $n=20$, $m=15$, $\alpha=0.05$, $\Delta=5 = \theta_1 - \theta_2$, 临界值 $t_{0.975}(33) = 2.0345$, 非中心参数 $\delta_2 = 1.4639$, 功效约为

$$1 - pt(2.0345, 33, ncp = 1.4639) + pt(-2.0345, 33, ncp = 1.4639) \approx 0.2954.$$

即约 29.5% 的概率检测出均值为 5 的差异。¹²

稳健性注记： t 检验在正态性假设不满足时表现如何？在大样本下，由 *Slutsky* 定理，即使底层分布非正态，只要方差有限， t 统计量仍然渐近正态——因此 t 检验是渐近正确的。然而，在有限样本且严重非正态（特别是高度偏态）时， t 检验可能失效——实际显著性水平会偏离名义水平。¹³

3.4. 8.3.2 正态方差的 LRT.

EXAMPLE 8.7 (两方差相等的 F 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_4)$, 独立样本，考虑检验：

$$H_0 : \theta_3 = \theta_4 \quad \text{versus} \quad H_1 : \theta_3 \neq \theta_4.$$

可以证明（练习 8.3.11）， LRT 统计量可以化为

$$F = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)}{\sum_{i=1}^m (Y_i - \bar{Y})^2 / (m-1)}.$$

¹¹两样本 t 检验的完整推导见附录 ??。

¹²非中心 t 分布的功效计算见附录 ??。

¹³非正态情况下 t 检验的稳健性讨论见附录 ??。

(8.3.2)

在 H_0 下, $F \sim F(n-1, m-1)$ 。因此双向 LRT 为:

$$\text{Reject } H_0 \quad \text{if } F \leq c_1 \quad \text{or} \quad F \geq c_2,$$

其中 c_1 和 c_2 满足 $P(F \leq c_1) = P(F \geq c_2) = \alpha_1/2$ 。

重要警告: 与 t 检验不同, F 检验对正态性假设是敏感的。在非正态情况下, F 检验的名义水平和实际水平可能相差甚远 (可高达 0.80), 因此不应在正态性未经检验的情况下使用 F 检验。¹⁴

4. 8.4 *Sequential Probability Ratio Test

4.1. 固定样本量检验的局限性. 到目前为止, 我们讨论的所有检验都有一个共同假设: 样本量 n 是预先固定的。但在实际应用中, 固定样本量检验存在一个根本性的低效:

为什么要等到收集完所有 n 个样本才做决策? 为什么不能边收集边决策?

考虑一个质量控制场景: 你需要判断一条生产线是否正常 ($\theta = \theta_0$)。固定样本量方法要求你先收集 n 个样本, 然后做决策。但如果在第 5 个样本时, 数据就已经极其强烈地支持 H_1 (生产线已严重偏离正常状态), 继续等待其余 $n-5$ 个样本就是在浪费时间和资源。

1930 年代, *Abraham Wald* 提出了一个革命性的思想: 允许样本量根据数据动态确定——这就是序贯分析 (*sequential analysis*) 的诞生。

Wald 的序贯概率比检验 (*SPRT*) 不仅在概念上优雅, 而且在功效和样本量之间实现了最优权衡。

4.2. SPRT 的构造. 设 $X_1, X_2, \dots$ 是 *iid* 随机变量序列, 考虑检验:

$$H_0 : \theta = \theta' \quad \text{versus} \quad H_1 : \theta = \theta'',$$

其中 θ' 和 θ'' 是给定的具体值。

核心理念: 在每个步骤 n , 计算似然比

$$\Lambda_n = \frac{L(\theta'; x_1, \dots, x_n)}{L(\theta''; x_1, \dots, x_n)} = \prod_{i=1}^n \frac{f(x_i; \theta')}{f(x_i; \theta'')}.$$

如果 Λ_n 非常小 (即数据强烈支持 H_1), 我们就提前停止并拒绝 H_0 ; 如果 Λ_n 非常大 (即数据强烈支持 H_0), 我们就提前停止并接受 H_0 ; 如果 Λ_n 处于中间位置, 我们就继续观察下一个样本。

¹⁴方差 F 检验的稳健性问题见附录 ??。

具体地, 选取两个常数 $A < B$ (通常 $A = \beta/(1 - \alpha)$, $B = (1 - \beta)/\alpha$), $SPRT$ 的决策规则为:

$$(8.4.1) \quad \text{在第 } n \text{ 步, 停止采样并: } \begin{cases} \text{拒绝 } H_0 \text{ (接受 } H_1) & \text{if } \Lambda_n \leq A, \\ \text{接受 } H_0 \text{ (拒绝 } H_1) & \text{if } \Lambda_n \geq B, \\ \text{继续采样} & \text{if } A < \Lambda_n < B. \end{cases}$$

Wald 的关键近似: 在实际应用中, Wald 证明了可以通过近似 $A \approx \beta/\alpha$ 和 $B \approx (1 - \beta)/(1 - \alpha)$ 来设置常数, 其中 α 和 β 分别是目标第一类和第二类错误概率。

EXAMPLE 8.8 (Bernoulli 的 SPRT). 设 $X_i \sim \text{Bernoulli}(\theta)$, 检验 $H_0: \theta = 1/3$ 对 $H_1: \theta = 2/3$ 。

似然比为

$$\Lambda_n = \frac{(1/3)^{\sum x_i} (2/3)^{n - \sum x_i}}{(2/3)^{\sum x_i} (1/3)^{n - \sum x_i}} = 2^{n - 2\sum x_i}.$$

取对数并整理, 不等式 $A < \Lambda_n < B$ 等价于

$$c_0(n) = \frac{n}{2} - \frac{\log_2 B}{2} < \sum_{i=1}^n x_i < \frac{n}{2} - \frac{\log_2 A}{2} = c_1(n).$$

决策规则: 当 $\sum x_i \geq c_1(n)$ 时, 拒绝 H_0 ; 当 $\sum x_i \leq c_0(n)$ 时, 接受 H_0 ; 否则继续采样。

序贯抽样的图示: 想象一条随机游走——每观察一次 $X_i = 1$, 我们就向右跳 1 个单位; 每观察一次 $X_i = 0$, 我们就向左跳 1 个单位。只要这条路径处于上下边界之间, 我们就继续。一旦路径碰到上界 (强烈支持 H_1) 或下界 (强烈支持 H_0), 我们就停止并做出相应决策。¹⁵

EXAMPLE 8.9 (正态均值的 SPRT). 设 $X_1, X_2, \dots \sim N(\theta, 100)$, 检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$, 目标是使 $\alpha \approx \beta \approx 0.10$ 。

取 $A = 1/9$ 、 $B = 9$ 。似然比为

$$\Lambda_n = \exp\left(-\frac{6\sum x_i - 459n}{200}\right).$$

不等式 $A < \Lambda_n < B$ 化为

$$c_0(n) = \frac{153}{2}n - \frac{100}{3}\log 9 < \sum_{i=1}^n x_i < \frac{153}{2}n + \frac{100}{3}\log 9 = c_1(n).$$

决策规则: 在第 n 步, 当 $\sum x_i \geq c_1(n)$ 时拒绝 H_0 (认为 $\theta = 78$); 当 $\sum x_i \leq c_0(n)$ 时接受 H_0 (认为 $\theta = 75$); 否则继续采样。¹⁶

¹⁵Bernoulli SPRT 的详细分析见附录 ??。

¹⁶正态 SPRT 的完整推导见附录 ??。

SPRT 的吸引力：为什么 SPRT 如此重要？因为它在固定两类错误概率的同时，通常使用比固定样本量检验更少的样本。Wald 的近似理论表明，当 H_0 或 H_1 为真时，SPRT 的平均样本量 (Average Sample Number, ASN) 比相应的固定样本量检验小得多——有时能节省 50% 以上的样本。

SPRT 与质量控制：SPRT 的思想在工业质量控制中有广泛应用。CUSUM (累积和) 控制图就是 SPRT 的一个变体——它持续累积标准化后的偏离量 $\sum(Z_i - 0.5)$ (其中 Z_i 是标准化后的检验统计量)，一旦超出控制限就发出警报。与固定间隔的 Shewhart 控制图相比，CUSUM 能更快检测到过程均值的微小漂移。

5. 8.5 *Minimax and Classification Procedures

5.1. 8.5.1 极小化极大检验。在第 7 章的决策论框架中，我们介绍了极小化极大 (minimax) 原则：将最大风险最小化。将这个思想应用到假设检验中，会得到一个有趣的结论——Neyman-Pearson 最佳检验在某种意义上也是极小化极大的。

考虑简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ ，损失函数满足 $\mathcal{L}(\theta', \theta') = \mathcal{L}(\theta'', \theta'') = 0$ (正确决策无损失)，而 $\mathcal{L}(\theta', \theta'') > 0$ 和 $\mathcal{L}(\theta'', \theta') > 0$ (错误决策有损失)。¹⁷

此时风险函数为：

$$R(\theta', C) = \mathcal{L}(\theta', \theta'') \cdot \alpha, \quad R(\theta'', C) = \mathcal{L}(\theta'', \theta') \cdot \beta,$$

其中 α 是显著性水平， β 是 Type II 错误概率。

极小化极大原则要求选择 C 使得 $\max\{R(\theta', C), R(\theta'', C)\}$ 最小。可以证明，当 k 满足

$$\mathcal{L}(\theta', \theta'') \int_C L(\theta') = \mathcal{L}(\theta'', \theta') \int_{C^c} L(\theta'')$$

时 (即两类错误造成的风险相等)，临界区域 C 是极小化极大的。这个条件与 NP 似然比条件是一致的——本质上，最佳检验同时也是极小化极大检验 (当两类错误的相对代价被适当选择时)。¹⁸

EXAMPLE 8.10 (正态均值的极小化极大检验). 设 $X_1, \dots, X_{100} \sim N(\theta, 100)$ ，检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$ ，损失为 $\mathcal{L}(75, 78) = 3$ 、 $\mathcal{L}(78, 75) = 1$ 。

临界区域形如 $\bar{x} \geq c$ ，其中 c 满足：

$$3 \cdot P_{\theta=75}(\bar{X} \geq c) = P_{\theta=78}(\bar{X} < c).$$

¹⁷极小化极大检验的决策论框架见附录 ??。

¹⁸极小化极大检验的完整证明见附录 ??。

由于 $\bar{X} \sim N(\theta, 1)$ ，这化为

$$3[1 - \Phi(c - 75)] = \Phi(c - 78).$$

求解得 $c \approx 76.8$ 。此时显著性水平 $\alpha = 1 - \Phi(1.8) \approx 0.036$ ，功效为 $1 - \Phi(-1.2) \approx 0.885$ 。¹⁹

5.2. 8.5.2 分类问题. 极小化极大检验理论在分类 (*classification*) 问题中有直接应用。考虑一个二分类问题：我们观察到 (X, Y) ，需要判断它来自分布 $f(x, y; \theta')$ 还是 $f(x, y; \theta'')$ 。

这本质上就是假设检验问题——如果接受 H_0 ，就把 (X, Y) 分类为来自 θ' 类；如果拒绝 H_0 ，就分类为来自 θ'' 类。

由 *NP* 定理，最佳分类规则是似然比规则：

$$\frac{f(x, y; \theta')}{f(x, y; \theta'')} \leq k \implies \text{分类为 } \theta'' \text{ 类}.$$

若两类的先验概率为 π' 和 π'' ，则最优规则取 $k = \pi''/\pi'$ （当两类等可能时 $k = 1$ ）。

Fisher 线性判别函数：在正态分布的特殊情况下，似然比不等式化为一个线性函数 $ax + by \leq c$ ——这就是著名的 *Fisher* 线性判别函数。当参数未知时，用训练样本的均值和方差代替，就得到了 *Fisher* 判别函数。²⁰

[二元正态的线性判别] 设 (X, Y) 来自二元正态分布，参数为 $(\mu'_1, \mu'_2, \sigma_1^2, \sigma_2^2, \rho')$ 或 $(\mu''_1, \mu''_2, \sigma_1^2, \sigma_2^2, \rho'')$ 。则似然比不等式化为

$$ax + by \leq c,$$

其中 a 和 b 是由两个总体的均值向量和协方差矩阵决定的常数。这给出了一个**线性决策边界**——在二维空间中是一条直线，将平面分为两部分，分别对应两类。²¹

附录：公式推导

本附录包含 *Chapter 8* 中省略的完整推导。

¹⁹极小化极大检验的数值求解 (Newton 法) 见附录 ??。

²⁰Fisher 线性判别函数的完整推导见附录 ??。

²¹二元正态线性判别的详细推导见附录 ??。

5.3. Neyman-Pearson 引理的证明. 背景 (Background): 我们需要证明, 当临界区域 C 满足 NP 条件 (a) - (c) 时, 它是在固定显著性水平 α 下功效最高的检验。

已知条件 (Given):

- $L(\theta'; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta')$ 是 H_0 下的似然函数
- $L(\theta''; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta'')$ 是 H_1 下的似然函数
- 临界区域 C 满足:

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k, \quad \forall \mathbf{x} \in C; \quad \frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k, \quad \forall \mathbf{x} \in C^c.$$

- 任意其他满足 $P_{\theta'}[\mathbf{X} \in A] = \alpha$ 的区域 A 。

目标 (Goal): 证明 $P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A]$ 。

推导步骤 (Derivation Steps):

1. 写出功效差:

$$\int_C L(\theta'') - \int_A L(\theta'') = \int_{C \cap A^c} L(\theta'') - \int_{A \cap C^c} L(\theta'').$$

2. 由条件 (a): 在 C 上 $L(\theta'') \geq \frac{1}{k} L(\theta')$, 故

$$\int_{C \cap A^c} L(\theta'') \geq \frac{1}{k} \int_{C \cap A^c} L(\theta').$$

3. 由条件 (b): 在 C^c 上 $L(\theta'') \leq \frac{1}{k} L(\theta')$, 故

$$\int_{A \cap C^c} L(\theta'') \leq \frac{1}{k} \int_{A \cap C^c} L(\theta').$$

4. 将 (8.A.2) 和 (8.A.3) 代入 (8.A.1):

$$\int_C L(\theta'') - \int_A L(\theta'') \geq \frac{1}{k} \left[\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') \right].$$

5. 计算括号内项:

$$\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') = \int_C L(\theta') - \int_A L(\theta') = \alpha - \alpha = 0.$$

6. 由 (8.A.4) 和 (8.A.5) 得 $\int_C L(\theta'') - \int_A L(\theta'') \geq 0$, 即

$$P_{\theta''}[\mathbf{X} \in C] \geq P_{\theta''}[\mathbf{X} \in A].$$

证毕。

5.4. 正态均值 NP 检验的完整推导. 背景 (Background): 在例 8.1.2 中, 我们构造了正态均值差假设的 NP 检验。本节补充完整推导。

目标 (Goal): 对 $X_1, \dots, X_n \sim N(\theta, 1)$, 检验 $H_0: \theta = 0$ 对 $H_1: \theta = 1$, 求大小为 α 的最佳检验。

推导步骤 (Derivation Steps):

1. 写出似然函数:

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

2. 似然比:

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \frac{\exp \left[-\frac{1}{2} \sum x_i^2 \right]}{\exp \left[-\frac{1}{2} \sum (x_i - 1)^2 \right]} = \exp \left[-\sum_{i=1}^n x_i + \frac{n}{2} \right].$$

3. 令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$:

$$\exp \left[-\sum x_i + \frac{n}{2} \right] \leq k \iff \sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

4. 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故临界值

$$c_1 = \frac{c}{n} = \frac{1}{2} - \frac{\log k}{n} = q_\alpha(0, 1/\sqrt{n}).$$

5. 功效函数: 当 $\theta = 1$ 时, $\bar{X} \sim N(1, 1/n)$,

$$Power(\theta = 1) = P_{\theta=1}(\bar{X} \geq q_\alpha(0, 1/\sqrt{n})) = 1 - \Phi \left(\frac{q_\alpha(0, 1/\sqrt{n}) - 1}{1/\sqrt{n}} \right).$$

证毕。

5.5. Karlin-Rubin 定理的证明. 背景 (Background): 证明当似然函数有 *MLR* 性质时, 单向复合假设存在 *UMP* 检验。

已知条件 (Given):

- 似然函数 $L(\theta, \mathbf{x})$ 在 $Y = u(\mathbf{x})$ 中有 *MLR*: 对 $\theta_1 < \theta_2$, $L(\theta_1; \mathbf{x})/L(\theta_2; \mathbf{x}) = g(Y)$, 其中 g 是递减函数。
- 单向假设: $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$ 。

目标 (Goal): 证明检验 $\phi(\mathbf{x}) = 1$ 当 $Y \geq c_Y$, 其中 c_Y 满足 $P_{\theta'}[Y \geq c_Y] = \alpha$, 是 *UMP level α* 检验。

推导步骤 (Derivation Steps):

1. 对简单假设 $H'_0: \theta = \theta'$ 对 $\theta'' > \theta'$ 的最优性: 由 *NP* 定理, 最佳临界区域由

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$$

给出。由于 *MLR* 性质, $g(Y) \leq k \iff Y \geq g^{-1}(k)$ 。取 $c_Y = g^{-1}(k)$, 则对任意 $\theta'' > \theta'$, 临界区域 $C = \{Y \geq c_Y\}$ 是 $H'_0: \theta = \theta'$ 对 θ'' 的最佳检验。

2. 对所有 $\theta'' > \theta'$ 的一致性: 由于 *NP* 最佳临界区域的形式只依赖于 $Y \geq c_Y$ (而不依赖于具体的 θ''), $C = \{Y \geq c_Y\}$ 对所有 $\theta'' > \theta'$ 都是最佳的。

3. 无偏性 (保证 *level* 不超过 α): 设 $\gamma_Y(\theta) = P_\theta(Y \geq c_Y)$ 为功效函数。对 $\theta_1 < \theta_2$, 由第 1 步, C 是 θ_1 对 θ_2 的最佳检验, 故 $\gamma_Y(\theta_2) \geq \gamma_Y(\theta_1)$ 。因此 $\gamma_Y(\theta)$ 是 θ 的非降函数, $\max_{\theta \leq \theta'} \gamma_Y(\theta) = \gamma_Y(\theta') = \alpha$ 。故该检验是 *level α* 的。

综上, $C = \{Y \geq c_Y\}$ 是 *UMP level α* 检验。证毕。

ANOVA and Regression

Chapter 9 Overview

在前几章中，我们讨论了来自单个总体的样本推断，以及两个总体的比较。但实际中，我们常常面临更复杂的问题：

如果有三个、四个甚至更多个总体，我们该如何比较它们的均值？

这个问题——即**多组比较问题**——在农业实验、医学试验、工业质量控制等领域无处不在。例如，在一项评估不同肥料对作物产量影响的实验中，我们需要同时比较多个处理组；而在研究药物疗效时，我们可能需要同时评估多种药物的效果。

本章，我们从单样本 t 检验 $\rightarrow$ 两样本 t 检验 $\rightarrow$ 多组比较的自然推广，引入**方差分析 (Analysis of Variance, 简称 ANOVA)**。这一方法由 *Ronald Fisher* 在 1920 年代创立，起源于他在英国洛桑农业实验站的农业实验研究。*Fisher* 的核心思想是：将总变异分解为可解释的变异和随机误差，通过比较两者来判断处理效应是否显著。

本章路线图：

- (1) *One-Way ANOVA* $\rightarrow$ 组间/组内平方和分解 $\rightarrow F$ 检验
- (2) 非中心 χ^2 和 F 分布 $\rightarrow$ 备择假设下的分布
- (3) *Multiple Comparisons* $\rightarrow$ *Tukey* 法、*Bonferroni* 法（控制族误差率）
- (4) *Two-Way ANOVA* $\rightarrow$ 主效应、交互效应
- (5) 回归问题 $\rightarrow$ 最小二乘估计、几何解释（投影）
- (6) 二次型分布 $\rightarrow$ *Cochran* 定理——平方和分解的理论基础

1. 9.1 Introduction

在正式进入 ANOVA 之前，我们需要介绍一个重要的数学工具——**二次型 (quadratic form)**。

DEFINITION 9.1 (二次型). 设 $X_1, \dots, X_n$ 是 n 个变量， a_{ij} 是常数。形如

$$q(X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^n X_i a_{ij} X_j$$

的表达式称为 $X_1, \dots, X_n$ 的（二次）二次型。

为什么二次型重要？ 在统计推断中，许多关键的统计量都可以表示为二次型。例如，样本方差

$$(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

就是关于样本 $X_1, \dots, X_n$ 的一个二次型。理解二次型的分布性质, 是理解 ANOVA 和回归分析的理论基础。

2. 9.2 One-Way ANOVA

2.1. 问题的引入. 考虑 b 个独立的正态总体, 第 j 个总体的均值为 μ_j , 共同方差为 σ^2 。从第 j 个总体中抽取容量为 n_j 的随机样本 $X_{1j}, X_{2j}, \dots, X_{n_jj}$ 。记总样本量为 $n = \sum_{j=1}^b n_j$ 。

模型为:

$$X_{ij} = \mu_j + e_{ij}, \quad i = 1, \dots, n_j, \quad j = 1, \dots, b, \quad (9.2.1)$$

其中 e_{ij} 是 $iid N(0, \sigma^2)$ 随机误差。

我们想检验: 所有 b 个总体的均值是否相等——

$$H_0: \mu_1 = \mu_2 = \dots = \mu_b \quad vs \quad H_1: \mu_j \neq \mu_{j'} \text{ 对某些 } j \neq j'. \quad (9.2.2)$$

实际背景: 例如, b 种药物对某种疾病的疗效比较; 或 b 种肥料对作物产量的影响。这里“一种因素 (factor)”处于 b 个“水平 (level)”, 因此称为单因素实验 (*one-way layout*)。

2.2. 似然比检验的推导. 完全模型 (*full model*) 参数空间:

$$\Omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : -\infty < \mu_j < \infty, \quad 0 < \sigma^2 < \infty\}.$$

约束模型 (*reduced model*) 参数空间 (H_0 下):

$$\omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : \mu_1 = \dots = \mu_b = \mu, \quad 0 < \sigma^2 < \infty\}.$$

完全模型下的 MLE:

$$\hat{\mu}_j = \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\Omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2. \quad (9.2.7)$$

约束模型下的 MLE (此时等价于单样本问题):

$$\hat{\mu}_\omega = \bar{X}_{\cdot\cdot} = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.3)$$

似然比统计量简化后的形式为:

$$\Lambda^{n/2} = \frac{\hat{\sigma}_\Omega^2}{\hat{\sigma}_\omega^2}. \quad (9.2.9)$$

拒绝 H_0 等价于 F 统计量过大, 其中

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)}, \quad (9.2.11)$$

而

$$Q_3 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2, \quad Q_4 = \sum_{j=1}^b n_j (\bar{X}_{\cdot j} - \bar{X}_{\cdot\cdot})^2. \quad (9.2.10)$$

核心分解:

$$\underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2}_Q = \underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}_{Q_3(\text{组内})} + \underbrace{\sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2}_{Q_4(\text{组间})}. \quad (9.2.10)$$

在 H_0 下, $Q_3/\sigma^2 \sim \chi^2(n-b)$, $Q_4/\sigma^2 \sim \chi^2(b-1)$, 且二者独立。因此 $F \sim F(b-1, n-b)$ 。

2.3. ANOVA 表格. 单因素 ANOVA 的结果可以汇总为一张清晰的表格:

表 1. 单因素 ANOVA 表格

来源	平方和 (SS)	df	均方 (MS)	F 统计量	p 值
组间 (<i>Between</i>)	Q_4	$b-1$	$MSB = Q_4/(b-1)$	$\frac{MSB}{MSW}$	$\mathbb{P}(F > F_0)$
组内 (<i>Within</i>)	Q_3	$n-b$	$MSW = Q_3/(n-b)$		
总计 (<i>Total</i>)	Q	$n-1$			

EXAMPLE 9.1 (合金弹性模量). Devore (2012, 第 412 页) 报告了一项数据: 三种铸造工艺 (永久模具、压铸、石膏模具) 生产合金的弹性模量。三种工艺各有多次测量, 我们想知道铸造工艺是否显著影响弹性模量。

数据汇总后, $F = 12.565$, 自由度为 2 和 19, p 值为 0.0003。如此小的 p 值表明: 铸造工艺对弹性模量有显著影响。¹

3. 9.3 Noncentral χ^2 and F Distributions

3.1. 为什么需要非中心分布? 在前一节的 ANOVA 中, 我们在原假设 H_0 下推导了 F 统计量的分布。但在实际应用中, 我们更关心: 当 H_0 不成立 (即各组均值不全相等) 时, F 统计量的分布是什么? 这时就需要引入非中心 χ^2 分布和非中心 F 分布。

DEFINITION 9.2 (非中心 χ^2 分布). 设 $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, \dots, n$, 独立。则

$$Y = \sum_{i=1}^n \frac{X_i^2}{\sigma^2}$$

的 mgf 为

$$M(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}, \quad t < \frac{1}{2}. \quad (9.3.1)$$

此时称 $Y \sim \chi^2(r, \theta)$, 其中 $r = n$ 是自由度, $\theta = \sum_{i=1}^n \mu_i^2 / \sigma^2$ 是非中心参数 (*noncentrality parameter*)。

直观理解: 当所有 $\mu_i = 0$ 时, $\theta = 0$, 回到中心 χ^2 分布; 当某些 $\mu_i \neq 0$ 时, Y 的分布在中心 χ^2 的基础上向右偏移, θ 越大, 偏移越明显。

非中心 χ^2 分布的均值: $E(Y) = r + \theta$ (中心部分 r 加上非中心部分 θ)。

¹该例子的详细计算与 R 代码实现见附录 ??。

DEFINITION 9.3 (非中心 F 分布). 设 $U \sim \chi^2(r_1, \theta)$, $V \sim \chi^2(r_2)$, 独立。则

$$F = \frac{r_2 U}{r_1 V}$$

服从自由度为 r_1, r_2 、非中心参数为 θ 的非中心 F 分布, 记作 $F(r_1, r_2, \theta)$ 。

EXAMPLE 9.2 (One-Way ANOVA 的非中心参数). 对于 one-way ANOVA 模型 (9.2.1), 在备择假设 H_1 下, F 统计量的分子 $Q_4/\sigma^2 \sim \chi^2(b-1, \theta)$, 其中

$$\theta = \frac{1}{\sigma^2} \sum_{j=1}^b n_j (\mu_j - \bar{\mu})^2, \quad \bar{\mu} = \frac{1}{n} \sum_{j=1}^b n_j \mu_j. \quad (9.3.5)$$

当 H_0 成立时, $\theta = 0$, 回到中心 F 分布; 当 H_1 成立时, $\theta > 0$, F 分布向右偏移, 偏移程度由 θ 刻画。这解释了为什么 F 检验在 H_0 不成立时倾向于取更大的值。²

4. 9.4 Multiple Comparisons

当 one-way ANOVA 的 F 检验拒绝了 H_0 后, 我们自然想知道: 具体哪些组之间存在显著差异? 这就是多重比较问题 (*Multiple Comparison Problem, MCP*)。

4.1. 问题的核心矛盾. 对 b 个总体, 若进行所有 $\binom{b}{2}$ 个成对比较, 即使每个置信区间的置信水平为 95%, 整体的置信水平也会急剧下降。举例来说, 若 $b = 5$, 则共有 10 个成对比较, 每个比较犯错的概率为 5%, 至少有一次犯错的概率粗略估计为 $1 - (0.95)^{10} \approx 40\%$ 。

因此, 我们需要专门设计的方法来控制族误差率 (*Family-Wise Error Rate, FWER*) ——即在所有比较中至少有一次犯错的概率。

4.2. Bonferroni 方法. Bonferroni 方法基于一个简单的不等式: 对 k 个参数 θ_i , 若每个区间 I_i 的置信水平为 $1 - \alpha$, 则

$$P(\text{所有 } \theta_i \in I_i) \geq 1 - k\alpha. \quad (9.4.2)$$

核心思想: 将每个区间的置信水平从 $1 - \alpha$ 调整为 $1 - \alpha/k$, 则整体的置信水平至少为 $1 - \alpha$ 。

对 one-way ANOVA, 成对差值 $\mu_j - \mu_{j'}$ 的 Bonferroni 置信区间为:

$$\bar{X}_{\cdot j} - \bar{X}_{\cdot j'} \pm t_{\alpha/(2k), n-b} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.3)$$

优点: 通用性强, 适用于任何成对比较。缺点: 比较数量 k 越大, 区间越宽, 精度损失越大。

²非中心 F 分布的完整推导见附录 ??。

4.3. Tukey 方法. *Tukey* 方法利用学生化极差分布 (*Studentized range distribution*), 专为 *balanced* 设计的成对比较设计。

当所有组样本容量相等 ($n_j = a, j = 1, \dots, b$) 时, 所有成对比较的同时置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm q_{1-\alpha, b, n-b} \frac{\hat{\sigma}_{\Omega}}{\sqrt{a}}, \quad \forall j \neq j'. \quad (9.4.4)$$

其中 $q_{1-\alpha, b, n-b}$ 是自由度为 b 和 $n-b$ 的学生化极差分布分位数。

对于 *unbalanced* 情形, 使用 *Tukey-Kramer* 修正:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm \frac{q_{1-\alpha, b, n-b}}{\sqrt{2}} \hat{\sigma}_{\Omega} \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}. \quad (9.4.5)$$

EXAMPLE 9.3 (赛车速度比较). *Kitchens (1997)* 报告了一项实验: 比较五种汽车 (*Acura, Ferrari, Lotus, Porsche, Viper*) 的最高速度。每种车进行 6 次运行测试。整体 F 检验高度显著 ($F = 25.15, p \approx 0$)。Tukey 多重比较结果表明: *Ferrari* 和 *Porsche* 的平均速度显著快于其他三种车, 但 *Ferrari* 与 *Porsche* 之间速度差异不显著。³

4.4. Fisher 的保护 LSD 方法. *Fisher* 方法是一个两步程序:

- (1) 首先进行整体 F 检验; 若拒绝 H_0 ,
- (2) 再使用标准的成对 t 置信区间 (置信水平 $1 - \alpha$)。

Fisher 方法不保证整体覆盖率为 $1 - \alpha$, 但 F 检验提供了“保护”。模拟研究表明它在功效和实际误差率方面表现良好。

5. 9.5 Two-Way ANOVA

5.1. 双因素实验的引入. 在实际研究中, 我们常常需要同时考虑两个因素对结果的影响。例如:

- 作物产量: 同时受品种 (因素 A) 和肥料类型 (因素 B) 的影响
- 考试成绩: 同时受教学方法 (因素 A) 和班级规模 (因素 B) 的影响

这就是双因素方差分析 (*two-way ANOVA*)。

设因素 A 有 a 个水平, 因素 B 有 b 个水平, 每个组合有一个观测值 X_{ij} 。模型为:

$$X_{ij} = \mu + \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b, \quad (9.5.2)$$

其中 $e_{ij} \sim N(0, \sigma^2)$ iid, 且 $\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0$ 。

可加模型 (*additive model*) 意味着两个因素的影响是相互独立的——因素 A 的效应不随因素 B 的水平变化。

表 2. 双因素可加模型的单元格均值示例 ($a = 2, b = 3$)

	$B=1$	$B=2$	$B=3$
$A=1$	7	6	5
$A=2$	5	4	3

³该例子的 R 实现与详细结果分析见附录 ??。

在可加模型中，行均值轮廓线是**平行的**——这是可加模型的重要特征。

5.2. 假设检验. 我们需要检验两个主效应假设：

$$H_{0A} : \alpha_1 = \cdots = \alpha_a = 0 \quad \text{vs} \quad H_{1A} : \text{某些 } \alpha_i \neq 0, \quad (9.5.3)$$

$$H_{0B} : \beta_1 = \cdots = \beta_b = 0 \quad \text{vs} \quad H_{1B} : \text{某些 } \beta_j \neq 0. \quad (9.5.4)$$

检验 H_{0B} 的 F 统计量：

$$F_B = \frac{a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 / (b-1)}{\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2 / [(a-1)(b-1)]}. \quad (9.5.12)$$

在 H_{0B} 下， $F_B \sim F(b-1, (a-1)(b-1))$ 。

类似地，检验 H_{0A} 的 F 统计量 $F_A \sim F(a-1, (a-1)(b-1))$ 。

5.3. 9.5.1 Interaction between Factors. 交互效应发生在：一个因素的影响程度取决于另一个因素的水平时。

在模型中引入交互参数 γ_{ij} ：

$$\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij}, \quad (9.5.15)$$

其中 $\sum_i \gamma_{ij} = \sum_j \gamma_{ij} = 0$ 。

若所有 $\gamma_{ij} = 0$ ，则回到可加模型；若存在非零 γ_{ij} ，则两个因素之间存在**交互作用**。

图形诊断：在双因素实验中，绘制各行（因素 A 各水平）的均值轮廓线。若线条大致平行，则交互作用不明显；若线条明显交叉或分离，则表明存在交互效应。

EXAMPLE 9.4 (沥青混合料热导率). Devore (2012, 第 435 页) 研究了两个因素对沥青混合料热导率的影响：粘结剂等级 (PG58, PG64, PG70) 和粗骨料含量 (38%, 41%, 44%)。每个处理组合有 2 次重复。

R 分析结果：交互效应不显著 ($p = 0.4135$)，但两个主效应都非常显著 ($p = 0.0017$ 和 $p < 10^{-5}$)。因此接受可加模型，两个因素独立地影响热导率。⁴

6. 9.6 A Regression Problem

6.1. 为什么研究回归?. ANOVA 研究的是类别型 (categorical) 自变量对因变量的影响。但在许多实际问题中，自变量是连续型的。例如：

- 学生的学习时间 (连续) $\rightarrow$ 考试成绩
- 汽车的发动机排量 (连续) $\rightarrow$ 每加仑行驶里程
- 农作物的施肥量 (连续) $\rightarrow$ 作物产量

这就引出了**回归分析 (regression analysis)**——研究自变量 (通常记作 x) 与因变量 Y 之间关系的方法。

线性模型：假设 $E(Y) = \mu(x)$ 是 x 的线性函数——

$$Y_i = \alpha + \beta(x_i - \bar{x}) + e_i, \quad i = 1, \dots, n, \quad (9.6.1)$$

⁴该例子的详细 ANOVA 表和 R 代码见附录 ??。

其中 $e_i \sim N(0, \sigma^2)$ iid。

为什么假设 x 是已知的非随机变量？这是为了简化分析——我们把不确定性全部放在 Y 上。在实际中，如果 x 也是随机的，则需要联合分布建模；但在受控实验或观测研究中，将 x 视为固定设计点是合理的近似。

线性模型 vs 非线性模型：这里“线性”指的是对参数 (α, β) 线性，而非对 x 线性。因此 $\alpha + \beta x + \gamma x^2$ 仍是线性模型，而 $\alpha e^{\beta x}$ 不是。

6.2. 9.6.1 Maximum Likelihood Estimates. 对模型 (9.6.1)，似然函数为

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{[Y_i - \alpha - \beta(x_i - \bar{x})]^2}{2\sigma^2} \right\}. \quad (9.6.12)$$

最大化似然等价于最小化

$$H(\alpha, \beta) = \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2. \quad (9.6.3)$$

这正是最小二乘法 (*least squares*) ——选择使残差平方和最小的 α, β 。

几何直观： $|Y_i - \alpha - \beta(x_i - \bar{x})|$ 是点 (x_i, Y_i) 到直线 $y = \alpha + \beta(x - \bar{x})$ 的垂直距离。最小二乘法就是找到使所有这些距离平方和最小的直线。

MLE 的解：

$$\hat{\alpha} = \bar{Y}, \quad (9.6.3)$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (9.6.5)$$

$\hat{\sigma}^2$ 的 MLE:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2. \quad (9.6.8)$$

拟合值与残差：

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}(x_i - \bar{x}), \quad \hat{e}_i = Y_i - \hat{Y}_i. \quad (9.6.6)$$

估计量的分布：可以证明

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{pmatrix} \right). \quad (9.6.9)$$

EXAMPLE 9.5 (男子 1500 米奥运会成绩). 考虑 27 届奥运会男子 1500 米冠军成绩与年份的关系。年份为自变量 x ，时间为因变量 Y 。

R 拟合结果： $\hat{y} = 12.33 - 0.0044 \times \text{year}$ 。斜率的 95% 置信区间为 $(-0.00547, -0.00328)$ ——这意味着每年获胜时间平均减少约 0.004 分钟 (约 0.24 秒)。对 2020 年奥运会的预测时间约为 3.486 分钟。⁵

残差图诊断：在回归分析中，绘制残差 $\hat{e}_i$ vs 拟合值 $\hat{Y}_i$ 的散点图。如果图呈现随机散布，说明模型是合理的；如果出现系统模式 (如 U 形、漏斗形)，则提示模型设定有问题 (如遗漏非线性项、异方差等)。

⁵该例子的详细计算、残差图分析和预测区间见附录 ??。

6.3. 9.6.2 *Geometry of the Least Squares Fit. 最小二乘拟合有一个优美的几何解释。

将数据写成向量形式 $\mathbf{Y} = (Y_1, \dots, Y_n)'$, 设计矩阵 $\mathbf{X}$ 的列为 $\mathbf{1}$ 和 $\mathbf{x}_c = (x_1 - \bar{x}, \dots, x_n - \bar{x})'$ 。模型为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}). \quad (9.6.13)$$

设 V 为 $\mathbf{X}$ 列张成的 $\mathbb{R}^n$ 中的二维子空间 (拟合空间)。最小二乘估计 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 正是 $\mathbf{Y}$ 在子空间 V 上的正交投影——即使得 $\|\mathbf{Y} - \boldsymbol{\theta}\|^2$ 最小的 V 中元素。

几何分解:

$$\|\mathbf{Y}\|^2 = \|\hat{\boldsymbol{\theta}}\|^2 + \|\hat{\mathbf{e}}\|^2,$$

其中 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 是残差向量, 且 $\hat{\boldsymbol{\theta}} \perp \hat{\mathbf{e}}$ (残差与拟合空间正交)。这正是 ANOVA 中平方和分解的几何版本。

7. 9.7 A Test of Independence

在许多应用中, 我们需要检验两个连续变量 X 和 Y 是否独立。对于二元正态分布, X 和 Y 独立当且仅当它们的相关系数 $\rho = 0$ 。因此我们检验:

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0. \quad (9.7.1)$$

样本相关系数:

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}. \quad (9.7.1)$$

关键定理: 在 H_0 下 (即 $\rho = 0$ 时), R 的分布不依赖于 X 的具体分布——只要 X 与 Y 独立, R 的分布在正态情况下就有上式 (9.3.1) 给出的精确形式。特别是,

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t(n-2). \quad (9.7.3)$$

因此, H_0 的拒绝域为 $|T| \geq t_{\alpha/2, n-2}$, 或等价地 $|R| \geq c$ 。

Remark 的深层含义: R 的条件分布 (在给定 $X_1, \dots, X_n$ 下) 不依赖于 X_i 的具体值, 这意味着 R 与所有仅依赖于 X 的统计量独立。这是一个非常优雅的性质——样本相关系数在 $\rho = 0$ 时“不受” X 取值的影响。

8. 9.8 Distributions of Certain Quadratic Forms

前几节的分析依赖于一个共同的理论支柱: 某些二次型服从 χ^2 分布, 且它们相互独立。本节和下一节建立这一理论的严格基础。

设 $\mathbf{X}' = (X_1, \dots, X_n)$, 其中 $X_i \sim N(\mu_i, \sigma^2)$ iid。二次型 $Q = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}$ 的 mgf 为:

$$M_Q(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}. \quad (9.8.10)$$

特别地, 若 $\mathbf{A}$ 是对称幂等矩阵 ($\mathbf{A}^2 = \mathbf{A}$), 则 $Q \sim \chi^2(r, \theta)$, 其中 $r = \text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A})$, $\theta = \boldsymbol{\mu}' \mathbf{A} \boldsymbol{\mu} / \sigma^2$ 。若进一步 $\boldsymbol{\mu} = \mu \mathbf{1}$ 且 $\sum_{i,j} a_{ij} = 0$, 则 $\theta = 0$, Q 为中心 $\chi^2(r)$ 。

Cochran 定理的特例：若 $Q_1, \dots, Q_k$ 是相互独立的 χ^2 变量之和，且 $\sum \text{rank}(Q_i) = n$ ，则各 Q_i 独立。

9. 9.9 The Independence of Certain Quadratic Forms

最后一个理论工具：*Craig* 定理，给出了两个二次型独立的充要条件。

THEOREM 9.1 (Craig). 设 $\mathbf{X} \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$ 。对对称矩阵 $\mathbf{A}, \mathbf{B}$ ，令

$$Q_1 = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}, \quad Q_2 = \sigma^{-2} \mathbf{X}' \mathbf{B} \mathbf{X}.$$

则 Q_1 与 Q_2 独立当且仅当 $\mathbf{AB} = \mathbf{0}$ 。

这个定理在 ANOVA 中有重要应用：在 *one-way ANOVA* 中，组间平方和 Q_4 （对应某个幂等矩阵）与组内平方和 Q_3 （对应另一个幂等矩阵）满足 $\mathbf{AB} = \mathbf{0}$ ，因此独立——这正是 F 检验的理论基础。

推论：在回归模型中，拟合值的二次型与残差的二次型相互独立，反映了“被解释的变异”与“未被解释的变异”之间的正交性。

附录：公式推导

One-Way ANOVA 平方和恒等式的证明。 背景：在 *one-way ANOVA* 中，总平方和 Q 可以分解为组内平方和 Q_3 与组间平方和 Q_4 之和。这一恒等式是 F 检验的基石。

目标：证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2.$$

推导：记 $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和：

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零，因为对每个固定的 j ，

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。

□

One-Way ANOVA 检验统计量的分布. 背景: 推导 *one-way ANOVA* 中 F 统计量在原假设下的分布。

目标: 证明在 H_0 下, $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导:

步骤 1: Q_3 的分布。对每个固定的 j , 由样本方差性质, $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立, 故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2 \left(\sum_{j=1}^b (n_j - 1) \right) = \chi^2(n-b).$$

步骤 2: Q_4 与 Q_3 的独立性。注意 $\bar{X}_{.j}$ 与 Q_3 独立 (由正态样本的性质), 且 $\bar{X}_{..}$ 是 $\bar{X}_{.1}, \dots, \bar{X}_{.b}$ 的线性组合, 因此 $\bar{X}_{..}$ 也与 Q_3 独立。故 Q_4 ($\bar{X}_{.j}$ 的函数) 与 Q_3 独立。

步骤 3: Q_4 的分布。在 H_0 下, $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$, 故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各 $\bar{X}_{.j}$ 通过 $\bar{X}_{..}$ 而不独立。直接计算知 $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

步骤 4: F 分布。由步骤 1、2、3 及 F 分布定义,

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b). \quad (\text{A9.3})$$

□

非中心 χ^2 分布的均值和方差. 背景: 验证非中心 χ^2 分布的基本性质。

已知: $Y \sim \chi^2(r, \theta)$, *mgf* 为 $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。

目标: 求 $E(Y)$ 和 $\text{var}(Y)$ 。

推导:

由 *mgf*, $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。对 $M(t)$ 求导:

$$M'(t) = \left[r(1-2t)^{-r/2-1} + \frac{r\theta}{(1-2t)^{r/2+1}} \right] \exp \left\{ \frac{t\theta}{1-2t} \right\}.$$

故 $E(Y) = M'(0) = r + \theta$ 。

对 $M''(t)$ 在 $t=0$ 求值, 可得 $\text{var}(Y) = 2(r + 2\theta)$ 。⁶

最小二乘估计的几何解释. 背景: 回归最小二乘估计的正交投影几何。

目标: 证明 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是 $\mathbf{Y}$ 在 $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$ 上的正交投影。

推导: 由正交投影的定义, $\hat{\boldsymbol{\theta}}$ 满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}_c$ 都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0. \quad (\text{A9.4})$$

由 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 得 $\sum_i \hat{e}_i = 0$ (残差之和为零)。

⁶该推导的详细计算见附录 ??。

由 $\mathbf{x}'_e \hat{\mathbf{e}} = 0$ 并利用正规方程，可解出 $\hat{\alpha}$ 和 $\hat{\beta}$ 的表达式与 (9.6.3)、(9.6.5) 一致。故 $\hat{\boldsymbol{\theta}}$ 确为正交投影。 $\square$

附录：公式推导

0.1. Gamma 分布的矩母函数推导. 背景 (Background) : 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions) :

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given) :

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal) : 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps) :

1. 根据矩母函数定义:

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换: 令 $y = \frac{x(1-\beta t)}{\beta}$, 则 $x = \frac{\beta y}{1-\beta t}$, $dx = \frac{\beta}{1-\beta t} dy$ 。

3. 代入积分 (要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$):

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论: 因此, $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$, 定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background) : 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$, 方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given) :

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1-\beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1-\beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha-1)(1-\beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha+1)\beta^2(1-\beta t)^{-\alpha-2}.$$

3. 代入 $t=0$:

$$M'(0) = \alpha\beta(1-0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha+1)\beta^2(1-0)^{-\alpha-2} = \alpha(\alpha+1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha+1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (*degrees of freedom*)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 *cdf* 出发, 对 x_2 求导得到联合 *pdf*:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 *cdf* 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 *cdf* 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 *Leibniz* 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 *pdf* 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

0.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证: 边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$, 确实是合法的 pdf。

结论: 条件 pdf 公式得证。■

0.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发:

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望 (即关于 X_1 求平均):

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论: 全期望公式得证。■

0.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论: 条件均值的方差不超过原变量的方差, 等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

0.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论: 故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.11. 相关系数范围的推导. 背景 (Background): 我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 *Cauchy-Schwarz* 不等式证明。

目标 (Goal): 证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps):

1. *Cauchy-Schwarz* 不等式: 对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差, 令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$:

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方:

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此:

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论: 故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

0.12. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i\{h_i/k_i\} < t < \min_i\{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.14. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.15. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 *mgf* 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. *pmf* 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. *mgf* 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 *mgf* 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.16. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j | Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 *pmf*:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j | Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.17. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。

2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.18. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。

2. 则 $X = \sum_{j=1}^n I_j$ 。

3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。

4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.19. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1 - p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1) \cdots (n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} \rightarrow 1, \\ \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.20. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数：

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论： *Poisson* 分布的均值和方差相等，都等于参数 λ 。■

0.21. 卡方分布与正态分布的关系. 背景 (Background)： 卡方分布定义为标准正态平方和。

目标 (Goal)： 证明若 $Z \sim N(0, 1)$ ，则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps)：

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$ ，先求 cdf:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式:

$$f_Y(y) = \frac{1}{\Gamma(1/2) 2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论： 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.22. 卡方分布的可加性证明. 背景 (Background)： 卡方分布满足可加性：独立卡方变量之和仍为卡方分布。

目标 (Goal)： 证明若 $X_1 \sim \chi^2(m)$ ， $X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps)：

1. 由卡方分布与 Gamma 分布的关系： $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性（见定理 3.3.1）：若 $Y_1 \sim \Gamma(\alpha_1, \beta)$ ， $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立，则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此：

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf: $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$ ，故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论： 卡方分布具有可加性，自由度可累加。■

0.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1 + X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.24. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.25. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 *mgf* 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 *mgf*:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 *mgf* 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.26. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 *mgf* 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}\left[e^{(t/\sigma)X}\right] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 *mgf*, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.27. t 分布的推导. 背景 (*Background*): t 分布由标准正态和卡方分布构造而来。

目标 (*Goal*): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (*Derivation Steps*):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. *Jacobian*: $|J| = \sqrt{u/n}$ 。

3. 联合 *pdf*:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 *pdf* 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是固定（但未知）的常数，而区间 $[L, U]$ 是随机的（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何单次观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
" $P(\theta \in [L, U]) = 0.95$ "	否	θ 是固定的
"用此方法构造的区间中 95% 包含 θ "	是	概率在区间构造上
" $P(\theta \in [L, U] \mid \text{data}) = 0.95$ "	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (*confidence interval*) 这一术语是频率派概念，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (*prior distribution*)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5”的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1”的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在观测数据之前对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) 主观贝叶斯视角: 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) 客观贝叶斯视角: 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (<i>Prior</i>)	后验 (<i>Posterior</i>)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 *Chapter 4* 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于非参数方法 (*Nonparametric Methods*)
- 在 *Chapter 4* 的 §4.1.2 有简要提及 (直方图估计)
- 深入讨论在 *Chapter 10* (*Nonparametric Methods*)

简单区分：

场景	方法	章节
分布形式未知	非参数方法 (直方图、核密度估计)	<i>Chapter 10</i>
分布形式已知、参数未知	参数方法 (<i>MLE</i> 、 <i>CI</i> 、检验)	<i>Chapter 4</i>

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个承上启下的关键过渡。

1. 防止误解：学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。

2. 揭示张力：无偏性只是一个基本要求，不是“最优性”的保证。无偏的估计量可以有有很多，且各有优劣。

3. 引出 MLE：正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计 (*MLE*) 被提出的动机。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 *MLE* 作为统一原则

具体例子：

- S^2 (无偏) 和 $\hat{\sigma}^2$ (有偏，但 *MLE*)
- 两者都常用，但各有用途
- “最优”需要更精确的定义 (后续章节的 *UMVUE*)

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 *Stein* 风格的典型特征，强调“为什么需要”而非直接罗列。

学习笔记.