

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;

如果没有对决策函数的限制（如要求无偏），很难找到统一最优的估计量。这促使我们聚焦于 MVUE——在无偏估计量的类中寻找方差最小者。

充分性的引入：如果我们有一个充分统计量 T ，那么所有无偏估计量都可以通过 Rao-Blackwell 过程改进为 T 的函数。这大大简化了 MVUE 的搜索。

本节小结.

- MVUE 在无偏估计量类中方差最小
- 寻找 MVUE 的困难在于无法枚举所有无偏估计量
- 充分统计量为这一问题提供了系统性的解决方案

2. 7.1 Measures of Quality of Estimators —Exercises

EXERCISE 7.1. **7.1 Unbiasedness and Variance of Sample Mean** –Hogg 7.1.1 Show that the mean $\bar{X}$ of a random sample of size n from a distribution having pdf $f(x; \theta) = (1/\theta)e^{-(x/\theta)}$, $0 < x < \infty$, $0 < \theta < \infty$, zero elsewhere, is an unbiased estimator of θ and has variance θ^2/n .

EXERCISE 7.2. **7.2 Unbiased Estimator for Normal Variance** –Hogg 7.1.2 Let $X_1, X_2, \dots, X_n$ denote a random sample from a normal distribution with mean zero and variance θ , $0 < \theta < \infty$. Show that $\sum_1^n X_i^2/n$ is an unbiased estimator of θ and has variance $2\theta^2/n$.

EXERCISE 7.3. **7.3 Unbiased Estimators from Uniform Order Statistics** –Hogg 7.1.3 Let $Y_1 < Y_2 < Y_3$ be the order statistics of a random sample of size 3 from the uniform distribution having pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, $0 < \theta < \infty$, zero elsewhere. Show that $4Y_1$, $2Y_2$, and $\frac{4}{3}Y_3$ are all unbiased estimators of θ . Find the variance of each of these unbiased estimators.

EXERCISE 7.4. **7.4 Optimal Linear Combination of Unbiased Estimators** –Hogg 7.1.4 Let Y_1 and Y_2 be two independent unbiased estimators of θ . Assume that the variance of Y_1 is twice the variance of Y_2 . Find the constants k_1 and k_2 so that $k_1Y_1 + k_2Y_2$ is an unbiased estimator with the smallest possible variance for such a linear combination.

EXERCISE 7.5. **7.5 Risk Comparison for Absolute Loss** –Hogg 7.1.5 In Example 7.1.2 of this section, take $\mathcal{L}[\theta, \delta(y)] = |\theta - \delta(y)|$. Show that $R(\theta, \delta_1) = \frac{1}{5}\sqrt{2/\pi}$ and $R(\theta, \delta_2) = |\theta|$. Of these two decision functions δ_1 and δ_2 , which yields the smaller maximum risk?

EXERCISE 7.6. **7.6 Risk Function for Poisson with Linear Decision** –Hogg 7.1.6 Let $X_1, X_2, \dots, X_n$ denote a random sample from a Poisson distribution with parameter θ , $0 < \theta < \infty$. Let $Y = \sum_1^n X_i$ and let $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$. If we restrict our considerations to decision functions of the form $\delta(y) = b + y/n$, where b does not depend on y , show that $R(\theta, \delta) = b^2 + \theta/n$. What decision function of this form yields a

uniformly smaller risk than every other decision function of this form? With this solution, say δ , and $0 < \theta < \infty$, determine $\max_{\theta} R(\theta, \delta)$ if it exists.

EXERCISE 7.7. *7.7 Minimum Risk under Squared Error for Normal Variance – Hogg 7.1.7* Let $X_1, X_2, \dots, X_n$ denote a random sample from a distribution that is $N(\mu, \theta)$, $0 < \theta < \infty$, where μ is unknown. Let $Y = \sum_1^n (X_i - \bar{X})^2/n$ and let $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$. If we consider decision functions of the form $\delta(y) = by$, where b does not depend upon y , show that $R(\theta, \delta) = (\theta^2/n^2)[(n^2 - 1)b^2 - 2n(n - 1)b + n^2]$. Show that $b = n/(n + 1)$ yields a minimum risk decision function of this form. Note that $nY/(n + 1)$ is not an unbiased estimator of θ . With $\delta(y) = ny/(n + 1)$ and $0 < \theta < \infty$, determine $\max_{\theta} R(\theta, \delta)$ if it exists.

EXERCISE 7.8. *7.8 Risk Function for Bernoulli with Linear Decision – Hogg 7.1.8* Let $X_1, X_2, \dots, X_n$ denote a random sample from a distribution that is $b(1, \theta)$, $0 \leq \theta \leq 1$. Let $Y = \sum_1^n X_i$ and let $\mathcal{L}[\theta, \delta(y)] = [\theta - \delta(y)]^2$. Consider decision functions of the form $\delta(y) = by$, where b does not depend upon y . Prove that $R(\theta, \delta) = b^2 n \theta (1 - \theta) + (bn - 1)^2 \theta^2$. Show that

$$\max_{\theta} R(\theta, \delta) = \frac{b^4 n^2}{4[b^2 n - (bn - 1)^2]},$$

provided that the value b is such that $b^2 n > (bn - 1)^2$. Prove that $b = 1/n$ does not minimize $\max_{\theta} R(\theta, \delta)$.

EXERCISE 7.9. *7.9 MLE and Fake Observations for Poisson – Hogg 7.1.9* Let $X_1, X_2, \dots, X_n$ be a random sample from a Poisson distribution with mean $\theta > 0$.

(a) Statistician A observes the sample to be the values $x_1, x_2, \dots, x_n$ with sum $y = \sum x_i$. Find the mle of θ .

(b) Statistician B loses the sample values $x_1, x_2, \dots, x_n$ but remembers the sum y_1 and the fact that the sample arose from a Poisson distribution. Thus B decides to create some fake observations, which he calls $z_1, z_2, \dots, z_n$ (as he knows they will probably not equal the original x -values) as follows. He notes that the conditional probability of independent Poisson random variables $Z_1, Z_2, \dots, Z_n$ being equal to $z_1, z_2, \dots, z_n$, given $\sum z_i = y_1$, is

$$\frac{\frac{\theta^{z_1} e^{-\theta}}{z_1!} \frac{\theta^{z_2} e^{-\theta}}{z_2!} \cdots \frac{\theta^{z_n} e^{-\theta}}{z_n!}}{\frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!}} = \frac{y_1!}{z_1! z_2! \cdots z_n!} \left(\frac{1}{n}\right)^{z_1} \left(\frac{1}{n}\right)^{z_2} \cdots \left(\frac{1}{n}\right)^{z_n}$$

since $Y_1 = \sum Z_i$ has a Poisson distribution with mean $n\theta$. The latter distribution is multinomial with y_1 independent trials, each terminating in one of n mutually exclusive and exhaustive ways, each of which has the same probability $1/n$. Accordingly, B runs such a multinomial experiment y_1 independent trials and obtains $z_1, z_2, \dots, z_n$. Find the likelihood function using these z -values. Is it proportional to that of statistician A?

3. 7.2 A Sufficient Statistic for a Parameter

上一节把困难暴露出来了：MVUE 的定义要求与所有无偏估计量比较，而决策论的风险函数又很难在所有 θ 上同时最优。因此我们不能只问“哪个公式更漂亮”，还要问“估计量到底用了数据中的哪一部分信息”。本节正式引入充分统计量，并建立判断充分性的核心工具——因子分解定理（Factorization Theorem）。

3.1. 为什么需要充分统计量？ 统计量 $Y = u(X_1, X_2, \dots, X_n)$ 本质上是对样本空间的一种划分（partition）。例如， $\bar{X} = 8.32$ 意味着所有满足 $\sum x_i = (8.32)n$ 的点 $(x_1, \dots, x_n)$ 被归入同一类。

给定一个统计量 $Y_1 = u_1(X_1, \dots, X_n)$ ，如果我们知道 $(X_1, \dots, X_n)$ 落在由 $Y_1 = y_1$ 确定的集合中，那么 $X_1, \dots, X_n$ 的条件分布可能仍然依赖于 θ 。如果这个条件分布**完全**不含 θ ，则 Y_1 包含了样本中关于 θ 的全部信息——这就是充分性的直觉。

EXAMPLE 7.3 (二项分布的充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 $Bernoulli(\theta)$ 分布的随机样本，即

$$f(x; \theta) = \theta^x (1 - \theta)^{1-x}, \quad x = 0, 1.$$

统计量 $Y_1 = \sum_{i=1}^n X_i$ 服从二项分布 $b(n, \theta)$ 。考虑条件概率

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n \mid Y_1 = y_1).$$

当且仅当 $\sum x_i = y_1$ 时该条件概率非零，此时

$$\frac{\theta^{x_1} (1 - \theta)^{1-x_1} \dots \theta^{x_n} (1 - \theta)^{1-x_n}}{\binom{n}{y_1} \theta^{y_1} (1 - \theta)^{n-y_1}} = \frac{1}{\binom{n}{y_1}},$$

该式不含 θ 。因此给定 $Y_1 = y_1$ ，数据的条件分布与 θ 无关—— Y_1 是 θ 的充分统计量。

这个例子的含义是：只要知道“成功次数” Y_1 是多少，就不再需要知道具体是哪几次试验成功了。 Y_1 已经包含了所有关于 θ 的信息。

3.2. 充分统计量的正式定义.

DEFINITION 7.2 (充分统计量). 设 $X_1, X_2, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是统计量，其 pdf 或 pmf 为 $f_{Y_1}(y_1; \theta)$ 。则 Y_1 是 θ 的**充分统计量**，当且仅当

$$\frac{f(x_1; \theta) f(x_2; \theta) \dots f(x_n; \theta)}{f_{Y_1}[u_1(x_1, \dots, x_n); \theta]} = H(x_1, \dots, x_n),$$

其中 $H(x_1, \dots, x_n)$ 不依赖于 θ 。

这个定义的要点是：分子是联合 pdf/pmf，分母是充分统计量的 pdf，比值只与原始数据有关而与 θ 无关。

3.3. 因子分解定理 (Factorization Theorem). 直接使用定义需要知道充分统计量的分布, 这往往很困难。Neyman 的因子分解定理提供了一个更实用的判定方法。

THEOREM 7.1 (Neyman 因子分解定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。统计量 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量, 当且仅当存在两个非负函数 k_1 和 k_2 , 使得

$$f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta) = k_1[u_1(x_1, \dots, x_n); \theta] \cdot k_2(x_1, \dots, x_n),$$

其中 $k_2(x_1, \dots, x_n)$ 不依赖于 θ 。

核心思想: 联合 pdf/pmf 可以分解为两部分——一部分只通过 $u_1(x_1, \dots, x_n)$ 依赖于 θ , 另一部分与 θ 无关。能完成这种分解的统计量就是充分的。也就是说, 我们不必先求出 Y_1 的边缘分布; 只要在联合密度里看清参数依赖如何通过 Y_1 进入即可。

EXAMPLE 7.4 (正态分布 $\bar{X}$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 $N(\theta, \sigma^2)$ 的样本, 其中 σ^2 已知。则

$$f(x_i; \theta) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x_i - \theta)^2}{2\sigma^2} \right].$$

联合 pdf 为

$$\prod_{i=1}^n f(x_i; \theta) = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^n \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

利用恒等式 $\sum (x_i - \theta)^2 = \sum (x_i - \bar{x})^2 + n(\bar{x} - \theta)^2$, 可得

$$\prod_{i=1}^n f(x_i; \theta) = \underbrace{\exp \left[-\frac{n(\bar{x} - \theta)^2}{2\sigma^2} \right]}_{k_1[\bar{x}; \theta]} \cdot \underbrace{\frac{\exp \left[-\frac{1}{2\sigma^2} \sum (x_i - \bar{x})^2 \right]}{(\sigma\sqrt{2\pi})^n}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\bar{X}$ 是 θ 的充分统计量。¹

EXAMPLE 7.5 (指数分布的充分统计量). 设 $X_1, \dots, X_n$ 是来自 $\Gamma(2, \theta)$ 分布的样本。已知 $\Gamma(\alpha, \beta)$ 分布的 mgf 为 $M(t) = (1 - \beta t)^{-\alpha}$, $t < 1/\beta$ 。

$Y_1 = \sum_{i=1}^n X_i$ 的 mgf 为 $[(1 - \theta t)^{-2}]^n = (1 - \theta t)^{-2n}$, 因此 $Y_1 \sim \Gamma(2n, \theta)$ 。

联合 pdf 为

$$\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2} = \frac{(\prod x_i) \exp(-\sum x_i/\theta)}{\theta^{2n}}.$$

给定 $Y_1 = y_1$ 时, 条件概率的比值为

$$\frac{\prod_{i=1}^n \frac{x_i e^{-x_i/\theta}}{\theta^2}}{\frac{y_1^{2n-1} e^{-y_1/\theta}}{\Gamma(2n)\theta^{2n}}} = \frac{\Gamma(2n) \prod x_i}{y_1^{2n-1}},$$

不含 θ 。故 $Y_1 = \sum X_i$ 是 θ 的充分统计量。

¹正态分布充分性的详细推导见附录 ??。

EXAMPLE 7.6 (乘积 $\prod X_i$ 的充分性). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0$$

的样本。这是参数化形式的 Beta 分布。

联合 pdf 为

$$\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta-1} = \underbrace{\theta^n \left(\prod_{i=1}^n x_i \right)^{\theta}}_{k_1[\prod x_i; \theta]} \cdot \underbrace{\frac{1}{\prod x_i}}_{k_2(x_1, \dots, x_n)}.$$

因此 $\prod_{i=1}^n X_i$ 是 θ 的充分统计量。

注意：使用因子分解定理时，必须正确处理支撑集 (support) 对参数的依赖。

EXAMPLE 7.7 (支撑集依赖参数的情况). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta) = e^{-(x-\theta)} \mathbb{I}_{(\theta, \infty)}(x).$$

一种错误的分解可能是：

$$\prod e^{-(x_i-\theta)} = [e^{3\theta}] [e^{-x_1-x_2-x_3}],$$

从而声称 $\max X_i$ 是充分的。但这是错误的，因为支撑集的交集必须满足 $\theta < \min x_i$ ，即

$$\prod \mathbb{I}_{(\theta, \infty)}(x_i) = \mathbb{I}_{(\theta, \infty)}(\min x_i).$$

正确的分解导致 $\min X_i$ 是充分统计量，而非 $\max X_i$ 。

本节小结.

- 充分统计量 T 保留了样本中关于 θ 的全部信息
- 因子分解定理是判断充分性的实用工具
- 注意支撑集对参数的依赖情况

4. 7.3 Properties of a Sufficient Statistic

充分统计量告诉我们哪些数据压缩没有丢失参数信息。下一步自然是：如果一个估计量还依赖于充分统计量之外的随机细节，能否把这些无关波动平均掉？Rao-Blackwell 定理正是这个问题的答案。

4.1. Rao-Blackwell 定理. 给定一个充分统计量 T ，我们可以把任意无偏估计量 Y_2 条件化为 $\varphi(T) = \mathbb{E}(Y_2 | T)$ 。这一步的直觉很清楚：在 T 已经固定、参数信息已经全部保留的前提下， Y_2 剩下的起伏只是无关噪声；对这些噪声取平均，会保留无偏性并降低方差。

THEOREM 7.2 (Rao-Blackwell 定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量。设 $Y_2 = u_2(X_1, \dots, X_n)$ (不是 Y_1 的函数) 是 θ 的无偏估计量。

则 $\mathbb{E}(Y_2 | y_1) = \varphi(y_1)$ 定义了一个统计量 $\varphi(Y_1)$ 。该统计量 $\varphi(Y_1)$ ：

- (1) 是 θ 的无偏估计量
- (2) 是充分统计量的函数
- (3) 方差不超过 Y_2 的方差

证明思路：利用全概率公式 $\mathbb{E}(Y_2) = \mathbb{E}[\mathbb{E}(Y_2 | Y_1)]$ 和条件方差不增性质 $\text{var}(Y_2) \geq \text{var}[\mathbb{E}(Y_2 | Y_1)]$ 。

这个定理的战略意义是：**在寻找 MVUE 时，只需在充分统计量的函数中搜索。**

EXAMPLE 7.8 (指数分布的 MVUE). 设 $X_1, \dots, X_n$ 是来自 pdf

$$f(x; \theta) = \theta e^{-\theta x}, \quad x > 0, \quad \theta > 0$$

的样本（这是 $\Gamma(1, 1/\theta)$ 分布）。

联合 pdf 为 $L(\theta) = \theta^n e^{-\theta \sum x_i}$ ，故 $Y_1 = \sum_{i=1}^n X_i$ 是充分统计量。

MLE 为 $Y_2 = 1/\bar{X} = n/Y_1$ 。由于 MLE 渐近无偏，我们计算其期望。 $Y_1 \sim \Gamma(n, 1/\theta)$ ，因此

$$\mathbb{E}(Y_2) = n \cdot \mathbb{E}(1/Y_1) = n \int_0^\infty \frac{\theta^n}{n!} t^{-1} t^{n-1} e^{-\theta t} dt = \frac{n}{n-1} \theta, \quad n > 1.$$

故 $(n-1)/n \cdot Y_2 = (n-1)/Y_1$ 是 θ 的无偏估计量，且是充分统计量的函数，因此是 MVUE。

4.2. 充分性与 MLE 的关系.

THEOREM 7.3 (充分性与 MLE). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$ ， $\theta \in \Omega$ 的随机样本。若 θ 的 MLE $\hat{\theta}$ 存在且唯一，则 $\hat{\theta}$ 是充分统计量的函数。

直觉：若 T 是充分的，则似然函数 $L(\theta) = f_T(t; \theta) \cdot H(\mathbf{x})$ 。 $L(\theta)$ 和 $f_T(t; \theta)$ 作为 θ 的函数同时达到最大值，故 $\hat{\theta}$ 必为 T 的函数。

这一结果具有重要的实践意义：对于指数族分布，MLE 通常可以解析地写成充分统计量的函数。

本节小结.

- Rao-Blackwell 定理：将任意无偏估计量改进为充分统计量的函数
- 充分性搜索范围：从所有统计量缩小到充分统计量的函数
- 若 MLE 存在且唯一，则必为充分统计量的函数

5. 7.4 Completeness and Uniqueness

有了 Rao-Blackwell 定理，我们知道 MVUE（若存在）必是充分统计量的函数。但充分统计量的函数可能有很多个：同一个充分统计量可以经过不同函数变换，得到许多不同的无偏估计。Rao-Blackwell 只告诉我们应当到哪里寻找，却还没有告诉我们如何保证答案唯一。

这就需要引入**完备性 (completeness)** 的概念。它的作用不是再压缩数据，而是排除“看起来不同、期望却总是相同”的函数自由度。

5.1. 完备性的定义.

DEFINITION 7.3 (完备族). 设随机变量 Z (连续型或离散型) 的 pdf 或 pmf 是族 $\{h(z; \theta) : \theta \in \Omega\}$ 的一页。若条件 $\mathbb{E}[u(Z)] = 0$ 对所有 $\theta \in \Omega$ 成立能够推出 $u(z) = 0$ (除了一个对每个 $h(z; \theta)$ 概率为零的点集), 则称该族为**完备族 (complete family)**。

简言之: 只有零函数才能期望为零。

EXAMPLE 7.9 (泊松分布族的完备性). 设 $X_1, \dots, X_n$ 是来自 $Poisson(\theta)$ 分布的样本。已知 $Y_1 = \sum X_i$ 是充分统计量, 其 pmf 为

$$g(y_1; \theta) = \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!}, \quad y_1 = 0, 1, 2, \dots$$

设 $\mathbb{E}[u(Y_1)] = 0$ 对所有 $\theta > 0$ 成立, 即

$$\sum_{y_1=0}^{\infty} u(y_1) \frac{(n\theta)^{y_1} e^{-n\theta}}{y_1!} = 0.$$

由于 $e^{-n\theta} \neq 0$, 可得

$$u(0) + nu(1)\theta + \frac{n^2 u(2)}{2!} \theta^2 + \dots = 0, \quad \forall \theta > 0.$$

无穷幂级数对所有 $\theta > 0$ 为零, 意味着所有系数必为零:

$$u(0) = u(1) = u(2) = \dots = 0.$$

故泊松充分统计量族是完备的。

EXAMPLE 7.10 (指数分布族的完备性). 设 $Z \sim Exp(\theta)$, 即 pdf 为 $h(z; \theta) = \frac{1}{\theta} e^{-z/\theta}$, $z > 0$ 。

设 $\mathbb{E}[u(Z)] = 0$ 对所有 $\theta > 0$ 成立:

$$\int_0^{\infty} u(z) \frac{1}{\theta} e^{-z/\theta} dz = 0, \quad \forall \theta > 0.$$

令 $t = z/\theta$, 则 $\theta dt = dz$:

$$\int_0^{\infty} u(\theta t) e^{-t} dt = 0, \quad \forall \theta > 0.$$

对 θ 求导并利用积分号内可微 (假设 u 满足适当条件), 可得 $u(\theta t) \equiv 0$ 。由拉普拉斯变换的唯一性, $u \equiv 0$ 。故该族是完备的。

5.2. 完备充分统计量与 MVUE 的唯一性.

THEOREM 7.4 (Lehmann-Scheffé 定理). 设 $X_1, \dots, X_n$ 是来自 pdf 或 pmf $f(x; \theta)$, $\theta \in \Omega$ 的随机样本。设 $Y_1 = u_1(X_1, \dots, X_n)$ 是 θ 的充分统计量, 且族 $\{f_{Y_1}(y_1; \theta) : \theta \in \Omega\}$ 是完备的。

若存在 Y_1 的一个函数是 θ 的无偏估计量, 则该函数是唯一的 MVUE。

证明思路：设 $\varphi(Y_1)$ 和 $\psi(Y_1)$ 都是 Y_1 的无偏估计量函数。则 $\mathbb{E}[\varphi(Y_1) - \psi(Y_1)] = 0$ 对所有 θ 成立。由完备性， $\varphi(y_1) - \psi(y_1) = 0$ 几乎处处成立，即两个估计量函数几乎处处相等——这就是“唯一”含义。

战略意义：完备充分统计量的无偏函数就是 MVUE。

EXAMPLE 7.11 (均匀分布最大值的 MVUE). 设 $X_1, \dots, X_n$ 是来自 $Uniform(0, \theta)$ 的样本。 $Y_n = \max\{X_i\}$ 是充分统计量 (习题 7.2.3)，其 pdf 为

$$g(y_n; \theta) = \frac{ny_n^{n-1}}{\theta^n}, \quad 0 < y_n < \theta.$$

验证完备性：设 $\mathbb{E}[u(Y_n)] = 0$ 对所有 $\theta > 0$ 成立，

$$\int_0^\theta u(t) \frac{nt^{n-1}}{\theta^n} dt = 0.$$

等价于 $\int_0^\theta u(t)t^{n-1}dt = 0$ 。对 θ 求导得 $u(\theta)\theta^{n-1} = 0$ ，故 $u(\theta) = 0$ 对所有 $\theta > 0$ 成立。故 Y_n 是完备充分的。

计算 $\mathbb{E}(Y_n) = \frac{n}{n+1}\theta$ ，故 $(n+1)/n \cdot Y_n$ 是 θ 的 MVUE。

EXAMPLE 7.12 (非完备的情况). 设 $X \sim N(0, \theta)$ ， $\theta > 0$ 。则 $Y = \sum X_i^2$ 是充分统计量，但族 $\{f_Y(y; \theta)\}$ 不是完备的 (因为 χ^2 分布的自由度参数不依赖于 θ 的形式)。

实际上，若 $Z \sim \chi_{n-1}^2$ (与 Y 独立)，则 $\mathbb{E}(Z) = n-1$ ，但这并不能推出关于 Y 的任何约束。

本节小结.

- 完备性：只有零函数才能期望为零
- Lehmann-Scheffé 定理：完备充分统计量的无偏函数是唯一的 MVUE
- 寻找 MVUE 的策略：先找完备充分统计量，再在其函数中找无偏估计量

6. 7.5 The Exponential Class of Distributions

在前几节中，我们看到充分性和完备性是找到 MVUE 的关键。但如果每遇到一个模型都从定义开始验证充分性、再单独证明完备性，方法就显得过于零散。统计学中一个重要的经验是：许多常见分布共享同一种指数形式，而这种形式会自动把样本中的参数信息集中到若干个求和统计量里。本节介绍的**指数族分布 (exponential class)**正是这样一个具有优良性质的大类。

6.1. 正则指数族的定义.

DEFINITION 7.4 (正则指数族). 设 $f(x; \theta)$ 具有如下形式：

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)], \quad x \in \mathcal{S},$$

其中 $\mathcal{S}$ 是 X 的支撑集。若满足：

- (1) $\mathcal{S}$ 不依赖于 θ
- (2) $p(\theta)$ 是 $\theta \in \Omega$ 的非线性连续函数

(3) 若 X 连续, 则 $K'(x) \neq 0$ 且 $H(x)$ 在 $\mathcal{S}$ 上连续; 若 X 离散, 则 $K(x)$ 在 $\mathcal{S}$ 上非线性

则称 $f(x; \theta)$ 属于正则指数族 (*regular exponential class*)。

直觉: 指数形式 $e^{p(\theta)K(x)}$ 使得对数似然函数是 $K(x)$ 的线性函数, 从而 $\sum K(X_i)$ 自然成为充分统计量。

EXAMPLE 7.13 (正态分布 $N(0, \theta)$ 是指数族). $N(0, \theta)$ 的 pdf 可写为

$$f(x; \theta) = \frac{1}{\sqrt{2\pi\theta}} e^{-x^2/(2\theta)} = \exp \left[-\frac{1}{2\theta} x^2 - \frac{1}{2} \log(2\pi\theta) \right].$$

对应 $p(\theta) = -1/(2\theta)$, $K(x) = x^2$, $H(x) = -\frac{1}{2} \log(2\pi)$, $q(\theta) = -\frac{1}{2} \log(2\pi\theta)$ 。故 $N(0, \theta)$ 属于正则指数族。

若 $X_1, \dots, X_n \sim N(0, \theta)$, 则 $\sum X_i^2$ 是充分统计量。

EXAMPLE 7.14 (泊松分布是指数族). 泊松分布的 pmf 为

$$f(x; \theta) = e^{-\theta} \frac{\theta^x}{x!} = \exp[(\log \theta)x - \theta - \log(x!)].$$

对应 $p(\theta) = \log \theta$, $K(x) = x$, $q(\theta) = -\theta$, $H(x) = -\log(x!)$ 。故泊松分布属于正则指数族, $\sum X_i$ 是充分统计量。

反例: 均匀分布 $f(x; \theta) = 1/\theta$, $0 < x < \theta$ 的支撑集依赖于 θ , 因此不是正则指数族。

6.2. 指数族的核心定理.

THEOREM 7.5 (指数族充分统计量的性质). 设 $X_1, \dots, X_n$ 来自正则指数族, pdf/pmf 如定义所示。设 $Y_1 = \sum_{i=1}^n K(X_i)$ 。则:

(1) Y_1 的 pdf/pmf 具有形式

$$f_{Y_1}(y_1; \theta) = R(y_1) \exp[p(\theta)y_1 + nq(\theta)], \quad y_1 \in \mathcal{S}_{Y_1},$$

其中 $\mathcal{S}_{Y_1}$ 和 $R(y_1)$ 不依赖于 θ

$$(2) \mathbb{E}(Y_1) = -n \frac{q'(\theta)}{p'(\theta)}$$

$$(3) \text{var}(Y_1) = n \cdot \frac{p''(\theta)q'(\theta) - q''(\theta)p'(\theta)}{[p'(\theta)]^3}$$

THEOREM 7.6 (指数族统计量的完备性). 在正则指数族条件下, $Y_1 = \sum_{i=1}^n K(X_i)$ 是 θ 的完备充分统计量。

证明思路: 设 $\mathbb{E}[u(Y_1)] = 0$ 对所有 θ 成立。利用 Y_1 的分布形式, 可得

$$\int u(y_1) R(y_1) \exp[p(\theta)y_1] dy_1 = 0, \quad \forall \theta.$$

由于 $p(\theta)$ 是非线性连续函数, 该积分本质上是 $u(y_1)R(y_1)$ 的拉普拉斯变换。拉普拉斯变换为零意味着 $u(y_1)R(y_1) \equiv 0$ 。由于 $R(y_1) > 0$ (它是 pdf 的因子), 故 $u(y_1) \equiv 0$ 。

EXAMPLE 7.15 (正态均值 θ 的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知。则

$$f(x; \theta) = \exp \left[\frac{\theta}{\sigma^2} x - \frac{x^2}{2\sigma^2} - \log \sqrt{2\pi\sigma^2} - \frac{\theta^2}{2\sigma^2} \right].$$

故 $p(\theta) = \theta/\sigma^2$, $K(x) = x$, $q(\theta) = -\frac{\theta^2}{2\sigma^2}$ 。 $Y_1 = \sum X_i = n\bar{X}$ 是完备充分统计量。
 $\mathbb{E}(Y_1) = n\theta$, 故 $\varphi(Y_1) = Y_1/n = \bar{X}$ 是 θ 的唯一 MVUE。

指数族的战略价值: 对于指数族, 完备充分统计量可以通过观察直接写出, MVUE 也容易通过期望计算得到。

本节小结.

- 正则指数族具有形式 $e^{p(\theta)K(x)+H(x)+q(\theta)}$
- $\sum K(X_i)$ 是指数族的充分统计量
- 指数族统计量是完备充分的
- 指数族的 MVUE 可通过期望计算直接得到

7. 7.6 Functions of a Parameter

很多时候, 我们关心的不是参数 θ 本身, 而是其某个函数 $\delta = g(\theta)$ 。例如, 在 Bernoulli 模型中, θ 是成功概率, 但方差 $\theta(1-\theta)$ 也常常是实际问题中更直接的目标。前面建立的完备充分框架并不只服务于 θ 本身; 只要能找到 $g(\theta)$ 的无偏函数, Lehmann-Scheffé 定理同样给出唯一 MVUE。

7.1. 技术一: 观察法. 如果能通过观察 $\mathbb{E}[\varphi(Y_1)] = g(\theta)$ 解出 φ 就可直接得到 MVUE。

EXAMPLE 7.16 (二项分布方差的 MVUE). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$ 。 $Y = \sum X_i$ 是完备充分统计量。样本比例 Y/n 是 θ 的 MVUE。

现欲估计 $\delta = \theta(1-\theta)$, 即 $\text{var}(Y/n) = \theta(1-\theta)/n$ 。

MLE 为 $\tilde{\delta} = (Y/n)(1-Y/n)$ 。计算期望:

$$\mathbb{E}[\tilde{\delta}] = \mathbb{E} \left[\frac{Y}{n} \left(1 - \frac{Y}{n} \right) \right] = \frac{n-1}{n} \theta(1-\theta).$$

故 $\hat{\delta} = \frac{n}{n-1} \tilde{\delta} = \frac{Y(n-Y)}{n(n-1)}$ 是 δ 的 MVUE。

7.2. 技术二: 条件期望法. 若 Z 是 θ 的无偏估计量, 则 $\varphi(Y_1) = \mathbb{E}(Z | Y_1)$ 是 MVUE。

EXAMPLE 7.17 (正态分布累积概率的 MVUE). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ 。欲估计 $\mathbb{P}(X \leq c) = \Phi(c-\theta)$ 。

取 $Z = \mathbb{I}(X_1 \leq c)$, 则 $\mathbb{E}(Z) = \Phi(c-\theta)$, 是无偏的。

$(X_1, \bar{X})$ 的联合分布是二元正态, 条件分布 $X_1 | \bar{X} = \bar{x}$ 是正态, 均值为 $\bar{x}$, 方差为 $(n-1)/n$ 。

计算条件期望：

$$\mathbb{E}[Z \mid \bar{X} = \bar{x}] = \mathbb{P}(X_1 \leq c \mid \bar{X} = \bar{x}) = \Phi \left[\frac{\sqrt{n}(c - \bar{x})}{\sqrt{n-1}} \right].$$

这是 $\Phi(c - \theta)$ 的 MVUE。

7.3. 7.6.1 Bootstrap 标准误. 对于 MVUE，我们通常没有像 MLE 那样的渐近理论。但可以使用 Bootstrap 来获得标准误。

设 $\hat{\theta}$ 是基于原始样本的估计量。从经验分布 $\hat{F}_n$ 中有放回地抽取 B 个 Bootstrap 样本，计算每个样本的估计值 $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ 。则 Bootstrap 标准误为

$$\text{SE}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\hat{\theta}})^2}, \quad \bar{\hat{\theta}} = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b^*.$$

这在 MVUE 的解析标准误难以获得时特别有用。

本节小结.

- 估计 $g(\theta)$ 时，先找 θ 的完备充分统计量
- MVUE 或者是 T 的函数的期望，或者通过条件期望改进
- Bootstrap 可用于估计 MVUE 的标准误

8. 7.7 The Case of Several Parameters

前面的讨论聚焦于单个参数。但许多基本模型天然含有多个参数，例如正态分布同时有均值和方差。此时一个统计量往往无法承载全部信息，我们需要把充分性的思想推广到向量形式：用一组统计量共同保留关于整个参数向量的信息。

8.1. 联合充分统计量.

DEFINITION 7.5 (联合充分统计量). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本，其中 $\theta \in \Omega \subset \mathbb{R}^p$ 。设 $\mathbf{Y} = (Y_1, \dots, Y_m)$ 是统计量向量。则 $\mathbf{Y}$ 是 θ 的联合充分统计量，当且仅当

$$\frac{\prod_{i=1}^n f(x_i; \theta)}{f_{\mathbf{Y}}(\mathbf{y}; \theta)} = H(x_1, \dots, x_n),$$

其中 H 不依赖于 θ 。

因子分解定理同样适用：联合似然函数可分解为仅依赖 $\mathbf{y}$ 的因子和与参数无关的因子。

EXAMPLE 7.18 (双参数正态分布). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$ ，其中 θ_1 是均值， θ_2 是方差。

联合 pdf 为

$$\prod_{i=1}^n \frac{1}{\sqrt{2\pi\theta_2}} \exp \left[-\frac{(x_i - \theta_1)^2}{2\theta_2} \right].$$

利用恒等式 $\sum (x_i - \theta_1)^2 = \sum x_i^2 - n\bar{x}^2 + n(\bar{x} - \theta_1)^2$, 可得

$$\prod f(x_i; \boldsymbol{\theta}) = \exp \left[-\frac{n(\bar{x} - \theta_1)^2}{2\theta_2} \right] \cdot \frac{\exp \left[-\frac{1}{2\theta_2} \sum (x_i - \bar{x})^2 \right]}{(\sqrt{2\pi\theta_2})^n}.$$

因此 $(\bar{X}, \sum X_i^2)$ 或等价地 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量。

EXAMPLE 7.19 (均匀分布的双参数). 设 $X_1, \dots, X_n$ 来自 pdf

$$f(x; \theta_1, \theta_2) = \frac{1}{2\theta_2} \mathbb{I}_{(\theta_1 - \theta_2, \theta_1 + \theta_2)}(x).$$

这是区间长度为 $2\theta_2$ 、中心为 θ_1 的均匀分布。充分统计量为 $(Y_1, Y_n) = (\min X_i, \max X_i)$ 。

8.2. 多参数指数族.

DEFINITION 7.6 (m 参数指数族). 设 $f(x; \boldsymbol{\theta})$ 具有形式

$$f(x; \boldsymbol{\theta}) = \exp \left[\sum_{j=1}^m p_j(\boldsymbol{\theta}) K_j(x) + H(x) + q(\boldsymbol{\theta}) \right], \quad x \in \mathcal{S}.$$

在正则条件下, 统计量

$$Y_j = \sum_{i=1}^n K_j(X_i), \quad j = 1, \dots, m$$

是 $\boldsymbol{\theta}$ 的联合完备充分统计量 (当 $n > m$ 时)。

EXAMPLE 7.20 (双参数指数族). $N(\theta_1, \theta_2)$ 可写为指数形式:

$$f(x; \theta_1, \theta_2) = \exp \left[-\frac{1}{2\theta_2} x^2 + \frac{\theta_1}{\theta_2} x - \frac{\theta_1^2}{2\theta_2} - \frac{1}{2} \log(2\pi\theta_2) \right].$$

取 $K_1(x) = x^2$, $K_2(x) = x$, 则联合充分统计量为 $(\sum X_i^2, \sum X_i)$, 与之前的结论一致。

多参数情况下的 MVUE: 设 $\delta = g(\boldsymbol{\theta})$ 是感兴趣的参数函数。若 $\mathbf{Y}$ 是联合完备充分统计量, 则 $\mathbb{E}[\delta | \mathbf{Y}]$ 是 δ 的 MVUE。

本节小结.

- 多参数时需要联合充分统计量
- 双参数正态: $(\bar{X}, S^2)$ 是联合完备充分统计量
- 多参数指数族具有联合完备充分统计量

9. 7.8 Minimal Sufficiency and Ancillary Statistics

充分统计量不唯一——任何一一变换 (one-to-one transformation) 还是充分统计量。因此, “充分” 本身并不等于 “简洁”: 把充分统计量旁边再附加一堆无关统计量, 仍然充分, 却显然没有完成数据压缩的目标。我们总希望找到 “最小” 的充分统计量, 用最少的统计量包含全部信息。

9.1. 最小充分统计量.

DEFINITION 7.7 (最小充分统计量). 设 T 是充分统计量. 若对任何其他充分统计量 T' , T 都是 T' 的函数, 则称 T 是**最小充分统计量** (*minimal sufficient statistic*).

直观理解: 最小充分统计量是“最压缩”的充分统计量——无法在保持充分性的前提下进一步压缩。

一个关键洞察: 若 MLE $\hat{\theta}$ 是充分的, 则 $\hat{\theta}$ 必是最小充分统计量 (因为任何其他充分统计量都能导出 $\hat{\theta}$).

EXAMPLE 7.21 (均匀分布 $(\theta - 1, \theta + 1)$ 的最小充分统计量). 设 $X_1, \dots, X_n$ 来自 $Uniform(\theta - 1, \theta + 1)$ 分布。

联合 pdf 中出现的指示函数要求 $\theta - 1 < \min x_i \leq x_j \leq \max x_i < \theta + 1$ 。因此 $(Y_1, Y_n) = (\min X_i, \max X_i)$ 是充分统计量。

由于无法进一步压缩 (两个统计量缺一不可), 它们是最小充分统计量。注意这与单参数情况不同——无法用一个统计量替代两个。

一般位置模型: 若 $X_i = \theta + W_i$, 其中 W_i iid, 则顺序统计量 $(Y_1, \dots, Y_n)$ 是最小充分的。但有时也可以进一步压缩——例如正态分布时 $\bar{X}$ 就足够了。

9.2. 辅助统计量 (Ancillary Statistics). 充分统计量包含关于参数的全部信息。辅助统计量的分布则完全不含参数信息——看似是充分性的“对立面”。

DEFINITION 7.8 (辅助统计量). 设 $Z = u(X_1, \dots, X_n)$ 是统计量。若 Z 的分布不依赖于 θ , 则称 Z 是**辅助统计量** (*ancillary statistic*)。

例子:

- $N(\theta, 1)$ 分布中, S^2 是辅助统计量 (其分布不依赖于 θ)
- 尺度模型 $X_i = \theta W_i$ 中, X_1/X_2 是辅助统计量

辅助统计量揭示了数据中与参数无关的部分。虽然看似无用, 但它们在构建置信区间和检验中很有价值。

EXAMPLE 7.22 (位置不变统计量). 设 $X_i = \theta + W_i, W_i$ iid。统计量 $Z = u(X_1, \dots, X_n)$ 若满足

$$u(x_1 + d, \dots, x_n + d) = u(x_1, \dots, x_n), \quad \forall d,$$

则是位置不变的。直观上, 这意味着 Z 只描述 W_i 的性质, 因此与 θ 无关。

常见的例子包括: 样本方差 S^2 、样本极差 $\max X_i - \min X_i$ 、以及 $\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$ 。

EXAMPLE 7.23 (尺度不变统计量). 设 $X_i = \theta W_i, \theta > 0, W_i$ iid。若 Z 满足

$$u(cx_1, \dots, cx_n) = u(x_1, \dots, x_n), \quad \forall c > 0,$$

则是尺度不变的。

例子: $X_1/(X_1 + X_2)$ 、 $X_1^2/\sum X_i^2$ 、 $\min X_i/\max X_i$ 。

辅助统计量与充分统计量的关系将在下节的 Basu 定理中揭示。

本节小结.

- 最小充分统计量是充分统计量的一一变换后仍保持充分性
- 若 MLE 是充分的, 则它必是最小充分的
- 辅助统计量的分布不含参数信息
- 位置/尺度不变统计量是常见的辅助统计量

10. 7.9 Sufficiency, Completeness, and Independence

本节揭示充分性、完备性与独立性之间的深刻联系——Basu 定理。前面我们把数据分成两类：一类统计量携带关于参数的信息，另一类统计量的分布完全不含参数。Basu 定理说明，在完备充分的条件下，这两类信息不仅概念上分离，而且在概率意义下独立。

10.1. Basu 定理的动机. 我们已经知道：

- 若 T 是充分的, 则 Z 的条件分布 $h(z | t)$ 不依赖于 θ
- 若 T 和 Z 独立, 则 Z 的边际分布 $g_2(z) = h(z | t)$ 不依赖于 θ ——即 Z 是辅助的

反过来：若 Z 是辅助的（分布不含 θ ）， T 是充分的， T 和 Z 是否独立？直觉上似乎应该独立——但这需要证明。

10.2. Basu 定理.

THEOREM 7.7 (Basu 定理). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的样本, $\theta \in \Omega$ (Ω 是区间)。设 T 是 θ 的**完备充分统计量**。设 $Z = u(X_1, \dots, X_n)$ 是另一个统计量。

若 Z 的分布不依赖于 θ (即 Z 是辅助的), 则 T 与 Z 独立。

证明思路：考虑 T 和 Z 的联合 pdf $g_1(t; \theta)h(z | t)$ 。 Z 的边际分布为

$$\int g_1(t; \theta)h(z | t)dt = g_2(z),$$

不依赖于 θ 。同时 $g_2(z) = \int g_2(z)g_1(t; \theta)dt$ 。两式相减得

$$\int [g_2(z) - h(z | t)]g_1(t; \theta)dt = 0, \quad \forall \theta.$$

由于 T 是完备的, 上式意味着 $g_2(z) - h(z | t) = 0$ 几乎处处成立, 即 $h(z | t) = g_2(z)$, 故 T 与 Z 独立。

核心洞察：完备性是独立性的关键——它保证了期望为零的函数必为零函数。

EXAMPLE 7.24 (正态分布中 $\bar{X}$ 与 S^2 的独立性). 设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知。则 $\bar{X}$ 是 θ 的**完备充分统计量**。

样本方差 S^2 是位置不变的——其分布不依赖于 θ 。由 Basu 定理, $\bar{X}$ 与 S^2 独立。这与我们在第 3 章用到的结果一致。

EXAMPLE 7.25 (指数分布中 T 与尺度不变量的独立性). 设 $X_1, X_2 \sim \text{Exp}(\theta)$ 。则 $Y_1 = X_1 + X_2$ 是完备充分统计量。

考虑比值 $Z = X_1/(X_1 + X_2)$ 。这是尺度不变的 ($Z(cX_1, cX_2) = Z(X_1, X_2)$)，因此 Z 的分布不含 θ 。

由 Basu 定理, Y_1 与 Z 独立。实际上, $Z \sim \text{Beta}(1, 1)$ (均匀分布), 与指数分布的参数无关。

EXAMPLE 7.26 (正态双参数中 $\bar{X}, S^2$ 与辅助量的独立性). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_2)$ 。则 $(\bar{X}, S^2)$ 是 (θ_1, θ_2) 的联合完备充分统计量。

考虑统计量

$$Z = \frac{\sum_{i=1}^{n-1} (X_{i+1} - X_i)^2}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

该统计量满足位置-尺度不变性, 因此其分布不含 (θ_1, θ_2) 。由 Basu 定理, Z 与 $(\bar{X}, S^2)$ 独立。

10.3. Basu 定理的应用. Basu 定理的价值在于:

- (1) 提供独立性证明的简洁方法 (无需计算联合分布)
- (2) 揭示了“信息对立”: 完备充分统计量与辅助统计量正交
- (3) 辅助统计量虽然不含参数信息, 但可用于构建置信区间 (如枢轴量)

重要注记: 若充分统计量不是完备的, Basu 定理不适用——此时辅助统计量可能与充分统计量不独立, 辅助统计量中可能仍包含关于参数的**条件信息**。

EXAMPLE 7.27 (非完备情况下的条件信息). 在均匀分布 $(\theta - 1, \theta + 1)$ 例子中, 充分统计量是 $(Y_1, Y_n) = (\min X_i, \max X_i)$, 但它们不是完备的。

令 $T_1 = (Y_1 + Y_n)/2$ (θ 的无偏估计) 和 $T_2 = Y_n - Y_1$ (辅助的)。虽然 T_2 是辅助的, 但给定 $T_2 = t_2$ 的条件下, T_1 的方差为 $(2 - t_2)^2/12$ ——较小的 t_2 意味着 T_1 有更大的方差。

这说明 T_2 虽然是边缘意义下的辅助统计量, 但在条件意义下仍提供关于估计精度的信息。

这种情况在实际中很重要: 当样本来自非正态分布时, 样本均值 $\bar{X}$ 和样本方差 S^2 可能相关, S^2 的值能提供关于 $\bar{X}$ 精度的信息。

本节小结.

- Basu 定理: 完备充分统计量与任何辅助统计量独立
- 独立性证明的新工具: 无需计算联合分布
- 若充分统计量非完备, 辅助统计量可能携带条件信息
- 这解释了为什么正态分布中 $\bar{X}$ 与 S^2 的独立性如此特别

本章习题

EXERCISE 7.10. **7.10** *Sufficient Statistic for Normal Variance – Hogg 7.2.1* Let $X_1, X_2, \dots, X_n$ be iid $N(0, \theta)$, $0 < \theta < \infty$. Show that $\sum_{i=1}^n X_i^2$ is a sufficient statistic for θ .

EXERCISE 7.11. **7.11** *Poisson Sufficient Statistic – Hogg 7.2.2* Prove that the sum of the observations of a random sample of size n from a Poisson distribution having parameter θ , $0 < \theta < \infty$, is a sufficient statistic for θ .

EXERCISE 7.12. **7.12** *Uniform Maximum Sufficient Statistic – Hogg 7.2.3* Show that the n th order statistic of a random sample of size n from the uniform distribution having pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, $0 < \theta < \infty$, zero elsewhere, is a sufficient statistic for θ . Generalize this result by considering the pdf $f(x; \theta) = Q(\theta)M(x)$, $0 < x < \theta$, $0 < \theta < \infty$, zero elsewhere. Here, of course,

$$\int_0^\theta M(x)dx = \frac{1}{Q(\theta)}.$$

EXERCISE 7.13. **7.13** *Geometric Distribution Sufficiency – Hogg 7.2.4* Let $X_1, X_2, \dots, X_n$ be a random sample of size n from a geometric distribution that has pmf $f(x; \theta) = (1-\theta)^x \theta$, $x = 0, 1, 2, \dots$, $0 < \theta < 1$, zero elsewhere. Show that $\sum_{i=1}^n X_i$ is a sufficient statistic for θ .

EXERCISE 7.14. **7.14** *Gamma Sufficient Statistic – Hogg 7.2.5* Show that the sum of the observations of a random sample of size n from a gamma distribution that has pdf $f(x; \theta) = (1/\theta)e^{-x/\theta}$, $0 < x < \infty$, $0 < \theta < \infty$, zero elsewhere, is a sufficient statistic for θ .

EXERCISE 7.15. **7.15** *Beta Product Sufficient Statistic – Hogg 7.2.6* Let $X_1, X_2, \dots, X_n$ be a random sample of size n from a beta distribution with parameters $\alpha = \theta$ and $\beta = 5$. Show that the product $X_1 X_2 \dots X_n$ is a sufficient statistic for θ .

EXERCISE 7.16. **7.16** *Gamma Product Sufficient Statistic – Hogg 7.2.7* Show that the product of the sample observations is a sufficient statistic for $\theta > 0$ if the random sample is taken from a gamma distribution with parameters $\alpha = \theta$ and $\beta = 6$.

EXERCISE 7.17. **7.17** *Beta(θ, θ) Sufficient Statistic – Hogg 7.2.8* What is the sufficient statistic for θ if the sample arises from a beta distribution in which $\alpha = \beta = \theta > 0$?

EXERCISE 7.18. **7.18** *Truncated Exponential MLE and Sufficiency – Hogg 7.2.9* We consider a random sample $X_1, X_2, \dots, X_n$ from a distribution with pdf $f(x; \theta) = (1/\theta)\exp(-x/\theta)$, $0 < x < \infty$, zero elsewhere, where $0 < \theta$. Possibly, in a life-testing situation, however, we only observe the first r order statistics $Y_1 < Y_2 < \dots < Y_r$.

(a) Record the joint pdf of these order statistics and denote it by $L(\theta)$.

- (b) Under these conditions, find the mle, $\hat{\theta}$, by maximizing $L(\theta)$.
- (c) Find the mgf and pdf of $\hat{\theta}$.
- (d) With a slight extension of the definition of sufficiency, is $\hat{\theta}$ a sufficient statistic?

EXERCISE 7.19. **7.19** MLE as Function of Sufficient Statistic – Hogg 7.3.1 In each of Exercises 7.2.1–7.2.4, show that the mle of θ is a function of the sufficient statistic for θ .

EXERCISE 7.20. **7.20** Rao-Blackwell for Uniform Order Statistics – Hogg 7.3.2 Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ be the order statistics of a random sample of size 5 from the uniform distribution having pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, $0 < \theta < \infty$, zero elsewhere. Show that $2Y_3$ is an unbiased estimator of θ . Determine the joint pdf of Y_3 and the sufficient statistic Y_5 for θ . Find the conditional expectation $\mathbb{E}(2Y_3|y_5) = \varphi(y_5)$. Compare the variances of $2Y_3$ and $\varphi(Y_5)$.

EXERCISE 7.21. **7.21** Rao-Blackwell for Exponential Distribution – Hogg 7.3.3 If X_1, X_2 is a random sample of size 2 from a distribution having pdf $f(x; \theta) = (1/\theta)e^{-x/\theta}$, $0 < x < \infty$, $0 < \theta < \infty$, zero elsewhere, find the joint pdf of the sufficient statistic $Y_1 = X_1 + X_2$ for θ and $Y_2 = X_2$. Show that Y_2 is an unbiased estimator of θ with variance θ^2 . Find $\mathbb{E}(Y_2 | y_1) = \varphi(y_1)$ and the variance of $\varphi(Y_1)$.

EXERCISE 7.22. **7.22** Joint Distribution and Conditional Expectation – Hogg 7.3.4 Let $f(x, y) = (2/\theta^2)e^{-(x+y)/\theta}$, $0 < x < y < \infty$, zero elsewhere, be the joint pdf of the random variables X and Y .

- (a) Show that the mean and the variance of Y are, respectively, $3\theta/2$ and $5\theta^2/4$.
- (b) Show that $\mathbb{E}(Y|x) = x + \theta$. In accordance with the theory, the expected value of $X + \theta$ is that of Y , namely, $3\theta/2$, and the variance of $X + \theta$ is less than that of Y . Show that the variance of $X + \theta$ is in fact $\theta^2/4$.

EXERCISE 7.23. **7.23** Unbiased Estimators via Sufficient Statistics – Hogg 7.3.5 In each of Exercises 7.2.1–7.2.3, compute the expected value of the given sufficient statistic and, in each case, determine an unbiased estimator of θ that is a function of that sufficient statistic alone.

EXERCISE 7.24. **7.24** Conditional Expectation for Poisson – Hogg 7.3.6 Let $X_1, X_2, \dots, X_n$ be a random sample from a Poisson distribution with mean θ . Find the conditional expectation $\mathbb{E}(X_1 + 2X_2 + 3X_3 | \sum_{i=1}^n X_i)$.

EXERCISE 7.25. **7.25** Completeness of Binomial Family – Hogg 7.4.1 If $az^2 + bz + c = 0$ for more than two values of z , then $a = b = c = 0$. Use this result to show that the family $\{b(2, \theta) : 0 < \theta < 1\}$ is complete.

EXERCISE 7.26. **7.26** *Non-Complete Families – Hogg 7.4.2* Show that each of the following families is not complete by finding at least one nonzero function $u(x)$ such that $\mathbb{E}[u(X)] = 0$, for all $\theta > 0$.

- (a) $f(x; \theta) = \frac{1}{2\theta}$ for $-\theta < x < \theta$, zero elsewhere, where $0 < \theta < \infty$
 (b) $N(0, \theta)$, where $0 < \theta < \infty$.

EXERCISE 7.27. **7.27** *Binomial Complete Sufficient Statistic – Hogg 7.4.3* Let $X_1, X_2, \dots, X_n$ represent a random sample from the discrete distribution having the pmf

$$f(x; \theta) = \begin{cases} \theta^x (1 - \theta)^{1-x} & x = 0, 1, 0 < \theta < 1 \\ 0 & \text{elsewhere.} \end{cases}$$

Show that $Y_1 = \sum_{i=1}^n X_i$ is a complete sufficient statistic for θ . Find the unique function of Y_1 that is the MVUE of θ .

EXERCISE 7.28. **7.28** *Completeness of Uniform Family – Hogg 7.4.4* Consider the family of probability density functions $\{h(z; \theta) : \theta \in \Omega\}$, where $h(z; \theta) = 1/\theta$, $0 < z < \theta$, zero elsewhere.

- (a) Show that the family is complete provided that $\Omega = \{\theta : 0 < \theta < \infty\}$.

Hint: For convenience, assume that $u(z)$ is continuous and note that the derivative of $\mathbb{E}[u(Z)]$ with respect to θ is equal to zero also.

- (b) Show that this family is not complete if $\Omega = \{\theta : 1 < \theta < \infty\}$.

Hint: Concentrate on the interval $0 < z < 1$ and find a nonzero function $u(z)$ on that interval such that $\mathbb{E}[u(Z)] = 0$ for all $\theta > 1$.

EXERCISE 7.29. **7.29** *Complete Sufficient Statistic for Shifted Exponential – Hogg 7.4.5* Show that the first order statistic $Y_1 = \min(X_i)$ of a random sample of size n from the distribution having pdf $f(x; \theta) = e^{-(x-\theta)}$, $\theta < x < \infty$, $-\infty < \theta < \infty$, zero elsewhere, is a complete sufficient statistic for θ . Find the unique function of this statistic which is the MVUE of θ .

EXERCISE 7.30. **7.30** *Discrete Uniform MVUE – Hogg 7.4.6* Let a random sample of size n be taken from a distribution of the discrete type with pmf $f(x; \theta) = 1/\theta$, $x = 1, 2, \dots, \theta$, zero elsewhere, where θ is an unknown positive integer.

(a) Show that the largest observation, say Y , of the sample is a complete sufficient statistic for θ .

- (b) Prove that

$$[Y^{n+1} - (Y - 1)^{n+1}] / [Y^n - (Y - 1)^n]$$

is the unique MVUE of θ .

EXERCISE 7.31. **7.31** *Absolute Value Sufficiency and Completeness – Hogg 7.4.7* Let X have the pdf $f_X(x; \theta) = 1/(2\theta)$, for $-\theta < x < \theta$, zero elsewhere, where $\theta > 0$.

- (a) Is the statistic $Y = |X|$ a sufficient statistic for θ ? Why?

(b) Let $f_Y(y; \theta)$ be the pdf of Y . Is the family $\{f_Y(y; \theta) : \theta > 0\}$ complete? Why?

EXERCISE 7.32. **7.32** *Symmetric Distribution Completeness* – Hogg 7.4.8 Let X have the pmf $p(x; \theta) = \frac{1}{2} \binom{n}{|x|} \theta^{|x|} (1 - \theta)^{n-|x|}$, for $x = \pm 1, \pm 2, \dots, \pm n$, $p(0, \theta) = (1 - \theta)^n$, and zero elsewhere, where $0 < \theta < 1$.

(a) Show that this family $\{p(x; \theta) : 0 < \theta < 1\}$ is not complete.

(b) Let $Y = |X|$. Show that Y is a complete and sufficient statistic for θ .

EXERCISE 7.33. **7.33** *Triangular Distribution MLE and MVUE* – Hogg 7.4.9 Let $X_1, \dots, X_n$ be iid with pdf $f(x; \theta) = 1/(3\theta)$, $-\theta < x < 2\theta$, zero elsewhere, where $\theta > 0$.

(a) Find the mle $\hat{\theta}$ of θ

(b) Is $\hat{\theta}$ a sufficient statistic for θ ? Why?

(c) Is $(n+1)\hat{\theta}/n$ the unique MVUE of θ ? Why?

EXERCISE 7.34. **7.34** *Asymptotics of Scaled Uniform Maximum* – Hogg 7.4.10 Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics of a random sample of size n from a distribution with pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, zero elsewhere. By Example 7.4.2, the statistic Y_n is a complete sufficient statistic for θ and it has pdf

$$g(y_n; \theta) = \frac{ny_n^{n-1}}{\theta^n}, \quad 0 < y_n < \theta,$$

and zero elsewhere.

(a) Find the distribution function $H_n(z; \theta)$ of $Z = n(\theta - Y_n)$

(b) Find the $\lim_{n \rightarrow \infty} H_n(z; \theta)$ and thus the limiting distribution of Z .

EXERCISE 7.35. **7.35** *Gamma Distribution in Exponential Form* – Hogg 7.5.1 Write the pdf

$$f(x; \theta) = \frac{1}{6\theta^4} x^3 e^{-x/\theta}, \quad 0 < x < \infty, \quad 0 < \theta < \infty,$$

zero elsewhere, in the exponential form. If $X_1, X_2, \dots, X_n$ is a random sample from this distribution, find a complete sufficient statistic Y_1 for θ and the unique function $\varphi(Y_1)$ of this statistic that is the MVUE of θ . Is $\varphi(Y_1)$ itself a complete sufficient statistic?

EXERCISE 7.36. **7.36** *MVUE via Exponential Class* – Hogg 7.5.2 Let $X_1, X_2, \dots, X_n$ denote a random sample of size $n > 1$ from a distribution with pdf $f(x; \theta) = \theta e^{-\theta x}$, $0 < x < \infty$, zero elsewhere, and $\theta > 0$. Then $Y = \sum_{i=1}^n X_i$ is a sufficient statistic for θ . Prove that $(n-1)/Y$ is the MVUE of θ .

EXERCISE 7.37. **7.37** *Beta Distribution Complete Sufficient Statistic* – Hogg 7.5.3 Let $X_1, X_2, \dots, X_n$ denote a random sample of size n from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere, and $\theta > 0$.

(a) Show that the geometric mean $(X_1 X_2 \dots X_n)^{1/n}$ of the sample is a complete sufficient statistic for θ

(b) Find the maximum likelihood estimator of θ , and observe that it is a function of this geometric mean.

EXERCISE 7.38. **7.38** *Conditional Expectation for Gamma Mean –Hogg 7.5.4* Let $\bar{X}$ denote the mean of the random sample $X_1, X_2, \dots, X_n$ from a gamma-type distribution with parameters $\alpha > 0$ and $\beta = \theta > 0$. Compute $\mathbb{E}[X_1|\bar{x}]$.

Hint: Can you find directly a function $\psi(\bar{X})$ of $\bar{X}$ such that $\mathbb{E}[\psi(\bar{X})] = \theta$? Is $\mathbb{E}(X_1|\bar{x}) = \psi(\bar{x})$? Why?

EXERCISE 7.39. **7.39** *Mean and Variance of Exponential Class –Hogg 7.5.5* Let X be a random variable with the pdf of a regular case of the exponential class, given by $f(x; \theta) = \exp[\theta K(x) + H(x) + q(\theta)]$, $a < x < b$, $\gamma < \theta < \delta$. Show that $\mathbb{E}[K(X)] = -q'(\theta)/p'(\theta)$, provided these derivatives exist, by differentiating both members of the equality

$$\int_a^b \exp[p(\theta)K(x) + H(x) + q(\theta)]dx = 1$$

with respect to θ . By a second differentiation, find the variance of $K(X)$.

EXERCISE 7.40. **7.40** *MGF of Exponential Class –Hogg 7.5.6* Given that $f(x; \theta) = \exp[\theta K(x) + H(x) + q(\theta)]$, $a < x < b$, $\gamma < \theta < \delta$, represents a regular case of the exponential class, show that the moment-generating function $M(t)$ of $Y = K(X)$ is $M(t) = \exp[q(\theta) - q(\theta + t)]$, $\gamma < \theta + t < \delta$.

EXERCISE 7.41. **7.41** *Normal from Exponential Class –Hogg 7.5.7* In the preceding exercise, given that $\mathbb{E}(Y) = \mathbb{E}[K(X)] = \theta$, prove that Y is $N(\theta, 1)$.

Hint: Consider $M'(0) = \theta$ and solve the resulting differential equation.

EXERCISE 7.42. **7.42** *Distribution of Sum in Exponential Class –Hogg 7.5.8* If $X_1, X_2, \dots, X_n$ is a random sample from a distribution that has a pdf which is a regular case of the exponential class, show that the pdf of $Y_1 = \sum_1^n K(X_i)$ is of the form $f_{Y_1}(y_1; \theta) = R(y_1) \exp[p(\theta)y_1 + nq(\theta)]$.

Hint: Let $Y_2 = X_2, \dots, Y_n = X_n$ be $n - 1$ auxiliary random variables. Find the joint pdf of $Y_1, Y_2, \dots, Y_n$ and then the marginal pdf of Y_1 .

EXERCISE 7.43. **7.43** *Conditional Expectation of Median given Mean –Hogg 7.5.9* Let Y denote the median and let $\bar{X}$ denote the mean of a random sample of size $n = 2k + 1$ from a distribution that is $N(\mu, \sigma^2)$. Compute $\mathbb{E}(Y|\bar{X} = \bar{x})$.

Hint: See Exercise 7.5.4.

EXERCISE 7.44. **7.44** *Gamma(2, θ) Complete Sufficient Statistic –Hogg 7.5.10* Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta^2 x e^{-\theta x}$, $0 < x < \infty$, where $\theta > 0$.

(a) Argue that $Y = \sum_1^n X_i$ is a complete sufficient statistic for θ .

(b) Compute $\mathbb{E}(1/Y)$ and find the function of Y that is the unique MVUE of θ .

EXERCISE 7.45. **7.45** Binomial MVUE via Rao-Blackwell-Hogg 7.5.11 Let $X_1, X_2, \dots, X_n$, $n > 2$, be a random sample from the binomial distribution $b(1, \theta)$.

- Show that $Y_1 = X_1 + X_2 + \dots + X_n$ is a complete sufficient statistic for θ .
- Find the function $\varphi(Y_1)$ that is the MVUE of θ .
- Let $Y_2 = (X_1 + X_2)/2$ and compute $\mathbb{E}(Y_2)$.
- Determine $\mathbb{E}(Y_2|Y_1 = y_1)$.

EXERCISE 7.46. **7.46** Zero-Truncated Geometric MVUE-Hogg 7.5.12 Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pmf $p(x; \theta) = \theta^x(1 - \theta)$, $x = 0, 1, 2, \dots$, zero elsewhere, where $0 \leq \theta \leq 1$.

- Find the mle, $\hat{\theta}$, of θ .
- Show that $\sum_{i=1}^n X_i$ is a complete sufficient statistic for θ .
- Determine the MVUE of θ .

EXERCISE 7.47. **7.47** MVUE of θ^2 for Normal-Hogg 7.6.1 Let $X_1, X_2, \dots, X_n$ denote a random sample from a distribution that is $N(\theta, 1)$, $-\infty < \theta < \infty$. Find the MVUE of θ^2 .

EXERCISE 7.48. **7.48** MVUE of θ^2 for Normal(0, θ)-Hogg 7.6.2 Let $X_1, X_2, \dots, X_n$ denote a random sample from a distribution that is $N(0, \theta)$. Then $Y = \sum X_i^2$ is a complete sufficient statistic for θ . Find the MVUE of θ^2 .

EXERCISE 7.49. **7.49** Bootstrap SE for Normal CDF MVUE-Hogg 7.6.3 Consider Example 7.6.3 where the parameter of interest is $\mathbb{P}(X < c)$ for X distributed $N(\theta, 1)$. Modify the R function `bootse1.R` so that for a specified value of c it returns the MVUE of $\mathbb{P}(X < c)$ and the bootstrap standard error of the estimate. Run your function on the data in `ex763data.rda` with $c = 11$ and 3,000 bootstraps. These data are generated from a $N(10, 1)$ distribution. Report (a) the true parameter, (b) the MVUE, and (c) the bootstrap standard error.

EXERCISE 7.50. **7.50** Bootstrap SE for Median MVUE-Hogg 7.6.4 For Example 7.6.4, modify the R function `bootse1.R` so that the estimate is the median not the mean. Using 3,000 bootstraps, run your function on the data set discussed in the example and report (a) the estimate and (b) the bootstrap standard error.

EXERCISE 7.51. **7.51** Uniform(0, θ) MVUEs-Hogg 7.6.5 Let $X_1, X_2, \dots, X_n$ be a random sample from a uniform $(0, \theta)$ distribution. Continuing with Example 7.6.2, find the MVUEs for the following functions of θ .

- $g(\theta) = \frac{\theta^2}{12}$, i.e., the variance of the distribution.
- $g(\theta) = \frac{1}{\theta}$, i.e., the pdf of the distribution.
- For t real, $g(\theta) = \frac{e^{t\theta} - 1}{t\theta}$, i.e., the mgf of the distribution.

EXERCISE 7.52. **7.52** Poisson MVUE for $\mathbb{P}(X \leq 1)$ –Hogg 7.6.6 Let $X_1, X_2, \dots, X_n$ be a random sample from a Poisson distribution with parameter $\theta > 0$.

(a) Find the MVUE of $\mathbb{P}(X \leq 1) = (1 + \theta)e^{-\theta}$

Hint: Let $u(x_1) = 1$, $x_1 \leq 1$, zero elsewhere, and find $\mathbb{E}[u(X_1)|Y = y]$ where $Y = \sum_{i=1}^n X_i$.

(b) Express the MVUE as a function of the mle of θ

(c) Determine the asymptotic distribution of the mle of θ

(d) Obtain the mle of $\mathbb{P}(X \leq 1)$. Then use Theorem 5.2.9 to determine its asymptotic distribution.

EXERCISE 7.53. **7.53** Poisson Conditional Expectation with $(-1)^{X_1}$ –Hogg 7.6.7 Let $X_1, X_2, \dots, X_n$ denote a random sample from a Poisson distribution with parameter $\theta > 0$. From Remark 7.6.1, we know that $\mathbb{E}[(-1)^{X_1}] = e^{-2\theta}$.

(a) Show that $\mathbb{E}[(-1)^{X_1}|Y_1 = y_1] = (1 - 2/n)^{y_1}$, where $Y_1 = X_1 + X_2 + \dots + X_n$. Hint: First show that the conditional pdf of $X_1, X_2, \dots, X_{n-1}$, given $Y_1 = y_1$, is multinomial, and hence that of X_1 , given $Y_1 = y_1$, is $b(y_1, 1/n)$.

(b) Show that the mle of $e^{-2\theta}$ is $e^{-2\bar{X}}$

(c) Since $y_1 = n\bar{x}$, show that $(1 - 2/n)^{y_1}$ is approximately equal to $e^{-2\bar{x}}$ when n is large.

EXERCISE 7.54. **7.54** Bivariate Normal Distribution of $(X_1, \bar{X})$ –Hogg 7.6.8 As in Example 7.6.3, let $X_1, X_2, \dots, X_n$ be a random sample of size $n > 1$ from a distribution that is $N(\theta, 1)$. Show that the joint distribution of X_1 and $\bar{X}$ is bivariate normal with mean vector (θ, θ) , variances $\sigma_1^2 = 1$ and $\sigma_2^2 = 1/n$, and correlation coefficient $\rho = 1/\sqrt{n}$.

EXERCISE 7.55. **7.55** Exponential MLE and MVUE of $\mathbb{P}(X \leq 2)$ –Hogg 7.6.9 Let a random sample of size n be taken from a distribution that has the pdf $f(x; \theta) = (1/\theta)\exp(-x/\theta)\mathbb{I}_{(0, \infty)}(x)$. Find the mle and MVUE of $\mathbb{P}(X \leq 2)$.

EXERCISE 7.56. **7.56** Gamma(1, θ) MLE and MVUE –Hogg 7.6.10 Let $X_1, X_2, \dots, X_n$ be a random sample with the common pdf $f(x) = \theta^{-1}e^{-x/\theta}$, for $x > 0$, zero elsewhere; that is, $f(x)$ is a $\Gamma(1, \theta)$ pdf.

(a) Show that the statistic $\bar{X} = n^{-1} \sum_{i=1}^n X_i$ is a complete and sufficient statistic for θ .

(b) Determine the MVUE of θ

(c) Determine the mle of θ

(d) Often, though, this pdf is written as $f(x) = \tau e^{-\tau x}$, for $x > 0$, zero elsewhere. Thus $\tau = 1/\theta$. Use Theorem 6.1.2 to determine the mle of τ .

(e) Show that the statistic $\bar{X} = n^{-1} \sum_{i=1}^n X_i$ is a complete and sufficient statistic for τ . Show that $(n-1)/(n\bar{X})$ is the MVUE of $\tau = 1/\theta$. Hence, as usual, the reciprocal of

the mle of θ is the mle of $1/\theta$, but, in this situation, the reciprocal of the MVUE of θ is not the MVUE of $1/\theta$.

(f) Compute the variances of each of the unbiased estimators in parts (b) and (e).

EXERCISE 7.57. **7.57** Two-Sample F -Distribution for θ^2 –Hogg 7.6.11 Consider the situation of the last exercise, but suppose we have the following two independent random samples: (1) $X_1, X_2, \dots, X_n$ is a random sample with the common pdf $f_X(x) = \theta^{-1}e^{-x/\theta}$, for $x > 0$, zero elsewhere, and (2) $Y_1, Y_2, \dots, Y_n$ is a random sample with common pdf $f_Y(y) = \theta e^{-\theta y}$, for $y > 0$, zero elsewhere. The last exercise suggests that, for some constant c , $Z = c\bar{X}/\bar{Y}$ might be an unbiased estimator of θ^2 . Find this constant c and the variance of Z .

Hint: Show that $\bar{X}/(\theta^2\bar{Y})$ has an F -distribution.

EXERCISE 7.58. **7.58** Asymptotics of Normal Variance MVUE at $\theta = 1/2$ –Hogg 7.6.12 Obtain the asymptotic distribution of the MVUE in Example 7.6.1 for the case $\theta = 1/2$.

11. 7.7 The Case of Several Parameters —Exercises

EXERCISE 7.59. **7.59** Joint Sufficient Statistics for Gumbel Distribution –Hogg 7.7.1 Let $Y_1 < Y_2 < Y_3$ be the order statistics of a random sample of size 3 from the distribution with pdf

$$f(x; \theta_1, \theta_2) = \begin{cases} \frac{1}{\theta_2} \exp\left(-\frac{x-\theta_1}{\theta_2}\right) & \theta_1 < x < \infty, -\infty < \theta_1 < \infty, 0 < \theta_2 < \infty \\ 0 & \text{elsewhere.} \end{cases}$$

Find the joint pdf of $Z_1 = Y_1, Z_2 = Y_2$, and $Z_3 = Y_1 + Y_2 + Y_3$. The corresponding transformation maps the space $\{(y_1, y_2, y_3) : \theta_1 < y_1 < y_2 < y_3 < \infty\}$ onto the space

$$\{(z_1, z_2, z_3) : \theta_1 < z_1 < z_2 < (z_3 - z_1)/2 < \infty\}.$$

Show that Z_1 and Z_3 are joint sufficient statistics for θ_1 and θ_2 .

EXERCISE 7.60. **7.60** Exponential Class Joint Sufficient Statistics –Hogg 7.7.2 Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution that has a pdf of the form (7.7.2) of this section. Show that $Y_1 = \sum_{i=1}^n K_1(X_i), \dots, Y_m = \sum_{i=1}^n K_m(X_i)$ have a joint pdf of the form (7.7.4) of this section.

EXERCISE 7.61. **7.61** Bivariate Normal Joint Complete Sufficient Statistics –Hogg 7.7.3 Let $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ denote a random sample of size n from a bivariate normal distribution with means μ_1 and μ_2 , positive variances σ_1^2 and σ_2^2 , and correlation coefficient ρ . Show that $\sum_1^n X_i$, $\sum_1^n Y_i$, $\sum_1^n X_i^2$, $\sum_1^n Y_i^2$, and $\sum_1^n X_i Y_i$ are joint complete sufficient statistics for the five parameters. Are $\bar{X} = \sum_1^n X_i/n$, $\bar{Y} = \sum_1^n Y_i/n$, $S_1^2 = \sum_1^n (X_i - \bar{X})^2/(n-1)$, $S_2^2 = \sum_1^n (Y_i - \bar{Y})^2/(n-1)$, and $\sum_1^n (X_i - \bar{X})(Y_i - \bar{Y})/(n-1)$ also joint complete sufficient statistics for these parameters?

EXERCISE 7.62. **7.62** *Reparameterization of Exponential Class – Hogg 7.7.4* Let the pdf $f(x; \theta_1, \theta_2)$ be of the form

$$\exp [p_1(\theta_1, \theta_2)K_1(x) + p_2(\theta_1, \theta_2)K_2(x) + H(x) + q_1(\theta_1, \theta_2)], a < x < b,$$

zero elsewhere. Suppose that $K'_1(x) = cK'_2(x)$. Show that $f(x; \theta_1, \theta_2)$ can be written in the form

$$\exp [p(\theta_1, \theta_2)K_2(x) + H(x) + q(\theta_1, \theta_2)], a < x < b,$$

zero elsewhere. This is the reason why it is required that no one $K'_j(x)$ be a linear homogeneous function of the others, that is, so that the number of sufficient statistics equals the number of parameters.

EXERCISE 7.63. **7.63** *MVUE of Standard Deviation for Normal – Hogg 7.7.5* In Example 7.7.2:

(a) Find the MVUE of the standard deviation $\sqrt{\theta_2}$.

(b) Modify the R function `bootse1.R` so that it returns the estimate in (a) and its bootstrap standard error. Run it on the Bavarian forest data discussed in Example 4.1.3, where the response is the concentration of sulfur dioxide. Using 3,000 bootstraps, report the estimate and its bootstrap standard error.

EXERCISE 7.64. **7.64** *Uniform($\theta_1 - \theta_2, \theta_1 + \theta_2$) Complete Sufficient – Hogg 7.7.6* Let $X_1, X_2, \dots, X_n$ be a random sample from the uniform distribution with pdf $f(x; \theta_1, \theta_2) = 1/(2\theta_2)$, $\theta_1 - \theta_2 < x < \theta_1 + \theta_2$, where $-\infty < \theta_1 < \infty$ and $\theta_2 > 0$, and the pdf is equal to zero elsewhere.

(a) Show that $Y_1 = \min(X_i)$ and $Y_n = \max(X_i)$, the joint sufficient statistics for θ_1 and θ_2 , are complete.

(b) Find the MVUEs of θ_1 and θ_2 .

EXERCISE 7.65. **7.65** *MVUE of Normal Quantile – Hogg 7.7.7* Let $X_1, X_2, \dots, X_n$ be a random sample from $N(\theta_1, \theta_2)$

(a) If the constant b is defined by the equation $\mathbb{P}(X \leq b) = p$ where p is specified, find the mle and the MVUE of b .

(b) Modify the R function `bootse1.R` so that it returns the MVUE of Part (a) and its bootstrap standard error.

(c) Run your function in Part (b) on the data set discussed in Example 7.6.4 for $p = 0.75$ and 3,000 bootstraps.

EXERCISE 7.66. **7.66** *MLE of Multinomial Cell Probability Product – Hogg 7.7.8* In the notation of Example 7.7.3, show that the mle of $p_j p_l$ is $n^{-2} Y_j Y_l$.

EXERCISE 7.67. **7.67** *MVUE of Covariance Parameters for Multivariate Normal – Hogg 7.7.9* Refer to Example 7.7.4 on sufficiency for the multivariate normal model.

- (a) Determine the MVUE of the covariance parameters σ_{ij} .
- (b) Let $g = \sum_{i=1}^k a_i \mu_i$, where $a_1, \dots, a_k$ are specified constants. Find the MVUE for g .

EXERCISE 7.68. **7.68** *Inverse Gaussian Complete Sufficient Statistics –Hogg 7.7.10*
In a personal communication, LeRoy Folks noted that the inverse Gaussian pdf

$$f(x; \theta_1, \theta_2) = \left(\frac{\theta_2}{2\pi x^3} \right)^{1/2} \exp \left[\frac{-\theta_2(x - \theta_1)^2}{2\theta_1^2 x} \right], \quad 0 < x < \infty,$$

where $\theta_1 > 0$ and $\theta_2 > 0$, is often used to model lifetimes. Find the complete sufficient statistics for (θ_1, θ_2) if $X_1, X_2, \dots, X_n$ is a random sample from the distribution having this pdf.

EXERCISE 7.69. **7.69** *MVUE of $3\theta_2^2$ for Normal –Hogg 7.7.11* Let $X_1, X_2, \dots, X_n$ be a random sample from a $N(\theta_1, \theta_2)$ distribution.

- (a) Show that $\mathbb{E}[(X_1 - \theta_1)^4] = 3\theta_2^2$.
- (b) Find the MVUE of $3\theta_2^2$

EXERCISE 7.70. **7.70** *MVUE of Mean for Continuous Distribution –Hogg 7.7.12* Let $X_1, \dots, X_n$ be a random sample from a distribution of the continuous type with cdf $F(x)$. Suppose the mean, $\mu = \mathbb{E}(X_1)$, exists. Using Example 7.7.5, show that the sample mean, $\bar{X} = n^{-1} \sum_{i=1}^n X_i$, is the MVUE of μ .

EXERCISE 7.71. **7.71** *MVUE of CDF at Known Point –Hogg 7.7.13* Let $X_1, \dots, X_n$ be a random sample from a distribution of the continuous type with cdf $F(x)$. Let $\theta = \mathbb{P}(X_1 \leq a) = F(a)$, where a is known. Show that the proportion $n^{-1} \# \{X_i \leq a\}$ is the MVUE of θ .

12. 7.9 Sufficiency, Completeness, and Independence —Exercises

EXERCISE 7.72. **7.72** *Basu for Normal Order Statistics and Sample Mean –Hogg 7.9.2* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics of a random sample from a $N(\theta, \sigma^2)$, $-\infty < \theta < \infty$, distribution. Show that the distribution of $Z = Y_n - \bar{X}$ does not depend upon θ . Thus $\bar{Y} = \sum_1^n Y_i/n$, a complete sufficient statistic for θ is independent of Z .

EXERCISE 7.73. **7.73** *Basu's Theorem for Uniform Distribution –Hogg 7.9.1* Let $Y_1 < Y_2 < Y_3 < Y_4$ denote the order statistics of a random sample of size $n = 4$ from a distribution having pdf $f(x; \theta) = 1/\theta$, $0 < x < \theta$, zero elsewhere, where $0 < \theta < \infty$. Argue that the complete sufficient statistic Y_4 for θ is independent of each of the statistics Y_1/Y_4 and $(Y_1 + Y_2)/(Y_3 + Y_4)$.

EXERCISE 7.74. [7.74](#) *Independence Condition for Linear Statistics –Hogg 7.9.3* Let $X_1, X_2, \dots, X_n$ be iid with the distribution $N(\theta, \sigma^2)$, $-\infty < \theta < \infty$. Prove that a necessary and sufficient condition that the statistics $Z = \sum_1^n a_i X_i$ and $Y = \sum_1^n X_i$, a complete sufficient statistic for θ , are independent is that $\sum_1^n a_i = 0$.

Optimal Statistical Tests

Chapter 8 Overview

前几章已经给出了假设检验的基本语言：原假设、备择假设、显著性水平、功效函数，以及似然比思想。可是，一旦这些语言建立起来，一个更尖锐的问题就不可避免地出现了：同一个检验问题往往有许多临界区域，它们都能把第一类错误控制在同一个水平；那么我们凭什么选择其中一个，而不是另一个？

在所有可能的检验中，哪个检验是“最好”的？

这个问题就是**最优检验理论 (optimal test theory)**的起点。假设检验的困难不在于写出一个拒绝域，而在于处理两类错误之间的张力：若把拒绝域取得太大，第一类错误会上升；若取得太小，又会牺牲发现备择假设的能力。最优性理论的基本思想是：先把第一类错误控制在给定水平 α ，再在这个约束下尽可能提高功效 (power)。

为什么需要最优性理论？以医学筛查为例，若我们把误报率控制在 5%，接下来真正关心的就是：当患者确实患病时，检验能否以尽可能高的概率发现它。没有最优性理论，检验的选择只是经验判断；有了最优性理论，我们至少能在清楚的数学标准下说明某个检验为什么不可改进。

本章按从理想到现实的顺序展开：

- (1) **Neyman-Pearson 引理** (8.1 节)：对于简单假设对简单假设的情况，给出了最优检验的完整刻画——这是整个理论的基石。
- (2) **一致最大功效检验 (UMP)** (8.2 节)：将最优性概念推广到复合备择假设。介绍 monotone likelihood ratio (MLR) 和 Karlin-Rubin 定理——单参数指数族存在 UMP 检验。
- (3) **似然比检验 (LRT)** (8.3 节)：在一般复合假设下，LRT 提供了一种构造检验的通用方法。虽然 LRT 不一定是最优的，但在很多情况下它是渐近最优的。
- (4) **序贯概率比检验 (SPRT)** (8.4 节)：打破固定样本量的束缚，允许检验在数据积累过程中随时停止——Wald 的革命性贡献。
- (5) **极小化极大分类** (8.5 节)：将决策论框架应用于假设检验和分类问题。

1. 8.1 Most Powerful Tests

1.1. 问题的起源：什么是“最好”的检验。在 4.5 节中，我们引入了假设检验的基本框架：给定原假设 H_0 和备择假设 H_1 ，构造一个临界区域 C ，当样本落入 C 时拒绝 H_0 。这个定义看似完整，却留下了最重要的自由度：临界区域 C 并不唯一。许多不同的 C 都可能具有同样的显著性水平，但它们发现备择假设的能力可能完全不同。

在所有这些检验中，我们凭什么说一个比另一个更好？

要回答这个问题，必须先固定比较的规则。在假设检验中，这个规则就是**功效 (power)**——当 H_1 为真时拒绝 H_0 的概率。直观上，我们希望：

- (1) 在 H_0 为真时，拒绝 H_0 的概率（即 α ，显著性水平）不超过预设值；
- (2) 在 H_1 为真时，拒绝 H_0 的概率（即功效）尽可能高。

这就引出了“最好检验”的定义。

1.2. 简单假设对简单假设的最优检验. 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本，其中 $\theta \in \Omega = \{\theta', \theta''\}$ （即只有两个可能的参数值）。我们考虑检验：

$$H_0 : \theta = \theta' \quad \text{versus} \quad H_1 : \theta = \theta''.$$

DEFINITION 8.1 (最佳临界区域). 设 C 是样本空间的一个子集。如果

- (a) $\mathbb{P}_{\theta'}(\mathbf{X} \in C) = \alpha$ (大小为 α)；
- (b) 对每一个满足 $\mathbb{P}_{\theta'}(\mathbf{X} \in A) = \alpha$ 的子集 A ，都有

$$\mathbb{P}_{\theta''}(\mathbf{X} \in C) \geq \mathbb{P}_{\theta''}(\mathbf{X} \in A),$$

则称 C 是检验 $H_0 : \theta = \theta'$ 对 $H_1 : \theta = \theta''$ 的大小为 α 的**最佳临界区域 (best critical region of size α)**。

定义的直观含义：在所有满足显著性水平 α 的检验中，最佳临界区域对应的检验在 H_1 为真时具有最高的拒绝概率——这正是我们想要的。

为什么要关心最佳检验？设想你在设计一个药物试验。你设定 $\alpha = 0.05$ （即当药物无效时，只有 5% 的概率错误地拒绝 H_0 ）。在所有满足这个条件的检验中，你当然希望当药物真的有效时，以最高概率检测出来——这就是最佳检验的价值。

那么，这样的最佳检验是否存在？Neyman-Pearson 定理给出了答案。

1.3. Neyman-Pearson 定理.

有没有一种系统性的方法构造最佳检验？

Neyman-Pearson 定理不仅回答了“最佳检验是否存在”的问题，还给出了构造方法——它是以似然比 (likelihood ratio) 为基础的。

THEOREM 8.1 (Neyman-Pearson). 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的随机样本，记似然函数为

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta).$$

设 θ' 和 θ'' 是 θ 的两个不同取值， $\Omega = \{\theta', \theta''\}$ 。设 $k > 0$ 是一个常数， C 是样本空间的一个子集，满足：

- (a) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$ 对所有 $\mathbf{x} \in C$;
 (b) $\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k$ 对所有 $\mathbf{x} \in C^c$;
 (c) $\alpha = \mathbb{P}_{H_0}[\mathbf{X} \in C]$ 。

则 C 是检验简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ 的、大小为 α 的最佳临界区域。

核心思想：似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x})$ 衡量了数据 $\mathbf{x}$ 更支持 H_0 还是更支持 H_1 。当这个比值很小时，说明同一组数据在 H_0 下相对不容易出现，而在 H_1 下相对容易出现；于是最自然的动作就是拒绝 H_0 。

物理直觉：想象你在两个解释之间做选择。 $L(\theta'; \mathbf{x})$ 告诉我们“如果 H_0 为真，观察到这组数据的可能性有多大”； $L(\theta''; \mathbf{x})$ 告诉我们同一组数据在 H_1 下有多自然。如果观察到的数据在 H_0 下很牵强、在 H_1 下很自然，那么拒绝 H_0 就不是主观偏好，而是似然原则的直接要求。

必要性：值得注意的是，教材中的证明还说明了一个更强的事实：如果存在大小为 α 的最佳检验，那么它必须具有这种似然比形式。连续型情形下，这个最佳区域除了零概率集外是唯一的；离散型情形中，因为边界点可能需要随机化或有并列比值，最佳区域可能不唯一。

EXAMPLE 8.1 (二项分布下的最佳检验). 设 $X \sim \text{Binomial}(n = 5, p = \theta)$ ，考虑检验：

$$H_0: \theta = \frac{1}{2} \quad \text{versus} \quad H_1: \theta = \frac{3}{4}.$$

下表给出 $f(x; 1/2)$ 、 $f(x; 3/4)$ 以及它们的比值：

x	0	1	2	3	4	5
$f(x; 1/2)$	1/32	5/32	10/32	10/32	5/32	1/32
$f(x; 3/4)$	1/1024	15/1024	90/1024	270/1024	405/1024	243/1024
$f(x; 1/2)/f(x; 3/4)$	32/1	32/3	32/9	32/27	32/81	32/243

问题：构造大小 $\alpha = 1/32$ 的最佳检验。

比值 $f(x; 1/2)/f(x; 3/4)$ 在 $x = 5$ 处取得最小值 (32/243)。因此，最佳临界区域应包含那些使 H_0 看起来极不可能而 H_1 看起来极可能的数据点——即 $C = \{x = 5\}$ 。

验证： $\mathbb{P}_{H_0}(X \in C) = f(5; 1/2) = 1/32 = \alpha$ ，且 $\mathbb{P}_{H_1}(X \in C) = f(5; 3/4) = 243/1024 \approx 0.237$ 。

如果取 $\alpha = 6/32$ ，则最佳临界区域为 $\{x = 4, 5\}$ ，因为 $x = 4$ 和 $x = 5$ 的比值最小。此时

$$\mathbb{P}_{H_1}(X \in \{4, 5\}) = \frac{405}{1024} + \frac{243}{1024} = \frac{648}{1024} \approx 0.633.$$

关键洞察：最佳检验包含了“最支持 H_1 而最不支持 H_0 ”的数据点——这正是似然比方法告诉我们的。

EXAMPLE 8.2 (正态均值差假设的最优检验). 设 $X_1, \dots, X_n \sim N(\theta, 1)$ ，考虑检验：

$$H_0: \theta = 0 \quad \text{versus} \quad H_1: \theta = 1.$$

构造最佳检验：似然函数为

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

似然比为

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \exp \left(-\sum_{i=1}^n x_i + \frac{n}{2} \right).$$

令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$, 等价于

$$\sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

因此, 最佳临界区域是 $C = \{\mathbf{x} : \sum_{i=1}^n x_i \geq c\}$, 即基于样本均值 $\bar{X}$ 的检验。

确定临界值: 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故

$$c_1 = \frac{c}{n} = \frac{\frac{n}{2} - \log k}{n} = \frac{1}{2} - \frac{\log k}{n}.$$

给定显著性水平 α , 临界值为 $c_1 = q_\alpha(0, 1/\sqrt{n})$ ($N(0, 1/n)$ 的上 α 分位数)。

数值示例: 设 $n = 25$, $\alpha = 0.05$, 则 $c_1 = \mathbf{qnorm}(0.95, 0, 1/5) = 0.329$ 。

功效计算: 当 H_1 为真时, $\bar{X} \sim N(1, 1/25)$, 功效为

$$Power = \mathbb{P}_{H_1}(\bar{X} \geq 0.329) = 1 - \Phi \left(\frac{0.329 - 1}{1/5} \right) = 1 - \Phi(-3.355) \approx 0.9996.$$

也就是说, 当 $\theta = 1$ 时, 这个检验有约 99.96% 的概率正确拒绝 H_0 。

EXAMPLE 8.3 (Poisson 对 Geometric 的检验). 设 $X_1, \dots, X_n \sim f(x)$, 其中

$$H_0 : f(x) = \frac{e^{-1}}{x!}, \quad x = 0, 1, 2, \dots \quad (Poisson(\lambda = 1)),$$

$$H_1 : f(x) = \left(\frac{1}{2}\right)^{x+1}, \quad x = 0, 1, 2, \dots \quad (Geometric(p = 1/2)).$$

构造最佳检验：似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \frac{(2e^{-1})^n \cdot 2^{\sum x_i}}{\prod_{i=1}^n (x_i!)}.$$

令 $k = 1$ (对应某个特定的 α), 不等式化为

$$\frac{2^{\sum x_i}}{\prod_{i=1}^n (x_i!)} \leq \frac{e}{2}.$$

取 $n = 1$, 则临界区域为 $C = \{x_1 : x_1 = 0, 3, 4, 5, \dots\}$ 。

验证:

$$\alpha = \mathbb{P}_{H_0}(X \in C) = 1 - \frac{e^{-1}}{1!} - \frac{e^{-1}}{2!} = 1 - \frac{2}{e} \approx 0.4482,$$

$$Power = \mathbb{P}_{H_1}(X \in C) = 1 - \frac{1}{4} - \frac{1}{8} = 0.625.$$

这符合无偏性要求 (功效大于显著性水平)。

无偏性 (Unbiasedness): 注意到所有最佳检验都满足一个共同性质——功效大于等于显著性水平。这意味着拒绝 H_0 (当它为假时) 的概率不小于错误拒绝它的概率。这在经济决策中是完全合理的——如果检验的功效低于 α , 那它的行为还不如随机猜测。

DEFINITION 8.2 (无偏检验). 设 C 是显著性水平为 α 的检验的临界区域。如果对所有 $\theta \in \omega_1$,

$$\mathbb{P}_\theta(\mathbf{X} \in C) \geq \alpha,$$

则称该检验是**无偏的 (unbiased)**。

推论 8.1.1 表明 Neyman-Pearson 最佳检验是无偏的——在 H_0 为假时拒绝它的概率不低于在 H_0 为真时错误拒绝它的概率。

2. 8.2 Uniformly Most Powerful Tests

2.1. 从简单假设到复合假设. 上一节的 Neyman-Pearson 定理解决的是“简单假设对简单假设”的问题—— H_0 和 H_1 都各只有一个参数值。这是最干净的理论模型, 但它也太理想化了: 实际问题中, 我们通常不知道备择假设会落在哪一个具体点上, 只知道它属于某个方向或某个范围。例如:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

这里 H_1 包含无穷多个参数值。若我们对每一个固定的 $\theta'' > \theta'$ 分别使用 Neyman-Pearson 定理, 可能会得到一族不同的最佳临界区域。真正有用的检验应当更强: 它不仅要对某一个备择点最佳, 而且要同时对整个备择方向都最佳。

能否找到一个检验, 它对 $\theta > \theta'$ 中的每一个 θ 都是最佳检验?

这就是“一致最大功效 (Uniformly Most Powerful, UMP)”检验的思想。

DEFINITION 8.3 (UMP 检验). 设 C 是显著性水平为 α 的检验的临界区域。如果 C 是 H_0 对 H_1 中每一个简单假设的最佳临界区域, 则称 C 为**大小为 α 的一致最大功效临界区域 (UMP critical region)**, 相应的检验称为 **UMP 检验 (Uniformly Most Powerful test)**。

但 UMP 检验并不总是存在。例 8.2.3 展示了: 对于正态均值 $\sigma^2 = 1$ 已知时, 检验 $H_0: \theta = \theta'$ 对 $H_1: \theta \neq \theta'$ (双向备择) 不存在 UMP 检验——因为对 $\theta'' > \theta'$ 的最佳临界区域 (拒绝域在右尾) 与对 $\theta'' < \theta'$ 的最佳临界区域 (拒绝域在左尾) 形式完全不同, 无法统一。

这个例子揭示了一个深刻的事实: **UMP 检验只在单向备择假设 (one-sided alternatives) 下才可能存在。**

2.2. 单调似然比与 Karlin-Rubin 定理. 那么, 在什么条件下 UMP 检验存在呢? 答案藏在一种叫做“单调似然比 (Monotone Likelihood Ratio, MLR)”的性质中。

DEFINITION 8.4 (单调似然比). 设 $L(\theta, \mathbf{x})$ 是似然函数。如果对 $\theta_1 < \theta_2$, 比值

$$\frac{L(\theta_1; \mathbf{x})}{L(\theta_2; \mathbf{x})}$$

是统计量 $y = u(\mathbf{x})$ 的单调递减函数, 则称似然函数在 $y = u(\mathbf{x})$ 中有**单调似然比 (monotone likelihood ratio, mlr)**。

为什么 MLR 如此重要? MLR 性质说的是: 无论把较大的参数值取成哪一个, 数据对大参数的支持程度都可以由同一个统计量 Y 排序。于是“证据更强”这件事有了统一方向: Y 越大, 越支持 θ 较大的备择假设。正因为这个排序不随具体的 θ'' 改变, 我们才有可能得到同一个拒绝域, 而不是为每个备择点重新设计检验。

THEOREM 8.2 (Karlin-Rubin 定理). 设随机样本来自密度 $f(x; \theta)$, 似然函数 $L(\theta, \mathbf{x})$ 在统计量 $Y = u(\mathbf{X})$ 中有单调似然比。考虑单向假设:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

则对任意显著性水平 α , UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y \geq c_Y,$$

其中临界值 c_Y 满足 $\mathbb{P}_{\theta'}(Y \geq c_Y) = \alpha$ 。

核心洞察: 由于 MLR 性质, 对任何 $\theta'' > \theta'$, 最佳临界区域的形式都是 $Y \geq c$ ——它们恰好是同一个区域! 因此这个区域对所有 $\theta'' > \theta'$ 都是最佳的, 从而是一致最大功效的。

证明思路: 对固定的 $\theta'' > \theta'$, 由 Neyman-Pearson 定理, 最佳临界区域由似然比 $L(\theta'; \mathbf{x})/L(\theta''; \mathbf{x}) \leq k$ 给出。由于 MLR 性质, 这个不等式等价于 $Y \geq g^{-1}(k)$ ——即只依赖于数据的形状, 而不依赖于具体的 θ'' 值。

EXAMPLE 8.4 (正态方差 UMP 检验). 设 $X_1, \dots, X_n \sim N(0, \theta)$, 其中 $\theta > 0$ 是方差。考虑检验:

$$H_0: \theta = \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然函数为

$$L(\theta; \mathbf{x}) = \left(\frac{1}{2\pi\theta}\right)^{n/2} \exp\left\{-\frac{1}{2\theta} \sum_{i=1}^n x_i^2\right\}.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left(\frac{\theta''}{\theta'}\right)^{n/2} \exp\left[-\left(\frac{\theta'' - \theta'}{2\theta'\theta''}\right) \sum_{i=1}^n x_i^2\right].$$

对 $\theta'' > \theta'$, 这是 $\sum x_i^2$ 的递减函数, 因此似然函数在 $Y = \sum X_i^2$ 中有 MLR。

由 Karlin-Rubin 定理, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad \sum_{i=1}^n X_i^2 \geq c,$$

其中 c 满足 $\mathbb{P}_{\theta'}(\sum X_i^2 \geq c) = \alpha$ 。

数值示例: 设 $n = 15$, $\alpha = 0.05$, $\theta' = 3$ 。当 H_0 为真时, $\sum X_i^2/\theta' \sim \chi^2(n)$, 故

$$\frac{c}{3} = \chi_{0.95}^2(15) = 24.996 \quad \Rightarrow \quad c = 74.988.$$

即当 $\sum x_i^2 \geq 74.988$ 时拒绝 $H_0: \theta = 3$ 。

EXAMPLE 8.5 (Bernoulli 分布的 UMP 检验). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(\theta)$, 考虑检验:

$$H_0: \theta \leq \theta' \quad \text{versus} \quad H_1: \theta > \theta'.$$

似然比为

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} = \left[\frac{\theta'(1-\theta'')}{\theta''(1-\theta')} \right]^{\sum x_i} \left(\frac{1-\theta'}{1-\theta''} \right)^n.$$

由于 $\theta' < \theta''$ 时 $\theta'(1-\theta'')/\theta''(1-\theta') < 1$, 该比值是 $Y = \sum X_i$ 的递减函数。因此似然函数在 $Y = \sum X_i$ 中有 MLR, UMP 检验为:

$$\text{Reject } H_0 \quad \text{if} \quad Y = \sum_{i=1}^n X_i \geq c,$$

其中 c 由 $\mathbb{P}_{\theta'}(Y \geq c) = \alpha$ 确定。

这正是我们直观上期望的: 观察到更多的成功次数, 就越有理由拒绝“成功率不高”的原假设。

正规指数族 (Regular Exponential Family): 其实 Bernoulli 分布、正态分布 (方差已知)、Poisson 分布都属于一个更广泛的族——正规指数族。在这个族中, 只要自然参数是单调的, 就存在 UMP 检验。具体地, 如果分布有形式

$$f(x; \theta) = \exp[p(\theta)K(x) + H(x) + q(\theta)],$$

且 $p(\theta)$ 是 θ 的递增函数, 则对假设 $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$, UMP 检验存在, 基于统计量 $Y = \sum_{i=1}^n K(X_i)$ 。

3. 8.3 Likelihood Ratio Tests

3.1. 似然比检验的动机. 前两节给出了最优检验理论中最漂亮的部分: 简单假设有 Neyman-Pearson 定理, 单向复合假设在 MLR 条件下有 Karlin-Rubin 定理。然而, 漂亮理论往往依赖强条件; 一旦问题变成双向备择、多参数模型或带有 nuisance parameter 的复合假设, UMP 检验通常不再存在。现实中许多重要问题正落在这些范畴之外:

- 检验正态均值 $H_0: \mu = \mu_0$ (σ^2 未知) 对 $H_1: \mu \neq \mu_0$ ——不存在 UMP 检验 (双向备择);
- 检验两正态均值是否相等 $H_0: \mu_1 = \mu_2$ ——涉及多于一个参数;
- 一般复合假设——没有 MLR 性质可供利用。

在这些情况下, 我们转向一种通用但不一定最优的构造检验的方法——**似然比检验 (Likelihood Ratio Test, LRT)**。

为什么即使 LRT 不是最优的, 我们仍然使用它? Neyman-Pearson 定理告诉我们, 在最简单的情形中, 似然比就是最佳检验的核心。LRT 保留了这个思想, 但把“两个点之间的比较”推广为“约束参数空间与完整参数空间之间的比较”: 若 H_0 受到约束后仍能很好解释数据, 就没有理由拒绝; 若放开约束后似然显著增大, 数据就在提醒我们 H_0 可能过于狭窄。虽然一般 LRT 不保证有限样本最优, 但它统一、可计算, 并且在正则条件下有清晰的渐近理论。

3.2. LRT 的定义. 设 X 的密度为 $f(\mathbf{x}; \boldsymbol{\theta})$, 参数 $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$. 考虑复合假设:

$$H_0: \boldsymbol{\theta} \in \omega \quad \text{versus} \quad H_1: \boldsymbol{\theta} \in \Omega \cap \omega^c,$$

其中 $\omega \subset \Omega$ 是参数空间的某个子集。

DEFINITION 8.5 (似然比). **似然比 (Likelihood Ratio)** 定义为:

$$\Lambda(\mathbf{x}) = \frac{\sup_{\omega} L(\boldsymbol{\theta}; \mathbf{x})}{\sup_{\Omega} L(\boldsymbol{\theta}; \mathbf{x})} = \frac{L(\hat{\omega}; \mathbf{x})}{L(\hat{\Omega}; \mathbf{x})},$$

其中 $\hat{\omega}$ 是在约束 $\boldsymbol{\theta} \in \omega$ 下的 MLE, $\hat{\Omega}$ 是在无约束 $\boldsymbol{\theta} \in \Omega$ 下的 MLE。

直观含义: 分子衡量数据在 H_0 约束下能达到的最大似然, 分母衡量数据在无约束情况下能达到的最大似然。如果 H_0 为真, 这两个值应该差不多, 比值接近 1; 如果 H_0 为假, 无约束的似然会显著大于约束下的似然, 比值会变小。因此我们在小比值时拒绝 H_0 :

$$\text{Reject } H_0 \quad \text{if} \quad \Lambda(\mathbf{x}) \leq \lambda_0 < 1.$$

LRT 的一个关键性质: 在 H_0 下, $-2 \log \Lambda$ 渐近服从 χ^2 分布, 自由度为 $\dim(\Omega) - \dim(\omega)$ (在一定正则条件下)。这使得我们可以近似地确定临界值。

LRT 与 NP 引理的关系: 当 $\Omega = \{\theta', \theta''\}$ (只有两点) 时, LRT 还原为 NP 似然比检验, 此时它是最优的。但一般来说, LRT 不一定是最优的。

接下来我们把 LRT 应用到几个具体的重要情形——正态均值差和正态方差检验。

3.3. 8.3.1 正态均值差的 LRT.

EXAMPLE 8.6 (两样本 t 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_3)$, 两组样本独立, 共同方差 θ_3 未知。考虑检验:

$$H_0: \theta_1 = \theta_2 \quad \text{versus} \quad H_1: \theta_1 \neq \theta_2.$$

构造 LRT: 在 H_0 下 ($\theta_1 = \theta_2 = \mu$), 参数的 MLE 为

$$\hat{\mu} = \frac{n\bar{x} + m\bar{y}}{n + m}, \quad \hat{\sigma}_0^2 = \frac{1}{n + m} \left[\sum_{i=1}^n (x_i - \hat{\mu})^2 + \sum_{i=1}^m (y_i - \hat{\mu})^2 \right].$$

在无约束下 (H_1), MLE 分别为 $\bar{x}$ 、 $\bar{y}$ 和

$$\hat{\sigma}^2 = \frac{1}{n+m} \left[\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 \right].$$

似然比为

$$\Lambda = \frac{L(\hat{\omega})}{L(\hat{\Omega})} = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2} \right)^{(n+m)/2}.$$

与 t 统计量的联系: 可以证明

$$\Lambda^{2/(n+m)} = \frac{(n+m-2)}{(n+m-2) + T^2},$$

其中

$$T = \sqrt{\frac{nm}{n+m}} \frac{\bar{x} - \bar{y}}{S_p}, \quad S_p^2 = \frac{(n-1)S_x^2 + (m-1)S_y^2}{n+m-2}.$$

T 服从自由度为 $n+m-2$ 的 t 分布 (在 H_0 下)。由于 $\Lambda \leq \lambda_0 \Leftrightarrow |T| \geq c$, LRT 就是经典的两样本 t 检验。

数值示例: 设 $n=10$, $m=6$, $\alpha=0.05$, 则临界值

$$c = t_{0.975}(14) = 2.1448.$$

如果 $|t| \geq 2.1448$, 拒绝 H_0 (认为两个总体均值不相等)。

功效函数: 对于非中心 t 分布, 当 $\theta_1 \neq \theta_2$ 时, T 服从非中心 t 分布, 非中心参数为

$$\delta = \sqrt{\frac{nm}{n+m}} \frac{\theta_1 - \theta_2}{\sigma}.$$

给定 $\theta_3 = 100$, $n = 20$, $m = 15$, $\alpha = 0.05$, $\Delta = 5 = \theta_1 - \theta_2$, 临界值 $t_{0.975}(33) = 2.0345$, 非中心参数 $\delta_2 = 1.4639$, 功效约为

$$1 - \text{pt}(2.0345, 33, \text{ncp} = 1.4639) + \text{pt}(-2.0345, 33, \text{ncp} = 1.4639) \approx 0.2954.$$

即约 29.5% 的概率检测出均值为 5 的差异。**稳健性注记:** t 检验在正态性假设不满足时表现如何? 在大样本下, 由 Slutsky 定理, 即使底层分布非正态, 只要方差有限, t 统计量仍然渐近正态——因此 t 检验是**渐近正确的**。然而, 在有限样本且严重非正态 (特别是高度偏态) 时, t 检验可能失效——实际显著性水平会偏离名义水平。

3.4. 8.3.2 正态方差的 LRT.

EXAMPLE 8.7 (两方差相等的 F 检验). 设 $X_1, \dots, X_n \sim N(\theta_1, \theta_3)$ 和 $Y_1, \dots, Y_m \sim N(\theta_2, \theta_4)$, 独立样本, 考虑检验:

$$H_0: \theta_3 = \theta_4 \quad \text{versus} \quad H_1: \theta_3 \neq \theta_4.$$

可以证明 (练习 8.3.11), LRT 统计量可以化为

$$F = \frac{\sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)}{\sum_{i=1}^m (Y_i - \bar{Y})^2 / (m-1)}.$$

在 H_0 下, $F \sim F(n-1, m-1)$ 。因此双向 LRT 为:

$$\text{Reject } H_0 \quad \text{if} \quad F \leq c_1 \quad \text{or} \quad F \geq c_2,$$

其中 c_1 和 c_2 满足 $\mathbb{P}(F \leq c_1) = \mathbb{P}(F \geq c_2) = \alpha_1/2$ 。

重要警告: 与 t 检验不同, F 检验对正态性假设是敏感的。在非正态情况下, F 检验的名义水平和实际水平可能相差甚远 (可高达 0.80), 因此不应在正态性未经检验的情况下使用 F 检验。

4. 8.4 *Sequential Probability Ratio Test

4.1. 固定样本量检验的局限性. 到目前为止, 我们讨论的所有检验都有一个共同假设: 样本量 n 是预先固定的。但在实际应用中, 固定样本量检验存在一个根本性的低效:

为什么要等到收集完所有 n 个样本才做决策? 为什么不能边收集边决策?

考虑一个质量控制场景: 你需要判断一条生产线是否正常 ($\theta = \theta_0$)。固定样本量方法要求你先收集 n 个样本, 然后做决策。但如果在第 5 个样本时, 数据就已经极其强烈地支持 H_1 (生产线已严重偏离正常状态), 继续等待其余 $n-5$ 个样本就是在浪费时间和资源。

1930 年代, Abraham Wald 提出了一个革命性的思想: 允许样本量根据数据动态确定——这就是序贯分析 (sequential analysis) 的诞生。

Wald 的序贯概率比检验 (SPRT) 不仅在概念上优雅, 而且在功效和样本量之间实现了最优权衡。

4.2. SPRT 的构造. 设 $X_1, X_2, \dots$ 是 iid 随机变量序列, 考虑检验:

$$H_0: \theta = \theta' \quad \text{versus} \quad H_1: \theta = \theta'',$$

其中 θ' 和 θ'' 是给定的具体值。

核心思想: 在每个步骤 n , 计算似然比

$$\Lambda_n = \frac{L(\theta'; x_1, \dots, x_n)}{L(\theta''; x_1, \dots, x_n)} = \prod_{i=1}^n \frac{f(x_i; \theta')}{f(x_i; \theta'')}.$$

如果 Λ_n 非常小 (即数据强烈支持 H_1), 我们就提前停止并拒绝 H_0 ; 如果 Λ_n 非常大 (即数据强烈支持 H_0), 我们就提前停止并接受 H_0 ; 如果 Λ_n 处于中间位置, 我们就继续观察下一个样本。

具体地, 选取两个常数 $A < B$ 。若预先给定目标错误概率 α_a 与 β_a , Hogg 的记号取

$$A = \frac{\alpha_a}{1 - \beta_a}, \quad B = \frac{1 - \alpha_a}{\beta_a},$$

SPRT 的决策规则为:

$$\text{在第 } n \text{ 步, 停止采样并: } \begin{cases} \text{拒绝 } H_0 \text{ (接受 } H_1) & \text{if } \Lambda_n \leq A, \\ \text{接受 } H_0 \text{ (拒绝 } H_1) & \text{if } \Lambda_n \geq B, \\ \text{继续采样} & \text{if } A < \Lambda_n < B. \end{cases}$$

Wald 的误差控制: 教材证明, 在连续型情形下若真实错误概率记为 α 与 β , 则

$$\frac{\alpha}{1-\beta} \leq A, \quad B \leq \frac{1-\alpha}{\beta}.$$

因此取 $A = \alpha_a/(1-\beta_a)$ 、 $B = (1-\alpha_a)/\beta_a$ 时, $\alpha + \beta \leq \alpha_a + \beta_a$, 并且实际应用中 α, β 通常接近预设值 α_a, β_a 。

EXAMPLE 8.8 (Bernoulli 的 SPRT). 设 $X_i \sim \text{Bernoulli}(\theta)$, 检验 $H_0: \theta = 1/3$ 对 $H_1: \theta = 2/3$ 。

似然比为

$$\Lambda_n = \frac{(1/3)^{\sum x_i} (2/3)^{n-\sum x_i}}{(2/3)^{\sum x_i} (1/3)^{n-\sum x_i}} = 2^{n-2\sum x_i}.$$

取对数并整理, 不等式 $A < \Lambda_n < B$ 等价于

$$c_0(n) = \frac{n}{2} - \frac{\log_2 B}{2} < \sum_{i=1}^n x_i < \frac{n}{2} - \frac{\log_2 A}{2} = c_1(n).$$

决策规则: 当 $\sum x_i \geq c_1(n)$ 时, 拒绝 H_0 ; 当 $\sum x_i \leq c_0(n)$ 时, 接受 H_0 ; 否则继续采样。

序贯抽样的图示: 想象一条随机游走——每观察一次 $X_i = 1$, 我们就向右跳 1 个单位; 每观察一次 $X_i = 0$, 我们就向左跳 1 个单位。只要这条路径处于上下边界之间, 我们就继续。一旦路径碰到上界 (强烈支持 H_1) 或下界 (强烈支持 H_0), 我们就停止并做出相应决策。

EXAMPLE 8.9 (正态均值的 SPRT). 设 $X_1, X_2, \dots \sim N(\theta, 100)$, 检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$, 目标是使 $\alpha \approx \beta \approx 0.10$ 。

取 $A = 1/9$ 、 $B = 9$ 。似然比为

$$\Lambda_n = \exp\left(-\frac{6\sum x_i - 459n}{200}\right).$$

不等式 $A < \Lambda_n < B$ 化为

$$c_0(n) = \frac{153}{2}n - \frac{100}{3}\log 9 < \sum_{i=1}^n x_i < \frac{153}{2}n + \frac{100}{3}\log 9 = c_1(n).$$

决策规则: 在第 n 步, 当 $\sum x_i \geq c_1(n)$ 时拒绝 H_0 (认为 $\theta = 78$); 当 $\sum x_i \leq c_0(n)$ 时接受 H_0 (认为 $\theta = 75$); 否则继续采样。

SPRT 的吸引力：为什么 SPRT 如此重要？因为它在固定两类错误概率的同时，通常使用比固定样本量检验更少的样本。Wald 的近似理论表明，当 H_0 或 H_1 为真时，SPRT 的平均样本量（Average Sample Number, ASN）比相应的固定样本量检验小得多——有时能节省 50% 以上的样本。

SPRT 与质量控制：SPRT 的思想在工业质量控制中有广泛应用。CUSUM（累积和）控制图就是 SPRT 的一个变体——它持续累积标准化后的偏离量 $\sum(Z_i - 0.5)$ （其中 Z_i 是标准化后的检验统计量），一旦超出控制限就发出警报。与固定间隔的 Shewhart 控制图相比，CUSUM 能更快检测到过程均值的微小漂移。

5. 8.5 *Minimax and Classification Procedures

5.1. 8.5.1 极小化极大检验。在第 7 章的决策论框架中，我们介绍了极小化极大（minimax）原则：将最大风险最小化。将这个思想应用到假设检验中，会得到一个有趣的结论——Neyman-Pearson 最佳检验在某种意义上也是极小化极大的。

考虑简单假设 $H_0: \theta = \theta'$ 对 $H_1: \theta = \theta''$ ，损失函数满足 $\mathcal{L}(\theta', \theta') = \mathcal{L}(\theta'', \theta'') = 0$ （正确决策无损失），而 $\mathcal{L}(\theta', \theta'') > 0$ 和 $\mathcal{L}(\theta'', \theta') > 0$ （错误决策有损失）。此时风险函数为：

$$R(\theta', C) = \mathcal{L}(\theta', \theta'') \cdot \alpha, \quad R(\theta'', C) = \mathcal{L}(\theta'', \theta') \cdot \beta,$$

其中 α 是显著性水平， β 是 Type II 错误概率。

极小化极大原则要求选择 C 使得 $\max\{R(\theta', C), R(\theta'', C)\}$ 最小。可以证明，当 k 满足

$$\mathcal{L}(\theta', \theta'') \int_C L(\theta') = \mathcal{L}(\theta'', \theta') \int_{C^c} L(\theta'')$$

时（即两类错误造成的风险相等），临界区域 C 是极小化极大的。这个条件与 NP 似然比条件是一致的——本质上，最佳检验同时也是极小化极大检验（当两类错误的相对代价被适当选择时）。

EXAMPLE 8.10（正态均值的极小化极大检验）。设 $X_1, \dots, X_{100} \sim N(\theta, 100)$ ，检验 $H_0: \theta = 75$ 对 $H_1: \theta = 78$ ，损失为 $\mathcal{L}(75, 78) = 3$ 、 $\mathcal{L}(78, 75) = 1$ 。

临界区域形如 $\bar{x} \geq c$ ，其中 c 满足：

$$3 \cdot \mathbb{P}_{\theta=75}(\bar{X} \geq c) = \mathbb{P}_{\theta=78}(\bar{X} < c).$$

由于 $\bar{X} \sim N(\theta, 1)$ ，这化为

$$3[1 - \Phi(c - 75)] = \Phi(c - 78).$$

求解得 $c \approx 76.8$ 。此时显著性水平 $\alpha = 1 - \Phi(1.8) \approx 0.036$ ，功效为 $1 - \Phi(-1.2) \approx 0.885$ 。

5.2. 8.5.2 分类问题. 极小化极大检验理论在分类 (classification) 问题中有直接应用。考虑一个二分类问题：我们观察到 (X, Y) ，需要判断它来自分布 $f(x, y; \theta')$ 还是 $f(x, y; \theta'')$ 。

这本质上就是假设检验问题——如果接受 H_0 ，就把 (X, Y) 分类为来自 θ' 类；如果拒绝 H_0 ，就分类为来自 θ'' 类。

由 NP 定理，最佳分类规则是似然比规则：

$$\frac{f(x, y; \theta')}{f(x, y; \theta'')} \leq k \implies \text{分类为 } \theta'' \text{ 类.}$$

若两类的先验概率为 π' 和 π'' ，则最优规则取 $k = \pi''/\pi'$ （当两类等可能时 $k = 1$ ）。

Fisher 线性判别函数：在正态分布的特殊情况下，似然比不等式化为一个线性函数 $ax + by \leq c$ ——这就是著名的 Fisher 线性判别函数。当参数未知时，用训练样本的均值和方差代替，就得到了 Fisher 判别函数。

EXAMPLE 8.11 (二元正态的线性判别). 设 (X, Y) 来自二元正态分布，参数为 $(\mu'_1, \mu'_2, \sigma_1^2, \sigma_2^2, \rho')$ 或 $(\mu''_1, \mu''_2, \sigma_1^2, \sigma_2^2, \rho'')$ 。则似然比不等式化为

$$ax + by \leq c,$$

其中 a 和 b 是由两个总体的均值向量和协方差矩阵决定的常数。这给出了一个**线性决策边界**——在二维空间中是一条直线，将平面分为两部分，分别对应两类。

附录：公式推导

本附录包含 Chapter 8 中省略的完整推导。

5.3. Neyman-Pearson 引理的证明. 背景 (Background): 我们需要证明，当临界区域 C 满足 NP 条件 (a) -(c) 时，它是在固定显著性水平 α 下功效最高的检验。

已知条件 (Given):

- $L(\theta'; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta')$ 是 H_0 下的似然函数
- $L(\theta''; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta'')$ 是 H_1 下的似然函数
- 临界区域 C 满足：

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k, \quad \forall \mathbf{x} \in C; \quad \frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \geq k, \quad \forall \mathbf{x} \in C^c.$$

- 任意其他满足 $\mathbb{P}_{\theta'}(\mathbf{X} \in A) = \alpha$ 的区域 A 。

目标 (Goal): 证明 $\mathbb{P}_{\theta''}(\mathbf{X} \in C) \geq \mathbb{P}_{\theta''}(\mathbf{X} \in A)$ 。

推导步骤 (Derivation Steps):

(1) 写出功效差:

$$\int_C L(\theta'') - \int_A L(\theta'') = \int_{C \cap A^c} L(\theta'') - \int_{A \cap C^c} L(\theta'').$$

(2) 由条件 (a): 在 C 上 $L(\theta'') \geq \frac{1}{k}L(\theta')$, 故

$$\int_{C \cap A^c} L(\theta'') \geq \frac{1}{k} \int_{C \cap A^c} L(\theta').$$

(3) 由条件 (b): 在 C^c 上 $L(\theta'') \leq \frac{1}{k}L(\theta')$, 故

$$\int_{A \cap C^c} L(\theta'') \leq \frac{1}{k} \int_{A \cap C^c} L(\theta').$$

(4) 将 item 2 和 item 3 代入 item 1:

$$\int_C L(\theta'') - \int_A L(\theta'') \geq \frac{1}{k} \left[\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') \right].$$

(5) 计算括号内项:

$$\int_{C \cap A^c} L(\theta') - \int_{A \cap C^c} L(\theta') = \int_C L(\theta') - \int_A L(\theta') = \alpha - \alpha = 0.$$

(6) 由 item 4 和 item 5 得 $\int_C L(\theta'') - \int_A L(\theta'') \geq 0$, 即

$$\mathbb{P}_{\theta''}(\mathbf{X} \in C) \geq \mathbb{P}_{\theta''}(\mathbf{X} \in A).$$

证毕。

5.4. 正态均值 NP 检验的完整推导. 背景 (Background): 在例 8.1.2 中, 我们构造了正态均值差假设的 NP 检验。本节补充完整推导。

目标 (Goal): 对 $X_1, \dots, X_n \sim N(\theta, 1)$, 检验 $H_0: \theta = 0$ 对 $H_1: \theta = 1$, 求大小为 α 的最佳检验。

推导步骤 (Derivation Steps):

(1) 写出似然函数:

$$L(\theta; \mathbf{x}) = (2\pi)^{-n/2} \exp \left[-\frac{1}{2} \sum_{i=1}^n (x_i - \theta)^2 \right].$$

(2) 似然比:

$$\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} = \frac{\exp \left[-\frac{1}{2} \sum x_i^2 \right]}{\exp \left[-\frac{1}{2} \sum (x_i - 1)^2 \right]} = \exp \left[-\sum_{i=1}^n x_i + \frac{n}{2} \right].$$

(3) 令 $\frac{L(0; \mathbf{x})}{L(1; \mathbf{x})} \leq k$:

$$\exp \left[-\sum x_i + \frac{n}{2} \right] \leq k \iff \sum_{i=1}^n x_i \geq \frac{n}{2} - \log k = c.$$

(4) 当 H_0 为真时, $\bar{X} \sim N(0, 1/n)$, 故临界值

$$c_1 = \frac{c}{n} = \frac{1}{2} - \frac{\log k}{n} = q_\alpha(0, 1/\sqrt{n}).$$

(5) 功效函数: 当 $\theta = 1$ 时, $\bar{X} \sim N(1, 1/n)$,

$$\text{Power}(\theta = 1) = \mathbb{P}_{\theta=1}(\bar{X} \geq q_\alpha(0, 1/\sqrt{n})) = 1 - \Phi \left(\frac{q_\alpha(0, 1/\sqrt{n}) - 1}{1/\sqrt{n}} \right).$$

证毕。

5.5. Karlin-Rubin 定理的证明. 背景 (Background): 证明当似然函数有 MLR 性质时, 单向复合假设存在 UMP 检验。

已知条件 (Given):

- 似然函数 $L(\theta, \mathbf{x})$ 在 $Y = u(\mathbf{x})$ 中有 MLR: 对 $\theta_1 < \theta_2$, $L(\theta_1; \mathbf{x})/L(\theta_2; \mathbf{x}) = g(Y)$, 其中 g 是递减函数。
- 单向假设: $H_0: \theta \leq \theta'$ 对 $H_1: \theta > \theta'$ 。

目标 (Goal): 证明检验 $\phi(\mathbf{x}) = 1$ 当 $Y \geq c_Y$, 其中 c_Y 满足 $\mathbb{P}_{\theta'}(Y \geq c_Y) = \alpha$, 是 UMP level α 检验。

推导步骤 (Derivation Steps):

- (1) **对简单假设 $H'_0: \theta = \theta'$ 对 $\theta'' > \theta'$ 的最优性:** 由 NP 定理, 最佳临界区域由

$$\frac{L(\theta'; \mathbf{x})}{L(\theta''; \mathbf{x})} \leq k$$

给出。由于 MLR 性质, $g(Y) \leq k \iff Y \geq g^{-1}(k)$ 。取 $c_Y = g^{-1}(k)$, 则对任意 $\theta'' > \theta'$, 临界区域 $C = \{Y \geq c_Y\}$ 是 $H'_0: \theta = \theta'$ 对 θ'' 的最佳检验。

- (2) **对所有 $\theta'' > \theta'$ 的一致性:** 由于 NP 最佳临界区域的形式只依赖于 $Y \geq c_Y$ (而不依赖于具体的 θ''), $C = \{Y \geq c_Y\}$ 对所有 $\theta'' > \theta'$ 都是最佳的。
- (3) **无偏性 (保证 level 不超过 α):** 设 $\gamma_Y(\theta) = \mathbb{P}_\theta(Y \geq c_Y)$ 为功效函数。对 $\theta_1 < \theta_2$, 由第 1 步, C 是 θ_1 对 θ_2 的最佳检验, 故 $\gamma_Y(\theta_2) \geq \gamma_Y(\theta_1)$ 。因此 $\gamma_Y(\theta)$ 是 θ 的非降函数, $\max_{\theta \leq \theta'} \gamma_Y(\theta) = \gamma_Y(\theta') = \alpha$ 。故该检验是 level α 的。

综上, $C = \{Y \geq c_Y\}$ 是 UMP level α 检验。证毕。

Exercises

Section 8.1.

EXERCISE 8.1. *8.1 Best Test for Normal Mean ($\theta'' = -1$) – Hogg 8.1.1 In Example 8.1.2 of this section, let the simple hypotheses read $H_0: \theta = \theta' = 0$ and $H_1: \theta = \theta'' = -1$. Show that the best test of H_0 against H_1 may be carried out by use of the statistic $\bar{X}$, and that if $n = 25$ and $\alpha = 0.05$, the power of the test is 0.9996 when H_1 is true.*

EXERCISE 8.2. *8.2 Best Test for Exponential Distribution – Hogg 8.1.2 Let the random variable X have the pdf $f(x; \theta) = (1/\theta)e^{-x/\theta}$, $0 < x < \infty$, zero elsewhere. Consider the simple hypothesis $H_0: \theta = \theta' = 2$ and the alternative hypothesis $H_1: \theta = \theta'' = 4$. Let X_1, X_2 denote a random sample of size 2 from this distribution. Show that the best test of H_0 against H_1 may be carried out by use of the statistic $X_1 + X_2$.*

EXERCISE 8.3. *8.3 Generalization for Exponential Best Test – Hogg 8.1.3 Repeat Exercise 8.1.2 when $H_1: \theta = \theta'' = 6$. Generalize this for every $\theta'' > 2$.*

EXERCISE 8.4. **8.4 Best Critical Region for Normal Variance – Hogg 8.1.4** Let $X_1, X_2, \dots, X_{10}$ be a random sample of size 10 from a normal distribution $N(0, \sigma^2)$. Find a best critical region of size $\alpha = 0.05$ for testing $H_0 : \sigma^2 = 1$ against $H_1 : \sigma^2 = 2$. Is this a best critical region of size 0.05 for testing $H_0 : \sigma^2 = 1$ against $H_1 : \sigma^2 = 4$? Against $H_1 : \sigma^2 = \sigma_1^2 > 1$?

EXERCISE 8.5. **8.5 Best Test for Beta Distribution – Hogg 8.1.5** If $X_1, X_2, \dots, X_n$ is a random sample from a distribution having pdf of the form $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere, show that a best critical region for testing $H_0 : \theta = 1$ against $H_1 : \theta = 2$ is $C = \{(x_1, x_2, \dots, x_n) : c \leq \prod_{i=1}^n x_i\}$.

EXERCISE 8.6. **8.6 Best Test for Bivariate Normal – Hogg 8.1.6** Let $X_1, X_2, \dots, X_{10}$ be a random sample from a distribution that is $N(\theta_1, \theta_2)$. Find a best test of the simple hypothesis $H_0 : \theta_1 = \theta'_1 = 0, \theta_2 = \theta'_2 = 1$ against the alternative simple hypothesis $H_1 : \theta_1 = \theta''_1 = 1, \theta_2 = \theta''_2 = 4$.

EXERCISE 8.7. **8.7 Best Test for Normal Mean with Power Constraint – Hogg 8.1.7** Let $X_1, X_2, \dots, X_n$ denote a random sample from a normal distribution $N(\theta, 100)$. Show that $C = \{(x_1, x_2, \dots, x_n) : c \leq \bar{x} = \sum_{i=1}^n x_i/n\}$ is a best critical region for testing $H_0 : \theta = 75$ against $H_1 : \theta = 78$. Find n and c so that

$$\mathbb{P}_{H_0}[(X_1, X_2, \dots, X_n) \in C] = \mathbb{P}_{H_0}(\bar{X} \geq c) = 0.05$$

and

$$\mathbb{P}_{H_1}[(X_1, X_2, \dots, X_n) \in C] = \mathbb{P}_{H_1}(\bar{X} \geq c) = 0.90,$$

approximately.

EXERCISE 8.8. **8.8 Best Test for Beta(,) Distribution – Hogg 8.1.8** If $X_1, X_2, \dots, X_n$ is a random sample from a beta distribution with parameters $\alpha = \beta = \theta > 0$, find a best critical region for testing $H_0 : \theta = 1$ against $H_1 : \theta = 2$.

EXERCISE 8.9. **8.9 Best Test for Bernoulli with CLT Approximation – Hogg 8.1.9** Let $X_1, X_2, \dots, X_n$ be iid with pmf $f(x; p) = p^x(1-p)^{1-x}$, $x = 0, 1$, zero elsewhere. Show that $C = \{(x_1, \dots, x_n) : \sum_{i=1}^n x_i \leq c\}$ is a best critical region for testing $H_0 : p = 1/2$ against $H_1 : p = 1/3$. Use the Central Limit Theorem to find n and c so that approximately $\mathbb{P}_{H_0}(\sum_{i=1}^n X_i \leq c) = 0.10$ and $\mathbb{P}_{H_1}(\sum_{i=1}^n X_i \leq c) = 0.80$.

EXERCISE 8.10. **8.10 Best Test for Poisson Distribution – Hogg 8.1.10** Let $X_1, X_2, \dots, X_{10}$ denote a random sample of size 10 from a Poisson distribution with mean θ . Show that the critical region C defined by $\sum_{i=1}^{10} x_i \geq 3$ is a best critical region for testing $H_0 : \theta = 0.1$ against $H_1 : \theta = 0.5$. Determine, for this test, the significance level α and the power at $\theta = 0.5$. Use the R function `ppois`.

Section 8.2.

EXERCISE 8.11. **8.11** *Power Function for Bernoulli Test – Hogg 8.2.1* Let X have the pmf $f(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$, zero elsewhere. We test the simple hypothesis $H_0 : \theta = 1/4$ against the alternative composite hypothesis $H_1 : \theta < 1/4$ by taking a random sample of size 10 and rejecting $H_0 : \theta = 1/4$ if and only if the observed values $x_1, x_2, \dots, x_{10}$ of the sample observations are such that $\sum_{i=1}^{10} x_i \leq 1$. Find the power function $\gamma(\theta)$, $0 < \theta \leq 1/4$, of this test.

EXERCISE 8.12. **8.12** *Power Function for Uniform Distribution Test – Hogg 8.2.2* Let X have a pdf of the form $f(x; \theta) = 1/\theta$, $0 < x < \theta$, zero elsewhere. Let $Y_1 < Y_2 < Y_3 < Y_4$ denote the order statistics of a random sample of size 4 from this distribution. Let the observed value of Y_4 be y_4 . We reject $H_0 : \theta = 1$ and accept $H_1 : \theta \neq 1$ if either $y_4 \leq 1/2$ or $y_4 > 1$. Find the power function $\gamma(\theta)$, $0 < \theta$, of the test.

EXERCISE 8.13. **8.13** *Power Function for Normal Mean Test – Hogg 8.2.3* Consider a normal distribution of the form $N(\theta, 4)$. The simple hypothesis $H_0 : \theta = 0$ is rejected, and the alternative composite hypothesis $H_1 : \theta > 0$ is accepted if and only if the observed mean $\bar{x}$ of a random sample of size 25 is greater than or equal to $3/5$. Find the power function $\gamma(\theta)$, $0 \leq \theta$, of this test.

EXERCISE 8.14. **8.14** *Two-Sample Normal Test with Power Constraint – Hogg 8.2.4* Consider the distributions $N(\mu_1, 400)$ and $N(\mu_2, 225)$. Let $\theta = \mu_1 - \mu_2$. Let $\bar{x}$ and $\bar{y}$ denote the observed means of two independent random samples, each of size n , from these two distributions. We reject $H_0 : \theta = 0$ and accept $H_1 : \theta > 0$ if and only if $\bar{x} - \bar{y} \geq c$. If $\gamma(\theta)$ is the power function of this test, find n and c so that $\gamma(0) = 0.05$ and $\gamma(10) = 0.90$, approximately.

EXERCISE 8.15. **8.15** *MLR and UMP Test for Normal Variance – Hogg 8.2.5* Consider Example 8.2.2. Show that $L(\theta)$ has a monotone likelihood ratio in the statistic $\sum_{i=1}^n X_i^2$. Use this to determine the UMP test for $H_0 : \theta = \theta'$, where θ' is a fixed positive number, versus $H_1 : \theta < \theta'$.

EXERCISE 8.16. **8.16** *No UMP Test for Two-Sided Normal Mean – Hogg 8.2.6* If, in Example 8.2.2 of this section, $H_0 : \theta = \theta'$, where θ' is a fixed positive number, and $H_1 : \theta \neq \theta'$, show that there is no uniformly most powerful test for testing H_0 against H_1 .

EXERCISE 8.17. **8.17** *UMP Test for Normal Mean – Hogg 8.2.7* Let $X_1, X_2, \dots, X_{25}$ denote a random sample of size 25 from a normal distribution $N(\theta, 100)$. Find a uniformly most powerful critical region of size $\alpha = 0.10$ for testing $H_0 : \theta = 75$ against $H_1 : \theta > 75$.

EXERCISE 8.18. **8.18** *UMP Test for Normal Mean (Lower Tail) – Hogg 8.2.8* Let $X_1, X_2, \dots, X_n$ denote a random sample from a normal distribution $N(\theta, 16)$. Find the

sample size n and a uniformly most powerful test of $H_0 : \theta = 25$ against $H_1 : \theta < 25$ with power function $\gamma(\theta)$ so that approximately $\gamma(25) = 0.10$ and $\gamma(23) = 0.90$.

EXERCISE 8.19. **8.19** *Sample Size for Bernoulli UMP Test – Hogg 8.2.9* Consider a distribution having a pmf of the form $f(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$, zero elsewhere. Let $H_0 : \theta = 1/20$ and $H_1 : \theta > 1/20$. Use the Central Limit Theorem to determine the sample size n of a random sample so that a uniformly most powerful test of H_0 against H_1 has a power function $\gamma(\theta)$, with approximately $\gamma(1/20) = 0.05$ and $\gamma(1/10) = 0.90$.

EXERCISE 8.20. **8.20** *Gamma Distribution SPRT Generalization – Hogg 8.2.10* Illustrative Example 8.2.1 of this section dealt with a random sample of size $n = 2$ from a gamma distribution with $\alpha = 1$, $\beta = \theta$. Thus the mgf of the distribution is $(1 - \theta t)^{-1}$, $t < 1/\theta$, $\theta \geq 2$. Let $Z = X_1 + X_2$. Show that Z has a gamma distribution with $\alpha = 2$, $\beta = \theta$. Express the power function $\gamma(\theta)$ of Example 8.2.1 in terms of a single integral. Generalize this for a random sample of size n .

EXERCISE 8.21. **8.21** *MLR and UMP Test for Beta Distribution – Hogg 8.2.11* Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere, where $\theta > 0$. Show the likelihood has MLR in the statistic $\prod_{i=1}^n X_i$. Use this to determine the UMP test for $H_0 : \theta = \theta'$ against $H_1 : \theta < \theta'$, for fixed $\theta' > 0$.

EXERCISE 8.22. **8.22** *Randomized UMP Test for Bernoulli – Hogg 8.2.12* Let X have the pdf $f(x; \theta) = \theta^x(1 - \theta)^{1-x}$, $x = 0, 1$, zero elsewhere. We test $H_0 : \theta = 1/2$ against $H_1 : \theta < 1/2$ by taking a random sample $X_1, X_2, \dots, X_5$ of size $n = 5$ and rejecting H_0 if $Y = \sum_{i=1}^n X_i$ is observed to be less than or equal to a constant c .

- Show that this is a uniformly most powerful test.
- Find the significance level when $c = 1$.
- Find the significance level when $c = 0$.
- By using a randomized test, as discussed in Example 4.6.4, modify the tests given in parts (b) and (c) to find a test with significance level $\alpha = 2/32$.

EXERCISE 8.23. **8.23** *UMP Test for Gamma Distribution – Hogg 8.2.13* Let $X_1, \dots, X_n$ denote a random sample from a gamma-type distribution with $\alpha = 2$ and $\beta = \theta$. Let $H_0 : \theta = 1$ and $H_1 : \theta > 1$.

- Show that there exists a uniformly most powerful test for H_0 against H_1 , determine the statistic Y upon which the test may be based, and indicate the nature of the best critical region.
- Find the pdf of the statistic Y in part (a). If we want a significance level of 0.05, write an equation that can be used to determine the critical region. Let $\gamma(\theta)$, $\theta \geq 1$, be the power function of the test. Express the power function as an integral.

EXERCISE 8.24. [8.24](#) *MLR Test is Unbiased – Hogg 8.2.14* Show that the MLR test defined by expression (8.2.3) is an unbiased test for the hypotheses (8.2.1).

Section 8.3.

EXERCISE 8.25. [8.25](#) *Temperature Data Analysis – Hogg 8.3.1 Verzani (2014)* discusses a data set on healthy individuals, including their temperatures by gender. The data are in the file `tempbygender.rda` and the variables of interest are `maletemp` and `femaletemp`. Download this file from the site listed in the Preface.

- (a) Obtain comparison boxplots. Comment on the plots. Which, if any, gender seems to have lower temperatures? Based on the width of the boxplots, comment on the assumption of equal variances.
- (b) As discussed in Example 8.3.3, compute the two-sample, two-sided t -test that there is no difference in the true mean temperatures between genders. Obtain the p -value of the test and conclude in terms of the problem at the nominal α -level of 0.05.
- (c) Obtain a 95% confidence interval for the difference in means. What does it mean in terms of the problem?

EXERCISE 8.26. [8.26](#) *Verify LRT Equations – Hogg 8.3.2* Verify Equations (8.3.2) of Example 8.3.1 of this section.

EXERCISE 8.27. [8.27](#) *Verify LRT Equations (Continued) – Hogg 8.3.3* Verify Equations (8.3.3) of Example 8.3.1 of this section.

EXERCISE 8.28. [8.28](#) *Location Model Two-Sample Test – Hogg 8.3.4* Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ follow the location model

$$\begin{aligned} X_i &= \theta_1 + Z_i, & i &= 1, \dots, n, \\ Y_i &= \theta_2 + Z_{n+i}, & i &= 1, \dots, m, \end{aligned}$$

where $Z_1, \dots, Z_{n+m}$ are iid random variables with common pdf $f(z)$. Assume that $\mathbb{E}(Z_i) = 0$ and $\text{var}(Z_i) = \theta_3 < \infty$.

- (a) Show that $\mathbb{E}(X_i) = \theta_1$, $\mathbb{E}(Y_i) = \theta_2$, and $\text{var}(X_i) = \text{var}(Y_i) = \theta_3$.
- (b) Consider the hypotheses of Example 8.3.1, i.e.,

$$H_0 : \theta_1 = \theta_2 \text{ versus } H_1 : \theta_1 \neq \theta_2.$$

Show that under H_0 , the test statistic T given in expression (8.3.4) has a limiting $N(0, 1)$ distribution.

- (c) Using part (b), determine the corresponding large sample test (decision rule) of H_0 versus H_1 . (This shows that the test in Example 8.3.1 is asymptotically correct.)

EXERCISE 8.29. **8.29** *Power Function for One-Sample t-Test – Hogg 8.3.5* In Example 8.3.2, the power function for the one-sample t-test is discussed.

- (a) Plot the power function for the following setup: X has a $N(\mu, \sigma^2)$ distribution; $H_0 : \mu = 50$ versus $H_1 : \mu \neq 50$; $\alpha = 0.05$; $n = 25$; and $\sigma = 10$.
- (b) Overlay the power curve in (a) with that for $\alpha = 0.01$. Comment.
- (c) Overlay the power curve in (a) with that for $n = 35$. Comment.
- (d) Determine the smallest value of n so the power exceeds 0.80 to detect $\mu = 53$.
Hint: Modify the R function `tpowerg.R` so it returns the power for a specified alternative.

EXERCISE 8.30. **8.30** *Drug Comparison Power Analysis – Hogg 8.3.6* The effect that a certain drug (Drug A) has on increasing blood pressure is a major concern. It is thought that a modification of the drug (Drug B) will lessen the increase in blood pressure. Let μ_A and μ_B be the true mean increases in blood pressure due to Drug A and B, respectively. The hypotheses of interest are $H_0 : \mu_A = \mu_B = 0$ versus $H_1 : \mu_A > \mu_B = 0$. The two-sample t-test statistic discussed in Example 8.3.3 is to be used to conduct the analysis. The nominal level is set at $\alpha = 0.05$. For the experimental design assume that the sample sizes are the same; i.e., $m = n$. Also, based on data from Drug A, $\sigma = 30$ seems to be a reasonable selection for the common standard deviation. Determine the common sample size, so that the difference in means $\mu_A - \mu_B = 12$ has an 80% detection rate. Suppose when the experiment is over, due to patients dropping out, the sample sizes for Drugs A and B are respectively $n = 72$ and $m = 68$. What was the actual power of the experiment to detect the difference of 12?

EXERCISE 8.31. **8.31** *LRT Equals NP Test for Simple Hypotheses – Hogg 8.3.7* Show that the likelihood ratio principle leads to the same test when testing a simple hypothesis H_0 against an alternative simple hypothesis H_1 , as that given by the Neyman-Pearson theorem. Note that there are only two points in Ω .

EXERCISE 8.32. **8.32** *LRT for Normal Mean (Two-Sided) – Hogg 8.3.8* Let $X_1, X_2, \dots, X_n$ be a random sample from the normal distribution $N(\theta, 1)$. Show that the likelihood ratio principle for testing $H_0 : \theta = \theta'$, where θ' is specified, against $H_1 : \theta \neq \theta'$ leads to the inequality $|\bar{x} - \theta'| \geq c$.

- (a) Is this a uniformly most powerful test of H_0 against H_1 ?
- (b) Is this a uniformly most powerful unbiased test of H_0 against H_1 ?

EXERCISE 8.33. **8.33** *LRT for Normal Variance – Hogg 8.3.9* Let $X_1, X_2, \dots, X_n$ be iid $N(\theta_1, \theta_2)$. Show that the likelihood ratio principle for testing $H_0 : \theta_2 = \theta'_2$ specified, and θ_1 unspecified, against $H_1 : \theta_2 \neq \theta'_2$, θ_1 unspecified, leads to a test that rejects when $\sum_1^n (x_i - \bar{x})^2 \leq c_1$ or $\sum_1^n (x_i - \bar{x})^2 \geq c_2$, where $c_1 < c_2$ are selected appropriately.

EXERCISE 8.34. **8.34** *Power Function for LRT in Example 8.3.5 – Hogg 8.3.10* For the situation discussed in Example 8.3.5, derive the power function for the likelihood ratio test statistic given in expression (8.3.9).

EXERCISE 8.35. **8.35** *LRT for Two Normal Variances – Hogg 8.3.11* Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ be independent random samples from the distributions $N(\theta_1, \theta_3)$ and $N(\theta_2, \theta_4)$, respectively.

- (a) Show that the likelihood ratio for testing $H_0 : \theta_1 = \theta_2, \theta_3 = \theta_4$ against all alternatives is given by

$$\frac{[\sum_1^n (x_i - \bar{x})^2 / n]^{n/2} [\sum_1^m (y_i - \bar{y})^2 / m]^{m/2}}{\{[\sum_1^n (x_i - u)^2 + \sum_1^m (y_i - u)^2] / (m + n)\}^{(n+m)/2}},$$

where $u = (n\bar{x} + m\bar{y}) / (n + m)$.

- (b) Show that the likelihood ratio for testing $H_0 : \theta_3 = \theta_4$ with θ_1 and θ_2 unspecified can be based on the test statistic F given in expression (8.3.9).

EXERCISE 8.36. **8.36** *LRT for Laplace Distribution – Hogg 8.3.12* Let $Y_1 < Y_2 < \dots < Y_5$ be the order statistics of a random sample of size $n = 5$ from a distribution with pdf $f(x; \theta) = \frac{1}{2}e^{-|x-\theta|}$, $-\infty < x < \infty$, for all real θ . Find the likelihood ratio test Λ for testing $H_0 : \theta = \theta_0$ against $H_1 : \theta \neq \theta_0$.

EXERCISE 8.37. **8.37** *LRT for Uniform vs Exponential – Hogg 8.3.13* A random sample $X_1, X_2, \dots, X_n$ arises from a distribution given by

$$H_0 : f(x; \theta) = \frac{1}{\theta}, \quad 0 < x < \theta, \quad \text{zero elsewhere,}$$

or

$$H_1 : f(x; \theta) = \frac{1}{\theta}e^{-x/\theta}, \quad 0 < x < \infty, \quad \text{zero elsewhere.}$$

Determine the likelihood ratio (Λ) test associated with the test of H_0 against H_1 .

EXERCISE 8.38. **8.38** *UMP and LRT for Beta-like Distribution – Hogg 8.3.14* Consider a random sample $X_1, X_2, \dots, X_n$ from a distribution with pdf $f(x; \theta) = \theta(1-x)^{\theta-1}$, $0 < x < 1$, zero elsewhere, where $\theta > 0$.

- (a) Find the form of the uniformly most powerful test of $H_0 : \theta = 1$ against $H_1 : \theta > 1$.
- (b) What is the likelihood ratio Λ for testing $H_0 : \theta = 1$ against $H_1 : \theta \neq 1$?

EXERCISE 8.39. **8.39** *LRT for Testing Means with Common Variance – Hogg 8.3.15* Let $X_1, X_2, \dots, X_n$ and $Y_1, Y_2, \dots, Y_n$ be independent random samples from two normal distributions $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$, respectively, where σ^2 is the common but unknown variance.

- (a) Find the likelihood ratio Λ for testing $H_0 : \mu_1 = \mu_2 = 0$ against all alternatives.

- (b) Rewrite Λ so that it is a function of a statistic Z which has a well-known distribution.
- (c) Give the distribution of Z under both null and alternative hypotheses.

EXERCISE 8.40. **8.40** *LRT for Bivariate Normal – Hogg 8.3.16* Let $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$ be a random sample from a bivariate normal distribution with $\mu_1, \mu_2, \sigma_1^2 = \sigma_2^2 = \sigma^2, \rho = 1/2$, where μ_1, μ_2 , and $\sigma^2 > 0$ are unknown real numbers. Find the likelihood ratio Λ for testing $H_0 : \mu_1 = \mu_2 = 0, \sigma^2$ unknown against all alternatives. The likelihood ratio Λ is a function of what statistic that has a well-known distribution?

EXERCISE 8.41. **8.41** *LRT for Comparing Variances of Laplace Distributions – Hogg 8.3.17* Let X be a random variable with pdf $f_X(x) = (2b_X)^{-1} \exp\{-|x|/b_X\}$, for $-\infty < x < \infty$ and $b_X > 0$. First, show that the variance of X is $\sigma_X^2 = 2b_X^2$. Next, let Y , independent of X , have pdf $f_Y(y) = (2b_Y)^{-1} \exp\{-|y|/b_Y\}$, for $-\infty < x < \infty$ and $b_Y > 0$. Consider the hypotheses

$$H_0 : \sigma_X^2 = \sigma_Y^2 \text{ versus } H_1 : \sigma_X^2 > \sigma_Y^2.$$

To illustrate Remark 8.3.2 for testing these hypotheses, consider the following data set (data are also in the file `exercise8316.rda`). Sample 1 represents the values of a sample drawn on X with $b_X = 1$, while Sample 2 represents the values of a sample drawn on Y with $b_Y = 1$. Hence, in this case H_0 is true.

Sample 1	−0.389	−0.110	−2.177	−0.709	0.813	0.456	−0.001
	0.135	0.763	0.403	−0.570	0.778	−2.565	−0.115
	−1.733						
Sample 2	−1.067	−0.634	−0.577	−0.996	0.361	−0.181	−0.680
	0.239	−0.775	0.213	−1.421	1.425	−0.818	−0.165
	0.328						

- (a) Obtain comparison boxplots of these two samples. Comparison boxplots consist of boxplots of both samples drawn on the same scale. Based on these plots, in particular the interquartile ranges, what do you conclude about H_0 ?
- (b) Obtain the F -test (for a one-sided hypothesis) as discussed in Remark 8.3.2 at level $\alpha = 0.10$. What is your conclusion?
- (c) The test in part (b) is not exact. Why?

EXERCISE 8.42. **8.42** *Skewed Contaminated Normal Properties – Hogg 8.3.18* For the skewed contaminated normal random variable X of Example 8.3.4, derive the cdf, pdf, mean, and variance of X .

EXERCISE 8.43. **8.43** *Binomial CI Half-Width – Hogg 8.3.19* For Table 8.3.1 of Example 8.3.4, show that the half-width of the 95% confidence interval for a binomial proportion as given in Chapter 4 is 0.004 at the nominal value of 0.05.

EXERCISE 8.44. [8.44](#) *Monte Carlo Study for t-Test under Contaminated Normal – Hogg 8.3.20* If computational facilities are available, perform a Monte Carlo study of the two-sided t -test for the skewed contaminated normal situation of Example 8.3.4. The R function `rsctn.R` generates variates from the distribution of X .

EXERCISE 8.45. [8.45](#) *Unbiased Test for Normal Mean with Known Variance – Hogg 8.3.21* Suppose $X_1, \dots, X_n$ is a random sample on X which has a $N(\mu, \sigma_0^2)$ distribution, where σ_0^2 is known. Consider the two-sided hypotheses

$$H_0 : \mu = 0 \text{ versus } H_1 : \mu \neq 0.$$

Show that the test based on the critical region $C = \{|\bar{X}| > \sqrt{\sigma_0^2/n} z_{\alpha/2}\}$ is an unbiased level α test.

EXERCISE 8.46. [8.46](#) *One-Sided Test is Not Unbiased – Hogg 8.3.22* Assume the same situation as in the last exercise but consider the test with critical region $C^* = \{\bar{X} > \sqrt{\sigma_0^2/n} z_\alpha\}$. Show that the test based on C^* has significance level α but that it is not an unbiased test.

Section 8.4.

EXERCISE 8.47. [8.47](#) *SPRT for Normal Variance – Hogg 8.4.1* Let X be $N(0, \theta)$ and, in the notation of this section, let $\theta' = 4$, $\theta'' = 9$, $\alpha_a = 0.05$, and $\beta_a = 0.10$. Show that the sequential probability ratio test can be based upon the statistic $\sum_1^n X_i^2$. Determine $c_0(n)$ and $c_1(n)$.

EXERCISE 8.48. [8.48](#) *SPRT for Poisson Distribution – Hogg 8.4.2* Let X have a Poisson distribution with mean θ . Find the sequential probability ratio test for testing $H_0 : \theta = 0.02$ against $H_1 : \theta = 0.07$. Show that this test can be based upon the statistic $\sum_{i=1}^n X_i$. If $\alpha_a = 0.20$ and $\beta_a = 0.10$, find $c_0(n)$ and $c_1(n)$.

EXERCISE 8.49. [8.49](#) *SPRT for Difference of Normal Means – Hogg 8.4.3* Let the independent random variables Y and Z be $N(\mu_1, 1)$ and $N(\mu_2, 1)$, respectively. Let $\theta = \mu_1 - \mu_2$. Let us observe independent observations from each distribution, say $Y_1, Y_2, \dots$ and $Z_1, Z_2, \dots$. To test sequentially the hypothesis $H_0 : \theta = 0$ against $H_1 : \theta = 1/2$, use the sequence $X_i = Y_i - Z_i$, $i = 1, 2, \dots$. If $\alpha_a = \beta_a = 0.05$, show that the test can be based upon $\bar{X} = \bar{Y} - \bar{Z}$. Find $c_0(n)$ and $c_1(n)$.

EXERCISE 8.50. [8.50](#) *SPRT for Binomial Process – Hogg 8.4.4* Suppose that a manufacturing process makes about 3% defective items, which is considered satisfactory for this particular product. The managers would like to decrease this to about 1% and clearly want to guard against a substantial increase, say to 5%. To monitor the process, periodically $n = 100$ items are taken and the number X of defectives counted. Assume that X is $b(n = 100, p = \theta)$. Based on a sequence $X_1, X_2, \dots, X_m, \dots$, determine a sequential

probability ratio test that tests $H_0 : \theta = 0.01$ against $H_1 : \theta = 0.05$. (Note that $\theta = 0.03$, the present level, is in between these two values.) Write this test in the form

$$h_0 > \sum_{i=1}^m (x_i - nd) > h_1$$

and determine d , h_0 , and h_1 if $\alpha_a = \beta_a = 0.02$.

EXERCISE 8.51. **8.51** SPRT for Beta Distribution – Hogg 8.4.5 Let $X_1, X_2, \dots, X_n$ be a random sample from a distribution with pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$, zero elsewhere.

- (a) Find a complete sufficient statistic for θ .
- (b) If $\alpha_a = \beta_a = 1/10$, find the sequential probability ratio test of $H_0 : \theta = 2$ against $H_1 : \theta = 3$.

Section 8.5.

EXERCISE 8.52. **8.52** Minimax Test for Normal Mean – Hogg 8.5.1 Let $X_1, X_2, \dots, X_{20}$ be a random sample of size 20 from a distribution that is $N(\theta, 5)$. Let $L(\theta)$ represent the joint pdf of $X_1, X_2, \dots, X_{20}$. The problem is to test $H_0 : \theta = 1$ against $H_1 : \theta = 0$. Thus $\Omega = \{\theta : \theta = 0, 1\}$.

- (a) Show that $L(1)/L(0) \leq k$ is equivalent to $\bar{x} \leq c$.
- (b) Find c so that the significance level is $\alpha = 0.05$. Compute the power of this test if H_1 is true.
- (c) If the loss function is such that $\mathcal{L}(1, 1) = \mathcal{L}(0, 0) = 0$ and $\mathcal{L}(1, 0) = \mathcal{L}(0, 1) > 0$, find the minimax test. Evaluate the power function of this test at the points $\theta = 1$ and $\theta = 0$.

EXERCISE 8.53. **8.53** Minimax Test for Poisson Distribution – Hogg 8.5.2 Let $X_1, X_2, \dots, X_{10}$ be a random sample of size 10 from a Poisson distribution with parameter θ . Let $L(\theta)$ be the joint pdf of $X_1, X_2, \dots, X_{10}$. The problem is to test $H_0 : \theta = 1/2$ against $H_1 : \theta = 1$.

- (a) Show that $L(1/2)/L(1) \leq k$ is equivalent to $y = \sum_1^n x_i \geq c$.
- (b) In order to make $\alpha = 0.05$, show that H_0 is rejected if $y > 9$ and, if $y = 9$, reject H_0 with probability $1/2$ (using some auxiliary random experiment).
- (c) If the loss function is such that $\mathcal{L}(1/2, 1/2) = \mathcal{L}(1, 1) = 0$ and $\mathcal{L}(1/2, 1) = 1$ and $\mathcal{L}(1, 1/2) = 2$, show that the minimax procedure is to reject H_0 if $y > 6$ and, if $y = 6$, reject H_0 with probability 0.08 (using some auxiliary random experiment).

EXERCISE 8.54. **8.54** Classification for Bivariate Normal – Hogg 8.5.3 In Example 8.5.2 let $\mu'_1 = \mu'_2 = 0$, $\mu''_1 = \mu''_2 = 1$, $\sigma_1^2 = 1$, $\sigma_2^2 = 1$, and $\rho = 1/2$.

- (a) Find the distribution of the linear function $aX + bY$.
- (b) With $k = 1$, compute $\mathbb{P}(aX + bY \leq c; \mu'_1 = \mu'_2 = 0)$ and $\mathbb{P}(aX + bY > c; \mu''_1 = \mu''_2 = 1)$.

EXERCISE 8.55. **8.55** *Newton's Algorithm for Minimax – Hogg 8.5.4* Determine Newton's algorithm to find the solution of Equation (8.5.2). If software is available, write a program that performs your algorithm and then show that the solution is $c = 76.8$. If software is not available, solve (8.5.2) by "trial and error".

EXERCISE 8.56. **8.56** *Classification Rule for Bivariate Exponential – Hogg 8.5.5* Let X and Y have the joint pdf

$$f(x, y; \theta_1, \theta_2) = \frac{1}{\theta_1 \theta_2} \exp \left(-\frac{x}{\theta_1} - \frac{y}{\theta_2} \right), \quad 0 < x < \infty, \quad 0 < y < \infty,$$

zero elsewhere, where $0 < \theta_1, 0 < \theta_2$. An observation (x, y) arises from the joint distribution with parameters equal to either $(\theta'_1 = 1, \theta'_2 = 5)$ or $(\theta''_1 = 3, \theta''_2 = 2)$. Determine the form of the classification rule.

EXERCISE 8.57. **8.57** *Quadratic Classification Rule – Hogg 8.5.6* Let X and Y have a joint bivariate normal distribution. An observation (x, y) arises from the joint distribution with parameters equal to either

$$\mu'_1 = \mu'_2 = 0, \quad (\sigma_1^2)' = (\sigma_2^2)' = 1, \quad \rho' = 1/2$$

or

$$\mu''_1 = \mu''_2 = 1, \quad (\sigma_1^2)'' = 4, \quad (\sigma_2^2)'' = 9, \quad \rho'' = 1/2.$$

Show that the classification rule involves a second-degree polynomial in x and y .

EXERCISE 8.58. **8.58** *Classification for Bivariate Normal with Different Variances – Hogg 8.5.7* Let $\mathbf{W}' = (W_1, W_2)$ be an observation from one of two bivariate normal distributions, I and II, each with $\mu_1 = \mu_2 = 0$ but with the respective variance-covariance matrices

$$\mathbf{V}_1 = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix} \quad \text{and} \quad \mathbf{V}_2 = \begin{pmatrix} 3 & 0 \\ 0 & 12 \end{pmatrix}.$$

How would you classify $\mathbf{W}$ into I or II?

CHAPTER 9

ANOVA and Regression

Chapter 9 Overview

在前几章中，我们讨论了来自单个总体的样本推断，以及两个总体的比较。但实际中，我们常常面临更复杂的问题：

如果有三个、四个甚至更多个总体，我们该如何比较它们的均值？

这个问题——即**多组比较问题**——在农业实验、医学试验、工业质量控制等领域无处不在。例如，在一项评估不同肥料对作物产量影响的实验中，我们需要同时比较多个处理组；而在研究药物疗效时，我们可能需要同时评估多种药物的效果。

本章，我们从单样本 t 检验 $\rightarrow$ 两样本 t 检验 $\rightarrow$ 多组比较的自然推广，引入**方差分析 (Analysis of Variance, 简称 ANOVA)**。这一方法由 Ronald Fisher 在 1920 年代创立，起源于他在英国洛桑农业实验站的农业实验研究。Fisher 的核心思想是：将总变异分解为可解释的变异和随机误差，通过比较两者来判断处理效应是否显著。

本章路线图：

- (1) One-Way ANOVA $\rightarrow$ 组间/组内平方和分解 $\rightarrow F$ 检验
- (2) 非中心 χ^2 和 F 分布 $\rightarrow$ 备择假设下的分布
- (3) Multiple Comparisons $\rightarrow$ Tukey 法、Bonferroni 法（控制族误差率）
- (4) Two-Way ANOVA $\rightarrow$ 主效应、交互效应
- (5) 回归问题 $\rightarrow$ 最小二乘估计、几何解释（投影）
- (6) 二次型分布 $\rightarrow$ Cochran 定理——平方和分解的理论基础

1. 9.1 Introduction

在正式进入 ANOVA 之前，我们需要介绍一个重要的数学工具——**二次型 (quadratic form)**。

DEFINITION 9.1 (二次型). 设 $X_1, \dots, X_n$ 是 n 个变量， a_{ij} 是常数。形如

$$q(X_1, \dots, X_n) = \sum_{i=1}^n \sum_{j=1}^n X_i a_{ij} X_j$$

的表达式称为 $X_1, \dots, X_n$ 的（二次）**二次型**。

为什么二次型重要？ 在统计推断中，许多关键的统计量都可以表示为二次型。例如，样本方差

$$(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

就是关于样本 $X_1, \dots, X_n$ 的一个二次型。理解二次型的分布性质, 是理解 ANOVA 和回归分析的理论基础。

2. 9.2 One-Way ANOVA

2.1. 问题的引入. 考虑 b 个独立的正态总体, 第 j 个总体的均值为 μ_j , 共同方差为 σ^2 。从第 j 个总体中抽取容量为 n_j 的随机样本 $X_{1j}, X_{2j}, \dots, X_{n_jj}$ 。记总样本量为 $n = \sum_{j=1}^b n_j$ 。

模型为:

$$X_{ij} = \mu_j + e_{ij}, \quad i = 1, \dots, n_j, \quad j = 1, \dots, b,$$

其中 e_{ij} 是 iid $N(0, \sigma^2)$ 随机误差。

我们想检验: 所有 b 个总体的均值是否相等——

$$H_0: \mu_1 = \mu_2 = \dots = \mu_b \quad \text{vs} \quad H_1: \mu_j \neq \mu_{j'} \text{ 对某些 } j \neq j'.$$

实际背景: 例如, b 种药物对某种疾病的疗效比较; 或 b 种肥料对作物产量的影响。这里“一种因素 (factor)”处于 b 个“水平 (level)”, 因此称为**单因素实验 (one-way layout)**。

2.2. 似然比检验的推导. 完全模型 (full model) 参数空间:

$$\Omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : -\infty < \mu_j < \infty, \quad 0 < \sigma^2 < \infty\}.$$

约束模型 (reduced model) 参数空间 (H_0 下):

$$\omega = \{(\mu_1, \dots, \mu_b, \sigma^2) : \mu_1 = \dots = \mu_b = \mu, \quad 0 < \sigma^2 < \infty\}.$$

完全模型下的 MLE:

$$\hat{\mu}_j = \bar{X}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\Omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2.$$

约束模型下的 MLE (此时等价于单样本问题):

$$\hat{\mu}_\omega = \bar{X}_{..} = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} X_{ij}, \quad \hat{\sigma}_\omega^2 = \frac{1}{n} \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2.$$

似然比统计量简化后的形式为:

$$\Lambda^{n/2} = \frac{\hat{\sigma}_\Omega^2}{\hat{\sigma}_\omega^2}.$$

拒绝 H_0 等价于 F 统计量过大, 其中

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)},$$

而

$$Q_3 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{\cdot j})^2, \quad Q_4 = \sum_{j=1}^b n_j (\bar{X}_{\cdot j} - \bar{X}_{..})^2.$$

核心分解:

$$\underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2}_Q = \underbrace{\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}_{Q_3(\text{组内})} + \underbrace{\sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2}_{Q_4(\text{组间})}.$$

在 H_0 下, $Q_3/\sigma^2 \sim \chi^2(n-b)$, $Q_4/\sigma^2 \sim \chi^2(b-1)$, 且二者独立。因此 $F \sim F(b-1, n-b)$ 。

2.3. ANOVA 表格. 单因素 ANOVA 的结果可以汇总为一张清晰的表格:

表 1. 单因素 ANOVA 表格

来源	平方和 (SS)	df	均方 (MS)	F 统计量	p 值
组间 (Between)	Q_4	$b-1$	$MSB = Q_4/(b-1)$	$\frac{MSB}{MSW}$	$\mathbb{P}(F > F_0)$
组内 (Within)	Q_3	$n-b$	$MSW = Q_3/(n-b)$		
总计 (Total)	Q	$n-1$			

EXAMPLE 9.1 (合金弹性模量). Devore (2012, 第 412 页) 报告了一项数据: 三种铸造工艺 (永久模具、压铸、石膏模具) 生产合金的弹性模量。三种工艺各有多次测量, 我们想知道铸造工艺是否显著影响弹性模量。

数据汇总后, $F = 12.565$, 自由度为 2 和 19, p 值为 0.0003。如此小的 p 值表明: 铸造工艺对弹性模量有显著影响。

3. 9.3 Noncentral χ^2 and F Distributions

3.1. 为什么需要非中心分布? 在前一节的 ANOVA 中, 我们在原假设 H_0 下推导了 F 统计量的分布。但在实际应用中, 我们更关心: 当 H_0 不成立 (即各组均值不全相等) 时, F 统计量的分布是什么? 这时就需要引入**非中心 χ^2 分布**和**非中心 F 分布**。

DEFINITION 9.2 (非中心 χ^2 分布). 设 $X_i \sim N(\mu_i, \sigma^2)$, $i = 1, \dots, n$, 独立。则

$$Y = \sum_{i=1}^n \frac{X_i^2}{\sigma^2}$$

的 mgf 为

$$M(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}, \quad t < \frac{1}{2}.$$

此时称 $Y \sim \chi^2(r, \theta)$, 其中 $r = n$ 是自由度, $\theta = \sum_{i=1}^n \mu_i^2 / \sigma^2$ 是**非中心参数 (noncentrality parameter)**。

直观理解: 当所有 $\mu_i = 0$ 时, $\theta = 0$, 回到中心 χ^2 分布; 当某些 $\mu_i \neq 0$ 时, Y 的分布在中心 χ^2 的基础上向右偏移, θ 越大, 偏移越明显。

非中心 χ^2 分布的均值: $\mathbb{E}(Y) = r + \theta$ (中心部分 r 加上非中心部分 θ)。

DEFINITION 9.3 (非中心 F 分布). 设 $U \sim \chi^2(r_1, \theta)$, $V \sim \chi^2(r_2)$, 独立。则

$$F = \frac{r_2 U}{r_1 V}$$

服从自由度为 r_1, r_2 、非中心参数为 θ 的非中心 F 分布, 记作 $F(r_1, r_2, \theta)$ 。

EXAMPLE 9.2 (One-Way ANOVA 的非中心参数). 对于 *one-way ANOVA* 模型 (2.1), 在备择假设 H_1 下, F 统计量的分子 $Q_4/\sigma^2 \sim \chi^2(b-1, \theta)$, 其中

$$\theta = \frac{1}{\sigma^2} \sum_{j=1}^b n_j (\mu_j - \bar{\mu})^2, \quad \bar{\mu} = \frac{1}{n} \sum_{j=1}^b n_j \mu_j.$$

当 H_0 成立时, $\theta = 0$, 回到中心 F 分布; 当 H_1 成立时, $\theta > 0$, F 分布向右偏移, 偏移程度由 θ 刻画。这解释了为什么 F 检验在 H_0 不成立时倾向于取更大的值。

4. 9.4 Multiple Comparisons

当 one-way ANOVA 的 F 检验拒绝了 H_0 后, 我们自然想知道: 具体哪些组之间存在显著差异? 这就是多重比较问题 (Multiple Comparison Problem, MCP)。

4.1. 问题的核心矛盾. 对 b 个总体, 若进行所有 $\binom{b}{2}$ 个成对比较, 即使每个置信区间的置信水平为 95%, 整体的置信水平也会急剧下降。举例来说, 若 $b = 5$, 则共有 10 个成对比较, 每个比较犯错的概率为 5%, 至少有一次犯错的概率粗略估计为 $1 - (0.95)^{10} \approx 40\%$ 。

因此, 我们需要专门设计的方法来控制族误差率 (Family-Wise Error Rate, FWER) ——即在所有比较中至少有一次犯错的概率。

4.2. Bonferroni 方法. Bonferroni 方法基于一个简单的不等式: 对 k 个参数 θ_i , 若每个区间 I_i 的置信水平为 $1 - \alpha$, 则

$$P(\text{所有 } \theta_i \in I_i) \geq 1 - k\alpha.$$

核心理想: 将每个区间的置信水平从 $1 - \alpha$ 调整为 $1 - \alpha/k$, 则整体的置信水平至少为 $1 - \alpha$ 。

对 one-way ANOVA, 成对差值 $\mu_j - \mu_{j'}$ 的 Bonferroni 置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm t_{\alpha/(2k), n-b} \hat{\sigma}_\Omega \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}.$$

优点: 通用性强, 适用于任何成对比较。**缺点:** 比较数量 k 越大, 区间越宽, 精度损失越大。

4.3. Tukey 方法. Tukey 方法利用学生化极差分布 (Studentized range distribution), 专为 balanced 设计的成对比较设计。

当所有组样本容量相等 ($n_j = a, j = 1, \dots, b$) 时, 所有成对比较的同时置信区间为:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm q_{1-\alpha, b, n-b} \frac{\hat{\sigma}_{\Omega}}{\sqrt{a}}, \quad \forall j \neq j'.$$

其中 $q_{1-\alpha, b, n-b}$ 是自由度为 b 和 $n-b$ 的学生化极差分布分位数。

对于 unbalanced 情形, 使用 Tukey-Kramer 修正:

$$\bar{X}_{.j} - \bar{X}_{.j'} \pm \frac{q_{1-\alpha, b, n-b}}{\sqrt{2}} \hat{\sigma}_{\Omega} \sqrt{\frac{1}{n_j} + \frac{1}{n_{j'}}}.$$

EXAMPLE 9.3 (赛车速度比较). *Kitchens (1997)* 报告了一项实验: 比较五种汽车 (*Acura, Ferrari, Lotus, Porsche, Viper*) 的最高速度。每种车进行 6 次运行测试。整体 F 检验高度显著 ($F = 25.15, p \approx 0$)。Tukey 多重比较结果表明: *Ferrari* 和 *Porsche* 的平均速度显著快于其他三种车, 但 *Ferrari* 与 *Porsche* 之间速度差异不显著。

4.4. Fisher 的保护 LSD 方法. Fisher 方法是一个两步程序:

- (1) 首先进行整体 F 检验; 若拒绝 H_0 ,
- (2) 再使用标准的成对 t 置信区间 (置信水平 $1 - \alpha$)。

Fisher 方法不保证整体覆盖率为 $1 - \alpha$, 但 F 检验提供了”保护”。模拟研究表明它在功效和实际误差率方面表现良好。

5. 9.5 Two-Way ANOVA

5.1. 双因素实验的引入. 在实际研究中, 我们常常需要同时考虑两个因素对结果的影响。例如:

- 作物产量: 同时受品种 (因素 A) 和肥料类型 (因素 B) 的影响
- 考试成绩: 同时受教学方法 (因素 A) 和班级规模 (因素 B) 的影响

这就是**双因素方差分析 (two-way ANOVA)**。

设因素 A 有 a 个水平, 因素 B 有 b 个水平, 每个组合有一个观测值 X_{ij} 。模型为:

$$X_{ij} = \mu + \alpha_i + \beta_j + e_{ij}, \quad i = 1, \dots, a, j = 1, \dots, b,$$

其中 $e_{ij} \sim N(0, \sigma^2)$ iid, 且 $\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0$ 。

可加模型 (additive model) 意味着两个因素的影响是相互独立的——因素 A 的效应不随因素 B 的水平变化。

表 2. 双因素可加模型的单元格均值示例 ($a = 2, b = 3$)

	B=1	B=2	B=3
A=1	7	6	5
A=2	5	4	3

在可加模型中, 行均值轮廓线是**平行的**——这是可加模型的重要特征。

5.2. 假设检验. 我们需要检验两个主效应假设:

$$H_{0A}: \alpha_1 = \cdots = \alpha_a = 0 \quad \text{vs} \quad H_{1A}: \text{某些} \alpha_i \neq 0,$$

$$H_{0B}: \beta_1 = \cdots = \beta_b = 0 \quad \text{vs} \quad H_{1B}: \text{某些} \beta_j \neq 0.$$

检验 H_{0B} 的 F 统计量:

$$F_B = \frac{a \sum_{j=1}^b (\bar{X}_{.j} - \bar{X}_{..})^2 / (b-1)}{\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..})^2 / [(a-1)(b-1)]}.$$

在 H_{0B} 下, $F_B \sim F(b-1, (a-1)(b-1))$ 。

类似地, 检验 H_{0A} 的 F 统计量 $F_A \sim F(a-1, (a-1)(b-1))$ 。

5.3. 9.5.1 Interaction between Factors. 交互效应发生在: 一个因素的影响程度取决于另一个因素的水平时。

在模型中引入交互参数 γ_{ij} :

$$\mu_{ij} = \mu + \alpha_i + \beta_j + \gamma_{ij},$$

其中 $\sum_i \gamma_{ij} = \sum_j \gamma_{ij} = 0$ 。

若所有 $\gamma_{ij} = 0$, 则回到可加模型; 若存在非零 γ_{ij} , 则两个因素之间存在交互作用。

图形诊断: 在双因素实验中, 绘制各行 (因素 A 各水平) 的均值轮廓线。若线条大致平行, 则交互作用不明显; 若线条明显交叉或分离, 则表明存在交互效应。

EXAMPLE 9.4 (沥青混合料热导率). Devore (2012, 第 435 页) 研究了两个因素对沥青混合料热导率的影响: 粘结剂等级 (PG58, PG64, PG70) 和粗骨料含量 (38%, 41%, 44%)。每个处理组合有 2 次重复。

R 分析结果: 交互效应不显著 ($p = 0.4135$), 但两个主效应都非常显著 ($p = 0.0017$ 和 $p < 10^{-5}$)。因此接受可加模型, 两个因素独立地影响热导率。

6. 9.6 A Regression Problem

6.1. 为什么研究回归? ANOVA 研究的是类别型 (categorical) 自变量对因变量的影响。但在许多实际问题中, 自变量是连续型的。例如:

- 学生的学习时间 (连续) $\rightarrow$ 考试成绩
- 汽车的发动机排量 (连续) $\rightarrow$ 每加仑行驶里程
- 农作物的施肥量 (连续) $\rightarrow$ 作物产量

这就引出了**回归分析 (regression analysis)**——研究自变量 (通常记作 x) 与因变量 Y 之间关系的方法。

线性模型: 假设 $\mathbb{E}(Y) = \mu(x)$ 是 x 的线性函数——

$$Y_i = \alpha + \beta(x_i - \bar{x}) + e_i, \quad i = 1, \dots, n,$$

其中 $e_i \sim N(0, \sigma^2)$ iid。

为什么假设 x 是已知的非随机变量? 这是为了简化分析——我们把不确定性全部放在 Y 上。在实际中, 如果 x 也是随机的, 则需要联合分布建模; 但在受控实验或观测研究中, 将 x 视为固定设计点是合理的近似。

线性模型 vs 非线性模型: 这里“线性”指的是对参数 (α, β) 线性, 而非对 x 线性。因此 $\alpha + \beta x + \gamma x^2$ 仍是线性模型, 而 $\alpha e^{\beta x}$ 不是。

6.2. 9.6.1 Maximum Likelihood Estimates. 对模型 (6.1), 似然函数为

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{[Y_i - \alpha - \beta(x_i - \bar{x})]^2}{2\sigma^2} \right\}.$$

最大化似然等价于最小化

$$H(\alpha, \beta) = \sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2.$$

这正是**最小二乘法 (least squares)**——选择使残差平方和最小的 α, β 。

几何直观: $|Y_i - \alpha - \beta(x_i - \bar{x})|$ 是点 (x_i, Y_i) 到直线 $y = \alpha + \beta(x - \bar{x})$ 的垂直距离。最小二乘法就是找到使所有这些距离平方和最小的直线。

MLE 的解:

$$\begin{aligned} \hat{\alpha} &= \bar{Y}, \\ \hat{\beta} &= \frac{\sum_{i=1}^n (Y_i - \bar{Y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n Y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}. \end{aligned}$$

$\hat{\sigma}^2$ 的 MLE:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

拟合值与残差:

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}(x_i - \bar{x}), \quad \hat{e}_i = Y_i - \hat{Y}_i.$$

估计量的分布: 可以证明

$$\begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix} \sim N_2 \left(\begin{pmatrix} \alpha \\ \beta \end{pmatrix}, \sigma^2 \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \end{pmatrix} \right).$$

EXAMPLE 9.5 (男子 1500 米奥运会成绩). 考虑 27 届奥运会男子 1500 米冠军成绩与年份的关系。年份为自变量 x , 时间为因变量 Y 。

R 拟合结果: $\hat{y} = 12.33 - 0.0044 \times \text{year}$. 斜率的 95% 置信区间为 $(-0.00547, -0.00328)$ ——这意味着每年获胜时间平均减少约 0.004 分钟 (约 0.24 秒)。对 2020 年奥运会的预测时间约为 3.486 分钟。

残差图诊断: 在回归分析中, 绘制残差 $\hat{e}_i$ vs 拟合值 $\hat{Y}_i$ 的散点图。如果图呈现随机散布, 说明模型是合理的; 如果出现系统模式 (如 U 形、漏斗形), 则提示模型设定有问题 (如遗漏非线性项、异方差等)。

6.3. 9.6.2 *Geometry of the Least Squares Fit. 最小二乘拟合有一个优美的几何解释。

将数据写成向量形式 $\mathbf{Y} = (Y_1, \dots, Y_n)'$, 设计矩阵 $\mathbf{X}$ 的列为 $\mathbf{1}$ 和 $\mathbf{x}_c = (x_1 - \bar{x}, \dots, x_n - \bar{x})'$ 。模型为

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}).$$

设 V 为 $\mathbf{X}$ 列张成的 $\mathbb{R}^n$ 中的二维子空间 (拟合空间)。最小二乘估计 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 正是 $\mathbf{Y}$ 在子空间 V 上的**正交投影**——即使得 $\|\mathbf{Y} - \boldsymbol{\theta}\|^2$ 最小的 V 中元素。

几何分解:

$$\|\mathbf{Y}\|^2 = \|\hat{\boldsymbol{\theta}}\|^2 + \|\hat{\mathbf{e}}\|^2,$$

其中 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 是残差向量, 且 $\hat{\boldsymbol{\theta}} \perp \hat{\mathbf{e}}$ (残差与拟合空间正交)。这正是 ANOVA 中平方和分解的几何版本。

7. 9.7 A Test of Independence

在许多应用中, 我们需要检验两个连续变量 X 和 Y 是否独立。对于二元正态分布, X 和 Y 独立当且仅当它们的相关系数 $\rho = 0$ 。因此我们检验:

$$H_0: \rho = 0 \quad \text{vs} \quad H_1: \rho \neq 0.$$

样本相关系数:

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2}}.$$

关键定理: 在 H_0 下 (即 $\rho = 0$ 时), R 的分布不依赖于 X 的具体分布——只要 X 与 Y 独立, R 的分布在正态情况下就有上式 (9.2) 给出的精确形式。特别是,

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}} \sim t(n-2).$$

因此, H_0 的拒绝域为 $|T| \geq t_{\alpha/2, n-2}$, 或等价地 $|R| \geq c$ 。

Remark 的深层含义: R 的条件分布 (在给定的 $X_1, \dots, X_n$ 下) 不依赖于 X_i 的具体值, 这意味着 R 与所有仅依赖于 X 的统计量独立。这是一个非常优雅的性质——样本相关系数在 $\rho = 0$ 时”不受” X 取值的影响。

8. 9.8 Distributions of Certain Quadratic Forms

前几节的分析依赖于一个共同的理论支柱: 某些二次型服从 χ^2 分布, 且它们相互独立。本节和下一节建立这一理论的严格基础。

设 $\mathbf{X}' = (X_1, \dots, X_n)$, 其中 $X_i \sim N(\mu_i, \sigma^2)$ iid. 二次型 $Q = \sigma^{-2} \mathbf{X}' \mathbf{A} \mathbf{X}$ 的 mgf 为:

$$M_Q(t) = \frac{1}{(1-2t)^{n/2}} \exp \left\{ \frac{t \sum_{i=1}^n \mu_i^2}{\sigma^2(1-2t)} \right\}.$$

特别地, 若 $\mathbf{A}$ 是对称幂等矩阵 ($\mathbf{A}^2 = \mathbf{A}$), 则 $Q \sim \chi^2(r, \theta)$, 其中 $r = \text{tr}(\mathbf{A}) = \text{rank}(\mathbf{A})$, $\theta = \boldsymbol{\mu}' \mathbf{A} \boldsymbol{\mu} / \sigma^2$ 。若进一步 $\boldsymbol{\mu} = \mu \mathbf{1}$ 且 $\sum_{i,j} a_{ij} = 0$, 则 $\theta = 0$, Q 为中心 $\chi^2(r)$ 。

Cochran 定理的特例: 若 $Q_1, \dots, Q_k$ 是相互独立的 χ^2 变量之和, 且 $\sum \text{rank}(Q_i) = n$, 则各 Q_i 独立。

9. 9.9 The Independence of Certain Quadratic Forms

最后一个理论工具: Craig 定理, 给出了两个二次型独立的充要条件。

这个定理在 ANOVA 中有重要应用: 在 one-way ANOVA 中, 组间平方和 Q_4 (对应某个幂等矩阵) 与组内平方和 Q_3 (对应另一个幂等矩阵) 满足 $\mathbf{AB} = \mathbf{0}$, 因此独立——这正是 F 检验的理论基础。

推论: 在回归模型中, 拟合值的二次型与残差的二次型相互独立, 反映了“被解释的变异”与“未被解释的变异”之间的正交性。

习题

EXERCISE 9.1. 9.1 T^2 与 F 统计量的关系—Hogg 9.2.1 考虑在例 8.3.1 中通过似然比检验推导出的 T 统计量, 用于检验两个具有公共方差的正态分布均值的相等性。证明 T^2 恰好是表达式 (9.2.11) 中的 F 统计量。

EXERCISE 9.2. 9.2 线性函数的不相关性—Hogg 9.2.2 在模型 (9.2.1) 下, 证明线性函数 $X_{ij} - \bar{X}_{.j}$ 与 $\bar{X}_{.j} - \bar{X}_{..}$ 不相关。

提示: 回忆 $\bar{X}_{.j}$ 和 $\bar{X}_{..}$ 的定义, 不失一般性地设 $E(X_{ij}) = 0$ 对所有 i, j 。

EXERCISE 9.3. 9.3 One-Way ANOVA 数据计算—Hogg 9.2.3 考虑来自三个正态分布的独立随机样本, 它们具有相等方差及 respective means μ_1, μ_2, μ_3 。数据如下:

I	II	III
0.5	2.1	3.0
1.3	3.3	5.1
-1.0	0.0	1.9
1.8	2.3	2.4
	2.5	4.2
		4.1

使用 R 或其他统计软件, 计算用于检验 $H_0: \mu_1 = \mu_2 = \mu_3$ 的 F 统计量。

EXERCISE 9.4. 9.4 样本方差的分解—Hogg 9.2.4 设 $X_1, X_2, \dots, X_n$ 是来自正态分布 $N(\mu, \sigma^2)$ 的随机样本。证明

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=2}^n (X_i - \bar{X}')^2 + \frac{n-1}{n} (X_1 - \bar{X}')^2,$$

其中 $\bar{X} = \sum_{i=1}^n X_i/n$ 且 $\bar{X}' = \sum_{i=2}^n X_i/(n-1)$ 。

提示: 将 $X_i - \bar{X}$ 替换为 $(X_i - \bar{X}') - (X_1 - \bar{X}')/n$ 。证明 $\sum_{i=2}^n (X_i - \bar{X}')^2/\sigma^2$ 服从自由度为 $n-2$ 的卡方分布。证明右边两项独立。下列统计量的分布是什么?

$$\frac{[(n-1)/n](X_1 - \bar{X}')^2}{\sigma^2}?$$

EXERCISE 9.5. 9.5 MLE 与平方和分解—Hogg 9.2.5 使用本节的记号, 假设均值满足条件 $\mu = \mu_1 + (b-1)d = \mu_2 - d = \mu_3 - d = \dots = \mu_b - d$ 。即最后 $b-1$ 个均值相等但

与第一个均值 μ_1 不同 (假设 $d \neq 0$)。从 b 个具有公共未知方差 σ^2 的正态分布中分别抽取容量为 a 的独立随机样本。

(a) 证明 μ 和 d 的最大似然估计量分别是 $\hat{\mu} = \bar{X}_{..}$ 和

$$\hat{d} = \frac{\sum_{j=2}^b \bar{X}_{.j}/(b-1) - \bar{X}_{.1}}{b}.$$

(b) 使用练习 9.2.4, 求 Q_6 和 $Q_7 = c\hat{d}^2$, 使得当 $d = 0$ 时, $Q_7/\sigma^2 \sim \chi^2(1)$, 且

$$\sum_{i=1}^a \sum_{j=1}^b (X_{ij} - \bar{X}_{..})^2 = Q_3 + Q_6 + Q_7.$$

(c) 论证当 $d = 0$ 时, 右边的三项除以 σ^2 后是相互独立的卡方分布随机变量。

(d) $Q_7/(Q_3 + Q_6)$ 乘以什么常数在 $d = 0$ 时服从 F 分布? 注意, 这个 F 实际上就是用于检验第一个分布的均值与后 $b - 1$ 个分布合并后的公共均值相等的双样本 T 的平方。

EXERCISE 9.6. **9.6 LDL 胆固醇水平 ANOVA 分析**—Hogg 9.2.6 一项研究比较了四种药物对 LDL (低密度脂蛋白) 胆固醇水平的影响。数据记录在文件 `quailldl.rda` 中。

(a) 绘制 LDL 水平的比较箱线图。哪种药物似乎导致更低的 LDL 水平? 识别数据中的异常值 (按观测号)。

(b) 计算所有四种药物的 LDL 均值相等的 F 检验。报告 F 检验统计量和 p 值。使用显著性水平 0.05 就问题给出结论。使用例 9.2.1 中的 R 代码。

(c) (b) 中的结论与 (a) 中的箱线图一致吗?

(d) 注意, F 检验的一个假设是模型 (9.2.1) 中的随机误差 e_{ij} 服从正态分布。 e_{ij} 的估计量是 $x_{ij} - \bar{x}_{.j}$, 这些称为残差, 即全模型拟合后剩余的部分。计算这些残差, 然后获取它们的直方图、箱线图和正态 $Q-Q$ 图。评价正态性假设。

EXERCISE 9.7. **9.7 One-Way ANOVA 假设检验**—Hogg 9.2.7 设 μ_1, μ_2, μ_3 分别为三个正态分布的均值, 它们具有公共未知方差 σ^2 。为在显著性水平 $\alpha = 0.05$ 下检验假设 $H_0: \mu_1 = \mu_2 = \mu_3$ 对所有可能备择假设, 从每个分布中抽取容量为 4 的独立随机样本。若观测值分别为:

$$X_1: \quad 5 \quad 9 \quad 6 \quad 8$$

$$X_2: \quad 11 \quad 13 \quad 10 \quad 12$$

$$X_3: \quad 10 \quad 6 \quad 9 \quad 9$$

判断是否拒绝 H_0 。

EXERCISE 9.8. 9.8 柴油燃料品牌 mpg 比较-Hogg 9.2.8 一位柴油汽车司机根据 mpg 测试三种柴油燃料的质量。使用以下数据检验三个均值相等的原假设。做通常的假设并取 $\alpha = 0.05$ 。

Brand A: 38.7 39.2 40.1 38.9

Brand B: 41.9 42.3 41.3

Brand C: 40.8 41.2 39.5 38.9 40.3

EXERCISE 9.9. 9.9 非中心 χ^2 分布的可加性-Hogg 9.3.1 设 $Y_i, i = 1, 2, \dots, n$, 是相互独立的随机变量, 分别服从 $\chi^2(r_i, \theta_i), i = 1, 2, \dots, n$ 。证明 $Z = \sum_{i=1}^n Y_i$ 服从 $\chi^2(\sum_{i=1}^n r_i, \sum_{i=1}^n \theta_i)$ 。

EXERCISE 9.10. 9.10 非中心 χ^2 分布的方差-Hogg 9.3.2 计算服从非中心 $\chi^2(r, \theta)$ 分布的随机变量的方差。

EXERCISE 9.11. 9.11 非中心性参数的计算与检验功效-Hogg 9.3.3 考虑 one-way ANOVA 问题, 其中各组样本容量相等 ($n_j = m, j = 1, \dots, b$), 且各组均值满足模式: $\mu_1 = \mu + 2d, \mu_2 = \mu_3 = \dots = \mu_b = \mu - d$ 。

(a) 确定上述均值模式下的非中心性参数。¹

(b) 使用 R 函数 `pf` 确定 F 检验在 $m = 5$ 和 $m = 10$ 时检测该均值模式的功效。²

(c) 确定检测功效至少为 0.80 的最小 m 值。³

(d) 如果 $\sigma^2 = 40$, 回答 (a)-(c)。

EXERCISE 9.12. 9.12 非中心 T 与非中心 F 的关系-Hogg 9.3.4 证明非中心 T 随机变量的平方是非中心 F 随机变量。

EXERCISE 9.13. 9.13 非中心 χ^2 分布的差-Hogg 9.3.5 设 X_1 和 X_2 是两个独立的随机变量。设 $X_1 \sim \chi^2(r_1, \theta_1), Y = X_1 + X_2 \sim \chi^2(r, \theta)$, 其中 $r_1 < r$ 且 $\theta_1 \leq \theta$ 。证明 $X_2 \sim \chi^2(r - r_1, \theta - \theta_1)$ 。

EXERCISE 9.14. 9.14 Bonferroni 多重比较程序-Hogg 9.4.1 对于练习 9.2.8 中讨论的研究, 使用 $\alpha = 0.10$ 获取 Bonferroni 多重比较程序的结果。基于此程序, 哪个品牌的燃料 (如果有的话) 显著最好?

EXERCISE 9.15. 9.15 Tukey-Kramer 程序-Hogg 9.4.2 对于练习 9.2.6 中讨论的研究, 计算 Tukey-Kramer 程序。是否存在显著差异?

EXERCISE 9.16. 9.16 Bonferroni 与 Fisher 多重比较方法-Hogg 9.4.3 假设 X 和 Y 是离散随机变量, 它们具有共同的范围 $\{1, 2, \dots, k\}$ 。设 p_{1j} 和 p_{2j} 分别是 $P(X = j)$ 和 $P(Y = j)$ 的相应概率。

(a) 确定执行所有这些比较的 Bonferroni 方法。

(b) 确定执行所有这些比较的 Fisher 方法。

¹答案: $\theta = 5md/3$, 当 $\sigma^2 = 1$ 。

²答案: 对于 $m = 5$: 功效 = 0.6174; 对于 $m = 10$: 功效 = 0.9421。

³答案: $m = 7$ 。

EXERCISE 9.17. 9.17 列联表的多重比较-Hogg 9.4.4 假设练习 9.4.3 中的样本产生了以下列联表:

	1	2	3	4	5	6	7	8	9	10
x	20	31	56	18	45	55	47	78	56	81
y	36	41	65	15	38	78	18	72	59	85

为计算 (用 R) 下面的置信区间, 使用命令 `prop.test` (见例 4.2.5)。

(a) 基于所有 10 个比较的 Bonferroni 程序, 计算 $p_{16} - p_{26}$ 的置信区间。

(b) 基于所有 10 个比较的 Fisher 程序, 计算 $p_{16} - p_{26}$ 的置信区间。

EXERCISE 9.18. 9.18 Fisher 程序的 R 函数-Hogg 9.4.5 编写一个 R 函数, 计算练习 9.4.3 中的 Fisher 程序。用练习 9.4.4 的数据验证它。

EXERCISE 9.19. 9.19 同时检验的 Bonferroni 程序推广-Hogg 9.4.6 将 Bonferroni 程序推广到同时检验。即, 假设我们有 m 个感兴趣的假设: H_{0i} 对 H_{1i} , $i = 1, \dots, m$ 。对于检验 H_{0i} 对 H_{1i} , 设 $C_{i,\alpha}$ 是大小为 α 的临界域, 并假设如果样本 $\mathbf{X}_i \in C_{i,\alpha}$, 则拒绝 H_{0i} 。确定一个规则, 使我们能够同时检验这 m 个假设, 且第一类错误率不超过 α 。

EXERCISE 9.20. 9.20 两因素可加模型平方和分解-Hogg 9.5.1 考虑一个双因素实验, 其中因素 A 有 2 个水平, 因素 B 有 3 个水平。设 $\mu = 5$, $\alpha_1 = 1$, $\alpha_2 = -1$, $\beta_1 = 1$, $\beta_2 = 0$, $\beta_3 = -1$ 。回答以下问题:

(a) 写出单元格均值 μ_{ij} 的表格。

(b) 绘制均值轮廓图 (mean profile plot)。

(c) 若交互效应存在, 轮廓图会有什么特征?

EXERCISE 9.21. 9.21 MLE 的分布-Hogg 9.5.2 考虑表达式 (9.5.14) 之前的讨论。证明随机变量 $\sqrt{a}\bar{X}_{.1}, \dots, \sqrt{a}\bar{X}_{.b}$ 是相互独立的, 且服从公共的 $N(\sqrt{a}\bar{\mu}, \sigma^2)$ 分布。

EXERCISE 9.22. 9.22 交互效应的非中心性参数-Hogg 9.5.3 对于双因素交互模型 (9.5.15), 证明检验统计量 F_{AB} 的非中心性参数等于 $c \sum_{j=1}^b \sum_{i=1}^a \gamma_{ij}^2 / \sigma^2$ 。

EXERCISE 9.23. 9.23 单观测值单元的 MLE 分布-Hogg 9.5.4 使用双因素分类 (每单元一观测值) 的背景, 确定 α_i 、 β_j 和 μ 的最大似然估计量的分布。

EXERCISE 9.24. 9.24 线性函数的不相关性-Hogg 9.5.5 证明在线性函数 $X_{ij} - \bar{X}_{i.} - \bar{X}_{.j} + \bar{X}_{..}$ 与 $\bar{X}_{.j} - \bar{X}_{..}$ 在本节的假设下是不相关的。

EXERCISE 9.25. 9.25 双因素分类的 F 检验计算-Hogg 9.5.6 给定以下与双因素分类相关的观测值, 其中 $a = 3$, $b = 4$, 使用 R 或其他统计软件计算用于检验列均值相等 ($\beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$) 和行均值相等 ($\alpha_1 = \alpha_2 = \alpha_3 = 0$) 的 F 统计量。

行/列	1	2	3	4
1	3.1	4.2	2.7	4.9
2	2.7	2.9	1.8	3.0
3	4.0	4.6	3.0	3.9

EXERCISE 9.26. 9.26 多观测值单元的 MLE 分布-Hogg 9.5.7 在每单元有 $c > 1$ 个观测值的双因素分类背景下, 确定 α_i 、 β_j 和 γ_{ij} 的最大似然估计量的分布。

EXERCISE 9.27. 9.27 含交互效应的双因素分类 F 检验-Hogg 9.5.8 给定以下在双因素分类中的观测值, 其中 $a = 3$, $b = 4$, $c = 2$, 计算用于检验所有交互效应为零 ($\gamma_{ij} = 0$)、所有列均值相等 ($\beta_j = 0$) 和所有行均值相等 ($\alpha_i = 0$) 的 F 统计量。数据形式为 x_{ijk} , i, j 在数据集 *sec951.rda* 中。

行/列	1	2	3	4
1	3.1	4.2	2.7	4.9
	2.9	4.9	3.2	4.5
2	2.7	2.9	1.8	3.0
	2.9	2.3	2.4	3.7
3	4.0	4.6	3.0	3.9
	4.4	5.0	2.5	4.2

EXERCISE 9.28. 9.28 可加模型的均值轮廓图-Hogg 9.5.9 对于可加模型 (9.5.1), 证明均值轮廓图是平行的。样本均值轮廓图通过绘制 $\bar{X}_{ij}$ 对 j (对每个 i) 得到。这些提供了检测交互效应的图形诊断。为上一道练习获取这些图。

EXERCISE 9.29. 9.29 随机区组设计的双因素 ANOVA -Hogg 9.5.10 考虑一个随机区组设计, 其中处理 (A) 有 3 个水平, 区组 (B) 有 5 个水平。数据如下:

处理	区组				
	B1	B2	B3	B4	B5
A1	52	47	44	51	42
A2	60	55	49	52	43
A3	56	48	45	44	38

- (a) 使用 5% 的显著性水平, 检验 $H_A: \alpha_1 = \alpha_2 = \alpha_3 = 0$ 对所有备择假设。
 (b) 使用 5% 的显著性水平, 检验 $H_B: \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = 0$ 对所有备择假设。

EXERCISE 9.30. 9.30 双因素模型参数分解-Hogg 9.5.11 设 $a = 3$ 、 $b = 4$, 如果 μ_{ij} ($i = 1, 2, 3$ 和 $j = 1, 2, 3, 4$) 由下表给出, 求 μ 、 α_i 、 β_j 和 γ_{ij} :

6	7	7	12
10	3	11	8
8	5	9	10

EXERCISE 9.31. 9.31 回归系数 α^* 的最小二乘估计-Hogg 9.6.1 通过最小化表达式 (9.6.11) 给出的平方和, 得到模型 $y_i = \alpha^* + \beta x_i + e_i$ 的最小二乘估计。确定 $\hat{\alpha}^*$ 的分布。

EXERCISE 9.32. 9.32 ACT 与微积分成绩的回归分析-Hogg 9.6.2 学生在 ACT 数学考试中的成绩 x 和第一学期微积分期末考试 (满分 200 分) 的成绩 y 如下:

x	25	20	26	26	28	28	29	32	20	25
y	138	84	104	112	88	132	90	183	100	143
x	26	28	25	31	30					
y	141	161	124	118	168					

数据也在 *rda* 文件 *regr1.rda* 中。使用 *R* 或其他统计软件进行计算和绘图。

- 计算这些数据的最小二乘回归线。
- 在同一图上绘制散点和最小二乘回归线。
- 获取残差图并评价模型的适用性。
- 求 β 的 95% 置信区间。就问题给出评论。

EXERCISE 9.33. 9.33 电话数据回归分析-Hogg 9.6.3 考虑以下数据。该数据集的响应变量 y 是 1950 年至 1973 年比利时电话通话次数 (单位: 千万次)。时间 (年份) 作为预测变量 x 。数据在文件 *telephone.rda* 中。

- 计算这些数据的最小二乘回归线。
- 在同一图上绘制散点和最小二乘回归线。
- 最小二乘拟合效果差的原因是什么?

EXERCISE 9.34. 9.34 回归估计量的协方差-Hogg 9.6.4 证明 $\hat{\alpha}$ 与 $\hat{\beta}$ 之间的协方差为零。

提示: 利用 (6.2) 中 $\hat{\beta}$ 的表达式, 以及 $\sum_{i=1}^n (x_i - \bar{x}) = 0$ 的性质。

EXERCISE 9.35. 9.35 回归参数的置信区间-Hogg 9.6.5 在模型 (6.1) 下, 求参数 α 和 β 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.36. 9.36 均值估计量的分布与置信区间-Hogg 9.6.6 考虑模型 (9.6.1)。设 $\eta_0 = E(Y|x = x_0 - \bar{x})$ 。 η_0 的最小二乘估计量是 $\hat{\eta}_0 = \hat{\alpha} + \hat{\beta}(x_0 - \bar{x})$ 。

- 使用 (9.6.9), 证明 $\hat{\eta}_0$ 是无偏估计量, 并证明其方差为

$$V(\hat{\eta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

- 获取 $\hat{\eta}_0$ 的分布, 并用它来确定 η_0 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.37. 9.37 预测区间-Hogg 9.6.7 假设样本 $(x_1, Y_1), \dots, (x_n, Y_n)$ 服从线性模型 (9.6.1)。设 Y_0 是在 $x = x_0 - \bar{x}$ 处的一个未来观测值, 我们想为其确定一个预测区间。假设模型 (9.6.1) 对 Y_0 成立; 即 $Y_0 \sim N(\alpha + \beta(x_0 - \bar{x}), \sigma^2)$ 。我们使用练习 9.6.6 中的 $\hat{\eta}_0$ 作为对 Y_0 的预测。

- 获取 $Y_0 - \hat{\eta}_0$ 的分布, 证明其方差为:

$$V(Y_0 - \hat{\eta}_0) = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

- 获取以 $Y_0 - \hat{\eta}_0$ 为分子的 t 统计量。

(c) 现在从 $1 - \alpha = P[-t_{\alpha/2, n-2} < T < t_{\alpha/2, n-2}]$ 开始, 其中 $0 < \alpha < 1$, 确定 Y_0 的 $(1 - \alpha)100\%$ 预测区间。

(d) 将此预测区间与练习 9.6.6 获得的置信区间进行比较。为什么预测区间更大? 从直觉上解释。

EXERCISE 9.38. 9.38 奥运会 1500 米成绩的预测区间—Hogg 9.6.8 在例 9.6.1 中, 我们得到了 2020 年奥运会男子 1500 米冠军成绩的预测。计算上一道练习中给出的该预测的 95% 预测区间。这些计算由 R 函数 `cipi.R` 执行。调用方式是 `cipi(lm(time~year), matrix(c(1,2020), ncol=2))`。就问题而言, 这个预测区间意味着什么? 接下来计算 2024 年和 2028 年奥运会的预测。为什么区间长度在增加?

EXERCISE 9.39. 9.39 回归平方和分解—Hogg 9.6.9 证明以下等式成立:

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

提示: 这本质上是将总平方和分解为拟合平方和与残差平方和。

EXERCISE 9.40. 9.40 简单最小二乘拟合—Hogg 9.6.14 使用最小二乘法拟合 $y = a + x$ 到以下数据:

$$\begin{array}{r} x \quad 0 \quad 1 \\ 2 \\ \hline y \quad 1 \quad 3 \\ 4 \end{array}$$

EXERCISE 9.41. 9.41 异方差回归模型的 MLE —Hogg 9.6.10 设独立随机变量 $Y_1, Y_2, \dots, Y_n$ 分别具有概率密度函数 $N(\beta x_i, \gamma^2 x_i^2), i = 1, 2, \dots, n$, 其中给定的数 $x_1, x_2, \dots, x_n$ 不全相等且均不为零。求 β 和 γ^2 的最大似然估计量。

EXERCISE 9.42. 9.42 似然比检验与回归—Hogg 9.6.11 设独立随机变量 $Y_1, \dots, Y_n$ 具有联合 pdf

$$L(\alpha, \beta, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - \alpha - \beta(x_i - \bar{x})]^2 \right\},$$

其中给定的数 $x_1, x_2, \dots, x_n$ 不全相等。设原假设 $H_0: \beta = 0$ (α 和 σ^2 未指定)。希望使用似然比检验来检验 H_0 对所有备择假设。求 Λ , 并看看检验是否能基于一个熟悉的统计量。

提示: 在本节的记号下, 证明

$$\sum_{i=1}^n (Y_i - \hat{\alpha})^2 = Q_3 + \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2.$$

EXERCISE 9.43. 9.43 线性趋势 ANOVA —Hogg 9.6.12 使用第 9.2 节的记号, 假设均值满足 j 的线性函数: $\mu_j = c + d[j - (b+1)/2]$ 。从 b 个均值分别为 $\mu_1, \mu_2, \dots, \mu_b$ 、公共未知方差为 σ^2 的正态分布中分别抽取容量为 a 的独立随机样本。

(a) 证明 c 和 d 的最大似然估计量分别为 $\hat{c} = \bar{X}_{..}$ 和

$$\hat{d} = \frac{\sum_{j=1}^b [j - (b-1)/2](\bar{X}_{.j} - \bar{X}_{..})}{\sum_{j=1}^b [j - (b+1)/2]^2}.$$

(b) 类似于练习 9.2.5, 求平方和分解。

(c) 论证当 $d = 0$ 时, (b) 中右边的两项除以 σ^2 后是自由度分别为 1 和 $ab - 2$ 的独立卡方分布随机变量。

(d) 什么 F 统计量用于检验均值的相等性, 即 $H_0: d = 0$?

EXERCISE 9.44. 9.44 最小二乘估计的几何-Hogg 9.6.13 考虑第 9.6.2 节的讨论。

(a) 证明 $\hat{\boldsymbol{\theta}} = \hat{\alpha}\mathbf{1} + \hat{\beta}\mathbf{x}_c$, 其中 $\hat{\alpha}$ 和 $\hat{\beta}$ 是本节导出的最小二乘估计量。

(b) 证明残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$; 即它的第 i 个元素是 $\hat{e}_i$, (9.6.7)。

(c) 如图 9.6.3 所示, 证明向量 $\hat{\boldsymbol{\theta}}$ 和 $\hat{\mathbf{e}}$ 之间的夹角是直角。

(d) 证明残差之和为零; 即 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 。

EXERCISE 9.45. 9.45 平面拟合-Hogg 9.6.15 用最小二乘法拟合平面 $z = a + bx + cy$ 到五个点 $(x, y, z): (-1, -2, 5), (0, -2, 4), (0, 0, 4), (1, 0, 2), (2, 1, 0)$ 。

令 R 向量 $\mathbf{x}$ 、 $\mathbf{y}$ 、 $\mathbf{z}$ 包含 x 、 y 和 z 的值。则 LS 拟合通过 $\text{lm}(\mathbf{z} \sim \mathbf{x} + \mathbf{y})$ 计算。

EXERCISE 9.46. 9.46 多元正态回归估计-Hogg 9.6.16 设 4×1 矩阵 $\mathbf{Y}$ 服从多元正态分布 $N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$, 其中 4×3 矩阵 $\mathbf{X}$ 等于

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 2 \\ 1 & -1 & 2 \\ 1 & 0 & -3 \\ 1 & 0 & -1 \end{pmatrix}.$$

(a) 求 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 的均值矩阵和协方差矩阵。

(b) 如果我们观测到 $\mathbf{Y}' = (6, 1, 11, 3)$, 计算 $\hat{\boldsymbol{\beta}}$ 。

EXERCISE 9.47. 9.47 多元正态回归的 pdf-Hogg 9.6.17 设 $\mathbf{Y}$ 是 $n \times 1$ 随机向量, $\mathbf{X}$ 是 $n \times p$ 已知常数矩阵 (秩为 p), $\boldsymbol{\beta}$ 是 $p \times 1$ 回归系数向量。设 $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$ 。求 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 的 pdf。

EXERCISE 9.48. 9.48 异方差检验-Hogg 9.6.18 设独立正态随机变量 $Y_1, Y_2, \dots, Y_n$ 分别具有概率密度函数 $N(\mu, \gamma^2 x_i^2)$, $i = 1, 2, \dots, n$, 其中给定的 $x_1, x_2, \dots, x_n$ 不全相等且均不为零。讨论在未指定 μ 的情况下, 检验原假设 $H_0: \gamma = 1$ 对所有备择假设 $H_1: \gamma \neq 1$ 。

EXERCISE 9.49. 9.49 相关系数表达式的化简-Hogg 9.7.1 证明

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{(\sum_{i=1}^n X_i^2 - n\bar{X}^2)(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2)}}.$$

EXERCISE 9.50. 9.50 相关系数的假设检验-Hogg 9.7.2 从二元正态分布中抽取容量为 $n = 6$ 的随机样本, 得到相关系数为 0.89。在 5% 的显著性水平下, 我们是接受还是拒绝 $\rho = 0$ 的假设?

EXERCISE 9.51. 9.51 验证相关系数的 t 分布-Hogg 9.7.3 验证本节的等式 (9.7.3)。

EXERCISE 9.52. 9.52 验证相关系数的分布-Hogg 9.7.4 验证本节的 (9.7.4) 中的 pdf。

EXERCISE 9.53. 9.53 相关系数的一致性-Hogg 9.7.5 使用第 4.5 节的结果, 证明 R , (9.7.1), 是 ρ 的一致估计量。

EXERCISE 9.54. 9.54 相关系数的置信区间-Hogg 9.7.6 通过执行以下步骤, 确定 ρ 的 $(1 - \alpha)100\%$ 近似置信区间。

(a) 对于 $0 < \alpha < 1$, 通常从 $1 - \alpha = P(-z_{\alpha/2} < Z < z_{\alpha/2})$ 开始, 其中 Z 由表达式 (9.7.5) 给出。然后在不等式的中间部分孤立 $h(\rho) = (1/2) \log[(1 + \rho)/(1 - \rho)]$ 。求 $h'(\rho)$ 并证明它在 $-1 < \rho < 1$ 上严格为正; 因此 h 是严格递增的, 其逆函数存在。

(b) 证明这个逆函数是双曲正切函数, $\tanh(y) = (e^y - e^{-y})/(e^y + e^{-y})$ 。

(c) 获取 ρ 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.55. 9.55 棒球数据的相关系数分析-Hogg 9.7.7 R 函数 `cor.test(x, y)` 计算 ρ 的估计量和练习 9.7.6 中的置信区间。回忆棒球数据, 它在文件 `bb.rda` 中。

(a) 使用棒球数据, 确定职业棒球运动员身高与体重之间相关系数的估计值和置信区间。

(b) 将投手和击球手分开, 分别获取身高与体重之间相关系数的估计值和置信区间。它们有显著差异吗?

(c) 论证第二部分中相关系数估计值的差异是关于两个独立样本的 $\rho_1 - \rho_2$ 的一个模型。

EXERCISE 9.56. 9.56 组合样本的相关系数-Hogg 9.7.8 两个实验给出以下结果:

n	$\bar{x}$	$\bar{y}$	s_x	s_y	r
100	10	20	5	8	0.70
200	12	22	6	10	0.80

计算组合样本的 r 。

EXERCISE 9.57. 9.57 二次型与卡方分布-Hogg 9.8.1 设 $Q = X_1X_2 - X_3X_4$, 其中 X_1, X_2, X_3, X_4 是来自 $N(0, \sigma^2)$ 分布的容量为 4 的随机样本。证明 Q/σ^2 不服从卡方分布。求 Q/σ^2 的 mgf。

EXERCISE 9.58. 9.58 二次型的非中心卡方分布-Hogg 9.8.2 设 $\mathbf{X}' = [X_1, X_2]$ 服从二元正态分布, 均值矩阵 $\boldsymbol{\mu}' = [\mu_1, \mu_2]$ 和正定协方差矩阵 Σ 。设

$$Q_1 = \frac{X_1^2}{\sigma_1^2(1 - \rho^2)} - 2\rho \frac{X_1X_2}{\sigma_1\sigma_2(1 - \rho^2)} + \frac{X_2^2}{\sigma_2^2(1 - \rho^2)}.$$

证明 $Q_1 \sim \chi^2(r, \theta)$, 并求 r 和 θ 。 Q_1 何时且仅何时服从中心卡方分布?

EXERCISE 9.59. 9.59 非中心卡方分布的计算-Hogg 9.8.3 设 $\mathbf{X}' = [X_1, X_2, X_3]$ 是来自 $N(4, 8)$ 分布的容量为 3 的随机样本, 并设

$$\mathbf{A} = \begin{pmatrix} \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 1 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} \end{pmatrix}.$$

设 $Q = \mathbf{X}'\mathbf{A}\mathbf{X}/\sigma^2$ 。

(a) 使用定理 9.8.1 求 $E(Q)$ 。

(b) 说明为什么断言 $Q \sim \chi^2(2, 6)$ 成立。

EXERCISE 9.60. 9.60 不等方差的样本均值方差-Hogg 9.8.4 假设 $X_1, \dots, X_n$ 是独立随机变量, 有公共均值 μ 但有不等方差 $\sigma_i^2 = \text{var}(X_i)$ 。

(a) 确定 $\bar{X}$ 的方差。

(b) 确定常数 K , 使得 $Q = K \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\bar{X}$ 方差的无偏估计量。(提示: 按例 9.8.3 中的方法进行。)

EXERCISE 9.61. 9.61 相关变量的样本均值方差-Hogg 9.8.5 假设 $X_1, \dots, X_n$ 是相关随机变量, 有公共均值 μ 和方差 σ^2 但相关系数 ρ (所有相关系数相同)。

(a) 确定 $\bar{X}$ 的方差。

(b) 确定常数 K , 使得 $Q = K \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\bar{X}$ 方差的无偏估计量。(提示: 按例 9.8.3 中的方法进行。)

EXERCISE 9.62. 9.62 验证表达式 (9.8.13) -Hogg 9.8.6 补充表达式 (9.8.13) 的细节。

EXERCISE 9.63. 9.63 迹算子的性质-Hogg 9.8.7 证明表达式 (9.8.1) 中定义的迹算子具有以下性质。

(a) 如果 $\mathbf{A}$ 和 $\mathbf{B}$ 是 $n \times n$ 矩阵, a 和 b 是标量, 则

$$\text{tr}(a\mathbf{A} + b\mathbf{B}) = a \text{tr} \mathbf{A} + b \text{tr} \mathbf{B}.$$

(b) 对于任何 $n \times n$ 矩阵 $\mathbf{A}$ 和 $\mathbf{B}$, $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ 。

(c) 如果 $\mathbf{A}$ 是方阵, Γ 是正交矩阵, 利用 (a) 的结果证明 $\text{tr}(\Gamma'\mathbf{A}\Gamma) = \text{tr} \mathbf{A}$ 。

(d) 如果 $\mathbf{A}$ 是实对称幂等矩阵, 利用 (b) 的结果证明 $\mathbf{A}$ 的秩等于 $\text{tr} \mathbf{A}$ 。

EXERCISE 9.64. 9.64 矩阵元素平方和与特征值-Hogg 9.8.8 设 $\mathbf{A} = [a_{ij}]$ 是实对称矩阵。证明 $\sum_i \sum_j a_{ij}^2$ 等于 $\mathbf{A}$ 的特征值的平方和。

提示: 如果 Γ 是正交矩阵, 证明 $\sum_j \sum_i a_{ij}^2 = \text{tr}(\mathbf{A}^2) = \text{tr}(\Gamma'\mathbf{A}^2\Gamma) = \text{tr}[(\Gamma'\mathbf{A}\Gamma)(\Gamma'\mathbf{A}\Gamma)]$ 。

EXERCISE 9.65. 9.65 非中心卡方分布的判定-Hogg 9.8.9 假设 $\mathbf{X} \sim N_n(0, \Sigma)$, 其中 Σ 是正定矩阵。对于对称矩阵 $\mathbf{A}$, 设 $Q = \mathbf{X}'\mathbf{A}\mathbf{X}$ 。证明当且仅当 $\mathbf{A}\Sigma\mathbf{A} = \mathbf{A}$ 时, $Q \sim \chi^2(r)$, 其中 $r = \text{rank}(\mathbf{A})$ 。

提示: 将 Q 写成

$$Q = (\Sigma^{-1/2} \mathbf{X})' \Sigma^{1/2} \mathbf{A} \Sigma^{1/2} (\Sigma^{-1/2} \mathbf{X}),$$

其中 $\Sigma^{1/2} = \Gamma' \Lambda^{1/2} \Gamma$, $\Sigma = \Gamma' \Lambda \Gamma$ 是 Σ 的谱分解。然后使用定理 9.8.4。

EXERCISE 9.66. 9.66 幂等矩阵的特征值-Hogg 9.8.10 假设 $\mathbf{A}$ 是实对称矩阵。如果 $\mathbf{A}$ 的特征值只有 0 和 1, 证明 $\mathbf{A}$ 是幂等的。

EXERCISE 9.67. 9.67 二次型的独立性判定-Hogg 9.9.1 设 X_1, X_2, X_3 是来自正态分布 $N(0, \sigma^2)$ 的随机样本。二次型 $X_1^2 + 3X_1X_2 + X_2^2 + X_1X_3 + X_3^2$ 和 $X_1^2 - 2X_1X_2 + \frac{2}{3}X_2^2 - 2X_1X_3 - X_3^2$ 是独立还是相关?

EXERCISE 9.68. 9.68 平方和与二次型的相关性-Hogg 9.9.2 设 $X_1, X_2, \dots, X_n$ 表示来自 $N(0, \sigma^2)$ 分布的容量为 n 的随机样本。证明 $\sum_{i=1}^n X_i^2$ 与每一个在 $X_1, X_2, \dots, X_n$ 中非恒为零的二次型都是相关的。

EXERCISE 9.69. 9.69 线性函数与二次型的独立性-Hogg 9.9.3 设 X_1, X_2, X_3, X_4 是来自 $N(0, \sigma^2)$ 分布的容量为 4 的随机样本。设 $Y = \sum_{i=1}^4 a_i X_i$, 其中 a_1, a_2, a_3, a_4 是实常数。如果 Y^2 和 $Q = X_1X_2 - X_3X_4$ 独立, 确定 a_1, a_2, a_3, a_4 。

附录：公式推导

One-Way ANOVA 平方和恒等式的证明. 背景：在 one-way ANOVA 中, 总平方和 Q 可以分解为组内平方和 Q_3 与组间平方和 Q_4 之和。这一恒等式是 F 检验的基石。

目标：证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2.$$

推导：记 $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和：

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零, 因为对每个固定的 j ,

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。

□

One-Way ANOVA 检验统计量的分布. 背景: 推导 one-way ANOVA 中 F 统计量在原假设下的分布。

目标: 证明在 H_0 下, $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导:

步骤 1: Q_3 的分布. 对每个固定的 j , 由样本方差性质, $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立, 故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2 \left(\sum_{j=1}^b (n_j - 1) \right) = \chi^2(n-b).$$

步骤 2: Q_4 与 Q_3 的独立性. 注意 $\bar{X}_{.j}$ 与 Q_3 独立 (由正态样本的性质), 且 $\bar{X}_{..}$ 是 $\bar{X}_{.1}, \dots, \bar{X}_{.b}$ 的线性组合, 因此 $\bar{X}_{..}$ 也与 Q_3 独立。故 Q_4 ($\bar{X}_{.j}$ 的函数) 与 Q_3 独立。

步骤 3: Q_4 的分布. 在 H_0 下, $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$, 故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各 $\bar{X}_{.j}$ 通过 $\bar{X}_{..}$ 而不独立。直接计算知 $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

步骤 4: F 分布. 由步骤 1、2、3 及 F 分布定义,

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b).$$

□

非中心 χ^2 分布的均值和方差. 背景: 验证非中心 χ^2 分布的基本性质。

已知: $Y \sim \chi^2(r, \theta)$, mgf 为 $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。

目标: 求 $\mathbb{E}(Y)$ 和 $\text{var}(Y)$ 。

推导:

由 mgf, $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。对 $M(t)$ 求导:

$$M'(t) = \left[r(1-2t)^{-r/2-1} + \frac{r\theta}{(1-2t)^{r/2+1}} \right] \exp \left\{ \frac{t\theta}{1-2t} \right\}.$$

故 $\mathbb{E}(Y) = M'(0) = r + \theta$ 。

对 $M''(t)$ 在 $t=0$ 求值, 可得 $\text{var}(Y) = 2(r + 2\theta)$ 。⁴

最小二乘估计的几何解释. 背景: 回归最小二乘估计的正交投影几何。

目标: 证明 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是 $\mathbf{Y}$ 在 $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$ 上的正交投影。

推导: 由正交投影的定义, $\hat{\boldsymbol{\theta}}$ 满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}_c$ 都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0.$$

由 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 得 $\sum_i \hat{e}_i = 0$ (残差之和为零)。

⁴该推导的详细计算见附录 section 9。

由 $\mathbf{x}'_e \hat{\mathbf{e}} = 0$ 并利用正规方程，可解出 $\hat{\alpha}$ 和 $\hat{\beta}$ 的表达式与 (6.2)、(6.2) 一致。故 $\hat{\boldsymbol{\theta}}$ 确为正交投影。 $\square$

0.1. Gamma 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given):

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal): 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换: 令 $y = \frac{x(1-\beta t)}{\beta}$, 则 $x = \frac{\beta y}{1-\beta t}$, $dx = \frac{\beta}{1-\beta t} dy$ 。

3. 代入积分 (要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$):

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论: 因此, $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$, 定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background): 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$, 方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given):

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1-0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha+1)\beta^2(1-0)^{-\alpha-2} = \alpha(\alpha+1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha+1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.6. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1], X_2 \in [x_2, x_2 + dx_2]\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证：边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$ ，确实是合法的 pdf。

结论：条件 pdf 公式得证。■

0.7. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发：

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望（即关于 X_1 求平均）：

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序：

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$ ：

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论：全期望公式得证。■

0.8. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解：

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance)：

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项：

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此：

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论：条件均值的方差不超过原变量的方差，等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0（即 X_2 可由 X_1 确定性决定）。■

0.9. 独立性判定的推导. 背景 (Background)：我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ （可分离变量）。

目标 (Goal)：证明这一判定条件。

推导步骤 (Derivation Steps)：

($\Rightarrow$) 若 X_1 与 X_2 独立，则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$ ，显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ ：

1. 由边缘密度定义：

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理：

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$ ，得 $c_1 c_2 = 1$ 。

4. 因此：

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论：故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.10. 相关系数范围的推导. 背景 (Background)：我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal)：证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps)：

1. Cauchy-Schwarz 不等式：对任意随机变量 U, V ，

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差，令 $U = X_1 - \mu_1$ ， $V = X_2 - \mu_2$ ：

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方：

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此：

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论：故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ （完美线性关系）。■

0.11. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.12. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.13. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.14. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.15. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.16. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。
2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.17. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。
2. 则 $X = \sum_{j=1}^n I_j$ 。
3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.18. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1)\cdots(n-k+1)}{n^k} \rightarrow 1, \\ \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.19. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数:

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论: Poisson 分布的均值和方差相等, 都等于参数 λ 。■

0.20. 卡方分布与正态分布的关系. 背景 (Background): 卡方分布定义为标准正态平方和。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, 则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps):

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$, 先求 cdf:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式:

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论: 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.21. 卡方分布的可加性证明. 背景 (Background): 卡方分布满足可加性: 独立卡方变量之和仍为卡方分布。

目标 (Goal): 证明若 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立, 则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps):

1. 由卡方分布与 Gamma 分布的关系: $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性 (见定理 3.3.1): 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此:

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf: $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$, 故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论: 卡方分布具有可加性, 自由度可累加。■

0.22. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1 + X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.23. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.24. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.25. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}[e^{(t/\sigma)X}] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.26. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2) 2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

0.27. 正态分布有界性的证明. 背景 (Background): 正态分布的尾部概率可以任意小。

目标 (Goal): 证明对任意 $\epsilon > 0$, 存在 η 使得 $\mathbb{P}[|X| > \eta] < \epsilon$ 。

推导步骤 (Derivation Steps):

1. 设 $X \sim N(\mu, \sigma^2)$, 考虑尾部概率 $\mathbb{P}(|X| > \eta)$ 。

2. 利用 Markov 不等式: 对任意 $t > 0$,

$$\mathbb{P}(|X - \mu| > \eta) = \mathbb{P}((X - \mu)^2 > \eta^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{\eta^2} = \frac{\sigma^2}{\eta^2}.$$

3. 由 Chebyshev 不等式可直接得出: 对于任意 $\epsilon > 0$, 取 $\eta > \sigma/\sqrt{\epsilon}$, 则

$$\mathbb{P}(|X - \mu| > \eta) \leq \frac{\sigma^2}{\eta^2} < \epsilon.$$

4. 进一步, 对于标准正态分布 $Z \sim N(0, 1)$, 尾部概率有更精确的界: 由积分不等式

$$\int_\eta^\infty e^{-t^2/2} dt \leq \frac{1}{\eta} e^{-\eta^2/2}, \quad \eta > 0,$$

可得 $\mathbb{P}(|Z| > \eta) \leq \sqrt{\frac{2}{\pi}} \frac{e^{-\eta^2/2}}{\eta}$ 。

5. 因此, 无论使用 Chebyshev 的粗略界还是正态分布的精确界, 均可证明: 对于任意 $\epsilon > 0$, 存在 η 使得 $\mathbb{P}(|X| > \eta) < \epsilon$ 。这说明正态分布的尾部概率可以任意小。

结论: 正态分布的尾部概率可以任意小, 即 $\lim_{\eta \rightarrow \infty} \mathbb{P}(|X| > \eta) = 0$ 。这体现了正态分布的 ** 有界性 ** (tails vanish)。■

0.28. 卡方分布 Δ 方法的详细推导. 背景 (Background): 将 Δ 方法应用于卡方变量的标准差。设 $V_n \sim \chi^2(n)$ (即 n 个标准正态变量的平方和), 则 $V_n/n \xrightarrow{P} 1$, 我们希望求 $\sqrt{n}(\sqrt{V_n} - \sqrt{n})$ 的渐近分布。

参数定义 (Parameter Definitions):

- $V_n \sim \chi^2(n)$: 自由度为 n 的卡方分布
- $v = n$: 卡方分布的均值
- $g(x) = \sqrt{x}$: 平方根变换函数

已知条件 (Given):

- 由大数定律: $V_n/n \xrightarrow{P} 1$
- 由中心极限定理: $\sqrt{n}(V_n/n - 1) \xrightarrow{D} N(0, 2)$
- Δ 方法 (Theorem 5.2.9, Hogg): 若 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 且 $g(x)$ 在 θ 处可导且 $g'(\theta) \neq 0$, 则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

目标 (Goal): 求 $\sqrt{n}(\sqrt{V_n} - \sqrt{n})$ 的渐近分布。

推导步骤 (Derivation Steps):

1. 令 $X_n = V_n/n$, 则 $X_n \xrightarrow{P} 1 = \theta$ 。
2. 计算 $g'(x) = \frac{d}{dx}\sqrt{x} = \frac{1}{2\sqrt{x}}$, 因此 $g'(\theta) = g'(1) = \frac{1}{2}$ 。
3. 验证 Δ 方法条件: - $X_n = V_n/n$ 依概率收敛到 $\theta = 1$ - $g(x) = \sqrt{x}$ 在 $x = 1$ 处可导 - 由 CLT: $\sqrt{n}(X_n - 1) = \frac{1}{\sqrt{n}}(V_n - n) \xrightarrow{D} N(0, 2)$
4. 应用 Δ 方法:

$$\sqrt{n}(g(V_n/n) - g(1)) = \sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) \xrightarrow{D} N\left(0, 2 \cdot \left(\frac{1}{2}\right)^2\right) = N(0, \frac{1}{2}).$$

5. 注意到

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = n \cdot \sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) = n \cdot \sqrt{n}\left(\frac{\sqrt{V_n}}{\sqrt{n}} - 1\right).$$

实际上更直接的方式是: 直接对 $g(V_n) = \sqrt{V_n}$ 在 $v = n$ 处应用 Δ 方法。

6. 设 $Y_n = V_n$, 则 $\sqrt{n}(Y_n - n) \xrightarrow{D} N(0, 2n)$ 。但更好的做法是利用 $V_n/n \xrightarrow{P} 1$: 由步骤 4 的结果, 乘以 $\sqrt{n}$:

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = \sqrt{n} \cdot \sqrt{n} \cdot \left(\sqrt{\frac{V_n}{n}} - 1\right) = n \cdot \sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right).$$

更直接地: 对 $X_n = V_n/n$ 应用 Δ 方法得

$$\sqrt{n}\left(\sqrt{\frac{V_n}{n}} - 1\right) \xrightarrow{D} N\left(0, \frac{1}{2}\right).$$

两边乘以 $\sqrt{n}$:

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) = \sqrt{n} \cdot \sqrt{n} \left(\sqrt{\frac{V_n}{n}} - 1 \right) \xrightarrow{D} \sqrt{n} \cdot N\left(0, \frac{1}{2}\right).$$

但这不是正确的缩放。正确的做法是直接对 $\sqrt{V_n}$ 应用 Δ 方法到 $\sqrt{n}$:

因为 $\sqrt{n}(\frac{V_n}{n} - 1) \xrightarrow{D} N(0, 2)$, 且 $g'(1) = \frac{1}{2}$, 所以

$$\sqrt{n} \left(\sqrt{\frac{V_n}{n}} - 1 \right) \xrightarrow{D} N\left(0, 2 \cdot \frac{1}{4}\right) = N\left(0, \frac{1}{2}\right).$$

即

$$\sqrt{n} \left(\frac{\sqrt{V_n}}{\sqrt{n}} - 1 \right) \xrightarrow{D} N\left(0, \frac{1}{2}\right).$$

因此

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) \xrightarrow{D} N\left(0, \frac{1}{2} \cdot n\right) = N\left(0, \frac{n}{2}\right).$$

这表明 $\sqrt{V_n}$ 的渐近方差与 $\sqrt{n}$ 成正比。

结论: 应用 Δ 方法于卡方变量的平方根变换, 得到

$$\sqrt{n}(\sqrt{V_n} - \sqrt{n}) \xrightarrow{D} N\left(0, \frac{1}{2}\right) \cdot \sqrt{n} = N\left(0, \frac{n}{2}\right).$$

更精确地, $\sqrt{n}(\sqrt{V_n} - \sqrt{n})/\sqrt{n/2} = \sqrt{2}(\sqrt{V_n} - \sqrt{n})/\sqrt{V_n/2} \xrightarrow{D} N(0, 1)$ 。■

0.29. 卡方检验的详细推导. 背景 (Background): 拟合优度 χ^2 检验 (Goodness-of-Fit Test) 由 Karl Pearson 于 1900 年提出, 是统计推断的早期方法之一。该检验用于检验观测频数与期望频数之间的偏离程度。

参数定义 (Parameter Definitions):

- $X_i \sim \text{Multinomial}(n, p_1, \dots, p_k)$: 多项分布, X_i 为落入第 i 类的频数
- p_i : 落入第 i 类的真实概率
- p_{i0} : 原假设 H_0 下指定的概率值
- np_{i0} : 原假设下第 i 类的期望频数
- $Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_{i0})^2}{np_{i0}}$: Pearson χ^2 统计量

已知条件 (Given):

- 当 H_0 为真时, $p_i = p_{i0}$, $i = 1, \dots, k$
- 由中心极限定理, 当 $n \rightarrow \infty$ 且 $np_i > 0$ 时,

$$\frac{X_i - np_i}{\sqrt{np_i(1 - p_i)}} \xrightarrow{D} N(0, 1).$$

- 当 H_0 为真时, $X_i \approx N(np_{i0}, np_{i0}(1 - p_{i0}))$

目标 (Goal): 证明在 H_0 下, $Q_{k-1} \xrightarrow{D} \chi^2(k-1)$ 。

推导步骤 (Derivation Steps):

1. 首先考虑二项分布情形。设 $X_1 \sim b(n, p_1)$, $X_2 = n - X_1$, $p_2 = 1 - p_1$ 。定义标准化变量

$$Z = \frac{X_1 - np_1}{\sqrt{np_1(1-p_1)}}.$$

由 CLT, $Z \xrightarrow{D} N(0, 1)$ 。

2. 则 $Z^2 \xrightarrow{D} \chi^2(1)$ (标准正态变量的平方服从自由度为 1 的卡方分布)。

3. 展开 Z^2 :

$$Z^2 = \frac{(X_1 - np_1)^2}{np_1(1-p_1)} = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_1 - np_1)^2}{n(1-p_1)}.$$

4. 利用 $X_2 = n - X_1$, 有 $(X_1 - np_1)^2 = (n - X_2 - n + np_2)^2 = (X_2 - np_2)^2$ 。因此

$$Z^2 = \frac{(X_1 - np_1)^2}{np_1} + \frac{(X_2 - np_2)^2}{np_2} = Q_1,$$

即二项情形的 Pearson χ^2 统计量。

5. 推广到多项分布。设 $(X_1, \dots, X_{k-1}) \sim \text{Multinomial}(n, p_1, \dots, p_{k-1})$, $X_k = n - \sum_{i=1}^{k-1} X_i$, $p_k = 1 - \sum_{i=1}^{k-1} p_i$ 。

定义 Pearson 统计量

$$Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i}.$$

6. 关键步骤: 将 Q_{k-1} 表示为平方和形式。令

$$Y_i = \frac{X_i - np_i}{\sqrt{np_i}}, \quad i = 1, \dots, k.$$

则 $Q_{k-1} = \sum_{i=1}^k Y_i^2$ 。

7. 向量形式: 设 $\mathbf{Y} = (Y_1, \dots, Y_k)$ 。可以证明 (见 Hogg, McKean, Craig Theorem 4.7.1 或更高级课程的证明), 当 $n \rightarrow \infty$ 时, $\mathbf{Y}$ 的协方差矩阵为

$$\Sigma = I_k - \mathbf{p}\mathbf{p}',$$

其中 $\mathbf{p} = (p_1, \dots, p_k)'$, I_k 为 $k \times k$ 单位矩阵。

8. 该协方差矩阵 Σ 是 ** 幂等矩阵 ** (idempotent), 且 $\text{rank}(\Sigma) = k - 1$ 。对于幂等矩阵, 其特征值为 0 或 1。

9. 因此, $Q_{k-1} = \mathbf{Y}'\mathbf{Y}$ 服从 (渐近) $\chi^2(k-1)$ 分布。这基于以下事实: 若 $\mathbf{Y} \xrightarrow{D} N(\mathbf{0}, \Sigma)$, 且 Σ 是幂等的, 则 $\mathbf{Y}'\Sigma^-\mathbf{Y} \xrightarrow{D} \chi^2(\text{rank}(\Sigma))$, 其中 Σ^- 为广义逆。

10. 具体推导 (来自 Hogg): 设 $Z_i = (X_i - np_i)/\sqrt{np_i}$, 则 $\sum_{i=1}^k \sqrt{p_i}Z_i = 0$ (因为 $\sum X_i = n$)。定义

$$Q_{k-1} = \sum_{i=1}^k Z_i^2 = \sum_{i=1}^k (Z_i - \bar{Z}_w)^2 + (\text{某个组合})^2,$$

其中 $\bar{Z}_w = \sum_{i=1}^k p_i Z_i / \sum_{i=1}^k p_i = 0$ 。

最终得到 Q_{k-1} 可以分解为一个 $\chi^2(1)$ 变量 (来自组合约束) 和一个 $\chi^2(k-2)$ 变量之和, 即 $\chi^2(k-1)$ 。

结论：在原假设 $H_0 : p_i = p_{i0}, i = 1, \dots, k$ 下，当样本量 $n \rightarrow \infty$ 时，

$$Q_{k-1} = \sum_{i=1}^k \frac{(X_i - np_{i0})^2}{np_{i0}} \xrightarrow{D} \chi^2(k-1).$$

因此，对于大样本， Q_{k-1} 具有近似卡方分布，自由度为 $k-1$ （减去一个约束 $\sum p_i = 1$ ）。这就是 Karl Pearson 于 1900 年提出的拟合优度 χ^2 检验的理论基础。■

1. 问答记录

1.1. 置信区间的频率派解释. 问: 很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别? 哪个是正确的, 为什么?

答: 这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别: 在频率派统计中, θ 是**固定(但未知)的常数**, 而区间 $[L, U]$ 是**随机的** (因为它依赖于样本数据)。因此, 我们不能对固定参数 θ 做概率陈述。

正确的频率派解释: 如果我们重复抽样很多次, 构造置信区间, 那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间, 真实的 θ 要么在里面, 要么不在里面——没有概率可言。

举例说明: 设硬币抛掷 $n = 100$ 次, $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**: 观察到的区间是某个具体区间如 $[0.45, 0.55]$, 真实的 θ 要么在里面, 要么不在——无法赋予概率。
- 对于**重复抽样**: 如果用同样的真实 θ 做 1000 次实验, 约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同: 在贝叶斯统计中, θ 被视为随机变量 (需要先验分布), 可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的, 可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比:

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**, 它描述的是构造过程的可靠性, 而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问: 在之前关于置信区间的回答中提到, 贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗? 先验分布到底代表什么?

答: 这是一个很好的问题。在贝叶斯统计中, 我们将参数 θ 视为随机变量, 因此在推断前必须为其指定一个**先验分布** (prior distribution), 表达我们对参数的初始信念。以下是几个经典例子。

例 1: 硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ , 抛掷 n 次得到 Y 次正面, 则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验: 我们为 θ 选择 Beta 分布作为先验:

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 Chapter 4 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及（直方图估计）
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

简单区分：

场景	方法	章节
分布形式未知	非参数方法（直方图、核密度估计）	Chapter 10
分布形式已知、参数未知	参数方法（MLE、CI、检验）	Chapter 4

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 1. 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 2. 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 3. 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计（MLE）被提出的**动机**。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

具体例子：

- S^2 （无偏）和 $\hat{\sigma}^2$ （有偏，但 MLE）
- 两者都常用，但各有用途
- “最优”需要更精确的定义（后续章节的 UMVUE）

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

1.5. 正则条件 (R0)-(R2) 的定义. 问: 在 Chapter 6 中多次提到”正则条件 (R0)-(R2)”, 但没有给出正确定义。这些条件具体是什么?

答: 正则条件 (R0)-(R2) 是 MLE 渐近理论中的经典正则条件, 确保 MLE 具有一致性和渐近正态性。

(R0) 可辨识性 (Identifiability): 参数 θ 可辨识, 即若对所有 x 有 $f(x; \theta) = f(x; \theta')$, 则 $\theta = \theta'$ 。这保证了不同参数值对应不同的分布。

(R1) 参数空间正则性: 参数空间 Ω 是 $\mathbb{R}^p$ 的开子集, 且真参数 θ_0 是 Ω 的内点。这保证了在 θ_0 附近可以进行泰勒展开。

(R2) 密度函数光滑性: 密度 $f(x; \theta)$ 对 θ 足够光滑, 满足:

- 积分号下可微分: $\frac{\partial}{\partial \theta} \int f(x; \theta) dx = \int \frac{\partial}{\partial \theta} f(x; \theta) dx$
- 得分函数 $S(X, \theta) = \nabla_{\theta} \log f(X; \theta)$ 有有限二阶矩
- Fisher 信息矩阵 $I(\theta) = \mathbb{E}[S(X, \theta)S(X, \theta)^T]$ 在 θ_0 处存在且正定

这些条件的作用:

- (R0) 保证参数可以被唯一估计
- (R1) 允许在真参数附近进行局部分析
- (R2) 使得大数定律和中心极限定理可以应用于得分函数, 从而建立 MLE 的渐近理论

注: Cauchy 分布的 MLE 不满足某些正则条件, 因此需要特殊处理 (见 §6.1 的例子)。

学习笔记.

参考文献

- [1] Jonas E. Salk, J. S. Youngner, E. N. Ward, A. B. Ángelbeck, H. C. Merritt, M. E. Glabe, I. L. Sherman, J. W. Osborne, A. J. Lindsey, A. M. Bodanza, et al. The use of adjuvants to facilitate studies on the immunologic properties of poliomyelitis vaccines. *American Journal of Public Health*, 45:151–170, 1955.
- [2] Samuel S. Wilks. *Statistical Design and Analysis of Experiments*. John Wiley & Sons, reprint of 1963 edition edition, 2006.
- [3] Edwin B. Wilson. One probable inference, the ligature of arteries, and the first statistical test of the etiology of disease. *Journal of the American Statistical Association*, 22:209–212, 1927.