

数理统计导论

Hogg, McKean, Craig

目录

引言：从随机性中学习	7
引言：从随机性中学习	7
1. 为什么需要概率论?	7
2. 教材内容预览	7
3. 这三章的内在逻辑	10
4. 学习方法建议	10
5. 习题说明	11
Chapter 1. Probability and Distributions	13
Chapter 1 Overview	13
1. 1.1 Introduction: Why Probability Theory?	13
2. 1.2 Sets: The Language of Uncertainty	14
3. 1.3 The Probability Set Function	15
4. 1.4 Conditional Probability and Independence	15
5. 1.5 Random Variables	17
6. 1.6 Discrete Random Variables	17
7. 1.7 Continuous Random Variables	19
8. 1.8 Expectation of a Random Variable	21
9. 1.9 Some Special Expectations	22
10. 1.10 Important Inequalities	24
Summary	25
Exercises	25
11. 附录：公式推导	27
Chapter 2. 多元随机变量及其分布	35
Chapter 2 概述	35
1. 2.1 从一元到多元：联合分布	35
2. 2.2 边缘分布：积分即求和	37
3. 2.3 条件分布：信息的价值	39
4. 2.4 独立性：变量间的”无关系”	45
5. 2.5 相关性：线性关联的度量	48
6. 2.6 二元正态：最重要的二元分布	50
7. 2.7 多元推广	52

8. 本章总结	54
习题	54
9. 附录：公式推导	55
Chapter 3. Special Distributions	67
Chapter 3 Overview	67
1. 3.1 二项分布及其相关分布	67
2. 3.2 Poisson 分布	72
3. 3.3 Gamma、 χ^2 与 Beta 分布	74
4. 3.4 正态分布 (Normal Distribution)	77
5. 3.5 多元正态分布	78
6. 3.6 t 分布与 F 分布	79
本章小结	81
习题	81
7. 附录：公式推导	90
Chapter 4. Some Elementary Statistical Inferences	97
Chapter 4 Overview	97
1. 4.1 Sampling and Statistics	97
2. 4.2 Confidence Intervals	100
3. 4.3 Order Statistics	102
4. 4.4 Hypothesis Testing	103
5. 4.5 Chi-Square Tests	104
6. 4.6 Monte Carlo Methods	107
7. 4.7 Bootstrap Methods	108
Exercises	108
本章小结	123
8. 附录：公式推导	123
Chapter 5. Asymptotic Theory	129
Chapter 5 Overview	129
1. 5.1 Convergence in Probability	129
2. 5.2 Convergence in Distribution	132
3. 5.3 Central Limit Theorem	136
4. 5.4 Extensions to Multivariate Distributions	137
Exercises	138
本章小结	142
5. 附录：公式推导	142
Chapter 6. Maximum Likelihood Methods	151
Chapter 6 Overview	151

1. 6.1 Maximum Likelihood Estimation	151
2. 6.2 Rao-Cramér Lower Bound and Efficiency	153
3. 6.3 Maximum Likelihood Tests	157
4. 6.4 Multiparameter Case: Estimation	158
5. 6.5 Multiparameter Case: Testing	161
6. 6.6 The EM Algorithm	162
7. 附录：公式推导	166
Chapter 7. Sufficiency and Quality of Estimators	169
Chapter 7 Overview	169
1. 7.1 Measures of Quality of Estimators	169
2. 7.2 A Sufficient Statistic for a Parameter	170
3. 7.3 Properties of a Sufficient Statistic	173
4. 7.4 Completeness and Uniqueness	174
5. 7.5 The Exponential Class of Distributions	176
6. 7.6 Functions of a Parameter	177
7. 7.7 The Case of Several Parameters	178
8. 7.8 Minimal Sufficiency and Ancillary Statistics	180
9. 7.9 Sufficiency, Completeness, and Independence	181
本章习题	183
Chapter 8. Optimal Statistical Tests	185
Chapter 8 Overview	185
1. 8.1 Most Powerful Tests	185
2. 8.2 Uniformly Most Powerful Tests	189
3. 8.3 Likelihood Ratio Tests	191
4. 8.4 *Sequential Probability Ratio Test	194
5. 8.5 *Minimax and Classification Procedures	196
附录：公式推导	198
Exercises	200
Chapter 9. ANOVA and Regression	203
Chapter 9 Overview	203
1. 9.1 Introduction	203
2. 9.2 One-Way ANOVA	204
3. 9.3 Noncentral χ^2 and F Distributions	205
4. 9.4 Multiple Comparisons	206
5. 9.5 Two-Way ANOVA	207
6. 9.6 A Regression Problem	208
7. 9.7 A Test of Independence	210

8. 9.8 Distributions of Certain Quadratic Forms	210
9. 9.9 The Independence of Certain Quadratic Forms	211
习题	211
附录：公式推导	212
附录 A. 附录：公式推导	215
1. 问答记录	230

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 notation，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 Overview

本章从概率论的公理化基础出发，逐步建立整套理论框架。这条脉络贯穿本书始终——理解随机现象的本质、建立描述分布的工具、掌握期望与矩的计算。

为什么从概率论开始？ 因为统计学的一切推断都建立在概率论的基础上。如果不理解概率的数学本质，就无法真正理解统计推断的逻辑。

本章路线图： 随机现象 → 概率公理 → 条件概率与独立性 → 随机变量 → 离散/连续分布 → 期望与矩 → 矩母函数 → 重要不等式

1. 1.1 Introduction: Why Probability Theory?

1.1. The Genesis of Probability. 概率论的故事始于一场赌博。1654 年，赌徒 Chevalier de Méré 向数学家 Blaise Pascal 提出一个问题：如果两名玩家在赌局中途中断，如何公平地分配赌金？这个问题引发了 Pascal 与 Pierre de Fermat 的通信，从而奠定了概率论的基础。

从频率到概率： 设想进行 N 次重复实验。事件 A 发生的次数记为 $f_N(A)$ ，则 $f_N(A)/N$ 称为相对频率 (relative frequency)。当 N 增大时， $f_N(A)/N$ 趋于稳定，趋向某个数 p ——这正是事件 A 的概率。Kolmogorov 在 1933 年的开创性著作《概率论基础》中将这种直觉严格化，建立了现代概率论的公理化体系。

两派观点： 概率的相对频率解释依赖于实验可重复的条件。另一种观点——贝叶斯学派——将概率视为主观信念的度量。无论采用哪种解释，概率的数学性质（公理）都是一致的，因此我们可以在坚实的数学基础上统一处理。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. Random Experiments and Sample Spaces. 若一个实验可以在相同条件下重复进行，且所有可能的结果可以在实验前描述，我们就称其为随机实验 (random experiment)。

所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

这三个例子揭示了样本空间的三种类型：离散有限（硬币）、离散无限（骰子）、连续（等待时间）。理解样本空间的类型决定了我们使用离散还是连续的数学工具。

EXAMPLE 1.1 (Coin Toss). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (Two Dice). 投掷一枚红骰子和一枚白骰子。样本空间包含 36 个有序对: $\mathcal{C} = \{(1, 1), (1, 2), \dots, (6, 6)\}$ 。

EXAMPLE 1.3 (Continuous Sample Space). 等待地铁到达的时间。样本空间为 $\mathcal{C} = (0, \infty)$ ——这是一个连续不可数的集合。

事件是样本空间的子集。如果一个实验进行一次, 事件 A 要么发生, 要么不发生, 没有第三种可能。概率论正是描述这种不确定性的数学语言。

2. 1.2 Sets: The Language of Uncertainty

2.1. Why Do We Need Set Theory for Probability? 在概率论中, 事件 (event) 本质上就是样本空间的子集。为什么要用集合的语言? 因为集合运算 (并、交、补) 完美地对应了事件的逻辑运算 (“或”、“且”、“非”)。

德摩根定律 (De Morgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c. \quad (1.2.1)$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C). \quad (1.2.2)$$

这些看似简单的定律, 在概率计算中非常有用。例如, 要计算 “既不是 A 也不是 B ” 的概率, 我们可以直接使用德摩根定律: $\mathbb{P}((A \cup B)^c) = \mathbb{P}(A^c \cap B^c)$ 。

2.2. Key Set Operations. 设 $\mathcal{C}$ 为样本空间, A, B, C 为事件:

- **补集** A^c : 所有不在 A 中的元素
- **并集** $A \cup B$: 至少在 A 或 B 之一中的元素
- **交集** $A \cap B$: 同时在 A 和 B 中的元素
- **不交** $A \cap B = \phi$: A 和 B 互不相容

EXAMPLE 1.4 (Set Operations). 设 $\mathcal{C} = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。

则 $A^c = \{3, 4, \dots, 10\}$, $A \cup B = \{1, 2, 3, 4\}$, $A \cap B = \{2\}$, $A \cap C = \phi$, $B \cap C = \{3, 4\}$ 。

2.3. Countable and Uncountable Sets. 若集合 C 是有限的, 或与正整数集等势, 则称 C 为可数的 (countable)。

可数并: $\cup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}$

可数交: $\cap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \cup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \cap_{n=1}^{\infty} A_n$ 。

3. 1.3 The Probability Set Function

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。

概率必须满足：

- (1) 非负性： $\mathbb{P}(A) \geq 0$
- (2) 规范化： $\mathbb{P}(\mathcal{C}) = 1$
- (3) 可数可加性：若 $A_1, A_2, \dots$ 两两不交，则 $\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$

REMARK. **概率公理的直观含义**：非负性说明概率不能为负；规范化说明必然事件的概率为 1；可数可加性说明互不相容事件的并的概率等于各自概率之和。

从这三条公理可以推导出概率的所有其他性质。¹

REMARK. **定理 1.3.1**：对每个事件 A ， $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ 。

证明：由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$ ，结合公理得

$$1 = \mathbb{P}(\mathcal{C}) = \mathbb{P}(A) + \mathbb{P}(A^c).$$

布尔不等式：对任意事件 $A_1, \dots, A_n$ ，

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i). \quad (1.3.1)$$

这在估计复合事件概率时非常有用——当精确计算困难时，布尔不等式提供了一个上界。

REMARK. **等可能性情形**：若样本空间 $\mathcal{C} = \{x_1, x_2, \dots, x_m\}$ 有限，且每个 *outcome* 等概率，则

$$\mathbb{P}(A) = \frac{\#(A)}{m}. \quad (1.3.2)$$

EXAMPLE 1.5 (扑克牌概率). 从 52 张扑克牌中随机抽取一张。设 $A =$ “抽到 A ”， $B =$ “抽到红桃”。则

$$\mathbb{P}(A) = \frac{4}{52}, \quad \mathbb{P}(B) = \frac{13}{52}, \quad \mathbb{P}(A \cap B) = \frac{1}{52}.$$

由容斥原理，

$$\mathbb{P}(A \cup B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52} = \frac{4}{13}.$$

4. 1.4 Conditional Probability and Independence

条件概率是概率论中最重要的概念之一。它描述了在已知某些信息发生的条件下，如何更新我们对其他事件概率的判断。

REMARK. **定义 1.4.1 (条件概率)**：设 $\mathbb{P}(B) > 0$ ，在事件 B 已发生的条件下，事件 A 的条件概率定义为

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (1.4.1)$$

¹详细推导见附录 section 11.1。

条件概率满足概率的三条公理——它是一种新的概率度量，样本空间缩小为 B 。

乘法法则：

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) = \mathbb{P}(B) \cdot \mathbb{P}(A | B). \quad (1.4.2)$$

推广到 n 个事件：

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right). \quad (1.4.3)$$

REMARK. **全概率公式：** 设 $\{B_i\}$ 为 C 的一个划分，则对任意事件 A ,

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i). \quad (1.4.4)$$

REMARK. **贝叶斯公式：**

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i)}. \quad (1.4.5)$$

术语：

- $\mathbb{P}(B_j)$: 先验概率 (*prior probability*) ——在观测到 A 之前我们对 B_j 的信念
- $\mathbb{P}(B_j | A)$: 后验概率 (*posterior probability*) ——在观测到 A 之后我们对 B_j 的更新信念
- $\mathbb{P}(A | B_j)$: 似然 (*likelihood*) ——在 B_j 成立的条件下观测到 A 的概率

贝叶斯公式不仅是一个计算工具，更提供了一种思考不确定性的思维方式。²

EXAMPLE 1.6 (医学检测). 设某疾病患病率为 1%，检测准确率为 99%。令 $D =$ “患病”， $+$ = “检测阳性”。

即使检测准确率高达 99%，检测阳性者真正患病的概率只有 50%!

这个违反直觉的结果说明：在疾病罕见的情况下，即使非常准确的检测也可能产生大量假阳性。³

4.1. 1.4.1 Independence.

REMARK. **定义 1.4.2 (独立性)：** 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，则称 A 与 B 相互独立，记作 $A \perp B$ 。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时，独立性等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$ ——知道 B 发生并不改变 A 的概率。

EXAMPLE 1.7 (独立硬币). 抛掷两枚独立硬币。设 $A =$ “第一枚正面朝上”， $B =$ “第二枚正面朝上”。则 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$ ，且 $\mathbb{P}(A \cap B) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，故 $A \perp B$ 。

WARNING: 两两独立 (pairwise independent) 不一定意味着相互独立!⁴

²贝叶斯公式的深层意义见附录 section 11.2。

³详细计算见附录 section 11.3。

⁴反例见附录 section 11.4。

5. 1.5 Random Variables

样本空间的元素可能不是数字——随机变量正是将样本空间数值化的工具。

REMARK. 定义 1.5.1 (随机变量): 随机变量是从样本空间 $\mathcal{C}$ 到实数的函数: $X: \mathcal{C} \rightarrow \mathbb{R}$ 。

通常用大写字母 X, Y, Z 表示随机变量, 用小写字母 x, y, z 表示具体取值。

随机变量可分为:

- 离散随机变量: 取值可数 (有限或无限)
- 连续随机变量: 取值充满区间, 不可数

给定随机变量 X , 它的取值空间 $\mathcal{D}$ 成为新的样本空间。 X 不仅诱导了新的样本空间, 还诱导了一个概率分布——这正是“分布”概念的起源。

EXAMPLE 1.8 (硬币投掷). 抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$ 。定义 X 为正面出现的次数: $X(HH) = 2, X(HT) = X(TH) = 1, X(TT) = 0$ 。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。

EXAMPLE 1.9 (均匀选择). 从区间 $(0, 1)$ 中随机选择一个数 X 。 X 是连续随机变量, 取值充满 $(0, 1)$ 。

5.1. Cumulative Distribution Function.

REMARK. 定义 1.5.2 (CDF): $F_X(x) = \mathbb{P}(X \leq x), -\infty < x < \infty$ 。

CDF 满足:

- (1) 非递减: 若 $x_1 < x_2$, 则 $F_X(x_1) \leq F_X(x_2)$
- (2) $\lim_{x \rightarrow -\infty} F_X(x) = 0, \lim_{x \rightarrow \infty} F_X(x) = 1$
- (3) 右连续: $F_X(x) = \lim_{t \rightarrow x^+} F_X(t)$

从 CDF 计算概率:

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a). \quad (1.5.1)$$

关键洞察: 对连续随机变量, $\mathbb{P}(X = x) = 0$, 因此

$$\mathbb{P}(a < X < b) = \mathbb{P}(a \leq X \leq b) = F(b) - F(a). \quad (1.5.2)$$

6. 1.6 Discrete Random Variables

离散随机变量的取值是可数的。

REMARK. 定义 1.6.1 (pmf): $p_X(x) = \mathbb{P}(X = x)$ 。

pmf 满足: $p_X(x) \geq 0$ 对所有 x , 且 $\sum_x p_X(x) = 1$ 。

6.1. 1.6.1 Common Discrete Distributions. 伯努利分布 $X \sim \text{Bernoulli}(p)$:

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p. \quad (1.6.1)$$

二项分布 $X \sim \text{Bin}(n, p)$:

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n. \quad (1.6.2)$$

EXAMPLE 1.10 (二项分布). 抛掷一枚均匀硬币 10 次。设 X 为正面出现的次数。则 $X \sim \text{Bin}(10, 0.5)$,

$$\mathbb{P}(X = 3) = \binom{10}{3} (0.5)^3 (0.5)^7 = \frac{120}{1024} \approx 0.117.$$

几何分布 $X \sim \text{Geom}(p)$:

$$\mathbb{P}(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, 3, \dots \quad (1.6.3)$$

几何分布具有“无记忆性”——等待时间不受过去等待的影响。⁵

EXAMPLE 1.11 (几何分布). 抛掷一枚均匀硬币直到第一次出现正面。设 X 为抛掷次数。则 $X \sim \text{Geom}(0.5)$,

$$\mathbb{P}(X = 3) = (0.5)^2 \cdot 0.5 = \frac{1}{8}.$$

泊松分布 $X \sim \text{Poisson}(\lambda)$:

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots \quad (1.6.4)$$

泊松分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限分布。⁶

这揭示了离散分布之间的深刻联系——泊松分布作为稀有事件的模型具有重要意义。

EXAMPLE 1.12 (泊松分布). 某医院每小时接到的急诊电话数服从泊松分布，均值 $\lambda = 3$ 。则

$$\mathbb{P}(\text{每小时接到 5 个电话}) = \frac{3^5 e^{-3}}{5!} \approx 0.101.$$

超几何分布 $X \sim \text{Hypergeometric}(N, K, n)$:

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}. \quad (1.6.5)$$

这是从有限总体中无放回抽样的模型。

EXAMPLE 1.13 (超几何分布). 一个盒子中有 20 个红球和 80 个白球 (共 100 个)。从中抽取 5 个 (无放回)。令 X 为抽到的红球数。则

$$\mathbb{P}(X = 2) = \frac{\binom{20}{2} \binom{80}{3}}{\binom{100}{5}}.$$

⁵详细证明见附录 section 11.5。

⁶详细推导见附录 section 7.10。

6.2. 1.6.2 Transformations of Discrete Random Variables. 在统计中, 我们经常需要对一个随机变量进行变换: $Y = g(X)$ 。

一对一变换: 若 g 是一一对应的, 则

$$p_Y(y) = p_X(g^{-1}(y)). \quad (1.6.6)$$

非一对一变换: 需要合并所有映射到相同 y 的 x 的概率。

EXAMPLE 1.14 (离散变换). 设 $X \sim \text{Geom}(0.5)$, $Y = X^2$ 。因为 $g(x) = x^2$ 在 $\{1, 2, 3, \dots\}$ 上是一一对应的 (没有负数),

$$p_Y(y) = p_X(\sqrt{y}) = (0.5)^{\sqrt{y}+1}, \quad y = 1, 4, 9, \dots$$

7. 1.7 Continuous Random Variables

连续随机变量的取值充满一个或多个区间, 不可数。

REMARK. **定义 1.7.1 (连续随机变量):** 若随机变量 X 的 *cdf* $F_X(x)$ 对所有 x 都连续, 则称 X 为连续随机变量。

对连续随机变量, $\mathbb{P}(X = x) = 0$ 对所有 x ——这意味着单点概率为零。

REMARK. **定义 1.7.2 (pdf):** 若存在非负函数 $f_X(x)$ 使得

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x) dx$$

对任意 $a < b$ 成立, 则称 $f_X(x)$ 为 *pdf*。

pdf 满足: $f_X(x) \geq 0$ 对所有 x , 且 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。

WARNING: $f_X(x)$ 可以大于 1! 这与 *pmf* 的 $p_X(x) \leq 1$ 形成对比。pdf 的值不是概率, 而是概率密度——只有积分才是概率。

EXAMPLE 1.15 (均匀分布). 从区间 $(0, 1)$ 中随机选择一个数 X 。则 $X \sim \text{Uniform}(0, 1)$,

$$f_X(x) = \begin{cases} 1 & 0 < x < 1 \\ 0 & \text{otherwise} \end{cases}$$

EXAMPLE 1.16 (单位圆内的随机点). 在单位圆内随机选择一个点。设 X 为该点到原点的距离。则 X 的 *cdf* 为 $F_X(x) = x^2$, $0 \leq x \leq 1$ 。因此 *pdf* 为 $f_X(x) = 2x$, $0 < x < 1$ 。

EXAMPLE 1.17 (指数分布). 电话呼叫间隔时间 X 服从指数分布, *pdf* 为

$$f_X(x) = \frac{1}{4}e^{-x/4}, \quad x > 0.$$

则 $\mathbb{P}(X > 4) = \int_4^{\infty} \frac{1}{4}e^{-x/4} dx = e^{-1} \approx 0.368$ 。

指数分布也具有无记忆性。⁷

⁷详细讨论见附录 section 11.7。

正态分布 $X \sim N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \quad (1.7.1)$$

正态分布是统计学中最重要的分布——这将在第三章详细讨论。

7.1. 1.7.1 Quantiles. 分位数是分布的重要特征。

REMARK. 定义 1.7.3 (分位数): 设 $0 < p < 1$. 分布的 $100p\%$ 分位数 ξ_p 满足

$$\mathbb{P}(X < \xi_p) \leq p \quad \text{且} \quad \mathbb{P}(X \leq \xi_p) \geq p. \quad (1.7.2)$$

特殊分位数:

- 中位数 (*median*): $\xi_{0.5}$
- 第一四分位数: $\xi_{0.25}$
- 第三四分位数: $\xi_{0.75}$

四分位距 (*IQR*): $q_3 - q_1$, 是衡量离散程度的稳健指标。

若 X 连续且 F_X 严格递增, 则 $\xi_p = F_X^{-1}(p)$ 。

偏度 (*Skewness*): 描述分布的不对称程度。

- 右偏 (*positively skewed*): 右尾较长, 如指数分布
- 左偏 (*negatively skewed*): 左尾较长
- 对称 (*symmetric*): 如正态分布

7.2. 1.7.2 Transformations of Continuous Random Variables. 设 X 是连续随机变量, $f_X(x)$ 已知。我们想知道 $Y = g(X)$ 的分布。

CDF 法: 先求 $F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y)$, 然后求导得 $f_Y(y) = \frac{d}{dy}F_Y(y)$ 。

EXAMPLE 1.18 (连续变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = X^2$ 。则对 $0 < y < 1$,

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(X \leq \sqrt{y}) = \sqrt{y}.$$

因此 $f_Y(y) = \frac{1}{2\sqrt{y}}$, $0 < y < 1$ 。

——变换公式: 若 $y = g(x)$ 是一一对应且可导的, $x = g^{-1}(y)$, 则

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy}g^{-1}(y) \right|, \quad y \in \mathcal{S}_Y. \quad (1.7.3)$$

这里 $|\frac{dx}{dy}|$ 称为雅可比 (Jacobian)。

EXAMPLE 1.19 (对数变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = -\log X$ 。则 $x = e^{-y}$, $dx/dy = -e^{-y}$ 。因此

$$f_Y(y) = 1 \cdot |-e^{-y}| = e^{-y}, \quad y > 0.$$

即 $Y \sim \text{Exp}(1)$ 。

这提供了从均匀分布生成指数分布的方法——逆变换采样 (*inverse transform sampling*) 的基础。⁸

⁸逆变换采样的详细讨论见第四章。

变换公式的证明：⁹

7.3. 1.7.3 Mixture Distributions. 有些分布既不是纯离散的，也不是纯连续的，而是两者的混合。

EXAMPLE 1.20 (混合分布). 设 X 的 cdf 为

$$F(x) = \begin{cases} 0 & x < 0 \\ \frac{x+1}{2} & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases}$$

则 $\mathbb{P}(X=0) = 1/2$ ，且对 $0 < x < 1$ ， $\mathbb{P}(0 < X < x) = x/2$ 。这是一个离散-连续混合分布。

这种分布在实际中经常出现，例如：

- 删失数据 (*censored data*)
- 保险中的限额保单

8. 1.8 Expectation of a Random Variable

期望是随机变量最重要的一致性度量。它描述了分布的”中心位置”。

REMARK. 定义 1.8.1 (数学期望):

- 离散型: $\mathbb{E}X = \sum x \cdot p_X(x)$
- 连续型: $\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$

要求级数或积分绝对收敛，即 $\mathbb{E}|X| < \infty$ 。

期望的起源：在赌博游戏中，”期望”(expectation)一词来源于玩家对游戏收益的长期平均预期。

公平游戏：若 $E(G) = 0$ ，则游戏是公平的 (fair game)。

EXAMPLE 1.21 (骰子期望). 设 X 为掷骰子的点数。则 $\mathbb{E}X = \frac{1}{6}(1+2+3+4+5+6) = 3.5$ 。

REMARK. 函数期望定理: 设 $Y = g(X)$ 。则

- 离散型: $\mathbb{E}Y = \sum g(x) \cdot p_X(x)$
- 连续型: $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx$

重要含义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！¹⁰

期望的线性性是概率论中最重要、最有用的性质之一。¹¹

⁹详细推导见附录 section 11.8。

¹⁰详细证明见附录 section 11.9。

¹¹详细证明见附录 section 0.5。

REMARK. 定理 1.8.1 (期望的线性性): 对任意随机变量 X, Y (期望存在) 和常数 a, b :

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y. \quad (1.8.1)$$

关键点: 无需 X, Y 相互独立!

EXAMPLE 1.22 (样本均值). 设 $X_1, \dots, X_n$ 是独立同分布的随机变量, $\mathbb{E}X_i = \mu$ 。则样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望为

$$\mathbb{E}\bar{X} = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \mu.$$

这说明样本均值是总体均值的无偏估计!¹²

乘积期望: 一般情况下 $\mathbb{E}(XY) \neq \mathbb{E}X \cdot \mathbb{E}Y$ 。只有当 X 和 Y 独立时, 等式才成立。

EXAMPLE 1.23 (乘积期望). 设 X 和 Y 是区间 $(0, 1)$ 上的均匀分布, 但 $Y = X$ (完全相关)。则 $\mathbb{E}(XY) = \mathbb{E}(X^2) = 1/3$, 而 $\mathbb{E}X \cdot \mathbb{E}Y = 1/4$, 两者不相等。

方差度量分布的离散程度。¹³

REMARK. 定理 1.8.2 (方差公式):

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}(X^2) - \mu^2. \quad (1.8.2)$$

方差性质:

- (1) $\text{var}(aX + b) = a^2 \text{var}(X)$
- (2) 若 $X_1, \dots, X_n$ 相互独立, 则 $\text{var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{var}(X_i)$

9. 1.9 Some Special Expectations

某些期望具有特殊名称和重要意义。

9.1. Moments.

REMARK. 定义 1.9.1 (矩):

- k 阶原点矩: $\mu'_k = \mathbb{E}(X^k)$
- k 阶中心矩: $\mu_k = \mathbb{E}[(X - \mu)^k]$

一阶原点矩 $\mu'_1 = \mathbb{E}X$ 就是均值。

均值 (Mean): $\mu = \mathbb{E}X$ 是分布的中心位置度量。

方差 (Variance): $\sigma^2 = \text{var}(X)$ 度量分布的离散程度。

标准差 (Standard Deviation): $\sigma = \sqrt{\text{var}(X)}$, 与 X 具有相同单位。

变异系数 (CV): $\text{CV} = \sigma/\mu$, 是无量纲的离散程度度量。

偏度系数: $\gamma_1 = \mathbb{E}[(X - \mu)^3]/\sigma^3$, 衡量分布的不对称程度。

峰度系数: $\gamma_2 = \mathbb{E}[(X - \mu)^4]/\sigma^4 - 3$, 衡量分布尾部的厚重程度。

¹²这将在第四章统计推断中发挥核心作用。

¹³详细推导见附录 section 11.11。

EXAMPLE 1.24 (均匀分布的矩). 设 $X \sim \text{Uniform}(-a, a)$ 。则

$$\mu = 0, \quad \text{var}(X) = \frac{a^2}{3}.$$

EXAMPLE 1.25 (指数分布的矩). 设 $X \sim \text{Exp}(\lambda)$ 。则

$$\mathbb{E}X = \frac{1}{\lambda}, \quad \text{var}(X) = \frac{1}{\lambda^2}.$$

9.2. Covariance and Correlation. 两个随机变量之间的”共同变化”程度，用协方差来度量。

REMARK. 定义 1.9.2 (协方差):

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y. \quad (1.9.1)$$

协方差性质:

- (1) $\text{cov}(X, X) = \text{var}(X)$
- (2) $\text{cov}(X, Y) = \text{cov}(Y, X)$
- (3) $\text{cov}(aX + b, Y) = a\text{cov}(X, Y)$
- (4) $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y)$
- (5) 若 $X \perp\!\!\!\perp Y$, 则 $\text{cov}(X, Y) = 0$

REMARK. 定义 1.9.3 (相关系数):

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}. \quad (1.9.2)$$

重要性质: $-1 \leq \text{corr}(X, Y) \leq 1$ 。

相关系数衡量两个变量之间的线性关系强度。

WARNING: 相关不等于因果! 两个变量相关可能是由于第三个隐藏变量导致的。

14

9.3. Moment Generating Function. 矩母函数是计算矩的强大工具。

REMARK. 定义 1.9.4 (矩母函数): 若对某个 $h > 0$,

$$M_X(t) = \mathbb{E}(e^{tX}) \quad \text{对 } -h < t < h \text{ 存在}, \quad (1.9.3)$$

则称 $M_X(t)$ 为 X 的矩母函数 (mgf)。

核心性质: 矩母函数唯一确定分布! 若两个随机变量的 mgf 相同, 则它们同分布。
为什么叫”矩母函数”? 因为

$$M_X^{(k)}(0) = \mathbb{E}(X^k). \quad (1.9.4)$$

这意味着如果我们有 mgf, 可以通过对它求导来获得所有矩!

¹⁴因果推断的讨论见本书因果推断部分。

EXAMPLE 1.26 (正态分布的 mgf). 设 $X \sim N(\mu, \sigma^2)$ 。则

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right).$$

特别地, $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - [M'(0)]^2 = \sigma^2$ 。

EXAMPLE 1.27 (泊松分布的 mgf). 设 $X \sim \text{Poisson}(\lambda)$ 。则

$$M_X(t) = \exp(\lambda(e^t - 1)).$$

mgf 的加法性质尤为重要: 若 $X_1, \dots, X_n$ 独立, 则

$$M_{X_1 + \dots + X_n}(t) = \prod_{i=1}^n M_{X_i}(t). \quad (1.9.5)$$

这提供了一种验证独立随机变量和的分布的方法。

10. 1.10 Important Inequalities

概率论中有几个基本不等式, 它们在理论证明和实际应用中都非常重要。

REMARK. 定理 1.10.1 (*Markov 不等式*): 若 X 为随机变量, $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}. \quad (1.10.1)$$

Markov 不等式的意义在于: 它仅用期望就能给出概率的上界, 而不需要知道分布的完整信息。¹⁵

REMARK. 定理 1.10.2 (*Chebyshev 不等式*): 设 $\mu = \mathbb{E}X$, $\sigma^2 = \text{var}(X)$ 。则对任意 $k > 0$,

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}. \quad (1.10.2)$$

Chebyshev 不等式告诉我们: 无论分布是什么, 至少 $1 - 1/k^2$ 的概率质量落在 $\mu \pm k\sigma$ 区间内。

EXAMPLE 1.28 (*Chebyshev 应用*). 设某考试成绩均值为 70, 标准差为 10。则根据 *Chebyshev* 不等式, 至少 75% 的学生成绩在 50 到 90 分之间。

Chebyshev 不等式虽然保守, 但在无法获知确切分布时是唯一可用的工具。它也是证明大数定律的关键工具。

REMARK. 定理 1.10.3 (*Cauchy-Schwarz 不等式*): 对于任意随机变量 X 和 Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}. \quad (1.10.3)$$

重要应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。¹⁶

Jensen 不等式: 若 g 是凸函数, 则 $\mathbb{E}[g(X)] \geq g(\mathbb{E}X)$ 。¹⁷

¹⁵详细证明见附录 section 11.12。

¹⁶详细证明及更多应用见附录 section 11.13。

¹⁷Jensen 不等式的证明及更多应用见附录 section 11.14。

Summary

本章建立了概率论的基本框架，这些概念相互关联，共同构成了数理统计的基石：

- (1) **概率公理化** (1.3 节)：从相对频率的直观性质出发，建立了概率的严格数学定义
- (2) **条件概率与贝叶斯公式** (1.4 节)：提供了更新信息的数学工具，是统计推断的理论基础
- (3) **独立性** (1.4.1 节)：刻画了两个事件之间的概率关系
- (4) **随机变量** (1.5 节)：从集合论过渡到数值函数，为分布理论奠定基础
- (5) **离散与连续分布** (1.6-1.7 节)：建立了描述随机现象的主要分布类型 (Binomial, Poisson, Geometric, Normal, Exponential 等)
- (6) **变换与分位数** (1.6.2, 1.7.1-1.7.3 节)：提供了操作随机变量的技术工具
- (7) **期望与矩** (1.8-1.9 节)：分别度量分布的中心位置、离散程度和分布形状
- (8) **矩母函数** (1.9.3 节)：统一处理矩的强大工具，具有唯一性定理
- (9) **重要不等式** (1.10 节)：Markov、Chebyshev、Cauchy-Schwarz 是理论证明的基础工具

本章的核心思想：从随机现象出发，通过公理化定义建立概率论，用随机变量将样本空间数值化，然后用分布描述随机变量的行为，最后用期望等数字特征概括分布的关键性质。

与后续章节的联系：

- 第二章将概率论扩展到多个随机变量，研究联合分布、边缘分布、条件分布
- 第三章将详细介绍各种具体分布及其性质
- 第四章将利用这些工具进行统计推断（点估计、区间估计、假设检验）

Exercises

EXERCISE 1.1. 1.2.1 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$ ：

- (1) $C_1 = \{0, 1, 2\}$, $C_2 = \{2, 3, 4\}$
- (2) $C_1 = \{x : 0 < x < 2\}$, $C_2 = \{x : 1 \leq x < 3\}$

EXERCISE 1.2. 1.3.1 设 $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.4$, $\mathbb{P}(A \cap B) = 0.1$ 。求：

- (1) $\mathbb{P}(A \cup B)$
- (2) $\mathbb{P}(A | B)$
- (3) $\mathbb{P}(B | A)$

EXERCISE 1.3. 1.3.2 从 5 男 3 女中随机选 3 人。求恰好选到 2 名女生的概率。

EXERCISE 1.4. 1.4.1 某箱中有 5 个红球和 3 个白球。无放回地抽取 3 个球。求恰好抽到 2 个红球的概率。

EXERCISE 1.5. 1.4.2 设 A 和 B 是互不相容的事件， $\mathbb{P}(A) = 0.2$, $\mathbb{P}(B) = 0.3$ 。求 $\mathbb{P}(A \cup B)$ 、 $\mathbb{P}(A^c)$ 、 $\mathbb{P}((A \cup B)^c)$ 。

EXERCISE 1.6. 1.5.1 设 X 的 *cdf* 为

$$F(x) = \begin{cases} 0 & x < 0 \\ x/2 & 0 \leq x < 1 \\ 1/2 & 1 \leq x < 2 \\ 1 & x \geq 2 \end{cases}$$

求 $\mathbb{P}(0 < X \leq 1)$ 、 $\mathbb{P}(X = 1)$ 、 $\mathbb{P}(X > 1/2)$ 。

EXERCISE 1.7. 1.6.1 设 $X \sim \text{Binomial}(10, 0.3)$ 。求：

- (1) $\mathbb{P}(X = 3)$
- (2) $\mathbb{P}(X \geq 2)$
- (3) $\mathbb{E}X$

EXERCISE 1.8. 1.6.2 设 $X \sim \text{Poisson}(4)$ 。求 $\mathbb{P}(X = 0)$ 、 $\mathbb{P}(X \leq 2)$ 、 $\mathbb{E}X$ 。

EXERCISE 1.9. 1.6.3 设 $X \sim \text{Geometric}(0.4)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.10. 1.6.4 设 $X \sim \text{Binomial}(5, 0.5)$ ， $Y = X^2$ 。求 Y 的 *pmf*。

EXERCISE 1.11. 1.7.1 设 $X \sim N(100, 225)$ 。求：

- (1) $\mathbb{P}(X < 95)$
- (2) $\mathbb{P}(90 < X < 110)$
- (3) $\mathbb{P}(X > 115)$

EXERCISE 1.12. 1.7.2 设 $X \sim \text{Exp}(2)$ 。求：

- (1) $\mathbb{P}(X > 1)$
- (2) $\mathbb{P}(X < 0.5)$
- (3) 50% 分位数 (中位数)

EXERCISE 1.13. 1.7.3 设 $X \sim \text{Uniform}(0, 1)$ ， $Y = -\log X$ 。证明 $Y \sim \text{Exp}(1)$ 。

EXERCISE 1.14. 1.7.4 设 $X \sim N(0, 1)$ ， $Y = e^X$ 。求 Y 的 *pdf* (这是对数正态分布)。

EXERCISE 1.15. 1.8.1 设 X 的 *pdf* 为 $f(x) = 3x^2$ ， $0 < x < 1$ 。求 $\mathbb{E}X$ 、 $\mathbb{E}(X^2)$ 、 $\text{var}(X)$ 。

EXERCISE 1.16. 1.8.2 设 $X \sim \text{Poisson}(\lambda)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.17. 1.8.3 设 X 和 Y 是独立同分布的随机变量， $\mathbb{E}X = \mu$ ， $\text{var}(X) = \sigma^2$ 。求 $\text{var}(X - Y)$ 和 $\text{var}(X + Y)$ 。

EXERCISE 1.18. 1.9.1 设 $X \sim N(\mu, \sigma^2)$ 。求 X 的 *mgf*，并验证它产生正确的均值和方差。

EXERCISE 1.19. 1.9.2 设 X 和 Y 独立, $X \sim \text{Poisson}(2)$, $Y \sim \text{Poisson}(3)$ 。求 $X+Y$ 的分布。

EXERCISE 1.20. 1.10.1 设 $\mathbb{E}X = 100$, $\text{var}(X) = 25$ 。用 Chebyshev 不等式给出 $\mathbb{P}(|X - 100| \geq 10)$ 的上界, 并用 Markov 不等式给出另一个上界。

EXERCISE 1.21. 1.10.2 用 Cauchy-Schwarz 不等式证明: 若 $\mathbb{E}(X^2) = \mathbb{E}(Y^2) = 1$, 则 $|\mathbb{E}(XY)| \leq 1$ 。

11. 附录：公式推导

11.1. 概率公理的推导. 背景: 概率公理 (Kolmogorov, 1933) 为概率论奠定了严格数学基础。

目标: 从三条公理推导出概率的其他基本性质。

推导步骤:

性质 1: $\mathbb{P}(\phi) = 0$ 。

由公理 3, 令 $A_n = \phi$ 对所有 n , 则 $\cup_{n=1}^{\infty} A_n = \phi$, 故

$$\mathbb{P}(\phi) = \sum_{n=1}^{\infty} \mathbb{P}(\phi) = \mathbb{P}(\phi) + \sum_{n=2}^{\infty} \mathbb{P}(\phi).$$

两边减去 $\sum_{n=2}^{\infty} \mathbb{P}(\phi)$ 得 $\mathbb{P}(\phi) = 0$ 。

性质 2: 若 $A \subset B$, 则 $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$ 。

由 $B = A \cup (B \setminus A)$ 且 $A \cap (B \setminus A) = \phi$, 结合公理得

$$\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A).$$

性质 3: $\mathbb{P}(A) \leq 1$ 。

由 $A \subset C$ 和性质 2, $\mathbb{P}(A) \leq \mathbb{P}(C) = 1$ 。

性质 4 (容斥原理):

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

将 $A \cup B$ 写成不交并: $A \cup B = A \cup (B \setminus A)$, 再用公理。

布尔不等式: 对任意 $A_1, \dots, A_n$,

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i).$$

使用数学归纳法, 从容斥原理中去掉负项得到。

11.2. 贝叶斯公式的深层意义. 背景: 贝叶斯公式是更新信念的数学工具。

全概率公式是贝叶斯公式的基础:

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \mathbb{P}(A | B_i),$$

其中 $\{B_i\}$ 是样本空间的一个划分。

贝叶斯公式的直觉:

将条件概率公式 $\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j \cap A)}{\mathbb{P}(A)}$ 中的分子、分母分别展开：

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j)\mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i)\mathbb{P}(A | B_i)}.$$

先验到后验的更新机制：

- (1) 先验概率 $\mathbb{P}(B_j)$ ：观测数据前对假设的信念
- (2) 似然 $\mathbb{P}(A | B_j)$ ：在该假设下观测到数据的“可能性”
- (3) 归一化常数 $\sum_i \mathbb{P}(B_i)\mathbb{P}(A | B_i)$ ：确保后验概率之和为 1
- (4) 后验概率 $\mathbb{P}(B_j | A)$ ：观测数据后对假设的更新信念

贝叶斯公式的核心思想：用数据（通过似然）来更新先验信念，得到后验分布。这构成了贝叶斯统计的理论基础。

11.3. 医学检测假阳性详解. 问题设定：

- 疾病患病率： $\mathbb{P}(D) = 0.01$ （1%）
- 检测准确率： $\mathbb{P}(+ | D) = 0.99$ （患病者 99% 阳性）
- 误报率： $\mathbb{P}(+ | D^c) = 0.01$ （健康者 1% 阳性）

求解： $\mathbb{P}(D | +)$ ——检测阳性者真正患病的概率。

由贝叶斯公式：

$$\mathbb{P}(D | +) = \frac{\mathbb{P}(D)\mathbb{P}(+ | D)}{\mathbb{P}(D)\mathbb{P}(+ | D) + \mathbb{P}(D^c)\mathbb{P}(+ | D^c)}.$$

代入数值：

$$= \frac{0.01 \times 0.99}{0.01 \times 0.99 + 0.99 \times 0.01} = \frac{0.0099}{0.0099 + 0.0099} = \frac{0.0099}{0.0198} = 0.5.$$

直觉解释：即使检测准确率高达 99%，由于疾病非常罕见（1%），在所有阳性结果中，真阳性（ $0.01 \times 0.99 = 0.0099$ ）和假阳性（ $0.99 \times 0.01 = 0.0099$ ）的数量竟然相同！这说明在罕见事件检测中，**先验概率**（患病率）对后验概率有决定性影响。

11.4. 两两独立但不相互独立的反例. 背景：独立性是概率论中的重要概念，但两两独立不等于相互独立。

经典反例：掷两枚公平硬币，考虑以下四个事件：

- A ：第一枚硬币正面朝上
- B ：第二枚硬币正面朝上
- C ：两枚硬币结果相同（ HH 或 TT ）

验证两两独立：

- $\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = 1/2$
- $\mathbb{P}(A \cap B) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(A)\mathbb{P}(B)$
- $\mathbb{P}(A \cap C) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(A)\mathbb{P}(C)$
- $\mathbb{P}(B \cap C) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(B)\mathbb{P}(C)$

但不相互独立：

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(HH) = 1/4 \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = 1/8.$$

这个例子说明：三个事件中，任意两个都独立，但三个放在一起就不独立了。

11.5. 几何分布无记忆性的证明. 背景：几何分布描述”直到第一次成功所需等待次数”的分布。

定义： $X \sim \text{Geom}(p)$, $\mathbb{P}(X = k) = (1-p)^{k-1}p$, $k = 1, 2, 3, \dots$

无记忆性：对任意 $m, n \geq 1$,

$$\mathbb{P}(X > m+n \mid X > m) = \mathbb{P}(X > n).$$

证明：

$$\mathbb{P}(X > m+n \mid X > m) = \frac{\mathbb{P}(X > m+n)}{\mathbb{P}(X > m)} = \frac{(1-p)^{m+n}}{(1-p)^m} = (1-p)^n = \mathbb{P}(X > n).$$

直观含义：如果已经等待了 m 次且没有成功，那么再等待 n 次的概率与”从头开始等待 n 次”的概率完全相同。过去的时间”被遗忘”了。

唯一性：无记忆性是几何分布的特征性质——离散支撑集 $\{1, 2, 3, \dots\}$ 上具有无记忆性的分布只有几何分布。

11.6. Poisson 近似二项分布的证明. 背景：Poisson 分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限。

定理：若 $X_n \sim \text{Bin}(n, p_n)$ ，且 $np_n \rightarrow \lambda$ ，则对任意固定 k ：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

证明：

二项分布式：

$$\mathbb{P}(X_n = k) = \frac{n(n-1)\cdots(n-k+1)}{k!} p_n^k (1-p_n)^{n-k}.$$

写成：

$$= \frac{n^k \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} + o(1).$$

当 $n \rightarrow \infty$ 时：

$$\begin{aligned} \left(1 - \frac{j}{n}\right) &\rightarrow 1 \quad \text{for fixed } j, \\ \left(1 - \frac{\lambda}{n}\right)^n &\rightarrow e^{-\lambda}, \\ \left(1 - \frac{\lambda}{n}\right)^{-k} &\rightarrow 1. \end{aligned}$$

因此：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

实际意义：当 n 很大、 p 很小时，用 $\text{Poisson}(\lambda = np)$ 近似 $\text{Bin}(n, p)$ 可以大大简化计算。

11.7. 指数分布无记忆性的讨论. 背景：指数分布是连续版本的无记忆分布。

定义： $X \sim \text{Exp}(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $x > 0$ 。

无记忆性：对任意 $s, t > 0$,

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t).$$

证明：

$$\mathbb{P}(X > s + t \mid X > s) = \frac{\mathbb{P}(X > s + t)}{\mathbb{P}(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(X > t).$$

与几何分布的类比：离散几何分布和连续指数分布都具有无记忆性。这不是巧合——它们都是“等待直到事件发生”这一过程的模型，只是时间参数不同。

实际应用：指数分布常用于描述：

- 电子元件的寿命（假设失效率恒定）
- 客户服务时间
- 打电话的间隔时间

Poisson 过程的联系：如果事件以固定速率 λ 发生（Poisson 过程），那么相邻事件的时间间隔服从指数分布 $\text{Exp}(\lambda)$ 。

11.8. 一元变换公式的推导. 背景：已知 X 的分布，求 $Y = g(X)$ 的分布。

定理：设 X 是连续随机变量， $f_X(x)$ 已知。 $y = g(x)$ 是一一对应且可导的， $x = g^{-1}(y) = h(y)$ 。则

$$f_Y(y) = f_X(h(y)) |h'(y)|, \quad y \in \mathcal{S}_Y.$$

证明：

由 CDF 定义：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq h(y)) = F_X(h(y)).$$

对 y 求导（链式法则）：

$$f_Y(y) = f_X(h(y)) \cdot h'(y) = f_X(h(y)) |h'(y)|.$$

多对一情况：若 g 不是一一对应，则需将所有映射到同一 y 的 x 的概率相加：

$$f_Y(y) = \sum_i f_X(x_i) |x'_i|,$$

其中 $x_i = h_i(y)$ 是 $y = g(x)$ 的各个解。

11.9. 函数期望定理的证明. 背景：已知 X 的分布，求 $Y = g(X)$ 的期望。

定理：设 $Y = g(X)$ 。

- 若 X 离散： $\mathbb{E}Y = \sum_x g(x)p_X(x)$
- 若 X 连续： $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x)f_X(x)dx$

证明（连续情形）：

由定义：

$$\mathbb{E}Y = \int_{-\infty}^{\infty} y f_Y(y) dy.$$

使用变换公式：

$$= \int_{-\infty}^{\infty} y \cdot f_X(h(y)) |h'(y)| dy.$$

做变量替换 $x = h(y)$ ，则 $dx = h'(y)dy$ ， $y = g(x)$ ：

$$= \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

重要意义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！这就是“函数期望定理”的价值。

11.10. 期望线性性的证明. 定理：对任意随机变量 X, Y （期望存在）和常数 a, b ：

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y.$$

证明：

由函数期望定理和重期望：

$$\mathbb{E}[aX + bY] = \iint (ax + by) f_{XY}(x, y) dx dy.$$

分离积分：

$$= a \iint x f_{XY}(x, y) dx dy + b \iint y f_{XY}(x, y) dx dy = a\mathbb{E}X + b\mathbb{E}Y.$$

关键点：无需 X, Y 独立！线性性对所有随机变量都成立，无论它们是否相关。

推论：对 iid $X_1, \dots, X_n$ ， $\mathbb{E}\bar{X} = \mathbb{E}X_1$ 。

由线性性：

$$\mathbb{E}\bar{X} = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \frac{1}{n} \cdot n\mathbb{E}X_1 = \mathbb{E}X_1.$$

11.11. 方差公式的推导. 背景：方差度量随机变量偏离其均值的程度。

定义： $\text{var}(X) = \mathbb{E}[(X - \mu)^2]$ ，其中 $\mu = \mathbb{E}X$ 。

计算公式： $\text{var}(X) = \mathbb{E}(X^2) - \mu^2$ 。

推导：

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2 - 2\mu X + \mu^2] = \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - 2\mu^2 + \mu^2 = \mathbb{E}(X^2) - \mu^2.$$

方差性质：

(1) $\text{var}(aX + b) = a^2\text{var}(X)$ （尺度变换）

(2) 若 $X \perp Y$: $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y)$

第二点的证明: 若 X, Y 独立,

$$\text{var}(X+Y) = \mathbb{E}[(X+Y)^2] - [\mathbb{E}(X+Y)]^2 = \mathbb{E}(X^2) + 2\mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(Y^2) - \mu_X^2 - 2\mu_X\mu_Y - \mu_Y^2 = \text{var}(X) + \text{var}(Y)$$

注意: 独立性条件不可少! 若 $X = Y$, 则 $\text{var}(X + Y) = \text{var}(2X) = 4\text{var}(X) \neq 2\text{var}(X)$ 。

11.12. Markov 不等式的证明. 定理: 若 $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}.$$

证明:

设事件 $A = \{g(X) \geq a\}$, 则 $g(X) \geq a \cdot \mathbb{I}_A$ (因为在 A 上 $g(X) \geq a$, 在 A^c 上 $g(X) \geq 0$)。

取期望:

$$\mathbb{E}[g(X)] \geq \mathbb{E}[a \cdot \mathbb{I}_A] = a \cdot \mathbb{P}(A) = a \cdot \mathbb{P}(g(X) \geq a).$$

两边除以 $a > 0$ 得证。

意义: Markov 不等式仅用一阶矩 (期望) 就能给出概率上界, 不依赖分布的具体形式。当然, 上界可能很松——例如对正态分布, $\mathbb{P}(|X| \geq 2\sigma)$ 的真实值约为 0.05, 而 Markov 上界给出的是 1/4。

特例: 取 $g(X) = (X - \mu)^2$, $a = k^2$, 得 Chebyshev 不等式:

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\text{var}(X)}{k^2}.$$

11.13. Cauchy-Schwarz 不等式的证明. 定理: 对任意随机变量 X, Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}.$$

证明:

考虑 $\mathbb{E}[(tX - Y)^2] \geq 0$ 对任意实数 t 成立。

展开:

$$0 \leq \mathbb{E}[t^2 X^2 - 2tXY + Y^2] = t^2 \mathbb{E}(X^2) - 2t \mathbb{E}(XY) + \mathbb{E}(Y^2).$$

这是关于 t 的二次不等式, 其判别式必须非正:

$$[2\mathbb{E}(XY)]^2 - 4\mathbb{E}(X^2)\mathbb{E}(Y^2) \leq 0.$$

整理得:

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}.$$

应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。

设 $X^* = X - \mu_X$, $Y^* = Y - \mu_Y$, 则

$$|\text{corr}(X, Y)| = \frac{|\mathbb{E}(X^*Y^*)|}{\sqrt{\text{var}(X)\text{var}(Y)}} \leq \frac{\sqrt{\mathbb{E}(X^{*2})\mathbb{E}(Y^{*2})}}{\sqrt{\text{var}(X)\text{var}(Y)}} = 1.$$

11.14. Jensen 不等式的证明. 定理：若 g 是凸函数， X 的期望存在，则

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}X).$$

证明（使用凸函数的支撑超平面）：

由凸函数的性质，对任意 x_0 ，存在支撑线 $L(x) = g(x_0) + c(x - x_0)$ 使得 $g(x) \geq L(x)$ 对所有 x 成立。

取 $x_0 = \mathbb{E}X$ ，则 $g(x) \geq g(\mathbb{E}X) + c(x - \mathbb{E}X)$ 。

取期望：

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}X) + c\mathbb{E}(X - \mathbb{E}X) = g(\mathbb{E}X) + c \cdot 0 = g(\mathbb{E}X).$$

特例：

- $g(x) = x^2$ (凸)： $\mathbb{E}(X^2) \geq (\mathbb{E}X)^2$
- $g(x) = e^x$ (凸)： $\mathbb{E}(e^X) \geq e^{\mathbb{E}X}$

第二个特例说明：指数函数的期望大于等于期望的指数——这在金融中用于证明“彩票溢价”现象。

CHAPTER 2

多元随机变量及其分布

Chapter 2 概述

在一元情形，我们用 cdf $F_X(x) = \mathbb{P}(X \leq x)$ 描述单个随机变量的行为。但在许多场景中，单个变量的分布并不能回答我们的问题——我们需要知道多个变量如何共同变化。

为什么需要联合分布？ 例如，在经济学中，我们关心收入与教育年限的共同分布；在医学中，我们关心血压与胆固醇的联合水平；在金融中，资产收益率之间的相关性是风险管理的核心。这些问题都涉及多个随机变量的联合行为。

统计推断的核心任务——从样本推断总体——本质上也是多元的：样本是多个观测值的向量，而统计量是这些观测值的函数。第 4 章将看到，点估计、置信区间、假设检验全部建立在多元分布理论之上。

本章路线图： 联合分布 $\rightarrow$ 边缘分布 $\rightarrow$ 条件分布 $\rightarrow$ 独立性 $\rightarrow$ 相关性 $\rightarrow$ 多元正态 $\rightarrow$ 多元推广

1. 2.1 从一元到多元：联合分布

1.1. 为什么需要联合分布？ 在一元情形，我们学会了用 cdf、pmf/pdf 描述单个随机变量的行为。但在真实世界中，变量很少孤立存在。

核心问题： 给定两个随机变量 X_1 和 X_2 ，如何描述它们的联合行为？

例如，设 X_1 为身高， X_2 为体重。知道身高分布和体重分布当然有用，但知道两者如何“共同变化”——高个子是否倾向于更重——显然更有价值。这种“共同变化”的数学表达，正是联合分布。

历史注记： 多元分析的思想可以追溯到 Francis Galton (1822-1911) 的工作。他研究遗传问题时发现，单个特征的分布不足以描述遗传规律——必须考虑特征之间的相关性。他发明的“相关系数” (correlation coefficient) 正是本章的核心概念之一。

1.2. 随机向量与联合分布.

DEFINITION 2.1 (随机向量). 设样本空间为 $\mathcal{C}$ ， X_1 和 X_2 为定义在 $\mathcal{C}$ 上的两个随机变量。则 (X_1, X_2) 称为随机向量，其取值空间为 $\mathcal{D} = \{(x_1, x_2) : x_1 = X_1(c), x_2 = X_2(c), c \in \mathcal{C}\}$ 。

联合 cdf 是一元 cdf 的自然推广：

$$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2). \quad (1)$$

注意：这里的“且” ($,$) 表示两个事件同时发生。