

数理统计导论

Hogg, McKean, Craig

目录

引言：从随机性中学习	7
引言：从随机性中学习	7
1. 为什么需要概率论?	7
2. 教材内容预览	7
3. 这三章的内在逻辑	10
4. 学习方法建议	10
5. 习题说明	11
Chapter 1. Probability and Distributions	13
Chapter 1 Overview	13
1. 1.1 Introduction: Why Probability Theory?	13
2. 1.2 Sets: The Language of Uncertainty	14
3. 1.3 The Probability Set Function	15
4. 1.4 Conditional Probability and Independence	15
5. 1.5 Random Variables	17
6. 1.6 Discrete Random Variables	17
7. 1.7 Continuous Random Variables	19
8. 1.8 Expectation of a Random Variable	21
9. 1.9 Some Special Expectations	22
10. 1.10 Important Inequalities	24
Summary	25
Exercises	25
11. 附录：公式推导	27
Chapter 2. 多元随机变量及其分布	35
Chapter 2 概述	35
1. 2.1 从一元到多元：联合分布	35
2. 2.2 边缘分布：积分即求和	37
3. 2.3 条件分布：信息的价值	39
4. 2.4 独立性：变量间的”无关系”	45
5. 2.5 相关性：线性关联的度量	48
6. 2.6 二元正态：最重要的二元分布	50
7. 2.7 多元推广	52

8. 本章总结	54
习题	54
9. 附录：公式推导	55
Chapter 3. Special Distributions	67
Chapter 3 Overview	67
1. 3.1 二项分布及其相关分布	67
2. 3.2 Poisson 分布	72
3. 3.3 Gamma、 χ^2 与 Beta 分布	74
4. 3.4 正态分布 (Normal Distribution)	77
5. 3.5 多元正态分布	78
6. 3.6 t 分布与 F 分布	79
本章小结	81
习题	81
7. 附录：公式推导	90
Chapter 4. Some Elementary Statistical Inferences	97
Chapter 4 Overview	97
1. 4.1 Sampling and Statistics	97
2. 4.2 Confidence Intervals	100
3. 4.3 Order Statistics	101
4. 4.4 Hypothesis Testing	102
5. 4.5 Chi-Square Tests	103
6. 4.6 Monte Carlo Methods	106
7. 4.7 Bootstrap Methods	107
Exercises	107
本章小结	122
8. 附录：公式推导	122
Chapter 5. Asymptotic Theory	129
Chapter 5 Overview	129
1. 5.1 Convergence in Probability	129
2. 5.2 Convergence in Distribution	132
3. 5.3 Central Limit Theorem	136
4. 5.4 Extensions to Multivariate Distributions	137
Exercises	138
本章小结	142
5. 附录：公式推导	142
Chapter 6. Maximum Likelihood Methods	151
Chapter 6 Overview	151

1. 6.1 Maximum Likelihood Estimation	151
2. 6.2 Rao-Cramér Lower Bound and Efficiency	153
3. 6.3 Maximum Likelihood Tests	157
4. 6.4 Multiparameter Case: Estimation	158
5. 6.5 Multiparameter Case: Testing	161
6. 6.6 The EM Algorithm	162
7. 附录：公式推导	176
Chapter 7. Sufficiency and Quality of Estimators	181
Chapter 7 Overview	181
1. 7.1 Measures of Quality of Estimators	181
2. 7.1 Measures of Quality of Estimators —Exercises	182
3. 7.2 A Sufficient Statistic for a Parameter	184
4. 7.3 Properties of a Sufficient Statistic	186
5. 7.4 Completeness and Uniqueness	187
6. 7.5 The Exponential Class of Distributions	189
7. 7.6 Functions of a Parameter	190
8. 7.7 The Case of Several Parameters	191
9. 7.8 Minimal Sufficiency and Ancillary Statistics	193
10. 7.9 Sufficiency, Completeness, and Independence	194
本章习题	196
11. 7.7 The Case of Several Parameters —Exercises	203
12. 7.9 Sufficiency, Completeness, and Independence —Exercises	205
Chapter 8. Optimal Statistical Tests	207
Chapter 8 Overview	207
1. 8.1 Most Powerful Tests	207
2. 8.2 Uniformly Most Powerful Tests	211
3. 8.3 Likelihood Ratio Tests	213
4. 8.4 *Sequential Probability Ratio Test	216
5. 8.5 *Minimax and Classification Procedures	218
附录：公式推导	220
Exercises	222
Chapter 9. ANOVA and Regression	233
Chapter 9 Overview	233
1. 9.1 Introduction	233
2. 9.2 One-Way ANOVA	234
3. 9.3 Noncentral χ^2 and F Distributions	235
4. 9.4 Multiple Comparisons	236

5. 9.5 Two-Way ANOVA	237
6. 9.6 A Regression Problem	238
7. 9.7 A Test of Independence	240
8. 9.8 Distributions of Certain Quadratic Forms	240
9. 9.9 The Independence of Certain Quadratic Forms	241
习题	241
附录：公式推导	251
1. 问答记录	268

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分的类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 notation，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 Overview

本章从概率论的公理化基础出发，逐步建立整套理论框架。这条脉络贯穿本书始终——理解随机现象的本质、建立描述分布的工具、掌握期望与矩的计算。

为什么从概率论开始？ 因为统计学的一切推断都建立在概率论的基础上。如果不理解概率的数学本质，就无法真正理解统计推断的逻辑。

本章路线图： 随机现象 → 概率公理 → 条件概率与独立性 → 随机变量 → 离散/连续分布 → 期望与矩 → 矩母函数 → 重要不等式

1. 1.1 Introduction: Why Probability Theory?

1.1. The Genesis of Probability. 概率论的故事始于一场赌博。1654 年，赌徒 Chevalier de Méré 向数学家 Blaise Pascal 提出一个问题：如果两名玩家在赌局中途中断，如何公平地分配赌金？这个问题引发了 Pascal 与 Pierre de Fermat 的通信，从而奠定了概率论的基础。

从频率到概率： 设想进行 N 次重复实验。事件 A 发生的次数记为 $f_N(A)$ ，则 $f_N(A)/N$ 称为相对频率 (relative frequency)。当 N 增大时， $f_N(A)/N$ 趋于稳定，趋向某个数 p ——这正是事件 A 的概率。Kolmogorov 在 1933 年的开创性著作《概率论基础》中将这种直觉严格化，建立了现代概率论的公理化体系。

两派观点： 概率的相对频率解释依赖于实验可重复的条件。另一种观点——贝叶斯学派——将概率视为主观信念的度量。无论采用哪种解释，概率的数学性质（公理）都是一致的，因此我们可以在坚实的数学基础上统一处理。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. Random Experiments and Sample Spaces. 若一个实验可以在相同条件下重复进行，且所有可能的结果可以在实验前描述，我们就称其为随机实验 (random experiment)。

所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

这三个例子揭示了样本空间的三种类型：离散有限（硬币）、离散无限（骰子）、连续（等待时间）。理解样本空间的类型决定了我们使用离散还是连续的数学工具。

EXAMPLE 1.1 (Coin Toss). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (Two Dice). 投掷一枚红骰子和一枚白骰子。样本空间包含 36 个有序对: $\mathcal{C} = \{(1, 1), (1, 2), \dots, (6, 6)\}$ 。

EXAMPLE 1.3 (Continuous Sample Space). 等待地铁到达的时间。样本空间为 $\mathcal{C} = (0, \infty)$ ——这是一个连续不可数的集合。

事件是样本空间的子集。如果一个实验进行一次, 事件 A 要么发生, 要么不发生, 没有第三种可能。概率论正是描述这种不确定性的数学语言。

2. 1.2 Sets: The Language of Uncertainty

2.1. Why Do We Need Set Theory for Probability? 在概率论中, 事件 (event) 本质上就是样本空间的子集。为什么要用集合的语言? 因为集合运算 (并、交、补) 完美地对应了事件的逻辑运算 (“或”、“且”、“非”)。

德摩根定律 (De Morgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c. \quad (1.2.1)$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C). \quad (1.2.2)$$

这些看似简单的定律, 在概率计算中非常有用。例如, 要计算 “既不是 A 也不是 B ” 的概率, 我们可以直接使用德摩根定律: $\mathbb{P}((A \cup B)^c) = \mathbb{P}(A^c \cap B^c)$ 。

2.2. Key Set Operations. 设 $\mathcal{C}$ 为样本空间, A, B, C 为事件:

- **补集** A^c : 所有不在 A 中的元素
- **并集** $A \cup B$: 至少在 A 或 B 之一中的元素
- **交集** $A \cap B$: 同时在 A 和 B 中的元素
- **不交** $A \cap B = \phi$: A 和 B 互不相容

EXAMPLE 1.4 (Set Operations). 设 $\mathcal{C} = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。

则 $A^c = \{3, 4, \dots, 10\}$, $A \cup B = \{1, 2, 3, 4\}$, $A \cap B = \{2\}$, $A \cap C = \phi$, $B \cap C = \{3, 4\}$ 。

2.3. Countable and Uncountable Sets. 若集合 C 是有限的, 或与正整数集等势, 则称 C 为可数的 (countable)。

可数并: $\cup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}$

可数交: $\cap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \cup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \cap_{n=1}^{\infty} A_n$ 。

3. 1.3 The Probability Set Function

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。

概率必须满足：

- (1) 非负性： $\mathbb{P}(A) \geq 0$
- (2) 规范化： $\mathbb{P}(\mathcal{C}) = 1$
- (3) 可数可加性：若 $A_1, A_2, \dots$ 两两不交，则 $\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$

REMARK. **概率公理的直观含义**：非负性说明概率不能为负；规范化说明必然事件的概率为 1；可数可加性说明互不相容事件的并的概率等于各自概率之和。

从这三条公理可以推导出概率的所有其他性质。¹

REMARK. **定理 1.3.1**：对每个事件 A ， $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ 。

证明：由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$ ，结合公理得

$$1 = \mathbb{P}(\mathcal{C}) = \mathbb{P}(A) + \mathbb{P}(A^c).$$

布尔不等式：对任意事件 $A_1, \dots, A_n$ ，

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i). \quad (1.3.1)$$

这在估计复合事件概率时非常有用——当精确计算困难时，布尔不等式提供了一个上界。

REMARK. **等可能性情形**：若样本空间 $\mathcal{C} = \{x_1, x_2, \dots, x_m\}$ 有限，且每个 *outcome* 等概率，则

$$\mathbb{P}(A) = \frac{\#(A)}{m}. \quad (1.3.2)$$

EXAMPLE 1.5 (扑克牌概率). 从 52 张扑克牌中随机抽取一张。设 $A =$ ”抽到 A ”， $B =$ ”抽到红桃”。则

$$\mathbb{P}(A) = \frac{4}{52}, \quad \mathbb{P}(B) = \frac{13}{52}, \quad \mathbb{P}(A \cap B) = \frac{1}{52}.$$

由容斥原理，

$$\mathbb{P}(A \cup B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52} = \frac{4}{13}.$$

4. 1.4 Conditional Probability and Independence

条件概率是概率论中最重要的概念之一。它描述了在已知某些信息发生的条件下，如何更新我们对其他事件概率的判断。

REMARK. **定义 1.4.1 (条件概率)**：设 $\mathbb{P}(B) > 0$ ，在事件 B 已发生的条件下，事件 A 的条件概率定义为

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}. \quad (1.4.1)$$

¹详细推导见附录 ??。

条件概率满足概率的三条公理——它是一种新的概率度量，样本空间缩小为 B 。

乘法法则：

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) = \mathbb{P}(B) \cdot \mathbb{P}(A | B). \quad (1.4.2)$$

推广到 n 个事件：

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right). \quad (1.4.3)$$

REMARK. **全概率公式：** 设 $\{B_i\}$ 为 C 的一个划分，则对任意事件 A ,

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i). \quad (1.4.4)$$

REMARK. **贝叶斯公式：**

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i)}. \quad (1.4.5)$$

术语：

- $\mathbb{P}(B_j)$: 先验概率 (*prior probability*) ——在观测到 A 之前我们对 B_j 的信念
- $\mathbb{P}(B_j | A)$: 后验概率 (*posterior probability*) ——在观测到 A 之后我们对 B_j 的更新信念
- $\mathbb{P}(A | B_j)$: 似然 (*likelihood*) ——在 B_j 成立的条件下观测到 A 的概率

贝叶斯公式不仅是一个计算工具，更提供了一种思考不确定性的思维方式。²

EXAMPLE 1.6 (医学检测). 设某疾病患病率为 1%，检测准确率为 99%。令 $D =$ “患病”， $+$ = “检测阳性”。

即使检测准确率高达 99%，检测阳性者真正患病的概率只有 50%!

这个违反直觉的结果说明：在疾病罕见的情况下，即使非常准确的检测也可能产生大量假阳性。³

4.1. 1.4.1 Independence.

REMARK. **定义 1.4.2 (独立性)：** 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，则称 A 与 B 相互独立，记作 $A \perp B$ 。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时，独立性等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$ ——知道 B 发生并不改变 A 的概率。

EXAMPLE 1.7 (独立硬币). 抛掷两枚独立硬币。设 $A =$ “第一枚正面朝上”， $B =$ “第二枚正面朝上”。则 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$ ，且 $\mathbb{P}(A \cap B) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B)$ ，故 $A \perp B$ 。

WARNING: 两两独立 (pairwise independent) 不一定意味着相互独立!⁴

²贝叶斯公式的深层意义见附录 ??。

³详细计算见附录 ??。

⁴反例见附录 ??。

5. 1.5 Random Variables

样本空间的元素可能不是数字——随机变量正是将样本空间数值化的工具。

REMARK. 定义 1.5.1 (随机变量): 随机变量是从样本空间 $\mathcal{C}$ 到实数的函数: $X: \mathcal{C} \rightarrow \mathbb{R}$ 。

通常用大写字母 X, Y, Z 表示随机变量, 用小写字母 x, y, z 表示具体取值。

随机变量可分为:

- 离散随机变量: 取值可数 (有限或无限)
- 连续随机变量: 取值充满区间, 不可数

给定随机变量 X , 它的取值空间 $\mathcal{D}$ 成为新的样本空间。 X 不仅诱导了新的样本空间, 还诱导了一个概率分布——这正是”分布”概念的起源。

EXAMPLE 1.8 (硬币投掷). 抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$ 。定义 X 为正面出现的次数: $X(HH) = 2, X(HT) = X(TH) = 1, X(TT) = 0$ 。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。

EXAMPLE 1.9 (均匀选择). 从区间 $(0, 1)$ 中随机选择一个数 X 。 X 是连续随机变量, 取值充满 $(0, 1)$ 。

5.1. Cumulative Distribution Function.

REMARK. 定义 1.5.2 (CDF): $F_X(x) = \mathbb{P}(X \leq x), -\infty < x < \infty$ 。

CDF 满足:

- (1) 非递减: 若 $x_1 < x_2$, 则 $F_X(x_1) \leq F_X(x_2)$
- (2) $\lim_{x \rightarrow -\infty} F_X(x) = 0, \lim_{x \rightarrow \infty} F_X(x) = 1$
- (3) 右连续: $F_X(x) = \lim_{t \rightarrow x^+} F_X(t)$

从 CDF 计算概率:

$$\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a). \quad (1.5.1)$$

关键洞察: 对连续随机变量, $\mathbb{P}(X = x) = 0$, 因此

$$\mathbb{P}(a < X < b) = \mathbb{P}(a \leq X \leq b) = F(b) - F(a). \quad (1.5.2)$$

6. 1.6 Discrete Random Variables

离散随机变量的取值是可数的。

REMARK. 定义 1.6.1 (pmf): $p_X(x) = \mathbb{P}(X = x)$ 。

pmf 满足: $p_X(x) \geq 0$ 对所有 x , 且 $\sum_x p_X(x) = 1$ 。

6.1. 1.6.1 Common Discrete Distributions. 伯努利分布 $X \sim \text{Bernoulli}(p)$:

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p. \quad (1.6.1)$$

二项分布 $X \sim \text{Bin}(n, p)$:

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n. \quad (1.6.2)$$

EXAMPLE 1.10 (二项分布). 抛掷一枚均匀硬币 10 次。设 X 为正面出现的次数。则 $X \sim \text{Bin}(10, 0.5)$,

$$\mathbb{P}(X = 3) = \binom{10}{3} (0.5)^3 (0.5)^7 = \frac{120}{1024} \approx 0.117.$$

几何分布 $X \sim \text{Geom}(p)$:

$$\mathbb{P}(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, 3, \dots \quad (1.6.3)$$

几何分布具有“无记忆性”——等待时间不受过去等待的影响。⁵

EXAMPLE 1.11 (几何分布). 抛掷一枚均匀硬币直到第一次出现正面。设 X 为抛掷次数。则 $X \sim \text{Geom}(0.5)$,

$$\mathbb{P}(X = 3) = (0.5)^2 \cdot 0.5 = \frac{1}{8}.$$

泊松分布 $X \sim \text{Poisson}(\lambda)$:

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots \quad (1.6.4)$$

泊松分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限分布。⁶

这揭示了离散分布之间的深刻联系——泊松分布作为稀有事件的模型具有重要意义。

EXAMPLE 1.12 (泊松分布). 某医院每小时接到的急诊电话数服从泊松分布，均值 $\lambda = 3$ 。则

$$\mathbb{P}(\text{每小时接到 5 个电话}) = \frac{3^5 e^{-3}}{5!} \approx 0.101.$$

超几何分布 $X \sim \text{Hypergeometric}(N, K, n)$:

$$\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}. \quad (1.6.5)$$

这是从有限总体中无放回抽样的模型。

EXAMPLE 1.13 (超几何分布). 一个盒子中有 20 个红球和 80 个白球 (共 100 个)。从中抽取 5 个 (无放回)。令 X 为抽到的红球数。则

$$\mathbb{P}(X = 2) = \frac{\binom{20}{2} \binom{80}{3}}{\binom{100}{5}}.$$

⁵详细证明见附录 ??。

⁶详细推导见附录 ??。

6.2. 1.6.2 Transformations of Discrete Random Variables. 在统计中, 我们经常需要对一个随机变量进行变换: $Y = g(X)$ 。

一对一变换: 若 g 是一一对应的, 则

$$p_Y(y) = p_X(g^{-1}(y)). \quad (1.6.6)$$

非一对一变换: 需要合并所有映射到相同 y 的 x 的概率。

EXAMPLE 1.14 (离散变换). 设 $X \sim \text{Geom}(0.5)$, $Y = X^2$ 。因为 $g(x) = x^2$ 在 $\{1, 2, 3, \dots\}$ 上是一一对应的 (没有负数),

$$p_Y(y) = p_X(\sqrt{y}) = (0.5)^{\sqrt{y}+1}, \quad y = 1, 4, 9, \dots$$

7. 1.7 Continuous Random Variables

连续随机变量的取值充满一个或多个区间, 不可数。

REMARK. **定义 1.7.1 (连续随机变量):** 若随机变量 X 的 *cdf* $F_X(x)$ 对所有 x 都连续, 则称 X 为连续随机变量。

对连续随机变量, $\mathbb{P}(X = x) = 0$ 对所有 x ——这意味着单点概率为零。

REMARK. **定义 1.7.2 (pdf):** 若存在非负函数 $f_X(x)$ 使得

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x) dx$$

对任意 $a < b$ 成立, 则称 $f_X(x)$ 为 *pdf*。

pdf 满足: $f_X(x) \geq 0$ 对所有 x , 且 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。

WARNING: $f_X(x)$ 可以大于 1! 这与 *pmf* 的 $p_X(x) \leq 1$ 形成对比。pdf 的值不是概率, 而是概率密度——只有积分才是概率。

EXAMPLE 1.15 (均匀分布). 从区间 $(0, 1)$ 中随机选择一个数 X 。则 $X \sim \text{Uniform}(0, 1)$,

$$f_X(x) = \begin{cases} 1 & 0 < x < 1 \\ 0 & \text{otherwise} \end{cases}$$

EXAMPLE 1.16 (单位圆内的随机点). 在单位圆内随机选择一个点。设 X 为该点到原点的距离。则 X 的 *cdf* 为 $F_X(x) = x^2$, $0 \leq x \leq 1$ 。因此 *pdf* 为 $f_X(x) = 2x$, $0 < x < 1$ 。

EXAMPLE 1.17 (指数分布). 电话呼叫间隔时间 X 服从指数分布, *pdf* 为

$$f_X(x) = \frac{1}{4}e^{-x/4}, \quad x > 0.$$

则 $\mathbb{P}(X > 4) = \int_4^{\infty} \frac{1}{4}e^{-x/4} dx = e^{-1} \approx 0.368$ 。

指数分布也具有无记忆性。⁷

⁷详细讨论见附录 ??。

正态分布 $X \sim N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \quad (1.7.1)$$

正态分布是统计学中最重要的分布——这将在第三章详细讨论。

7.1. 1.7.1 Quantiles. 分位数是分布的重要特征。

REMARK. 定义 1.7.3 (分位数): 设 $0 < p < 1$. 分布的 $100p\%$ 分位数 ξ_p 满足

$$\mathbb{P}(X < \xi_p) \leq p \quad \text{且} \quad \mathbb{P}(X \leq \xi_p) \geq p. \quad (1.7.2)$$

特殊分位数:

- 中位数 (*median*): $\xi_{0.5}$
- 第一四分位数: $\xi_{0.25}$
- 第三四分位数: $\xi_{0.75}$

四分位距 (*IQR*): $q_3 - q_1$, 是衡量离散程度的稳健指标。

若 X 连续且 F_X 严格递增, 则 $\xi_p = F_X^{-1}(p)$ 。

偏度 (*Skewness*): 描述分布的不对称程度。

- 右偏 (*positively skewed*): 右尾较长, 如指数分布
- 左偏 (*negatively skewed*): 左尾较长
- 对称 (*symmetric*): 如正态分布

7.2. 1.7.2 Transformations of Continuous Random Variables. 设 X 是连续随机变量, $f_X(x)$ 已知。我们想知道 $Y = g(X)$ 的分布。

CDF 法: 先求 $F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y)$, 然后求导得 $f_Y(y) = \frac{d}{dy}F_Y(y)$ 。

EXAMPLE 1.18 (连续变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = X^2$ 。则对 $0 < y < 1$,

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X^2 \leq y) = \mathbb{P}(X \leq \sqrt{y}) = \sqrt{y}.$$

因此 $f_Y(y) = \frac{1}{2\sqrt{y}}$, $0 < y < 1$ 。

——变换公式: 若 $y = g(x)$ 是一一对应且可导的, $x = g^{-1}(y)$, 则

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy}g^{-1}(y) \right|, \quad y \in \mathcal{S}_Y. \quad (1.7.3)$$

这里 $\left| \frac{dx}{dy} \right|$ 称为雅可比 (Jacobian)。

EXAMPLE 1.19 (对数变换). 设 $X \sim \text{Uniform}(0, 1)$, $Y = -\log X$ 。则 $x = e^{-y}$, $dx/dy = -e^{-y}$ 。因此

$$f_Y(y) = 1 \cdot |-e^{-y}| = e^{-y}, \quad y > 0.$$

即 $Y \sim \text{Exp}(1)$ 。

这提供了从均匀分布生成指数分布的方法——逆变换采样 (*inverse transform sampling*) 的基础。⁸

⁸逆变换采样的详细讨论见第四章。

变换公式的证明：⁹

7.3. 1.7.3 Mixture Distributions. 有些分布既不是纯离散的，也不是纯连续的，而是两者的混合。

EXAMPLE 1.20 (混合分布). 设 X 的 cdf 为

$$F(x) = \begin{cases} 0 & x < 0 \\ \frac{x+1}{2} & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases}$$

则 $\mathbb{P}(X=0) = 1/2$ ，且对 $0 < x < 1$ ， $\mathbb{P}(0 < X < x) = x/2$ 。这是一个离散-连续混合分布。

这种分布在实际中经常出现，例如：

- 删失数据 (*censored data*)
- 保险中的限额保单

8. 1.8 Expectation of a Random Variable

期望是随机变量最重要的一致性度量。它描述了分布的”中心位置”。

REMARK. 定义 1.8.1 (数学期望):

- 离散型: $\mathbb{E}X = \sum x \cdot p_X(x)$
- 连续型: $\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$

要求级数或积分绝对收敛，即 $\mathbb{E}|X| < \infty$ 。

期望的起源：在赌博游戏中，”期望”(expectation)一词来源于玩家对游戏收益的长期平均预期。

公平游戏：若 $\mathbb{E}(G) = 0$ ，则游戏是公平的 (fair game)。

EXAMPLE 1.21 (骰子期望). 设 X 为掷骰子的点数。则 $\mathbb{E}X = \frac{1}{6}(1+2+3+4+5+6) = 3.5$ 。

REMARK. 函数期望定理: 设 $Y = g(X)$ 。则

- 离散型: $\mathbb{E}Y = \sum g(x) \cdot p_X(x)$
- 连续型: $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx$

重要含义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！¹⁰

期望的线性性是概率论中最重要、最有用的性质之一。¹¹

⁹详细推导见附录 ??。

¹⁰详细证明见附录 ??。

¹¹详细证明见附录 ??。

REMARK. 定理 1.8.1 (期望的线性性): 对任意随机变量 X, Y (期望存在) 和常数 a, b :

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y. \quad (1.8.1)$$

关键点: 无需 X, Y 相互独立!

EXAMPLE 1.22 (样本均值). 设 $X_1, \dots, X_n$ 是独立同分布的随机变量, $\mathbb{E}X_i = \mu$ 。则样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 的期望为

$$\mathbb{E}\bar{X} = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \mu.$$

这说明样本均值是总体均值的无偏估计!¹²

乘积期望: 一般情况下 $\mathbb{E}(XY) \neq \mathbb{E}X \cdot \mathbb{E}Y$ 。只有当 X 和 Y 独立时, 等式才成立。

EXAMPLE 1.23 (乘积期望). 设 X 和 Y 是区间 $(0, 1)$ 上的均匀分布, 但 $Y = X$ (完全相关)。则 $\mathbb{E}(XY) = \mathbb{E}(X^2) = 1/3$, 而 $\mathbb{E}X \cdot \mathbb{E}Y = 1/4$, 两者不相等。

方差度量分布的离散程度。¹³

REMARK. 定理 1.8.2 (方差公式):

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}(X^2) - \mu^2. \quad (1.8.2)$$

方差性质:

$$(1) \text{var}(aX + b) = a^2 \text{var}(X)$$

$$(2) \text{若 } X_1, \dots, X_n \text{ 相互独立, 则 } \text{var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{var}(X_i)$$

9. 1.9 Some Special Expectations

某些期望具有特殊名称和重要意义。

9.1. Moments.

REMARK. 定义 1.9.1 (矩):

- k 阶原点矩: $\mu'_k = \mathbb{E}(X^k)$
- k 阶中心矩: $\mu_k = \mathbb{E}[(X - \mu)^k]$

一阶原点矩 $\mu'_1 = \mathbb{E}X$ 就是均值。

均值 (Mean): $\mu = \mathbb{E}X$ 是分布的中心位置度量。

方差 (Variance): $\sigma^2 = \text{var}(X)$ 度量分布的离散程度。

标准差 (Standard Deviation): $\sigma = \sqrt{\text{var}(X)}$, 与 X 具有相同单位。

变异系数 (CV): $\text{CV} = \sigma/\mu$, 是无量纲的离散程度度量。

偏度系数: $\gamma_1 = \mathbb{E}[(X - \mu)^3]/\sigma^3$, 衡量分布的不对称程度。

峰度系数: $\gamma_2 = \mathbb{E}[(X - \mu)^4]/\sigma^4 - 3$, 衡量分布尾部的厚重程度。

¹²这将在第四章统计推断中发挥核心作用。

¹³详细推导见附录 ??。

EXAMPLE 1.24 (均匀分布的矩). 设 $X \sim \text{Uniform}(-a, a)$ 。则

$$\mu = 0, \quad \text{var}(X) = \frac{a^2}{3}.$$

EXAMPLE 1.25 (指数分布的矩). 设 $X \sim \text{Exp}(\lambda)$ 。则

$$\mathbb{E}X = \frac{1}{\lambda}, \quad \text{var}(X) = \frac{1}{\lambda^2}.$$

9.2. Covariance and Correlation. 两个随机变量之间的”共同变化”程度，用协方差来度量。

REMARK. 定义 1.9.2 (协方差):

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y. \quad (1.9.1)$$

协方差性质:

- (1) $\text{cov}(X, X) = \text{var}(X)$
- (2) $\text{cov}(X, Y) = \text{cov}(Y, X)$
- (3) $\text{cov}(aX + b, Y) = a\text{cov}(X, Y)$
- (4) $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y)$
- (5) 若 $X \perp\!\!\!\perp Y$, 则 $\text{cov}(X, Y) = 0$

REMARK. 定义 1.9.3 (相关系数):

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}. \quad (1.9.2)$$

重要性质: $-1 \leq \text{corr}(X, Y) \leq 1$ 。

相关系数衡量两个变量之间的线性关系强度。

WARNING: 相关不等于因果! 两个变量相关可能是由于第三个隐藏变量导致的。

14

9.3. Moment Generating Function. 矩母函数是计算矩的强大工具。

REMARK. 定义 1.9.4 (矩母函数): 若对某个 $h > 0$,

$$M_X(t) = \mathbb{E}(e^{tX}) \quad \text{对 } -h < t < h \text{ 存在}, \quad (1.9.3)$$

则称 $M_X(t)$ 为 X 的矩母函数 (mgf)。

核心性质: 矩母函数唯一确定分布! 若两个随机变量的 mgf 相同, 则它们同分布。
为什么叫”矩母函数”? 因为

$$M_X^{(k)}(0) = \mathbb{E}(X^k). \quad (1.9.4)$$

这意味着如果我们有 mgf, 可以通过对它求导来获得所有矩!

¹⁴因果推断的讨论见本书因果推断部分。

EXAMPLE 1.26 (正态分布的 mgf). 设 $X \sim N(\mu, \sigma^2)$ 。则

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right).$$

特别地, $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - [M'(0)]^2 = \sigma^2$ 。

EXAMPLE 1.27 (泊松分布的 mgf). 设 $X \sim \text{Poisson}(\lambda)$ 。则

$$M_X(t) = \exp(\lambda(e^t - 1)).$$

mgf 的加法性质尤为重要: 若 $X_1, \dots, X_n$ 独立, 则

$$M_{X_1 + \dots + X_n}(t) = \prod_{i=1}^n M_{X_i}(t). \quad (1.9.5)$$

这提供了一种验证独立随机变量和的分布的方法。

10. 1.10 Important Inequalities

概率论中有几个基本不等式, 它们在理论证明和实际应用中都非常重要。

REMARK. 定理 1.10.1 (*Markov 不等式*): 若 X 为随机变量, $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}. \quad (1.10.1)$$

Markov 不等式的意义在于: 它仅用期望就能给出概率的上界, 而不需要知道分布的完整信息。¹⁵

REMARK. 定理 1.10.2 (*Chebyshev 不等式*): 设 $\mu = \mathbb{E}X$, $\sigma^2 = \text{var}(X)$ 。则对任意 $k > 0$,

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}. \quad (1.10.2)$$

Chebyshev 不等式告诉我们: 无论分布是什么, 至少 $1 - 1/k^2$ 的概率质量落在 $\mu \pm k\sigma$ 区间内。

EXAMPLE 1.28 (*Chebyshev 应用*). 设某考试成绩均值为 70, 标准差为 10。则根据 *Chebyshev* 不等式, 至少 75% 的学生成绩在 50 到 90 分之间。

Chebyshev 不等式虽然保守, 但在无法获知确切分布时是唯一可用的工具。它也是证明大数定律的关键工具。

REMARK. 定理 1.10.3 (*Cauchy-Schwarz 不等式*): 对于任意随机变量 X 和 Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}. \quad (1.10.3)$$

重要应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。¹⁶

Jensen 不等式: 若 g 是凸函数, 则 $\mathbb{E}[g(X)] \geq g(\mathbb{E}X)$ 。¹⁷

¹⁵详细证明见附录 ??。

¹⁶详细证明及更多应用见附录 ??。

¹⁷Jensen 不等式的证明及更多应用见附录 ??。

Summary

本章建立了概率论的基本框架，这些概念相互关联，共同构成了数理统计的基石：

- (1) **概率公理化** (1.3 节)：从相对频率的直观性质出发，建立了概率的严格数学定义
- (2) **条件概率与贝叶斯公式** (1.4 节)：提供了更新信息的数学工具，是统计推断的理论基础
- (3) **独立性** (1.4.1 节)：刻画了两个事件之间的概率关系
- (4) **随机变量** (1.5 节)：从集合论过渡到数值函数，为分布理论奠定基础
- (5) **离散与连续分布** (1.6-1.7 节)：建立了描述随机现象的主要分布类型 (Binomial, Poisson, Geometric, Normal, Exponential 等)
- (6) **变换与分位数** (1.6.2, 1.7.1-1.7.3 节)：提供了操作随机变量的技术工具
- (7) **期望与矩** (1.8-1.9 节)：分别度量分布的中心位置、离散程度和分布形状
- (8) **矩母函数** (1.9.3 节)：统一处理矩的强大工具，具有唯一性定理
- (9) **重要不等式** (1.10 节)：Markov、Chebyshev、Cauchy-Schwarz 是理论证明的基础工具

本章的核心思想：从随机现象出发，通过公理化定义建立概率论，用随机变量将样本空间数值化，然后用分布描述随机变量的行为，最后用期望等数字特征概括分布的关键性质。

与后续章节的联系：

- 第二章将概率论扩展到多个随机变量，研究联合分布、边缘分布、条件分布
- 第三章将详细介绍各种具体分布及其性质
- 第四章将利用这些工具进行统计推断（点估计、区间估计、假设检验）

Exercises

EXERCISE 1.1. 1.2.1 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$ ：

- (1) $C_1 = \{0, 1, 2\}$, $C_2 = \{2, 3, 4\}$
- (2) $C_1 = \{x : 0 < x < 2\}$, $C_2 = \{x : 1 \leq x < 3\}$

EXERCISE 1.2. 1.3.1 设 $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.4$, $\mathbb{P}(A \cap B) = 0.1$ 。求：

- (1) $\mathbb{P}(A \cup B)$
- (2) $\mathbb{P}(A | B)$
- (3) $\mathbb{P}(B | A)$

EXERCISE 1.3. 1.3.2 从 5 男 3 女中随机选 3 人。求恰好选到 2 名女生的概率。

EXERCISE 1.4. 1.4.1 某箱中有 5 个红球和 3 个白球。无放回地抽取 3 个球。求恰好抽到 2 个红球的概率。

EXERCISE 1.5. 1.4.2 设 A 和 B 是互不相容的事件， $\mathbb{P}(A) = 0.2$, $\mathbb{P}(B) = 0.3$ 。求 $\mathbb{P}(A \cup B)$ 、 $\mathbb{P}(A^c)$ 、 $\mathbb{P}((A \cup B)^c)$ 。

EXERCISE 1.6. 1.5.1 设 X 的 *cdf* 为

$$F(x) = \begin{cases} 0 & x < 0 \\ x/2 & 0 \leq x < 1 \\ 1/2 & 1 \leq x < 2 \\ 1 & x \geq 2 \end{cases}$$

求 $\mathbb{P}(0 < X \leq 1)$ 、 $\mathbb{P}(X = 1)$ 、 $\mathbb{P}(X > 1/2)$ 。

EXERCISE 1.7. 1.6.1 设 $X \sim \text{Binomial}(10, 0.3)$ 。求：

- (1) $\mathbb{P}(X = 3)$
- (2) $\mathbb{P}(X \geq 2)$
- (3) $\mathbb{E}X$

EXERCISE 1.8. 1.6.2 设 $X \sim \text{Poisson}(4)$ 。求 $\mathbb{P}(X = 0)$ 、 $\mathbb{P}(X \leq 2)$ 、 $\mathbb{E}X$ 。

EXERCISE 1.9. 1.6.3 设 $X \sim \text{Geometric}(0.4)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.10. 1.6.4 设 $X \sim \text{Binomial}(5, 0.5)$ ， $Y = X^2$ 。求 Y 的 *pmf*。

EXERCISE 1.11. 1.7.1 设 $X \sim N(100, 225)$ 。求：

- (1) $\mathbb{P}(X < 95)$
- (2) $\mathbb{P}(90 < X < 110)$
- (3) $\mathbb{P}(X > 115)$

EXERCISE 1.12. 1.7.2 设 $X \sim \text{Exp}(2)$ 。求：

- (1) $\mathbb{P}(X > 1)$
- (2) $\mathbb{P}(X < 0.5)$
- (3) 50% 分位数 (中位数)

EXERCISE 1.13. 1.7.3 设 $X \sim \text{Uniform}(0, 1)$ ， $Y = -\log X$ 。证明 $Y \sim \text{Exp}(1)$ 。

EXERCISE 1.14. 1.7.4 设 $X \sim N(0, 1)$ ， $Y = e^X$ 。求 Y 的 *pdf* (这是对数正态分布)。

EXERCISE 1.15. 1.8.1 设 X 的 *pdf* 为 $f(x) = 3x^2$ ， $0 < x < 1$ 。求 $\mathbb{E}X$ 、 $\mathbb{E}(X^2)$ 、 $\text{var}(X)$ 。

EXERCISE 1.16. 1.8.2 设 $X \sim \text{Poisson}(\lambda)$ 。求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

EXERCISE 1.17. 1.8.3 设 X 和 Y 是独立同分布的随机变量， $\mathbb{E}X = \mu$ ， $\text{var}(X) = \sigma^2$ 。求 $\text{var}(X - Y)$ 和 $\text{var}(X + Y)$ 。

EXERCISE 1.18. 1.9.1 设 $X \sim N(\mu, \sigma^2)$ 。求 X 的 *mgf*，并验证它产生正确的均值和方差。

EXERCISE 1.19. 1.9.2 设 X 和 Y 独立, $X \sim \text{Poisson}(2)$, $Y \sim \text{Poisson}(3)$ 。求 $X+Y$ 的分布。

EXERCISE 1.20. 1.10.1 设 $\mathbb{E}X = 100$, $\text{var}(X) = 25$ 。用 Chebyshev 不等式给出 $\mathbb{P}(|X - 100| \geq 10)$ 的上界, 并用 Markov 不等式给出另一个上界。

EXERCISE 1.21. 1.10.2 用 Cauchy-Schwarz 不等式证明: 若 $\mathbb{E}(X^2) = \mathbb{E}(Y^2) = 1$, 则 $|\mathbb{E}(XY)| \leq 1$ 。

11. 附录：公式推导

11.1. 概率公理的推导. 背景: 概率公理 (Kolmogorov, 1933) 为概率论奠定了严格数学基础。

目标: 从三条公理推导出概率的其他基本性质。

推导步骤:

性质 1: $\mathbb{P}(\phi) = 0$ 。

由公理 3, 令 $A_n = \phi$ 对所有 n , 则 $\cup_{n=1}^{\infty} A_n = \phi$, 故

$$\mathbb{P}(\phi) = \sum_{n=1}^{\infty} \mathbb{P}(\phi) = \mathbb{P}(\phi) + \sum_{n=2}^{\infty} \mathbb{P}(\phi).$$

两边减去 $\sum_{n=2}^{\infty} \mathbb{P}(\phi)$ 得 $\mathbb{P}(\phi) = 0$ 。

性质 2: 若 $A \subset B$, 则 $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$ 。

由 $B = A \cup (B \setminus A)$ 且 $A \cap (B \setminus A) = \phi$, 结合公理得

$$\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A).$$

性质 3: $\mathbb{P}(A) \leq 1$ 。

由 $A \subset C$ 和性质 2, $\mathbb{P}(A) \leq \mathbb{P}(C) = 1$ 。

性质 4 (容斥原理):

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B).$$

将 $A \cup B$ 写成不交并: $A \cup B = A \cup (B \setminus A)$, 再用公理。

布尔不等式: 对任意 $A_1, \dots, A_n$,

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbb{P}(A_i).$$

使用数学归纳法, 从容斥原理中去掉负项得到。

11.2. 贝叶斯公式的深层意义. 背景: 贝叶斯公式是更新信念的数学工具。

全概率公式是贝叶斯公式的基础:

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \mathbb{P}(A | B_i),$$

其中 $\{B_i\}$ 是样本空间的一个划分。

贝叶斯公式的直觉:

将条件概率公式 $\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j \cap A)}{\mathbb{P}(A)}$ 中的分子、分母分别展开：

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j)\mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i)\mathbb{P}(A | B_i)}.$$

先验到后验的更新机制：

- (1) 先验概率 $\mathbb{P}(B_j)$ ：观测数据前对假设的信念
- (2) 似然 $\mathbb{P}(A | B_j)$ ：在该假设下观测到数据的“可能性”
- (3) 归一化常数 $\sum_i \mathbb{P}(B_i)\mathbb{P}(A | B_i)$ ：确保后验概率之和为 1
- (4) 后验概率 $\mathbb{P}(B_j | A)$ ：观测数据后对假设的更新信念

贝叶斯公式的核心思想：用数据（通过似然）来更新先验信念，得到后验分布。这构成了贝叶斯统计的理论基础。

11.3. 医学检测假阳性详解. 问题设定：

- 疾病患病率： $\mathbb{P}(D) = 0.01$ （1%）
- 检测准确率： $\mathbb{P}(+ | D) = 0.99$ （患病者 99% 阳性）
- 误报率： $\mathbb{P}(+ | D^c) = 0.01$ （健康者 1% 阳性）

求解： $\mathbb{P}(D | +)$ ——检测阳性者真正患病的概率。

由贝叶斯公式：

$$\mathbb{P}(D | +) = \frac{\mathbb{P}(D)\mathbb{P}(+ | D)}{\mathbb{P}(D)\mathbb{P}(+ | D) + \mathbb{P}(D^c)\mathbb{P}(+ | D^c)}.$$

代入数值：

$$= \frac{0.01 \times 0.99}{0.01 \times 0.99 + 0.99 \times 0.01} = \frac{0.0099}{0.0099 + 0.0099} = \frac{0.0099}{0.0198} = 0.5.$$

直觉解释：即使检测准确率高达 99%，由于疾病非常罕见（1%），在所有阳性结果中，真阳性（ $0.01 \times 0.99 = 0.0099$ ）和假阳性（ $0.99 \times 0.01 = 0.0099$ ）的数量竟然相同！这说明在罕见事件检测中，**先验概率**（患病率）对后验概率有决定性影响。

11.4. 两两独立但不相互独立的反例. 背景：独立性是概率论中的重要概念，但两两独立不等于相互独立。

经典反例：掷两枚公平硬币，考虑以下四个事件：

- A ：第一枚硬币正面朝上
- B ：第二枚硬币正面朝上
- C ：两枚硬币结果相同（ HH 或 TT ）

验证两两独立：

- $\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = 1/2$
- $\mathbb{P}(A \cap B) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(A)\mathbb{P}(B)$
- $\mathbb{P}(A \cap C) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(A)\mathbb{P}(C)$
- $\mathbb{P}(B \cap C) = \mathbb{P}(HH) = 1/4 = \mathbb{P}(B)\mathbb{P}(C)$

但不相互独立：

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(HH) = 1/4 \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = 1/8.$$

这个例子说明：三个事件中，任意两个都独立，但三个放在一起就不独立了。

11.5. 几何分布无记忆性的证明. 背景：几何分布描述”直到第一次成功所需等待次数”的分布。

定义： $X \sim \text{Geom}(p)$, $\mathbb{P}(X = k) = (1-p)^{k-1}p$, $k = 1, 2, 3, \dots$

无记忆性：对任意 $m, n \geq 1$,

$$\mathbb{P}(X > m+n \mid X > m) = \mathbb{P}(X > n).$$

证明：

$$\mathbb{P}(X > m+n \mid X > m) = \frac{\mathbb{P}(X > m+n)}{\mathbb{P}(X > m)} = \frac{(1-p)^{m+n}}{(1-p)^m} = (1-p)^n = \mathbb{P}(X > n).$$

直观含义：如果已经等待了 m 次且没有成功，那么再等待 n 次的概率与”从头开始等待 n 次”的概率完全相同。过去的时间”被遗忘”了。

唯一性：无记忆性是几何分布的特征性质——离散支撑集 $\{1, 2, 3, \dots\}$ 上具有无记忆性的分布只有几何分布。

11.6. Poisson 近似二项分布的证明. 背景：Poisson 分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限。

定理：若 $X_n \sim \text{Bin}(n, p_n)$ ，且 $np_n \rightarrow \lambda$ ，则对任意固定 k ：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

证明：

二项分布式：

$$\mathbb{P}(X_n = k) = \frac{n(n-1)\cdots(n-k+1)}{k!} p_n^k (1-p_n)^{n-k}.$$

写成：

$$= \frac{n^k \left(1 - \frac{1}{n}\right) \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} + o(1).$$

当 $n \rightarrow \infty$ 时：

$$\begin{aligned} \left(1 - \frac{j}{n}\right) &\rightarrow 1 \quad \text{for fixed } j, \\ \left(1 - \frac{\lambda}{n}\right)^n &\rightarrow e^{-\lambda}, \\ \left(1 - \frac{\lambda}{n}\right)^{-k} &\rightarrow 1. \end{aligned}$$

因此：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} e^{-\lambda}.$$

实际意义：当 n 很大、 p 很小时，用 $\text{Poisson}(\lambda = np)$ 近似 $\text{Bin}(n, p)$ 可以大大简化计算。

11.7. 指数分布无记忆性的讨论. 背景：指数分布是连续版本的无记忆分布。

定义： $X \sim \text{Exp}(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $x > 0$ 。

无记忆性：对任意 $s, t > 0$,

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t).$$

证明：

$$\mathbb{P}(X > s + t \mid X > s) = \frac{\mathbb{P}(X > s + t)}{\mathbb{P}(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(X > t).$$

与几何分布的类比：离散几何分布和连续指数分布都具有无记忆性。这不是巧合——它们都是“等待直到事件发生”这一过程的模型，只是时间参数不同。

实际应用：指数分布常用于描述：

- 电子元件的寿命（假设失效率恒定）
- 客户服务时间
- 打电话的间隔时间

Poisson 过程的联系：如果事件以固定速率 λ 发生（Poisson 过程），那么相邻事件的时间间隔服从指数分布 $\text{Exp}(\lambda)$ 。

11.8. 一元变换公式的推导. 背景：已知 X 的分布，求 $Y = g(X)$ 的分布。

定理：设 X 是连续随机变量， $f_X(x)$ 已知。 $y = g(x)$ 是一一对应且可导的， $x = g^{-1}(y) = h(y)$ 。则

$$f_Y(y) = f_X(h(y)) |h'(y)|, \quad y \in \mathcal{S}_Y.$$

证明：

由 CDF 定义：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq h(y)) = F_X(h(y)).$$

对 y 求导（链式法则）：

$$f_Y(y) = f_X(h(y)) \cdot h'(y) = f_X(h(y)) |h'(y)|.$$

多对一情况：若 g 不是一一对应，则需将所有映射到同一 y 的 x 的概率相加：

$$f_Y(y) = \sum_i f_X(x_i) |x'_i|,$$

其中 $x_i = h_i(y)$ 是 $y = g(x)$ 的各个解。

11.9. 函数期望定理的证明. 背景：已知 X 的分布，求 $Y = g(X)$ 的期望。

定理：设 $Y = g(X)$ 。

- 若 X 离散： $\mathbb{E}Y = \sum_x g(x)p_X(x)$
- 若 X 连续： $\mathbb{E}Y = \int_{-\infty}^{\infty} g(x)f_X(x)dx$

证明（连续情形）：

由定义：

$$\mathbb{E}Y = \int_{-\infty}^{\infty} y f_Y(y) dy.$$

使用变换公式：

$$= \int_{-\infty}^{\infty} y \cdot f_X(h(y)) |h'(y)| dy.$$

做变量替换 $x = h(y)$ ，则 $dx = h'(y)dy$ ， $y = g(x)$ ：

$$= \int_{-\infty}^{\infty} g(x) f_X(x) dx.$$

重要意义：我们不需要先求 Y 的分布，直接用 X 的分布计算即可！这就是“函数期望定理”的价值。

11.10. 期望线性性的证明. 定理：对任意随机变量 X, Y （期望存在）和常数 a, b ：

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y.$$

证明：

由函数期望定理和重期望：

$$\mathbb{E}[aX + bY] = \iint (ax + by) f_{XY}(x, y) dx dy.$$

分离积分：

$$= a \iint x f_{XY}(x, y) dx dy + b \iint y f_{XY}(x, y) dx dy = a\mathbb{E}X + b\mathbb{E}Y.$$

关键点：无需 X, Y 独立！线性性对所有随机变量都成立，无论它们是否相关。

推论：对 iid $X_1, \dots, X_n$ ， $\mathbb{E}\bar{X} = \mathbb{E}X_1$ 。

由线性性：

$$\mathbb{E}\bar{X} = \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n X_i \right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}X_i = \frac{1}{n} \cdot n\mathbb{E}X_1 = \mathbb{E}X_1.$$

11.11. 方差公式的推导. 背景：方差度量随机变量偏离其均值的程度。

定义： $\text{var}(X) = \mathbb{E}[(X - \mu)^2]$ ，其中 $\mu = \mathbb{E}X$ 。

计算公式： $\text{var}(X) = \mathbb{E}(X^2) - \mu^2$ 。

推导：

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2 - 2\mu X + \mu^2] = \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - 2\mu^2 + \mu^2 = \mathbb{E}(X^2) - \mu^2.$$

方差性质：

(1) $\text{var}(aX + b) = a^2\text{var}(X)$ （尺度变换）

(2) 若 $X \perp Y$: $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y)$

第二点的证明: 若 X, Y 独立,

$$\text{var}(X+Y) = \mathbb{E}[(X+Y)^2] - [\mathbb{E}(X+Y)]^2 = \mathbb{E}(X^2) + 2\mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(Y^2) - \mu_X^2 - 2\mu_X\mu_Y - \mu_Y^2 = \text{var}(X) + \text{var}(Y)$$

注意: 独立性条件不可少! 若 $X = Y$, 则 $\text{var}(X + Y) = \text{var}(2X) = 4\text{var}(X) \neq 2\text{var}(X)$ 。

11.12. Markov 不等式的证明. 定理: 若 $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}.$$

证明:

设事件 $A = \{g(X) \geq a\}$, 则 $g(X) \geq a \cdot \mathbb{I}_A$ (因为在 A 上 $g(X) \geq a$, 在 A^c 上 $g(X) \geq 0$)。

取期望:

$$\mathbb{E}[g(X)] \geq \mathbb{E}[a \cdot \mathbb{I}_A] = a \cdot \mathbb{P}(A) = a \cdot \mathbb{P}(g(X) \geq a).$$

两边除以 $a > 0$ 得证。

意义: Markov 不等式仅用一阶矩 (期望) 就能给出概率上界, 不依赖分布的具体形式。当然, 上界可能很松——例如对正态分布, $\mathbb{P}(|X| \geq 2\sigma)$ 的真实值约为 0.05, 而 Markov 上界给出的是 1/4。

特例: 取 $g(X) = (X - \mu)^2$, $a = k^2$, 得 Chebyshev 不等式:

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\text{var}(X)}{k^2}.$$

11.13. Cauchy-Schwarz 不等式的证明. 定理: 对任意随机变量 X, Y ,

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}.$$

证明:

考虑 $\mathbb{E}[(tX - Y)^2] \geq 0$ 对任意实数 t 成立。

展开:

$$0 \leq \mathbb{E}[t^2 X^2 - 2tXY + Y^2] = t^2 \mathbb{E}(X^2) - 2t \mathbb{E}(XY) + \mathbb{E}(Y^2).$$

这是关于 t 的二次不等式, 其判别式必须非正:

$$[2\mathbb{E}(XY)]^2 - 4\mathbb{E}(X^2)\mathbb{E}(Y^2) \leq 0.$$

整理得:

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}(X^2) \cdot \mathbb{E}(Y^2)}.$$

应用: 证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。

设 $X^* = X - \mu_X$, $Y^* = Y - \mu_Y$, 则

$$|\text{corr}(X, Y)| = \frac{|\mathbb{E}(X^*Y^*)|}{\sqrt{\text{var}(X)\text{var}(Y)}} \leq \frac{\sqrt{\mathbb{E}(X^{*2})\mathbb{E}(Y^{*2})}}{\sqrt{\text{var}(X)\text{var}(Y)}} = 1.$$

11.14. Jensen 不等式的证明. 定理：若 g 是凸函数， X 的期望存在，则

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}X).$$

证明（使用凸函数的支撑超平面）：

由凸函数的性质，对任意 x_0 ，存在支撑线 $L(x) = g(x_0) + c(x - x_0)$ 使得 $g(x) \geq L(x)$ 对所有 x 成立。

取 $x_0 = \mathbb{E}X$ ，则 $g(x) \geq g(\mathbb{E}X) + c(x - \mathbb{E}X)$ 。

取期望：

$$\mathbb{E}[g(X)] \geq g(\mathbb{E}X) + c\mathbb{E}(X - \mathbb{E}X) = g(\mathbb{E}X) + c \cdot 0 = g(\mathbb{E}X).$$

特例：

- $g(x) = x^2$ (凸)： $\mathbb{E}(X^2) \geq (\mathbb{E}X)^2$
- $g(x) = e^x$ (凸)： $\mathbb{E}(e^X) \geq e^{\mathbb{E}X}$

第二个特例说明：指数函数的期望大于等于期望的指数——这在金融中用于证明“彩票溢价”现象。

CHAPTER 2

多元随机变量及其分布

Chapter 2 概述

在一元情形，我们用 cdf $F_X(x) = \mathbb{P}(X \leq x)$ 描述单个随机变量的行为。但在许多场景中，单个变量的分布并不能回答我们的问题——我们需要知道多个变量如何共同变化。

为什么需要联合分布？ 例如，在经济学中，我们关心收入与教育年限的共同分布；在医学中，我们关心血压与胆固醇的联合水平；在金融中，资产收益率之间的相关性是风险管理的核心。这些问题都涉及多个随机变量的联合行为。

统计推断的核心任务——从样本推断总体——本质上也是多元的：样本是多个观测值的向量，而统计量是这些观测值的函数。第 4 章将看到，点估计、置信区间、假设检验全部建立在多元分布理论之上。

本章路线图： 联合分布 $\rightarrow$ 边缘分布 $\rightarrow$ 条件分布 $\rightarrow$ 独立性 $\rightarrow$ 相关性 $\rightarrow$ 多元正态 $\rightarrow$ 多元推广

1. 2.1 从一元到多元：联合分布

1.1. 为什么需要联合分布？ 在一元情形，我们学会了用 cdf、pmf/pdf 描述单个随机变量的行为。但在真实世界中，变量很少孤立存在。

核心问题： 给定两个随机变量 X_1 和 X_2 ，如何描述它们的联合行为？

例如，设 X_1 为身高， X_2 为体重。知道身高分布和体重分布当然有用，但知道两者如何“共同变化”——高个子是否倾向于更重——显然更有价值。这种“共同变化”的数学表达，正是联合分布。

历史注记： 多元分析的思想可以追溯到 Francis Galton (1822-1911) 的工作。他研究遗传问题时发现，单个特征的分布不足以描述遗传规律——必须考虑特征之间的相关性。他发明的“相关系数” (correlation coefficient) 正是本章的核心概念之一。

1.2. 随机向量与联合分布.

DEFINITION 2.1 (随机向量). 设样本空间为 $\mathcal{C}$ ， X_1 和 X_2 为定义在 $\mathcal{C}$ 上的两个随机变量。则 (X_1, X_2) 称为随机向量，其取值空间为 $\mathcal{D} = \{(x_1, x_2) : x_1 = X_1(c), x_2 = X_2(c), c \in \mathcal{C}\}$ 。

联合 cdf 是一元 cdf 的自然推广：

$$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2). \quad (1)$$

注意：这里的“且” ($,$) 表示两个事件同时发生。

离散型用 pmf 描述:

$$p_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 = x_1, X_2 = x_2), \quad (2)$$

满足 $p \geq 0$ 且 $\sum \sum_{\mathcal{D}} p = 1$ 。

连续型用 pdf 描述:

$$f_{X_1, X_2}(x_1, x_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f(w_1, w_2) dw_1 dw_2, \quad (3)$$

其中 $f \geq 0$ 且 $\int \int_{\mathcal{D}} f = 1$ 。

emark **警告:** 与一元情形不同, 这里的 $f(x_1, x_2)$ 可以大于 1! 因为它是“密度”而非概率值。emark

几何直观: 若把联合 pdf $z = f(x_1, x_2)$ 视作一张曲面, 则 $\mathbb{P}((X_1, X_2) \in A)$ 就是该曲面下区域 A 上的体积。这是一元情形“曲线下面积”在二维的推广。

1.3. R 计算: 联合分布.

EXAMPLE 2.1 (二元正态概率计算). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.5)$ 。求 $\mathbb{P}(X_1 \leq 0, X_2 \leq 0)$ 。

在 R 中使用 *mvtnorm* 包:

```
install.packages("mvtnorm")
library(mvtnorm)
```

二元正态 CDF

```
pmvnorm(lower = c(-Inf, -Inf), upper = c(0, 0),
         mean = c(0, 0), sigma = matrix(c(1, 0.5, 0.5, 1), nrow = 2))
```

EXAMPLE 2.2 (生成二元正态样本). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.8)$ 。生成 $n = 1000$ 的样本并可视化。

```
library(mvtnorm)
n <- 1000
rho <- 0.8
sigma <- matrix(c(1, rho, rho, 1), nrow = 2)
set.seed(42)
sample <- rmvnorm(n, mean = c(0, 0), sigma = sigma)
```

绘制散点图

```
plot(sample, xlab = expression(X[1]), ylab = expression(X[2]),
     main = bquote(rho == .(rho)), pch = 20, cex = 0.5)
```

计算样本相关系数

```
cor(sample[,1], sample[,2])
```

不同 ρ 值的散点图形态：

- $\rho = 0$ ：分布呈圆形，变量独立
- $\rho > 0$ ：分布沿主对角线 ($x_2 = x_1$) 拉伸
- $\rho < 0$ ：分布沿副对角线 ($x_2 = -x_1$) 拉伸
- $|\rho| \rightarrow 1$ ：分布越来越集中在一条直线附近

2. 2.2 边缘分布：积分即求和

2.1. 核心问题：如何从联合分布得到边缘分布？ 我们已经知道 (X_1, X_2) 的联合分布，自然会问：如何得到单个 X_1 的分布？

直觉上，我们需要“忽略” X_2 的信息。具体做法是：

- **离散型**：对 x_2 求和
- **连续型**：对 x_2 积分

这引导我们得到边缘分布公式。¹

边缘 pmf:

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2). \quad (4)$$

边缘 pdf:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2. \quad (5)$$

emark 为什么叫“边缘”？ 在二维离散情形，将联合 pmf 列表，边缘分布恰好是每行（或每列）的“边缘”之和。这解释了名称的由来。emark

一个重要发现： 已知联合分布可以推出边缘分布，但反过来不成立——边缘分布丢失了变量之间的依赖信息。例如，两个不同的联合分布可能有相同的边缘分布。

EXAMPLE 2.3 (不同联合分布有相同边缘分布). 设 (X_1, X_2) 和 (Y_1, Y_2) 有相同的边缘分布，但不同的联合结构。实际上，如果不知道联合分布，就无法回答“两个变量是否相关”这样的问题。

2.2. R 计算：边缘分布. 边缘分布在 R 中通过逐行或逐列求和（离散）或积分（连续）计算。

EXAMPLE 2.4 (离散边缘分布). 设 (X_1, X_2) 的联合 pmf 如下（列联表形式）：

$X_2 \backslash X_1$	1	2	3	4	边缘
1	0.05	0.10	0.05	0.02	?
2	0.08	0.15	0.12	0.05	?
3	0.02	0.08	0.10	0.08	?
边缘	?	?	?	?	1.00

¹推导见附录 ??。

则 X_1 的边缘 *pmf* 为每列之和:

$$p_{X_1}(1) = 0.05 + 0.08 + 0.02 = 0.15, \quad p_{X_1}(2) = 0.10 + 0.15 + 0.08 = 0.33, \quad \text{等等}$$

R 计算:

```
# 联合 pmf (矩阵形式)
joint <- matrix(c(0.05, 0.08, 0.02, # X1=1
                  0.10, 0.15, 0.08, # X1=2
                  0.05, 0.12, 0.10, # X1=3
                  0.02, 0.05, 0.08), # X1=4
                nrow = 3, byrow = FALSE)
colnames(joint) <- c("X1=1", "X1=2", "X1=3", "X1=4")
rownames(joint) <- c("X2=1", "X2=2", "X2=3")

# 边缘分布 (按行、按列求和)
margin_x1 <- colSums(joint) # X1 的边缘 pmf
margin_x2 <- rowSums(joint) # X2 的边缘 pmf

# 验证: 边缘分布之和为 1
sum(margin_x1) # = 1
sum(margin_x2) # = 1
```

EXAMPLE 2.5 (连续边缘分布). 设 (X_1, X_2) 的联合 *pdf* 为

$$f(x_1, x_2) = \begin{cases} 8x_1x_2 & 0 < x_1 < x_2 < 1, \\ 0 & \text{otherwise.} \end{cases}$$

求 X_1 的边缘 *pdf*。

由于 $0 < x_1 < x_2 < 1$, x_2 的取值范围是 $x_1 < x_2 < 1$, 因此:

$$f_{X_1}(x_1) = \int_{x_1}^1 8x_1x_2 dx_2 = 8x_1 \left[\frac{x_2^2}{2} \right]_{x_2=x_1}^{x_2=1} = 8x_1 \cdot \frac{1-x_1^2}{2} = 4x_1(1-x_1^2),$$

其中 $0 < x_1 < 1$ 。

验证:

$$\int_0^1 4x_1(1-x_1^2) dx_1 = 4 \left[\frac{x_1^2}{2} - \frac{x_1^4}{4} \right]_0^1 = 4 \left(\frac{1}{2} - \frac{1}{4} \right) = 1.$$

R 数值验证:

```
# 验证边缘 pdf 的数值积分
f_marginal_x1 <- function(x1) {
  f <- function(x2) 8 * x1 * x2
  integrate(f, lower = x1, upper = 1)$value
}
```

```
# 在几个点验证
x1_vals <- c(0.2, 0.5, 0.8)
sapply(x1_vals, f_marginal_x1) # 应该接近 4*x1*(1-x1^2)
4 * x1_vals * (1 - x1_vals^2)
```

2.3. 边缘分布的深度理解. 为什么边缘分布重要? 边缘分布在实际应用中有广泛用途：

1. 人口统计学：当我们研究”收入”与”教育年限”的联合分布时，边缘分布给出了各变量的边缘分布——即不考虑另一变量时该变量的分布。这相当于”总体”的分布。

2. 保险精算：在汽车保险中，我们关心”理赔次数”与”理赔金额”的联合分布，但边缘分布分别给出了理赔次数的分布和理赔金额的分布——这两个分布本身就有独立的应用价值。

3. 信号处理：在处理二元信号时，边缘分布给出了各分量信号的分布，这在单独分析各分量时有用。

信息损失：一个关键事实是，从联合分布到边缘分布会丢失信息。如果只知道边缘分布，则无法恢复联合分布——因为这需要知道变量之间的依赖结构。

Clayton 模型：在金融保险中，Clayton copula 正是用来说明：相同的边缘分布可以对应于不同的联合分布。这个事实在风险管理中非常重要——仅知道各变量的边缘分布是不够的。

3. 2.3 条件分布：信息的价值

3.1. 条件分布的核心思想. 核心问题：已知 X_1 的值， X_2 的分布会如何变化？

这就是条件分布要回答的问题。条件分布本质上是在 $X_1 = x_1$ 的条件下，重新审视 X_2 的行为——这是贝叶斯思维在随机变量层面的延伸。

离散型条件 pmf: ²

$$p_{X_2|X_1}(x_2 | x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}, \quad p_{X_1}(x_1) > 0. \quad (6)$$

连续型条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}, \quad f_{X_1}(x_1) > 0. \quad (7)$$

分子是联合密度，分母是边缘密度。这个比值衡量的是，在 $X_1 = x_1$ 的条件下， (x_1, x_2) 这个”点”有多”典型”。

注意：在连续情形， $\mathbb{P}(X_1 = x_1) = 0$ ，所以不能直接用条件概率定义。这里用条件密度代替——条件密度的定义源自 Radon-Nikodym 定理，它是条件期望存在性的数学基础。³

²推导见附录 ??。

³详细讨论见附录 ??。

由此定义条件期望：

$$\mathbb{E}[u(X_2) | x_1] = \int_{-\infty}^{\infty} u(x_2) f_{X_2|X_1}(x_2 | x_1) dx_2. \quad (8)$$

条件期望 $\mathbb{E}[X_2 | X_1 = x_1]$ 是 x_1 的函数，可以理解为 X_1 取某个值时 X_2 的最佳预测。

3.2. 全期望公式与方差分解. 这里有一个深刻的定理，它连接了条件与边缘。⁴

THEOREM 2.1 (全期望公式).

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2). \quad (2.3.1)$$

含义：对条件均值再取期望，等于无条件期望。这看起来显而易见，但它是概率论中最强大的工具之一。

更惊人的是方差的不等式：⁵

THEOREM 2.2 (条件方差公式).

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)]. \quad (2.3.2)$$

直观理解：总方差等于“平均条件方差”加上“条件均值的方差”。第一项度量 X_2 在给定 X_1 后的残余不确定性；第二项度量 X_1 带来的不确定性。

Rao-Blackwell 定理：若用 X_2 估计 $\mu_2 = \mathbb{E}X_2$ ，则条件均值 $\mathbb{E}(X_2 | x_1)$ 比 X_2 本身更精确（方差更小）。这在统计推断中极其重要——它告诉我们如何利用辅助信息改进估计。⁶

3.3. R 计算：条件分布.

EXAMPLE 2.6 (离散条件分布). 设 (X_1, X_2) 的联合 pmf 如下：

$$p_{X_1, X_2}(x_1, x_2) = \frac{1}{8}, \quad x_1 = 1, 2, \quad x_2 = 1, 2, 3, 4.$$

求条件分布 $\mathbb{P}(X_2 = x_2 | X_1 = 1)$ 。

边缘分布 $p_{X_1}(1) = \sum_{x_2=1}^4 \frac{1}{8} = \frac{4}{8} = \frac{1}{2}$ 。

条件分布：

$$\mathbb{P}(X_2 = x_2 | X_1 = 1) = \frac{p_{X_1, X_2}(1, x_2)}{p_{X_1}(1)} = \frac{1/8}{1/2} = \frac{1}{4}, \quad x_2 = 1, 2, 3, 4.$$

因此，给定 $X_1 = 1$ 时， X_2 均匀分布于 $\{1, 2, 3, 4\}$ 。

⁴推导见附录 ??。

⁵推导见附录 ??。

⁶详细讨论见附录 ??。

EXAMPLE 2.7 (连续条件分布). 设 (X_1, X_2) 服从二元正态 $N(0, 0, 1, 1, 0.5)$ 。求条件分布 $f_{X_2|X_1}(x_2 | x_1 = 0.5)$ 。

由公式 (??):

$$X_2 | X_1 = 0.5 \sim N\left(0 + 0.5 \cdot \frac{1}{1}(0.5 - 0), 1 \cdot (1 - 0.5^2)\right) = N(0.25, 0.75).$$

R 验证:

条件分布参数

```
mu2_given_x1 <- 0 + 0.5 * (0.5 - 0) # = 0.25
```

```
sigma2_sq <- 1 * (1 - 0.5^2) # = 0.75
```

在 R 中绘制条件密度

```
curve(dnorm(x, mu2_given_x1, sqrt(sigma2_sq)),
      from = -2, to = 2,
      xlab = expression(x[2]), ylab = "Density",
      main = expression(paste("Conditional density of ", X[2], " | ", X[1], " = 0.5"))
```

3.4. 条件分布的实际应用. 条件分布在统计建模中有广泛应用:

1. **回归分析:** 条件均值 $\mathbb{E}(Y | X = x)$ 正是回归函数。线性回归假设 $\mathbb{E}(Y | X = x) = \alpha + \beta x$, 但更一般地, 任何条件均值函数都可以作为回归目标。

2. **分层抽样:** 在抽样设计中, 我们经常按子群 (strata) 分组。子群内的条件分布描述了组内变异, 而边缘分布描述了总体变异。方差分解公式 (??) 正是这种思想的数学表达。

3. **贝叶斯统计:** 后验分布 $f(\theta | x)$ 是在观测数据 x 的条件下参数 θ 的条件分布。整个贝叶斯推断都建立在条件分布的理论之上。

3.5. R 计算: 条件分布的应用. 继续展示条件分布在 R 中的实际计算。

EXAMPLE 2.8 (二元正态条件分布可视化). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.7)$ 。绘制不同 x_1 条件下 X_2 的条件密度。

```
library(mvtnorm)
```

```
library(ggplot2)
```

设置参数

```
mu1 <- mu2 <- 0
```

```
sigma1 <- sigma2 <- 1
```

```
rho <- 0.7
```

条件分布参数

```
cond_mean <- function(x1) mu2 + rho * (sigma2/sigma1) * (x1 - mu1)
```

```
cond_var <- sigma2^2 * (1 - rho^2)
```

```
# 绘制条件密度
x1_vals <- c(-2, -1, 0, 1, 2)
colors <- c("blue", "green", "red", "orange", "purple")

plot(NULL, xlim = c(-4, 4), ylim = c(0, 0.5),
      xlab = expression(x[2]), ylab = "Density",
      main = "Conditional densities of X2 given X1")

for (i in seq_along(x1_vals)) {
  curve(dnorm(x, cond_mean(x1_vals[i]), sqrt(cond_var)),
        add = TRUE, col = colors[i], lwd = 2)
  abline(v = cond_mean(x1_vals[i]), col = colors[i], lty = 2)
}

legend("topright", legend = paste("X1 =", x1_vals),
      col = colors, lwd = 2, cex = 0.8)
```

观察：条件均值随 x_1 线性变化（回归效应），条件方差保持不变（正态分布的特殊性质）。

EXAMPLE 2.9 (分层抽样的方差分解). 设某大学有 10000 名学生，按专业分为 5 个阶层 (*strata*)。我们想估计学生的平均每周学习时间。

假设各阶层的样本均值和方差如下：

专业	n_h	$\bar{X}_h$	s_h^2
理工	3000	20	25
文科	2500	25	20
商科	2000	22	30
法学	1500	18	15
医学	1000	28	35

边缘分布的方差分解：

$$\text{var}(\bar{X}) = \mathbb{E}[\text{var}(X | H)] + \text{var}[\mathbb{E}(X | H)].$$

第一项（层内方差）是各阶层方差的加权平均：

$$\mathbb{E}[\text{var}(X | H)] = \sum_h \frac{n_h}{N} s_h^2.$$

第二项（层间方差）是各阶层均值方差的加权平均：

$$\text{var}[\mathbb{E}(X | H)] = \sum_h \frac{n_h}{N} (\bar{X}_h - \bar{X})^2,$$

其中 $\bar{X}$ 是总体均值。

R 计算：

```
# 阶层数据
n_h <- c(3000, 2500, 2000, 1500, 1000)
Xbar_h <- c(20, 25, 22, 18, 28)
s2_h <- c(25, 20, 30, 15, 35)
N <- sum(n_h)

# 总体均值
Xbar <- sum(n_h * Xbar_h) / N

# 层内方差期望
within_var <- sum(n_h * s2_h) / N

# 层间方差
between_var <- sum(n_h * (Xbar_h - Xbar)^2) / N

# 总方差
total_var <- within_var + between_var

# 分层抽样估计的方差
# 简单随机抽样的方差（比较基准）
srs_var <- total_var / N # 简单随机抽样

# 分层抽样的效率
strat_efficiency <- srs_var / (within_var/N)
cat("层内方差期望:", within_var, "\n")
cat("层间方差:", between_var, "\n")
cat("总方差:", total_var, "\n")
cat("分层抽样相对效率:", round(strat_efficiency, 2), "倍\n")
```

3.6. 条件分布的贝叶斯视角. 贝叶斯统计的核心思想是：参数 θ 也是随机变量，我们应该用条件分布来描述我们对参数的认知。

先验分布： θ 在观测数据之前的分布，记作 $f(\theta)$ 。

似然函数： $L(\theta | x) = f(x | \theta)$ ，描述数据如何更新我们对 θ 的认知。

后验分布：⁷

$$f(\theta | x) = \frac{f(x | \theta)f(\theta)}{f(x)},$$

⁷详细推导见附录 ??。

其中 $f(x) = \int f(x | \theta) f(\theta) d\theta$ 是归一化常数。

后验均值： $\mathbb{E}(\theta | x)$ 是贝叶斯估计量，它优于普通样本均值——尤其在样本量较小时。

后验方差： $\text{var}(\theta | x)$ 度量了参数估计的不确定性。它在统计决策理论和置信区间构建中都有重要应用。

历史注记：Thomas Bayes (1702-1761) 在其论文《An Essay Towards Solving a Problem in the Doctrine of Chances》中首次提出了贝叶斯公式。拉普拉斯 (Laplace) 后来独立发展了贝叶斯方法，并将其应用于天文学、人口统计等领域。贝叶斯方法在 20 世纪经历了从被忽视到复兴的过程——部分原因是计算限制（马尔可夫链蒙特卡洛方法解决了这个问题），部分原因是哲学层面的争论。⁸

EXAMPLE 2.10 (Beta-Binomial 共轭). 设 $X | \theta \sim \text{Binomial}(n, \theta)$, $\theta \sim \text{Beta}(\alpha, \beta)$ 。则后验分布为

$$\theta | X = x \sim \text{Beta}(\alpha + x, \beta + n - x).$$

后验均值为

$$\mathbb{E}(\theta | X = x) = \frac{\alpha + x}{\alpha + \beta + n}.$$

这个估计量是样本比例 $\hat{p} = x/n$ 和先验均值 $\frac{\alpha}{\alpha+\beta}$ 的加权平均——数据越多，权重越倾向于数据一方。

R 验证：

```
# 先验参数
```

```
alpha <- 2
```

```
beta <- 3
```

```
# 观测数据
```

```
n <- 10
```

```
x <- 7
```

```
# 后验参数
```

```
alpha_post <- alpha + x
```

```
beta_post <- beta + n - x
```

```
# 后验均值
```

```
post_mean <- alpha_post / (alpha_post + beta_post)
```

```
# 样本比例
```

```
sample_prop <- x / n
```

⁸详细历史讨论见附录 ??。

```
# 先验均值
prior_mean <- alpha / (alpha + beta)

# 贝叶斯估计量（后验均值）
cat("先验均值:", prior_mean, "\n")
cat("样本比例:", sample_prop, "\n")
cat("后验均值:", post_mean, "\n")
cat("后验均值 = (n/(n++)) * 样本比例 + ((+)/(n++)) * 先验均值\n")
cat("= (10/15)*0.7 + (5/15)*0.4 =", 10/15*0.7 + 5/15*0.4, "\n")
```

4. 2.4 独立性：变量间的“无关系”

4.1. 什么时候 X_1 和 X_2 互不影响? 若 X_1 与 X_2 独立，则知道 X_1 的值不会改变我们对 X_2 的认知。用条件分布的语言：

$$f_{X_2|X_1}(x_2 | x_1) = f_{X_2}(x_2) \quad (\text{不依赖于 } x_1) .$$

由此推出联合密度可分离。⁹

THEOREM 2.3 (独立性).

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv f_1(x_1)f_2(x_2). \quad (2.4.1)$$

一个实用的判据：

THEOREM 2.4 (独立性因子化判据).

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv g(x_1)h(x_2) \quad (\text{可分离变量}) . \quad (2.4.2)$$

独立性的后果：

- $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$
- $\text{cov}(X_1, X_2) = 0$

emark **逆命题不成立!** $\text{cov}(X_1, X_2) = 0$ 并不意味着独立性（除二元正态分布外）。
emark

这提醒我们：**不相关**（uncorrelated）和**独立**（independent）是两个不同概念。不相关只说明没有线性关系，但变量间可能存在非线性依赖。

一个经典反例：设 $X \sim \text{Uniform}(-1, 1)$, $Y = X^2$ 。则 $\text{cov}(X, Y) = 0$ （因为 X 对称），但 Y 完全由 X 决定——它们显然不独立。¹⁰

⁹推导见附录 ??。

¹⁰更多反例见附录 ??。

4.2. 独立的实际意义. 独立性在统计推断中极其重要, 因为:

1. **简化计算:** 若 $X_1 \perp\!\!\!\perp X_2$, 则

$$\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)],$$

这大大简化了期望的计算。

2. **分解问题:** 在许多统计问题中, 我们假设观测独立。这使得复杂问题可以分解为简单问题的组合。

3. **乘积分布:** 若 $X_1 \perp\!\!\!\perp X_2$, 则联合分布是边缘分布的乘积——这是一个优雅的结构性陈述。

4.3. R 计算: 独立性检验. 在实际数据分析中, 我们经常需要检验两个变量是否独立。

EXAMPLE 2.11 (独立性检验). 使用卡方检验检验两个分类变量的独立性:

```
# 创建列联表
smoking <- c(rep("Yes", 45), rep("No", 105))
cancer <- c(rep("Yes", 20), rep("No", 25), rep("Yes", 15), rep("No", 90))
table <- matrix(c(20, 25, 15, 90), nrow = 2, byrow = TRUE)
colnames(table) <- c("Cancer Yes", "Cancer No")
rownames(table) <- c("Smoking Yes", "Smoking No")

# 卡方检验
chisq.test(table)
```

Fisher 精确检验: 当样本量较小时, 使用 Fisher 精确检验比卡方检验更可靠:

```
fisher.test(table)
```

4.4. 独立性的深入理解. 为什么独立性如此重要? 独立性假设是现代统计推断的基石之一。

1. **计算简化:** 若 $X_1 \perp\!\!\!\perp X_2$, 则

$$\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)].$$

这大大简化了期望的计算。

2. **分解简化:** 在许多统计问题中, 我们假设观测独立。这使得复杂问题可以分解为简单问题的组合。例如, 样本均值 $\bar{X} = n^{-1} \sum X_i$ 的方差, 当 X_i 独立同分布时, 为 $\text{var}(\bar{X}) = \sigma^2/n$ 。没有独立性, 这个公式不成立。

3. **乘积分布:** 若 $X_1 \perp\!\!\!\perp X_2$, 则联合分布是边缘分布的乘积——这是一个优雅的结构性陈述。

独立性的判别: 在实际问题中, 我们如何判断两个变量是否独立?

1. **因子化判据:** 若联合 pdf/pmf 可以写成 $f(x_1, x_2) = g(x_1)h(x_2)$ 的形式, 则 X_1 与 X_2 独立。

2. 条件分布判据：若条件分布等于边缘分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_2}(x_2)$ ，则独立。

3. 协方差判据（反向）：若 $\text{cov}(X_1, X_2) \neq 0$ ，则一定不独立。但 $\text{cov}(X_1, X_2) = 0$ 不能推出独立（除特殊情况外）。

独立 vs 不相关：这是一个极其重要的区别。

不相关 (uncorrelated) 只说明没有线性关系： $\text{cov}(X_1, X_2) = 0$ 。

独立 (independent) 意味着知道一个变量的值对另一个变量的分布没有任何影响。

独立 $\Rightarrow$ 不相关，但反过来一般不成立。

二元正态的特殊性：在二元正态分布中，不相关 $\iff$ 独立。这是因为二元正态的联合分布完全由一阶矩和二阶矩决定。

在其他分布中：对于非正态分布， $\text{cov} = 0$ 但不独立是可能的。

反例： X 与 $Y = X^2$ ：设 $X \sim \text{Uniform}(-1, 1)$ ， $Y = X^2$ 。则 $\text{cov}(X, Y) = 0$ ，但显然 Y 完全由 X 决定，不独立。¹¹

EXAMPLE 2.12 (独立性检验的更多方法). 在实际数据分析中，独立性检验方法的选择取决于数据。

1. 连续变量的 *Pearson* 相关系数检验：

检验 X 和 Y 是否独立（假设二元正态）

```
x <- rnorm(100, mean = 0, sd = 1)
y <- 0.5 * x + rnorm(100, mean = 0, sd = sqrt(1 - 0.5^2))
cor.test(x, y, method = "pearson")
```

2. 秩相关 (*Spearman* 和 *Kendall*): 对非正态数据更鲁棒：

Spearman 秩相关

```
cor.test(x, y, method = "spearman")
```

Kendall tau 相关

```
cor.test(x, y, method = "kendall")
```

3. 互信息：度量变量的整体依赖关系（包括非线性）：

计算互信息（需要 *infotheo* 包）

```
library(infotheo)
discretize(cbind(x, y))
mutualinformation(discretize(cbind(x, y)))
```

4. χ^2 检验：适用于分类变量：

创建列联表

```
smoke <- c(rep("Yes", 45), rep("No", 105))
cancer <- c(rep("Yes", 20), rep("No", 25), rep("Yes", 15), rep("No", 90))
table <- matrix(c(20, 25, 15, 90), nrow = 2, byrow = TRUE)
```

¹¹详细计算见附录 ??。

卡方检验

```
chisq.test(table)
```

Fisher 精确检验 (样本量小时更可靠)

```
fisher.test(table)
```

独立性的实际应用：

1. 金融风险管理的核心假设：在金融工程中，资产收益率的独立性假设是 Black-Scholes 公式的基础。虽然这个假设在实践中经常被违反（存在“波动率聚集”等现象），但它提供了一个有用的基准模型。

2. 信号处理：在噪声模型中，我们通常假设信号与噪声独立。这使得我们可以从噪声观测中恢复信号。

3. 机器学习：许多算法假设训练样本独立同分布 (i.i.d.)。当这个假设被违反时（如时间序列数据），需要使用专门的模型（如 RNN、LSTM）。

5. 2.5 相关性：线性关联的度量

我们已经知道 $\text{cov}(X_1, X_2) = 0$ 不能完全刻画独立性。那么如何量化 X_1 与 X_2 之间的“关联程度”？

协方差 $\text{cov}(X_1, X_2)$ 存在一个问题：它依赖于 X_1, X_2 的量纲。例如，身高 (cm) 和体重 (kg) 的协方差与换算成英寸和磅时不同。

解决方案：先标准化，再求协方差：

$$\rho_{12} = \text{corr}(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)}\sqrt{\text{var}(X_2)}} = \frac{\text{cov}(X_1, X_2)}{\sigma_1\sigma_2}. \quad (2.5.1)$$

这就是相关系数 (correlation coefficient)。

核心性质：¹²

- $-1 \leq \rho_{12} \leq 1$
- $|\rho_{12}| = 1 \iff X_2 = aX_1 + b$ (完美线性关系)
- $\rho_{12} = 0$ 称**不相关**

为什么是 $[-1, 1]$ ？这来自 Cauchy-Schwarz 不等式：

$$|\text{cov}(X_1, X_2)| = |\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]| \leq \sqrt{\mathbb{E}[(X_1 - \mu_1)^2] \cdot \mathbb{E}[(X_2 - \mu_2)^2]} = \sigma_1\sigma_2. \quad (2.5.2)$$

emark 相关 vs 协方差：协方差取决于量纲（“米的协方差”vs“厘米的协方差”数值不同）；相关系数是无量纲的，消除了单位影响。因此，相关系数是更通用的“关联程度”度量。emark

¹²推导见附录 ??。

5.1. 历史注记：Pearson 与相关系数. 相关系数的概念由 Francis Galton (1888) 在研究遗传问题时首次提出，但 Karl Pearson (1896) 给出了严格的数学定义和估计方法。Pearson 的工作奠定了生物计量学的基础，也使得相关性成为统计学中最广泛使用的概念之一。

Galton 的发现： Galton 研究双胞胎身高时发现，父亲身高与子女身高之间存在“回归” (regression) 现象——极端身高（非常高或非常矮）的父母，其子女的身高倾向于向平均值“回归”。这种“向均值回归”的现象正是相关性的体现。

Pearson 的贡献： Pearson 给出了相关系数的精确数学定义：

$$\rho_{XY} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y},$$

并推导了其统计性质。他发展的矩估计方法至今仍是估计相关系数的主要方法之一。

5.2. R 计算：相关分析. R 提供了丰富的相关分析功能：

EXAMPLE 2.13 (样本相关系数). 计算两组数据的 *Pearson* 相关系数：

```
# 数据：父亲身高与儿子身高（模拟 Galton 数据）
father <- c(65, 63, 67, 64, 68, 62, 70, 66, 68, 65)
son <- c(68, 66, 68, 65, 69, 63, 71, 67, 69, 66)

# 计算样本相关系数
cor(father, son)

# 计算置信区间（使用 Fisher z 变换）
n <- length(father)
r <- cor(father, son)
z <- 0.5 * log((1+r)/(1-r)) # Fisher z 变换
se <- 1/sqrt(n-3)
z_ci <- c(z - 1.96*se, z + 1.96*se)
r_ci <- (exp(2*z_ci) - 1)/(exp(2*z_ci) + 1)
r_ci
```

相关性的解释：

- $|\rho| = 0$ ：无线性关系
- $|\rho| \in (0, 0.3)$ ：弱相关
- $|\rho| \in [0.3, 0.7)$ ：中等相关
- $|\rho| \in [0.7, 1)$ ：强相关
- $|\rho| = 1$ ：完美线性关系

注意事项：

- (1) 相关系数只度量线性关系，非线性关系可能表现出 $\rho = 0$

- (2) 相关系数对异常值敏感（可以使用 Spearman 或 Kendall 相关系数作为鲁棒替代）
- (3) 相关不等于因果——两个变量相关可能是因为它们共同受第三个变量影响

EXAMPLE 2.14 (相关与因果). 冰淇淋销量与溺水死亡人数呈正相关 ($\rho \approx 0.9$)。但这并不意味着吃冰淇淋导致溺水——两者都与夏季气温正相关。正确的解释是：夏季（共同原因）导致冰淇淋销量增加和更多人游泳（从而溺水增加）。

6. 2.6 二元正态：最重要的二元分布

在所有二元分布中，二元正态分布占据核心地位。它是一元正态分布在二维的自然推广，也是计量经济学、信号处理等领域的基石。

为什么重要？

- (1) 边缘分布和条件分布都是正态的
- (2) 线性组合仍是正态
- (3) 不相关 $\iff$ 独立（这是正态独有的优雅性质）
- (4) 多元正态是计量经济学、信号处理等领域的基石

历史注记：二元正态分布由 Francis Galton 和 Karl Pearson 在 19 世纪末独立发展。Pearson 发展的多元相关理论为现代统计学奠定了重要基础。

DEFINITION 2.2 (二元正态分布). (X_1, X_2) 服从二元正态分布，若其联合 pdf 为

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\},$$

记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

五个参数的含义：

- μ_1, μ_2 : 边缘分布的均值
- σ_1^2, σ_2^2 : 边缘分布的方差
- ρ : 相关系数

关键性质：

- (1) 边缘分布: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) 条件分布: ¹³

$$X_2 | X_1 = x_1 \sim N \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2 (1 - \rho^2) \right) \quad (2.6.1)$$

- (3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ （正态独有的”不相关 $\Rightarrow$ 独立”）
- (4) 任意线性组合 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, \text{var}(aX_1 + bX_2))$

emark 条件分布的几何直觉：条件均值

$$\mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1)$$

¹³推导见附录 ??。

是 x_1 的线性函数。这意味着：给定 $X_1 = x_1$ ， X_2 的最佳预测也是线性的，其斜率由相关系数 ρ 决定。emark

条件分布的方差 $\sigma_2^2(1 - \rho^2)$ 小于无条件方差 σ_2^2 ——知道 X_1 的值减少了对 X_2 的不确定性。当 $|\rho| = 1$ 时，方差为零，意味着 X_2 可以完全由 X_1 线性决定。

6.1. R 计算：二元正态. R 中处理二元正态分布的核心函数包括 `mvtnorm` 包中的函数。

EXAMPLE 2.15 (二元正态概率计算). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.7)$ 。求 $\mathbb{P}(X_1 \leq 0.5, X_2 \leq 0.5)$ 。

在 R 中：

```
# 安装和加载 mvtnorm 包
install.packages("mvtnorm")
library(mvtnorm)

# 计算二元正态 CDF
pmvnorm(lower = c(-Inf, -Inf), upper = c(0.5, 0.5),
         mean = c(0, 0), sigma = matrix(c(1, 0.7, 0.7, 1), nrow = 2))
```

EXAMPLE 2.16 (生成二元正态样本). 设 $(X_1, X_2) \sim N(0, 0, 1, 1, 0.8)$ 。生成 $n = 1000$ 的样本并可视化。

```
library(mvtnorm)
n <- 1000
rho <- 0.8
sigma <- matrix(c(1, rho, rho, 1), nrow = 2)
set.seed(123)
sample <- rmvnorm(n, mean = c(0, 0), sigma = sigma)

# 绘制散点图
plot(sample, xlab = expression(X[1]), ylab = expression(X[2]),
     main = paste("Bivariate Normal, rho =", rho), pch = 20, cex = 0.5)

# 添加相关系数
cor(sample[,1], sample[,2])
```

不同 ρ 值的效果：

- $\rho = 0$: X_1 和 X_2 独立，分布呈圆形对称
- $\rho > 0$: 正相关，分布沿主对角线 ($y = x$) 拉伸
- $\rho < 0$: 负相关，分布沿副对角线 ($y = -x$) 拉伸
- $|\rho| = 1$: 分布退化为一条直线（完美线性关系）

6.2. 条件均值与预测. 二元正态的一个核心应用是**最优线性预测**。给定 $X_1 = x_1$, X_2 的最佳预测是条件均值:

$$\hat{X}_2 = \mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1).$$

为什么是”最优”? 考虑预测误差 $e = X_2 - \hat{X}_2$ 。可以证明, 在所有线性预测中, 这个条件均值预测的均方误差最小。¹⁴

预测误差的方差: $\text{var}(e) = \sigma_2^2(1 - \rho^2)$ 。当 $|\rho| = 1$ 时, 误差方差为零—— X_2 可以完全由 X_1 预测。

EXAMPLE 2.17 (身高与体重预测). 设 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 其中 X_1 为父亲身高 (英寸), X_2 为儿子身高 (英寸)。根据 Galton 的经典数据:

$$\mu_1 = \mu_2 = 68.2, \quad \sigma_1 = \sigma_2 = 2.7, \quad \rho = 0.5.$$

给定父亲身高 $x_1 = 72$ 英寸, 儿子的预测身高为:

$$\mathbb{E}(X_2 | X_1 = 72) = 68.2 + 0.5 \cdot \frac{2.7}{2.7} (72 - 68.2) = 68.2 + 1.9 = 70.1 \text{ 英寸}.$$

预测误差的标准差为 $\sigma_2 \sqrt{1 - \rho^2} = 2.7 \cdot \sqrt{0.75} \approx 2.34$ 英寸。

6.3. 回归与条件均值. 从条件均值公式, 我们可以写出”回归方程”:

$$X_2 = \alpha + \beta X_1 + \varepsilon,$$

其中 $\beta = \rho \frac{\sigma_2}{\sigma_1}$, $\alpha = \mu_2 - \beta \mu_1$, $\varepsilon \sim N(0, \sigma_2^2(1 - \rho^2))$ 与 X_1 独立。

最小二乘法的联系: 在统计学中, 我们通常从数据估计回归系数。样本回归系数 $\hat{\beta} = \hat{\rho}_{s_2 s_1}^{s_2}$ 依概率收敛到真实的 β 。¹⁵

7. 2.7 多元推广

前述概念可以推广到 n 个随机变量。记随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$, 其联合 cdf 为

$$F_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

7.1. 边缘与条件分布. 边缘 pdf 通过 $n - 1$ 重积分得到:

$$f_1(x_1) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, x_2, \dots, x_n) dx_2 \cdots dx_n.$$

条件分布定义为联合密度与边缘密度之比:

$$f_{2, \dots, n|1}(x_2, \dots, x_n | x_1) = \frac{f(x_1, x_2, \dots, x_n)}{f_1(x_1)}.$$

¹⁴推导见附录 ??。

¹⁵详细讨论见附录 ??。

7.2. 多元独立性. n 个随机变量 $X_1, \dots, X_n$ 相互独立, 当且仅当

$$f(x_1, x_2, \dots, x_n) \equiv f_1(x_1)f_2(x_2) \cdots f_n(x_n). \quad (2.7.1)$$

注意: 两两独立 (pairwise independence) 不一定推出相互独立 (mutual independence)。Bernstein 的例子说明了这一点。¹⁶

7.3. 线性组合的 mgf. 若 $X_1, \dots, X_n$ 相互独立, $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为

$$M_T(t) = \prod_{i=1}^n M_i(k_i t).$$

¹⁷

特别地, 若 $X_1, \dots, X_n$ iid (独立同分布), 则 $T = \sum_{i=1}^n X_i$ 的 mgf 为

$$M_T(t) = [M(t)]^n. \quad (2.7.2)$$

这个性质在研究样本和的分布时极为有用——它是一切大样本理论的起点。¹⁸

7.4. 多元正态分布. 多元正态分布是二元正态的自然推广, 在统计学中占据核心地位。

DEFINITION 2.3 (n 元正态分布). 随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 服从 n 元正态分布, 若其联合 pdf 为

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\},$$

记作 $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$, 其中 $\boldsymbol{\mu}$ 是均值向量, Σ 是协方差矩阵。

关键性质:

- (1) 任意边缘分布都是正态的
- (2) 任意线性组合 $a_1 X_1 + \cdots + a_n X_n \sim N(\mathbf{a}' \boldsymbol{\mu}, \mathbf{a}' \Sigma \mathbf{a})$
- (3) 若 Σ 对角线之外所有元素为零 (即变量独立), 则 $\mathbf{X}$ 的分量独立
- (4) 条件分布仍是正态的

协方差矩阵的性质:

- Σ 是对称的 ($\Sigma' = \Sigma$)
- Σ 是半正定的 (所有特征值 ≥ 0)
- $|\Sigma|^{1/2}$ 是 Σ 的行列式的平方根

¹⁶反例见附录 ??。

¹⁷推导见附录 ??。

¹⁸详细讨论见附录 ??。

7.5. 复相关系数与偏相关. 在多元分析中, 我们经常关心一个变量与一组变量整体的相关性。

复相关系数 (Multiple Correlation Coefficient): 度量 X_1 与 $(X_2, \dots, X_n)$ 整体之间的相关性:

$$R_{1.23\dots n} = \sqrt{\frac{\text{var}(\mathbb{E}(X_1 | X_2, \dots, X_n))}{\text{var}(X_1)}}.$$

偏相关系数 (Partial Correlation Coefficient): 在控制其他变量的影响后, X_1 与 X_2 之间的相关性:

$$\rho_{12.3\dots n} = \frac{\text{cov}(X_1, X_2 | X_3, \dots, X_n)}{\sqrt{\text{var}(X_1 | X_3, \dots, X_n) \cdot \text{var}(X_2 | X_3, \dots, X_n)}}.$$

偏相关在因果推断中特别重要——它度量了在控制一组混杂变量后, 两个变量之间的”直接”相关性。

8. 本章总结

概念	公式/描述
联合 cdf	$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2)$
边缘 pmf	$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2)$
边缘 pdf	$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2) dx_2$
条件 pmf	$p_{X_2 X_1}(x_2 x_1) = p(x_1, x_2)/p_{X_1}(x_1)$
条件 pdf	$f_{X_2 X_1}(x_2 x_1) = f(x_1, x_2)/f_{X_1}(x_1)$
全期望	$\mathbb{E}[\mathbb{E}(X_2 X_1)] = \mathbb{E}X_2$
方差分解	$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 X_1)] + \text{var}[\mathbb{E}(X_2 X_1)]$
独立性	$f(x_1, x_2) = f_1(x_1)f_2(x_2)$
协方差	$\text{cov} = \mathbb{E}(X_1X_2) - \mathbb{E}X_1\mathbb{E}X_2$
相关系数	$\rho = \text{cov}/(\sigma_1\sigma_2), -1 \leq \rho \leq 1$

本章内部脉络: 联合分布 (描述共同行为) $\rightarrow$ 边缘分布 (提取单个变量信息) $\rightarrow$ 条件分布 (利用已知变量更新未知变量) $\rightarrow$ 独立性 (无关系时的简化) $\rightarrow$ 相关性 (量化关联程度)。

为下一章铺垫: 第 3 章将系统研究最重要的几类分布, 这些分布在多元情形下自然出现。第 4 章则利用这些分布建立统计推断的基本工具。

习题

EXERCISE 2.1. 2.1.1 设 X_1 和 X_2 的联合 pdf 为 $f(x_1, x_2) = x_1 + x_2, 0 < x_1 < 1, 0 < x_2 < 1$, 其他位置为零。求 X_1 的边缘 pdf。

EXERCISE 2.2. 2.2.1 设 (X_1, X_2) 的联合 pdf 为 $f(x_1, x_2) = 2, 0 < x_1 < x_2 < 1$, 其他位置为零。

(1) 求边缘 pdf $f_{X_1}(x_1)$ 和 $f_{X_2}(x_2)$

(2) 验证 $\int \int f = 1$

EXERCISE 2.3. 2.3.1 设 X_1 和 X_2 具有联合 pdf $f(x_1, x_2) = x_1 + x_2$, $0 < x_1 < 1$, $0 < x_2 < 1$ 。求给定 $X_1 = x_1$ 时 X_2 的条件均值和条件方差。

EXERCISE 2.4. 2.3.2 证明全期望公式: $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}X_2$ 。(提示: 对离散和连续两种情形分别证明)

EXERCISE 2.5. 2.4.1 证明: 若 X_1 和 X_2 独立, 则 $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$ 。

EXERCISE 2.6. 2.4.2 设 (X, Y) 具有联合 pdf $f(x, y) = x + y$, $0 < x < 1$, $0 < y < 1$ 。 X 与 Y 是否独立? 为什么?

EXERCISE 2.7. 2.5.1 设 (X, Y) 具有联合 pdf $f(x, y) = x + y$, $0 < x < 1$, $0 < y < 1$ 。求相关系数 ρ 。

EXERCISE 2.8. 2.5.2 证明: $-1 \leq \text{corr}(X, Y) \leq 1$ 。(提示: 使用 Cauchy-Schwarz 不等式)

EXERCISE 2.9. 2.6.1 设 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。证明条件分布 $X_2 | X_1 = x_1 \sim N(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2))$ 。

EXERCISE 2.10. 2.6.2 设 $(X_1, X_2) \sim N(0, 0, 1, 1, \rho)$ (相关系数为 ρ 的二元标准正态)。求 $X_1 + X_2$ 的分布。

EXERCISE 2.11. 2.7.1 设 X_1, X_2, X_3 为三个独立同分布的随机变量, 每个的 pdf 为 $f(x) = 2x$, $0 < x < 1$ 。求 $Y = \max\{X_1, X_2, X_3\}$ 的分布。

EXERCISE 2.12. 2.7.2 设 $X_1, \dots, X_n \text{ iid} \sim N(\mu, \sigma^2)$ 。令 $\bar{X} = n^{-1} \sum X_i$ 。利用 mgf 证明 $\bar{X} \sim N(\mu, \sigma^2/n)$ 。

9. 附录：公式推导

9.1. 边缘分布公式推导. 背景: 已知联合分布, 如何得到单个变量的边缘分布?

目标: 从联合 pmf/pdf 推导边缘 pmf/pdf 的计算公式。

推导步骤:

离散型: 设 (X_1, X_2) 的联合 pmf 为 $p_{X_1, X_2}(x_1, x_2)$ 。

1. 由边缘 pmf 的定义, X_1 的边缘 pmf 为 $p_{X_1}(x_1) = \mathbb{P}(X_1 = x_1)$ 。

2. 事件 $\{X_1 = x_1\}$ 可以分解为与 X_2 的联合事件:

$$\mathbb{P}(X_1 = x_1) = \sum_{x_2} \mathbb{P}(X_1 = x_1, X_2 = x_2).$$

3. 因此边缘 pmf 公式为

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2).$$

连续型: 设 (X_1, X_2) 的联合 pdf 为 $f_{X_1, X_2}(x_1, x_2)$ 。

1. 由边缘 pdf 的定义, X_1 的边缘 pdf 满足

$$\mathbb{P}(a \leq X_1 \leq b) = \int_a^b f_{X_1}(x_1) dx_1.$$

2. 另一方面,

$$\mathbb{P}(a \leq X_1 \leq b) = \int_a^b \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

3. 比较两式, 由微积分基本定理, 得到边缘 pdf 公式:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2.$$

几何直观: 联合 pdf 是二维” 概率密度曲面”, 边缘 pdf 是该曲面对 x_2 方向” 压扁” 后得到的、一维曲线下的面积。

9.2. 条件分布公式推导. 背景: 已知联合分布, 如何描述” 已知 X_1 的值时 X_2 的分布”?

目标: 推导条件 pmf/pdf 的计算公式。

推导步骤:

离散型:

1. 条件概率的基本定义:

$$\mathbb{P}(X_2 = x_2 \mid X_1 = x_1) = \frac{\mathbb{P}(X_1 = x_1, X_2 = x_2)}{\mathbb{P}(X_1 = x_1)}.$$

2. 代入联合 pmf 和边缘 pmf:

$$p_{X_2|X_1}(x_2 \mid x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}.$$

3. 验证归一性: $\sum_{x_2} p_{X_2|X_1}(x_2 \mid x_1) = 1$ 。

连续型:

1. 连续情形不能直接用条件概率定义, 因为 $\mathbb{P}(X_1 = x_1) = 0$ 。我们用极限思想:

$$f_{X_2|X_1}(x_2 \mid x_1) = \lim_{\Delta \rightarrow 0} \frac{\mathbb{P}(x_1 \leq X_1 < x_1 + \Delta, X_2 \in dx_2)}{\mathbb{P}(x_1 \leq X_1 < x_1 + \Delta) \cdot dx_2}.$$

2. 分子分母同除以 Δ 并取极限, 得到

$$f_{X_2|X_1}(x_2 \mid x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

3. 验证归一性: $\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 \mid x_1) dx_2 = 1$ 。

直觉理解: 条件密度是联合密度在固定 x_1 处的” 切片”, 再除以该切片下的总面积 (边缘密度) 进行归一化。

9.3. 条件密度与 Radon-Nikodym 定理. 背景：连续情形下条件密度 $f_{X_2|X_1}(x_2|x_1) = f(x_1, x_2)/f_{X_1}(x_1)$ 的严格数学基础是什么？

已知条件：

- 联合 pdf $f_{X_1, X_2}(x_1, x_2)$ 存在
- 边缘 pdf $f_{X_1}(x_1) > 0$

目标：严格论证条件密度的存在性与定义。

推导步骤：

1. 条件分布函数定义为

$$F_{X_2|X_1}(x_2 | x_1) = \mathbb{P}(X_2 \leq x_2 | X_1 = x_1).$$

2. 由 Radon-Nikodym 定理：若 $\mathbb{P}_c(\cdot | X_1)$ 是给定 X_1 时的条件概率测度，则存在 Radon-Nikodym 导数（即条件密度）：

$$\mathbb{P}(X_2 \leq x_2 | X_1 = x_1) = \int_{-\infty}^{x_2} f_{X_2|X_1}(x'_2 | x_1) dx'_2.$$

3. 验证条件密度的公式：

$$\int_{-\infty}^{x_2} \frac{f_{X_1, X_2}(x_1, x'_2)}{f_{X_1}(x_1)} dx'_2 = \frac{1}{f_{X_1}(x_1)} \int_{-\infty}^{x_2} f_{X_1, X_2}(x_1, x'_2) dx'_2 = \frac{F_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 对 x_2 求导得到条件密度表达式：

$$\frac{\partial}{\partial x_2} F_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

注：Radon-Nikodym 定理保证了在 σ -有限条件下，条件密度（条件期望的 Radon-Nikodym 导数）的存在性，这是现代概率论的基础结果之一。

9.4. 全期望公式推导. 背景：全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是概率论中最强大的工具之一。

目标：严格推导全期望公式。

推导步骤：

离散型：

1. 条件期望的定义：

$$\mathbb{E}(X_2 | X_1 = x_1) = \sum_{x_2} x_2 \cdot p_{X_2|X_1}(x_2 | x_1) = \sum_{x_2} x_2 \cdot \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}.$$

2. 外层期望是对 X_1 求平均：

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \sum_{x_1} \left[\sum_{x_2} x_2 \cdot \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)} \right] p_{X_1}(x_1).$$

3. 约去 $p_{X_1}(x_1)$ ：

$$= \sum_{x_1} \sum_{x_2} x_2 \cdot p_{X_1, X_2}(x_1, x_2) = \sum_{x_2} x_2 \left[\sum_{x_1} p_{X_1, X_2}(x_1, x_2) \right].$$

4. 内层和是边缘 pmf： $= \sum_{x_2} x_2 \cdot p_{X_2}(x_2) = \mathbb{E}(X_2)$ 。

连续型：类似地，

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} x_2 \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2 \right] f_{X_1}(x_1) dx_1 = \iint x_2 f_{X_1, X_2}(x_1, x_2) dx_1 dx_2 = \mathbb{E}(X_2).$$

意义：全期望公式本质上是”加权平均的加权平均”——先在每个 X_1 条件下计算 X_2 的条件均值，再对条件均值按 X_1 的分布加权平均，结果等于全体平均。

9.5. 方差分解公式推导. 背景：条件方差公式 $\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)]$ 是统计学中最重要的恒等式之一。

目标：证明总方差等于”平均条件方差”加上”条件均值的方差”。

推导步骤：

1. 由方差的定义：

$$\text{var}(X_2) = \mathbb{E}(X_2^2) - [\mathbb{E}(X_2)]^2.$$

2. 对第一项应用全期望公式：

$$\mathbb{E}(X_2^2) = \mathbb{E}[\mathbb{E}(X_2^2 | X_1)].$$

3. 在每个 $X_1 = x_1$ 条件下， $\mathbb{E}(X_2^2 | X_1 = x_1) = \text{var}(X_2 | X_1 = x_1) + [\mathbb{E}(X_2 | X_1 = x_1)]^2$ 。

4. 因此

$$\mathbb{E}(X_2^2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \mathbb{E}[[\mathbb{E}(X_2 | X_1)]^2].$$

5. 代入方差公式：

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \mathbb{E}[[\mathbb{E}(X_2 | X_1)]^2] - [\mathbb{E}(X_2)]^2.$$

6. 注意最后两项恰好是 $\mathbb{E}(X_2 | X_1)$ 的方差：

$$\text{var}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}[[\mathbb{E}(X_2 | X_1)]^2] - [\mathbb{E}(X_2)]^2.$$

7. 代入即得方差分解公式：

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

直观理解：第一项是”组内方差的平均”（知道 X_1 后 X_2 的残余变异），第二项是”组间方差”（不同 X_1 条件下条件均值的变化）。

9.6. Rao-Blackwell 定理. 背景：Rao-Blackwell 定理是统计决策理论的核心结果，说明了如何利用条件化改进估计量。

已知条件：

- T 是 θ 的无偏估计量： $\mathbb{E}_\theta(T) = \theta$
- $S = \mathbb{E}(T | U)$ 是 T 关于充分统计量 U 的条件期望

目标：证明 $\mathbb{E}[(S - \theta)^2] \leq \mathbb{E}[(T - \theta)^2]$ ，即 S 比 T 更好（均方误差更小）。

推导步骤：

1. 由全方差公式：

$$\text{var}_\theta(T) = \mathbb{E}[\text{var}_\theta(T | U)] + \text{var}_\theta[\mathbb{E}_\theta(T | U)].$$

2. 由于 $S = \mathbb{E}(T | U)$ ，有 $\mathbb{E}_\theta(S) = \mathbb{E}_\theta(T) = \theta$ （ S 仍是无偏的）。

3. 由方差分解式两边减去 θ^2 （注意 S 无偏），得

$$\mathbb{E}[(T - \theta)^2] = \underbrace{\mathbb{E}[\text{var}(T | U)]}_{\geq 0} + \mathbb{E}[(S - \theta)^2] \geq \mathbb{E}[(S - \theta)^2].$$

结论：条件化（于充分统计量）不会增加均方误差，且在 T 不是充分统计量的函数时严格减少。这为用条件期望改进任意估计量提供了理论依据。

9.7. 贝叶斯公式推导. 背景：贝叶斯公式是连接先验、似然和后验的桥梁。

已知条件：

- 先验分布： $\theta \sim \pi(\theta)$
- 似然函数： $X | \theta \sim f(x | \theta)$

目标：求后验分布 $\pi(\theta | x)$ 。

推导步骤：

1. 由条件概率的定义：

$$\pi(\theta | x) = \frac{f(x, \theta)}{f(x)} = \frac{f(x | \theta)\pi(\theta)}{f(x)}.$$

2. 其中归一化常数（边际似然）为

$$f(x) = \int f(x | \theta')\pi(\theta') d\theta'.$$

3. 因此贝叶斯公式为

$$\pi(\theta | x) = \frac{f(x | \theta)\pi(\theta)}{\int f(x | \theta')\pi(\theta') d\theta'}.$$

后验均值：作为点估计，

$$\mathbb{E}(\theta | x) = \int \theta \cdot \pi(\theta | x) d\theta = \frac{\int \theta f(x | \theta)\pi(\theta) d\theta}{\int f(x | \theta)\pi(\theta) d\theta}.$$

共轭先验：若先验 π 与似然 $f(\cdot | \theta)$ 共轭，则后验与先验有相同形式，计算大为简化。

9.8. 贝叶斯方法历史概述. 背景: 理解贝叶斯方法的历史脉络有助于认识其哲学内涵。

历史时间线:

1761 年: Thomas Bayes (1702-1761) 发表《An Essay Towards Solving a Problem in the Doctrine of Chances》, 首次提出贝叶斯公式。贝叶斯的证明使用了“逆概率”思想——从观测数据反推原因的概率。

1774 年: Pierre-Simon Laplace (1749-1827) 独立发展了贝叶斯方法, 并将其系统化。拉普拉斯使用贝叶斯方法估计太阳系行星的质量和轨道参数。

19 世纪: 贝叶斯方法在统计界占据主导地位, 但 Frequentist 学派 (Fisher、Pearson、Neyman) 对其“主观先验”提出了批评。

1930-1950 年代: Frequentist 方法成为主流, 贝叶斯方法被边缘化。Fisher 的显著性检验和 Neyman 的置信区间理论主导了统计实践。

1980 年代至今: 由于计算革命 (尤其是 MCMC 方法的发展), 贝叶斯方法复兴。如今它与 Frequentist 方法并列为统计学的两大流派。

哲学争论: 贝叶斯方法的核心争议在于先验分布的选择——

- **客观贝叶斯学派:** 选择无信息先验 (如 Jeffreys 先验), 使后验主要由数据决定
- **主观贝叶斯学派:** 先验分布应反映研究者的真实信念

现代应用: 贝叶斯方法在机器学习 (贝叶斯神经网络)、生物统计 (药物试验)、金融 (风险建模) 等领域有广泛应用。

9.9. 独立性因子化判据推导. 背景: 独立性 $X_1 \perp\!\!\!\perp X_2$ 的定义是 $F(x_1, x_2) = F_1(x_1)F_2(x_2)$, 但这在应用中不方便。因子化判据提供了更实用的检验方法。

目标: 证明 $X_1 \perp\!\!\!\perp X_2 \iff f(x_1, x_2) \equiv g(x_1)h(x_2)$ (对某些 g, h)。

推导步骤:

($\Rightarrow$) 若 $X_1 \perp\!\!\!\perp X_2$:

1. 由独立性, $f_{X_1, X_2}(x_1, x_2) = f_{X_1}(x_1) \cdot f_{X_2}(x_2)$ 。
2. 取 $g(x_1) = f_{X_1}(x_1)$, $h(x_2) = f_{X_2}(x_2)$, 则 $f(x_1, x_2) = g(x_1)h(x_2)$ 。

($\Leftarrow$) 若 $f(x_1, x_2) = g(x_1)h(x_2)$:

1. 对两边积分求边缘:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \underbrace{\int_{-\infty}^{\infty} h(x_2) dx_2}_{C_2} = C_2 g(x_1).$$

同理 $f_{X_2}(x_2) = C_1 h(x_2)$ 。

2. 由归一性 $\iint f = 1$, 得 $C_1 C_2 \iint g(x_1)h(x_2) dx_1 dx_2 = 1$, 故 $C_1 C_2 \cdot C_2 C_1 = 1$, 即 $C_1 C_2 = 1$ (假设 $C_1, C_2 > 0$)。

3. 因此

$$f_{X_1}(x_1)f_{X_2}(x_2) = (C_2 g(x_1)) \cdot (C_1 h(x_2)) = C_1 C_2 g(x_1)h(x_2) = f(x_1, x_2).$$

4. 故 $X_1 \perp\!\!\!\perp X_2$ 。

注：这个判据对于离散型同样适用，只需把积分换成求和。

9.10. 独立 $\Rightarrow$ 不相关的反例. 背景：已知独立一定推出不相关 ($\text{cov} = 0$)，但逆命题一般不成立。这里给出经典反例。

目标：构造 $\text{cov}(X, Y) = 0$ 但 X 与 Y 不独立的例子。

推导步骤：

设 $X \sim \text{Uniform}(-1, 1)$, $Y = X^2$ 。

1. 验证 $\text{cov}(X, Y) = 0$:

$$\text{cov}(X, Y) = \mathbb{E}(X \cdot X^2) - \mathbb{E}(X) \cdot \mathbb{E}(X^2) = \mathbb{E}(X^3) - 0 \cdot \mathbb{E}(X^2).$$

由于 X 对称分布 ($\text{Uniform}(-1, 1)$ 对称于 0), $\mathbb{E}(X^3) = \int_{-1}^1 x^3 \cdot \frac{1}{2} dx = 0$ (奇函数在对称区间积分为零)。

故 $\text{cov}(X, Y) = 0$ 。

2. 验证 X 与 Y 不独立:

给定 $X = 0.5$, 则 $Y = 0.25$ 是确定值。给定 $X = -0.5$, 则 $Y = 0.25$ 也是确定值。但 Y 的取值完全由 X 决定——知道 X 就完全知道 Y , 这说明两者不独立。

更精确地, $\mathbb{P}(Y > 0.5) \neq \mathbb{P}(Y > 0.5 | X > 0)$, 因为 $Y = X^2$ 。

结论：不相关只说明没有线性关系，但不排除非线性依赖。在这个例子中, Y 是 X 的二次函数，它们之间存在明确的函数关系（非线性），但协方差为零。

9.11. 相关系数范围推导. 背景：相关系数满足 $-1 \leq \rho \leq 1$, 这一性质源自 Cauchy-Schwarz 不等式。

目标：严格证明 $|\rho| \leq 1$ 。

已知条件：

$$\rho = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)}\sqrt{\text{var}(X_2)}} = \frac{\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]}{\sigma_1 \sigma_2}.$$

推导步骤：

1. 考虑随机变量 $Y = (X_1 - \mu_1) - t(X_2 - \mu_2)$, 其中 $t \in \mathbb{R}$ 待定。

2. 由方差的非负性:

$$0 \leq \text{var}(Y) = \mathbb{E}(Y^2) = \sigma_1^2 - 2t\text{cov}(X_1, X_2) + t^2\sigma_2^2.$$

3. 将 $\text{cov}(X_1, X_2) = \rho\sigma_1\sigma_2$ 代入:

$$0 \leq \sigma_1^2 - 2t\rho\sigma_1\sigma_2 + t^2\sigma_2^2.$$

4. 这是关于 t 的二次不等式，要使对所有 t 成立，判别式必须 ≤ 0 :

$$(2\rho\sigma_1\sigma_2)^2 - 4\sigma_1^2\sigma_2^2 \leq 0.$$

5. 化简得

$$4\rho^2\sigma_1^2\sigma_2^2 \leq 4\sigma_1^2\sigma_2^2 \implies \rho^2 \leq 1.$$

6. 即 $-1 \leq \rho \leq 1$ 。

等号条件： $|\rho| = 1$ 当且仅当存在 t 使 $\text{var}(Y) = 0$ ，即 Y 几乎处处为零： $X_1 - \mu_1 = t(X_2 - \mu_2)$ ，此时 X_1 与 X_2 有完美线性关系。

9.12. 二元正态条件分布推导. 背景：二元正态分布的条件分布仍是正态的，这是其最重要的性质之一。

已知条件： $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，联合 pdf 为

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{Q(x_1, x_2)}{2(1-\rho^2)}\right\},$$

其中 $Q = \frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}$ 。

目标：求条件分布 $X_2 | X_1 = x_1$ 。

推导步骤：

1. 条件分布的 pdf 为

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f(x_1, x_2)}{f_{X_1}(x_1)} = \frac{f(x_1, x_2)}{\frac{1}{\sigma_1}\phi\left(\frac{x_1-\mu_1}{\sigma_1}\right)}.$$

2. 将 Q 整理成关于 x_2 的二次函数：

$$Q = \frac{1}{1-\rho^2} \left[\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1} \right)^2 + (1-\rho^2)\frac{(x_1-\mu_1)^2}{\sigma_1^2} \right].$$

3. 因此

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)} \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1} \right)^2\right\} \cdot \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}.$$

4. 除以边缘密度 $f_{X_1}(x_1) = \frac{1}{\sigma_1}\phi\left(\frac{x_1-\mu_1}{\sigma_1}\right)$ ，消去与 x_2 无关的因子：

$$f_{X_2|X_1}(x_2 | x_1) = \frac{1}{\sigma_2\sqrt{2\pi(1-\rho^2)}} \exp\left\{-\frac{1}{2(1-\rho^2)} \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1} \right)^2\right\}.$$

5. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1-\rho^2)$ 的正态分布密度。

6. 故

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1-\rho^2)\right).$$

最优线性预测：条件均值 $\mathbb{E}(X_2 | x_1) = \mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 是 x_1 的线性函数，它在均方误差意义下是 X_2 的最优预测。

9.13. 回归理论的简要推导. 背景：回归分析的核心是找到使预测误差最小的线性预测器。

目标：在所有线性预测 $\hat{X}_2 = \alpha + \beta X_1$ 中，找到均方误差最小的预测。

推导步骤：

1. 均方预测误差 (MSE) 为

$$\mathbb{E}[(X_2 - \alpha - \beta X_1)^2] = \mathbb{E}(X_2^2) + \alpha^2 + \beta^2\mathbb{E}(X_1^2) - 2\alpha\mathbb{E}(X_2) - 2\beta\mathbb{E}(X_1X_2) + 2\alpha\beta\mathbb{E}(X_1).$$

2. 对 α 求偏导并设为零：

$$\frac{\partial \text{MSE}}{\partial \alpha} = 2\alpha + 2\beta\mathbb{E}(X_1) - 2\mathbb{E}(X_2) = 0 \implies \alpha^* = \mathbb{E}(X_2) - \beta\mathbb{E}(X_1).$$

3. 对 β 求偏导并设为零：

$$\frac{\partial \text{MSE}}{\partial \beta} = 2\beta\mathbb{E}(X_1^2) + 2\alpha\mathbb{E}(X_1) - 2\mathbb{E}(X_1X_2) = 0.$$

4. 代入 α^* ：

$$\beta^*\mathbb{E}(X_1^2) + [\mathbb{E}(X_2) - \beta^*\mathbb{E}(X_1)]\mathbb{E}(X_1) - \mathbb{E}(X_1X_2) = 0.$$

5. 整理得

$$\beta^* = \frac{\mathbb{E}(X_1X_2) - \mathbb{E}(X_1)\mathbb{E}(X_2)}{\mathbb{E}(X_1^2) - [\mathbb{E}(X_1)]^2} = \frac{\text{cov}(X_1, X_2)}{\text{var}(X_1)} = \rho \frac{\sigma_2}{\sigma_1}.$$

6. 最优线性预测为

$$\hat{X}_2^* = \mathbb{E}(X_2) + \rho \frac{\sigma_2}{\sigma_1} (X_1 - \mathbb{E}(X_1)).$$

7. 对二元正态分布，这就是条件均值。

最小二乘法：在样本情形，用样本矩代替总体矩，得到 $\hat{\beta} = \hat{\rho} \frac{s_2}{s_1}$ ，其中 s_1^2, s_2^2 是样本方差， $\hat{\rho}$ 是样本相关系数。

9.14. 两两独立不推出相互独立反例。背景：对于多个随机变量，两两独立不一定推出相互独立，这是一个经典反例。

目标：构造三个事件 A, B, C ，使得两两独立但三者不相互独立。

推导步骤：

考虑抛两枚公平硬币的样本空间 $\{HH, HT, TH, TT\}$ ，每个结果等概率 $1/4$ 。

定义事件：

- A ：第一枚硬币正面（ HH 或 HT ）
- B ：第二枚硬币正面（ HH 或 TH ）
- C ：两面相同（ HH 或 TT ）

1. 验证两两独立：

$$\mathbb{P}(A) = \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}.$$

$$\mathbb{P}(A \cap B) = \mathbb{P}(HH) = \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(B) = \frac{1}{2} \cdot \frac{1}{2}.$$

同理 $\mathbb{P}(A \cap C) = \mathbb{P}(B \cap C) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2}$ 。故 A, B, C 两两独立。

2. 验证三者不相互独立：

$$\mathbb{P}(A \cap B \cap C) = \mathbb{P}(HH) = \frac{1}{4}.$$

但 $\mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8} \neq \frac{1}{4}$ 。

3. 不独立性体现：给定 A 和 B 都发生（即两面都是正面），则 C 必然发生（两面相同），即

$$\mathbb{P}(C \mid A \cap B) = 1 \neq \mathbb{P}(C) = \frac{1}{2}.$$

结论：两两独立只保证任意两个变量之间的依赖关系被消除，但不能保证多个变量之间的整体依赖结构。这个反例提醒我们，在处理多元随机变量时需要小心。

9.15. 独立随机变量线性组合的 mgf 推导. 背景：若 $X_1, \dots, X_n$ 相互独立， $T = \sum_{i=1}^n k_i X_i$ ，则 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标：推导独立随机变量线性组合的矩母函数。

推导步骤：

1. 由 mgf 的定义：

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[e^{t \sum_{i=1}^n k_i X_i}\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立， $e^{tk_1 X_1}, \dots, e^{tk_n X_n}$ 也相互独立。

3. 对独立随机变量的乘积取期望，等于各自期望的乘积：

$$M_T(t) = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_{X_i}(k_i t).$$

特别情形：若 $X_1, \dots, X_n$ iid，则 $M_T(t) = [M_X(t)]^n$ 。

例如，若 $X_i \sim N(\mu, \sigma^2)$ ， $M_X(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ ，则

$$M_{\bar{X}}(t) = M_X(t/n)^n = \exp\left\{n \left(\mu \frac{t}{n} + \frac{1}{2}\sigma^2 \frac{t^2}{n^2}\right)\right\} = \exp\left\{\mu t + \frac{1}{2} \frac{\sigma^2}{n} t^2\right\},$$

这正是 $N(\mu, \sigma^2/n)$ 的 mgf。

9.16. 中心极限定理概述. 背景：中心极限定理 (CLT) 是概率论和统计学中最重要的结果之一。

已知条件：

- $X_1, \dots, X_n$ iid (独立同分布)
- $\mathbb{E}X_i = \mu$, $\text{var}(X_i) = \sigma^2 < \infty$
- $\bar{X} = n^{-1} \sum X_i$

目标：描述 $\bar{X}$ (或标准化后的 $\bar{X}$) 的极限分布。

推导思路：

1. 考虑标准化和 $Z_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$ 。
2. 由独立随机变量和的 mgf 性质， Z_n 的 mgf 为

$$M_{Z_n}(t) = \left[M_X\left(\frac{t}{\sqrt{n}\sigma}\right) \right]^n e^{-\sqrt{n}\mu t/\sigma}.$$

3. 对 $M_X(t/\sqrt{n}\sigma)$ 在 $t = 0$ 处 Taylor 展开：

$$M_X\left(\frac{t}{\sqrt{n}\sigma}\right) = 1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right).$$

4. 代入得

$$M_{Z_n}(t) = \left(1 + \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n e^{-\sqrt{n}\mu t/\sigma} \xrightarrow{n \rightarrow \infty} e^{t^2/2}.$$

5. 标准正态分布 $\mathcal{N}(0, 1)$ 的 mgf 正是 $e^{t^2/2}$ 。

6. 由 mgf 的唯一性（若随机变量的 mgf 收敛到某个分布的 mgf，则该随机变量的分布收敛到该分布），得

$$Z_n \Rightarrow \mathcal{N}(0, 1), \quad \text{即} \quad \sqrt{n}(\bar{X} - \mu)/\sigma \Rightarrow \mathcal{N}(0, 1).$$

核心洞察：无论 X_i 原来是什么分布（只要方差有限），其样本均值经适当标准化后都收敛到标准正态分布。这使得正态分布在统计推断中具有核心地位。

CHAPTER 3

Special Distributions

Chapter 3 Overview

在前两章中，我们建立了描述单一和多元随机变量的数学框架。现在我们面临一个根本性问题：

哪些概率分布值得我们特别关注？为什么？

答案蕴藏在统计学本身的核心之中。某些分布在自然界、实验中和理论研究里反复出现——这不是任意的选择，而是来自简单、重复模式的自然涌现：独立试验中成功次数的计数、等待时间的测量、测量误差的建模，以及描述平均值的行为。

本章介绍统计学理论及实践中最重要的分布族。我们将发现这些分布如何从基本原理中产生，欣赏它们之间错综复杂的联系，理解每个分布在统计工作中的不可替代性。

本章路线图：

- Bernoulli $\rightarrow$ Binomial (二项分布) $\rightarrow$ Negative Binomial/Geometric (负二项/几何分布) $\rightarrow$ Multinomial (多项分布) $\rightarrow$ Hypergeometric (超几何分布)
- Poisson (作为二项分布的极限形式)
- Gamma (Gamma 分布) $\rightarrow \chi^2$ (卡方分布) $\rightarrow$ Beta (BETA 分布)
- Normal (正态分布) $\rightarrow$ Bivariate Normal (二元正态分布) $\rightarrow$ Multivariate Normal (多元正态分布)
- t 和 F 分布 (由正态理论导出)

这些分布之间的关系并非偶然——它们反映了将贯穿整个统计推断的深层数学结构。

1. 3.1 二项分布及其相关分布

1.1. 为什么研究二项分布？ 考虑以下场景：抛掷一枚硬币 100 次，出现多少次正面？一袋 1000 件产品中有多少件次品？接受实验治疗后有多少患者康复？

这些问题共享一个共同的数学结构：我们进行 n 次独立试验，每次试验只有两个可能结果（成功或失败），然后计算成功出现的总次数。这个“计数问题”遍布统计学，而二项分布正是其天然数学模型。

二项分布起源于 18 世纪对赌博游戏的研究。Jakob Bernoulli (1713 年) 为 Bernoulli 试验 (Bernoulli trial) 建立了大数定律 (弱律)，奠定了理论基础。随后 Abraham de Moivre 和 Pierre-Simon Laplace 发展出了逼近方法，最终导致了中心极限定理——这是数学最卓越的成果之一。

1.2. Bernoulli 试验 (Bernoulli Trial). Bernoulli 试验是最简单的随机实验：结果只有两个互斥且穷举的可能性——成功或失败。

设随机变量 X 表示结果：

$$X(\text{成功}) = 1, \quad X(\text{失败}) = 0.$$

概率质量函数 (pmf) 为：

$$p(x) = p^x(1-p)^{1-x}, \quad x = 0, 1, \quad (9)$$

其中 p 是成功概率。

Bernoulli 分布的均值和方差为：

$$\mathbb{E}X = p, \quad \text{var}(X) = p(1-p). \quad (10)$$

EXAMPLE 3.1 (抛硬币). 如果抛一枚均匀硬币 ($p = 1/2$), 则 $\mathbb{E}X = 1/2$, $\text{var}(X) = 1/4$ 。标准差为 0.5, 意味着典型偏差约为半次硬币翻转。

为什么 Bernoulli 分布如此基础? 它是最简单但非平凡的随机变量——既不是确定性常数, 也不是均匀分布。它捕捉了“是/否”决策不确定性的本质。每个二元结果的实验都可以建模为 Bernoulli 试验。

1.3. 二项分布 (Binomial Distribution). 现在我们问： n 次独立 Bernoulli 试验中成功次数的分布是什么？

设 X_i 是第 i 次试验的 Bernoulli 变量, 我们关心 $X = \sum_{i=1}^n X_i$ 。

恰好有 x 次成功意味着：我们在 n 个位置中选择 x 个作为成功 (共有 $\binom{n}{x}$ 种方式), 其余 $n-x$ 个位置是失败。每种排列的概率为 $p^x(1-p)^{n-x}$ 。

因此, pmf 为：

$$p(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n. \quad (11)$$

记作 $X \sim \text{Bin}(n, p)$, 称 n 和 p 为二项分布的参数。

验证 $p(x)$ 之和为 1: 由二项式定理,

$$\sum_{x=0}^n \binom{n}{x} p^x (1-p)^{n-x} = [(1-p) + p]^n = 1^n = 1.$$

EXAMPLE 3.2 (骰子问题). 掷一枚均匀六面骰子 3 次, 恰好出现 2 次六点的概率是多少？

设 X 为六点出现的次数, 则 $X \sim \text{Bin}(n=3, p=1/6)$:

$$\mathbb{P}(X=2) = \binom{3}{2} \left(\frac{1}{6}\right)^2 \left(\frac{5}{6}\right)^1 = 3 \times \frac{1}{36} \times \frac{5}{6} = \frac{15}{216} \approx 0.06944.$$

在 R 中计算: `dbinom(2, 3, 1/6)`。

矩母函数 (mgf): 二项分布的 mgf 为:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x} = [(1-p) + pe^t]^n. \quad (12)$$

由此可得均值和方差:¹

$$\mathbb{E}X = M'(0) = np, \quad \text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p). \quad (13)$$

EXAMPLE 3.3 (电池寿命). 假设一枚电池有概率 $p = 0.95$ 可以使用至少 100 小时。一包 $n = 10$ 枚电池中, 预期有 $np = 9.5$ 枚可以使用至少 100 小时, 方差为 $np(1-p) = 0.475$ 。

至少 8 枚电池可用的概率为:

$$\mathbb{P}(X \geq 8) = \sum_{x=8}^{10} \binom{10}{x} (0.95)^x (0.05)^{10-x}.$$

在 R 中: $1 - \text{pbinom}(7, 10, 0.95) = 0.9885$ 。

二项分布的可加性. 二项分布最重要的性质之一是在相同成功概率下的可加性。

THEOREM 3.1 (二项分布的可加性). 若 $X_1 \sim \text{Bin}(n_1, p)$ 和 $X_2 \sim \text{Bin}(n_2, p)$ 独立, 则

$$X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p).$$

直观理解: 想象两堆独立的硬币翻转。第一堆 n_1 枚硬币产生 X_1 个正面, 第二堆 n_2 枚硬币产生 X_2 个正面。合并后, 我们有 $n_1 + n_2$ 枚硬币, 总正面数为 $X_1 + X_2$ 。这仍然服从二项分布, 样本量是合并后的总量。²

这种可加性反映了计数的本质: 如果我们在两批试验 (每批具有相同成功概率) 中计数成功次数, 总数就是简单求和。

EXAMPLE 3.4. $\text{Bin}(n, p)$ 分布的众数 (最可能取值) 为 $\lfloor (n+1)p \rfloor$ 。这很直观: 成功次数的期望值是 np , 众数应该接近这个值。

1.4. 负二项分布与几何分布. 一个不同的问题: 不是计数 n 次试验中的成功次数, 而是问: 需要多少次试验才能实现第 r 次成功?

这个问题引出了负二项分布。设 Y 为第 r 次成功前的失败次数, 则试验总次数为 $Y + r$ 。

恰好有 y 次失败发生在第 r 次成功之前意味着: 前 $y+r-1$ 次试验恰好包含 $r-1$ 次成功和 y 次失败 (任意顺序), 而最后一次 (第 $y+r$ 次) 必须是成功。这样的序列数为 $\binom{y+r-1}{r-1}$:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots \quad (14)$$

¹推导见附录。

²使用 mgf 的证明见附录。

记作 $Y \sim \text{NB}(r, p)$ 。该分布的名称来源于 $p_Y(y)$ 是 $p^r[1 - (1 - p)]^{-r}$ 展开式中的通项。³

当 $r = 1$ 时, 得到**几何分布 (geometric distribution)**:

$$p_Y(y) = p(1 - p)^y, \quad y = 0, 1, 2, \dots \quad (15)$$

从 Bernoulli 试验的角度看, Y 是直到第一次成功前的失败次数。

EXAMPLE 3.5 (血型问题). 设一个人拥有 B 型血的概率为 $p = 0.12$ 。抽取患者直到获得 10 个 B 型血的人。最多需要检测 30 个患者的概率是多少?

设 $Y \sim \text{NB}(r = 10, p = 0.12)$ 。我们需要 $\mathbb{P}(Y \leq 20)$ (因为第 10 次成功发生在试验 $y + r = y + 10$, $y \leq 20$ 意味着最多 30 次试验)。

在 R 中: `pnbinom(20, 10, 0.12) = 0.0019`。概率相当小!

EXAMPLE 3.6 (首次成功等待时间). 对于 $p = 0.12$ 的几何分布, 必须恰好检测 11 个患者才能找到第一个 B 型血的人的概率为:

$$\mathbb{P}(Y = 11) = (0.12)(0.88)^{10} \approx 0.0294.$$

在 R 中: `dgeom(11, 0.12)`。

EXAMPLE 3.7 (几何分布的无记忆性). 几何分布具有独特的**无记忆性 (memorylessness property)**:

$$\mathbb{P}(Y \geq k + j \mid Y \geq k) = \mathbb{P}(Y \geq j), \quad k, j \geq 0. \quad (16)$$

这是什么意思? 如果你已经失败了 k 次, 那么距离第一次成功的剩余等待时间与开始时完全相同。过去的失败不会改变未来的期望。这个性质刻画了 $\{0, 1, 2, \dots\}$ 上所有离散分布中几何分布的独特地位。⁴

几何分布 (支撑集为 $\{0, 1, 2, \dots\}$) 的均值和方差为:⁵

$$\mathbb{E}Y = \frac{1 - p}{p}, \quad \text{var}(Y) = \frac{1 - p}{p^2}. \quad (17)$$

EXAMPLE 3.8. 负二项分布的 *mgf* 为:

$$M(t) = \frac{p^r}{[1 - (1 - p)e^t]^r}, \quad t < -\log(1 - p).$$

这可以用负二项级数推导。⁶

³推导见附录。

⁴证明见附录。

⁵推导见附录。

⁶推导见附录。

1.5. 多项分布 (Multinomial Distribution). 二项分布自然推广到 k 个类别。每次试验恰好发生 k 个互斥类别中的一个。

设类别为 $C_1, C_2, \dots, C_k$, 概率分别为 $p_1, p_2, \dots, p_k$ (其中 $\sum_{i=1}^k p_i = 1$)。独立重复实验 n 次。设 X_i 为类别 i 出现的次数。

$(X_1, X_2, \dots, X_k)$ 的联合 pmf 为:

$$\mathbb{P}(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! x_2! \dots x_k!} p_1^{x_1} \dots p_k^{x_k}, \quad (18)$$

其中 $\sum_{i=1}^k x_i = n$ 。

称 $(X_1, \dots, X_k)$ 服从参数为 n 和 $p_1, \dots, p_k$ 的**多项分布**。二项分布是 $k = 2$ 的特殊情形。⁷

性质: 对每个 i , X_i 的边缘分布为 $\text{Bin}(n, p_i)$ 。 X_i 和 X_j ($i \neq j$) 之间的协方差为:

$$\text{cov}(X_i, X_j) = -np_i p_j. \quad (19)$$

EXAMPLE 3.9 (掷骰子). 掷一枚均匀六面骰子 $n = 30$ 次。恰好得到 5 个一点、4 个两点、6 个三点、3 个四点、7 个五点和 5 个六点的概率是多少?

这里 $k = 6$, 对所有 i 有 $p_i = 1/6$ 。概率为:

$$\frac{30!}{5!4!6!3!7!5!} \left(\frac{1}{6}\right)^{30} \approx 0.0028.$$

EXAMPLE 3.10. X_i 和 X_j 的相关系数为:

$$\rho_{ij} = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}}.$$

这种负相关很直观: 如果我们观察到类别 i 出现更多, 那么剩余给类别 j 的试验次数就更少。

1.6. 超几何分布 (Hypergeometric Distribution). 核心问题: 不放回抽样时成功次数的分布是什么?

考虑一批 N 件产品, 其中 D 件次品。我们不放回地抽取 n 件, X 为样本中次品的个数。与二项情形不同, 连续抽取不独立, 因为抽样过程中组成成分在变化。

pmf 为:

$$p(x) = \frac{\binom{N-D}{n-x} \binom{D}{x}}{\binom{N}{n}}, \quad x = 0, 1, \dots, \min(n, D). \quad (20)$$

记作 $X \sim \text{Hypergeometric}(N, D, n)$ 。

均值和方差:

$$\mathbb{E}X = n \frac{D}{N}, \quad \text{var}(X) = n \frac{D}{N} \left(1 - \frac{D}{N}\right) \frac{N-n}{N-1}. \quad (21)$$

因子 $\frac{N-n}{N-1}$ 是**有限总体校正因子 (finite population correction factor)**。当 $N \gg n$ 时, 它趋近于 1, 超几何分布近似于 $p = D/N$ 的二项分布。⁸

⁷推导见附录。

⁸推导见附录。

这个近似反映了一个重要原理：当样本量相对于总体较小时，不放回抽样几乎等同于放回抽样。

EXAMPLE 3.11 (抽牌). 从一副 52 张牌中不放回地抽取 2 张。恰好得到 1 张 A 的概率是多少？

这里 $N = 52$, $D = 4$ (A 的数量), $n = 2$ 。我们需要 $\mathbb{P}(X = 1)$:

$$\mathbb{P}(X = 1) = \frac{\binom{48}{1}\binom{4}{1}}{\binom{52}{2}} = \frac{48 \times 4}{1326} \approx 0.1448.$$

作为对比，放回抽样（二项分布）的概率为：

$$\binom{2}{1} \left(\frac{4}{52}\right) \left(\frac{48}{52}\right) \approx 0.1412.$$

概率非常接近！

2. 3.2 Poisson 分布

在自然界和社会中存在一类显著的现象：**在固定时间或空间区间内发生的事件次数**。例子包括：

- 每小时到达银行的客户数
- 手稿每页的印刷错误数
- 一个地区每年的地震次数
- 放射性物质的衰变事件数
- 每周一个路口的事故数

这些现象有一个共同特征：**每个单独事件的概率很小，但机会数量很大**。这正是 Poisson 分布出现的领域。

历史注记：Poisson 分布由 Siméon Denis Poisson 于 1837 年引入，最初用于分析法国法院判决数据——法官在给定时间段内做出一定数量判决的概率。Poisson 当时并不知道，他的分布会成为整个统计学中最广泛使用的工具之一。

2.1. 定义与性质. 若离散随机变量 X 的 pmf 为：

$$p(x) = \mathbb{P}(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots \quad (22)$$

则称 X 服从参数为 $\lambda > 0$ 的 Poisson 分布。

记作 $X \sim \text{Poisson}(\lambda)$ 。

验证： 因为 $e^\lambda = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$,

$$\sum_{x=0}^{\infty} p(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} \cdot e^\lambda = 1. \quad (3.2.1)$$

参数 λ 有一个优美的解释：它是分布的均值和方差：

$$\mathbb{E}X = \lambda, \quad \text{var}(X) = \lambda. \quad (23)$$

9

这里有一个令人惊讶且有用的性质：均值等于方差！这是 Poisson 分布的标志特征，可用于检验数据是否可能服从 Poisson 模型。

EXAMPLE 3.12 (汽车事故). 设 X 为一个繁忙路口每周的汽车事故数。假设 $X \sim \text{Poisson}(\lambda = 2)$ 。

则 $\mathbb{E}X = 2$, $\text{std}(X) = \sqrt{2} \approx 1.41$ 。

- $\mathbb{P}(X \geq 1) = 1 - \mathbb{P}(X = 0) = 1 - e^{-2} \approx 0.8647$
- $\mathbb{P}(3 \leq X \leq 8) = \mathbb{P}(X \leq 8) - \mathbb{P}(X \leq 2) \approx 0.3231$

在 R 中: $1 - \text{ppois}(0, 2)$ 和 $\text{ppois}(8, 2) - \text{ppois}(2, 2)$ 。

EXAMPLE 3.13 (巧克力碎片). 一块饼干中巧克力碎片的数量服从 Poisson 分布。我们希望至少含有 2 片碎片的概率大于 0.99。求最小的均值 λ 。

我们需要：

$$\mathbb{P}(X \geq 2) = 1 - \mathbb{P}(X = 0) - \mathbb{P}(X = 1) = 1 - e^{-\lambda} - \lambda e^{-\lambda} > 0.99.$$

求解: $e^{-\lambda}(1 + \lambda) < 0.01$ 。通过试错, $\lambda \approx 6$ 有效, 因为 $e^{-6}(7) \approx 0.007$ 。

所以平均至少需要 6 片!

2.2. Poisson 分布对二项分布的近似. 概率论中最重要的极限定理之一, 连接了二项分布和 Poisson 分布。

THEOREM 3.2 (Poisson 分布对二项分布的近似). 若 $X_n \sim \text{Bin}(n, p_n)$, 且当 $n \rightarrow \infty$ 时 $np_n \rightarrow \lambda$, 则对任意固定的 k :

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}.$$

即 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

直观理解: 当 n 很大且 p 很小时, 二项分布的行为几乎与 Poisson 分布完全相同。关键洞见是: 在极限中只有 $\lambda = np$ (均值) 起作用。¹⁰

EXAMPLE 3.14 (印刷错误). 一份手稿有 500 页, 每页约 300 个单词。一个单词拼写错误的概率为 $p = 1/10,000$, 则每页错误数服从 $\text{Bin}(300, 1/10000) \approx \text{Poisson}(0.03)$ 。

使用 Poisson 模型:

$$\mathbb{P}(\text{至少 1 个错误}) \approx 1 - e^{-0.03} \approx 0.03.$$

这就解释了为什么 Poisson 分布常用于稀有事件计数!

EXAMPLE 3.15. 若 $X_1 \sim \text{Poisson}(\lambda_1)$ 和 $X_2 \sim \text{Poisson}(\lambda_2)$ 独立, 则 $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$ 。这种可加性反映了独立 Poisson 过程 (Poisson process) 的叠加性质。

⁹推导见附录 ??。

¹⁰证明见附录。

3. 3.3 Gamma、 χ^2 与 Beta 分布

这三种分布构成了连续统计推断的支柱。理解它们之间的关系对于掌握统计学的数学基础至关重要。

3.1. Gamma 函数. Gamma 函数架起了阶乘与积分之间的桥梁——这是数学中最美的恒等式之一。

DEFINITION 3.1 (Gamma 函数). 对于 $\alpha > 0$, Gamma 函数定义为:

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx. \quad (3.3.1)$$

关键性质 (递归公式):

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha). \quad (3.3.2)$$

这来自分部积分: ¹¹:

$$\Gamma(\alpha + 1) = \int_0^{\infty} x^{\alpha} e^{-x} dx = [-x^{\alpha} e^{-x}]_0^{\infty} + \alpha \int_0^{\infty} x^{\alpha-1} e^{-x} dx = \alpha \Gamma(\alpha).$$

对于正整数 n :

$$\Gamma(n) = (n-1)!.$$

Gamma 函数还与 Beta 函数有联系:

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} = \int_0^1 t^{\alpha-1}(1-t)^{\beta-1} dt. \quad (3.3.3)$$

EXAMPLE 3.16 (Gamma 函数的值). • $\Gamma(1) = 0! = 1$

- $\Gamma(2) = 1! = 1$
- $\Gamma(3) = 2! = 2$
- $\Gamma(4) = 3! = 6$
- $\Gamma(\frac{1}{2}) = \sqrt{\pi}$ (一个惊人的结果!)

3.2. Gamma 分布. Gamma 分布是 $(0, \infty)$ 上的连续分布, 它统一了指数分布和卡方分布。

DEFINITION 3.2 (Gamma 分布). 若连续随机变量 X 的 pdf 为:

$$f(x) = \begin{cases} \frac{1}{\Gamma(\alpha)\beta^{\alpha}} x^{\alpha-1} e^{-x/\beta} & x > 0 \\ 0 & \text{elsewhere.} \end{cases} \quad (3.3.4)$$

则称 X 服从参数为 $\alpha > 0$ (形状参数) 和 $\beta > 0$ (尺度参数) 的 Gamma 分布, 记作 $X \sim \Gamma(\alpha, \beta)$ 。

¹¹推导见附录。

验证 $f(x)$ 积分等于 1: 使用代换 $z = x/\beta$, $dz = dx/\beta$:

$$\int_0^\infty \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)} \int_0^\infty z^{\alpha-1} e^{-z} dz = 1.$$

参数的含义:

- α (形状参数, shape): 控制分布的形状。较大的 α 意味着更多质量集中在均值附近。
- β (尺度参数, scale): 控制分散程度。较大的 β 意味着在较大值处有更多概率。

特殊情形:

- $\Gamma(1, \beta) = \text{Exp}(1/\beta)$ (指数分布, exponential distribution)
- $\Gamma(n/2, 2) = \chi^2(n)$ (自由度为 n 的卡方分布, chi-square distribution)

矩母函数:

$$M(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}. \quad (3.3.5)$$

由此可得均值和方差: ¹²

$$\mathbb{E}X = \alpha\beta, \quad \text{var}(X) = \alpha\beta^2. \quad (3.3.6)$$

EXAMPLE 3.17 (电池寿命). 设 X 为某种电池在极寒条件下的寿命 (小时)。假设 $X \sim \Gamma(5, 4)$ 。

则:

- 平均寿命: $\mathbb{E}X = 5 \times 4 = 20$ 小时
- 标准差: $\sqrt{5 \times 16} = 8.94$ 小时
- 至少使用 50 小时的概率: $1 - F(50) = 0.0053$ (在 R 中: `1 - pgamma(50, shape=5, scale=4)`)
- 中位寿命: $F^{-1}(0.5) = 18.68$ 小时 (在 R 中: `qgamma(0.5, shape=5, scale=4)`)

EXAMPLE 3.18. 若 $X_1 \sim \Gamma(\alpha_1, \beta)$ 和 $X_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。这种可加性反映了 Gamma 分布等待时间的自然结构。 ¹³

EXAMPLE 3.19. Gamma 分布的危险函数 (hazard function) 为 $r(x) = \frac{x^{\alpha-1}e^{-x/\beta}}{\beta^\alpha \Gamma(\alpha)(1-F(x))}$ 。对于指数分布 ($\alpha = 1$), $r(x) = 1/\beta$ 是常数; 对于 $\alpha > 1$, $r(x)$ 递增; 对于 $\alpha < 1$, $r(x)$ 递减。

3.3. χ^2 分布. 卡方分布在统计学中处于核心地位, 它自然出现在涉及方差和平方正态变量和的问题中。

DEFINITION 3.3 (卡方分布). 设 $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid, 则

$$X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n). \quad (3.3.7)$$

参数 n 称为自由度 (degrees of freedom) 数目。

¹²推导见附录。

¹³使用 mgf 的证明见附录。

χ^2 分布是 $\Gamma(n/2, 2)$ 的特殊情形：如果 $X \sim \chi^2(n)$ ，则 $X \sim \Gamma(n/2, 2)$ 。

均值和方差：

$$\mathbb{E}X = n, \quad \text{var}(X) = 2n. \quad (3.3.8)$$

EXAMPLE 3.20. 若 $X_1 \sim \chi^2(m)$ 和 $X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$ 。这直接来自 *Gamma* 分布的可加性。

为什么它很重要？ 样本方差的抽样分布与 χ^2 分布密切相关，这使它成为方差估计和假设检验的基础。

EXAMPLE 3.21 (样本方差分布). 对于 *iid* $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ ，样本方差 S^2 满足：

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1). \quad (3.3.9)$$

这个基本结果告诉我们：偏离均值的缩放平方和服从卡方分布。它是方差置信区间和 ANOVA 的基础。

EXAMPLE 3.22 (卡方分位数). 假设 $X \sim \chi^2(10)$ 。在 *R* 中：

- 均值： $\mathbb{E}X = 10$ ，标准差： $\sqrt{20} = 4.47$
- 四分位数：`qchisq(c(0.25, 0.5, 0.75), 10) = (6.74, 9.34, 12.55)`

3.4. Beta 分布. Beta 分布是区间 $(0, 1)$ 上的连续分布，特别适用于建模概率和比例。

DEFINITION 3.4 (Beta 分布). 若 X 的 *pdf* 为：

$$f(x) = \begin{cases} \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} & 0 < x < 1 \\ 0 & \text{elsewhere,} \end{cases} \quad (3.3.10)$$

其中 $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ ，则 $X \sim \text{Beta}(\alpha, \beta)$ 。

Beta 函数 $B(\alpha, \beta)$ 使分布归一化，确保 $\int_0^1 f(x)dx = 1$ 。

均值和方差：

$$\mathbb{E}X = \frac{\alpha}{\alpha + \beta}, \quad \text{var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}. \quad (3.3.11)$$

14

特殊情形：

- $\text{Beta}(1, 1) = \text{Uniform}(0, 1)$ (均匀分布)
- $\text{Beta}(\alpha, 1) = \text{Power}(1/\alpha)$ ($(0, 1)$ 上的幂分布)

EXAMPLE 3.23 (Beta 分布的形状). *Beta* 分布提供了丰富多样的形状：

- $\alpha = \beta = 1$ ：均匀分布
- $\alpha = \beta > 1$ ：对称、峰形

¹⁴推导见附录 ??。

- $\alpha > \beta$: 右偏
- $\alpha < \beta$: 左偏

EXAMPLE 3.24. 在贝叶斯统计中, 当我们用 *Beta* 分布作为二项分布参数 p 的先验时, 后验分布仍然是 *Beta* 分布。这称为**共轭先验** (*conjugate prior*) 关系。*Beta*-二项模型是贝叶斯分析中最重要的共轭对之一。¹⁵

Beta 分布的灵活性——通过不同的 α, β 值在 $(0, 1)$ 上捕捉各种形状——使其成为建模不确定概率的理想选择。

4. 3.4 正态分布 (Normal Distribution)

在所有概率分布中, **正态分布 (normal distribution)** 占据至高无上的地位。它构成了统计推断、计量经济学、信号处理及许多其他领域的基石。

正态分布的重要性源于三个关键事实:

- (1) **中心极限定理 (Central Limit Theorem)**: 许多独立小因素的和近似正态分布
- (2) **数学优美性 (Mathematical elegance)**: 正态变量的线性组合仍然是正态的
- (3) **可解释的参数 (Interpretable parameters)**: 均值和方差都有清晰、直观的含义

历史注记: 正态分布由 Carl Friedrich Gauss 于 1809 年在研究测量误差时引入。虽然 Laplace 早些时候讨论过误差分布, 但 Gauss 的工作巩固了正态分布在统计学中的核心地位。这就是为什么我们经常称它为“高斯分布 (Gaussian distribution)”。

4.1. 定义与基本性质.

DEFINITION 3.5 (正态分布). 若随机变量 X 的 pdf 为:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\}, \quad -\infty < x < \infty. \quad (3.4.1)$$

则称 X 服从正态分布, 记作 $X \sim N(\mu, \sigma^2)$, 其中 μ 是均值, σ^2 是方差。

标准正态分布是 $N(0, 1)$, 其 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$, cdf 为 $\Phi(z)$ 。

关键性质: 若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$ 。这种标准化使得任何正态概率计算都可以转化为标准正态计算:

$$\mathbb{P}(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right). \quad (3.4.2)$$

EXAMPLE 3.25 (身高分布). 假设成年男性的身高为 $N(\mu = 70, \sigma^2 = 16)$ (英寸)。则:

- 一个男性超过 6 英尺 (72 英寸) 的概率: $Z = (72 - 70)/4 = 0.5$, 所以 $\mathbb{P}(X > 72) = 1 - \Phi(0.5) \approx 0.3085$

¹⁵共轭先验的讨论见附录。

- 95 分位数: $x_{0.95} = 70 + 4 \cdot \Phi^{-1}(0.95) \approx 76.6$ 英寸
- 在一个标准差内的概率: $\Phi(1) - \Phi(-1) \approx 0.6827$

$N(\mu, \sigma^2)$ 的 mgf 为:

$$M(t) = \exp \left\{ \mu t + \frac{1}{2} \sigma^2 t^2 \right\}, \quad -\infty < t < \infty. \quad (3.4.3)$$

16

由此得 $\mathbb{E}X = \mu$, $\text{var}(X) = \sigma^2$ 。

THEOREM 3.3 (正态变量的线性组合). 若 $X_1 \sim N(\mu_1, \sigma_1^2)$ 和 $X_2 \sim N(\mu_2, \sigma_2^2)$ 独立, 则对任意常数 a, b :

$$aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2). \quad (3.4.4)$$

为什么这个性质重要? 它意味着正态分布在线性变换下闭合——这使它成为线性模型的理论基础。¹⁷

EXAMPLE 3.26. 均值 μ 是**位置参数 (location parameter)**: 改变 μ 只平移整个分布而不改变形状。标准差 σ 是**尺度参数 (scale parameter)**: 改变 σ 拉伸或压缩分布。

EXAMPLE 3.27. 对于任何正态分布:

- $\mathbb{P}(\mu - \sigma < X < \mu + \sigma) \approx 0.6827$
- $\mathbb{P}(\mu - 2\sigma < X < \mu + 2\sigma) \approx 0.9545$
- $\mathbb{P}(\mu - 3\sigma < X < \mu + 3\sigma) \approx 0.9973$

这些有时被称为**经验法则 (empirical rule)** 或 **68-95-99.7 法则**。

EXAMPLE 3.28 (正态平方到卡方). 若 $X \sim N(\mu, \sigma^2)$, 则 $\frac{(X-\mu)^2}{\sigma^2} \sim \chi^2(1)$ 。

这连接了正态分布和卡方分布, 解释了为什么自由度为 n 的卡方分布涉及 n 个平方标准正态的和。

5. 3.5 多元正态分布

正态分布到高维的自然推广, 为建模相关变量提供了强大工具。

5.1. 二元正态分布 (Bivariate Normal Distribution). 二元正态分布不仅仅是一元正态的二维版本——它的相关结构创造了椭圆轮廓的丰富几何学。

DEFINITION 3.6 (二元正态分布). 若 (X_1, X_2) 的联合 pdf 为:

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{Q(x_1, x_2)}{2(1-\rho^2)} \right\}, \quad (3.5.1)$$

¹⁶推导见附录 ??。

¹⁷证明见附录 ??。

其中

$$Q = \frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2},$$

则 (X_1, X_2) 服从二元正态分布, 记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

五个参数有清晰的解释:

- μ_1, μ_2 : 边缘分布的均值
- σ_1^2, σ_2^2 : 边缘分布的方差
- ρ : X_1 和 X_2 之间的相关系数

THEOREM 3.4 (二元正态分布的性质). 若 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则:

- (1) 边缘分布: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) 条件分布: $X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right)$
- (3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ (对正态变量, 不相关等价于独立)
- (4) 任何线性组合 $aX_1 + bX_2$ 服从正态分布

关键洞见: 条件均值是 x_1 的线性函数。这意味着给定一个变量, 对另一个变量的最佳预测也是线性的。斜率 $\rho\sigma_2/\sigma_1$ 告诉我们 X_2 相对于 X_1 每个标准差变化多少 (以标准差计)。

条件方差 $\sigma_2^2(1 - \rho^2)$ 始终小于边缘方差 σ_2^2 ——知道 X_1 降低了对 X_2 的不确定性。当 $|\rho| = 1$ 时, 条件方差为零: X_2 完全由 X_1 决定。

EXAMPLE 3.29 (夫妻身高). 在某人群中, 丈夫身高 $X_1 \sim N(5.8, 0.04)$ 英尺, 妻子身高 $X_2 \sim N(5.3, 0.04)$ 英尺, 相关系数 $\rho = 0.6$ 。

给定丈夫身高为 6.3 英尺, 妻子身高的条件分布为:

$$X_2 | X_1 = 6.3 \sim N\left(5.3 + 0.6 \cdot \frac{0.2}{0.2}(6.3 - 5.8), 0.04(1 - 0.36)\right) = N(5.6, 0.0256).$$

因此预测妻子身高为 5.6 英尺, 标准差为 0.16 英尺。95% 预测区间为 $5.6 \pm 1.96 \times 0.16 = (5.29, 5.91)$ 英尺。

二元正态分布的联合 mgf 为: ¹⁸

$$M(t_1, t_2) = \exp\left\{t_1\mu_1 + t_2\mu_2 + \frac{1}{2}(t_1^2\sigma_1^2 + 2t_1t_2\rho\sigma_1\sigma_2 + t_2^2\sigma_2^2)\right\}. \quad (3.5.2)$$

6. 3.6 t 分布与 F 分布

这两个分布源于一个实际问题: **当总体方差未知时, 我们如何进行推断?**

这个问题处于统计推断的核心: 当我们用样本均值估计总体均值时, 通常不知道真实的方差。 t 和 F 分布使我们能够考虑这种额外的不确定性。

历史注记: William Gosset (笔名“Student”) 于 1908 年在 Guinness 啤酒厂工作时引入了 t 分布。由于雇主禁止员工发表研究, 他以笔名“Student”发表。Fisher 后来为 ANOVA 开发了 F 分布。

¹⁸推导见附录。

6.1. t 分布.

DEFINITION 3.7 (t 分布). 若 $Z \sim N(0, 1)$ 和 $X \sim \chi^2(n)$ 独立, 则

$$T = \frac{Z}{\sqrt{X/n}} \sim t(n). \quad (3.6.1)$$

称 T 服从自由度为 n 的 t 分布。

t 分布的 pdf 为:

$$f(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, \quad -\infty < t < \infty. \quad (3.6.2)$$

19

t 分布的尾部比正态分布更厚, 反映了估计方差时引入的额外不确定性。

均值和方差:

$$\mathbb{E}T = 0 \ (n > 1), \quad \text{var}(T) = \frac{n}{n-2} \ (n > 2). \quad (3.6.3)$$

当 $n = 1$ 时, 得到柯西分布——一种“危险”的分布, 没有均值 (积分发散)。

与正态的关系: 当 $n \rightarrow \infty$ 时, $t(n) \xrightarrow{d} N(0, 1)$ 。这反映了直观思想: 随着样本量增大, 对方差的了解改善, t 分布收敛到标准正态。

EXAMPLE 3.30 (t 分布应用). 设 $T \sim t(10)$ 。求 $\mathbb{P}(|T| > 2.228)$ 。

由表得 $t_{0.025, 10} = 2.228$, 所以 $\mathbb{P}(|T| > 2.228) = 0.05$ 。

与正态对比: 对于 $Z \sim N(0, 1)$, $\mathbb{P}(|Z| > 1.96) = 0.05$ 。 t 分布的临界值更大, 因为尾部更厚。

在 R 中: `2 * (1 - pt(2.228, 10)) = 0.05`。

t 分布在总体方差未知时构造均值的置信区间中起基础作用。当我们用样本标准差 S 替换总体标准差 σ 时, 所得统计量服从 t 分布。²⁰

6.2. F 分布.

DEFINITION 3.8 (F 分布). 若 $X_1 \sim \chi^2(m)$ 和 $X_2 \sim \chi^2(n)$ 独立, 则

$$F = \frac{X_1/m}{X_2/n} \sim F(m, n). \quad (3.6.4)$$

称 F 服从自由度为 (m, n) 的 F 分布。

pdf 为: ²¹

$$f(w) = \begin{cases} \frac{\Gamma((m+n)/2)}{\Gamma(m/2)\Gamma(n/2)} \left(\frac{m}{n}\right)^{m/2} \frac{w^{m/2-1}}{(1+mw/n)^{(m+n)/2}} & w > 0 \\ 0 & \text{elsewhere.} \end{cases} \quad (3.6.5)$$

F 分布是两个独立卡方变量的比值, 每个除以各自的自由度。

¹⁹推导见附录 ??。

²⁰这是第四章置信区间理论的基础。

²¹推导见附录 ??。

均值和方差：

$$\mathbb{E}F = \frac{n}{n-2} \quad (n > 2), \quad \text{var}(F) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)} \quad (n > 4). \quad (3.6.6)$$

22

倒数性质：若 $F \sim F(m, n)$ ，则 $1/F \sim F(n, m)$ 。这个对称性对计算尾部概率很有用。

EXAMPLE 3.31. 若 $T \sim t(n)$ ，则 $T^2 \sim F(1, n)$ 。这从定义可得： $T = Z/\sqrt{\chi^2(n)/n}$ ，所以 $T^2 = Z^2/(\chi^2(n)/n) = \chi^2(1)/(\chi^2(n)/n) \sim F(1, n)$ 。

为什么 F 分布重要？它是 ANOVA（方差分析）和回归分析的核心——我们用它比较两个方差是否相等，或模型解释的方差是否显著大于残差方差。

ANOVA 中的 F 统计量比较组间均值方差与组内方差。如果组间方差相对于组内方差较大，我们拒绝所有组具有相同均值的原假设。

本章小结

本章介绍了统计学中最重要的分布族：

离散分布：

- Bernoulli $\rightarrow$ Binomial $\rightarrow$ Negative Binomial/Geometric
- Multinomial $\rightarrow$ Hypergeometric
- Poisson（二项分布在稀有事件下的极限）

连续分布：

- Uniform $\rightarrow$ Exponential $\rightarrow$ Gamma $\rightarrow$ Chi-square
- Beta（在单位区间上）
- Normal $\rightarrow$ Bivariate Normal
- t 和 F （由正态 + 卡方结构导出）

习题

EXERCISE 3.1. 3.1.1 If the mgf of a random variable X is $(\frac{1}{3} + \frac{2}{3}e^t)^5$, find $P(X = 2 \text{ or } 3)$. Verify using the R function `dbinom`.

EXERCISE 3.2. 3.1.2 The mgf of a random variable X is $(\frac{2}{3} + \frac{1}{3}e^t)^9$.

(1) Show that $P(\mu - 2\sigma < X < \mu + 2\sigma) = \sum_{x=1}^5 \binom{9}{x} (\frac{1}{3})^x (\frac{2}{3})^{9-x}$.

(2) Use R to compute the probability in Part (a).

EXERCISE 3.3. 3.1.3 If X is $b(n, p)$, show that $E(X/n) = p$ and $E[(X/n - p)^2] = p(1-p)/n$.

²²推导见附录 ??。

EXERCISE 3.4. 3.1.4 Let the independent random variables $X_1, X_2, \dots, X_{40}$ be iid with the common pdf $f(x) = 3x^2$, $0 < x < 1$, zero elsewhere. Find the probability that at least 35 of the X_i 's exceed $\frac{1}{2}$.

EXERCISE 3.5. 3.1.5 Over the years, the percentage of candidates passing an entrance exam to a prestigious law school is 20%. At one of the testing centers, a group of 50 candidates take the exam and 20 pass. Is this odd? Answer on the basis that $X \geq 20$ where X is the number that pass in a group of 50 when the probability of a pass is 0.2.

EXERCISE 3.6. 3.1.6 Let Y be the number of successes throughout n independent repetitions of a random experiment with probability of success $p = \frac{1}{4}$. Determine the smallest value of n so that $P(1 \leq Y) \geq 0.70$.

EXERCISE 3.7. 3.1.7 Let the independent random variables X_1 and X_2 have binomial distribution with parameters $n_1 = 3$, $p = \frac{2}{3}$ and $n_2 = 4$, $p = \frac{1}{2}$, respectively. Compute $P(X_1 = X_2)$.

Hint: List the four mutually exclusive ways that $X_1 = X_2$ and compute the probability of each.

EXERCISE 3.8. 3.1.8 For this exercise, the reader must have access to a statistical package that obtains the binomial distribution. Hints are given for R code, but other packages can be used too.

- (1) Obtain the plot of the pmf for the $b(15, 0.2)$ distribution.
- (2) Repeat part (a) for the binomial distributions with $n = 15$ and with $p = 0.10, 0.20, \dots, 0.90$.
Comment on the shapes of the pmf's as p increases.
- (3) Let $Y = X/n$, where X has a $b(n, 0.05)$ distribution. Obtain the plots of the pmfs of Y for $n = 10, 20, 50, 200$. Comment on the plots.

EXERCISE 3.9. 3.1.9 If $x = r$ is the unique mode of a distribution that is $b(n, p)$, show that $(n+1)p - 1 < r < (n+1)p$.

Hint: Determine the values of x for which $p(x+1)/p(x) > 1$.

EXERCISE 3.10. 3.1.10 Suppose X is $b(n, p)$. Then by definition the pmf is symmetric if and only if $p(x) = p(n-x)$, for $x = 0, \dots, n$. Show that the pmf is symmetric if and only if $p = 1/2$.

EXERCISE 3.11. 3.1.11 Toss two nickels and three dimes at random. Make appropriate assumptions and compute the probability that there are more heads showing on the nickels than on the dimes.

EXERCISE 3.12. 3.1.12 Let $X_1, X_2, \dots, X_{k-1}$ have a multinomial distribution.

- (1) Find the mgf of $X_2, X_3, \dots, X_{k-1}$.
- (2) What is the pmf of $X_2, X_3, \dots, X_{k-1}$?

(3) Determine the conditional pmf of X_1 given that $X_2 = x_2, \dots, X_{k-1} = x_{k-1}$.

(4) What is the conditional expectation $E(X_1 | x_2, \dots, x_{k-1})$?

EXERCISE 3.13. 3.1.13 Let X be $b(2, p)$ and let Y be $b(4, p)$. If $P(X \geq 1) = \frac{5}{9}$, find $P(Y \geq 1)$.

EXERCISE 3.14. 3.1.14 Let X have a binomial distribution with parameters n and $p = \frac{1}{3}$. Determine the smallest integer n can be such that $P(X \geq 1) \geq 0.85$.

EXERCISE 3.15. 3.1.15 Let X have the pmf $p(x) = \left(\frac{1}{3}\right) \left(\frac{2}{3}\right)^x$, $x = 0, 1, 2, 3, \dots$, zero elsewhere. Find the conditional pmf of X given that $X \geq 3$.

EXERCISE 3.16. 3.1.16 One of the numbers $1, 2, \dots, 6$ is to be chosen by casting an unbiased die. Let this random experiment be repeated five independent times. Let the random variable X_1 be the number of terminations in the set $\{x : x = 1, 2, 3\}$ and let the random variable X_2 be the number of terminations in the set $\{x : x = 4, 5\}$. Compute $P(X_1 = 2, X_2 = 1)$.

EXERCISE 3.17. 3.1.17 Show that the moment generating function of the negative binomial distribution is $M(t) = p^r [1 - (1 - p)e^t]^{-r}$. Find the mean and the variance of this distribution.

Hint: In the summation representing $M(t)$, make use of the negative binomial series.

EXERCISE 3.18. 3.1.18 One way of estimating the number of fish in a lake is the following capture-recapture sampling scheme. Suppose there are N fish in the lake where N is unknown. A specified number of fish T are captured, tagged, and released back to the lake. Then at a specified time and for a specified positive integer r , fish are captured until the r th tagged fish is caught. The random variable of interest is Y the number of nontagged fish caught.

(1) What is the distribution of Y ? Identify all parameters.

(2) What is $E(Y)$ and the $\text{var}(Y)$?

(3) The method of moment estimate of N is to set Y equal to the expression for $E(Y)$ and solve this equation for N . Call the solution $\hat{N}$. Determine $\hat{N}$.

(4) Determine the mean and variance of $\hat{N}$.

EXERCISE 3.19. 3.1.19 Consider a multinomial trial with outcomes $1, 2, \dots, k$ and respective probabilities $p_1, p_2, \dots, p_k$.

(1) Compute 10 random trials if $p_1 = 0.3, p_2 = 0.2, p_3 = 0.2, p_4 = 0.2, p_5 = 0.1$.

(2) Compute 10,000 random trials for the above probabilities. Check to see how close the estimates of p_i are with p_i .

EXERCISE 3.20. 3.1.20 Using the experiment in part (a) of Exercise 3.1.19, consider a game when a person pays \$5 to play. If the trial results in a 1 or 2, she receives nothing;

if a 3, she receives \$1; if a 4, she receives \$2; and if a 5, she receives \$20. Let G be her gain.

- (1) Determine $E(G)$.
- (2) Write R code that simulates the gain. Then simulate it 10,000 times, collecting the gains. Compute the average of these 10,000 gains and compare it with $E(G)$.

EXERCISE 3.21. 3.1.21 Let X_1 and X_2 have a trinomial distribution. Differentiate the moment-generating function to show that their covariance is $-np_1p_2$.

EXERCISE 3.22. 3.1.22 If a fair coin is tossed at random five independent times, find the conditional probability of five heads given that there are at least four heads.

EXERCISE 3.23. 3.1.23 Let an unbiased die be cast at random seven independent times. Compute the conditional probability that each side appears at least once given that side 1 appears exactly twice.

EXERCISE 3.24. 3.1.24 Compute the measures of skewness and kurtosis of the binomial distribution $b(n, p)$.

EXERCISE 3.25. 3.1.27 Let X have a geometric distribution. Show that $P(X \geq k + j \mid X \geq k) = P(X \geq j)$, where k and j are nonnegative integers. Note that we sometimes say in this situation that X is memoryless.

EXERCISE 3.26. 3.1.28 Let X equal the number of independent tosses of a fair coin that are required to observe heads on consecutive tosses. Let u_n equal the n th Fibonacci number, where $u_1 = u_2 = 1$ and $u_n = u_{n-1} + u_{n-2}$, $n = 3, 4, 5, \dots$

- (1) Show that the pmf of X is $p(x) = \frac{u_x - 1}{2^x}$, $x = 2, 3, 4, \dots$
- (2) Use the fact that $u_n = \frac{1}{\sqrt{5}} \left[\left(\frac{1+\sqrt{5}}{2} \right)^n - \left(\frac{1-\sqrt{5}}{2} \right)^n \right]$ to show that $\sum_{x=2}^{\infty} p(x) = 1$.

EXERCISE 3.27. 3.1.30 Consider a shipment of 1000 items into a factory. Suppose the factory can tolerate about 5% defective items. Let X be the number of defective items in a sample without replacement of size $n = 10$. Suppose the factory returns the shipment if $X \geq 2$.

- (1) Obtain the probability that the factory returns a shipment of items that has 5% defective items.
- (2) Suppose the shipment has 10% defective items. Obtain the probability that the factory returns such a shipment.
- (3) Obtain approximations to the probabilities in parts (a) and (b) using appropriate binomial distributions.

EXERCISE 3.28. 3.1.31 Show that the variance of a hypergeometric (N, D, n) distribution is given by expression (3.1.8).

Hint: First obtain $E[X(X-1)]$ by proceeding in the same way as the derivation of the mean given in Section 3.1.3.

EXERCISE 3.29. 3.2.1 If the random variable X has a Poisson distribution such that $P(X=1) = P(X=2)$, find $P(X=4)$.

EXERCISE 3.30. 3.2.2 The mgf of a random variable X is $e^{4(e^t-1)}$. Show that $P(\mu - 2\sigma < X < \mu + 2\sigma) = 0.931$.

EXERCISE 3.31. 3.2.3 In a lengthy manuscript, it is discovered that only 13.5 percent of the pages contain no typing errors. If we assume that the number of errors per page is a random variable with a Poisson distribution, find the percentage of pages that have exactly one error.

EXERCISE 3.32. 3.2.4 Let the pmf $p(x)$ be positive on and only on the nonnegative integers. Given that $p(x) = (4/x)p(x-1)$, $x = 1, 2, 3, \dots$, find the formula for $p(x)$.

Hint: Note that $p(1) = 4p(0)$, $p(2) = (4^2/2!)p(0)$, and so on. That is, find each $p(x)$ in terms of $p(0)$ and then determine $p(0)$ from $1 = p(0) + p(1) + p(2) + \dots$.

EXERCISE 3.33. 3.2.5 Let X have a Poisson distribution with $\mu = 100$. Use Chebyshev's inequality to determine a lower bound for $P(75 < X < 125)$. Next, calculate the probability using R . Is the approximation by Chebyshev's inequality accurate?

EXERCISE 3.34. 3.2.7 By Exercise 3.2.6 it seems that the Poisson pmf peaks at its mean λ . Show that this is the case by solving the inequalities $[p(x+1)/p(x)] > 1$ and $[p(x+1)/p(x)] < 1$, where $p(x)$ is the pmf of a Poisson distribution with parameter λ .

EXERCISE 3.35. 3.2.10 The approximation discussed in Exercise 3.2.8 can be made precise in the following way. Suppose X_n is binomial with the parameters n and $p = \lambda/n$, for a given $\lambda > 0$. Let Y be Poisson with mean λ . Show that $P(X_n = k) \rightarrow P(Y = k)$, as $n \rightarrow \infty$, for an arbitrary but fixed value of k .

Hint: First show that $P(X_n = k) = \frac{\lambda^k}{k!} \left[\frac{n(n-1)\cdots(n-k+1)}{n^k} \left(1 - \frac{\lambda}{n}\right)^{-k} \right] \left(1 - \frac{\lambda}{n}\right)^n$.

EXERCISE 3.36. 3.2.11 Let the number of chocolate chips in a certain type of cookie have a Poisson distribution. We want the probability that a cookie of this type contains at least two chocolate chips to be greater than 0.99. Find the smallest value of the mean that the distribution can take.

EXERCISE 3.37. 3.2.12 Compute the measures of skewness and kurtosis of the Poisson distribution with mean μ .

EXERCISE 3.38. 3.2.13 On the average, a grocer sells three of a certain article per week. How many of these should he have in stock so that the chance of his running out within a week is less than 0.01? Assume a Poisson distribution.

EXERCISE 3.39. 3.2.14 Let X have a Poisson distribution. If $P(X = 1) = P(X = 3)$, find the mode of the distribution.

EXERCISE 3.40. 3.3.2 If X is $\chi^2(5)$, determine the constants c and d so that $P(c < X < d) = 0.95$ and $P(X < c) = 0.025$.

EXERCISE 3.41. 3.3.3 Suppose the lifetime in months of an engine, working under hazardous conditions, has a Γ distribution with a mean of 10 months and a variance of 20 months squared.

- (1) Determine the median lifetime of an engine.
- (2) Suppose such an engine is termed successful if its lifetime exceeds 15 months. In a sample of 10 engines, determine the probability of at least 3 successful engines.

EXERCISE 3.42. 3.3.4 Let X be a random variable such that $E(X^m) = (m+1)!2^m$, $m = 1, 2, 3, \dots$. Determine the mgf and the distribution of X .

Hint: Write out the Taylor series of the mgf.

EXERCISE 3.43. 3.3.6 Let X_1, X_2, X_3 be iid random variables, each with pdf $f(x) = e^{-x}$, $0 < x < \infty$, zero elsewhere.

- (1) Find the distribution of $Y = \text{minimum}(X_1, X_2, X_3)$.

Hint: $P(Y \leq y) = 1 - P(Y > y) = 1 - P(X_i > y, i = 1, 2, 3)$.

- (2) Find the distribution of $Y = \text{maximum}(X_1, X_2, X_3)$.

EXERCISE 3.44. 3.3.7 Let X have a gamma distribution with pdf $f(x) = \frac{1}{\beta^2}xe^{-x/\beta}$, $0 < x < \infty$, zero elsewhere. If $x = 2$ is the unique mode of the distribution, find the parameter β and $P(X < 9.49)$.

EXERCISE 3.45. 3.3.8 Compute the measures of skewness and kurtosis of a gamma distribution that has parameters α and β .

EXERCISE 3.46. 3.3.9 Let X have a gamma distribution with parameters α and β . Show that $P(X \geq 2\alpha\beta) \leq (2/e)^\alpha$.

Hint: Use the result of Exercise 1.10.5.

EXERCISE 3.47. 3.3.11 Using the computer, obtain plots of the pdfs of chi-squared distributions with degrees of freedom $r = 1, 2, 5, 10, 20$. Comment on the plots.

EXERCISE 3.48. 3.3.12 Using the computer, plot the cdf of a $\Gamma(5, 4)$ distribution and use it to guess the median. Confirm it with a computer command that returns the median. In R, use the command `qgamma(.5, shape=5, scale=4)`.

EXERCISE 3.49. 3.3.13 Using the computer, obtain plots of beta pdfs for $\alpha = 1, 5, 10$ and $\beta = 1, 2, 5, 10, 20$.

EXERCISE 3.50. 3.3.16 Let X have the uniform distribution with pdf $f(x) = 1$, $0 < x < 1$, zero elsewhere. Find the cdf of $Y = -2 \log X$. What is the pdf of Y ?

EXERCISE 3.51. 3.3.17 Find the uniform distribution of the continuous type on the interval (b, c) that has the same mean and the same variance as those of a chi-square distribution with 8 degrees of freedom. That is, find b and c .

EXERCISE 3.52. 3.3.18 Find the mean and variance of the β distribution.

Hint: From the pdf, we know that $\int_0^1 y^{\alpha-1}(1-y)^{\beta-1} dy = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ for all $\alpha > 0$, $\beta > 0$.

EXERCISE 3.53. 3.3.19 Determine the constant c in each of the following so that each $f(x)$ is a β pdf:

- (1) $f(x) = cx(1-x)^3$, $0 < x < 1$, zero elsewhere.
- (2) $f(x) = cx^4(1-x)^5$, $0 < x < 1$, zero elsewhere.
- (3) $f(x) = cx^2(1-x)^8$, $0 < x < 1$, zero elsewhere.

EXERCISE 3.54. 3.3.25 Let X have an exponential distribution.

- (1) For $x > 0$ and $y > 0$, show that $P(X > x + y \mid X > x) = P(X > y)$. Hence, the exponential distribution has the memoryless property.
- (2) Let $F(x)$ be the cdf of a continuous random variable Y . Assume that $F(0) = 0$ and $0 < F(y) < 1$ for $y > 0$. Suppose property $P(X > x + y \mid X > x) = P(X > y)$ holds for Y . Show that $F_Y(y) = 1 - e^{-\lambda y}$ for $y > 0$.

Hint: Show that $g(y) = 1 - F_Y(y)$ satisfies the equation $g(y + z) = g(y)g(z)$.

EXERCISE 3.55. 3.4.1 If $\Phi(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-w^2/2} dw$, show that $\Phi(-z) = 1 - \Phi(z)$.

EXERCISE 3.56. 3.4.2 If X is $N(75, 100)$, find $P(X < 60)$ and $P(70 < X < 100)$ by using either Table II or the R command `pnorm`.

EXERCISE 3.57. 3.4.3 If X is $N(\mu, \sigma^2)$, find b so that $P[-b < (X - \mu)/\sigma < b] = 0.90$, by using either Table II of Appendix D or the R command `qnorm`.

EXERCISE 3.58. 3.4.4 Let X be $N(\mu, \sigma^2)$ so that $P(X < 89) = 0.90$ and $P(X < 94) = 0.95$. Find μ and σ^2 .

EXERCISE 3.59. 3.4.6 If X is $N(\mu, \sigma^2)$, show that $E(|X - \mu|) = \sigma\sqrt{2/\pi}$.

EXERCISE 3.60. 3.4.7 Show that the graph of a pdf $N(\mu, \sigma^2)$ has points of inflection at $x = \mu - \sigma$ and $x = \mu + \sigma$.

EXERCISE 3.61. 3.4.9 Determine the 90th percentile of the distribution which is $N(65, 25)$.

EXERCISE 3.62. 3.4.10 If e^{3t+8t^2} is the mgf of the random variable X , find $P(-1 < X < 9)$.

EXERCISE 3.63. 3.4.12 Let X be $N(5, 10)$. Find $P[0.04 < (X - 5)^2 < 38.4]$.

EXERCISE 3.64. 3.4.13 If X is $N(1, 4)$, compute the probability $P(1 < X^2 < 9)$.

EXERCISE 3.65. 3.4.17 Compute the measures of skewness and kurtosis of a distribution which is $N(\mu, \sigma^2)$. See Exercises 1.9.14 and 1.9.15 for the definitions of skewness and kurtosis, respectively.

EXERCISE 3.66. 3.4.29 Let X_1 and X_2 be independent with normal distributions $N(6, 1)$ and $N(7, 1)$, respectively. Find $P(X_1 > X_2)$.

Hint: Write $P(X_1 > X_2) = P(X_1 - X_2 > 0)$ and determine the distribution of $X_1 - X_2$.

EXERCISE 3.67. 3.4.30 Compute $P(X_1 + 2X_2 - 2X_3 > 7)$ if X_1, X_2, X_3 are iid with common distribution $N(1, 4)$.

EXERCISE 3.68. 3.4.32 Let X be $N(0, 1)$. Use the moment generating function technique to show that $Y = X^2$ is $\chi^2(1)$.

Hint: Evaluate the integral that represents $E(e^{tX^2})$ by writing $w = x\sqrt{1-2t}$, $t < 1/2$.

EXERCISE 3.69. 3.5.1 Let X and Y have a bivariate normal distribution with respective parameters $\mu_x = 2.8$, $\mu_y = 110$, $\sigma_x^2 = 0.16$, $\sigma_y^2 = 100$, and $\rho = 0.6$. Using R , compute:

- (1) $P(106 < Y < 124)$.
- (2) $P(106 < Y < 124 \mid X = 3.2)$.

EXERCISE 3.70. 3.5.2 Let X and Y have a bivariate normal distribution with parameters $\mu_1 = 3$, $\mu_2 = 1$, $\sigma_1^2 = 16$, $\sigma_2^2 = 25$, and $\rho = \frac{3}{5}$. Using R , determine the following probabilities:

- (1) $P(3 < Y < 8)$
- (2) $P(3 < Y < 8 \mid X = 7)$
- (3) $P(-3 < X < 3)$
- (4) $P(-3 < X < 3 \mid Y = -4)$

EXERCISE 3.71. 3.5.3 Show that $E(XY) = \rho\sigma_1\sigma_2 + \mu_1\mu_2$ for the bivariate normal distribution.

EXERCISE 3.72. 3.5.7 Let X and Y have a bivariate normal distribution with parameters $\mu_1 = 5$, $\mu_2 = 10$, $\sigma_1^2 = 1$, $\sigma_2^2 = 25$, and $\rho > 0$. If $P(4 < Y < 16 \mid X = 5) = 0.954$, determine ρ .

EXERCISE 3.73. 3.5.9 Say the correlation coefficient between the heights of husbands and wives is 0.70 and the mean male height is 5 feet 10 inches with standard deviation 2 inches, and the mean female height is 5 feet 4 inches with standard deviation 1.5 inches. Assuming a bivariate normal distribution, what is the best guess of the height of a woman whose husband's height is 6 feet? Find a 95% prediction interval for her height.

EXERCISE 3.74. 3.6.1 Let T have a t -distribution with 10 degrees of freedom. Find $P(|T| > 2.228)$ from either Table III or by using R .

EXERCISE 3.75. 3.6.2 Let T have a t -distribution with 14 degrees of freedom. Determine b so that $P(-b < T < b) = 0.90$. Use either Table III or by using R .

EXERCISE 3.76. 3.6.3 Let T have a t -distribution with $r > 4$ degrees of freedom. Use expression (3.6.4) to determine the kurtosis of T . See Exercise 1.9.15 for the definition of kurtosis.

EXERCISE 3.77. 3.6.7 Let F have an F -distribution with parameters r_1 and r_2 . Assuming that $r_2 > 2k$, continue with Example 3.6.2 and derive the $E(F^k)$.

EXERCISE 3.78. 3.6.9 Let F have an F -distribution with parameters r_1 and r_2 . Argue that $1/F$ has an F -distribution with parameters r_2 and r_1 .

EXERCISE 3.79. 3.6.11 Let $T = W/\sqrt{V/r}$, where the independent variables W and V are, respectively, normal with mean zero and variance 1 and chi-square with r degrees of freedom. Show that T^2 has an F -distribution with parameters $r_1 = 1$ and $r_2 = r$.

EXERCISE 3.80. 3.6.12 Show that the t -distribution with $r = 1$ degree of freedom and the Cauchy distribution are the same.

EXERCISE 3.81. 3.6.15 Let X_1, X_2 be iid with common distribution having the pdf $f(x) = e^{-x}$, $0 < x < \infty$, zero elsewhere. Show that $Z = X_1/X_2$ has an F -distribution.

EXERCISE 3.82. 3.7.1 Suppose Y has a $\Gamma(\alpha, \beta)$ distribution. Let $X = e^Y$. Show that the pdf of X is given by expression (3.7.5). Determine the cdf of X in terms of the cdf of a Γ -distribution. Derive the mean and variance of X .

EXERCISE 3.83. 3.7.3 In Example 3.7.1, derive the pdf of the mixture distribution given in expression (3.7.6), then obtain its mean and variance as given in expressions (3.7.7) and (3.7.8).

EXERCISE 3.84. 3.7.5 Consider the mixture distribution $(9/10)N(0, 1) + (1/10)N(0, 9)$. Show that its kurtosis is 8.34.

EXERCISE 3.85. 3.7.14 If X has a Pareto distribution with parameters α and β and if c is a positive constant, show that $Y = cX$ has a Pareto distribution with parameters α and β/c .

7. 附录：公式推导

7.1. 二项分布矩母函数的推导. 背景：二项分布 $X \sim \text{Bin}(n, p)$ 的矩母函数定义为 $M(t) = \mathbb{E}[e^{tX}]$ 。

目标：求 $M(t)$ ，并由此导出均值和方差。

推导步骤：

由定义：

$$M(t) = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

将 $e^{tx} p^x = (pe^t)^x$ 提取出来：

$$M(t) = \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n,$$

其中最后一步使用了二项式定理。

对 $M(t)$ 求导：

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t.$$

在 $t = 0$ 处求值：

$$M'(0) = n[(1-p) + p]^{n-1} \cdot p = np,$$

$$M''(0) = n(n-1)[(1-p) + p]^{n-2} \cdot p^2 + n[(1-p) + p]^{n-1} \cdot p = n(n-1)p^2 + np.$$

因此：

$$\text{var}(X) = M''(0) - [M'(0)]^2 = [n(n-1)p^2 + np] - n^2p^2 = np(1-p).$$

7.2. 二项分布可加性的证明. 背景：若 $X_1 \sim \text{Bin}(n_1, p)$ 和 $X_2 \sim \text{Bin}(n_2, p)$ 独立，证明 $X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p)$ 。

推导步骤：

使用矩母函数方法。两独立随机变量和的 mgf 是它们 mgf 的乘积：

$X_1 + X_2$ 的 mgf 为：

$$M_{X_1+X_2}(t) = M_{X_1}(t) \cdot M_{X_2}(t) = [(1-p) + pe^t]^{n_1} \cdot [(1-p) + pe^t]^{n_2} = [(1-p) + pe^t]^{n_1+n_2}.$$

这正是 $\text{Bin}(n_1 + n_2, p)$ 的 mgf。由于 mgf 唯一确定分布，结论得证。

7.3. 负二项分布的推导. 背景：负二项分布描述“第 r 次成功前失败次数”的分布。

目标：推导 pmf $p_Y(y) = \mathbb{P}(Y = y)$ 。

推导步骤：

恰好有 y 次失败发生在第 r 次成功之前，当且仅当：

- (1) 前 $y + r - 1$ 次试验中恰好有 $r - 1$ 次成功和 y 次失败
- (2) 第 $y + r$ 次试验是成功

第一步的概率由二项分布给出： $\binom{y+r-1}{r-1}p^{r-1}(1-p)^y$ 。

第二步的成功概率为 p 。

由独立性，总概率为：

$$p_Y(y) = \binom{y+r-1}{r-1}p^{r-1}(1-p)^y \cdot p = \binom{y+r-1}{r-1}p^r(1-p)^y, \quad y = 0, 1, 2, \dots$$

验证归一性：利用负二项级数 $\sum_{y=0}^{\infty} \binom{y+r-1}{r-1}(1-p)^y = p^{-r}$ ，可得 $\sum_y p_Y(y) = 1$ 。

7.4. 几何分布无记忆性的证明. 背景：几何分布具有独特的无记忆性： $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤：

由条件概率定义：

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)}.$$

几何分布下， $\mathbb{P}(Y \geq y) = (1-p)^y$ （对于 $y = 0, 1, 2, \dots$ ）。

因此：

$$\frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

证毕。

7.5. 几何分布矩的推导. 目标：求几何分布 $Y \sim \text{Geom}(p)$ （支撑集 $\{0, 1, 2, \dots\}$ ）的均值和方差。

推导步骤：

均值：使用几何级数求和技巧。

$$\mathbb{E}Y = \sum_{y=0}^{\infty} y \cdot p(1-p)^y = p(1-p) \sum_{y=1}^{\infty} y(1-p)^{y-1}.$$

利用 $\sum_{y=1}^{\infty} yx^{y-1} = \frac{1}{(1-x)^2}$ ($|x| < 1$)，得：

$$\mathbb{E}Y = p(1-p) \cdot \frac{1}{p^2} = \frac{1-p}{p}.$$

方差：先求 $\mathbb{E}[Y(Y-1)]$ ：

$$\mathbb{E}[Y(Y-1)] = \sum_{y=0}^{\infty} y(y-1)p(1-p)^y = p(1-p)^2 \sum_{y=2}^{\infty} y(y-1)(1-p)^{y-2} = p(1-p)^2 \cdot \frac{2}{p^3} = \frac{2(1-p)^2}{p^2}.$$

由 $\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2$ 和 $\mathbb{E}[Y(Y-1)] = \mathbb{E}[Y^2] - \mathbb{E}[Y]$ ，得：

$$\mathbb{E}[Y^2] = \mathbb{E}[Y(Y-1)] + \mathbb{E}[Y] = \frac{2(1-p)^2}{p^2} + \frac{1-p}{p} = \frac{(1-p)(2-p)}{p^2}.$$

因此：

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{(1-p)(2-p)}{p^2} - \frac{(1-p)^2}{p^2} = \frac{1-p}{p^2}.$$

7.6. 负二项分布矩母函数的推导. 目标: 推导负二项分布 $Y \sim \text{NB}(r, p)$ 的 mgf。

推导步骤:

使用概率生成函数的性质。负二项分布可以分解为 r 个独立几何随机变量之和:

$$Y = G_1 + G_2 + \cdots + G_r,$$

其中每个 $G_i \sim \text{Geom}(p)$ (支撑集 $\{0, 1, 2, \dots\}$)。

几何分布的 mgf 为 $M_G(t) = \frac{p}{1-(1-p)e^t}$ ($t < -\log(1-p)$)。

由于独立同分布之和:

$$M_Y(t) = [M_G(t)]^r = \left[\frac{p}{1-(1-p)e^t} \right]^r = \frac{p^r}{[1-(1-p)e^t]^r}.$$

7.7. 多项分布的推导. 背景: 多项分布是二项分布对 k 个类别的推广。

目标: 推导联合 pmf。

推导步骤:

在 n 次独立试验中, 第 i 个类别出现 x_i 次的概率为 $\binom{n}{x_1, x_2, \dots, x_k} \prod_{i=1}^k p_i^{x_i}$, 其中 $\binom{n}{x_1, x_2, \dots, x_k} = \frac{n!}{x_1! x_2! \cdots x_k!}$ 是多项式系数。

这正是 pmf 的形式。验证归一性: 由多项式定理, $\sum_{x_1 + \cdots + x_k = n} \binom{n}{x_1, \dots, x_k} \prod p_i^{x_i} = (p_1 + \cdots + p_k)^n = 1$ 。

边缘分布: X_i 的边缘分布为 $\text{Bin}(n, p_i)$, 因为忽略其他类别后, 每次试验中类别 i 出现的概率为 p_i 。

协方差: 对于 $i \neq j$,

$$\text{cov}(X_i, X_j) = \mathbb{E}[X_i X_j] - \mathbb{E}[X_i] \mathbb{E}[X_j].$$

利用多项分布的性质可得 $\text{cov}(X_i, X_j) = -np_i p_j$ 。

7.8. 超几何分布的推导. 背景: 超几何分布描述不放回抽样。

目标: 推导 pmf 和矩。

推导步骤:

pmf: 从 N 件产品中不放回抽取 n 件, 恰好得到 x 件次品的概率为:

$$p(x) = \frac{\binom{D}{x} \binom{N-D}{n-x}}{\binom{N}{n}}.$$

这来自组合计数: 选择 x 件次品的方式数乘以选择 $n-x$ 件好品的方式数, 除以从 N 件中选择 n 件的总方式数。

均值: $\mathbb{E}X = n \frac{D}{N}$ 。直观理解: 每次抽取次品的“概率”在不放回情况下仍为 D/N (对称性)。

方差: $\text{var}(X) = n \frac{D}{N} \left(1 - \frac{D}{N}\right) \frac{N-n}{N-1}$ 。

有限总体校正因子 $\frac{N-n}{N-1}$ 反映了不放回抽样与放回抽样的差异。当 $N \gg n$ 时, 此因子接近 1。

7.9. Poisson 分布矩的推导. 目标：求 Poisson 分布的均值和方差。

推导步骤：

均值：

$$\mathbb{E}X = \sum_{x=0}^{\infty} x \cdot \frac{\lambda^x e^{-\lambda}}{x!} = \lambda e^{-\lambda} \sum_{x=1}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} = \lambda e^{-\lambda} \cdot e^{\lambda} = \lambda.$$

方差：先求 $\mathbb{E}[X(X-1)]$ ：

$$\mathbb{E}[X(X-1)] = \sum_{x=0}^{\infty} x(x-1) \cdot \frac{\lambda^x e^{-\lambda}}{x!} = \lambda^2 e^{-\lambda} \sum_{x=2}^{\infty} \frac{\lambda^{x-2}}{(x-2)!} = \lambda^2 e^{-\lambda} \cdot e^{\lambda} = \lambda^2.$$

因此 $\mathbb{E}[X^2] = \mathbb{E}[X(X-1)] + \mathbb{E}[X] = \lambda^2 + \lambda$ ，方差为：

$$\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda.$$

7.10. Poisson 近似二项分布的证明. 背景：当 n 很大、 p 很小时，二项分布 $\text{Bin}(n, p)$ 近似 Poisson(λ)。

推导步骤：

设 $X_n \sim \text{Bin}(n, p_n)$ ，其中 $np_n \rightarrow \lambda$ 。对固定的 k ：

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

写成：

$$= \frac{n(n-1)\cdots(n-k+1)}{k!} p_n^k (1-p_n)^{n-k} = \frac{n^k p_n^k}{k!} (1-p_n)^n \cdot \frac{(1-p_n^{-1})(1-2p_n^{-1})\cdots(1-(k-1)p_n^{-1})}{(1-p_n)^k}.$$

当 $n \rightarrow \infty$ 时， $np_n \rightarrow \lambda$ ，所以 $p_n \rightarrow 0$ 。因此：

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k}{k!} \cdot \lim_{n \rightarrow \infty} (1-p_n)^n = \frac{\lambda^k}{k!} e^{-\lambda}.$$

证毕。

7.11. Gamma 函数递归公式的推导. 目标：证明 $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$ 。

推导步骤：

由定义：

$$\Gamma(\alpha+1) = \int_0^{\infty} x^{\alpha} e^{-x} dx.$$

使用分部积分 ($u = x^{\alpha}$, $dv = e^{-x} dx$)：

$$\Gamma(\alpha+1) = [-x^{\alpha} e^{-x}]_0^{\infty} + \alpha \int_0^{\infty} x^{\alpha-1} e^{-x} dx = 0 + \alpha \Gamma(\alpha) = \alpha \Gamma(\alpha).$$

边界项在两端均为零，因为 $x^{\alpha} e^{-x} \rightarrow 0$ 当 $x \rightarrow \infty$ (指数衰减快于多项增长)，且当 $x \rightarrow 0$ 时 $x^{\alpha} \rightarrow 0$ ($\alpha > 0$)。

7.12. Gamma 分布矩母函数的推导. 目标: 推导 $\Gamma(\alpha, \beta)$ 分布的 mgf, 并求均值和方差。

推导步骤:

由定义:

$$M(t) = \mathbb{E}[e^{tX}] = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx.$$

令 $z = x/\beta$, $dx = \beta dz$:

$$M(t) = \frac{1}{\Gamma(\alpha)} \int_0^\infty e^{t\beta z} z^{\alpha-1} e^{-z} dz = \frac{1}{\Gamma(\alpha)} \int_0^\infty z^{\alpha-1} e^{-(1-t\beta)z} dz.$$

利用 $\int_0^\infty z^{\alpha-1} e^{-sz} dz = \Gamma(\alpha)/s^\alpha$ ($\text{Re}(s) > 0$), 得:

$$M(t) = (1 - \beta t)^{-\alpha}, \quad t < \frac{1}{\beta}.$$

求导:

$$M'(t) = \alpha\beta(1 - \beta t)^{-\alpha-1}, \quad M''(t) = \alpha(\alpha+1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

在 $t = 0$ 处求值:

$$\mathbb{E}X = M'(0) = \alpha\beta, \quad \mathbb{E}[X^2] = M''(0) = \alpha(\alpha+1)\beta^2.$$

因此 $\text{var}(X) = \alpha(\alpha+1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2$ 。

7.13. Gamma 分布可加性的证明. 背景: 若 $X_1 \sim \Gamma(\alpha_1, \beta)$ 和 $X_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 证明 $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

推导步骤:

使用 mgf 方法。独立随机变量和的 mgf 是 mgf 的乘积:

$$M_{X_1+X_2}(t) = M_{X_1}(t) \cdot M_{X_2}(t) = (1 - \beta t)^{-\alpha_1} \cdot (1 - \beta t)^{-\alpha_2} = (1 - \beta t)^{-(\alpha_1+\alpha_2)}.$$

这正是 $\Gamma(\alpha_1 + \alpha_2, \beta)$ 的 mgf。证毕。

7.14. Beta 分布矩的推导. 目标: 推导 $\text{Beta}(\alpha, \beta)$ 分布的均值和方差。

推导步骤:

均值:

$$\mathbb{E}X = \frac{1}{B(\alpha, \beta)} \int_0^1 x \cdot x^{\alpha-1} (1-x)^{\beta-1} dx = \frac{1}{B(\alpha, \beta)} \int_0^1 x^\alpha (1-x)^{\beta-1} dx = \frac{B(\alpha+1, \beta)}{B(\alpha, \beta)}.$$

利用 $B(\alpha+1, \beta) = \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+\beta+1)} = \frac{\alpha}{\alpha+\beta} \cdot \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} = \frac{\alpha}{\alpha+\beta} B(\alpha, \beta)$, 得:

$$\mathbb{E}X = \frac{\alpha}{\alpha+\beta}.$$

方差: 先求 $\mathbb{E}[X^2]$:

$$\mathbb{E}[X^2] = \frac{B(\alpha+2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}.$$

因此：

$$\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \frac{\alpha^2}{(\alpha+\beta)^2} = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}.$$

7.15. Beta-二项共轭关系. 背景：在贝叶斯统计中，Beta 分布是二项分布的共轭先验。

推导步骤：

设 $X \sim \text{Bin}(n, p)$ ，先验 $p \sim \text{Beta}(\alpha, \beta)$ 。

似然： $L(p) \propto p^x(1-p)^{n-x}$ 。

先验： $\pi(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$ 。

后验：

$$\pi(p | x) \propto p^x(1-p)^{n-x} \cdot p^{\alpha-1}(1-p)^{\beta-1} = p^{\alpha+x-1}(1-p)^{\beta+n-x-1}.$$

这正是 $\text{Beta}(\alpha+x, \beta+n-x)$ 的核。因此后验仍是 Beta 分布。

这就是“共轭先验”的含义：先验和后验属于同一分布族。

7.16. 正态分布矩母函数的推导. 目标：推导 $N(\mu, \sigma^2)$ 的 mgf。

推导步骤：

标准化方法。设 $Z \sim N(0, 1)$ ，则 $X = \mu + \sigma Z$ 。

$$M_X(t) = \mathbb{E}[e^{tX}] = \mathbb{E}[e^{t(\mu+\sigma Z)}] = e^{\mu t} \mathbb{E}[e^{\sigma t Z}] = e^{\mu t} M_Z(\sigma t).$$

对 $Z \sim N(0, 1)$ ，完成平方：

$$M_Z(s) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{sz - z^2/2} dz = e^{s^2/2} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-(z-s)^2/2} dz = e^{s^2/2}.$$

因此：

$$M_X(t) = \exp \left\{ \mu t + \frac{1}{2} \sigma^2 t^2 \right\}.$$

7.17. 正态变量线性组合的证明. 背景：正态分布在线性变换下闭合。

推导步骤：

设 $X_1 \sim N(\mu_1, \sigma_1^2)$ ， $X_2 \sim N(\mu_2, \sigma_2^2)$ 独立。

$Y = aX_1 + bX_2$ 的 mgf：

$$M_Y(t) = \mathbb{E}[e^{t(aX_1+bX_2)}] = \mathbb{E}[e^{(at)X_1}] \cdot \mathbb{E}[e^{(bt)X_2}] = M_{X_1}(at) \cdot M_{X_2}(bt).$$

代入正态 mgf：

$$M_Y(t) = \exp \left\{ \mu_1(at) + \frac{1}{2} \sigma_1^2(at)^2 \right\} \cdot \exp \left\{ \mu_2(bt) + \frac{1}{2} \sigma_2^2(bt)^2 \right\} = \exp \left\{ (a\mu_1 + b\mu_2)t + \frac{1}{2} (a^2\sigma_1^2 + b^2\sigma_2^2)t^2 \right\}.$$

这正是 $N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$ 的 mgf。证毕。

7.18. 二元正态分布矩母函数的推导. 目标: 推导二元正态分布的联合 mgf.

推导步骤:

由二元正态的定义, (X_1, X_2) 的联合 pdf 可写成矩阵形式. 联合 mgf 为:

$$M(t_1, t_2) = \mathbb{E}[e^{t_1 X_1 + t_2 X_2}].$$

利用条件分布或矩阵形式可证:

$$M(t_1, t_2) = \exp \left\{ t_1 \mu_1 + t_2 \mu_2 + \frac{1}{2} (t_1^2 \sigma_1^2 + 2t_1 t_2 \rho \sigma_1 \sigma_2 + t_2^2 \sigma_2^2) \right\}.$$

7.19. t 分布 pdf 的推导. 背景: t 分布由 $T = Z/\sqrt{\chi^2(n)/n}$ 定义, 其中 $Z \sim N(0, 1)$, $\chi^2(n)$ 独立。

推导步骤:

使用变量变换法。设 $U = \chi^2(n)$, 则 $T = Z/\sqrt{U/n}$, U 与 Z 独立。

联合分布: $f_{Z,U}(z, u) = \phi(z) \cdot f_{\chi^2(n)}(u)$ 。

变换 $(T, U) \rightarrow (Z, U)$ 的雅可比为 $|\partial z / \partial t| = \sqrt{u/n}$ 。

因此 T 的边缘 pdf 为:

$$f_T(t) = \int_0^\infty f_{Z,U}(t\sqrt{u/n}, u) \sqrt{u/n} du.$$

完成积分 (标准推导) 可得:

$$f(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}.$$

7.20. F 分布 pdf 的推导. 背景: F 分布由 $F = \frac{X_1/m}{X_2/n}$ 定义, 其中 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立。

推导步骤:

设 $W = F$, $V = X_2$, 则 $X_1 = W \cdot \frac{m}{n} V$ 。

变换的雅可比为 $|\partial(x_1, x_2)/\partial(w, v)| = \frac{m}{n} v$ 。

积分掉 v 可得 W 的 pdf:

$$f(w) = \frac{\Gamma((m+n)/2)}{\Gamma(m/2)\Gamma(n/2)} \left(\frac{m}{n}\right)^{m/2} \frac{w^{m/2-1}}{(1+mw/n)^{(m+n)/2}}, \quad w > 0.$$

7.21. F 分布矩的推导. 目标: 求 $F(m, n)$ 分布的均值和方差。

推导步骤:

由定义 $F = \frac{X_1/m}{X_2/n} = \frac{n}{m} \cdot \frac{X_1}{X_2}$, 其中 $X_1 \sim \chi^2(m)$, $X_2 \sim \chi^2(n)$ 独立。

$E(F)$ 的存在性要求 $n > 2$:

$$\mathbb{E}F = \frac{n}{m} \cdot \frac{\mathbb{E}[X_1]}{\mathbb{E}[X_2]} = \frac{n}{m} \cdot \frac{m}{n} = \frac{n}{n-2}, \quad n > 2.$$

方差的计算类似, 需要 $\mathbb{E}[F^2]$, 要求 $n > 4$:

$$\text{var}(F) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}, \quad n > 4.$$

CHAPTER 4

Some Elementary Statistical Inferences

Chapter 4 Overview

在前三章中，我们建立了描述随机变量和概率分布的理论框架。现在我们面临一个根本性问题：

给定观测数据，如何推断产生这些数据的底层分布？

这个问题——从已知数据推断未知规律——正是统计学的核心任务。正如 Fisher 在 1922 年的经典论文中所强调的，统计推断的本质是在不确定性下做出明智决策。

本章介绍三种主要的推断工具：

- **点估计** (Point Estimation)：用单一数值估计未知参数
- **置信区间** (Confidence Intervals)：参数的合理取值范围，而非点估计的单一数值
- **假设检验** (Hypothesis Testing)：评估关于总体的声明是否获得数据支持

这三种工具相互关联：点估计给出参数的最佳猜测，置信区间度量这个猜测的精度，而假设检验则让我们能够验证关于总体的具体声明。

本章路线图：抽样与统计量 → 点估计 (MLE) → 置信区间 → 假设检验 → 卡方检验 → 蒙特卡洛 → Bootstrap

1. 4.1 Sampling and Statistics

1.1. 从总体到样本。在典型的统计问题中，我们关心某个随机变量 X ，但其 pdf $f(x)$ 或 pmf $p(x)$ 未知。这种未知性可以分为两类：

- (1) $f(x)$ 或 $p(x)$ 的形式完全未知
- (2) 分布的形式已知，但包含未知参数 θ (θ 可以是向量)

¹

本章聚焦第二类——这正是统计学中最常见的场景。我们已知数据的分布类型，只是不知道具体的参数值。几个典型例子：

- (a) $X \sim \text{Exp}(\theta)$, θ 未知——指数分布常用于描述等待时间
- (b) $X \sim \text{Binomial}(n, p)$, p 未知——二项分布描述 n 次试验中的成功次数
- (c) $X \sim \Gamma(\alpha, \beta)$, α 和 β 均未知——Gamma 分布广泛出现于保险和排队论
- (d) $X \sim N(\mu, \sigma^2)$, μ 和 σ^2 均未知——正态分布是统计学的核心

我们用 $f(x; \theta)$ 或 $p(x; \theta)$ 表示含参分布，其中 $\theta \in \Omega$, Ω 是参数空间（所有可能的 θ 组成的集合）。

¹第一种情况属于非参数方法 (Chapter 10 深入讨论)，第二种情况是本章的核心内容。见附录。

1.2. 随机样本. 为什么要强调“随机”抽取? 因为只有随机抽样才能保证样本具有代表性——每个个体被选中的概率相等, 这样样本才能“代表”总体。

从总体中抽取样本, 样本观测值与 X 同分布。记为随机变量 $X_1, X_2, \dots, X_n$, 其中 n 是样本量。抽到具体数值后记为 $x_1, x_2, \dots, x_n$ 。

若 $X_1, \dots, X_n$ 相互独立且同分布, 则称它们为来自该共同分布的**随机样本 (random sample)**。

DEFINITION 4.1 (随机样本). 如果随机变量 $X_1, X_2, \dots, X_n$ 独立同分布 (*iid*), 则称这些随机变量构成来自该共同分布的容量为 n 的随机样本。

从这个定义出发, 样本的联合 pdf/pmf 为

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

这正是后续推导似然函数的基础。

1.3. 统计量. 我们已经学会了如何描述单个随机变量, 现在面临一个新问题: **如何从样本中提取信息?**

设 $T = T(X_1, X_2, \dots, X_n)$ 是样本的函数。则称 T 为一个**统计量 (statistic)**。

统计量的关键特征在于: **不依赖任何未知参数**。换言之, 统计量只基于观测数据进行计算, 不涉及任何未知数。一旦样本被观测, $t = T(x_1, \dots, x_n)$ 称为 T 的实现值。

1.4. 4.1.1 Point Estimation. 点估计提供一个单一数值 (记作 $\hat{\theta}$) 作为未知参数 θ 的估计。但这里立刻产生一个问题: 如何找到“好”的估计量?

1.5. 无偏性. 我们希望估计量具有什么性质? 最基本的要求是无偏性——如果反复抽样, 估计量的平均值应该等于真实参数值。

DEFINITION 4.2 (无偏估计量). 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的样本, $\theta \in \Omega$ 。设 $T = T(X_1, \dots, X_n)$ 是统计量。若

$$\mathbb{E}(T) = \theta,$$

则称 T 是 θ 的**无偏估计量 (unbiased estimator)**。

若 $\mathbb{E}(T) \neq \theta$, 则称 $\text{Bias}(T) = \mathbb{E}(T) - \theta$ 为偏差。无偏性保证估计量没有系统性偏差——既不高估也不低估。

注意: 无偏性并不保证估计量“最好”。例如, 样本方差 S^2 是无偏的, 但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题: 能否找到一个统一的、“最优”的估计原则?

²

1.6. 最大似然估计 (MLE). 为什么需要似然函数? 样本来自参数 θ 的分布 $f(x; \theta)$ 。给定 θ 时, 观察到当前数据 $\mathbf{x} = (x_1, \dots, x_n)$ 的概率 (密度) 为 $f(\mathbf{x}; \theta)$ 。似然函数正是这个想法的数学表达——它衡量在给定 θ 时, 观察到当前数据的“可能性”。³

²问: 为什么要举这个例子? 它在整个章节中起什么作用? 见附录。

³在贝叶斯统计中, 似然函数与先验分布结合通过贝叶斯定理产生后验分布。见附录。

DEFINITION 4.3 (似然函数). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本。则

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

称为该随机样本的**似然函数 (likelihood function)**。

核心思想：如果 θ 是真实参数，那么它应该使得观察到的数据具有较高的“可能性”。因此，我们选择使 $L(\theta)$ 最大化的 $\hat{\theta}$ ——这正是最大似然估计量的定义。

最大似然估计量 (MLE)：

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} L(\theta). \quad (4.2.1)$$

在实际计算中，通常使用对数似然 $l(\theta) = \log L(\theta)$ ，因为 $\log$ 是严格递增函数，最大化 $l(\theta)$ 等价于最大化 $L(\theta)$ 。在正则条件下， $\hat{\theta}$ 满足

$$\frac{\partial l(\theta)}{\partial \theta} = 0. \quad (4.2.2)$$

这个方程称为**似然方程 (score equation)**。⁴

EXAMPLE 4.1 (指数分布的 MLE). 设 $X_1, \dots, X_n \sim \operatorname{Exp}(\theta)$, pdf 为 $f(x) = \theta^{-1} \exp\{-x/\theta\}$, $x > 0$ 。

对数似然为

$$l(\theta) = -n \log \theta - \frac{1}{\theta} \sum_{i=1}^n x_i.$$

令导数为零，解得 $\hat{\theta} = \bar{x}$ 。由于 $\mathbb{E}(X) = \theta$ ，故 $\hat{\theta} = \bar{X}$ 也是无偏估计。⁵

EXAMPLE 4.2 (二项分布的 MLE). 设 $X \sim \operatorname{Bernoulli}(\theta)$, $p(x; \theta) = \theta^x (1 - \theta)^{1-x}$, $x = 0, 1$ 。

对于随机样本，似然函数为

$$L(\theta) = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}.$$

对数似然求导并令为零，解得 $\hat{\theta} = \bar{x}$ 。由于 $\mathbb{E}(X) = \theta$ ，故 $\hat{\theta} = \bar{X}$ 是无偏的。⁶

EXAMPLE 4.3 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ ，参数向量为 $\boldsymbol{\theta} = (\mu, \sigma)$ 。

对数似然为

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2. \quad (4.2.3)$$

对 μ 和 σ 分别求偏导并令为零，解得

$$\hat{\mu} = \bar{X}, \quad (4.2.4)$$

⁴通用推导框架见附录。

⁵详细推导见附录。

⁶详细推导见附录。

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (4.2.5)$$

一个重要发现： $\hat{\mu} = \bar{X}$ 是无偏的 ($\mathbb{E}(\bar{X}) = \mu$)，但 $\hat{\sigma}^2$ 是有偏的——

$$\mathbb{E}(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2,$$

而样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是无偏的 ($\mathbb{E}(S^2) = \sigma^2$)。这说明 MLE 有时并非无偏——无偏性和最大似然是两种不同的估计原则。⁷

MLE 的吸引力来自其渐近理论：在温和条件下，MLE 是渐近正态的、渐近有效的，且具有最优性。这些性质使 MLE 成为现代统计推断的基石。

2. 4.2 Confidence Intervals

点估计给出一个数值，但它没有告诉我们这个估计有多“可靠”。置信区间通过提供参数的取值范围来解决这个问题。

一个直观的类比：如果点估计是“我认为明天的温度是 22 度”，那么置信区间就是“我认为温度在 18 到 26 度之间”。后者不仅给出估计，还表达了不确定性。

DEFINITION 4.4 (置信区间). 设 $L = g_1(X_1, \dots, X_n)$ 和 $U = g_2(X_1, \dots, X_n)$ 是两个统计量。若对所有 $\theta \in \Omega$,

$$\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha,$$

则称随机区间 $[L, U]$ 为 θ 的 $100(1 - \alpha)\%$ 置信区间 (*confidence interval*)。

正确理解：不是说“ θ 以 $1 - \alpha$ 概率落在区间内” (θ 是固定常数，没有随机性)，而是说“如果重复抽样 $100(1 - \alpha)\%$ 的区间会包含 θ ”。这称为置信区间的频率学派解释。⁸

构造置信区间的关键是找到枢轴量 (pivot) —— 一个其分布不依赖于未知参数的函数。⁹

2.1. 正态均值的置信区间.

EXAMPLE 4.4 (已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。则 μ 的 $100(1 - \alpha)\%$ 置信区间为

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right], \quad (4.3.1)$$

其中 $z_{\alpha/2}$ 满足 $\Phi(z_{\alpha/2}) = 1 - \alpha/2$ 。

直觉理解：区间宽度 $\propto \sigma/\sqrt{n}$ —— 样本量越大，估计越精确。这与大数定律的直觉一致：更多信息带来更精确的估计。¹⁰

⁷详细推导见附录。

⁸问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？见附录 ??。

⁹枢轴量的构造方法及推导见附录。

¹⁰详细推导见附录。

EXAMPLE 4.5 (未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。用 S^2 替代 σ^2 , 则

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}, \quad (4.3.2)$$

故 μ 的 $100(1 - \alpha)\%$ 置信区间为

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \right]. \quad (4.3.3)$$

用 t 分布替代正态分布: 当方差未知时, 我们用样本标准差 S 替代总体标准差 σ 。这引入了额外的随机性, 导致分布从正态变为 t 分布。 t 分布比正态分布更“重尾”, 反映了未知方差带来的不确定性。¹¹

THEOREM 4.1 (方差置信区间). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ 。则 σ^2 的 $100(1 - \alpha)\%$ 置信区间为

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right]. \quad (4.3.4)$$

其中 $\chi_{p,k}^2$ 是 $\chi^2(k)$ 分布的上侧 p 分位数。¹²




图 1. χ^2 分布的置信区间示意图。图中阴影区域为置信区间 $[(n-1)S^2/\chi_{\alpha/2, n-1}^2, (n-1)S^2/\chi_{1-\alpha/2, n-1}^2]$ 对应的统计量 $(n-1)S^2/\sigma^2$ 的取值范围, 两侧红色区域为显著性水平 $\alpha/2$ 的拒绝域。

3. 4.3 Order Statistics

3.1. 次序统计量的定义. 设 $X_1, X_2, \dots, X_n$ 是来自连续型分布的随机样本, 该分布的 pdf 为 $f(x)$, 支撑集为 $S = (a, b)$, 其中 $-\infty \leq a < b \leq \infty$ 。将样本按从小到大排列:

$$Y_1 < Y_2 < \dots < Y_n$$

¹¹详细推导见附录。

¹²详细推导见附录。

其中 Y_1 是最小值, Y_2 是次小值, $\dots$, Y_n 是最大值。则称 Y_i 为第 i 个次序统计量 (order statistic)。

次序统计量在统计推断中扮演重要角色, 因为它们的某些性质不依赖于母体分布的具体形式。

3.2. 联合 pdf.

THEOREM 4.2 (次序统计量的联合分布). 设 $Y_1 < Y_2 < \dots < Y_n$ 是来自连续型分布的随机样本 $X_1, X_2, \dots, X_n$ 的次序统计量, 该分布的 pdf 为 $f(x)$, 支撑集为 (a, b) 。则 $Y_1, Y_2, \dots, Y_n$ 的联合 pdf 为

$$g(y_1, y_2, \dots, y_n) = \begin{cases} n! f(y_1) f(y_2) \cdots f(y_n) & a < y_1 < y_2 < \cdots < y_n < b \\ 0 & \text{otherwise} \end{cases} \quad (4.3.1)$$

证明思路: 样本空间可以划分为 $n!$ 个互不相交的集合, 每个集合对应 $Y_1, \dots, Y_n$ 的一个排列。其中一种排列是 $a < x_1 < x_2 < \dots < x_n < b$, 雅可比为 1; 其他排列的雅可比为 ± 1 。求和后即得公式。

3.3. 单个次序统计量的分布. 设 Y_k 是第 k 个次序统计量。其边缘 pdf 为

$$g_k(y_k) = \begin{cases} \frac{n!}{(k-1)!(n-k)!} [F(y_k)]^{k-1} [1 - F(y_k)]^{n-k} f(y_k) & a < y_k < b \\ 0 & \text{otherwise} \end{cases} \quad (4.3.2)$$

其中 $F(x)$ 是母体分布函数。

EXAMPLE 4.6 (均匀分布次序统计量). 设 $Y_1 < Y_2 < Y_3 < Y_4$ 是来自 pdf

$$f(x) = \begin{cases} 2x & 0 < x < 1 \\ 0 & \text{otherwise} \end{cases}$$

的随机样本 (容量为 4) 的次序统计量。求 $P(1/2 < Y_3)$ 。

解: 此处 $F(x) = x^2$, $f(x) = 2x$ ($0 < x < 1$)。由公式 (??), Y_3 的 pdf 为

$$g_3(y_3) = \frac{4!}{2!1!} (y_3^2)^2 (1 - y_3^2) (2y_3) = 24(y_3^5 - y_3^7), \quad 0 < y_3 < 1.$$

因此

$$P\left(\frac{1}{2} < Y_3\right) = \int_{1/2}^1 24(y_3^5 - y_3^7) dy_3 = \frac{243}{256}.$$

4. 4.4 Hypothesis Testing

假设检验回答一个根本性问题: 数据是否提供足够证据拒绝关于总体的某个声明?

这本质上是一种“举证”逻辑: 我们先假设某个声明为真 (H_0), 然后问: 在这个假设下, 当前数据出现的概率有多大? 如果概率很小, 我们就有理由拒绝这个假设。

核心概念:

- **原假设** H_0 : 被检验的假设 (通常代表“无效应”或“现状”)
- **备择假设** H_1 : 与 H_0 对立的假设

在设定假设时, 我们需要权衡两类错误:

	未拒绝 H_0	拒绝 H_0
H_0 为真	正确 (置信度 $1 - \alpha$)	第一类错误 (概率 α)
H_0 为假	第二类错误 (概率 β)	正确 (功效 $1 - \beta$)

显著性水平: $\alpha = \mathbb{P}(\text{第一类错误}) = \mathbb{P}(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$

自然的问题: 为什么不能同时最小化两类错误? 因为在固定样本量下, 两类错误是此消彼长的——降低 α 会提高 β , 反之亦然。这正是统计推断中不确定性本质的体现。

EXAMPLE 4.7 (正态均值检验、已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。检验 $H_0: \mu = \mu_0$ vs $H_1: \mu > \mu_0$ (单侧检验)。

检验统计量:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}. \quad (4.4.1)$$

在 α 水平下, 当 $Z > z_\alpha$ 时拒绝 H_0 。¹³

EXAMPLE 4.8 (正态均值检验、未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。检验 $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$ (双侧检验)。

检验统计量:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}. \quad (4.4.2)$$

在 α 水平下, 当 $|T| > t_{\alpha/2, n-1}$ 时拒绝 H_0 。¹⁴

p 值: 在 H_0 为真条件下, 观察到比当前样本更极端结果的概率。 p 值越小, 拒绝 H_0 的证据越强。

与置信区间的联系: 假设检验和置信区间在本质上是等价的——如果 μ_0 落在置信区间内, 我们就不拒绝 $H_0: \mu = \mu_0$; 反之则拒绝。

5. 4.5 Chi-Square Tests

直到现在, 我们讨论的都是连续型数据。但统计学同样关注**分类数据 (categorical data)**——即计数数据。例如: 选举中支持不同候选人的选民人数、不同药物治疗后的治愈/未治愈人数。

卡方检验的核心思想: 比较观测频数与期望频数。如果两者差异很大, 说明数据可能不服从假设的分布。

¹³详细推导见附录。

¹⁴详细推导见附录。