

数理统计导论

Hogg, McKean, Craig

目录

Part 1

概率论基础

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 notation，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 Overview

本章从概率论的公理化基础出发，逐步建立整套理论框架。这条脉络贯穿本书始终——理解随机现象的本质、建立描述分布的工具、掌握期望与矩的计算。

为什么从概率论开始？ 因为统计学的一切推断都建立在概率论的基础上。如果不理解概率的数学本质，就无法真正理解统计推断的逻辑。

本章路线图： 随机现象 → 概率公理 → 条件概率与独立性 → 随机变量 → 离散/连续分布 → 期望与矩 → 矩母函数 → 重要不等式

1. 1.1 Introduction: Why Probability Theory?

1.1. The Genesis of Probability. 概率论的故事始于一场赌博。1654 年，赌徒 Chevalier de Méré 向数学家 Blaise Pascal 提出一个问题：如果两名玩家在赌局中途中断，如何公平地分配赌金？这个问题引发了 Pascal 与 Pierre de Fermat 的通信，从而奠定了概率论的基础。

从频率到概率： 设想进行 N 次重复实验。事件 A 发生的次数记为 $f_N(A)$ ，则 $f_N(A)/N$ 称为相对频率 (relative frequency)。当 N 增大时， $f_N(A)/N$ 趋于稳定，趋向某个数 p ——这正是事件 A 的概率。Kolmogorov 在 1933 年的开创性著作《概率论基础》中将这种直觉严格化，建立了现代概率论的公理化体系。

两派观点： 概率的相对频率解释依赖于实验可重复的条件。另一种观点——贝叶斯学派——将概率视为主观信念的度量。无论采用哪种解释，概率的数学性质（公理）都是一致的，因此我们可以在坚实的数学基础上统一处理。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. Random Experiments and Sample Spaces. 若一个实验可以在相同条件下重复进行，且所有可能的结果可以在实验前描述，我们就称其为随机实验 (random experiment)。

所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

这三个例子揭示了样本空间的三种类型：离散有限（硬币）、离散无限（骰子）、连续（等待时间）。理解样本空间的类型决定了我们使用离散还是连续的数学工具。

EXAMPLE 1.1 (Coin Toss). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (Two Dice). 投掷一枚红骰子和一枚白骰子。样本空间包含 36 个有序对: $\mathcal{C} = \{(1, 1), (1, 2), \dots, (6, 6)\}$ 。

EXAMPLE 1.3 (Continuous Sample Space). 等待地铁到达的时间。样本空间为 $\mathcal{C} = (0, \infty)$ ——这是一个连续不可数的集合。

事件是样本空间的子集。如果一个实验进行一次, 事件 A 要么发生, 要么不发生, 没有第三种可能。概率论正是描述这种不确定性的数学语言。

2. 1.2 Sets: The Language of Uncertainty

2.1. Why Do We Need Set Theory for Probability? 在概率论中, 事件 (event) 本质上就是样本空间的子集。为什么要用集合的语言? 因为集合运算 (并、交、补) 完美地对应了事件的逻辑运算 (“或”、“且”、“非”)。

德摩根定律 (De Morgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c. \quad (1.2.1)$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C). \quad (1.2.2)$$

这些看似简单的定律, 在概率计算中非常有用。例如, 要计算 “既不是 A 也不是 B ” 的概率, 我们可以直接使用德摩根定律: $\mathbb{P}((A \cup B)^c) = \mathbb{P}(A^c \cap B^c)$ 。

2.2. Key Set Operations. 设 $\mathcal{C}$ 为样本空间, A, B, C 为事件:

- **补集** A^c : 所有不在 A 中的元素
- **并集** $A \cup B$: 至少在 A 或 B 之一中的元素
- **交集** $A \cap B$: 同时在 A 和 B 中的元素
- **不交** $A \cap B = \phi$: A 和 B 互不相容

EXAMPLE 1.4 (Set Operations). 设 $\mathcal{C} = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。

则 $A^c = \{3, 4, \dots, 10\}$, $A \cup B = \{1, 2, 3, 4\}$, $A \cap B = \{2\}$, $A \cap C = \phi$, $B \cap C = \{3, 4\}$ 。

2.3. Countable and Uncountable Sets. 若集合 C 是有限的, 或与正整数集等势, 则称 C 为可数的 (countable)。

可数并: $\cup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}$

可数交: $\cap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \cup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \cap_{n=1}^{\infty} A_n$ 。