

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;

1E/Æ

É ЪJm *!œ z	d
É ЪJm *!œ z	d
RX n ô! ¹Jr	d
kX Æpμ(¬	d
jX øgĐáμè ª	Ry
9Xz ¢š ÷	Ry
8X £ ´	RR
*? Ti2`RX S`Q# #BHBiv M/ .Bbi`B#miBQMb	Rj
*? Ti2`R Pp2`pB2r	Rj
RX RXR AMi`Q/m+iBQM, q?v S`Q# #BHBiv h?2Q`v\	Rj
kX RXk a2ib, h?2 G M;m ;2 Q7 IM+2`i BMiv	R9
jX RXj h?2 S`Q# #BHBiv a2i 6mM+iBQM	R8
9X RX9 *QM/BiBQM H S`Q# #BHBiv M/ AM/2T2M/2M+2	R+8
8X RX8 _ M/QK o `B #H2b	Rd
eX RXe .Bb+`2i2 _ M/QK o `B #H2b	Rd
dX RXd *QM iBMmQmb _ M/QK o `B #H2b	RN
3X RX3 1tT2+i iBQM Q7 _ M/QK o `B #H2	kR
NX RXN aQK2 aT2+B H 1tT2+i iBQM b	kk
RyX RXRy AKTQ`i Mi AM2[m HBiB2b	k9
amKK `v	k8
1t2`+Bb2b	k8
RRX9Jm 4 Ô	kd
*? Ti2`kX œ8•õ74¿	j8
*? Ti2`!k	j8
RX kXÄÄ ú ÄJm>Á4¿	j8
kX kX% 4¿Jm i43 D	jd
jX kXijn 4¿Jm ž¥ácÚ	jN
9X k Xù9Jm 8•½á ôj. • ô	98
8X kX 8m ö .>á••	93
eX kXÄe nJm 73ôá Ä4¿	8y
dX kXÄd 2	8k

x	25	20	26	26	28	28	29	32	20	25
y	138	84	104	112	88	132	90	183	100	143
x	26	28	25	31	30					
y	141	161	124	118	168					

数据也在 *rda* 文件 *regr1.rda* 中。使用 *R* 或其他统计软件进行计算和绘图。

- 计算这些数据的最小二乘回归线。
- 在同一图上绘制散点和最小二乘回归线。
- 获取残差图并评价模型的适用性。
- 求 β 的 95% 置信区间。就问题给出评论。

EXERCISE 9.33. ?? 电话数据回归分析-Hogg 9.6.3 考虑以下数据。该数据集的响应变量 y 是 1950 年至 1973 年比利时电话通话次数 (单位: 千万次)。时间 (年份) 作为预测变量 x 。数据在文件 *telephone.rda* 中。

- 计算这些数据的最小二乘回归线。
- 在同一图上绘制散点和最小二乘回归线。
- 最小二乘拟合效果差的原因是什么?

EXERCISE 9.34. ?? 回归估计量的协方差-Hogg 9.6.4 证明 $\hat{\alpha}$ 与 $\hat{\beta}$ 之间的协方差为零。

提示: 利用 (??) 中 $\hat{\beta}$ 的表达式, 以及 $\sum_{i=1}^n (x_i - \bar{x}) = 0$ 的性质。

EXERCISE 9.35. ?? 回归参数的置信区间-Hogg 9.6.5 在模型 (??) 下, 求参数 α 和 β 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.36. ?? 均值估计量的分布与置信区间-Hogg 9.6.6 考虑模型 (9.6.1)。设 $\eta_0 = E(Y|x = x_0 - \bar{x})$ 。 η_0 的最小二乘估计量是 $\hat{\eta}_0 = \hat{\alpha} + \hat{\beta}(x_0 - \bar{x})$ 。

- 使用 (9.6.9), 证明 $\hat{\eta}_0$ 是无偏估计量, 并证明其方差为

$$V(\hat{\eta}_0) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

- 获取 $\hat{\eta}_0$ 的分布, 并用它来确定 η_0 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.37. ?? 预测区间-Hogg 9.6.7 假设样本 $(x_1, Y_1), \dots, (x_n, Y_n)$ 服从线性模型 (9.6.1)。设 Y_0 是在 $x = x_0 - \bar{x}$ 处的一个未来观测值, 我们想为其确定一个预测区间。假设模型 (9.6.1) 对 Y_0 成立; 即 $Y_0 \sim N(\alpha + \beta(x_0 - \bar{x}), \sigma^2)$ 。我们使用练习 9.6.6 中的 $\hat{\eta}_0$ 作为对 Y_0 的预测。

- 获取 $Y_0 - \hat{\eta}_0$ 的分布, 证明其方差为:

$$V(Y_0 - \hat{\eta}_0) = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

- 获取以 $Y_0 - \hat{\eta}_0$ 为分子的 t 统计量。

(c) 现在从 $1 - \alpha = P[-t_{\alpha/2, n-2} < T < t_{\alpha/2, n-2}]$ 开始, 其中 $0 < \alpha < 1$, 确定 Y_0 的 $(1 - \alpha)100\%$ 预测区间。

(d) 将此预测区间与练习 9.6.6 获得的置信区间进行比较。为什么预测区间更大？从直觉上解释。

EXERCISE 9.38. ?? 奥运会 1500 米成绩的预测区间—Hogg 9.6.8 在例 9.6.1 中，我们得到了 2020 年奥运会男子 1500 米冠军成绩的预测。计算上一道练习中给出的该预测的 95% 预测区间。这些计算由 R 函数 `cipi.R` 执行。调用方式是 `cipi(lm(time~year), matrix(c(1,2020), ncol=2))`。就问题而言，这个预测区间意味着什么？接下来计算 2024 年和 2028 年奥运会的预测。为什么区间长度在增加？

EXERCISE 9.39. ?? 回归平方和分解—Hogg 9.6.9 证明以下等式成立：

$$\sum_{i=1}^n [Y_i - \alpha - \beta(x_i - \bar{x})]^2 = n(\hat{\alpha} - \alpha)^2 + (\hat{\beta} - \beta)^2 \sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^n [Y_i - \hat{\alpha} - \hat{\beta}(x_i - \bar{x})]^2.$$

提示：这本质上是将总平方和分解为拟合平方和与残差平方和。

EXERCISE 9.40. ?? 简单最小二乘拟合—Hogg 9.6.14 使用最小二乘法拟合 $y = a + x$ 到以下数据：

$$\begin{array}{r} x \quad 0 \quad 1 \\ 2 \\ \hline y \quad 1 \quad 3 \\ 4 \end{array}$$

EXERCISE 9.41. ?? 异方差回归模型的 MLE—Hogg 9.6.10 设独立随机变量 $Y_1, Y_2, \dots, Y_n$ 分别具有概率密度函数 $N(\beta x_i, \gamma^2 x_i^2)$, $i = 1, 2, \dots, n$ ，其中给定的数 $x_1, x_2, \dots, x_n$ 不全相等且均不为零。求 β 和 γ^2 的最大似然估计量。

EXERCISE 9.42. ?? 似然比检验与回归—Hogg 9.6.11 设独立随机变量 $Y_1, \dots, Y_n$ 具有联合 pdf

$$L(\alpha, \beta, \sigma^2) = \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n [y_i - \alpha - \beta(x_i - \bar{x})]^2 \right\},$$

其中给定的数 $x_1, x_2, \dots, x_n$ 不全相等。设原假设 $H_0: \beta = 0$ (α 和 σ^2 未指定)。希望使用似然比检验来检验 H_0 对所有备择假设。求 Λ ，并看看检验是否能基于一个熟悉的统计量。

提示：在本节的记号下，证明

$$\sum_{i=1}^n (Y_i - \hat{\alpha})^2 = Q_3 + \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2.$$

EXERCISE 9.43. ?? 线性趋势 ANOVA—Hogg 9.6.12 使用第 9.2 节的记号，假设均值满足 j 的线性函数： $\mu_j = c + d[j - (b+1)/2]$ 。从 b 个均值分别为 $\mu_1, \mu_2, \dots, \mu_b$ 、公共未知方差为 σ^2 的正态分布中分别抽取容量为 a 的独立随机样本。

(a) 证明 c 和 d 的最大似然估计量分别为 $\hat{c} = \bar{X}_{..}$ 和

$$\hat{d} = \frac{\sum_{j=1}^b [j - (b-1)/2](\bar{X}_{.j} - \bar{X}_{..})}{\sum_{j=1}^b [j - (b+1)/2]^2}.$$

(b) 类似于练习 9.2.5, 求平方和分解。

(c) 论证当 $d = 0$ 时, (b) 中右边的两项除以 σ^2 后是自由度分别为 1 和 $ab - 2$ 的独立卡方分布随机变量。

(d) 什么 F 统计量用于检验均值的相等性, 即 $H_0: d = 0$?

EXERCISE 9.44. ?? 最小二乘估计的几何-Hogg 9.6.13 考虑第 9.6.2 节的讨论。

(a) 证明 $\hat{\boldsymbol{\theta}} = \hat{\alpha}\mathbf{1} + \hat{\beta}\mathbf{x}_c$, 其中 $\hat{\alpha}$ 和 $\hat{\beta}$ 是本节导出的最小二乘估计量。

(b) 证明残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$; 即它的第 i 个元素是 $\hat{e}_i$, (9.6.7)。

(c) 如图 9.6.3 所示, 证明向量 $\hat{\boldsymbol{\theta}}$ 和 $\hat{\mathbf{e}}$ 之间的夹角是直角。

(d) 证明残差之和为零; 即 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 。

EXERCISE 9.45. ?? 平面拟合-Hogg 9.6.15 用最小二乘法拟合平面 $z = a + bx + cy$ 到五个点 $(x, y, z): (-1, -2, 5), (0, -2, 4), (0, 0, 4), (1, 0, 2), (2, 1, 0)$ 。

令 R 向量 $\mathbf{x}$ 、 $\mathbf{y}$ 、 $\mathbf{z}$ 包含 x 、 y 和 z 的值。则 LS 拟合通过 $\text{lm}(\mathbf{z} \sim \mathbf{x} + \mathbf{y})$ 计算。

EXERCISE 9.46. ?? 多元正态回归估计-Hogg 9.6.16 设 4×1 矩阵 $\mathbf{Y}$ 服从多元正态分布 $N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$, 其中 4×3 矩阵 $\mathbf{X}$ 等于

$$\mathbf{X} = \begin{pmatrix} 1 & 1 & 2 \\ 1 & -1 & 2 \\ 1 & 0 & -3 \\ 1 & 0 & -1 \end{pmatrix}.$$

(a) 求 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 的均值矩阵和协方差矩阵。

(b) 如果我们观测到 $\mathbf{Y}' = (6, 1, 11, 3)$, 计算 $\hat{\boldsymbol{\beta}}$ 。

EXERCISE 9.47. ?? 多元正态回归的 pdf-Hogg 9.6.17 设 $\mathbf{Y}$ 是 $n \times 1$ 随机向量, $\mathbf{X}$ 是 $n \times p$ 已知常数矩阵 (秩为 p), $\boldsymbol{\beta}$ 是 $p \times 1$ 回归系数向量。设 $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{I})$ 。求 $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ 的 pdf。

EXERCISE 9.48. ?? 异方差检验-Hogg 9.6.18 设独立正态随机变量 $Y_1, Y_2, \dots, Y_n$ 分别具有概率密度函数 $N(\mu, \gamma^2 x_i^2)$, $i = 1, 2, \dots, n$, 其中给定的 $x_1, x_2, \dots, x_n$ 不全相等且均不为零。讨论在未指定 μ 的情况下, 检验原假设 $H_0: \gamma = 1$ 对所有备择假设 $H_1: \gamma \neq 1$ 。

EXERCISE 9.49. ?? 相关系数表达式的化简-Hogg 9.7.1 证明

$$R = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sqrt{(\sum_{i=1}^n X_i^2 - n\bar{X}^2)(\sum_{i=1}^n Y_i^2 - n\bar{Y}^2)}}.$$

EXERCISE 9.50. ?? 相关系数的假设检验-Hogg 9.7.2 从二元正态分布中抽取容量为 $n = 6$ 的随机样本, 得到相关系数为 0.89 。在 5% 的显著性水平下, 我们是接受还是拒绝 $\rho = 0$ 的假设?

EXERCISE 9.51. ?? 验证相关系数的 t 分布-Hogg 9.7.3 验证本节的等式 (9.7.3)。

EXERCISE 9.52. ?? 验证相关系数的分布-Hogg 9.7.4 验证本节的 (9.7.4) 中的 pdf。

EXERCISE 9.53. ?? 相关系数的一致性-Hogg 9.7.5 使用第 4.5 节的结果, 证明 R , (9.7.1), 是 ρ 的一致估计量。

EXERCISE 9.54. ?? 相关系数的置信区间-Hogg 9.7.6 通过执行以下步骤, 确定 ρ 的 $(1 - \alpha)100\%$ 近似置信区间。

(a) 对于 $0 < \alpha < 1$, 通常从 $1 - \alpha = P(-z_{\alpha/2} < Z < z_{\alpha/2})$ 开始, 其中 Z 由表达式 (9.7.5) 给出。然后在不等式的中间部分孤立 $h(\rho) = (1/2) \log[(1 + \rho)/(1 - \rho)]$ 。求 $h'(\rho)$ 并证明它在 $-1 < \rho < 1$ 上严格为正; 因此 h 是严格递增的, 其逆函数存在。

(b) 证明这个逆函数是双曲正切函数, $\tanh(y) = (e^y - e^{-y})/(e^y + e^{-y})$ 。

(c) 获取 ρ 的 $(1 - \alpha)100\%$ 置信区间。

EXERCISE 9.55. ?? 棒球数据的相关系数分析-Hogg 9.7.7 R 函数 `cor.test(x, y)` 计算 ρ 的估计量和练习 9.7.6 中的置信区间。回忆棒球数据, 它在文件 `bb.rda` 中。

(a) 使用棒球数据, 确定职业棒球运动员身高与体重之间相关系数的估计值和置信区间。

(b) 将投手和击球手分开, 分别获取身高与体重之间相关系数的估计值和置信区间。它们有显著差异吗?

(c) 论证第二部分中相关系数估计值的差异是关于两个独立样本的 $\rho_1 - \rho_2$ 的一个模型。

EXERCISE 9.56. ?? 组合样本的相关系数-Hogg 9.7.8 两个实验给出以下结果:

n	$\bar{x}$	$\bar{y}$	s_x	s_y	r
100	10	20	5	8	0.70
200	12	22	6	10	0.80

计算组合样本的 r 。

EXERCISE 9.57. ?? 二次型与卡方分布-Hogg 9.8.1 设 $Q = X_1X_2 - X_3X_4$, 其中 X_1, X_2, X_3, X_4 是来自 $N(0, \sigma^2)$ 分布的容量为 4 的随机样本。证明 Q/σ^2 不服从卡方分布。求 Q/σ^2 的 mgf。

EXERCISE 9.58. ?? 二次型的非中心卡方分布-Hogg 9.8.2 设 $\mathbf{X}' = [X_1, X_2]$ 服从二元正态分布, 均值矩阵 $\boldsymbol{\mu}' = [\mu_1, \mu_2]$ 和正定协方差矩阵 Σ 。设

$$Q_1 = \frac{X_1^2}{\sigma_1^2(1 - \rho^2)} - 2\rho \frac{X_1X_2}{\sigma_1\sigma_2(1 - \rho^2)} + \frac{X_2^2}{\sigma_2^2(1 - \rho^2)}.$$

证明 $Q_1 \sim \chi^2(r, \theta)$, 并求 r 和 θ 。 Q_1 何时且仅何时服从中心卡方分布?

EXERCISE 9.59. ?? 非中心卡方分布的计算-Hogg 9.8.3 设 $\mathbf{X}' = [X_1, X_2, X_3]$ 是来自 $N(4, 8)$ 分布的容量为 3 的随机样本, 并设

$$\mathbf{A} = \begin{pmatrix} \frac{1}{2} & 0 & \frac{1}{2} \\ 0 & 1 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} \end{pmatrix}.$$

设 $Q = \mathbf{X}'\mathbf{A}\mathbf{X}/\sigma^2$ 。

(a) 使用定理 9.8.1 求 $E(Q)$ 。

(b) 说明为什么断言 $Q \sim \chi^2(2, 6)$ 成立。

EXERCISE 9.60. ?? 不等方差的样本均值方差-Hogg 9.8.4 假设 $X_1, \dots, X_n$ 是独立随机变量, 有公共均值 μ 但有不等方差 $\sigma_i^2 = \text{Var}(X_i)$ 。

(a) 确定 $\bar{X}$ 的方差。

(b) 确定常数 K , 使得 $Q = K \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\bar{X}$ 方差的无偏估计量。(提示: 按例 9.8.3 中的方法进行。)

EXERCISE 9.61. ?? 相关变量的样本均值方差-Hogg 9.8.5 假设 $X_1, \dots, X_n$ 是相关随机变量, 有公共均值 μ 和方差 σ^2 但相关系数 ρ (所有相关系数相同)。

(a) 确定 $\bar{X}$ 的方差。

(b) 确定常数 K , 使得 $Q = K \sum_{i=1}^n (X_i - \bar{X})^2$ 是 $\bar{X}$ 方差的无偏估计量。(提示: 按例 9.8.3 中的方法进行。)

EXERCISE 9.62. ?? 验证表达式 (9.8.13) -Hogg 9.8.6 补充表达式 (9.8.13) 的细节。

EXERCISE 9.63. ?? 迹算子的性质-Hogg 9.8.7 证明表达式 (9.8.1) 中定义的迹算子具有以下性质。

(a) 如果 $\mathbf{A}$ 和 $\mathbf{B}$ 是 $n \times n$ 矩阵, a 和 b 是标量, 则

$$\text{tr}(a\mathbf{A} + b\mathbf{B}) = a \text{tr} \mathbf{A} + b \text{tr} \mathbf{B}.$$

(b) 对于任何 $n \times n$ 矩阵 $\mathbf{A}$ 和 $\mathbf{B}$, $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ 。

(c) 如果 $\mathbf{A}$ 是方阵, Γ 是正交矩阵, 利用 (a) 的结果证明 $\text{tr}(\Gamma'\mathbf{A}\Gamma) = \text{tr} \mathbf{A}$ 。

(d) 如果 $\mathbf{A}$ 是实对称幂等矩阵, 利用 (b) 的结果证明 $\mathbf{A}$ 的秩等于 $\text{tr} \mathbf{A}$ 。

EXERCISE 9.64. ?? 矩阵元素平方和与特征值-Hogg 9.8.8 设 $\mathbf{A} = [a_{ij}]$ 是实对称矩阵。证明 $\sum_i \sum_j a_{ij}^2$ 等于 $\mathbf{A}$ 的特征值的平方和。

提示: 如果 Γ 是正交矩阵, 证明 $\sum_j \sum_i a_{ij}^2 = \text{tr}(\mathbf{A}^2) = \text{tr}(\Gamma'\mathbf{A}^2\Gamma) = \text{tr}[(\Gamma'\mathbf{A}\Gamma)(\Gamma'\mathbf{A}\Gamma)]$ 。

EXERCISE 9.65. ?? 非中心卡方分布的判定-Hogg 9.8.9 假设 $\mathbf{X} \sim N_n(0, \Sigma)$, 其中 Σ 是正定矩阵。对于对称矩阵 $\mathbf{A}$, 设 $Q = \mathbf{X}'\mathbf{A}\mathbf{X}$ 。证明当且仅当 $\mathbf{A}\Sigma\mathbf{A} = \mathbf{A}$ 时, $Q \sim \chi^2(r)$, 其中 $r = \text{rank}(\mathbf{A})$ 。

提示: 将 Q 写成

$$Q = (\Sigma^{-1/2} \mathbf{X})' \Sigma^{1/2} \mathbf{A} \Sigma^{1/2} (\Sigma^{-1/2} \mathbf{X}),$$

其中 $\Sigma^{1/2} = \Gamma' \Lambda^{1/2} \Gamma$, $\Sigma = \Gamma' \Lambda \Gamma$ 是 Σ 的谱分解。然后使用定理 9.8.4。

EXERCISE 9.66. ?? 幂等矩阵的特征值-Hogg 9.8.10 假设 $\mathbf{A}$ 是实对称矩阵。如果 $\mathbf{A}$ 的特征值只有 0 和 1, 证明 $\mathbf{A}$ 是幂等的。

EXERCISE 9.67. ?? 二次型的独立性判定-Hogg 9.9.1 设 X_1, X_2, X_3 是来自正态分布 $N(0, \sigma^2)$ 的随机样本。二次型 $X_1^2 + 3X_1X_2 + X_2^2 + X_1X_3 + X_3^2$ 和 $X_1^2 - 2X_1X_2 + \frac{2}{3}X_2^2 - 2X_1X_3 - X_3^2$ 是独立还是相关?

EXERCISE 9.68. ?? 平方和与二次型的相关性-Hogg 9.9.2 设 $X_1, X_2, \dots, X_n$ 表示来自 $N(0, \sigma^2)$ 分布的容量为 n 的随机样本。证明 $\sum_{i=1}^n X_i^2$ 与每一个在 $X_1, X_2, \dots, X_n$ 中非恒为零的二次型都是相关的。

EXERCISE 9.69. ?? 线性函数与二次型的独立性-Hogg 9.9.3 设 X_1, X_2, X_3, X_4 是来自 $N(0, \sigma^2)$ 分布的容量为 4 的随机样本。设 $Y = \sum_{i=1}^4 a_i X_i$, 其中 a_1, a_2, a_3, a_4 是实常数。如果 Y^2 和 $Q = X_1X_2 - X_3X_4$ 独立, 确定 a_1, a_2, a_3, a_4 。

附录：公式推导

One-Way ANOVA 平方和恒等式的证明. 背景：在 one-way ANOVA 中, 总平方和 Q 可以分解为组内平方和 Q_3 与组间平方和 Q_4 之和。这一恒等式是 F 检验的基石。

目标：证明

$$\sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{..})^2 = \sum_{j=1}^b \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j=1}^b n_j (\bar{X}_{.j} - \bar{X}_{..})^2. \quad (\text{A9.1})$$

推导：记 $d_{ij} = X_{ij} - \bar{X}_{..}$ 。则

$$d_{ij} = (X_{ij} - \bar{X}_{.j}) + (\bar{X}_{.j} - \bar{X}_{..}).$$

展开平方和：

$$\sum_{j,i} d_{ij}^2 = \sum_{j,i} (X_{ij} - \bar{X}_{.j})^2 + \sum_{j,i} (\bar{X}_{.j} - \bar{X}_{..})^2 + 2 \sum_{j,i} (X_{ij} - \bar{X}_{.j})(\bar{X}_{.j} - \bar{X}_{..}).$$

最后一项为零, 因为对每个固定的 j ,

$$\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j}) = 0,$$

故交叉项为零。得证。

□

One-Way ANOVA 检验统计量的分布. 背景: 推导 one-way ANOVA 中 F 统计量在原假设下的分布。

目标: 证明在 H_0 下, $F = [Q_4/(b-1)]/[Q_3/(n-b)] \sim F(b-1, n-b)$ 。

推导:

步骤 1: Q_3 的分布. 对每个固定的 j , 由样本方差性质, $\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2 / \sigma^2 \sim \chi^2(n_j - 1)$ 。各组样本独立, 故

$$\frac{Q_3}{\sigma^2} = \sum_{j=1}^b \frac{\sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2}{\sigma^2} \sim \chi^2\left(\sum_{j=1}^b (n_j - 1)\right) = \chi^2(n-b). \quad (\text{A9.2})$$

步骤 2: Q_4 与 Q_3 的独立性. 注意 $\bar{X}_{.j}$ 与 Q_3 独立 (由正态样本的性质), 且 $\bar{X}_{..}$ 是 $\bar{X}_{.1}, \dots, \bar{X}_{.b}$ 的线性组合, 因此 $\bar{X}_{..}$ 也与 Q_3 独立。故 Q_4 ($\bar{X}_{.j}$ 的函数) 与 Q_3 独立。

步骤 3: Q_4 的分布. 在 H_0 下, $\bar{X}_{.j} \sim N(\mu, \sigma^2/n_j)$, 故

$$\frac{n_j(\bar{X}_{.j} - \bar{X}_{..})^2}{\sigma^2} \sim \chi^2(1).$$

但各 $\bar{X}_{.j}$ 通过 $\bar{X}_{..}$ 而不独立。直接计算知 $Q_4/\sigma^2 \sim \chi^2(b-1)$ 。

步骤 4: F 分布. 由步骤 1、2、3 及 F 分布定义,

$$F = \frac{Q_4/(b-1)}{Q_3/(n-b)} \sim F(b-1, n-b). \quad (\text{A9.3})$$

□

非中心 χ^2 分布的均值和方差. 背景: 验证非中心 χ^2 分布的基本性质。

已知: $Y \sim \chi^2(r, \theta)$, mgf 为 $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。

目标: 求 $\mathbb{E}(Y)$ 和 $\text{var}(Y)$ 。

推导:

由 mgf, $M(t) = (1-2t)^{-r/2} \exp\{t\theta/(1-2t)\}$ 。对 $M(t)$ 求导:

$$M'(t) = \left[r(1-2t)^{-r/2-1} + \frac{r\theta}{(1-2t)^{r/2+1}} \right] \exp\left\{ \frac{t\theta}{1-2t} \right\}.$$

故 $E(Y) = M'(0) = r + \theta$ 。

对 $M''(t)$ 在 $t=0$ 求值, 可得 $\text{var}(Y) = 2(r + 2\theta)$ 。⁴

最小二乘估计的几何解释. 背景: 回归最小二乘估计的正交投影几何。

目标: 证明 $\hat{\boldsymbol{\theta}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ 是 $\mathbf{Y}$ 在 $V = \text{span}(\mathbf{1}, \mathbf{x}_c)$ 上的正交投影。

推导: 由正交投影的定义, $\hat{\boldsymbol{\theta}}$ 满足:

$$\mathbf{Y} - \hat{\boldsymbol{\theta}} \perp V.$$

即残差向量 $\hat{\mathbf{e}} = \mathbf{Y} - \hat{\boldsymbol{\theta}}$ 与 $\mathbf{1}$ 和 $\mathbf{x}_c$ 都正交:

$$\mathbf{1}'\hat{\mathbf{e}} = 0, \quad \mathbf{x}_c'\hat{\mathbf{e}} = 0. \quad (\text{A9.4})$$

由 $\mathbf{1}'\hat{\mathbf{e}} = 0$ 得 $\sum_i \hat{e}_i = 0$ (残差之和为零)。

⁴该推导的详细计算见附录 ??。

由 $\mathbf{x}'_e \hat{\mathbf{e}} = 0$ 并利用正规方程，可解出 $\hat{\alpha}$ 和 $\hat{\beta}$ 的表达式与 (??)、(??) 一致。故 $\hat{\boldsymbol{\theta}}$ 确为正交投影。 $\square$

附录：公式推导

0.1. Gamma 分布的矩母函数推导. 背景 (Background)： 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions)：

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given)：

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal)： 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps)：

1. 根据矩母函数定义：

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换：令 $y = \frac{x(1-\beta t)}{\beta}$ ，则 $x = \frac{\beta y}{1-\beta t}$ ， $dx = \frac{\beta}{1-\beta t} dy$ 。
3. 代入积分（要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$ ）：

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论： 因此， $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ ，定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background)： 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$ ，方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given)：

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

0.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证: 边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$, 确实是合法的 pdf。

结论: 条件 pdf 公式得证。■

0.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发:

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望 (即关于 X_1 求平均):

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论: 全期望公式得证。■

0.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论: 条件均值的方差不超过原变量的方差, 等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

0.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论: 故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.11. 相关系数范围的推导. 背景 (Background): 我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal): 证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps):

1. Cauchy-Schwarz 不等式: 对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差, 令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$:

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方:

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此:

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论: 故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

0.12. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.14. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.15. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.16. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j \mid Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j \mid Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.17. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。
2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.18. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。
2. 则 $X = \sum_{j=1}^n I_j$ 。
3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.19. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1-p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1) \cdots (n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} \rightarrow 1, \\ \left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.20. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数：

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论： Poisson 分布的均值和方差相等，都等于参数 λ 。■

0.21. 卡方分布与正态分布的关系. 背景 (Background)： 卡方分布定义为标准正态平方和。

目标 (Goal)： 证明若 $Z \sim N(0, 1)$ ，则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps)：

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$ ，先求 cdf：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf：

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式：

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论： 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.22. 卡方分布的可加性证明. 背景 (Background)： 卡方分布满足可加性：独立卡方变量之和仍为卡方分布。

目标 (Goal)： 证明若 $X_1 \sim \chi^2(m)$ ， $X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps)：

1. 由卡方分布与 Gamma 分布的关系： $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性（见定理 3.3.1）：若 $Y_1 \sim \Gamma(\alpha_1, \beta)$ ， $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立，则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此：

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf： $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$ ，故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论： 卡方分布具有可加性，自由度可累加。■

0.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1 + X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.24. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.25. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.26. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}[e^{(t/\sigma)X}] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.27. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

0.28. 弱大数定律的完整推导. 背景 (Background): 弱大数定律 (Weak Law of Large Numbers, WLLN) 表明, 当样本量趋于无穷时, 样本均值依概率收敛到总体均值。

目标 (Goal): 证明对于独立同分布的随机变量 $X_1, X_2, \dots$, 若 $\mathbb{E}[X_i] = \mu$ 且 $\text{var}(X_i) = \sigma^2 < \infty$, 则 $\bar{X}_n \xrightarrow{P} \mu$ 。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.29. 乘积收敛性的完整证明. 背景 (Background): 若 $X_n \xrightarrow{P} X$ 且 $Y_n \xrightarrow{P} Y$, 在什么条件下有 $X_n Y_n \xrightarrow{P} XY$?

目标 (Goal): 证明乘积的收敛性定理。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.30. 样本方差一致性的完整推导. 背景 (Background): 样本方差 S_n^2 是总体方差 σ^2 的一致估计。

目标 (Goal): 证明 $S_n^2 \xrightarrow{P} \sigma^2$ 。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.31. 均匀分布最大值的详细分析. 背景 (Background): 对于 $U(0, \theta)$ 分布, 样本最大值 Y_n 的分布分析。

目标 (Goal): 详细推导 Y_n 的期望、方差及其一致性。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.32. 退化分布的详细分析. 背景 (Background): 退化分布是所有概率质量集中于一点的分布。

目标 (Goal): 分析在什么情况下 $\bar{X}_n$ 收敛到退化分布。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.33. Stirling 公式. 背景 (Background) : Stirling 公式用于近似阶乘: $n! \approx \sqrt{2\pi n}(n/e)^n$ 。

目标 (Goal): 给出 Stirling 公式的推导。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.34. 均匀分布到指数分布的完整推导. 背景 (Background) : 标准化后的均匀分布最大值收敛到指数分布。

目标 (Goal): 证明 $n(\max\{X_1, \dots, X_n\} - 1) \xrightarrow{D} \text{Exp}(1)$ 。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.35. 依概率收敛到依分布收敛的完整证明. 背景 (Background) : 依概率收敛是依分布收敛的充分条件, 但非必要条件。

目标 (Goal): 证明当 $X_n \xrightarrow{P} c$ (常数) 时, 有 $X_n \xrightarrow{D} c$ 。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.36. Slutsky 定理的详细证明. 背景 (Background) : Slutsky 定理允许在依分布收敛的极限中替换依概率收敛的随机变量。

目标 (Goal): 证明 Slutsky 定理的完整形式。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.37. 正态分布有界性的证明. 背景 (Background) : 正态分布的尾部概率可以任意小。

目标 (Goal): 证明对任意 $\epsilon > 0$, 存在 η 使得 $\mathbb{P}[|X| > \eta] < \epsilon$ 。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.38. 乘积收敛到依概率收敛的完整证明. 背景 (Background) : 若 $X_n \xrightarrow{P} X$ 且 $Y_n \xrightarrow{P} 0$, 则 $X_n Y_n \xrightarrow{P} 0$ 。

目标 (Goal): 证明该定理。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.39. Δ 方法的完整推导. 背景 (Background) : Δ 方法用于计算渐近分布的变换。

目标 (Goal): 证明若 $\sqrt{n}(X_n - \mu) \xrightarrow{D} N(0, \sigma^2)$, 则 $\sqrt{n}(g(X_n) - g(\mu)) \xrightarrow{D} N(0, \sigma^2[g'(\mu)]^2)$ 。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.40. 卡方分布 Δ 方法的详细推导. 背景 (Background) : 将 Δ 方法应用于卡方变量的标准差。

目标 (Goal): 求 $\sqrt{n}(\sqrt{V_n} - \sqrt{v})$ 。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.41. 二项分布到泊松分布近似的误差分析. 背景 (Background) : 当 n 增大、 p 减小时, 二项分布可用泊松分布近似。

目标 (Goal): 分析该近似的误差界。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.42. 中心极限定理的完整证明. 背景 (Background): 中心极限定理 (CLT) 是统计学中最重要的定理之一。

目标 (Goal): 用矩母函数方法证明独立同分布随机变量的 CLT。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.43. 均匀分布样本均值概率的详细计算. 背景 (Background): $U(0, 1)$ 样本均值 $\bar{X}$ 的分布不是正态, 但可用 CLT 近似。

目标 (Goal): 计算 $\mathbb{P}(\bar{X} \leq 0.5)$ 的精确值和近似值。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.44. 比例推断的详细讨论. 背景 (Background): 比例 p 的置信区间和假设检验。

目标 (Goal): 详细推导比例推断的渐近理论。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.45. 卡方检验的详细推导. 背景 (Background): 拟合优度 χ^2 检验的理论基础。

目标 (Goal): 推导 χ^2 统计量的渐近分布。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.46. 方差稳定化变换的详细讨论. 背景 (Background): 方差稳定化变换使得变换后的变量方差近似常数。

目标 (Goal): 推导方差稳定化变换的一般形式。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

0.47. 多元中心极限定理的完整证明. 背景 (Background): 多元 CLT 是一元 CLT 的推广。

目标 (Goal): 用 mgf 方法证明多元 CLT。

推导步骤 (Derivation Steps): 占位符内容 (待补充)。

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是**固定（但未知）的常数**，而区间 $[L, U]$ 是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 Chapter 4 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及（直方图估计）
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

简单区分：

场景	方法	章节
分布形式未知	非参数方法（直方图、核密度估计）	Chapter 10
分布形式已知、参数未知	参数方法（MLE、CI、检验）	Chapter 4

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计（MLE）被提出的**动机**。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

具体例子：

- S^2 （无偏）和 $\hat{\sigma}^2$ （有偏，但 MLE）
- 两者都常用，但各有用途
- “最优”需要更精确的定义（后续章节的 UMVUE）

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

学习笔记.