

数理统计导论

Hogg, McKean, Craig

目录

Part 1. 概率论基础	5
引言：从随机性中学习	7
引言：从随机性中学习	7
1. 为什么需要概率论?	7
2. 教材内容预览	7
3. 这三章的内在逻辑	10
4. 学习方法建议	10
5. 习题说明	11
Chapter 1. Probability and Distributions	13
Chapter 1 概述	13
1. 1.1 Introduction	13
2. 1.2 Sets	14
3. 1.3 The Probability Set Function	15
4. 1.4 Conditional Probability and Independence	16
5. 1.5 Random Variables	17
6. 1.6 Discrete Random Variables	17
7. 1.7 Continuous Random Variables	18
8. 1.8 Expectation of a Random Variable	18
9. 1.9 Some Special Expectations	19
10. 1.10 Important Inequalities	19
Summary	20
Exercises	20
Chapter 2. 多元随机变量及其分布	23
Chapter 2 概述	23
1. 2.1 从一元到多元：为什么需要联合分布?	23
2. 2.2 变换：寻找新视角	24
3. 2.3 条件分布：信息的价值	25
4. 2.4 独立性：变量间的”无关系”	26
5. 2.5 相关性：线性关联的度量	26
6. 2.6 二元正态：最重要的二元分布	27

7. 2.7 多元推广	28
8. 本章总结	28
习题	29
Chapter 3. Special Distributions	31
Chapter 3 Overview	31
1. 3.1 From Bernoulli to Binomial: The Science of Counting	31
2. 3.2 The Poisson Distribution: The World of Rare Events	33
3. 3.3 The Gamma, χ^2 , and Beta Distributions	34
4. 3.4 The Normal Distribution: Queen of Statistics	36
5. 3.5 Multivariate Normal Distribution	37
6. 3.6 The t and F Distributions	37
Chapter Summary	39
Chapter 4. Some Elementary Statistical Inferences	41
Chapter 4 Overview	41
1. 4.1 Sampling and Statistics	41
2. 4.2 Point Estimation	42
3. 4.3 Confidence Intervals	44
4. 4.4 Hypothesis Testing	45
5. 4.5 Chi-Square Tests	46
6. 4.6 Monte Carlo Methods	47
7. 4.7 Bootstrap Methods	47
Exercises	48
本章小结	62
8. 附录：公式推导	62
1. 附录：公式推导	68
2. 问答记录	75

Part 1

概率论基础

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 *notation*，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 概述

本章从概率论的公理化基础出发，逐步建立整套理论框架。我们将从集合论的语言开始，引入概率的严格定义，然后过渡到条件概率、独立性等核心概念，最终走向随机变量与期望的一般理论。这一脉络不仅是数理统计的基础，更是理解整个现代统计学的钥匙。

1. 1.1 Introduction

1.1. 为何需要概率论? 在科学研究中，我们经常面对这样的情境：在本质上相同的条件下，可以反复进行某种实验。例如，医学研究者关心新药的效果；经济学家关注某些商品的价格波动；农学家研究肥料对作物产量的影响。这种实验产生的结果在实验前无法确定预测——这正是随机现象的本质。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. 随机实验与样本空间. 若一个实验可以在相同条件下重复进行，且所有可能的结果 (outcome) 可以在实验前描述，我们就称其为随机实验 (random experiment)。所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

EXAMPLE 1.1 (例 1.1.1). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (例 1.1.2). 投掷一枚红骰子和一枚白骰子。令 *outcome* 为有序对 (红骰子点数，白骰子点数)。样本空间包含 36 个有序对： $\mathcal{C} = \{(1, 1), \dots, (6, 6)\}$ 。

1.3. 事件与概率的直观起源. 我们用小写 Roman 字母 (如 a, b, c) 表示 $\mathcal{C}$ 的元素，用大写 Roman 字母 (如 A, B, C) 表示 $\mathcal{C}$ 的子集，即事件 (event)。

设想进行 N 次重复实验。事件 A 发生的次数 (频率) 记为 f ，则 f/N 称为相对频率 (relative frequency)。当 N 增大时，相对频率趋于稳定，趋向某个数 p ——这正是事件 A 的概率 (probability)。

概率的相对频率解释依赖于实验可重复的条件。另一种观点是将概率视为主观信念 (贝叶斯学派)。无论采用哪种解释，1.3 节的概率数学性质都是一致的。

统计学的目的就是为随机实验提供数学模型，进而进行统计推断。

2. 1.2 Sets

2.1. 集合论基础. 集合 (set) 是现代数学的基本概念。若对象 x 属于集合 C , 记作 $x \in C$ 。

若集合 C 是有限的或与正整数集等势, 则称 C 为可数的 (countable)。

设 C 为样本空间。事件是 C 的子集。

DEFINITION 1.1 (定义 1.2.1). 事件 A 的补 (complement) A^c 是 C 中所有不属于 A 的元素构成的集合: $A^c = \{x \in C : x \notin A\}$ 。

空集 (empty set) 记为 ϕ 。注意 $C^c = \phi$, $\phi^c = C$ 。

DEFINITION 1.2 (定义 1.2.2). 若集合 A 的每个元素都是集合 B 的元素, 则称 A 是 B 的子集, 记作 $A \subset B$ 。若 $A \subset B$ 且 $B \subset A$, 则 $A = B$ 。

DEFINITION 1.3 (定义 1.2.3). 设 A 和 B 为事件。 A 和 B 的并 (union) $A \cup B$ 是所有属于 A 或属于 B 的元素构成的集合。

DEFINITION 1.4 (定义 1.2.4). 设 A 和 B 为事件。 A 和 B 的交 (intersection) $A \cap B$ 是所有同时属于 A 和 B 的元素构成的集合。

DEFINITION 1.5 (定义 1.2.5). 若 $A \cap B = \phi$, 则称 A 和 B 是不交的 (disjoint)。

可数并和可数交定义为

$$\bigcup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}, \quad \bigcap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}.$$

德摩根定律 (DeMorgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c.$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

EXAMPLE 1.3 (例 1.2.1). 设 $C = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。则

$$A^c = \{3, 4, \dots, 10\}, \quad A \cup B = \{1, 2, 3, 4\}, \quad A \cap B = \{2\},$$

$$A \cap C = \phi, \quad B \cap C = \{3, 4\}.$$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} A_n$ 。

2.2. 集合函数. 集合函数 (set function) 是将集合映射到实数的函数。

EXAMPLE 1.4 (例 1.2.2). 设 $\mathcal{C} = \mathbb{R}$, $Q(A)$ 为 A 中正整数的个数。若 $A = \{x : 0 < x < 5\}$, 则 $Q(A) = 4$ 。

EXAMPLE 1.5 (例 1.2.3). 设 $\mathcal{C} = \mathbb{R}^2$, $Q(A)$ 为 A 的面积。若 $A = \{(x, y) : x^2 + y^2 \leq 1\}$ (单位圆盘), 则 $Q(A) = \pi$ 。

集合函数常用求和或积分定义。记号:

$\sum_A f(x)$ 表示在所有 $x \in A$ 上求和, $\int_A f(x) dx$ 表示在集合 A 上的积分。

3. 1.3 The Probability Set Function

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。¹

DEFINITION 1.6 (定义 1.3.1 (概率)). 设 $\mathcal{C}$ 为样本空间, $\mathcal{B}$ 为事件域。函数 $\mathbb{P} : \mathcal{B} \rightarrow \mathbb{R}$ 满足以下三条条件则称为概率集函数:

- (1) $\mathbb{P}(A) \geq 0$, 对所有 $A \in \mathcal{B}$
- (2) $\mathbb{P}(\mathcal{C}) = 1$
- (3) 若 $\{A_n\}$ 为两两不相交的事件序列, 则

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

若事件序列两两不相交, 称其为互不相容的 (mutually exclusive)。若其并为 $\mathcal{C}$, 则构成 $\mathcal{C}$ 的一个划分 (partition)。

概率集函数告诉我们在事件域上概率如何分布。从这三条公理出发, 可以推导出概率论的所有其他结果。²

THEOREM 1.1 (定理 1.3.1). 对每个事件 $A \in \mathcal{B}$, $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ 。

证明. 由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$, 结合公理 (2) 和 (3) 得

$$1 = \mathbb{P}(A) + \mathbb{P}(A^c).$$

□

THEOREM 1.2 (定理 1.3.2). $\mathbb{P}(\phi) = 0$ 。

EXAMPLE 1.6 (例 1.3.1). 从 52 张扑克牌中随机抽取一张。设 A 为抽到 A 的事件, B 为抽到红桃的事件。则 $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52} = \frac{4}{13}$ 。

¹详细推导见附录 ??。

²详细推导见附录 ??。

等可能性情形 (Equilikely Case): 若样本空间 $\mathcal{C} = \{x_1, x_2, \dots, x_m\}$ 有限, 且每个 outcome 等概率 $p_i = 1/m$, 则

$$\mathbb{P}(A) = \sum_{x_i \in A} \frac{1}{m} = \frac{\#(A)}{m}.$$

4. 1.4 Conditional Probability and Independence

4.1. Conditional Probability. 我们经常需要在已知某些信息发生的条件下, 对事件概率进行调整。这就是条件概率 (conditional probability) 的直观来源。

DEFINITION 1.7 (定义 1.4.1 (条件概率)). 设 $\mathbb{P}(B) > 0$, 在事件 B 已发生的条件下, 事件 A 的条件概率定义为

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

由条件概率定义可直接导出乘法法则 (multiplication rule):

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) = \mathbb{P}(B) \cdot \mathbb{P}(A | B).$$

推广到 n 个事件:

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right).$$

全概率公式 (Law of Total Probability): 设 $\{B_i\}$ 为 $\mathcal{C}$ 的一个划分, 则对任意事件 A ,

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i).$$

THEOREM 1.3 (定理 1.4.1 (贝叶斯公式)). 设 $\{B_i\}$ 为 $\mathcal{C}$ 的一个划分, $\mathbb{P}(B_i) > 0$. 则对任意事件 A ($\mathbb{P}(A) > 0$),

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i)}.$$

术语: $\mathbb{P}(B_j)$ 为先验概率 (prior probability), $\mathbb{P}(B_j | A)$ 为后验概率 (posterior probability), $\mathbb{P}(A | B_j)$ 为似然 (likelihood)。

贝叶斯公式不仅仅是一个计算工具, 更提供了一种思考不确定性的思维方式。³

EXAMPLE 1.7 (例 1.4.1 (医学检测)). 设某疾病患病率为 1%, 检测准确率为 99%。令 $D = \{\text{患病}\}$, $+= \{\text{检测阳性}\}$ 。则

$$\mathbb{P}(D | +) = \frac{\mathbb{P}(D) \cdot \mathbb{P}(+ | D)}{\mathbb{P}(D) \cdot \mathbb{P}(+ | D) + \mathbb{P}(D^c) \cdot \mathbb{P}(+ | D^c)} = \frac{0.01 \cdot 0.99}{0.01 \cdot 0.99 + 0.99 \cdot 0.01} = \frac{1}{2}.$$

即使检测准确率高达 99%, 检测阳性者真正患病的概率只有 50%!

³详细讨论见附录 ??。

4.2. 1.4.1 Independence.

DEFINITION 1.8 (定义 1.4.2 (独立性)). 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$, 则称事件 A 与 B 相互独立 (*independent*), 记作 $A \perp B$ 。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时, 独立性等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$ 或 $\mathbb{P}(B | A) = \mathbb{P}(B)$ 。

EXAMPLE 1.8 (例 1.4.2). 抛掷两枚独立硬币。设 A 为第一枚正面朝上, B 为第二枚正面朝上。则 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$, 且 $\mathbb{P}(A \cap B) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B)$, 故 $A \perp B$ 。

DEFINITION 1.9 (定义 1.4.3 (相互独立)). 事件序列 $\{A_i : i \in I\}$ 相互独立, 若对任意有限子集 $\{i_1, \dots, i_k\}$,

$$\mathbb{P}\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k \mathbb{P}(A_{i_j}).$$

Warning: 两两独立 (pairwise independent) 不一定意味着相互独立!⁴

5. 1.5 Random Variables

样本空间 $\mathcal{C}$ 的元素可能不是数字, 这在描述和分析上会带来不便。我们需要一个规则, 将 $\mathcal{C}$ 的每个元素映射到一个实数——这正是随机变量 (random variable) 的思想。

随机变量 (random variable) 是从样本空间 $\mathcal{C}$ 到实数的函数: $X : \mathcal{C} \rightarrow \mathbb{R}$ 。

通常用大写字母 X, Y, Z 表示随机变量, 用小写字母 x, y, z 表示具体取值。

随机变量可分为:

- 离散随机变量 (discrete): 取值可数
- 连续随机变量 (continuous): 取值充满区间, 不可数

给定随机变量 X , 它的取值空间 $\mathcal{D}$ 成为新的样本空间。 X 不仅诱导了新的样本空间, 还诱导了一个概率分布——这正是“分布” (distribution) 概念的起源。

EXAMPLE 1.9 (例 1.5.1). 抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$ 。定义 X 为正面出现的次数: $X(HH) = 2$, $X(HT) = X(TH) = 1$, $X(TT) = 0$ 。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。

6. 1.6 Discrete Random Variables

DEFINITION 1.10 (定义 1.6.1 (概率质量函数)). 设 X 为离散随机变量。函数 $p_X(x) = \mathbb{P}(X = x)$ 称为概率质量函数 (*probability mass function, pmf*)。

pmf 满足: $p_X(x) \geq 0$ 对所有 x , 且 $\sum_x p_X(x) = 1$ 。

伯努利分布 (Bernoulli): $X \sim \text{Bernoulli}(p)$, 取值 $\{0, 1\}$,

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

⁴反例见附录 ??。

二项分布 (Binomial): $X \sim \text{Bin}(n, p)$,

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

这是 n 次独立伯努利试验中成功的次数。

泊松分布 (Poisson): $X \sim \text{Poisson}(\lambda)$,

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

泊松分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限分布——这揭示了离散分布之间的深刻联系。⁵

7. 1.7 Continuous Random Variables

连续随机变量的取值充满一个或多个区间，不可数。

DEFINITION 1.11 (定义 1.7.1 (概率密度函数)). 设 X 为连续随机变量。若存在非负函数 $f_X(x)$ 使得

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x) dx$$

对任意 $a < b$ 成立，则称 $f_X(x)$ 为概率密度函数 (*probability density function, pdf*)。

pdf 满足: $f_X(x) \geq 0$ 对所有 x ，且 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。

Warning: $f_X(x)$ 可以大于 1! 这与 pmf 的 $p_X(x) \leq 1$ 形成对比。

正态分布 (Normal/Gaussian): $X \sim N(\mu, \sigma^2)$,

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad -\infty < x < \infty.$$

指数分布 (Exponential): $X \sim \text{Exp}(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $x > 0$ 。

8. 1.8 Expectation of a Random Variable

期望 (expected value) 是随机变量最重要的一致性度量。它描述了分布的“中心位置”。

DEFINITION 1.12 (定义 1.8.1 (数学期望)). 随机变量 X 的期望:

- 离散型: $\mathbb{E}X = \sum_x x \cdot p_X(x)$
- 连续型: $\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$

要求级数或积分绝对收敛。

EXAMPLE 1.10 (例 1.8.1). 设 X 为掷骰子的点数。则 $\mathbb{E}X = \frac{1}{6}(1+2+3+4+5+6) = 3.5$ 。

期望的线性性是概率论中最重要、最有用的性质之一。⁶

⁵详细推导见附录 ??。

⁶详细证明见附录 section 1.5。

THEOREM 1.4 (定理 1.8.1 (期望的线性性)). 对任意随机变量 X, Y 和常数 a, b :

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y.$$

关键点: 无需 X, Y 相互独立!

方差 (variance) 度量分布的离散程度。⁷

THEOREM 1.5 (定理 1.8.2 (方差公式)).

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2,$$

其中 $\mu = \mathbb{E}X$ 。

THEOREM 1.6 (定理 1.8.3 (方差的性质)). (1) $\text{var}(aX + b) = a^2 \text{var}(X)$

(2) 若 $X_1, \dots, X_n$ 相互独立, 则 $\text{var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{var}(X_i)$

9. 1.9 Some Special Expectations

两个随机变量之间的”共同变化”程度, 用协方差 (covariance) 来度量。

DEFINITION 1.13 (定义 1.9.1 (协方差)).

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y.$$

协方差的性质:

- (1) $\text{cov}(X, X) = \text{var}(X)$
- (2) $\text{cov}(X, Y) = \text{cov}(Y, X)$
- (3) $\text{cov}(aX + b, Y) = a\text{cov}(X, Y)$
- (4) $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y)$
- (5) 若 $X \perp\!\!\!\perp Y$, 则 $\text{cov}(X, Y) = 0$

相关系数 (correlation) 将协方差标准化, 消除了量纲的影响。

DEFINITION 1.14 (定义 1.9.2 (相关系数)).

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}.$$

$-1 \leq \text{corr}(X, Y) \leq 1$ 。相关系数衡量的是两个变量之间的线性关系强度。

10. 1.10 Important Inequalities

概率论中有几个基本不等式, 它们在理论证明和实际应用中都非常重要。

⁷详细推导见附录 ??。

THEOREM 1.7 (Markov 不等式). 若 X 为随机变量, $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}.$$

特别地, 取 $g(X) = X^2$, $a = k^2$, 得

$$\mathbb{P}(|X| \geq k) \leq \frac{\mathbb{E}[X^2]}{k^2}.$$

Markov 不等式的意义在于: 它仅用期望就能给出概率的上界, 而不需要知道分布的完整信息。⁸

THEOREM 1.8 (Chebyshev 不等式). 设 $\mu = \mathbb{E}X$, $\sigma^2 = \text{var}(X)$ 。则对任意 $k > 0$,

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}.$$

Chebyshev 不等式是 Markov 不等式的直接推论。它告诉我们: 无论分布是什么, 至少 $1 - 1/k^2$ 的概率质量落在 $\mu \pm k\sigma$ 区间内。

THEOREM 1.9 (Cauchy-Schwarz 不等式).

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}.$$

Cauchy-Schwarz 不等式在概率论中有着广泛的应用, 例如证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。

Summary

本章建立了概率论的基本框架:

- (1) **概率公理化**: 从相对频率的直观性质出发, 建立了概率的公理化定义
- (2) **条件概率与贝叶斯公式**: 提供了更新信息的数学工具
- (3) **独立性**: 刻画了两个事件之间的概率关系
- (4) **随机变量**: 从集合论过渡到数值函数, 为分布理论奠定基础
- (5) **期望与方差**: 分别度量分布的中心位置和离散程度
- (6) **协方差与相关系数**: 度量两个随机变量的联合变化趋势
- (7) **重要不等式**: Markov、Chebyshev、Cauchy-Schwarz

这些概念相互关联, 共同构成了数理统计的基石。理解它们之间的有机联系, 比单纯记忆公式更重要。

Exercises

EXERCISE 1.1. 1.2.1 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$:

- (1) $C_1 = \{0, 1, 2\}$, $C_2 = \{2, 3, 4\}$
- (2) $C_1 = \{x : 0 < x < 2\}$, $C_2 = \{x : 1 \leq x < 3\}$

EXERCISE 1.2. 1.3.1 设 $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.4$, $\mathbb{P}(A \cap B) = 0.1$ 。求:

⁸详细证明见附录 ??。

$$(1) \mathbb{P}(A \cup B)$$

$$(2) \mathbb{P}(A \mid B)$$

$$(3) \mathbb{P}(B \mid A)$$

EXERCISE 1.3. 1.4.1 某箱中有 5 个红球和 3 个白球。无放回地抽取 3 个球。求恰好抽到 2 个红球的概率。

EXERCISE 1.4. 1.5.1 设 $X \sim N(100, 225)$ 。求：

$$(1) \mathbb{P}(X < 95)$$

$$(2) \mathbb{P}(90 < X < 110)$$

CHAPTER 2

多元随机变量及其分布

Chapter 2 概述

本章路线图：联合分布 $\rightarrow$ 边缘分布 $\rightarrow$ 条件分布 $\rightarrow$ 独立性 $\rightarrow$ 相关性 $\rightarrow$ 多元正态

1. 2.1 从一元到多元：为什么需要联合分布？

在一元情形，我们用 cdf $F_X(x) = \mathbb{P}(X \leq x)$ 描述单个随机变量的行为。但在许多场景中，单个变量的分布并不能回答我们的问题——我们需要知道多个变量如何共同变化。

核心问题：给定两个随机变量 X_1 和 X_2 ，如何描述它们的联合行为？

这促使我们建立联合分布理论。本章以二元情形为主，揭示多元分布的核心思想。

1.1. 随机向量与联合分布.

DEFINITION 2.1 (随机向量). 设样本空间为 $\mathcal{C}$ ， X_1 和 X_2 为定义在 $\mathcal{C}$ 上的两个随机变量。则 (X_1, X_2) 称为随机向量，其取值空间为 $\mathcal{D} = \{(x_1, x_2) : x_1 = X_1(c), x_2 = X_2(c), c \in \mathcal{C}\}$ 。

联合 cdf 是一元 cdf 的自然推广：

$$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2). \quad (1)$$

离散型用 pmf 描述：

$$p_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 = x_1, X_2 = x_2), \quad (2)$$

满足 $p \geq 0$ 且 $\sum \sum_{\mathcal{D}} p = 1$ 。

连续型用 pdf 描述：

$$F_{X_1, X_2}(x_1, x_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f(w_1, w_2) dw_1 dw_2, \quad (3)$$

其中 $f \geq 0$ 且 $\int \int_{\mathcal{D}} f = 1$ 。

emark Warning: 与一元情形不同，这里的 $f(x_1, x_2)$ 可以大于 1！因为它是“密度”而非概率值。emark

几何直观：若把联合 pdf $z = f(x_1, x_2)$ 视作一张曲面，则 $\mathbb{P}((X_1, X_2) \in A)$ 就是该曲面下区域 A 上的体积。这是一元情形“曲线下面积”在二维的推广。

1.2. 边缘分布：积分即求和。核心问题：已知 (X_1, X_2) 的联合分布，如何得到单个 X_1 的分布？

直觉上，我们需要”忽略” X_2 的信息。具体做法是：

- **离散型：**对 x_2 求和
- **连续型：**对 x_2 积分

这引导我们得到边缘分布公式。¹

边缘 pmf:

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2). \quad (4)$$

边缘 pdf:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2. \quad (5)$$

emark **为什么叫”边缘”？** 在二维离散情形，将联合 pmf 列表，边缘分布恰好是每行（或每列）的”边缘”之和。这解释了名称的由来。emark

1.3. 期望的推广与线性性。 设 $Y = g(X_1, X_2)$ 是新的随机变量，其期望为

$$\mathbb{E}Y = \int \int g(x_1, x_2) f(x_1, x_2) dx_1 dx_2 \quad (\text{连续型}).$$

关键发现：期望算子 E 对加法保持线性，无论 X_1, X_2 是否独立。²

$$\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2. \quad (6)$$

这为什么重要？ 在第 1 章我们学过独立随机变量之和的方差公式 $\text{var}(X_1 + X_2) = \text{var}(X_1) + \text{var}(X_2)$ 。期望的线性性是其基础——它无需独立性即可成立。

2. 2.2 变换：寻找新视角

给定 (X_1, X_2) 的分布，我们经常想研究其函数 $Y = u(X_1, X_2)$ 的分布。例如：

- 和 $Y = X_1 + X_2$ （两个随机变量之和）
- 商 $Y = X_1/X_2$ （比值）
- 极坐标变换 $(R, \Theta) = (\sqrt{X_1^2 + X_2^2}, \arctan(X_2/X_1))$

对于连续型，一一对应的变换有简洁的公式。³

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|. \quad (7)$$

其中 Jacobian 行列式

$$J = \det \begin{pmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{pmatrix} = \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1}. \quad (8)$$

¹推导见附录 section 1.4。

²推导见附录 section 1.5。

³推导见附录 section 1.6。

为什么有 $|J|$? 这是面积元素的变换因子。在一元情形我们有 $f_Y(y) = f_X(h(y))|h'(y)|$; 二维情形类似, 只是用行列式度量了面积缩放比例。

3. 2.3 条件分布：信息的价值

核心问题：已知 X_1 的值, X_2 的分布会如何变化?

这就是条件分布要回答的问题。条件分布本质上是在 $X_1 = x_1$ 的条件下, 重新审视 X_2 的行为。

离散型条件 pmf: ⁴

$$p_{X_2|X_1}(x_2 | x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}, \quad p_{X_1}(x_1) > 0. \quad (9)$$

连续型条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}, \quad f_{X_1}(x_1) > 0. \quad (10)$$

分子是联合密度, 分母是边缘密度。这个比值衡量的是, 在 $X_1 = x_1$ 的条件下, (x_1, x_2) 这个“点”有多“典型”。

由此定义条件期望:

$$\mathbb{E}[u(X_2) | x_1] = \int_{-\infty}^{\infty} u(x_2) f_{X_2|X_1}(x_2 | x_1) dx_2. \quad (11)$$

3.1. 全期望公式与 Rao-Blackwell 定理。 这里有一个深刻的定理, 它连接了条件与边缘。⁵

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2). \quad (12)$$

这称为**全期望公式**。它的含义是: 对条件均值再取期望, 等于无条件期望。

更惊人的是方差的不等式:⁶

$$\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2).$$

Rao-Blackwell 定理: 若用 X_2 估计 $\mu_2 = \mathbb{E}X_2$, 则条件均值 $E(X_2 | x_1)$ 比 X_2 本身更精确 (方差更小)。这在统计推断中极其重要——它告诉我们如何利用辅助信息改进估计。

⁴推导见附录 section 1.7。

⁵推导见附录 section 1.8。

⁶推导见附录 section 1.9。

4. 2.4 独立性：变量间的”无关系”

核心问题：什么时候 X_1 和 X_2 互不影响？

若 X_1 与 X_2 独立，则知道 X_1 的值不会改变我们对 X_2 的认知。用条件分布的语言：

$$f_{X_2|X_1}(x_2 | x_1) = f_{X_2}(x_2) \quad (\text{不依赖于 } x_1) .$$

由此推出联合密度可分离。⁷

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv f_1(x_1)f_2(x_2). \quad (13)$$

一个实用的判据：

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv g(x_1)h(x_2) \quad (\text{可分离变量}) . \quad (14)$$

独立性的后果：

- $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$
- $\text{cov}(X_1, X_2) = 0$

emark **逆命题不成立！** $\text{cov}(X_1, X_2) = 0$ 并不意味着独立性（除二元正态分布外）。
emark

这提醒我们：**不相关**（uncorrelated）和**独立**（independent）是两个不同概念。不相关只说明没有线性关系，但变量间可能存在非线性依赖。

5. 2.5 相关性：线性关联的度量

我们已经知道 $\text{cov}(X_1, X_2) = 0$ 不能完全刻画独立性。那么如何量化 X_1 与 X_2 之间的”关联程度”？

协方差 $\text{cov}(X_1, X_2)$ 存在一个问题：它依赖于 X_1, X_2 的量纲。例如，身高（cm）和体重（kg）的协方差与换算成英寸和磅时不同。

解决方案：先标准化，再求协方差：

$$\rho_{12} = \text{corr}(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)}\sqrt{\text{var}(X_2)}} = \frac{\text{cov}(X_1, X_2)}{\sigma_1\sigma_2}. \quad (15)$$

这就是相关系数（correlation coefficient）。

核心性质：⁸

- $-1 \leq \rho_{12} \leq 1$
- $|\rho_{12}| = 1 \iff X_2 = aX_1 + b$ （完美线性关系）
- $\rho_{12} = 0$ 称**不相关**

⁷推导见附录 section 1.10。

⁸推导见附录 section 1.11。

为什么是 $[-1, 1]$? 这来自 Cauchy-Schwarz 不等式:

$$|\text{cov}(X_1, X_2)| = |\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]| \leq \sqrt{\mathbb{E}[(X_1 - \mu_1)^2] \cdot \mathbb{E}[(X_2 - \mu_2)^2]} = \sigma_1 \sigma_2.$$

emark **相关 vs 协方差**: 协方差取决于量纲 (“米的协方差” vs “厘米的协方差” 数值不同); 相关系数是无量纲的, 消除了单位影响。因此, 相关系数是更通用的 “关联程度” 度量。emark

6. 2.6 二元正态：最重要的二元分布

在所有二元分布中, 二元正态分布占据核心地位。它是一元正态分布在二维的自然推广。

为什么重要?

- (1) 边缘分布和条件分布都是正态的
- (2) 线性组合仍是正态
- (3) 不相关 $\iff$ 独立 (这是正态独有的优雅性质)
- (4) 多元正态是计量经济学、信号处理等领域的基石

DEFINITION 2.2 (二元正态分布). (X_1, X_2) 服从二元正态分布, 若其联合 pdf 为

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\},$$

记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

五个参数的含义:

- μ_1, μ_2 : 边缘分布的均值
- σ_1^2, σ_2^2 : 边缘分布的方差
- ρ : 相关系数

emark **条件分布的几何直觉**: 在二元正态中, 条件均值

$$\mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1)$$

是 x_1 的线性函数。这意味着: 给定 $X_1 = x_1$, X_2 的最佳预测也是线性的, 其斜率由相关系数 ρ 决定。emark

关键性质:

- (1) 边缘分布: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) 条件分布: ⁹

$$X_2 | X_1 = x_1 \sim N \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2 (1 - \rho^2) \right)$$

- (3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ (正态独有的 “不相关 $\Rightarrow$ 独立”)
- (4) 任意线性组合 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, \text{var}(aX_1 + bX_2))$

⁹推导见附录 section 1.12。

7. 2.7 多元推广

前述概念可以推广到 n 个随机变量。记随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ ，其联合 cdf 为

$$F_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

7.1. 边缘与条件分布. 边缘 pdf 通过 $n-1$ 重积分得到：

$$f_1(x_1) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, x_2, \dots, x_n) dx_2 \cdots dx_n.$$

条件分布定义为联合密度与边缘密度之比：

$$f_{2,\dots,n|1}(x_2, \dots, x_n | x_1) = \frac{f(x_1, x_2, \dots, x_n)}{f_1(x_1)}.$$

7.2. 多元独立性. n 个随机变量 $X_1, \dots, X_n$ 相互独立，当且仅当

$$f(x_1, x_2, \dots, x_n) \equiv f_1(x_1)f_2(x_2) \cdots f_n(x_n).$$

注意：两两独立 (pairwise independence) 不一定推出相互独立 (mutual independence)。Bernstein 的例子说明了这一点。

7.3. 线性组合的 mgf. 若 $X_1, \dots, X_n$ 相互独立， $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为

$$M_T(t) = \prod_{i=1}^n M_i(k_i t).$$

10

特别地，若 $X_1, \dots, X_n$ iid (独立同分布)，则 $T = \sum_{i=1}^n X_i$ 的 mgf 为

$$M_T(t) = [M(t)]^n.$$

8. 本章总结

概念	公式/描述
联合 cdf	$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2)$
边缘 pmf	$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2)$
边缘 pdf	$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2) dx_2$
条件 pmf	$p_{X_2 X_1}(x_2 x_1) = p(x_1, x_2)/p_{X_1}(x_1)$
条件 pdf	$f_{X_2 X_1}(x_2 x_1) = f(x_1, x_2)/f_{X_1}(x_1)$
全期望	$\mathbb{E}[\mathbb{E}(X_2 X_1)] = \mathbb{E}X_2$
独立性	$f(x_1, x_2) = f_1(x_1)f_2(x_2)$
协方差	$\text{cov} = \mathbb{E}(X_1 X_2) - \mathbb{E}X_1 \mathbb{E}X_2$
相关系数	$\rho = \text{cov}/(\sigma_1 \sigma_2), -1 \leq \rho \leq 1$

¹⁰推导见附录 section 1.13。

习题

EXERCISE 2.1. 2.1.1 设 X_1 和 X_2 的联合 pdf 为 $f(x_1, x_2) = x_1 + x_2$, $0 < x_1 < 1$, $0 < x_2 < 1$, 其他位置为零。求 X_1 的边缘 pdf。

EXERCISE 2.2. 2.2.1 设 (X_1, X_2) 的联合 pdf 为 $f(x_1, x_2) = 2$, $0 < x_1 < x_2 < 1$, 其他位置为零。求 $Y = X_1 + X_2$ 的分布。

EXERCISE 2.3. 2.3.1 设 X_1 和 X_2 具有联合 pdf $f(x_1, x_2) = x_1 + x_2$, $0 < x_1 < 1$, $0 < x_2 < 1$ 。求给定 $X_1 = x_1$ 时 X_2 的条件均值和条件方差。

EXERCISE 2.4. 2.4.1 证明：若 X_1 和 X_2 独立，则 $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$ 。

EXERCISE 2.5. 2.5.1 设 (X, Y) 具有联合 pdf $f(x, y) = x + y$, $0 < x < 1$, $0 < y < 1$ 。求相关系数 ρ 。

EXERCISE 2.6. 2.6.1 设 X_1, X_2, X_3 为三个独立同分布的随机变量，每个的 pdf 为 $f(x) = 2x$, $0 < x < 1$ 。求 $Y = \max\{X_1, X_2, X_3\}$ 的分布。

CHAPTER 3

Special Distributions

Chapter 3 Overview

In Chapters 1 and 2, we established the mathematical framework for describing single and multiple random variables. Now we ask: **Which distributions deserve our special attention?**

Statistics matters because certain probability distributions appear repeatedly in nature and experimental data. Mastering these distributions is like learning the basic vocabulary of a language—they form the foundation for further study.

Chapter Roadmap: Bernoulli $\rightarrow$ Binomial $\rightarrow$ Poisson $\rightarrow$ Gamma/Chi-square/Beta $\rightarrow$ Normal $\rightarrow$ Multivariate Normal $\rightarrow t$ and F Distributions

1. 3.1 From Bernoulli to Binomial: The Science of Counting

1.1. Why Do We Need the Binomial Distribution? When we repeat an independent experiment, the most natural question is: **How many successes?** How many heads appear in 10 coin tosses? How many defective items among 1000 products? This “counting problem” pervades statistics.

1.2. Bernoulli Trials. A **Bernoulli trial** is the simplest random experiment: the outcome is one of two mutually exclusive and complementary possibilities—success or failure.

Let the random variable X denote the outcome:

$$X(\text{success}) = 1, \quad X(\text{failure}) = 0.$$

Its pmf is

$$p(x) = p^x(1-p)^{1-x}, \quad x = 0, 1. \tag{16}$$

Mean and variance:

$$\mathbb{E}X = p, \quad \text{var}(X) = p(1-p).$$

Why is the Bernoulli distribution so fundamental? It is the simplest non-trivial random variable—neither a deterministic constant nor a uniform distribution. It captures the essential nature of “yes/no” decision uncertainty.

1.3. The Binomial Distribution. Now we ask: **What is the distribution of the number of successes in n independent Bernoulli trials?**

Let X_i be the Bernoulli variable for trial i , and we are interested in $X = \sum_{i=1}^n X_i$.

To have x successes means we choose x positions out of n for the successes, with the remaining positions being failures. The number of such arrangements is $\binom{n}{x}$, and each arrangement has probability $p^x(1-p)^{n-x}$.

$$p(x) = \binom{n}{x} p^x (1-p)^{n-x}, \quad x = 0, 1, \dots, n. \quad (17)$$

We write $X \sim \text{Bin}(n, p)$.

EXAMPLE 3.1 (Dice Problem). *Rolling a fair six-sided die 3 times, what is the probability of getting exactly 2 sixes?*

Solution: Let X be the number of sixes, so $X \sim \text{Bin}(n = 3, p = 1/6)$,

$$\mathbb{P}(X = 2) = \binom{3}{2} \left(\frac{1}{6}\right)^2 \left(\frac{5}{6}\right)^1 = 0.06944.$$

Moment generating function:

$$M(t) = [(1-p) + pe^t]^n.$$

Mean and variance:

$$\mathbb{E}X = np, \quad \text{var}(X) = np(1-p).$$

heorem[Additivity of Binomial Distributions] If $X_1 \sim \text{Bin}(n_1, p)$ and $X_2 \sim \text{Bin}(n_2, p)$ are independent, then $X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p)$. **heorem**

This means: two binomial experiments can be combined into one larger binomial experiment.

emark **Intuitive understanding:** Imagine two independent piles of coin flips: the first pile of n_1 coins yields X_1 heads, the second pile of n_2 coins yields X_2 heads. Combined, we have $n_1 + n_2$ coins with total heads $X_1 + X_2$. **emark**

1.4. Negative Binomial and Geometric Distributions. Central question: If we do not count the number of successes, but rather **the number of trials needed to achieve the r -th success**, what is the distribution?

Let Y be the number of failures before the r -th success. Then the total number of trials is $Y + r$.

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots \quad (18)$$

This is called the **negative binomial distribution**.

When $r = 1$, we obtain the **geometric distribution**:

$$p_Y(y) = p(1-p)^y, \quad y = 0, 1, 2, \dots \quad (19)$$

The geometric distribution possesses a unique **memorylessness property**:

$$\mathbb{P}(Y \geq k + j \mid Y \geq k) = \mathbb{P}(Y \geq j).$$

What does this mean? If you have already failed k times, the remaining waiting time for the first success is exactly the same as it was at the beginning. Past failures do not change future expectations.

1.5. The Multinomial Distribution. The binomial generalizes to k categories: each trial results in exactly one of k mutually exclusive categories.

Let X_i be the count of category i occurrences. Then $(X_1, \dots, X_k)$ follows a **multinomial distribution** with parameters n and $p_1, \dots, p_k$:

$$\mathbb{P}(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k}. \quad (20)$$

1.6. The Hypergeometric Distribution. Central question: What is the distribution of successes when sampling **without replacement**?

In a batch of N items with D defectives, we draw n items (without replacement), and X is the number of defectives:

$$p(x) = \frac{\binom{N-D}{n-x} \binom{D}{x}}{\binom{N}{n}}, \quad x = 0, 1, \dots, n. \quad (21)$$

Mean and variance:

$$\mathbb{E}X = n \frac{D}{N}, \quad \text{var}(X) = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

The final factor $\frac{N-n}{N-1}$ is the **finite population correction factor**. When $N \gg n$, it approaches 1, and the hypergeometric distribution approximates the binomial.

2. 3.2 The Poisson Distribution: The World of Rare Events

2.1. Why Is the Poisson Distribution Important? In nature and society, there exists a special class of phenomena: **the number of events occurring in a fixed time/space interval**—such as customers arriving at a bank per hour, printing errors per page, earthquakes per year.

These phenomena share a common feature: **the probability of occurrence is small, but the number of trials is large**. The limiting form of the binomial distribution is precisely the Poisson distribution.

2.2. Definition of the Poisson Distribution.

$$p(x) = \frac{\lambda^x e^{-\lambda}}{x!}, \quad x = 0, 1, 2, \dots \quad (22)$$

Here $\lambda > 0$ is the parameter. We write $X \sim \text{Poisson}(\lambda)$.

Verification: Because $e^\lambda = \sum_{x=0}^{\infty} \frac{\lambda^x}{x!}$,

$$\sum_{x=0}^{\infty} p(x) = e^{-\lambda} \sum_{x=0}^{\infty} \frac{\lambda^x}{x!} = e^{-\lambda} \cdot e^\lambda = 1.$$

Mean and variance:

$$\mathbb{E}X = \lambda, \quad \text{var}(X) = \lambda.$$

Here is a surprising property: Mean and variance are equal! This is a hallmark feature of the Poisson distribution.

heorem[Poisson Approximation] If $X_n \sim \text{Bin}(n, p_n)$ and $np_n \rightarrow \lambda$, then $X_n \xrightarrow{d} \text{Poisson}(\lambda)$. **heorem**

Intuitive understanding: When n is large and p is small, the binomial distribution behaves almost identically to the Poisson distribution. In practice, the Poisson approximation is often used to simplify calculations.

emark The Poisson distribution was introduced by Siméon Denis Poisson in 1837, originally for analyzing data on French court judgments—the probability that a judge makes a certain number of rulings in a given time period. **emark**

3. 3.3 The Gamma, χ^2 , and Beta Distributions

These three distributions form the backbone of continuous statistical inference. Understanding their relationships 掌握了它们的关系，就理解了半参数推断的数学基础。

3.1. The Gamma Function. Why do we start with the gamma function?

Because it serves as a bridge between factorials and integrals—this is one of the most beautiful identities in mathematics.

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx, \quad \alpha > 0.$$

Key property: $\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$, and for positive integers n , $\Gamma(n) = (n-1)!$.

3.2. The Gamma Distribution.

DEFINITION 3.1 (Gamma Distribution). A continuous random variable X has a gamma distribution with parameters $\alpha > 0$ and $\beta > 0$ if its pdf is

$$f(x) = \begin{cases} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} & x > 0 \\ 0 & \text{elsewhere,} \end{cases}$$

We write $X \sim \Gamma(\alpha, \beta)$.

Meaning of the parameters:

- α : shape parameter, controlling the distribution's shape
- β : scale parameter, controlling the spread

Mean and variance:

$$\mathbb{E}X = \alpha\beta, \quad \text{var}(X) = \alpha\beta^2.$$

Two important special cases:

- $\Gamma(1, \beta) = \text{Exp}(1/\beta)$ (exponential distribution)
- $\Gamma(n/2, 2) = \chi^2$ -distribution

emark If $X_1 \sim \Gamma(\alpha_1, \beta)$ and $X_2 \sim \Gamma(\alpha_2, \beta)$ are independent, then $X_1 + X_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$. emark

The moment generating function of a gamma distribution is $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$.¹

3.3. The χ^2 Distribution. Central question: If we square multiple standard normal random variables and sum them, what is the distribution of this new variable?

DEFINITION 3.2 (Chi-Square Distribution). Let $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ be iid. Then

$$X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n).$$

The χ^2 distribution is a special case of $\Gamma(n/2, 2)$.

Mean and variance:

$$\mathbb{E}X = n, \quad \text{var}(X) = 2n.$$

Additivity: If $X_1 \sim \chi^2(m)$ and $X_2 \sim \chi^2(n)$ are independent, then $X_1 + X_2 \sim \chi^2(m + n)$.

Why is it important? The sampling distribution of the sample variance is closely connected to the χ^2 distribution—making it a central tool for variance estimation and hypothesis testing.

3.4. The Beta Distribution. Similar to the gamma, the beta distribution is a continuous distribution defined on the $(0, 1)$ interval, particularly useful for modeling probabilities.

DEFINITION 3.3 (Beta Distribution). If X has pdf

$$f(x) = \begin{cases} \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} & 0 < x < 1 \\ 0 & \text{elsewhere,} \end{cases}$$

where $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$, then $X \sim \text{Beta}(\alpha, \beta)$.

¹推导见附录 section 1.1.

Mean and variance:

$$\mathbb{E}X = \frac{\alpha}{\alpha + \beta}, \quad \text{var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

Special case: $\text{Beta}(1, 1) = \text{Uniform}(0, 1)$.

Bayesian perspective: In Bayesian statistics, when we use a beta distribution as the prior for a binomial distribution's parameter p , the posterior distribution remains beta—this is called a **conjugate prior**.

4. 3.4 The Normal Distribution: Queen of Statistics

Among all probability distributions, the **normal distribution** holds a paramount position. It forms the cornerstone of statistical inference, econometrics, signal processing, and many other fields.

Why is the normal distribution so special? There are three reasons:

- (1) **Central Limit Theorem:** Sums of many independent small factors approximate a normal distribution
- (2) **Mathematical elegance:** Linear combinations of normal variables remain normal
- (3) **Interpretable parameters:** Both mean and variance have intuitive meanings

DEFINITION 3.4 (Normal Distribution). *If X has pdf*

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(x - \mu)^2}{2\sigma^2}\right\}, \quad -\infty < x < \infty,$$

then X follows a normal distribution, written $X \sim N(\mu, \sigma^2)$.

In particular, $N(0, 1)$ is called the **standard normal distribution**, with pdf denoted $\phi(z)$ and cdf denoted $\Phi(z)$.

Standardization: If $X \sim N(\mu, \sigma^2)$, then $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$.

This allows any normal probability calculation to be transformed into a standard normal calculation:

$$\mathbb{P}(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right).$$

EXAMPLE 3.2 (Normal Probability Calculation). *Let $X \sim N(100, 225)$ (i.e., $\sigma = 15$), find $\mathbb{P}(X < 85)$.*

Solution: $Z = \frac{85 - 100}{15} = -1$, so $\mathbb{P}(X < 85) = \Phi(-1) \approx 0.1587$.

theorem[Linear Combinations of Normal Variables] If $X_1 \sim N(\mu_1, \sigma_1^2)$ and $X_2 \sim N(\mu_2, \sigma_2^2)$ are independent, then for any constants a, b ,

$$aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2).$$

theorem

Why is this property important? It means the normal distribution is closed under linear transformations—making the normal distribution the theoretical foundation of linear models.

emark The normal distribution was introduced by Carl Friedrich Gauss in 1809 when studying measurement errors. Although Laplace had discussed error distributions earlier, Gauss’s work cemented the normal distribution’s central role in statistics. This explains why the normal distribution is often called the “Gaussian distribution”. emark

5. 3.5 Multivariate Normal Distribution

The natural extension of the normal distribution to higher dimensions.

5.1. Bivariate Normal Distribution.

DEFINITION 3.5 (Bivariate Normal Distribution). *If (X_1, X_2) has joint pdf*

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{Q(x_1, x_2)}{2(1-\rho^2)} \right\},$$

where $Q = \frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}$, then (X_1, X_2) follows a bivariate normal distribution, written $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$.

Meaning of the five parameters:

- μ_1, μ_2 : means of the marginal distributions
- σ_1^2, σ_2^2 : variances of the marginal distributions
- ρ : correlation coefficient

heorem[Properties of the Bivariate Normal] If $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, then:

- (1) Marginal distributions: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) Conditional distribution: $X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right)$
- (3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ (uniqueness to normals: uncorrelated implies independent)
- (4) Any linear combination $aX_1 + bX_2$ follows a normal distribution

heorem

Key insight: The conditional mean is a linear function of x_1 . This means that given one variable, the best prediction for the other is also linear.

6. 3.6 The t and F Distributions

These two distributions originated from a practical question: **How do we make inferences when the population variance is unknown?**

6.1. The t Distribution.

DEFINITION 3.6 (t Distribution). *If $Z \sim N(0, 1)$ and $X \sim \chi^2(n)$ are independent, then*

$$T = \frac{Z}{\sqrt{X/n}} \sim t(n).$$

Mean and variance:

$$\mathbb{E}T = 0 \ (n > 1), \quad \text{var}(T) = \frac{n}{n-2} \ (n > 2).$$

Relationship to normal: As $n \rightarrow \infty$, $t(n) \xrightarrow{d} N(0, 1)$.

Intuitive understanding: The numerator Z is standard normal, while the denominator $\sqrt{X/n}$ estimates the standard deviation of Z . When n is small, this estimate is very unstable, so the t distribution has heavier tails than the normal. When $n = 1$, we obtain the Cauchy distribution—a “dangerous” distribution with no mean.

EXAMPLE 3.3 (t Distribution Application). *Let $T \sim t(10)$, find $\mathbb{P}(|T| > 2.228)$.*

From tables, $t_{0.025,10} = 2.228$, so $\mathbb{P}(|T| > 2.228) = 0.05$.

6.2. The F Distribution.

DEFINITION 3.7 (F Distribution). *If $X_1 \sim \chi^2(m)$ and $X_2 \sim \chi^2(n)$ are independent, then*

$$F = \frac{X_1/m}{X_2/n} \sim F(m, n).$$

Mean and variance:

$$\mathbb{E}F = \frac{n}{n-2} \ (n > 2), \quad \text{var}(F) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)} \ (n > 4).$$

Reciprocal property: If $F \sim F(m, n)$, then $1/F \sim F(n, m)$.

Why is it important? The F distribution is central to ANOVA (analysis of variance) and regression analysis—we use it to compare whether two variances are equal.

Distribution	Parameters	Notation
Binomial	Trials n , prob. p	$\text{Bin}(n, p)$
Poisson	Rate λ	$\text{Poisson}(\lambda)$
Gamma	Shape α , scale β	$\Gamma(\alpha, \beta)$
Chi-square	Degrees of freedom n	$\chi^2(n)$
Beta	Shapes α, β	$\text{Beta}(\alpha, \beta)$
Normal	Mean μ , var. σ^2	$N(\mu, \sigma^2)$
t	Degrees of freedom n	$t(n)$
F	D.F. m, n	$F(m, n)$

Chapter Summary

This chapter introduced the most important families of distributions in statistics:

Discrete: Bernoulli $\rightarrow$ Binomial $\rightarrow$ Negative Binomial/Geometric $\rightarrow$ Poisson $\rightarrow$ Multinomial/Hypergeometric

Continuous: Uniform $\rightarrow$ Exponential $\rightarrow$ Gamma $\rightarrow$ Chi-square $\rightarrow$ Beta $\rightarrow$ Normal $\rightarrow t/F$

Key relationships:

- $\text{Bin}(n, p) \xrightarrow{n \rightarrow \infty, p \rightarrow 0} \text{Poisson}(\lambda)$
- $\Gamma(n/2, 2) = \chi^2(n)$
- $t(n) \xrightarrow{n \rightarrow \infty} N(0, 1)$
- If $F \sim F(m, n)$, then $1/F \sim F(n, m)$

EXERCISE 3.1. 3.1 Let X be the number of successes in n independent Bernoulli trials with success probability p . Show that the moment generating function of X is $M(t) = [(1 - p) + pe^t]^n$.

EXERCISE 3.2. 3.2 Suppose $X \sim \text{Poisson}(\lambda)$. Show that $\mathbb{E}X = \lambda$ and $\text{var}(X) = \lambda$.

EXERCISE 3.3. 3.3 Let $X \sim \Gamma(\alpha, \beta)$. Show that $\mathbb{E}X = \alpha\beta$ and $\text{var}(X) = \alpha\beta^2$.²

EXERCISE 3.4. 3.4 If $Z_1, Z_2, \dots, Z_n$ are iid $N(0, 1)$, show that $Y = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$.

EXERCISE 3.5. 3.5 Let $X \sim N(\mu, \sigma^2)$. Show that the standardized variable $Z = (X - \mu)/\sigma \sim N(0, 1)$.

EXERCISE 3.6. 3.6 If $X_1 \sim N(\mu_1, \sigma_1^2)$ and $X_2 \sim N(\mu_2, \sigma_2^2)$ are independent, show that $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

EXERCISE 3.7. 3.7 Let $X \sim \text{Beta}(\alpha, \beta)$. Show that $\mathbb{E}X = \frac{\alpha}{\alpha + \beta}$.

EXERCISE 3.8. 3.8 If $X \sim \chi^2(n)$, show that $E(X^k) = \frac{2^k \Gamma(\frac{n}{2} + k)}{\Gamma(\frac{n}{2})}$ for $k > -n/2$.

²推导见附录 section 1.2.

CHAPTER 4

Some Elementary Statistical Inferences

Chapter 4 Overview

在前三章中，我们建立了描述随机变量和概率分布的理论框架。现在我们面临一个根本性问题：

给定观测数据，如何推断产生这些数据的底层分布？

这个问题——从已知数据推断未知规律——正是统计学的核心任务。正如 Fisher 在 1922 年的经典论文中所强调的，统计推断的本质是在不确定性下做出明智决策。

本章介绍三种主要的推断工具：

- **点估计** (Point Estimation)：用单一数值估计未知参数
- **置信区间** (Confidence Intervals)：参数的合理取值范围，而非点估计的单一数值
- **假设检验** (Hypothesis Testing)：评估关于总体的声明是否获得数据支持

这三种工具相互关联：点估计给出参数的最佳猜测，置信区间度量这个猜测的精度，而假设检验则让我们能够验证关于总体的具体声明。

本章路线图：抽样与统计量 → 点估计 (MLE) → 置信区间 → 假设检验 → 卡方检验 → 蒙特卡洛 → Bootstrap

1. 4.1 Sampling and Statistics

1.1. 从总体到样本。在典型的统计问题中，我们关心某个随机变量 X ，但其 pdf $f(x)$ 或 pmf $p(x)$ 未知。这种未知性可以分为两类：

- (1) $f(x)$ 或 $p(x)$ 的形式完全未知
- (2) 分布的形式已知，但包含未知参数 θ (θ 可以是向量)

本章聚焦第二类——这正是统计学中最常见的场景。我们已知数据的分布类型，只是不知道具体的参数值。几个典型例子：

- (a) $X \sim \text{Exp}(\theta)$, θ 未知——指数分布常用于描述等待时间
- (b) $X \sim \text{Binomial}(n, p)$, p 未知——二项分布描述 n 次试验中的成功次数
- (c) $X \sim \Gamma(\alpha, \beta)$, α 和 β 均未知——Gamma 分布广泛出现于保险和排队论
- (d) $X \sim N(\mu, \sigma^2)$, μ 和 σ^2 均未知——正态分布是统计学的核心

我们用 $f(x; \theta)$ 或 $p(x; \theta)$ 表示含参分布，其中 $\theta \in \Omega$, Ω 是参数空间（所有可能的 θ 组成的集合）。

1.2. 随机样本. 为什么要强调“随机”抽取? 因为只有随机抽样才能保证样本具有代表性——每个个体被选中的概率相等, 这样样本才能“代表”总体。

从总体中抽取样本, 样本观测值与 X 同分布。记为随机变量 $X_1, X_2, \dots, X_n$, 其中 n 是样本量。抽到具体数值后记为 $x_1, x_2, \dots, x_n$ 。

若 $X_1, \dots, X_n$ 相互独立且同分布, 则称它们为来自该共同分布的**随机样本 (random sample)**。

DEFINITION 4.1 (随机样本). 如果随机变量 $X_1, X_2, \dots, X_n$ 独立同分布 (*iid*), 则称这些随机变量构成来自该共同分布的容量为 n 的随机样本。

从这个定义出发, 样本的联合 pdf/pmf 为

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

这正是后续推导似然函数的基础。

1.3. 统计量. 我们已经学会了如何描述单个随机变量, 现在面临一个新问题: **如何从样本中提取信息?**

设 $T = T(X_1, X_2, \dots, X_n)$ 是样本的函数。则称 T 为一个**统计量 (statistic)**。

统计量的关键特征在于: **不依赖任何未知参数**。换言之, 统计量只基于观测数据进行计算, 不涉及任何未知数。一旦样本被观测, $t = T(x_1, \dots, x_n)$ 称为 T 的实现值。

2. 4.2 Point Estimation

点估计提供一个单一数值 (记作 $\hat{\theta}$) 作为未知参数 θ 的估计。但这里立刻产生一个问题: 如何找到“好”的估计量?

2.1. 无偏性. 我们希望估计量具有什么性质? 最基本的要求是无偏性——如果反复抽样, 估计量的平均值应该等于真实参数值。

DEFINITION 4.2 (无偏估计量). 设 $X_1, \dots, X_n$ 是来自分布 $f(x; \theta)$ 的样本, $\theta \in \Omega$ 。设 $T = T(X_1, \dots, X_n)$ 是统计量。若

$$\mathbb{E}(T) = \theta,$$

则称 T 是 θ 的**无偏估计量 (unbiased estimator)**。

若 $\mathbb{E}(T) \neq \theta$, 则称 $\text{Bias}(T) = \mathbb{E}(T) - \theta$ 为偏差。无偏性保证估计量没有系统性偏差——既不高估也不低估。

注意: 无偏性并不保证估计量“最好”。例如, 样本方差 S^2 是无偏的, 但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题: 能否找到一个统一的、“最优”的估计原则?

2.2. 最大似然估计 (MLE). 为什么需要似然函数? 样本来自参数 θ 的分布 $f(x; \theta)$ 。给定 θ 时, 观察到当前数据 $\mathbf{x} = (x_1, \dots, x_n)$ 的概率 (密度) 为 $f(\mathbf{x}; \theta)$ 。似然函数正是这个想法的数学表达——它衡量在给定 θ 时, 观察到当前数据的”可能性”。

DEFINITION 4.3 (似然函数). 设 $X_1, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本。则

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

称为该随机样本的**似然函数 (likelihood function)**。

核心思想: 如果 θ 是真实参数, 那么它应该使得观察到的数据具有较高的”可能性”。因此, 我们选择使 $L(\theta)$ 最大化的 $\hat{\theta}$ ——这正是最大似然估计量的定义。

最大似然估计量 (MLE):

$$\hat{\theta} = \underset{\theta}{\operatorname{argmax}} L(\theta). \quad (4.2.1)$$

在实际计算中, 通常使用对数似然 $l(\theta) = \log L(\theta)$, 因为 $\log$ 是严格递增函数, 最大化 $l(\theta)$ 等价于最大化 $L(\theta)$ 。在正则条件下, $\hat{\theta}$ 满足

$$\frac{\partial l(\theta)}{\partial \theta} = 0. \quad (4.2.2)$$

这个方程称为**似然方程 (score equation)**。¹

EXAMPLE 4.1 (指数分布的 MLE). 设 $X_1, \dots, X_n \sim \operatorname{Exp}(\theta)$, pdf 为 $f(x) = \theta^{-1} \exp\{-x/\theta\}$, $x > 0$ 。

对数似然为

$$l(\theta) = -n \log \theta - \frac{1}{\theta} \sum_{i=1}^n x_i.$$

令导数为零, 解得 $\hat{\theta} = \bar{x}$ 。由于 $\mathbb{E}(X) = \theta$, 故 $\hat{\theta} = \bar{X}$ 也是无偏估计。²

EXAMPLE 4.2 (二项分布的 MLE). 设 $X \sim \operatorname{Bernoulli}(\theta)$, $p(x; \theta) = \theta^x (1 - \theta)^{1-x}$, $x = 0, 1$ 。

对于随机样本, 似然函数为

$$L(\theta) = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}.$$

对数似然求导并令为零, 解得 $\hat{\theta} = \bar{x}$ 。由于 $\mathbb{E}(X) = \theta$, 故 $\hat{\theta} = \bar{X}$ 是无偏的。³

EXAMPLE 4.3 (正态分布的 MLE). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 参数向量为 $\boldsymbol{\theta} = (\mu, \sigma)$ 。

对数似然为

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2. \quad (4.2.3)$$

¹通用推导框架见附录 section 8.1。

²详细推导见附录 section 8.2。

³详细推导见附录 section 8.3。

对 μ 和 σ 分别求偏导并令为零，解得

$$\hat{\mu} = \bar{X}, \quad (4.2.4)$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (4.2.5)$$

一个重要发现： $\hat{\mu} = \bar{X}$ 是无偏的 ($\mathbb{E}(\bar{X}) = \mu$)，但 $\hat{\sigma}^2$ 是有偏的——

$$\mathbb{E}(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2,$$

而样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是无偏的 ($\mathbb{E}(S^2) = \sigma^2$)。这说明 MLE 有时并非无偏——无偏性和最大似然是两种不同的估计原则。⁴

MLE 的吸引力来自其渐近理论：在温和条件下，MLE 是渐近正态的、渐近有效的，且具有最优性。这些性质使 MLE 成为现代统计推断的基石。

3. 4.3 Confidence Intervals

点估计给出一个数值，但它没有告诉我们这个估计有多“可靠”。置信区间通过提供参数的取值范围来解决这个问题。

一个直观的类比：如果点估计是“我认为明天的温度是 22 度”，那么置信区间就是“我认为温度在 18 到 26 度之间”。后者不仅给出估计，还表达了不确定性。

DEFINITION 4.4 (置信区间). 设 $L = g_1(X_1, \dots, X_n)$ 和 $U = g_2(X_1, \dots, X_n)$ 是两个统计量。若对所有 $\theta \in \Omega$,

$$\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha,$$

则称随机区间 $[L, U]$ 为 θ 的 $100(1 - \alpha)\%$ **置信区间 (confidence interval)**。

正确理解：不是说“ θ 以 $1 - \alpha$ 概率落在区间内” (θ 是固定常数，没有随机性)，而是说“如果重复抽样 $100(1 - \alpha)\%$ 的区间会包含 θ ”。这称为置信区间的频率学派解释。

构造置信区间的关键是找到枢轴量 (pivot) ——一个其分布不依赖于未知参数的函数。⁵

3.1. 正态均值的置信区间.

EXAMPLE 4.4 (已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。则 μ 的 $100(1 - \alpha)\%$ 置信区间为

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right], \quad (4.3.1)$$

其中 $z_{\alpha/2}$ 满足 $\Phi(z_{\alpha/2}) = 1 - \alpha/2$ 。

直觉理解：区间宽度 $\propto \sigma/\sqrt{n}$ ——样本量越大，估计越精确。这与大数定律的直觉一致：更多信息带来更精确的估计。⁶

⁴详细推导见附录 section 8.4。

⁵枢轴量的构造方法及推导见附录 section 8.5。

⁶详细推导见附录 section 8.6。

EXAMPLE 4.5 (未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。用 S^2 替代 σ^2 , 则

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}, \quad (4.3.2)$$

故 μ 的 $100(1 - \alpha)\%$ 置信区间为

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \right]. \quad (4.3.3)$$

用 t 分布替代正态分布: 当方差未知时, 我们用样本标准差 S 替代总体标准差 σ 。这引入了额外的随机性, 导致分布从正态变为 t 分布。 t 分布比正态分布更”重尾”, 反映了未知方差带来的不确定性。⁷

THEOREM 4.1 (方差置信区间). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ 。则 σ^2 的 $100(1 - \alpha)\%$ 置信区间为

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right]. \quad (4.3.4)$$

其中 $\chi_{p,k}^2$ 是 $\chi^2(k)$ 分布的上侧 p 分位数。⁸

4. 4.4 Hypothesis Testing

假设检验回答一个根本性问题: **数据是否提供足够证据拒绝关于总体的某个声明?**

这本质上是一种”举证”逻辑: 我们先假设某个声明为真 (H_0), 然后问: 在这个假设下, 当前数据出现的概率有多大? 如果概率很小, 我们就有理由拒绝这个假设。

核心概念:

- **原假设 H_0 :** 被检验的假设 (通常代表”无效应”或”现状”)
- **备择假设 H_1 :** 与 H_0 对立的假设

在设定假设时, 我们需要权衡两类错误:

	未拒绝 H_0	拒绝 H_0
H_0 为真	正确 (置信度 $1 - \alpha$)	第一类错误 (概率 α)
H_0 为假	第二类错误 (概率 β)	正确 (功效 $1 - \beta$)

显著性水平: $\alpha = \mathbb{P}(\text{第一类错误}) = \mathbb{P}(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$

自然的问题: 为什么不能同时最小化两类错误? 因为在固定样本量下, 两类错误是此消彼长的——降低 α 会提高 β , 反之亦然。这正是统计推断中不确定性本质的体现。

EXAMPLE 4.6 (正态均值检验、已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。检验 $H_0: \mu = \mu_0$ vs $H_1: \mu > \mu_0$ (单侧检验)。

检验统计量:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}. \quad (4.4.1)$$

在 α 水平下, 当 $Z > z_\alpha$ 时拒绝 H_0 。⁹

⁷详细推导见附录 section 8.7。

⁸详细推导见附录 section 8.8。

⁹详细推导见附录 section 8.9。

EXAMPLE 4.7 (正态均值检验、未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。检验 $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$ (双侧检验)。

检验统计量:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}. \quad (4.4.2)$$

在 α 水平下, 当 $|T| > t_{\alpha/2, n-1}$ 时拒绝 H_0 。¹⁰

p 值: 在 H_0 为真条件下, 观察到比当前样本更极端结果的概率。 p 值越小, 拒绝 H_0 的证据越强。

与置信区间的联系: 假设检验和置信区间在本质上是等价的——如果 μ_0 落在置信区间内, 我们就不拒绝 $H_0: \mu = \mu_0$; 反之则拒绝。

5. 4.5 Chi-Square Tests

直到现在, 我们讨论的都是连续型数据。但统计学同样关注**分类数据 (categorical data)**——即计数数据。例如: 选举中支持不同候选人的选民人数、不同药物治疗后的治愈/未治愈人数。

卡方检验的核心思想: 比较观测频数与期望频数。如果两者差异很大, 说明数据可能不服从假设的分布。

5.1. 拟合优度检验. 问题: 数据是否来自某个特定分布?

设 $O_1, \dots, O_k$ 是 k 个类别的观测频数, $E_i = np_{i,0}$ 是 H_0 下的期望频数。

检验统计量:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}. \quad (4.5.1)$$

在 H_0 下, $\chi^2 \approx \chi^2(k-1)$ (大样本近似)。拒绝 H_0 当 $\chi^2 > \chi_{\alpha, k-1}^2$ 。

直观理解: $(O_i - E_i)^2/E_i$ 衡量每个类别的偏差, 平方消去正负号, 除以 E_i 进行标准化, 求和得到总体偏差。¹¹

5.2. 独立性检验. 对于 $r \times c$ 列联表, 设 O_{ij} 为单元格 (i, j) 的观测频数。

在独立性假设下, 行合计与列合计的乘积除以总数给出期望频数:

$$E_{ij} = \frac{O_{i.} O_{.j}}{n}. \quad (4.5.2)$$

检验统计量:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}. \quad (4.5.3)$$

在 H_0 下, $\chi^2 \approx \chi^2((r-1)(c-1))$ 。

¹⁰详细推导见附录 section 8.9。

¹¹详细推导见附录 section 8.10。

6. 4.6 Monte Carlo Methods

有些概率和期望无法解析计算——积分可能没有闭式解，分布可能过于复杂。这时，Monte Carlo 方法提供了一条出路。

核心思想：用随机模拟来近似计算。如果我们可以从某个分布抽样，就可以通过大量重复实验来估计任何期望。

大数定律保证了模拟的收敛性：

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \xrightarrow{P} \mathbb{E}[g(X)]. \quad (4.6.1)$$

这意味着：只要模拟次数足够多，样本均值可以任意接近真实期望。

接受-拒绝算法：当目标分布 $f(x)$ 难以直接抽样时，我们可以利用更容易抽样的提议分布 $g(x)$ ：

- (1) 选择提议分布 $g(x)$ ，满足 $f(x) \leq Mg(x)$ （对某个 $M > 1$ ）
- (2) 生成 $Y \sim g$ 和 $U \sim \text{Uniform}(0, 1)$ 独立
- (3) 若 $U \leq f(Y)/(Mg(Y))$ ，接受 $X = Y$ ；否则拒绝，返回步骤 2

接受概率为 $1/M$ 。¹²

7. 4.7 Bootstrap Methods

核心困境：估计量的抽样分布是统计推断的基础，但这个分布在大多数情况下难以解析计算。例如，样本中位数 $\hat{m}$ 的分布无法用初等函数表达。

Bootstrap 的解决思路既简单又巧妙：**用重抽样近似抽样分布。**

Bootstrap 的核心假设：样本就像总体。如果我们有了一个“好”的样本，为什么不从这个样本中有放回地再次抽样，模拟重复实验的过程？

步骤：

- (1) 从原始样本中有放回地抽取 n 个观测，形成一个 bootstrap 样本 $X_1^*, \dots, X_n^*$
- (2) 计算 bootstrap 复制 $T^* = g(X_1^*, \dots, X_n^*)$
- (3) 重复步骤 1-2 多次（如 $B = 1000$ 次），得到 $T_1^*, \dots, T_B^*$
- (4) 用 $T_1^*, \dots, T_B^*$ 的经验分布近似 T 的抽样分布

percentile bootstrap 置信区间： θ 的 $100(1 - \alpha)\%$ 置信区间为

$$[T_{(\alpha B)}^*, T_{((1-\alpha)B)}^*]. \quad (4.7.1)$$

直觉：如果样本是总体的良好代表，那么从样本有放回抽样就是在模拟“从总体中抽取样本”的过程。 T^* 的分布反映了 T 的抽样分布的近似。¹³

Bootstrap 的强大之处在于它的通用性——几乎任何估计量都可以用 Bootstrap 近似其分布，不需要繁复的数学推导。这使它成为现代统计实践中的重要工具。

¹²接受-拒绝算法的推导及收敛性证明见附录 section 8.11。

¹³Bootstrap 的理论基础及更多细节见附录 section 8.12。

Exercises

EXERCISE 4.1. [4.1](#) *Motor Lifetime Data* Twenty motors were put on test under a high-temperature setting. The lifetimes in hours of the motors under these conditions are given below. Suppose we assume that the lifetime of a motor under these conditions, X , has a $\Gamma(1, \theta)$ distribution.

- (a) Obtain a histogram of the data and overlay it with a density estimate. Based on this plot, do you think that the $\Gamma(1, \theta)$ model is credible?
- (b) Assuming a $\Gamma(1, \theta)$ model, obtain the maximum likelihood estimate $\hat{\theta}$ of θ and locate it on your histogram.
- (c) Obtain the sample median of the data. What parameter is it estimating?
- (d) Based on the mle, what is another estimate of the median of X ?

EXERCISE 4.2. [4.2](#) *Baseball Player Weights* Here are the weights of 26 professional baseball pitchers. Suppose we assume that the weight of a professional baseball pitcher is normally distributed with mean μ and variance σ^2 .

- (a) Obtain a histogram of the data. Based on this plot, is a normal probability model credible?
- (b) Obtain the maximum likelihood estimates of μ , σ^2 , σ , and μ/σ .
- (c) Using the binomial model, obtain the maximum likelihood estimate of the proportion p of professional baseball pitchers who weigh over 215 pounds.
- (d) Determine the mle of p assuming that the weight follows the normal probability model $N(\mu, \sigma^2)$.

EXERCISE 4.3. [4.3](#) *Poisson Customer Arrivals* Suppose the number of customers X that enter a store between 9:00 a.m. and 10:00 a.m. follows a Poisson distribution with parameter θ . Suppose a random sample of the number of customers for 10 days results in values: 9, 7, 9, 15, 10, 13, 11, 7, 2, 12.

- (a) Determine the maximum likelihood estimate of θ . Show that it is an unbiased estimator.
- (b) Based on these data, obtain the realization of your estimator. Explain its meaning.

EXERCISE 4.4. [4.4](#) *Verify Likelihood Equations* For Example 4.1.3, verify equations (4.1.4)-(4.1.8).

EXERCISE 4.5. [4.5](#) *Order Statistics Probability* Let $X_1, X_2, \dots, X_n$ be a random sample from a continuous-type distribution.

- (a) Find $P(X_1 \leq X_2)$, $P(X_1 \leq X_2, X_1 \leq X_3)$, $\dots$, $P(X_1 \leq X_i, i = 2, 3, \dots, n)$.

- (b) Suppose the sampling continues until X_1 is no longer the smallest observation. Let Y equal the number of trials (not including X_1) until X_1 is no longer the smallest. Show that $P(Y = y) = \frac{1}{y(y+1)}$, $y = 1, 2, 3, \dots$
- (c) Compute the mean and variance of Y if they exist.

EXERCISE 4.6. [4.6](#) *Variance of PMF Estimator* Consider the estimator of the pmf in expression (4.1.10). We showed that this estimator is unbiased. Find the variance of the estimator and its mgf.

EXERCISE 4.7. [4.7](#) *Scottish Schoolchildren Eye Colors* The data set on Scottish schoolchildren included the eye colors of the children. The frequencies of their eye colors are: Blue: 2978, Light: 6697, Medium: 7511, Dark: 5175. Use these frequencies to obtain a bar chart and an estimate of the associated pmf.

EXERCISE 4.8. [4.8](#) *MLE of Poisson PMF* Assuming that the data in Example 4.1.6 were drawn from a Poisson distribution with mean λ , obtain the mle of λ and then use it to obtain the mle of the pmf. Compare the mle of the pmf to the nonparametric estimate.

EXERCISE 4.9. [4.9](#) *Nonparametric Density Estimator* Consider the nonparametric estimator of a pdf.

- (a) Obtain its mean and determine the bias of the estimator.
- (b) Obtain the variance of the estimator.

EXERCISE 4.10. [4.10](#) *Brain Data Analysis* This data set consists of a sample of brain information recorded on 40 college students. The variables include gender, height, weight, three IQ measurements, and MRI counts.

- (a) Load the rda file and print the MRI data.
- (b) Obtain a histogram of the data. Comment on the shape.
- (c) Overlay the default density estimator. Comment on the shape.
- (d) Obtain the sample mean and standard deviation and overlay the normal pdf with these estimates. Comment on the fit.
- (e) Determine the proportions of the data within 1 and 2 standard deviations of the sample mean.

EXERCISE 4.11. [4.11](#) *Speed of Light Data* This is a famous data set on the speed of light recorded by the scientist Simon Newcomb.

- (a) Load the rda file. Discuss the data.
- (b) Obtain a histogram of the data. Comment on the shape.
- (c) Overlay the default density estimator. Comment on the shape.
- (d) Overlay the normal pdf with sample mean and standard deviation. Comment on the fit.

- (e) Determine the proportions of the data within 1 and 2 standard deviations of the sample mean.

EXERCISE 4.12. [4.12](#) *Normal Confidence Intervals* Let the observed value of the mean $\bar{X}$ and of the sample variance of a random sample of size 20 from a distribution that is $N(\mu, \sigma^2)$ be 81.2 and 26.5, respectively. Find respectively 90%, 95% and 99% confidence intervals for μ .

EXERCISE 4.13. [4.13](#) *Motor Lifetime Confidence Interval* Consider the data on the lifetimes of motors given in Exercise 4.1.1. Obtain a large sample 95% confidence interval for the mean lifetime of a motor.

EXERCISE 4.14. [4.14](#) *Gamma Distribution Inference* Suppose we assume that $X_1, X_2, \dots, X_n$ is a random sample from a $\Gamma(1, \theta)$ distribution.

- Show that the random variable $(2/\theta) \sum_{i=1}^n X_i$ has a χ^2 -distribution with $2n$ degrees of freedom.
- Using the random variable in part (a) as a pivot random variable, find a $(1 - \alpha)100\%$ confidence interval for θ .
- Obtain the confidence interval for the data of Exercise 4.1.1.

EXERCISE 4.15. [4.15](#) *Baseball Weight Difference* In Example 4.2.4, for the baseball data, find the pooled t 95% confidence interval for the mean difference in weights between the pitchers and hitters.

EXERCISE 4.16. [4.16](#) *Left-handed Baseball Players* In the baseball data set, it was found that out of 59 baseball players, 15 were left-handed. Construct a 95% approximate confidence interval for p , the proportion of left-handed professional baseball players.

EXERCISE 4.17. [4.17](#) *Sample Size for CI Length* Let $\bar{X}$ be the mean of a random sample of size n from a distribution that is $N(\mu, 9)$. Find n such that $P(\bar{X} - 1 < \mu < \bar{X} + 1) = 0.90$, approximately.

EXERCISE 4.18. [4.18](#) *CI from Sample Data* Let a random sample of size 17 from the normal distribution $N(\mu, \sigma^2)$ yield $\bar{x} = 4.7$ and $s^2 = 5.76$. Determine a 90% confidence interval for μ .

EXERCISE 4.19. [4.19](#) *Sample Size for Half-length* Let $\bar{X}$ denote the mean of a random sample of size n from a distribution that has mean μ and variance $\sigma^2 = 10$. Find n so that the probability is approximately 0.954 that the random interval $(\bar{X} - 1/2, \bar{X} + 1/2)$ includes μ .

EXERCISE 4.20. [4.20](#) *Normal CI Length Comparison* Let $X_1, X_2, \dots, X_9$ be a random sample of size 9 from a distribution that is $N(\mu, \sigma^2)$.

- (a) If σ is known, find the length of a 95% confidence interval for μ .
- (b) If σ is unknown, find the expected value of the length of a 95% confidence interval for μ .
- (c) Compare these two answers.

EXERCISE 4.21. [4.21](#) *Prediction Interval* Let $X_1, X_2, \dots, X_n, X_{n+1}$ be a random sample of size $n + 1$, $n > 1$, from a distribution that is $N(\mu, \sigma^2)$. Find the constant c so that the statistic $c(\bar{X} - X_{n+1})/S$ has a t -distribution.

EXERCISE 4.22. [4.22](#) *Monte Carlo CI Coverage* Let $X_1, \dots, X_n$ be a random sample from a $N(0, 1)$ distribution. Simulate m confidence intervals and calculate the proportion that trap 0.

- (a) Set $n = 10$ and $m = 50$. Run the R code and find the proportion of successful confidence intervals.
- (b) Plot the intervals and comment on the variability of the lengths.

EXERCISE 4.23. [4.23](#) *Invariance of CI Coverage* In Exercise 4.2.11, show that setting $\mu = 0$ and $\sigma = 1$ is without loss of generality.

EXERCISE 4.24. [4.24](#) *Empirical Confidence Level* Change the code in the R function `getcis` so that it also returns the vector `ind` where `ind[i] = 1` if the i th confidence interval is successful. Show that the empirical confidence level is `mean(ind)`.

EXERCISE 4.25. [4.25](#) *Gamma CI via CLT* Let $\bar{X}$ denote the mean of a random sample of size 25 from a gamma-type distribution with $\alpha = 4$ and $\beta > 0$. Use the Central Limit Theorem to find an approximate 0.954 confidence interval for μ .

EXERCISE 4.26. [4.26](#) *Sample Size for Given Length* Let $\bar{x}$ be the observed mean of a random sample of size n from a distribution having mean μ and known variance σ^2 . Find n so that $\bar{x} - \sigma/4$ to $\bar{x} + \sigma/4$ is an approximate 95% confidence interval for μ .

EXERCISE 4.27. [4.27](#) *Binomial Sample Size* Assume a binomial model for a certain random variable. If we desire a 90% confidence interval for p that is at most 0.02 in length, find n .

EXERCISE 4.28. [4.28](#) *Poisson Confidence Interval* It is known that a random variable X has a Poisson distribution with parameter μ . A sample of 200 observations from this distribution has a mean equal to 3.4. Construct an approximate 90% confidence interval for μ .

EXERCISE 4.29. [4.29](#) *Variance CI via Chi-square* Let $X_1, X_2, \dots, X_n$ be a random sample from $N(\mu, \sigma^2)$, where both parameters are unknown.

- (a) Show that $P((n - 1)S^2/\sigma^2 < b) = 0.975$ and $P(a < (n - 1)S^2/\sigma^2 < b) = 0.95$.

(b) If $n = 9$ and $s^2 = 7.93$, find a 95% confidence interval for σ^2 .

(c) If μ is known, how would you modify the procedure?

EXERCISE 4.30. [4.30](#) *Exact Gamma CI* Let $X_1, X_2, \dots, X_n$ be a random sample from a gamma distribution with known parameter $\alpha = 3$ and unknown $\beta > 0$. Obtain an exact confidence interval by first obtaining the distribution of $2 \sum_{i=1}^n X_i / \beta$.

EXERCISE 4.31. [4.31](#) *Tack Point-Up Probability* When 100 tacks were thrown on a table, 60 of them landed point up. Obtain a 95% confidence interval for the probability that a tack of this type lands point up.

EXERCISE 4.32. [4.32](#) *Two-Sample Normal CI* Let two independent random samples, each of size 10, from two normal distributions $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$ yield $\bar{x} = 4.8$, $s_1^2 = 8.64$, $\bar{y} = 5.6$, $s_2^2 = 7.88$. Find a 95% confidence interval for $\mu_1 - \mu_2$.

EXERCISE 4.33. [4.33](#) *Binomial Proportion Difference* Let two independent random variables Y_1 and Y_2 with binomial distributions having parameters $n_1 = n_2 = 100$, p_1 and p_2 , be observed to be $y_1 = 50$ and $y_2 = 40$. Determine an approximate 90% confidence interval for $p_1 - p_2$.

EXERCISE 4.34. [4.34](#) *Known Variance Difference* Discuss the problem of finding a confidence interval for the difference $\mu_1 - \mu_2$ between the two means of two normal distributions if the variances σ_1^2 and σ_2^2 are known but not necessarily equal.

EXERCISE 4.35. [4.35](#) *Unknown Unequal Variance* Discuss the problem when the variances are unknown and unequal. If the variances are unknown but their ratio σ_1^2 / σ_2^2 is a known constant k , then a statistic that is a T random variable can again be used. Why?

EXERCISE 4.36. [4.36](#) *Ratio Known Variance CI* Let $X_1, \dots, X_9$ and $Y_1, \dots, Y_{12}$ represent two independent random samples from $N(\mu_1, \sigma_1^2)$ and $N(\mu_2, \sigma_2^2)$. It is given that $\sigma_1^2 = 3\sigma_2^2$, but σ_2^2 is unknown. Define a random variable that has a t -distribution for a 95% confidence interval for $\mu_1 - \mu_2$.

EXERCISE 4.37. [4.37](#) *Sample Size for Mean Difference* Let $\bar{X}$ and $\bar{Y}$ be the means of two independent random samples, each of size n , from $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$, where the common variance is known. Find n such that $P(\bar{X} - \bar{Y} - \sigma/5 < \mu_1 - \mu_2 < \bar{X} - \bar{Y} + \sigma/5) = 0.90$.

EXERCISE 4.38. [4.38](#) *Variance Ratio CI* Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ be two independent random samples from $N(\mu_1, \sigma_1^2)$ and $N(\mu_2, \sigma_2^2)$. Construct a confidence interval for the ratio σ_1^2 / σ_2^2 .

EXERCISE 4.39. [4.39](#) *Exact Binomial CI* Recall for the baseball data, 15 out of 59 ballplayers are left-handed. Determine an exact 90% confidence interval for p .

EXERCISE 4.40. [4.40](#) *Asymptotic CI Verification* In Example 4.3.2, verify the result for the asymptotic confidence interval for θ .

EXERCISE 4.41. [4.41](#) *Discrete Exact Tack CI* In Exercise 4.2.20, find the discrete exact confidence interval for the proportion.

EXERCISE 4.42. [4.42](#) *Poisson Exact CI* Suppose $X_1, X_2, \dots, X_{10}$ is a random sample from a Poisson distribution with mean θ . Suppose $n\bar{x} = 5$. Compute the exact 90% confidence interval for θ .

EXERCISE 4.43. [4.43](#) *t-Interval Derivation* Consider the same setup as in Example 4.3.1 except now assume that σ^2 is unknown. Set up the equations and derive the t-interval for θ .

EXERCISE 4.44. [4.44](#) *Beta Integral Identity* Using Exercise 3.3.22, show that

$$\int_0^p \frac{n!}{(k-1)!(n-k)!} z^{k-1} (1-z)^{n-k} dz = \sum_{w=k}^n \binom{n}{w} p^w (1-p)^{n-w}.$$

EXERCISE 4.45. [4.45](#) *Poisson CDF Identity* This exercise obtains a useful identity for the cdf of a Poisson cdf.

(a) Show that

$$\frac{\lambda^n}{\Gamma(n)} \int_1^\infty x^{n-1} e^{-x\lambda} dx = \sum_{j=0}^{n-1} e^{-\lambda} \frac{\lambda^j}{j!}.$$

(b) Obtain the identity used in Example 4.3.3.

EXERCISE 4.46. [4.46](#) *Distribution Quantiles* Obtain closed-form expressions for the distribution quantiles based on the exponential and Laplace distributions.

EXERCISE 4.47. [4.47](#) *Potential Outlier Probability* Suppose the pdf $f(x)$ is symmetric about 0. Show that the probability of a potential outlier from this distribution is $2F(4q_1)$, where $F^{-1}(0.25) = q_1$. Use this for:

(a) The normal distribution.

(b) The logistic distribution.

(c) The Laplace distribution.

EXERCISE 4.48. [4.48](#) *Data Summary and Outliers* Consider the sample of data: 13, 5, 202, 15, 99, 4, 67, 83, 36, 11, 301, 23, 213, 40, 66, 106, 78, 69, 166, 84, 64.

(a) Obtain the five-number summary.

(b) Determine if there are any outliers.

(c) Boxplot the data. Comment.

EXERCISE 4.49. [4.49](#) *Normal Q-Q Plot* Consider the data in Exercise 4.4.3. Obtain the normal q-q plot. Does it suggest the underlying distribution is normal? If not, determine a more appropriate distribution.

EXERCISE 4.50. [4.50](#) *Exponential Order Statistic* Let $Y_1 < Y_2 < Y_3 < Y_4$ be the order statistics of a random sample of size 4 from the distribution having pdf $f(x) = e^{-x}$, $0 < x < \infty$. Find $P(Y_4 \geq 3)$.

EXERCISE 4.51. [4.51](#) *Continuous Distribution Order Stats* Let X_1, X_2, X_3 be a random sample from a distribution having pdf $f(x) = 2x$, $0 < x < 1$.

- (a) Compute the probability that the smallest exceeds the median.
- (b) Find the correlation between Y_2 and Y_3 .

EXERCISE 4.52. [4.52](#) *Discrete Order Statistic PMF* Let $f(x) = 1/6$, $x = 1, 2, 3, 4, 5, 6$, be the pmf of a discrete distribution. Show that the pmf of the smallest observation of a random sample of size 5 is $g_1(y_1) = (7 - y_1)^5/6^5 - (6 - y_1)^5/6^5$, $y_1 = 1, 2, \dots, 6$.

EXERCISE 4.53. [4.53](#) *Independent Transformations* Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ denote the order statistics from exponential distribution. Show that $Z_1 = Y_2$ and $Z_2 = Y_4 - Y_2$ are independent.

EXERCISE 4.54. [4.54](#) *Beta Distribution of Order Statistic* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics from $\text{uniform}(0,1)$. Show that Y_k has a beta pdf with parameters $\alpha = k$ and $\beta = n - k + 1$.

EXERCISE 4.55. [4.55](#) *Weibull Minimum* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics from a Weibull distribution. Find the distribution function and pdf of Y_1 .

EXERCISE 4.56. [4.56](#) *Uniform Range* Find the probability that the range of a random sample of size 4 from the uniform distribution is less than $1/2$.

EXERCISE 4.57. [4.57](#) *Ratio of Order Statistics* Let $Y_1 < Y_2 < Y_3$ be order statistics from $f(x) = 2x$, $0 < x < 1$. Show that $Z_1 = Y_1/Y_2$, $Z_2 = Y_2/Y_3$, and $Z_3 = Y_3$ are mutually independent.

EXERCISE 4.58. [4.58](#) *Ratio of Observations* Suppose a random sample of size 2 is obtained from $f(x) = 2(1 - x)$, $0 < x < 1$. Compute the probability that one sample observation is at least twice as large as the other.

EXERCISE 4.59. [4.59](#) *Midrange Distribution* Let $Y_1 < Y_2 < Y_3$ denote order statistics from $\text{uniform}(0,1)$. Let $Z = (Y_1 + Y_3)/2$ be the midrange. Find the pdf of Z .

EXERCISE 4.60. [4.60](#) *Normal Order Stats Expectation* Let $Y_1 < Y_2$ denote the order statistics of a random sample of size 2 from $N(0, \sigma^2)$.

- (a) Show $E(Y_1) = -\sigma/\sqrt{\pi}$.
- (b) Find the covariance of Y_1 and Y_2 .

EXERCISE 4.61. [4.61](#) *Independence Characterizes Exponential* Let $Y_1 < Y_2$ be order statistics from a continuous distribution with pdf $f(x) > 0$ for $x \geq 0$. Show that the independence of $Z_1 = Y_1$ and $Z_2 = Y_2 - Y_1$ characterizes the gamma pdf with $\alpha = 1$.

EXERCISE 4.62. [4.62](#) *Conditional Distribution* Let $Y_1 < Y_2 < Y_3 < Y_4$ be order statistics from $f(x) = 2x$, $0 < x < 1$.

- (a) Find the joint pdf of Y_3 and Y_4 .
- (b) Find the conditional pdf of Y_3 given $Y_4 = y_4$.
- (c) Evaluate $E(Y_3|y_4)$.

EXERCISE 4.63. [4.63](#) *Triangle Probability* Two numbers are selected at random from the interval $(0, 1)$. Compute the probability that the three resulting line segments can form a triangle.

EXERCISE 4.64. [4.64](#) *Min and Max Joint PDF* Let X and Y be independent with $f(x) = 2x$ and $g(y) = 3y^2$ on $(0, 1)$. Let $U = \min(X, Y)$ and $V = \max(X, Y)$. Find the joint pdf of U and V .

EXERCISE 4.65. [4.65](#) *Joint PDF of Min and Max* Let the joint pdf of X and Y be $f(x, y) = 12x(x + y)/7$, $0 < x < 1$, $0 < y < 1$. Let $U = \min(X, Y)$ and $V = \max(X, Y)$. Find the joint pdf of U and V .

EXERCISE 4.66. [4.66](#) *Gini's Mean Difference* Let $X_1, X_2, \dots, X_n$ be a random sample. Gini's mean difference is $G = \sum_{j=2}^n \sum_{i=1}^{j-1} |X_i - X_j| / \binom{n}{2}$.

- (a) If $n = 10$, find $a_1, \dots, a_{10}$ so that $G = \sum_{i=1}^{10} a_i Y_i$.
- (b) Show $E(G) = 2\sigma/\sqrt{\pi}$ for normal distribution.

EXERCISE 4.67. [4.67](#) *Exponential Order Stats Properties* Let $Y_1 < Y_2 < \dots < Y_n$ be order statistics from exponential distribution.

- (a) Show $Z_1 = nY_1$, $Z_2 = (n-1)(Y_2 - Y_1)$, $Z_3 = (n-2)(Y_3 - Y_2)$, $\dots$, $Z_n = Y_n - Y_{n-1}$ are independent exponentials.
- (b) Demonstrate that all linear functions of Y_i can be expressed as linear functions of independent random variables.

EXERCISE 4.68. [4.68](#) *PERT Distribution* In PERT, let X_1, X_2, X_3 be three independent uniform random times. For series completion ($Y = X_1 + X_2 + X_3$) and parallel completion ($Z = \max(X_1, X_2, X_3)$), find their pdfs.

EXERCISE 4.69. [4.69](#) *Sample Size for Extreme Quantile* Let Y_n denote the n th order statistic. Find the smallest n for which $P(\xi_{0.9} < Y_n) \geq 0.75$.

EXERCISE 4.70. [4.70](#) *Probability Involving Quantiles* Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ denote order statistics of size 5. Compute:

- (a) $P(Y_1 < \xi_{0.5} < Y_5)$
- (b) $P(Y_1 < \xi_{0.25} < Y_3)$
- (c) $P(Y_4 < \xi_{0.80} < Y_5)$

EXERCISE 4.71. [4.71](#) *Median Between Order Stats* Compute $P(Y_3 < \xi_{0.5} < Y_7)$ if $Y_1 < \dots < Y_9$ are order statistics of size 9.

EXERCISE 4.72. [4.72](#) *Sample Size for Median Coverage* Find the smallest n for which $P(Y_1 < \xi_{0.5} < Y_n) \geq 0.99$.

EXERCISE 4.73. [4.73](#) *Normal Order Stats Interval* Let $Y_1 < Y_2$ be order statistics from $N(\mu, \sigma^2)$ with known σ^2 .

- (a) Show $P(Y_1 < \mu < Y_2) = 1/2$ and compute $E(Y_2 - Y_1)$.
- (b) Find c such that $P(\bar{X} - c\sigma < \mu < \bar{X} + c\sigma) = 1/2$.

EXERCISE 4.74. [4.74](#) *Selection Algorithm* Let $y_1 < y_2 < y_3$ be observed order statistics. A statistician is given these values in random order and wants to select the largest. She looks at the first but refuses it and then takes the second if larger than the first, else takes the third. Show this algorithm has probability $1/2$ of selecting the largest.

EXERCISE 4.75. [4.75](#) *Motor Median CI* Refer to Exercise 4.1.1. Using expression (4.4.10), obtain a confidence interval for the median lifetime of a motor.

EXERCISE 4.76. [4.76](#) *Power Function of Test* Show that the approximate power function given in expression (4.5.12) is strictly increasing. Show the test has approximate size α for testing $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$.

EXERCISE 4.77. [4.77](#) *Darwin Data t-Test* For the Darwin data, verify that the Student t -test statistic is 2.15.

EXERCISE 4.78. [4.78](#) *Neyman-Pearson Test* Let X have pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$. To test $H_0 : \theta = 1$ against $H_1 : \theta = 2$, use critical region $C = \{(x_1, x_2) : x_1 x_2 \geq 3/4\}$. Find the power function.

EXERCISE 4.79. [4.79](#) *Binomial Significance Level* Let X have binomial distribution with $n = 10$ and $p = 1/4$ or $1/2$. Test $H_0 : p = 1/2$ vs $H_1 : p = 1/4$ by rejecting if $X_1 \leq 3$. Find significance level and power.

EXERCISE 4.80. [4.80](#) *Exponential LR Test* Let X_1, X_2 be a sample from $f(x; \theta) = (1/\theta)e^{-x/\theta}$. Reject $H_0 : \theta = 2$ if $f(x_1; 2)f(x_2; 2)/[f(x_1; 1)f(x_2; 1)] \leq 1/2$. Find significance level and power when H_0 is false.

EXERCISE 4.81. [4.81](#) *Power Curve Sketch* Consider tests Test 1 and Test 2. For Test A, reject H_0 if $S \leq k_A$; for Test B, reject if $S \leq k_B$. If Test A has higher significance level, show Test A has higher power.

EXERCISE 4.82. [4.82](#) *Tire Life Test* Let tire life $X \sim N(\theta, 5000^2)$. Test $H_0 : \theta = 30000$ vs $H_1 : \theta > 30000$. Determine n and c so that $\gamma(30000) = 0.01$ and $\gamma(35000) = 0.98$.

EXERCISE 4.83. [4.83](#) *Poisson Power Function* Let X have Poisson distribution. Test $H_0 : \theta = 1/2$ vs $H_1 : \theta < 1/2$. With $n = 12$, reject if $Y = \sum X_i \leq 2$. Graph the power function and determine significance level.

EXERCISE 4.84. [4.84](#) *Binomial Sample Size* Let $Y \sim \text{binomial}(n, p)$. Test $H_0 : p = 1/2$ vs $H_1 : p > 1/2$. Find n and c so that $\gamma(1/2) = 0.10$ and $\gamma(2/3) = 0.95$.

EXERCISE 4.85. [4.85](#) *Uniform Max Test* Let $Y_1 < Y_2 < Y_3 < Y_4$ be order statistics from $f(x; \theta) = 1/\theta$, $0 < x < \theta$. Test $H_0 : \theta = 1$ vs $H_1 : \theta > 1$ by rejecting if $Y_4 \geq c$.

(a) Find c for $\alpha = 0.05$.

(b) Determine the power function.

EXERCISE 4.86. [4.86](#) *Poisson Test Size* Let $X_1, \dots, X_8$ be from Poisson with mean μ . Test $H_0 : \mu = 0.5$ vs $H_1 : \mu > 0.5$ by rejecting if $\sum x_i \geq 8$.

(a) Show significance level is $1 - \text{ppois}(7, 4)$.

(b) Determine $\gamma(0.75)$, $\gamma(1)$, $\gamma(1.25)$.

EXERCISE 4.87. [4.87](#) *Tennis Serve Hypothesis* Let p be probability that first serve is good. Test $H_0 : p = 0.40$ vs $H_1 : p > 0.40$ with $n = 25$. Reject if $Y \geq 13$.

(a) Show $\alpha = 1 - \text{pbinom}(12, 25, 0.4)$.

(b) Find β when $p = 0.60$.

EXERCISE 4.88. [4.88](#) *Bernoulli Power Comparison* Let S be number of successes in $n = 40$ Bernoulli trials. Test $H_0 : p \leq 0.3$ vs $H_1 : p > 0.3$. Compare tests: (1) Reject if $S \geq 16$ and (2) Reject if $S \geq 17$. Determine levels.

EXERCISE 4.89. [4.89](#) *Proportion Power Curve* Consider the two-sided test for proportions. Write R code to compute a plot of the power curve.

EXERCISE 4.90. [4.90](#) *Power Function Derivative* Consider the power function $\gamma(\mu)$. Show $\gamma'(\mu)$ is strictly negative for $\mu < \mu_0$ and strictly positive for $\mu > \mu_0$.

EXERCISE 4.91. [4.91](#) *Exact Size t-Test* Show that the test defined by (4.6.9) has exact size α for testing $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$.

EXERCISE 4.92. [4.92](#) *One vs Two-Sided Power* Consider the one-sided t -test and two-sided t -test, both of size α . Show that for $\mu > \mu_0$, the power function of the one-sided test is larger.

EXERCISE 4.93. [4.93](#) *Paired Design Analysis* A baseball coach paired 20 members by speed. Data on self vs rival times are given.

- (a) Obtain comparison boxplots. Comment.
- (b) Compute paired t -test and p -value.
- (c) Obtain point estimate and 95% CI for μ_d .
- (d) Conclude.

EXERCISE 4.94. [4.94](#) *AZT Dosage Study* A data set concerning the effect of AZT dosages on HIV patients. Compare 300mg and 600mg groups.

- (a) Obtain comparison boxplots.
- (b) Compute two-sample t -test and p -value.
- (c) Obtain point estimate and 95% CI for Δ .
- (d) Conclude.

EXERCISE 4.95. [4.95](#) *Air Quality Comparison* Compare suspended particle concentrations between Melbourne and Houston. Test $H_0 : \mu_X = \mu_Y$ against $H_1 : \mu_X < \mu_Y$.

- (a) Define test statistic and critical region.
- (b) Calculate with given statistics.

EXERCISE 4.96. [4.96](#) *Seat Belt Campaign* Let p be proportion of drivers using seat belts. After campaign, $y = 104$ out of $n = 590$ wore belts. Was campaign successful?

- (a) Define hypotheses.
- (b) Critical region at $\alpha = 0.01$.
- (c) Determine p -value.

EXERCISE 4.97. [4.97](#) *Variance Test Critical Value Test* $H_0 : \sigma^2 = \sigma_0^2$ against $H_1 : \sigma^2 > \sigma_0^2$ using critical region $(n-1)S^2/\sigma_0^2 \geq c$. If $n = 13$ and $\alpha = 0.025$, determine c .

EXERCISE 4.98. [4.98](#) *F-Test Critical Value Test* $H_0 : \sigma_1^2 = \sigma_2^2$ against $H_1 : \sigma_1^2 > \sigma_2^2$ using $F \geq c$. If $n = 13$, $m = 11$, and $\alpha = 0.05$, find c .

EXERCISE 4.99. [4.99](#) *Modified Frequency Test* Suppose observed frequencies of $A_1, \dots, A_4$ are 20, 30, 92, 105. Calculate the test and report p -value.

EXERCISE 4.100. [4.100](#) *Continuous Interval Test* A number is selected from $(0, 2)$. Test hypothesis with $p_{i0} = \int_{A_i} (1/2)(2-x)dx$. For observed frequencies 30, 30, 10, 10, would H_0 be accepted?

EXERCISE 4.101. [4.101](#) *Normal Approximation Test* Define sets $A_1 = \{x : -\infty < x \leq 0\}$, $A_i = \{x : i-2 < x \leq i-1\}$ for $i = 2, \dots, 7$, $A_8 = \{x : 6 < x < \infty\}$. Test with frequencies 60, 96, 140, 210, 172, 160, 88, 74.

EXERCISE 4.102. [4.102](#) *Die Casting Test* A die was cast $n = 120$ times with frequencies: 1:b, 2:20, 3:20, 4:20, 5:20, 6:40 – b. For what values of b would the hypothesis of unbiased die be rejected at 0.025 level?

EXERCISE 4.103. [4.103](#) *Mendelian Genetics* Mendelian theory states probabilities are $9/16$, $3/16$, $3/16$, $1/16$ for four classifications. With observed frequencies 86, 35, 26, 13 out of 160, test at $\alpha = 0.01$.

EXERCISE 4.104. [4.104](#) *Teaching Method Comparison* Two groups of 100 students each. Test at 5% whether the two distributions are the same.

EXERCISE 4.105. [4.105](#) *Crime and Alcoholism Data* on crime type and alcoholic status. Test independence.

- (a) Compute χ^2 -test for independence.
- (b) Use Pearson residuals to determine strongest dependence.
- (c) Confirm with conditional test.

EXERCISE 4.106. [4.106](#) *Independence Test* 180 independent trials with classification into A_1, A_2, A_3 and B_1, B_2, B_3, B_4 . What is smallest k that leads to rejection at $\alpha = 0.05$?

EXERCISE 4.107. [4.107](#) *Poisson Goodness of Fit* Fit Poisson distribution to data: x : 0, 1, 2, 3, 3 < x with frequencies 20, 40, 16, 18, 6.

- (a) Compute chi-square statistic.
- (b) Degrees of freedom?
- (c) Reject at $\alpha = 0.05$?

EXERCISE 4.108. [4.108](#) *MCT Converse* Prove the converse of Theorem MCT: Let X have continuous cdf $F(x)$ strictly increasing. Show $Z = F(X)$ has uniform(0,1) distribution.

EXERCISE 4.109. [4.109](#) *Monte Carlo Log 2 Approximation* $\log 2 = \int_0^1 1/(x+1)dx$ using uniform(0,1) generator. Write R function and compare with true value.

EXERCISE 4.110. [4.110](#) *Normal CDF Approximation* Approximate $\int_0^{1.96} (1/\sqrt{2\pi}) \exp\{-t^2/2\}dt$ using Monte Carlo.

EXERCISE 4.111. [4.111](#) *Location-Scale Generation* Suppose X has pdf $f_X(x) = b^{-1}f((x-a)/b)$. If we can generate from $f(z)$, explain how to generate from $f_X(x)$.

EXERCISE 4.112. [4.112](#) *Logistic Distribution Generation* Determine a method to generate random observations for the logistic pdf. Write R function and verify with histogram.

EXERCISE 4.113. [4.113](#) *Beta Generator* Determine a method to generate random observations for $f(x) = 4x^3$, $0 < x < 1$. Write R function.

EXERCISE 4.114. [4.114](#) *Laplace Inverse CDF* Obtain the inverse function of the cdf of the Laplace pdf $f(x) = (1/2)e^{-|x|}$. Write R function.

EXERCISE 4.115. [4.115](#) *Extreme Value Generation* Determine a method to generate random observations for the extreme-valued pdf $f(x) = \exp\{x - e^x\}$. Write R function.

EXERCISE 4.116. [4.116](#) *Cauchy Distribution* Determine a method to generate random observations for the Cauchy distribution $f(x) = 1/[\pi(1 + x^2)]$. Write R function.

EXERCISE 4.117. [4.117](#) *Weibull Generation* Determine a method to generate random observations for the Weibull distribution. Write R function.

EXERCISE 4.118. [4.118](#) *Contaminated Normal Power* Write algorithm to simulate power of the test for contaminated normal distribution. Modify R function.

EXERCISE 4.119. [4.119](#) *Logistic Power Simulation* Write algorithm to simulate significance level and power for logistic distribution.

EXERCISE 4.120. [4.120](#) *General Inverse CDF* For cdf $F(x)$ not strictly increasing, define $F^{-1}(u) = \inf\{x : F(x) \geq u\}$. Let $U \sim \text{uniform}(0, 1)$. Prove $F^{-1}(U)$ has cdf $F(x)$.

EXERCISE 4.121. [4.121](#) *Ratio Maximum* Verify the derivative in (4.8.12) and show the function attains maximum at $x = (\alpha - [\alpha])/(1 - b)$.

EXERCISE 4.122. [4.122](#) *Minimum Derivation* Derive expression (4.8.14) and show $b = [\alpha]/\alpha$ gives minimum.

EXERCISE 4.123. [4.123](#) *Gamma via Beta* Assume $Y_1 \sim \Gamma(\alpha+1, 1)$, $Y_2 \sim \text{uniform}(0, 1)$. Let $X_1 = Y_1 Y_2^{1/\alpha}$ and $X_2 = Y_2$. Show $X_1 \sim \Gamma(\alpha, 1)$.

EXERCISE 4.124. [4.124](#) *Ratio Derivative* Show the derivative of the ratio in (4.8.10) is $-x \exp\{-x^2/2\}(x^2 - 1)$ with critical values ± 1 .

EXERCISE 4.125. [4.125](#) *Beta Distribution Generation* Consider accept-reject algorithm for beta distribution. Show X has beta distribution with parameters α and β .

EXERCISE 4.126. [4.126](#) *Marsaglia-Bray Normal* Consider the Marsaglia-Bray algorithm for generating normal random variables. Show X_1 and X_2 are iid $N(0, 1)$.

EXERCISE 4.127. [4.127](#) *Bootstrap CI for Mean* Use the R function `percentboot` to obtain a bootstrap 95% confidence interval for the mean concentration. Compare with t -CI.

EXERCISE 4.128. [4.128](#) *Bootstrap Sample Properties* Let $x_1^*, \dots, x_n^*$ be a bootstrap sample drawn with replacement.

(a) Show x_i^* are iid with common cdf $\hat{F}_n$.

(b) Show $E(x_i^*) = \bar{x}$.

(c) If n odd, show $\text{median}\{x_i^*\} = x_{(n+1)/2}$.

(d) Show $V(x_i^*) = n^{-1} \sum (x_i - \bar{x})^2$.

EXERCISE 4.129. [4.129](#) *Gamma Bootstrap CI* Let $X_1, \dots, X_n \sim \Gamma(1, \beta)$.

(a) Show $(2n\bar{X}/(\chi_{2n}^2)^{(1-\alpha/2)}, 2n\bar{X}/(\chi_{2n}^2)^{(\alpha/2)})$ is exact CI for β .

(b) Show 90% CI for data is (64.99, 136.69).

EXERCISE 4.130. [4.130](#) *Bootstrap Median CI* Suppose we want to estimate the median using sample median. Obtain 90% bootstrap percentile CI. Did it trap the true median?

EXERCISE 4.131. [4.131](#) *Bootstrap t-Interval* Suppose $X_1, \dots, X_n \sim N(\mu, \sigma^2)$. Show the pivot $t = (\bar{X} - \mu)/(S/\sqrt{n})$ leads to CI.

EXERCISE 4.132. [4.132](#) *Standardized Bootstrap CI* Consider bootstrap pivot $t^* = (\bar{x}^* - \bar{x})/(s^*/\sqrt{n})$.

(a) Rewrite percentile CI algorithm using t^* .

(b) Find 90% CI for data in Example 4.9.3.

(c) Compare with nonstandardized CI.

EXERCISE 4.133. [4.133](#) *Bootstrap Median Test* Consider algorithm for two-sample bootstrap test based on difference in medians.

(a) Rewrite algorithm for median.

(b) Obtain bootstrap test.

(c) Compare p-value with 0.063.

EXERCISE 4.134. [4.134](#) *Two-Sample t-Test Value* Consider data of Example 4.9.2. Show $t = 0.93$ with p-value 0.18.

EXERCISE 4.135. [4.135](#) *Bootstrap Two-Sided Test* In Example 4.9.3, test $H_0 : \mu = 90$ vs $H_1 : \mu \neq 90$.

(a) Determine bootstrap p-value.

(b) Rewrite R program.

(c) Compute p-value with 3000 bootstraps.

EXERCISE 4.136. [4.136](#) *Permutation Test* Consider permutation test for two-sample problem.

(a) For $x' = (10, 15, 21)$ and $y' = (20, 25, 30)$, determine p-value.

(b) Approximate permutation test with 3000 resamples.

(c) Probability of distinct samples?

EXERCISE 4.137. [4.137](#) *Bootstrap z Distribution* Let z^* be drawn from discrete distribution with mass n^{-1} at $z_i = x_i - \bar{x} + \mu_0$. Determine $E(z^*)$ and $V(z^*)$.

EXERCISE 4.138. [4.138](#) *Bootstrap t-Test Value* For Example 4.9.3, show $t = 0.84$ and p-value is 0.20.

EXERCISE 4.139. 4.139 *Bootstrap Median Test* For Example 4.9.3, obtain bootstrap test based on medians for $H_0: \mu = 90$ vs $H_1: \mu > 90$.

EXERCISE 4.140. 4.140 *Darwin Experiment Bootstrap* Consider Darwin's experiment on *Zea mays*.

- (a) Obtain bootstrap test keeping pairing intact.
 (b) Write R program and compare p-value.

本章小结

核心概念：

- 统计量：样本的函数，不依赖未知参数
- 点估计：MLE、矩估计；无偏性、偏差
- 置信区间：参数的合理取值范围；宽度随样本量增大而减小
- 假设检验：第一类和第二类错误的权衡

重要公式：

场景	置信区间/检验统计量
正态均值、已知 σ	$\bar{X} \pm z_{\alpha/2}\sigma/\sqrt{n}$
正态均值、未知 σ	$\bar{X} \pm t_{\alpha/2, n-1}S/\sqrt{n}$
正态方差	$\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}$
单样本 Z 检验	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$
单样本 t 检验	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$
拟合优度 χ^2	$\chi^2 = \sum \frac{(O-E)^2}{E} \approx \chi^2(k-1)$

8. 附录：公式推导

8.1. 通用 MLE 推导. 背景：最大似然估计的通用推导框架。

核心思想：MLE 选择使似然函数最大化的参数值。在正则条件下，MLE 满足似然方程 $\frac{\partial l(\theta)}{\partial \theta} = 0$ 。

渐近性质（不证）：在温和条件下， $\hat{\theta}$ 具有以下渐近性质：

- (1) 一致性： $\hat{\theta} \xrightarrow{P} \theta$
- (2) 渐近正态性： $\sqrt{n}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, I(\theta)^{-1})$ ，其中 $I(\theta)$ 是 Fisher 信息量
- (3) 渐近有效性：方差达到 Cramér-Rao 下界

这些性质使 MLE 成为现代统计推断的基石。

8.2. 指数分布 MLE 的推导. 背景：设 $X_1, \dots, X_n \sim \text{Exp}(\theta)$ ，即 $f(x) = \theta^{-1} \exp\{-x/\theta\}$ ， $x > 0$ 。

目标：求使似然函数最大化的 θ 值。

推导步骤：

1. 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta^{-1} \exp\{-x_i/\theta\} = \theta^{-n} \exp\{-\theta^{-1} \sum_{i=1}^n x_i\}.$$

2. 对数似然函数为

$$l(\theta) = -n \log \theta - \theta^{-1} \sum_{i=1}^n x_i.$$

3. 求导并设为零：

$$\frac{\partial l(\theta)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i = 0.$$

4. 解得

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

5. 验证这是最大值（二阶导数为负）：

$$\frac{\partial^2 l(\theta)}{\partial \theta^2} = \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^n x_i = -\frac{n}{\theta^2} < 0.$$

结论： $\hat{\theta} = \bar{X}$ 是 θ 的 MLE。由于 $\mathbb{E}(X) = \theta$ ，故它也是无偏的。

8.3. 二项分布 MLE 的推导. 背景： 设 $X \sim \text{Bernoulli}(\theta)$ ，对于随机样本 $X_1, \dots, X_n$ 。

目标： 求 θ 的 MLE。

推导步骤：

1. 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}.$$

2. 对数似然函数为

$$l(\theta) = \left(\sum_{i=1}^n x_i \right) \log \theta + \left(n - \sum_{i=1}^n x_i \right) \log(1 - \theta).$$

3. 求导并设为零：

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{\sum x_i}{\theta} - \frac{n - \sum x_i}{1 - \theta} = 0.$$

4. 解得

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

结论： 样本均值（样本比例）是 θ 的 MLE，也是无偏估计。

8.4. 正态分布 MLE 的推导. 背景: 设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 对于随机样本。

目标: 求 μ 和 σ^2 的 MLE。

推导步骤:

1. 对数似然函数为

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2.$$

2. 对 μ 求偏导并设为零:

$$\frac{\partial l}{\partial \mu} = -\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu} = \bar{x}.$$

3. 对 σ 求偏导并设为零 (先代入 $\hat{\mu}$):

$$\frac{\partial l}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \bar{x})^2 = 0 \implies \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

注意: $\hat{\sigma}^2$ 是有偏的, 因为

$$\mathbb{E}[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2.$$

无偏估计为 $S^2 = \frac{n}{n-1} \hat{\sigma}^2$ 。

8.5. 置信区间推导汇总. 背景: 置信区间构造的核心思想是找枢轴量。

枢轴量的定义: 设 $Q = q(X_1, \dots, X_n; \theta)$ 。如果 Q 的分布不依赖于 θ , 则称 Q 为枢轴量。

构造步骤:

- (1) 找一个枢轴量 Q
- (2) 确定 a, b 使得 $\mathbb{P}(a \leq Q \leq b) = 1 - \alpha$
- (3) 解不等式得到 θ 的置信区间

8.6. 正态均值置信区间 (已知方差) 的推导. 背景: 设 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, 其中 σ^2 已知, 推导 μ 的置信区间。

已知条件:

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- 标准化的随机变量 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$

目标: 找到 L 和 U 使得 $\mathbb{P}(L \leq \mu \leq U) = 1 - \alpha$

推导步骤:

1. 由标准正态分布的对称性:

$$\mathbb{P}(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha.$$

2. 代入 Z 的表达式:

$$\mathbb{P}\left(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha.$$

3. 利用不等式的代数运算：

$$\mathbb{P}\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

4. 因此置信区间为：

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right].$$

关键洞察： 区间以 $\bar{X}$ 为中心，宽度为 $2z_{\alpha/2}\sigma/\sqrt{n}$ ，随 $\sqrt{n}$ 减小。

8.7. 正态均值置信区间（未知方差）的推导。 背景：设 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ ，其中 σ^2 未知，用 S^2 估计。

已知条件：

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$
- $\bar{X}$ 与 S^2 独立

目标： 推导 μ 的置信区间

推导步骤：

1. 构造枢轴量：

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

2. 可以证明 $T \sim t(n-1)$ 。

3. 给定置信水平 $1 - \alpha$ ：

$$\mathbb{P}(-t_{\alpha/2, n-1} \leq T \leq t_{\alpha/2, n-1}) = 1 - \alpha.$$

4. 代入 T 并解出 μ ：

$$\mathbb{P}\left(\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}\right) = 1 - \alpha.$$

5. 因此置信区间为：

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}\right].$$

与已知方差情形的比较： 用 S 替代 σ ，用 t 分位数替代 z 分位数。由于 t 分布比正态分布更重尾，区间更宽，反映了用样本方差代替总体方差的不确定性。

8.8. 方差置信区间的推导。 背景：推导正态分布方差 σ^2 的置信区间。

已知条件： $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$

推导步骤：

1. 由卡方分布的性质：

$$\mathbb{P}\left(\chi_{1-\alpha/2, n-1}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{\alpha/2, n-1}^2\right) = 1 - \alpha.$$

2. 解出 σ^2 :

$$\mathbb{P}\left(\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}\right) = 1 - \alpha.$$

3. 因此置信区间为:

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right].$$

8.9. 假设检验的推导. 背景: 正态均值检验的推导。

已知方差情形:

1. 在 $H_0: \mu = \mu_0$ 下, $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ 。
2. 拒绝域为 $Z > z_\alpha$ (单侧) 或 $|Z| > z_{\alpha/2}$ (双侧)。
3. p 值定义为观察到比当前样本更极端结果的概率。

未知方差情形:

1. 在 $H_0: \mu = \mu_0$ 下, $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ 。
2. 拒绝域为 $|T| > t_{\alpha/2, n-1}$ 。
3. p 值由 t 分布计算。

8.10. 卡方统计量极限分布的推导. 背景: 拟合优度 χ^2 统计量的极限分布推导。

推导步骤:

1. 在 H_0 下, $O_i \sim \text{Binomial}(n, p_{i0})$, 因此 $\mathbb{E}(O_i) = E_i = np_{i0}$, $\text{var}(O_i) = np_{i0}(1-p_{i0})$ 。
2. 标准化: $Z_i = (O_i - E_i)/\sqrt{E_i}$ 。
3. 可以证明 Z_i 近似服从 $\mathcal{N}(0, 1-p_{i0})$, 且协方差矩阵不是单位矩阵 (因为 $\sum O_i = n$ 是约束)。
4. 因此

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \approx \chi^2(k-1).$$

自由度减 1 是因为约束 $\sum O_i = n$ 。

8.11. 蒙特卡洛方法的推导. 背景: 接受-拒绝算法的推导和收敛性分析。

逆 CDF 方法:

定理: 如果 $U \sim \text{Uniform}(0, 1)$, F 是连续分布函数, 则 $X = F^{-1}(U)$ 的分布函数为 F 。

证明: 设 $X = F^{-1}(U)$, 即 $X \leq x$ 当且仅当 $U \leq F(x)$ 。因此

$$\mathbb{P}(X \leq x) = \mathbb{P}(U \leq F(x)) = F(x).$$

证毕。

接受-拒绝算法:

1. 每次迭代的接受概率为

$$\mathbb{P}(\text{接受}) = \int \frac{f(y)}{Mg(y)} g(y) dy = \frac{1}{M} \int f(y) dy = \frac{1}{M}.$$

2. 因此平均接受次数为 M 。

3. 效率与 M 成反比。

收敛性： 由大数定律，接受的样本确实来自 $f(x)$ 。

8.12. Bootstrap 的理论基础. 背景：Bootstrap 的理论基础。

核心假设： 样本的经验分布函数 $\hat{F}_n$ 是真实分布 F 的良好估计。

Bootstrap 分布：

$$T^* \mid X_1, \dots, X_n \approx T \mid X_1, \dots, X_n$$

其中 $\approx$ 表示“分布近似”。

误差分析：

Bootstrap 的误差来源：

(1) 抽样变异性：由 B 的有限性引入

(2) 代理误差：由 $\hat{F}_n$ 逼近 F 引入

当样本量 n 足够大时，这两种误差都可以控制。

偏差校正 Bootstrap：

如果 $\hat{\theta}$ 有系统性偏差 ($\mathbb{E}[\hat{\theta}] \neq \theta$)，则 percentile bootstrap 区间可能有偏差。偏差校正因子：

$$\hat{a} = \Phi^{-1} \left(\frac{\#\{\hat{\theta}_b^* < \hat{\theta}\}}{B} \right).$$

偏差校正的置信区间为 $[\theta_{\alpha_1}^*, \theta_{\alpha_2}^*]$ ，其中 $\alpha_1 = \Phi(2\hat{a} + z_\alpha)$ ， $\alpha_2 = \Phi(2\hat{a} - z_\alpha)$ 。

1. 附录：公式推导

1.1. Gamma 分布的矩母函数推导. 背景 (Background) : 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions) :

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given) :

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal) : 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps) :

1. 根据矩母函数定义:

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换: 令 $y = \frac{x(1-\beta t)}{\beta}$, 则 $x = \frac{\beta y}{1-\beta t}$, $dx = \frac{\beta}{1-\beta t} dy$ 。
3. 代入积分 (要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$):

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论: 因此, $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$, 定义域为 $t < 1/\beta$ 。■

1.2. Gamma 分布的均值与方差推导. 背景 (Background) : 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$, 方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given) :

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal) : 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps) :

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数：

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$ ：

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差：

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论： 因此， $\mathbb{E}X = \alpha\beta$ ， $\text{var}(X) = \alpha\beta^2$ 。■

1.3. 卡方分布与 Gamma 分布的关系. 背景 (Background)： 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一，它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions)：

- n ：自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal)： 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps)：

1. 单个标准正态平方的分布：若 $Z \sim N(0, 1)$ ，则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性：若 $Y_1 \sim \Gamma(\alpha_1, \beta)$ ， $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立，则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布，且每个 $Z_i^2 \sim \Gamma(1/2, 2)$ ，根据可加性：

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论： 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

1.4. 边缘分布公式的推导. 背景 (Background)： 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal)： 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps)：

1. 从联合 cdf 出发，对 x_2 求导得到联合 pdf：

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

1.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

1.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。

2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。

3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导：

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则：

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论： $|J|$ 度量了变换下的面积元素缩放比例。■

1.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义：

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$ ：

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf：

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证：边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$ ，确实是合法的 pdf。

结论： 条件 pdf 公式得证。■

1.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发：

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望（即关于 X_1 求平均）：

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序：

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1)f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论: 全期望公式得证。■

1.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论: 条件均值的方差不超过原变量的方差, 等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

1.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论：故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

1.11. 相关系数范围的推导. 背景 (Background)：我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal)：证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps)：

1. Cauchy-Schwarz 不等式：对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差，令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$ ：

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方：

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此：

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论：故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

1.12. 二元正态条件分布的推导. 背景 (Background)：在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions)：

- μ_1, μ_2 ：边缘分布均值
- σ_1^2, σ_2^2 ：边缘分布方差
- ρ ：相关系数
- $f(x_1, x_2)$ ：二元正态联合密度

目标 (Goal)：求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps)：

1. 条件密度公式：

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1 \sqrt{2\pi}} \exp\left\{-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数)：

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1 - \rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1 \sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right]\right\}.$$

3. 关于 x_2 完全平方配方：

$$\frac{(x_2 - \mu_2)^2}{\sigma_2^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1 \sigma_2} = \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho \frac{x_1 - \mu_1}{\sigma_1} \right)^2 - \rho^2 \frac{(x_1 - \mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp \left\{ -\frac{(x_1 - \mu_1)^2}{2\sigma_1^2} \right\} \cdot \exp \left\{ -\frac{1}{2(1-\rho^2)} \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho \frac{x_1 - \mu_1}{\sigma_1} \right)^2 \right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp \left\{ -\frac{1}{2(1-\rho^2)} \left(\frac{x_2 - \mu_2}{\sigma_2} - \rho \frac{x_1 - \mu_1}{\sigma_1} \right)^2 \right\}.$$

6. 这正是均值为 $\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

1.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E} \left[\exp \left(t \sum_{i=1}^n k_i X_i \right) \right] = \mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

2. 问答记录

问题记录. 问题: ... 回答: ...

学习笔记.