

数理统计导论

Hogg, McKean, Craig

目录

Part 1

概率论基础

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分的类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 *notation*，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 概述

本章从概率论的公理化基础出发，逐步建立整套理论框架。我们将从集合论的语言开始，引入概率的严格定义，然后过渡到条件概率、独立性等核心概念，最终走向随机变量与期望的一般理论。这一脉络不仅是数理统计的基础，更是理解整个现代统计学的钥匙。

1. 1.1 Introduction

1.1. 为何需要概率论? 在科学研究中，我们经常面对这样的情境：在本质上相同的条件下，可以反复进行某种实验。例如，医学研究者关心新药的效果；经济学家关注某些商品的价格波动；农学家研究肥料对作物产量的影响。这种实验产生的结果在实验前无法确定预测——这正是随机现象的本质。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. 随机实验与样本空间. 若一个实验可以在相同条件下重复进行，且所有可能的结果 (outcome) 可以在实验前描述，我们就称其为随机实验 (random experiment)。所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

EXAMPLE 1.1 (例 1.1.1). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (例 1.1.2). 投掷一枚红骰子和一枚白骰子。令 *outcome* 为有序对 (红骰子点数，白骰子点数)。样本空间包含 36 个有序对： $\mathcal{C} = \{(1, 1), \dots, (6, 6)\}$ 。

1.3. 事件与概率的直观起源. 我们用小写 Roman 字母 (如 a, b, c) 表示 $\mathcal{C}$ 的元素，用大写 Roman 字母 (如 A, B, C) 表示 $\mathcal{C}$ 的子集，即事件 (event)。

设想进行 N 次重复实验。事件 A 发生的次数 (频率) 记为 f ，则 f/N 称为相对频率 (relative frequency)。当 N 增大时，相对频率趋于稳定，趋向某个数 p ——这正是事件 A 的概率 (probability)。

概率的相对频率解释依赖于实验可重复的条件。另一种观点是将概率视为主观信念 (贝叶斯学派)。无论采用哪种解释，1.3 节的概率数学性质都是一致的。

统计学的目的就是为随机实验提供数学模型，进而进行统计推断。

2. 1.2 Sets

2.1. 集合论基础. 集合 (set) 是现代数学的基本概念。若对象 x 属于集合 C , 记作 $x \in C$ 。

若集合 C 是有限的或与正整数集等势, 则称 C 为可数的 (countable)。

设 C 为样本空间。事件是 C 的子集。

DEFINITION 1.1 (定义 1.2.1). 事件 A 的补 (complement) A^c 是 C 中所有不属于 A 的元素构成的集合: $A^c = \{x \in C : x \notin A\}$ 。

空集 (empty set) 记为 ϕ 。注意 $C^c = \phi$, $\phi^c = C$ 。

DEFINITION 1.2 (定义 1.2.2). 若集合 A 的每个元素都是集合 B 的元素, 则称 A 是 B 的子集, 记作 $A \subset B$ 。若 $A \subset B$ 且 $B \subset A$, 则 $A = B$ 。

DEFINITION 1.3 (定义 1.2.3). 设 A 和 B 为事件。 A 和 B 的并 (union) $A \cup B$ 是所有属于 A 或属于 B 的元素构成的集合。

DEFINITION 1.4 (定义 1.2.4). 设 A 和 B 为事件。 A 和 B 的交 (intersection) $A \cap B$ 是所有同时属于 A 和 B 的元素构成的集合。

DEFINITION 1.5 (定义 1.2.5). 若 $A \cap B = \phi$, 则称 A 和 B 是不交的 (disjoint)。

可数并和可数交定义为

$$\bigcup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}, \quad \bigcap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}.$$

德摩根定律 (DeMorgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c.$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

EXAMPLE 1.3 (例 1.2.1). 设 $C = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。则

$$A^c = \{3, 4, \dots, 10\}, \quad A \cup B = \{1, 2, 3, 4\}, \quad A \cap B = \{2\},$$

$$A \cap C = \phi, \quad B \cap C = \{3, 4\}.$$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} A_n$ 。

2.2. 集合函数. 集合函数 (set function) 是将集合映射到实数的函数。

EXAMPLE 1.4 (例 1.2.2). 设 $\mathcal{C} = \mathbb{R}$, $Q(A)$ 为 A 中正整数的个数。若 $A = \{x : 0 < x < 5\}$, 则 $Q(A) = 4$ 。

EXAMPLE 1.5 (例 1.2.3). 设 $\mathcal{C} = \mathbb{R}^2$, $Q(A)$ 为 A 的面积。若 $A = \{(x, y) : x^2 + y^2 \leq 1\}$ (单位圆盘), 则 $Q(A) = \pi$ 。

集合函数常用求和或积分定义。记号:

$$\sum_A f(x) \text{ 表示在所有 } x \in A \text{ 上求和, } \int_A f(x) dx \text{ 表示在集合 } A \text{ 上的积分.}$$

3. 1.3 The Probability Set Function

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。¹

DEFINITION 1.6 (定义 1.3.1 (概率)). 设 $\mathcal{C}$ 为样本空间, $\mathcal{B}$ 为事件域。函数 $\mathbb{P} : \mathcal{B} \rightarrow \mathbb{R}$ 满足以下三条条件则称为概率集函数:

- (1) $\mathbb{P}(A) \geq 0$, 对所有 $A \in \mathcal{B}$
- (2) $\mathbb{P}(\mathcal{C}) = 1$
- (3) 若 $\{A_n\}$ 为两两不相交的事件序列, 则

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

若事件序列两两不相交, 称其为互不相容的 (mutually exclusive)。若其并为 $\mathcal{C}$, 则构成 $\mathcal{C}$ 的一个划分 (partition)。

概率集函数告诉我们在事件域上概率如何分布。从这三条公理出发, 可以推导出概率论的所有其他结果。²

THEOREM 1.1 (定理 1.3.1). 对每个事件 $A \in \mathcal{B}$, $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ 。

证明. 由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$, 结合公理 (2) 和 (3) 得

$$1 = \mathbb{P}(A) + \mathbb{P}(A^c).$$

□

THEOREM 1.2 (定理 1.3.2). $\mathbb{P}(\phi) = 0$ 。

EXAMPLE 1.6 (例 1.3.1). 从 52 张扑克牌中随机抽取一张。设 A 为抽到 A 的事件, B 为抽到红桃的事件。则 $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52} = \frac{4}{13}$ 。

¹详细推导见附录 ??。

²详细推导见附录 ??。

等可能性情形 (Equilikely Case): 若样本空间 $\mathcal{C} = \{x_1, x_2, \dots, x_m\}$ 有限, 且每个 outcome 等概率 $p_i = 1/m$, 则

$$\mathbb{P}(A) = \sum_{x_i \in A} \frac{1}{m} = \frac{\#(A)}{m}.$$

4. 1.4 Conditional Probability and Independence

4.1. Conditional Probability. 我们经常需要在已知某些信息发生的条件下, 对事件概率进行调整。这就是条件概率 (conditional probability) 的直观来源。

DEFINITION 1.7 (定义 1.4.1 (条件概率)). 设 $\mathbb{P}(B) > 0$, 在事件 B 已发生的条件下, 事件 A 的条件概率定义为

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

由条件概率定义可直接导出乘法法则 (multiplication rule):

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) = \mathbb{P}(B) \cdot \mathbb{P}(A | B).$$

推广到 n 个事件:

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right).$$

全概率公式 (Law of Total Probability): 设 $\{B_i\}$ 为 $\mathcal{C}$ 的一个划分, 则对任意事件 A ,

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i).$$

THEOREM 1.3 (定理 1.4.1 (贝叶斯公式)). 设 $\{B_i\}$ 为 $\mathcal{C}$ 的一个划分, $\mathbb{P}(B_i) > 0$. 则对任意事件 A ($\mathbb{P}(A) > 0$),

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i)}.$$

术语: $\mathbb{P}(B_j)$ 为先验概率 (prior probability), $\mathbb{P}(B_j | A)$ 为后验概率 (posterior probability), $\mathbb{P}(A | B_j)$ 为似然 (likelihood)。

贝叶斯公式不仅仅是一个计算工具, 更提供了一种思考不确定性的思维方式。³

EXAMPLE 1.7 (例 1.4.1 (医学检测)). 设某疾病患病率为 1%, 检测准确率为 99%。令 $D = \{\text{患病}\}$, $+= \{\text{检测阳性}\}$ 。则

$$\mathbb{P}(D | +) = \frac{\mathbb{P}(D) \cdot \mathbb{P}(+ | D)}{\mathbb{P}(D) \cdot \mathbb{P}(+ | D) + \mathbb{P}(D^c) \cdot \mathbb{P}(+ | D^c)} = \frac{0.01 \cdot 0.99}{0.01 \cdot 0.99 + 0.99 \cdot 0.01} = \frac{1}{2}.$$

即使检测准确率高达 99%, 检测阳性者真正患病的概率只有 50%!

³详细讨论见附录 ??。

4.2. 1.4.1 Independence.

DEFINITION 1.8 (定义 1.4.2 (独立性)). 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$, 则称事件 A 与 B 相互独立 (*independent*), 记作 $A \perp B$ 。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时, 独立性等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$ 或 $\mathbb{P}(B | A) = \mathbb{P}(B)$ 。

EXAMPLE 1.8 (例 1.4.2). 抛掷两枚独立硬币。设 A 为第一枚正面朝上, B 为第二枚正面朝上。则 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$, 且 $\mathbb{P}(A \cap B) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B)$, 故 $A \perp B$ 。

DEFINITION 1.9 (定义 1.4.3 (相互独立)). 事件序列 $\{A_i : i \in I\}$ 相互独立, 若对任意有限子集 $\{i_1, \dots, i_k\}$,

$$\mathbb{P}\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k \mathbb{P}(A_{i_j}).$$

Warning: 两两独立 (pairwise independent) 不一定意味着相互独立!⁴

5. 1.5 Random Variables

样本空间 $\mathcal{C}$ 的元素可能不是数字, 这在描述和分析上会带来不便。我们需要一个规则, 将 $\mathcal{C}$ 的每个元素映射到一个实数——这正是随机变量 (random variable) 的思想。

随机变量 (random variable) 是从样本空间 $\mathcal{C}$ 到实数的函数: $X : \mathcal{C} \rightarrow \mathbb{R}$ 。

通常用大写字母 X, Y, Z 表示随机变量, 用小写字母 x, y, z 表示具体取值。

随机变量可分为:

- 离散随机变量 (discrete): 取值可数
- 连续随机变量 (continuous): 取值充满区间, 不可数

给定随机变量 X , 它的取值空间 $\mathcal{D}$ 成为新的样本空间。 X 不仅诱导了新的样本空间, 还诱导了一个概率分布——这正是“分布” (distribution) 概念的起源。

EXAMPLE 1.9 (例 1.5.1). 抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$ 。定义 X 为正面出现的次数: $X(HH) = 2, X(HT) = X(TH) = 1, X(TT) = 0$ 。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。

6. 1.6 Discrete Random Variables

DEFINITION 1.10 (定义 1.6.1 (概率质量函数)). 设 X 为离散随机变量。函数 $p_X(x) = \mathbb{P}(X = x)$ 称为概率质量函数 (*probability mass function, pmf*)。

pmf 满足: $p_X(x) \geq 0$ 对所有 x , 且 $\sum_x p_X(x) = 1$ 。

伯努利分布 (Bernoulli): $X \sim \text{Bernoulli}(p)$, 取值 $\{0, 1\}$,

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

⁴反例见附录 ??。

二项分布 (Binomial): $X \sim \text{Bin}(n, p)$,

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

这是 n 次独立伯努利试验中成功的次数。

泊松分布 (Poisson): $X \sim \text{Poisson}(\lambda)$,

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

泊松分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限分布——这揭示了离散分布之间的深刻联系。⁵

7. 1.7 Continuous Random Variables

连续随机变量的取值充满一个或多个区间，不可数。

DEFINITION 1.11 (定义 1.7.1 (概率密度函数)). 设 X 为连续随机变量。若存在非负函数 $f_X(x)$ 使得

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x) dx$$

对任意 $a < b$ 成立，则称 $f_X(x)$ 为概率密度函数 (*probability density function, pdf*)。

pdf 满足: $f_X(x) \geq 0$ 对所有 x ，且 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。

Warning: $f_X(x)$ 可以大于 1! 这与 pmf 的 $p_X(x) \leq 1$ 形成对比。

正态分布 (Normal/Gaussian): $X \sim N(\mu, \sigma^2)$,

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad -\infty < x < \infty.$$

指数分布 (Exponential): $X \sim \text{Exp}(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $x > 0$ 。

8. 1.8 Expectation of a Random Variable

期望 (expected value) 是随机变量最重要的一致性度量。它描述了分布的“中心位置”。

DEFINITION 1.12 (定义 1.8.1 (数学期望)). 随机变量 X 的期望:

- 离散型: $\mathbb{E}X = \sum_x x \cdot p_X(x)$
- 连续型: $\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$

要求级数或积分绝对收敛。

EXAMPLE 1.10 (例 1.8.1). 设 X 为掷骰子的点数。则 $\mathbb{E}X = \frac{1}{6}(1+2+3+4+5+6) = 3.5$ 。

期望的线性性是概率论中最重要、最有用的性质之一。⁶

⁵详细推导见附录 ??。

⁶详细证明见附录 ??。

THEOREM 1.4 (定理 1.8.1 (期望的线性性)). 对任意随机变量 X, Y 和常数 a, b :

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y.$$

关键点: 无需 X, Y 相互独立!

方差 (variance) 度量分布的离散程度。⁷

THEOREM 1.5 (定理 1.8.2 (方差公式)).

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2,$$

其中 $\mu = \mathbb{E}X$ 。

THEOREM 1.6 (定理 1.8.3 (方差的性质)). (1) $\text{var}(aX + b) = a^2 \text{var}(X)$

(2) 若 $X_1, \dots, X_n$ 相互独立, 则 $\text{var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{var}(X_i)$

9. 1.9 Some Special Expectations

两个随机变量之间的”共同变化”程度, 用协方差 (covariance) 来度量。

DEFINITION 1.13 (定义 1.9.1 (协方差)).

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y.$$

协方差的性质:

- (1) $\text{cov}(X, X) = \text{var}(X)$
- (2) $\text{cov}(X, Y) = \text{cov}(Y, X)$
- (3) $\text{cov}(aX + b, Y) = a\text{cov}(X, Y)$
- (4) $\text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y)$
- (5) 若 $X \perp\!\!\!\perp Y$, 则 $\text{cov}(X, Y) = 0$

相关系数 (correlation) 将协方差标准化, 消除了量纲的影响。

DEFINITION 1.14 (定义 1.9.2 (相关系数)).

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}.$$

$-1 \leq \text{corr}(X, Y) \leq 1$ 。相关系数衡量的是两个变量之间的线性关系强度。

10. 1.10 Important Inequalities

概率论中有几个基本不等式, 它们在理论证明和实际应用中都非常重要。

⁷详细推导见附录 ??。

THEOREM 1.7 (Markov 不等式). 若 X 为随机变量, $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}.$$

特别地, 取 $g(X) = X^2$, $a = k^2$, 得

$$\mathbb{P}(|X| \geq k) \leq \frac{\mathbb{E}[X^2]}{k^2}.$$

Markov 不等式的意义在于: 它仅用期望就能给出概率的上界, 而不需要知道分布的完整信息。⁸

THEOREM 1.8 (Chebyshev 不等式). 设 $\mu = \mathbb{E}X$, $\sigma^2 = \text{var}(X)$ 。则对任意 $k > 0$,

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}.$$

Chebyshev 不等式是 Markov 不等式的直接推论。它告诉我们: 无论分布是什么, 至少 $1 - 1/k^2$ 的概率质量落在 $\mu \pm k\sigma$ 区间内。

REMARK. *Cauchy-Schwarz* 不等式表明: 对于任意随机变量 X 和 Y , 有

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}.$$

这在概率论中应用广泛, 例如可用来证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。

Summary

本章建立了概率论的基本框架:

- (1) **概率公理化**: 从相对频率的直观性质出发, 建立了概率的公理化定义
- (2) **条件概率与贝叶斯公式**: 提供了更新信息的数学工具
- (3) **独立性**: 刻画了两个事件之间的概率关系
- (4) **随机变量**: 从集合论过渡到数值函数, 为分布理论奠定基础
- (5) **期望与方差**: 分别度量分布的中心位置和离散程度
- (6) **协方差与相关系数**: 度量两个随机变量的联合变化趋势
- (7) **重要不等式**: Markov、Chebyshev、Cauchy-Schwarz

这些概念相互关联, 共同构成了数理统计的基石。理解它们之间的有机联系, 比单纯记忆公式更重要。

Exercises

EXERCISE 1.1. 1.2.1 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$:

- (1) $C_1 = \{0, 1, 2\}$, $C_2 = \{2, 3, 4\}$
- (2) $C_1 = \{x : 0 < x < 2\}$, $C_2 = \{x : 1 \leq x < 3\}$

EXERCISE 1.2. 1.3.1 设 $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.4$, $\mathbb{P}(A \cap B) = 0.1$ 。求:

- (1) $\mathbb{P}(A \cup B)$

⁸详细证明见附录 ??。

$$(2) \mathbb{P}(A \mid B)$$

$$(3) \mathbb{P}(B \mid A)$$

EXERCISE 1.3. 1.4.1 某箱中有 5 个红球和 3 个白球。无放回地抽取 3 个球。求恰好抽到 2 个红球的概率。

EXERCISE 1.4. 1.5.1 设 $X \sim N(100, 225)$ 。求：

$$(1) \mathbb{P}(X < 95)$$

$$(2) \mathbb{P}(90 < X < 110)$$

