

数理统计导论

Hogg, McKean, Craig

目录

Part 1. 概率论基础	5
引言：从随机性中学习	7
引言：从随机性中学习	7
1. 为什么需要概率论?	7
2. 教材内容预览	7
3. 这三章的内在逻辑	10
4. 学习方法建议	10
5. 习题说明	11
Chapter 1. Probability and Distributions	13
Chapter 1 概述	13
1. 1.1 Introduction	13
2. 1.2 Sets	14
3. 1.3 The Probability Set Function	15
4. 1.4 Conditional Probability and Independence	16
5. 1.5 Random Variables	18
6. 1.6 Discrete Random Variables	18
7. 1.7 Continuous Random Variables	19
8. 1.8 Expectation of a Random Variable	19
9. 1.9 Some Special Expectations	20
10. 1.10 Important Inequalities	20
Summary	21
Exercises	21
Chapter 2. 二元随机变量分布	23
Chapter 2 概述	23
1. 2.1 从一元到二元	23
2. 2.2 变换：寻找新视角	24
3. 2.3 条件分布：信息的价值	25
4. 2.4 独立性：变量间的”无关系”	25
5. 2.5 相关性：线性关联的度量	26
6. 2.6 二元正态：最重要的二元分布	26

Chapter 3. 一些特殊分布	29
Chapter 3 概述	29
1. 3.1 从伯努利到二项：计数的科学	29
2. 3.2 泊松分布：稀有事件的世界	31
3. 3.3 伽马、卡方与贝塔分布	31
4. 3.4 正态分布：统计学的女王	33
5. 3.5 多元正态分布	34
6. 3.6 t 分布与 F 分布	34
本章小结	35
Chapter 4. Some Elementary Statistical Inferences	37
Chapter 4 Overview	37
1. 4.1 Sampling and Statistics	37
2. 4.2 Point Estimation	38
3. 4.3 Confidence Intervals	40
4. 4.4 Hypothesis Testing	41
5. 4.5 Chi-Square Tests	42
6. 4.6 Monte Carlo Methods	43
7. 4.7 Bootstrap Methods	43
Exercises	44
本章小结	58
8. 附录：公式推导	58
1. 问答记录	64

Part 1

概率论基础

引言：从随机性中学习

1. 为什么需要概率论？

当我们掷一枚硬币时，结果是“正面”还是“反面？”在单次实验中，答案似乎是确定的——但我们无法准确预测。这看似矛盾的现象揭示了一个深刻的真理：**随机性并非无知，而是世界的固有属性。**

数理统计 (mathematical statistics) 的核心问题是：给定一组带有随机性的观测数据，我们如何从中提取关于未知真理的信息？

要回答这个问题，我们必须首先拥有描述随机现象的数学语言。这正是概率论 (probability theory) 存在的意义。概率论提供了一套严谨的公理体系，使我们能够：

- 量化“可能性的”大小（概率）；
- 描述随机变量的行为（分布）；
- 研究多个随机变量之间的关系（相关性、独立性）；
- 在大样本极限下揭示隐藏的规律（中心极限定理）。

正如微积分为物理学提供了描述连续变化的工具，概率论为数理统计提供了描述随机性的工具。**没有坚实的概率论基础，统计推断将成为无本之木。**

REMARK. 这部分类比是否恰当？微积分 *vs* 概率论

2. 教材内容预览

本书 (Hogg, McKean & Craig, *Introduction to Mathematical Statistics*) 的前三章构建了概率论的基础设施，为后续的统计推断做好铺垫。这是一场从具体到抽象、从低维到高维的旅程。

2.1. 第一章：概率与分布 (Probability and Distributions). 第一章从最基本的问题出发：如何用数学语言描述“可能性？”

1. 概率公理化. 我们从集合论开始，建立样本空间 (sample space) 和事件 (event) 的概念。然后引入概率集函数 (probability set function) P ，这是一个满足非负性、归一化、可列可加性的集合函数。为什么需要公理化？因为我们需要一套在任何情况下都适用的严格规则，而不是依赖直觉。

2. 分布函数. 随机变量 (random variable) 是将随机现象数量化的桥梁。对于随机变量 X ，其累积分布函数 (cumulative distribution function, CDF) 定义为

$$F_X(x) = \mathbb{P}(X \leq x).$$

CDF 完整描述了随机变量的概率行为。对于离散型随机变量，我们用概率质量函数 (probability mass function, pmf) $p_X(x) = \mathbb{P}(X = x)$ ；对于连续型随机变量，我们用概率密度函数 (probability density function, pdf) $f_X(x)$ ，满足 $\mathbb{P}(a < X \leq b) = \int_a^b f_X(x) dx$ 。

为什么需要同时引入 CDF、pmf、pdf？这三种描述适用于不同场景。CDF 是最一般的概念；pmf 适用于离散型变量（如二项分布）；pdf 适用于连续型变量（如正态分布）。

3. 条件概率与贝叶斯公式. 条件概率 (conditional probability) $P(A | B)$ 刻画了在已知 B 发生的前提下 A 发生的可能性。贝叶斯公式 (Bayes' theorem)

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

是统计推断的基石——它允许我们从“结果反”向推断“原因”的概率。

4. 条件期望. 条件期望 (conditional expectation) $\mathbb{E}(X | Y = y)$ 是期望的概念在知道另一个变量信息下的推广。这在预测问题中至关重要：当我们知道 Y 的值时， X 的最佳预测恰好是条件期望。

5. 变换 (Transformations). 如果 X 是一个随机变量，当我们对其进行变换 $Y = g(X)$ 时，如何求 Y 的分布？这是统计学中的核心操作——我们经常需要对数据进行函数变换以简化分析。

6. 重要不等式. 本章以马尔可夫不等式 (Markov inequality) 和切比雪夫不等式 (Chebyshev inequality) 结尾。这些不等式建立了概率与矩之间的关系，尽管比较粗糙，但它们是证明大数定律等深刻结果的工具。

- 马尔可夫不等式: 若 $X \geq 0$ ，则 $\mathbb{P}(X \geq t) \leq \mathbb{E}(X)/t$
- 切比雪夫不等式: $\mathbb{P}(|X - \mathbb{E}X| \geq t) \leq \text{var}(X)/t^2$

为什么关注不等式而不是精确概率？因为在信息不完整时，不等式提供了我们能获得的最好估计。

本章还包含 R 语言的基本使用——通过 Monte Carlo 模拟来验证理论结果。这体现了统计学的实践性：理论必须经受计算的检验。

2.2. 第二章：多元分布 (Multivariate Distributions). 第二章将我们从单变量世界带入多变量世界。为什么要研究多个随机变量？因为现实中的现象往往是多因素共同作用的结果——人的身高与体重、教育的投入与产出、药物的剂量与疗效。

1. 联合分布与边缘分布. 对于两个随机变量 X 和 Y ，其联合分布 (joint distribution) $F_{XY}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$ 完整描述了它们的共同行为。从联合分布，我们可以“消去”一个变量得到边缘分布 (marginal distribution)：

$$F_X(x) = \lim_{y \rightarrow \infty} F_{XY}(x, y).$$

为什么需要边缘分布？因为我们有时只关心其中一个变量，而忽略另一个的影响。

2. 条件分布与条件期望. 给定 $Y = y$ 下 X 的条件分布为

$$F_{X|Y}(x | y) = \mathbb{P}(X \leq x | Y = y).$$

条件期望 $\mathbb{E}(X | Y = y)$ 是最佳预测——在均方误差意义下，它最小化了 X 的预测误差。

3. 相关系数. 相关系数 (correlation coefficient)

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$

度量了两个变量之间的线性关系强度。为什么关注“线性关系”？因为线性相关是最容易处理的依赖形式，它连接了概率论与线性代数。

4. 矩阵形式与线性变换. 当我们推广到 n 维随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ 时，协方差矩阵 (covariance matrix)

$$\Sigma = \text{cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})']$$

成为了描述多变量随机性的核心工具。线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ 的协方差矩阵为 $\mathbf{A}\Sigma\mathbf{A}'$ 。

为什么使用矩阵语言？因为矩阵提供了处理高维数据的紧凑 *notation*，同时揭示了线性变换与二次型之间的深刻联系。

5. 变换. 与单变量情况类似，我们需要研究多变量变换：若 (X, Y) 的联合分布已知，如何求 $(U, V) = g(X, Y)$ 的联合分布？在 g 是双射时，我们有变量变换公式。

2.3. 第三章：一些特殊分布 (Some Special Distributions). 第三章介绍统计学中最常用的概率分布。为什么要专门研究这些分布？因为它们在理论和应用中反复出现——掌握它们就像掌握基本词汇表。

1. 二项分布与相关分布. 二项分布 (binomial distribution) $B(n, p)$ 描述了 n 次独立 Bernoulli 试验中成功次数的分布。其近亲包括：

- **几何分布:** 首次成功出现的试验次数
- **负二项分布:** 第 r 次成功出现的试验次数
- **超几何分布:** 不放回抽样时的成功次数（用于总体规模有限的情形）

2. 泊松分布. 泊松分布 (Poisson distribution) $P(\lambda)$ 是稀有事件发生次数的极限分布。它具有独特的性质：若 $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 且独立，则 $X + Y \sim P(\lambda_1 + \lambda_2)$ (可加性)。

3. 伽马分布与卡方分布. 伽马分布 (gamma distribution) $\Gamma(\alpha, \beta)$ 是连接多种分布的统一框架：

- 当 $\alpha = n/2$, $\beta = 1/2$ 时，得到**卡方分布** $\chi^2(n)$ ——在方差估计和拟合优度检验中核心地位
- 当 $\alpha = 1$ 时，得到指数分布
- 卡方分布的加法性质：若 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$ 独立，则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

为什么卡方分布如此重要？因为它出现在样本方差的抽样分布中——而样本方差是统计推断的核心量。

4. 贝塔分布. 贝塔分布 (beta distribution) $\text{Beta}(\alpha, \beta)$ 是定义在 $(0, 1)$ 区间上的连续分布，常用于建模概率本身（当我们对概率参数 p 进行贝叶斯推断时，其后验分布往往是贝塔分布）。

5. 正态分布. 正态分布 (normal distribution) $N(\mu, \sigma^2)$ 是统计学中最重要的分布。高斯 (Gauss) 发现测量误差服从正态分布；中心极限定理表明大量独立小因素的总和近似正态分布。其特殊地位体现在：

- 样本均值 $\bar{X}$ 的精确分布（若总体正态）或渐近分布 (CLT)
- t 分布、 F 分布的构造基础
- 多元正态分布是线性模型的理论支柱

6. t 分布与 F 分布. 这两个分布起源于小样本推断。当我们用样本标准差 S 替代总体标准差 σ 时，统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从学生 t 分布 (Student's t distribution)。在方差分析和回归分析中， F 分布用于比较模型拟合优度。

3. 这三章的内在逻辑

纵观前三章，我们可以看到一条清晰的主线：

- (1) **描述单个随机变量.** 概率函数 $\rightarrow$ CDF/PDF $\rightarrow$ 期望与矩 $\rightarrow$ 特殊分布（第一、三章）
- (2) **描述多个随机变量的关系.** 联合分布 $\rightarrow$ 边缘/条件分布 $\rightarrow$ 相关系数 $\rightarrow$ 线性变换（第二、七章）
- (3) **连接理论与计算.** 理论结果 $\leftrightarrow$ R 模拟验证（每一章都有）

这条主线将在后续章节中继续延伸：当我们研究估计量的大样本性质时（第五章），概率论的极限定理会再次登场；当我们构建最优检验时（第八章），充分性（第七章）的概念将揭示降维的奥秘。

统计学不是孤立的技巧集合，而是一个有机联系的理论体系。掌握这个体系的内在逻辑，比记住具体公式更为重要。

4. 学习方法建议

基于前三章的内容特点，我们建议：

- **重视定义.** 统计学的每一个概念——随机变量、分布函数、独立性、条件期望——都需要精确理解其定义。
- **多做计算.** 通过具体例子（如正态分布的标准化、二项分布的概率计算）来巩固抽象概念。

- **理解证明.** 关键定理（如全概率公式、贝叶斯公式、变量变换公式）的证明揭示了概念的深层联系。
- **结合 R 实践.** Monte Carlo 模拟帮助我们将抽象概率与具体数值联系起来。
- **建立联系.** 时刻问自己：这个概念与之前学过的内容有什么关联？

5. 习题说明

每章末尾的习题（Exercises）是学习的重要组成部分。习题类型包括：

- 概念验证题：检验对基本定义和定理的理解
- 计算题：练习具体概率和期望的计算
- 证明题：训练数学推导能力
- R 编程题：通过模拟验证理论结果

我们强烈建议在阅读正文后独立完成所有习题。统计学的理解只有在解决问题的过程中才能真正深化。

CHAPTER 1

Probability and Distributions

Chapter 1 概述

本章从概率论的公理化基础出发，逐步建立整套理论框架。我们将从集合论的语言开始，引入概率的严格定义，然后过渡到条件概率、独立性等核心概念，最终走向随机变量与期望的一般理论。这一脉络不仅是数理统计的基础，更是理解整个现代统计学的钥匙。

1. 1.1 Introduction

1.1. 为何需要概率论? 在科学研究中，我们经常面对这样的情境：在本质上相同的条件下，可以反复进行某种实验。例如，医学研究者关心新药的效果；经济学家关注某些商品的价格波动；农学家研究肥料对作物产量的影响。这种实验产生的结果在实验前无法确定预测——这正是随机现象的本质。

统计学的主要目的，就是为随机现象提供数学模型，从而进行统计推断 (statistical inference)：从观测数据出发，对未知现象做出结论。而构建这种模型的理论基础，正是概率论。

1.2. 随机实验与样本空间. 若一个实验可以在相同条件下重复进行，且所有可能的结果 (outcome) 可以在实验前描述，我们就称其为随机实验 (random experiment)。所有可能结果的集合称为样本空间 (sample space)，记为 $\mathcal{C}$ 。

EXAMPLE 1.1 (例 1.1.1). 抛掷一枚硬币。令 H 表示正面， T 表示反面。样本空间为 $\mathcal{C} = \{H, T\}$ 。

EXAMPLE 1.2 (例 1.1.2). 投掷一枚红骰子和一枚白骰子。令 *outcome* 为有序对 (红骰子点数, 白骰子点数)。样本空间包含 36 个有序对: $\mathcal{C} = \{(1, 1), \dots, (6, 6)\}$ 。

1.3. 事件与概率的直观起源. 我们用小写 Roman 字母 (如 a, b, c) 表示 $\mathcal{C}$ 的元素，用大写 Roman 字母 (如 A, B, C) 表示 $\mathcal{C}$ 的子集，即事件 (event)。

设想进行 N 次重复实验。事件 A 发生的次数 (频率) 记为 f ，则 f/N 称为相对频率 (relative frequency)。当 N 增大时，相对频率趋于稳定，趋向某个数 p ——这正是事件 A 的概率 (probability)。

概率的相对频率解释依赖于实验可重复的条件。另一种观点是将概率视为主观信念 (贝叶斯学派)。无论采用哪种解释，1.3 节的概率数学性质都是一致的。

统计学的目的就是为随机实验提供数学模型，进而进行统计推断。

2. 1.2 Sets

2.1. 集合论基础. 集合 (set) 是现代数学的基本概念。若对象 x 属于集合 C , 记作 $x \in C$ 。

若集合 C 是有限的或与正整数集等势, 则称 C 为可数的 (countable)。

设 C 为样本空间。事件是 C 的子集。

DEFINITION 1.1 (定义 1.2.1). 事件 A 的补 (complement) A^c 是 C 中所有不属于 A 的元素构成的集合: $A^c = \{x \in C : x \notin A\}$ 。

空集 (empty set) 记为 ϕ 。注意 $C^c = \phi$, $\phi^c = C$ 。

DEFINITION 1.2 (定义 1.2.2). 若集合 A 的每个元素都是集合 B 的元素, 则称 A 是 B 的子集, 记作 $A \subset B$ 。若 $A \subset B$ 且 $B \subset A$, 则 $A = B$ 。

DEFINITION 1.3 (定义 1.2.3). 设 A 和 B 为事件。 A 和 B 的并 (union) $A \cup B$ 是所有属于 A 或属于 B 的元素构成的集合。

DEFINITION 1.4 (定义 1.2.4). 设 A 和 B 为事件。 A 和 B 的交 (intersection) $A \cap B$ 是所有同时属于 A 和 B 的元素构成的集合。

DEFINITION 1.5 (定义 1.2.5). 若 $A \cap B = \phi$, 则称 A 和 B 是不交的 (disjoint)。

可数并和可数交定义为

$$\bigcup_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for some } n\}, \quad \bigcap_{n=1}^{\infty} A_n = \{x : x \in A_n \text{ for all } n\}.$$

德摩根定律 (DeMorgan's Laws):

$$(A \cap B)^c = A^c \cup B^c, \quad (A \cup B)^c = A^c \cap B^c.$$

分配律:

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

EXAMPLE 1.3 (例 1.2.1). 设 $C = \{1, 2, \dots, 10\}$, $A = \{1, 2\}$, $B = \{2, 3, 4\}$, $C = \{3, 4, 5, 6\}$ 。则

$$A^c = \{3, 4, \dots, 10\}, \quad A \cup B = \{1, 2, 3, 4\}, \quad A \cap B = \{2\},$$

$$A \cap C = \phi, \quad B \cap C = \{3, 4\}.$$

单调序列: 若 $\{A_n\}$ 非递减 ($A_n \subset A_{n+1}$), 则 $\lim_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} A_n$ 。若非递增, 则 $\lim_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} A_n$ 。

2.2. 集合函数. 集合函数 (set function) 是将集合映射到实数的函数。

EXAMPLE 1.4 (例 1.2.2). 设 $\mathcal{C} = \mathbb{R}$, $Q(A)$ 为 A 中正整数的个数。若 $A = \{x : 0 < x < 5\}$, 则 $Q(A) = 4$ 。

EXAMPLE 1.5 (例 1.2.3). 设 $\mathcal{C} = \mathbb{R}^2$, $Q(A)$ 为 A 的面积。若 $A = \{(x, y) : x^2 + y^2 \leq 1\}$ (单位圆盘), 则 $Q(A) = \pi$ 。

集合函数常用求和或积分定义。记号:

$\sum_A f(x)$ 表示在所有 $x \in A$ 上求和, $\int_A f(x) dx$ 表示在集合 A 上的积分。

3. 1.3 The Probability Set Function

概率的定义由三条公理组成——这三条公理来源于相对频率的三条直观性质。¹

DEFINITION 1.6 (定义 1.3.1 (概率)). 设 $\mathcal{C}$ 为样本空间, $\mathcal{B}$ 为事件域。函数 $\mathbb{P} : \mathcal{B} \rightarrow \mathbb{R}$ 满足以下三条条件则称为概率集函数:

- (1) $\mathbb{P}(A) \geq 0$, 对所有 $A \in \mathcal{B}$
- (2) $\mathbb{P}(\mathcal{C}) = 1$
- (3) 若 $\{A_n\}$ 为两两不相交的事件序列, 则

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

若事件序列两两不相交, 称其为互不相容的 (mutually exclusive)。若其并为 $\mathcal{C}$, 则构成 $\mathcal{C}$ 的一个划分 (partition)。

概率集函数告诉我们在事件域上概率如何分布。从这三条公理出发, 可以推导出概率论的所有其他结果。²

THEOREM 1.1 (定理 1.3.1). 对每个事件 $A \in \mathcal{B}$, $\mathbb{P}(A) = 1 - \mathbb{P}(A^c)$ 。

证明. 由 $\mathcal{C} = A \cup A^c$ 和 $A \cap A^c = \phi$, 结合公理 (2) 和 (3) 得

$$1 = \mathbb{P}(A) + \mathbb{P}(A^c).$$

□

THEOREM 1.2 (定理 1.3.2). $\mathbb{P}(\phi) = 0$ 。

EXAMPLE 1.6 (例 1.3.1). 从 52 张扑克牌中随机抽取一张。设 A 为抽到 A 的事件, B 为抽到红桃的事件。则 $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) = \frac{4}{52} + \frac{13}{52} - \frac{1}{52} = \frac{16}{52} = \frac{4}{13}$ 。

¹详细推导见附录 ??。

²详细推导见附录 ??。

等可能性情形 (Equilikely Case): 若样本空间 $\mathcal{C} = \{x_1, x_2, \dots, x_m\}$ 有限, 且每个 outcome 等概率 $p_i = 1/m$, 则

$$\mathbb{P}(A) = \sum_{x_i \in A} \frac{1}{m} = \frac{\#(A)}{m}.$$

4. 1.4 Conditional Probability and Independence

4.1. Conditional Probability. 我们经常需要在已知某些信息发生的条件下, 对事件概率进行调整。这就是条件概率 (conditional probability) 的直观来源。

DEFINITION 1.7 (定义 1.4.1 (条件概率)). 设 $\mathbb{P}(B) > 0$, 在事件 B 已发生的条件下, 事件 A 的条件概率定义为

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

由条件概率定义可直接导出乘法法则 (multiplication rule):

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B | A) = \mathbb{P}(B) \cdot \mathbb{P}(A | B).$$

推广到 n 个事件:

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdots \mathbb{P}\left(A_n | \bigcap_{i=1}^{n-1} A_i\right).$$

全概率公式 (Law of Total Probability): 设 $\{B_i\}$ 为 $\mathcal{C}$ 的一个划分, 则对任意事件 A ,

$$\mathbb{P}(A) = \sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i).$$

THEOREM 1.3 (定理 1.4.1 (贝叶斯公式)). 设 $\{B_i\}$ 为 $\mathcal{C}$ 的一个划分, $\mathbb{P}(B_i) > 0$. 则对任意事件 A ($\mathbb{P}(A) > 0$),

$$\mathbb{P}(B_j | A) = \frac{\mathbb{P}(B_j) \cdot \mathbb{P}(A | B_j)}{\sum_i \mathbb{P}(B_i) \cdot \mathbb{P}(A | B_i)}.$$

术语: $\mathbb{P}(B_j)$ 为先验概率 (prior probability), $\mathbb{P}(B_j | A)$ 为后验概率 (posterior probability), $\mathbb{P}(A | B_j)$ 为似然 (likelihood)。

贝叶斯公式不仅仅是一个计算工具, 更提供了一种思考不确定性的思维方式。³

EXAMPLE 1.7 (例 1.4.1 (医学检测)). 设某疾病患病率为 1%, 检测准确率为 99%。令 $D = \{\text{患病}\}$, $+= \{\text{检测阳性}\}$ 。则

$$\mathbb{P}(D | +) = \frac{\mathbb{P}(D) \cdot \mathbb{P}(+ | D)}{\mathbb{P}(D) \cdot \mathbb{P}(+ | D) + \mathbb{P}(D^c) \cdot \mathbb{P}(+ | D^c)} = \frac{0.01 \cdot 0.99}{0.01 \cdot 0.99 + 0.99 \cdot 0.01} = \frac{1}{2}.$$

即使检测准确率高达 99%, 检测阳性者真正患病的概率只有 50%!

³详细讨论见附录 ??。

4.2. 1.4.1 Independence.

DEFINITION 1.8 (定义 1.4.2 (独立性)). 若 $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$, 则称事件 A 与 B 相互独立 (*independent*), 记作 $A \perp B$ 。

当 $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 时, 独立性等价于 $\mathbb{P}(A | B) = \mathbb{P}(A)$ 或 $\mathbb{P}(B | A) = \mathbb{P}(B)$ 。

EXAMPLE 1.8 (例 1.4.2). 抛掷两枚独立硬币。设 A 为第一枚正面朝上, B 为第二枚正面朝上。则 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$, 且 $\mathbb{P}(A \cap B) = 1/4 = \mathbb{P}(A) \cdot \mathbb{P}(B)$, 故 $A \perp B$ 。

DEFINITION 1.9 (定义 1.4.3 (相互独立)). 事件序列 $\{A_i : i \in I\}$ 相互独立, 若对任意有限子集 $\{i_1, \dots, i_k\}$,

$$\mathbb{P}\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k \mathbb{P}(A_{i_j}).$$

Warning: 两两独立 (pairwise independent) 不一定意味着相互独立!⁴

5. 1.5 Random Variables

样本空间 $\mathcal{C}$ 的元素可能不是数字, 这在描述和分析上会带来不便。我们需要一个规则, 将 $\mathcal{C}$ 的每个元素映射到一个实数——这正是随机变量 (random variable) 的思想。

随机变量 (random variable) 是从样本空间 $\mathcal{C}$ 到实数的函数: $X : \mathcal{C} \rightarrow \mathbb{R}$ 。

通常用大写字母 X, Y, Z 表示随机变量, 用小写字母 x, y, z 表示具体取值。

随机变量可分为:

- 离散随机变量 (discrete): 取值可数
- 连续随机变量 (continuous): 取值充满区间, 不可数

给定随机变量 X , 它的取值空间 $\mathcal{D}$ 成为新的样本空间。 X 不仅诱导了新的样本空间, 还诱导了一个概率分布——这正是“分布” (distribution) 概念的起源。

EXAMPLE 1.9 (例 1.5.1). 抛掷两枚硬币。样本空间 $\mathcal{C} = \{HH, HT, TH, TT\}$ 。定义 X 为正面出现的次数: $X(HH) = 2, X(HT) = X(TH) = 1, X(TT) = 0$ 。则 X 是取值在 $\{0, 1, 2\}$ 的离散随机变量。

6. 1.6 Discrete Random Variables

DEFINITION 1.10 (定义 1.6.1 (概率质量函数)). 设 X 为离散随机变量。函数 $p_X(x) = \mathbb{P}(X = x)$ 称为概率质量函数 (*probability mass function, pmf*)。

pmf 满足: $p_X(x) \geq 0$ 对所有 x , 且 $\sum_x p_X(x) = 1$ 。

伯努利分布 (Bernoulli): $X \sim \text{Bernoulli}(p)$, 取值 $\{0, 1\}$,

$$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p.$$

⁴反例见附录 ??。

二项分布 (Binomial): $X \sim \text{Bin}(n, p)$,

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

这是 n 次独立伯努利试验中成功的次数。

泊松分布 (Poisson): $X \sim \text{Poisson}(\lambda)$,

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

泊松分布是二项分布当 $n \rightarrow \infty$ 、 $p \rightarrow 0$ 、 $np = \lambda$ 固定时的极限分布——这揭示了离散分布之间的深刻联系。⁵

7. 1.7 Continuous Random Variables

连续随机变量的取值充满一个或多个区间，不可数。

DEFINITION 1.11 (定义 1.7.1 (概率密度函数)). 设 X 为连续随机变量。若存在非负函数 $f_X(x)$ 使得

$$\mathbb{P}(a < X < b) = \int_a^b f_X(x) dx$$

对任意 $a < b$ 成立，则称 $f_X(x)$ 为概率密度函数 (*probability density function, pdf*)。

pdf 满足: $f_X(x) \geq 0$ 对所有 x ，且 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。

Warning: $f_X(x)$ 可以大于 1! 这与 pmf 的 $p_X(x) \leq 1$ 形成对比。

正态分布 (Normal/Gaussian): $X \sim N(\mu, \sigma^2)$,

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad -\infty < x < \infty.$$

指数分布 (Exponential): $X \sim \text{Exp}(\lambda)$, $f(x) = \lambda e^{-\lambda x}$, $x > 0$ 。

8. 1.8 Expectation of a Random Variable

期望 (expected value) 是随机变量最重要的一致性度量。它描述了分布的“中心位置”。

DEFINITION 1.12 (定义 1.8.1 (数学期望)). 随机变量 X 的期望:

- 离散型: $\mathbb{E}X = \sum_x x \cdot p_X(x)$
- 连续型: $\mathbb{E}X = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$

要求级数或积分绝对收敛。

EXAMPLE 1.10 (例 1.8.1). 设 X 为掷骰子的点数。则 $\mathbb{E}X = \frac{1}{6}(1+2+3+4+5+6) = 3.5$ 。

期望的线性性是概率论中最重要、最有用的性质之一。⁶

⁵详细推导见附录 ??。

⁶详细证明见附录 ??。

THEOREM 1.4 (定理 1.8.1 (期望的线性性)). 对任意随机变量 X, Y 和常数 a, b :

$$\mathbb{E}[aX + bY] = a\mathbb{E}X + b\mathbb{E}Y.$$

关键点: 无需 X, Y 相互独立!

方差 (variance) 度量分布的离散程度。⁷

[定理 1.8.2 (方差公式)]

$$\text{var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2,$$

其中 $\mu = \mathbb{E}X$ 。

[定理 1.8.3 (方差的性质)]

$$(1) \text{var}(aX + b) = a^2 \text{var}(X)$$

$$(2) \text{若 } X_1, \dots, X_n \text{ 相互独立, 则 } \text{var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{var}(X_i)$$

9. 1.9 Some Special Expectations

两个随机变量之间的“共同变化”程度, 用协方差 (covariance) 来度量。

DEFINITION 1.13 (定义 1.9.1 (协方差)).

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y.$$

协方差的性质:

$$(1) \text{cov}(X, X) = \text{var}(X)$$

$$(2) \text{cov}(X, Y) = \text{cov}(Y, X)$$

$$(3) \text{cov}(aX + b, Y) = a\text{cov}(X, Y)$$

$$(4) \text{var}(X + Y) = \text{var}(X) + \text{var}(Y) + 2\text{cov}(X, Y)$$

$$(5) \text{若 } X \perp Y, \text{ 则 } \text{cov}(X, Y) = 0$$

相关系数 (correlation) 将协方差标准化, 消除了量纲的影响。

DEFINITION 1.14 (定义 1.9.2 (相关系数)).

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \cdot \text{var}(Y)}}.$$

$-1 \leq \text{corr}(X, Y) \leq 1$ 。相关系数衡量的是两个变量之间的线性关系强度。

10. 1.10 Important Inequalities

概率论中有几个基本不等式, 它们在理论证明和实际应用中都非常重要。

[Markov 不等式] 若 X 为随机变量, $g(X) \geq 0$, 则对任意 $a > 0$,

$$\mathbb{P}(g(X) \geq a) \leq \frac{\mathbb{E}[g(X)]}{a}.$$

⁷详细推导见附录 ??。

特别地, 取 $g(X) = X^2$, $a = k^2$, 得

$$\mathbb{P}(|X| \geq k) \leq \frac{\mathbb{E}[X^2]}{k^2}.$$

Markov 不等式的意义在于: 它仅用期望就能给出概率的上界, 而不需要知道分布的完整信息。⁸

[Chebyshev 不等式] 设 $\mu = \mathbb{E}X$, $\sigma^2 = \text{var}(X)$ 。则对任意 $k > 0$,

$$\mathbb{P}(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}.$$

Chebyshev 不等式是 Markov 不等式的直接推论。它告诉我们: 无论分布是什么, 至少 $1 - 1/k^2$ 的概率质量落在 $\mu \pm k\sigma$ 区间内。

[Cauchy-Schwarz 不等式]

$$|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]}.$$

Cauchy-Schwarz 不等式在概率论中有着广泛的应用, 例如证明相关系数 $|\text{corr}(X, Y)| \leq 1$ 。

Summary

本章建立了概率论的基本框架:

- (1) **概率公理化**: 从相对频率的直观性质出发, 建立了概率的公理化定义
- (2) **条件概率与贝叶斯公式**: 提供了更新信息的数学工具
- (3) **独立性**: 刻画了两个事件之间的概率关系
- (4) **随机变量**: 从集合论过渡到数值函数, 为分布理论奠定基础
- (5) **期望与方差**: 分别度量分布的中心位置和离散程度
- (6) **协方差与相关系数**: 度量两个随机变量的联合变化趋势
- (7) **重要不等式**: Markov、Chebyshev、Cauchy-Schwarz

这些概念相互关联, 共同构成了数理统计的基石。理解它们之间的有机联系, 比单纯记忆公式更重要。

Exercises

EXERCISE 1.1. 1.2.1 求 $C_1 \cup C_2$ 和 $C_1 \cap C_2$:

- (1) $C_1 = \{0, 1, 2\}$, $C_2 = \{2, 3, 4\}$
- (2) $C_1 = \{x : 0 < x < 2\}$, $C_2 = \{x : 1 \leq x < 3\}$

EXERCISE 1.2. 1.3.1 设 $\mathbb{P}(A) = 0.3$, $\mathbb{P}(B) = 0.4$, $\mathbb{P}(A \cap B) = 0.1$ 。求:

- (1) $\mathbb{P}(A \cup B)$
- (2) $\mathbb{P}(A | B)$
- (3) $\mathbb{P}(B | A)$

⁸详细证明见附录 ??。

EXERCISE 1.3. 1.4.1 某箱中有 5 个红球和 3 个白球。无放回地抽取 3 个球。求恰好抽到 2 个红球的概率。

EXERCISE 1.4. 1.5.1 设 $X \sim N(100, 225)$ 。求：

(1) $\mathbb{P}(X < 95)$

(2) $\mathbb{P}(90 < X < 110)$

CHAPTER 2

多元随机变量及其分布

Chapter 2 概述

本章路线图：联合分布 $\rightarrow$ 边缘分布 $\rightarrow$ 条件分布 $\rightarrow$ 独立性 $\rightarrow$ 相关性 $\rightarrow$ 多元正态

1. 2.1 从一元到多元：为什么需要联合分布？

在一元情形，我们用 cdf $F_X(x) = \mathbb{P}(X \leq x)$ 描述单个随机变量的行为。但在许多场景中，单个变量的分布并不能回答我们的问题——我们需要知道多个变量如何共同变化。

核心问题：给定两个随机变量 X_1 和 X_2 ，如何描述它们的联合行为？

这促使我们建立联合分布理论。本章以二元情形为主，揭示多元分布的核心思想。

1.1. 随机向量与联合分布.

DEFINITION 2.1 (随机向量). 设样本空间为 $\mathcal{C}$ ， X_1 和 X_2 为定义在 $\mathcal{C}$ 上的两个随机变量。则 (X_1, X_2) 称为随机向量，其取值空间为 $\mathcal{D} = \{(x_1, x_2) : x_1 = X_1(c), x_2 = X_2(c), c \in \mathcal{C}\}$ 。

联合 cdf 是一元 cdf 的自然推广：

$$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2). \quad (1)$$

离散型用 pmf 描述：

$$p_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 = x_1, X_2 = x_2), \quad (2)$$

满足 $p \geq 0$ 且 $\sum \sum_{\mathcal{D}} p = 1$ 。

连续型用 pdf 描述：

$$F_{X_1, X_2}(x_1, x_2) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} f(w_1, w_2) dw_1 dw_2, \quad (3)$$

其中 $f \geq 0$ 且 $\int \int_{\mathcal{D}} f = 1$ 。

emark 与一元情形不同，这里的 $f(x_1, x_2)$ 可以大于 1！因为它是“密度”而非概率值。emark

几何直观：若把联合 pdf $z = f(x_1, x_2)$ 视作一张曲面，则 $\mathbb{P}((X_1, X_2) \in A)$ 就是该曲面下区域 A 上的体积。这是一元情形“曲线下面积”在二维的推广。

1.2. 边缘分布：积分即求和。核心问题：已知 (X_1, X_2) 的联合分布，如何得到单个 X_1 的分布？

直觉上，我们需要”忽略” X_2 的信息。具体做法是：

- **离散型：**对 x_2 求和
- **连续型：**对 x_2 积分

这引导我们得到边缘分布公式：¹

边缘 pmf:

$$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2). \quad (4)$$

边缘 pdf:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2. \quad (5)$$

emark[为什么叫”边缘”?] 在二维离散情形，将联合 pmf 列表，边缘分布恰好是每行（或每列）的”边缘”之和。这解释了名称的由来。emark

1.3. 期望的推广与线性性。设 $Y = g(X_1, X_2)$ 是新的随机变量，其期望为

$$\mathbb{E}Y = \int \int g(x_1, x_2) f(x_1, x_2) dx_1 dx_2 \quad (\text{连续型}).$$

关键发现：期望算子 E 对加法保持线性，无论 X_1, X_2 是否独立：²

$$\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2. \quad (6)$$

这为什么重要？在第 1 章我们学过独立随机变量之和的方差公式 $\text{var}(X_1 + X_2) = \text{var}(X_1) + \text{var}(X_2)$ 。期望的线性性是其基础——它无需独立性即可成立。

2. 2.2 变换：寻找新视角

给定 (X_1, X_2) 的分布，我们经常想研究其函数 $Y = u(X_1, X_2)$ 的分布。例如：

- 和 $Y = X_1 + X_2$ （两个随机变量之和）
- 商 $Y = X_1/X_2$ （比值）
- 极坐标变换 $(R, \Theta) = (\sqrt{X_1^2 + X_2^2}, \arctan(X_2/X_1))$

对于连续型，一一对应的变换有简洁的公式：³

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|. \quad (7)$$

其中 Jacobian 行列式

$$J = \det \begin{pmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{pmatrix} = \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1}. \quad (8)$$

¹推导见附录 ??。

²推导见附录 ??。

³推导见附录 ??。

为什么有 $|J|$? 这是面积元素的变换因子。在一元情形我们有 $f_Y(y) = f_X(h(y))|h'(y)|$; 二维情形类似, 只是用行列式度量了面积缩放比例。

3. 2.3 条件分布：信息的价值

核心问题：已知 X_1 的值, X_2 的分布会如何变化?

这就是条件分布要回答的问题。条件分布本质上是在 $X_1 = x_1$ 的条件下, 重新审视 X_2 的行为。

离散型条件 pmf: ⁴

$$p_{X_2|X_1}(x_2 | x_1) = \frac{p_{X_1, X_2}(x_1, x_2)}{p_{X_1}(x_1)}, \quad p_{X_1}(x_1) > 0. \quad (9)$$

连续型条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}, \quad f_{X_1}(x_1) > 0. \quad (10)$$

分子是联合密度, 分母是边缘密度。这个比值衡量的是, 在 $X_1 = x_1$ 的条件下, (x_1, x_2) 这个“点”有多“典型”。

由此定义条件期望:

$$\mathbb{E}[u(X_2) | x_1] = \int_{-\infty}^{\infty} u(x_2) f_{X_2|X_1}(x_2 | x_1) dx_2. \quad (11)$$

3.1. 全期望公式与 Rao-Blackwell 定理。 这里有一个深刻的定理, 它连接了条件与边缘: ⁵

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2). \quad (12)$$

这称为**全期望公式**。它的含义是: 对条件均值再取期望, 等于无条件期望。

更惊人的是方差的不等式:

$$\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2).$$

⁶

Rao-Blackwell 定理: 若用 X_2 估计 $\mu_2 = \mathbb{E}X_2$, 则条件均值 $E(X_2 | x_1)$ 比 X_2 本身更精确 (方差更小)。这在统计推断中极其重要——它告诉我们如何利用辅助信息改进估计。

⁴推导见附录 ??。

⁵推导见附录 ??。

⁶推导见附录 ??。

4. 2.4 独立性：变量间的”无关系”

核心问题：什么时候 X_1 和 X_2 互不影响？

若 X_1 与 X_2 独立，则知道 X_1 的值不会改变我们对 X_2 的认知。用条件分布的语言：

$$f_{X_2|X_1}(x_2 | x_1) = f_{X_2}(x_2) \quad (\text{不依赖于 } x_1) .$$

由此推出联合密度可分离：⁷

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv f_1(x_1)f_2(x_2). \quad (13)$$

一个实用的判据：

$$X_1 \text{ 与 } X_2 \text{ 独立} \iff f(x_1, x_2) \equiv g(x_1)h(x_2) \quad (\text{可分离变量}) . \quad (14)$$

独立性的后果：

- $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$
- $\text{cov}(X_1, X_2) = 0$

emark **逆命题不成立！** $\text{cov}(X_1, X_2) = 0$ 并不意味着独立性（除二元正态分布外）。
emark

这提醒我们：**不相关**（uncorrelated）和**独立**（independent）是两个不同概念。不相关只说明没有线性关系，但变量间可能存在非线性依赖。

5. 2.5 相关性：线性关联的度量

我们已经知道 $\text{cov}(X_1, X_2) = 0$ 不能完全刻画独立性。那么如何量化 X_1 与 X_2 之间的”关联程度”？

协方差 $\text{cov}(X_1, X_2)$ 存在一个问题：它依赖于 X_1, X_2 的量纲。例如，身高（cm）和体重（kg）的协方差与换算成英寸和磅时不同。

解决方案：先标准化，再求协方差：

$$\rho_{12} = \text{corr}(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sqrt{\text{var}(X_1)}\sqrt{\text{var}(X_2)}} = \frac{\text{cov}(X_1, X_2)}{\sigma_1\sigma_2}. \quad (15)$$

这就是相关系数（correlation coefficient）。

核心性质：⁸

- $-1 \leq \rho_{12} \leq 1$
- $|\rho_{12}| = 1 \iff X_2 = aX_1 + b$ （完美线性关系）
- $\rho_{12} = 0$ 称**不相关**

⁷推导见附录 ??。

⁸推导见附录 ??。

为什么是 $[-1, 1]$? 这来自 Cauchy-Schwarz 不等式:

$$|\text{cov}(X_1, X_2)| = |\mathbb{E}[(X_1 - \mu_1)(X_2 - \mu_2)]| \leq \sqrt{\mathbb{E}[(X_1 - \mu_1)^2] \cdot \mathbb{E}[(X_2 - \mu_2)^2]} = \sigma_1 \sigma_2.$$

emark[相关 vs 协方差] 协方差取决于量纲 (“米的协方差”vs“厘米的协方差”数值不同); 相关系数是无量纲的, 消除了单位影响。因此, 相关系数是更通用的“关联程度”度量。emark

6. 2.6 二元正态：最重要的二元分布

在所有二元分布中, 二元正态分布占据核心地位。它是一元正态分布在二维的自然推广。

为什么重要?

- (1) 边缘分布和条件分布都是正态的
- (2) 线性组合仍是正态
- (3) 不相关 $\iff$ 独立 (这是正态独有的优雅性质)
- (4) 多元正态是计量经济学、信号处理等领域的基石

DEFINITION 2.2 (二元正态分布). (X_1, X_2) 服从二元正态分布, 若其联合 pdf 为

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\},$$

记作 $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

五个参数的含义:

- μ_1, μ_2 : 边缘分布的均值
- σ_1^2, σ_2^2 : 边缘分布的方差
- ρ : 相关系数

emark[条件分布的几何直觉] 在二元正态中, 条件均值

$$\mathbb{E}(X_2 | x_1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1)$$

是 x_1 的线性函数。这意味着: 给定 $X_1 = x_1$, X_2 的最佳预测也是线性的, 其斜率由相关系数 ρ 决定。emark

关键性质:

- (1) 边缘分布: $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$
- (2) 条件分布:

$$X_2 | X_1 = x_1 \sim N \left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1} (x_1 - \mu_1), \sigma_2^2 (1 - \rho^2) \right)$$

9

- (3) $X_1 \perp\!\!\!\perp X_2 \iff \rho = 0$ (正态独有的“不相关 $\Rightarrow$ 独立”)
- (4) 任意线性组合 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, \text{var}(aX_1 + bX_2))$

⁹推导见附录 ??.

7. 2.7 多元推广

前述概念可以推广到 n 个随机变量。记随机向量 $\mathbf{X} = (X_1, \dots, X_n)'$ ，其联合 cdf 为

$$F_{\mathbf{X}}(\mathbf{x}) = \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n).$$

7.1. 边缘与条件分布. 边缘 pdf 通过 $n-1$ 重积分得到：

$$f_1(x_1) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, x_2, \dots, x_n) dx_2 \cdots dx_n.$$

条件分布定义为联合密度与边缘密度之比：

$$f_{2,\dots,n|1}(x_2, \dots, x_n | x_1) = \frac{f(x_1, x_2, \dots, x_n)}{f_1(x_1)}.$$

7.2. 多元独立性. n 个随机变量 $X_1, \dots, X_n$ 相互独立，当且仅当

$$f(x_1, x_2, \dots, x_n) \equiv f_1(x_1)f_2(x_2) \cdots f_n(x_n).$$

：两两独立 (pairwise independence) 不一定推出相互独立 (mutual independence)。Bernstein 的例子说明了这一点。

7.3. 线性组合的 mgf. 若 $X_1, \dots, X_n$ 相互独立， $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为

$$M_T(t) = \prod_{i=1}^n M_i(k_i t).^{10}$$

特别地，若 $X_1, \dots, X_n$ iid (独立同分布)，则 $T = \sum_{i=1}^n X_i$ 的 mgf 为

$$M_T(t) = [M(t)]^n.$$

8. 本章总结

概念	公式/描述
联合 cdf	$F_{X_1, X_2}(x_1, x_2) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2)$
边缘 pmf	$p_{X_1}(x_1) = \sum_{x_2} p_{X_1, X_2}(x_1, x_2)$
边缘 pdf	$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f(x_1, x_2) dx_2$
条件 pmf	$p_{X_2 X_1}(x_2 x_1) = p(x_1, x_2)/p_{X_1}(x_1)$
条件 pdf	$f_{X_2 X_1}(x_2 x_1) = f(x_1, x_2)/f_{X_1}(x_1)$
全期望	$\mathbb{E}[\mathbb{E}(X_2 X_1)] = \mathbb{E}X_2$
独立性	$f(x_1, x_2) = f_1(x_1)f_2(x_2)$
协方差	$\text{cov} = \mathbb{E}(X_1 X_2) - \mathbb{E}X_1 \mathbb{E}X_2$
相关系数	$\rho = \text{cov}/(\sigma_1 \sigma_2), -1 \leq \rho \leq 1$

¹⁰推导见附录 ??.

习题

EXERCISE 2.1. 2.1.1 设 X_1 和 X_2 的联合 pdf 为 $f(x_1, x_2) = x_1 + x_2$, $0 < x_1 < 1$, $0 < x_2 < 1$, 其他位置为零。求 X_1 的边缘 pdf。

EXERCISE 2.2. 2.2.1 设 (X_1, X_2) 的联合 pdf 为 $f(x_1, x_2) = 2$, $0 < x_1 < x_2 < 1$, 其他位置为零。求 $Y = X_1 + X_2$ 的分布。

EXERCISE 2.3. 2.3.1 设 X_1 和 X_2 具有联合 pdf $f(x_1, x_2) = x_1 + x_2$, $0 < x_1 < 1$, $0 < x_2 < 1$ 。求给定 $X_1 = x_1$ 时 X_2 的条件均值和条件方差。

EXERCISE 2.4. 2.4.1 证明：若 X_1 和 X_2 独立，则 $\mathbb{E}[g(X_1)h(X_2)] = \mathbb{E}[g(X_1)] \cdot \mathbb{E}[h(X_2)]$ 。

EXERCISE 2.5. 2.5.1 设 (X, Y) 具有联合 pdf $f(x, y) = x + y$, $0 < x < 1$, $0 < y < 1$ 。求相关系数 ρ 。

EXERCISE 2.6. 2.6.1 设 X_1, X_2, X_3 为三个独立同分布的随机变量，每个的 pdf 为 $f(x) = 2x$, $0 < x < 1$ 。求 $Y = \max\{X_1, X_2, X_3\}$ 的分布。