

5÷.{7ç+\& /å

> Q ; ; - J + E 2 M - * ` B ;




图 1. χ^2 分布的置信区间示意图。图中阴影区域为置信区间 $[(n-1)S^2/\chi_{\alpha/2, n-1}^2, (n-1)S^2/\chi_{1-\alpha/2, n-1}^2]$ 对应的统计量 $(n-1)S^2/\sigma^2$ 的取值范围，两侧红色区域为显著性水平 $\alpha/2$ 的拒绝域。

4. 4.4 Hypothesis Testing

假设检验回答一个根本性问题：**数据是否提供足够证据拒绝关于总体的某个声明？**

这本质上是一种“举证”逻辑：我们先假设某个声明为真 (H_0)，然后问：在这个假设下，当前数据出现的概率有多大？如果概率很小，我们就有理由拒绝这个假设。

核心概念：

- **原假设 H_0 ：**被检验的假设（通常代表“无效应”或“现状”）
- **备择假设 H_1 ：**与 H_0 对立的假设

在设定假设时，我们需要权衡两类错误：

	未拒绝 H_0	拒绝 H_0
H_0 为真	正确（置信度 $1 - \alpha$ ）	第一类错误（概率 α ）
H_0 为假	第二类错误（概率 β ）	正确（功效 $1 - \beta$ ）

显著性水平： $\alpha = \mathbb{P}(\text{第一类错误}) = \mathbb{P}(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$

自然的问题：为什么不能同时最小化两类错误？因为在固定样本量下，两类错误是此消彼长的——降低 α 会提高 β ，反之亦然。这正是统计推断中不确定性本质的体现。

EXAMPLE 4.6 (正态均值检验、已知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 已知。检验 $H_0 : \mu = \mu_0$ vs $H_1 : \mu > \mu_0$ (单侧检验)。

检验统计量：

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}. \quad (4.4.1)$$

在 α 水平下，当 $Z > z_\alpha$ 时拒绝 H_0 。¹³

¹³详细推导见附录 section 8.9。

EXAMPLE 4.7 (正态均值检验、未知方差). 设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 未知。检验 $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$ (双侧检验)。

检验统计量:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}. \quad (4.4.2)$$

在 α 水平下, 当 $|T| > t_{\alpha/2, n-1}$ 时拒绝 H_0 。¹⁴

p 值: 在 H_0 为真条件下, 观察到比当前样本更极端结果的概率。 p 值越小, 拒绝 H_0 的证据越强。

与置信区间的联系: 假设检验和置信区间在本质上是等价的——如果 μ_0 落在置信区间内, 我们就不拒绝 $H_0: \mu = \mu_0$; 反之则拒绝。

5. 4.5 Chi-Square Tests

直到现在, 我们讨论的都是连续型数据。但统计学同样关注**分类数据 (categorical data)**——即计数数据。例如: 选举中支持不同候选人的选民人数、不同药物治疗后的治愈/未治愈人数。

卡方检验的核心思想: 比较观测频数与期望频数。如果两者差异很大, 说明数据可能不服从假设的分布。

5.1. 拟合优度检验. 问题: 数据是否来自某个特定分布?

设 $O_1, \dots, O_k$ 是 k 个类别的观测频数, $E_i = np_{i,0}$ 是 H_0 下的期望频数。

检验统计量:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}. \quad (4.5.1)$$

在 H_0 下, $\chi^2 \approx \chi^2(k-1)$ (大样本近似)。拒绝 H_0 当 $\chi^2 > \chi_{\alpha, k-1}^2$ 。

直观理解: $(O_i - E_i)^2/E_i$ 衡量每个类别的偏差, 平方消去正负号, 除以 E_i 进行标准化, 求和得到总体偏差。¹⁵

includegraphics[width=0.7]R/chi-square-goodness.png

图 2. 自由度为 5 的卡方分布, 显著性水平 $\alpha = 0.05$ 的拒绝域 (右侧尾部)。当检验统计量 $\chi^2 > 11.07$ 时, 拒绝原假设。

例 1: 骰子公平性检验

投掷一枚均匀骰子 $n = 600$ 次, 观测到各面的次数记录如下:

点数 i	1	2	3	4	5	6	合计
观测频数 O_i	100	110	95	105	90	100	600

¹⁴详细推导见附录 section 8.9。

¹⁵详细推导见附录 section 8.10。

如果骰子是均匀的 (H_0 : 骰子公平), 每个面的期望频数为 $E_i = 600/6 = 100$ 。

计算 χ^2 统计量:

$$\begin{aligned}\chi^2 &= \sum_{i=1}^6 \frac{(O_i - E_i)^2}{E_i} = \frac{(100 - 100)^2}{100} + \frac{(110 - 100)^2}{100} + \frac{(95 - 100)^2}{100} + \frac{(105 - 100)^2}{100} + \frac{(90 - 100)^2}{100} + \frac{(100 - 100)^2}{100} \\ &= 0 + 1 + 0.25 + 0.25 + 1 + 0 = 2.5.\end{aligned}$$

自由度为 $k - 1 = 6 - 1 = 5$ 。在 $\alpha = 0.05$ 水平,

$$\chi_{0.05,5}^2 = 11.07.$$

由于 $\chi^2 = 2.5 < 11.07$, 我们**不拒绝** H_0 —— 没有足够证据认为这枚骰子不公平。

例 2: 遗传学中的 Hardy-Weinberg 平衡

Hardy-Weinberg 平衡 (遗传平衡定律) 是群体遗传学的基石: 在一个随机交配、无选择、无突变、无迁移的群体中, 基因型频率将保持世代不变。

设一个二等位基因位点, 等位基因频率为 p (A) 和 q (a), 则 Hardy-Weinberg 平衡下的基因型期望频率为:

$$p^2 \text{ (AA)}, \quad 2pq \text{ (Aa)}, \quad q^2 \text{ (aa)}, \quad p + q = 1.$$

数据: 在某人群中随机调查 300 人, 观测到:

基因型	AA	Aa	aa	合计
观测频数 O_i	100	50	150	300

首先由数据估计等位基因频率:

$$\hat{p} = \frac{2 \times 100 + 50}{2 \times 300} = \frac{250}{600} \approx 0.417, \quad \hat{q} = 1 - \hat{p} \approx 0.583.$$

在 Hardy-Weinberg 平衡假设下, 期望频数为:

$$E_{AA} = 300 \times \hat{p}^2 = 300 \times 0.417^2 \approx 52.1,$$

$$E_{Aa} = 300 \times 2\hat{p}\hat{q} = 300 \times 2 \times 0.417 \times 0.583 \approx 145.8,$$

$$E_{aa} = 300 \times \hat{q}^2 = 300 \times 0.583^2 \approx 102.1.$$

计算 χ^2 统计量:

$$\chi^2 = \frac{(100 - 52.1)^2}{52.1} + \frac{(50 - 145.8)^2}{145.8} + \frac{(150 - 102.1)^2}{102.1} \approx 44.1 + 63.0 + 22.5 = 129.6.$$

自由度为 $k - 1 = 3 - 1 = 2$ 。在 $\alpha = 0.05$ 水平, $\chi_{0.05,2}^2 = 5.99$ 。

由于 $\chi^2 = 129.6 > 5.99$, 我们**拒绝** H_0 —— 该人群的基因型分布显著偏离 Hardy-Weinberg 平衡, 可能受到自然选择、突变、迁移或其他进化因素的影响。

5.2. 独立性检验. 对于 $r \times c$ 列联表, 设 O_{ij} 为单元格 (i, j) 的观测频数。

在独立性假设下, 行合计与列合计的乘积除以总数给出期望频数:

$$E_{ij} = \frac{O_{i.} O_{.j}}{n}. \quad (4.5.2)$$

检验统计量:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}. \quad (4.5.3)$$

在 H_0 下, $\chi^2 \approx \chi^2((r-1)(c-1))$ 。

直观理解: 如果行变量与列变量独立, 则每个单元格的观测频数 O_{ij} 应该接近其期望 E_{ij} 。 χ^2 统计量衡量这种偏离程度——偏离越大, 行列不独立的可能性越高。

例 3: 吸烟与肺癌的关联性检验

下表记录了 400 人的吸烟状态与肺癌诊断结果:

	肺癌	无肺癌	合计
吸烟	60	140	200
不吸烟	20	180	200
合计	80	320	400

研究问题: 吸烟与肺癌是否独立?

在独立性假设下, 每个单元格的期望频数为 $E_{ij} = (\text{行合计} \times \text{列合计})/n$:

$$E_{11} = \frac{200 \times 80}{400} = 40, \quad E_{12} = \frac{200 \times 320}{400} = 160,$$

$$E_{21} = \frac{200 \times 80}{400} = 40, \quad E_{22} = \frac{200 \times 320}{400} = 160.$$

计算 χ^2 统计量:

$$\begin{aligned} \chi^2 &= \frac{(60 - 40)^2}{40} + \frac{(140 - 160)^2}{160} + \frac{(20 - 40)^2}{40} + \frac{(180 - 160)^2}{160} \\ &= \frac{400}{40} + \frac{400}{160} + \frac{400}{40} + \frac{400}{160} = 10 + 2.5 + 10 + 2.5 = 25. \end{aligned}$$

自由度为 $(r-1)(c-1) = (2-1)(2-1) = 1$ 。在 $\alpha = 0.05$ 水平, $\chi_{0.05,1}^2 = 3.84$ 。

由于 $\chi^2 = 25 > 3.84$, 我们**拒绝** H_0 ——吸烟与肺癌之间存在显著关联。进一步计算效应量:

$$\phi = \sqrt{\frac{\chi^2}{n}} = \sqrt{\frac{25}{400}} = 0.25,$$

表明吸烟与肺癌之间存在中等强度的正向关联。

例 4: 两种药物疗效比较

某制药公司希望比较药物 A 和药物 B 的疗效, 将 120 名患者随机分配到两组:

	治愈	未治愈	合计
药物 A	45	15	60
药物 B	30	30	60
合计	75	45	120

研究问题：两种药物的治愈率是否有显著差异？

在独立性假设下计算期望频数：

$$E_{11} = \frac{60 \times 75}{120} = 37.5, \quad E_{12} = \frac{60 \times 45}{120} = 22.5,$$

$$E_{21} = \frac{60 \times 75}{120} = 37.5, \quad E_{22} = \frac{60 \times 45}{120} = 22.5.$$

计算 χ^2 统计量：

$$\begin{aligned} \chi^2 &= \frac{(45 - 37.5)^2}{37.5} + \frac{(15 - 22.5)^2}{22.5} + \frac{(30 - 37.5)^2}{37.5} + \frac{(30 - 22.5)^2}{22.5} \\ &= \frac{56.25}{37.5} + \frac{56.25}{22.5} + \frac{56.25}{37.5} + \frac{56.25}{22.5} = 1.5 + 2.5 + 1.5 + 2.5 = 8. \end{aligned}$$

自由度为 $(2 - 1)(2 - 1) = 1$ 。在 $\alpha = 0.05$ 水平， $\chi_{0.05,1}^2 = 3.84$ 。

由于 $\chi^2 = 8 > 3.84$ ，我们**拒绝** H_0 ——两种药物的疗效存在显著差异。药物 A 的治愈率为 75%，显著高于药物 B 的 50%。

6. 4.6 Monte Carlo Methods

有些概率和期望无法解析计算——积分可能没有闭式解，分布可能过于复杂。这时，Monte Carlo 方法提供了一条出路。

核心思想：用随机模拟来近似计算。如果我们可以从某个分布抽样，就可以通过大量重复实验来估计任何期望。

大数定律保证了模拟的收敛性：

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \xrightarrow{P} \mathbb{E}[g(X)]. \quad (4.6.1)$$

这意味着：只要模拟次数足够多，样本均值可以任意接近真实期望。

接受-拒绝算法：当目标分布 $f(x)$ 难以直接抽样时，我们可以利用更容易抽样的提议分布 $g(x)$ ：

- (1) 选择提议分布 $g(x)$ ，满足 $f(x) \leq Mg(x)$ （对某个 $M > 1$ ）
- (2) 生成 $Y \sim g$ 和 $U \sim \text{Uniform}(0, 1)$ 独立
- (3) 若 $U \leq f(Y)/(Mg(Y))$ ，接受 $X = Y$ ；否则拒绝，返回步骤 2

接受概率为 $1/M$ 。¹⁶

¹⁶接受-拒绝算法的推导及收敛性证明见附录 section 8.11。

7. 4.7 Bootstrap Methods

核心困境：估计量的抽样分布是统计推断的基础，但这个分布在大多数情况下难以解析计算。例如，样本中位数 $\hat{m}$ 的分布无法用初等函数表达。

Bootstrap 的解决思路既简单又巧妙：**用重抽样近似抽样分布。**

Bootstrap 的核心假设：样本就像总体。如果我们有了一个“好”的样本，为什么不从这个样本中有放回地再次抽样，模拟重复实验的过程？

步骤：

- (1) 从原始样本中有放回地抽取 n 个观测，形成一个 bootstrap 样本 $X_1^*, \dots, X_n^*$
- (2) 计算 bootstrap 复制 $T^* = g(X_1^*, \dots, X_n^*)$
- (3) 重复步骤 1-2 多次（如 $B = 1000$ 次），得到 $T_1^*, \dots, T_B^*$
- (4) 用 $T_1^*, \dots, T_B^*$ 的经验分布近似 T 的抽样分布

percentile bootstrap 置信区间： θ 的 $100(1 - \alpha)\%$ 置信区间为

$$\left[T_{(\alpha B)}^*, T_{((1-\alpha)B)}^* \right]. \quad (4.7.1)$$

直觉：如果样本是总体的良好代表，那么从样本有放回抽样就是在模拟“从总体中抽取样本”的过程。 T^* 的分布反映了 T 的抽样分布的近似。¹⁷

Bootstrap 的强大之处在于它的通用性——几乎任何估计量都可以用 Bootstrap 近似其分布，不需要繁复的数学推导。这使它成为现代统计实践中的重要工具。

Exercises

EXERCISE 4.1. *4.1 Motor Lifetime Data Twenty motors were put on test under a high-temperature setting. The lifetimes in hours of the motors under these conditions are given below. Suppose we assume that the lifetime of a motor under these conditions, X , has a $\Gamma(1, \theta)$ distribution.*

- (a) Obtain a histogram of the data and overlay it with a density estimate. Based on this plot, do you think that the $\Gamma(1, \theta)$ model is credible?
- (b) Assuming a $\Gamma(1, \theta)$ model, obtain the maximum likelihood estimate $\hat{\theta}$ of θ and locate it on your histogram.
- (c) Obtain the sample median of the data. What parameter is it estimating?
- (d) Based on the mle, what is another estimate of the median of X ?

EXERCISE 4.2. *4.2 Baseball Player Weights Here are the weights of 26 professional baseball pitchers. Suppose we assume that the weight of a professional baseball pitcher is normally distributed with mean μ and variance σ^2 .*

- (a) Obtain a histogram of the data. Based on this plot, is a normal probability model credible?

¹⁷Bootstrap 的理论基础及更多细节见附录 section 8.12。

- (b) Obtain the maximum likelihood estimates of μ , σ^2 , σ , and μ/σ .
- (c) Using the binomial model, obtain the maximum likelihood estimate of the proportion p of professional baseball pitchers who weigh over 215 pounds.
- (d) Determine the mle of p assuming that the weight follows the normal probability model $N(\mu, \sigma^2)$.

EXERCISE 4.3. [4.3 Poisson Customer Arrivals](#) Suppose the number of customers X that enter a store between 9:00 a.m. and 10:00 a.m. follows a Poisson distribution with parameter θ . Suppose a random sample of the number of customers for 10 days results in values: 9, 7, 9, 15, 10, 13, 11, 7, 2, 12.

- (a) Determine the maximum likelihood estimate of θ . Show that it is an unbiased estimator.
- (b) Based on these data, obtain the realization of your estimator. Explain its meaning.

EXERCISE 4.4. [4.4 Verify Likelihood Equations](#) For Example 4.1.3, verify equations (4.1.4)-(4.1.8).

EXERCISE 4.5. [4.5 Order Statistics Probability](#) Let $X_1, X_2, \dots, X_n$ be a random sample from a continuous-type distribution.

- (a) Find $P(X_1 \leq X_2)$, $P(X_1 \leq X_2, X_1 \leq X_3)$, $\dots$, $P(X_1 \leq X_i, i = 2, 3, \dots, n)$.
- (b) Suppose the sampling continues until X_1 is no longer the smallest observation. Let Y equal the number of trials (not including X_1) until X_1 is no longer the smallest. Show that $P(Y = y) = \frac{1}{y(y+1)}$, $y = 1, 2, 3, \dots$.
- (c) Compute the mean and variance of Y if they exist.

EXERCISE 4.6. [4.6 Variance of PMF Estimator](#) Consider the estimator of the pmf in expression (4.1.10). We showed that this estimator is unbiased. Find the variance of the estimator and its mgf.

EXERCISE 4.7. [4.7 Scottish Schoolchildren Eye Colors](#) The data set on Scottish schoolchildren included the eye colors of the children. The frequencies of their eye colors are: Blue: 2978, Light: 6697, Medium: 7511, Dark: 5175. Use these frequencies to obtain a bar chart and an estimate of the associated pmf.

EXERCISE 4.8. [4.8 MLE of Poisson PMF](#) Assuming that the data in Example 4.1.6 were drawn from a Poisson distribution with mean λ , obtain the mle of λ and then use it to obtain the mle of the pmf. Compare the mle of the pmf to the nonparametric estimate.

EXERCISE 4.9. [4.9 Nonparametric Density Estimator](#) Consider the nonparametric estimator of a pdf.

- (a) Obtain its mean and determine the bias of the estimator.

- (b) Obtain the variance of the estimator.

EXERCISE 4.10. [4.10](#) *Brain Data Analysis* This data set consists of a sample of brain information recorded on 40 college students. The variables include gender, height, weight, three IQ measurements, and MRI counts.

- (a) Load the rda file and print the MRI data.
- (b) Obtain a histogram of the data. Comment on the shape.
- (c) Overlay the default density estimator. Comment on the shape.
- (d) Obtain the sample mean and standard deviation and overlay the normal pdf with these estimates. Comment on the fit.
- (e) Determine the proportions of the data within 1 and 2 standard deviations of the sample mean.

EXERCISE 4.11. [4.11](#) *Speed of Light Data* This is a famous data set on the speed of light recorded by the scientist Simon Newcomb.

- (a) Load the rda file. Discuss the data.
- (b) Obtain a histogram of the data. Comment on the shape.
- (c) Overlay the default density estimator. Comment on the shape.
- (d) Overlay the normal pdf with sample mean and standard deviation. Comment on the fit.
- (e) Determine the proportions of the data within 1 and 2 standard deviations of the sample mean.

EXERCISE 4.12. [4.12](#) *Normal Confidence Intervals* Let the observed value of the mean $\bar{X}$ and of the sample variance of a random sample of size 20 from a distribution that is $N(\mu, \sigma^2)$ be 81.2 and 26.5, respectively. Find respectively 90%, 95% and 99% confidence intervals for μ .

EXERCISE 4.13. [4.13](#) *Motor Lifetime –Hogg 4.2.2* Consider the data on the lifetimes of motors given in Exercise 4.1.1. Obtain a large sample 95% confidence interval for the mean lifetime of a motor.

EXERCISE 4.14. [4.14](#) *Gamma Distribution Inference* Suppose we assume that $X_1, X_2, \dots, X_n$ is a random sample from a $\Gamma(1, \theta)$ distribution.

- (a) Show that the random variable $(2/\theta) \sum_{i=1}^n X_i$ has a χ^2 -distribution with $2n$ degrees of freedom.
- (b) Using the random variable in part (a) as a pivot random variable, find a $(1 - \alpha)100\%$ confidence interval for θ .
- (c) Obtain the confidence interval for the data of Exercise 4.1.1.

EXERCISE 4.15. [4.15](#) *Baseball Weight Difference* In Example 4.2.4, for the baseball data, find the pooled t 95% confidence interval for the mean difference in weights between the pitchers and hitters.

EXERCISE 4.16. [4.16](#) *Left-handed Baseball Players* In the baseball data set, it was found that out of 59 baseball players, 15 were left-handed. Construct a 95% approximate confidence interval for p , the proportion of left-handed professional baseball players.

EXERCISE 4.17. [4.17](#) *Sample Size for CI Length* Let $\bar{X}$ be the mean of a random sample of size n from a distribution that is $N(\mu, 9)$. Find n such that $P(\bar{X} - 1 < \mu < \bar{X} + 1) = 0.90$, approximately.

EXERCISE 4.18. [4.18](#) *CI from Sample Data* Let a random sample of size 17 from the normal distribution $N(\mu, \sigma^2)$ yield $\bar{x} = 4.7$ and $s^2 = 5.76$. Determine a 90% confidence interval for μ .

EXERCISE 4.19. [4.19](#) *Sample Size for Half-length* Let $\bar{X}$ denote the mean of a random sample of size n from a distribution that has mean μ and variance $\sigma^2 = 10$. Find n so that the probability is approximately 0.954 that the random interval $(\bar{X} - 1/2, \bar{X} + 1/2)$ includes μ .

EXERCISE 4.20. [4.20](#) *Normal CI Length Comparison* Let $X_1, X_2, \dots, X_9$ be a random sample of size 9 from a distribution that is $N(\mu, \sigma^2)$.

- (a) If σ is known, find the length of a 95% confidence interval for μ .
- (b) If σ is unknown, find the expected value of the length of a 95% confidence interval for μ .
- (c) Compare these two answers.

EXERCISE 4.21. [4.21](#) *Prediction Interval* Let $X_1, X_2, \dots, X_n, X_{n+1}$ be a random sample of size $n + 1$, $n > 1$, from a distribution that is $N(\mu, \sigma^2)$. Find the constant c so that the statistic $c(\bar{X} - X_{n+1})/S$ has a t -distribution.

EXERCISE 4.22. [4.22](#) *Monte Carlo CI Coverage* Let $X_1, \dots, X_n$ be a random sample from a $N(0, 1)$ distribution. Simulate m confidence intervals and calculate the proportion that trap 0.

- (a) Set $n = 10$ and $m = 50$. Run the R code and find the proportion of successful confidence intervals.
- (b) Plot the intervals and comment on the variability of the lengths.

EXERCISE 4.23. [4.23](#) *Invariance of CI Coverage* In Exercise 4.2.11, show that setting $\mu = 0$ and $\sigma = 1$ is without loss of generality.

EXERCISE 4.24. [4.24](#) *Empirical Confidence Level* Change the code in the R function `getcis` so that it also returns the vector `ind` where $\text{ind}[i] = 1$ if the i th confidence interval is successful. Show that the empirical confidence level is $\text{mean}(\text{ind})$.

EXERCISE 4.25. [4.25](#) *Gamma CI via CLT* Let $\bar{X}$ denote the mean of a random sample of size 25 from a gamma-type distribution with $\alpha = 4$ and $\beta > 0$. Use the Central Limit Theorem to find an approximate 0.954 confidence interval for μ .

EXERCISE 4.26. [4.26](#) *Sample Size for Given Length* Let $\bar{x}$ be the observed mean of a random sample of size n from a distribution having mean μ and known variance σ^2 . Find n so that $\bar{x} - \sigma/4$ to $\bar{x} + \sigma/4$ is an approximate 95% confidence interval for μ .

EXERCISE 4.27. [4.27](#) *Binomial Sample Size* Assume a binomial model for a certain random variable. If we desire a 90% confidence interval for p that is at most 0.02 in length, find n .

EXERCISE 4.28. [4.28](#) *Poisson Confidence Interval* It is known that a random variable X has a Poisson distribution with parameter μ . A sample of 200 observations from this distribution has a mean equal to 3.4. Construct an approximate 90% confidence interval for μ .

EXERCISE 4.29. [4.29](#) *Variance CI via Chi-square* Let $X_1, X_2, \dots, X_n$ be a random sample from $N(\mu, \sigma^2)$, where both parameters are unknown.

- (a) Show that $P((n-1)S^2/\sigma^2 < b) = 0.975$ and $P(a < (n-1)S^2/\sigma^2 < b) = 0.95$.
- (b) If $n = 9$ and $s^2 = 7.93$, find a 95% confidence interval for σ^2 .
- (c) If μ is known, how would you modify the procedure?

EXERCISE 4.30. [4.30](#) *Exact Gamma CI* Let $X_1, X_2, \dots, X_n$ be a random sample from a gamma distribution with known parameter $\alpha = 3$ and unknown $\beta > 0$. Obtain an exact confidence interval by first obtaining the distribution of $2\sum_1^n X_i/\beta$.

EXERCISE 4.31. [4.31](#) *Tack Point-Up Probability* When 100 tacks were thrown on a table, 60 of them landed point up. Obtain a 95% confidence interval for the probability that a tack of this type lands point up.

EXERCISE 4.32. [4.32](#) *Two-Sample Normal CI* Let two independent random samples, each of size 10, from two normal distributions $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$ yield $\bar{x} = 4.8$, $s_1^2 = 8.64$, $\bar{y} = 5.6$, $s_2^2 = 7.88$. Find a 95% confidence interval for $\mu_1 - \mu_2$.

EXERCISE 4.33. [4.33](#) *Binomial Proportion Difference* Let two independent random variables Y_1 and Y_2 with binomial distributions having parameters $n_1 = n_2 = 100$, p_1 and p_2 , be observed to be $y_1 = 50$ and $y_2 = 40$. Determine an approximate 90% confidence interval for $p_1 - p_2$.

EXERCISE 4.34. [4.34](#) *Known Variance Difference* Discuss the problem of finding a confidence interval for the difference $\mu_1 - \mu_2$ between the two means of two normal distributions if the variances σ_1^2 and σ_2^2 are known but not necessarily equal.

EXERCISE 4.35. [4.35](#) *Unknown Unequal Variance* Discuss the problem when the variances are unknown and unequal. If the variances are unknown but their ratio σ_1^2/σ_2^2 is a known constant k , then a statistic that is a T random variable can again be used. Why?

EXERCISE 4.36. [4.36](#) *Ratio Known Variance CI* Let $X_1, \dots, X_9$ and $Y_1, \dots, Y_{12}$ represent two independent random samples from $N(\mu_1, \sigma_1^2)$ and $N(\mu_2, \sigma_2^2)$. It is given that $\sigma_1^2 = 3\sigma_2^2$, but σ_2^2 is unknown. Define a random variable that has a t -distribution for a 95% confidence interval for $\mu_1 - \mu_2$.

EXERCISE 4.37. [4.37](#) *Sample Size for Mean Difference* Let $\bar{X}$ and $\bar{Y}$ be the means of two independent random samples, each of size n , from $N(\mu_1, \sigma^2)$ and $N(\mu_2, \sigma^2)$, where the common variance is known. Find n such that $P(\bar{X} - \bar{Y} - \sigma/5 < \mu_1 - \mu_2 < \bar{X} - \bar{Y} + \sigma/5) = 0.90$.

EXERCISE 4.38. [4.38](#) *Variance Ratio CI* Let $X_1, \dots, X_n$ and $Y_1, \dots, Y_m$ be two independent random samples from $N(\mu_1, \sigma_1^2)$ and $N(\mu_2, \sigma_2^2)$. Construct a confidence interval for the ratio σ_1^2/σ_2^2 .

EXERCISE 4.39. [4.39](#) *Exact Binomial CI* Recall for the baseball data, 15 out of 59 ballplayers are left-handed. Determine an exact 90% confidence interval for p .

EXERCISE 4.40. [4.40](#) *Asymptotic CI Verification* In Example 4.3.2, verify the result for the asymptotic confidence interval for θ .

EXERCISE 4.41. [4.41](#) *Discrete Exact Tack CI* In Exercise 4.2.20, find the discrete exact confidence interval for the proportion.

EXERCISE 4.42. [4.42](#) *Poisson Exact CI* Suppose $X_1, X_2, \dots, X_{10}$ is a random sample from a Poisson distribution with mean θ . Suppose $n\bar{x} = 5$. Compute the exact 90% confidence interval for θ .

EXERCISE 4.43. [4.43](#) *t-Interval Derivation* Consider the same setup as in Example 4.3.1 except now assume that σ^2 is unknown. Set up the equations and derive the t -interval for θ .

EXERCISE 4.44. [4.44](#) *Beta Integral Identity* Using Exercise 3.3.22, show that

$$\int_0^p \frac{n!}{(k-1)!(n-k)!} z^{k-1} (1-z)^{n-k} dz = \sum_{w=k}^n \binom{n}{w} p^w (1-p)^{n-w}.$$

EXERCISE 4.45. **4.45 Poisson CDF Identity** This exercise obtains a useful identity for the cdf of a Poisson cdf.

(a) Show that

$$\frac{\lambda^n}{\Gamma(n)} \int_1^\infty x^{n-1} e^{-x\lambda} dx = \sum_{j=0}^{n-1} e^{-\lambda} \frac{\lambda^j}{j!}.$$

(b) Obtain the identity used in Example 4.3.3.

EXERCISE 4.46. **4.46 Distribution Quantiles** Obtain closed-form expressions for the distribution quantiles based on the exponential and Laplace distributions.

EXERCISE 4.47. **4.47 Potential Outlier Probability** Suppose the pdf $f(x)$ is symmetric about 0. Show that the probability of a potential outlier from this distribution is $2F(4q_1)$, where $F^{-1}(0.25) = q_1$. Use this for:

(a) The normal distribution.

(b) The logistic distribution.

(c) The Laplace distribution.

EXERCISE 4.48. **4.48 Data Summary and Outliers** Consider the sample of data: 13, 5, 202, 15, 99, 4, 67, 83, 36, 11, 301, 23, 213, 40, 66, 106, 78, 69, 166, 84, 64.

(a) Obtain the five-number summary.

(b) Determine if there are any outliers.

(c) Boxplot the data. Comment.

EXERCISE 4.49. **4.49 Normal Q-Q Plot** Consider the data in Exercise 4.4.3. Obtain the normal q-q plot. Does it suggest the underlying distribution is normal? If not, determine a more appropriate distribution.

EXERCISE 4.50. **4.50 Exponential Order Statistic** Let $Y_1 < Y_2 < Y_3 < Y_4$ be the order statistics of a random sample of size 4 from the distribution having pdf $f(x) = e^{-x}$, $0 < x < \infty$. Find $P(Y_4 \geq 3)$.

EXERCISE 4.51. **4.51 Continuous Distribution Order Stats** Let X_1, X_2, X_3 be a random sample from a distribution having pdf $f(x) = 2x$, $0 < x < 1$.

(a) Compute the probability that the smallest exceeds the median.

(b) Find the correlation between Y_2 and Y_3 .

EXERCISE 4.52. **4.52 Discrete Order Statistic PMF** Let $f(x) = 1/6$, $x = 1, 2, 3, 4, 5, 6$, be the pmf of a discrete distribution. Show that the pmf of the smallest observation of a random sample of size 5 is $g_1(y_1) = (7 - y_1)^5/6^5 - (6 - y_1)^5/6^5$, $y_1 = 1, 2, \dots, 6$.

EXERCISE 4.53. **4.53 Independent Transformations** Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ denote the order statistics from exponential distribution. Show that $Z_1 = Y_2$ and $Z_2 = Y_4 - Y_2$ are independent.

EXERCISE 4.54. [4.54](#) *Beta Distribution of Order Statistic* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics from $\text{uniform}(0,1)$. Show that Y_k has a beta pdf with parameters $\alpha = k$ and $\beta = n - k + 1$.

EXERCISE 4.55. [4.55](#) *Weibull Minimum* Let $Y_1 < Y_2 < \dots < Y_n$ be the order statistics from a Weibull distribution. Find the distribution function and pdf of Y_1 .

EXERCISE 4.56. [4.56](#) *Uniform Range* Find the probability that the range of a random sample of size 4 from the uniform distribution is less than $1/2$.

EXERCISE 4.57. [4.57](#) *Ratio of Order Statistics* Let $Y_1 < Y_2 < Y_3$ be order statistics from $f(x) = 2x$, $0 < x < 1$. Show that $Z_1 = Y_1/Y_2$, $Z_2 = Y_2/Y_3$, and $Z_3 = Y_3$ are mutually independent.

EXERCISE 4.58. [4.58](#) *Ratio of Observations* Suppose a random sample of size 2 is obtained from $f(x) = 2(1 - x)$, $0 < x < 1$. Compute the probability that one sample observation is at least twice as large as the other.

EXERCISE 4.59. [4.59](#) *Midrange Distribution* Let $Y_1 < Y_2 < Y_3$ denote order statistics from $\text{uniform}(0,1)$. Let $Z = (Y_1 + Y_3)/2$ be the midrange. Find the pdf of Z .

EXERCISE 4.60. [4.60](#) *Normal Order Stats Expectation* Let $Y_1 < Y_2$ denote the order statistics of a random sample of size 2 from $N(0, \sigma^2)$.

- (a) Show $E(Y_1) = -\sigma/\sqrt{\pi}$.
- (b) Find the covariance of Y_1 and Y_2 .

EXERCISE 4.61. [4.61](#) *Independence Characterizes Exponential* Let $Y_1 < Y_2$ be order statistics from a continuous distribution with pdf $f(x) > 0$ for $x \geq 0$. Show that the independence of $Z_1 = Y_1$ and $Z_2 = Y_2 - Y_1$ characterizes the gamma pdf with $\alpha = 1$.

EXERCISE 4.62. [4.62](#) *Conditional Distribution* Let $Y_1 < Y_2 < Y_3 < Y_4$ be order statistics from $f(x) = 2x$, $0 < x < 1$.

- (a) Find the joint pdf of Y_3 and Y_4 .
- (b) Find the conditional pdf of Y_3 given $Y_4 = y_4$.
- (c) Evaluate $E(Y_3|y_4)$.

EXERCISE 4.63. [4.63](#) *Triangle Probability* Two numbers are selected at random from the interval $(0,1)$. Compute the probability that the three resulting line segments can form a triangle.

EXERCISE 4.64. [4.64](#) *Min and Max Joint PDF* Let X and Y be independent with $f(x) = 2x$ and $g(y) = 3y^2$ on $(0,1)$. Let $U = \min(X, Y)$ and $V = \max(X, Y)$. Find the joint pdf of U and V .

EXERCISE 4.65. **4.65** *Joint PDF of Min and Max* Let the joint pdf of X and Y be $f(x, y) = 12x(x + y)/7$, $0 < x < 1$, $0 < y < 1$. Let $U = \min(X, Y)$ and $V = \max(X, Y)$. Find the joint pdf of U and V .

EXERCISE 4.66. **4.66** *Gini's Mean Difference* Let $X_1, X_2, \dots, X_n$ be a random sample. Gini's mean difference is $G = \sum_{j=2}^n \sum_{i=1}^{j-1} |X_i - X_j| / \binom{n}{2}$.

(a) If $n = 10$, find $a_1, \dots, a_{10}$ so that $G = \sum_{i=1}^{10} a_i Y_i$.

(b) Show $E(G) = 2\sigma/\sqrt{\pi}$ for normal distribution.

EXERCISE 4.67. **4.67** *Exponential Order Stats Properties* Let $Y_1 < Y_2 < \dots < Y_n$ be order statistics from exponential distribution.

(a) Show $Z_1 = nY_1$, $Z_2 = (n-1)(Y_2 - Y_1)$, $Z_3 = (n-2)(Y_3 - Y_2)$, $\dots$, $Z_n = Y_n - Y_{n-1}$ are independent exponentials.

(b) Demonstrate that all linear functions of Y_i can be expressed as linear functions of independent random variables.

EXERCISE 4.68. **4.68** *PERT Distribution* In PERT, let X_1, X_2, X_3 be three independent uniform random times. For series completion ($Y = X_1 + X_2 + X_3$) and parallel completion ($Z = \max(X_1, X_2, X_3)$), find their pdfs.

EXERCISE 4.69. **4.69** *Sample Size for Extreme Quantile* Let Y_n denote the n th order statistic. Find the smallest n for which $P(\xi_{0.9} < Y_n) \geq 0.75$.

EXERCISE 4.70. **4.70** *Probability Involving Quantiles* Let $Y_1 < Y_2 < Y_3 < Y_4 < Y_5$ denote order statistics of size 5. Compute:

(a) $P(Y_1 < \xi_{0.5} < Y_5)$

(b) $P(Y_1 < \xi_{0.25} < Y_3)$

(c) $P(Y_4 < \xi_{0.80} < Y_5)$

EXERCISE 4.71. **4.71** *Median Between Order Stats* Compute $P(Y_3 < \xi_{0.5} < Y_7)$ if $Y_1 < \dots < Y_9$ are order statistics of size 9.

EXERCISE 4.72. **4.72** *Sample Size for Median Coverage* Find the smallest n for which $P(Y_1 < \xi_{0.5} < Y_n) \geq 0.99$.

EXERCISE 4.73. **4.73** *Normal Order Stats Interval* Let $Y_1 < Y_2$ be order statistics from $N(\mu, \sigma^2)$ with known σ^2 .

(a) Show $P(Y_1 < \mu < Y_2) = 1/2$ and compute $E(Y_2 - Y_1)$.

(b) Find c such that $P(\bar{X} - c\sigma < \mu < \bar{X} + c\sigma) = 1/2$.

EXERCISE 4.74. **4.74** *Selection Algorithm* Let $y_1 < y_2 < y_3$ be observed order statistics. A statistician is given these values in random order and wants to select the largest. She looks at the first but refuses it and then takes the second if larger than the first, else takes the third. Show this algorithm has probability $1/2$ of selecting the largest.

EXERCISE 4.75. [4.75](#) *Motor Median CI* Refer to Exercise 4.1.1. Using expression (4.4.10), obtain a confidence interval for the median lifetime of a motor.

EXERCISE 4.76. [4.76](#) *Power Function of Test* Show that the approximate power function given in expression (4.5.12) is strictly increasing. Show the test has approximate size α for testing $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$.

EXERCISE 4.77. [4.77](#) *Darwin Data t-Test* For the Darwin data, verify that the Student t -test statistic is 2.15.

EXERCISE 4.78. [4.78](#) *Neyman-Pearson Test* Let X have pdf $f(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1$. To test $H_0 : \theta = 1$ against $H_1 : \theta = 2$, use critical region $C = \{(x_1, x_2) : x_1 x_2 \geq 3/4\}$. Find the power function.

EXERCISE 4.79. [4.79](#) *Binomial Significance Level* Let X have binomial distribution with $n = 10$ and $p = 1/4$ or $1/2$. Test $H_0 : p = 1/2$ vs $H_1 : p = 1/4$ by rejecting if $X_1 \leq 3$. Find significance level and power.

EXERCISE 4.80. [4.80](#) *Exponential LR Test* Let X_1, X_2 be a sample from $f(x; \theta) = (1/\theta)e^{-x/\theta}$. Reject $H_0 : \theta = 2$ if $f(x_1; 2)f(x_2; 2)/[f(x_1; 1)f(x_2; 1)] \leq 1/2$. Find significance level and power when H_0 is false.

EXERCISE 4.81. [4.81](#) *Power Curve Sketch* Consider tests Test 1 and Test 2. For Test A, reject H_0 if $S \leq k_A$; for Test B, reject if $S \leq k_B$. If Test A has higher significance level, show Test A has higher power.

EXERCISE 4.82. [4.82](#) *Tire Life Test* Let tire life $X \sim N(\theta, 5000^2)$. Test $H_0 : \theta = 30000$ vs $H_1 : \theta > 30000$. Determine n and c so that $\gamma(30000) = 0.01$ and $\gamma(35000) = 0.98$.

EXERCISE 4.83. [4.83](#) *Poisson Power Function* Let X have Poisson distribution. Test $H_0 : \theta = 1/2$ vs $H_1 : \theta < 1/2$. With $n = 12$, reject if $Y = \sum X_i \leq 2$. Graph the power function and determine significance level.

EXERCISE 4.84. [4.84](#) *Binomial Sample Size* Let $Y \sim \text{binomial}(n, p)$. Test $H_0 : p = 1/2$ vs $H_1 : p > 1/2$. Find n and c so that $\gamma(1/2) = 0.10$ and $\gamma(2/3) = 0.95$.

EXERCISE 4.85. [4.85](#) *Uniform Max Test* Let $Y_1 < Y_2 < Y_3 < Y_4$ be order statistics from $f(x; \theta) = 1/\theta$, $0 < x < \theta$. Test $H_0 : \theta = 1$ vs $H_1 : \theta > 1$ by rejecting if $Y_4 \geq c$.

(a) Find c for $\alpha = 0.05$.

(b) Determine the power function.

EXERCISE 4.86. [4.86](#) *Poisson Test Size* Let $X_1, \dots, X_8$ be from Poisson with mean μ . Test $H_0 : \mu = 0.5$ vs $H_1 : \mu > 0.5$ by rejecting if $\sum x_i \geq 8$.

(a) Show significance level is $1 - \text{ppois}(7, 4)$.

(b) Determine $\gamma(0.75)$, $\gamma(1)$, $\gamma(1.25)$.

EXERCISE 4.87. [4.87](#) *Tennis Serve Hypothesis* Let p be probability that first serve is good. Test $H_0 : p = 0.40$ vs $H_1 : p > 0.40$ with $n = 25$. Reject if $Y \geq 13$.

(a) Show $\alpha = 1 - \text{pbinom}(12, 25, 0.4)$.

(b) Find β when $p = 0.60$.

EXERCISE 4.88. [4.88](#) *Bernoulli Power Comparison* Let S be number of successes in $n = 40$ Bernoulli trials. Test $H_0 : p \leq 0.3$ vs $H_1 : p > 0.3$. Compare tests: (1) Reject if $S \geq 16$ and (2) Reject if $S \geq 17$. Determine levels.

EXERCISE 4.89. [4.89](#) *Proportion Power Curve* Consider the two-sided test for proportions. Write R code to compute a plot of the power curve.

EXERCISE 4.90. [4.90](#) *Power Function Derivative* Consider the power function $\gamma(\mu)$. Show $\gamma'(\mu)$ is strictly negative for $\mu < \mu_0$ and strictly positive for $\mu > \mu_0$.

EXERCISE 4.91. [4.91](#) *Exact Size t-Test* Show that the test defined by (4.6.9) has exact size α for testing $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$.

EXERCISE 4.92. [4.92](#) *One vs Two-Sided Power* Consider the one-sided t-test and two-sided t-test, both of size α . Show that for $\mu > \mu_0$, the power function of the one-sided test is larger.

EXERCISE 4.93. [4.93](#) *Paired Design Analysis* A baseball coach paired 20 members by speed. Data on self vs rival times are given.

(a) Obtain comparison boxplots. Comment.

(b) Compute paired t-test and p-value.

(c) Obtain point estimate and 95% CI for μ_d .

(d) Conclude.

EXERCISE 4.94. [4.94](#) *AZT Dosage Study* A data set concerning the effect of AZT dosages on HIV patients. Compare 300mg and 600mg groups.

(a) Obtain comparison boxplots.

(b) Compute two-sample t-test and p-value.

(c) Obtain point estimate and 95% CI for Δ .

(d) Conclude.

EXERCISE 4.95. [4.95](#) *Air Quality Comparison* Compare suspended particle concentrations between Melbourne and Houston. Test $H_0 : \mu_X = \mu_Y$ against $H_1 : \mu_X < \mu_Y$.

(a) Define test statistic and critical region.

(b) Calculate with given statistics.

EXERCISE 4.96. **4.96** *Seat Belt Campaign* Let p be proportion of drivers using seat belts. After campaign, $y = 104$ out of $n = 590$ wore belts. Was campaign successful?

- (a) Define hypotheses.
- (b) Critical region at $\alpha = 0.01$.
- (c) Determine p -value.

EXERCISE 4.97. **4.97** *Variance Test Critical Value Test* $H_0 : \sigma^2 = \sigma_0^2$ against $H_1 : \sigma^2 > \sigma_0^2$ using critical region $(n-1)S^2/\sigma_0^2 \geq c$. If $n = 13$ and $\alpha = 0.025$, determine c .

EXERCISE 4.98. **4.98** *F-Test Critical Value Test* $H_0 : \sigma_1^2 = \sigma_2^2$ against $H_1 : \sigma_1^2 > \sigma_2^2$ using $F \geq c$. If $n = 13$, $m = 11$, and $\alpha = 0.05$, find c .

EXERCISE 4.99. **4.99** *Modified Frequency Test* Suppose observed frequencies of $A_1, \dots, A_4$ are 20, 30, 92, 105. Calculate the test and report p -value.

EXERCISE 4.100. **4.100** *Continuous Interval Test* A number is selected from $(0, 2)$. Test hypothesis with $p_{i0} = \int_{A_i} (1/2)(2-x)dx$. For observed frequencies 30, 30, 10, 10, would H_0 be accepted?

EXERCISE 4.101. **4.101** *Normal Approximation Test* Define sets $A_1 = \{x : -\infty < x \leq 0\}$, $A_i = \{x : i-2 < x \leq i-1\}$ for $i = 2, \dots, 7$, $A_8 = \{x : 6 < x < \infty\}$. Test with frequencies 60, 96, 140, 210, 172, 160, 88, 74.

EXERCISE 4.102. **4.102** *Die Casting Test* A die was cast $n = 120$ times with frequencies: 1: b , 2:20, 3:20, 4:20, 5:20, 6:40 – b . For what values of b would the hypothesis of unbiased die be rejected at 0.025 level?

EXERCISE 4.103. **4.103** *Mendelian Genetics* Mendelian theory states probabilities are 9/16, 3/16, 3/16, 1/16 for four classifications. With observed frequencies 86, 35, 26, 13 out of 160, test at $\alpha = 0.01$.

EXERCISE 4.104. **4.104** *Teaching Method Comparison* Two groups of 100 students each. Test at 5% whether the two distributions are the same.

EXERCISE 4.105. **4.105** *Crime and Alcoholism* Data on crime type and alcoholic status. Test independence.

- (a) Compute χ^2 -test for independence.
- (b) Use Pearson residuals to determine strongest dependence.
- (c) Confirm with conditional test.

EXERCISE 4.106. **4.106** *Independence Test* 180 independent trials with classification into A_1, A_2, A_3 and B_1, B_2, B_3, B_4 . What is smallest k that leads to rejection at $\alpha = 0.05$?

EXERCISE 4.107. **4.107** *Poisson Goodness of Fit* Fit Poisson distribution to data: x : 0, 1, 2, 3, 3 < x with frequencies 20, 40, 16, 18, 6.

- (a) Compute chi-square statistic.
- (b) Degrees of freedom?
- (c) Reject at $\alpha = 0.05$?

EXERCISE 4.108. [4.108](#) *MCT Converse* Prove the converse of Theorem MCT: Let X have continuous cdf $F(x)$ strictly increasing. Show $Z = F(X)$ has uniform(0,1) distribution.

EXERCISE 4.109. [4.109](#) *Monte Carlo Log 2 Approximate* $\log 2 = \int_0^1 1/(x+1)dx$ using uniform(0,1) generator. Write R function and compare with true value.

EXERCISE 4.110. [4.110](#) *Normal CDF Approximation* Approximate $\int_0^{1.96} (1/\sqrt{2\pi}) \exp\{-t^2/2\}dt$ using Monte Carlo.

EXERCISE 4.111. [4.111](#) *Location-Scale Generation* Suppose X has pdf $f_X(x) = b^{-1}f((x-a)/b)$. If we can generate from $f(z)$, explain how to generate from $f_X(x)$.

EXERCISE 4.112. [4.112](#) *Logistic Distribution Generation* Determine a method to generate random observations for the logistic pdf. Write R function and verify with histogram.

EXERCISE 4.113. [4.113](#) *Beta Generator* Determine a method to generate random observations for $f(x) = 4x^3$, $0 < x < 1$. Write R function.

EXERCISE 4.114. [4.114](#) *Laplace Inverse CDF* Obtain the inverse function of the cdf of the Laplace pdf $f(x) = (1/2)e^{-|x|}$. Write R function.

EXERCISE 4.115. [4.115](#) *Extreme Value Generation* Determine a method to generate random observations for the extreme-valued pdf $f(x) = \exp\{x - e^x\}$. Write R function.

EXERCISE 4.116. [4.116](#) *Cauchy Distribution* Determine a method to generate random observations for the Cauchy distribution $f(x) = 1/[\pi(1+x^2)]$. Write R function.

EXERCISE 4.117. [4.117](#) *Weibull Generation* Determine a method to generate random observations for the Weibull distribution. Write R function.

EXERCISE 4.118. [4.118](#) *Contaminated Normal Power* Write algorithm to simulate power of the test for contaminated normal distribution. Modify R function.

EXERCISE 4.119. [4.119](#) *Logistic Power Simulation* Write algorithm to simulate significance level and power for logistic distribution.

EXERCISE 4.120. [4.120](#) *General Inverse CDF* For cdf $F(x)$ not strictly increasing, define $F^{-1}(u) = \inf\{x : F(x) \geq u\}$. Let $U \sim \text{uniform}(0,1)$. Prove $F^{-1}(U)$ has cdf $F(x)$.

EXERCISE 4.121. [4.121](#) *Ratio Maximum* Verify the derivative in (4.8.12) and show the function attains maximum at $x = (\alpha - [\alpha])/(1-b)$.

EXERCISE 4.122. [4.122](#) *Minimum Derivation* Derive expression (4.8.14) and show $b = [\alpha]/\alpha$ gives minimum.

EXERCISE 4.123. [4.123](#) *Gamma via Beta* Assume $Y_1 \sim \Gamma(\alpha+1, 1)$, $Y_2 \sim \text{uniform}(0, 1)$. Let $X_1 = Y_1 Y_2^{1/\alpha}$ and $X_2 = Y_2$. Show $X_1 \sim \Gamma(\alpha, 1)$.

EXERCISE 4.124. [4.124](#) *Ratio Derivative* Show the derivative of the ratio in (4.8.10) is $-x \exp\{-x^2/2\}(x^2 - 1)$ with critical values ± 1 .

EXERCISE 4.125. [4.125](#) *Beta Distribution Generation* Consider accept-reject algorithm for beta distribution. Show X has beta distribution with parameters α and β .

EXERCISE 4.126. [4.126](#) *Marsaglia-Bray Normal* Consider the Marsaglia-Bray algorithm for generating normal random variables. Show X_1 and X_2 are iid $N(0, 1)$.

EXERCISE 4.127. [4.127](#) *Bootstrap CI for Mean* Use the R function `percentboot` to obtain a bootstrap 95% confidence interval for the mean concentration. Compare with t -CI.

EXERCISE 4.128. [4.128](#) *Bootstrap Sample Properties* Let $x_1^*, \dots, x_n^*$ be a bootstrap sample drawn with replacement.

- (a) Show x_i^* are iid with common cdf $\hat{F}_n$.
- (b) Show $E(x_i^*) = \bar{x}$.
- (c) If n odd, show $\text{median}\{x_i^*\} = x_{(n+1)/2}$.
- (d) Show $V(x_i^*) = n^{-1} \sum (x_i - \bar{x})^2$.

EXERCISE 4.129. [4.129](#) *Gamma Bootstrap CI* Let $X_1, \dots, X_n \sim \Gamma(1, \beta)$.

- (a) Show $(2n\bar{X}/(\chi_{2n}^2)^{(1-\alpha/2)}, 2n\bar{X}/(\chi_{2n}^2)^{(\alpha/2)})$ is exact CI for β .
- (b) Show 90% CI for data is (64.99, 136.69).

EXERCISE 4.130. [4.130](#) *Bootstrap Median CI* Suppose we want to estimate the median using sample median. Obtain 90% bootstrap percentile CI. Did it trap the true median?

EXERCISE 4.131. [4.131](#) *Bootstrap t -Interval* Suppose $X_1, \dots, X_n \sim N(\mu, \sigma^2)$. Show the pivot $t = (\bar{X} - \mu)/(S/\sqrt{n})$ leads to CI.

EXERCISE 4.132. [4.132](#) *Standardized Bootstrap CI* Consider bootstrap pivot $t^* = (\bar{x}^* - \bar{x})/(s^*/\sqrt{n})$.

- (a) Rewrite percentile CI algorithm using t^* .
- (b) Find 90% CI for data in Example 4.9.3.
- (c) Compare with nonstandardized CI.

EXERCISE 4.133. [4.133](#) *Bootstrap Median Test* Consider algorithm for two-sample bootstrap test based on difference in medians.

- (a) Rewrite algorithm for median.
- (b) Obtain bootstrap test.
- (c) Compare p -value with 0.063.

EXERCISE 4.134. [4.134](#) Two-Sample t -Test Value Consider data of Example 4.9.2. Show $t = 0.93$ with p -value 0.18.

EXERCISE 4.135. [4.135](#) Bootstrap Two-Sided Test In Example 4.9.3, test $H_0 : \mu = 90$ vs $H_1 : \mu \neq 90$.

- (a) Determine bootstrap p -value.
- (b) Rewrite R program.
- (c) Compute p -value with 3000 bootstraps.

EXERCISE 4.136. [4.136](#) Permutation Test Consider permutation test for two-sample problem.

- (a) For $x' = (10, 15, 21)$ and $y' = (20, 25, 30)$, determine p -value.
- (b) Approximate permutation test with 3000 resamples.
- (c) Probability of distinct samples?

EXERCISE 4.137. [4.137](#) Bootstrap z Distribution Let z^* be drawn from discrete distribution with mass n^{-1} at $z_i = x_i - \bar{x} + \mu_0$. Determine $E(z^*)$ and $V(z^*)$.

EXERCISE 4.138. [4.138](#) Bootstrap t -Test Value For Example 4.9.3, show $t = 0.84$ and p -value is 0.20.

EXERCISE 4.139. [4.139](#) Bootstrap Median Test For Example 4.9.3, obtain bootstrap test based on medians for $H_0 : \mu = 90$ vs $H_1 : \mu > 90$.

EXERCISE 4.140. [4.140](#) Darwin Experiment Bootstrap Consider Darwin's experiment on *Zea mays*.

- (a) Obtain bootstrap test keeping pairing intact.
- (b) Write R program and compare p -value.

本章小结

核心概念：

- 统计量：样本的函数，不依赖未知参数
- 点估计：MLE、矩估计；无偏性、偏差
- 置信区间：参数的合理取值范围；宽度随样本量增大而减小
- 假设检验：第一类和第二类错误的权衡

重要公式：

场景	置信区间/检验统计量
正态均值、已知 σ	$\bar{X} \pm z_{\alpha/2}\sigma/\sqrt{n}$
正态均值、未知 σ	$\bar{X} \pm t_{\alpha/2, n-1}S/\sqrt{n}$
正态方差	$\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}$
单样本 Z 检验	$Z = \frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}}$
单样本 t 检验	$T = \frac{\bar{X}-\mu_0}{S/\sqrt{n}}$
拟合优度 χ^2	$\chi^2 = \sum \frac{(O-E)^2}{E} \approx \chi^2(k-1)$

8. 附录：公式推导

8.1. 通用 MLE 推导. 背景：最大似然估计的通用推导框架。

核心思想：MLE 选择使似然函数最大化的参数值。在正则条件下，MLE 满足似然方程 $\frac{\partial l(\theta)}{\partial \theta} = 0$ 。

渐近性质（不证）：在温和条件下， $\hat{\theta}$ 具有以下渐近性质：

- (1) **一致性：** $\hat{\theta} \xrightarrow{P} \theta$
- (2) **渐近正态性：** $\sqrt{n}(\hat{\theta} - \theta) \Rightarrow \mathcal{N}(0, I(\theta)^{-1})$ ，其中 $I(\theta)$ 是 Fisher 信息量
- (3) **渐近有效性：** 方差达到 Cramér-Rao 下界

这些性质使 MLE 成为现代统计推断的基石。

8.2. 指数分布 MLE 的推导. 背景：设 $X_1, \dots, X_n \sim \text{Exp}(\theta)$ ，即 $f(x) = \theta^{-1} \exp\{-x/\theta\}$ ， $x > 0$ 。

目标：求使似然函数最大化的 θ 值。

推导步骤：

1. 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta^{-1} \exp\{-x_i/\theta\} = \theta^{-n} \exp\{-\theta^{-1} \sum_{i=1}^n x_i\}.$$

2. 对数似然函数为

$$l(\theta) = -n \log \theta - \theta^{-1} \sum_{i=1}^n x_i.$$

3. 求导并设为零：

$$\frac{\partial l(\theta)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n x_i = 0.$$

4. 解得

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

5. 验证这是最大值（二阶导数为负）：

$$\frac{\partial^2 l(\theta)}{\partial \theta^2} = \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^n x_i = -\frac{n}{\theta^2} < 0.$$

结论： $\hat{\theta} = \bar{X}$ 是 θ 的 MLE。由于 $\mathbb{E}(X) = \theta$ ，故它也是无偏的。

8.3. 二项分布 MLE 的推导. 背景: 设 $X \sim \text{Bernoulli}(\theta)$, 对于随机样本 $X_1, \dots, X_n$ 。

目标: 求 θ 的 MLE。

推导步骤:

1. 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} = \theta^{\sum x_i} (1-\theta)^{n-\sum x_i}.$$

2. 对数似然函数为

$$l(\theta) = \left(\sum_{i=1}^n x_i \right) \log \theta + \left(n - \sum_{i=1}^n x_i \right) \log(1-\theta).$$

3. 求导并设为零:

$$\frac{\partial l(\theta)}{\partial \theta} = \frac{\sum x_i}{\theta} - \frac{n - \sum x_i}{1-\theta} = 0.$$

4. 解得

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

结论: 样本均值 (样本比例) 是 θ 的 MLE, 也是无偏估计。

8.4. 正态分布 MLE 的推导. 背景: 设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 对于随机样本。

目标: 求 μ 和 σ^2 的 MLE。

推导步骤:

1. 对数似然函数为

$$l(\mu, \sigma) = -\frac{n}{2} \log 2\pi - n \log \sigma - \frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2.$$

2. 对 μ 求偏导并设为零:

$$\frac{\partial l}{\partial \mu} = -\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu} = \bar{x}.$$

3. 对 σ 求偏导并设为零 (先代入 $\hat{\mu}$):

$$\frac{\partial l}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \bar{x})^2 = 0 \implies \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

注意: $\hat{\sigma}^2$ 是有偏的, 因为

$$\mathbb{E}[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2.$$

无偏估计为 $S^2 = \frac{n}{n-1} \hat{\sigma}^2$ 。

8.5. 置信区间推导汇总. 背景: 置信区间构造的核心思想是找枢轴量。

枢轴量的定义: 设 $Q = q(X_1, \dots, X_n; \theta)$ 。如果 Q 的分布不依赖于 θ ，则称 Q 为枢轴量。

构造步骤:

- (1) 找一个枢轴量 Q
- (2) 确定 a, b 使得 $\mathbb{P}(a \leq Q \leq b) = 1 - \alpha$
- (3) 解不等式得到 θ 的置信区间

8.6. 正态均值置信区间（已知方差）的推导. 背景: 设 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ ，其中 σ^2 已知，推导 μ 的置信区间。

已知条件:

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- 标准化的随机变量 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$

目标: 找到 L 和 U 使得 $\mathbb{P}(L \leq \mu \leq U) = 1 - \alpha$

推导步骤:

1. 由标准正态分布的对称性:

$$\mathbb{P}(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha.$$

2. 代入 Z 的表达式:

$$\mathbb{P}\left(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha.$$

3. 利用不等式的代数运算:

$$\mathbb{P}\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

4. 因此置信区间为:

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

关键洞察: 区间以 $\bar{X}$ 为中心，宽度为 $2z_{\alpha/2}\sigma/\sqrt{n}$ ，随 $\sqrt{n}$ 减小。

8.7. 正态均值置信区间（未知方差）的推导. 背景: 设 $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ ，其中 σ^2 未知，用 S^2 估计。

已知条件:

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$
- $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$
- $\bar{X}$ 与 S^2 独立

目标: 推导 μ 的置信区间

推导步骤:

1. 构造枢轴量:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

2. 可以证明 $T \sim t(n-1)$ 。
3. 给定置信水平 $1 - \alpha$ ：

$$\mathbb{P}(-t_{\alpha/2, n-1} \leq T \leq t_{\alpha/2, n-1}) = 1 - \alpha.$$

4. 代入 T 并解出 μ ：

$$\mathbb{P}\left(\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}\right) = 1 - \alpha.$$

5. 因此置信区间为：

$$\left[\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \right].$$

与已知方差情形的比较：用 S 替代 σ ，用 t 分位数替代 z 分位数。由于 t 分布比正态分布更重尾，区间更宽，反映了用样本方差代替总体方差的不确定性。

8.8. 方差置信区间的推导. 背景：推导正态分布方差 σ^2 的置信区间。

已知条件： $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$

推导步骤：

1. 由卡方分布的性质：

$$\mathbb{P}\left(\chi_{1-\alpha/2, n-1}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{\alpha/2, n-1}^2\right) = 1 - \alpha.$$

2. 解出 σ^2 ：

$$\mathbb{P}\left(\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2}\right) = 1 - \alpha.$$

3. 因此置信区间为：

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \right].$$

8.9. 假设检验的推导. 背景：正态均值检验的推导。

已知方差情形：

1. 在 $H_0: \mu = \mu_0$ 下， $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ 。
2. 拒绝域为 $Z > z_\alpha$ （单侧）或 $|Z| > z_{\alpha/2}$ （双侧）。
3. p 值定义为观察到比当前样本更极端结果的概率。

未知方差情形：

1. 在 $H_0: \mu = \mu_0$ 下， $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ 。
2. 拒绝域为 $|T| > t_{\alpha/2, n-1}$ 。
3. p 值由 t 分布计算。

8.10. 卡方统计量极限分布的推导. 背景: 拟合优度 χ^2 统计量的极限分布推导。

推导步骤:

1. 在 H_0 下, $O_i \sim \text{Binomial}(n, p_{i0})$, 因此 $\mathbb{E}(O_i) = E_i = np_{i0}$, $\text{var}(O_i) = np_{i0}(1-p_{i0})$ 。
2. 标准化: $Z_i = (O_i - E_i)/\sqrt{E_i}$ 。
3. 可以证明 Z_i 近似服从 $\mathcal{N}(0, 1-p_{i0})$, 且协方差矩阵不是单位矩阵 (因为 $\sum O_i = n$ 是约束)。
4. 因此

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i} \approx \chi^2(k-1).$$

自由度减 1 是因为约束 $\sum O_i = n$ 。

8.11. 蒙特卡洛方法的推导. 背景: 接受-拒绝算法的推导和收敛性分析。

逆 CDF 方法:

定理: 如果 $U \sim \text{Uniform}(0, 1)$, F 是连续分布函数, 则 $X = F^{-1}(U)$ 的分布函数为 F 。

证明: 设 $X = F^{-1}(U)$, 即 $X \leq x$ 当且仅当 $U \leq F(x)$ 。因此

$$\mathbb{P}(X \leq x) = \mathbb{P}(U \leq F(x)) = F(x).$$

证毕。

接受-拒绝算法:

1. 每次迭代的接受概率为

$$\mathbb{P}(\text{接受}) = \int \frac{f(y)}{Mg(y)}g(y)dy = \frac{1}{M} \int f(y)dy = \frac{1}{M}.$$

2. 因此平均接受次数为 M 。

3. 效率与 M 成反比。

收敛性: 由大数定律, 接受的样本确实来自 $f(x)$ 。

8.12. Bootstrap 的理论基础. 背景: Bootstrap 的理论基础。

核心假设: 样本的经验分布函数 $\hat{F}_n$ 是真实分布 F 的良好估计。

Bootstrap 分布:

$$T^* \mid X_1, \dots, X_n \approx T \mid X_1, \dots, X_n$$

其中 $\approx$ 表示“分布近似”。

误差分析:

Bootstrap 的误差来源:

- (1) 抽样变异性: 由 B 的有限性引入
- (2) 代理误差: 由 $\hat{F}_n$ 逼近 F 引入

当样本量 n 足够大时, 这两种误差都可以控制。

偏差校正 Bootstrap:

如果 $\hat{\theta}$ 有系统性偏差 ($\mathbb{E}[\hat{\theta}] \neq \theta$)，则 percentile bootstrap 区间可能有偏差。偏差校正因子：

$$\hat{a} = \Phi^{-1} \left(\frac{\#\{\hat{\theta}_b^* < \hat{\theta}\}}{B} \right).$$

偏差校正的置信区间为 $[\theta_{\alpha_1}^*, \theta_{\alpha_2}^*]$ ，其中 $\alpha_1 = \Phi(2\hat{a} + z_\alpha)$ ， $\alpha_2 = \Phi(2\hat{a} - z_\alpha)$ 。

CHAPTER 5

Asymptotic Theory

Chapter 5 Overview

在前四章中，我们建立了描述概率分布和统计推断的理论框架。现在我们面临一个根本性问题：

当样本量趋向无穷大时，统计量的行为如何？

这个问题——即**渐近理论 (asymptotic theory)**——是现代统计学的核心。在实际应用中，我们往往无法获得精确的有限样本分布，但通过渐近分析，我们可以理解统计量在大样本下的行为。

本章介绍三种关键的收敛概念和中心极限定理：

- **依概率收敛** (Convergence in Probability)：统计量越来越接近参数真值
- **依分布收敛** (Convergence in Distribution)：统计量的分布越来越接近某个极限分布
- **中心极限定理** (Central Limit Theorem)：样本均值标准化后趋向正态分布

这三种收敛是渐近统计学的基石。依概率收敛保证估计量的一致性 (**consistency**)；依分布收敛结合中心极限定理，使得我们能够对大样本下的统计推断进行近似计算；而 Slutsky 定理和 Δ 方法则提供了处理统计量函数的通用工具。

本章路线图：依概率收敛 $\rightarrow$ 依分布收敛 $\rightarrow$ 中心极限定理 $\rightarrow$ 多元扩展 $\rightarrow$ Δ 方法

1. 5.1 Convergence in Probability

1.1. 收敛性的定义。本节，我们形式化地描述随机变量序列 X_n “接近”另一个随机变量 X 的方式。

为什么需要收敛性？ 在统计中，我们通常不知道总体的精确分布，但希望知道当样本量增大时，估计量是否越来越准确。收敛性正是描述这种“越来越准确”的数学语言。

DEFINITION 5.1 (依概率收敛)。设 X_n 是一列随机变量， X 是定义在同一样本空间上的随机变量。若对所有 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}[|X_n - X| \geq \epsilon] = 0,$$

或等价地，

$$\lim_{n \rightarrow \infty} \mathbb{P}[|X_n - X| < \epsilon] = 1,$$

则称 X_n 依概率收敛到 X ，记作

$$X_n \xrightarrow{P} X.$$

直观理解：无论你设定多小的误差界 ϵ ，当 n 足够大时， X_n 与 X 的差异超过 ϵ 的概率可以任意小。

统计中的特殊情况：在统计学中，渐近随机变量 X 往往是常数——即所有概率质量集中在某个常数 a 上的退化分布。此时记 $X_n \xrightarrow{P} a$ 。

例：数列收敛是依概率收敛的特殊情况 (习题 5.1.1)：若 a_n 是普通数列（可视为退化的随机变量），则 $a_n \rightarrow a$ 等价于 $a_n \xrightarrow{P} a$ 。

1.2. 弱大数定律。 展示依概率收敛的一个经典方法是使用 Chebyshev 不等式。

EXAMPLE 5.1 (弱大数定律 (WLLN)). 设 X_n 是 iid 随机变量序列，具有共同均值 μ 和有限方差 σ^2 。令 $\bar{X}_n = n^{-1} \sum_{i=1}^n X_i$ 。则

$$\bar{X}_n \xrightarrow{P} \mu.$$

证明：由例 2.8.1， $\bar{X}_n$ 的均值和方差分别为 μ 和 σ^2/n 。因此，由 Chebyshev 不等式，对 $\epsilon > 0$ ，

$$\mathbb{P}[|\bar{X}_n - \mu| \geq \epsilon] = \mathbb{P}[|\bar{X}_n - \mu| \geq (\epsilon\sqrt{n}/\sigma)(\sigma/\sqrt{n})] \leq \frac{\sigma^2}{n\epsilon^2} \rightarrow 0. \quad (5.1.1)$$

意义：这个定理表明，当 $n \rightarrow \infty$ 时，样本均值 $\bar{X}_n$ 的概率质量越来越集中在 μ 附近。从某种意义上看，当 n 足够大时， $\bar{X}_n$ “接近” μ 。¹

强化的注记：在更高级的课程中，可以证明强大数定律——它只需要每个随机变量有有限均值 μ （不要求方差存在）。这说明强大数定律是“一阶矩定理”，而弱大数定律需要二阶矩存在。

1.3. 依概率收敛的性质。 以下定理表明，依概率收敛在线性运算下是封闭的。

THEOREM 5.1 (和的收敛性). 若 $X_n \xrightarrow{P} X$ 且 $Y_n \xrightarrow{P} Y$ ，则 $X_n + Y_n \xrightarrow{P} X + Y$ 。

证明：由三角不等式，

$$|X_n + Y_n - (X + Y)| \leq |X_n - X| + |Y_n - Y|.$$

对 $\epsilon > 0$ ，有

$$\mathbb{P}[|X_n + Y_n - (X + Y)| \geq \epsilon] \leq \mathbb{P}[|X_n - X| \geq \epsilon/2] + \mathbb{P}[|Y_n - Y| \geq \epsilon/2] \rightarrow 0. \quad (5.1.2)$$

THEOREM 5.2 (常数乘积的收敛性). 若 $X_n \xrightarrow{P} X$ 且 a 是常数，则 $aX_n \xrightarrow{P} aX$ 。

证明：若 $a = 0$ ，结论显然。若 $a \neq 0$ ，

$$\mathbb{P}[|aX_n - aX| \geq \epsilon] = \mathbb{P}[|X_n - X| \geq \epsilon/|a|] \rightarrow 0. \quad (5.1.3)$$

THEOREM 5.3 (连续函数变换). 若 $X_n \xrightarrow{P} a$ 且实函数 g 在 a 处连续，则 $g(X_n) \xrightarrow{P} g(a)$ 。

¹弱大数定律的完整推导见附录 section 5.1。

证明：由于 g 在 a 处连续，对 $\epsilon > 0$ ，存在 $\delta > 0$ ，使得若 $|x - a| < \delta$ ，则 $|g(x) - g(a)| < \epsilon$ 。因此

$$\mathbb{P}[|g(X_n) - g(a)| \geq \epsilon] \leq \mathbb{P}[|X_n - a| \geq \delta] \rightarrow 0. \quad (5.1.4)$$

重要推论：由该定理，若 $X_n \xrightarrow{P} a$ ，则：

$$X_n^2 \xrightarrow{P} a^2, \quad \frac{1}{X_n} \xrightarrow{P} \frac{1}{a} \quad (a \neq 0), \quad \sqrt{X_n} \xrightarrow{P} \sqrt{a} \quad (a \geq 0).$$

THEOREM 5.4 (乘积的收敛性). 若 $X_n \xrightarrow{P} X$ 且 $Y_n \xrightarrow{P} Y$ ，则 $X_n Y_n \xrightarrow{P} XY$ 。

证明：利用恒等式 $2X_n Y_n = X_n^2 + Y_n^2 - (X_n - Y_n)^2$ ，结合上述结果可得。²

1.4. 5.1.1 抽样与统计量. 考虑随机变量 X ，其 pdf (或 pmf) 为 $f(x; \theta)$ ，其中 $\theta \in \Omega$ 是未知参数。例如：

- $X \sim N(\mu, \sigma^2)$, $\theta = (\mu, \sigma^2)$
- $X \sim \Gamma(1, \beta)$, $\beta > 0$ 未知

设 $X_1, X_2, \dots, X_n$ 是来自 $f(x; \theta)$ 的随机样本 (即 iid)。我们称统计量 $T = T(X_1, \dots, X_n)$ 为**估计量 (estimator)**。

两个关键性质：

- (1) **无偏性 (Unbiasedness):** $E(T) = \theta$
- (2) **一致性 (Consistency):** $T_n \xrightarrow{P} \theta$

DEFINITION 5.2 (一致性估计量). 设 X 是具有 cdf $F(x; \theta)$ 的随机变量， $\theta \in \Omega$ 。设 $X_1, \dots, X_n$ 是来自该分布的样本， T_n 是统计量。若

$$T_n \xrightarrow{P} \theta,$$

则称 T_n 是 θ 的**一致估计量 (consistent estimator)**。

注：一致性是估计量最重要的性质之一——如果估计量随着样本量增大都不能接近真实参数，那它就是一个“糟糕”的估计量。无偏性则不能保证这一点。例如，有偏估计量 $V = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是一致的 (有偏但偏差随 $n \rightarrow \infty$ 消失)，而 S^2 是无偏的。

EXAMPLE 5.2 (样本方差的一致性). 设 $X_1, \dots, X_n$ 是来自均值为 μ 、方差为 σ^2 的分布的随机样本。在例 2.8.7 中，我们证明了样本方差 S_n^2 是 σ^2 的无偏估计。

进一步，假设 $E[X_1^4] < \infty$ (有限四阶矩)，则 $S_n^2 \xrightarrow{P} \sigma^2$ 。

证明思路：由弱大数定律， $\bar{X}_n \xrightarrow{P} \mu$ ， $\frac{1}{n} \sum X_i^2 \xrightarrow{P} E(X_1^2)$ 。利用

$$S_n^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum X_i^2 - \bar{X}_n^2 \right) \xrightarrow{P} E(X_1^2) - \mu^2 = \sigma^2. \quad (5.1.5)$$

因此，样本标准差 $S_n \xrightarrow{P} \sigma$ 也是一致的。³

²乘积收敛性的完整证明见附录 section 5.2。

³样本方差一致性的完整推导见附录 section 5.3。

EXAMPLE 5.3 (均匀分布最大值的收敛). 设 $X_1, \dots, X_n \sim \text{Uniform}(0, \theta)$, θ 未知。令 $Y_n = \max X_1, \dots, X_n$ 。

Y_n 的 cdf 为 (习题 5.1.4)

$$F_{Y_n}(t) = \begin{cases} 0, & t \leq 0 \\ (t/\theta)^n, & 0 < t \leq \theta \\ 1, & t > \theta \end{cases} \quad (5.1.6)$$

由此可得 $Y_n \xrightarrow{P} \theta$, 即样本最大值是 θ 的一致估计。注意, 虽然 $E(Y_n) = \frac{n}{n+1}\theta$ (有偏), 但 $(n+1)/n \cdot Y_n$ 是无偏且一致的。⁴

2. 5.2 Convergence in Distribution

上一节我们介绍了依概率收敛的概念。利用这个概念, 我们可以形式化地说统计量收敛到参数。但“有多接近”? 我们能否量化估计的误差? 本节介绍的依分布收敛与前述结果结合, 给出了这些问题的肯定答案。

DEFINITION 5.3 (依分布收敛). 设 X_n 是一列随机变量, X 是一随机变量。设 F_{X_n} 和 F_X 分别是 X_n 和 X 的 cdf。设 $C(F_X)$ 表示 F_X 的所有连续点集合。若

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x), \quad \forall x \in C(F_X),$$

则称 X_n 依分布收敛到 X , 记作

$$X_n \xrightarrow{D} X.$$

注: 在统计学和概率论中, 依分布收敛常称为**弱收敛 (weak convergence)**。

简化记号: 若 $X_n \xrightarrow{D} X$, 其中 $X \sim N(0, 1)$, 我们可以简短地写作

$$X_n \xrightarrow{D} N(0, 1). \quad (5.2.1)$$

为什么只要求在 F_X 的连续点收敛? 考虑一个简单例子: X_n 所有概率质量集中在 $1/n$, X 所有质量集中在 0。则在 F_X 的间断点 0 处, $\lim F_{X_n}(0) = 0 \neq 1 = F_X(0)$; 但在所有其他点, 两者的 CDF 收敛。因此 $X_n \xrightarrow{D} X$ 。

EXAMPLE 5.4 (样本均值的退化分布). 设 $\bar{X}_n$ 的 cdf 为

$$F_n(\bar{x}) = \int_{-\infty}^{\bar{x}} \frac{1}{\sqrt{1/n}\sqrt{2\pi}} e^{-nw^2/2} dw.$$

令 $v = \sqrt{n}w$, 有

$$F_n(\bar{x}) = \int_{-\infty}^{\sqrt{n}\bar{x}} \frac{1}{\sqrt{2\pi}} e^{-v^2/2} dv.$$

⁴均匀分布最大值的详细分析见附录 section 5.4。

当 $n \rightarrow \infty$,

$$\lim_{n \rightarrow \infty} F_n(\bar{x}) = \begin{cases} 0, & \bar{x} < 0 \\ \frac{1}{2}, & \bar{x} = 0 \\ 1, & \bar{x} > 0 \end{cases} \quad (5.2.2)$$

这正是集中在 $\bar{x} = 0$ 的退化分布。因此 $\bar{X}_n$ 依分布收敛到该退化分布。⁵

EXAMPLE 5.5 (t 分布趋近正态分布). 设 T_n 服从自由度为 n 的 t 分布。其 cdf 为

$$F_n(t) = \int_{-\infty}^t \frac{\Gamma[(n+1)/2]}{\sqrt{\pi n} \Gamma(n/2)} \frac{1}{(1+y^2/n)^{(n+1)/2}} dy. \quad (5.2.3)$$

由 Lebesgue 控制收敛定理, 可以交换极限和积分次序。计算表明

$$\lim_{n \rightarrow \infty} F_n(t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} e^{-y^2/2} dy,$$

即标准正态分布的 cdf 。因此 $T_n \xrightarrow{D} N(0, 1)$ 。⁶

EXAMPLE 5.6 (均匀分布最大值的渐近指数分布). 回顾例 5.1.2: $Y_n = \max X_1, \dots, X_n$, 其中 $X_i \sim \text{Uniform}(0, \theta)$ 。考虑 $Z_n = n(\theta - Y_n)$ 。

对 $t \in (0, n\theta)$, 利用 Y_n 的 cdf , 可得

$$\mathbb{P}[Z_n \leq t] = 1 - \left(1 - \frac{t/\theta}{n}\right)^n \rightarrow 1 - e^{-t/\theta}. \quad (5.2.4)$$

因此 $Z_n \xrightarrow{D} \Gamma(1, \theta)$ (指数分布)。这是一个典型的“最大值标准化后收敛到指数分布”的例子。⁷

2.1. 依概率收敛与依分布收敛的关系.

THEOREM 5.5 (依概率收敛推出依分布收敛). 若 $X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{D} X$ 。

证明梗概: 设 x 是 F_X 的连续点。对 $\epsilon > 0$,

$$F_{X_n}(x) = \mathbb{P}[X_n \leq x] \leq \mathbb{P}[X \leq x + \epsilon] + \mathbb{P}[|X_n - X| \geq \epsilon].$$

令 $n \rightarrow \infty$, 再令 $\epsilon \rightarrow 0$, 利用 $X_n \xrightarrow{P} X$ 可得上确界收敛到 $F_X(x)$ 。类似地可得到下界。⁸

注: 反过来一般不成立。但若极限 X 是常数, 则两者等价。

THEOREM 5.6 (常数情形下两种收敛等价). 若 $X_n \xrightarrow{D} b$ (常数), 则 $X_n \xrightarrow{P} b$ 。

THEOREM 5.7 (和的极限分布). 设 $X_n \xrightarrow{D} X$ 且 $Y_n \xrightarrow{P} 0$ 。则 $X_n + Y_n \xrightarrow{D} X$ 。

⁵该例子的详细分析见附录 section 5.5。

⁶该证明利用了 Stirling 公式, 见附录 section 5.6。

⁷均匀分布最大值的完整推导见附录 section 5.7。

⁸完整证明见附录 section 5.8。

应用场景：若难以直接证明 $X_n \xrightarrow{D} X$ ，但容易证明 $Y_n \xrightarrow{D} X$ 且 $X_n - Y_n \xrightarrow{P} 0$ ，则 $X_n = Y_n + (X_n - Y_n) \xrightarrow{D} X$ 。

THEOREM 5.8 (连续函数变换保持依分布收敛). 设 $X_n \xrightarrow{D} X$ 且 g 是支撑上的连续函数，则 $g(X_n) \xrightarrow{D} g(X)$ 。

重要应用：若 $Z_n \xrightarrow{D} Z \sim N(0, 1)$ ，则 $Z_n^2 \xrightarrow{D} \chi^2(1)$ (因为 $Z^2 \sim \chi^2(1)$)。

THEOREM 5.9 (Slutsky 定理). 设 X_n, X, A_n, B_n 是随机变量, a, b 是常数。若 $X_n \xrightarrow{D} X$, $A_n \xrightarrow{P} a$, $B_n \xrightarrow{P} b$ ，则

$$A_n + B_n X_n \xrightarrow{D} a + bX. \quad (5.2.5)$$

核心思想：依分布收敛允许与依概率收敛的随机变量相乘——这是中心极限定理应用中最重要工具。⁹

2.2. 5.2.1 有界概率。 另一个有用的概念是随机变量序列的**概率有界性**。

DEFINITION 5.4 (有界概率). 称随机变量序列 X_n 概率有界，若对所有 $\epsilon > 0$ ，存在常数 $B_\epsilon > 0$ 和整数 N_ϵ ，使得

$$n \geq N_\epsilon \Rightarrow \mathbb{P}[|X_n| \leq B_\epsilon] \geq 1 - \epsilon. \quad (5.2.6)$$

直观理解：概率有界意味着序列的概率质量不会“逃逸”到无穷。

EXAMPLE 5.7 (标准正态分布是有界概率). 设 $X \sim N(0, 1)$ 。对 $\epsilon > 0$ ，可以找到 η 使得 $\mathbb{P}[|X| \leq \eta] \geq 1 - \epsilon$ 。这是因为正态分布的尾部概率可以任意小。¹⁰

THEOREM 5.10 (依分布收敛蕴含概率有界). 若 $X_n \xrightarrow{D} X$ ，则 X_n 概率有界。

EXAMPLE 5.8 (有界但不依分布收敛). 令 $n = 2m$ (偶数) 时 $X_{2m} = 2 + 1/(2m)$; $n = 2m - 1$ (奇数) 时 $X_{2m-1} = 1 + 1/(2m)$ 。则偶数子序列依分布收敛到常数 2，奇数子序列依分布收敛到常数 1。整个序列不依分布收敛 (两个极限不同)，但所有项都在 $[1, 5/2]$ 中，因此是概率有界的。

THEOREM 5.11 (乘积的收敛性). 设 X_n 概率有界, $Y_n \xrightarrow{P} 0$ 。则 $X_n Y_n \xrightarrow{P} 0$ 。

证明梗概：由概率有界性, $|X_n|$ 在大概率下被某个常数控制。再由 $Y_n \rightarrow 0$ 的概率，可得上确界收敛到 0。¹¹

⁹Slutsky 定理的详细证明见附录 section 5.9。

¹⁰该性质的证明见附录 ??。

¹¹完整证明见附录 section 5.10。

2.3. 5.2.2 Δ 方法. Δ 方法是处理统计量函数渐近分布的强大工具。

背景: 在渐近理论中, 我们常需确定一个函数的分布。设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 如何求 $g(X_n)$ 的渐近分布?

关键工具——Taylor 展开: 若 $g(x)$ 在 x 处可微, 则

$$g(y) = g(x) + g'(x)(y - x) + o(|y - x|). \quad (5.2.7)$$

记号 o_p 和 O_p (小 o 和大 O 的概率版本):

$$Y_n = o_p(X_n) \iff \frac{Y_n}{X_n} \xrightarrow{P} 0, \quad Y_n = O_p(X_n) \iff \frac{Y_n}{X_n} \text{ 概率有界}. \quad (5.2.8)$$

EXAMPLE 5.9 (Δ 方法的应用). 设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, g 在 θ 处可微且 $g'(\theta) \neq 0$ 。则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2). \quad (5.2.9)$$

这称为 Δ 方法。¹²

EXAMPLE 5.10 (卡方分布标准化). 在例 5.2.7 中, 我们证明了 $Z_n \sim \chi^2(n)$, 则

$$Y_n = \frac{Z_n - n}{\sqrt{2n}} \xrightarrow{D} N(0, 1). \quad (5.2.10)$$

利用 Δ 方法, 取 $g(t) = \sqrt{t}$, 则 $W_n = g(Z_n/(\sqrt{2}n)) = (Z_n/(\sqrt{2}n))^{1/2}$ 的渐近分布为

$$\sqrt{n}[W_n - 1/2^{1/4}] \xrightarrow{D} N(0, 2^{-3/2}). \quad (5.2.11)$$

这在实践中非常有用, 例如当我们对卡方变量的标准差感兴趣时。¹³

2.4. 5.2.3 矩母函数技巧. 矩母函数 (MGF) 提供了一种确定渐近分布的系统方法。

THEOREM 5.12 (MGF 收敛定理). 设 X_n 是随机变量序列, 每个 X_n 的 mgf $M_{X_n}(t)$ 在 $-h < t < h$ 上存在。设 X 的 mgf $M(t)$ 在 $|t| \leq h_1 \leq h$ 上存在。若

$$\lim_{n \rightarrow \infty} M_{X_n}(t) = M(t), \quad |t| \leq h_1,$$

则 $X_n \xrightarrow{D} X$ 。

应用: 二项分布趋近泊松分布. 设 $Y_n \sim b(n, p)$, 其中 $p = \mu/n$ (μ 固定)。则

$$M_{Y_n}(t) = [1 + p(e^t - 1)]^n = \left[1 + \frac{\mu(e^t - 1)}{n}\right]^n \rightarrow e^{\mu(e^t - 1)},$$

这正是参数为 μ 的泊松分布的 mgf。因此当 n 大、 p 小时, 二项分布可用泊松分布近似。¹⁴

应用: 卡方分布标准化趋近正态. 设 $Z_n \sim \chi^2(n)$, 可计算其 mgf 并证明

$$\frac{Z_n - n}{\sqrt{2n}} \xrightarrow{D} N(0, 1). \quad (5.2.12)$$

¹² Δ 方法的完整推导见附录 section 5.11。

¹³卡方分布 Δ 方法的详细推导见附录 ??。

¹⁴该近似的误差分析和更精确的估计见附录 section 5.12。

3. 5.3 Central Limit Theorem

本节介绍统计学中最重要、最优雅的定理之一——中心极限定理 (CLT)。

背景：在第 3 章中，我们知道若 $X_1, \dots, X_n$ 来自均值为 μ 、方差为 σ^2 的正态分布，则

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \sim N(0, 1)$$

对每个正整数 n 都成立。

中心极限定理的核心发现：这一定理告诉我们，即使总体分布不是正态，只要满足某些温和条件（有限方差），上述统计量在大样本下仍然近似服从标准正态分布！

[中心极限定理 (CLT)] 设 $X_1, X_2, \dots, X_n$ 是来自均值为 μ 、正方差为 σ^2 的分布的随机样本。则随机变量

$$Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma}$$

依分布收敛到标准正态随机变量：

$$Y_n \xrightarrow{D} N(0, 1). \quad (5.3.1)$$

实践意义：当 n 足够大（通常 $n \geq 30$ ），我们可以将 $\bar{X}$ 近似为 $N(\mu, \sigma^2/n)$ ，从而计算概率近似值。¹⁵

等价的表述：

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{D} N(0, \sigma^2). \quad (5.3.2)$$

这一表述在实践中更方便使用。

EXAMPLE 5.11 (均匀分布样本均值的概率). 设 $\bar{X}$ 是来自 $\text{Uniform}(0, 1)$ 分布、样本量为 75 的样本均值。对于该分布， $\mu = 1/2$ ， $\sigma^2 = 1/12$ 。

要计算 $P(0.45 < \bar{X} < 0.55)$ ，直接计算需要知道 $\bar{X}$ 的精确分布（由 75 个不同多项式片段组成的复杂函数）。但由 CLT，

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \approx N(0, 1),$$

因此

$$P(0.45 < \bar{X} < 0.55) \approx \Phi(1.5) - \Phi(-1.5) = 0.8663. \quad (5.3.3)$$

这个近似相当准确，尽管 $\bar{X}$ 的精确分布并不正态！¹⁶

EXAMPLE 5.12 (二项分布的正态近似). 设 $Y_n \sim b(n, p)$ 。则 $Y_n = \sum_{i=1}^n X_i$ ，其中 $X_i \sim \text{Bernoulli}(p)$ 。由 CLT，

$$\frac{Y_n - np}{\sqrt{np(1-p)}} = \frac{\sqrt{n}(\bar{X}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1). \quad (5.3.4)$$

因此， Y_n 近似服从 $N(np, np(1-p))$ 。

¹⁵中心极限定理的完整证明（包括 MGF 方法）见附录 section 5.13。

¹⁶均匀分布样本均值概率的详细计算见附录 section 5.14。

图 5.3.1 展示了 $b(10, 1/2)$ 的二项分布与 $N(5, 5/2)$ 正态近似的对比。即使 $n = 10$, 拟合效果已相当不错。

连续性校正: 对于离散分布, 通常使用 ± 0.5 的校正来提高近似精度。例如,

$$P(Y = 48, 49, 50, 51, 52) = P(47.5 < Y < 52.5). \quad (5.3.5)$$

EXAMPLE 5.13 (大样本比例推断). 设 $X_1, \dots, X_n \sim \text{Bernoulli}(p)$, $\hat{p} = \bar{X}$. 则

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1 - \hat{p})/n}} \xrightarrow{D} N(0, 1). \quad (5.3.6)$$

这是大样本置信区间和假设检验 (第 4 章) 的基础。¹⁷

EXAMPLE 5.14 (卡方检验的渐近分布). 由 CLT 和定理 5.2.4,

$$\left(\frac{Y_n - np}{\sqrt{np(1-p)}} \right)^2 \xrightarrow{D} \chi^2(1). \quad (5.3.7)$$

这正是第 4 章中拟合优度 χ^2 检验的理论基础。¹⁸

EXAMPLE 5.15 (Δ 方法与函数变换). 设 $X_1, \dots, X_n$ 是来自均值为 μ 、方差为 σ^2 的分布的随机样本。由 CLT,

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{D} N(0, \sigma^2). \quad (5.3.8)$$

对连续变换 g , 由 Δ 方法,

$$\sqrt{n}[g(\bar{X}) - g(\mu)] \xrightarrow{D} N(0, \sigma^2[g'(\mu)]^2). \quad (5.3.9)$$

应用: 反正弦变换. 在二项情形 ($X_i \sim \text{Bernoulli}(p)$), 为了获得渐近方差与 p 无关的估计, 取 $g(p) = \arcsin(\sqrt{p})$, 则

$$\sqrt{n}[\arcsin(\sqrt{\bar{X}}) - \arcsin(\sqrt{p})] \xrightarrow{D} N(0, 1/4). \quad (5.3.10)$$

这一变换在方差稳定化中有重要应用。¹⁹

4. 5.4 Extensions to Multivariate Distributions

本节简要讨论随机向量序列的渐近概念。

为什么需要多元扩展? 在多参数统计中, 我们经常同时估计多个参数, 需要知道这些估计量的联合渐近分布。

记 $\mathbf{v} \in \mathbb{R}^p$ 的 Euclidean 范数为

$$\|\mathbf{v}\| = \sqrt{\sum_{i=1}^p v_i^2}. \quad (5.4.1)$$

¹⁷比例推断的详细讨论见附录 section 5.15。

¹⁸卡方检验的详细推导见附录 ??。

¹⁹方差稳定化变换的详细讨论见附录 section 5.16。

DEFINITION 5.5 (随机向量的依概率收敛). 设 $\mathbf{X}_n$ 是一列 p 维随机向量, $\mathbf{X}$ 是随机向量。若对所有 $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}[\|\mathbf{X}_n - \mathbf{X}\| \geq \epsilon] = 0,$$

则称 $\mathbf{X}_n \xrightarrow{P} \mathbf{X}$ 。

[向量收敛等价于分量收敛] $\mathbf{X}_n \xrightarrow{P} \mathbf{X}$ 当且仅当对每个 $j = 1, \dots, p$, $X_{nj} \xrightarrow{P} X_j$ 。

应用: 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 是 iid 随机向量, 均值向量为 $\boldsymbol{\mu}$, 协方差矩阵为 $\boldsymbol{\Sigma}$ 。则样本均值向量

$$\bar{\mathbf{X}}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \xrightarrow{P} \boldsymbol{\mu}. \quad (5.4.2)$$

样本协方差矩阵 $\mathbf{S} \xrightarrow{P} \boldsymbol{\Sigma}$ 。

EXAMPLE 5.16 (多元中心极限定理). 设 $\mathbf{X}_n$ 是 iid 随机向量序列, 均值向量为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ (正定)。则

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.3)$$

证明思路: 将问题转化为一元情形。设 $\mathbf{t} \in \mathbb{R}^p$, 则 $\mathbf{t}'\mathbf{X}_i$ 是均值为 $\mathbf{t}'\boldsymbol{\mu}$ 、方差为 $\mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}$ 的随机变量。对一维随机变量应用 CLT, 再利用 mgf 的性质可得多元情形。²⁰

EXAMPLE 5.17 (线性变换的正态性). 设 $\mathbf{X}_n \xrightarrow{D} N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。则对任意常数矩阵 $\mathbf{A}$ ($m \times p$) 和向量 $\mathbf{b}$ (m 维),

$$\mathbf{A}\mathbf{X}_n + \mathbf{b} \xrightarrow{D} N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}'). \quad (5.4.4)$$

多元 Δ 方法: 设

$$\sqrt{n}(\mathbf{X}_n - \boldsymbol{\mu}_0) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}),$$

$g: \mathbb{R}^p \rightarrow \mathbb{R}^k$ 是可微变换, Jacobian 矩阵 $\mathbf{B} = \partial g / \partial \mathbf{x}$ 在 $\boldsymbol{\mu}_0$ 处非奇异。则

$$\sqrt{n}(g(\mathbf{X}_n) - g(\boldsymbol{\mu}_0)) \xrightarrow{D} N_k(\mathbf{0}, \mathbf{B}_0 \boldsymbol{\Sigma} \mathbf{B}_0'). \quad (5.4.5)$$

Exercises

EXERCISE 5.1. 5.1 Sequence Convergence Let a_n be a sequence of real numbers (degenerate random variables). Let a be a real number. Show that $a_n \rightarrow a$ is equivalent to $a_n \xrightarrow{P} a$.

EXERCISE 5.2. 5.2 Binomial Convergence Let $Y_n \sim b(n, p)$.

(a) Prove that Y_n/n converges in probability to p . This is one form of the weak law of large numbers.

(b) Prove that $1 - Y_n/n$ converges in probability to $1 - p$.

(c) Prove that $(Y_n/n)(1 - Y_n/n)$ converges in probability to $p(1 - p)$.

²⁰多元 CLT 的完整证明见附录 section 5.17。

EXERCISE 5.3. **5.3 Variance Convergence** Let W_n denote a random variable with mean μ and variance b/n^p , where $p > 0$, μ , and b are constants (not functions of n). Prove that W_n converges in probability to μ .

Hint: Use Chebyshev's inequality.

EXERCISE 5.4. **5.4 Uniform Maximum CDF** Derive the cdf given in expression (5.1.6).

EXERCISE 5.5. **5.5 Sample Median Convergence** Consider the R function `consistmean` which produces the plot shown in Figure 5.1.1. Obtain a similar plot for the sample median when the distribution sampled is the $N(0, 1)$ distribution. Compare the mean and median plots.

EXERCISE 5.6. **5.6 Uniform Maximum Plot** Write an R function that obtains a plot similar to Figure 5.1.1 for the situation described in Example 5.1.2. For the plot choose $\theta = 10$.

EXERCISE 5.7. **5.7 Shifted Exponential Minimum** Let $X_1, \dots, X_n$ be iid random variables with common pdf

$$f(x) = \begin{cases} e^{-(x-\theta)} & x > \theta, -\infty < \theta < \infty \\ 0 & \text{elsewhere.} \end{cases} \quad (5.1.3)$$

This pdf is called the shifted exponential. Let $Y_n = \min X_1, \dots, X_n$. Prove that $Y_n \rightarrow \theta$ in probability by first obtaining the cdf of Y_n .

EXERCISE 5.8. **5.8 Ratio Convergence** Using the assumptions behind the confidence interval given in expression (4.3.3), show that

$$\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} / \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \xrightarrow{P} 1.$$

EXERCISE 5.9. **5.9 Shifted Exponential Mean** For Exercise 5.1.7, obtain the mean of Y_n . Is Y_n an unbiased estimator of θ ? Obtain an unbiased estimator of θ based on Y_n .

EXERCISE 5.10. **5.10 Normal Sample Mean Limit** Let $\bar{X}_n$ denote the mean of a random sample of size n from a distribution that is $N(\mu, \sigma^2)$. Find the limiting distribution of $\bar{X}_n$.

EXERCISE 5.11. **5.11 Exponential Minimum Limit** Let Y_1 denote the minimum of a random sample of size n from a distribution that has pdf $f(x) = e^{-(x-\theta)}$, $\theta < x < \infty$, zero elsewhere. Let $Z_n = n(Y_1 - \theta)$. Investigate the limiting distribution of Z_n .

EXERCISE 5.12. **5.12 Maximum Limit Distribution** Let Y_n denote the maximum of a random sample of size n from a distribution of the continuous type that has cdf $F(x)$ and pdf $f(x) = F'(x)$. Find the limiting distribution of $Z_n = n[1 - F(Y_n)]$.

EXERCISE 5.13. **5.13** *Second Minimum Limit* Let Y_2 denote the second smallest item of a random sample of size n from a distribution of the continuous type that has cdf $F(x)$ and pdf $f(x) = F'(x)$. Find the limiting distribution of $W_n = nF(Y_2)$.

EXERCISE 5.14. **5.14** *No Limiting Distribution* Let the pmf of Y_n be $p_n(y) = 1$, $y = n$, zero elsewhere. Show that Y_n does not have a limiting distribution. (In this case, the probability has "escaped" to infinity.)

EXERCISE 5.15. **5.15** *Normal Sum No Limit* Let $X_1, X_2, \dots, X_n$ be a random sample of size n from a distribution that is $N(\mu, \sigma^2)$, where $\sigma^2 > 0$. Show that the sum $Z_n = \sum_{i=1}^n X_i$ does not have a limiting distribution.

EXERCISE 5.16. **5.16** *Gamma Limit* Let X_n have a gamma distribution with parameter $\alpha = n$ and β , where β is not a function of n . Let $Y_n = X_n/n$. Find the limiting distribution of Y_n .

EXERCISE 5.17. **5.17** *Chi-Square Ratio Limit* Let Z_n be $\chi^2(n)$ and let $W_n = Z_n/n^2$. Find the limiting distribution of W_n .

EXERCISE 5.18. **5.18** *Chi-Square Probability* Let X be $\chi^2(50)$. Using the limiting distribution discussed in Example 5.2.7, approximate $P(40 < X < 60)$. Compare your answer with that calculated by R .

EXERCISE 5.19. **5.19** *Poisson Binomial Approximation* Let $p = 0.95$ be the probability that a man, in a certain age group, lives at least 5 years.

- (a) If we are to observe 60 such men and if we assume independence, use R to compute the probability that at least 56 of them live 5 or more years.
- (b) Find an approximation to the result of part (a) by using the Poisson distribution.

Hint: Redefine p to be 0.05 and $1 - p = 0.95$.

EXERCISE 5.20. **5.20** *Poisson to Normal* Let the random variable Z_n have a Poisson distribution with parameter $\mu = n$. Show that the limiting distribution of the random variable $Y_n = (Z_n - n)/\sqrt{n}$ is normal with mean zero and variance 1.

EXERCISE 5.21. **5.21** *Normal Sample Chi-Square* Let $\bar{X}_n$ denote the mean of a random sample of size 100 from a distribution that is $\chi^2(50)$. Compute an approximate value of $P(49 < \bar{X} < 51)$.

EXERCISE 5.22. **5.22** *Gamma Sample Mean* Let $\bar{X}_n$ denote the mean of a random sample of size 128 from a gamma distribution with $\alpha = 2$ and $\beta = 4$. Approximate $P(7 < \bar{X} < 9)$.

EXERCISE 5.23. **5.23** *Binomial Probability* Let Y be $b(72, 1/3)$. Approximate $P(22 \leq Y \leq 28)$.

EXERCISE 5.24. **5.24** *Beta Sample Mean* Compute an approximate probability that the mean of a random sample of size 15 from a distribution having pdf $f(x) = 3x^2$, $0 < x < 1$, zero elsewhere, is between $\frac{3}{5}$ and $\frac{4}{5}$.

EXERCISE 5.25. **5.25** *Discrete Sample Sum* Let Y denote the sum of the observations of a random sample of size 12 from a distribution having pmf $p(x) = 1/6$, $x = 1, 2, 3, 4, 5, 6$, zero elsewhere. Compute an approximate value of $P(36 \leq Y \leq 48)$.

Hint: Since the event of interest is $Y = 36, 37, \dots, 48$, rewrite the probability as $P(35.5 < Y < 48.5)$.

EXERCISE 5.26. **5.26** *Binomial Proportion* Let Y be $b(400, 1/5)$. Compute an approximate value of $P(0.25 < Y/400)$.

EXERCISE 5.27. **5.27** *Binomial Point Probability* If Y is $b(100, 1/2)$, approximate the value of $P(Y = 50)$.

EXERCISE 5.28. **5.28** *Sample Size for Proportion* Let Y be $b(n, 0.55)$. Find the smallest value of n such that (approximately) $P(Y/n > 1/2) \geq 0.95$.

EXERCISE 5.29. **5.29** *Tail Probability Approximation* Let $f(x) = 1/x^2$, $1 < x < \infty$, zero elsewhere, be the pdf of a random variable X . Consider a random sample of size 72 from the distribution having this pdf. Compute approximately the probability that more than 50 of the observations of the random sample are less than 3.

EXERCISE 5.30. **5.30** *Rounding Error Approximation* Forty-eight measurements are recorded to several decimal places. Each of these 48 numbers is rounded off to the nearest integer. The sum of the original 48 numbers is approximated by the sum of these integers. If we assume that the errors made by rounding off are iid and have a uniform distribution over the interval $(-1/2, 1/2)$, compute approximately the probability that the sum of the integers is within two units of the true sum.

EXERCISE 5.31. **5.31** *Cube Transformation* We know that $\bar{X}$ is approximately $N(\mu, \sigma^2/n)$ for large n . Find the approximate distribution of $u(\bar{X}) = \bar{X}^3$, provided that $\mu \neq 0$.

EXERCISE 5.32. **5.32** *Variance Stabilization* Let $X_1, X_2, \dots, X_n$ be a random sample from a Poisson distribution with mean μ . Thus, $Y = \sum_{i=1}^n X_i$ has a Poisson distribution with mean $n\mu$. Moreover, $\bar{X} = Y/n$ is approximately $N(\mu, \mu/n)$ for large n . Show that $u(Y/n) = \sqrt{Y/n}$ is a function of Y/n whose variance is essentially free of μ .

EXERCISE 5.33. **5.33** *Proportion CLT* Using the notation of Example 5.3.5, show that equation (5.3.6) is true.

EXERCISE 5.34. **5.34** *Gamma Asymptotics* Assume that $X_1, \dots, X_n$ is a random sample from a $\Gamma(1, \beta)$ distribution. Determine the asymptotic distribution of $\sqrt{n}(\bar{X} - \beta)$. Then find a transformation $g(\bar{X})$ whose asymptotic variance is free of β .

EXERCISE 5.35. **5.35 Multivariate Convergence** Let $\mathbf{X}_n$ be a sequence of p -dimensional random vectors. Show that

$$\mathbf{X}_n \xrightarrow{D} N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \text{ if and only if } \mathbf{a}'\mathbf{X}_n \xrightarrow{D} N_1(\mathbf{a}'\boldsymbol{\mu}, \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a}),$$

for all vectors $\mathbf{a} \in \mathbb{R}^p$.

EXERCISE 5.36. **5.36 Uniform Vector Convergence** Let $X_1, \dots, X_n$ be a random sample from a $\text{Uniform}(a, b)$ distribution. Let $Y_1 = \min X_i$ and let $Y_2 = \max X_i$. Show that $(Y_1, Y_2)'$ converges in probability to the vector $(a, b)'$.

本章小结

核心概念：

- 依概率收敛： $X_n \xrightarrow{P} X$ ，概率质量越来越集中在目标附近
- 依分布收敛： $X_n \xrightarrow{D} X$ ，分布函数在连续点处收敛
- 弱大数定律：样本均值依概率收敛到总体均值
- 中心极限定理：标准化样本均值趋向标准正态分布
- Slutsky 定理：允许依概率收敛的随机变量参与依分布收敛的线性组合
- Δ 方法：处理统计量函数渐近分布的工具
- 一致性：估计量的基本要求， $T_n \xrightarrow{P} \theta$

重要公式：

场景	渐近分布
$\sqrt{n}(\bar{X} - \mu)/\sigma$	$N(0, 1)$ (CLT)
$\bar{X}_n$	$N(\mu, \sigma^2/n)$ (大样本)
$\sqrt{n}(g(\bar{X}) - g(\mu))$	$N(0, \sigma^2[g'(\mu)]^2)$ (Δ 方法)
$\hat{p}$ 样本比例	$N(p, p(1-p)/n)$ (大样本)
$(Y_n - np)/\sqrt{np(1-p)}$	$N(0, 1)$ (二项正态近似)

收敛关系图：

依概率收敛 + 连续函数 $\Rightarrow$ 依概率收敛

依概率收敛 $\Rightarrow$ 依分布收敛

依分布收敛 (常数) $\Leftrightarrow$ 依概率收敛

5. 附录：公式推导

5.1. 弱大数定律的完整证明. 背景 (Background)：弱大数定律 (WLLN) 是最基本的渐近结果之一，说明样本均值依概率收敛到总体均值。

已知条件 (Given)：

- $X_1, X_2, \dots, X_n$ 是 iid 随机变量
- $E(X_i) = \mu$
- $\text{Var}(X_i) = \sigma^2 < \infty$
- $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$

目标 (Goal): 证明 $\bar{X}_n \xrightarrow{P} \mu$ 。

推导步骤 (Derivation Steps):

1. 计算 $\bar{X}_n$ 的均值和方差:

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu,$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

2. 对任意 $\epsilon > 0$, 应用 Chebyshev 不等式:

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}.$$

3. 当 $n \rightarrow \infty$ 时, 右边趋于 0, 故

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) = 0.$$

结论: 由定义, $\bar{X}_n \xrightarrow{P} \mu$ 。

5.2. 依概率收敛性质证明. 背景: 证明若 $X_n \xrightarrow{P} X$ 和 $Y_n \xrightarrow{P} Y$, 则 $X_n Y_n \xrightarrow{P} XY$ 。

推导步骤:

1. 利用恒等式:

$$X_n Y_n = \frac{1}{2} X_n^2 + \frac{1}{2} Y_n^2 - \frac{1}{2} (X_n - Y_n)^2.$$

2. 由定理 5.1.3 (标量乘积收敛) 和定理 5.1.2 (和的收敛), $X_n^2 \xrightarrow{P} X^2$, $Y_n^2 \xrightarrow{P} Y^2$, $(X_n - Y_n)^2 \xrightarrow{P} (X - Y)^2$ 。

3. 因此

$$X_n Y_n \xrightarrow{P} \frac{1}{2} X^2 + \frac{1}{2} Y^2 - \frac{1}{2} (X - Y)^2 = XY.$$

证毕。

5.3. 样本方差一致性的详细推导. 背景: 证明样本方差 S_n^2 是 σ^2 的一致估计量。

已知条件:

- $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$
- $E(X_i^4) < \infty$ (有限四阶矩)

推导步骤:

1. 由弱大数定律:

$$\bar{X}_n \xrightarrow{P} \mu, \quad \frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} E(X_1^2).$$

2. 利用恒等式:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{n}{n-1} \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \right).$$

3. 由连续映射定理 (定理 5.1.4), $\bar{X}_n^2 \xrightarrow{P} \mu^2$ 。

4. 因此

$$\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2 \xrightarrow{P} E(X_1^2) - \mu^2 = \sigma^2.$$

5. 由于 $\frac{n}{n-1} \rightarrow 1$, 故 $S_n^2 \xrightarrow{P} \sigma^2$ 。

结论: S_n^2 是 σ^2 的一致估计。

5.4. 均匀分布最大值分析. 背景: 分析 $\text{Uniform}(0, \theta)$ 分布最大值的渐近行为。

已知条件: $Y_n = \max X_1, \dots, X_n$, 其中 $X_i \sim \text{Uniform}(0, \theta)$ 。

推导步骤:

1. 求 Y_n 的 CDF:

$$F_{Y_n}(t) = \mathbb{P}(Y_n \leq t) = \mathbb{P}(X_1 \leq t, \dots, X_n \leq t) = [F_X(t)]^n = \left(\frac{t}{\theta}\right)^n,$$

对 $0 < t \leq \theta$ 。

2. 求 Y_n 的 PDF:

$$f_{Y_n}(t) = \frac{d}{dt} F_{Y_n}(t) = \frac{n}{\theta^n} t^{n-1}, \quad 0 < t \leq \theta.$$

3. 计算期望:

$$E(Y_n) = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{n+1} \theta.$$

关键发现: $Y_n \xrightarrow{P} \theta$, 因为对任意 $\epsilon > 0$,

$$\mathbb{P}(|Y_n - \theta| \geq \epsilon) = \mathbb{P}(Y_n \leq \theta - \epsilon) = \left(\frac{\theta - \epsilon}{\theta}\right)^n \rightarrow 0.$$

渐近分布: 标准化后 $n(\theta - Y_n) \xrightarrow{D} \Gamma(1, \theta)$ (见例 5.2.4)。

5.5. 退化分布的例子. 背景: 说明为什么在 CDF 的间断点处不要求收敛。

例子: 设 X_n 所有概率质量集中在 $1/n$, X 所有概率质量集中在 0。

(1) 若 $x < 0$, 则 $F_{X_n}(x) = 0 = F_X(x)$ 。

(2) 若 $x > 0$, 则 $F_{X_n}(x) = 1 = F_X(x)$ 。

(3) 若 $x = 0$ (F_X 的间断点), 则 $F_{X_n}(0) = 0 \neq 1 = F_X(0)$ 。

因此 $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$ 对所有 $x \in C(F_X)$ (即 $x \neq 0$) 成立, 故 $X_n \xrightarrow{D} X$ 。

5.6. Stirling 公式. 背景: Stirling 公式在渐近分析中非常重要。

公式:

$$\Gamma(k+1) \approx \sqrt{2\pi} k^{k+1/2} e^{-k}. \quad (5.2.2)$$

应用: 在例 5.2.3 中, 证明 t 分布趋向标准正态分布时, 需要用到

$$\lim_{n \rightarrow \infty} \frac{\Gamma[(n+1)/2]}{\sqrt{n/2} \Gamma(n/2)} = 1.$$

使用 Stirling 公式:

$$\frac{\Gamma[(n+1)/2]}{\sqrt{n/2} \Gamma(n/2)} \approx \frac{\sqrt{2\pi} (n/2)^{n/2+1/2} e^{-n/2}}{\sqrt{n/2} \sqrt{2\pi} (n/2-1)^{n/2-1/2} e^{-(n/2-1)}} = 1.$$

5.7. 均匀分布到指数分布的极限. 背景：证明 $n(\theta - Y_n) \xrightarrow{D} \Gamma(1, \theta)$ 。

推导：

对 $t > 0$,

$$\mathbb{P}[n(\theta - Y_n) \leq t] = \mathbb{P}[Y_n \geq \theta - t/n] = 1 - F_{Y_n}(\theta - t/n).$$

由 $F_{Y_n}(t) = (t/\theta)^n$ (对 $0 < t \leq \theta$),

$$1 - F_{Y_n}(\theta - t/n) = 1 - \left(\frac{\theta - t/n}{\theta}\right)^n = 1 - \left(1 - \frac{t}{n\theta}\right)^n.$$

令 $n \rightarrow \infty$,

$$\lim_{n \rightarrow \infty} \left(1 - \frac{t}{n\theta}\right)^n = e^{-t/\theta}.$$

因此

$$\lim_{n \rightarrow \infty} \mathbb{P}[n(\theta - Y_n) \leq t] = 1 - e^{-t/\theta},$$

这正是 $\Gamma(1, \theta)$ (指数分布) 的 CDF。

5.8. 依概率收敛推出依分布收敛的证明. 背景：证明定理 5.2.1。

目标：若 $X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{D} X$ 。

推导步骤：

1. 设 x 是 F_X 的连续点。对 $\epsilon > 0$,

$$F_{X_n}(x) = \mathbb{P}[X_n \leq x] = \mathbb{P}[X_n \leq x, |X_n - X| < \epsilon] + \mathbb{P}[X_n \leq x, |X_n - X| \geq \epsilon].$$

2. 第一个概率 $\leq \mathbb{P}[X \leq x + \epsilon]$, 第二个概率 $\leq \mathbb{P}[|X_n - X| \geq \epsilon]$ 。因此

$$F_{X_n}(x) \leq F_X(x + \epsilon) + \mathbb{P}[|X_n - X| \geq \epsilon].$$

3. 取上确界并令 $n \rightarrow \infty$ (利用 $X_n \xrightarrow{P} X$), 再令 $\epsilon \rightarrow 0$ (利用 x 是连续点), 可得

$$\overline{\lim}_{n \rightarrow \infty} F_{X_n}(x) \leq F_X(x).$$

4. 类似地可得

$$\underline{\lim}_{n \rightarrow \infty} F_{X_n}(x) \geq F_X(x).$$

5. 因此 $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$ 。

证毕。

5.9. Slutsky 定理的详细证明. 背景：Slutsky 定理是连接依概率收敛和依分布收敛的关键工具。

定理陈述：若 $X_n \xrightarrow{D} X$, $A_n \xrightarrow{P} a$, $B_n \xrightarrow{P} b$, 则 $A_n + B_n X_n \xrightarrow{D} a + bX$ 。

推导步骤：

1. 首先证明 $B_n X_n \xrightarrow{D} bX$ 。

考虑 $B_n X_n = bX_n + (B_n - b)X_n$ 。由 $B_n \xrightarrow{P} b$, 有 $B_n - b \xrightarrow{P} 0$ 。

2. 由定理 5.2.6 (依分布收敛蕴含概率有界), X_n 概率有界。

3. 应用定理 5.2.7 (概率有界序列与依概率收敛到零的乘积趋于零):

$$(B_n - b)X_n \xrightarrow{P} 0.$$

4. 由定理 5.2.3 (和的极限分布), $bX_n + (B_n - b)X_n \xrightarrow{D} bX$ 。

5. 再考虑 $A_n + B_nX_n = a + bX + (A_n - a) + (B_nX_n - bX)$ 。

由于 $(A_n - a) \xrightarrow{P} 0$ 和 $(B_nX_n - bX) \xrightarrow{P} 0$, 再次应用定理 5.2.3 可得

$$A_n + B_nX_n \xrightarrow{D} a + bX.$$

证毕。

核心洞察: Slutsky 定理允许我们将依概率收敛的随机变量”替换”为其极限常数, 而不影响依分布收敛性。

5.10. 概率有界与乘积收敛的证明. 背景: 证明定理 5.2.7。

目标: 若 X_n 概率有界, $Y_n \xrightarrow{P} 0$, 则 $X_nY_n \xrightarrow{P} 0$ 。

推导步骤:

1. 由概率有界性, 对 $\epsilon > 0$, 存在 B_ϵ 和 N_ϵ 使得

$$n \geq N_\epsilon \Rightarrow \mathbb{P}[|X_n| \leq B_\epsilon] \geq 1 - \epsilon.$$

2. 对任意 $\delta > 0$,

$$\mathbb{P}[|X_nY_n| \geq \delta] = \mathbb{P}[|X_nY_n| \geq \delta, |X_n| \leq B_\epsilon] + \mathbb{P}[|X_nY_n| \geq \delta, |X_n| > B_\epsilon].$$

3. 第一个概率 $\leq \mathbb{P}[|Y_n| \geq \delta/B_\epsilon]$, 第二个概率 $\leq \mathbb{P}[|X_n| > B_\epsilon] \leq \epsilon$ 。

4. 由于 $Y_n \xrightarrow{P} 0$, 当 n 足够大时, 第一个概率 $< \epsilon$ 。

5. 因此对足够大的 n , $\mathbb{P}[|X_nY_n| \geq \delta] \leq 2\epsilon$ 。

由 ϵ 和 δ 的任意性, $X_nY_n \xrightarrow{P} 0$ 。

证毕。

5.11. Δ 方法的完整推导. 背景: Δ 方法提供了一种计算统计量函数渐近分布的系统方法。

定理陈述: 设 $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, g 在 θ 处可微且 $g'(\theta) \neq 0$ 。则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

推导步骤:

1. 由 Taylor 展开 (带余项):

$$g(X_n) = g(\theta) + g'(\theta)(X_n - \theta) + o_p(|X_n - \theta|).$$

2. 两边乘以 $\sqrt{n}$:

$$\sqrt{n}(g(X_n) - g(\theta)) = g'(\theta)\sqrt{n}(X_n - \theta) + o_p(\sqrt{n}|X_n - \theta|).$$

3. 由假设, $\sqrt{n}(X_n - \theta) \xrightarrow{D} N(0, \sigma^2)$, 故 $\sqrt{n}|X_n - \theta|$ 概率有界。

4. 由 o_p 的定义, $o_p(\sqrt{n}|X_n - \theta|) \xrightarrow{P} 0$ 。

5. 应用 Slutsky 定理（或更精确地，定理 5.2.3），可得

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{D} N(0, \sigma^2[g'(\theta)]^2).$$

证毕。

应用举例：卡方分布的平方根。设 $Z_n \sim \chi^2(n)$ ，则

$$\sqrt{n} \left(\frac{Z_n}{n} - 1 \right) \xrightarrow{D} N(0, 2).$$

取 $g(t) = \sqrt{t}$ ，则 $g'(1) = 1/2$ ，故

$$\sqrt{n}(\sqrt{Z_n/n} - 1) \xrightarrow{D} N(0, 2 \cdot (1/2)^2) = N(0, 1/2).$$

5.12. 二项分布的正态近似误差分析. 背景：二项分布 $b(n, p)$ 在大样本下可用正态分布近似。

误差分析：

设 $Y \sim b(n, p)$ ， $\mu = np$ ， $\sigma^2 = np(1-p)$ 。则

$$Z = \frac{Y - \mu}{\sigma} \xrightarrow{D} N(0, 1).$$

Berry-Esseen 不等式给出了收敛速度的估计：

$$\sup_x |\mathbb{P}(Z \leq x) - \Phi(x)| \leq \frac{C \cdot \rho}{\sigma^3 \sqrt{n}},$$

其中 $\rho = E(|X - \mu|^3)$ ， C 是某个绝对常数（约 0.4748）。

实践意义：当 $np(1-p) \geq 10$ 时，正态近似效果较好。

连续性校正的效果：对于离散分布，使用 ± 0.5 的校正通常可以将误差减少一半。

5.13. 中心极限定理的 MGF 证明. 背景：中心极限定理（CLT）的矩母函数证明。

假设： $X_1, \dots, X_n$ 是 iid 随机变量， $E(X_i) = \mu$ ， $\text{Var}(X_i) = \sigma^2$ ，矩母函数 $M(t) = E(e^{tX})$ 在 0 的邻域内存在。

目标：证明

$$Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \xrightarrow{D} N(0, 1).$$

推导步骤：

1. 考虑 $X_i - \mu$ 的矩母函数 $m(t) = E(e^{t(X_i - \mu)})$ 。则 $m(0) = 1$ ， $m'(0) = 0$ ， $m''(0) = \sigma^2$ 。

2. 由 Taylor 公式，存在 ξ （介于 0 和 t 之间）使得

$$m(t) = 1 + \frac{\sigma^2 t^2}{2} + \frac{[m''(\xi) - \sigma^2] t^2}{2}. \quad (5.3.1)$$

3. Y_n 的矩母函数为

$$M_{Y_n}(t) = E \left[\exp \left(t \frac{\sum X_i - n\mu}{\sqrt{n}\sigma} \right) \right] = [m(t/(\sigma\sqrt{n}))]^n. \quad (5.3.2)$$

4. 将 $t/(\sigma\sqrt{n})$ 代入 (5.3.1)：

$$m \left(\frac{t}{\sigma\sqrt{n}} \right) = 1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2] t^2}{2n\sigma^2},$$

其中 ξ 介于 0 和 $t/(\sigma\sqrt{n})$ 之间。

5. 因此

$$M_{Y_n}(t) = \left[1 + \frac{t^2}{2n} + \frac{[m''(\xi) - \sigma^2]t^2}{2n\sigma^2} \right]^n.$$

6. 由于 $m''(t)$ 在 0 处连续, 且 $\xi \rightarrow 0$ 当 $n \rightarrow \infty$, 故

$$\lim_{n \rightarrow \infty} [m''(\xi) - \sigma^2] = 0.$$

7. 应用极限定理 (5.2.16):

$$\lim_{n \rightarrow \infty} M_{Y_n}(t) = \lim_{n \rightarrow \infty} \left[1 + \frac{t^2}{2n} \right]^n = e^{t^2/2},$$

这正是 $N(0, 1)$ 的矩母函数。

结论: 由矩母函数收敛定理, $Y_n \xrightarrow{D} N(0, 1)$ 。

证毕。

注: 若不使用矩母函数而使用特征函数, 则证明对所有分布成立 (特征函数总是存在的)。

5.14. 均匀分布样本均值的概率计算. 背景: 计算 $P(0.45 < \bar{X} < 0.55)$ 的近似值。

已知条件:

- $X_i \sim \text{Uniform}(0, 1)$
- $n = 75$
- $\mu = 1/2, \sigma^2 = 1/12$

推导步骤:

1. 由 CLT,

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \approx N(0, 1).$$

2. 标准化:

$$P(0.45 < \bar{X} < 0.55) = P\left(\frac{\sqrt{n}(0.45 - \mu)}{\sigma} < \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} < \frac{\sqrt{n}(0.55 - \mu)}{\sigma}\right).$$

3. 代入数值:

$$\frac{\sqrt{75}(0.5 - 0.5)}{1/\sqrt{12}} = 0, \quad \frac{\sqrt{75}(0.55 - 0.5)}{1/\sqrt{12}} = \sqrt{75} \cdot 0.05 \cdot \sqrt{12} \approx 1.5.$$

4. 因此

$$P(0.45 < \bar{X} < 0.55) \approx \Phi(1.5) - \Phi(-1.5) = 2\Phi(1.5) - 1 \approx 2(0.9332) - 1 = 0.8664.$$

精确值比较: 使用 R 计算精确概率约为 0.864, 近似值 0.866 非常接近。

5.15. 比例推断的详细讨论. 背景：大样本比例推断的理论基础。

设 $X_1, \dots, X_n \sim \text{Bernoulli}(p)$, $\hat{p} = \bar{X}$ 。

推导步骤：

1. 由 CLT,

$$\frac{\sqrt{n}(\hat{p} - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1). \quad (5.3.4)$$

2. 但 p 未知! 用 $\hat{p}$ 替代 p 。需证明

$$\frac{\hat{p}(1-\hat{p})}{p(1-p)} \xrightarrow{P} 1. \quad (5.3.6)$$

3. 由弱大数定律, $\hat{p} \xrightarrow{P} p$, 再由连续映射定理,

$$\hat{p}(1-\hat{p}) \xrightarrow{P} p(1-p).$$

4. 由 Slutsky 定理,

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})/n}} = \frac{\sigma}{\sqrt{\hat{p}(1-\hat{p})}} \cdot \frac{\sqrt{n}(\hat{p} - p)}{\sigma} \xrightarrow{D} N(0, 1). \quad (5.3.7)$$

这正是大样本比例置信区间和假设检验的理论基础。

置信区间： p 的 $100(1-\alpha)\%$ 置信区间为

$$\left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]. \quad (5.3.8)$$

假设检验： 检验 $H_0: p = p_0$ 的检验统计量为

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} \xrightarrow{H_0} N(0, 1). \quad (5.3.9)$$

5.16. 方差稳定化变换. 背景：在例 5.3.7 中, 我们寻求一个变换使渐近方差与参数无关。

问题：设 $X \sim \text{Binomial}(1, p)$, $\hat{p} = \bar{X}$ 。求变换 g 使得 $\text{Var}[\sqrt{n}g(\hat{p})]$ 与 p 无关。

推导步骤：

1. 由 Δ 方法,

$$\text{Var}[\sqrt{n}g(\hat{p})] \approx \sigma^2[g'(p)]^2 = p(1-p)[g'(p)]^2. \quad (5.3.10)$$

2. 要求 $p(1-p)[g'(p)]^2 = c$ (常数), 即

$$g'(p) = \frac{c}{\sqrt{p(1-p)}}. \quad (5.3.11)$$

3. 积分得

$$g(p) = c \int \frac{1}{\sqrt{p(1-p)}} dp = 2c \arcsin(\sqrt{p}) + \text{常数}. \quad (5.3.12)$$

4. 取 $c = 1/2$ 可得最简单的形式 $g(p) = \arcsin(\sqrt{p})$ 。

结论：变换 $g(\hat{p}) = \arcsin(\sqrt{\hat{p}})$ 的渐近方差为 $1/(4n)$, 与 p 无关。²¹

²¹方差稳定化变换的更多应用见 DeGroot 和 Schervish 的《概率与统计》。

5.17. 多元中心极限定理的证明. 背景: 多元中心极限定理说明样本均值向量的标准化形式依分布收敛到多元正态分布。

定理陈述: 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 是 iid 随机向量, 均值向量为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ (正定)。则

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.3)$$

推导步骤:

1. 对任意固定向量 $\mathbf{t} \in \mathbb{R}^p$, 考虑随机变量 $W_i = \mathbf{t}'\mathbf{X}_i$ 。

2. 则 $E(W_i) = \mathbf{t}'\boldsymbol{\mu}$, $\text{Var}(W_i) = \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}$ 。

3. 对 $W_1, \dots, W_n$ 应用一元 CLT:

$$\sqrt{n}(\bar{W}_n - \mathbf{t}'\boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}). \quad (5.4.8)$$

4. 但 $\bar{W}_n = \mathbf{t}'\bar{\mathbf{X}}_n$, 故

$$\sqrt{n}(\mathbf{t}'\bar{\mathbf{X}}_n - \mathbf{t}'\boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{t}'\boldsymbol{\Sigma}\mathbf{t}). \quad (5.4.9)$$

5. 由 Cramer-Wold 定理 (若对所有 $\mathbf{t}$, $\mathbf{t}'\mathbf{X}_n \xrightarrow{D} \mathbf{t}'\mathbf{X}$, 则 $\mathbf{X}_n \xrightarrow{D} \mathbf{X}$), 可得

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}). \quad (5.4.10)$$

证毕。

注: Cramer-Wold 定理的证明依赖于特征函数的一致有界性和逆转公式。

附录：公式推导

0.1. Gamma 分布的矩母函数推导. 背景 (Background)： 在正文中我们声明 Gamma 分布的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。这里给出完整推导。

参数定义 (Parameter Definitions)：

- $\alpha > 0$: 形状参数 (shape parameter)
- $\beta > 0$: 尺度参数 (scale parameter)
- $X \sim \Gamma(\alpha, \beta)$: 服从 Gamma 分布的随机变量

已知条件 (Given)：

- Gamma 分布的 pdf: $f(x) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta}$, $x > 0$
- 矩母函数定义: $M(t) = \mathbb{E}(e^{tX})$

目标 (Goal)： 证明 $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$ 。

推导步骤 (Derivation Steps)：

1. 根据矩母函数定义：

$$M(t) = \int_0^\infty e^{tx} \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} dx = \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty x^{\alpha-1} e^{-x(1-\beta t)/\beta} dx.$$

2. 作变量替换：令 $y = \frac{x(1-\beta t)}{\beta}$ ，则 $x = \frac{\beta y}{1-\beta t}$ ， $dx = \frac{\beta}{1-\beta t} dy$ 。
3. 代入积分（要求 $t < 1/\beta$ 以保证 $1 - \beta t > 0$ ）：

$$\begin{aligned} M(t) &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \int_0^\infty \left(\frac{\beta y}{1-\beta t} \right)^{\alpha-1} e^{-y} \frac{\beta}{1-\beta t} dy \\ &= \frac{1}{\Gamma(\alpha)\beta^\alpha} \cdot \frac{\beta^\alpha}{(1-\beta t)^\alpha} \int_0^\infty y^{\alpha-1} e^{-y} dy \\ &= \frac{1}{(1-\beta t)^\alpha} \cdot \Gamma(\alpha) \\ &= (1-\beta t)^{-\alpha}. \end{aligned}$$

结论： 因此， $X \sim \Gamma(\alpha, \beta)$ 的矩母函数为 $M(t) = (1 - \beta t)^{-\alpha}$ ，定义域为 $t < 1/\beta$ 。■

0.2. Gamma 分布的均值与方差推导. 背景 (Background)： 在正文中我们给出 Gamma 分布的均值为 $\mathbb{E}X = \alpha\beta$ ，方差为 $\text{var}(X) = \alpha\beta^2$ 。这里基于矩母函数给出推导。

已知条件 (Given)：

- 矩母函数: $M(t) = (1 - \beta t)^{-\alpha}$ for $t < 1/\beta$
- 均值公式: $\mathbb{E}X = M'(0)$
- 方差公式: $\text{var}(X) = M''(0) - [M'(0)]^2$

目标 (Goal): 计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. 计算一阶导数:

$$M'(t) = -\alpha(1 - \beta t)^{-\alpha-1}(-\beta) = \alpha\beta(1 - \beta t)^{-\alpha-1}.$$

2. 计算二阶导数:

$$M''(t) = \alpha\beta \cdot (-\alpha - 1)(1 - \beta t)^{-\alpha-2}(-\beta) = \alpha(\alpha + 1)\beta^2(1 - \beta t)^{-\alpha-2}.$$

3. 代入 $t = 0$:

$$M'(0) = \alpha\beta(1 - 0)^{-\alpha-1} = \alpha\beta = \mathbb{E}X.$$

$$M''(0) = \alpha(\alpha + 1)\beta^2(1 - 0)^{-\alpha-2} = \alpha(\alpha + 1)\beta^2.$$

4. 计算方差:

$$\text{var}(X) = M''(0) - [M'(0)]^2 = \alpha(\alpha + 1)\beta^2 - (\alpha\beta)^2 = \alpha\beta^2.$$

结论: 因此, $\mathbb{E}X = \alpha\beta$, $\text{var}(X) = \alpha\beta^2$ 。■

0.3. 卡方分布与 Gamma 分布的关系. 背景 (Background): 卡方分布 $\chi^2(n)$ 是统计学中最重要的分布之一, 它实际上是 Gamma 分布的特例。

参数定义 (Parameter Definitions):

- n : 自由度 (degrees of freedom)
- $Z_1, Z_2, \dots, Z_n \sim N(0, 1)$ iid
- $X = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$

目标 (Goal): 证明 $X \sim \Gamma(n/2, 2)$ 。

推导步骤 (Derivation Steps):

1. 单个标准正态平方的分布: 若 $Z \sim N(0, 1)$, 则 $Y = Z^2$ 的 pdf 为

$$f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2} y^{-1/2} = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2}, \quad y > 0.$$

这正是 $\Gamma(1/2, 2)$ 的形式。

2. 利用 Gamma 分布的可加性: 若 $Y_1 \sim \Gamma(\alpha_1, \beta)$, $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立, 则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 由于 $Z_1^2, Z_2^2, \dots, Z_n^2$ 独立同分布, 且每个 $Z_i^2 \sim \Gamma(1/2, 2)$, 根据可加性:

$$X = \sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, 2\right).$$

结论: 卡方分布 $\chi^2(n)$ 等价于 $\Gamma(n/2, 2)$ 。■

0.4. 边缘分布公式的推导. 背景 (Background): 在正文中我们给出边缘分布的公式。这里展示如何从联合分布推导边缘分布。

目标 (Goal): 证明 $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。

推导步骤 (Derivation Steps):

1. 从联合 cdf 出发, 对 x_2 求导得到联合 pdf:

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2).$$

2. 边缘 cdf 定义为:

$$F_{X_1}(x_1) = \mathbb{P}(X_1 \leq x_1) = \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

3. 对边缘 cdf 求导:

$$f_{X_1}(x_1) = \frac{d}{dx_1} F_{X_1}(x_1) = \frac{d}{dx_1} \lim_{x_2 \rightarrow \infty} F_{X_1, X_2}(x_1, x_2).$$

4. 利用 Leibniz 积分法则:

$$\frac{d}{dx_1} \int_{-\infty}^{x_1} \int_{-\infty}^{\infty} f(w_1, w_2) dw_2 dw_1 = \int_{-\infty}^{\infty} f(x_1, w_2) dw_2.$$

结论: 因此, $f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2$ 。对于离散情形, 将积分替换为求和即可。■

0.5. 期望线性性的推导. 背景 (Background): 在正文中我们声称期望算子 E 是线性的, 即 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。

目标 (Goal): 给出这一性质的形式化推导。

推导步骤 (Derivation Steps):

1. 期望定义 (连续型):

$$\mathbb{E}(aY_1 + bY_2) = \int \int [ay_1 + by_2] f(y_1, y_2) dy_1 dy_2.$$

2. 利用积分的线性性:

$$= a \int \int y_1 f(y_1, y_2) dy_1 dy_2 + b \int \int y_2 f(y_1, y_2) dy_1 dy_2.$$

3. 由联合 pdf 的性质 $\int \int f(y_1, y_2) dy_1 dy_2 = 1$, 我们分别处理两项。

4. 第一项: 先对 y_2 积分得到边缘密度, 再积分:

$$\int \int y_1 f(y_1, y_2) dy_1 dy_2 = \int y_1 \left(\int f(y_1, y_2) dy_2 \right) dy_1 = \int y_1 f_{Y_1}(y_1) dy_1 = \mathbb{E}Y_1.$$

5. 第二项同理可得 $\mathbb{E}Y_2$ 。

结论: 因此 $\mathbb{E}(aY_1 + bY_2) = a\mathbb{E}Y_1 + b\mathbb{E}Y_2$ 。注意此性质无需 Y_1, Y_2 独立。■

0.6. Jacobian 变换公式的推导. 背景 (Background): 在正文中我们给出二元变换公式 $f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1(y_1, y_2), v_2(y_1, y_2)) \cdot |J|$ 。

目标 (Goal): 解释 $|J|$ 的来源。

推导步骤 (Derivation Steps):

1. 设变换为 $(X_1, X_2) = (v_1(Y_1, Y_2), v_2(Y_1, Y_2))$, 逆变换为 $(Y_1, Y_2) = (u_1(X_1, X_2), u_2(X_1, X_2))$ 。
2. 事件 $\{Y_1 \leq y_1, Y_2 \leq y_2\}$ 等价于 $\{X_1 \leq v_1(y_1, y_2), X_2 \leq v_2(y_1, y_2)\}$ 。
3. 因此边缘 cdf:

$$F_{Y_1, Y_2}(y_1, y_2) = \int_{-\infty}^{v_1(y_1, y_2)} \int_{-\infty}^{v_2(y_1, y_2)} f_{X_1, X_2}(x_1, x_2) dx_2 dx_1.$$

4. 对两边求混合偏导:

$$f_{Y_1, Y_2}(y_1, y_2) = \frac{\partial^2}{\partial y_1 \partial y_2} F_{Y_1, Y_2}(y_1, y_2).$$

5. 应用多元链式法则:

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(v_1, v_2) \cdot \left| \frac{\partial x_1}{\partial y_1} \cdot \frac{\partial x_2}{\partial y_2} - \frac{\partial x_1}{\partial y_2} \cdot \frac{\partial x_2}{\partial y_1} \right| = f_{X_1, X_2}(v_1, v_2) \cdot |J|.$$

结论: $|J|$ 度量了变换下的面积元素缩放比例。■

0.7. 条件分布公式的推导. 背景 (Background): 条件分布 $f_{X_2|X_1}(x_2|x_1) = f_{X_1, X_2}(x_1, x_2)/f_{X_1}(x_1)$ 是概率论的核心概念。

目标 (Goal): 从条件概率的基本定义出发推导出条件 pdf 公式。

推导步骤 (Derivation Steps):

1. 条件概率的基本定义:

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

2. 对于无穷小事件 $\{X_1 \in [x_1, x_1 + dx_1), X_2 \in [x_2, x_2 + dx_2)\}$:

$$\mathbb{P}(X_2 \in dx_2 | X_1 \in dx_1) = \frac{f_{X_1, X_2}(x_1, x_2) dx_1 dx_2}{f_{X_1}(x_1) dx_1} = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)} dx_2.$$

3. 因此条件 pdf:

$$f_{X_2|X_1}(x_2 | x_1) = \frac{f_{X_1, X_2}(x_1, x_2)}{f_{X_1}(x_1)}.$$

4. 验证: 边缘密度公式的逆过程

$$\int_{-\infty}^{\infty} f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 = \int_{-\infty}^{\infty} f_{X_1, X_2}(x_1, x_2) dx_2 = f_{X_1}(x_1),$$

故 $\int f_{X_2|X_1}(x_2 | x_1) dx_2 = 1$, 确实是合法的 pdf。

结论: 条件 pdf 公式得证。■

0.8. 全期望公式的推导. 背景 (Background): 全期望公式 $\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \mathbb{E}(X_2)$ 是连接条件期望与边缘期望的桥梁。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 从条件期望定义出发:

$$\mathbb{E}(X_2 | X_1) = \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2.$$

2. 对条件期望再取期望 (即关于 X_1 求平均):

$$\mathbb{E}[\mathbb{E}(X_2 | X_1)] = \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) dx_2 \right) f_{X_1}(x_1) dx_1.$$

3. 重新排列积分次序:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) dx_2 dx_1.$$

4. 由条件 pdf 定义 $f_{X_2|X_1}(x_2 | x_1) f_{X_1}(x_1) = f_{X_1, X_2}(x_1, x_2)$:

$$= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x_2 f_{X_1, X_2}(x_1, x_2) dx_2 dx_1 = \mathbb{E}X_2.$$

结论: 全期望公式得证。■

0.9. 条件方差不等式的推导. 背景 (Background): 在正文中我们给出 $\text{var}[\mathbb{E}(X_2 | X_1)] \leq \text{var}(X_2)$ 。这里给出证明。

目标 (Goal): 证明条件方差不等式。

推导步骤 (Derivation Steps):

1. 方差分解:

$$\text{var}(X_2) = \mathbb{E}[\text{var}(X_2 | X_1)] + \text{var}[\mathbb{E}(X_2 | X_1)].$$

2. 上式等价于全方差公式 (Law of Total Variance):

$$\text{var}(X_2) = \mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} + \text{var}[\mathbb{E}(X_2 | X_1)].$$

3. 展开第一项:

$$\mathbb{E}\{[X_2 - \mathbb{E}(X_2 | X_1)]^2 | X_1\} \geq 0,$$

因为平方的期望非负。

4. 因此:

$$\text{var}(X_2) \geq \text{var}[\mathbb{E}(X_2 | X_1)].$$

结论: 条件均值的方差不超过原变量的方差, 等号成立当且仅当 $X_2 | X_1$ 的条件方差几乎处处为 0 (即 X_2 可由 X_1 确定性决定)。■

0.10. 独立性判定的推导. 背景 (Background): 我们声称 X_1 与 X_2 独立等价于 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ (可分离变量)。

目标 (Goal): 证明这一判定条件。

推导步骤 (Derivation Steps):

($\Rightarrow$) 若 X_1 与 X_2 独立, 则 $f(x_1, x_2) = f_1(x_1)f_2(x_2)$, 显然可分离。

($\Leftarrow$) 若 $f(x_1, x_2) \equiv g(x_1)h(x_2)$:

1. 由边缘密度定义:

$$f_1(x_1) = \int_{-\infty}^{\infty} g(x_1)h(x_2) dx_2 = g(x_1) \int_{-\infty}^{\infty} h(x_2) dx_2 = c_1 g(x_1),$$

其中 $c_1 = \int h(x_2) dx_2$ 为常数。

2. 同理:

$$f_2(x_2) = h(x_2) \int_{-\infty}^{\infty} g(x_1) dx_1 = c_2 h(x_2),$$

其中 $c_2 = \int g(x_1) dx_1$ 为常数。

3. 由归一性 $\int \int f(x_1, x_2) dx_1 dx_2 = 1$, 得 $c_1 c_2 = 1$ 。

4. 因此:

$$f(x_1, x_2) \equiv g(x_1)h(x_2) \equiv c_1 g(x_1) \cdot c_2 h(x_2) \equiv f_1(x_1)f_2(x_2).$$

结论: 故 $f(x_1, x_2) \equiv g(x_1)h(x_2)$ 是独立性的等价条件。■

0.11. 相关系数范围的推导. 背景 (Background): 我们声称相关系数满足 $-1 \leq \rho \leq 1$ 。这里用 Cauchy-Schwarz 不等式证明。

目标 (Goal): 证明 $|\rho| \leq 1$ 。

推导步骤 (Derivation Steps):

1. Cauchy-Schwarz 不等式: 对任意随机变量 U, V ,

$$[\mathbb{E}(UV)]^2 \leq \mathbb{E}(U^2) \cdot \mathbb{E}(V^2).$$

2. 应用于协方差, 令 $U = X_1 - \mu_1$, $V = X_2 - \mu_2$:

$$[\text{cov}(X_1, X_2)]^2 = [\mathbb{E}(X_1 - \mu_1)(X_2 - \mu_2)]^2 \leq \mathbb{E}(X_1 - \mu_1)^2 \cdot \mathbb{E}(X_2 - \mu_2)^2 = \sigma_1^2 \sigma_2^2.$$

3. 两边开方:

$$|\text{cov}(X_1, X_2)| \leq \sigma_1 \sigma_2.$$

4. 因此:

$$|\rho| = \frac{|\text{cov}(X_1, X_2)|}{\sigma_1 \sigma_2} \leq 1.$$

结论: 故 $-1 \leq \rho \leq 1$ 。等号成立当且仅当 $X_2 = aX_1 + b$ (完美线性关系)。■

0.12. 二元正态条件分布的推导. 背景 (Background): 在正文中给出二元正态的条件分布为

$$X_2 | X_1 = x_1 \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x_1 - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

这里给出推导。

参数定义 (Parameter Definitions):

- μ_1, μ_2 : 边缘分布均值
- σ_1^2, σ_2^2 : 边缘分布方差
- ρ : 相关系数
- $f(x_1, x_2)$: 二元正态联合密度

目标 (Goal): 求条件分布 $f_{2|1}(x_2|x_1)$ 。

推导步骤 (Derivation Steps):

1. 条件密度公式:

$$f_{2|1}(x_2|x_1) = \frac{f(x_1, x_2)}{f_1(x_1)},$$

其中 $f_1(x_1) = \frac{1}{\sigma_1\sqrt{2\pi}} \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\}$ 。

2. 写出联合密度的指数部分 (略去归一化常数):

$$f(x_1, x_2) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right\}.$$

3. 关于 x_2 完全平方配方:

$$\frac{(x_2-\mu_2)^2}{\sigma_2^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} = \left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2 - \rho^2\frac{(x_1-\mu_1)^2}{\sigma_1^2}.$$

4. 代入并整理:

$$f(x_1, x_2) \propto \exp\left\{-\frac{(x_1-\mu_1)^2}{2\sigma_1^2}\right\} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

5. 因此条件密度为:

$$f_{2|1}(x_2|x_1) \propto \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{x_2-\mu_2}{\sigma_2} - \rho\frac{x_1-\mu_1}{\sigma_1}\right)^2\right\}.$$

6. 这正是均值为 $\mu_2 + \rho\frac{\sigma_2}{\sigma_1}(x_1 - \mu_1)$ 、方差为 $\sigma_2^2(1 - \rho^2)$ 的正态密度。

结论: 二元正态的条件分布仍是正态分布。■

0.13. 独立随机变量线性组合 mgf 的推导. 背景 (Background): 在正文中给出若 $X_1, \dots, X_n$ 相互独立, 则 $T = \sum_{i=1}^n k_i X_i$ 的 mgf 为 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。

目标 (Goal): 形式化推导这一公式。

推导步骤 (Derivation Steps):

1. 由 mgf 定义:

$$M_T(t) = \mathbb{E}[e^{tT}] = \mathbb{E}\left[\exp\left(t \sum_{i=1}^n k_i X_i\right)\right] = \mathbb{E}\left[\prod_{i=1}^n e^{tk_i X_i}\right].$$

2. 由于 $X_1, \dots, X_n$ 相互独立, $e^{tk_i X_i}$ 也相互独立, 因此期望可分解为乘积:

$$\mathbb{E} \left[\prod_{i=1}^n e^{tk_i X_i} \right] = \prod_{i=1}^n \mathbb{E}[e^{tk_i X_i}] = \prod_{i=1}^n M_i(k_i t).$$

3. 定义域: 由各 $M_i(t)$ 的存在域 $-h_i < t < h_i$, T 的 mgf 定义域为 $-\min_i \{h_i/k_i\} < t < \min_i \{h_i/k_i\}$ (假设 $k_i > 0$; 若 $k_i < 0$ 则需调整)。

结论: 故 $M_T(t) = \prod_{i=1}^n M_i(k_i t)$ 。特别地, 若 X_i iid, 则 $M_T(t) = [M(kt)]^n$ 。■

0.14. Binomial 分布的矩母函数推导. 背景 (Background): 在正文中我们声明 Binomial 分布的矩母函数为 $M(t) = [(1-p) + pe^t]^n$ 。这里给出完整推导。

参数定义 (Parameter Definitions):

- n : 试验次数
- p : 成功概率
- $X \sim \text{Bin}(n, p)$: 成功次数

目标 (Goal): 证明 $M(t) = [(1-p) + pe^t]^n$ 。

推导步骤 (Derivation Steps):

1. 根据矩母函数定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x}.$$

2. 提出公共项并利用二项展开:

$$= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = [(1-p) + pe^t]^n.$$

3. 均值和方差可由矩母函数求得:

$$M'(t) = n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\mathbb{E}X = M'(0) = np$ 。

$$M''(t) = n(n-1)[(1-p) + pe^t]^{n-2} \cdot (pe^t)^2 + n[(1-p) + pe^t]^{n-1} \cdot pe^t,$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = np(1-p)$ 。

结论: 因此, $X \sim \text{Bin}(n, p)$ 的矩母函数为 $M(t) = [(1-p) + pe^t]^n$, 均值为 np , 方差为 $np(1-p)$ 。■

0.15. Negative Binomial 分布的矩母函数推导. 背景 (Background): 负二项分布描述的是在获得 r 次成功之前所需的失败次数。

参数定义 (Parameter Definitions):

- r : 成功次数
- p : 单次成功概率
- Y : 失败次数
- $Y \sim \text{NegativeBinomial}(r, p)$

目标 (Goal): 证明负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。

推导步骤 (Derivation Steps):

1. pmf 为:

$$p_Y(y) = \binom{y+r-1}{r-1} p^r (1-p)^y, \quad y = 0, 1, 2, \dots$$

2. mgf 定义:

$$M(t) = \mathbb{E}[e^{tY}] = \sum_{y=0}^{\infty} e^{ty} \binom{y+r-1}{r-1} p^r (1-p)^y.$$

3. 利用负二项级数展开:

$$(1-z)^{-r} = \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} z^y, \quad |z| < 1.$$

4. 令 $z = (1-p)e^t$, 得:

$$M(t) = p^r \sum_{y=0}^{\infty} \binom{y+r-1}{r-1} [(1-p)e^t]^y = p^r (1 - (1-p)e^t)^{-r} = \left(\frac{p}{1-(1-p)e^t}\right)^r.$$

5. 定义域要求 $|(1-p)e^t| < 1$, 即 $t < -\log(1-p)$ 。

结论: 负二项分布的 mgf 为 $M(t) = \left(\frac{p}{1-(1-p)e^t}\right)^r$, $t < -\log(1-p)$ 。■

0.16. 几何分布的无记忆性推导. 背景 (Background): 几何分布具有独特的“无记忆”性质, 这在离散时间等待问题中非常重要。

目标 (Goal): 证明 $\mathbb{P}(Y \geq k+j | Y \geq k) = \mathbb{P}(Y \geq j)$ 。

推导步骤 (Derivation Steps):

1. 几何分布的 pmf:

$$\mathbb{P}(Y = y) = p(1-p)^y, \quad y = 0, 1, 2, \dots$$

2. 计算生存函数:

$$\mathbb{P}(Y \geq y) = \sum_{i=y}^{\infty} p(1-p)^i = p \cdot \frac{(1-p)^y}{1-(1-p)} = (1-p)^y.$$

3. 计算条件概率:

$$\mathbb{P}(Y \geq k+j | Y \geq k) = \frac{\mathbb{P}(Y \geq k+j)}{\mathbb{P}(Y \geq k)} = \frac{(1-p)^{k+j}}{(1-p)^k} = (1-p)^j = \mathbb{P}(Y \geq j).$$

结论: 几何分布具有无记忆性: 已知前 k 次失败, 未来等待时间与最初等待时间分布相同。■

0.17. 多项分布的协方差推导. 背景 (Background): 多项分布是二项分布在多类别上的推广。

目标 (Goal): 求 $\text{cov}(X_i, X_j)$ for $i \neq j$ 。

推导步骤 (Derivation Steps):

1. 多项分布的均值: $X_i \sim \text{Bin}(n, p_i)$, 故 $\mathbb{E}X_i = np_i$ 。
2. 对于 $i \neq j$, 考虑 $X_i + X_j \sim \text{Bin}(n, p_i + p_j)$, 故

$$\text{var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j).$$

3. 另一方面,

$$\text{var}(X_i + X_j) = \text{var}(X_i) + \text{var}(X_j) + 2 \text{cov}(X_i, X_j).$$

4. 代入 $\text{var}(X_i) = np_i(1 - p_i)$ 和 $\text{var}(X_j) = np_j(1 - p_j)$:

$$n(p_i + p_j)(1 - p_i - p_j) = np_i(1 - p_i) + np_j(1 - p_j) + 2 \text{cov}(X_i, X_j).$$

5. 整理得:

$$\text{cov}(X_i, X_j) = -np_i p_j.$$

结论: 对于多项分布, $\text{cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$), 这反映了类别之间的竞争关系。■

0.18. 超几何分布的均值与方差推导. 背景 (Background): 超几何分布描述不放回抽样中的成功次数。

参数定义 (Parameter Definitions):

- N : 总体容量
- D : 总体中成功元素个数
- n : 抽样个数 (不放回)
- $X \sim \text{Hypergeometric}(N, D, n)$

目标 (Goal): 求 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

均值推导:

1. 使用指示变量法: 设 $I_j = 1$ if 第 j 次抽样抽到成功元素, 否则为 0。
2. 则 $X = \sum_{j=1}^n I_j$ 。
3. 由对称性, $\mathbb{E}[I_j] = \mathbb{P}(I_j = 1) = D/N$ 。
4. 故 $\mathbb{E}X = \sum_{j=1}^n \mathbb{E}[I_j] = n \cdot \frac{D}{N}$ 。

方差推导:

1. 首先计算 $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{j \neq k} \mathbb{P}(I_j = 1, I_k = 1).$$

2. 由于抽样不放回, 任意两时刻抽取成功的概率为 $\frac{D}{N} \cdot \frac{D-1}{N-1}$ 。

3. 共有 $n(n-1)$ 对, 故

$$\mathbb{E}[X(X-1)] = n(n-1) \cdot \frac{D(D-1)}{N(N-1)}.$$

4. 利用 $\text{var}(X) = \mathbb{E}[X^2] - (\mathbb{E}X)^2 = \mathbb{E}[X(X-1)] + \mathbb{E}X - (\mathbb{E}X)^2$:

$$\text{var}(X) = n(n-1) \frac{D(D-1)}{N(N-1)} + n \frac{D}{N} - \left(n \frac{D}{N}\right)^2 = n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}.$$

结论: 超几何分布的均值为 $n \frac{D}{N}$, 方差为 $n \frac{D}{N} \frac{N-D}{N} \frac{N-n}{N-1}$, 其中 $\frac{N-n}{N-1}$ 是有限总体校正因子。■

0.19. Poisson 近似二项分布的证明. 背景 (Background): 当 n 很大、 p 很小时, 二项分布 $\text{Bin}(n, p)$ 近似于 $\text{Poisson}(\lambda = np)$ 。

目标 (Goal): 证明若 $X_n \sim \text{Bin}(n, p_n)$ 且 $np_n \rightarrow \lambda$, 则 $X_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。

推导步骤 (Derivation Steps):

1. 二项分布的概率质量函数:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1 - p_n)^{n-k}.$$

2. 将组合数拆开:

$$= \frac{n(n-1) \cdots (n-k+1)}{k!} \cdot \frac{\lambda^k}{n^k} \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

3. 当 $n \rightarrow \infty$ 时:

$$\frac{n(n-1) \cdots (n-k+1)}{n^k} \rightarrow 1,$$

$$\left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow e^{-\lambda}.$$

4. 故

$$\mathbb{P}(X_n = k) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda},$$

这正是 $\text{Poisson}(\lambda)$ 的 pmf。

结论: Poisson 分布是二项分布在“稀有事件”情形下的极限。■

0.20. Poisson 分布的矩母函数推导. 背景 (Background): Poisson 分布的矩母函数和均值、方差。

目标 (Goal): 求 $M(t)$ 并计算 $\mathbb{E}X$ 和 $\text{var}(X)$ 。

推导步骤 (Derivation Steps):

1. mgf 定义:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x e^{-\lambda}}{x!} = e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda e^t)^x}{x!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

2. 一阶导数:

$$M'(t) = \lambda e^t \cdot e^{\lambda(e^t-1)} = \lambda e^t M(t),$$

故 $\mathbb{E}X = M'(0) = \lambda$ 。

3. 二阶导数：

$$M''(t) = \lambda e^t M(t) + \lambda^2 e^{2t} M(t),$$

故 $\text{var}(X) = M''(0) - [M'(0)]^2 = (\lambda + \lambda^2) - \lambda^2 = \lambda$ 。

结论： Poisson 分布的均值和方差相等，都等于参数 λ 。■

0.21. 卡方分布与正态分布的关系. 背景 (Background)： 卡方分布定义为标准正态平方和。

目标 (Goal)： 证明若 $Z \sim N(0, 1)$ ，则 $Z^2 \sim \chi^2(1)$ 。

推导步骤 (Derivation Steps)：

1. Z 的 pdf 为 $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$ 。

2. 设 $Y = Z^2$ ，先求 cdf：

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(-\sqrt{y} \leq Z \leq \sqrt{y}) = \int_{-\sqrt{y}}^{\sqrt{y}} \phi(z) dz.$$

3. 求导得 pdf：

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} + \phi(-\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}.$$

4. 写成标准形式：

$$f_Y(y) = \frac{1}{\Gamma(1/2)2^{1/2}} y^{1/2-1} e^{-y/2},$$

这正是 $\chi^2(1)$ 的 pdf。

结论： 标准正态变量的平方服从自由度为 1 的卡方分布。■

0.22. 卡方分布的可加性证明. 背景 (Background)： 卡方分布满足可加性：独立卡方变量之和仍为卡方分布。

目标 (Goal)： 证明若 $X_1 \sim \chi^2(m)$ ， $X_2 \sim \chi^2(n)$ 独立，则 $X_1 + X_2 \sim \chi^2(m+n)$ 。

推导步骤 (Derivation Steps)：

1. 由卡方分布与 Gamma 分布的关系： $\chi^2(r) = \Gamma(r/2, 2)$ 。

2. 利用 Gamma 分布的可加性（见定理 3.3.1）：若 $Y_1 \sim \Gamma(\alpha_1, \beta)$ ， $Y_2 \sim \Gamma(\alpha_2, \beta)$ 独立，则 $Y_1 + Y_2 \sim \Gamma(\alpha_1 + \alpha_2, \beta)$ 。

3. 因此：

$$X_1 + X_2 \sim \Gamma(m/2, 2) + \Gamma(n/2, 2) = \Gamma((m+n)/2, 2) = \chi^2(m+n).$$

或者直接利用 mgf： $\chi^2(r)$ 的 mgf 为 $M(t) = (1-2t)^{-r/2}$ ，故

$$M_{X_1+X_2}(t) = (1-2t)^{-m/2} \cdot (1-2t)^{-n/2} = (1-2t)^{-(m+n)/2}.$$

结论： 卡方分布具有可加性，自由度可累加。■

0.23. Beta 分布从 Gamma 变量构造的推导. 背景 (Background): Beta 分布可由两个独立 Gamma 变量构造而来。

目标 (Goal): 证明若 $X_1 \sim \Gamma(\alpha, 1)$, $X_2 \sim \Gamma(\beta, 1)$ 独立, 令 $Y = X_1/(X_1 + X_2)$, 则 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 联合 pdf ($x_1 > 0, x_2 > 0$):

$$h(x_1, x_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} x_1^{\alpha-1} x_2^{\beta-1} e^{-x_1-x_2}.$$

2. 变换: $y_1 = x_1 + x_2$, $y_2 = \frac{x_1}{x_1+x_2}$, 则 $x_1 = y_1 y_2$, $x_2 = y_1(1 - y_2)$ 。

3. Jacobian 行列式: $|J| = y_1$ 。

4. 联合 pdf:

$$g(y_1, y_2) = \frac{1}{\Gamma(\alpha)\Gamma(\beta)} (y_1 y_2)^{\alpha-1} [y_1(1 - y_2)]^{\beta-1} e^{-y_1} \cdot y_1 = y_1^{\alpha+\beta-1} e^{-y_1} \cdot \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)}.$$

5. 分离变量, 可见 $Y_1 = X_1 + X_2 \sim \Gamma(\alpha + \beta, 1)$, $Y_2 = \frac{X_1}{X_1+X_2} \sim \text{Beta}(\alpha, \beta)$, 且独立。

6. 边缘 pdf:

$$g_2(y_2) = \frac{y_2^{\alpha-1} (1 - y_2)^{\beta-1}}{\Gamma(\alpha)\Gamma(\beta)} \int_0^\infty y_1^{\alpha+\beta-1} e^{-y_1} dy_1 = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_2^{\alpha-1} (1 - y_2)^{\beta-1}.$$

结论: Beta 分布可如此构造, 且 Y_1 和 Y_2 独立。■

0.24. Beta 分布的均值与方差推导. 背景 (Background): Beta 分布的均值和方差的计算。

目标 (Goal): 求 $\mathbb{E}Y$ 和 $\text{var}(Y)$, 其中 $Y \sim \text{Beta}(\alpha, \beta)$ 。

推导步骤 (Derivation Steps):

1. 利用 Beta 函数性质:

$$\int_0^1 y^{\alpha-1} (1 - y)^{\beta-1} dy = B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

2. 均值:

$$\mathbb{E}Y = \int_0^1 y \cdot \frac{1}{B(\alpha, \beta)} y^{\alpha-1} (1 - y)^{\beta-1} dy = \frac{B(\alpha + 1, \beta)}{B(\alpha, \beta)} = \frac{\alpha}{\alpha + \beta}.$$

3. 二阶矩:

$$\mathbb{E}[Y^2] = \frac{B(\alpha + 2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)}.$$

4. 方差:

$$\text{var}(Y) = \mathbb{E}[Y^2] - (\mathbb{E}Y)^2 = \frac{\alpha(\alpha + 1)}{(\alpha + \beta)(\alpha + \beta + 1)} - \frac{\alpha^2}{(\alpha + \beta)^2} = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

结论: Beta 分布的均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。■

0.25. 正态分布的矩母函数推导. 背景 (Background): 正态分布是最重要的连续分布之一。

目标 (Goal): 证明 $X \sim N(\mu, \sigma^2)$ 的 mgf 为 $M(t) = \exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。

推导步骤 (Derivation Steps):

1. $X = \sigma Z + \mu$, 其中 $Z \sim N(0, 1)$ 。

2. 标准正态的 mgf:

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \int_{-\infty}^{\infty} e^{tz} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz = e^{t^2/2} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(z-t)^2/2} dz = e^{t^2/2}.$$

3. 一般正态:

$$M_X(t) = \mathbb{E}[e^{t(\sigma Z + \mu)}] = e^{\mu t} \mathbb{E}[e^{t\sigma Z}] = e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} = \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\}.$$

4. 验证均值和方差:

$$M'(t) = (\mu + \sigma^2 t) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

$$M''(t) = (\sigma^2 + (\mu + \sigma^2 t)^2) \exp\left\{\mu t + \frac{1}{2}\sigma^2 t^2\right\},$$

故 $\mathbb{E}X = M'(0) = \mu$, $\text{var}(X) = M''(0) - \mu^2 = \sigma^2$ 。

结论: 正态分布 $N(\mu, \sigma^2)$ 的 mgf 为 $\exp\{\mu t + \frac{1}{2}\sigma^2 t^2\}$ 。■

0.26. 标准化变换的推导. 背景 (Background): 任何正态变量都可以通过标准化变换化为标准正态。

目标 (Goal): 证明若 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$ 。

推导步骤 (Derivation Steps):

1. 变换 $Z = g(X) = \frac{X-\mu}{\sigma}$, 其逆为 $X = \sigma Z + \mu$ 。

2. 利用 mgf 的性质 (或直接积分):

$$M_Z(t) = \mathbb{E}[e^{tZ}] = \mathbb{E}\left[e^{t\frac{X-\mu}{\sigma}}\right] = e^{-\mu t/\sigma} \mathbb{E}[e^{(t/\sigma)X}] = e^{-\mu t/\sigma} \cdot \exp\left\{\mu \frac{t}{\sigma} + \frac{1}{2}\sigma^2 \left(\frac{t}{\sigma}\right)^2\right\} = e^{t^2/2}.$$

3. 这正是 $N(0, 1)$ 的 mgf, 故 $Z \sim N(0, 1)$ 。

4. 概率计算:

$$\mathbb{P}(X \leq x) = \mathbb{P}\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

结论: 标准化变换将正态分布转化为标准正态分布, 从而可用标准正态表计算任意正态概率。■

0.27. t 分布的推导. 背景 (Background): t 分布由标准正态和卡方分布构造而来。

目标 (Goal): 证明若 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$ 独立, $T = \frac{Z}{\sqrt{V/n}}$, 则 $T \sim t(n)$ 。

推导步骤 (Derivation Steps):

1. 变换: $T = \frac{Z}{\sqrt{V/n}}$, $U = V$, 逆变换为 $Z = T\sqrt{U/n}$, $V = U$ 。

2. Jacobian: $|J| = \sqrt{u/n}$ 。

3. 联合 pdf:

$$h(z, v) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} v^{n/2-1} e^{-v/2}.$$

4. 代入变换并对 u 积分:

$$f_T(t) = \int_0^\infty \frac{1}{\sqrt{2\pi}} e^{-t^2 u/(2n)} \cdot \frac{1}{\Gamma(n/2)2^{n/2}} u^{n/2-1} e^{-u/2} \cdot \sqrt{\frac{u}{n}} du.$$

5. 整理后令 $y = \frac{u}{2}(1 + t^2/n)$, 得:

$$f_T(t) = \frac{\Gamma((n+1)/2)}{\sqrt{\pi n} \Gamma(n/2)} \cdot \frac{1}{(1 + t^2/n)^{(n+1)/2}}.$$

6. 均值为 0 (对称性), 方差为 $\frac{n}{n-2}$ (当 $n > 2$)。

结论: t 分布的 pdf 如上所示, 当 $n \rightarrow \infty$ 时趋于标准正态分布。■

1. 问答记录

1.1. 置信区间的频率派解释. 问：很多初学者把置信区间的定义 $\mathbb{P}_\theta(L \leq \theta \leq U) = 1 - \alpha$ 误解为“ θ 有 $1 - \alpha$ 的概率落在区间 $[L, U]$ 中”。这两种解释有什么区别？哪个是正确的，为什么？

答：这是一个关于频率派与贝叶斯派对置信区间不同理解的核心问题。

关键区别：在频率派统计中， θ 是**固定（但未知）的常数**，而区间 $[L, U]$ 是**随机的**（因为它依赖于样本数据）。因此，我们不能对固定参数 θ 做概率陈述。

正确的频率派解释：如果我们重复抽样很多次，构造置信区间，那么 $100(1 - \alpha)\%$ 的区间会包含真实的 θ 。但对于任何**单次**观察到的区间，真实的 θ 要么在里面，要么不在里面——没有概率可言。

举例说明：设硬币抛掷 $n = 100$ 次， $\hat{p} \sim \text{Binomial}(100, \theta)/100$ 。

- 对于**单一样本**：观察到的区间是某个具体区间如 $[0.45, 0.55]$ ，真实的 θ 要么在里面，要么不在——无法赋予概率。
- 对于**重复抽样**：如果用同样的真实 θ 做 1000 次实验，约 950 次构造出的区间会包含 θ 。这就是“95% 置信度”的含义。

贝叶斯派的理解则不同：在贝叶斯统计中， θ 被视为随机变量（需要先验分布），可以得到“后验可信区间” $P(\theta \in [L, U] \mid \text{data}) = 1 - \alpha$ 。这里的概率是关于 θ 的，可以合理地说是“ θ 有 95% 的概率在这个区间内”。

总结对比：

表述	频率派有效?	含义
$P(\theta \in [L, U]) = 0.95$	否	θ 是固定的
“用此方法构造的区间中 95% 包含 θ ”	是	概率在区间构造上
$P(\theta \in [L, U] \mid \text{data}) = 0.95$	仅在贝叶斯框架下成立	需要对 θ 设定先验分布

置信区间 (confidence interval) 这一术语是**频率派概念**，它描述的是构造过程的可靠性，而不是关于某个固定区间的概率。

1.2. 贝叶斯先验分布的具体例子. 问：在之前关于置信区间的回答中提到，贝叶斯学派认为 θ 需要先验分布。能给出一些具体的先验分布例子吗？先验分布到底代表什么？

答：这是一个很好的问题。在贝叶斯统计中，我们将参数 θ 视为随机变量，因此在推断前必须为其指定一个**先验分布** (prior distribution)，表达我们对参数的初始信念。以下是几个经典例子。

例 1：硬币抛掷 (Bernoulli 分布) ——Beta 先验

设硬币正面朝上的概率为 θ ，抛掷 n 次得到 Y 次正面，则 $Y \sim \text{Binomial}(n, \theta)$ 。

共轭先验：我们为 θ 选择 Beta 分布作为先验：

$$\theta \sim \text{Beta}(\alpha, \beta)$$

其 pdf 为:

$$\pi(\theta) = \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < \theta < 1$$

直观理解: Beta 分布是 $[0, 1]$ 区间上的灵活分布, 参数 (α, β) 控制先验信念:

- $\alpha = \beta = 1$: 均匀分布 (无信息先验), 表示”对 θ 一无所知”
- $\alpha = \beta = 2$: 表示” θ 可能接近 0.5” 的信念 (对称且集中)
- $\alpha = 3, \beta = 1$: 表示” θ 更可能接近 1” 的信念

为什么选择 Beta 分布? 因为它是 Bernoulli/binomial 的共轭先验——后验分布与先验分布具有相同的函数形式, 计算极为方便。观测数据后, 后验分布为:

$$\theta | Y \sim \text{Beta}(\alpha + Y, \beta + n - Y)$$

例 2: 正态均值——正态先验

设 $X_1, \dots, X_n \sim N(\theta, \sigma^2)$, 其中 σ^2 已知, θ 未知。

共轭先验: 我们为 θ 选择正态分布作为先验:

$$\theta \sim N(\mu_0, \tau_0^2)$$

其中 μ_0 是先验均值 (你对 θ 的初始猜测), τ_0^2 是先验方差 (你对这个猜测的信心)。

直观理解:

- τ_0^2 很大: 先验方差大, 表示对 θ 的初始信念很模糊
- τ_0^2 很小: 先验方差小, 表示对 θ 有很强的先验信念
- $\mu_0 = 0$: 如果你没有任何理由偏好正值或负值

后验分布: 观测数据后, 后验分布为:

$$\theta | \bar{x} \sim N\left(\frac{\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}, \frac{1}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}\right)$$

这是又一个正态分布——共轭性的体现。

为什么需要先验分布? 先验代表什么?

先验分布 (prior distribution) 代表我们在**观测数据之前**对参数 θ 的主观信念 (subjective belief)。这可以从两个角度理解:

- (1) **主观贝叶斯视角:** 先验反映了个人的真实信念。例如, 如果你认为硬币”通常”是公平的, 你可以将先验设为 $\theta \sim \text{Beta}(2, 2)$ (中心在 0.5, 但允许不确定性)。
- (2) **客观贝叶斯视角:** 选择尽量”无信息”的先验, 使后验主要由数据驱动。例如, $\text{Beta}(1, 1)$ (均匀分布) 或 Jeffreys 先验 $\text{Beta}(1/2, 1/2)$ 。

贝叶斯推断的本质是通过贝叶斯定理将先验更新为后验:

$$\underbrace{\pi(\theta | \text{data})}_{\text{后验}} \propto \underbrace{L(\theta | \text{data})}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

数据通过似然函数”告诉”我们信息, 先验通过贝叶斯定理被更新为后验。后验分布集中了所有关于 θ 的信息——既包含先验信念, 也包含数据证据。

先验 vs. 后验的直观理解：

	先验 (Prior)	后验 (Posterior)
时机	看到数据之前	看到数据之后
性质	主观信念或无信息设定	更新后的知识状态

总结：先验分布是贝叶斯统计的标志性特征。它将参数视为随机变量，允许我们以概率语言描述对参数的认知，并通过数据不断更新这种认知。这与频率派的“参数固定但未知”观点形成了根本性对比。

1.3. 参数方法 vs. 非参数方法. 问：在 Chapter 4 的 §4.1 中提到，当 $f(x)$ 或 $p(x)$ 的形式完全未知时，属于哪种统计方法？在哪一章深入讨论？

答：

- 形式完全未知的情况属于**非参数方法** (Nonparametric Methods)
- 在 Chapter 4 的 §4.1.2 有简要提及（直方图估计）
- 深入讨论在 **Chapter 10** (Nonparametric Methods)

简单区分：

场景	方法	章节
分布形式未知	非参数方法（直方图、核密度估计）	Chapter 10
分布形式已知、参数未知	参数方法（MLE、CI、检验）	Chapter 4

1.4. 无偏性过渡到 MLE 的动机. 问：在介绍完无偏估计量的定义后，笔记写道：“无偏性并不保证估计量‘最好’。例如，样本方差 S^2 是无偏的，但 $n^{-1} \sum (X_i - \bar{X})^2$ 是有偏的。这引发了一个自然的问题：能否找到一个统一的、‘最优’的估计原则？”为什么要举这个例子？它在整个章节中起什么作用？

答：这是一个**承上启下的关键过渡**。

- 防止误解：**学生刚学完无偏性，容易误以为“无偏 = 最好估计量”。
- 揭示张力：**无偏性只是一个**基本要求**，不是“最优性”的保证。无偏的估计量可以有**很多**，且各有**优劣**。
- 引出 MLE：**正因为无偏性不够，我们需要找“统一的最优原则”——这正是最大似然估计（MLE）被提出的**动机**。

逻辑链条：

无偏性定义 → 揭示局限性 → 引出 MLE 作为统一原则

具体例子：

- S^2 （无偏）和 $\hat{\sigma}^2$ （有偏，但 MLE）
- 两者都常用，但各有用途
- “最优”需要更精确的定义（后续章节的 UMVUE）

数学写作手法：先介绍概念，再指出局限性，自然引出下一个概念——这是 Stein 风格的典型特征，强调“为什么需要”而非直接罗列。

学习笔记.