

CHAPTER 1

综合评述

1. 摘要

本文综述 Tang-Rong 系列工作 (2021–2025)，涵盖 Rong Tang 与 Yun Yang 等在流形统计学习领域的系列研究。该系列围绕三个核心问题展开：(1) 低维流形上分布估计的统计极限是什么？(2) 深度生成模型能否隐式自适应流形结构？(3) 如何在流形约束下进行稳健的贝叶斯推断和高效 MCMC？

系列包含 9 篇论文，发表于 COLT、Annals of Statistics、JRSS B、ICML、AISTATS 等顶级会议与期刊，并延伸至分布回归与条件扩散模型的 arXiv 工作。整个系列在极小极大理论、稳健贝叶斯推断和扩散模型自适应三个维度上建立了从理论奠基到方法验证、再到算法优化的完整体系。本文对各论文进行批判性评述，分析其技术贡献与局限性，梳理三条研究主线之间的内在联系，并提出若干开放问题。

2. 研究脉络总览

现代高维数据（图像、文本、点云）的本质特征是：环境维度 D 巨大，但有效信息维度 $d \ll D$ ，数据通常位于某个未知低维流形上。这一观察催生了三个根本性问题：

- (1) **统计极限**：当数据支撑于未知低维流形时，分布估计的极小极大速率是什么？ D 是否必然出现在速率中？
- (2) **自适应机制**：深度生成模型（VAE、GAN、扩散模型）在实践中表现出色，但其隐式自适应流形结构的理论机制尚不清晰。
- (3) **贝叶斯推断**：当参数自然地取值于黎曼流形时，如何进行稳健的贝叶斯推断？后验分布的渐近行为是什么？

该系列可划分为三条交织演进的研究主线：**主线一**（极小极大 → 深度验证）：(?) 建立极小极大理论框架；(?) 将理论具体化为 MLDMAE 方法；(?) 推广至分布回归设定。

主线二（VAE → 扩散模型自适应）：(?) 建立 VAE 的 Excess Risk Bound；(?) 证明扩散模型同样自适应流形；(?) 将最优性推广至条件扩散模型。

主线三（稳健贝叶斯 → 高效 MCMC）：(?) 建立黎曼 BvM 定理与 RRWM 算法；(?) 利用 BvM 性质证明 MALA 最优混合时间。

3. 主线一：从极小极大理论到深度模型验证

3.1. (?)：极小极大理论的奠基. 论文信息：Annals of Statistics, 2022, Vol.50, No.4, 2197–2216.

创新性：首次建立了未知子流形上分布估计在对抗损失下的完整极小极大理论。核心发现是三类不同收敛机制的识别：参数机制 ($n^{-1/2}$)、密度估计机制 ($n^{-(\alpha+\gamma)/(2\alpha+d)}$) 和流形估计机制 ($n^{-\beta\gamma/d}$)，三者取最大值构成最终速率。**关键发现**：环境维度 D 完全不出现在速率指数中。

技术贡献：引入单位分解 (Partition of Unity) 技术，构造了能够覆盖无全局参数化流形的估计器，突破了单编码器 VAE/GAN 的根本局限。下界证明综合运用 Fano 不等式、

Varshamov-Gilbert 引理、经验过程理论 (chaining、peeling、localization) 和 Poincaré 不等式。

局限性：

- 估计器构造涉及小波截断、Lepski 自适应等复杂步骤，未给出具体算法实现——这是一篇“理论导向”而非“方法导向”的工作。
- 仅考虑无噪声观测；噪声情形下收敛速率急剧下降至仅对数级。
- 流形光滑阶 β 和密度光滑阶 α 须已知或通过额外假设获得。

在系列中的地位：(?) 是整个系列的理论基石，为 (?)、(?)、(?) 中具体生成模型的分析提供了理论参照系。

3.2. (?)：MLDMAE 方法. 论文信息：ICML, 2023.

创新性：提出混合潜在分布匹配自编码器 (MLDMAE) 方法，利用 K 个局部编码器-解码器对分别学习流形局部区域的参数化，通过单位分解函数 ρ_k 实现光滑拼接。**核心发现：多编码器/解码器结构在流形分布估计中是必要的。**在 1-Wasserstein 距离下达极小极大最优（至多对数因子）。

技术贡献：将 (?) 的理论极小极大框架转化为可计算的深度学习方法，验证了单位分解技术在深度学习中的可实现性。

局限性：

- 聚类数 K 的选择缺乏自适应理论指导，仅通过实验说明 $K \approx 10$ 对 MNIST 有效。
- 当 $\alpha > \beta - 1$ 时，最优速率是否仍然保持极小极大最优，论文仅提及但未严格证明。
- 局部块之间的重叠区域在理论上没有得到充分分析。

3.3. (?)：分布回归的极小极大速率. 论文信息：arXiv:2501.00001, 2025.

创新性：在三类层次递进的设定下系统建立了极小极大下界，并提出融合对抗学习 (IPM 度量) 与同步最小二乘的混合估计量。 γ -Hölder IPM d_γ 统一了全变差距离 ($\gamma = 0$) 和 1-Wasserstein 距离 ($\gamma = 1$)。

Regime 3 (协变量依赖响应空间) 揭示了 $d_X, d_Y, \beta_X, \beta_Y$ 等几何参数如何共同决定收敛速率。

局限性：

- 三层 Regime 的下界证明复杂，但上界中 $\frac{\alpha_Y}{\alpha_X} \cdot d_X$ 项的出现略显 ad hoc，缺乏几何直觉。
- 提出的混合估计量在 $\gamma \neq 0, 1$ 时是否仍然可计算（如何实现 IPM 的判别器优化？）并未讨论。
- 条件流形族 $\mathcal{M}_{Y|x}$ 随 x 光滑变化的假设较强，在实际应用中难以验证。

4. 主线二：从 VAE 到扩散模型自适应理论

4.1. (?)：VAE 的 Excess Risk Bound. 论文信息：COLT, 2021.

创新性：为 VAE 型生成模型提供了首个关于 Excess Risk 的非渐近上界，揭示了 VAE 隐式自适应低维流形结构的机制——潜在空间维数与流形本征维数的关系是关键。

局限性：

- 假设条件依赖于解码器族和编码器族的逼近能力，在实际应用中的可验证性有待进一步讨论。
- VAE 的 posterior collapse 问题在理论上没有得到解释，限制了理论结果的实践指导意义。
- Excess Risk Bound 的速率可能不是最优的，与 (?) 的极小极大速率存在差距。

4.2. (?): 扩散模型自适应流形结构. 论文信息: AISTATS, 2024.

创新性: 系统证明了两类扩散模型 (Langevin 扩散和正向-反向扩散) 的分布估计收敛速率仅依赖于数据的本征维度 d 而非环境维度 D ——这是该论文最重要的理论发现, 建立了“实践有效的工具 $\Leftrightarrow$ 理论最优的方法”这一对应关系。

技术贡献:

- **Langevin 扩散分支:** 通过 Gaussian 平滑 $p_\sigma(x) = \int p_{\text{data}}(y)\phi_\sigma(x-y)dy$ 使密度函数在任意时刻 $t > 0$ 关于 Lebesgue 测度绝对连续, 关键改进为只需分数函数的四阶矩误差 (而非 L_∞ 或矩母函数误差) 即可控制分布估计误差。
- **正向-反向扩散分支:** 构造了时间分段常数的神经网络架构 $\mathcal{S}_{\text{NN}}$ 逼近时变分数函数, 在 1-Wasserstein 距离下达极小极大最优速率 $\frac{1}{\sqrt{n}} \vee n^{-\frac{\alpha+1}{2\alpha+d}}$ 。
- 通过 Girsanov 定理建立了分数估计误差与分布估计误差之间的联系, 是连接 SDE 理论与统计学习的核心技术。

深层机制: 正向扩散天然地通过高斯噪声填充了流形的管状邻域, 从而回避了奇异分布 (流形支撑分布) 的困难。

局限性:

- 神经网络架构 (时间分段常数) 过于简化, 距实际使用的 ResNet、U-Net 等架构仍有较大差距。
- 各向同性高斯噪声可能“稀释”流形结构——论文提及但未给出严格的量化分析。
- 分段数 J 依赖于未知的光滑度参数 α , 实践中难以选择。

与系列的关系: (?) 提供极小极大目标; 本篇证明扩散模型能够达到该目标。

4.3. (?): 条件扩散模型的最优性. 论文信息: arXiv:2501.00002, 2025 (joint with Lizhen Lin).

创新性: 首次建立了条件扩散模型的流形自适应理论, 在两种场景下均达到极小极大最优收敛速率: (1) 经典密度回归设定 (基于全变差度量): 推广了已有文献结果 (现有文献仅覆盖 $\alpha_X \in [0, 1]$ 情形); (2) 高维回归设定 (基于 Wasserstein 度量): 估计误差仅依赖内在维度 (d_X, d_Y) 而非环境维度 (D_X, D_Y) 。

局限性:

- 缺乏对条件生成模型与 (?) 条件分布回归理论之间关系的讨论。
- 条件扩散模型中的 classifier-free guidance 等实践技术的理论解释尚未涉及。
- 条件分数函数的估计需要额外的条件生成模型架构, 计算成本较高。

5. 主线三：从稳健贝叶斯到高效 MCMC

5.1. (?): 黎曼子流形上的稳健贝叶斯推断. 论文信息: JRSS B, 2023, Vol.85, No.4, 1079–1103 (joint with Anirban Bhattacharya and Debdeep Pati).

创新性: 提出 Bayesian RPETEL 框架——无需正确指定似然函数的模型自由贝叶斯推断框架, 展现三重稳健性: (1) 无需正确指定似然函数即可提供自动校准的不确定性量化; (2) 即使欧氏风险最小化器不在流形上, 后验中心仍能接近流形上的风险最小化器; (3) 在正确设定下与标准贝叶斯后验渐近等价而不损失效率。

核心理论贡献: 黎曼流形上的 Bernstein-von Mises (BvM) 定理。通过将后验分布投影到流形切空间并利用局部坐标变换, 成功将欧氏空间中的分析工具推广到流形 setting, 证明了后验分布在切空间上的投影渐近正态——这是本文最重要的理论贡献。

计算贡献: 提出黎曼随机游走 Metropolis (RRWM) 算法, 证明了混合时间仅依赖流形内在维度 d 而非环境维度 D 。

局限性:

- 正则性假设较强：假设流形局部为 C^3 光滑，且要求风险函数满足二次增长条件，限制了在更一般流形上的应用。
- BvM 定理的收敛速度（到渐近正态的速率）在论文中没有给出，使得有限样本下的可靠性难以量化。
- RRWM 的 proposal 设计较为简单，在多峰分布或强非线性流形上可能表现不佳。

5.2. (?): MALA 的最优混合时间. 论文信息: ICML, 2024.

创新性：引入 s -conductance profile 新技术，在无需对目标分布施加光滑或强对数凹性假设的条件下，证明了 MALA 达到最优 $O(d^{1/3})$ 维度依赖（经 burn-in 后），且条件数依赖为线性，给出了匹配的下界。

技术贡献： s -conductance profile 提供了介于经典 conductance 与 Chen et al. (2020) 的 conductance profile 之间的精细分析工具，在非凸集假设下将 warm-start 参数依赖从 $\log M_0$ 改进到 $\log \log M_0$ ——在高维后验分布（ M_0 极大）的实际场景中意义显著。

与 (?) 的内在联系：(?) 建立了流形上的 BvM 定理（后验渐近正态）；本篇则利用渐近高斯性，将 MALA 在高斯目标分布上的最优性质桥接到一大类实际感兴趣的后验分布。

局限性：

- 定理要求 $d \leq cn^{\kappa_1}/\log n$ ，对于非光滑情形需要相对更大的样本量才能保证 $d^{1/3}$ 混合时间。
- s -warm start 假设在实践中难以验证，与 MCMC “无知采样”的哲学存在张力。
- 没有给出实际可用的 burn-in 长度估计。
- 在欧氏空间建立结果，流形上的 MALA 最优混合时间是开放问题。

6. 两样本检验：独立分支

6.1. (?) 论文信息: AISTATS, 2023.

创新性：建立了统一的两样本检验框架，基于负 Besov 范数的样本版本（通过截断小波展开构造），然后进行标准化处理。核心创新是建立了负 Besov 范数与对抗损失之间的等价关系（引理 1），从而能够同时适用于 ℓ_1 、 ℓ_2 距离和 Wasserstein 距离等多种度量。计算复杂度 $O(n \log n + n^{2d/(4\alpha+d)})$ 远优于 MMD 的 $O(n^2)$ 。

局限性：

- 正则性假设过强：假设密度函数具有紧支撑且一致有界，在许多实际应用中可能难以满足。
- 最优截断水平 J 的选择依赖于未知的光滑度参数 α ——如何构造对 α 自适应的检验仍是开放问题。
- Bootstrap 阈值的理论支撑不足。

7. 论文关系与技术索引

7.1. 发表时间线.

- (1) **2021** — (?) (COLT: VAE Excess Risk Bound)
- (2) **2022** — (?) (Annals of Statistics: 流形极小极大框架)
- (3) **2023a** — (?) (ICML: MLDMAE 混合生成模型)
- (4) **2023b** — (?) (JRSS B: 流形稳健贝叶斯 + BvM)
- (5) **2023c** — (?) (AISTATS: 两样本检验)
- (6) **2024a** — (?) (AISTATS: 扩散模型自适应流形)
- (7) **2024b** — (?) (ICML: MALA 最优混合时间)
- (8) **2025a** — (?) (arXiv: 分布回归极小极大速率)
- (9) **2025b** — (?) (arXiv: 条件扩散模型最优性)

7.2. 核心技术索引.

- (1) **单位分解 (Partition of Unity)**: (?)、(?) 利用此技术处理无全局参数化流形——是估计器构造的核心工具，也是区别于单编码器 VAE/GAN 的关键。
- (2) **γ -Hölder IPM 框架**: (?)、(?)、(?) 将不同光滑度的判别器类统一在同一个框架下，实现多种距离度量的同时最优。 γ 参数在流形支撑恢复与密度估计之间引入了可调节的权衡。
- (3) **Gaussian 平滑 + 四阶矩误差**: (?) 将 Langevin 扩散的分析从 L_∞ 弱化到四阶矩，建立了更弱但更实用的误差条件，是沟通 SDE 理论与统计估计的关键技术。
- (4) **时间分段神经网络架构**: (?)、(?) 构造了随时间演化的神经网络架构，有效平衡了近时间端 (t 小) 与远时间端 (t 大) 的逼近精度。
- (5) **s-conductance profile**: (?) 提出的马尔可夫链分析新技术，提供了介于经典 conductance 与 conductance profile 之间的精细分析工具，改进 warm-start 参数依赖。
- (6) **黎曼流形 Bernstein-von Mises 定理**: (?) 将经典 BvM 推广到黎曼子流形 setting，后验分布在切空间投影上渐近正态，是连接贝叶斯渐近理论与 MCMC 收敛分析的桥梁。
- (7) **Girsanov 定理桥梁**: (?)、(?) 通过 Girsanov 定理建立分数估计误差与分布估计误差之间的联系，是连接 SDE 理论与统计学习的核心技术。

8. 批判性评估

8.1. 整体优势.

- (1) **理论系统性极强**: 该系列从极小极大理论出发，依次建立了深度生成模型自适应理论和稳健贝叶斯推断框架，三条主线相互呼应而非孤立发表。这种系统性在国内统计机器学习研究中较为罕见。
- (2) **技术工具有原创性**: 单位分解、s-conductance profile、四阶矩误差分析等技术工具均具有原创性贡献，而非简单照搬已有方法。
- (3) **理论与实践的桥梁意识**: (?) 和 (?) 体现了将理论极小极大速率转化为具体深度学习算法的努力，这一点在纯理论论文中常常缺失。
- (4) **顶级发表记录**: 在五年内 (2021–2025) 发表了 7 篇顶级会议/期刊论文 (COLT, Annals, JRSS B, ICML x2, AISTATS x2)，表明该系列工作得到了国际同行的高度认可。

8.2. 主要不足.

- (1) **理论与实践的显著差距**: 尽管 (?) 和 (?) 试图弥合理论与实践，但估计器构造 (时间分段常数神经网络等) 与实际使用的架构 (U-Net, ResNet) 之间仍有较大差距。预训练模型能否进一步改善理论速率，这一问题未被触及。
- (2) **流形维数自适应缺失**: 整个系列均假设内在维度 d 已知，但实际应用中 d 通常未知。如何构造对 d 自适应的估计器，同时保持极小极大最优性，是该系列最大的理论缺口之一。
- (3) **噪声观测情形被忽视**: 除两样本检验外，多数论文仅考虑无噪声观测。噪声情形下 (?) 的速率急剧下降 (仅对数级)，这表明当前理论与实际应用之间存在根本性断层。
- (4) **计算复杂度与统计最优性未统一**: 渐近最优的神经网络架构面临严重的计算挑战，但论文中对此几乎未做讨论。
- (5) **与其他生成模型理论的比较不足**: 如与变分推断的泛化理论、归一化流的统计理论等，缺乏有意义的比较和区分。

- (6) **BvM 定理的局限性**: (?) 的 BvM 定理要求后验分布相对”规则”，对实际中常见的混合后验、退化后验等情形不适用。

9. 开放问题与进一步阅读

基于对 Tang-Rong 系列的批判性分析，以下问题值得进一步探索：

- (1) **流形维数的自适应估计**: 如何构造对 d 自适应的估计器，同时保持极小极大最优性？是否存在类似 Lepski 方法的维数自适应技术？
- (2) **噪声观测情形的多项式速率**: (?) 的无噪声设定过于理想化。是否有方法在适度噪声假设（如有界噪声、测量误差模型）下恢复多项式收敛速率？
- (3) **光滑性自适应**: 极小极大速率依赖于未知的光滑度参数 α, β, γ ，如何构造对这些参数同时自适应的估计器？
- (4) **预训练模型的理论分析**: 实际应用中的扩散模型通常在大规模数据上预训练。预训练能否改善从零开始训练的极小极大速率？迁移学习在流形统计学习中的理论保证是什么？
- (5) **流形 MCMC 的最优收敛**: (?) 在欧氏空间建立了 MALA 的最优混合时间；流形上的 MALA（黎曼流形上的 Metropolis-Hastings 算法）在何种条件下能够达到类似的最优依赖？
- (6) **深度生成模型与其他 IPM 的结合**: 当前的理论主要围绕 Wasserstein 距离和全变差距离展开。对于 MMD、Stein 差异等更一般的 IPM，深度生成模型能否达到相应的极小极大速率？
- (7) **条件生成模型的不确定性量化**: (?) 证明了条件扩散模型的条件分布估计最优性，但条件生成模型的后验不确定性如何刻画？这与 (?) 的稳健贝叶斯框架有何联系？

10. 参考文献