

CHAPTER 1

黎曼子流形上的稳健贝叶斯推断

1. 引言

统计推断的根本挑战之一在于：当数据的高维特征空间 $\mathbb{R}^D$ 本质上由低维流形结构主导时，经典方法往往失效。环境维度 D 巨大（图像、文本、点云数据），但有效自由度 $d \ll D$ ，数据点近乎均匀分布在某个未知低维黎曼流形 $\mathcal{M}$ 上。

在贝叶斯框架下，这一几何约束引出了一个深刻问题：如何对取值于黎曼流形 $\mathcal{M}$ 的参数进行稳健的贝叶斯推断？特别地，当数据生成机制偏离标准假设时——例如，数据服从 Huber 污染模型（contamination model）——后验分布是否仍能提供可靠的不确定性量化？

本论文（(?)）的核心贡献在于提出 Bayesian RPETEL 框架，并建立了一套完整的三重稳健性理论。

1.1. Huber 污染模型. 设真实数据分布 P 为纯净分布 P_0 与污染分布 Q 的混合：

$$(1) \quad P = (1 - \epsilon) P_0 + \epsilon Q, \quad 0 \leq \epsilon < \frac{1}{2},$$

其中 ϵ 为污染率（contamination rate）。纯净分布 P_0 关于勒贝格测度绝对连续，其密度函数记为 p_0 ；污染分布 Q 任意。该模型刻画了“大部分数据来自正确模型，但存在少量对抗性或异常噪声”这一实际情形。

在传统欧氏空间设定下，Huber 损失与污染模型催生了鲁棒似然（robust likelihood）和鲁棒估计的理论。本文将此框架推广至黎曼流形 $\mathcal{M}$ 设定，引入了流形约束下的欧氏风险最小化（Projected Euclidean Risk Minimization，简称 PERM）以及其贝叶斯版本 RPETEL。

1.2. 三重稳健性目标. 本文所追求的稳健性包含三个层面：

- (1) **似然稳健性 (likelihood robustness)**: 即使似然函数未正确指定，后验分布仍能提供自动校准的不确定性量化。
- (2) **风险稳健性 (risk robustness)**: 即使欧氏风险最小化器 (Euclidean risk minimizer) 不在流形 $\mathcal{M}$ 上，后验中心仍能接近流形上的风险最小化器。
- (3) **先验稳健性 (prior robustness)**: 在正确设定 (correct specification) 下，后验分布与标准贝叶斯后验渐近等价，不因引入稳健机制而损失效率。

这三重稳健性目标之间存在内在张力——提高似然稳健性通常会牺牲效率，而宽松的先验稳健性条件又可能削弱风险稳健性。本文的核心结果表明，在一定正则性条件下，Bayesian RPETEL 框架可以同时实现这三个目标。

2. RPETEL 框架

2.1. 从 PERM 到 RPETEL. 设损失函数 $\ell_x : \mathcal{M} \rightarrow \mathbb{R}_+$ ，风险函数定义为

$$(2) \quad R(\theta) = \mathbb{E}_P[\ell_X(\theta)] = \int \ell_x(\theta) dP(x).$$

在欧氏空间中，风险最小化器 (ERM) 为 $\theta^\dagger = \arg \min_{\theta \in \mathbb{R}^D} R(\theta)$ 。然而，当参数自然地取值于流形 $\mathcal{M}$ 时，将 $\theta^\dagger$ 投影到 $\mathcal{M}$ 上是自然的想法。

PERM (Projected Euclidean Risk Minimization) 的定义为：

$$(3) \quad \theta^\ddagger = \arg \min_{\theta \in \mathcal{M}} R(\theta), \quad \text{即 } \theta^\ddagger = \Pi_{\mathcal{M}}(\theta^\dagger),$$

其中 $\Pi_{\mathcal{M}}(\cdot)$ 为到流形 $\mathcal{M}$ 的最近点投影。

RPETEL (Bayesian Robust Projected Euclidean Risk Minimization) 则将 PERM 嵌入贝叶斯框架：设先验分布 Π 在 $\mathcal{M}$ 上定义，定义伪似然 (pseudo-likelihood) 如下：对于观测数据 $x_1, \dots, x_n$ ，定义加权负对数似然

$$(4) \quad L_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell_{x_i}(\theta), \quad \theta \in \mathcal{M}.$$

后验分布定义为

$$(5) \quad \Pi_n(d\theta) = \frac{\exp(-nL_n(\theta)) \Pi(d\theta)}{\int_{\mathcal{M}} \exp(-nL_n(\theta')) \Pi(d\theta')}.$$

关键观察：在平方损失 $\ell_x(\theta) = \|x - \theta\|_2^2$ 下，风险函数 $R(\theta)$ 的形式关于 θ 是二次的，这使得后续的局部坐标分析和切空间投影变得 tractable。

2.2. 平方损失下的风险函数. 设损失函数 $\ell_x(\theta) = \|x - \theta\|_2^2$ 。记 $m := \mathbb{E}_P[X] \in \mathbb{R}^D$ 为数据的均值向量，则风险函数简化为

$$(6) \quad R(\theta) = \mathbb{E}_P[\|X - \theta\|_2^2] = \text{tr}(\Sigma) + \|\theta - m\|_2^2,$$

其中 $\Sigma = \text{Cov}_P(X)$ 为协方差矩阵。该分解揭示了一个核心事实： $\theta^\dagger = m$ ，而 $\theta^\ddagger = \Pi_{\mathcal{M}}(m)$ ——流形上的风险最小化器是均值向量在流形上的投影。

在后验分布 eq. (5) 中，指数项 $-nL_n(\theta)$ 对应于样本均值的指数型族，这与欧氏空间中的经典结果形成类比。

3. 黎曼流形 BvM 定理

贝叶斯渐近理论的核心问题是：当样本量 $n \rightarrow \infty$ 时，后验分布如何收缩到真实参数？经典的 Bernstein-von Mises (BvM) 定理表明，在正则条件下，后验分布渐近正态且集中于真参数附近，中心为 $\sqrt{n}(\theta - \theta_0)$ 的渐近协方差由 Fisher 信息决定。

本文将这一经典结果推广到黎曼子流形 setting，建立了流形上的 BvM 定理——这是本文最重要的理论贡献。

3.1. 切空间投影与局部坐标. 设 $\mathcal{M}$ 为 $\mathbb{R}^D$ 中紧致光滑 d 维黎曼子流形，嵌入维度为 D 。对任意点 $\theta \in \mathcal{M}$ ，记其切空间 (tangent space) 为 $T_\theta \mathcal{M} \subset \mathbb{R}^D$ ，维数为 d ；记到切空间的正交投影算子为 $\Pi_\theta : \mathbb{R}^D \rightarrow T_\theta \mathcal{M}$ 。

给定后验分布 Π_n ，定义其在切空间 $T_\theta \mathcal{M}$ 上的投影为

$$(7) \quad \Pi_n^\theta(B) = \Pi_n(\{\theta' \in \mathcal{M} : \Pi_\theta(\theta' - \theta) \in B\}), \quad B \subset T_\theta \mathcal{M}.$$

局部坐标的构造依赖指数映射 (exponential map) $\exp_\theta : T_\theta \mathcal{M} \rightarrow \mathcal{M}$ ：对任意切向量 $v \in T_\theta \mathcal{M}$ ， $\exp_\theta(v)$ 为从 θ 出发沿测地线以速度 $\|v\|$ 行进得到的点。在 θ 的小邻域内，指数映射为微分同胚，因此可将 $\mathcal{M}$ 上的局部问题拉回到切空间 $T_\theta \mathcal{M}$ 上分析。

3.2. 渐近正态性. 设真实参数为 $\theta_0 \in \mathcal{M}$, 数据生成分布为 P_{θ_0} (正确设定)。以下定理给出了流形上 BvM 定理的精确表述。

[黎曼流形 BvM 定理] 假设以下正则性条件成立：

- (A1) 流形 $\mathcal{M}$ 为 C^3 光滑紧致黎曼子流形；
- (A2) 损失函数 $\ell_x(\cdot)$ 在 $\mathcal{M}$ 上满足二次增长条件 (quadratic growth condition)；
- (A3) 先验分布 Π 在 θ_0 的邻域内具有正的光滑密度；
- (A4) $n \rightarrow \infty$ 时收缩条件 $\epsilon_n \rightarrow 0$ 成立，其中 ϵ_n 为某种熵量度。

记 $\Pi_n^{\theta_0}$ 为后验分布在切空间 $T_{\theta_0}\mathcal{M}$ 上的投影 (eq. (7))。则

$$(8) \quad \Pi_n^{\theta_0} \implies N(0, n^{-1}G(\theta_0)^{-1}) \quad (\text{在分布意义下}),$$

其中 $G(\theta_0)$ 为黎曼度量 (metric) 在 θ_0 处的 Fisher 信息矩阵在局部坐标下的表示。

eq. (8) 的含义是：将后验分布投影到 θ_0 处的切空间后，该投影渐近等价于均值在 θ_0 、协方差为 $n^{-1}G(\theta_0)^{-1}$ 的正态分布。这与欧氏空间 BvM 定理的形式完全类比，唯一的差异在于协方差由黎曼 Fisher 信息矩阵 $G(\theta_0)$ 决定，而非欧氏 Fisher 信息。

证明思路¹:

3.3. 收敛速率. 由 eq. (8)，后验分布在切空间投影上的集中速率由 $n^{-1/2}$ 主导。进一步的分析表明，在额外正则性假设下，后验收缩速率 (posterior contraction rate) 为

$$(9) \quad \pi_n = \sqrt{\frac{d}{n}} \vee n^{-\frac{\beta}{2}},$$

其中 β 与流形光滑度和损失函数的局部行为有关。注意这一速率仅依赖于流形内在维度 d ，而非环境维度 D ——这正是流形结构带来统计效率提升的体现。

收敛速率中 d 的出现是本质的：在 d 维切空间中，Fisher 信息矩阵 $G(\theta_0)$ 的特征值个数为 d ，后验协方差的尺度自然地与 d 成正比。然而，与纯维数灾难不同， d 是数据的有效自由度——它是固定的 (不随 n 增长)，因此不会导致速率的多项式衰退。

4. RRWM 算法

贝叶斯推断的计算核心在于从后验分布 Π_n 中采样。在流形约束下，标准 MCMC 算法 (如随机游走 Metropolis、Metropolis-Hastings) 的直接应用面临几何障碍——如何保证 proposal 分布产生的候选点严格位于流形上？

本文提出的 RRWM (Riemannian Random Walk Metropolis) 算法通过在切空间 $T_{\theta}\mathcal{M}$ 中构造 proposal 并利用指数映射将其推回流形，成功解决了这一问题。

4.1. 算法构造. 设当前状态为 $\theta \in \mathcal{M}$ 。RRWM 的 proposal 分布定义在切空间 $T_{\theta}\mathcal{M}$ 上：

$$(10) \quad v \sim N(0, \sigma^2 G(\theta)^{-1}), \quad \theta' = \exp_{\theta}(v),$$

其中 $G(\theta)$ 为 θ 处的黎曼度量矩阵， $\sigma > 0$ 为步长参数。 $G(\theta)^{-1}$ 作为协方差矩阵的逆保证了 proposal 分布在黎曼几何意义下是“各向同性”的——这被称为黎曼-高斯 (Riemannian-Gaussian) 分布。

¹详细证明见 (?, Section 3)。核心步骤分为三步：(1) 在局部坐标下将流形上的问题转化为切空间 $\mathbb{R}^d$ 上的问题；(2) 运用欧氏 BvM 定理的标准技术 (van der Vaart & Wellner 方法) 证明切空间上的渐近正态性；(3) 通过指数映射 $\exp_{\theta_0}$ 的近似性质 (在小邻域内接近线性映射) 将切空间结果拉回流形。其中步骤 (1) 需要用到流形的局部平坦化性质和投影算子 Π_{θ} 的光滑性。

接受概率 (acceptance probability) 由 Metropolis 准则给出：

$$(11) \quad a(\theta, \theta') = \min \left\{ 1, \frac{\exp(-nL_n(\theta')) \pi_{\mathcal{M}}(\theta') q(\theta', \theta)}{\exp(-nL_n(\theta)) \pi_{\mathcal{M}}(\theta) q(\theta, \theta')} \right\},$$

其中 $q(\theta, \theta')$ 为从 θ 到 θ' 的 proposal 密度 (相对于流形上的适当测度), $\pi_{\mathcal{M}}$ 为流形体积元 (volume element)。关键的是, 指数映射 $\exp_{\theta}$ 的 Jacobian 行列式出现在 proposal 密度的计算中, 它补偿了流形弯曲带来的体积变化。

4.2. 混合时间分析. RRWM 算法的核心理论保证是：其混合时间 (mixing time) 仅依赖流形内在维度 d , 而非环境维度 D 。

[RRWM 混合时间] 在 section 3 的正则性条件下, 设 $\epsilon > 0$, n 固定。RRWM 算法的 ϵ -混合时间 (ϵ -mixing time) 满足

$$(12) \quad t_{\text{mix}}(\epsilon) \asymp d \cdot \log(d/\epsilon),$$

其中隐含常数仅依赖流形几何 (截面曲率、injectivity radius) 和目标分布的局部行为。

eq. (12) 的意义在于： D 完全不出现在混合时间的维度依赖中。这与欧氏空间随机游走 Metropolis 的已知结果形成鲜明对比——在后者的经典分析中, 混合时间通常具有 $O(D)$ 的维度依赖。这一改进来源于黎曼几何结构：曲率约束和流形的紧性使得链在”局部”行为上不受 D 的影响。

证明思路²:

5. 极小极大最优性

本节讨论 Bayesian RPETEL 后验的收缩速率是否达到了统计最优。这一问题的回答需要建立上界 (由 section 3.3 的分析给出) 与相应的下界 (下确界) 之间的匹配。

5.1. 收缩速率上界. 由 eq. (9), Bayesian RPETEL 后验的收缩速率上界为 $\pi_n \asymp \sqrt{d/n}$ (在典型正则性假设下)。这一速率与经典的 Le Cam's lemma 所给出的二元检验下界一致, 表明在 L_2 风险意义下, $\sqrt{d/n}$ 是几乎所有估计量的最优收敛速率。

5.2. 极小极大下界. [极小极大下界] 设 $\mathcal{M}$ 为 d 维紧致光滑黎曼子流形, 族 $\mathcal{P}$ 由 n 个 i.i.d. 样本的分布构成, 满足一定的光滑性假设。则任意估计量 $\hat{\theta}_n$ 的极小极大风险满足

$$(13) \quad \inf_{\hat{\theta}_n} \sup_{P \in \mathcal{P}} \mathbb{E}_P[\|\hat{\theta}_n - \theta^\dagger\|_2] \gtrsim \sqrt{\frac{d}{n}}.$$

eq. (13) 给出了 $\sqrt{d/n}$ 的下界。结合上界 $\pi_n \asymp \sqrt{d/n}$, 我们得到：

[极小极大最优性] 在 section 3 的正则性条件下, Bayesian RPETEL 后验的收缩速率达到了极小极大最优 (至多常数因子和对数因子)。

eq. (13) 的证明综合运用了 Le Cam's method、tensor product construction 和黎曼几何中的 volume comparison 技术。关键是构造一族难以区分的替代分布 (alternative distributions), 其参数在流形上以适当距离分隔。黎曼流形的体积增长性质 (volume growth rate $\asymp s^d$) 在此处发挥了关键作用——它决定了在给定分辨率下能够构造多少个相互”可区分”的备择假设。

²详见 (?, Section 5)。核心思想是将流形上的链投影到一系列局部坐标卡 (coordinate charts) 上, 在每个局部卡内运用欧氏 Metropolis 算法的混合时间界, 然后利用流形的有限覆盖性质拼接各局部分析。关键引理是：切空间投影的方差在 d 维而非 D 维尺度上增长。

6. 本章小结

本章系统介绍了(?)的核心内容。Bayesian RPETEL 框架将稳健统计的思想与黎曼几何的结构结合,通过三重稳健性目标——似然稳健性、风险稳健性和先验稳健性——为流形约束下的贝叶斯推断提供了统一理论。

- (1) **RPETEL 框架** (section 2): 通过伪似然构造 (eq. (4)) 和后验定义 (eq. (5)), 将 PERM 嵌入贝叶斯框架, 在平方损失下简化为对样本均值的指数型后验。
- (2) **黎曼 BvM 定理** (section 3): eq. (8) 建立了后验分布在切空间投影上的渐近正态性, 是连接贝叶斯渐近理论与流形几何的核心工具。
- (3) **RRWM 算法** (section 4): eq. (10)–eq. (11) 实现了流形上的 Metropolis 采样, eq. (12) 证明其混合时间仅依赖 d 而非 D 。
- (4) **极小极大最优性** (section 5): corollary 5.2 表明 RPETEL 后验收缩速率达到极小极大最优 $\sqrt{d/n}$ 。

本章内容与系列中其他论文存在深刻联系: (?) 的极小极大理论为最优性判断提供了参照系; (?) 则利用本章建立的流形 BvM 定理, 将 MALA 在欧氏空间的最优混合性质桥接到黎曼流形 setting, 从而将后验推断的计算效率提升到了最优的 $O(d^{1/3})$ 维度依赖。