

CHAPTER 1

黎曼子流形上的稳健贝叶斯推断

本笔记系统整理 (?) (JRSS B, 2023, Vol.85, No.4, 1079–1103) 的核心内容, 聚焦于流形约束下的贝叶斯推断理论、RPETEL 框架与 RRWM 算法。

1. 引言

现代统计中大量问题涉及取值于黎曼流形上的参数估计: 协方差矩阵 (正定矩阵流形 $\mathbb{S}_+^p$)、方向数据 (单位球面 $\mathbb{S}^{d-1}$)、降秩回归系数 (Grassmannian 流形)、扩散张量均值 (正定对称矩阵流形) 等。设 $\mathcal{M} \subset \mathbb{R}^D$ 为紧致光滑 d 维黎曼子流形, 嵌入维度为 D (通常 $d \ll D$)。经典贝叶斯方法将参数先验置于全空间 $\mathbb{R}^D$ 上, 但这忽略了流形约束, 可能导致后验分布在高维环境空间中的不必要扩散。

一个更本质的困难在于: 即便将先验限制在 $\mathcal{M}$ 上, 后验分布关于 $\mathbb{R}^D$ 中的 Lebesgue 测度是奇异的——它集中在 d 维子流形上, 质量为零。因此, 经典的 Bernstein-von Mises (BvM) 定理不能直接应用。

更严峻的挑战来自模型误设定 (model misspecification): 在实践中, 似然函数难以正确指定, 数据生成分布可能来自 Huber 污染模型 (Huber contamination model)。在欧氏空间中, 即使似然误设定, Gibbs 后验的 BvM 定理 (如 (?)) 仍可在一定条件下成立。本文的核心问题是: 能否将这一鲁棒性推广到黎曼流形 setting, 同时保持计算上的可行性?

2. 黎曼几何预备

本节给出全文所需的核心几何定义与记号, 细节参见 (?, Appendix A) 和 (?)。

[黎曼子流形] 设 $\mathcal{M}$ 为嵌入于 $\mathbb{R}^D$ 的 d 维黎曼子流形。对任意 $\theta \in \mathcal{M}$, 记 $T_\theta \mathcal{M} \subset \mathbb{R}^D$ 为其在 θ 处的切空间, 维数为 d 。设 $P_\theta \in \mathbb{R}^{D \times D}$ 为到 $T_\theta \mathcal{M}$ 的正交投影矩阵, $W_\theta \in \mathbb{R}^{D \times d}$ 为 $T_\theta \mathcal{M}$ 的任意一组标准正交基, 满足 $P_\theta = W_\theta W_\theta^\top$ 。

局部坐标的构造依赖投影映射 $\psi_\theta: \mathcal{U}_\theta \rightarrow T_\theta \mathcal{M}$, 定义为 $\psi_\theta(x) = \text{Proj}_{T_\theta \mathcal{M}}(x - \theta)$, 其中 $\mathcal{U}_\theta$ 为 θ 在 $\mathcal{M}$ 中的邻域。其逆映射 $\phi_\theta = \psi_\theta^{-1}: T_\theta \mathcal{M} \rightarrow \mathcal{U}_\theta$ 被称为 retraction (或称为指数映射的近似), 其 Fréchet 导数满足一阶等价性。

可测性说明: 由于 ψ_θ 为线性正交投影算子的限制, 它是从 $\mathbb{R}^D$ 到 d 维子空间 $T_\theta \mathcal{M}$ 的连续 (从而 Borel 可测) 映射。给定 Borel 集 $B \subset T_\theta \mathcal{M}$, 预像 $\psi_\theta^{-1}(B) \subset \mathbb{R}^D$ 为 Borel 集; 将其限制在 $\mathcal{M}$ 上仍为 Borel (相对于 $\mathcal{M}$ 上的子空间拓扑), 故后验分布在该集合上的取值良定。

本文的关键假设是局部 $C_{r,L}^3$ 光滑性: 在 θ^* 的邻域内, ϕ_θ 三阶 Fréchet 可微, 且导数范数一致有界于 L 。这一假设确保切空间 $T_{\theta^*} \mathcal{M}$ 在 θ^* 附近提供了流形 $\mathcal{M}$ 的良好线性近似。

对于损失函数 $\ell: \mathcal{X} \times \mathcal{M} \rightarrow \mathbb{R}$, 定义黎曼梯度 $\text{grad}_\theta \ell(x, \theta) \in T_\theta \mathcal{M}$ 为 $\ell(x, \cdot)$ 在流形上的最速上升切方向。相应地, 总体风险函数 $R(\theta) = \mathbb{E}_P[\ell(X, \theta)]$ 的黎曼梯度为 $\text{grad } R(\theta)$ 。风险最小化器 $\theta^* = \arg \min_{\theta \in \mathcal{M}} R(\theta)$ 的一阶最优性条件为 $\text{grad } R(\theta^*) = 0$ 。

3. 流形上的 BvM 定理

3.1. Gibbs 后验的 BvM 定理. 本节研究参数取值于黎曼子流形 $\mathcal{M}$ 上的 Gibbs 后验的渐近形态。设先验分布 Π 在 $\mathcal{M}$ 上定义，Gibbs 后验定义为

$$(1) \quad \Pi(d\theta \mid X^{(n)}) = \frac{\exp\left(-\sum_{i=1}^n \ell(X_i, \theta)\right) \Pi(d\theta)}{\int_{\mathcal{M}} \exp\left(-\sum_{i=1}^n \ell(X_i, \theta')\right) \Pi(d\theta')}.$$

注意此处的 ℓ 不一定是负对数似然——它可以是任意损失函数。

记经验风险最小化器 (ERM) 为 $\hat{\theta} = \arg \min_{\theta \in S_{\Pi}} \frac{1}{n} \sum_{i=1}^n \ell(X_i, \theta)$ 。设 $\mathcal{H}_{\theta^*}$ 为 $R(\cdot)$ 在 θ^* 处的黎曼 Hessian 矩阵 (在 $T_{\theta^*}\mathcal{M}$ 的局部坐标下)， $\Delta_{\theta^*} = \mathbb{E}[g(X, \theta^*)g(X, \theta^*)^\top]$ 为梯度型函数 g 的协方差矩阵。

关于 θ^* 的识别: section 2 中定义 $\theta^* = \arg \min_{\theta \in \mathcal{M}} R(\theta)$ 。在正确模型设定 (Assumption 5) 下，数据分布 P_{θ_0} 满足 $\theta_0 = \arg \min_{\theta \in \mathcal{M}} R(\theta)$ ，故 $\theta^* = \theta_0$ 。在误设定下， θ^* 为流形上的“伪真值” (pseudo-true parameter)，它不唯一对应某个真实分布，但仍是后验收缩的目标点。这一区分对理解 BvM 定理中的协方差矩阵至关重要: eq. (2) 中的 $\mathcal{H}_{\theta^*}^\dagger$ 是相对于该伪真值的 Fisher 型矩阵，而非相对于某个真实 θ_0 的。

[流形 BvM 定理 (Gibbs 后验)] 设正则性条件 (Assumptions 1-4, 详见 (?, Section 2)) 成立:

- (A1) $\mathcal{M}$ 在 θ^* 附近局部 $C_{r,L}^3$ 光滑;
- (A2) 先验支撑 S_{Π} 包含 θ^* 的固定半径邻域，且先验密度在 θ^* 附近 Lipschitz 连续;
- (A3) 风险函数 $R(\theta)$ 在 θ^* 处二次增长，即 $|R(\theta) - R(\theta^*)| \geq \frac{1}{L} \|\theta - \theta^*\|^2$;
- (A4) 损失函数的梯度型代理 $g(X, \theta)$ 满足 $\mathbb{E}[g(X, \theta^*)g(X, \theta^*)^\top] \succcurlyeq \frac{1}{L} I_d$ ，且具有一致有界的度量熵。

则存在集合 $\mathcal{A} \subset \mathcal{X}^n$ ，满足 $\mathbb{P}(X^{(n)} \in \mathcal{A}) \geq 1 - n^{-1}$ ，使得对任意 $X^{(n)} \in \mathcal{A}$ ，有

$$(2) \quad \text{TV}\left(\Pi(\cdot \mid X^{(n)}), \phi_{\theta^*} \# \mathcal{N}\left(\text{Proj}_{T_{\theta^*}\mathcal{M}}(\hat{\theta} - \theta^*), n^{-1} \mathcal{H}_{\theta^*}^\dagger\right)\right) \leq C \frac{(\log n)^{\frac{1}{\beta_1}+1}}{n^{\frac{\beta_2}{2}}},$$

其中 $\beta_1, \beta_2 \in (0, 1]$ 为 Assumption 4 中的光滑性参数， $\mathcal{H}_{\theta^*}^\dagger$ 为 Moore-Penrose 逆。

eq. (2) 表明: 将后验分布投影到切空间 $T_{\theta^*}\mathcal{M}$ 后，该投影渐近等价于以 $\text{Proj}_{T_{\theta^*}\mathcal{M}}(\hat{\theta} - \theta^*)$ 为均值、协方差为 $n^{-1} \mathcal{H}_{\theta^*}^\dagger$ 的正态分布。

关键发现: 即使后验分布在 $\mathbb{R}^D$ 中是奇异的，其在切空间上的投影仍然渐近正态——这一发现是本文最重要的理论贡献。值得注意的是，渐近协方差矩阵中的 Moore-Penrose 逆 $\mathcal{H}_{\theta^*}^\dagger$ 自动处理了切空间的约束，无需额外的拉格朗日乘子。

正确设定下的特例 (corollary 3.1): 当损失函数为负对数似然 $\ell(x, \theta) = -\log p(x \mid \theta)$ 且模型正确指定时， $\mathcal{H}_{\theta^*} = \Delta_{\theta^*} = I_{\theta^*}$ (Fisher 信息矩阵在切空间上的投影)，此时后验收缩至 $n^{-1/2}$ ，与经典 BvM 定理一致。

[正确设定下的 BvM] 在正确模型设定下 (Assumption 5)，对任意光滑函数 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ (在 θ^* 处 Riemannian 梯度非零)，有

$$\sqrt{n} (f(\hat{\theta}) - f(\theta^*)) \xrightarrow{d} \mathcal{N}\left(0, \nabla f(\theta^*)^\top (P_{\theta^*} I_{\theta^*} P_{\theta^*})^\dagger \nabla f(\theta^*)\right).$$

且后验分布产生的置信集渐近达到有效频率覆盖率。

流形结构带来的效率提升: Corollary 3.1 还揭示了一个量化结论: 后验方差 $n^{-1} \nabla f(\theta^*)^\top (P_{\theta^*} I_{\theta^*} P_{\theta^*})^\dagger \nabla f(\theta^*)$ 恒不超过欧氏后验方差 $n^{-1} \nabla f(\theta^*)^\top I_{\theta^*}^{-1} \nabla f(\theta^*)$ 。这表明: 利用流形约束可以在不牺牲覆盖率的前提下缩短置信集长度。

3.2. RPETEL 框架: 三重稳健性.

3.2.1. 问题引入. Gibbs 后验 BvM 定理的核心局限在于：即使在欧氏空间中，当模型误设定时，后验分布的协方差与频率学派采样分布的协方差可能不匹配，导致不确定性量化失效。在流形设定下，这一问题更加严峻——误设定下的后验可能在远离 θ^* 的方向上过度扩张。

本文提出的 Bayesian RPETEL 框架通过引入黎曼指数倾斜经验似然 (Riemannian Exponentially Tilted Empirical Likelihood, 简称 RETEL) 来构造伪似然，并结合经验风险惩罚项，成功实现了三重稳健性。

3.2.2. RETEL 伪似然的构造. 设损失函数 $\ell : \mathcal{X} \times \mathcal{M} \rightarrow \mathbb{R}$ ，对应的黎曼梯度为 $g(x, \theta) = \text{grad}_\theta \ell(x, \theta) \in T_\theta \mathcal{M}$ 。风险最小化器 $\theta^* = \arg \min_{\theta \in \mathcal{M}} R(\theta)$ 的一阶最优性条件为 $\mathbb{E}[g(X, \theta^*)] = 0$ ——这提供了 θ^* 的识别条件，无需完整指定似然函数。

RETEL 的构造借鉴了 (?) 的指数倾斜方法：对给定的 θ ，引入非负权重 $w_1, \dots, w_n$ (满足 $\sum_i w_i = 1$)，最小化后向 KL 散度 $D_{\text{KL}}(\text{Unif} \parallel \sum_i w_i \delta_{X_i})$ 并施加一阶最优性条件的加权版本约束：

$$\sum_{i=1}^n w_i g(X_i, \theta) = 0, \quad w_i \geq 0.$$

具体而言，RETEL 函数 $L(X^{(n)}; \theta)$ 由以下优化问题定义：

$$(3) \quad \begin{aligned} L(X^{(n)}; \theta) &= \max_{w_1, \dots, w_n} \sum_{i=1}^n [-w_i \log(nw_i)] \\ \text{s.t.} \quad &\sum_{i=1}^n w_i = 1, \quad \sum_{i=1}^n w_i g(X_i, \theta) = 0, \quad w_i \geq 0. \end{aligned}$$

直观上，RETEL 寻找一组权重，使经验分布的加权版本尽可能接近均匀分布，同时保证一阶最优性条件成立。这等价于在经验似然框架下融入了流形几何结构。

3.2.3. Bayesian RPETEL 后验. 为防止后验在远离 θ^* 的方向上分散，本文进一步引入经验风险惩罚项 $\alpha_n \mathcal{R}_n(\theta)$ ，其中 $\mathcal{R}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(X_i, \theta)$ ， α_n 为正则化参数 (典型取值为 $c_1 \log n \leq \alpha_n \leq c_2 \sqrt{n}$)。最终定义的后验分布为

$$(4) \quad \Pi_{\text{RP}}(d\theta \mid X^{(n)}) = \frac{\exp\left(\sum_{i=1}^n \log p_i(\theta) - \alpha_n \mathcal{R}_n(\theta)\right) \Pi(d\theta)}{\int_{\mathcal{M}} \exp\left(\sum_{i=1}^n \log p_i(\theta') - \alpha_n \mathcal{R}_n(\theta')\right) \Pi(d\theta')},$$

其中 $p_i(\theta)$ 为 RETEL 优化问题的最优权重对应的概率。当 $\alpha_n = 0$ 时，上式退化为基于纯 RETEL 伪似然的后验；当 α_n 适当大时，后验被强制集中于经验风险最小化器附近。

设计 RPETEL 时的一个关键选择是使用黎曼梯度 $\text{grad}_\theta \ell(X, \theta)$ 而非欧氏梯度 $\nabla_\theta \ell(X, \theta)$ 。理由如下：若使用欧氏梯度，当欧氏风险最小化器 $\theta_E^* \notin \mathcal{M}$ 时，一阶条件 $\mathbb{E}[\nabla_\theta \ell(X, \theta)] = 0$ 不蕴含 $\theta_E^* \in \mathcal{M}$ ，导致伪似然过识别 (over-identified) —— D 个方程约束 d 维参数——从而使后验分散到多个局部模。使用黎曼梯度则自动将问题投影到切空间，等效于只施加 d 个有效约束，避免了这一问题。

3.2.4. RPETEL 的三重稳健性. [流形 BvM 定理 (Bayesian RPETEL)] 在 section 3.1 的正则性条件下，设 $c_1 \log n \leq \alpha_n \leq c_2 \sqrt{n}$ 。则存在集合 $\mathcal{A} \subset \mathcal{X}^n$ ($\mathbb{P}(X^{(n)} \in \mathcal{A}) \geq 1 - n^{-1}$)，使得对任意 $X^{(n)} \in \mathcal{A}$ ，有

$$(5) \quad \text{TV}\left(\Pi_{\text{RP}}(\cdot \mid X^{(n)}), \phi_{\theta^* \#} \mathcal{N}\left(\text{Proj}_{T_{\theta^*} \mathcal{M}}(\hat{\theta} - \theta^*), n^{-1} \mathcal{H}_{\theta^*}^\dagger \Delta_{\theta^*} \mathcal{H}_{\theta^*}^\dagger\right)\right) \leq C \frac{(\log n)^{\frac{2}{\beta_1} + 1}}{n^{\frac{\beta_2}{2}}}.$$

eq. (5) 与 eq. (2) 的关键区别在于协方差矩阵中的”夹心”结构 $\mathcal{H}_{\theta^*}^\dagger \Delta_{\theta^*} \mathcal{H}_{\theta^*}^\dagger$ ——这恰好是经验风险最小化器 $\sqrt{n}(\hat{\theta} - \theta^*)$ 渐近分布的协方差 (由 (? , Section 2) 的 CLT 给出)。这带来了以下三重稳健性。

第一重：似然稳健性。 由于后验收缩分布的协方差与 $\sqrt{n}(\hat{\theta} - \theta^*)$ 的渐近协方差一致，由该后验产生的置信集能够渐近达到正确的频率覆盖率——即使似然函数未正确指定。

第二重：风险稳健性。 即使欧氏风险最小化器 $\theta_E^* \notin \mathcal{M}$ ，后验中心 (投影后验均值) 仍接近流形上的风险最小化器 θ^* ——此时后验收缩至 θ^* 而非 θ_E^* ，避免了在 θ_E^* 附近的不稳定行为。

第三重：先验稳健性。 在正确模型设定下 (似然正确 + $\theta^* \in \mathcal{M}$)，Bayesian RPETEL 后验收缩分布与标准贝叶斯后验渐近等价，不因引入稳健机制而损失效率。

[正确设定下的 RPETEL 等价性] 在正确模型设定下 (Assumption 5), Bayesian RPETEL 后验与使用同一流形先验的标准贝叶斯后验渐近等价——两者都渐近正态且具有相同的协方差。这确保了在正确设定下稳健性不带来效率损失。

4. RRWM 算法

4.1. 算法构造。 计算上的核心问题是：从 $\Pi_{\text{RP}}(\cdot | X^{(n)})$ 中高效采样。后验分布在流形 $\mathcal{M}$ 上定义，标准随机游走 Metropolis (RWM) 算法无法直接应用——因为在 $\mathbb{R}^D$ 中生成的 proposal 点几乎必然不在 $\mathcal{M}$ 上。

本文提出的 RRWM (Riemannian Random-Walk Metropolis) 算法通过以下三步将 RWM 适配到流形 setting:

- (1) **在切空间中生成 proposal:** 设当前状态为 $\theta^{k-1} \in \mathcal{M}$ 。从 $\mathcal{N}(0, 2\tilde{h}\tilde{I})$ 生成环境向量 $\tilde{v} \in \mathbb{R}^D$ ，然后投影到切空间: $v = \text{Proj}_{T_{\theta^{k-1}}\mathcal{M}}(\tilde{v})$ 。此步骤确保 proposal 方向始终位于切空间中。
- (2) **通过 retraction 映射回流形:** 设 retraction $\phi_\theta : T_\theta\mathcal{M} \rightarrow \mathcal{M}$ 为投影映射 $\psi_\theta(x) = \text{Proj}_{T_\theta\mathcal{M}}(x - \theta)$ 的逆。令候选点 $y = \phi_{\theta^{k-1}}(v)$ 。Retraction 的关键性质是一阶近似: $\|y - \theta^{k-1} - v\| = O(\|v\|^2)$ ，这保证了 proposal 步长的局部一致性。
- (3) **Metropolis-Hastings 接受/拒绝:** 计算接受率

$$(6) \quad A(\theta^{k-1}, y) = 1 \wedge \frac{\mu^*(y) \exp(-v'^\top (P_y \tilde{I} P_y)^\dagger v' / (4\tilde{h}))}{\mu^*(\theta^{k-1}) \exp(-v^\top (P_{\theta^{k-1}} \tilde{I} P_{\theta^{k-1}})^\dagger v / (4\tilde{h}))},$$

其中 $v' = \psi_y(\theta^{k-1})$ ， $\mu^*(\theta) \propto \exp(\sum_i \log p_i(\theta) - \alpha_n \mathcal{R}_n(\theta))$ 为目标密度的未归一化版本。接受概率的计算中出现了 retraction 导数的伪行列式，用于补偿流形弯曲带来的体积变化。

Jacobian 修正因子的显式说明: proposal 密度的比值 $q(\theta^{k-1}, y)/q(y, \theta^{k-1})$ (eq. (6) 中隐含于 $\exp(-v^\top \dots)$ 的比值) 须包含从切空间到流形的体积变化修正。设 $y = \phi_{\theta^{k-1}}(v)$ ，则 $q(\theta^{k-1}, y) d\theta^{k-1} = \phi_{\theta^{k-1}\#}(\mathcal{N}(0, 2\tilde{h}\tilde{I}))(dy)$ 中的拉回密度包含 retraction 导数行列式 $\det(D\phi_{\theta^{k-1}}(0))$ 的倒数。原文 (? , Algorithm 1) 中通过比较 backward proposal (从切空间到流形) 与 forward proposal (从流形到切空间) 的密度，将 Jacobian 修正显式化为 retraction 导数的伪行列式比值，这就是 eq. (6) 中 v 与 v' 方向所对应的不同协方差矩阵的来源。

Retraction 的选取对算法的接受率有显著影响。当使用投影映射的逆 ϕ_θ 作为 retraction 时，伪行列式项退化为常数，接受率简化为只包含 proposal 高斯密度的比值，这大大简化了计算实现。对一般流形 (如 Stiefel、Grassmannian)，投影映射的逆可以通过 Newton-Raphson 方法或黎曼梯度下降法数值求解。

4.2. 混合时间分析. RRWM 算法的核心计算保证是其混合时间仅依赖流形内在维度 d ，而非环境维度 D 。

设 s -lazy 版本的 RRWM (每步以概率 $1-s$ 保持当前状态), 在 M_0 -warm start 下 (初始分布与目标分布的 χ^2 距离有界于 M_0), 定义 ε -混合时间 $\tau_{\text{mix}}(\varepsilon, \mu_0) = \inf\{k : \sqrt{\chi^2(\mu_k, \mu^*)} \leq \varepsilon\}$, 其中 μ_k 为第 k 步的链分布。

[RRWM 混合时间] 在 section 3.2 的正则性条件下, 设 n 足够大, 步长参数 $\tilde{h} = h/n$, 其中 $h = c_0 \rho_2^{-1} (d + \log(M_0 d \rho_2 / (\varepsilon \rho_1)))^{-1}$, ρ_1, ρ_2 为条件数相关的常数。则对任意 $\varepsilon \geq M_0/n^c$, 有

$$(7) \quad \tau_{\text{mix}}(\varepsilon, \mu_0) \leq \frac{C_1}{\zeta} \left\{ \left[\kappa \left(d + \log \frac{M_0 d \kappa}{\varepsilon} \right) \log \frac{\log M_0}{\varepsilon} \right] \vee \log M_0 \right\}, \quad \kappa = \frac{\rho_2}{\rho_1}.$$

eq. (7) 的核心含义是: RRWM 的 ε -混合时间关于 d 是线性的, 且不包含对 D 的任何依赖。在 M_0 为常数、 ε 固定的情况下, 主导项的维度依赖为 $O(d \log d)$ ——这与欧氏空间 RWM 的 $O(D \log D)$ 形成鲜明对比。这一改进来源于流形的几何结构: 在高维环境空间 $\mathbb{R}^D$ 中, 切空间只有 d 个有效自由度。

条件数的角色: 当预条件矩阵 $\tilde{I}$ 满足 $P_{\theta^*} \tilde{I} P_{\theta^*} \approx \mathcal{H}_{\theta^*}^\dagger \Delta_{\theta^*} \mathcal{H}_{\theta^*}$ 时, 条件数 $\kappa \approx 1$, 混合时间最优。论文建议两种自适应选择 $\tilde{I}$ 的方法: (1) 直接估计 $\mathcal{H}_{\theta^*}$ 和 Δ_{θ^*} ; (2) 利用后验样本的协方差迭代更新 $\tilde{I}$ 。

5. 数值实验

5.1. 多元分位数回归. 本文在三个问题上验证了 Bayesian RPETEL 的有效性。第一个实验考虑多元分位数回归中的共同斜率约束问题。设 J 个分位数水平 $(\tau_1, \dots, \tau_J)$, 参数 (u, β) 受约束 $\beta_1 = \dots = \beta_J$, 即所有分位数共享相同的斜率向量。这一约束将参数空间限制为 $\mathcal{M}$ (一个线性子空间)。数据来自 $Y_i = X_i + \varepsilon_i(1 + \epsilon X_i)$, 其中 $X_i \sim \mathcal{N}(0, 1)$, $\varepsilon_i \sim \text{Laplace}(0, 1)$ 。 $\epsilon = 0$ 对应正确设定, $\epsilon = 0.1$ 对应误设定。

实验结果显示 (1000 次重复): 在正确设定下, Bayesian RPETEL 与全梯度 PETEL (BPETELM) 的 MSE 基本相同, 且均优于欧氏 PETEL (BPETELE)。在误设定下, Bayesian RPETEL 的 95 而 BPETELM 在某些坐标上仅为 87.7%——Bayesian RPETEL 在保持效率的同时实现了更好的稳健性。

在计算效率方面, RRWM 算法的有效样本量 (ESS) 约为 700, 远高于欧氏 RWM 的约 280——比例接近 $D/d = 6/3 = 2$, 与理论预测 (ESS 反比于维度) 吻合。

5.2. 扩散张量均值推断. 第三个实验分析真实扩散张量成像 (DTI) 数据, 来自 Gordon Kindlmann 的大脑扫描。数据点为 3×3 对称正定协方差矩阵 (扩散张量), 参数空间为 $\mathbb{S}_+^3$ (6 维流形)。关注三个具有科学意义的功能量: 分数各向异性 (FA)、迹 (trace) 和最大特征值。

通过子采样 (每次从原始数据中有放回抽取 $n = 1000$ 个样本, 重复 1000 次) 评估频率学覆盖性质: Bayesian RPETEL 的 95 均接近 94% (目标 95%), 而 Wishart 参数化方法在迹上仅达 59.2%——后者严重低估了推断精度。这一对比有力地验证了 Bayesian RPETEL 在真实数据分析中的稳健优势。

6. 本章小结

本章系统整理了 (?) 的核心内容与理论贡献。

- (1) **流形 BvM 定理** (section 3): eq. (2) 建立了后验分布在切空间投影上的渐近正态性, 突破了奇异性带来的分析障碍; 协方差矩阵中的 Moore-Penrose 逆 $\mathcal{H}_{\theta^*}^\dagger$ 自动处理了流形约束。

- (2) **RPETEL 三重稳健性** (section 3.2): eq. (5) 中的夹心协方差结构 $\mathcal{H}_{\theta^*}^\dagger \Delta_{\theta^*} \mathcal{H}_{\theta^*}^\dagger$ 确保后验协方差与采样分布协方差一致, 从而同时实现似然稳健性、风险稳健性和先验稳健性。
- (3) **RRWM 算法** (section 4): 切空间 proposal + retraction 的组合设计实现了流形上的 Metropolis 采样; eq. (7) 证明其混合时间仅依赖 d 而非 D , 在高维流形问题中具有显著计算优势。

本章方法存在以下局限性: (1) 正则性假设较强——流形局部 C^3 光滑且风险函数二次增长; (2) BvM 定理的收敛速度 (到渐近正态的速率) 在论文中未给出显式下界; (3) RRWM 的 proposal 设计相对简单, 在强非线性流形或多峰后验上可能表现不佳。这些局限性也为后续研究留下了空间——(?) 即在欧氏空间中证明了 MALA 的最优 $O(d^{1/3})$ 混合时间, 流形上的最优 MCMC 设计仍是开放问题。