

分布回归的极小极大速率

1. 引言

分布回归 (distribution regression) 的目标是：给定协变量 $X \in \mathbb{R}^{D_X}$ ，估计响应变量 $Y \in \mathbb{R}^{D_Y}$ 的条件分布 $\mu_{Y|X=x}^*$ 。与传统的标量回归或分类不同，分布回归恢复的是完整的条件分布，从而可以刻画条件变异性、偏度、多峰性和不确定性等丰富信息，在生物医学、气候建模和计量经济学中有广泛应用。

传统非参数密度回归方法存在两个根本性局限：

- (1) **存在性假设**：要求 $\mu_{Y|X=x}^*$ 关于 Lebesgue 测度绝对连续——当 Y 含离散分量或支撑于高维空间中的低维流形时，该假设失效。
- (2) **维度灾难**：环境维度 D_X, D_Y 主导收敛速率，对现代高维数据（图像、文本、点云）效率极低。

本文 (?) 的核心贡献在于放弃 $\mu_{Y|X=x}^*$ 须有密度的假设，转而假设 $\mu_{Y|X=x}^*$ 支撑于某个低维流形 $\mathcal{M}_{Y|x}$ 上，从而同时处理奇异分布（流形支撑）和密度函数（光滑条件密度）两类信息。

与条件密度估计的关系：传统条件密度估计 (conditional density estimation) 假设 $\mu_{Y|X=x}^*$ 有密度 $u^*(y|x)$ ，关注光滑性假设下 $n^{-1/2}$ 到 n^{-1} 之间的收敛速率 (??)。本文则将问题推广到：

- $\mu_{Y|X=x}^*$ 可无密度（流形支撑），须用 IPM 度量；
- 收敛速率仅依赖内在维度 d_X, d_Y 而非环境维度 D_X, D_Y ；
- γ -Hölder IPM 统一了全变差 ($\gamma = 0$) 和 Wasserstein ($\gamma = 1$) 距离。

γ -Hölder IPM 的统一作用：给定光滑度参数 $\gamma \geq 0$ ， γ -Hölder IPM 定义为

$$(1) \quad d_\gamma(\mu, \nu) = \sup_{f \in \mathcal{H}_1^\gamma(\mathbb{R}^{D_Y})} \left| \int f(y) d\mu - \int f(y) d\nu \right|,$$

其中 $\mathcal{H}_1^\gamma(\mathbb{R}^{D_Y})$ 为单位半径的 γ -Hölder 函数类。特别地：

- $\gamma = 0$ ： d_0 退化为全变差距离 d_{TV} ；
- $\gamma = 1$ ： d_1 等价于 1-Wasserstein 距离 W_1 (Kantorovich-Rubinstein 定理)。

参数 γ 调控度量对局部细节的敏感度： γ 越大，测试函数越光滑，越能忽略局部起伏（如支撑不完全对齐）； γ 越小， d_γ 对密度局部变化越敏感。

2. 数学框架

2.1. 基本设定. 设

- 协变量 $X \sim \mu_X^*$ ，支撑于 $\mathbb{R}^{D_X}$ 中的 d_X 维子流形 $\mathcal{M}_X$ ；
- 给定 $X = x$ ，响应 $Y \sim \mu_{Y|X=x}^*$ ，支撑于 $\mathbb{R}^{D_Y}$ 中的 d_Y 维 β_Y -光滑子流形 $\mathcal{M}_{Y|x}$ ；
- 数据 $\{(X_i, Y_i)\}_{i=1}^n$ 为来自 $\mu^* = \mu_X^* \mu_{Y|X}^*$ 的 n 个 i.i.d. 样本。

定义 1.1 (协变量空间的 Minkowski 维数). 称拓扑空间 $\mathcal{M}_X \subset \mathbb{R}^{D_X}$ 的 *Minkowski* 维数至多为 d_X (记 $\mathcal{M}_X \in \mathcal{M}_X(D_X, d_X, L)$), 若 $\mathcal{M}_X \subset \mathbb{B}_{\mathbb{R}^{D_X}}(\mathbf{0}, L)$, 且对任意 $0 < \varepsilon \leq 1$, $\mathcal{M}_X$ 的最大 ε -packing 基数至多为 $L\varepsilon^{-d_X}$.

该定义比子流形假设更宽松——不要求 $\mathcal{M}_X$ 光滑或有正 reach。

定义 1.2 (边缘光滑函数类). 称二元函数 $u^*: \mathcal{M}_Y \times \mathcal{M}_X \rightarrow \mathbb{R}_+$ 属于 **边缘光滑函数类** $\overline{\mathcal{H}}_L^{\alpha_Y, \alpha_X}(\mathcal{M}_Y, \mathcal{M}_X)$, 若

- (1) 对任意 $y \in \mathcal{M}_Y$, $u^*(\cdot|y) \in \mathcal{H}_L^{\alpha_Y}(\mathcal{M}_Y)$ (关于 y 为 α_Y -光滑);
- (2) 对任意 $x \in \mathcal{M}_X$, $u^*(\cdot|x) \in \mathcal{H}_L^{\alpha_X}(\mathcal{M}_X)$ (关于 x 为 α_X -光滑)。

此定义刻画了条件密度在不同方向上具有独立光滑度的情形。

评估条件分布估计量 $\hat{\mu}_{Y|X}$ 的整体质量采用 **期望 γ -Hölder IPM**:

$$(2) \quad \mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|X}^*, \hat{\mu}_{Y|X})] = \int_{\mathcal{M}_X} d_\gamma(\mu_{Y|X=x}^*, \hat{\mu}_{Y|X=x}) d\mu_X^*(x).$$

3. Regime 1: 经典密度回归

本节考虑最简设定: 响应空间无流形结构, 即 $\mathcal{M}_{Y|x} = \mathbb{R}^{D_Y}$, $\mu_{Y|x}^*$ 对 Lebesgue 测度绝对连续。此为经典密度回归设定, 与条件密度估计直接对应。

定义 1.3 (Regime 1: 欧氏响应空间). 给定维度 $D_Y, D_X \in \mathbb{N}_+$, $d_X \in \mathbb{N} \cap [0, D_X]$ 、光滑度参数 $\alpha_Y, \alpha_X \in (0, \infty)$ 和常数 $L > 0$, 定义分布族

$$\mathcal{P}_1^* = \mathcal{P}_1^*(D_Y, D_X, d_X, \alpha_Y, \alpha_X, L)$$

为满足以下条件的联合分布 $\mu^* = \mu_X^* \mu_{Y|X}^*$ 构成的集合:

- (1) μ_X^* 的支撑 $\mathcal{M}_X \in \mathcal{M}_X(D_X, d_X, L)$, μ_Y^* 的支撑含于 $\mathbb{B}_{\mathbb{R}^{D_Y}}(\mathbf{0}, L)$;
- (2) 对任意 $x \in \mathcal{M}_X$, $\mu_{Y|x}^*$ 有密度函数 $u^*(\cdot|x)$, 且 $u^*(y|x) \in \overline{\mathcal{H}}_L^{\alpha_Y, \alpha_X}(\mathbb{R}^{D_Y}, \mathcal{M}_X)$ 。

注 1.1. $d_X = 0$ 对应 X 为离散变量 (取有限个值), 此时 α_X 的光滑性条件自动满足, 极小极大速率简化为 $n^{-(\alpha_Y + \gamma)/(2\alpha_Y + D_Y)}$, 即 (?) 的无条件密度估计结果。

3.1. 极小极大速率.

定理 1.1 (Regime 1 的极小极大速率(?)). 对任意 $\gamma \geq 0$, 存在常数 L_0 , 使得当 $L, n \geq L_0$ 时,

$$(3) \quad \begin{aligned} & C \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + D_Y + \frac{\alpha_Y}{\alpha_X} d_X}} \right) \\ & \leq \inf_{\hat{\mu}_{Y|X}} \sup_{\mu^* \in \mathcal{P}_1^*} \mathbb{E}_{\mu^*, \otimes n} [\mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|X}^*, \hat{\mu}_{Y|X})]] \\ & \leq C_1 \tilde{\mathcal{O}} \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + D_Y + \frac{\alpha_Y}{\alpha_X} d_X}} \right), \end{aligned}$$

其中 C, C_1 为与 n 无关的常数, $\tilde{\mathcal{O}}$ 忽略对数因子。

速率的两项意义:

- (1) **第一项** $n^{-\alpha_X/(2\alpha_X + d_X)}$: 对应 α_X -光滑条件均值函数在 L_2 损失下的经典极小极大速率(?). γ 越大, 该项越可能主导——因为光滑测试函数抹平了条件密度的局部起伏, d_γ 主要响应 X 与 Y 之间的全局依赖趋势。

- (2) **第二项** $n^{-(\alpha_Y+\gamma)/(2\alpha_Y+D_Y+\alpha_Y d_X/\alpha_X)}$: 反映非参数条件密度估计的固有难度。 α_Y 越大 (密度越光滑) 或 d_X, D_Y 越小, 速率越快; γ 越大, d_Y 对局部细节越不敏感, 密度估计难度降低。

与已有文献的关系: (?) 的结果改进了 (?) 的上界 (在 $\gamma = 0$ 时给出更紧的全变差速率) 并拓展了 (?) 的结果 (仅覆盖 $\alpha_X \in [0, 1]$); (?) 中条件扩散模型的收敛速率在 $\gamma = 1$ 时与本定理上界匹配, 结合下界可知条件扩散模型在期望 1-Wasserstein 距离下是极小极大最优的。

4. Regime 2: 响应空间为协变量无关流形

本节将设定推广到 Y 支撑于低维流形上的情形, 但假设 $\mathcal{M}_{Y|x} = \mathcal{M}_Y$ 不依赖于 x ——此时问题从密度回归变为分布回归, 且须同时估计未知流形 $\mathcal{M}_Y$ 。

流形上的密度函数须关于流形体积测度而非 Lebesgue 测度定义, 这使得经典的核密度估计不再适用。

定义 1.4 (Regime 2: 协变量无关的流形响应空间). 给定维度参数 $D_Y, d_Y, D_X \in \mathbb{N}_+$, $d_X \in \mathbb{N}_0$ 、光滑度 $\beta_Y, \alpha_Y, \alpha_X > 0$ 、函数 $g: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ 和常数 $\tau, \tau_1, L > 0$, 定义分布族

$$\mathcal{P}_2^* = \mathcal{P}_2^*(D_Y, D_X, d_Y, d_X, \beta_Y, \alpha_Y, \alpha_X, \tau, \tau_1, g, L)$$

为满足以下条件的 $\mu^* = \mu_X^* \mu_{Y|x}^*$ 构成的集合:

- (1) $\mathcal{M}_X \in \mathcal{M}_X(D_X, d_X, L)$;
- (2) 对任意 $x \in \mathcal{M}_X$, $\mu_{Y|x}^*$ 支撑于与 x 无关的子流形 $\mathcal{M}_Y$ 上, 且有相对于 $\mathcal{M}_Y$ 体积测度的密度函数 $u^*(\cdot|x)$, 其中 $\mathcal{M}_Y \in \mathcal{M}_{\tau, \tau_1, L}^{\beta_Y}(d_Y, D_Y)$ (d_Y 维、 β_Y -光滑子流形), $u^* \in \overline{\mathcal{H}}_L^{\alpha_Y, \alpha_X}(\mathcal{M}_Y, \mathcal{M}_X)$;
- (3) 下界条件: 对任意 $x_0 \in \mathcal{M}_X, y_0 \in \mathcal{M}_Y$ 和 $0 < r \leq 1$, $\mu_X^*(\mathbb{B}_{\mathcal{M}_X}(x_0, r)) \geq g(r)r^{d_X}/L$ 且 $\mu_{Y|x_0}^*(\mathbb{B}_{\mathcal{M}_Y}(y_0, r)) \geq g(r)r^{d_Y}/L$ 。

条件 $\beta_Y \geq 2$ 保证 $\mathcal{M}_Y$ 曲率有界; $\beta_Y \geq \alpha_Y + 1$ 保证 α_Y 光滑性与局部坐标卡的选择无关。

注 1.2. 在 *Regime 2* 中, 由于 $\hat{\mu}_{Y|x}$ 与 $\mu_{Y|x}^*$ 几乎必然相互奇异 (支撑在不同流形上), 全变差距离恒为 1, 无法反映估计质量——因此 *Regime 2* 须要求 $\gamma > 0$ (即使用非平凡光滑测试函数)。这凸显了 *IPM* 框架比全变差距离更适用于流形支撑数据的重要性。

4.1. 极小极大速率.

定理 1.2 (Regime 2 的极小极大速率 (?)). 对任意 $\gamma > 0$ 和 $\beta_Y \geq 2 \vee (\alpha_Y + 1)$, 存在常数 L_0 , 使得当 $L, \tau, \tau_1, n \geq L_0$ 时,

$$\begin{aligned}
 & C \left(n^{-\frac{\alpha_X}{2\alpha_X+d_X}} + n^{-\frac{\alpha_Y+\gamma}{2\alpha_Y+d_Y+\frac{\alpha_Y}{\alpha_X}d_X}} + n^{-\frac{\gamma\beta_Y}{d_Y}} \right) \\
 (4) \quad & \leq \inf_{\hat{\mu}_{Y|x}} \sup_{\mu^* \in \mathcal{P}_2^*} \mathbb{E}_{\mu^*, \otimes n} [\mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|x}^*, \hat{\mu}_{Y|x})]] \\
 & \leq C_1 (\log n)^3 \tilde{\mathcal{O}} \left(n^{-\frac{\alpha_X}{2\alpha_X+d_X}} + n^{-\frac{\alpha_Y+\gamma}{2\alpha_Y+d_Y+\frac{\alpha_Y}{\alpha_X}d_X}} + n^{-\frac{\gamma\beta_Y}{d_Y}} \right).
 \end{aligned}$$

与 Regime 1 的对比: Regime 2 的速率多了第三项 $n^{-\gamma\beta_Y/d_Y}$, 反映了对未知流形 $\mathcal{M}_Y$ 进行支撑估计的固有难度。当 γ 较小 (d_Y 对支撑几何敏感) 时, 该项主导误差——这正是 d_Y 度量奇异分布的独特之处。

关键现象—— γ 决定三项竞争：随着 γ 从 0 增大，Regime 2 的主导误差项经历两次相变：

- **第一次相变** (γ 较小)： d_γ 对支撑错位敏感，主导项为流形估计项 $n^{-\gamma\beta_Y/d_Y} \iff$ 条件密度估计项 $n^{-(\alpha_Y+\gamma)/(2\alpha_Y+d_Y+\alpha_Y d_X/\alpha_X)}$ ；
- **第二次相变** (γ 较大)： d_γ 进一步光滑化，主导项变为 $n^{-\alpha_X/(2\alpha_X+d_X)}$ ——此时问题退化为 α_X -光滑条件均值估计。

注 1.3. 关键发现： D_Y 完全不出现在 *Regime 2* 的速率指数中。仅 d_Y (流形本征维度)、 β_Y (流形光滑度) 和内在几何参数决定收敛速率。这正是内在维度 *vs* 环境维度的核心体现——流形结构将高维环境空间中的估计问题”降维”为低维本征空间中的问题。

5. Regime 3: 协变量依赖流形

本节研究最一般设定：响应流形 $\mathcal{M}_{Y|x}$ 随 x 光滑变化——这将问题从单一流形估计推广为流形回归。

5.1. 协变量依赖流形的形式定义.

定义 1.5 ((β_Y, β_X) -光滑子流形族). 称 $\{\mathcal{M}_{Y|x} : x \in \mathcal{M}_X\}$ 为 (β_Y, β_X) -光滑的 d_Y 维子流形族，若存在常数 $\tau, \tau_1, L > 0$ 使得：对每个 $x \in \mathcal{M}_X$ ， $\mathcal{M}_{Y|x} \in \mathcal{M}_{\tau, \tau_1, L}^{\beta_Y}(d_Y, D_Y)$ ，且对任意 $x, x' \in \mathcal{M}_X$ ，

$$\mathbb{H}(\mathcal{M}_{Y|x}, \mathcal{M}_{Y|x'}) \leq L \|x - x'\|^{\beta_X/\beta_Y},$$

其中 $\mathbb{H}$ 为 *Hausdorff* 距离。

直观例子：考虑人脸图像数据 Y 以年龄和性别 X 为条件的情形。对固定的 X ， Y 的支撑自然位于某低维图像子流形；而不同年龄段对应的流形差异较大，这正构成协变量依赖流形族。

5.2. Regime 3a: 纯流形回归. 为建立 Regime 3b 的下界，先研究纯流形回归问题——仅估计 $\{\mathcal{M}_{Y|x}\}$ 而不计密度。

定理 1.3 (流形回归的极小极大速率). 假设 $\beta_Y \geq 2$ 和 $\beta_Y \geq \beta_X$ ，则存在常数 L_0 ，使得当 $L, \tau, \tau_1, n \geq L_0$ 时，

$$(5) \quad C n^{-\frac{1}{\frac{d_Y}{\beta_Y} + \frac{d_X}{\beta_X}}} \leq \inf_{\{\widehat{\mathcal{M}}_{Y|x}\}} \sup_{\mu^* \in \mathcal{P}^*} \mathbb{E}_{\mu^*, \otimes n} \left[\sup_{x \in \mathcal{M}_X} \mathbb{H}(\mathcal{M}_{Y|x}, \widehat{\mathcal{M}}_{Y|x}) \right] \leq C_1 \left(\frac{n}{\log n} \right)^{-\frac{1}{\frac{d_Y}{\beta_Y} + \frac{d_X}{\beta_X}}}.$$

与单一流形估计的极小极速率 $n^{-1/(d_Y/\beta_Y)}$ (?) 相比，流形回归多了 d_X/β_X 项，反映了估计整个流形族的额外复杂度。 β_X 越大 ($\mathcal{M}_{Y|x}$ 随 x 变化越慢)，分母越大，速率越快——这与直觉一致。

估计策略¹：

¹详见 (?, Section 4.1). 推广了 (?) 的局部多项式估计量，对每个数据点 $w_k = (X_k, Y_k)$ ，选取满足 $\|Y - Y_k\| \leq h_1$ 和 $\|X - X_k\| \leq h_2$ 的邻域样本，其中 $h_1 \asymp (\log n/n)^{\frac{\beta_X}{d_Y \beta_X + d_X \beta_Y}}$ 、 $h_2 \asymp (\log n/n)^{\frac{\beta_Y}{d_Y \beta_X + d_X \beta_Y}}$ ，然后通过最小化重建损失学习局部多项式估计量。

5.3. Regime 3b: 协变量依赖流形上的分布回归. 现在回到完整的分布回归问题, 但此时 $\mathcal{M}_{Y|x}$ 依赖 x 。

定理 1.4 (Regime 3b 的极小极大速率). 对任意 $\gamma > 0$, 若 $\beta_Y \geq 2 \vee (\alpha_Y + 1) \vee \beta_X$, $\beta_X \geq \alpha_X + \frac{\alpha_X}{\alpha_Y}$ 且 $\alpha_Y \geq \alpha_X$, 则存在常数 L_0 , 使得当 $L, \tau, \tau_1, n \geq L_0$ 时,

$$(6) \quad \begin{aligned} & C \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + d_Y + \frac{\alpha_Y}{\alpha_X} d_X}} + n^{-\frac{\gamma}{\frac{d_Y}{\beta_Y} + \frac{d_X}{\beta_X}}} \right) \\ & \leq \inf_{\hat{\mu}_{Y|x}} \sup_{\mu^* \in \mathcal{P}_3^*} \mathbb{E}_{\mu^*, \otimes n} [\mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|x}^*, \hat{\mu}_{Y|x})]] \\ & \leq C_1 \tilde{\mathcal{O}} \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + d_Y + \frac{\alpha_Y}{\alpha_X} d_X}} + n^{-\frac{\gamma}{\frac{d_Y}{\beta_Y} + \frac{d_X}{\beta_X}}} \right). \end{aligned}$$

与 Regime 2 的关键区别: Regime 3b 的第三项为 $n^{-\gamma/(d_Y/\beta_Y + d_X/\beta_X)}$, 而非 Regime 2 中的 $n^{-\gamma\beta_Y/d_Y}$ 。这一替换将单一流形估计的复杂度 d_Y/β_Y 推广为流形回归的复杂度 $d_Y/\beta_Y + d_X/\beta_X$ ——几何参数 $d_Y, \beta_Y, d_X, \beta_X$ 共同决定收敛速率。

几何参数的物理意义:

- d_Y 越小: 响应流形本征维度越低, 估计越容易;
- β_Y 越大: $\mathcal{M}_{Y|x}$ 越光滑, 其几何特征越规则, 支撑估计越容易;
- d_X 越小: 协变量空间复杂度越低;
- β_X 越大: $\mathcal{M}_{Y|x}$ 随 x 变化越慢, 允许跨 x 值的信息共享更充分。

注 1.4. 三个 Regime 的极小极大速率可统一理解为三项的取大:

- (1) $n^{-\alpha_X/(2\alpha_X + d_X)}$: 协变量效应;
- (2) $n^{-(\alpha_Y + \gamma)/(2\alpha_Y + d_Y + \alpha_Y d_X/\alpha_X)}$: 密度效应;
- (3) 流形支撑效应 (Regime 依赖): $\text{Regime 2} \rightarrow n^{-\gamma\beta_Y/d_Y}$, $\text{Regime 3b} \rightarrow n^{-\gamma/(d_Y/\beta_Y + d_X/\beta_X)}$ 。

当 γ 足够大时, 前两项之一主导; 当 γ 较小时, 支撑估计项主导——这正是 d_γ 度量奇异分布的核心挑战。

6. 极小极大最优估计量

本文不仅建立了极小极大下界, 还提出了融合对抗学习 (adversarial learning) 与同步最小二乘的 **混合估计量**, 在各 Regime 下均达上界 (至多对数因子)。

6.1. Euclid 响应空间的估计量 (Regime 1). 估计量基于小波展开和局部多项式回归。对条件密度 $u^*(y|x)$ 在 y 方向做小波分解, 在 x 方向做局部多项式逼近。

核心思想: 对每个小波基 $\psi \in \Psi_j^{D_Y}$ 在尺度 j , 估计条件期望 $\mathbb{E}_{\mu_{Y|x}^*}[\psi(Y)]$ ——这本身是一个非参数回归问题, 但 $u^*(\cdot|x)$ 的 α_X -光滑性允许用局部多项式有效逼近。

构造条件密度估计量:

$$(7) \quad \hat{u}(y|x) = \sum_{j=0}^J \sum_{\psi \in \Psi_j^{D_Y}} \hat{u}_\psi(x) \psi(y), \quad x \in \mathcal{M}_X,$$

其中 $\hat{u}_\psi(x)$ 通过局部多项式回归获得。截断水平 J 的选择:

$$(8) \quad J \asymp \frac{1}{2\alpha_Y + D_Y + d_X \frac{\alpha_Y}{\alpha_X}} \log_2 \left(\frac{n}{\log n} \right).$$

定理 1.5 (Regime 1 估计量的收敛速率). 在 $\mathcal{P}_1^*$ 假设下, 对任意 $\gamma \geq 0$, eq. (7) 定义的条件密度估计量满足

$$(9) \quad \mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|X}^*, \hat{\mu}_{Y|X})] \leq C_\gamma \tilde{O} \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + D_Y + \frac{\alpha_Y}{\alpha_X} d_X}} \right),$$

以至至少 $1 - n^{-1}$ 的概率成立。速率与 eq. (3) 上界匹配, 故为极小极大最优。

与扩散模型的深层联系²:

6.2. 流形响应空间的估计量 (Regime 2 和 3b). 当 $\mathcal{M}_{Y|x}$ 为流形时, 条件密度关于 Lebesgue 测度不存在, 须将问题重新表述为对条件期望泛函

$$\mathcal{T}^*(f, x) = \mathbb{E}_{\mu_{Y|x}^*} [f(Y)], \quad f \in \mathcal{H}_1^\gamma(\mathbb{R}^{D_Y})$$

的同步估计。

两步走策略:

步骤 1 (粗糙尺度): 将小波函数截断到 J 层, 估计 $\mathbb{E}_{\mu_{Y|x}^*} [f_J(Y)]$, 其中 f_J 为 f 的粗糙 (小波) 逼近。由于 f_J 变化缓慢, 可将 $\mu_{Y|x}^*$ 视为有密度, 使用局部多项式回归构造条件密度估计量。

关键改进: 对每个 j 水平, 同时估计所有小波系数的条件期望, 构建**联合均值回归问题**:

$$(10) \quad \hat{S}_j^\dagger = \arg \min_{S \in \mathcal{S}_j^\dagger} \frac{1}{n} \sum_{i=1}^n \sum_{\psi \in \Psi_j^{D_Y}} \left(2^{\frac{j(d_Y - D_Y)}{2}} \psi(Y_i) - S(\psi, X_i) \right)^2,$$

其中 $\mathcal{S}_j^\dagger$ 为特定的非可分逼近族。与分别独立估计每个小波系数不同, 联合估计利用了流形结构固有的稀疏性——只有部分小波函数在 $\mathcal{M}_{Y|x}$ 上有非零条件均值。

引理 1.1 (联合 vs 独立估计的最优性). 在 *Regime 2* 中, 令 $\hat{u}_j(x)$ 为独立估计得到的各尺度条件密度, $\hat{u}_j^\dagger(x)$ 为联合估计得到的条件密度。则

$$\mathbb{E} \left[|\hat{u}_j^\dagger(x) - u^*(y|x)|^2 \right] \leq \mathbb{E} \left[|\hat{u}_j(x) - u^*(y|x)|^2 \right] \quad (\text{至多差常数因子}),$$

且在某些构造下严格更优。详见 (? , Appendix B.2.3)。

步骤 2 (精细尺度): 对 $f_J^\perp$, 采用显式流形估计步骤。学习编码器 $Q: \mathbb{R}^{D_Y} \rightarrow \mathbb{R}^{d_Y}$ 和条件解码器 $G: \mathbb{R}^{d_Y} \times \mathbb{R}^{D_X} \rightarrow \mathbb{R}^{D_Y}$, 使得 $y \approx G(Q(y), x)$ 在局部成立。将数据映射到潜在空间 $\mathbb{R}^{d_Y}$, 在其中进行密度回归。

注 1.5. 这种编码器-解码器框架正是潜扩散模型 (*latent diffusion models*) (?), 变分自编码器 (VAE) (?) 和 Wasserstein 自编码器 (?) 的理论基础——本文从统计估计的角度严格证明了该框架的理论最优性。

7. 技术要点

本节详细介绍极小极大下界和上界证明的核心技术工具。

²详见 (? , Section 3.3)。多分辨率小波分析与分数阶前向-后向扩散模型之间存在深刻类比: 小波分解中不同尺度 j 捕获从全局趋势到局部细节的层次结构, 正好对应扩散模型中时间变量 t 从 0 到 T 的演化过程。条件扩散模型的每步去噪可视为在某分辨率水平上的条件均值估计。

7.1. Fano 不等式与 Varshamov-Gilbert 引理. 极小极大下界证明的第一步是将估计问题规约到多假设检验问题。设 $\mathcal{Q}$ 为一族难以区分的分布（或流形-密度对），则估计误差的下界由区分这些分布所需的最小信息量决定。

Fano 不等式³:

引理 1.2 (广义 Fano 不等式). 设 $\mathcal{P} = \{P_0, P_1, \dots, P_M\}$ 为 $M+1$ 个概率分布，任意两个分布 P_j, P_k 之间的 Hellinger 距离满足 $H(P_j, P_k) \leq \epsilon$ ，且 P_0 为参考分布。记 $\Phi: \mathcal{P} \rightarrow \{0, 1, \dots, M\}$ 为任意检验函数。则

$$\inf_{\Phi} \max_{j \in \{0, 1, \dots, M\}} P_j(\Phi(X) \neq j) \geq \frac{1}{2} \left(1 - \frac{I(X; J) + \epsilon^2}{\log(M+1)} \right),$$

其中 $I(X; J)$ 为 X 与指标 J 之间的互信息。

Varshamov-Gilbert 引理（用于构造难以区分的假设序列）:

引理 1.3 (Varshamov-Gilbert 引理). 设 $\mathcal{M}$ 为紧致 d 维黎曼子流形，半径为 s 的球的最大 packing 基数为 $N \asymp (C/s)^d$ 。存在 $\{0, 1\}^m$ 上的 Hamming 子集 $\mathcal{V}$ （即“错误模式”集合），满足 $|\mathcal{V}| \geq 2^m$ 且 $\rho(v, w) \geq m/10$ 对任意 $v \neq w \in \mathcal{V}$ ，其中 ρ 为 Hamming 距离。将 $\mathcal{V}$ 的每个顶点映射到 $\mathcal{M}$ 上适当分离的点，得到 $N \asymp 2^m$ 个相互之间距离至少为 δ 的分布。

注 1.6 在 Regime 2 的下界证明中，通过 Varshamov-Gilbert 引理在 d_Y 维流形上构造 $N \asymp \exp(cn\epsilon^2)$ 个难以区分的备择分布。具体地：设 $m \asymp n\epsilon^2$ ，则 packings 的尺度为 $s \asymp n^{-1/(2m)}$ ，利用流形的覆盖数性质可得所需下界。

注 1.6. Varshamov-Gilbert 引理的几何意义是：在 d 维流形上，以分辨率 δ 进行离散化，可以构造 $\asymp \delta^{-d}$ 个相互可区分的“模式” (mode)。当 n 个样本不足以区分如此多的模式时，任何估计量的误差必然至少为 δ ——这正是极小极大下界的来源。

将 Fano 不等式与 Varshamov-Gilbert 引理结合的标准流程为：(1) 在参数空间（流形 + 密度函数）中构造一组合法的分布 $\{P_v : v \in \mathcal{V}\}$ ；(2) 证明任意两个分布之间的 KL 散度或 Hellinger 距离受限于 $O(\epsilon^2/n)$ ；(3) 应用 Fano 不等式得到检验误差下界；(4) 通过 Le Cam 引理将检验下界转化为估计下界。

7.2. 热核平滑. 在 Regime 2 和 Regime 3 的上界证明中，热核平滑是连接流形几何与概率度量的核心技术。

热核的定义: 设 $\mathcal{M}$ 为紧致黎曼流形，其热核 (heat kernel) $p_t(x, y)$ 为热方程 $\frac{\partial}{\partial t} p_t(x, y) = \Delta_{\mathcal{M}} p_t(x, y)$ 的基本解，其中 $\Delta_{\mathcal{M}}$ 为拉普拉斯-贝尔特拉米算子。热核满足以下基本性质：

- (1) $\int_{\mathcal{M}} p_t(x, y) dy = 1$ (守恒性)；
- (2) $p_t(x, y) \asymp t^{-d/2} \exp(-C \|x - y\|^2/t)$ (短时间近似)；
- (3) $\|p_t(\cdot, x) - p_t(\cdot, y)\|_{TV} \asymp \|x - y\|/\sqrt{t}$ (Li-Yau 不等式)。

热核平滑的核心思想: 给定流形 $\mathcal{M}$ 上的原始分布 μ^* ，定义其热核平滑版本

$$\mu_t^*(\cdot) = \int_{\mathcal{M}} p_t(\cdot, y) d\mu^*(y).$$

热核平滑的作用是将奇异分布（流形支撑）转化为关于 Lebesgue 测度绝对连续的分布，从而允许使用标准的密度估计技术。

³详见 (?) 引理 7 (Generalized Fano)。

引理 1.4 (热核平滑的逼近误差). 设 μ^* 支撑于 β -光滑子流形 $\mathcal{M}$ 上, d_Y 维, 截面曲率有界. 对任意 $\gamma \in [0, \beta]$ 和光滑测试函数 $f \in \mathcal{H}_1^\gamma$,

$$\left| \int f(y) d\mu^*(y) - \int f(y) d\mu_t^*(y) \right| \leq C \|f\|_{\mathcal{H}^\gamma} t^{\gamma/\beta}.$$

注 1.7 的含义是: 热核平滑后的分布与原始分布之间的 IPM 距离以 $t^{\gamma/\beta}$ 为界. 特别地, 当 $t \asymp n^{-\gamma\beta/d_Y}$ 时, 平滑误差与样本误差量级相同——这正是 Regime 2 第三项 $n^{-\gamma\beta_Y/d_Y}$ 的来源.

注 1.7. 热核平滑提供了处理流形支撑数据的统一技术: (?) 用热核平滑建立流形分布估计的极小极大下界; (?) 用热核正则化构造全变差意义下的最优检验统计量; 本文 (?) 则将热核平滑与 IPM 框架结合, 统一处理 Regime 2 和 3 中的流形估计项.

7.3. 上界证明技术.

- (1) **小波分解**: 将测试函数分解为粗糙和精细分量, 分别处理;
- (2) **局部多项式回归**: 利用 α_X -光滑性控制粗糙尺度的逼近误差;
- (3) **单位分解 (Partition of Unity)**: 在无全局参数化的流形上构造局部估计量, 并光滑拼接——这是 (?) 发展的核心技术;
- (4) **Talagrand 集中不等式**: 控制经验过程偏离均值的高概率界;
- (5) **联合估计 vs 独立估计**: Regime 2 估计量采用联合均值回归而非分别估计各小波系数, 关键在于利用了流形结构的稀疏性——独立估计忽略了不同小波系数之间的几何依赖 (见 eq. (10)).

8. 内在维度 vs 环境维度分析

本节集中阐述本文最重要的统计发现: 为何收敛速率只依赖 d_X, d_Y , 而完全不受 D_X, D_Y 影响.

注 1.8. 三个 Regime 的极小极大速率中, 环境维度 D_X, D_Y 仅出现在 Regime 1 的第二项中 (作为 α_Y 的系数出现). 在 Regime 2 和 Regime 3b 中, D_Y 完全消失, 速率仅由内在维度 d_X, d_Y 和光滑度参数决定. 这一现象的本质原因是:

- (1) 流形 $\mathcal{M}_X \in \mathcal{M}_X(D_X, d_X, L)$ 的 Minkowski 维数为 d_X , 与环境维度 D_X 无关——这是维度降维的第一层;
- (2) IPM d_γ 通过对抗测试函数类 $\mathcal{H}_1^\gamma(\mathbb{R}^{D_Y})$ 自然地适应流形结构——光滑测试函数在远离流形处无作用, 仅在流形的 d_Y 维邻域内有效发挥作用;
- (3) 热核平滑将流形上的奇异分布转化为 d_Y 维空间中的密度估计问题, 完全绕过了 D_Y 的影响.

9. 与系列工作的联系

本章结果在 Tang-Rong 系列中的地位:

- (1) **与 (?) (Annals 2022) 的关系**: 极小极大理论框架相同 (γ -Hölder IPM、三项取大结构), 但本文从无条件的流形分布估计推广到协变量条件设定.
- (2) **与 (?) (ICML 2023) 的关系**: MLDMAE 方法是 Regime 2 上界的具体算法实现, 验证了单位分解 + 混合局部估计策略的实践有效性.
- (3) **与 (?) (AISTATS 2024) 的关系**: 条件扩散模型在 Wasserstein 距离 ($\gamma = 1$) 下与 Regime 1 上界匹配, 证明了扩散模型的极小极大最优性.
- (4) **与 (?) (arXiv 2025) 的关系**: 条件扩散模型在流形设定下的收敛速率与 Regime 3b 的极小极大速率对照——实践工具能否在一般 γ 下达到最优仍是开放问题.

10. 开放问题

基于本章结果，以下问题值得进一步研究：

- (1) $\gamma \in (0, 1)$ 时的可计算估计量：混合估计量在 $\gamma \neq 0, 1$ 时涉及无穷维对抗优化，实践中如何有效实现？IPM 判别器的逼近误差如何量化？
- (2) **流形维数自适应**：本文假设 d_X, d_Y 已知；如何构造对这些参数同时自适应的估计量？Lepski 方法能否扩展到分布回归设定？
- (3) α_X -**自适应**：极小极大速率依赖于 α_X, α_Y 等光滑度参数，构造对所有光滑度同时自适应的估计量是重要挑战。
- (4) **噪声观测情形**：本文考虑无噪声观测 (X_i, Y_i 精确采样)；测量噪声或标签噪声下的极小极大速率是什么？
- (5) **流形回归与分布回归的统一理论**：Regime 3a (纯流形回归) 和 Regime 3b (带密度) 是否可以统一在一个更简洁的框架下？
- (6) **深度生成模型与 IPM 的结合**：当前理论主要围绕 Wasserstein 距离和全变差距离；对 MMD、Stein 差异等更一般的 IPM，深度生成模型能否达到相应的极小极大速率？

11. 小结

本章系统介绍了 (?) 关于分布回归极小极大速率的理论。

核心贡献：

- (1) **统一框架**： γ -Hölder IPM 统一了全变差距离和 Wasserstein 距离，使得同一套理论可分析多种概率度量下的估计问题。
- (2) **三类 Regime**：根据 $\mathcal{M}_{Y|x}$ 与 x 的关系，建立了从经典密度回归到协变量依赖流形回归的层次化理论，各 Regime 的极小极大速率清晰刻画。
- (3) **几何参数决定复杂度**：收敛速率由 $d_X, d_Y, \beta_X, \beta_Y, \alpha_X, \alpha_Y, \gamma$ 等参数的特定组合决定，揭示了低维流形结构如何缓解维度灾难。
- (4) **最优估计量**：提出了融合对抗学习与同步最小二乘的混合估计量，在各 Regime 下均达极小极大上界（至多对数因子），为条件生成模型提供了理论基础。

关键洞见：流形支撑与密度的联合估计是分布回归的核心挑战； γ 的选择决定了“关注支撑”与“关注密度”的权衡；联合估计（而非分别估计各小波系数）是流形设定下达到极小极大最优的关键；热核平滑为奇异分布与 IPM 度量之间提供了自然的桥梁。