

Tang & Yang 流形统计学习系列综述

Review Notes

Contents

Chapter 1. 综合评述	5
1. 摘要	5
2. 研究脉络总览	5
3. 主线一：从极小极大理论到深度模型验证	5
4. 主线二：从 VAE 到扩散模型自适应理论	6
5. 主线三：从稳健贝叶斯到高效 MCMC	7
6. 两样本检验：独立分支	8
7. 论文关系与技术索引	8
8. 批判性评估	9
9. 开放问题与进一步阅读	10
10. 参考文献	10
Chapter 2. 黎曼子流形上的稳健贝叶斯推断	11
1. 引言	11
2. 黎曼几何预备	11
3. 流形上的 BvM 定理	12
4. RRWM 算法	14
5. 数值实验	15
6. 本章小结	16
7. 习题	16
Chapter 3. 分布回归的极小极大速率	19
1. 引言	19
2. 数学框架	19
3. Regime 1: 经典密度回归	20
4. Regime 2: 响应空间为协变量无关流形	21
5. Regime 3: 协变量依赖流形	22
6. 极小极大最优估计量	23
7. 技术要点	24
8. 内在维度 vs 环境维度分析	26
9. 与系列工作的联系	26
10. 开放问题	27
11. 小结	27
Bibliography	29

CHAPTER 1

综合评述

1. 摘要

本文综述 Tang-Rong 系列工作 (2021–2025), 涵盖 Rong Tang 与 Yun Yang 等在流形统计学习领域的系列研究。该系列围绕三个核心问题展开: (1) 低维流形上分布估计的统计极限是什么? (2) 深度生成模型能否隐式自适应流形结构? (3) 如何在流形约束下进行稳健的贝叶斯推断和高效 MCMC?

系列包含 9 篇论文, 发表于 COLT、Annals of Statistics、JRSS B、ICML、AISTATS 等顶级会议与期刊, 并延伸至分布回归与条件扩散模型的 arXiv 工作。整个系列在极小极大理论、稳健贝叶斯推断和扩散模型自适应三个维度上建立了从理论奠基到方法验证、再到算法优化的完整体系。本文对各论文进行批判性评述, 分析其技术贡献与局限性, 梳理三条研究主线之间的内在联系, 并提出若干开放问题。

2. 研究脉络总览

现代高维数据 (图像、文本、点云) 的本质特征是: 环境维度 D 巨大, 但有效信息维度 $d \ll D$, 数据通常位于某个未知低维流形上。这一观察催生了三个根本性问题:

- (1) **统计极限**: 当数据支撑于未知低维流形时, 分布估计的极小极大速率是什么? D 是否必然出现在速率中?
- (2) **自适应机制**: 深度生成模型 (VAE、GAN、扩散模型) 在实践中表现出色, 但其隐式自适应流形结构的理论机制尚不清晰。
- (3) **贝叶斯推断**: 当参数自然地取值于黎曼流形时, 如何进行稳健的贝叶斯推断? 后验分布的渐近行为是什么?

该系列可划分为三条交织演进的研究主线: **主线一** (极小极大 $\rightarrow$ 深度验证): (Tang and Yang, 2022) 建立极小极大理论框架; (Tang and Yang, 2023a) 将理论具体化为 MLDMAE 方法; (Tang and Yang, 2025) 推广至分布回归设定。

主线二 (VAE $\rightarrow$ 扩散模型自适应): (Tang and Yang, 2021) 建立 VAE 的 Excess Risk Bound; (Tang and Yang, 2024a) 证明扩散模型同样自适应流形; (Tang et al., 2025) 将最优性推广至条件扩散模型。

主线三 (稳健贝叶斯 $\rightarrow$ 高效 MCMC): (Tang et al., 2023) 建立黎曼 BvM 定理与 RRWM 算法; (Tang and Yang, 2024b) 利用 BvM 性质证明 MALA 最优混合时间。

3. 主线一: 从极小极大理论到深度模型验证

3.1. (Tang and Yang, 2022): 极小极大理论的奠基. 论文信息: Annals of Statistics, 2022, Vol.50, No.4, 2197–2216.

创新性: 首次建立了未知子流形上分布估计在对抗损失下的完整极小极大理论。核心发现是三类不同收敛机制的识别: 参数机制 ($n^{-1/2}$)、密度估计机制 ($n^{-(\alpha+\gamma)/(2\alpha+d)}$) 和流形估计机制 ($n^{-\beta\gamma/d}$), 三者取最大值构成最终速率。**关键发现**: 环境维度 D 完全不出现在速率指数中。

技术贡献：引入单位分解 (Partition of Unity) 技术，构造了能够覆盖无全局参数化流形的估计器，突破了单编码器 VAE/GAN 的根本局限。下界证明综合运用 Fano 不等式、Varshamov-Gilbert 引理、经验过程理论 (chaining、peeling、localization) 和 Poincaré 不等式。

局限性：

- 估计器构造涉及小波截断、Lepski 自适应等复杂步骤，未给出具体算法实现——这是一篇“理论导向”而非“方法导向”的工作。
- 仅考虑无噪声观测；噪声情形下收敛速率急剧下降至仅对数级。
- 流形光滑阶 β 和密度光滑阶 α 须已知或通过额外假设获得。

在系列中的地位：(Tang and Yang, 2022) 是整个系列的理论基石，为 (Tang and Yang, 2023a)、(Tang and Yang, 2024a)、(Tang and Yang, 2025) 中具体生成模型的分析提供了理论参照系。

3.2. (Tang and Yang, 2023a): MLDMAE 方法. 论文信息: ICML, 2023.

创新性：提出混合潜在分布匹配自编码器 (MLDMAE) 方法，利用 K 个局部编码器-解码器对分别学习流形局部区域的参数化，通过单位分解函数 ρ_k 实现光滑拼接。**核心发现：多编码器/解码器结构在流形分布估计中是必要的。**在 1-Wasserstein 距离下达极小极大最优（至多对数因子）。

技术贡献：将 (Tang and Yang, 2022) 的理论极小极大框架转化为可计算的深度学习方法，验证了单位分解技术在深度学习中的可实现性。

局限性：

- 聚类数 K 的选择缺乏自适应理论指导，仅通过实验说明 $K \approx 10$ 对 MNIST 有效。
- 当 $\alpha > \beta - 1$ 时，最优速率是否仍然保持极小极大最优，论文仅提及但未严格证明。
- 局部块之间的重叠区域在理论上没有得到充分分析。

3.3. (Tang and Yang, 2025): 分布回归的极小极大速率. 论文信息: arXiv:2501.00001, 2025.

创新性：在三类层次递进的设定下系统建立了极小极大下界，并提出融合对抗学习 (IPM 度量) 与同步最小二乘的混合估计量。 γ -Hölder IPM d_γ 统一了全变差距离 ($\gamma = 0$) 和 1-Wasserstein 距离 ($\gamma = 1$)。

Regime 3 (协变量依赖响应空间) 揭示了 $d_X, d_Y, \beta_X, \beta_Y$ 等几何参数如何共同决定收敛速率。

局限性：

- 三层 Regime 的下界证明复杂，但上界中 $\frac{\alpha_Y}{\alpha_X} \cdot d_X$ 项的出现略显 ad hoc，缺乏几何直觉。
- 提出的混合估计量在 $\gamma \neq 0, 1$ 时是否仍然可计算（如何实现 IPM 的判别器优化？）并未讨论。
- 条件流形族 $\mathcal{M}_{Y|x}$ 随 x 光滑变化的假设较强，在实际应用中难以验证。

4. 主线二：从 VAE 到扩散模型自适应理论

4.1. (Tang and Yang, 2021): VAE 的 Excess Risk Bound. 论文信息: COLT, 2021.

创新性：为 VAE 型生成模型提供了首个关于 Excess Risk 的非渐近上界，揭示了 VAE 隐式自适应低维流形结构的机制——潜在空间维数与流形本征维数的关系是关键。

局限性：

- 假设条件依赖于解码器族和编码器族的逼近能力，在实际应用中的可验证性有待进一步讨论。
- VAE 的 posterior collapse 问题在理论上没有得到解释，限制了理论结果的实践指导意义。
- Excess Risk Bound 的速率可能不是最优的，与 (Tang and Yang, 2022) 的极小极大速率存在差距。

4.2. (Tang and Yang, 2024a): 扩散模型自适应流形结构. 论文信息: AISTATS, 2024.

创新性: 系统证明了两类扩散模型 (Langevin 扩散和正向-反向扩散) 的分布估计收敛速率仅依赖于数据的本征维度 d 而非环境维度 D ——这是该论文最重要的理论发现，建立了“实践有效的工具 $\Leftrightarrow$ 理论最优的方法”这一对应关系。

技术贡献:

- **Langevin 扩散分支:** 通过 Gaussian 平滑 $p_\sigma(x) = \int p_{\text{data}}(y)\phi_\sigma(x-y)dy$ 使密度函数在任意时刻 $t > 0$ 关于 Lebesgue 测度绝对连续，关键改进为只需分数函数的四阶矩误差 (而非 L_∞ 或矩母函数误差) 即可控制分布估计误差。
- **正向-反向扩散分支:** 构造了时间分段常数的神经网络架构 $\mathcal{S}_{\text{NN}}$ 逼近时变分数函数，在 1-Wasserstein 距离下达极小极大最优速率 $\frac{1}{\sqrt{n}} \vee n^{-\frac{\alpha+1}{2\alpha+d}}$ 。
- 通过 Girsanov 定理建立了分数估计误差与分布估计误差之间的联系，是连接 SDE 理论与统计学习的核心技术。

深层机制: 正向扩散天然地通过高斯噪声填充了流形的管状邻域，从而回避了奇异分布 (流形支撑分布) 的困难。

局限性:

- 神经网络架构 (时间分段常数) 过于简化，距实际使用的 ResNet、U-Net 等架构仍有较大差距。
- 各向同性高斯噪声可能“稀释”流形结构——论文提及但未给出严格的量化分析。
- 分段数 J 依赖于未知的光滑度参数 α ，实践中难以选择。

与系列的关系: (Tang and Yang, 2022) 提供极小极大目标；本篇证明扩散模型能够达到该目标。

4.3. (Tang et al., 2025): 条件扩散模型的最优性. 论文信息: arXiv:2501.00002, 2025 (joint with Lizhen Lin).

创新性: 首次建立了条件扩散模型的流形自适应理论，在两种场景下均达到极小极大最优收敛速率: (1) 经典密度回归设定 (基于全变差度量): 推广了已有文献结果 (现有文献仅覆盖 $\alpha_X \in [0, 1]$ 情形); (2) 高维回归设定 (基于 Wasserstein 度量): 估计误差仅依赖内在维度 (d_X, d_Y) 而非环境维度 (D_X, D_Y) 。

局限性:

- 缺乏对条件生成模型与 (Tang and Yang, 2025) 条件分布回归理论之间关系的讨论。
- 条件扩散模型中的 classifier-free guidance 等实践技术的理论解释尚未涉及。
- 条件分数函数的估计需要额外的条件生成模型架构，计算成本较高。

5. 主线三：从稳健贝叶斯到高效 MCMC

5.1. (Tang et al., 2023): 黎曼子流形上的稳健贝叶斯推断. 论文信息: JRSS B, 2023, Vol.85, No.4, 1079–1103 (joint with Anirban Bhattacharya and Debdeep Pati).

创新性: 提出 Bayesian RPETEL 框架——无需正确指定似然函数的模型自由贝叶斯推断框架，展现三重稳健性: (1) 无需正确指定似然函数即可提供自动校准的不确定性

量化；(2) 即使欧氏风险最小化器不在流形上，后验中心仍能接近流形上的风险最小化器；(3) 在正确设定下与标准贝叶斯后验渐近等价而不损失效率。

核心理论贡献：黎曼流形上的 Bernstein-von Mises (BvM) 定理。 通过将后验分布投影到流形切空间并利用局部坐标变换，成功将欧氏空间中的分析工具推广到流形 setting，证明了后验分布在切空间上的投影渐近正态——这是本文最重要的理论贡献。

计算贡献： 提出黎曼随机游走 Metropolis (RRWM) 算法，证明了混合时间仅依赖流形内在维度 d 而非环境维度 D 。

局限性：

- 正则性假设较强：假设流形局部为 C^3 光滑，且要求风险函数满足二次增长条件，限制了在更一般流形上的应用。
- BvM 定理的收敛速度（到渐近正态的速率）在论文中没有给出，使得有限样本下的可靠性难以量化。
- RRWM 的 proposal 设计较为简单，在多峰分布或强非线性流形上可能表现不佳。

5.2. (Tang and Yang, 2024b): MALA 的最优混合时间. 论文信息： ICML, 2024.

创新性： 引入 s -conductance profile 新技术，在无需对目标分布施加光滑或强对数凹性假设的条件下，证明了 MALA 达到最优 $O(d^{1/3})$ 维度依赖（经 burn-in 后），且条件数依赖为线性，给出了匹配的下界。

技术贡献： s -conductance profile 提供了介于经典 conductance 与 Chen et al. (2020) 的 conductance profile 之间的精细分析工具，在非凸集假设下将 warm-start 参数依赖从 $\log M_0$ 改进到 $\log \log M_0$ ——在高维后验分布（ M_0 极大）的实际场景中意义显著。

与 (Tang et al., 2023) 的内在联系： (Tang et al., 2023) 建立了流形上的 BvM 定理（后验渐近正态）；本篇则利用渐近高斯性，将 MALA 在高斯目标分布上的最优性质桥接到一大类实际感兴趣的后验分布。

局限性：

- 定理要求 $d \leq cn^{\kappa_1}/\log n$ ，对于非光滑情形需要相对更大的样本量才能保证 $d^{1/3}$ 混合时间。
- s -warm start 假设在实践中难以验证，与 MCMC “无知采样”的哲学存在张力。
- 没有给出实际可用的 burn-in 长度估计。
- 在欧氏空间建立结果，流形上的 MALA 最优混合时间是开放问题。

6. 两样本检验：独立分支

6.1. (Tang and Yang, 2023b). 论文信息： AISTATS, 2023.

创新性： 建立了统一的两样本检验框架，基于负 Besov 范数的样本版本（通过截断小波展开构造），然后进行标准化处理。核心创新是建立了负 Besov 范数与对抗损失之间的等价关系（引理 1），从而能够同时适用于 ℓ_1 、 ℓ_2 距离和 Wasserstein 距离等多种度量。计算复杂度 $O(n \log n + n^{2d/(4\alpha+d)})$ 远优于 MMD 的 $O(n^2)$ 。

局限性：

- 正则性假设过强：假设密度函数具有紧支撑且一致有界，在许多实际应用中可能难以满足。
- 最优截断水平 J 的选择依赖于未知的光滑度参数 α ——如何构造对 α 自适应的检验仍是开放问题。
- Bootstrap 阈值的理论支撑不足。

7. 论文关系与技术索引

7.1. 发表时间线.

- (1) **2021** — (Tang and Yang, 2021) (COLT: VAE Excess Risk Bound)
- (2) **2022** — (Tang and Yang, 2022) (Annals of Statistics: 流形极小极大框架)
- (3) **2023a** — (Tang and Yang, 2023a) (ICML: MLDMAE 混合生成模型)
- (4) **2023b** — (Tang et al., 2023) (JRSS B: 流形稳健贝叶斯 + BvM)
- (5) **2023c** — (Tang and Yang, 2023b) (AISTATS: 两样本检验)
- (6) **2024a** — (Tang and Yang, 2024a) (AISTATS: 扩散模型自适应流形)
- (7) **2024b** — (Tang and Yang, 2024b) (ICML: MALA 最优混合时间)
- (8) **2025a** — (Tang and Yang, 2025) (arXiv: 分布回归极小极大速率)
- (9) **2025b** — (Tang et al., 2025) (arXiv: 条件扩散模型最优性)

7.2. 核心技术索引.

- (1) **单位分解 (Partition of Unity)**: (Tang and Yang, 2022)、(Tang and Yang, 2023a) 利用此技术处理无全局参数化流形——是估计器构造的核心工具，也是区别于单编码器 VAE/GAN 的关键。
- (2) **γ -Hölder IPM 框架**: (Tang and Yang, 2022)、(Tang and Yang, 2023b)、(Tang and Yang, 2025) 将不同光滑度的判别器类统一在同一个框架下，实现多种距离度量的同时最优。 γ 参数在流形支撑恢复与密度估计之间引入了可调节的权衡。
- (3) **Gaussian 平滑 + 四阶矩误差**: (Tang and Yang, 2024a) 将 Langevin 扩散的分析从 L_∞ 弱化到四阶矩，建立了更弱但更实用的误差条件，是沟通 SDE 理论与统计估计的关键技术。
- (4) **时间分段神经网络架构**: (Tang and Yang, 2024a)、(Tang et al., 2025) 构造了随时间演化的神经网络架构，有效平衡了近时间端 (t 小) 与远时间端 (t 大) 的逼近精度。
- (5) **s -conductance profile**: (Tang and Yang, 2024b) 提出的马尔可夫链分析新技术，提供了介于经典 conductance 与 conductance profile 之间的精细分析工具，改进 warm-start 参数依赖。
- (6) **黎曼流形 Bernstein-von Mises 定理**: (Tang et al., 2023) 将经典 BvM 推广到黎曼子流形 setting，后验分布在切空间投影上渐近正态，是连接贝叶斯渐近理论与 MCMC 收敛分析的桥梁。
- (7) **Girsanov 定理桥梁**: (Tang and Yang, 2024a)、(Tang et al., 2025) 通过 Girsanov 定理建立分数估计误差与分布估计误差之间的联系，是连接 SDE 理论与统计学习的核心技术。

8. 批判性评估

8.1. 整体优势.

- (1) **理论系统性极强**: 该系列从极小极大理论出发，依次建立了深度生成模型自适应理论和稳健贝叶斯推断框架，三条主线相互呼应而非孤立发表。这种系统性在国内统计机器学习研究中较为罕见。
- (2) **技术工具有原创性**: 单位分解、 s -conductance profile、四阶矩误差分析等技术工具均具有原创性贡献，而非简单照搬已有方法。
- (3) **理论与实践的桥梁意识**: (Tang and Yang, 2023a) 和 (Tang and Yang, 2024a) 体现了将理论极小极大速率转化为具体深度学习算法的努力，这一点在纯理论论文中常常缺失。
- (4) **顶级发表记录**: 在五年内 (2021–2025) 发表了 7 篇顶级会议/期刊论文 (COLT, Annals, JRSS B, ICML x2, AISTATS x2)，表明该系列工作得到了国际同行的高度认可。

8.2. 主要不足.

- (1) **理论与实践的显著差距**: 尽管 (Tang and Yang, 2023a) 和 (Tang and Yang, 2024a) 试图弥合理论与实践, 但估计器构造 (时间分段常数神经网络等) 与实际使用的架构 (U-Net, ResNet) 之间仍有较大差距。预训练模型能否进一步改善理论速率, 这一问题未被触及。
- (2) **流形维数自适应缺失**: 整个系列均假设内在维度 d 已知, 但实际应用中 d 通常未知。如何构造对 d 自适应的估计器, 同时保持极小极大最优性, 是该系列最大的理论缺口之一。
- (3) **噪声观测情形被忽视**: 除两样本检验外, 多数论文仅考虑无噪声观测。噪声情形下 (Tang and Yang, 2022) 的速率急剧下降 (仅对数级), 这表明当前理论与实际应用之间存在根本性断层。
- (4) **计算复杂度与统计最优性未统一**: 渐近最优的神经网络架构面临严重的计算挑战, 但论文中对此几乎未做讨论。
- (5) **与其他生成模型理论比较不足**: 如与变分推断的泛化理论、归一化流的统计理论等, 缺乏有意义的比较和区分。
- (6) **BvM 定理的局限性**: (Tang et al., 2023) 的 BvM 定理要求后验分布相对“规则”, 对实际中常见的混合后验、退化后验等情形不适用。

9. 开放问题与进一步阅读

基于对 Tang-Rong 系列的批判性分析, 以下问题值得进一步探索:

- (1) **流形维数的自适应估计**: 如何构造对 d 自适应的估计器, 同时保持极小极大最优性? 是否存在类似 Lepski 方法的维数自适应技术?
- (2) **噪声观测情形的多项式速率**: (Tang and Yang, 2022) 的无噪声设定过于理想化。是否有方法在适度噪声假设 (如有界噪声、测量误差模型) 下恢复多项式收敛速率?
- (3) **光滑性自适应**: 极小极大速率依赖于未知的光滑度参数 α, β, γ , 如何构造对这些参数同时自适应的估计器?
- (4) **预训练模型的理论分析**: 实际应用中的扩散模型通常在大规模数据上预训练。预训练能否改善从零开始训练的极小极大速率? 迁移学习在流形统计学习中的理论保证是什么?
- (5) **流形 MCMC 的最优收敛**: (Tang and Yang, 2024b) 在欧氏空间建立了 MALA 的最优混合时间; 流形上的 MALA (黎曼流形上的 Metropolis-Hastings 算法) 在何种条件下能够达到类似的最优依赖?
- (6) **深度生成模型与其他 IPM 的结合**: 当前的理论主要围绕 Wasserstein 距离和全变差距离展开。对于 MMD、Stein 差异等更一般的 IPM, 深度生成模型能否达到相应的极小极大速率?
- (7) **条件生成模型的不确定性量化**: (Tang et al., 2025) 证明了条件扩散模型的条件分布估计最优性, 但条件生成模型的后验不确定性如何刻画? 这与 (Tang et al., 2023) 的稳健贝叶斯框架有何联系?

10. 参考文献

CHAPTER 2

黎曼子流形上的稳健贝叶斯推断

本笔记系统整理 (Tang et al., 2023) (JRSS B, 2023, Vol.85, No.4, 1079–1103) 的核心内容，聚焦于流形约束下的贝叶斯推断理论、RPETEL 框架与 RRWM 算法。

1. 引言

现代统计中大量问题涉及取值于黎曼流形上的参数估计：协方差矩阵（正定矩阵流形 $\mathbb{S}_+^p$ ）、方向数据（单位球面 $\mathbb{S}^{d-1}$ ）、降秩回归系数（Grassmannian 流形）、扩散张量均值（正定对称矩阵流形）等。设 $\mathcal{M} \subset \mathbb{R}^D$ 为紧致光滑 d 维黎曼子流形，嵌入维度为 D （通常 $d \ll D$ ）。经典贝叶斯方法将参数先验置于全空间 $\mathbb{R}^D$ 上，但这忽略了流形约束，可能导致后验分布在高维环境空间中的不必要扩散。

一个更本质的困难在于：即便将先验限制在 $\mathcal{M}$ 上，后验分布关于 $\mathbb{R}^D$ 中的 Lebesgue 测度是奇异的——它集中在 d 维子流形上，质量为零。因此，经典的 Bernstein-von Mises (BvM) 定理不能直接应用。

更严峻的挑战来自模型误设定 (model misspecification)：在实践中，似然函数难以正确指定，数据生成分布可能来自 Huber 污染模型 (Huber contamination model)。在欧氏空间中，即使似然误设定，Gibbs 后验的 BvM 定理（如 (Kleijn and van der Vaart, 2012)）仍可在一定条件下成立。本文的核心问题是：能否将这一鲁棒性推广到黎曼流形 setting，同时保持计算上的可行性？

2. 黎曼几何预备

本节给出全文所需的核心几何定义与记号，细节参见 (Tang et al., 2023, Appendix A) 和 (Boumal, 2023)。

定义 2.1 (黎曼子流形). 设 $\mathcal{M}$ 为嵌入于 $\mathbb{R}^D$ 的 d 维黎曼子流形。对任意 $\theta \in \mathcal{M}$ ，记 $T_\theta \mathcal{M} \subset \mathbb{R}^D$ 为其在 θ 处的切空间，维数为 d 。设 $P_\theta \in \mathbb{R}^{D \times D}$ 为到 $T_\theta \mathcal{M}$ 的正交投影矩阵， $W_\theta \in \mathbb{R}^{D \times d}$ 为 $T_\theta \mathcal{M}$ 的任意一组标准正交基，满足 $P_\theta = W_\theta W_\theta^\top$ 。

局部坐标的构造依赖投影映射 $\psi_\theta : \mathcal{U}_\theta \rightarrow T_\theta \mathcal{M}$ ，定义为 $\psi_\theta(x) = \text{Proj}_{T_\theta \mathcal{M}}(x - \theta)$ ，其中 $\mathcal{U}_\theta$ 为 θ 在 $\mathcal{M}$ 中的邻域。其逆映射 $\phi_\theta = \psi_\theta^{-1} : T_\theta \mathcal{M} \rightarrow \mathcal{U}_\theta$ 被称为 retraction（或称为指数映射的近似），其 Fréchet 导数满足一阶等价性。

可测性说明：由于 ψ_θ 为线性正交投影算子的限制，它是从 $\mathbb{R}^D$ 到 d 维子空间 $T_\theta \mathcal{M}$ 的连续（从而 Borel 可测）映射。给定 Borel 集 $B \subset T_\theta \mathcal{M}$ ，预像 $\psi_\theta^{-1}(B) \subset \mathbb{R}^D$ 为 Borel 集；将其限制在 $\mathcal{M}$ 上仍为 Borel（相对于 $\mathcal{M}$ 上的子空间拓扑），故后验分布在该集合上的取值良定。

本文的关键假设是局部 $C_{r,L}^3$ 光滑性：在 θ^* 的邻域内， ϕ_θ 三阶 Fréchet 可微，且导数范数一致有界于 L 。这一假设确保切空间 $T_{\theta^*} \mathcal{M}$ 在 θ^* 附近提供了流形 $\mathcal{M}$ 的良好线性近似。

对于损失函数 $\ell : \mathcal{X} \times \mathcal{M} \rightarrow \mathbb{R}$ ，定义黎曼梯度 $\text{grad}_\theta \ell(x, \theta) \in T_\theta \mathcal{M}$ 为 $\ell(x, \cdot)$ 在流形上的最速上升切方向。相应地，总体风险函数 $R(\theta) = \mathbb{E}_P[\ell(X, \theta)]$ 的黎曼梯度为 $\text{grad} R(\theta)$ 。风险最小化器 $\theta^* = \arg \min_{\theta \in \mathcal{M}} R(\theta)$ 的一阶最优性条件为 $\text{grad} R(\theta^*) = 0$ 。

3. 流形上的 BvM 定理

3.1. Gibbs 后验的 BvM 定理. 本节研究参数取值于黎曼子流形 $\mathcal{M}$ 上的 Gibbs 后验的渐近形态。设先验分布 Π 在 $\mathcal{M}$ 上定义，Gibbs 后验定义为

$$(1) \quad \Pi(d\theta \mid X^{(n)}) = \frac{\exp\left(-\sum_{i=1}^n \ell(X_i, \theta)\right) \Pi(d\theta)}{\int_{\mathcal{M}} \exp\left(-\sum_{i=1}^n \ell(X_i, \theta')\right) \Pi(d\theta')}.$$

注意此处的 ℓ 不一定是负对数似然——它可以是任意损失函数。

记经验风险最小化器 (ERM) 为 $\hat{\theta} = \arg \min_{\theta \in S_{\Pi}} \frac{1}{n} \sum_{i=1}^n \ell(X_i, \theta)$ 。设 $\mathcal{H}_{\theta^*}$ 为 $R(\cdot)$ 在 θ^* 处的黎曼 Hessian 矩阵 (在 $T_{\theta^*}\mathcal{M}$ 的局部坐标下)， $\Delta_{\theta^*} = \mathbb{E}[g(X, \theta^*)g(X, \theta^*)^\top]$ 为梯度型函数 g 的协方差矩阵。

注 2.1. 关于 θ^* 的识别: *section 2* 中定义 $\theta^* = \arg \min_{\theta \in \mathcal{M}} R(\theta)$ 。在正确模型设定 (*Assumption 5*) 下，数据分布 P_{θ_0} 满足 $\theta_0 = \arg \min_{\theta \in \mathcal{M}} R(\theta)$ ，故 $\theta^* = \theta_0$ 。在误设定下， θ^* 为流形上的“伪真值” (*pseudo-true parameter*)，它不唯一对应某个真实分布，但仍是后验收缩的目标点。这一区分对理解 BvM 定理中的协方差矩阵至关重要: *eq. (2)* 中的 $\mathcal{H}_{\theta^*}^\dagger$ 是相对于该伪真值的 Fisher 型矩阵，而非相对于某个真实 θ_0 的。

定理 2.1 (流形 BvM 定理 (Gibbs 后验)). 设正则性条件 (*Assumptions 1-4*, 详见 (*Tang et al., 2023, Section 2*)) 成立:

- (A1) $\mathcal{M}$ 在 θ^* 附近局部 $C_{r,L}^3$ 光滑;
- (A2) 先验支撑 S_{Π} 包含 θ^* 的固定半径邻域，且先验密度在 θ^* 附近 Lipschitz 连续;
- (A3) 风险函数 $R(\theta)$ 在 θ^* 处二次增长，即 $|R(\theta) - R(\theta^*)| \geq \frac{1}{L} \|\theta - \theta^*\|^2$;
- (A4) 损失函数的梯度型代理 $g(X, \theta)$ 满足 $\mathbb{E}[g(X, \theta^*)g(X, \theta^*)^\top] \succcurlyeq \frac{1}{L} I_d$ ，且具有一致有界的度量熵。

则存在集合 $\mathcal{A} \subset \mathcal{X}^n$ ，满足 $\mathbb{P}(X^{(n)} \in \mathcal{A}) \geq 1 - n^{-1}$ ，使得对任意 $X^{(n)} \in \mathcal{A}$ ，有

$$(2) \quad \text{TV}\left(\Pi(\cdot \mid X^{(n)}), \phi_{\theta^* \#} \mathcal{N}\left(\text{Proj}_{T_{\theta^*}\mathcal{M}}(\hat{\theta} - \theta^*), n^{-1} \mathcal{H}_{\theta^*}^\dagger\right)\right) \leq C \frac{(\log n)^{\frac{1}{\beta_1} + 1}}{n^{\frac{\beta_2}{2}}},$$

其中 $\beta_1, \beta_2 \in (0, 1]$ 为 *Assumption 4* 中的光滑性参数， $\mathcal{H}_{\theta^*}^\dagger$ 为 Moore-Penrose 逆。

eq. (2) 表明: 将后验分布投影到切空间 $T_{\theta^*}\mathcal{M}$ 后，该投影渐近等价于以 $\text{Proj}_{T_{\theta^*}\mathcal{M}}(\hat{\theta} - \theta^*)$ 为均值、协方差为 $n^{-1} \mathcal{H}_{\theta^*}^\dagger$ 的正态分布。

关键发现: 即使后验分布在 $\mathbb{R}^D$ 中是奇异的，其在切空间上的投影仍然渐近正态——这一发现是本文最重要的理论贡献。值得注意的是，渐近协方差矩阵中的 Moore-Penrose 逆 $\mathcal{H}_{\theta^*}^\dagger$ 自动处理了切空间的约束，无需额外的拉格朗日乘子。

正确设定下的特例 (*corollary 2.1*): 当损失函数为负对数似然 $\ell(x, \theta) = -\log p(x \mid \theta)$ 且模型正确指定时， $\mathcal{H}_{\theta^*} = \Delta_{\theta^*} = I_{\theta^*}$ (Fisher 信息矩阵在切空间上的投影)，此时后验收缩至 $n^{-1/2}$ ，与经典 BvM 定理一致。

推论 2.1 (正确设定下的 BvM). 在正确模型设定下 (*Assumption 5*)，对任意光滑函数 $f: \mathbb{R}^D \rightarrow \mathbb{R}$ (在 θ^* 处 Riemannian 梯度非零)，有

$$\sqrt{n}(f(\hat{\theta}) - f(\theta^*)) \xrightarrow{d} \mathcal{N}\left(0, \nabla f(\theta^*)^\top (P_{\theta^*} I_{\theta^*} P_{\theta^*})^\dagger \nabla f(\theta^*)\right).$$

且后验分布产生的置信集渐近达到有效频率覆盖率。

流形结构带来的效率提升: *Corollary 2.1* 还揭示了一个量化结论: 后验方差 $n^{-1} \nabla f(\theta^*)^\top (P_{\theta^*} I_{\theta^*} P_{\theta^*})^\dagger \nabla f(\theta^*)$ 恒不超过欧氏后验方差 $n^{-1} \nabla f(\theta^*)^\top I_{\theta^*}^{-1} \nabla f(\theta^*)$ 。这表明: 利用流形约束可以在不牺牲覆盖率的前提下缩短置信集长度。

3.2. RPETEL 框架：三重稳健性.

3.2.1. 问题引入. Gibbs 后验 BvM 定理的核心局限在于：即使在欧氏空间中，当模型误设定时，后验分布的协方差与频率学派采样分布的协方差可能不匹配，导致不确定性量化失效。在流形设定下，这一问题更加严峻——误设定下的后验可能在远离 θ^* 的方向上过度扩张。

本文提出的 Bayesian RPETEL 框架通过引入黎曼指数倾斜经验似然 (Riemannian Exponentially Tilted Empirical Likelihood, 简称 RETEL) 来构造伪似然，并结合经验风险惩罚项，成功实现了三重稳健性。

3.2.2. RETEL 伪似然的构造. 设损失函数 $\ell : \mathcal{X} \times \mathcal{M} \rightarrow \mathbb{R}$ ，对应的黎曼梯度为 $g(x, \theta) = \text{grad}_\theta \ell(x, \theta) \in T_\theta \mathcal{M}$ 。风险最小化器 $\theta^* = \arg \min_{\theta \in \mathcal{M}} R(\theta)$ 的一阶最优性条件为 $\mathbb{E}[g(X, \theta^*)] = 0$ ——这提供了 θ^* 的识别条件，无需完整指定似然函数。

RETEL 的构造借鉴了 (Schennach, 2005) 的指数倾斜方法：对给定的 θ ，引入非负权重 $w_1, \dots, w_n$ (满足 $\sum_i w_i = 1$)，最小化后向 KL 散度 $D_{\text{KL}}(\text{Unif} \parallel \sum_i w_i \delta_{X_i})$ 并施加一阶最优性条件的加权版本约束：

$$\sum_{i=1}^n w_i g(X_i, \theta) = 0, \quad w_i \geq 0.$$

具体而言，RETEL 函数 $L(X^{(n)}; \theta)$ 由以下优化问题定义：

$$(3) \quad \begin{aligned} L(X^{(n)}; \theta) &= \max_{w_1, \dots, w_n} \sum_{i=1}^n [-w_i \log(nw_i)] \\ \text{s.t. } &\sum_{i=1}^n w_i = 1, \quad \sum_{i=1}^n w_i g(X_i, \theta) = 0, \quad w_i \geq 0. \end{aligned}$$

直观上，RETEL 寻找一组权重，使经验分布的加权版本尽可能接近均匀分布，同时保证一阶最优性条件成立。这等价于在经验似然框架下融入了流形几何结构。

3.2.3. Bayesian RPETEL 后验. 为防止后验在远离 θ^* 的方向上分散，本文进一步引入经验风险惩罚项 $\alpha_n \mathcal{R}_n(\theta)$ ，其中 $\mathcal{R}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(X_i, \theta)$ ， α_n 为正则化参数 (典型取值为 $c_1 \log n \leq \alpha_n \leq c_2 \sqrt{n}$)。最终定义的后验分布为

$$(4) \quad \Pi_{\text{RP}}(d\theta \mid X^{(n)}) = \frac{\exp\left(\sum_{i=1}^n \log p_i(\theta) - \alpha_n \mathcal{R}_n(\theta)\right) \Pi(d\theta)}{\int_{\mathcal{M}} \exp\left(\sum_{i=1}^n \log p_i(\theta') - \alpha_n \mathcal{R}_n(\theta')\right) \Pi(d\theta')},$$

其中 $p_i(\theta)$ 为 RETEL 优化问题 (eq. (3)) 的最优权重对应的概率。当 $\alpha_n = 0$ 时，上式退化为基于纯 RETEL 伪似然的后验；当 α_n 适当大时，后验被强制集中于经验风险最小化器附近。

注 2.2. 设计 RPETEL 时的一个关键选择是使用黎曼梯度 $\text{grad}_\theta \ell(X, \theta)$ 而非欧氏梯度 $\nabla_\theta \ell(X, \theta)$ 。理由如下：若使用欧氏梯度，当欧氏风险最小化器 $\theta_E^* \notin \mathcal{M}$ 时，一阶条件 $\mathbb{E}[\nabla_\theta \ell(X, \theta)] = 0$ 不蕴含 $\theta_E^* \in \mathcal{M}$ ，导致伪似然过识别 (over-identified) —— D 个方程约束 d 维参数——从而使后验分散到多个局部模。使用黎曼梯度则自动将问题投影到切空间，等效于只施加 d 个有效约束，避免了这一问题。

3.2.4. RPETEL 的三重稳健性.

定理 2.2 (流形 BvM 定理 (Bayesian RPETEL)). 在 section 3.1 的正则性条件下，设 $c_1 \log n \leq \alpha_n \leq c_2 \sqrt{n}$ 。则存在集合 $\mathcal{A} \subset \mathcal{X}^n$ ($\mathbb{P}(X^{(n)} \in \mathcal{A}) \geq 1 - n^{-1}$)，使得对任意

$X^{(n)} \in \mathcal{A}$, 有

$$(5) \quad \text{TV}\left(\Pi_{\text{RP}}(\cdot | X^{(n)}), \phi_{\theta^* \#} \mathcal{N}\left(\text{Proj}_{T_{\theta^*} \mathcal{M}}(\hat{\theta} - \theta^*), n^{-1} \mathcal{H}_{\theta^*}^\dagger \Delta_{\theta^*} \mathcal{H}_{\theta^*}^\dagger\right)\right) \leq C \frac{(\log n)^{\frac{2}{\beta_1}+1}}{n^{\frac{\beta_2}{2}}}.$$

eq. (5) 与 eq. (2) 的关键区别在于协方差矩阵中的”夹心”结构 $\mathcal{H}_{\theta^*}^\dagger \Delta_{\theta^*} \mathcal{H}_{\theta^*}^\dagger$ ——这恰好是经验风险最小化器 $\sqrt{n}(\hat{\theta} - \theta^*)$ 渐近分布的协方差 (由 (Tang et al., 2023, Section 2) 的 CLT 给出)。这带来了以下三重稳健性。

第一重：似然稳健性。 由于后验收缩分布的协方差与 $\sqrt{n}(\hat{\theta} - \theta^*)$ 的渐近协方差一致，由该后验产生的置信集能够渐近达到正确的频率覆盖率——即使似然函数未正确指定。

第二重：风险稳健性。 即使欧氏风险最小化器 $\theta_E^* \notin \mathcal{M}$ ，后验中心（投影后验均值）仍接近流形上的风险最小化器 θ^* ——此时后验收缩至 θ^* 而非 θ_E^* ，避免了在 θ_E^* 附近的不稳定行为。

第三重：先验稳健性。 在正确模型设定下（似然正确 + $\theta^* \in \mathcal{M}$ ），Bayesian RPETEL 后验收缩分布与标准贝叶斯后验渐近等价，不因引入稳健机制而损失效率。

推论 2.2 (正确设定下的 RPETEL 等价性). 在正确模型设定下 (*Assumption 5*), *Bayesian RPETEL* 后验与使用同一流形先验的标准贝叶斯后验渐近等价——两者都渐近正态且具有相同的协方差。这确保了在正确设定下稳健性不带来效率损失。

4. RRWM 算法

4.1. 算法构造. 计算上的核心问题是：从 $\Pi_{\text{RP}}(\cdot | X^{(n)})$ 中高效采样。后验分布在流形 $\mathcal{M}$ 上定义，标准随机游走 Metropolis (RWM) 算法无法直接应用——因为在 $\mathbb{R}^D$ 中生成的 proposal 点几乎必然不在 $\mathcal{M}$ 上。

本文提出的 RRWM (Riemannian Random-Walk Metropolis) 算法通过以下三步将 RWM 适配到流形 setting:

- (1) **在切空间中生成 proposal:** 设当前状态为 $\theta^{k-1} \in \mathcal{M}$ 。从 $\mathcal{N}(0, 2\tilde{h}\tilde{I})$ 生成环境向量 $\tilde{v} \in \mathbb{R}^D$ ，然后投影到切空间： $v = \text{Proj}_{T_{\theta^{k-1}} \mathcal{M}}(\tilde{v})$ 。此步骤确保 proposal 方向始终位于切空间中。
- (2) **通过 retraction 映射回流形:** 设 retraction $\phi_\theta : T_\theta \mathcal{M} \rightarrow \mathcal{M}$ 为投影映射 $\psi_\theta(x) = \text{Proj}_{T_\theta \mathcal{M}}(x - \theta)$ 的逆。令候选点 $y = \phi_{\theta^{k-1}}(v)$ 。Retraction 的关键性质是一阶近似： $\|y - \theta^{k-1} - v\| = O(\|v\|^2)$ ，这保证了 proposal 步长的局部一致性。
- (3) **Metropolis-Hastings 接受/拒绝:** 计算接受率

$$(6) \quad A(\theta^{k-1}, y) = 1 \wedge \frac{\mu^*(y) \exp(-v'^\top (P_y \tilde{I} P_y)^\dagger v' / (4\tilde{h}))}{\mu^*(\theta^{k-1}) \exp(-v^\top (P_{\theta^{k-1}} \tilde{I} P_{\theta^{k-1}})^\dagger v / (4\tilde{h}))},$$

其中 $v' = \psi_y(\theta^{k-1})$ ， $\mu^*(\theta) \propto \exp(\sum_i \log p_i(\theta) - \alpha_n \mathcal{R}_n(\theta))$ 为目标密度的未归一化版本。接受概率的计算中出现了 retraction 导数的伪行列式，用于补偿流形弯曲带来的体积变化。

注 2.3. **Jacobian 修正因子的显式说明:** *proposal* 密度的比值 $q(\theta^{k-1}, y)/q(y, \theta^{k-1})$ (eq. (6) 中隐含于 $\exp(-v^\top \dots)$ 的比值) 须包含从切空间到流形的体积变化修正。设 $y = \phi_{\theta^{k-1}}(v)$ ，则 $q(\theta^{k-1}, y) d\theta^{k-1} = \phi_{\theta^{k-1} \#}(\mathcal{N}(0, 2\tilde{h}\tilde{I}))(dy)$ 中的拉回密度包含 *retraction* 导数行列式 $\det(D\phi_{\theta^{k-1}}(0))$ 的倒数。原文 (Tang et al., 2023, Algorithm 1) 中通过比较 *backward proposal* (从切空间到流形) 与 *forward proposal* (从流形到切空间) 的密度，将 *Jacobian* 修正显式化为 *retraction* 导数的伪行列式比值，这就是 eq. (6) 中 v 与 v' 方向所对应的不同协方差矩阵的来源。

注 2.4. *Retraction* 的选取对算法的接受率有显著影响。当使用投影映射的逆 ϕ_θ 作为 *retraction* 时，伪行列式项退化为常数，接受率简化为只包含 *proposal* 高斯密度的比值，这大大简化了计算实现。对一般流形（如 *Stiefel*、*Grassmannian*），投影映射的逆可以通过 *Newton-Raphson* 方法或黎曼梯度下降法数值求解。

4.2. 混合时间分析. RRWM 算法的核心计算保证是其混合时间仅依赖流形内在维度 d ，而非环境维度 D 。

设 s -lazy 版本的 RRWM（每步以概率 $1-s$ 保持当前状态），在 M_0 -warm start 下（初始分布与目标分布的 χ^2 距离有界于 M_0 ），定义 ε -混合时间 $\tau_{\text{mix}}(\varepsilon, \mu_0) = \inf\{k : \sqrt{\chi^2(\mu_k, \mu^*)} \leq \varepsilon\}$ ，其中 μ_k 为第 k 步的链分布。

定理 2.3 (RRWM 混合时间). 在 section 3.2 的正则性条件下，设 n 足够大，步长参数 $\tilde{h} = h/n$ ，其中 $h = c_0 \rho_2^{-1} (d + \log(M_0 d \rho_2 / (\varepsilon \rho_1)))^{-1}$ ， ρ_1, ρ_2 为条件数相关的常数。则对任意 $\varepsilon \geq M_0/n^c$ ，有

$$(7) \quad \tau_{\text{mix}}(\varepsilon, \mu_0) \leq \frac{C_1}{\zeta} \left\{ \left[\kappa \left(d + \log \frac{M_0 d \kappa}{\varepsilon} \right) \log \frac{\log M_0}{\varepsilon} \right] \vee \log M_0 \right\}, \quad \kappa = \frac{\rho_2}{\rho_1}.$$

eq. (7) 的核心含义是：RRWM 的 ε -混合时间关于 d 是线性的，且不包含对 D 的任何依赖。在 M_0 为常数、 ε 固定的情况下，主导项的维度依赖为 $O(d \log d)$ ——这与欧氏空间 RWM 的 $O(D \log D)$ 形成鲜明对比。这一改进来源于流形的几何结构：在高维环境空间 $\mathbb{R}^D$ 中，切空间只有 d 个有效自由度。

条件数的角色：当预条件矩阵 $\tilde{I}$ 满足 $P_{\theta^*} \tilde{I} P_{\theta^*} \approx \mathcal{H}_{\theta^*}^\dagger \Delta_{\theta^*} \mathcal{H}_{\theta^*}$ 时，条件数 $\kappa \approx 1$ ，混合时间最优。论文建议两种自适应选择 $\tilde{I}$ 的方法：(1) 直接估计 $\mathcal{H}_{\theta^*}$ 和 Δ_{θ^*} ；(2) 利用后验样本的协方差迭代更新 $\tilde{I}$ 。

5. 数值实验

5.1. 多元分位数回归. 本文在三个问题上验证了 Bayesian RPETEL 的有效性。第一个实验考虑多元分位数回归中的共同斜率约束问题。设 J 个分位数水平 $(\tau_1, \dots, \tau_J)$ ，参数 (u, β) 受约束 $\beta_1 = \dots = \beta_J$ ，即所有分位数共享相同的斜率向量。这一约束将参数空间限制为 $\mathcal{M}$ （一个线性子空间）。数据来自 $Y_i = X_i + \varepsilon_i(1 + \epsilon X_i)$ ，其中 $X_i \sim \mathcal{N}(0, 1)$ ， $\varepsilon_i \sim \text{Laplace}(0, 1)$ 。 $\epsilon = 0$ 对应正确设定， $\epsilon = 0.1$ 对应误设定。

实验结果显示（1000 次重复）：在正确设定下，Bayesian RPETEL 与全梯度 PETEL (BPETELM) 的 MSE 基本相同，且均优于欧氏 PETEL (BPETELE)。在误设定下，Bayesian RPETEL 的 95 而 BPETELM 在某些坐标上仅为 87.7%——Bayesian RPETEL 在保持效率的同时实现了更好的稳健性。

在计算效率方面，RRWM 算法的有效样本量 (ESS) 约为 700，远高于欧氏 RWM 的约 280——比例接近 $D/d = 6/3 = 2$ ，与理论预测 (ESS 反比于维度) 吻合。

5.2. 扩散张量均值推断. 第二个实验分析真实扩散张量成像 (DTI) 数据，来自 Gordon Kindlmann 的大脑扫描。数据点为 3×3 对称正定协方差矩阵（扩散张量），参数空间为 $\mathbb{S}_+^3$ （6 维流形）。关注三个具有科学意义的功能量：分数各向异性 (FA)、迹 (trace) 和最大特征值。

通过子采样（每次从原始数据中有放回抽取 $n = 1000$ 个样本，重复 1000 次）评估频率学覆盖性质：Bayesian RPETEL 的 95 均接近 94%（目标 95%），而 Wishart 参数化方法在迹上仅达 59.2%——后者严重低估了推断精度。这一对比有力地验证了 Bayesian RPETEL 在真实数据分析中的稳健优势。

6. 本章小结

本章系统整理了 (Tang et al., 2023) 的核心内容与理论贡献。

- (1) **流形 BvM 定理** (section 3): eq. (2) 建立了后验分布在切空间投影上的渐近正态性, 突破了奇异性带来的分析障碍; 协方差矩阵中的 Moore-Penrose 逆 $\mathcal{H}_{\theta^*}^\dagger$ 自动处理了流形约束。
- (2) **RPETEL 三重稳健性** (section 3.2): eq. (5) 中的夹心协方差结构 $\mathcal{H}_{\theta^*}^\dagger \Delta_{\theta^*} \mathcal{H}_{\theta^*}^\dagger$ 确保后验协方差与采样分布协方差一致, 从而同时实现似然稳健性、风险稳健性和先验稳健性。
- (3) **RRWM 算法** (section 4): 切空间 proposal + retraction 的组合设计实现了流形上的 Metropolis 采样; eq. (7) 证明其混合时间仅依赖 d 而非 D , 在高维流形问题中具有显著计算优势。

注 2.5. 本章方法存在以下局限性: (1) 正则性假设较强——流形局部 C^3 光滑且风险函数二次增长; (2) BvM 定理的收敛速度 (到渐近正态的速率) 在论文中未给出显式下界; (3) RRWM 的 *proposal* 设计相对简单, 在强非线性流形或多峰后验上可能表现不佳。这些局限性也为后续研究留下了空间——(Tang and Yang, 2024b) 即在欧氏空间中证明了 MALA 的最优 $O(d^{1/3})$ 混合时间, 流形上的最优 MCMC 设计仍是开放问题。

7. 习题

- (1) **切空间投影算子的可微性**. 设 $\mathcal{M}$ 为 $\mathbb{R}^D$ 中的 C^3 光滑 d 维子流形, 对任意点 $\theta \in \mathcal{M}$, 证明最近点投影算子 $\Pi_{\mathcal{M}}: U \rightarrow \mathcal{M}$ 在邻域 $U \supset \theta$ 上光滑。进一步, 计算 $\Pi_{\mathcal{M}}$ 在 θ 处的 Fréchet 导数。(提示: 利用隐函数定理和 $\mathcal{M}$ 的局部参数化。
- (2) **黎曼 Hessian 与欧氏 Hessian 的关系**. 设损失函数 $\ell: \mathcal{X} \times \mathcal{M} \rightarrow \mathbb{R}$, 记 $\mathcal{H}_{\theta}^{\text{Euc}}$ 为 $\ell(x, \cdot)$ 在 $\theta \in \mathcal{M}$ 处的欧氏 Hessian 矩阵 ($D \times D$), $\mathcal{H}_{\theta}^{\text{Riem}}$ 为其黎曼 Hessian (在 $T_{\theta}\mathcal{M}$ 的局部坐标下, $d \times d$)。证明两者满足 $\mathcal{H}_{\theta}^{\text{Riem}} = W_{\theta}^{\top} \mathcal{H}_{\theta}^{\text{Euc}} W_{\theta} - \Pi_{\theta}(W_{\theta} \cdot, W_{\theta} \cdot)$, 其中 W_{θ} 为切空间的正交基矩阵, Π_{θ} 为第二基本形式。解释为什么这一关系使得 $\mathcal{H}_{\theta}^{\text{Riem}}$ 在 θ 附近可以用 $d \times d$ 矩阵而非 $D \times D$ 矩阵表示。
- (3) **RETEL 伪似然的显式解**. 证明 RETEL 优化问题 (eq. (3)) 在 Slater 条件成立时有显式解: 对拉格朗日乘子向量 $\lambda \in \mathbb{R}^d$, 最优权重满足 $w_i^* = \frac{1}{n} \cdot \frac{1}{1 + \lambda^{\top} g(X_i, \theta)} \Big/ \sum_{j=1}^n \frac{1}{1 + \lambda^{\top} g(X_j, \theta)}$ 。进一步证明对偶问题转化为求解 $\sum_{i=1}^n \frac{g(X_i, \theta)}{1 + \lambda^{\top} g(X_i, \theta)} = 0$ 。(提示: 利用凸优化的 KKT 条件。)
- (4) **RPETEL 后验与 Gibbs 后验的渐近等价性**. 在正确模型设定下 (Assumption 5), 证明 Bayesian RPETEL 后验 (eq. (4)) 与 Gibbs 后验 (eq. (1)) 在全变差距离下渐近等价。具体而言, 证明两者的差以速率 $O_p(n^{-1/2})$ 收敛。(提示: 利用 eq. (5) 与 eq. (2) 中的相同渐近正态形式。)
- (5) **RRWM 接受率的几何解释**. 在 RRWM 算法 (section 4.1) 中, 推导在当前点 θ 的小邻域内, 接受率近似为 $a(\theta, y) \approx 1 \wedge \exp(-\mathcal{R}_n(y) + \mathcal{R}_n(\theta))$ 。解释这一近似背后的几何直觉: 当步长足够小时, proposal 分布和 target 分布在局部都近似高斯, 接受/拒绝决策主要由能量差决定。进一步, 构造一个具体例子, 说明当 proposal 尺度过大时接受率急剧下降的原因。
- (6) **三重稳健性的数值验证**. 设 $\mathcal{M} = \mathbb{S}^1$ (单位圆), 数据来自 von Mises-Fisher 分布。构造以下三种污染数据生成过程:
 - (a) ϵ -contamination with outliers far from true mean;
 - (b) ϵ -contamination with a shift in circular mean;
 - (c) mixture of two von Mises-Fisher distributions.

在每种情形下，分别计算 Bayesian RPETEL 后验的 95% 置信区间的覆盖率，并与标准贝叶斯后验对比。验证 section 3.2.4 中的三个稳健性声明。

- (7) **混合时间的维度依赖**。设流形为 $\mathcal{M} = \mathbb{S}^{d-1}$ (单位球面)，目标分布为 von Mises-Fisher 分布。通过数值模拟，研究 RRWM 的有效样本量 (ESS) 随维度 d 和样本量 n 的变化关系。具体而言，固定 $n = 500$ ，取 $d \in \{5, 10, 20, 50\}$ ，绘制 ESS 随 d 的变化曲线，并验证理论预测： $\text{ESS} \asymp d^{-1}$ 。(提示：ESS 的估计可采用 coda 包中的 `effectiveSize` 函数。)
- (8) **与 MALA 的联系 ((Tang and Yang, 2024b))**。查阅 (Tang and Yang, 2024b) 的相关结果，解释为何 RRWM 的混合时间具有 $O(d \log d)$ 依赖，而 MALA 的混合时间具有 $O(d^{1/3})$ 依赖。这两种算法分别在何种场景下更具优势？提示：MALA 利用梯度信息 (score function) 构造 proposals，而 RRWM 仅使用零阶信息 (目标函数值)。

分布回归的极小极大速率

1. 引言

分布回归 (distribution regression) 的目标是：给定协变量 $X \in \mathbb{R}^{D_X}$ ，估计响应变量 $Y \in \mathbb{R}^{D_Y}$ 的条件分布 $\mu_{Y|X=x}^*$ 。与传统的标量回归或分类不同，分布回归恢复的是完整的条件分布，从而可以刻画条件变异性、偏度、多峰性和不确定性等丰富信息，在生物医学、气候建模和计量经济学中有广泛应用。

传统非参数密度回归方法存在两个根本性局限：

- (1) **存在性假设**：要求 $\mu_{Y|X=x}^*$ 关于 Lebesgue 测度绝对连续——当 Y 含离散分量或支撑于高维空间中的低维流形时，该假设失效。
- (2) **维度灾难**：环境维度 D_X, D_Y 主导收敛速率，对现代高维数据（图像、文本、点云）效率极低。

本文 (Tang and Yang, 2025) 的核心贡献在于放弃 $\mu_{Y|X=x}^*$ 须有密度的假设，转而假设 $\mu_{Y|X=x}^*$ 支撑于某个低维流形 $\mathcal{M}_{Y|x}$ 上，从而同时处理奇异分布（流形支撑）和密度函数（光滑条件密度）两类信息。

与条件密度估计的关系：传统条件密度估计 (conditional density estimation) 假设 $\mu_{Y|X=x}^*$ 有密度 $u^*(y|x)$ ，关注光滑性假设下 $n^{-1/2}$ 到 n^{-1} 之间的收敛速率 (Hyndman et al., 1995; Li and Li, 2022)。本文则将问题推广到：

- $\mu_{Y|X=x}^*$ 可无密度（流形支撑），须用 IPM 度量；
- 收敛速率仅依赖内在维度 d_X, d_Y 而非环境维度 D_X, D_Y ；
- γ -Hölder IPM 统一了全变差 ($\gamma = 0$) 和 Wasserstein ($\gamma = 1$) 距离。

γ -Hölder IPM 的统一作用：给定光滑度参数 $\gamma \geq 0$ ， γ -Hölder IPM 定义为

$$(8) \quad d_\gamma(\mu, \nu) = \sup_{f \in \mathcal{H}_1^\gamma(\mathbb{R}^{D_Y})} \left| \int f(y) d\mu - \int f(y) d\nu \right|,$$

其中 $\mathcal{H}_1^\gamma(\mathbb{R}^{D_Y})$ 为单位半径的 γ -Hölder 函数类。特别地：

- $\gamma = 0$ ： d_0 退化为全变差距离 d_{TV} ；
- $\gamma = 1$ ： d_1 等价于 1-Wasserstein 距离 W_1 (Kantorovich-Rubinstein 定理)。

参数 γ 调控度量对局部细节的敏感度： γ 越大，测试函数越光滑，越能忽略局部起伏（如支撑不完全对齐）； γ 越小， d_γ 对密度局部变化越敏感。

2. 数学框架

2.1. 基本设定. 设

- 协变量 $X \sim \mu_X^*$ ，支撑于 $\mathbb{R}^{D_X}$ 中的 d_X 维子流形 $\mathcal{M}_X$ ；
- 给定 $X = x$ ，响应 $Y \sim \mu_{Y|X=x}^*$ ，支撑于 $\mathbb{R}^{D_Y}$ 中的 d_Y 维 β_Y -光滑子流形 $\mathcal{M}_{Y|x}$ ；
- 数据 $\{(X_i, Y_i)\}_{i=1}^n$ 为来自 $\mu^* = \mu_X^* \mu_{Y|X}^*$ 的 n 个 i.i.d. 样本。

定义 3.1 (协变量空间的 Minkowski 维数). 称拓扑空间 $\mathcal{M}_X \subset \mathbb{R}^{D_X}$ 的 *Minkowski* 维数至多为 d_X (记 $\mathcal{M}_X \in \mathcal{M}_X(D_X, d_X, L)$), 若 $\mathcal{M}_X \subset \mathbb{B}_{\mathbb{R}^{D_X}}(\mathbf{0}, L)$, 且对任意 $0 < \varepsilon \leq 1$, $\mathcal{M}_X$ 的最大 ε -packing 基数至多为 $L\varepsilon^{-d_X}$.

该定义比子流形假设更宽松——不要求 $\mathcal{M}_X$ 光滑或有正 reach。

定义 3.2 (边缘光滑函数类). 称二元函数 $u^* : \mathcal{M}_Y \times \mathcal{M}_X \rightarrow \mathbb{R}_+$ 属于 **边缘光滑函数类** $\overline{\mathcal{H}}_L^{\alpha_Y, \alpha_X}(\mathcal{M}_Y, \mathcal{M}_X)$, 若

- (1) 对任意 $y \in \mathcal{M}_Y$, $u^*(\cdot|y) \in \mathcal{H}_L^{\alpha_Y}(\mathcal{M}_Y)$ (关于 y 为 α_Y -光滑);
- (2) 对任意 $x \in \mathcal{M}_X$, $u^*(\cdot|x) \in \mathcal{H}_L^{\alpha_X}(\mathcal{M}_X)$ (关于 x 为 α_X -光滑)。

此定义刻画了条件密度在不同方向上具有独立光滑度的情形。

评估条件分布估计量 $\hat{\mu}_{Y|X}$ 的整体质量采用 **期望 γ -Hölder IPM**:

$$(9) \quad \mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|X}^*, \hat{\mu}_{Y|X})] = \int_{\mathcal{M}_X} d_\gamma(\mu_{Y|X=x}^*, \hat{\mu}_{Y|X=x}) d\mu_X^*(x).$$

3. Regime 1: 经典密度回归

本节考虑最简设定: 响应空间无流形结构, 即 $\mathcal{M}_{Y|x} = \mathbb{R}^{D_Y}$, $\mu_{Y|x}^*$ 对 Lebesgue 测度绝对连续。此为经典密度回归设定, 与条件密度估计直接对应。

定义 3.3 (Regime 1: 欧氏响应空间). 给定维度 $D_Y, D_X \in \mathbb{N}_+$, $d_X \in \mathbb{N} \cap [0, D_X]$ 、光滑度参数 $\alpha_Y, \alpha_X \in (0, \infty)$ 和常数 $L > 0$, 定义分布族

$$\mathcal{P}_1^* = \mathcal{P}_1^*(D_Y, D_X, d_X, \alpha_Y, \alpha_X, L)$$

为满足以下条件的联合分布 $\mu^* = \mu_X^* \mu_{Y|X}^*$ 构成的集合:

- (1) μ_X^* 的支撑 $\mathcal{M}_X \in \mathcal{M}_X(D_X, d_X, L)$, μ_Y^* 的支撑含于 $\mathbb{B}_{\mathbb{R}^{D_Y}}(\mathbf{0}, L)$;
- (2) 对任意 $x \in \mathcal{M}_X$, $\mu_{Y|x}^*$ 有密度函数 $u^*(\cdot|x)$, 且 $u^*(y|x) \in \overline{\mathcal{H}}_L^{\alpha_Y, \alpha_X}(\mathbb{R}^{D_Y}, \mathcal{M}_X)$ 。

注 3.1. $d_X = 0$ 对应 X 为离散变量 (取有限个值), 此时 α_X 的光滑性条件自动满足, 极小极大速率简化为 $n^{-(\alpha_Y + \gamma)/(2\alpha_Y + D_Y)}$, 即 (Li and Li, 2022) 的无条件密度估计结果。

3.1. 极小极大速率.

定理 3.1 (Regime 1 的极小极大速率 (Tang and Yang, 2025)). 对任意 $\gamma \geq 0$, 存在常数 L_0 , 使得当 $L, n \geq L_0$ 时,

$$(10) \quad \begin{aligned} & C \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + D_Y + \frac{\alpha_Y}{\alpha_X} d_X}} \right) \\ & \leq \inf_{\hat{\mu}_{Y|X}} \sup_{\mu^* \in \mathcal{P}_1^*} \mathbb{E}_{\mu^*, \otimes n} [\mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|X}^*, \hat{\mu}_{Y|X})]] \\ & \leq C_1 \tilde{O} \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + D_Y + \frac{\alpha_Y}{\alpha_X} d_X}} \right), \end{aligned}$$

其中 C, C_1 为与 n 无关的常数, $\tilde{O}$ 忽略对数因子。

速率的两项意义:

- (1) **第一项** $n^{-\alpha_X/(2\alpha_X + d_X)}$: 对应 α_X -光滑条件均值函数在 L_2 损失下的经典极小极大速率 (Stone, 1982)。 γ 越大, 该项越可能主导——因为光滑测试函数抹平了条件密度的局部起伏, d_γ 主要响应 X 与 Y 之间的全局依赖趋势。

- (2) **第二项** $n^{-(\alpha_Y + \gamma)/(2\alpha_Y + D_Y + \alpha_Y d_X / \alpha_X)}$: 反映非参数条件密度估计的固有难度。 α_Y 越大（密度越光滑）或 d_X, D_Y 越小，速率越快； γ 越大， d_γ 对局部细节越不敏感，密度估计难度降低。

与已有文献的关系: (Tang and Yang, 2025) 的结果改进了 (Bilodeau et al., 2023) 的上界（在 $\gamma = 0$ 时给出更紧的全变差速率）并拓展了 (Li and Li, 2022) 的结果（仅覆盖 $\alpha_X \in [0, 1]$ ）；(Tang and Yang, 2024a) 中条件扩散模型的收敛速率在 $\gamma = 1$ 时与本定理上界匹配，结合下界可知条件扩散模型在期望 1-Wasserstein 距离下是极小极大最优的。

4. Regime 2: 响应空间为协变量无关流形

本节将设定推广到 Y 支撑于低维流形上的情形，但假设 $\mathcal{M}_{Y|x} = \mathcal{M}_Y$ 不依赖于 x ——此时问题从密度回归变为分布回归，且须同时估计未知流形 $\mathcal{M}_Y$ 。

流形上的密度函数须关于流形体积测度而非 Lebesgue 测度定义，这使得经典的核密度估计不再适用。

定义 3.4 (Regime 2: 协变量无关的流形响应空间). 给定维度参数 $D_Y, d_Y, D_X \in \mathbb{N}_+$, $d_X \in \mathbb{N}_0$ 、光滑度 $\beta_Y, \alpha_Y, \alpha_X > 0$ 、函数 $g: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ 和常数 $\tau, \tau_1, L > 0$ ，定义分布族

$$\mathcal{P}_2^* = \mathcal{P}_2^*(D_Y, D_X, d_Y, d_X, \beta_Y, \alpha_Y, \alpha_X, \tau, \tau_1, g, L)$$

为满足以下条件的 $\mu^* = \mu_X^* \mu_{Y|x}^*$ 构成的集合：

- (1) $\mathcal{M}_X \in \mathcal{M}_X(D_X, d_X, L)$;
- (2) 对任意 $x \in \mathcal{M}_X$ ， $\mu_{Y|x}^*$ 支撑于与 x 无关的子流形 $\mathcal{M}_Y$ 上，且有相对于 $\mathcal{M}_Y$ 体积测度的密度函数 $u^*(\cdot|x)$ ，其中 $\mathcal{M}_Y \in \mathcal{M}_{\tau, \tau_1, L}^{\beta_Y}(d_Y, D_Y)$ (d_Y 维、 β_Y -光滑子流形)， $u^* \in \overline{\mathcal{H}}_L^{\alpha_Y, \alpha_X}(\mathcal{M}_Y, \mathcal{M}_X)$;
- (3) 下界条件: 对任意 $x_0 \in \mathcal{M}_X, y_0 \in \mathcal{M}_Y$ 和 $0 < r \leq 1$ ， $\mu_X^*(\mathbb{B}_{\mathcal{M}_X}(x_0, r)) \geq g(r)r^{d_X}/L$ 且 $\mu_{Y|x_0}^*(\mathbb{B}_{\mathcal{M}_Y}(y_0, r)) \geq g(r)r^{d_Y}/L$ 。

条件 $\beta_Y \geq 2$ 保证 $\mathcal{M}_Y$ 曲率有界； $\beta_Y \geq \alpha_Y + 1$ 保证 α_Y 光滑性与局部坐标卡的选择无关。

注 3.2. 在 *Regime 2* 中，由于 $\hat{\mu}_{Y|x}$ 与 $\mu_{Y|x}^*$ 几乎必然相互奇异（支撑在不同流形上），全变差距离恒为 1，无法反映估计质量——因此 *Regime 2* 须要求 $\gamma > 0$ （即使用非平凡光滑测试函数）。这凸显了 *IPM* 框架比全变差距离更适用于流形支撑数据的重要性。

4.1. 极小极大速率.

定理 3.2 (Regime 2 的极小极大速率 (Tang and Yang, 2025)). 对任意 $\gamma > 0$ 和 $\beta_Y \geq 2 \vee (\alpha_Y + 1)$ ，存在常数 L_0 ，使得当 $L, \tau, \tau_1, n \geq L_0$ 时，

$$\begin{aligned}
 & C \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + d_Y + \frac{\alpha_Y}{\alpha_X} d_X}} + n^{-\frac{\gamma\beta_Y}{d_Y}} \right) \\
 (11) \quad & \leq \inf_{\hat{\mu}_{Y|x}} \sup_{\mu^* \in \mathcal{P}_2^*} \mathbb{E}_{\mu^*, \otimes n} [\mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|x}^*, \hat{\mu}_{Y|x})]] \\
 & \leq C_1 (\log n)^3 \tilde{\mathcal{O}} \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + d_Y + \frac{\alpha_Y}{\alpha_X} d_X}} + n^{-\frac{\gamma\beta_Y}{d_Y}} \right).
 \end{aligned}$$

与 Regime 1 的对比: Regime 2 的速率多了第三项 $n^{-\gamma\beta_Y/d_Y}$ ，反映了对未知流形 $\mathcal{M}_Y$ 进行支撑估计的固有难度。当 γ 较小（ d_γ 对支撑几何敏感）时，该项主导误差——这正是 d_γ 度量奇异分布的独特之处。

关键现象—— γ 决定三项竞争：随着 γ 从 0 增大，Regime 2 的主导误差项经历两次相变：

- **第一次相变** (γ 较小)： d_γ 对支撑错位敏感，主导项为流形估计项 $n^{-\gamma\beta_Y/d_Y} \iff$ 条件密度估计项 $n^{-(\alpha_Y+\gamma)/(2\alpha_Y+d_Y+\alpha_Y d_X/\alpha_X)}$ ；
- **第二次相变** (γ 较大)： d_γ 进一步光滑化，主导项变为 $n^{-\alpha_X/(2\alpha_X+d_X)}$ ——此时问题退化为 α_X -光滑条件均值估计。

注 3.3. 关键发现： D_Y 完全不出现在 *Regime 2* 的速率指数中。仅 d_Y (流形本征维度)、 β_Y (流形光滑度) 和内在几何参数决定收敛速率。这正是内在维度 *vs* 环境维度的核心体现——流形结构将高维环境空间中的估计问题”降维”为低维本征空间中的问题。

5. Regime 3: 协变量依赖流形

本节研究最一般设定：响应流形 $\mathcal{M}_{Y|x}$ 随 x 光滑变化——这将问题从单一流形估计推广为流形回归。

5.1. 协变量依赖流形的形式定义.

定义 3.5 ((β_Y, β_X)-光滑子流形族). 称 $\{\mathcal{M}_{Y|x} : x \in \mathcal{M}_X\}$ 为 (β_Y, β_X) -光滑的 d_Y 维子流形族，若存在常数 $\tau, \tau_1, L > 0$ 使得：对每个 $x \in \mathcal{M}_X$ ， $\mathcal{M}_{Y|x} \in \mathcal{M}_{\tau, \tau_1, L}^{\beta_Y}(d_Y, D_Y)$ ，且对任意 $x, x' \in \mathcal{M}_X$ ，

$$\mathbb{H}(\mathcal{M}_{Y|x}, \mathcal{M}_{Y|x'}) \leq L \|x - x'\|^{\beta_X/\beta_Y},$$

其中 $\mathbb{H}$ 为 *Hausdorff* 距离。

直观例子：考虑人脸图像数据 Y 以年龄和性别 X 为条件的情形。对固定的 X ， Y 的支撑自然位于某低维图像子流形；而不同年龄段对应的流形差异较大，这正构成协变量依赖流形族。

5.2. Regime 3a: 纯流形回归. 为建立 Regime 3b 的下界，先研究纯流形回归问题——仅估计 $\{\mathcal{M}_{Y|x}\}$ 而不计密度。

定理 3.3 (流形回归的极小极大速率). 假设 $\beta_Y \geq 2$ 和 $\beta_Y \geq \beta_X$ ，则存在常数 L_0 ，使得当 $L, \tau, \tau_1, n \geq L_0$ 时，

$$(12) \quad C n^{-\frac{1}{\frac{d_Y}{\beta_Y} + \frac{d_X}{\beta_X}}} \leq \inf_{\{\widehat{\mathcal{M}}_{Y|x}\}} \sup_{\mu^* \in \mathcal{P}^*} \mathbb{E}_{\mu^*, \otimes n} \left[\sup_{x \in \mathcal{M}_X} \mathbb{H}(\mathcal{M}_{Y|x}, \widehat{\mathcal{M}}_{Y|x}) \right] \leq C_1 \left(\frac{n}{\log n} \right)^{-\frac{1}{\frac{d_Y}{\beta_Y} + \frac{d_X}{\beta_X}}}.$$

与单一流形估计的极小极大速率 $n^{-1/(d_Y/\beta_Y)}$ (Aamari and Levrard, 2019) 相比，流形回归多了 d_X/β_X 项，反映了估计整个流形族的额外复杂度。 β_X 越大 ($\mathcal{M}_{Y|x}$ 随 x 变化越慢)，分母越大，速率越快——这与直觉一致。

估计策略¹：

¹详见 (Tang and Yang, 2025, Section 4.1)。推广了 (Aamari and Levrard, 2019) 的局部多项式估计量，对每个数据点 $w_k = (X_k, Y_k)$ ，选取满足 $\|Y - Y_k\| \leq h_1$ 和 $\|X - X_k\| \leq h_2$ 的邻域样本，其中 $h_1 \asymp (\log n/n)^{\frac{\beta_X}{d_Y\beta_X+d_X\beta_Y}}$ 、 $h_2 \asymp (\log n/n)^{\frac{\beta_Y}{d_Y\beta_X+d_X\beta_Y}}$ ，然后通过最小化重建损失学习局部多项式估计量。

5.3. Regime 3b: 协变量依赖流形上的分布回归. 现在回到完整的分布回归问题, 但此时 $\mathcal{M}_{Y|x}$ 依赖 x 。

定理 3.4 (Regime 3b 的极小极大速率). 对任意 $\gamma > 0$, 若 $\beta_Y \geq 2 \vee (\alpha_Y + 1) \vee \beta_X$, $\beta_X \geq \alpha_X + \frac{\alpha_X}{\alpha_Y}$ 且 $\alpha_Y \geq \alpha_X$, 则存在常数 L_0 , 使得当 $L, \tau, \tau_1, n \geq L_0$ 时,

$$(13) \quad \begin{aligned} & C \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + d_Y + \frac{\alpha_Y}{\alpha_X} d_X}} + n^{-\frac{\gamma}{\frac{d_Y}{\beta_Y} + \frac{d_X}{\beta_X}}} \right) \\ & \leq \inf_{\hat{\mu}_{Y|x}} \sup_{\mu^* \in \mathcal{P}_3^*} \mathbb{E}_{\mu^*, \otimes n} [\mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|x}^*, \hat{\mu}_{Y|x})]] \\ & \leq C_1 \tilde{\mathcal{O}} \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + d_Y + \frac{\alpha_Y}{\alpha_X} d_X}} + n^{-\frac{\gamma}{\frac{d_Y}{\beta_Y} + \frac{d_X}{\beta_X}}} \right). \end{aligned}$$

与 Regime 2 的关键区别: Regime 3b 的第三项为 $n^{-\gamma/(d_Y/\beta_Y + d_X/\beta_X)}$, 而非 Regime 2 中的 $n^{-\gamma\beta_Y/d_Y}$ 。这一替换将单一流形估计的复杂度 d_Y/β_Y 推广为流形回归的复杂度 $d_Y/\beta_Y + d_X/\beta_X$ ——几何参数 $d_Y, \beta_Y, d_X, \beta_X$ 共同决定收敛速率。

几何参数的物理意义:

- d_Y 越小: 响应流形本征维度越低, 估计越容易;
- β_Y 越大: $\mathcal{M}_{Y|x}$ 越光滑, 其几何特征越规则, 支撑估计越容易;
- d_X 越小: 协变量空间复杂度越低;
- β_X 越大: $\mathcal{M}_{Y|x}$ 随 x 变化越慢, 允许跨 x 值的信息共享更充分。

注 3.4. 三个 Regime 的极小极大速率可统一理解为三项的取大:

- (1) $n^{-\alpha_X/(2\alpha_X + d_X)}$: 协变量效应;
- (2) $n^{-(\alpha_Y + \gamma)/(2\alpha_Y + d_Y + \alpha_Y d_X/\alpha_X)}$: 密度效应;
- (3) 流形支撑效应 (Regime 依赖): Regime 2 为 $n^{-\gamma\beta_Y/d_Y}$, Regime 3b 为 $n^{-\gamma/(d_Y/\beta_Y + d_X/\beta_X)}$ 。

当 γ 足够大时, 前两项之一主导; 当 γ 较小时, 支撑估计项主导——这正是 d_γ 度量奇异分布的核心挑战。

6. 极小极大最优估计量

本文不仅建立了极小极大下界, 还提出了融合对抗学习 (adversarial learning) 与同步最小二乘的 **混合估计量**, 在各 Regime 下均达上界 (至多对数因子)。

6.1. Euclid 响应空间的估计量 (Regime 1). 估计量基于小波展开和局部多项式回归。对条件密度 $u^*(y|x)$ 在 y 方向做小波分解, 在 x 方向做局部多项式逼近。

核心思想: 对每个小波基 $\psi \in \Psi_j^{D_Y}$ 在尺度 j , 估计条件期望 $\mathbb{E}_{\mu_{Y|x}^*}[\psi(Y)]$ ——这本身是一个非参数回归问题, 但 $u^*(\cdot|x)$ 的 α_X -光滑性允许用局部多项式有效逼近。

构造条件密度估计量:

$$(14) \quad \hat{u}(y|x) = \sum_{j=0}^J \sum_{\psi \in \Psi_j^{D_Y}} \hat{u}_\psi(x) \psi(y), \quad x \in \mathcal{M}_X,$$

其中 $\hat{u}_\psi(x)$ 通过局部多项式回归获得。截断水平 J 的选择:

$$(15) \quad J \asymp \frac{1}{2\alpha_Y + D_Y + d_X \frac{\alpha_Y}{\alpha_X}} \log_2 \left(\frac{n}{\log n} \right).$$

定理 3.5 (Regime 1 估计量的收敛速率). 在 $\mathcal{P}_1^*$ 假设下, 对任意 $\gamma \geq 0$, eq. (14) 定义的条件密度估计量满足

$$(16) \quad \mathbb{E}_{\mu_X^*} [d_\gamma(\mu_{Y|X}^*, \hat{\mu}_{Y|X})] \leq C_\gamma \tilde{\mathcal{O}} \left(n^{-\frac{\alpha_X}{2\alpha_X + d_X}} + n^{-\frac{\alpha_Y + \gamma}{2\alpha_Y + D_Y + \frac{\alpha_Y}{\alpha_X} d_X}} \right),$$

以至少 $1 - n^{-1}$ 的概率成立。速率与 eq. (10) 上界匹配, 故为极小极大最优。

与扩散模型的深层联系²:

6.2. 流形响应空间的估计量 (Regime 2 和 3b). 当 $\mathcal{M}_{Y|x}$ 为流形时, 条件密度关于 Lebesgue 测度不存在, 须将问题重新表述为对条件期望泛函

$$\mathcal{T}^*(f, x) = \mathbb{E}_{\mu_{Y|x}^*} [f(Y)], \quad f \in \mathcal{H}_1^\gamma(\mathbb{R}^{D_Y})$$

的同步估计。

两步走策略:

步骤 1 (粗糙尺度): 将小波函数截断到 J 层, 估计 $\mathbb{E}_{\mu_{Y|x}^*} [f_J(Y)]$, 其中 f_J 为 f 的粗糙 (小波) 逼近。由于 f_J 变化缓慢, 可将 $\mu_{Y|x}^*$ 视为有密度, 使用局部多项式回归构造条件密度估计量。

关键改进: 对每个 j 水平, 同时估计所有小波系数的条件期望, 构建**联合均值回归问题**:

$$(17) \quad \hat{S}_j^\dagger = \arg \min_{S \in \mathcal{S}_j^\dagger} \frac{1}{n} \sum_{i=1}^n \sum_{\psi \in \Psi_j^{D_Y}} \left(2^{\frac{j(d_Y - D_Y)}{2}} \psi(Y_i) - S(\psi, X_i) \right)^2,$$

其中 $\mathcal{S}_j^\dagger$ 为特定的非可分逼近族。与分别独立估计每个小波系数不同, 联合估计利用了流形结构固有的稀疏性——只有部分小波函数在 $\mathcal{M}_{Y|x}$ 上有非零条件均值。

引理 3.1 (联合 vs 独立估计的最优性). 在 *Regime 2* 中, 令 $\hat{u}_j(x)$ 为独立估计得到的各尺度条件密度, $\hat{u}_j^\dagger(x)$ 为联合估计得到的条件密度。则

$$\mathbb{E} \left[|\hat{u}_j^\dagger(x) - u^*(y|x)|^2 \right] \leq \mathbb{E} \left[|\hat{u}_j(x) - u^*(y|x)|^2 \right] \quad (\text{至多差常数因子}),$$

且在某些构造下严格更优。详见 (Tang and Yang, 2025, Appendix B.2.3)。

步骤 2 (精细尺度): 对 $f_J^\perp$, 采用显式流形估计步骤。学习编码器 $Q: \mathbb{R}^{D_Y} \rightarrow \mathbb{R}^{d_Y}$ 和条件解码器 $G: \mathbb{R}^{d_Y} \times \mathbb{R}^{D_X} \rightarrow \mathbb{R}^{D_Y}$, 使得 $y \approx G(Q(y), x)$ 在局部成立。将数据映射到潜在空间 $\mathbb{R}^{d_Y}$, 在其中进行密度回归。

注 3.5. 这种编码器-解码器框架正是潜扩散模型 (*latent diffusion models*) (Rombach et al., 2022)、变分自编码器 (VAE) (Kingma and Welling, 2013) 和 Wasserstein 自编码器 (Tolstikhin et al., 2017) 的理论基础——本文从统计估计的角度严格证明了该框架的理论最优性。

7. 技术要点

本节详细介绍极小极大下界和上界证明的核心技术工具。

²详见 (Tang and Yang, 2025, Section 3.3)。多分辨率小波分析与分数阶前向-后向扩散模型之间存在深刻类比: 小波分解中不同尺度 j 捕获从全局趋势到局部细节的层次结构, 正好对应扩散模型中时间变量 t 从 0 到 T 的演化过程。条件扩散模型的每步去噪可视为在某一分辨率水平上的条件均值估计。

7.1. Fano 不等式与 Varshamov-Gilbert 引理. 极小极大下界证明的第一步是将估计问题规约到多假设检验问题。设 $\mathcal{Q}$ 为一族难以区分的分布（或流形-密度对），则估计误差的下界由区分这些分布所需的最小信息量决定。

Fano 不等式³:

引理 3.2 (广义 Fano 不等式). 设 $\mathcal{P} = \{P_0, P_1, \dots, P_M\}$ 为 $M+1$ 个概率分布，任意两个分布 P_j, P_k 之间的 Hellinger 距离满足 $H(P_j, P_k) \leq \epsilon$ ，且 P_0 为参考分布。记 $\Phi: \mathcal{P} \rightarrow \{0, 1, \dots, M\}$ 为任意检验函数。则

$$\inf_{\Phi} \max_{j \in \{0, 1, \dots, M\}} P_j(\Phi(X) \neq j) \geq \frac{1}{2} \left(1 - \frac{I(X; J) + \epsilon^2}{\log(M+1)} \right),$$

其中 $I(X; J)$ 为 X 与指标 J 之间的互信息。

Varshamov-Gilbert 引理（用于构造难以区分的假设序列）:

引理 3.3 (Varshamov-Gilbert 引理). 设 $\mathcal{M}$ 为紧致 d 维黎曼子流形，半径为 s 的球的最大 packing 基数为 $N \asymp (C/s)^d$ 。存在 $\{0, 1\}^m$ 上的 Hamming 子集 $\mathcal{V}$ （即“错误模式”集合），满足 $|\mathcal{V}| \geq 2^m$ 且 $\rho(v, w) \geq m/10$ 对任意 $v \neq w \in \mathcal{V}$ ，其中 ρ 为 Hamming 距离。将 $\mathcal{V}$ 的每个顶点映射到 $\mathcal{M}$ 上适当分离的点，得到 $N \asymp 2^m$ 个相互之间距离至少为 δ 的分布。

注 3.6 在 Regime 2 的下界证明中，通过 Varshamov-Gilbert 引理在 d_Y 维流形上构造 $N \asymp \exp(cn\epsilon^2)$ 个难以区分的备择分布。具体地：设 $m \asymp n\epsilon^2$ ，则 packings 的尺度为 $s \asymp n^{-1/(2m)}$ ，利用流形的覆盖数性质可得所需下界。

注 3.6. Varshamov-Gilbert 引理的几何意义是：在 d 维流形上，以分辨率 δ 进行离散化，可以构造 $\asymp \delta^{-d}$ 个相互可区分的“模式” (mode)。当 n 个样本不足以区分如此多的模式时，任何估计量的误差必然至少为 δ ——这正是极小极大下界的来源。

将 Fano 不等式与 Varshamov-Gilbert 引理结合的标准流程为：(1) 在参数空间（流形 + 密度函数）中构造一组合法的分布 $\{P_v : v \in \mathcal{V}\}$ ；(2) 证明任意两个分布之间的 KL 散度或 Hellinger 距离受限于 $O(\epsilon^2/n)$ ；(3) 应用 Fano 不等式得到检验误差下界；(4) 通过 Le Cam 引理将检验下界转化为估计下界。

7.2. 热核平滑. 在 Regime 2 和 Regime 3 的上界证明中，热核平滑是连接流形几何与概率度量的核心技术。

热核的定义: 设 $\mathcal{M}$ 为紧致黎曼流形，其热核 (heat kernel) $p_t(x, y)$ 为热方程 $\frac{\partial}{\partial t} p_t(x, y) = \Delta_{\mathcal{M}} p_t(x, y)$ 的基本解，其中 $\Delta_{\mathcal{M}}$ 为拉普拉斯-贝尔特拉米算子。热核满足以下基本性质：

- (1) $\int_{\mathcal{M}} p_t(x, y) dy = 1$ (守恒性)；
- (2) $p_t(x, y) \asymp t^{-d/2} \exp(-C \|x - y\|^2/t)$ (短时间近似)；
- (3) $\|p_t(\cdot, x) - p_t(\cdot, y)\|_{TV} \asymp \|x - y\|/\sqrt{t}$ (Li-Yau 不等式)。

热核平滑的核心思想: 给定流形 $\mathcal{M}$ 上的原始分布 μ^* ，定义其热核平滑版本

$$\mu_t^*(\cdot) = \int_{\mathcal{M}} p_t(\cdot, y) d\mu^*(y).$$

热核平滑的作用是将奇异分布（流形支撑）转化为关于 Lebesgue 测度绝对连续的分布，从而允许使用标准的密度估计技术。

³详见 (Tang and Yang, 2025) 引理 7 (Generalized Fano)。

引理 3.4 (热核平滑的逼近误差). 设 μ^* 支撑于 β -光滑子流形 $\mathcal{M}$ 上, d_Y 维, 截面曲率有界. 对任意 $\gamma \in [0, \beta]$ 和光滑测试函数 $f \in \mathcal{H}_1^\gamma$,

$$\left| \int f(y) d\mu^*(y) - \int f(y) d\mu_t^*(y) \right| \leq C \|f\|_{\mathcal{H}^\gamma} t^{\gamma/\beta}.$$

注 3.7 的含义是: 热核平滑后的分布与原始分布之间的 IPM 距离以 $t^{\gamma/\beta}$ 为界. 特别地, 当 $t \asymp n^{-\gamma\beta/d_Y}$ 时, 平滑误差与样本误差量级相同——这正是 Regime 2 第三项 $n^{-\gamma\beta_Y/d_Y}$ 的来源.

注 3.7. 热核平滑提供了处理流形支撑数据的统一技术: (Tang and Yang, 2022) 用热核平滑建立流形分布估计的极小极大下界; (Tang and Yang, 2023b) 用热核正则化构造全变差意义下的最优检验统计量; 本文 (Tang and Yang, 2025) 则将热核平滑与 IPM 框架结合, 统一处理 Regime 2 和 3 中的流形估计项.

7.3. 上界证明技术.

- (1) **小波分解**: 将测试函数分解为粗糙和精细分量, 分别处理;
- (2) **局部多项式回归**: 利用 α_X -光滑性控制粗糙尺度的逼近误差;
- (3) **单位分解 (Partition of Unity)**: 在无全局参数化的流形上构造局部估计量, 并光滑拼接——这是 (Tang and Yang, 2022) 发展的核心技术;
- (4) **Talagrand 集中不等式**: 控制经验过程偏离均值的高概率界;
- (5) **联合估计 vs 独立估计**: Regime 2 估计量采用联合均值回归而非分别估计各小波系数, 关键在于利用了流形结构的稀疏性——独立估计忽略了不同小波系数之间的几何依赖 (见 eq. (17)).

8. 内在维度 vs 环境维度分析

本节集中阐述本文最重要的统计发现: 为何收敛速率只依赖 d_X, d_Y , 而完全不受 D_X, D_Y 影响.

注 3.8. 三个 Regime 的极小极大速率中, 环境维度 D_X, D_Y 仅出现在 Regime 1 的第二项中 (作为 α_Y 的系数出现). 在 Regime 2 和 Regime 3b 中, D_Y 完全消失, 速率仅由内在维度 d_X, d_Y 和光滑度参数决定. 这一现象的本质原因是:

- (1) 流形 $\mathcal{M}_X \in \mathcal{M}_X(D_X, d_X, L)$ 的 Minkowski 维数为 d_X , 与环境维度 D_X 无关——这是维度降维的第一层;
- (2) IPM d_γ 通过对抗测试函数类 $\mathcal{H}_1^\gamma(\mathbb{R}^{D_Y})$ 自然地适应流形结构——光滑测试函数在远离流形处无作用, 仅在流形的 d_Y 维邻域内有效发挥作用;
- (3) 热核平滑将流形上的奇异分布转化为 d_Y 维空间中的密度估计问题, 完全绕过了 D_Y 的影响.

9. 与系列工作的联系

本章结果在 Tang-Rong 系列中的地位:

- (1) **与 (Tang and Yang, 2022) (Annals 2022) 的关系**: 极小极大理论框架相同 (γ -Hölder IPM、三项取大结构), 但本文从无条件的流形分布估计推广到协变量条件设定.
- (2) **与 (Tang and Yang, 2023a) (ICML 2023) 的关系**: MLDMAE 方法是 Regime 2 上界的具体算法实现, 验证了单位分解 + 混合局部估计策略的实践有效性.

- (3) **与 (Tang and Yang, 2024a) (AISTATS 2024) 的关系**: 条件扩散模型在 Wasserstein 距离 ($\gamma = 1$) 下与 Regime 1 上界匹配, 证明了扩散模型的极小极大最优性。
- (4) **与 (Tang et al., 2025) (arXiv 2025) 的关系**: 条件扩散模型在流形设定下的收敛速率与 Regime 3b 的极小极大速率对照——实践工具能否在一般 γ 下达到最优仍是开放问题。

10. 开放问题

基于本章结果, 以下问题值得进一步研究:

- (1) **$\gamma \in (0, 1)$ 时的可计算估计量**: 混合估计量在 $\gamma \neq 0, 1$ 时涉及无穷维对抗优化, 实践中如何有效实现? IPM 判别器的逼近误差如何量化?
- (2) **流形维数自适应**: 本文假设 d_X, d_Y 已知; 如何构造对这些参数同时自适应的估计量? Lepski 方法能否扩展到分布回归设定?
- (3) **α_X -自适应**: 极小极大速率依赖于 α_X, α_Y 等光滑度参数, 构造对所有光滑度同时自适应的估计量是重要挑战。
- (4) **噪声观测情形**: 本文考虑无噪声观测 (X_i, Y_i 精确采样); 测量噪声或标签噪声下的极小极大速率是什么?
- (5) **流形回归与分布回归的统一理论**: Regime 3a (纯流形回归) 和 Regime 3b (带密度) 是否可以统一在一个更简洁的框架下?
- (6) **深度生成模型与 IPM 的结合**: 当前理论主要围绕 Wasserstein 距离和全变差距离; 对 MMD、Stein 差异等更一般的 IPM, 深度生成模型能否达到相应的极小极大速率?

11. 小结

本章系统介绍了 (Tang and Yang, 2025) 关于分布回归极小极速率的理论。

核心贡献:

- (1) **统一框架**: γ -Hölder IPM 统一了全变差距离和 Wasserstein 距离, 使得同一套理论可分析多种概率度量下的估计问题。
- (2) **三类 Regime**: 根据 $\mathcal{M}_{Y|x}$ 与 x 的关系, 建立了从经典密度回归到协变量依赖流形回归的层次化理论, 各 Regime 的极小极速率清晰刻画。
- (3) **几何参数决定复杂度**: 收敛速率由 $d_X, d_Y, \beta_X, \beta_Y, \alpha_X, \alpha_Y, \gamma$ 等参数的特定组合决定, 揭示了低维流形结构如何缓解维度灾难。
- (4) **最优估计量**: 提出了融合对抗学习与同步最小二乘的混合估计量, 在各 Regime 下均达极小极上界 (至多对数因子), 为条件生成模型提供了理论基础。

关键洞见: 流形支撑与密度的联合估计是分布回归的核心挑战; γ 的选择决定了“关注支撑”与“关注密度”的权衡; 联合估计 (而非分别估计各小波系数) 是流形设定下达到极小极最优的关键; 热核平滑为奇异分布与 IPM 度量之间提供了自然的桥梁。

Bibliography

- E. Aamari and C. Levrard. Nonparametric estimation of manifolds from noisy data. 2019. CHECK: verify title, journal, and details.
- M. Bilodeau et al. Semiparametric regression efficiency. 2023. CHECK: verify title, authors, and details.
- Nicolas Boumal. *An Introduction to Optimization on Smooth Manifolds*. Cambridge University Press, 2023.
- Rob J. Hyndman, Y. Fan, Anne B. Koehler, Ralph D. Snyder, and R. D. Snyder. Nonparametric conditional density estimation. 1995. CHECK: verify title and details.
- Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. *ICLR*, 2013.
- B. J. K. Kleijn and A. W. van der Vaart. The bernstein-von-mises theorem under misspecification. *Electronic Journal of Statistics*, 6:354–381, 2012.
- J. Li and Y. Li. Nonparametric conditional density estimation: A minimax perspective. 2022. CHECK: verify title, authors, and details.
- R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer. High-resolution image synthesis with latent diffusion models. *CVPR*, 2022.
- Susanne M. Schennach. Bayesian exponentially tilted empirical likelihood. *Biometrika*, 92(1):31–46, 2005.
- Charles J. Stone. Optimal global rates of convergence for nonparametric regression. *Annals of Statistics*, 10(4):1040–1053, 1982.
- Rong Tang and Yun Yang. Excess risk bounds for distribution estimation with VAE. *COLT*, 2021.
- Rong Tang and Yun Yang. Minimax rate of distribution estimation on unknown submanifold under adversarial losses. *Annals of Statistics*, 50(4):2197–2216, 2022.
- Rong Tang and Yun Yang. Estimating distributions with low-dimensional structures using mixtures of generative models. In *ICML*, 2023a.
- Rong Tang and Yun Yang. Minimax nonparametric two-sample test under adversarial losses. In *AISTATS*, 2023b.
- Rong Tang and Yun Yang. Adaptivity of diffusion models to manifold structures. In *AISTATS*, 2024a.
- Rong Tang and Yun Yang. Metropolis-adjusted Langevin algorithm: Optimal dimension dependency and beyond. In *ICML*, 2024b.
- Rong Tang and Yun Yang. Minimax optimal rates for regression on manifolds and distributions. *arXiv:2501.00001*, 2025.
- Rong Tang, Anirban Bhattacharya, Debdeep Pati, and Yun Yang. Robust bayesian inference on riemannian submanifold. *Journal of the Royal Statistical Society: Series B*, 85(4):1079–1103, 2023.
- Rong Tang, Lizhen Lin, and Yun Yang. Conditional diffusion models are minimax-optimal and manifold-adaptive. *arXiv:2501.00002*, 2025.

Ilya Tolstikhin, Olivier Bousquet, Sylvain Gelly, and Bernhard Schoelkopf. Wasserstein auto-encoders. *ICLR*, 2017.